分类号_____ 学号 202204601004

学校代码 10488 密级_____

武漢科技大学

博士学位论文

先验知识引导的离焦模糊图估计与图像去模糊方法研究

学位申请人：李晓盼

学 科 专 业：控制科学与工程

指 导 教 师：伍世虔

答 辩 日 期：2025 年 9 月

中国知网 https://www.cnki.net

A Dissertation Submitted in Partial Fulfillment of the Requirements for the Degree of Doctor of Philosophy in Engineering

Research on Defocus Blur Map Estimation and Image Deblurring Methods Guided by Prior Knowledge

Ph.D. Candidate：	**Xiaopan Li**
Major：	**Control Science and Engineering**
Supervisor：	**Prof. Shiqian Wu**

Wuhan University of Science and Technology

Wuhan, Hubei 430081, China

September, 2025

中国知网 https://www.cnki.net

摘 要

图像作为信息传递的重要载体，不仅是人类感知与记录世界的基本方式，也是众多计算机视觉任务的数据来源。然而，在图像采集过程中，常因相机设置不当或场景条件受限而产生离焦模糊或运动模糊。前者通常由被摄体超出相机景深引起，后者则源于相机抖动或物体运动。这两类模糊均会导致图像细节的显著丢失，严重降低视觉质量，进而影响后续的图像分析与理解任务。尽管近年来图像模糊处理技术取得了显著进展，但在应对复杂场景时仍面临诸多挑战：在弱纹理与低对比度区域，模糊感知精度有限；对于空间变化显著的离焦模糊，高保真复原仍具困难；在均匀退化场景中，先验构建与优化效率尚待提升；而在动态模糊条件下，频率信息利用不足，限制了细节恢复能力。针对上述问题，本文引入一系列有效的先验知识，用以引导离焦模糊图估计与图像去模糊，从而显著提升算法在复杂场景下的去模糊性能。主要研究内容与创新贡献如下：

1）针对弱纹理与低对比度区域中模糊感知不准确的问题，本文提出了一种基于感知先验引导的离焦模糊图估计算法。该方法利用人类视觉系统在不同对比度下对模糊感知的差异，构建感知权重以调制再模糊奇异值差异特征，从而增强聚焦与离焦区域的可分性。同时，引入模糊-清晰边缘点作为额外约束，有效缓解无边缘区域中模糊估计困难的问题。实验结果表明，本文提出的方法在定量和定性评估上均优于现有方法，所生成的离焦模糊图可用于推导空间变化的模糊核，为后续的离焦去模糊提供重要先验支持，显著提升图像复原效果。

2）针对复杂离焦模糊场景下高保真复原困难的问题，本文提出了一种大模型先验引导的离焦去模糊算法。该方法结合微调后的大规模深度估计模型与语义识别模型，有效提取图像的结构与语义信息。随后，构建多模态融合模块，通过交叉注意力机制引导预训练的扩散模型生成高质量复原图像。进一步地，利用深度图先验生成离焦权重图，并结合加权拉普拉斯金字塔策略，自适应融合原图中清晰区域与扩散模型生成的细化结果，从而提升结构一致性与细节保真度。实验结果表明，本文提出的方法在离焦图像质量恢复方面显著优于现有方法。

3）针对均匀退化建模中图像先验与优化方法设计不足的问题，本文提出了

中国知网 https://www.cnki.net

一种基于动态极值先验的盲去模糊算法。该方法利用相机抖动导致的极值变化特性，引入图像块最大/最小像素值作为先验特征，并结合模糊 C 均值聚类算法，根据像素特征动态划分先验类别。聚类过程在每次迭代中自适应更新，以匹配中间潜在图像的特性。同时，设计稀疏诱导的优化策略以增强潜在图像的稀疏表达能力，并提升求解效率。实验结果表明，本文提出的方法在自然图像和特定领域图像上的去模糊质量和计算效率方面均优于现有方法。

4）针对频率信息利用不足而导致细节恢复受限的问题，本文提出了一种基于频率先验引导的扩散模型去模糊算法。该方法利用预训练的频率特征，并通过交叉注意力机制将其分层注入扩散模型，有效恢复图像中的低频与高频分量。此外，将模糊图像与频率先验联合作为条件信息，引导扩散模型更准确地建模复杂的模糊分布，显著增强其在真实动态模糊场景中的适应能力。实验结果表明，本文提出的方法在真实运动模糊图像中的细节还原能力明显优于现有先进方法。

综上所述，本文围绕图像模糊处理中的问题，提出了一系列基于感知先验、大模型先验、动态极值先验和频率先验的创新方法，系统解决了弱纹理感知、高保真复原、均匀退化建模以及高频细节还原等难题，显著提升了离焦模糊图的估计精度与图像复原质量，增强了模型在复杂场景中的泛化能力。

关键词： 离焦模糊图估计；图像去模糊；先验引导；扩散模型；注意力机制

中国知网 https://www.cnki.net

Abstract

Images, as a crucial medium for information transmission, not only serve as a fundamental means for humans to perceive and record the world but also constitute essential data sources for numerous computer vision tasks. However, during image acquisition, defocus or motion blur often occurs due to improper camera settings or constrained scene conditions. The former is typically caused by subjects falling outside the camera's depth of field, while the latter stems from camera shake or object movement. Both types of blur lead to significant loss of image details and textures, severely degrading visual quality and impairing the performance of subsequent image analysis and understanding tasks. Although image deblurring techniques have made remarkable progress in recent years, challenges remain in handling complex real-world scenarios. Specifically, blur estimation in weak-texture or low-contrast regions is often inaccurate; high-fidelity restoration of spatially varying defocus blur is difficult; prior construction and optimization in uniformly degraded scenes are inefficient; and insufficient utilization of frequency information limits the recovery of fine details. To address these challenges, this dissertation introduces a series of effective prior-guided mechanisms for defocus blur map estimation and image deblurring. These priors significantly enhance the performance of deblurring algorithms under complex and diverse conditions. The main contributions are summarized as follows:

1) To address the challenge of inaccurate blur perception in low-texture and low-contrast regions, a perceptual-prior-guided defocus blur map estimation algorithm is proposed. Inspired by the human visual system's sensitivity to blur under varying contrast conditions, perceptual weights are designed to modulate the re-blurred singular value difference features, enhancing the discriminability between focused and defocused regions. Furthermore, blur-sharp edge points are incorporated as additional constraints, effectively mitigating the difficulty of blur estimation in edge-less areas. Experimental results demonstrate that the proposed method outperforms existing techniques in both quantitative metrics and qualitative visual quality. The resulting defocus blur maps can also be used to derive spatially-varying blur kernels, providing essential prior support for subsequent defocus deblurring and significantly improving

中国知网 https://www.cnki.net

restoration quality.

2) To address the challenge of high-fidelity restoration in complex defocus blur scenarios, a defocus deblurring algorithm guided by large-model priors is proposed. Structural and semantic features are extracted by fine-tuned large-scale depth estimation and semantic recognition models, and then integrated into a pre-trained diffusion model through a multimodal cross-attention module. A defocus weight map is generated based on the depth prior, and a weighted Laplacian pyramid strategy is employed to adaptively fuse clear regions from the underlying image with the diffusion model's output, thereby enhancing structural consistency and preserving fine details. Experimental results demonstrate that the effectiveness of the proposed method is validated in restoring complex defocused images with high fidelity.

3) To address the limitations in prior construction and optimization in uniformly degraded scenarios, a blind deblurring algorithm based on dynamic extremum priors is proposed. Extremum changes caused by camera shake are exploited, with the maximum and minimum pixel values of image patches used as prior features. A fuzzy C-means clustering algorithm is employed to dynamically classify prior categories based on pixel features, and the clustering process is adaptively updated in each iteration to match the characteristics of the intermediate latent image. Additionally, a sparsity-inducing strategy is designed to enhance the sparse representation of the latent image and improve computational efficiency. Experimental results demonstrate that the proposed method outperforms existing techniques in both deblurring quality and efficiency across natural and domain-specific images.

4) To address the insufficient utilization of frequency information that limits detail restoration, a frequency-prior-guided diffusion model is proposed for deblurring. Pre-trained frequency features are hierarchically injected into the diffusion model through a cross-attention mechanism, enabling effective recovery of both low- and high-frequency components of images. Moreover, the blurry image and frequency prior are jointly used as conditional information to guide the diffusion model in accurately modeling complex blur distributions, thereby significantly improving adaptability in real dynamic blur scenarios. Experimental results demonstrate that the proposed method achieves superior detail restoration in real motion-blurred images compared to state-of-the-art methods.

中国知网 https://www.cnki.net

In conclusion, this dissertation proposes a series of innovative algorithms for image deblurring, guided by perceptual priors, large-model priors, dynamic extremum priors, and frequency priors respectively. These proposed algorithms systematically address challenges related to weak-texture blur perception, high-fidelity restoration, uniform degradation modeling, and high-frequency detail recovery. As a result, the proposed approaches significantly improve the accuracy of defocus blur estimation and the quality of image restoration, while enhancing the model's generalization ability in complex real-world scenarios.

Keywords: Defocus blur map estimation; Image deblurring; Prior guidance; Diffusion model; Attention mechanism

中国知网 https://www.cnki.net

插图索引

图 1.1 不同成像设备及其采集的图像示例 1
图 1.2 不同类型的模糊图像示例 2
图 1.3 图像去模糊的应用领域 3
图 1.4 图像模糊研究在“中国知网”中的年度发文量及学科分布 5
图 1.5 图像金字塔“由粗到细”的多尺度估计示意图 10
图 1.6 基于深度学习方法的示意图 11
图 1.7 基于 GAN 的图像去模糊算法流程图 13
图 1.8 基于 Transformer 的图像去模糊算法流程图 14
图 1.9 扩散模型的结构示意图 15
图 1.10 本文的研究内容与组织结构 20
图 2.1 离焦模糊图像的成像原理 23
图 2.2 不同位置物点成像的示意图 23
图 2.3 运动模糊图像的成像原理 24
图 2.4 离焦模糊核与运动模糊核的表现形式 26
图 2.5 σ_{JNB} 非线性拟合示意图 29
图 2.6 图像中边缘像素及其宽度测量示意图 30
图 2.7 暗通道与亮通道先验的统计分布 33
图 2.8 图像小波分解与重构示意图 35
图 2.9 清晰图与模糊图进行两级小波分解后的信息熵对比 35
图 3.1 感知加权的离焦模糊图估计框架 38
图 3.2 一维边缘模型示意图 39
图 3.3 清晰块和模糊块的统计结果 40
图 3.4 不同α的映射结果 41
图 3.5 基于 RESVD 稀疏模糊图估计流程图 42
图 3.6 基于 RESVD 稀疏模糊图估计的失败案例 43
图 3.7 清晰块和模糊块模糊度分布的比较 44
图 3.8 添加边缘点的示意图 45
图 3.9 不同方法 PR 曲线的比较 50
图 3.10 不同方法在 CUHK 数据集上的视觉比较 52
图 3.11 不同方法在 CTCUG 数据集上的视觉比较 53
图 3.12 不同分量 PR 曲线的比较 55

中国知网 https://www.cnki.net

图 3.13 不同分量有效性的视觉比较 56
图 3.14 不同离焦模糊图的去模糊结果比较 59
图 4.1 两阶段离焦去模糊框架示意图 62
图 4.2 可控稳定扩散模型架构示意图 63
图 4.3 不同方法获取的标签提示及其对应的去模糊结果对比 64
图 4.4 DepthAnything 模型生成深度图的可视化效果 65
图 4.5 多模态融合模块示意图 66
图 4.6 所提方法中间结果的可视化 68
图 4.7 加权拉普拉斯金字塔融合示意图 69
图 4.8 不同方法在四个数据集上的定性比较 75
图 4.9 CUHK 数据集中人物图像的定性比较 76
图 4.10 CUHK 数据集中风景图像的定性比较 77
图 4.11 来自 CUHK 数据集上的例子 78
图 4.12 七种配置下消融实验的定性比较 79
图 4.13 DWF 和 WLPF 对去模糊结果的定性比较 80
图 5.1 模糊对不同图像块极强度值的影响 84
图 5.2 PMaxP 和 PMinP 的统计分布 89
图 5.3 清晰图像和模糊图像在 PMaxP 和 PMinP 上的差异统计 89
图 5.4 基于动态极值先验的图像去模糊示意图 90
图 5.5 Levin 数据集上估计的模糊核 97
图 5.6 不同方法在 Köhler 数据集上的定量比较 98
图 5.7 自然图像上的视觉比较 100
图 5.8 人脸图像上的视觉比较 101
图 5.9 低光照图像上的视觉比较 101
图 5.10 不同先验对去模糊结果的定量比较 102
图 5.11 不同先验对去模糊结果的视觉比较 103
图 5.12 稀疏诱导算法的有效性 103
图 5.13 所提算法的收敛性分析 104
图 6.1 扩散模型中不同条件的比较 106
图 6.2 模糊、预测和清晰图像的小波系数比较 107
图 6.3 频率先验引导的扩散模型框架 108
图 6.4 提出的 PFRNet 网络结构示意图 111
图 6.5 去噪过程框架的示意图 112
图 6.6 不同方法在 GoPro 和 HIDE 数据集上的定性比较 118

中国知网 https://www.cnki.net

图 6.7 不同方法在 RealBlur-R 和 RealBlur-J 数据集上的定性比较..... 118
图 6.8 模糊、预测和清晰图像在三个尺度上的小波系数信息熵..... 119
图 6.9 MFCA 模块消融实验的视觉对比结果..... 121
图 6.10 粗训练和精训练结果的定性比较..... 122
图 6.11 不同方法在 Köhler 数据集上的定性比较..... 123

中国知网 https://www.cnki.net

表格索引

表 1.1 图像去模糊方法对比 16
表 2.1 不同对比度下测量的 σ_{JNB} 和 w_{JNB} 值 30
表 3.1 再模糊参数的选择 47
表 3.2 感知权重参数的选择 48
表 3.3 不同方法的定量比较 51
表 3.4 CUHK 数据集在相同数据划分下的定量比较 52
表 3.5 使用不同分量的定量比较 54
表 3.6 使用不同离焦模糊图的去模糊结果的定量比较 58
表 4.1 不同方法在 DPDD 数据集上的定量比较 73
表 4.2 不同方法在 RealDOF 数据集上的定量比较 73
表 4.3 不同方法在 LFDOF 数据集上的定量比较 74
表 4.4 不同方法在 RTF 数据集上的定量比较 74
表 4.5 七种配置下消融实验的定量比较 78
表 4.6 DWF 和 WLPF 对去模糊结果的定量比较 81
表 4.7 不同方法在 DPDD 和 RTF 数据集上的定量比较 81
表 4.8 模型复杂度比较 82
表 5.1 不同方法在 Levin 数据集上的定量比较 97
表 5.2 不同方法在 Lai 数据集上的 PSNR 值 99
表 5.3 不同方法在 Lai 数据集上的 SSIM 值 99
表 5.4 不同方法在 Lai 数据集上的 KS 值 100
表 5.5 不同方法运行时间（秒）比较 105
表 6.1 不同方法在 GoPro 和 HIDE 数据集上的定量比较 116
表 6.2 不同方法在 RealBlur-R 和 RealBlur-J 数据集上的定量比较 117
表 6.3 不同规模的 PFRNet 网络结构的消融实验 119
表 6.4 不同小波系数的消融研究 120
表 6.5 关于 MFCA 消融研究的定量比较 120
表 6.6 单独训练和联合训练结果的定量比较 121
表 6.7 “由粗到精”训练策略有效性的定量比较 122
表 6.8 不同方法在 Köhler 数据集上的定量比较 123
表 6.9 模型复杂度比较 124

中国知网 https://www.cnki.net

符号对照表

符号	符号名称
$\|\|\cdot\|\|_0$	L_0 范数
$\|\|\cdot\|\|_1$	L_1 范数
$\|\|\cdot\|\|_2$	L_2 范数
$\mathrm{sign}(\cdot)$	符号函数
$erf(\cdot)$	误差函数
$p(\cdot)$	模糊检测的概率
Δ	拉普拉斯算子
∇	梯度算子
$\otimes$	卷积算子
$\mathcal{F}$	傅里叶变换
$\mathcal{F}^{-1}$	傅里叶逆变换
$\mathbb{E}$	期望
$\mathcal{N}(0,\mathbf{I})$	标准正态分布
$P_a(\cdot)$	计算最大像素值
$P_b(\cdot)$	计算最小像素值
$\mathcal{M}$	最大像素主导的块集合
$\mathcal{N}$	最小像素主导的块集合
Ω	图像的邻域集合
e_i	边缘点
ϵ_θ	噪声预测网络
$\cap$	交集符号
$\cup$	并集符号
$diag(\cdot)$	对角矩阵
$\mathbb{R}$	实数域

中国知网 https://www.cnki.net

缩略语对照表

缩略语	英文全称	中文对照
CoC	Circle of Confusion	散光圈
IMU	Inertial Measurement Unit	惯性测量单元
LBP	Local Binary Patterns	局部二值模式
LDMP	Local Directional Mean Pattern	局部方向均值模式
MSDP	Multisequential Deviated Pattern	多序列偏差模式
JNB	Just Noticeable Blur	恰可察觉模糊
DDPM	Denoising Diffusion Probabilistic Model	去噪扩散概率模型
DDIM	Denoising Diffusion Implicit Model	去噪扩散隐式模型
DDRM	Denoising Diffusion Restoration Model	去噪扩散恢复模型
SD	Stable Diffusion	稳定扩散
RAM	Recognize Anything Model	通用识别模型
CNN	Convolutional Neural Network	卷积神经网络
RNN	Recurrent Neural Network	循环神经网络
GAN	Generative Adversarial Network	生成对抗网络
DM	Diffusion Model	扩散模型
MAP	Maximum A Posterior	最大后验概率
EM	Expectation-Maximization	期望最大化
TV	Total Variation	总变分
SVD	Singular Value Decomposition	奇异值分解
DFT	Discrete Fourier Transform	离散傅里叶变换
DCT	Discrete Cosine Transformation	离散余弦变换
DWT	Discrete Wavelet Transform	离散小波变换
HVS	Human Visual System	人类视觉系统
RESVD	Re-blurred Singular Value Difference	再模糊奇异值差异
DCP	Dark Channel Prior	暗通道先验

中国知网 https://www.cnki.net

BCP	Bright Channel Prior	亮通道先验
PMaxP	Patch-wise Maximal Pixels	逐块最大像素
PMinP	Patch-wise Minimal Pixels	逐块最小像素
FCM	Fuzzy C-Means	模糊 C 均值
SI	Sparsity Inducing	稀疏诱导
HQS	Half Quadratic Splitting	半二次分裂
PR	Precision-Recall	准确率-召回率
MAE	Mean Absolute Error	平均绝对误差
PSNR	Peak Signal-to-Noise Ratio	峰值信噪比
SSIM	Structural Similarity	结构相似度
CER	Cumulative Error Ratio	积累误差比
KS	Kernel Similarity	核相似度
LPIPS	Learned Perceptual Image Patch Similarity	学习感知图像块相似性
DISTS	Deep Image Structure and Texture Similarity	深度图像结构和纹理相似性
FID	Fréchet Inception Distance	Fréchet Inception 距离
NIQE	Naturalness Image Quality Evaluator	自然图像质量评估器

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景与意义.....1
1.2 图像模糊处理的研究现状.....4
1.2.1 离焦模糊处理研究.....5
1.2.2 运动模糊处理研究.....9
1.3 存在的问题.....16
1.4 本文主要研究内容.....18
1.5 本文的组织结构.....19
第 2 章 图像模糊处理的理论基础.....22
2.1 引言.....22
2.2 图像模糊成因.....22
2.2.1 离焦模糊成因.....22
2.2.2 运动模糊成因.....23
2.3 图像模糊数学模型与病态性分析.....24
2.3.1 图像模糊数学模型.....24
2.3.2 图像模糊模型的病态性分析.....26
2.4 常用的图像先验.....28
2.4.1 感知先验.....28
2.4.2 大模型先验.....31
2.4.3 极值先验.....32
2.4.4 频率先验.....34
2.5 本章小结.....36
第 3 章 基于感知先验的离焦模糊图估计方法.....37
3.1 引言.....37
3.2 感知先验引导的离焦模糊图估计算法.....38
3.2.1 边缘检测.....38
3.2.2 基于 RESVD 的模糊度量算子.....39
3.2.3 感知先验加权的度量算子.....43
3.2.4 额外边缘点约束.....45
3.2.5 完整离焦模糊图估计.....46
3.3 实验结果与分析.....47
3.3.1 实验设置.....47
3.3.2 数据集与评价指标.....48
3.3.3 定量与定性实验结果.....50

中国知网 https://www.cnki.net

3.3.4 消融实验.....54
3.3.5 离焦去模糊.....56
3.4 本章小结.....60
第 4 章 基于大模型先验的离焦去模糊方法.....61
4.1 引言.....61
4.2 多模态引导与深度先验融合的离焦去模糊算法.....62
4.2.1 多模态先验引导的稳定扩散模型.....63
4.2.2 深度先验融合网络.....67
4.3 实验结果与分析.....71
4.3.1 实验设置.....71
4.3.2 数据集与评价指标.....71
4.3.3 定量与定性实验结果.....72
4.3.4 消融实验.....78
4.3.5 鲁棒性与复杂性分析.....81
4.4 本章小结.....83
第 5 章 基于动态极值先验的图像盲去模糊方法.....84
5.1 引言.....84
5.2 逐块极值像素先验.....85
5.2.1 理论证明.....86
5.2.2 统计分析.....88
5.3 基于动态极值先验的图像去模糊模型.....90
5.3.1 潜在图像的估计.....91
5.3.2 模糊核的估计.....93
5.3.3 算法实现的细节.....94
5.4 实验结果与分析.....95
5.4.1 实验设置.....95
5.4.2 数据集与评价指标.....95
5.4.3 基准数据集的实验结果.....96
5.4.4 特定域图像的实验结果.....100
5.4.5 消融实验.....102
5.4.6 收敛性分析与运行时间比较.....104
5.5 本章小结.....105
第 6 章 基于频率先验的动态场景去模糊方法.....106
6.1 引言.....106
6.2 频率先验引导的扩散模型.....107
6.2.1 随机前向扩散过程.....108
6.2.2 确定性反向去噪过程.....109
6.2.3 损失函数.....113

中国知网 https://www.cnki.net

6.3 实验结果与分析.....114
6.3.1 实验设置.....114
6.3.2 数据集与评价指标.....114
6.3.3 定量与定性实验结果.....115
6.3.4 消融实验.....119
6.3.5 鲁棒性与复杂性分析.....122
6.4 本章小结.....125
第 7 章 总结与展望.....126
7.1 全文总结.....126
7.2 工作展望.....128
参考文献.....129

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景与意义

视觉是人类感知外部世界并获取信息的最重要方式之一。数字图像作为记录客观世界的重要载体，是人类视觉信息的重要来源。随着监控设备、智能手机、数码相机以及无人机等成像设备的普及，海量图像数据不断涌现，为社会生产、日常生活以及科学研究提供了丰富的信息支持。图 1.1 展示了几种常见的数字图像成像设备以及其对应的采集图像示例。



图 1.1 不同成像设备及其采集的图像示例

Figure 1.1 Examples of images captured by different imaging devices

然而，在图像采集过程中，由于成像设备抖动、相机或拍摄目标的运动、对焦误差以及场景深度变化等因素，图像往往会出现信息缺失和质量下降，难以准确反映真实场景[1]。根据模糊的成因，图像模糊通常可分为两大类：离焦模糊与运动模糊。图 1.2 展示了这两类模糊的典型图像示例。离焦模糊通常由被摄对象处于相机景深范围之外引起，导致图像整体或局部出现模糊，具体表现为边缘轮廓不清晰或纹理细节缺失（如图 1.2（a）所示）。运动模糊则进一步分为两种类型：一种是由相机在曝光期间发生抖动所导致的全局运动模糊（如图 1.2（b）所示），另一种则是由于拍摄场景中物体自身运动所引起的局部运动模糊（如图 1.2（c）所示）。其中，全局运动模糊影响整幅图像，其模糊程度与相机运动的方向和速度密切相关，具有整体性与模糊连续性的特征；相比之下，局部运动模糊通常呈现空间不均匀性，运动速度越快的物体其模糊程度越高，而静止区域则基本

中国知网 https://www.cnki.net

保持清晰。这两类模糊不仅显著降低图像的视觉质量，还会严重削弱其结构信息与可用性，进而影响如目标检测、识别、跟踪与分割等高层次视觉任务的性能。



(a) 离焦模糊　　(b) 相机抖动模糊　　(c) 物体运动模糊

图 1.2 不同类型的模糊图像示例

Figure 1.2 Examples of different types of blurred images

近年来，随着图像、视频等多媒体技术的快速发展，模糊现象在数码影像、社交媒体、工业检测等各类实际应用中普遍存在。尤其在深空探测、军事侦察、地质勘探和视频监控等关键场景中，受限于拍摄条件或不可重复的拍摄时机，模糊图像往往难以重新获取，其清晰度直接关系到任务执行的成败。因此，如何有效去除模糊并恢复潜在的清晰图像，一直是国内外图像处理领域研究的核心问题之一。图像去模糊技术具有广泛的应用价值，几乎涵盖所有涉及图像获取和处理的场景，不仅在理论研究中占据重要地位，也在诸多实际应用中发挥着关键作用。其主要应用领域包括但不限于：

1）安防监控领域。智能视频监控通过计算机视觉技术分析监控场景，以提取关键信息并生成事件或警报。然而，监控视频通常采用无约束图像捕获方式，不同的拍摄角度、时间和地点会导致目标的姿态、形态、光照及分辨率变化，进而引发图像模糊和成像质量下降（如图 1.3（a）所示）。利用图像去模糊技术可有效恢复清晰图像，提升监控效果，从而为公共安全和社会治安提供有力支持。

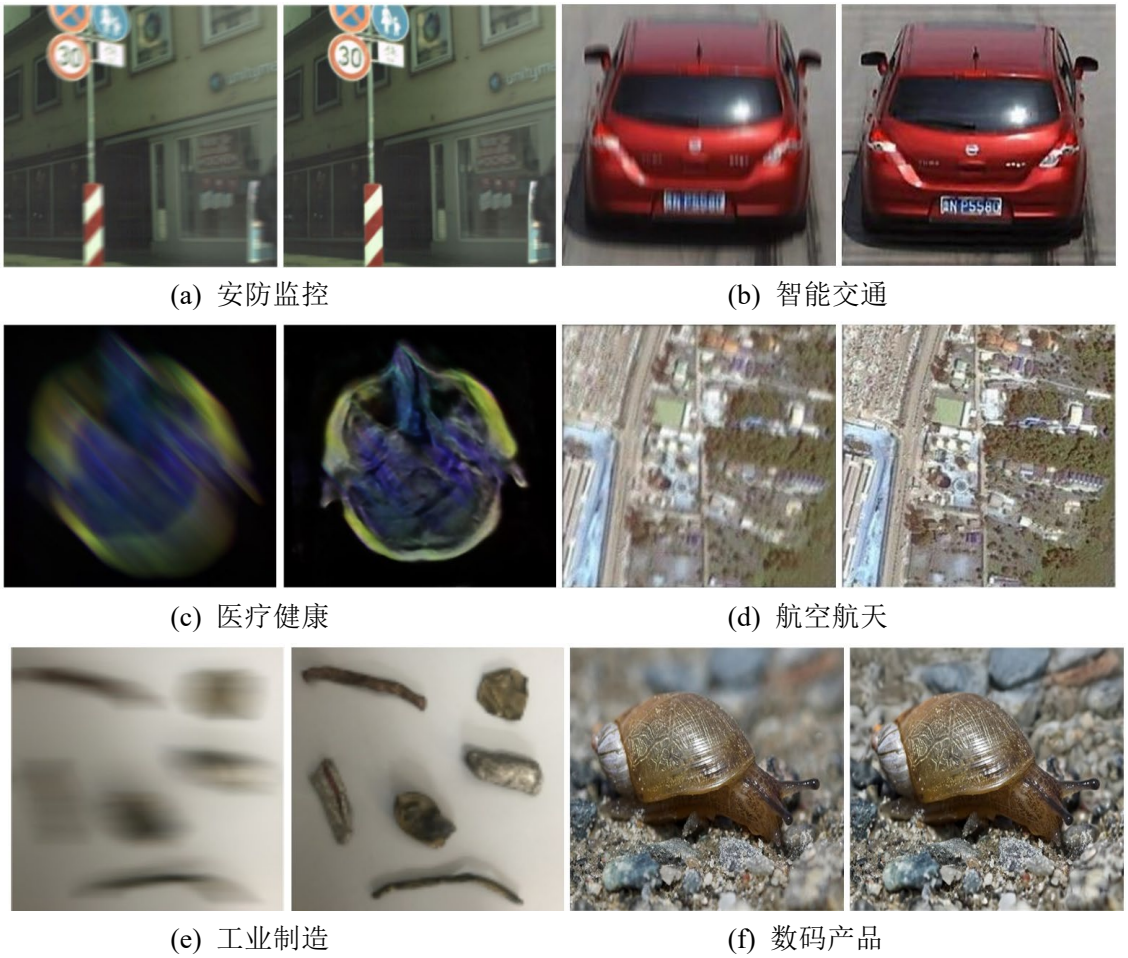
2）智能交通领域。随着城市交通需求的增长，交通拥堵和事故频发等问题日益突出。智能交通系统通过融合计算机视觉、云端通讯和车辆工程技术，有效提升交通管理效率。然而，在高速行驶、传感器抖动及恶劣天气等因素影响下，交通图像易出现模糊，干扰目标物体的识别。图像去模糊技术能够显著提升图像质量，尤其在关键区域的清晰度和可辨识性方面表现突出[2]。如图 1.3（b）所示，模糊图像中的车牌信息难以辨识，而去模糊处理后，车牌可清晰呈现。

3）医疗健康领域。医学图像处理在现代医疗中起到了至关重要的作用，有助于提高诊断精度和治疗质量[3]。然而，由于成像设备的技术限制、曝光时间与辐射剂量的平衡，以及患者自主或非自主运动等因素，医学图像中往往存在模糊或伪影，影响诊断的准确性。图像去模糊技术在此类场景中具有重要意义，能够

中国知网　https://www.cnki.net

有效降低模糊，显著提升图像的清晰度，使医生能够获取更丰富的诊断信息。如图 1.3（c）所示，复原后的医学图像提供了更清晰、更有价值的临床信息。

4）航空航天领域。图像处理技术广泛应用于太空探测和遥感成像任务[4]。然而，由于大气湍流、远距离成像等不利因素，获取的图像往往存在显著的模糊现象。为满足航空航天领域对图像信息质量的严格要求，图像去模糊技术已成为不可或缺的重要手段，推动了相关图像处理技术的不断创新与发展。如图 1.3（d）所示，复原后的遥感图像较原始图像具有更丰富的细节和更清晰的纹理，为准确观测和科学研究提供了有力保障。



(a) 安防监控　(b) 智能交通　(c) 医疗健康　(d) 航空航天　(e) 工业制造　(f) 数码产品

图 1.3 图像去模糊的应用领域

Figure 1.3 Applications of image deblurring

5）工业制造领域。人工智能和信息技术的快速发展推动了制造业的智能化和自动化转型，数字图像处理技术在无损检测、缺陷检测和流水线检测等工业检测任务中得到了广泛应用[5]。图像去模糊技术不仅提高了检测的精度和效率，还有效降低了成本。随着工业设计和视觉技术的不断进步，智能机器人在制造业中

中国知网 https://www.cnki.net

的应用愈发广泛，进一步推动了对高效、精准的图像去模糊技术的需求。如图 1.3（e）所示，模糊图像中的零件细节难以分辨，而复原后的图像清晰地呈现了零件的原始结构，便于检测与分析。

6）数码产品领域。随着数码相机、手机等多媒体电子产品的广泛普及，用户对高质量视觉体验的需求不断增长。然而，由于手机和小型数码相机的体积小、成像装置简化及性能限制，加之手持拍摄中的抖动及复杂场景对焦不准等因素，拍摄的图像易出现模糊，影响图像质量。图像去模糊技术可有效提升图像清晰度，弥补设备性能的不足。如图 1.3（f）所示，经过去模糊处理的图像显著提升了视觉清晰度。

尽管现代拍摄设备通过集成惯性测量单元（Inertial Measurement Unit，IMU）和光学防抖等硬件技术，在一定程度上提升了图像清晰度并减轻了拍摄过程中的模糊问题，但硬件手段依然存在局限性。其在应对快速运动、复杂场景下的空间变化模糊（如离焦模糊）、低光照环境以及对已采集模糊图像的后期修复方面，仍显不足[6]。因此，基于软件的图像去模糊方法因其更高的灵活性与性价比，依然是研究与应用的重点方向。一方面，软件算法可嵌入硬件设备中，与传感器数据协同工作，实现拍摄过程中的实时去模糊，满足移动设备和消费电子产品对实时性与便捷性的需求；另一方面，针对高精度或特定应用场景，软件方法还可对已采集的模糊图像进行离线后处理，用户可根据需求调节参数，以获得更优的图像恢复效果，从而满足多样化与高质量的图像处理需求。未来，图像去模糊技术将持续演进，其在不同时代背景与应用场景中的价值和意义也将不断深化，进一步推动图像处理技术向更高水平发展。

1.2 图像模糊处理的研究现状

图像模糊处理是图像复原领域的核心研究方向，近年来在学术界备受关注，并取得了诸多重要进展。作为图像复原的重要分支，其研究目标和方法与图像增强、图像重建存在本质区别[7]。图像增强主要通过调节对比度、亮度或色彩等视觉属性提升图像观感，通常不依赖于退化模型；图像重建则通常基于多幅图像，通过推理和映射操作重构目标图像。而图像模糊处理的核心在于从单幅退化图像中恢复出清晰图像，其依赖于退化模型与先验知识，目标是提升图像的可用性与真实感。在具体研究方向上，离焦模糊图估计与去除、运动去模糊是长期以来的研究热点，国内外学者围绕这些问题提出了众多有代表性的成果。例如，大连理工大学赵文达等人[8–11]和巴西的 Karaali 等人[12,13]分别基于学习方法和边缘特征分析方法在离焦模糊图估计与去模糊方面取得了较为优异的成果；华南理工大学全宇晖等人[14–16]在基于深度学习的离焦图像复原方面表现突出；南京理工大学潘金

中国知网 https://www.cnki.net

山等人[17–19]与加州大学 Merced 分校的 Yang 等人[20,21]在运动去模糊方向也提出了多种基于深度学习与优化求解的方法。

为全面了解图像模糊处理领域的研究现状与发展趋势，本文基于“中国知网”对 2005 年至 2024 年间相关研究文献的数量及学科分布进行了系统检索与统计（统计时间截至 2025 年 6 月 1 日）。统计结果表明，以“图像模糊”、“离焦模糊”或“运动模糊”为主题词的文献总数达到 12780 篇，其中中文文献为 9183 篇，外文文献为 3597 篇。需要指出的是，由于 2024 年部分文献尚未完整录入数据库，该年度的统计数据可能略低于实际水平。图 1.4 分别展示了图像模糊研究在不同年份的文献数量变化以及相关文献的学科分布情况。可以观察到，该研究方向在多个学科中均得到了广泛应用，尤以计算机软件与应用、自动化技术等领域最为显著。从文献数量的年增长趋势来看，图像模糊处理领域持续受到学术界的高度关注，近年来相关研究文献的发表数量已趋于稳定并维持在较高水平。上述统计结果充分体现了该领域突出的科研价值与广阔的发展前景，进一步说明其在实际问题求解中的重要意义与应用潜力。

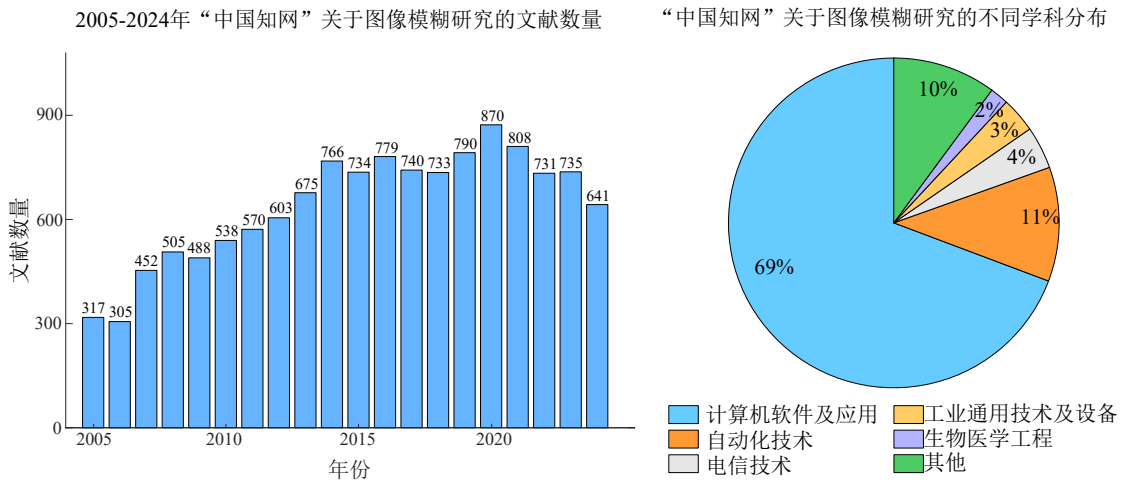


图 1.4 图像模糊研究在“中国知网”中的年度发文量及学科分布

Figure 1.4 Annual publication volume and disciplinary distribution of image blur research in the “China National Knowledge Infrastructure (CNKI)”

1.2.1 离焦模糊处理研究

离焦模糊是图像退化中常见的一种类型，尤其在消费级相机设备中较为普遍。根据薄透镜成像模型，理想情况下，来自焦平面的光线在成像平面上汇聚为清晰的点，从而生成清晰图像；而来自其他深度平面的光线则在成像平面上形成“散光圈”（Circle of Confusion，CoC），造成不同程度的模糊。焦平面与非焦平面之间的距离越大，对应的散光圈越大，模糊程度也越显著。由于物体与相机之间的距离分布不一，图像中往往存在空间变化的模糊现象，使得单一模糊核难

中国知网 https://www.cnki.net

以准确描述整幅图像的模糊过程。因此，如何准确建模离焦模糊、并有效还原清晰图像成为该领域的研究重点。主流方法主要分为两大类：基于离焦模糊图估计的传统方法与基于深度学习的端到端方法。

（1）基于离焦模糊图估计的传统方法

基于离焦模糊图估计的传统方法将去模糊任务划分为两个相对独立的子任务：首先对图像中不同区域的模糊程度进行估计，生成一张离焦模糊图；然后依据该模糊图，通过非盲反卷积方法实现清晰图像的复原。针对离焦模糊图的估计方法，现有研究大致可分为三类：基于像素的方法、基于边缘的方法和基于学习的方法，下文将对这三类方法进行系统阐述。

基于像素的方法通常利用滑动窗口法依次计算图像中所有像素的模糊度来获得模糊图。在这个过程中，单个像素的模糊度常常是在一个以该像素为中心的窗口中直接计算得到，即利用像素邻域信息来推断像素模糊度大小。Xiao 等人[22]提出了一种基于多尺度奇异值融合特征来检测图像中的局部模糊。Yi 等人[23]对模糊区域和清晰区域中不同局部二值模式（Local Binary Patterns，LBP）出现的频率进行统计，并以此为依据来构造模糊特征。Kehan 等人[24,25]在 Yi 等人[23]工作的基础上，提出了一种基于局部方向均值模式（Local Directional Mean Patterns，LDMP）[24]和多序列偏差模式（Multisequential Deviated Patterns，MSDPs）[25]，以提升模糊度描述能力。Golestaneh 等人[26]则设计了一种基于梯度幅度的高频多尺度融合和排序变换系数的模糊特征。梁晓等人[27]提出了一种基于沃尔什-哈达玛变换的列率域特征，以此来进行逐像素点的模糊图估计。章秀华等人[28]提出了一种基于奇异值差分测量的方法，计算模糊图像与其再模糊图像之间的像素差异以构造模糊特征。基于像素的方法原理相对简单，模糊特征的构造方式比较灵活，是最为常用的一类模糊图估计的方法。然而，由于光滑区域中缺乏明显纹理，往往难以准确估计模糊度[29]。此外，在较大的窗口中计算中心像素模糊度时，可能会破坏原始图像的结构信息，从而降低边缘定位精度。

基于边缘的方法一般分为两步：首先对边缘像素的模糊度进行估计以得到稀疏模糊图，然后依据稀疏模糊图来对其余位置像素进行插值以获得完整的模糊图，插值的过程也就是模糊信息传播的过程。图像的边缘含有丰富的梯度信息，这些梯度信息同边缘的模糊程度密切相关。Bae 等人[30]通过测量梯度方向上相反符号的二阶导数极值之间的距离以确定边缘像素模糊度。Zhuo 等人[31]将图像再模糊，通过计算再模糊前后边缘梯度幅度的变化来估计边缘像素的模糊度，并利用 Matting Laplacian 插值方法来将边缘像素模糊信息进行传播。Karaali 等人[13]基于 Zhuo 等人[31]的工作，研究了再模糊尺度的选择，优化了边缘像素模糊度的估计过程，并提出一种基于滤波的模糊信息传播方法。Ma 等人[32]将边缘图像块进行 DCT

中国知网 https://www.cnki.net

分解，从多个尺度上估计再模糊前后 DCT 系数的差异，从而确定边缘像素模糊度。Xu 等人[29]利用局部梯度域不同方向的最大秩来估计边缘像素的离焦模糊量。基于边缘的方法能够较好地保持图像的边缘轮廓信息，但整体性能高度依赖于边缘模糊度的准确估计。同时，边缘模糊信息的传播过程也不易控制，在无边缘区域易受噪声或结构干扰影响。

基于学习的方法通过训练分类器来学习模糊特征，从而实现离焦模糊图的自动估计。Shi 等人[33]将图像梯度分布特征、图像频谱特征和局部滤波器特征相结合，训练贝叶斯分类器以区分清晰与模糊区域。后续，Shi 等人[34]又通过字典学习方法，将稀疏边缘表示和模糊强度估计之间建立关联，用于检测恰可察觉模糊。近年来，深度学习方法在离焦模糊图估计任务中取得了显著进展。Park 等人[35]首先使用卷积神经网络提取深度特征，然后使用全卷积网络分类器检测离焦模糊。Huang 等人[36]设计了一个 6 层卷积神经网络来学习区分模糊特征。Tang 等人[37]提出了一种融合和细化多尺度的深度特征的卷积神经网络，用于离焦模糊检测。Zhao 等人[38]提出了一个自底向上的卷积网络，将低级线索与高级语义信息有效融合。Lee 等人[39]开发了首个用于空间变化离焦图估计的端到端卷积神经网络结构。Zhao 等人[9]引入了双对抗鉴别网络，生成精确的离焦模糊检测掩模。Li 等人[40]提出了一种基于多块和多尺度对比相似度学习的深度网络，用于无监督散焦模糊检测。Zhao 等人[11]设计了一个新的分离和组合框架，以执行不同的离焦模糊场景。虽然深度学习方法在性能上具备显著优势，但其训练过程往往依赖大量标注数据，模型结构复杂，泛化能力有限，并且其复杂的非线性机制使模型的可解释性受到限制。

获得能够反映图像中各像素点模糊强度的离焦模糊图后，可将其作为局部模糊核的参数，从而将清晰图像的恢复问题转化为一个具有已知空间变化模糊核的非盲反卷积问题。由于图像不同区域的离焦程度存在差异，相应的模糊核在空间上呈现非均匀分布。基于模糊图中每个像素所携带的模糊量信息，可在局部区域内拟合高斯核或其他核函数，构建一组空间变化的模糊核模型。例如，Zhuo 和 Sim[31]假设离焦模糊核服从高斯分布，通过在原始图像上施加额外的高斯模糊，并利用原图与再模糊图在边缘处的梯度比估计模糊核参数；Oliveira 等人[41]提出基于频域拉东变换（Radon Transform）的方法来估计离焦模糊核；Chen 等人[42]针对多光谱图像中的离焦问题进行了研究，指出在模糊程度较小时，使用高斯函数近似离焦模糊是合理的。尽管上述方法在离焦程度较轻、模糊分布相对简单的情况下表现良好，但在处理更复杂、接近真实场景的模糊图像时，存在一定局限。一方面，这些传统方法往往难以捕捉图像中的全局结构信息与高阶语义特征；另一方面，模糊图估计过程中的误差在后续的反卷积操作中可能被进一步放大，导

中国知网 https://www.cnki.net

致去模糊效果受限。近年来，随着深度学习的发展，计算机视觉各项任务取得了显著进展，基于深度学习的离焦去模糊方法在性能上也实现了突破，展现出更强的建模能力和对复杂模糊场景的适应性。

（2）基于深度学习的端到端方法

基于深度学习的端到端方法能够直接从模糊输入中恢复清晰图像，有效避免了传统方法中离焦图估计误差在反卷积过程中累积的问题。Abuolaim 等人[43]首次提出利用双像素（Dual-pixel，DP）传感器提供的两个子孔径视图（左视图和右视图）进行端到端的离焦去模糊。由于来自焦平面内的场景点在两个视图间几乎无相位差异，而焦平面外的点在左右视图中则存在显著差异，作者据此构建训练数据，并设计深度神经网络架构以从左右视图中直接估计清晰图像。虽然该方法在一定程度上增强了对空间变化模糊的建模能力，但其应用通常受限于特定传感器或数据集。针对空间变化和大范围离焦模糊问题，Lee 等人[44]提出了迭代滤波自适应网络（Iterative Filter Adaptive Network，IFAN）。该网络通过为每个像素预测一组可分离的局部去模糊滤波器，并引入迭代自适应卷积（Iterative Adaptive Convolution, IAC）模块，有效提升了对空间变化模糊的适应性。此外，Quan 等人[15]在网络训练中引入高斯核近似，利用大模糊区域中模糊核的高斯特性提高了模型泛化能力。但在应对非高斯、形状不规则的模糊核时，性能仍受限制。为此，Quan 等人[14]又提出基于结构正则化的逆核预测方法，采用多尺度隐式神经表征对逆核进行建模，从而进一步提升模型的去模糊能力。Tang 等人[45]则结合逆高斯核模块与逆卷积核预测模块，针对规则与不规则模糊联合建模，有效提升了恢复精度。尽管现有神经网络方法在定量指标上表现良好，但仍存在细节恢复能力不足的问题，特别是在高频纹理和结构信息的复原方面。近年来，去噪扩散概率模型[46]（Denoising Diffusion Probabilistic Models，DDPMs）展示了强大的图像生成与细节恢复能力，但其采样过程通常较为耗时。为提升效率，Song 等人[47]提出了去噪扩散隐式模型（Denoising Diffusion Implicit Models，DDIM），显著加快了采样速度。Rombach 等人[48]将 DDPM 扩展至潜在空间，在降低计算成本的同时推动了诸如稳定扩散（Stable Diffusion，SD）[48]和 CLIP（Contrastive Language-Image Pre-training）[49]等大规模预训练模型的发展。这些扩散模型在处理复杂图像生成任务中展现出较传统生成对抗网络更强的适应性和生成质量。为应对成像逆问题，Kawar 等人[50]提出了去噪扩散恢复模型（Denoising Diffusion Restoration Models，DDRM），在无需任务特定训练的前提下，利用预训练扩散模型解决恢复任务。Zhang 和 Agrawala[51]提出的 ControlNet 则允许在图像生成过程中引入边缘图、分割图等结构性条件，从而实现更精准的控制。一些研究者进一步引入高层语义模型[52,53]，增强了扩散模型的生成能力和语义一致性。然而，当前大多数

中国知网 https://www.cnki.net

基于扩散或深度学习的方法通常仅依赖输入图像作为条件，难以准确建模由光学系统和焦平面偏移引起的复杂、非均匀离焦退化过程。由于该过程高度空间变化，仅靠数据驱动学习易导致生成结果与真实场景存在偏差。因此，如何在扩散模型中有效融合语义先验与物理先验（如深度信息），提升模型对复杂离焦模糊模式的理解与适应能力，仍是当前研究中亟待解决的问题。

1.2.2 运动模糊处理研究

图像中的运动模糊通常由相机与场景之间或相机与运动物体之间的相对运动引起，其模糊程度受相对位移大小和相机曝光时间的影响。根据是否已知模糊核，图像运动去模糊研究大致可分为两类：非盲去模糊（模糊核已知）和盲去模糊（模糊核未知）。早期研究多聚焦于非盲去模糊，即在假设模糊核已知的条件下进行图像恢复。然而，在实际应用中，模糊核往往难以获取，因而盲去模糊问题逐渐成为该领域的研究重点与难点。传统盲去模糊方法通常依赖图像先验，通过交替优化策略迭代估计模糊核与清晰图像。这类方法大多假设模糊核在空间上均匀，即模糊主要源于相机抖动所导致的空间不变模糊。然而，该假设在真实场景中往往不成立，尤其在动态场景中，物体具有不同运动轨迹，模糊核在空间上呈现强烈变化，传统方法难以准确建模和恢复。随着深度学习技术的发展，基于神经网络的去模糊方法逐渐成为主流。此类方法无需显式估计模糊核，能够通过大规模数据学习从模糊图像中直接恢复清晰图像，具有端到端建模能力。与传统方法不同，深度学习方法更擅长处理动态场景中空间变化显著的非均匀模糊，能够捕捉高层语义特征和复杂的模糊退化模式，在恢复质量和运行效率上均表现出显著优势。目前，运动模糊处理研究主要分为两大方向：一是基于传统优化的方法，主要适用于均匀模糊建模；二是基于深度学习的方法，更适合应对动态场景中复杂、多样的空间变化模糊问题。

（1）基于传统优化的方法

早期图像去模糊研究主要集中在非盲去模糊任务，即假设模糊核已知的前提下对图像进行恢复。最初的尝试是逆滤波方法，该方法在忽略噪声影响的假设下，通过反卷积运算还原图像。然而，实际图像中不可避免存在噪声，使得该方法去模糊效果不佳。为此，Wiener 在逆滤波的基础上引入图像与噪声的功率谱比信息，提出了维纳滤波[54]方法，以最小化恢复图像与真实图像之间的均方误差为目标，提升了鲁棒性。但该方法依赖于精确已知的功率谱比，一旦估计不准，性能将明显下降。为增强适应性，Lucy 与 Richardson 提出了 Lucy-Richardson 算法[55]，在已知模糊核的情况下使用最大期望算法迭代求解图像的最大似然估计。该算法收敛稳定，但对噪声依然较为敏感。Biggs 等人[56]对其进行了加速改进，提升了迭

中国知网 https://www.cnki.net

代效率，但在较多迭代步时仍容易出现振铃伪影。随着对图像统计特性的深入理解，研究者尝试将自然图像的先验知识引入非盲去模糊框架中。Krishnan 等人[57]采用超拉普拉斯分布建模图像梯度，提出相应快速优化算法，有效减轻振铃效应。Cho 等人[58]进一步考虑曝光过度、非高斯噪声及相机响应曲线非线性等因素，建立了更加鲁棒的退化模型，提升了去模糊效果。

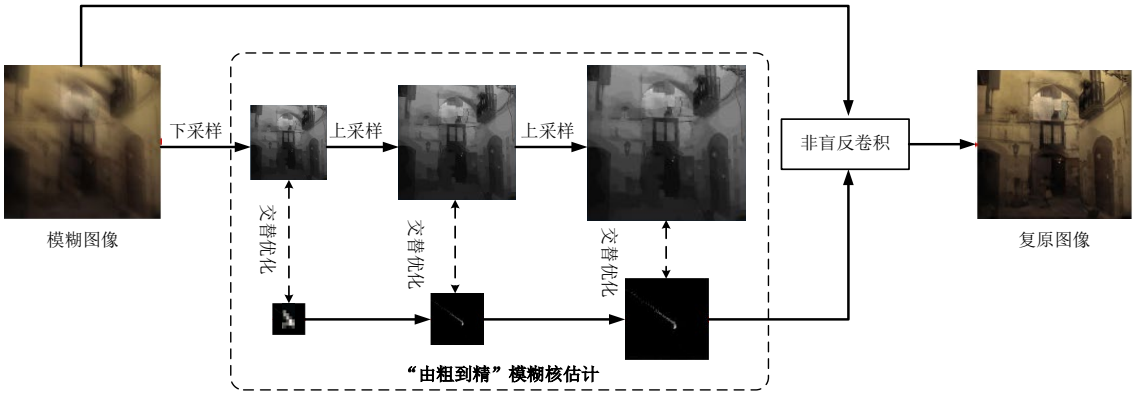


图 1.5 图像金字塔“由粗到细”的多尺度估计示意图

Figure 1.5 “Coarse-to-Fine” multi-scale estimation using an image pyramid

尽管非盲方法取得了重要进展，其对已知模糊核的依赖严重限制了其在真实应用中的可行性。因此，研究者逐步转向盲去模糊任务，即在未知模糊核的条件下，联合估计清晰图像与模糊核。该方向的重要突破由 Fergus 等人[59]提出的基于图像金字塔的“由粗到细”多尺度估计策略。如图 1.5 所示，该方法先在低分辨率图像中交替优化潜在图像与模糊核，然后逐级上采样与优化，最终实现对模糊核的精确估计，并结合非盲反卷积获得清晰图像。该策略显著提高了模糊核估计的稳定性，成为后续方法的重要基础。然而，盲去模糊问题存在解不唯一的固有挑战，即不同的图像与模糊核组合可能导致相同的模糊观测图像[60]。为缩小解空间，研究者引入先验正则项构建约束模型。Chan 和 Wong 等人[61]首次将图像梯度的稀疏性作为先验，引入总变分（Total Variation，TV）正则项，构建联合优化的能量函数，开启了基于正则化范式的盲去模糊研究。然而，该方法容易陷入平凡解的问题，限制了其实用性。为进一步提升先验建模能力，研究者提出了更符合自然图像统计的建模方法。例如，Shan 等人[62]将图像梯度的重尾分布建模为分段连续多项式，同时假设模糊核服从稀疏分布；Krishnan 等人[63]提出图像梯度的 L_1 / L_2 范数作为图像梯度稀疏先验，并以 L_1 范数约束模糊核，提高建模的准确性；Xu 等人[64]采用分段函数作为图像梯度稀疏性的正则项，具有良好数学性质，避免使用特定滤波器提取图像边缘。此外，部分研究面向特定图像类型构建先验，取得了有针对性的成果。Pan 等人[17]在研究文本图像的二值特性后，采用 L_0 范数

中国知网 https://www.cnki.net

分别约束图像灰度与梯度通道，显著提升了文本图像的恢复效果。进一步地，Pan等人[18]提出基于暗通道先验的方法，发现模糊图像中暗通道的非零值比清晰图像更多，据此构建稀疏正则项，并设计非线性非凸优化策略，提升了对各种模糊的适应性，但对缺乏暗通道特征的图像性能有限。Yan 等人[65]引入亮通道先验，通过分析亮通道分布差异，联合暗通道先验构建极通道先验，进一步提升了算法的适用性和去模糊效果。为了简化模型结构并提升鲁棒性，Wen 等人[66]提出局部最小强度先验，显著提升了模糊图像的恢复质量。

尽管传统去模糊方法通过引入各种图像先验（如梯度稀疏性、暗通道等）对模糊退化过程进行建模，取得了一定进展，但仍面临显著局限性：一方面，这些先验通常为静态先验，当图像缺乏相应特征（如暗像素）时，先验约束易失效，导致模糊核估计不准确，并在复原图像中产生振铃伪影；另一方面，此类方法常涉及非线性非凸优化问题，计算复杂度高，难以高效处理高分辨率图像。因此，如何构建更具表达能力的图像先验，并设计高效且稳定的优化算法，以进一步提升模糊核估计的精度与鲁棒性，仍是该领域亟待解决的核心挑战。

（2）基于深度学习的方法

现实场景中的图像模糊通常由复杂的空间变化退化过程引起，而该过程往往未知且难以精确建模，这使得传统依赖显式退化模型的去模糊方法难以在真实条件下实现高质量复原。近年来，随着深度学习技术的飞速发展，图像去模糊研究范式发生了根本转变：从依赖先验建模与优化求解的传统方法，转向基于数据驱动的深度神经网络方法。如图 1.6 所示，基于深度学习的方法通过深度神经网络强大的特征表征能力，直接从大规模训练数据中学习模糊图像与清晰图像之间的映射关系，避免了对退化过程的显式建模。

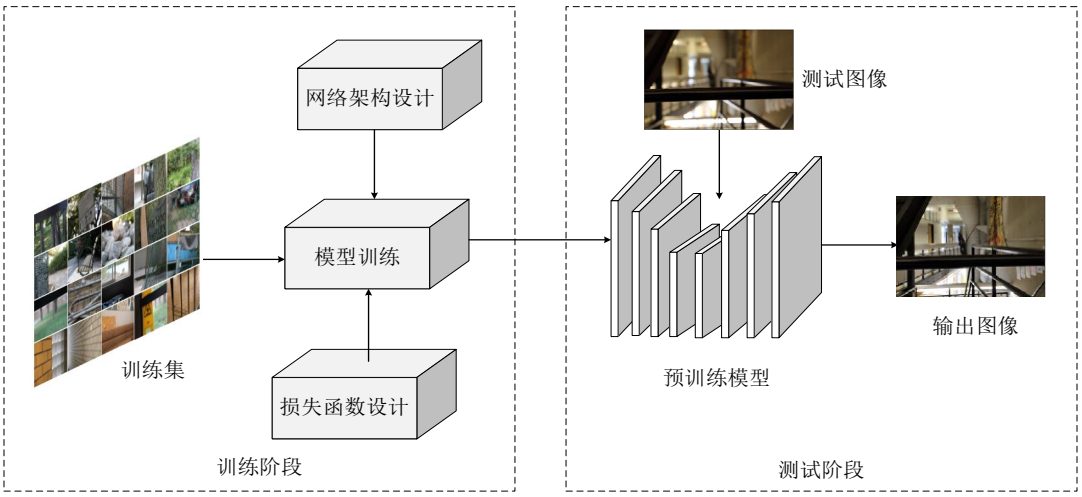


图 1.6 基于深度学习方法的示意图

Figure 1.6 Illustration of deep learning-based method

中国知网 https://www.cnki.net

根据网络结构设计的不同，可将基于深度学习的图像去模糊研究大致分为基于卷积神经网络（Convolutional Neural Network，CNN）、循环神经网络（Recurrent Neural Network，RNN）、生成对抗网络（Generative Adversarial Network，GAN）、Transformer 和扩散模型（Diffusion Model，DM）等五个方面进行介绍。

CNN 因其在提取局部特征方面的有效性和对空间平移具有不变性，被广泛应用于图像去模糊任务。通过多层网络结构的堆叠，CNN 能够扩大感受野，从而提升特征提取能力。在训练过程中，CNN 可学习退化图像的分布特性，从而从同类型的模糊图像中恢复丢失的高频信息。基于 CNN 的方法通常通过多层卷积和池化操作，自动学习图像或模糊核的特征，最终生成清晰图像。Sun 等人[67]首次将 CNN 应用于盲去模糊问题，提出利用 CNN 预测图像块中水平方向的运动模糊核概率分布。Schuler 等人[68]基于从粗到细的建模思想，在 CNN 中设计可学习的网络结构以提取局部特征，用于模糊核估计。然而，当模糊核较大且未知时，以上方法的性能仍然有限。针对该问题，Chakrabarti[69]提出了一种多分辨率频率分解策略，通过调整网络初始层的连接方式以适配频率局部性，使得模型能够估计较大的模糊核。Gong 等人[70]充分利用图像上下文信息，构建了一个全卷积深度网络，用于直接估计模糊核的运动流。Xu 等人[71]受到基于图像边缘的模糊核估计方法的启发，设计了一种 CNN 结构来提取并增强图像中的主干结构，从而实现更精确的模糊核估计。Tang 等人[72]提出一种基于未经训练的深度神经网络表示模糊核残差的无监督半盲去模糊方法。Fang 等人[73]提出一种基于隐空间先验的非均匀模糊核估计方法，通过标准化流动模型将运动模糊核映射至高斯分布空间，从而在图像隐空间中进行模糊核估计。上述方法多依赖于模糊核估计作为中间步骤，其性能在一定程度上受限于模糊核估计的精度。为此，一些研究者尝试构建端到端的学习模型，直接从模糊图像中恢复清晰图像，避免了模糊核估计带来的误差。Nah 等人[74]训练了一个深层 CNN 网络，能够从模糊图像中端到端地复原高质量图像。Dong 等人[75]利用自然图像的多尺度冗余特性，设计了一种基于 CNN 的图像去噪器，有效提升了去模糊效果。Cho 等人[76]提出了一种多输入多输出的 U-Net 网络，采用由粗到精的多尺度策略，实现了更为有效的去模糊。

RNN 是一种擅长处理序列数据的神经网络结构。在图像盲去模糊任务中，RNN 通过对图像局部区域的特征进行递归计算，将前一区域的状态信息传递至当前区域，从而建模不同区域之间的上下文依赖关系，逐步实现去模糊处理。Zhang 等人[77]利用 RNN 的空间可变性特点，隐式地模拟图像的去模糊过程。其模型在时间维度与空间维度上均进行循环操作，逐步恢复图像的结构与细节信息。Tao 等人[78]提出了一个多尺度循环去模糊网络，在多个尺度上共享网络权重，有效降低了模型训练的复杂度。同时，循环模块中状态信息的传递机制使得网络能够在

中国知网 https://www.cnki.net

各个尺度之间融合有用特征信息，从而提高图像恢复效果。在此基础上，Gao 等人[79]进一步考虑图像特征在不同尺度下的变化特性，提出参数选择性共享策略，用以提升图像细节的复原能力。由于多尺度特征提取通常伴随着大量参数，Park 等人[80]提出以多时态策略替代多尺度方法。具体而言，他们将图像划分为多个局部模糊区域，并在原始尺度上依次对这些区域进行处理，实现逐步去模糊。该方法在保留模型性能的同时显著降低了参数量，提升了模型的效率。

GAN 由生成器（Generator）与判别器（Discriminator）两个神经网络构成。在图像去模糊任务中，生成器以模糊图像为输入，输出清晰图像；判别器则用于判断生成图像与真实清晰图像之间的相似程度。GAN 的基本训练过程如图 1.7 所示，生成器与判别器通过对抗训练不断优化各自参数，从而提升图像复原质量。Kupyn 等人[81]首次提出基于 GAN 的单尺度去模糊网络 DeblurGAN，其生成器采用残差结构与卷积模块以实现去模糊，判别器则基于马尔可夫模型对图像真伪进行判别。然而，该方法可能面临梯度消失或梯度爆炸等问题。为此，Kupyn 等人[82]又提出了 DeblurGANv2，引入特征金字塔结构增强生成器的多尺度建模能力，并采用相对判别器以同时评估图像的全局与局部特征，有效缓解训练不稳定的问题。Zhang 等人[83]提出一种双阶段 GAN 去模糊框架。首先，训练一个 GAN 模型学习从非配对的清晰/模糊图像中模拟模糊过程；其次，利用生成的模糊图像，再训练另一个 GAN 实现图像去模糊。该方法还引入相对模糊损失以缩小真实模糊与合成模糊之间的差异。此外，Yang 等人[84]利用深度神经网络的深层和浅层特征来生成 GAN 的潜空间映射特征和噪声，以恢复模糊图像的全局结构和局部细节。大多数基于 GAN 的方法采用端到端方式直接生成清晰图像，避免了传统模糊核估计过程。尽管基于对抗损失的 GAN 训练能够生成更符合人类感知的图像，但其训练过程仍面临模型崩溃、梯度消失及优化不稳定等问题[85]。

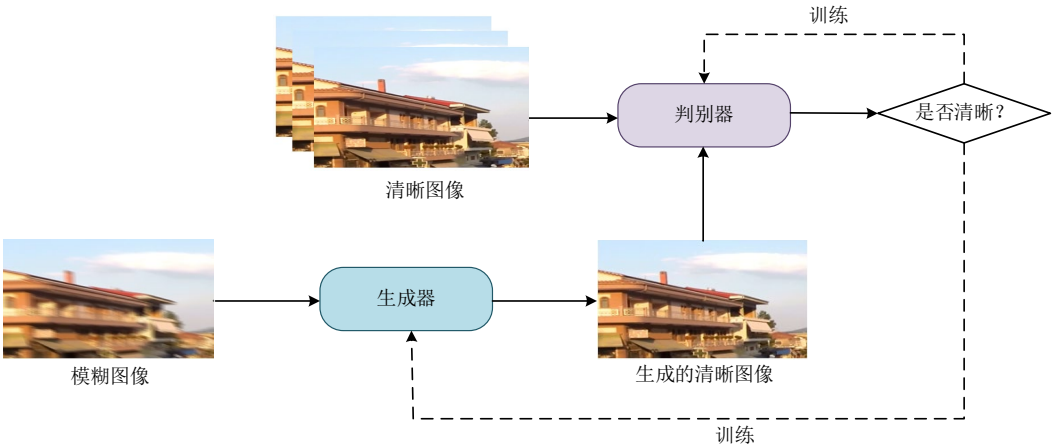


图 1.7 基于 GAN 的图像去模糊算法流程图

Figure 1.7 Flowchart of the GAN-based image deblurring algorithm

中国知网 https://www.cnki.net

Transformer 是一种结合自注意力机制和前馈神经网络的神经网络架构。自注意力机制能够有效捕捉不同位置之间的长距离依赖关系，而前馈网络则有助于建模局部信息和非线性特征。由于 Transformer 具备同时处理多尺度、多范围信息的能力，使其在应对多样化的模糊类型时表现出良好的适应性。基于 Transformer 的图像去模糊框架如图 1.8 所示。Zamir 等人[86]开发了一种高效的 Transformer 架构，通过在特征深度维度上计算缩放点积注意力，增强了通道间特征的建模能力。Wang 等人[87]提出 Uformer 结构，采用局部增强窗口（Locally-enhanced Window，LeWin）自注意力模块以及可学习的多尺度调制器，从而在捕捉局部和全局特征时实现更优的平衡。Tsai 等人[88]构建了一种基于 Transformer 的架构，通过水平与垂直方向上的条内/条间注意力机制，重加权图像特征以适应不同方向的模糊模式。Kong 等人[19]引入频率前馈网络以判别图像中应保留的高频或低频成分，从而缓解传统前馈网络在 Transformer 中对去模糊支持不足的问题。Yan 等人[89]提出 Sharpformer 模型，融合全局 Transformer 特征与自适应局部特征以实现高质量的运动去模糊。考虑到卷积操作擅长提取局部信息，而自注意力机制更适于建模全局上下文，Zhao 等人[90]设计了一个并行 Transformer 和 CNN 的架构，协同提取图像的局部与全局特征以增强去模糊性能。

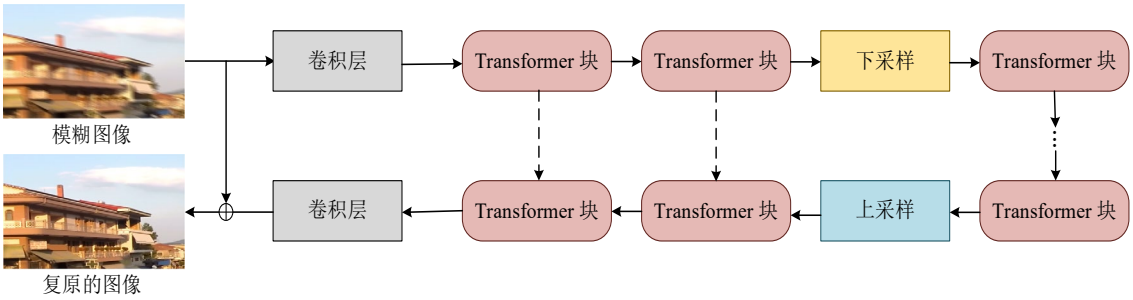


图 1.8 基于 Transformer 的图像去模糊算法流程图

Figure 1.8 Flowchart of the Transformer-based image deblurring algorithm

DM 是一类基于逐步加噪与去噪过程建模图像分布的生成模型。其基本过程包括前向扩散与反向去噪两个阶段，如图 1.9 所示。前向扩散过程指的是在原始图像中不断的加入高斯噪声，得到噪声图 x_T 的过程，从而达到破坏图像的目的。而反向去噪过程指的是从高斯噪声恢复出原始图像的过程。近年来，基于 DM 的方法在图像修补[91,92]、超分辨率[93,94]和去模糊[95–97] 等图像恢复任务中表现出显著优势。Kawar 等人[50]利用预训练扩散模型解决线性逆向图像恢复问题，但在处理非线性退化问题时仍存在局限。为应对非线性成像退化，后续研究[98]将扩散模型引入更广泛的图像逆问题中，但这类方法往往依赖于退化函数形式与参数的先验

中国知网 https://www.cnki.net

知识。Ozan 等人[99]提出基于块的扩散模型，在恶劣天气条件下进行图像恢复，其通过跨重叠图像块的引导去噪过程提高了推理质量。其他研究[95,96]利用扩散模型生成图像恢复的先验表征，并采用两阶段训练策略；也有方法[94]将扩散模型与残差网络相结合，在感知指标上取得良好性能。然而，这些方法通常缺乏明确的先验约束，容易导致细节还原不一致、伪影增加等问题。针对该挑战，Ren 等人[97]在扩散模型中引入多尺度结构先验作为隐式约束，有效引导模型保持关键结构信息，从而显著提升了其在未知模糊类型下的泛化能力。尽管如此，更深层次的问题在于当前方法对图像表征的理解仍存在局限。虽然空间域的多尺度处理能够捕捉不同分辨率的视觉特征，但这种方法本质上忽略了频域信息的关键价值。图像的高频分量承载着边缘锐度和纹理细节等对去模糊至关重要的视觉信息，而低频分量则决定了图像的整体结构和光照特性。单纯依赖空间域的多尺度处理难以实现对这些频域特征的精准控制和复原，这一局限性直接影响了现有方法在图像细节恢复方面的表现。

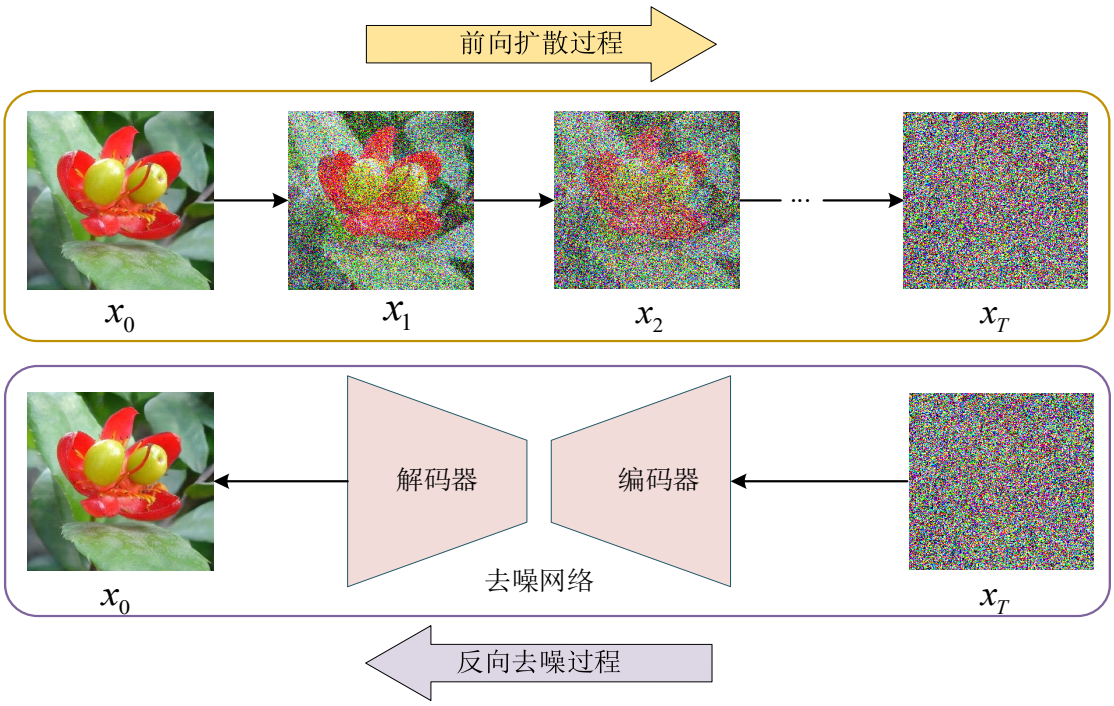


图 1.9 扩散模型的结构示意图

Figure 1.9 Structural diagram of the diffusion model

为全面梳理当前图像去模糊领域的研究现状，本文对典型的去模糊算法进行了系统整理与对比，涵盖了传统优化方法、基于 CNN、RNN、GAN、Transformer 等深度学习方法以及近年来快速发展的 DM 方法。对比内容包括各类方法的核心机制、优势表现、以及存在的局限性。具体对比结果详见表 1.1。

中国知网 https://www.cnki.net

表 1.1 图像去模糊方法对比

Table 1.1 Comparison of image deblurring methods

方法	核心机制	优势	局限性
传统优化	构建包含先验正则项的优化模型，通过解析或迭代求解	模型可解释性强，能有效抑制噪声	依赖先验设计，容易过度平滑，导致高频细节丢失
CNN	利用多层卷积网络学习从模糊图到清晰图的映射关系	特征提取能力强，可自动学习模糊模式，细节还原效果良好	对大规模数据和计算资源依赖较高，泛化能力有限
RNN	采用递归结构逐步优化图像清晰度，并建模多尺度模糊特征	擅长处理动态模糊和时序信息，适合多阶段/多尺度去模糊	网络结构复杂，训练时间长，参数调优难度较高
GAN	通过生成器与判别器的对抗训练，提升图像的真实性	能生成视觉真实感强的图像，细节丰富	训练不稳定，易产生伪影或结构畸变，对数据质量敏感
Transformer	基于自注意力机制建模图像中长距离依赖关系	全局建模能力强，适合高分辨率与大范围模糊的恢复	模型参数多，计算开销大，对数据和硬件资源要求较高
DM	正向逐步添加噪声、逆向逐步去噪学习图像生成过程	出色的细节与纹理建模能力，生成结果自然且高质量	推理过程迭代次数多，计算成本高；条件控制能力有待增强

1.3 存在的问题

图像离焦模糊和运动模糊的分析与处理一直是计算机视觉领域的重要研究方向。尽管经过数十年的发展，该领域已形成较为完善的理论体系，并在实际应用中取得了显著进展，但现有模糊处理技术在复杂场景下仍然面临诸多挑战。基于对现有研究的分析，本文总结了亟待解决的四个问题。

1）弱纹理低对比度区域的模糊感知不准确。当前的离焦模糊图估计方法通常依赖于构造能够区分清晰区域和模糊区域的判别性特征，这些特征多基于空域、梯度域或频域的信息。然而，在处理弱纹理或低对比度区域时，现有方法仍面临显著挑战。一般而言，清晰区域相较于模糊区域包含更丰富的细节与高频成分，可为模糊程度估计提供有效依据。但在实际图像中，部分清晰区域（如天空、墙壁或阴影等）本身呈现平坦或低纹理特征，缺乏明显的高频信息，尽管在视觉上被感知为清晰，其数值特征却可能与模糊区域相似，导致模糊度估计偏高，进而被误判为模糊区域。该问题削弱了现有方法在弱纹理区域中的鲁棒性，并影响

中国知网 https://www.cnki.net

后续离焦去模糊任务的准确性和复原质量。相比之下，人眼在感知模糊区域方面具有显著优势，能够有效弥补现有特征表征的不足。因此，引入人类视觉系统的感知机制作为先验信息，成为提升模糊感知能力的重要研究方向。

2）复杂离焦模糊分布下的高保真复原困难。真实场景中的离焦模糊退化通常呈现高度空间非均匀性，且受光学系统参数变化、景深差异、焦平面偏移等多因素的影响，导致模糊分布难以明确建模。传统方法通常将模糊过程简化为局部均匀的高斯核或圆盘核模型，难以准确刻画真实场景中复杂且多变的模糊特征。尽管深度学习方法在特征建模方面具有优势，但由于缺乏对模糊生成机制的物理理解，其对未知或复杂模糊模式的适应能力仍有限，表现为复原的图像边缘模糊、纹理缺失等问题。针对该挑战，结合语义先验与深度先验成为一种潜在的解决路径。语义先验可辅助模型理解场景语义，深度先验则可为模糊分布提供空间变化的指导信息。因此，如何有效提取并融合这些先验信息，与深度神经网络协同工作，是提升复杂离焦模糊复原质量的关键研究方向。

3）均匀退化模型缺乏有效的图像先验与优化策略。图像去模糊本质上属于高度不适定的“病态”逆问题，依赖合理的退化建模与先验约束以有效缩小解空间，从而提升问题的可解性与稳定性。传统的相机抖动去模糊方法通常基于均匀退化模型假设，认为模糊过程可由空间不变的模糊核描述，并通过引入图像先验（如暗通道先验、亮通道先验等）以增强约束能力。然而，这些方法在图像区域缺乏显著先验特征时（如缺少暗像素或亮像素），模糊核估计精度大幅下降，导致复原效果不理想。同时，这类算法通常依赖复杂的迭代优化过程，在处理高分辨率图像时计算开销较大，难以满足实际应用需求。因此，构建更具判别力和鲁棒性的图像先验模型，并设计高效优化策略以提升模糊核估计准确性与整体计算效率，已成为相机抖动去模糊研究中亟需解决的重要问题。

4）频率信息利用不足导致细节恢复能力受限。当前动态场景下的去模糊方法多采用多尺度或多分块策略，通过不同分辨率下的特征提取与融合来提升图像复原质量。一般而言，低分辨率分支用于捕捉图像的全局结构信息，高分辨率分支则聚焦于图像的局部细节，从而在空间尺度上实现信息整合。然而，这类方法主要关注空间分辨率的变化，较少引入频率域信息进行建模。事实上，图像的频率分量承载着不同层次的视觉信息：低频分量反映图像的基本结构与平滑区域，高频分量则蕴含丰富的边缘与纹理细节。由于去模糊任务的核心目标是恢复因模糊而丢失的高频信息，单纯依赖空间尺度的特征建模难以充分捕捉关键高频信息，从而影响最终复原效果。因此，如何在去模糊过程中有效引入频率域信息，并在深度学习框架下充分利用频域信息进行特征表达和融合，是提升动态场景去模糊性能的关键研究方向。

中国知网 https://www.cnki.net

1.4 本文主要研究内容

针对当前模糊图像处理领域中存在的若干关键挑战，包括弱纹理与低对比度区域中离焦模糊感知不准确，复杂离焦模糊分布下的高保真复原困难，均匀退化模型中图像先验与优化策略的不足，以及真实动态场景下频率信息严重丢失等问题，本文提出一系列基于不同先验信息引导的处理框架。该框架通过引入感知先验、大模型先验、动态极值先验和频率先验，有效提升离焦模糊图的估计精度与图像去模糊的整体性能。主要研究内容如下：

（1）基于感知先验的离焦模糊图估计算法研究

针对弱纹理和低对比度区域中模糊感知不准确的问题，本文提出了一种基于感知先验引导的离焦模糊图估计算法。该方法创新性地结合再模糊奇异值差异度量算子与基于恰可察觉模糊（Just Noticeable Blur，JNB）理论的感知权重调制机制，有效提升了离焦模糊图估计的鲁棒性与精度。具体研究内容：首先设计了一种再模糊奇异值差异度量算子，通过比较图像原始版本与其再模糊版本之间的梯度奇异值差异，准确刻画聚焦区域与离焦区域的特征差异。其次，结合人类视觉系统（Human Visual System，HVS）对模糊感知的行为规律，构建了一种基于感知特性的权重调制方法，用于引导稀疏模糊图的构建，从而显著增强弱纹理与低对比度区域的模糊识别能力。为解决由边缘点稀疏性带来的估计不完整问题，进一步引入额外的清晰-模糊边缘点作为约束信息，并结合双边滤波以减少误差传播。随后，通过引入 Matting Laplacian 插值策略，实现稀疏模糊图向全图范围的高质量补全，确保模糊估计在空间上的连续性和准确性。最终所生成的离焦模糊图不仅在感知层面具有良好的一致性，还可用于推导空间变化的模糊核信息，为离焦去模糊过程提供关键支撑，有效提升图像复原质量。

（2）基于大模型先验的离焦去模糊算法研究

针对自然复杂离焦模糊场景中高保真图像复原困难的问题，本文提出了一种基于大模型先验引导的离焦去模糊算法。该方法充分挖掘在大规模自然图像数据集上预训练的大模型中所蕴含的通用知识与图像先验信息，从而提升去模糊结果的准确性与视觉质量。具体研究内容：首先对预训练的大模型进行适应性微调，提取高保真的结构信息与语义特征，并将其输入至多模态融合模块，构建融合了大模型先验的多模态表示，用以有效引导扩散模型生成细节丰富、自然逼真的清晰图像。其次，针对离焦模糊在空间分布上存在非均匀性的问题，设计了一种深度感知融合网络，通过分析模糊图像中的深度特征构建离焦权重图，以精确刻画模糊程度的空间变化规律。最后，基于生成的离焦权重图，提出了一种加权拉普拉斯金字塔融合策略，用于实现扩散模型生成图像与原始模糊图像之间的自适应

中国知网 https://www.cnki.net

融合。该策略根据图像不同区域的模糊程度分配融合权重，在保持结构一致性的同时增强细节保真度，从而进一步提升最终图像的整体视觉质量。

（3）基于动态极值先验的图像盲去模糊算法研究

针对均匀退化模型中图像先验表达能力不足以及优化方法效率低下的问题，本文提出了一种基于动态极值先验的正则化盲去模糊算法。该方法充分考虑相机抖动引发的极值分布变化特性，并结合高效的求解策略，旨在提升模糊核估计的准确性，同时加快正则化模型的优化过程。具体研究内容：首先，通过理论分析与实验验证，揭示了相机抖动模糊对图像局部极值（如最大值和最小值）分布所产生的差异性影响，并据此设计了一种基于模糊 C 均值聚类的先验分类机制。该机制能够动态分析像素的极值变化，自适应构建先验约束，有效捕捉运动模糊图像中极值变化特征，从而提升模糊核估计的准确性。其次，进一步引入稀疏诱导机制对动态极值先验进行优化，使得在去模糊过程中能够保留更多清晰图像的潜在结构特征信息，并提升非凸正则化模型的求解效率。

（4）基于频率先验的动态场景去模糊算法研究

针对真实动态场景中运动模糊导致的频率信息严重丢失，细节恢复能力受限的问题，本文提出了一种基于频率先验引导的扩散模型，以增强不同频率成分的恢复能力。该方法构建多层次频率先验融合机制，通过交叉注意力逐层引导扩散过程，有效整合低频结构信息与高频细节，从而提升模型在复杂场景下的去模糊性能与泛化能力。具体研究内容：首先，构建主频率恢复网络，生成包含丰富频率信息的初始图像，并在小波域中定义损失函数，以强化频率成分的恢复精度。其次，设计多频率特征提取模块，对初始图像的不同频率成分进行提取与融合，并作为先验信息参与扩散过程。最后，利用交叉注意力机制，在扩散模型的各层中引导多尺度频率信息融合。低频特征促进全局结构的准确复原，高频特征细化局部纹理与边缘细节，从而生成结构清晰、细节丰富的高质量图像。

1.5 本文的组织结构

本文共分为七章，其主要研究内容和组织结构如图 1.10 所示。各个章节的内容安排如下：

第一章，绪论。介绍图像模糊处理的研究背景与意义，阐明图像去模糊技术在智能交通、工业检测、医疗成像与安防监控等领域的广泛应用价值。在充分调研国内外相关文献的基础上，系统梳理了图像离焦模糊与运动模糊的研究现状，深入分析了当前方法在弱纹理区域模糊感知、高保真图像复原、退化模型建模以及频率信息利用等方面面临的四个主要技术瓶颈。在此基础上，明确本文的研究目标，提出四种针对性解决方案，并概述全文的组织结构。

中国知网 https://www.cnki.net

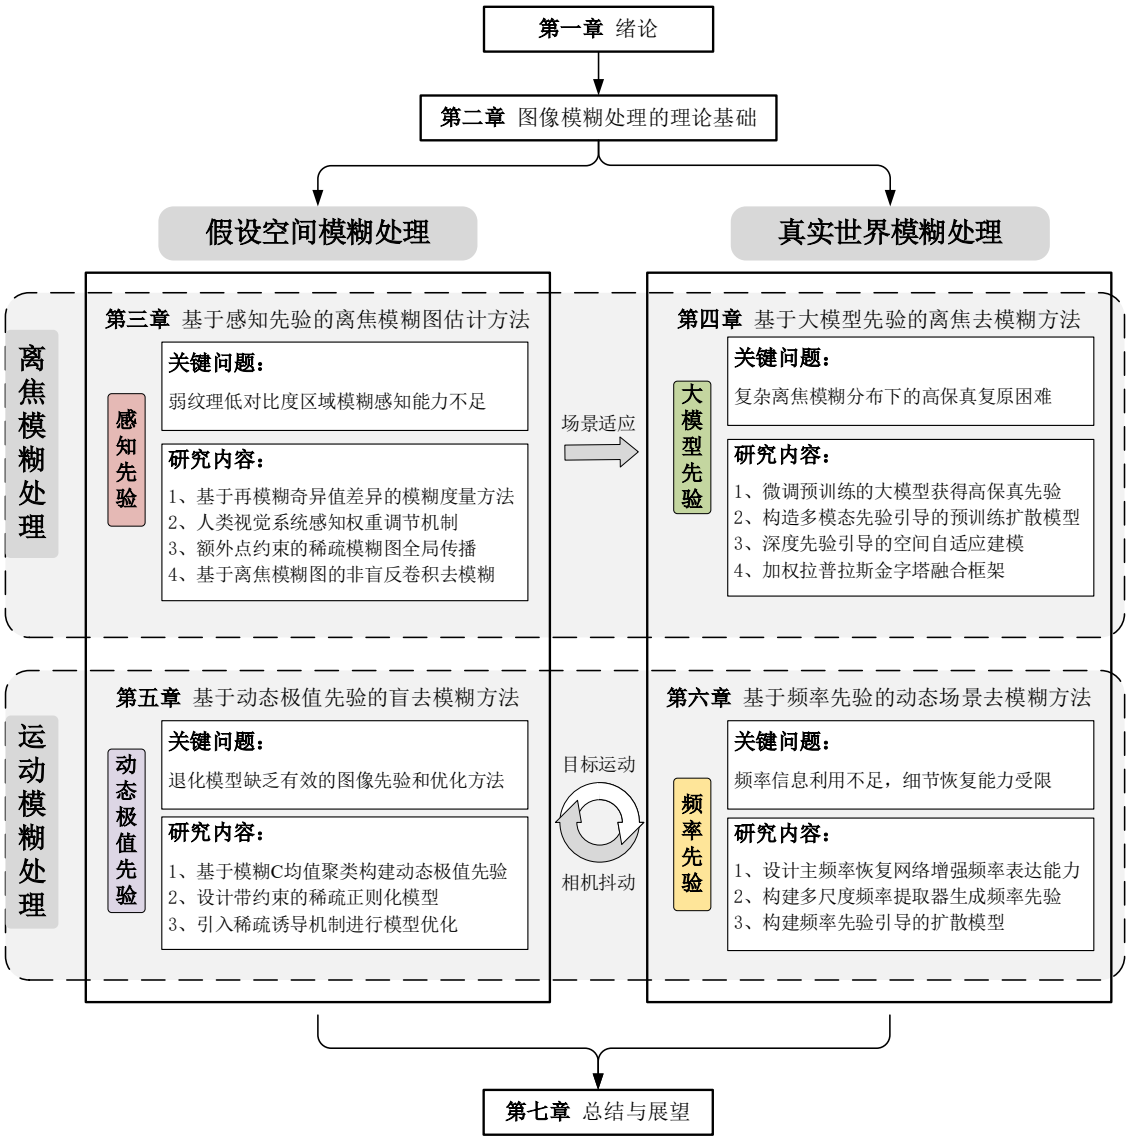


图 1.10 本文的研究内容与组织结构

Figure 1.10 Research content and organizational structure of this thesis

第二章，图像模糊处理的理论基础。介绍图像模糊的形成机理与数学建模，分析图像去模糊问题的病态性。围绕第一章提出的四个核心问题，重点阐述了相应的感知先验、大模型先验、极值先验和频率先验的基本理论和代表性方法，为后续各章方法设计提供理论支撑。

第三章，基于感知先验的离焦模糊图估计方法。利用第二章介绍的感知先验，本章针对弱纹理、低对比度区域模糊感知不准确的难题，提出引入人类视觉系统模糊感知机制，结合再模糊奇异值差异度量算子与边缘点补充策略，构建稀疏模糊图，并通过 Matting Laplacian 算法实现高质量补全。在获得完整离焦模糊图后，基于高斯模糊核假设进行非盲反卷积，实现初步图像复原，同时为下一章更复杂退化建模方法提供基线支持。

中国知网 https://www.cnki.net

第四章，基于大模型先验的离焦去模糊方法。针对第三章方法在离焦去模糊中仍受限于简化高斯模糊核假设的问题，本章进一步提出一种基于大模型先验引导的离焦去模糊算法。该方法通过微调预训练模型，提取图像的语义信息与结构特征，并结合多模态特征融合模块，生成具有结构语义感知能力的多模态先验表示，用以引导预训练的稳定扩散模型生成细节丰富的清晰图像。此外，提出一种深度感知引导的加权拉普拉斯金字塔融合策略，实现模糊图像与生成图像在不同区域的自适应融合，有效平衡局部细节恢复与全局结构保持，显著提升模型在复杂离焦模糊场景下的去模糊性能。

第五章，基于动态极值先验的图像盲去模糊方法。区别于第三章与第四章所处理的离焦模糊问题，本章聚焦于由相机抖动引起的运动模糊场景，在假设模糊核为空间均匀不变的前提下，提出一种基于动态极值先验的正则化盲去模糊算法。该方法通过理论分析揭示模糊对图像局部极值分布的影响特性，结合模糊 C 均值聚类实现先验的自适应构建，并引入稀疏诱导机制与交替优化策略，有效提升非凸正则化模型的求解效率与复原质量。

第六章，基于频率先验的动态场景去模糊方法。鉴于第五章方法建立在模糊核空间均匀不变的假设之上，难以有效应对真实动态场景中广泛存在的非均匀模糊，同时运动模糊常导致图像频率信息严重丢失，影响细节恢复效果，本章提出一种频率先验引导的扩散模型去模糊方法。该方法构建多层次的小波域频率先验，并通过交叉注意力机制将其逐层引入扩散模型，实现低频结构与高频细节的协同恢复，增强对复杂动态模糊模式的建模能力。

第七章，总结与展望。总结本文在感知先验、大模型先验、动态极值先验与频率先验四个方面的研究工作与主要贡献，并对未来图像模糊统一建模、多源信息融合以及跨领域应用等方向进行了展望。

中国知网 https://www.cnki.net

第 2 章 图像模糊处理的理论基础

2.1 引言

在图像采集过程中，模糊现象往往难以避免。其成因既包括客观因素，如拍摄场景中存在多个景深位置的物体，即便精确对焦，也难以实现整幅图像的全局清晰；也包括人为因素，例如拍摄过程中因镜头抖动或场景中物体快速运动所导致的成像不稳定。由此可知，图像模糊的产生既具有一定的偶然性，也存在物理机制上的必然性。

图像作为信息的重要载体，其清晰度直接关系到所承载信息的完整性与可用性。模糊图像不仅会降低图像的视觉质量，还会对后续的信息提取与分析过程产生不利影响。因此，研究图像模糊的形成机制，构建有效的数学模型，并设计相应的去模糊方法，对于提高图像处理与计算机视觉系统的整体性能具有重要意义。本章将围绕图像模糊处理的理论基础展开论述，主要从以下三个方面进行分析：图像模糊的成因、图像模糊的数学模型与病态性分析、以及常用的图像先验知识等内容，为后续章节中去模糊算法的提出奠定理论基础。

2.2 图像模糊成因

如第一章所述，图像模糊常发生于图像的采集、变换、存储、传输与显示等过程中，主要由成像设备缺陷、成像原理的限制、外界环境干扰以及处理操作误差等因素引起。本节重点探讨手持设备在实际拍摄中常见的两类模糊类型，即离焦模糊与运动模糊的成因。

2.2.1 离焦模糊成因

在使用光学成像设备拍摄场景时，图像模糊常由于场景中存在多个深度层次的物体而产生。这些物体与光学传感器所在的成像平面之间存在不同的垂直距离。根据光学成像系统的原理，只有位于焦平面的物体，其反射光线才能在成像平面上准确汇聚，形成清晰图像；而位于非焦平面的物体则无法正确聚焦，最终在成像平面上形成模糊图像，从而产生离焦模糊。尽管离焦模糊在某些摄影和图像编辑任务中可用于营造艺术性的虚化效果，但在多数图像处理应用中，这种模糊会导致纹理细节缺失与语义信息丢失，影响中层特征的提取，并对后续任务如图像去模糊、图像分割、深度估计、目标识别与检测、场景分类、跟踪、压缩感

中国知网 https://www.cnki.net

知、图像编辑和图像质量评估等造成不利影响。因此，准确识别与估计模糊区域对于提升图像处理效果具有重要意义。

图 2.1 展示了离焦模糊成像原理示意图，当成像系统聚焦于图中物点 A 时，成像平面上形成清晰的黑色聚焦点 a；而当物体位于点 B 或点 C 时，分别在成像平面上形成类似圆斑的黄色区域 b 与红色区域 c。图 2.2 展示了这两个圆斑的正面图像，当物体与焦平面的距离越远时，形成的圆斑（半径 $R_2>R_1$）越大，对应的离焦模糊程度也越严重。

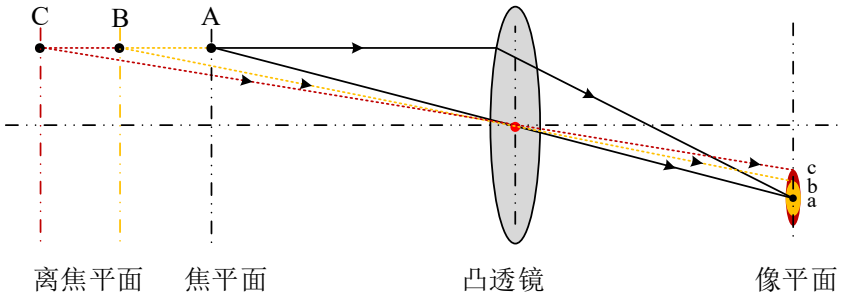


图 2.1 离焦模糊图像的成像原理

Figure 2.1 Imaging principle of defocus blur

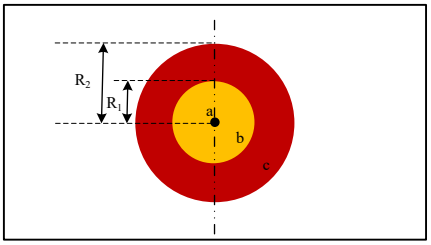


图 2.2 不同位置物点成像的示意图

Figure 2.2 Illustration of imaging at different object positions

2.2.2 运动模糊成因

在使用手持图像采集设备（例如智能手机和单反相机）拍摄照片时，由于成像设备与被拍摄场景在曝光过程中发生相对位移，导致图像质量下降的现象称为运动模糊。影响运动模糊程度的主要原因是相机抖动或拍摄场景中物体的运动。此外，曝光时间的长短、光线环境的明暗以及拍摄高亮反光区域时的曝光过程也会加剧模糊现象。总体而言，运动模糊是由于相机或物体在曝光期间沿成像系统主光轴垂直方向发生位移，导致图像出现模糊的结果。

图 2.3 展示了运动模糊成像原理示意图，当物点在曝光前后从 A 点位置移动到位置 A_1，其对应的像点在成像平面上发生长度为 L 的位移，导致该像点在最终图像上形成一条运动轨迹，本来在 a 点成像的像素点被拖影到了 a_1 点。模糊轨迹

中国知网 https://www.cnki.net

的长度 L 称为模糊尺度，运动方向由模糊角度θ确定（模糊角度θ是指物体的运动方向与成像系统焦平面之间的夹角，该图中$\theta = 0$）。当物体在曝光时发生的位移越大，模糊尺度 L 就越大，从而图像的运动模糊程度也越大。

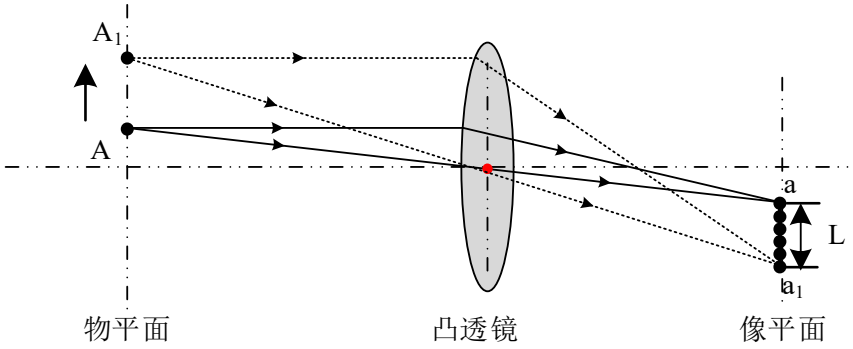


图 2.3 运动模糊图像的成像原理

Figure 2.3 Imaging principle of motion blur

2.3 图像模糊数学模型与病态性分析

图像模糊的形成过程本质上是一个退化过程，可通过数学建模形式化地刻画清晰图像与模糊图像之间的映射关系。为了深入理解图像模糊的内在机制，本节将首先构建图像模糊的数学模型，随后分析该模型所呈现的病态特性。

2.3.1 图像模糊数学模型

图像是三维世界场景在二维成像平面上的投影。在典型的光学成像系统中，场景的反射光线通过有限孔径的光学透镜汇聚到图像传感器的感光单元，光子被转换为电荷信号；随后，经由模数转换器转化为数字信号；最终，通过图像处理单元生成数字图像。此过程可建模为透视投影和几何变换的组合。由于传感器的非线性响应，光子首先被转换为模拟图像，然后通过离散化操作形成最终的数字图像。从数学角度来说，上述过程可以被表达为：

$$B = \mathrm{S}(f(\mathrm{D}(\mathrm{P}(s) \otimes k_{ex}) \otimes k_{in})) + n \tag{2-1}$$

其中，B 表示模糊观测图像，s 为真实场景，$\mathrm{P}(\cdot)$ 表示透视投影，$\mathrm{D}(\cdot)$ 表示几何畸变算子，$f(\cdot)$ 表示相机的非线性响应函数，其将场景辐照度映射为像素强度，k_{ex} 表示由外部因素（如运动）引起的模糊核，k_{in} 表示由内部元素（如离焦）所导致的模糊核，$\otimes$ 表示卷积算子，$\mathrm{S}(\cdot)$ 表示传感器阵列的采样算子，n 表示加性噪声。

中国知网 https://www.cnki.net

以上过程清晰的描述了模糊产生的机理。然而，本文的研究重点是如何从一个模糊观测中恢复出潜在清晰图像，而不是真实场景的几何图形。因此，聚焦于像平面并忽略采样误差，可以得到：

$$B \approx f(I \otimes k) + n \tag{2-2}$$

其中，I 表示由 D(P(s)) 产生的潜在图像，k 表示结合 k_{ex} 与 k_{in} 的近似模糊核。为了简化，大多数研究者忽略非线性响应函数的作用，或者将其作为预处理步骤进行探索。在这里不考虑非线性响应函数的影响，从而获得进一步的简化公式:

$$B = I \otimes k + n \tag{2-3}$$

此即为图像模糊处理过程中最常用的数学模型。其中 k 可以反映出图像模糊的类型，下面给出离焦模糊核和运动模糊核公式和表现形式（如图 2.4）。

（1）离焦模糊核

图像离焦模糊是真实场景中常见的模糊类型，其对应的模糊核呈圆盘状，均匀向四周扩散，数学模型表达式为：

$$k(i,j) = \begin{cases} \dfrac{1}{\pi r^2} & \sqrt{i^2 + j^2} \le r \\ 0 & \text{otherwise} \end{cases} \tag{2-4}$$

其中，r 为点光源扩散所得的圆盘状光斑的半径，即模糊核的半径，图像的离焦程度与其直接相关，模糊圆盘越大，图像的离焦程度越大，图像越模糊。

实际成像中，真正的离焦模糊核一般表现为成像平面上平滑且逐渐衰减的圆斑状图像，常采用方差为 σ 的二维对称高斯分布进行建模，公式（2-4）可改写为：

$$k(i,j) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{i^2 + j^2}{2\sigma^2} \right) \tag{2-5}$$

其中，σ 可解释为离焦度，与模糊圆盘半径 r 有如下关系：

$$\sigma = \rho r \tag{2-6}$$

其中，ρ 是与成像设备相关的常数，通常表示每平方英寸含像素的数量。

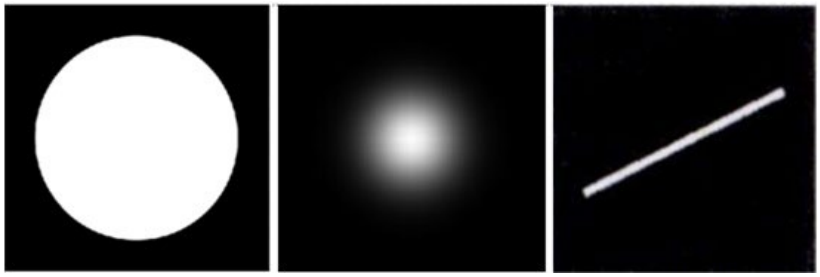
中国知网 https://www.cnki.net

（2）运动模糊核

运动模糊核在一定程度上可以反映运动的方向和尺度，短暂的运动可视为匀速直线运动，对应的运动模糊核可用如下数学公式表示：

$$k(i,j)=\begin{cases}\dfrac{1}{L} & \sqrt{i^2+j^2}\le\dfrac{L}{2},\dfrac{i}{j}=-\tan(\theta)\\ 0 & \text{otherwise}\end{cases} \tag{2-7}$$

其中，(i,j)表示由k中心出发的坐标位置，L为运动距离，即模糊尺度，θ为运动方向（即与水平方向的夹角）。



离焦模糊核（圆盘）　离焦模糊核（高斯）　运动模糊核

图 2.4 离焦模糊核与运动模糊核的表现形式

Figure 2.4 Representation of defocus and motion blur kernels

2.3.2 图像模糊模型的病态性分析

根据公式（2-3），图像去模糊的目标是从模糊观测图像B中恢复潜在清晰图像I（即非盲去模糊），或同时估计出图像I和模糊核k（即盲去模糊），同时去除噪声n的影响。在实际求解中，公式（2-3）常被表示为矩阵-向量形式：

$$\mathbf{B}=\mathbf{KI}+\mathbf{n} \tag{2-8}$$

其中，$\mathbf{B}$和$\mathbf{I}$分别表示将大小为$n\times n$的二维图像矩阵B和I转换为n^2维的列向量，噪声矩阵$\mathbf{n}$在一般的成像模型中通常被建模为服从均值为零，方差为σ^2的高斯分布，即高斯白噪声。模糊矩阵$\mathbf{K}$为模糊核k所构成的矩阵，大小为$n^2\times n^2$，当成像系统为线性空间不变系统时，$\mathbf{K}$是一个具有块循环结构的 Toeplitz 矩阵。

对于公式（2-8），一种最简单的解决方法为最小二乘法对其进行求解以获得复原图像，即：

$$\hat{\mathbf{I}}=\arg\min\|\mathbf{B}-\mathbf{KI}\|_2^2 \tag{2-9}$$

中国知网 https://www.cnki.net

公式（2-9）又可转化为如下欧拉-拉格朗日（Euler-Lagrange）方程的求解：

$$\mathbf{K}^T\mathbf{K}\hat{\mathbf{I}} = \mathbf{K}^T\mathbf{B} \tag{2-10}$$

设方阵$\mathbf{K}$可逆，就可求解出无约束的恢复公式：

$$\hat{\mathbf{I}} = (\mathbf{K}^T\mathbf{K})^{-1}\mathbf{K}^T\mathbf{B} = \mathbf{K}^{-1}\mathbf{B} \tag{2-11}$$

由此可知，若模糊矩阵$\mathbf{K}$和退化图像$\mathbf{B}$已知，且$\mathbf{K}$可逆则可以根据上式求出$\mathbf{I}$的最小均方误差意义下的估计值$\hat{\mathbf{I}}$。

通常来说，这里需要解决$\mathbf{K}^{-1}$以下三个方面的问题：

1）$\mathbf{K}^{-1}$是否存在的问题，如果其逆变换不存在，从数学理论上来说是不能求解$\hat{\mathbf{I}}$的，但从实际应用来说，还是可以从$\mathbf{B}$复原出尽量接近于$\hat{\mathbf{I}}$。

2）$\mathbf{K}^{-1}$存在的情况下，是否唯一的问题。这就是说在$\mathbf{K}^{-1}$存在的情况下，也可能从$\mathbf{B}$复原出多个$\hat{\mathbf{I}}$，即存在多个$\mathbf{K}^{-1}$，使得解不唯一。

3）$\mathbf{K}^{-1}$的稳定性问题，即指在$\mathbf{K}^{-1}$存在且唯一的情况下，观测数据的微小变化是否有可能导致解发生很大变化，或者说方程的解是否能连续地依赖于数据。

然而，根据考虑图像大小一般不小，而$\mathbf{K}$作为$n^2 \times n^2$矩阵，其阶数非常大，且$\mathbf{K}$的非零元素仅有$|\Omega_{\mathbf{K}}| \times |\Omega_{\mathbf{I}}|$个。这里$\Omega_{\mathbf{K}}$是由$\mathbf{K}$的非零元素构成的子集，$|\cdot|$意味着集合的基数。因此，尽管$\mathbf{K}$的阶数非常大，$\mathbf{K}$却很稀疏。通常来说，$\mathbf{K}$的条件数很大，导致去模糊问题的病态性或不适定性（ill-posed）。

去模糊问题的不适定性可以通过奇异值分解（Singular Value Decomposition，SVD）来解释[100]。设模糊矩阵$\mathbf{K}$的奇异值分解为：

$$\mathbf{K} = \mathbf{U}\Sigma^{-1}\mathbf{V}^T = \sum_{i=1}^{n^2} u_i \sigma_i v_i^T \tag{2-12}$$

其中，对角矩阵$\Sigma \in \mathbb{R}^{n^2 \times n^2}$的对角线元素为满足$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_{n^2} \geq 0$的奇异值，矩阵$\mathbf{U}$和$\mathbf{V}$为正交矩阵，其列向量$u_i, v_i$分别称为左奇异向量和右奇异向量。至此，公式（2-11）的解可表示如下：

$$\hat{\mathbf{I}} = \mathbf{K}^{-1}\mathbf{B} = \mathbf{V}\Sigma^{-1}\mathbf{U}^T\mathbf{B} = \sum_{i=1}^{n^2} \frac{u_i^T\mathbf{B}}{\sigma_i} v_i \tag{2-13}$$

中国知网 https://www.cnki.net

由于公式（2-13）涉及对较小奇异值的除法运算，噪声的存在将显著放大误差，导致求解结果高度不稳定，即微小的观测误差可能引起与真实解之间的巨大偏差。为缓解该问题，一个自然的解决方法是通过引入一些有关图像的先验知识，对问题进行正则化处理，从而使求解结果尽可能逼近真实解。

2.4 常用的图像先验

在图像模糊处理任务中，先验知识作为一种有效的约束机制，能够通过引入已知的规律或经验信息，显著提升图像模糊估计精度和去模糊的稳定性。在模糊估计任务中，先验的引入旨在捕捉清晰图像与模糊图像的特征差异[23]，以便最大化利用这些信息来提升估计的性能。在去模糊任务中，合理的先验可以有效的约束解空间，使得模型在有限的观测信息基础上生成更加合理、自然的清晰图像[18]。在实际应用中，先验知识既可以通过正则项的方式融入传统优化模型[18]，也可以作为条件信息整合进深度学习模型中以增强其建模能力和泛化表现[97]。本节将围绕感知先验、大模型先验、极值先验和频率先验四类典型的图像先验展开讨论。

2.4.1 感知先验

感知先验在图像质量分析与处理领域占据重要地位，它通过模拟 HVS 的感知机制，为图像模糊的检测与估计提供了科学依据。尽管人眼对图像模糊的识别极其直观，但对于计算机而言，由于图像内容的多样性，自动、准确地评估模糊程度仍是一项具有挑战性的任务。

感知先验的研究基础是基于 JNB 的概念[101]，该概念能够较好的模拟人眼在不同图像内容下的模糊感知能力。JNB 被定义为在给定对比度条件下，人眼能够察觉的最小模糊阈值。当图像模糊程度超过该阈值时，人眼即可感知图像的模糊失真。早期研究通过主观实验的方法对不同对比度条件下的 JNB 阈值进行了量化。具体而言，实验采用矩形块作为刺激信号，将其置于具有均匀背景亮度 I_b 的图像上，前景亮度设为 I_f，两者之间的绝对差 $c = |I_f - I_b|$ 被用于表征图像对比度。矩形块的选择是基于自然图像中水平和垂直边缘最为常见的统计特征。在实验中，前景信号通过不同方差 σ 的 7×7 高斯核进行模糊处理，方差 $0.1 \le \sigma \le 0.95$。若被测者恰好能够察觉模糊，此时的标准差即为阈值 σ_{JNB}。为了得到 σ_{JNB}，在实验中，令 $I_b, I_f \in \{0,30,60,80,128,192,255\}$，综合起来，一共有 27 对不同的对比度，最小绝对差为 20，最大为 255。为减少测试时间，对于每一种前景，背景强度的组合，σ 取六个不同的离散值，其中 0.1，0.95 是两个必取的极值。对于每一种测试环境，被测者必须报告自己是否可以感知图像的模糊。

中国知网 https://www.cnki.net

对于给定的对比度c，检测模糊失真的概率采用心理测量函数的形式，该函数被建模为具有以下形式的指数：

$$p = 1 - \exp\left(-\left| \frac{\sigma}{\sigma_{JNB}} \right|^{\beta} \right) \tag{2-14}$$

当$\sigma = \sigma_{JNB}$时，$p = 63\%$，也就是说，当高斯模糊核的标准差为σ_{JNB}时，人眼能感知到模糊的概率为63%。β为控制函数形状的超参数，其范围从3.4到3.8。对于不同的c，公式（2-14）中的σ_{JNB}由与主观实验的直方图进行最小平方差拟合得到。其中一条$I_b = 255$，$I_f = 192$，拟合曲线如下图所示：

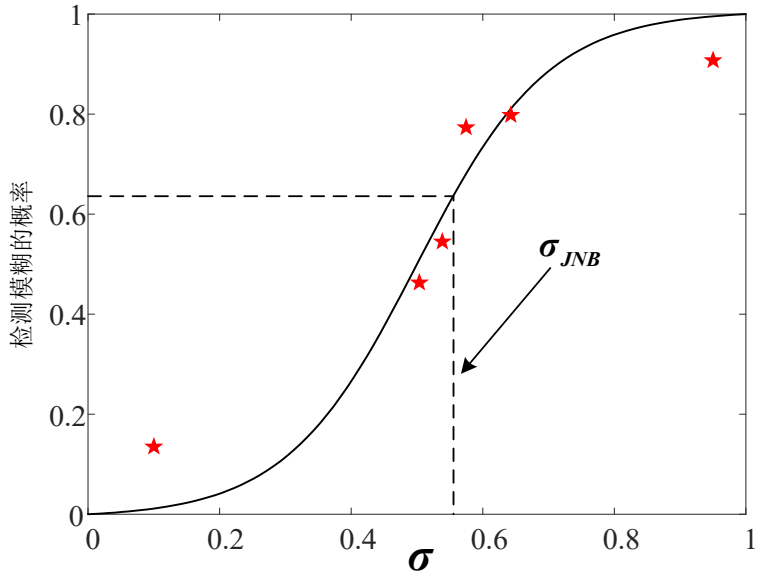


图 2.5 σ_{JNB} 非线性拟合示意图

Figure 2.5 Illustration of nonlinear fitting to obtain σ_{JNB}

仿照公式（2-14），将σ，σ_{JNB}分别替换为w，w_{JNB}，可得到公式如下：

$$p(e_k) = 1 - \exp\left(-\left| \frac{w(e_k)}{w_{JNB}(e_k)} \right|^{\beta} \right) \tag{2-15}$$

其中，e_k表示位于k位置的边缘像素，$p(e_k)$表示在e_k处感知到模糊的概率，$w(e_k)$是测量的边缘宽度，$w_{JNB}(e_k)$则类似σ_{JNB}，取决于边缘邻域的局部对比度，由上述主观实验测得。

中国知网 https://www.cnki.net

对于每个模糊检测阈值σ_{JNB}，会测量对应的边缘宽度并记为w_{JNB}。边缘宽度的测量方法是：沿边缘像素一侧统计强度值递增的像素数量，另一侧统计强度值递减的像素数量，最终宽度为两侧计数之和（不包括边缘像素本身）。其中，正向与梯度方向一致。图 2.6 通过图像某行的边缘像素及其宽度测量示意图展示了这一过程，图中标注“o”表示局部极值点。

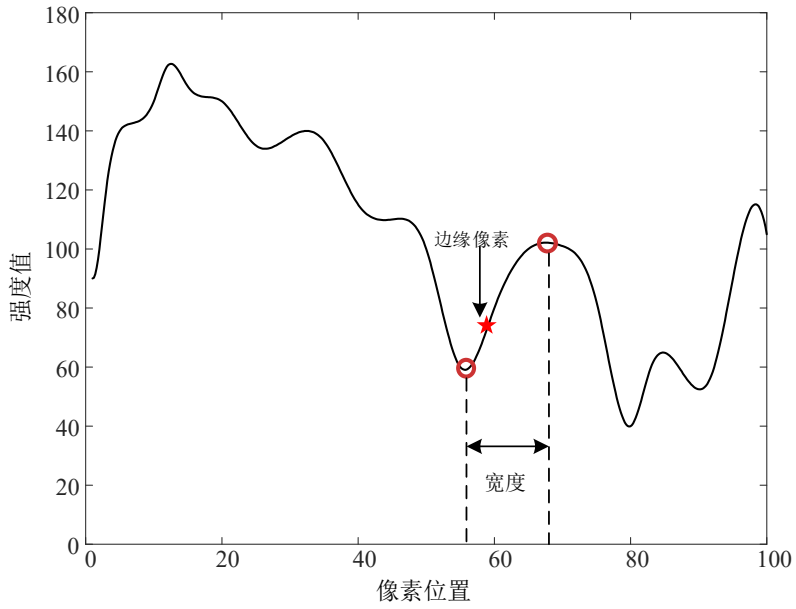


图 2.6 图像中边缘像素及其宽度测量示意图

Figure 2.6 Illustration of edge pixels and their width measurement in an image

表 2.1 中给出了在不同的对比度c的情况下，σ_{JNB}和w_{JNB}的测量值。

表 2.1 不同对比度下测量的σ_{JNB}和w_{JNB}值

Table 2.1 Measured σ_{JNB} and w_{JNB} for different contrasts

对比度c	σ_{JNB}	w_{JNB}
20	0.860	5
30	0.848	5
50	0.818	5
64	0.578	3
128	0.448	3
192	0.345	3
255	0.305	3

中国知网 https://www.cnki.net

在 JNB 理论的基础上，感知先验的研究持续发展，涌现出多种改进方法，旨在进一步提升模糊检测与估计的准确性和鲁棒性。例如，文献[101]提出了一种基于 JNB 的概率求和模型，首次将多个边缘位置的模糊检测概率进行整合，有效克服了传统方法仅依赖单一边缘分析的局限性。该模型通过统计图像边缘的 JNB 分布，模拟 HVS 对模糊的全局感知特性，从而显著提升了模糊度量的客观性。然而，传统 JNB 方法往往依赖边缘检测，限制了其在复杂场景中的适应性。针对这一问题，文献[102]提出了一种基于模糊失真标准差的边缘宽度参数化模型。该方法通过自适应分配像素级 JNB 阈值，增强了对高对比度显著区域的检测精度，同时支持复杂场景下的局部模糊量化。在进一步的研究中，Zhu 等人[103]结合方向边缘扩散函数与局部概率求和，提出了一种空间变化的模糊估计框架。该方法充分挖掘图像中模糊程度随空间位置变化的特点，利用方向扩散信息增强对局部模糊变化的感知能力，从而在多样化场景下实现更为稳健和精确的模糊检测与估计。

基于上述特性，感知先验在弱纹理和低对比度的离焦模糊场景中表现出明显优势：此类模糊往往导致边缘与细节被显著平滑，而感知先验通过模拟人眼对模糊的敏感性，能够在纹理退化严重的区域提供精确的模糊估计，从而显著提升离焦图像去模糊的稳定性与视觉感知质量。

2.4.2 大模型先验

大模型先验是指利用在大规模数据集上预训练的基础模型所蕴含的深层知识，作为图像去模糊任务中的先验信息。此类模型通常通过在大规模图像或图文对等数据上进行训练，具备强大的特征提取能力，能够有效捕捉图像中的全局结构、语义特征以及局部细节，从而为图像复原提供更通用、鲁棒的先验支持。相较于传统先验方法，大模型先验在图像去模糊任务中展现出以下几方面的显著优势[104]：1）更强的特征表达能力：依托深层神经网络的多层特征提取机制，大模型能够学习复杂的图像模式和高级语义信息，显著提升细节恢复的质量；2）全局上下文建模能力：得益于在多模态大数据上的训练，大模型具备全局感知能力，能够理解场景结构、物体关系等上下文信息，从而精准地引导模糊区域的重建；3）良好的泛化能力：由于在多样化场景和跨域数据上进行训练，大模型对特定数据分布的依赖性较弱，能够适应多种类型的模糊场景。

典型的大模型如 CLIP[49]、Stable Diffusion[48]和 DepthAnything[105]，已在图像复原任务中展现出显著优势[50]。CLIP[49]是一种基于对比学习的多模态基础模型，通过超过 4 亿图像-文本对训练，学习了图像与文本之间的语义对齐关系。其丰富的视觉概念知识可用于引导图像去模糊模型恢复语义关键区域，尤其在人脸、物体边缘及复杂场景中表现出色。Stable Diffusion[48]是一种潜在扩散模型，在包含

中国知网 https://www.cnki.net

23 亿张图文配对样本的大规模数据集上训练，擅长生成结构清晰、细节丰富的图像，尤其适用于处理具有高度不确定性和复杂纹理的模糊区域。此外，DepthAnything[105]是一款专为图像深度估计任务而设计的基础模型，具备从复杂图像中提取准确深度信息的能力，因此，可为离焦去模糊任务提供关键的几何先验支持。

总体而言，大模型先验通过提供结构化、语义化和几何化的多维信息，有效约束了图像去模糊任务中的解空间，提高了复原结果的稳定性与合理性。尤其在复杂离焦场景中，这一优势表现得尤为突出。复杂离焦往往涉及深度分布不均、模糊模式多样等问题，而大模型凭借其全局上下文建模和多维语义理解能力，能够提取跨区域的结构与语义信息，从而在高度复杂的场景中实现对空间变化模糊的有效恢复。随着训练数据规模的持续扩大与模型能力的不断提升，大模型先验在图像复原领域的重要性将进一步增强。

2.4.3 极值先验

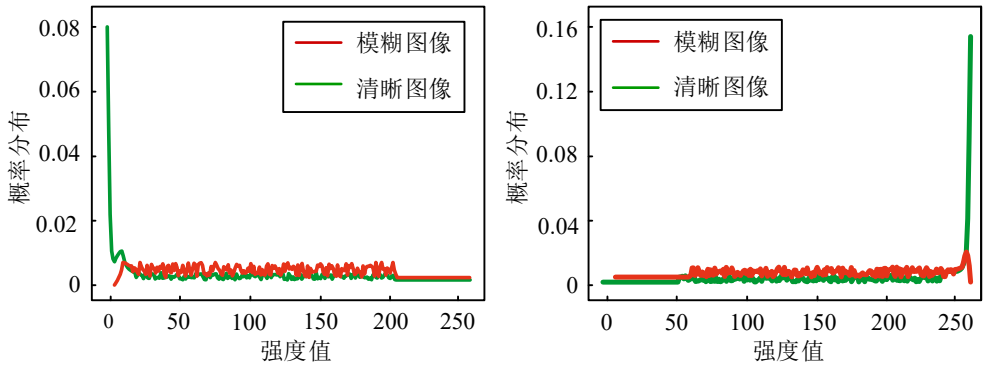
极值先验是一类基于图像局部统计特性的先验知识，在图像去模糊任务中被广泛应用。该类先验通过建模图像局部区域内像素强度的极值分布规律，为模糊核估计和清晰图像复原提供有效约束，从而显著提升去模糊算法的稳定性与鲁棒性。在众多极值先验中，暗通道先验（Dark Channel Prior，DCP）[18]和亮通道先验（Bright Channel Prior，BCP）[65]是最具代表性且应用最广泛的两种形式。

DCP 由 Pan 等人[18]在 2016 年提出，其核心假设为：在自然清晰图像中，大多数局部区域中至少存在一个颜色通道的像素值接近于零，因此清晰图像的暗通道具有较高的稀疏性。然而，在模糊图像中，由于模糊过程中的卷积作用，暗像素会与周围的亮像素混合，从而显著降低模糊图像中暗通道的稀疏性。因此，暗通道的稀疏程度可作为衡量图像清晰度的一个重要依据。暗通道在数学上的定义如下：

$$P_{DC}(I(x)) = \min_{c\in\{r,g,b\}} \left(\min_{y\in\Omega(x)} I^{c}(y) \right) \tag{2-16}$$

其中，$P_{DC}(\cdot)$ 表示在某个像素位置处的暗通道值，$\Omega(x)$ 表示以 x 为中心的局部邻域，$I^{c}(y)$ 表示图像在第 c 个颜色通道上像素 y 的强度值，r，g，b 表示输入彩色图像的三个通道。该先验已通过理论分析和大量的实验验证了清晰图像的暗通道（即图像块中像素值的局部最小值）相比于模糊图像的暗通道往往呈现出更高的稀疏性（如图 2.7（a）所示）。

中国知网 https://www.cnki.net



(a) 暗通道先验　　(b) 亮通道先验

图 2.7 暗通道与亮通道先验的统计分布

Figure 2.7 Statistical distribution of dark channel and bright channel priors

受 DCP 的启发，Yan 等人[65]提出了 BCP，其核心假设为：清晰图像中某些局部区域内往往存在接近饱和的亮像素，即亮通道值较高；而在模糊图像中，这些亮度特征会被模糊卷积所削弱（如图 2.7（b）所示）。因此，亮通道也可作为图像去模糊的先验信息。亮通道的数学公式定义如下：

$$P_{BC}(I(x)) = \max_{c\in\{r,g,b\}} \left(\max_{y\in\Omega(x)} I^{c}(y) \right) \tag{2-17}$$

Yan 等人[65]进一步提出将 DCP 和 BCP 同时用于图像去模糊，其优化目标可统一建模为以下形式：

$$\min_{I,k} \| I \otimes k - B \|_2^2 + \gamma \| k \|_2^2 + \mu \| \nabla I \|_0 + \alpha \| P_{DC}(I) \|_0 + \beta \| 1 - P_{BC}(I) \|_0 \tag{2-18}$$

然而，同时引入 DCP 与 BCP 并不总是能够获得最优的去模糊效果，主要体现在以下两个方面：1）不同类型图像在局部区域内的亮暗分布存在显著差异。例如，在夜景图像中，暗像素通常占据主导地位，而高曝光或户外场景图像则往往包含大面积的高亮区域。在这种情况下，统一地同时使用 DCP 与 BCP 可能导致二者在局部区域内产生冲突，相互干扰，从而削弱各自的优势。2）DCP 和 BCP 本质上都依赖于稀疏性假设，通常会导致目标函数具有非凸性和非线性，增加了求解难度。为此，Yan 等人[65]设计了一种基于查找表的最小值操作的线性近似算子，在一定程度上缓解了由稀疏性引起的非凸优化问题，但该方法所得解仍为非严格意义上的近似解。

2020 年，Wen 等人[66]提出了逐块最小像素（Patch-wise Minimal Pixels，PMP）先验，该方法可视为 DCP 的简化版本，其定义如下：

中国知网 https://www.cnki.net

$$P(I)(i)=\min_{(x,y)\in\Omega_i}\left(\min_{c\in\{r,g,b\}}I(x,y,c)\right) \tag{2-19}$$

其中，Ω_i表示非重叠的第i个块中像素的位置集合。由于 PMP 的稀疏性会引入非凸非线性优化问题，Wen 等人[66]通过最大后验框架对 PMP 进行稀疏性诱导，从而避免了以往方法中的非严格近似解，同时显著提升了计算效率。

基于这一特性，极值先验在由相机抖动引起的均匀模糊场景中表现尤为突出。相机抖动往往导致线性、均匀的模糊核分布，而极值先验通过建模图像中暗/亮像素的分布特性，为模糊核估计提供了稳健的先验约束，使得均匀运动模糊的退化过程能够被更准确地逆转，从而显著提升了图像复原质量。

2.4.4 频率先验

频率先验是一种基于图像在频域中分布特性的先验知识，广泛应用于图像复原任务。该先验基于一个核心假设：清晰图像和模糊图像在频域中的表现存在显著差异，特别是在高频分量的分布上。模糊图像通常伴随着高频信息的显著衰减，导致边缘和纹理细节的丢失；而清晰图像则包含丰富的边缘信息和纹理结构，在频域中表现为高频分量的增强。因此，利用频率先验可以有效引导模型恢复出模糊过程中丢失的高频信息，增强图像的清晰度与细节表达能力。

为了提取图像的频域信息，研究者普遍采用以下几类频域变换方法：离散傅里叶变换（Discrete Fourier Transform，DFT）[106]、离散余弦变换（Discrete Cosine Transformation，DCT）[107]、离散小波变换（Discrete Wavelet Transform，DWT）[108]以及奇异值分解（Singular Value Decomposition，SVD）[22]等。其中，DWT 因其具有多尺度性、方向选择性和良好的可逆性，被广泛应用于图像去模糊、去噪、超分辨等低级视觉任务中[108,109]。DWT 能够将图像分解为多个频率子带，包括低频近似系数和三个方向（水平、垂直和对角）的高频细节系数。假设输入图像为$I\in\mathbb{R}^{H\times W}$，其基于二维 Haar 小波的两级 DWT 分解表示为：

$$\left\{A_2,\{V_2,H_2,D_2\},\{V_1,H_1,D_1\}\right\}=\mathrm{DWT}(\mathrm{DWT}(I)) \tag{2-20}$$

其中，$A_2\in\mathbb{R}^{H/4\times W/4}$表示第二级的低频近似系数，$\{V_1,H_1,D_1\}\in\mathbb{R}^{H/2\times W/2}$表示第一级高频细节系数（分别对应水平、垂直和对角方向），$\{V_2,H_2,D_2\}\in\mathbb{R}^{H/4\times W/4}$表示第二级的高频细节系数。

整个过程采用递归方式：首先对图像进行一级小波分解，然后对低频子带进一步分解，得到更深层的结构特征。

中国知网 https://www.cnki.net

图像的重构过程可通过逆小波变换（Inverse Discrete Wavelet Transform, IDWT）实现，公式表达如下：

$$I = \mathrm{IDWT}(\mathrm{IDWT}(A_2, \{V_2, H_2, D_2\}, \{V_1, H_1, D_1\})) \tag{2-21}$$

图 2.8 展示了图像经过两级小波分解与重构的完整流程。DWT 能够从原始图像中提取多层次的频率信息，并借助 IDWT 在无信息损失的前提下实现图像的恢复。图 2.9 进一步展示了清晰图像与其对应的模糊图像在不同频带下的信息熵对比结果，可以明显观察到，模糊图像在高频子带上的熵值显著低于清晰图像，反映出其在边缘与纹理等高频细节方面存在严重缺失。基于上述现象，若在去模糊过程中能从清晰图像中学习并恢复出包含多频率成分的初始估计图像，并将其作为频率先验引导后续复原过程，便可有效弥补模糊图像中丢失的高频信息。通过引入频率先验，特别是结合小波分解等多尺度频域分析方法，可实现频率特征的显式建模与分层利用，从而引导网络在不同尺度上恢复低频结构与高频细节。

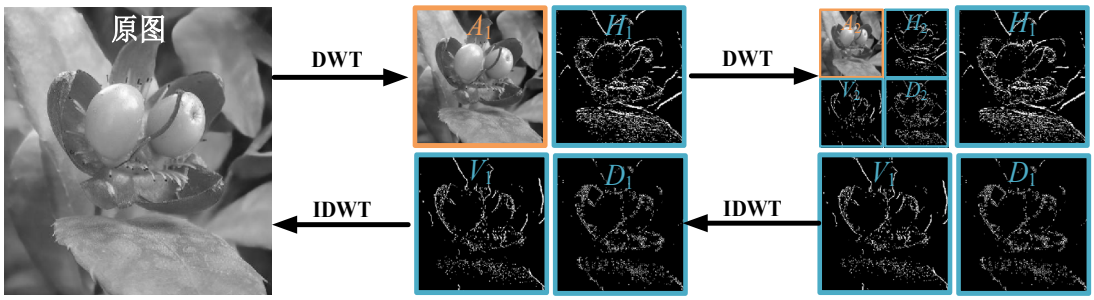
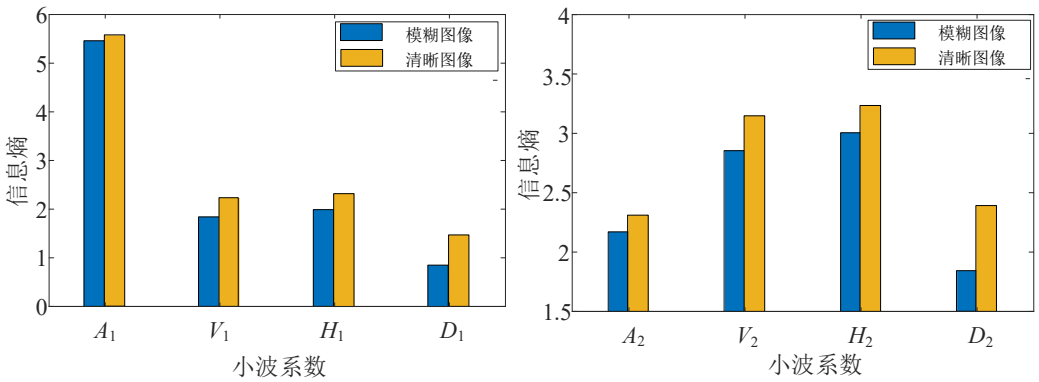


图 2.8 图像小波分解与重构示意图

Figure 2.8 Illustration of wavelet decomposition and reconstruction of an image



(a) 一级小波变换　　(b) 二级小波变换

图 2.9 清晰图与模糊图进行两级小波分解后的信息熵对比

Figure 2.9 Entropy of wavelet coefficients after two-level decomposition of sharp and blurred images

中国知网 https://www.cnki.net

近年来，研究者提出了多种基于小波分解的多尺度频域分析方法，以进一步提升图像恢复的性能。例如，Min 等人[110]利用小波变换分离模糊图像的不同频率信息，从而缓解模糊导致的平滑效应。Zou 等人[111]提出小波复原模块，有效增强网络对高频细节的恢复能力。Shang 等人[94]将小波高频分量引入扩散模型以增强细节重建，但未对低频成分进行建模。在文献[108,109]中，低频分量通过逆向扩散过程进行预测，而高频分量则通过卷积操作进行复原。然而，这些方法大多采用频率分量的独立处理策略，未能实现多频信号在扩散模型中的协同建模，限制了其在扩散模型中对结构与细节的整体复原能力。值得注意的是，频率先验在由目标运动引起的动态模糊场景中展现出独特的优势。运动模糊往往会显著削弱图像的高频分量，导致细节缺失。通过在频域中分离低频背景与高频细节，频率先验能够有效恢复运动轨迹模糊区域中的纹理和边缘信息，从而提升动态模糊场景下的图像重建质量。

2.5 本章小结

本章首先从图像模糊的成因出发，系统介绍了离焦模糊和运动模糊的形成机制。随后，对图像模糊的数学模型进行了分析，并重点讨论了其所面临的病态性问题。具体而言，图像去模糊属于典型的病态逆问题，微小的观测扰动可能导致复原结果与真实图像之间存在显著偏差，严重影响去模糊的精度与稳定性。为缓解上述问题，本章介绍了四类常用的图像先验知识：感知先验、大模型先验、极值先验与频率先验。这些先验在约束解空间和引导网络学习过程中发挥了重要作用。感知先验关注人眼对模糊的主观感知；大模型先验依托大规模预训练模型中蕴含的丰富纹理与语义信息；极值先验通过建模图像中的极值分布提升模糊特征的表达能力；频率先验则利用频域信息指导细节恢复，强化图像的结构与纹理表现。进一步结合场景适应性分析，感知先验适用于弱纹理、低对比度的离焦模糊场景，大模型先验在深度分布复杂的离焦模糊中表现更佳，极值先验在相机抖动导致的均匀运动模糊下具备稳健优势，而频率先验则在动态运动模糊中能有效恢复高频细节。该先验-场景匹配策略不仅揭示了不同先验的适用边界，也为后续算法设计提供了理论指导和方法论依据。

中国知网 https://www.cnki.net

第 3 章 基于感知先验的离焦模糊图估计方法

3.1 引言

如上一章所述，离焦模糊是图像采集过程中常见的一类退化现象，主要由传统相机光学镜头景深受限所导致。由于离焦模糊具有明显的空间非均匀性，图像中不同区域的模糊程度往往存在显著差异。为了有效建模这一特性，亟需构建一种能够反映模糊强度空间分布的像素级表示形式，即离焦模糊图。该图通过估计每个像素的模糊程度生成，已广泛应用于前景背景分割、离焦效果增强和图像去模糊等多个图像处理任务中。

现有的离焦模糊图估计方法多依赖图像边缘的局部响应特征，通常通过将原图与再模糊图进行比较，提取模糊差异以量化模糊程度。然而，此类方法在低对比度或弱纹理区域表现不佳，易导致模糊估计误差或模糊图结构不完整，从而影响后续应用的效果。为提升估计的准确性，本章提出一种基于感知先验的离焦模糊图估计方法，充分结合人类视觉系统在模糊感知中的心理物理特性。具体而言，本章以再模糊奇异值差异（Re-blurred Singular Value Difference，RESVD）作为核心特征，并引入基于 JNB 理论构建的感知先验权重，对传统模糊度量进行感知调制，从而提升在低对比度区域的模糊判别能力。此外，为增强模糊图的空间一致性与结构完整性，本章进一步引入额外边缘点约束与传播优化策略，实现从稀疏模糊估计向高质量全图补全的过渡。最后，通过在多个标准离焦模糊数据集上的定量与定性实验，验证了所提方法在模糊强度估计中的精度提升，以及在离焦去模糊任务中的优越表现。

本章的主要贡献总结如下：

（1）提出一种基于局部梯度块与再模糊理论的 RESVD 特征提取方法，能够有效表征图像边缘处的模糊特征，显著提升边缘模糊估计的准确性；

（2）引入基于 JNB 理论构建的感知权重，对 RESVD 特征进行感知调制，从而增强低对比度区域的模糊辨别能力，提高模糊图估计的鲁棒性；

（3）构建带有额外边缘点约束的稀疏模糊图，并结合双边滤波与 Matting Laplacian 插值策略，实现稀疏模糊信息向完整图的高质量传播与补全，确保模糊图在空间结构上的完整性；

（4）将所估计的离焦模糊图应用于离焦图像去模糊任务中，在恢复图像清晰度方面取得显著提升，充分验证了所提方法在图像处理任务中的应用潜力。

中国知网 https://www.cnki.net

3.2 感知先验引导的离焦模糊图估计算法

本节将系统阐述所提出的感知先验引导的离焦模糊图估计算法。首先，依据边缘建模理论对图像进行边缘检测，提取用于模糊估计的初始边缘点。随后，构建一种基于 RESVD 的模糊度量算子，用于量化边缘点处的模糊程度。考虑到传统模糊度量方法在边缘点存在估计不准、对比度敏感等问题，本章进一步引入融合感知先验的加权机制，结合人类视觉系统对模糊感知的心理物理特性，对 RESVD 特征进行感知调制，从而提高其在低对比度区域的鲁棒性与准确性。为增强稀疏模糊估计在空间传播过程中的稳定性与完整性，本节在初始边缘点基础上添加额外的边缘点，以构建具有约束的稀疏模糊图。最后，采用 Matting Laplacian 插值方法对稀疏模糊图进行全图扩展，从而生成最终的完整离焦模糊图。该算法的整体流程如图 3.1 所示。

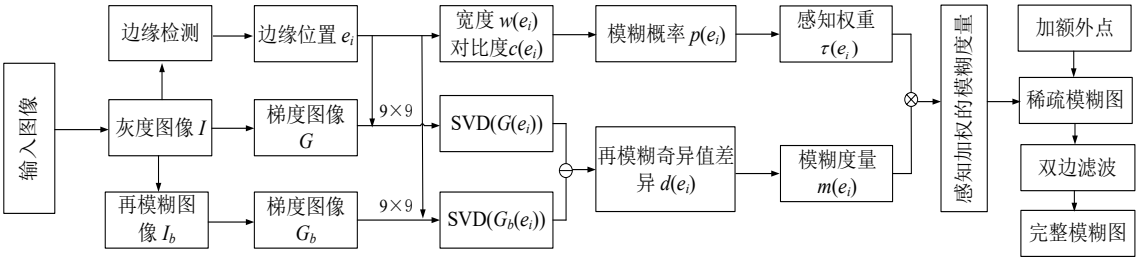


图 3.1 感知加权的离焦模糊图估计框架

Figure 3.1 Defocus blur map estimation framework with perceptual weighting

3.2.1 边缘检测

离焦图像的边缘包含丰富的场景深度信息，其中边缘像素的梯度幅度通常与其模糊程度密切相关。在自然图像中，大多数边缘属于阶跃型边缘。因此，采用参数化边缘模型[112]进行边缘描述和检测，不仅能够准确识别边缘位置，还可以为每个边缘像素估计其模糊相关的宽度与对比度。图 3.2 展示了一维边缘模型的示意图。其中，图像中位置 x_0 处的边 $e\left(x;b,c,w,x_0\right)$ 可建模为如下数学形式：

$$e\left(x;b,c,w,x_0\right)=b+\frac{c}{2}\left(1+erf\left(\frac{x-x_0}{w\sqrt{2}}\right)\right) \tag{3-1}$$

其中，$erf(\cdot)$ 是误差函数，w 是边缘宽度，c 是边缘对比度，b 是边缘基准强度，x 是水平轴位置。

中国知网 https://www.cnki.net

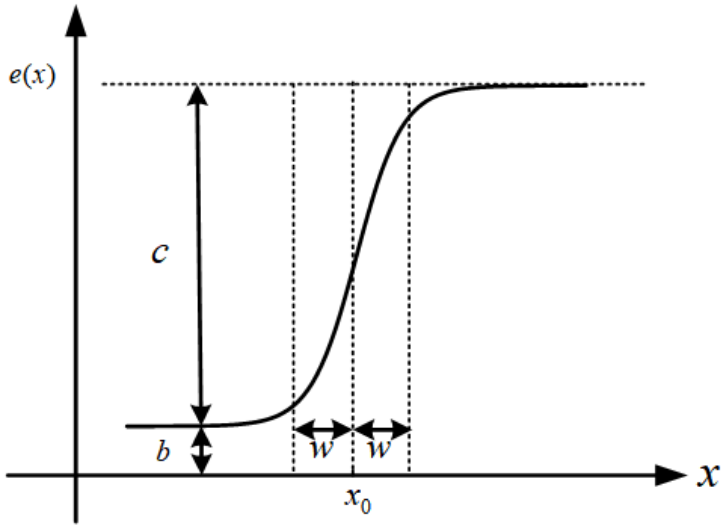


图 3.2 一维边缘模型示意图

Figure 3.2 illustration of the one-dimensional edge model

此外，所有边都可以通过拟合公式（3-1）来参数化。拟合过程包括边缘检测和参数估计两个部分。与 Canny 算子类似，边缘检测是通过卷积 $e(x;b,c,w,x_0)$ 与预定义的高斯滤波器 $g(x,\sigma)$ 的导数来完成的，其表达式为：

$$d(x;\sigma,c,w,x_0)=\frac{c}{\sqrt{2\pi\left(w^2+\sigma^2\right)}}\exp\left(\frac{-(x-x_0)^2}{2\left(w^2+\sigma^2\right)}\right) \tag{3-2}$$

在 $x=0$， $x=a$， $x=-a$ 处进行多点估计，可以得到峰值附近的三个测量值 $d_1(0;\sigma,c,w,x_0)$， $d_2(a;\sigma,c,w,x_0)$ 和 $d_3(-a;\sigma,c,w,x_0)$。对比度 c 和宽度 w 可以由以下推导获得：

$$c=d_1\sqrt{\frac{2\pi a^2}{\mathrm{In}\left(d_1^2/d_2d_3\right)}}\left(\frac{d_2}{d_3}\right)^{\frac{1}{4a}} \tag{3-3}$$

$$w=\sqrt{\frac{a^2}{\mathrm{In}\left(d_1^2/d_2d_3\right)}-\sigma^2} \tag{3-4}$$

其中， a 是所选两点到边缘的距离，通常 $a=1$。

3.2.2 基于 RESVD 的模糊度量算子

对于给定的灰度图像 $I\in\mathbb{R}^{m\times n}$，其奇异值分解形式如下所示：

中国知网 https://www.cnki.net

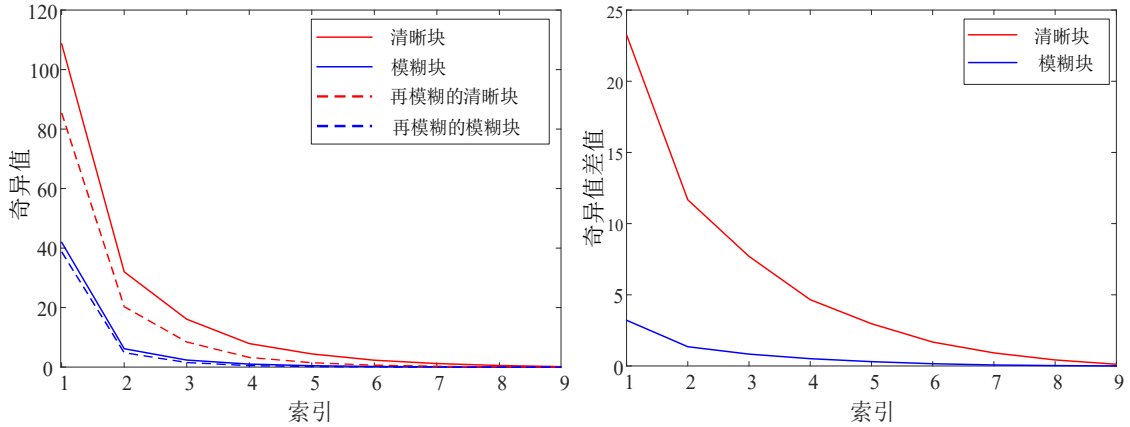
$$I = U \times \Sigma \times V^T \tag{3-5}$$

其中，$U \in \mathbb{R}^{m \times m}$ 是左奇异向量，$V^T \in \mathbb{R}^{n \times n}$ 是右奇异向量，Σ 是主对角矩阵，其主对角元素为奇异值。左奇异向量 U 和右奇异向量 V^T 分别反映图像中的纹理与几何结构信息，而奇异值所组成的对角矩阵 Σ 则表征图像的能量分布特性。图像纹理越丰富，即越清晰，其能量分布越分散，奇异值相对较小；反之，图像越模糊，能量越集中，对应的奇异值越大。上述分解中各变量 U 、V^T 和 Σ 的定义如下：

$$\begin{aligned} U &= [u_1, u_2, \cdots, u_m] \\ V^T &= [v_1, v_2, \cdots, v_n] \\ \Sigma &= diag(\lambda_1, \lambda_2, \cdots, \lambda_r) \end{aligned} \tag{3-6}$$

其中，u_i 和 v_i 是标准正交基，$diag(\cdot)$ 是对角矩阵，λ_i 表示第 i 个奇异值，$r = \min(m, n)$，奇异值由大到小的顺序排列：$\lambda_1 > \lambda_2 > \cdots > \lambda_r$。

根据再模糊理论，图像块越清晰，模糊处理后的奇异值变化越显著；反之，图像块越模糊，再模糊操作对其奇异值影响较小。本节在图像的梯度域中构建图像块，该方式不仅能有效去除大部分空间冗余信息，同时保留图像的清晰结构。为验证该理论，本节在公共数据集[113]中分别选取了 1 万个以边缘点为中心的 9×9 大小的清晰块与模糊块。图 3.3 展示了清晰与模糊图像块在再模糊处理前后的奇异值分布统计情况。结果表明，模糊块的奇异值在再模糊前后变化幅度较小，而清晰块的变化较为显著。



(a) 奇异值分布曲线　　(b) 奇异值差值分布曲线

图 3.3 清晰块和模糊块的统计结果

Figure 3.3 Statistical results of clear and blurred patches

中国知网 https://www.cnki.net

给定一个原始的梯度图像 G，对其进行再模糊处理后得到 G_b，并定义以边缘点 e_i 为中心的图像块的 RESVD 向量为：

$$\begin{aligned} d(e_i) &= [d_1, d_2, d_3, \cdots, d_r] \\ d_k &= |\lambda_k - \lambda_k^b|,\ k = 1, 2, \cdots, r \end{aligned} \tag{3-7}$$

其中，λ_k 是原始图像块的奇异值，λ_k^b 是相应的再模糊块的奇异值，r 是奇异值的数量，d_k 表示 RESVD 向量 d 的第 k 个元素，其取值范围为 $[0, \infty)$。

为量化每个边缘点 e_i 的模糊度，采用逻辑回归函数对 RESVD 向量进行拟合，具体形式如下：

$$\begin{aligned} \hat{d}(e_i) &= [\hat{d}_1, \hat{d}_2, \hat{d}_3, \cdots, \hat{d}_r] \\ \hat{d}_k &= \frac{1}{1 + \exp(\alpha \cdot d_k)},\ k = 1, 2, \cdots, r \end{aligned} \tag{3-8}$$

其中，$\hat{d}_k$ 表示模糊度向量 $\hat{d}$ 的第 k 个元素，其取值范围 $(0, 0.5]$，值越大表示越模糊；α 是一个调整映射结果的常量。从图 3.3（b）可以观察到，模糊块在再模糊前后的奇异值最大差异不超过 4。基于此，本节设计了映射函数，用于提升模糊块的 RESVD 值，并压缩清晰块的 RESVD 值。该函数将小于 4 的值映射至更高区间，将大于 4 的值映射至接近 0 的区间，如图 3.4 所示。多组 α 值测试结果表明，$\alpha = 2$ 所对应的映射函数最符合模糊度区分的设计目标。

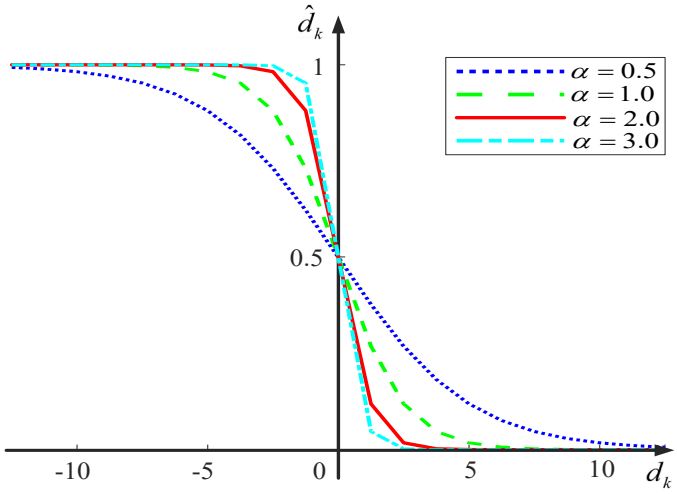


图 3.4 不同 α 的映射结果

Figure 3.4 Mapping results of different α

中国知网 https://www.cnki.net

在稀疏模糊图估计中，边缘点 e_i 的模糊度向量需要通过累加所有元素融合成一个模糊度值，表示为：

$$m(e_i)=\sum_{k=1}^{r}\hat{d}_k(e_i) \tag{3-9}$$

其中，$\hat{d}_k(e_i)$ 为 RESVD 特征，$m(e_i)$ 为模糊度量值。图 3.5 展示了基于 RESVD 稀疏模糊图估计的整体流程图。

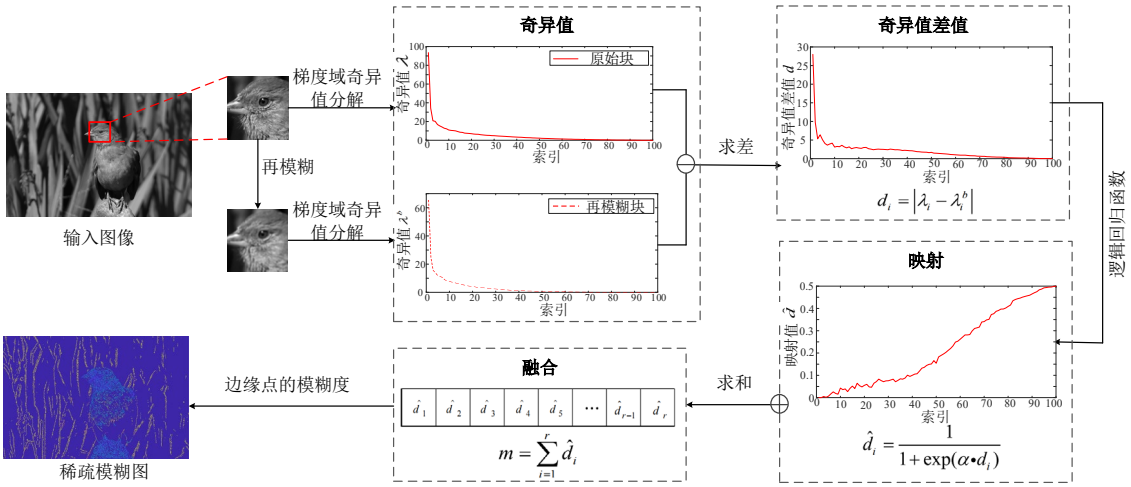


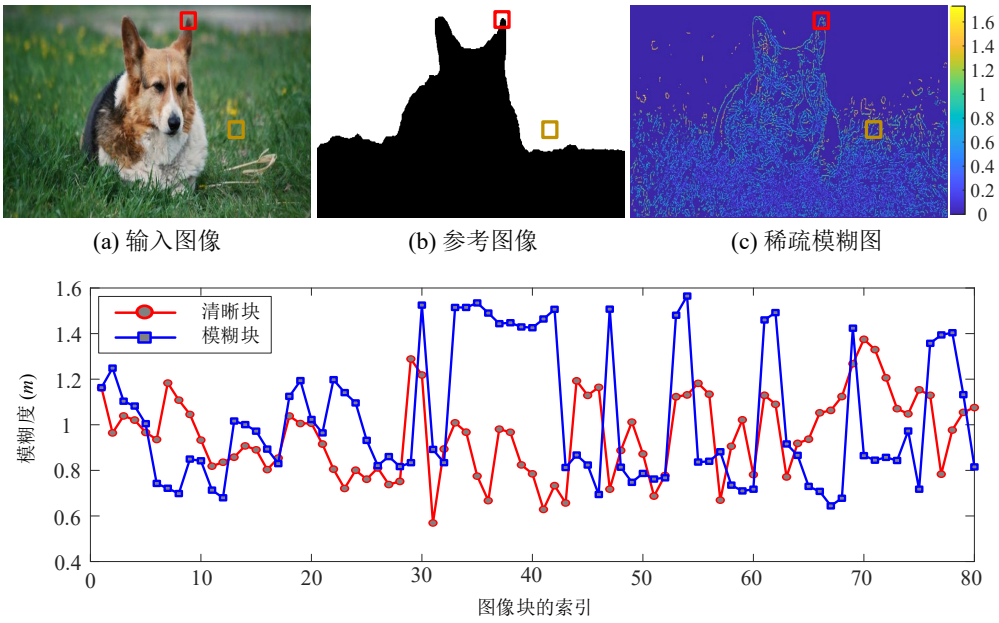
图 3.5 基于 RESVD 稀疏模糊图估计流程图

Figure 3.5 Flowchart of sparse blur map estimation based on RESVD

尽管上述所提的 RESVD 特征在多数情况下能够有效地估计稀疏模糊映射，但当清晰块与模糊块之间的 RESVD 差异较小时，其判别能力将显著下降。图 3.6 展示了此类基于 RESVD 的模糊图估计失效的典型案例。该图像取自数据集[33]，其中红色框标示的是以清晰边缘点为中心的图像块，黄色框则对应以模糊边缘点为中心的图像块。由于红色框所处区域为图像中的平坦区域，其再模糊处理前后的奇异值差异较小，导致所估计出的模糊度与实际模糊区域非常接近，进而降低了判别效果。

为了更加直观地比较图像清晰块与模糊块之间的模糊程度差异，本节进一步从图 3.6（a）中分别随机选取了 80 个清晰块和 80 个模糊块，并计算各自的模糊度值，其分布结果如图 3.6（d）所示。图中横轴表示图像块的编号，纵轴对应其模糊度值。统计结果表明，部分清晰块的模糊度显著高于模糊块，而部分模糊块的模糊度则明显偏低，这揭示了在特定情形下基于 RESVD 的模糊度估计存在一定的误判风险。

中国知网 https://www.cnki.net



(a) 输入图像　(b) 参考图像　(c) 稀疏模糊图

(d) 不同图像块的模糊度

图 3.6 基于 RESVD 稀疏模糊图估计的失败案例

Figure 3.6 A failure case of sparse blur map estimation based on RESVD

3.2.3 感知先验加权的度量算子

为进一步评估基于 RESVD 的模糊度量算子在区分模糊与清晰区域方面的有效性，从数据集[113]中分别选取了 10000 个清晰和模糊边缘块，统计其模糊度分布，结果如图 3.7（a）和（b）所示。从图中可以观察到，约 40%的清晰边缘块被赋予了较高的模糊度值。这一现象说明，单纯依赖 RESVD 特征所构建的模糊度量方法难以准确区分图像中的模糊与清晰区域。

为此，本节引入人类感知先验作为辅助，利用人类视觉系统在不同对比度水平下对模糊的响应特性，以提升模糊区域的识别效果。根据文献[101]的主观实验研究，首次提出了基于 JNB 的图像模糊度量方法。JNB 被定义为在给定对比度下，边缘周围人眼可感知的最小模糊量。对于边缘点 e_i，其边缘宽度 $w(e_i)$ 和对比度 $c(e_i)$ 可由公式（3-1）估算。模糊感知概率模型由文献[101]建立如下：

$$p(e_i)=1-\exp\left(-\left|\frac{w(e_i)}{w_{JNB}(e_i)}\right|^{\beta}\right) \tag{3-10}$$

其中，w_{JNB} 表示人眼在给定对比度下无法察觉的最大边缘模糊宽度。根据第二章中的 JNB 表，β 被设置为 3.6，$c\le 50$ 时 w_{JNB} 为 5，$c>50$ 时 w_{JNB} 为 3。当 $w_{JNB}(e_i)=w(e_i)$ 时，相应的模糊检测概率为 63%，即 $p_{JNB}=63\%$。

中国知网 https://www.cnki.net

基于“低于 JNB 的模糊难以被人眼觉察”的感知先验知识，本节提出一种感知权重因子，以增强清晰与模糊区域之间的区分度。该因子定义如下：

$$\tau(e_i)=\begin{cases}\tau_{low} & p(e_i)\le 63\% \\ \tau_{high} & p(e_i)>63\%\end{cases} \tag{3-11}$$

其中，当 $p(e_i)\le 63\%$ 时，e_i 被视为清晰，赋予小于 1 的感知权值；当 $p(e_i)>63\%$ 时，e_i 被视为模糊，赋予大于 1 的感知权值。感知权值细化了基于 RESVD 的模糊图。具体而言，τ_{low} 设置在 $(0.5,1)$ 区间内，而 τ_{high} 设置在 $(1,1.5)$ 区间内。

接下来，本节提出一种感知加权模糊度量方法，在 RESVD 基础上引入 JNB 感知权重。每个边缘点 e_i 的最终模糊度计算如下：

$$M(e_i)=\tau(e_i)\cdot m(e_i) \tag{3-12}$$

为验证感知权重在区分模糊与清晰区域中的有效性，本节重新计算了图 3.7（a-b）中样本块在引入感知加权后的模糊度分布，结果见下图 3.7（c-d）。从中可以观察到，引入感知加权后有效增强了模糊区域与清晰区域的区分度。

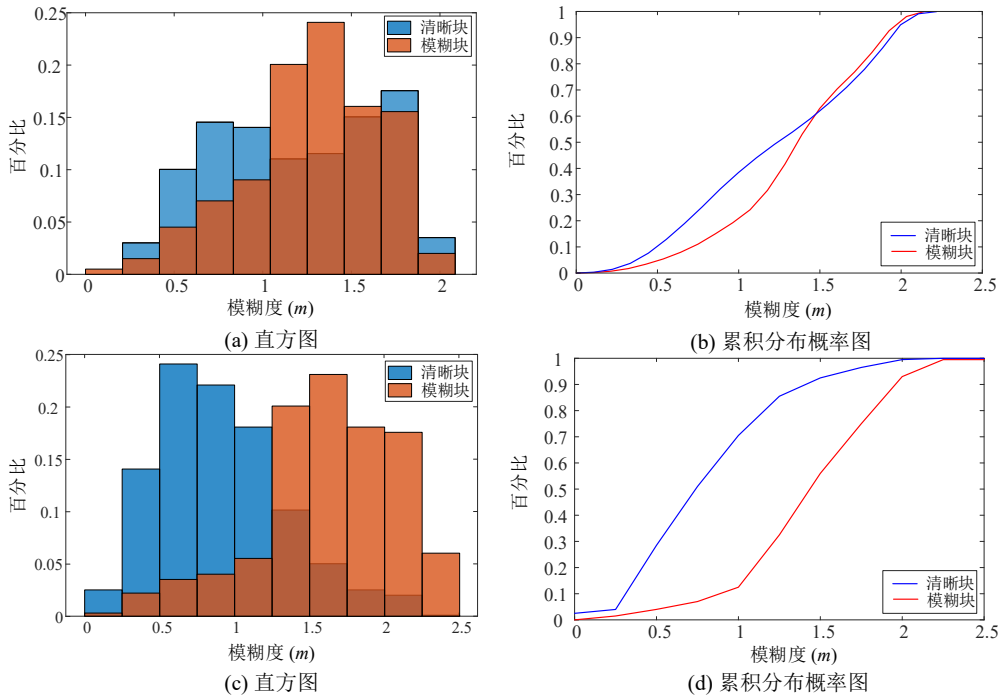


图 3.7 清晰块和模糊块模糊度分布的比较

Figure 3.7 Comparison of blurriness distribution between clear and blurred patches

中国知网 https://www.cnki.net

3.2.4 额外边缘点约束

当图像中原始边缘点较为稀疏时，直接基于初始稀疏离焦图进行模糊信息传播，往往难以获得理想的完整模糊图。为此，本节提出一种边缘点补充策略，在边缘点分布稀疏区域引入额外的清晰或模糊边缘点，以提高模糊估计的完整性。

该策略基于如下观察：若某一区域被多个小模糊度的边缘点所包围，则该区域极有可能属于清晰区域；反之，则可能为模糊区域。因此，可根据周围边缘点的模糊度信息，在当前区域内补充伪边缘点，强化边缘点表达。具体步骤如下：将图像划分为若干不重叠图像块，每块大小为 $0.05\times\min(h,w)$，其中 h 和 w 分别表示原始图像的高度和宽度。接着，依次扫描每个图像块，判断当前块中是否包含边缘点。若为空，则检测其四个方向（上、下、左、右）相邻图像块中的边缘点模糊度。若四个方向的边缘点模糊度均小于预设阈值（设为 1.2），则将该图像块的对角线区域三分之一标记为清晰边缘点；否则标记为模糊边缘点。该方法有效填补了原始边缘点未覆盖区域的模糊信息空缺，提升了后续传播过程中模糊估计的连续性与准确性。

图 3.8 展示了所提方法的具体操作流程及其对比结果：（a）为输入的离焦模糊图像；（b）为边缘点补充后的稀疏模糊图，其中蓝色表示清晰点，黄色表示模糊点；（c）为参考的模糊检测图；（d）为添加边缘点后的完整模糊图；（e）为未添加边缘点的结果。对比可见，所提方法在空间连续性与结构完整性方面均优于未补充方案，验证了其在离焦模糊估计中的有效性。

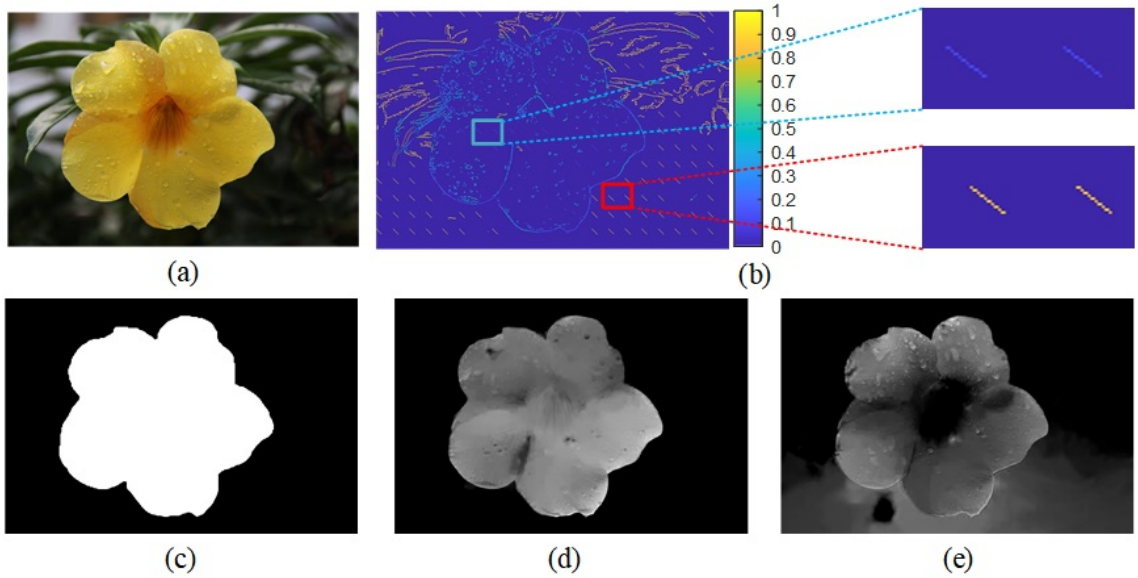


图 3.8 添加边缘点的示意图

Figure 3.8 Illustration of adding edge points

中国知网 https://www.cnki.net

3.2.5 完整离焦模糊图估计

在上一节中，已获得初始的稀疏模糊图，记为 $M \in \mathbb{R}^{H\times W}$。为获得完整的离焦模糊图 $\hat{M} \in \mathbb{R}^{H\times W}$，需将边缘处的离焦模糊估计扩展传播至整个图像。为此，本节引入 Matting Laplacian 插值方法进行模糊度的全图推断。该插值过程可形式化为如下优化问题：

$$\min J(\hat{M}), J(\hat{M}) = \hat{M}^T L\hat{M} + \lambda(\hat{M} - M)^T D(\hat{M} - M) \tag{3-13}$$

其中，D 是一个对角矩阵，表示边缘位置的指示函数，如果像素 i 位于边缘，其元素 D_{ii} 为 1，否则为 0。λ 是一个惩罚因子，它平衡了稀疏映射的保真度和插值的平滑性。L 为 Matting Laplacian 矩阵，用于表达图像颜色空间中像素间的局部相似性，其元素 L_{ij} 被定义为：

$$L_{ij} = \sum_{k|(i,j)\in w_k} (\delta_{ij} - \frac{1}{|w_k|}(1 + (I_i - \mu_k)^T (\Sigma_k + \frac{\varepsilon}{|w_k|}U_3)^{-1}(I_j - \mu_k))) \tag{3-14}$$

其中，U_3 是一个 3×3 的单位矩阵，δ_{ij} 是克罗内克函数。μ_k 和 Σ_k 是窗口 w_k 中颜色的均值和协方差矩阵。ε 是正则化参数，$|w_k|$ 是窗口 w_k 的大小。I_i 和 I_j 是输入图像 I 在像素 i 和 j 处的颜色。直观理解为：若像素 i 与 j 在同一颜色窗口内并具有相似颜色，则 L_{ij} 值较小，说明它们的模糊值在插值时应趋于一致。

公式（3-13）是凸二次型问题，其最优解可通过解线性方程组获得：

$$\hat{M} = (L + \lambda D)^{-1} \lambda DM \tag{3-15}$$

其中，正则化参数 λ 被设置为 0.005。

考虑到边缘位置的模糊度估计在实际图像中可能会受到噪声、纹理重复或局部反射的影响，直接使用未经处理的稀疏模糊图 M 进行插值可能会传播误差。因此，插值前需对 M 进行双边滤波[114]，该方法可在保留边缘结构的同时平滑图像响应，从而提升最终完整模糊图 $\hat{M}$ 的准确性与一致性。最终，经双边滤波处理的稀疏模糊图被输入 Matting Laplacian 插值框架，生成完整的全图离焦模糊估计图，为后续的模糊区域定位与图像复原提供高质量先验支持。整个完整离焦模糊图估计过程如算法 3.1 所示。

中国知网 https://www.cnki.net

算法 3.1 离焦模糊图估计

Input：离焦图像 I

Output：完整离焦模糊估计图 $\hat{M}$

01：构造一组边缘点

02：对 I 施加高斯滤波器生成再模糊图像 I_b，并计算其梯度图像 ∇I_b

03：基于公式（3-9）计算基于再模糊奇异值差的模糊度量

04：基于公式（3-11）计算基于 JNB 的感知权重

05：基于公式（3-12）构造一个稀疏离焦模糊图

06：向稀疏离焦模糊图中添加额外的清晰点和模糊点

07：基于公式（3-15）获得完整离焦模糊图

3.3 实验结果与分析

3.3.1 实验设置

本研究在 MATLAB 平台上实现，所有实验均在一台配备 AMD Ryzen 7 3.20 GHz 处理器和 16GB 内存的工作站上完成。在边缘点选取过程中，仅保留对比度较高的显著边缘用于模糊度估计。显著边缘通常更易引起人眼注意，且相较于非显著边缘对噪声不敏感，具有更强的稳定性。根据文献[102]，通过设置对比度阈值 $c_T = 8$ 从公式（3-3）中筛选出显著边缘。对比度值低于阈值的边缘点被视为不稳定区域并予以剔除，而对比度高于阈值的点则被保留用于后续离焦模糊估计。在特征提取阶段，使用 9×9 的块大小，并在再模糊过程中引入高斯核函数，其标准差 σ_0 为关键控制参数。为保证实验的公平性，选取 DUT 数据集[38]中的训练图像对参数 σ_0 进行调优。具体步骤如下：从 DUT 训练集中随机选取 100 张图像，采用受试者工作特征曲线下的面积（Area Under the Curve，AUC）作为性能评价指标。参数 σ_0 的取值范围设置为 0.5 至 2.5，步长为 0.5。AUC 值越接近 1，说明结果与真实标注越接近。不同参数设置下的性能评估结果见表 3.1。

表 3.1 再模糊参数的选择

Table 3.1 Re-blurred parameter selection

σ_0	0.5	1.0	1.5	2	2.5
AUC↑	0.9120	0.9028	**0.9230**	0.9068	0.9097

中国知网 https://www.cnki.net

当σ_0设置为 1.5 时，算法性能达到最佳。为进一步优化基于 RESVD 的稀疏模糊图，需要准确确定两个感知权值阈值。该阈值通过大量统计实验确定。具体而言，基于上述 100 张图像，探索感知权值的范围：τ_{low}在 0.5 到 1.0 之间，τ_{high}在 1.0 到 1.5 之间。AUC 结果如表 3.2 所示，当τ_{low}设置为 0.8，τ_{high}设置为 1.2 时，性能表现最佳。最后，为减少稀疏离焦图中的误差，需要合理选择联合双边滤波的两个尺度参数。一个参数用于控制空间邻域的大小，另一个参数用于控制强度差异的影响。根据文献[31]，两参数分别设为图像大小的 10%和强度范围的 10%。

表 3.2 感知权重参数的选择

Table 3.2 Selection of perception weight parameters

$\tau_{high} \backslash \tau_{low}$	0.5	0.6	0.7	0.8	0.9	1.0
1.0	0.9116	0.9121	0.9125	0.9157	0.9115	0.9088
1.1	0.9123	0.9125	0.9134	0.9159	0.9136	0.9090
1.2	0.9147	0.9163	0.921	**0.9230**	0.9140	0.9092
1.3	0.9132	0.9124	0.9158	0.9199	0.9108	0.9044
1.4	0.9053	0.9114	0.9126	0.9173	0.9060	0.8986
1.5	0.9032	0.9093	0.9137	0.9154	0.9008	0.8926

3.3.2 数据集与评价指标

（1）数据集

为全面评估本章方法在像素级离焦模糊估计任务中的性能，实验选用了三个常用的公开离焦模糊数据集，具体说明如下：CUHK 数据集[33]是目前最常用的模糊图估计数据集，包含 704 张离焦模糊图像。主流深度学习方法通常使用前 604 张图像进行训练，余下 100 张图像作为测试集。为保证与现有深度学习方法的公平比较，本文方法仅在最后 100 张测试图像上进行评估，不涉及训练过程。DUT 数据集[38]包含 600 张训练图像与 500 张测试图像。数据集中存在大量低对比度的聚焦区域以及复杂背景场景，因而具有较高的检测难度。参考现有方法[115,115]，选取该数据集中的 500 张测试图像作为算法性能的评估对象。CTCUG 数据集[37]为近年来提出的高质量像素级离焦标注数据集，共计 150 张图像，所有图像均由人工完成离焦区域的精细标注。该数据集涵盖多个具有挑战性的场景，如低对比度的聚焦区域、前景离焦与背景聚焦的组合关系，以及同类目标在不同离焦状态下的复杂情形，能够更全面地反映算法在实际应用中的适应能力。

中国知网 https://www.cnki.net

（2）评价指标

离焦模糊图的典型应用之一是模糊区域检测，其核心目标在于评估图像中各像素的离焦程度，并据此将图像划分为清晰区域与模糊区域。该过程通常通过对估计得到的模糊图施加简单的阈值分割操作，实现像素级的模糊区域判别。为全面评估不同算法在模糊区域检测中的性能，本章采用三种主流评价指标：准确率-召回率（Precision-Recall，PR）曲线[23,33]、F_β-measure 值[32]以及平均绝对误差（Mean Absolute Error，MAE）。

首先，基于 PR 曲线评估各方法的性能。具体而言，将最终生成的离焦模糊图在[0,255]范围内，以每一个整数为二值化阈值，逐步对图像进行二值化处理，并计算相应的精确率（Precision）与召回率（Recall），据此绘制 PR 曲线。两者的数学定义如下：

$$precision = \frac{R \cap R_g}{R}, recall = \frac{R \cap R_g}{R_g} \tag{3-16}$$

其中，R 表示模糊图经二值化后的预测模糊区域像素集合，R_g 表示参考标注图中的真实模糊区域像素集合。精确率为被正确检测的模糊像素占所有被判定为模糊像素的比例，而召回率表示被正确检测的模糊像素占全部真实模糊像素的比例。

其次，计算 F_β-measure 值，以综合衡量算法在精确率和召回率之间的权衡。为此，需首先将模糊图使用自适应阈值进行二值化，该阈值被设定为模糊图平均灰度值的 1.5 倍。F_β-measure 值是精确率和召回率的加权调和平均值，定义如下：

$$F_\beta = \frac{(1+\beta^2) \times precision \times recall}{\beta^2 \times precision + recall} \tag{3-17}$$

其中，β^2 被设置为 0.3，以强调精度的重要性。F_β-measure 值越大，算法越优。

最后，采用平均绝对误差（Mean Absolute Error，MAE）对模糊图与参考图之间的整体差异进行评估。MAE 衡量的是生成的模糊图 $\hat{M}$ 与真实模糊图 G 之间的平均像素级绝对误差，其定义如下：

$$MAE = \frac{1}{W \times H} \sum_{x=1}^{W} \sum_{y=1}^{H} \left| \hat{M}(x,y) - G(x,y) \right| \tag{3-18}$$

其中，H 和 W 为输入图像的高度和宽度，(x,y) 表示像素坐标。

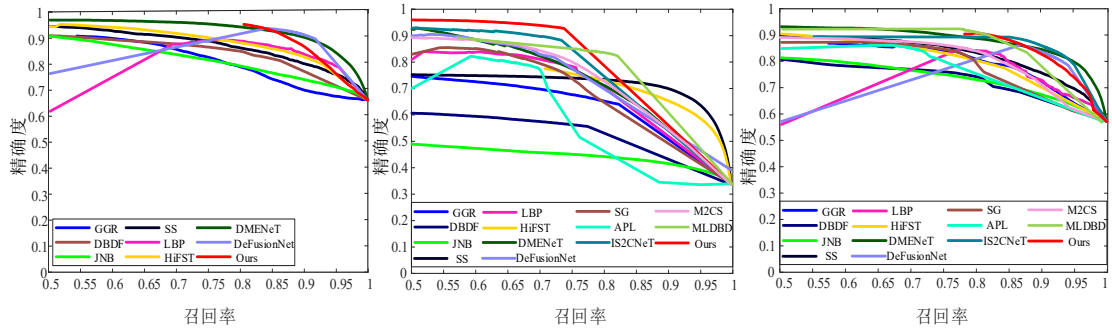
中国知网 https://www.cnki.net

3.3.3 定量与定性实验结果

本章将所提出的方法与 13 种最新的离焦模糊估计算法进行了对比，包括 6 种传统方法和 7 种基于深度学习的方法。传统的离焦模糊估计方法：高斯梯度比（Gaussian Gradient Ratio，GGR）[31]，判别性模糊检测特征（Discriminative Blur Detection Features，DBDF）[33]，最小可察觉离焦模糊估计（Just Noticeable Blur，JNB）[34]，频谱与空间方法（Spectral and Spatial，SS）[116]，局部二值模式（Local Binary Patterns，LBP）[23]，以及高频多尺度融合与梯度幅值排序变换离焦模糊估计（High-frequency Multi-scale Fusion and Sort Transform，HiFST）[26]。基于深度学习的离焦模糊估计方法：基于领域自适应的离焦图估计（DMENet）[39]，空间注意力模块与频率注意力模块的融合网络（DeFusionNet）[37]，自生成离焦模糊检测（SG）[9]，对抗性促进学习（APL）[115]，图像尺度对称协作网络（IS2CNet）[10]，多补丁多尺度对比相似性（M2CS）[40]，以及多层次蒸馏学习（MLDBD）[11]。

（1）定量实验结果分析

本章在三个具有代表性的数据集[33,37,38]上进行了 PR 曲线和定量指标的评估。图 3.9 展示了本章方法与其他方法在 PR 曲线表现。从图中可以观察到，本章方法在 CUHK 和 DUT 数据集上表现优异，曲线整体位于其他方法之上，尤其在低召回率区间展现出显著优势，表明其在边缘模糊区域具有更强的识别能力。这种性能提升主要归因于方法中引入的感知加权机制与边缘点提取策略，有效增强了关键区域的模糊特征表达能力。然而，在 CTCUG 数据集上，本章方法的整体性能略低于 MLDBD[11]和 IS2CNet[10]，主要原因在于该方法侧重于提取图像边缘点的模糊特征，对于结构复杂且含有较多纹理区域的图像存在一定局限。尽管如此，PR 曲线显示本章方法在多数召回率区间内仍保持较高的精确度，说明其在不同模糊模式下具有良好的适应性。未来将结合多尺度上下文和深层语义特征，提取更鲁棒且具备更强泛化能力的模糊特征，以进一步提升复杂场景下的去模糊性能。



(a) CUHK数据集　(b) DUT数据集　(c) CTCUG数据集

图 3.9 不同方法 PR 曲线的比较

Figure 3.9 Comparison of PR curves of different methods

中国知网 https://www.cnki.net

表3.3展示了不同方法在三个数据集[33,37,38]上 F_β -measure值和MAE值的对比结果。在 CUHK 数据集[33]上，本章方法的 F_β -measure 值相较于排名第二的算法提升了 3.3%，在 DUT 数据集[38]上提升了 0.3%。同时，相比于 F_β -measure 次优的 MLDBD[11]，本章方法在 MAE 指标上实现了显著优化，误差降低了 3.8%。虽然在 CTCUG 数据集[37]上，本章方法的 F_β -measure 值和 MAE 值未达到最佳，但在这两项指标间取得了良好的平衡。需要指出的是，SG[9]、APL[115]、IS2CNet[10]、M2CS[40]和 MLDBD[11]方法在 CUHK 数据集[33]上采用了与本章方法不同的测试数据划分方式，因此其性能结果未列入到表 3.3，而是单独归纳于表 3.4。从表 3.4 中可以看出，在相同数据划分的设置下（相同的测试集），本章方法在 F_β -measure 指标上优于 MLDBD[11]（性能提升了 0.1%），并且在 MAE 指标上显著优于 IS2CNet[10]（性能提升了 1.4%）。

表 3.3 不同方法的定量比较

Table 3.3 Quantitative comparison of different methods

方法	CUHK 数据集		DUT 数据集		CTCUG 数据集	
	F_β -measure↑	MAE↓	F_β -measure↑	MAE↓	F_β -measure↑	MAE↓
GGR[31]	0.710	0.294	0.614	0.099	0.680	0.343
DBDF[33]	0.770	0.343	0.489	0.318	0.671	0.360
JNB[34]	0.388	0.355	0.489	0.417	0.415	0.347
SS[116]	0.350	0.266	0.649	0.276	0.441	0.288
LBP[23]	0.850	0.211	0.726	0.192	0.799	0.291
HiFST[26]	0.469	0.238	0.684	0.258	0.596	0.274
DMENeT[39]	0.650	0.344	0.742	0.351	0.623	0.301
DeFusionNet[37]	0.706	**0.109**	0.776	0.139	0.736	**0.132**
SG[9]	-	-	0.701	0.176	0.769	0.612
APL[115]	-	-	0.683	0.197	0.425	0.653
IS2CNeT[10]	-	-	0.795	0.137	0.858	0.336
M2CS[40]	-	-	0.743	0.164	0.742	0.274
MLDBD[11]	-	-	0.799	0.119	**0.860**	0.261
本章方法	**0.883**	0.201	**0.802**	**0.081**	0.843	0.252

中国知网 https://www.cnki.net

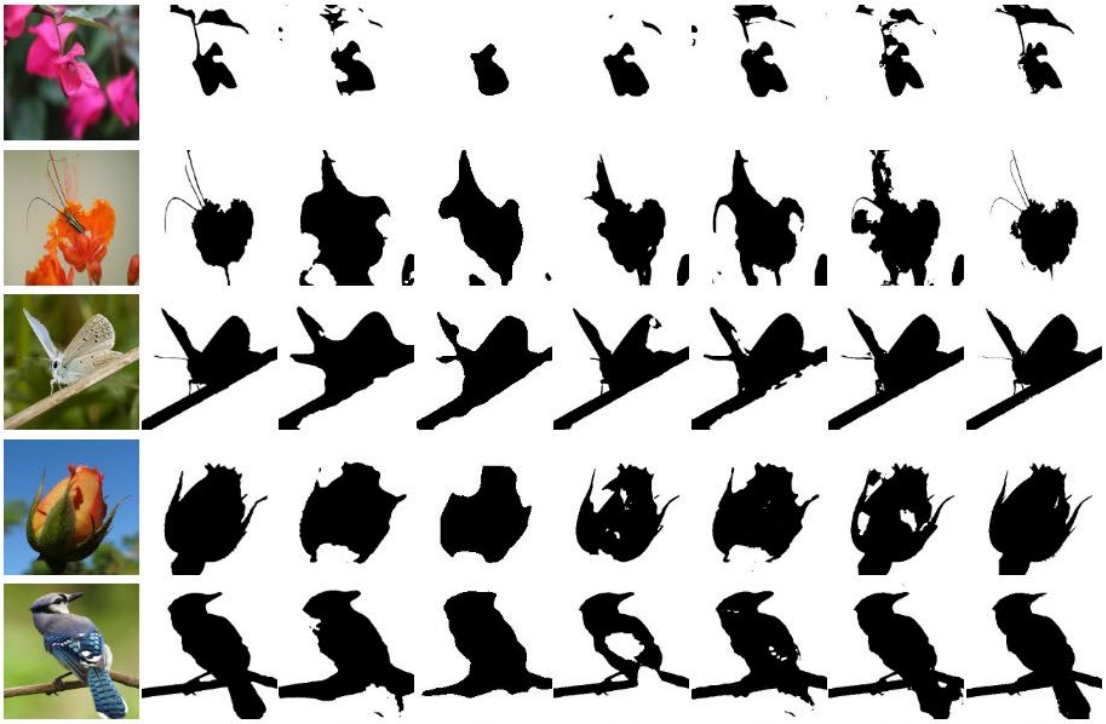
表 3.4 CUHK 数据集在相同数据划分下的定量比较

Table 3.4 Quantitative comparison on the same data-split of the CUHK dataset

方法	SG[9]	APL[115]	IS2CNeT[10]	M2CS[40]	MLDBD[11]	本章方法
F_β -measure↑	0.769	0.816	0.907	0.821	0.906	**0.907**
MAE↓	0.122	0.124	0.062	0.105	0.049	**0.048**

（2）定性实验结果分析

图 3.11 展示了本章方法与其他方法在 CUHK 数据集[33]上的视觉对比结果。为直观地比较各方法效果，使用大津法[117]为每个模糊图生成阈值，以分割出模糊区域与清晰区域。图 3.10 从左到右依次是：（a）输入模糊图像；（b）真实模糊标注图；（c）SG 方法[9]；（d）APL 方法[115]；（e）IS2CNet 方法[10]；（f）M2CS 方法[40]；（g）MLDBD 方法[11]；（h）本章方法。从对比结果可见，本章方法在细节保留方面表现更优，尤其在第二张和第三张样本中，能准确识别动物的触角等细小结构，而 IS2CNet[10]在第二张图像中未能检测出该区域，体现了本章方法在细节感知能力上的显著优势。



(a) (b) (c) (d) (e) (f) (g) (h)

图 3.10 不同方法在 CUHK 数据集上的视觉比较

Figure 3.10 Visual comparison of different methods on the CUHK dataset

中国知网 https://www.cnki.net

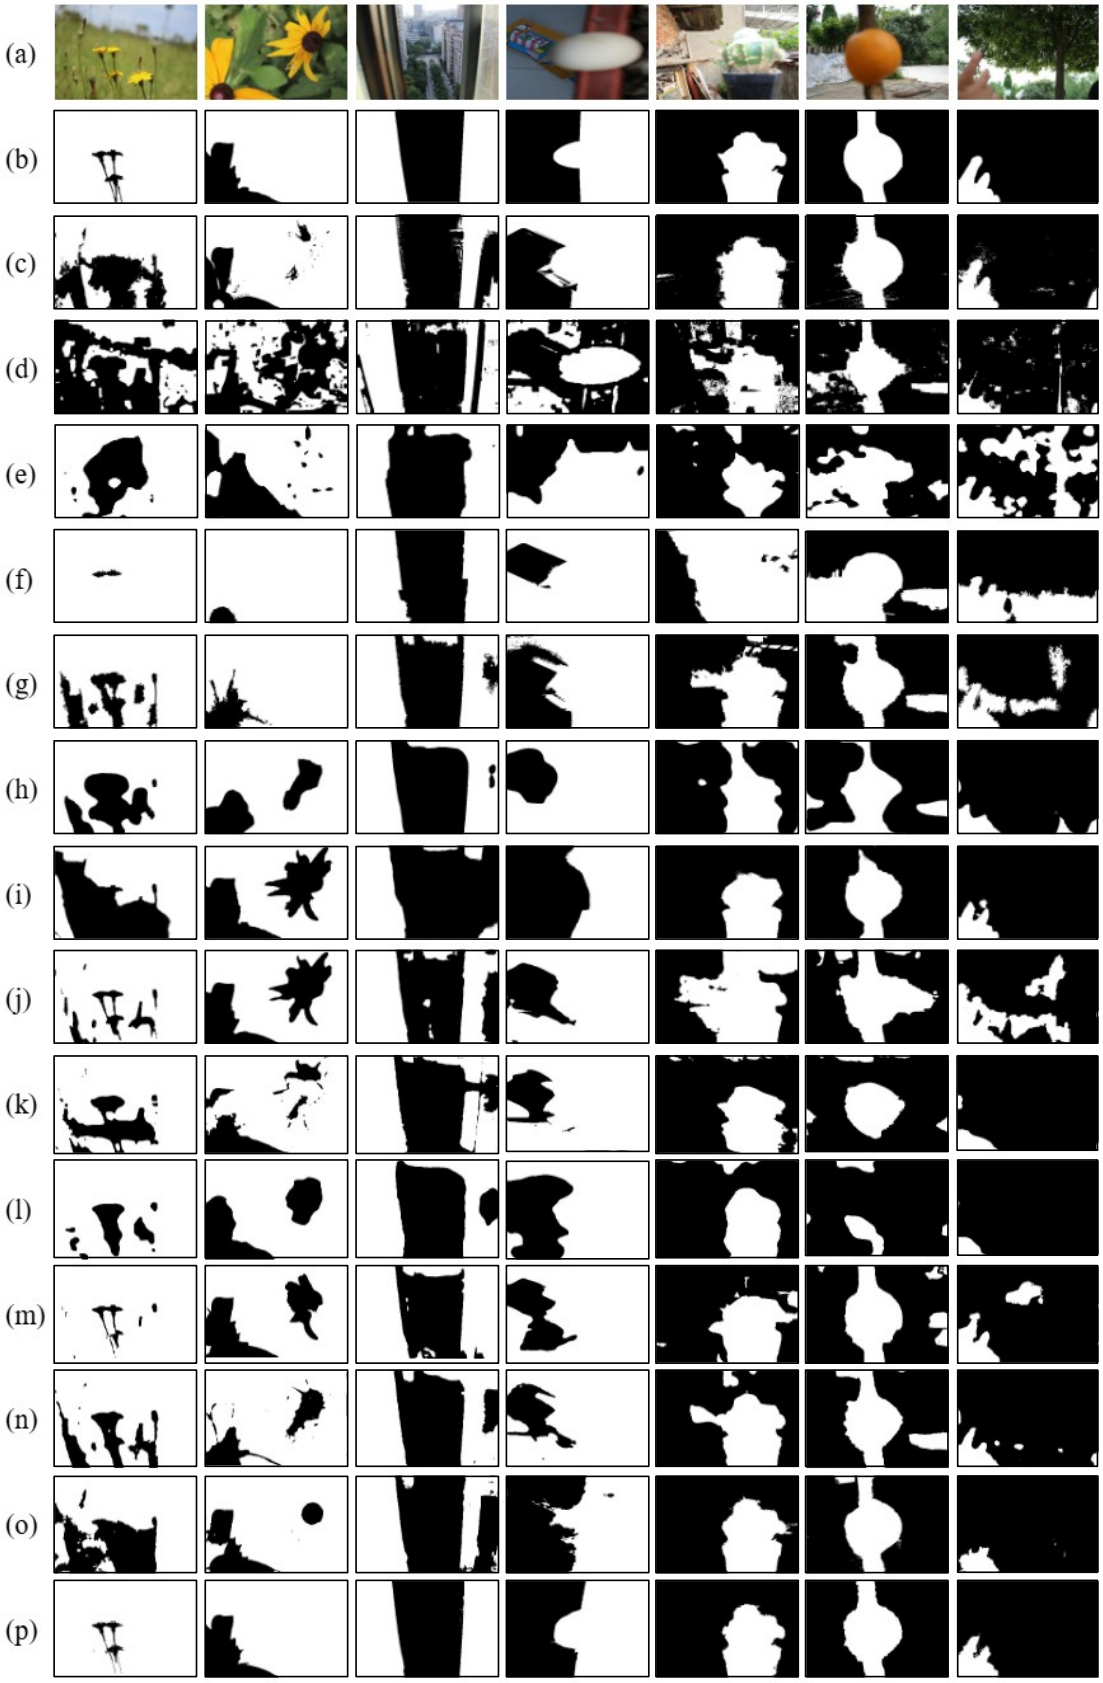


图 3.11 不同方法在 CTCUG 数据集上的视觉比较

Figure 3.11 Visual comparison of different methods on the CTCUG dataset

中国知网 https://www.cnki.net

图 3.11 展示了本章方法与多种方法在 CTCUG 数据集[37]上的视觉对比结果，包括两个前景聚焦样本和五个背景聚焦样本。图 3.11 从上到下依次为：（a）输入的离焦模糊图像；（b）真实模糊标注图；（c）GGR 方法[31]；（d）DBDF 方法[33]；（e）JNB 方法[34]；（f）SS 方法[116]；（g）LBP 方法[23]；（h）HiFST 方法[26]；（i）DMENeT 方法[39]；（j）DeFusionNet 方法[37]；（k）SG 方法[9]；（l）APL 方法[115]；（m）IS2CNet 方法[10]；（n）M2CS 方法[40]；（o）MLDBD 方法[11]；（p）本章方法。结果表明，本章方法生成的结果在视觉上明显优于其他方法。即便背景复杂，本章方法依然能准确检测模糊区域，且在背景简单时，检测结果与真实值高度一致。例如，在第一个复杂背景样本中，本章方法凭借感知权重，有效增强了聚焦与离焦区域的区分度，实现了精准检测；在第四个低对比度样本中，通过引入额外边缘点，有效补全了聚焦区域边界。这些结果进一步验证了感知权重与边缘点相结合策略在提升离焦检测质量方面的有效性。

3.3.4 消融实验

本节首先构建一个仅依赖 RESVD 生成离焦模糊图的基线模型，随后逐步引入感知权重与边缘点，以验证各模块的有效性。

（1）感知权重的有效性

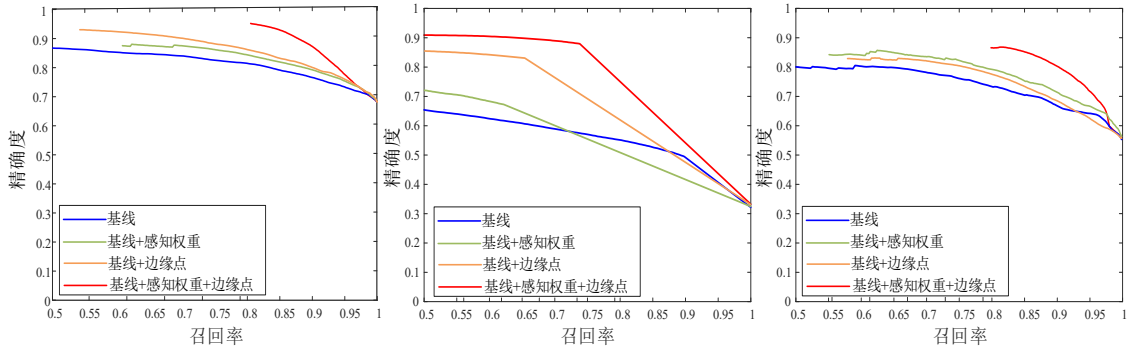
本章方法融合了 HVS 对模糊感知的先验特性。为验证感知权重的有效性，在三个公开数据集[33,37,38]上进行了实验，其结果如表 3.5 和图 3.12 所示。从表 3.5 可知，相较于基线模型，引入感知权重后（即“基线+感知权重”），模型在三个数据集上的 F_β-measure 值平均提升了 3.5%，MAE 值平均下降了 4.5%。此外，图 3.12 展示了对应的 PR 曲线。从可观察到，感知权重有效地修正了基线模型生成的离焦模糊图中的误差，它增强了聚焦与离焦区域之间的特征差异，显著提升了检测精度。

表 3.5 使用不同分量的定量比较

Table 3.5 Quantitative comparison using different components

方法	CUHK 数据集		DUT 数据集		CTCUG 数据集	
	F_β-measure	MAE	F_β-measure	MAE	F_β-measure	MAE
基线	0.742	0.274	0.532	0.197	0.723	0.361
基线+感知权重	0.761	0.251	0.576	0.098	0.765	0.347
基线+边缘点	0.813	0.240	0.709	0.082	0.759	0.290
基线+感知权重+边缘点	**0.883**	**0.201**	**0.802**	**0.081**	**0.843**	**0.252**

中国知网 https://www.cnki.net



(a) CUHK数据集　(b) DUT数据集　(c) CTCUG数据集

图 3.12 不同分量 PR 曲线的比较

Figure 3.12 Comparison of PR curves of different components

（2）添加边缘点的有效性

为验证边缘点添加的有效性，本节在三个公开数据集[33,37,38]上进行了实验。表 3.5 显示了在稀疏离焦模糊图中是否添加边缘点的 F_β-measure 值和 MAE 值的对比。可以看到，添加边缘点的模型（即“基线+边缘点”），在 CUHK 数据集上 F_β-measure 值提升了 7.1%，MAE 下降 3.4%；在 DUT 数据集上 F_β-measure 值提升了 17.7%，MAE 下降 11.5%；在 CTCUG 数据集上 F_β-measure 值提升了 3.6%，MAE 下降 7.1%。总的来说，在以上三个数据集上，F_β-measure 值平均提升 9.4%，MAE 值平均降低 7.3%。

图 3.12 也展示了对应的 PR 曲线。从实验结果可见，添加边缘点的模型（即“基线+边缘点”）在三个数据集上都有明显的精度提升。这一结果主要得益于边缘点增强了图像结构信息的表达，尤其在传统方法难以检测的平滑区域中，边缘点为模糊图的构建提供了关键引导，有效缓解了传播过程中的信息稀疏问题。进一步地，将感知权重与边缘点结合（即“基线+感知权重+边缘点”）后，模型性能获得更大幅度提升。在“基线+感知权重+边缘点”的组合策略下，三个数据集上的 F_β-measure 值平均提升 17.7%，MAE 平均下降 9.9%，明显优于单独添加任一因素的方案。综上所述，感知权重能有效感知弱纹理和低对比度区域，而边缘点细化了边界线索，两者协同作用，显著增强了模糊图的估计精度。

图 3.13 进一步展示了不同设置下的视觉效果。从左至右依次为：（a）输入模糊图像；（b）真实模糊标注图；（c）基线模型结果；（d）基线+感知权重；（e）基线+边缘点；（f）基线+感知权重+边缘点。从实验结果可见，方案（f）在边界清晰度、结构完整性和模糊区域过渡方面均表现最佳，生成的结果最接近真实标注图。

中国知网 https://www.cnki.net



(a) (b) (c) (d) (e) (f)

图 3.13 不同分量有效性的视觉比较

Figure 3.13 Visual comparison of the effectiveness of different components

3.3.5 离焦去模糊

离焦图像去模糊是离焦模糊图估计的典型应用场景之一。在实际成像过程中，由于景深受限或对焦偏差，图像中常常存在显著的空间变化的模糊区域。此类模糊通常具有强烈的空间非均匀性，因此，准确估计离焦模糊图对于实现高质量的图像去模糊具有重要意义。

在非盲反卷积框架中，模糊图可视为描述空间变化高斯模糊核的参数，其估计质量直接影响最终复原图像的清晰度。为验证所提出模糊图估计方法在去模糊任务中的有效性，本节采用经典的非盲反卷积模型[57]对模糊图像进行复原。其优化模型形式如下：

$$\hat{I} = \arg\min_{I} \psi_{\text{data}}(I) + \lambda \psi_{\text{reg}}(I) \tag{3-19}$$

其中，$\hat{I}$ 表示最终估计得到的清晰图像，$\psi_{\text{data}}(I)$ 是数据保真项，用于保证去模糊图像与观测模糊图像之间的一致性；$\psi_{\text{reg}}(I)$ 是正则化项，用于引入图像先验以约束解空间。λ 为权重参数，用于控制数据保真项和正则化项之间的平衡，在实验中，设定 $\lambda = 0.002$ 。

中国知网 https://www.cnki.net

公式（3-19）中的数据保真项定义为：

$$\psi_{\text{data}}(I) = \| I \otimes k - B \|_2^2 \tag{3-20}$$

其中，k 表示表示空间变化的高斯模糊核，通过离焦模糊图的数值确定；B 是输入的离焦模糊图像，$\otimes$ 表示卷积操作。该项保证了去模糊图像在模糊核作用下能够尽量逼近原始图像。

公式（3-19）中的正则项采用稀疏导数建模，表示为：

$$\psi_{\text{reg}}(I) = \| f_1 \otimes I \|_\alpha + \| f_2 \otimes I \|_\alpha \tag{3-21}$$

其中，f_1 和 f_2 分别表示图像在水平方向和垂直方向上的一阶微分算子，$\|\cdot\|_\alpha$ 表示 α 范数（在本章研究过程中，设定 $\alpha = 0.8$），该范数基于超拉普拉斯先验（Hyper-Laplacian Prior）模型，能够有效地保留图像边缘结构，同时抑制去模糊结果中噪声和伪影的出现。

（1）定量实验结果分析

为从客观和量化的角度评估不同离焦模糊图估计算法在离焦去模糊任务中的性能表现，本节选取 RTF 数据集[118]中的 22 张具有真实离焦模糊特征的图像作为测试样本，分别采用 Zhuo 等人[31]，D'Andrès 等人[118]，Karaali 等人[13]以及本章所提出的离焦模糊图估计方法进行离焦去模糊处理。为确保对比的客观性与一致性，所有方法均在上述非盲反卷积框架上运行，并以峰值信噪比（Peak Signal-to-Noise Ratio，PSNR）与结构相似度（Structural Similarity，SSIM）两项指标作为评估标准。

实验结果如表 3.6 所示，本章提出的离焦模糊图估计算法在离焦去模糊结果中显著优于其他三种对比方法。与原始模糊图像相比，使用本章方法得到的复原结果在 PSNR 和 SSIM 指标上显著提升，验证了所估计模糊图在非盲去模糊任务中的有效性。虽然部分对比方法在个别图像样本上实现了一定程度的性能改善，但整体提升幅度有限，且在空间模糊变化剧烈的区域，部分方法甚至出现复原质量下降的情况，反映出其在处理空间非均匀模糊方面的局限性。

此外，实验结果还表明，即便直接使用真实离焦模糊图作为先验信息，若所采用的去模糊算法未能有效结合该先验或缺乏足够的适应性，其复原效果依然难以达到理想水平。例如，使用真实模糊图的去模糊结果仅获得 25.13dB 的 PSNR 和 0.810 的 SSIM，整体表现仍不具备优势。

中国知网 https://www.cnki.net

表 3.6 使用不同离焦模糊图的去模糊结果的定量比较

Table 3.6 Quantitative comparison of deblurring results using different defocus blur maps

序号	模糊图	真实离焦图	Zhuo[31]	D'Andrès[31]	Karaali[13]	本章方法
1	25.51/0.810	26.48/0.826	24.90/0.791	26.25/0.816	26.07/0.814	**26.39/0.845**
2	24.54/0.692	25.19/0.707	24.18/0.675	24.90/0.696	24.89/0.691	**24.91/0.729**
3	23.74/0.868	25.23/0.891	23.60/0.867	24.76/0.885	24.21/0.877	**25.28/0.914**
4	23.58/0.734	25.98/0.791	24.87/0.762	25.56/0.785	25.64/0.790	**25.74/0.833**
5	26.50/0.895	28.32/0.906	25.17/0.871	27.83/0.901	**26.81**/0.894	26.56/**0.910**
6	24.05/0.827	25.06/0.852	21.47/0.814	23.87/0.843	24.66/0.852	**25.34/0.879**
7	27.09/0.852	28.59/0.886	26.02/0.854	28.28/0.880	**27.49**/0.880	27.17/**0.885**
8	23.47/0.754	24.48/0.790	23.95/0.769	24.40/0.787	23.92/0.767	**24.16/0.786**
9	22.56/0.750	23.35/0.790	21.94/0.723	23.26/0.785	22.70/0.758	**23.68/0.821**
10	23.97/0.754	25.13/0.801	24.09/0.768	24.93/0.792	**24.87**/0.790	24.51/**0.795**
11	23.47/0.671	24.04/0.707	23.37/0.667	23.87/0.703	23.81/0.698	**23.90/0.724**
12	23.73/0.742	24.49/0.773	23.70/0.738	24.36/0.766	23.96/0.750	**24.49/0.786**
13	28.09/0.875	28.41/0.887	24.95/0.843	28.13/0.884	**28.40/0.889**	28.28/**0.899**
14	24.75/0.849	25.17/0.863	24.52/0.843	25.47/0.866	**25.19**/0.860	24.45/**0.852**
15	20.43/0.602	21.17/0.653	19.84/0.575	21.08/0.646	20.48/0.602	**20.88/0.651**
16	23.87/0.795	25.14/0.830	24.16/0.805	25.01/0.825	24.60/0.811	**24.68/0.843**
17	24.33/0.598	24.10/0.619	22.40/0.566	22.69/0.597	23.75/0.587	**25.32/0.733**
18	22.71/0.755	23.73/0.787	22.74/0.746	23.53/0.778	23.17/0.760	**23.30/0.814**
19	24.31/0.868	25.47/0.895	24.11/0.866	25.11/0.891	24.61/0.879	**24.62/0.880**
20	22.23/0.704	22.63/0.738	21.46/0.696	21.92/0.720	22.38/0.722	**22.45/0.751**
21	25.63/0.925	26.47/0.936	25.26/0.920	26.08/0.932	26.23/0.933	**26.78/0.940**
22	23.91/0.893	24.24/0.899	23.24/0.880	24.06/0.897	23.95/0.892	**23.99/0.894**
平均值	24.20/0.782	25.13/0.810	23.63/0.774	24.79/0.803	24.63/0.795	**24.85/0.825**

（2）定性实验结果分析

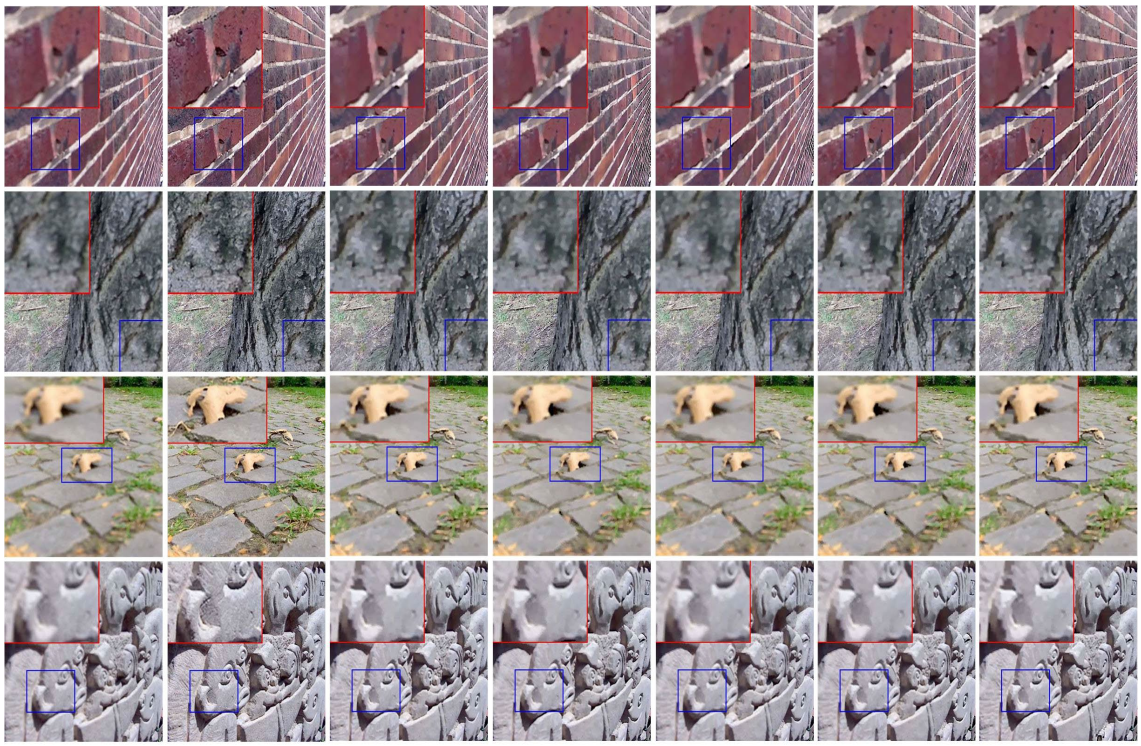
为进一步验证本章方法在离焦去模糊任务中的实际有效性，本节从 RTF 数据集[118]中选取 4 张具有代表性的图像样本，对不同算法的复原效果进行定性可视化

中国知网 https://www.cnki.net

比较。实验结果如图 3.14 所示。

图 3.14 从左到右依次为：（a）输入的离焦模糊图像；（b）对应的清晰图像；（c）基于真实离焦模糊图的去模糊结果；（d）Zhuo 等人[31]方法；（e）D'Andrès 等人[118]方法；（f）Karaali 等人[13]方法；（g）本章方法。从主观视觉评价角度来看，本章方法在图像细节还原、边缘锐化以及纹理重建方面均明显优于现有主流方法。无论图像背景结构的复杂程度如何，所提算法均表现出更高的复原稳定性，生成结果更加自然，整体观感更接近参考清晰图像。

为更直观地展示各方法在细节恢复方面的表现，图中通过蓝色边框标注关键区域，并采用红色边框对典型局部进行放大，便于视觉对比分析。具体包括以下四处关键区域：第一处为墙面纹理区域，Zhuo 和 Karaali 方法在纹理复原上存在模糊与缺失，而本章方法能够清晰还原墙体细节；第二处与第三处关注树干与小狗区域，该部分结构复杂、边缘变化丰富，其他方法在小狗毛发和树干边缘仍存在模糊与伪影，而本章方法恢复出的轮廓清晰、纹理自然；最后一处为石壁表面，该区域细节密集、纹理复杂，本章方法在凹凸结构与材质还原上表现更佳，视觉对比度与真实感更强。



(a) (b) (c) (d) (e) (f) (g)

图 3.14 不同离焦模糊图的去模糊结果比较

Figure 3.14 Comparison of deblurring results using different defocus blur maps

中国知网 https://www.cnki.net

3.4 本章小结

本章提出了一种基于感知先验引导的离焦模糊图估计方法，实现了图像中边缘模糊程度的精确估计。为解决低对比度区域模糊估计困难的问题，本章引入了JNB 感知模型，并提出了一种基于感知权重调制的模糊度量算子。该算子能够综合考虑人眼对模糊变化的感知特性与图像局部结构变化，构建出准确的稀疏离焦模糊图。为控制边缘信息在完整图中的传播，本章进一步引入边缘点约束机制，并融合双边滤波与 Matting Laplacian 传播策略，实现了从稀疏模糊图向完整图的合理扩展，最终实现完整的像素级离焦模糊图估计。

在实验评估方面，本章方法在模糊图估计精度上显著优于 13 种当前主流方法。具体而言，在 DUT 数据集上，本章方法取得了最高的 F_β-measure 值（0.802）和最低的 MAE 值（0.081），明显优于其他方法（F_β-measure≤0.799，MAE≥0.099）；在 CUHK 和 CTCUG 数据集上，本章方法亦表现出良好的稳定性，在 F_β-measure 与 MAE 两项指标之间达成了更优的平衡。

此外，为验证本章估计的离焦模糊图在实际应用中的有效性，本文将其应用于离焦图像去模糊任务。在 RTF 数据集上的实验结果表明，本章方法在 PSNR 和 SSIM 等图像质量评价指标上均显著优于现有去模糊算法。视觉分析结果亦显示，所提方法能够更有效地保留图像细节与结构轮廓，复原效果更接近真实清晰图像。然而，离焦模糊在真实场景中通常呈现高度非均匀性与复杂的模糊模式，单一估计方法或简化建模难以充分应对。因此，下一章将进一步探讨面向真实复杂场景的离焦图像去模糊算法，以提升方法在实际应用中的鲁棒性与实用性。

中国知网 https://www.cnki.net

第 4 章 基于大模型先验的离焦去模糊方法

4.1 引言

上一章提出了一种基于离焦模糊图估计的离焦去模糊方法，虽然在一定程度上提升了图像复原质量，但其性能高度依赖于模糊图的准确性。同时，该方法采用简化的高斯模糊核作为退化模型，难以真实刻画复杂多变的离焦模糊过程。即使在输入中引入真实离焦模糊图作为先验，也难以获得理想的复原效果。因此，离焦去模糊不仅需要准确估计图像的模糊区域，更需要整合深层语义理解与场景深度感知，以有效引导图像的结构恢复与细节复原。

为克服传统方法在先验利用和特征引导方面的局限性，本章提出一种大模型先验引导的离焦去模糊框架。该方法充分挖掘在大规模图像数据集上预训练的大模型在语义理解与深度感知方面的强大能力，通过多模态引导与深度融合，提升去模糊性能。具体而言，本章设计了多模态输入机制，并构建了两个关键模块：图像保真度特征提取器和模糊自适应提示提取器。图像保真度特征提取器基于 DepthAnything 模型[105]实现结构对齐与深度保真；模糊自适应提示提取器则基于通用识别模型（Recognize Anything Model，RAM）[119]提取图像语义提示，强化内容一致性。上述多模态特征在多模态融合模块中集成，并通过多模态交叉注意力机制引导预训练的稳定扩散模型生成高保真图像。虽然扩散模型在细节生成上表现出色，但在失真指标（如 PSNR、SSIM）方面仍有提升空间。为进一步增强像素级保真度与结构一致性，本章进一步引入深度先验融合模块，基于深度信息生成自适应离焦权重图，对初步复原结果进行细化优化。最终，通过加权拉普拉斯金字塔融合实现优化图像与原始清晰区域的无缝集成，确保复原图像在结构与纹理层面均具备自然过渡与真实感。实验表明，本章方法在多个数据集上实现优异的视觉质量与定量性能表现，为离焦去模糊任务树立了新的性能基准。

本章的主要贡献总结如下：

（1）提出一种融合多模态引导扩散与深度感知融合的两阶段离焦去模糊框架，兼顾感知质量与失真指标；

（2）设计多模态先验提取机制，联合结构特征与语义特征，并通过交叉注意力机制引导扩散过程，有效缓解扩散模型中的结构失真与语义错位问题；

（3）构建深度先验融合网络，生成深度自适应离焦权重图，结合加权拉普拉斯金字塔融合，实现清晰区域与优化结果的自然融合，保证了像素级的一致性，提高了整体恢复质量。

中国知网 https://www.cnki.net

4.2 多模态引导与深度先验融合的离焦去模糊算法

本章提出了一种融合多模态先验与深度信息的离焦去模糊算法，整体分为两个阶段：第一阶段构建多模态引导的稳定扩散模型，融合结构和语义先验，引导扩散模型生成细节丰富、高保真的初步清晰图像；第二阶段引入深度先验融合模块，利用深度先验生成离焦权重图，自适应融合初步结果与原始模糊图像，进一步提升局部清晰度与全局一致性。图 4.1 展示了本章方法的整体框架。

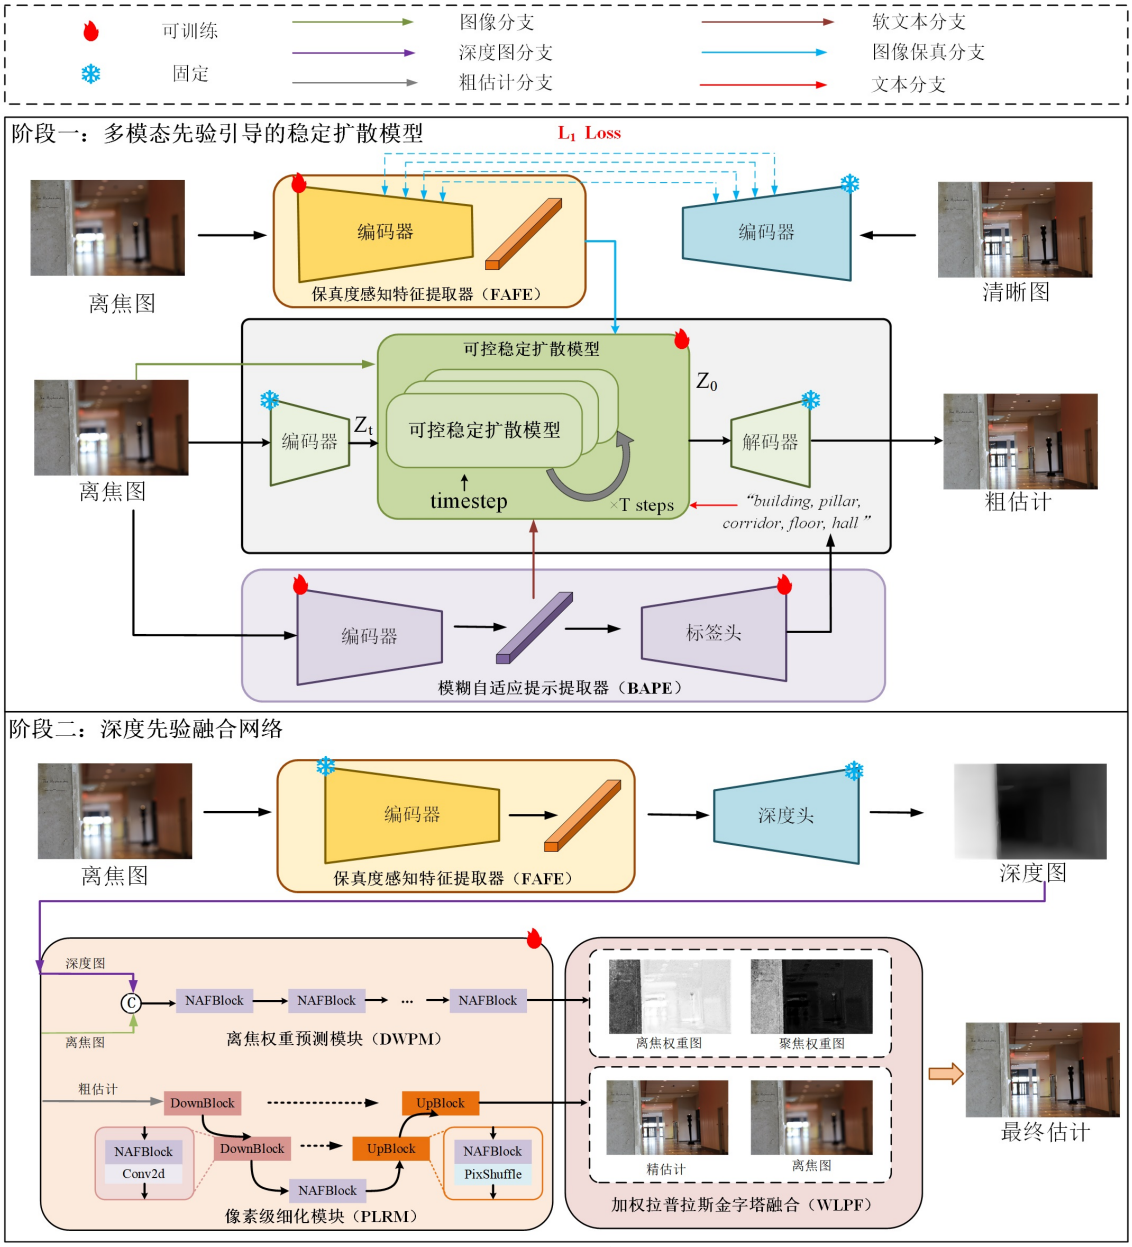


图 4.1 两阶段离焦去模糊框架示意图

Figure 4.1 Schematic diagram of the two-stage defocus deblurring framework

中国知网 https://www.cnki.net

4.2.1 多模态先验引导的稳定扩散模型

在第一阶段，本章设计了一种多模态引导的稳定扩散模型，用于生成具有高质量细节的去模糊图像。如图 4.2 所示，采用 ControlNet[51]作为条件图像生成的主干网络。具体而言，从预训练的稳定扩散模型中克隆 U-Net 编码器，用于初始化 ControlNet 的可训练副本。为了将多模态特征（如图像结构线索和文本语义线索）引入扩散模型，本章在 Transformer 2D 模块之后集成了多模态交叉注意力（Multimodal Cross-Attention，MCA）模块[52]。这些 MCA 模块与 U-Net 编码器一同克隆，为扩散模型提供多模态引导。此外，图像和文本分支在生成清晰输出方面起到了至关重要的作用[53]。模糊图像通过一个可训练的图像编码器进行处理，获取潜在表示；而文本则通过一个冻结的文本编码器（CLIP）进行编码，为稳定扩散模型提供语义引导。

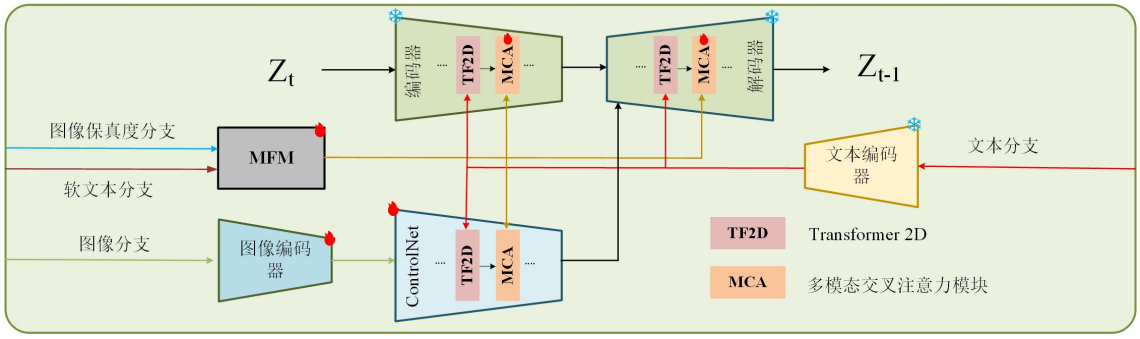


图 4.2 可控稳定扩散模型架构示意图

Figure 4.2 Architecture diagram of the controlled stable diffusion model

接下来，本节将详细介绍所提出的多模态表示的三大核心组件：模糊自适应提示提取器（Blur-Adaptive Prompt Extractor，BAPE）、图像保真度特征提取器（Fidelity-Aware Feature Extractor，FAFE）和多模态融合模块（Multimodal Fusion Module，MFM）。

（1）BAPE

为了在利用预训练稳定扩散模型的强大生成能力的同时减少离焦模糊带来的语义失真，本章使用标签风格提示（Tag-Style Prompts）来为图像中的对象提供结构化类别信息。相较于标题风格提示（Caption-Style Prompts），标签风格提示能够提供更系统、更全面的语义覆盖，使得稳定扩散模型能够利用其内在的语义分割能力[53]，更有效地将语义线索与图像区域对齐。

然而，现有的基于标签的提示提取方法在处理图像退化问题时表现不佳，

中国知网 https://www.cnki.net

常表现为语义线索提取不准确，并在复原图像中引入失真。为了解决这个问题，Wu 等人[53]提出了退化感知提示提取器（Degradation-Aware Prompt Extractor，DAPE），通过微调 RAM[119]以适配超分辨率任务。然而，DAPE 不适合处理离焦图像中的语义提取问题。为此，本节设计了 BAPE 模块，专用于从离焦模糊图像中稳健提取标签风格提示，以提升稳定扩散模型的语义引导能力。BAPE 继承了 DAPE 相同的损失函数和训练策略，但在 RAM 上针对离焦图像进行了重新微调，使其更适用于离焦语义提取任务。提取的提示包括两种类型：1）硬提示（Hard Prompts）：从标签头输出的文本标签，输入至冻结的文本编码器中，增强局部语义理解；2）软提示（Soft Prompts）：从图像编码器提取连续的表示嵌入（Representation Embeddings），保留连续特征表示，以增强对图像内容的细腻解释。图 4.3 展示了不同提示提取方法获取的标签提示及其对应的去模糊结果对比。其中，（a）为输入的离焦图像，（b）-（d）分别为基于 RAM[119]、DAPE[53]与本章的 BAPE 提取的标签提示及其对应的去模糊结果，（e）为人工标注的真实标签提示和清晰图像。结果表明，RAM[119]和 DAPE[53]在处理离焦图像时难以提取准确语义信息，复原的图像中存在明显失真；而 BAPE 能提供更稳定准确的语义引导，显著提升了去模糊质量。



(a) (b) (c) (d) (e)

图 4.3 不同方法获取的标签提示及其对应的去模糊结果对比

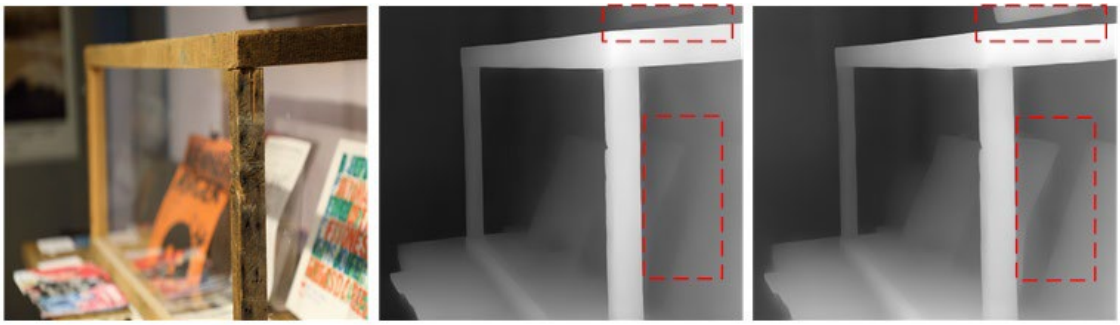
Figure 4.3 Comparison of tag prompts obtained by different methods and their corresponding deblurring results

（2）FAFE

离焦模糊图像通常呈现出复杂且空间变化明显的退化特性，导致结构细节模糊不清，影响图像的真实还原。针对这一问题，本节提出 FAFE，旨在从模糊图像中提取更接近清晰图像的结构特征，为后续稳定扩散去模糊过程提供精确的结构引导，从而提升图像的结构保真度。如图 4.1 所示，FAFE 基于 DepthAnything 模型[105]的编码器构建，通过对模糊图像与清晰图像在多层级特征空间的对齐，促使模型在各尺度上获得更接近清晰图像的表达能力，有助于扩散模型更好地还原图像中的真实细节。同时，DepthAnything 模型中的深度预测头能够直接从离焦模

中国知网 https://www.cnki.net

糊图像中估计深度图。如图 4.4 所示，（a）为离焦输入图像，（b）为引入保真度对齐的 DepthAnything 模型输出，（c）为未引入保真度对齐的 DepthAnything 模型输出。实验结果表明，引入保真度对齐后，模型估计的深度图结构更加清晰、层次更加分明，充分验证了 FAFE 在深度信息及结构特征提取方面的有效性。



(a) (b) (c)

图 4.4 DepthAnything 模型生成深度图的可视化效果

Figure 4.4 Visualization of depth maps generated by the DepthAnything model

保真度对齐过程如下：首先，将清晰图像输入一个冻结的 DINOv2 模型[120]，提取其输出的表示嵌入；同时，离焦模糊图像输入一个基于 DINOv2[120]初始化的可训练图像编码器。为了保证两者在多尺度特征上的一致性，分别在对应尺度的中间特征层施加对齐约束。具体地，设清晰图像和模糊图像在尺度 s 的中间特征分别为 $\mathbf{F}_{clear}^{s}$ 和 $\mathbf{F}_{blur}^{s}$，定义 L_1 损失函数为：

$$\mathcal{L}_{FAFE} = \sum_{s} || \mathbf{F}_{clear}^{s} - \mathbf{F}_{blur}^{s} ||_1, \tag{4-1}$$

在训练过程中，仅对可训练编码器的最后四个块进行参数更新，其他层保持冻结状态，以保证稳定的特征对齐效果。

（3）MFM

为在扩散生成过程中兼顾结构保真度与语义引导效果，本节提出了 MFM，该模块将来自 FAFE 的图像保真度嵌入和来自 BAPE 的软文本嵌入融合为统一的多模态输入。图 4.5 展示了 MFM 的整体结构。具体而言，MFM 采用一系列交叉注意力模块（Cross-Attention Module，CAM）、自注意力模块（Self-Attention Module，SAM）以及前馈神经网络（Feed-Forward Network，FFN）来处理并融合多模态特征，生成融合结构与语义的表征，作为中间条件信号引导扩散模型的去噪过程，从而在结构保真度和语义一致性方面显著提升图像复原质量。

中国知网 https://www.cnki.net

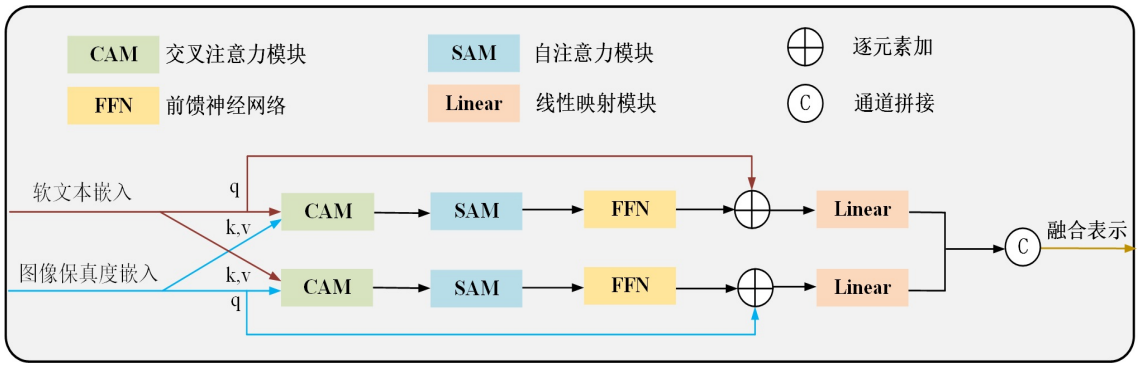


图 4.5 多模态融合模块示意图

Figure 4.5 Illustration of multimodal fusion module

首先，CAM 用于实现图像保真度嵌入与软文本嵌入之间的信息交互。设图像保真度嵌入的查询、键和值矩阵分别为Q_i，K_i，V_i，软文本嵌入的查询、键和值矩阵分别为Q_t，K_t，V_t，则交叉注意力生成的信息表示可表示为：

$$\begin{aligned} e^{i}_{\text{cross}} &= \text{softmax}(\frac{Q_i K_t^T}{\sqrt{d}})V_t \\ e^{t}_{\text{cross}} &= \text{softmax}(\frac{Q_t K_i^T}{\sqrt{d}})V_i \end{aligned} \tag{4-2}$$

其中，d 表示缩放因子；e^{i}_{cross} 表示在图像查询引导下生成的基于文本的信息表示；e^{t}_{cross} 表示在文本查询引导下生成的基于图像的信息表示。

在交叉注意力之后，每个表示嵌入都会经过 SAM 以确保内部一致性，其计算方式如下

$$\begin{aligned} e^{i}_{\text{self}} &= \text{softmax}(\frac{Q_i K_i^T}{\sqrt{d}})V_i \\ e^{t}_{\text{self}} &= \text{softmax}(\frac{Q_t K_t^T}{\sqrt{d}})V_t \end{aligned} \tag{4-3}$$

接着，生成的输出由 FFN 进一步处理，以增强特征表达能力。随后，这些输出与初始输入进行逐元素相加，并通过线性层处理，以满足后续扩散模型模块的输入兼容性。MFM 所生成的融合表示有效整合了几何结构信息与语义上下文信息，为稳定扩散模型提供了强健的条件控制，从而显著增强去模糊过程的质量与稳定性。

中国知网 https://www.cnki.net

（4）损失函数

在模型训练阶段，为实现对模糊图像的高质量复原，本文采用了基于稳定扩散模型的条件噪声预测策略。具体而言，首先对清晰图像 x_0 提取其潜在表示 s_0，并在此基础上逐步添加高斯噪声以生成一个带噪声的潜在表示 s_t，其中 t 表示随机采样的扩散步长。在给定扩散步长 t、模糊输入 B 和多模态融合条件特征 c（由 MFM 输出）作为条件的前提下，训练一个神经网络 ϵ_θ 来预测添加到潜在表示 s_t 上的噪声 ϵ。该过程的优化目标可表示为：

$$\mathcal{L}_{SD} = \mathbb{E}_{s_0,t,c,\epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[\| \epsilon - \epsilon_\theta(s_t,t,c,B) \|_2^2\right] \tag{4-4}$$

为进一步提升结构保真度，引入了来自 FAFE 模块的结构特征作为辅助监督信号，在训练过程中与主干网络进行协同优化。最终的总损失为 $\mathcal{L} = \mathcal{L}_{SD} + \gamma\mathcal{L}_{FAFE}$，其中 γ 是一个平衡参数，在实验中设置为 1。需要指出的是，为保持稳定扩散模型生成能力的泛化性，本文对原始预训练稳定扩散模型的参数保持完全冻结，仅对新引入的模块进行训练与更新，包括：FAFE，BAPE，MFM，ControlNet 和 U-Net 中的 MCA 模块。

4.2.2 深度先验融合网络

尽管 4.2.1 节提出的稳定扩散去模糊模型在细节生成方面展现出显著的优势，但该类生成模型仍存在空间不一致性与伪细节的问题，可能影响去模糊图像的真实性。为缓解这个问题，本节进一步提出一种深度先验融合网络，以充分挖掘深度信息的空间引导能力，从而提升图像的真实感与局部清晰度。该网络基于深度图生成空间权重图，有效区分图像中的清晰区域与模糊区域，并通过细化与加权融合实现对初步去模糊结果的修正与增强。正如图 4.1 所示，该方法包含三个关键模块：离焦权重预测模块（Defocus Weight Prediction Module，DWPM）、像素级细化模块（Pixel-Level Refinement Module，PLRM）和加权拉普拉斯金字塔融合（Weighted Laplacian Pyramid Fusion，WLPF）模块。本节将对上述各模块的设计思想与实现细节进行逐一阐述。

（1）DWPM

为实现初步结果与原始图像的有效融合，DWPM 设计了一种基于图像内容与深度信息的空间权重预测机制。考虑到离焦模糊具有显著的空间非均匀性，并与场景深度密切相关，DWPM 首先采用 DepthAnything 模型估计模糊图像的深度图，作为全局结构的先验信息。随后，引入五个轻量级的 NAFBlocks[121]，用于融合深

中国知网 https://www.cnki.net

度特征与模糊图像的信息，从而增强两者之间的语义对齐与特征互补。最终，DWPM 生成两张权重图：聚焦权重图（W）和离焦权重图（$1-W$），并统一归一化至[0,1]区间。其中，较高的数值表示对应区域更加清晰，较低的数值则表示模糊程度更高。图 4.6 展示了本章方法的中间结果。其中，（a）为输入的离焦图像；（b）为参考的清晰图像；（c）为第一阶段输出的粗估计结果；（d）为第二阶段 PLRM 输出的精估计结果；（e）为第一阶段微调后的 DepthAnything 模型输出的深度图；（f）为 DWPM 生成的聚焦权重图，能够有效刻画图像中每一个像素的清晰程度；（g）为权重图对应的热图；（h）为本章方法最终的输出结果。

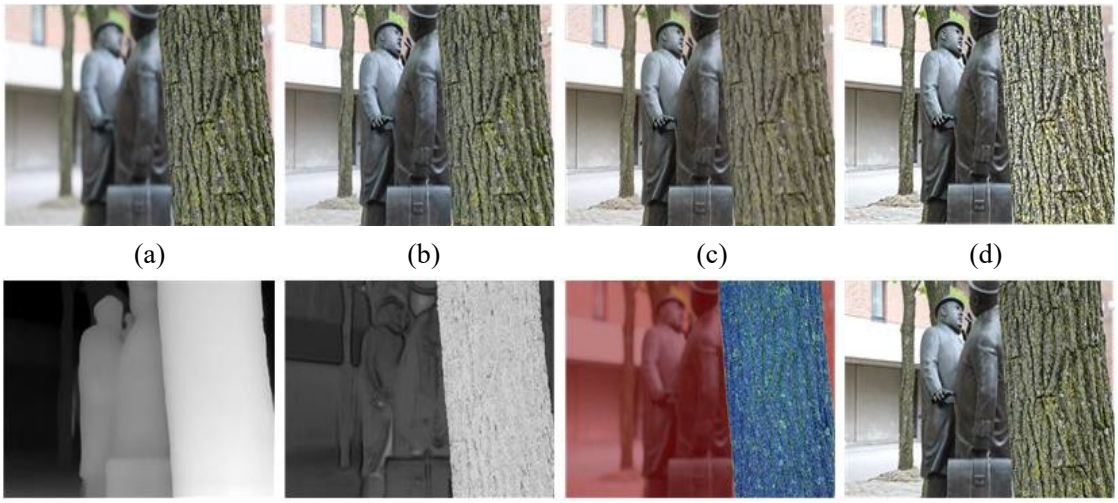


图 4.6 所提方法中间结果的可视化

Figure 4.6 Visualization of intermediate results in the proposed method

（2）PLRM

尽管第一阶段的稳定扩散模型已能生成初步清晰的图像，但由于其训练目标主要集中于噪声建模与语义生成，其输出结果在纹理一致性、结构连续性等方面仍存在一定不足。如图 4.6（c）所示，在离焦区域中可能出现伪边缘、错位结构或过度锐化等现象。为此，本节引入了 PLRM，在初步去模糊结果的基础上进一步提升图像的结构准确性与纹理质量。该模块基于图像恢复任务中表现突出的 NAFNet[121]结构进行构建。PLRM 主要针对第一阶段输出的粗恢复结果进行细粒度修正。然而，如图 4.6（d）所示，简单地对所有区域进行统一的像素级增强可能会导致焦内区域过度锐化而导致颜色失真，缺乏自然过渡感。考虑到离焦模糊在图像中具有明显的区域特异性，本章采用 DWPM 生成的离焦权重图作为引导，动态调整增强力度，实现对焦外区域的重点修复与对焦内区域的轻度干预，从而在提升整体清晰度的同时保持图像的自然感与真实感。

中国知网 https://www.cnki.net

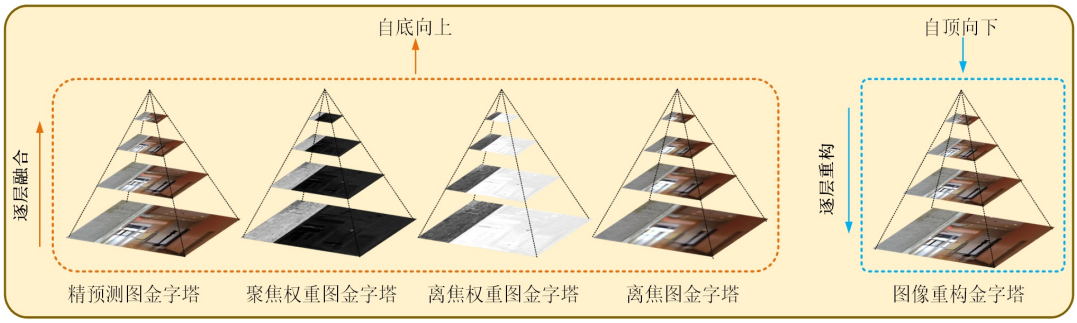


图 4.7 加权拉普拉斯金字塔融合示意图

Figure 4.7 Illustration of weighted Laplacian pyramid fusion

（3）WLPF

为进一步提升图像的局部细节一致性与全局结构连续性，本节设计了 WLPF 模块。如图 4.7 所示，该模块以深度感知的权重图为引导，对精细预测结果与原始输入图像在多个尺度上进行分解与融合，从而实现细节增强与边缘平滑的有效平衡，最终复原出高质量的清晰图像。

具体来说，WLPF 首先分别为原始离焦图像、PLRM 生成的精细预测图像以及 DWPM 提供的权重图构建高斯金字塔。每个高斯金字塔由若干图像层级组成，其中每一层是其上一层通过下采样获得的表示，能够有效提取和表征图像在不同空间尺度上的结构信息。定义第 i 层的高斯金字塔为：

$$G_{\text{image}}^{i} = \text{Downsample}(G_{\text{image}}^{i-1}) \tag{4-5}$$

其中，G_{image}^{i} 为高斯金字塔的第 i 层，G_{image}^{0} 为原始图像，$\text{Downsample}(\cdot)$ 表示下采样操作。在获得高斯金字塔后，进一步构建对应的拉普拉斯金字塔，用于提取图像的高频细节信息。拉普拉斯金字塔的每一层都是通过从当前层中减去高斯金字塔下一层的上采样版本得到：

$$L_{\text{image}}^{i} = G_{\text{image}}^{i} - \text{Upsample}(G_{\text{image}}^{i+1}) \tag{4-6}$$

其中，L_{image}^{i} 表示拉普拉斯金字塔的第 i 层，$\text{Upsample}(\cdot)$ 表示上采样操作。

接着，在每一层上，基于深度感知的权重图进行加权融合操作。假设 L_{defocus}^{i} 和 L_{fine}^{i} 分别表示原始模糊图像与精细预测图像在第 i 层的拉普拉斯分量，W^{i} 表示归一化的聚焦权重图，则融合结果 L_{fused}^{i} 可表示为：

$$L_{\text{fused}}^{i} = W^{i} * L_{\text{defocus}}^{i} + (1 - W^{i}) * L_{\text{fine}}^{i} \tag{4-7}$$

中国知网 https://www.cnki.net

最后，融合后的拉普拉斯金字塔通过逐层上采样与加和的方式进行重构，以生成最终的高质量清晰图像。该过程自融合金字塔中最粗层级（记作第n层）开始，初始重构图像I_{recon}^{n}等于该层的融合拉普拉斯层：

$$I_{\text{recon}}^{n} = L_{\text{fused}}^{n} \tag{4-8}$$

随后，从第$n-1$层到第 0 层，依次向上进行图像复原。在每一个中间层i中，当前层的重构图像I_{recon}^{i}由上一级的重构结果上采样后与该层融合拉普拉斯分量相加获得，具体计算如下：

$$I_{\text{recon}}^{i} = \text{Upsample}(I_{\text{recon}}^{i+1}) + L_{\text{fused}}^{i} \tag{4-9}$$

该迭代过程确保了复原图像在每一个尺度上都能有效捕捉到对应的高频细节，同时实现从粗到细的逐步图像细化。在最细尺度（即第 0 层）完成迭代后，得到最终的融合图像：

$$I_{\text{final}} = I_{\text{recon}}^{0} \tag{4-10}$$

这种多尺度逐层融合与复原策略在保留精细纹理信息的同时，能够有效抑制边界伪影，并确保聚焦区域与离焦区域之间的平滑过渡与结构一致性。最终生成的图像在视觉上展现出更佳的细节保真度和空间一致性，显著提升了去模糊结果的质量。

（4）损失函数

在模型训练过程中，使用均方误差$\mathcal{L}_2$损失来约束最终的恢复图像I_{final}与相应的清晰图像I_{gt}，这主要是因为均方误差的平滑特性，有助于在融合过程中最小化边界伪影。具体公式如下：

$$\mathcal{L}_2 = \| I_{\text{final}} - I_{\text{gt}} \|_2^2 \tag{4-11}$$

值得注意的是，在深度先验融合网络中，用于引导融合过程的离焦权重图并未依赖离焦掩码的显式监督信号。该权重图作为一种中间潜在特征，通过对公式（4-11）中最终复原图像与清晰图像之间一致性损失的反向传播，在训练过程中被隐式地优化与学习。

中国知网 https://www.cnki.net

4.3 实验结果与分析

4.3.1 实验设置

本研究基于 PyTorch 框架实现，并在配备 NVIDIA RTX A6000 48GB 显存的服务器上完成所有训练与测试过程。首先，依据 DAPE 方法[53]中的训练策略，对 RAM[119]进行微调，以构建 BAPE。在第一阶段，FAFE 以官方发布的 DepthAnything 模型权重初始化，选择三种规模中参数最少的“s”版本以兼顾效率与性能。此外，采用 SD-2 base 作为预训练的稳定扩散模型，并与 FAFE 联合训练。训练采用 Adam 优化器，批处理大小设为 1，初始学习率为5×10^{-5}，迭代总数为 80 万次。训练图像来自 DPDD 数据集[43]，裁剪为512×512大小的图像块输入网络。在推理过程中，采样步长设置为 10，并借助 LR 嵌入策略[53]缓解训练与推理分布不一致的问题。第二阶段训练深度先验融合网络，采用从原始图像中随机裁剪256×256图像块的方式进行从头训练，使用 Adam 优化器，批处理大小同样设为 1，初始学习率为5×10^{-4}，每 10 万次迭代衰减为原值的一半，总训练步数为 50 万次。

4.3.2 数据集与评价指标

为全面评估所提出方法的性能，本章在五个主流离焦去模糊基准数据集上开展实验，包括：DPDD 数据集[43]，LFDOF 数据集[122]，RealDOF 数据集[44]，RTF 数据集[118]以及 CUHK 数据集[33]。这些数据集由不同类型的设备与光学系统采集，涵盖多样化的图像特征与分辨率设置，具有良好的代表性。本章方法在 DPDD 数据集[43]上进行训练，并分别在 DPDD[43]，LFDOF[122]，RealDOF[44]和 RTF[118]四个测试集上进行定量和定性评估。值得注意的是，由于硬件资源限制，RealDOF[44]测试集在缩放至1120×1680分辨率后进行推理与评估。CUHK 数据集[33]由于缺乏参考图像，仅用于定性视觉比较分析。

本章在定量评估中采用多种主流指标，从多个维度综合衡量图像去模糊的质量：（1）失真指标，包括 PSNR 和 SSIM，用于评估复原图像与参考图像之间的像素级还原度和结构保真一致性；（2）感知指标，包括学习感知图像块相似性（Learned Perceptual Image Patch Similarity，LPIPS），深度图像结构与纹理相似性（Deep Image Structure and Texture Similarity，DISTS），Fréchet Inception 距离（Fréchet Inception Distance，FID）以及自然图像质量评估器（Naturalness Image Quality Evaluator，NIQE），用于从感知层面衡量图像的真实性、自然度与结构还原质量。

中国知网 https://www.cnki.net

4.3.3 定量与定性实验结果

本节将本章方法与当前主流的先进离焦去模糊方法进行了系统比较。对比方法包括：DPDNet[43]、KPAC[123]、IFAN[44]、Restormer[86]、INIKNet[14]、NRKNet[16]、DefocusGAN[124]、DEDDNet[125]和 P2IKT[45]。这些方法的实验结果来源于其原始论文或其公开发布的预训练模型与代码。

（1）定量实验结果分析

本章在四个具有代表性的数据集上，即 DPDD 数据集[43]，RealDOF 数据集[44]，LFDOF 数据集[122]以及 RTF 数据集[118]，进行了全面的定量对比实验，结果分别呈现在表 4.1 至表 4.4。实验结果表明：1）在四个数据集上，本章方法在 PSNR 与 SSIM 指标上均获得最高分数，充分展现了卓越的去模糊能力与图像质量提升效果。2）在 DPDD 数据集[43]上，本章方法在 FID 指标上相较于排名第二的方法实现了超过 1.35 的显著提升。FID 衡量的是生成图像与真实图像在深层特征空间中的分布距离，表明本章方法在生成自然纹理与真实结构方面更具优势，视觉感受更加逼真自然。3）在个别感知质量指标如 DISTS 和 NIQE 上，DefocusGAN[124]表现略优，其优势来自于引入了专门设计的离焦对抗损失函数，有助于提升感知空间的纹理建模能力。然而，DefocusGAN[124]在 PSNR 与 SSIM 等像素级指标上的表现相对较弱，说明其更倾向于提升主观视觉质量，而非追求严格的像素还原精度。4）在多个模型未见过的数据集上，包括 LFDOF 数据集[122]，RealDOF 数据集[44]以及 RTF 数据集[118]，本章方法依然在大多数感知质量指标上保持领先，充分展示了良好的跨数据场景泛化能力。具体而言，在 RealDOF 数据集[44]上，本章方法在 FID 指标上相较于次优方法提升了 2.18，表明其在生成图像与真实图像统计分布对齐方面具有显著优势；在 LFDOF 数据集[122]上，LPIPS 和 DISTS 指标分别超越第二优方法 3.7%和 1.27%，显示出更强的感知相似度和结构还原能力；在 RTF 数据集[118]上，本章方法在上述两个指标上分别提升超过 3%和 0.61%，进一步验证了其在真实场景下的适应性。这些稳定且显著的性能提升，主要归因于本章在第一阶段引入的多模态先验引导扩散机制。该机制在特征空间中对模糊图像与清晰图像的结构与纹理信息进行对齐，有效提升了两者之间的语义一致性，使生成结果不仅在视觉上更加自然真实，也在感知指标上更贴近人类主观判断。

尽管本章方法在多数感知指标上表现优越，但在 NIQE 这一无参考图像质量评价指标上，相较部分方法略显劣势。NIQE 是基于自然图像统计规律构建的无监督指标，偏重于评估图像整体的自然性与统计一致性。相比之下，本章方法更关注结构细节的恢复与图像语义结构的一致性。因此，在生成图像中，局部区域可能因高度保真还原真实结构而偏离自然图像的统计特性，导致 NIQE 得分略低。

中国知网 https://www.cnki.net

然而，该项指标的劣势并未影响图像的主观感知质量与视觉真实感，整体而言，本章方法在各类评估指标中依然展现出综合领先的性能。

表 4.1 不同方法在 DPDD 数据集上的定量比较

Table 4.1 Quantitative comparison of different methods on the DPDD dataset

方法	PSNR↑	SSIM↑	LPIPS↓	DISTS↓	FID↓	NIQE↓
DPDNet[43]	24.35	0.747	0.277	0.1808	100.23	5.4498
KPAC[123]	25.22	0.774	0.229	0.1420	53.12	5.0120
IFAN[44]	25.37	0.789	0.217	0.1331	52.77	4.8815
Restormer[86]	25.98	0.811	0.178	0.1204	47.54	5.1006
INIKNet[14]	26.06	0.803	0.185	0.1234	53.46	4.7215
NRKNet[16]	26.11	0.810	0.210	0.1396	55.23	4.8786
DefocusGAN[124]	25.52	0.791	0.165	**0.0965**	51.04	**4.2966**
DEDDNet[125]	25.57	0.794	**0.162**	0.0975	51.35	4.3679
P2IKT[45]	26.29	0.807	0.191	0.1311	47.94	4.9684
本章方法	**26.52**	**0.817**	0.226	0.1490	**46.19**	5.1243

表 4.2 不同方法在 RealDOF 数据集上的定量比较

Table 4.2 Quantitative comparison of different methods on the RealDOF dataset

方法	PSNR↑	SSIM↑	LPIPS↓	DISTS↓	FID↓	NIQE↓
DPDNet[43]	22.87	0.670	0.425	0.2409	103.08	7.0584
KPAC[123]	23.98	0.762	0.338	0.1431	42.10	5.9812
IFAN[44]	24.71	0.748	0.306	0.1455	41.69	5.7485
Restormer[86]	25.09	0.762	0.285	0.1267	37.83	5.4684
INIKNet[14]	25.23	0.765	0.287	0.1316	43.99	5.9163
NRKNet[16]	25.15	0.768	0.338	0.1488	44.56	6.1696
DefocusGAN[124]	24.07	0.734	0.280	0.1255	44.51	4.9416
DEDDNet[125]	24.37	0.748	0.264	**0.1205**	41.73	**4.8897**
P2IKT[45]	25.78	0.787	0.235	0.1389	38.80	6.2610
本章方法	**25.97**	**0.812**	**0.234**	0.1345	**35.65**	6.1206

中国知网 https://www.cnki.net

表 4.3 不同方法在 LFDOF 数据集上的定量比较

Table 4.3 Quantitative comparison of different methods on the LFDOF dataset

方法	PSNR↑	SSIM↑	LPIPS↓	DISTS↓	FID↓	NIQE↓
DPDNet[43]	23.25	0.733	0.312	0.1601	79.07	5.3454
KPAC[123]	25.98	0.805	0.272	0.1495	51.14	5.1020
IFAN[44]	26.11	0.811	0.222	0.3784	49.55	4.9859
Restormer[86]	26.44	0.824	0.207	0.1166	44.37	5.0040
INIKNet[14]	26.49	0.810	0.219	0.1187	59.90	4.7706
NRKNet[16]	26.40	0.805	0.233	0.1184	53.27	4.6036
DefocusGAN[124]	25.57	0.776	0.207	0.1240	51.08	3.8176
DEDDNet[125]	25.09	0.776	0.195	0.1222	49.11	**3.8071**
P2IKT[45]	26.90	0.821	0.220	0.1253	47.94	5.1022
本章方法	**28.57**	**0.859**	**0.158**	**0.1039**	**34.75**	5.1006

表 4.4 不同方法在 RTF 数据集上的定量比较

Table 4.4 Quantitative comparison of different methods on the RTF dataset

方法	PSNR↑	SSIM↑	LPIPS↓	DISTS↓	FID↓	NIQE↓
DPDNet[43]	23.61	0.591	0.296	0.1559	113.83	4.3998
KPAC[123]	24.62	0.777	0.236	0.1201	59.54	4.2130
IFAN[44]	24.92	0.801	0.227	0.1132	56.82	4.1710
Restormer[86]	24.21	0.821	0.224	0.1097	**52.15**	3.9138
INIKNet[14]	25.45	0.834	0.215	0.1151	72.59	4.0104
NRKNet[16]	25.93	0.829	0.215	0.1116	56.92	4.1609
DefocusGAN[124]	24.38	0.752	0.193	0.1127	76.20	**3.8236**
DEDDNet[125]	24.59	0.774	0.178	0.1119	71.91	3.9764
P2IKT[45]	25.85	0.839	0.207	0. 1128	71.94	4.2287
本章方法	**26.23**	**0.860**	**0.148**	**0.1036**	56.11	3.9033

（2）定性实验结果分析

在 DPDD 数据集[43]，LFDOF 数据集[122]，RealDOF 数据集[44]和 RTF 数据集[118]上的定性对比结果如图 4.8 所示。与现有主流方法相比，本章方法在面对显著离

中国知网 https://www.cnki.net

焦模糊的复杂场景中表现出更为优越的视觉效果，而其他方法往往难以生成令人满意的复原图像。具体而言，在 DPDD[43]样本上，本章方法在文字区域的恢复方面表现尤为突出，能够清晰地复原文字轮廓且无明显伪影；在 RealDOF[44]样本中，其他方法在复杂结构（如栏杆）上容易出现形变或模糊，而本章方法能够准确还原栏杆的细节，展示出更强的结构还原能力；在 LFDOF[122]样本中，其他方法在汽车边缘区域的恢复效果不佳，复原结果仍然模糊，而本章方法有效复原了边缘轮廓，细节更加清晰；在 RTF[118]样本中，本章方法在结构保持和纹理复原方面表现优异，生成图像更贴近人类视觉感知，整体观感更为自然。

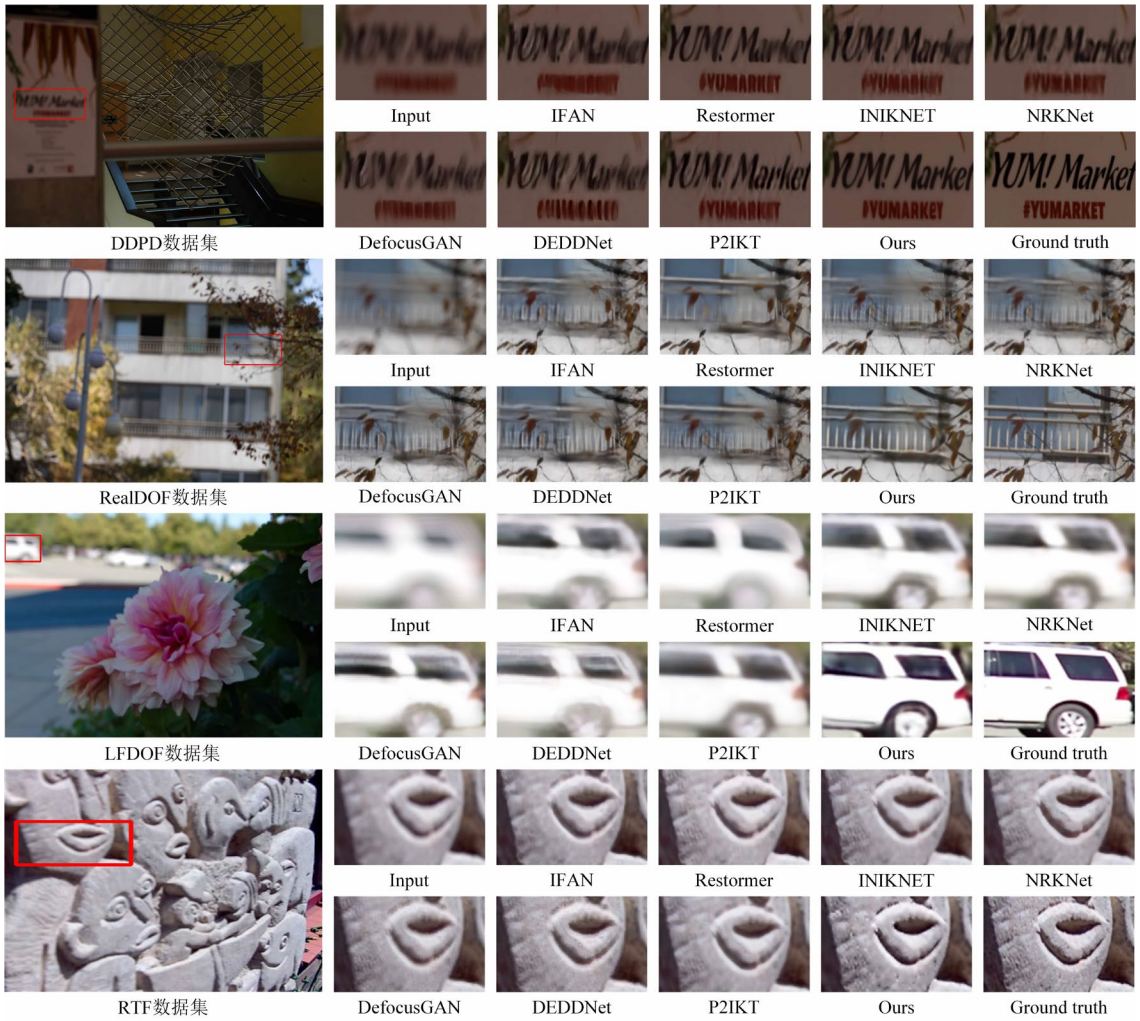


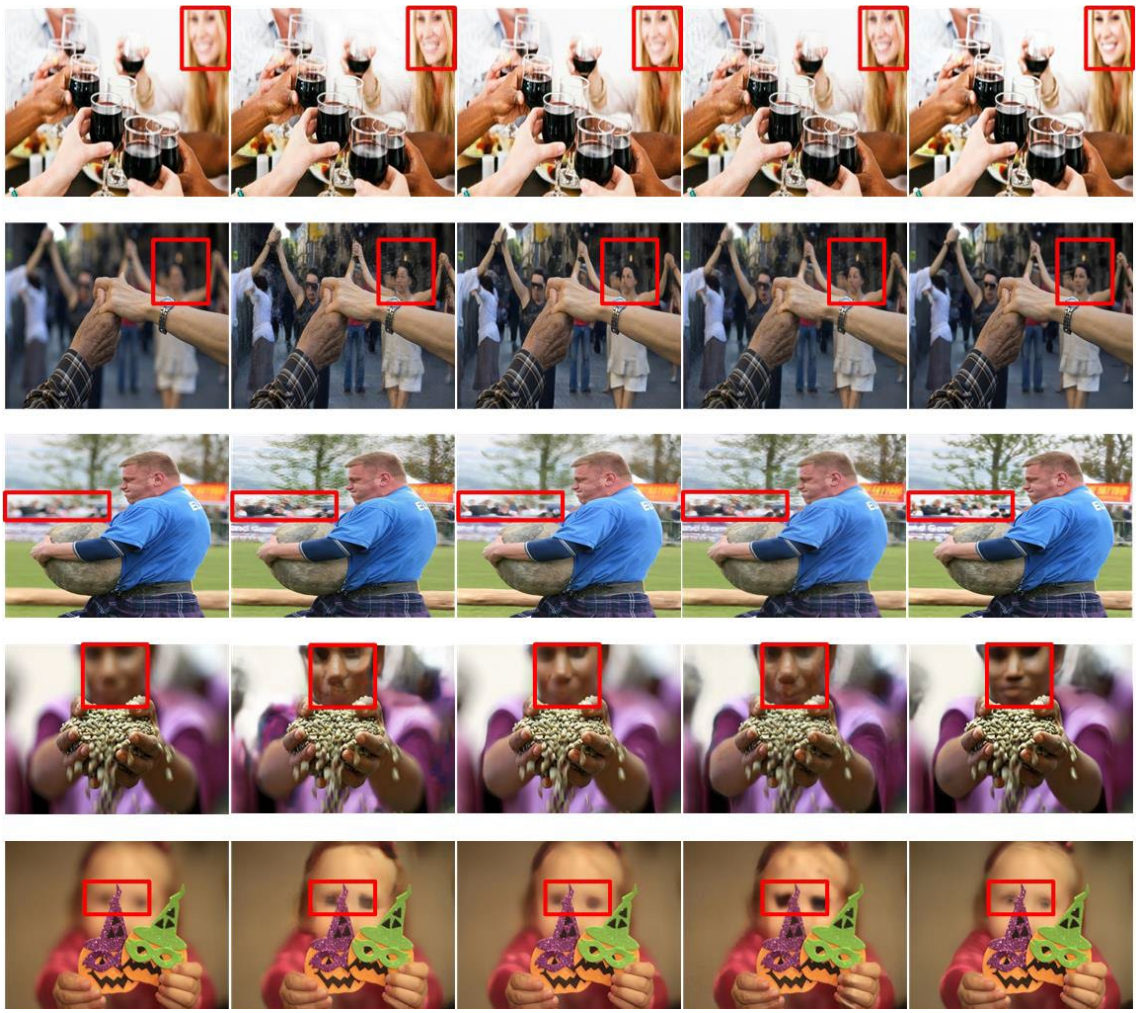
图 4.8 不同方法在四个数据集上的定性比较

Figure 4.8 Qualitative comparison of different methods on four datasets

进一步地，为了验证模型在真实场景中的适用性，本节还在 CUHK 数据集[33]上进行了补充实验。该数据集由 704 张来自各大在线平台的离焦图像构成，未提供对应的清晰图像，因此主要通过定性可视化比较进行性能评估。如图 4.9 所示，

中国知网 https://www.cnki.net

该数据集中包含大量人物图像，普遍存在明显的离焦模糊和严重的细节缺失，是对任何图像去模糊算法的重大挑战。从可视化结果来看，本章方法在面部纹理、轮廓边缘及眼部细节等关键区域的恢复上明显优于其他对比方法。特别是在图中第四行与第五行，其他方法常出现伪影（如边缘模糊、轮廓漂移）或无法复原五官结构（如眼睛、鼻梁等），而本章方法能够显著改善这些问题，成功恢复清晰面部轮廓和可辨识的五官细节，展现出更高的感知一致性与自然感。



(a) 离焦输入　(b) DefocusGAN　(c) Restormer　(d) P2IKT　(e) 本章方法

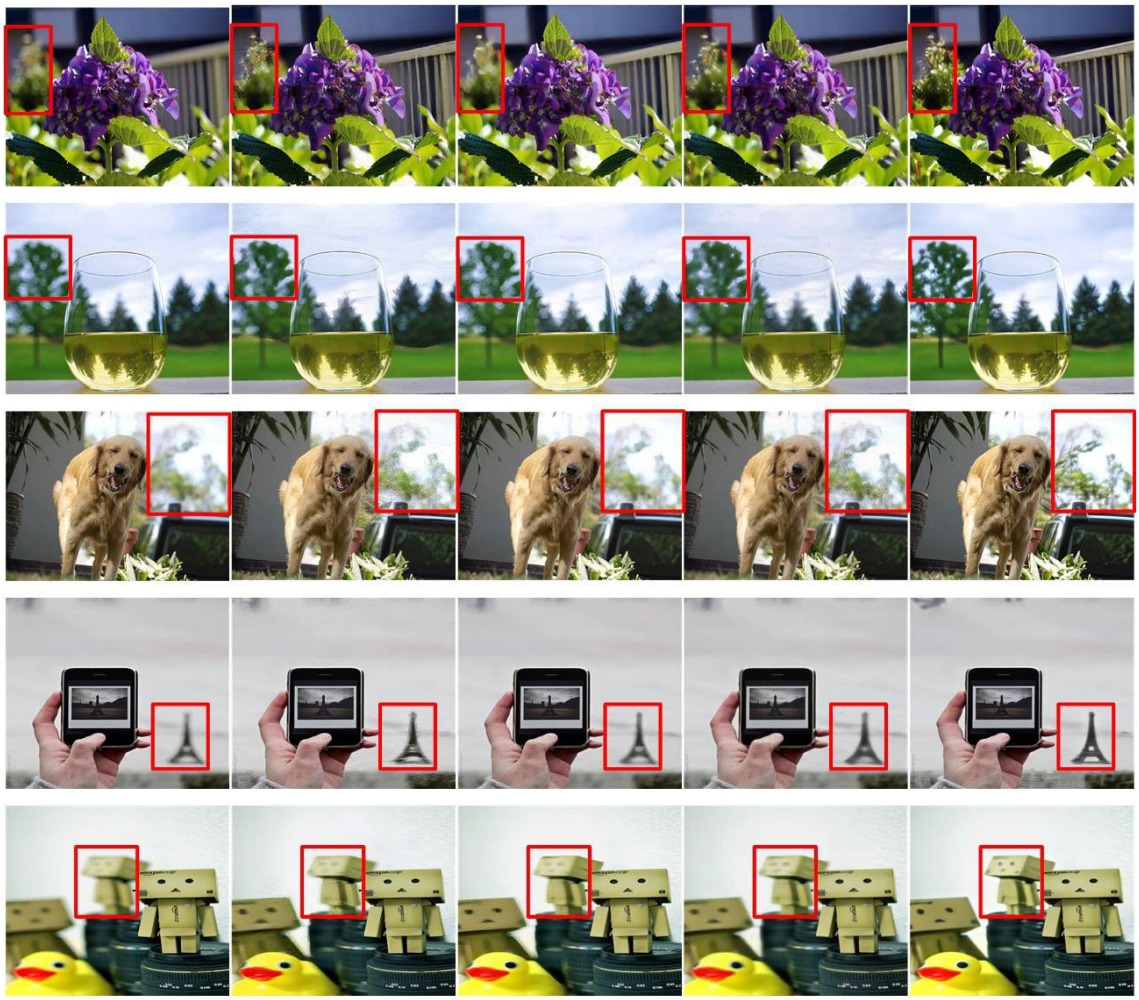
图 4.9 CUHK 数据集中人物图像的定性比较

Figure 4.9 Qualitative comparison of human images in the CUHK dataset

图 4.10 展示了 CUHK 数据集[33]中多个风景图像的定性比较结果。可以观察到，本文方法在保持结构完整性和纹理细节方面具备明显优势。在前三行中，其他方法对树枝和树叶等高频结构的还原能力有限，生成图像仍显模糊；而本章方法则恢复出更为尖锐的纹理和复杂细节，尤其在包含小物体的复杂场景中表现尤

中国知网　https://www.cnki.net

为出色。在第四行和第五行样本中，本章方法成功复原了如铁塔、机器人等关键结构，生成图像轮廓清晰，视觉效果优越。



(a) 离焦输入　(b) DefocusGAN　(c) Restormer　(d) P2IKT　(e) 本章方法

图 4.10 CUHK 数据集中风景图像的定性比较

Figure 4.10 Qualitative comparison of landscape images in the CUHK dataset

此外，图 4.11 展示了 CUHK 数据集[33]中一个典型样本，其中可以观察到本章方法的 NIQE 得分略差于 DefocusGAN[124]的得分。这种差异主要源于两者优化目标的不同。DefocusGAN[124]通过引入对抗损失，更倾向于生成符合自然图像统计特性的纹理，因此在无参考质量指标 NIQE 上获得略高分数。然而，本章方法更注重图像细节与对比度的恢复，尤其在高对比度区域中，显著提升了图像锐度和清晰度。虽然这种增强可能与 NIQE 所建模的“自然性”特征不完全一致，但从视觉感知角度来看，本章方法生成的图像更加清晰、结构更完整，具有更强的实用性与主观吸引力。

中国知网　https://www.cnki.net



(a) 离焦输入　(b) DefocusGAN　(c) Restormer　(d) 本章方法

图 4.11 来自 CUHK 数据集上的例子

Figure 4.11 An example from the CUHK dataset

4.3.4 消融实验

为了验证本章提出方法中各模块的有效性，本节在 DPDD 数据集[43]上设计了一系列消融实验，采用控制变量法逐步引入关键组件，定量分析不同模块对性能的影响。实验共设置七种配置，每种配置启用不同的模块组合，具体说明如下：配置①仅使用 FAFE，引导扩散模型；配置②仅使用 BAPE，引导扩散模型；配置③联合使用 FAFE 与 BAPE，实现多模态引导扩散；配置④是跳过扩散模型阶段，直接对模糊图像应用 PLRM 并通过 WLPF 融合原图；配置⑤是第一阶段输出经过 PLRM 细化，但未进行融合；配置⑥是第一阶段输出仅通过 WLPF 与原图融合，未进行 PLRM 细化；配置⑦是第一阶段输出同时经过 PLRM 细化与 WLPF 融合，为完整模型配置。表 4.5 展示了七种配置在 PSNR、SSIM 与 LPIPS 下的性能表现，图 4.14 则提供了视觉对比示例，图中绿色框标注清晰区域，红色框标注模糊区域，用于直观评估各方法在细节恢复与结构保持上的能力。

表 4.5 七种配置下消融实验的定量比较

Table 4.5 Quantitative comparison of ablation studies under seven configurations

方法	SD		DAFN		DPDD 数据集		
	FAFE	BAPE	PLRM	WLPF	PSNR↑	SSIM↑	LPIPS↓
①	✓				23.14	0.676	0.240
②		✓			23.69	0.714	0.207
③	✓	✓			24.22	0.731	**0.197**
④			✓	✓	24.35	0.742	0.232
⑤	✓	✓	✓		24.92	0.773	0.228
⑥	✓	✓		✓	25.83	0.802	0.227
⑦	✓	✓	✓	✓	**26.52**	**0.817**	0.226

中国知网 https://www.cnki.net



图 4.12 七种配置下消融实验的定性比较

Figure 4.12 Qualitative comparison of ablation studies under seven configurations

（1）多模态引导嵌入的有效性

本节评估了第一阶段扩散模型中不同引导先验对结果的影响。配置①仅使用图像保真度嵌入，由于缺乏文本引导，导致模型在严重模糊区域无法恢复细节，生成结果模糊不清。如图 4.12 中①所示，图像边缘模糊，纹理信息丢失，PSNR 与 SSIM 得分相对较低。配置②改为使用软文本嵌入作为引导条件，语义信息提升了细节生成能力，但由于缺少视觉一致性约束，生成结果与真实内容不完全匹配，出现一定程度的伪细节（见图 4.12 的②）。配置③综合使用 FAFE 与 BAPE，引入多模态引导，兼顾了结构保真与语义特征，整体恢复质量明显提升。如图 4.12 的③，图像细节更清晰，边缘过渡自然，减少了部分伪细节。该配置在 LPIPS 上表现最佳，同时 PSNR 相比配置②提升约 0.6，SSIM 提升 0.02，验证了多模态输入在提升扩散模型表现方面的有效性。

（2）精细预测和融合模块的有效性

第二阶段对第一阶段的粗估计进行细化和自适应融合，本节评估了细化与融合模块的作用。配置④直接对模糊输入应用 PLRM 进行精细预测，并利用深度先验生成的离焦权重图来引导 PLRM 输出与原始离焦图像的融合。虽然该方法能够保留空间结构，但在生成清晰结果方面表现不足（见图 4.12 的④）。与利用第一阶段粗估计进行细化和融合相比，该方法在 PSNR 上下降 2.17，SSIM 减少 0.075（见表 4.5）。这表明第一阶段估计在保持结构完整性方面具有重要作用，对于高质量恢复至关重要。配置⑤使用 PLRM 对第一阶段粗估计进行细化，但由于缺乏空间自适应性，有时会生成更多的伪影（见图 4.12 的⑤）。配置⑥将第一阶段粗估计与原始离焦图像通过加权拉普拉斯金字塔进行融合，由于缺乏对粗估计的细化步骤，生成的结果仍缺乏细节，并且在聚焦区域产生伪影。结合细化步骤后，配置⑦在 PSNR 上提升 0.69，SSIM 提升 0.015（见表 4.5），证明了其在增强恢复质量方面的有效性。

中国知网 https://www.cnki.net

（3）融合策略的有效性

为了进一步评估融合模块对图像恢复质量的影响，本节对比分析了提出的WLPF与一种简化版本的直接加权融合（Direct Weight Fusion，DWF）策略，探讨二者在处理离焦图像与精细预测融合过程中的差异及优劣。WLPF基于经典的拉普拉斯金字塔图像融合理论，构建了一套多尺度融合框架。该方法首先将输入的离焦图像与PLRM输出的精细预测图像分别构建高斯金字塔和拉普拉斯金字塔表示，并结合深度引导生成的空间注意权重图，在每一层尺度上进行加权融合，最后复原出细节丰富且结构完整的高质量图像。由于拉普拉斯金字塔能够在不同频率尺度上分离图像的结构信息与边缘细节，WLPF在保持图像局部细节、平滑过渡边缘、强化空间一致性方面具有天然优势。相比之下，DWF方法则采用了较为简单的单尺度融合策略。具体而言，其将离焦图像和PLRM输出通过一个聚焦权重图进行加权组合，融合公式如下：

$$I_{final} = W * I_{\text{defocus}} + (1 - W) * I_{\text{fine}} \tag{4-12}$$

其中，W为聚焦权重图，用于衡量每个像素应来源于精细预测图或原始离焦图的比例。由于仅在单一尺度上进行处理，DWF在应对结构剧烈变化或细节复杂的区域时，缺乏对多尺度信息的有效建模能力，易导致模糊过渡或边界伪影的出现。图4.13展示了两种融合策略在一个代表性样本上的视觉表现对比。可以明显观察到，DWF在模糊与清晰区域交界处往往会出现明显的锐度断层或不自然的融合过渡，尤其是在边缘细节或纹理区域，更容易出现光晕或边缘伪影。而WLPF则能较好地保持边缘连续性和整体结构的自然过渡，融合效果更加细腻流畅，复原出的图像更具真实感。



(a) 离焦输入　(b) 清晰图像　(c) 基于DWF结果　(d) 基于WLPF结果

图4.13 DWF和WLPF对去模糊结果的定性比较

Figure 4.13 Qualitative comparison of deblurring results using DWF and WLPF

中国知网 https://www.cnki.net

此外，表 4.6 展示了上述两种方法在 DPDD 数据集[43]上取得的定量评估结果。从 PSNR、SSIM 及 LPIPS 三项指标来看，WLPF 在所有指标上均优于 DWF，特别是在 LPIPS 指标上优势更为明显，表明其在感知质量方面具有更好表现。例如，WLPF 相比 DWF 在 PSNR 上提升约 0.6，在 SSIM 上提升 0.012，在 LPIPS 上则降低了 0.017，显示出其在细节保留与整体结构还原方面的综合优势。

表 4.6 DWF 和 WLPF 对去模糊结果的定量比较

Table 4.6 Quantitative comparison of deblurring results using DWF and WLPF

方法	PSNR↑	SSIM↑	LPIPS↓
DWF	25.92	0.805	0.243
WLPF	**26.52**	**0.817**	**0.226**

4.3.5 鲁棒性与复杂性分析

（1）鲁棒性分析

为评估本章所提方法在复杂离焦模糊场景中的泛化能力，本节将其与第三章中基于离焦模糊图估计的去模糊方法在 DPDD 数据集[43]和 RTF 数据集[118]上进行了定量对比，实验结果如表 4.7 所示。从表中结果可以看出，本章提出的直接估计方法在 PSNR、SSIM 及 LPIPS 三项指标上均显著优于第三章方法。具体而言，在 DPDD 数据集上，本章方法的 PSNR 相较第三章方法提升了 3.04dB，SSIM 提升了 0.109，而感知质量指标 LPIPS 显著降低了 0.142，表明恢复图像在细节结构及视觉感知上更接近真实清晰图像。在 RTF 数据集上，本章方法同样取得了 1.38dB 的 PSNR 提升和 0.035 的 SSIM 增益，LPIPS 指标则进一步下降了 0.044，表明其在跨数据集和复杂模糊场景中依旧保持了良好的性能优势。

表 4.7 不同方法在 DPDD 和 RTF 数据集上的定量比较

Table 4.7 Quantitative comparison of different methods on the DPDD and RTF dataset

数据集	方法	PSNR↑	SSIM↑	LPIPS↓
DPDD 数据集[43]	第三章的方法	23.48	0.708	0.368
	本章方法	**26.52**	**0.817**	**0.226**
RTF 数据集[118]	第三章的方法	24.85	0.825	0.192
	本章方法	**26.23**	**0.860**	**0.148**

性能差异的主要原因在于第三章方法依赖于离焦模糊图的估计，模糊图估计

中国知网 https://www.cnki.net

误差在后续的非盲去卷积过程中会被逐步放大，导致恢复质量下降。相较之下，本章提出的直接估计方法跳过了中间模糊图的显式建模环节，直接在端到端框架下恢复清晰图像，有效避免了误差累积问题。同时，实验表明该方法在不同类型的模糊场景下均表现出稳定的性能提升，体现了良好的泛化性和鲁棒性。

（2）复杂性分析

为全面评估本章所提方法在模型复杂度方面的表现，本节在3×512×512的图像上，从浮点运算次数、参数量以及推理时间三个维度，将本章方法与第三章方法及两种代表性的深度学习离焦去模糊方法（Restormer[86]、P2IKT[45]）进行了系统对比，结果如表 4.8 所示。

从表中结果可以看出，本章方法在单次采样步骤下的总浮点运算次数为260.738G，显著低于 Restormer 和 P2IKT。然而，由于扩散模型的迭代采样特性，计算量的减少并未直接转化为推理速度的提升。在 10 个采样步骤下，本章方法的推理时间为 2.42 秒，虽然略高于在像素空间直接运行的 Restormer 和 P2IKT，但相比第三章传统方法需要多次迭代反卷积的过程，仍然具备明显的速度优势。

在参数量方面，本章方法达到 494.183M，其中 491.083M 来源于扩散模型，3.1M 来自融合网络。参数量较大主要归因于集成了 Stable Diffusion、RAM、DepthAnything 等大规模预训练模块，这些模块提升了模型感知能力和泛化性能，但同时带来了较高的内存开销与推理负担。为提升推理效率与部署可行性，未来将从以下方向进行轻量化优化：1）单步潜在去噪：将多步迭代采样蒸馏为单步潜在空间去噪网络，显著降低推理时间。2）结构重参数化：训练阶段采用多分支结构增强特征表达，推理阶段等效转换为单分支卷积，以减少计算量并保持精度。3）高效的预训练模块：以轻量化 Transformer 或移动端友好 CNN 替代 RAM、DepthAnything 等重型组件，降低计算与内存需求。

表 4.8 模型复杂度比较

Table 4.8 Model complexity comparisons

方法	浮点运算次数（G）	参数量 (M)	推理时间(秒)	
			CPU	GPU
第三章的方法	-	-	604.7	-
Restormer[86]	563.962	26.097	-	0.461
P2IKT[45]	339.465	**3.319**	**-**	**0.204**
本章方法	**260.738**	494.183	-	2.420

注：G 表示十亿次浮点运算，M 表示百万参数。

中国知网 https://www.cnki.net

4.4 本章小结

针对第三章方法在真实场景中表现受限的问题，本章提出了一种融合多模态引导扩散机制与深度感知融合策略的单幅图像离焦去模糊方法，旨在应对复杂模糊场景下的图像复原挑战。该方法包括两个阶段：第一阶段构建保真感知多模态融合模块，融合图像保真度特征与软文本语义信息，引导扩散模型生成结构一致、细节丰富的清晰图像，显著提升去模糊结果的自然性与真实感；第二阶段引入深度先验融合网络，以像素级一致性为优化目标，结合第一阶段预测图中的细节信息与原始图像中保留的清晰区域。该网络采用深度先验引导的加权拉普拉斯金字塔融合策略，在多尺度空间实现原图与预测图的权重自适应融合，有效平衡高频细节恢复与整体像素一致性。

大量实验结果充分验证了本章方法的有效性。在 DPDD、RealDOF、LFDOF 及 RTF 四个标准数据集上的系统评估中，所提方法在多个关键指标上全面优于现有 9 种主流方法：PSNR 平均提升 0.597dB，SSIM 平均提升 0.021，LPIPS 和 FID 两项感知指标上分别降低 0.007 和 2.29，体现出更强的图像复原质量与视觉感知效果。尤其在 RTF 数据集上，PSNR 和 SSIM 分别较第三章方法提升了 1.38dB 和 0.035，展现出更强的真实离焦图像复原能力。此外，定性实验结果显示，本章方法在边缘结构保持和纹理细节还原方面表现突出，有效抑制了纹理失真与边界伪影，进一步验证了多模态语义先验与深度空间先验在图像复原中的重要作用。

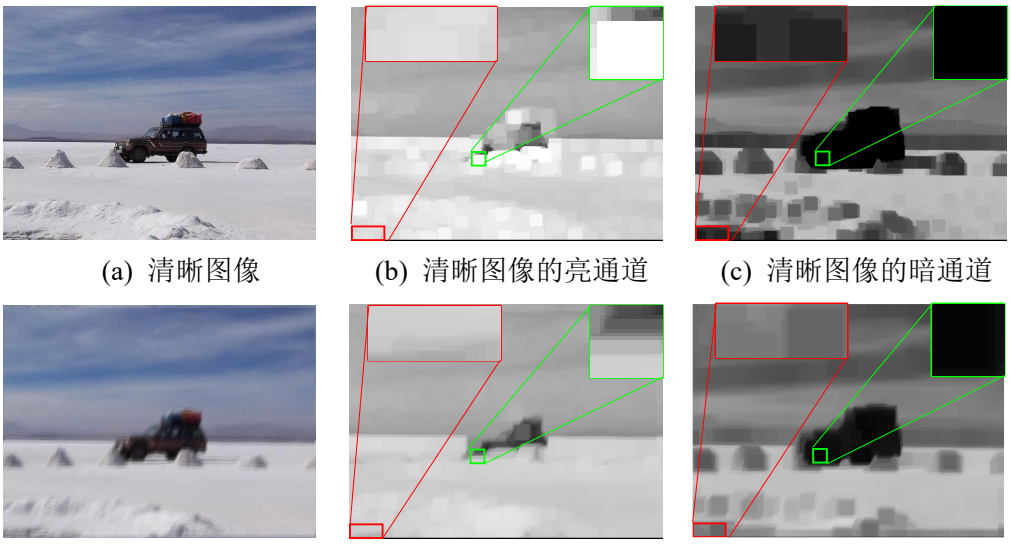
中国知网 https://www.cnki.net

第 5 章 基于动态极值先验的图像盲去模糊方法

5.1 引言

第三章和第四章分别针对离焦图像去模糊问题进行了深入研究：第三章聚焦于低对比度区域中模糊估计困难的问题，并成功将所提模糊图估计方法应用于离焦去模糊任务；第四章则引入大模型先验，提升了方法在复杂场景中的适应能力。尽管上述两章均面向离焦模糊展开研究，但在实际应用中，由相机抖动或物体运动引发的运动模糊同样广泛存在，且已成为影响图像质量的另一关键因素。因此，本章将重点研究由相机抖动引发的均匀运动模糊的盲去模糊问题。

图像盲去模糊的核心挑战在于在未知模糊核的情况下，从模糊图像中恢复出清晰图像。由于不同图像与模糊核的组合可能产生相同结果[18,66]，该问题本质上是病态的，缺乏唯一解。为缓解这一病态性，已有研究引入暗通道先验[18]、亮通道先验[65]和逐块最小像素先验[66]等，利用清晰图像中极值像素的稀疏性引导去模糊。然而，这些先验在高或低强度像素占优的图像中表现不稳定。即使是同时考虑极大值与极小值的极通道先验[65]，也难以适应不同区域的稀疏性变化，易导致恢复不稳定。如图 5.1 所示，模糊可能对某些图像块（如绿色块）的暗通道没有显著影响，但会破坏其亮通道稀疏性；反之，对另一些图像块（如红色块）的亮通道稀疏性影响较小，但显著破坏了其暗通道的稀疏性。



(a) 清晰图像　(b) 清晰图像的亮通道　(c) 清晰图像的暗通道

(d) 模糊图像　(e) 模糊图像的亮通道　(f) 模糊图像的暗通

图 5.1 模糊对不同图像块极强度值的影响

Figure 5.1 Impact of blur on extreme intensity values in different image patches

中国知网 https://www.cnki.net

为解决上述问题，本章提出了一种基于动态极值先验的图像盲去模糊方法，旨在更有效地适应不同图像区域的模糊特性。为刻画该特性，本章引入了两种局部块先验：逐块最大像素（Patch-wise Maximal Pixels，PMaxP）先验和逐块最小像素（Patch-wise Minimal Pixels，PMinP）先验。通过模糊 C 均值（Fuzzy C-Means，FCM）聚类方法，将图像块根据强度特征动态分为两组，并为每个图像块分配相应的 PMaxP 或 PMinP 先验。在每次迭代中，聚类结果动态更新，以适应中间潜在图像的估计。针对由动态极值先验引入的非凸非线性优化问题，本章进一步提出稀疏诱导（Sparsity Inducing，SI）优化策略，相比传统的半二次分裂（Half Quadratic Splitting，HQS）算法更高效。

本章的主要贡献总结如下：

（1）提出动态极值先验建模方法，结合图像局部极端强度值的统计特征，分别构建最大值与最小值的稀疏性模型，并通过 FCM 聚类机制将先验动态分配至不同图像块，从而提升模型对复杂模糊场景的适应性；

（2）设计稀疏诱导优化策略，针对动态极值先验所带来的非凸非线性目标函数，构建高效的优化求解框架，在保持精度的同时显著提升运行效率；

（3）通过大量自然图像和特定场景图像的盲去模糊实验，验证了本章方法在恢复质量与计算效率上的优势，整体性能优于现有主流方法。

5.2 逐块极值像素先验

在一个局部图像块中，模糊会对极值像素造成损害。为研究这一特性，本章将一幅图像 $I \in \mathbb{R}^{m\times n\times c}$ 分成 N 个大小为 $r\times r$ 的不重叠的图像小块，其中 $N=\lceil m/r\rceil\times\lceil n/r\rceil$，$\lceil\bullet\rceil$ 是向上取整运算符，PMinP 定义为：

$$P_b(I)(i)=\min_{(x,y)\in\Omega_i}\left(\min_{c\in\{r,g,b\}} I(x,y,c)\right) \tag{5-1}$$

其中，Ω_i 表示第 i 个块中像素的位置集，$i=1,2,3,\cdots,N$。因此，PMinP 是 I 的非重叠块上的局部最小像素的集合。如果图像 I 是灰度图像，则只需计算 $\min_{(x,y)\in\Omega_i}$。同样，PMaxP 描述了一个局部图像块中的最大值，定义为：

$$P_a(I)(i)=\max_{(x,y)\in\Omega_i}\left(\max_{c\in\{r,g,b\}} I(x,y,c)\right) \tag{5-2}$$

其中，$P_a(I)$ 是从 I 中提取的逐块最大像素的集合。先前亮通道先验[65]同样基于图

中国知网 https://www.cnki.net

像局部像素用于图像去模糊，其计算依赖图像中逐点的最大像素。与亮通道先验[65]类似卷积的方式计算并生成大小为$m\times n$的输出不同，本章提出的 PMaxP 是在非重叠的图像块上计算的，输出大小为$1\times N$的向量。因此，PMaxP 先验提供了一种更简单的亮通道先验[65]的替代方案，显著减少了计算成本，同时保持了有效的图像先验。

5.2.1 理论证明

为了说明模糊过程会平滑局部极值像素，即增加非 0 像素和非 1 像素的数量，本章通过模糊过程的数学推导得出了一系列相关性质。

性质 1：令$P_b(B)(i)$和$P_b(I)(i)$分别表示模糊图像块和清晰图像块的 PMinP。则以下不等式成立：

$$\| P_b(B)(i) \|_0 \geq \| P_b(I)(i) \|_0 \tag{5-3}$$

证明：对于一个离散信号（图像），卷积运算可以定义为两个信号在其中一个信号反转和移位后的乘积之和：

$$B(x,y)=\sum_{(p,q)\in\phi(x,y)} I\left((x,y)-(p,q)+\left\lfloor\frac{m}{2}\right\rfloor\right)k(p,q) \tag{5-4}$$

其中，$\phi(x,y)$表示以像素(x,y)为中心的图像块，m表示图像块与模糊核的尺寸大小。根据模糊的性质：$k(p,q)\geq 0$和$\sum_{(p,q)\in\phi(x,y)} k(p,q)=1$，可以得到：

$$\begin{aligned} B(x,y) &= \sum_{(p,q)\in\phi(x,y)} I\left((x,y)-(p,q)+\left\lfloor\frac{m}{2}\right\rfloor\right)k(p,q) \\ &\geq \sum_{(p,q)\in\phi(x,y)} \min_{(x_i,y_i)\in\Omega_i} I(x_i,y_i)k(p,q) \\ &= \min_{(x_i,y_i)\in\Omega_i} I(x_i,y_i) \sum_{(p,q)\in\phi(x,y)} k(p,q) \\ &= \min_{(x_i,y_i)\in\Omega_i} I(x_i,y_i) \end{aligned} \tag{5-5}$$

如果(x,y)是一个邻域中最小像素，那么$I(x,y)=\min_{(x_i,y_i)\in\Omega_i} I(x_i,y_i)$，公式（5-5）变成$B(x,y)\geq I(x,y)$。即，在一个局部邻域内加权平均后的像素值大于该邻域中的最小的像素值，即卷积使得一个图像中的局部最小像素的值增大。

中国知网 https://www.cnki.net

接下来，在不失一般性的情况下，假设处理后的图像为灰度图。令Ω_i和Ω'_i表示图像的局部区域，ϕ表示图像的模糊核区域，Ω'_i大小等于模糊核的大小与图像块Ω_i大小之和，根据 PMinP 的定义，

$$\begin{aligned}
P_b(B)(i) &= \min_{(x,y)\in\Omega_i}\left(\min_{c\in\{r,g,b\}} B(x,y,c)\right) = \min_{(x,y)\in\Omega_i} B(x,y) \\
&= \min_{(x,y)\in\Omega_i} \sum_{(p,q)\in\phi(x,y)} I\left((x,y)-(p,q)+\left[\frac{m}{2}\right]\right)k(p,q) \\
&\geq \sum_{(p,q)\in\phi(x,y)} \min_{(x,y)\in\Omega_i} I\left((x,y)-(p,q)+\left[\frac{m}{2}\right]\right)k(p,q) \\
&\geq \sum_{(p,q)\in\phi(x,y)} \min_{(x_i,y_i)\in\Omega'_i} I(x_i,y_i)k(p,q) \\
&= \min_{(x_i,y_i)\in\Omega'_i} I(x_i,y_i) \sum_{(p,q)\in\phi(x,y)} k(p,q) \\
&= \min_{(x_i,y_i)\in\Omega'_i} I(x_i,y_i) = P_b(I)(i)
\end{aligned} \tag{5-6}$$

如果存在像素$(x,y)\in\Omega_i$满足$I(x,y)=0$，那么$\| P_b(B)(i) \|_0 \geq \| P_b(I)(i) \|_0$，其中$\|\bullet\|_0$统计$P_b(I)$的非 0 元素个数。

性质 2：令$P_a(B)(i)$和$P_a(I)(i)$分别表示模糊图像块和清晰图像块的 PMaxP，则以下不等式成立：

$$\| 1-P_a(B)(i) \|_0 \geq \| 1-P_a(I)(i) \|_0 \tag{5-7}$$

证明：假设Ω_i表示图像的局部区域，窗口大小与模糊核的大小相同，那么：

$$\begin{aligned}
B(x,y) &= \sum_{(p,q)\in\phi(x,y)} I\left((x,y)-(p,q)+\left[\frac{m}{2}\right]\right)k(p,q) \\
&\leq \sum_{(p,q)\in\phi(x,y)} \max_{(x_i,y_i)\in\Omega_i} I(x_i,y_i)k(p,q) \\
&= \max_{(x_i,y_i)\in\Omega_i} I(x_i,y_i) \sum_{(p,q)\in\phi(x,y)} k(p,q) \\
&= \max_{(x_i,y_i)\in\Omega_i} I(x_i,y_i)
\end{aligned} \tag{5-8}$$

如果(x,y)是一个邻域中最大像素，那么$I(x,y)=\max_{(x_i,y_i)\in\Omega_i} I(x_i,y_i)$,公式（5-8）变成$B(x,y)\leq I(x,y)$。也就是说，在一个局部邻域内加权平均后的像素值小于该

中国知网 https://www.cnki.net

邻域中的最大像素，即卷积使得一个图像中的局部最大像素的值减小。

接下来，在不失一般性的情况下，假设处理后的图像为灰度图。令 Ω_i 和 Ω'_i 表示图像的局部区域，ϕ 表示图像的模糊核区域，Ω'_i 大小等于模糊核的大小与图像块 Ω_i 大小之和，根据 PMaxP 的定义，

$$\begin{aligned} P_a(B)(i) &= \max_{(x,y)\in\Omega_i}\left(\max_{c\in\{r,g,b\}} B(x,y,c)\right) = \max_{(x,y)\in\Omega_i} B(x,y) \\ &= \max_{(x,y)\in\Omega_i} \sum_{(p,q)\in\phi(x,y)} I\left((x,y)-(p,q)+\left[\frac{m}{2}\right]\right)k(p,q) \\ &\le \sum_{(p,q)\in\phi(x,y)} \max_{(x,y)\in\Omega_i} I\left((x,y)-(p,q)+\left[\frac{m}{2}\right]\right)k(p,q) \\ &\le \sum_{(p,q)\in\phi(x,y)} \max_{(x_i,y_i)\in\Omega'_i} I(x_i,y_i)k(p,q) \\ &= \max_{(x_i,y_i)\in\Omega'_i} I(x_i,y_i) \sum_{(p,q)\in\phi(x,y)} k(p,q) \\ &= \max_{(x_i,y_i)\in\Omega'_i} I(x_i,y_i) = P_a(I)(i) \end{aligned} \tag{5-9}$$

如果存在像素 $(x,y)\in\Omega_i$ 满足 $I(x,y)=1$，那么 $1-I(x,y)=0$。由于模糊过程使得局部最大像素值减少，即减少像素值为 1 的个数。因此，模糊图像的逆 PMaxP 比清晰图像的稀疏程度要低，可以得到 $\|1-P_b(B)(i)\|_0 \ge \|1-P_b(I)(i)\|_0$。

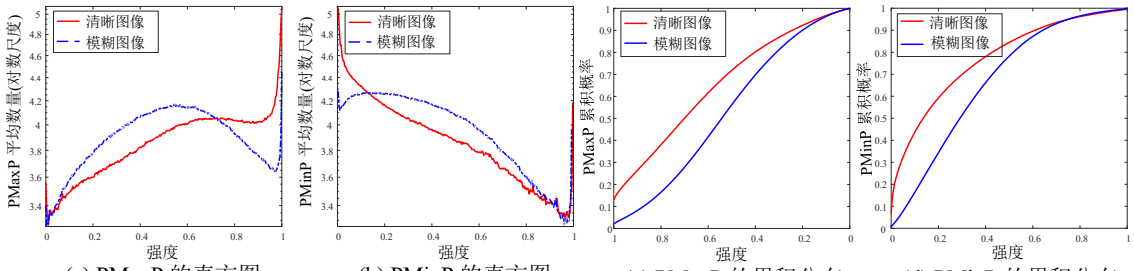
5.2.2 统计分析

为进一步验证前述极值先验的统计特性，本节从 PASCAL 2012 数据集[126]中随机选取了 5000 张自然图像样本，并进行统计分析。本节将所选的 5000 张样本，基于数据集[60]中提供的模糊核，对清晰图像进行卷积操作以合成模糊图像，用以研究 PMaxP 与 PMinP 在自然图像中的分布特性及模糊过程中的变化趋势。图 5.2（a）和（b）展示了清晰图像与合成模糊图像在 PMaxP 与 PMinP 两个指标下的直方图分布情况。可以观察到，在清晰图像中，PMaxP 的数值普遍较高，绝大部分图像块的 PMaxP 强度集中在 0.8 以上；而 PMinP 值则显著较低，集中在 0.1 以下。这些统计结果为后续实验中识别高强度和低强度像素提供了有价值的信息。

为了更深入刻画其分布规律，图 5.2（c）和（d）分别展示了 PMaxP 和 PMinP 的累积分布情况。在计算每张图像的 PMaxP 和 PMinP 时，图像块的大小设置为 20×20。特别地，在图 5.2（c）中，为了更直观展示 PMaxP 分布特征，对 x 轴方向进行了水平翻转处理，即高强度 PMaxP 位于图的左侧，便于与 PMinP 分布形成对照。

中国知网 https://www.cnki.net

值得注意的是，尽管从视觉上来看，清晰图像与模糊图像在 PMaxP 和 PMinP 的累积分布上都近似呈现出超拉普拉斯分布形态，即两端突起、中间平缓，符合自然图像分布特性，但它们之间仍存在一定的差异。

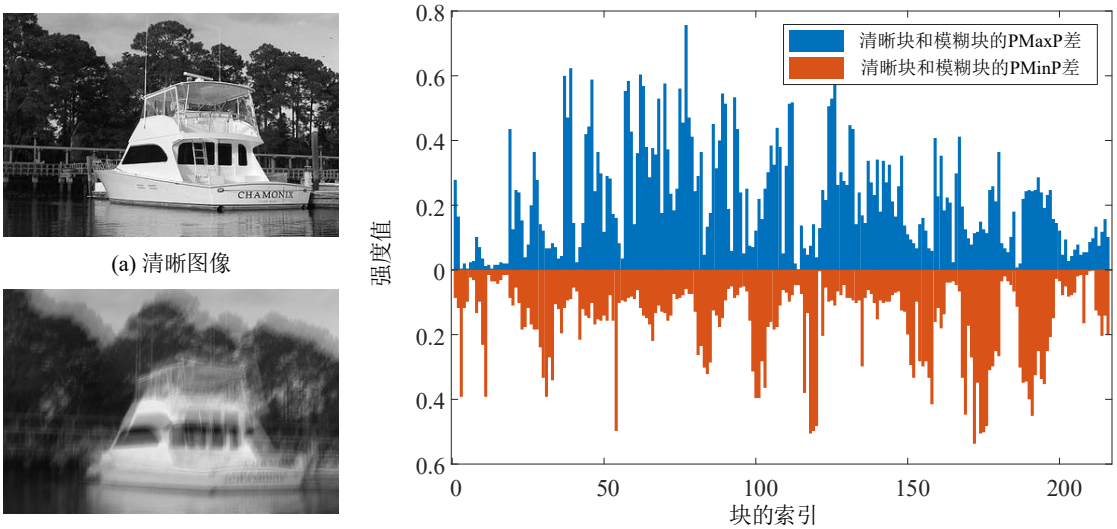


(a) PMaxP 的直方图　(b) PMinP 的直方图　(c) PMaxP 的累积分布　(d) PMinP 的累积分布

图 5.2 PMaxP 和 PMinP 的统计分布

Figure 5.2 Statistical distribution of the PMaxP and PMinP

图 5.3 进一步展示了清晰图像和模糊图像在 PMaxP 和 PMinP 上的差异统计。其中，图 5.3（a）为清晰图像；图 5.3（b）为模糊图像；图 5.3（c）为清晰图像块与对应模糊图像块在 PMaxP 和 PMinP 差上的差异。从图 5.3（c）可以观察到，模糊过程对 PMaxP 和 PMinP 的影响趋势存在显著差异：某些图像块中 PMaxP 下降明显，而 PMinP 变化较小；而另一些图像块则表现出相反的特征。这表明在模糊过程中，PMaxP 与 PMinP 在不同区域的主导性存在差异，无法通过固定先验统一建模。基于上述统计观察，本章在每次迭代中引入 FCM 聚类算法，根据图像块当前的强度特征对其进行动态聚类，并为每个图像块自适应地分配主导的 PMaxP 或 PMinP 先验，从而更有效地捕捉不同区域的模糊变化特性。



(a) 清晰图像

(b) 模糊图像　(c) 清晰块和模糊块PMaxP和PMinP的差

图 5.3 清晰图像和模糊图像在 PMaxP 和 PMinP 上的差异统计

Figure 5.3 Statistical differences in PMaxP and PMinP between sharp and blurred images

中国知网 https://www.cnki.net

5.3 基于动态极值先验的图像去模糊模型

本节提出一种结合图像块 PMaxP 与 PMinP 稀疏性差异的动态极值先验。通过考虑不同图像块在 PMaxP 与 PMinP 上的主导性差异，定义如下动态极值先验：

$$P_r(I)=\sum_{i\in\mathcal{M}}\|P_b(I)(i)\|_0+\sum_{j\in\mathcal{N}}\|1-P_a(I)(j)\|_0 \tag{5-10}$$

其中，$P_a(I)$和$P_b(I)$分别代表 PMaxP 和 PMinP，$\mathcal{M}$和$\mathcal{N}$分别代表由 PMinP 和 PMaxP 主导的图像块集合，$\mathcal{M}\cup\mathcal{N}=\{1,2,3,\cdots,N\}$。

为得到集合$\mathcal{M}$和$\mathcal{N}$，本节采用基于 FCM 的聚类方法[127]，将输入图像的N块分成两个类别。具体而言，将图像N个块的最大值和最小值组成的特征向量作为 FCM 的输入。经过多次迭代，图像块被有效地划分为两个集合$\mathcal{M}$和$\mathcal{N}$，其中集合$\mathcal{M}$用于提升 PMinP 的稀疏性，而集合$\mathcal{N}$用于提升 PMaxP 的稀疏性。图 5.4 展示了潜在图像中极值像素的动态聚类过程。在每次潜在图像更新的迭代中，输入图像的所有块会被重新聚类为两类，并在下一次迭代中进行更新，这一过程被称为动态聚类。每次聚类后，每个图像块都会根据其所属类别使用相应的极值先验（PMinP 先验或 PMaxP 先验）。

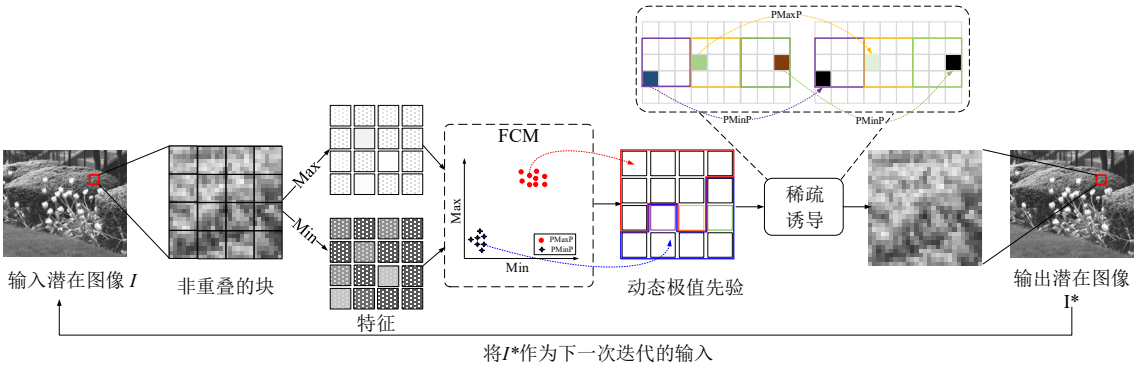


图 5.4 基于动态极值先验的图像去模糊示意图

Figure 5.4 Illustration of image deblurring based on dynamic extremum prior

在此基础上，本章构建了一个基于动态极值先验的图像盲去模糊模型，并设计了高效的优化算法。在经典的最大后验概率（Maximum A Posterior，MAP）框架下，该模型可形式化为以下无约束优化问题：

$$\min_{I,k}\|I\otimes k-B\|_2^2+\gamma\|k\|_2^2+\mu\|\nabla I\|_0+\alpha\sum_{i\in\mathcal{M}}\|P_b(I)(i)\|_0+\beta\sum_{j\in\mathcal{N}}\|1-P_a(I)(j)\|_0 \tag{5-11}$$

中国知网 https://www.cnki.net

其中，γ，μ，α 和 β 为正权重参数。第一个 L_2 正则项表示数据保真度。第二个 L_2 正则项是模糊核的平滑约束。第三项是 L_0 范数，用于增强潜在图像梯度的稀疏性。最后两项是基于动态极值先验的 L_0 正则项，以提高潜在图像的稀疏性。

文献[66]指出，基于 PMinP 的盲图像去模糊的有约束优化在计算复杂度和近似精度方面优于传统的无约束正则化方法。因此，本节建立了基于动态极值先验的盲图像去模糊有约束优化模型：

$$\begin{aligned} &\min_{I,k} \| I \otimes k - B\|_2^2 + \gamma \| k\|_2^2 + \mu \| \nabla I\|_0 \\ &\text{subject to } P_b(I)(i) \sim p_1(x), \text{ for } i \in \mathcal{M}; (1 - P_a(I)(j)) \sim p_2(x), \text{ for } j \in \mathcal{N} \end{aligned} \tag{5-12}$$

其中，$p_1(x)$ 和 $p_2(x)$ 分别表示 PMinP 和 PMaxP 的概率密度函数，“~”表示左侧的分布近似等于右侧的分布。

由于公式（5-12）具有非线性和非凸性，直接求解变得非常困难。本章提出了一种有效的算法，通过交替更新中间潜像和估计模糊核来求解该约束优化问题。该算法涉及以下两个子问题：

1）给定模糊核的中间估计 k^i，通过解决以下子问题来更新潜在图像：

$$\begin{aligned} &\min_{I} \left\| I \otimes k^i - B\right\|_2^2 + \mu \| \nabla I\|_0 \\ &\text{subject to } P_b(I)(i) \sim p_1(x), \text{ for } i \in \mathcal{M}; \ (1 - P_a(I)(j)) \sim p_2(x), \text{ for } j \in \mathcal{N} \end{aligned} \tag{5-13}$$

2）给定潜在图像的中间估计 I^i，通过解决以下子问题来更新模糊核：

$$\min_{k} \left\| I^i \otimes k - B\right\|_2^2 + \gamma \| k\|_2^2 \tag{5-14}$$

5.3.1 潜在图像的估计

由于图像梯度是 L_0 正则项，直接最小化公式（5-13）是困难的。通过引入辅助变量 G，公式（5-13）可以重新表述为：

$$\begin{aligned} &\min_{I,G} \left\| I \otimes k^i - B\right\|_2^2 + \alpha \| \nabla I - G\|_2^2 + \mu \| G\|_0 \\ &\text{subject to } P_b(I)(i) \sim p_1(x), \text{ for } i \in \mathcal{M}; \ (1 - P_a(I)(j)) \sim p_2(x), \text{ for } j \in \mathcal{N} \end{aligned} \tag{5-15}$$

其中，α 是一个非负惩罚参数。当 α 接近无穷大时，公式（5-15）的解等价于公

中国知网 https://www.cnki.net

式（5-13）的解。为了计算简单，可以将$1-P_a(I)$替换为$P_b(1-I)$：

$$\begin{aligned}&\min_{I,G}\left\|I\otimes k^i-B\right\|_2^2+\alpha\|\nabla I-G\|_2^2+\mu\|G\|_0\\&\text{subject to } P_b(I)(i)\sim p_1(x),\ \text{for } i\in\mathcal{M};\ P_b(1-I)(j)\sim p_2(x),\ \text{for } j\in\mathcal{N}\end{aligned}\tag{5-16}$$

需要注意的是，本文在两个图像块集上同时施加了稀疏性约束，即对 PMinP 和逆 PMaxP 的极值分布进行稀疏约束。为此，在迭代过程中引入阈值收缩算子，对潜在图像的极值进行稀疏诱导，具体过程如下：

（1）阈值设定。首先，设$\lambda_1>0$和$\lambda_2>0$为阈值参数，这是基于图 5.2 中的统计分析结果，用于对高强度与低强度像素进行定量区分。PMinP 和逆 PMaxP 的阈值为：

$$\begin{aligned}\tilde{P}\left(I^{t+1,n}\right)(i)&=\begin{cases}0, & |P_b\left(I^{t+1,n}\right)(i)|<\lambda_1\\P_b\left(I^{t+1,n}\right)(i), & \text{otherwise}\end{cases}\\\tilde{P}\left(1-I^{t+1,n}\right)(j)&=\begin{cases}0, & |P_b\left(1-I^{t+1,n}\right)(j)|<\lambda_2\\P_b\left(1-I^{t+1,n}\right)(j), & \text{otherwise}\end{cases}\end{aligned}\tag{5-17}$$

（2）设置掩码。设$\Omega_1^{t+1,n}$和$\Omega_2^{t+1,n}$分别为$I^{t+1,n}$中使用的 PMinP 和 PMaxP 的位置索引集，并定义与它们相关联的掩码为：

$$\begin{aligned}M_1\left(I^{t+1,n}\right)(p,q)&=\begin{cases}1 & (p,q)\in\Omega_1^{t+1,n}\\0 & \text{otherwise}\end{cases}\\M_2\left(I^{t+1,n}\right)(p,q)&=\begin{cases}1 & (p,q)\in\Omega_2^{t+1,n}\\0 & \text{otherwise}\end{cases}\end{aligned}\tag{5-18}$$

（3）更新潜像。在潜在图像$t+1$次迭代中，$I^{t+1,n}$被更新：

$$\tilde{I}^{t+1,n}=I^{t+1,n}\circ(1-(M_1+M_2))+\tilde{P}_{min}^T+\tilde{P}_{max}^T\tag{5-19}$$

其中，$\circ$代表逐像素积，$\tilde{P}_{min}^T=\tilde{P}\left(I^{t+1,n}\right)\circ M_1\left(I^{t+1,n}\right)$和$\tilde{P}_{max}^T=1-\tilde{P}\left(1-I^{t+1,n}\right)\circ M_2\left(I^{t+1,n}\right)$分别为更新后图像的 PMinP 和 PMaxP 值。计算出$\tilde{I}^{t+1,n}$后，变量G可以通过求解以下梯度子问题进行更新：

中国知网 https://www.cnki.net

$$G^{t+1,n+1} = \arg\min_{G} \alpha \left\| \nabla \tilde{I}^{t+1,n} - G \right\|_2^2 + \mu \| G \|_0 \tag{5-20}$$

这有显式解析解：

$$G^{t+1,n+1}(p,q) = \begin{cases} 0, & \left(\nabla \tilde{I}^{t+1,n}(p,q) \right)^2 < \mu / \alpha \\ \nabla \tilde{I}^{t+1,n}(p,q), & \text{otherwise} \end{cases} \tag{5-21}$$

最后，通过求解以下 L_2 优化问题来更新潜在图像：

$$I^{t+1,n+1} = \arg\min_{I} \left\| I \otimes k^i - B \right\|_2^2 + \alpha \left\| \nabla I - G^{t+1,n+1} \right\|_2^2 \tag{5-22}$$

其可以通过快速傅里叶变换（Fast Fourier Transform，FFT）有效地解决

$$I^{t+1,n+1} = \mathcal{F}^{-1} \left(\frac{\overline{\mathcal{F}\left(k^i\right)} \circ \mathcal{F}(B) + \alpha \mathcal{F}_{G^{t+1,n+1}}}{\overline{\mathcal{F}\left(k^i\right)} \circ \mathcal{F}\left(k^i\right) + \alpha \overline{\mathcal{F}(\nabla)} \circ \mathcal{F}(\nabla)} \right) \tag{5-23}$$

其中 $\mathcal{F}_{G^{t+1,n+1}} = \overline{\mathcal{F}\left(\nabla_h\right)} \circ \mathcal{F}\left(G_h^{t+1,n+1}\right) + \overline{\mathcal{F}\left(\nabla_v\right)} \circ \mathcal{F}\left(G_v^{t+1,n+1}\right)$；$\nabla = \left(\nabla_h, \nabla_v\right)$ 和 $G = \left(G_h, G_v\right)$ 分别表示水平方向和垂直方向的图像梯度；$\mathcal{F}$ 和 $\mathcal{F}^{-1}$ 分别为 FFT 和逆 FFT。

5.3.2 模糊核的估计

给定潜在图像的中间估计 I^i，优化模糊核 k 是一个最小二乘问题。为了更准确，本节在梯度空间中估计模糊核[64]。因此，将模型（5-14）替换为：

$$k^{i+1} = \arg\min_{k} \left\| \left(\nabla I^i \right) \otimes k - \nabla B \right\|_2^2 + \gamma \| k \|_2^2 \tag{5-24}$$

这是一个二次形式，类似于现有的方法[18,65]，可以通过 FFT 来计算:

$$k^{i+1} = \mathcal{F}^{-1} \left(\frac{\overline{\mathcal{F}\left(\nabla I^i\right)} \circ \mathcal{F}(\nabla B)}{\overline{\mathcal{F}\left(\nabla I^i\right)} \circ \mathcal{F}\left(\nabla I^i\right) + \gamma} \right) \tag{5-25}$$

在得到模糊核后，将 k^{i+1} 的负元素设为零，并对 k^{i+1} 进行归一化。

中国知网 https://www.cnki.net

5.3.3 算法实现的细节

为处理大尺度的模糊核，本章采用由粗到精的图像金字塔策略进行模糊核估计。各层的去模糊过程如算法 5.1 所示。为使公式（5-15）中的增广目标函数有效逼近原始目标函数（5-13），理想情况下应令α值接近无穷大（$\alpha \to \infty$）。但直接使用较大的值$\alpha_{\max}$会导致交替优化过程收敛缓慢。为此，本节对α使用一个延续过程：从较小的α值开始，逐步乘以大于 1 的增长因子τ，直到达到所需的大目标值$\alpha_{\max}$，从而在计算效率与优化精度之间取得平衡。此外，公式（5-17）中 PMinP 与逆 PMaxP 的阈值对应于两个非凸L_0正则项，因此公式（5-16）整体为非凸优化问题，易受初始值或参数影响而陷入局部最小值。为增强稳定性，算法 5.1 在多尺度框架的前几个尺度中采用软阈值代替硬阈值进行优化，随后再切换回硬阈值。由于软阈值对应于凸L_1正则项，该“先松后紧”的策略提升稳定性。

算法 5.1 基于动态极值先验的盲去模糊算法

Input:模糊图像 B

Output:估计的模糊核 $\hat{k}$**，估计的中间潜在图像** $\hat{I}$

01:生成初始模糊核 k^0;

02:**for** $i = 0 : max_iter - 1$ **do**

03: $\alpha \leftarrow 2\mu, I^0 \leftarrow B$

04: **while** $\alpha \le \alpha_{\max}$ **do**

05: $I^{t+1,0} \leftarrow I^t$

06: **for** $n = 0 : N - 1$ **do**

07: 通过 FCM 获取集合 $\mathcal{M}$ 和 $\mathcal{N}$;

08: 根据公式（5-18）计算掩码 $M_1(I^{t+1,n})$ 和 $M_2(I^{t+1,n})$

09: 根据公式（5-17）计算 $\tilde{P}(I^{t+1,n})$ 和 $\tilde{P}(1-I^{t+1,n})$

10: 根据公式（5-19）更新 $\tilde{I}^{t+1,n}$

11： 根据公式（5-21）更新 $G^{t+1,n+1}$

12: 根据公式（5-23）更新 $I^{t+1,n+1}$

13: **end**

14: $I^{t+1} \leftarrow I^{t+1,N}$， $\alpha \leftarrow \tau\alpha$

15: **end**

16: $I^{i+1} \leftarrow I^{t+1}$

17: 根据公式（5-25）求解模糊核 k^{i+1}

18:**end**

19: $\hat{k} \leftarrow k^{max_iter}, \hat{I} \leftarrow I^{max_iter}$

中国知网 https://www.cnki.net

5.4 实验结果与分析

5.4.1 实验设置

在所有实验中，与文献[66]一致，设置$\tau=2$，$N=3$，$\alpha_{\max}=10^5$，$\mu=4\times10^{-3}$，$\gamma=2$，$max_iter=5$以及$r=0.025\cdot mean(m,n)$。PMinP 和 PMaxP 的阈值参数初始分别设置为 0.1 和 0.2，并逐渐降低到其平均值。需要指出的是，上述参数的最优值通常依赖于清晰图像的分布、所使用的模糊核模型以及针对非凸去模糊问题的优化算法等因素。因此，确定这些参数的精确最优值可能具有挑战性。与许多现有的盲去模糊方法相似，这些参数值在实践中通常是通过经验来选择的。类似于文献[18]中的做法，本章首先使用提出的算法来估计模糊核，然后应用非盲去模糊方法[17]来恢复最终的潜在图像。为了进一步提高去模糊效果，可以通过伪影抑制技术[62]增强非盲去模糊方法[17]的性能，从而实现更加精细的图像细节恢复。

5.4.2 数据集与评价指标

为了评估本章提出的算法性能，本节在三个基准数据集[60,113,128]上进行了实验，并将实验结果与最先进的算法进行了比较。此外，本节还在特定领域的图像上评估了提出的方法，并与为这些特定场景定制的算法进行了比较。为全面评估不同方法的性能，本节使用了 4 个指标，包括 PSNR、SSIM、积累误差比（Cumulative Error Ratio，CER）[60]和核相似度（Kernel Similarity，KS）[129]。PSNR 和 SSIM 是常用的图像质量评价指标，下面将简单介绍一下 CER 和 KS。

（1）CER

在图像盲去模糊问题中，平方误差和（Sum of Square Distance，SSD）是一种常用的度量指标，用于衡量估计结果与真实图像之间的差异。其基本思想是对每个像素位置处估计值与真实值之间的误差平方求和，从而反映整体恢复图像的精度。设盲去模糊算法根据模糊核反卷积所获得的恢复图像为L，真实图像为G，则 SSD 定义为：

$$SSD(L,G)=\sum_{i=1}^{m}\sum_{j=1}^{n}\left(L(i,j)-G(i,j)\right)^2 \tag{5-26}$$

其中，(i,j)表示图像中的像素坐标。SSD 越小，表示恢复图像与真实图像之间的差异越小，算法性能越优。然而，在模糊核较大的情况下，即便使用真实模糊核进行反卷积，误差仍可能较大，影响评价的准确性。为规范这种影响，本章采用

中国知网 https://www.cnki.net

CER 作为更稳健的性能评价指标，即：将使用估计模糊核所得到的反卷积误差与使用真实模糊核所得到的反卷积误差进行比值计算。设使用真实模糊核反卷积得到的图像为 R，则 CER 计算方法如下:

$$CER = \frac{\sum_{i=1}^{m}\sum_{j=1}^{n}\left(L(i,j)-G(i,j)\right)^2}{\sum_{i=1}^{m}\sum_{j=1}^{n}\left(R(i,j)-G(i,j)\right)^2} \tag{5-27}$$

（2）KS

KS 是衡量估计模糊核与真实模糊核相似度的重要指标。由于图像复原高度依赖模糊核的准确性，盲去模糊本质上可视为模糊核估计问题。KS 通过计算两者之间的归一化最大相关性，直接反映估计核与真实核的一致程度，是评估模糊核估计算法性能的重要度量。设 K 表示真实模糊核，$\hat{K}$ 表示估计的模糊核，τ 为模糊核中像素的坐标，则 KS 定义为：

$$KS(K,\hat{K},\tau) = \max_{\vartheta}\frac{\sum_{\vartheta}K(\tau)\cdot\hat{K}(\tau+\vartheta)}{\|K\|_2^2\cdot\|\hat{K}\|_2^2} \tag{5-28}$$

其中，ϑ 表示模糊核位移，当 τ 超出模糊核支撑域范围时，$K(\tau)=\hat{K}(\tau+\vartheta)=0$。

5.4.3 基准数据集的实验结果

（1）Levin 等人[27]的数据集

Levin 等人[27]提供的数据集由 4 幅灰度图像与 8 个均匀模糊核卷积生成，共计 32 幅模糊图像。为了评估所提出方法的性能，本章将其与多种先进的盲去模糊方法[60,65,66,130–133]进行了比较。与算法[134]类似，所有实验统一采用非盲反卷积方法[135]来生成最终的清晰图像。为实验定量对比，表 5.1 列出了 32 幅图像的平均 CER、平均 KS、平均 PSNR 和平均 SSIM。方法[60,130,132]的实验结果采用文献[136]中报告的数据，而方法[65,66,131,133]的结果则基于作者公开代码的默认配置生成。从表 5.1 可以看出，本章算法在这个基准数据集上相较于最先进的方法具有最好的表现。在 PSNR 指标上，相较于次优算法显著提升了 0.62dB；在 SSIM 指标上，相较于次优算法提升了 0.59%；在 CER 和 KS 指标上分别提升了 6.35%和 2.7%。此外，图 5.5 展示了由所提出的算法在该数据集上估计的模糊核的可视化效果。可以看出，本章算法估计的模糊核与真实模糊核非常接近。

中国知网 https://www.cnki.net

表 5.1 不同方法在 Levin 数据集上的定量比较

Table 5.1 Quantitative comparisons with different methods on the Levin dataset

方法	CER↓	KS↑	PSNR↑	SSIM↑
Ground-truth kernel	1.0000	1.0000	34.5345	0.9492
Cho and Lee[132]	1.7113	0.7412	30.5661	0.8966
Levin et al. [27]	1.7724	0.7546	30.8004	0.9092
Xu and Jia[130]	1.4898	0.7955	31.6754	0.9163
Yan et al.[65]	1.2436	0.8427	32.6837	0.9297
Li et al.[133]	1.3823	0.8034	31.4782	0.9136
Liu et al.[131]	1.3530	0.8118	31.5224	0.9133
Wen et al.[66]	1.2603	0.8306	32.4450	0.9344
本章方法	**1.1801**	**0.8697**	**33.3052**	**0.9403**

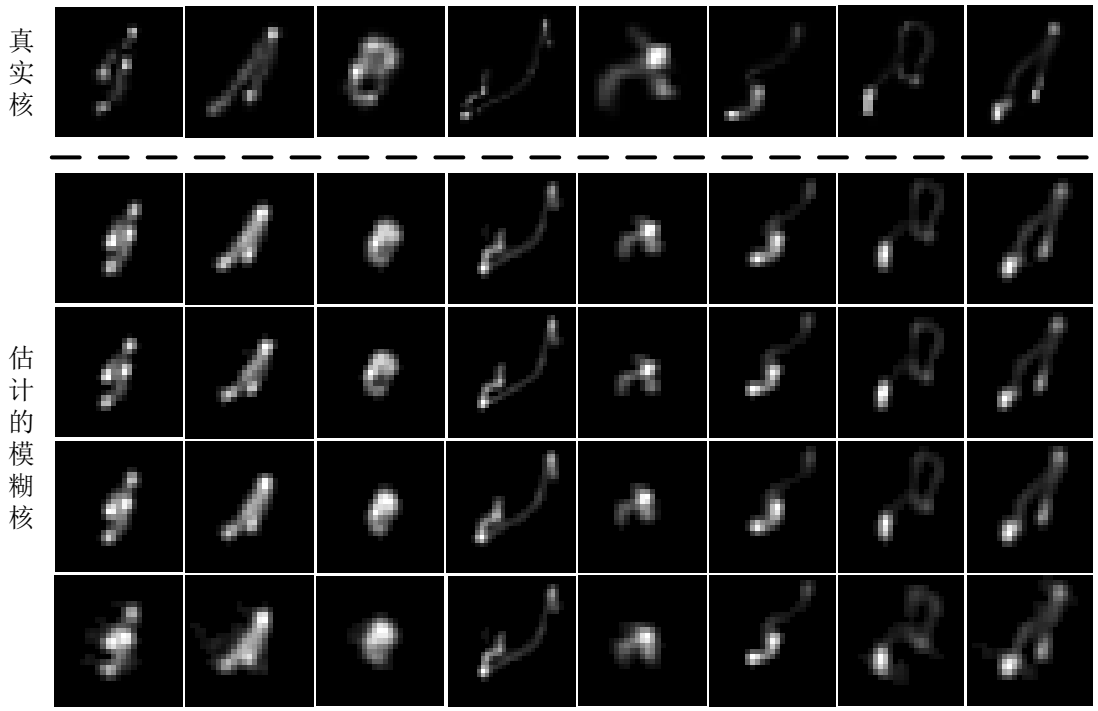


图 5.5 Levin 数据集上估计的模糊核

Figure 5.5 Estimated blur kernels on the Levin dataset

（2）Köhler 等人[128]的数据集

Köhler 等人[128]构建的数据集由 4 幅原始图像与 12 个模糊核卷积生成，共包含 48 幅模糊图像。该数据集的特点在于每幅图像均配有沿真实摄像机运动轨迹

中国知网 https://www.cnki.net

拍摄的 199 张清晰参考图像，可用于计算去模糊结果的 PSNR 进行性能评估。本节评估了本章方法和多个现有算法[59,62,63,65,66,130,132,137,138]的性能。需要指出，除了文献[65,66]和本章所提出的方法外，其他方法的实验结果直接采用文献[128]中公布的数据。文献[65,66]的 PSNR 值是根据作者在其网站上提供的去模糊结果计算出来的。图 5.6 给出了各方法在 PSNR 指标下的定量对比结果。可以看出，本章方法在该数据集上取得了最高的平均 PSNR 值（30.12dB），表明所本章方法在应对真实相机运动模糊方面具有较强的恢复能力和稳定性。

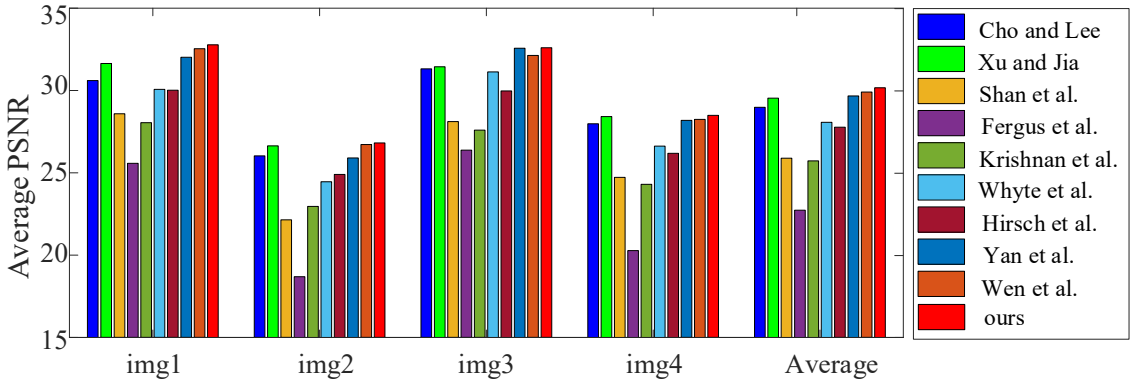


图 5.6 不同方法在 Köhler 数据集上的定量比较

Figure 5.6 Quantitative comparison of different methods on the Köhler dataset

（3）Lai 等人[113]的数据集

Lai 等人[113]构建的数据集包括 100 幅模糊图像，分为五类，即人造图像、自然图像、人像图像、饱和图像和文本图像，每类各含 20 幅。为评估所提方法的性能，本节将所提算法与当前主流的盲去模糊算法[18,64–66,130,132,136,139,140]进行了对比实验。其中，方法[18,64,130,132,136,139,140]的实验结果采用文献[136]中报告的数据，方法[65,66]的结果由其官网公开的代码生成。

表 5.2–5.4 分别汇总了以上方法在 Lai 等人[113]数据集中五个子类别下的 PSNR、SSIM 和 KS 指标的定量对比结果。实验结果清晰表明，本章所提出的动态极值先验盲去模糊方法在所有子类别中均实现了最优的平均性能指标，显示出方法在不同图像类型和模糊形式下的高度适应性和鲁棒性。具体分析如下：（1）在 PSNR 指标上，本章方法的平均 PSNR 达到最高水平，相较于第二名算法，平均提升为 0.58 dB。该提升表明所提方法在细节还原、边缘重建和整体清晰度方面具有更强的表达与恢复能力，能够更有效地抑制模糊引起的信息损失。（2）在 SSIM 指标上，本章方法的平均得分比次优方法高出 3.82%，显示本章方法在保持图像结构完整性、边缘连续性和纹理一致性方面表现优越，特别是在处理文本图像和自然图像时，能够更好地重构局部细节和全局结构。（3）在 KS 指标上，本

中国知网 https://www.cnki.net

章方法也取得了最优表现，平均得分相较第二名方法提升了 0.28。该提升进一步证明了本章方法在模糊核估计阶段的精度更高，所恢复图像在质量上具有更坚实的理论基础。

表 5.2 不同方法在 Lai 数据集上的 PSNR 值

Table 5.2 PSNR values of different methods on the Lai dataset

方法	人造图像	自然图像	人像图像	饱和图像	文本图像	平均
Cho and Lee[132]	16.35	20.14	19.90	14.05	14.87	17.06
Xu and Jia[130]	19.23	23.03	25.32	14.79	18.56	20.18
Xu et al.[64]	17.99	21.58	24.40	14.53	17.64	19.23
Michaeli et al.[139]	17.43	20.70	23.35	14.14	16.23	18.37
Perrone et al.[140]	17.41	21.04	22.77	14.24	16.94	18.48
Pan et al.[18]	18.59	22.60	24.03	16.52	17.42	19.89
Yan et al.[65]	20.66	**24.95**	**28.76**	17.33	20.02	22.34
Wen et al.[66]	20.41	24.74	27.87	17.38	19.36	21.95
Ren et al.[136]	20.08	22.50	27.41	16.58	19.06	21.13
本章方法	**20.98**	24.93	28.02	**17.59**	**23.06**	**22.92**

表 5.3 不同方法在 Lai 数据集上的 SSIM 值

Table 5.3 SSIM values of different methods on the Lai dataset

方法	人造图像	自然图像	人像图像	饱和图像	文本图像	平均
Cho and Lee[132]	0.3890	0.5198	0.5560	0.4927	0.4429	0.4801
Xu and Jia[130]	0.6540	0.7542	0.8517	0.5632	0.7171	0.7080
Xu et al.[64]	0.5986	0.6788	0.8133	0.5383	0.6677	0.6593
Michaeli et al.[139]	0.4189	0.5116	0.6999	0.4914	0.4686	0.5181
Perrone et al.[140]	0.5507	0.6764	0.7347	0.5107	0.5927	0.6130
Pan et al.[18]	0.5942	0.6984	0.7719	0.6322	0.6193	0.6656
Yan et al.[65]	0.7503	0.8580	**0.9127**	0.6884	0.7166	0.7852
Wen et al.[66]	0.7438	0.8442	0.8917	0.6893	0.6897	0.7717
Ren et al.[136]	0.7338	0.7183	0.8784	0.6165	0.7126	0.7319
本章方法	**0.7719**	**0.8581**	0.8943	**0.7061**	**0.8867**	**0.8234**

中国知网 https://www.cnki.net

表 5.4 不同方法在 Lai 数据集上的 KS 值

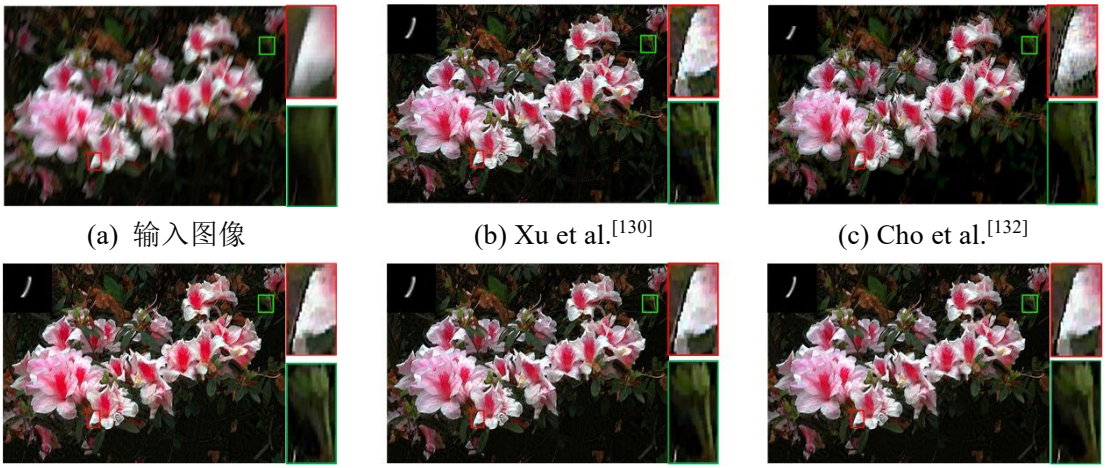
Table 5.4 KS values of different methods on the Lai dataset

方法	人造图像	自然图像	人像图像	饱和图像	文本图像	平均
Cho and Lee[132]	0.4850	0.5300	0.4796	0.5258	0.4870	0.5015
Xu and Jia[130]	0.7982	0.8043	0.7327	0.6161	0.7877	0.7478
Xu et al.[64]	0.6966	0.7626	0.7096	0.6014	0.7126	0.6966
Michaeli et al.[139]	0.6755	0.7312	0.6972	0.5600	0.6478	0.6623
Perrone et al.[140]	0.6712	0.7513	0.6900	0.5612	0.6502	0.6648
Pan et al.[18]	0.7215	0.7812	0.7015	0.7702	0.7002	0.7349
Yan et al.[65]	0.8206	0.8112	**0.7712**	0.7855	0.8020	0.7981
Wen et al.[66]	0.8168	0.8003	0.7607	0.7900	0.8012	0.7938
Ren et al.[136]	0.8012	0.7923	0.7537	0.7815	0.7853	0.7828
本章方法	**0.8302**	**0.8138**	0.7637	**0.7915**	**0.8053**	**0.8009**

5.4.4 特定域图像的实验结果

（1）自然图像

本节在一幅真实的自然图像上测试了本章方法与最近最先进的盲图像去模糊方法[18,66,130,132]的性能。从图 5.7 中可以看出，与其他方法相比，本章方法生成的图像具有更少的伪影，且在视觉上呈现出更加可信的结构和纹理。



(a) 输入图像　(b) Xu et al.[130]　(c) Cho et al.[132]

(d) Pan et al.[18]　(e) Wen et al.[66]　(f) 本章方法

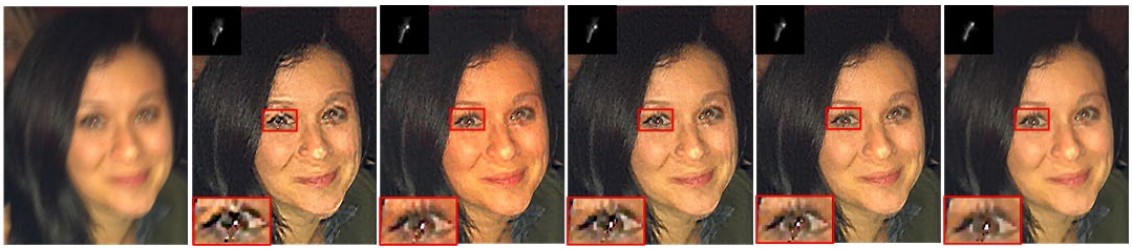
图 5.7 自然图像上的视觉比较

Figure 5.7 Visual comparison on a real natural image

中国知网 https://www.cnki.net

（2）人脸图像

由于人脸图像中缺乏足够的边缘和纹理信息，用于模糊核估计的特征较少，因此，人脸图像去模糊具有极大的挑战性。如图 5.8 所示，本章提出的动态极值先验方法在处理人脸图像时展现出显著优势。与当前主流的先进去模糊方法[18,65,66,130]相比，本章方法生成了更精细的人脸去模糊图像。



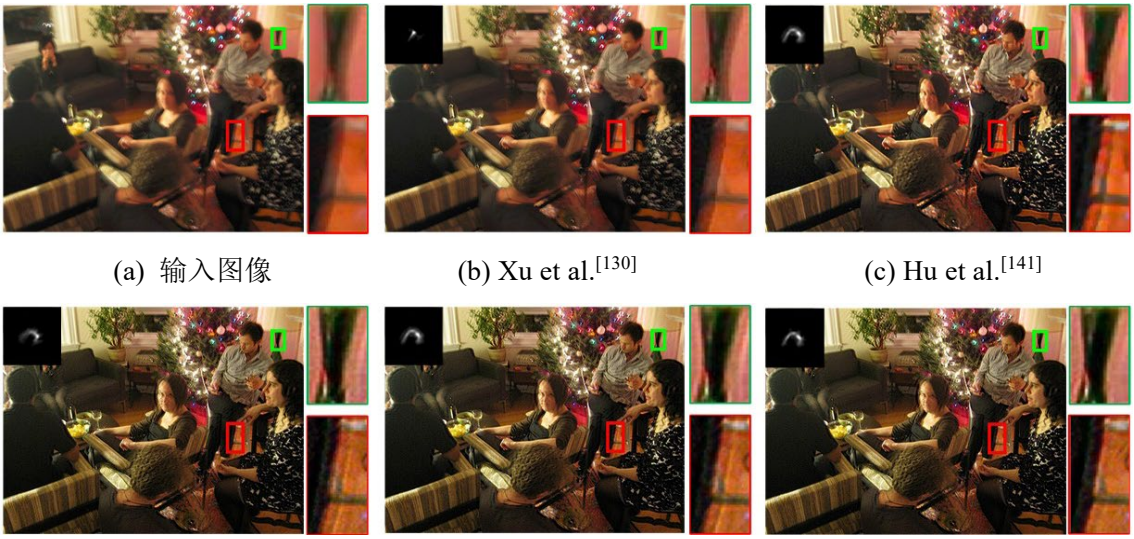
(a) 输入图像 (b) Xu et al.[130] (c) Pan et al.[18] (d) Yan et al.[65] (e) Wen et al.[66] (f) 本章方法

图 5.8 人脸图像上的视觉比较

Figure 5.8 Visual comparison on a face image

（3）低照度图像

低照度图像由于整体亮度不足，往往伴随局部区域的过曝或欠曝，从而引入饱和像素。这些饱和区域会破坏图像的灰度分布和结构信息，严重干扰模糊核的准确估计，导致现有盲去模糊算法在该类图像上表现不佳[141]。如图 5.9 所示，与当前先进的去模糊算法[65,66,130,141]相比，本章方法生成的图像呈现出更自然的视觉观感。



(a) 输入图像 (b) Xu et al.[130] (c) Hu et al.[141]

(d) Yan et al.[65] (e) Wen et al.[66] (f) 本章方法

图 5.9 低光照图像上的视觉比较

Figure 5.9 Visual comparison on a low-illumination image

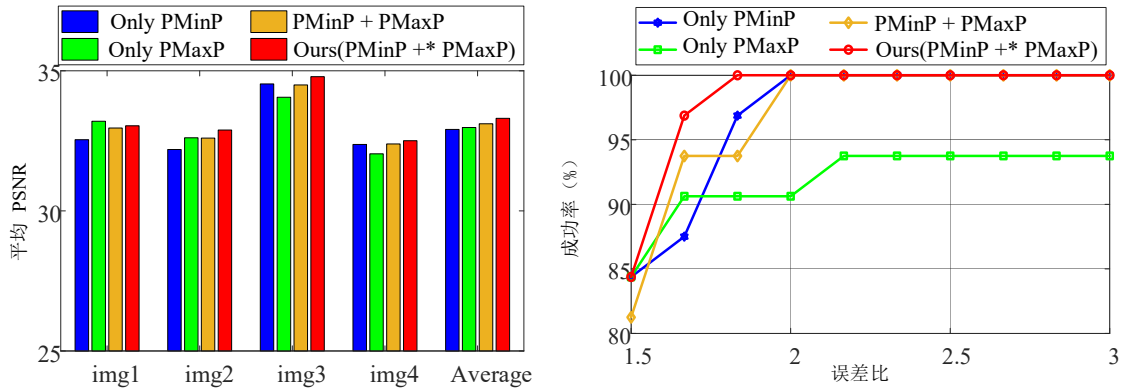
中国知网 https://www.cnki.net

5.4.5 消融实验

本节展示了所提出的动态极值先验的有效性，并讨论了本章提出的优化方案的有效性。在所有实验中，均采用 Levin 等人[27]构建的数据集，并使用相同的非盲去模糊方法[16]。

（1）动态极值先验的有效性

为验证本章提出的动态先验的有效性，图 5.10（a）显示了本章方法与基于 PMinP、基于 PMaxP 和直接结合 PMinP-PMaxP 的方法在 PSNR 上的定量评价结果。可以看出，本章方法在 PSNR 指标上取得了最高的性能。此外，该方法在 CER 指标上也表现最佳，如图 5.10（b）所示。本章方法的性能达到 100%时，而紧随其后的次优方法在相同条件下仅达到 97%的性能水平。这些结果表明，所提出的基于动态极值先验的算法能够有效提升图像盲去模糊的性能。



(a) 平均PSNR的比较　　(b) 成功率的比较

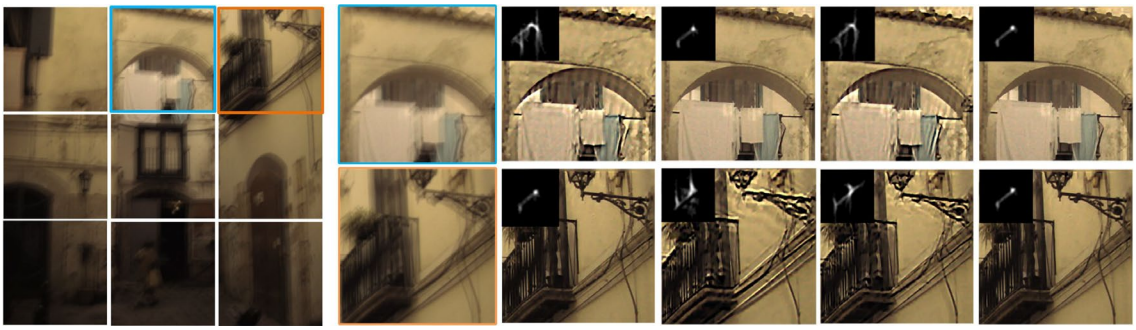
图 5.10 不同先验对去模糊结果的定量比较

Figure 5.10 Quantitative comparison of deblurring results using different priors

图 5.11 展示了使用不同先验去模糊结果的视觉比较，（a）是一幅模糊图像；（b）是来自（a）的两个图像块；（c）是单独使用 PMinP；（d）是单独使用 PMaxP；（e）是同时使用 PMinP 和 PMaxP；（f）是动态使用 PMinP 和 PMaxP。实验结果表明，PMinP 先验仅在下方子图像中有效，PMaxP 先验则仅在上方子图像中表现良好，而将两者直接结合的方法在两个子图像中效果均不理想。这主要是因为上方子图像包含更多高强度像素，大模糊核会将低强度像素与部分高强度像素混合，使得低强度像素稀疏性降低，从而削弱了 PMinP 先验的作用，导致去模糊失败；而下方子图像主要以低强度像素为主，PMaxP 先验受模糊干扰后引发明显的振铃伪影。同时使用 PMinP 和 PMaxP 的方法削弱了各自先验的独特作用，导致两类子图像中均产生振铃伪影。相比之下，本章提出的动态极值先验方法通过动

中国知网 https://www.cnki.net

态聚类机制，自适应选择 PMinP 或 PMaxP 先验，充分发挥各自优势，在两类图像区域中均获得理想的去模糊效果。



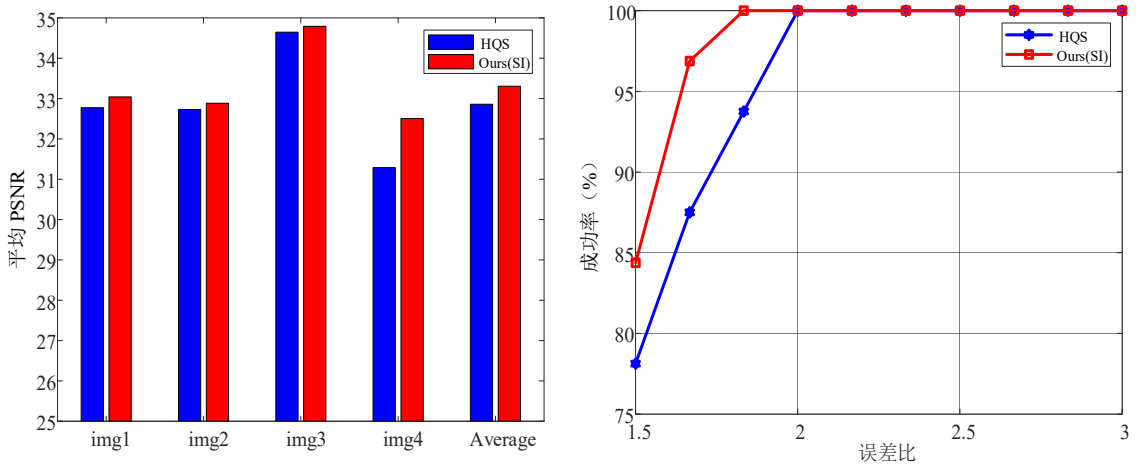
(a) (b) (c) (d) (e) (f)

图 5.11 不同先验对去模糊结果的视觉比较

Figure 5.11 Visual comparison of deblurring results using different priors

（2）优化算法的有效性

本节验证了所提出的基于 SI 的优化算法在求解本章提出的正则化问题时，相较于传统的 HQS 算法，不仅计算更为简单，还能取得更优的性能。为全面评估所提出算法的有效性，本节设计了两种实验方案：一种基于传统的 HQS 算法，用于求解潜在图像的子问题；另一种则采用 SI 进行优化，用以解决潜在图像估计的子问题。为了更客观地比较两种算法的性能，本节从 PSNR 和 CER 两个关键指标对其进行了定量评估。实验结果如图 5.12 所示，可以看到所提出的 SI 算法在 PSNR 和 CER 两个方面均优于 HQS 算法，进一步验证了其在处理图像盲去模糊问题时的优越性。



(a) 平均PSNR的比较　　(b) 成功率的比较

图 5.12 稀疏诱导算法的有效性

Figure 5.12 Effectiveness of the sparse inducing algorithm

中国知网 https://www.cnki.net

5.4.6 收敛性分析与运行时间比较

由于算法 5.1 中所涉及的目标函数具有非线性和高度非凸的特性，其收敛性可能引发一定的质疑。为验证本章算法的收敛性能，本节在 Levin 等人提出的数据集[27]上进行了系统的定量实验分析。具体而言，本节计算了公式（5-11）中能量函数值的变化趋势，并评估了最精细图像尺度下的平均 KS 指标。实验结果如图 5.13 所示，能量函数在不足 20 次迭代内迅速收敛，且 KS 值在迭代过程中持续提升，说明模糊核估计越来越准确。这一实验充分证明了本章提出的优化框架的有效性与稳定性。

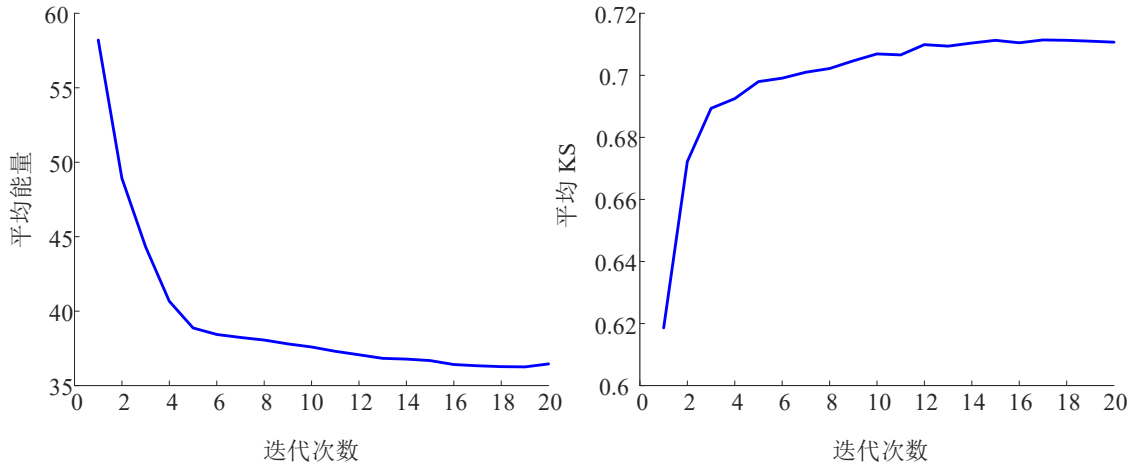


图 5.13 所提算法的收敛性分析

Figure 5.13 Convergence analysis of the proposed algorithm

为进一步评估本章算法的实际应用价值，本节将其与多种主流去模糊算法[18,65,66,131]在运行时间上的表现进行了比较。所有实验均在相同的硬件环境下进行，具体为：MATLAB 平台，搭载 AMD Ryzen 7 3.20 GHz CPU 和 16GB 内存的 PC 机。表 5.5 总结了各方法在统一测试条件下的运行时间统计结果。从表中可见，与文献[18,65,131]中采用 HQS 优化策略的算法相比，本章算法在运行时间上具有显著地优势。特别地，相较于文献[65]所提出的计算重叠块先验的方法，本章所采用的基于不重叠图像块的处理方式在面对高分辨率图像时显著加速，实验结果表明在大尺寸图像处理任务中可实现超过 20 倍的加速效果，大幅提升了算法的实用性和效率。此外，为进一步验证所提出稀疏诱导优化策略的有效性，本节还构建了结合动态极值先验与 HQS 优化策略的对比模型。实验结果显示，该 HQS 版本在保持相似图像质量的前提下，其平均运行时间较本章所提算法延长超过 10 倍，进一步证明了稀疏诱导（SI）优化方法在效率上的显著优势。

中国知网 https://www.cnki.net

表 5.5 不同方法运行时间（秒）比较

Table 5.5 Comparison of running times (in seconds) of different methods

方法	256×256	512×512	800×800
Pan et al.[18]	123.44	460.11	953.69
Yan et al.[65]	220.37	721.92	1717.78
Liu et al.[131]	14.85	47.97	121.42
本章方法（HQS）	106.23	367.12	860.35
本章方法（SI）	**12.25**	**31.59**	**61.65**

5.5 本章小结

本章针对传统图像先验方法（如暗通道先验与极通道先验）在盲图像去模糊任务中建模能力有限的问题，提出了一种基于动态极值先验的盲去模糊算法。与依赖静态图像特征的传统方法不同，本章算法在迭代优化过程中充分挖掘模糊图像中的极值像素信息，并引入图像块级别的动态聚类机制，对图像块中极值像素进行自适应建模与调整。该动态建模框架有效增强了算法在面对由摄像机抖动引起的全局模糊场景中的适应能力，显著提升了去模糊的准确性与鲁棒性。

在实验验证方面，本章方法在三个典型的盲去模糊基准数据集[60,113,128]上均取得优异表现，平均 PSNR 相较当前主流方法提升 0.53dB，充分验证了本章方法在图像细节恢复、边缘清晰度与整体视觉质量方面的优势。同时，在处理特定领域的图像类别（如自然图像、人脸图像和低照度图像）时，本章方法亦能有效保持图像结构一致性与纹理还原度，生成更加自然、真实的复原图像。

尽管取得良好性能，本章方法仍存在一定的局限性。由于动态极值先验仍属于手工设计的先验形式，其对复杂模糊模式（尤其是动态物体引起的非均匀模糊）建模能力仍显不足，难以全面捕捉模糊场景的非线性与多样性特征，导致在某些复杂实际场景中的表现尚有提升空间。为进一步克服上述限制，下一章将以动态模糊场景为研究重点，提出一种基于数据驱动的频率先验建模方法。该方法通过深度学习框架自适应学习图像的多频率特征分布，用以引导扩散模型进行高质量图像重建，从而提升方法在多样化模糊场景下的适应性与复原能力。

中国知网 https://www.cnki.net

第 6 章 基于频率先验的动态场景去模糊方法

6.1 引言

上一章针对由相机抖动引起的全局均匀运动模糊问题，提出了一种基于传统优化的盲去模糊算法。该方法通过构建手工设计的图像与模糊核先验，实现了较为有效的图像恢复。然而，当模糊具有明显的空间变化特征，尤其是在动态场景中由物体运动引发的复杂非均匀模糊情况下，传统先验模型在表达模糊过程的多样性与非均匀性方面存在明显不足，从而限制了去模糊性能的进一步提升。

为解决上述问题，本章进一步探索基于生成模型的图像运动去模糊方法，旨在构建具备更强建模能力与泛化能力的去模糊框架。近年来，扩散模型（Diffusion Models, DMs）凭借其出色的生成能力，逐渐被引入图像去模糊任务中[142]。典型方法通常将模糊图像作为条件输入，引导 DM 的逆向去噪过程，以生成清晰图像（见图 6.1（a））。部分研究[143]进一步引入预测图像作为条件（见图 6.1（b）），以提高复原质量。然而，该类方法高度依赖预测图像的准确性，易导致结构缺失或伪影等问题。相比之下，融合模糊图像与预测图像生成的鲁棒特征作为引导条件的策略[97]（见图 6.1（c）），在去模糊任务中展现出更好的稳定性与复原能力。

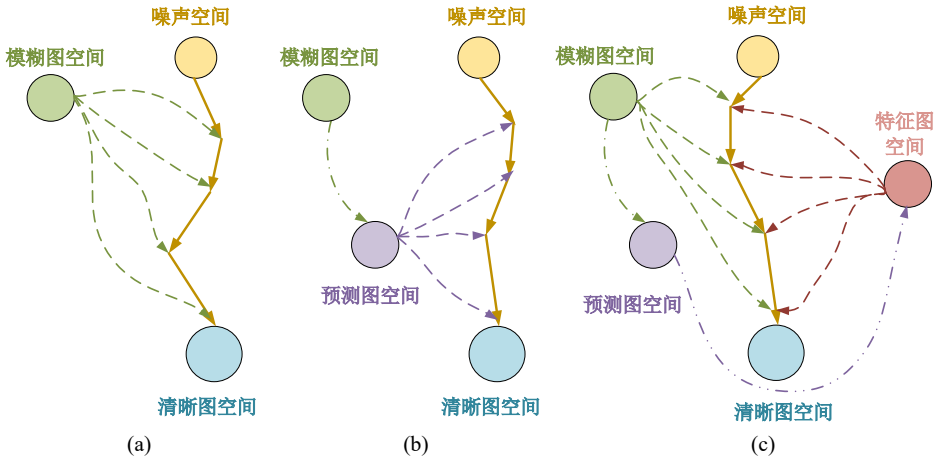


图 6.1 扩散模型中不同条件的比较

Figure 6.1 Comparison of different conditions in the diffusion model

本章提出一种基于频率先验的图像运动去模糊方法，通过引导 DM 的反向去噪过程，实现对动态模糊场景的高质量复原。该方法的核心在于将多层次小波域中的频率信息作为先验引入，以增强 DM 对模糊细节的建模能力。具体而言，首

中国知网 https://www.cnki.net

先设计主频率恢复网络，基于 CNN 生成初步的清晰图像估计，使其包含比原始模糊图像更丰富的频率信息（见图 6.2）。为进一步提升频率恢复能力，本章在小波域中构建损失函数，从频率层面加强图像还原效果。随后，构建多频率特征提取器，通过多层次小波变换从预测图像中提取不同尺度下的频率特征，作为先验信息提升图像的多尺度表征能力。所提频率特征通过交叉注意力机制逐层融合至 DM 的反向去噪网络中，有效增强模型在各尺度下的恢复能力，尤其在处理真实动态场景中的复杂非均匀模糊时展现出显著优势。

本章的主要贡献总结如下：

（1）提出一种频率先验引导的扩散模型框架，通过引入小波域的多层次频率特征，有效引导扩散模型实现高质量的图像恢复；

（2）设计主频率恢复网络，在小波域构建频率损失函数，增强初始估计中频率成分的表达能力；

（3）构建多频率特征提取与融合机制，通过交叉注意力将频率先验逐层引入扩散模型去噪网络，实现多尺度、多频率的细节恢复，适应复杂动态模糊场景。

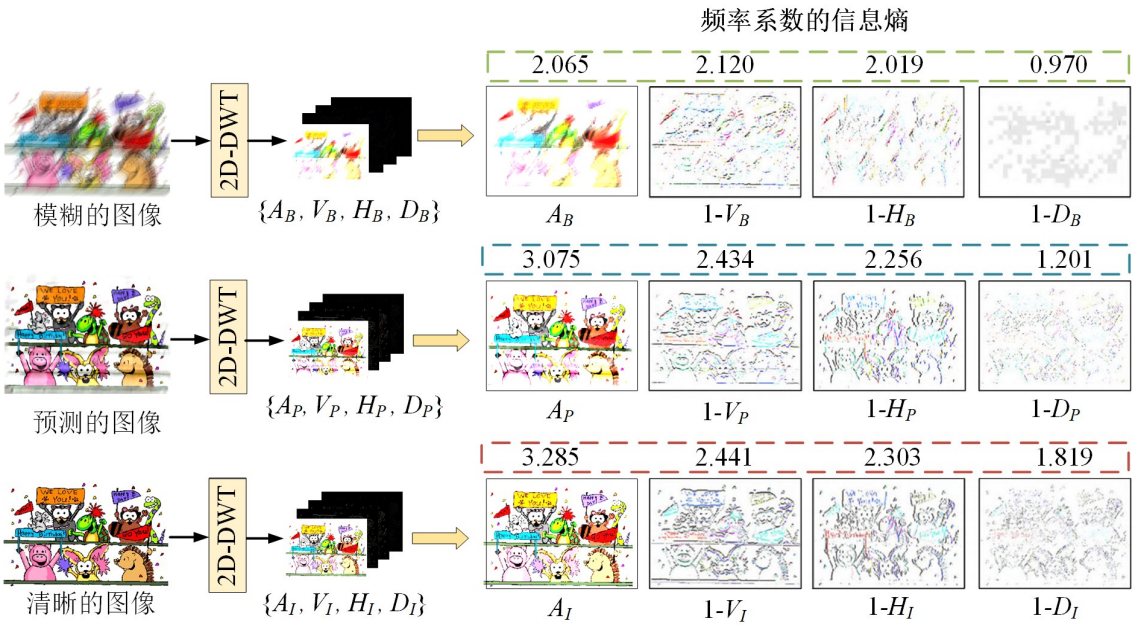


图 6.2 模糊、预测和清晰图像的小波系数比较

Figure 6.2 Comparison of wavelet coefficients for blurry, predicted, and clear images

6.2 频率先验引导的扩散模型

图 6.3 展示了本章提出图像去模糊方法的整体框架。本章方法基于去噪扩散隐式模型（Denoising Diffusion Implicit Model，DDIM）[47]，包括一个随机前向扩散过程和一个确定性反向去噪过程。在前向扩散阶段，噪声逐步添加至清

中国知网 https://www.cnki.net

晰图像中，使其退化为高斯噪声；在反向去噪阶段，利用条件去噪网络从噪声图像中复原清晰图像。在本章方法中，模糊图像与其对应的多频率先验信息共同作为条件输入，辅助扩散模型实现高质量的图像恢复。

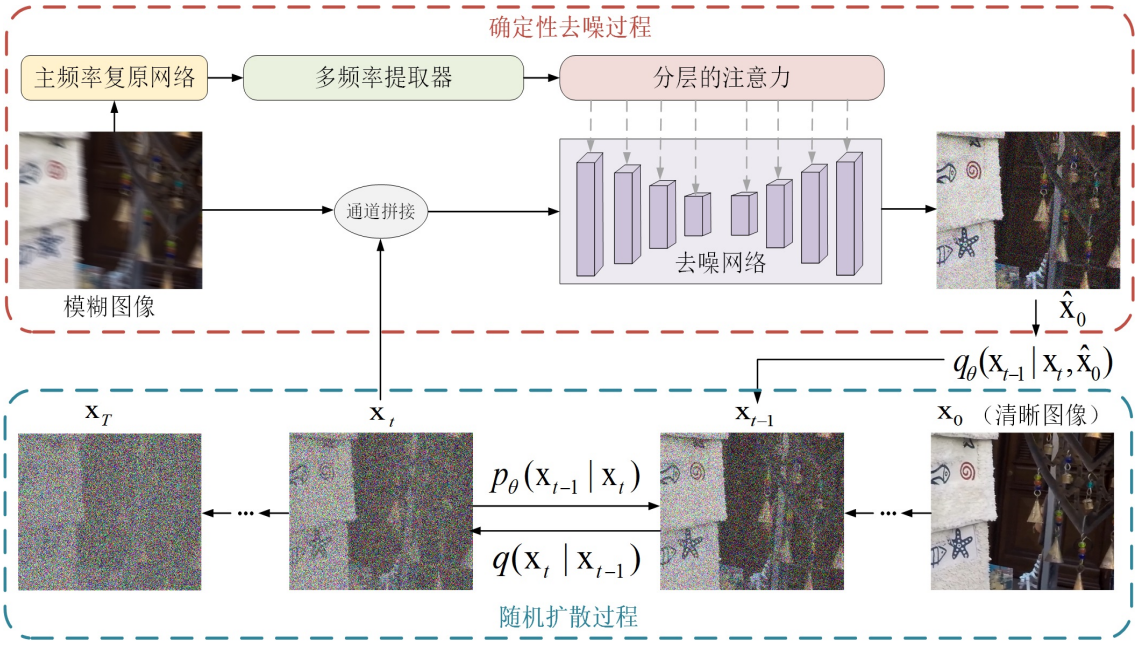


图 6.3 频率先验引导的扩散模型框架

Figure 6.3 Framework of the diffusion model guided by frequency priors

6.2.1 随机前向扩散过程

设清晰图像样本的分布为 $x_0 \sim q(x_0)$，按照预设的方差调度 $\{\beta_1,\beta_2,\cdots,\beta_T\}$ 对图像逐步添加高斯噪声，构建一个参数化的马尔可夫链，用于模拟清晰图像退化为噪声图像的过程。该前向扩散过程可表示为：

$$\begin{aligned} q(x_t \mid x_{t-1}) &= \mathcal{N}(x_t;\sqrt{1-\beta_t}x_{t-1},\beta_t\mathbf{I}) \\ q(x_{1:T} \mid x_0) &= \prod_{t=1}^{T} q(x_t \mid x_{t-1}) \end{aligned} \tag{6-1}$$

其中，$t=1,2,\cdots,T$；$\beta_t \in (0,1)$ 是控制噪声方差的参数；x_t 是第 t 步的噪声图像；$\mathcal{N}$ 表示高斯分布。当 T 足够大时，x_T 接近纯高斯噪声。

通过重参数化的迭代推导，x_t 的概率分布可从 x_0 计算得到：

$$q(x_t \mid x_0) = \mathcal{N}(x_t;\sqrt{\bar{\alpha}_t}x_0,(1-\bar{\alpha}_t)\mathbf{I}) \tag{6-2}$$

中国知网 https://www.cnki.net

其中，$\alpha_t = 1-\beta_t$，$\bar{\alpha}_t = \prod_{i=1}^{t} \alpha_i$。随着扩散步数$t$增加，图像逐渐退化为纯高斯噪声$x_T \sim \mathcal{N}(0,\mathbf{I})$。扩散模型的目标是学习从该高斯噪声$x_T$中逐步恢复清晰图像$x_0$的反向过程。

在条件扩散框架中，为了生成受控图像样本，条件输入c被引入到去噪网络中。条件去噪过程学习从高斯分布恢复图像的马尔可夫链，其形式如下：

$$\begin{aligned} q(x_{t-1} \mid x_t, x_0) &= \mathcal{N}(x_{t-1}; \mu_t(x_t,t), \sigma_t^2 \mathbf{I}) \\ \mu_t(x_t,t) &= \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_t\right) \end{aligned} \tag{6-3}$$

其中，$\epsilon_t \sim \mathcal{N}(0,\mathbf{I})$表示$x_t$中的不确定噪声变量。神经网络$\epsilon_\theta(x_t,c,t)$用于估计每一步的噪声$\epsilon_t$。为训练网络，采用最大化变分下界（Variational Lower Bound，VLB）[46]的方法优化模型目标：

$$\begin{aligned} \mathcal{L} &= \mathbb{E}_{t,x_0,\epsilon_t}\left[\left\|\epsilon_t - \epsilon_\theta(x_t,c,t)\right\|_2^2\right] \\ &= \mathbb{E}_{t,x_0,\epsilon_t}\left[\left\|\epsilon_t - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{(1-\bar{\alpha}_t)}\epsilon_t, c, t)\right\|_2^2\right] \end{aligned} \tag{6-4}$$

6.2.2 确定性反向去噪过程

与标准扩散模型采用随机采样进行反向推理不同，DDIM 引入了一种确定性的反向生成过程$p_\theta(x_{t-1} \mid x_t)$，对噪声图像进行反向预测以生成清晰图像。给定第$t$步的图像$x_t$，由正向后验$q_\theta(x_{t-1} \mid x_t, \hat{x}_0)$描述的$x_{t-1}$生成过程为：

$$\begin{aligned} p_\theta(x_{t-1} \mid x_t) &= q_\theta\left(x_{t-1} \mid x_t, \hat{x}_0\right) = \mathcal{N}\left(x_{t-1}; \sqrt{\bar{\alpha}_{t-1}}\hat{x}_0 + \sqrt{1-\bar{\alpha}_{t-1}}\epsilon_\theta(x_t,c,t), 0\right) \\ \hat{x}_0 &= \frac{1}{\sqrt{\bar{\alpha}_t}}\left(x_t - \sqrt{1-\bar{\alpha}_t}\epsilon_\theta(x_t,c,t)\right) \end{aligned} \tag{6-5}$$

其中，$\hat{x}_0$是由神经网络推测得到的清晰图像估计，c为条件信息。

为了实现更加真实且符合原始模糊图像分布的去模糊复原效果，本章提出将模糊图像B与其对应的多频率先验信息Z联合作为条件输入，指导噪声预测网络$\epsilon_\theta(x_t,B,Z,t)$生成更符合真实分布的清晰图像。整体过程如下：首先，利用主频率恢复网络（Primary Frequency Recovery Network，PFRNet）对输入的模糊图像进行初步复原，以获得包含更多频率信息的粗略清晰估计；随后，提出多频率提取

中国知网 https://www.cnki.net

器（Multi-Frequency Extractor，MFE），利用多级二维 Haar 离散小波变换从该粗略估计中提取多尺度、多频段的频率系数，用于构建频率先验信息；最后，设计多频率交叉注意力（Multi-Frequency Cross Attention，MFCA）模块，将上述频率特征逐层融合至扩散模型的去噪网络（Diffusion Model Denoising Network，DMDNet）中，进一步增强其在动态复杂模糊场景中的恢复能力。算法 6.1 详细给出了模型的推理流程。

算法 6.1 本章算法的推理过程

Input: 模糊图像 B，PFRNet 模型 ϕ_θ，噪声预测器 ϵ_θ，总时间步长 T，隐式采样步长数 S

Output:复原的图像 x_0

01: $Z = \text{2D-DWT}（\phi_\theta(B)）$；//小波特征提取

02: $x_T \sim \mathcal{N}(0, \mathbf{I})$；//从标准高斯分布采样初始噪声图像

03: **for** $i = S:1$ **do**

04: $t = (i-1)\cdot T/(S-1)+1$；//当前时间步

05： **if** $i > 1$ **then**

06: $t_{next} = (i-2)\cdot T/(S-1)+1$；//下一个时间步

07: **else**

08: $t_{next} = 0$；//最后一个时间步

09: **end**

10: $x_{next} = \sqrt{\bar{\alpha}_{t_{next}}}\left(\frac{x_t - \sqrt{1-\bar{\alpha}_t}\epsilon_\theta(x_t, B, Z, t)}{\sqrt{\bar{\alpha}_t}}\right) + \sqrt{1-\bar{\alpha}_{t_{next}}}\epsilon_\theta(x_t, B, Z, t)$；

11: **end**

12: **returen** x_0

接下来，将依次详细介绍本章方法中三个关键模块的具体设计与实现，包括：PFRNet 的结构；MFE 的构建方法；以及 MFCA 模块的融合机制。

（1）PFRNet

为有效提取频率先验信息，本章设计了轻量级卷积神经网络 PFRNet，用于从模糊图像中生成清晰图像的初始估计。如图 6.4 所示，PFRNet 采用三层 U-Net 结构，在去模糊性能与计算效率之间取得良好平衡。其中，二维离散 Haar 小波变换（2D-DWT）用于实现高效的下采样，而二维逆小波变换（2D-IWT）用于上采样，确保图像分辨率的恢复。在网络瓶颈处引入三个残差模块（Residual Block，RB）以增强特征表达能力并提升预测图像质量。

中国知网 https://www.cnki.net

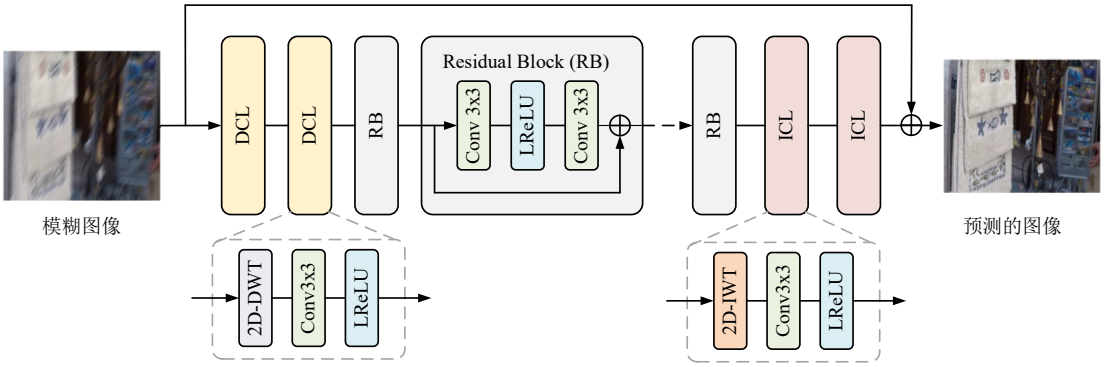


图 6.4 提出的 PFRNet 网络结构示意图

Figure 6.4 Illustration of the proposed PFRNet network architecture

2D-DWT 可将图像分解为四个子带：A、V、H 和 D。此过程具有可逆性，从而在特征提取过程中保留了图像的细节信息。其中，子带 A 保存了原始图像的低频内容，其余三个子带则分别包含图像的垂直、水平和对角方向的高频成分。低频内容可进一步分解以获取多尺度频率成分。通过对低频系数 $A_1 \in \mathbb{R}^{H/2\times W/2\times C}$ 进行 K 次小波变换，获得以下结果：

$$\{A_{k+1}, V_{k+1}, H_{k+1}, D_{k+1}\} = \text{2D-DWT}(A_k) \tag{6-6}$$

其中，A_{k+1}、V_{k+1}、H_{k+1} 和 $D_{k+1} \in \mathbb{R}^{H/2^{k+1}\times W/2^{k+1}\times C}$，$k \in [1, K]$。小波变换将图像空间维度缩小四倍，可视为图像的下采样算子，适用于多尺度网络。

（2）MFE

在通过 PFRNet 获得预测图像 $P \in \mathbb{R}^{H\times W\times 3}$ 后，如图 6.5（a）所示，利用 2D-DWT 提取第 i 层的多频率系数 $\{\hat{A}_i, \hat{V}_i, \hat{H}_i, \hat{D}_i\}$，具体表示如下：

$$\{\hat{A}_i, \hat{V}_i, \hat{H}_i, \hat{D}_i\} = \text{2D-DWT}(P) \tag{6-7}$$

其中，$\hat{A}_i, \hat{V}_i, \hat{H}_i, \hat{D}_i \in \mathbb{R}^{H/2^i\times W/2^i\times 3}$，$i = \{1, 2, 3\}$。

随后，提出的 MFE 通过通道连接这些频率系数以形成先验特征 Z_i：

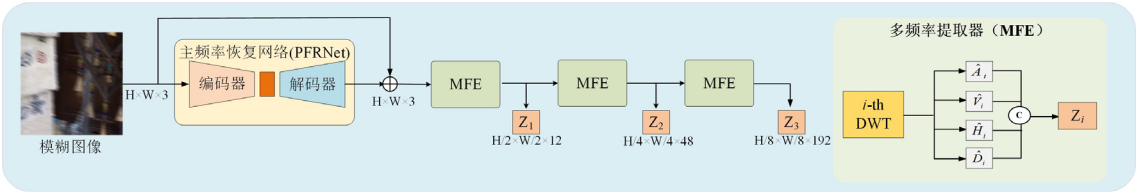
$$Z_i = \left[\hat{A}_i, \hat{V}_i, \hat{H}_i, \hat{D}_i\right]_c \tag{6-8}$$

其中，$[\cdot]_c$ 表示通道级连接，$Z_i \in \mathbb{R}^{H/2^i\times W/2^i\times 3\cdot 4^i}$。

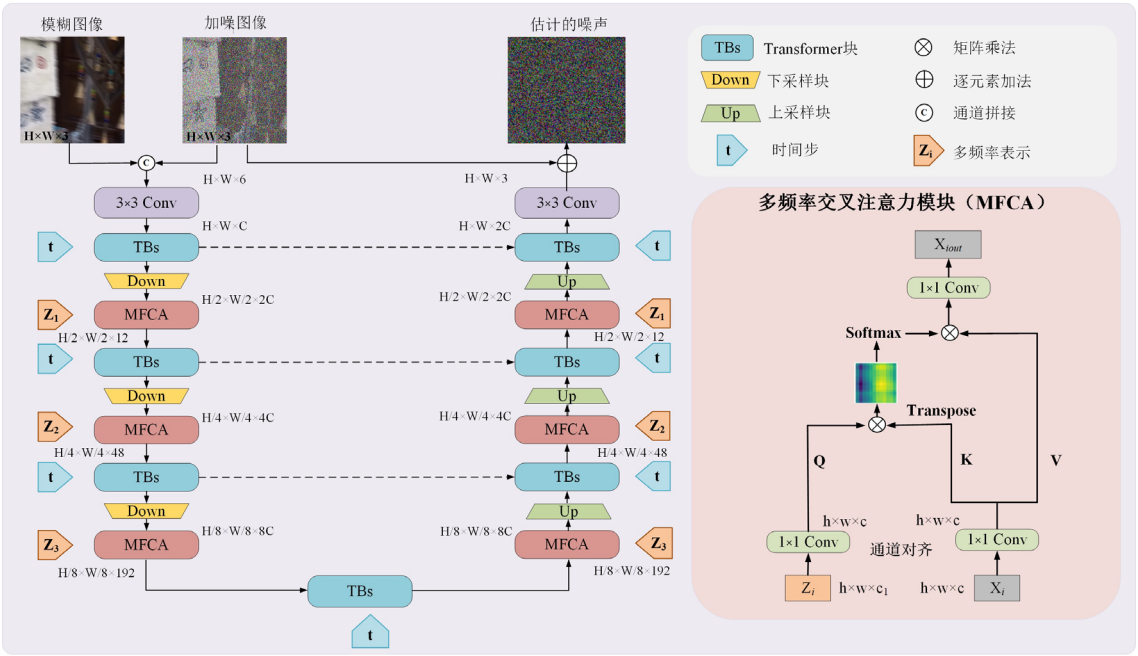
中国知网 https://www.cnki.net

（3）MFCA

为有效引入频率先验信息并引导扩散模型聚焦图像中的高频细节信息，本章提出 MFCA，如图 6.5（b）所示。与传统扩散模型仅使用模糊图像作为条件不同，MFCA 进一步将由 PFRNet 提取的多频率特征纳入建模过程。在每个 MFCA 模块中，采用交叉注意力机制，以多频率特征作为查询项（Query），扩散模型中间层的潜在表示同时作为键（Key）和值（Value）进行计算。该机制能够有效引导网络聚焦于频率先验中的关键细节区域，提升图像结构与边缘信息的复原能力。通过在扩散过程中逐层引入多频率特征，本章方法在应对复杂动态模糊场景时表现出更强的恢复性能与细节还原能力。



(a) 多频率信息提取过程



(b) 去噪过程

图 6.5 去噪过程框架的示意图

Figure 6.5 Illustration of the denoising process framework

具体而言，通过对多频率特征 $Z_i \in \mathbb{R}^{h\times w\times c_1}$ 进行线性投影，生成聚合频率信息的特征图 Q：

$$Q = Conv_{1\times1}(Z_i) \tag{6-9}$$

中国知网 https://www.cnki.net

其中，$Q \in \mathbb{R}^{h \times w \times c}$，$Conv_{1\times1}$为$1\times1$卷积算子。接着，对输入特征图$X_i \in \mathbb{R}^{h \times w \times c}$进行不同线性投影，得到交叉注意力机制中的$K$和$V$：

$$\begin{aligned} K &= Conv_{1\times1}(X_i) \\ V &= Conv_{1\times1}(X_i) \end{aligned} \tag{6-10}$$

其中，$K,V \in \mathbb{R}^{h \times w \times c}$。交叉注意力机制的输出特征图$X_i^{out}$表示为：

$$X_i^{out} = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{6-11}$$

其中，d_k为矩阵Q的列数。

此外，在实际场景中，由于模糊通常表现为非均匀性，单一尺度特征可能无法有效处理复杂的模糊问题。与传统方法通过下采样获取多尺度特征不同，本节研究通过小波变换以无信息丢失的方式实现多尺度特性。因此，提出的去噪过程将多尺度特征$Z_i(i=1,2,3)$与中间特征X_i以分层方式结合，最终实现更优的去模糊效果。

6.2.3 损失函数

本章联合优化了 PFRNet 和 DMDNet 网络，设计的损失函数具有分阶段、分目标、由粗到精的特点，旨在同时提升去模糊的结构恢复能力与细节保真度。在 PFRNet 的优化中，引入了基于小波域的损失函数$\mathcal{L}_{DWT}$，该损失函数定义为真实图像和预测图像的小波变换系数幅值之间的均方误差，具体表示为：

$$\mathcal{L}_{DWT} = \sum_{i=1}^{L}[\left\|\hat{A}_i - A_i\right\|_2^2 + \left\|\hat{V}_i - V_i\right\|_2^2 + \left\|\hat{H}_i - H_i\right\|_2^2 + \left\|\hat{D}_i - D_i\right\|_2^2] \tag{6-12}$$

其中，A_i,V_i,H_i,D_i分别表示真实图像在第i层下采样级别的子带系数，$\hat{A}_i,\hat{V}_i,\hat{H}_i,\hat{D}_i$为预测图像在第$i$层下采样级别的子带系数；$L$表示下采样层数，本章设置为 3。

在 DMDNet 的优化中，采用了一个包含噪声损失和内容损失的两阶段优化方法。其中，噪声损失$\mathcal{L}_{noise}$用于对噪声进行约束，表达式为：

$$\mathcal{L}_{noise} = \mathbb{E}\left[\left\|\epsilon - \epsilon_\theta(\sqrt{\overline{\alpha}_t}x_0 + \sqrt{(1-\overline{\alpha}_t)}\epsilon, B, Z, t)\right\|_2^2\right] \tag{6-13}$$

中国知网 https://www.cnki.net

内容损失 $\mathcal{L}_{content}$ 是用于约束采样恢复结果与其对应的真实清晰图像之间的一致性，定义如下：

$$\mathcal{L}_{content} = \lambda(1 - \mathrm{SSIM}(x_0, x)) + (1-\lambda)\left\|x_0 - x\right\|_1 \tag{6-14}$$

其中，x_0 表示生成的采样恢复结果，λ 的值根据经验设置为 0.84。

为提升模型性能，本章采用了一种“由粗到精”的联合训练策略以提升模型恢复性能。在粗训练阶段，定义的总损失函数为：$\mathcal{L} = \mathcal{L}_{DWT} + \mathcal{L}_{noise}$，该阶段主要通过增强扩散模型中的噪声约束以优化模型的性能。进入精训练阶段后，更新的总损失函数则定义为：$\mathcal{L} = \mathcal{L}_{DWT} + \mathcal{L}_{content}$，该阶段侧重于增强采样恢复结果与真实清晰图像之间的内容一致性，从而弥补粗训练阶段中噪声估计存在的误差，有效提升扩散模型在去模糊任务中的恢复质量。

6.3 实验结果与分析

6.3.1 实验设置

本研究基于 PyTorch 框架实现，并在配备 NVIDIA Tesla V100 GPU 的服务器上进行训练和测试。DMDNet 采用四层 U 型结构，内部集成若干 Transformer 块，其中 Transformer 块的数量为 $[4,6,6,8]$，注意力头的数量为 $[1,2,4,8]$，通道数依次设置为 $[48,96,192,384]$。在扩散过程建模中，噪声方差从 $\beta_1 = 1e^{-4}$ 线性增长至 $\beta_2 = 2e^{-2}$。最大时间步 T 设置为 1000，采样步长 S 设置为 3。训练过程中，初始阶段仅引入小波域损失，并逐步线性提升噪声损失的权重直至 1。在粗训练阶段，采用 AdamW 优化器，超参数设置为 $\beta_1 = 0.9$，$\beta_2 = 0.999$，权重衰减为 $1e^{-4}$。初始学习率设为 $3e^{-4}$，并通过余弦退火策略逐渐降低至 $1e^{-5}$。此外，采用渐进式学习策略，逐步调整图像块大小和批处理大小，粗训练阶段在每 1 万次迭代后更新为 $[(64^2,64),(128^2,16),(256^2,4)]$，总共 160 万次迭代。在后续的精训练阶段，学习率设为 $1e^{-5}$，并逐步降低至 $1e^{-7}$。图像块大小和批量大小在每 1 万次迭代后更新为 $[(64^2,16),(128^2,4),(256^2,1)]$，总共进行 50 万次迭代。

6.3.2 数据集与评价指标

本节使用公共图像去模糊数据集对所提方法进行评估，包括 GoPro 数据集[74]、HIDE 数据集[144]、RealBlur-R 数据集[145]和 RealBlur-J 数据集[145]。GoPro 数据集[74]

中国知网 https://www.cnki.net

包含 3214 对分辨率为 1280×720 的图像，其中 2103 对用于训练，1111 对用于测试。HIDE 数据集[144]包括 2025 对相同分辨率的测试图像。RealBlur-R 和 RealBlur-J 数据集[145]为真实场景数据集，主要由低光照条件下的运动模糊场景组成，每个数据集包含 980 张测试图像。本章方法基于 GoPro 数据集[145]进行训练，并在 HIDE 数据集[144]、RealBlur-R 数据集[145]和 RealBlur-J 数据集[145]上进行评估，以检验模型在不同分布数据上的泛化能力。评价指标包括两种客观指标：峰值信噪比（PSNR）和结构相似性指数（SSIM），以及一种感知指标：学习感知图像块相似性（Learned Perceptual Image Patch Similarity，LPIPS）[147]。

6.3.3 定量与定性实验结果

本节中将所提出的方法与现有的最先进的方法进行比较。这些方法根据其核心技术创新进行了分类：（1）基于 CNN 的方法：DeblurGAN-v2[82]，SRN[78]，DBGAN[83]，MIMO[76]，MPRNet[148]，DGUNet[149]，HINet[150]，NAFNet[121]；（2）基于 Transformer 的方法：Restormer[86]，Uformer[87]，Stripformer[88]；3）基于 Diffusion 的方法：IR-SDE[151]，C2F-DFT[142]，HI-Diff[95]。虽然 HI-Diff[95]结合了 Diffusion 和 Transformer，但本章将其归类为基于 Diffusion 的方法，因为它的关键创新在于应用了扩散模型的概念。具体来说，HI-Diff[95]利用扩散模型的力量来生成信息先验，然后将其集成到一个 Transformer 架构中，以增强去模糊图像的细节。本节使用他们各自的作者提供的代码和权重来测试上述方法。为了进行公平的比较，所有这些方法都是在 GoPro 数据集[74]上进行训练的，然后直接应用于 HIDE[144]、RealBlur-R[145]和 RealBlur-J[145]数据集。

（1）定量实验结果分析

在 GoPro[74]和 HIDE[144]测试集上的定量评估结果如表 6.1 所示。尽管本章方法在失真指标（如 PSNR 和 SSIM）上略低于部分现有方法，但在更能反映人眼感知质量的 LPIPS 指标上表现突出，取得了最好得分。这表明本章方法在恢复图像的自然感、纹理细节以及结构一致性方面具有更优表现，能够生成更符合人类视觉偏好的高质量图像。值得注意的是，与同样基于扩散模型的方法（如 IR-SDE[151]和 C2F-DFT[142]）相比，本章方法在整体性能（PSNR、SSIM 和 LPIPS 指标）上实现了显著提升。HI-Diff[95]通过将扩散先验融入 Transformer 架构中，在失真指标方面略优于本章方法。然而，在感知指标 LPIPS 上，HI-Diff[95]及其它基于 CNN、Transformer 和 Diffusion 的方法均表现不佳，而本章方法在 GoPro[74]和 HIDE[144]测试集上均取得了最优 LPIPS 分数，进一步验证了其在生成高感知质量图像方面的优势。

中国知网 https://www.cnki.net

表 6.1 不同方法在 GoPro 和 HIDE 数据集上的定量比较

Table 6.1 Quantitative comparison of different methods on the GoPro and HIDE datasets

类别	方法	GoPro 数据集			HIDE 数据集		
		PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
CNN	DeblurGAN-v2[82]	29.08	0.876	0.119	27.51	0.852	0.160
	SRN[78]	30.25	0.901	0.130	28.36	0.875	0.154
	DBGAN[83]	31.18	0.916	0.112	28.94	0.889	0.145
	MIMO[76]	31.72	0.924	0.104	29.28	0.896	0.141
	MPRNet[148]	32.66	0.936	0.091	30.96	0.918	0.116
	DGUNet[149]	32.70	0.937	0.094	30.96	0.919	0.125
	HINet[150]	32.77	0.936	0.090	30.32	0.910	0.122
Transformer	NAFNet[121]	**33.71**	**0.947**	0.081	31.32	0.924	0.109
	Restormer[86]	32.92	0.939	0.086	31.22	0.922	0.110
	Uformer[87]	33.05	0.941	0.089	30.89	0.920	0.116
	Stripformer[88]	33.08	0.941	0.088	31.03	0.918	0.108
Diffusion	HI-Diff[95]	33.33	0.945	0.082	**31.46**	**0.925**	0.112
	IR-SDE[151]	30.63	0.901	0.069	25.76	0.825	0.130
	C2F-DFT[142]	31.96	0.928	0.100	30.52	0.915	0.118
	本章方法	32.52	0.935	**0.066**	30.89	0.920	**0.106**

在 RealBlur-R[145]和 RealBlur-J[145]两个真实模糊图像数据集上的定量评估结果如表 6.2 所示。与现有多种代表性去模糊方法相比，本章提出的基于频率先验引导的扩散模型在两个真实场景数据集上均取得了最优性能，充分展示了该方法在实际复杂模糊场景中的强泛化能力与应用潜力。具体而言，相较于在 GoPro 数据集[74]上表现最优的 NAFNet[121]，本章方法在 RealBlur-R[145]数据集上的 PSNR 提升了 0.4dB，在 RealBlur-J[145]数据集上的 PSNR 的提升更达到了 0.92dB，显示出更优的跨数据集泛化能力。进一步比较具体指标，在 RealBlur-R[145]数据集上，本章方法相较于第二最佳方法 C2F-DFT[142]，在 PSNR 指标上提高了 0.03dB；在 RealBlur-J[145]数据集上，PSNR 较第二最佳方法 HI-Diff[95]在 PSNR 指标上提升了 0.08dB，SSIM 指标上提升了 0.002。

中国知网 https://www.cnki.net

表 6.2 不同方法在 RealBlur-R 和 RealBlur-J 数据集上的定量比较

Table 6.2 Quantitative comparison of different methods on the RealBlur-R and RealBlur-J datasets

类别	方法	RealBlur-R 数据集			RealBlur-J 数据集		
		PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
CNN	DeblurGAN-v2[82]	35.10	0.934	0.086	28.69	0.865	0.144
	SRN[78]	35.41	0.929	0.087	28.49	0.863	0.160
	DBGAN[83]	33.78	0.908	0.135	24.93	0.745	0.295
	MIMO[76]	35.47	0.946	0.089	27.75	0.836	0.191
	MPRNet[148]	35.98	0.952	0.075	28.69	0.872	0.158
	DGUNet[149]	35.95	0.952	0.071	28.75	0.875	0.152
	HINet[150]	35.75	0.949	0.078	28.17	0.849	0.173
	NAFNet[121]	35.97	0.951	0.068	28.31	0.856	0.167
Transformer	Restormer[86]	36.19	0.957	0.061	28.96	0.878	0.155
	Uformer[87]	36.18	0.956	0.062	29.08	0.885	0.146
	Stripformer[88]	36.07	0.954	0.063	28.82	0.876	0.145
Diffusion	HI-Diff[95]	36.28	0.958	0.060	29.15	0.889	0.146
	IR-SDE[151]	33.96	0.918	0.114	24.21	0.729	0.267
	C2F-DFT[142]	36.34	0.957	0.064	28.89	0.876	0.154
	本章方法	**36.37**	**0.958**	**0.058**	**29.23**	**0.891**	**0.141**

总体而言，尽管本章方法在 GoPro[74]和 HIDE[144]数据集上 PSNR 和 SSIM 略低于部分对比方法，但在更能反映人眼感知质量的 LPIPS 指标上表现优异。需要指出的是，GoPro[74]和 HIDE[144]数据集为无噪声的合成数据，运动模糊变化较少，而 RealBlur-R[145]和 RealBlur-J[145]数据集则包含复杂的真实场景噪声和模糊。本章方法在更具挑战性的 RealBlur-R 和 RealBlur-J 数据集[145]上的显著性能提升，主要得益于其频率先验引导的扩散模型框架。

（2）定性实验结果分析

在 GoPro[74]、HIDE[144]、RealBlur-R[145]和 RealBlur-J[145]数据集上的定性对比结果如图 6.6 和图 6.7 所示。可以观察到，本章方法在恢复更精确的纹理和更清晰的边缘方面优于现有方法。在 GoPro[74]样本中，本章方法比其他模型更好地还原了汽车后视镜的边缘且无明显伪影。在 HIDE[144]样本中，其他方法难以准确复

中国知网 https://www.cnki.net

原人类眉毛和眼睛，而本章方法成功恢复了清晰的纹理。在 RealBlur-J[145]样本中，大多数现有方法在处理真实图像时引入了不利效果，导致恢复结果甚至比原始模糊图像更差，而本章方法生成了更清晰的结果并还原了更精细的结构。在 RealBlur-R[145]样本中，本章方法有效减少了广告牌数字的模糊，而其他算法难以恢复广告牌上的数字。这些定性结果表明，本章方法在处理真实动态场景时表现出色，是一种鲁棒的去模糊扩散模型。

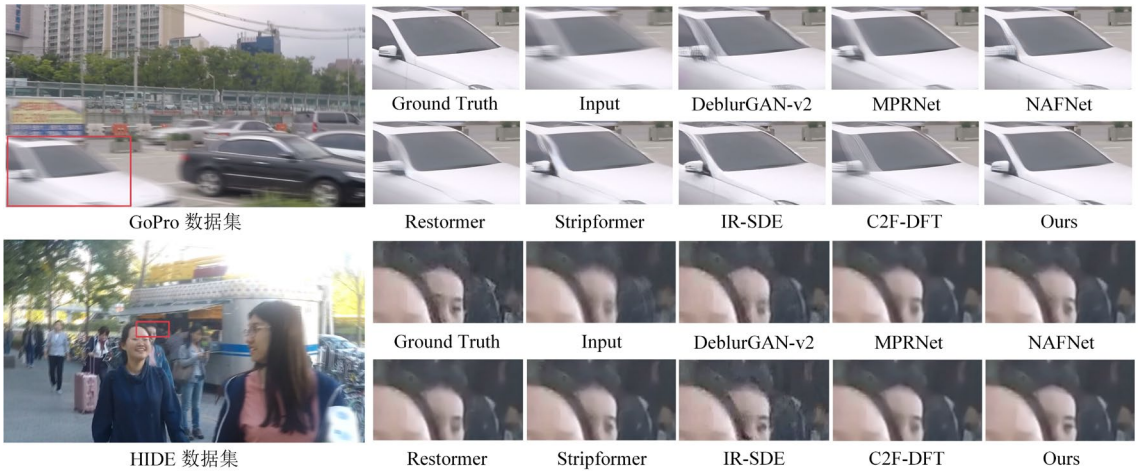


图 6.6 不同方法在 GoPro 和 HIDE 数据集上的定性比较

Figure 6.6 Qualitative comparison of different methods on the GoPro and HIDE datasets

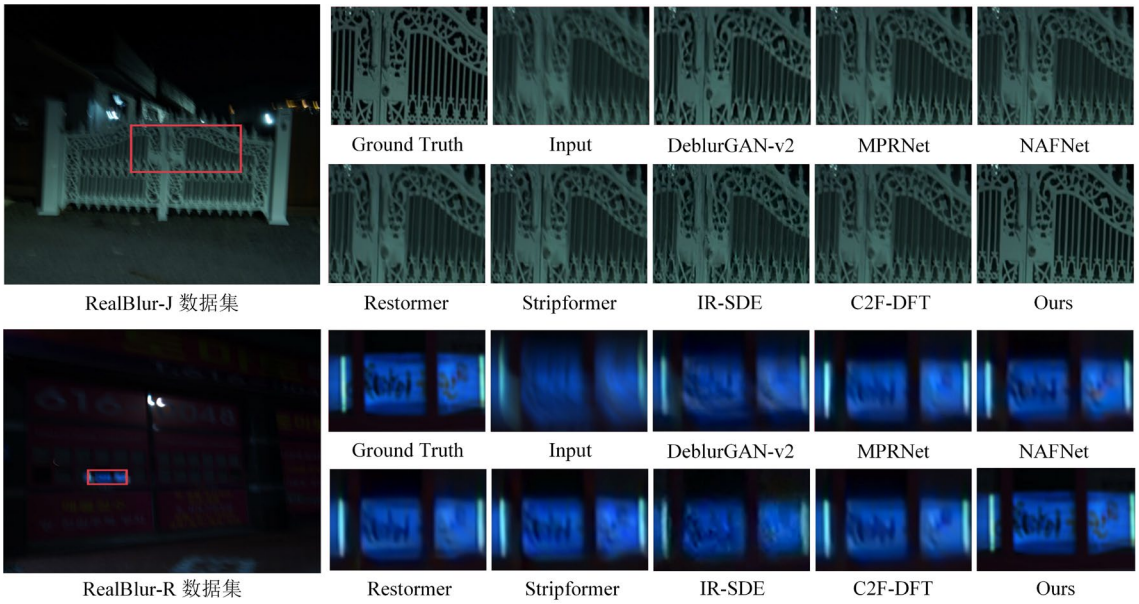


图 6.7 不同方法在 RealBlur-R 和 RealBlur-J 数据集上的定性比较

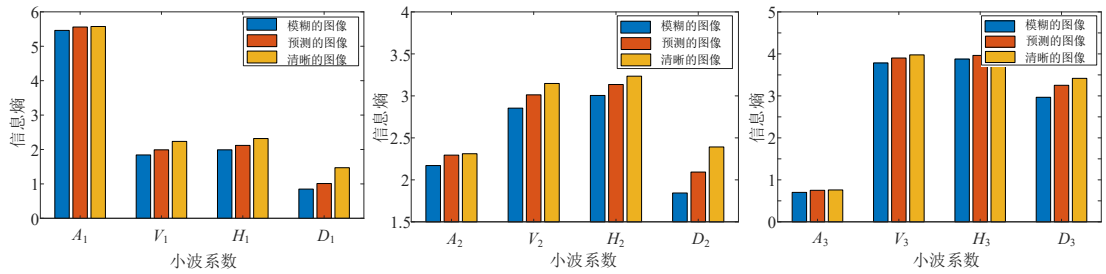
Figure 6.7 Qualitative comparison of different methods on the RealBlur-R and RealBlur-J datasets

中国知网 https://www.cnki.net

6.3.4 消融实验

（1）PFRNet 的有效性分析

表 6.3 评估了使用与不使用 PFRNet 的性能差异，以及不同网络规模对模型表现的影响。直接使用模糊图像进行初始估计相比采用 PFRNet 的情况下，性能显著下降。这一差异主要是由于模糊图像中可用的频率信息有限。图 6.8 展示了在 GoPro 数据集[74]上，不同图像类型（模糊图像、PFRNet 预测的图像和清晰图像）在三种尺度下的小波系数的平均信息熵，验证了 PFRNet 预测的图像保留了更丰富的频率细节。实验还探讨了 PFRNet 不同的通道数（16，32，64）对模型性能的影响，分别记为 S、M 和 L 网络。由于训练过程中的频率约束，网络规模对模型性能影响较小。如表 6.3 所示，即使在更大的网络中，SSIM 仅提升了 0.001，说明最小规模的网络已经能够满足需求。



(a) 一次小波变换　(b) 二次小波变换　(c) 三次小波变换

图 6.8 模糊、预测和清晰图像在三个尺度上的小波系数信息熵

Figure 6.8 Information entropy of wavelet coefficients at three scales for blurry, PFRNet-predicted, and clear images

表 6.3 不同规模的 PFRNet 网络结构的消融实验

Table 6.3 Ablation study on PFRNet with different network scales

方法	网络通道数	参数量	PSNR↑	SSIM↑	LPIPS↓
N/A	-	-	30.92	0.911	0.117
CNN-S	**16**	**3.69**	32.52	0.935	**0.066**
CNN-M	32	14.53	32.54	0.935	0.067
CNN-L	64	57.67	**32.55**	**0.936**	0.069

（2）MFE 的有效性分析

为了深入分析 MFE 提取的小波系数在扩散模型中的作用，本节设计了一系列消融实验，旨在评估不同频段的小波系数对图像去模糊性能的影响。具体而言，

中国知网 https://www.cnki.net

本节将小波分解后的系数按频率划分为低频分量（$[A]$）、高频分量（$[V,H,D]$）以及全频组合（$[A,V,H,D]$），并分别将这些组合作为引导条件输入到扩散模型中进行训练与测试，定量结果如表 6.4 所示。从实验结果可以明显看出，当提取仅仅包含低频分量（$[A]$）或者高频分量（$[V,H,D]$）时效果较差，只有包括全频分量（$[A,V,H,D]$）时，模型的恢复性能才达到最佳。这种表现可以归因于这些系数同时提供了全局结构信息和局部细节信息，从而形成了更丰富的特征表示并最小化了信息损失。

表 6.4 不同小波系数的消融研究

Table 6.4 Ablation studies of the different wavelet coefficients

方法	GoPro 数据集			RealBlur-J 数据集		
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
低频分量（$[A]$）	31.54	0.920	0.110	27.76	0.835	0.195
高频分量（$[V,H,D]$）	31.67	0.922	0.108	28.15	0.843	0.172
全频分量（$[A,V,H,D]$）	**32.52**	**0.935**	**0.066**	**29.23**	**0.891**	**0.141**

（3）MFCA 的有效性分析

为验证所提出的 MFCA 模块的有效性，本节构建了一个以模糊图像作为条件输入的标准扩散模型作为基线，并在此基础上引入 MFCA 模块（基线+MFCA）进行对比实验。如表 6.5 所示，在 GoPro 数据集[74]上引入 MFCA 后，PSNR、SSIM 和 LPIPS 分别提升了 0.8dB、0.009 和 0.035。此外，在 RealBlur-J 数据集[117 上，PSNR、SSIM 和 LPIPS 分别提高了 0.47dB、0.016 和 0.011，进一步证明了该模块在真实模糊场景下的适应能力与稳定性。

表 6.5 关于 MFCA 消融研究的定量比较

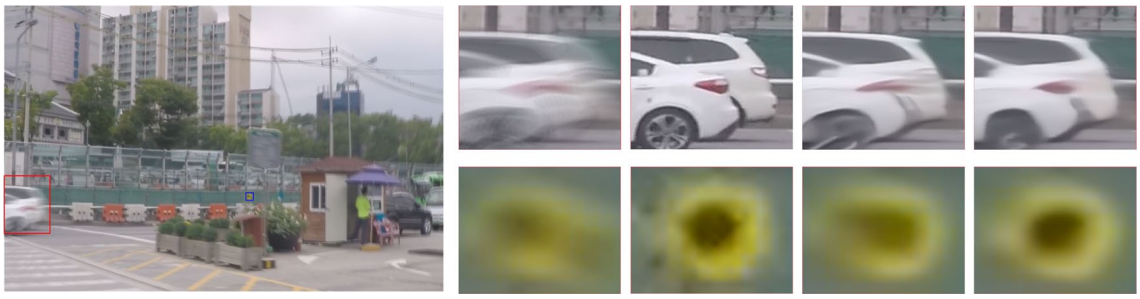
Table 6.5 Quantitative comparison of the ablation study on MFCA

方法	GoPro 数据集			RealBlur-J 数据集		
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
基线	31.72	0.926	0.101	28.76	0.875	0.152
本章方法（基线+MFCA）	**32.52**	**0.935**	**0.066**	**29.23**	**0.891**	**0.141**

视觉对比结果如图 6.9 所示，（a）是模糊图像，（b）是清晰图像，（c）是未引入 MFCA 的方法，（d）是引入 MFCA 的方法。可以看出（d）在图像的轮

中国知网 https://www.cnki.net

廓结构以及花朵等复杂纹理区域的恢复效果明显增强，呈现出更加完整、自然且富有层次感的视觉表现。这种提升主要得益于 MFCA 在扩散过程中的关键作用，其引入的交叉注意力机制能够自适应地关注并整合从多频率特征中提取的信息，尤其是在不同尺度下捕捉高频细节与低频结构的能力。通过将多频率先验作为引导条件嵌入至扩散模型的多层潜在表示中，MFCA 有效增强了模型对局部细节与全局结构的理解，从而实现了更精确且感知质量更高的图像复原结果。



GoPro 数据集　(a)　(b)　(c)　(d)

图 6.9 MFCA 模块消融实验的视觉对比结果

Figure 6.9 Qualitative comparison of the ablation study on the MFCA module

（4）联合训练的有效性分析

为了进一步提升模型整体的去模糊性能，本章采用了联合训练策略，将 PFRNet 与 DMDNet 进行端到端的联合优化。该策略的核心思想在于通过共享训练目标，使得两个子模块在特征提取与图像复原过程中能够更紧密地协同工作，从而提高整个系统的表现力与鲁棒性。

为验证联合训练策略的有效性，本节将其与传统的单独训练进行了对比分析。在单独训练设置中，首先根据第 6.3.1 节所述的实验配置对 PFRNet 进行预训练，训练总迭代次数为 10 万步。完成 PFRNet 预训练后，固定其网络参数，仅对 DMDNet 单独进行优化。这种方式虽具有训练过程简单、模块易于分析等优点，但由于缺乏模块间的信息协同与反馈机制，可能导致特征引导与生成过程之间存在不一致，进而限制模型性能的上限。实验结果如表 6.6 所示，联合训练方式相比单独训练在 PSNR 上提升了 1.37dB，表明联合训练策略的重要性。

表 6.6 单独训练和联合训练结果的定量比较

Table 6.6 Quantitative comparison of separate training and joint training results

训练策略	PSNR↑	SSIM↑	LPIPS↓
单独训练	31.15	0.915	0.112
联合训练	**32.52**	**0.935**	**0.066**

中国知网 https://www.cnki.net

（5）“由粗到精”训练的有效性分析

本节还探讨了“由粗到精”的训练方式对模型性能的影响。表 6.7 显示，在粗训练阶段增加迭代次数仅带来了 0.06dB 的 PSNR 小幅提升，而在粗训练后引入精训练，则显著提高了 1.07dB 的 PSNR。图 6.10 展示了粗训练与精训练结果的视觉对比结果。粗训练难以恢复理想效果，而精训练显著改善了视觉恢复质量。这说明，精训练通过使用真实图像约束采样恢复结果而非噪声，优化了扩散模型，使模型能够学习更加复杂的退化信息，从而实现更优的恢复效果。

表 6.7 “由粗到精”训练策略有效性的定量比较

Table 6.7 Quantitative comparison of the effectiveness of “coarse-to-fine” training strategy

训练策略	PSNR↑	SSIM↑	LPIPS↓
粗训练 1600K 次	31.45	0.925	0.108
粗训练 2100K 次	31.51	0.926	0.105
粗训练 1600K 次+精训练 500K 次	**32.52**	**0.935**	**0.066**



(a) 模糊图像　(b) 清晰图像　(c) 粗估计结果　(d) 精估计结果

图 6.10 粗训练和精训练结果的定性比较

Figure 6.10 Qualitative comparison of coarse and fine training results

6.3.5 鲁棒性与复杂性分析

（1）鲁棒性分析

为验证本章方法在不同类型模糊场景中的泛化能力，本节将该模型应用于第五章中使用的 Köhler 数据集[128]进行性能评估。该数据集包含 48 张由 4 张清晰图像与 12 种相机运动轨迹合成的模糊图像，是相机抖动去模糊方法的重要基准数据集。在实验中，本章方法未在 Köhler 数据集[128]上进行微调或再训练，而是直接使用在动态模糊数据集（GoPro 数据集[74]）上训练得到的模型进行推理。此设置旨在考察模型在未见数据集上的迁移能力和泛化性能，尤其是在与原始训练模

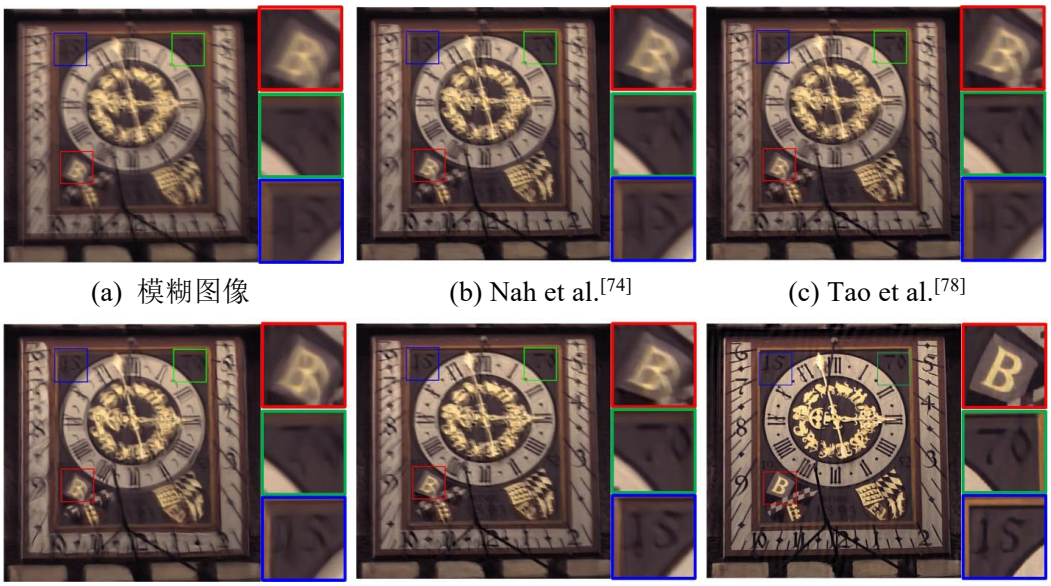
中国知网 https://www.cnki.net

糊类型存在显著差异的情况下的适应性表现。

表 6.8 不同方法在 Köhler 数据集上的定量比较

Table 6.8 Quantitative comparison of different methods on the Köhler dataset

类别	方法	训练数据	PSNR↑	SSIM↑
基于传统优化	第五章的方法	-	**30.12**	**0.874**
基于深度学习	Nah et al.[74]	GoPro	26.48	0.808
	Tao et al.[78]	GoPro	26.75	0.837
	Zhang et al.[77]	GoPro	25.71	0.800
	本章方法	GoPro	<u>27.58</u>	<u>0.839</u>



(a) 模糊图像 (b) Nah et al.[74] (c) Tao et al.[78]

(d) Zhang et al.[77] (e) 本章方法 (f) 第五章方法

图 6.11 不同方法在 Köhler 数据集上的定性比较

Figure 6.11 Qualitative comparison of different methods on the Köhler dataset

表 6.8 展示了本章方法与多种主流深度学习方法[74,77,78]在 Köhler 数据集[128]上的平均 PSNR 和 SSIM 对比结果。实验表明，相比于现有的深度学习方法，本章方法取得了更高的 PSNR 和 SSIM，比第二名高 0.83dB，体现出良好的泛化能力和鲁棒性。然而，本章方法与第五章中基于传统优化方法的结果（30.12dB）相比仍存在差距。图 6.11 给出了其中一张重度模糊图像的视觉对比结果。可以看出，本章方法能够较好地恢复数字“70”和“15”的轮廓，明显优于其他深度学习方法；但在字母“B”的细节恢复上仍存在伪影，而第五章中的传统方法则更为自然清晰。

中国知网 https://www.cnki.net

该差距主要源于 Köhler 数据集提供了精确的模糊核信息，传统优化方法能够更好地利用这些物理先验进行非盲反卷积，从而在细节上表现优异；而本章方法作为数据驱动的生成模型，在未引入模糊核先验的情况下，主要依赖于对动态模糊分布的学习，对局部纹理复杂或小尺度相机抖动模糊的处理仍存在局限。为进一步提升性能，可从以下方面进行改进：一方面，引入模糊核估计与先验信息的融合，以增强模型对精确模糊模式的适应能力；另一方面，采用混合训练策略，在训练阶段引入带有精确模糊核的样本，实现对物理先验的弱监督学习，从而在保持模型泛化能力的同时，提高对精确模糊场景的复原效果。

（2）复杂性分析

为全面评估本章所提方法在模型复杂度方面的表现，本节在3×512×512的图像上，从浮点运算次数、参数量以及推理时间三个维度，对本章方法与第五章方法及两种典型深度学习运动去模糊方法（Restormer[86]、HI-Diff[95]）进行了系统对比，结果如表 6.9 所示。

从表中可以看出，本章方法的总浮点运算次数为 428.901G，略低于 Restormer（563.962G）和 HI-Diff（521.396G），表明在单次采样步骤下，本方法的计算量相对较小。在参数规模方面，本章方法为 25.335M，是三者中最小的，显示出在保持高性能的同时模型具有更高的轻量化特性。在 GPU 上的推理效率方面，本章方法在 10 个采样步骤下的推理时间为 2.931 秒，略高于 Restormer 的 0.461 秒。这主要是由于扩散模型本身具有迭代采样的特性，即便单次采样步骤下的浮点运算次数有所降低，计算量的减少也未能完全转化为推理时间的缩短。然而，相比于第五章基于传统优化的方法在 CPU 上达到 31.59 秒的推理时间，本章方法仍具有明显的速度优势。

表 6.9 模型复杂度比较

Table 6.9 Model complexity comparisons

方法	浮点运算次数 (G)	参数量 (M)	推理时间(秒)	
			CPU	GPU
第五章的方法	-	-	31.59	-
Restormer[86]	563.962	26.097	-	**0.461**
HI-Diff[95]	521.396	28.49	-	3.623
本章方法	**428.901**	**25.335**	-	2.931

注：G 表示十亿次浮点运算，M 表示百万参数。

中国知网 https://www.cnki.net

6.4 本章小结

不同于第五章聚焦的由相机抖动引起的均匀运动模糊问题，本章面向动态场景中更为复杂的非均匀运动模糊，提出了一种基于频率先验引导的扩散模型去模糊方法，以提升对真实复杂模糊模式的建模与恢复能力。具体而言，本章设计了轻量级的主频率恢复网络以生成图像的初步估计结果，并通过多级小波变换提取不同尺度的频率特征，构建结构化频率先验，为扩散模型提供有效的条件引导。为了充分融合多尺度频率信息与扩散模型的生成能力，本章进一步引入多频率交叉注意力模块，实现频率特征与扩散模型中间层表示的跨尺度交互，从而显著增强图像结构与纹理细节的复原效果。

在多个大规模动态模糊数据集上的实验结果表明，本章所提出的方法在应对真实复杂运动模糊方面显著优于现有 13 种主流方法，兼具更高的定量评估指标与更佳的主观视觉效果。在 RealBlur-R 和 RealBlur-J 数据集上，PSNR 分别提升了 0.4dB 和 0.92dB，表现出良好的细节还原能力与整体复原质量。此外，在 Köhler 等基于相机抖动构建的数据集上，尽管本方法未引入显式模糊核先验，也未进行针对性微调，性能略低于第五章的优化方法，但仍较现有深度学习方法在 PSNR 上提升了 0.83dB，展现出良好的泛化能力与稳健性。

中国知网 https://www.cnki.net

第 7 章 总结与展望

7.1 全文总结

图像模糊处理作为图像复原领域的重要研究方向，近年来在学术界引起了广泛关注，并取得了诸多突破性进展。尽管在特定艺术创作中，模糊可被有意用于增强图像表现力，但在大多数实际应用中，模糊会严重削弱图像细节信息，降低视觉质量，进而影响图像理解、目标检测、图像分割等关键计算机视觉任务的性能。因此，如何有效估计并去除图像模糊、恢复高质量清晰图像，成为图像复原领域亟待解决的核心问题。本论文围绕图像模糊中的两类典型退化形式，即离焦模糊与运动模糊，开展了深入研究，并提出了一系列具有创新性的方法。具体而言，针对离焦模糊，本文首先提出一种基于感知先验的离焦模糊图估计方法，为离焦去模糊任务提供高质量模糊图支撑；进一步地，利用大模型的结构和语义先验，引导扩散模型实现复杂场景下的高保真离焦去模糊。针对运动模糊，分别从相机抖动与目标运动两个层面出发，构建了基于动态极值先验与频率先验的运动去模糊方法，在图像细节还原与真实场景适应性方面表现出优越性能。论文的主要研究成果与创新点总结如下：

（1）基于感知先验的离焦模糊图估计方法

针对离焦模糊图像中弱纹理和低对比度区域模糊感知不准确的问题，本文提出了一种基于感知先验引导的离焦模糊图估计算法。该方法首先设计再模糊奇异值差异度量算子，以有效刻画图像边缘处的模糊特征，从而提升边缘区域的模糊估计准确性。其次，基于 JNB 理论构建感知权重，对模糊特征进行感知调制，增强低对比度区域的模糊辨识能力，提升整体估计的鲁棒性。进一步地，结合边缘点约束与 Matting Laplacian 插值策略，实现稀疏模糊图向完整模糊图的高质量补全，确保模糊图在空间结构上的连续性与准确性。实验结果表明，本文提出的方法在 CUHK 和 DUT 两个数据集上分别取得了最高的 F_β -measure 值 0.883 和 0.802，性能显著优于当前最先进的方法。上述结果不仅验证了感知先验在离焦模糊图估计任务中的有效性，也为实际应用场景如图像分割、视觉增强及去模糊处理等任务提供了高质量且可信赖的模糊估计基础。

（2）基于大模型先验的离焦去模糊方法

针对自然场景中离焦模糊分布复杂，现有方法难以实现高保真复原的问题，本文提出了一种基于大模型先验引导的离焦去模糊方法。该方法首先构建多模态保真度感知模块，对齐模糊图像与清晰图像的结构与语义特征，并将融合后的多

中国知网 https://www.cnki.net

模态先验作为条件信息引入预训练扩散模型，从而有效引导其生成高保真度的清晰图像。随后，设计深度先验融合网络以生成深度自适应的离焦权重图，并结合加权拉普拉斯金字塔融合策略，实现原始图像中清晰区域与扩散模型输出结果的自然融合，从而在保持像素级一致性的同时显著提升整体复原质量。实验结果表明，本文所提出的方法在 DPDD、LFDOF、RealDOF 和 RTF 四个真实自然场景数据集上均取得了显著性能提升。其中，平均 PSNR 提升达到 0.597dB，感知质量指标 FID 平均提升 2.29，显著改善了图像的复原质量与视觉感知效果。上述结果充分验证了所提方法在复杂真实场景中出色的细节还原能力与感知质量增强效果，为基于扩散模型的离焦去模糊任务提供了新的性能基准和研究方向。

（3）基于动态极值先验的图像盲去模糊方法

针对均匀退化条件下图像先验设计与优化策略不足的问题，本文提出了一种基于动态极值先验的图像盲去模糊算法。该方法首先基于图像局部极值的统计特性，分别构建最大值与最小值的稀疏性模型。随后，引入 FCM 聚类机制，将极值先验自适应地分配至不同图像块，并在迭代过程中动态更新聚类中心，以更好适应潜在清晰图像的变化趋势，从而提升模糊核估计精度。同时，针对动态极值先验带来的非凸非线性优化问题，设计稀疏诱导的高效求解框架，在保证去模糊质量的前提下显著提升计算效率。实验结果表明，本文所提出的方法在 Levin、Köhler 和 Lai 三个典型基准数据集上实现了平均 0.53dB 的 PSNR 提升，显著优于现有主流方法。在不同类型图像（如自然图像、人脸图像和低照度图像）中均表现出良好的结构一致性与纹理还原能力，能够生成更为自然、真实的复原结果。在计算效率方面，针对大尺寸图像处理任务，所提出的方法实现了超过 20 倍的速度提升，显著增强了算法在实际应用中的可行性。

（4）基于频率先验的动态场景去模糊方法

针对动态模糊场景中频率信息利用不足，细节恢复能力受限的问题，本文提出了一种基于频率先验引导的扩散模型图像去模糊算法。该方法首先设计主频率恢复网络，在小波域构建频率损失函数，以增强初始图像估计中的频率表达能力。随后，构建多频率特征提取与融合机制，并通过交叉注意力模块将频率先验逐层注入扩散模型的去噪网络，使模型在低频结构恢复与高频细节增强方面均具备更优性能。借助多尺度、多频率的细节建模策略，有效增强了模型对复杂动态模糊场景的适应性。实验结果表明，本章提出的方法在 RealBlur-R 和 RealBlur-J 两个真实动态模糊数据集上分别实现了 0.4dB 和 0.92dB 的 PSNR 提升，且主观视觉质量显著改善，生成图像在细节与纹理表现方面更加丰富自然。上述结果充分验证了频率先验引导机制在动态去模糊任务中的有效性与可扩展性，例如可用于运动监控图像增强及智能交通系统中的动态场景去模糊任务。

中国知网 https://www.cnki.net

7.2 工作展望

本论文提出的研究方法在图像模糊估计与去除方面取得了显著成果，尤其在真实场景下展现出较强的泛化能力。结合感知先验、大模型先验、动态极值先验和频率先验等多种创新技术，本文的方法在多个公开数据集上均取得了领先的性能。然而，图像模糊处理仍存在诸多值得深入探索的研究方向。未来的研究工作可从以下几个方面展开：

（1）多源信息融合与多模态特征引导

现有去模糊方法多以图像本身的模糊特征为基础，忽略了场景中可能存在的其他潜在信息。随着多模态传感器技术的快速发展，图像之外的附加信息已成为提升去模糊性能的重要潜在资源。未来的研究可探索将光流场、运动估计信息及时间序列数据（如视频数据）等多模态信息纳入去模糊框架，以充分挖掘场景中的时空特征。例如，光流信息可提供像素级运动方向和速度估计，为运动模糊区域的细节恢复提供有效补充；时间序列数据可通过多帧图像的联合推理，缓解动态模糊场景下的信息不足问题。此外，随着事件相机技术的不断发展，基于事件相机的图像恢复方法因其高时间分辨率和快速响应特性，有望进一步提升去模糊方法的精度与实时性。

（2）统一去模糊网络框架

尽管本论文提出的方法分别在离焦模糊和运动模糊下均展现出良好的去模糊性能，但图像模糊本质上具有高度的多样性和复杂性，不同类型的模糊在成因、表现形式及其分布特征上存在显著差异。因此，未来的研究将朝着统一复原所有模糊类型的目标迈进。具体而言，首先，构建一个能够处理多种模糊退化类型的统一模糊建模框架，以更好地模拟现实场景中的混合模糊；其次，设计一种具备模糊类型感知能力的自适应去模糊模型，通过动态调整网络结构或推理策略来适应不同模糊类型；最后，构建一个通用的模糊复原框架，力求在面对未知退化过程时，模型能够展现更强的泛化能力与鲁棒性。

（3）跨领域应用与实际场景测试

尽管本论文方法在多个公开数据集上取得了良好的性能，但这些数据集往往无法完全覆盖真实场景中复杂多变的模糊模式。因此，未来研究应注重将所提出的方法扩展至更具挑战性的实际应用场景，包括但不限于自动驾驶、医学影像、监控视频及计算摄影等领域。为进一步提升模型在实际应用中的有效性，可引入用户反馈机制及动态参数调节策略，使模型能够根据环境特征和任务需求实时调整，以更好地满足实际场景中的图像质量要求。

中国知网 https://www.cnki.net

参考文献

[1] Feng Z, Zhang J, Ran X, et al. Ghost-Unet: multi-stage network for image deblurring via lightweight subnet learning[J]. The Visual Computer, 2025, 41(1): 141-155.

[2] Kong L, Dong J, Tang J, et al. Efficient visual state space model for image deblurring[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2025: 12710-12719.

[3] Ali M, Ali M, Hussain M, et al. Generative adversarial networks (GANs) for medical image processing: recent advancements[J]. Archives of Computational Methods in Engineering, 2025, 32(2): 1185-1198.

[4] Pang C, Weng X, Wu J, et al. Vhm: Versatile and honest vision language model for remote sensing image analysis[C]. AAAI Conference on Artificial Intelligence, 2025: 6381-6388.

[5] Li Y, Zhou Y, Liu H. Research on the influence of image motion blur on the effectiveness of machine vision-based metal scraps separation system[J]. Journal of Material Cycles and Waste Management, 2024, 26(4): 2509-2517.

[6] 李钰．基于多传感器的离焦和运动模糊图像复原方法研究[D]．哈尔滨：哈尔滨工业大学，2024.

[7] Fang Z, Wu F, Huang T, et al. Parameterized Blur Kernel Prior Learning for Local Motion Deblurring[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2025: 23006-23015.

[8] Zhao W, Hu G, Wei F, et al. Attacking defocus detection with blur-aware transformation for defocus deblurring[J]. IEEE Transactions on Multimedia, 2024, 26: 5450-5460.

[9] Zhao W, Shang C, Lu H. Self-generated defocus blur detection via dual adversarial discriminators[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2021: 6929-6938.

[10] Zhao F, Lu H, Zhao W, et al. Image-scale-symmetric cooperative network for defocus blur detection[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 32(5): 2719-2731.

[11] Zhao W, Wei F, Wang H, et al. Full-scene defocus blur detection with DeFBD+

中国知网 https://www.cnki.net

via multi-level distillation learning[J]. IEEE Transactions on Multimedia, 2023, 25: 9228-9240.

[12] Karaali A，Harte N，Jung C R．Deep Multi-Scale Feature Learning for Defocus Blur Estimation[J]．IEEE Transactions on Image Processing，2022，31：1097-1106.

[13] Karaali A, Jung C R. Edge-based defocus blur estimation with adaptive scale selection[J]. IEEE Transactions on Image Processing, 2018, 27(3): 1126-1137.

[14] Quan Y, Yao X, Ji H. Single image defocus deblurring via implicit neural inverse kernels[C]. IEEE International Conference on Computer Vision, 2023: 12566-12576.

[15] Quan Y, Wu Z, Ji H. Gaussian kernel mixture network for single image defocus deblurring[J]. Advances in Neural Information Processing Systems, 2021, 34: 20812-20824.

[16] Quan Y, Wu Z, Ji H. Neumann network with recursive kernels for single image defocus deblurring[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2023: 5754-5763.

[17] Pan J, Hu Z, Su Z, et al. Deblurring text images via L0-regularized intensity and gradient prior[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2014: 2901-2908.

[18] Pan J, Sun D, Pfister H, et al. Blind image deblurring using dark channel prior[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1628-1636.

[19] Kong L, Dong J, Ge J, et al. Efficient frequency domain-based transformers for high-quality image deblurring[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2023: 5886-5895.

[20] Ren W, Deng S, Zhang K, et al. Fast Ultra High-Definition Video Deblurring via Multi-scale Separable Network[J]. International Journal of Computer Vision, 2024, 132(5): 1817-1834.

[21] Kuo P H, Pan J, Chien S Y, et al. Efficient Non-Blind Image Deblurring with Discriminative Shrinkage Deep Networks[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2025: 1-14.

[22] Xiao H, Lu W, Li R, et al. Defocus blur detection based on multiscale SVD fusion in gradient domain[J]. Journal of Visual Communication and Image

中国知网 https://www.cnki.net

Representation, 2019, 59: 52-61.

[23] Yi X, Eramian M. LBP-based segmentation of defocus blur[J]. IEEE Transactions on Image Processing, 2016, 25(4): 1626-1638.

[24] Khan A, Irtaza A, Javed A, et al. Defocus blur detection using novel local directional mean patterns (LDMP) and segmentation via KNN matting[J]. Frontiers of Computer Science, 2022, 16(2): 162702-162715.

[25] Khan A, Javed A, Irtaza A, et al. A robust approach for blur and sharp regions' detection using multisequential deviated patterns[J]. International Journal of Optics, 2021, 2021: 1-13.

[26] Golestaneh S A, Karam L J. Spatially-varying blur detection based on multiscale fused and sorted transform coefficients of gradient magnitudes[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2017: 596-605.

[27] 梁晓，王雪玮，郭京波，等．结合沃尔什变换与列率截断的图像局部模糊抗噪检测[J]．计算机辅助设计与图形学学报，2022，34（1）：94-103.

[28] 章秀华，程鉴，洪汉玉，等．奇异值分解域差异性度量的低景深图像显著性目标提取方法[J]．电子与信息学报，2022，44（11）：3987-3997.

[29] Xu G, Quan Y, Ji H. Estimating defocus blur via rank of local patches[C]. IEEE International Conference on Image Processing, 2017: 5381-5389.

[30] Bae S, Durand F. Defocus magnification[J]. Computer Graphics Forum, 2010, 26(3): 571-579.

[31] Zhuo S, Sim T. Defocus map estimation from a single image[J]. Pattern Recognition, 2011, 44(9): 1852-1858.

[32] Ma M, Lu W, Lyu W. Defocus blur detection via edge pixel DCT feature of local patches[J]. Signal Processing, 2020, 176: 107670.

[33] Shi J, Xu L, Jia J. Discriminative blur detection features[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2014: 2965-2972.

[34] Shi J, Xu L, Jia J. Just noticeable defocus blur detection and estimation[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2015: 657-665.

[35] Park J, Tai Y W, Cho D, et al. A unified approach of multi-scale deep and hand-crafted features for defocus estimation[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2017: 2760-2769.

[36] Huang R, Feng W, Fan M, et al. Multiscale blur detection by learning discriminative deep features[J]. Neurocomputing, 2018, 285: 154-166.

中国知网 https://www.cnki.net

[37] Tang C, Liu X, Zheng X, et al. DeFusionNET: defocus blur detection via recurrently fusing and refining discriminative multi-scale deep features[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(2): 955-968.

[38] Zhao W, Zhao F, Wang D, et al. Defocus blur detection via multi-stream bottom-top-bottom network[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(8): 1884-1897.

[39] Lee J, Lee S, Cho S, et al. Deep defocus map estimation using domain adaptation[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2019: 12214-12222.

[40] Li J, Liang B, Lu X, et al. From global to local: Multi-patch and multi-scale contrastive similarity learning for unsupervised defocus blur detection[J]. IEEE Transactions on Image Processing, 2023, 32: 1158-1169.

[41] Oliveira J P, Figueiredo M A T, Bioucas-Dias J M. Parametric blur estimation for blind restoration of natural images: Linear motion and out-of-focus[J]. IEEE Transactions on Image Processing, 2014, 23(1): 466-477.

[42] Chen S J, Shen H L. Multispectral image out-of-focus deblurring using interchannel correlation[J]. IEEE Transactions on Image Processing, 2015, 24(11): 4433-4445.

[43] Abuolaim A, Brown M S. Defocus deblurring using dual-pixel data[C]. European Conference on Computer Vision, 2020: 111-126.

[44] Lee J, Son H, Rim J, et al. Iterative filter adaptive network for single image defocus deblurring[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2021: 2034-2042.

[45] Tang P, Xu Z, Zhou C, et al. Prior and prediction inverse kernel transformer for single image defocus deblurring[C]. AAAI Conference on Artificial Intelligence, 2024: 5145-5153.

[46] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[C]. 34th International Conference on Neural Information Processing Systems, 2020: 6840-6851.

[47] Song J, Meng C, Ermon S. Denoising diffusion implicit models[C]. International Conference on Learning Representations, 2020: 1-20.

[48] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with

中国知网 https://www.cnki.net

latent diffusion models[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2022: 10674-10685.

[49] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]. International Conference on Machine Learning, 2021: 8748-8763.

[50] Kawar B, Elad M, Ermon S, et al. Denoising diffusion restoration models[J]. Advances in Neural Information Processing Systems, 2022, 35: 23593-23606.

[51] Zhang L, Rao A, Agrawala M. Adding conditional control to text-to-image diffusion models[C]. IEEE International Conference on Computer Vision, 2023: 3813-3824.

[52] Yang T, Wu R, Ren P, et al. Pixel-aware stable diffusion for realistic image super-resolution and personalized stylization[C]. European Conference on Computer Vision, 2024: 74-91.

[53] Wu R, Yang T, Sun L, et al. SeeSR: towards semantics-aware real-world image super-resolution[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2024: 25456-25467.

[54] Wiener N, Mathematician C. Extrapolation, interpolation, and smoothing of stationary time series with engineering applications[J]. Mit Press, 1964, 113(21): 1043-1054.

[55] Richardson W H. Bayesian-based iterative method of image restoration[J]. Journal of the Optical Society of America, 1972, 62(1): 55-59.

[56] Biggs D S C, Andrews M. Acceleration of iterative image restoration algorithms[J]. Applied Optics, 1997, 36(8): 1766-1775.

[57] Krishnan D, Fergus R. Fast image deconvolution using hyper-laplacian priors[J]. Advances in Neural Information Processing Systems, 2009, 22: 1033-1041.

[58] Cho S, Jue Wang, Lee S. Handling outliers in non-blind image deconvolution[C]. IEEE International Conference on Computer Vision, 2011: 495-502.

[59] Fergus R, Singh B, Hertzmann A, et al. Removing camera shake from a single photograph[J]. ACM Transactions on Graphics, 2006: 787-794.

[60] Levin A, Weiss Y, Durand F, et al. Understanding blind deconvolution algorithms[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2009: 1964-1971.

[61] Chan T F, Wong C K. Total variation blind deconvolution[J]. IEEE Transactions

中国知网 https://www.cnki.net

on Image Processing, 1998, 7(3): 370-375.

[62] Shan Q, Jia J, Agarwala A. High-quality motion deblurring from a single image[J]. ACM Transactions on Graphics, 2008, 27(3): 1-10.

[63] Krishnan D, Tay T, Fergus R. Blind deconvolution using a normalized sparsity measure[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2011: 233-240.

[64] Xu L, Zheng S, Jia J. Unnatural L0 sparse representation for natural image deblurring[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2013: 1107-1114.

[65] Yan Y, Ren W, Guo Y, et al. Image deblurring via extreme channels prior[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2017: 4003-4011.

[66] Wen F, Ying R, Liu Y, et al. A simple local minimal intensity prior and an improved algorithm for blind image deblurring[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 31(8): 2923-2937.

[67] Sun J, Wenfei Cao, Zongben Xu, et al. Learning a convolutional neural network for non-uniform motion blur removal[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2015: 769-777.

[68] Schuler C J, Hirsch M, Harmeling S, et al. Learning to deblur[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(7): 1439-1451.

[69] Ayan Chakrabarti. A neural approach to blind motion deblurring[C]. European Conference on Computer Vision, 2016: 221-235.

[70] Gong D, Yang J, Liu L, et al. From motion blur to motion flow: A deep learning solution for removing heterogeneous motion blur[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2017: 3806-3815.

[71] Xu X, Pan J, Zhang Y J, et al. Motion blur kernel estimation via deep learning[J]. IEEE Transactions on Image Processing, 2018, 27(1): 194-205.

[72] Tang X, Zhao X, Liu J, et al. Uncertainty-aware unsupervised image deblurring with deep residual prior[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2023: 9883-9892.

[73] Fang Z, Wu F, Dong W, et al. Self-supervised non-uniform kernel estimation with flow-based motion prior for blind image deblurring[C]. IEEE Conference on

中国知网 https://www.cnki.net

Computer Vision and Pattern Recognition, 2023: 18105-18114.

[74] Nah S, Kim T H, Lee K M. Deep multi-scale convolutional neural network for dynamic scene deblurring[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2017: 257-265.

[75] Dong W, Wang P, Yin W, et al. Denoising prior driven deep neural network for image restoration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(10): 2305-2318.

[76] Cho S J, Ji S W, Hong J P, et al. Rethinking coarse-to-fine approach in single image deblurring[C]. IEEE International Conference on Computer Vision, 2021: 4641-4650.

[77] Zhang J, Pan J, Ren J, et al. Dynamic scene deblurring using spatially variant recurrent neural networks[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2521-2529.

[78] Tao X, Gao H, Shen X, et al. Scale-recurrent network for deep image deblurring[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2018: 8174-8182.

[79] Gao H, Tao X, Shen X, et al. Dynamic scene deblurring with parameter selective sharing and nested skip connections[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2019: 3843-3851.

[80] Park D, Kang D U, Kim J, et al. Multi-temporal recurrent neural networks for progressive non-uniform single image deblurring with incremental temporal training[C]. European Conference on Computer Vision, 2020: 327-343.

[81] Kupyn O, Budzan V, Mykhailych M, et al. Deblurgan: Blind motion deblurring using conditional adversarial networks[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2018: 8183-8192.

[82] Kupyn O, Martyniuk T, Wu J, et al. Deblurgan-v2: Deblurring (orders-of-magnitude) faster and better[C]. IEEE International Conference on Computer Vision, 2019: 8878-8887.

[83] Zhang K, Luo W, Zhong Y, et al. Deblurring by realistic blurring[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2020: 2737-2746.

[84] Yang T, Ren P, Xie X, et al. GAN prior embedded network for blind face restoration in the wild[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2021: 672-681.

中国知网 https://www.cnki.net

[85] Croitoru F A, Hondru V, Ionescu R T, et al. Diffusion models in vision: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(9): 10850-10869.

[86] Zamir S W, Arora A, Khan S, et al. Restormer: Efficient transformer for high-resolution image restoration[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2022: 5718-5729.

[87] Wang Z, Cun X, Bao J, et al. Uformer: A general u-shaped transformer for image restoration[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2022: 17683-17693.

[88] Tsai F J, Peng Y T, Lin Y Y, et al. Stripformer: Strip transformer for fast image deblurring[C]. European Conference on Computer Vision, 2022: 146-162.

[89] Yan Q, Gong D, Wang P, et al. SharpFormer: Learning local feature preserving global representations for image deblurring[J]. IEEE Transactions on Image Processing, 2023, 32: 2857-2866.

[90] Zhao Q, Yang H, Zhou D, et al. Rethinking image deblurring via CNN-Transformer multiscale hybrid architecture[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-15.

[91] Xie S, Zhang Z, Lin Z, et al. Smartbrush: Text and shape guided object inpainting with diffusion model[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2023: 22428-22437.

[92] Corneanu C, Gadde R, Martinez A M. Latentpaint: Image inpainting in latent space with diffusion models[C]. IEEE Winter Conference on Applications of Computer Vision, 2024: 4334-4343.

[93] Wu R, Sun L, Ma Z, et al. One-step effective diffusion network for real-world image super-resolution[J]. Advances in Neural Information Processing Systems, 2024, 37: 92529-92553.

[94] Shang S, Shan Z, Liu G, et al. Resdiff: Combining cnn and diffusion model for image super-resolution[C]. AAAI Conference on Artificial Intelligence, 2024: 8975-8983.

[95] Chen Z, Zhang Y, Liu D, et al. Hierarchical integration diffusion model for realistic image deblurring[J]. Advances in Neural Information Processing Systems, 2023, 36: 29114-29125.

[96] Xia B, Zhang Y, Wang S, et al. Diffir: Efficient diffusion model for image

中国知网 https://www.cnki.net

restoration[C]. IEEE International Conference on Computer Vision, 2023: 13049-13059.

[97] Ren M, Delbracio M, Talebi H, et al. Multiscale structure guided diffusion for image deblurring[C]. IEEE International Conference on Computer Vision, 2023: 10721-10733.

[98] Song J, Vahdat A, Mardani M, et al. Pseudoinverse-guided diffusion models for inverse problems[C]. International Conference on Learning Representations, 2022: 1-30.

[99] Özdenizci O, Legenstein R. Restoring vision in adverse weather conditions with patch-based denoising diffusion models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(8): 10346-10357.

[100] Hansen P C. Deconvolution and regularization with Toeplitz matrices[J]. Numerical Algorithms, 2002, 29(4): 323-378.

[101] Ferzli R, Karam L J. A no-reference objective image sharpness metric based on the notion of just noticeable blur (JNB)[J]. IEEE Transactions on Image Processing, 2009, 18(4): 717-728.

[102] Guan J, Zhang W, Gu J, et al. No-reference blur assessment based on edge modeling[J]. Journal of Visual Communication and Image Representation, 2015, 29: 1-7.

[103] Zhu T, Karam L J. Efficient perceptual-based spatially varying out-of-focus blur detection[C]. IEEE International Conference on Image Processing, 2016: 2673-2677.

[104] Xu X, Kong S, Hu T, et al. Boosting Image Restoration via Priors from Pre-Trained Models[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2024: 2900-2909.

[105] Yang L, Kang B, Huang Z, et al. Depth anything: Unleashing the power of large-scale unlabeled data[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2024: 10371-10381.

[106] Mao X, Liu Y, Liu F, et al. Intriguing findings of frequency selection for image deblurring[C]. AAAI Conference on Artificial Intelligence, 2023: 1905-1913.

[107] Liu Y, Fang F, Wang T, et al. Multi-scale grid network for image deblurring with high-frequency guidance[J]. IEEE Transactions on Multimedia, 2022, 24: 2890-2901.

中国知网 https://www.cnki.net

[108]Huang Y, Huang J, Liu J, et al. WaveDM: Wavelet-based diffusion models for image restoration[J]. IEEE Transactions on Multimedia, 2024, 26: 7058-7073.

[109]Jiang H, Luo A, Han S, et al. Low-light image enhancement with wavelet-based diffusion models[J]. ACM Transactions on Graphics, 2023, 42(6): 1-14.

[110]Min C, Wen G, Li B, et al. Blind deblurring via a novel recursive deep cnn improved by wavelet transform[J]. IEEE Access, 2018, 6: 69242-69252.

[111]Zou W, Jiang M, Zhang Y, et al. Sdwnet: A straight dilated network with wavelet transformation for image deblurring[C]. IEEE International Conference on Computer Vision, 2021: 1895-1904.

[112]Wu S, Xie S. An efficient blind method for image quality measurement[C]. International Conference on Information, Communications and Signal Processing, 2009: 1-5.

[113]Lai W S, Huang J B, Hu Z, et al. A comparative study for single image blind deblurring[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1701-1709.

[114]Petschnigg G, Szeliski R, Agrawala M, et al. Digital photography with flash and no-flash image pairs[J]. ACM Transactions on Graphics, 2004, 23(3): 664-672.

[115]Zhao W, Wei F, He Y, et al. United defocus blur detection and deblurring via adversarial promoting learning[C]. European Conference on Computer Vision, 2022: 569-586.

[116]Tang C, Wu J, Hou Y, et al. A spectral and spatial approach of coarse-to-fine blurred image region detection[J]. IEEE Signal Processing Letters, 2016, 23(11): 1652-1656.

[117]Otsu N. A threshold selection method from gray-level histograms[J]. IEEE Transactions on Systems, Man, and Cybernetics, 1979, 9(1): 62-66.

[118]D'Andres L, Salvador J, Kochale A, et al. Non-parametric blur map regression for depth of field extension[J]. IEEE Transactions on Image Processing, 2016, 25(4): 1660-1673.

[119]Zhang Y, Huang X, Ma J, et al. Recognize anything: A strong image tagging model[C]. IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2024: 1724-1732.

[120]Oquab M, Darcet T, Moutakanni T, et al. Dinov2: Learning robust visual features without supervision[J]. Transactions on Machine Learning Research, 2024:

中国知网 https://www.cnki.net

2835-8856.

[121]Chen L, Chu X, Zhang X, et al. Simple baselines for image restoration[C]. European Conference on Computer Vision, 2022: 17-33.

[122]Zhou S, Hu L, Wang Y, et al. AIF-LFNet: All-in-focus light field super-resolution method considering the depth-varying defocus[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2023, 33(8): 3976-3988.

[123]Son H, Lee J, Cho S, et al. Single image defocus deblurring using kernel-sharing parallel atrous convolutions[C]. IEEE International Conference on Computer Vision, 2021: 2622-2630.

[124]Zhai J, Zeng P, Ma C, et al. Learnable blur kernel for single-image defocus deblurring in the wild[C]. AAAI Conference on Artificial Intelligence, 2023: 3384-3392.

[125]Zhai J, Liu Y, Zeng P, et al. Efficient fusion of depth information for defocus deblurring[C]. IEEE International Conference on Acoustics, Speech and Signal Processing, 2024: 2640-2644.

[126]Arbelaez P, Pont-Tuset J, Barron J T, et al. Multiscale combinatorial grouping[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2014: 328-335.

[127]Lei T, Jia X, Zhang Y, et al. Superpixel-based fast fuzzy c-means clustering for color image segmentation[J]. IEEE Transactions on Fuzzy Systems, 2019, 27(9): 1753-1766.

[128]Köhler R, Hirsch M, Mohler B, et al. Recording and playback of camera shake: Benchmarking blind deconvolution with a real-world database[C]. European Conference on Computer Vision, 2012: 27-40.

[129]Hu Z, Yang M H. Good regions to deblur[C]. European Conference on Computer Vision, 2012: 59-72.

[130]Xu L, Jia J. Two-phase kernel estimation for robust motion deblurring[C]. European Conference on Computer Vision, 2010: 157-170.

[131]Liu J, Yan M, Zeng T. Surface-aware blind image deblurring[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 43(3): 1041-1055.

[132]Cho S, Lee S. Fast motion deblurring[J]. ACM Transactions on Graphics, 2009, 28(5): 1-8.

中国知网 https://www.cnki.net

[133]Li L, Pan J, Lai W S, et al. Blind image deblurring via deep discriminative priors[J]. International Journal of Computer Vision, 2019, 127(8): 1025-1043.

[134]Sun L, Cho S, Wang J, et al. Edge-based blur kernel estimation using patch priors[C]. IEEE International Conference on Computational Photography, 2013: 1-8.

[135]Levin A, Weiss Y, Durand F, et al. Efficient marginal likelihood optimization in blind deconvolution[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2011: 2657-2664.

[136]Ren D, Zhang K, Wang Q, et al. Neural blind deconvolution using deep priors[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2020: 3338-3347.

[137]Whyte O, Sivic J, Zisserman A. Deblurring shaken and partially saturated images[J]. International Journal of Computer Vision, 2014, 110(2): 185-201.

[138]Hirsch M, Schuler C J, Harmeling S, et al. Fast removal of non-uniform camera shake[C]. IEEE International Conference on Computer Vision, 2011: 463-470.

[139]Michaeli T, Irani M. Blind deblurring using internal patch recurrence[C]. European Conference on Computer Vision, 2014: 783-798.

[140]Perrone D, Favaro P. Total variation blind deconvolution: the devil is in the details[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2014: 2909-2916.

[141]Hu Z, Cho S, Wang J, et al. Low-light images with light streaks[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2014: 3382-3389.

[142]Wang L, Yang Q, Wang C, et al. Coarse-to-fine mechanisms mitigate diffusion limitations on image restoration[J]. Computer Vision and Image Understanding, 2024, 248: 104118.

[143]Niu A, Zhang K, Pham T X, et al. CDPMSR: Conditional diffusion probabilistic models for single image super-resolution[C]. IEEE International Conference on Image Processing, 2023: 615-619.

[144]Shen Z, Wang W, Lu X, et al. Human-aware motion deblurring[C]. IEEE International Conference on Computer Vision, 2019: 5571-5580.

[145]Rim J, Lee H, Won J, et al. Real-World Blur Dataset for Learning and Benchmarking Deblurring Algorithms[C]. European Conference on Computer Vision, 2020: 184-201.

中国知网 https://www.cnki.net

[146]Shnayderman A, Gusev A, Eskicioglu A M. An SVD-based grayscale image quality measure for local and global assessment[J]. IEEE Transactions on Image Processing, 2006, 15(2): 422-429.

[147]Zhang R, Isola P, Efros A A, et al. The unreasonable effectiveness of deep features as a perceptual metric[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2018: 586-595.

[148]Zamir S W, Arora A, Khan S, et al. Multi-stage progressive image restoration[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2021: 14821-14831.

[149]Mou C, Wang Q, Zhang J. Deep generalized unfolding networks for image restoration[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2022: 17399-17410.

[150]Chen L, Lu X, Zhang J, et al. HINet: Half instance normalization network for image restoration[C]. IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2021: 182-192.

[151]Luo Z, Gustafsson F K, Zhao Z, et al. Image restoration with mean-reverting stochastic differential equations[C]. International Conference on Machine Learning, 2023: 23045-23066.

中国知网 https://www.cnki.net