博士学位论文

基于加权关键帧与 FSC-McCNN 的浮选过程双目相机标定

Binocular Camera Calibration for Flotation Process Based on Weighted Keyframes and FSC-McCNN

一 级 学 科	控制科学与工程
二 级 学 科	检测技术与自动化装置
作 者 姓 名	罗金
指 导 教 师	唐朝晖 教授

2025 年 5 月

中国知网 https://www.cnki.net

中图分类号 TP29　　学校代码 10533
UDC 62　　学位类别 学术学位

博士学位论文

基于加权关键帧与FSC-McCNN的浮选过程双目相机标定

Binocular Camera Calibration for Flotation Process Based on Weighted Keyframes and FSC-McCNN

作 者 姓 名　罗金
一 级 学 科　控制科学与工程
二 级 学 科　检测技术与自动化装置
研 究 方 向　机器视觉与机器学习
二级培养单位　自动化学院
指 导 教 师　唐朝晖 教授

论文答辩日期 2025.5.16　　答辩委员会主席

中 南 大 学
2025 年 5 月

中国知网 https://www.cnki.net

基于加权关键帧与 FSC-McCNN 的浮选过程双目相机标定

摘要：泡沫浮选过程中表层泡沫的立体结构信息直接反映生产过程优劣，相机标定是进行表层泡沫三维形态重构的基础和关键。工业浮选现场外部环境复杂多变，关键监测目标通常不包含平行直线、二次曲线等特定的几何特征。同时设备安装空间受限、标定操作受限，不能为相机标定提供精确的相机移动信息，难以获取具有理想位姿的高质量标定图像，使得现有标定方法难以满足浮选过程的标定需求。为此，以锌浮选过程的双目立体视觉系统为研究对象，研究基于加权关键帧与 FSC-McCNN 的浮选过程相机标定方法。

论文主要围绕“失焦平面板图像复原”、“浮选过程相机内参标定”、“双目特征点同步校正”和“双目相机外参标定”四个挑战开展研究，提出基于分块掩码调制 U 形网络(ROI-Patched Mask Adaptive Modulation-UNet，RPMU-NET)的浮选过程失焦平面板图像复原方法、基于关键帧提取和位姿加权的浮选过程相机内参标定方法、基于闭环混合优化的双目特征点同步校正方法和基于特征编码卷积网络(Feature Spatial Coding-Multi-channel Convolutional Neural Networks，FSC-McCNN)的浮选过程双目外参标定方法，并在此基础上形成泡沫浮选过程相机标定系统。论文的主要研究工作和创新性成果如下：

(1) 针对因平面板倾斜、成像距离差异导致的标定板图像失焦模糊、标定效率低的问题，提出了基于 RPMU-NET 的浮选过程失焦平面板图像复原方法。该方法针对圆形标定板构建了基于自适应掩码调制的编码解码器模型 MAM-UNet，通过对泡沫图像的感兴趣区域执行特征引导的图像块分割操作来提升模型效率，并利用 CUDA 线程阵列对具有不同模糊程度的特征区块实施并行计算，同时引入渐进式策略训练深度复原网络，为相机内参标定提供高精度特征。

(2) 针对因操作环境受限、标定板非线性运动、位姿不可控等因素导致的基于泡沫视频进行相机内参标定难的问题，提出了基于关键帧提取和位姿加权的浮选过程相机内参标定方法。在进行失焦平面板图像复原的基础上，利用标定物几何特征从原始泡沫视频中提取高质

中国知网 https://www.cnki.net

量图像序列，通过量化平面板倾斜度构建图像质量评价模型，以提取泡沫视频内参关键帧，同时引入图像质量差异来计算关键帧图像序列的位姿权重，并使用加权归一化位姿差异求解相机内参，提高了浮选过程相机内参标定的鲁棒性。

(3) 针对浮选过程复杂外部光源环境及硬件差异导致的双目相机成像时间异步的问题，提出了基于闭环混合优化的双目特征点同步校正方法。该方法构建了浮选过程双目相机的时间序列模型，通过双目时序分析进行左右相机初始延时估计；为适应浮选过程平面板的随机运动，使用特征匹配点预测方法从左右视图序列中提取右相机特征匹配点坐标；最后，利用差分进化算法和希尔爬升算法研发了闭环混合优化模型，以实现异步双目特征点的闭环校正，提升了异步相机的特征匹配度，为准确的双目相机外参标定奠定了基础。

(4) 针对浮选过程液位波动、相机视角变化等情况下双目外参高精度标定能力受限的问题，提出了基于 FSC-McCNN 的浮选过程双目外参标定方法。该方法在进行双目特征点同步校正的基础上，进行双目相机参数初始化，利用无畸变的虚拟成像场景构建了表征特征图谱和相机参数之间映射关系的合成数据集，实施了基于边界约束的合成数据增强，并研发了深度标定网络 FSC-McCNN，深度挖掘不同位姿特征图像的空间信息，提升了浮选过程双目相机外参标定性能。

(5) 结合本文研究成果，搭建了泡沫浮选过程相机标定平台，研发基于加权关键帧与 FSC-McCNN 的浮选过程相机标定系统，应用于某锌浮选过程的立体视觉系统，实现双目相机内外参数的有效标定，应用效果良好，验证了所提理论和方法的有效性。

图 69 幅，表 27 个，参考文献 201 篇

关键词：相机标定；失焦图像复原；关键帧提取；深度标定网络；双目视觉系统；双目特征点校正；泡沫浮选
分类号：TP29

中国知网 https://www.cnki.net

Binocular Camera Calibration for Flotation Process Based on Weighted Keyframes and FSC-McCNN

Abstract: The three-dimensional structural information of the surface froth in the flotation process directly reflects the quality of the production process, and camera calibration is the foundation and key to reconstructing the three-dimensional morphology of the surface froth. The external environment of industrial flotation sites is complex and variable, and the key monitoring targets usually do not contain specific geometric features such as parallel lines or quadratic curves. Additionally, limited installation space and operational constraints prevent the provision of precise camera movement information for calibration, making it difficult to obtain high-quality calibration images with ideal poses. As a result, existing calibration methods struggle to meet the calibration requirements of the flotation process. Therefore, this study focuses on the binocular stereo vision system of the zinc flotation process and investigates a camera calibration method based on weighted keyframes and FSC-McCNN for the flotation process.

The thesis primarily addresses four challenges: "defocused calibration plate image restoration," "camera intrinsic parameter calibration for the flotation process," "binocular feature point synchronization correction," and "binocular camera extrinsic parameter calibration." It proposes a defocused calibration pattern image restoration method for the flotation process based on ROI-Patched Mask Adaptive Modulation-UNet (RPMU-NET), a camera intrinsic parameter calibration method based on keyframe extraction and pose weighting, a binocular feature point synchronization correction method based on closed-loop hybrid optimization, and a binocular extrinsic parameter calibration method for the flotation process based on Feature Spatial Coding-Multi-channel Convolutional Neural Networks (FSC-McCNN). On this basis, a camera calibration system for the froth flotation process is developed. The main research work and

中国知网 https://www.cnki.net

innovative achievements of the thesis are as follows:

(1) To address the issues of defocused and blurred calibration plate images and low calibration efficiency caused by the tilt of the planar plate and differences in imaging distance, a defocused plate image restoration method for the flotation process based on RPMU-NET is proposed. This method constructs an encoder-decoder model, MAM-UNet, based on adaptive mask modulation for circular plates. It improves model efficiency by performing feature-guided image patch segmentation on regions of interest in froth images, and utilizes CUDA thread arrays for parallel computation of feature blocks with varying degrees of blur. Additionally, a progressive strategy is introduced to train the deep network, providing high-precision features for camera intrinsic parameter calibration.

(2) Aiming at the difficulty of camera intrinsic calibration based on froth videos caused by factors such as restricted operating environments, non-linear motion of planar plate, and uncontrollable poses, a flotation process camera intrinsic calibration method based on keyframe extraction and pose weighting is proposed. Building on the restoration of defocused calibration plate images, high-quality image sequences are extracted from the original froth video using the geometric features of the calibration object. An image quality evaluation model is constructed by quantifying the tilt of the planar plate to extract intrinsic parameter keyframes from the froth video. The pose weights of the keyframe image sequence are calculated based on image quality differences, and the camera intrinsic parameters are solved using weighted normalized pose differences, improving the robustness of camera intrinsic parameter calibration for the flotation process.

(3) To address the issue of asynchronous imaging times in binocular cameras caused by complex external lighting environments and hardware differences in the flotation process, a binocular feature point synchronization correction method based on closed-loop hybrid optimization is proposed. This method constructs a time series model for the binocular cameras in the flotation process and estimates the initial delay between the left and right cameras through binocular temporal analysis. To adapt to the random motion of the planar plate in the flotation process, a

中国知网 https://www.cnki.net

feature matching point prediction method is used to extract the coordinates of feature matching points from the right camera's view sequence. Finally, a closed-loop hybrid optimization model is developed using differential evolution and hill-climbing algorithms to achieve closed-loop correction of asynchronous binocular feature points, improving the feature matching accuracy of asynchronous cameras and laying the foundation for accurate binocular camera extrinsic parameter calibration.

(4) To address the limitations of high-precision binocular extrinsic parameter calibration in the flotation process under conditions such as liquid level fluctuations and changes in camera perspective, a binocular extrinsic parameter calibration method for the flotation process based on FSC-McCNN is proposed. Building on the synchronization correction of binocular feature points, this method initializes the binocular camera parameters and constructs a synthetic dataset representing the mapping relationship between feature maps and camera parameters using a distortion-free virtual imaging scene. Data augmentation based on boundary constraints is implemented, and a deep calibration network, FSC-McCNN, is developed to deeply explore the spatial information of feature images from different poses, improving the performance of binocular camera extrinsic parameter calibration for the flotation process.

(5) Combining the research results of this thesis, a camera calibration platform for the froth flotation process is established, and a camera calibration system based on weighted keyframes and FSC-McCNN is developed. This system is applied to the stereo vision system of a zinc flotation process, achieving effective calibration of the intrinsic and extrinsic parameters of the binocular cameras. The application results are satisfactory, validating the effectiveness of the proposed theories and methods.

Keywords: Camera calibration; out-of-focus image restoration; key frame extraction; deep calibration network; binocular vision system; binocular feature point correction; froth flotation
Classification: TP29

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 基于图像特征点修正的相机标定方法研究现状.....3
1.2.2 基于深度学习的相机标定方法研究现状.....5
1.2.3 工业相机标定方法研究现状.....9
1.3 本文主要内容及结构安排.....15
第 2 章 基于加权关键帧与 FSC-McCNN 的相机标定框架.....18
2.1 相机标定过程分析.....18
2.1.1 相机标定原理.....18
2.1.2 常规环境下的相机标定.....21
2.2 影响泡沫浮选过程相机标定的因素分析.....23
2.2.1 泡沫浮选过程相机标定环境.....23
2.2.2 泡沫浮选过程受限环境下相机标定的影响因素分析.....25
2.3 基于加权关键帧与 FSC-McCNN 的相机标定框架.....29
2.3.1 泡沫浮选过程相机标定难点.....29
2.3.2 基于加权关键帧与 FSC-McCNN 的相机标定框架.....30
2.4 本章小结.....32
第 3 章 基于 RPMU-NET 的浮选过程失焦平面板图像复原.....33
3.1 基于 RPMU-NET 的浮选过程失焦平面板图像复原方案.....33
3.2 RPMU-NET 网络架构.....34
3.2.1 特征引导的图像块分割.....34
3.2.2 基于平面板图像特征分区的并行计算.....36
3.2.3 基于自适应掩码调制的编码解码器模型.....37
3.3 基于失焦平面板图像复原的浮选过程相机标定实现.....44
3.3.1 基于预训练-微调数据集的渐进式模型训练.....44
3.3.2 基于失焦平面板图像复原的浮选过程相机标定实现步骤.....46
3.4 基于 RPMU-NET 图像复原的浮选过程失焦相机标定效果验证.....47
3.4.1 实验数据集、模型性能评估及对比模型.....47
3.4.2 RPMU-NET 模型消融实验.....49
3.4.3 失焦相机标定虚拟仿真实验.....50
3.4.4 失焦相机标定工业应用实验.....55
3.5 本章小结.....59

中国知网 https://www.cnki.net

第 4 章 基于关键帧提取和位姿加权的工业相机内参标定 60
4.1 基于关键帧提取和位姿加权的浮选过程相机内参标定框架 60
4.2 基于图像质量评价的泡沫视频关键帧提取 61
4.2.1 泡沫视频序列预处理.....62
4.2.2 基于平面板倾斜度的图像质量评价方法 63
4.2.3 基于高质量图像序列质量差异的泡沫视频内参关键帧提取 67
4.3 基于加权位姿差异的相机内参计算 68
4.3.1 基于平面板位姿表征的关键帧图像序列内参权重计算 69
4.3.2 基于加权归一化位姿差异的相机内参标定 69
4.4 基于关键帧提取和位姿加权的相机内参标定效果验证 70
4.4.1 相机标定数据集及性能评估指标.....70
4.4.2 基于关键帧提取和位姿加权的相机内参标定方法消融实验 71
4.4.3 相机标定虚拟仿真实验.....72
4.4.4 相机标定工业应用实验.....73
4.5 本章小结.....78
第 5 章 基于闭环混合优化的双目特征点同步校正 79
5.1 基于闭环混合优化的双目相机特征点同步校正方案 79
5.2 基于双目时序分析的浮选过程双目相机初始延时估计 80
5.2.1 浮选过程双目图像外参关键帧提取.....80
5.2.2 浮选过程双目相机时间序列模型构建 81
5.2.3 基于双目时序分析的初始延时估计.....82
5.3 基于闭环混合优化的浮选过程双目相机特征点同步校正 82
5.3.1 基于左右视图序列的右相机特征匹配点预测 83
5.3.2 基于闭环策略及 HC-IDE 混合优化的双目特征点同步校正 84
5.4 基于特征点同步校正的双目相机标定效果验证 88
5.4.1 实验数据集、模型性能评估及对比模型 88
5.4.2 特征匹配点预测模块的有效性验证.....90
5.4.3 闭环混合优化模型的有效性验证.....91
5.4.4 实验室环境下的异步相机外参标定实验 91
5.4.5 泡沫浮选环境下的异步相机外参标定工业应用实验 94
5.5 本章小结.....97
第 6 章 基于 FSC-McCNN 的浮选过程双目外参标定.....98
6.1 基于 FSC-McCNN 的浮选过程相机标定框架.....98
6.2 FSC-McCNN 网络架构 99
6.2.1 基于双目特征点同步校正的相机参数初始化 99

中国知网 https://www.cnki.net

6.2.2 基于边界约束的合成数据增强.....100
6.2.3 基于特征空间编码的深度标定网络构建.....103
6.3 基于 FSC-McCNN 的浮选过程双目外参标定实现.....106
6.3.1 基于标定损失解耦的 FSC-McCNN 模型训练.....106
6.3.2 基于 FSC-McCNN 的浮选过程双目外参标定实现步骤..107
6.4 基于 FSC-McCNN 的双目外参标定效果验证.....108
6.4.1 实验数据集、模型性能评估及对比模型.....108
6.4.2 FSC-McCNN 的有效性验证.....109
6.4.3 双目平面板图像外参标定虚拟仿真实验.....110
6.4.4 双目平面板图像外参标定工业应用实验.....113
6.5 本章小结.....118
第 7 章 泡沫浮选过程相机标定系统.....119
7.1 泡沫浮选过程相机标定系统功能需求.....119
7.2 浮选过程相机标定系统设计与实现.....120
7.2.1 硬件系统设计与实现.....120
7.2.2 软件系统设计与实现.....122
7.3 本章小结.....127
第 8 章 结论与展望.....128
8.1 主要结论.....128
8.2 工作展望.....129
参考文献.....131

中国知网 https://www.cnki.net

第 1 章 绪论

泡沫浮选是一种广泛应用于选矿过程的技术，其核心原理是利用矿物颗粒表面性质的差异（如疏水性），使有用矿物颗粒与气泡结合并浮至矿浆表面，从而实现与杂质的有效分离。泡沫浮选过程中，气泡立体形状、泡沫层高度等立体信息是浮选工况识别不可或缺的因素。有效获取泡沫层的立体视觉信息是实现泡沫浮选过程工况智能精细化感知的前提。要进行精确的泡沫形态重构，准确、高效、灵活的工业相机标定是关键。深入研究泡沫浮选过程受限环境下的工业相机标定理论和方法，可进一步降低双目图像中的畸变和误差，提高图像测量精度和机器视觉系统稳定性，确保泡沫表观特征在双目视图中的准确表达，为后续的三维重建和数据挖掘提供可靠依据，具有十分重要的研究价值和现实意义。本章结合研究背景，探讨泡沫浮选过程受限环境下的工业相机标定的研究意义，通过国内外现状分析，指出了目前泡沫浮选过程工业相机标定存在的挑战，并给出了本文的主要内容和结构安排。

1.1 研究背景及意义

自然界中的矿产资源通常难以直接应用于工业生产和日常生活，需进行选矿加工后才能有效利用[1]。随着全球资源日益紧张和生态环保意识的增强，传统粗放式的矿产资源开发模式已难以为继。在此背景下，选矿过程的智能化生产日益重要。智能化选矿通过应用人工智能、大数据分析、机器学习等先进技术，能够实现对浮选过程工况的高精度三维检测，优化选矿流程，提高资源回收率和产品质量，同时减少能源消耗和环境污染。选矿过程的智能化转型，不仅是应对资源挑战、实现绿色发展的有效途径，也是推动矿业行业高质量发展的新引擎[2, 3]。推进生产过程智能化，是实现复杂工业过程绿色化、高效化发展的关键，是全面落实“三高四新”战略定位和使命任务的重要内容[4-7]。

泡沫浮选主要包括矿物混合、搅拌、充气、上浮和分离过程，其工艺流程长，包含固、液、气多相交互的复杂物理、化学反应[8]。浮选过程的表层泡沫状态直接反映生产过程运行优劣及发展态势，是及时制定并调整生产过程操作策略的前提[9, 10]。此外，与泡沫浮选过程状态相关的变量数目众多，受生产环境及工艺流程等因素限制，很难实现表层泡沫状态的直接检测[11]。

机器视觉可模仿人类的视觉系统来感知和检测工业流程中的重要目标，它具有无接触操作、易维护和实时监控等特点，在国内外的学术研究和工业应用中都受到了广泛的关注[12-17]。采用机器视觉技术可获得浮选生产过程关键监测目标视

中国知网 https://www.cnki.net

觉信息，是泡沫浮选过程表层泡沫形态重构的重要手段[18-20]。在泡沫浮选生产过程中，核心监控指标往往展现出三维形态特征，诸如浮选槽表层泡沫的三维形状、泡沫层垂直维度等三维信息，构成了浮选状态辨识不可或缺的要素。精确且高效地捕获这些核心监控指标的三维视觉数据，是实现浮选工业流程状态智能化检测的核心途径。

双目立体视觉根据视差原理，通过左右视图获取监测目标的立体视觉信息，是一种典型的被动测量三维重建方法[21,22]。该方法具有效率高、系统结构简单等优点，非常适合于泡沫浮选工业现场关键监测目标立体视觉信息的非接触式测量[23,24]。将双目立体视觉引入浮选工业过程监测，能进一步提高工业过程感知能力，提升工业过程智能监测水平。

双目相机同步标定是同步求解双目相机内外参数的过程，是采用双目立体视觉技术准确获取监测目标立体信息的基础和关键[25-27]。同时，准确稳定的双目相机标定对于提取三维泡沫特征和实时非接触式泡沫层厚度测量等应用非常重要。其中，精确的相机内参能确保图像中的泡沫特征能够正确地映射到三维空间中，从而可以精确分析泡沫的形态、大小和分布。此外，在泡沫浮选过程中，精确的相机外参能确保来自不同视角的泡沫图像能够正确地配准和融合，从而能够评估相机在三维空间中的位置和方向，以全面分析泡沫的动态过程，这有助于更准确地追踪泡沫轨迹，为浮选过程的智能控制提供强有力的支持。

近些年，不少学者对相机标定方法进行了研究和改进，取得了良好的应用效果，但是现有方法应用场景较为简单，通常具备良好的拍摄环境和操作条件，待监测目标清晰、显著。然而在矿物浮选工业过程中，拍摄环境和操作条件受限，待监测目标复杂多变，使得现有相机标定方法准确性不高，鲁棒性不强。

为此，本文以部署于某铅锌矿的双目视觉系统为研究对象，研究泡沫浮选过程受限环境下的工业相机标定方法，探索一种便捷、准确且鲁棒性高的工业相机内外参数求解方案，解决泡沫浮选过程中工业相机标定存在的若干问题，对提高相机标定性能，准确获取浮选过程关键监测目标的立体视觉信息，提升泡沫浮选过程的智能化水平，促进工业过程的稳定运行有积极的推动作用。

本文得到国家重点研发计划“冶炼炉高温强冲击载荷作业机器人技术研究与研发应用(2023YFB4706900)”、国家自然科学基金面上项目“基于双目立体视觉的复杂工业过程工况智能精细化感知(62171476)”和国家自然科学基金重点项目“基于全流程性能退化评估的矿物浮选过程智能协同优化(62233018)”的资助开展研究。针对泡沫浮选过程工业相机标定中的难点问题，开展泡沫浮选过程受限环境下的工业相机标定方法研究，提出基于 RPMU-NET 的浮选过程失焦平面板图像复原方法、基于关键帧提取和位姿加权的浮选工业相机内参标定方法，并针对双

中国知网 https://www.cnki.net

目立体视觉提出基于闭环混合优化的双目特征点同步校正方法、构建基于 FSC-McCNN 的浮选过程双目外参标定模型。通过虚拟成像场景进行仿真实验，并利用工业过程数据进行应用实验验证，为泡沫浮选过程受限环境下的工业相机标定提供切实有效的理论方法和技术支撑，对其他复杂工业过程的双目相机内外参标定具有重要的参考价值。

1.2 国内外研究现状

在泡沫浮选过程等工业环境下，由于安装环境、拍摄环境、操作环境受限，难以获取满意的标定物位姿图像，进行特征点修正是提升标定精度的主要手段之一。因此，本节首先对基于图像特征点修正的相机标定方法研究现状进行介绍。近年来，随着深度学习技术的快速发展，深度学习和相机标定技术的融合受到了广泛关注。因此，本节随后对基于深度学习的相机标定方法研究现状进行介绍。最后，本节对工业相机标定方法的研究现状进行了介绍。

1.2.1 基于图像特征点修正的相机标定方法研究现状

在图像测量和机器视觉应用中，相机标定是确定空间物体表面某点的三维几何位置与其在图像中对应点之间相互关系的关键步骤。通过相机标定，可以建立相机成像的几何模型，进而求解相机参数。基于图像特征点修正的相机标定方法通过修正标定物图像的特征点信息来优化相机参数，可以进一步提高相机标定的精度和稳定性。图像特征点修正方法主要可分为退化图像特征点修正和双目图像异步特征点修正。

(1) 基于退化图像特征点修正的相机标定

基于退化图像特征点修正的相机标定方法针对图像在捕获、传输和记录过程中由于各种因素导致的模糊、畸变、噪声等退化问题，通过对退化图像进行预处理、特征点提取、匹配和修正等步骤，来减少图像退化对相机标定精度的影响。

Datta 等人[28]采用初始相机参数对标定图像进行去畸变处理并反投影至正则平面，然后基于正则平面对图像特征点坐标进行迭代优化，并重新计算相机参数直至收敛，该方法通过提升特征点定位精度有效增强了相机标定的准确性。Bu 等人[29]采用同心圆网格作为标定模板，提出了一种鲁棒、精确的图像特征点修正方法。该方法根据同心圆的几何特性，使用局部亚像素边缘检测算法在投影变换下修正特征点的亚像素坐标，以最小化图像噪声、畸变和分辨率的影响。Cheng 等人[30]提出了一种基于周期性相位网格模式的相机标定方法，该方法通过角度校正与相位估计来修正图像特征点坐标，并计算图像倾斜角以校正透视畸变，在应对图像模糊、噪声及光照不均匀等退化图像时展现出良好的精度与鲁棒性。Huang 等人[31]针对相机标定过程中目标不完整且缺乏预测量的情况，运用标定目

中国知网 https://www.cnki.net

标的几何特征设计了一种约束优化方法，该方法在图案设计的统计约束条件下对图像特征点进行精细修正，从而有效提升了测量精度。Nakano 等人[32]针对透视投影和镜头缺陷引起的平面板图像畸变，提出了一种基于特征点修正和相机参数迭代优化的标定方法。该方法使用估计的畸变参数进行图像复原，然后基于复原图像进行特征点坐标修正，以提取更精确的相机参数。Huang 等人[33]采用正弦条纹图作为主动相位目标，结合基于统计约束的光束法平差技术对图像特征点进行修正。该方法利用多项式拟合法提升了特征检测的准确度，实验结果显示可有效降低重投影误差。

近年来，为了对相机镜头未正确对焦而产生的模糊图像进行精确标定，失焦图像特征点修正获得了广泛关注。Meng 等人[34]提出了一种离焦不敏感的特征点编码模板，通过基于 Swin Transformer 的相位恢复网络修正图像特征点，最后基于虚拟转换误差对相机参数进行优化，该方法可有效应用于隧道掘进机施工的大视场双目相机标定。Huo 等人[35]提出了一种相机失焦区域标定方法，该方法采用基于相位编码的圆形标定模式，并设计了基于深度学习的相位恢复网络，通过校正恢复的相位图中的椭圆偏心率，获得相机标定所需的精确特征点。Huo 等人[36]首先使用传统方法进行失焦相机初始标定，然后基于修正图像独立求解相机畸变系数，建立像距转换模型，解耦中间参数以得到相机参数的线性优化解，该方法具有良好的抗噪声性能，可实现灵活的离焦相机标定。Ding 等人[37]提取了失焦图像中标定物的核心几何特征，然后运用几何运算精确估算图像的离焦程度，并通过图像增强来修正特征点坐标，实验表明该方法在较大离焦范围内能取得高精度的标定结果。Liu 等人[38]针对由透视畸变和失焦模糊导致的标定板图像特征点定位偏差，基于 Levenberg-Marquardt 优化算法提出了一种鲁棒的特征点坐标修正方法，有效满足了相机精确对焦及特征点高精度检测的传统标定需求。此外，Wang 等人[39]提出了一种基于常规周期目标的离焦相机标定方法，该方法利用傅里叶变换从周期性目标图像中恢复交叉相位图，进而在相位域中提取修正后的图像特征点，实验表明该方法能同时对聚焦和失焦图像进行精确标定。Chen 等人[40]提出了一种鲁棒的抗散焦图像特征点检测方法，用于提取平面正方形周期目标的中心或角点坐标，同时利用傅里叶变换计算周期性目标图像的相位映射，并据此修正图像特征点，以提升标定精度。Heikkinen 等人[41]提出了一种基于衍射的失焦相机自标定方法，该方法无需借助外部传感器，直接从捕获的散斑图像中提取失焦图像的特定几何特征，进而通过激光照明与散斑衍射分析相结合的手段精确求解相机参数。Choi 等人[42]提出了一种直观的提取模糊图像特征点的方法，该方法通过动态调整标定图案中圆的大小，并利用累积同心圆的梯度信息来修正模糊程度变化时的图像特征点，从而精确求解严重失焦图像的相机参数。

中国知网 https://www.cnki.net

(2) 基于双目图像异步特征点修正的相机标定

基于双目图像异步特征点修正的相机标定方法广泛应用于机器人导航、自动驾驶等领域[43]。该方法主要是利用特征点修正技术对提取的双目图像异步特征点进行优化，以提高双目相机外参标定的精度。

双目图像异步特征点修正方法主要可分为基于硬件的异步特征点修正方法和基于软件的异步特征点修正方法。基于硬件的修正方法主要侧重于通过直接调节相机硬件参数来校正双目图像。例如，Yao 等人[44]提出了一种双目相机异步运动估计方法，该方法利用高速相机的可扩展时间间隔捕获双帧图像，并设计了专用的硬件架构来实现透视变换和信号滤波，以降低双目相机拍摄时的异步性和亮度差异，从而有效修正了异步图像特征点并显著提升了测量速度上限。Cai 等人[45]构建了基于高速工业相机和双目视觉的轨迹提取系统，通过集成图像采集卡与控制系统以最小化信号传输影响，并实施了一种基于滤波的双目同步转换方案，有效减弱了异步图像采集的影响。Chen 等人[46]针对动态图像捕获场景，设计了一种可调基线和相对角的立体图像采集系统，并提出了一种物理方法测量双目相机延迟。该方法首先测量相机在外部信号触发下的最大帧率，然后通过自由落体实验测量最大帧率下触发间隔的延迟，有效降低了双目图像特征点的异步差异。

基于软件的异步特征点修正方法主要利用图像处理算法处理异步双目图像，降低畸变和差异，以实现图像的时间一致性。例如，针对因相机不同步或相机曝光时间不连贯导致的左右相机图像不匹配问题，Yin 等人[47]提出了一种基于时间校正的双目相机标定方法，利用两相邻图像帧之间的时间信息对异步图像特征点进行线性插值修正，有效标定了手动平面板图像序列，提高了双目相机标定的准确度。此外，鉴于线性插值在相机同步过程的平滑性不足，Wang 等人[48]引入三次插值法来自动标定机器人相机-编码器系统的外部参数。该方法同步处理与当前图像最近的四个采样数据点，并应用最小二乘法成功实现了比传统线性方法更高精度的数据同步。进一步地，Hu 等人[49]通过修正运动的异步双目相机，提出了一种基于双目视觉系统的运动位姿重建方法。该方法针对立体视觉系统专门构建了运动目标启动时间误差的几何模型，并利用虚拟目标点在等间隔的时间差下搜索特征匹配点，从而显著提升了双目图像的时间一致性。

1.2.2 基于深度学习的相机标定方法研究现状

传统的相机标定方法通常依赖于繁琐的人工干预和特定的场景假设，难以灵活拓展至不同的相机模型和标定场景。因此，基于深度学习的相机标定方法应运而生，旨在实现全自动化的标定过程，提高标定的效率和准确性。基于深度学习的相机标定方法在多个领域展现了广泛的应用潜力，包括机器人视觉、增强现实、

中国知网 https://www.cnki.net

无人驾驶和工业检测等[50]。基于深度学习的相机标定方法根据所求解的参数类别可分为内参标定、外参标定以及内外参联合标定。

(1) 基于深度学习的相机内参标定

基于深度学习的相机内参标定方法通过先进的神经网络架构和学习策略，基于原始图像实现了对相机内参的高效和精确标定。目前，基于深度学习的相机内参标定方法主要用于确定如焦距、主点位置、畸变系数等参数。

作为使用深度学习进行相机内参标定的先驱，Workman 等人[51]使用深度卷积神经网络对从互联网图片集获得的自然图像进行训练，仅使用原始像素强度作为输入特征直接估计相机焦距，该方法不要求在视场中出现特定的几何标定对象。针对由于组件磨损、温度波动或碰撞等外部干扰导致的相机参数变化，Cramariuc 等人[52]提出了一种数据驱动的方法来学习 RGB 相机参数，通过训练深度卷积神经网络，该方法可对重新标定相机内参的必要性进行评估。Duan 等人[53]提出了一种基于双分支深度神经网络的大视场相机标定方法，通过一个小的标定对象将视场划分为具有部分重叠区域的子区域，然后将子区域融合到一个全局框架中，并输入双分支深度神经网络以优化求解相机内参。DeTone 等人[54]运用深度卷积神经网络，直接以两张堆叠的灰度图像为输入，估计它们之间的相对单应性。该方法无需额外的局部特征检测和转换估计步骤，即可生成多自由度同形图，将第一张图像的像素映射至第二张图像，从而估算内参单应性矩阵。Nguyen 等人[55]提出了一种无监督学习算法，该算法训练深度卷积神经网络来估计多幅航拍图像之间的单应性矩阵，该方法传统方法具有更快的推理速度，同时保持了较好的精度和对光照变化的鲁棒性。Cao 等人[56]提出了一种创新的深度单应性估计架构—迭代单应性网络，该网络可分别处理用于静态场景以及具有运动物体的动态场景，并在处理序列图像对时展现了较高的精度和效率。

此外，Rong 等人[57]运用卷积神经网络（CNN）技术，实现了图像径向畸变的校正。他们通过 CNN 合成径向畸变图像，有效缓解了训练数据匮乏的难题。实验证明，该方法在与多种基线方法的对比中，能够准确估计径向畸变。Bogdan 等人[58]提出了一种全自动深度学习方法来标定宽视场摄像机，该方法通过大量全向图像自动生成大规模数据集，该数据集包含具有真实地面内在参数的宽视场图像，进而实现仅从单个输入图像即可自动估计相机的内参（包括焦距和失真参数）。Yang 等人[59]设计了一种无监督的鱼眼相机校正网络，通过预测相机畸变参数来校正鱼眼图像中的显著畸变。此外，他们利用预测的畸变参数有效填补因不可逆映射函数而产生的图像空洞区域，展现出良好的精度和灵活性。Zhao 等人[60]提出了一种简洁高效的图像径向畸变校正方法，该方法通过两个可微层来合成并校正畸变图像。同时，他们引入了一种在线数据合成策略，结合采样网格损

中国知网 https://www.cnki.net

失与图像重投影损失来提升畸变校正的精度。Liao 等人[61]提出了一种畸变校正生成对抗网络，专门用于处理广角镜头拍摄的图像。该网络不估计相机畸变参数，而是通过学习不同结构图像间的映射关系来实现无监督图像校正，具备校正速度快的优势。

(2) 基于深度学习的相机外参标定

相机外参标定是指在三维空间中确定相机的位置和方向，从而在图像中获取准确的尺寸和形状。传统的相机外参标定方法通常采用手动标定或者基于传统图像处理算法的自动标定，但这些方法通常需要大量的标定物和人为干预，且精度有限。基于深度学习的相机外参标定为确定相机在三维空间中的位置和方向提供了高效、智能的方法，目前主要用于确定旋转向量、位移向量等外部参数[62]。

Kendall 等人[63]率先研发出一种鲁棒且实时的单目相机多姿态定位系统，该系统通过训练卷积神经网络实现了从单个 RGB 图像中直接预测多种相机姿态的功能，无需依赖额外的图形优化措施，且对光照变化和运动模糊具有良好的鲁棒性。在此基础上，Jau 等人[64]构建了一个端到端的可训练外部参数标定框架，该框架集成了检测、特征提取、匹配及异常值剔除的可学习模块，并直接针对几何位姿目标进行优化，此方法对新数据集展现了良好的泛化能力。Xian 等人[65]提出了一个融合显式几何推理的端到端深度学习框架，该框架利用可微最小二乘模块预测相机方向，并通过真实相机姿势及其对应几何形状进行监督学习，此方法在单图像相机定位任务上表现优异。Gil 等人[66]提出了一种结合立体深度图和单目深度图的在线自标定方法，通过增强两者间的一致性实现外参标定，该方法利用预训练网络的全局上下文信息有效规避了异常值问题。Chen 等人[67]针对相机运动引起的显著视角变化，采用新型参数化方法预测相机相对姿态空间上的离散分布，简化了参数估计，提升了位姿回归精度，并有效减少了外参标定误差。

此外，Parameshwara 等人[68]分离了相机的三维运动与深度估计，仅依赖法向流图像梯度计算三维运动，并通过深度网络端到端学习相对相机姿态，该方法展现出优异的噪声鲁棒性和跨数据集泛化能力。Do 等人[69]运用深度学习提出了一项创新的相机定位技术，该技术将稀疏而关键的 3D 场景点外观隐式编码至卷积神经网络内，随后在图像中识别这些特征点以实现相机定位，从而无需存储图像特征或详尽的 3D 点云数据。Yang 等人[70]构建了一个深度学习框架以实现视觉定位，首先依据图像匹配信息对数据库帧进行聚类，随后基于姿态估计精度对各聚类点进行精细修剪，并进一步压缩选定点的特征，这一方法能够在保持低内存占用的同时，确保相机定位的精度。为标定远距离不同摄像机间的外参，Su 等人[71]采用球面标定物建立视点对应，并运用多样视图变换函数建模相机外参，以增强算法鲁棒性，此外他们通过最小化全局三维重投影误差优化了相机参数。

中国知网 https://www.cnki.net

Nguyen 等人[72]提出了一种无需特定目标或离线设置的深度神经网络来求解激光雷达与相机间的外参，该网络采用双流 LSTM 捕捉序列数据的时间特征，通过最小化深度损失预测标定参数，并利用时间损失进一步精炼相机外参。Itu 等人[73]提出一种人工神经网络方法用于道路交通场景中的消失点检测，该方法利用经典算法自动标注大量训练数据，经手动验证后用于模型训练，以提升深度神经网络的学习性能。Aouragh 等人[74]通过单眼图像与 3D 深度信息预测激光雷达与相机的外参，该方法融合了残差网络的跳跃连接优势，并引入循环网络跟踪先前预测，从而实现了高精度的位移与旋转向量预测。

(3) 基于深度学习的相机内外参联合标定

基于深度学习的相机内外参联合标定结合了深度学习的强大能力与相机标定的实际需求，以实现对相机内外参数的精确估计。相机内外参数是描述相机成像过程的重要参数，内参描述了相机的内部属性，外参则描述了相机的外部姿态，用于将世界坐标系中的点转换到相机坐标系中。基于深度学习的相机内外参联合标定方法不需要繁琐的手动交互，可灵活实现野外、工业过程等复杂场景的自动标定，具有广阔的应用前景。

近年来，基于图像几何表示的内外参联合标定方法以其较高的精度和灵活性受到了广泛关注。Zhai 等人[75]提出了一种检测人工环境中图像消失点的方法，该方法利用深度卷积网络提取全局图像上下文信息，有效约束水平消失点候选集，从而快速求解相机内外参数。Chang 等人[76]运用卷积神经网络在谷歌街景图像数据集上训练，利用谷歌街景的相机参数和道路方向数据推断实际地面消失点，并通过设定包含可能消失点位置的输出层，将消失点检测转化为 CNN 分类问题，进而解析相机参数。Zhou 等人[77]设计了一个简单高效的端到端可训练深度网络，旨在检测图像中的消失点。该网络通过界定一个典型的二次曲线空间，并引入二次卷积，实现了与常规 2D 卷积相当维度的特征聚合，从而有效提升了标定性能。Lin 等人[78]通过融入先验知识的深度消失点检测网络，显著增强了模型的泛化能力。该方法不仅大幅减少了标注工作量和计算成本，还成功应对了现实世界的少样本挑战，有效降低了域变更的影响，从而提升了数据效率和领域变化的鲁棒性。此外，一些学者通过将图像中的无穷远直线投影到垂直于重力向量的平面上来确定地平线的位置，进而求解相机参数。Lee 等人[79]提出了一种基于端到端神经网络的单图像摄像机标定方法，该网络能有效捕捉多模态输入图像的全局结构，并通过多分类任务来训练网络从线段中提取全局几何信息，以直接从图像和一组线段中估算相机参数。Grelsson 等人[80]提出了一种基于水平线检测的高精度鱼眼相机姿态估计方法，该方法利用 Canny 边缘检测器和霍夫投票方案计算图像中的近似水平线位置，并在邻近区域提取地平线边缘像素，从而实现高精度的参数估

中国知网 https://www.cnki.net

计。Brouwers 等人[81]提出了一种用于单目静止监控摄像机的全自动标定算法，该算法仅依赖行人轨迹信息挖掘消失点几何特征，并通过优化地平线与消失点坐标来生成完整的相机参数矩阵。

此外，大量学者通过深度学习方法同时估计复合参数，以实现相机的内外参联合标定。Xiao 等人[82]创建了一个涵盖多地点类别的 360°全景图像数据库，并运用深度网络实现各类别与全景图的自动对齐，构建出周围环境的全视图表征，然后基于此数据推断相机复合参数等额外信息。Geoffroy 等人[83]利用深度卷积神经网络直接从单个图像推断相机复合参数，该网络使用大规模全景数据集自动生成样本进行训练，并开发了一种摄像机标定感知度量以全面评估深度标定网络的性能。Lee 等人[84]提出一种用于人工场景下单图像相机标定的深度几何解析网络，该网络以弱监督方式融合语义与几何线索，利用图像线段估计消失点，生成含相机旋转和焦距信息的候选点，并结合先验知识来提升标定准确性。Kocabas 等人[85]训练了一个深度神经网络用于从输入图像中估计相机内外参数，该方法引入了新的损失函数以提高标定精度，并随后构建了一个深度网络模型，有效关联相机参数与图像特征。Baradad 等人[86]设计了一个深度标定系统直接从图像像素回归其对应的 3D 世界坐标，该系统沿相机光轴预测每个像素的 3D 位置，并通过对这些世界坐标施加回归损失，显著提升了相机内外参数的预测精度。Ponimatkin 等人[87]提出了一种深度学习模型来从单个已知物体的 RGB 图像中联合估计相机的内外参数，该模型通过推导焦距更新规则来优化联合估计任务，并利用多种损失函数协同估计相机位姿和焦距。Butt 等人[88]提出了一种通过多任务学习联合估计相机内外参数的方法，该方法将相机模型方程融入神经网络，结合相机投影损失与重建损失来联合估计相机的内外参数，并将分析方程整合于学习框架中以提升模型精度。

1.2.3 工业相机标定方法研究现状

相机标定是机器视觉的基础，其目的是确定相机的内外参数，建立起三维空间物体与二维图像间的对应关系，是采用双目立体视觉获取三维立体信息的基础和关键[89]。这一技术对于后续的场景理解[90]、决策推断[91]以及三维重建[92]等任务至关重要。随着工业自动化的不断发展，相机标定技术在工业领域的应用也越来越广泛，如质量检测[93]、自动化装配[94-98]、机器人导航[99-102]等。常见的工业相机标定方法包括自标定方法、基于主动视觉的相机标定方法和基于平面模板的相机标定方法等。

(1) 相机自标定方法

相机自标定是指在没有已知标定物的情况下，通过相机拍摄的图像信息，利

中国知网 https://www.cnki.net

用标定场景中特殊几何形状（如平行直线[103]、绝对二次曲线[104]等）及其透视投影不变性求解相机的内部参数和外部参数的过程。相机自标定方法在机器视觉[105]、图像测量[106]、增强现实[107]等领域具有广泛的应用前景。例如，在机器视觉检测中，通过相机自标定可以提高检测的精度和稳定性；在增强现实中，通过相机自标定可以实现虚拟物体与真实场景的准确融合。

孟晓桥等人[108]和胡培成等人[109]利用摄影几何的直线交比不变性，采用一个平面圆和通过圆心的若干直线获得圆环点的图像坐标，然后根据绝对二次曲线的特性求取摄像机的内参，摆脱了左右图像标志点匹配问题，方法更为灵活。此外，张虎等人[110]提出了一种基于两相同圆的自标定方法，首先根据两相同圆的仿射不变性和几何特性提取圆环点并获取摄像机的内部参数，然后根据透视投影变换的相切不变性，采用两圆的内外公切线求得摄像机的外部参数，该标定方法简单、有效。Huai 等人[111]提出了一种基于关键帧的滑动窗口滤波器，通过在状态向量中保留图像特定的几何信息，以减轻相机的时间偏移，进而实现滚动快门相机的参数自标定。Yin 等人[112]利用加速度计和陀螺仪的偏差来估计平面板位姿和运动速度，从而实现了立体视觉-惯性里程计的在线自标定，应用效果良好。Chen 等人[113]提出了一种新的遵循弱监督框架的外参自标定方案，首先利用弱监督框架对少量标定点图像中的角点进行优化，然后使用一个由自然图像的光度信息构造的自监督光度损失项进行微调，进而求解相机外部参数，该方法人工成本较低。刘福明等人[114]依据左手系构建世界坐标系，利用欧式变换计算相机与世界坐标系的对应关系，确定双目相机外参，满足地图采集需求，实现车载双目相机外参的高效自标定。Zheng 等人[115]通过提取视频图像中的地平线、路径等几何信息，提出了一种基于最小二乘优化的交通监控摄像机参数动态自标定方法，该方法具有较好的精度和实用性。Führ 等人[116]利用行人检测中的前景像素估计个体脚至头的线段，以此为基础初步估算相机矩阵，随后通过非线性代价函数优化初始估计，旨在最小化重投影误差，该方法在视频监控任务中成效显著。Fang 等人[117]设计了一种创新的学习算法，该算法运用一系列高效且通用的相机模型来回归标定参数，此方法能够达成亚像素级别的重投影误差自标定效果，并且在多种类型的相机上进行了广泛的验证，均取得了较好的成效。

近年来，不少学者利用数字图像处理技术和相关几何计算来定位图像消失点，进而求解相机内外参数。Liang 等人[118]对共面圆的仿射不变性进行了研究，采用搜索算法迭代求解公切，并利用包含两个共面圆模板的三幅图像获得消失点，然后依此提出了基于两个共面圆的摄像机内部参数求解方法。王伟等人[119]针对交通场景下消失点检测不稳定的问题，构建了稳定的单消失点标定模型，并在钻石空间中求取最佳消失点用于相机参数求解，适用于弯道场景下的摄像机标定。石

中国知网 https://www.cnki.net

李智等人[120]针对传统相机自标定方法需依赖三正交消失点且无法计算畸变系数的局限，提出了一种基于双消失点与低秩纹理的自标定及畸变校正方法，该方法在车载相机应用中展现出较好的精度与实用性。Lee 等人[121]研发了一种针对人工环境的快速且精确的消失点检测算法，旨在实现相机的自标定。该算法采用碎片化处理与重合并策略，有效提升了检测精度，可应用于自主导航系统中的相机定位以及单视图图像的三维重建。Chang 等人[122]使用三张或多张相同物体的图像求解消失点，然后分解出对应的相机参数矩阵，该方法是一种简单有效的在线标定方法。Duan 等人[123]利用两组正交平行线形成的消失点的几何特性，实现了基于这两组消失点的相机自标定，然后利用连接光心与消失点矢量的正交性质，构建了相机固有参数的约束方程，实验验证了该方法的实用性和有效性。He 等人[124]提出了一种简单、几何直观的自标定方法，该方法利用每个图像中的消失点来确定相机的内参，并通过图像边缘和视点之间的附加平移运动计算相机外参。Zhao 等人[125]提出了一种准确可靠的相机外参标定方法，该方法将消失点引入相机和激光雷达的外部参数标定中。与现有的无目标外参标定方法相比，该方法具有简单直观的数学模型，避免了收敛性和一致性的考虑，计算速度较快。

(2) 基于主动视觉的相机标定方法

基于主动视觉的相机标定方法是一种利用已知的相机运动信息对相机进行标定的技术[126]，这类方法不需要使用传统的标定物，而是通过控制相机进行某些特殊运动，并利用这些运动的特殊性来计算相机参数。基于主动视觉的相机标定方法在机器视觉、计算机视觉等领域具有广泛的应用前景[127-129]。例如，在智能机器人导航[130]、智能监控[131]、人机交互[132]等场景中，该方法可以用于精确计算相机的内部参数，从而提高系统的精度和稳定性。

主动视觉标定方法通常将相机固定于载体平台，通过控制载体平台的特定运动改变相机位姿，利用已知载体平台的运动信息和不同位姿相机图像变化求解相机参数，常见的方法包括基于摄像机纯旋转的标定方法[133]、基于三正交平移运动的标定方法[134]、基于平面正交运动的标定方法[135]等。然而，上述方法均需对摄像机运动进行复杂的运动控制，设备控制要求高。为减少摄像机的运动限制和对复杂精密控制的依赖，Faraji 等人[136]提出了一种基于简易可行的主动视觉的摄像机标定方法，通过在 X 轴、Y 轴方向的小角度旋转控制摄像机位姿，以不同偏航角和俯仰角拍摄标定图像，仅需三幅图像对便可实现摄像机的内参标定。此外，Xu 等人[137]设计了一套具有对称偏航角双目相机的主动视觉装置，采用同步皮带和齿轮实现双目相机偏航角的同步控制，仅需在两次不同偏航角下拍摄双目相机标定图像便可实现相机的内参标定，主动视觉装置更为简单，并取得了可观的相机标定结果。Ma[138]提出了一种利用主动视觉系统灵活性的方法，用于标定头眼

中国知网 https://www.cnki.net

几何与相机内参。该方法无需参考对象，而是直接采用环境图像，并依据一系列特殊设计的运动序列来实现摄像机的标定。Rebello 等人[139]提出了一种动态摄像机集群主动视觉标定方法，该方法利用信息理论的次优视图策略选择标定测量值，直接降低了参数的不确定性，实验表明该方法能够使用较少的测量集实现准确的标定。

近年来，主动视觉标定方法以其精度高、稳定性好等优点在机器人手眼标定等主动视觉系统中受到广泛关注[140-142]。Wei 等人[143]提出了一种机械手相机标定方法，该方法基于主动运动，通过追踪机器人在运动过程中一组未知坐标的世界点来估算相机参数，无需预设初始值。此外，他们还提出了运用最优模型辨识与运动规划策略，以增强标定的精度与鲁棒性。Huang 等人[144]通过获取在机械臂工件平台上特征点的世界坐标，进行手眼关系旋转矩阵和平移向量的标定，该方法手眼标定精度较高，可以满足机器人工件定位和自动抓取的要求。Pedrosa 等人[145]提出了一种解决手眼标定问题的通用方案，该方案运用非线性最小二乘法实施标定，并以最小化重投影误差为优化导向，能在初始配置极为简约的条件下实现相机标定。Zhang 等人[146]提出了一种标定与测量同步优化的方法，在分析机器运动特性的基础上，建立了具有非线性约束的测量与标定模型，并提出了一种具有闭式解的迭代法来提升标定精度。为了标定非固定视点系统，邱晓荣等人[147]依据扩展焦点理念，设计了一种主动视觉驱动的手眼系统自标定方法，该方法通过操控机器人进行多次精准运动来求解相机参数，既可行又高效，达到了工业应用所需的精度标准。此外，黄朝兴等人[148]通过固定机械臂上的激光笔来定位特征点的基坐标，然后使用旋转矩阵-平移矩阵两阶段的策略进行相机外参标定，取得了较高的手眼标定精度。Nickels 等人[149]开发了一种基于立体摄像机观测的机械手手眼标定技术，该技术利用机械臂自反馈的关节角度信息与视觉测量的标定夹具三维坐标，实现基础坐标系至视觉坐标系的参数映射，显著提升了机械手的手眼协同效率。吉峰等人[150]不使用特定标定物，而是通过控制机器人进行精确可测量的位姿运动来进行结构光手眼系统的相机标定，该方法稳定性较好，工业过程适用性较强。为了进行线结构光传感器的标定，Qiao 等人[151]根据摄像机特殊设计的运动，使用场景中的两个特征点进行主动视觉系统的机器人手眼关系标定，该方法简便、快速，标定步骤少，有效降低了计算误差和成本。Zhang 等人[152]利用相机标定误差指导机器人的运动及相机视角选择，通过选取次优视图作为每一步的目标移动姿态，开发了一个全自动化系统，实现了整个手眼标定过程的无人干预执行。

(3) 基于平面模板的相机标定方法

平面模板标定法是一种经典的相机标定方法，其原理是依据特征点图像坐标

中国知网 https://www.cnki.net

和世界坐标之间的对应关系，建立图像的单应性矩阵，进而计算相机的内外部参数[153]。平面模板标定法需要相机从几个不同的位置对同一平面标定板进行拍摄，可以通过移动相机或者移动平面标定板来实现。通过提取标定板图像中的特征点，并与其在世界坐标系中的实际坐标相对应，可以建立一系列方程来求解相机的内外参数。基于平面模板的相机标定方法在实验室环境[154]、工业过程等复杂场景[155, 156]具有广泛的应用前景。

作为平面模板标定法的先驱，张正友最开始提出一种基于 2D 平面靶标的相机标定方法，通过建立摄像机图像像素位置与场景点位置之间的关系，来求解相机的模型参数[157]。他利用一张打印的棋盘格作为标定板，通过摄像机拍摄不同位姿下的标定板图像，然后检测标定板上的特征点(通常是棋盘格角点)，获取每个特征点的像素坐标。由于标定板的制作精度高，因此每个特征点的物理坐标(在世界坐标系中的坐标)是已知的。根据这些已知的物理坐标和像素坐标，可以构建约束方程，进而求解摄像机的内外参矩阵和畸变参数，标定过程简单、灵活，准确度高。在此基础上，大量学者基于张氏标定法进行了衍生研究。

Gai 等人[158]采用质心距离增量矩阵法计算双目相机外参矩阵，有效降低了参数耦合度。随后，他们运用空间交点法重建标定点的三维坐标，并通过最小化重构误差来优化标定参数。Chuang 等人[159]提出了一种创新的几何相机标定技术，该技术基于主线的闭式解，利用主线交点作为主点，并以每条主线表达成像平面与标定模式特定坐标系对间的相对位置，从而简化了标定流程，有效克服了张氏方法的部分局限性。Heinze 等人[160]提出了一种鲁棒的平面板标定技术，该技术引入物理模型，通过估算主透镜相对于传感器的位置和方向校正透镜畸变，为多焦全光相机的建模开辟了新途径。Basso 等人[161]设计了一个人性化、可靠且精确的标定框架，能轻松估算通用颜色深度传感器的内外参数。该框架采用新颖的双分量误差模型，统一了结构光三维相机与飞行时间相机的误差源。Yang 等人[162]提出了一种几何驱动的地下相机标定方法，利用共面性约束推导了等效共线方程的几何关系，充分考虑了地下相机双层玻璃引起的折射影响，在地下相机标定中取得了较大进展；杨霈等人[163]设计了一种方向性靶标作为双目相机标定求解的标定模板，通过引入描述平面靶标姿态的天顶角和方位角，挑选位姿明显差异的图像作为标定图像，提高了双目标定结果的稳定性；Zheng 等人[164]在严格的双目相机外部成像条件下，移动平面板目标沿不同方向运动，并通过最小化重投影误差来模拟平面图案的运动并优化相机参数。此外，Chen 等人[165]借助运动捕捉系统，提出了一种可靠的标定框架，能精确估算 RGB-D 传感器的内外参数。该框架还引入了一种基于异方差高斯过程的无模型深度标定方法，能同时估算不同测量距离下的深度误差均值与方差，从而提升点云信息的准确性与可靠性。

中国知网 https://www.cnki.net

Monteiro 等人[166]构建了标准全光学相机模型与视点相机阵列间的映射，并据此提出了一种基于角网格的平面板标定程序。该程序首先求解相机线性参数，随后进行非线性优化，以最小化重投影误差。Gao 等人[167]针对平面模板不完整的问题，创新性地提出一种优化的棋盘图案与图像处理算法。当标定板仅部分可见时，该算法仍能有效提供必要的世界坐标与图像坐标，无需额外采样，相较于传统方法有效简化了标定流程。Loaiza 等人[168]利用由四个共线标记构成的一维不变物理特征进行多相机标定，通过新技术捕获和识别投影不变模式的鲁棒样本，该方法能同时捕捉跟踪区域内的多个不变模式，以提升标定过程的适用性和鲁棒性。为了解决人工操作带来的标定结果不稳定问题，Tan 等人[169]提出了一种用虚拟模式代替物理模式的相机全自动标定方法，该方法不需要任何人工操作，直接从二维图像点与虚拟图形的点对应关系中估计相机内外参数。Kang 等人[170]提出了一种适用于工业现场复杂背景与不均匀光照条件下的相机标定模板检测方法。该方法引入了一种概率准则，用于检测局部标定点集，并能在不规则光照和杂乱背景下有效提取其他标定点，从而实现低质量图像的相机标定。此外，由于相机标定过程复杂，场景多变，涉及多个内外参的非线性寻优过程，为获得更好的标定结果，一些学者将粒子群等先进的进化算法运用于优化相机内外参数[171, 172]，应用效果良好。

近年来，大量学者通过引入投影仪、激光雷达、高精度标定平台等辅助设备来提高标定精度、细化标定流程、提升模型适应性、强化标定过程的自动化程度[173]。Huang 等人[174]设计了一种实用且鲁棒的投影仪-摄像机标定系统，该系统在彩色编码的空间结构光模式上应用了基于图论的对应算法，并开发了束平差算法，以联合优化投影仪-摄像机参数及对应坐标，从而增强系统对不完美平面标定板噪声的鲁棒性。Usamentiaga 等人[175]提出了一种基于凸圆柱标定板的标定方法，该方法首先利用鲁棒估计器进行粗标定以获得初步近似值，随后利用激光线在标定板上投影形成的局部轮廓进行精细调整。Deglint 等人[176]运用投影仪投射一系列灰色编码的结构光模式，随后在投影仪与相机间构建了密集的像素对应关系，该方法采用目标函数对立体系统进行标定，并应用贪婪算法以最小化标定过程中的损失。Yousef 等人[177]提出了一种灵活的摄像机-激光雷达系统外参标定方法，该方法基于对标定环境中几何结构的合理假设，专门设计用于处理相机与激光雷达传感器视场不重叠或不完全共享的情况。Fuersattel 等人[178]针对多传感器标定系统，首先进行多模态坐标系统的粗略对齐，然后利用激光扫描仪的反射率生成场景的虚拟图像，最后依据多传感器间的空间关系精确计算出相机参数。Wei 等人[179]提出了一种基于激光扫描的非重叠视场多相机外参标定方法，该方法通过控制机械手的运动将线结构光投射至某一相机视场，以此标定相机坐标系内的光

中国知网 https://www.cnki.net

平面方程，进而精确标定多台摄像机的外部参数。

在进行工业相机标定时，往往需根据特定的标定需求来选择标定方法。其中，自标定方法在相机标定时不需要额外的标定物和运动，灵活性高，但却要求标定场景中包含具有透视投影不变性的特定几何物体。在泡沫浮选生产过程中，关键监测目标通常不包含平行直线、二次曲线等特定的几何特征，难以采用自标定方法。主动视觉标定方法依据已知且精确控制的三维运动信息求解相机参数，标定结果精度高，鲁棒性好，但要求具有三维方向精确运动的相机控制平台。在复杂工业场景中，如矿物浮选过程，设备安装空间受限，使得工业现场不具备安装提供相机旋转或平移装置的条件，不能为相机标定提供精确的相机移动信息，基于主动视觉的标定方法很难适用。平面模板标定法操作简单，对标定设备要求不高，应用颇为广泛，但现有标定模板法应用场景较为简单，容易实现标定板不同位姿的清晰成像。然而，在矿物浮选过程中，标定环境恶劣，无支撑平面放置标定物，而且标定操作受限，难以获取具有理想位姿的高质量标定图像，现有平面模板法标定结果准确度不高。

1.3 本文主要内容及结构安排

本文以某铅锌浮选厂的锌快粗选过程双目视觉系统为研究对象，针对浮选过程相机标定的难点及挑战，研究基于加权关键帧与 FSC-McCNN 的浮选过程相机标定方法。具体而言，针对浮选生产过程因平面板倾斜、成像距离差异导致的标定板图像失焦模糊的问题，提出基于 RPMU-NET 的浮选过程失焦平面板图像复原方法，提高了模糊标定板图像的特征点提取精度；针对因操作环境受限、标定板非线性运动、位姿不可控等因素导致的基于泡沫视频进行相机内参标定难的问题，提出基于关键帧提取和位姿加权的浮选工业相机内参标定方法，使用图像质量评价规则来表征平面板位姿权重，在进行失焦平面板图像复原的基础上从泡沫视频序列加权求解高精度相机内参。针对浮选过程复杂外部光源环境导致的双目相机成像时间异步的问题，提出基于闭环混合优化的双目特征点同步校正方法，通过混合优化算法预测最优特征匹配点，以最小化双目成像时间异步对左右相机外参标定的影响。针对浮选过程液位波动情况下双目外参高精度标定能力受限的问题，提出基于 FSC-McCNN 的浮选过程双目外参标定方法，利用平面图谱特征到相机参数的端到端映射创建合成数据集，并构建基于特征空间编码的深度标定网络 FSC-McCNN，实现了相机外参的高精度标定。在上述理论和方法的研究基础上，搭建泡沫浮选过程相机标定平台，构建了泡沫浮选过程相机标定系统，并已成功投入使用。本文共分为八章，各章节的结构及关系如图 1-1 所示，各章节的主要内容如下。

中国知网 https://www.cnki.net

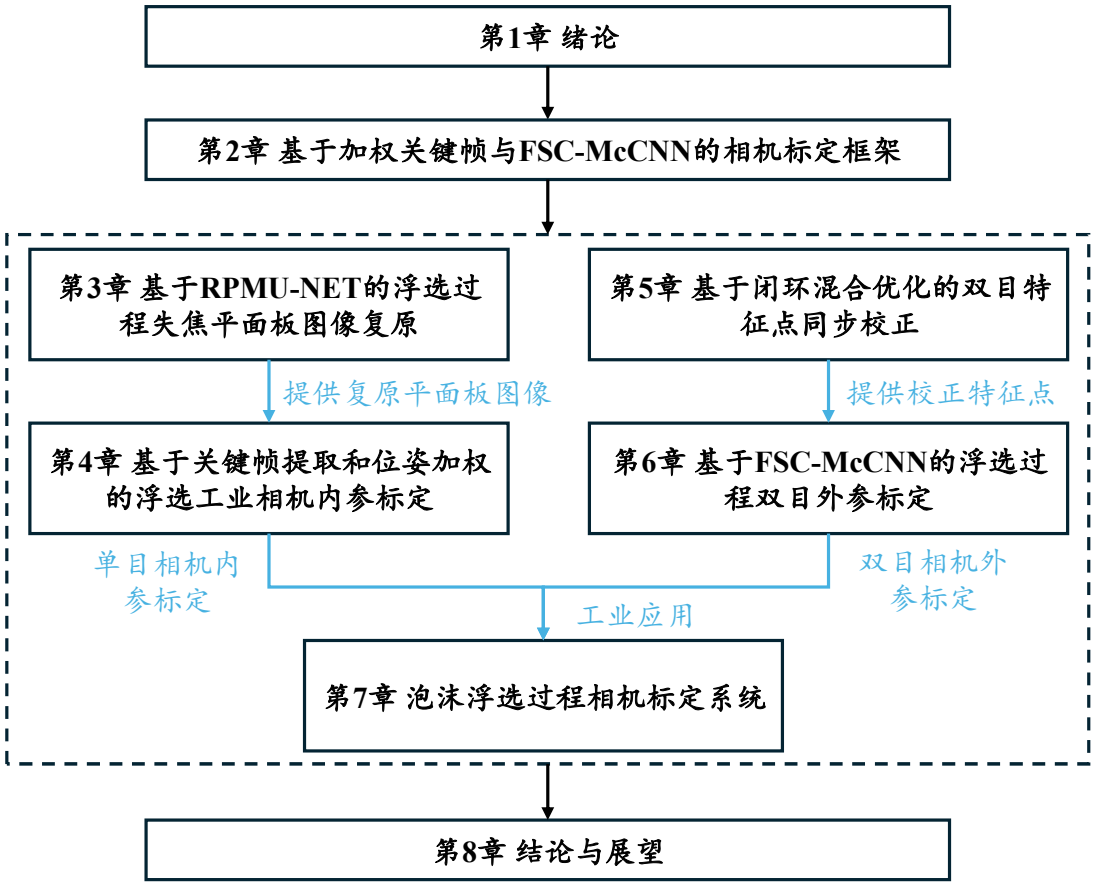


图 1-1 本文章节结构及关系

第 1 章为绪论，主要介绍论文的研究背景与意义，对基于图像特征点修正的相机标定方法、基于深度学习的相机标定方法和工业相机的标定方法进行了回顾和综述，同时给出了本文的主要研究内容及论文各章节安排。

第 2 章在介绍相机标定过程基本原理的基础上，以泡沫浮选过程为例，指出影响泡沫浮选过程相机标定的主要因素，并对泡沫浮选过程相机标定难点进行分析，随后制定了基于加权关键帧与 FSC-McCNN 的浮选过程相机标定研究框架。

第 3 章针对泡沫浮选过程因平面板倾斜、成像距离差异导致的标定板图像失焦模糊的问题，提出基于 RPMU-NET 的浮选过程失焦平面板图像复原方法。首先针对泡沫浮选过程平面板倾斜导致的图像不均匀局部模糊，利用自适应掩码调制构建针对圆形平面板的深度去模糊网络 MAM-UNet，为了平衡标定精度与计算效率，提出基于平面板图像特征分区的去模糊并行计算方法，以减少因计算能力不足而导致的故障或标定异常，并在此基础上，实施基于预训练-微调数据集的渐进式模型训练方案，实现泡沫浮选过程的失焦平面板图像复原。本章提出的浮选过程失焦平面板图像复原方法是后续相机内参标定的基础。

第 4 章针对因操作环境受限、标定板非线性运动、位姿不可控等因素导致的

中国知网 https://www.cnki.net

泡沫视频关键帧提取难的问题，提出基于关键帧提取和位姿加权的浮选工业相机内参标定方法。在进行失焦平面板图像复原的基础上，提出基于平面板倾斜度的图像质量评价规则以评估泡沫视频中不同标定板图像的质量，在此基础上，通过计算图像间平面板倾斜度差异来衡量图像序列的位姿分布，以恢复尽可能多的畸变和透视参数，随后基于平面板位姿表征计算关键帧序列内参权重，实现基于加权位姿差异的浮选过程相机内参标定。

第 5 章针对浮选过程复杂外部光源环境导致的双目相机成像时间异步的问题，提出基于闭环混合优化的双目特征点同步校正方法。首先基于双目时序分析估计左右图像的初始延迟，以最小化硬件差异的影响并加速模型的收敛速度；然后，基于希尔爬升算法和差分进化算法提出了一种两阶段混合优化算法 HC-IDE，并提出一种改进的变异策略来提高模型的全局搜索能力，以同步优化所有的双目图像特征匹配点。最后，提出了一种闭环优化策略来管理泡沫浮选过程双目平面板图像特有的非线性延迟变化，以准确预测双目视图特征匹配点。本章提出的浮选过程双目特征点同步校正方法是后续双目相机外参标定的基础。

第 6 章针对浮选过程液位波动情况下双目外参高精度标定能力受限的问题，提出基于 FSC-McCNN 的浮选过程双目外参标定方法。首先建立特征图谱与相机参数之间的直接映射，然后在指定的范围约束内进行合成数据增强以增强模型的鲁棒性和泛化能力；然后，提出一种基于标定损失解耦的深度标定网络 FSC-McCNN，利用特征空间编码模块来提升模型对不同姿态特征图谱的空间表征能力，并采用多通道卷积神经网络来挖掘特征编码的多维成像信息；最后，使用校正后的左右图像特征匹配点进行双目外参标定。所提双目外参标定方法的有效性最终通过虚拟仿真环境和锌快粗选工业过程数据进行验证。

第 7 章根据论文研究成果，搭建泡沫浮选过程相机内外参数标定平台，研发基于加权关键帧与 FSC-McCNN 的浮选过程相机标定系统，并于应用于某铅锌浮选厂的锌浮选过程，实现单目相机内参和双目相机外参的准确、及时标定，证实了所提理论和方法的有效性。

第 8 章对全文内容进行了总结，并对未来的研究方向和前景进行了讨论与展望。

中国知网 https://www.cnki.net

第 2 章 基于加权关键帧与 FSC-McCNN 的相机标定框架

本章以某铅锌矿的锌泡沫浮选过程相机标定为例，介绍相机标定基本原理和泡沫浮选过程相机标定环境，对泡沫浮选过程受限环境下相机标定的影响因素进行了分析，并给出泡沫浮选过程相机标定难点及整体研究框架。

2.1 相机标定过程分析

2.1.1 相机标定原理

在图像测量过程以及机器视觉应用中，三维物体的几何信息是由摄像机从图像信息中获取的。为了得到空间点与图像像素之间的对应关系，对工业相机进行准确的标定是关键。空间中一个点的三维几何位置与其在图像中的对应点之间的关系是由相机成像的几何模型决定的，这些几何模型参数就是相机参数。相机标定就是从世界坐标系转换为相机坐标系，再由相机坐标系转换为图像坐标系的过程，也就是求解最终的相机投影矩阵的过程。这一过程中涉及多个坐标系的转换，并需要运用数学方法和优化算法来精确计算相机的内外参数。

图 2-1 显示了相机标定的基本流程，图 2-1-a 所示为空间中三维点世界坐标到相机坐标的转换，该过程为刚体变换，也就是不改变物体的形状，而只改变物体的空间位置(平移)和方向(旋转)。该过程主要用于求解相机外部参数，如旋转参数 R 和位移参数 t。世界坐标系，也称为测量坐标系，它是一个全局的三维直角坐标系，用于描述相机和待测物体的空间位置。

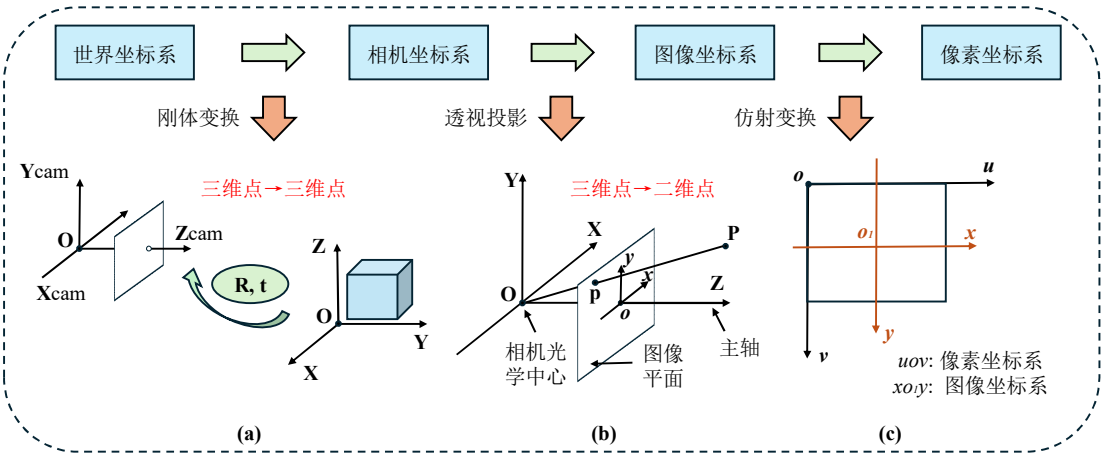


图 2-1 相机标定流程

在世界坐标系中，每个物体的位置都是基于一个固定的原点来进行描述的。同时，相机坐标系也是一个三维直角坐标系，相机坐标系的原点是摄像机镜头的

中国知网 https://www.cnki.net

光心，其中 x 与 y 轴分别平行于相面的两边，z 轴为相机镜头的光轴，垂直于像平面。在齐次坐标系中，旋转矩阵 R 保持正交性，能经由 Rodrigues 旋转公式转化为仅含三个独立分量的旋转矢量。因此，刚体变换仅需六个参数即可表征(即三个旋转分量与三个平移分量)，这些参数构成了相机的外部参数。相机的外部参数确定了空间点由世界坐标系转换至相机坐标系的过程。对于世界坐标系中的任意点 $Pw = (Xw,Yw,Zw)$, 可通过下式转换到相机坐标系 $Pc = (Xc,Yc,Zc)$，即：

$$\begin{bmatrix} X_c \\ Y_c \\ Z_c \end{bmatrix} = R \begin{bmatrix} X_w \\ Y_w \\ Z_w \end{bmatrix} + t . \tag{2-1}$$

齐次坐标下可表示为：

$$\begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} = \begin{bmatrix} R & t \\ 0^T & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} = \begin{bmatrix} r_{11} & r_{12} & r_{13} & t_x \\ r_{21} & r_{22} & r_{23} & t_y \\ r_{31} & r_{32} & r_{33} & t_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} . \tag{2-2}$$

从相机坐标系转换到图像坐标系，是通过透视投影实现从三维到二维的转变，如图 2-1-b 所示。图像坐标系亦称平面坐标系，它利用物理单位(毫米)来标定像素的位置，图像坐标系的原点设定在摄像机光轴与图像平面的交汇点上。根据相似三角形原理，可以得到相机坐标系转换到图像坐标系的坐标，即：

$$x = f \frac{X_c}{Z_c} . \tag{2-3}$$

$$y = f \frac{Y_c}{Z_c} . \tag{2-4}$$

在齐次坐标下可表示为：

$$Z_c \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} . \tag{2-5}$$

这一步实现了从相机坐标系到理想图像坐标系的线性映射。整体上看，透视投影是将相机坐标系内的点映射到理想图像坐标系上的过程，这一转换仅取决于相机的焦距 f。理想的针孔成像模型规定的坐标变换是线性的，然而在实际应用中，透镜由于制造精度以及组装工艺的偏差不可避免的会引入畸变，导致原始图像的失真，这种畸变使得原本线性的成像模型几何变换关系变得非线性。这意味着按照理想针孔成像模型计算得到的图像点坐标，与实际坐标之间存在偏差，提升了模型的复杂度，但也更贴近实际情况。在众多畸变类型中，影响最普遍的是

中国知网 https://www.cnki.net

径向畸变和切向畸变。由透镜的形状引起的畸变称为径向畸变，即沿着透镜半径方向分布的畸变曲。径向畸变通常源于镜头制造工艺的局限性，具体表现为枕形畸变和桶形畸变，如图 2-2 所示。一些特定的镜头系统(特别是工业相机)会在最大的图像高度上进行畸变校正。这些系统在距离光学中心较近处展现出最高的畸变级别，最终产生的畸变类型通常是桶形和枕形畸变的混合，即波形畸变。切向畸变包括薄透镜畸变和离心畸变等类型，其中薄透镜畸变源于透镜存在微小倾斜；而离心畸变则是由于镜头由多个透镜组合，且这些透镜的光轴未对准同一中心线所致。



桶形畸变　　**枕形畸变**　　**波形畸变**

图 2-2 图像畸变

一般情况下，对于图像坐标系中任意点(x,y)，其径向畸变坐标可以用以下表达式来描述：

$$\begin{cases}\delta_{xr}=x(k_1r^2+k_2r^4+k_3r^6+M)\\ \delta_{yr}=y(k_1r^2+k_2r^4+k_3r^6+M)\end{cases} \tag{2-6}$$

式(2-6)中的$(\delta_{xr},\delta_{yr})$为径向畸变后的坐标，$M$ 为常数。因此径向畸变可以通过参数 k_1，k_2，　k_3 来进行校正。

此外，对于图像坐标系中任意点(x,y)，其切向畸变坐标可以用以下表达式来描述：

$$\begin{cases}\delta_{xd}=2p_1xy+p_2(r^2+2x^2)+x\\ \delta_{yd}=p_1(r^2+2y^2)+2p_2xy+y\end{cases} \tag{2-7}$$

式(2-7)中的$(\delta_{xd},\delta_{yd})$为切向畸变后的坐标。切向畸变可以通过参数 p_1 和 p_2 来进行校正。

在标定过程中，引入镜头畸变后，成像点从理想图像坐标系到真实图像坐标系的变换关系可以表示为：

$$\begin{cases}x'=x+\delta_{xr}+\delta_{xd}\\ y'=y+\delta_{yr}+\delta_{yd}\end{cases}. \tag{2-8}$$

需注意的是，在实际计算过程中，若纳入过多高阶畸变参数，会致使标定结

中国知网　https://www.cnki.net

果的稳定性下降。

从图像坐标系转换到像素坐标系，两者间不存在旋转关系，仅坐标原点位置及度量单位有所不同，该过程为仿射变换，和透视投影过程共同用于求解相机内部参数和畸变参数。像素坐标系以像素为单位，其原点设定在左上角，如图 2-1-c 所示。该过程可通过下式进行表示：

$$\begin{cases} u = \dfrac{x}{dx} + u_0 \\ v = \dfrac{y}{dy} + v_0 \end{cases} \tag{2-9}$$

式(2-9)中，(u,v)表示像素坐标系中的点，(u_0,v_0)指的是从图像坐标系中心点到像素坐标系中心点的偏移量，属于相机内参的一部分。式(2-9)在齐次坐标下可表示为：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \dfrac{1}{dx} & 0 & u_0 \\ 0 & \dfrac{1}{dy} & v_0 \\ 0 & 0 & 1 \end{bmatrix}. \tag{2-10}$$

综上所述，相机标定的整个过程，即从世界坐标系到像素坐标系的完整转换可以表示为：

$$Z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \dfrac{1}{dx} & 0 & u_0 \\ 0 & \dfrac{1}{dy} & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} R & t \\ 0^T & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}. \tag{2-11}$$

2.1.2 常规环境下的相机标定

在常规实验室环境下进行相机标定的主要目的是获取相机的精确内外参数，这些参数对于后续的三维重建、物体识别、定位等任务至关重要。通过标定，可以校正相机镜头产生的畸变，提高图像的准确性和可靠性。当前，在常规实验室环境下主流的标定方法是基于标定参照物的方法，这种方法使用一块已知尺寸的平面标定板，通过拍摄标定板在不同位置和角度下的图像，提取标定板上的特征点(如角点)，并利用这些特征点与图像像素之间的对应关系来求解相机的内外参数。

在常规实验室环境下进行相机标定主要包括以下步骤，即：安装照明设备→

中国知网 https://www.cnki.net

固定相机并连接电脑→选择标定板→拍摄多帧不同标定图像→标定图像特征点提取→参数求解→建立成像模型→图像校正→参数验证与优化→保存相机参数。其中，目前主流的平面标定板包括棋盘格标定板和圆形标定板等，一般要求所使用的标定板图像至少有四个已知特征点，如图 2-3 所示。

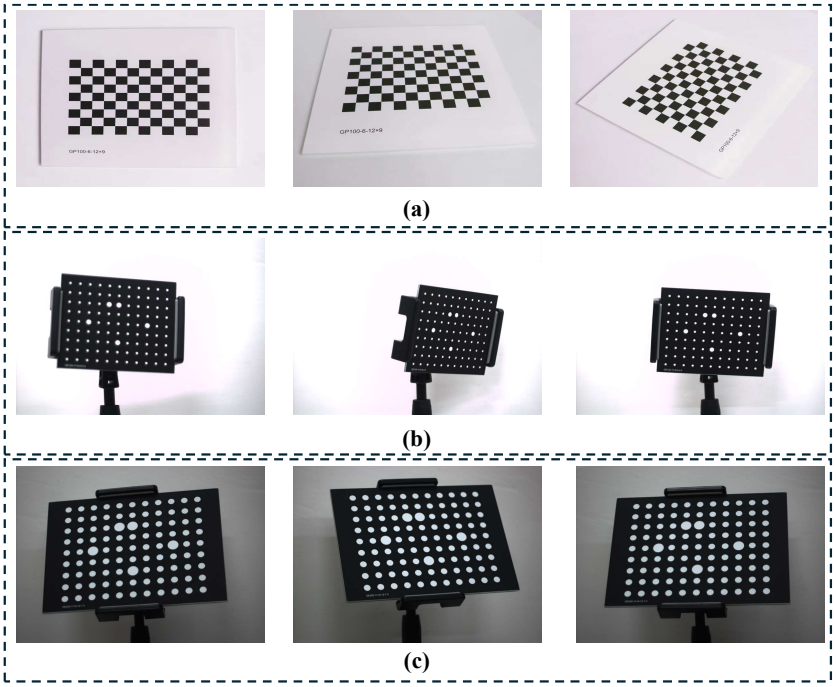


图 2-3 实验室环境下拍摄的不同类型平面标定板；(a) 棋盘格标定板；(b) 半径为 2.5mm-5mm 的圆形标定板；(c) 半径为 7.5mm-12mm 的圆形标定板

在拍摄多帧不同角度的标定板图像后，即可进行标定图像特征点提取。以圆形标定板为例，圆形标定板图像特征点提取过程通常采用 Hough 圆心检测法提取特征点坐标。因为圆形平面板上的所有特征点共处同一平面，因此在世界坐标系中这些特征点的 Z 轴坐标均可设定为 0，相当于设定模板平面与世界坐标系中 Z=0 的平面重合。由此可进行旋转矩阵降维，则对于外参 $R=\begin{bmatrix} r_1 & r_2 & r_3 \end{bmatrix}$，具体变换如下：

$$Z_c\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = A\begin{bmatrix} r_1 & r_2 & r_3 & t \end{bmatrix}\begin{bmatrix} X_w \\ Y_w \\ 0 \\ 1 \end{bmatrix} = A\begin{bmatrix} r_1 & r_2 & t \end{bmatrix}\begin{bmatrix} X_w \\ Y_w \\ 1 \end{bmatrix} \tag{2-12}$$

式(2-12)中 A 表示相机内参。此外，可以定义相机单应性矩阵为：

$$H=\begin{bmatrix} h_1 & h_2 & h_3 \end{bmatrix} = A\begin{bmatrix} r_1 & r_2 & t \end{bmatrix}. \tag{2-13}$$

然后，根据旋转矩阵 R 的正交性质，可以得到：

中国知网 https://www.cnki.net

$$\begin{cases} r_1^T r_2 = 0 \\ \|r_1\| = \|r_2\| = 1 \end{cases}. \tag{2-14}$$

通过变换，可得到如下约束方程：

$$\begin{cases} h_1^T A^{-T} A^{-1} h_2 = 0 \\ h_1^T A^{-T} A^{-1} h_1 = h_2^T A^{-T} A^{-1} h_2 \end{cases}. \tag{2-15}$$

在内参 A 中包含 5 个未知变量，因此至少需要使用 3 幅不同位姿的图像，以求解单应性矩阵的 3 个 h 值。基于式(2-15)这两个约束条件，可以建立 6 个方程，从而求解出 A 中的全部 5 个变量。之后，可通过相应的转换公式进一步求得相机外参 R 和 t，即：

$$\begin{bmatrix} h_1 & h_2 & h_3 \end{bmatrix} = \lambda A \begin{bmatrix} r_1 & r_2 & t \end{bmatrix} \tag{2-16}$$

$$\begin{cases} r_1 = \lambda A^{-1} h_1 \\ r_2 = \lambda A^{-1} h_2 \\ r_3 = r_1 \times r_2 \\ t = \lambda A^{-1} h_3 \end{cases} \tag{2-17}$$

$$\lambda = \frac{1}{\left\| A^{-1} h_1 \right\|} = \frac{1}{\left\| A^{-1} h_2 \right\|}. \tag{2-18}$$

在此情况下，我们得到的内参 A 和外参$[R, t]$均基于无畸变的理想相机模型。之后，可利用最小二乘法等算法来估算图像径向和切向畸变系数，并最终通过极大似然法对整个参数进行优化估计，以在实验室等可控环境下获取高精度的相机内外参数。

2.2 影响泡沫浮选过程相机标定的因素分析

2.2.1 泡沫浮选过程相机标定环境

泡沫浮选是应用最广泛的矿物分选技术之一，而相机标定是进行准确的表层泡沫三维重构的重要基础，本节详细介绍了泡沫浮选过程相机标定环境。

图 2-4 展示了某铅锌浮选厂的锌浮选工艺流程。锌浮选回路主要由锌粗选、锌精选、锌扫选三个模块组成。锌快粗槽是浮选回路的首槽，锌快粗选运行状况对产品质量有着较大影响，因此需对锌快粗选的工况进行重点监测。此外，锌快粗选泡沫状态直接影响最终产品质量，因此选择在锌快粗槽搭建双目视觉系统，以获取表层泡沫立体视觉信息。

锌快粗选过程是固、液、气三相交互的复杂物理化学过程，在该浮选过程中，为了应对不同的入矿条件和浮选工况，常需使用大量腐蚀性强的强酸强碱药剂(如捕收剂、pH 调整剂、活化剂、起泡剂、絮凝剂等)来调节矿浆 pH 值、改变矿

中国知网　https://www.cnki.net

物表面性质、调整杂质溶解度和电荷状态，以使浮选过程达到最优状态。同时，工业浮选现场环境恶劣，浮选现场的温度通常较高，长期保持在 30℃以上，这种高温环境对相机的性能和稳定性提出了很高的要求。受矿石的物理特性、浮选工艺过程、设备与环境等因素的影响，浮选现场往往存在大量粉尘和蒸汽，这些粉尘和蒸汽容易附着在相机和标定物上。此外，浮选设备在工作时会产生振动和噪音，这会对相机的稳定性和标定精度产生不利影响。另外，浮选现场存在大量的机械设备和电气线路，为了确保操作人员的安全，需要避免在危险区域安装额外的设备。一般情况下，浮选过程通常是连续进行的，中断生产进行相机标定会对生产效率产生不利影响。因此，需要在不影响生产的前提下进行相机标定，这增加了相机标定的难度。

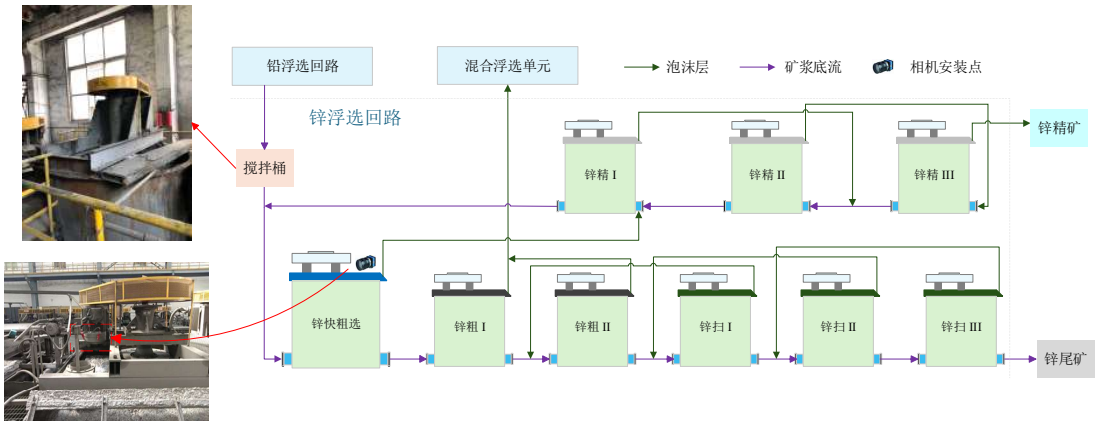


图 2-4 锌浮选过程工艺流程

另一方面，浮选过程矿浆流量及浓度存在不稳定情况，流量高低会间接影响浮选品质，因此需进行相应调节。而在进行矿浆流量调整的过程中，表层泡沫液位会存在波动。同时，若浮选过程中的介质会发生性质变化(如密度、粘度等)，也会直接影响矿浆的沉降速度和分离效果，进而影响泡沫层高度。这种液位的波动会直接改变相机到表层泡沫的距离，进而影响标定质量。

锌浮选现场及锌快粗槽双目视觉采集系统如图 2-5 所示，主要包括以下硬件设备：工业光源、控制器、工业交换机、两个工业相机、一个伸缩杆以及工控机。分别采用了两个包含 11*9 个特征圆的圆形平面标定板作为相机标定的基准标定物，这两个平面标定板的半径分别为 2.5 mm-5 mm 以及 7.5 mm-12 mm，大小分别为 120 mm*100 mm 以及 200 mm*150 mm，其中相邻两个特征圆之间的中心距离分别为 10 mm 和 15 mm，图像分辨率设置为 1388*1038 像素。此外，为了平衡图像清晰度和畸变，双目相机的公共视场较小，这主要是由于浮选池上方机械

中国知网　https://www.cnki.net

设备多导致相机拍摄受限，且不同区域表层泡沫形态、尺寸、纹理基本一致，因此考虑到图像清晰度和拍摄需求，选择了较小的相机视场角。

在安装好工业相机标定所需的软硬件设备后，即可进行标定数据采集。然而，浮选现场的空间通常较为有限，特别是在大型浮选槽周围，很难找到合适的位置来固定放置平面板。因此，主要采用标定人员手持伸缩杆控制平面标定板位移和旋转的方式进行数据采集。为了捕获更多位姿的标定板图像，设定左右相机为连续视频采集模式，帧率均设定为 30 fps。



(a) 锌浮选现场　　(b) 锌快粗槽

图 2-5 锌浮选现场及锌快粗槽双目视觉采集系统

2.2.2 泡沫浮选过程受限环境下相机标定的影响因素分析

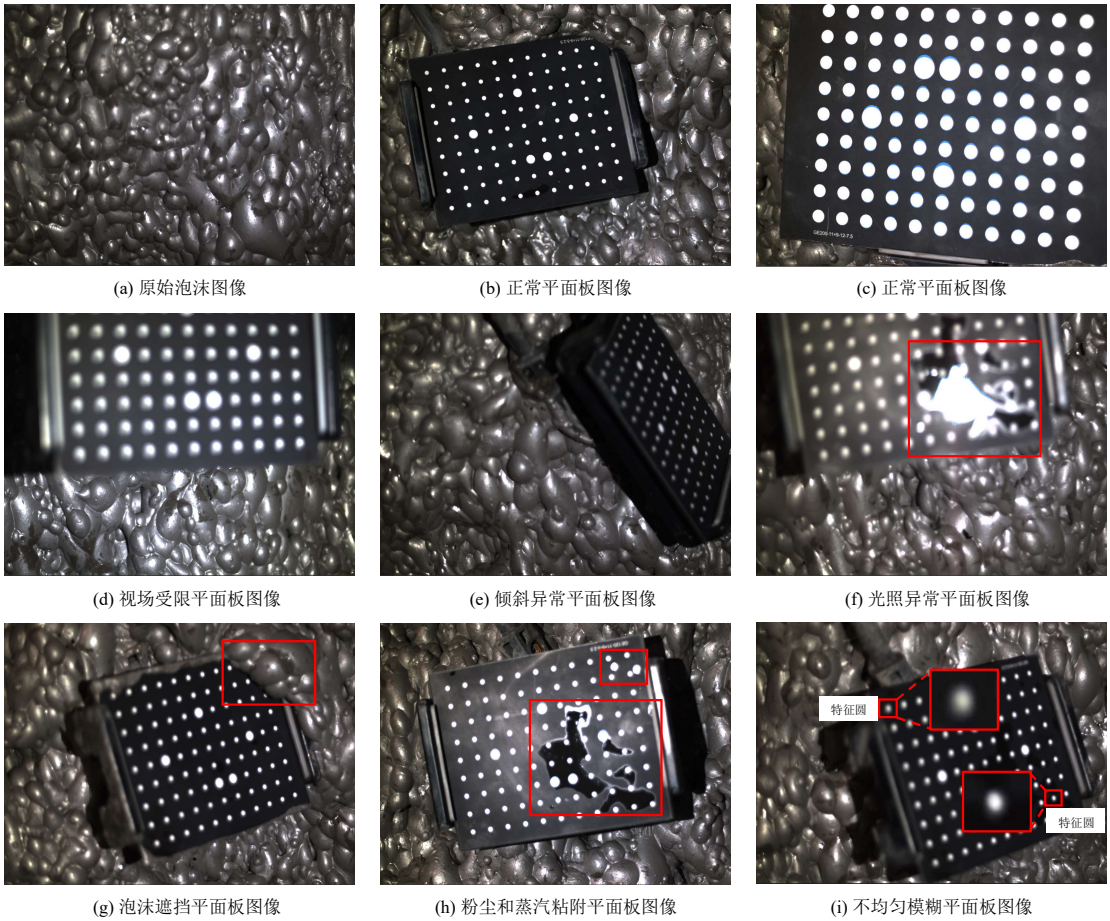
在泡沫浮选过程受限环境下进行相机标定时会受到多种因素的影响，包括外部环境、光照变化、拍摄距离与角度、图像清晰度、图像完整性、相机稳定性等，对这些影响因素的具体分析如下。

在泡沫浮选过程中，所采集的部分典型单目平面板图像如图 2-6 所示。图 2-6-a 所示为原始泡沫图像，可见泡沫图像形态复杂，尺寸分布不一，没有特定的几何结构，不存在如二次曲线、线段等具有明显边界特征的可定义几何信息。同时，泡沫图像没有前景背景之分，难以通过图像分割等操作来解析相机成像信息。此外，泡沫图像具有无结构特征和高度相似性，很难直接从泡沫图像的空间变化中感知到相机视角的变化。

图 2-6-b 所示为泡沫浮选过程采集的半径 2.5 mm-5 mm 圆形平面板的正常图像。图像中的平面板特征点区域清晰度高，平面板完整，无泡沫遮挡，光照良好，平面板的倾斜度正常，平面板与表层泡沫之间的距离适中，无明显粉尘和蒸汽粘附的情况，平面板区域在整体图像的占比适中。

中国知网 https://www.cnki.net

图 2-6-c 所示为泡沫浮选过程采集的半径 7.5 mm-12 mm 圆形平面板的正常图像。图像中平面板特征点区域清晰完整，无泡沫遮挡，光照良好，平面板的倾斜度正常，无明显粉尘和蒸汽粘附的情况，但是由于相机和表层泡沫之间的距离较短，该平面板尺寸较大，使得平面板区域在整体图像的占比过高，造成平面板活动区域和倾斜角度受限。



(a) 原始泡沫图像　(b) 正常平面板图像　(c) 正常平面板图像

(d) 视场受限平面板图像　(e) 倾斜异常平面板图像　(f) 光照异常平面板图像

(g) 泡沫遮挡平面板图像　(h) 粉尘和蒸汽粘附平面板图像　(i) 不均匀模糊平面板图像

图 2-6 泡沫浮选过程典型平面板图像

图 2-6-d 所示为泡沫浮选过程采集的视场受限平面板图像。由于浮选现场不具备安装固定平面板的条件，因此受相机视场和平面板位置影响，图像中平面板区域不完整。且平面板与表层泡沫之间的距离较大，造成了一定的平面板区域模糊。此外，由于平面板是标定人员手动控制的，使得在这些视场受限平面板图像中标定板的缺失部分不一致，造成这一类图像在标定过程的应用困难。

图 2-6-e 所示为泡沫浮选过程采集的倾斜异常平面板图像。由于左右相机的视角不同，为保持平面板图像完整处于双目公共视场内，在调整平面板角度对准其中一个相机时，其在另一相机中的图像可能出现倾斜度异常的情况，这种情况

中国知网　https://www.cnki.net

也有可能是标定人员操作失误造成。倾斜异常的平面板图像特征提取困难，同时过大的倾斜也会造成较严重的图像畸变。

图 2-6-f 所示为泡沫浮选过程采集的光照异常平面板图像。泡沫浮选过程光照环境复杂，太阳光、环境光等外部光源较多，同时浮选过程存在较多蒸汽，平面板位姿在旋转变化的过程中，可能出现如图 2-6-f 所示的光反射异常的情况。图像中光斑区域较大，且与多个平面板特征点区域重合，图像中的其他部分和明亮光斑部分形成了鲜明的对比度，对后续的平面板图像特征提取造成了较大负面影响。

图 2-6-g 所示为泡沫浮选过程采集的泡沫遮挡平面板图像。受浮选过程液位波动、泡沫的堆叠和动态变化以及平面板位姿高度的影响，在进行平面板位移和旋转的过程中可能会使得局部平面板粘附泡沫，从而造成平面板特征区域遮挡。此外，受相机的位置和视野范围影响，如果相机视角与泡沫堆叠方向重合，则更容易出现遮挡现象。平面板被泡沫遮挡后，可能造成特征点缺失或变形，进而影响后续的图像处理和分析。

图 2-6-h 所示为泡沫浮选过程采集的粉尘和蒸汽粘附的平面板图像。在进行标定操作的过程中，为了采集位姿角度好且图像清晰度较高的平面板图像，平面板通常直接置于表层泡沫上方。因此，受浮选过程高温、高尘、多蒸汽的外部环境影响，可能会出现粉尘和蒸汽粘附在平面板上的情况。这种粉尘和蒸汽的粘附会使得平面板图像区域对比度增大，光反射异常，同时可能出现类似于特征点的圆形噪点，进而影响后续的特征提取过程。

图 2-6-i 所示为泡沫浮选过程采集的不均匀模糊平面板图像。在数据采集过程中，为确保采集的泡沫图像清晰，相机焦距通常是基于表层泡沫到相机之间的距离来设定的。而为了避免与矿化泡沫中的腐蚀性化学物质接触，平面板与表层泡沫相对于相机的高度存在明显差异。因此，所采集的平面板图像中可能会出现出泡沫区域清晰而平面板区域模糊的情况。此外，为了捕获更多样的位姿图像，平面板倾斜不可避免，而这种倾斜可能会导致平面板图像中出现不同程度的局部模糊，进而影响后续的相机标定过程。

此外，所采集的部分典型双目平面板图像如图 2-7 所示。图 2-7-a 所示为在泡沫浮选过程左右相机曝光时间相同时所采集的原始泡沫图像。受泡沫浮选过程外部复杂光源及左右相机视角影响，当不调整左右相机曝光时间时所采集的双目图像存在明显的亮度差异。而双目立体视觉系统依赖于左右两个摄像机拍摄的图像之间的匹配来提取深度信息，当双目图像存在明显的亮度差异时，图像匹配过程会受到干扰，导致误匹配或匹配失败，进而影响到后续的深度估计和表层泡沫三维重建。因此，需调整双目相机的曝光时间来尽可能保持左右视图的亮度一致，

中国知网　https://www.cnki.net

进行曝光时间调整后的双目原始泡沫图像如图 2-7-b 所示。从图 2-7-b 可以发现，双目视图公共区域亮度基本一致，图像纹理清晰。但是，不一致的曝光时间会造成左右视图的成像时间差异，这可能导致双目相机拍摄的图像在视差上存在差异，进而使得计算出的深度信息不准确，最终导致表层泡沫三维重建的结果出现偏差或失真。

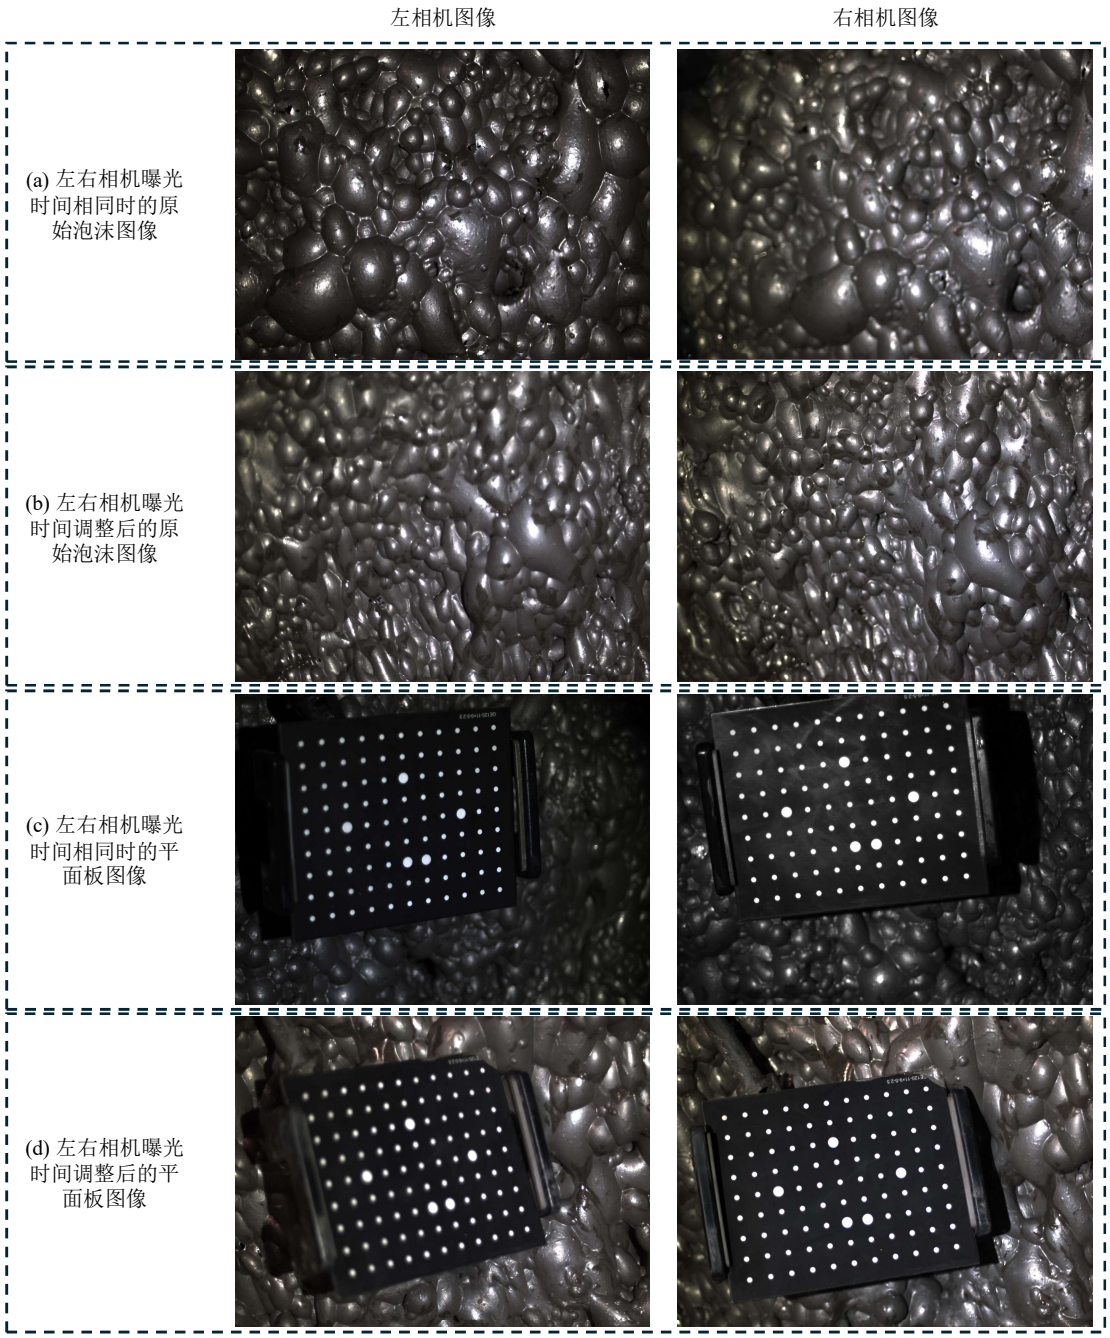


图 2-7 泡沫浮选过程双目平面板图像

图 2-7-c 所示为在泡沫浮选过程左右相机曝光时间相同时所采集的平面板图像，同时双目相机曝光时间调整后的左右平面板图像如图 2-7-d 所示。由于平面

中国知网　https://www.cnki.net

板是标定人员手动控制的，且始终处于运动状态，因此不同的成像时间差异也可能会导致左右视图平面板特征的不匹配，进而引入标定误差，影响双目外参标定结果的稳定性和准确性。

2.3 基于加权关键帧与 FSC-McCNN 的相机标定框架

2.3.1 泡沫浮选过程相机标定难点

相机标定对环境的要求主要包括环境稳定性、实验环境控制、标定图像质量以及标定效率等方面。在实际标定操作中，需严格控制这些因素，以确保标定结果的准确性和稳定性。而在泡沫浮选过程等受限环境下进行相机标定时，还面临以下问题及挑战。

(1) 因平面板倾斜、成像距离差异导致的浮选过程平面标定板图像失焦模糊、标定效率低的问题。

由于平面板与表层泡沫之间存在一定距离，同时为了获取更多位姿状态的平面板图像，往往会进行平面板倾斜，这造成了平面板图像的不均匀模糊。这种不均匀模糊体现在圆形特征区域，当平面板倾斜时，距离相机端更近侧的圆形特征比距离泡沫端更近侧的圆形特征模糊程度更高，且可能存在一定畸变。而在传统标定板图像去模糊算法中，通常针对全图进行去模糊操作，一方面这种方法难以有效处理不同模糊程度的圆形特征。同时，在进行全图去模糊处理后，泡沫图像区域中的高亮点会对圆形特征提取造成干扰。另一方面，针对全局图像进行去模糊需耗费较高的计算成本，整体效率较低。而在复杂的工业浮选环境中，较高的计算效率在维持相机标定过程的稳定性以及减少因计算能力不足而导致的故障或异常结果方面表现得尤为重要。因此，如何在平衡标定精度与计算效率的同时解决标定板图像的不均匀模糊是本文需解决的问题之一。

(2) 因操作环境受限、标定板非线性运动、位姿不可控等因素导致的基于泡沫视频进行相机内参标定难的问题。

浮选泡沫中的腐蚀性化学物质限制了标定操作人员的操作范围和幅度，同时受限的操作环境不具备放置固定平台和其他辅助设备的条件。因此，选择标定人员操作平面板运动的方式拍摄标定视频，这种人工操作的方式使得标定板表现出不可控的非线性运动，所采集的标定视频不可避免地包含一些视场受限、倾斜异常、泡沫遮挡的标定图像，这些图像会严重影响相机标定的准确性。此外，平面板的位姿对相机标定的结果至关重要，不同的平面板姿态会直接影响标定质量。然而，在泡沫浮选过程中，很难像在可控实验室环境中那样捕捉到三张或更多具有合适姿态的平面板标定图像。因此，如何在浮选过程标定视频中提取标定板特征完整、相互间位姿差异较大的高质量图像关键帧，是本文需解决的另一重要问

中国知网　https://www.cnki.net

题。

(3) 因浮选过程复杂外部光源环境及硬件差异而间接导致的双目相机成像时间异步的问题。

受泡沫浮选现场复杂外部光源环境影响，左右相机的曝光时间设置往往不同，同时由于硬件差异及网络延迟等影响，易造成双目视图的成像时间异步。这种成像异步可能导致双目外参的标定精度下降以及标定过程不稳定。此外，平面板位姿的非线性运动使得当前主流的基于线性插值法的特征点校正方法难以适用。另一方面，在双目相机延时范围不确定的情况下，直接进行特征优化需耗费大量的计算时间且可能陷入局部最优。因此，如何在兼顾模型效率的同时补偿双目相机的成像时间异步，获取高匹配度的左右视图校正特征点，进而提升双目外参的标定精度，是本文需解决的又一问题。

(4) 在浮选过程液位波动、相机视角变化等情况下双目外参高精度标定能力受限的问题。

受入矿条件、浮选工况状态、设备因素等多方面影响，锌快粗选过程存在一定的液位波动，可能造成表层泡沫与相机之间的距离变化。因此为了采集高清晰度的泡沫图像，有时需动态改变相机焦距以适应这种距离变化，但这使得需要固定标定板高度的传统标定方法标定精度降低。此外，为了使双目相机拥有更大范围的公共视野及光照条件，有时需改变相机视角或安装姿态，这对标定方法的稳定性和可靠性提出了较高的要求。因此，如何在浮选过程液位波动、相机视角变化等情况下进行稳定准确的相机外参标定，是本文需解决的关键问题。

2.3.2 基于加权关键帧与 FSC-McCNN 的相机标定框架

针对上述泡沫浮选过程受限环境下相机标定面临的问题及挑战，本文以锌快粗选双目视觉系统为研究对象，研究基于加权关键帧与 FSC-McCNN 的相机标定理论与方法，研发泡沫浮选过程相机标定系统，整体框架如图 2-8 所示，主要包括基于 RPMU-NET 的浮选过程失焦平面板图像复原、基于关键帧提取和位姿加权的浮选过程相机内参标定、基于闭环混合优化的双目特征点同步校正、基于 FSC-McCNN 的浮选过程双目外参标定等四个部分。

(1) 基于 RPMU-NET 的浮选过程失焦平面板图像复原

针对因平面板倾斜、成像距离差异导致的浮选过程平面标定板图像不均匀模糊的问题，提出一种基于自适应掩码调制的深度去模糊网络 RPMU-NET，采用特制的圆形掩码图像来增强深度学习模型对核心特征区域的关注度，从而提高模糊圆形特征图案的复原程度。同时，提出了一种基于平面板图像特征分区的并行计算方法，分别对单个特征圆区域进行去模糊操作，以应对模糊程度不均匀的平

中国知网 https://www.cnki.net

面板图像并大幅提升图像去模糊效率。此外，构建了一个专门针对圆形平面板图像的预训练和微调数据集，并实施了一种包含预训练和微调在内的渐进式训练策略，提高了图像复原模型的鲁棒性和泛化能力。

(2) 基于关键帧提取和位姿加权的浮选过程相机内参标定

针对因操作环境受限、标定板非线性运动、位姿不可控等因素导致的基于泡沫视频进行相机内参标定难的问题，提出基于图像质量评价的泡沫视频关键帧提取方法，以从泡沫视频中提取高质量关键帧序列。该方法通过计算不同图像间平面板倾斜度差异来评估序列图像的质量，并考虑了泡沫视频中所有可能的平面板倾斜情况，从而恢复尽可能多的畸变和透视参数。此外，提出了一种基于平面板位姿表征的关键帧图像权重计算方法，通过计算不同姿态图像的加权归一化倾斜度差异来求解相机内参，提高了相机内参标定的准确性和鲁棒性。

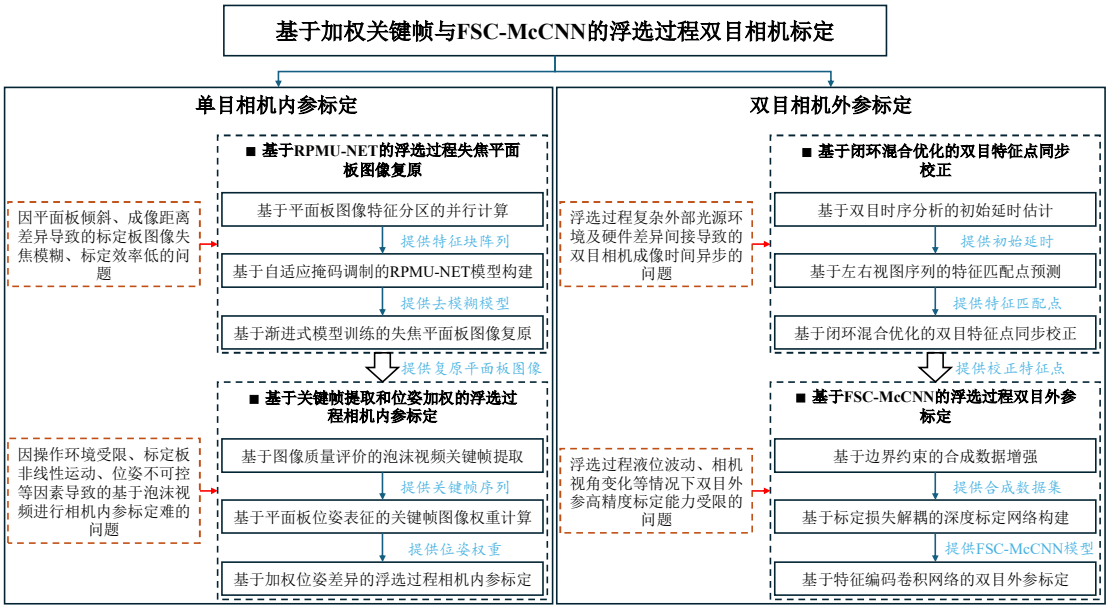


图 2-8 基于加权关键帧与 FSC-McCNN 的浮选过程相机标定研究框架

(3) 基于闭环混合优化的双目特征点同步校正

针对因浮选过程复杂外部光源环境及硬件差异而间接导致的双目相机成像时间异步的问题，提出基于闭环混合优化的双目特征点同步校正方法。该方法首先通过双目时序分析进行左右图像初始延时估计，以最小化硬件差异的影响并加速模型的收敛速度。然后，提出了一种基于左右视图序列的特征匹配点预测方法，使用了一种闭环优化策略来迭代处理浮选过程特有的平面板非线性运动，从而增强了模型的鲁棒性。最后，提出了一种基于复合误差的两阶段混合优化算法，即基于希尔爬升的改进差分进化算法(HC-IDE)，以同步优化所有的右相机特征匹配点。其中，该方法通过引入一种改进的变异策略，提高了优化模型的准确性和全

中国知网 https://www.cnki.net

局搜索能力。

(4) 基于 FSC-McCNN 的浮选过程双目外参标定

针对浮选过程液位波动、相机视角变化等情况，提出了一种基于 FSC-McCNN 的浮选过程双目外参标定方法。首先，建立了平面板特征图谱与相机参数之间的映射关系，在指定边界约束内进行合成数据增强，以增强模型在外部环境变化时的鲁棒性和泛化能力。然后，提出了一种基于标定损失解耦的深度标定网络，即 FSC-McCNN。该网络利用特征空间编码模块(FSC)来提升模型在不同姿态特征图谱上的空间信息表征能力，并采用多通道卷积神经网模块(McCNN)来挖掘特征编码内的多维成像信息。此外，通过解耦标定损失进一步提升了模型对不同类型相机参数的预测能力，有效避免了误差传递。

2.4 本章小结

本章首先介绍了相机标定过程基本原理，并对常规实验室环境下的相机标定方法进行了描述。然后对泡沫浮选过程的相机标定环境进行了介绍，并基于泡沫浮选过程受限环境下的典型单、双目平面板图像对影响浮选过程相机标定的主要因素进行了详细分析。最后，以锌快粗选过程为研究对象，详细分析了实现基于平面板图像的泡沫浮选过程双目相机标定需要解决的难点问题，在此基础上形成了基于加权关键帧与 FSC-McCNN 的浮选过程相机标定框架。

中国知网　https://www.cnki.net

第 3 章 基于 RPMU-NET 的浮选过程失焦平面板图像复原

失焦平面板图像复原可以更准确地获取图像中的特征信息，从而提升相机标定的精度。通过对失焦图像进行复原，可以得到更清晰的平面板图像，进而更精确地确定图像中的特征点坐标，提高相机参数求解的准确性。在图像处理领域，失焦是一种常见的图像退化现象，失焦会导致图像中的信息丢失和模糊，给后续的特征提取带来困难。通过对失焦平面板图像进行复原，可以恢复图像中的清晰信息，提高相机标定的稳定性和鲁棒性。针对现有失焦平面板图像复原方法难以处理不均匀图像模糊的问题，本章提出基于平面板图像特征分区的并行计算方法进行浮选过程失焦图像复原，并提出一种面向圆形平面板图像的深度去模糊网络来优化特征坐标。

3.1 基于 RPMU-NET 的浮选过程失焦平面板图像复原方案

失焦平面板图像复原旨在恢复或提高模糊图像的清晰度，主要包括基于传统方法的图像去模糊和基于深度学习的图像去模糊。传统方法依赖于对图像模糊成因的建模和估计，而深度学习方法则通过数据驱动的方式学习从模糊图像到清晰图像的映射关系。其中，传统方法难以处理浮选过程的复杂模糊情况(如非均匀模糊、非线性模糊等)，且传统方法计算复杂度较高，难以在浮选过程实时应用中实现快速去模糊。因此，本章采用基于深度学习的失焦平面板图像复原方案。

浮选过程失焦平面板图像复原主要依托于深度学习模型 RPMU-Net (ROI-Patched MAM-UNet)。其中，U-Net 是一种专门用于图像处理领域的卷积神经网络架构，主要由编码器(Encoder)和解码器(Decoder)两部分组成，中间通过跳跃连接相连。UNet 通过编码器提取图像的特征，这些特征包含了不同层次的语义信息，解码器则利用这些特征逐步恢复图像的空间信息。跳跃连接将编码器和解码器中的特征进行融合，实现了包含密集位置信息的特征图与包含丰富语义信息的特征图之间的融合，提高了像素分类的准确性和定位精度。UNet 具有高效利用小样本数据集的能力，这使得 UNet 在有标签数据稀缺的情况下也能取得较好的图像复原效果。本章提出的基于 RPMU-Net 的浮选过程失焦平面板图像复原方案如图 3-1 所示，分为基于感兴趣区域特征分区的并行计算和基于渐进式模型训练的编码解码器模型(MAM-UNet)两个部分。

基于感兴趣区域特征分区的并行计算部分旨在为深度去模糊网络提供尺寸适中、按模糊度分区的输入特征图像。该部分通过特征块分区来处理具有不均匀模糊的平面板图像，以在提升模型效率的同时改进图像复原效果。对于输入的原始泡沫图像，首先从该图像中提取感兴趣区域(ROI)，该区域对应于图像中的平

中国知网 https://www.cnki.net

面板部分。随后，根据特征点的定位将感兴趣区域分割成固定大小的特征块。在此基础上，对所有特征块进行两级并行计算，以提高深度学习模型的去模糊效率，方法细节详见本章第 3.2.1 和 3.2.2 节。

基于渐进式模型训练的编码解码器模型部分旨在构建深度图像复原网络 MAM-UNet，以实现高精度的圆形平面板图像去模糊。对于第一部分所提供的特征块阵列，该部分首先为每个特征块生成一个对应的圆形掩码表示，然后将该掩码和对应的特征块并行输入到 MAM-UNet 中，以获得复原特征图像。同时，本章还为 MAM-UNet 网络设计了一种渐进式模型训练策略，分别基于虚拟成像场景、受控实验室场景和真实浮选场景构建了针对圆形平面板图像的预训练和微调数据集。最后，在对所有输入特征图像进行深度复原操作之后，对集成后的特征点进行共线校正，以修正离散值，提高标定模型的准确性，方法细节详见本章第 3.2.3 和 3.3.1 节。

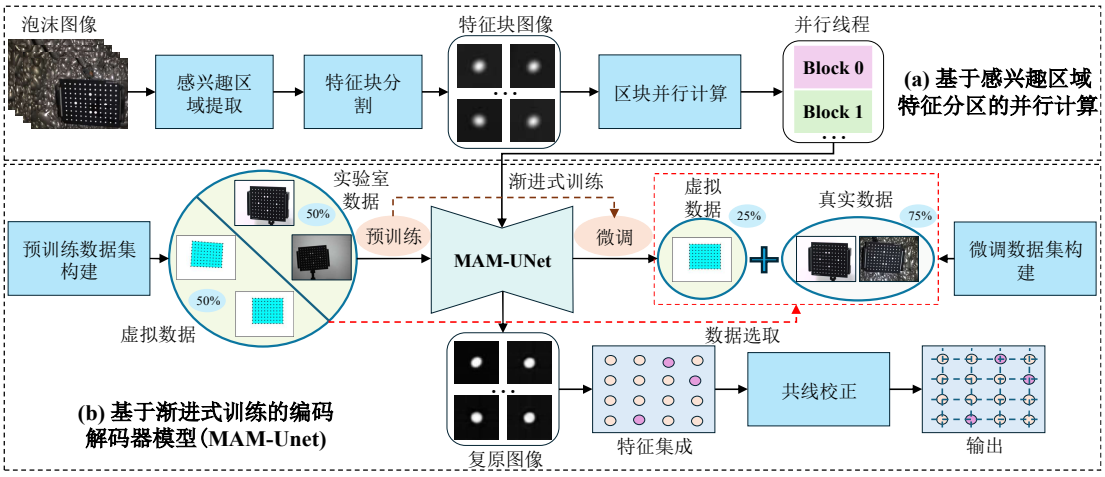


图 3-1　基于 RPMU-NET 的浮选过程失焦平面板图像复原方案

3.2 RPMU-NET 网络架构

3.2.1 特征引导的图像块分割

图 3-2 展示了典型高亮点干扰下的浮选过程不均匀模糊泡沫图像。受泡沫的物理特性和光照条件变化影响，在泡沫的顶层，由于重力作用，矿化粒子最少，光线照射后，气泡顶端的镜面反射光线最多，造成该区域的亮度最大。此外，泡沫表面通常是不规则的，存在许多微小的凹凸和纹理，这些特性会导致光线在泡沫表面发生散射和反射，进一步增强了该区域的亮度。因此，在每个气泡中心经常会形成一个亮点团簇，这个团簇就是泡沫图像中的高亮点。由于部分泡沫高亮点呈现圆形或椭圆形态，尺寸与平面板上的圆形图案接近，在进行圆形特征提取时易生成噪点。因此，本节首先进行感兴趣区域(即平面板图像区域)提取。

中国知网　https://www.cnki.net

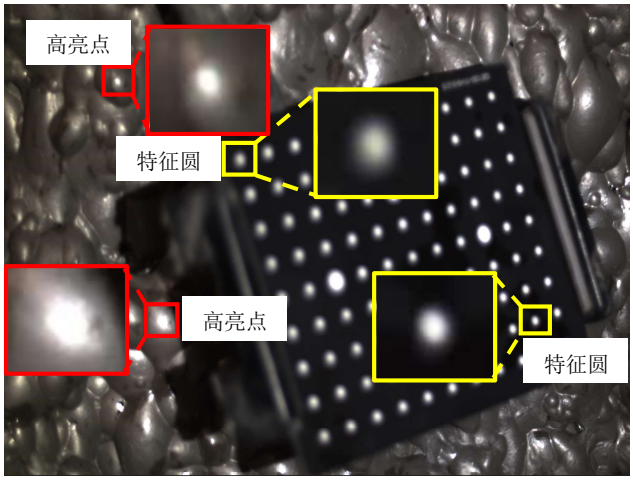


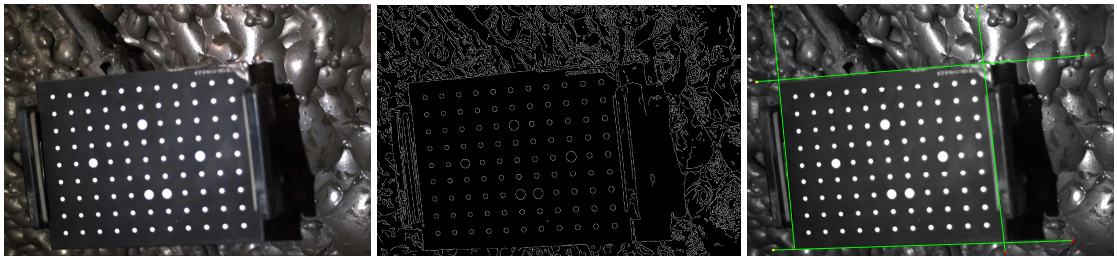
图 3-2 高亮点干扰的浮选过程不均匀模糊泡沫图像

对于输入的泡沫图像 I，首先使用 Canny 边缘检测算法生成二值图像，其核心思想是在图像中找到梯度变化最大的位置，从而确定边缘的位置。通过高斯滤波降噪、计算梯度幅值和方向、非极大值抑制、双阈值检测以及边缘连接等步骤，能够高效、准确地检测出图像中的边缘，具有低错误率和单一响应等优点，检测结果如图 3-3-b 所示。

然后，采用霍夫变换算法提取边缘检测二值化图像中的感兴趣平面板区域，对于二值图像中的每一条曲线，分别计算其相对于原点坐标的距离，由于直线是图像中离散点的集合，因此通过直线的离散极坐标公式，可得到线条的参数化表示为：

$$rho = X * \cos(\theta) + Y * \sin(\theta) \tag{3-1}$$

式(3-1)中，rho 指的是直线几何垂直距离，$\theta \in [-90°, 90°)$ 指的是从原点到线条的垂线相对于 X 轴的夹角。在进行霍夫变换时，将二值化图像中的每个像素坐标点从(X,Y)坐标系转换到(rho，θ)上，当出现参数峰值时表明检测到直线，检测结果如图 3-3-c 所示，其中直线封闭区域即为感兴趣平面板区域。



(a) 原始图像　(b) 边缘检测二值化图像　(c) 感兴趣区域

图 3-3 感兴趣平面板区域提取

中国知网 https://www.cnki.net

在从原始泡沫图像中提取了感兴趣平面板区域之后，进行特征引导的图像块分割操作，使模型能够更有效地管理呈现不均匀模糊的圆形特征点区域，同时大幅提升去模糊效率。对于输入泡沫图像 I 的感兴趣平面板区域，我们使用 Hough 圆检测算法定位感兴趣区域的圆形中心坐标和半径，即：

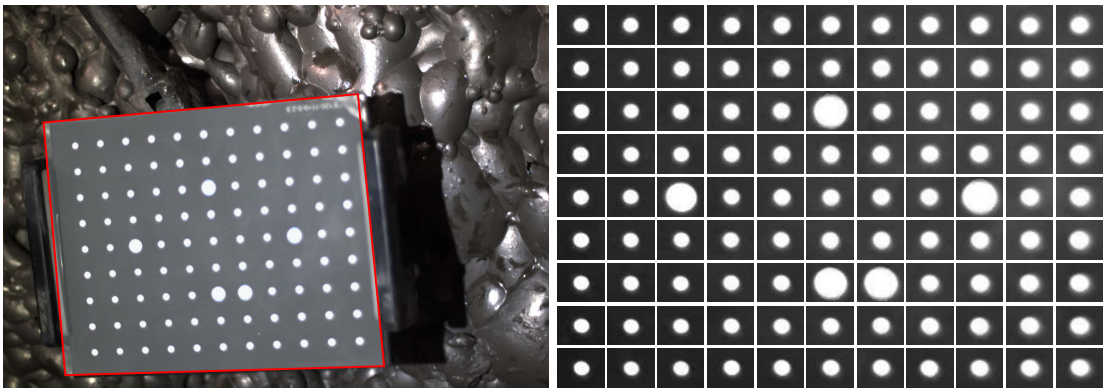
$$[(c_i^x, c_i^y), r_i] = HoughCircle(ROI(I)), i = 1, 2, ..., m. \tag{3-2}$$

式(3-2)中，c 和 r 分别指的是感兴趣区域中所检测到的圆形特征的圆心坐标和半径，m 为感兴趣区域 $ROI(I)$中检测到的圆的总数量，$HoughCircle(\cdot)$表示的是 Hough 圆检测算法[180]。

然后，根据所提取的圆心特征坐标分割每个圆的正方形特征块图像，即：

$$FP_i = I(c_i^x - l : c_i^x + l, c_i^y - l : c_i^y + l) \tag{3-3}$$

式(3-3)中，l 为圆形特征对应的图像块边长的一半，$I(\cdot)$为原始泡沫图像 I 对应的像素区域，图像 I 中感兴趣区域所分割的所有特征块图像如图 3-4 所示。



(a) 平面板图像感兴趣区域　　(b) 特征块图像

图 3-4 平面板图像感兴趣区域分割后的特征块图像

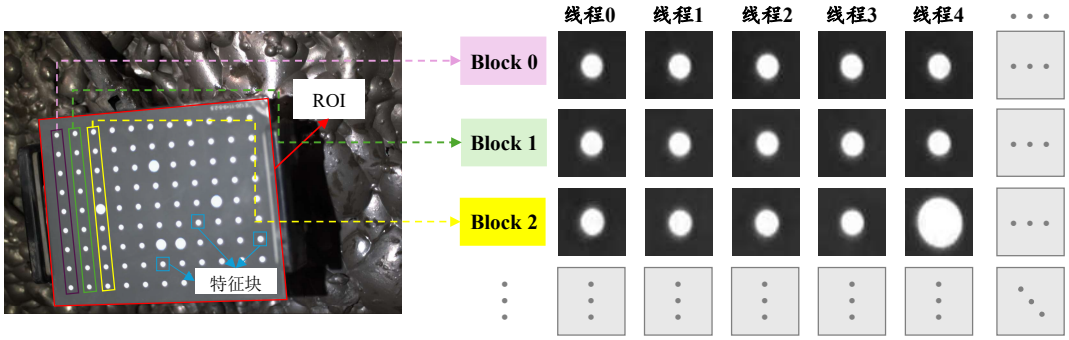
3.2.2 基于平面板图像特征分区的并行计算

为了提高深度复原模型的处理效率，在提取了特征块图像后，对所有的特征块进行分区并行计算。并行计算的原理是同时利用多个处理器或多台计算机的核心来处理任务的各个部分，从而提高总体计算效率。通过同时执行多个子任务，可显著缩短计算时间，同时能最大化地发挥计算资源的作用，避免资源闲置。而当图像复原任务规模扩大时，可以通过增加处理器或计算节点来扩展计算能力，具有良好的可扩展性。在运行过程中，即使部分处理器或计算节点出现故障，其他正常节点仍能继续工作，确保所有复原任务完成。

基于平面板图像特征分区的并行计算过程如图 3-5 所示。在泡沫浮选过程的平面板数据采集过程中，为了尽可能的使平面板完全处于双目相机的公共视场中，

中国知网　https://www.cnki.net

同时为了捕获更多样的平面板位姿图像，通常选择基于平面板短轴的左右倾斜方式，这种倾斜方式造成了不同列圆形特征之间的显著模糊差异。因此，以单列圆形特征作为一个特征块分区进行并行计算。本节使用了一种两层并行处理方法来提升深度图像复原模型的效率，在第一层，使用单独的 CUDA(Compute Unified Device Architecture)线程阵列来并行处理不同列之间的特征块。CUDA 是一种并行计算平台和 API 模型，可使用 GPU 进行通用计算。使用单独的 CUDA 线程块并行处理一个分区的特征块图像主要需利用 CUDA 的并行计算模型和内存管理模型。



(a) 特征块并行调度　　(b) CUDA线程并行处理

图 3-5 基于平面板图像特征分区的并行计算

记特征块图像的总数量为 $u*v$，则设置线程网格的维数为 v，线程块的维数为 u，可得特征块分区如下：

$$Block(h)=\left\{FP_{(1:u,h)}\right\},(h=1,2,...,v)\,. \tag{3-4}$$

在第二层，每个区块中的线程负责处理同一列中的不同特征块图像。该过程的核心原理是将复杂的计算任务分解为多个简单的子任务，然后在 GPU 的多个核心上并行执行这些子任务，从而显著提高模型效率。在 CUDA 中，GPU 被划分为多个流处理器，每个流处理器包含多个 CUDA 核心。CUDA 通过线程阵列的方式将任务分配给流处理器，这些线程在流处理器上并行执行。对于图像复原任务，特别是分区特征块图像的并行处理，CUDA 的并行计算能力可以显著加速处理过程。通过将每张特征块图像分配给不同的线程或线程块进行处理，以实现高效的并行计算。通过上述两层并行处理过程，最终产生了所有特征块图像的完整复原结果，在 GPU 上完成并行处理后，将复原特征图像从 GPU 内存复制回主机内存，并对结果进行进一步的处理和分析。

3.2.3 基于自适应掩码调制的编码解码器模型

针对模糊平面板特征块图像，提出了一种基于自适应掩码调制的编码解码器

中国知网 https://www.cnki.net

模型(Mask adaptive modulation U-shaped Network，MAM-UNet)，用于模糊圆形特征图像复原，该编解码网络的详细架构如图 3-6 所示。

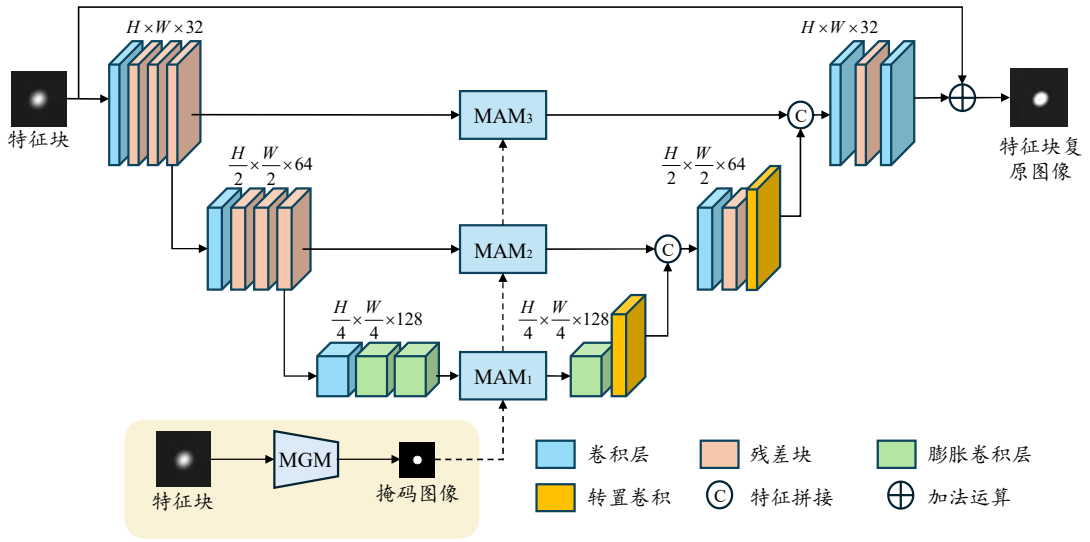


图 3-6 基于自适应掩码调制的编码解码器模型 MAM-UNet

(1) 掩码生成模块(Mask generation module，MGM)

为了强化模型对圆形特征区域的集中处理与精准复原，提出了一个掩码生成模块(MGM)，该模块的核心功能在于能够动态且精确地生成一系列与输入特征块对应的掩码表示。MGM 能定位特征块的位置和边界，特别是针对圆形特征区域，确保所生成的掩码能够紧密贴合，避免信息的泄露或冗余。这种高度定制化的掩码设计，有效提升了模型在复原不均匀模糊图像时的鲁棒性和准确性。对于任意输入的特征块图像 $FP_i \in \mathbb{R}^{H*W}$，其对应的掩码表示为：

$$\mathrm{M}=\begin{cases}255, if\ FP_i(\sqrt{(x_0-c_i^x/4)^2+(y_0-c_i^y/4)^2}\le r_i/4)\\ 0,\quad else\end{cases} \tag{3-5}$$

式(3-5)中，$M \in \mathbb{R}^{\frac{H}{4}*\frac{W}{4}}$。

然后，将图像 I 的所有特征块及其所生成的对应掩码表示并行输入到深度图像复原模型 MAM-UNet 中。在模型内部，掩码图像作为额外的信息输入层，引导深度学习模型更加专注于圆形特征区域的处理，有效抑制了背景噪声和其他非关键信息的干扰。通过这种方式，模型能够更高效地分配计算资源，集中力量解决圆形特征的去模糊问题，从而在整体上提升图像复原的质量和效率。

(2) MAM-UNet

为了有效地整合掩码信息来预测去模糊图像，提出了一种深度学习架构，MAM-UNet，该架构专为模糊圆形图像复原所设计。MAM-UNet 融合了多种类型的网络模块，以确保有效处理不均匀、非线性的复杂模糊图像。具体而言，MAM-

中国知网　https://www.cnki.net

UNet 由一个编码器、一个解码器、基于特征拼接的跳跃连接以及自适应掩码调制模块(MAM)组成。这些组件相互集成，共同提升了模型在提取、处理和重建图像特征方面的能力。

MAM-UNet 的初始残差块和下采样组件均基于经典的 U-Net 体系结构进行构建。U-Net 架构以其对称的编码器-解码器结构和多尺度特征融合能力而闻名，已被广泛应用于多种图像处理任务中，特别是在去模糊任务中展现出了卓越性能[181, 182]。通过继承 U-Net 的这些优势，MAM-UNet 能够在保留图像细节的同时，有效地去除图像模糊。此外，MAM-UNet 还引入了自适应掩码调制模块(MAM)，该模块能够根据输入的掩码信息动态地调整网络参数，从而实现对不同区域特征的精细处理。这种自适应机制使得 MAM-UNet 在处理具有复杂模糊图像时展现出更强的泛化能力。其中，在 MAM-UNet 网络架构中，引入了包含扩大感受野的膨胀卷积块，这些膨胀卷积块通过调整卷积核的大小和步长，有效地扩大了模型的感受野，使深度学习模型能够捕捉到更广泛、更全面的图像上下文信息。此外，通过在模型中引入嵌入 MAM 的跳跃连接方式，来优化图像信息传输的路径，显著提升了信息传输的效率和质量，使得更细节的图像信息能够顺利地从较低的学习层传输到较高的层。这一改进有利于实现更好的模糊图像细节重建，同时也有助于最大限度地减少在图像重建过程中可能产生的伪影，从而提升图像的整体质量。

自适应掩码调制模块(MAM): MAM 模块的详细结构如图 3-7 所示。在 MAM 模块中，首先使用普通的卷积块从输入的模糊特征块图像中提取出局部特征，这些局部特征随后被传递给膨胀卷积块，以进一步提取全局图像特征。其中，使用膨胀卷积块的目的是为了在不增加模型计算复杂度的情况下，感知更大范围内的图像信息，从而提取更全局的图像特征。在 MAM 模块中，组合使用卷积块和膨胀卷积块可实现局部特征和全局特征的互补。这种互补性不仅有助于保留更多的图像信息，还能在恢复图像时呈现出更清晰的细节。

在 MAM 中，卷积运算与整体 MAM 模块的交互是通过多个卷积层(包括膨胀卷积层)与上采样层的结合来实现的，共同完成特征提取、感受野扩展、特征融合、图像去模糊等任务。对于输入到 MAM 模块的平面板特征块图像 $\hat{\Phi}$，将其所生成的对应掩码表示记作 $\mathrm{M}_s,(s=1,2,3.)$，则其输出到下一层的掩码表示为：

$$\mathrm{M}_{s+1}=DC(conv_{1\times1}(H_{upsample}(\mathrm{M}_s))) \tag{3-6}$$

式(3-6)中，$DC(\cdot)$指的是膨胀卷积块，$conv$ 指的是卷积层，$H_{upsample}$ 表示的是上采样操作。

基于上述操作，对于编码器从原始图像中提取的特征图谱 f_s，MAM 模块对应的输出为：

中国知网 https://www.cnki.net

$$f_s' = f_s \otimes DC(conv(M_s) + DC(conv(conv(M_s)) . \tag{3-7}$$

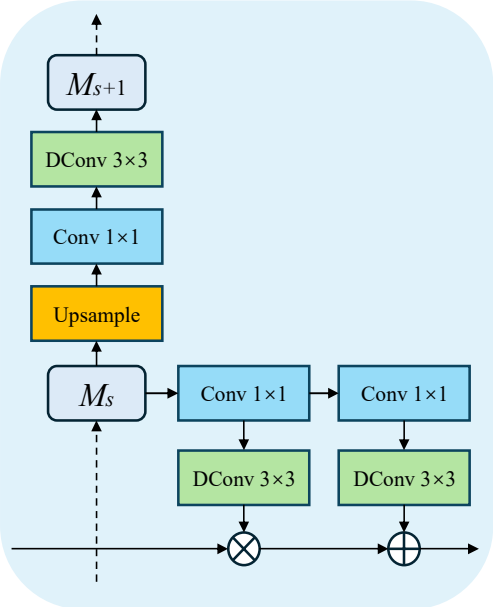


图 3-7 自适应掩码调制模块(MAM)

编码器设计: MAM-UNet 编码解码器框架如图 3-8 所示。其主要功能是将输入图像转换为一系列具有不同分辨率和特征表示的特征图，这些特征图包含了图像的关键信息和结构，然后将这些信息传递给解码器，用于指导去模糊过程，生成清晰的图像。编码器整体设计旨在通过卷积层提取底层特征，通过多层残差块增强特征提取能力和解决梯度消失问题，以及通过膨胀卷积块扩大感受野和提高去模糊效果。这些设计共同作用，使得编码器能够学习到图像中的模糊模式和结构信息，为后续的去模糊操作提供准确、可靠的特征表示。

MAM-UNet 网络中编码器部分采用多层卷积层、残差块、膨胀卷积块的结构，逐步提取输入图像的高层次特征。其中，卷积层通过不同的卷积核(滤波器)对输入图像进行卷积操作，提取出图像中的边缘、纹理等底层特征。卷积操作通常会减少特征图的尺寸(通过步长大于 1 的卷积或池化操作)，从而减少计算量，并提取出更抽象的特征。通过多层残差块，使得深度复原网络能够学习到更深层次的特征，而跳跃连接允许梯度在反向传播时直接传递到较浅的层，从而避免了梯度消失问题，使网络能够训练得更深。同时多层残差块能够增强网络的非线性表达能力，从而提高去模糊效果。编码器中的膨胀卷积块通过增加卷积核元素之间的间距来扩大感受野，从而捕捉到更广阔的图像信息，帮助网络更准确地判断模糊区域和清晰区域，从而提高去模糊效果。

中国知网　https://www.cnki.net

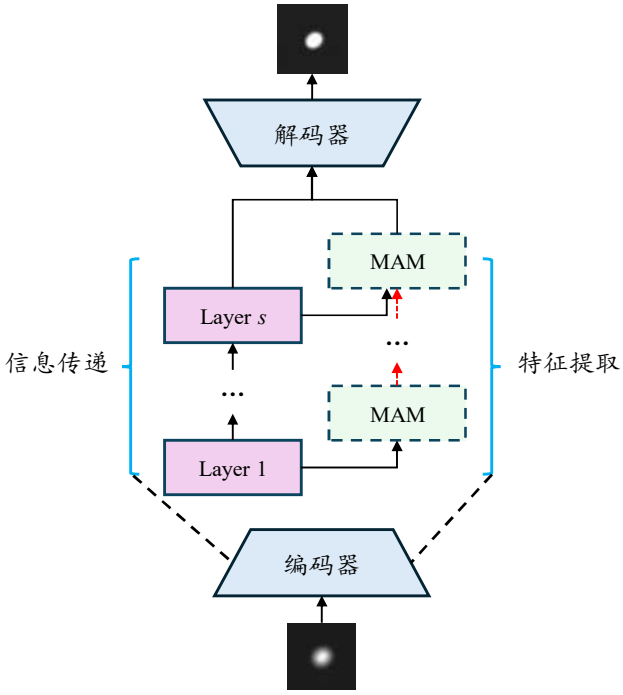


图 3-8 编码解码器设计框架图

解码器设计：MAM-UNet 解码器部分的整体设计旨在进一步提取和融合特征信息，通过转置卷积逐步恢复图像的分辨率和细节信息，并通过特征拼接、加法运算和跳跃连接等操作融合来自不同层和不同模块的特征信息。这些设计共同作用，使得解码器能够准确地恢复图像的细节和纹理信息，同时去除图像中的模糊和噪声。这种设计不仅提高了去模糊效果，还有效增强了网络的泛化能力和鲁棒性。

其中，在解码器中卷积层和残差块用于进一步提取和融合来自编码器传递的特征，以逐步恢复图像的分辨率和细节。转置卷积(也称为反卷积或上采样卷积)是卷积的逆操作，用于把低分辨率的特征图上采样到高分辨率。在解码器中，转置卷积用于逐步恢复图像的分辨率，使其接近输入图像的尺寸，同时转置卷积还有助于保留和增强图像的边缘和纹理等细节信息。特征拼接是将来自不同层或不同分支的特征图按通道维度进行拼接，从而增加特征的维度和丰富性，有助于融合来自编码器和解码器不同层的特征信息，提高去模糊效果。加法运算是对两个相同尺寸的特征图进行逐元素相加，可以用于融合来自不同层或不同模块的特征信息，增强网络的表达能力。跳跃连接有助于保留和传递编码器中的关键特征信息，避免信息在解码过程中的丢失。

因此，根据图 3-6 所述的编码解码器架构，对于输入的特征块图像 I，其解码器各层的输入如下：

$$d_1(I) = f_1' \in \mathbb{R}^{\frac{H}{4}*\frac{W}{4}} \tag{3-8}$$

中国知网 https://www.cnki.net

$$d_2(I) = Concat(f_2', d_1(O)) \in \mathbb{R}^{\frac{H}{2}*\frac{W}{2}} \tag{3-9}$$

$$d_3(I) = Concat(f_3', d_2(O)) \in \mathbb{R}^{H*W} \tag{3-10}$$

其中，$d_s(I)$和 $d_s(O)$分别表示解码器在第 s 层的输入和输出，$Concat(\cdot)$表示的是特征拼接操作。

然后，可以得到输入特征块图像的复原结果，即：

$$D = FP + conv(RB(conv(d_3(I)))) \tag{3-11}$$

式(3-11)中，$RB(\cdot)$表示的是残差块。

损失函数设计：MAM-UNet 使用输出的复原图像与输入的特征块图像之间的均方误差(Mean-Square Error, MSE)和结构相似性(Structural Similarity, SSIM)来计算损失函数。MSE 是衡量预测值和真实值之间差异程度的一种方法，广泛应用于数据分析和机器学习领域。通过计算每个像素预测值与真实值之差的平方，然后求这些平方差的平均值，MSE 能够提供一个量化的误差指标。在图像去模糊任务中，MSE 可以帮助深度网络学习到如何减少复原图像与真实清晰图像之间的像素差异。SSIM 是一种衡量两幅图像相似度的指标，它考虑了图像的亮度、对比度和结构三个维度[183]。相较于 MSE 逐像素计算差异的方式，SSIM 更注重图像的整体结构和感知质量。在图像复原过程中，SSIM 可以帮助深度网络学习到如何恢复出与真实清晰图像在结构上更为相似的复原图像。将 MSE 和 SSIM 结合使用，可以互补二者的不足，更全面地评估复原图像的质量。同时可以引导网络在减少像素差异的同时，也注重恢复图像的整体结构，这有助于模型在处理不同场景和类型的模糊图像时表现出更好的泛化能力。

在 MAM-UNet 网络中 MSE 损失计算公式为：

$$\mathcal{L}_{MSE} = \frac{1}{N}\sum_{j=1}^{N}(D^j - FP^j)^2 \tag{3-12}$$

式(3-12)中，$\mathcal{L}_{MSE}$ 指的是 MSE 损失。

此外，SSIM 损失计算公式为：

$$\mathcal{L}_{SSIM}(D, FP) = \frac{(2\mu_D\mu_{FP} + c_1)(2\sigma_{D\cdot FP} + c_1)}{(\mu_D^2 + \mu_{FP}^2 + c_1)(\sigma_D^2 + \sigma_{FP}^2 + c_2)} \tag{3-13}$$

式(3-13)中，$\mathcal{L}_{SSIM}$ 指的是 SSIM 损失，μ_D 是 D 的平均值，μ_{FP} 是 FP 的平均值，σ_D^2 和 σ_{FP}^2 分别表示 D 和 FP 的方差，$\sigma_{D\cdot FP}$ 是 D 和 FP 的协方差，c_1 和 c_2 是维持算法稳定的常数。此外，SSIM 损失的范围为[-1,1]，当两张输入图像相同时，SSIM 值等于 1。

然后，在训练过程中使用以下组合损失函数对 MAM-UNet 进行迭代优化：

中国知网 https://www.cnki.net

$$\mathcal{L}_{total} = \mathcal{L}_{MSE}(D, FP) + \lambda * \left(1 - \mathcal{L}_{SSIM}(D, FP)\right) \tag{3-14}$$

式(3-14)中，λ 指的是用于调整不同损失误差比例的超参数。

(3) 共线校正

对于单帧原始泡沫图像，在进行感兴趣区域提取、特征块分割、区块并行计算、基于 MAM-UNet 的图像复原过程后，共可产生 *u***v* 个复原特征图像。考虑到图像复原过程是针对每一个特征块图像独立进行的，这样的处理方式虽然能有效适应图像的不均匀模糊，但也可能导致不同特征块之间的信息关联性减弱，使得标定误差增大。因此，对所有复原特征图像进行了共线校正，旨在通过算法调整使得可能因去模糊处理而略微离散的特征点重新回归到直线阵列上。该过程不仅增强了特征点之间的几何一致性，也为后续的参数求解提供了更为可靠的数据基础。

首先，对 *u***v* 个复原特征图像进行特征提取和集成，即：

$$\widehat{D} = \begin{bmatrix} D'_{1,1} & D'_{1,2} & \cdots & D'_{1,v} \\ D'_{2,1} & D'_{2,2} & \cdots & D'_{2,v} \\ \cdots & \cdots & \cdots & \cdots \\ D'_{u,1} & D'_{u,2} & \cdots & D'_{u,v} \end{bmatrix} \tag{3-15}$$

式(3-15)中，$D'_{i,j}$ 指的是提取第 *i* 行第 *j* 列的特征块图像的圆心坐标。

然后，使用最小二乘法对每一行和每一列的特征点分别进行直线拟合，使得这条直线与给定的数据点之间的误差(即每个数据点到直线的垂直距离)的平方和最小，随后对所有的偏移点进行共线校正。以第一行特征点坐标为例，首先假定最佳拟合直线方程为 *y*=*mx*+*b*，则这些点距离直线的偏差之和为：

$$s^2 = \sum_{i=1}^{v} (D'_{i,j}(y) - y)^2 = \sum_{i=1}^{v} (y_i - (mD'_{i,j}(x) + b))^2 \tag{3-16}$$

式(3-16)中，$D'_{i,j}(x)$ 和 $D'_{i,j}(y)$ 分别指的是特征点 $D'_{i,j}$ 的横坐标和纵坐标，常数 *m* 表示斜率，常数 *b* 表示直线在 *y* 轴上的截距。根据最小二乘法，上式中的 *m* 和 *b* 可以通过式(3-17)进行求解，即：

$$\begin{cases} m = \dfrac{v * \left(\sum D'_{i,j}(x) D'_{i,j}(y)\right) - \left(\sum D'_{i,j}(x)\right) * \left(\sum D'_{i,j}(y)\right)}{v * \left(\sum D'_{i,j}(x)^2\right) - \left(\sum D'_{i,j}(x)\right)^2} \\ b = \dfrac{\left(\sum D'_{i,j}(x)^2\right) * \left(\sum D'_{i,j}(y)\right) - \left(\sum D'_{i,j}(x)\right) * \left(\sum D'_{i,j}(x) D'_{i,j}(y)\right)}{v * \left(\sum D'_{i,j}(x)^2\right) - \left(\sum D'_{i,j}(x)\right)^2} \end{cases} . \tag{3-17}$$

中国知网 https://www.cnki.net

3.3 基于失焦平面板图像复原的浮选过程相机标定实现

3.3.1 基于预训练-微调数据集的渐进式模型训练

为了提高 RPMU-Net 模型的鲁棒性和泛化能力，本节实现了一种由预训练和微调组成的渐进式模型训练策略，如图 3-1 中间部分所示。渐进式训练策略的核心在于结合预训练的广泛性与微调的精准性。预训练阶段确保了模型拥有初始的图像复原能力，而微调阶段则针对特定泡沫浮选场景进行优化。这一策略旨在通过分阶段的学习过程，逐步增强模型复原浮选过程模糊平面板图像的能力。

首先，在预训练阶段，构建了一个多元数据集，该数据集不仅包含了大量虚拟生成的特征图像，还融入了从实际泡沫浮选过程中捕获的真实场景图像。虚拟图像通过模拟不同的模糊类型和程度，帮助模型学习到圆图像去模糊的基本原理和通用策略，而真实图像则确保了模型能够接触到实际应用中的多样性和复杂性，从而具备了处理实际工业图像去模糊的基本技能。预训练过程不仅让模型具备了基础的图像恢复能力，还赋予了模型一定的初始泛化能力，为后续针对特定任务的微调过程奠定基础。然后，针对泡沫浮选过程数据创建了一个微调数据集。微调数据集充分考虑了泡沫浮选过程中离焦问题的特殊性，如泡沫形态的变化、光照条件的差异以及相机视角的变化等，确保微调过程能够精准地针对这些需求进行优化。

(1) 预训练数据集构建

虚拟数据集：为了增强模型对平面板特征图像复原任务的适用性，本节设计了一个虚拟成像场景，该场景包括一个虚拟相机和一个固定 $u*v$ 维的圆形平面板，如图 3-9-a 所示。

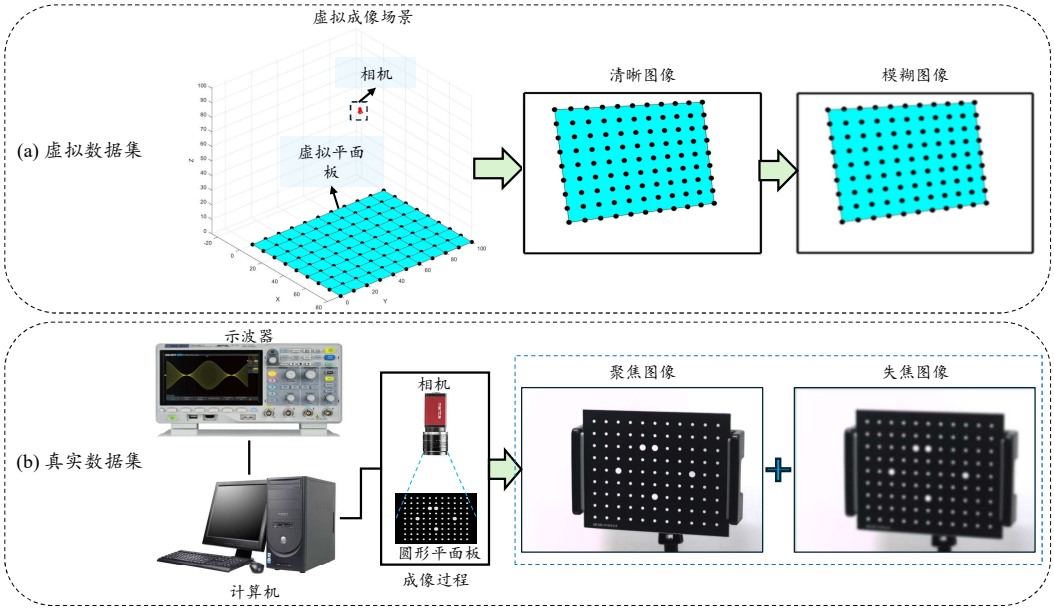


图 3-9 虚拟数据集和真实数据集构建

中国知网 https://www.cnki.net

虚拟成像场景中的虚拟相机拍摄方向设定为：

$$CamDir=\begin{bmatrix}0 & 1 & 0\\ 0 & 0 & -1\\ -1 & 0 & 0\end{bmatrix}. \tag{3-18}$$

假设给定特征点的三维坐标为 $P=[X, Y, Z]$，相机的内参为 A，外参分别为 R 和 t，则使用虚拟场景可以在针孔相机成像规则下清晰地捕获圆形特征图像，该图像没有任何畸变和模糊，所得成像点的坐标 $p=[x, y]$计算公式如下所示：

$$\begin{bmatrix}p\\ 1\end{bmatrix}=\lambda\begin{bmatrix}A & 0\end{bmatrix}\begin{bmatrix}R*CamDir & T\\ 0 & 1\end{bmatrix}\begin{bmatrix}P\\ 1\end{bmatrix}. \tag{3-19}$$

在此基础上，可以得到一个清晰的二维特征图像 S_I。然后，在一部分清晰二维图像上添加随机高斯模糊：

$$\hat{S}_I=S_I\otimes N(\sigma) \tag{3-20}$$

式(3-20)中，$N(\sigma)$指的是半径为 σ 的高斯模糊函数。

然后，可以用真实参数标签捕获更多平面板清晰-模糊图像对。此外，为了增强模型在真实场景中的性能，使用虚拟图像和真实实验室图像以相同比例构建预训练数据集，如图 3-1 中间所示。

实验室环境数据集：实验室环境下的数据采集过程如图 3-9-b 所示。在可控的实验室环境下，构建了一个工业相机成像平台，主要硬件设备包括示波器、计算机、工业相机、稳定支架和高精度平面板等。示波器用于监测信号质量，确保数据传输的稳定性与准确性。在平台搭建完毕后，使用稳定支架固定相机和平面板的位置和姿态，以最大限度地减少因震动或位移引起的图像畸变和模糊。然后，分别在聚焦和失焦的情况下采集平面板图像。聚焦状态下，通过精确调整相机的焦距和光圈，捕获细节丰富、边缘锐利的清晰平面板图像。而在失焦条件下，通过逐渐增大相机的焦距偏差，捕获一系列从轻微模糊到显著模糊的图像对。

(2) 微调数据集构建

为了增强模型在真实浮选图像上的性能，构建了一个包含三种类别图像的微调数据集，如图 3-1 中间所示。这一策略旨在通过多样化的图像资源，提升模型在复杂多变的实际应用场景中的泛化能力和复原能力。利用一部分的预训练数据集可以增强微调数据集的多样性和代表性，因此对预训练数据集进行了数据选取操作[184]。数据选取可以帮助模型更好地将预训练阶段学到的知识迁移到浮选图像复原任务上，同时这些重叠的样本也增加了微调数据集的代表性，使其更能反映真实场景情况。由于预训练数据与目标数据之间的标签匹配程度较高，本文采用基于标签的数据选取和随机选取两种相结合的方式。这种方式既考虑了标签匹

中国知网 https://www.cnki.net

配程度保证了数据的多样性，使得微调数据集既包含了与浮选图像复原任务高度相关的样本，又包含了足够多样的样本以避免过拟合。微调数据集中包括 25%的虚拟数据和 75%的真实数据，其中虚拟数据通过从预训练数据集中数据选取得到，真实数据包括实验室环境数据和真实浮选数据。

3.3.2 基于失焦平面板图像复原的浮选过程相机标定实现步骤

RPMU-Net 属于深度神经网络模型，基于 RPMU-Net 的浮选过程相机失焦标定分为 RPMU-Net 模型构建和浮选过程失焦相机内参标定两个部分。其中，RPMU-Net 模型构建是在数据集上通过渐进式策略离线进行的，而浮选过程失焦相机内参标定是在浮选现场采集的平面板图像上进行。

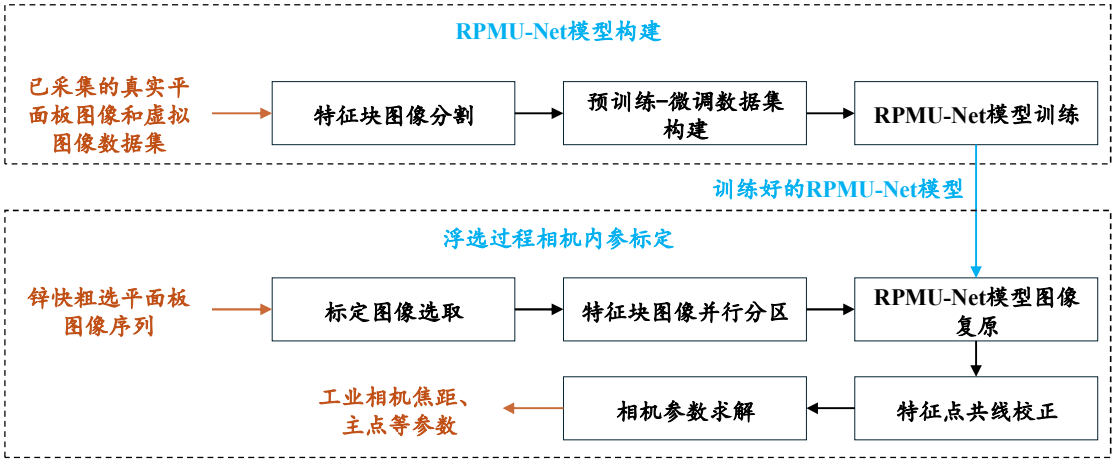


图 3-10 基于失焦平面板图像复原的浮选过程相机标定步骤

根据虚拟相机和工业相机采集的预训练-微调数据集，训练并建立性能良好的 RPMU-Net 模型，实施步骤如图 3-10 的上图所示，具体过程描述如下：

(1) **特征块图像分割：**根据采集的真实平面板图像和虚拟图像数据集，按本文第 3.2.1 节的方法，对每张平面板图像进行特征引导的图像块分割，生成如式(3-3)所示的正方形特征块图像。

(2) **预训练-微调数据集构建：**根据采集的虚拟图像、实验室数据集、浮选数据集的特征块图像，按本文第 3.3.1 节的方法，生成特征块图像清晰-模糊图像对，并按特定比例分别构建预训练数据集和微调数据集。

(3) **RPMU-Net 模型训练：**按图 3-1 和图 3-6 建立 RPMU-Net 网络框架，并采用反向传播训练方法在所构建的预训练-微调数据集上，按式(3-14)计算模型训练损失，通过不断训练和迭代选择最佳的模型超参，从而构建最优的图像复原模型。

浮选过程失焦相机内参标定通过已建立的最优 RPMU-Net 模型，根据现场

中国知网 https://www.cnki.net

采集的平面板图像获得相机内参值，实施步骤如图 3-10 下图所示，具体过程描述如下：

(1) **标定图像选取：**根据式(3-2)从采集的浮选泡沫图像中提取特征点坐标，选取特征点完整的标定图像，并使用最近采集的 8 张完整平面板图像进行相机标定。

(2) **特征块图像并行分区：**按本文第 3.2.2 节的方法，对选定的 8 张标定图像进行特征块提取和分区，并按图 3-5 所述的并行计算方法将特征块图像分区并行输入图像复原模型。

(3) **RPMU-Net 模型图像复原：**对于并行输入的特征块图像，使用已训练好的 RPMU-Net 模型进行图像复原，并按式(3-11)获得清晰的复原特征块图像。

(4) **特征点共线校正：**根据所有的复原特征块图像，按本文第 3.2.3 节的方法，分别对每一行和每一列的特征点进行共线校正，并按图像序号存储校正后的特征点坐标。

(5) **相机参数求解：**根据 8 张复原图像的校正特征点坐标，使用张正友标定法求解相机内参，包括焦距、主点、畸变参数等。

3.4 基于 RPMU-NET 图像复原的浮选过程失焦相机标定效果验证

3.4.1 实验数据集、模型性能评估及对比模型

为了全面评估所提失焦标定方法的性能，分别在合成数据集和实际浮选过程上进行了一系列对比实验，具体描述如下。

合成数据集：合成数据集来自本文第 3.3.1 节所描述的虚拟成像场景，首先创建了一个具有 11*9 个圆形特征点的标定目标，并给定了相机的真实内参以及标定板的旋转参数和位移参数。随后，利用虚拟相机对具有不同外参的标定目标进行图像采集，所得合成平面板图像的分辨率配置为 640*480 像素。同时，为了更深入的评估模型性能，在原始合成图像上添加了图像模糊、图像噪声以构成退化图像。之后，将所提方法和其他对模型分别在原始和退化的合成图像上进行对比评估。所提模型的实现是在 PyTorch 框架[185]中进行的。此外，为了确保对比公平，所有方法都在相同的硬件上执行(即操作系统：Windows 11， CPU: Intel I7-9700, RAM: 32 GB, GPU: NVIDIA GeForce RTX 2070S)，并采用 30 次重复实验的平均结果作为最终实验结果。

泡沫浮选数据集：本文在浮选数据集上对所提方法的工业性能进行了全面的实验评估，真实浮选数据集来自位于中国南方的一座铅锌选矿厂。为了便于评估，在浮选现场同样采用了 11*9 的圆形平面板，每个圆形特征点的中心间距为 10mm。实验装置采用了工业光源、工业交换机、伸缩杆、控制器以及 Manta G-145C 工

中国知网　https://www.cnki.net

业相机，该相机以 30 的帧率连续捕获分辨率为 1388*1038 像素的泡沫图像。在采集图像时，将相机的焦平面与浮选表层泡沫精确对准，并用伸缩杆将平面板随机放置在泡沫层上方。为了进一步提高研究结果的可靠性，对比过程中使用计算机随机选择平面板图像，以最大限度地减少人为干预。

模型评估：如上所述，合成数据集中图像对应的内参和外参是已知的。因此，为了进行严格且可量化的评估，使用不同方法的估计值与实际值之间的直接差异来评估模型性能，如下所示：

$$\Delta A = \left\| A_{est} - A_{GT} \right\|_2 \tag{3-21}$$

$$\Delta R = \cos^{-1}\left(\frac{T_r(R_{GT} R_{est}^T) - 1}{2} \right) \tag{3-22}$$

$$\Delta T = \left\| T_{est} - T_{GT} \right\|_2 \tag{3-23}$$

式(3-21)中，A_{est} 指的是内参矩阵的估计值，A_{GT} 指的是内参矩阵的真实值。式(3-22)中，R_{est} 指的是旋转矩阵的估计值，R_{GT} 指的是旋转矩阵的真实值，T_r 表示的是矩阵的迹。式(3-23)中，T_{est} 指的是位移矩阵的估计值，T_{GT} 指的是位移矩阵的真实值。ΔA、ΔR、ΔT 分别表示标定过程的内外参差异评价指标。

在泡沫浮选现场的标定过程中，由于没有真实标签，因此使用重投影误差、标定结果方差及成功率作为评估指标。其中，重投影误差基本原理是将已知的三维点投影到相机图像上，然后将投影点与实际图像中的对应点进行比较。这个比较的过程可以通过计算投影点与对应点之间的欧几里得距离来实现，主要用于评估相机的内外参数的准确性。重投影误差计算公式如下：

$$E_{rep} = \sum_{i=1}^{u} \sum_{j=1}^{v} \left\| s_{i,j} - \hat{s}_{i,j}(A, R_i, t_i, D, M_j) \right\|^2 \tag{3-24}$$

式(3-24)中，$s_{i,j}$ 指的是平面板图像中的实际特征点坐标，$\hat{s}_{i,j}$ 为 $s_{i,j}$ 对应的特征重投影坐标，M_j 指的是该点的世界坐标。

此外，标定结果方差用于衡量多次标定结果之间的离散程度，该指标主要反映标定结果的稳定性和一致性。由于平面板图像是随机选取的，对于一些模糊程度较高的图像，基于传统方法的标定模型可能难以标定，因此使用成功率来衡量模型的有效性和可靠性。

对比模型：为了验证 RPMU-Net 的有效性，实验对比了多种类型的模型。根据模型功能的不同主要可以分为两类，即基于深度去模糊网络的模型与基于传统方法的相机标定模型。第一类对比模型是基于深度去模糊网络的模型，包括 DeblurGAN[186]，FS-DeblurGAN[187]，和 DeepDeblur[188]，这些模型的输入均为平

中国知网　https://www.cnki.net

面板图像，并使用本文第 3.3.1 节所述的微调数据集微调模型参数。此外，在完成图像复原任务后，所有方法的特征点均执行本文第 3.2.3 节所述的共线校正操作，并使用张正友标定法求解相机参数。第一类模型与 RPMU-Net 的详细对比过程见本文第 3.4.3 节。第二类对比模型是基于传统方法的相机标定模型，包括 SSP-DC[189]，PE-CC[30]，张式标定法[157]，RCPE-DC[42]，KFS-WNTD[156]。为了对比公平，分别按各文献所描述的方法处理平面板图像并求解相机参数，但是所有方法均只采用 8 张平面板图像进行标定。第二类模型与 RPMU-Net 的详细对比过程见本文第 3.4.3 节及第 3.4.4 节。

3.4.2 RPMU-NET 模型消融实验

为了全面评估 RPMU-Net 模型中每个模块的贡献，分别对特征引导的图像块分割过程、区块并行计算过程和自适应掩码调制模块进行了消融研究。值得注意的是，为了更好地模拟真实的浮选过程，在虚拟实验中对原始合成图像添加了非均匀模糊。此外，在去除平面板图像块分割过程后，使用原始平面板图像作为输入源。由于掩码生成模块与原始图像的交互是无效的，因此在第一部分实验中(即去除平面板图像块分割过程，保留自适应掩码调制模块)，使用随机噪声掩码来代替掩码生成模块。实验结果如表 3-1 所示，表中包括标定结果与计算时间，其中粗体表示最优结果，下划线表示次优结果。考虑到基于平面板的相机标定需要使用多张图像，因此使用每张图像的平均计算时间作为最终结果。

表 3-1 RPMU-NET 模型消融实验

特征引导的图像块分割过程	区块并行计算过程	自适应掩码调制模块	$\triangle A$	$\triangle R$	$\triangle T$	t (s)
✗	✗	✗	1.57	0.62	0.48	<u>2.57</u>
✗	✗	✓	1.34	0.57	0.51	2.61
✓	✗	✗	0.73	0.42	0.45	3.18
✓	✗	✓	<u>0.56</u>	**0.34**	<u>0.31</u>	3.24
✓	✓	✓	**0.53**	<u>0.36</u>	**0.28**	**0.62**

特征引导的图像块分割过程的有效性验证：当特征引导的图像块分割过程和自适应掩码调制模块同时被省略时，可以观察到相机标定的总体误差达到最大值，这表明特征引导的图像块分割过程在减少标定误差中起着重要作用。比较表 3-1 的第 1 行和第 3 行，可以发现当特征引导的图像块分割过程被加入(✓)时，标定结果的 ΔA 从 1.57 降低为 0.73，ΔR 从 0.62 降低为 0.42，ΔT 从 0.48 降低为 0.45，这表明该过程对于提高模型在相机参数估计的准确性方面是有效的。这可能是由于图像块分割处理增强了 RPMU-Net 模型对不规则图像模糊的适应性，这种适应性涉及到对图像中感兴趣区域的精确分割和处理，从而降低了相机内外参数的

中国知网 https://www.cnki.net

估计错误率。

区块并行计算过程的有效性验证：从表 3-1 可以发现，区块并行计算模块的集成显著提高了整体模型效率。例如，比较表 3-1 的第 4 行和第 5 行，可以发现当区块并行计算过程被加入时，单帧图像的平均运行时间 t 从 $3.24s$ 降低到了 $0.62s$，而其他指标 ΔA、ΔR、ΔT 几乎没有变化，这说明区块并行计算过程可以在不影响模型精度的同时显著提高模型运行效率。这可能是因为区块并行计算过程允许模型在处理大量数据时同时执行多个计算任务，从而减少了处理时间，提高了计算速度。这种效率的提升对于实际浮选过程应用中的快速响应和处理大尺度数据具有一定价值。

自适应掩码调制模块的有效性验证：比较表 3-1 的第 1 行到第 4 行，可以发现在加入特征引导的图像块分割过程之后，再加入自适应掩码调制模块可以显著提升标定性能。这种协同效应可能源于特征引导的图像块分割过程为 MAM 模块提供了更高质量的图像块数据，使得 MAM 模块能够对不同模糊程度的图像进行针对性的掩码调制，从而进一步提升模型精度。此外，自适应掩码调制模块通过提供有效的掩码处理，增强了模型对关键图像区域的识别和利用，从而降低了内外参标定误差，这种性能提升证明了自适应掩码调制模块在整体 RPMU-Net 模型中的作用。

综上所述，特征引导的图像块分割过程、区块并行计算过程和自适应掩码调制模块的集成，不仅提高了失焦标定的准确性，也提升了模型处理效率，三个部分的相互作用共同构成了最终的失焦相机标定系统。

3.4.3 失焦相机标定虚拟仿真实验

本节在合成数据集上对 RPMU-Net 模型及其他对比模型进行了失焦相机标定虚拟仿真实验，包括 RPMU-Net 模型整体性能评估、合成数据集标定结果对比以及在退化合成数据集的鲁棒性评估。

(1) RPMU-Net 模型整体性能评估

与第一类模型(深度去模糊模型)的对比实验：RPMU-Net 模型及第一类对比模型(即 DeblurGAN、FS-DeblurGAN 和 DeepDeblur)在合成数据集上的实验结果如表 3-2 所示。从表 3-2 中可以发现 RPMU-NET 模型在相机参数各项指标上均表现最佳，其中 ΔA 为 0.53，ΔR 为 0.36，ΔT 为 0.28，误差均远低于其他深度去模糊模型，这凸显了 RPMU-Net 模型在处理圆形平面板的失焦模糊问题的卓越性能。此外，RPMU-Net 模型的处理时间最短，仅为 0.62 秒，低于其他对比的深度图像复原算法，使其更适应需快速响应的应用场景。

与第二类模型的对比实验：RPMU-Net 模型及第二类对比模型在合成数据集

中国知网 https://www.cnki.net

上的失焦标定实验结果如表 3-3 所示。从表 3-3 中可以发现 RPMU-Net 模型在三种相机参数指标中实现了最佳性能。同时，RPMU-Net 模型的效率仅略低于张式标定法，但明显优于其他传统标定算法。这表明 RPMU-Net 模型可以有效地平衡计算成本和标定精度。此外，考虑到泡沫浮选过程对标定效率的要求，一些基于几何运算且需要大量计算时间的失焦标定方法(如 SSP-DC)并不适合。而面对工业浮选图像中存在的明显局部模糊差异，一些基于全图相位信息的方法(如 PE-CC)难以实现高精度失焦标定。

表 3-2 与第一类模型的对比实验

对比模型	$\triangle A$	$\triangle R$	$\triangle T$	t (s)
DeblurGAN	1.75	1.39	1.25	3.27
FS-DeblurGAN	2.14	1.27	1.33	4.19
DeepDeblur	1.82	0.98	1.06	2.84
RPMU-Net	0.53	0.36	0.28	0.62

表 3-3 与第二类模型的对比实验

对比模型	$\triangle A$	$\triangle R$	$\triangle T$	t (s)
SSP-DC	2.19	1.55	1.41	5.87
PE-CC	1.40	0.51	0.42	1.43
张式标定法	2.24	1.37	1.36	0.36
RCPE-DC	1.35	0.41	0.46	2.12
KFS-WNTD	1.75	0.83	0.68	2.25
RPMU-Net	0.53	0.36	0.28	0.62

(2) 合成数据集标定结果对比

本节使用第二类模型在合成数据集上的标定结果来评估 RPMU-Net 模型的性能。利用 RPMU-Net 模型和第二类模型对具有相同模糊度的退化合成数据集进行标定，各方法的内参标定结果如表 3-4 所示。

表 3-4 合成数据集标定结果对比

参数	fx (像素)	fy (像素)	u_0 (像素)	v_0 (像素)
真实值	600	600	320	240
SSP-DC	601.24	601.33	319.12	239.15
E_{rel}	0.21%	0.22%	-0.28%	-0.35%
PE-CC	600.82	600.59	320.73	240.64
E_{rel}	0.14%	0.10%	0.23%	0.27%
张式标定法	601.55	601.38	320.62	240.59
E_{rel}	0.26%	0.23%	0.19%	0.25%
RCPE-DC	601.03	600.67	319.46	239.82
E_{rel}	0.17%	0.11%	-0.17%	-0.08%
KFS-WNTD	601.12	599.10	320.75	240.67
E_{rel}	0.19%	-0.15%	0.23%	0.28%
RPMU-Net	600.30	600.32	320.18	240.24
E_{rel}	0.05%	0.05%	0.06%	0.10%

中国知网 https://www.cnki.net

表 3-4 中的相对误差表示的是标定结果和真实值之间的差异，以 x 方向焦距 fx 为例，计算方式如下：

$$E_{rel}=\frac{fx(est)-fx(GT)}{fx(GT)} \tag{3-25}$$

式(3-25)中，$fx(est)$表示的是 fx 的标定结果估计值，$fx(GT)$表示的是 fx 的真实值，E_{rel} 表示的是相对误差。

从表 3-4 中可以发现所有模型均展现了良好的性能，整体误差均较低。特别地，RPMU-Net 模型在 x 方向焦距和 y 方向焦距上的标定结果相对误差均为 0.05%，低于其他对比模型。此外，通过对其他参数相对误差的比较，可以直观地发现 RPMU-Net 模型具有较好的标定效果。

(3) 在退化合成数据集的鲁棒性评估

为了彻底评估 RPMU-Net 模型的鲁棒性及其在退化图像上的标定性能，本节分别在合成数据集中引入高斯噪声、失焦模糊和非均匀光照。随后，分别在这三种退化图像上对 RPMU-Net 模型与其他三种先进的标定方法进行了对比实验(即张式标定法[157]，RCPE-DC[42]，KFS-WNTD[156])，具体实验结果如下。

对图像噪声的鲁棒性评估：图像噪声是影响图像质量的重要因素，特别是在泡沫浮选过程工业监控系统中，图像采集设备可能会受到各种干扰，如电磁干扰、设备老化等，这些都可能引入噪声，噪声不仅会降低图像的清晰度，还可能导致误判。因此，评估模型对噪声的鲁棒性对于确保其在实际应用中的稳定性和可靠性具有一定指示意义。

本节首先在原始合成数据集上添加高斯噪声来构建噪声退化数据集，其中高斯噪声的均值固定设置为 0，并在集合 $\sigma_1=\{0.3, 0.5, 0.7, 0.9, 1.1\}$ 内按序搜索标准差以构建不同程度的噪声退化图像，噪声退化图像示例如图 3-11 所示。

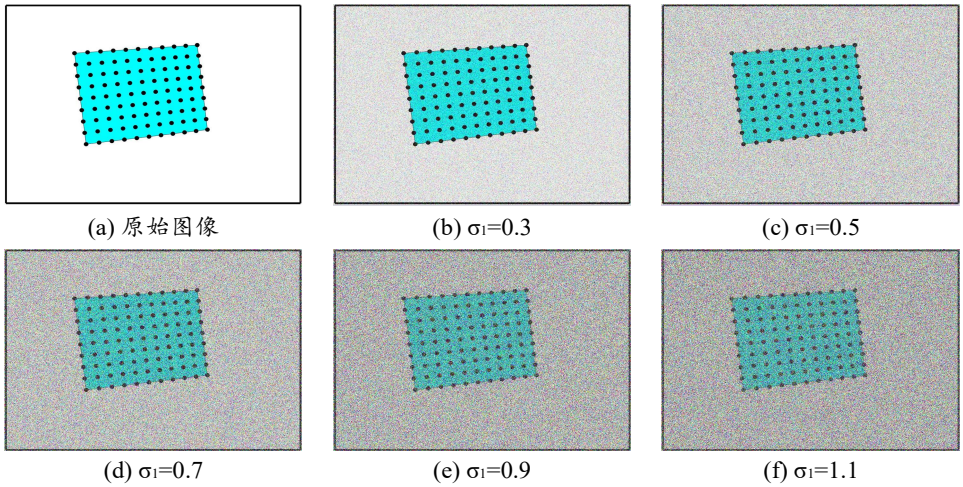


图 3-11 不同程度的噪声退化图像示例

中国知网 https://www.cnki.net

然后，分别使用张式标定法，RCPE-DC 方法，KFS-WNTD 方法和 RPMU-Net 模型对不同退化程度的噪声合成数据集进行相机内外参标定。和前文一样，本节实验也采用 30 次重复实验的平均结果作为最终输出，实验结果如图 3-12 所示。从图 3-12 可以发现，随着噪声强度的增大，张式标定法和 RCPE-DC 方法的标定误差明显增大，其中噪声变化对这两种方法的内参标定影响较大。相比之下，KFS-WNTD 方法和 RPMU-Net 模型在不同噪声强度下的误差变化保持相对稳定。此外，在所有对比方法中，RPMU-Net 模型展现了最佳的标定性能，表明该方法对图像噪声具有良好的鲁棒性。

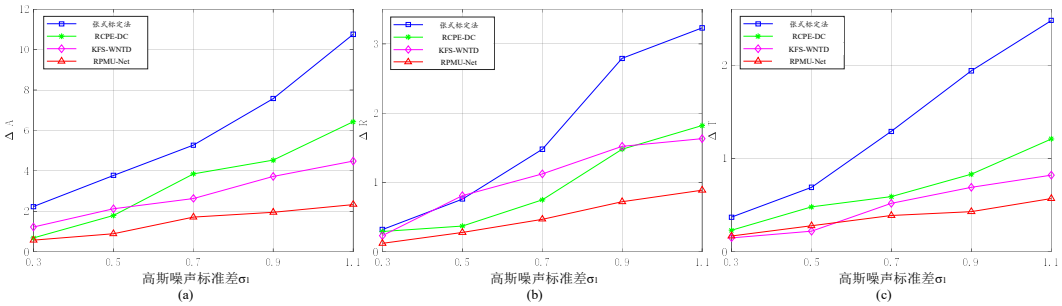
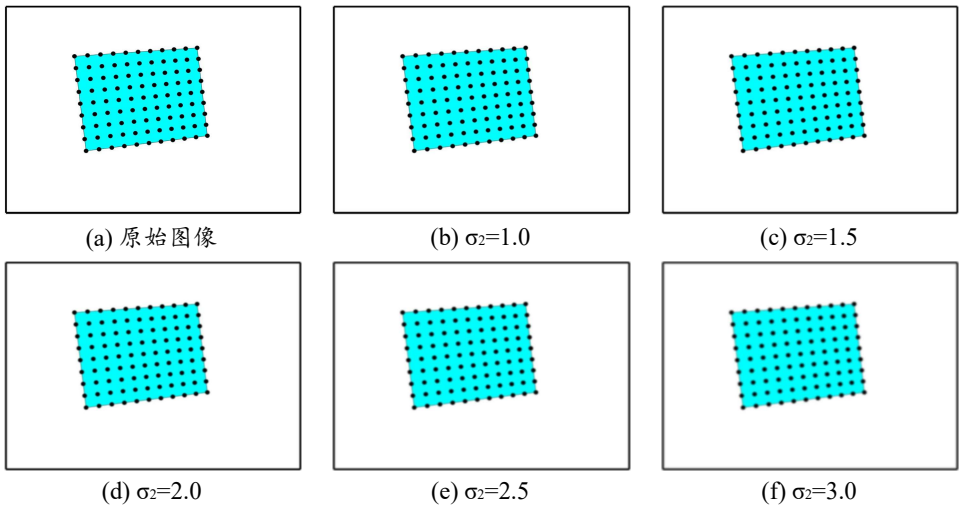


图 3-12 在噪声退化合成数据集的鲁棒性评估

对失焦模糊的鲁棒性评估： 失焦图像模糊会直接影响泡沫浮选过程的相机标定效果，导致内外参预测不准确。通过评估 RPMU-Net 模型对图像模糊的鲁棒性，可以验证模型在实际工业应用中的有效性和适应性。本节在合成数据集中添加了具有不同模糊半径的高斯模糊，并在集合 $\sigma_2=\{1.0, 1.5, 2.0, 2.5, 3.0\}$ 内按序搜索模糊半径以构建不同程度的模糊退化图像数据集，模糊退化图像示例如图 3-13 所示。



(a) 原始图像　(b) σ_2=1.0　(c) σ_2=1.5

(d) σ_2=2.0　(e) σ_2=2.5　(f) σ_2=3.0

图 3-13 不同程度的模糊退化图像示例

中国知网 https://www.cnki.net

与图像噪声的鲁棒性评估实验类似，使用上述三种比较方法和 RPMU-Net 模型对不同模糊退化程度的合成数据集进行相机内外参标定，实验结果如图 3-14 所示。从图 3-14 中可以发现，张氏标定法和 KFS-WNTD 方法的标定误差随着图像模糊强度的增大而明显增大。与这两种方法相比，RCPE-DC 方法总体误差相对较小，但在相机内参上也呈现出一致的误差上升趋势。此外，相对其他几种对比方法，RPMU-Net 模型在内外参数上都表现出最低的误差和最稳定的标定性能，这表明该方法在标定失焦图像时是有效的且鲁棒性良好。

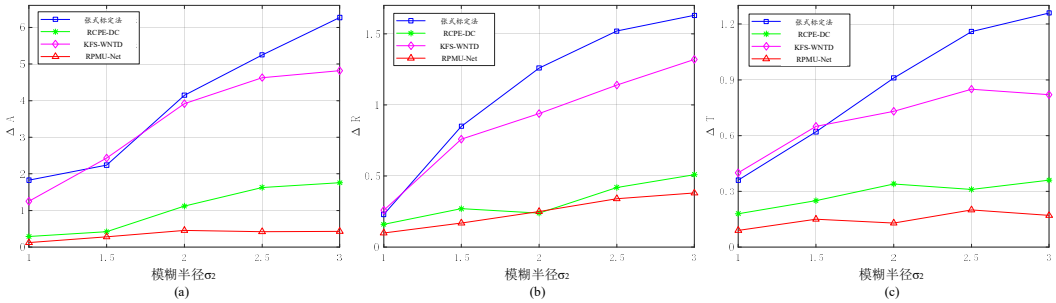


图 3-14 在模糊退化合成数据集的鲁棒性评估

对光照强度变化的鲁棒性评估：光照强度变化可能导致图像对比度和亮度的波动，导致图像质量下降。本节使用伽马指数法来调整合成数据集中原始图像的亮度，并在集合 $\sigma_3=\{0.5, 0.7, 0.9, 1.1, 1.3\}$ 内按序搜索强度因子以构建不同程度的光照变化图像数据集，光照强度变化图像示例如图 3-15 所示。

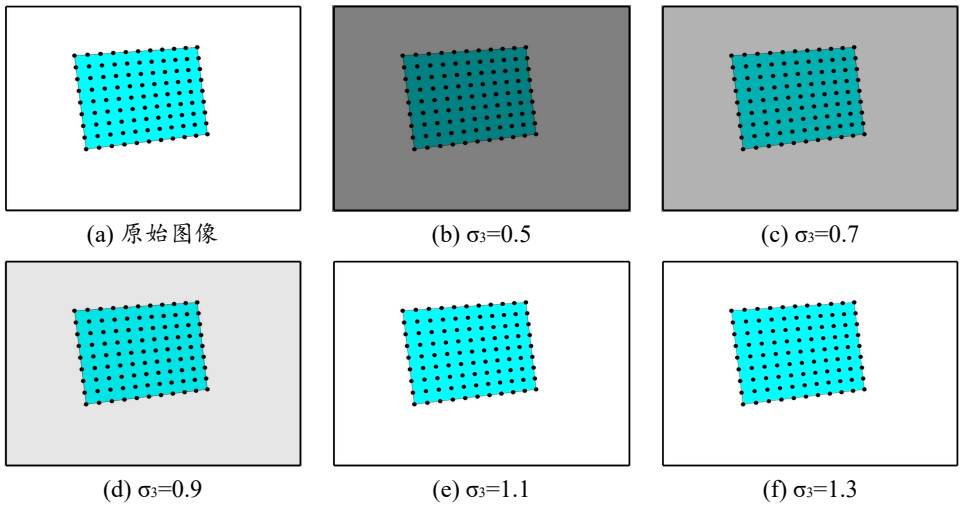


图 3-15 不同光照强度的图像示例

与前两种鲁棒性评估过程类似，使用上述三种比较方法和 RPMU-Net 模型对光照强度变化图像数据集进行标定，实验结果如图 3-16 所示。从图 3-16 中可

中国知网 https://www.cnki.net

以发现，随着图像光照强度的变化，所有方法对标定参数误差呈现不规则变化，没有明显的线性变化趋势。这表明这几种方法对图像光照强度展现出高度的鲁棒性，在所测试的强度因子变化范围内均呈现了相对稳定的标定结果。

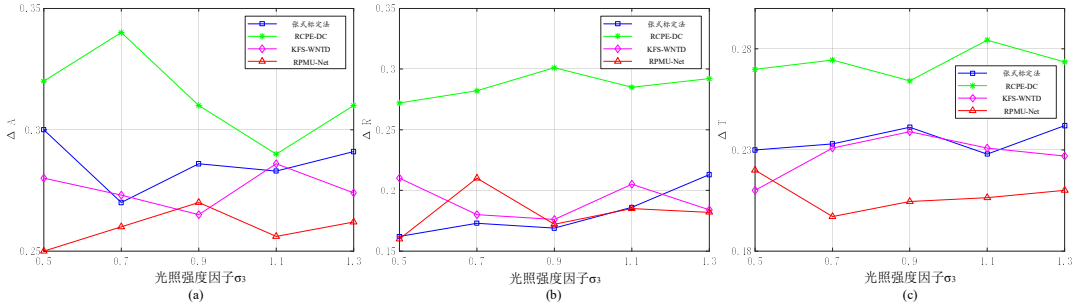


图 3-16 在光照强度变化合成数据集的鲁棒性评估

3.4.4 失焦相机标定工业应用实验

本节在真实泡沫浮选环境进行了失焦相机标定工业应用实验，并将 RPMU-Net 模型和张式标定法[157]，RCPE-DC [42]，KFS-WNTD [156]进行了对比分析。主要包括泡沫浮选过程中失焦相机标定结果分析、失焦标定重投影误差对比实验、浮选过程标定鲁棒性对比实验和 RPMU-Net 模型可扩展性及计算效率分析。

(1) 泡沫浮选过程中失焦相机标定结果分析

泡沫浮选场景模型性能评估：表 3-5 分别展示了多种对比方法在工业浮选过程中的相机内参标定结果，包括张式标定法[157]，RCPE-DC [42]，KFS-WNTD [156]、没有进行渐进式训练的 RPMU-Net 模型，以及进行渐进式训练的 RPMU-Net 模型。特别地，在没有进行渐进式训练的 RPMU-Net 模型中，仅使用本文第 3.3.1 节所述的预训练数据集来训练模型。其中，由于用于标定的原始泡沫图像是从泡沫视频序列随机选取的，张式标定法和 KFS-WNTD 方法在面对具有显著局部模糊或全局模糊的图像时，可能会在标定过程中遇到困难或表现出异常高的误差。为了应对这一问题，本节对使用这两种方法难以标定的图像进行了统计分析，并随机替换它们直到成功完成标定。同样的，使用 30 次正常标定运行的结果作为最终输出。

此外，在表 3-5 中列出了所有对比方法的标定结果标准差。从表 3-5 可以发现，RPMU-Net 模型的标定成功率明显高于其他方法，进一步证明了 RPMU-Net 模型在工业浮选过程中的适应性和有效性。此外，从表 3-5 中可以观察到张式标定法和 KFS-WNTD 方法的标定结果标准差相对较高，这可能是由于这两种方法对平面板图像质量波动具有较高的敏感性。相比之下，RPMU-Net 模型在焦距和主点标定的标准差明显低于其他方法，展示了其良好的稳定性。同时，通过比较

中国知网 https://www.cnki.net

没有进行渐进式训练以及进行了渐进式训练的 RPMU-Net 模型，可以发现渐进式训练模块的加入有效降低了焦距和主点的标定标准差，并略微提高了标定成功率。这表明包括预训练和微调在内的渐进训练过程可以有效地提高模型在泡沫浮选场景中的标定稳定性和整体性能。

表 3-5 泡沫浮选过程中失焦相机标定结果对比

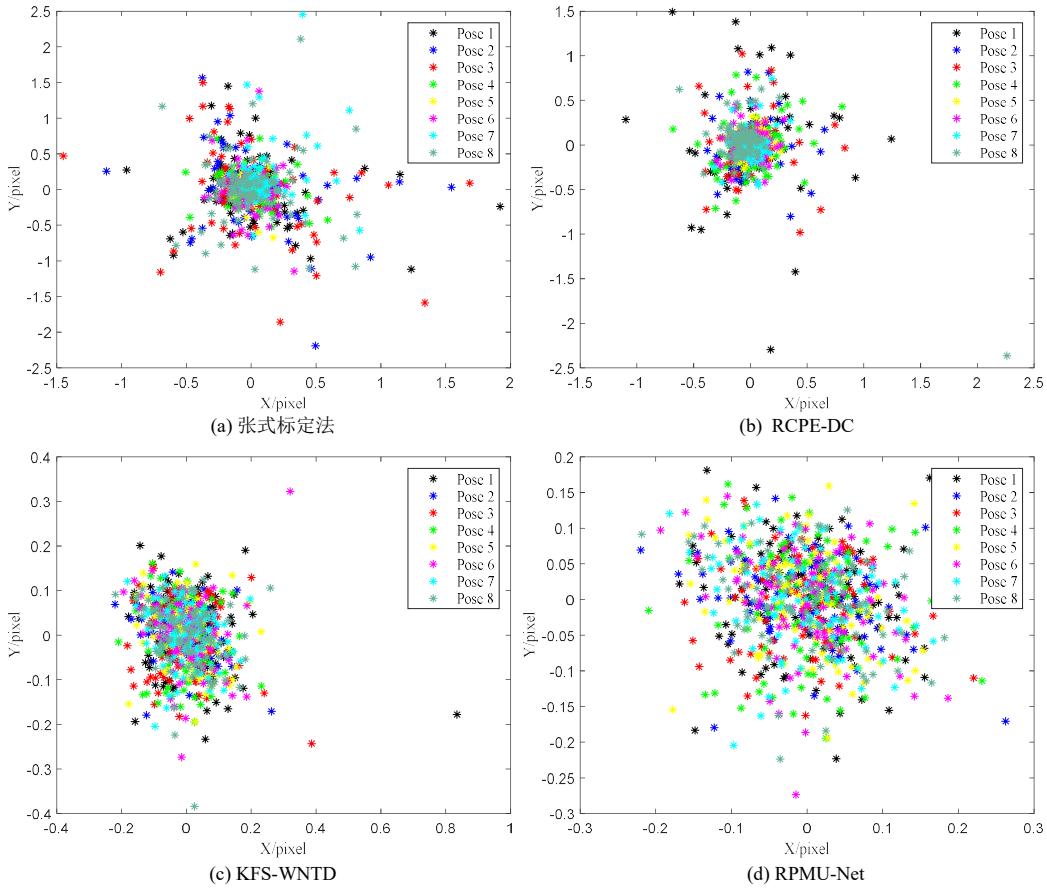
对比模型	参数	标定结果
张式标定法	焦距	(4110.74±**9.285**, 4105.82±**10.376**)
	主点	(698.52±**4.237**, 517.86±**5.014**)
	成功率	0.876
RCPE-DC	焦距	(4112.65±**8.581**, 4098.87±**8.237**)
	主点	(703.34±**4.085**, 531.56±**4.659**)
	成功率	0.914
KFS-WNTD	焦距	(4099.37±**9.074**, 4103.25±**10.523**)
	主点	(691.86±**5.243**, 527.83±**4.827**)
	成功率	0.858
没有进行渐进式训练的 RPMU-Net	焦距	(4107.51±**6.932**,4102.17±**6.793**)
	主点	(689.32±**4.147**,519.45±**3.795**)
	成功率	0.963
进行渐进式训练的 RPMU-Net	焦距	(4104.68±**6.253**, 4096.53±**6.471**)
	主点	(691.29±**3.737**, 522.06±**3.656**)
	成功率	0.969

不同训练数据集对比实验：如上所述，为了增强 RPMU-Net 模型对真实浮选场景的适应性，在训练过程中将真实实验室数据和真实泡沫浮选数据都纳入了预训练和微调阶段。因此，在本小节中，进行了比较实验来验证训练数据集中不同组成部分的效果。本节实验使用了 30 组真实浮选数据进行标定，每组数据包括 8 张泡沫图像，并使用在不同训练数据源下相机标定的平均重投影误差和标准差作为实验指标，实验结果如表 3-6 所示。从表 3-6 中可以观察到，在将真实实验室数据和泡沫数据纳入深度复原神经网络模型训练后，平均重投影误差显著降低，标准差也有所减少，这表明所采用的训练模式能够很好地适应真实泡沫浮选场景。

表 3-6 RPMU-Net 模型训练中不同训练数据集对比实验

合成数据	实验室数据	真实浮选数据	平均重投影误差	标准差
✓	✗	✗	0.092	0.027
✓	✓	✗	0.079	0.020
✓	✗	✓	0.080	0.018
✓	✓	✓	**0.076**	**0.013**

中国知网 https://www.cnki.net



(a) 张式标定法　(b) RCPE-DC

(c) KFS-WNTD　(d) RPMU-Net

图 3-17 浮选过程失焦标定重投影误差分布对比实验

(2) 失焦标定重投影误差对比实验

在本小节实验中，对比了泡沫浮选过程多种方法相机标定的重投影误差，包括张式标定法[157]，RCPE-DC [42]，KFS-WNTD [156]以及 RPMU-Net 模型，实验结果如图 3-17 所示。图 3-17 展示了所有对比方法成功标定的 8 张不同位姿泡沫图像的重投影误差分布。图中点的横纵坐标分别对应于标定结果在 X 方向和 Y 方向上的重投影误差值。从图 3-17 可以发现，张式标定法和 RCPE-DC 方法出现了更高频的异常值，这两种方法的误差主要分布在[-0.3, 0.3]的范围内。此外，与其它方法相比，RPMU-Net 模型的重投影误差相对较小，并且表现出更加均匀的误差分布。

(3) 浮选过程标定鲁棒性对比实验

为了进一步评估 RPMU-Net 模型在真实浮选场景的标定鲁棒性，本节在各种环境变化场景中进行了对比实验。为了更清晰、直观地展示标定性能，本节实验固定使用了一组泡沫图像(共 8 张)，所使用的四种对比方法在该组泡沫图像上所获得的相机内参接近。随后，分别在这组原始泡沫图像上进行了不同的环境变化，包括高斯噪声、失焦模糊、光照强度变化和图像遮挡(所有图像中均遮挡五个

中国知网 https://www.cnki.net

特征点)。此外，在保持相机焦距不变的情况下，改变了相机视点，并分别进行了标定。然后，使用四种标定方法分别对这五种环境变化场景的泡沫数据进行了定性对比实验，实验结果如表 3-7 所示。

表 3-7 浮选过程标定鲁棒性对比实验

环境变化情况	参数	对比模型			
		张式标定法	RCPE-DC	KFS-WNTD	RPMU-Net
原始图像	fx	4107.68	4108.34	4108.65	4108.51
	fy	4102.43	4101.83	4103.25	4102.75
	u_0	698.36	699.75	698.84	698.26
	v_0	516.39	517.27	517.46	516.33
噪声图像 (σ_1=1.1)	fx	4103.73	4106.75	4104.28	4108.23
	fy	4098.59	4102.26	4099.61	4102.55
	u_0	700.18	698.15	698.21	698.74
	v_0	512.27	517.69	514.32	516.89
模糊图像 (σ_2=3)	fx	4095.25	4110.56	4093.94	4109.37
	fy	4093.74	4099.47	4094.72	4103.53
	u_0	684.61	699.26	684.49	698.65
	v_0	531.83	519.35	529.51	517.36
光照强度变化图像 (σ_3=1.1)	fx	4107.22	4108.13	4107.46	4108.42
	fy	4101.59	4100.33	4103.54	4102.29
	u_0	698.84	699.39	698.37	698.46
	v_0	516.17	516.85	517.26	516.15
视点变化图像	fx	4113.76	4105.68	4114.51	4111.74
	fy	4109.28	4106.25	4110.62	4105.28
	u_0	685.82	700.53	688.37	697.56
	v_0	511.75	516.37	514.36	515.19
遮挡图像	fx	4105.24	4104.87	4103.15	4107.63
	fy	4103.73	4098.79	4098.87	4103.35
	u_0	697.47	702.63	701.34	698.71
	v_0	517.65	518.35	514.52	517.16

从表 3-7 中可以发现，与其他几种对比方法相比，RPMU-Net 模型在所有环境变化图像上都显示出最佳的稳定性。值得注意的是，在失焦模糊条件下，张式标定法和 KFS-WNTD 方法的标定结果变化明显。同时，RPMU-Net 模型在视角变化场景中的性能下降比其他场景更为明显，但这种下降仍然在可接受的范围内。总体而言，RPMU-Net 模型在图像噪声、图像模糊和遮挡场景下的标定结果表现出最小的性能退化，显示出稳定的标定性能，表明其在真实浮选场景中对环境变化具有良好的鲁棒性。

(4) RPMU-Net 模型可扩展性及计算效率分析

数据可扩展性和计算效率分析：为了全面评估 RPMU-Net 模型的性能，本节分析了 RPMU-Net 模型在不同数据规模下的数据可扩展性和计算效率。在不同规模数据集下比较了模型训练一个回合所需的计算时间，结果如表 3-8 所示。从表 3-8 可以发现，当采用区块并行计算模块时，训练时间显著减少。值得注意的

中国知网 https://www.cnki.net

是，随着数据集规模的增加，这种效率的提升变得更加明显，这表明 RPMU-Net 模型非常适合大规模数据集。同时，这也说明 RPMU-Net 模型具有良好的数据可扩展性，能有效地平衡标定精度和计算成本。

表 3-8 RPMU-Net 模型数据可扩展性及计算效率分析

数据规模	10^1	10^2	10^3	10^4	10^5
不采用区块并行计算模块的计算时间(s)	2.695	3.467	11.352	93.761	915.716
采用区块并行计算模块的计算时间(s)	1.543	1.972	3.376	15.079	118.763

在其他数据集上的可扩展性分析：由于 RPMU-Net 模型专为圆形平面板图像设计，因此很难直接将其应用于偏好使用棋盘格和非对称网格图案的其他标定场景，这可能在一定程度上限制了 RPMU-Net 模型的可扩展性。但是，可以在 RPMU-Net 模型之前加入一个轻量级的图像识别模块，以识别输入图像中的标定目标类型，然后进行自适应特征提取和去模糊策略。对于其他非圆形标定板图像的数据集，可以使用随机掩码来替代掩码生成模块，以增强所提出方法的可扩展性，但这可能会以牺牲精度为代价。

3.5 本章小结

本章提出了一种基于 RPMU-Net 的浮选过程失焦平面板图像复原方法。首先，给出了 RPMU-Net 模型的设计框架。然后详细描述了 RPMU-Net 模型的实现过程，通过提取原始泡沫图像的感兴趣区域并进行特征块分割，在此基础上进行平面板图像区块并行计算。之后，构建了基于自适应掩码调制的编码解码器模型 MAM-UNet，并设计了基于预训练-微调数据集的渐进式模型训练方案。在此基础上，给出了基于失焦平面板图像复原的浮选过程相机标定步骤。最后，分别在虚拟场景和真实浮选场景进行了对比实验，实验结果表明 RPMU-Net 模型在泡沫浮选过程失焦相机标定中具有良好的性能效果。

中国知网　https://www.cnki.net

第 4 章 基于关键帧提取和位姿加权的工业相机内参标定

在浮选过程中，准确的相机内参标定对于监控和分析泡沫特性至关重要。在进行失焦平面板图像复原的基础上，本章针对浮选过程因操作环境受限、标定板非线性运动、位姿不可控等因素导致的基于泡沫视频进行相机内参标定难的问题，提出基于关键帧提取和位姿加权的浮选过程相机内参标定方法。通过泡沫视频关键帧提取，可以识别出最具信息量的画面，从而提高标定的精度。位姿加权技术可以根据平面板位姿信息给予不同帧权重，从而增强整个标定过程的鲁棒性，以满足工业浮选过程的需求。

4.1 基于关键帧提取和位姿加权的浮选过程相机内参标定框架

根据本文第 2.2.1 节所描述的泡沫浮选过程相机标定环境，可见泡沫层上方没有固定的平台或支架，很难将标定板放置在理想的位置，这给工业相机内参标定带来了以下两个挑战：

(1) 浮选槽表层的矿化泡沫中存在一些腐蚀性化学物质(如强酸、强碱)，这些腐蚀性化学物质限制了标定操作员的操作范围和幅度。在进行相机标定时，所采集的标定视频不可避免地包含一些不完整和失焦的标定图像，这影响了相机标定的准确性。因此，第一个挑战是如何提取左右相机的高质量标定图像对。

(2) 平面板位姿直接影响相机内参标定的结果，同时不同的平面板位姿对相机标定的作用也不同。然而，在泡沫浮选场景下，很难像在实验室中那样捕捉到三个或更多具有合适位姿的平面板标定图像。因此，另一个挑战是如何为相机标定过程选择并加权关键帧图像。

针对以上挑战，本章提出了一种基于关键帧提取和位姿加权的浮选过程工业相机内参标定方法，该方法使用泡沫视频灵活地获取相机参数，不需要使用其他辅助设备，同时考虑了泡沫视频中平面板图像的所有倾斜情况，以恢复尽可能多的畸变和透视参数。基于关键帧提取和位姿加权的浮选过程相机内参标定整体框架如图 4-1 所示。输入包括两个泡沫视频序列：左相机视频序列和右相机视频序列。输出是两个工业相机的内参。整个相机标定过程包括两个部分：基于图像质量评价的泡沫视频关键帧提取和基于加权位姿差异的相机内参计算。

基于图像质量评价的泡沫视频关键帧提取旨在找出对相机内参标定最重要的平面板图像帧序列。首先，对左右相机原始泡沫视频序列进行预处理以获取高质量图像序列，包括去除不完整的平面板图像，并使用本文第三章所述的方法进行失焦平面板图像复原。然后，分别计算每个高质量图像帧中平面板相对于相机平面的倾斜度，以此构建平面板位姿图像质量评价方法。之后，使用平面板位姿

中国知网 https://www.cnki.net

质量评分计算高质量帧序列中每两帧之间的图像质量差异，在此基础上提取泡沫视频关键帧序列。基于图像质量评价的泡沫视频关键帧提取的详细信息请参见本文第 4.2 节。

基于加权位姿差异的相机内参计算主要用于求解最终的相机参数。首先，从上一部分所提取的泡沫视频关键帧中提取多个子图像序列，并计算每个子图像序列的内参权重。然后，分别计算每个子图像序列对应的的相机内参。最后，使用加权参数的综合结果作为最终的相机内参输出。基于加权位姿差异的相机内参计算的详细信息请参见本文第 4.3 节。

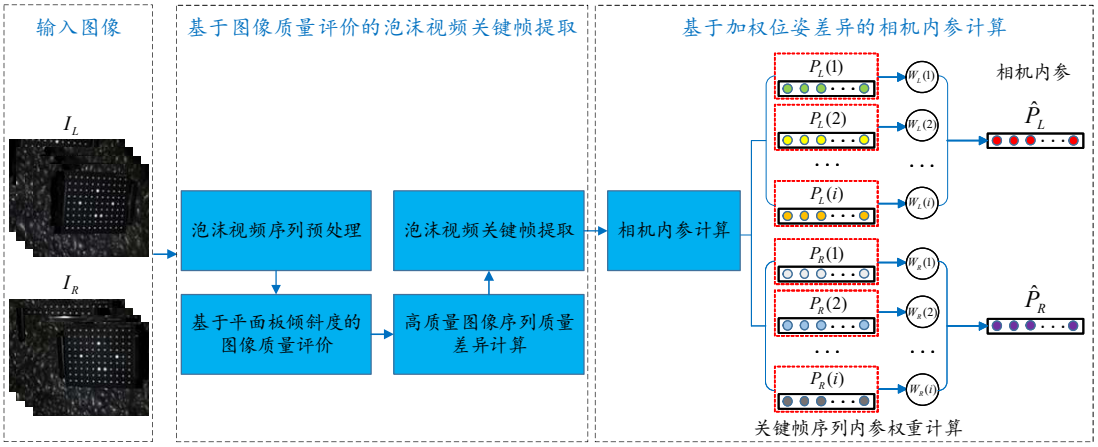


图 4-1 基于关键帧提取和位姿加权的浮选过程相机内参标定整体框架

4.2 基于图像质量评价的泡沫视频关键帧提取

本节详细介绍了基于图像质量评价的泡沫视频关键帧提取过程，具体实施方案如图 4-2 所示。

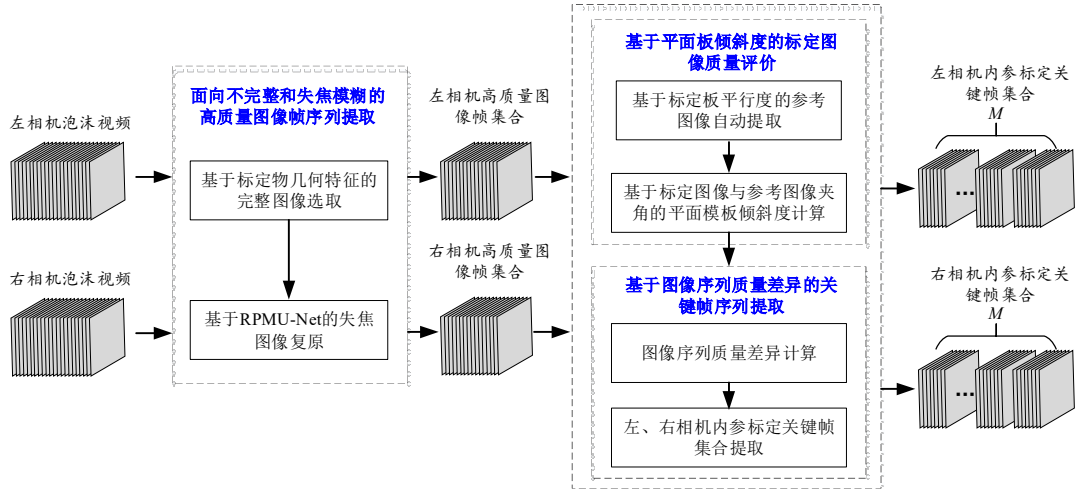


图 4-2 基于图像质量评价的泡沫视频关键帧提取方案

中国知网 https://www.cnki.net

4.2.1 泡沫视频序列预处理

将从左相机泡沫视频和右相机泡沫视频中所采集的图像帧序列分别定义为 S_L 和 S_R。为了获得满意的相机标定结果，需要进行泡沫视频序列预处理，包括去除一些不完整的平面板图像，并对失焦平面板图像进行复原，具体情况如图 4-3 所示。

不完整平面板图像剔除：相机标定算法通常依赖于图像中的特征点来计算相机参数，如果图像中的标定板特征不完整，算法可能无法正确识别或匹配特征点，这可能导致算法不稳定或失败，为了确保标定算法的稳定性，本节首先剔除不完整平面板图像。对于图像帧序列 S_L 和 S_R 中的任意图像 I，使用 *Hough* 圆检测算法在平面板图像上定位圆心，并得到圆心数目，如下所示：

$$N_c(I) = HoughCircle(I) \tag{4-1}$$

式(4-1)中 $N_c(I)$表示所检测到的圆心数目。

由于泡沫浮选过程所采用的平面板有 11*9 个特征圆，若图像中平面板区域不完整，所检测到的中心数将少于 99 个。因此，如图 4-2 所示，对满足条件 $N_c(I)$<99 的不完整平面板图像进行剔除，如下所示：

$$< S_{1L}, S_{1R} >= \underset{I_L = S_L(k),\, I_R = S_R(k)}{\arg} \left(N_c(I_L) = 99 \; and \; N_c(I_R) = 99 \right) \tag{4-2}$$

式(4-2)中 k 表示序列 S_L 和 S_R 中的图像帧序号，<S_{1L},S_{1R}>表示进行不完整平面板图像剔除操作后的左右图像序列集合。

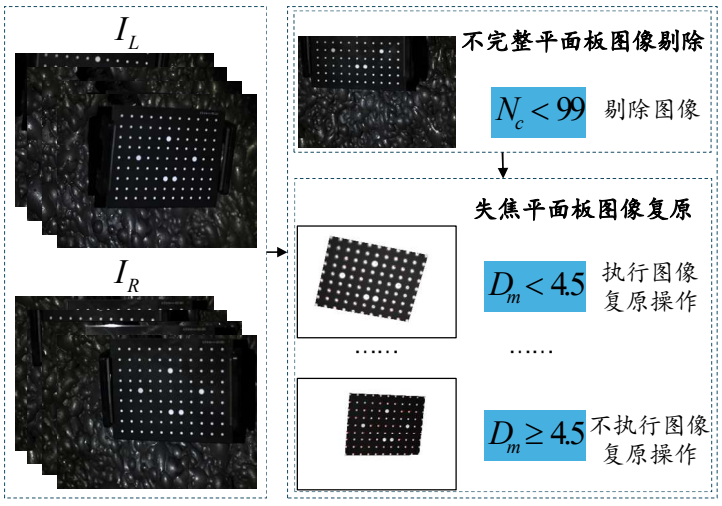


图 4-3 泡沫视频序列预处理

失焦平面板图像复原：为了提高标定精度和稳定性，同时减少误差并优化资源使用，对满足条件的失焦模糊平面板图像进行图像复原操作。在去除不完整平面板图像后，采用累积差分法[190]对平面板图像进行模糊程度评估。首先根据本

中国知网 https://www.cnki.net

文第 3.2.1 节所述的方法进行感兴趣平面板区域分割。然后，通过检测到的平面板图像四个角特征点提取关键特征区域。由于正常拍摄图像的轮廓比失焦图像更清晰，因此可以计算平面板特征区域中每个像素的横向和纵向差异，并使用累积差异来判断图像失焦程度，如下所示：

$$D_m(I) = CDM(ROI(I)) \tag{4-3}$$

式(4-3)中 $CDM(\cdot)$表示累积差分法，$D_m(\cdot)$表示图像 I 中平面板区域的累积差分值。对于满足条件 D_m<4.5 的平面板图像使用本文第 3 章所述的 RPMU-Net 模型执行图像复原操作，最终预处理后所得的高质量图像序列记作<S_{2L},S_{2R}>。

4.2.2 基于平面板倾斜度的图像质量评价方法

近年来，Moru 等人[191]发现平面板的倾斜度会对工业相机的内参标定质量产生较大影响，但是该研究并没有从数学上计算平面板倾斜度。因此，本文提出了一种计算平面板倾斜度的方法，并用于衡量平面板图像的质量，具体细节如下。

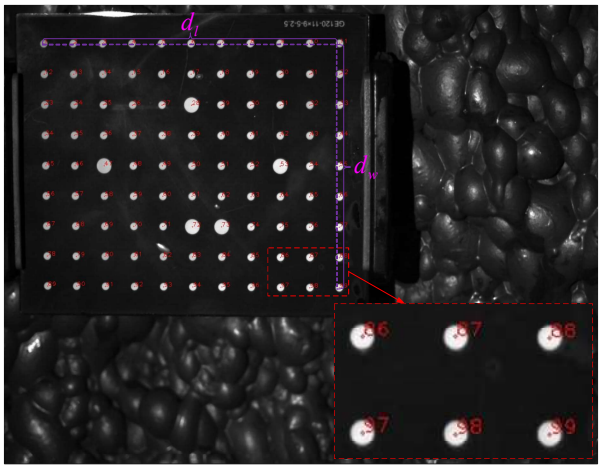


图 4-4 泡沫视频中的图像参考帧

图像参考帧提取：为了计算每帧泡沫图像中的平面板倾斜角度，应尽可能地拍摄与相机平面平行的参考图像，以减少相机畸变。然而，在工业浮选环境中，手工将平面板平行放置是比较困难的。因此，本节提出了一种从泡沫视频中自动提取图像参考帧的方法。图像参考帧提取旨在从所采集的泡沫视频中选取相机成像平面与标定板平行度最高的图像帧。首先，由于图像参考帧应尽可能与相机平面平行，因此参考帧中的感兴趣平面板区域需接近于矩形。然后，分别记感兴趣平面板区域的四条边线为 l_1、l_2、l_3、和 l_4，则可定义每帧泡沫图像中平面板区域的平行度为：

$$p(I) = |k_1| + |k_3| + \left(1/\left(|k_2| + \varepsilon\right)\right) + \left(1/\left(|k_4| + \varepsilon\right)\right) \tag{4-4}$$

中国知网 https://www.cnki.net

式(4-4)中，k_1、k_2、k_3、k_4 分别表示边线 l_1、l_2、l_3、l_4 对应的斜率，ε 是一个给定的微小正数，$p(I)$为图像中平面板区域的平行度。由式(4-4)可知，当图像中平面板区域与相机平面越平行时，$p(I)$越接近于 0。因此，可以通过下式提取图像参考帧，即：

$$I_{REF} = \arg\min_{I \in S_{2L} \cup S_{2R}} (p(I)) \tag{4-5}$$

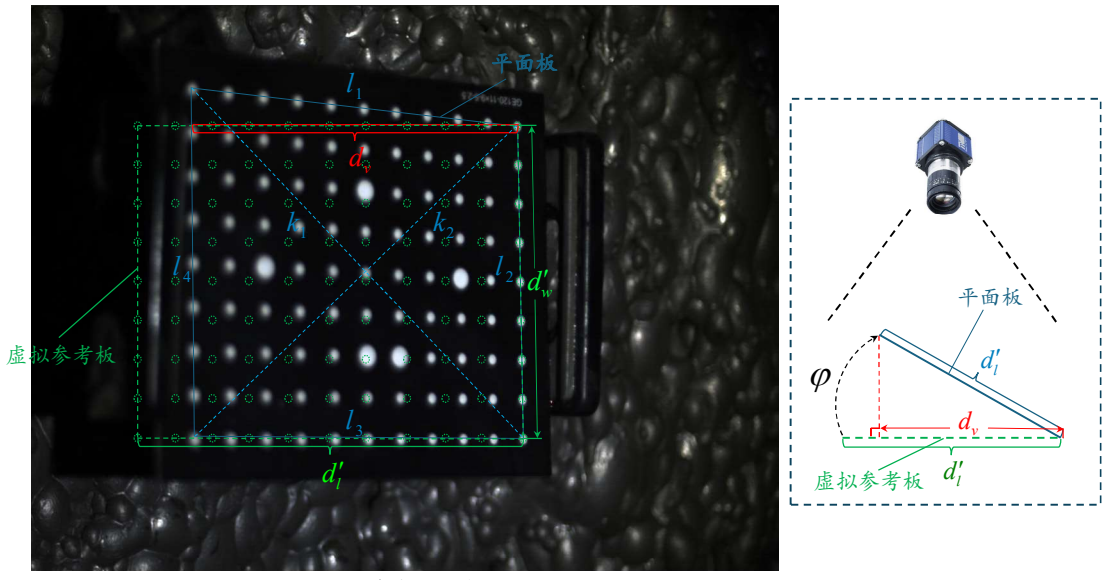
式(4-5)中，$I_{REF} \in S_{2L} \cup S_{2R}$ 表示从预处理所得的高质量图像中所选择的图像参考帧，如图 4-4 所示。

虚拟参考板构建：由于不同泡沫图像中的平面板区域在空间中是不对齐的，因此，为了准确计算平面板倾斜角度，本节通过平移、旋转和缩放图像参考帧 I_{REF} 来构建一个倾斜角度为零的虚拟参考板。如图 4-5 所示，如果平面板是围绕 Y 轴旋转的，则将平面板区域左右边线中较短的一边作为旋转轴。显然，图 4-4 中的平面板旋转轴是右边线。然后，对图像参考帧 I_{REF} 进行缩放和旋转，以确保旋转轴与平面板右边线完全重合。

使用 d_l 和 d_w 分别表示 I_{REF} 的长度和宽度，并用 d'_w 表示平面板的宽度，则虚拟参考板的缩放比例是 d'_w / d_w，虚拟参考板的长度可通过下式计算：

$$d'_l = \frac{d_l * d'_w}{d_w}. \tag{4-6}$$

此外，虚拟参考板的宽度等于旋转轴上的边线长度 d'_w。



(a) 虚拟参考板示意图　　(b) 侧视图

图 4-5 虚拟参考板示意图

平面板倾斜度计算：在泡沫浮选过程的相机内参标定中，平面板倾斜度是通

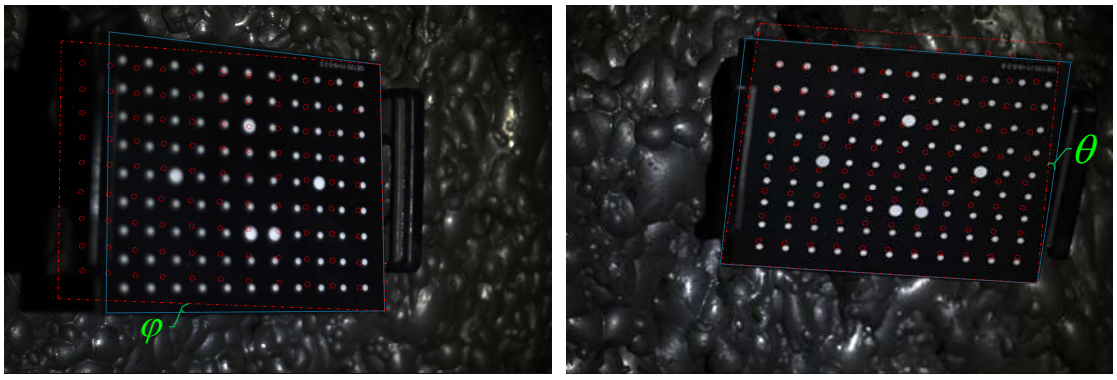
中国知网 https://www.cnki.net

过偏航角、俯仰角和翻滚角来衡量的。这三个角度是描述物体在三维空间中姿态的三个欧拉角，通常用于航空、航天、机器人和计算机视觉等领域。其中，偏航角是绕垂直于地面的轴(通常是物体的垂直轴)进行旋转。当物体的前端向左或向右旋转时，偏航角会相应地增加或减少，但偏航角的变化不影响物体的俯仰或翻滚姿态。俯仰角是绕横向轴(通常是物体的水平轴)进行旋转，当物体的前端向上或向下旋转时，俯仰角会相应地增加或减少，同时俯仰角的变化会影响物体的翻滚姿态，但不直接影响偏航角。翻滚角是绕纵向轴(通常是物体的前后轴)进行旋转，当物体的一侧向上或向下旋转时，翻滚角会相应地增加或减少，翻滚角的变化会影响物体的偏航和俯仰姿态。这三个角的组合可以描述物体在空间中的任何姿态，在相机标定过程中，利用这些角度可以校正图像的倾斜和旋转，以获得准确的标定结果。

在泡沫浮选场景的数据采集过程中，平面板总是位于泡沫层之上。因此，假定平面板没有绕 Z 轴旋转，偏航角总是 0。则平面板倾斜角度主要包括平面板俯仰角 φ 和平面板翻滚角 θ。此外，由于倾斜角度计算采用 ZYX 序列(即先传递围绕 Z 轴旋转的偏航角，再传递围绕 Y 轴旋转的俯仰角，最后传递围绕 X 轴旋转的翻滚角)，因此需先计算平面板俯仰角，再计算平面板翻滚角。根据图 4-4 所示，平面板俯仰角 φ 可通过下式计算：

$$\varphi = \arccos(\frac{d_v}{d_l'}) \tag{4-7}$$

式(4-7)中，d_v 表示的是线段 l_2 和 l_4 之间的距离。



(a) 泡沫图像中的平面板俯仰角　　(b)泡沫图像中的平面板翻滚角

图 4-6 泡沫图像中的平面板俯仰角和翻滚角示意图

在计算完平面板俯仰角之后，需要重建虚拟平面板以计算平面板的翻滚角。平面板翻滚的旋转轴是 X 轴。因此，平面板翻滚角度的计算方法是：

中国知网 https://www.cnki.net

$$\theta = \arccos(\frac{d_s}{d'_w}) \tag{4-8}$$

式(4-8)中，d_s 表示的是线段 l_1 和 l_3 之间的距离。

泡沫图像中的平面板俯仰角 φ 和平面板翻滚角 θ 分别如图 4-6-a 和 4-6-b 所示。在此基础上，通过综合平面板俯仰角与平面板翻滚角来衡量整体平面板倾斜角 ϕ，即：

$$\phi = \varphi + \theta . \tag{4-9}$$

平面板垂直度计算：除了平面板倾斜角度之外，本节还引入了另一个指标来反映整体倾斜程度，即平面板对角线的垂直度。如图 4-6 所示，为了方便评估，使用平面板左侧的 9*9 个特征圆来测量垂直度。

在不考虑图像畸变的情况下，当平面板图像与相机平面平行时，上述 9*9 个特征圆心所包围的区域是一个标准的正方形，即图 4-7 中的对角线(l_{d1} 和 l_{d2})是垂直的。因此，使用垂直度 p 来衡量平面板在平面内的偏转程度：

$$p = \left|1 + k_{d1} * k_{d2}\right| \tag{4-10}$$

式(4-10)中，k_{d1} 和 k_{d2} 分别表示对角线 l_{d1} 和 l_{d2} 的斜率，当平面板与成像平面平行时，垂直度 p 为 0。

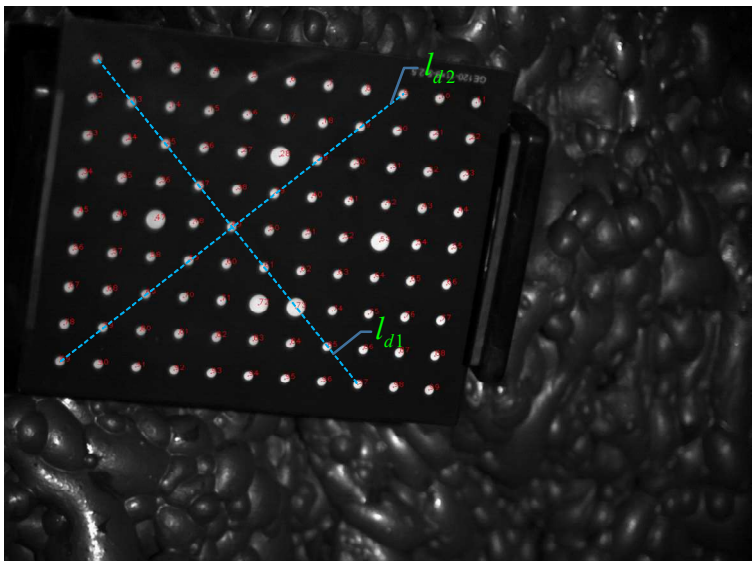


图 4-7 平面板垂直度示意图

图像质量评分计算：平面板倾斜角决定了平面板在三维空间中的倾斜程度，而垂直度则反映了平面板在二维平面上的偏转情况。因此，通过整合平面板倾斜角和垂直度来计算平面板图像的质量评分，即：

中国知网 https://www.cnki.net

$$t(I) = p * \phi \tag{4-11}$$

式(4-11)中，$t(I)$表示的是图像 I 的质量评分。

4.2.3 基于高质量图像序列质量差异的泡沫视频内参关键帧提取

通常情况下，相机内参标定过程需要使用三到十张平面板图像，合适的平面板图像组合可以提高标定性能。在本文第 4.2.1 节提取高质量图像序列 $<S_{2L},S_{2R}>$之后，使用高质量图像序列中的任意平面板图像可满足基本的标定需求。然而，平面板的倾斜度差异对于相机内参标定至关重要，不同组合的平面板图像会带来明显不同的标定结果。在实际的泡沫浮选环境工业相机标定过程中，难以人工识别具有最大差异的图像组。因此，本节使用图像质量评分差异来自动提取平面板图像关键帧组合。

图像质量评分差异计算：对于高质量图像序列 $<S_{2L},S_{2R}>$中的任意两幅平面板图像 I_1 和 I_2，其图像质量评分差异可通过下式计算，即：

$$g(I_1,I_2) = \left| t(I_1) - t(I_2) \right| \tag{4-12}$$

式(4-12)中，$g(I_1,I_2)$表示的是图像 I_1 和 I_2 之间的图像质量评分差异，图像质量评分差异可以准确反映两幅不同图像之间的平面板位姿差异。

图像序列质量差异计算：在 Moru 的研究中[191]，当平面板图像的数量为 8 时，相机标定性能最好。因此，本文使用 8 幅平面板图像构成的图像序列组合进行标定操作。记 n 为高质量图像序列 $<S_{2L},S_{2R}>$中的图像对总数，则对于每个相机共可随机产生 $N_{IS}=C_n^8$ 个图像序列组合。对于任意图像序列组合 S，该图像序列组合内所有图像的整体质量差异可通过下式计算，即：

$$h(S) = \sum_{i=1}^{7}\sum_{j=i+1}^{8} g(I_i,I_j), \left(S = \{I_1,...,I_k,...,I_8\} \right) \tag{4-13}$$

式(4-13)中，I_k(k=1,…,8)表示图像序列组合 S 中的第 k 张图像。

泡沫视频内参关键帧提取：为了提升标定性能，图像序列质量差异值越大越好。同时，为了提升相机内参标定的鲁棒性，本文选择图像序列质量差异值最大的 M 组图像序列组合进行标定操作，并集成每个图像序列组合的内参标定结果作为最终输出。综上，可以分别从图像序列组集合Ω_L和Ω_R中提取左右相机的泡沫视频关键帧序列 S_{3L} 和 S_{3R}，即：

$$S_{3L} = \arg\max_{S_L \in \Omega_L} \left(h(S_L), M \right) \tag{4-14}$$

$$S_{3R} = \arg\max_{S_R \in \Omega_R} \left(h(S_R), M \right) \tag{4-15}$$

式(4-14)和式(4-15)中，集合Ω_L和Ω_R中分别有 $N_{IS}=C_n^8$ 个图像序列组合，其中部

中国知网　https://www.cnki.net

分关键帧图像序列组合示意图如图 4-8 所示。



图 4-8 部分关键帧图像序列组合示意图

4.3 基于加权位姿差异的相机内参计算

本节详细介绍了基于加权位姿关键帧序列的相机内参计算方案，具体实施方案如图 4-9 所示。

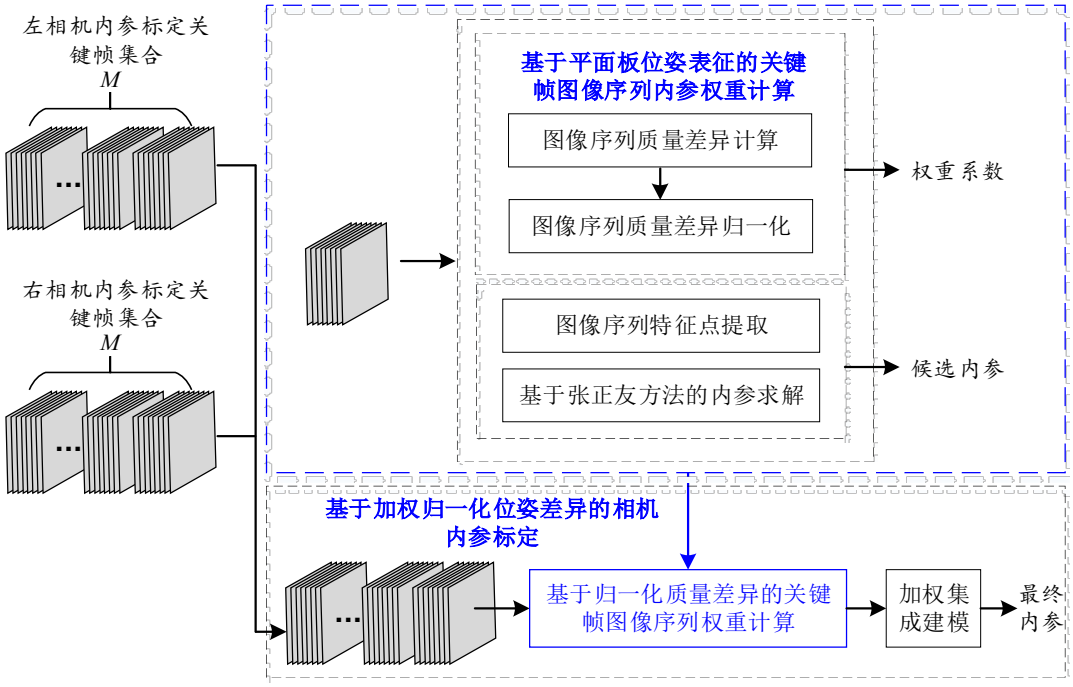


图 4-9 部分关键帧图像序列组合示意图

中国知网 https://www.cnki.net

4.3.1 基于平面板位姿表征的关键帧图像序列内参权重计算

在提取了泡沫视频关键帧后，本节使用左右相机的关键帧序列及其对应的位姿权重来求解最终的相机内参。首先，将每组关键帧序列的质量差异记作 $h(k),(k=1,...,M)$，则归一化的质量差异可以定义为：

$$\bar{h}(k)=\frac{h(k)-h_{\min}}{h_{\max}-h_{\min}} \tag{4-16}$$

式(4-16)中，$\bar{h}(k)$ 表示归一化的质量差异，$h_{\min}$ 和 $h_{\max}$ 分别表示 M 组关键帧序列质量差异的最小值和最大值。

然后，对于关键帧序列中的每一个图像序列组合，引入一个位姿权重，并通过归一化质量差异来表示，即：

$$W_k=\frac{\bar{h}(k)}{\sum_k \bar{h}(k)}. \tag{4-17}$$

式(4-17)中，W 表示的是所求的关键帧图像序列内参权重。

4.3.2 基于加权归一化位姿差异的相机内参标定

将泡沫视频关键帧序列 S_{3L} 和 S_{3R} 中的图像序列组合表示为 $\hat{I}_3(i),(i=1,\ldots,M)$，则每个图像序列组合的初始内参矩阵可由下式求得，即：

$$P_i=[A(i),dt(i)]=f_{Zhang}(\hat{I}_3(i)) \tag{4-18}$$

式(4-18)中，$A(\cdot)$表示内参矩阵，$dt(\cdot)$表示畸变参数，$f_{Zhang}(\cdot)$表示张正友标定法。

根据式(4-17)，可以计算每个组合的图像序列内参权重，即：

$$W_i=\frac{\bar{h}_3(i)}{\sum_i \bar{h}_3(i)}. \tag{4-19}$$

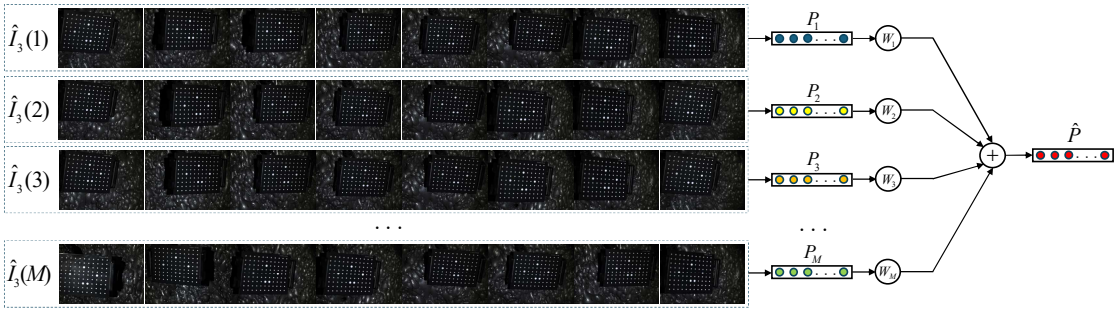


图 4-10 基于加权归一化位姿差异的相机内参计算

基于加权归一化位姿差异的相机内参计算方法如图 4-10 所示，图 4-10 左侧即多组关键帧图像序列组合。其中，在融入位姿差异权重后的最终相机内参矩阵

中国知网 https://www.cnki.net

可由下式求得，即：

$$\hat{P} = \sum_i P_i \cdot W_i \,. \tag{4-20}$$

4.4 基于关键帧提取和位姿加权的相机内参标定效果验证

4.4.1 相机标定数据集及性能评估指标

为了更全面的评估基于关键帧提取和位姿加权的相机内参标定方法的性能，分别在虚拟数据集和真实泡沫浮选数据集上进行了对比实验。因此，所使用的内参标定数据集包括虚拟数据集和真实泡沫浮选数据集。

内参标定虚拟数据集：为了模拟真实浮选环境的相机内参标定过程，首先在平面板上以 10 毫米的等距离设置了 99 个特征点作为参考标定物。这些模拟点的 Z 轴坐标为零，X 轴和 Y 轴的特征点坐标分布如图 4-11 所示。然后，通过对参考标定物执行旋转和平移操作生成一系列标定目标。其中，绕 X 轴和 Y 轴的旋转角度在[0°,40°]范围内变化，步长设置为 20°，绕 Z 轴的旋转角度固定设置为 30°。沿 X 轴和 Y 轴的平移在[0,40]像素范围内变化，步长为 20，沿 Z 轴的平移固定设置为 120。因此，总共可以生成 $2^3*2^3=64$ 个虚拟标定目标。之后，为方便实验对比，设置了一组固定的相机参数作为真实值，如表 4-1 所示。然后在所有的标定目标上实施摄影仿射变换，最终可分别生成 64 张左相机图像和 64 张右相机图像，图像分辨率设定为 640*480 像素。这些左右相机平面板图像构成了后续标定操作的输入，输出是对应的相机参数。

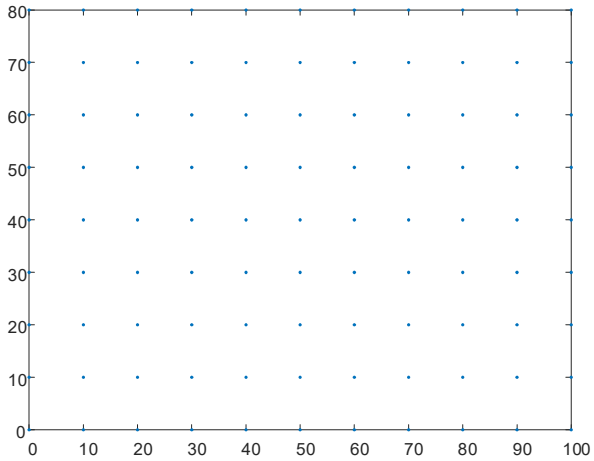


图 4-11 X 轴和 Y 轴的特征点坐标分布

内参标定真实数据集：本实验中的所有真实数据都是从中国南方的一个铅锌浮选厂采集的，在一个锌快粗选槽顶部安装了一套双目视觉系统，如本文第 2.2.1 节所示。该系统主要包括一个工业光源、一台工业计算机和两台相同的工业相机

中国知网 https://www.cnki.net

(左相机和右相机均为 Manta G-145C)。相机的帧率设定为 30 帧每秒(FPS)。同时，选择了一个带有 99 个均匀分布圆圈的平面板作为标定物，平面板的尺寸为 102.5*82.5 毫米，特征点水平和垂直方向的中心间距均为 10 毫米。然后，分别使用两个相机捕获平面板视频，并将视频保存为连续图像序列，图像分辨率为 1388*1038 像素。

表 4-1 虚拟数据集测试图像的真实值

内参矩阵真实值	$A=\begin{bmatrix}500 & 0 & 320\\ 0 & 500 & 240\\ 0 & 0 & 1\end{bmatrix}$
旋转、位移向量真实值	$R=[\pi/6 \quad \pi/6 \quad \pi/9]$ $T=[50 \quad -20 \quad 20]$

性能评估指标：由于虚拟数据集有真实值，因此和本文第 3 章类似，使用估计值和真实值之间的差异作为在虚拟数据集上进行对比实验的性能评估指标，具体公式请参见式(3-21)至(3-23)。此外，由于真实浮选数据集没有真实值可参考，因此使用重投影误差和双目相机的点云重构误差作为性能评估指标。其中，重投影误差的计算方法见式(3-24)。

4.4.2 基于关键帧提取和位姿加权的相机内参标定方法消融实验

本节对基于关键帧提取和位姿加权的相机内参标定方法进行了消融实验，包括关键帧提取的有效性验证和平面板图像位姿加权的有效性验证。本节实验采用所有特征点的点云重构误差平均值作为性能评估指标。

关键帧提取的有效性验证：本节实验对基于图像质量评价的泡沫视频关键帧提取模块的有效性进行了评估。在按本文第 4.2.1 节的方法对泡沫视频进行预处理操作后，不进行后续的关键帧提取操作，而是随机选取其中的任意 8 帧图像组合进行相机标定操作。同时，在本组实验中仍保留基于加权位姿差异的相机内参计算模块，即使用每个子序列的图像质量差异来计算最终的相机参数。然后，使用在上述操作下所求的相机参数对一组选定的左右图像对重建特征点坐标，并计算所有特征点的平均点云重构误差，如表 4-2 第一行所示。此外，表 4-2 第三行给出了使用完整基于关键帧提取和位姿加权的相机内参标定方法所求得的相机参数之后，进行特征点重建的平均点云重构误差。从表 4-2 可以发现，当关键帧提取模块被禁用(标记为✗)时，平均点云重构误差为 1.088 毫米。而当关键帧提取模块被启用(标记为✓)时，平均点云重构误差降低了 0.347 毫米，这表明关键帧提取模块对于工业相机标定具有积极作用。

中国知网 https://www.cnki.net

表 4-2 基于关键帧提取和位姿加权的相机内参标定方法消融实验

关键帧提取模块	平面板图像位姿加权模块	平均点云重构误差/mm
✗	✓	1.088
✓	✗	1.256
✓	✓	0.741

平面板图像位姿加权的有效性验证：本节实验对基于加权位姿差异的相机内参计算中所描述的平面板图像位姿加权模块的有效性进行了评估。首先，按照本文第 4.2 节的描述提取了泡沫视频关键帧图像序列。然后不执行平面板图像位姿加权模块，而是选择其中具有最大质量差异的图像序列组合来计算相机参数，并使用该情况下所求得的相机参数来重建左右图像的特征点并计算平均点云重构误差，实验结果如表 4-2 的第二行所示。从表 4-2 可以发现，当平面板图像位姿加权模块被禁用且仅关键帧提取模块被启用时，平均点云重构误差为 1.256 毫米，这比仅禁用关键帧提取模块而启用平面板图像位姿加权模块时的误差要高。这主要是因为位姿加权模块考虑了多种平面板姿态，并有效融合了不同位姿的图像信息。此外，当位姿加权模块与关键帧提取模块同时启用时，平均点云重构误差显著降低至 0.741 毫米。这表明位姿加权模块在关键帧提取模块的配合下，两个模块的结合可以产生协同效应，进而提高相机标定的准确性。

消融实验结果表明，关键帧提取模块和平面板图像位姿加权模块对于提高相机内参标定的准确性都是有效的。特别是当两个模块同时使用时，可以显著降低点云重构的平均误差，从而提高整体标定性能。

4.4.3 相机标定虚拟仿真实验

本节分别在无噪声和有噪声的虚拟数据集上进行了仿真对比实验，所使用的对比方法包括张氏标定法[157]，CFS-CC[159]以及本文所提的基于关键帧提取和位姿加权的相机标定方法。

无噪声数据集虚拟仿真实验：在无噪声和任何畸变的虚拟合成数据集上，分别使用所提出的方法、张氏标定法[157]和 CFS-CC [159]来计算相机参数。需要注意的是，使用张氏标定法进行相机标定时所使用的合成图像是从虚拟数据集随机选取的，共使用了 8 帧图像。由于所提出的方法需要进行位姿分析和关键帧选取，因此使用了所有的无噪声虚拟数据，其中外参标定时使用的是具有最大质量差异的图像序列组合。此外，为了避免随机性，本节实验使用 30 次标定结果的平均值作为最终参数输出。三种比较方法的标定结果如表 4-3 所示。从表 4-3 可以发现，所有对比方法都取得了良好的性能。因为在合成数据集中没有噪声且无任何

中国知网 https://www.cnki.net

畸变，因此在这种理想环境下几种方法均能成功求解相机参数。

表 4-3 无噪声数据集上的虚拟仿真实验结果

参数	张氏标定法	CFS-CC	所提方法
ΔA	0	0	0
ΔR	0.027	0	0
ΔT	0.016	0	0

有噪声数据集虚拟仿真实验：为了综合评估不同方法的噪声鲁棒性，本节实验在原始合成数据集的图像特征点上加入了均值为 0、标准差为σ的高斯噪声，该噪声直接添加至特征点坐标上。然后以 0.2 像素的间隔将σ从 0 到 1 像素逐级变化，并分别获取不同噪声级别下的退化数据集。然后，分别在不同程度噪声的合成数据集上使用张氏标定法，CFS-CC 方法以及本文所提出的方法进行标定操作，并取不同噪声合成数据集的标定结果平均值作为最终输出。在整个实验过程中，相机焦距保持固定，所得三种对比方法的标定结果如图 4-12 所示。从图 4-12 可以发现，所提基于关键帧提取和位姿加权的相机标定方法在不同噪声水平下都能获得较好的标定精度。当噪声为 0 时，三种方法的所有参数标定误差几乎接近，但是随着数据集中噪声强度的增加，所有方法的标定误差都有所增加，特别是当噪声强度大于 0.6 之后，张氏标定法标定误差快速上升，CFS-CC 方法的标定结果也存在一定程度的退化。相比之下，所提方法的误差增长速度比其他两种方法相对更慢，表明其在噪声环境下的鲁棒性更好。以单个场景为例进行横向比较，例如当$\sigma=1$的时候，与其他两种标定方法相比，本文所提方法的内参差值相对减小了至少 27.16%，旋转矩阵差值相对减小了至少 17.36%，平移矩阵差值相对减小了至少 22.92%。上述实验结果表明，所提方法展现了良好的标定性能。

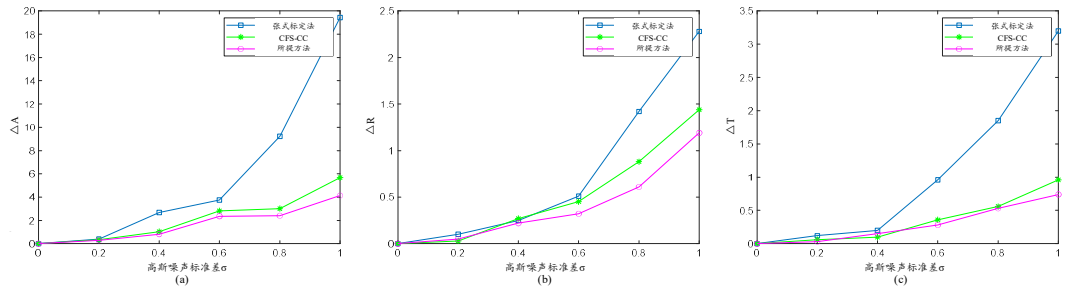


图 4-12 有噪声数据集上的虚拟仿真实验结果

4.4.4 相机标定工业应用实验

为了深入评估所提基于关键帧提取和位姿加权的相机内参标定方法在实际

中国知网 https://www.cnki.net

工业过程中的运行性能，本节在真实泡沫浮选过程中对比了多种不同标定方法。所使用的平面板视频数据是在锌快粗选使用左右相机同步收集的，其中每个视频的采样时间为一分钟。

由于真实泡沫浮选场景中没有工业相机的真实参数值，因此本节选择比较不同方法的重投影误差、同一姿态下的点云重构误差以及不同姿态下的点云重构误差。此外，灵活性是工业相机标定方法的一个重要特性，标定方法应具备一定的灵活性，能够适应不同的标定需求和场景，提供多样化的标定模式和参数设置。在泡沫浮选等工业应用中，这种灵活性尤为重要，因为良好的灵活性可以确保相机标定过程能够适应现场的具体条件，从而提高整个浮选过程相机标定的自动化程度和效率。因此，本节评估了多个先进模型的应用范围及灵活性。

本节实验将所提出的方法与一些流行的相机标定方法进行了比较，包括张氏标定法[157]，NDCC[158]和 CFS-CC[159]。其中，张氏标定法和 NDCC 方法中所使用的平面板图像是从泡沫视频中随机选取的。在本节实验中，关键帧图像序列组合的数量 M 设置为 50。为了进行公平比较，使用执行 30 次标定的结果平均值作为最终输出，具体细节如下。

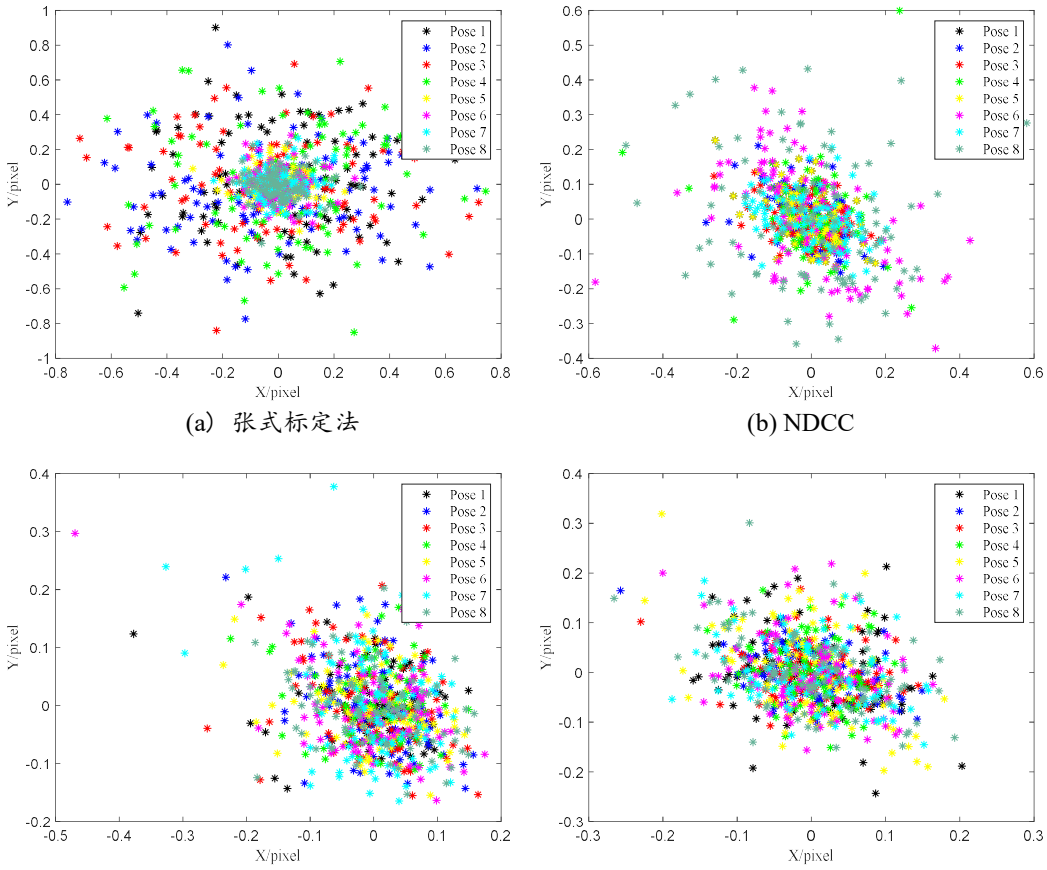
泡沫图像重投影误差对比：本小节实验使用重投影误差来评估相机标定精度，重投影误差的预估用于判断标定的精确性和可靠性，通过比较真实的三维点在图像中的投影位置与标定模型计算出的投影位置之间的差异，来衡量标定的准确性。通过随机选择一组泡沫图像序列，然后计算 8 帧不同姿态平面板图像的重投影误差分布。所使用的对比方法包括张氏标定法，NDCC 方法和 CFS-CC 方法，最终实验结果如图 4-13 所示。

从图 4-13 可以发现，张氏标定法和 NDCC 方法在 X 和 Y 方向上的大部分特征点重投影误差分布在[-0.3,0.3]范围内，CFS-CC 方法和本文提出的方法的大部分特征点重投影误差分布在[-0.1,0.1]范围内。这表明所提方法相机标定的准确性越高，相机模型能够更好地描述相机图像空间和三维空间的关系。也就是标定过程中的计算误差和图像测量误差较小，从而使得标定后的相机参数更加精确。此外，和 CFS-CC 方法相比，所提方法的重投影误差较小且分布更均匀，这表明误差没有在特定方向或特定点上出现集中，这可能意味着标定模型能够较好地描述相机的成像特性。同时，均匀分布的误差表明所提标定算法能够一致地处理所有特征点，没有出现明显的系统性偏差，即没有对某些特定点或特定条件下的点产生过大的偏差，体现了所提算法具有良好的稳定性，这有助于提高标定后相机模型在实际应用中的性能。

同时，为了分析使用本文第三章所提的图像复原方法对本章所提方法的贡献，分别在使用图像复原方法和没使用图像复原方法的情况下进行了对比实验。在没

中国知网　https://www.cnki.net

有使用图像复原方法的情况下，所有图像的平均重投影误差为 0.13 像素，使用了图像复原方法之后的平均重投影误差为 0.081 像素，相对降低了 37.69%，表明在泡沫浮选场景的相机标定过程中，同时使用本文第三章和第四章的方法可以产生协同效应，从而提升整体标定性能。



(a) 张式标定法　(b) NDCC

(c) CFS-CC　(d) 所提方法

图 4-13 在泡沫图像上的重投影误差对比

泡沫图像同一姿态下的点云重构误差对比：左右图像特征点重构坐标之间的距离可以有效地反映系统的标定精度。因此，本小节分别使用几种对比方法来重构同一姿态下左右图像上的特征点。其中，本章所提的方法对一组左右相机平面板图像的点云重构结果如图 4-14 所示。从图 4-14 可以发现，左右相机重构点云展现了良好的重合程度。这表明根据相机参数重建的左右相机特征点在三维空间中非常接近，点云重构误差较小，展现了所提方法良好的准确性和可靠性。同时，点云重构误差较小时，说明内外参数之间的匹配程度较高，能够较好地实现三维重建。

此外，由于双目相机设备硬件差异和计算误差，左右相机的重构点云并不能完全重合。因此，本节选择左右图像重构点云之间的距离进行误差分析，并进行

中国知网 https://www.cnki.net

了对比实验。所有对比方法的点云重构误差分布情况如图 4-15 所示。从图 4-15 可以发现，本章所提出方法的点云重构误差分布完全集中在(0,2)之间，且主要分区在(0,1)范围内。相比之下，张氏标定法和 NDCC 方法的点云重构误差分布均匀性较差，范围较广。CFS-CC 方法的点云重构误差整体分布在较低的误差范围内，但是所提出方法的点云重构误差相对较小且更加集中。

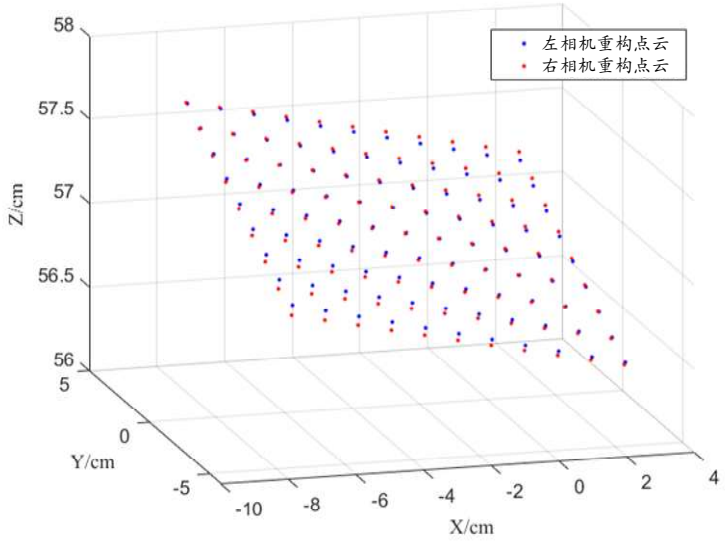


图 4-14 在左右图像同一姿态下的点云重构情况

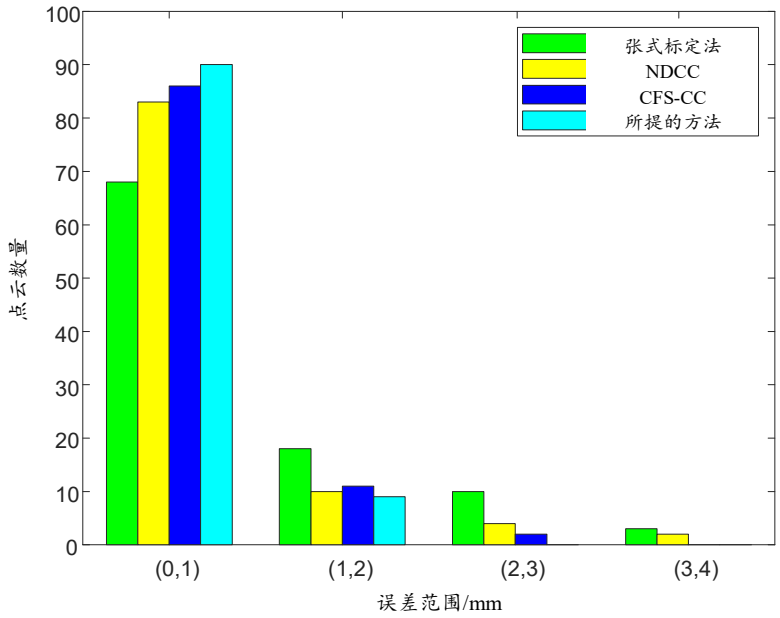


图 4-15 不同对比方法的点云重构误差分布

泡沫图像不同姿态下的点云重构误差对比：本小节实验对比了不同标定方法

中国知网 https://www.cnki.net

在 8 个不同位姿平面板图像的点云重构误差分布情况，并计算了每个位姿图像下的误差均方根值(RMS)，最终结果展示在表 4-4 中。根据表 4-4，可以发现所提出的方法在不同姿态下具有最佳的点云重构性能。与其他几种对比方法相比，所提方法的平均点云重构误差至少降低了 23.31%。同时，在所有位姿中，NDCC 方法和所提方法的点云重构误差普遍低于其他两种方法，表明这两种方法所得的相机参数匹配度更高。而所提方法在大多数位姿下的点云重构误差是最低的，尤其是在位姿 2、位姿 5 和位姿 7 中。张氏标定法在所有位姿下的误差普遍较高，尤其是在位姿 3 中，误差达到了 1.622，这可能表明该方法在某些姿态下的标定性能不佳。虽然 CFS-CC 方法在某些位姿(如位姿 4 和位姿 6)下的表现接近所提方法，但在其他位姿下(如位姿 3 和位姿 8)的误差较大。

此外，张氏标定法，NDCC 方法，CFS-CC 方法以及所提出的方法在不同姿态图像下的均方根值的标准差分别为 0.0719、0.0282、0.0415 和 0.0187。其中所提方法的标准差最小，这可能是因为所提出的方法在相机内参计算过程中加权综合了多种位姿情况，考虑了更多样的平面板位姿变化，使得其对不同姿态图像的适应性更强。

表 4-4 泡沫图像不同姿态下的点云重构误差对比结果

平面板位姿	张氏标定法	NDCC	CFS-CC	所提方法
位姿 1	1.465	0.988	0.997	0.723
位姿 2	1.384	0.963	1.038	0.719
位姿 3	1.622	0.989	1.102	0.769
位姿 4	1.436	1.024	0.988	0.746
位姿 5	1.397	0.946	1.082	0.771
位姿 6	1.452	0.951	1.049	0.749
位姿 7	1.533	0.929	0.993	0.728
位姿 8	1.470	0.981	1.076	0.754

应用范围及灵活性对比：当前主流的许多相机内参标定方法经常需要各种辅助标定设备，如相机固定平台、激光投影仪、平面板和可控的相机移动平台(包括相机平移和旋转等)。这些辅助设备显著影响了标定算法的灵活性，并限制了其在复杂环境或实际工业场景(例如泡沫浮选过程)中的应用。

因此，本小节比较了一些主流相机标定方法所需使用的辅助标定设备，如表 4-5 所示。从表 4-5 可以发现，张氏标定法，NDCC 方法，CFS-CC 方法和所提出的方法所需要的辅助设备较少，均只需使用平面板即可进行相机标定操作，展现了比其他方法更灵活的特性。综上所述，从标定精度和应用范围的整体情况来看，所提方法具有最佳的工业应用表现。

中国知网　https://www.cnki.net

表 4-5 不同标定方法的灵活性比较

对比方法	相机固定平台	激光投影仪	相机移动	平面板
Xu 的方法[137]	√	×	√	√
Faraji 的方法[136]	√	×	√	×
OAD-NS[152]	√	×	√	√
SOM[146]	√	×	√	√
Sapienza 的方法[192]	√	×	√	×
张氏标定法[157]	×	×	×	√
NDCC[158]	×	×	×	√
CFS-CC[159]	×	×	×	√
Huang 的方法[174]	×	×	√	√
Kolecki 的方法[155]	×	√	×	√
Usamentiaga 的方法[175]	√	×	√	√
Heinze 的方法[160]	×	√	√	×
Basso 的方法[161]	×	√	×	√
所提方法	×	×	×	√

4.5 本章小结

本章提出了一种基于关键帧提取和位姿加权的浮选过程相机内参标定方法。首先，针对浮选过程相机内参标定的挑战，给出了基于关键帧提取和位姿加权的浮选过程相机内参标定框架。然后详细描述了基于图像质量评价的泡沫视频关键帧提取过程，在进行泡沫视频序列预处理的基础上，设计基于平面板倾斜度的图像质量评价方法，并基于该方法提取泡沫视频关键帧。之后，提出了基于平面板位姿表征的关键帧图像序列内参权重计算方法，以此加权求解泡沫浮选过程的相机内参。最后，分别在虚拟场景和真实浮选场景进行了对比实验，实验结果表明基于关键帧提取和位姿加权的浮选过程相机内参标定方法在泡沫浮选环境下展现了良好的性能效果。

中国知网 https://www.cnki.net

第 5 章 基于闭环混合优化的双目特征点同步校正

在泡沫浮选过程中，环境因素如光照、温度、湿度等可能对相机的拍摄效果产生影响。这些因素会导致左右相机拍摄到的图像存在成像时间差异，从而影响特征点的识别和匹配，进而影响后续的双目相机外参标定。因此，本章针对因浮选过程复杂外部光源环境及硬件差异而导致的双目相机成像时间异步的问题，提出基于闭环混合优化的双目特征点同步校正方法。通过特征点校正，可以减少这种相机不同步带来的时间偏差，确保左右图像在时间和空间上的一致性，提高双目相机外参标定的准确性。

5.1 基于闭环混合优化的双目相机特征点同步校正方案

由于工业浮选现场复杂外部光源的影响(包括阳光、灯光、手电筒等光源)，泡沫表层区域可能存在局部阴影。另外，为了扩大左右视图的共同视域，左右相机的朝向设置有较大区别，导致双目相机之间的光照程度存在显著差异。因此，如本文第 2.2.2 节所述，为了使捕获的双目图像亮度尽可能接近，需要为双目相机设置不同的曝光时间。不可避免地，双目相机之间会有一些硬件(例如控制器、工业开关和工业相机)和软件延迟(例如复杂光照环境导致的双目相机曝光时间不同)。这些延迟可能导致左右相机拍摄不同步，使得左右图像不匹配，影响相机标定结果。

为了解决左右图像不匹配的问题，目前的研究主要采用三次插值和最小二乘法进行数据同步，或者构建双目相机启动时间误差与移动物体坐标偏移之间的几何模型，然后通过等间隔采样来估计启动间隔。然而，这些方法没有考虑平面板的非线性运动和小范围内成像延迟的波动，而且在等间隔采样匹配点时容易陷入局部最优。因此，针对浮选过程复杂外部光源环境及硬件差异而导致的双目相机成像时间异步的问题，本章提出了一种基于初始延迟估计和闭环混合优化的特征点同步优化方法，该方法采用差分进化算法和希尔爬升算法等智能优化方法对相邻帧特征点坐标值进行闭环优化求解，解决因相机硬件不同步、曝光时间不同等造成的双目相机左右视图获取不同步问题，可以用作工业双目相机标定过程中运动目标的端到端异步校正工具。

基于闭环混合优化的双目相机特征点同步校正旨在通过一定的约束关系，在双目相机关键帧序列上获取准确、可靠的标记点，对图像坐标系和世界坐标系之间的关系进行表征。具体实施方案如图 5-1 所示。主要包括两部分内容，即基于双目时序分析的浮选过程双目相机初始延时估计和基于闭环混合优化的双目相机特征点同步校正。其中，基于双目时序分析的浮选过程双目相机初始延时估计

中国知网 https://www.cnki.net

通过分析浮选过程双目相机的时间序列模型，使用经验知识和设备机理自适应估计左右相机的初始同步延时，并根据该时间差获取与左相机图像帧同步的右相机图像帧特征点初始坐标，以最小化硬件差异的影响，加快模型的收敛速度。双目相机特征点同步校正模块通过融合希尔爬升和差分进化算法构建混合优化模型，在约束时间范围内对同步时间差进行闭环全局寻优。同时引入了一种改进的突变策略来提高优化模型的准确性和全局搜索功能，使得采用左、右相机同步匹配后特征点的复合标定误差最佳。此外，该部分使用一种闭环优化策略来管理双目相机特有的非线性延迟变化，从而增强了模型的鲁棒性。最后，根据最佳的同步时间差，求解与左相机每个图像帧同步匹配的右相机图像帧特征点坐标。

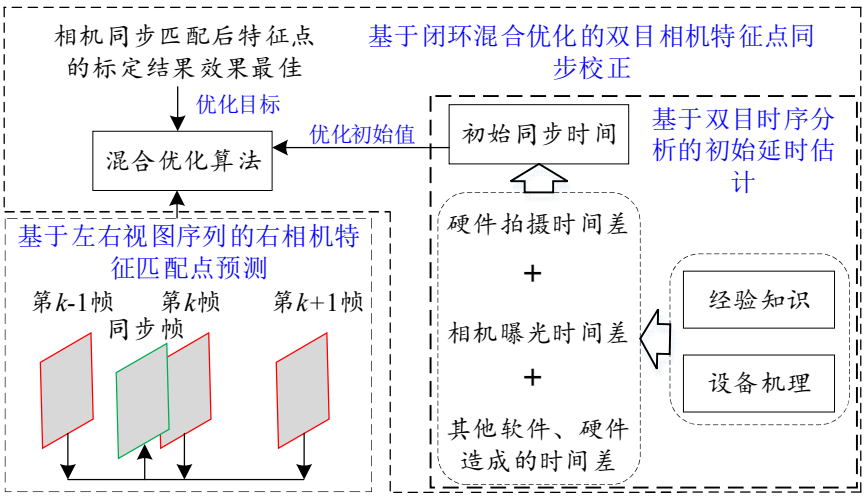


图 5-1 基于闭环混合优化的双目相机特征点同步校正方案

5.2 基于双目时序分析的浮选过程双目相机初始延时估计

5.2.1 浮选过程双目图像外参关键帧提取

为了提高双目相机同步标定的质量，首先使用本文第 4 章所述的图像质量评价方法从输入的双目泡沫视频中提取外参关键帧。双目相机的外参需使用匹配的左右图像对进行标定计算，即需要一组左右视图均为 8 帧的匹配图像序列。对于包含 N_{IS} 个匹配图像序列的泡沫图像集合，使用公式(4-13)计算其中每一个匹配图像序列的质量差异。具体而言，对于输入的左右相机视频序列 I_L 和 I_R，通过在匹配帧序列上搜索所有图像序列质量差异的最大值来提取外参关键帧，即：

$$\{\hat{I}_L^i,\hat{I}_R^i\}=\underset{I_L=\Omega_L(l),I_R=\Omega_R(l)}{\arg\max}\left(h(I_L)+h(I_R)\right) \tag{5-1}$$

式(5-1)中，$\{\hat{I}_L^i,\hat{I}_R^i\},(i=1,2,...,8.)$ 表示的是所提取的左右视图外参关键帧，l 为图像序列组 Ω_L 和 Ω_R 的标签序号。

中国知网 https://www.cnki.net

5.2.2 浮选过程双目相机时间序列模型构建

为了更准确地校正双目相机之间的异步性，本节通过时间序列模型来分析双目相机在浮选过程中图像采集的时间差异。时间序列模型可以提供双目相机采集图像的时间序列信息，捕捉和描述数据随时间变化的规律和趋势，有助于确定校正过程中的关键时间点，进而提高双目相机的校正精度。

为了匹配左右相机图像，本节选择关键帧集合中的左相机图像 $\hat{I}_L$ 作为基准图像，并根据左相机图像的成像时间搜索匹配的右相机图像 $\hat{I}_R$。为便于描述，将关键帧图像的序号记作 $sn(\hat{I}_R)$，则可提取右相机的邻域帧序列，即：

$$\overline{I}_R = I_R\left\{sn(\hat{I}_R)-2, sn(\hat{I}_R)-1, sn(\hat{I}_R), sn(\hat{I}_R)+1, sn(\hat{I}_R)+2\right\} \tag{5-2}$$

式(5-2)中，$I_R\{\cdot\}$ 表示的是提取输入视频中对应序号的平面板图像。

基于左右相机关键帧及其邻域帧序列，可得浮选过程双目相机的时间序列模型如图 5-2 所示。图 5-2 中，上半部分表示左相机成像时间序列，下半部分表示右相机成像时间序列。左相机关键帧为基准图像，其特征点坐标如图右上半部分所示，校正后的右相机特征匹配点坐标如图右下半部分所示。左相机的曝光时间为 Et_1，右相机的曝光时间为 Et_2。左右相机的成像时刻分别记作 t_L 和 t_R。绿色矩形和灰色矩形的左侧初始时间分别表示左右相机的拍摄触发时间，不同硬件触发时间所产生的双目相机成像硬件延时记作 Δt。绿色矩形和灰色矩形的宽度分别表示左右相机的曝光时间，中间的虚线对应的时刻分别表示左右相机的成像时间，不同成像时间所产生的双目相机成像延时记作 ΔT。

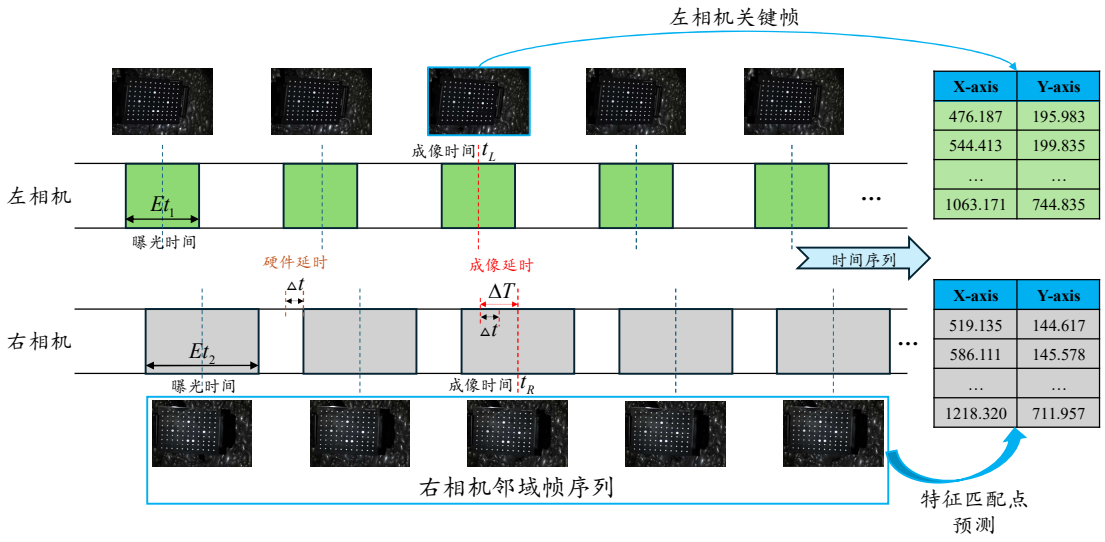


图 5-2 浮选过程双目相机的时间序列模型

中国知网 https://www.cnki.net

5.2.3　基于双目时序分析的初始延时估计

为了加快混合优化模型的收敛速度，本节基于经验知识来估计双目相机之间成像时间的初始延迟。在图 5-2 中，由于硬件差异及其他设备、环境因素造成的左右相机拍摄时间差，双目相机的触发时间之间存在不确定的延迟。此外，为了平衡左右视图的亮度，在工业现场为不同的相机设置了不同的曝光时间。由于所采用的工业相机成像时刻为曝光时间的中间时刻，因此基于上述浮选过程双目相机的时间序列模型，可用下式表示左右相机成像时间差异，即：

$$\Delta T = t_R - t_L = \frac{Et_2 - Et_1}{2} + \Delta t \,. \tag{5-3}$$

由于硬件延迟与曝光时间延迟相比通常要小得多，因此根据这一相机经验知识，可以估计浮选过程双目相机的初始延时为：

$$\Delta \hat{T} = \frac{Et_2 - Et_1}{2} \,. \tag{5-4}$$

5.3　基于闭环混合优化的浮选过程双目相机特征点同步校正

在提取了浮选过程双目图像外参关键帧，并进行了基于双目时序分析的初始延时估计之后，本节在此基础上实施基于闭环混合优化的双目相机特征点同步校正操作，具体实施流程如图 5-3 所示。图 5-3 左侧所示为所提取的左右视图外参关键帧，将左相机外参关键帧和右相机邻域帧序同时输入特征匹配点同步校正模块，最终实现双目相机的外参同步标定。特征匹配点同步校正模块主要包括基于左右视图序列的右相机特征匹配点预测，基于复合误差的 HC-IDE 混合优化模型构建及基于闭环混合优化的双目特征点同步校正。

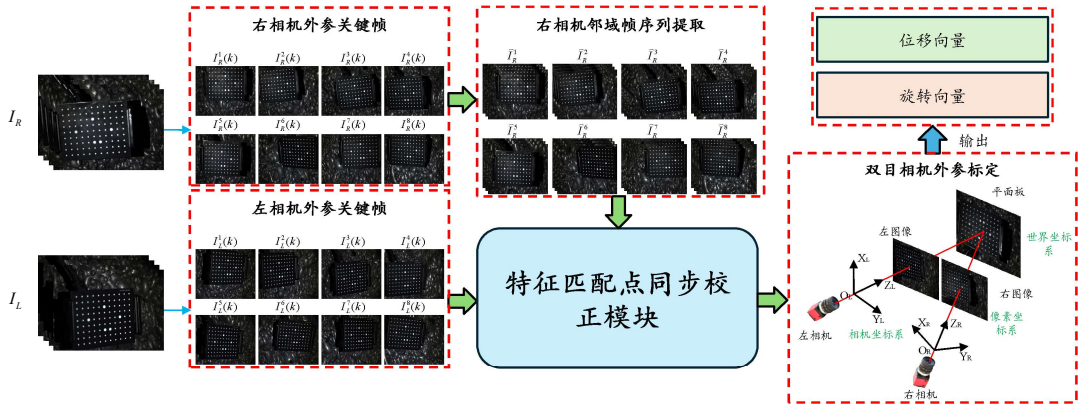


图 5-3　基于闭环混合优化的双目相机特征点同步校正实施流程

中国知网　https://www.cnki.net

5.3.1 基于左右视图序列的右相机特征匹配点预测

在估计了浮选过程左右相机的初始延时之后，本节进行右相机特征匹配点预测，以提取与左相机关键帧图像特征点相匹配的右相机坐标集合，具体过程如图 5-4 所示。

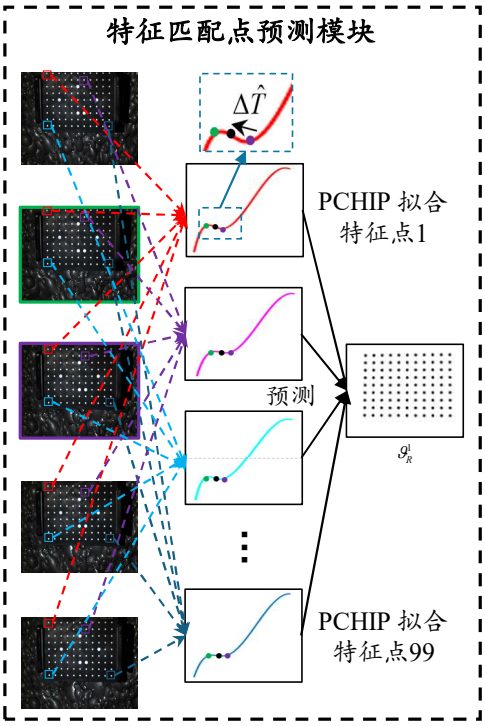


图 5-4 右相机特征匹配点预测模块

首先，对所有输入平面板图像进行畸变校正，主要考虑对图像特征影响最大的径向畸变和切向畸变，具体校正过程如下所示：

$$\begin{cases} x_{dist} = x(1+k_1r^2+k_2r^4+k_3r^6)+2p_1xy+p_2(r^2+2x^2) \\ y_{dist} = y(1+k_1r^2+k_2r^4+k_3r^6)+p_1(r^2+2y^2)+2p_2xy \end{cases} \tag{5-5}$$

式(5-5)中，(x_{dist}, y_{dist}) 表示的是畸变点的归一化坐标，(x, y) 为畸变校正后的坐标。因此，可以得到校正后的左右视图 $\overline{I}_L$ 和 $\overline{I}_R$。

然后，对右相机邻域帧序列提取特征点集，记作 $\tilde{I}_R$。并采用分段三次 Hermite 插值多项式(PCHIP)[193]来拟合每个特征点的运动轨迹，如下所示：

$$g_{mt}^{p} = f_{pchip}(\tilde{I}_R^{p}), p = 1,2,...,m. \tag{5-6}$$

式(5-6)中，m 表示的是特征点数量，g_{mt}^{p} 为特征点 p 的运动拟合函数。基于式(5-6)所得的运动轨迹，可预测与左相机图像成像时间相匹配的右相机特征点坐标为：

$$\vartheta_R = \underset{p=1,2,...,m}{\arg} \left\{ coor(g_{mt}^{p}, \Delta\hat{T}) \right\} \tag{5-7}$$

式(5-7)中，$coor(g_{mt}^{p}, \Delta\hat{T})$ 表示的是特征点运动拟合函数在左右相机延时为 $\Delta\hat{T}$ 时

中国知网 https://www.cnki.net

的预测坐标值。

5.3.2 基于闭环策略及 HC-IDE 混合优化的双目特征点同步校正

本节详细介绍了基于闭环策略及 HC-IDE 混合优化的双目特征点同步校正过程，其具体方案如图 5-5 所示。

使用前文所述的特征匹配点预测模块，可根据公式(5-6)为双目相机的 n 对关键帧提取 n 组右相机特征匹配点坐标，记作 $\Re(\Delta\hat{T})=\{\vartheta_R^1,\vartheta_R^2,...,\vartheta_R^n\}$。为了在小范围内优化初始延时以提升模型收敛速度和鲁棒性，本节构建了一种融合希尔爬升算法和改进差分进化优化算法的混合优化算法(HC-IDE)。希尔爬升算法是一种局部搜索算法，它通过在当前解的邻域内进行搜索来逐步改进解的质量，但可能会陷入局部最优。而差分进化算法是一种基于群体差异的启发式优化算法，广泛应用于各种连续优化问题，具有较好的全局搜索能力。通过将两者融合，可以利用差分进化算法的全局搜索能力来避免局部最优，同时利用希尔爬升算法的局部搜索能力来加速收敛。此外，所构建的混合优化算法可以提高算法的成功率和稳定性，通过记忆机制加速了收敛过程。这种融合策略有助于在保持算法性能的同时提高收敛速度，增强算法的全局和局部搜索平衡性，提高算法在复杂优化问题上的性能。

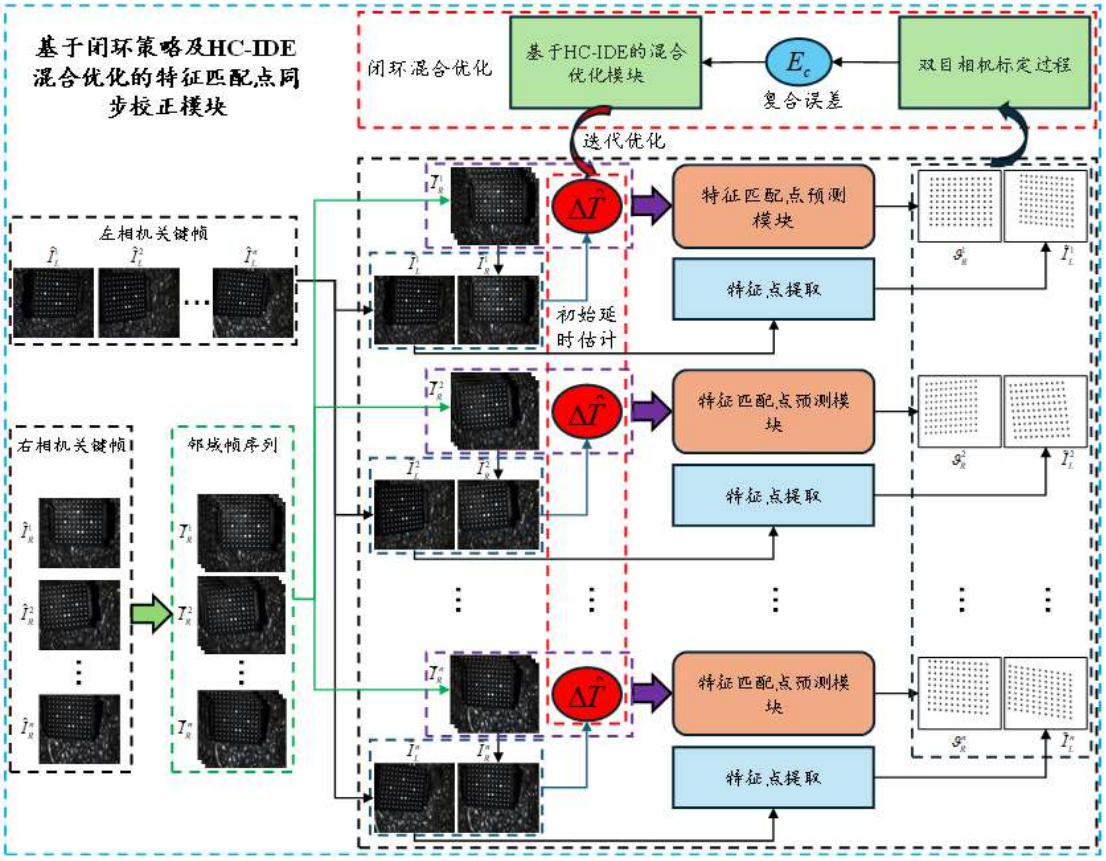


图 5-5 基于闭环策略及 HC-IDE 混合优化的双目特征点同步校正方案

中国知网 https://www.cnki.net

复合标定误差：首先，使用希尔爬升算法对初始成像延时 $\Delta\hat{T}$ 进行局部优化。优化目标是最小化复合标定误差，该复合误差同时考虑了双目相机的标定精度和空间约束，主要包括来自左右相机的重投影误差和对极误差。重投影误差不仅考虑了单应矩阵间的计算误差，也考虑了图像的测量误差。同时，对极误差考虑了立体视觉中极线几何的约束，这有助于确保左右相机图像之间的几何一致性。通过同时最小化重投影误差和对极误差，可以提高标定过程的鲁棒性。这种方法可以减少由于单一误差最小化导致的潜在问题，例如过度拟合或对特定类型误差的敏感性。此外，将重投影误差和对极误差结合起来，可以更全面地考虑浮选环境标定过程中可能遇到的多种误差类型，从而提高标定的整体性能和可靠性。其中，对于包含 s 个特征点的 k 帧平面板标定图像，其平均重投影误差可通过下式计算，即：

$$E_{rep}=\sum_{i=1}^{k}\sum_{j=1}^{s}\left\|s_{i,j}-\hat{s}_{i,j}(A,R_i,t_i,D,M_j)\right\|^2 \tag{5-8}$$

式(5-8)中，$s_{i,j}$ 表示的是在平面板图像中的实际特征点，$\hat{s}_{i,j}$ 表示的是重投影点，M_j 表示的是空间点坐标。

此外，对于包含 s 个特征点的 k 帧平面板标定图像，其对极误差可通过下式计算，即：

$$E_{epi}=\sum_{i=1}^{k}\sum_{j=1}^{s}\left(d\left(\tilde{s}_{r,i,j},M\tilde{s}_{l,i,j}\right)^2+d\left(\tilde{s}_{l,i,j},M^T\tilde{s}_{r,i,j}\right)^2\right) \tag{5-9}$$

$$d\left(\tilde{s}_{r,i},M\tilde{s}_{l,i}\right)=\frac{\left|\tilde{s}_{r,i}M\tilde{s}_{l,i}\right|}{\sqrt{\left(M\tilde{s}_{l,i}\right)^2+\left(M\tilde{s}_{r,i}\right)^2}} \tag{5-10}$$

式(5-9)和(5-10)中，M 表示的是基础矩阵，l 和 r 分别表示左右相机，$\tilde{s}_l$ 和 $\tilde{s}_r$ 表示其次坐标。

然后，可通过下式计算复合标定误差，即：

$$E_c(\Delta\hat{T})=\frac{1}{n}\sum_{i=1}^{n}\left(\alpha\cdot(E_{rep}^i(\Gamma)+E_{rep}^i(\Re(\Delta\hat{T})))+(1-\alpha)\cdot E_{epi}^i(\Gamma,\Re(\Delta\hat{T}))\right) \tag{5-11}$$

式(5-11)中，$E_c(\Delta\hat{T})$ 为在成像延时 $\Delta\hat{T}$ 下的复合标定误差，$\Gamma=\{\tilde{I}_L^1,\tilde{I}_L^2,...,\tilde{I}_L^n\}$，其中 $\tilde{I}_L$ 为关键帧 $\hat{I}_L$ 的特征点图谱，α 表示的是重投影误差权重，具体的权重设置请参见本文第 5.4.2 节。

HC-IDE 混合优化算法：对于初始成像延时 $\Delta\hat{T}$，使用式(5-11)中的复合标定误差作为优化目标，利用希尔爬升算法得到双目相机成像延时的第一阶段最优解，即：

$$\Delta\hat{T}'=\arg\min(f_{HC}(\Delta\hat{T},E_c(\Delta\hat{T}))) \tag{5-12}$$

中国知网 https://www.cnki.net

式(5-12)中，$f_{HC}(\cdot)$表示的是希尔爬升算法[194]。

然后，使用双目相机成像延时的第一阶段最优解作为初始值，并采用改进的差分进化算法进行全局优化。差分进化算法的关键调节参数涉及种群规模、缩放因子和交叉概率。种群规模(NP)体现了算法中种群所包含的信息量，较大的 NP 值意味着种群能够覆盖更多的信息，但同时也意味着需要更多的计算资源，这可能会影响求解效率。相反，较小的 NP 值可能会限制种群的多样性，不利于找到全局最优解，有时甚至可能导致搜索过程陷入停滞。交叉概率(CR)则反映了在交叉操作中，后代与亲代以及变异个体之间信息交换的程度。较高的交叉概率意味着更广泛的信息交换，如果交叉概率较低，则可能导致种群多样性迅速降低，这不利于进行全局优化。与交叉概率相比，缩放因子(F)对算法性能的影响更为显著，它主要影响算法的全局搜索能力。较小的 F 值有助于算法更好地探索局部区域，而较大的 F 值则有助于算法跳出局部最小值，但这可能会减慢收敛速度。此外，缩放因子也会影响种群的多样性。

其中，对于使用 D 维向量(种群规模为 NP)作为初始解的情况，交叉操作如下所示，对于个体 $x_{r,G}$，其试验个体可通过下式生成：

$$\overline{x}_{rb,G+1}=\begin{cases}\hat{x}_{rb,G+1}, R_b \le CR\\ x_{rb,G}, otherwise\end{cases}(b=1,2,...,D.) \tag{5-13}$$

式(5-13)中，R_b 为[0,1]范围内的随机数。

此外，在差分进化算法中，变异策略的选择显著影响探索能力、收敛精度和速度[195]。因此，本节提出了一种改进的两步变异策略，以更有效地适应相机标定模型。首先，在改进的差分进化算法中，使用 DE/rand/1 的变异策略来为下一代生成候选种群，如下所示：

$$V_{i,G}=x_{r_1,G}+F\cdot(x_{r_2,G}-x_{r_3,G}) \tag{5-14}$$

式(5-14)中，r_1，r_2，r_3 是在种群[1，NP]中进行随机选择的，并且 $r_1\neq r_2\neq r_3\neq i$，此外 $F\in[0,1]$ 是一个常数比例因子。

一般情况下，在引入新的评估参数和权重因子的情况时，通过调整邻域模型可有效增加同一邻域内向量的多样性[196]。在此基础上，本节提出了一种基于邻域结构的改进变异策略来提高整体优化算法的收敛速度和准确性，名为 DE/neighbor-rand-to-qbest/1。这种方法避免了大规模的全局变异，减少了大量低效的变异操作，并有效防止了模型的过早收敛。具体设计概述如下：

$$V_{i,G}=x_{r_3,G}+F_1\cdot F_a\cdot(x_{qbest,G}-x_{r_3,G})+F_2\cdot F_a\cdot(x_{r_1}-x_{r_2,G}) \tag{5-15}$$

式(5-15)中，$x_{qbest,G}$ 是从前 $q\%(q\in[0,1])$的个体中随机选择的解，F_a 是一个缩放因子：

中国知网 https://www.cnki.net

$$F_a = 0.5 + 0.5 \cdot \frac{FEs}{FEs_{\max}} \tag{5-16}$$

式(5-16)中，FEs 表示的是寻优操作结束时函数求值的次数。

基于上述描述，可以根据改进的变异策略 DE/neighbor-rand-to-qbest/1 构建最终的 HC-IDE 混合优化模型。特别地，本节将复合标定误差作为改进差分进化算法的适应度值。然后，通过闭环策略计算最终的最优成像延时，即：

$$\Delta\hat{T}^* = \arg\min(f_{IDE}(\Delta\hat{T}', E_c(\Delta\hat{T}'))) \tag{5-17}$$

式(5-17)中，$f_{IDE}(\cdot)$表示的是上文所描述的改进差分进化算法，$\Delta\hat{T}^*$ 为迭代优化后成像延时的最优解。

基于闭环策略的右相机特征点同步校正：在得到式(5-17)中成像延时的最优解后，则可以提取出同步校正后的右相机特征匹配点坐标集，即：

$$\Re^*(\Delta\hat{T}^*) = \left\{ \mathcal{G}_R^{1^*}, \mathcal{G}_R^{2^*}, ..., \mathcal{G}_R^{n^*} \right\}. \tag{5-18}$$

上述右相机特征匹配点坐标集即为与输入左相机关键帧图像对应的右相机平面板图像同步校正特征点集合，共 n 帧匹配图像。由于泡沫浮选环境的相机标定过程是开环过程，为了提升标定精度和模型鲁棒性，在进行右相机特征点同步校正的步骤中融入了闭环策略，使用复合标定误差为优化目标，双目相机成像延时为变量，通过闭环迭代优化获取最优的特征匹配点坐标，基于闭环策略的右相机特征点同步校正的具体过程如图 5-6 所示。通过执行右相机特征点同步校正操作，可以同步获得与输入的左相机关键帧图像特征匹配的右相机关键帧图像坐标集合，然后可使用张正友标定法对校正后的坐标集合求解相机参数。

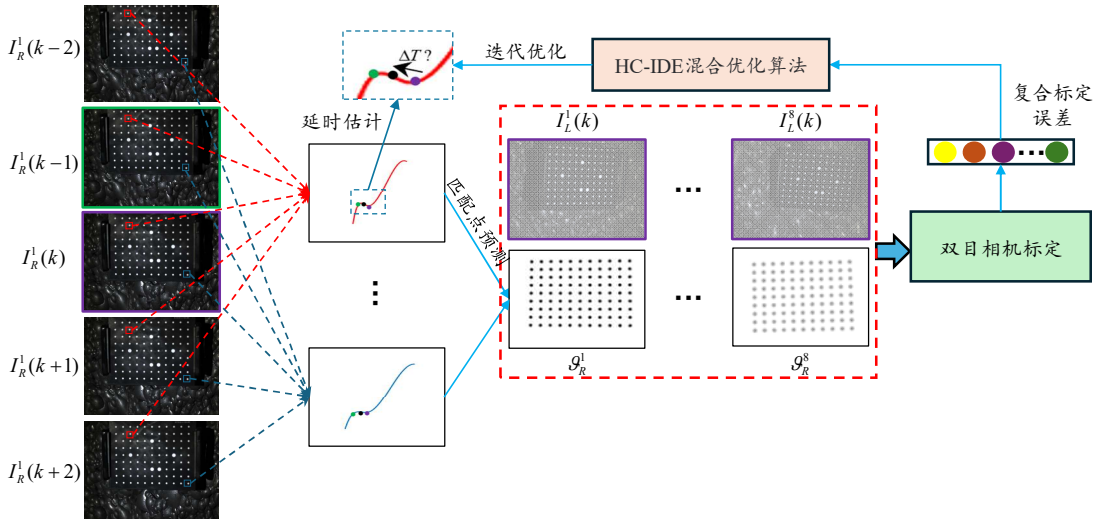


图 5-6 基于闭环策略的右相机特征点同步校正

中国知网　https://www.cnki.net

5.4 基于特征点同步校正的双目相机标定效果验证

5.4.1 实验数据集、模型性能评估及对比模型

本节分别在实验室环境和真实泡沫浮选环境进行了对比实验，所使用的实验数据集包括实验室数据集和真实泡沫浮选数据集，具体描述如下。

实验室数据集：为了全面评估所提特征点同步校正方法的性能，首先在实验室环境中进行了实验验证。同时，为了更好的模拟真实浮选环境双目相机的不一致曝光时间，将左右相机的曝光时间设置为不同。其中，左相机曝光时间固定设置为 16000 微秒，右相机曝光时间分别设置为 18000、21000、24000、27000 和 30000 微秒，并构建了五种不同配置的实验场景进行模拟实验。另外，与真实浮选场景标定过程类似，在整个平面板图像数据收集过程中，平面板始终保持手动运动状态。曝光时间配置如表 5-1 所示，同时在图 5-7 中展示了相应的平面板图像。在整个实验室环境的平面板图像捕获过程中，双目相机的空间位置保持稳定不变。此外，在整个实验室环境下的异步相机外参标定实验中，使用 30 次重复实验的平均结果作为最终输出。

表 5-1 双目相机曝光时间配置

实验场景	左相机曝光时间(μs)	右相机曝光时间(μs)
场景 1	16000	18000
场景 2	16000	21000
场景 3	16000	24000
场景 4	16000	27000
场景 5	16000	30000

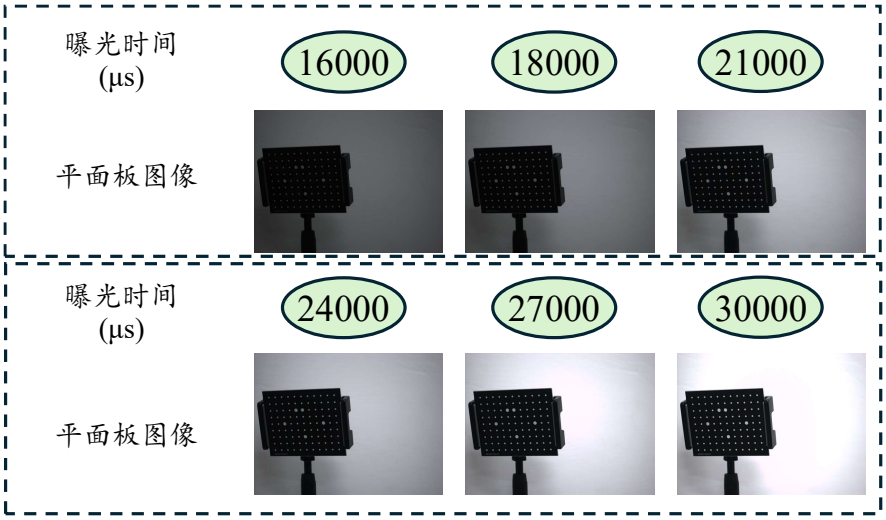


图 5-7 不同曝光时间下的平面板图像

中国知网 https://www.cnki.net

真实泡沫浮选数据集：除了实验室环境下的异步相机标定对比实验，本文还在中国南方某浮选厂的真实泡沫浮选环境下评估了所提双目相机同步校正方法的性能。具体描述请参见本文第 2.2 节。实验中使用的标定板包括 11*9 个特征圆，尺寸为 102.5*82.5 毫米，两个相邻圆心之间的距离为 10 毫米，图像分辨率设置为 1388*1038 像素。同时，为了减轻工业浮选现场环境光的影响，适当调整了双目相机的曝光时间。之后，通过手动控制的方式移动并旋转平面板，然后捕获平面板视频以进行相机标定。

模型性能评估指标：在实验室环境下，为了进行定量评估，首先在左右相机曝光时间同步的情况下对双目相机进行标定。同时为了降低硬件延时，使用示波器同步触发左右相机。具体而言，分别在左右相机曝光时间同步设置为 16000、18000、21000、24000、27000 和 30000 的场景下求解相机参数，并取所有重复实验的平均结果作为相机参数的参考值，如表 5-2 所示。

表 5-2 同步场景下的相机参数参考值

相机参数	参考值
f_L (*pixel*)	[4090.54, 4089.41]
f_R (*pixel*)	[4085.63, 4084.72]
PP (*pixel*)	[694, 519]
R (*rad*)	[-0.027, 0.387, -0.014]
T (*mm*)	[319.235, 0.607,82.975]

然后，通过将异步场景下估计的相机参数与同步场景中的参考值进行比较来评估所提出方法的性能，性能评估指标包括：

$$\Delta f = \frac{\left\| f_L^{ref} - f_L^{est} \right\|_2 + \left\| f_R^{ref} - f_R^{est} \right\|_2}{2} \tag{5-19}$$

$$\Delta PP = \left\| PP^{ref} - PP^{est} \right\|_2 \tag{5-20}$$

$$\Delta R = \left\| R_{EA}^{ref} - R_{EA}^{est} \right\|_2 \tag{5-21}$$

$$\Delta T = \left\| T^{ref} - T^{est} \right\|_2 \tag{5-22}$$

式(5-19)-(5-22)中，f^{ref}，R_{EA}^{ref}，PP^{ref}，和T^{ref}分别表示的是焦距参考值、由旋转矩阵按“ZYX”顺序换算的欧拉角参考值、主点参考值、位移向量参考值。同时，f^{est}，R_{EA}^{est}，PP^{est}，和T^{est}分别表示的是上述各参数的估计值。

此外，在真实泡沫浮选环境下，使用重投影误差和平均重构误差作为性能评估指标。

对比模型：在实验室环境和真实泡沫浮选环境的对比实验中，均使用了五种

中国知网 https://www.cnki.net

对比模型，包括张氏标定法[157]、TC-BCC[47]、KFS-WNTD[156]、OEPC[48]以及SECM[49]。

5.4.2 特征匹配点预测模块的有效性验证

为了分析基于闭环混合优化的双目特征点同步校正方法中主要模块的具体贡献，本节首先进行了复合标定误差超参选取，然后分别使用最佳超参对特征匹配点预测模块和闭环混合优化模型进行了验证实验。

复合标定误差超参选择：在进行各模块的有效性验证之前，首先对复合标定误差中重投影误差的权重$\alpha \in [0,1]$进行了选取，以评估重投影误差和对极误差的重要性，本小节实验在场景 3 中进行。为了确定最优权重取值，在[0,1]范围内进行了参数搜索，搜索步长设置为 0.1。实验结果如表 5-3 所示，从表 5-3 可以发现当仅使用重投影误差或极线误差时(即$\alpha = 0$或$\alpha = 1.0$)，整体标定性能未达到最佳。此外，可以发现通过同时使用这两种误差，可以获得更好的标定精度。其中，当重投影误差权重为$\alpha = 0.7$时，Δf，ΔR，和ΔT的误差最低，同时误差ΔPP也较小。因此，本章实验给重投影误差分配$\alpha = 0.7$的权重，并给对极误差分配 0.3 的权重。

表 5-3 复合标定误差超参选择(粗体表示最优的结果，下划线表示次优结果)

误差权重α	$\triangle f$	$\triangle PP$	$\triangle R$	$\triangle T$
0	14.31	8.24	0.47	4.75
0.1	14.62	8.87	0.43	4.69
0.2	13.77	<u>6.49</u>	0.52	4.71
0.3	12.29	7.26	0.51	4.23
0.4	12.84	7.72	0.45	3.98
0.5	10.39	8.51	0.39	4.17
0.6	9.67	7.40	0.40	4.06
0.7	**8.43**	7.15	**0.31**	**3.79**
0.8	9.35	8.81	<u>0.37</u>	<u>3.87</u>
0.9	10.17	**6.38**	0.41	3.95
1.0	<u>9.28</u>	7.76	0.44	3.92

特征匹配点预测模块的有效性验证：在本文第 5.3.1 节所述的特征匹配点预测模块中，使用了 PCHIP 方法来精确模拟右相机特征点的运动轨迹，因此本节对 PCHIP 方法的有效性进行了评估分析。首先将 PCHIP 方法和几种其他常用的拟合算法进行了对比，包括线性插值法、多项式插值法和高斯函数拟合方法，对比实验结果如表 5-4 所示。从表 5-4 可以发现，线性插值和多项式插值方法在内参上的误差比高斯函数拟合方法要小，且这三种对比方法得到的外参误差较为接近。但是，PCHIP 方法展现了最佳的标定性能，特别是在外参上的误差最小，表现出最优的平面板轨迹拟合效果。这主要是因为 PCHIP 方法具有更好的平滑性

中国知网 https://www.cnki.net

和稳定性，更能适应平面板的非线性运动情况。综上所述，实验表明所提的特征匹配点预测模块在异步相机标定中是有效的。

表 5-4 特征匹配点预测模块的有效性验证

对比模型	$\triangle f$	$\triangle PP$	$\triangle R$	$\triangle T$
线性插值法	9.87	8.53	0.43	4.17
多项式插值法	10.73	8.21	0.47	3.96
高斯函数拟合法	12.68	9.75	0.69	4.25
所提方法	8.39	7.06	0.32	3.82

5.4.3 闭环混合优化模型的有效性验证

针对本文第 5.3.2 节所述的基于 HC-IDE 的闭环混合优化模型，本节对其进行了有效性验证。主要通过对比实验来评估所提出的 HC-IDE 闭环混合优化模型在双目相机同步标定过程中的性能。为了全面分析模型的有效性，分别使用遗传算法(GA)、差分进化算法(DE)、改进的差分进化算法(IDE)、融合希尔爬升算法的遗传算法(HC-GA)、融合希尔爬升算法的差分进化(HC-DE)以及所提的融合希尔爬升算法的改进差分进化算法(HC-IDE)这几种优化算法进行了对比实验。实验结果如表 5-5 所示，从表 5-5 可以发现，与传统的差分进化算法相比，所提出的 IDE 算法在多个指标上都有所改进，验证了所提改进变异策略的有效性。此外，当融合了希尔爬升算法时，所有对比算法都显示出一定程度的准确性提升，例如 HC-GA 相对于 GA 算法性能有所提升，HC-DE 相对于 DE 算法有所提升，同时 HC-IDE 相对于 IDE 算法的标定误差明显降低。此外，在所有的对比算法中，所提出的 HC-IDE 算法取得了最佳的标定性能，证明了所提闭环混合优化模型的有效性。

表 5-5 闭环混合优化模型的有效性验证(粗体表示最优的结果，下划线表示次优结果)

对比算法	$\triangle f$	$\triangle PP$	$\triangle R$	$\triangle T$
GA	8.76	7.63	0.51	4.02
DE	8.77	7.54	0.53	4.05
IDE	<u>8.42</u>	7.33	0.44	<u>3.88</u>
HC-GA	8.74	7.38	<u>0.41</u>	3.96
HC-DE	8.49	<u>7.06</u>	0.45	3.92
HC-IDE	**8.26**	**6.95**	**0.37**	**3.85**

5.4.4 实验室环境下的异步相机外参标定实验

为了评估所提基于闭环混合优化的双目特征点同步校正方法的异步相机外

中国知网 https://www.cnki.net

参标定性能，本节在实验室环境下进行了实验，包括消融实验、模型整体性能评估和极线误差评估。

消融实验：为了全面评估所提出方法的性能，本节首先在实验室环境的场景 2 下对所提基于闭环混合优化的双目特征点同步校正方法进行了消融实验，以分析不同模块对标定结果的影响，主要包括初始延时估计模块消融实验、特征匹配点预测模块消融实验和闭环混合优化模块消融实验。

(1) 初始延时估计模块消融实验：通过比较去除和保留初始延时估计模块前后的性能来验证该模块的有效性。当移除初始延时估计模块时，模型收敛的平均迭代次数为 75，而添加该模块时平均迭代次数约为 40。这表明初始延时估计模块能够有效加速模型的收敛。

(2) 特征匹配点预测模块消融实验：使用平均复合误差来验证特征匹配点预测模块的有效性。当移除特征匹配点预测模块时，模型运行的平均复合误差约为 0.337，而添加该模块时误差约为 0.242。这表明特征匹配点预测模块对提高模型性能是有益的。

(3) 闭环混合优化模块消融实验：和上述实验类似，使用平均复合误差来验证闭环混合优化模块的有效性。当移除闭环混合优化模块时，模型的平均复合误差约为 0.461，而添加该模块时误差约为 0.242。这表明闭环混合优化模块能够有效提高标定精度，且该模块的作用相对于特征匹配点预测模块更显著，说明其在整个双目相机同步校正算法中发挥关键作用。

以上实验表明，所提双目特征点同步校正方法中的各个模块均发挥了重要作用，各个模块协同运行，共同提升了模型的精度和效率。

模型整体性能评估：在本小节实验中，分别在不同的曝光时间配置下对张氏标定法[157]、TC-BCC[47]、KFS-WNTD[156]、OEPC[48]、SECM[49]和本章所提出的方法进行了异步相机外参标定对比分析，然后取所有场景下的平均值作为最终结果。在实验室环境下，通过使用示波器改变触发时间来模拟工业过程的相机异步，在保持左相机无触发延时的情况下对右相机增加了 1.5 毫秒的延时。以上六种对比方法最终的实验结果如图 5-8 所示，图 5-8 中的误差条高度代表标准差。对于外参中的旋转向量误差 ΔR，张氏标定法、TC-BCC 方法、KFS-WNTD 方法、OEPC 方法、SECM 方法和本章所提方法在所有场景中的平均标准差分别为 0.0543、0.0512、0.0551、0.0472、0.0445 和 0.0386。对于外参中的位移向量误差 ΔT，以上这六种方法的平均标准差分别为 0.6794、0.6878、0.6404、0.6096、0.6147 和 0.5853。

中国知网 https://www.cnki.net

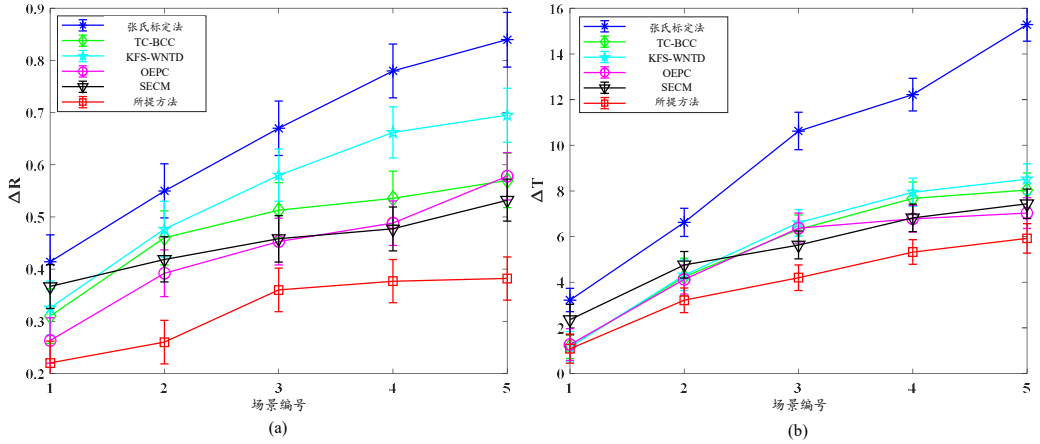


图 5-8 实验室环境下的异步相机外参标定整体性能评估

根据图 5-8 和以上实验结果，可以得出以下结论：

(1) 在双目相机异步程度较低的场景中，例如场景 1，左右相机曝光时间差异较小，所使用的六种对比方法均表现出了较好的外参标定性能。然而，随着曝光时间差异的增加，即双目相机的异步程度增强后，所有对比方法的外参标定误差都不同程度地有所上升。

(2) 与非相机同步的传统方法(例如张氏标定法和 KFS-WNTD 方法)相比，基于双目相机时间校正的方法(包括 TC-BCC 方法、OEPC 方法、SECM 方法和所提方法)在不同的异步场景下展现出了更强的鲁棒性，这证明了在异步双目相机标定过程中进行特征点校正操作的有效性和必要性。

(3) 与其他五种对比方法相比，本章所提方法在所有的双目相机异步场景中相机外参的整体平均误差和标准差均有所降低。特别是与当前主流的双目相机同步方法(例如 OEPC 方法和 SECM 方法)相比，所提方法具有更高的准确性和稳定性，这可能是由于所提方法引入了闭环混合优化模型，使得双目相机成像时间差异的估计更加精确。此外，所提方法考虑了数据采集过程中标定板的非线性运动，从而增强了模型对手动标定环境的适应能力。综上所述，与仅依赖像素匹配或时间校正的方法相比，所提方法显著提高了异步双目图像时间同步的准确性和鲁棒性。

极线误差评估：极线约束指的是在双目立体视觉系统中，任意一点在左、右相机成像平面上的投影点必然位于一对极线上。因此，进行极线校正的目的就是将两个相机的成像平面通过数学变换对准到同一观察平面上，使得对应点的匹配从在整个图像平面上的二维搜索转变为在极线上的一维搜索。极线误差评估就是用来量化这种对准程度的好坏，即评估校正后的极线是否真正满足约束条件。如果极线误差较小，则说明标定结果较精确。

中国知网　https://www.cnki.net

本节实验首先在保持左右相机空间位置不变的情况下，分别采集三个不同玩具模型(即菠萝玩偶、卡通人物模型和绿色盒子)的双目图像。然后，分别在场景 1 和场景 3 的双目相机曝光时间配置下，使用经典的张正友标定法与所提方法进行对比实验。分别使用这两种方法来计算不同场景下相机的内外参数和基础矩阵后，然后确定了每个玩具模型左右视图中的已知匹配点(在图 5-9 中用“+”表示)。接下来，通过计算每个匹配点与其对应极线之间的距离来衡量相机标定结果的准确性，具体的实验结果如图 5-9 所示。

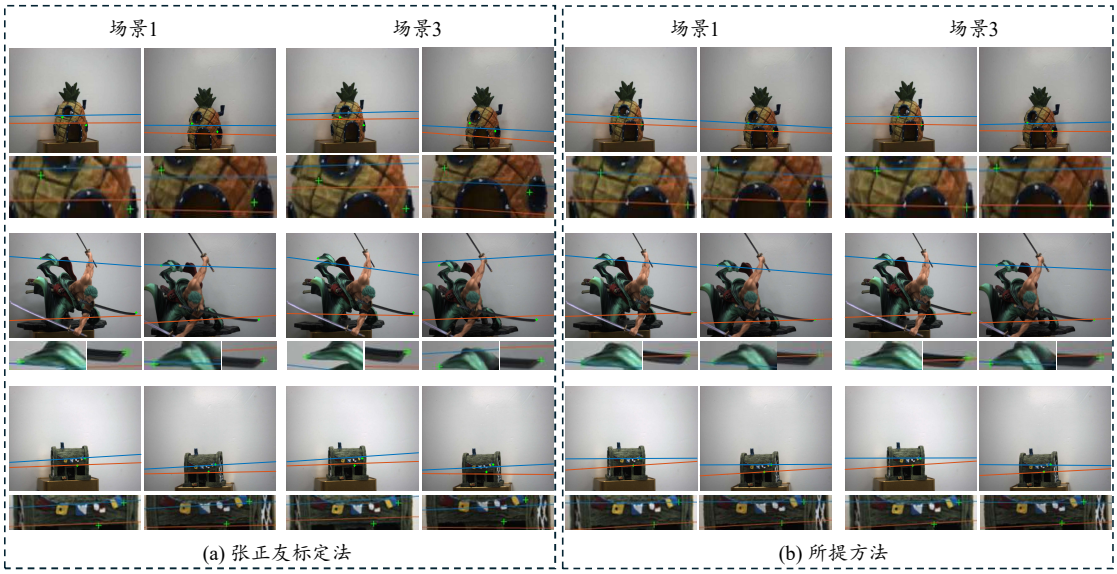


图 5-9 实验室环境下的异步相机外参标定极线误差评估

从图 5-9 可以发现，张氏标定法在场景 3 下的标定结果明显比场景 1 下有所退化，这表明该方法难以适应左右图像高度不匹配的场景。此外，所提方法在两种场景下都展现了较高的精度，误差明显低于张氏标定法。这种性能提升可能是由于所提方法在相机外参标定过程中使用复合标定误差作为模型优化目标来进行成像延时优化，从而提升了左右视图特征点的匹配程度。

5.4.5 泡沫浮选环境下的异步相机外参标定工业应用实验

本节在真实泡沫浮选环境下对所提基于闭环混合优化的双目特征点同步校正方法进行了异步相机外参标定工业应用实验，所使用的对比方法为张氏标定法、TC-BCC、KFS-WNTD、OEPC 以及 SECM 和所提方法。主要实验内容包括泡沫浮选过程中不同方法相机标定的结果对比，重投影误差对比实验和双目相机平均重构误差对比实验。

泡沫浮选过程相机标定结果对比：表 5-6 展示了所有对比方法在泡沫浮选环境下的标定结果。从表 5-6 中可以发现，不同方法的标定结果存在一定差异，尤

中国知网 https://www.cnki.net

其是在双目相机的外参结果方面。这些差异可能源于不同的标定算法、数据采集条件或相机本身的特性。其中，基于非相机同步的传统方法外参标定结果想接近，而基于双目相机特征点时间校正的方法结果也相对接近，这表明左右视图特征点校正操作会一定程度的改变外参标定结果。

表 5-6 泡沫浮选过程不同方法的相机标定结果对比

相机参数	张氏标定法	TC-BCC	KFS-WNTD	OEPC	SECM	所提方法
f_{xL}	4144.19	4143.19	4127.10	4113.71	4117.36	4121.79
f_{yL}	4134.49	4134.19	4117.23	4111.59	4114.23	4117.51
u_{0L}	749.61	695.36	730.18	691.82	694.69	698.30
v_{0L}	537.66	523.61	545.22	536.88	528.75	524.94
f_{xR}	4221.45	4159.19	4177.72	4089.05	4090.49	4088.70
f_{yR}	4211.54	4153.76	4172.86	4084.41	4087.81	4087.43
u_{0R}	663.25	686.91	676.29	685.72	690.28	687.95
v_{0R}	575.69	554.92	544.36	537.67	529.76	532.46
R_x	0.0006	-0.0043	-0.0093	-0.0091	-0.0088	-0.0087
R_y	0.517	0.4949	0.5047	0.5178	0.5126	0.4971
R_z	0.0143	0.0124	0.0125	0.0087	0.0107	0.0116
T_x	-282.69	-281.40	-279.45	-288.74	-284.51	-281.52
T_y	-0.267	-1.306	-0.888	-1.167	-0.822	-0.687
T_z	102.73	93.76	98.39	119.11	94.37	94.70

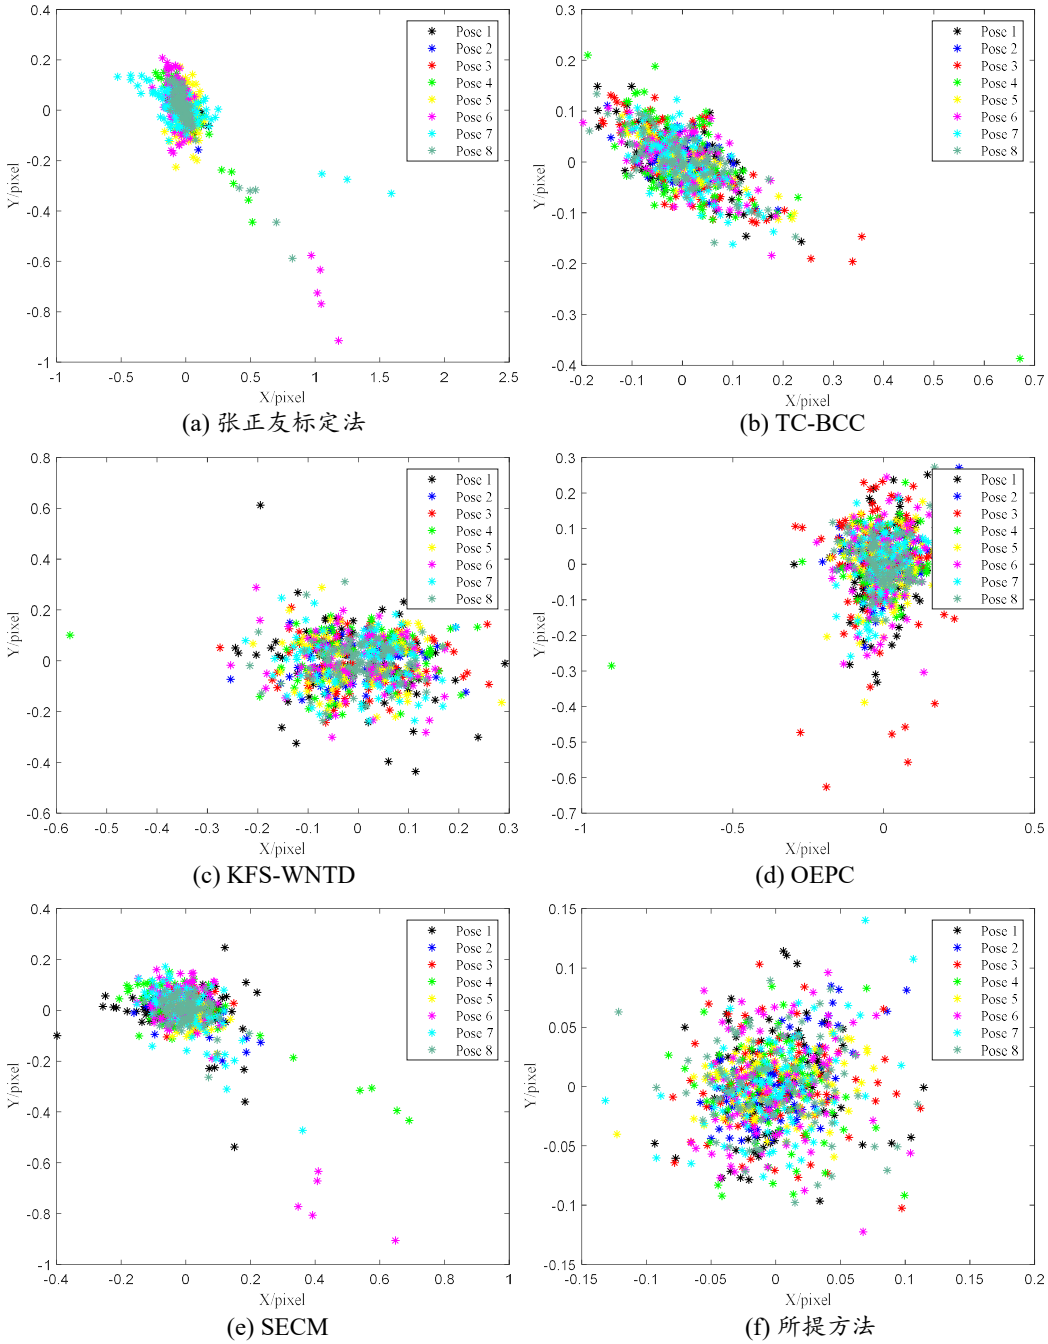
重投影误差对比实验：本小节在真实泡沫浮选数据上使用上述六种对比方法进行了异步双目相机标定。与前文不同，为了直观对比，本节实验使用右相机的校正特征点进行重投影误差对比实验。

图 5-10 展示了右相机不同平面板位姿下的重投影误差分布情况，图中的点代表特征点在 X 轴和 Y 轴上的重投影误差。从图 5-10 可以发现，张氏标定法和 TC-BCC 方法的重投影误差分布主要集中在[-0.25, 0.25]范围内，同时存在许多较大误差的异常值。此外，当平面板运动幅度较大时，OEPC 方法和 SECM 方法偶尔会出现误差很大的情况。相比之下，所提方法的重投影误差在[-0.1, 0.1]之间均匀分布，且无明显的离群点。另一方面，图 5-10 中的结果表明，不同方法的重投影误差分布存在较大差异，这反映了它们在处理复杂场景和特征点匹配方面的能力不同。所提出的方法在重投影误差的均匀性和准确性方面表现最佳，这有助于在后续的三维重建和特征点匹配中获得更准确的结果。

双目相机平均重构误差对比实验：本节使用所有对比算法对左右相机关键帧图像对中的特征点进行了重构，并使用平面板中所有特征点的平均重构误差作为评估指标，实验结果如表 5-7 所示。从表 5-7 可以发现，张氏标定法产生了较大的平均重构误差，TC-BCC 方法整体误差适中，但稳定性较差。OEPC 方法和 SECM 方法的平均重构误差小于张氏标定法和 KFS-WNTD 方法，这表明在泡沫

中国知网 https://www.cnki.net

浮选环境的双目相机标定过程中进行特征点校正操作是有效的。此外，所提方法的平均重构误差及其方差分别为约 1.8mm 和 0.107，这表明该方法在准确性和稳定性方面均表现最佳，这有助于在泡沫浮选过程中获得更准确和可靠的数据分析结果。



(a) 张正友标定法　(b) TC-BCC

(c) KFS-WNTD　(d) OEPC

(e) SECM　(f) 所提方法

图 5-10 泡沫浮选过程不同方法的重投影误差实验结果

中国知网 https://www.cnki.net

表 5-7 泡沫浮选过程不同方法的双目相机平均重构误差对比结果

平面板位姿	张氏标定法	TC-BCC	KFS-WNTD	OEPC	SECM	所提方法
位姿 1	6.72	3.78	4.26	3.82	3.21	1.66
位姿 2	7.32	4.32	4.91	3.71	3.69	2.18
位姿 3	7.28	4.15	4.21	4.36	3.87	1.63
位姿 4	8.72	7.85	5.52	3.15	3.08	1.78
位姿 5	7.61	4.36	3.64	3.39	2.86	1.53
位姿 6	9.25	7.63	5.82	4.22	3.42	2.42
位姿 7	8.24	5.21	5.77	3.24	3.16	1.55
位姿 8	8.72	5.64	3.19	2.39	2.97	1.61

5.5 本章小结

本章提出了一种基于闭环混合优化的双目相机特征点同步校正方法。首先，针对浮选过程左右图像特征点不匹配的问题，给出了基于闭环混合优化的双目相机特征点同步校正方案。然后详细描述了基于双目时序分析的浮选过程双目相机初始延时估计过程，在进行双目图像外参关键帧提取的基础上，设计基于双目相机的时间序列模型的初始延时估计方法。之后，提出了基于闭环混合优化的浮选过程双目相机特征点同步校正方法，使用闭环策略及 HC-IDE 混合优化模型来同步预测右相机关键帧的匹配点坐标。最后，分别在实验室环境和真实浮选场景进行了对比实验，实验结果表明基于闭环混合优化的双目相机特征点同步校正方法展现了良好的异步相机外参标定效果。

中国知网 https://www.cnki.net

第 6 章 基于 FSC-McCNN 的浮选过程双目外参标定

泡沫浮选过程准确且鲁棒的双目相机外参标定是实现相机姿态准确估计的基础。因此，在进行双目图像特征点同步校正的基础上，本章针对浮选过程液位波动、相机视角变化等情况下双目外参高精度标定能力受限的问题，提出基于 FSC-McCNN 的浮选过程双目外参标定方法。卷积神经网络(CNN)通过多层卷积和池化操作，能够自动学习到输入数据中的局部结构和全局特征，从而捕捉到更高层次的语义信息。但是，对于泡沫浮选过程的平面板图像数据，简单的 CNN 模型难以有效处理二维特征点数据。为此，研制能从平面板图像数据中学习相机参数且适用于工业浮选过程相机外参标定的 CNN 方法。

6.1 基于 FSC-McCNN 的浮选过程相机标定框架

根据本文第 2.2.2 节所述的泡沫浮选过程相机标定环境，在工业开放场景下难以在不同平面板位姿下捕获高质量的相机标定图像。此外，数据采集过程中浮选槽液位的波动可能导致相机焦距变化，从而影响传统平面板标定方法的精确性和可靠性。当前主流的一些平面板标定方法在泡沫浮选过程存在一定的局限性，主要包括以下几点：

(1) 对于基于相位编码的标定方法(例如文献[34]和文献[35]的方法)，泡沫浮选过程难以安装投影仪等外部辅助设备，使得部分需要辅助设备的方法难以应用。此外，基于相位编码的标定方法对环境变化较敏感，工业浮选过程潜在的泡沫干扰和遮挡，以及不可控的光照条件变化(如图像阴影和反射光干扰)，可能会影响这一类方法的稳定性和准确性。

(2) 对于基于几何运算的标定方法(例如文献[197]和文献[159]的方法)，在泡沫浮选过程的数据采集过程中，为了捕捉特定区域的泡沫图像，可能需要在浮选运行过程中改变相机的视角或安装姿态，使得这一类方法易出现较大外参标定误差。

(3) 对于基于平面板倾斜度的标定方法(例如文献[30]和文献[156]的方法)，这些方法对标定图像均是在相同焦距下采集的场合能取得良好的效果。但是当面临浮选生产过程因液位波动而引起的相机焦距变化情况时，受视场空间变化影响，这些方法在同时计算不同焦距的平面板图像倾斜度时可能会出现异常值，甚至可能完全失效。

鉴于上述局限性，本章提出了基于 FSC-McCNN 的浮选过程相机标定方法，该方法利用深度学习网络构建了一个端到端相机标定模型，可用于从平面板特征图谱中直接预测相机参数，具体框架如图 6-1 所示。所提方法主要包括两部分内容，即基于边界约束的合成数据增强和基于特征空间编码和标定损失解耦的深度

中国知网　https://www.cnki.net

标定网络构建。

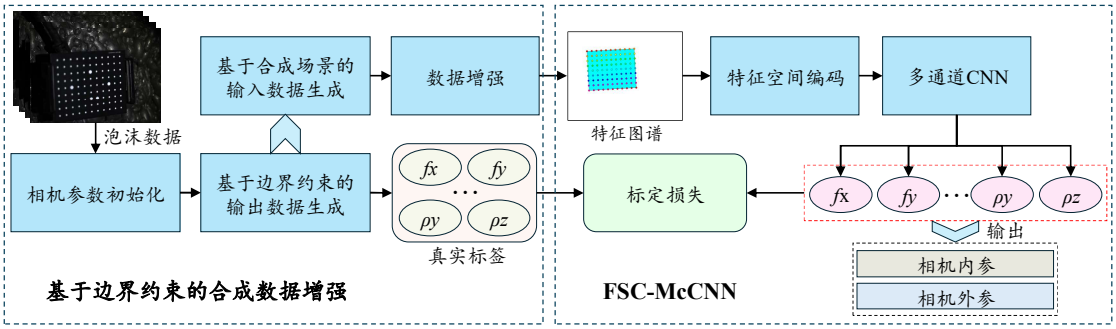


图 6-1 基于 FSC-McCNN 的浮选过程相机标定框架

第一阶段为基于边界约束的合成数据增强部分，首先使用本文第 5 章所述的基于闭环混合优化的双目相机特征点同步校正方法对泡沫数据进行相机参数初始化。并构建了表征平面板特征图谱和相机参数之间映射关系的深度标定网络训练数据集。主要步骤包括在特定边界约束下生成模型训练的输出数据，然后构建了一个合成相机成像场景，以捕获从相机参数到特征图谱的真实映射，并将其作为深度学习模型的输入数据。最后，通过对输入数据实施合成数据增强来提高深度标定网络的鲁棒性和泛化能力。有关基于边界约束的合成数据增强部分的详细信息请参见本文第 6.2.1 和 6.2.2 节。

第二阶段为基于特征空间编码和标定损失解耦的深度标定网络(FSC-McCNN)构建部分。对于输入的特征图谱数据，首先在特征空间中对输入特征图的横纵坐标进行位置编码，以提高模型对不同位姿平面板的空间信息表征能力。然后构建基于膨胀卷积和二维卷积的多通道卷积神经网络模型来挖掘特征编码中的多维成像信息，同时利用多通道 CNN 模块来估计与输入特征编码对应的相机内参和外参。此外，为了提升模型泛化能力，提出了基于标定损失解耦的模型训练方案。有关 FSC-McCNN 的详细信息请参见本文第 6.2.3 和 6.3.1 节。

6.2 FSC-McCNN 网络架构

6.2.1 基于双目特征点同步校正的相机参数初始化

为了提升双目相机外参标定的准确性，需首先对左右视图异步特征点进行校正操作。因此，对于输入的左右相机视频序列 I_L 和 I_R，使用本文第 5 章所述的基于闭环混合优化的双目特征点同步校正方法进行右相机特征匹配点修正，如下所示：

$$\left\{\overline{I}_L,\overline{I}_R\right\}=f_{CHO-CSC}\left(I_L,I_R\right) \tag{6-1}$$

式(6-1)中，$f_{CHO\text{-}CSC}(\cdot)$表示的即是本文第 5 章所述方法，$\{\overline{I}_L,\overline{I}_R\}$表示的是校正后

中国知网 https://www.cnki.net

的左右图像特征匹配点。

然后，使用张正友标定法分别对校正后的左右相机特征匹配点进行初始化标定，以获取双目相机的初始参数，即：

$$\left[\overline{A}_L,\overline{R}_L,\overline{T}_L,\overline{A}_R,\overline{R}_R,\overline{T}_R\right]=f_{Zhang}(\overline{I}_L,\overline{I}_R) \tag{6-2}$$

式(6-2)中，$\overline{A}_L$和$\overline{A}_R$分别表示左右相机的初始化内参，各包括$\overline{f}_x$、$\overline{f}_y$、$\overline{u}_0$和$\overline{v}_0$；$\overline{R}_L$和$\overline{R}_R$分别表示左右相机的初始化外参旋转矩阵，各包括$\overline{\theta}_p$、$\overline{\theta}_y$和$\overline{\theta}_r$；$\overline{T}_L$和$\overline{T}_R$分别表示左右相机的初始化外参位移矩阵，各包括$\overline{\rho}_x$、$\overline{\rho}_y$和$\overline{\rho}_z$。

6.2.2 基于边界约束的合成数据增强

本节详细阐述了深度标定网络 FSC-McCNN 的训练数据集构建方式，图 6-2 展示了基于边界约束的合成数据增强的具体方案。主要包括基于边界约束的输出数据生成、基于合成成像场景的输入数据生成和合成数据增强三个部分。

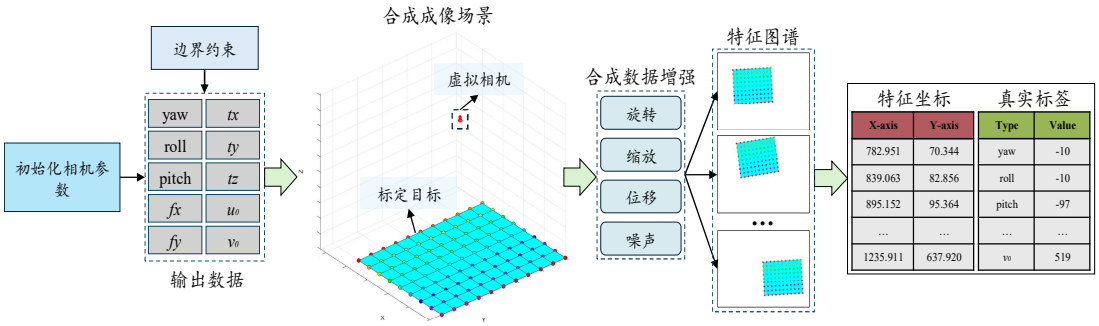


图 6-2 基于边界约束的合成数据增强方案

基于边界约束的输出数据生成：为了提升模型的运行效率，使用深度标定网络 FSC-McCNN 同时预测多个相机参数，包括焦距(即 f_x 和 f_y)、主点(即 u_0 和 v_0)、旋转角度(即俯仰角 θ_p、偏航角 θ_y 和翻滚角 θ_r)以及位移向量(即 X 轴位移 ρ_x、Y 轴位移 ρ_y 和 Z 轴位移 ρ_z)。然后，为了提升模型的搜索精度同时避免出现离散值，对所有的预测参数施加了边界约束，以确保预测参数遵循标定过程的实际限制，从而提高合成数据集的真实性和可靠性。其中，可将待预测的相机参数表示为 $\kappa=[f_x, f_y, u_0, v_0, \theta_p, \theta_y, \theta_r, \rho_x, \rho_y, \rho_z]$，具体的边界约束条件如下：

$$\left\{f_x,f_y\right\}\in\left[\frac{\overline{f}_x+\overline{f}_y}{2}-\Delta s_1,\frac{\overline{f}_x+\overline{f}_y}{2}+\Delta s_1\right] \tag{6-3}$$

$$u_0\in\left[\overline{u}_0-\Delta s_2,\overline{u}_0+\Delta s_2\right] \tag{6-4}$$

$$v_0\in\left[\overline{v}_0-\Delta s_3,\overline{v}_0+\Delta s_3\right] \tag{6-5}$$

中国知网 https://www.cnki.net

$$\theta_p \in \left[\overline{\theta}_p - \Delta s_4, \overline{\theta}_p + \Delta s_4\right] \tag{6-6}$$

$$\theta_r \in \left[\overline{\theta}_r - \Delta s_5, \overline{\theta}_r + \Delta s_5\right] \tag{6-7}$$

$$\theta_y \in \left[\overline{\theta}_y - \Delta s_6, \overline{\theta}_y + \Delta s_6\right] \tag{6-8}$$

$$\rho_x \in \left[\overline{\rho}_x - \Delta s_7, \overline{\rho}_x + \Delta s_7\right] \tag{6-9}$$

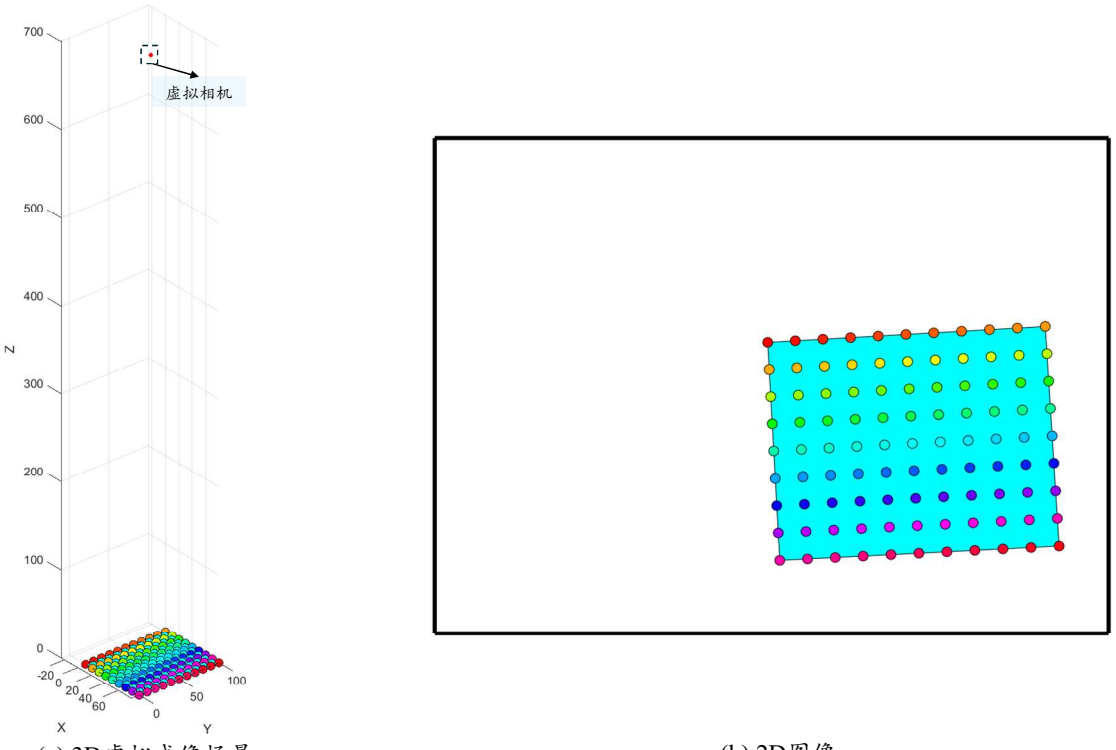
$$\rho_y \in \left[\overline{\rho}_y - \Delta s_8, \overline{\rho}_y + \Delta s_8\right] \tag{6-10}$$

$$\rho_z \in \left[\overline{\rho}_z - \Delta s_9, \overline{\rho}_z + \Delta s_9\right] \tag{6-11}$$

式(6-3)-(6-11)中，$[\Delta s_1, \Delta s_2, \ldots, \Delta s_{10}]$为各参数的边界约束范围。

基于以上边界约束，可以获得深度标定网络训练集输出数据的真实值。值得注意的是，为了提高标定质量，在后续的输入数据生成过程中剔除了特征点超出给定图像范围的平面板图像数据。

基于合成成像场景的输入数据生成：为了构建从特征点图谱到相机参数的直接映射关系，本节搭建了一个合成成像场景来生成深度标定网络的输入数据，如图 6-3 所示。该合成成像场景包括一个没有任何畸变的虚拟相机，以及一个包含多个特征点的虚拟标定目标。

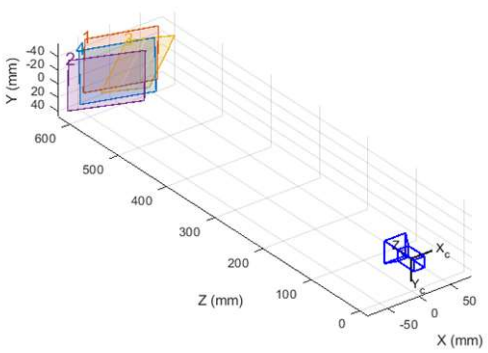


(a) 3D虚拟成像场景　　(b) 2D图像

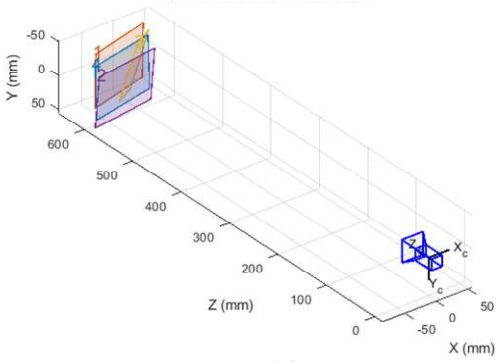
图 6-3 使用虚拟相机的合成成像场景

中国知网 https://www.cnki.net

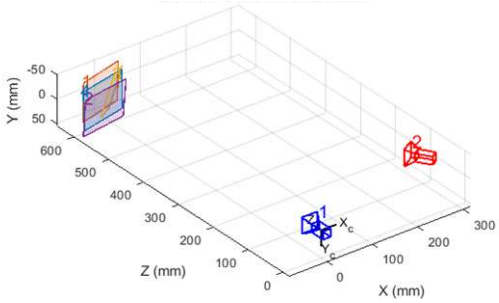
图 6-3 展示了虚拟单目相机的成像过程，对于双目相机成像，在几个相同位姿下其外参可视化情况如图 6-4 所示。



(a) 左相机外参可视化



(b) 右相机外参可视化



(c) 双目相机外参可视化

图 6-4 单双目相机成像外参可视化情况

要完成虚拟相机成像，需要输入包括相机内参和外参在内的共十个参数 κ，因此基于前文描述，相机内参矩阵可表示为：

$$A=\begin{bmatrix} f_x & 0 & u_0 \\ 0 & f_y & v_0 \\ 0 & 0 & 1 \end{bmatrix}. \tag{6-12}$$

此外，在合成成像场景中，3D 虚拟相机的方向函数设置为：

$$Ori_cam=\begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & -1 \\ -1 & 0 & 0 \end{bmatrix}. \tag{6-13}$$

然后，通过参数转换可以计算出相机外参的旋转矩阵为：

$$R=[r_x,r_y,r_z]=f_{VtM}(\theta_p,\theta_r,\theta_y)*Ori_cam \tag{6-14}$$

式(6-14)中，$f_{VtM}(\cdot)$指的是将向量转换成矩阵的函数。

同时，可通过下式计算相机外参的转移矩阵，即：

中国知网 https://www.cnki.net

$$T=[t_x,t_y,t_z]=R*[\rho_x,\rho_y,\rho_z]. \tag{6-15}$$

在此基础上，对于任意一组给定的原始特征点集合 F_p=[p_x, p_y, p_z]，通过使用上述相机内外参数，可以根据下式获得这些特征点在给定的相机参数下进行仿射投影的二维像素坐标，即：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix}=\lambda\begin{bmatrix} f_x & 0 & u_0 & 0 \\ 0 & f_y & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}\begin{bmatrix} R & T \\ 0_{3\times1}^{T} & 1 \end{bmatrix}\begin{bmatrix} p_x \\ p_y \\ p_z \\ 1 \end{bmatrix}. \tag{6-16}$$

因此，对于每一组边界约束下的输出参数，可以使用式(6-16)获得其对应的输入数据。

合成数据增强：为了增强 FSC-McCNN 模型的鲁棒性，减少其对理想图像条件的敏感性，同时扩大其泛化能力，本节在合成成像场景中实施了数据增强。通过引入参数变化，数据增强旨在让深度标定网络能面对更广泛的标定场景，从而增强其适用性，并使其能够在不同环境中表现出更一致的性能。其中，通过应用各种外部变换到虚拟相机上来增强特征点的位姿多样性，包括旋转、平移和缩放。这个过程旨在捕获不同条件下的多种标定板姿态，从而丰富合成数据集。对于原始特征点 F_p，通过这些变换生成的增强数据可表示为：

$$F_r'=rotate(F_p,\theta_p,\theta_y,\theta_r) \tag{6-17}$$

$$\widehat{F}_a=translate(F_r',\rho_x,\rho_y,\rho_z) \tag{6-18}$$

式(6-17)-(6-18)中，*rotate*(·) 表示是特征点在三个空间方向上的旋转，*translate*(·) 表示是 F_p 在三个坐标轴方向上的位移。

此外，为了增强模型对噪声数据的鲁棒性，在 30%的增强数据集中添加了高斯噪声。这种增强策略模拟了真实泡沫浮选过程的外部条件，以使模型在推理过程中能够有效处理非理想数据，如下所示：

$$\widehat{F}_n=\widehat{F}_a+N(\mu,\sigma) \tag{6-19}$$

式(6-19)中，$N(\mu, \sigma)$表示的是期望为 μ，方差为 σ 的高斯噪声。

随后，将上述增强数据和注入噪声的虚拟数据结合起来可形成一个综合的合成数据集，即：

$$\widehat{F}=\left\{\widehat{F}_a,\widehat{F}_n\right\}. \tag{6-20}$$

6.2.3 基于特征空间编码的深度标定网络构建

图 6-5 展示了所提基于特征空间编码的深度标定网络 FSC-McCNN 的详细

中国知网 https://www.cnki.net

架构，主要包括特征空间编码模块(FSC)和多通道卷积神经网络模块(McCNN)，具体情况如下所示。

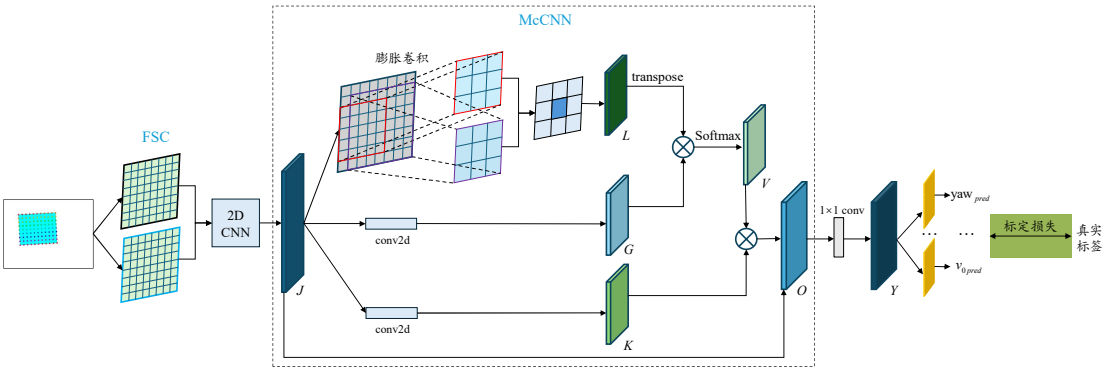


图 6-5 基于特征空间编码的深度标定网络 FSC-McCNN 架构

特征空间编码模块(FSC)：为了提高模型感知不同位姿特征点空间信息的能力，同时促进模型学习更多的相机参数细节，本节首先对输入的特征图谱进行空间编码。特征空间编码模块旨在使模型能更好的识别和表征特征点的位置空间，最终提高相机标定过程的性能。

将输入数据的维度定义为 $\widehat{F}\in\mathbb{R}^{W*H}$，然后分别在 X 和 Y 维度上对输入特征进行空间编码：

$$S_X(\widehat{F})=\begin{bmatrix} s_x^{(1,1)} & s_x^{(1,2)} & \cdots & s_x^{(1,H)} \\ s_x^{(2,1)} & s_x^{(2,2)} & \cdots & s_x^{(2,H)} \\ \cdots & \cdots & \cdots & \cdots \\ s_x^{(W,1)} & s_x^{(W,2)} & \cdots & s_x^{(W,H)} \end{bmatrix}\in\mathbb{R}^{W*H} \tag{6-21}$$

$$S_Y(\widehat{F})=\begin{bmatrix} s_y^{(1,1)} & s_y^{(1,2)} & \cdots & s_y^{(1,H)} \\ s_y^{(2,1)} & s_y^{(2,2)} & \cdots & s_y^{(2,H)} \\ \cdots & \cdots & \cdots & \cdots \\ s_y^{(W,1)} & s_y^{(W,2)} & \cdots & s_y^{(W,H)} \end{bmatrix}\in\mathbb{R}^{W*H} \tag{6-22}$$

式(6-21)-(6-22)中，s_x 和 s_y 分别表示的是沿着 X 和 Y 方向排列的不同特征元素，其中的每一个特征元素都被唯一地映射到空间域中相应的像素点坐标。

基于上述特征编码，可以构建输入合成数据的多尺度特征空间编码，即：

$$S(\widehat{F})=\left\{S_X(\widehat{F});S_Y(\widehat{F})\right\}\in\mathbb{R}^{W*H*2}. \tag{6-23}$$

多通道卷积神经网络模块(McCNN): 为了增强深度标定网络对 FSC 模块的适应性，并使模型能更深入地挖掘相机参数信息，本节引入了一个多通道卷积神经网络模块 McCNN，如图 6-5 中间部分所示。McCNN 模块包括三个 CNN 通道，第一个通道利用膨胀卷积在不改变参数量的情况下扩大卷积核的感受野[198]。该通道可以感知更大范围的特征编码信息，使其能够更有效地挖掘潜在的成像信

中国知网 https://www.cnki.net

息，例如平面板位姿。膨胀卷积和二维卷积结合的方式使模型能够整合特征空间编码的全局和局部信息，从而提高相机参数预测的整体性能和准确性。

对于输入的特征空间编码 $S(\widehat{F})$，首先使用 2D CNN 进行初始特征提取：

$$J = conv_{2d}^{1}(S(\widehat{F})). \tag{6-24}$$

然后，使用多通道卷积网络来处理初始特征，如下所示：

$$\begin{cases} L = Dconv(J) \\ G = conv_{2d}^{2}(J) \\ K = conv_{2d}^{3}(J) \end{cases} \tag{6-25}$$

式(6-25)中，$Dconv(\bullet)$表示的是膨胀卷积块。

本节在进行相机参数预测任务中使用了两层膨胀卷积，膨胀率分别设置为 2 和 3。这种膨胀率设置是为了能够在避免过度稀疏采样的同时适当地扩展感受野，这有助于从特征图谱中准确提取和融合多尺度信息。此外，这样的膨胀率设置为模型训练提供了足够的空间覆盖和特征多样性，使模型能够更有效地捕获特征图谱中的多层次、多尺度信息。另一方面，使用两层膨胀卷积可以逐步扩大特征图谱的感受野，并逐步提取和融合更高层次的空间特征，而不会过度增加计算成本，这有利于快速准确地从平面板特征图中预测相机参数。对于其他两个卷积层，主要的参数设置为：卷积核尺寸设置为 3，步长设置为 1，填充项设置为 1，分组项设置为 1，偏置项设置为 True。

基于以上模型超参配置，最终的特征可以通过以下过程提取，即：

$$Y = conv_{1\times1}(J + K \otimes Soft\max(G \otimes Trans(L))) \tag{6-26}$$

式(6-26)中，$Softmax(\bullet)$和 $Trans(\bullet)$分别表示的是 Softmax 函数和转置操作。

最后，使用多个全连接层来解析相机的内外参数，即：

$$\left\{f_x, f_y, ..., \rho_z\right\} = FC(Y) \tag{6-27}$$

式(6-27)中，$FC(\bullet)$表示的是全连接层。其中，每个参数的输出对应于一个独立的全连接层，每个全连接层都有其独立的权重和偏置参数，这些参数在训练过程中会根据损失函数进行更新和优化。

通过上式求得左右相机外参 R_r、R_l、T_r、T_l 之后，即可求解双目相机外参:

$$R = R_r R_l^{-1}. \tag{6-28}$$

$$T = T_r - RT_l. \tag{6-29}$$

对于相机参数的预测，每个参数可能依赖于不同的特征组合。使用单独的全连接层可以为每个参数提供独立的特征整合路径，从而更准确地捕捉和整合与每

中国知网 https://www.cnki.net

个参数相关的特征。这种设计允许网络对每个参数进行针对性的处理，提高预测的准确性和鲁棒性。另一方面，使用单独的全连接层意味着每个相机参数都有其独立的参数集进行学习，这有助于网络更好地拟合数据，并减少不同参数之间的相互影响。

6.3 基于 FSC-McCNN 的浮选过程双目外参标定实现

6.3.1 基于标定损失解耦的 FSC-McCNN 模型训练

当使用单一架构来预测不同量级的参数时，平衡标定损失中的各个分量至关重要，这可以确保模型对某些个别参数的估计不会主导整体学习过程。其中，由于相机的内参和外参决定了相机坐标系中每个特征点的重建结果，因此在基于平面板图像的相机标定场景中，可以使用估计的相机参数和真实的相机参数的特征点投影坐标来进行参数优化。

将已知参数记作 M=[κ, O]，其中 O=[X, Y, Z]表示的是使用参数 κ 对特征点进行投影后的三维坐标。进一步地，可以得到模型输出的参数估计结果 M′=[κ', O']。然后，对于 n 个特征点，可以通过以上这两组参数的均方误差(MSE)计算得到标定损失，即：

$$\mathcal{L} = (\frac{1}{n})\sum_{i=1}^{n} MSE(\mathrm{M}, \mathrm{M}') . \tag{6-30}$$

为了解决任务平衡问题，上述标定损失通过使用单一指标来表示不同的误差。然而，在深度标定网络学习过程中同时预测多个相机参数存在一个挑战：潜在的误差传播，其中一个参数的误差可能通过标定损失反向传播到其他参数。为了解决这个问题，受文献[199]的启发，本文通过标定损失解耦操作来分别估计各个参数，即：

$$\begin{aligned}
\mathcal{L}_{f_x} &= \mathcal{L}((f_x, f_y^{GT}, u_0^{GT}, v_0^{GT}, \theta_p^{GT}, \theta_y^{GT}, \theta_r^{GT}, \\
&\quad \rho_x^{GT}, \rho_y^{GT}, \rho_z^{GT}, X^{GT}, Y^{GT}, Z^{GT}), \mathrm{M}) \\
\mathcal{L}_{f_y} &= \mathcal{L}((f_x^{GT}, f_y, u_0^{GT}, v_0^{GT}, \theta_p^{GT}, \theta_y^{GT}, \theta_r^{GT}, \\
&\quad \rho_x^{GT}, \rho_y^{GT}, \rho_z^{GT}, X^{GT}, Y^{GT}, Z^{GT}), \mathrm{M}) \\
&\cdots \\
\mathcal{L}_Z &= \mathcal{L}((f_x^{GT}, f_y^{GT}, u_0^{GT}, v_0^{GT}, \theta_p^{GT}, \theta_y^{GT}, \theta_r^{GT}, \\
&\quad \rho_x^{GT}, \rho_y^{GT}, \rho_z^{GT}, X^{GT}, Y^{GT}, Z), \mathrm{M})
\end{aligned} \tag{6-31}$$

在此基础上，为每个参数引入了特定权重($\alpha_{fx}, \alpha_{fy}, \ldots, \alpha_Z$)，这些权重是在训练过程中自适应学习的。则解耦后模型训练的最终标定损失为：

$$\mathcal{L}^* = \alpha_{f_x}\mathcal{L}_{f_x} + \alpha_{f_y}\mathcal{L}_{f_y} + \alpha_{u_0}\mathcal{L}_{u_0} + \alpha_{v_0}\mathcal{L}_{v_0} + \ldots + \alpha_Z\mathcal{L}_Z . \tag{6-32}$$

中国知网 https://www.cnki.net

6.3.2 基于 FSC-McCNN 的浮选过程双目外参标定实现步骤

FSC-McCNN 属于深度神经网络模型，基于 FSC-McCNN 的浮选过程双目外参标定分为 FSC-McCNN 模型构建和浮选过程双目外参标定两个部分。其中，FSC-McCNN 模型构建是在增强的合成数据集上通过解耦的标定损失离线进行的，而浮选过程双目外参标定是在浮选现场采集的平面板图像上进行。

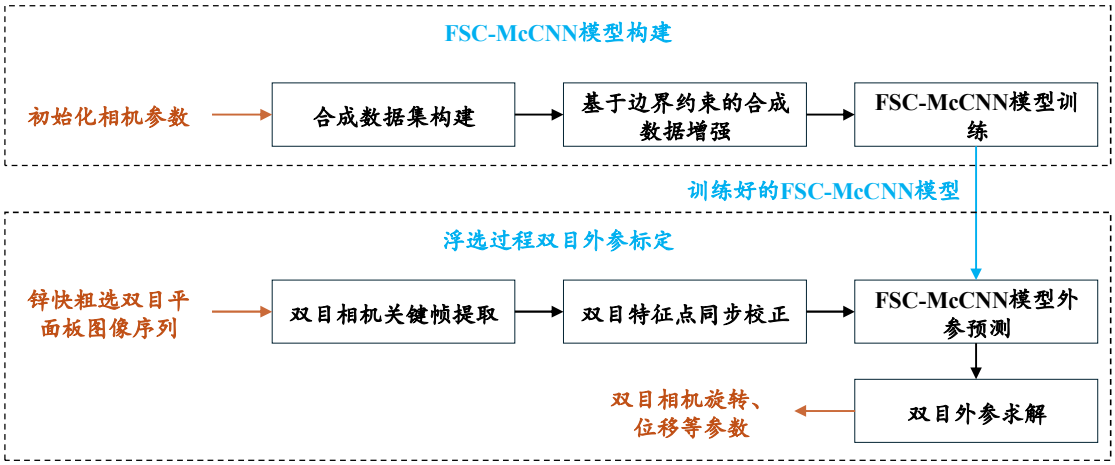


图 6-6 基于 FSC-McCNN 的浮选过程双目外参标定步骤

根据虚拟场景所构建的合成数据集，训练并建立性能良好的 FSC-McCNN 模型，实施步骤如图 6-6 的上图所示，具体过程描述如下：

(1) **合成数据集构建：**根据所构建的相机合成成像场景，按本文第 6.2.1 和 6.2.2 节的方法，使用初始化的相机参数生成无任何畸变的特征图谱，构建理想合成数据集。

(2) **基于边界约束的合成数据增强：**根据所构建理想合成数据集，按本文第 6.2.2 节的方法，在一定的边界约束条件下进行合成数据增强，构建最终的 FSC-McCNN 模型训练数据集。

(3) **FSC-McCNN 模型训练：**按图 6-5 建立 FSC-McCNN 网络框架，并采用标定损失解耦方法在所构建的数据集上训练，按式(6-30)计算模型训练损失，通过不断训练和迭代选择最佳的模型超参，从而构建最优的深度标定网络模型。

浮选过程双目外参标定通过已建立的最优 FSC-McCNN 模型，根据现场采集的平面板图像获得双目相机外参值，实施步骤如图 6-6 的下图所示，具体过程描述如下：

(1) **双目相机关键帧提取：**对于输入的锌快粗选双目平面板图像序列，使用本文第 4 章所述的图像质量评价方法计算图像评分，然后使用图像序列质量评分最大的双目帧序列作为双目相机外参关键帧。

中国知网 https://www.cnki.net

(2) **双目特征点同步校正：**对于双目相机外参关键帧，使用本文第 5 章所述的双目特征点同步校正方法进行特征点优化，以获取时间同步的左右相机特征匹配点。

(3) **FSC-McCNN 模型外参预测：**对于输入的左右相机特征匹配点，分别使用已训练好的 FSC-McCNN 模型进行相机参数预测，以得到每帧平面板图像对应的旋转向量、位移向量等参数。

(4) **双目外参求解：**使用 FSC-McCNN 模型预测得到左右图像外参之后，综合左右匹配视图的外参求解双目相机之间的相对位置和姿态。

6.4 基于 FSC-McCNN 的双目外参标定效果验证

6.4.1 实验数据集、模型性能评估及对比模型

本节分别在虚拟数据集和真实泡沫浮选数据集上进行了实验评估，详细信息如下所示。

虚拟数据集：为了全面评估所提出的深度标定网络 FSC-McCNN 的性能，本节进行了大量虚拟仿真实验，主要使用本文第 6.2 节所构建的合成数据集。其中，所生成数据的图像尺寸设置为 640*480 像素，并设置标定对象的特征点数目为 11*9。此外，将初始化参数设置为 κ=[415,415,320,240,-90,0,0,50,40,220]，其中每个参数的边界约束范围设置为[Δs1, Δs2,…, Δs10]=[15,15,10,10,10,10,10,40,40,20]。在此基础上，按本文第 6.2 节的方法可以获得合成增强数据集。

泡沫浮选数据集：与第 5 章类似，本章所使用的泡沫浮选数据集来自某铅锌浮选厂，相机型号为 Manta G-145C，图像分辨率为 1388*1038 像素。不同的是，本节针对相机焦距变化的情况进行了数据采集，在图像采集过程中使用相机自动聚焦模式进行拍摄，使得焦距存在一定范围的波动，然后本节分别在固定焦距和焦距变化的情况下进行了相机标定对比实验。

模型性能评估：本章所使用的标定损失是用开源深度学习框架 Pytorch 实现和训练的。此外，所有对比模型都在相同的硬件配置和工作条件下进行训练(即，操作系统：Windows 11，编程平台：Pycharm，CPU：Intel I7-9700，RAM：64 GB，GPU：GeForce RTX 2080)，并在 MSE 损失函数上使用 ADAM 优化器[200]进行了 200 次迭代，学习率为10^{-3}。

在对比实验中，虚拟数据集具备相机内外参数的真实标签。因此，本节使用参数估计值与真实值之间的差异作为性能评估指标，如下所示：

$$\Delta FL = \left\| FL_{GT} - FL_{est} \right\|_2 \tag{6-33}$$

$$\Delta PP = \left\| PP_{GT} - PP_{est} \right\|_2 \tag{6-34}$$

中国知网 https://www.cnki.net

$$\Delta R = \cos^{-1}\left(\frac{Tr(R_{GT}R_{est}^{T})-1}{2}\right) \tag{6-35}$$

$$\Delta T = \left\|T_{GT} - T_{est}\right\|_2 \tag{6-36}$$

式(6-33)-(6-36)中，FL_{GT}，PP_{GT}，R_{GT}和 T_{GT}分别表示主点、焦距、旋转矩阵和位移矩阵的真实值，FL_{est}，PP_{est}，R_{est}和 T_{est}分别表示主点、焦距、旋转矩阵和位移矩阵的估计值。在虚拟仿真实验中，所有方法均使用 20 次重复实验的平均值作为最终结果。

上述性能评估指标可以分为内参评估指标(即 ΔFL 和 ΔPP)和外参评估指标(即 ΔR 和 ΔT)。其中，内参评估指标主要通过计算内参估计值与真实值之间的差异来评估标定方法的准确性。相机的内参差异越小，表明标定精度越高。此外，相机的外参差异越小，表明标定方法在空间定位上的精度越高，这有助于更准确地追踪泡沫轨迹。

对比模型：在实验室环境和真实泡沫浮选环境的对比实验中，使用了四种相机标定模型，包括 CFS-CC 方法[159]、KFS-WNTD 方法[156]、张氏标定法[157]和所提方法。

6.4.2 FSC-McCNN 的有效性验证

为了评估所提 FSC-McCNN 模型的性能，本节进行了 FSC-McCNN 的有效性验证实验。所使用的对比算法包括密集连接层(DL)、多层感知机(MLP)、长短期记忆网络(LSTM)、残差网络(ResNet)、自编码器(AutoEncoder)、Kolmogorov-Arnold 网络(KAN)[201]、Transformer 和所提 McCNN 模型。

为了确保对比实验的公平性，将 FSC 模块整合到了所有对比模型中。然后在增强的合成数据集上进行了实验，最终实验结果如表 6-1 所示。

表 6-1 FSC-McCNN 的有效性验证(粗体表示最优的结果，下划线表示次优结果)

对比模型	$\triangle FL$	$\triangle PP$	$\triangle R$	$\triangle T$
FSC-DL	34.23	17.82	11.71	10.63
FSC-MLP	26.32	19.76	7.47	8.15
FSC-LSTM	5.48	1.59	1.73	1.31
FSC-ResNet	6.42	2.38	2.69	1.84
FSC-AutoEncoder	<u>3.65</u>	1.47	<u>0.83</u>	0.97
FSC-KAN	3.69	<u>1.34</u>	1.15	<u>0.91</u>
FSC-Transformer	4.84	1.62	1.77	1.47
FSC-McCNN	**1.83**	**1.06**	**0.35**	**0.42**

从表 6-1 可以观察到，与其他深度学习模型相比，DL 和 MLP 的性能相对较差。此外，与 LSTM 和 ResNet 相比，AutoEncoder 和 KAN 展现出更小的整体标

中国知网 https://www.cnki.net

定误差。值得注意的是，所提 FSC-McCNN 模型优于其他几种对比模型，这证明了所提深度标定网络在相机标定过程的适应性和有效性。

6.4.3 双目平面板图像外参标定虚拟仿真实验

在无噪声合成数据集的性能验证：在本小节中，在无任何噪声干扰的原始合成数据集上进行了对比实验，实验所使用的相机标定方法包括 CFS-CC 方法、KFS-WNTD 方法、张氏标定法和所提 FSC-McCNN 方法。其中，张氏标定法和 KFS-WNTD 方法需要从合成数据集中随机选择多幅图像来完成标定操作。所有比较方法的标定结果如表 6-2 所示。从表 6-2 可以发现，这四种方法的相对误差都相对较低。这说明所使用的对比方法在处理适合相机标定的无噪声图像数据集时都展现了优良的性能。

表 6-2 在无噪声合成数据集的性能验证

参数类型	f_x (pixels)	f_y (pixels)	u_0 (pixels)	v_0 (pixels)
真实值	420	420	320	240
CFS-CC	420.43	420.35	319.73	239.69
相对误差	0.10%	0.08%	-0.08%	-0.13%
KFS-WNTD	420.51	420.28	320.25	240.28
相对误差	0.12%	0.07%	0.08%	0.12%
张氏标定法	420.63	420.48	320.39	240.33
相对误差	0.15%	0.11%	0.12%	0.14%
所提方法	420.35	420.29	320.21	240.18
相对误差	0.08%	0.07%	0.07%	0.08%

在有噪声合成数据集的性能验证：本节实验在有噪声干扰的合成数据集上进行了对比实验，主要包括整体性能评估、相机焦距固定时的标定误差分析和相机焦距变化时的标定误差分析三个部分。

整体性能评估：为了更有效地评估 FSC-McCNN 模型的鲁棒性，本节实验在合成数据集中特征点的 x 和 y 坐标上添加了均值为 0、标准差为 {0,0.2,0.4,0.6,0.8,1.0,1.2,1.4,1.6}像素的高斯噪声，这些噪声均匀分布。随后，分别使用包括 CFS-CC 方法、KFS-WNTD 方法、张氏标定法和所提 FSC-McCNN 方法对有噪声的合成数据集进行标定，然后分析不同噪声条件下所有方法的标定误差，实验结果如图 6-7 所示。从图 6-7 可以发现，在噪声强度较低时，所有对比方法均表现出良好的鲁棒性。然而，随着噪声强度的增加，标定误差会在一定程度上增大，进而导致鲁棒性下降。在这些方法中，FSC-McCNN 模型在主点、焦距和旋转向量标定方面表现最佳。具体而言，在处理噪声影响方面，FSC-McCNN 模型展现出了比其他几种对比模型更出色的稳定性，这可能是由于合成

中国知网 https://www.cnki.net

数据增强模块强化了模型对噪声环境的适应性和鲁棒性。

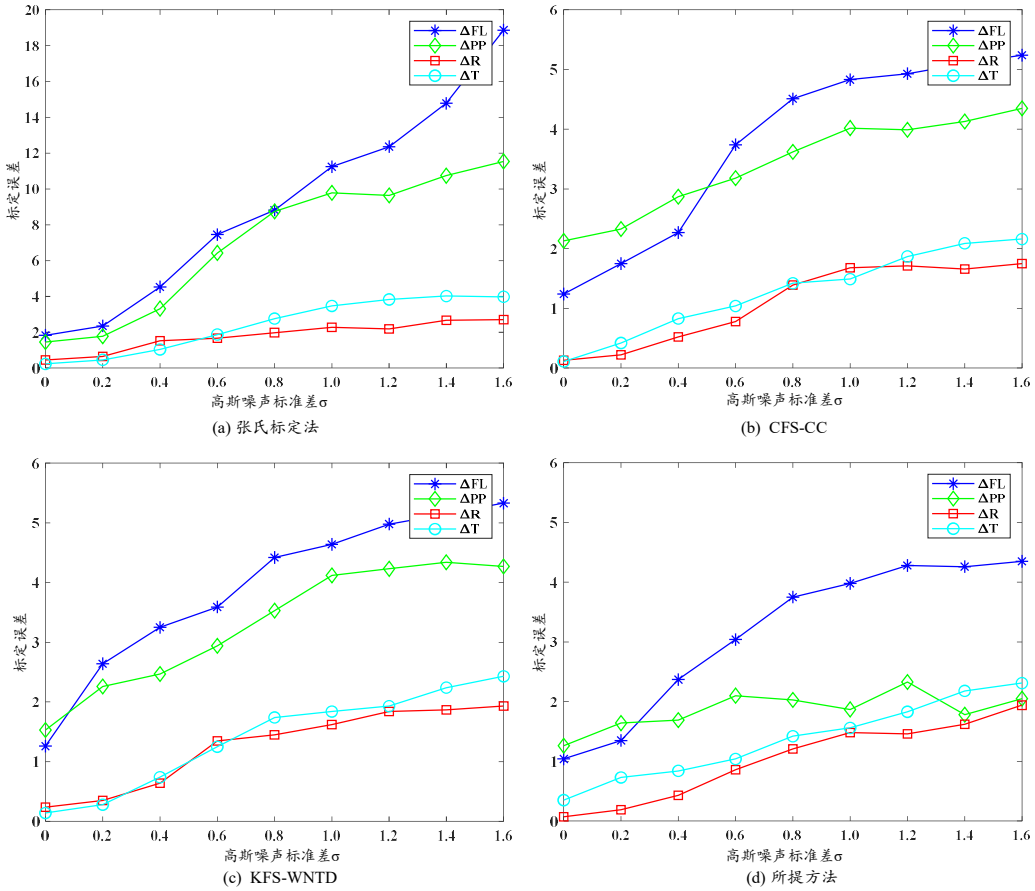


图 6-7 不同模型在有噪声合成数据集的性能比较

相机焦距固定时的标定误差分析：在进行相机焦距固定和变化时的模型标定误差分析过程中，使用高斯噪声标准差为 1.0 的合成数据集。本节使用焦距固定时所采集的合成平面板图像进行对比分析，即在图像采集过程中仅改变了旋转和位移两个外参指标。此外，本节还设计了一个包含位姿质量较差图像的对比实验，位姿质量较差图像指的是该图像的平面板位姿与已选取的图像位姿高度相似的情况。为了便于比较，设置了多个特征图集合，每个特征图集合包含八帧平面板图像，其中特征图集合 6 包含 3 帧位姿质量较差图像且特征图集合 7 包含 5 帧位姿质量较差图像，然后取所有图像的平均标定误差作为最终结果。实验结果如表 6-3 所示，图中粗体表示最优的结果，下划线表示次优结果。基于表 6-3 的结果，可以得出以下结论：

(1) 在相机焦距固定时，即使在相机外参等其他参数条件变化的情况下，所提方法仍然表现出较低的标定误差。

(2) 所提方法的标定结果稳定，CFS-CC 方法的误差波动情况与所提方法近似，整体误差明显低于 KFS-WNTD 方法和张氏标定法。

中国知网 https://www.cnki.net

(3) 当存在 3 个位姿质量较差图像时，KFS-WNTD 方法和张氏标定法的内外参标定误差较大，且在存在大量位姿质量较差图像时这两种方法可能无法正常标定。然而，所提方法不受平面板位姿质量的影响，即使在存在大量位姿质量较差图像的情况下也能获得较好的标定结果，在这方面所提方法明显优于上述方法。

表 6-3 相机焦距固定时的不同模型标定误差分析

对比模型	标定误差	特征图谱集合						
		1	2	3	4	5	6	7
张氏标定法	△*FL*	11.2	9.76	10.4	9.29	14.7	14.4	N/A
	△*PP*	8.58	8.42	12.8	9.73	9.65	11.8	N/A
	△*R*	1.58	2.72	3.41	2.26	2.88	2.79	N/A
	△*T*	3.46	3.61	4.66	3.51	3.82	3.76	N/A
KFS-WNTD	△*FL*	4.73	5.02	4.87	5.43	5.22	9.63	N/A
	△*PP*	3.77	3.85	3.92	4.23	3.98	10.5	N/A
	△*R*	2.03	2.45	2.17	1.95	2.26	3.75	N/A
	△*T*	1.86	2.63	1.95	2.35	2.51	3.83	N/A
CFS-CC	△*FL*	4.85	4.64	5.23	5.17	4.83	8.94	7.37
	△*PP*	4.06	3.79	4.23	3.36	3.85	5.74	5.68
	△*R*	1.68	1.73	<u>1.32</u>	1.77	1.69	1.85	1.93
	△*T*	1.51	<u>1.45</u>	1.96	1.72	1.63	2.57	2.48
FSC-McCNN	△*FL*	**3.86**	4.28	4.31	4.43	<u>3.97</u>	4.25	4.18
	△*PP*	2.41	<u>1.57</u>	**1.39**	1.86	2.53	2.37	2.06
	△*R*	1.53	1.76	**1.02**	1.34	1.64	1.58	1.61
	△*T*	**1.27**	1.55	2.23	1.65	1.49	2.42	2.25

相机焦距变化时的标定误差分析：本节针对相机焦距变化场景进行了标定误差分析。如前文所述，所提 FSC-McCNN 模型能够在一定的边界约束内预测相机参数，从而允许对具有不同焦距的平面板图像进行直接标定。相比之下，KFS-WNTD 方法和张氏标定法并未专门设计用来解决这一挑战，因此这两种方法对焦距变化的平面图像进行标定时可能出现较大误差。不同模型的标定实验结果如表 6-4 所示，图中粗体表示最优的结果，下划线表示次优结果。表 6-4 的结果表明 KFS-WNTD 方法和张氏标定法在解决因焦距变化和噪声导致的相机焦距问题时会产生的显著估计误差。相反，FSC-McCNN 在对焦距变化展现出了良好的鲁棒性，能够为相机内外参提供稳定的标定结果。这可能是由于 FSC-McCNN 可以更准确地捕捉不同姿态特征图谱之间的空间信息。当焦距发生变化时，特征图谱中的空间信息也会随之变化，而 FSC 模块凭借其强大的空间表征能力，能够更有效地适应这些变化。此外，通过利用 McCNN 模块进一步挖掘特征编码中的多维成像信息，可以提高焦距补偿的准确性。此外，FSC-McCNN 通过合成数据增强增加了训练数据的多样性，使模型能够学习到更具泛化性的特征。这允许深度标定模型在训练过程中逐渐适应焦距、视角等参数的变化。同时，这也进一步提

中国知网 https://www.cnki.net

高了模型对未知数据的适应能力，使其在焦距变化、相机视角变化和光照强度变化等特定条件下展现出更好的标定性能。

表 6-4 相机焦距变化时的不同模型标定误差分析

对比模型	标定误差	特征图谱集合				
		1	2	3	4	5
张氏标定法	△*FL*	36.32	49.64	40.28	37.68	54.75
	△*PP*	9.34	11.02	10.62	9.72	11.63
	△*R*	2.51	2.25	1.88	1.93	2.12
	△*T*	3.73	4.42	4.24	4.19	3.57
KFS-WNTD	△*FL*	25.32	16.43	17.58	20.74	19.66
	△*PP*	7.57	7.89	9.73	8.28	8.51
	△*R*	2.38	2.33	1.89	2.34	2.07
	△*T*	4.02	4.37	3.96	4.25	3.93
CFS-CC	△*FL*	4.67	5.52	5.25	4.87	4.74
	△*PP*	3.75	3.69	3.87	3.91	3.73
	△*R*	1.57	1.74	1.78	1.61	1.89
	△*T*	**1.53**	1.85	2.07	1.98	1.94
FSC-McCNN	△*FL*	4.45	4.37	**3.66**	5.04	4.07
	△*PP*	**1.71**	2.13	2.04	1.89	2.28
	△*R*	1.66	1.59	**1.53**	1.62	1.74
	△*T*	1.72	1.63	1.82	2.15	2.09

6.4.4 双目平面板图像外参标定工业应用实验

本节在泡沫浮选场景下进行了双目相机标定工业应用实验，在浮选过程数据集采集过程中相机位置固定，浮选泡沫液位波动范围适中。根据前文描述，在离线训练好深度标定网络之后，使用训练好的 FSC-McCNN 分别对焦距固定和焦距变化两种情况的真实泡沫数据进行标定，详细信息如下所示。

焦距固定时的相机参数标定结果对比：在本节实验的数据采集过程中，双目相机焦距保持不变，随后随机选择样本进行参数标定，并使用 20 次实验结果的平均值和标准差作为最终结果。和前文类似，所采用的对比模型为 CFS-CC 方法、KFS-WNTD 方法、张氏标定法和 FSC-McCNN 方法，左相机实验结果如表 6-5 所示。根据表 6-5，可以得出以下结论：

(1) 在相机焦距固定的情况下，所有方法均成功完成了工业浮选过程的相机标定任务，且取得了较为接近的标定结果。

(2) FSC-McCNN 模型在预测焦距和主点时多次标定的标准差较小，展现出良好的稳定性。

(3) CFS-CC 方法标定标准差较大，表明其所得预测参数波动较大，这可能是由于浮选泡沫背景产生的干扰所致。

(4) KFS-WNTD 方法展现出良好的标定稳定性，但该方法需要使用更多的标定图像，并且对平面板的姿态提出了更严格的要求。

中国知网 https://www.cnki.net

表 6-5 焦距固定时的相机参数标定结果对比(粗体表示标准差)

对比模型	参数	标定结果
FSC-McCNN	FL	(4139.3±**7.343**, 4136.9±**6.897**)
	PP	(692.5±**3.426**,526.3±**4.084**)
CFS-CC	FL	(4136.7±**10.469**, 4136.7±**10.469**)
	PP	(688.6±**7.471**,525.5±**6.953**)
KFS-WNTD	FL	(4144.8±**7.785**, 4139.5±**7.592**)
	PP	(702.2±**4.647**,532.6±**3.873**)
张氏标定法	FL	(4143.6±**8.279**,4137.4±**8.689**)
	PP	(706.3±**4.185**,529.7±**4.972**)

此外，在双目相机异步拍摄的情况下，为了分析使用本文第五章所提的双目特征点校正方法(记作 CHO-CSC)对本章所提方法的贡献，分别在单独使用 CHO-CSC、单独使用 FCS-McCNN 和级联使用两种方法的情况下进行了对比实验，使用平均重构误差作为评估指标，实验结果如表 6-6 所示。从表 6-6 可以发现，级联使用两种方法的平均重构误差和方差较单独使用任意一种方法时均有所降低，表明在泡沫浮选场景的相机外参标定过程中，同时使用本文第五章和第六章的方法可以产生协同效应，从而提升整体标定性能。

表 6-6 双目校正方法与 FSC-McCNN 的协同效应评估

对比模型	对比参数	平面板位姿				
		1	2	3	4	5
单独使用 CHO-CSC	平均重构误差	1.77	1.92	1.71	1.79	1.67
	方差	0.115	0.131	0.109	0.113	0.121
单独使用 FSC-McCNN	平均重构误差	1.81	1.74	1.73	1.81	1.65
	方差	0.102	0.097	0.105	0.103	0.099
级联使用两种方法	平均重构误差	1.48	1.51	1.52	1.43	1.46
	方差	0.095	0.092	0.101	0.084	0.091

焦距变化时的相机参数标定结果对比：在本节实验中相机设置为自动聚焦模式，并采集不同焦距下的平面板图像。和前文类似，分别采用四种对比方法对焦距变化时的平面板图像进行相机标定，左相机实验结果如表 6-7 所示。根据表 6-7 的结果可以发现，当焦距变化时 FSC-McCNN 模型和 CFS-CC 方法始终能够稳定地估计参数，并能对每帧图像解析出内参。相比之下，即使所使用的平面板图像集合中存在不同焦距的图像，KFS-WNTD 方法和张氏标定法在进行标定时仅提供一个内参预测值，使得这两种方法在焦距变化场景下易出现显著误差。例如，这两种方法的主点标定结果分别为(625.7, 532.6)和(663.8, 527.3)，与预期值(694, 519)存在明显偏差。以上结果表明 FSC-McCNN 模型在工业浮选环境中展现了优越的性能，对焦距变化具有良好的鲁棒性。

中国知网 https://www.cnki.net

表 6-7 焦距变化时的相机参数标定结果对比

对比模型	参数	平面板位姿序号				
		1	2	3	4	5
FSC-McCNN	FL	(4145.3, 4144.8)	(4140.5, 4141.7)	(4105.2, 4104.6)	(4101.5, 4102.9)	(4111.8, 4105.1)
	PP	(692.7,520.1)	(695.3,521.9)	(691.8,522.4)	(696.4,518.4)	(698.7,519.5)
	θ	(-86.42, 5.34, -5.15)	(-94.71,-7.53, -10.42)	(-88.27,-7.38, -4.75)	(-91.98,-0.72, -1.36)	(-90.04,8.33, -4.66)
	ρ	(74.23,53.37, 783.87)	(26.28,29.63, 712.36)	(56.15,39.03, 860.28)	(15.82,27.38, 783.29)	(10.32, -9.23, 862.75)
CFS-CC	FL	(4134.5, 4134.5)	(4149.8, 4149.8)	(4112.6, 4112.6)	(4096.3, 4096.3)	(4115.7, 4115.7)
	PP	(685.8,521.7)	(685.8,521.7)	(685.8,521.7)	(685.8,521.7)	(685.8,521.7)
	θ	(-84.86, 4.82, -5.61)	(-90.81, -10.63,-9.98)	(-90.72, -6.38, -4.62)	(-88.74, -1.63, -1.08)	(-89.92, 9.74, -3.85)
	ρ	(70.59,54.82, 788.75)	(30.74,28.49, 703.64)	(58.83,43.71, 862.57)	(13.72,30.75, 790.32)	(10.53, -8.87, 859.38)
KFS-WNTD	FL	(4087.6, 4093.7)	(4087.6, 4093.7)	(4087.6, 4093.7)	(4087.6, 4093.7)	(4087.6, 4093.7)
	PP	(663.8,527.3)	(663.8,527.3)	(663.8,527.3)	(663.8,527.3)	(663.8,527.3)
	θ	(-78.53, 4.74, -8.01)	(-88.75, -8.68, -9.96)	(-84.62, -6.17, -6.25)	(-89.63, -3.36, -0.71)	(-94.72, 10.59, 2.62)
	ρ	(60.58,48.64, 791.97)	(13.52,26.78, 700.26)	(42.18,43.36, 858.53)	(4.96, 34.21, 789.04)	(26.27, 1.82, 847.06)
张氏标定法	FL	(4049.2, 4035.4)	(4049.2, 4035.4)	(4049.2, 4035.4)	(4049.2, 4035.4)	(4049.2, 4035.4)
	PP	(625.7,532.6)	(625.7,532.6)	(625.7,532.6)	(625.7,532.6)	(625.7,532.6)
	θ	(-80.42, 4.56, -7.83)	(-88.25, -9.15, -9.23)	(-84.45, -6.03, -6.43)	(-88.23, -3.72, -0.79)	(-95.53, 11.26, 2.35)
	ρ	(59.81,49.78, 791.32)	(12.64,26.35, 701.53)	(43.52,42.27, 858.70)	(4.63, 35.34, 788.26)	(24.51, 1.63, 847.27)

泡沫浮选过程相机标定鲁棒性评估：为了全面评估所提方法在各种复杂场景下的标定鲁棒性，在多种不同环境条件(即图像噪声、光照强度、泡沫浓度和相机安装角度)下进行了对比实验。由于当相机安装角度改变时，相机的外参也会随之改变，为了控制变量，本节实验仅对比焦距和主点。为了确保实验公平，采用原始图像与变化后图像的标定结果之间的差异作为评价指标。例如，当原始泡沫浓度为 1 时进行相机标定的结果为 S1，当泡沫浓度变化为 1.4 时进行重新标定所得结果为 S2，则使用 S1 和 S2 之间的差异作为实验结果，计算方式和式(6-33)类似。此外，本节所有对比实验均在固定焦距下进行，具体细节如下。

(1) 图像噪声鲁棒性评估：和前文类似，本节实验向原始泡沫图像特征点添加了均值为 0、标准差为{0.3, 0.5, 0.7, 0.9, 1.1, 1.3}的高斯噪声。然后使用以上四种对比方法分别求解原始泡沫图像和噪声退化图像的焦距和主点，各方法标定结果如图 6-8 所示。

中国知网 https://www.cnki.net

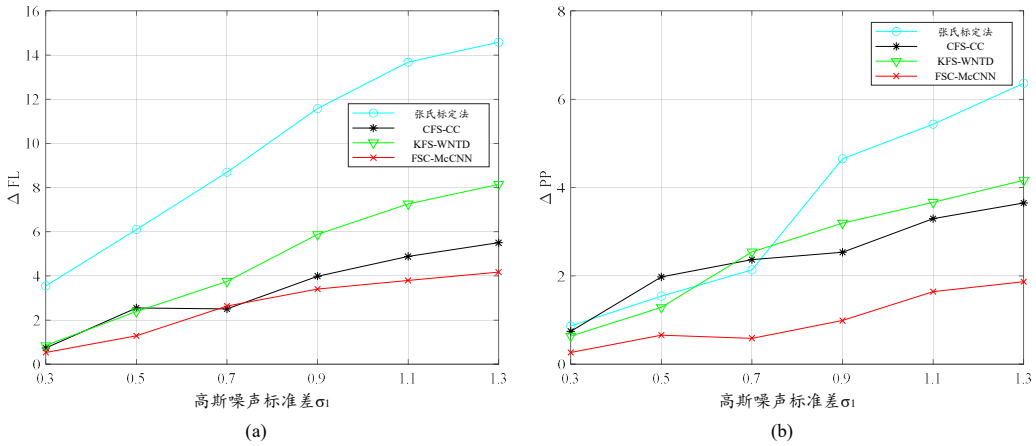


图 6-8 不同模型的泡沫图像噪声鲁棒性评估

从图 6-8 的结果可以观察到，随着噪声强度的增大，张氏标定法的标定结果显著退化，CFS-CC 方法和 KFS-WNTD 方法也出现了较大的误差。所提方法在焦距和主点的标定结果上表现出相对较小的差异，这表明在真实浮选场景中 FSC-McCNN 对于图像噪声具有良好的鲁棒性。

(2) 光照强度鲁棒性评估：在本小节实验中，使用伽马指数方法调整原始泡沫图像的光照强度，强度因子设置为{0.5, 0.7, 0.9, 1.1, 1.3}。然后进行了对比实验来评估所提方法的光照强度鲁棒性，实验结果如图 6-9 所示。

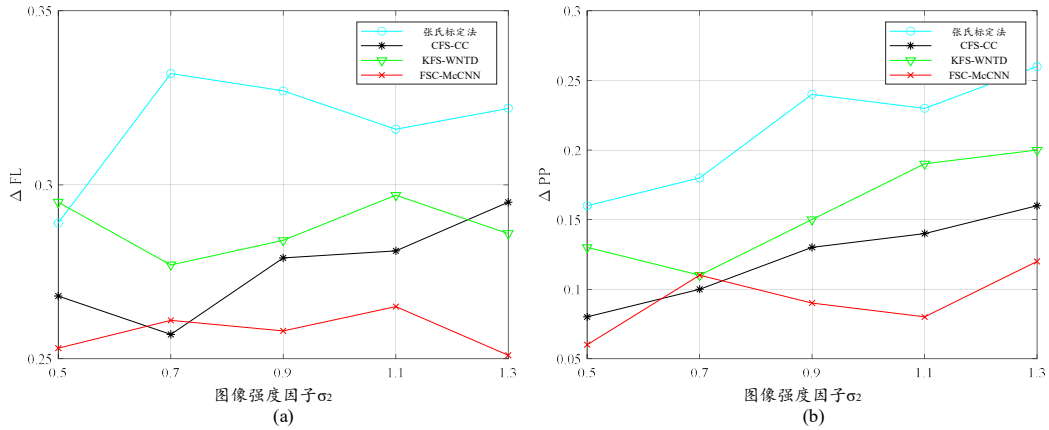


图 6-9 不同模型的泡沫图像光照强度鲁棒性评估

从图 6-9 可以观察到，随着光照强度的增加，KFS-WNTD 方法和张氏标定法的焦距退化并不显著，但主点的退化较为明显。此外，在所有对比方法中，FSC-McCNN 的标定结果退化程度最小，这表明 FSC-McCNN 模型对于光照变化具有良好的鲁棒性。

(3) 泡沫层品位鲁棒性评估：在本小节实验中，比较了几种方法在不同锌快粗选泡沫层品位下的标定鲁棒性。数据采集系统固定安装在锌快粗选槽上方，在

中国知网 https://www.cnki.net

固定焦距的情况下对不同泡沫层品位时的泡沫图像进行标定。所使用的原始泡沫图像对应的泡沫层品位为 1.1，而用于比较的其他泡沫层品位为{0.8, 1.0, 1.2, 1.4, 1.6}。泡沫层品位的差异可能导致液位波动和平面板拍摄姿态的变化。具体实验结果如图 6-10 所示。从图 6-10 可以发现，泡沫层品位变化并没有对这几种标定方法产生明显的影响。整体来看，FSC-McCNN 模型的标定结果退化程度最小，误差波动也较小，这表明其对于泡沫层品位变化具有良好的适应性。

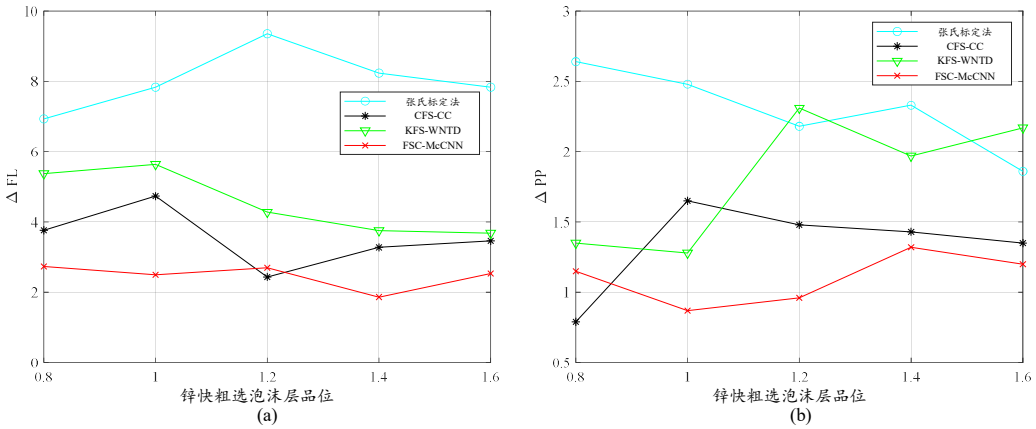


图 6-10 不同模型的泡沫层品位变化鲁棒性评估

(4) 相机安装角度鲁棒性评估：本小节实验评估了几种对比方法在不同相机安装角度下的标定稳定性。在保持相机焦距不变的情况下，对相机安装角度进行了调整，然后重新采集了平面板图像。之后使用几种对比方法分别对原始相机角度和安装角度变化后的平面板图像进行标定，实验结果如图 6-11 所示。

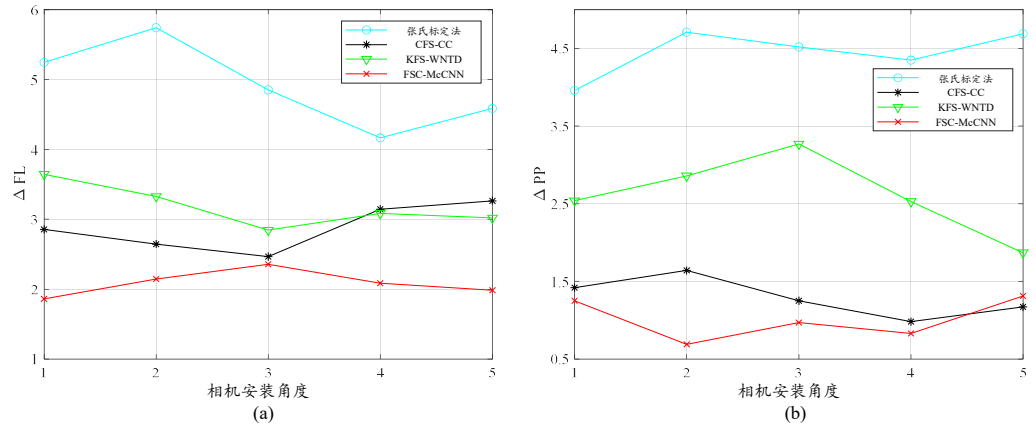


图 6-11 不同模型的相机安装角度变化鲁棒性评估

从图 6-11 可以发现，当相机安装角度发生变化时，KFS-WNTD 方法和张氏标定法标定结果退化明显。相比之下，CFS-CC 方法和 FSC-McCNN 方法标定结果退化较小，这表明所提方法在不同相机安装角度下具有良好的准确性和稳定性。

中国知网 https://www.cnki.net

泡沫浮选过程相机标定误差源分析：在真实泡沫浮选场景的相机标定过程中，上述几种对比方法均表现出了不同程度的误差，这些误差可能源自以下多个方面。

(1) 数据采集误差：平面板图像数据采集的质量直接影响标定结果。例如，如果捕获的图像包含噪声、模糊或畸变，这些误差将直接传递到特征图和最终的相机参数中。

(2) 模型泛化能力：在工业浮选过程的开放式场景中，光照条件、相机安装角度和入矿条件等因素可能会动态变化，这对模型的泛化能力提出了较高要求，而极端环境变化还可能导致标定结果中出现异常值。

(3) 不可控因素：在工业浮选过程中，振动和温度变化等环境因素可能导致图像采集异常，从而引入标定误差。

6.5 本章小结

本章提出了一种基于 FSC-McCNN 的浮选过程双目外参标定方法。首先，针对浮选过程液位波动、相机视角变化等情况，给出了基于 FSC-McCNN 的浮选过程双目外参标定框架。然后详细描述了相机参数初始化过程，并实现了基于边界约束的合成数据增强，在此基础上构建基于特征空间编码的深度标定网络 FSC-McCNN。之后，给出了基于 FSC-McCNN 的浮选过程双目外参标定步骤。最后，分别在虚拟仿真环境和真实浮选场景进行了对比实验，实验结果表明 FSC-McCNN 方法具有良好的标定精度和鲁棒性。

中国知网　https://www.cnki.net

第 7 章 泡沫浮选过程相机标定系统

本章结合第 2 章描述的泡沫浮选过程和相机标定原理，研发浮选过程相机内外参标定系统。并融入第 3 章~第 6 章所提出的理论和方法，对锌快粗槽双目采集系统的相机内外参数进行有效标定，在实际浮选数据采集过程得到了成功应用。本章将对该系统的功能需求、系统设计及应用进行介绍，并给出了泡沫浮选过程相机标定系统运行结果。

7.1 泡沫浮选过程相机标定系统功能需求

设计泡沫浮选过程相机标定系统的目的是获取高精度的双目相机内外参数，为后续的浮选槽表层泡沫三维重构提供支撑。结合泡沫浮选现场需求和数据分析过程需要，明确了泡沫浮选过程相机标定系统需要满足以下功能需求：

(1) 浮选泡沫双目视频采集及保存

能实时显示锌快粗槽的泡沫双目视频，以便观察公共视域和采集双目平面板图像。同时提供双目视频自动采集/手动采集功能选项，自动保存双目图像采集序号，自动检测左右图像特征点坐标并保存，双目相机曝光时间等参数可在系统界面中设置并可一键恢复默认设置。

(2) 失焦平面板图像复原及保存

为了提升相机参数标定精度和成功率，系统需具备失焦平面板图像复原功能。提供平面板图像自动复原/手动复原功能选项、一键恢复原始特征选项、显示左右图像原始特征点坐标及复原结果，并按图像序号进行保存。

(3) 泡沫视频图像关键帧提取

平面板图像质量直接影响相机标定结果，需对采集的左右相机泡沫视频图像提取平面板关键帧。提供平面板关键帧自动提取/手动提取功能选项，平面板关键帧序列组合数量可在系统进行设置，同时提供关键帧图像序号，对所提取的平面板关键帧图像进行显示。

(4) 相机内参标定及显示

具备相机内参标定功能，同时对左右相机的内参进行标定。提供左右相机内参自动标定/手动标定功能选项，显示用于内参标定的关键帧图像序列，设置相机内参保存路径，显示左右相机内参。

(5) 异步双目图像特征点校正及保存

在左右相机曝光时间设置差异较大的情况下，系统需具备异步双目图像特征点校正功能。提供双目相机图像特征点自动校正/手动校正功能选项，同时显示并保存校正前的双目视图特征点坐标及校正后的右视图特征点坐标。

中国知网 https://www.cnki.net

(6) 双目相机外参标定及显示

具备双目相机外参标定功能，提供双目相机外参自动标定/手动标定功能选项，显示用于双目外参标定的左右相机关键帧图像及对应的序号，显示并保存双目相机外参。

7.2 浮选过程相机标定系统设计与实现

7.2.1 硬件系统设计与实现

根据第 2.2.1 节所述的锌浮选过程相机标定环境和泡沫浮选过程相机标定系统需求，泡沫浮选过程相机标定硬件系统主要包括双目图像采集装置、工业交换机、标定设备和工业控制计算机四部分，如图 7-1 所示。

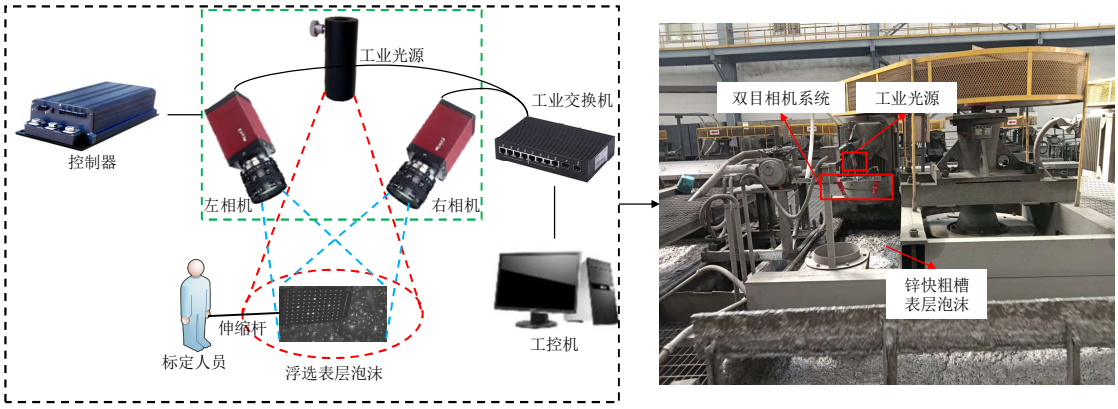


图 7-1 浮选过程相机标定硬件系统及现场环境

(1) 双目图像采集装置

双目图像采集装置是泡沫浮选过程相机标定系统的重要部分，主要用于拍摄锌快粗槽的表层泡沫，并将双目泡沫图像或视频实时传输给工业控制计算机进行保存或处理，以支持后续的相机标定和三维重建。由于工业浮选现场高温、高尘、外部环境光复杂，为了使双目图像采集装置较好的适应工业环境中的复杂条件，并提供高分辨率和高帧率的左右相机图像数据，双目相机及工业光源的安装角度和高度颇为重要。因此，设计了如图 7-1-b 所示的双目图像采集装置。为了平衡双目图像公共区域范围和左右视图清晰度，同时减少水汽、粉尘对工业相机的干扰，在该装置中左右相机分别以 30 度左右的倾斜角相对固定安装，横向安装距离约 25-35 厘米，距离泡沫表层的安装高度约 70-90 厘米，最高距离控制在一米以内。为了降低环境光影响、避免漫反射，工业光源以与地面垂直的角度安装于双目相机的正中间，安装高度较双目相机高约 20 厘米。

为了确保双目图像采集装置能清晰、实时的捕获左右视频图像，对工业相机、光学镜头和工业光源进行了如下配置：

中国知网 https://www.cnki.net

① 所配置的双目工业相机型号均为 Manta G-145C，该相机为低成本的千兆网口面阵相机，配备灵敏的 Sony ICX285 ExView HAD 传感器，有坚固的金属外壳。该工业相机支持自动增益、自动曝光、自动白平衡、可自动调整感兴趣区域。图像分辨率为 1388*1038 像素，像元尺寸 6.45μm，数据接口 GigE，彩色光谱，包含转接器的机械尺寸为 44 mm × 29 mm × 86.4 mm，重量约 200g。

② 所配置的光学镜头为 200 万像素抗振抗冲击镜头，型号为 Kowa LM25JCM-V，该镜头使用双向可调螺母代替传统螺丝，以紧密锁定对焦调节环的位置并避免螺丝松动现象，同时内部镜片通过强力粘合固定，以强化镜头的稳定性。

③ 所配置的工业光源为基于发光二极管的 LED 点光源，是一种小巧灵活、高亮度光源，使用非球面透镜，具有高透光率和耐热性，能够产生集中且均匀的光束，并将光线聚焦成一个小而明亮的光斑，具备高亮度、高效、节能、寿命长、响应快速、环保的特点，并可调节亮度以适应不同的光照需求。此外，结合光源控制器，可以实现工业光源的开关控制以及光强的无极调节。

使用上述工业相机、光学镜头和工业光源组建双目图像采集装置，可在一定范围内实现高精度、快速、连续的双目视频图像采集。此外，配备 GigE 数据接口的工业相机可直接与工业控制计算机通讯，不需要另设图像采集卡。工业控制计算机与交换机放置于监控室内，与双目图像采集装置的最大距离约 50 米，为提升信号强度和稳定性，信号传输电缆采用超六类屏蔽网线。

(2) 工业交换机

所配置的工业交换机是 TP-Link 8 口千兆工业级交换机，每个端口支持 10/100/1000Mbps 自适应速率，能满足高速数据传输需求，可通过网线为设备供电，简化布线，工作温度范围为-40°C 至 75°C，能适应恶劣工业环境，采用金属外壳和防护设计，具有强抗干扰和高可靠性，能满足工业环境的高稳定性需求。在工业浮选现场，将双目工业相机直接与工业交换机进行通讯连接，并连接工业控制计算机。

(3) 标定设备

如图 7-1 所示，所使用的标定设备包括伸缩杆和标定板。由于工业浮选现场不具备固定放置标定板的外在条件，同时为了避免标定操作人员接触浮选槽中的腐蚀性化学物质，确保人员安全并降低操作风险，使用伸缩杆控制标定板运动。伸缩杆由多节嵌套的杆体组成，通过手动或电动方式实现伸缩，可通过旋钮、卡扣锁定装置固定伸缩后的长度，确保标定板保持相对稳定。标定板面板采用氧化铝材质，漫反射不反光、不透明、不变形、可触水，采用具有极高表面平整度的玻璃基板，确保标定图案的几何精度，减少因标定板表面不平整导致的误差，同

中国知网 https://www.cnki.net

时玻璃基板具有较高的耐腐蚀性，能够适应温度变化，可满足工业浮选过程的标定需求。

(4) 工业控制计算机

在整个泡沫浮选过程相机标定系统中，工业控制计算机是核心设备，主要负责读取从双目图像采集装置传输过来的双目视频数据，并对这些双目数据进行处理和分析，通过已建立的双目相机内外参标定模型，实现泡沫浮选过程双目相机内外参的快速准确标定。工业控制计算机搭载了人机交互界面，对整个相机标定系统进行数据采集、数据处理、参数设置、内外参标定、数据显示和保存，所采用的操作系统为 Windows 11，RAM 为 64G，硬盘容量 3T，CPU 为 Intel I7-9700，GPU 为 GeForce RTX 2080。

7.2.2 软件系统设计与实现

根据上述相机标定系统功能需求，本节详细描述了基于加权关键帧与 FSC-McCNN 的相机标定系统设计与实现过程。其中，所使用的硬件系统如图 2-5 所示，系统软件设计如下所示。

基于加权关键帧与 FSC-McCNN 的泡沫浮选过程相机标定系统搭载在工业控制计算机上，所使用的操作系统为 Windows 11，软件开发平台为 Visual Studio 2022，开发语言为 C#，数据库使用 SQLServer2022。根据双目视觉系统采集的泡沫视频图像，使用已建立的相机内外参标定模型，对锌快粗槽所部署的双目相机求解内外参数，并在工控机上进行显示和保存，为后续的双目图像立体匹配和浮选工况识别提供数据支撑。图 7-2 展示了软件系统的主要构成，包括数据处理子系统和数据显示及导出子系统。

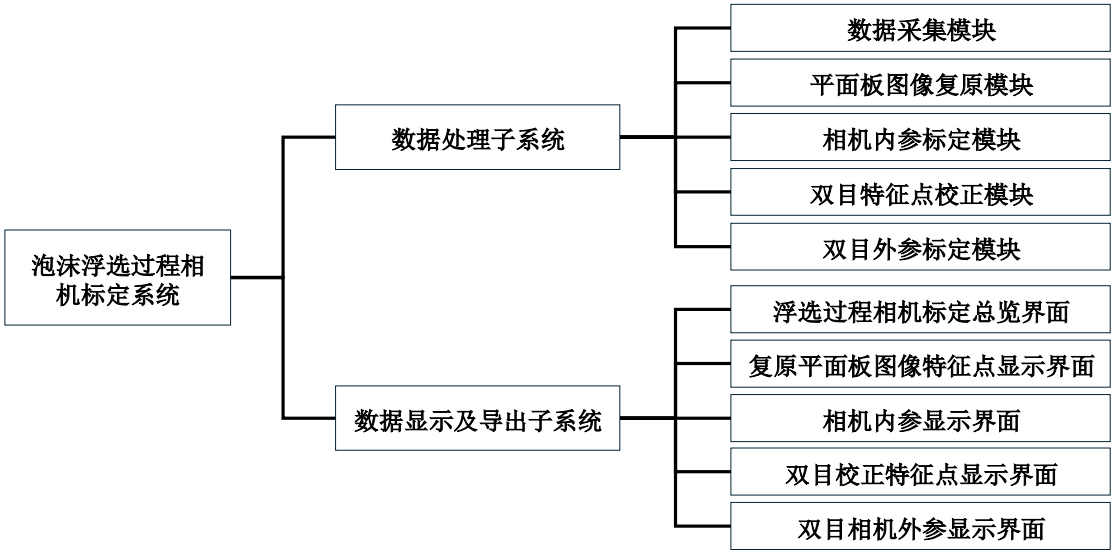


图 7-2 软件系统的主要构成

中国知网 https://www.cnki.net

(1) 数据处理子系统

数据处理子系统是相机标定系统中的核心部分，包含了本文第 3 章~第 6 章所提出的理论和方法。主要包括数据采集模块、平面板图像复原模块、相机内参标定模块、双目特征点校正模块和双目外参标定模块五个部分，各模块的详细信息如下所示。

数据采集模块采用 Vimba 软件开发工具包与双目工业相机建立连接，以控制相机并获取锌快粗槽实时拍摄的左右图像，并将所拍摄的图像进行保存。

平面板图像复原模块负责将失焦模糊的平面板图像进行复原，提取复原图像特征点坐标。平面板图像复原采用已训练好的 RPMU-Net 深度网络，模型构建及训练详情参见本文第 3 章。当选择自动复原选项时，首先对所采集的平面板图像进行模糊程度评估，对满足条件的图像进行自动复原操作，详情参见本文第 4.2.1 节。在进行图像复原操作后，使用 Hough 圆检测法提取复原图像的特征点坐标，用于相机内参标定。

相机内参标定模块负责求解双目相机的内参。首先，根据设定的平面板关键帧序列组合数量，采用图像质量评价方法对所采集的平面板视频图像提取关键帧序列，详情参见本文第 4.2 节。然后，基于平面板位姿差异求解每一组关键帧序列的权重，在此基础上计算单目相机的加权内参，详情参见本文第 4.3 节。

双目特征点校正模块负责在左右相机曝光时间差异较大的情况下，对所采集的左右平面板图像特征点进行同步校正。对于输入的左右泡沫视频图像，首先提取外参关键帧，详情参见本文第 5.2.1 节。当选择自动校正选项时，采用闭环混合优化方法对双目外参关键帧图像进行自动校正，详情参见本文第 5 章。在进行双目图像校正操作后，保存特征匹配点坐标，并用于相机外参标定。

双目外参标定模块负责求解双目相机外参。双目外参标定采用已训练好的深度标定网络 FSC-McCNN，模型构建及训练详情参见本文第 6 章。当选择自动标定选项时，使用 FSC-McCNN 模型预测校正后特征匹配点对应的相机外参，并转换为双目外参。

(2) 数据显示及导出子系统

数据显示及导出子系统与浮选过程相机标定软件使用者直接交互，主要包括浮选过程相机标定主界面、复原平面板图像特征点显示界面、相机内参显示界面、双目图像校正特征点显示界面和双目相机外参显示界面。

浮选过程相机标定主界面如图 7-3 所示。其中，左上部分实时显示双目相机在锌快粗槽的成像情况，右上部分显示了相机列表和视频图像自动保存/手动保存选项，当选择自动保存选项时，单个视频保存时长为 3 分钟，保存格式为 AVI 文件。在图 7-3 中间部分可进行双目相机的存图路径设置，用于自定义图像保存

中国知网 https://www.cnki.net

路径，同时可设置双目相机曝光时间，并配备了一键恢复按钮。此外，图像中下部分为系统功能区，包括平面板图像复原、相机内参标定、双目图像特征点校正和双目相机外参标定四个功能选项。在图 7-3 下方直观展示了锌浮选工艺流程和图像采集状态，其中图像采集序号为图像在当前视频中的序号。

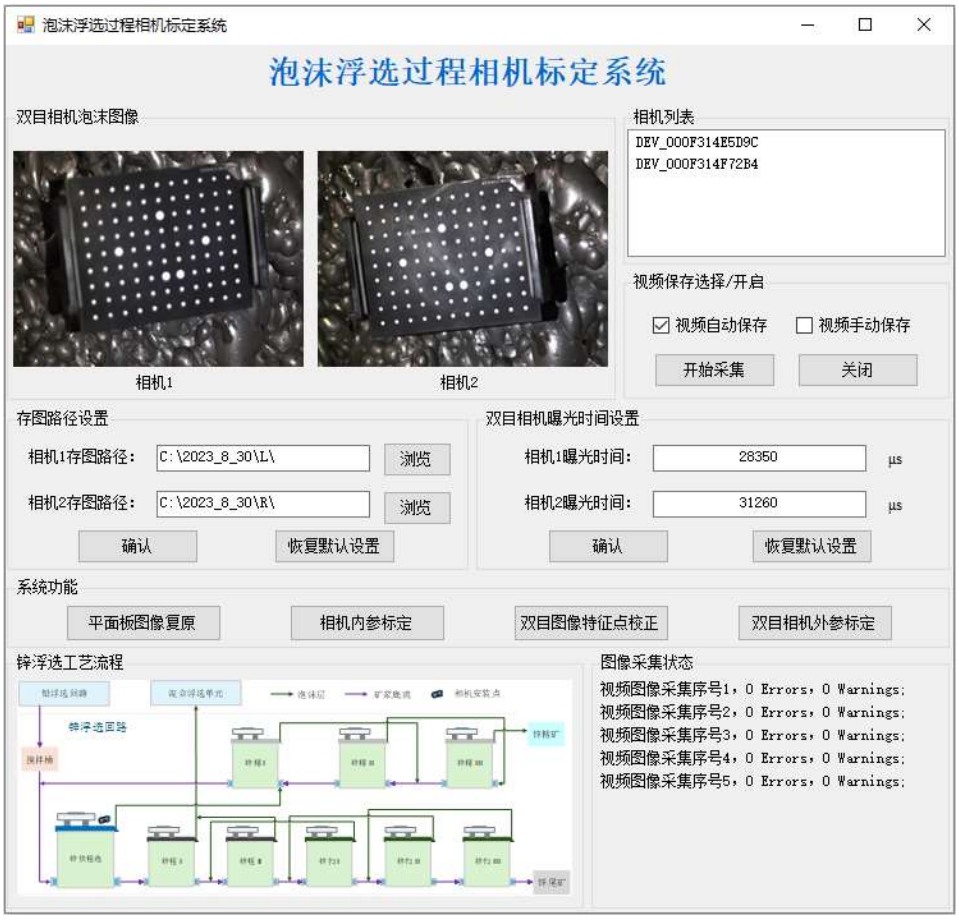


图 7-3 浮选过程相机标定主界面

复原平面板图像特征点显示界面如图 7-4 所示。其中，左上部分显示进行图像复原操作的双目图像及其对应的序号，右上部分可设置图像自动/手动复原。同时，可分别设置左右相机复原图像保存路径，并配备了一键恢复按钮。图像下方展示了双目相机复原平面板图像的特征点结果，可通过查看全部按钮检查所有的特征点坐标。此外，点击左上角的返回可回到主界面。

相机内参标定结果显示界面如图 7-5 所示。其中，图 7-5 上半部分显示了从双目视频中所提取的关键帧图像序列，关键帧序列组合数量和单个序列中的图像数量等参数可在图像左下角设置。同时，可设置相机内参标定模式为自动标定或手动选择图像进行标定，在图像中间部分可对左右相机内参保存路径进行设置。此外，在图像的下半部分可以查看双目相机的内参标定结果，包括焦距、主点和畸变系数。

中国知网 https://www.cnki.net

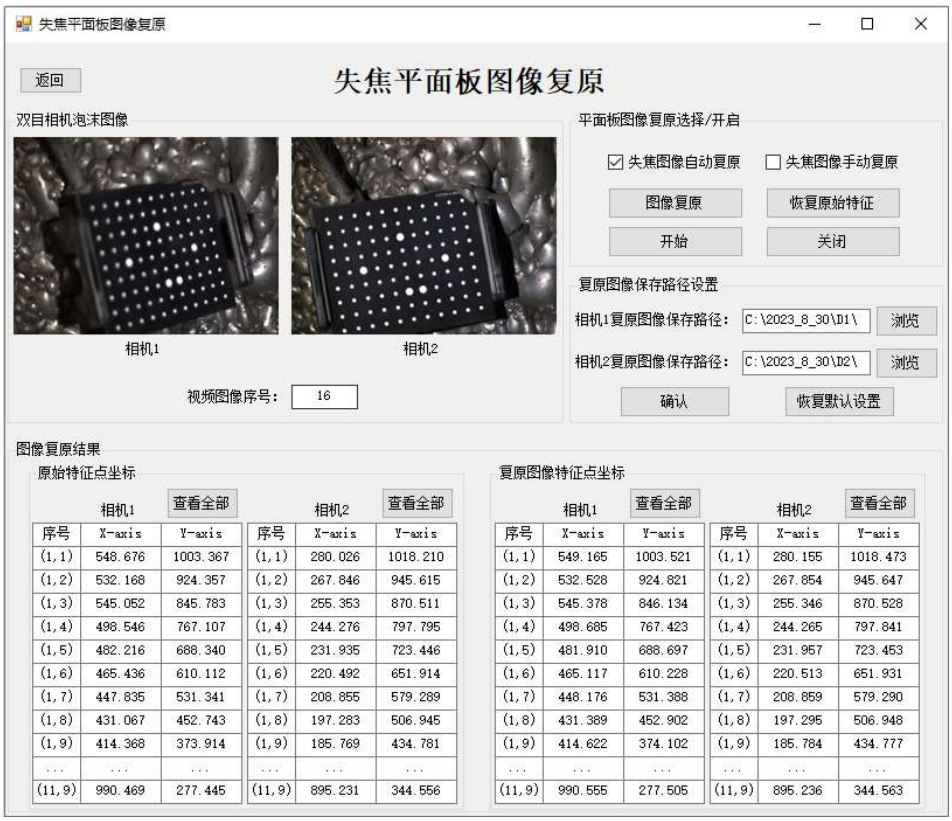


图 7-4 复原平面板图像特征点显示界面

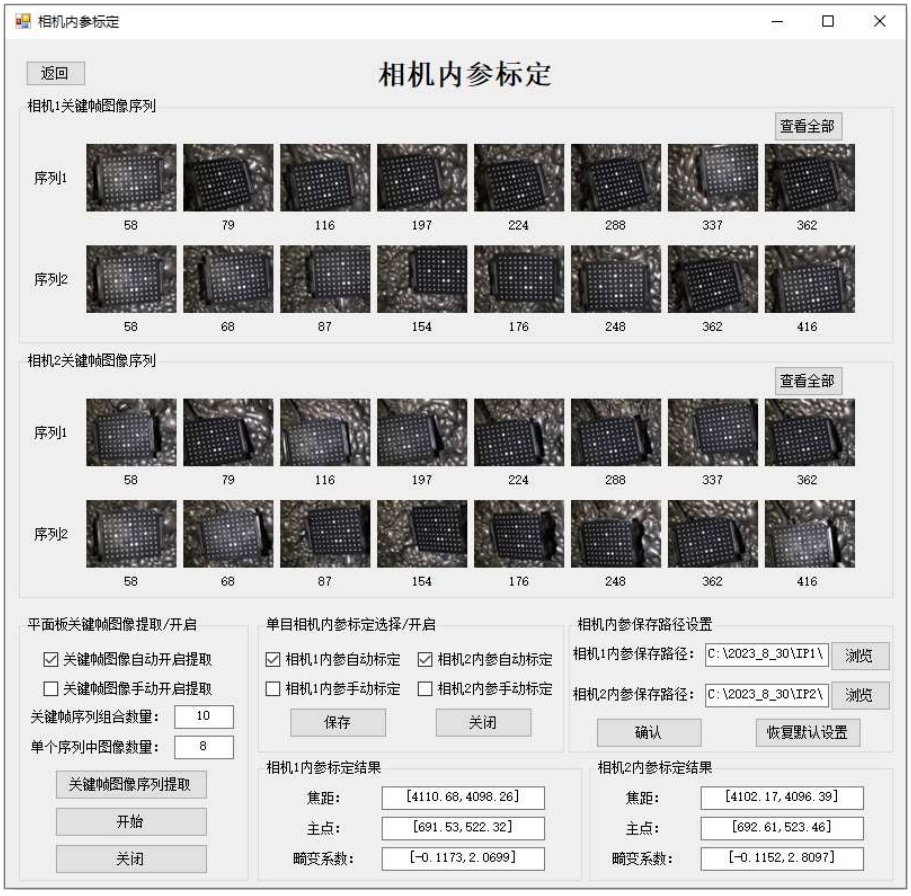


图 7-5 相机内参标定结果显示界面

中国知网 https://www.cnki.net



序号	X-axis	Y-axis	序号	X-axis	Y-axis
(1,1)	308.288	832.172	(1,1)	236.452	852.176
(1,2)	303.075	757.518	(1,2)	232.485	784.071
(1,3)	297.045	683.030	(1,3)	227.946	715.369
...	...	...	...	...	...
(11,9)	988.016	189.186	(11,9)	867.257	247.042
(1,1)	340.358	955.148	(1,1)	130.686	962.693
(1,2)	319.747	877.645	(1,2)	119.450	891.285
(1,3)	298.436	800.447	(1,3)	108.423	820.376
...	...	...	...	...	...
(11,9)	782.585	247.263	(11,9)	733.859	307.182
...	...	...	...	...	...

序号	X-axis	Y-axis	序号	X-axis	Y-axis
(1,1)	308.288	832.172	(1,1)	235.648	851.669
(1,2)	303.075	757.518	(1,2)	231.600	783.183
(1,3)	297.045	683.030	(1,3)	227.218	714.645
...	...	...	...	...	...
(11,9)	988.016	189.186	(11,9)	866.123	245.962
(1,1)	340.358	955.148	(1,1)	129.456	964.527
(1,2)	319.747	877.645	(1,2)	117.961	892.965
(1,3)	298.436	800.447	(1,3)	106.388	822.169
...	...	...	...	...	...
(11,9)	782.585	247.263	(11,9)	732.437	308.448
...	...	...	...	...	...

图 7-6 双目图像校正特征点显示界面



图 7-7 双目相机外参标定显示界面

中国知网 https://www.cnki.net

双目图像校正特征点显示界面如图 7-6 所示。其中，图像上半部分显示了用于双目相机外参标定的左右关键帧图像。同时，可设置双目图像特征点校正模式为自动校正或手动校正，并可对校正特征点保存路径进行设置。此外，在图像的下半部分显示了原始特征点坐标和校正之后的特征点坐标。

双目相机外参标定显示界面如图 7-7 所示。其中，图像上半部分显示了用于双目相机外参标定的左右关键帧图像。同时，在图像下半部分可设置双目相机外参标定模式为自动标定或手动选择图像进行标定，并可对双目相机外参保存路径进行设置，对进行双目外参标定的特征点来源进行选择。此外，在图像的下半部分可以查看双目相机的外参标定结果，包括旋转向量和位移向量。

7.3 本章小结

结合第 2 章所描述的锌浮选过程，本章研发了泡沫浮选过程相机标定系统，从系统功能需求和相机标定系统软硬件设计与实现方面进行了详细介绍。该系统搭载了本文提出的失焦平面板图像复原方法、基于关键帧图像的相机内参标定方法、异步双目特征点校正方法和相机外参标定方法，实现了泡沫浮选过程双目视觉系统的有效标定。本章是第 3 章至第 6 章研究成果的综合与应用，将多个分散的技术模块集成到一个完整的系统方案中，最终实现泡沫浮选过程相机标定的工业应用。

中国知网 https://www.cnki.net

第 8 章 结论与展望

8.1 主要结论

本文以锌浮选过程所部署的双目视觉监控系统为研究对象，介绍了泡沫浮选过程相机标定环境，分析了浮选过程受限环境下双目相机内外参标定的影响因素，并针对泡沫浮选过程相机标定的难点与挑战，研究基于加权关键帧与 FSC-McCNN 的相机标定方法，研发泡沫浮选过程相机标定系统，实现浮选过程双目相机内外参数的快速、准确标定。本文的主要研究成果和内容总结如下：

(1) 提出了基于 RPMU-NET 的浮选过程失焦平面板图像复原方法

针对泡沫浮选过程因平面板倾斜、成像距离差异导致的标定板图像失焦模糊、标定效率低的问题，本文提出了基于 RPMU-NET 的浮选过程失焦平面板图像复原方法。首先，使用 Canny 边缘检测算法和霍夫变换算法提取原始泡沫图像的感兴趣区域，以减少泡沫高亮点的干扰。然后，根据感兴趣区域的圆形中心定位来进行特征块分割，获取大小相同的特征块图像。同时，实施了基于平面板图像特征分区的并行计算方法来提升模型的图像复原效率，该方法通过一种两层并行处理方法将复杂的计算任务分解为多个简单的子任务。此外，构建了一种基于自适应掩码调制的编码解码器模型 MAM-UNet，该模型使用一个掩码生成模块来强化模型对圆形特征区域的集中处理与精准复原，然后对该模型实施了一种由预训练和微调组成的渐进式训练策略，有效提高了模型的鲁棒性和泛化能力。分别在虚拟数据集和真实工业数据集上进行了实验，验证了所提方法的有效性和准确性。

(2) 提出了基于关键帧提取和位姿加权的浮选过程相机内参标定方法

为了解决因操作环境受限、标定板非线性运动、位姿不可控等因素导致的基于泡沫视频进行相机内参标定难的问题，本文提出了基于关键帧提取和位姿加权的浮选过程相机内参标定方法。首先，利用图像质量评价方法进行泡沫视频关键帧提取，以获取对相机内参标定最重要的平面板图像帧序列。同时去除不完整的平面板图像，对失焦平面板图像进行复原操作，从左右相机原始泡沫视频序列中提取高质量图像序列。然后，使用平面板倾斜度等量化指标来提取平面板位姿差异较大的图像集合，并利用图像序列质量差异提取左右相机的内参标定关键帧集合。此外，为了考虑更多的平面板图像序列组合，提出了基于平面板位姿表征的关键帧图像序列内参权重计算方法，并最终实现基于加权归一化位姿差异的相机内参标定。在真实泡沫浮选现场进行了实验，验证了所提方法的准确性和可行性。

(3) 提出了基于闭环混合优化的双目特征点同步校正方法

浮选过程复杂外部光源环境易导致双目图像亮度不一致，针对该现象而进行的曝光时间调整操作会间接导致双目相机成像时间异步。为了解决这一问题，本

中国知网 https://www.cnki.net

文提出了基于闭环混合优化的双目特征点同步校正方法。首先，使用图像质量评价方法从输入的双目泡沫视频中提取外参关键帧。然后，构建了浮选过程双目相机的时间序列模型来分析双目图像采集的时间差异，以更准确地校正双目相机之间的异步性。同时，利用经验知识实现了双目相机成像初始延时估计，以加快混合优化模型的收敛速度，并使用特征匹配点预测模块来提取与左相机关键帧特征点相匹配的右相机坐标集合。为了在小范围内优化初始延时，提升模型收敛速度和鲁棒性，构建了混合优化算法，并在此基础上实现了异步双目特征点的闭环校正。工业数据实验证实了所提方法的可靠性和先进性。

(4) 提出了基于 FSC-McCNN 的浮选过程双目外参标定方法

为了解决浮选过程液位波动、相机视角变化等情况下双目外参高精度标定能力受限的问题，本文提出了基于 FSC-McCNN 的浮选过程双目外参标定方法。其中，为了提升双目相机外参标定的准确性，首先对左右视图异步特征点进行校正操作，并获取双目相机的初始参数。然后搭建了相机合成成像场景来生成深度标定网络的输入数据，以构建从特征点图谱到相机参数的直接映射关系。同时，为了增强深度标定模型的鲁棒性，减少其对理想图像条件的敏感性，在合成成像场景中实施了数据增强操作。此外，提出了基于特征空间编码的深度标定网络 FSC-McCNN，该网络使用特征空间编码模块来强化模型识别和表征特征点位置空间的能力，并使用多通道卷积神经网络来深入挖掘相机参数信息。在虚拟数据和泡沫浮选数据集上进行了大量实验，验证了所提双目外参标定方法的性能。

(5) 研发了泡沫浮选过程相机标定系统

在工业浮选现场搭建了泡沫浮选过程相机标定平台，使用 Visual Studio 2022 C#和 SQLServer2022 等开发工具，研发了泡沫浮选过程相机标定系统，实现了双目相机内外参数的快速、准确测量，成功应用于某铅锌矿的双目立体视觉系统，为表层泡沫三维重构提供了有力支撑。

8.2 工作展望

本文以泡沫浮选过程双目相机内外参标定存在的难点及挑战为研究背景，在失焦平面板图像复原、相机内参标定、异步双目特征点校正和双目相机外参标定方面开展了一定的研究工作，取得了一些研究成果，但仍有很多工作值得进一步探索，后续研究工作可以从以下三方面开展：

(1) 目前主流的标定板包括棋盘格和圆形标定板，本文只考虑了圆形标定板。而在失焦平面板图像复原方面，本文方法专为圆形平面板设计，这在一定程度上限制了本文方法的可扩展性。因此，分析棋盘格和圆形标定板的共性和区别，设计更通用的失焦标定算法是一项值得深入研究的课题。

中国知网 https://www.cnki.net

(2) 基于传统技术的相机标定方法和基于深度学习技术的相机标定方法优势互补，当前主流方法主要是单独使用传统技术或者深度学习技术，没有将两种方法进行有效的融合。传统方法在理想条件下表现稳定，深度学习方法对噪声、光照变化、标定板部分遮挡等非理想条件具有更强的鲁棒性。在复杂环境下，结合使用传统技术和深度学习技术可以充分发挥两者的优势，提高标定的稳定性和可靠性。因此，如何有效融合传统技术和深度学习技术是下一步需要解决的问题。

(3) 泡沫浮选过程外部环境复杂多变，当面对极端照明环境、强烈图像模糊、平面板极端倾斜等不可控环境变化时，基于平面板的相机标定方法会受到严重限制。因此，如何在极端浮选工业环境下进行准确、鲁棒的双目相机标定，并有效平衡标定性能和效率，是一个值得继续研究的课题。

中国知网 https://www.cnki.net

参考文献

[1] 桂卫华, 阳春华, 谢永芳, 等. 泡沫浮选泡沫图像处理与过程监测技术[M]. 中南大学出版社, 2013.

[2] 袁小锋, 桂卫华, 陈晓方, 等. 人工智能助力有色金属工业转型升级[J]. 中国工程科学, 2018, 20(4): 59-65.

[3] 袁小锋, 王雅琳, 阳春华, 等. 深度学习在流程工业过程数据建模中的应用[J]. 智能科学与技术学报, 2020, 2(2): 107-115.

[4] 吴飞, 阳春华, 兰旭光, 等. 人工智能的回顾与展望[J]. 中国科学基金, 2018, 32(3): 243-250.

[5] 钱锋, 桂卫华. 人工智能助力制造业优化升级[J]. 中国科学基金, 2018, 32(3): 257-261.

[6] Qian F. Smart process manufacturing systems: deep integration of artificial intelligence and process manufacturing[J]. Engineering, 2019, 5(6): 981-981.

[7] 柴天佑. 工业人工智能发展方向[J]. 自动化学报, 2020, 46(10): 2005-2012.

[8] Zhang H, Tang Z H, Xie Y F, et al. A Similarity-Based Burst Bubble Recognition Using Weighted Normalized Cross Correlation and Chamfer Distance[J]. IEEE Transactions on Industrial Informatics, 2020, 16(6): 4077-4089.

[9] Luo J, Tang Z H, Zhang H, et al. LTGH: A Dynamic Texture Feature for Working Condition Recognition in the Froth Flotation[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-10.

[10] Jovanović I, Miljanović I, Jovanović T. Soft computing-based modeling of flotation processes–A review[J]. Minerals Engineering, 2015, 84: 34-63.

[11] Jovanović I, Miljanović I. Contemporary advanced control techniques for flotation plants with mechanical flotation cells–A review[J]. Minerals Engineering, 2015, 70: 228-249.

[12] Qiu Z, Dou D, Zhou D, et al. On-line prediction of clean coal ash content based on image analysis[J]. Measurement, 2021, 173: 108663.

[13] Mehrabi A, Mehrshad N, Massinaei M. Machine vision based monitoring of an industrial flotation cell in an iron flotation plant[J]. International Journal of Mineral Processing, 2014, 133: 60-66.

[14] Massinaei M, Jahedsaravani A, Taheri E, et al. Machine vision based monitoring and analysis of a coal column flotation circuit[J]. Powder Technology, 2019,

中国知网 https://www.cnki.net

343: 330-341.

[15] Zhang H, Tang Z H, Xie Y F, et al. ES-net: An Integration Model Based on EncoderDecoder and Siamese Time Series Difference Network for Grade Monitoring of Zinc Tailings and Concentrate[J]. IEEE Transactions on Industrial Electronics, 2023, 70(11): 11819-11830.

[16] Golnabi H, Asadpour A. Design and application of industrial machine vision systems[J]. Robotics and Computer-Integrated Manufacturing, 2007, 23(6): 630-637.

[17] 张国福, 沈洪艳. 机器视觉技术在工业检测中的应用综述[J]. 电子技术与软件工程, 2013, (22): 111.

[18] Zhang H, Tang Z H, Xie Y F, et al. Siamese Time Series and Difference Networks for Performance Monitoring in the Froth Flotation Process[J]. IEEE Transactions on Industrial Informatics, 2022, 18(4): 2539-2549.

[19] Zhang H, Tang Z H, Xie Y F, et al. Feature Reconstruction-Regression Network: A Light-Weight Deep Neural Network for Performance Monitoring in the Froth Flotation[J]. IEEE Transactions on Industrial Informatics, 2021, 17(12): 8406-8417.

[20] Fan Y, Tang Z, Luo J, et al. Extended Shapelet Learning-Based Discriminant Dictionary for Froth Flotation Fault Recognition[J]. IEEE Sensors Journal, 2024, 24(7): 10853-10864.

[21] Xie Q, Hu X, Ren L, et al. A binocular vision application in IoT: Realtime trustworthy road condition detection system in passable area[J]. IEEE Transactions on Industrial Informatics, 2022, 19(1): 973-983.

[22] 郑太雄, 黄帅, 李永福, 等. 基于视觉的三维重建关键技术研究综述[J]. 自动化学报, 2020, 46(4): 631-652.

[23] Lu Y, Wang S, Fan S, et al. Image-based 3D reconstruction for Multi-Scale civil and infrastructure Projects: A review from 2012 to 2022 with new perspective from deep learning methods[J]. Advanced Engineering Informatics, 2024, 59: 102268.

[24] Wu R, Mildenhall B, Henzler P, et al. Reconfusion: 3d reconstruction with diffusion priors[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024: 21551-21561.

[25] 张峰峰, 陈龙, 薛保珊, 等 差分遗传算法优化 BP 神经网络的双目相机标定[J]. 哈尔滨工程大学学报, 2021, 42(7): 928-935.

中国知网 https://www.cnki.net

[26] 邹朋朋, 张滋黎, 王平, 等. 基于共线向量与平面单应性的双目相机标定方法[J]. 光学学报, 2017, 37(11): 244-252.

[27] Li W, Shan S, Liu H. High-precision method of binocular camera calibration with a distortion model[J]. Applied optics, 2017, 56(8): 2368-2377.

[28] Datta A, Kim J-S, Kanade T. Accurate camera calibration using iterative refinement of control points[C]// IEEE 12th International Conference on Computer Vision Workshops, 2009: 1201-1208.

[29] Bu L, Huo H, Liu X, et al. Concentric circle grids for camera calibration with considering lens distortion[J]. Optics and Lasers in Engineering, 2021, 140: 106527.

[30] Cheng Q, Huang P. Camera Calibration Based on Phase Estimation[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 72: 1-9.

[31] Huang L, Zhang Q, Asundi A. Flexible camera calibration using not-measured imperfect target[J]. Applied optics, 2013, 52(25): 6278-6286.

[32] Nakano K, Okutomi M, Hasegawa Y. Camera calibration with precise extraction of feature points using projective transformation[C]// IEEE International Conference on Robotics and Automation, 2002, 3: 2532-2538.

[33] Huang L, Zhang Q, Asundi A. Camera calibration with active phase target: improvement on feature detection and optimization[J]. Optics letters, 2013, 38(9): 1446-1448.

[34] Meng Z, Zhang H, Guo D, et al. Defocused calibration for large field-of-view binocular cameras[J]. Automation in Construction, 2023, 147: 104737.

[35] Huo J, Meng Z, Zhang H, et al. Feature points extraction of defocused images using deep learning for camera calibration[J]. Measurement, 2022, 188: 110563.

[36] Huo J, Zhang H, Meng Z, et al. A flexible calibration method based on small planar target for defocused cameras[J]. Optics and Lasers in Engineering, 2022, 157: 107125.

[37] Ding W, Liu X, Xu D, et al. A robust detection method of control points for calibration and measurement with defocused images[J]. IEEE Transactions on Instrumentation and Measurement, 2017, 66(10): 2725-2735.

[38] Liu J, Li Y, Chen S. Robust camera calibration by optimal localization of spatial control points[J]. IEEE Transactions on Instrumentation and Measurement, 2014, 63(12): 3076-3087.

[39] Wang Y, Wang Y, Liu L, et al. Defocused camera calibration with a conventional

中国知网 https://www.cnki.net

periodic target based on Fourier transform[J]. Optics Letters, 2019, 44(13): 3254-3257.

[40] Chen X, Fan R, Wu J, et al. Fourier-transform-based two-stage camera calibration method with simple periodical pattern[J]. Optics and Lasers in Engineering, 2020, 133: 106121.

[41] Heikkinen J, Schajer G S. Diffraction-based self-calibration method for defocused speckle imaging[J]. Optics and Lasers in Engineering, 2022, 158: 107124.

[42] Choi H, Ha H-G, Lee H, et al. Robust control point estimation with an out-of-focus camera calibration pattern[J]. Pattern Recognition Letters, 2021, 143: 1-7.

[43] Cheng L, Dai Y, Peng R, et al. Positioning and navigation of mobile robot with asynchronous fusion of binocular vision system and inertial navigation system[J]. International Journal of Advanced Robotic Systems, 2017, 14(6): 1729881417745607.

[44] Yao R, Deng H, Zhang W, et al. Asynchronous Double-Frame-Exposure Binocular-Camera with Pixel-Level Pipeline Architecture for High-Speed Motion Tracking[J]. IEEE Transactions on Circuits and Systems II: Express Briefs, 2022, 69(6): 2967-2971.

[45] Cai G L. A method for prediction the trajectory of table tennis in multirotation state based on binocular vision[J]. Computational Intelligence and Neuroscience, 2022, 2022(1): 8274202.

[46] Chen X, Wu X, Gao S, et al. Synchronization and calibration of a stereo vision system[C]// Global Oceans 2020: Singapore–US Gulf Coast, 2020: 1-6.

[47] Yin Z Y, Ren X Y, Du Y F, et al. Binocular camera calibration based on timing correction[J]. Applied Optics, 2022, 61(6): 1475-1481.

[48] Wang X, Chen H, Li Y, et al. Online extrinsic parameter calibration for robotic camera–encoder system[J]. IEEE Transactions on Industrial Informatics, 2019, 15(8): 4646-4655.

[49] Hu S, Zhang J. An adaptive kernel correlation filter algorithm and synchronization error correction method for 3D motion reconstruction of flexible flapping wings using binocular vision[J]. Measurement, 2024, 228: 114388.

[50] Liao K, Nie L, Huang S, et al. Deep learning for camera calibration and beyond:

中国知网 https://www.cnki.net

A survey[J]. arXiv preprint arXiv:230310559, 2023: 1-29.

[51] Workman S, Greenwell C, Zhai M, et al. Deepfocal: A method for direct focal length estimation[C]// IEEE International Conference on Image Processing (ICIP), 2015: 1369-1373.

[52] Cramariuc A, Petrov A, Suri R, et al. Learning camera miscalibration detection [C]// IEEE International Conference on Robotics and Automation (ICRA), 2020: 4997-5003.

[53] Duan Q, Wang Z, Huang J, et al. A deep-learning based high-accuracy camera calibration method for large-scale scene[J]. Precision Engineering, 2024, 88: 464-474.

[54] DeTone D, Malisiewicz T, Rabinovich A. Deep image homography estimation[J]. arXiv preprint arXiv:160603798, 2016.

[55] Nguyen T, Chen S W, Shivakumar S S, et al. Unsupervised deep homography: A fast and robust homography estimation model[J]. IEEE Robotics and Automation Letters, 2018, 3(3): 2346-2353.

[56] Cao S-Y, Hu J, Sheng Z, et al. Iterative deep homography estimation[C]// IEEE/CVF conference on computer vision and pattern recognition, 2022: 1879-1888.

[57] Rong J, Huang S, Shang Z, et al. Radial lens distortion correction using convolutional neural networks trained with synthesized images[C]// Asian Conference on Computer Vision, 2017: 35-49.

[58] Bogdan O, Eckstein V, Rameau F, et al. DeepCalib: A deep learning approach for automatic intrinsic calibration of wide field-of-view cameras[C]// ACM SIGGRAPH European Conference on Visual Media Production, 2018: 1-10.

[59] Yang S, Lin C, Liao K, et al. Unsupervised fisheye image correction through bidirectional loss with geometric prior[J]. Journal of Visual Communication and Image Representation, 2020, 66: 102692.

[60] Zhao H, Shi Y, Tong X, et al. A simple yet effective pipeline for radial distortion correction[C]// IEEE International Conference on Image Processing (ICIP), 2020: 878-882.

[61] Liao K, Lin C, Zhao Y, et al. DR-GAN: Automatic radial distortion rectification using conditional GAN in real-time[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2019, 30(3): 725-733.

[62] Tan Z, Zhang X, Teng S, et al. A Review of Deep Learning-Based LiDAR and

中国知网 https://www.cnki.net

Camera Extrinsic Calibration[J]. Sensors, 2024, 24(12): 3878.

[63] Kendall A, Grimes M, Cipolla R. Posenet: A convolutional network for real-time 6-dof camera relocalization[C]// IEEE international conference on computer vision, 2015: 2938-2946.

[64] Jau Y-Y, Zhu R, Su H, et al. Deep keypoint-based camera pose estimation with geometric constraints[C]// IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2020: 4950-4957.

[65] Xian W, Li Z, Fisher M, et al. UprightNet: geometry-aware camera orientation estimation from single images[C]// IEEE/CVF International Conference on Computer Vision, 2019: 9974-9983.

[66] Gil Y, Elmalem S, Haim H, et al. Online training of stereo self-calibration using monocular depth estimation[J]. IEEE Transactions on Computational Imaging, 2021, 7: 812-823.

[67] Chen K, Snavely N, Makadia A. Wide-baseline relative camera pose estimation with directional learning[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 3258-3268.

[68] Parameshwara C M, Hari G, Fermüller C, et al. Diffposenet: Direct differentiable camera pose estimation[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 6845-6854.

[69] Do T, Miksik O, DeGol J, et al. Learning to detect scene landmarks for camera localization[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 11132-11142.

[70] Yang L, Shrestha R, Li W, et al. Scenesqueezer: Learning to compress scene for camera relocalization[C]// IEEE/CVF conference on computer vision and pattern recognition, 2022: 8259-8268.

[71] Su P-C, Shen J, Xu W, et al. A fast and robust extrinsic calibration for RGB-D camera networks[J]. Sensors, 2018, 18(1): 235.

[72] Nguyen A D, Yoo M. CalibBD: Extrinsic calibration of the LiDAR and camera using a bidirectional neural network[J]. IEEE Access, 2022, 10: 121261-121271.

[73] Itu R, Borza D, Danescu R. Automatic extrinsic camera parameters calibration using Convolutional Neural Networks[C]// IEEE International Conference on Intelligent Computer Communication and Processing (ICCP), 2017: 273-278.

[74] Aouragh M, Gulyás L. Extrinsic Calibration Framework for Camera-Lidar Fusion Using Recurrent Residual Network[C]// International Conference on

中国知网 https://www.cnki.net

Computational Collective Intelligence, 2023: 578-590.

[75] Zhai M, Workman S, Jacobs N. Detecting vanishing points using global image context in a non-manhattan world[C]// IEEE Conference on Computer Vision and Pattern Recognition, 2016: 5657-5665.

[76] Chang C-K, Zhao J, Itti L. Deepvp: Deep learning for vanishing point detection on 1 million street view images[C]// IEEE International Conference on Robotics and Automation (ICRA), 2018: 4496-4503.

[77] Zhou Y, Qi H, Huang J, et al. Neurvps: Neural vanishing point scanning via conic convolution[C]// Advances in Neural Information Processing Systems, 2019: 32: 1-10.

[78] Lin Y, Wiersma R, Pintea S L, et al. Deep vanishing point detection: Geometric priors make dataset variations vanish[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 6103-6113.

[79] Lee J, Go H, Lee H, et al. Ctrl-c: Camera calibration transformer with line-classification[C]// IEEE/CVF International Conference on Computer Vision, 2021: 16228-16237.

[80] Grelsson B, Felsberg M, Isaksson F. Highly accurate attitude estimation via horizon detection[J]. Journal of Field Robotics, 2016, 33(7): 967-993.

[81] Brouwers G M, Zwemer M H, Wijnhoven R G, et al. Automatic calibration of stationary surveillance cameras in the wild[C]// European Conference on Computer Vision, 2016: 743-759.

[82] Xiao J, Ehinger K A, Oliva A, et al. Recognizing scene viewpoint using panoramic place representation[C]// IEEE conference on computer vision and pattern recognition, 2012: 2695-2702.

[83] Hold-Geoffroy Y, Sunkavalli K, Eisenmann J, et al. A perceptual measure for deep single image camera calibration[C]// IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2354-2363.

[84] Lee J, Sung M, Lee H, et al. Neural geometric parser for single image camera calibration[C]// European Conference on Computer Vision, 2020: 541-557.

[85] Kocabas M, Huang C-H P, Tesch J, et al. SPEC: Seeing people in the wild with an estimated camera[C]// IEEE/CVF International Conference on Computer Vision, 2021: 11035-11045.

[86] Baradad M, Torralba A. Height and uprightness invariance for 3d prediction from a single view[C]// IEEE/CVF Conference on Computer Vision and Pattern

中国知网 https://www.cnki.net

Recognition, 2020: 491-500.

[87] Ponimatkin G, Labbé Y, Russell B, et al. Focal length and object pose estimation via render and compare[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 3825-3834.

[88] Butt T H, Taj M. Camera calibration through camera projection loss[C]// IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2022: 2649-2653.

[89] Remondino F, Fraser C. Digital camera calibration methods: considerations and comparisons[J]. International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 2006, 36(5): 266-272.

[90] Teixeira L, Maffra F, Badii A. Scene understanding for auto-calibration of surveillance cameras[C]// International Symposium on Visual Computing, 2014: 671-682.

[91] Gutiérrez-Moizant R, Boada M J L, Ramírez-Berasategui M, et al. Novel Bayesian Inference-Based Approach for the Uncertainty Characterization of Zhang's Camera Calibration Method[J]. Sensors, 2023, 23(18): 7903.

[92] 陈强. 基于双目立体视觉的三维重建[J]. 现代计算机(专业版), 2015, (2): 66-69.

[93] Aasen H, Burkart A, Bolten A, et al. Generating 3D hyperspectral information with lightweight UAV snapshot cameras for vegetation monitoring: From camera calibration to quality assurance[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2015, 108: 245-259.

[94] Jiang T, Cui H, Cheng X. A calibration strategy for vision-guided robot assembly system of large cabin[J]. Measurement, 2020, 163: 107991.

[95] Liu S, Xu D, Zhang D, et al. High precision automatic assembly based on microscopic vision and force information[J]. IEEE Transactions on Automation Science and Engineering, 2014, 13(1): 382-393.

[96] Parpală R C, Ivan M A, Parpală L F, et al. Camera Calibration in High-Speed Robotic Assembly Operations[J]. Applied Sciences, 2024, 14(19): 8687.

[97] Song R, Li F, Fu T, et al. A robotic automatic assembly system based on vision[J]. Applied Sciences, 2020, 10(3): 1157.

[98] 高志成, 文晨锐, 杨歆豪, 等. 基于视觉定位的空调压缩机装配系统设计[J]. 科技创新与应用, 2019, (28): 43-45.

[99] Schmidt A, Kasiński A, Kraft M, et al. Calibration of the multi-camera

中国知网 https://www.cnki.net

registration system for visual navigation benchmarking[J]. International Journal of Advanced Robotic Systems, 2014, 11(6): 83.

[100] Zhang S, Liang H, Zhu H, et al. A camera-based real-time polarization sensor and its application to mobile robot navigation[C]// IEEE International Conference on Robotics and Biomimetics, 2014: 271-276.

[101] Chen H, Matsumoto K, Ota J, et al. Self-calibration of environmental camera for mobile robot navigation[J]. Robotics and Autonomous Systems, 2007, 55(3): 177-190.

[102] Petersen A, Koch R. Video-based realtime IMU-camera calibration for robot navigation[J]. Real-Time Image and Video Processing, 2012, 8437: 55-64.

[103] Xu D, Li Y F, Shen Y, et al. New pose-detection method for self-calibrated cameras based on parallel lines and its application in visual control system[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 2006, 36(5): 1104-1117.

[104] Chai B, Wei Z. Stratified camera calibration algorithm based on the calibrating conic[J]. Optics Express, 2023, 31(2): 1282-1302.

[105] Mendikute A, Leizea I, Yagüe-Fabra J A, et al. Self-calibration technique for on-machine spindle-mounted vision systems[J]. Measurement, 2018, 113: 71-81.

[106] 程向楠, 马沁巍, 马少鹏. 自标定多视角三维数字图像相关测量方法及其应用[J]. 北京理工大学学报, 2024: 1-13.

[107] Baum Z, Lasso A, Ungi T, et al. Real-time self-calibration of a tracked augmented reality display[C]// Medical Imaging 2016: Image-Guided Procedures, Robotic Interventions, and Modeling, 2016, 9786: 141-148.

[108] 孟晓桥, 胡占义. 一种新的基于圆环点的摄像机自标定方法[J]. 软件学报, 2002, (5): 957-965.

[109] 胡培成, 黎宁, 周建江. 一种改进的基于圆环点的摄像机自标定方法[J]. 光电工程, 2007, 34(12): 54-60.

[110] 张虎, 达飞鹏, 李勤. 基于两相同圆的自标定方法[J]. 仪器仪表学报, 2010, 31(3): 618-624.

[111] Huai J, Lin Y, Zhuang Y, et al. Observability analysis and keyframe-based filtering for visual inertial odometry with full self-calibration[J]. IEEE Transactions on Robotics, 2022, 38(5): 3219-3237.

[112] Yin H, Liu P X, Zheng M. Stereo visual-inertial odometry with online

中国知网 https://www.cnki.net

initialization and extrinsic self-calibration[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-10.

[113] Chen Y, Zhang L, Shen Y, et al. Extrinsic self-calibration of the surround-view system: A weakly supervised approach[J]. IEEE Transactions on Multimedia, 2022, 25: 1622-1635.

[114] 刘福明. 一种车载双目相机自标定方法[J]. 电子技术与软件工程, 2022, (1): 155-159.

[115] Zheng Y, Peng S. A practical roadside camera calibration method based on least squares optimization[J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 15(2): 831-843.

[116] Führ G, Jung C R. Camera self-calibration based on nonlinear optimization and applications in surveillance systems[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2015, 27(5): 1132-1142.

[117] Fang J, Vasiljevic I, Guizilini V, et al. Self-supervised camera self-calibration from video[C]// International Conference on Robotics and Automation, 2022: 8468-8475.

[118] Liang S, Zhao Y. Common pole-polar and common tangent properties of dual coplanar circles and their application in camera calibration[J]. Multimedia Tools and Applications, 2024, 83(1): 381-401.

[119] 王伟, 张朝阳, 唐心瑶, 等. 道路场景下相机自动标定及优化算法[J]. 计算机辅助设计与图形学学报, 2019, 31(11): 1955-1962.

[120] 石李智, 刘宾. 关于相机自标定算法的研究[J]. 电子技术应用, 2024, 50(7): 78-82.

[121] Lee S J, Hwang S S. Fast and accurate self-calibration using vanishing point detection in manmade environments[J]. International Journal of Control, Automation and Systems, 2020, 18(10): 2609-2620.

[122] Chang D, Wang K, Wang L. Camera self-calibration based on the vanishing points[C]// International Conference on Artificial Intelligence and Computational Intelligence, 2011: 47-53.

[123] Duan S, Zang H, Zhang X, et al. Image mosaic based on the camera self-calibration of combining two vanishing points and pure rotational motion[J]. Hyperspectral Remote Sensing Applications and Environmental Monitoring and Safety Testing Technology, 2016, 10156: 511-517.

[124] He B, Li Y F. Camera calibration from vanishing points in a vision system[J].

中国知网 https://www.cnki.net

Optics & Laser Technology, 2008, 40(3): 555-561.

[125] Zhao Y, Zhao L, Yang F, et al. Extrinsic Calibration of High Resolution LiDAR and Camera Based on Vanishing Points[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-12.

[126] 胡占义, 吴福朝. 基于主动视觉摄像机标定方法[J]. 计算机学报, 2002, (11): 1149-1156.

[127] 贾畅, 卞永鑫, 金伟峰, 等. 一种基于主动式双目视觉的三维测量方法[J]. 仪表技术, 2022, (3): 66-71.

[128] 黄文文, 彭小红, 李丽圆, 等. 相机标定方法及进展研究综述[J]. 激光与光电子学进展, 2023, 60(16): 9-19.

[129] 张素枝, 秦宇锦. 基于主动视觉的相机标定方法在太阳能电池片丝印机上的应用[J]. 机电工程, 2016, 33(3): 378-382.

[130] Hwang C-L, Shih C-Y. A distributed active-vision network-space approach for the navigation of a car-like wheeled robot[J]. IEEE Transactions on Industrial Electronics, 2008, 56(3): 846-855.

[131] Shashank, Sreedevi I. Distributed network of adaptive and self-reconfigurable active vision systems[J]. Symmetry, 2022, 14(11): 1-33.

[132] Siegl H, Hanheide M, Wrede S, et al. An augmented reality human–computer interface for object localization in a cognitive vision system[J]. Image and Vision Computing, 2007, 25(12): 1895-1903.

[133] Li X, Xiao Y, Wang B, et al. Automatic targetless LiDAR–camera calibration: a survey[J]. Artificial Intelligence Review, 2023, 56(9): 9949-9987.

[134] Jiang C, Li W-l, Li W-p, et al. A novel dual-robot accurate calibration method using convex optimization and lie derivative[J]. IEEE Transactions on Robotics, 2023, 40: 960-977.

[135] Li H, Liao Z, Cai W, et al. Flexible calibration of the telecentric vision systems using only planar calibration target[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 73: 1-10.

[136] Faraji M, Basu A. Simplified active calibration[M]. Computer Vision: A Reference Guide. Springer. 2021: 1166-1170.

[137] Xu D, Zhang D, Liu X, et al. A calibration and 3-D measurement method for an active vision system with symmetric yawing cameras[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-13.

[138] De Ma S. A self-calibration technique for active vision systems[J]. IEEE

中国知网 https://www.cnki.net

Transactions on Robotics and Automation, 1996, 12(1): 114-120.

[139] Rebello J, Das A, Waslander S. Autonomous active calibration of a dynamic camera cluster using next-best-view[C]// IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017: 1484-1489.

[140] 吴庆华, 万偲, 李子奇, 等. 机器人线结构光视觉引导系统的手眼标定方法[J]. 制造业自动化, 2021, 43(11): 29-34.

[141] 郜承岳, 谌业清, 李昊冉, 等. 基于 M 型标准块的视觉引导机器人系统手眼标定方法研究[J]. 计算机测量与控制, 2024, 32(01): 133-141.

[142] 贾铜, 毕德学, 宋韦辰, 等. 基于视觉引导的机器人抓取系统手眼标定方法[J]. 食品与机械, 2024, 40(7): 63-67.

[143] Wei G-Q, Arbter K, Hirzinger G. Active self-calibration of robotic eyes and hand-eye relationships with model identification[J]. IEEE Transactions on Robotics and Automation, 1998, 14(1): 158-166.

[144] Huang C, Chen D, Tang X. Robotic hand-eye calibration based on active vision[C]// International Symposium on Computational Intelligence and Design, 2015, 1: 55-59.

[145] Pedrosa E, Oliveira M, Lau N, et al. A general approach to hand–eye calibration through the optimization of atomic transformations[J]. IEEE Transactions on Robotics, 2021, 37(5): 1619-1633.

[146] Zhang Y, Qiu Z, Zhang X. A simultaneous optimization method of calibration and measurement for a typical hand–eye positioning system[J]. IEEE Transactions on Instrumentation and Measurement, 2020, 70: 1-11.

[147] 邱晓荣, 刘全胜, 赵吉. 基于主动视觉的手眼系统自标定方法[J]. 中国测试, 2018, 44(7): 1-6.

[148] 黄朝兴, 陈丹, 唐旭晟. 带激光笔的机器人主动视觉手眼标定[J]. 微型机与应用, 2015, 34(17): 70-74.

[149] Nickels K, Huber E, DiCicco M. Hand-eye calibratilon using active vision[C]// IEEE Aerospace Conference, 2007: 1-9.

[150] 吉峰, 郭新年, 曹沁婕, 等. 基于主动视觉的结构光手眼系统自标定方法[J]. 自动化仪表, 2015, 36(02): 8-11.

[151] Qiao Y, Liu Q-s, Peng L, et al. A new method of self-calibration of hand-eye systems based on active vision[C]// IFAC Proceedings Volumes, 2014, 47(3): 9347-9352.

[152] Zhang X, Xi Y, Huang Z, et al. Active hand-eye calibration via online accuracy-

中国知网 https://www.cnki.net

driven next-best-view selection[J]. The Visual Computer, 2023, 39(1): 381-391.

[153] 林绿开, 钮倩倩, 李毅. 基于棋盘标定板的优化相机参数标定方法[J]. 计算机技术与发展, 2023, 33(12): 101-105.

[154] Wu B, Hu H, Zhu Q, et al. A flexible method for zoom lens calibration and modeling using a planar checkerboard[J]. Photogrammetric Engineering & Remote Sensing, 2013, 79(6): 555-571.

[155] Kolecki J, Kuras P, Pastucha E, et al. Calibration of industrial cameras for aerial photogrammetric mapping[J]. Remote Sensing, 2020, 12(19): 3130.

[156] Luo J, Tang Z, Zhang H, et al. A Binocular Camera Calibration Method in Froth Flotation Based on Key Frame Sequences and Weighted Normalized Tilt Difference[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2023, 33(10): 5576 - 5586.

[157] Zhang Z Y. A flexible new technique for camera calibration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, 22(11): 1330-1334.

[158] Gai S, Da F, Dai X. A novel dual-camera calibration method for 3D optical measurement[J]. Optics and Lasers in Engineering, 2018, 104: 126-134.

[159] Chuang J-H, Ho C-H, Umam A, et al. Geometry-based camera calibration using closed-form solution of principal line[J]. IEEE Transactions on Image Processing, 2021, 30: 2599-2610.

[160] Heinze C, Spyropoulos S, Hussmann S, et al. Automated robust metric calibration algorithm for multifocus plenoptic cameras[J]. IEEE Transactions on Instrumentation and Measurement, 2016, 65(5): 1197-1205.

[161] Basso F, Menegatti E, Pretto A. Robust intrinsic and extrinsic calibration of RGB-D cameras[J]. IEEE Transactions on Robotics, 2018, 34(5): 1315-1332.

[162] Yang W, Zhang X, Ma H, et al. Geometrically driven underground camera modeling and calibration with coplanarity constraints for a boom-type roadheader[J]. IEEE Transactions on Industrial Electronics, 2020, 68(9): 8919-8929.

[163] 杨霈, 殷玉龙, 卢荣胜, 等. 基于方向性靶标和多约束优化的双目相机标定[J]. 光学学报, 2022, 42(8): 195-206.

[164] Zheng Z, Fan J, Shao L, et al. Affine Constrained Binocular Camera Calibration With Planar Target Single-Axis Translating[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-13.

中国知网 https://www.cnki.net

[165] Chen G, Cui G, Jin Z, et al. Accurate intrinsic and extrinsic calibration of RGB-D cameras with GP-based depth correction[J]. IEEE Sensors Journal, 2018, 19(7): 2685-2694.

[166] Monteiro N B, Barreto J P, Gaspar J A. Standard plenoptic cameras mapping to camera arrays and calibration based on DLT[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2019, 30(11): 4090-4099.

[167] Gao Z, Zhu M, Yu J. A novel camera calibration pattern robust to incomplete pattern projection[J]. IEEE Sensors Journal, 2021, 21(8): 10051-10060.

[168] Loaiza M E, Raposo A B, Gattass M. Multi-camera calibration based on an invariant pattern[J]. Computers & Graphics, 2011, 35(2): 198-207.

[169] Tan L, Wang Y, Yu H, et al. Automatic camera calibration using active displays of a virtual pattern[J]. Sensors, 2017, 17(4): 685.

[170] Kang D-J, Ha J-E, Jeong M-H. Detection of calibration patterns for camera calibration with irregular lighting and complicated backgrounds[J]. International Journal of Control, Automation, and Systems, 2008, 6(5): 746-754.

[171] 张贵阳, 霍炬, 杨明, 等. 基于双更新策略加权差分进化粒子群的双目相机标定[J]. 红外与激光工程, 2021, 50(4): 176-186.

[172] Lü X, Meng L, Long L, et al. Comprehensive improvement of camera calibration based on mutation particle swarm optimization[J]. Measurement, 2022, 187: 110303.

[173] Nie L, Ye Y, Song Z. Method for calibration accuracy improvement of projector-camera-based structured light system[J]. Optical Engineering, 2017, 56(7): 074101-074101.

[174] Huang B, Tang Y, Ozdemir S, et al. A fast and flexible projector-camera calibration system[J]. IEEE Transactions on Automation Science and Engineering, 2020, 18(3): 1049-1063.

[175] Usamentiaga R, García D F. Multi-camera calibration for accurate geometric measurements in industrial environments[J]. Measurement, 2019, 134: 345-358.

[176] Deglint J, Cameron A, Scharfenberger C, et al. Auto-calibration of a projector–camera stereo system for projection mapping[J]. Journal of the Society for Information Display, 2016, 24(8): 510-520.

[177] Ahmad Yousef K M, J. Mohd B, Al-Widyan K, et al. Extrinsic calibration of camera and 2D laser sensors without overlap[J]. Sensors, 2017, 17(10): 2346.

[178] Fuersattel P, Plank C, Maier A, et al. Accurate laser scanner to camera

中国知网 https://www.cnki.net

calibration with application to range sensor evaluation[J]. IPSJ Transactions on Computer Vision and Applications, 2017, 9: 1-12.

[179] Wei Z, Zou W, Zhang G, et al. Extrinsic parameters calibration of multi-camera with non-overlapping fields of view using laser scanning[J]. Optics Express, 2019, 27(12): 16719-16737.

[180] Illingworth J, Kittler J. A survey of the Hough transform[J]. Computer vision, graphics, and image processing, 1988, 44(1): 87-116.

[181] Cho S-J, Ji S-W, Hong J-P, et al. Rethinking coarse-to-fine approach in single image deblurring[C]// IEEE/CVF international conference on computer vision, 2021: 4641-4650.

[182] Li D, Zhang Y, Cheung K C, et al. Learning degradation representations for image deblurring[C]// European conference on computer vision, 2022: 736-753.

[183] Zhao H, Gallo O, Frosio I, et al. Loss functions for image restoration with neural networks[J]. IEEE Transactions on Computational Imaging, 2016, 3(1): 47-57.

[184] Liu Z, Xu Y, Xu Y, et al. Improved fine-tuning by better leveraging pre-training data[C]// Advances in Neural Information Processing Systems, 2022, 35: 32568-32581.

[185] Paszke A, Gross S, Massa F, et al. Pytorch: An imperative style, high-performance deep learning library[C]// Advances in neural information processing systems. 2019: 1-12.

[186] Kupyn O, Budzan V, Mykhailych M, et al. Deblurgan: Blind motion deblurring using conditional adversarial networks[C]// IEEE conference on computer vision and pattern recognition, 2018: 8183-8192.

[187] Xiao W, Tang Z, Luo J, et al. FS-DeblurGAN: a spatiotemporal deblurring method for zinc froth flotation[J]. The European Physical Journal Special Topics, 2022, 231(10): 1983-1993.

[188] Nah S, Hyun Kim T, Mu Lee K. Deep multi-scale convolutional neural network for dynamic scene deblurring[C]// IEEE conference on computer vision and pattern recognition, 2017: 3883-3891.

[189] Wu J, Zhang M, Wang H, et al. A stable and effective calibration method for defocused cameras using synthetic speckle patterns[J]. Measurement Science and Technology, 2023, 34(8): 085011.

[190] Thompson R. Relationship between the cumulative difference and best linear unbiased predictor methods of evaluating bulls[J]. Animal Science, 1976, 23(1):

中国知网 https://www.cnki.net

15-24.

[191] Moru D K, Borro D. Analysis of different parameters of influence in industrial cameras calibration processes[J]. Measurement, 2021, 171: 108750.

[192] Sapienza M, Hansard M, Horaud R. Real-time visuomotor update of an active binocular head[J]. Autonomous Robots, 2013, 34(1): 35-45.

[193] Fritsch F N, Carlson R E. Monotone piecewise cubic interpolation[J]. SIAM Journal on Numerical Analysis, 1980, 17(2): 238-246.

[194] Lozano M, Herrera F, Krasnogor N, et al. Real-coded memetic algorithms with crossover hill-climbing[J]. Evolutionary computation, 2004, 12(3): 273-302.

[195] Biswas S, Saha D, De S, et al. Improving differential evolution through Bayesian hyperparameter optimization[C]// IEEE congress on evolutionary computation (CEC). 2021: 832-840.

[196] Deng W, Shang S, Cai X, et al. An improved differential evolution algorithm and its application in optimization problem[J]. Soft Computing, 2021, 25: 5277-5298.

[197] Gong X, Liu X, Cao Z, et al. Industrial Binocular Vision System Calibration With Unknown Imaging Model[J]. IEEE Transactions on Industrial Informatics, 2024, 20(5): 7370-7379.

[198] Yu F, Koltun V. Multi-scale context aggregation by dilated convolutions[C]// International Conference On Learning Representations. 2016: 1-13.

[199] López M, Marí R, Gargallo P, et al. Deep Single Image Camera Calibration With Radial Distortion[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 11809-11817.

[200] Kingma D P, Ba J. Adam: A method for stochastic optimization[C]// International Conference on Learning Representations. 2015: 1-15.

[201] Liu Z, Wang Y, Vaidya S, et al. Kan: Kolmogorov-arnold networks[J]. arXiv preprint arXiv:240419756, 2024.

中国知网 https://www.cnki.net