燕山大学
YANSHAN UNIVERSITY

博 士 学 位 论 文

DOCTORAL DISSERTATION

（ 学 术 学 位 ）

论文题名　基于机器视觉的铜带表面缺陷智能检测研究

作者姓名　段伯伟

学科专业　机械设计及理论

指导教师　王东城　副教授

2025 年 12 月

中国知网　https://www.cnki.net

中图分类号：TP277　　学校代码：10216
UDC：621.7　　密级：公开

学术学位博士学位论文

基于机器视觉的铜带表面缺陷智能检测研究

答辩委员会主席　：于　辉 教授　燕山大学
委　　员 1：李　明 教授　燕山大学
委　　员 2：王　健 教授　燕山大学
委　　员 3：王志远 教授　东北大学秦皇岛分校
委　　员 4：董艳英 教授　河北科技师范学院

博 士 研 究 生：段伯伟
导　　师：王东城　副教授
副　导　师　刘宏民　教授
申 请 学 位：工学博士
学 科 专 业：机械设计及理论
所 属 学 院：机械工程学院
答 辩 日 期：2025 年 12 月
授予学位单位：燕山大学

中国知网　https://www.cnki.net

Research on Intelligent Surface Defects Detection of Copper Strip Based on Machine Vision

A dissertation submitted to

Yanshan University

in partial fulfillment of the requirement for the degree of

Doctor of Engineering

in Mechanical Design and Theory

By

Duan Bowei

Supervisor: Associate Professor Wang Dongcheng

Assistant Supervisor: Professor Liu Hongmin

School of Mechanical Engineering, Yanshan University

December, 2025

中国知网 https://www.cnki.net

基于机器视觉的铜带表面缺陷智能检测研究

摘要：铜带作为电子信息和航空航天等领域的重要基础材料，其表面质量直接关系到后续加工性能与产品可靠性。目前，许多生产现场仍采用人工目测方法进行表面缺陷检测，这种方法精度低、劳动强度大，存在较高的安全风险。少部分企业引进了无损检测技术，但在实际应用中存在设备复杂、通用性较差、检出缺陷类别少、成本高等问题。随着人工智能理论的发展以及受到人工目测方法的启发，基于机器视觉的智能检测技术逐渐成为实现表面缺陷检测的有效途径。然而，该技术在实际应用仍面临成像环境复杂、样本稀缺及模型部署受限等挑战。为此，本文以铜带表面缺陷检测为研究对象，以深度学习理论与机器视觉技术为支撑，系统研究了非均匀光照恢复、图像去雾、多源数据增强、轻量化智能检测、铜带智能分割与位置辅助检测等关键技术，旨在提供一套通用性和实用性强的智能化解决方案。

为应对复杂工业环境对成像质量的干扰，分别针对非均匀光照与雾气干扰两种典型图像退化场景开展图像复原方法研究。对于非均匀光照退化场景，通过实验室采集少量配对样本，并基于Retinex成像理论提出一种非均匀光照退化图像合成方法，构建了铜带表面非均匀光照退化数据集。同时，引入基于Laplacian金字塔分解的非均匀光照校正框架，以此得到的复原模型能够恢复由于光照不均造成的缺陷特征丢失，增强图像的视觉效果。对于冷轧中的雾气干扰退化场景，在冷轧现场采集了真实生产数据，并基于大气散射模型提出一种雾气退化图像合成方法，构建了铜带表面雾气退化数据集。采用一种两阶段弱监督去雾框架，可以有效恢复铜带表面纹理与缺陷特征，显著降低雾气对检测性能的干扰。

针对工业生产中铜带表面缺陷样本规模有限、类间分布不均衡的问题，提出一种多源数据融合策略。在少量真实缺陷样本基础上，引入生成模型生成高质量、多样化缺陷样本，并建立了融合真实样本、标准增强样本、mixup样本与生成样本的多源数据驱动范式，显著增加了样本规模并缓解了类间不均衡问题。

为实现缺陷智能检测模型的高效部署，设计了自适应部分卷积算子APConv，通过引入通道注意力机制增强特征表达能力。为实现多尺度信息的高效融合，通过融合高效多尺度注意力机制构建了具有残差结构的 EAPR_Block 模块，进而搭建轻量化高效主干网络EAPRNet，以此为基础对RT-DETR进行轻量化改进。实验结果表明，

中国知网 https://www.cnki.net

该方法训练的缺陷智能检测模型在保证高检测精度的同时，实现了推理速度的显著提升，展现出优异的综合性能。

针对冷轧生产中原始图像受复杂背景干扰的问题，本文构建了铜带区域快速智能分割模型，作为图像预处理的重要环节，以实现铜带表面的准确提取，从而有效降低无效计算并提升缺陷检测的精度。同时，结合分割结果提出了边缘位置提取算法，用于实时计算铜带跑偏量，以保证缺陷定位信息的可靠性。最后，从硬件配置、模型微调与部署和软件架构设计三个层面研制了一套具有较强通用性和实用性的铜带表面缺陷检测系统，并在国内某冷轧铜带产线完成上机应用。

关键词：铜带表面缺陷；机器视觉；深度学习；多源数据驱动；图像复原；工业检测

分类号：TP227

中国知网 https://www.cnki.net

Research on Intelligent Surface Defects Detection of Copper Strip Based on Machine Vision

Abstract: Copper strips serve as pivotal foundational materials in electronics and aerospace. Consequently, their surface quality is a critical determinant of downstream processing performance and product reliability. Currently, many production lines still rely on manual visual inspection, a method hindered by low accuracy, high labor intensity, and significant safety risks. Although some enterprises have adopted nondestructive testing technologies, their practical application is often limited by equipment complexity, poor generalizability, few detectable defect categories, and high costs. With the advancement of artificial intelligence, machine vision-based intelligent detection has emerged as an effective approach for surface defect inspection. However, its industrial application still faces significant challenges, including data scarcity, complex imaging environments, and model deployment constraints. Therefore, this dissertation focuses on the surface defect detection of copper strip. Supported by deep learning theory and machine vision technology, it systematically investigates key technologies such as non-uniform illumination restoration, image dehazing, multi-source data augmentation, lightweight intelligent detection, and intelligent strip segmentation with position-assisted measurement, aiming to provide a generalized and practical intelligent solution.

To mitigate the impact of complex industrial environments on imaging quality, this study focuses on two representative degradation scenarios: non-uniform illumination and haze interference. For the non-uniform illumination scenario, a degradation dataset was constructed by synthesizing images based on Retinex theory, using a limited number of paired samples collected under laboratory conditions. A correction framework based on Laplacian pyramid decomposition was introduced, through which the resulting restoration model effectively recovered defect features obscured by non-uniform illumination and enhanced overall visual quality. For haze degradation, real industrial production data were collected, and a haze-degraded dataset was established based on the atmospheric scattering model. A two-stage weakly supervised dehazing framework was employed, which

中国知网 https://www.cnki.net

effectively restored surface textures and defect features and significantly reduced the adverse impact of haze on detection performance.

To address the challenges of data scarcity and imbalanced class distribution in copper strip surface defect detection, a multi-source data fusion strategy is proposed. Leveraging a limited set of authentic defect samples, generative models are employed to synthesize high-quality and diverse defect images. Furthermore, a multi-source data-driven paradigm is established by integrating authentic samples with data from standard augmentation, mixup techniques, and generative models. Consequently, this approach significantly expands the dataset scale and effectively mitigates the issue of class imbalance.

To facilitate the efficient deployment of intelligent defect detection models, an Adaptive Partial Convolution operator incorporating a channel attention mechanism was designed to enhance feature representation capabilities. To achieve efficient fusion of multi-scale information, an EAPR_Block module featuring a residual structure was constructed by integrating an EMA mechanism. Subsequently, a lightweight and efficient backbone network, termed EAPRNet, was developed. This backbone serves as the foundation for the lightweight optimization of the RT-DETR. Experimental results demonstrate that the proposed model maintains high detection accuracy while significantly accelerating inference speed, thereby exhibiting superior comprehensive performance.

To address interference from complex backgrounds in raw images, a fast intelligent segmentation model for the copper strip region was developed as a crucial preprocessing step. This model accurately extracts the strip surface, effectively reducing redundant computations and improving detection accuracy. Concurrently, an edge position extraction algorithm based on the segmentation results was proposed to calculate strip deviation in real-time. Finally, a comprehensive and practical surface defect detection system was developed, integrating hardware configuration, model fine-tuning and deployment, and software architecture design. The system was successfully deployed on a domestic cold-rolled copper strip production line.

Keywords: copper strip surface defects; machine vision; deep learning; multi-source data-driven; image restoration; industrial detection

Classification: TP227

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景与目的意义.....1
1.2 表面缺陷与检测技术.....3
1.2.1 工业表面缺陷定义.....3
1.2.2 金属带材表面缺陷传统检测方法.....5
1.3 基于机器视觉的金属带材表面缺陷智能检测方法.....7
1.3.1 机器视觉技术概述.....7
1.3.2 深度学习理论的发展.....8
1.3.3 金属带材表面缺陷智能检测方法.....10
1.4 铜带表面缺陷智能检测面临的关键挑战.....15
1.4.1 复杂成像环境对图像质量与检测稳定性的影响.....15
1.4.2 缺陷样本稀缺与标注质量对模型性能的制约.....15
1.4.3 实时检测需求下模型轻量化与部署效率的矛盾.....19
1.5 本文主要研究内容与技术路线.....19
第 2 章 铜带表面非均匀光照退化图像复原方法.....22
2.1 铜带表面真实非均匀光照图像采集.....22
2.2 铜带表面非均匀光照图像合成方法与数据集构建.....25
2.2.1 Retinex 成像理论.....25
2.2.2 非均匀光照退化图像合成方法.....25
2.2.3 构建数据集.....27
2.3 铜带表面非均匀光照图像复原方法.....29
2.3.1 基于 Laplacian 金字塔分解的非均匀光照校正框架.....29
2.3.2 训练细节.....34
2.3.3 结果分析.....35
2.4 本章小结.....38
第 3 章 铜带表面雾气退化图像复原方法.....39
3.1 铜带表面真实雾气图像采集.....39
3.2 铜带表面雾气图像合成方法与数据集构建.....40
3.2.1 大气散射模型.....40
3.2.2 雾气退化图像合成方法.....42
3.2.3 构建数据集.....44
3.3 铜带雾气退化图像复原方法.....46
3.3.1 两阶段弱监督去雾框架.....46
3.3.2 训练细节.....51

中国知网 https://www.cnki.net

3.3.3 结果分析.....52
3.4 本章小结.....54
第 4 章 铜带表面缺陷多源数据集构建方法.....55
4.1 铜带表面缺陷数据集构建.....55
4.2 基于扩散模型的表面缺陷样本生成方法.....57
4.2.1 去噪扩散概率模型 DDPM.....57
4.2.2 网络结构.....59
4.2.3 模型训练细节.....63
4.2.4 结果分析.....64
4.3 铜带表面缺陷多源数据集构建.....67
4.4 本章小结.....71
第 5 章 铜带表面缺陷高效轻量化智能检测方法.....72
5.1 构建轻量化高效特征提取网络.....72
5.1.1 自适应部分卷积算子 APConv.....72
5.1.2 高效特征提取模块 EAPR__Block.....75
5.1.3 轻量化特征提取网络 EAPRNet.....76
5.2 基于改进 RT-DETR 的轻量化目标检测器.....77
5.3 基于 Optuna 的超参数寻优.....79
5.4 实验结果分析.....80
5.4.1 评价指标.....80
5.4.2 测试集结果分析.....81
5.4.3 消融实验.....83
5.4.4 对比实验.....84
5.5 本章小结.....86
第 6 章 铜带表面缺陷智能检测系统的集成与工业应用.....87
6.1 铜带区域智能分割模型与跑偏量辅助检测.....87
6.1.1 铜带区域智能分割模型.....87
6.1.2 铜带跑偏量辅助检测.....93
6.2 工业应用场景与硬件配置.....97
6.2.1 工业应用场景分析.....97
6.2.2 硬件配置.....98
6.3 智能模型微调部署与整体检测流程.....102
6.3.1 图像预处理.....102
6.3.2 模型微调.....104
6.3.3 检测结果分析.....107
6.3.4 整体检测流程.....108
6.4 人机交互界面开发与应用效果.....110
6.4.1 系统架构.....110

中国知网 https://www.cnki.net

6.4.2 模型部署.....112
6.4.3 人机交互界面与应用效果.....113
6.5 本章小结.....114
第 7 章 结论.....116
参考文献.....119

中国知网 https://www.cnki.net

第 1 章　绪论

1.1　研究背景与目的意义

随着全球新一轮科技革命和产业变革的加速推进，制造业作为国民经济的支柱产业，不仅构成实体经济的基础，也是科技创新的重要载体和国家安全的战略支撑力量[1,2]。自《中国制造 2025》战略实施以来，我国高度重视制造业转型升级，将其提升至国家发展全局的核心地位[3]。不仅如此，国家也相继出台多项配套政策文件，系统谋划制造强国建设路径，推动制造业在数字化、网络化与智能化等方向实现深度融合发展[4,5]。

在制造业体系中，金属加工行业是支撑重大装备制造与基础设施建设的重要组成部分。当前，金属加工行业亟需加快与数字经济及技术的深度融合，推动生产全流程的智能化、绿色化与高质量转型[6,7]。通过建设数字化创新基础设施，充分利用工业互联网、大数据、云计算与人工智能等先进技术，有望突破传统生产模式的瓶颈，显著提升产品质量、生产效率以及资源利用水平。尤其是金属带材的全流程智能制造，不仅是推动金属行业数字化、绿色化与高效化转型的核心环节，也是增强中国制造业国际竞争力、落实制造强国战略的重要支撑力量[8-10]。

在金属带材诸多产品中，冷轧铜带凭借优异的导电性、高效的热传导性以及良好的耐腐蚀性，被广泛应用于航空器构件、新能源装备等高端工业领域[11,12]。近年来，我国铜带材及铜加工材产量持续增长，如图 1-1 所示。然而，国内铜加工行业依然呈现出低端产能过剩、高端冷轧铜带产品供给不足且严重依赖进口的结构性矛盾。这反映出我国铜加工企业在高端产品制造工艺与装备水平方面与国际先进制造地区存在显著差距。因此，加快提升产品工艺技术与装备水平，已成为推动行业高质量发展的关键任务。

近年来，随着半导体、新能源等高精尖产业的迅速发展，市场对高端冷轧铜带产品的性能与质量提出了更为严苛的要求。除了力学性能和尺寸精度外，还需在表面粗糙度、组织均匀性以及表面缺陷控制等方面满足严格指标。其中，表面缺陷作为评价金属带材表面质量的重要指标之一，直接影响成品的外观质量与使用性能[13]。冷轧铜带的生产流程复杂，涉及多个工序，每道工序均可能对表面质量产生直接影

中国知网　https://www.cnki.net

响。在实际生产中，由于原材料质量缺陷、生产设备故障以及工艺参数不合理等因素，带材在不同工序中可能产生各种表面缺陷。这些缺陷不仅降低了产品质量和生产效率，还可能引发工艺波动，影响后续加工的稳定性。

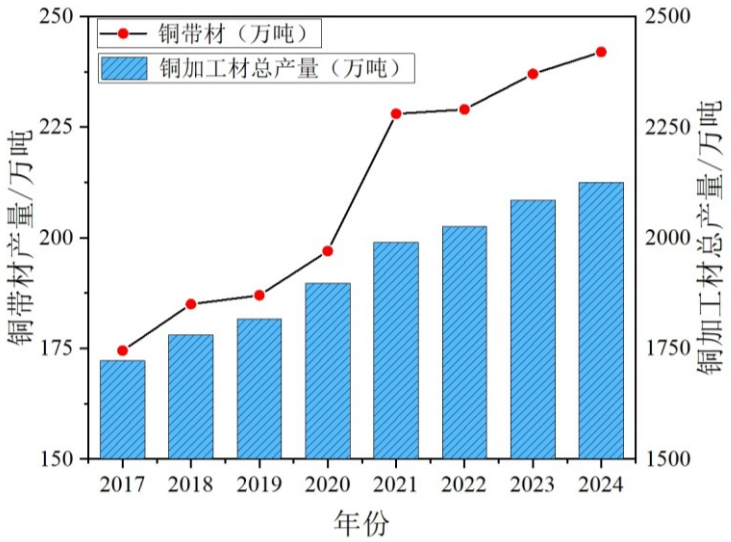


图 1-1　近年来中国铜带材及铜加工材产量统计

Fig. 1-1　Statistics of copper strip and copper processing material production in China in recent years

目前，国内很多铜带生产企业仍依赖人工目视方法检测表面缺陷，如图 1-2 所示。这种方法受限于操作人员的经验与主观判断，易出现漏检与误检，且检测精度与观察距离直接相关，不仅检测效率低下，还存在较大安全隐患，难以满足大规模连续生产需求。部分企业虽引入红外检测等无损检测方法，但受制于设备结构复杂、适应性不足、可检缺陷类型有限以及成本高等因素，难以在工业生产中普遍推广。

在此背景下，机器视觉技术与深度学习算法的迅速发展为金属带材表面缺陷检测提供了全新解决方案。基于机器视觉的检测方法利用高分辨率工业相机采集带材表面图像，结合图像处理与分析技术实现缺陷的自动识别与定位。深度学习算法的引入使检测模型能够自动提取深层次特征，显著降低了人工特征设计的依赖性，同时提升检测的准确性与鲁棒性。这些技术进展为铜带表面缺陷的智能化检测奠定了坚实的理论与技术基础。

综上所述，本文将以深度学习理论与机器视觉技术为核心，针对现有方法存在的结构复杂、检测效率低和通用性不足等问题，开展铜带表面缺陷检测的理论与技术研究，推动检测装备向轻量化与智能化方向发展。该研究不仅有助于实现铜带表

中国知网　https://www.cnki.net

面缺陷检测的智能化落地，也将为有色金属行业的转型升级和高质量发展提供有力支撑。



图 1-2　人工目视检测方法

Fig. 1-2　Manual visual inspection method

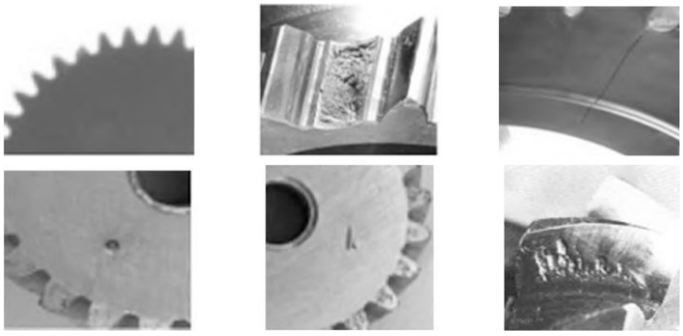
1.2　表面缺陷与检测技术

1.2.1　工业表面缺陷定义

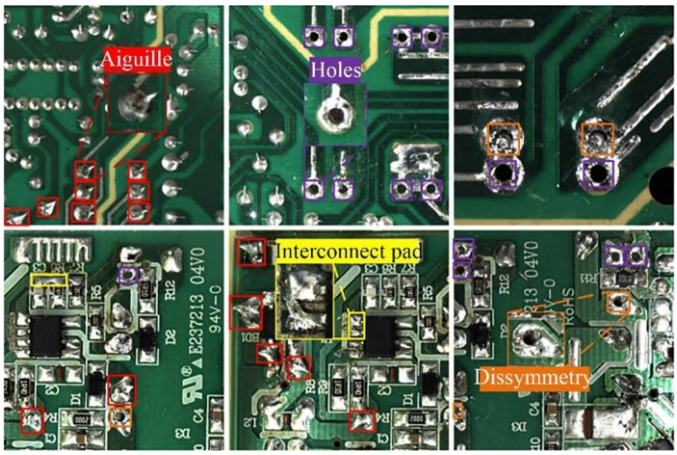
工业产品的表面缺陷，是指存在于产品最外层或近表层区域，由原材料质量、制造或装配过程、环境应力等因素引起的各种异常现象。这些异常使表面形貌、外观特性或表层材料连续性偏离设计规范与技术要求，并且达到或超过规定的判定阈值（如尺寸、数量、密度、对比度或粗糙度等）。此类缺陷可能对产品的外观等级、装配精度、服役可靠性或安全性产生不利影响。图 1-3 展示了工业领域常见的产品表面缺陷。

在有色金属加工领域，铜带作为重要的精密金属材料，其表面缺陷具有更高的敏感性与复杂性[14]。铜带在冶炼、热轧、酸洗、冷轧、退火、拉弯矫、清洗、剪切等多道工序中均可能产生缺陷[13,15-19]，不同工序形成的缺陷在类型、成因及尺度特征上差异显著[20,21]。即便是相同类型的缺陷，在不同工序条件下，其形貌特征与严重程度也可能存在明显差别。

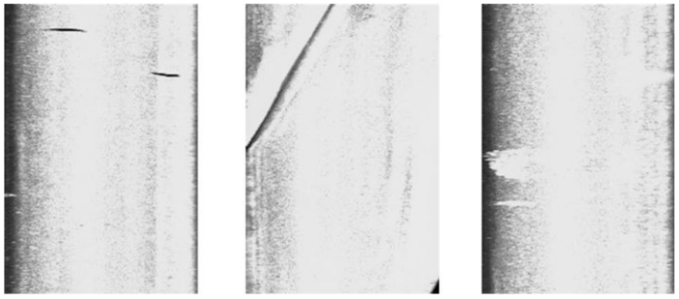
中国知网　https://www.cnki.net



(a)齿轮表面缺陷



(b)PCB 电路板表面缺陷



(c)钢轨表面缺陷



(d)木材表面缺陷

图 1-3　工业领域常见的产品表面缺陷实例

Fig. 1-3　Examples of typical product surface defects in industrial fields

中国知网　https://www.cnki.net

表面缺陷对铜带的性能与应用价值影响深远。一方面，缺陷会破坏产品的表观质量，降低表面光洁度与一致性；另一方面，裂纹、夹杂等结构性缺陷可能成为应力集中源，导致力学性能下降、使用寿命缩短，甚至引发失效事故。然而，受限于铜带表面高反射率，以及部分缺陷形貌与背景纹理高度相似等因素，传统检测方法在识别精度与稳定性方面面临巨大挑战。

1.2.2　金属带材表面缺陷传统检测方法

表面缺陷检测技术是指通过构建感知、采集与分析系统，对目标物体表面的物理异常特征进行高精度识别与分类的技术。其核心任务包括检测、定位、分类和量化等步骤，在金属、玻璃、陶瓷、塑料、纺织等材料的生产制造中均有广泛应用[22]。对于金属板带材的表面质量检测技术也经历了从人工检测到自动化视觉检测的持续发展。

（1）人工目视检测方法

人工目视检测是金属板带材表面缺陷检测的早期方法。该方法主要分为在线检测和离线抽检两种形式。在线检测时，检测人员通常在生产线的固定位置，通过肉眼观察和经验判断带材表面是否存在缺陷，必要时配合频闪仪提高观察精度。此方法多用于低速生产线，且检测精度受观察距离影响较大，存在较大安全隐患。离线抽检则是对冷却后的成品带材进行开卷检查，存在明显的检测滞后[23]。总体而言，人工目视检测易受高温、噪声、振动等生产环境因素干扰，长时间工作容易引发疲劳，且在识别细小或复杂缺陷时能力有限。此外，缺陷种类与等级的判定具有较强的主观性，容易导致漏检与误检。

（2）涡流检测方法

涡流检测技术基于电磁感应原理。激励线圈通过交变电流产生变化的磁场，当金属试件靠近时，磁场变化会在其表面感生涡流，进而引起周围磁场的变化，并感生电势。若金属带材存在缺陷，检测线圈将感知到电势的变化，用于缺陷判定[24]。该技术最早由法国洛林连轧公司福斯厂于 1989 年研发，推出了一套用于热连铸板坯表面缺陷检测的涡流无损检测系统 EDISOL。该系统在板坯的上、下表面布置了可横向往复运动的涡流探头，用于识别横向裂纹和角部裂纹。随后，ABB Metallurgy 公司基于多频涡流检测原理开发了 DECRACKTOR 系统，通过引入多个频率通道，获取更丰富的检测参数，从而增强了对不同深度及类型缺陷的响应能力。涡流检测技

中国知网　https://www.cnki.net

术具有灵敏度高、检测速度快等优势，尤其能有效检测导电材料表面及近表面微裂纹。然而，其性能易受材料表面状态（如氧化皮、粗糙度）的影响，对于大面积、形貌复杂的缺陷类型则存在分辨率限制。因此，涡流检测技术在高速连续轧制生产线中的应用仍面临一定制约[25]。

（3）红外检测方法

金属带材的红外检测技术基于材料在红外波段的热辐射特性和温度分布差异，利用红外成像设备获取带材表面的温度场或红外辐射强度分布，进而识别生产过程中产生的表面缺陷、温度异常及工艺偏差[26]。1990 年，挪威 Elkem 公司将红外检测技术应用于连铸板坯表面缺陷自动化检测系统，该系统利用红外扫描仪实时监测表面温度场变化，识别并定位缺陷区域。日本 Ibaraki 大学的冈本芳三等通过实验研究表明，红外检测在分辨率和灵敏度方面具有一定优势。然而，复杂的工业热环境可能引发温度场扰动，影响检测的稳定性。尽管红外检测在实验室和离线检测中表现出色，但在高温高速生产线如热轧带钢的工程化应用中仍面临限制，尚难实现大规模推广。

（4）漏磁检测方法

漏磁检测是一种基于磁通泄漏信号与缺陷体积正相关的无损检测技术。通过测量磁化材料中的磁通泄漏密度，可以识别和分类缺陷的位置及尺度。漏磁检测广泛应用于钢铁工业中的带钢和管材的在线质量监测，尤其适用于识别材料内部的非金属夹杂等微小结构异常[27-29]。1993 年，日本川崎制铁千叶制铁所开发了在线非金属夹杂物检测系统，首次实现了直流磁化漏磁法的工业化应用。同年，日本 NKK 公司福冈制铁所研制出超高灵敏度的磁敏传感器，其在灵敏度和稳定性方面优于磁敏二极管、磁敏电阻和霍尔传感器。尽管漏磁检测在内部缺陷检测中表现出色，但在检测浅表裂纹、划伤等表面缺陷时存在局限性，因此在表面质量检测中的适用性较为有限。

（5）传统机器视觉检测方法

随着光电子技术与计算机性能的提升，基于机器视觉的自动化检测技术逐渐取代人工目测与传统无损检测方法，成为现代金属带材表面质量检测的主流手段。该方法利用光电成像系统替代人眼获取表面图像，并结合数字图像处理技术进行缺陷识别。其中，图像传感器作为视觉系统的“眼睛”，其技术演进直接推动了检测装备的发展。

中国知网 https://www.cnki.net

早期机器视觉系统主要采用电荷耦合器件（Charge-Coupled Device, CCD）作为图像传感器。自 20 世纪 70 年代以来，CCD 相机凭借其高分辨率和稳定成像性能，逐渐应用于工业检测领域[30]。早期，CCD 检测系统以线阵 CCD 配合高强度线光源和图像采集卡，实现带钢表面的在线成像与缺陷识别。

然而，CCD 传感器存在制造工艺复杂、功耗较高以及数据读取速度受限等问题。随着半导体集成电路技术的突破，互补金属氧化物半导体（Complementary Metal-Oxide-Semiconductor, CMOS）图像传感器迅速崛起[31]。相比于 CCD，CMOS 传感器具有高集成度、低功耗、高帧率以及成本效益高等显著优势。特别是近年来全局快门与背照式技术的应用，使得 CMOS 在成像质量上已能够媲美 CCD，同时能满足工业场景下实时性的要求。目前，主流的工业视觉检测系统已逐渐从 CCD 向高性能 CMOS 传感器过渡。

进入智能化阶段，机器视觉检测系统结合模式识别、人工神经网络、决策树等算法，实现缺陷的自动分类与统计分析，显著提升了检测精度与在线稳定性。目前，机器视觉技术已成为热轧与冷轧带材表面缺陷检测的主流方案，具备非接触、高精度、实时性强等优势。

1.3　基于机器视觉的金属带材表面缺陷智能检测方法

1.3.1　机器视觉技术概述

机器视觉是利用成像设备替代人眼，对目标对象进行自动采集、处理与分析，从而实现识别、检测、测量与控制的一类综合性技术。该技术融合了光学成像、电子信息、图像处理与模式识别等多学科成果，通过对采集的图像信息进行分析与理解，辅助完成特定任务。作为一种替代人工目检的检测方式，机器视觉不仅显著降低了人为误差与劳动强度，还提升了检测系统的稳定性和扩展性，尤其适用于高强度和复杂工况下的工业生产环境。目前，该技术已广泛应用于工业制造、交通运输、医疗影像、安防监控及农业监测等领域[32-35]。

典型的机器视觉系统通常由图像采集模块、图像处理与分析模块、输出与控制模块三部分构成，如图 1-4 所示。其中，图像采集模块负责获取目标对象的高质量图像，核心设备包括工业相机、镜头、光源及光学滤波器等。光源的设计与布置直接决定图像的对比度与缺陷可见性，而相机的分辨率、帧率及传感器类型则影响检测

中国知网　https://www.cnki.net

的精度与实时性。图像处理与分析模块是系统的核心环节，涵盖图像预处理、特征提取、目标检测与分类等步骤。早期的系统多依赖人工设计特征与传统分类算法。随着深度学习理论的发展，特征提取与决策过程逐步实现端到端自动化，降低了检测算法的复杂度。输出与控制模块则将分析结果转化为可执行的控制信号，用于分拣、报警、参数调整等工业操作，并可与生产线控制系统无缝对接，从而实现闭环质量管理。

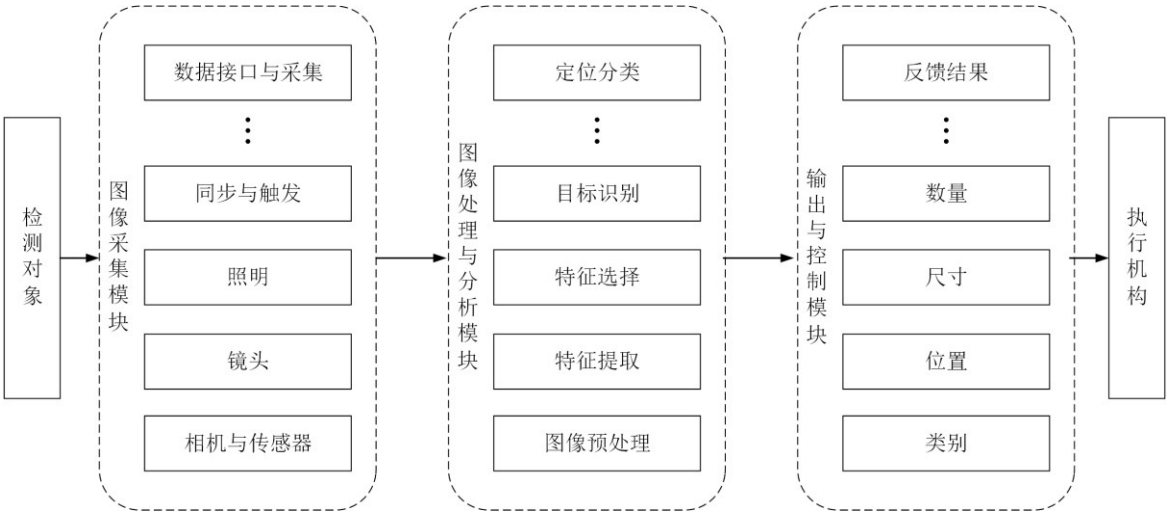


图 1-4　典型机器视觉系统

Fig. 1-4　Typical machine vision system

1.3.2　深度学习理论的发展

人工智能的发展大致经历了三个阶段：符号主义人工智能、机器学习和深度学习[36]。传统人工智能依赖规则推理与专家系统，难以适应复杂且高维的数据环境。机器学习通过数据驱动实现了从感知到预测的能力，但在图像等高维感知任务中受制于特征提取瓶颈。随着大规模数据资源与计算能力的提升，深度学习凭借端到端学习和强大的特征表达能力，逐渐成为人工智能的核心驱动力。在视觉领域，深度学习通过卷积神经网络（Convolution neural networks, CNNs）、Transformer 以及扩散模型等经典结构，实现了从底层感知到高层语义的全面建模，显著提升了机器对图像的理解与生成能力，尤其在图像复原[37]、图像理解[38]和图像生成建模[39,40]三大研究方向中展现出卓越的性能与广泛的适应性。

图像理解是机器视觉的核心研究方向，其目标是从原始图像中提取高层语义信息。典型任务包括图像分类、目标检测和图像分割。图像分类任务的目标是判定整

中国知网　https://www.cnki.net

幅图像所属类别。早期的 CNNs 网络（如 LeNet[41]、AlexNet[42]、VGGNet[43]、GoogLeNet[44]）开启了深度学习图像识别的新纪元。随后，ResNet[45]引入残差结构解决了深层网络退化问题；MobileNet[46-48]、ShuffleNet[49,50]、EfficientNet[51]等网络在精度与参数效率之间取得平衡。近年来，ViT（Vision Transformer）[52]等通过引入自注意力机制结构逐步替代部分 CNNs 架构，并适用于大规模图像识别任务。目标检测任务旨在识别图像中多个目标的类别与位置，一般分为 Two-stage 方法和 One-stage 方法两类。其中，Two-stage 方法（如 R-CNN[53]、Fast R-CNN[54]、Faster R-CNN[55]）先生成候选区域再进行分类与回归，精度与鲁棒性较高。One-stage 方法（如 SSD[56]、YOLO[57-65]系列、RetinaNet[66]）在同一网络中完成位置回归与类别预测，检测速度快、适合工业场景。相比之下，End-to-end 方法（如 DETR[67]、DINO[68]）去除了锚框与非极大值抑制操作，通过匈牙利匹配等方式实现目标与预测框的一一对应，减少对人工先验知识的依赖。图像分割任务是为每个像素赋予语义标签。其中，语义分割（如 FCN[69]、U-Net[70]、DeepLab[71]）关注类别级像素区域；实例分割（如 Mask R-CNN[72]、YOLACT[73]）进一步区分同类目标个体；全景分割（如 Panoptic-DeepLab[74]）统一了语义与实例信息。最新的 SAM（Segment Anything Model）[75]支持零样本条件下的任意目标分割，代表着分割任务向通用基础模型发展的趋势。

图像复原旨在提升图像质量与可解释性，尤其适用于非均匀光照、雾气干扰、低分辨率成像等工业场景下的成像缺陷修复，是保障后续视觉任务可靠性的关键前处理技术。针对非均匀光照、局部过曝或欠曝等问题，学者们提出了多种基于深度学习的增强方法。RetinexNet 将传统 Retinex 理论与端到端网络结合，分离反射与照明分量实现亮度均衡[76]。Zero-DCE 构建无监督对比增强曲线，通过最小化亮度偏差实现低光图像自适应增强[77]。URetinexNet 则引入注意力机制与多尺度融合策略，提高复杂场景下的光照校正能力[78]。图像去雾旨在恢复因大气散射导致的对比度降低与细节丢失问题。DehazeNet 为早期的端到端网络，直接回归透射率图[79]。AOD-Net 融合了成像物理模型，采用单网络同时预测透射率与大气光[80]。GridDehazeNet[81]引入多尺度、注意力机制与循环一致性等结构，进一步提升对厚雾、非均匀雾等复杂退化的建模能力。超分辨率重建旨在从低分辨率图像中重建出高分辨率细节。SRCNN 首次采用卷积网络实现端到端图像超分辨率方法，开创深度超分辨率领域[82]。随后，EDSR[83]、RCAN[84]等深层残差网络逐步提高重建精度。近年来，SwinIR[85]等基于 Transformer 的架构利用窗口注意力机制增强了对长距离依赖与结构纹理的建

中国知网　https://www.cnki.net

模能力，已在工业检测与遥感成像中广泛应用。

图像生成建模致力于从潜在空间中学习图像分布，用于图像合成、补全、风格转换与数据增强等任务，已成为机器视觉中的重要研究前沿。图像生成主要经历了自编码器类方法（Autoencoder）、生成对抗网络（Generative adversarial network, GAN）与扩散模型（Diffusion Models）三大发展阶段。初期图像生成研究多采用 Autoencoder 结构，其通过压缩与重建机制学习图像表示，但生成图像质量较低。变分自编码器（Variational auto-encoder, VAE）引入概率建模思想，在潜在空间中学习高斯分布，实现可控采样，但生成结果往往存在模糊问题[86,87]。GAN 通过生成器与判别器的对抗博弈显著提升了图像生成质量[88]。DCGAN（Deep Convolutional Generative Adversarial Network）率先提出稳定的卷积生成架构[89]，CycleGAN（Cycle-Consistent Generative Adversarial Network）支持无配对图像转换，解决领域迁移问题[90]，而 pix2pix 则适用于有监督图像到图像转换[91]。StyleGAN（Style Generative Adversarial Network）引入风格分层控制机制，实现高保真度图像合成，广泛应用于人脸与缺陷图像生成[92]。StarGAN（Star Generative Adversarial Network）进一步扩展至多域图像转换[93]。扩散模型通过正向加噪和反向去噪过程建模图像生成路径，具备训练稳定、可控性强等优势。去噪扩散概率模型（Denoising Diffusion Probabilistic Model, DDPM）提出标准扩散流程[94]，Latent Diffusion 将生成过程转移至低维潜空间以提升效率[95]。ControlNet 引入结构条件控制机制，实现精确图像内容约束[96]。当前图像生成研究正朝向多模态控制、结构可控、稳定高质量生成与视觉基础模型融合方向快速发展，为工业智能检测、缺陷样本扩展、复杂场景建模等提供丰富支持。

深度学习理论在图像理解、图像复原与图像生成建模三大任务中不断演进与突破，不仅推动了机器视觉从感知走向认知，更为工业缺陷检测、图像增强处理与数据建模提供了强大理论支撑。

1.3.3 金属带材表面缺陷智能检测方法

基于机器视觉的金属带材表面缺陷检测通常包括四个主要环节：图像采集（获取被检测带材的表面图像数据）、图像预处理（提升图像质量、抑制噪声、增强缺陷特征）、特征提取（提取能够表征缺陷类型与形态的有效特征）以及缺陷识别（包括缺陷分类、定位或分割等决策过程）。各阶段环环相扣，构成完整的自动化缺陷识别流程。

中国知网 https://www.cnki.net

（1）图像采集是整个检测系统的基础，通过机器视觉硬件设备构建开发检测系统，其目标是以高分辨率获取金属带材表面图像，确保缺陷区域被准确捕捉。自 20 世纪 80 年代以来，国外在金属板带表面缺陷检测领域率先开展机器视觉研究。1983 年，Honeywell 公司开发了首套基于视觉的连铸板坯表面自动检测系统，奠定了机器视觉与模式识别在表面检测中的应用基础[97]。1988 年，Westinghouse 公司构建了融合明场、暗场与微光场照明的钢板缺陷检测系统，采用线阵 CCD 相机与高强度线光源实现图像采集[98]。1996 年，芬兰 Rautaruukki 公司首次引入机器学习方法用于缺陷分类，推出 SmartView 检测系统[99]。随后，美国 Cognex 公司于 1998 年发布 iS-2000 检测平台及 iLearn 自学习分类器，有效提升了分类效率与准确率[100,101]。我国起步相对较晚，天津大学的胡亮团队使用 FPGA+DSP 的硬件架构，开发了用于冷轧带钢表面缺陷检测的机器视觉系统[102-104]。北京科技大学的徐科团队分别开发了冷轧带钢表面在线检测系统[105]、热连轧在线检测系统[106]和连铸板坯表面裂纹检测系统[107]，并在国内产线进行了实际应用验证。宝钢何永辉等[108,109]人研发的冷轧带钢表面质量在线检测系统应用与宝钢电镀锌线上。上海交通大学罗新斌针对有色加功行业表面检测需求，开发了带材表面检测系统，并成功应用于中色铜带精整线[110]。

（2）采集的原始图像中可能会存在背景干扰及无用噪声信息，图像预处理阶段旨在提升图像质量、增强缺陷区域特征，为后续识别任务提供可靠基础。一般预处理操作包括图像去噪、图像增强和图像分割三个步骤等。

工业现场图像采集及传输过程中，由于传感器异常、环境恶劣及传输异常等因素，原始图像中可能存在多种噪声，干扰图像中的正常信息。研究者使用不同滤波方法（如中值滤波器[111-113]、高斯平滑滤波器[114]、均值滤波器[115]、双边滤波器[116,117]和维纳滤波器[118,119]等）减少原始带材表面图像中的噪声干扰。然而，单一滤波方法在消除噪声的同时，还会平滑图像，导致丢失一部分细节。为此，有人将不同滤波方法进行组合及改进使用，在抑制噪声的同时，还能提升边缘精度和表达能力[120,121]。

图像增强旨在增强测试图像的全局或局部有效信息。合理的图像增强技术能够增强图像中有效特征，抑制冗余信息。这种方式有助于提高图像的可读性并增强其特征表达能力，以满足后续分析（即缺陷检测与缺陷分类）的需求。图像增强方法一般分为空间域方法和频率域方法两大类。其中，空间域方法是直接在图像像素灰度值层面上进行操作的图像增强技术。通过对图像中每个像素的灰度值或其邻域区域进行数学变换，以增强图像的局部或整体视觉效果。常用的方法有直方图均衡化

中国知网　https://www.cnki.net

[122,123]、灰度变换[124]。频率域增强方法是将图像从空间域转换到频率域，通过处理图像的频谱信息来增强图像，再将其逆变换回空间域。常用方法有二维傅里叶变换[125]和同态滤波器[126]。但上述方法通常需要对全局进行计算，消耗大量时间和资源。

图像分割的目标是去除冗余信息，提取具有代表性的目标区域，以便于后续缺陷识别与分类。在传统金属带材表面缺陷检测中，图像分割通常用于提取缺陷区域。然而，由于表面缺陷与背景间的对比度不一致，分割任务面临较大挑战。传统的阈值分割方法因实现简单、计算效率高而被广泛应用，如固定阈值法可将灰度图像二值化以突出缺陷区域[122,127]。但在灰度变化不均或背景复杂场景下，固定阈值难以准确区分前景与背景。为此，自适应阈值法应运而生，该类方法依据图像局部特征动态调整阈值，提升分割鲁棒性。其中，OTSU 方法作为典型代表，基于类间方差最大原则自动确定分割阈值，已在金属带材缺陷检测中获得广泛应用[128,129]。边缘检测方法则基于图像灰度在相邻区域的不连续性，通过一阶或二阶导数识别边缘点，常用算子包括 Robert[97]、Sobel[130]、Canny[119]和 Kirsch[117]。但由于金属带材图像中常包含光照不均和低对比度区域，Sobel、Roberts 等算子在检测模糊或微小缺陷时性能有限，而 Kirsch 虽能较好保持边缘细节，但对边缘方向依赖性强，难以保证边缘闭合连续。

（3）图像特征提取是表面缺陷检测系统中的核心环节，直接影响到后续分类、分割与识别任务的精度与鲁棒性。传统特征工程方法依赖人工经验设计特征提取规则，通常根据图像的灰度分布、几何形状、纹理结构及频域特性进行分析。灰度特征（如均值、标准差、偏度、能量和熵等）是对灰度值分布的统计，可描述金属带材图像的整体亮度变化[127]。轮廓形状和区域形状是两种典型的形状特征，分别描述物体的外边界和整体目标区域，常用的区域形状特征包括几何形状参数法[131]、Hu 不变矩[132]等。纹理特征则反映图像局部空间分布规律，常见方法包括局部二值模式（Local Binary Pattern, LBP）[133]、灰度共生矩阵（Gray Level Co-occurrence Matrix, GLCM）[132]与方向梯度直方图（Histogram of Oriented Gradients, HOG）[134]等。变换域特征通过将图像从空间域映射到频率域，提取隐藏在多尺度、多方向下的深层信息，具备较强的抗干扰能力与表达精度。常见方法包括傅里叶变换（Fourier Transform, FT）[135,136]、Gabor 滤波[124]、小波变换（Wavelet Transform, WT）[137,138]、曲波变换（Curvelet Transform）[136,139]、剪切波（Shearlet Transform, ST）[140,141]、散射变换（Scattering Transform, SCT）[142]和离散余弦变换（Discrete Cosine Transform, DCT）

中国知网 https://www.cnki.net

[138]等。传统特征工程方法具有较高的可解释性和实现效率，在特定场景下仍具优势。

基于深度学习的特征提取方法则通过端到端的网络训练自动学习最优特征表示，其中，CNNs 的图像特征提取方法已成为金属带材表面缺陷检测中的主流选择。CNNs 能够通过多层卷积操作自动提取图像的空间结构特征和语义信息，避免了传统方法中繁琐的人工特征设计环节，显著提升了特征表达的自适应能力与泛化性能。目前，为满足工业现场对检测精度与计算效率的双重需求，研究者围绕网络结构设计开展了多方面探索。一方面，为了提升缺陷检测精度，大量工作致力于构建更深、更复杂的网络结构，以增强特征提取的层次性和非线性表达能力。Song 等[143]建立了热轧带钢表面缺陷数据集，提出多特征融合的卷积神经网络缺陷识别算法，实现了热轧生产中六种常见表面缺陷的分类。王延舒等[144]提出一种基于自适应全局定位网络 AGLNet，通过引入残差网络和特征金字塔网络集成特征提取结构，并融合基于 TPE 的自适应树型候选框提取网络，在 NEU-DET 数据集上实现了 79.9%的检测精度。

另一方面，为了提高检测效率，学者们提出了多种轻量化策略以实现模型在资源受限环境下的部署。Ma 等[145]提出一种基于注意力机制的新型轻量级检测方法，用于铝带缺陷检测的工业应用。在 YOLOv4 框架的基础上，构建了主干网络 YOLO-DCSAM，利用深度可分离卷积并设计并行双通道注意力模块，压缩网络规模并更好地增强不同通道对特征图的影响。同时，重新设计并轻量化了颈部网络以进行特征融合，通过 SPPM-PANet 模块增大感受野，并进一步简化网络。Chen 等[146]提出了一种基于 YOLOv5 的冷轧带钢表面缺陷检测器。首先设计了基于单个残差块内的类残差连接的特征提取网络，并引入多头注意力模块来关注关键信息特征。为了减少特征融合过程中的信息丢失，建立了自适应特征融合路径聚合网络，通过设计轻量级自适应下采样模块来优化该网络，有效减少了参数数量，提高了速度。与此同时，网络剪枝[147,148]与知识蒸馏[149,150]等模型压缩技术也被广泛应用于缺陷检测任务中，进一步提升模型在嵌入式设备或工业相机端的运行效率。这些方法在保障精度的同时，显著降低了计算开销，适用于高速钢带产线的在线检测需求。

（4）缺陷识别旨在通过构建判别模型，将检测到的目标区域准确识别为具体的缺陷类别、位置或轮廓形态，从而实现缺陷的分类、定位与分割等综合结果。根据训练过程中对标注信息的依赖程度，现有缺陷识别方法可分为有监督学习、半监督学习和无监督或自监督学习三类。

有监督学习依赖大量高质量的标注数据，通过学习输入样本与对应标签之间的

中国知网　https://www.cnki.net

映射关系，实现精确的缺陷类别判定与位置回归。对于传统特征工程方法，通常先由人工依据领域知识设计并提取特征，再将其输入到支持向量机（Support Vector Machine, SVM）[127,137,140,141]、K 近邻（K-Nearest Neighbors, KNN）[151,152]、随机森林（Random Forest, RF）[114,153,154]等分类器中进行训练，实现缺陷类别的识别。对于深度学习方法，则通过 CNNs[143,155-157]、Transformer[158-160]等端到端架构，在特征提取与分类/定位任务中实现联合优化，无需显式人工特征设计。该方法能够自动学习多尺度、层次化的判别特征，对复杂背景和多变缺陷具有更强的适应性，但训练过程对数据量、计算资源和标注质量依赖较高。

半监督学习在少量标注数据与大量未标注数据的联合训练中，通过一致性约束、自训练等方式提升识别性能。这类方法适合在缺陷位置难以精确标注或标注成本高昂的生产现场部署，但模型设计与优化过程相对复杂，性能稳定性受数据分布影响较大。为解决大规模数据集和高质量标签短缺问题，Gao 等[161]通过伪标签对卷积神经网络进行改进，提出一种半监督学习方法，该方法所需标记样本少、并且未标记数据可用于辅助训练。He 等[162]基于卷积自编码器和半监督生成对抗网络提出一种半监督学习方法 CAE-SGAN。首先通过大量未标记数据训练堆叠 CAE，并使用直通层来帮助 CAE 提取细粒度特征。在 CAE 训练完成后，保留 CAE 的编码器网络作为特征提取器，并将其输入到 softmax 层，形成新的分类器。最后引入 SGAN 进行半监督学习。

无监督学习在训练过程中不依赖任何人工标签，通常通过聚类、异常检测或特征嵌入等方法在特征空间中挖掘缺陷类别结构。Cohn[163]等使用预训练的 VGGNet-16 模型提取热轧带钢显微图像特征图，然后应用主成分分析从特征图中提取信号并使用 K 均值聚类对图像进行分类，而无需标记训练数据。Liu 等[164]为消除伪缺陷的干扰，提出了一种新颖的 HWV 无监督模型，用于描述图像中每个局部块的纹理分布特性，最终通过自适应阈值技术，实现了缺陷与背景的精确分割。Yu 等[165]基于聚合注意力机制和分类辅助模块的特征融合策略，提出一种无监督算法 VQGNet，通过整合原始图像和异常图中的不同特征来分割缺陷，从而将注意力集中到异常信息而非不规则的复杂纹理上。无监督检测网络可通过重构误差、特征空间密度估计等方式识别异常缺陷，具备跨设备、跨工况迁移的潜力，但在缺陷差异微弱或背景复杂时，易出现聚类不稳定与误检率升高的问题。

中国知网 https://www.cnki.net

1.4　铜带表面缺陷智能检测面临的关键挑战

尽管基于机器视觉的智能检测技术在金属带材表面缺陷任务中取得了显著进展，但在真实工业生产环境中仍面临多方面的挑战。首先，铜带生产线环境复杂多变，易受到光照变化、雾气干扰、振动抖动等因素影响，采集过程往往存在对比度降低、噪声增加和特征不明显等问题，导致检测稳定性下降。其次，缺陷样本普遍存在数量稀缺与类别分布不均的问题，高质量标注数据的获取难度较大且存在标注噪声，这在一定程度上制约了模型的泛化能力与检测精度。此外，工业生产中，检测系统需要在保持精度的同时实现模型轻量化与高效部署，这对算法设计、网络结构优化和硬件适配均提出了更高要求。

1.4.1　复杂成像环境对图像质量与检测稳定性的影响

在复杂工业生产环境中，成像质量不可避免地受到影响。其中以非均匀光照和雾气干扰最为典型。雾气干扰主要来源于生产线冷却与润滑过程中产生的乳化液雾气、冷却水蒸汽以及因温差引发的冷凝现象，这些气溶胶颗粒会在空气中弥漫或沉积于镜头表面，导致成像对比度降低、细节纹理丢失及边缘模糊化。与此同时，铜带表面高反射率特性与现场光照条件不稳定相叠加，容易造成局部过曝或过暗的非均匀光照现象。这种亮度和色彩分布的不均破坏了缺陷与背景的对比关系，使得传统基于阈值或边缘的检测方法失效。而对于深度学习模型而言，光照不均则会引发特征分布漂移，在实际检测中表现为分类混淆与定位精度下降。雾气与非均匀光照均表现出随机性和时变性，且会导致检测样本与训练集中样本在成像分布上的不一致，从而显著削弱模型的稳定性与泛化性能。

针对非均匀光照问题，当前研究主要通过成像环节优化与图像预处理两方面加以缓解。在成像环节，合理布置光源位置与角度、采用恒照度工业光源以及减少背景光干扰，可在采集阶段改善亮度分布均衡性。在图像处理阶段，可利用直方图均衡化、基于 Retinex 理论的光照校正、自适应光照补偿等方法，提升图像整体亮度一致性与细节表现力。

1.4.2　缺陷样本稀缺与标注质量对模型性能的制约

在表面缺陷智能检测研究中，数据集是驱动智能模型发展的核心资源。数据集

中国知网　https://www.cnki.net

的规模与质量直接决定了模型的鲁棒性与泛化能力。因此，构建完善的数据集是实现铜带表面缺陷智能检测的首要前提。然而，在实际工业生产中，获取大规模的缺陷图像数据面临诸多挑战。一方面，真实缺陷发生频率较低且分布不均，不同类型缺陷的出现概率差异显著，导致数据集中存在类别不均衡问题。同时，铜带生产环境中光照条件复杂、表面存在油膜或氧化层，导致缺陷在图像中呈现弱对比度、边界模糊等特征，进一步增加了采集难度。另一方面，人工标注不仅工作量大，而且受限于标注人员的专业经验和判断能力，一些微小、弱纹理或与背景相似度高的缺陷易被漏标、错标。

随着深度学习算法在工业表面缺陷检测领域的广泛应用，高质量公开数据集的建设与共享已成为推动算法研发与性能评估的重要驱动力。近年来，学术界与工业界陆续发布了一系列金属板带材表面缺陷数据集，涵盖冷轧带钢、热轧带钢及部分合金材料，为缺陷检测、分类与分割等任务提供了标准化的基准数据支撑，并显著加快了智能算法在工业场景中的验证与迭代进程，如表 1-1 所示。

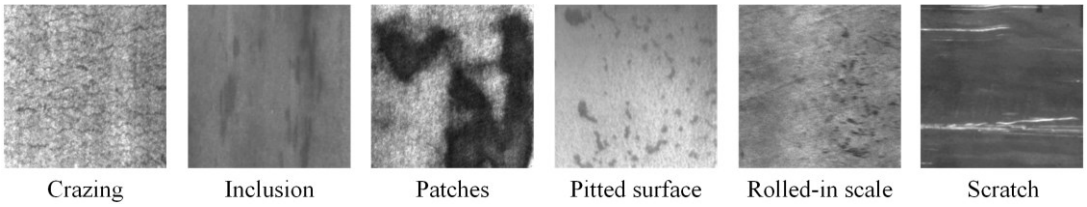
表 1-1　现有典型金属板带材表面缺陷数据集对比

Table 1-1　Comparison of existing typical metal plate and strip surface defect datasets

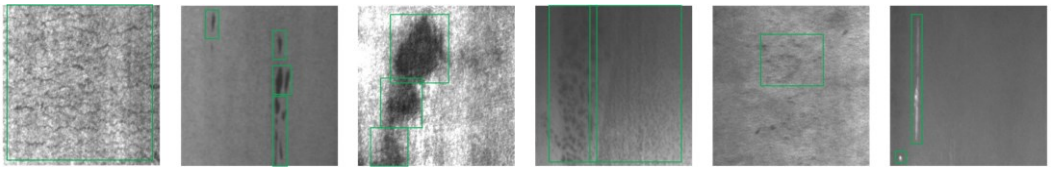
数据集名称	材料类型	缺陷类别数	样本数量	图像分辨率	任务类型	是否公开
NEU-Dataset	热轧带钢	6	1800	200×200	分类、目标检测、语义分割	是
GC10-DET	带钢	10	3570	2048×1000	目标检测	是
Severstal Dataset	带钢	4	5506	1600×256	语义分割	是
X-SDD Dataset	热轧带钢	7	1360	128×128	分类	是
CR7-DET[146]	冷轧带钢	7	4140	400×400	目标检测	否
Kmust-DET[169]	铜带	3	1800	/	语义分割	否

关于热轧带钢，东北大学机器视觉与机器人团队在 2019 年公开了热轧带钢表面缺陷图像数据集 NEU-Datasest[143]，该数据集中包含 6 类常见表面缺陷（crazing 裂纹、inclusion 夹杂、patches 斑块、pitted-surface 麻面、rolled-in scale 压入氧化铁皮和 scratch 划伤），每个类别共有 300 张图像，该数据集包含分类任务 NEU-CLS、目标检测任务 NEU-DET 和语义分割任务 NEU-Seg，如图 1-5 所示。

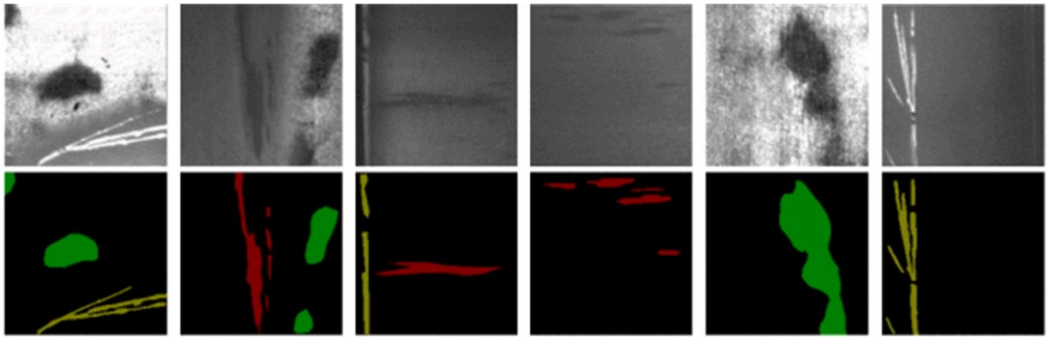
中国知网　https://www.cnki.net



(a)NEU-CLS



(b)NEU-DET



(c)NEU-Seg

图 1-5　东北大学热轧带钢表面缺陷数据集

Fig.1-5　Surface defect dataset of hot-rolled steel strips from Northeastern University

天津大学段发阶团队在 2020 年公开了 10 种钢板表面缺陷数据集 GC10-DET[166]，该数据集共有 3570 张缺陷灰度图像，用于目标检测任务，如图 1-6 所示。

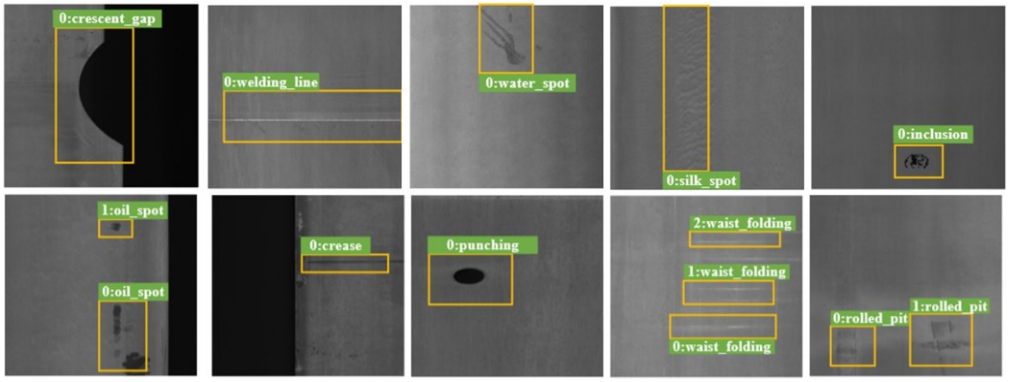


图 1-6　天津大学 GC10-DET 数据集

Fig.1-6　GC10-DET surface defect dataset from Tianjin University

中国知网　https://www.cnki.net

谢韦尔（Severstal）钢铁公司 2019 年在 Kaggle 网站上发布一个钢铁表面缺陷识别挑战赛，并公开了工业生产中的表面缺陷数据集[167]。Severstal 数据集为语义分割任务数据集，提供了四种类型的带钢表面缺陷。训练集有 12568 张图像，测试集有 5506 张图像，图像尺寸为 1600×256 像素，如图 1-7 所示。

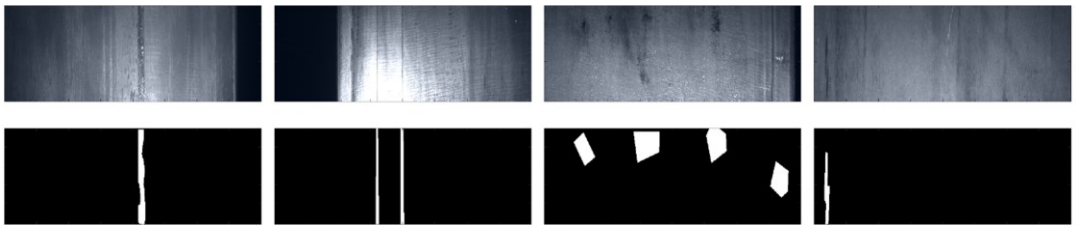


图 1-7　Severstal 数据集

Fig.1-7　Severstal dataset

东北大学 Feng 等 2021 年公开了包含 7 种类型的热轧带钢表面缺陷数据集 X-SDD[168]，共有 1360 张图像，图像尺寸为 128×128 像素，如图 1-8 所示。

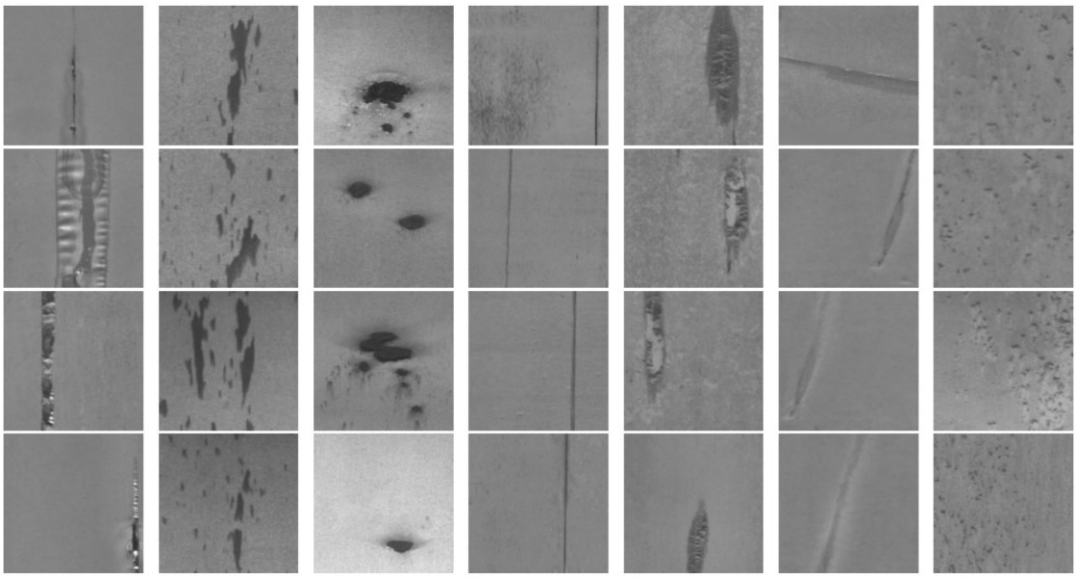


图 1-8　X-SDD 数据集

Fig.1-8　X-SDD dataset

由于铜带与钢带在材料特性、表面纹理、缺陷成因及成像特征等方面存在显著差异，基于钢带的智能检测模型直接迁移到铜带数据集任务中难以获得理想的检测效果。此外，现有少量涉及铜带的缺陷图像多为企业内部封闭数据[169,170]，缺乏统一的采集标准、标注规范与公开共享机制，限制了算法性能的可比性与研究成果的复现性。因此，构建一个高质量、标准化、多类别且具备代表性的铜带表面缺陷数据

中国知网　https://www.cnki.net

集，不仅对于推动相关检测算法的研究具有重要意义，也将为工业生产线智能检测系统提供坚实的数据基础，促进该领域从方法研究向工程应用的落地转化。

1.4.3　实时检测需求下模型轻量化与部署效率的矛盾

金属带材表面缺陷检测系统在实际工业应用中，必须满足实时性要求，即具备毫秒级响应能力，并以每秒处理帧数作为性能衡量指标。然而，智能模型的检测精度与推理速度之间存在天然的权衡关系。高精度检测模型通常拥有庞大的参数规模和复杂的计算图，推理延迟显著增加，难以满足高速生产的要求。相反，轻量化检测模型虽然在推理速度和部署适配性上具有明显优势，但在结构简化后，其特征提取能力受限，尤其在识别小尺寸、低对比度及复杂纹理缺陷时，精度下降更为明显。

为缓解这一矛盾，研究者通常从软、硬件协同优化入手。一方面，在模型设计层面引入深度可分离卷积、Shuffle 操作、Ghost 模块等轻量化结构，并结合特征金字塔优化多尺度信息融合，可在有限计算量下保持对小缺陷的敏感性；另一方面，通过参数剪枝、网络量化和知识蒸馏等模型压缩技术，在控制计算复杂度的同时尽量保持精度。此外，结合 GPU、FPGA、NPU 等硬件加速平台以及 TensorRT、OpenVINO 等推理引擎，可显著提升部署效率；针对工业检测的区域分布特征，还可通过动态分辨率采集或自适应检测频率实现计算资源的按需分配。通过上述策略的综合应用，能够在一定程度上缓解铜带表面缺陷检测中实时性与精度之间的矛盾，为高速生产环境下的稳定运行提供技术保障。

1.5　本文主要研究内容与技术路线

通过上述分析，本文以深度学习理论与机器视觉技术为支撑，聚焦于铜带表面缺陷智能检测。针对该领域在工业应用中普遍面临复杂环境干扰、缺陷样本稀缺和智能模型部署困难三大通用性问题与工业在线应用这一实用性挑战构建了系统的研究框架，并按照图像采集、图像复原、数据集构建、表面缺陷检测、铜带区域快速智能分割与跑偏量辅助检测以及工业化系统实现的顺序展开研究。旨在提升表面缺陷检测的准确性、鲁棒性与实用性，推动铜带表面质量检测方法走向智能化、实用化与产业化。本文主要研究内容如下：

（1）铜带表面非均匀光照退化图像的复原方法。工业冷轧现场复杂的照明环境及铜带表面的镜面反射特性，极易导致图像局部过曝或欠曝，造成对比度下降、细

中国知网　https://www.cnki.net

节丢失和伪影干扰，从而削弱缺陷特征的可见性并引发漏检与误检，降低了检测系统的准确性与可靠性。本文首先在实验室搭建采集平台，收集真实非均匀光照退化样本，同时结合 Retinex 成像模型设计了一种非均匀光照合成方法，构建了覆盖多种非均匀光照模式的退化数据集。在此基础上，借鉴多尺度曝光校正思路，引入 Laplacian 金字塔分解的多尺度曝光校正框架，对图像进行由低频到高频的逐层处理，实现全局色彩与局部细节的协同优化。最后，构建并训练了适用于铜带表面的非均匀光照校正模型，以实现对复杂工业环境下曝光退化的有效复原。

（2）铜带表面雾气退化图像的复原方法。冷轧生产中的雾气是由轧制油分子和其他气溶胶颗粒在空气中聚集产生的物理现象，该现象会导致空气透明度下降，从而引发视觉模糊。在雾气环境中拍摄的图像质量通常会严重下降，主要表现为对比度降低、细节纹理丢失以及褪色等问题。本文基于冷轧生产现场采集的图像数据提出一种铜带雾气退化图像生成方法，通过提取暗通道先验值进行 k-means 聚类，降低了场景深度的估计误差，使用引导滤波器细化透射率图，减少了生成图像与真实图像之间的差异。通过该方法生成三种具有不同程度雾气的退化图像，并构建了包含真实图像和生成图像两种类型退化图像的复合数据集。最后，以两阶段弱监督去雾架构 RefineDNet 为核心，基于复合数据集对其进行训练，得到了铜带去雾模型，该模型能够有效恢复铜带表面纹理细节和缺陷特征，实现复杂工况下的图像增强。

（3）多源数据驱动的铜带表面缺陷智能检测。工业数据的获取在实际生产中容易受到环境、空间等因素的影响，数据集规模、质量均会受到一定限制，一些缺陷的诱发条件较为苛刻，只能采集到很少量的样本，可能引起数据集类间分布不均衡，进而导致模型出现训练偏向性或过拟合问题。首先，以少量实际样本为基础，通过去噪扩散概率模型训练缺陷生成模型得到高质量多样化的缺陷生成样本。进一步提出一种将真实样本、标准增强样本、mixup 样本与生成样本结合的多源数据融合策略，以增加样本规模并缓解类间不均衡问题。

（4）以 RT-DETR 网络为基础进行轻量化改进，提出了新颖的 Adaptive partial convolution 基本卷积算子，并以此为基础构建了轻量化主干特征提取网络 PResNet，并在特征输出阶段添加高效多尺度 EMA 注意力机制。利用该网络训练多源样本得到缺陷检测模型，该模型在检测精度和速度上实现了性能的均衡，具有较高的泛化能力和鲁棒性，能够满足生产要求。

（5）铜带区域快速智能分割与跑偏量辅助检测方法。在冷轧生产中，工业相机

中国知网 https://www.cnki.net

采集的原始图像通常包含复杂背景，若直接输入缺陷检测模型，极易导致模型受到无关特征干扰，出现误检或漏检现象。为解决这一问题，基于现场采集的实际生产图像构建了铜带区域分割数据集，利用快速语义分割网络建立了铜带区域快速智能分割模型作为图像预处理前置环节，通过铜带区域的高效、精确提取减少背景干扰并降低无效计算开销，从而提升检测的准确性与效率。同时，冷轧过程中由于缺乏有效检测手段，铜带经常发生跑偏现象，影响表面缺陷定位精度。为此，结合分割结果提出边缘位置提取算法，用于实时辅助计算铜带的跑偏量和几何尺寸信息，为缺陷的空间定位提供可靠支撑。

（6）工业检测系统的设计与应用验证。结合铜带生产线的应用场景，完成了硬件架构搭建与软件系统集成。在模型层面进行了微调与优化，并探索了基于 TensorRT 的轻量化部署方案。同时，开发了基于 LabVIEW 的人机交互界面，实现了检测结果的可视化、实时交互与报警提示。最终，通过现场实验验证了本文方法在工业环境下的适应性与应用效果。

图 1-9 为本文主要研究路线。

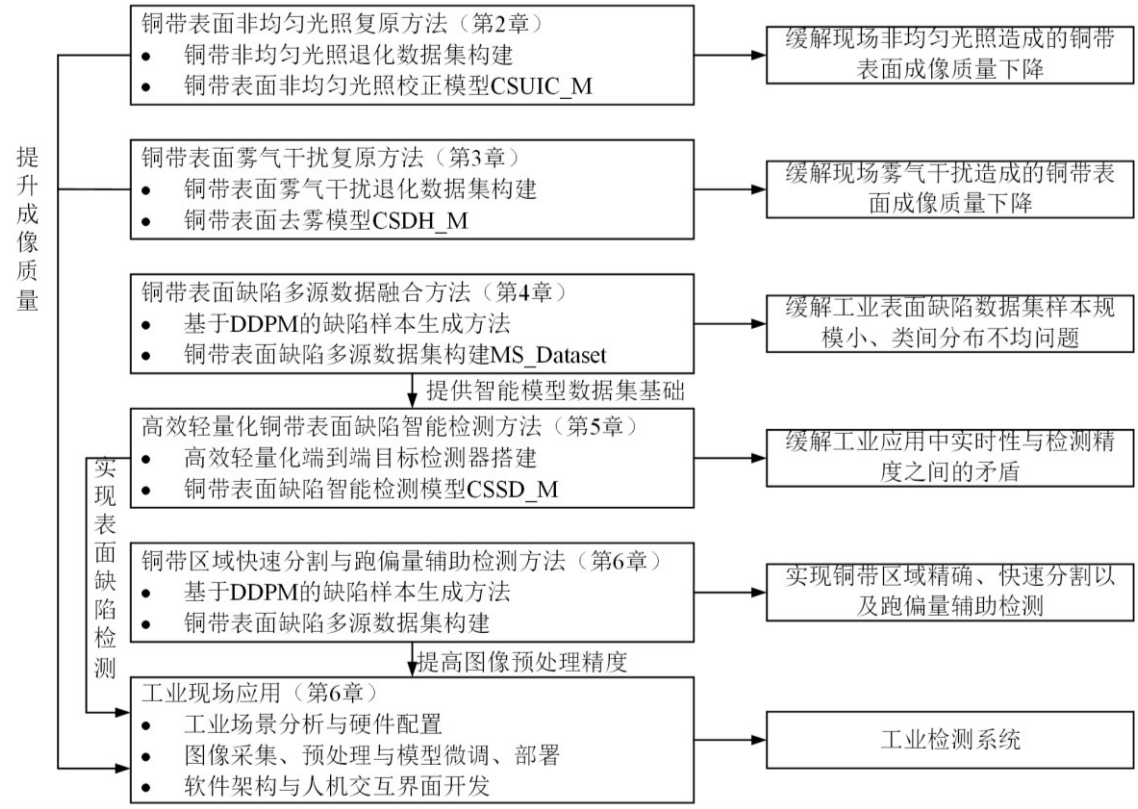


图 1-9　研究路线

Fig.1-9　Research roadmap

中国知网　https://www.cnki.net

第 2 章　铜带表面非均匀光照退化图像复原方法

工业现场中的机器视觉系统经常面临复杂多变的成像环境，其中非均匀光照是影响图像质量的关键因素之一。光照分布不均会导致采集图像出现亮度与对比度退化，削弱表面细节表达能力，进而降低成像质量与缺陷检测系统的稳定性。基于深度学习的图像复原方法虽然在效果上具有显著优势，但通常依赖大规模成对训练数据，而工业现场难以获取此类严格配对样本。为此，本章提出一种基于 Retinex 成像理论的非均匀光照退化图像合成方法，用于模拟真实生产环境中的多种光照不均现象，并据此构建了铜带表面非均匀光照退化数据集。在此基础上，引入基于 Laplacian 金字塔分解的多尺度光照校正框架，从而有效缓解非均匀光照导致的图像质量下降问题，为后续高精度缺陷检测提供更加稳定与可靠的图像输入。

2.1　铜带表面真实非均匀光照图像采集

相比生产现场，实验室的环境条件更加稳定，便于精确控制光源位置等关键参数。因此，本章在实验室环境中开展非均匀光照条件下铜带表面的图像获取工作。本文作者所在实验室引入了一套工业级图像采集实验平台(MV-DK2500-XS1800)。该平台具备高精度、可调节、模块化等特点，可在实验室环境中稳定地开展连续成像实验，图像采集实验平台整体结构如图 2-1 所示。

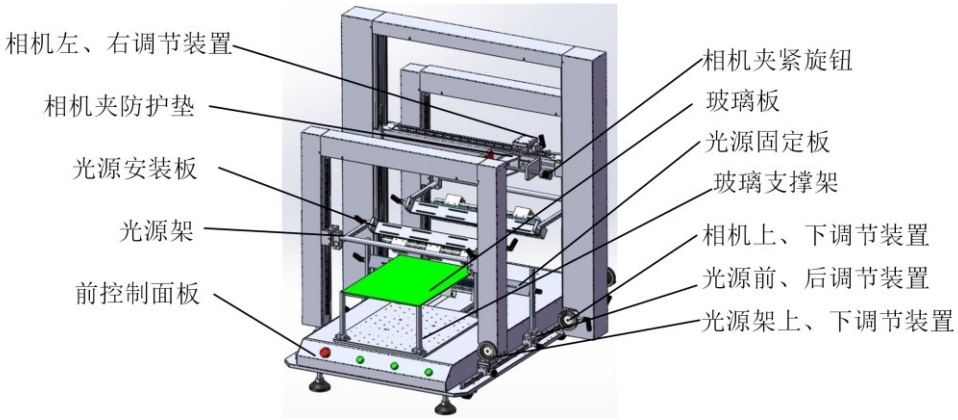


图 2-1　工业级图像采集平台整体结构

Fig. 2-1　Overall structure of the industrial-grade image acquisition platform

该平台整体结构由高精度运动系统、光源模块、相机安装结构、PLC 控制系统

中国知网　https://www.cnki.net

及人机交互界面组成。其中，平台采用丝杆+导轨结构，最大运动行程为 550 mm，最大速度可达 500 mm/s，具备较高的稳定性，能够模拟生产线金属带材的均匀移动过程。通过旋转编码器与 PLC 控制模块联动，实现运动位置的精准控制与同步触发信号输出，便于获取具有精确空间位置标记的图像数据。丝杆导程为 10 mm，配合每圈输出 2500 个脉冲的编码器，可实现高分辨率行触发控制。实验平台还支持 4 个位置的相机触发功能，通过设置触发点可实现在指定位置采集图像的需求，适应多种采集任务。平台配备专用工业相机安装夹具，最大开口宽度为 130 mm，具备上、下微调与垂直角度调节功能，可实现相机的精确定位、对焦及角度优化，确保相机处于最佳成像状态。该结构还支持稳定夹紧，避免采集过程中的位移或震动。光源部分由两个龙门式机架固定在导轨上，支持光源在前后、左右、上下方向的移动与 360° 旋转调节，用户可根据缺陷类型与表面反光情况灵活调整照明角度，以实现最优光照效果。此外，平台下方配备玻璃载台及背光装置，可安装线光源用于背光成像，进一步拓展了图像采集方式的多样性。平台配有触摸屏式人机控制界面，支持手动、自动、单动与连动等多种运行模式。用户可设置运动起止位置、速度、相机触发时间与位置等参数，具备良好的可操作性与实验灵活性，人机控制界面如图 2-2 所示。



图 2-2　人机控制界面

Fig. 2-2　Human-machine control interface

平台可安装最大幅宽为 650 mm 的待测带材，工作台有效承载宽度为 400 mm。运动平面可安装 4 根支柱用于支撑 465 mm×400 mm 的玻璃板，整个平台重量约 300 kg，保证了系统的结构稳定性和抗干扰能力，图像采集平台实物图如图 2-3 所示。

中国知网　https://www.cnki.net



图 2-3　图像采集平台

Fig. 2-3　Image acquisition platform

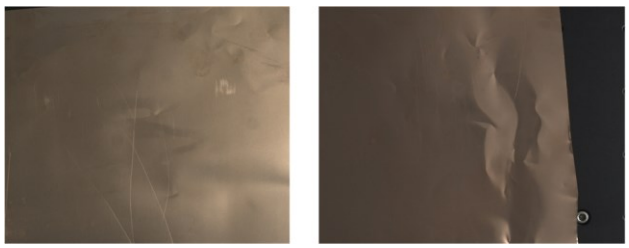
本文作者在企业开展了一段时间的技术调研与交流，并在企业技术人员的协助下收集了一批来源于实际生产线、具有典型表面缺陷特征的真实铜带样本，如图 2-4 所示。这些样本能够较为真实地反映工业环境下铜带表面缺陷的形成机制与分布规律。随后，将其带回实验室依托工业图像采集平台进行拍摄，通过设置不同光照条件以模拟真实生产场景中的非均匀光照环境。为突出非理想工况对成像质量的影响，实验过程中引入光源布置不均、局部遮挡以及角度偏移等因素，获得了一批具有非均匀光照特性的退化图像。所采集的真实铜带表面非均匀光照退化图像如图 2-5 所示。



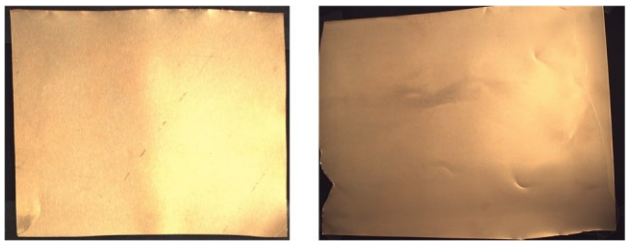
图 2-4　生产现场收集的具有典型缺陷的铜带样本

Fig. 2-4　Copper strip samples with typical defects collected from the production site

中国知网　https://www.cnki.net



(a)弱光照



(b)强光照

图 2-5　非均匀光照条件的铜带图像

Fig. 2-5　Copper strip images under non-uniform illumination conditions

2.2　铜带表面非均匀光照图像合成方法与数据集构建

2.2.1　Retinex 成像理论

Retinex 成像理论基于人类视觉系统对亮度与颜色感知的机制，属于一种颜色恒常性知觉的计算模型[171]。该理论旨在解释人类视觉系统对颜色与亮度的感知规律，核心思想在于揭示物体颜色恒常性的本质。Retinex 理论认为图像由光照分量和反射分量组成，其中光照分量指物体的光照入射分量，用 $L(x,y)$ 表示。反射分量则指物体的反射特性，用 $R(x,y)$ 表示。可根据式(2-1)获得图像 $I(x,y)$：

$$I(x,y)=R(x,y)\cdot L(x,y) \tag{2-1}$$

Retinex 理论是目前图像亮度建模与增强中广泛应用的基础模型之一，已经从单尺度 Retinex 方法[172]发展为多尺度 Retinex 方法[173]，并进一步发展为色彩恢复的多尺度 Retinex 方法[174]。近年来随着深度学习技术的发展，基于 Retinex 理论的深度学习模型[76,175]也不断被提出。

2.2.2　非均匀光照退化图像合成方法

基于深度学习的图像复原与增强方法训练过程高度依赖于包含清晰图像与对应

中国知网　https://www.cnki.net

退化图像的大规模配对数据集。然而，在真实工业场景中精确采集大量配对数据极其困难。为此，提出一种两阶段非均匀光照图像合成方法。首先，基于各向异性高斯分布函数，通过引入坐标仿射变换，构建了一个能够模拟任意方向和椭圆形状的光照分量模拟函数。进一步，根据 Retinex 理论，将该函数生成的光照图以乘性方式作用于清晰图像，在空间维度上引入了非均匀光照退化。其次，为模拟数字成像链路中普遍存在的传感器非线性响应，引入伽马校正来对图像的全局亮度和对比度进行非线性调整，使生成图像的像素分布更符合真实相机的成像特性。该方法能够最终生成符合真实复杂环境的非均匀光照退化图像，为深度学习模型的训练和评估提供了数据基础。

为了生成任意位置、任意方向和任意形状的光源，首先对图像的原始坐标系进行变换，使其与光源坐标系对齐，以光源为中心归一化后的平移变换坐标(x_0, y_0)见式(2-2)：

$$\begin{cases} x_0 = \dfrac{x - x_c}{d_{\max}} \\ y_0 = \dfrac{y - y_c}{d_{\max}} \end{cases} \tag{2-2}$$

其中，(x, y)表示图像原始坐标；(x_c, y_c)表示在图像范围内随机选择的光源中心点坐标，用于实现光照位置的随机化；$d_{\max}$表示从光源中心(x_c, y_c)到图像四个角点的最大欧几里得距离。

在归一化坐标系中，各向异性高斯核表达式为：

$$G(x_0, y_0) = \exp\left(-\frac{1}{2}\left[\left(\frac{x_0}{\sigma_x} \right)^2 + \left(\frac{y_0}{\sigma_y} \right)^2 \right] \right) \tag{2-3}$$

其中，$\exp(\cdot)$表示自然指数函数；σ_x和σ_y分别表示沿椭圆光斑主轴和次轴方向的标准差，若$\sigma_x = \sigma_y$，生成圆形光源，若$\sigma_x \neq \sigma_y$，则生成椭圆形光源。

为模拟旋转后的任意倾斜角度光照，根据二维旋转矩阵：

$$\begin{pmatrix} x' \\ y' \end{pmatrix} = \begin{pmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{pmatrix} \begin{pmatrix} x_0 \\ y_0 \end{pmatrix} \tag{2-4}$$

其中，θ表示随机选择的旋转角度，弧度制；(x', y')表示旋转变换得到的坐标系。

旋转后的各向异性高斯核表达式为：

中国知网 https://www.cnki.net

$$G\left(x',y';\sigma_x,\sigma_y\right)=\exp\left(-\frac{1}{2}\left[\left(\frac{x'}{\sigma_x}\right)^2+\left(\frac{y'}{\sigma_y}\right)^2\right]\right) \tag{2-5}$$

最后，由旋转各向异性高斯模型生成的光照图为$\tilde{L}\left(x,y\right)$：

$$\tilde{L}\left(x,y\right)=v_{\min}+\left(v_{\max}-v_{\min}\right)\cdot\exp\left(-\frac{1}{2}\left[\left(\frac{x'}{\sigma_x}\right)^2+\left(\frac{y'}{\sigma_y}\right)^2\right]\right) \tag{2-6}$$

其中，$v_{\max}$和$v_{\min}$分别表示随机采样的光照图的最小值和最大值。

在传统的 Retinex 模型中，图像亮度被视为反射率与照度的乘积。本文使用的原始图像是在实验模拟平台下采集的，采用了稳定可控的人工光源，原始图像中的照度分布较为均匀，为此，将原始图像的灰度分量$I_{gt}\left(x,y\right)$近似视为表面反射分量$R\left(x,y\right)$。生成的非均匀光照退化图像$I'\left(x,y\right)$：

$$I'\left(x,y\right)=I_{gt}\left(x,y\right)\cdot\tilde{L}\left(x,y\right) \tag{2-7}$$

上述过程模拟的是光线到达物体表面的物理现象。而此阶段将模拟光线经过相机镜头，被感光元件捕获并转化为数字信号的过程。几乎所有数字成像系统都存在非线性响应，即输出的像素值与入射光能量不成正比。通过伽马校正可以实现对这一过程的一阶近似，得到最终的非均匀光照退化图像$I_{\deg}\left(x,y\right)$：

$$I_{\deg}\left(x,y\right)=C_{\max}\left(\frac{I'\left(x,y\right)}{C_{\max}}\right)^{\gamma} \tag{2-8}$$

其中，$C_{\max}$表示图像数据类型的最大值，对于 8 位灰度图像，一般为 255；γ表示随机采样的伽马系数。

2.2.3　构建数据集

为了生成具有真实性和多样性的非均匀光照退化图像，在退化建模过程中引入多组可调节参数，用于控制光照分量的空间分布形态与成像系统的非线性响应特征。通过调节这些参数，可以系统性地模拟工业场景中常见的亮度不均、光源位置、边缘遮挡等光照退化现象，进而生成多样化的退化图像。

本文将这些超参数分为两大类：光照几何与形态参数和光照强度与响应参数，分别用于控制退化过程的不同环节。

（1）光照几何与形态参数

中国知网　https://www.cnki.net

光照几何与形态参数用于控制光照的空间位置、方向和形状，包括：光源中心位置(x_c, y_c)、光源旋转角度θ和各向异性高斯分布标准差(σ_x, σ_y)。其中，(x_c, y_c)直接决定了光源的位置，改变(x_c, y_c)的值，相当于在图像中移动光源；θ控制光源的方向，当光源为椭圆形时（即$\sigma_x \neq \sigma_y$），改变θ会使椭圆光源发生旋转，用于模拟非水平或垂直的条状光源或倾斜角度的投影；(σ_x, σ_y)是高斯分布函数在变换后坐标系(x', y')的两个主轴方向上的标准差，它们是经过归一化的相对尺度，代表了光强沿这两个方向衰减的速度，σ_x和σ_y的值越大，光源尺寸越大，光照衰减越平缓，视觉效果越柔和。反之，光源尺寸越小，光照衰减越剧烈，视觉效果越集中。此外，当$\sigma_x = \sigma_y$时，为正圆形光源。当$\sigma_x \neq \sigma_y$时，为椭圆形光源，σ_x / σ_y决定了光源的扁平程度。

（2）光照强度与响应参数

光照强度与响应参数负责调节光照的亮暗、对比度以及最终的成像非线性效应，包括：光源最亮中心的光强系数$v_{\max}$、最远边缘的环境光强系数$v_{\min}$和伽马系数γ。其中，$v_{\max}$和$v_{\min}$共同决定了光照的整体亮度与对比度，若二者均大于 1，图像整体偏亮；小于 1，则整体偏暗。当$v_{\max} > v_{\min}$时，产生中心亮、边缘暗的效果，当$v_{\max} < v_{\min}$时，模拟中心被遮挡或逆光的特殊效果；参数γ是伽马校正幂律变换的指数，用于模拟成像传感器的非线性响应特性，$\gamma \neq 1$会改变图像的整体亮度感知和对比度，$\gamma > 1$时，图像的暗部细节被压缩，亮部细节被拉伸，整体对比度增强；$\gamma < 1$ 时，图像的暗部细节被提升，亮部细节被压缩，整体对比度降低。

为系统合成不同类型的退化图像，预设定四种具有不同非均匀光照模式的参数范围组合，如表 2-1 所示。具体参数从设定范围中随机采样，保证不同退化图像间具备充分的样本多样性，最终合成的不同模式退化图像如图 2-6 所示。



(a)原始图像　(b)模式 1　(c)模式 2　(d)模式 3　(e)模式 4

图 2-6　合成的不同模式非均匀光照图像

Fig. 2-6　Synthetic non-uniform illumination images with different patterns

本文在实验平台共采集了 104 张正常光照下的铜带表面缺陷图像，以及对应的

中国知网　https://www.cnki.net

非均匀光照下的图像。为提高非均匀光照模式的多样性，以真实正常光照图像为基础，通过表 2-1 中的四种模式合成非均匀光照图像。最后按照 9:1 的比例划分为训练集 Trainset 和测试集 Testset，划分后的数据集分布如表 2-2 所示。

表 2-1　不同模式非均匀光照退化合成参数

Table 2-1　Synthesis parameters for non-uniform illumination degradation in different modes

模式		1	2	3	4
		均匀弱光	不均匀弱光	均匀强光	不均匀强光
参数范围	x_c	(0, w)	(0, w)	(0, w)	(0, w)
	y_c	(0, h)	(0, h)	(0, h)	(0, h)
	θ	(0, 180°)	(0, 180°)	(0, 180°)	(0, 180°)
	$v_{\min}$	(0.85, 0.95)	(0.6, 0.8)	(1.05, 1.15)	(0.9, 1.05)
	$v_{\max}$	(0.9, 1.05)	(0.9, 1.10)	(1.10, 1.25)	(1.30, 1.5)
	σ_x / σ_y	(0.6, 0.8)	(0.25, 0.45)	(0.6, 0.8)	(0.25, 0.45)
	γ	(0.9, 1.1)	(0.8, 1.0)	(1.0, 1.2)	(1.0, 1.3)

表 2-2　非均匀光照图像数据集分布

Table 2-2　Distribution of non-uniform illumination image dataset

数据集	图像类型	光照类型	图像数量	总计
Trainset	真实图像	真实非均匀光照	93	465
	合成图像	模式 1	93	
		模式 2	93	
		模式 3	93	
		模式 4	93	
Testset	真实图像	真实非均匀光照	11	55
	合成图像	模式 1	11	
		模式 2	11	
		模式 3	11	
		模式 4	11	

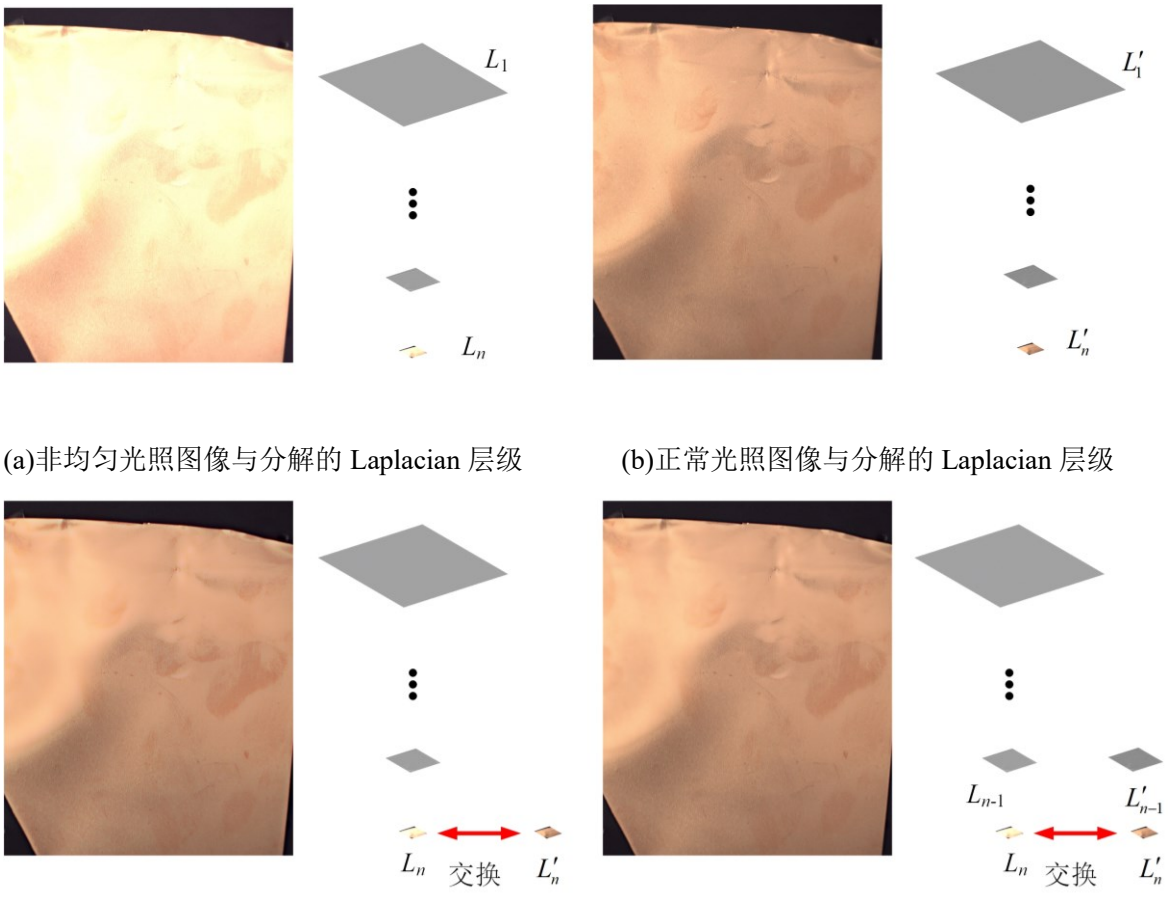
2.3　铜带表面非均匀光照图像复原方法

2.3.1　基于 Laplacian 金字塔分解的非均匀光照校正框架

针对铜带表面非均匀光照问题，本文采用一种基于 Laplacian 金字塔分解的校正方法[176]。该方法借鉴多尺度曝光校正的思想，图 2-7 阐释了采用拉普拉斯金字塔进

中国知网　https://www.cnki.net

行多尺度图像分析与信息分离的基本原理，为后续构建的从粗到细非均匀光照校正框架提供了理论依据。首先，将输入的铜带表面非均匀光照图像（如图 2-7(a)）与对应的正常曝光参考图像（如图 2-7(b)）分别进行拉普拉斯金字塔分解。此分解过程将每张图像表示为一系列不同尺度的层级，其中最低分辨率的基底层（图中 L_n 层）主要包含图像的全局低频信息，如整体亮度、色彩分布及基础结构轮廓。而其余较高分辨率的层级（图中 L_1 至 L_{n-1} 层）则依次捕捉从粗到细的局部高频细节，如边缘与纹理信息。



(a)非均匀光照图像与分解的 Laplacian 层级　　(b)正常光照图像与分解的 Laplacian 层级

(c)替换 L_n 层级　　(d) 替换 L_n 和 L_{n-1} 和层级

图 2-7　基于 Laplacian 金字塔分解的非均匀光照校正基本思想

Fig. 2-7　Basic principle of non-uniform illumination correction based on Laplacian pyramid decomposition

进一步，通过层级替换实验来验证全局信息与局部细节在金字塔中的分离特性。图 2-7(c)展示了将输入图像金字塔的最低层 L_n 替换为正常曝光图像对应的最低层 L'_n

中国知网　https://www.cnki.net

后进行重建的结果。由图可知，仅替换最低层即可显著校正图像的全局曝光和色调，而图像原有的局部纹理细节得以保留。图 2-7(d)展示了同时替换输入图像金字塔的最后两层（最低层 L_n 和次底层 $L_{n\text{-}1}$）后重建的结果，相较于仅替换最低层，图像在全局曝光校正的基础上，部分细节也得到了改善。图像的全局光照信息主要编码于拉普拉斯金字塔的低频基底层，而不同尺度的细节信息则分布于其余各层。这一特性表明，可以通过分层处理的方式，首先校正低频层以恢复整体曝光，再逐层向上修正高频层以增强细节，从而实现有效的曝光校正。在此基础上，设计卷积神经网络以自低到高的方式逐层对这些不同尺度分量进行校正。

（1）整体框架

首先，模型在低尺度层通过神经网络预测并恢复合理的亮度分布，校正因过曝或欠曝造成的整体曝光偏差；随后，在中、高尺度层通过神经网络逐级增强图像的细节信息，实现缺陷区域纹理与边缘的逐步还原。最终，各层校正结果通过重建融合，生成亮度均匀且清晰的复原图像。该方法的整体框架如图 2-8 所示，主要包括 Laplacian 金字塔分解、多尺度校正网络、损失函数设计与图像重建四个模块。

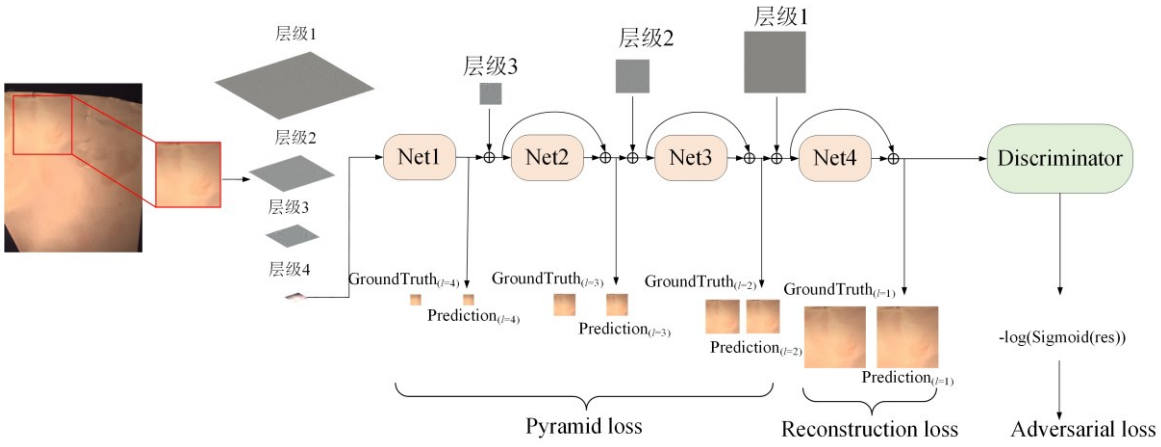


图 2-8　非均匀光照校正框架

Fig. 2-8　Non-uniform illumination correction framework

（2）图像预处理

在图像处理领域，Laplacian 金字塔是一种多尺度图像表示方法[177]，能够将输入图像分解为不同频率和分辨率的尺度层，从而实现局部细节与全局信息的分离。给定输入图像为 $I \in \mathbb{R}^{H\times W}$，通过迭代的低通滤波与下采样操作，得到第 l 层 Gaussian 金字塔图像 G_l：

中国知网　https://www.cnki.net

$$\begin{cases} G_1 = I \\ G_l = \mathcal{D}\left(\mathcal{H}\left(G_{l+1}\right)\right) & \left(l = 1 \sim 4\right) \end{cases} \tag{2-9}$$

其中，$\mathcal{H}(\cdot)$表示 Gaussian 低通滤波；$\mathcal{D}(\cdot)$表示下采样操作。

得到 Gaussian 金字塔序列$\{G_1, G_2, G_3, G_4\}$后，通过相邻层的差分构建 Laplacian 金字塔：

$$\begin{aligned} L_4 &= G_4 \\ L_l &= G_l - \mathcal{U}\left(G_{l+1}\right) \quad \left(l = 1 \sim 3\right) \end{aligned} \tag{2-10}$$

其中，$\mathcal{U}(\cdot)$表示上采样与 Gaussian 插值操作；L_l 表示第 l 层。

最终，得到各尺度 Laplacian 金字塔：

$$L_{Laplacian} = \{L_1, L_2, L_3, L_4\} \tag{2-11}$$

（3）非均匀曝光校正网络结构设计

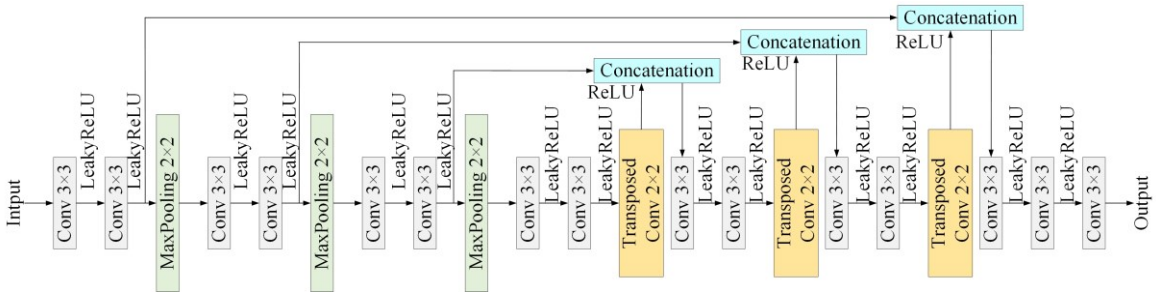
本文采用的神经网络由四个子网络顺序堆叠构成，以端到端方式进行训练。该设计符合多尺度 Laplacian 金字塔校正思路：第一个子网络负责低频全局亮度校正；后续网络聚焦于中级尺度层与高级尺度层细节的逐级修复。每个子网络均为具有非共享权重的编码器-解码器结构，并采用跳跃连接以保留多尺度特征。每个子网络主要由卷积层 Conv2D、最大池化层 MaxPooling2D、反卷积层 Transposed Conv2D 和拼接层 Concatenation 组成，具体结构如图 2-9 所示。

子网络 1、2、3 均为三层编码器-解码器结构。其中，子网络 1 的输入为 Laplacian 金字塔的最低尺度层 L_1，主要负责全局曝光与色调的校正，其输出结果经过一个的反卷积层（尺寸为 2×2、步长为 2）进行上采样。子网络 2 与子网络 3 主要用于中级尺度层的细节残差修复。子网络 2 接收来自子网络 1 的上采样输出与 L_3 的相加结果，输出残差并叠加至输入。随后，再通过反卷积层（尺寸为 2×2、步长为 2）进行上采样。子网络 3 结构与第二子网络相同，进一步输出残差并加回输入，完成更细一级尺度层的校正。

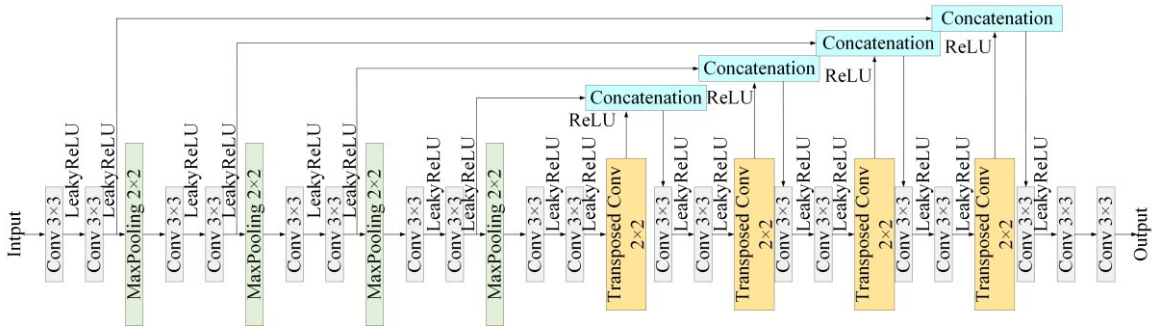
子网络 4 为四层编码器-解码器结构，用于高频细节恢复与最终输出。子网络 4 的输入为子网络 3 的结果与 Laplacian 金字塔高频带 L_1 的相加结果，负责最高分辨率下的细粒度结构重建，输出最终复原图像。

在网络的对抗生成训练中，使用了一个具有 7 层卷积层的轻量化判别器网络。在输入判别器之前，将所有图像块统一调整为 256×256 像素。判别器最后一层的输出为一个标量值，该值在优化过程中用于损失计算。

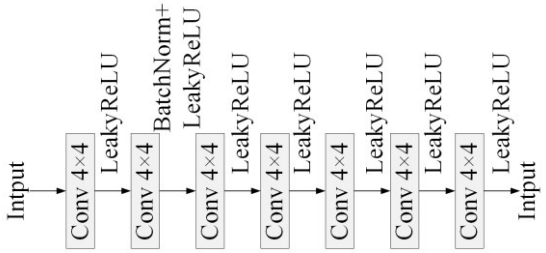
中国知网 https://www.cnki.net



(a)子网络 1、2、3 结构



(b)子网络 4 结构



(c)判别器结构

图 2-9　网络结构

Fig. 2-9　Network structure

（4）损失函数

损失函数包括重建损失 L_{rec}、金字塔损失 L_{pyr} 和对抗损失 L_{adv} 三部分。

重建损失 L_{rec} 使用 $L1$ 损失函数计算重建图像 Y 与参考图像 T 之间的差异：

$$L_{rec}=\sum_{p=1}^{3hw}\left|Y(p)-T(p)\right| \tag{2-12}$$

其中，h 和 w 分别表示训练图像的高和宽；p 表示重建图像 Y 和对应参考图像 T 中每个像素的索引。

中国知网　https://www.cnki.net

为引导每个子网络遵循 Laplacian 金字塔重建过程，专门引入金字塔损失 L_{pyr}。给定 $T^{(l)}$表示参考图像 T 的 Gaussian 金字塔第 l 层在上采样两倍后的结果，则金字塔损失 L_{pyr} 计算公式如下：

$$L_{pyr}=\sum_{l=2}^{n}2^{(l-2)}\sum_{p=1}^{3h_l w_l}\left|Y^{(l)}(p)-T^{(l)}(p)\right| \tag{2-13}$$

其中，h_l 和 w_l 分别表示训练图像 Laplacian 金字塔第 l 层高度和宽度的两倍；p 表示在第 l 层级重建图像 Y 和对应参考图像 T 中每个像素的索引。

最后，引入对抗损失作为正则项，其定义为：

$$L_{adv}=-3hwn\log\left(\text{sigmoid}\left(\text{D}\left(Y\right)\right)\right) \tag{2-14}$$

其中，$\text{sigmoid}(\cdot)$表示 sigmoid 函数；D 表示与曝光校正网络同时训练的判别器。

最终损失函数为：

$$L=L_{pyr}+L_{rec}+L_{adv} \tag{2-15}$$

2.3.2 训练细节

训练过程中未使用整幅原始图像，而是将其拆分成不同尺寸大小的图像块进行训练。主要原因包括以下几点：首先，整幅图像通常分辨率较高，采用小尺寸图像块训练能够显著降低计算资源消耗，提高训练效率；其次，图像块训练能够增加样本数量，使模型在有限数据集上具备更好的泛化能力；最后，不同尺寸图像块的递进式训练可以逐步提升模型对不同尺度特征的学习能力，先在低分辨率块上学习全局曝光与颜色校正，再在高分辨率块上细化局部纹理与细节增强，从而更好地实现粗到细的曝光校正目标。具体而言，对每张图像分别进行随机裁剪，获得 10 个 128×128 的图像块、6 个 256×256 的图像块和 4 个 512×512 的图像块，如图 2-10 所示。

本文采用迁移学习进行训练，在训练前加载文献[176]给出的预训练权重。训练过程使用 Adam 优化器最小化损失函数，优化器衰减指数 β_1 设置为 0.9，β_2 设置为 0.99。曝光校正网络初始学习率设置为 10^{-4}，判别器初始学习率设置为 10^{-5}，学习率策略使用按步衰减策略，γ 设置为 0.1。将训练过程性能最优的权重参数保存作为铜带非均匀光照校正模型 CSUIC_M。

中国知网 https://www.cnki.net

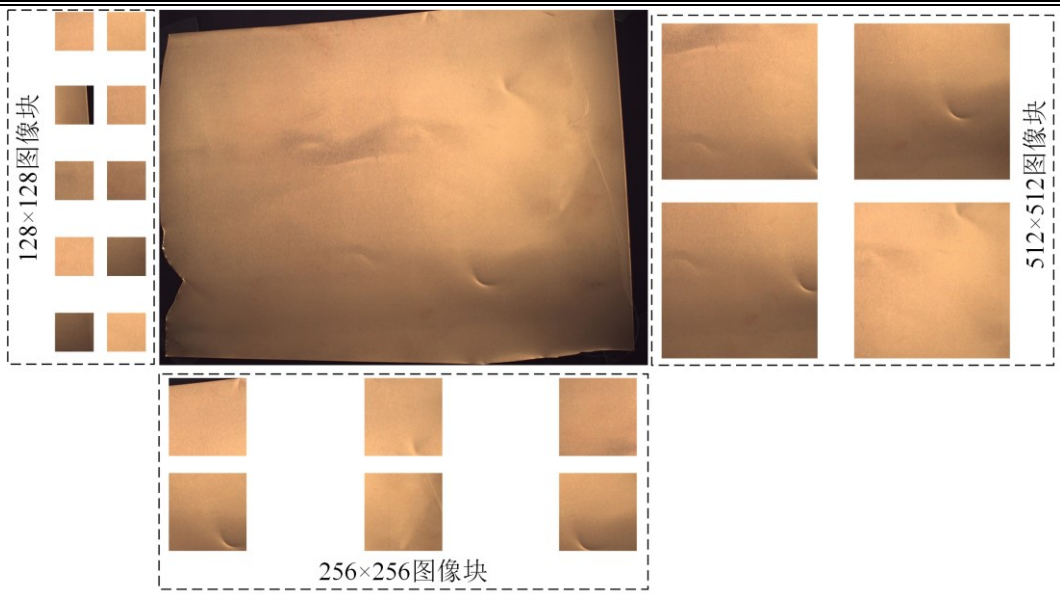


图 2-10　图像块提取

Fig. 2-10　Image patch extraction

2.3.3　结果分析

为评估非均匀光照校正算法的效果，采用两种定量评价指标对校正前后的图像质量与结构信息进行分析，包括：峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）和结构相似性（Structural Similarity Index Measure, SSIM）。PSNR 是一种用于度量重建或增强图像与参考图像（通常为高质量“无失真”图像）之间失真程度的传统客观指标，常用于评价图像增强、压缩和复原算法的重建效果。PSNR 值越高，增强结果与参考图像差异越小，主观质量越高，但对结构、纹理等高阶信息不敏感。首先计算图像均方误差（MSE），定义如下：

$$MSE=\frac{1}{MN}\sum_{i=1}^{M}\sum_{j=1}^{N}\left[X\left(i,j\right)-Y\left(i,j\right)\right]^2 \tag{2-16}$$

PSNR 的计算基于 *MSE*，定义如下：

$$PSNR=10\cdot\log_{10}\left(\frac{MAX_X^2}{\mathrm{MSE}}\right) \tag{2-17}$$

其中，$X\left(i,j\right)$为原始参考图像；$Y\left(i,j\right)$为增强或复原后图像；M，N 为图像的宽和高；MAX_X为参考图像 $X\left(i,j\right)$中像素值最大值。

SSIM 指标通过对比参考图像与增强图像的亮度、对比度和结构三个方面，评价图像整体结构信息的保持程度。SSIM 取值范围为[0,1]，越接近 1 表示结构越相似，

中国知网　https://www.cnki.net

更贴近人眼对图像结构的主观评价，适用于检测纹理、边缘等高阶特征的保持能力。*SSIM* 定义如下：

$$SSIM\left(X,Y\right)=\frac{\left(2\mu_X\mu_Y+C_1\right)\left(2\sigma_{XY}+C_2\right)}{\left(\mu_X^2+\mu_Y^2+C_1\right)\left(\sigma_X^2+\sigma_Y^2+C_2\right)} \tag{2-18}$$

其中，X 和 Y 分别表示参考图像和复原图像；μ_X 和 μ_Y 分别为图像 X 和 Y 在局部窗口内的均值，表示图像平均亮度；σ_X^2 和 σ_Y^2 分别为图像 X 和 Y 在局部窗口内的方差，表示图像对比度；σ_{XY} 为协方差，表示图像 X 和 Y 的结构相似性；C_1 和 C_2 为常数。

为对比评估 CSUIC_M 的效果，选取其它算法作为对比，包括：ACE[178]、SSR[172]、MSR[191]、GAMMA 校正[179]和 MSRCR[174]五种光照校正算法。表 2-3 给出了各种方法在测试集 Testset 上的对比结果。在 Testset 中真实图像上，本文方法的 PSNR 和 SSIM 值分别达到了 19.71 和 0.89。在 Testset 中合成图像上，CSUIC_M 的 PSNR 和 SSIM 值分别达到了 23.47 和 0.93，在所有对比方法中取得了最佳结果。

表 2-3　不同曝光校正方法在测试集上的对比结果

Table 2-3　Comparison results of different exposure correction methods on the test set

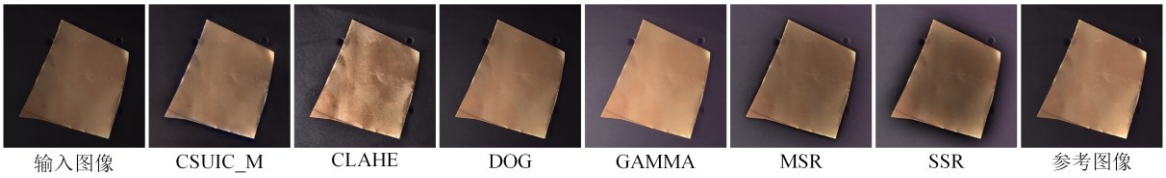
图像类型		评估指标	曝光校正方法					
			CLAHE	DOG	GAMMA	SSR	MSRCR	CSUIC_M
真实图像	\	PSNR	18.19	20.09	17.96	13.12	12.55	19.71
		SSIM	0.77	0.85	0.84	0.70	0.68	0.89
合成图像	1	PSNR	16.07	20.83	19.90	13.31	12.61	25.29
		SSIM	0.77	0.92	0.91	0.74	0.72	0.94
	2	PSNR	19.52	19.87	19.68	13.75	12.91	24.14
		SSIM	0.84	0.90	0.89	0.75	0.72	0.94
	3	PSNR	16.66	19.47	13.28	14.57	13.65	22.52
		SSIM	0.76	0.88	0.74	0.70	0.68	0.93
	4	PSNR	15.15	17.70	11.93	14.82	13.90	21.94
		SSIM	0.71	0.83	0.69	0.66	0.65	0.92
	平均值	PSNR	16.85	19.47	16.20	14.11	13.27	23.47
		SSIM	0.77	0.88	0.81	0.71	0.69	0.93

中国知网　https://www.cnki.net

图 2-11 和图 2-12 分别给出了 CSUIC_M 和其它对比方法的复原结果，可以看出 CSUIC_M 在针对非均匀光照的校正效果优于其它方法，并且在颜色和细节恢复方法均具有优异性能。



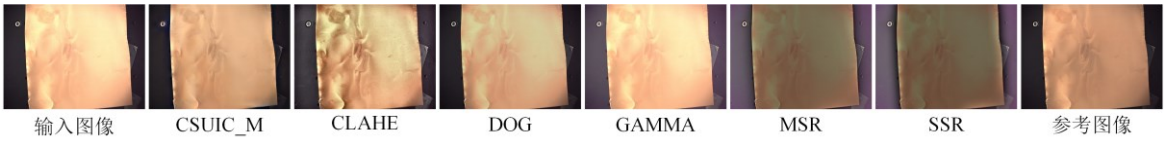
(a)模式 1



(b)模式 2



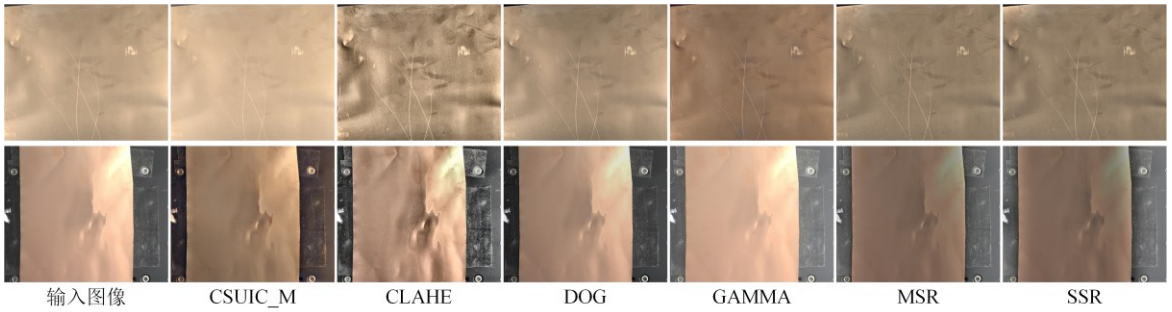
(c)模式 3



(d)模式 4

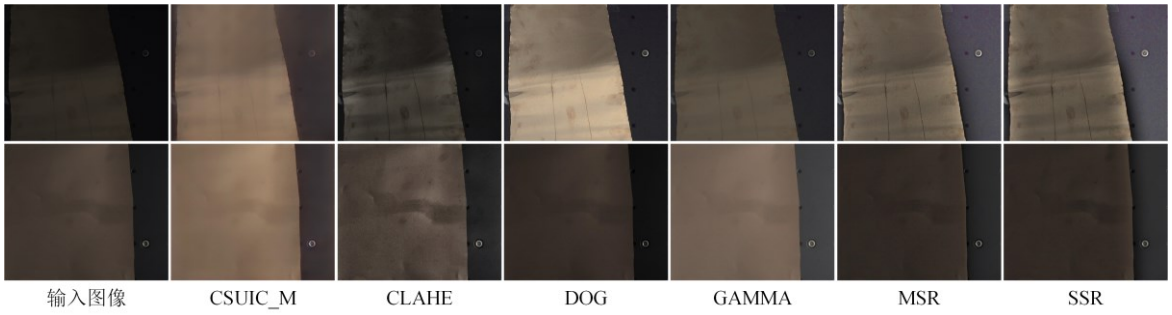
图 2-11　不同方法在 Testset 中合成图像上的复原结果

Fig. 2-11　Restoration results of different methods on synthetic images in Testset



(a)强光照

中国知网　https://www.cnki.net



(b)弱光照

图 2-12　不同方法在 Testset 中真实图像上的复原结果

Fig. 2-12　Restoration results of different methods on real-world images in Testset

2.4　本章小结

本章系统构建了铜带表面非均匀光照图像合成与复原方法。首先，通过在实验室采集真实样本，并提出一种基于 Retinex 理论的两阶段图像合成方法，构建了一个覆盖多种光照模式的退化数据集。基于该数据集，采用 Laplacian 金字塔分解的多尺度校正框架，训练并得到了铜带表面非均匀光照校正模型 CSUIC_M。实验结果表明，该模型在测试集上的 PSNR 和 SSIM 指标分别达到了 23.47 和 0.93，显著优于其它经典的光照增强算法。从视觉效果上看，复原后的图像不仅亮度分布更为均匀，而且缺陷区域的颜色与纹理细节也得到了高质量恢复，为后续铜带表面缺陷智能检测任务的准确性与鲁棒性提供了关键的数据支撑与技术保障。

中国知网　https://www.cnki.net

第 3 章　铜带表面雾气退化图像复原方法

冷轧生产现场中，雾气干扰导致的图像质量退化削弱了缺陷检测系统的稳定性。针对工业场景下难以获取严格配对训练数据的实际问题，提出了一种透射率图细化方法，基于大气散射模型用以合成不同程度雾气的退化样本，并据此构建了铜带表面雾气退化数据集。在此基础上，采用一种两阶段弱监督去雾框架，可有效恢复铜带表面的纹理细节与缺陷特征，显著提升图像清晰度与特征可辨性，从而增强视觉检测系统在复杂工况下的鲁棒性与可靠性。

3.1 铜带表面真实雾气图像采集

本章数据采集自国内某冷轧铜带生产现场，此产线的主体设备为一台 800 mm 四辊可逆轧机，主要生产的铜带宽度规格为 400 mm~650 mm，产线现场如图 3-1 所示。以轧机为中心左、右对称布置有除油辊、测厚仪、激光测速仪、板形辊、偏导辊和卷取机等设备，产线布置示意图如图 3-2 所示。四辊可逆轧机板形调控装置包括：轧辊倾斜、轧辊弯曲、分段冷却等。此产线还配备了由燕山大学自主研制的整辊无线式板形仪和板形在线控制系统。板形辊安装在轧机出口、卷取机前，实时检测包覆在板形辊上的铜带径向力分布，同时兼具导向辊的作用。本章所用的图像采集设备为工业面扫描相机，安装在板形辊斜上方，实时采集板形辊上铜带图像，采集过程如图 3-3 所示。



图 3-1　800mm 四辊铜带冷轧产线

Fig. 3-1　800 mm four-high copper strip cold rolling production line

中国知网　https://www.cnki.net

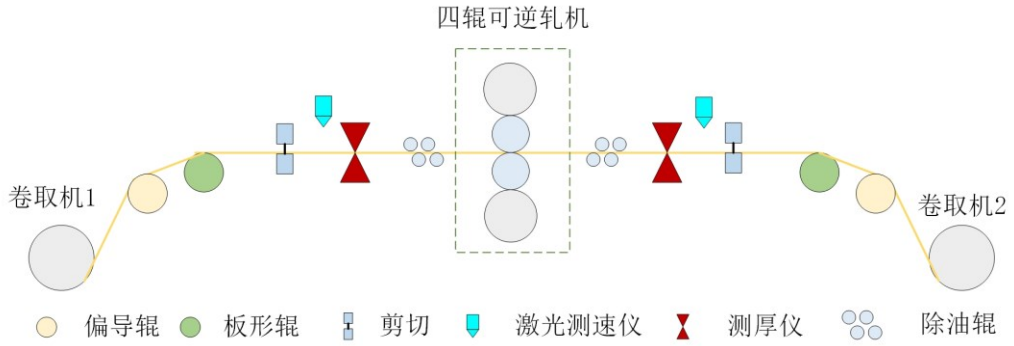


图 3-2　800mm 四辊铜带冷轧产线布置示意图

Fig. 3-2　Layout schematic of the 800 mm four-high copper strip cold rolling production line

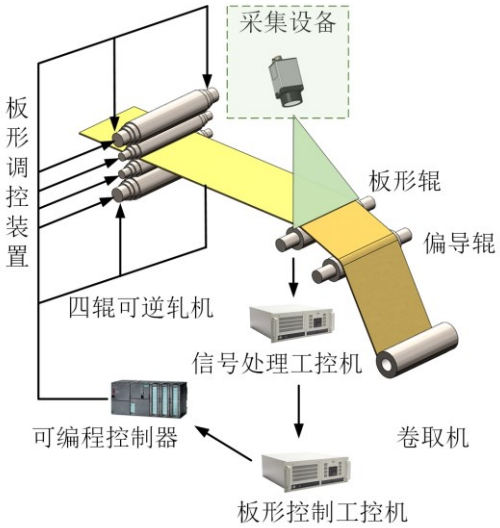


图 3-3　数据采集过程

Fig. 3-3　Data acquisition process

3.2 铜带表面雾气图像合成方法与数据集构建

3.2.1　大气散射模型

根据 McCartney 提出的相关理论[180]，大气散射对光传播的影响主要包括两方面：一是目标反射光在传播至传感器过程中因大气粒子散射导致的光能量衰减；二是环境光经过大气粒子散射后形成的漫反射光到达传感器，增加了图像噪声，降低清晰度。这两种过程共同影响传感器对目标光的接收和成像质量。场景成像机制可用两个模型描述：入射光衰减模型和大气光成像模型。这两个模型揭示了雾气退化图像模糊和低对比度等特点的产生机理，是研究雾气退化机理和图像复原的主要依据，大气散射模型示意图如图 3-4 所示。

中国知网　https://www.cnki.net

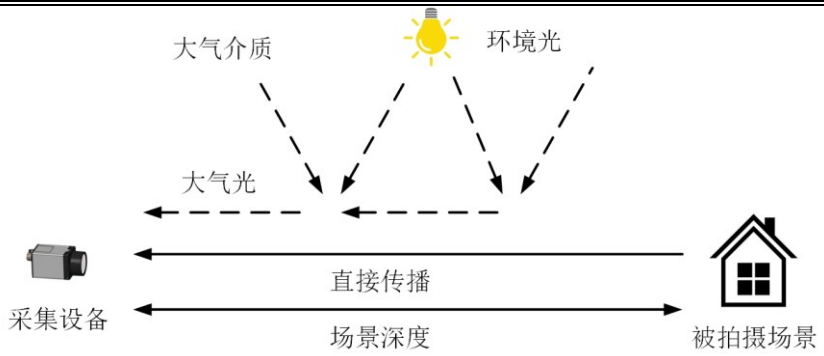


图 3-4　大气散射模型

Fig. 3-4　Atmospheric scattering model

入射光衰减模型描述了被拍摄场景所反射的光传播到采集设备的衰减过程。假设有一束光线从场景发射后在位置 v=0 处进入散射介质，经过每个 dv 厚度的介质，光线会发生部分衰减。经过 v=d 厚度的介质后，衰减后射出光线最终达到采集设备，如图 3-5 所示。

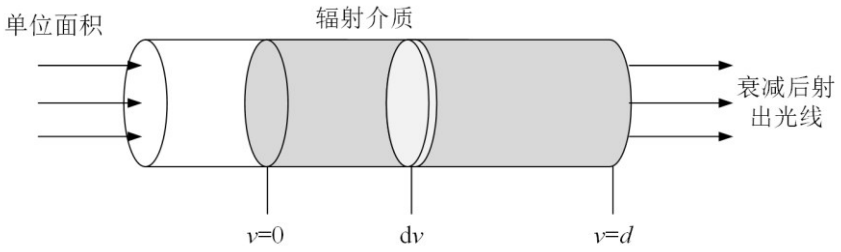


图 3-5　入射光散射衰减原理示意图

Fig. 3-5　Schematic diagram of incident light scattering attenuation principle

假设一束直射光进入到大气介质，当入射光线通过单元区域后，其能量最终可表达为：

$$E_d(d,\lambda)=E_0(\lambda)e^{-\beta(\lambda)d} \tag{3-1}$$

其中，λ 为可见光波长；d 为被拍摄场景到采集设备的距离，即场景深度；$\beta(\lambda)$ 为大气散射系数；$E_0(\lambda)$ 是 v=0 处的光线辐射度。

在光路上半径较大的大气粒子对周围环境的入射光同样有反射作用，因此会有部分光沿着观察路线射向采集装置，这部分光照可以看成由大气产生的光源，称为大气光。假设大气光的方向、强度、光谱未知，沿着采集装置视线方向传播的光线满足能量守恒，则大气光成像模型如图 3-6 所示。

中国知网　https://www.cnki.net

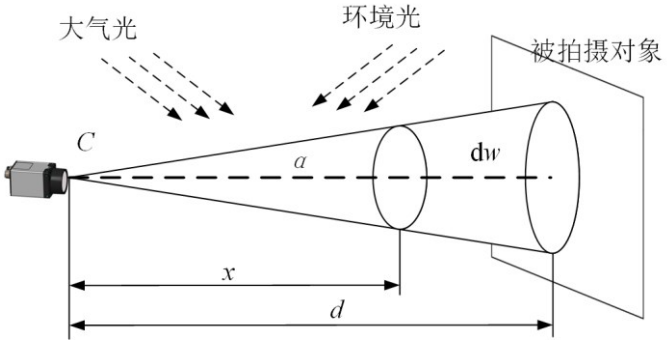


图 3-6　大气成像模型示意图

Fig. 3-6　Schematic diagram of atmospheric imaging model

假设 $E_{\infty}(\lambda)$ 表示无穷远处大气光的辐射度，则到达采集装置处的大气光辐射度可以表示为：

$$E_a(d,\lambda)=E_{\infty}(\lambda)\left(1-e^{-\beta(\lambda)d}\right) \tag{3-2}$$

根据 McCartney 模型，在雾气环境中，大气散射的衰减模型与大气光成像模型共同作用，导致目标图像对比度和分辨率下降。因此，视觉传感器接收到的总辐射度（总强度）可以等效为两部分的线性叠加：一是入射光经大气衰减后到达传感器的景物辐射光，二是周围环境中各种散射光进入成像系统形成的辐射光，即：

$$E(d,\lambda)=E_0(\lambda)e^{-\beta(\lambda)d}+E_{\infty}(\lambda)\left(1-e^{-\beta(\lambda)d}\right) \tag{3-3}$$

式(3-3)中第一项描述的是物体反射的光由于介质的散射而发生的衰减，称为衰减项。第二项表示介质对环境照明的散射，称为散射项。

设 $I(x)=E(d,\lambda)$ 表示有雾条件下图像在位置 x 处的像素值，$J(x)=E_0(\lambda)$ 表示无雾条件下图像在 x 处的像素值，$t(x)=e^{-\beta(\lambda)d}$ 表示透射率，$A=E_{\infty}(\lambda)$ 表示大气光，由此可以得到最广泛使用的雾气退化图像简化模型：

$$I(x)=J(x)t(x)+A\left(1-t(x)\right) \tag{3-4}$$

3.2.2　雾气退化图像合成方法

由式(3-4)可知，合成雾气退化图像，需要清晰图像的对应场景深度图来计算透射率。场景深度图是一种灰度图像，图中每个像素点处的像素值代表场景距采集设备的距离信息，用于描述场景的三维结构。目前有两种主流方法用于获取场景深度：

中国知网　https://www.cnki.net

传统方法和基于深度学习的方法。其中，传统方法需要配备深度传感器或构建立体视觉系统获取清晰图像所对应的深度图，但设备价格昂贵，受现场安装环境限制较大。基于深度学习的单目深度估计方法是获取场景深度图的一种高效且经济的方法。单目深度估计通过使用深度学习模型从单张图像中推断场景深度信息，克服了传统方法在硬件和环境方面的限制。

MiDaS（Monocular Depth Estimation via a Multi-scale Vision Transformer）是由 Ranftl 等人提出的一种基于深度学习的单目深度估计模型[181]，其核心思想是通过大规模数据集的训练，使模型能够适应不同场景和视觉风格，实现高鲁棒性的深度预测。MiDaS 方法不仅能够输出相对深度图，还能保持全局结构的连续性，广泛应用于三维重建、场景理解、工业检测等领域。本文采用经典的单目深度估计方法 MiDaS 基于 Transformer 架构进行预训练的 DPT_Large_384 模型对冷轧生产现场图像进行场景深度图的估算。

进一步，根据场景深度图可以计算初始透射率图。然而，基于深度学习的预训练模型在估计场景深度时可能受到场景分布差异、相机参数不匹配以及噪声等因素影响，导致透射率图中的局部区域存在异常值或不连续现象，降低准确率。为此，提出一种新颖的透射率图细化方法，旨在提高雾气合成精度。

暗通道先验（Dark Channel Prior, DCP）理论[182]认为，在非天空区域的局部区域内，至少有一个颜色通道的强度值非常低，接近于零。暗通道先验值可间接反映场景深度：较大的暗通道先验值对应更远的深度（雾气更重），较小的暗通道先验值对应较近的深度，为雾气合成提供了初步的区域深度信息。

首先，计算原始图像的暗通道先验值。为显著区分关键目标和背景，确保同一类别物体具有一致的透射率，使用 k-means 聚类方法将暗通道先验值分为 3 个类别：铜带、板形辊、背景。进一步，将聚类结果映射到初始透射率图中，分别计算初始透射率图中每个类别的平均透射率值，合成聚类透射率图。最后，根据原始图像灰度图提供的纹理和边缘信息，通过引导滤波器对聚类透射率图进行细化，利用这些信息可以同时平滑透射率图中的噪声并保持边缘特征。本文提出的透射率细化方法整体流程如图 3-7 所示。

最后根据大气散射模型合成雾气退化图像，整体合成流程如图 3-8 所示。

中国知网　https://www.cnki.net

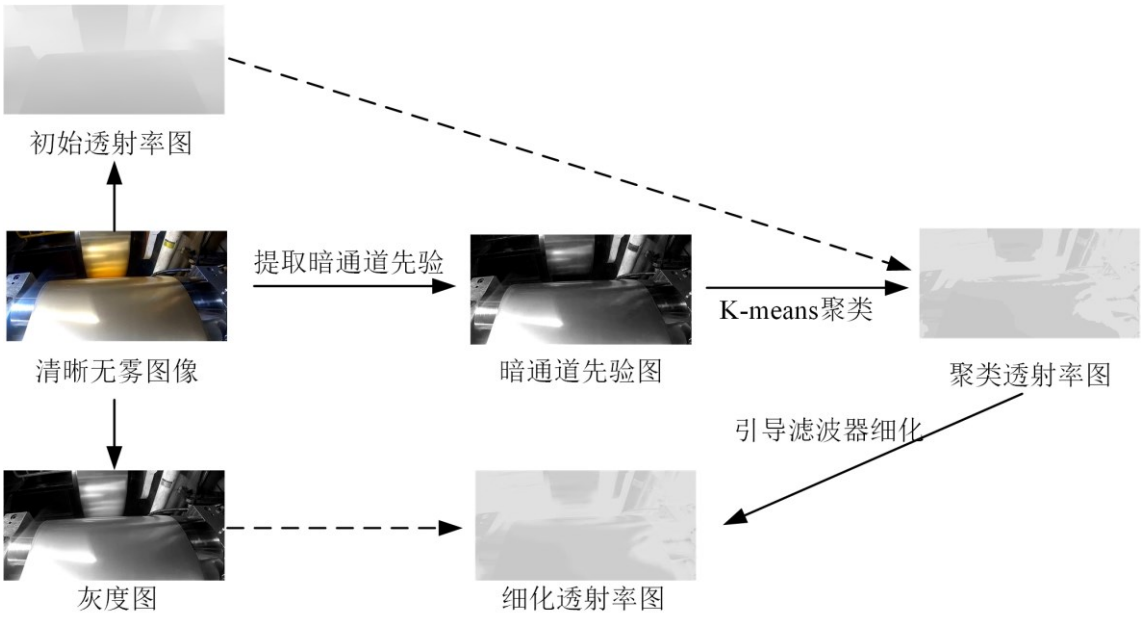


图 3-7　透射率图细化方法

Fig. 3-7　The refine method for transmission map

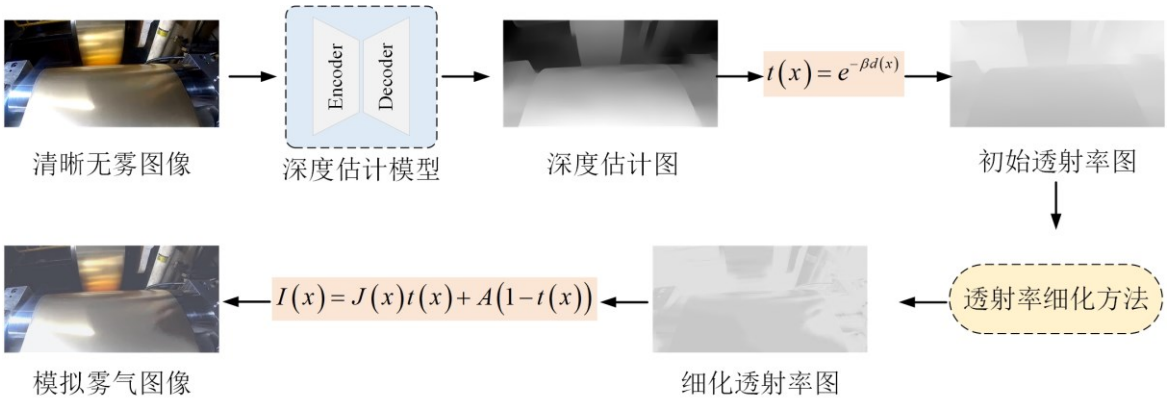


图 3-8　雾气退化图像合成流程

Fig. 3-8　Haze-degraded image generation process

3.2.3　构建数据集

在大气散射模型中，大气光 A、可视距离 V 和散射系数 β 是用于模拟或逆推图像雾气退化过程的关键参数。

大气光 A 描述的是背景散射光对成像结果的影响，通常表现为图像中最亮区域的亮度。当场景中的物体距离相机趋近于无穷远时，其像素值将逐渐趋于 A。因此，A 控制了雾图整体的明亮程度和偏灰倾向。提高 A 将增强远处区域的亮度，导致图

中国知网　https://www.cnki.net

像整体出现“泛白”效果，增强雾感；降低 A 则产生较暗的雾图，保留部分原始色彩信息。

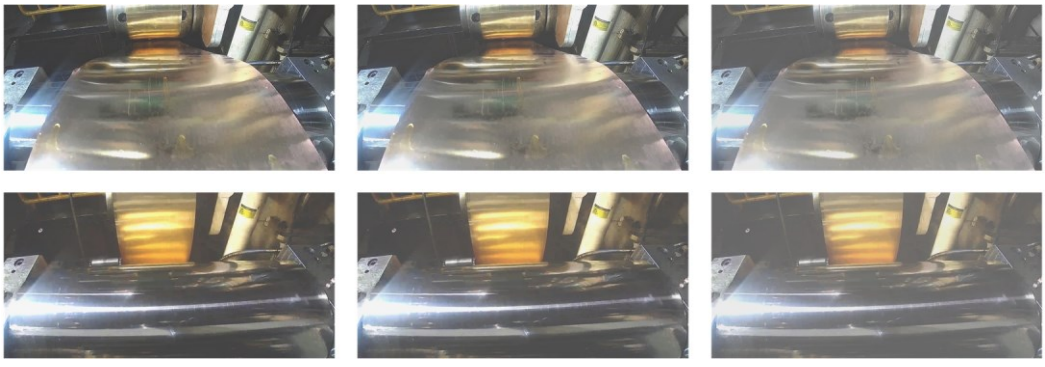
V 是间接控制雾浓度的重要参数。根据 Koschmieder 定律，可视距离与大气散射系数满足如下关系：

$$V=\frac{3.912}{\beta} \tag{3-5}$$

当给定场景深度时，减小 V 会增大 β，从而使透射率 $t(x)$ 更快衰减，导致图像中远处信息几乎不可见。较小的 V 会快速丧失远距离细节，模拟能见度低的环境；而较大的 V 则对应轻度薄雾。

散射系数 β 是描述单位距离内光衰减强度的参数，直接决定透射率 $t(x)$ 的指数衰减速率。随着 β 增大，更多图像区域被背景大气光 A 主导，原始场景信息快速丧失。大 β 值对应强烈雾气退化情形，小 β 值则可合成轻雾或晨雾等场景。

本文从现场采集的大量图像数据中挑选了 100 张不同生产情况下的有铜带清晰图像和 10 张无铜带清晰图像。然后根据 3.2.2 节方法合成三种不同程度（S1-轻微，S2-中度，S3-严重）的雾气图像合成的雾气退化图像，如图 3-9 所示。不同雾气程度图像的合成参数对照表如表 3-1 所示。进一步，再从原始图像中挑选出 210 张不同生产情况下的真实雾气图像，其中有铜带图像 200 张，无铜带图像 10 张。最后将数据集按照 9:1 的比例划分为训练集 Trainset 和测试集 Testset。划分后的数据集分布如表 3-2 所示。



(a)S1　　(b)S2　　(c)S3

图 3-9　合成三种不同程度雾气退化图像

Fig. 3-9　Synthesis of images with three different levels of haze degradation

中国知网　https://www.cnki.net

表 3-1　不同程度雾气对应的合成参数

Table 3-1　Synthesis parameters corresponding to different levels of haze

雾气程度	调节参数		
	A	V	β
S1	0.75	0.4	10
S2	0.85	0.3	12
S3	0.95	0.2	14

表 3-2　不同程度雾气对应的合成参数

Table 3-2　Synthesis parameters corresponding to different levels of haze

数据集	有无铜带	雾气程度			真实	总计
		S1	S2	S3		
Trainset	有	90	90	90	180	486
	无	9	9	9	9	
Testset	有	10	10	10	20	54
	无	1	1	1	1	

3.3　铜带雾气退化图像复原方法

3.3.1　两阶段弱监督去雾框架

针对雾气干扰导致的图像质量退化问题，研究者已提出多种图像去雾方法以恢复图像清晰度与结构信息。现有单图像去雾技术大体可分为两类：基于先验知识的去雾方法与基于深度学习的去雾方法。

基于先验知识的去雾方法通常以大气散射模型为理论基础，通过构建图像中光强分布、颜色饱和度、暗通道等领域先验，估计大气光值与透射率，从而反推出真实场景的辐照图像。代表性方法包括 He 等人提出的暗通道先验方法[182]、颜色衰减先验 ACP 方法[183]等。此类方法具有计算量低、无需大量训练数据、硬件适配性强等优点，适用于资源受限或计算平台能力有限的工业系统。然而，其性能在处理具有高亮区域、严重雾气遮蔽或非自然色彩分布的图像时往往会显著下降，且难以适应复杂工况中多样化的雾气分布特征。

随着深度学习的发展，基于深度学习的去雾方法逐渐成为研究热点。其优势在于模型具备端到端学习能力，能够在训练过程中捕捉复杂的雾气成分、图像纹理与

中国知网　https://www.cnki.net

场景语义之间的高阶关联，从而在真实复杂场景下取得更优的复原效果。然而，该类方法往往需要大量标注数据和高性能计算资源，且在训练过程中可能存在泛化能力不足的问题，尤其是在特定工业场景中获取真实配对数据难度较大的情况下。为此，本文以 RefineDNet[184]为基础，采用两阶段弱监督学习策略构建铜带雾气退化复原模型。

（1）整体框架

RefineDNet 整体架构包括两个阶段，如图 3-10 所示。在第一阶段，采用 DCP 方法合成环境光 A、初步去雾图像 J_{DCP} 和透射率图 T_{DCP}。在第二阶段，T_{DCP} 和 J_{DCP} 分别由细化网络 R_T 和细化网络 R_J 细化为 T_{ref} 和 J_{ref}。训练过程中，为确保 T_{ref} 得到较好的细化，使用 T_{ref}、J_{ref} 和 A 将 I_{real} 重建为 I_{rec}。然后，通过最小化 I_{real} 和 I_{rec} 之间的距离来更新 R_T。此外，附加判别器 D 用于接收 J_{ref} 或 J_{real} 进行对抗学习，并使细化网络 R_J 得到更新。由于没有要求 J_{real} 和 I_{real} 必须取自同一场景，因此网络整体训练过程属于弱监督学习。RefineDNet 还采用基于 IQA 的感知融合策略，通过计算权重将 J_{ref} 和 J_{rec} 进行加权融合作为最终的去雾输出 J_{fused}。

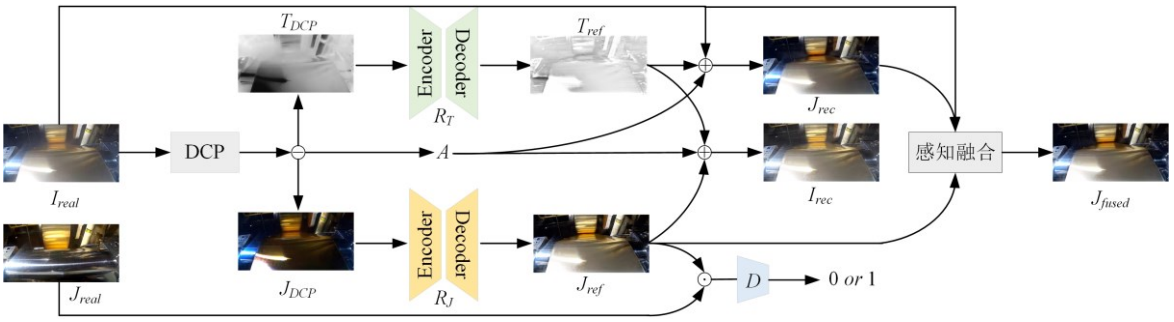


图 3-10　两阶段弱监督学习框架

Fig. 3-10　Two-stage weakly supervised learning framework

（2）基于 DCP 的初步去雾结果

首先，基于 DCP 方法获取初步去雾结果。DCP 方法嵌入在 RefineDNet 中以实现端到端的训练和推理。当 RGB 三通道图像 I_{real} 输入 DCP 模块后，首先计算每个像素位置在三个通道的最小像素值 $I_{min}(x)$：

$$I_{min}(x)=\min_{c\in\{R,G,B\}} I^{c}(x) \tag{3-6}$$

中国知网　https://www.cnki.net

其中，$I^c(x)$表示像素点 x 在 R、G、B 任一通道上的像素值。

进一步，使用尺寸为 5×5 池化核对 $I_{min}(x)$的加法逆进行最大池化操作，然后再次求加法逆，得到暗通道先验图像结果：

$$I_{dark}(x) = -\max_{y\in\Omega(x)}\left(-I_{min}(x)\right) \tag{3-7}$$

其中，$\Omega(x)$表示以 x 为中心的 5×5 邻域窗口。

由式(3-4)可知：

$$I_{dark}(x) = J_{dark}(x)t(x) + A\left(1-t(x)\right) \tag{3-8}$$

其中，$I_{dark}(x)$和$J_{dark}(x)$分别表示有雾图像和清晰图像在像素点 x 处的暗通道先验值。

根据暗通道先验假设，对于没有天空区域的室内场景，大多数局部斑块中至少有一个颜色通道的像素值接近零，即 $I_{dark}(x)\to 0$。则有：

$$t(x) = 1 - \frac{I_{dark}(x)}{A} \tag{3-9}$$

通过图像中亮度较高的区域（如铜带反射表面）像素值来估计环境光 A。因此，选取$I_{dark}(x)$中最亮的前 0.1％像素，并将它们在$I(x)$的颜色通道中的所有像素点平均值作为 A。

（3）网络结构

RefineDNet 中的细化网络 R_T 采用一种具有 U 型结构的深度卷积神经网络 U-Net[70]。U-Net 主要包括收缩路径、扩展路径和连接结构，其中收缩路径和扩展路径呈对称排布，连接结构在收缩路径和扩展路径间，允许网络将浅层特征图与深层特征图进行融合，U-Net 网络结构如图 3-11 所示。

另一细化网络 R_J 则采用具有 9 个残差块的 ResNet。输入的 J_{DCP} 首先通过两次下采样从高分辨率压缩到低分辨率。在低分辨率空间中，使用 9 个 Res_block 块提取高级语义特征。再通过两次上采样恢复到原始分辨率。最后通过卷积层输出与输入相同的通道数，具体结构如图 3-12 所示。

RefineDNet 中的附加判别器 D 使用的是一个具有 5 个卷积层的卷积神经网络，用于判别 R_J 生成结果的真实性。

中国知网 https://www.cnki.net

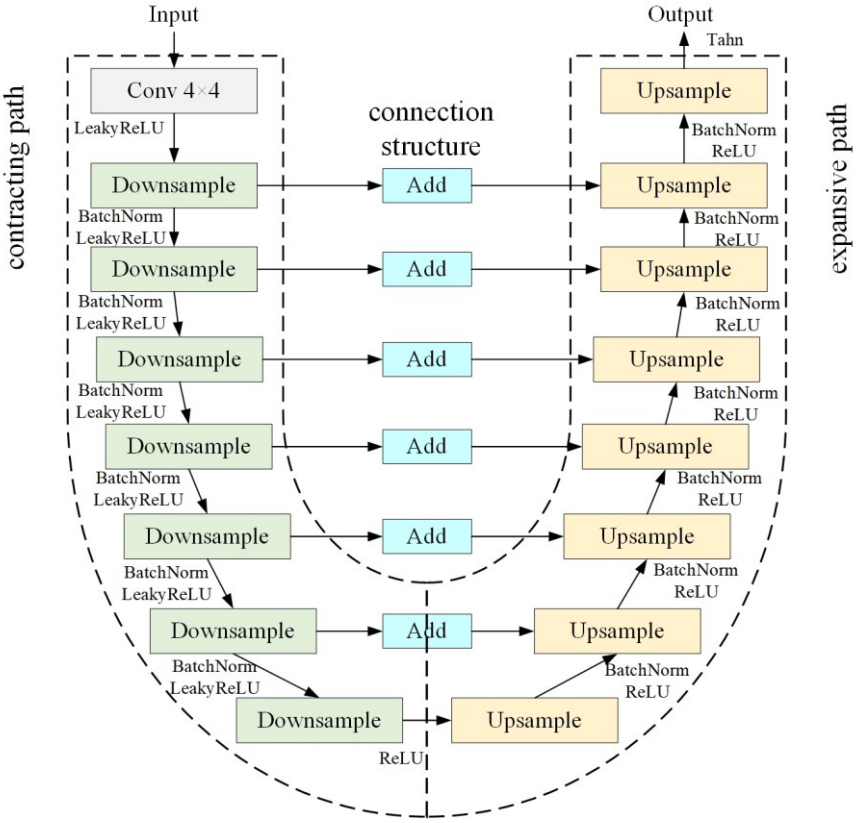


图 3-11　细化网络 R_T 结构

Fig. 3-11　The structure of refiner network R_T

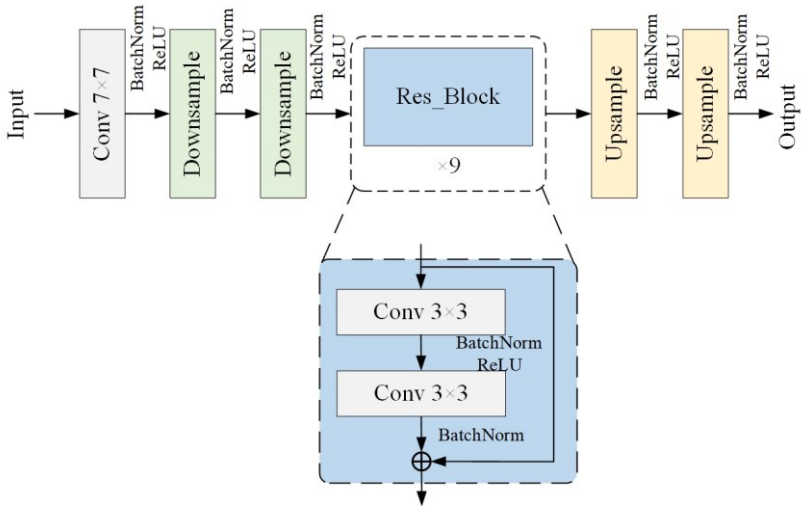


图 3-12　细化网络 R_J 结构

Fig. 3-12　The structure of refiner network R_J

（4）损失函数

RefineDNet 的损失函数包括三项：生成对抗损失 L_G、重建损失 L_{rec} 和一致性损

中国知网　https://www.cnki.net

失 L_{idt}。其中，L_G 用于监督 R_J 和 D 的训练过程，将其定义为：

$$L_G\left(R_J,D\right)=\mathbb{E}_{J_{real}\sim\mathcal{J}_{real}}\left[\log D\left(J_{real}\right)\right]+\mathbb{E}_{J_{DCP}\sim\mathcal{J}_{DCP}}\left[\log\left(1-D\left(R_J\left(J_{DCP}\right)\right)\right)\right] \quad (3\text{-}10)$$

其中，$\mathcal{J}_{real}$ 是包含所有 J_{real} 的集合，$\mathcal{J}_{DCP}$ 是包含所有 J_{DCP} 的集合。

L_{rec} 用于对重建 I_{rec} 进行正则化，定义为 I_{real} 和 I_{rec} 之间的距离，即：

$$L_{rec}=\left\|I_{real}-I_{rec}\right\| \quad (3\text{-}11)$$

其中，I_{real} 是输入的雾气退化图像；I_{rec} 是获得的重建结果；$\|\cdot\|$表示距离度量。

L_{idt} 用于抑制由细化网络 R_J 引入的伪影。当输入为清晰无雾图像时，L_{idt} 用于引导 R_J 的输出，使其接近输入的清晰无雾图像，L_{idt} 定义为：

$$L_{idt}=\left\|J_{real}-R_J\left(J_{real}\right)\right\| \quad (3\text{-}12)$$

RefineDNet 的最终优化目标表达式如下：

$$R_T^*,R_J^*=\arg\min_{R_T,R_J}\max_{D}\lambda L_G+L_{rec}+L_{idt} \quad (3\text{-}13)$$

其中，λ 是一个超参数，表示 L_G 的权重，设置为 0.02。

（5）感知融合策略

在 RefineDNet 中，J_{rec} 和 I_{rec} 是由不同方式生成的复原图像，在图像的某些区域，其中一个可能比另一个效果更好。因此，RefineDNet 采用 I_{real} 和 J_{ref}（或 I_{real} 和 J_{rec}）之间的相似性图作为复原结果 J_{ref} 和 J_{rec} 的真实性信息指标，并为 J_{ref} 和 J_{rec} 在相似度图中具有较大值的位置分配较大的权重，称为感知融合策略。

相似度图采用 IQA 领域广泛应用的梯度模量（gradient modulus，GM）和色度信息（chrominance information，ChromMN）作为基本特征。其中，GM 在 *YIQ* 颜色空间中的 Y 通道（亮度通道）中计算。首先，Y 通道的表达式如下：

$$Y=0.299\cdot R+0.587\cdot G+0.114\cdot B \quad (3\text{-}14)$$

其中，R，G，B 分别是图像在 *RGB* 颜色空间的三个通道像素值。

进一步，计算特征 GM：

$$G\left(x\right)=\sqrt{G_i^2\left(x\right)+G_j^2\left(x\right)} \quad (3\text{-}15)$$

其中，$G_i(x)$和 $G_j(x)$是该图像在 Y 通道像素点 x 处的偏导数。

ChromMN 是指在 *LMN* 颜色空间的 M 和 N 通道值，如式(3-16)：

中国知网 https://www.cnki.net

$$\begin{cases} M = 0.30 \cdot R + 0.04 \cdot G - 0.35 \cdot B \\ N = 0.34 \cdot R - 0.60 \cdot G + 0.17 \cdot B \end{cases} \tag{3-16}$$

通过计算 GM 和 ChromMN 的相似度评估去雾结果的真实性。假设有两张图像的 GM 值分别记为 $G_1(x)$和 $G_2(x)$，则在像素点 x 处的相似度 $S^G(x)$定义为：

$$S^G(x) = \frac{2G_1(x) \cdot G_2(x) + C_1}{G_1^2(x) + G_2^2(x) + C_1} \tag{3-17}$$

其中，C_1 值设置为 160。

对于 ChromMN，假设由第一张图像计算得到的 M 和 N 记为 $M_1(x)$和 $N_1(x)$，由第二张图像计算得到的 M 和 N 记为 $M_2(x)$和 $N_2(x)$，则在像素点 x 处的相似度 $S^C(x)$定义为：

$$S^C(x) = \frac{2M_1(x) \cdot M_2(x) + C_2}{M_1^2(x) + M_2^2(x) + C_2} \cdot \frac{2N_1(x) \cdot N_2(x) + C_2}{N_1^2(x) + N_2^2(x) + C_2} \tag{3-18}$$

其中，C_2 值设置为 130。

综合考虑 $S^G(x)$和 $S^C(x)$，并将整体相似度图 $S^{GC}(x)$定义为：

$$S^{GC}(x) = S^G(x) \cdot \left[S^C(x) \right]^{\alpha} \tag{3-19}$$

其中，α 是用于调整 GM 和 ChromMN 之间相对重要性的参数，设置为 0.4。

假设 $S_{ref}^{GC}(x)$是 $I_{real}(x)$和 $J_{ref}(x)$在像素点 x 处的相似度值，$S_{rec}^{GC}(x)$是 I_{real} (x)和 $J_{rec}(x)$在像素点 x 处的相似度值，则可以通过 softmax 函数将相似度值 $S_{ref}^{GC}(x)$和 $S_{rec}^{GC}(x)$映射为 $J_{ref}(x)$和 J_{rec} (x)在像素点 x 处的权重，将其定义为：

$$\begin{bmatrix} W_{ref}(x) \\ W_{rec}(x) \end{bmatrix} = softmax\left(\begin{bmatrix} S_{ref}^{GC}(x) \\ S_{rec}^{GC}(x) \end{bmatrix} \right) \tag{3-20}$$

其中，$softmax(z_i) = \dfrac{e^{z_i}}{\sum_{k=1}^{n} e^{z_i}}$，且 $W_{ref}(x) + W_{rec}(x) = 1$。

最后，将 J_{ref}和 J_{rec}与其权重进行融合，得到最终的感知融合结果 J_{fused}：

$$J_{fused} = J_{ref} \odot W_{ref} + J_{rec} \odot W_{rec} \tag{3-21}$$

其中，$\odot$表示像素级乘积。

3.3.2　训练细节

为保证客观性，本文所有实验均在标准化平台进行。训练前加载文献[184]的预

中国知网　https://www.cnki.net

训练权重，网络训练的优化器使用 Adam，动量设置为 0.5；Batch-size 设置为 1；学习率设置为 0.0002，输入图像像素尺寸大小设置为 1520×760。最大迭代次数设置为 60，每训练 1 个 Epoch 保存一次模型权重，完成所有 Epoch 训练后将性能最优的权重文件作为铜带表面去雾模型，记为 CSDH_M。

3.3.3 结果分析

为验证本文构建的CSDH_M去雾复原效果，选取了多种经典去雾方法进行对比，包括：基于先验知识的去雾算法 DCP[182]、ACP[183]和基于深度学习的去雾算法 DehazeNet[79]、FFANet[185]，并在测试集 Testset 上分别从主观和客观两方面进行评估。

图 3-13 为 CSDH_M 与其他方法在 Testset 中合成雾气图像上的去雾效果对比。可以看出，ACP 和 FFANet 方法的去雾效果最差，复原图像中雾气残留严重。DehazeNet 和 DCP 方法均能够有效去除不同程度雾气，但复原结果的颜色存在偏差，部分高亮区域存在轻微过饱和现象，颜色失真明显，这是全局大气光估计不准确所导致的。此外，DehazeNet 方法的图像复原结果中细节信息丢失严重。而 CSDH_M 对各种程度雾气的处理结果均表现优异，复原图像的颜色和纹理细节均最接近真实标签。

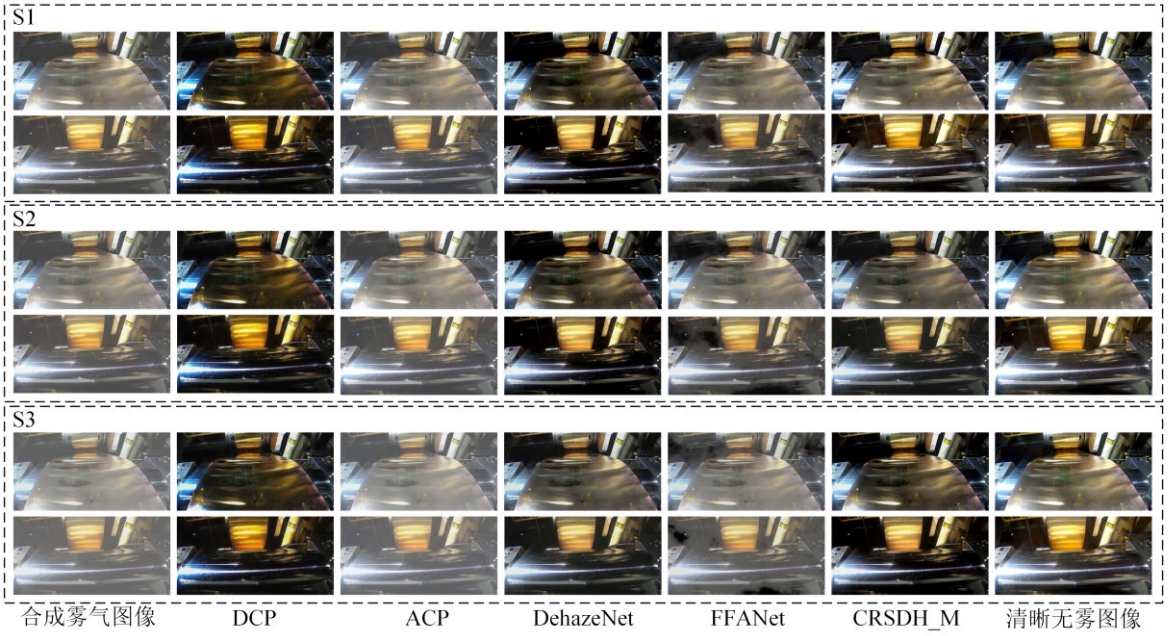


图 3-13　Testset 中合成雾气图像上的去雾效果对比

Fig. 3-13　Comparison of dehazing effects on synthetic hazy images in Testset

中国知网　https://www.cnki.net

图 3-14 为 CSDH_M 与其他方法在 Testset 中真实雾气图像上的去雾效果对比。对于有铜带图像，所有算法均展示出了一定的去雾效果。对于无铜带图像，ACP 和 FFANet 方法去雾效果依然最差。此外，由第一排局部放大图像可以看出，DCP 和 DehazeNet 两种方法的图像复原结果中均出现较为严重的颜色偏差，失真明显。综合对比，本文方法在真实雾气图像上也实现了最好的去雾效果。

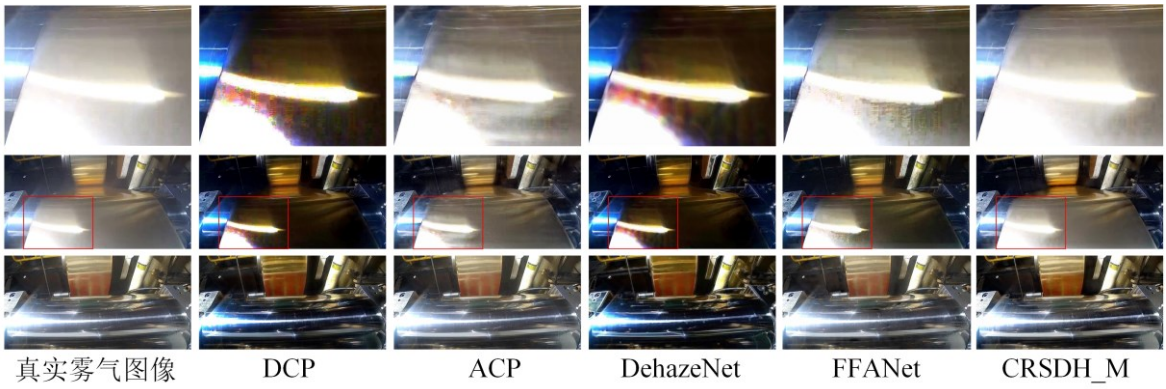


图 3-14　Testset 中真实雾气图像上的去雾效果对比

Fig. 3-14　Comparison of dehazing effects on real-world hazy images in Testset

表 3-3 给出了不同方法在 Testset 中合成雾气图像上的 PSNR 和 SSIM 均值。可以看出，随着雾气浓度的增加，大部分方法的去雾效果均有所下降，只有 DehazeNet 呈现出相反的趋势，由图 3-14 也可以看出 DehazeNet 对低浓度雾气图像容易出现过处理现象，说明模型对雾气浓度的区分能力不足。

表 3-3　不同方法在 Testset 合成雾气图像上的客观评价结果

Fig. 3-3　Objective evaluation results of different methods on synthetic hazy images in Testset

雾气程度	评价指标	模型				
		DCP	ACP	DehazeNet	FFANet	CSDH_M
S1	PSNR	14.11	17.81	17.40	25.01	25.72
	SSIM	0.6778	0.7662	0.6747	0.8380	0.8360
S2	PSNR	14.02	15.84	18.28	21.87	24.87
	SSIM	0.6728	0.7329	0.7325	0.8014	0.8227
S3	PSNR	14.01	12.68	21.09	16.81	22.30
	SSIM	0.6767	0.6729	0.8238	0.7319	0.7950
均值	PSNR	14.05	15.45	18.92	21.23	24.30
	SSIM	0.6758	0.7240	0.7437	0.7904	0.8179

中国知网　https://www.cnki.net

此外，尽管基于先验知识的方法展现出较好的去雾性能，但复原图像与真实图像之间颜色与对比度偏差较大，导致其具有较低的 PSNR 和 SSIM 值。而本文构建的 CSDH_M 模型几乎在所有测试实例中均能够实现最佳的去雾复原效果。

3.4 本章小结

本章系统构建了铜带表面雾气干扰图像合成与复原方法。首先，通过现场采集的真实数据，提出了一种基于大气散射模型的图像合成方法，该方法通过 MiDaS 网络估计场景深度，并利用 k-means 聚类优化暗通道先验以细化透射率图，最终构建了包含真实与合成样本的复合数据集。基于该数据集，采用两阶段弱监督学习框架 RefineDNet，训练并得到了铜带表面去雾模型 CSDH_M。实验结果表明，该模型在合成与真实雾气图像上均取得了最优的复原效果，其 PSNR 和 SSIM 指标平均值分别达到 24.30 和 0.8179，显著优于 DCP、DehazeNet 等多种主流算法。该方法能够有效且高效地解决工业雾气环境下的图像退化问题，复原图像颜色自然、细节清晰，为提升后续缺陷检测任务的精度与稳定性提供了关键技术保障。

中国知网 https://www.cnki.net

第 4 章　铜带表面缺陷多源数据集构建方法

在工业生产中，受环境、设备条件等因素影响，导致铜带表面缺陷样本的获取存在困难，部分缺陷类型样本的严重稀缺造成了数据集的分布失衡，这直接限制了智能检测模型的性能上限。为此，本章提出一种多源样本融合策略，旨在改善数据集的质量。本章所定义的“多源”并非传统意义上源自多传感器或多模态的异构数据，而是特指在单一视觉模态下，通过集成多种数据增强与深度生成技术，构建出一个包含多种统计分布特征的样本集合。该方法作为一种新型的数据驱动策略，对提升检测模型在实际部署中的稳定性和准确率具有至关重要的实践意义。

4.1　铜带表面缺陷数据集构建

本文通过与合作企业开展技术交流与数据共享，获取了在实际生产环境下不同工序环节中采集的铜带表面缺陷图像样本。这些样本均由工业相机采集，具有典型的工业表面缺陷特征，能够反映真实工业环境下的铜带生产状态。鉴于原始数据在图像尺寸上存在差异，本文参考东北大学公开的 NEU-DET[143]中图像格式，采用滑动窗口法对原始图像进行预处理。具体操作如下，设置窗口大小为 256×256 像素，并以 256 像素为步长，按从左至右、从上至下的顺序对图像进行滑动裁剪，最终获得标准化的 256×256 像素大小图像样本。

在此基础上，通过人工方式筛选出包含缺陷的图像。针对铜带缺陷形状不规则、边缘纹理模糊等特点，邀请生产现场经验丰富的表面缺陷质检人员制定了统一的质量检测标准。依据该标准，筛选出对产品外观、性能及后续加工序有显著影响的关键缺陷，并将其划分为 9 类，分别为：黑点（Black Spots, BS）、凹坑（Concave and convex Pits, CP）、边裂（Edge Cracks, EC）、孔洞（Holes, Ho）、虫斑（Insect Spots, IS）、黑线（Black Line, BL）、起皮（Peeling, Pe）、褶皱（Ruffle, Ru）和脏污（Smudges, Sm）。

为系统归纳和分析铜带表面缺陷，本文依据其在冷轧过程中的主要形成机制与根本原因，建立了一套基于成因的科学分类体系。该体系将缺陷划分为三类：（1）材料类缺陷，源于原材料（如铸坯）内部冶金质量问题，在轧制过程中显现或演变；（2）设备类缺陷，由轧辊、导向辊等设备异常或与铜带相互作用引起；（3）介质

中国知网　https://www.cnki.net

类缺陷，因轧制油、乳化液、清洗剂等工艺介质或外部污染造成。该分类方法有助于从机理层面理解缺陷成因，各类缺陷的具体形貌特征与形成原因见表 4-1。

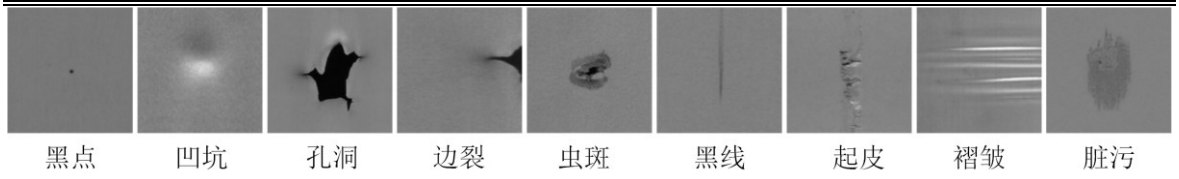
表 4-1　各类缺陷的细节特点

Table 4-1　Detailed characteristics of various types of defects

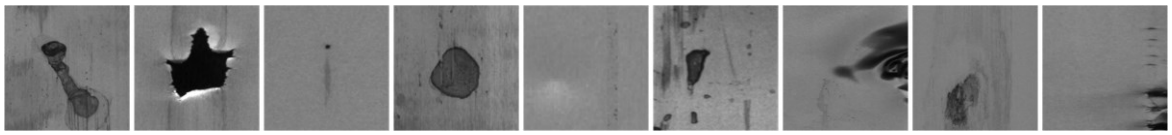
典型缺陷	形貌特征	形成原因	缺陷所属类型
黑点	缺陷呈单个或多个圆形黑色斑点，边缘清晰。	铸坯中存在夹杂物或成分偏析，这些硬质颗粒在轧制过程中会随着塑性变形而流向带材表面。	材料类
边裂	缺陷位于铜带边缘，呈不规则裂纹状向内延伸。	铸造过程中铜熔体的结晶不均匀导致铸坏边缘出现裂纹，而在后续的轧制过程中形成了边缘裂纹。	材料类
孔洞	缺陷呈大小不同和形状不规则的孔洞，周围伴有轻微阴影扩散。	偏析形成氧化硬点，冷轧过程中硬点附近产生应力集中，并形成孔洞。	材料类
起皮	铜带表面出现严重的翘曲，呈现不规则块状凸起。	通常由于铜带表层结合力不足，受张力或杂质夹杂影响造成表层材料局部剥离或翘起。	材料类
黑线	缺陷表现为不同方向的单条或多条细长黑色条带，分布连续或间断且长度不同。	轧辊或偏导辊表面存在缺陷或铜屑，导致表面划痕。	设备类
凹坑	缺陷呈局部不同大小圆形凹陷。	通常由轧辊表面局部凹坑、压痕或异物粒子造成压印，或材料局部塑性变形不均引起表面凹陷。	设备类
褶皱	缺陷呈局部弯曲或起伏状结构，伴随明显的纹理褶皱。	由于张力控制不当或材料厚度不均，在轧制或卷取过程中产生局部失稳而形成褶皱。	设备类
虫斑	缺陷区域呈椭圆状扩散斑块，内部存在不规则黑色斑点，边缘模糊且伴有垂直拖尾纹理。	多因昆虫或有机杂质附着在铜带表面，经过高温退火或压延后碳化并嵌入，形成典型虫斑形貌。	介质类
脏污	缺陷区域呈分散的残留物痕迹，边缘模糊、不规则。	清洁过程中铜条表面出现水渍、油渍、乳化液或其他液体残留物。	介质类

在整理过程中发现，大多数样本仅包含单一类型缺陷，少部分样本同时存在两种及以上缺陷。因此，本文将前者定义为单缺陷样本，将后者定义为复合缺陷样本，典型示例如图 4-1 所示。

中国知网　https://www.cnki.net



(a)单缺陷样本



(b)复合缺陷样本

图 4-1　典型铜带表面缺陷样本

Fig. 4-1　Typical surface defect samples of copper strips

4.2　基于扩散模型的表面缺陷样本生成方法

4.2.1　去噪扩散概率模型 DDPM

DDPM[94]由前向过程和逆向过程组成，均为参数化的马尔可夫链。假设给定原始数据 y_0 和总时间步 T，则前向过程在时间步 T 内向原始数据 y_0 逐步添加随机噪声，直至完全破坏 y_0 中的原始信息，最终得到随机噪声 y_T。此时，y_T 的概率密度函数服从标准高斯分布，见式(4-1)：

$$q\left(\mathrm{y}_T\right)=\mathcal{N}\left(\mathrm{y}_T;0,\mathbf{I}\right) \tag{4-1}$$

其中，$\mathcal{N}\left(\mathrm{y}_T;0,\mathbf{I}\right)$ 表示均值为 0，协方差矩阵为 $\mathbf{I}$ 的标准高斯分布，$\mathbf{I}$ 表示单位矩阵，$\mathbf{I}=\begin{bmatrix}1 & 0 & \cdots & 0\\ 0 & 1 & \cdots & 0\\ \vdots & \vdots & \ddots & \vdots\\ 0 & 0 & \cdots & 1\end{bmatrix}$。

DDPM 的前向过程可定义为式(4-2)：

$$q\left(y_t \mid y_{t-1}\right)=\mathcal{N}\left(y_t;\sqrt{1-\beta_t}\,y_{t-1},\beta_t\mathbf{I}\right) \tag{4-2}$$

其中，t 为时间步，$t\in\{1,2,\cdots,T\}$；y_t 为时间步 t 时的带噪声数据；$\{\beta_t\}$ 为噪声调度，用于控制每个时间步 t 向样本中添加的高斯噪声强度，β_1 和 β_T 是预设的最大值和最小值。β_t 由最小值逐渐增大，保证前期噪声扰动较小，后期噪声能够接近纯高斯分布。

为加快计算速度，y_t 可以直接从 y_0 计算，无需通过 t 次前向过程的迭代。定义

中国知网　https://www.cnki.net

$\alpha_t = 1-\beta_t$，$\bar{\alpha}_t = \prod_{i=1}^{t}\alpha_i$，前向过程可改写为式(4-3)：

$$q(\mathrm{y}_t \mid \mathrm{y}_0) = \mathcal{N}\left(\mathrm{y}_t; \sqrt{\bar{\alpha}_t}\mathrm{y}_0, (1-\bar{\alpha}_t)\mathbf{I}\right) \tag{4-3}$$

重参数化技巧是一种常用的数学方法，用于将随机变量的采样过程从概率分布中解耦出来，从而使得梯度可以通过采样过程反向传播[87]。通过重参数化技巧可以由式(4-3)得到式(4-4)：

$$\mathrm{y}_t = \sqrt{\bar{\alpha}_t}\mathrm{y}_0 + \sqrt{1-\bar{\alpha}_t}\epsilon \tag{4-4}$$

其中，ϵ是从标准高斯分布中采样的随机噪声，$\epsilon \sim \mathcal{N}(0, \mathbf{I})$。

逆向过程对 y_T逐步去除噪声，以恢复原始数据 y_0。每一步逆向过程由 y_t得到的 y_{t-1}也符合高斯分布。然而，对任意时间步 t 的真实后验分布$q(\mathrm{y}_{t-1} \mid \mathrm{y}_t)$难以直接计算，因此使用神经网络进行建模：

$$p_\theta(\mathrm{y}_{t-1} \mid \mathrm{y}_t) = \mathcal{N}(\mathrm{y}_{t-1}; \mu_\theta, \beta_\theta) \tag{4-5}$$

其中，$\mu_\theta(\mathrm{y}_t, t)$为逆向过程中的均值，通过神经网络进行预测；$\Sigma_\theta(\mathrm{y}_t, t)$为逆向过程中的协方差矩阵，一般固定为常量$\sqrt{\beta_t}\mathbf{I}$。

DDPM 通过训练深度神经网络获得噪声预测器，模型输入带噪声数据以及对应的时间步，输出要去除的噪声。DDPM 训练的目标是最小化预测噪声与真实添加噪声的均方误差，如式(4-6)：

$$L_t = \mathbb{E}_{\mathrm{y}_0, t, \epsilon_t}\left[\left\|\epsilon - \epsilon_\theta(\mathrm{y}_t, t)\right\|^2\right] \tag{4-6}$$

其中，$\mathbb{E}$为期望值；ϵ为前向过程添加的随机噪声；$\epsilon_\theta(\mathrm{y}_t, t)$为噪声预测器，输入为噪声数据 y_t和时间步 t，输出为预测的前向过程所添加的噪声。

在已有训练好的噪声预测器和当前时间步 t 的噪声图像后，可以通过式(4-7)进行逆向去噪，生成时间步 t-1 的数据，逆向过程可表达为：

$$\mathrm{y}_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(\mathrm{y}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(\mathrm{y}_t, t)\right) + \sqrt{\beta_t}z \tag{4-7}$$

其中，公式中包含两项，$\frac{1}{\sqrt{\alpha_t}}\left(\mathrm{y}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(\mathrm{y}_t, t)\right)$代表去噪项，用于从当前噪声数据 y_t去除噪声，恢复前一时间步 t-1 的数据 y_{t-1}，$\epsilon_\theta(\mathrm{y}_t, t)$代表噪声预测器预测的噪声，

中国知网 https://www.cnki.net

$\frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}$ 为噪声强度控制因子，将噪声 $\epsilon_\theta(\mathrm{y}_t,t)$ 调整至合适的尺度，$\frac{1}{\sqrt{\alpha_t}}$ 为归一化因子，确保去噪后的样本 $\mathrm{y}_t-\frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(\mathrm{y}_t,t)$ 与原始数据 $\mathrm{y}_{t\text{-}1}$ 处于同一尺度内；$\sqrt{\beta_t}z$ 为噪声项，用于在反向过程添加随机噪声，z 为从标准高斯分布中采样的随机噪声，$z\sim\mathcal{N}(0,\mathbf{I})$，$\sqrt{\beta_t}$ 用于控制反向过程每个时间步添加的噪声强度。

DDPM 的完整训练过程示意图如图 4-2 所示。

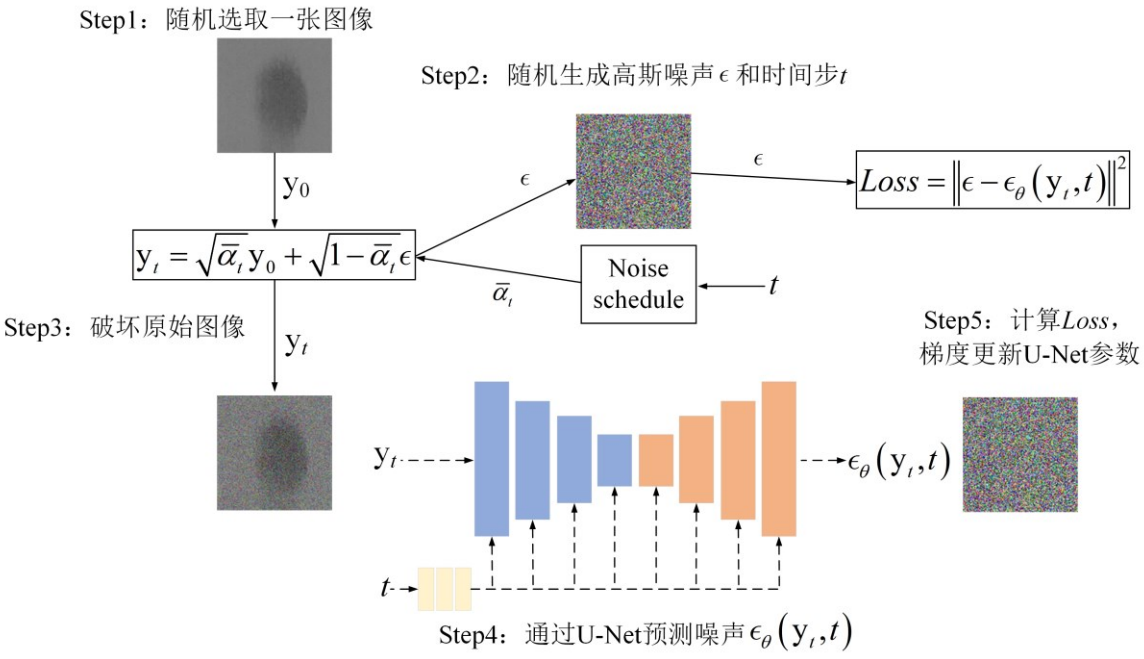


图 4-2　DDPM 训练过程

Fig. 4-2　Training process of DDPM

4.2.2　网络结构

DDPM 的核心任务是学习从高斯噪声逐步恢复为结构化图像的反向扩散过程。因此，生成网络不仅需要具备同时捕捉图像全局结构与局部细节的能力，还需具备在多尺度层次上表征图像特征的能力，从而在全局与局部之间建立有效联系。为此，本章采用具有对称结构的 U-Net 作为基础网络[70]。U-Net 最初应用于医学图像分割，其核心特点在于对称的编码器–解码器架构，并通过多级跳跃连接将编码器的高分辨率特征传递至对应解码器层，从而有效融合全局语义与局部细节信息。

中国知网　https://www.cnki.net

原始 U-Net 网络主要由三部分组成，包含收缩路径、跳跃连接结构与扩展路径，收缩路径与扩展路径呈对称排布，同时在每一级别建立跳跃连接，用于特征融合与细节补偿。为实现基于 DDPM 的高效表面缺陷生成任务，在 U-Net 基础上引入残差模块、时间步嵌入、全局注意力机制等操作。文献[45]提出的具有残差结构的 ResNet 网络有效解决了超深层神经网络在训练过程中出现的梯度爆炸或消失问题，为深层深度神经网络的探索奠定了基础。本文以 ResNet 中的残差块 Res_Block 作为基础模块，设计了一种具有残差结构的 ARes_Block，如图 4-3 所示。通过引入全局注意力机制帮助模型在全局范围内捕捉长距离依赖关系，使网络能够理解图像中远距离区域之间的关系，提高图像生成质量。此外，引入了基于正余弦函数的位置编码，该编码方式能够为每个时间步 t 生成一个高维连续向量，通过每个时间步骤的特定嵌入向量指导网络进行去噪处理。这种设计提升了网络在不同扩散阶段处理噪声的能力，增强了模型的生成效果。

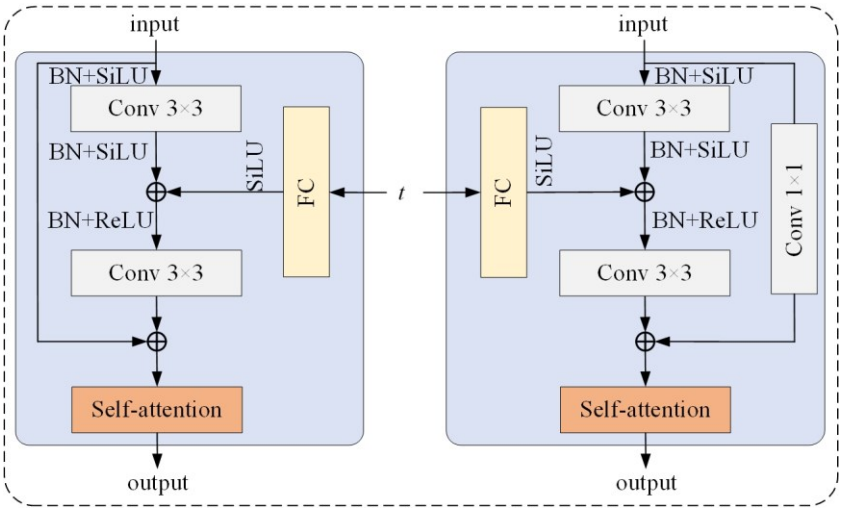


图 4-3　ARes_Block

Fig. 4-3　Attention residual block

首先使用尺寸为 3×3 的卷积核对输入特征进行卷积，提取局部特征信息。相较于 5×5 或 7×7 的大尺寸卷积核，3×3 卷积具有较小感受野，能够捕获更多细粒度特征，并且能在保持特征提取能力的基础上极大减少计算开销。

生成网络需要在每一时间步 $t \in \{1,2,\cdots,T\}$ 对图像的噪声程度进行建模与去噪，因此，必须具备对当前时间步的感知能力。给定时间步 $t \in \mathbb{R}$，目标嵌入维度为 d，为了将时间步 t 嵌入网络中，使用位置编码对时间步 t 进行函数变换，将其映射为一个

中国知网　https://www.cnki.net

具有周期性的高维时间步向量$\mathbf{e}_t \in \mathbb{R}$，其前一半采用正弦函数编码，后一半采用余弦函数编码，确保模型在处理不同的时间步时保留足够的周期性和可区分性。然后通过 ARes_Block 中的全连接层加入到第一个卷积层的输出中，使得网络能够在每个时间步中动态调整去噪策略。通过式(4-8)来计算时间步 t 的位置嵌入：

$$\begin{cases} \mathrm{PE}_t\left[2i\right]=\sin\left(t\cdot s\cdot\exp\left(-\dfrac{i\cdot\log\left(10000\right)}{d/2}\right)\right) \\ \mathrm{PE}_t\left[2i+1\right]=\cos\left(t\cdot s\cdot\exp\left(-\dfrac{i\cdot\log\left(10000\right)}{d/2}\right)\right) \end{cases} \tag{4-8}$$

其中，t 为时间步；d 为嵌入维度；s 为可调缩放因子，用于调节时间嵌入在前期或后期时间步的分布变化速率；i 为位置嵌入中的维度索引。

随后，经过一个 3×3 的卷积核后由残差学习块将输入特征图与输出特征图进行融合，保证输入信息能够直接传递到后续层，缓解特征退化问题。其中，残差学习块有两种结构：identity 残差块和 downsample 残差块。当输入和输出特征维度一致时，可以通过 identity 残差边直接将输入与输出融合，等同于执行了同等映射操作，不产生额外参数以及复杂度。当输入输出特征维度不一致时，需要通过 1×1 卷积调整输入特征的通道维度，进一步实现与输出特征融合。

最后，添加了自注意力机制，自注意力机制利用三个基本的向量（查询 Q、键 K 和值 V）来对输入进行变换，通过计算输入数据内部的各个部分之间的依赖关系，使得每个位置能够根据其他位置的信息进行加权更新，从而捕获全局的上下文信息。

融合残差后的输出进行归一化得到特征图 $X \in \mathbb{R}^{b\times C\times H\times W}$。其中，$b$ 为批次大小，C 为通道数量，W 和 H 分别为特征图的宽和高。将特征图 X 输入到一个 1×1 的卷积层，将特征维度扩展为原来的 3 倍，其中三分之一用于 Q、三分之一用于 K、三分之一用于 V：

$$Q,K,V=\mathrm{split}\left(\mathrm{Conv}\left(\mathrm{Norm}\left(X\right)\right)\right) \tag{4-9}$$

进一步，计算 Q 和 K 之间的相似度，即点积，并通过 softmax 函数得到注意力权重。注意力机制的核心思想是，每个查询向量与所有键向量进行比较，计算它们之间的相似度，从而得到权重，用于加权求和：

$$A=\frac{QK^T}{\sqrt{d_k}} \tag{4-10}$$

中国知网　https://www.cnki.net

$$Attention = \mathrm{softmax}\left(A\right) \tag{4-11}$$

其中，d_k 是 K 向量的维度，为了防止计算结果过大，使用 $\sqrt{d_k}$ 对点积结果进行缩放。

根据计算出的注意力权重，使用加权求和的方式来得到输出。每个位置的输出是所有值的加权和，权重由注意力矩阵决定：

$$O = Attention \times V \tag{4-12}$$

其中，O 是每个位置的加权输出，它包含了每个位置对其他位置的全局信息感知。

得到加权求和后的输出 O 通常需要被重新调整，以便与原始输入的形状匹配，或进行后续的卷积操作。最终的输出 O 会与输入通过残差连接结合，从而确保网络能高效地学习特征，同时避免梯度消失问题，见式(4-13)：

$$Output = O + X \tag{4-13}$$

图 4-4 为本文构建的完整网络结构图。

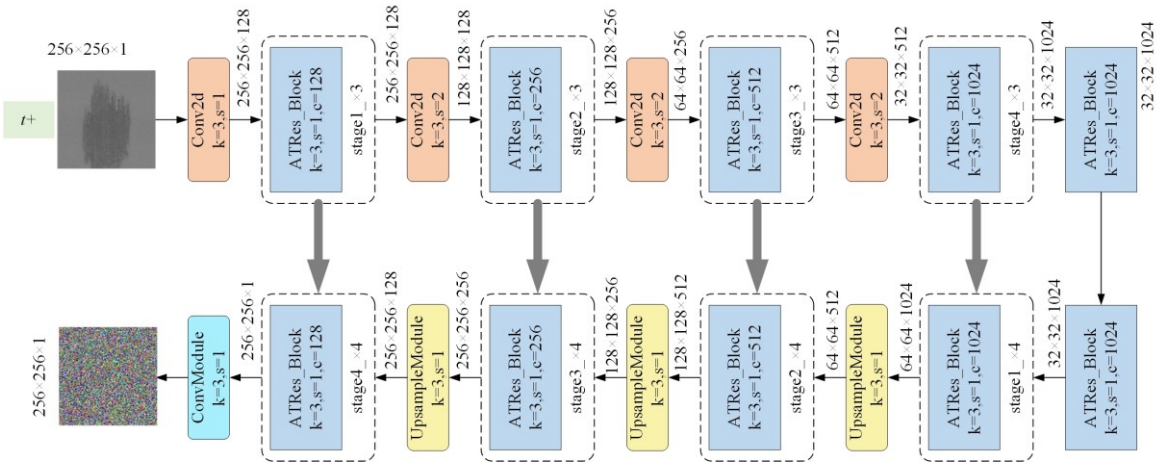


图 4-4　生成网络结构

Fig. 4-4　Generator network architecture

收缩路径由 4 个下采样阶段组成，分别对应空间分辨率从 256×256 到 32×32 的逐层压缩。在每一尺度内，堆叠 3 个 ARes_Block 用于提取丰富的空间语义信息，并在第一层启用自注意力机制，增强图像结构区域间的长距离依赖建模。下采样操作通过步长为 2 的 3×3 卷积实现，输出特征图尺寸依次减半，各层输出通道数分别为 128、256、512、1024。中间所有层的输出特征均保存在跳跃连接列表中，用于后续扩展路径的融合与恢复。模型中间瓶颈模块由两个通道数固定为 1024 的 ARes_Block 组成。每个模块均融合了时间步嵌入信息，用于调节各扩散阶段的噪声表征方式。

中国知网　https://www.cnki.net

扩展路径采用四阶段上采样结构，每阶段包含四个 ARes_Block 与一个上采样模块。各层通过跳跃连接融合收缩路径阶段提取的低级特征，提升细节还原能力。最终特征图经过归一化与卷积输出，恢复为输入图像维度，得到完整的噪声预测结果。

4.2.3　模型训练细节

本文构建的铜带表面缺陷数据集中共有 9 种类别，针对每种类别分别构建了一个生成模型，如图 4-5 所示。本文实验环境为标准化实验平台。实验平台为 Xeon Gold 5220R CPU×2，128GB 运行内存和 NVIDIA A6000 GPU×3。所有算法依托 Pytorch 深度学习框架实现，实验环境为 Python3.9，CUDA11.6 和 CUDnn 7.6.4。详细实验平台配置如表 4-2 所示。

网络训练参数设置：输入图像尺寸大小为 256×256；最大迭代次数 epoch 设置为 1000；时间步 T 为 1000；Batch-size 为 4；初始学习率为 2×10^{-5}，学习率衰减方式采用余弦函数；优化器选择 Adamw。为防止 U-Net 在训练过程中过拟合训练数据，噪声调度 β_t 采用线性噪声调度策略[186]，最小值设置为 0.0004，最大值设置为 0.02。此外，在训练前对数据进行随机简单变化操作（裁剪、翻转、亮度变化等），提高训练样本的表观多样性。

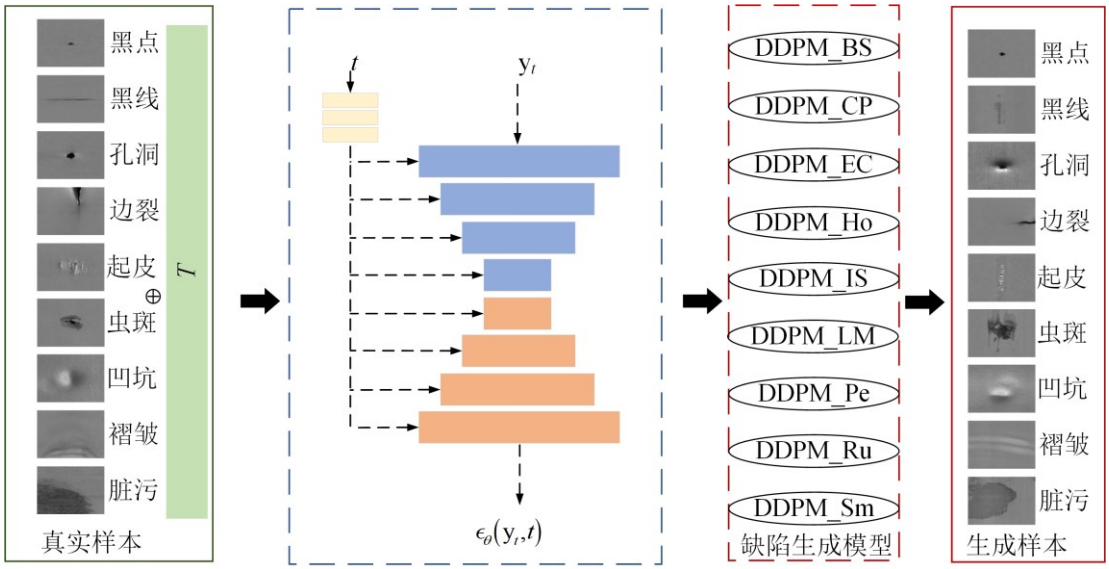


图 4-5　铜带表面缺陷样本生成方法

Fig. 4-5　Generation method of copper strip surface defect samples

中国知网　https://www.cnki.net

表 4-2　实验平台配置细节

Table 4-2　Details of experimental platform configuration

参数	配置细节
Pytorch	1.13.1
CUDA	11.6
CUDnn	8.4.1
Python	3.9.18
GPU	NVIDIA RTX A6000
CPU	Xeon Platinum 8375C

4.2.4　结果分析

为对比 DDPM 构建的生成模型效果，还使用 DCGAN[89]构建了生成模型，并给出两类模型在不同 epoch 时的生成样本结果。基于 DDPM 的生成模型在不同时间步时的生成样本如图 4-6 所示。当 epoch 为 0 时，模型并未得到训练，生成样本为服从标准正态分布的噪声图像。当 epoch 为 500 时，已经能显示出一些特征信息，但图像整体存在较大噪声。当 epoch 为 800 时，模型对简单类别缺陷特征学习的比较好，对复杂类别缺陷特征的学习还有较大提升空间，图像整体质量不高。当 epoch 为 1000 时，模型能够根据类别生成对应质量较高的缺陷图像，并且图像具有一定的多样性。

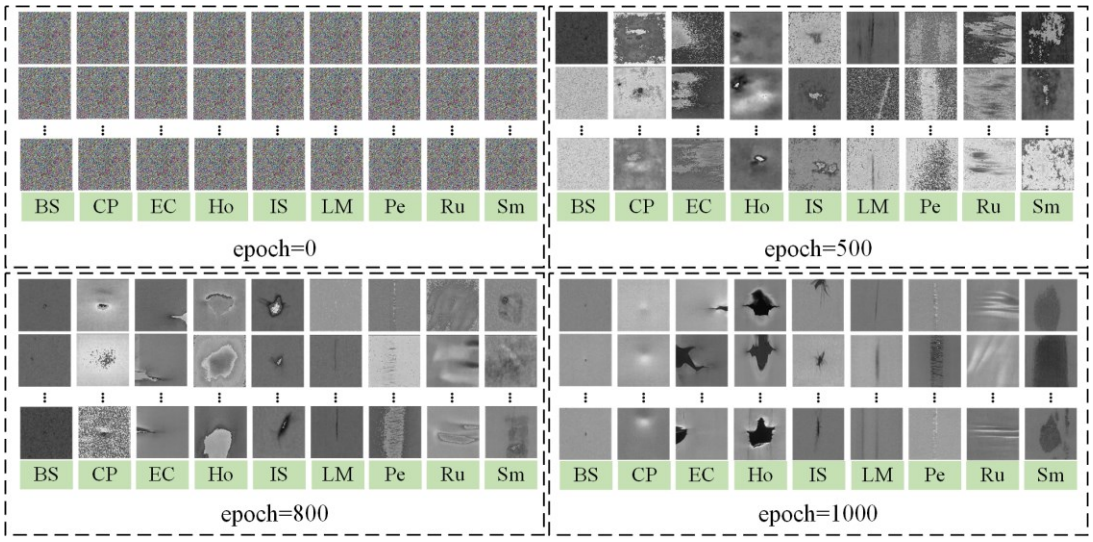


图 4-6　基于 DDPM 生成的缺陷生成样本

Fig. 4-6　Defect samples generated based on DDPM

基于 DCGAN 的生成模型在不同 epoch 时生成样本结果如图 4-7 所示。当 epoch

中国知网　https://www.cnki.net

为 0 时，模型并未得到训练。epoch 为 500 时，模型学习到缺陷的一些大致轮廓特征。当 epoch 为 800 时，模型又对学习到的轮廓特征增加了一些细节的描述。当 epoch 为 1000 时，模型也并没有进一步学习到更进一步的细节特征，生成样本总体质量较差，并且生成的图像模式多样性较低。综合上述结果表明，相较于 DCGAN，基于 DDPM 训练得到的缺陷生成样本具有更高的图像质量以及更丰富的样本多样性，更符合实际生产情况。

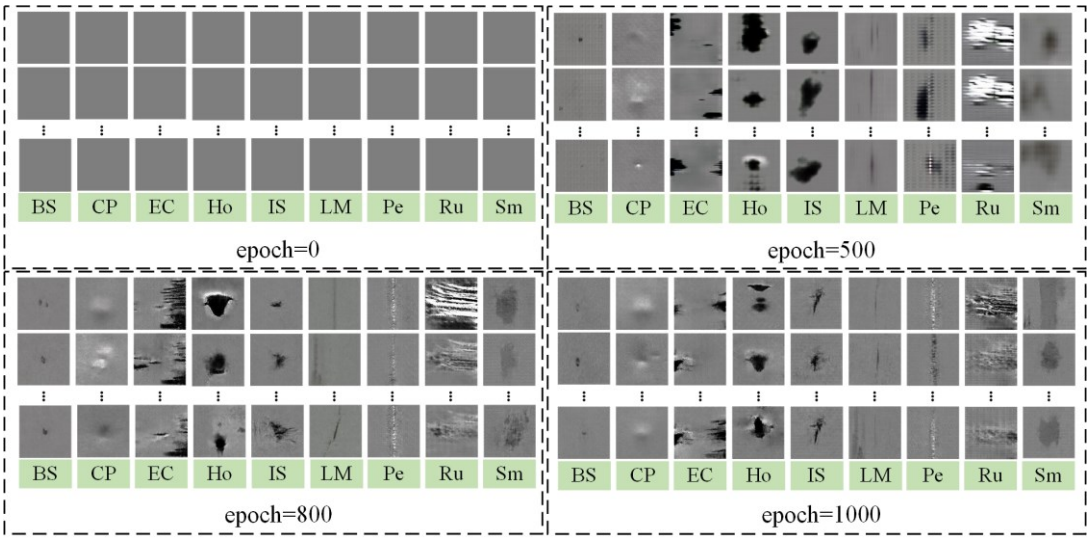


图 4-7　基于 DCGAN 生成的缺陷生成样本

Fig. 4-7　Defect samples generated based on DCGAN

为评估生成的缺陷图像质量和多样性，使用自然图像质量评估器（Naturalness Image Quality Evaluator, NIQE）[187]、基于感知的图像质量评估器（Perception based Image Quality Evaluator, PIQE）[188]和感知分数（Inception Score, IS）[189]来评估生成模型的性能。其中，NIQE 关注输入图像与真实自然图像之间统计特性的偏离程度，值越低，图像质量越好。PIQE 则关注输入图像的局部失真程度，值越低，图像感知质量好。IS 关注生成图像的类别分布与真实图像类别分布之间的差异，值越高，生成图像不仅具有清晰的分类特征，而且具有较高的多样性，生成模型效果越好，评估结果如表 4-3 所示。可以看出，相较于 DCGAN，基于 DDPM 生成的缺陷图像在三个指标均取得了更好的结果，说明基于 DDPM 生成的图像质量更好、图像局部失真更小、多样化程度更高。此外，相较于其他缺陷，BS、CP、LM 的 NIQE 值更高，而 PIQE 值更低。经过分析，对于 NIQE 指标，图像特征越简单（如平滑区域或低频特征较多），偏离自然图像的特性会更大，NIQE 值可能会更高。而对于 PIQE 指标，

中国知网　https://www.cnki.net

图像特征越复杂（如高对比度的边缘、不均匀纹理）越容易存在噪声或失真，PIQE值越高。基于 DDPM 生成的各类别缺陷图像也很好的反映了这些潜在趋势。

表 4-3　基于 DDPM 和 DCGAN 生成缺陷模型的性能评估

Table 4-3　Performance evaluation of defect generation models based on DDPM and DCGAN

模型	指标	BS	CP	EC	Ho	IS	LM	Pe	Ru	Sm	平均
DDPM	NIQE	8.66	6.14	3.78	3.95	4.61	6.83	4.31	5.95	4.95	5.46
	PIQE	21.77	19.73	28.16	31.00	27.65	19.67	32.69	27.79	26.27	26.08
	IS	3.31	3.58	4.56	5.81	5.21	4.07	4.16	4.18	4.69	4.40
DCGAN	NIQE	12.65	8.08	7.85	5.19	7.51	8.16	7.02	8.91	7.49	8.10
	PIQE	24.6	20.94	40.87	48.82	37.89	25.05	39.7	42.49	32.71	34.79
	IS	3.25	3.08	3.68	4.78	3.79	3.64	3.87	3.20	3.82	3.68

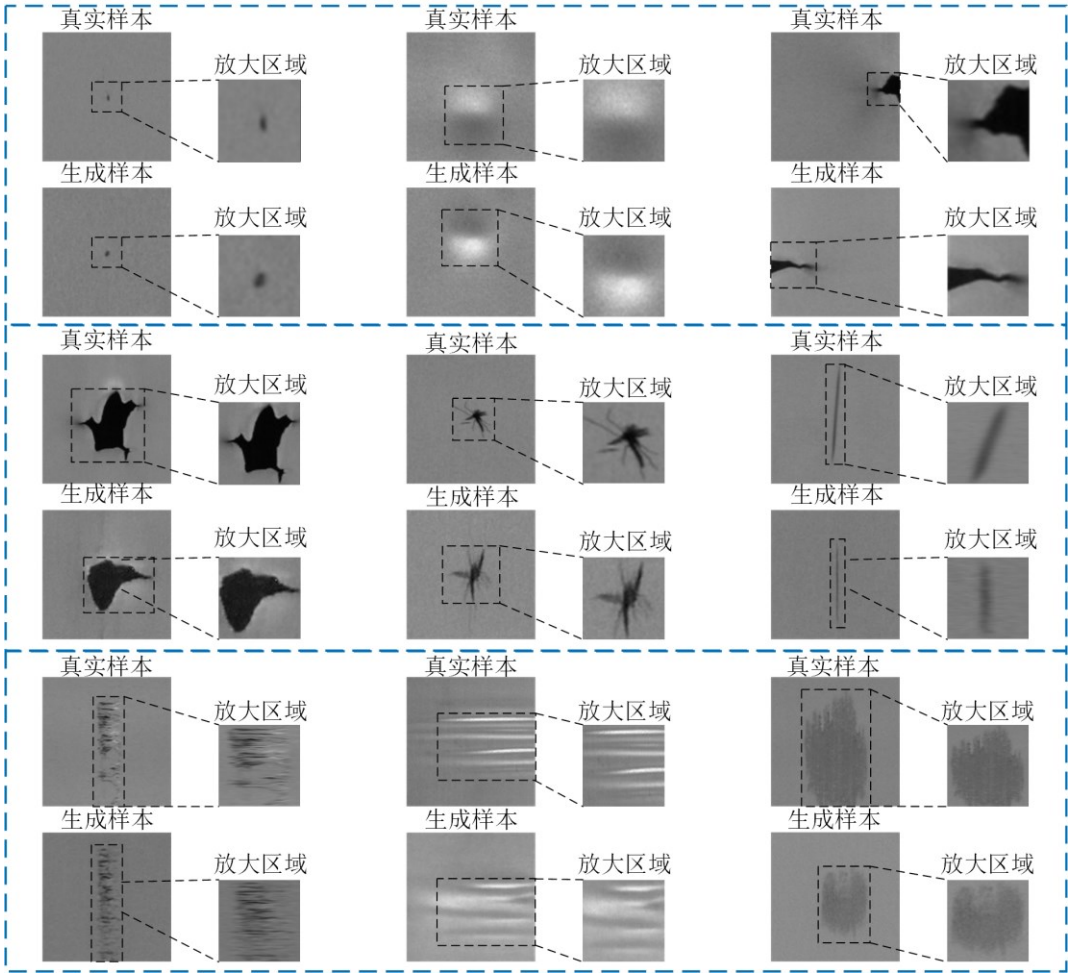


图 4-8　真实样本与生成样本对比

Fig. 4-8　Comparison between real samples and generated samples

中国知网　https://www.cnki.net

为评估生成样本图像质量，图 4-8 给出各类缺陷真实样本与生成样本对比图及其部分区域放大对比图，可以比较真实样本与生成样本之间全局与局部的差异。图 4-8 中每个虚线框内上排为真实样本及其放大图像，下排为生成样本及其放大图像。可以看出，生成样本和真实样本基本保持了各类别缺陷特征的一致性，虽然同类别缺陷不同样本之间可能存在一些差异，但也能够证明基于 DDPM 训练的生成模型学习到了各类别缺陷的潜在特征，生成样本具有较强的鲁棒性。因此，融合真实样本和生成样本的多源样本，能够为检测模型的训练带来更多样化的缺陷特征，更容易学习到不同缺陷的特征趋势和潜在解释。

4.3　铜带表面缺陷多源数据集构建

实际生产环境复杂多变，本文构建的原始铜带表面缺陷数据集很难涵盖真实环境中所有潜在的样本分布，以此训练的生成模型也存在限制。随着深度学习的发展，数据增强成为了提高模型泛化能力的重要手段，合理的数据增强方法、组合策略和样本规模能够极大提高模型性能。为此，结合实际生产情况引入标准数据增强中的多种变化操作，旨在增加数据集的多样性。

根据实际生产情况，选取七种常用的图像数据增强操作，包括：随机调整图像大小、随机裁剪、水平翻转、垂直翻转、添加高斯噪声、添加椒盐噪声和亮度调整。其中，随机调整图像大小操作能够模拟铜带宽度、相机位置变化等因素带来的输入图像尺寸上的变化，使模型能够学习到多尺度特征，避免仅依赖特定尺寸的目标进行分割。随机裁剪操作能够让模型关注到局部特征和上下文信息，提高模型对特征位置变化的适应性。水平和垂直翻转操作能够使模型适应不同位置采集的图像数据，改变相同背景中的非对称环境分布，避免过拟合特定背景模式。添加高斯噪声和椒盐噪声操作则用于模拟实际生产现场中图像采集过程受到的电气干扰、感光器件噪声、环境粉尘等影响，提高模型在噪声干扰条件下的鲁棒性。随机亮度调整能够模拟不同时间段、天气和光源位置变化等因素的影响，提高模型对复杂光照条件的适应性和鲁棒性。为提高增强数据集的多样性，从上述七种标准数据增强变换操作中随机选取一至四种操作进行组合，实现一次数据增强。

传统的数据增强方法通过对数据的空间变换生成新的样本。然而，针对图像分类、回归等任务，这些方法未能充分利用数据的潜在结构。为此，mixup[190]方法应运而生，该方法通过对样本进行加权混合，能够在不改变数据标签的情况下生成更

中国知网　https://www.cnki.net

多样化且合理的训练样本。mixup 通过结合先验知识扩展训练分布，将两个样本融合为一个样本。给定两张图像 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 以及其对应的真实标签 y_i 和 y_j，则使用 Mixup 生成新样本 $\mathbf{x}_{\text{mixup}}$ 和 y_{mixup} 的计算方法见式(4-14)：

$$\begin{cases}\mathbf{x}_{\text{mixup}} = \lambda \mathbf{x}_i + (1-\lambda)\mathbf{x}_j \\ y_{\text{mixup}} = \lambda y_i + (1-\lambda) y_j\end{cases} \tag{4-14}$$

其中，λ 是一个从 Beta 分布中采样的超参数，表示混合比例，$\lambda \in (0,1)$。

通过在样本间进行加权混合，mixup 方法能够生成新的样本，这些新样本不仅保留了原始样本的特征，而且具有较大的多样性。通过控制混合比例 λ，可以在生成过程中引入不同的样本组合，从而扩展训练集的多样性。这种数据多样性有助于提高模型的鲁棒性，减少过拟合的风险。

实际生产中，复合缺陷发生频率较低，采集的复合缺陷图像数量较少，如果使用较小规模数据训练，模型难以准确学习类别之间的复合方式和规律，从而生成与真实情况不符合的样本，影响训练数据质量。为此，使用 mixup 方法将单缺陷样本合成复合缺陷样本。然而，复合缺陷样本需要基于缺陷的实际发生规律、缺陷类型之间的关联性、缺陷发生的位置及工序等因素来制定合理的组合规则。若忽视这些物理规律和工艺限制，可能导致不符合实际生产场景的样本。表 4-4 为根据不同缺陷类型的空间分布、产生机理以及工艺关联性，给出的合理缺陷类别组合。

表 4-4　合理的复合缺陷样本组合

Table 4-4　Reasonable combinations of composite defect samples

主要缺陷	合理的伴随缺陷
黑点	凹坑、划擦伤、黑点、黑线、脏污、边裂、孔洞
凹坑	褶皱、黑点、黑线、划擦伤、孔洞
划擦伤	凹坑、黑点、黑线、脏污、
边裂	孔洞、黑点、黑线、凹坑、褶皱
孔洞	凹坑、边裂、黑点、褶皱、黑线、划擦伤
黑线	褶皱、划擦伤、黑点、脏污、起皮
起皮	黑点、黑线、孔洞、脏污
褶皱	边裂、黑点、黑线、划擦伤、脏污
脏污	黑点、黑线、起皮

中国知网 https://www.cnki.net

为进行对照分析，以原始铜带表面缺陷数据集为基础分别构建铜带表面缺陷的真实样本数据集（Real_Dataset）和多源样本数据集（MS_Dataset）。

首先构建 Real_Dataset，从原始数据集中单缺陷样本的每个类别和复合缺陷样本中随机抽取 40 个样本，作为测试集 Testset，剩余样本按 9:1 的比例划分成训练集 Trainset 和验证集 Valset，共同构成真实样本数据集 Real_Dataset。

进一步构建 MS_Dataset，从原始数据集中抽取与 Real_Dataset 中 Testset 相同的样本也作为 MS_Dataset 的 Testset，剩余样本记为数据集 Dataset1。然后基于 DDPM 模型利用 Dataset1 中单缺陷样本训练缺陷生成模型，每个类别生成 1000 个样本，按照 9:1 的比例划分成 trainset1 和 valset1。进一步，基于 Dataset1 中的单缺陷样本从表 4-4 中随机选取组合，共生成 1800 个 mixup 复合缺陷样本，将 mixup 复合缺陷样本按照 9:1 的比例划分成 trainset2 和 valset2。对 Dataset1 中的单缺陷样本和复合缺陷样本进行标准数据增强操作，将 Dataset1 中所有类别（单缺陷样本所有类别和复合缺陷样本）分别扩充至 400 个，然后将 Dataset1 按照 9:1 的比例划分成 trainset3 和 valset3，最后，融合 trainset1、trainset2 和 trainset3 得到 Trainset，融合 valset1、valset2 和 valset3 得到 Valset，与 Testset 共同记为多源样本数据集 MS_Dataset。MS_Dataset 构建过程示意图如图 4-9 所示。

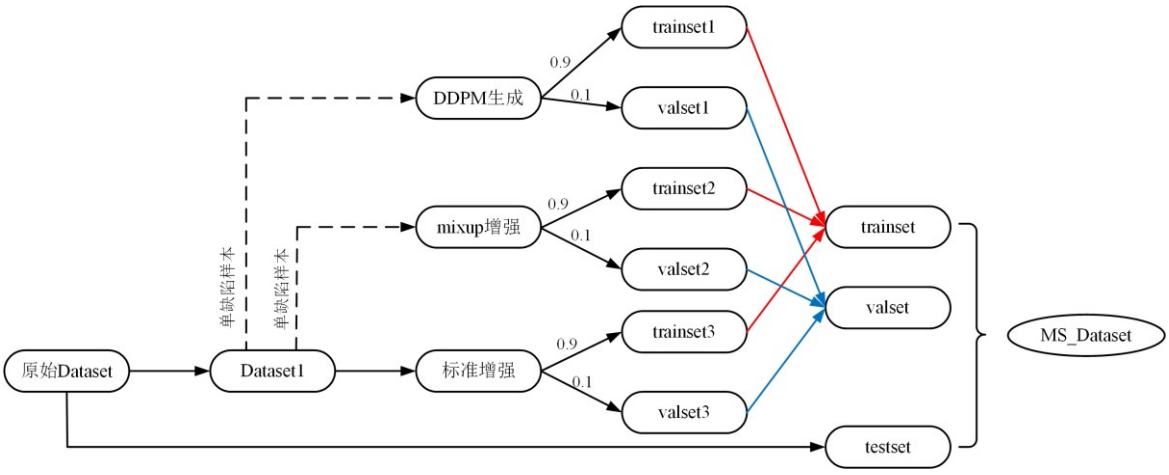


图 4-9　MS_Dataset 构建过程

Fig. 4-9　Construction process of MS_Dataset

本文最终构建的真实样本数据集 Real_Dataset 和多源样本数据集 MS_Dataset 的样本分布如表 4-5 所示。

中国知网　https://www.cnki.net

表 4-5　构建的两个数据集样本分布

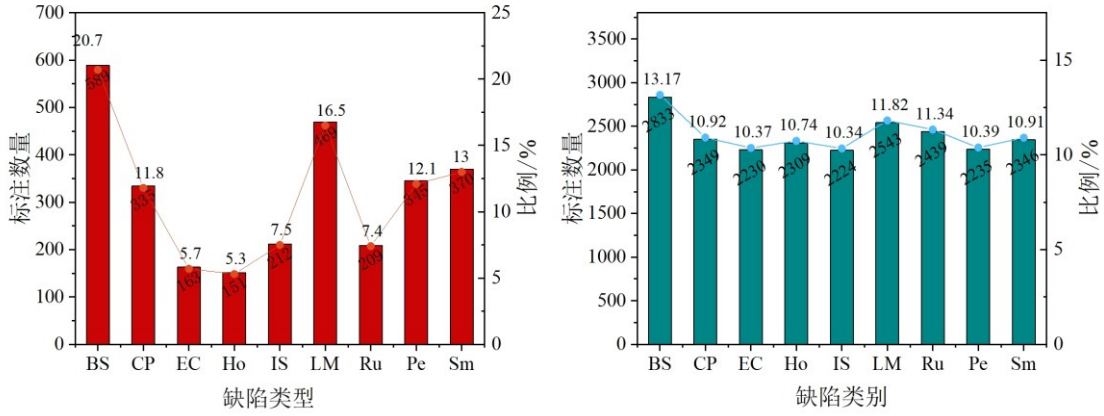
Table 4-5　Sample distribution of the two constructed datasets

数据集类别	样本类别	缺陷类别	Trainset	Validataionset	Testset
真实样本 Real_Dataset	单类别	BS	126(Real)	31(Real)	40(Real)
		CP	179(Real)	44(Real)	40(Real)
		EC	55(Real)	13(Real)	40(Real)
		Ho	49(Real)	12(Real)	40(Real)
		IS	136(Real)	34(Real)	40(Real)
		LM	209(Real)	52(Real)	40(Real)
		Pe	220(Real)	54(Real)	40(Real)
		Ru	166(Real)	25(Real)	40(Real)
		Sm	150(Real)	37(Real)	40(Real)
	复合类别	/	189(Real)	22(Real)	40(Real)
多源样本 MS_Dataset	单类别	BS	320 (Real+Aug)+ 900 (DDPM)	80(Real+Aug)+ 100(DDPM)	40(Real)
		CP	320 (Real+Aug)+ 900 (DDPM)	80 (Real+Aug)+ 100(DDPM)	40(Real)
		EC	320 (Real+Aug)+ 900 (DDPM)	80 (Real+Aug)+ 100(DDPM)	40(Real)
		Ho	320 (Real+Aug)+ 900 (DDPM)	80 (Real+Aug)+ 100(DDPM)	40(Real)
		IS	320 (Real+Aug)+ 900 (DDPM)	80 (Real+Aug)+ 100(DDPM)	40(Real)
		LM	320 (Real+Aug)+ 900 (DDPM)	80 (Real+Aug)+ 100(DDPM)	40(Real)
		Pe	320 (Real+Aug)+ 900(DDPM)	80 (Real+Aug)+ 100(DDPM)	40(Real)
		Ru	320 (Real+Aug)+ 900(DDPM)	80 (Real+Aug)+ 100(DDPM)	40(Real)
		Sm	320 (Real+Aug)+ 900(DDPM)	80 (Real+Aug)+ 100(DDPM)	40(Real)
	复合类别	/	320 (Real+Aug)+ 1620(mixUp)	80 (Real+Aug)+ 180(mixUp)	40(Real)

构建的真实样本数据集（Real_Dataset）和多源样本数据集（MS_Dataset）均使用 Labelimg 软件手动标注类别及缺陷真实框位置。分别统计两个数据集中 Trainset

中国知网 https://www.cnki.net

和 Valset 的标注标签，并对不同缺陷类别标签数量进行了可视化，如图 4-10 所示。图 4-10(a)为数据集 Real_Dataset，图 4-10(b)为数据集 MS_Dataset。图中横坐标为缺陷类别，左侧纵坐标为缺陷数量，右侧纵坐标为各个类别缺陷所占比例。柱状图为原始数据集中各类别缺陷数量，点线图为各类别所占比例。可以看出，相较于 Real_Dataset，融合了多源样本的 MS_Dataset 不仅各类别样本数量得到极大提升，各缺陷的类间分布不均问题也得到有效改善，类间样本数量最大仅相差 2.8%。



(a) Real_Dataset　　(b)MS_Dataset

图 4-10　不同类别缺陷标签分布可视化

Fig. 4-10　Visualization of label distribution for different defect categories

4.4　本章小结

针对铜带生产现场表面缺陷样本获取规模有限、类间数量分布不均衡的问题，本章提出一种多源样本融合策略。首先，通过校企合作实现真实铜带表面缺陷图像的获取，构建了包含九类典型缺陷的原始数据集。其次，基于 DDPM 设计并训练了缺陷生成模型，通过与 DCGAN 模型的对比实验，验证了 DDPM 在生成样本质量与真实性方面的显著优势。进一步，提出一种融合真实样本、标准数据增强样本、mixup 复合样本以及 DDPM 生成样本的多源数据集构建新范式。实验结果表明，该多源融合策略有效缓解了数据类别不均衡问题，使最大类间样本数量差距由 15.4%显著降低至 2.8%，显著提升了数据集的规模、多样性与均衡性。

中国知网　https://www.cnki.net

第 5 章　铜带表面缺陷高效轻量化智能检测方法

针对铜带表面缺陷检测中存在的特征尺度差异大、缺陷形态复杂及模型推理效率低等问题，本章提出一种高效轻量化的智能检测方法。结合工业实际需求，在端到端实时检测器 RT-DETR 的基础上，设计了自适应部分卷积算子 APConv，通过引入通道注意力机制在降低冗余计算的同时增强特征表达能力。随后，通过融合高效多尺度注意力机制构建了具有残差结构的 EAPR_Block 模块，进而搭建轻量化高效主干网络 EAPRNet。最后，将 EAPRNet 嵌入改进的 RT-DETR 检测框架，结合 Optuna 贝叶斯优化算法实现超参数自动寻优，完成轻量级铜带表面缺陷检测模型 CSSD_M 的构建。该方法在保证检测精度的同时显著提升了模型的计算效率与工业部署适应性。

5.1　构建轻量化高效特征提取网络

铜带表面缺陷检测任务存在种类繁多、面积分布广泛、缺陷特征相似度高以及缺陷重叠等挑战，要求检测方法具有足够的重点特征表达能力和多尺度特征捕捉能力。此外，要实现生产现场的工业部署还需要平衡检测精度和检测效率。

本文以 RT-DETR 为基础，搭建了一种轻量化表面缺陷目标检测器。首先，提出一种新颖的自适应部分卷积 APConv(Adaptive partial convolution)作为基本卷积算子，APConv 不仅减少了冗余计算和内存访问，还能够根据输入动态调整通道权重，提高对重点特征通道的关注程度。为建立不同尺度特征之间的相互依赖关系，嵌入了高效多尺度注意力机制 EMA，并通过残差学习块将输入特征与 EMA 的输出特征进行融合，得到 EAPR_Block。最后，以 EAPR_Block 为基础，建立了新颖的轻量化高效主干特征提取网络 EAPRNet。结合 DETR 结构的端到端预测，有效避免了 NMS 等复杂后处理操作在实际应用中带来的不稳定性因素。

5.1.1　自适应部分卷积算子 APConv

为提高网络的性能和效率，一些学者提出了新的卷积基本算子，如深度可分离卷积(Depthwise Separable Convolution，DWConv)和组卷积(Group Convolution，GConv)，并以此为基础设计了具有时间成本效益的快速神经网络，如 MobileNet[46-48]、

中国知网　https://www.cnki.net

ShuffleNet[49,50]和 GhostNet[191-193]，利用 DWConv 和 GConv 提取空间特征降低浮点运算次数(Floating Point Operations，FLOPs)。但有学者指出 DWConv 虽然能有效降低 FLOPs，但实际应用中为保证精度会增加通道数，进而产生更高的内存访问，造成延迟。文献[194]提出一种简单高效的部分卷积(Partial Convolution，PConv)作为基本卷积算子，其结构如图 5-1 所示。PConv 在保留剩余通道不变的基础上，应用滤波器在部分输入通道提取空间特征，能够同时减少计算冗余和内存访问。当输入和输出特征图具有相同的通道数时，PConv 的 FLOPs 仅为传统 Conv 的 1/16，而每秒浮点运算次数(Floating Point Operations Per Second，FLOPS)仅为传统 Conv 的 1/4，有效降低了计算的延迟。

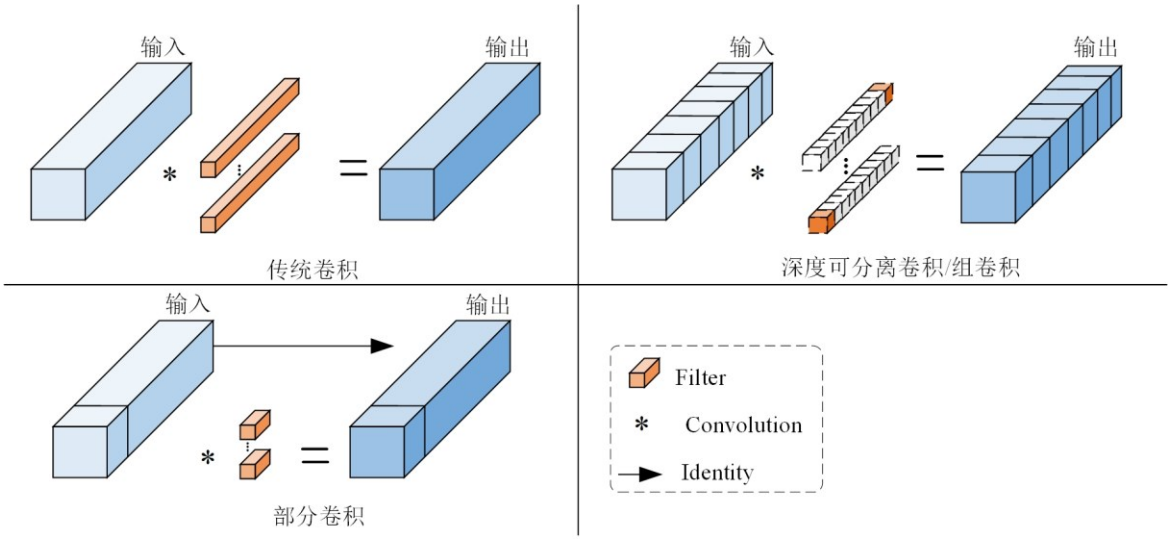


图 5-1　基本卷积算子

Fig. 5-1　Basic convolution operator

PConv 利用不同特征通道中存在特征冗余这一特点，仅在部分输入特征通道上应用常规卷积，其余通道保持不变，同时减少了冗余计算和内存访问。但原始 PConv 算子仅使用固定的部分特征通道参与卷积，而不是根据输入分布动态选择，这种设计可能无法适应不同输入特征的变化，缺乏灵活性。为此，本文通过引入通道注意力对参与卷积的特征通道进行局部自适应通道加权，这种方法能够根据输入动态调整通道权重，提高对重点特征的关注程度和模型在不同任务上的表达能力。提出的 APConv 结构如图 5-2 所示。

中国知网　https://www.cnki.net

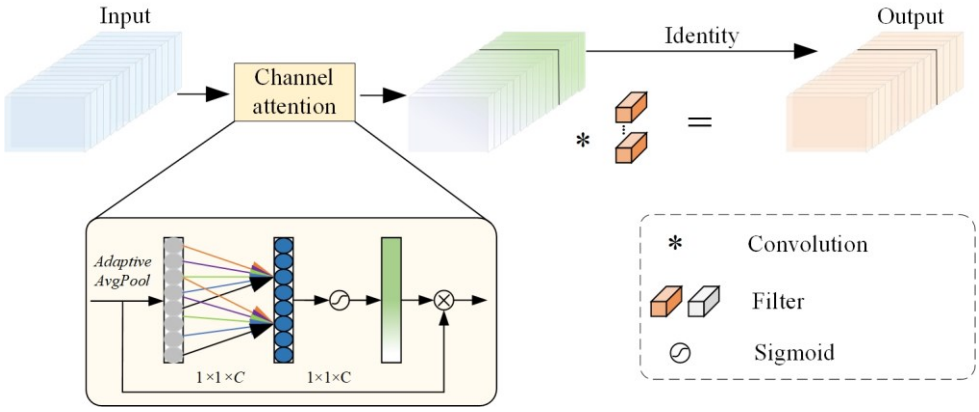


图 5-2　自适应部分卷积算子

Fig. 5-2　Adaptive partial convolution operator

以 PConv 为基础，在对部分通道进行卷积前引入通道注意力，计算注意力权重与需要卷积的输入通道进行加权，实现特征通道的自适应选择。假设输入特征为 $x \in \mathbb{R}^{C\times H\times W}$，$C$ 是通道数，H 和 W 是特征维度。首先根据式(5-1)计算输入特征的各通道注意力权重：

$$A' = \sigma\left[w'_{1\times1} * \mathrm{AaptiveAvgPool}(x) \right] \tag{5-1}$$

其中，σ 为 sigmoid 函数；$w'_{1\times1}$ 为输出通道为 C_p 的 1×1 卷积层；C_p 为被卷积部分的通道数；AaptiveAvgPool 为自适应平均池化层。

将输入特征 x 划分为需要进行卷积的特征 x_1 和不需要进行卷积的特征 x_2。根据式(5-2)将注意力权重应用到 x_1 的对应通道：

$$x'_1 = x_1 \odot A' \tag{5-2}$$

其中，x'_1 为加权后需进行卷积的特征。

然后对加权后的 x'_1 进行卷积操作，最后根据式(5-3)将输出结果与 x_2 进行拼接：

$$x_{out} = Concat\left(w_{3\times3} * x_1', x_2 \right) \tag{5-3}$$

为验证本文所提出的 APConv 在参数量与计算复杂度方面的表现，将其与标准卷积 Conv、DWConv 和 GConv 进行了全面的量化对比。输入张量尺寸设定为 64×256×256，以模拟网络中间层的典型特征图。对比结果如表 5-1 所示。从表中可以看出，Conv 的参数量与 FLOPs 最高，分别达到 0.0369 M 和 4.8318 G。本文提出的 APConv 在引入通道注意力机制的同时，仅对部分通道执行卷积运算，使得参数量与 FLOPs 进一步下降，分别为 0.0033 M 和 0.3104 G。结果表明，APConv 在保持较低

中国知网　https://www.cnki.net

计算复杂度的同时，通过通道注意力实现了特征通道的自适应加权与冗余计算的动态削减，有效兼顾了轻量化特性与特征表达能力。

表 5-1　不同卷积算子参数量与计算复杂度对比

Table 5-1　Comparison of parameter count and computational complexity for different convolutional operators

操作算子	参数量/M	FLOPs
标准卷积 Conv	0.0369	4.8318
DWConv	0.0047	0.6124
GConv	0.0092	1.2080
APConv	0.0033	0.3104

5.1.2　高效特征提取模块 EAPR_Block

本文受到残差块结构的启发，提出一种新颖的具有残差连接的 EAPR_Block，如图 5-3 所示。首先，使用尺寸为 3×3 的卷积核对输入特征进行下采样，提取局部特征信息。然后，将提取的局部特征图输入 APConv 中，经过通道注意力计算各通道权重，对参与卷积的特征通道进行加权后进行常规卷积，剩余通道特征与卷积后的特征直接融合，APConv 能够同时减少了计算冗余和内存访问数量，并针对不同输入特征图进行自适应调整。

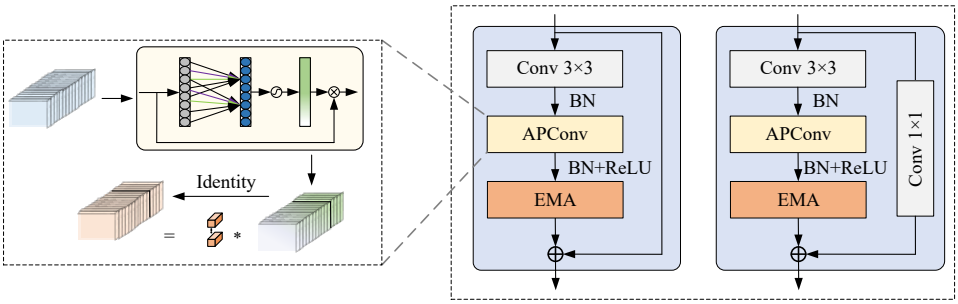


图 5-3　EAPR_Block

Fig. 5-3　Efficient adaptive residual block

进一步，添加了一种新颖的跨空间学习高效多尺度注意力模块（Efficient Multi-scale Attention, EMA）[195]，EMA 集成了通道注意力和空间注意力单元，利用

中国知网　https://www.cnki.net

并行子网络的大感受野收集更多尺度空间信息，在不同尺度建立相互依赖关系，实现跨空间学习，其结构如图 5-4 所示。最后，由残差学习块将输入特征图与 EMA 机制的输出特征图进行融合。

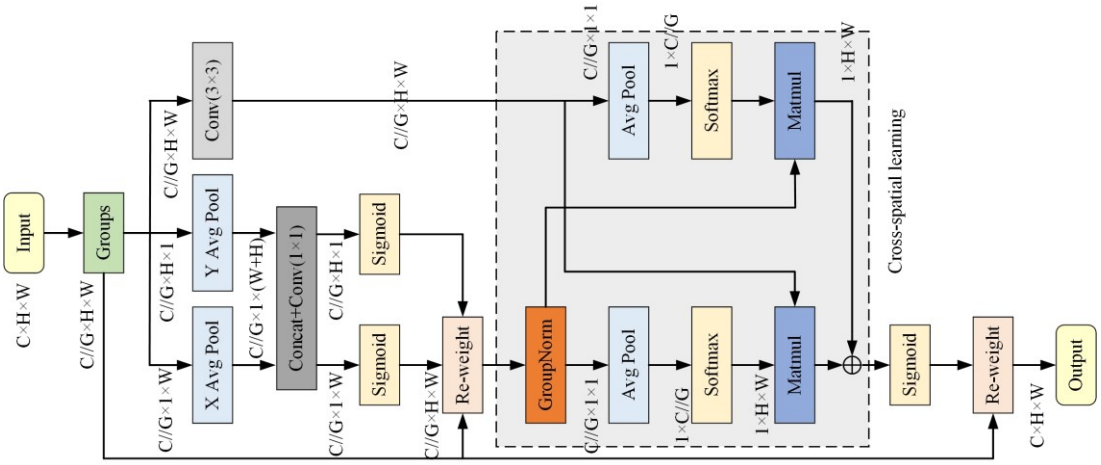


图 5-4　高效多尺度注意力机制

Fig. 5-4　Efficient multi-scale attention mechanism

5.1.3　轻量化特征提取网络 EAPRNet

以 EAPR_Block 为基础，本文搭建了具有高效多尺度特征提取等特点的主干特征提取网络 EAPRNet，如图 5-5 所示。输入图像经过两个 3×3 卷积核进行下采样，提取抽象特征。然后经过连续两个 1×1 卷积核，第一个 1×1 卷积核用于特征通道升维，将卷积后的特征通道维度提高 2 倍。第二个 1×1 卷积核用于增加网络的非线性映射次数，通过加入非线性激活函数，使得网络可以表达更复杂的特征。通过 MaxPooling 池化操作对特征图进行空间降采样，扩大感受野。最后，经过三个 EAPR_Block 进行不同尺度的特征图提取。

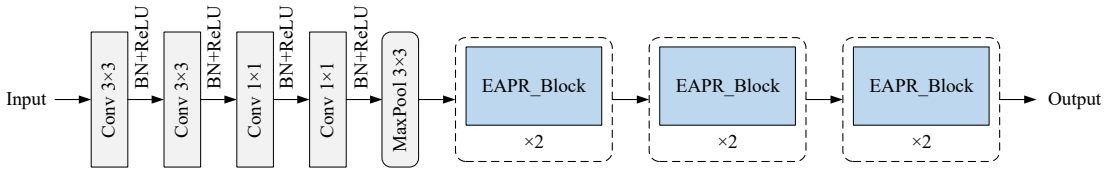


图 5-5　高效自适应残差网络

Fig. 5-5　Efficient adaptive residual network

中国知网　https://www.cnki.net

5.2　基于改进 RT-DETR 的轻量化目标检测器

RT-DETR（Real Time Detection Transformer）是第一个基于 Transformer 的实时端到端目标检测器[196]。RT-DETR 在继承 DETR[67]端到端这一优势的基础上，进一步缓解了训练成本过高的问题。RT-DETR 主要由三部分组成：Backbone、Encoder 和一个带有辅助检测头的 Decoder。

RT-DETR 的 backbone 输出最后三个不同阶段的特征图。Encoder 包括 AIFI 模块和 CCFM 模块，分别用于对特征图进行自注意操作和多尺度特征融合操作。由于自注意力操作对高级特征中不同对象实体联系具有更强的捕捉能力，且低层特征缺乏与高层特征的交互能力，存在重复和混淆的风险，因此，仅将最后一阶段特征图与位置编码融合后输入 AIFI 模块，AIFI 的输出与 backbone 输出的前两个阶段特征图一同输入 CCFM 模块进行多尺度特征融合。Decoder 部分为多层 Transformer 解码器，Decoder 的输入为编码内存、位置编码和由 IoU-aware selection 选取的特征向量。Decoder 的输出为预测类别和预测框。

Decoder 的预测由两个前馈神经网络（Feedforward Network, FFN）计算，其中 FFN 包括两层全连接层和一层 ReLU 激活函数层。其中一个 FFN 输出预测框的高度、宽度和中心坐标，另一个 FFN 的输出经过 softmax 函数预测类别标签。

假设图像中真实目标框的集合记为 $y=\{y_i\}_{i=1}^{B}$，RT-DETR 输出的预测框集合记为 $\hat{y}=\{\hat{y}_i\}_{i=1}^{N}$，通常预测框比图像中真实框数量多，即 $N>B$。为方便后续计算，将真实框集合用 $\varnothing$ 填充至 N 个，记为 $y=\{y_i\}_{i=1}^{N}$。其中，每个真实框包含两个元素 $y_i=(c_i,b_i)$，c_i 代表目标类别标签(可能为空集)；b_i 定义了真实框中心坐标及其相对于图像尺寸的宽高向量。

由于预测框数量多于真实框，RT-DETR 在计算损失前需要将预测框与真实框一一匹配，并通过匈牙利算法找到使匹配成本最小的最优匹配。匈牙利算法是一种用于解决二分匹配问题的优化算法，通过最小化匹配成本来找到最佳的匹配方案，见式(5-4):

$$\hat{\sigma}=\arg\min_{\sigma\in S_N}\sum_{i}^{N}\mathcal{L}_{match}\left(y_i,\hat{y}_{\sigma(i)}\right) \tag{5-4}$$

其中，$\hat{\sigma}$ 表示匹配成本最小的最优匹配；S_N 为所有可能匹配的集合；$\mathcal{L}_{match}$ 为匹配成本；$\sigma_{(i)}$ 代表当前匹配中预测框的索引。

中国知网　https://www.cnki.net

匹配成本 $\mathcal{L}_{match}$ 的计算包括分类损失和回归损失两部分，如式(5-5)：

$$\mathcal{L}_{match}\left(y_i,\hat{y}_{\sigma(i)}\right)=\mathcal{L}_{cls}\left(y_i,\hat{y}_{\sigma(i)}\right)+\mathcal{L}_{box}\left(y_i,\hat{y}_{\sigma(i)}\right) \tag{5-5}$$

其中，$\mathcal{L}_{cls}$ 为交叉熵损失，记为 $\mathcal{L}_{cls}\left(y_i,\hat{y}_{\sigma(i)}\right)=-\log\left(\hat{p}_{\hat{\sigma}(i)}\left(c_i\right)\right)$；$\hat{p}_{\sigma(i)}\left(c_i\right)$ 代表预测框预测为 c_i 类别的概率；$\mathcal{L}_{box}$ 为 L1 损失和 GIoU 损失的组和，记为 $\mathcal{L}_{box}\left(y_i,\hat{y}_{\sigma(i)}\right)=\lambda_{\mathrm{L1}}\left|b_i-\hat{b}_{\sigma(i)}\left(i\right)\right|+\lambda_{\mathrm{GIoU}}\mathcal{L}_{box}\left(b_i,\hat{b}_{\sigma(i)}\left(i\right)\right)$；$\hat{b}_{\sigma}\left(i\right)$ 代表预测框中心坐标及其相对于图像尺寸的宽高向量，λ_{L1} 和 λ_{GIoU} 为超参数。

最后，根据匈牙利算法得到的最优匹配 $\hat{\sigma}$ 计算总损失，定义为：

$$\mathcal{L}_{total}\left(y,\hat{y}\right)=\sum_{i=1}^{B}\left[-\log\hat{p}_{\hat{\sigma}(i)}\left(c_i\right)+\lambda_{\mathrm{L1}}\left|b_i-\hat{b}_{\hat{\sigma}(i)}\left(i\right)\right|+\lambda_{\mathrm{GIoU}}\mathcal{L}_{box}\left(b_i,\hat{b}_{\hat{\sigma}(i)}\left(i\right)\right)\right] \tag{5-6}$$

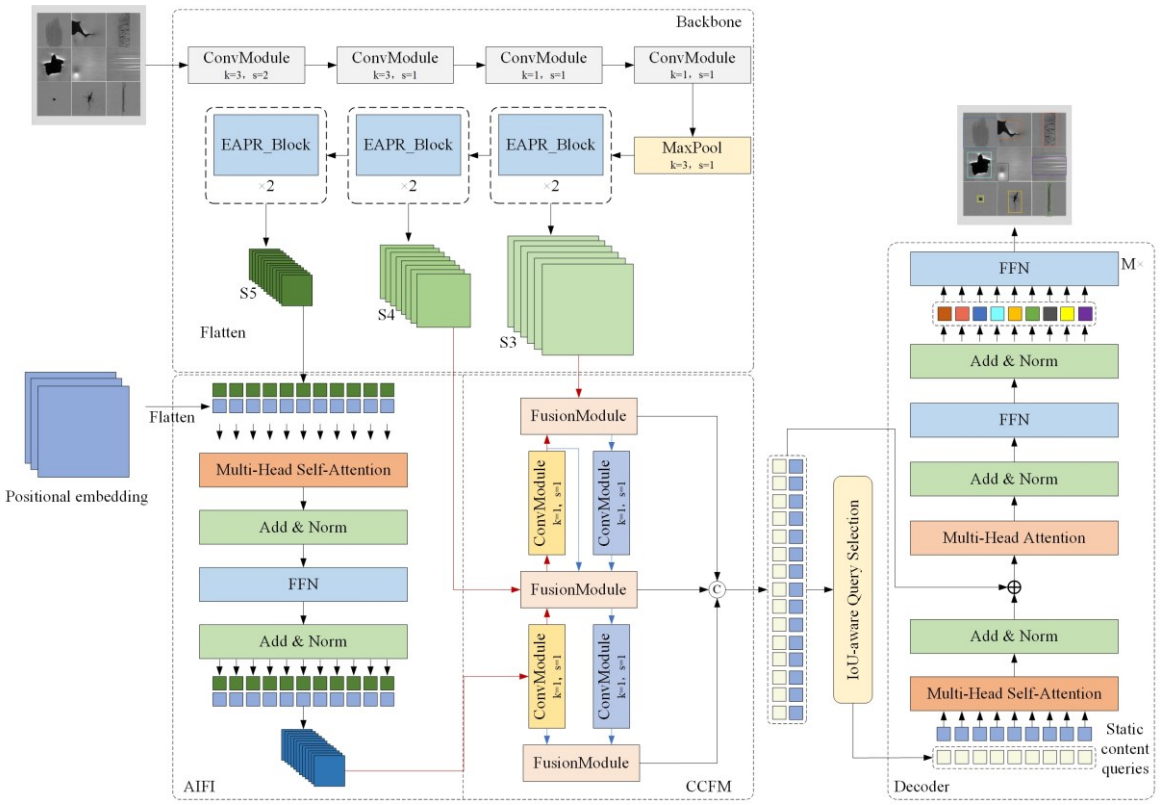


图 5-6　轻量化铜带表面缺陷检测器

Fig. 5-6　Lightweight copper strip surface defect detector

网络整体结构如图 5-6 所示。图像输入 Backbone 后，提取到不同尺度的特征图

中国知网　https://www.cnki.net

{S3, S4, S5}。将最后阶段的特征图 S5 进行 Flatten 操作拉伸成一维向量并融合位置编码（position embedding），输入到 AIFI 模块进行自注意操作，得到全局特征向量。将全局特征向量进行 Reshape 操作调整维度与 S5 相同，得到全局特征图 F5。将 F5 与另外两个阶段的低层特征 S3 和 S4 共同输入到 CCFM 模块中，实现跨尺度特征融合。通过 IoU-aware query selection 从 Encoder 的输出特征中选取固定数量的特征向量作为 Decoder 的初始特征向量。具有 M 层的 Decoder 的输入为初始特征向量、位置向量和 Encoder 的输出，解码后通过辅助预测头进行迭代优化特征向量得到预测类别和预测框。Decoder 中的层数会影响检测模型的准确性和速度，因此，可以通过使用不同的解码器层数灵活调整推理速度，而无需重新训练。

5.3　基于 Optuna 的超参数寻优

在深度学习模型的训练过程中，超参数的设定对模型性能具有显著影响。不同于可通过反向传播学习得到的网络参数，超参数需在训练前进行人工设定，涵盖学习率、批量大小、优化器类型、正则化系数、网络结构深度等多个维度。随着模型复杂度的提升，超参数之间呈现出高度非线性和耦合关系，其选取面临诸多挑战。一方面，超参数搜索空间往往维度高、范围广，组合数量呈指数级增长，使得穷举式搜索在计算资源受限的场景中难以实施；另一方面，超参数对模型性能的影响通常表现为非凸、非平滑甚至带噪声的目标函数，传统的梯度优化方法难以直接应用。此外，每组超参数配置都需通过完整训练和验证过程进行性能评估，尤其在计算资源紧张或模型体量较大的情况下，超参数搜索的成本显著增加。在早期实践中，网格搜索和随机搜索是最常见的策略[197]。前者在预设的离散网格中进行遍历搜索，虽具有确定性，但在高维空间中效率极低；后者则通过从搜索空间中随机采样一定数量的超参数组合进行评估，在高维空间中往往能够更快地覆盖关键区域。相比之下，基于概率建模的贝叶斯优化方法[198]逐渐成为主流，其通过构建超参数与模型性能之间的代理函数，并利用采集函数平衡探索与利用，从而在较少的搜索成本下找到最优解。

为实现高效的超参数搜索，本文采用基于贝叶斯优化策略的自动化调参框架 Optuna 对模型关键超参数进行系统性优化[199]。Optuna 是近年来提出的一种高性能、灵活性强的开源超参数优化工具，其核心优化算法基于 Tree-structured Parzen Estimator（TPE），是一种非参数的贝叶斯优化方法，特别适用于高维、非凸、黑箱

中国知网　https://www.cnki.net

型目标函数的优化问题。与传统网格搜索或随机搜索相比，Optuna 能够在更少的试验次数下更快地逼近最优超参数组合，显著降低计算成本。

本文基于 Optuna 框架设定了如下超参数搜索空间：批量训练大小 Batch-size、初始学习率 lr、优化器类型 optimizer、动量系数 momentum、权重衰减系数 weight_decay、Dropout 概率、单样本最大检测数量 max-det 和标签平滑因子 label_smoothing。

每种组合均在验证集上进行性能评估，以 mAP_{50} 作为评估指标，设定最大试验次数为 100，最终筛选出验证性能最优的一组超参数用于正式训练，如表 5-2 所示。

表 5-2　基于 optuna 框架的超参数搜索空间与寻优结果

Table 5-2　Hyperparameter search space and optimization results based on Optuna framework

超参数	搜索空间	寻优结果
Batch-size	Categorical[4,8,16,32,64]	8
lr0	UniformFloat[1e-6, 1e-3]	0.000383
optimizer	Categorical[‘Adam’, ‘SGD’, ‘RMSprop’]	AdamW
momentum	UniformFloat[1e-5, 1e-1]	0.522
weight_decay	UniformFloat[1e-5, 1e-1]	0.00665

训练过程中，设置最大迭代次数 Epoch 为 200，设置耐心学习策略，当连续训练 20 个 Epoch 精度未提高后则提前结束训练。训练时将输入图像大小设置为 256×256。训练过程采用余弦退火衰减策略动态调整学习率[200]，余弦退火策略通过引入周期性的余弦函数，逐步将学习率从初始值下降至一个较小的最小值，使得训练过程前期快速下降、后期缓慢微调，从而实现“先快后慢”的退火式优化过程。完成所有迭代次数训练后保存模型参数，记为 CSSD_M，用于后续结果分析。

5.4　实验结果分析

5.4.1　评价指标

目标检测的常用精度评价指标包括：查准率 P(Precision)、召回率 R(Recall)和平均精度 AP(Average Precision)。本文中，将预测框与真实框之间的 IoU 阈值设定为 0.5，假设一个任务中共有 k 个类别，TP(True Positive)代表正确检测的数量，即预测框与

中国知网 https://www.cnki.net

真实框之间的 IoU 值大于 0.5 的数量。FP(False Positive)代表误检数量，即预测框与真实框之间的 IoU 值小于等于 0.5 的数量；FN(False Negative)代表漏检数量，即未被检测到的真实框数量。以精度为纵坐标召回率为横坐标可以绘制 P-R 曲线，而 AP 值是 P-R 曲线所围成的面积，是用于评价模型精度的关键指标，mAP 代表所有类别 AP 的平均值。评价指标如式(5-7)：

$$\begin{cases} IoU=\dfrac{\left|A\cap A'\right|}{\left|A\cup A'\right|} \\ P=\dfrac{\mathrm{TP}}{\mathrm{TP+FP}} \\ R=\dfrac{\mathrm{TP}}{\mathrm{TP+FN}} \\ mAP=\dfrac{1}{k}\sum_{i=1}^{k}AP_i \end{cases} \tag{5-7}$$

其中，A为缺陷预测框区域；A'为缺陷真实框区域。

此外，还使用计算量(Floating point operations, FLOPs)、参数量（Parameters, params）和每秒处理检测帧数三个指标来评价模型性能。FLOPs 用来衡量时间复杂度。params 是模型在训练中的参数总量，用来衡量模型的空间复杂度。FPS 是指一秒钟模型能预测的图像数量。在工业生产中，检测速度意味着能否实现实时生产检测，是工业生产中的一个重要指标。检测速度不仅与模型规模有关，还与模型运行的平台硬件设备有关。

5.4.2　测试集结果分析

图 5-7 为使用 CSSD_M 在测试集上的检测结果，每个检测到的缺陷都有一个候选框，并在上方标明缺陷类别和置信度分数。可以看出，CSSD_M 在缺陷检测中的定位和分类中都取得了较好的性能。

表 5-3 和表 5-4 给出了原始 RT-DETR 模型和 CSSD_M 在测试集的结果。可以看出，与原始 RT-DETR 相比，CSSD_M 提高了对所有缺陷的检测精度，并且对缺陷 CP 和 Pe 的检测精度分别达到了 99.4%和 99.3%，证明了该方法的优越性。值得注意的是，CSSD_M 大幅提高了相似缺陷的检测精度，例如 BS 和 Ho，IS 和 Sm，模型在保证 Ho 和 IS 检测精度的前提下（各自提高了 0.3%），对应的 BS 和 Sm 的检测精度分别提高了 12.5%和 24.1%，证明了本文方法在区分相似缺陷上的能力。此外，

中国知网　https://www.cnki.net

本文方法的 Params 和 GFLOPS 分别降低了 4.6M 和 19.7G，FPS 也提高了 19.6%，说明本文方法能够实现检测精度和推理速度上的均衡。

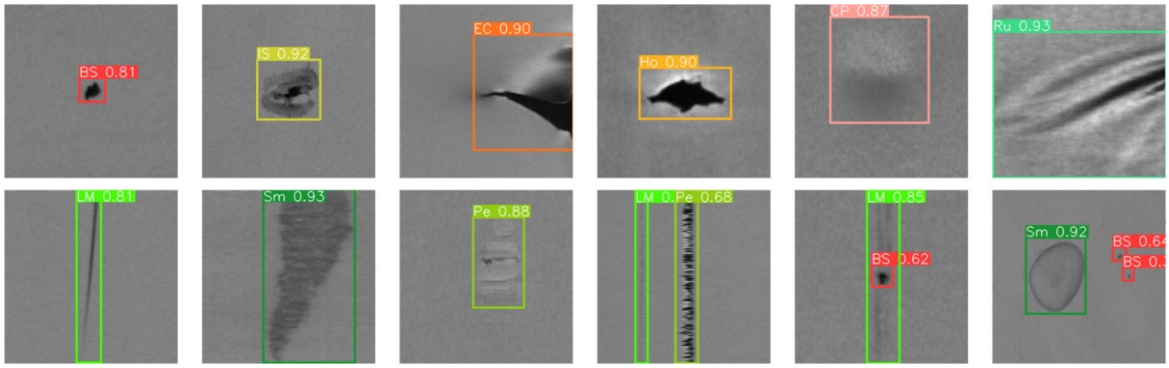


图 5-7　本文方法在测试集中的部分样本检测结果

Fig. 5-7　Detection results of the proposed method on partial samples in the test set

表 5-3　改进前后网络在测试集上的检测结果对比

Table 5-3　Comparison of detection results between the original and improved networks on the test set

模型	AP_{BS} /%	AP_{CP} /%	AP_{EC} /%	AP_{Ho} /%	AP_{IS} /%	AP_{LM} /%	AP_{Pe} /%	AP_{Ru} /%	AP_{Sm} /%	mAP_{50} /%
RT-DETR	66.1	94.5	81.3	88.0	92.0	89.8	84.7	87.2	66.3	83.3
CSSD_M	78.6	99.4	82.4	88.3	92.3	92.1	99.3	90.3	90.4	90.3
	↑12.5	↑4.9	↑1.1	↑0.3	↑0.3	↑2.3	↑14.6	↑3.1	↑24.1	↑7.0

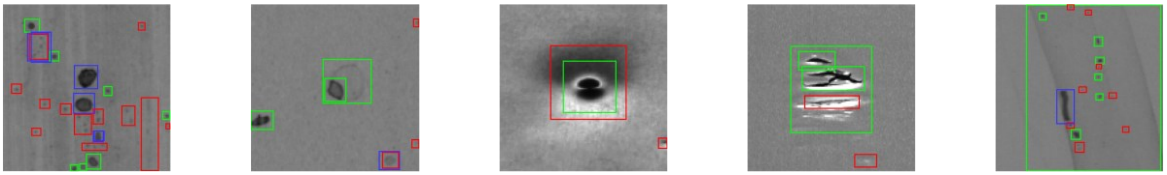
表 5-4　改进前后模型复杂度对比

Table 5-4　Comparison of model complexity before and after improvement

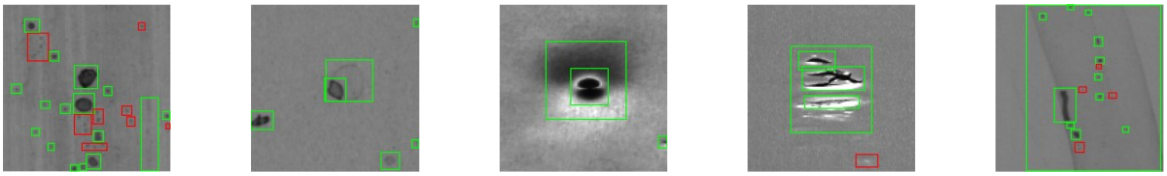
模型	Params/M	GFLOPS	FPS
RT-DETR	19.1	57.3	43.8
CSSD_M	14.5	37.6	52.4
	↓4.6	↓19.7	↑8.6

为对比 CSSD_M 相较于原始 RT-DETR 的效果，本文统计了两种模型在测试集上每张图像的 TP（真正例）、FP（假正例）和 FN（假负例），并进行了可视化对比，部分结果如图 5-8 所示。图像绿色框表示检测正确，蓝色框代表误检，红色框代表漏检。可以看出本文所提方法对表面缺陷的检测更加有效，对各个类型缺陷的漏检和误检都得到有效缓解，预测框也更加贴合真实缺陷区域。

中国知网　https://www.cnki.net



(a)原始 RT-DETR



(b)CSSD_M

图 5-8　CSSD_M 在检测性能的提升

Fig. 5-8　Improvement of CSSD_M in detection performance

5.4.3　消融实验

本文设计消融实验验证所提方法的有效性，实验结果如表 5-5 所示。

表 5-5　消融实验

Table 5-5　Ablation experiment

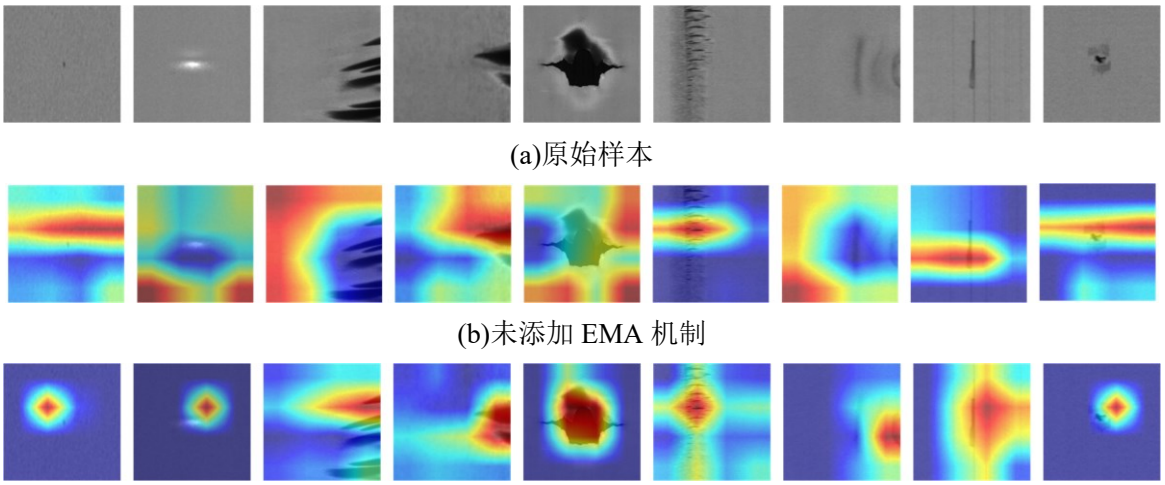
实验序号	使用 EAPRNet	添加 EMA	使用 MS_Dataset	mAP_{50}/%	FPS
1				83.3	43.8
2	√			82.8	56.2
3		√		86.7	39.2
4			√	86.9	43.2
5	√	√		86.5	52.1
6		√	√	89.4	39.6
7	√	√	√	90.3	52.4

以 RT-DETR-r18 为 Baseline，分析了构建的 EAPRNet、EMA 机制和多源样本驱动架构的有效性。对比实验 1、2、5、7，可以看出，本文构建的 EAPRNet 网络能够在保证一定精度的前提下极大提高模型的推理速度，为实现模型轻量化提供了基础。对比实验 1、2、3、5、6、7，可以看出，添加 EMA 机制后，虽然 FPS 有小幅度降低，但能够有效提高模型检测精度，增强网络对目标特征的感知能力，并且将 EAM 机制嵌入 EAPRNet 网络中，同时提高了检测精度和推理速度。对比实验 1、4、5、7，可以看出，使用本文提出的多源样本驱动构架进行训练后，在仅增加训练成本的情

中国知网　https://www.cnki.net

况下，模型 mAP_{50} 值得到大幅度提升，为 3.6%。最终，模型的 mAP_{50} 达到了 90.3%，实现了 52.4 的 FPS。

图 5-9 比较了添加 EMA 机制前后两种情况下模型的 GradCAM 图[201]，如图 5-9 所示。可以看出，在添加了 EMA 机制后，网络可以更好地关注到图像中的目标缺陷区域，提高了网络对目标特征的感知能力。



(a)原始样本

(b)未添加 EMA 机制

(c)添加 EMA 机制

图 5-9　添加 EMA 机制前后的 Grad-CAM 热力图

Fig. 5-9　Grad-CAM heatmaps before and after adding the EMA mechanism

5.4.4　对比实验

为验证本文所提方法的有效性，与其他经典目标检测器进行比较，包括 one-stage 算法 YOLOv7[62]、YOLOv8[202]，two-stage 算法 Faster-RCNN[55]、Mask-RCNN[72]以及基于 Transformer 算法的 RT-DETR[196]。对比的算法实验均使用 MMDetection[203]框架进行，因为它是一个模块化、高效、灵活且支持多任务的目标检测工具箱，拥有丰富的预训练模型和强大的社区支持，适用于学术研究和工业应用。

表 5-6 给出了 CSSD_M 与其他方法在测试集上的结果。对于 two-stage 算法，Mask-RCNN 和 Fast-RCNN 的 mAP_{50} 值分别达到了 80.8%和 79.6%，高于大部分 one-stage 算法，但参数量和 FLOPs 相对较高，并且检测速度慢，FPS 分别只有 19.6 和 23.8，是所有模型中最低的。对于 one-stage 算法，YOLOv7 的 tiny 网络虽然参数量和 FLOPs 较小，检测速度较快，但其 mAP_{50} 值仅为 63.2%，而网络参数量较大的 YOLOv7-l 网络的 mAP_{50} 值也仅为 68.7%。YOLOv8 算法根据网络复杂度由小到大分

中国知网　https://www.cnki.net

为 n、s、m、l 和 x 五个版本。其中，YOLOv8-n 的参数量和 FLOPs 最小，检测速度最快，并且实现了 76.9%的 mAP_{50} 值，优于 YOLOv7 算法。YOLOv8-l 实现了 YOLOv8 系列最高的 mAP_{50} 值为 81.7%，其 FPS 也达到 54.5 了，各方面均优于 YOLOv7。基于 Transformer 算法的 RT-DETR 网络使用 ResNet 系列网络作为主干，分为 Res18、Res34 和 Res50，mAP_{50} 值和 FPS 随着主干网络复杂度的增加分别增加和降低。RT-DETR-r50 达到了最高的 mAP_{50} 值为 86.2%，RT-DETR-r18 实现了最高的 FPS43.8。CSSD_M 实现了所有模型中最高的 mAP_{50} 值，达到了 90.3%。此外，与 Baseline 模型相比，CSSD_M 在大幅提高模型精度的基础上，降低了 FPS，实现了模型轻量化。

表 5-6　不同模型在测试集上的结果

Table 5-6　Results of different models on the test set

模型	P/%	R/%	mAP_{50}/%	Params/M	GFLOPs	FPS
Mask-RCNN	71.8	76.1	80.8	44.01	190.46	19.6
Faster-RCNN	69.1	74.8	79.6	41.39	137.22	23.8
YOLOv7-l	48.5	60.3	68.7	36.5	103.3	46.9
YOLOv7-tiny	45.6	57.5	63.2	6.0	13.1	63.7
YOLOv8-n	71.4	72.8	76.9	2.87	8.7	98.6
YOLOv8-s	71.4	75.9	78.2	10.61	28.6	88.7
YOLOv8-m	63.1	75.4	74.4	24.65	78.9	66.3
YOLOv8-l	74.2	79.7	81.7	41.59	165.2	54.5
YOLOv8-x	71.4	76.7	80.5	64.98	257.8	48.5
RT-DETR-r18	77.2	82.5	83.3	19.05	57.3	43.8
RT-DETR-r34	79.2	82.8	85.8	29.78	89.1	32.8
RT-DETR-r50	81.5	83.4	86.2	40.17	129.9	31
CSSD_M	89.1	86.3	90.3	14.5	37.6	52.4

本文根据指标 mAP_{50}、FPS 和 Params 绘制的不同模型的气泡图，如图 5-10 所示。其中，横坐标为 FPS，纵坐标为 mAP_{50}，越接近右上角代表模型综合性能越好，气泡大小代表模型的参数量的多少。可以看出，CSSD_M 在指标 mAP_{50} 上实现了最优性能。在推理速度方面，虽然相较于 YOLO 系列的轻量化网络有一定差距，也能满足工业生产要求。此外，本文方法能直接得到预测结果，而 YOLO 系列算法在输出前还需进行 NMS 等后处理操作，本文方法有效避免了后处理操作在实际应用中带来的不稳定性因素。

中国知网　https://www.cnki.net

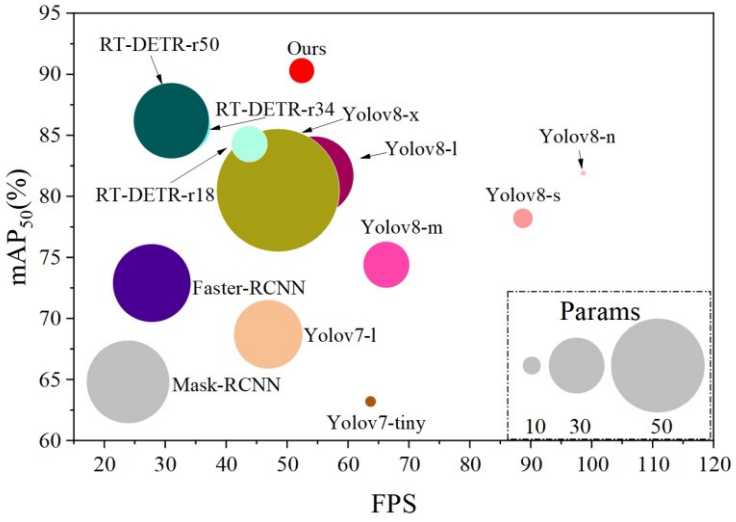


图 5-10　不同方法之间综合性能对比

Fig. 5-10　Comprehensive performance comparison between different methods

5.5　本章小结

本章基于多源数据集，构建了高效铜带表面缺陷检测模型 CSSD_M。通过设计自适应部分卷积算子 APConv，有效减少了特征通道冗余计算量；引入 EAPR_Block 与高效多尺度注意力机制 EMA，并据此搭建高效自适应残差网络，实现模型结构的轻量化设计。训练过程使用 Optuna 框架实现超参数自动寻优，提升了模型的检测性能。实验结果表明，CSSD_M 在 mAP_{50} 指标上达到 90.3%，较原始 RT-DETR 提升 7.0%，同时模型参数量减少 4.6M、计算量降低 19.7G、推理速度提升 19.6%，在精度与速度之间实现了良好平衡。此外，对比实验显示，本文方法在检测精度与轻量化性能上均表现最优，验证了其在实际工业环境下的高效性与可行性。

中国知网　https://www.cnki.net

第 6 章　铜带表面缺陷智能检测系统的集成与工业应用

本章旨在解决工业现场原始图像中复杂背景干扰及铜带跑偏对缺陷检测精度与定位准确性的制约问题，并最终实现检测系统的工业化应用。首先研究了面向铜带的快速智能分割方法，通过构建适用于生产现场的分割数据集，并采用轻量化网络模型实现对铜带区域的精确提取。在此基础上，研究了基于分割结果的边缘位置提取算法，以实现对铜带跑偏量的实时辅助检测。最后，针对实际生产现场研制了一套集硬件配置、软件架构、模型轻量化部署及人机交互界面于一体的智能化在线检测系统，通过在典型冷轧产线上的在线应用，验证了前述理论与方法在工业环境下的有效性与实用价值。

6.1　铜带区域智能分割模型与跑偏量辅助检测

6.1.1　铜带区域智能分割模型

（1）铜带区域分割数据集构建

本节所用数据为 3.1 节采集的无雾条件下冷轧生产图像数据。由于采集设备与轧制平面呈一定的空间倾角，采用透视变换原理对其进行矫正。透视变换前确定四个原始坐标点和四个目标坐标点。由于铜带与板形辊间的包角会随铜带卷径的变化而变化，为方便后续跑偏计算，需确定当包角最小时图像中铜带与板形辊的接触部分，延伸这部分到板形辊边缘四个顶点，将其选定为四个原始坐标点 $\mathrm{A}_i(i=1\sim4)$，如图 6-1 中红色虚线部分。目标坐标点选取在透视变换后图像的四个顶点 $\mathrm{A}_i'(i=1\sim4)$，如图 6-1 中蓝色虚线部分，透视变换后图像宽高尺寸设置为 600×100 像素。

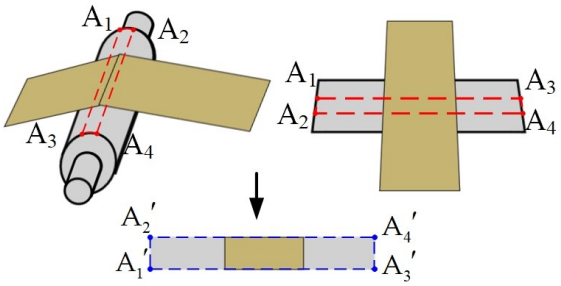


图 6-1　透视变换坐标点选取

Fig. 6-1　Selection of coordinate points for perspective transformation

中国知网　https://www.cnki.net

将原始坐标点 $\mathrm{A}_i(x_i,y_i)(i=1\sim4)$ 从笛卡尔坐标系转换到齐次坐标系，转换关系如式(6-1)：

$$\begin{cases} x_i=\dfrac{X_i}{Z_i} \\ y_i=\dfrac{Y_i}{Z_i} \end{cases} \quad (i=1\sim4) \tag{6-1}$$

其中，(X_i,Y_i,Z_i) 为齐次坐标系下原始坐标点，记为 $\mathrm{Ah}_i(i=1\sim4)$，一般令 Z_i=1。

同理，根据 $\mathrm{A}_i'(i=1\sim4)$ 得到齐次坐标系下目标坐标点，记为 $\mathrm{Ah}_i'\left(X_i',Y_i',Z_i'\right)\left(i=1\sim4\right)$。进而通过式(6-2)求解透视变换矩阵 $\boldsymbol{M_T}$：

$$\begin{bmatrix} X_i' \\ Y_i' \\ Z_i' \end{bmatrix}=\boldsymbol{M_T}\begin{bmatrix} X_i \\ Y_i \\ Z_i \end{bmatrix} \tag{6-2}$$

其中，$\boldsymbol{M_T}=\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$，一般令 a_{33}=1。

在现场共采集了 2000 张不同带宽、不同跑偏位置图像数据，进行透视变换处理后保存为图像数据集。然后通过人工标定方法，使用 Labelme 软件手动标出图像中的铜带区域作为真实标签，标注过程如图 6-2 所示。

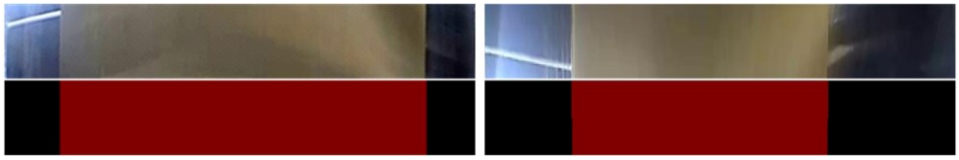


图 6-2　图像标注过程

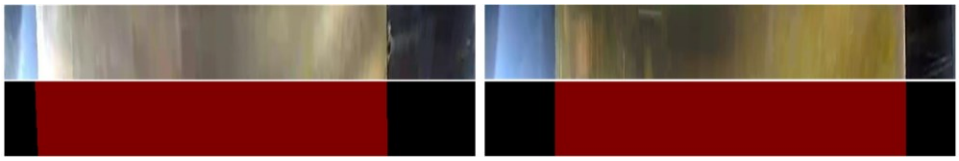
Fig. 6-2　Image annotation process

中国知网　https://www.cnki.net

将图像数据与对应的标签数据保存为数据集 CSRS_Dataset，共 2000 组，部分数据如图 6-3 所示。将 CSRS_Dataset 按照 8:1:1 的比例划分为训练集 CSRS_Trainset、验证集 CSRS_Valset 和测试集 CSRS_Testset，用于后续模型训练及性能测试，划分后数据集分布如表 6-1 所示。



(a)不同铜带宽度



(b)不同位置

图 6-3　图像数据及对应标签

Fig. 6-3　Image data and corresponding labels

表 6-1　铜带区域分割数据集分布

Table 6-1　Distribution of copper strip region segmentation dataset

数据集	铜带宽度/mm	数据量/组	总计/组
CSRS_Trainset	320	448	1600
	348	584	
	420	568	
CSRS_Valtset	320	56	200
	348	73	
	420	71	
CSRS_Testset	320	56	200
	348	73	
	420	71	

（2）轻量化智能语义分割网络

为提高缺陷检测精度以及获取后续铜带跑偏量信息，首要任务是对图像中的铜带区域进行高精度分割。该步骤需能够准确区分铜带本体与背景、边缘区域与环境，从而为后续的几何计算、位置分析与缺陷检测奠定基础。

中国知网　https://www.cnki.net

图像分割技术作为计算机视觉中的关键任务之一，通常可分为两大类：传统图像分割方法与基于深度学习的图像分割方法。传统方法主要包括阈值分割、区域生长、图割和活动轮廓模型等。这些方法具有结构简单、计算效率高、可解释性强等优势，在早期工业图像处理中得到广泛应用。然而，这类方法面对工业现场中复杂多变的光照条件、表面纹理变化、背景干扰、图像噪声及动态运动模糊等情况下，往往依赖于人工设计的图像特征（如灰度梯度、边缘位置、几何先验等），难以适应多样化场景，且对参数设置高度敏感，鲁棒性与泛化能力有限。相比之下，基于深度学习的图像分割方法则展现出显著的性能优势。该类方法通过构建端到端的深度神经网络架构，能够从原始图像中自动学习高维语义特征，并有效融合空间信息与上下文信息，进而实现更加准确的语义分割效果。在大规模标注数据的支持下，无需人工设计特征，显著提升了系统的自适应能力与泛化能力。

在深度学习技术的推动下，图像语义分割技术取得了显著进展，广泛应用于自动驾驶[204]、医疗图像处理[205]、遥感解译[206]等多个领域。语义分割旨在为图像中每一个像素赋予其语义类别标签，是一种典型的密集预测任务。针对该任务，学术界设计出了具有不同架构的分割网络，主要可分为编码器-解码器架构和双分支架构两大类。

编码器-解码器架构代表性方法如 U-Net[70]、SegNet[207]等。此类网络通常包含一个逐步降低图像空间分辨率的编码器部分，负责提取高层次抽象语义信息。同时，通过解码器逐步恢复图像空间细节。在该过程中，模型常通过“跳跃连接”机制，将编码器中不同尺度的低级特征传递至解码器，以弥补语义信息传递过程中在图像细节的损失，从而提升分割精度。此类架构虽然精度较高，但通常参数量较大、计算开销较高，难以满足实时性要求。

双分支架构则以 ICNet[208]、BiSeNet[209]、Fast-SCNN[210]等为代表，核心思想是在两个不同分辨率尺度下并行提取图像特征：高分辨率分支聚焦于边缘与纹理等空间细节信息，低分辨率分支则提取全局语义信息。在特征融合阶段，将两类特征综合处理，实现语义准确性与空间细节保留之间的有效权衡。

考虑到铜带表面智能检测系统对模型推理速度、部署资源占用和分割精度的综合要求，本文采用 Fast-SCNN 算法进行研究[210]。Fast-SCNN 是一种专为移动端与实时场景设计的轻量级语义分割网络，其创新性地融合了编码器-解码器结构与双分支架构的优势，通过结构上的高效设计，在保证精度的同时显著提升了推理速度与计

中国知网 https://www.cnki.net

算效率。

Fast-SCNN 网络整体结构如图 6-4 所示，由四个关键模块组成：学习下采样模块（Learning to Downsample）、全局特征提取模块（Global Feature Extractor）、特征融合模块（Feature Fusion Module）以及分类器模块（Classifier）。

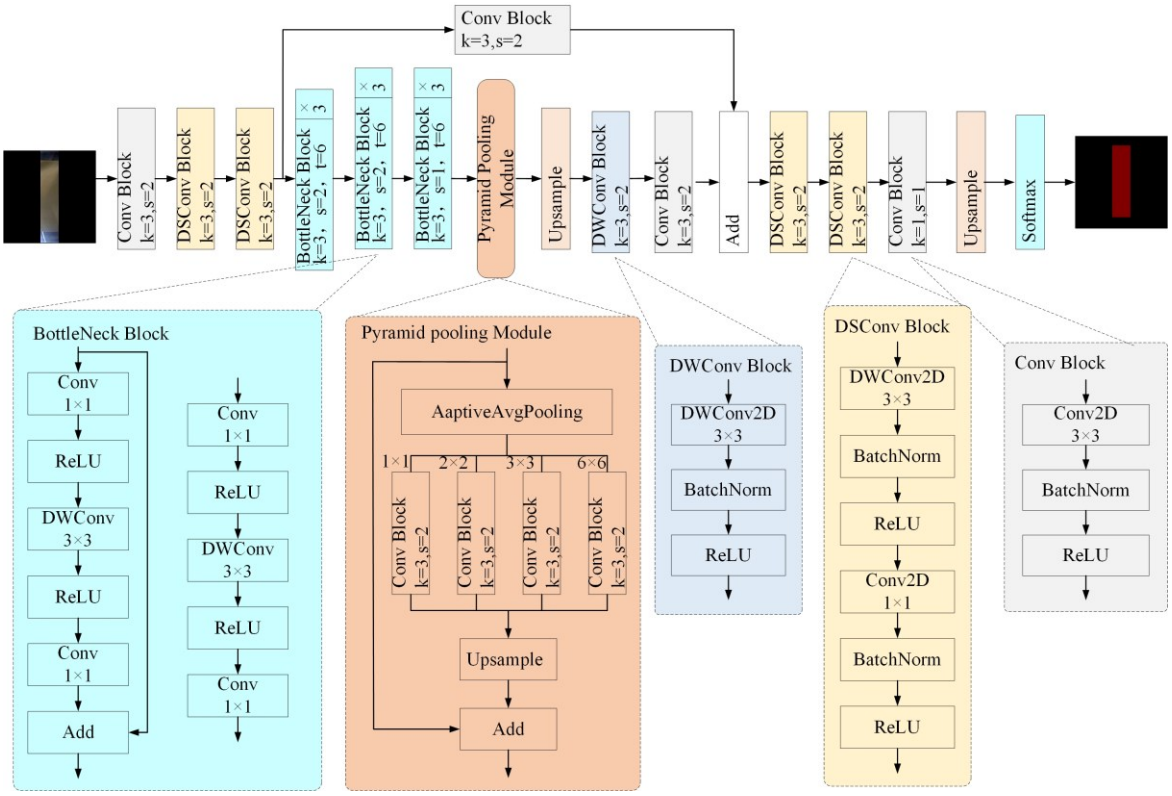


图 6-4　Fast-SCNN 网络结构

Fig. 6-4　Fast-SCNN network structure

其中，学习下采样模块主要负责对输入图像进行初步特征提取与降维，结构上采用一层标准卷积和两层深度可分离卷积，可在保证特征表达能力的同时显著减少参数量与计算量。全局特征提取模块采用堆叠的残差瓶颈块（Residual Bottleneck），并结合深度可分离卷积进行高层语义特征提取。该模块最后引入金字塔池化模块（Pyramid Pooling Module, PPM）[211]，用于聚合多尺度上下文信息，增强模型对不同尺寸物体的识别能力，提升全局感受野。特征融合模块将高分辨率路径中保留的细节特征与低分辨率路径中提取的语义特征进行对齐融合，通过上采样与逐点卷积完成特征对齐，保证融合特征具备良好的空间分辨率与语义表达能力。分类器模块则使用两层深度可分离卷积和一层逐点卷积，最后通过上采样恢复到原始图像尺寸，

中国知网　https://www.cnki.net

使用 Softmax 分类器对每个像素进行语义分类。

Fast-SCNN 在模型参数量和推理速度方面具有明显优势。其整体参数量远小于传统高精度模型，非常适用于工业生产环境的在线部署需求。

（3）训练细节

Fast-SCNN 网络训练的优化器使用 SGD，动量设置为 0.9；Batch-size 设置为 8；最大迭代次数 Epoch 设置为 200；初始学习率 lr_0 设置为 0.0001，每训练一个 Epoch，则下一次训练的学习率衰减为上一次训练学习率的 γ 倍，γ 设置为 0.1；损失函数使用 CrossEntropyLoss。训练学习率采用按步衰减策略，如式(6-3)：

$$lr_i = lr_0 \times \gamma^i \left(i = 1, 2, \cdots, n\right) \tag{6-3}$$

每训练完成一个 Epoch，利用验证集 CSRS_Valset 进行一次精度验证并保存一个权重文件。完成所有 Epoch 训练后，将性能最优的权重文件作为铜带区域分割模型 CSRS_M。

（4）实验结果分析

分割精度常用的评价指标有交并比 IoU(Intersection over Union)和像素精度 PA(Pixel Accuracy)。假设一个任务中共有 k+1 个类别（k 表示要预测的类别个数加上一个背景类别），p_{ii} 代表真实类别为 i 并且预测正确的像素数量；p_{ij} 代表真实类别为 i 但被预测为类别 j 的像素数量；p_{ji} 代表真实类别为 j 但被预测为类别 i 的像素数量。PA 代表某类别预测正确的像素占真实像素的比例，mPA 为所有类别 PA 的平均值。IoU 代表某类别预测像素与真实像素的交集与并集的比，mIoU 为所有类别 IoU 的平均值。评价指标公式如式(6-4)：

$$\begin{cases} PA = \dfrac{\sum_{i=0}^{k} p_{ii}}{\sum_{i=0}^{k}\sum_{j=0}^{k} p_{ij}} \\ mPA = \dfrac{1}{k+1}\sum_{i=0}^{k} \dfrac{p_{ii}}{\sum_{j=0}^{k} p_{ij}} \\ IoU = \dfrac{\sum_{i=0}^{k} p_{ii}}{\sum_{i=1,j=0,i\neq j}^{k}\left(p_{ij} + p_{ji} - p_{ii}\right)} \\ mIoU = \dfrac{1}{k+1}\sum_{i=0}^{k} \dfrac{p_{ii}}{\sum_{j=0}^{k} p_{ij} + \sum_{j=0}^{k} p_{ji} - p_{ii}} \end{cases} \tag{6-4}$$

本文在构建好的 CSRS_Testset 上对铜带区域分割模型进行验证，分别从模型的分割精度、复杂度、推理效率三方面进行评估。

中国知网 https://www.cnki.net

为验证 CSRS_M 的有效性，与其他经典语义分割算法进行比较，包括 FastFCN[212]、KNet[213]、U-Net[70]、PSPNet[211]、Mask2Former[214]、DDRNet[215]、PIDNet[216]。对比的算法实验均使用 MMDetection[188]框架进行，实验结果如表 6-2 所示。对于分割精度，Mask2Former 的 mIoU 值最高，达到 98.83%。CSRS_M 模型的 mPA 值最高，达到 99.54%。对于模型复杂度，KNet 的 FLOPs 和 Params 最大，分别达到了 420G 和 245.2M。而 CSRS_M 的 FLOPs 和 Params 为所有模型中最小的，仅为 0.927G 和 1.4M，说明基于 Fast-SCNN 构建的分割模型更适合部署在计算资源受限的工业环境中。此外，具有最小参数量的 CSRS_M 也具有最快的 FPS，为 104.3 FPS，能够满足工业生产中的实时性要求。综合考虑模型分割精确、复杂度以及推理时间，基于 Fast-SCNN 的铜带区域分割模型 CSRS_M 的综合性能最优。

表 6-2　CSRS_M 与经典语义分割网络对比结果

Table 6-2　Comparison results of CSRS_M and classic semantic segmentation networks

模型	mIoU/%	mPA/%	FLOPs/G	Params/M	FPS
CSRS_M	98.79	99.54	0.9	1.4	104.3
FastFCN	98.72	99.48	221	85.5	18.6
KNet	98.81	99.53	420	245.2	5.4
U-Net	98.71	99.49	203	29.0	14.1
PSPNet	98.02	99.25	179	46.6	18.0
Mask2Former	98.83	99.53	381	216	4.6
DDRNet	98.74	99.48	4.6	5.7	55.9
PIDNet-s	97.87	99.24	5.9	7.7	47.4
PIDNet-l	97.43	98.98	34.4	37.3	34.5

6.1.2　铜带跑偏量辅助检测

（1）跑偏量辅助检测算法

经过 CSRS_M 检测得到的图像分割结果如图 6-5 所示。



图 6-5　铜带区域分割结果

Fig. 6-5　Segmentation results of the copper strip region

中国知网　https://www.cnki.net

图中白色区域为分割出的铜带，黑色部分为背景，可以看出图中已经包含了铜带边缘的位置信息，为进一步获取铜带位置及几何尺寸，还需要设计铜带边缘位置提取算法，算法流程如图 6-6 所示。

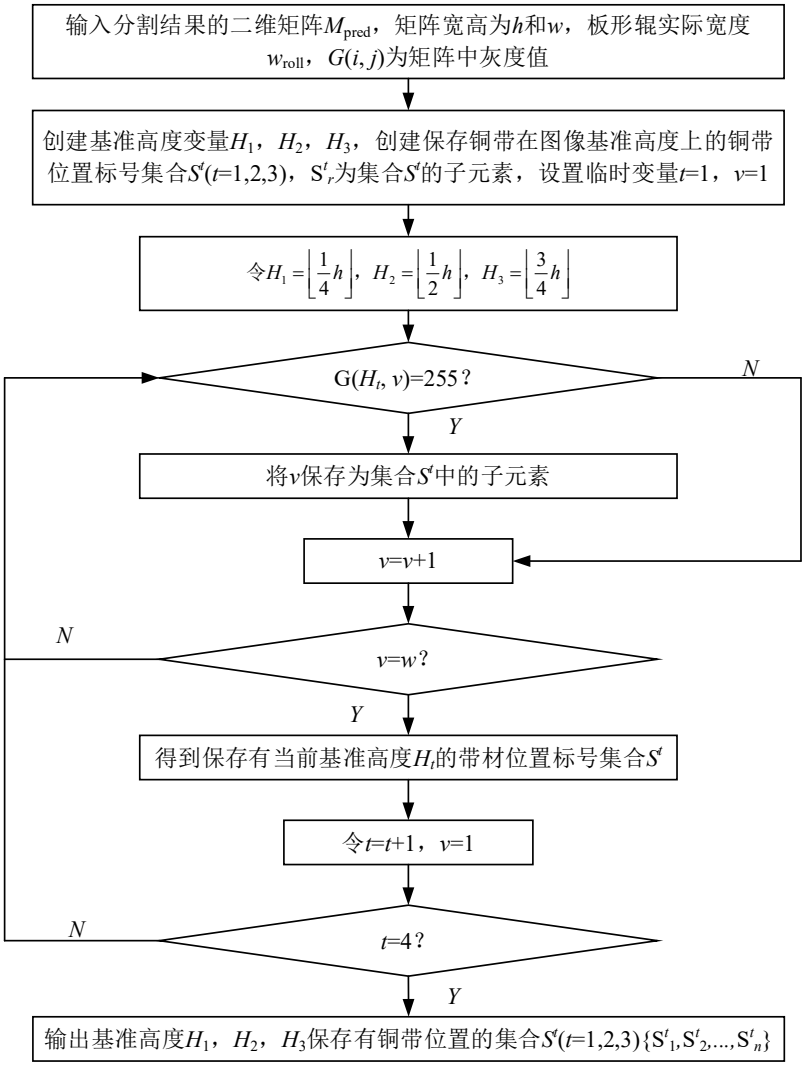


图 6-6　铜带边缘位置提取算法流程图

Fig. 6-6　Flowchart of the copper strip edge position extraction algorithm

通过图 6-6 算法可以得到三个不同基准高度的铜带位置集合 $S^t=\{S^t_1,S^t_2,\cdots,S^t_n\}(t=1,2,3)$，再通过式(6-5)计算三个不同基准高度的铜带边缘平均位置。

$$P_{op}=\left\lfloor\frac{1}{4}S^t_1\right\rfloor \qquad P_{dr}=\left\lfloor\frac{1}{4}S^t_n\right\rfloor \ (t=1,2,3) \tag{6-5}$$

其中，P_{op}为操作侧铜带边缘平均位置；P_{dr}为传动侧铜带边缘平均位置。

中国知网　https://www.cnki.net

根据铜带边缘位置可以进行后续裁剪处理，剔除无用背景信息，仅保留铜带区域，方便后续进行缺陷检测。此外，铜带尺寸与位置可由式(6-6)计算得到：

$$\begin{cases} W_{strip} = \left| P_{\text{op}} - P_{\text{dr}} \right| \\ \delta = \left(P_{\text{op}} + P_{\text{dr}} - w \right) \times \dfrac{w_{\text{roll}}}{w} \end{cases} \tag{6-6}$$

其中，W_{strip} 为铜带宽度；δ 为铜带位置，即跑偏量；w 为图像像素宽度。

（2）实例验证

此冷轧生产现场安装有一套基于红外传感器的边缘检测装置，实物如图 6-7 所示。此装置检测器分为左、右两部分，分别检测铜带左、右边缘，检测信号经过前置放大器和主放大器，最终计算出跑偏量。该装置数据采集周期为 2 次/s。而本文图像采集周期为 30 帧/s。为方便两者进行结果对比，分别取每个采集周期第 8 帧和第 23 帧图像用于模型输入，共采集了一卷铜带轧制过程的 944 组连续生产样本数据。

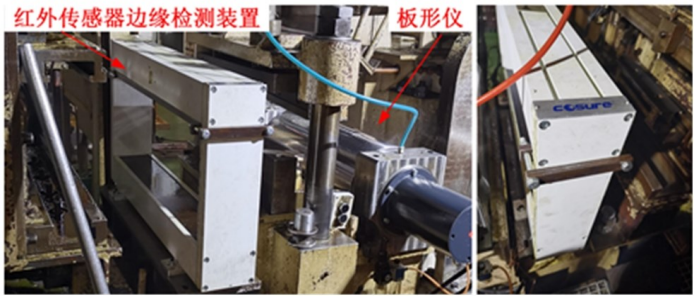


图 6-7　红外传感器边缘检测装置实物图

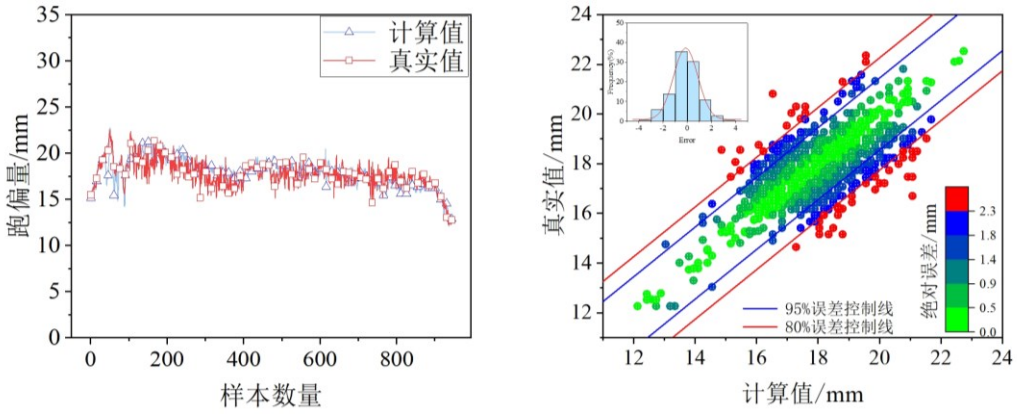
Fig. 6-7　Physical image of the infrared sensor edge detection device

通过本文方法可以得到 944 组铜带位置计算值。图 6-8 给出了本文方法跑偏量计算值与真实值（边缘检测装置）的对比结果。

图 6-8(a)为 944 个样本的跑偏量计算值与真实值对比图，蓝色三角符号点线代表计算值，红色方框形点线代表真实值，可以看出计算值与真实值的折线趋势基本一致，并且本文方法的跑偏量计算值波动更小。图 6-8(b)为所有样本跑偏量计算值与真实值间的绝对误差散点图，点的颜色代表该样本的绝对误差大小，图中绿色点代表绝对误差在全部样本的前 80%，蓝色点代表绝对误差在全部样本的前 80%-95%之间，红色点代表绝对误差在全部样本的后 5%。图中还给出了 80%和 95%的绝对误差控制线，分别为 1.45mm 和 2.26mm。左上角给出了绝对误差分布图，65.88%的样本绝对误差在±1mm 之间，99.36%的样本绝对误差在±2mm 之间，且 944 个样本的平均绝

中国知网　https://www.cnki.net

对误差仅为 1.15mm。



(a)计算值与真实值对比图　　(b)计算值与真实值间的绝对误差散点图

图 6-8　本文方法跑偏量计算值与真实值结果对比

Fig. 6-8　Comparison between calculated strip deviation values of the our method and ground truth

为分析本文方法与传统方法的性能差异，选取三种经典传统图像分割方法进行对比，包括基于阈值方法的 OTSU 算法、基于聚类方法的 K-means 算法和基于区域方法的区域生长算法，实验结果如表 6-3 所示。

表 6-3　与传统方法性能对比

Table 6-3　Performance comparison with traditional methods

分割方法		平均绝对误差/mm	平均推理时间/ms
OTSU		127.32	14.3
K-means		62.54	37.2
区域生长	α =15	76.14	63.2
	α =30	27.66	111.3
	α =48	7.17	434.2
本文方法		1.15	21.6

可以看出，OTSU 算法的平均推理时间最短，仅为 14.3 ms，但计算的跑偏量平均误差达到 127.32 mm，说明 OTSU 算法无法正确分割出图像中的铜带区域。由于本文只需将图像分割为铜带和背景两部分，因此将 K-means 聚类算法中的聚类数量设置为 2。结果显示，K-means 算法平均误差为 65.54 mm，比 OTSU 算法有所降低，但平均推理时间也明显增加。区域生长算法的整体性能受相似性阈值参数α影响较

中国知网　https://www.cnki.net

大，表中给出区域生长算法在不同α值下的性能。可以看出，随着α值的增大，误差降低，但计算复杂度增加，导致平均推理时间增大。当α值为 48 时，平均误差为 7.17 mm，但此时平均推理时间已经达到 434.2 ms，说明区域生长算法可以在牺牲计算速度的情况下达到一定的精度。而本文方法的平均误差仅为 1.15 mm，显著低于上述三种方法，并且平均推理速度仅为 21.6 ms，能够满足生产需求。

6.2　工业应用场景与硬件配置

6.2.1　工业应用场景分析

安徽芜湖楚江高精铜带有限公司某分厂铜带生产线配置了 800mm 冷轧铜带六辊可逆精轧机，可满足宽度为 800mm 以下的铜带生产需求。该产线还配备了 AGC 厚度控制系统和板形自动检测与控制系统，保证铜带厚度精度与板形精度。此 800mm 六辊可逆轧精轧机基本参数与可生产的产品规格如表 6-4 所示。

表 6-4　800mm 铜带六辊可逆精轧机基本参数

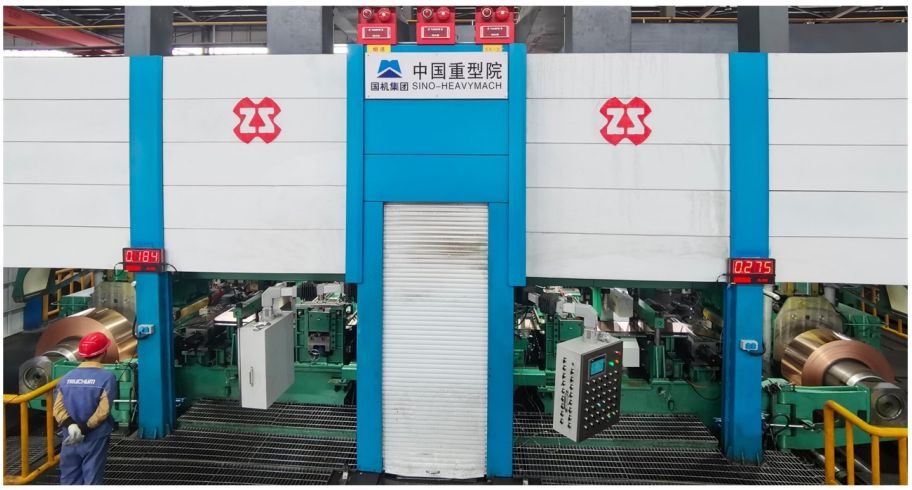
Table 6-4　Basic parameters of 800mm copper strip six-high reversible cold finishing mill

类别	参数
工作辊辊径	Φ160/Φ150×800 mm
中间辊规格	Φ260/Φ240×950 mm
工作辊辊径	Φ650/Φ610×800 mm
最大轧制力	4500 kN
最大轧制速度	480 m/min
来料最大厚度	2.0 mm
来料最大宽度	670mm
带卷内径	Φ610mm
带卷最大外径	Φ1800mm
来料厚差	纵向：±1.5%　横向：±1%
成品厚度范围	0.08-1.6mm

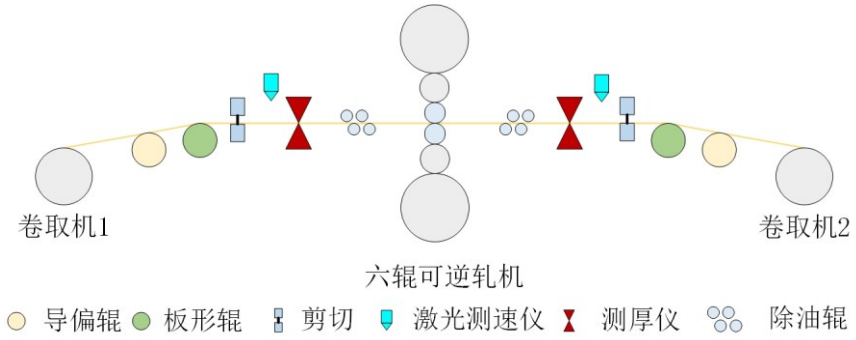
800 六辊可逆精轧机实物图与设备布置示意图如图 6-9 所示。生产过程中，铜带上表面经常会出现表面缺陷问题，生产过程不能及时发现，导致难以评估产品表面

中国知网　https://www.cnki.net

质量等级。此外，生产中的铜带还经常发生位置偏移现象，不仅影响缺陷位置定位，而且可能导致生产事故。针对上述问题，本文开展了基于机器视觉的铜带表面缺陷检测系统研究，完成了检测系统硬件设备与软件平台的协同开发，实现了对铜带表面质量的实时监测与评估。



(a)产线图



(b)产线布置示意图

图 6-9　800mm 六辊可逆精轧机产线

Fig. 6-9　800 mm six-high reversible finishing mill production line

6.2.2　硬件配置

铜带表面缺陷检测系统的硬件配置方案如图 6-10 所示。硬件主要由图像采集设备、照明系统、检测箱体以及数据处理与存储单元等组成。

中国知网　https://www.cnki.net

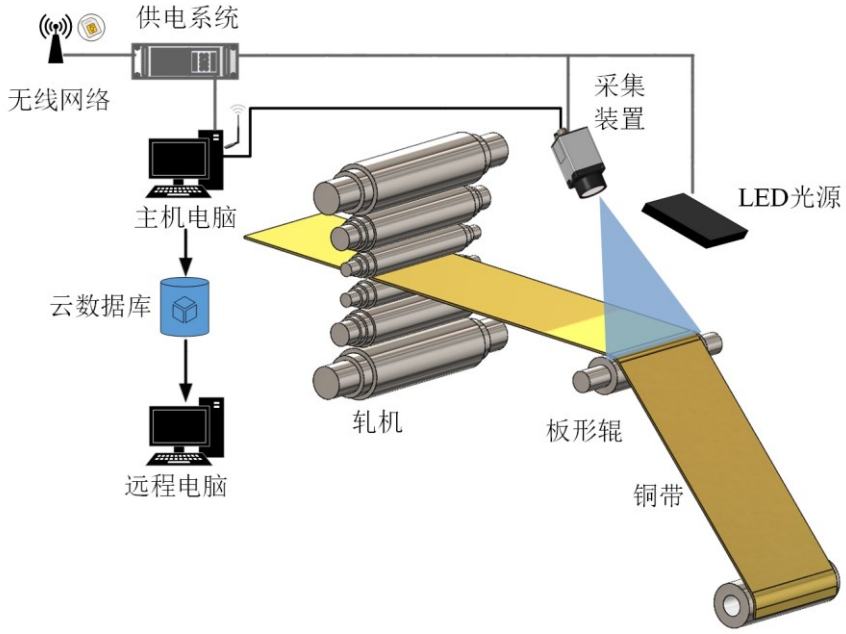


图 6-10　硬件配置方案

Fig. 6-10　Hardware configuration plan

工业相机作为机器视觉系统的核心部件，其在采样稳定性、数据链路可靠性与电磁抗扰性方面显著优于普通相机。按照扫描方式，工业相机可分为线阵与面阵两类。线阵方案在超高速、超宽幅连续铜带检测中具备先天带宽优势，但对光机同轴性、同步与安装精度要求较高；面阵方案在安装维护与图像可视化方面更为直观，适合与通用深度学习检测框架快速对接。综合现场工况、安装空间与部署便捷性，本文选择采用海康机器人 320 万像素 1/1.8”CMOS 千兆以太网面阵相机，型号为 MV-CA032-10GC，并搭配焦距为 8 mm 的镜头，如图 6-11 所示。工业相机的关键参数见表 6-5。



图 6-11　工业相机选型

Fig. 6-11　Selection of industrial cameras

中国知网　https://www.cnki.net

表 6-5　工业相机的具体参数

Table 6-5　Detailed parameters of the industrial camera

性能指标	参数
相机型号	MV-CA032-10GC
传感器	Sony IMX265
传感器类型	CMOS，全局快门
相机分辨率	2048×1536
像元尺寸	3.45 μm×3.45 μm
靶面尺寸	1/1.8”
最大帧率	38.5 fps
动态范围	73 dB
信噪比	40 dB
增益范围	0-20 dB
数据接口	GigE
镜头接口	C-Mount
黑白 / 彩色	彩色

在机器视觉检测系统中，光源的选型直接决定了缺陷的可见性和成像对比度。常见的照明方式包括同轴光、环形光、条形光和面光源，其中面光源能够提供均匀的大面积照明，适合大视场的平面目标检测。本文选用中间开孔的高亮度 LED 面光源，并采用直射式照明方式。此外，光源还必须配合专用的光源控制器进行精确驱动与管理。光源控制器能够提供恒流输出，避免电流波动对其寿命和照度稳定性的影响，同时支持亮度分级调节与 PWM 脉宽调制，实现对光照强度的精细控制。本文使用的照明系统如图 6-12 所示。

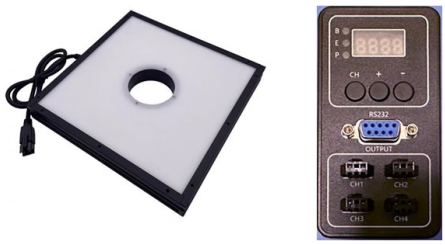


图 6-12　照明系统

Fig. 6-12　Lighting system

中国知网　https://www.cnki.net

数据处理单元是工业检测系统的核心，主要作用是接收和处理相机采集的高速图像数据，并完成深度学习模型的推理与结果输出。该单元通常由配备高性能 CPU 和 GPU 的工业计算机构成，CPU 负责系统调度与基础图像预处理，GPU 用于缺陷检测与图像增强的加速计算。同时，内存与高速存储设备用于缓存与保存检测数据，确保结果可追溯。在采用千兆以太网相机时，图像可直接通过网口传输至工控机而无需采集卡。数据处理单元还通过标准工业通信接口与 PLC 进行交互，实现结果上传与报警联动。此外，工控机具备高耐久性、强抗干扰能力和优越的环境适应性，能够在恶劣工业现场实现 24 小时稳定可靠运行，如图 6-13 所示。



(a) CPU　　(b) 工控机　　(c) GPU

图 6-13　数据处理单元

Fig. 6-13　Data processing unit

为在复杂工业生产环境下有效保护图像采集装置并满足散热需求，设计了一套箱体结构。整体框架如图 6-14 所示，主要由固定部分、自由度调节部分以及图像采集装置组成。



图 6-14　整体框架与箱体结构图

Fig. 6-14　Overall frame and box structure diagram

固定部分采用铝合金材料制造，具有重量轻、强度高、安装便捷等优点，能够在保证结构刚性的同时减少整体体积和重量，适用于空间受限的生产线环境。自由度调节部分主要用于实现设备位置与角度的灵活调整，可沿 Z 轴与 Y 轴进行大范围位移，以满足不同检测位置和视角下的图像采集需求。固定部分的横梁上安装有导

中国知网　https://www.cnki.net

轨-滑块机构，图像采集装置通过支撑底座固定在滑块上，每个滑块均配备锁紧装置，可在调整到指定位置后保持稳定，避免运行过程中产生偏移，从而确保成像一致性与检测精度。

图像采集装置整体封装于防护箱体中。箱体采用不锈钢材料加工而成，两侧通过大扭矩阻尼转轴与支撑板连接，可实现沿 Y 轴的连续旋转并能在任意角度位置稳定停留，方便调整相机与铜带表面的相对角度。箱体前端安装高透光率钢化玻璃，既保证成像透光性，又具备优良的耐冲击与耐腐蚀性能；上部设置有抽拉密封板，进一步提升了整体密封性，可有效防止油雾与粉尘进入箱体内部，保证系统在复杂工况下的长期稳定运行。

箱体内部集成了相机、光源及相机云台等关键部件。其中，相机安装于万向云台上，可实现小范围的升降与旋转，以适应不同检测视角与焦距的微调需求。考虑到工业现场长时间连续运行会产生大量热量，箱体尾部设计了主动散热系统，利用散热风扇及时排出内部热量，防止相机与光源因温度升高导致性能下降或寿命缩短。为避免外部粉尘随气流进入，散热系统配备了可拆卸防尘滤网。箱体主体采用厚度为 2 mm 的镀锌板结构，并经过喷砂表面处理，以消除金属反光对图像采集造成的干扰。装置实物如图 6-15 所示。



图 6-15　箱体结构实物图

Fig. 6-15　Physical diagram of the enclosure structure

6.3　智能模型微调部署与整体检测流程

6.3.1　图像预处理

根据上述构建的机器视觉采集装置在此现场收集了一批真实铜带生产数据，原始图像如图 6-16 所示。

中国知网　https://www.cnki.net

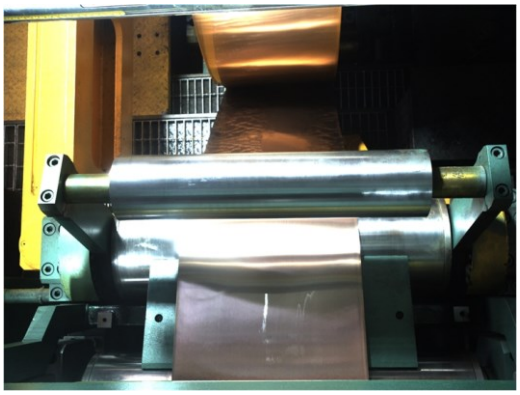


图 6-16　原始图像

Fig. 6-16　Original image

可以看出，采集的原始图像中包含了大量冗余背景信息。此外，随着生产不同批次的产品规格以及卷取机上铜带卷径的变化，铜带宽度、铜带与相机之间的空间倾角也是动态变化的，无法采用固定区域裁剪的方式去除背景和透视畸变，增加了图像预处理的复杂性。为此，首先对原始图像进行预处理，具体流程如下：

（1）采集原始图像：给定原始图像 I_{raw}；

（2）ROI 裁剪：对 I_{raw} 进行 ROI 裁剪，将裁剪后范围选定在铜带与板形辊附近区域，裁剪范围为[1050:1495, 500:1750]，ROI 后的图像记为 I_{ROI}，将 I_{ROI} 的高度记为 h，宽度记为 w；

（3）高斯滤波：对 I_{ROI} 进行高斯去噪处理，高斯核尺寸 kernel_size 设定为 5×5，标准差 sigma 设定为 1.5，得到高斯去噪后图像 I_{gauss}；

（4）图像复原（可选操作）：使用建立的图像复原模型（非均匀光照校正模型和去雾模型）对 I_{gauss} 进行光照校正和去雾处理，复原后图像记为 $I_{recovery}$；

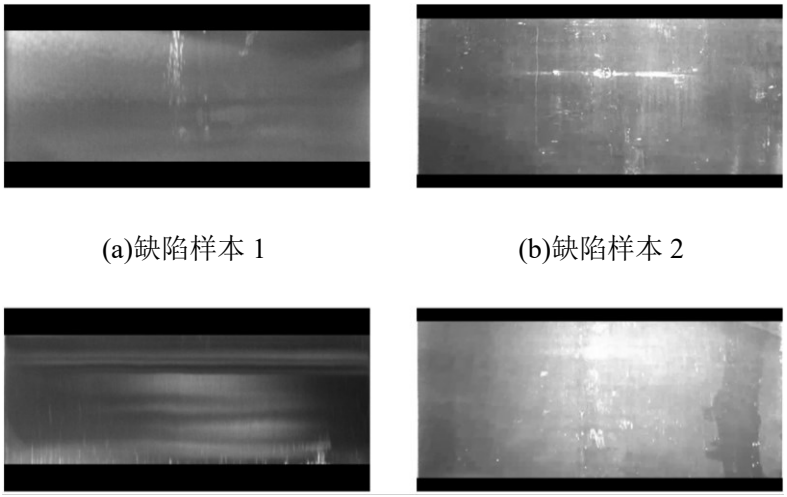
（4）透视畸变校正：采用透视变换原理校正 I_{gauss} / $I_{recovery}$ 中的透视畸变，原始坐标点选择垫板的 4 个顶点(73, 43)、(1132, 28)、(1156, 293)、(51, 297)，目标坐标点选择透视变换后图像的四个边缘点(0, 0)、(w, 0)、(0, h)、(w, h)，透视变换后图像记为 $I_{transform}$；

（4）铜带区域分割：将 $I_{transform}$ 输入 6.1 节建立的铜带区域分割模型中，根据分割结果计算铜带边缘的四个顶点坐标；

（5）输入标准化：为统一数据集中的图像尺寸，设定宽高为 800×400 像素大小的黑色模板，根据铜带边缘的四个顶点坐标，对 $I_{transform}$ 进行裁剪后按原比例缩放，

中国知网　https://www.cnki.net

嵌入到黑色模板并进行图像灰度化后，得到用于后续缺陷检测的标准输入图像，预处理后的图像如图 6-17 所示。



(a)缺陷样本 1　　(b)缺陷样本 2

(c)缺陷样本 3　　(d)缺陷样本 4

图 6-17　预处理后的图像

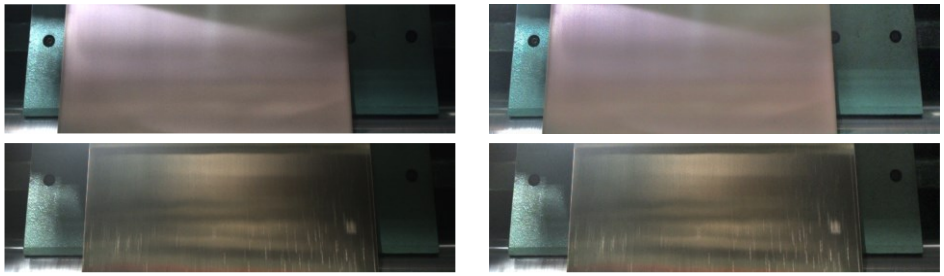
Fig. 6-17　Preprocessed images

6.3.2　模型微调

在深度学习任务中，迁移学习已成为解决小样本场景下模型训练难题的有效手段。其核心思想是利用在大规模数据集或相关任务上预训练得到的模型参数作为基础，通过在新场景下小规模目标数据集上的再训练，使模型快速适配新任务。与从头训练相比，迁移学习能够有效缩短模型收敛时间，降低计算开销，并缓解因数据量有限而导致的过拟合问题。尤其在工业检测场景下，现场数据采集与标注代价高昂，迁移学习为深度学习模型的工程化部署提供了可行路径。

（1）由于工业现场难以采集到严格配对的“退化-清晰”图像，我们为光照校正模型的微调设计了一种基于专家知识的半人工标注策略。该策略从新产线采集少量具有代表性的非均匀光照样本，并由专业人员利用图像处理软件，依据统一的光照均衡标准进行手动校正，从而构建一个高质量的小规模配对微调数据集，如图 6-18 所示。基于此数据集，以第 2 章训练的 CSUIC_M 为基础进行监督学习微调，使其能够精准学习并适应新产线特有的光照模式。通过迁移学习得到的适用于新场景下的铜带表面非均匀光照校正模型记为 CSUIC_M1。

中国知网　https://www.cnki.net

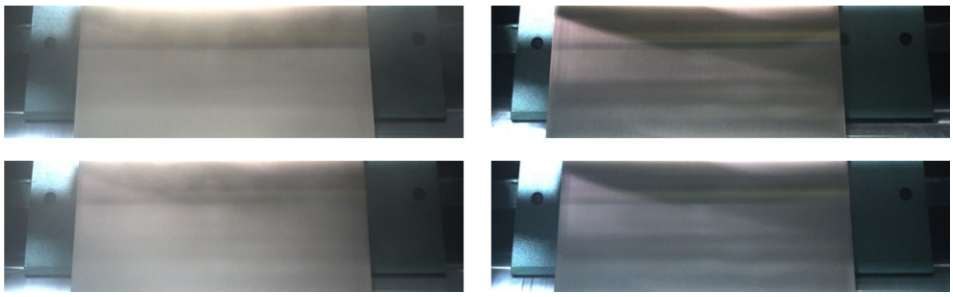


(a)原始图像　　(b)校正图像

图 6-18　新场景下的非均匀光照数据集

Fig. 6-18　Non-uniform illumination dataset under new scenes

（2）由于第 3 章所采用的去雾框架是基于弱监督学习范式的，因此，去雾模型的微调无需严格的配对数据。我们仅需从新产线采集一批典型的有雾图像和一批清晰图像，如图 6-19 所示。以第 3 章训练好的 CSDH_M 为预训练模型，利用其内在的重建损失函数进行自监督微调，使其能够让模型自主学习到新产线雾气的特定物理特性，通过迁移学习得到的适用于新场景下的铜带表面去雾模型记为 CSDH_M1。



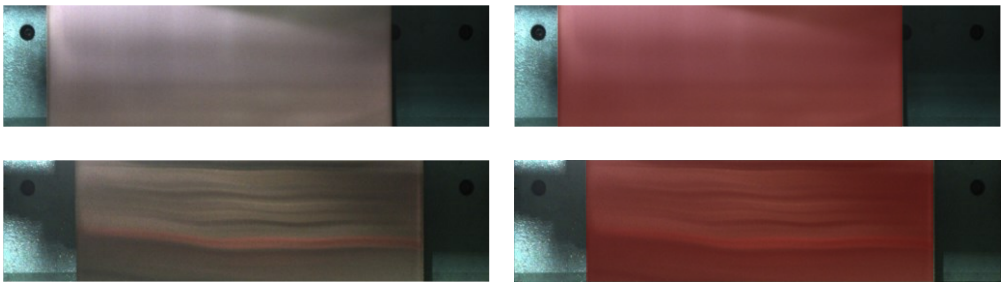
(a)有雾气图像　　(b)清晰图像

图 6-19　新场景下的雾气干扰数据集

Fig. 6-19　Haze interference dataset in new scenes

（3）针对铜带区域分割模型，考虑到原有模型在新场景下可能出现区域边界偏移或分割不完整等问题。为此，在新产线采集了一批具有代表性的铜带表面图像样本，采用人工标注方法构建了新场景下的铜带区域分割微调数据集，如图 6-20 所示。为保证样本的多样性与泛化性，数据集中同时包含不同带宽与跑偏位置的图像样本。以 6.1 节训练完成的 CSRS_M 模型作为预训练模型，采用迁移学习策略进行微调训练。通过此迁移学习过程得到的、专门针对目标工业场景优化的铜带区域分割模型记为 CSRS_M1。

中国知网　https://www.cnki.net



(a)图像数据　　(b)标签数据

图 6-20　新场景下的铜带区域分割数据集

Fig. 6-20　Copper strip region segmentation dataset in new scenes

（4）针对缺陷检测模型，首先构建新场景下的表面缺陷检测数据集。本文从 6.3.1 节预处理后的图像中筛选出三类对产品外观、性能以及后续加工影响显著的关键缺陷（黑线 BL，划痕 Sc 和起皮 Pe）。对筛选出的各类缺陷样本通过 Lableimg 工具对缺陷样本进行标注，如图 6-21 所示，并按 8:1:1 的比例划分为训练集 Trainset、验证集 Valset 和测试集 Testset，划分后的数据集分布如表 6-6 所示。

表 6-6　现场采集的铜带表面缺陷数据集

Table 6-6　Copper strip surface defect dataset collected on-site

数据集	样本数量	标注数量			总计
		黑线	划痕	起皮	
Trainset	1299	2160	2259	6406	10825
Valset	162	294	272	862	1428
Testset	163	335	276	864	1475

铜带表面缺陷模型的训练采用一种两阶段式的微调策略。首先，加载第 5 章训练好的 CSSD_M 作为预训练模型。在第一阶段，冻结其提取通用底层特征的主干网络，仅对与特定任务关联更紧密的高层网络及检测头进行训练。此阶段使用相对较大的学习率，旨在让模型快速学习新产线三类核心缺陷的宏观特征。在第二阶段，解冻所有网络层，并采用一个更小的学习率对整个模型进行全局微调，以精细调整所有参数，从而在保留泛化能力的同时，最大化模型在新数据集上的检测性能。通过迁移学习得到的适用于新场景下的表面缺陷检测模型记为 CSSD_M1。

中国知网　https://www.cnki.net

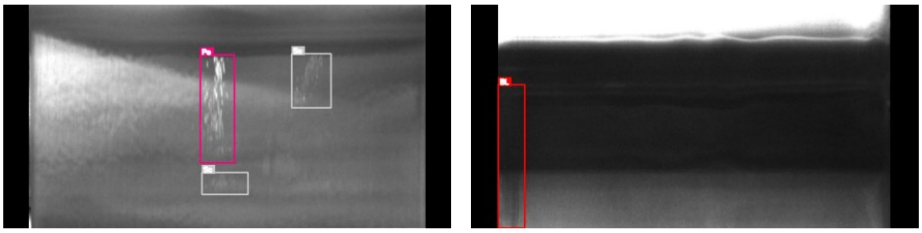


图 6-21　新场景下的铜带表面缺陷数据集

Fig. 6-21　Copper strip surface defect dataset in new scenes

6.3.3　检测结果分析

2.3.3 节和 3.3.3 节表明，本文提出的非均匀光照校正模型 CSUIC_M 在评价指标 PSNR 和 SSIM 上均取得了较好效果。然而，图像复原的最终目的是服务于下游的视觉任务。图 6-22 展示了在未经过图像复原与经过复原处理两种条件下的铜带表面图像及其对应的缺陷检测结果。

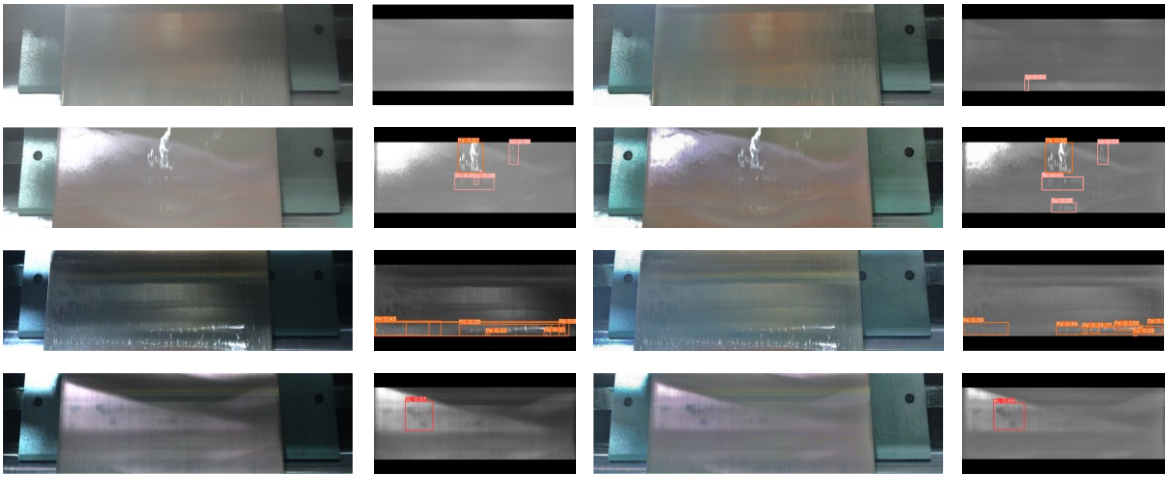


图 6-22　图像复原对铜带表面缺陷检测性能的提升效果

Fig. 6-22　Improvement of copper strip surface defect detection performance via image restoration

第一列为未经任何复原处理的原始图像，可以看到受非均匀光照与雾气干扰影响，图像整体亮度分布不均、局部区域存在过曝或灰蒙现象，导致表面纹理与缺陷边界模糊。第二列为在此类原始图像上直接使用 CSSD_M1 模型的检测结果，可见部分细微缺陷出现漏检或置信度偏低的情况，模型难以稳定识别被低对比度区域掩盖的缺陷。第三列为经非均匀光照校正模型（CSUIC_M1）与去雾复原模型（CSDH_M1）联合处理后的图像，亮度分布显著均匀，雾气干扰基本消除，铜带表面纹理细节及缺陷边缘得到良好恢复。第四列为复原后图像的检测结果，模型对多

中国知网　https://www.cnki.net

类缺陷的定位更加准确，部分在原始图像中未被识别的缺陷得到成功检测，且预测框的置信度普遍提高。对比结果表明，经过图像复原预处理后，输入图像的质量提升显著改善了模型的特征提取能力与判别性能，有效减少了漏检与误检现象，验证了光照校正与去雾复原对提高铜带表面缺陷检测精度与稳定性的积极作用。

为了定量评估非均匀光照校正方法和去雾方法对铜带表面缺陷检测任务的实际效果，本节设计了消融实验，以验证两种复原方法对缺陷检测模型精度的影响。实验以统一的缺陷检测模型 CSSD_M1 为评估基准，分别测试其在原始测试集及不同复原条件下的检测精度，结果如表 6-7 所示。从表中数据可见，原始测试集上 CSSD_M1 的 mAP_{50} 为 46.8%，经光照复原后提升至 50.8%，去雾复原后为 47.9%，两者联合复原达到 51.6%。说明光照校正带来的性能提升最显著，去雾复原提升有限，但两者结合效果最佳。分缺陷类型看，划痕的 AP 由 40.4%提升至 46.4%，黑线由 45.8%升至 49.2%，起皮由 54.1%升至 56.8%，其中划痕与黑线对光照不均最敏感。非均匀光照会导致亮度梯度变化，使线状缺陷特征被掩盖，是检测性能下降的主要原因；雾气干扰主要降低对比度和细节清晰度，对大面积起皮影响较小。联合使用光照校正与去雾复原能在亮度一致性和纹理清晰度上互补，使图像质量和检测精度进一步提升，验证了图像复原对下游缺陷检测的显著促进作用。

表 6-7　复原方法对缺陷检测精度的对比结果

Table 6-7　Comparison of defect detection accuracy with different restoration methods

序号	测试集	AP_{Sc}/%	AP_{Pe}/%	AP_{BL}/%	mAP_{50}/%
1	/	40.4	54.1	45.8	46.8
2	光照复原	46.4	56.8	49.2	50.8
3	去雾复原	41.2	54	48.4	47.9
4	光照+去雾复原	47.6	57.1	50.2	51.6

6.3.4　整体检测流程

本文构建的铜带表面缺陷智能检测方法整体流程如图 6-23 所示，主要包括图像采集模块、图像预处理模块、图像分析与识别模块三个阶段，形成从图像获取、成像质量增强到智能识别的全流程闭环。

中国知网　https://www.cnki.net

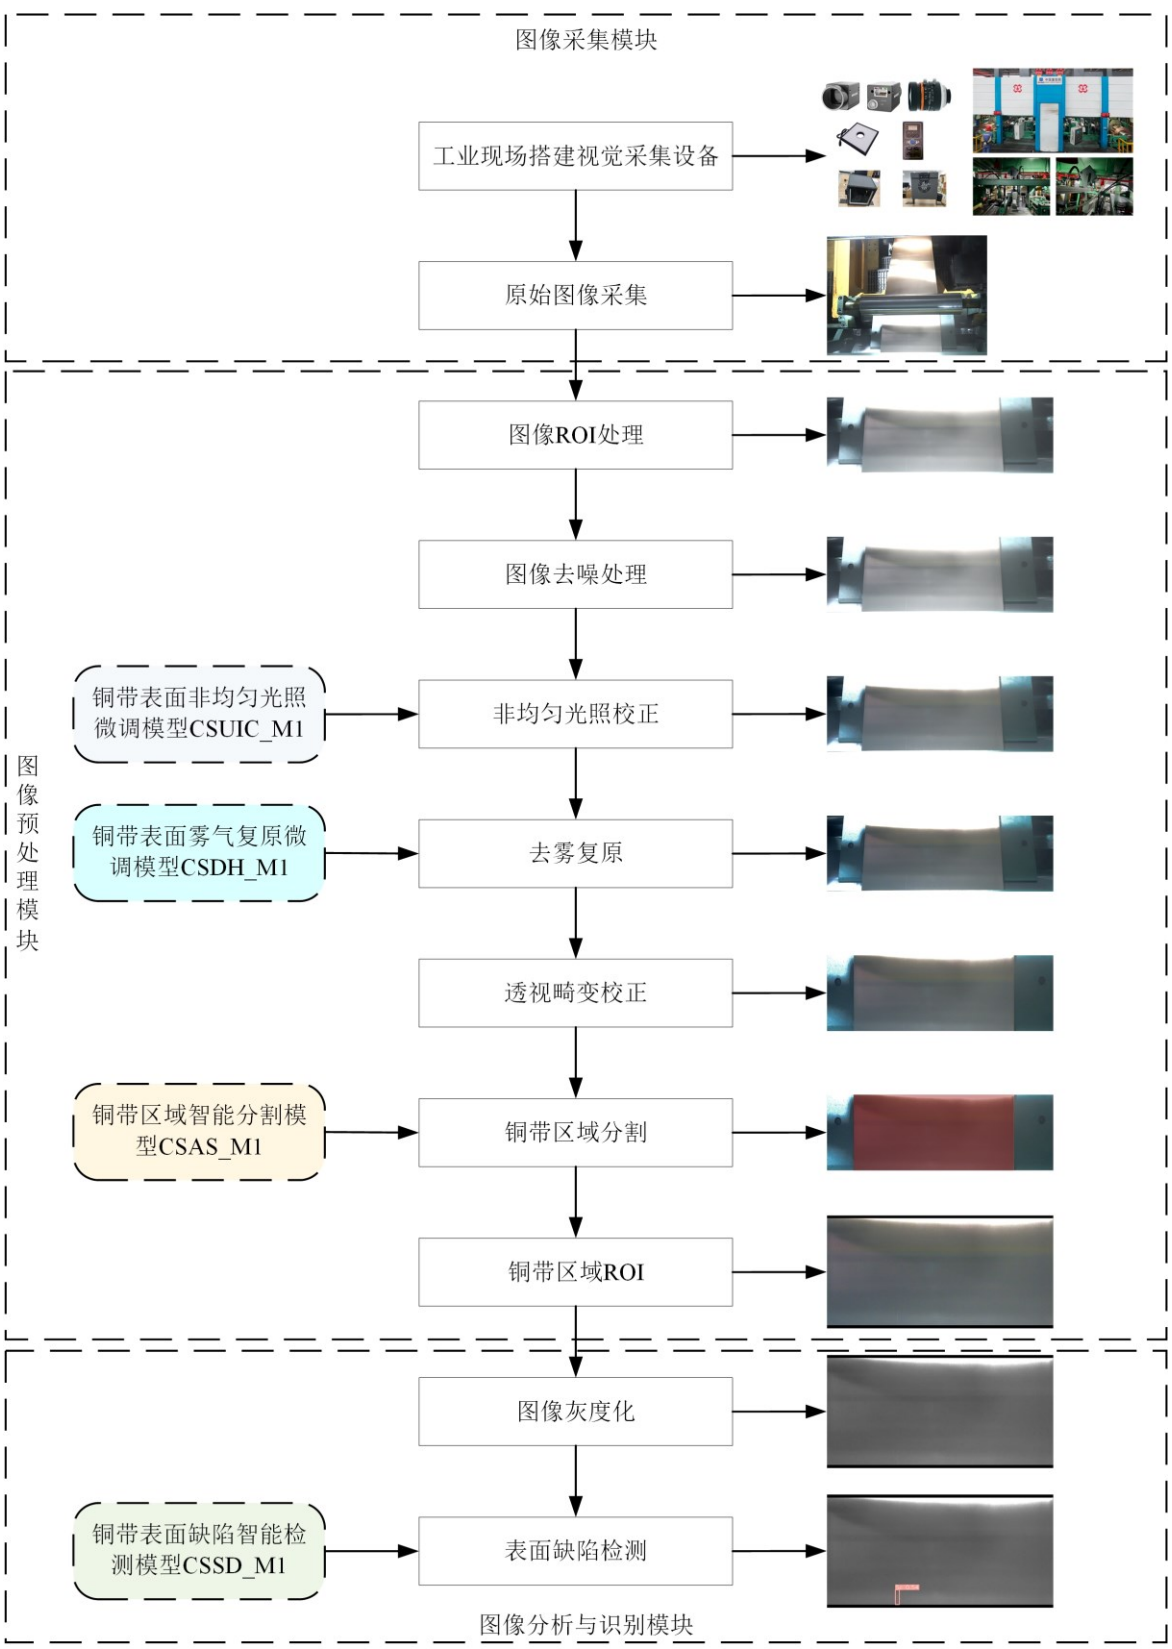


图 6-23　整体检测流程图

Fig. 6-23　Overall detection flowchart

中国知网　https://www.cnki.net

图像采集模块是整个检测系统的起点。在工业生产现场，首先利用预先搭建好的机器视觉采集设备，包括配置合适的工业相机、镜头以及 LED 照明系统，对运行中的铜带表面进行实时、连续的图像数据采集，为后续处理提供基础数据输入。

采集到的原始图像随后进入图像预处理模块，该模块整合了多项关键技术，旨在消除环境干扰、增强有效信息，并标准化输入数据。首先，原始图像首先经过 ROI 裁剪，剔除无关背景区域，初步聚焦于包含铜带的关键区域，以提高后续处理效率。接着，应用高斯滤波器进行图像去噪，有效抑制采集和传输过程中引入的高频噪声。针对现场复杂的光照与雾气干扰，依次调用经迁移学习微调的非均匀光照校正模型 CSUIC_M1 与雾气复原模型 CSDH_M1。前者对图像进行非均匀光照校正，恢复因光照不均导致的局部过曝或欠曝问题；后者对校正后的图像进行去雾操作，提升在雾气干扰下的图像对比度与细节清晰度。

图像复原之后，采用透视变换对图像进行几何校正，消除因相机安装角度引起的透视畸变。为彻底分离铜带与背景，引入了同样经过微调的铜带区域智能分割模型 CSAS_M1，该模型能像素级精确地分割出铜带区域。利用分割得到的掩模边界信息，执行最终的铜带区域 ROI 提取，确保后续分析仅针对有效区域，降低了背景干扰对缺陷检测的影响。最后，将复原后的图像进行灰度化处理，得到高质量的单通道输入，为缺陷识别提供稳定输入数据。

最后，在图像分析与识别模块中，经过全面预处理的高质量灰度图像被输入到核心的铜带表面缺陷智能检测模型 CSSD_M1。该模型利用深度学习算法对输入的图像进行分析，自动识别其中是否存在表面缺陷，并输出缺陷的具体类别、位置（通常为边界框坐标）以及相应的置信度分数。整个系统实现了从图像采集、复原校正、区域分割到缺陷检测的全流程自动化处理，具备较高的检测精度与实时性，可在工业生产现场稳定运行，为铜带表面质量智能监测提供可靠的技术支撑。

6.4 人机交互界面开发与应用效果

6.4.1 系统架构

在表面缺陷检测系统的总体设计中，整个软件被划分为六个逻辑层次，由下至上分别形成数据流动的链条。整个分层架构将输入、采集、处理、建模、输出与应用有机衔接，既保证了实时性和准确性，也为后续的模型迭代与数据驱动的工艺优

中国知网 https://www.cnki.net

化提供了支撑，整体系统架构如图 6-24 所示。

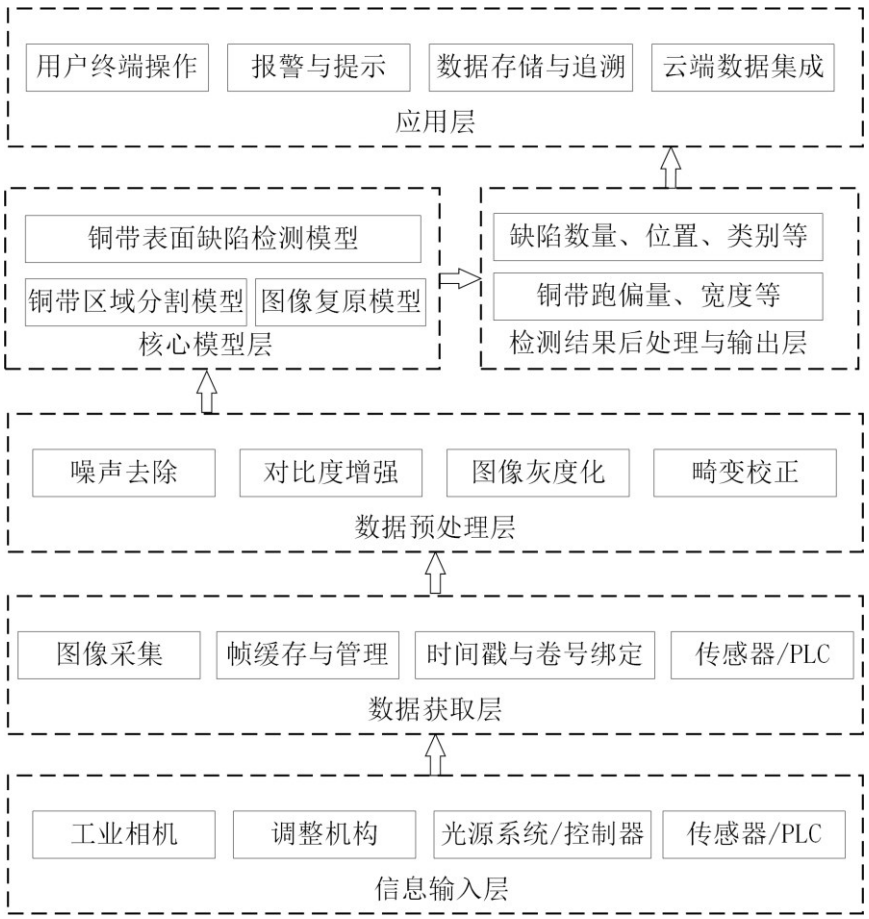


图 6-24　系统架构

Fig. 6-24　System architecture

最底层是信息输入层，它作为系统的数据源，主要包括工业相机、光源控制器、编码器或 PLC、传感器以及调整机构。工业相机保证高分辨率和低畸变成像，光源控制器则调节照明条件以凸显缺陷，编码器与 PLC 提供运动同步信息，传感器采集环境与工艺变量，而调整机构则确保成像稳定性和可重复性。其上为数据获取层，该层通过外部触发和同步机制采集图像，并结合帧缓存与管理方法保证数据传输的稳定性，同时将时间戳和卷号等生产信息绑定在图像帧中，从而实现可追溯的数据接口。

在此基础上，数据处理层对原始图像进行质量增强与异常剔除。其内容包括畸变校正与平场/暗场校正以消除成像偏差，去噪与对比度增强以提升缺陷可见性，灰度化或多通道融合以适应不同检测需求，以及通过统计特征剔除过暗或过曝等异常

中国知网　https://www.cnki.net

帧。核心模型层是系统的智能核心，涵盖了缺陷检测模型、可选的缺陷分割模型、缺陷分类模型以及判级与规则引擎。检测模型用于快速定位缺陷，分割模型对复杂形态进行像素级提取，分类模型进一步细分缺陷类型，而判级与规则引擎则结合面积、数量和工艺规则实现严重度分级。核心模型的输出传递至检测结果与数据输出层，该层将缺陷的位置、类型和置信度以结构化数据输出，并生成等级的严重度分级结果，同时自动裁剪保存缺陷区域图像并生成日志和统计报表，支持质量分析与工艺优化。

最上层是应用层，它是系统与用户交互的终端环节，主要功能包括用户操作终端用于结果浏览和复核，实时可视化大屏用于动态展示缺陷分布，报警与提示用于超阈值缺陷的快速反馈，以及数据存储与追溯功能，用于归档检测结果和支持长期的质量管理。

6.4.2 模型部署

本文采用一种轻量化的部署方式，通过在工业计算机上运行深度学习模型，并采用 LabVIEW 软件开发的人机交互界面调用推理结果，实现检测功能的集成。

首先，训练完成的表面缺陷检测模型通常以“.pth”文件格式保存，该格式是 PyTorch 框架下的模型权重文件，记录了网络各层的参数，但在调用时依赖对应的网络结构定义及运行环境，必须在兼容的 PyTorch 框架中加载才能完成推理。为了实现跨平台与跨框架的部署，通常需要将“.pth”文件进一步转换为开放神经网络交换格式（Open Neural Network Exchange, ONNX）。ONNX 作为一种中间表示，能够在保持模型结构与权重一致性的同时，脱离特定深度学习框架的限制，使模型可以在多种推理引擎上运行。随后，将 ONNX 模型转换为 TensorRT 引擎文件。TensorRT 是 NVIDIA 推出的深度学习推理优化工具，能够针对 GPU 进行算子融合、低精度计算（如 FP16、INT8）和内存优化，从而显著降低推理时延、提高吞吐率。

在实际运行过程中，工业计算机内的 Python 程序会加载由 ONNX 生成的 TensorRT 文件，并通过调用相应的 Python API 依次完成图像的预处理、模型推理以及结果的后处理。为了将推理功能嵌入 LabVIEW 构建的人机交互界面，本文采用 Python Node 节点。Python Node 是 LabVIEW 提供的功能模块，可以直接调用本地 Python 脚本或函数。通过这种方式，LabVIEW 界面将图像数据传入 Python 脚本，调用 TensorRT 完成缺陷检测，并接收结构化的检测结果，再在界面中进行可视化展示

中国知网 https://www.cnki.net

和报警提示。

这种轻量化方案具有开发周期短、灵活性高的优点。研究人员无需复杂的 C++ 编译或服务化部署，就能快速将训练好的模型集成到工业现场的检测系统中。同时，由于 ONNX 和 TensorRT 提供了跨框架与性能优化支持，未来系统若需进一步扩展至更高性能的部署方式，也能在保持接口不变的情况下平滑升级。因此，该方案为模型从实验室向工业现场的迁移提供了一种简洁、直观且可扩展的路径。

6.4.3　人机交互界面与应用效果

铜带表面缺陷检测系统的现场安装情况如图 6-25 所示。



图 6-25　现场安装情况

Fig. 6-25　On-site installation

本文开发的铜带表面缺陷检测系统人机交互界面，主要包括表面缺陷检测、跑偏量辅助检测、离线检测、系统参数检测与图像预处理设置等模块。其中，图 6-26 为表面缺陷检测界面，左侧下方两个显示控件分别显示实时预处理后的铜带表面图像以及经智能模型得到的检测结果。左侧上方 XY 图直观展示检测出的缺陷位置，X 轴代表铜带长度方向，Y 轴代表铜带宽度方向。右侧上方为从轧机主控系统获取的一些基本轧制信息以及缺陷检出次数。右侧下方表格记录了缺陷检测时间、类型以及位置信息。图 6-27 为铜带跑偏量辅助检测界面，左侧下方两个显示控件分别显示实时预处理后的铜带表面图像以及铜带分割结果。左侧上方两个波形图实时显示检测的铜带跑偏量与铜带宽度。右下角显示跑偏量与铜带宽度具体值，当跑偏量与铜带宽度与预设定偏差较大时会发生报警，指示灯会变成红色。

中国知网　https://www.cnki.net

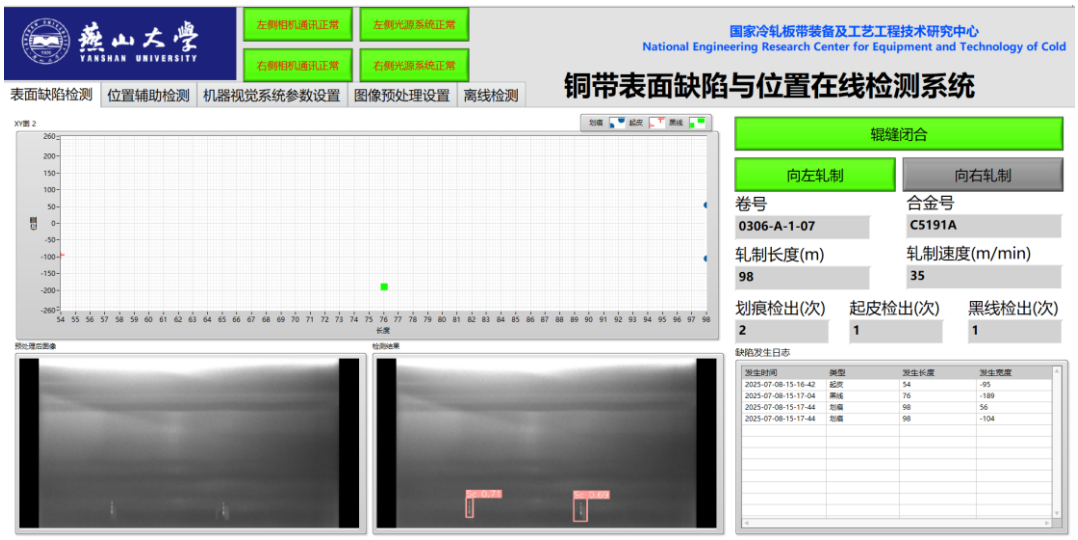


图 6-26　检测系统表面缺陷检测界面

Fig. 6-26　Surface defect detection interface of the detection system

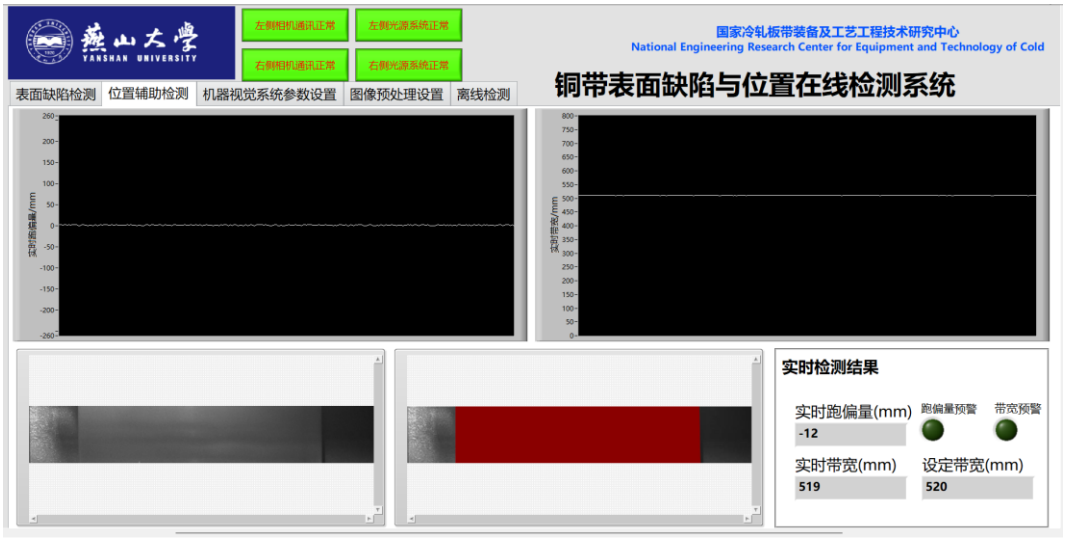


图 6-27　检测系统铜带跑偏量辅助检测界面

Fig. 6-27　Copper strip deviation auxiliary detection interface of the detection system

6.5　本章小结

本章围绕铜带表面缺陷检测的工程化落地，提出并验证了一套从算法到系统的完整实现方案。通过构建透视校正与 Fast-SCNN 轻量化分割网络，建立了高效的铜带区域提取模型 CSRS_M，其 mPA 达到 99.54%、mIoU 为 98.79%，推理速度达 104.3 FPS，可满足工业实时检测需求；基于分割结果设计的边缘位置提取算法实现了跑偏

中国知网　https://www.cnki.net

量的高精度计算，现场验证平均误差仅 1.15 mm。进一步，针对铜带生产线的实际应用需求，从硬件配置、系统架构、模型微调和人机交互界面开发等多个方面展开了系统设计。在硬件层面，结合复杂工况下的成像特征，构建了相机、光源、箱体结构与数据处理单元的集成配置，确保了图像采集的稳定性与鲁棒性。在系统架构层面，设计了从图像采集、预处理、深度学习推理到结果输出的完整流程，实现了高效的端到端检测。针对现场采集的新数据集，采用模型微调策略进行适配，有效提升了模型在特定缺陷类别和复杂工况下的检测性能，并验证了前面所提出的图像复原方法对缺陷检测的有效性。最后，在人机交互环节，利用 LabVIEW 开发了界面系统，将模型推理结果与产线运行参数集成展示，支持实时可视化、报警提示与质量追溯。通过上述设计，本章提出了一套从实验室研究到工业现场落地的基于机器视觉的铜带表面缺陷检测应用方案，为后续的生产实践与推广应用提供了技术支撑。

中国知网　https://www.cnki.net

第 7 章　结论

本文以铜带表面缺陷的智能检测为研究对象，围绕工业应用中存在的缺陷样本稀缺、成像环境复杂、检测算法实时性不足以及生产过程综合监控困难等关键挑战，开展了系统性的理论研究与技术攻关。本文以深度学习理论与机器视觉技术为基础，完成了从多源数据构建、复杂环境图像复原、轻量化缺陷检测、铜材区域智能分割、跑偏量辅助检测到工业化系统集成与验证的全链路研究，取得了一系列创新性成果，为提升我国冷轧铜带产业的智能化水平提供了有效的技术方案与实践经验。

本文主要结论如下：

（1）非均匀光照复原方法能够有效改善铜带表面成像亮度不均与细节丢失问题。基于 Retinex 模型提出非均匀光照合成方法，构建覆盖多种模式的退化数据集，采用 Laplacian 金字塔分解的非均匀光照校正框架训练复原模型。实验表明，该方法在测试集上的 PSNR 和 SSIM 指标上分别达到了 23.47 和 0.93，在复原性能方面优于其它方法。

（2）雾气复原方法能够显著降低雾气干扰。基于大气散射模型构建不同程度雾气退化数据集。采用 RefineDNet 两阶段去雾框架训练铜带表面雾气复原模型。实验结果显示，该方法在测试集上的 PSNR 和 SSIM 指标分别达到了 24.3 和 0.82，复原图像颜色自然，细节清晰。

（3）多源数据融合策略能够有效缓解样本规模小、类间分布不均衡的问题。以少量真实样本为基础利用 DDPM 可生成高质量缺陷样本，相较于原始数据集，融合真实样本、标准增强样本和 mixup 样本得到的多源数据集的训练样本规模提高了 8.8 倍，最大类间样本数量差距也由原来的 15.4%降低至 2.8%。

（4）提出的轻量化表面缺陷检测网络在保证高精度的同时实现了推理速度的大幅提升。提出了高效基本卷积算子 APConv，结合结构残差结构和 EMA 机制构建了高效多尺度特征提取网络 EAPRNet。基于改进网络训练的表面缺陷检测模型 mAP_{50} 达到了 90.3%，FPS 达到了 52.4。

（5）铜带区域智能分割与跑偏量辅助检测方法能够快速准确分割铜带区域并获取跑偏量信息。基于冷轧现场采集的生产数据构建了铜带区域分割数据集，采用 Fast-SCNN 网络建立了铜带区域快速分割模型，该模型能够以 104.3 的 FPS 实现

中国知网　https://www.cnki.net

99.54%的 mPA 和 98.79%的 mIoU。进一步设计了边缘提取算法实时计算跑偏与宽度信息，通过与现场的真实跑偏值对比，65.88%的样本绝对误差在±1 mm 之间，99.36%的样本绝对误差在±2 mm 之间，且平均绝对误差仅为 1.15 mm。

本文创新点如下：

（1）提出了面向复杂工业环境的非均匀光照与雾气退化图像合成及复原方法。针对非均匀光照现象，基于 Retinex 成像理论提出了非均匀光照退化图像合成方法构建了包含四种退化模式的非均匀光照数据集。在此基础上，引入基于 Laplacian 金字塔分解的多尺度光照校正框架，实现了由低频到高频的逐层亮度均衡与细节增强。针对雾气干扰问题，基于大气散射模型提出了雾气退化图像合成方法并构建了不同程度雾气退化图像数据集。进一步，采用两阶段弱监督去雾框架，通过粗复原与细节增强的协同优化，有效恢复了铜带表面的纹理结构与缺陷特征。

（2）提出了一种面向工业小样本场景的多源数据融合策略。将去噪扩散概率模型应用于铜带表面缺陷的生成任务，实现了高质量、多样化的缺陷样本扩充，并在此基础上，建立了融合真实样本、标准增强样本、mixup 增强样本与生成样本的多源数据驱动范式。

（3）构建了端到端高效轻量化目标检测器。通过引入通道注意力对参与卷积的特征通道进行局部自适应加权，提出了一种高效的基本卷积算子 APConv。进一步融合 EMA 注意力机制构建了一种兼顾高精度与高效率的轻量化主干特征提取网络 PResNet。以此为基础对 RT-DETR 进行轻量化改进，为工业场景下的实时高精度检测提供了新的网络架构。

未来展望：

（1）开发基于无监督学习或半监督学习范式的缺陷检测方法。当前，缺陷样本的获取仍然面临稀缺与标注困难的问题，尤其是对于新型缺陷的检测，传统的有监督学习方法可能难以应对。未来探索无监督或半监督学习方法，通过生成模型或对比学习等方式，利用未标注样本进行模型训练，增强模型在新型缺陷检测上的适应能力。

（2）针对检测失败案例进行深入分析与完善。尽管本文提出的模型已在大多数典型缺陷上表现出较高的准确性，但在某些特定情况下仍存在检测失败的情况。未来研究可以通过对检测失败案例的深度分析，查明模型失效的根本原因，例如不充分的样本覆盖、特征不敏感、模型鲁棒性不足等问题。

中国知网　https://www.cnki.net

（3）解决图像复原方法的实时性问题。当前，本文提出的图像复原方法在处理质量上取得了较好的效果，但处理速度仍然略低，尤其是在处理速度和计算资源消耗方面存在瓶颈。未来研究可进一步通过优化算法结构、引入轻量化模型设计，提升复原方法的处理速度，使其能够实时应用于铜带的在线检测过程中。

中国知网 https://www.cnki.net

参考文献

[1] 沈坤荣, 乔刚, 林剑威. 智能制造政策与中国企业高质量发展[J]. 数量经济技术经济研究, 2024, 41(2): 5-25.

[2] 余明桂, 贺蒙蒙, 张萌萌. 人才引进政策、劳动力优化配置与制造业智能化[J]. 中国工业经济, 2024(5): 116-134.

[3] 周济. 智能制造——“中国制造 2025”的主攻方向[J]. 中国机械工程, 2015, 26(17): 2273-2284.

[4] 晓宇. 《中国制造 2025》落地提速五大工程“施工图”出炉[J]. 经济研究参考, 2016(60): 26.

[5] 秦伟, 陈曦. 十大战略产业期待突破——新出炉《中国制造 2025》重点领域技术路线图详解[J]. 装备制造, 2015(11): 36-39.

[6] 臧冀原, 季桓永, 黄庆学. 数智化赋能传统产业转型升级[J]. 中国科学院院刊, 2024, 39(7): 1183-1190.

[7] 王国栋, 张殿华, 孙杰. 建设数据驱动的钢铁材料创新基础设施 加速钢铁行业的数字化转型[J]. 冶金自动化, 2023, 47(1): 2-9.

[8] 王国栋. 科技创新与产业创新深度融合推动我国钢铁工业发展新质生产力[J]. 中国科技产业, 2024(10): 4-6.

[9] 黄庆学. 高品质钢铁板带轧制关键装备与技术研究进展[J]. 机械工程学报, 2023, 59(20): 34-63.

[10] 王国栋. 创建钢铁企业数字化创新基础设施加速钢铁行业数字化转型[J]. 轧钢, 2022, 39(6): 2-11.

[11] 高心成, 刘宏民, 王东城, 等. 冷轧铜带板形控制系统数字孪生研究[J]. 中国有色金属学报, 2024, 34(9): 2978-2988.

[12] 高心成, 刘宏民, 王东城, 等. 铜带冷轧机板形控制分段冷却机理模型[J]. 中国有色金属学报, 2025, 35(6): 2037-2049.

[13] 张文芹, 郑晨飞. 铜及铜合金带材表面质量控制及技术现状[J]. 有色金属材料与工程, 2016, 37(4): 125-131.

[14] 张玉杰. 浅析铜板带材的表面质量控制[J]. 有色金属加工, 2005(5): 27-29, 52.

[15] 周文凤, 黄文荣, 黄姝珂, 等. H62 薄带退火缺陷预防措施[J]. 热加工工艺, 2013, 42(2):

中国知网 https://www.cnki.net

204-206.

[16] 傅红华. 铜带材纵剪缺陷分析及质量控制[J]. 上海有色金属, 2014, 35(4): 150-153.

[17] 陈伟文. 清洗研磨对改善铜板带材表面质量的作用[J]. 上海有色金属, 2015, 36(1): 22-24.

[18] 赵永林, 李阁强. 电子铜带精整工序表面质量缺陷的分析和改进[J]. 有色金属加工, 2015, 44(5): 37-39.

[19] 陈建涛, 钱泽涛. 铜板带材粘结缺陷形成与控制分析[J]. 铜业工程, 2017(6): 7-9.

[20] 田英明, 孙克斌. 铜板带表面质量的影响因素及控制措施[J]. 中国有色金属, 2017(S2): 427-429.

[21] 吴文博, 郑学清, 闫永, 等. H85 黄铜带材表面点状起皮原因分析及对策[J]. 有色金属科学与工程, 2019, 10(3): 75-80.

[22] 赵朗月, 吴一全. 基于机器视觉的表面缺陷检测方法研究进展[J]. 仪器仪表学报, 2022, 43(1): 198-219.

[23] 王争. 频闪仪在带钢表面检测系统的应用[J]. 科技资讯, 2012(6): 106.

[24] 陈薇, 蒋科, 张振忠, 等. 涡流检测技术在金属表面缺陷检测中的应用[J]. 世界有色金属, 2022(11): 160-162.

[25] 吴平川, 路同浚, 王炎. 钢板表面缺陷的无损检测技术与应用[J]. 无损检测, 2000(7): 312-315.

[26] BOUTEILLE P, LEGROS G, WALASZEK H, et al. Non-destructive testing of metallic materials using passive and active infrared thermography[J]. Mechanics and Industry, 2014, 15(4): 313-321.

[27] SHI Y, ZHANG C, LI R, et al. Theory and application of magnetic flux leakage pipeline detection[J]. Sensors, 2015, 15(12): 31036-31055.

[28] SUN Y H, FENG B, LIU S W, et al. A methodology for identifying defects in the magnetic flux leakage method and suggestions for standard specimens[J]. Journal of Nondestructive Evaluation, 2015, 34(3): 20.

[29] EGE Y, CORAMIK M. A new measurement system using magnetic flux leakage method in pipeline inspection[J]. Measurement, 2018, 123: 163-174.

[30] TOMPSETT M F, AMELIO G F, BERTRAM W J, et al. Charge-coupled imaging devices: Experimental results[J]. IEEE Transactions on Electron Devices, 1971, 18(11): 992-996.

[31] FOSSUM E R. CMOS image sensors: Electronic camera-on-a-chip[J]. IEEE transactions on

中国知网 https://www.cnki.net

electron devices, 2002, 44(10): 1689-1698.

[32] 马钦, 唐庚宇, 付尊元, 等. 中国无人驾驶农机技术与机库自动泊机方法研究进展[J]. 农业工程学报, 2025, 41(10): 15-27.

[33] 唐彦嵩, 徐锐豪, 王夙加. 机器视觉在食品无损检测中的应用研究进展[J]. 中国食品学报, 2024, 24(12): 13-27.

[34] CAO Z W, QIN Y, JIA L M, et al. Railway intrusion detection based on machine vision: a survey, challenges, and perspectives[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(7): 6427-6448.

[35] ZHANG L, LI B, SUN X, et al. Intelligent fish feeding based on machine vision: a review[J]. Biosystems Engineering, 2023, 231: 133-164.

[36] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016: 85-102.

[37] QI Y L, YANG Z, SUN W H, et al. A comprehensive overview of image enhancement techniques[J]. Archives of Computational Methods in Engineering, 2022, 29(1): 583-607.

[38] MANAKITSA N, MARASLIDIS G S, MOYSIS L, et al. A review of machine learning and deep learning for object detection, semantic segmentation, and human action recognition in machine and robotic vision[J]. Technologies, 2024, 12(2): 15.

[39] ELASRI M, ELHARROUSS O, AL-MAADEED S, et al. Image generation: a review[J]. Neural Processing Letters, 2022, 54(5): 4609-4646.

[40] JIA Z, ZHANG Z, WANG L, et al. Human image generation: a comprehensive survey[J]. ACM Comput. Surv., 2024, 56(11): 1-39.

[41] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[42] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[C]// Advances in Neural Information Processing Systems, Lake Tahoe: Curran Associates, Inc., 2012: 1097-1105.

[43] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[EB/OL]. (2015-04-10) [2025-07-25]. https://doi.org/10.48550/arXiv.1409.1556.

[44] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[C]// 2015 IEEE Conference on Computer Vision and Pattern Recognition, Boston: IEEE Computer Society, 2015: 1-9.

[45] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition[C]// 2016

中国知网 https://www.cnki.net

IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas: IEEE, 2016: 770-778.

[46] HOWARD A G, ZHU M L, CHEN B, et al. MobileNets: efficient convolutional neural networks for mobile vision applications[EB/OL]. (2017-4-17) [2025-07-16]. https://doi.org/10.48550/arXiv.1704.04861.

[47] SANDLER M, HOWARD A G, ZHU M L, et al. Mobilenetv2: inverted residuals and linear bottlenecks[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City: IEEE, 2018: 4510-4520.

[48] HOWARD A, SANDLER M, CHU G, et al. Searching for mobilenetv3[C]// IEEE/CVF International Conference on Computer Vision, Seoul: IEEE, 2019: 1314-1324.

[49] ZHANG X Y, ZHOU X Y, LIN M X, et al. Shufflenet: an extremely efficient vonvolutional neural network for mobile devices[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2018: 6848-6856.

[50] MA N N, ZHANG X Y, ZHENG H T, et al. Shufflenet v2: practical guidelines for efficient cnn architecture design[C]// European Conference on Computer Vision, Munich: Springer, 2018: 116-131.

[51] TAN M, LE Q. Efficientnet: rethinking model scaling for convolutional neural networks[C]// Proceedings of the 36th International Conference on Machine Learning, Long Beach: PMLR, 2019: 6105-6114.

[52] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: transformers for image recognition at scale[EB/OL]. (2021-06-03) [2025-07-16]. https://doi.org/10.48550/arXiv.2010.11929.

[53] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]// IEEE Conference on Computer Vision and Pattern Recognition, Columbus: IEEE, 2014: 580-587.

[54] GIRSHICK R. Fast r-cnn[C]// 2015 IEEE International Conference on Computer Vision, Santiago: IEEE, 2015: 1440-1448.

[55] REN S, HE K M, GIRSHICK R, et al. Faster r-cnn: towards real-time object detection with region proposal networks[C]// Advances in Neural Information Processing Systems, Montreal: Curran Associates, Inc., 2015: 91-99.

中国知网 https://www.cnki.net

[56] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot multibox detector[C]// European Conference on Computer Vision, Amsterdam: Springer, 2016: 21 37.

[57] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]// IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas: IEEE, 2016: 779 788.

[58] REDMON J, FARHADI A. Yolo9000: better, faster, stronger[C]// IEEE Conference on Computer Vision and Pattern Recognition, Honolulu: IEEE, 2017: 6517 6525.

[59] REDMON J, FARHADI A. Yolov3: an incremental improvement[EB/OL]. (2018-04-08) [2025-07-16]. https://doi.org/10.48550/arXiv.1804.02767.

[60] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. Yolov4: optimal speed and accuracy of object detection[EB/OL]. (2020-04-23) [2025-07-16]. https://doi.org/10.48550/arXiv.2004.10934.

[61] LI C, LI L, JIANG H, et al. Yolov6: a single-stage object detection framework for industrial applications[EB/OL]. (2022-09-07) [2025-07-16]. https://doi.org/10.48550/arXiv.2209.02976.

[62] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. Yolov7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Vancouver: IEEE, 2023: 7464 7475.

[63] WANG C Y, YEH I H, LIAO H Y M. Yolov9: learning what you want to learn using programmable gradient information [C]// European Conference on Computer Vision, Zürich: Springer, 2024: 1 21.

[64] WANG A, CHEN H, LIU L H, et al. Yolov10: real-time end-to-end object detection[EB/OL]. (2024-10-30) [2025-07-16]. https://doi.org/10.48550/arXiv.2405.14458.

[65] TIAN Y J, YE Q X, DOERMANN D. Yolov12: attention-centric real-time object detectors[EB/OL]. (2025-02-31) [2025-07-16]. https://doi.org/10.48550/arXiv.2405.14458.

[66] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]// Proceedings of the IEEE International Conference on Computer Vision, Venice: IEEE, 2017: 2980 2988.

[67] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]// European Conference on Computer Vision, Glasgow: Springer, 2020: 213 229.

[68] ZHANG H, LI F, LIU S, et al. DINO: detr with improved denoising anchor boxes for end-to-end object detection[EB/OL]. (2022-07-11) [2025-07-16]. https://doi.org/10.48550/arXiv.2203.03605.

中国知网 https://www.cnki.net

[69] LONG J, SHELHAMER E, DARRELL T. Fully convolutional networks for semantic segmentation[C]// 2015 IEEE Conference on Computer Vision and Pattern Recognition, Boston: IEEE, 2015: 3431 3440.

[70] RONNEBERGER O, FISCHER P, BROX T. U-net: convolutional networks for biomedical image segmentation[C]// Medical Image Computing and Computer Assisted Intervention, Munich: Springer, 2015: 234 241.

[71] CHEN L C, PAPANDREOU G, KOKKINOS I, et al. Semantic image segmentation with deep convolutional nets and fully connected crfs[EB/OL]. (2016-06-07) [2025-07-16]. https://doi.org/10.48550/arXiv.1412.7062.

[72] HE K M, GKIOXARI G, DOLLAR P, et al. Mask r-cnn[C]// IEEE International Conference on Computer Vision, Venice: IEEE, 2017: 2961 2969.

[73] BOLYA D, ZHOU C, XIAO F, et al. Yolact: real-time instance segmentation[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision, Seoul: IEEE, 2019: 9157 9166.

[74] CHENG B, COLLINS M D, ZHU Y, et al. Panoptic-deeplab: a simple, strong, and fast baseline for bottom-up panoptic segmentation[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle: IEEE, 2020: 12475 12485.

[75] KIRILLOV A, MINTUN E, RAVI N, et al. Segment anything[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision, Paris: IEEE, 2023: 4015-4026.

[76] WEI C, WANG W, YANG W, et al. Deep retinex decomposition for low-light enhancement[EB/OL]. (2018-08-14) [2025-07-16]. https://doi.org/10.48550/arXiv.1808.04560.

[77] GUO C L, LI C Y, GUO J C, et al. Zero-reference deep curve estimation for low-light image enhancement[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle: IEEE, 2020: 1780-1789.

[78] WU W, WENG J, ZHANG P, et al. Uretinex-net: retinex-based deep unfolding network for low-light image enhancement[C]// 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans: IEEE, 2022: 5901-5910.

[79] CAI B, XU X, JIA K, et al. Dehazenet: an end-to-end system for single image haze removal[J]. IEEE Transactions on Image Processing, 2016, 25(11): 5187-5198.

[80] LI B, PENG X, WANG Z, et al. Aod-net: all-in-one dehazing network[C]// 2017 IEEE International Conference on Computer Vision, Venice: IEEE, 2017: 4780-4788.

中国知网 https://www.cnki.net

[81] LIU X, MA Y, SHI Z, et al. Griddehazenet: attention-based multi-scale network for image dehazing[C]// 2019 IEEE/CVF International Conference on Computer Vision, Seoul: IEEE, 2019: 7313-7322.

[82] DONG C, LOY C C, HE K, et al. Image super-resolution using deep convolutional networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(2): 295-307.

[83] LIM B, SON S, KIM H, et al. Enhanced deep residual networks for single image super-resolution[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops, Honolulu: IEEE, 2017: 136-144.

[84] ZHANG Y, LI K, LI K, et al. Image super-resolution using very deep residual channel attention networks[C]// European Conference on Computer Vision, Munich: Springer, 2018: 284-301.

[85] LIANG J, CAO J, SUN G, et al. Swinir: image restoration using swin transformer[C]// 2021 IEEE/CVF International Conference on Computer Vision Workshops, Montreal: IEEE, 2021: 1833-1844.

[86] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786): 504-507.

[87] KINGMA D P, WELLING M. Auto-encoding variational bayes[EB/OL]. (2022-12-10) [2025-07-16]. https://doi.org/10.48550/arXiv.1312.6114.

[88] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]// Advances in Neural Information Processing Systems, Montreal: Curran Associates, Inc., 2014: 2672-2680.

[89] RADFORD A, METZ L, CHINTALA S. Unsupervised representation learning with deep convolutional generative adversarial networks[EB/OL]. (2016-01-07) [2025-07-16]. https://doi.org/10.48550/arXiv.1511.06434.

[90] ZHU J Y, PARK T, ISOLA P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]// 2017 IEEE International Conference on Computer Vision, Venice: IEEE, 2017: 2242-2251.

[91] ISOLA P, ZHU J Y, ZHOU T, et al. Image-to-image translation with conditional adversarial networks[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition, Honolulu: IEEE, 2017: 1125-1134.

[92] KARRAS T, LAINE S, AILA T. A style-based generator architecture for generative adversarial

中国知网 https://www.cnki.net

networks[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach: IEEE, 2019: 4401-4410.

[93] CHOI Y, CHOI M, KIM M, et al. Stargan: unified generative adversarial networks for multi-domain image-to-image translation[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City: IEEE, 2018: 8789-8797.

[94] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[C]// Proceedings of the 34th Conference on Neural Information Processing Systems, Vancouver: Curran Associates, Inc., 2020: 14396-14406.

[95] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]// 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans: IEEE, 2022: 10684-10695.

[96] ZHANG L, RAO A, AGRAWALA M. Adding conditional control to text-to-image diffusion models[C]// IEEE/CVF International Conference on Computer Vision, Paris: IEEE, 2023: 3813-3824.

[97] SURESH B R, FUNDAKOWSKI R A, LEVITT T S, et al. A real-time automated visual inspection system for hot steel slabs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1983, 5(6): 563-572.

[98] PORTER T F, SYLVESTER R A, BOUYOUCAS T W, et al. Automatic strip surface defect detection system[J]. Iron and Steel Engineer, 1988, 65(12): 17-20.

[99] BADGER J C. Automated surface inspection system[J]. Iron and Steel Engineer, 1996, 73(3): 48-51.

[100]RODRICK T J. Software controlled on-line surface inspection[J]. Steel Times International, 1998, 22(3): 30.

[101] CARISETTI C A, FONG T Y, FROMM C. iLearn self-learning defect classifier[J]. Iron and Steel Engineer, 1998, 75(8): 50-53.

[102] 胡亮, 段发阶, 丁克勤, 等. 钢板表面缺陷计算机视觉在线检测系统的研制[J]. 钢铁, 2005(2): 59-61.

[103] 胡亮, 段发阶, 丁克勤, 等. 带钢表面缺陷计算机视觉在线检测系统的设计[J]. 无损检测, 2003(6): 287-290.

[104] 胡亮,段发阶,丁克勤, 等. 基于线阵 CCD 钢板表面缺陷在线检测系统的研究[J]. 计量学报,

中国知网 https://www.cnki.net

2005(3): 200-203.

[105] 徐科,徐金梧,陈雨来. 冷轧带钢表面缺陷在线监测系统[J]. 北京科技大学学报, 2002(3): 329-332.

[106] 徐科, 杨朝霖, 周鹏. 热轧带钢表面缺陷在线检测的方法与工业应用[J]. 机械工程学报, 2009, 45(4): 111-114, 124.

[107] 徐科, 杨朝霖, 周鹏, 等. 基于线型激光的连铸板坯表面裂纹在线检测技术[J]. 北京科技大学学报, 2009, 31(12): 1620-1624.

[108] 何永辉, 黄胜标, 石桂芬, 等. 冷轧带钢表面缺陷在线检测系统应用研究[C]// 2007 中国钢铁年会论文集. 成都: 冶金工业出版社, 2007: 913-914.

[109] 何永辉. 宝钢带钢表面检测技术研发与应用[C]// 2010 钢材质量控制技术、形状、尺寸精度、表面质量控制与改善学术研讨会文集. 北京, 2010: 170-178.

[110] 罗新斌. 机器视觉带材表面缺陷检测关键技术研究[D]. 上海: 上海交通大学, 2020: 20-86.

[111] LANDSTROM A, THURLEY M J. Morphology-based crack detection for steel slabs[J]. IEEE Journal of Selected Topics in Signal Processing, 2012, 6(7): 866-875.

[112] RYU S G, CHOI D C, JEON Y J, et al. Detection of scarfing faults on the edges of slabs[J]. ISIJ International, 2014, 54(1): 112-118.

[113] BULNES F G, GARCÍA D F, CALLE F D L, et al. A non-invasive technique for online defect detection on steel strip surfaces[J]. Journal of Nondestructive Evaluation, 2016, 35(4): 54.

[114] WANG Y L, XIA H B, YUAN X F, et al. Distributed defect recognition on steel surfaces using an improved random forest algorithm with optimal multi-feature-set fusion[J]. Multimedia Tools and Applications, 2018, 77(13): 16741-16770.

[115] TANG B, KONG J Y, WANG X D, et al. Surface inspection system of steel strip based on machine vision[C]//2009 First International Workshop on Database Technology and Applications, Wuhan: IEEE, 2009: 359-362.

[116] GONG R, WU C, CHU M. Steel surface defect classification using multiple hyper-spheres support vector machine with additional information[J]. Chemometrics and Intelligent Laboratory Systems, 2018, 172: 109-117.

[117] CHEN Y J, CHEN L, LIU X M, et al. Real-time steel inspection system based on support vector machine and multiple kernel learning[C]// Practical Applications of Intelligent Systems, Advances in Intelligent and Soft Computing, Berlin: Springer, 2011: 185-190.

中国知网 https://www.cnki.net

[118] 管声启, 王燕妮, 师红宇. 基于图像预处理的神经网络带钢缺陷检测[J]. 钢铁研究, 2013, 41(1): 22-26.

[119] RICCI M, FICOLA A, FRAVOLINI M L, et al. Magnetic imaging and machine vision ndt for the on-line inspection of stainless steel strips[J]. Measurement Science and Technology, 2012, 24(2): 025401.

[120] LI X, TSO S K, GUAN X P, et al. Improving automatic detection of defects in castings by applying wavelet technique[J]. IEEE Transactions on Industrial Electronics, 2006, 53(6): 1927-1934.

[121] 葛宵烨, 郭英军, 孙梓钧, 等. 冷轧带钢表面缺陷图像预处理研究[J]. 河北科技大学学报, 2016, 37(3): 262-267.

[122] WU X Y, XU K, XU J W. Application of undecimated wavelet transform to surface defect detection of hot rolled steel plates[C]// 2008 Congress on Image and Signal Processing, Sanya: IEEE, 2008: 528-532.

[123] MEDINA R, GAYUBO F, GONZÁLEZ-RODRIGO L M, et al. Automated visual classification of frequent defects in flat steel coils[J]. The International Journal of Advanced Manufacturing Technology, 2011, 57(9): 1087-1097.

[124] CHOI D C, JEON Y J, LEE S J, et al. Algorithm for detecting seam cracks in steel plates using a Gabor filter combination method[J]. Applied Optics, 2014, 53(22): 4865-4872.

[125] YAZDCHI M, YAZDI M, MAHYARI A G. Steel surface defect detection using texture segmentation based on multifractal dimension[C]// 2009 International Conference on Digital Image Processing, Bangkok: IEEE, 2009: 346-350.

[126] ZHAO J, YANG Y M, LI G. The cold rolling strip surface defect on-line inspection system based on machine vision[C]// 2010 Second Pacific-Asia Conference on Circuits, Communications and System, Beijing: IEEE, 2010: 402-405.

[127] HU H, LIU Y, LIU M, et al. Surface defect classification in large-scale strip steel image collection via hybrid chromosome genetic algorithm[J]. Neurocomputing, 2016, 181: 86-95.

[128] YAZDCHI M R, MAHYARI A G, NAZERI A. Detection and classification of surface defects of cold rolling mill steel using morphology and neural network[C]// 2008 International Conference on Computational Intelligence for Modelling Control & Automation, Hong Kong, China: IEEE, 2008: 1071-1076.

中国知网 https://www.cnki.net

[129] WIN M, BUSHROA A R, HASSAN M A, et al. A contrast adjustment thresholding method for surface defect detection based on mesoscopy[J]. IEEE Transactions on Industrial Informatics, 2015, 11(3): 642-649.

[130] BORSELLI A, COLLA V, VANNUCCI M, et al. A fuzzy inference system applied to defect detection in flat steel production[C]// 2010 IEEE International Conference on Fuzzy Systems, Barcelona: IEEE, 2010: 1-6.

[131] ZHANG X, KREWET C, KUHLENKÖTTER B. Automatic classification of defects on the product surface in grinding and polishing[J]. International Journal of Machine Tools and Manufacture, 2006, 46(1): 59-69.

[132] ZHANG X, LI W, XI J, et al. Surface defect target identification on copper strip based on adaptive genetic algorithm and feature saliency[J]. Mathematical Problems in Engineering, 2013, 2013(1): 504895.

[133] XIAO M, JIANG M, LI G, et al. An evolutionary classifier for steel surface defects with small sample set[J]. EURASIP Journal on Image and Video Processing, 2017, 2017(1): 48.

[134] MASCI J, MEIER U, CIRESAN D, et al. Steel defect classification with Max-Pooling Convolutional Neural Networks[C]//The 2012 International Joint Conference on Neural Networks (IJCNN). 2012: 1-6.

[135] DONGYAN C, KEWEN X, ASLAM N, et al. Defect Classification Recognition on Strip Steel Surface Using Second-Order Cone Programming-Relevance Vector Machine Algorithm[J]. Journal of Computational and Theoretical Nanoscience, 2016, 13(9): 6141-6148.

[136] AI Y H, XU K. Surface detection of continuous casting slabs based on curvelet transform and kernel locality preserving projections[J]. Journal of Iron and Steel Research International, 2013, 20(5): 80-86.

[137] XU K, AI Y H, WU X Y. Application of multi-scale feature extraction to surface defect classification of hot-rolled steels[J]. International Journal of Minerals, Metallurgy, and Materials, 2013, 20(1): 37-41.

[138] PERNKOPF F. Detection of surface defects on raw steel blocks using Bayesian network classifiers[J]. Pattern Analysis and Applications, 2004, 7(3): 333-342.

[139] ASHOUR M W, KHALID F, ABDUL HALIN A, et al. Surface defects classification of hot-rolled steel strips using multi-directional shearlet features[J]. Arabian Journal for Science and

中国知网 https://www.cnki.net

Engineering, 2019, 44(4): 2925-2932.

[140] LIU X, XU K, ZHOU P, et al. Surface defect identification of aluminium strips with non-subsampled shearlet transform[J]. Optics and Lasers in Engineering, 2020, 127: 105986.

[141] XU K, LIU S, AI Y. Application of Shearlet transform to classification of surface defects for metals[J]. Image and Vision Computing, 2015, 35: 23-30.

[142] SONG K, HU S, YAN Y. Automatic recognition of surface defects on hot-rolled steel strip using scattering convolution Network[J]. Journal of Computer Information Systems, 2014, 10(7): 3049-3055.

[143] HE Y, SONG K, MENG Q, et al. An end-to-end steel surface defect detection approach via fusing multiple hierarchical features[J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(4): 1493-1504.

[144] 王延舒, 余建波. 基于自适应全局定位算法的带钢表面缺陷检测[J]. 自动化学报, 2024, 50(8): 1550-1564.

[145] MA Z, LI Y, HUANG M, et al. A lightweight detector based on attention mechanism for aluminum strip surface defect detection[J]. Computers in Industry, 2022, 136: 103585.

[146] CHEN S, JIANG S, WANG X, et al. An efficient detector for detecting surface defects on cold-rolled steel strips[J]. Engineering Applications of Artificial Intelligence, 2024, 138: 109325.

[147] 杨春龙, 吕东澔, 张勇, 等. 联合元素乘法算子与通道剪枝的钢材表面缺陷检测网络[J]. 计算机工程与应用, 2024, 1-15.

[148] ZHANG G, LIU S, NIE S, et al. YOLO-RDP: lightweight steel defect detection through improved yolov7-tiny and model pruning[J]. Symmetry, 2024, 16(4): 458.

[149] LIU J, LI H, ZUO F, et al. KD-lightnet: a lightweight network based on knowledge distillation for industrial defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-13.

[150] LIU C, YANG Q, MA S, et al. A lightweight dual-stream enhanced network with multilevel feature guidance and hybrid knowledge distillation for steel surface defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2025, 74: 1-13.

[151] LUO Q, SUN Y, LI P, et al. Generalized completed local binary patterns for time-efficient steel surface defect classification[J]. IEEE Transactions on Instrumentation and Measurement, 2019, 68(3): 667-679.

中国知网 https://www.cnki.net

[152] LUO Q, FANG X, SUN Y, et al. Surface defect classification for hot-rolled steel strips by selectively dominant local binary patterns[J]. IEEE Access, 2019, 7: 23488-23499.

[153] LECHWAR S, RAUCH Ł, PIETRZYK M. Use of artificial intelligence in classification of mill scale defects[J]. Steel Research International, 2015, 86(3): 266-277.

[154] ZHANG T, XIA D, TANG H, et al. Classification of steel samples by laser-induced breakdown spectroscopy and random forest[J]. Chemometrics and Intelligent Laboratory Systems, 2016, 157: 196-201.

[155] 徐扬欢, 王东城, 刘宏民, 等. 冷轧铜带表面缺陷智能识别方法[J]. 中国有色金属学报, 2022, 32(10): 2950-2964.

[156] XU Y, WANG D, DUAN B, et al. Copper strip surface defect detection model based on deep convolutional neural network[J]. Applied Sciences, 2021, 11(19): 8945.

[157] WANG D, XU Y, DUAN B, et al. Intelligent recognition model of hot rolling strip edge defects based on deep learning[J]. Metals, 2021, 11(2): 223.

[158] ZHU W, ZHANG H, ZHANG C, et al. Surface defect detection and classification of steel using an efficient Swin Transformer[J]. Advanced Engineering Informatics, 2023, 57: 102061.

[159] MAO H, GONG Y. Steel surface defect detection based on the lightweight improved RT-DETR algorithm[J]. Journal of Real-Time Image Processing, 2024, 22(1): 28.

[160] ZHOU S, CAI Y, ZHANG Z, et al. MESC-DETR: an improved rt-detr algorithm for steel surface defect detection[J]. Electronics, 2025, 14(11): 2232.

[161] GAO Y, GAO L, LI X, et al. A semi-supervised convolutional neural network-based method for steel surface defect recognition[J]. Robotics and Computer-Integrated Manufacturing, 2020, 61: 101825.

[162] DI H, KE X, PENG Z, et al. Surface defect classification of steels with a new semi-supervised learning method[J]. Optics and Lasers in Engineering, 2019, 117: 40-48.

[163] COHN R, HOLM E. Unsupervised machine learning via transfer learning and k-means clustering to classify materials image data[J]. Integrating Materials and Manufacturing Innovation, 2021, 10(2): 231-244.

[164] LIU K, WANG H, CHEN H, et al. Steel surface defect detection using a new haar–weibull-variance model in unsupervised manner[J]. IEEE Transactions on Instrumentation and Measurement, 2017, 66(10): 2585-2596.

中国知网 https://www.cnki.net

[165] YU R, LIU Y, YANG R, et al. VQGNet: An unsupervised defect detection approach for complex textured steel surfaces[J]. Sensors, 2024, 24(19): 6252.

[166] LV X, DUAN F, JIANG J J, et al. Deep metallic surface defect detection: the new benchmark and detection network[J]. Sensors, 2020, 20(6): 1562.

[167] BOIKOV A, PAYOR V, SAVELEV R, et al. Synthetic data generation for steel defect detection and classification using deep learning[J]. Symmetry, 2021, 13(7): 1176.

[168] FENG X, GAO X, LUO L. X-SDD: a new benchmark for hot rolled steel strip surface defects detection[J]. Symmetry, 2021, 13(4): 706.

[169] 赵鹤. 基于视觉注意力机制的金属表面缺陷图像分割算法研究[D]. 昆明理工大学, 2022.

[170] 孟繁明. 基于 ARM 和 DSP 的铜带缺陷在线检测系统研发[D]. 中国计量大学, 2021.

[171] LAND E H, MCCANN J J. Lightness and retinex theory[J]. Journal of the Optical Society of America, 1971, 61(1): 1.

[172] JOBSON D J, RAHMAN Z, WOODELL G A. Properties and performance of a center/surround retinex[J]. IEEE Transactions on Image Processing, 1997, 6(3): 451-462.

[173] JOBSON D J, RAHMAN Z, WOODELL G A. A multiscale retinex for bridging the gap between color images and the human observation of scenes[J]. IEEE Transactions on Image Processing, 1997, 6(7): 965-976.

[174] RAHMAN Z ur, JOBSON D J, WOODELL G A. Retinex processing for automatic image enhancement[J]. Journal of Electronic Imaging, 2004, 13(1): 100-110.

[175]GUO X, LI Y, LING H. LIME: Low-light image enhancement via illumination map estimation[J]. IEEE Transactions on Image Processing, 2017, 26(2): 982-993.

[176] AFIFI M, DERPANIS K G, OMMER B, et al. Learning multi-scale photo exposure correction[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle: IEEE, 2021: 9157-9167.

[177] BURT P J, ADELSON E H. The Laplacian Pyramid as a Compact Image Code[J]. IEEE Transactions on Communications, 1983, 3(4): 532-540.

[178] GATTA C, RIZZI A, MARINI D, et al. ACE: an automatic color equalization algorithm[C] //First European Conference on Colour in Graphics, Imaging, and Vision, Poitiers: Society of Imaging Science and Technology, 2002: 316-320.

[179] CAO G, HUANG L, TIAN H, et al. Contrast enhancement of brightness-distorted images by

中国知网 https://www.cnki.net

improved adaptive gamma correction[J]. Computers and Electrical Engineering, 2018, 66: 569-582.

[180] MACCARTNEY E J. Optics of the atmosphere[M]. New York: John Wiley and Sons, 1976: 55-71.

[181] RANFTL R, LASINGER K, HAFNER D, et al. Towards robust monocular depth estimation: mixing datasets for zero-shot cross-dataset transfer[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(3): 1623-1637.

[182] HE K, SUN J, TANG X. Single image haze removal using dark channel prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33(12): 2341-2353.

[183] ZHU Q, MAI J, SHAO L. A fast single image haze removal algorithm using color Attenuation prior[J]. IEEE Transactions on Image Processing, 2015, 24(11): 3522-3533.

[184] ZHAO S, ZHANG L, SHEN Y, et al. RefineDNet: A weakly supervised refinement framework for single image dehazing[J]. IEEE Transactions on Image Processing, 2021, 30: 3391-3404.

[185] QIN X, WANG Z, BAI Y, et al. FFA-Net: feature fusion attention network for single image dehazing [C] // The Thirty-Fourth AAAI Conference on Artificial Intelligence, New York: AAAI Press, 2020: 11908-11915.

[186] NICHOL A Q, DHARIWAL P. Improved denoising diffusion probabilistic models[C]// Proceedings of the 38th International Conference on Machine Learning, Virtual: PMLR, 2021: 8162-8171.

[187] MITTAL A, SOUNDARARAJAN R, BOVIK A C. Making a “completely blind” image quality analyzer[J]. IEEE Signal Processing Letters, 2013, 20(3): 209-212.

[188] N V, D P, BH M C, et al. Blind image quality evaluation using perception based features[C]// 2015 Twenty First National Conference on Communications, Chennai: IEEE, 2015: 1-6.

[189] SEKAR A, PERUMAL V. SS-GAN based road surface crack region segmentation and forecasting[J]. Engineering Applications of Artificial Intelligence, 2024, 133: 108300.

[190] ZHANG H, CISSE M, DAUPHIN Y N, et al. Mixup: beyond empirical risk minimization[EB/OL]. (2018-04-27) [2025-07-16]. https://doi.org/10.48550/arXiv.1710.09412.

[191] HAN K, WANG Y, TIAN Q, et al. GhostNet: more features from cheap operations[C]// 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle: IEEE, 2020: 1490-1499.

中国知网 https://www.cnki.net

[192] TANG Y, HAN K, GUO J, et al. GhostNetV2: enhance cheap operation with long-range attention[C]// Advances in Neural Information Processing Systems, New Orleans: Curran Associates, Inc., 2022: 2033-2045.

[193] LIU Z, HAO Z, HAN K, et al. GhostNetV3: exploring the training strategies for compact models[EB/OL]. (2024-04-22) [2025-08-22]. https://doi.org/10.48550/arXiv.2404.11202.

[194] CHEN J, KAO S H, HE H, et al. Run, don't walk: chasing higher flops for faster neural networks[C] // 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Vancouver, Canada: IEEE, 2023: 11638-11648.

[195] OUYANG D, HE S, ZHANG G, et al. Efficient multi-scale attention module with cross-spatial learning[C]// 2023 IEEE International Conference on Acoustics, Speech and Signal Processing, Vancouver: IEEE, 2023: 1-5.

[196] LV W, ZHAO Y, XU S, et al. DETRs beat yolos on real-time object detection [C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle: IEEE, 2024: 842-851.

[197] LIASHCHYNSKYI P, LIASHCHYNSKYI P. Grid search, random search, genetic algorithm: a big comparison for NAS[EB/OL]. (2019-12-12) [2025-08-22]. https://doi.org/10.48550/arXiv.1912.06059.

[198] SNOEK J, LAROCHELLE H, ADAMS R P. Practical bayesian optimization of machine learning algorithms[C]// Advances in Neural Information Processing Systems 25, Lake Tahoe: Neural Information Processing Systems Foundation, 2012: 2951-2959.

[199] AKIBA T, SANO S, YANASE T, et al. Optuna: A next-generation hyperparameter optimization framework[C]// Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Anchorage: ACM, 2019: 2623-2631.

[200] LOSHCHILOV I, HUTTER F. SGDR: stochastic gradient descent with warm restarts[EB/OL]. (2017-05-03) [2025-08-22]. https://doi.org/10.48550/arXiv.1608.03983.

[201] PANWAR H, GUPTA P K, SIDDIQUI M K, et al. A deep learning and grad-cam based color visualization approach for fast detection of covid-19 cases using chest x-ray and ct-scan images[J]. Chaos, Solitons and Fractals, 2020, 140: 110190.

[202] TALAAT F M, ZAINELDIN H. An improved fire detection approach based on YOLO-v8 for smart cities[J]. Neural Computing and Applications, 2023, 35(28): 20939-20954.

中国知网 https://www.cnki.net

[203] CHEN K, WANG J Q, PANG J M, et al. MMDetection: open mmlab detection toolbox and benchmark[EB/OL]. (2019-06-17) [2025-08-22]. https://doi.org/10.48550/arXiv.1906.07155.

[204] 罗玉涛, 薛志成. 面向自动驾驶的多任务辅助驾驶策略学习方法[J]. 华南理工大学学报（自然科学版）, 2024, 52(10): 31-40.

[205] 金涛, 王震, 李昭蒂. 基于多尺度注意力 U-Net 的医学肝脏 CT 分割算法[J]. 哈尔滨工程大学学报, 2024: 1-11.

[206] 于营, 王春平, 寇人可, 等. 多时相高分辨率卫星遥感图像语义分割算法[J]. 吉林大学学报（工学版）, 2025, 55(6): 2131-2137.

[207] BADRINARAYANAN V, KENDALL A, CIPOLLA R. SegNet: A deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(12): 2481-2495.

[208] ZHAO H, QI X, SHEN X, et al. ICNet for real-time semantic segmentation on high-resolution images[C]// European Conference on Computer Vision, Munich: Springer, 2018: 418-434.

[209] YU C, WANG J, PENG C, et al. BiSeNet: bilateral segmentation network for real-time semantic segmentation[C]// European Conference on Computer Vision, Munich: Springer, 2018: 334-349.

[210] POUDEL R P K, LIWICKI S, CIPOLLA R. Fast-SCNN: fast semantic segmentation network[EB/OL]. (2019-02-12) [2025-08-22]. https://doi.org/10.48550/arXiv.1902.04502.

[211] ZHAO H, SHI J, QI X, et al. Pyramid scene parsing network[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition, Honolulu: IEEE, 2017: 2881-2890.

[212] WU H, ZHANG J, HUANG K, et al. FastFCN: rethinking dilated convolution in the backbone for semantic segmentation[EB/OL]. (2019-03-28) [2025-08-22]. https://doi.org/10.48550/arXiv.1903.11816.

[213] ZHANG W, PANG J, CHEN K, et al. K-Net: towards unified image segmentation[C]// Advances in Neural Information Processing Systems, Virtual conference: NeurIPS Foundation, 2021: 10326-10338.

[214] CHENG B, MISRA I, SCHWING A G, et al. Masked-attention mask transformer for universal image segmentation[C]// 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans: IEEE Computer Society, 2022: 1280-1289.

[215] PAN H, HONG Y, SUN W, et al. Deep dual-resolution networks for real-time and accurate semantic segmentation of traffic scenes[J]. IEEE Transactions on Intelligent Transportation

中国知网 https://www.cnki.net

Systems, 2023, 24(3): 3448-3460.

[216] XU J, XIONG Z, BHATTACHARYYA S P. PIDNet: A real-time semantic segmentation network inspired by PID controllers[C]// 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Vancouver: IEEE, 2023: 7286-7296.

中国知网 https://www.cnki.net