大连海事大学
DALIAN MARITIME UNIVERSITY

博士学位论文

DOCTOR DISSERTATION

论文题目：基于正则化变分模型的高光谱图像复原和异常检测研究

英文题目：Research on Hyperspectral Image Restoration and Anomaly Detection Based on Regularized Variation Model

作　　者：李 兰

指导教师：宋梅萍

学位类别：工学博士

专业名称：计算机科学与技术

研究方向：高光谱图像处理

2025 年 6 月

中国知网 https://www.cnki.net

博 士 学 位 论 文

基于正则化变分模型的高光谱图像复原和异常检测研究

Research on Hyperspectral Image Restoration and Anomaly Detection Based on Regularized Variation Model

作 者 姓 名：李 兰

学　　号：0120210083

指 导 教 师：宋梅萍 教授

学 科 专 业：计算机科学与技术

学 位 类 别：工学博士

培 养 单 位：信息科学与技术学院

答 辩 时 间：2025 年 6 月 9 日

大连海事大学

Dalian Maritime University

中国知网 https://www.cnki.net

创 新 点 摘 要

1 提出基于局部极值约束总变分模型的高光谱图像非盲去模糊算法。通过分析模糊退化过程对图像像素及固有结构的作用，设计像素级自适应约束机制以自适应处理纹理和强度差异；将模糊图像暗通道先验嵌入总变分框架，构建基于模糊先验的约束总变分模型避免多正则项参数调节，提升图像固有纹理结构复原精度。

2 提出基于全局变分和局部结构低秩稀疏模型的高光谱图像去噪算法。通过深入挖掘数据底层结构特征，定义局部低秩正则项提升复杂纹理区域适应能力，引入相关总变分模型，融合全局变分和局部结构低秩稀疏模型，有效提升图像去噪性能。

3 提出基于反馈式波段组群和变分低秩稀疏模型的高光谱异常目标检测算法。设计波段组检测方案，降低计算量和非目标因素的干扰；联合相关总变分和 $L_{2,1}$ 范数以保持异常信号并噪声抑制；利用波段组之间的一致性和互补性，构建反馈式波段组群异常检测框架以应对先验知识缺乏，减轻光谱差异度信息的丢失，提供更可靠的检测结果。

4 提出基于判别性增量多尺度联合字典的高光谱异常检测算法。构建多尺度背景字典，减轻背景重建易受干扰问题；通过分析数据底层结构特征，设计结构先验矩阵并结合相关总变分增强模型背景与异常分离能力；设计判别性增量联合字典，动态优化背景和异常字典，构建具有高表征力且低冗余的字典；融合深度聚类网络，剔除非异常残差，提升检测性能。

中国知网 https://www.cnki.net

摘　要

高光谱遥感技术凭借其卓越的光谱分辨能力和丰富的波段信息，在各类遥感成像模式中脱颖而出。得益于其强大的信息获取能力，该技术已在精准农业、资源勘探、生态环境监测等多个领域展现出广阔的应用前景。然而，在实际成像过程中，受成像设备性能限制、复杂大气环境干扰以及传输过程中的多种因素影响，所获取的高光谱图像往往伴随着噪声污染和模糊退化等问题，严重削弱了光谱数据的可靠性，给后续的数据分析与应用带来了严峻挑战。此外，复杂的成像环境还导致异常目标与背景之间出现光谱混杂现象，进一步加剧了数据分析的难度。针对上述挑战，本研究重点探索如何有效抑制高光谱数据中非期望的退化干扰，提升数据质量、增强光谱信息可用性，进而提升数据分析精度与可靠性。总变分模型因其在边缘保持、抑制噪声和图像去模糊方面的优越表现，已被广泛用于高光谱图像复原与异常检测。然而，其在处理高光谱图像时其仍面临诸多挑战。例如，全局一致的正则强度使其仅聚焦于数据显著边缘而忽略了对局部重要细节的有效保留；其平滑特性虽有助于噪声抑制，但在地物关键结构保持与噪声去除之间的平衡仍存在挑战；在异常检测任务中，现有方法多侧重于背景建模与噪声抑制，却普遍忽视了对异常信号本身的保护，易造成异常信息的丢失。因此，本文围绕高光谱图像在获取过程中易受多种因素干扰的问题，结合当前研究在图像纹理结构表征与任务需求匹配方面的不足，聚焦于图像去噪、去模糊及异常检测中的关键挑战，从退化机理、复原目标及后续数据分析需求等多个维度展开深入研究。分别提出了像素级纹理自适应调整策略、局部极值结构补充项以及任务级动态引导机制，旨在构建一套从高光谱图像复原到数据分析的一体化处理框架，实现图像质量提升与任务性能优化的协同推进。主要研究内容如下[1]：

(1) 提出基于局部极值约束总变分模型的高光谱图像去模糊算法。针对传统总变分约束单一、难以适应图像中复杂纹理与强度差异的问题，本文从像素自身的强度分布特性及模糊图像的先验信息出发，深入分析了模糊退化过程中像素间的相互作用，提出了一种逐像素自适应的正则化约束策略，优化图像细节与纹理结构的恢复。在此基础上，进一步设计了一种融合模糊先验的总变分正则项，在增强模型表达能力的同时，避免了多正则项联合建模所带来的参数调节难题，增强了算法的稳定性与泛化能力。实验结果表明，所提出的模型不仅表现出优越的复原性能，其复原结果在后续的下游数据分析任务中也表现出良好的适用性和提升效果，验证了该方法在实际应用中的潜力与价值。

(2) 提出基于全局变分和局部结构低秩稀疏模型的高光谱图像去噪算法。针对总变分模型在高光谱图像去噪中对局部纹理关注不足、以及在复杂无序纹理区域适应能力较弱的问题，本文以高光谱数据固有的空间与光谱相关性为基础，深入挖掘其底层结构特征。通过构建 Carorati 矩阵并定义局部结构低秩正则项，以提升局部结构建模能力。在此基础上，进一步引入相关总变分，提出一种联合全局变分与局部结构低秩

[1]本研究 2024 年获得大连海事大学优秀博士学位论文培育项目资助（项目编号：0034012408）

中国知网 https://www.cnki.net

稀疏模型的去噪方法，实现对图像局部与全局结构的一致性保持。大量基于模拟数据和真实高光谱图像的实验结果表明，所提方法能够有效应对混合噪声的影响，在多种噪声环境下均表现出优越的去噪性能。去噪后的数据可提升下游数据分析任务精度，验证了该方法在实际应用中的有效性与鲁棒性。

(3) 提出基于反馈式波段组群和变分低秩稀疏模型的高光谱异常目标检测算法。针对异常检测算法在复杂场景下面临的异常信号保持与噪声抑制难以平衡的问题，本文提出一种联合相关总变分模型与 $L_{2,1}$ 范数的数据分解模型，实现背景、异常和噪声的有效分离。为应对高光谱数据中波段冗余严重所带来的计算负担和干扰问题，提出基于波段组的异常检测算法，通过波段组处理机制降低计算复杂度，并有效抑制非目标成分的干扰。在此基础上，充分利用不同波段组之间的一致性与互补性，设计反馈式波段组群异常检测框架，强化异常要素。该反馈调节机制无需在缺少异常先验的情况下进行波段选择，从根本上避免了因波段选择所导致的特征损失问题，可实现有效和稳定的异常检测。实验结果表明，该方法在复杂背景下能够实现对弱异常目标的有效识别，具有良好的应用前景。

(4) 提出基于结构先验与变分约束的判别性增量多尺度联合字典高光谱异常检测算法。针对检测算法在平滑噪声的过程中易削弱目标信号，且背景重建易受异常成分干扰问题，首先提出一种多尺度背景字典构建方法，该方法依据高光谱数据中异常目标分布特性，构建多尺度背景特征以降低背景样本中异常占比。其次，通过深入分析数据的底层结构特征，设计结构先验矩阵，并结合相关总变分模型，增强背景与异常成分分离能力。再次，结合地物的空间分布特性与潜在异常信号的预提取信息，引入聚类网络以剔除非异常残差。最后，在此基础上，提出一种判别性背景与异常增量字典学习方法，在检测过程中动态优化背景和异常字典，逐步构建具有高表征能力且低冗余的字典集合，从而缓解因异常信号被抑制而导致的信息丢失问题。实验结果表明，所提方法在一定程度上有效缓解了异常先验知识缺失所带来的挑战，在多种复杂场景下均展现出良好的检测性能，显著提升了异常检测的有效性与稳定性。

关键词：高光谱图像；高光谱图像复原；高光谱异常检测；总变分模型；低秩稀疏矩阵分解

中国知网 https://www.cnki.net

ABSTRACT

Hyperspectral remote sensing technology, owing to its high spectral resolution and rich spectral bands, has become increasingly prominent among various remote sensing imaging modalities. With its exceptional capacity for capturing fine-grained spectral information, it has demonstrated broad application prospects in a wide range of domains, including precision agriculture, resource exploration, and environmental monitoring. Nevertheless, in practical imaging scenarios, hyperspectral images (HSI) are often subject to various types of degradation, primarily caused by sensor limitations, complex atmospheric conditions, and transmission interference. These factors introduce significant noise and blur, thereby impairing the reliability of the spectral information and posing serious challenges for subsequent data analysis. Furthermore, complex imaging environments also induce spectral mixing between anomalous targets and background materials, further complicating HSI analysis. In light of these issues, the present study focuses on suppressing undesired degradations in HSI by investigating methods to improve data quality and enhance the usability of spectral information, with the ultimate goal of improving the accuracy and robustness of downstream analytical tasks. In recent years, total-variation-based models have been extensively employed in HSI restoration and hyperspectral anomaly detection (HAD) due to their effectiveness in preserving edges, suppressing noise, and mitigating blur. However, despite their advantages, existing total-variation-based approaches still suffer from several inherent limitations when applied to HSI. For example, the use of a globally uniform regularization parameter often results in an overemphasis on prominent edges while neglecting locally important details. Although the smoothness prior facilitates noise suppression, achieving a satisfactory balance between detail preservation and noise removal remains a challenging task. Furthermore, in HAD, most existing methods predominantly focus on background modeling and noise suppression, often overlooking the preservation of anomalous features themselves, which can result in the loss of crucial anomaly information. To tackle the above challenges, this work focuses on the specific issue of multi-source degradation during HSI acquisition. It examines the limitations of current approaches in texture structure modeling and task adaptability, and targets three core technical challenges: image denoising, image deblurring, and HAD. A comprehensive study is conducted from the perspectives of degradation modeling, restoration objectives, and the demands of downstream tasks. To this end, this paper proposes a unified processing framework that integrates the following key components: A pixel-wise texture-adaptive regularization strategy; A local extremum structure-aware enhancement term; A task-aware dynamic guidance mechanism. This framework aims to provide a seamless pipeline from image restoration to data analysis, thereby achieving simultaneous improvements in data quality

中国知网 https://www.cnki.net

and task effectiveness. The major contributions of this study are as follows[1]:

(1) Hyperspectral image deblurring method based on local extrema-constrained total variation. To address the limitations of the traditional total variation model in adaptively handling complex textures and varying intensity distributions in HSI, this study introduces a novel pixel-wise adaptive regularization strategy. This method is developed through an analysis of the intensity distribution characteristics of pixels, incorporating prior knowledge derived from blurred observations. By explicitly modeling the interactions between neighboring pixels during the blurring degradation process, the proposed strategy enhances the recovery of image details and complex texture structures. Building on this foundation, we further develop a total variation-based regularization term that incorporates blur priors. This formulation preserves the expressive capability of the original model while effectively avoiding the parameter tuning complexity commonly encountered when multiple regularization terms are used in combination. As a result, the proposed approach improves the overall stability and generalization capability of the restoration algorithm. Extensive experimental results demonstrate that the proposed model not only achieves superior restoration performance in terms of quantitative and visual metrics, but also exhibits strong adaptability and effectiveness in subsequent downstream analytical tasks. These findings validate the practical applicability and potential value of the proposed method in real-world hyperspectral imaging scenarios.

(2) Hyperspectral image denoising method based on global variation and local structure low-rank sparse model. To address the limitations of traditional total variation in HSI denoising, particularly its insufficient sensitivity to fine textures and poor adaptability in complex, disordered regions, a denoising framework is proposed by leveraging the spatial-spectral correlations inherent in HSI. Specifically, the underlying structural features of the data are deeply explored to construct a Carorati matrix, based on which a local structure low-rank regularization term is defined to enhance the reconstruction accuracy of critical local structures. Furthermore, a correlated total variation term is introduced, and a denoising model that integrates global variation constraints with local structure low-rank sparsity is developed. This joint model effectively preserves both local structural details and global consistency. Extensive experiments on both synthetic and real-world datasets demonstrate that the proposed method is robust against mixed noise in HSI and significantly improves the accuracy of subsequent data analysis tasks.

(3) Hyperspectral anomaly detection method based on feedback band grouping and variational low-rank sparse model. To address the inherent challenge of balancing anomaly preservation and noise suppression in complex hyperspectral imaging scenarios, this study proposes a data decomposition model that integrates the correlated total variation model with

[1]This work was supported by the Excellent Doctoral Dissertation Cultivation Project of Dalian Maritime University in 2024 (Project No. 0034012408)

中国知网 https://www.cnki.net

the $L_{2,1}$-norm. This formulation enables the accurate separation of background, anomalies, and noise components, thereby enhancing HAD performance under adverse conditions. In response to the severe spectral redundancy and the resulting computational burden commonly observed in HSI, we further introduce a band-group-based HAD algorithm. This approach significantly reduces computational complexity while effectively suppressing interference from non-target components. Building upon this, we design a feedback-driven band group HAD framework that exploits the consistency and complementarity across different band groups to enhance anomaly features. This feedback mechanism eliminates the need for explicit band selection in the absence of prior anomaly knowledge, thereby avoiding potential feature loss caused by suboptimal band subset selection. As a result, the proposed method achieves robust and efficient HAD without reliance on predefined priors. Extensive experimental evaluations demonstrate that the proposed method can effectively identify weak anomaly targets even in complex backgrounds, highlighting its practical applicability and strong potential for real-world deployment in HAD tasks.

(4) Discriminative incremental multi-scale joint dictionary learning for hyperspectral anomaly detection based on structural priors and variational constraints. To overcome the limitations of current HAD, particularly the attenuation of target signals during noise suppression and the vulnerability of background estimation to anomalous signatures, First, a multi-scale background dictionary construction method is introduced. This approach uses the spatial distribution characteristics of anomalous targets in HSI to construct multi-scale background features, effectively reducing the contamination of background samples by anomalous signatures. Second, by thoroughly analyzing the intrinsic structural properties of the data, a structural prior matrix is designed and incorporated into a correlated total variation model. This enhances the separability between background and anomaly. Third, considering both the spatial distribution of surface materials and pre-extracted information related to potential anomalies, a clustering-based network is introduced to eliminate residuals unrelated to anomalies. Finally, a discriminative incremental dictionary learning strategy is proposed to dynamically optimize both the background and anomaly dictionaries during the detection process. This method incrementally constructs a dictionary set with high representational capacity and low redundancy, thereby mitigating the risk of information loss caused by the suppression of subtle anomaly signals. Experimental results demonstrate that the proposed method effectively alleviates the challenges posed by the absence of reliable anomaly priors. In various complex scenarios, it effectively improves detection accuracy, significantly enhancing the effectiveness and stability of HAD.

Key Words: Hyperspectral Image; Hyperspectral Image Restoration; Hyperspectral Anomaly Detection; Total Variation; Low-Rank and Sparse Matrix Factorization

中国知网 https://www.cnki.net

目 录

1 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外相关研究工作进展.....2
1.2.1 高光谱图像复原的研究现状.....2
1.2.2 抗噪声干扰高光谱异常检测研究现状.....7
1.3 研究内容与结构安排.....10
1.3.1 研究内容.....10
1.3.2 论文结构安排.....11
2 相关理论基础知识.....13
2.1 总变分正则化模型.....13
2.2 低秩稀疏分解理论.....14
2.3 评价指标.....16
2.4 本章小结.....18
3 基于局部极值约束总变分模型的高光谱图像非盲去模糊算法.....19
3.1 引言.....19
3.2 基于总变分模型的图像去模糊.....19
3.3 基于局部极值约束总变分的图像非盲去模糊模型.....21
3.3.1 基于模糊先验的约束定义.....21
3.3.2 基于局部极值约束总变分模型.....23
3.3.3 模型求解.....23
3.4 实验验证与分析.....26
3.4.1 局部极值约束有效性分析.....27
3.4.2 自然图像上实验.....28
3.4.3 高光谱图像上实验.....32
3.4.4 去模糊后数据在下游任务中验证.....37
3.5 本章小结.....38
4 基于全局变分和局部结构低秩模型的高光谱去噪算法.....39
4.1 引言.....39
4.2 基于相关总变分的高光谱图像去噪.....39
4.3 基于全局和局部结构低秩模型的高光谱去噪模型.....41
4.3.1 M 和 A 算子定义.....41
4.3.2 LMD 定义.....41
4.3.3 GLLR 模型建立及优化.....43
4.4 实验验证与分析.....47

中国知网 https://www.cnki.net

4.4.1 模拟数据上实验.....48
4.4.2 真实数据上实验.....51
4.4.3 复原数据在下游任务中验证.....53
4.4.4 讨论.....54
4.5 本章小结.....56
5 基于反馈式波段组群和变分低秩稀疏模型的高光谱异常检测算法.....57
5.1 引言.....57
5.2 基于低秩稀疏矩阵分解的高光谱异常检测.....57
5.3 反馈式波段组群和变分低秩稀疏模型的异常检测.....58
5.3.1 波段组内的低秩稀疏矩阵分解.....59
5.3.2 基于相关总变分的分段平滑和低秩先验.....60
5.3.3 波段组间引导与优化反馈机制的设计.....62
5.4 实验结果和性能分析.....64
5.4.1 实验设置.....64
5.4.2 全波段和波段组上的异常目标检测结果分析.....66
5.4.3 实验结果与分析.....69
5.4.4 收敛性和参数分析.....77
5.5 本章小结.....78
6 基于结构与变分约束的增量多尺度联合字典高光谱异常检测算法.....80
6.1 引言.....80
6.2 基于联合字典的高光谱图像异常检测.....81
6.3 基于结构先验与变分约束的判别性增量多尺度联合字典高光谱异常检测.....82
6.3.1 DIMSJD 模型.....82
6.3.2 背景字典构建与更新.....86
6.3.3 异常字典更新.....88
6.3.4 基于深度聚类的非异常残差去除.....88
6.4 实验结果和性能分析.....90
6.4.1 实验设置.....90
6.4.2 实验结果与分析.....92
6.4.3 增量字典有效性验证分析.....98
6.4.4 收敛分析.....100
6.5 本章小结.....101
7 结论与展望.....102
7.1 结论.....102
7.2 展望.....103

中国知网 https://www.cnki.net

参考文献.....105

中国知网 https://www.cnki.net

图 目 录

图 1.1 高光谱图像示意图 1
图 1.2 论文结构框架 11
图 3.1 提出的 LECTV 图像去模糊方法框架 21
图 3.2 局部最小像素的相关值与模糊图像空间结构关系 22
图 3.3 退化图像的无约束梯度和约束梯度对比 27
图 3.4 TV 和 LECTV$_{\mathrm{CTV}}$ 的平均 PSNR 28
图 3.5 TV 和 LECTV$_{\mathrm{CTV}}$ 的平均 SSIM 28
图 3.6 TV 和 LECTV$_{\mathrm{CTV}}$ 复原的视觉示例 29
图 3.7 视觉示例：G_A 31
图 3.8 视觉示例：S_A 32
图 3.9 视觉示例：M_A 32
图 3.10 TV 和 LECTV$_{\mathrm{CTV}}$ 复原过程中相对误差和 PSNR 值的演变 32
图 3.11 chart and stuffed toy 上的复原结果的视觉示例 (波段 24) 34
图 3.12 fake and real strawberries 数据中每个波段的 PSNR 和 SSIM 值 (案例 A) 34
图 3.13 光谱曲线及其定量指标 35
图 3.14 Urban 数据（案例 A）中每个波段的 PSNR 和 SSIM 值 35
图 3.15 Urban 数据上的复原结果视觉示例 36
图 3.16 光谱曲线及其定量指标 37
图 4.1 噪声影响下的图像局部结构特征变化 42
图 4.2 LMD 低秩特性 43
图 4.3 GLLR 示意图 44
图 4.4 不同方法在案例 1 下 W. D.C. Mall 数据的复原结合可视化 50
图 4.5 不同方法在案例 6 下 Pavia City 数据的复原结合可视化 50
图 4.6 案例 6 中 Pavia City 位置 (178,174) 处的光谱曲线 52
图 4.7 Indian Pines 数据（波段 2）复原结果可视化 52
图 4.8 Urban 数据（波段 104）复原结果可视化 53
图 4.9 不同方法复原的 Indian Pines 分类结果图 54
图 4.10 参数 λ_1 的敏感性分析 55
图 4.11 参数 λ_2 的敏感性分析 55
图 5.1 FBGVLRS 的流程图 59
图 5.2 HYDICE15-panel 场景的伪彩色图像、地物真值图和光谱特征 64
图 5.3 四个实验数据的伪彩色图像、地物真值图和光谱特征 65
图 5.4 全波段各成分的可视化结果 67
图 5.5 波段组各成分的可视化结果 67
图 5.6 全波段不同成分的异常检测结果 68
图 5.7 波段组不同成分的 AD 结果 68

中国知网 https://www.cnki.net

图 5.8 不同方法在 HYDICE15-panel 数据上的 HAD 结果图 70
图 5.9 不同方法在 HYDICE Urban 数据上的检测结果图 71
图 5.10 不同方法在 ABU-beach3 数据上的检测结果图 72
图 5.11 不同方法在 Pavia Center 数据上的检测结果图 72
图 5.12 不同方法在 ABU-beach2 数据上的检测结果图 73
图 5.13 不同方法在 HYDICE panel 数据集上的 ROC 曲线 73
图 5.14 不同方法在 HYDICE Urban 数据集上的 ROC 曲线 73
图 5.15 不同方法在 ABU-beach3 数据上的 ROC 曲线 74
图 5.16 不同方法在 Pavia Center 数据上的 ROC 曲线 75
图 5.17 不同方法在 ABU-beach2 数据上的 ROC 曲线 77
图 5.18 相对误差随迭代次数的变化 78
图 5.19 五组数据在不同 c 设置下的 AUC (P_D, P_F) 值 79
图 6.1 DIMSJD 流程图 82
图 6.2 Pavia 数据的多尺度特征图 87
图 6.3 Cat Island 的增强特征图 89
图 6.4 聚类网络结构 90
图 6.5 实验数据可视化 91
图 6.6 不同方法在 Cat Island 数据上的异常检测结果 93
图 6.7 不同方法在 Los Angeles-I 数据上的异常检测结果 94
图 6.8 不同方法在 Texas Coast 数据上的异常结果 94
图 6.9 不同方法在 Texas Coast 数据上的异常检测结果 95
图 6.10 不同方法在 HYD-U 数据上的异常检测结果 95
图 6.11 不同方法在 Pavia 数据上的异常检测结果 96
图 6.12 不同方法在 Cat Island 数据上的 ROC 曲线 96
图 6.13 不同方法在 Los Angeles-I 数据上的 ROC 曲线 97
图 6.14 不同方法在 Texas Coast 数据上的 ROC 曲线 97
图 6.15 不同方法在 Los Angele-II 数据上的 ROC 曲线 97
图 6.16 不同方法在 HYD-U 数据上的 ROC 曲线 97
图 6.17 不同方法在 Pavia 数据上的 ROC 曲线 98
图 6.18 字典原子更新的有效性验证 99
图 6.19 相对误差与迭代次数 100

中国知网 https://www.cnki.net

表目录

表 1.1 基于数据驱动的高光谱图像去模糊方法对比 3
表 1.2 基于物理建模与优化的典型高光谱图像去模糊方法 3
表 1.3 基于数据驱动的典型高光谱图像去噪方法 5
表 1.4 基于模型驱动的典型高光谱图像去噪方法 6
表 1.5 基于统计的典型高光谱异常检测方法 8
表 1.6 基于数据驱动的典型高光谱异常检测方法 8
表 1.7 基于数据分解的典型高光谱异常检测方法 9
表 3.1 不同方法在 Dataset1 数据集上的定量评估 30
表 3.2 不同方法在 Dataset2 数据集上的定量评估 30
表 3.3 不同方法在 Dataset3 数据集上的定量评估 31
表 3.4 不同方法在 Cave 数据集上的定量评估结果 33
表 3.5 不同方法在高光谱图像数据集上的定量评估 36
表 3.6 Urban 数据去模糊前后异常检测结果 38
表 4.1 不同方法在 W. D.C. MALL 数据上的定量评估结果 49
表 4.2 不同方法在 Pavia City 数据上的定量评估结果 51
表 4.3 不同方法复原的 Indian Pines 分类精度 54
表 4.4 消融实验 56
表 5.1 不同数据的 j 估计值 67
表 5.2 全波段和波段组各成分的异常目标检测结果 68
表 5.3 全波段及波段组数据分解时间对比 (秒) 69
表 5.4 不同方法在 HYDICE15-panel 数据上的 AUC 值 74
表 5.5 不同方法在 Hydice Urban 数据上的 AUC 值 75
表 5.6 不同方法在 ABU-Beach3 数据上的 AUC 值 76
表 5.7 不同方法在 Pavia Center 数据上的 AUC 值 76
表 5.8 不同方法在 ABU-Beach2 数据上的 AUC 值 77
表 6.1 Cat Island 数据上不同方法的 AUC 值 92
表 6.2 Los Angeles-I 数据上不同方法的 AUC 值 99
表 6.3 Texas Coast 数据上不同方法的 AUC 值 99
表 6.4 Los Angele-II 数据上不同方法的 AUC 值 100
表 6.5 HYD-U 数据上不同方法的 AUC 值 100
表 6.6 Pavia 数据上不同方法的 AUC 值 101

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景与意义

遥感技术作为现代对地观测体系的核心手段，通过航空/航天平台搭载的传感器远距离获取地表电磁辐射信息。该技术发轫于测谱学原理，在演进过程中逐步融合了光谱学、信息学、地理学、大气科学及林学等多个学科的理论与技术成果。其独特的全谱段、多时相和大范围观测能力，不仅为地球资源普查、环境动态监测和灾害预警评估等关键领域提供数据支撑，更通过多角度立体观测架构，推动人类对地球圈层系统和宇宙空间认知的范式转变。

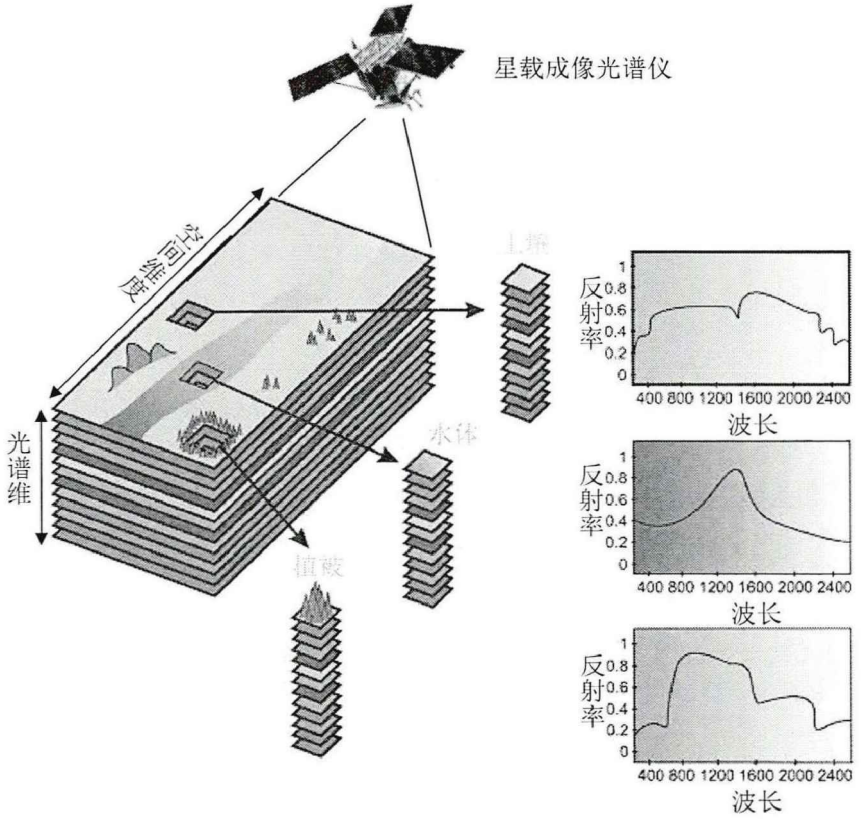

图 1.1 高光谱图像示意图

Fig. 1.1 Hyperspectral Image Illustration

在遥感技术迭代进程中，数据获取模式经历了从最初的全色单波段图像到彩色图像，再到多光谱图像和高光谱图像的跨越式发展。相较于传统宽波段遥感技术存在的光谱分辨率低、波段数量有限且分布离散等不足，高光谱遥感通过纳米级的光谱分辨率，能够提供连续且精细的光谱曲线，有助于地物光谱特征的精准识别与区分。如图1.1所示[1]，其核心在于采用成像光谱仪同步获取二维空间信息与连续光谱特征，形成具有“空间-光谱”三维属性的数据立方体[2]。该技术可覆盖紫外至热红外的完整电磁谱段，为每个像素点提供包含数百个窄波段的连续光谱响应曲线，能够精确反映不同材料在各波长范围内的光谱吸收和反射特性，从而揭示地物之间的细微光谱差异。这

中国知网 https://www.cnki.net

一优势使得高光谱遥感在区分相似地物、精细识别目标等方面取得了显著成绩[3]，意味着遥感技术从宏观形态辨识向物质组分解析的质的飞跃[4,5]。

如今，高光谱遥感已凭借其高精度、多维度的观测能力在生态环境评估、精准农业监测、矿产资源勘探、灾害监测及军事侦察等领域具有广泛的应用潜力[6,7]，推动了对地观测技术的进一步发展，成为实现全球可持续发展目标的重要技术支撑。然而，高光谱图像在采集过程中由于大气扰动、成像系统稳定性和仪器噪声等多方面原因，常常伴随噪声干扰、模糊和异常目标混杂等现象[8]。这些退化现象极大地影响了图像质量，不仅造成空间纹理信息损失，更会破坏光谱曲线的物理一致性，使得原始数据信噪比下降、特征区分度降低，直接影响下游数据分析任务（如高光谱异常检测）的精度。因此，恢复高质量的高光谱数据立方体或在下游任务中抵抗噪声干扰是确保生态监测、资源勘查等应用结果可靠性的先决条件，也是发挥纳米级光谱分辨率优势的必要保障。

1.2 国内外相关研究工作进展

1.2.1 高光谱图像复原的研究现状

高光谱数据复原试图从受模糊、噪声等污染损伤的观测图像中重建潜在的高质量数据立方体，其本质是通过数学模型反演实现对原始光谱特征的精确恢复。该过程不仅改善数据的可视化质量，更重要的是重构光谱曲线的物理真实性，为定量遥感分析提供可靠数据支撑。研究表明，有效的复原处理对提升下游数据分析任务精度方面具有重要意义[9]。在线性观测模型中，图像退化过程可形式化表征为：

$$\mathcal{Y} = \mathcal{T}(\mathcal{X}) + \mathcal{E} + \mathcal{N} \tag{1.1}$$

其中，$\mathcal{Y} \in \mathbb{R}^{r\times c\times B}$，$\mathcal{X} \in \mathbb{R}^{r\times c\times B}$，$\mathcal{E} \in \mathbb{R}^{r\times c\times B}$ 和 $\mathcal{N} \in \mathbb{R}^{r\times c\times B}$ 分别是观测高光谱图像、潜在干净高光谱图像、稀疏项和高斯噪声项，$r \times c$ 表示图像的空间维度，B 表示波段数量，$\mathcal{T}(\cdot)$ 为线性退化算子。高光谱图像复原任务即从给定的降质图像中估计出潜在的干净图像 $\mathcal{X}$ 和稀疏项 $\mathcal{E}$。在不同的情形下，(1.1) 可以表征不同的高光谱图像复原问题。更具体地说，当 $\mathcal{T}(\cdot)$ 为单位张量时，问题 (1.1) 可以表征高光谱图像去噪问题。当 $\mathcal{T}(\cdot)$ 为模糊算子时，问题 (1.1) 则构成图像去模糊问题。本文按照退化类型，分别对高光谱图像复原中的去模糊和去噪的研究现状进行介绍。

(1) 图像去模糊是一个经典的逆问题，它是计算机视觉和图像处理中一个非常活跃的话题，在高光谱图像处理领域也受到了广泛的关注。为了更全面的介绍当前高光谱图像去模糊的研究现状，可将其大致分为基于物理建模与优化方法和基于数据驱动方法。相关方法在表1.1-1.2中列出，并在下文对其进行概述：

随着深度学习技术的迅速发展，基于深度神经网络的遥感图像处理方法取得了显著进展。在图遥感像去模糊方面，Zhang 等人[10] 提出了一种基于 GAN(generative adversarial network, GAN) 的端到端学习方法，有效提升了遥感图像去模糊效果。随

中国知网 https://www.cnki.net

表 1.1 基于数据驱动的高光谱图像去模糊方法对比
Tab. 1.1 Data Driven-based hyperspectral image deblurring methods

典型的方法/模型	主流架构划分			建模维度	
	CNN	GAN	Hybrid	2D	3D
GAND[10]		√		√	
3DDnCNN[11]	√		√		√
DeblurCNN[12]	√			√	
苏乐辉[13]	√		√		√
PnP[14]	√				√

表 1.2 基于物理建模与优化的典型高光谱图像去模糊方法
Tab. 1.2 Physics modeling and optimization-based hyperspectral image deblurring methods

典型的方法/模型	涉及图像属性				建模维度	
	低秩	非局部相似	局部平滑	字典学习	矩阵分解	张量分解
SCCTD[15]				√		√
WLRTR[16]	√	√				√
OLRT[17]	√	√				√
ABGI[18]			√		√	
TSSS[19]			√		√	
DSU[20]			√		√	
JDD[21]			√		√	
DSSTV[22]			√		√	
3DFTV[23]			√		√	

后，Wang 等人[11] 针对高光谱图像的数据特点，提出了一种基于交替方向乘子法 (Alternating Direction Method of Multipliers, ADMM) 框架和三维去噪卷积神经网络 (3D Denoising Convolutional Neural Network, 3DDnCNN) 的高光谱图像去卷积方法。该方法通过变量分裂技术将优化问题分解为简单的二次子问题和去噪子问题，并利用深度学习方法直接从数据中学习高光谱图像的空谱先验。随后，Deshpande 等人[12] 通过从清晰-模糊图像块对中提取低层-高层特征，设计端到端深度卷积神经网络，用于处理卫星图像中从轻微到严重的不同程度模糊。苏乐辉[13] 通过 3D CNN 提取模糊图像特征，利用图像重建层获取特征重组，估计潜在清晰高光谱图像。文献 [14] 通过数据驱动方式学习高光谱图像的空谱信息，将其嵌入 ADMM 框架，提出一种即插即用的高光谱图像去卷积框架。这类方法能够有效建模模糊与清晰图像之间的映射关系，但需要一定数量的标注数据支撑，特别是在处理复杂地物场景和多样化的模糊类型时。

基于物理建模与优化方法的高光谱图像去模糊研究侧重于利用数据先验属性构建数学模型，具备理论严谨性和良好的可解释性。此类方法通常将去模糊问题建模为不适定逆问题，通过正则化或最大后验框架引入先验知识来增强解的稳定性，其核心在于正则项的优化设计。常见方法包括基于字典学习、低秩张量和图像梯度约束等。在基于字典学习的方法中，研究着通过寻找基本元素的线性组合来实现高光谱图像的稀疏表示。例如，为将多光谱图像的空间结构与光谱相关性纳入统一表征框架，Geng

中国知网 https://www.cnki.net

等人[15]将图像块建模为三阶张量，通过约束张量的稀疏性与投影矩阵正交性，构建结构紧凑核心张量学习模型，提升张量估计准确度。虽然这类方法能够实现较好的去模糊效果，但其复杂的字典构建过程需要较高的计算成本和充足的数据支持，限制其在某些场景下的实际应用。在低秩张量方法方面，为充分利用三维高光谱数据的结构化的空间和光谱相关性，文献 [16] 提出统一的高光谱图像恢复框架，以张量形式集成了对基于向量/矩阵恢复模型的统一理解。Chang 等人[17]基于高光谱图像沿空间、光谱和非局部模型具有不同的物理意义和维度，探索各自不同的低秩属性，认为沿不同模式的内在低秩相关性将对图像恢复结果发挥不一样的贡献。这类方法虽然能够有效利用高光谱数据的三维空谱结构特征，具有一定的研究潜力，但由于涉及到高维数据的处理和分析，通常需要大量计算资源。梯度相关方法通过利用图像固有梯度信息指导降质数据的复原过程。例如，为避免纹理平滑和阶梯效应，Guo 等人[18]利用三维图像的结构信息和分数阶导数模型提出基于三维分数总变分 (Three-dimensional Fractional Total Variation, 3DFTV) 的去模糊方法。Liao 等人[19]根据不同光谱波段间的梯度信息相似性，提出了一种辅助波段梯度信息先验，但在核估计方面对各种噪声的鲁棒性不够。Hao 等人[20]提出在变换域中引入结构稀疏性和拉普拉斯尺度混合模型，对结构稀疏性进行建模，强调了对空间和光谱方向的梯度稀疏性，并通过变换学习进一步优化稀疏结构表达。除上述方法外，**总变分**模型由于其可以自然地编码高光谱图像的结构特征，成为该领域主流方法之一。例如，文献 [21] 采用总变分正则化用于处理高光谱图像去模糊与稀疏解混问题。Chang 等人[22]通过结合小波框架正则化和总变分模型，实现不同类型模糊和条带噪声的联合去除。为适应高光谱图像的 3D 结构特性，文献 [23] 利用空间-光谱联合总变分和显式非负约束保持空间域边缘信息。这些方法在一定程度上验证了总变分模型在刻画图像结构方面的优秀性能，并在高光谱图像去模糊中表现出了显著优势。

（2）噪声干扰也是困扰高光谱数据实际应用的一个重要因素。高光谱图像去噪通过减少或去除图像中的噪声干扰，可获得更精确的光谱信息，为下游分析任务提供可靠的数据支持[24]。论文从基于数据驱动的方法和基于模型驱动的方法两个方面介绍目前的高光谱图像去噪相关研究工作，表1.3-表1.4列出了相关的研究方法。

基于数据驱动的方法依据其强大的非线性建模能力，能够捕捉输入数据中的复杂映射关系。受此启发，Xiong 等人[25]利用模型引导的深度神经网络，在端到端架构中考虑空谱相关性、光谱低秩性和空间稀疏性等先验属性。考虑利用高光谱图像的局部和全局信息，文献 [26] 建立深度空间-光谱全局推理网络用于高光谱图像去噪。Wang 等人[27]针对光谱波段间强相关性的特点，将总变分模型与 Transformer 网络结合，引入总变分损失函数，在去噪同时保留边缘锐度，但该方法内存成本极高。Zhang 等人[28]利用 Tucker 分解刻画全局光谱低秩约束，并通过两个深度去噪网络分别优化光谱正交基和空间降维因子。Ye 等人[29]将秩最小化模块嵌入 U-Net 架构，通过迭代优化的方式补充细节信息。这类方法具有较强的特征学习能力，端到端的训练方式能够自动建立噪声图像到干净图像的映射关系，但此类方法对训练所需的计算资源和时

中国知网 https://www.cnki.net

间成本较高，且依赖标注或合成的训练数据支撑。但在实际成像环境中，干净的高光谱数据较为罕见，且成像机制和退化过程的复杂性可能会导致合成数据与实际场景存在偏差。

表 1.3 基于数据驱动的典型高光谱图像去噪方法

Tab. 1.3 Data driven-based typical methods for hyperspectral image denoising

典型的方法/模型	主流架构划分					建模维度	
	CNN	GAN	Transformer	Hybrid	Model-Unfolded	2D	3D
SMDS-Net[25]					√		√
GRN-Net[26]	√		√	√		√	
DP-LRTF[28]	√			√		√	
SdeCNN[30]	√						√
ILRNet[29]	√			√			√
MTSR[31]			√		√	√	
SSTD[27]	√			√			√
HSI-DCGAN[32]	√	√		√			√

相较于数据驱动方法，模型驱动方法通过挖掘数据本身的内在结构特性，构建相应的求解模型，对数据依赖较低，具有较强的可解释性。典型代表包括滤波、非局部均值、稀疏表示、低秩矩阵/低秩张量及总变分模型等类别。具体来说，基于滤波的方法主要思想是利用图像局部或全局统计特性，通过设计各种滤波器对图像进行平滑，从而压制高频噪声成分。例如，均值滤波[33]、双边滤波[34] 等，这类方法实现简单、计算效率高，但往往存在光谱信息失真或损失，边缘模糊[35] 等问题。为克服传统滤波器方法的局限性，Dabov 等人[36] 通过将相似的二维图像块分组，设计协同滤波技术，但其计算成本较高。最近，Tun 等人[37] 通过联合训练噪声图像块和低通滤波生成具有更优边缘保留特性和感知质量的图像。Diwakar 等人[38] 提出一种边缘引导的分数阶全变分模型，用于处理严重泊松再生导致的图像降质问题。

基于自然图像中非局部图像块间的高度相似性，Efros 等人[39] 首次提出非局部先验理论，后被拓展至高光谱图像。Maggioni 等人[40] 利用分组与协同滤波范式，开发了一种名为 BM4D 的去噪方法。在稀疏表示方法中，Ye 等人[41] 从噪声图像中提取训练样本构建集成模型，开发了多任务稀疏非负矩阵分解方法。在此基础上，Xiong 等人[31] 学习共享稀疏系数刻画图像边缘共性结构，并利用独享稀疏系数描述细节特征。传统稀疏表示方法虽能建模光谱与空间维度的冗余性，但其对高光谱数据在三维张量空间中的联合稀疏性与跨维度相关性利用不足。由于高光谱图像的强波段相关性与主成分分析依赖数据相关性的数学机制高度契合，文献 [42] 将干扰视为独立未知信号源，提出干扰与噪声自适应主成分分析。Peng 等人[43] 提出采用非均匀奇异值阈值算子增强矩阵的低秩特性，其性能较原始主成分追踪优化和加权 L_1 最小化方法有大幅提升。随后，He 等人[44] 对通过字典序重排三维图像块得到的 Casorati 矩阵实施分块随机奇异值分解，在分块低秩矩阵近似的基础上利用迭代正则化技术实现信号与噪声的精细分离。基于低秩张量分解的方法是针对低秩矩阵方法忽略三维立方体结构问题而提出

中国知网 https://www.cnki.net

表 1.4 基于模型驱动的典型高光谱图像去噪方法

Tab. 1.4 Model driven-based typical methods for hyperspectral image denoising

典型的方法/模型	涉及图像属性				建模维度	
	低秩	非局部均值	局部平滑	稀疏表示	矩阵分解	张量分解
BM4D[40]		√			√	
MTSNMF[41]				√	√	
INAPCA[42]	√				√	
RLRMR[43]	√				√	
NAILRMA[44]	√				√	
ITSReg[45]	√					√
NLR-CPTD[46]	√					√
TV-NLRTD[47]	√		√			√
NG-Meet[48]	√					√
FGSLR[49]	√		√			√
FRCTR-PnP[50]	√					√
MLR-SSTV[51]	√		√			√
NLTR[52]	√					√
LRTFL$_0$[53]	√		√			√
SSAHTV[54]			√		√	
CSSWHTV[55]			√		√	
ESSTV[56]	√		√			√
TPTV[57]	√		√			√
PWRCTV[58]	√		√			√
LLRSSTV[59]	√		√			√
LSSTV[60]	√		√		√	
TLR-L$_0$TV[61]	√		√			√
SDD-UTV[62]			√	√	√	
CTV-RPCA[63]	√		√		√	
HLTV[64]	√		√			√

的，其将高光谱立方体视为一个三阶张量，同时考虑空间维度和光谱维度上的相关性。根据不同的张量分解方式可将其划分为：1) CP 分解 (Canonical Polyadic，CP)[45,46]；2) Tucker 分解[47–49]；3) t-SVD 分解 (Tensor Singular Value Decomposition, t-SVD)[50,51]；4) tensorring 分解[52]；5) BTD 分解 (Block Term Decomposition, BTD)[53]。与矩阵方法相比，张量分解能更充分挖掘全局光谱-空间相关性，但其优化过程复杂度显著增加。

除上述方法，鉴于高光谱图像的分段平滑特性，**总变分**[65] 正则化技术由于其善于对图像结构特征建模的优势，在高光谱图像去噪中也被广泛研究。通过在去噪过程中考虑不同波段间的噪声分布差异与不同像素间的空间信息差异，文献 [54] 提出光谱-空间自适应总变分正则项。在此基础上，Jiang 等人[55] 提出空间-光谱重加权总变分，其自适应加权机制意图实现边缘保护与噪声消除的自动平衡。Peng 等人[56] 则认为实际场景中高光谱图像梯度在不同波段间往往呈现差异性与相关性并存的复杂结构特征，基于这一观点，开发了增强 3DCTV。基于拉普拉斯尺度混合模型，文献 [57] 通过对梯度图进行加权 L_1 范数约束，提出纹理保留总变分模型，其中 L_1 权重

中国知网 https://www.cnki.net

由去噪后图像自适应确定，确保在像素变化较大的区域减弱稀疏约束，达到保留图像纹理的目的。文献 [58] 根据同一场景下全色图像与高光谱图像在结构纹理上的相似性以及全色图像更低的噪声水平，将全色图像作为引导信息，提出全色加权表示系数总变分正则项，在平滑过程中为各像素分配不同的总变分正则化权重。从上述分析可以看到，与其他几类方法相比，总变分约束在边缘特征的保留上具有显著优势，但其对复杂纹理的高噪声高光谱图像效果不佳。为提高此类方法性能，有研究将总变分正则化与其他几类方法相结合。例如，根据不同类型的噪声所表现出的不同统计特性，He 等人[59] 通过协同利用高光谱图像的局部低秩结构和全局分段平滑性与一致性分离干净信号与噪声干扰。Wang 等人[60] 提出低秩约束和空间-光谱总变分 SSTV(Spatial-Spectral Total Variation, SSTV) 正则化联合模型，在消除噪声的同时增强图像在空间和光谱维度的分段平滑性。文献 [61] 介绍了总变分模型联合张量低秩约束的应用，充分考虑了高光谱图像的结构特性。Chang 等人[62] 利用总变分与稀疏表示协同优化实现同步去除条纹与随机噪声，缺点是计算耗时。文献 [63] 建立了相关总变分正则化项，并设计相关全变分-主成分分析模型同时编码低秩和局部平滑属性。最近，Yang 等人[64] 发现在光谱梯度域更加能够体现高光谱数据的低秩性与平滑性，提出光谱梯度域超拉普拉斯总变分，提升去噪性能且降低了计算成本。总之，一个良好的高光谱图像复原算法能够有效恢复图像中的显著边缘和细节纹理特征，使获取的数据能够以更佳的状态服务于后续数据分析任务，具有重要研究意义。

1.2.2 抗噪声干扰高光谱异常检测研究现状

除了对降质数据进行去噪处理，现有异常检测研究也在模型中加入抵抗噪声干扰项，以应对噪声对数据分析性能的限制[66]。通过数据分析方法的设计思想、背景与异常的分离标准、所使用的基础函数模型，这些方法可以分为基于统计方法、基于数据分解方法和基于数据驱动方法[67]，下面在表1.5-1.7中简要列出。

基于统计的异常检测方法是高光谱图像处理中的经典检测方法之一，其通过构建背景像素的统计分布模型，并利用异常评分函数对偏离背景模型的像素进行检测。此类方法虽未显式分离噪声分布，但通常通过对协方差矩阵的鲁棒估计或局部建模，间接考虑噪声干扰。以典型的 RX[68] 检测器为例，其通过背景均值与协方差估计构建马氏距离型检测统计量，协方差项中包含了背景变异与噪声扰动，因此能在一定程度上反映噪声影响。此外，为进一步提升对噪声的适应性，相关研究提出了 KRX[69]，局部 RX[70]、子空间 RX[71] 和 RXD[72] 等改进方法。这类方法具备计算效率高、模型结构简单的优点。但其依赖于背景分布假设，对非高斯噪声敏感。并且在高噪声的情况下，可能会把噪声误认为异常目标，或导致真实异常目标被背景噪声掩盖，造成虚警率的上升和检测率的下降。

随着深度学习技术在各个领域中表现出的突破性进展，基于数据驱动的高光谱异常检测方法也成为当前主流之一。其在网络架构或损失函数中，通过 CNN[73,74]、自编码器 (Autoencoder, AE)[75–79]、GAN[80–82]、Transformer[83] 等，显式或隐式地抑制噪

中国知网 https://www.cnki.net

表 1.5 基于统计的典型高光谱异常检测方法

Tab. 1.5 Statistically-based typical methods for hyperspectral anomaly detection

典型的方法/模型	涉及图像属性				建模维度	
	空间	光谱	局部	非线性	矩阵运算	张量运算
RX[68]		√			√	
KRX[69]	√	√	√	√	√	
LRX[70]	√	√	√		√	
SRX[71]		√		√	√	
RXD[72]		√	√		√	

声干扰，并精确重建背景分量，进而提取稀疏且显著的异常信号[74,84]。这类方法在不依赖人工设计算子的同时具有出色的特征学习能力，但也面临：1) 训练样本是否足够或者训练样本是否有效；2) 庞大的模型参数；3) 较高的计算复杂度等挑战，限制了其在资源受限场景中的应用。

表 1.6 基于数据驱动的典型高光谱异常检测方法

Tab. 1.6 Data driven-based typical methods for hyperspectral anomaly detection

典型的方法/模型	主流架构划分						建模维度	
	CNN	GAN	Transformer	AE	Hybrid	Model-Unfolding	2D	3D
GIL-HAD[75]			√	√	√			√
Auto-AD[76]				√				√
SMCNet[77]	√		√	√	√			√
SFM2AE[78]				√				√
BASGAN[80]		√					√	
WeaklyAD[81]		√						√
CL-CaGAN[82]		√					√	
CTA[79]	√		√	√	√		√	
FrFTTCNN[83]	√				√		√	
GT-HAD[73]	√	√			√			√
TGFA-AD[74]	√		√		√			√
贾森等人[84]				√				√
LRR-Net[85]					√	√	√	
LRR-Net+[86]					√	√	√	

除上述方法外，基于数据分解的方法也当前主流方法之一，其能够将数据中的主要成分（背景）与稀有而显著的异常目标有效分离，并显式建模噪声以去除或抑制噪声干扰。研究学者基于各种不同考量引入额外的惩罚项，提出一系列数据分解的异常检测算法，例如，Qu 等人[66] 利用光谱解混和基于构造字典的低秩矩阵分解来处理受噪声污染的高光谱数据。文献 [87] 将分数阶傅里叶变换与协同表示检测器相结合，增强异常目标与背景之间的可区分性。Ma 等人[88] 通过结合分数阶傅立叶变换域低秩稀疏矩阵分解保证背景抑制能力。Zhuang 等人[8] 采用低秩表示促进非局部相似块的自相似性，并借助协作稀疏性的形式保留异常像素。文献 [89] 利用双子空间表示方法来同时获得去噪和异常检测结果。除此之外，**总变分**模型在高光谱异常目标检测中取得

中国知网 https://www.cnki.net

了出色的成绩。例如，考虑到空间因素和噪声干扰，文献 [90] 中将超像素分割与低秩和总变分模型相结合来保持背景像素的局部结构。孙等人[91] 利用傅立叶变分提取光谱维的时频域特征，并利用总变分正则项描述中间域内背景部分的空间平滑性，通过综合利用空谱信息的方式提升背景和异常的可分性。Feng 等人[92] 介绍了一种联合因子总变分正则项的张量环分解异常检测方法，该方法根据背景张量在空间和光谱维度上的低秩性和分段平滑性实现背景成分精确重建，并利用 $L_{2,1}$ 范数约束异常目标提取。针对噪声对异常检测的影响，Wang 等人[93] 考虑了耦合的去噪和异常检测任务，通过在集成迭代循环中引入高光谱数据的空间光谱域的平滑特性去噪，并提高异常位置检测的准确性。

表 1.7　基于数据分解的典型高光谱异常检测方法

Tab. 1.7　Data decomposition-based typical methods for hyperspectral anomaly detection

典型的方法/模型	涉及图像属性			建模维度	
	低秩	局部平滑	稀疏表示	矩阵分解	张量分解
ADLR[66]	√				
IFEBP[88]	√			√	
RhyDe[8]	√		√	√	
DSR-ADNR[89]	√			√	
LSC-TV[90]		√		√	
孙菲等人[91]	√	√	√	√	
TRDFTVAD[92]	√	√			√
HyADD[93]	√	√			√

综上，降质高光谱数据复原的迅速发展极大地提升了高光谱数据的应用潜力。数据分析目标和噪声抑制的联合考虑也为下游分析任务的性能提升提供了可行的技术方案。总变分充分利用高光谱图像固有的局部连续性，在抑制干扰的同时，保护了图像关键结构信息，在图像去噪、去模糊以及异常目标检测等图像处理中发挥了重要作用。但由于高光谱数据信息丰富、背景结构错综复杂以及任务本身具有多样性，许多理论和实践问题仍需深入探讨。

第一、高光谱图像去模糊中传统总变分模型难以根据图像中不同纹理区域的特性进行自适应调整，导致复原结果中细节纹理信息的丢失。现有大多数方法通过定义不同的正则项来表征图像的整体统计特性，鲜少从像素自身强度出发，分析其在模糊退化过程中的局部变化。再者，为融合多种图像先验信息，一些研究引入了多正则项联合优化的策略，但这无疑会增加多个参数之间的耦合效应，增加了参数调节的复杂性，并在一定程度上限制了模型的稳定性。因此，如何构建一种能够根据像素强度动态调整正则化策略的变分模型，以增强算法对图像细节的保持能力；以及如何在不牺牲复原性能的前提下，减少模型参数数量，提升算法的鲁棒性与稳定性，是值得深入探索的问题。

第二、高光谱图像去噪中总变分模型对局部结构关注不足及复杂纹理区域适应能力较弱。部分方法依据全局低秩与总变分约束来揭示高光谱数据的显著特性，虽在一

中国知网 https://www.cnki.net

定程度上提升了去噪效果，但往往忽略了对局部结构细节的有效恢复，难以应对因关键信息丢失而对后续数据分析造成的不利影响。因此，如何深入挖掘高光谱数据的底层结构特征以在抑制噪声的同时有效缓解过度平滑现象，并兼顾局部结构的保真性与全局一致性的提升，成为提高去噪算法性能、实现关键细节复原和复杂混合噪声处理的关键所在。

第三、高光谱异常检测算法忽略了对潜在异常信号本身的保护和强化，且异常先验缺失以及波段冗余多限制了背景和异常的分离。因此，在非监督的情况下，如何深入挖掘数据质量提升与任务分析需求之间的内在关联，设计一种既能有效保留异常信号、又能抑制冗余信息与噪声干扰的正则化模型，成为提升降质高光谱图像异常检测性能的关键突破点。再者，尽管高光谱数据具有丰富的光谱信息，但直接对全波段数据进行分解和建模会导致巨大的计算开销。因此，如何在不丢失异常信息的同时降低算法计算量，实现高效准确的异常检测，仍是当前亟待进一步探索的关键问题。

1.3 研究内容与结构安排

1.3.1 研究内容

高光谱成像技术因其独特的光谱分辨能力，在精准农业、环境监测、资源勘探和军事侦察等领域展现出巨大的应用潜力。然而，在实际应用中，高光谱图像在采集、传输、压缩和存储等过程中易受到多种内部与外部因素的干扰，常伴随高斯噪声、脉冲噪声、条带噪声及模糊等多种退化现象。这些降质问题不仅降低了高光谱图像的可用性，也给下游图像分析任务 (如地物分类、异常目标检测等) 带来了挑战。此外，复杂背景下异常目标与背景之间的光谱混杂问题，也进一步加剧了图像分析的难度。在此背景下，研究高效、鲁棒的高光谱图像复原与异常检测技术具有重要意义。通过去噪、去模糊等复原方法，可以有效提升数据质量，为高光谱遥感的应用提供更可靠的数据支撑。噪声抑制与任务导向联合考虑的先进技术，为改善高光谱图像分析性能提供了新的解决思路。

论文针对高光谱数据获取过程中易受多种非期望干扰导致数据质量下降问题，从退化因素、复原目标以及下游分析任务需求开展研究。具体研究内容组织结构如图1.2所示，具体来说，本研究针对获取的高光谱数据常伴随噪声污染、模糊、波段冗余和异常与背景混杂等问题，并基于现有研究对图像固有纹理特性、下游任务目标表征力不足，围绕高光谱图像复原与异常检测的核心挑战，从退化因素、复原目标以及下游分析任务需求开展研究，并从像素级处理 (研究内容一)、结构块建模 (研究内容二) 和波段组分析 (研究内容三和研究内容四) 逐步深化，构建了一个层次递进、任务导向的技术体系。

研究从底层图像质量提升出发，在第三章 (研究内容一) 提出基于模糊先验的局部极值约束总变分模型，有效解决了传统方法在图像去模糊过程中细节丢失的难题；第四章 (研究内容二) 通过深入探索高光谱数据深层结构特性，进一步结合全局变分

中国知网 https://www.cnki.net

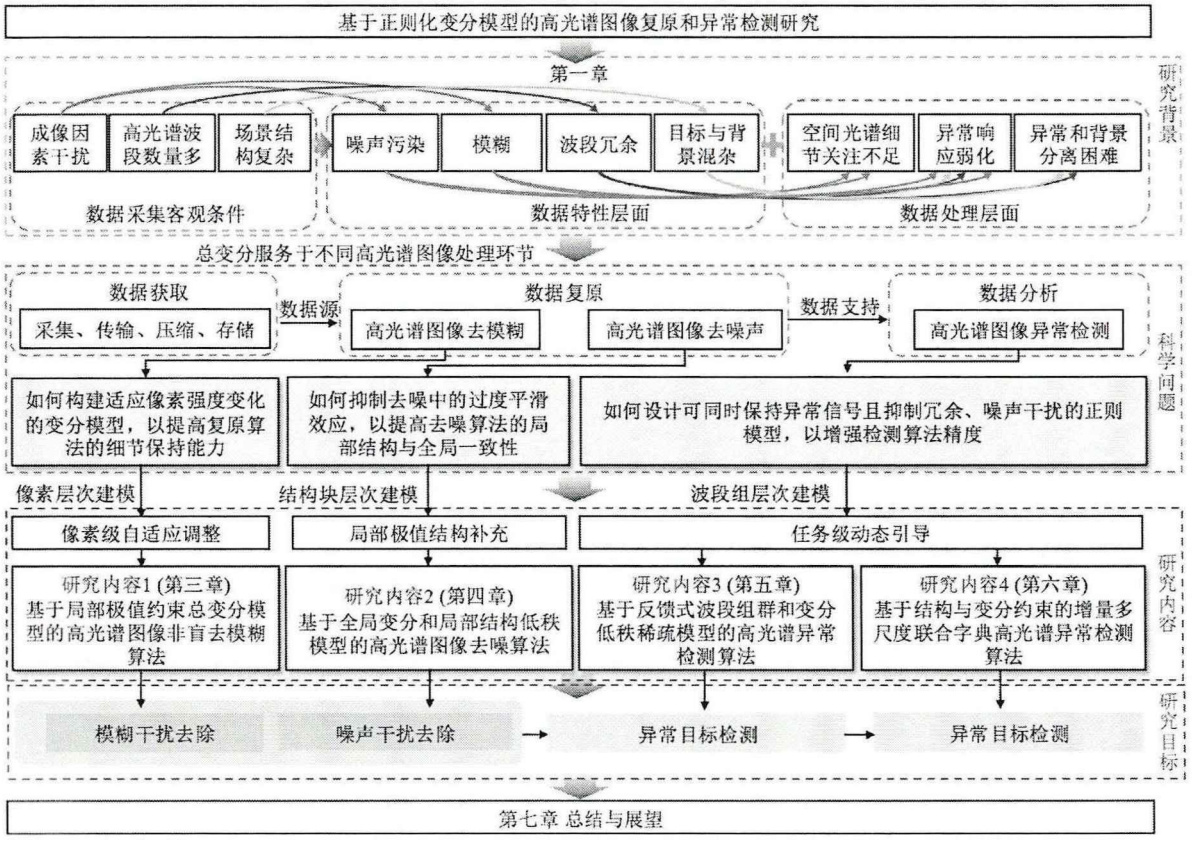

图 1.2　论文结构框架

Fig. 1.2　Thesis framework

与局部结构低秩建模，实现了噪声抑制与结构保持的最佳平衡，为后续高级分析提供了高质量的数据基础。在数据分析层面，第五章 (研究内容三) 通过反馈式波段组分解和低秩稀疏建模，并强化数据中的异常要素，解决了异常目标与复杂背景干扰的分离问题；第六章 (研究内容四) 则更进一步，通过设计判别性多尺度联合字典和增量学习方法，增强背景重建精度，显著提升了弱目标检测能力。这些内容形成了从数据预处理到异常目标识别的技术链条。这一研究体系以变分模型为统一框架，通过局部极值约束、低秩稀疏分解、波段组分析和判别性多尺度字典等设计，有效应对高光谱图像处理中的三大核心挑战：图像退化、背景复杂性和弱目标检测。研究成果不仅在理论上完善了高光谱图像处理的技术体系，更在实际应用中展现出显著价值，可应用于矿产勘探、精准农业、军事侦察等领域中，为遥感智能分析提供了新的技术范式和方法支撑。各模块设计既保持独立性以适应特定应用场景，又通过变分框架的内在一致性形成协同增效的解决方案，体现了从数据复原到下游分析的链条。

1.3.2　论文结构安排

基于课题研究背景和内容，论文的整体结构安排如下：

第一章，绪论。首先，本章介绍了高光谱遥感成像及其数据特点。接着，回顾了高光谱图像复原和异常检测的研究意义、研究现状及当前研究的局限性。最后，总结

中国知网　https://www.cnki.net

了本课题的主要研究内容和全文结构安排。

第二章，相关理论基础知识。本章对后续章节所涉及的理论基础知识和算法评价指标进行了系统梳理。首先，概述了总变分从灰度图像到高光谱图像发展的演进过程。接着，介绍了低秩和稀疏分解理论。最后，概述了论文中实验部分所涉及的评价指标的定义及其计算方式。

第三章，基于局部极值约束总变分模型的高光谱图像去模糊算法。针对模糊退化图像复原中复原算法对细节纹理以及模型稳定性受限问题，本章对退化图像自身像素强度和模糊先验知识进一步分析，定义局部极值约束矩阵以优化图像细节纹理，并依据模糊先验知识设计自适应约束总变分模型，从退化数据中探索图像固有结构特征的复原。

第四章，基于全局变分和局部结构低秩模型的高光谱图像去噪算法。针对噪声退化图像复原中复原算法对局部结构关注不足及复杂纹理区域适应能力弱的问题，本章以高光谱图像的空间和光谱相关性为基础，试图关注图像更深层结构特性，通过设计更为有效的正则项来处理图像局部细节，提出基于全局和变分和局部结构低秩模型的高光谱图像去噪方法，以局部和全局相结合的方式，实现图像高精度复原。

第五章，基于反馈式波段组群和变分低秩稀疏模型的高光谱异常检测算法。针对异常检测中非目标信息的干扰多问题，设计波段组群上的数据分解；利用 $L_{2,1}$ 范数和相关总变分来建模背景和异常成分；最后，利用波段组之间的一致性和互补性，提出反馈式波段组群和变分低秩稀疏模型的高光谱异常检测方法，强化异常要素的提取。

第六章，基于结构先验与变分约束的判别性增量多尺度联合字典高光谱异常检测算法。针对异常检测中噪声去除与异常目标保持上的困境，依据不同场景中异常目标表现出的形状和尺寸差异，设计一种多尺度背景字典的构建方法；针对异常检测先验知识缺失、噪声和复杂背景干扰问题，设计背景和异常联合字典增量学习方案；在此基础上，根据字典原子和检测样本之间的光谱信息设计结构关系矩阵，增强背景和异常成分的分离能力；最后，利用深度聚类网络和地物分布特征获取异常目标检测结果。

第七章，总结与展望。本章系统地归纳和总结了全文研究工作，并展望未来工作方向。

中国知网 https://www.cnki.net

2 相关理论基础知识

2.1 总变分正则化模型

总变分模型具有边缘保持能力强和噪声鲁棒的优势，因而从灰度图像[65]、多波段图像[94]被推广至高维数据(如多/高光谱图像)[54,95]的处理中。基于式(1.1)中的退化过程，在变分框架下，基于总变分正则化复原模型通常表示为以下能量泛函的最小化问题：

$$\min_{\mathbf{X}} \left\{ \frac{1}{2} \|\mathbf{Y} - \mathcal{T}(\mathbf{X})\|_F^2 + \lambda \cdot \mathrm{TV}(\mathbf{X}) \right\} \tag{2.1}$$

其中，$\mathbf{Y}$ 和 $\mathbf{X}$ 分别为观测高光谱图像和待复原图像的矩阵形式。TV(X) 为总变分正则项，λ 为正则化参数，用于控制保真项与正则项的平衡。

在高光谱图像处理中，根据高光谱图像的空谱特性，总变分正则化通常需考虑空间维与光谱维的联合。下面按照正则化项中使用的范数类型划分，常见变体包括：

(1) L_2 总变分：

早在 1992 年，Rudin 等人[65]便率先将总变分模型应用于图像去噪任务。对于一幅灰度图像 $\mathbf{X}$，其标准总变分模型定义如下：

$$\mathrm{TV}(\mathbf{X}) = \sum_{i,j} \sqrt{(\nabla_1 \mathbf{X}_{i,j})^2 + (\nabla_2 \mathbf{X}_{i,j})^2} \tag{2.2}$$

其中，i 和 j 分别为水平和垂直方向像素索引，∇_1 和 ∇_2 分别表示作用于像素 (i,j) 的水平方向和垂直方向的一阶差分算子，h 和 w 为图像空间尺寸大小。

在这之后，随着总变分模型和图像处理技术的发展，标准总变分被推广至高维数据[95]：

$$\mathrm{TV}(\mathbf{X}) = \sum_{i,j,b} \sqrt{(\nabla_1 \mathbf{X}_{i,j,b})^2 + (\nabla_2 \mathbf{X}_{i,j,b})^2 + (\nabla_3 \mathbf{X}_{i,j,b})^2} \tag{2.3}$$

其中，b 为光谱波段索引。上式对梯度向量取欧氏范数，所以水平方向、垂直方向变化被整体统一考虑，这种定义方式对高斯噪声有较好的效果。常用于图像去噪等需要平滑的任务，但对于含有大量边缘或细节的图像，可能会导致一些细节模糊。

(2) L_1 总变分：

公式（2.2）采用 L_2 范数将图像的水平梯度和垂直梯度一起处理，然后对所有像素求和，也被称为各向同性总变分。基于 Rudin 等人[65]提出的最小全变分原理，Li 等人[96]设计了 L_1 总变分，其将图像的水平梯度和垂直梯度分别独立地进行 L_1 范数求和，也称作各向异性总变分：

$$\mathrm{TV}(\mathbf{X}) = \sum_{i,j} (|\nabla_1 \mathbf{X}_{i,j}| + |\nabla_2 \mathbf{X}_{i,j}|) \tag{2.4}$$

上式中，水平方向和垂直方向分开处理的设计使其更倾向于保留水平和垂直方向的边

中国知网 https://www.cnki.net

缘，但在非水平/非垂直 (比如斜线) 方向容易产生伪影。同样，对应于高维数据，上式可扩展为：

$$\mathrm{TV}(\mathbf{X}) = \sum_{i,j,b} \left(|\nabla_1 \mathbf{X}_{i,j,b}| + |\nabla_2 \mathbf{X}_{i,j,b}| + |\nabla_3 \mathbf{X}_{i,j,b}| \right) \tag{2.5}$$

其中，∇_3 表示光谱方向的一节差分算子。上式分别独立地对水平、垂直梯度做绝对值求和，该方式适用于快速去噪。

（3）L_0 总变分：

文献 [97] 首次通过逼近 L_0 的梯度稀疏性去除非期望的小幅度结构，用于图像去模糊研究。与其他两种范数约束相比，L_0 梯度强调非零梯度的个数，是一种更加严格的稀疏性约束，能够精确地保留边缘信息，不允许有过多的非零梯度。根据其定义，单波段的 L_0 梯度总变分可以表示为：

$$\mathrm{TV}(\mathbf{X}) = \sum_{i,j} O\left(\left(|\nabla_1 \mathbf{X}_{i,j}| + |\nabla_2 \mathbf{X}_{i,j}| \right) \right) \tag{2.6}$$

上式中，$O(\mathbf{X})$ 表示一个二进制函数，可计算图像 $\mathbf{X}$ 梯度的非零个数，其定义为：若 $\mathbf{X} \neq 0$ 则 $\mathbf{X} = 1$，反之，$\mathbf{X} = 0$。

在这之后，Wang 等人[98] 将其扩展至高光谱图像去噪，提出了基于张量低秩约束和 L_0 总变分的高光谱图像混合噪声去除方法，实现噪声污染图像边缘特征的有效复原。考虑高光谱波段空间结构变化的稀疏特性，L_0 总变分可描述为：

$$\mathrm{TV}(\mathbf{X}) = \sum_{i,j} O\left(\sum_{b} \left(|\nabla_1 \mathbf{X}_{i,j,b}| + |\nabla_2 \mathbf{X}_{i,j,b}| \right) \right) \tag{2.7}$$

L_0 约束强调图像的稀疏性，通常用于强调边缘保留并同时抑制噪声。由于 L_0 范数是非连续的，因此其优化过程较为复杂。

除上述定义形式外，其他类型总变分变体，例如方向性光谱总变分模型[99]、结构总变分模型[100] 等，也逐渐被引入到高光谱图像复原的研究中。总体而言，基于总变分的光滑先验模型主要聚焦于刻画图像的分段平滑特性。尽管这些研究已取得较好的成果，能够有效保留图像的边缘结构信息，但由于其平滑策略的局限性以及高光谱数据结构的复杂性，往往在图像纹理的保留上存在一定的局不足。

2.2 低秩稀疏分解理论

在实际成像过程中，采集到的高光谱数据常常伴随复杂噪声的干扰，不仅显著降低了图像质量，也使得后续如异常检测、分类识别等分析任务更为困难。尤其是在噪声干扰与复杂背景共同作用下，异常信号难以从背景中准确分离，显著加剧了异常检测的挑战。随着低秩稀疏分解 (Low-Rank and Sparse Decomposition, LRSD) 理论被广

中国知网 https://www.cnki.net

泛引入高光谱图像处理领域，凭借其结构化建模优势，在图像去噪与异常检测中展现出显著效果。该理论基于高光谱数据中背景成分 (如水体、植被、城市等) 具有统计上的冗余性和全局相似性，从而在数据矩阵中表现为低秩结构；而异常目标由于其空间分布稀少、光谱特征突变，在整体图像中呈现出稀疏特性的假设。据此，Candes 等人[101] 在 2011 年提出的鲁棒主成分分析（RPCA）模型首次将观测数据分解为低秩背景与稀疏异常两部分，为高光谱图像异常检测与去噪任务提供了统一建模框架。对于具有 B 个波段和 $h \times w$ 个样本的观测矩阵 $\mathbf{Y}$，其可以表示为主成分矩阵 $\mathbf{X}$ 和稀疏成分 $\mathbf{S}$ 的组合：

$$\mathbf{Y} = \mathbf{X} + \mathbf{S} \tag{2.8}$$

鉴于高光谱数据背景成分和稀疏噪声表现出的低秩和稀疏特性，式 (2.8) 的求解被描述为 (2.9) 的形式:

$$\begin{aligned} \min_{\mathbf{X},\mathbf{S}} &= rank(\mathbf{X}) + \lambda \|\mathbf{S}\|_0 \\ \text{s.t. } &\mathbf{Y} = \mathbf{X} + \mathbf{S} \end{aligned} \tag{2.9}$$

上式中 λ 为正则项参数。针对上式中 NP 难问题 $rank(\mathbf{X})$ 和 $\|\cdot\|_0$ 的求解，通常将 (2.9) 松弛为 (2.10) 中的形式

$$\begin{aligned} \min_{\mathbf{X},\mathbf{S}} &= \|\mathbf{X}\|_* + \lambda \|\mathbf{S}\|_1 \\ \text{s.t. } &\mathbf{Y} = \mathbf{X} + \mathbf{S} \end{aligned} \tag{2.10}$$

其中，核范数 $\|\cdot\|_*$ 和 L_1 范数 $\|\cdot\|_1$ 分别计算矩阵奇异值和与矩阵元素绝对值和。随后，Chen 等人[102] 将 RPCA 与 RX 检测器相结合，奠定了低秩稀疏分解方法在高光谱异常检测中的典范范式。此外，Zhou 等人[103] 提出低秩稀疏矩阵分解 (Low-Rank and Sparse Matrix Decomposition, LRaSMD) 模型，并利用 GoDec 求解：

$$\mathbf{Y} = \mathbf{X} + \mathbf{S} + \mathbf{N} \tag{2.11}$$

其中，N 为噪声项，通常假设为独立同分布的高斯噪声。随后，Zhang 等人[104] 通过引入 Mahalanobis 距离约束构建 LRaSMD 检测器，有效增强了检测模型对高斯噪声的鲁棒性；此外，Liu 等人[105,106] 认为每种材料的光谱都可以在一个子空间中表示，因此高光谱图像中的所有光谱可以从多个子空间中提取，提出如下的低秩表示模型 (Low-Rank Representation, LRR)：

$$\begin{aligned} \min_{\mathbf{X},\mathbf{S}} &= rank(\mathbf{L}) + \lambda \|\mathbf{E}\|_{2,1} \\ \text{s.t. } &\mathbf{Y} = \mathbf{D}\mathbf{L} + \mathbf{E} \end{aligned} \tag{2.12}$$

中国知网 https://www.cnki.net

上式中，**DL** 表示由背景字典 $\mathbf{D}=[\mathbf{d}_1,\mathbf{d}_2,...,\mathbf{d}_m]$ 和表示稀系数 $\mathbf{L}=[\mathbf{l}_1,\mathbf{l}_2,...,\mathbf{l}_N]$ 构成的背景成分。$N=h\times w$ 代表像素个数。基于此，Xu 等人[107] 首次将其引入用于高光谱图像异常检测，并将残差 $\mathbf{E}=[\mathbf{e}_1,\mathbf{e}_2,...,\mathbf{e}_N]$ 看作异常成分。

2.3 评价指标

在介绍课题研究内容之前，首先介绍几种常用的高光谱图像空间和光谱质量评价指标、高光谱异常检测性能评价指标和图像分类评价指标，其中，图像质量评价指标包括了图像空间质量评价指标和光谱质量评价指标。

(1) 高光谱图像空间和光谱质量评价指标

复原图像的质量对后续处理步骤至关重要，但仅凭视觉效果往往难以做出直接评估且易加入主观判断。因此，实验采用定量和定性相结合的方式来全面评估实验结果。定量评价指标主要涵盖了空间质量和光谱质量两个方面，具体采用以下四种广泛认可的定量指标：在空间质量评估方面，峰值信噪比 (Peak Signal-to-Noise Ratio, PSNR) 用于量化复原图像与参考图像之间的信噪比，其值越高表明复原质量越优。结构相似性 (Structural Similarity Index Measure, SSIM) 则用于评估复原图像与参考图像在结构、亮度及对比度方面的相似程度，其值越大表示复原图像与真实图像的结构信息保持得越完整。在光谱质量评估方面，归一化相对全局误差 (Erreur Relative Globale Adimensionnelle de Synthèse, ERGAS) 用于衡量复原图像相较于参考图像的全局误差，其值越小表明复原精度越高。光谱角映射 (Spectral Angle Mapper, SAM) 通过计算复原光谱与参考光谱之间的角度偏差来评估光谱信息的保真度，其值越小表示光谱畸变越低。基于此，本研究采用 PSNR、SSIM、SAM 和 ERGAS 作为评估指标，以全面量化所提出 GLLR 方法及对比方法在不同退化场景下的复原性能。为便于分析，实验中每个评价指标的最佳结果和次优结果分别以加粗和下划线的形式标注。此外，可视化结果图也直观反映了不同方法复原结果的视觉效果。上述指标的计算方式如下：

$$\text{PSNR}=10\cdot\log_{10}\left(\frac{MAX^2}{\text{MSE}}\right) \tag{2.13}$$

$$\text{MSE}=\frac{1}{h\times w\times B}\sum_{i=1}^{h}\sum_{j=1}^{w}\sum_{b=1}^{B}(Y(i,j,b)-X(i,j,b))^2 \tag{2.14}$$

其中，h，w，B 分别是高光谱图像水平、垂直和光谱维度的尺寸大小，$Y(i,j,b)$ 和 $X(i,j,b)$ 分别为原始图像像素值和复原图像像素值。MAX 表示像素峰值，MSE 表示均方误差。对于高光谱图像，通过计算所有波段的平均 PNSR 来衡量算法复原性能，其值越大表明结果越优。

$$\text{SSIM}(Y,X)=\frac{(2\mu_Y\mu_X+C_1)(2\sigma_{YX}+C_2)}{(\mu_Y^2+\mu_X^2+C_1)(\sigma_Y^2+\sigma_X^2+C_2)} \tag{2.15}$$

中国知网 https://www.cnki.net

其中，μ_Y、μ_X 分别为原始图像 Y 和复原图像 X 的均值，σ_Y 和 σ_X 分别为 Y 和 X 的方差，σ_{YX} 表示协方差。K_1 和 K_2 表示常数，用于避免分母为零的情况。

(2) 高光谱异常检测评价指标

为系统地评估所提出方法的异常检测性能，本章采用了多维度的量化分析指标，采用以下三类核心评估指标：二维受试者工作特征 (Receiver Operating Characteristic, ROC) 曲线、三维受试者工作特征 (3D ROC) 曲线[108] 以及 AUC 及其衍生指标。与传统 2D ROC 相比，3D ROC 曲线通过引入特定阈值 τ 作为第三个独立变量，构建了 (P_D, P_F, τ) 参数空间，拓展了传统 ROC 曲线的表达能力。基于此，本研究采用四种 AUC 值进行定量分析，包括：$\mathrm{AUC}(P_D, P_F)$、$\mathrm{AUC}(P_D, \tau)$、$\mathrm{AUC}(P_F, \tau)$ 和 $\mathrm{AUC}_{\mathrm{SNPR}}$。其中，2D ROC 曲线由 (P_D, P_F)、(P_D, τ) 和 (P_F, τ) 组成，其对应的 AUC 值衡量了不同变量之间的关系。AUC 计算的是 ROC 曲线与坐标轴围成的面积，因此，$\mathrm{AUC}(P_D, P_F)$、$\mathrm{AUC}(P_D, \tau)$ 分别评价算法的检测性能和目标检测能力，其值越大表明方法的检测性能越出色。$\mathrm{AUC}(P_F, \tau)$ 值越小，表明该方法具有更强的背景抑制能力，能够更有效地突出异常目标。$\mathrm{AUC}_{\mathrm{SNPR}}$ 值则用于衡量检测结果的信噪概率比，因此其值越大检测性能越优。这些评估指标通过多角度对检测算法进行评估，涵盖了异常检测的有效性、背景抑制能力、异常检测能力以及两者之间的权衡，共同构成了本研究的性能分析体系，为不同方法的优劣提供了客观、量化的比较依据。

(3) 高光谱图像分类评价指标

为全面、客观地评估复原数据在下游数据分析任务中的性能，在第四章中对所提方法复原后的数据进行了分类性能验证。在分类性能评价指标上，采用了常用的分类评价指标包括整体分类精度 (Overall Accuracy, OA) 和 Kappa 系数，具体定义如下：

OA 是最常用的分类性能指标，定义为分类正确的样本数与总样本数之比。其数学表达式为：

$$\mathrm{OA} = \frac{\sum_{i=1}^{C} N_{ii}}{N} \tag{2.16}$$

其中，N_{ii} 表示被正确分类到第 i 类的样本数，C 表示类别总数，N 表示样本总数。

Kappa 系数用于衡量分类结果与随机分类结果之间的一致性，定义如下：

$$\kappa = \frac{p_o - p_e}{1 - p_e} \tag{2.17}$$

其中，p_o 表示观察到的一致性 (即整体分类精度 OA)，p_e 表示预期一致性，计算公式为：

$$p_e = \sum_{i=1}^{C} \left(\frac{N_{i'}}{N} \times \frac{N_i}{N} \right) \tag{2.18}$$

其中，$N_{i'}$ 为第 i 类的实际样本总数 (即混淆矩阵中第 i 行的总和)，N_i 为第 i 类的预测样本总数 (即混淆矩阵中第 i 列的总和)。

中国知网 https://www.cnki.net

2.4 本章小结

本章对课题研究的相关基础内容进行了简要介绍，首先回顾了高光谱图像中不同形式的总变分模型；其次，简要介绍了低秩稀疏分解理论在高光谱图像去噪和异常检测中的发展过程；最后，在 2.3 节中对本文中涉及的算法性能评价指标进行了概述，为后续所提出方法的实验验证提供了客观评估标准。

中国知网 https://www.cnki.net

3 基于局部极值约束总变分模型的高光谱图像非盲去模糊算法

3.1 引言

近年来，图像去模糊领域取得了显著进展，众多基于总变分模型、暗通道先验(Dark Channel Prior, DCP)及其联合策略的方法相继涌现。特别是，文献[109]和[110]探讨了这些方法在遥感图像恢复中的应用，并引入了基于 L_0 和 L_1 的总变分正则项，以提高遥感图像去模糊的性能。然而，这类方法仍然存在一定的局限性。首先，尽管这些方法试图结合总变分模型和DCP这两种技术的优势，但大多仅将DCP或总变分模型视为独立的正则项，而未能深入挖掘二者的协同效应，限制了去模糊性能的进一步提升。此外，多个正则项联合也增加了参数调节的难度，导致模型的稳定性受限。其次，现有方法主要关注暗通道的全局稀疏性，强调图像整体特征的表达，其对像素层面上的强度变化描述不足，难以有效捕捉局部纹理细节。

针对上述问题，本章提出一种基于局部极值约束总变分的图像去模糊(Local Extremum-Constrained Total Variation, LECTV)框架。与大多数关注暗通道整体稀疏性的现有方法不同，该框架通过将图像的模糊先验知识与图像的局部平滑属性集成至一个正则项，实现了逐像素尺度的自适应约束，有助于恢复图像的本征空间纹理结构。更具体地说，本章从模糊图像自身先验知识出发设计了像素级自适应约束，在这之上，结合图像的局部平滑属性，设计了一种将模糊先验显示地嵌入到总变分中的方式。这种在一个统一的正则项利用两种先验知识的优势可以解决总变分对图像纹理的过渡平滑缺陷，增强了对图像纹理特征的精细刻画，同时避免了多个正则项带来的参数调节困扰。此外，为高效求解所提出的LECTV框架，本章设计了一种基于主导最小化(Majorization-Minimization, MM)的优化算法，以确保在复杂去模糊任务中的稳健性与收敛性。实验结果表明，所提出的方法在自然图像、多光谱和高光谱图像去模糊任务中均表现出色，能够有效去除不同类型及不同程度的模糊。进一步的定量与定性评估亦验证了本方法在去模糊质量、边缘保持能力及计算效率等方面相较于现有先进方法的优势。

本章后续部分内容组织如下：第3.2节简要介绍了总变分模型和图像去模糊研究的相关理论基础；第3.3节中阐述了基于局部极值约束总变分模型的图像非盲去模糊算法的具体实施流程和理论推导过程；第3.4节中测试并分析了所提方法在多个数据集上的实验结果，验证了本章所提方法的有效性；第3.5节总结概述了本章内容。

3.2 基于总变分模型的图像去模糊

图像去模糊问题本质上是一个不适定的逆问题，目标是从模糊观测图像 $\mathbf{Y}$ 估计出清晰图像 $\mathbf{X}$，该问题通常建模为：

$$\mathbf{Y} = \mathbf{H}\mathbf{X} + \mathbf{n} \tag{3.1}$$

中国知网 https://www.cnki.net

其中，$\mathbf{H}$ 为模糊核，$\mathbf{n}$ 代表成像过程中的噪声。基于最大后验（Maximum A Posteriori, MAP）框架，原始清晰图像 $\mathbf{X}$ 可通过最大化后验分布进行估计，即：

$$\hat{\mathbf{X}} = \arg\max_{\mathbf{X}} P(\mathbf{Y}|\mathbf{X})P(\mathbf{X}) \tag{3.2}$$

为提升恢复效果，通常需要在 MAP 框架中引入正则项，描述图像的结构或先验信息。通过结合似然项和先验项，可将去模糊问题形式化为如下优化模型：

$$\hat{\mathbf{X}} = \arg\min_{\mathbf{X}} L(\mathbf{X})L(\mathbf{X}) = \|\mathbf{Y} - \mathbf{H}\mathbf{X}\|^2 + \lambda R(\mathbf{X}) \tag{3.3}$$

其中，$R(\mathbf{X})$ 代表正则项，用于约束恢复图像的结构特性，如平滑性、稀疏性等。λ 为正则化参数，控制数据一致性项与先验项之间的平衡。第一项 $\|\mathbf{Y} - \mathbf{H}\mathbf{X}\|^2$ 量化了观测数据 $\mathbf{Y}$ 与 $\mathbf{H}\mathbf{X}$ 之间的误差，确保优化过程能够恢复符合观测数据的清晰图像。总变分模型因其在保持图像分段平滑特性方面的优越性，在图像恢复领域得到了广泛关注。考虑图像的局部平滑特征，若在模型 (3.3) 中引入总变分正则项，则相应的基于总变分的去模糊模型可表示为：

$$L(\mathbf{X}) = \|\mathbf{Y} - \mathbf{H}\mathbf{X}\|^2 + \lambda \sum_{i=1}^{hw} \sqrt{\left(\nabla_i^1 \mathbf{X}\right)^2 + \left(\nabla_i^2 \mathbf{X}\right)^2} \tag{3.4}$$

将公式 (2.2) 中的总变分模型从灰度图像扩展至多光谱或高光谱图像的最直接方式是对各波段的总变分约束进行逐波段累加，形成适用于高光谱图像的 HTV(Hyperspectral TV, HTV) 模型，其定义如下：

$$\mathrm{HTV}(\mathbf{X}) = \sum_{j=1}^{B} \mathrm{TV}\left(\mathbf{X}_j\right) \tag{3.5}$$

其中，$\mathbf{X} = [\mathbf{X}_1, \ldots, \mathbf{X}_B]$ 表示高光谱图像，$\mathbf{X}_j$ 为其第 j 个波段。但由于不同地物在各光谱波段上的反射特性存在差异，不同波段间的梯度信息可能有所不同，这种梯度变化蕴含着额外的互补信息 [99]。因此，为更全面地刻画高光谱图像的结构信息，可进一步引入光谱方向上的梯度约束，构建空间-光谱全变分 SSTV(Spatial-Spectral Total Variation, SSTV) 模型：

$$\mathrm{SSTV}(\mathbf{X}) = \sum_{i=1}^{hw} \sum_{j=1}^{B} \sqrt{\left[\left(\nabla_i^1 \mathbf{X}\right)^2 + \left(\nabla_i^2 \mathbf{X}\right)^2 + \left(\nabla_i^3 \mathbf{X}\right)^2\right]_j} \tag{3.6}$$

其中，∇_i^s 代表光谱方向上的一阶差分算子。将 (3.6) 中的 SSTV 约束项代入损失函数

中国知网 https://www.cnki.net

(3.3)，可构建基于 SSTV 约束的高光谱图像去模糊模型：

$$L(\mathbf{X}) = \|\mathbf{Y} - \mathbf{H}\mathbf{X}\|^2 + \lambda \sum_{i=1}^{hw} \sum_{j=1}^{B} \sqrt{\left[(\nabla_i^1 \mathbf{X})^2 + (\nabla_i^2 \mathbf{X})^2 + (\nabla_i^3 \mathbf{X})^2\right]_j} \tag{3.7}$$

该模型综合考虑了空间和光谱维度上的分段平滑性，使得高光谱图像在去模糊的同时，能够更好地保持其结构特征。

3.3 基于局部极值约束总变分的图像非盲去模糊模型

为更清晰的表示所提方法的处理流程，图3.1 中描绘了 LECTV 如何利用模糊图像的先验信息联合总变分来复原潜在清晰图像，其中 $\odot$ 表示 Hadamard 乘积。具体地说，LECTV 通过利用像素信息以及模糊图像自身所反映的先验知识定义约束矩阵。随后，对梯度进行像素级约束，提升复原图像的结构一致性与细节保真度。更详细的内容将在后续小节中逐一介绍。

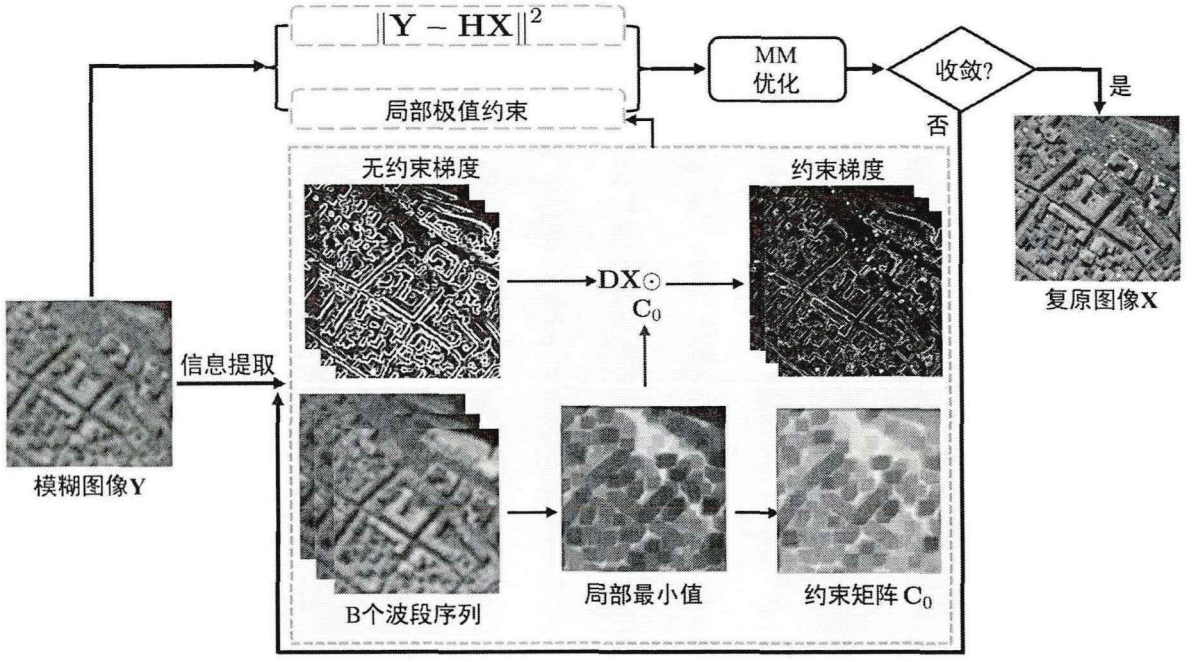

图 3.1 提出的 LECTV 图像去模糊方法框架

Fig. 3.1 Framework of the proposed LECTV image deblurring method

3.3.1 基于模糊先验的约束定义

在图像处理领域，DCP[111] 是一种基于局部邻域最小像素值的统计先验，在图像去模糊、去雾等任务中广泛应用。基于这一概念，该理论被进一步推广至多光谱及高光谱图像，其扩展定义如下：

$$\mathrm{P}(\mathbf{X})(p) = \min_{q \in \mathcal{N}(p)} \left\{ \min_{j \in \{1,..,B\}} \mathbf{X}^j(q) \right\} \tag{3.8}$$

中国知网 https://www.cnki.net

其中，p 和 q 分别表示像素位置，$\mathcal{N}(p)$ 为以 p 为中心的局部邻域，$\mathbf{X}^j$ 代表图像 $\mathbf{X}$ 在波段 j 处的像素值。当 $\mathbf{X}$ 为灰度图像时，显然 $\min_{j\in 1,\ldots,B}\mathbf{X}^j(q)=\mathbf{X}(q)$。

在现有研究中，DCP 通常以稀疏性假设的形式被用于正则化模型。本章基于以下事实定义新的约束项，即 DCP 由局部最小值定义，其能够有效捕捉图像的结构信息。如图3.2(d) 所示的局部最小像素相关值在一定程度上反映了图3.2(c) 的结构信息，这表明模糊图像的暗通道分布与空间结构具有相关性。因此，LECTV 考虑深入探索局部最小像素相关值，并根据其构建结构约束项，以期望能够基于模糊退化图像自身属性增强图像结构特征。

(a) 干净图像　(b) 模糊图像　(c) (a) 的梯度　(d) (b) 的局部最小像素相关值

图 3.2　局部最小像素的相关值与模糊图像空间结构关系

Fig. 3.2　The relationship between correlation values of the local minimum pixel and spatial structure of blurred image

基于对户外无雾干净图像的暗通道几乎为零的观察，He 等人[111] 提出了用于户外图像去雾的 DCP。受此启发，研究学者将 DCP 用于各种图像复原任务[112–114]。其中，Pan 等人[114] 发现模糊图像的暗通道大部分为非零值，清晰图像的暗通道更为稀疏。通过深入推导模糊（卷积）运算性质，将这一观察现象解释为局部块中像素的加权和大于最小值，也就是说，卷积增加了暗像素的值。因此，引入了 L_0 来约束暗通道的稀疏性，从而去除模糊干扰实现潜在干净图像的复原。在这之后一系列基于 DCP 的图像去模糊方法被相继提出，如极端通道[115]、非线性通道[116] 等。这类方法虽然取得了较好的结果，但具有相同的限制，即这类方法对图像暗通道整体施加稀疏约束，并未考虑图像中每个像素的具体情况。与采用暗通道的稀疏先验不同，LECTV 首先考虑了暗通道背后的局部最小值所蕴含的图像本质结构信息。基于模糊图像先验知识，本章设计一种像素级自适应约束矩阵 $\mathbf{C}_0(i)$，以提升图像纹理细节的复原，其定义如下：

$$\mathbf{C}_0(i)=\varepsilon\sqrt{(\mathbf{C}(i)} \tag{3.9}$$

中国知网　https://www.cnki.net

其中，ε 是一个常数，用于调整 $\mathbf{C}_0$ 的取值范围。$\mathbf{C}$ 为模糊图像的局部最小值矩阵，它可以根据模糊像素强度自适应的反映图像纹理结构，定义如下：

$$\mathbf{C}(i)=\begin{cases}\mathbf{P}\left(\mathbf{X}_0\right)(i), & \mathbf{P}\left(\mathbf{X}_0\right)(i)>0\\ \tau, & \text{otherwise}\end{cases} \tag{3.10}$$

其中，$\mathbf{P}\left(\mathbf{X}_0\right)$ 的定义见公式 (3.8)，τ 为大于零的常数，在本文中设置为 $\tau=10^{-6}$。

3.3.2 基于局部极值约束总变分模型

针对自然图像和高光谱图像去模糊问题，$\mathbf{C}_0$ 被融合到标准总变分约束，定义约束总变分正则项。所提约束总变分正则项分别记为 $\mathrm{LECTV}_{\mathrm{CTV}}$ 和 $\mathrm{LECTV}_{\mathrm{CHTV}}$，其中，$\mathrm{LECTV}_{\mathrm{CTV}}$ 仅在空间维度上进行梯度运算，而 $\mathrm{LECTV}_{\mathrm{CHTV}}$ 则能够更有效地利用高光谱图像的空间-光谱联合信息。具体如下：

$$\mathrm{LECTV}_{\mathrm{CTV}}(\mathbf{X})=\sum_{i=1}^{hw}\sqrt{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}\right)^2+\left(\nabla_i^2\mathbf{X}\right)^2\right]} \tag{3.11}$$

$$\mathrm{LECTV}_{\mathrm{CHTV}}(\mathbf{X})=\sum_{i=1}^{hw}\sum_{j=1}^{B}\sqrt{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}\right)^2+\left(\nabla_i^2\mathbf{X}\right)^2+\left(\nabla_i^3\mathbf{X}\right)^2\right]_j} \tag{3.12}$$

将公式 (3.12) 中的 $\mathrm{LECTV}_{\mathrm{CHTV}}$ 模型融入公式 (3.3)，可构建如下用于高光谱图像去模糊的 $\mathrm{LECTV}_{\mathrm{CHTV}}$ 的优化目标函数：

$$L(\mathbf{X})=\|\mathbf{Y}-\mathbf{H}\mathbf{X}\|^2+\lambda\sum_{i=1}^{hw}\sum_{j=1}^{B}\sqrt{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}\right)^2+\left(\nabla_i^2\mathbf{X}\right)^2+\left(\nabla_i^3\mathbf{X}\right)^2\right]_j} \tag{3.13}$$

其中，第一个保真项用于确保 $\mathbf{Y}$ 和 $\mathbf{H}\mathbf{X}$ 之间的相似性，第二项是定义的 $\mathrm{LECTV}_{\mathrm{CHTV}}$ 正则项。在公式 (3.13) 中，$\mathrm{LECTV}_{\mathrm{CHTV}}$ 正则项考虑了高光谱图像的多波段结构。相较于单独对每个波段进行去卷积，该模型能够生成更可靠的结果。此外，参数 λ 的设计也模糊图像先验信息，并根据波段强度自适应定义，具体定义见式 (3.27)-(3.28)。

类似地，将公式 (3.11) 融入公式 (3.3)，所提出的 $\mathrm{LECTV}_{\mathrm{CTV}}$ 方法可表示为：

$$L(\mathbf{X})=\|\mathbf{Y}-\mathbf{H}\mathbf{X}\|^2+\lambda\sum_{i=1}^{hw}\sqrt{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}\right)^2+\left(\nabla_i^2\mathbf{X}\right)^2\right]} \tag{3.14}$$

3.3.3 模型求解

令 $\mathbf{X}^{(k)}$ 表示第 k 次迭代中的图像，首先定义函数 $F\left(\mathbf{X}\mid\mathbf{X}^{(k)}\right)$，其满足以下条件：

$$F\left(\mathbf{X}^{(k)}\mid\mathbf{X}^{(k)}\right)=L\left(\mathbf{X}^{(k)}\right)\quad L(\mathbf{X})\leq F\left(\mathbf{X}\mid\mathbf{X}^{(k)}\right),\quad \mathbf{X}\neq\mathbf{X}^{(k)} \tag{3.15}$$

中国知网 https://www.cnki.net

其中，$F\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right)$ 是一个与 $\mathbf{X}$ 相关的函数，并且它为 $L(\mathbf{X})$ 提供了一个上界。假设 $\mathbf{X}^{(k+1)}$ 通过下式获得：

$$\mathbf{X}^{(k+1)} = \arg\min_{\mathbf{x}} F\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right) \tag{3.16}$$

由此，得出以下不等式：

$$L\left(\mathbf{X}^{(k+1)}\right) \leq F\left(\mathbf{X}^{(k+1)} \mid \mathbf{X}^{(k)}\right) \leq F\left(\mathbf{X}^{(k)} \mid \mathbf{X}^{(k)}\right) = L\left(\mathbf{X}^{(k)}\right) \tag{3.17}$$

LECTV 并未精确求解每个线性方程组，而是对相关的二次型函数进行了简化处理。根据文献 [117]，通过采用共轭梯度 (Conjugate Gradient, CG) 算法来实现这一过程。由于式 (3.13) 已经是二次型，因此对式 (3.12) 进行处理时，可以应用以下不等式：

$$\sqrt{a} \leq \sqrt{a_0} + \frac{1}{2\sqrt{a_0}}\left(a - a_0\right) \tag{3.18}$$

其中，对于任意 $a \geq 0$ 和 $a_0 \geq 0$，上述不等式成立。函数 F_{CHTV} 的定义为：

$$\begin{aligned} F_{\mathrm{CHTV}}\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right) = & \mathrm{CHTV}\left(\mathbf{X}^{(k)}\right) \\ & + \frac{1}{2}\sum_{i=1}^{hw}\sum_{j=1}^{B} \frac{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}\right)^2 + \left(\nabla_i^2\mathbf{X}\right)^2 + \left(\nabla_i^3\mathbf{X}\right)^2\right]_j}{\sqrt{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^2\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^3\mathbf{X}^{(k)}\right)^2\right]_j}} \\ & - \frac{1}{2}\sum_{i=1}^{hw}\sum_{j=1}^{B} \frac{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^2\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^3\mathbf{X}^{(k)}\right)^2\right]_j}{\sqrt{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^2\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^3\mathbf{X}^{(k)}\right)^2\right]_j}} \end{aligned} \tag{3.19}$$

上式中，$\mathbf{C}_0 = \mathbf{C}\left(\mathbf{X}^0\right)$ 为常数矩阵。对于任意 $\mathbf{X}, \mathbf{X}^{(k)}$ 满足 $F_{\mathrm{CHTV}}\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right) \geq \mathrm{CHTV}(\mathbf{X})$，且当且仅当 $\mathbf{X} = \mathbf{X}^{(k)}$ 时等式成立。因此，式 (3.19) 可以重写为：

$$\begin{aligned} F_{\mathrm{CHTV}}\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right) = & \frac{1}{2}\sum_{i=1}^{hw}\sum_{j=1}^{B} \frac{\mathbf{C}_{0_i}\left(\nabla_i^1\mathbf{X}\right)_j^2}{\sqrt{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^2\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^3\mathbf{X}^{(k)}\right)^2\right]_j}} \\ & + \frac{1}{2}\sum_{i=1}^{hw}\sum_{j=1}^{B} \frac{\mathbf{C}_{0_i}\left(\nabla_i^2\mathbf{X}\right)_j^2}{\sqrt{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^2\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^3\mathbf{X}^{(k)}\right)^2\right]_j}} \\ & + \frac{1}{2}\sum_{i=1}^{hw}\sum_{j=1}^{B} \frac{\mathbf{C}_{0_i}\left(\nabla_i^3\mathbf{X}\right)_j^2}{\sqrt{\mathbf{C}_{0_i}\left[\left(\nabla_i^1\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^2\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^3\mathbf{X}^{(k)}\right)^2\right]_j}} \\ & + \mathrm{T}\left(\mathbf{X}^{(k)}\right) \end{aligned} \tag{3.20}$$

中国知网 https://www.cnki.net

其中，$\mathrm{T}\left(\mathbf{X}^{(k)}\right)$ 是一个与 $\mathbf{X}$ 无关的常数。因此，$F_{\mathrm{CHTV}}\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right)$ 为 CHTV($\mathbf{X}$) 提供了一个二次型的上界。定义 $\mathbf{w}^{(k)}=w_i^{(k)}, i=1, \ldots, hw$，其中：

$$w_i^{(k)}=\frac{1}{\sqrt{\mathbf{C}_{0_i}\left[\left(\nabla_i^1 \mathbf{X}^{(k)}\right)^2+\left(\nabla_i^2 \mathbf{X}^{(k)}\right)^2+\left(\nabla_i^3 \mathbf{X}^{(k)}\right)^2\right]_j}} \tag{3.21}$$

此时，式 (3.20) 可以进一步简化为：

$$\begin{aligned} F_{\mathrm{CHTV}}\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right)=&\frac{1}{2} \sum_{i=1}^{hw}\left[\left[\mathbf{D}^3 \mathbf{X}\right]_i^2\left(\mathbf{C}_{0_i} \mathbf{w}_{j,i}\right)\right]+\mathrm{T}\left(\mathbf{X}^{(k)}\right) \\ &+\frac{1}{2} \sum_{i=1}^{hw}\left[\left[\mathbf{D}^1 \mathbf{X}\right]_i^2\left(\mathbf{C}_{0_i} \mathbf{w}_{j,i}\right)+\left[\mathbf{D}^2 \mathbf{X}\right]_i^2\left(\mathbf{C}_{0_i} \mathbf{w}_{j,i}\right)\right] \end{aligned} \tag{3.22}$$

其中，$\mathbf{D}^1, \mathbf{D}^2$ 和 $\mathbf{D}^3$ 分别表示沿 X 轴、Y 轴和 Z 轴的一阶差分算子。接下来，为了更清晰的重写上式，定义对角矩阵 $\mathbf{\Lambda}^{(k)}$ 如下：

$$\mathbf{\Lambda}^{(k)}=\operatorname{diag}\left(\mathbf{C}_{0_i} \mathbf{w}^{(k)}\right) \tag{3.23}$$

然后，利用式 (3.23)，F_{CHTV} 可以进一步表示为：

$$F_{\mathrm{CHTV}}\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right)=\mathbf{X}^T \mathbf{D}^T \Upsilon^{(k)} \mathbf{D X}+\mathrm{T}\left(\mathbf{X}^{(k)}\right) \tag{3.24}$$

其中，$\mathbf{D}=\left[(\mathbf{D}^1)^T(\mathbf{D}^2)^T(\mathbf{D}^3)^T\right]^T$，且 $\mathbf{\Upsilon}^{(k)}=\operatorname{diag}(\mathbf{\Lambda}^{(k)}, \mathbf{\Lambda}^{(k)}, \mathbf{\Lambda}^{(k)})$。将上述结果代入式 (3.13)，得到：

$$\begin{aligned} F\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right) &=\|\mathbf{Y}-\mathbf{H X}\|^2+\lambda \mathbf{X}^T \mathbf{D}^T \Upsilon^{(k)} \mathbf{D X}+\lambda \mathrm{T}\left(\mathbf{X}^{(k)}\right) \\ &=\mathbf{X}^T\left(\mathbf{H}^T \mathbf{H}+\lambda \mathbf{D}^T \Upsilon^{(k)} \mathbf{D}\right) \mathbf{X}-2 \mathbf{X}^T \mathbf{H Y}+\mathrm{T}'\left(\mathbf{X}^{(k)}\right) \end{aligned} \tag{3.25}$$

其中，$\mathrm{T}'\left(\mathbf{X}^{(k)}\right)$ 是一个与 $\mathbf{X}$ 无关的常数。

通过最小化式 (3.25)，可以得到：

$$\mathbf{X}^{(k+1)}=\left(\mathbf{H}^T \mathbf{H}+\lambda \mathbf{D}^T \Upsilon^{(k)} \mathbf{D}\right)^{-1} \mathbf{H}^T \mathbf{Y} \tag{3.26}$$

从式 (3.26) 可知，求解 $\mathbf{X}^{(k+1)}$ 等价于求解一个大型线性系统 $\mathbf{A}^{(k)} \mathbf{X}=\overline{\mathbf{Y}}$，其中，矩阵 $\mathbf{A}$ 定义为 $\mathbf{A} \equiv \mathbf{H}^T \mathbf{H}+\lambda \mathbf{D}^T \Upsilon^{(k)} \mathbf{D}$。而向量 $\overline{\mathbf{Y}}$ 计算为 $\overline{\mathbf{Y}}=\mathbf{H}^T \mathbf{Y}$。为求解该线性系统，本章采用了 CG 算法迭代更新 $F\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right)$，确保该函数相对于 $\mathbf{X}$ 单调递减，从而达到收敛目标。

算法3.1概述了应用 MM 技术优化并求解所提 LECTV 图像去模糊算法的关键步

中国知网 https://www.cnki.net

骤。所提算法3.1中，K 为 MM 算法的最大迭代次数，本章将其设置为 $K=20$，CG 最大迭代次数设置为 $T=200$，ε 为 CG 迭代阈值，λ 为正则化参数。

Algorithm 3.1 基于 LECTV 的图像去模糊算法

输入: 退化图像 Y，参数 ε，迭代次数 K;
输出: 复原结果 X;

while $0 \leq k < K$ **do**
根据 (3.9) 计算 $\mathbf{C}_0$;
根据 (3.27) 或 (3.28) 计算 λ;
基于 (3.21), (3.22) 和 (3.23) 计算矩阵 $\mathbf{\Lambda}^{(k)}$;
根据 (3.25) 计算 $F\left(\mathbf{X} \mid \mathbf{X}^{(k)}\right)$;
$\mathbf{X}^{(k+1)} := \mathbf{X}^{(k)}$;
由 $\mathbf{A}^{(k)}\mathbf{X} = \overline{\mathbf{Y}}$ 求解 $\mathbf{X}^{(k+1)}$;
$k \leftarrow k+1$;
end while

受文献 [118] 启发，本章提出了一种新的自适应 λ 设计方法，该方法中 λ 值与模糊像素密切相关，其能够根据模糊图像的自身强度进行动态调整，并且在高光谱图像中每个波段也能够实现自适应调整。具体如下：

对于灰度图像，λ 的表达式则可以写为：

$$\lambda^{(k)} = \frac{\rho\sigma^2}{\frac{1}{\mathbf{C}_{0_i}}\left[\left(\nabla_i^1\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^2\mathbf{X}^{(k)}\right)^2\right] + \beta} \tag{3.27}$$

对于高光谱图像，λ 的表达式则可以写为：

$$\lambda^{(k)} = \frac{\rho\sigma^2}{\frac{1}{\mathbf{C}_{0_i}}\left[\left(\nabla_i^1\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^2\mathbf{X}^{(k)}\right)^2 + \left(\nabla_i^3\mathbf{X}^{(k)}\right)^2\right]_j + \beta} \tag{3.28}$$

其中，$\rho = 2(\alpha + \theta hw)$，$\sigma$ 表示零均值高斯噪声的标准差。ρ、β 和 θ 的取值与对比算法[118] 保持一致。由公式 (3.27) 和 (3.28) 中的定义可见，本章所定义的 λ 具有自适应特性，无需手动调整不同波段。此外，在高光谱图像处理中，每个波段均可独立自适应调整 λ，这使得该方法更适用于不同波段的去模糊。

3.4 实验验证与分析

1）实验数据

本次实验采用三个自然图像数据集和多个高光谱图像数据集。自然图像数据集包括：文献 [119] 中的数据集 (记为 Dataset1)，包含 20 张灰度图像；文献 [120] 中的数据集 (记为 Dataset2)，包含 9 张彩色图像和 6 张灰度图像；以及文献 [121] 中的数据集 (记为 Dataset3)，包含 100 张图像。在高光谱图像实验中，使用 CAVE 数据集、Pavia University 数据集、Urban 数据集和 Pavia City 数据集来验证所提方法的有效性。其中，CAVE 数据集包含了 32 幅图像，每幅图像空间尺寸为 512×512，由 31 个光谱波段

中国知网 https://www.cnki.net

组成。高光谱数据包括 Pavia University（610×340×103）、Urban（307×307×162）和 Pavia Center(200×200×191)，这些数据广泛用于高光谱图像去模糊研究[16,17,20,122]。此外，Pavia University 和 Pavia City 数据常被用于高光谱图像分类研究。Urban 数据被截取用于高光谱异常检测研究。

为展示 LECTV 在不同退化环境下的适应性，实验中设计了七种模拟退化情景，具体如下所示：

1. G_A: 高斯噪声标准差 $\delta = 1.6$，噪声标准差 $\sigma = 0.00006$(平均 PSNR 为 24.30 dB)；
2. G_B: 高斯噪声标准差 $\delta = 3$，噪声标准差 $\sigma = 0.0001$(平均 PSNR 为 22.91 dB)；
3. G_C: 高斯噪声标准差 $\delta = 5$，噪声标准差 $\sigma = 0.0001$(平均 PSNR 为 22.55 dB)；
4. S_A: 方形核边长 $s = 9$，噪声标准差 $\sigma = 0.00006$(平均 PSNR 为 21.48 dB)；
5. S_B: 方形核边长 $s = 13$，噪声标准差 $\sigma = 0.00006$(平均 PSNR 为 20.31 dB)；
6. M_A: 运动模糊核位移 20 像素，角度 15 度，噪声标准差 $\sigma = 0.0002$(平均 PSNR 为 20.75 dB)；
7. M_B: 运动模糊核位移 35 像素，角度 45 度，噪声标准差 $\sigma = 0.0002$(平均 PSNR 为 18.65 dB)。

其中，平均 PSNR 值是基于所有数据集 (包括 Dataset1、Dataset2 和 Dataset3) 的计算结果。图像复原质量评价采用了广泛使用的 PSNR、SSIM、SAM 和 ERGAS 进行综合评估。

3.4.1 局部极值约束有效性分析

本小节首先验证所提方法中局部极值约束项的有效性，具体如下：

(1) 对梯度的影响：为验证提出的局部极值约束对图像梯度的影响，图 3.3 分别绘制了退化图像 (由 G_A 生成) 的无约束梯度与施加 $\mathbf{C}_0$ 约束的梯度对比。可以看到，相

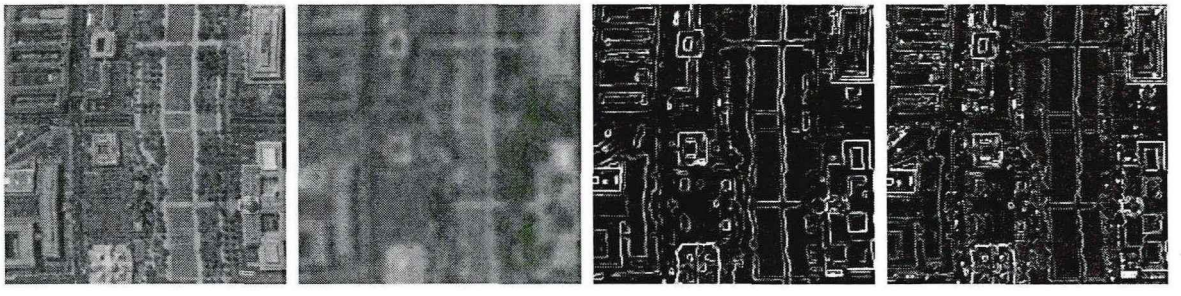

(a) 干净图像　(b) 模糊图像　(c) (b) 的无约束梯度　(d) (b) 的约束梯度

图 3.3　退化图像的无约束梯度和约束梯度对比

Fig. 3.3　Comparison of unconstrained and constrained gradients of degraded image

比较于图 3.3(c) 中的无约束梯度，加入 $\mathbf{C}_0$ 约束后的梯度 (图 3.3(d)) 能够有效捕捉图像中更细致的纹理结构，更加生动的描绘图像纹理细节和更为清晰的边界，其反映的结构信息比无约束版本更加清晰和可靠。

中国知网 https://www.cnki.net

(2) 对性能的影响：为分析局部极值约束对图像去模糊性能的有效性，本小节对比分析了基于标准总变分模型到去模糊方法和本章所提 LECTV 算法的复原性能。通过将基于标准总变分模型的方法 [118] 与所提 $\text{LECTV}_{\text{CTV}}$ 在 Dataset1、Dataset2 和 Dataset3 数据上实验结果进行统计。实验选择了四种退化案例：G_A、G_B、S_A 和 S_B。图 3.4 和图 3.5 显示了不同退化情形下，复原结果的平均 PSNR 和 SSIM 值。实验结果表明，所提 LECTV 算法的复原结果在各项指标上均优于标准总变分模型，验证了所提方法的有效性。

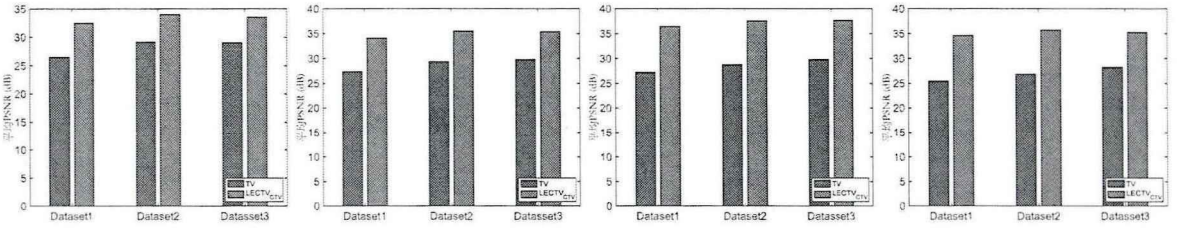

(a) G_A (b) G_B (c) S_A (d) S_B

图 3.4 TV 和 $\text{LECTV}_{\text{CTV}}$ 的平均 PSNR

Fig. 3.4 The average PSNR of TV and $\text{LECTV}_{\text{CTV}}$

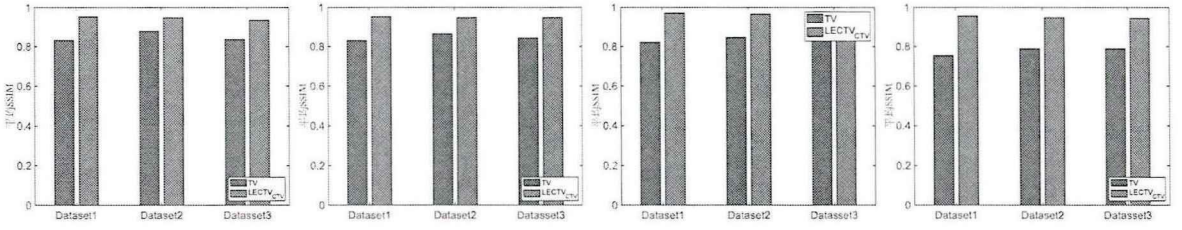

(a) G_A (b) G_B (c) S_A (d) S_B

图 3.5 TV 和 $\text{LECTV}_{\text{CTV}}$ 的平均 SSIM

Fig. 3.5 The average SSIM of TV and $\text{LECTV}_{\text{CTV}}$

除了上述定量评估外，图 3.6 为 G_A 和 S_A 退化案例下的视觉复原示例。第一行和第二行分别显示了由 G_A 和 S_A 退化图像的复原结果。结果表明，基于标准总变分模型的复原结果在局部细节上仍存在一定程度的模糊现象，而 $\text{LECTV}_{\text{CTV}}$ 在细节恢复方面表现出色，尤其在蝴蝶翅膀同质区域上的细节纹理和小女孩脸部斑点和头发纹理处所题方法表现出了显著优势。由此可见，局部极值约束能够有效地补偿图像的细节信息，使得恢复结果更加清晰可靠。

3.4.2 自然图像上实验

自然图像数据集上实验的对比方法包括超拉普拉斯先验方法 (Hyper-laplacian prior, HL)[123]、自适应 TV(Adaptive Total Variation, TV) 去模糊算法[118]、基于导数交替方向优化的快速全变分图像恢复 (Fast total-variation based image restoration based

中国知网 https://www.cnki.net

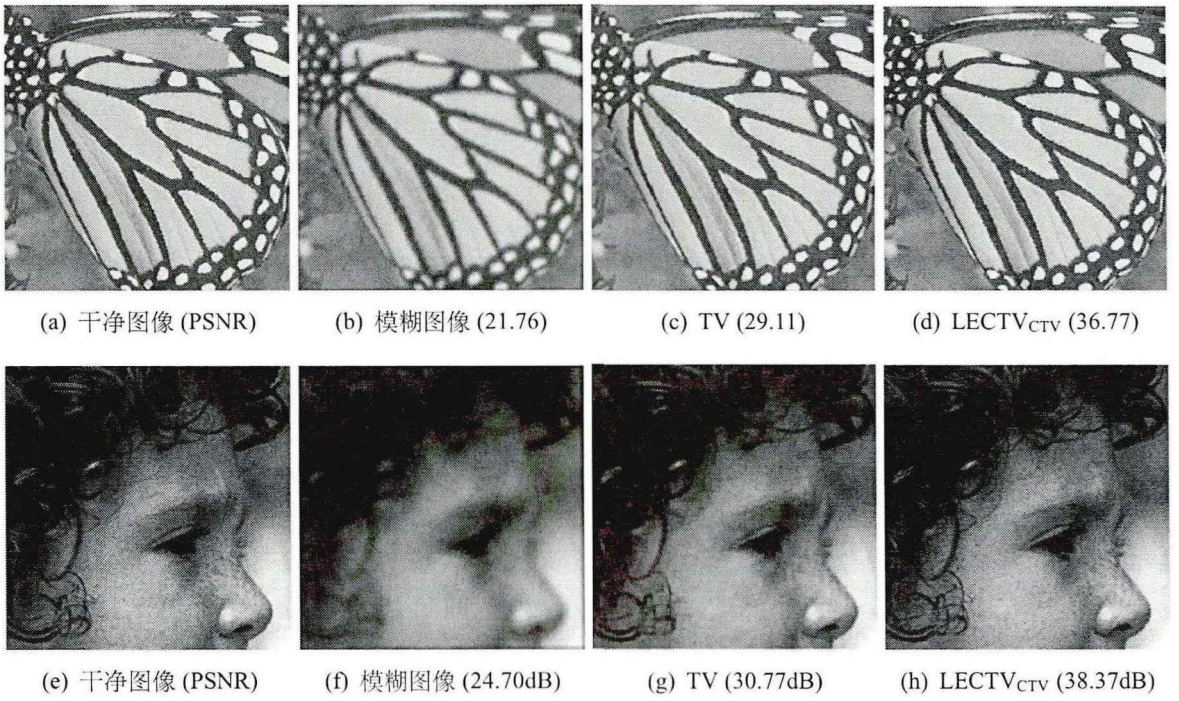

(a) 干净图像 (PSNR) (b) 模糊图像 (21.76) (c) TV (29.11) (d) LECTV$_{CTV}$ (36.77)

(e) 干净图像 (PSNR) (f) 模糊图像 (24.70dB) (g) TV (30.77dB) (h) LECTV$_{CTV}$ (38.37dB)

图 3.6 TV 和 LECTV$_{CTV}$ 复原的视觉示例

Fig. 3.6 Visual example restored by TV and LECTV$_{CTV}$

on derivative alternated direction optimization, ADMM) [124]、非局部集中稀疏表示 (Non-locally centralized sparse representation，NCSR)[125]、级联收缩场 (Cascade of shrinkage fields, CSF)[119]、全卷积网络学习方法 (Learning fully convolutional networks, LFCNN)[126]、SelfDeblur [127]、MPRNet[128]、快速两步盲光学像差校正 (Fast Two-step Optical Aberration Correction, FTOAC)[129] 和 INFWIDE [130]。

表3.1-3.3 分别为不同方法在 Dataset1、Dataset2 和 Dataset3 上的平均性能 (PSNR/SSIM)。表中实验结果表明，首先，在多个数据集和退化案例下，所提 LECTV$_{CTV}$ 方法在几乎所有情况下都达到了最高的 PSNR 和 SSIM 值，验证了 LECTV$_{CTV}$ 的优越性能。其次，对比三个数据集上的实验结果，HL 和 CSF 在 S_A、S_B、M_A 和 M_B 案例下的性能显著下降。ADMM 和 LFCNN 在 S_A、S_B 和 M_B 案例下的性能也有所下降。NCSR 在 S_B 案例下的也未能保持先前的优势。四种基于深度学习的方法：MPRNet、SelfDeblur、FTOAC 和 INFWIDE 在两种运动模糊 (M_A 和 M_B) 退化案例下的性能也明显降低，这也反映了基于深度学习的方法在泛化能力上的局限性。基于标准总变分的方法在 S_B 和 M_B 案例下的性能也存在下降情况。相比之下，所提 LECTV$_{CTV}$ 方法在不同的模糊核和数据集上表现出稳定且优越的性能，验证了 LECTV$_{CTV}$ 在复原图像上的鲁棒性和有效性。最后，与标准总变分模型相比，LECTV$_{CTV}$ 在不同退化案例和数据集上所表现出的优秀性能也说明了所提出的局部极值约束对于总变分模型性能提升的促进作用。

定量评估通过数值分析客观的衡量不同方法的复原性能，而定性评估则从视觉感

中国知网 https://www.cnki.net

表 3.1 不同方法在 Dataset1 数据集上的定量评估

Tab. 3.1 Quantitative evaluation of different methods on Dataset1

案例	指标	HL	ADMM	NCSR	CSF	LFCNN	MPRNET	SelfDeblur	FTOA	CINFWIDE	TV	LECTV$_{CTV}$
G_A	PSNR	24.84	25.76	30.82	23.51	25.56	22.93	24.05	23.12	25.33	26.48	**32.51**
	SSIM	0.7714	0.8148	0.9245	0.7369	0.7930	0.6626	0.6990	0.7126	0.7111	0.8306	**0.9536**
G_B	PSNR	23.94	26.23	31.52	22.32	24.77	22.13	23.90	20.97	24.33	27.34	**34.06**
	SSIM	0.7033	0.8074	0.9141	0.6586	0.7494	0.5753	0.6538	0.5222	0.6588	0.8286	**0.9527**
G_C	PSNR	24.24	26.73	32.86	22.20	25.17	22.12	25.16	20.41	24.69	28.13	**36.26**
	SSIM	0.7112	0.826	0.9318	0.6528	0.7662	0.5712	0.7078	0.4681	0.6742	0.8514	**0.9687**
S_A	PSNR	23.24	25.42	32.12	21.26	24.06	21.80	24.71	19.62	24.19	27.20	**36.45**
	SSIM	0.6528	0.7707	0.9262	0.5864	0.7121	0.5360	0.6799	0.3766	0.6542	0.8214	**0.9716**
S_B	PSNR	21.58	23.23	29.07	20.04	22.14	20.61	22.93	19.03	22.69	25.45	**34.61**
	SSIM	0.5524	0.6574	0.8694	0.4923	0.5997	0.4630	0.5790	0.3345	0.5905	0.7536	**0.9566**
M_A	PSNR	23.72	26.46	35.28	21.00	20.54	24.29	19.61	19.23	22.09	30.60	**36.78**
	SSIM	0.7003	0.8246	0.9524	0.5991	0.6186	0.7090	0.4033	0.4435	0.6230	0.9049	**0.9616**
M_A	PSNR	21.32	23.07	33.77	18.53	19.66	17.30	18.26	17.79	20.93	25.70	**35.56**
	SSIM	0.5667	0.6842	0.9293	0.4442	0.5407	0.2998	0.3613	0.3378	0.5694	0.7664	**0.9494**

表 3.2 不同方法在 Dataset2 数据集上的定量评估

Tab. 3.2 Quantitative evaluation of different methods on Dataset2

案例	指标	HL	ADMM	NCSR	CSF	LFCNN	MPRNET	SelfDeblur	FTOA	CINFWIDE	TV	LECTV$_{CTV}$
G_A	PSNR	27.47	28.11	32.28	25.58	26.09	23.22	25.02	23.61	26.41	29.10	**34.97**
	SSIM	0.8347	0.8546	0.9313	0.8097	0.8448	0.8092	0.8501	0.8322	0.8600	0.8763	**0.9490**
G_B	PSNR	26.39	28.18	33.12	24.27	25.36	22.93	24.74	21.69	25.45	29.35	**35.52**
	SSIM	0.7863	0.8390	0.9241	0.7466	0.8068	0.7841	0.8234	0.7331	0.8304	0.8632	**0.9477**
G_C	PSNR	26.50	28.47	34.31	24.08	25.50	23.29	25.69	21.16	25.74	29.93	**37.36**
	SSIM	0.7849	0.8469	0.9367	0.7370	0.8088	0.7938	0.8393	0.7033	0.8373	0.8729	**0.9624**
S_A	PSNR	25.19	27.14	32.86	22.93	24.51	22.93	25.41	20.24	25.04	28.80	**37.56**
	SSIM	0.7354	0.8065	0.9175	0.6754	0.7682	0.7711	0.8172	0.6416	0.8251	0.8458	**0.9670**
S_B	PSNR	23.40	24.93	29.75	21.57	22.93	21.21	24.06	19.17	23.44	26.82	**35.68**
	SSIM	0.6578	0.7245	0.8608	0.5974	0.6937	0.7024	0.7543	0.5889	0.7908	0.7875	**0.9484**
M_A	PSNR	25.24	27.72	35.73	22.21	21.90	25.00	19.01	18.76	23.22	31.92	**38.42**
	SSIM	0.7497	0.8390	0.9435	0.6636	0.6843	0.8265	0.5981	0.6103	0.8083	0.9065	**0.9541**
M_B	PSNR	23.16	24.92	34.04	20.20	21.02	17.82	18.01	17.38	21.34	28.21	**37.64**
	SSIM	0.6697	0.7580	0.9168	0.5657	0.6586	0.5701	0.5817	0.5488	0.7655	0.8334	**0.9458**

知角度筛选出更自然、真实的复原结果图。因此，视觉上的真实和自然对于性能评估同样具有重要意义。为直观评估恢复结果的可靠性，本节在不同图像上选取了三种退化案例进行分析。图 3.7-3.9 分别展示了 G_A、S_A 和 M_A 退化案例下的模糊图像及其相应的各算法复原结果图。从图 3.7-3.9 可以直观地看出，所提 LECTV$_{CTV}$ 方法的复原结果在视觉上始终优于其他对比方法，尤其在图像细节方面表现出色。具体而言，与其他方法相比，LECTV$_{CTV}$ 的恢复结果呈现出更清晰的边缘和纹理结构。这一点在放大区域中尤为明显，例如花朵的花蕊和鹦鹉的面部特征。这些结果证实了 LECTV$_{CTV}$

中国知网 https://www.cnki.net

表 3.3 不同方法在 Dataset3 数据集上的定量评估

Tab. 3.3 Quantitative evaluation of different methods on Dataset3

案例	指标	HL	ADMM	NCSR	CSF	LFCNN	MPRNET	SelfDeblur	FTOAC	INFWIDE	TV	LECTV$_{CTV}$
G_A	PSNR	27.17	27.91	31.85	26.11	25.87	24.36	24.86	23.95	25.68	29.02	**33.50**
	SSIM	0.7677	0.8043	0.9195	0.7509	0.7680	0.8174	0.8274	0.8217	0.8496	0.8359	**0.9359**
G_B	PSNR	26.26	27.90	33.01	25.09	25.28	23.76	24.34	22.73	24.45	29.84	**35.40**
	SSIM	0.7111	0.7864	0.9297	0.6922	0.7217	0.7822	0.7998	0.7511	0.8158	0.8424	**0.9483**
G_C	PSNR	26.37	28.24	34.12	24.99	25.44	23.72	24.70	22.29	25.20	30.57	**37.00**
	SSIM	0.7111	0.8023	0.9410	0.6882	0.7277	0.7797	0.8117	0.7266	0.8342	0.8625	**0.9615**
S_A	PSNR	25.43	27.10	32.76	24.14	24.73	23.02	24.55	21.62	24.92	29.82	**37.64**
	SSIM	0.6655	0.7516	0.9226	0.6390	0.6855	0.7536	0.8056	0.6882	0.8283	0.8405	**0.9690**
S_B	PSNR	24.13	25.28	29.93	23.08	23.68	22.01	23.69	20.98	23.74	28.21	**35.22**
	SSIM	0.6000	0.6596	0.8662	0.5761	0.6230	0.7188	0.7754	0.6664	0.8000	0.7879	**0.9447**
M_A	PSNR	25.95	28.13	37.04	24.20	23.91	24.85	20.70	20.61	23.59	33.53	**37.28**
	SSIM	0.7108	0.8113	**0.9613**	0.670	0.6885	0.8346	0.6667	0.6739	0.8189	0.9203	0.9432
M_B	PSNR	23.93	25.41	33.64	22.17	22.57	19.11	19.93	19.41	21.90	28.76	**36.42**
	SSIM	0.6140	0.7017	0.9238	0.5597	0.6020	0.6258	0.6653	0.6273	0.7697	0.7924	**0.9336**

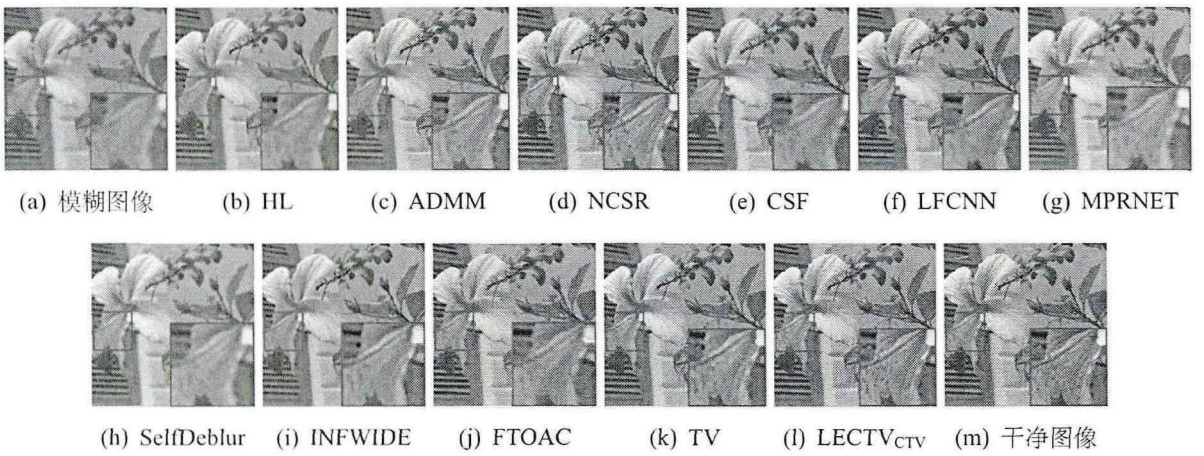

(a) 模糊图像 (b) HL (c) ADMM (d) NCSR (e) CSF (f) LFCNN (g) MPRNET

(h) SelfDeblur (i) INFWIDE (j) FTOAC (k) TV (l) LECTV$_{CTV}$ (m) 干净图像

图 3.7 视觉示例：G_A

Fig. 3.7 Visual examples: G_A

通过结合像素信息与模糊图像的先验知识提出的像素级复原方法，在复原模糊图像的细节纹理方面具有显著优势。

此外，本节还将 LECTV$_{CTV}$ 方法与使用标准总变分方法的收敛性进行了对比。图 3.10 为 Flower 图像 (G_A, PSNR: 24.91dB) 上，标准总变分方法与 LECTV$_{CTV}$ 方法在恢复过程中的 PSNR 值和相对误差值随着迭代次数的变化情况。可以看出，随着迭代次数的增加，LECTV$_{CTV}$ 的相对误差能够更快的趋于零，这表明该方法在收敛速度上的优势，即所提方法能够在更少的迭代次数内获得稳定的恢复结果，且对应的 PSNR 值始终高于标准总变分方法的结果。

中国知网 https://www.cnki.net

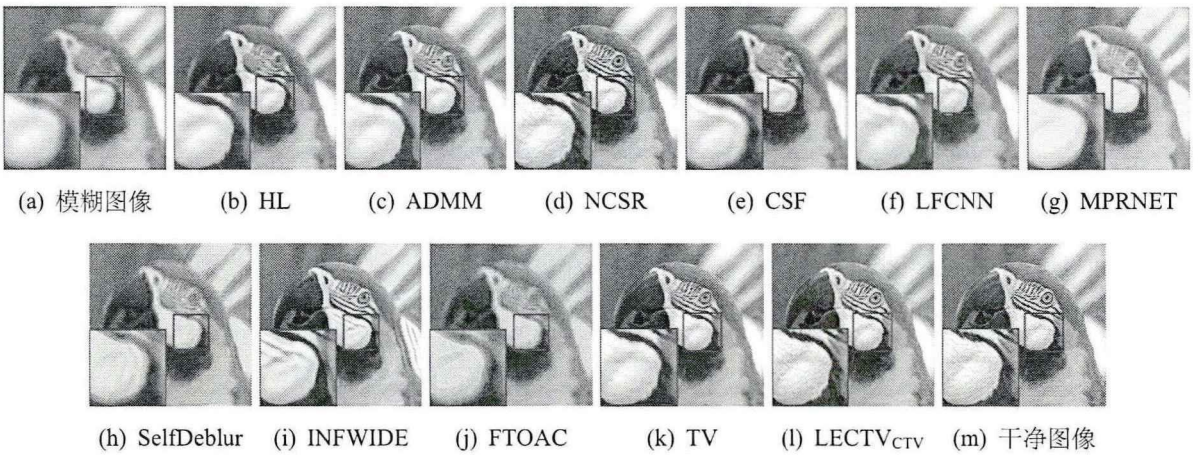

图 3.8　视觉示例：S_A

Fig. 3.8　Visual examples: S_A

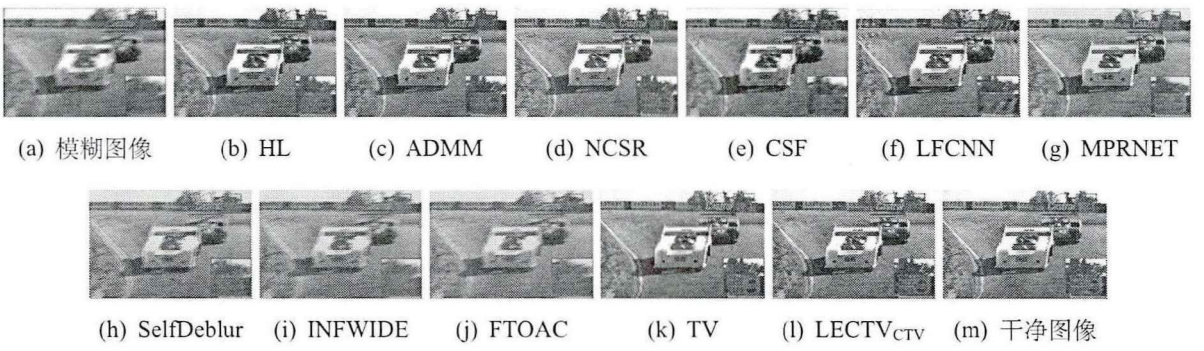

图 3.9　视觉示例：M_A

Fig. 3.9　Visual examples: M_A

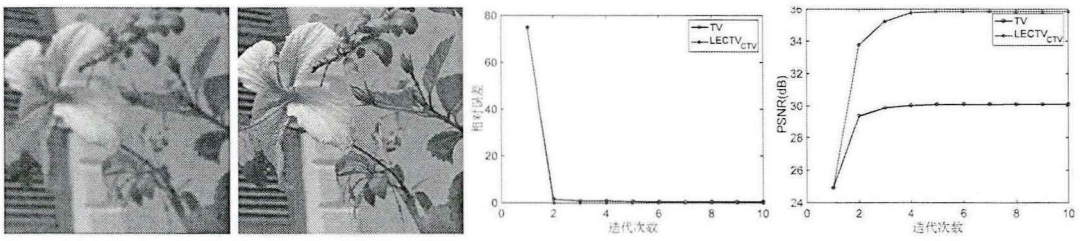

图 3.10　TV 和 LECTV$_{CTV}$ 复原过程中相对误差和 PSNR 值的演变

Fig. 3.10　Evolution of relative error and PSNR during the restoration process of TV and LECTV$_{CTV}$

3.4.3　高光谱图像上实验

LECTV$_{CHTV}$ 通过挖掘高光谱图像中相邻波段间的光谱冗余性，有效利用未受干扰波段的信息对受损波段进行补偿，可增强复原结果的稳定性与光谱一致性。这些特性使得 LECTV$_{CHTV}$ 更适用于高光谱数据。相较于单一波段的去模糊策略，多波段去

中国知网　https://www.cnki.net

模糊的方式能够提供更加稳定和可靠的恢复结果。为验证所提出方法在高光谱数据上的有效性，本小节采用 LECTV(包括 $\text{LECTV}_{\text{CTV}}$ 和 $\text{LECTV}_{\text{CHTV}}$) 进行实验，并与包括 HL [123]、FPD [131]、SSTV [23]、WLRTR [16] 和 OLRT [17] 在内的六种图像去模糊方法进行对比分析。在这一节的实验中，分别采用标准差为 3(案例 A) 和 5(案例 B) 的高斯模糊核生成退化图像，并叠加额外的高斯噪声以模拟真实退化情况。

1) CAVE 数据集上实验结果分析：不同方法在 CAVE 数据上实验的定量评估结果在表 3.4 中给出。可以看到，所提出 LECTV 方法以及对比方法均能够有效提升退化图像的质量。从空间和光谱质量上看，LECTV 方法在所有定量指标上均优于 FPD、SSTV、HL、WLRTR 和 OLRT 方法。具体来说，在案例 B 设定下，$\text{LECTV}_{\text{CHTV}}$ 在 PSNR、SSIM、SAM 和 ERGAS 四个指标上均取得最佳结果，而 $\text{LECTV}_{\text{CTV}}$ 在所有指标上排名次优。在案例 A 设定下，$\text{LECTV}_{\text{CTV}}$ 在 PSNR、SSIM 和 SAM 指标上表现最佳，$\text{LECTV}_{\text{CHTV}}$ 在 ERGAS 指标上表现最佳。此外，尽管 WLRTR 和 OLRT 在定量评估中表现较优，但其计算成本较高，运行时间显著长于 LECTV。HL 在计算效率（时间/秒）方面具有显著优势。从图 3.11 所示的视觉复原结果可以看到，HL 在多光谱图像的复原任务中表现不佳，无法有效恢复图像细节。相比之下，SSTV 和 FPD 虽然在视觉质量上有所提升，但仍未能提供理想的修复效果。相较于这些方法，WLRTR、OLRT 以及所提 LECTV 方法在恢复细节信息方面表现更为出色，能够更精确地重建边缘结构和纹理特征，生成更加清晰、真实的复原图像。此外，图 3.12 绘制了“fake and real strawberries”数据中各波段对应的 PSNR 和 SSIM 变化曲线。结果表明，WLRTR、OLRT 及 LECTV 在 SSIM 和 PSNR 方面均处于较优水平，并显著优于 HL、FPD 和 SSTV 。通过进一步分析表 3.4 的定量结果，LECTV 在几乎所有光谱波段上均取得最佳 PSNR 和 SSIM 值，同时其平均 PSNR 和 SSIM 也优于 WLRTR 和 OLRT。这些结果证实了所提 LECTV 方法在多光谱图像去模糊任务中的有效性和优越性，表明了像素级约束总变分带来的去模糊优势。

表 3.4　不同方法在 Cave 数据集上的定量评估结果

Tab. 3.4　Quantitative evaluation results of different methods on Cave dataset

	方法	HL	FPD	SSTV	WLRTR	OLRT	$\text{LECTV}_{\text{CTV}}$	$\text{LECTV}_{\text{CHTV}}$
案例 A	PSNR	38.06	43.41	36.74	48.45	48.78	50.84	**50.89**
	SSIM	0.9535	0.9810	0.9490	0.9904	0.9904	0.9944	**0.9946**
	SAM	0.0657	0.0626	0.0699	0.0991	0.1025	0.0535	**0.0519**
	ERGAS	75.86	41.97	88.79	21.12	20.11	16.48	**16.03**
	时间/秒	**5.86**	88.63	317.23	1129.20	854.84	540.45	700.50
案例 B	PSNR	38.19	43.78	36.31	49.51	50.02	52.19	**52.30**
	SSIM	0.9523	0.9814	0.9459	0.9920	0.9926	0.9956	**0.9959**
	SAM	0.0901	0.0672	0.0647	0.0740	0.0909	0.0514	**0.0475**
	ERGAS	74.38	39.91	91.60	18.50	17.33	13.94	**13.50**
	时间/秒	**5.72**	93.33	303.81	1124.33	848.98	580.10	625.21

中国知网 https://www.cnki.net

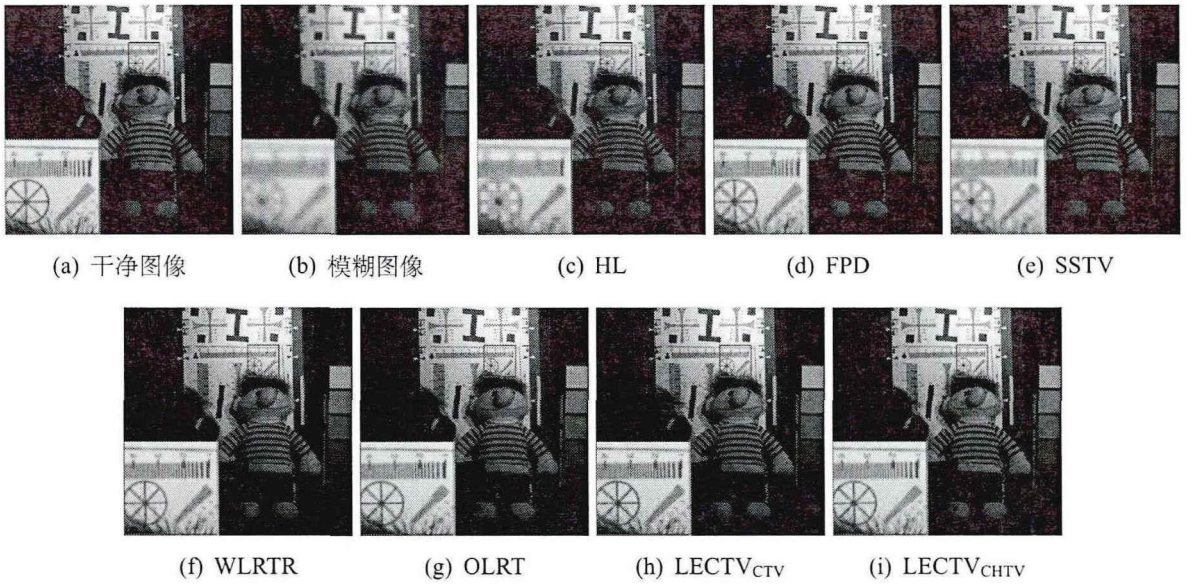

图 3.11　chart and stuffed toy 上的复原结果的视觉示例 (波段 24)

Fig. 3.11　Visual examples of restoration results on chart and stuffed toy (band 24)

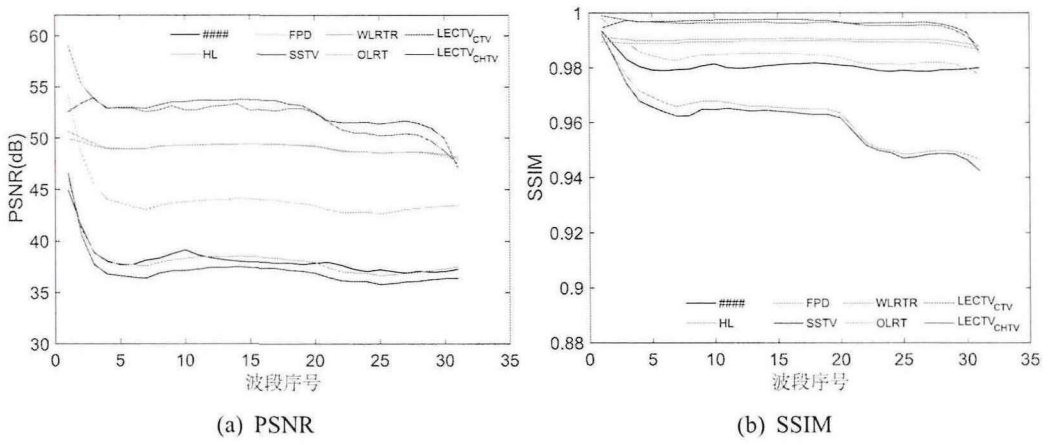

图 3.12　fake and real strawberries 数据中每个波段的 PSNR 和 SSIM 值 (案例 A)

Fig. 3.12　PSNR and SSIM values of each band on fake and real strawberries data (Case A)

为进一步评估各方法对光谱信息的恢复能力，图 3.13绘制了不同方法复原后的光谱曲线以及它们与原始光谱进行对比，并在图例中给出了皮尔逊相关系数 (Pearson correlation coefficients，P) 和均方根误差 (Root Mean Square Error，R) 值，衡量复原光谱与真实光谱之间的相似性。具体来说，图 3.13(a) 显示了"chart and stuffed toy" 数据中空间位置 (326, 136) 处的光谱曲线，而图 3.13(b) 对应于"stuffed toys" 数据中空间位置 (373, 64) 处的光谱曲线。通过采用 SAM 和 ERGAS 指标对复原光谱的准确性进行量化，表3.4汇总了不同方法复原图像的光谱质量评估结果。从表 3.4 中案例 A 的实验结果来看，LECTV$_{CTV}$ 在 SAM 指标上取得了最佳结果，LECTV$_{CHTV}$ 在 ERGAS 指标上表现最优。在案例 B 设定下，LECTV$_{CHTV}$ 和 LECTV$_{CTV}$ 分别在 SAM 和 ERGAS 指

中国知网　https://www.cnki.net

标上取得最优与次优结果。这些实验结果表明所提 LECTV 方法能够有效恢复图像的光谱信息，在光谱保真度方面显著优于对比方法。

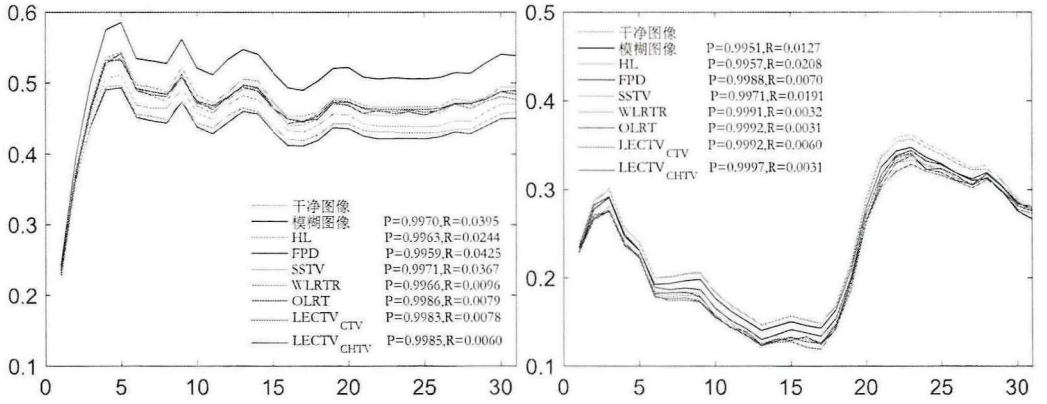

(a) chart and stuffed toy (326,136)　　(b) stuffed toys (373, 64)

图 3.13　光谱曲线及其定量指标

Fig. 3.13　Spectral curves and their quantitative metrics

2) 高光谱图像上实验结果分析：表 3.5 为不同方法在高光谱图像数据集上的定量评估结果。如表所示，LECTV 依旧具有出色的表现。更具体地说，$\text{LECTV}_{\text{CHTV}}$ 在 PSNR、SSIM 和 ERGAS 三个定量指标上达到了最佳值，并在 SAM 指标上取得了次优表现。图 3.14 为 Urban 数据每个波段复原结果的 PSNR 和 SSIM 值。从图中可以看到，LECTV、WLRTR 和 OLRT 的曲线位于第一梯队，整体优于 FPD、SSTV 和 HL。特别地，$\text{LECTV}_{\text{CHTV}}$ 在几乎所有波段的 PSNR 和 SSIM 值上均表现出色，达到了最高值，$\text{LECTV}_{\text{CTV}}$ 也取得了优异的性能。此外，从表 3.5 中的时间指标可以发现，LECTV 的计算时间显著低于基于张量的 OLRT 和 WLRTR，这凸显了所提出 LECTV 方法在效率与性能方面的优势。

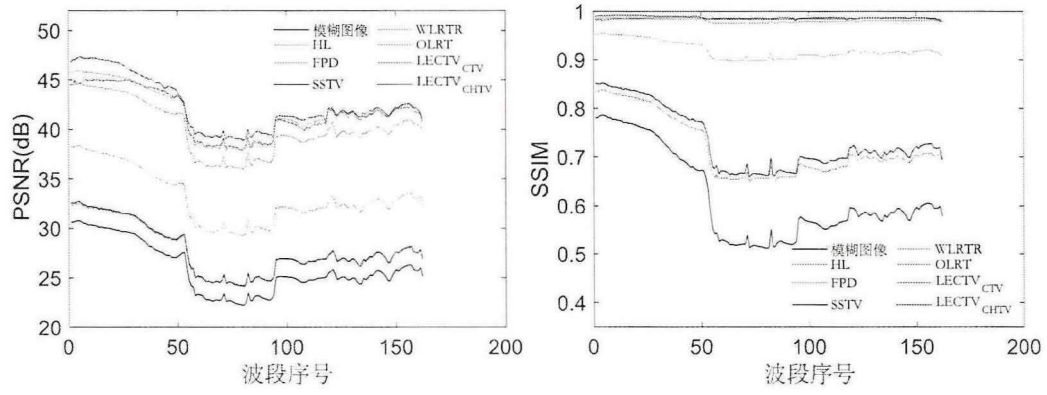

(a) PSNR　　(b) SSIM

图 3.14　Urban 数据（案例 A）中每个波段的 PSNR 和 SSIM 值

Fig. 3.14　PSNR and SSIM values of each band on Urban (Case A)

中国知网　https://www.cnki.net

表 3.5　不同方法在高光谱图像数据集上的定量评估

Tab. 3.5　Quantitative evaluation of different methods on HSI Dataset

	方法	HL	FPD	SSTV	WLRTR	OLRT	$\text{LECTV}_{\text{CTV}}$	$\text{LECTV}_{\text{CHTV}}$
案例 A	PSNR	28.42	33.16	28.59	40.52	42.01	42.19	**42.53**
	SSIM	0.7582	0.9209	0.7760	0.9799	0.9847	0.9853	**0.9863**
	SAM	0.0887	0.0608	0.0873	0.0399	**0.0365**	0.0390	0.0374
	ERGAS	153.31	88.84	150.50	38.34	32.35	31.53	**30.49**
	时间/秒	**14.11**	176.69	622.91	2435.01	1739.05	1044.47	1401.42
案例 B	PSNR	28.25	33.59	29.53	42.15	43.56	43.69	**44.14**
	SSIM	0.7474	0.9277	0.8046	0.9852	0.9887	0.9890	**0.9899**
	SAM	0.0909	0.0588	0.0812	0.0349	**0.0314**	0.0322	0.0318
	ERGAS	156.23	84.46	135.54	27.13	31.84	26.58	**25.44**
	时间/秒	**13.95**	175.55	556.38	2455.69	1737.56	1235.61	1567.49

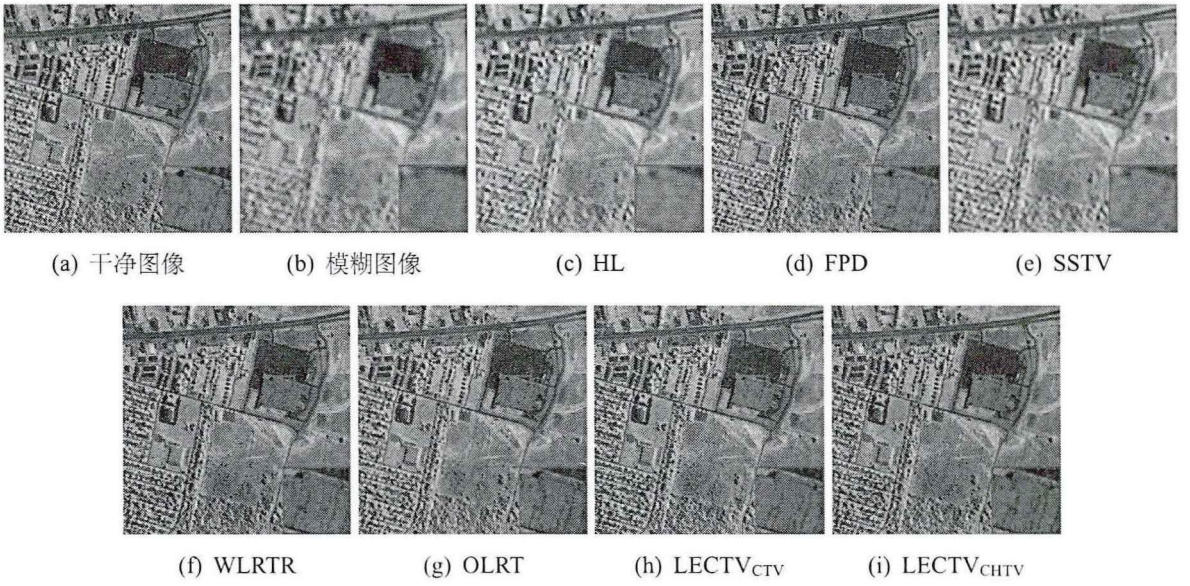

(a) 干净图像　(b) 模糊图像　(c) HL　(d) FPD　(e) SSTV

(f) WLRTR　(g) OLRT　(h) $\text{LECTV}_{\text{CTV}}$　(i) $\text{LECTV}_{\text{CHTV}}$

图 3.15　Urban 数据上的复原结果视觉示例

Fig. 3.15　Visual examples of restoration result on Urban

图3.15为不同算法在 Urban 数据上的视觉结果。结果表明，所提出 LECTV 方法(图3.15(h)-(i)) 在视觉质量上表现突出。与之相比，HL 方法未能产生令人满意的恢复效果。尽管 SSTV 和 FPD 的表现优于 HL 方法，但仍未达到理想的恢复效果。特别是在图3.15(d) 中，可以明显看到 FPD 方法在图像边缘处产生了明显的振铃伪影，图3.15(e) 中 SSTV 的结果则呈现出明显的模糊残留。总体而言，WLRTR、OLRT 和 LECTV 在视觉质量上显著优于 HL、SSTV 和 FPD，能够更好地恢复图像并保持更多细节。

为直观展示所提方法的光谱复原能力，图3.16绘制了 Urban 数据 (空间位置：105, 163) 和 Pavia University 数据 (空间位置：126, 150) 的光谱特征。从图3.16中可以看出，LECTV 恢复曲线明显更接近原始光谱曲线，这说明其复原光谱质量优于其他方法。此

中国知网　https://www.cnki.net

外，实验还对图3.16中的光谱曲线进行了定量分析，在图中添加了光谱曲线的皮尔逊相关系数和均方根误差。这些定量分析结果与表3.5中的评估结果一致，进一步验证了 LECTV 方法的优越性。表3.5显示，$\text{LECTV}_{\text{CHTV}}$ 在 ERGAS 值上表现优异，并且在案例 A 和案例 B 的 SAM 指标上取得了次优成绩。这些结果证实了 LECTV 在光谱信息保持方面具有显著优势。与 $\text{LECTV}_{\text{CTV}}$ 相比，$\text{LECTV}_{\text{CHTV}}$ 在高光谱图像去模糊实验中的改进性能进一步证明了其在光谱补偿方面的有效性。

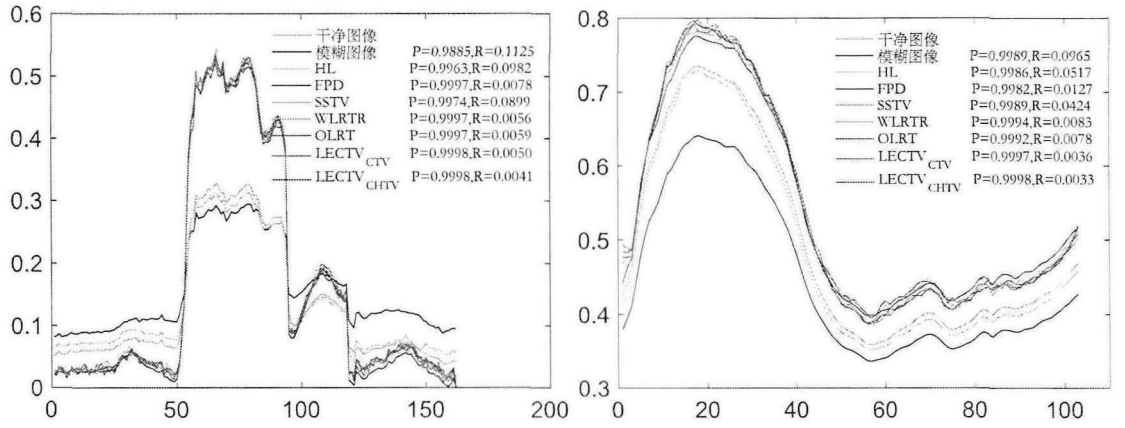

(a) Urban (105, 163)　　(b) Pavia University(126, 150)

图 3.16　光谱曲线及其定量指标

Fig. 3.16　Spectral curves and their quantitative metrics

综上所述，所提出的 LECTV 方法在视觉效果和定量评估中的出色表现验证了其能够有效地利用模糊图像的先验知识。该方法通过利用高光谱图像的空间和光谱相关性，并结合空间光谱总变分模型优势，有效地补偿了受损信息，去除了波段中的严重模糊干扰。同时，所提出的像素级自适应约束进一步增强了图像细节纹理的复原效果。因此，LECTV 在空间和光谱信息的恢复方面表现出了可靠的性能。

3.4.4　去模糊后数据在下游任务中验证

为深入评估不同去模糊方法的效果并验证所提方法的实际应用价值，本节对模糊图像复原后数据进行异常检测研究，验证所提 LECTV 方法在后续介意任务中的有效性和适用性。通过选取 Urban 数据中常用于异常目标检测研究的典型场景作为研究对象，实验采用了定性和定量相结合的的评价方法，其中，定量评估使用三种 2D ROC 曲线、3D ROC 曲线、以及曲线线下面积 AUC 值。通过综合这些指标能够全面、客观地反映模型的检测性能。

表3.6中给出了模糊数据及各去模糊方法的复原数据异常检测结果。实验结果表明，除 HL 外，所有去模糊方法均显著提升了检测结果的 $\text{AUC}(P_d, P_f)$ 值。值得注意的是，$\text{LECTV}_{\text{CHTV}}$ 在 $\text{AUC}(P_d, P_f)$ 和 AUC_{PSNR} 两个指标上均取得了最优性能，同时，$\text{LECTV}_{\text{CTV}}$ 在 $\text{AUC}(P_d, P_f)$、$\text{AUC}(P_D, \tau)$ 和 AUC_{PSNR} 三个指标上也表现出色，均位列前茅。这些结果体现了本章所提 LECTV 方法通过自适应考虑像素强度变化进行去模

中国知网 https://www.cnki.net

表 3.6 Urban 数据去模糊前后异常检测结果

Tab. 3.6 Anomaly detection results before and after deblurring on the Urban Data

	AUC of (P_D,P_F)	AUC of (P_D,τ)	AUC of (P_F,τ)	AUC of SNPR
模糊图像	0.7297	0.4231	0.3404	1.242
SSTV	0.9570	**0.4207**	0.1466	2.896
HL	0.6477	0.0497	**0.0421**	1.181
FPD	0.8985	0.2307	0.1176	1.960
WLRTR	0.9887	0.3302	0.0856	3.8564
OLRT	0.9831	0.3364	0.0904	3.7213
$\text{LECTV}_{\text{CHTV}}$	0.9898	0.3211	0.0783	4.099
$\text{LECTV}_{\text{CTV}}$	**0.9905**	0.3926	0.0792	**4.959**

糊，能够更有效的复原目标光谱信息，更有利于提升异常检测性能。

3.5 本章小结

本章从模糊先验的角度设计了一种像素级自适应调整的约束总变分模型，旨在解决由于模糊退化导致的图像细节和纹理丢失问题，适用于自然图像和高光谱图像的去模糊处理。与现有主要依赖图像暗通道稀疏性假设的去模糊方法不同，所提出的模型能够自适应地描述图像的像素级特征。该方法首先借助模糊图像的先验知识，定义了逐像素自适应约束，从而更精准地表征每个像素的强度。其次，为了避免参数之间的相互干扰，本章将自适应约束融入传统的总变分模型，开发出了一种新的约束总变分模型，有效刻画了图像的固有结构特征。在此基础上，通过将定义的约束总变分模型联合一般图像去模糊框架，实现模糊退化图像质量的改善。

通过在多个自然图像和高光谱图像数据集上进行的综合实验，分析并验证了所提出的 LECTV 方法能够有效恢复图像中的不同纹理区域，尤其是在显著的结构信息和细节特征恢复方面表现突出。这些结果证明了该方法相较于现有技术在去模糊效果上的显著提升。此外，改善后的数据有效恢复了感兴趣的异常信号，对于后续异常目标检测应用的精度提升具有积极作用。

中国知网 https://www.cnki.net

4 基于全局变分和局部结构低秩模型的高光谱去噪算法

4.1 引言

第三章的内容主要研究了总变分正则化在图像去模糊中存在的两个关键问题：一是未能充分考虑纹理和强度差异问题，二是模型约束单一导致稳定性受限。然而，在高光谱图像采集过程中，由于传感器抖动、大气干扰、信号响应等多种因素的共同作用，图像也常受到复杂的噪声干扰，如高斯噪声、椒盐噪声、条纹噪声以及混合噪声[9]。这些噪声不仅显著降低了图像的视觉质量，更给后续数据分析与应用带来诸多挑战。作为遥感图像处理的关键环节，高光谱图像去噪对于提升图像质量、增强地表变化特征的可辨识度具有重要作用，是确保数据分析有效性与可靠性的重要前提。因此，去噪技术是遥感图像处理流程中不可或缺的一环，更具有重要的理论价值和实际应用意义。然而，现有的基于全局低秩和总变分正则化的方法主要关注高光谱图像的全局统计特性，往往忽视了噪声干扰对图像局部特征的破坏性影响。值得注意的是，图像的局部特征承载着丰富的空间纹理信息，这些信息对于保持空间细节的完整性和处理混合噪声至关重要。基于此，开发一种能够同时兼顾全局和局部结构的高光谱图像去噪方法显得尤为必要。

针对上述问题，本章提出了一种基于全局变分与局部结构低秩特性 (Global Variation and Local Structure Low-Rank Model, GLLR) 的高光谱图像去噪算法，该方法以高光谱图像的空间和光谱相关性为基础，深入挖掘图像的内在结构特征，构建了一个统一的去噪模型。具体而言，GLLR 结合了噪声高光谱图像的先验属性，并将局部结构信息有机地融入全局优化框架中，实现对图像局部细节纹理的精确刻画和有效保留。为全面评估所提方法在处理混合噪声方面的性能优势，本章分别在模拟数据和真实数据上设计了一系列对比实验，以系统性地评估和讨论所提方法的去噪性能。实验结果表明，GLLR 通过充分考虑图像细节特征，不仅显著提升了复原精度，复原后数据在后续数据分析任务中也表现出明显的性能优势。这些结果验证了所提方法能够为高光谱数据的精确分析提供了可靠的数据基础。

本章后续部分内容组织如下：第 4.2 节阐述了相关总变分和高光谱图像去噪研究的相关理论基础；第 4.3 节介绍了提出的基于全局和局部结构低秩模型的高光谱去噪方法的设计思路和理论推导过程；第 4.4 节对所提方法在多个数据集上的实验结果进行了测试分析，验证了本章所提方法的有效性；第 4.5 节对本章工作进行了总结概述。

4.2 基于相关总变分的高光谱图像去噪

一般情况下，在高光谱图像去噪问题中，噪声退化模型通常可以表示为：

$$\mathbf{Y} = \mathbf{X} + \mathbf{N} + \mathbf{S} \tag{4.1}$$

中国知网 https://www.cnki.net

其中，$\mathbf{Y} \in \mathbb{R}^{hw \times B}$ 为观测的含噪声高光谱图像，$\mathbf{X} \in \mathbb{R}^{hw \times B}$ 为期望的无噪高光谱图像，$\mathbf{N} \in \mathbb{R}^{hw \times B}$ 表示加性随机噪声 (如高斯噪声和泊松噪声)，$\mathbf{S} \in \mathbb{R}^{hw \times B}$ 代表稀疏噪声（如条纹噪声与死线噪声）。h 和 w 分别表示图像的空间高度和宽度，B 表示光谱波段数。高光谱图像去噪的核心目标是从观测图像 $\mathbf{Y}$ 中精确重建出期望的无噪图像 $\mathbf{X}$。然而，由于方程 (4.1) 是一个典型的病态反问题，即给定观测数据 $\mathbf{Y}$ 可能存在多个解 $\mathbf{X}$ 满足该方程，这使得直接从 $\mathbf{Y}$ 中估计潜在干净图像 $\mathbf{X}$ 成为一个具有挑战性的研究问题。

为有效解决这一问题，研究者们通常根据高光谱图像的固有先验信息，对数据的各组成成分施加合理的正则化约束，从而增强复原过程的稳定性和结果的可解释性。在这一思路下，高光谱图像去噪问题可转化为以下约束优化模型：

$$\arg\min_{\mathbf{X}} \frac{1}{2}\|\mathbf{Y}-\mathbf{X}-\mathbf{S}\|_F^2 + \alpha \cdot \mathcal{R}(\mathbf{X}) + \beta \cdot \mathcal{T}(\mathbf{S}) \tag{4.2}$$

其中，$\mathcal{R}(\mathbf{X})$ 和 $\mathcal{T}(\mathbf{S})$ 分别为针对高光谱图像 $\mathbf{X}$ 和稀疏噪声 $\mathbf{S}$ 设计的正则化项，α 和 β 为权衡各项正则化约束强度的参数。

高光谱图像本质上具有显著的空间-光谱相关性及局部平滑特性，基于这些固有特征，低秩建模与总变分 (Total Variation, TV) 方法得到了广泛应用。低秩正则化能够有效捕捉图像的全局结构信息，而总变分正则化则有益于保持局部区域的平滑连续性。然而，在实际应用中，多先验约束虽能够提升算法精度，但不可避免地会引入多超参数的耦合问题，增加了模型调优的难度。为此，相关总变分 (Correlated Total Variation, CTV) 正则化被提出，它旨在将高光谱数据的低秩性与局部平滑性相结合，同时有效降低了参数间的相互干扰。

高光谱图像固有的低秩特性和局部平滑属性为图像复原提供了重要的先验信息基础。基于这一特性，CTV-RPCA[63] 利用核范数描述梯度图像之间的相关性。该方法通过整合低秩约束和局部平滑约束，实现了对稀疏噪声 $\mathbf{S}$ 和目标图像 $\mathbf{X}$ 的分离。与传统 RPCA 问题类似，CTV-RPCA 试图从观测数据 $\mathbf{Y}$ 中估计未知的低秩矩阵（$\mathbf{X}$ 或其梯度 $\nabla\mathbf{X}$）并识别稀疏噪声 $\mathbf{S}$，其优化问题可形式化表示为：

$$\begin{aligned} &\min_{\mathbf{X},\mathbf{S}} \sum_{i=1}^{3} \|\mathbf{H}_i\|_* + 3\lambda_1\|\mathbf{S}\|_1 \\ &\text{s.t. } \mathbf{Y} = \mathbf{X} + \mathbf{S},\ \nabla_i(\mathbf{X}) = \mathbf{H}_i \end{aligned} \tag{4.3}$$

其中，$\mathbf{H}_i$ 表示 $\mathbf{X}$ 在不同方向上的梯度矩阵，而 λ_1 为权衡低秩约束与稀疏约束的正则化参数。通过进一步结合高光谱图像的退化模型 (4.1)，上述问题可重写为：

$$\begin{aligned} &\min_{\mathbf{X},\mathbf{S}} \ \|\nabla\mathbf{X}\|_* + \lambda\|\mathbf{S}\|_1 \\ &\text{s.t.} \ \ \|\mathbf{Y}-\mathbf{X}-\mathbf{S}\|_F \le \delta \end{aligned} \tag{4.4}$$

中国知网 https://www.cnki.net

其中，参数 δ 用于控制数据保真度，其取值与加性随机噪声 $\mathbf{N}$ 密切相关。该优化模型具有双重优势：一方面通过数据保真项确保与观测数据的一致性，另一方面通过核范数强化目标函数的低秩属性，同时利用 L_1 范数约束增强稀疏噪声的去除能力。

4.3 基于全局和局部结构低秩模型的高光谱去噪模型

4.3.1 M 和 A 算子定义

在本章提出的 GLLR 方法中，最小值运算与绝对值运算 ($|\cdot|$) 可被形式化为映射算子[132]，分别记作 $\mathbf{M}$ 和 $\mathbf{A}$。梯度算子 ∇ 作用于高光图像的三个维度，可记为 $\nabla = (\nabla_1, \nabla_2, \nabla_3)^T$，其中 ∇_1、∇_2 和 ∇_3 分别对应水平方向、垂直方向和光谱方向的梯度计算。相应地，绝对值算子同样涉及这三个维度，即 $A = (A_1, A_2, A_3)$，其具体定义如下：

$$A_1(x,y) = \begin{cases} 1, & \text{if } \nabla_1 X(x,y) \geq 0 \\ -1, & \text{if } \nabla_1 X(x,y) < 0 \end{cases} \tag{4.5}$$

类似地，可定义 A_2 和 A_3。基于此，梯度幅值可表示为：

$$|\nabla X| = A \odot \nabla X \tag{4.6}$$

其中，$\odot$ 表示 Hadamard 乘积。考虑到 A 和 ∇ 作用于 X 的向量形式时表现出显著的稀疏特性，从而得到以下表达式：

$$|\nabla X| = \mathbf{A}\nabla\mathbf{X} \tag{4.7}$$

另一方面，最小值运算可用一个稀疏矩阵 $\mathbf{M}$ 代替，该矩阵作用于 $|\nabla\mathbf{X}|$ 的向量化表示[133]，并满足如下条件：

$$\mathbf{M}(x,z) = \begin{cases} 1, & z = \arg\min |\nabla\mathbf{X}|(y) \\ 0, & \text{otherwise} \end{cases} \tag{4.8}$$

令 $\mathbf{D} = \mathbf{M} * \mathbf{A} * \nabla$，则局部最小差分（Local Minimum Difference, LMD）运算可表示为：

$$LMD(\mathbf{X}) = \mathbf{DX} \tag{4.9}$$

4.3.2 LMD 定义

为深入挖掘数据更深层的特征，以帮助提升数据固有结构的复原，本节提出一种能够反映图像局部结构特征的新正则项。通过统计并分析噪声对图像局部结构特征的影响，定义图像局部最小差分 (Local Minimum Difference, LMD) 值表征图像局部结构特征。图 4.1中展示了噪声破坏前后的图像局部结构特征统计的可视化结果，可以看

中国知网 https://www.cnki.net

到，在无噪声条件下，图像在三个方向 LMD 特征均能够在一定程度反映地物分布的结构特性；而受噪声污染后，LMD 值呈现出毫无规则的分布现象。这一下现象表明 LMD 值对噪声较为敏感，且易遭到噪声破坏。为深入探讨该现象，定义如下 LMD 特征：

$$LMD(\mathbf{X})(p) = \min_{q \in \mathcal{N}(p)} \nabla \mathbf{X}^b(q) \tag{4.10}$$

其中，p 和 q 分别表示像素位置，$\mathcal{N}(p)$ 为 p 的邻域，$b \in 1, \ldots, B$。

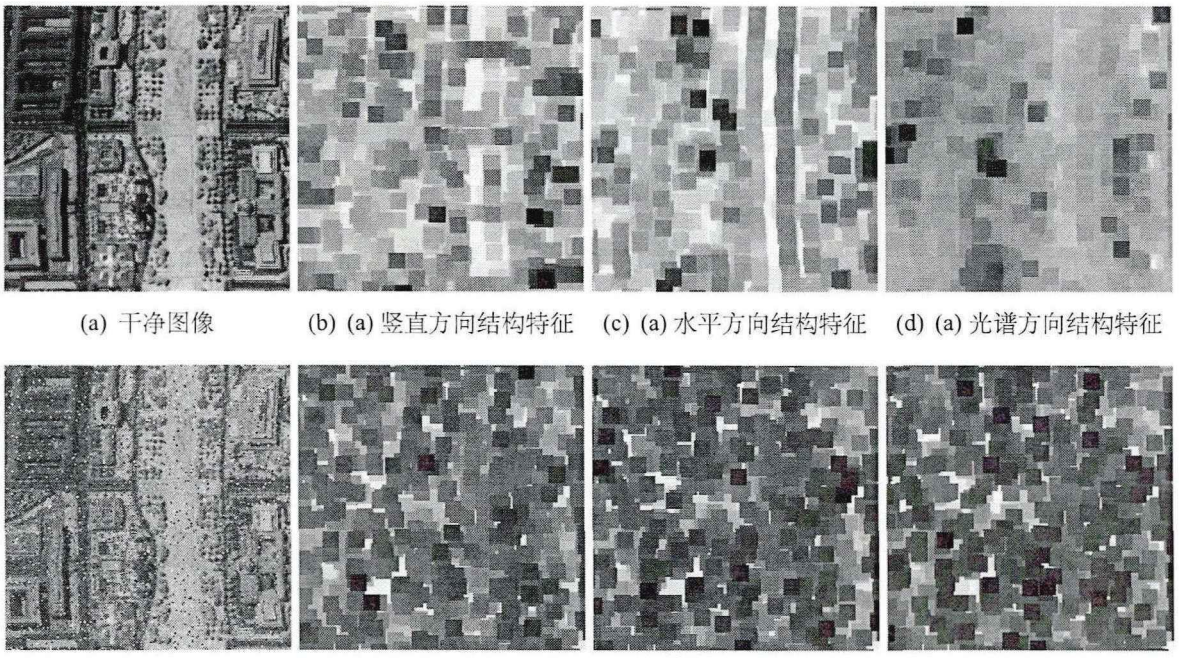

(a) 干净图像　(b) (a) 竖直方向结构特征　(c) (a) 水平方向结构特征　(d) (a) 光谱方向结构特征

(e) 噪声图像　(f) (e) 竖直方向结构特征　(g) (e) 水平方向结构特征　(h) (e) 光谱方向结构特征

图 4.1　噪声影响下的图像局部结构特征变化

Fig. 4.1　The local structural features of the image with noise interfere

基于上述分析，为深入探讨图像更深层次的结构特征，接下来对高光谱图像的结构特征进行建模。如图 4.2 所示，通过对 LMD 矩阵进行奇异值分解，可以观察到仅有少数奇异值占据主导地位，这表明 LMD 矩阵本质上具有低秩结构特性。基于这一观察，可得出以下重要结论：对于原始无噪高光谱图像 $\mathbf{X}$，其 LMD 矩阵的秩显著低于噪声高光谱图像 $\mathbf{Y}$ 的 LMD 矩阵的秩。这种现象的原因在于噪声的存在会导致局部结构失真，使得 LMD 矩阵出现波动，从而增加了 LMD 矩阵的秩；而干净图像的 LMD 矩阵则能够保持较低秩的特性。这一发现强调了 LMD 固有的低秩特性，并反映了其在去噪过程中捕捉和保留结构特征的潜力，它可以有效地将噪声成分和图像结构信息区分开来。因此，核范数可以用于对 LMD 进行约束以描述其结构特性，则有，

$$\|LMD(\mathbf{X})\|_* = \|\mathbf{MA}\nabla\mathbf{X}\|_* \tag{4.11}$$

其中，$\mathbf{MA}\nabla\mathbf{X}$ 是基于高光谱图像的结构特征先验信息对 $\nabla\mathbf{X}$ 进行构建的。

中国知网 https://www.cnki.net

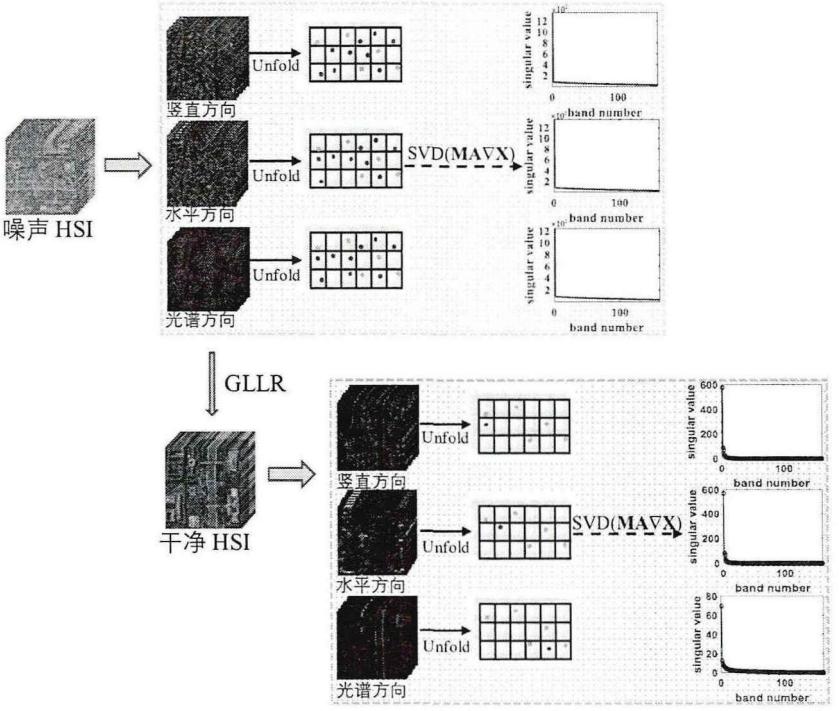

图 4.2　LMD 低秩特性

Fig. 4.2　Low-rank prior of the LMD.

图 4.3 展示了 GLLR 如何结合 LMD 低秩先验和梯度低秩先验来实现高光谱图像的有效恢复。这里，符号 $\otimes$ 表示矩阵乘法。通过将 LMD 正则化项 $\|LMD(\mathbf{X})\|_*$ 融入现有的高光谱图像去噪模型 (4.4) 中，最终形成以下优化问题：

$$\begin{aligned} &\min_{\mathbf{X},\mathbf{S}} \|LMD(\mathbf{X})\|_* + \|\nabla\mathbf{X}\|_* + \lambda\|\mathbf{S}\|_1 \\ &\text{s.t.} \quad \|\mathbf{Y}-\mathbf{X}-\mathbf{S}\|_F \le \delta \end{aligned} \tag{4.12}$$

4.3.3　GLLR 模型建立及优化

为有效求解优化模型 (4.12)，首先将其重构为以下形式，以便引入低秩约束并增强优化问题的结构性：

$$\begin{aligned} &\min_{\mathbf{X},\mathbf{S},\mathbf{H},\mathbf{J}} \sum_{i=1}^{3}\|\mathbf{H}_i\|_* + 3\lambda_1\|\mathbf{S}\|_1 + \sum_{i=1}^{3}\lambda_2\|\mathbf{J}_i\|_* \\ &\text{s.t.} \quad \|\mathbf{Y}-\mathbf{X}-\mathbf{S}\|_F^2 \le \delta,\ \ \nabla_i(\mathbf{X}) = \mathbf{H}_i \\ &\qquad \mathbf{J}_i = \mathbf{MA}\nabla_i(\mathbf{X}), i = 1,2,3 \\ &\qquad \text{rank}(\mathbf{H}) \le r_1,\ \text{rank}(\mathbf{J}) \le r_2 \end{aligned} \tag{4.13}$$

其中，$\mathbf{H}_i$ 和 $\mathbf{J}_i$ 为辅助变量，分别用于建模梯度结构和局部低秩特性。此外，$\mathbf{M}$ 和 $\mathbf{A}$ 分别表示最小值算子和绝对值算子，以确保 $\mathbf{J}_i = \mathbf{MA}\nabla_i(\mathbf{X})$ 能够有效提取 $\nabla_i(\mathbf{X})$ 中的

中国知网　https://www.cnki.net

非平滑区域（如边缘、纹理突变等），从而保证优化模型在恢复图像时不会过度平滑重要结构信息。模型 (4.13) 结合总变分约束与低秩属性能够在抑制噪声的同时保持结构信息，确保高光谱图像的光谱-空间一致性。

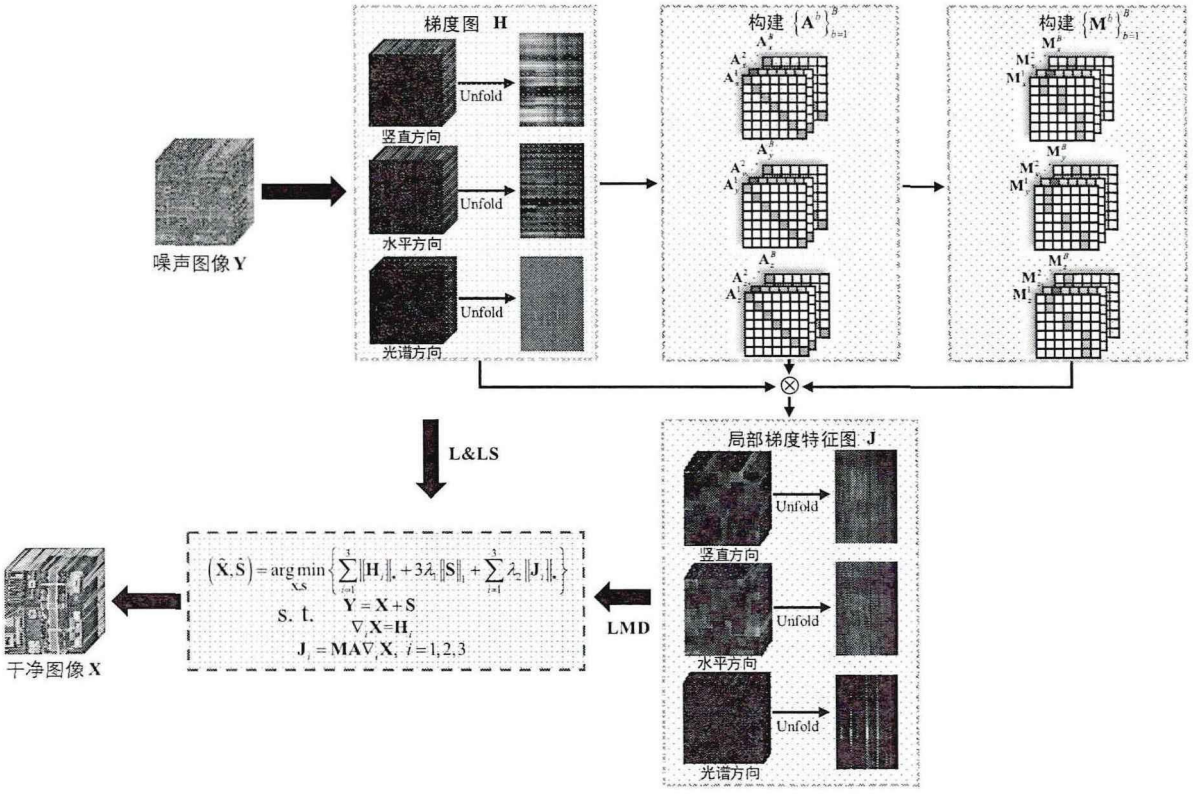

图 4.3　GLLR 示意图

Fig. 4.3　Schematic diagram of GLLR

为高效求解上述约束优化问题，这里引入增广拉格朗日方法（Augmented lagrange method，ALM）构建以下优化目标函数：

$$\begin{aligned}\min\ell(\mathbf{X},\mathbf{S},\mathbf{H},\mathbf{J},\mathbf{\Gamma}_i)=&\min_{\mathbf{X},\mathbf{S},\mathbf{H},\mathbf{J},\mathbf{\Gamma}_i}\sum_{i=1}^{3}\|\mathbf{H}_i\|_*+3\lambda_1\|\mathbf{S}\|_1+\sum_{i=1}^{3}\lambda_2\|\mathbf{J}_i\|_*\\&+\langle\mathbf{\Gamma}_i,\nabla_i\mathbf{X}-\mathbf{H}_i\rangle+\langle\mathbf{\Gamma},\mathbf{Y}-\mathbf{X}-\mathbf{S}\rangle+\langle\mathbf{\Gamma}_i,\mathbf{D}_i\mathbf{X}-\mathbf{J}_i\rangle\\&+\frac{\mu_1}{2}\|\mathbf{Y}-\mathbf{X}-\mathbf{S}\|_F^2+\frac{\mu_2}{2}\sum_{i=1}^{3}(\|\nabla_i\mathbf{X}-\mathbf{H}_i\|_F^2+\|\mathbf{D}_i\mathbf{X}-\mathbf{J}_i\|_F^2)\\\text{s.t. }&\text{rank}(\mathbf{H})\le r_1,\ \text{rank}(\mathbf{J})\le r_2\end{aligned}\tag{4.14}$$

其中，λ_1 和 λ_2 分别控制稀疏性和低秩性，$\mathbf{\Gamma}$ 代表拉格朗日乘子，μ_1 和 μ_2 为惩罚参数，$\langle\cdot,\cdot\rangle$ 表示 Frobenius 内积。

通过将问题 (4.14) 分解为以下三个子问题，逐步优化不同变量：

中国知网 https://www.cnki.net

$$\mathbf{H}^{t+1}=\arg\min_{\mathbf{H}}\sum_{i=1}^{3}\|\mathbf{H}_i\|_*+\frac{\mu_2}{2}\|\nabla_i\mathbf{X}-\mathbf{H}_i+\frac{\mathbf{\Gamma}_i}{\mu_2}\|_F^2 \tag{4.15}$$

$$\mathbf{S}^{t+1}=\arg\min_{\mathbf{S}}3\lambda\|\mathbf{S}\|_1+\frac{\mu_1}{2}\|\mathbf{Y}-\mathbf{X}-\mathbf{S}+\frac{\mathbf{\Gamma}_7}{\mu_1}\|_F^2 \tag{4.16}$$

$$\mathbf{J}^{t+1}=\arg\min_{\mathbf{J}}\sum_{i=1}^{3}\lambda_2\|\mathbf{J}_i\|_*+\frac{\mu_2}{2}\|\mathbf{D}_i\mathbf{X}-\mathbf{J}_i+\frac{\mathbf{\Gamma}_{i+3}}{\mu_2}\|_F^2 \tag{4.17}$$

接下来，展示了涉及变量的每个子问题的求解步骤：

1) 计算子问题 **H**。在固定公式 (4.14) 中其他变量的情况下，将优化目标化为如下形式：

$$\begin{cases}\mathbf{H}_i^{t+1}=\mathbf{U}\mathcal{S}_{1/\mu_2}(\mathbf{\Sigma})\mathbf{V}^T\\ \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T=\text{svd}\left(\nabla_i\mathbf{X}^t+\mathbf{\Gamma}_i^t/\mu_2,'\text{econ}'\right)\end{cases} \tag{4.18}$$

2) 计算子问题 **S**。变量 **S** 对应的优化子问题涉及稀疏正则化约束，其求解可通过软阈值收缩算子[134] 实现。其定义如下：

$$\Re=\begin{cases}x-\delta, & \text{if}\quad x>\delta\\ x+\delta, & \text{if}\quad x<-\delta\\ 0, & \text{otherwise}\end{cases} \tag{4.19}$$

相应地，$\mathbf{S}^{t+1}$ 可表示为：

$$\mathbf{S}^{t+1}=\mathcal{S}_{3\lambda/\mu_1}(\mathbf{Y}-\mathbf{X}^{(t)}+\frac{\mathbf{\Gamma}_7}{\mu_1}) \tag{4.20}$$

3) 计算子问题 **J**。**J** 的优化问题可以类似于公式 (4.18) 的方式求解：

$$\begin{cases}\mathbf{J}_i^{t+1}=\mathbf{U}\mathcal{S}_{\lambda_2/\mu_2}(\mathbf{\Sigma})\mathbf{V}^T\\ \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T=\text{svd}\left(\mathbf{D}_i\mathbf{X}^t+\mathbf{\Gamma}_{i+3}^t/\mu_2,'\ \text{econ}\ '\right)\end{cases} \tag{4.21}$$

4) 计算 **X** 相关子问题。在变量 **H** 和 **J** 已更新的情况下，优化 **X** 需最小化以下目标函数：

$$\begin{aligned}\arg\min_{\mathbf{X}}&\sum_{i=1}^{3}\left(\frac{\mu_2}{2}\|\nabla_i\mathbf{X}-\mathbf{H}_i^{t+1}+\frac{\mathbf{\Gamma}_i}{\mu_2}\|_F^2\right)+\frac{\mu_1}{2}\|\mathbf{Y}-\mathbf{X}-\mathbf{S}^{t+1}+\frac{\mathbf{\Gamma}_7}{\mu_1}\|_F^2\\ &+\sum_{i=1}^{3}\left(\frac{\mu_2}{2}\|\mathbf{D}_i\mathbf{X}-\mathbf{J}_i^{t+1}+\frac{\mathbf{\Gamma}_{i+3}}{\mu_2}\|_F^2\right)\end{aligned} \tag{4.22}$$

中国知网 https://www.cnki.net

为提高计算效率，引入辅助变量 $\mathbf{q}$ 以分解优化目标：

$$\begin{aligned}\arg\min_{\mathbf{X}} \sum_{i=1}^{3}\left(\frac{\mu_2}{2}\|\nabla_i\mathbf{X}-\mathbf{H}_i^{t+1}+\frac{\mathbf{\Gamma}_i}{\mu_2}\|_F^2\right)+\frac{\mu_1}{2}\|\mathbf{Y}-\mathbf{X}-\mathbf{S}^{t+1}+\frac{\mathbf{\Gamma}_7}{\mu_1}\|_F^2 \\ +\frac{\mu_3}{2}\|\mathbf{q}-\mathbf{X}\|^2+\sum_{i=1}^{3}\left(\frac{\mu_2}{2}\|\mathbf{D}_i\mathbf{q}-\mathbf{J}_i^{t+1}+\frac{\mathbf{\Gamma}_{i+1}}{\mu_2}\|_F^2\right)\end{aligned} \tag{4.23}$$

优化 $\mathbf{X}$ 和 $\mathbf{q}$ 子问题：

$$\begin{aligned}\arg\min_{\mathbf{X}} \sum_{i=1}^{3}\left(\frac{\mu_2}{2}\|\nabla_i\mathbf{X}-\mathbf{H}_i^{t+1}+\frac{\mathbf{\Gamma}_i}{\mu_2}\|_F^2\right)+\frac{\mu_1}{2}\|\mathbf{Y}-\mathbf{X}-\mathbf{S}^{t+1}+\frac{\mathbf{\Gamma}_7}{\mu_1}\|_F^2 \\ +\frac{\mu_3}{2}\|\mathbf{q}-\mathbf{X}\|^2\end{aligned} \tag{4.24}$$

$$\arg\min_{\mathbf{q}} \sum_{i=1}^{3}\left(\frac{\mu_2}{2}\|\mathbf{D}_i\mathbf{q}-\mathbf{J}_i^{t+1}+\frac{\mathbf{\Gamma}_{i+1}}{\mu_2}\|_F^2\right)+\frac{\mu_3}{2}\|\mathbf{q}-\mathbf{X}\|^2 \tag{4.25}$$

问题 (4.24) 可以通过以下方式求解来优化：

$$\left[\mu_2\sum_{i=1}^{3}\nabla_i^T\nabla_i+(\mu_1+\mu_3)\mathbf{I}\right]\mathbf{X}=\nabla_i^T\left(\mu_2\sum_{i=1}^{3}\mathbf{H}_i^{t+1}-\mathbf{\Gamma}_i^{t+1}\right)+\mu_1\left(\mathbf{Y}-\mathbf{S}^{t+1}\right)+\mathbf{\Gamma}_7^{t+1}+\mu_3\mathbf{q}^t$$

其中，∇^T 表示 ∇ 的转置算子。通过对式 (4.26) 的两边执行傅里叶变换，并利用卷积定理[123]，最终，$\mathbf{X}_{t+1}$ 的解可由以下公式得出：

$$\begin{cases}\mathbf{T}_x=|\mathcal{F}(\mathbf{D}_1)|^2+\mathcal{F}(\mathbf{D}_2)|^2+|\mathcal{F}(\mathbf{D}_3)|^2 \\ \mathbf{F}=\sum_{n=1}^{3}\mathcal{F}(\mathbf{D}_n)^*\odot\mathcal{F}\left(\text{ fold }\left(\mu_2\mathbf{F}_i^{t+1}-\mathbf{\Gamma}_i^t\right)\right) \\ \mathbf{X}^{t+1}=\mathcal{F}^{-1}\left(\frac{\mathcal{F}\left(\text{ fold }\left(\mu_1(\mathbf{Y}-\mathbf{S}^{t+1})+\mathbf{\Gamma}_7^t+\mu_3\mathbf{q}^{t+1}\right)\right)+\mathbf{H}}{(\mu_1+\mu_3)\mathbf{I}+\mu_2\mathbf{T}_x}\right)\end{cases} \tag{4.26}$$

问题 (4.25) 中关于 $\mathbf{q}$ 问题的解为：

$$\mathbf{q}=\frac{\mathbf{D}_i^T\left(\mu_2\mathbf{J}_i^{t+1}-\mathbf{\Gamma}_{i+3}\right)+\mu_3\mathbf{X}^{t+1}}{\mu_2\mathbf{D}_i^T\mathbf{D}_i+\mu_3\mathbf{I}} \tag{4.27}$$

5) 计算拉格朗日乘子 $\mathbf{\Gamma}$。拉格朗日乘子 $\mathbf{\Gamma}$ 的更新方式如下：

$$\begin{cases}\mathbf{\Gamma}_i^{t+1}=\mathbf{\Gamma}_i^t+\mu\left(\nabla_i\mathbf{X}^{t+1}-\mathbf{H}_i^{t+1}\right),i=1,2,3 \\ \mathbf{\Gamma}_{i+3}^{t+1}=\mathbf{\Gamma}_{i+3}^t+\mu\left(\mathbf{D}_i\mathbf{X}^{t+1}-\mathbf{J}^{t+1}\right),i=1,2,3 \\ \mathbf{\Gamma}_7^{t+1}=\mathbf{\Gamma}_7^t+\mu\left(\mathbf{Y}-\mathbf{X}^{t+1}-\mathbf{S}^{t+1}\right) \\ \mu=\mu\rho\end{cases} \tag{4.28}$$

中国知网 https://www.cnki.net

其中，ρ 是一个常数。最终，GLLR 实现的详细流程由算法4.1总结。

Algorithm 4.1 基于 GLLR 的高光谱图像去噪

输入：观测高光谱图像 $\mathbf{Y}$；参数：$\epsilon_1 = 10^{-6}$，$\lambda_1 = 5/\sqrt{hw}, \mu, T$，步长 ρ；
输出：复原结果 $\mathbf{X}$；

1: **while** $0 \leq t < T \wedge \|\mathbf{Y} - \mathbf{X}^{t+1} - \mathbf{S}^{t+1}\|_F^2 / \|\mathbf{Y}\|_F^2 \geq \epsilon_1$ **do**
2: 根据式 (4.18) 更新 $\mathbf{H}_i^{t+1}$;
3: 根据式 (4.21) 更新 $\mathbf{J}_i^{t+1}$;
4: 根据式 (4.25) 更新 $\mathbf{q}^{t+1}$;
5: 根据式 (4.26) 更新 $\mathbf{X}^{t+1}$;
6: 根据式 (4.20) 更新 $\mathbf{S}^{t+1}$;
7: 根据式 (4.28) 更新 $\mathbf{\Gamma}_i^{t+1}$;
8: $\mu \leftarrow \rho\mu$;
9: $t \leftarrow t + 1$;
10: **end while**

4.4 实验验证与分析

(1) 实验数据

本章采用两组模拟高光谱图像数据，并构建多组噪声退化案例评价所提方法的鲁棒性。第一组数据是由 HYDICE 传感器获取的 Washington D.C. Mall 数据，原始数据覆盖 401-2473nm 光谱范围共 191 个波段。这里根据文献 [63] 进行以下预处理构建标准化实验样本：剔除水汽强吸收波段，并截取大小为 $200 \times 200 \times 160$ 的子图像 (空间区域为 $(567:766, 40:239)$)。第二组数据是由反射光学系统成像光谱仪获取的 Pavia City 数据，原始数据包含 115 个光谱通道。需要注意的是，Pavia City 数据的前几个波段受到严重噪声污染，无法作为去噪实验的对比参考。因此本章根据文献 [135] 移除了相应的严重污染波段，并选择大小为 $200 \times 200 \times 85$ 的子图像 (空间区域为 $(1:200, 25:224)$)。

(2) 对比方法

为全面分析和验证本章提出的 GLLR 方法的综合性能，本章从模型驱动和数据驱动两个维度选取了具有代表性的去噪方法作为对比方法。在模型驱动方法方面，选取了以下经典及前沿方法：低秩总变分 (LRTV)[136]、低秩矩阵恢复 (LRMR)[136]、张量总变分鲁棒主成分分析 (CTV-RPCA)[63]、主成分追踪 (PCP)[101]、三维低秩分解 (TDL)[137] 以及非局部梯度融合 (NGMeet)[48]。在数据驱动方法方面，选择了深度卷积去噪网络 (SdeCNN)[30]、图正则网络 (GRN-Net)[26] 以及光谱运动解耦网络 (SMDS-Net)[25] 等深度学习模型。为确保对比实验的严谨性，所有对比算法的参数均依据原作者公开代码的默认配置或文献推荐的取值区间进行了针对性优化，以实现各算法的最优性能表现。实验采用了定性与定量相结合的评估方式。其中，图像质量的定量评价指标包括 PSNR、SSIM、SAM 和 ERGAS，下游数据分析任务的性能评估则采用了常用的整体精度 OA 和 Kappa 系数。为便于直观比较各方法的检测性能，实验中采用粗体标识最

中国知网 https://www.cnki.net

佳性能指标，采用下划线标识次佳性能指标。

为评估所提算法在不同退化场景下的适应性和鲁棒性，实验设计了六种混合噪声模型，涵盖了高光谱图像处理中常见的高斯噪声、条带噪声及椒盐噪声等典型退化类型。具体的噪声设置方案如下：

- 案例 1：每个高光谱波段均受到不同强度的高斯噪声 $\mathcal{N}(0,\sigma^2)$ 污染，其中 $\sigma^2 \sim U[0.05, 0.1]$。
- 案例 2：在两个高光谱图像的所有波段中加入比例为 ρ =0.1 的椒盐噪声，模拟传输信道突发干扰。
- 案例 3：通过模拟方差为 σ^2 =0.1 的高斯噪声和比例为 ρ =0.1 的椒盐噪声，以模拟复合退化场景。
- 案例 4：在所有波段添加与案例 1 相同水平的高斯噪声，同时对 40% 的波段施加条带噪声污染。
- 案例 5：基于案例 1 的高斯噪声模型，在两个高光谱图像中进一步叠加比例范围为 $\rho \sim U[0.05, 0.15]$ 的椒盐噪声，以增加退化复杂度。
- 案例 6：同时模拟与案例 3 相同水平的高斯噪声和椒盐噪声，并添加与案例 4 相同的条纹噪声，以构建高度复杂的退化场景。

4.4.1 模拟数据上实验

表 4.1 和表 4.2 分别列出了 W. D.C. MALL(Washington D.C. Mall, W.DC MALL) 和 Pavia City 数据在六种退化场景下，所提出方法及对比方法的定量评估结果。图 4.4 和图 4.5 分别展示了 W. D.C. Mall 在案例 1 以及 Pavia City 在案例 6 下的合成伪彩色图像及其对比实验结果。其中，Washington D.C. Mall 数据的红、绿、蓝波段分别设置为 R = 58, G = 27, B = 17。Pavia City 数据的红、绿、蓝波段分别设置为 R = 75, G = 50, B = 10。

为突出各方法在细节恢复方面的性能差异，图 4.4 中对部分关键区域进行了局部放大，以便更清晰地对比分析。从图 4.4 的视觉结果可以看出，各对比方法在噪声去除和细节保留方面表现各异。具体来说，TDL 和 SMDS-Net 在处理案例 1 的复杂噪声时效果欠佳，复原后的图像中仍存在明显的噪声残留。SdeCNN 和 GRN-Net 虽然表现出较好的去噪能力，但在某些区域导致图像细节过度平滑，可能损失部分结构信息。LRMR 和 PCP 在视觉上能够较好地去除噪声，但仍存在少量残留噪声，未能完全恢复原始影像质量。相比之下，CTV-RPCA、LRTV、NGMeet 及本文方法在噪声去除和结构细节保留之间达到了较好的平衡，不仅有效抑制了混合噪声，还较好地保留了图像的边缘和纹理信息。结合表4.1的定量结果，GRN-Net 在挖掘高光谱图像中的光谱信息方面存在一定局限性，在不同退化情况下的表现相对较弱。相比之下，本章所提

中国知网 https://www.cnki.net

表 4.1 不同方法在 W. D.C. MALL 数据上的定量评估结果

Tab. 4.1 Performance comparison of different methods on W. D.C. MALL data

案例	指标	噪声图像	SdeCNN	SMDS-Net	GRN-Net	TDL	LRMR	PCP	LRTV	NGMeet	RPCA	GLLR
案例 1	PSNR	19.48	33.23	32.56	22.98	23.28	33.93	31.68	33.89	34.23	34.23	**34.97**
	SSIM	0.500	0.949	0.940	0.789	0.680	0.959	0.958	0.966	0.964	0.961	**0.967**
	SAM	31.69	6.07	7.16	18.15	19.70	6.20	6.47	5.64	5.70	5.57	**5.34**
	ERGAS	458.55	77.65	85.81	307.20	272.30	71.73	99.42	74.31	73.78	69.50	**63.83**
	Time/s	-	**7.53**	24.70	9.44	26.62	26.62	26.62	26.62	80.36	80.36	1254.87
案例 2	PSNR	14.53	26.78	27.31	23.21	24.00	44.17	45.12	36.82	28.16	**49.69**	48.82
	SSIM	0.354	0.867	0.887	0.776	0.880	0.995	0.998	0.985	0.914	**0.998**	0.998
	SAM	36.80	8.50	8.49	18.71	8.69	2.33	1.28	2.92	7.30	**0.91**	1.16
	ERGAS	693.14	172.62	144.33	306.86	240.98	23.76	26.67	62.59	145.62	15.25	**14.58**
	Time/s	-	**7.45**	18.51	9.27	16.92	139.01	17.48	139.05	77.36	89.47	1504.79
案例 3	PSNR	13.45	26.51	26.83	23.17	23.79	33.63	31.32	33.35	27.99	33.45	**34.73**
	SSIM	0.272	0.856	0.868	0.774	0.862	0.955	0.951	0.960	0.911	0.954	**0.963**
	SAM	40.10	8.95	9.02	18.83	9.63	6.18	6.63	5.68	7.47	5.77	**5.36**
	ERGAS	780.58	176.79	151.78	307.75	244.95	73.37	96.73	78.59	147.12	75.68	**65.34**
	Time/s	-	**7.57**	27.15	9.39	16.10	146.01	15.51	148.53	79.18	162.06	1658.96
案例 4	PSNR	21.77	34.98	35.95	24.01	29.07	35.90	33.68	36.01	**37.26**	35.43	36.87
	SSIM	0.606	0.967	0.972	0.780	0.911	0.974	0.972	0.972	**0.982**	0.971	0.977
	SAM	23.47	5.11	5.09	17.41	7.70	5.11	5.47	5.22	**3.79**	4.94	4.50
	ERGAS	299.77	64.59	58.93	258.52	134.74	57.78	75.83	57.55	**49.37**	60.88	51.58
	Time/s	-	7.40	24.88	10.20	15.10	150.77	14.48	137.17	76.94	154.78	1183.13
案例 5	PSNR	13.83	25.49	26.04	23.23	23.56	35.31	33.02	34.32	26.63	34.97	**36.23**
	SSIM	0.292	0.835	0.876	0.713	0.847	0.969	0.967	0.970	0.882	0.967	**0.973**
	SAM	38.69	9.90	8.55	19.43	10.90	5.16	5.56	5.33	8.92	5.02	**4.58**
	ERGAS	758.23	205.09	165.17	277.73	264.03	60.93	81.35	72.00	181.89	64.21	**55.44**
	Time/s	-	**7.38**	24.88	9.89	23.30	145.38	14.90	139.13	81.19	165.88	1401.62
案例 6	PSNR	13.45	26.67	27.08	23.12	24.13	33.26	31.0	33.40	28.23	33.32	**34.68**
	SSIM	0.270	0.855	0.870	0.771	0.867	0.953	0.950	0.962	0.912	0.953	**0.962**
	SAM	40.21	8.78	8.88	18.92	9.16	6.31	6.60	5.79	7.20	5.79	**5.37**
	ERGAS	779.16	171.65	147.71	308.40	232.09	77.13	99.42	78.54	141.31	76.69	**65.51**
	Time/s	-	**7.48**	27.15	9.14	14.62	144.86	6.60	6.60	80.62	6.60	1158.89

GLLR 方法在大多数测试场景中均取得了最优或次优的性能。具体而言，在案例 1、3、5 和 6 中，GLLR 方法在所有评估指标上均表现最佳，展现了其卓越的混合噪声去除能力。在案例 2 中，GLLR 方法在 ERGAS 指标上取得最优值，并在 PSNR、SSIM 和 SAM 指标上表现为次优，仅次于 CTV-RPCA。在案例 4 中，NGMeet 和 GLLR 分别取得最佳与次优性能，表明 GLLR 在该退化场景下仍具有较强的鲁棒性。

进一步分析表 4.2 的实验结果也可以发现，GLLR 方法在案例 1、2、3、5 和 6 中均取得了最佳性能，进一步验证了其在多种混合噪声场景下的适应性和稳健性。在案例 4 中，尽管 NGMeet 在 PSNR 指标上略优于 GLLR，但 GLLR 仍然保持了较好的综合性能，在其他评估指标上表现突出。结合图 4.5 中的视觉结果，GLLR 方法不仅在定量指标上表现优异，同时在视觉质量上也展现出良好的噪声去除效果，能够更好地

中国知网 https://www.cnki.net

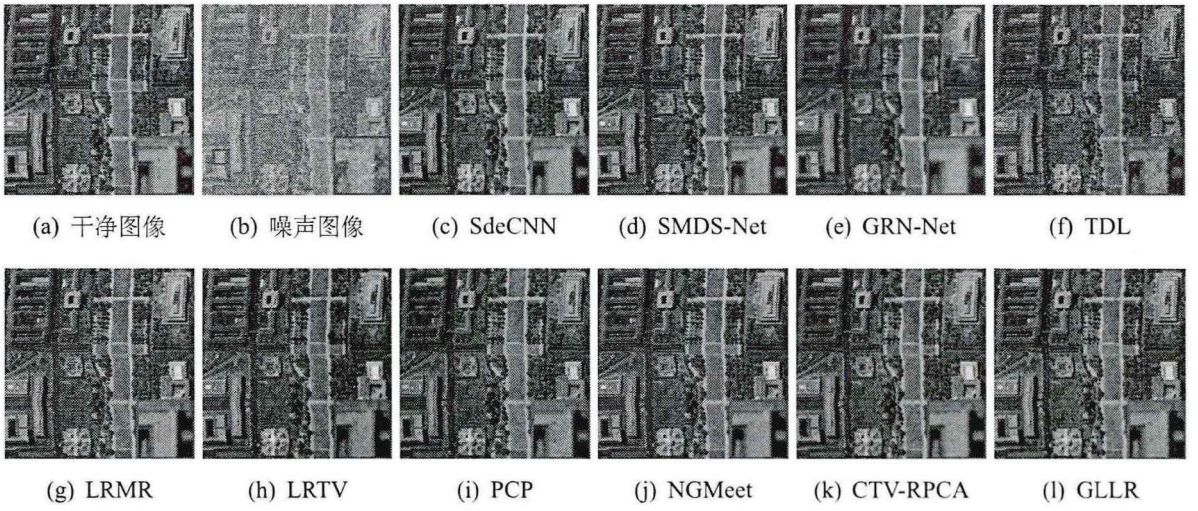

图 4.4　不同方法在案例 1 下 W. D.C. Mall 数据的复原结合可视化

Fig. 4.4　Visualization of restoration results by different methods on W. D.C. Mall in Case 1

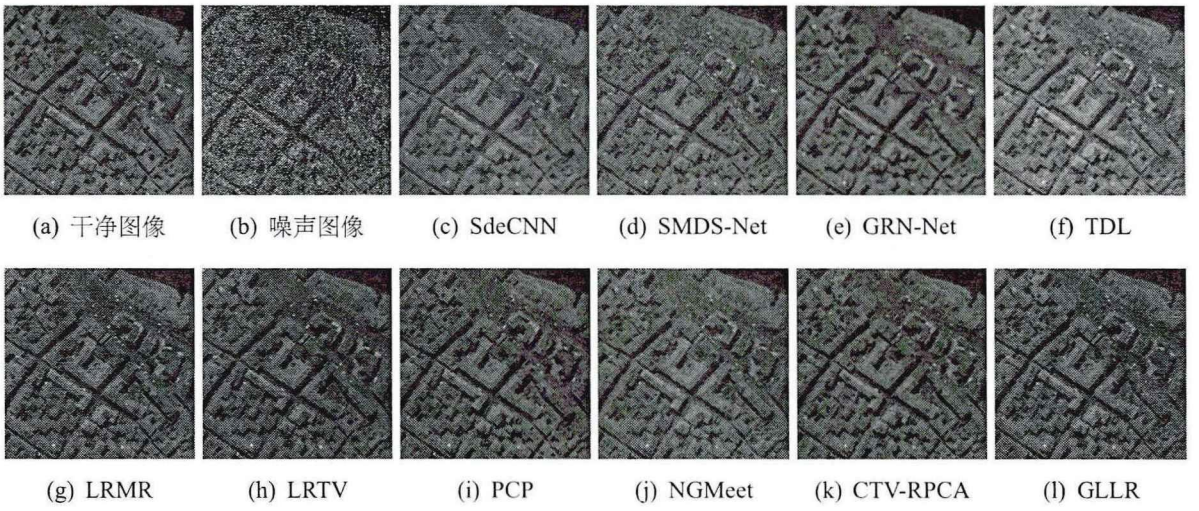

图 4.5　不同方法在案例 6 下 Pavia City 数据的复原结合可视化

Fig. 4.5　Visualization of restoration results by different methods on Pavia City Mall in Case 6

保留高光谱图像的细节和结构信息。

综合表 4.1 和表 4.2 的定量评估结果，可以得出如下结论：本章所提 GLLR 算法在多种混合噪声环境下均能够有效抑制噪声并恢复高光谱图像结构，展现了较强的泛化能力和鲁棒性。此外，GLLR 在整体性能上优于 LRTV 和 CTV-RPCA，这也体现了 LMD 作为补偿策略的有效性，凸显了其在高光谱图像复原任务中的显著优势。

此外，光谱信息的准确恢复对于高光谱图像去噪处理至关重要，其准确性直接关系到下游数据分析任务的可靠性。为评估各方法对光谱信息的保留能，在 Pavia City 数据案例 6 中，提取了复原后数据在空间位置 (178, 174) 处的光谱曲线，并在图 4.6 中绘制。为提供直观的对比，图中还标注了无噪声的真实光谱曲线。从图 4.6 (a)-(k)

中国知网　https://www.cnki.net

表 4.2 不同方法在 Pavia City 数据上的定量评估结果

Tab. 4.2 Performance comparison of different methods on Pavia City data

案例	指标	噪声图像	SdeCNN	SMDS-Net	GRN-Net	TDL	LRMR	PCP	LRTV	NGMeet	RPCA	GLLRX
案例 1	PSNR	19.67	35.13	31.89	28.56	23.38	33.97	31.46	34.82	35.03	34.76	**35.15**
	SSIM	0.380	0.948	0.880	0.879	0.620	0.932	0.925	0.934	0.950	0.947	**0.950**
	SAM	39.14	5.55	10.09	5.55	21.61	6.83	7.30	7.30	9.40	5.51	**5.07**
	ERGAS	493.24	**69.36**	102.92	181.98	285.66	81.17	108.52	74.92	74.48	73.43	70.29
	Time/s	-	**3.72**	9.44	9.44	13.66	118.96	6.23	29.90	73.41	29.90	1314.2
案例 2	PSNR	14.32	26.81	26.41	27.46	20.95	44.86	45.04	38.41	27.92	44.97	**50.25**
	SSIM	0.242	0.841	0.801	0.859	0.805	0.993	0.998	0.966	0.884	0.998	**0.999**
	SAM	42.75	7.42	12.47	9.23	8.11	2.43	**1.06**	5.79	6.32	**1.06**	1.37
	ERGAS	784.13	187.01	175.26	199.26	366.32	23.96	26.43	85.60	165.08	25.68	**12.47**
	Time/s	-	**3.71**	8.58	7.24	8.67	101.46	6.83	40.45	69.23	65.74	917.09
案例 3	PSNR	13.28	26.69	25.93	27.42	18.91	33.28	30.52	33.10	27.85	33.87	**34.72**
	SSIM	0.165	0.830	0.769	0.855	0.748	0.916	0.907	0.929	0.880	0.934	**0.937**
	SAM	46.66	7.57	9.87	12.7	8.24	7.30	7.72	7.37	6.413	5.83	**5.81**
	ERGAS	881.47	188.76	184.19	200.34	458.21	87.08	118.85	98.81	166.04	82.91	**74.21**
	Time/s	-	**3.60**	8.74	7.26	7.95	119.41	6.22	38.11	72.20	52.30	803.00
案例 4	PSNR	21.82	36.78	36.10	28.47	28.46	35.70	32.99	36.79	**37.49**	35.35	36.82
	SSIM	0.476	0.961	0.953	0.896	0.866	0.951	0.9420	0.957	**0.962**	0.952	**0.962**
	SAM	30.23	5.13	6.09	8.08	9.69	6.01	6.01	5.42	6.13	5.53	**4.87**
	ERGAS	331.62	60.22	65.50	212.25	157.04	66.90	92.21	**58.86**	63.59	70.48	58.90
	Time/s	-	**3.60**	10.75	10.20	12.83	102.56	6.47	30.61	67.98	63.30	723.01
案例 5	PSNR	13.73	25.62	26.19	24.54	21.17	34.80	31.85	33.96	26.22	34.84	**36.13**
	SSIM	0.185	0.804	0.845	0.816	0.769	0.942	0.932	0.941	0.809	0.945	**0.953**
	SAM	44.57	8.47	8.83	8.08	9.46	5.75	6.61	6.99	9.74	5.65	**4.96**
	ERGAS	847.55	218.43	180.86	266.41	362.00	73.64	104.93	94.20	219.61	74.71	**63.65**
	Time/s	-	**3.73**	8.85	9.89	10.35	119.86	6.24	39.03	78.41	65.28	742.00
案例 6	PSNR	13.28	26.84	26.00	27.42	20.87	33.01	30.16	33.30	28.03	33.78	**34.63**
	SSIM	0.164	0.828	0.769	0.854	0.788	0.921	0.906	0.929	0.880	0.934	**0.936**
	SAM	46.94	7.56	10.10	12.77	7.45	6.82	7.91	7.52	6.56	6.02	**5.88**
	ERGAS	880.10	185.02	183.47	200.89	363.93	87.77	126.90	100.08	162.37	83.83	**75.12**
	Time/s	-	**3.67**	8.67	7.30	7.67	91.85	6.36	39.62	71.38	64.59	890.53

可以看出，不同方法在光谱恢复精度方面存在显著差异。与其他对比方法相比，本章 GLLR 方法在光谱形状保持和噪声抑制方面均表现出显著的优势，能够更准确地重建光谱信息。

4.4.2 真实数据上实验

为进一步验证所提方法的鲁棒性与通用性，本节采用两个真实噪声高光谱图像作为测试对象进行了真实数据上实验[9]，实验数据分别为 Urban 数据和 Indian Pines 数据。Urban 数据由 Hydice 传感器获取，图像尺寸为 $(307 \times 307 \times 210)$。为避免水吸收波段的影响，对水吸收波段进行剔除，最终保留了 188 个有效波段。Indian Pines 数据由 AVIRIS 传感器获取，图像尺寸为 $(145 \times 145 \times 206)$。需要注意的是，Urban 和

中国知网 https://www.cnki.net

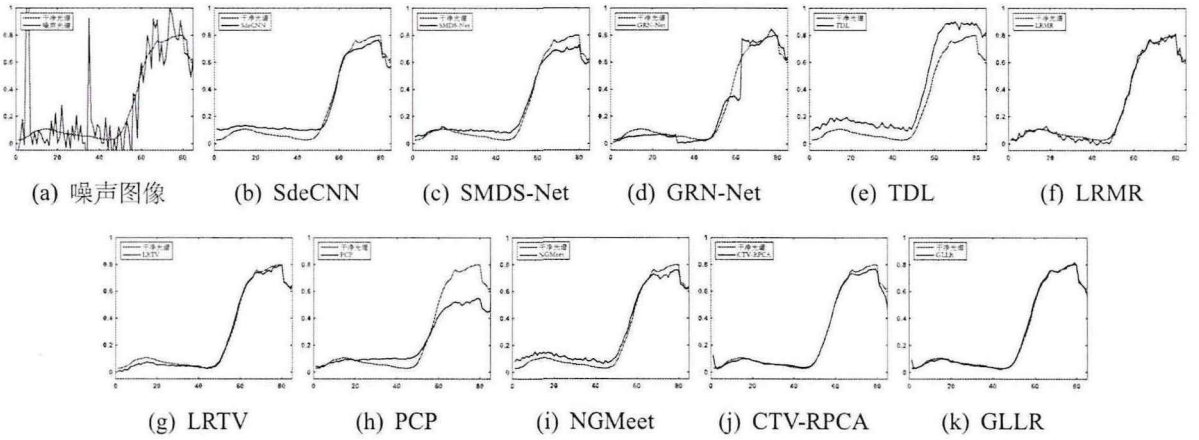

图 4.6　案例 6 中 Pavia City 位置 (178,174) 处的光谱曲线
Fig. 4.6　sSectral curvers for position (178,174) of Pavia City in Case 6

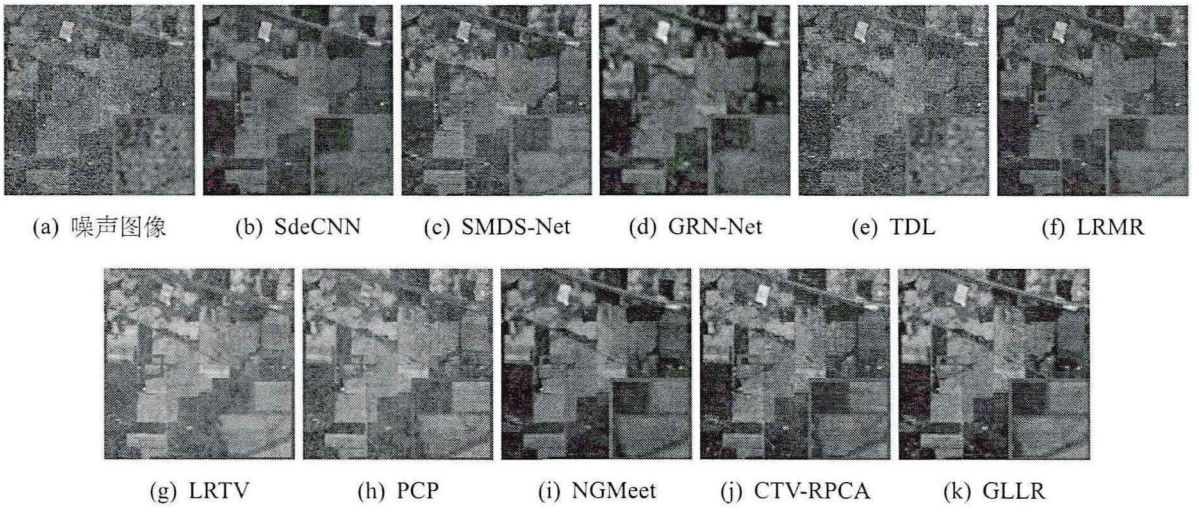

图 4.7　Indian Pines 数据（波段 2）复原结果可视化
Fig. 4.7　Visualization of restoration results of Indian Pines (band 2)

Indian Pines 数据在空间分辨率、光谱分辨率、场景特征以及噪声类型与强度方面存在显著差异。如 Urban 数据的第 104 波段受到随机噪声与条纹噪声的联合干扰，而 Indian Pines 数据的第 2 波段主要受脉冲噪声的影响。本章选择这些具有代表性的波段进行定性分析，并在图 4.7 和图 4.8中展示了不同方法的去噪结果图。

2) Urban 数据: 与 Indian Pines 数据不同，Urban 数据受到高斯噪声和条纹噪声的双重干扰。图 4.8 展示了不同方法在该数据上的恢复结果。图 4.8(e) 中 TDL 方法去噪效果有限，图像中仍存在明显的噪声残留。SMDS-Net 在一定程度上抑制了高斯噪声，但条纹噪声残留仍然较为明显。图 4.8(b)-(d) 中的结果显示 SdeCNN、SMDS-Net 和 GRN-Net 这几种方法在去噪过程中导致图像内部结构信息丢失，平滑效应较为严重。图 4.8 (f)-(k) 对应的 LRMR、PCP、LRTV、NGMeet 和 CTV-RPCA 这几种方法均在一定程度上实现了混合噪声的去除，但去噪质量存在差异。为了进一步分析恢复细

中国知网　https://www.cnki.net

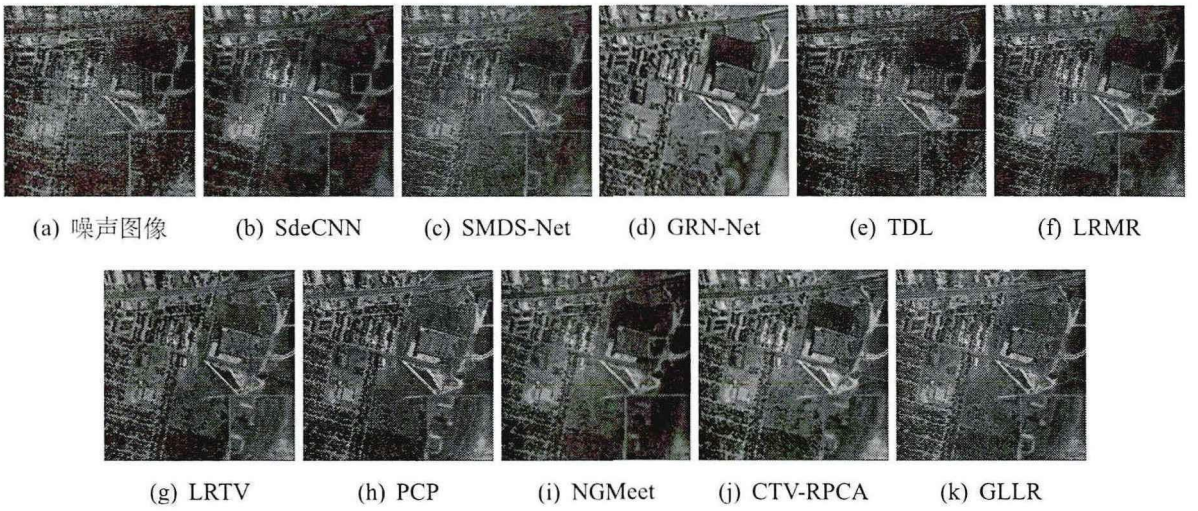

图 4.8 Urban 数据（波段 104）复原结果可视化
Fig. 4.8 Visualization of restoration results of Urban (band 104)

节，本文对局部区域进行了放大。结果表明，LRMR、NGMeet 和 CTV-RPCA 的去噪结果仍然存在一定的细节丢失现象。相比之下，PCP、LRTV 和 GLLR 在噪声抑制和空间结构保持方面表现优越，能够更好地恢复真实图像信息。

综上所述，在两个不同空间分辨率、场景结构与噪声类型的真实高光谱数据上的实验结果表明，所提 GLLR 方法具有较强的泛化能力，能够有效去除不同类型的混合噪声，同时较好地保持图像的结构细节。实验结果验证了其在真实高光谱图像去噪中的有效性与可靠性以及复杂噪声场景下的稳定性。这也体现了 LMD 作为补偿策略，在恢复过程中起到了关键作用，使得 GLLR 方法在视觉上的恢复性能不弱于性能经典和前沿方法。但是仅从视觉上的结果无法对其进行全面的评估，因此，在第4.4.3节中，进一步比较分析了不同方法复原的 Indian Pines 数据在下游数据分析中对精度提升的效果。

4.4.3 复原数据在下游任务中验证

为验证 GLLR 复原数据在下游分析任务中的有效性，本部分对去噪前后数据的分类性能对比分析。具体而言，通过采用支持向量机对 Indian Pines 数据的去噪前后影像进行分类实验，并以总体精度 OA 和 Kappa 系数作为关键评估指标，定量衡量去噪对分类效果的提升。为减少光谱冗余并保持关键信息，实验选择了信息熵最低的前 8 个波段，同时从数据中随机抽取 30% 的样本用于训练。在图4.9中对十六种地物覆盖类别的分类结果进行了可视化呈现，其中4.9(b) 为未去噪数据的分类结果，4.9(c)-(l) 则分别展示了不同去噪方法复原数据的分类表现。

此外，表 4.3 汇总了各方法的定量评估结果。结果表明，相较于原始受噪声污染的高光谱图像，经过去噪处理后几乎所有方法的 OA 和 Kappa 系数均有显著提升，这验证了高光谱图像去噪技术在提高遥感影像分析性能方面的重要性。值得注意的是，

中国知网 https://www.cnki.net

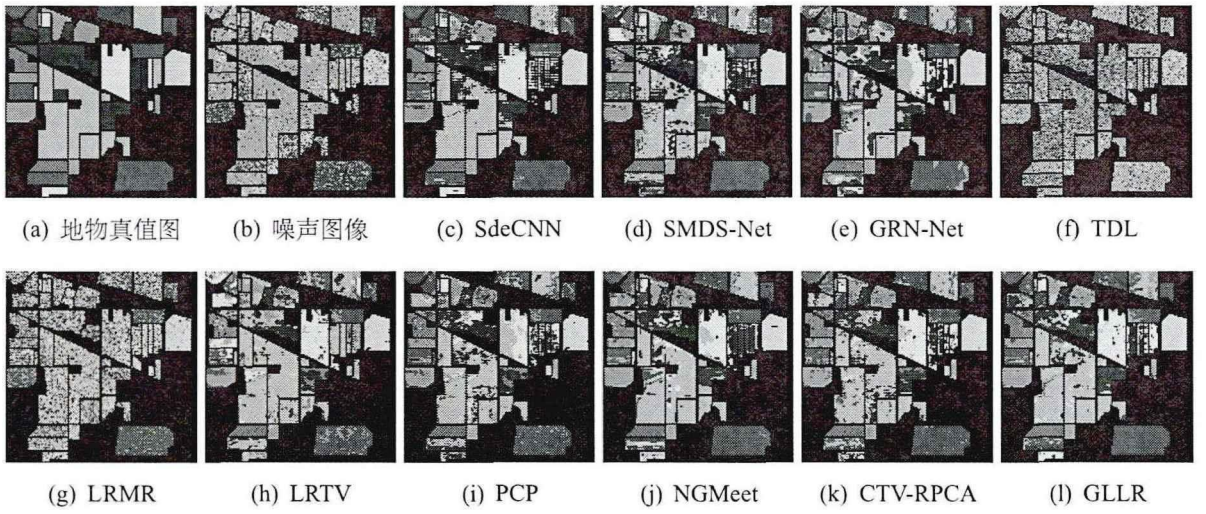

图 4.9 不同方法复原的 Indian Pines 分类结果图

Fig. 4.9 Classification results of Indian Pines restored by different methods

表 4.3 不同方法复原的 Indian Pines 分类精度

Tab. 4.3 Classification accuracy of Indian Pines restored by different methods

指标	噪声图像	SdeCNN	SMDS-Net	GRN-Net	TDL	LRMR	PCP	LRTV	NGMeet	RPCA	GLLR
OA	39.02%	80.84%	68.88%	62.65%	12.37%	41.83%	66.62%	61.73%	75.99%	74.47%	**81.59%**
Kappa	0.2377	0.7757	0.6378	0.5647	0.0414	0.3004	0.6083	0.5485	0.7197	0.7016	**0.7845**

所提 GLLR 方法在所有对比方法中表现最佳，获得了最高的 OA 和 Kappa 系数。实验结果表明，GLLR 不仅能够有效恢复图像结构信息，还有能够显著提升高光谱图像在下游分析任务中的可用性和可靠性。

4.4.4 讨论

前面的内容展示了 GLLR 在模拟数据与真实数据上的实验结果。本节将进一步深入探讨 GLLR 涉及的相关参数：λ_1 和 λ_2 的变化对其去噪性能的影响。关于参数 r_1 的选择，现有研究提供了两种主要的估计方法[135]：一种是基于 Hysime 算法[138] 的噪声水平估计方法，另一种则是依赖经验观测的估计方法。对于参数 r_2，目前的主要做法是通过人工经验进行调整。为了全面评估所提去噪方法的鲁棒性，本研究对不同 λ_1 和 λ_2 参数组合下的性能进行了系统分析。

(1) 参数 λ_1 的敏感性分析：作为控制 GLLR 性能的关键正则化参数，λ_1 的取值遵循 $\lambda_1 = c/\sqrt{MN}$ 的数学表达式，其中调节系数 c 从离散参数集 $1, 2, 3, 4, 5, 6, 8, 10, 13, 20$ 中选取。图4.10展示了采用 GLLR 求解器时，MPSNR 与 MSSIM 值随参数变化的响应曲线。实验数据显示，当 c 在 [3,20] 区间变化时，MPSNR 和 MSSIM 的值保持相对稳定。基于此，本研究最终选定 $c = 5$，以确保获得稳定且可接受的去噪结果。

中国知网 https://www.cnki.net

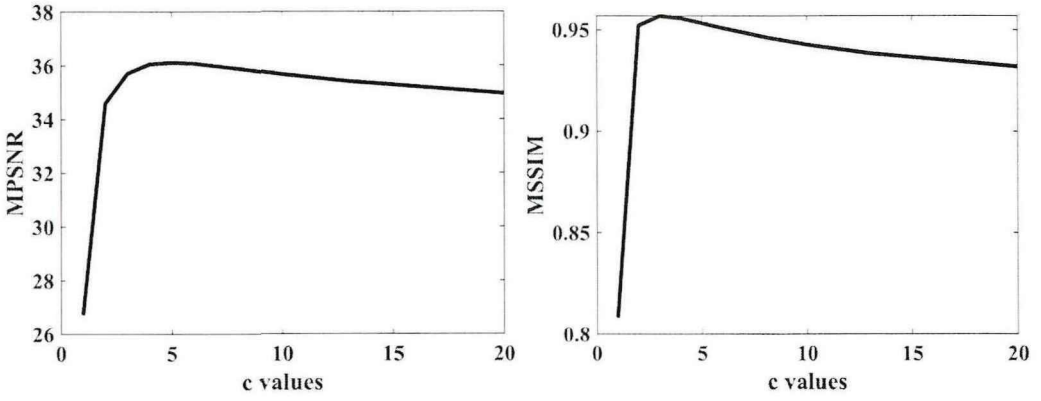

(a) MPSNR (b) MSSIM

图 4.10 参数 λ_1 的敏感性分析

Fig. 4.10 Sensitivity analysis of parameter λ_1

(2) 参数 λ_2 的敏感性分析：参数 λ_2 的取值范围为 {0.0001, 0.0004, 0.001, 0.004, 0.007, 0.01, 0.02, 0.03}。图 4.11 展示了不同 λ_2 设置下 GLLR 复原结果的 MPSNR 和 MSSIM 值变化趋势。从图中可以观察到，当 $\lambda_2 \approx 0.02$ 时，所提出的方法获得了最优的 MPSNR 值。

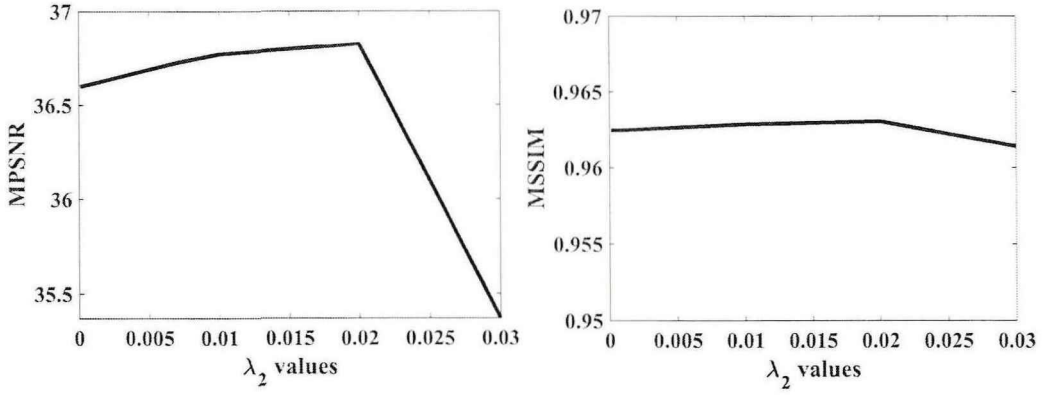

(a) MPSNR (b) MSSIM

图 4.11 参数 λ_2 的敏感性分析

Fig. 4.11 Sensitivity analysis of parameter λ_2

需要说明的是，实验中真实噪声高光谱数据的实验参数选择同样遵循了上述分析结果。以参数 c 为例，根据图 4.10 的分析，当 $c \in [3, 20]$ 时，MPSNR 和 MSSIM 的值保持相对稳定。因此，为确保真实数据的去噪结果在可接受范围内，GLLR 选择 $c = 5$ 作为固定值。参数 λ_1 可通过公式 $\lambda_1 = c/\sqrt{MN}$ 来设置。类似地，参数 λ_2 和秩的选择亦可依据图 4.10 中的分析原则进行确定。

(3) 消融实验：本章所提 GLLR 方法从兼顾图像全局和局部结构部角度提出局部结构低秩正则项 LMD，并结合了全局相关变分低秩先验。为深入评估 LMD 项对 GLLR 性能的贡献，在 Pavia City 数据 (案例 5) 上开展了系统地消融实验，对比分析

中国知网 https://www.cnki.net

了包含和不包含 LMD 项两种情况下的算法性能差异。基于此，定义 (4.29) 中的目标函数，并同样采用基于 ALM 技术的迭代优化算法进行求解。

$$\begin{aligned} &\min_{\mathbf{X},\mathbf{S},\mathbf{H},\mathbf{J}} \sum_{i=1}^{3} \|\mathbf{H}_i\|_* + 3\lambda_1 \|\mathbf{S}\|_1 \\ &\text{s.t. } \|\mathbf{Y}-\mathbf{X}-\mathbf{S}\|_F^2 \le \delta, \quad \nabla_i(\mathbf{X}) = \mathbf{H}_i, \quad \text{rank}(\mathbf{H}) \le r_1 \end{aligned} \tag{4.29}$$

所设计的消融实验结果如表 4.4 所示，其中 'Without LMD' 表示未添加 LMD 正则项的结果，实验结果表明，引入 LMD 正则项后去噪性能得到了显著提升，充分验证了 LMD 在模型中的有效性和必要性。

表 4.4 消融实验

Tab. 4.4 Ablation experiment

指标	CTV	Without LMD	With LMD
PSNR	34.84	35.11	**36.13**
SSIM	0.946	0.949	**0.953**
SAM	5.65	5.52	**4.96**
ERGAS	74.71	72.53	**63.65**

4.5 本章小结

针对高光谱图像在采集过程中易受多种噪声干扰，以及现有复原方法过度依赖图像全局属性而忽视局部结构特征等问题，本章提出了一种融合全局变分和局部结构低秩模型的高光谱图像去噪方法。该方法通过深入挖掘高光谱图像的内在结构特征，设计了一种新型结构低秩正则项，有效捕捉了图像局部细节信息。通过将局部结构信息融入到去噪模型中，实现了对噪声退化图像的精确恢复。

实验结果表明，所提 GLLR 方法在多组模拟数据和真实数据集上均展现出卓越的去噪性能。在包含不同噪声类型和强度水平的混合噪声退化场景中，所提方法均取得了显著的效果，充分证实了局部结构信息的引入对提升图像质量是有益的。此外，去噪后数据在分类任务中的性能提升进一步验证了所提方法在实际应用中的有效性和实用性。

中国知网 https://www.cnki.net

5 基于反馈式波段组群和变分低秩稀疏模型的高光谱异常检测算法

5.1 引言

除了上述利用高光谱图像复原技术提升数据支持的可靠性和应用潜力外，在任务中考虑噪声干扰并对其进行抑制也为下游数据分析性能提升提供了可行的技术方案。随着高光谱图像成像技术的快速发展，高光谱图像凭借其卓越的光谱分辨率在对地观测中展现出前所未有的应用潜力[139,140]。高光谱异常检测技术因其无需任何先验知识即可识别潜在目标的独特优势，在众多应用场景中展现出重要价值。由于缺乏异常先验信息，异常目标检测通常依赖于异常目标与背景之间的光谱特征差异，从而在复杂背景中提取出潜在的异常目标[141]。然而，由于成像系统和设备本身的局限性，获取的高光谱图像不可避免的受到噪声的干扰[136,142]，这不仅破坏了光谱特征的可靠性，对异常检测性能也产生了不利影响[9,143]。总变分模型的分段平滑特性有益于抑制图像中的噪声干扰，因此其在高光谱异常检测领域中发挥了显著作用。但面对复杂背景或弱目标场景时，现有方法在噪声抑制和异常目标信号保持方面难以取得理想平衡。因此如何在非监督的情况下建立噪声抑制与下游数据分析需求之间更深层次的连接，具有重要研究意义。此外，高光谱数据具有信息量大、冗余多的特点。在这种背景下，全波段处理可能导致计算量和冗余信息的增加，波段之间的相互“干扰”也可能限制数据分析性能提升，从而影响异常目标检测任务的效率和精度[144]。

针对上述挑战，本章提出了一种基于反馈式波段组群和变分低秩稀疏模型的高光谱异常检测方法 (Feedback Band Group and Variation Low-rank Sparse Model for Hyperspectral Anomaly Detection，FBGVLRS)。该方法首先采用均匀波段选择 (Uniform Band Selection，UBS) 策略对光谱波段进行划分，进而在波段组群上进行数据分解。其次，采用 $L_{2,1}$ 范数联合相关总变分来抑制噪声并提取感兴趣的异常目标。最后，设计了一种迭代反馈框架，利用已有波段组群的检测信息来引导和促进下一个波段组群稀疏成分的提取，持续强化感兴趣的异常要素。实验结果表明，FBGVLRS 在计算效率和检测精度方面均取得显著提升，为高光谱异常检测提供了新的技术路径。

本章后续部分内容组织如下，第 5.2 节简要阐述了低秩稀疏矩阵分解的高光谱图像异常检测的相关研究基础；第 5.3 节介绍了提出的反馈式波段组群和变分低秩稀疏模型的高光谱图像异常检测方法的设计思路和理论推导过程；第 5.4 节中展示了所提方法在多组数据上的实验结果，并进行详细分析，验证了本章所提方法的有效性；第 5.5 节对本章工作进行了总结概述。

5.2 基于低秩稀疏矩阵分解的高光谱异常检测

高光谱数据通常表示为一个三维数据立方体 $\mathcal{X} \in \mathbb{R}^{h\times w\times b}$，具有 $h \times w$ 的空间尺寸大小，包含 b 个波段，可将其展开为二维矩阵形式 $\mathbf{X} \in \mathbb{R}^{b\times n}$，其中 $n = h \times w$ 为图

中国知网 https://www.cnki.net

像中像素的总数。由于高光谱图像背景像素间存在显著的相关性，这些像素可通过线性组合有效表示。基于此，原始数据可分解为：

$$\mathbf{X} = \mathbf{L} + \mathbf{S} \tag{5.1}$$

上式表明，原始高光谱数据 $\mathbf{X}$ 可以视为由一个低秩背景矩阵 $\mathbf{L}$ 和一个稀疏异常矩阵 $\mathbf{S}$ 构成。在这一框架下，对 $\mathbf{L}$ 和 $\mathbf{S}$ 施加约束是常见的求解方法。考虑到高光谱数据具有显著相关性，通常的做法是对 $\mathbf{L}$ 施加低秩约束，而异常目标因其空间分布稀疏特性，其信息主要集中于 $\mathbf{S}$ 中。因此，公式 (5.1) 中的问题可转化为以下优化问题：

$$\begin{aligned} &\min_{\mathbf{L},\mathbf{S}} rank(\mathbf{L}) + \beta\|\mathbf{S}\|_0 \\ &\text{s.t. } \mathbf{X} = \mathbf{L} + \mathbf{S} \end{aligned} \tag{5.2}$$

进一步地，由于异常目标在光谱维度上区别于噪声，通常表现出良好地光谱连续性，可利用 $L_{2,1}$ 范数强化 $\mathbf{S}$ 的列稀疏性：

$$\begin{aligned} &\min_{\mathbf{L},\mathbf{S}} rank(\mathbf{L}) + \beta\|\mathbf{S}\|_{2,1} \\ &\text{s.t. } \mathbf{X} = \mathbf{L} + \mathbf{S} \end{aligned} \tag{5.3}$$

其中，$\beta > 0$ 为权衡系数，$\text{rank}(\cdot)$ 表示矩阵秩函数，$\|\cdot\|_{2,1}$ 为混合范数，用于促进矩阵 $\mathbf{S}$ 列的稀疏性[145]，其具体定义为：

$$\|\mathbf{S}\|_{2,1} = \sum_{j=1}^{hw} \sqrt{\sum_{i=1}^{b} \mathbf{S}_{i,j}^2} \tag{5.4}$$

该范数通过惩罚列向量的 L_2 范数和，鼓励矩阵列稀疏，从而更有效地分离异常目标。然而，方程 (5.3) 是一个非凸优化问题，且属于 NP 难问题。为有效解决该问题，常规做法是采用凸松弛技术，即利用核范数替代非凸的秩函数。由此得到凸优化问题：

$$\begin{aligned} &\min_{\mathbf{L},\mathbf{S}} \|\mathbf{L}\|_* + \beta\|\mathbf{S}\|_{2,1} \\ &\text{s.t. } \mathbf{X} = \mathbf{L} + \mathbf{S} \end{aligned} \tag{5.5}$$

其中，$\|\cdot\|_*$ 为矩阵核范数，可以通过奇异值阈值方法进行求解，该凸松弛形式可保持对低秩结构的约束能力。

5.3 反馈式波段组群和变分低秩稀疏模型的异常检测

为提升计算效率并缓解波段间干扰，本章设计了一种波段组检测机制，将全波段数据划分为若干波段组，进行级联式处理。具体而言，它由三个组成部分构成：1)

中国知网 https://www.cnki.net

首先，利用 UBS 进行数据分组，在保证计算效率的同时减少光谱冗余；2) 通过相关总变分低秩约束与稀疏范数的协同作用，实现非异常成分与目标信号的精确分离；3) 利用前期检测信息动态指导后续分解过程，形成性能增强的迭代系统。图 5.1 为所提 FBGVLRS 异常检测方法的实现框架图。

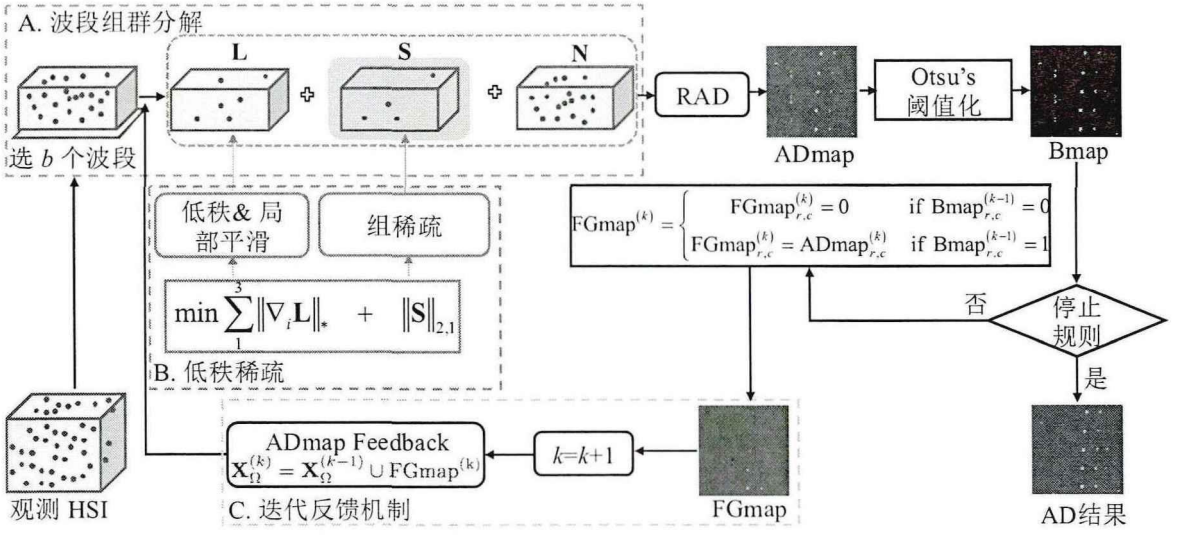

图 5.1　FBGVLRS 的流程图

Fig. 5.1　Flowchart of FBGVLRS

5.3.1　波段组内的低秩稀疏矩阵分解

为有效抑制背景信息的干扰，FBGVLRS 在波段组内应用了低秩和稀疏表示。波段组上进行数据分解具有以下优势：1) 降低算法计算负担。直接对全波段数据进行分解需要更大的计算负担。不同于 PCA 和波段选择的预处理，FBGVLRS 并没有选择性的保留或者去除某些信息或者波段，而是通过 UBS 将大规模的全波段数据运算划分为多个波段组上的小规模运算，迭代处理这些子问题。这样做可以保留足够的信息用于后续处理，避免了由于缺少先验知识造成的有用波段信息损失对异常检测性能的限制。2) 减少波段间干扰。波段冗余多会增加 **N** 和 **S** 的区分难度，进而影响 **S** 提取的准确性。通过这种划分处理，可以降低非异常成分的干扰。3) 不同波段集合间的异常检测效果具有一定的一致性和互补性。FBGVLRS 中设计的波段组迭代分解框架能够利用已有的波段组检测知识引导和促进后续波段组中稀疏成分 **S** 的提取，强化异常要素。波段组上分解模型可表示为：

$$\begin{aligned} &\min_{\mathbf{L}_\Omega, \mathbf{S}_\Omega} \|\mathbf{L}_\Omega\|_* + \beta \|\mathbf{S}_\Omega\|_{2,1} \\ &\text{s.t. } \mathbf{X}_\Omega = \mathbf{L}_\Omega + \mathbf{S}_\Omega + \mathbf{N}_\Omega \end{aligned} \tag{5.6}$$

其中，$\Omega = b_1, b_2, ..., b_i$ 表示通过 UBS 选择的波段组。

在所提异常检测方法实现中，用于波段组数量确定的关键参数 j 需要预先计算。

中国知网　https://www.cnki.net

根据参考文献 [146, 147]，j 被视为稀疏矩阵 $\mathbf{S}$ 的秩，可通过 MX-SVD[148] 计算得到。虚拟维度（VD）[149] 可用于估计低秩矩阵 $\mathbf{L}$ 和稀疏矩阵 $\mathbf{S}$ 的总基向量数估计 p，满足 $p=m+j$，其中，$m=p-j$ 表示 $\mathbf{L}$ 的秩。需要注意的是，HFC[150,151] 和 NWHFC[149,150] 都可以用来估计 VD 的值，分别用记为 $\mathrm{VD}^{\mathrm{HFC}}$ 和 $\mathrm{VD}^{\mathrm{NWHFC}}$ 。

5.3.2 基于相关总变分的分段平滑和低秩先验

高光谱数据中的大部分区域通常为非异常信息，且这些非异常区域在空间上具有连续性与光谱低秩特性。低秩稀疏方法虽然能够保留数据主要信息，但由于忽略了图像的空间分段连续特性，导致非异常的低秩成分提取不足问题。这一问题可能进而导致两种情况发生：一是部分异常成分被错误地识别为背景，降低异常检测灵敏度；二是背景成分被误判为异常，增加误警率。

为解决上述问题，本章引入相关总变分正则项联合 $L_{2,1}$ 范数编码背景和异常特征，促进模型的背景和异常分离能力。相关总变分在保持数据分段平滑特性和低秩属性的同时，避免了引入过多参数；$L_{2,1}$ 可以确保异常成分的稀疏特性，从而保留感兴趣的异常目标。最终，所提出的目标模型可表述为：

$$\begin{aligned}&\min_{\mathbf{L}_\Omega,\mathbf{S}_\Omega}\sum_{i=1}^{3}\|\nabla_i\mathbf{L}_\Omega\|_*+\beta\|\mathbf{S}_\Omega\|_{2,1}\\&\text{s.t. }\mathbf{X}_\Omega=\mathbf{L}_\Omega+\mathbf{S}_\Omega+\mathbf{N}_\Omega,\quad i=1,2,3\end{aligned}\tag{5.7}$$

其中，∇_1、∇_2 和 ∇_3 分别表示水平、垂直和光谱三个方向的一阶差分算子。

为简化优化过程，引入辅助变量 $\mathbf{J}=\nabla\mathbf{L}_\Omega$，则 (5.7) 中的第一项 $\sum_{i=1}^{3}\|\nabla_i\mathbf{L}_\Omega\|_*$ 可重新表达为 $\sum_{i=1}^{3}\|\mathbf{J}_i\|_*$。在不影响一般性的前提下，用 $\mathbf{X}$、$\mathbf{L}$、$\mathbf{S}$ 和 $\mathbf{N}$ 代替 $\mathbf{X_B}$、$\mathbf{L_B}$、$\mathbf{S_B}$ 和 $\mathbf{N_B}$ 进行求解过程的推导。在此基础上，所提出的问题可以转化为：

$$\begin{aligned}&\min_{\mathbf{X},\mathbf{S}}\sum_{i=1}^{3}\|\mathbf{J}_i\|_*+\beta\|\mathbf{S}\|_{2,1}\\&\text{s.t. }\mathbf{X}{=}\mathbf{L}{+}\mathbf{S}{+}\mathbf{N}\qquad\mathbf{J}_i{=}\nabla_i(\mathbf{L})\end{aligned}\tag{5.8}$$

优化问题 (5.8) 可采用增强拉格朗日法求解，其可重写为以下增强拉格朗日函数：

$$\begin{aligned}\min_{\mathbf{L},\mathbf{S}}\ell(\mathbf{L},\mathbf{S},\mathbf{J},\mathbf{\Gamma}_i)=\min_{\mathbf{L},\mathbf{J},\mathbf{S},\mathbf{\Gamma}}\sum_{i=1}^{3}\left(\|\mathbf{J}_i\|_*+\frac{\lambda}{2}\|\nabla_i\mathbf{L}-\mathbf{J}\|_F^2+<\mathbf{\Gamma}_i,\nabla_i\mathbf{L}-\mathbf{J}_i>\right)\\+<\mathbf{\Gamma},\mathbf{X}-\mathbf{L}-\mathbf{S}>+\frac{\lambda}{2}\|\mathbf{X}-\mathbf{L}-\mathbf{S}\|_F^2+\beta\|\mathbf{S}\|_{2,1}\end{aligned}\tag{5.9}$$

其中，λ 为惩罚参数，用于平衡目标函数各项的权重；$\mathbf{\Gamma}$ 为拉格朗日乘子，$<\cdot,\cdot>$ 表示矩阵的 Frobenius。求解上述问题的典型方法是交替的优化每个变量，而其它变量

中国知网 https://www.cnki.net

保持不变。详细地说，在第 $t+1$ 次迭代中，各变量的更新为：

$$\begin{aligned}
\mathbf{J}_i^{t+1} &= \underset{rank(\mathbf{J}_i)\leq r}{\arg\min}\ \ell\left(\mathbf{J},\mathbf{L}^t,\mathbf{S}^t,\mathbf{\Gamma}^t\right)\\
\mathbf{L}^{t+1} &= \underset{\mathbf{L}}{\arg\min}\,\ell\left(\mathbf{J}^{t+1},\mathbf{L},\mathbf{S}^t,\mathbf{\Gamma}^t\right)\\
\mathbf{S}^{t+1} &= \underset{\mathbf{S}}{\arg\min}\,\ell\left(\mathbf{J}^{t+1},\mathbf{L}^{t+1},\mathbf{S},\mathbf{\Gamma}^t\right)\\
\mathbf{\Gamma}^{t+1} &= \mathbf{\Gamma}^t+\lambda\left(\mathbf{X}-\mathbf{L}^{t+1}-\mathbf{S}^{t+1}\right)
\end{aligned} \tag{5.10}$$

通过将 (5.9) 分解为 (5.10) 中的主要子问题，可以推导出以下更新方程。

1) **J** 相关子问题的更新可以通过求解以下方程获得：

$$\begin{aligned}
\mathbf{J}_i^{t+1} &= \underset{rank(\mathbf{J}_i)\leq r}{\arg\min}\ \ell\left(\mathbf{J},\mathbf{L}^t,\mathbf{S}^t,\mathbf{\Gamma}^t\right)\\
&= \underset{rank(\mathbf{J}_i)\leq r}{\arg\min}\ \|\mathbf{J}_i\|_*+\frac{\lambda}{2}\|\nabla_i\mathbf{L}-\mathbf{J}\|_F^2+<\mathbf{\Gamma}_i,\nabla_i\mathbf{L}-\mathbf{J}_i>\\
&= \underset{rank(\mathbf{J}_i)\leq r}{\arg\min}\ \|\mathbf{J}_i\|_*+\frac{\lambda}{2}\left\|\nabla_i\mathbf{L}-\mathbf{J}_i+\frac{\mathbf{\Gamma}_i}{\lambda}\right\|_F^2
\end{aligned} \tag{5.11}$$

进一步地，问题 (5.11) 的解可以表示为：

$$\begin{cases}
\mathbf{J}_i^{t+1}=\mathbf{U}\mathbf{S}_{1/\lambda}(\mathbf{\Sigma})\mathbf{V}^T\\
\boldsymbol{U}\mathbf{\Sigma}\mathbf{V}^T=svd(\nabla_i\mathbf{L}^t+\mathbf{\Gamma}_i/\lambda,'econ')
\end{cases} \tag{5.12}$$

2) **S** 相关子问题的更新可以通过求解以下方程获得：

$$\begin{aligned}
\mathbf{S}^{t+1} &= \underset{\mathbf{S}}{\arg\min}\,\ell\left(\mathbf{J}^{t+1},\mathbf{L}^{t+1},\mathbf{S},\mathbf{\Gamma}^t\right)\\
&= \underset{\mathbf{S}}{\arg\min}\,\beta\|\mathbf{S}\|_{2,1}+<\mathbf{\Gamma},\mathbf{X}-\mathbf{L}-\mathbf{S}>+\frac{\lambda}{2}\|\mathbf{X}-\mathbf{L}-\mathbf{S}\|_F^2\\
&= \underset{\mathbf{S}}{\arg\min}\,\mu\|\mathbf{S}\|_{2,1}+\frac{\lambda}{2}\left\|\mathbf{X}-\mathbf{L}-\mathbf{S}+\frac{\mathbf{\Gamma}_4}{\lambda}\right\|_F^2
\end{aligned} \tag{5.13}$$

(5.13) 可借助以下方程[152] 求解，

$$[\mathbf{S}]_{i,:}=\begin{cases}
\frac{\|[\mathrm{E}]_{i,:}\|_2-\beta_2}{\|[\mathrm{E}]_{i,:}\|_2}[\mathrm{E}]_{i,:}, & \beta_2<\left\|[\mathrm{E}]_{i,:}\right\|_2\\
0, & \text{otherwise}
\end{cases} \tag{5.14}$$

其中，$\mathrm{E}=\mathbf{X}-\mathbf{L}+\frac{\mathbf{\Gamma}_4}{\lambda}$ 和 $\beta_2=\mu/\lambda$。

3) **L** 相关子问题的更新可以通过求解以下方程获得：

中国知网 https://www.cnki.net

$$\begin{aligned}\mathbf{L}^{t+1} &= \arg\min_{\mathbf{L}} \ell\left(\mathbf{J}_i^{t+1}, \mathbf{L}, \mathbf{S}^t, \mathbf{\Gamma}^t\right) \\ &= \arg\min_{\mathbf{L}} \|\mathbf{J}_i\|_* + \frac{\lambda}{2}\|\nabla_i \mathbf{L} - \mathbf{J}\|_F^2 + <\mathbf{\Gamma}_i, \nabla_i \mathbf{L} - \mathbf{J}_i> \\ &\quad + <\mathbf{\Gamma}, \mathbf{X} - \mathbf{L} - \mathbf{S}> + \frac{\lambda}{2}\|\mathbf{X} - \mathbf{L} - \mathbf{S}\|_F^2 \\ &= \arg\min_{\mathbf{L}} \sum_{i=1}^{3} \frac{\lambda}{2}\left\|\nabla_i \mathbf{L} - \mathbf{J}_i^{t+1} + \frac{\mathbf{\Gamma}_i^t}{\lambda}\right\|_F^2 + \frac{\lambda}{2}\left\|\mathbf{X} - \mathbf{L} - \mathbf{S}^{t+1} + \frac{\mathbf{\Gamma}_4^t}{\lambda}\right\|_F^2\end{aligned} \tag{5.15}$$

(5.15) 可以通过以下公式更新，

$$\left(\lambda \mathbf{I} + \lambda \sum_{i=1}^{3} \nabla_i^T \nabla_i\right) \mathbf{L} = \lambda\left(\mathbf{X} - \mathbf{S}^{t+1}\right) + \mathbf{\Gamma}_4^t + \lambda \sum_{i=1}^{3} \nabla_i^T\left(\mathbf{J}_i^{t+1}\right) - \nabla_n^T\left(\mathbf{\Gamma}_n^t\right) \tag{5.16}$$

其中，∇_i^T 表示 $\nabla_i(\cdot)$ 的转置算子。$\nabla_i^T \nabla_i$ 可以通过三维快速傅立叶变换矩阵对角化。$\mathbf{L}^{t+1}$ 的可行解可以通过对 (5.16) 的两边进行傅里叶变换，并采用卷积定理推导出。

$$\begin{cases} \mathbf{H} = \sum_{i=1}^{3} F(\mathbf{D}_n)^* \odot F\left(\text{fold}\left(\mu \mathbf{J}_i^{t+1} - \mathbf{\Gamma}_i^t\right)\right) \\ \mathbf{T}_x = |F(\mathbf{D}_1)|^2 + |F(\mathbf{D}_2)|^2 + |F(\mathbf{D}_3)|^2 \\ \mathbf{L}^{t+1} = F^{-1}\left(\frac{F\left(\text{fold}\left(\mu \mathbf{X} - \lambda \mathbf{S}^{t+1} + \mathbf{\Gamma}_4^t\right)\right) + \mathbf{H}}{\lambda(\mathbf{1} + \mathbf{T}_x)}\right) \end{cases} \tag{5.17}$$

(5.17) 中的 $\odot$ 和 $|\cdot|^2$ 分别是元素乘法和平方运算。$F(\cdot)$ 表示傅里叶变换。

4）最后，拉格朗日乘数的更新可以表示为：

$$\begin{aligned} \mathbf{\Gamma}_i^{t+1} &= \mathbf{\Gamma}_i^t + \lambda\left(\nabla_i \mathbf{L}^{t+1} - \mathbf{J}_i^{t+1}\right) \\ \mathbf{\Gamma}_4^{t+1} &= \mathbf{\Gamma}_4^t + \lambda\left(\mathbf{X} - \mathbf{L}^{t+1} - \mathbf{S}^{t+1}\right) \\ \lambda &= \lambda\rho \end{aligned} \tag{5.18}$$

上式中，$\rho > 1$ 为常数。

5.3.3 波段组间引导与优化反馈机制的设计

尽管基于波段组 BS 的数据分解有益于降低计算负担，但 UBS 并非针对异常目标设计的波段选择，其在异常目标检测中存在一定的局限性。为突破这一限制，本章设计迭代反馈机制，其核心思想是通过建立前向信息传递通道，将提取的目标信息动态的融入分解过程。该机制的设计基于以下重要发现[139]：1) 异常检测器通常仅生成单一的异常目标检测结果图，难以充分表征目标的空间-光谱特征；2) 检测结果中隐含的异常分布信息可指导后续波段组的优化分解。为了更好地利用检测图中反映的目标信息，FBGVLRS 设计了 FGmap 来提取前序波段组的检测信息。具体而言，采用 Otsu 方法[153] 对检测图进行阈值分割，生成二值图 Bmap。在 FGmap 中，根据 Bmap

中国知网 https://www.cnki.net

Algorithm 5.1 基于反馈式波段组群和变分低秩稀疏模型的高光谱异常检测

输入: $\mathbf{X} \in \mathbb{R}^{n\times b}$, $\lambda = 1\sqrt{hw}$, φ;
输出: 异常目标检测结果;

初始化: $\Omega_{\mathbf{X}}^{(k)} = \mathbf{X}$, $\mathbf{L} = \text{randn}(hw, b/j)$, $\mathbf{S} = \mathbf{0}$, $k = 0$;
while $0 \le k < K \wedge \text{TI}^{(k)} = \frac{|\text{Bmap}^{(k)} \cap \text{Bmap}^{(k-1)}|}{|\text{Bmap}^{(k)} \cup \text{Bmap}^{(k-1)}|} \ge \varphi$ **do**;
    选择波段组: $\mathbf{X}_{\Omega}^{(k)}$ =UBS_{HSI};
    while $0 \le t < T \wedge \|\mathbf{X} - \mathbf{L}^{t+1} - \mathbf{S}^{t+1}\|_F^2 / \|\mathbf{X}\|_F^2 \ge \tau_1$ **do**
        通过 (5.12) 计算 $\mathbf{J}^t$;
        基于 (5.14) 更新 $\mathbf{S}^t$;
        根据 (5.17) 更新 $\mathbf{L}^t$;
        由 (5.18) 优化 $\mathbf{\Gamma}^t$;
        $t \leftarrow t + 1$;
    end while
    在 $\Omega_{\mathbf{S}}^{(k)}$ 上执行 $\delta_{\mathbf{S}_j}^{\text{RAD}}\left(\mathbf{r}_{\mathbf{S}_j}\right)$ 生成 $\text{ADmap}^{(k)}$;
    采用 Otsu's 阈值化 $\text{ADmap}^{(k)}$ 生成 $\text{Bmap}^{(k)}$;
    创建 $\text{FGmap}^{(k)}$:

$$\text{FGmap}^{(k+1)} = \begin{cases} \text{FGmap}_{r,c}^{(k)} = 0 & \text{if } \text{Bmap}_{r,c}^{(k)} = 0 \\ \text{FGmap}_{r,c}^{(k)} = \text{ADmap}_{r,c}^{(k)} & \text{if } \text{Bmap}_{r,c}^{(k)} = 1 \end{cases}$$

    $k \leftarrow k + 1$;
    由 $\mathbf{X}_{\Omega}^{(k)} = \mathbf{X}_{\Omega}^{(k-1)} \cup \text{FGmap}^{(k)}$ 扩展当前立方体;
end while

保留检测图的原始信息以引导稀疏部分的分离，而背景部分则置为零。因此，FGmap 的定义如下:

$$\text{FGmap}^{(k+1)} = \begin{cases} \text{FGmap}_{r,c}^{(k)} = 0, & \text{Bmap}_{r,c}^{(k)} = 0 \\ \text{FGmap}_{r,c}^{(k)} = \text{ADmap}_{r,c}^{(k)}, & \text{Bmap}_{r,c}^{(k)} = 1 \end{cases} \tag{5.19}$$

根据式 (5.19)，利用 FGmap 中指示的潜在异常信息指导后续波段组的分解，构建 $\mathbf{X}_{\Omega}^{(k)} = \mathbf{X}_{\Omega}^{(k-1)} \cup \text{FGmap}^{(\text{k})}$，其中，$k$ 表示当前的迭代次数。迭代执行该过程，直到满足 (5.20) 中的停止规则[139]:

$$\text{TI}^{(k)} = \frac{|\text{Bmap}^{(k)} \cap \text{Bmap}^{(k-1)}|}{|\text{Bmap}^{(k)} \cup \text{Bmap}^{(k-1)}|} > \varphi \tag{5.20}$$

算法5.1总结了提出的 FBGVLR-AD 方法的完整处理流程。该方法主要分为两个阶段：背景和异常的精确分离以及已获取的检测信息的反馈。在第一个阶段，当相对误差或最大迭代次数满足条件时，内层优化过程终止。在第二个阶段，当连续两次 Bmap 的 $\text{TI}^{(k)}$ 值大于给定阈值 φ，或达到最大迭代次数 K，外层迭代过程停止。

上述机制通过建立"检测-反馈-优化"的检测方案，不仅充分利用了高光谱数据立

中国知网 https://www.cnki.net

方体所蕴含的丰富信息，有效减少计算复杂度，还缓解了缺乏异常先验下进行的波段子集选择对检测性能的限制，显著提升了算法对弱目标的检测能力，其有效性在5.4节中验证。

5.4 实验结果和性能分析

5.4.1 实验设置

(1) 实验数据

本章采用五组高光谱数据验证所提方法检测性能，下面是所使用数据集的详细介绍：

1) HYDICE15-panel：本数据集由高光谱数字图像收集实验传感器 (Hyperspectral Digital Imagery Collection Experiment, HYDICE) 于 1995 年获取，拍摄高度为 10,000 英尺，地面采样距离约为 1.56 米。该数据集已在大量研究中得到广泛分析[154,155]，其数据维度为$64 \times 64 \times 169$。该场景包含了三个尺寸的 15 个方形面板，分别为：$33m \times 3m$、$2m \times 2m$ 和 $1m \times 1m$。其中，第 2-5 行的第一列中每个面板都包含两个红色突出显示的目标像素，其余 11 个面板仅包含一个红色目标像素。因此，该场景共计包含 19 个红色面板像素。图5.2对其空间位置进行了精确标注，其中黄色像素表示与背景混合的面板像素。该场景的伪彩色图像、地物真值图以及光谱特征图分别如图5.2所示。

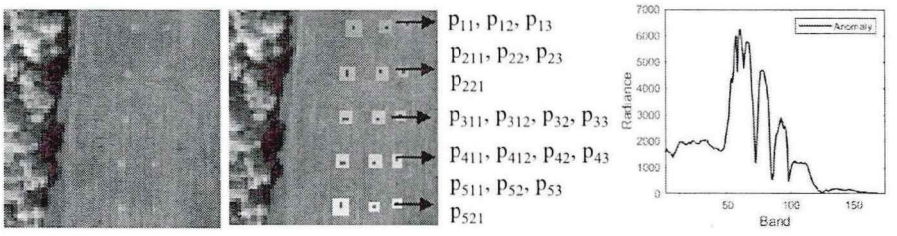

图 5.2 HYDICE15-panel 场景的伪彩色图像、地物真值图和光谱特征

Fig. 5.2 The pseudocolored image, ground truth, and spectral features of HYDICE15-panel scene

2) HYDICE Urban：该实验数据集同样由 HYDICE 传感器获取。原始场景尺寸为 307 ×307 像素，具有 188 个光谱波段。为了适用于异常检测研究，从中选取了 80 × 100 的子区域进行分析[156,157]。场景主要由高速公路、屋顶、车辆及工厂等地物组成，其中车辆被视为异常目标，总计包含 21 个异常像素。图 5.3展示了该数据集对应的伪彩色图像、地物真值图及其光谱特征图。

3) ABU-beach3：该数据由机载可见光/红外成像光谱仪（Airborne Visible/Infrared Imaging Spectrometer, AVIRIS）传感器获取，包含 188 个光谱波段，空间分辨率为 100×100 像素，异常目标由 11 个像素构成。该数据集广泛用于异常检测研究[158]。其对应的伪彩色图像、地面真实情况及光谱特征如图 5.3所示。

4) Pavia center：本数据集由反射光学系统成像光谱仪（Reflective Optics System Imaging Spectrometer, ROSIS）传感器在飞越意大利帕维亚市上空时获取[104]。原始高

中国知网 https://www.cnki.net

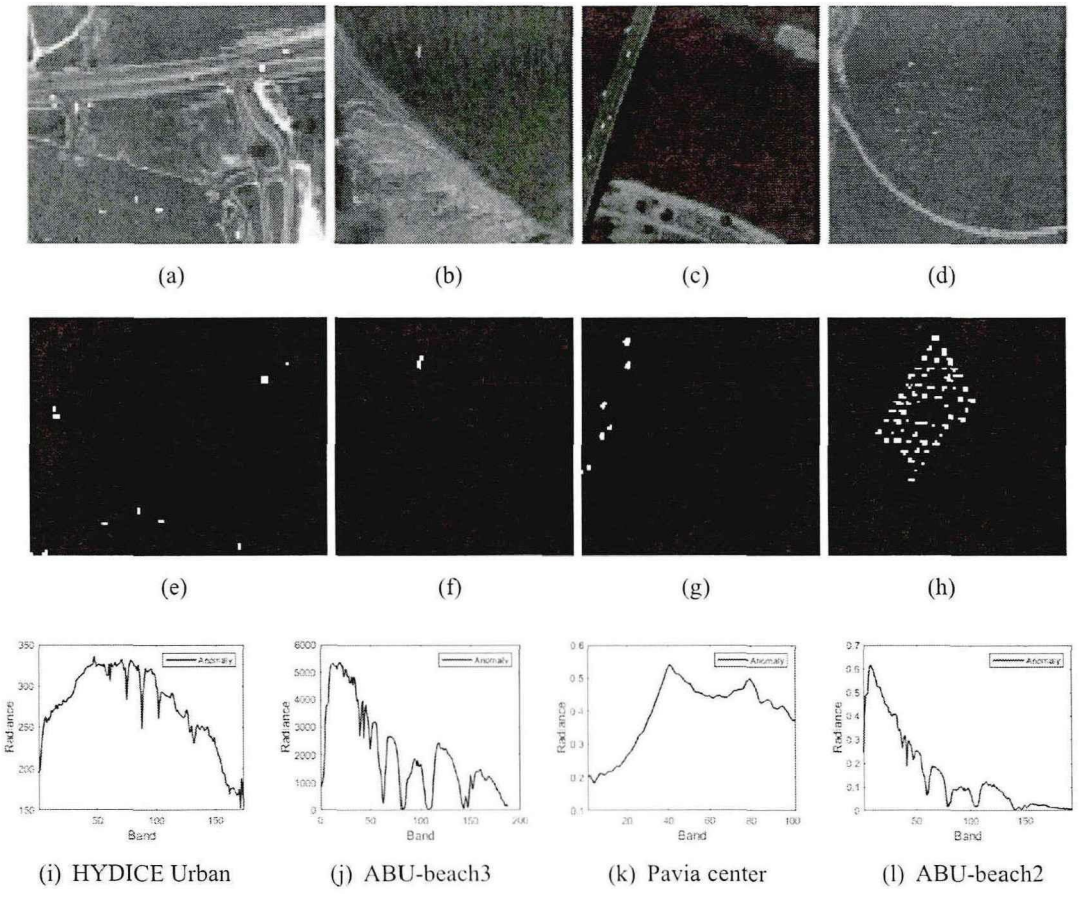

图 5.3　四个实验数据的伪彩色图像、地物真值图和光谱特征

Fig. 5.3　Pseudocolor images, ground-truth maps, and spectral signature of four experimental datasets

光谱数据尺寸为 1096×1096 像素，空间分辨率为 1.3 米，包含 102 个有效光谱波段。针对异常检测任务，部分尺寸大小为 150×150 像素的子区域被广泛研究分析[159]，其中异常目标主要包括桥梁及桥梁支撑结构上的车辆，共计 68 个异常像素。该场景的伪彩色图像、地面真实情况及光谱特征如图 5.3所示。

5) ABU-beach2：该数据集同样由 AVIRIS 传感器获取，空间分辨率为 100×100 像素，包含 193 个光谱波段。该场景中共有 202 个像素被视为异常目标，广泛用于异常检测研究中的性能验证[158]。其对应的伪彩色图像、地面真实情况及光谱特征如图 5.3 所示。

(2) 对比方法

为全面评估所提出方法的性能表现，本章将其与十二种经典和前沿方法进行了系统性对比。这些对比方法包括经典的异常检测方法（RXD[68] 和 RAD[72]）方法；五种低秩与稀疏建模方法（CTV[63]、OSP-GoDec[147]、RhyDe[8]、IFEBP[88] 和 AHMID[156]），基于张量表示的 PTA[160]，基于孤立森林的 SSIFD[161]，基于协作表示的 CRD[162]；以及两种基于自动编码器（Autoencode，AE）网络的高光谱异常检测方法（GAED[163] 和 RGAE[164]）。

中国知网 https://www.cnki.net

在具体对比分析中，本研究特别关注各方法的对比价值。RXD 作为经典的异常检测方法，为后续众多研究提供了重要参考。RAD 方法基于相关矩阵 **R** 进行异常目标识别。对于 OSP-GoDec，为确保对比公平性，本章统一采用稀疏空间检测器 $\delta_{\mathbf{S}}^{\mathrm{R-AD}}(\mathbf{r}_{\mathbf{S}})$ 进行异常检测。RhyDe 通过引入去噪与异常检测相结合的框架，显著提升了背景抑制能力，这为验证所提方法在去噪背景下的检测性能提供了重要参照。CTV-RPCA 方法是一种基于低秩和稀疏分解的高光谱去噪方法，其异常检测是基于稀疏矩阵 **S** 进行的，其对比结果有效反映所提方法在目标保持与提取方面的能力。PTA 方法通过张量建模同时考虑背景的低秩先验和异常目标的空间稀疏性，与之对比可评估所提方法在平衡背景抑制和目标检测方面的能力。CRD 方法利用协作表示进行异常检测，其对比结果凸显了所提方法在异常特征提取方面的优势。IFEBP 方法结合分数阶傅里叶变换与稀疏约束，与之对比分析验证了所提方法在异常表征和背景抑制方面的综合性能。AHMID 采用层次化互不干扰判别学习策略对数据的三种主要成分进行建模，为评估所提方法在区分背景与异常目标方面提供了重要参考。在深度学习方法方面，RGAE 通过 $\ell_{2,1}$ 范数约束和超像素图正则化策略分离背景和异常。GAED 则利用引导模块增强背景特征的表征能力，并通过反馈机制抑制异常目标的特征表达。与 GAED 进行对比可衡量本章方法中提出的反馈分解策略的优势。值得注意的是，本研究严格按照各对比方法原论文提供的参数范围与默认设置进行调整优化。此外，由于所提方法的波段分组策略基于稀疏成分的秩 j 进行选择，其值基于 p 值和 MX-SVD 方法计算，如表 5.1 所示，每组数据对应的两组 j 值。因此，所有涉及 j 值的实验采用 j_1 和 j_2 进行标注，其中所提方法标注为 FBGVLR-j_1 和 FBGVLR-j_2，对比方法 OSP-GoDec 标注为 OSP-GoDec-j_1 和 OSP-GoDec-j_2。实验采用定性和定量结合的方式评估所提方法的性能。在定性分析方面，基于检测结果图的视觉评估提供了直观的性能展示；在定量评估方面，引入了三种 2D ROC 曲线、3D ROC 曲线以及其对应的曲线线下面积 AUC 值构建了完整的评估框架。为直观比较各方法的检测能力，采用粗体标识最佳性能指标，并使用下划线标识次佳性能指标。

5.4.2 全波段和波段组上的异常目标检测结果分析

在进行实验之前，首先计算各数据的 j 值以划分波段组，其值可由 VD 和 MX-SVD 方法估计，结果如表 5.1 所示。

为系统地评估全波段和波段组分解后各成分 (**L**, **S**, 和 **N**) 对异常目标的表征力，本节对各成分分别进行异常检测实验。图 5.4-5.5 分别展示了 HYDICE 15-panel 的全波段和 $(p, m, j) = (13, 7, 6)$ 时的 UBS 波段组上进行数据分解之后各成分的可视化结果。与此同时，表 5.2 以及图 5.6-5.7 为各成分异常检测结果的 AUC 值及异常检测结果图。

根据图 5.4 和图 5.5 的可视化分析结果可以得出，波段组上的数据分解更有益于增强 **L** 和 **S** 的可分性。特别是在图 5.4(c) 与图 5.5(c) 的对比中，可以清晰地观察到波段组分解在分离异常目标与复杂背景干扰方面展现出明显的优势，即 $\mathbf{S_B}$ 具有更少的非目标因素的干扰。这一实验结果证实，在波段子集上实施数据分解能够更有效地抑

中国知网 https://www.cnki.net

表 5.1 不同数据的 j 估计值

Tab. 5.1 Estimated values of j for various data

数据	VD	p	m by $p-j$	j by MX-SVD
HYDICE Panel	HFC, PF$\leq 10^{-4}$	9	5	4
	NWHFC, PF$\leq 10^{-4}$	13	7	6
HYDICE Urban	HFC, PF$\leq 10^{-4}$	9	5	4
	NWHFC, PF$\leq 10^{-4}$	13	7	6
ABU-beach3	HFC, PF$\leq 10^{-4}$	13	9	4
	NWHFC, PF$\leq 10^{-4}$	15	9	6
Pavia Center	HFC, PF$\leq 10^{-4}$	10	3	7
	NWHFC, PF$\leq 10^{-4}$	7	3	4
ABU-beach2	HFC, PF$\leq 10^{-4}$	12	8	4
	NWHFC, PF$\leq 10^{-4}$	12	8	4

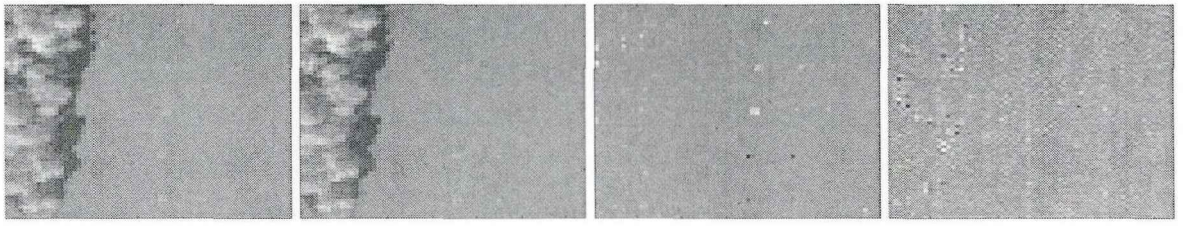

(a) **X** (b) **L** (c) **S** (d) **N**

图 5.4 全波段各成分的可视化结果

Fig. 5.4 Visualization results of various components for the full bands

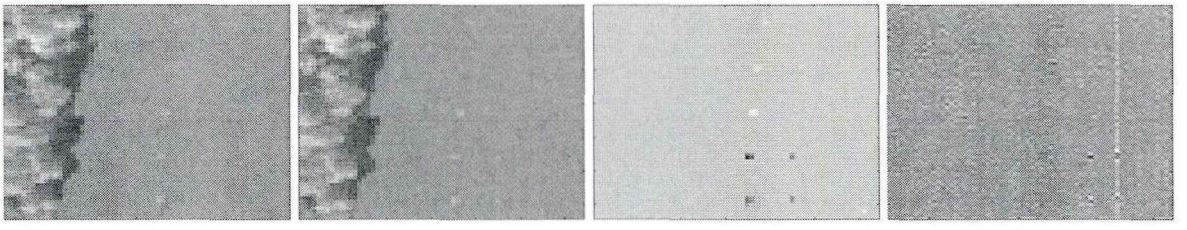

(a) $\mathbf{X}_B$ (b) $\mathbf{L}_B$ (c) $\mathbf{S}_B$ (d) $\mathbf{N}_B$

图 5.5 波段组各成分的可视化结果

Fig. 5.5 Visualization results of various components for the band group

制异常检测任务中的非目标成分的干扰。

在表 5.2 中，通过对各成分检测结果的横向对比分析可以发现，波段组分解的稀疏成分 **S** 在 AUC(P_D, P_F)、AUC(P_D, τ) 和 AUC_{SNPR} 等关键指标上均表现出显著优势，同时 AUC(P_F, τ) 明显低于其他分量。这一现象表明，相较于传统全波段分解方式，波段组分解策略上更有助于提升异常目标检测性能，具体表现 AUC(P_D, P_F) 值的提升及 AUC(P_F, τ) 值的降低。图 5.6 和图 5.7的可视化检测结果也进一步验证了这一结论，即

中国知网 https://www.cnki.net

表 5.2　全波段和波段组各成分的异常目标检测结果

Tab. 5.2　AD results of various components for both full bands and band group

	全波段				波段组			
	AUC of (P_D, P_F)	AUC of (P_D, τ)	AUC of (P_F, τ)	AUC of SNPR	AUC of (P_D, P_F)	AUC of (P_D, τ)	AUC of (P_F, τ)	AUC of SNPR
X	0.9897	0.345	0.0434	7.9486	0.9798	0.3711	0.0193	19.2017
L	0.9512	0.4926	0.0936	5.2643	0.9948	0.4953	0.0521	9.4996
S	0.9942	**0.7616**	0.0409	18.6401	**0.9977**	0.6905	**0.0087**	**79.1162**
N	0.3039	0.0387	0.0770	0.5022	0.005	0.0050	0.1995	0.0251

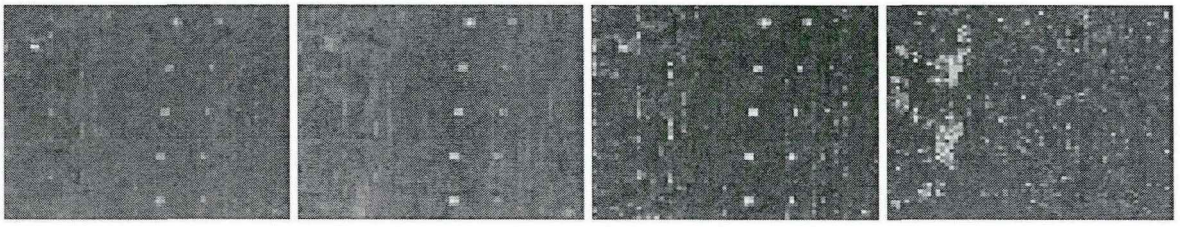

(a) **X**　(b) **L**　(c) **S**　(d) **N**

图 5.6　全波段不同成分的异常检测结果

Fig. 5.6　AD results of different components for the full bands

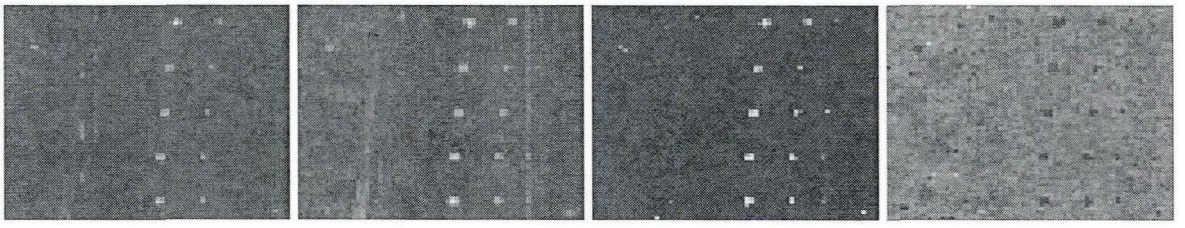

(a) $\mathbf{X_B}$　(b) $\mathbf{L_B}$　(c) $\mathbf{S_B}$　(d) $\mathbf{N_B}$

图 5.7　波段组不同成分的 AD 结果

Fig. 5.7　AD results of various components for the band group

波段组的 **L**、**N** 和 **S** 表现出更干净的背景抑制能力和更清晰的异常目标提取效果。

这些结果说明了在波段子集上的数据分解更有利于区分异常和背景。这是因为全波段数据的光谱变异特性导致当秩较小时，提取低秩部分后剩余的信息量增加，从而增加了 **N** 和 **S** 的区分难度，影响 **S** 提取的准确性，最终限制了异常检测的性能。从波段组群以及全波段的 **N** 和 **S** 的检测结果比较中也可以验证这一点，波段组群的 $\mathbf{S_B}$ 具有更高的 AUC(P_D，P_F)，$\mathbf{N_B}$ 具有更小的 AUC(P_D，P_F)，这表明波段组群上的分解更有利于区分 **N** 和 **S**。因此，在波段子集上的分解是降低虚警率的关键。

此外，表 5.2 的纵向对比结果显示，在所有分解方案中，稀疏成分 **S** 始终保持着最优异的检测，包括更高的 AUC(P_D,P_F)、AUC(P_D, τ) 和 AUC_{SNPR}，以及更低的 AUC(P_F, τ)，这一规律在全波段和波段组分解中均成立。这充分证明了稀疏空间有益于更准确

中国知网　https://www.cnki.net

地捕捉感兴趣的异常目标。

最后，HYDICE15-panel 数据的第三列是由红色面板像素和微小黄色面板像素组成的典型弱异常目标，所提方法能够更加准确分离此类挑战性目标 (图 5.5(c) 和图 5.7(c))。这表明所提分解模型能够在分离非异常成分干扰的同时，有效保持和提取异常像素，有利于提升弱异常目标的检测灵敏度。

除了对全波段数据和波段子集上执行基于数据分解的异常检测性能进行比较分析外，这里进一步对它们的计算时间进行分析。表 5.3 统计了全波段和波段子集在数据分解处理步骤中花费时间的比较，结果表明，波段组分解可显著降低计算时间，其在保证检测性能的同时提升了算法的实际应用价值。

表 5.3　全波段及波段组数据分解时间对比 (秒)

Tab. 5.3　Time comparison of data decomposition for full bands and band group (second)

数据	全波段	波段组
HYDICE	3.98	1.11
Panel		0.39
HYDICE	26.09	4.31
Urban		2.76
ABU-beach3	13.43	3.36
		2.08
ABU-beach3	5.02	0.80
		1.18
ABU-beach3	8.84	1.94
		1.94

5.4.3　实验结果与分析

不同方法在五组数据集上的检测结果如图 5.8-5.12 所示。图 5.13-5.17和表5.4-5.8为各方法的 ROC 曲线和相应的 AUC 值。

(1) HYDICE15-panel: 从图 5.8 中 HYDICE15-panel 数据的实验结果表明，所提方法能够成功检测出不同尺度的所有目标像素，并实现优异的背景抑制效果。相比之下，AHMID、PTA、SSIIFD、RGAE 和 GAED 等方法在第三列检测中均存在不同程度的漏检现象。IFEBP 方法虽然能够部分检测出第三列的异常目标，但仍有部分弱目标未被正确识别。值得注意的是，RhyDe 方法在背景抑制方面表现突出，检测结果较为干净。但其子空间操作倾向于保留主要成分的特性，导致对第三列弱异常目标的检测能力受限。RXD、RAD、CTV、OSP-GoDec 和 CRD 等方法在第三列目标检测上表现尚可，但由于背景抑制效果欠佳，检测可靠性受到复杂背景干扰的影响。

(2) HYDICE Urban: 图 5.9 中 HYDICE Urban 数据的实验结果显示，FBGVLR 在不同 (p, m, j) 参数设置下均能够稳定检测到大部分异常目标，表现出较强的稳定性。由于该数据集中的异常目标尺寸较小，RhyDe 的优势未能充分发挥。OSP-GoDec、PTA

中国知网 https://www.cnki.net

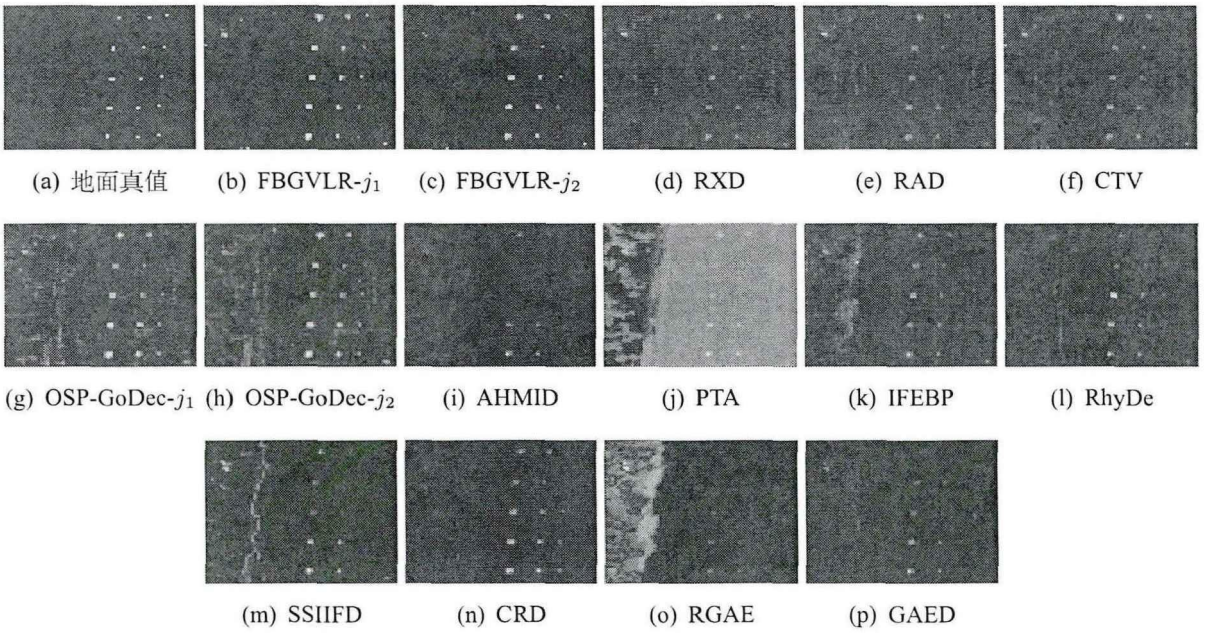

图 5.8　不同方法在 HYDICE15-panel 数据上的 HAD 结果图
Fig. 5.8　AD maps of all compared methods for HYDICE15-panel data

和 RGAE 等方法在背景抑制方面存在不足，其中 PTA 方法尤为明显。CRD、CTV、IFEBP 和 GAED 等方法受到背景像素干扰，影响了检测的准确性。SSIIFD 方法在该数据集上表现良好，但仍然存在少量背景像素被误识别为异常目标的问题。RXD 和 RAD 方法在该数据集上的检测效果较差，难以有效区分异常目标与背景。AHMID 方法在背景抑制方面具有一定优势，但仍存在部分异常目标漏检的问题，影响了整体检测性能。

(3) ABU-beach3: 图 5.10 中 ABU-beach3 数据的实验结果表明，RhyDe 和 AHMID 仅能检测到少量异常目标，而 IFEBP、RXD、CTV 和 RAD 等方法的检测能力也较为有限。值得注意的是,CRD 在该数据上表现出较差的检测性能。PTA 由于背景抑制能力不足，检测结果受到严重限制；RGAE 在该数据上同样存在背景抑制不足的问题，使其异常目标的检测能力受限。相比之下，GAED 的检测结果较为干净，能够有效突出异常目标。OSP-GoDec 和 SSIIFD 在所有对比方法中表现相对较好，但仍存在少量异常像素漏检的情况。FBGVLR 不仅实现了异常目标的精确检测，还能保持目标形状和大小与真实值高度一致。这得益于其结合空间信息与波段分组的反馈策略，有效增强了特征保留能力和检测稳定性。

(4) Pavia Center: 图 5.11 展示了不同方法在 Pavia Center 数据集上的检测结果。结果表明，PTA 方法虽然能够捕获大部分异常目标，但由于背景抑制能力较弱，检测图中仍存在较多背景干扰。CRD 的检测结果中存在大量误检点，严重影响了整体检测可靠性。IFEBP 将部分背景像素被误识别为异常目标。与 PTA、IFEBP、RAD 和 RXD 相比，OSP-GoDec 和 AHMID 在背景抑制方面表现更优，但仍存在不同程度的背景残留。RGAE 和 GAED 受背景干扰影响，检测准确性有所下降。相比之下，CTV、RhyDe

中国知网　https://www.cnki.net

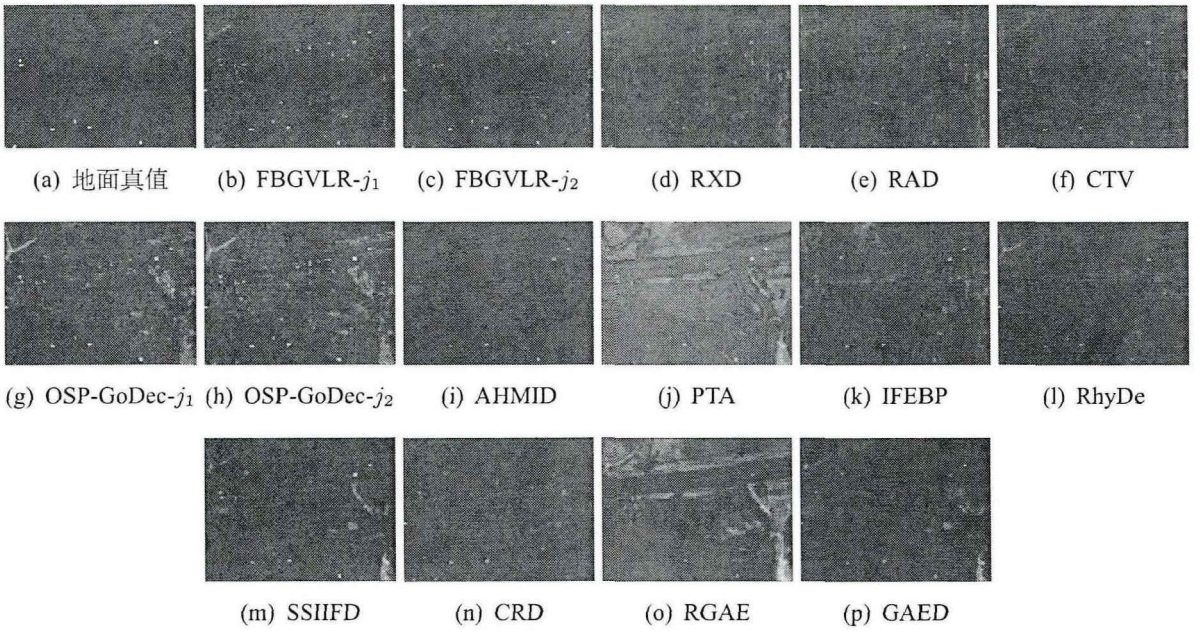

图 5.9 不同方法在 HYDICE Urban 数据上的检测结果图
Fig. 5.9 AD maps of all compared methods for HYDICE Urban data

以及 FBGVLR 在异常目标检测和背景抑制方面均表现优异，特别是在桥梁边缘区域效果显著。这一优势主要源于所提方法采用的波段分组策略，有效缓解了全波段数据的波段冗余干扰，增强了复杂场景下异常目标与背景的区分能力。

(5) ABU-beach2: 图 5.12 展示了不同方法在 ABU-beach2 数据集上的检测表现。从检测结果可以看到，SSIIFD 仅检测到极少量异常目标，并且误将部分背景像素识别为异常目标，表现出较高的误检率。RXD、RAD 和 PTA 方法的检测结果受背景影响较大，对异常目标的检测能力较弱。CTV 在背景抑制效果优于 RXD、RAD 和 PTA，但整体性能仍不理想。CRD 和 RhyDe 在背景抑制方面表现较好，但对异常目标的抑制过强导致部分异常像素未能被成功检测。RGAE 和 GAED 方法在异常目标检测方面存在不足，大部分异常目标被抑制，且部分背景区域被误识别为异常目标，影响了最终检测的可靠性。IFEBP 和 AHMID 在该数据集上表现相对较好，但仍有少量异常目标被背景信息淹没。综合来看，OSP-GoDec 和所提方法在背景抑制和异常目标保持之间取得了更优的平衡，既能够有效检测异常目标，又能够最大程度地减少背景干扰，展现出更稳定可靠的检测性能。

图 5.13-5.17中的 ROC 曲线清晰地呈现了不同方法的检测性能差异。同时，为精确量化各方法的优劣，表 5.4-5.8 详细列出了相应的 AUC 数值指标。这种双重视角的评估策略，既保证了评估结果的直观性，又确保了比较的客观和准确性，为检测器性能的综合评价提供了可靠依据。

(1) HYDICE15-panel: 图 5.13 和表 5.4 显示，所提方法在 $(p, m, j) = (9, 5, 4)$ 和 $(p, m, j) = (13, 7, 6)$ 的设定下均表现出优异的整体检测性能，四项 AUC 指标均达到最优或次优水平。这一出色表现源于：首先，波段分组策略有效利用了不同波段分组检测

中国知网 https://www.cnki.net

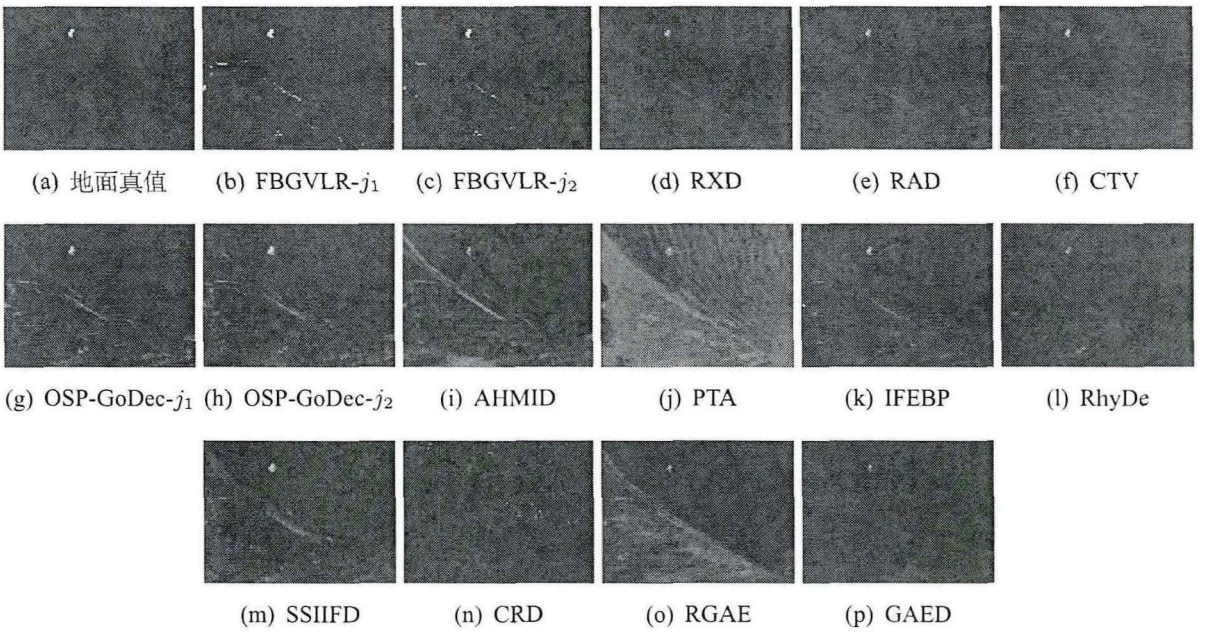

图 5.10　不同方法在 ABU-beach3 数据上的检测结果图

Fig. 5.10　AD maps of all compared methods for ABU-beach3 data

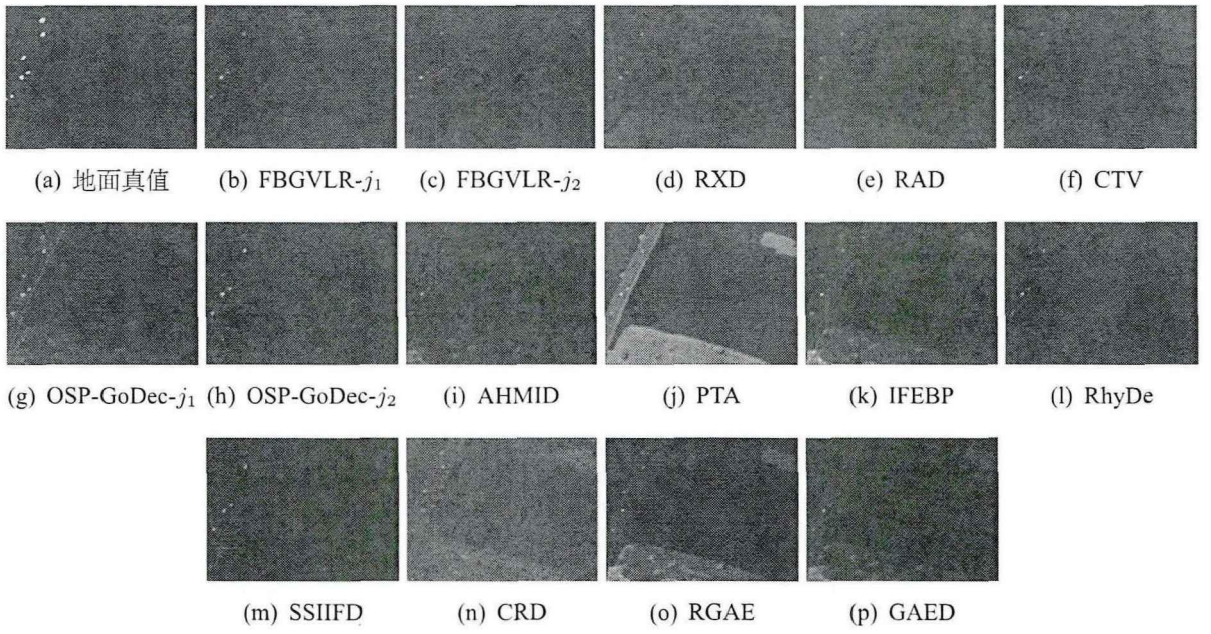

图 5.11　不同方法在 Pavia Center 数据上的检测结果图

Fig. 5.11　AD maps of all compared methods for Pavia Center data

结果的一致性与互补性，使得模型能够在复杂背景下增强对异常目标的区分能力；其次，迭代反馈机制有效强化了异常特征的表征能力并抑制了背景和噪声的干扰。值得注意的是，传统全波段处理方法由于高光谱数据冗余多的特性，可能会导致残差信息的增加，从而加剧背景与异常目标的区分难度。而所提方法通过波段分组策略有效缓

中国知网　https://www.cnki.net

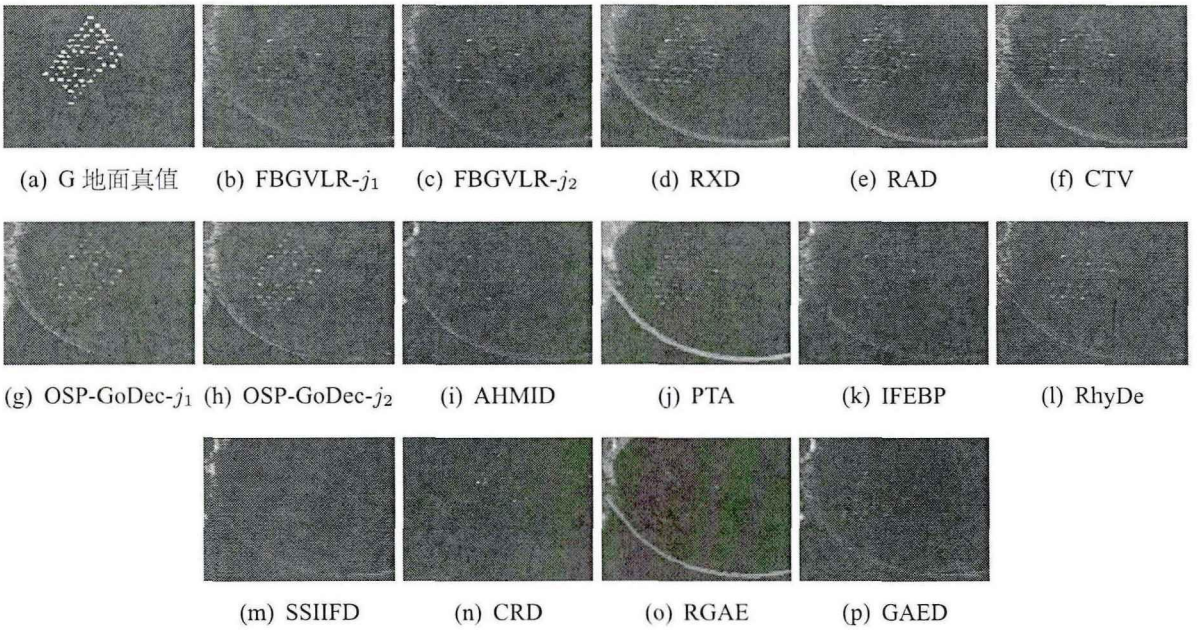

(a) G 地面真值 (b) FBGVLR-j_1 (c) FBGVLR-j_2 (d) RXD (e) RAD (f) CTV

(g) OSP-GoDec-j_1 (h) OSP-GoDec-j_2 (i) AHMID (j) PTA (k) IFEBP (l) RhyDe

(m) SSIIFD (n) CRD (o) RGAE (p) GAED

图 5.12 不同方法在 ABU-beach2 数据上的检测结果图

Fig. 5.12 AD maps of all compared methods for ABU-beach2 data

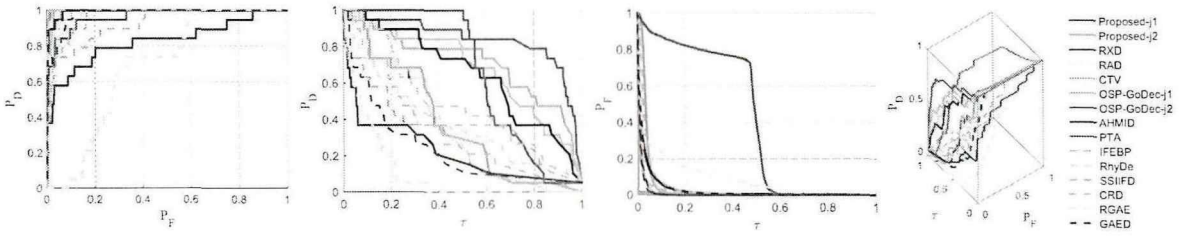

(a) 2D ROC 曲线 (P_D, P_F) (b) 2D ROC 曲线 (P_D, τ) (c) 2D ROC 曲线 (P_F, τ) (d) 3D ROC 曲线 (P_D, P_F, τ)

图 5.13 不同方法在 HYDICE panel 数据集上的 ROC 曲线

Fig. 5.13 ROC curves of different methods for HYDICE panel

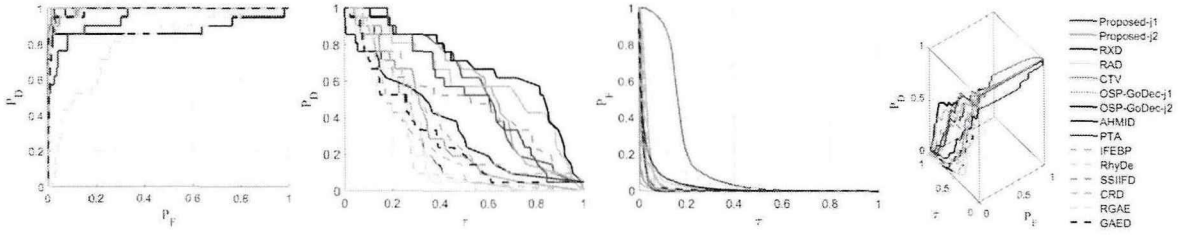

(a) 2D ROC 曲线 (P_D, P_F) (b) 2D ROC 曲线 (P_D, τ) (c) 2D ROC 曲线 (P_F, τ) (d) 3D ROC 曲线 (P_D, P_F, τ)

图 5.14 不同方法在 HYDICE Urban 数据集上的 ROC 曲线

Fig. 5.14 ROC curves of different methods for HYDICE Urban

解了这一挑战。

(2) HYDICE Urban: 从前述数据描述可知，HYDICE Urban 数据中的异常目标像素相对较少，并且整体呈现稀疏特性。图 5.14 和表 5.5 中的实验结果表明，所提

中国知网 https://www.cnki.net

表 5.4　不同方法在 HYDICE15-panel 数据上的 AUC 值

Tab. 5.4　AUC values of different methods for HYDICE15-panel data

方法	p,m,j	AUC of (P_D,P_F)	AUC of (P_D,τ)	AUC of (P_F,τ)	AUC of SNPR
FBGVLR	9,5,4	0.9975	**0.8332**	0.0118	70.7145
	13,7,6	**0.9977**	0.7042	**0.0089**	**79.1248**
RXD	-	0.9898	0.3445	0.0429	8.0308
RAD	-	0.9897	0.3450	0.0434	7.9486
CTV	-	0.9927	0.3639	0.0381	9.5514
OSP-GoDec	9,5,4	0.9894	0.6732	0.0282	23.8370
	13,7,6	0.9921	0.6458	0.0299	21.6120
AHMID	-	0.8225	0.2011	0.0120	16.7099
PTA	-	0.9601	0.6542	0.4155	1.5746
IFEBP	-	0.9635	0.3282	0.0388	8.4682
RhyDe	-	0.9841	0.3684	0.0139	26.5739
SSIIFD	-	0.8820	0.3600	0.0175	20.5726
CRD	-	0.9968	0.4732	0.0208	22.7360
RGAE	-	0.6331	0.0976	0.0902	1.0826
GAED	-	0.9742	0.2074	0.0100	20.7099

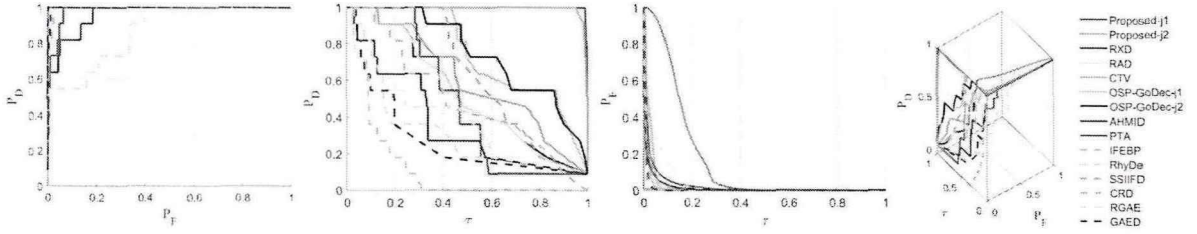

(a) 2D ROC 曲线 (P_D, P_F)　(b) 2D ROC 曲线 (P_D, τ)　(c) 2D ROC 曲线 (P_F, τ)　(d) 3D ROC 曲线 (P_D, P_F, τ)

图 5.15　不同方法在 ABU-beach3 数据上的 ROC 曲线

Fig. 5.15　ROC curves of different methods for ABU-beach3 data

方法在 AUC (P_D, P_F)、AUC (P_F, τ) 和 AUC_{SNPR} 指标上均取得了最佳或次优的成绩，AUC (P_D, τ) 指标仅次于 OSP-GoDec。这些结果表明所提方法在弱异常目标检测中的出色能力。

(3) ABU-beach3: 图 5.15 和表 5.6 显示，所提方法整体性能领先。具体表现为：首先，图 5.15(a) 中绘制的 (P_D, P_F) 曲线接近左上角，表明其在高检测率和低误报率方面的优势；其次，图 5.15(b) 中 (P_D, τ) 曲线偏向右上角，验证了其异常目标保留能力。特别是在 $(p, m, j) = (15, 9, 6)$ 下，较低的 (P_F, τ) 值凸显了出色的背景抑制能力。这表明所提方法不仅能有效检测异常目标，还能较好地抑制背景，提升整体检测效果。

(4) Pavia Center: 图 5.16 和表 5.7 结果表明，所提方法在 AUC (P_D, P_F) 指标上明

中国知网　https://www.cnki.net

表 5.5 不同方法在 Hydice Urban 数据上的 AUC 值
Tab. 5.5 AUC values of different methods for Hydice Urban data

方法	p,m,j	AUC of (P_D,P_F)	AUC of (P_D,τ)	AUC of (P_F,τ)	AUC of SNPR
FBGVLR	9,5,4	0.9970	0.5490	0.0094	58.5090
	13,7,6	**0.9983**	0.5583	**0.0076**	**73.1856**
RXD	-	0.9864	0.2507	0.0360	6.9631
RAD	-	0.9864	0.2483	0.0359	6.9237
CTV	-	0.9905	0.3093	0.0207	14.9212
OSP-GoDec	9,5,4	0.9889	0.6064	0.0245	24.7038
	13,7,6	0.9921	**0.6810**	0.0328	20.7531
AHMID	-	0.8997	0.3281	0.0120	27.3230
PTA	-	0.9497	0.5405	0.1789	3.0205
IFEBP	-	0.9918	0.3652	0.0290	12.5810
RhyDe	-	0.9889	0.1931	0.0122	15.7977
SSIIFD	-	0.9912	0.4757	0.0124	38.2220
CRD	-	0.9958	0.2360	0.0330	7.1446
RGAE	-	0.8018	0.1945	0.0878	2.2162
GAED	-	0.9835	0.2814	0.0172	16.3280

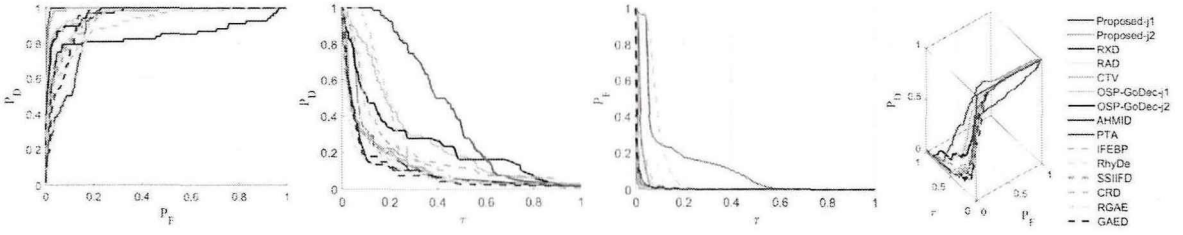

(a) 2D ROC 曲线 (P_D, P_F) (b) 2D ROC 曲线 (P_D, τ) (c) 2D ROC 曲线 (P_F, τ) (d) 3D ROC 曲线 (P_D, P_F, τ)

图 5.16 不同方法在 Pavia Center 数据上的 ROC 曲线
Fig. 5.16 ROC curves of different methods for Pavia Center data

显优于其他对比方法。尽管在 AUC (P_D, τ) 指标上并未表现出明显优势，但其创造了最低的 AUC (P_F, τ) 值，且 AUC_{SNPR} 排名第三，展现了较好的综合性能。这些结果与图 5.7 中的检测结果相互印证，验证了所提方法的有效性。

(5) ABU-beach2: 图 5.17 和表 5.8 显示，所提方法在 AUC (P_D, P_F) 指标上表现出色，表明其在异常目标保持和背景异常抑制之间实现了较好的平衡。

综合五个数据的评估结果表明，所提方法在所有对比算法中取得了出色的检测表现，尤其在 AUC (P_D, P_F) 指标上表现尤为突出。具体而言：1) 在所有五组数据的 AUC (P_D, P_F) 评估中均取得了最高值；2) 在四个数据集上取得了最低的 AUC (P_F, τ) 值；3) 同时在三组数据上包揽了 AUC_{SNPR} 和 AUC (PD, τ) 的最佳成绩。这些实验结果

中国知网 https://www.cnki.net

表 5.6 不同方法在 ABU-Beach3 数据上的 AUC 值

Tab. 5.6 AUC values of different methods for ABU-Beach3 data

方法	p, m, j	AUC of (P_D, P_F)	AUC of (P_D, τ)	AUC of (P_F, τ)	AUC of SNPR
FBGVLR	13,9,4	0.99995	**0.9955**	0.0087	114.7631
	15,9,6	**0.99996**	0.9891	**0.0072**	**137.5648**
RXD	-	0.99982	0.4918	0.0259	18.9562
RAD	-	0.99983	0.4891	0.0257	19.0360
CTV	-	0.99976	0.5773	0.0152	38.0360
OSP-GoDec	13,9,4	0.99984	0.7300	0.0152	48.0643
	15,9,6	0.99975	0.7400	0.0164	45.0807
AHMID	-	0.96273	0.3400	0.0265	12.8307
PTA	-	0.98493	0.4800	0.1607	2.9865
IFEBP	-	0.99879	0.4686	0.0197	23.7754
RhyDe	-	0.99722	0.2918	0.0076	38.6514
SSIIFD	-	0.99985	0.6082	0.0162	37.6164
CRD	-	0.99321	0.1177	0.0076	15.4214
RGAE	-	0.86600	0.3282	0.0405	8.1001
GAED	-	0.99694	0.2355	0.0087	27.1074

表 5.7 不同方法在 Pavia Center 数据上的 AUC 值

Tab. 5.7 AUC values of different methods for Pavia Center data

方法	p, m, j	AUC of (P_D, P_F)	AUC of (P_D, τ)	AUC of (P_F, τ)	AUC of SNPR
FBGVLR	10,3,7	**0.9881**	0.1186	**0.0055**	21.7500
	7,3,4	0.9858	0.1201	0.0057	21.1323
RXD	-	0.9513	0.1289	0.0232	5.5540
RAD	-	0.9467	0.1279	0.0274	4.6715
CTV	-	0.9595	0.1221	0.0075	16.3782
OSP-GoDec	10,3,7	0.9658	**0.2654**	0.0140	18.9211
	7,3,4	0.9315	0.2427	0.0088	**27.6259**
AHMID	-	0.8710	0.0964	0.0077	12.5812
PTA	-	0.9122	0.4298	0.1224	3.5116
IFEBP	-	0.9422	0.1733	0.0237	7.3135
RhyDe	-	0.9205	0.0827	0.0061	13.5342
SSIIFD	-	0.8283	0.1424	0.0063	22.7300
CRD	-	0.9074	0.2238	0.0921	2.4307
RGAE	-	0.9118	0.1490	0.0263	5.6610
GAED	-	0.9204	0.0892	0.0105	8.5309

中国知网 https://www.cnki.net

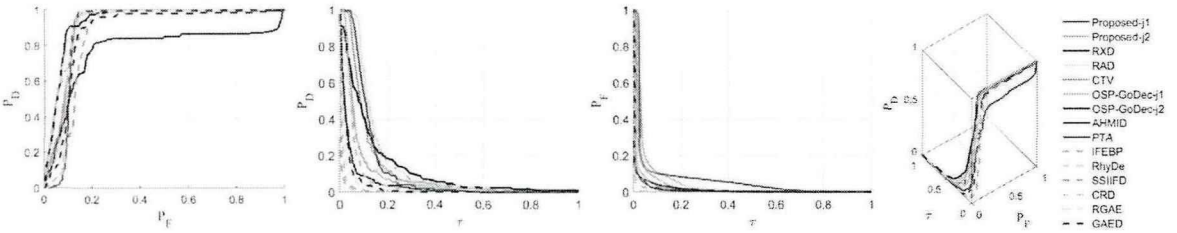

(a) 2D ROC 曲线 (P_D, P_F)　(b) 2D ROC 曲线 (P_D, τ)　(c) 2D ROC 曲线 (P_F, τ)　(d) 3D ROC 曲线 (P_D, P_F, τ)

图 5.17　不同方法在 ABU-beach2 数据上的 ROC 曲线

Fig. 5.17　ROC curves of different methods for ABU-beach2 data

表 5.8　不同方法在 ABU-Beach2 数据上的 AUC 值

Tab. 5.8　AUC values of different methods for ABU-Beach2 data

方法	p, m, j	AUC of (P_D,P_F)	AUC of (P_D,τ)	AUC of (P_F,τ)	AUC of SNPR
FBGVLR	12,8,4	**0.9200**	0.0814	0.0173	4.7089
	12,8,4	**0.9200**	0.0814	0.0173	4.7089
RXD	-	0.9100	**0.1520**	0.0488	3.1137
RAD	-	0.9102	0.1515	0.0484	3.1302
CTV	-	0.9183	0.1202	0.0308	3.8973
OSP-GoDec	12,8,4	0.9060	0.1273	0.0174	**7.3339**
	12,8,4	0.9060	0.1273	0.0174	**7.3339**
AHMID	-	0.7446	0.0386	0.0126	3.0473
PTA	-	0.8935	0.1209	0.0667	1.8137
IFEBP	-	0.9112	0.0582	0.0176	3.3193
RhyDe	-	0.8971	0.0805	0.0119	6.7736
SSIIFD	-	0.5105	0.0086	0.0108	0.7895
CRD	-	0.6788	0.0111	**0.0062**	1.8077
RGAE	-	0.6820	0.0210	0.0227	0.9283
GAED	-	0.7665	0.0278	0.0134	2.0696

充分验证了所提方法中波段组数据分解策略和迭代反馈机制在高光谱数据异常检测中的显著优势。该方法不仅通过波段分组有效降低了计算复杂度并抑制了背景干扰，还借助迭代反馈机制保留了足够的异常信息，从而维持对弱异常特征的检测能力。这种兼顾计算效率与检测精度的特性，使得所提方法在实际应用中具有重要的实用价值。

5.4.4　收敛性和参数分析

(1) 收敛性分析：本小节对所提算法在五组数据上的数值收敛性进行了详细分析。图 5.18 展示了算法 5.1 中相对误差随迭代次数的变化曲线。可以看到，随着迭代次数

中国知网　https://www.cnki.net

的增加，所有数据的相对误差均呈现稳定下降的趋势，直至满足收敛条件。这一结果从实证上验证了 FBGVLRS 具有稳定可靠的收敛性能。

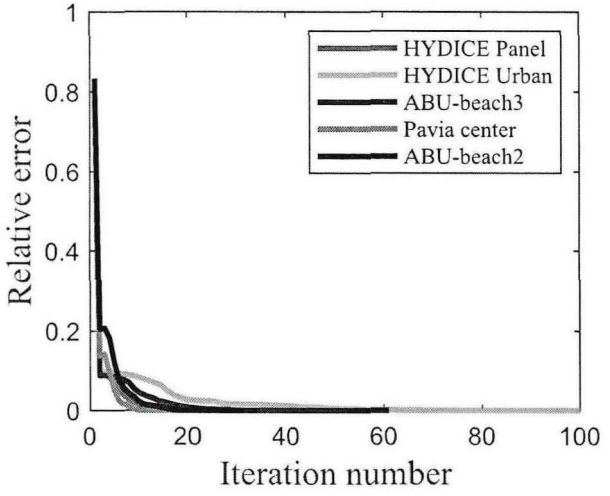

图 5.18　相对误差随迭代次数的变化

Fig. 5.18　Relative errors versus iterations

(2) 参数分析：关键参数 β(式 (5.7)) 在平衡低秩项和稀疏项的过程中起着至关重要的作用，并且与检测精度密切相关。为研究正则化参数对检测性能的影响，图 5.19 展示了在 $\beta = c/\sqrt{h \times w}$ 条件下，所提出方法在五组数据上 AUC $(P_{\mathrm{D}}, P_{\mathrm{F}})$ 值随参数 c 的变化情况，其中，c 的取值范围为 {5, 10, 15, 20, 25, 30, 35, 40, 45}。从图中可以看出，当 $c = 40$ 时，所提出的方法在 HYDICE panel 和 ABU-Beach3 数据上取得较高的 AUC $(P_{\mathrm{D}}, P_{\mathrm{F}})$ 值；而当 $c = 15$ 和 $c = 20$ 时，所提方法分别在 Pavia Center 和 ABU-Beach2 数据上表现出最佳的 AUC $(P_{\mathrm{D}}, P_{\mathrm{F}})$ 值。通过对这些检测结果的详细分析，当数据中异常目标像素占比较少时，较大的 c 值有助于避免更多异常像素被抑制；当异常目标像素占比较大时，较小的 c 值则能取得更好的检测效果。

5.5　本章小结

本章针对总变分正则化在异常检测中面对非目标成分干扰和异常信号保留难以平衡问题导致的检测性能瓶颈，提出了反馈式波段组群和变分低秩稀疏模型的高光谱异常检测方法。首先，考虑到高光谱图像中信息量庞大，直接对全波段进行去噪将导致计算量和冗余信息的增加。为此，本章提出了一种基于波段划分的处理策略，通过将全波段数据划分为多个波段组进行级联式处理，在保证信息完整性的同时，有效降低了计算负担并减少了非目标成分的干扰。其次，在背景成分建模中引入了相关总变分模型，显著增强了高光谱数据空间上的平滑性并提高算法对噪声的鲁棒性；采用 $L_{2,1}$ 范数约束稀疏成分，在抑制噪声的同时避免了建模过程中异常信息的削弱；最后，针对异常先验缺乏导致的波段选择过程中异常信息丢失问题，本章设计了一种迭代反馈机制，通过利用已有波段组的检测信息来引导后续波段组中异常成分的提取，从而增强模型对异常目标的提取能力。需要强调的是，该框架并未选择性地保留或剔除波

中国知网 https://www.cnki.net

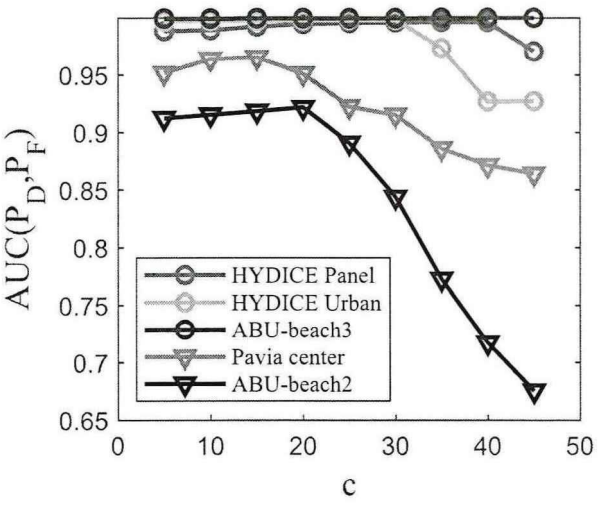

图 5.19　五组数据在不同 c 设置下的 AUC (P_D, P_F) 值

Fig. 5.19　AUC (P_D, P_F) value of five data under different c

段信息，而是充分利用了不同波段组之间的一致性和互补性，有效避免了由于异常先验不足而导致的有用信息丢失问题。通过这种方式，在保留足够异常信息的同时，有效减少了冗余信息和光谱变异的干扰。

总之，多组高光谱数据上的实验结果表明，所提方法能够有效对抗数据中的非期望干扰，表现出干净的背景抑制效果。特别是在弱异常目标检测任务中，取得了优异的检测精度与鲁棒性。实验进一步验证了，基于波段组的分解有助于实现非异常成分的有效分离，而反馈式分解策略的引入，使得 FBGVLR 方法在抑制背景与噪声干扰的同时，能够更好地保留数据中的异常信号特征。

中国知网　https://www.cnki.net

6 基于结构与变分约束的增量多尺度联合字典高光谱异常检测算法

6.1 引言

第五章重点解决了如何有效抑制非期望干扰并强化数据中的异常目标要素。本章针对异常信号对背景重建的干扰问题，提出基于结构先验与变分约束的判别性增量多尺度联合字典高光谱异常检测算法，提升背景重建精度，并增强背景和异常成分的分离。具体来说，作为一种无监督的目标检测技术，异常目标检测能够有效识别那些无法通过先验知识或目视检查判断发现的未知微弱信号。该技术的核心在于通过关注异常像素与背景像素之间的光谱差异，实现二者的有效分离。由于缺乏异常目标的先验信息，使得检测性能在很大程度上依赖于抑制背景的有效性[108]。换言之，背景抑制越干净，背景与异常之间的对比度就越突出，从而更有助于突出异常目标。因此，背景抑制和异常可检测性成为高光谱图像异常检测中的关键因素。为提升检测性能，现有研究主要从两个维度进行探索：一方面通过挖掘高光谱数据的结构特性和噪声分布特征来改进背景重建精度，从而实现背景成分的精确提取。例如，文献 [165–168] 等研究通过引入不同的正则化约束来优化背景字典或表示系数。多约束模型能够综合考虑数据的多种属性特征，但正则项之间的平衡也会限制检测性能的提升。此外，背景字典的质量与所选样本的代表性密切相关。当前大多数方法采用聚类技术提取代表性特征，但潜在异常像素的干扰以及噪声污染会降低字典原子的表征力，进而影响背景重建精度。另一方面，异常目标通常由少量像素组成，通常被称为“稀有像素”。在噪声干扰的影响下，现有方法在异常与噪声分离方面仍存在不足，特别是对微弱目标的检测效果欠佳。为此，部分方法利用异常与噪声在光谱域连续性上的差异特性，通过提取显著偏离周围像素的潜在异常来构建异常字典[169–171]。这种方式虽能区别于噪声干扰，发现隐藏在场景中的异常目标。但由于背景复杂性以及异常先验知识的缺乏，单纯依赖初步差异筛选可能误将部分非目标光谱包含在字典中，导致虚警率升高。因此，如何在有效提取异常特征的同时抑制非目标成分干扰，仍然是一个亟待解决的关键问题。

针对上述挑战，本章提出了一种用于高光谱异常检测的结构先验与变分约束的判别性增量多尺度联合字典 (discriminative incremental multi-scale joint dictionary，DIM-SJD) 方法。具体来说，首先，根据异常目标表现出的空间特征构建多尺度背景字典 (multi-scale background dictionary, MSBD)，应对背景重建过程中异常特征污染的问题。其次，利用不同波段组之间的一致性和互补性，提出一种判别性增量背景-异常联合字典 (discriminative incremental background-anomaly dictionary, DID-BA) 方法，动态优化背景和异常字典，构建具有高表征能力且低冗余的字典。再次，相关总变分和 $L_{2,1}$ 背景成分的低秩及局部平滑特性和异常成分的稀疏性相结合来维护数据的全局和局部数据结构，同时探索高光谱底层结构特征，定义结构先验约束促进模型的背景和异常成分的分离能力。在此基础上，引入深度聚类网络，将初步检测结果作为潜在异常

中国知网 https://www.cnki.net

特征的预提取信息，结合 PCA 提取的地物分布特征进行联合优化，最终构建了以空间结构为先导、结合光谱差异与变分先验的多尺度谱空联合表示模型获得精确的检测结果。实验结果表明，DIMSJD 能够有效抑制异常特征对背景重构干扰，显著提升检测精度。

本章后续部分内容组织如下，第 6.2 节简要阐述了基于联合字典的高光谱图像异常检测的相关研究基础；第 6.3 节介绍了提出的基于结构先验与变分约束的判别性增量多尺度联合字典高光谱异常检测方法的模型设计和理论推导；第 6.4 节中展示了所提方法在多个数据上的实验结果和性能分析，验证了本章所提方法的有效性；第 6.5 节对本章工作进行了总结概述。

6.2 基于联合字典的高光谱图像异常检测

将高光谱图像 $\mathcal{Y} \in \mathbb{R}^{h\times w\times b}$ 表示为沿光谱维度展开的二维矩阵 $\mathbf{Y} = unfold(\mathcal{Y})$。基于此表示，高光谱异常检测可以建模为如下矩阵分解问题：

$$\mathbf{Y} = \mathbf{DB} + \mathbf{S} + \mathbf{N} \tag{6.1}$$

其中，背景成分由背景字典 $\mathbf{D} = [d_1, d_2, ..., d_{n_B}]$ 及其对应的稀疏表示系数矩阵 $\mathbf{B} = [b_1, b_2, ..., b_{n_B}]$ 构成，n_B 为字典原子数。$\mathbf{S}$ 和 $\mathbf{N}$ 分别表示异常成分和噪声成分。由于高光谱图像中的每个像素光谱向量通常对应着一种或多种材料的混合，每种材料的光谱可以被视为一个子空间中的元素。因此，高光谱图像可以由多个低维子空间表示。为发现隐藏在场景中的异常目标，利用异常与噪声在光谱域连续性上的差异特性，通过提取显著偏离周围像素的潜在异常像素来构建异常字典。假设潜在的异常字典原子为 $\mathbf{T} = [t_1, t_2, ..., t_{n_A}]$，$n_A$ 为异常原子数，则式 (6.1) 可进一步表示为：

$$\mathbf{Y} = \mathbf{DB} + \mathbf{TA} + \mathbf{N} \tag{6.2}$$

其中，$\mathbf{A} = [a_1, a_2, ..., a_{n_A}]$ 为异常成分的稀疏表示系数矩阵。

基于高光谱图像中背景像素的高度相关性以及异常像素的固有稀疏特性，现有研究通常采用低秩和稀疏约束相结合的策略来优化模型性能，促进背景与异常成分的精确分离[169]。这种正则化框架通过数据建模充分挖掘了高光谱数据的本质特性，有助于保持背景成分的全局结构一致性，优化高光谱图像的异常检测效果。

$$\begin{aligned} &\min_{\mathbf{B},\mathbf{A},\mathbf{S}} rank(\mathbf{B}) + \beta\|\mathbf{A}\|_{2,1} + \|\mathbf{N}\|_1 \\ &s.t.\ \ \mathbf{Y} = \mathbf{DB} + \mathbf{TA} + \mathbf{N} \end{aligned} \tag{6.3}$$

鉴于方程 (6.3) 的非凸性和 NP-hard 性质，解决该问题的一种常见策略是利用核

中国知网 https://www.cnki.net

范数来近似秩函数。通过这种方式，方程 (6.3) 可以重新表述为：

$$\begin{aligned} &\min_{\mathbf{B},\mathbf{A},\mathbf{S}} \|\mathbf{B}\|_* + \beta\|\mathrm{A}\|_{2,1} + \|\mathbf{N}\|_1 \\ &s.t.\ \ \mathbf{Y} = \mathbf{DB} + \mathbf{TA} + \mathbf{N} \end{aligned} \tag{6.4}$$

6.3 基于结构先验与变分约束的判别性增量多尺度联合字典高光谱异常检测

本章提出了一种判别性增量联合字典方法，通过波段组之间的一致性和互补性充分挖掘高光谱图像中的丰富信息，可显著提升背景与异常成分的分离效果。该方法实现流程如图 6.1 所示，首先，基于 UBS 和 VD 值[148,149] 将原始光谱波段划分为 j 个波段组。其次，采用所提出的字典构建策略，获取背景和异常字典原子。再次，利用检测样本与字典原子之间的光谱信息，设计结构先验矩阵，提升背景和异常成分的分离能力。再次，使用深度聚类网络提取异常目标。最后，根据已有波段组提供的检测信息，选择增量字典原子，动态优化背景和异常字典，构建具有高表征能力且低冗余的字典，优化检测结果。

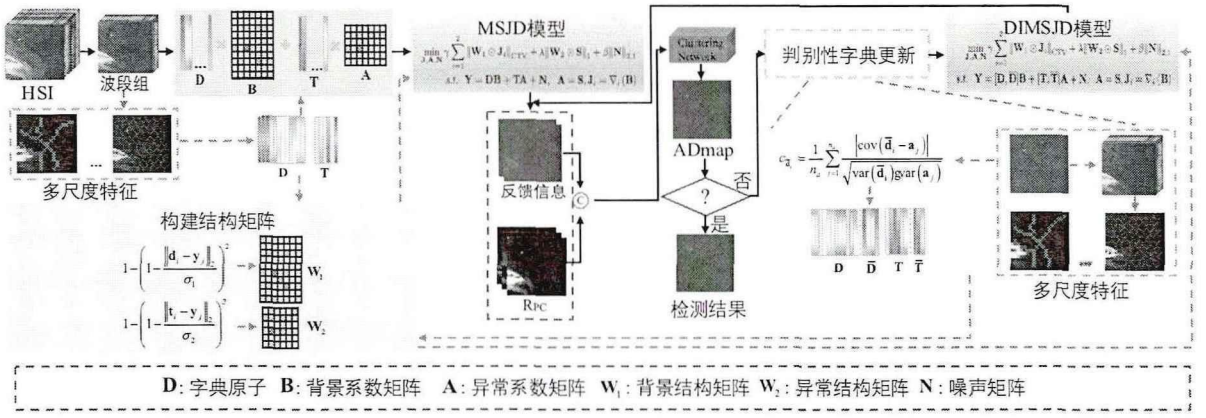

图 6.1 DIMSJD 流程图

Fig. 6.1 Flowchart of the DIMSJD

6.3.1 DIMSJD 模型

核范数和总变分模型被广泛应用于约束背景成分的整体低秩特性和局部空间结构，并取得了显著的效果[90,107]。以往基于 LRaSR 的高光谱异常检测方法中，研究者通常联合使用 $\|\mathbf{B}\|*$ 和 $\|\mathbf{B}\|_{TV}$，旨在同时利用高光谱图像的多种图像特性。然而，这些方法往往将多正则项利用平衡参数独立处理，在实际应用中难以实现最优的平衡与结合。为解决这一问题，本章引入相关总变分正则项[63,172]，它将背景的局部平滑特性与低秩先验整合到一个统一的正则项中，增强了模型对复杂场景的适应能力。改进后的模型如下：

中国知网 https://www.cnki.net

$$\begin{aligned} &\min_{\mathbf{B},\mathbf{A},\mathbf{N}} \|\mathbf{B}\|_{\mathrm{CTV}} + \beta\|\mathrm{A}\|_{2,1} + \|\mathbf{N}\|_1 \\ &s.t.\ \ \mathbf{Y} = \mathbf{DB} + \mathbf{TA} + \mathbf{N} \end{aligned} \tag{6.5}$$

其中，第 i 维上的相关总变分正则项可以表示为 $\|\mathbf{B}\|_{\mathrm{CTV}} = \|\nabla_i \mathbf{B}\|_* = \|\mathbf{J}_i\|_*$。因此，方程 (6.5) 可以重新表述为：

$$\begin{aligned} &\min_{\mathbf{J},\mathbf{A},\mathbf{N}} \sum_{i=1}^{2} \|\mathbf{J}_i\|_* + \beta\|\mathbf{S}\|_{2,1} + \|\mathbf{N}\|_1 \\ &s.t.\ \ \mathbf{Y} = \mathbf{DB} + \mathbf{TA} + \mathbf{N},\ \mathbf{A} = \mathbf{S}, \mathbf{J}_i = \nabla_i(\mathbf{B}) \end{aligned} \tag{6.6}$$

其中，∇ 表示一阶差分算子，$i = 1$ 和 $i = 2$ 分别对应图像空间维度中的水平和垂直方向。

虽然该联合低秩和稀疏模型能够同时刻画高光谱图像的全局低秩特性和局部平滑结构，但其在挖掘和利用数据的潜在先验信息方面仍存在明显不足。为进一步挖掘数据底层结构信息，本章基于检测样本与字典原子之间的光谱信息，通过分析测试样本与字典原子之间的光谱相关性，设计结构先验矩阵 $\mathbf{W}_1 \in {}^{m_1 \times n_1}$ 和 $\mathbf{W}_2 \in {}^{m_2 \times n_2}$，以增强背景和异常成分的可分性。其中，$m_1$ 和 m_2 分别表示字典 $\mathbf{D}$ 和 $\mathbf{T}$ 中的原子数量，而 n_1 和 n_2 分别表示背景样本和异常样本的数量。结构先验矩阵 $\mathbf{W}_1$ 和 $\mathbf{W}_2$ 的具体计算过程如下：

$$\mathbf{W}_{1_{i,j}} = 1 - \left(1 - \frac{\|\mathbf{d}_i - \mathbf{y}_i\|_2}{\sigma_1}\right)^2 \tag{6.7}$$

$$\mathbf{W}_{2_{i,j}} = 1 - \left(1 - \frac{\|\mathbf{t}_i - \mathbf{y}_i\|_2}{\sigma_2}\right)^2 \tag{6.8}$$

其中，$\mathbf{W}_{1_{i,j}}$ 和 $\mathbf{W}_{2_{i,j}}$ 分别表示矩阵 $\mathbf{W}_1$ 和 $\mathbf{W}_2$ 的元素。利用 $\max \forall i,j \left(|\mathbf{d}_i - \mathbf{y}_j|^2\right)$ 和 $\max \forall i,j \left(|\mathbf{t}_i - \mathbf{y}_j|^2\right)$ 分别计算 σ_1 和 σ_2。式 (6.7) 和 (6.8) 反映了字典原子与检测样本之间的相似性关系，具体来说，字典原子 $\mathbf{d}_i$ 和 $\mathbf{t}_j$ 与检测样本 $\mathbf{y}_j$ 的相似性越高，相应的先验矩阵 $\mathbf{W}_{1_{i,j}}$ 和 $\mathbf{W}_{2_{i,j}}$ 的值越小。因此，$\mathbf{W}_{1_{i,j}}$ 和 $\mathbf{W}_{2_{i,j}}$ 可以视为对系数矩阵 $\mathbf{B}_{i,j}$ 和 $\mathbf{A}_{i,j}$ 的惩罚参数。换句话说，$\mathbf{W}_{1_{i,j}}$ 和 $\mathbf{W}_{2_{i,j}}$ 的值越小，对应的惩罚越弱，从而减轻对系数矩阵 $\mathbf{B}_{i,j}$ 和 $\mathbf{A}_{i,j}$ 的约束。通过引入这些先验矩阵来约束背景和异常成分，式 (6.6) 可重新表述为：

$$\begin{aligned} &\min_{\mathbf{J},\mathbf{A},\mathbf{N}} \gamma \sum_{i=1}^{2} \|\mathbf{W}_1 \odot \mathbf{J}_i\|_* + \lambda\|\mathbf{W}_2 \odot \mathbf{S}\|_{2,1} + \beta\|\mathbf{N}\|_1 \\ &s.t.\ \ \mathbf{Y} = \mathbf{DB} + \mathbf{TA} + \mathbf{N},\ \ \mathbf{A} = \mathbf{S}, \mathbf{J}_i = \nabla_i(\mathbf{B}) \end{aligned} \tag{6.9}$$

其中，Hadamard 乘积 $\odot$ 用于将先验矩阵 $\mathbf{W}_1$ 和 $\mathbf{W}_2$ 应用于表示系数 $\mathbf{B}$ 和 $\mathbf{A}$。随着迭代过程的推进，根据更新后的字典原子 $\mathbf{D} = [\mathbf{D}, \overline{\mathbf{D}}]$ 和 $\mathbf{T} = [\mathbf{T}, \overline{\mathbf{T}}]$，对矩阵 $\mathbf{W}_1$ 和 $\mathbf{W}_2$ 进

中国知网 https://www.cnki.net

行动态更新，其中，$\overline{\mathbf{D}}$ 和 $\overline{\mathbf{T}}$ 表示获取的增量字典原子。因此，式 (6.9) 重新表述为：

$$\begin{aligned} &\min_{\mathbf{J},\mathbf{A},\mathbf{N}} \gamma \sum_{i=1}^{2} \|\mathbf{W}_1 \odot \mathbf{J}_i\|_* + \lambda \|\mathbf{W}_2 \odot \mathbf{S}\|_{2,1} + \beta \|\mathbf{N}\|_1 \\ &s.t.\ \mathbf{Y} = [\mathbf{D}, \overline{\mathbf{D}}]\mathbf{B} + [\mathbf{T}, \overline{\mathbf{T}}]\mathbf{A} + \mathbf{N},\ \mathbf{A} = \mathbf{S}, \mathbf{J}_i = \nabla_i(\mathbf{B}) \end{aligned} \tag{6.10}$$

在不失一般性的情况下，使用 $\mathbf{D} = [\mathbf{D}, \overline{\mathbf{D}}]$ 和 $\mathbf{T} = [\mathbf{T}, \overline{\mathbf{T}}]$ 表示字典原子。交替方向乘子法 (Alternating Direction Method of Multipliers, ADMM) 是一种有效的约束优化问题求解方法，可用于解决公式 (6.10) 中提出的问题。通过引入辅助变量，公式 (6.10) 的增广拉格朗日形式可以写作：

$$\begin{aligned} &\ell\left(\mathbf{B}, \mathbf{A}, \{\mathbf{J}_i\}_{i=1}^{2}, \mathbf{N}, \mathbf{S}\right) \\ &= \gamma \sum_{i=1}^{2} \|\mathbf{W}_1 \odot \mathbf{J}_i\|_* + \lambda \|\mathbf{W}_2 \odot \mathbf{S}\|_{2,1} + < \mathbf{Y}_1, \mathbf{Y} - \mathbf{DB} - \mathbf{TA} - \mathbf{N} > \\ &+ < \mathbf{Y}_2, \nabla\mathbf{B} - \mathbf{J} > + < \mathbf{Y}_3, \mathbf{A} - \mathbf{S} > + \frac{\mu}{2}\left(\left\|\nabla_i\mathbf{B} - \mathbf{J}_i + \frac{\mathbf{Y}_i}{\mu}\right\|_F^2\right. \\ &\left. + \left\|\mathbf{Y} - \mathbf{DB} - \mathbf{TA} - \mathbf{N} + \frac{\mathbf{Y}_3}{\mu}\right\|_F^2 + \left\|\mathbf{A} - \mathbf{S} + \frac{\mathbf{Y}_4}{\mu}\right\|_F^2\right) + \beta\|\mathbf{N}\|_1 \end{aligned} \tag{6.11}$$

其中，$\mathbf{Y}_i (i = 1, 2, 3)$ 表示拉格朗日乘子，λ 和 β 是权衡参数，$< \cdot, \cdot >$ 表示两个矩阵的内积。根据 ADMM，式 (6.11) 被分解为每个涉及变量的子问题，并进行迭代求解。具体如下：

1）**J**-子问题:

$$\arg\min_{\mathbf{J}_i} \gamma \sum_{i=1}^{2} \left(\|\mathbf{W}_1 \odot \mathbf{J}_i\|_*\right) + \frac{\mu}{2}\left\|\mathbf{J}_i - \left(\nabla_i\mathbf{B} + \frac{\mathbf{Y}_i}{\mu}\right)\right\|_F^2 \tag{6.12}$$

由于 $\mathbf{W}_1$ 不是全 1 矩阵，直接应用 SVT 算子求解具有一定的挑战性。根据文献 [173, 174] 中的相关引理，子问题 **J** 的解可以表示为：

$$\left[2\gamma\left(\mathbf{W}_1 \odot \mathbf{W}_1\right) + \mu\right]\mathbf{J}_i = \mu\left(\nabla_i\mathbf{B} + \frac{\mathbf{Y}_i}{\mu}\right) \tag{6.13}$$

2）**N**-子问题:

$$\mathbf{N}_{k+1} = \arg\min_{\mathbf{N}} \beta\|\mathbf{N}\|_1 + \frac{\mu}{2}\left\|\mathbf{Y} - \mathbf{DB} - \mathbf{TA} - \mathbf{N} + \frac{\mathbf{Y}_3}{\mu}\right\|_F^2 \tag{6.14}$$

根据 [105]，式 (6.14) 的解可以重写为：

$$\mathbf{N}_{k+1} = \mathcal{S}_{\frac{\beta}{\mu}}\left(\mathbf{Y} - \mathbf{DB} - \mathbf{TA} + \frac{\mathbf{Y}_3}{\mu}\right) \tag{6.15}$$

中国知网 https://www.cnki.net

3）**S**-子问题:

$$\arg\min_{\mathbf{S}} \lambda\|\mathbf{W}_2 \odot \mathbf{S}\|_{2,1} + \frac{\mu}{2}\left\|\mathbf{A} - \mathbf{S} + \frac{\mathbf{Y}_4}{\mu}\right\|_F^2 \tag{6.16}$$

S 问题可以通过对矩阵 $\mathbf{A} + \frac{(\mathbf{Y}_4)}{\mu}$ 应用软阈值算子来求解:

$$\mathbf{S}_{i,:} = \begin{cases} \left(1 - \frac{\lambda\|\mathbf{W}_{2,i,:}\|_2}{\mu\|\mathbf{Q}_{i,:}\|_2}\right)\mathbf{Q}_{i,:}, & \text{if } \|\mathbf{Q}_{i,:}\|_2 > \frac{\lambda\|\mathbf{W}_{2,i,:}\|_2}{\mu} \\ 0, & \text{otherwise} \end{cases} \tag{6.17}$$

其中，$\lambda\mathbf{W}_2/\mu$ 是阈值，$\mathbf{Q} = \mathbf{A} + \frac{(\mathbf{Y}_4)}{\mu}$。

4）**A**-子问题:

$$\arg\min_{\mathbf{A}} \frac{\mu}{2}\left\|\mathbf{A} - \mathbf{S} + \frac{\mathbf{Y}_4}{\mu}\right\|_F^2 + \frac{\mu}{2}\left\|\mathbf{Y} - \mathbf{DB} - \mathbf{TA} - \mathbf{N} + \frac{\mathbf{Y}_3}{\mu}\right\|_F^2 \tag{6.18}$$

随后，**A** 可以通过以下方式计算:

$$\left(\mu\mathbf{I} + \mu\mathbf{T}^T\mathbf{T}\right)\mathbf{A} = \mu\left(\mathbf{S} - \frac{\mathbf{Y}_4}{\mu}\right) + \mu\mathbf{T}^T\left(\mathbf{Y} - \mathbf{DB} - \mathbf{N} + \frac{\mathbf{Y}_3}{\mu}\right) \tag{6.19}$$

5）**B**-子问题:

$$\arg\min_{\mathbf{B}} \frac{\mu}{2}\left\|\mathbf{Y} - \mathbf{DB} - \mathbf{TA} - \mathbf{N} + \frac{\mathbf{Y}_3}{\mu}\right\|_F^2 + \frac{\mu}{2}\left\|\mathbf{J}_i - \left(\nabla_i\mathbf{B} + \frac{\mathbf{Y}_i}{\mu}\right)\right\|_F^2 \tag{6.20}$$

对于子问题 **B** 的求解，可通过引入变量 $\mathbf{q} = \mathbf{B}$，式 (6.20) 重写为:

$$\begin{aligned} \arg\min_{\mathbf{B},\mathbf{q}} & \frac{\mu}{2}\left\|\mathbf{Y} - \mathbf{Dq} - \mathbf{TA} - \mathbf{N} + \frac{\mathbf{Y}_3}{\mu}\right\|_F^2 \\ & + \frac{\mu_2}{2}\left\|\mathbf{q} - \left(\mathbf{B} + \frac{\mathbf{Y}_5}{\mu_2}\right)\right\|^2 + \frac{\mu}{2}\left\|\mathbf{J}_i - \left(\nabla_i\mathbf{B} + \frac{\mathbf{Y}_i}{\mu}\right)\right\|_F^2 \end{aligned} \tag{6.21}$$

公式 (6.21) 的解通过以下两个子问题求得:

$$\begin{cases} \arg\min_{\mathbf{B}} \frac{\mu_2}{2}\left\|\mathbf{q} - \left(\mathbf{B} + \frac{\mathbf{Y}_5}{\mu_2}\right)\right\|^2 + \frac{\mu}{2}\left\|\mathbf{J}_i - \left(\nabla_i\mathbf{B} + \frac{\mathbf{Y}_i}{\mu}\right)\right\|_F^2 \\ \arg\min_{\mathbf{q}} \frac{\mu}{2}\left\|\mathbf{Y} - \mathbf{Dq} - \mathbf{TA} - \mathbf{N} + \frac{\mathbf{Y}_3}{\mu}\right\|_F^2 + \frac{\mu_2}{2}\left\|\mathbf{q} - \left(\mathbf{B} + \frac{\mathbf{Y}_5}{\mu_2}\right)\right\|^2 \end{cases} \tag{6.22}$$

其中，与 **B** 相关的子问题可以通过傅里叶变换来求解。

$$\left(\mu_2\mathbf{I} + \mu\nabla^T\nabla\right)\mathbf{B} = \mu_2\left(\mathbf{q} - \frac{\mathbf{Y}_5}{\mu_2}\right) + \mu\nabla^T\left(\mathbf{J} - \frac{\mathbf{Y}_i}{\mu}\right) \tag{6.23}$$

中国知网 https://www.cnki.net

Algorithm 6.1 DIMSJD 模型求解

输入: $\mathbf{D}, \mathbf{T}, \overline{\mathbf{D}}, \overline{\mathbf{T}}, \mathbf{W}, \lambda, \mu, K$
输出: $\mathbf{B}, \mathbf{A}, \mathbf{N}$

while $0 \leq k < K \wedge \left\|\mathbf{Y} - \mathbf{D}^{k+1} * \mathbf{B}^{k+1} - \mathbf{T}^{k+1} * \mathbf{A}^{k+1} - \mathbf{N}^{k+1}\right\|_F / \|\mathbf{Y}\|_F \geq \partial$ **do**
    由 (6.12) 更新 $\mathbf{J}^k$
    根据 (6.14) 求解 $\mathbf{N}^k$
    使用 (6.16) 计算 $\mathbf{S}^k$
    通过 (6.18) 获取 $\mathbf{A}^k$
    根据 (6.20) 求解 $\mathbf{B}^k$
    利用 (6.24) 计算 $\mathbf{q}^k$
    $\mu \leftarrow \rho\mu$
    $k \leftarrow k + 1$;
end while

与 $\mathbf{q}$ 相关问题的解如下:

$$\left(\mu\mathbf{D}^T\mathbf{D} + \mu_2\mathbf{I}\right)\mathbf{q} = \mu\mathbf{D}^T\left(\mathbf{Y} - \mathbf{TA} - \mathbf{N} + \frac{\mathbf{Y}_3}{\mu}\right) + \mu_2\left(\mathbf{B} + \frac{\mathbf{Y}_5}{\mu_2}\right) \tag{6.24}$$

DIMSJD 相应的伪代码在算法 6.1 中总结。

6.3.2 背景字典构建与更新

在背景重建的过程中，背景字典的质量直接影响异常检测性能。当背景字典缺乏完备性和判别能力时，背景成分与异常成分的有效分离将面临显著挑战。为解决这一问题，本章设计了 MSBD 和 DID-BA 方法。

1) MSBD：构建纯净且具有强表征力的背景字典是实现精确背景分离的重要条件。然而，实际场景中异常像素往往嵌入在背景区域中，导致背景字典构建过程中受到异常信号干扰。为此，本章提出了一种 MSBD 构建方法，通过分析异常形状和尺寸特性，利用多尺度降采样策略构建多尺度特征，降低背景字典构建过程中异常信号的占比，实现背景字典的优化构建。图 6.2(a)-(c) 显示了不同降采样尺度下 Pavia 数据的可视化结果，其中，图6.2(a) 和图6.2(d) 为尺度 1(S_1) 下的可视化与超像素分割结果，图6.2(b) 和图6.2(e) 为尺度 2(S_2) 下的可视化与超像素分割结果，图6.2(c) 和图6.2(f) 为尺度 3(S_3) 下的可视化与超像素分割结果。可以看到，随着尺度的减小，场景中的异常像素数量显著降低，这表明降采样操作能够有效地去除场景中的大多数异常像素，从而增加了背景像素的比例。

通过超像素分割方法[175,176] 和 K-means 聚类算法[177]，DIMSJD 从多尺度数据中提取了背景原子。图 6.2(d)-(f) 展示了从每个超像素中提取的聚类中心原子。因此，多尺度背景字典原子的构成如以下所示:

$$\mathbf{D} = (\mathbf{D}_1; \mathbf{D}_2; \mathbf{D}_3; \mathbf{D}_4) \tag{6.25}$$

中国知网 https://www.cnki.net

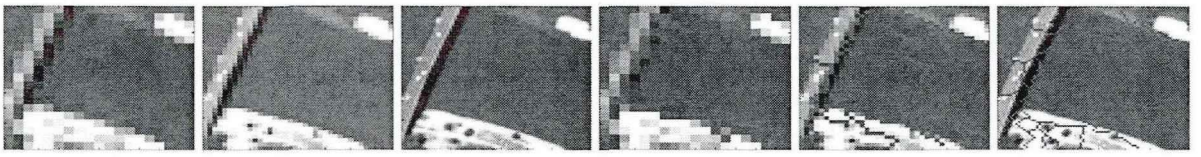

(a) S_1 可视化 (b) S_2 可视化 (c) S_3 可视化 (d) S_1 超像素分割 (e) S_2 超像素分割 (f) S_3 超像素分割

图 6.2 Pavia 数据的多尺度特征图

Fig. 6.2 Multiscale feature maps of the Pavia

其中，$\mathbf{D}_1$、$\mathbf{D}_2$、$\mathbf{D}_3$ 和 $\mathbf{D}_4$ 分别表示在降采样 S_1、S_2、S_3 和 S_4(原尺度) 下提取的背景字典原子。在本章中，降采样尺度分别设定为 0.125、0.25、0.5 和 1。

2) DID-BA：尽管多尺度降采样操作能够在一定程度上抑制场景中的大部分异常像素。但由于不同场景中异常目标在空间形状和尺度上的不确定性和差异性，降采样后的数据中仍不可避免地存在异常像素的残留。因此，仅依赖于多尺度特征进行背景原子提取，难以彻底解决背景重建过程中受到异常目标污染的问题。此外，由于高光谱异常检测任务通常缺乏可靠的先验信息，所提取的字典原子可能代表性不足，或受到噪声干扰，从而影响字典的表达能力，难以达到理想的背景建模效果。为弥补上述缺陷，本文提出了一种判别性增量多尺度字典学习方法。该方法基于当前波段组检测结果所提供的背景信息，动态更新并优化背景字典，以进一步提升其表征能力与鲁棒性。具体来说，高光谱图像的波段被划分为 j 个波段组，由 $\mathrm{VD_{HFC}}$, $\mathrm{VD_{NWHFC}}$ 和 MX-SVD[148,149,151] 确定。在第一个波段组中，字典 $\mathbf{D}$ 是固定的，由 MSBD 构建策略获得。当前第 j 个波段组的检测结果指示了可能的异常像素和背景像素。换句话说，预测值较低的像素更可能是背景像素。因此，当前波段组的检测结果可以被用于辅助后续波段组的背景像素重建。

$$\mathbf{F}_{i,j} = \begin{cases} 1 & \text{if } \ \mathrm{ADmap}_{i,j} > \delta \\ 0 & otherwise \end{cases} \tag{6.26}$$

在式 (6.26) 中，反馈信息矩阵 $\mathbf{F}$ 由异常检测结果动态生成，其元素取值由预定义的阈值 δ 决定。本章根据异常像素通常由少量像素构成的事实，采用基于统计百分位的阈值确定方法：将 ADmap 中的检测值进行降序排列，将随后取 0.2% 分位点作为 δ 的取值，由此确定潜在异常增量原子集合 $\bar{\mathbf{a}}$ 与潜在背景增量字典原子集合 $\overline{\mathbf{D}}$。

随着波段组的逐步处理，$\mathbf{F}$ 会被周期性地更新和优化。由于背景像素通常占据场景的大部分区域，直接采用全部标识像素会导致字典规模膨胀，计算量庞大。此外，错误的字典原子会对背景重构产生误导，而过度相关的冗余原子无法提升字典的表征力。它不仅无法带来额外的判别信息，还会增加计算量。为确保增量字典的冗余度较低并保持其完备性，本节通过评估增量原子 $\overline{\mathbf{D}}$ 和潜在异常原子 $\mathbf{a}$ 之间的相关性来优化增量原子。具体地，令 $\bar{\mathbf{d}}_i$ 表示 $\overline{\mathbf{D}}_0$ 中的第 i 个原子，$\mathbf{a}_j$ 表示 $\mathbf{a}$ 中的第 j 个样本，$\bar{\mathbf{d}}_i$ 与 $\mathbf{a}$ 之间的平均相关系数定义为：

中国知网 https://www.cnki.net

$$c_{\overline{\mathbf{d}}_i} = \frac{1}{n_a}\sum_{j=1}^{n_a}\frac{\left|\operatorname{cov}\left(\overline{\mathbf{d}}_i - \mathbf{a}_j\right)\right|}{\sqrt{\operatorname{var}\left(\overline{\mathbf{d}}_i\right)\operatorname{var}\left(\mathbf{a}_j\right)}} \tag{6.27}$$

其中，cov(·) 和 $var(\cdot)$ 分别表示协方差和方差运算。根据公式 (6.27)，相关性较低的增量原子更可能属于背景成分。因此，本节提出以下优化策略：将 $\overline{\mathbf{D}}$ 中的原子按照其相关性值降序排列，并移除相关性高的原子 (在本文中去除率为 10%)。与此同时，为在背景重建精度和计算效率之间取得平衡，DID-BA 进一步从剩余的原子中随机选择一定比例来确定最终增量字典原子 $\overline{\mathbf{D}}$。在本研究中，背景原子的采样率被设定为 $\ell_1 = 0.05$。由此，MSBD 构建过程表示为：

$$\mathbf{D} = \left(\mathbf{D}_1; \mathbf{D}_2; \mathbf{D}_3; \mathbf{D}_4; \overline{\mathbf{D}}_1; \overline{\mathbf{D}}_2; \overline{\mathbf{D}}_3; \overline{\mathbf{D}}_4\right) \tag{6.28}$$

其中，增量背景字典原子 $\overline{\mathbf{D}}$ 在整个检测过程中被定期优化和更新。

6.3.3 异常字典更新

除了占据场景主体的背景像素外，噪声的存在也可能干扰对异常成分的有效提取。不同于异常像素，噪声干扰通常仅出现在某些特定波段中。为此，本章采用潜在异常字典来表征感兴趣的异常光谱，从而有效去除数据中的噪声成分干扰。与现有方法[169–171] 类似，所提方法通过选取那些显著区别于周围背景的光谱特征来构建潜在异常目标初始字典。即，利用 RXD 检测结果中前 $c(c = 50)$ 个最可能为异常的像素构建初始异常字典。与文献 [169–171] 的不同之处在于，为克服高光谱异常检测缺乏目标的先验信息的局限性，本章设计了一个潜在异常字典的动态更新机制。该机制通过利用当前波段组的检测结果，为后续波段组的字典构建提供搜索方向，从而实现异常字典的逐步优化。

与背景字典的增量学习过程类似，DIMSJD 根据公式 (6.26) 中反馈矩阵 $\mathbf{F}$ 所指示的异常信息，从候选原子去除与背景相关性高的样本 (在本文中去除率为 10%)，以剔除不可靠或冗余的原子。这种持续的优化过程使得潜在异常字典能够更加精确地表征感兴趣的异常像素。因此，本章所提方法中异常字典原子集合 $\mathbf{T}$ 的构建过程如下

$$\mathbf{T} = [\mathbf{T}; \overline{\mathbf{T}}] \tag{6.29}$$

与背景增量字典一样，异常增量字典原子 $\overline{\mathbf{T}}$ 在检测过程中被定期优化和更新。

6.3.4 基于深度聚类的非异常残差去除

复杂背景可能导致背景提取后过多的非目标成分的残留，为后续波段组的异常检测提供不准确的指导。为了解决这一问题，本章将初始波段组的检测结果 R_1 作为基础信息，进而通过 Otsu 阈值分割法[153] 生成优化后的检测结果 R_2，以此指导后续波段组的异常检测过程。尽管该方式能够有效提升潜在异常像素的提取精度，但也存在

中国知网 https://www.cnki.net

一定的局限性，即过度抑制背景像素可能会无意中抑制部分异常像素，从而限制检测精度的进一步提升。因此，单独依赖 R_2 提供的异常信息难以构建一个鲁棒的异常目标检测方法。

受到文献 [178] 中深度聚类的启发，本章将初步异常检测过程与 Otsu 操作视为提取异常像素空间和光谱特征的关键步骤。为全面表征场景中不同材料分布特性，通过引入主成分分析作为补充信息，完善由 R_1 和 R_2 提供的目标分布信息。具体而言，图 6.3 (a) 展示了初始的异常检测结果 R_1，而图 6.3 (b) 为对 R_1 应用 Otsu 方法生成的 R_2。可以看到，尽管图 6.3 (a) 成功检测到异常像素，但同时也错误的将大量背景像素 (例如海滩区域) 归类为异常，导致较高的误检率。值得注意的是，背景像素的有效抑制能力也是评估高光谱异常检测算法性能的一个重要指标[166]。在图 6.3 (b) 中，Otsu 阈值分割算法有效实现了背景像素的抑制，但同时也造成了部分异常像素的抑制。图 6.3 (c)-(e) 展示了该场景的前三个主成分的可视化结果，这些主成分清晰地反映了不同材料在空间上的分布特征。

(a) R_1 (b) R_2 (c) PC_1 (d) PC_2 (e) PC_3

图 6.3 Cat Island 的增强特征图

Fig. 6.3 Enhanced feature map of beach1

基于以上观察，本章将图 6.3 (c)-(e) 的主成分信息与 R_1 和 R_2 特征结合，构建了增强特征 $\mathcal{F}$。该增强特征融合了更为丰富的细节与信息，有助于准确地提取异常目标。增强特征 $\mathcal{F}$ 的构建过程可表述如下：

$$\mathcal{F} = \begin{pmatrix} R_1 \\ R_2 \\ R_{PC} \end{pmatrix} \tag{6.30}$$

所构建的增强特征实现了对背景和异常分布更全面、更精细的表征，显著提升了异常与背景之间的可区分性，同时增强了算法的鲁棒性。最后，使用 C 对融合特征 $\mathcal{F}$ 进行聚类，以准确识别感兴趣的异常目标。该网络架构采用 1×1 卷积核设计，其中前两个模块均采用双曲正切 (hyperbolic tangent, Tanh) 激活函数。在第三模块中，通过 Softmax 函数，根据预设的聚类数 M 计算个样本的隶属度 c，其数学表达式如下：

$$\mathbf{c}_p = C(\mathbf{z}_p, \theta_{c1}) = soft\max(\tanh(\omega_{c1}\mathbf{z}_p + \mathbf{b}_{c1})) \tag{6.31}$$

式中，θ_{c1} 表示网络 C 的参数，ω_{c1} 和 $\mathbf{b}_{c1}$ 分别对应权重和偏置。高斯混合模型 (Gaussian

中国知网 https://www.cnki.net

Mixture Model, GMM) 的概率密度函数 (probability density function, pdf) 被用于密度估计，以生成能量图。聚类网络 $\mathcal{C}$ 的结构如图6.4所示，其中，反馈信息包括 R_1 和 R_2。随后，对能量图进行精细化处理[178,179]，以获得最终的检测结果。

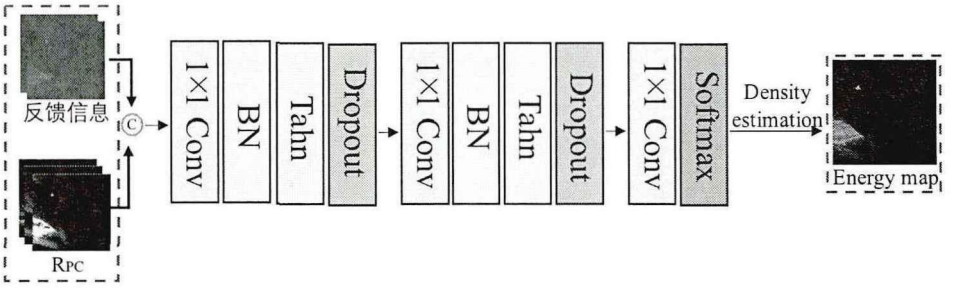

图 6.4 聚类网络结构

Fig. 6.4 Architecture of clustering network

算法 6.2 详细描述了所提 DIMSJD 方法的执行流程，该方法包含两个主要阶段。首先，基于提取的异常成分生成初步的检测结果。其次，利用初步检测结果标识的异常和背景像素，并结合样本的一致性，初步确定每个字典的增量原子。这些增量原子随后根据其平均相关性进行精细化处理。当两次连续检测迭代之间的 TI 值低于设定的阈值 φ，或达到最大迭代次数 T 时，输出最终检测结果。

Algorithm 6.2 基于 DIMSJD 的高光谱异常检测算法

输入: 高光谱图像 $\mathcal{Y} \in \mathbb{R}^{h\times w\times B}$, 参数 λ, μ, 最大迭代次数 T;
输出: 最终异常检测结果;

初始化:
利用多尺度降采样构建多尺度数据: S_1-S_4;
利用超像素分割、K-means、RX 初始化背景 **D** 和异常字典 **T**;
while $0 \le t < T \wedge \mathrm{TI}^{(k)} = \frac{|\mathrm{ADmap}^t \cap \mathrm{ADmap}^{t-1}|}{|\mathrm{ADmap}^t \cup \mathrm{ADmap}^{t-1}|} > \varphi$ **do**
    选择波段组: $\mathbf{Y}_B^t = \mathrm{UBS}_{\mathrm{HSI}}$
    根据 (6.9) 构建和求解 DIMSJD 模型;
    根据 $\mathbf{Y}_B^t$ 计算异常检测结果;
    根据 (6.26) 计算反馈信息矩阵 **F**;
    选择下一个波段组: $\mathbf{Y}_B^{t+1} = \mathrm{UBS}_{\mathrm{HSI}}$;
    计算并优化背景和异常字典原子 $\overline{\mathbf{D}}$ 和 $\overline{\mathbf{T}}$;
    根据 (6.10) 构建并求解 DIMSJD-DID 模型;
    计算 $\mathbf{Y}_B^{t+1}$ 的异常检测结果;
    $t \leftarrow t+1$;
end while

6.4 实验结果和性能分析

6.4.1 实验设置

(1) 实验数据

中国知网 https://www.cnki.net

本小节采用异常检测研究中广泛分析的六组数据对所提方法进行评估，图6.5中展示了这些数据的可视化结果，这些数据的详细介绍如下：

1) Cat Island：该数据空间尺寸大小为 150×150，每个像素具有 188 个光谱波段。该数据集中的船只被标记为异常，占据总像素的 0.08%。尽管该数据集的复杂性较低，但如研究 [180, 181] 中提到的，该数据中的异常像素周围存在较强的非异常干扰。

2) Los Angeles-I：该数据空间尺寸为 100×100×205，空间分辨率为 7.1 米。场景中的飞机被标识为异常目标。如图 6.5(b) 所示，Los Angeles-I 数据具有相对复杂的背景。

3)) Texas Coast：Texas Coast 数据集的尺寸为 100×100 像素，包含 207 个光谱波段。在该数据中，不同尺度的建筑物被指定为异常目标。

4) Los Angeles-II：此数据由 100×100 像素组成，包含 205 个光谱波段，空间分辨率为 1.7 米，其中不同规模的建筑物被标记为异常目标，异常占比为 2.72%。相较于其他数据，该数据具有较大的异常占比。

5) HYD-U：该数据由 HYDICE 传感器采集，包含 80×100 像素，跨越 174 个光谱波段，空间分辨率为 1.2 米，其中，汽车和屋顶被识别为异常目标，占比 0.2%。

6) Pavia：Pavia 数据的空间分辨率为 1.3 米，具有 102 个光谱波段，尺寸为 150×150 像素。异常目标是由 68 个像素组成的车辆，因此该场景中的异常像素分布相对稀疏。

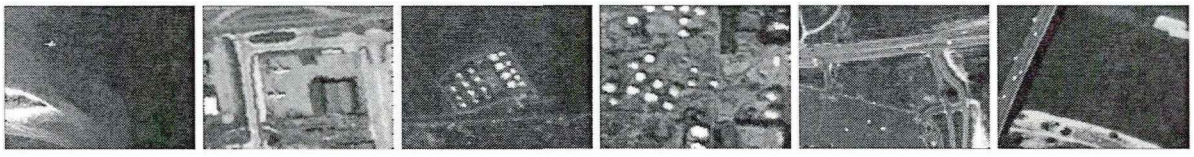

(a) Cat Island (b) Los Angeles-I (c) Texas Coast (d) Los Angele-II (e) HYD-U (f) Pavia

图 6.5 实验数据可视化

Fig. 6.5 Visualization of experimental data

(2) 对比方法

如前文所述，高光谱异常检测领域的不断发展催生了大量创新性研究的涌现。为全面评估本章所提 DIMSJD 方法的检测性能，本章选取了十一类具有代表性的对比方法，构建了多层次、多维度的评估体系。具体而言，这些对比方法可分为以下四类：1) 经典统计方法：RXD[68]；2) 基于低秩和稀疏表示的方法：基于正交子空间投影的 OSP-GoDec[147]；考虑噪声影响的 RhyDe[8]；具有分层抗噪声互不相干性的 AHMID[156]；特征提取和背景一直相结合的 IFEBP[88]；以及考虑了高光谱结构特征的两种基于张量的方法：PTA[160] 和 PCA-TLRSR；3) 基于孤立森林的 SSIIFD[161]；4) 基于数据驱动的方法：基于自编码器网络的 RGAE[164] 和 GAED[163]，以及联合解混和异常检测的 UADNet[178]。

实验对比设计具有明确的针对性，具体来说，RXD 作为异常检测的基线被广泛研

中国知网 https://www.cnki.net

究，与该方法的对比可验证基础检测性能，并评估所提方法在不同数据上的稳定性。OSP-GoDec 提供了不同子空间中的背景抑制和异常目标检测，通过比较 OSP-GoDec 在稀疏空间中的表现 ($\delta_{\mathbf{S}}^{\mathrm{R-AD}}(\mathbf{r}_{\mathbf{S}})$) 和背景抑制出色的 IFEBP 方法，可验证 DIMSJD 在背景抑制方面的优势。RhyDe 和 AHMID 考虑了噪声影响下的异常检测方法，因此，与它们的对比分析可验证 DIMSJD 在抵抗噪声干扰方面的优势。与 PTA 和 PCA-TLRSR 的比较可以评估提出方法的背景成分和异常成分的分割能力。此外，鉴于目前基于深度学习在异常目标检测中的深入发展，GAED，RGAE 和 UADNet 被添加为对比算法，其中，GAED 在网络中引入了引导模块，利用反馈信息减少背景重建时的异常目标的干扰，与 GAED 的比较可反映提出方法中基于波段组的反馈策略的优势。与 UADNet 的比较可更公平的评估多尺度背景字典构建和从异常分布出发考虑的聚类网络的优越性。

这些方法各自从不同的视角开发设计，通常涉及大量参数的微调，为确保准确实验的公平性和可重复性，实验中严格依据原始文献的理论分析和公开代码的默认设置进行参数优化，最大程度的还原各方法的最佳性能表现。本章同样采用定性和定量结合的评估体系对所提方法进行系统性性能验证，其中，定量指标采用 3D ROC 曲线、2D ROC 曲线和曲线线下面积 AUC 值。

6.4.2 实验结果与分析

图 6.6-6.17 和表 6.1-6.6展示了包括所提方法在内的十二种异常检测方法的定性和定量对比分析结果。为了更直观地比较各检测器的性能差异，表中采用加粗字体标注最佳结果，次优结果则以下划线标识。

表 6.1 Cat Island 数据上不同方法的 AUC 值

Tab. 6.1 AUC Values of Different Methods on Cat Island

AUC	RXD	OSP-GoDec	PCA-TLRSR	AHMID	PTA	IFEBP	RhyDe	SSIIFE	RGAE	UADNet	GAED	DIMSJD
$(P_{\mathrm{D}},P_{\mathrm{F}})$	0.9675	0.9693	0.9865	0.7399	0.9831	0.9691	0.9696	0.9339	0.9445	<u>0.9995</u>	0.9484	**0.9997**
(P_{D},τ)	0.2432	**0.5905**	0.3184	0.0987	0.2592	0.2211	0.2205	0.1529	0.1076	0.3671	0.2165	<u>0.3963</u>
(P_{F},τ)	0.0075	0.0116	0.0132	0.0190	0.0148	0.0072	<u>0.0057</u>	0.0099	0.0182	0.0077	0.0147	**0.0052**
SNPR	32.5295	<u>50.8767</u>	24.1980	5.1876	17.5653	30.7231	38.7091	15.4893	5.9171	47.3990	14.7104	**75.7774**

定性评估分析：通过可视化检测结果图可直观反映各算法对异常目标的响应特性。图 6.6-6.11 采用蓝-红渐变色的方式表征从背景到异常的响应强度变化。由于高光谱图像中大部分区域通常由背景像素组成，RhyDe 方法通过子空间运算有效提取高光谱图像主成分，展现出出色的背景抑制效果。但其对于稀疏异常目标通常是不利的。基于张量的 PCA-TLRSR 方法同样受限于 PCA 操作的特性，其对于异常较弱的而干扰较强的场景检测效果欠佳，例如 Cat Island。另外一种基于张量的 PTA 方法将高光谱图像分解为背景张量和异常张量，但其在 Cat Island、Los Angeles-I 和 HYD-U 数据

中国知网 https://www.cnki.net

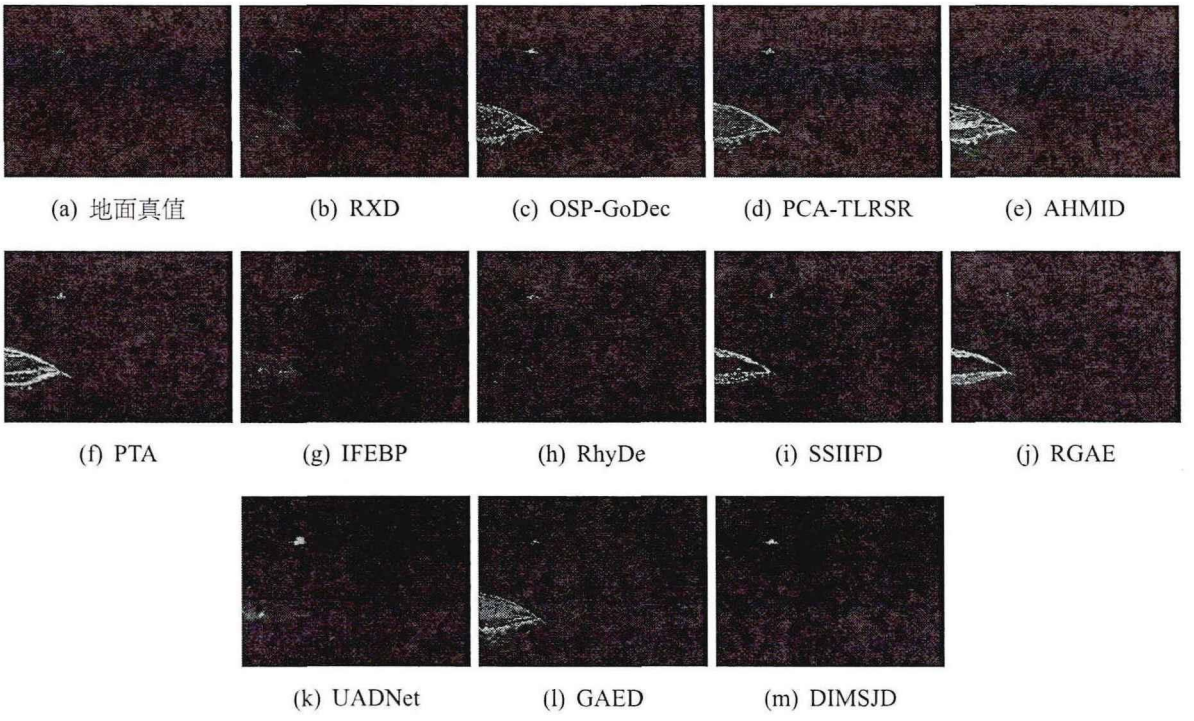

图 6.6 不同方法在 Cat Island 数据上的异常检测结果
Fig. 6.6 HAD results of different methods on the Cat Island

中出现大量背景像素被误判为异常目标的情况，导致检测图中存在不容忽视的干扰信息，表明了其检测能力的局限性。OSP-GoDec 在 HYD-U 和 Texas Coast 数据上表现优异，但在其他场景中难以有效区分异常与背景成分。IFEBP 融合分数傅里叶变换和低秩稀疏矩阵分解，在 Texas Coast 和 Los Angeles-II 上实现良好的背景抑制，但存在部分异常像素过度一直抑制问题，限制了整体检测表。AHMID 采用抗噪声分层互不相干性判别学习，在 Pavia、HYD-U、Texas Coast 和 Los Angeles-II 数据上获得干净的背景输出，但存在少量异常像素缺失问题。此外，其在 Los Angeles-I 和 Cat Island 数据上同时存在背景抑制和异常检测性能均不理想的情况。RXD 性能发挥稳定，但未能取得突出优势，其背景抑制和异常检测能力上均存在一定的提升空间。两种基于自编码器网络的 RGAE 和 GAED 在 Cat Island 和 Los Angeles-I 场景的检测结果中具有明显的误检，一些本应是背景的像素被错误的识别为异常，且表现出了更高的异常响应程度。除此之外，RGAE 在其余数据上也存在不同程度的非异常区域残留。相对来说，GAED 具有更干净的背景，但代价是部分异常像素被抑制。类似地情况也发生在基于隔离森立的 SSIIFD 方法的检测结果中，其难以在误检与真实异常检测之间取得平衡。与以上方法相比，UADNet 在视觉上更具优势，但其在背景抑制和异常突出能力的平衡上仍然具有改进空间。相比之下，提出的 DIMSJD 很大程度上改善了这方面的表现，其在背景抑制和异常突出方面均表现出了视觉可见的优势，即使在具有强背景干扰下的 Cat Island 场景中也表现出出色的检测性能。

定量评估分析: 定量评估通过量化数值指标客观评估不同算法的异常检测性能。

中国知网 https://www.cnki.net

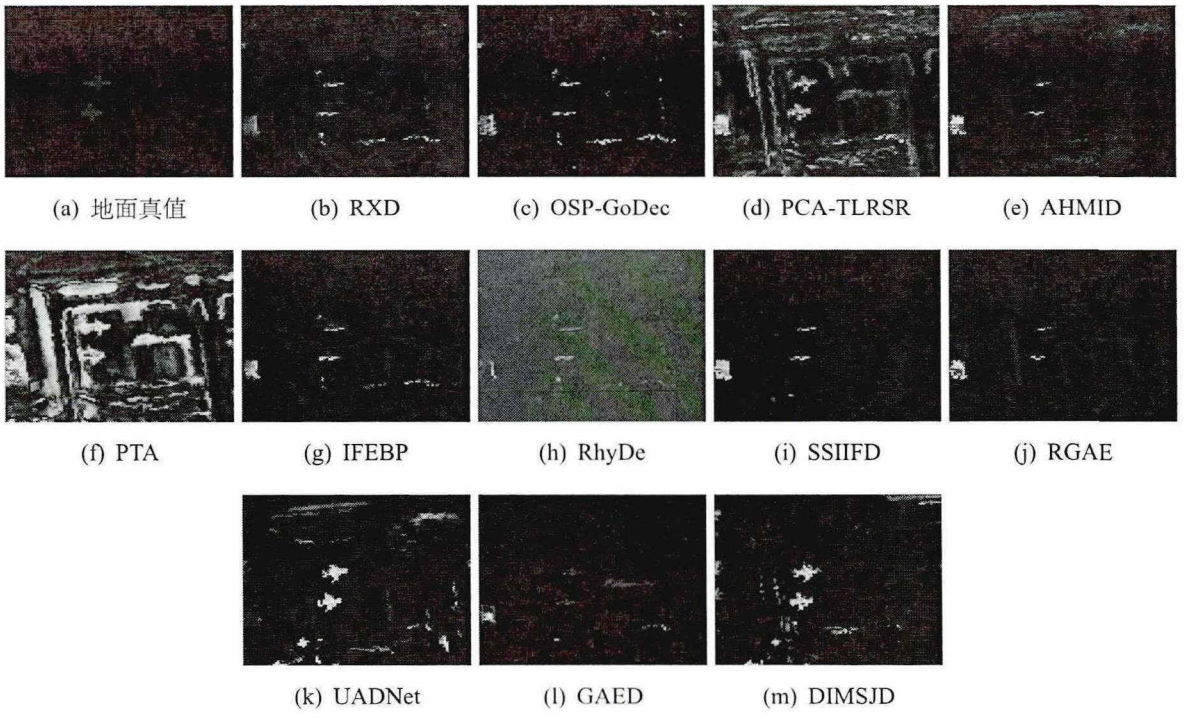

图 6.7　不同方法在 Los Angeles-I 数据上的异常检测结果

Fig. 6.7　HAD results of different methods on the Los Angeles-I

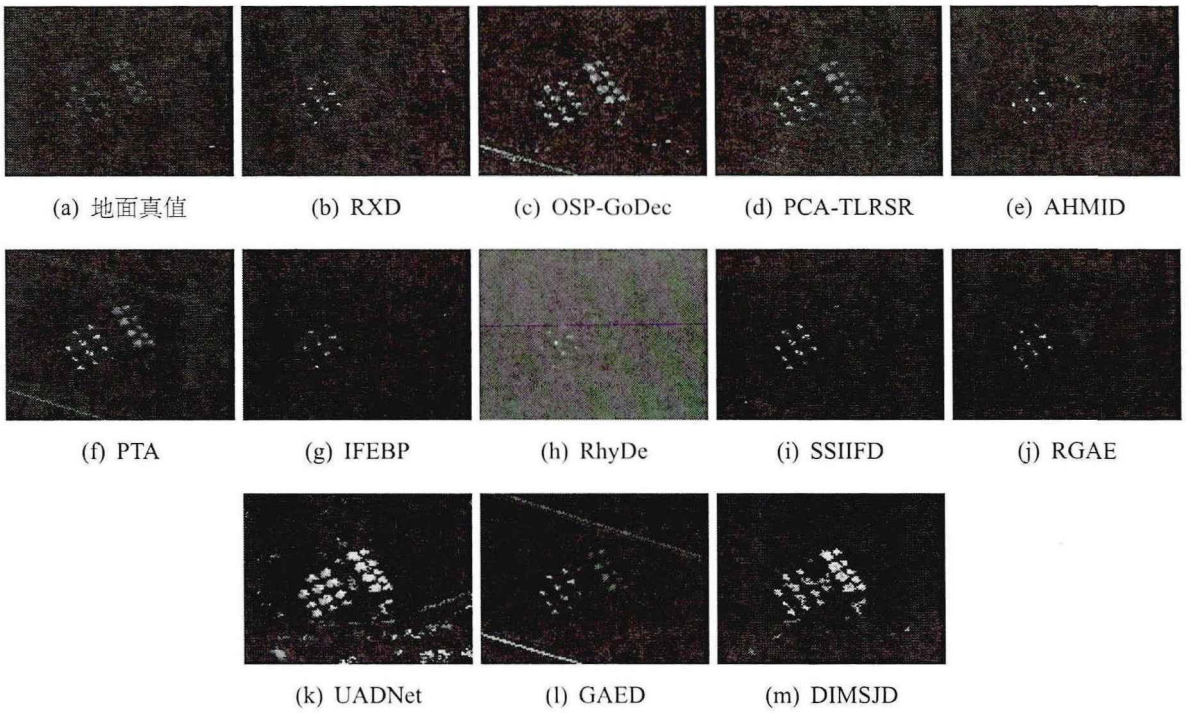

图 6.8　不同方法在 Texas Coast 数据上的异常结果

Fig. 6.8　HAD results of different methods on the Texas Coast

中国知网　https://www.cnki.net

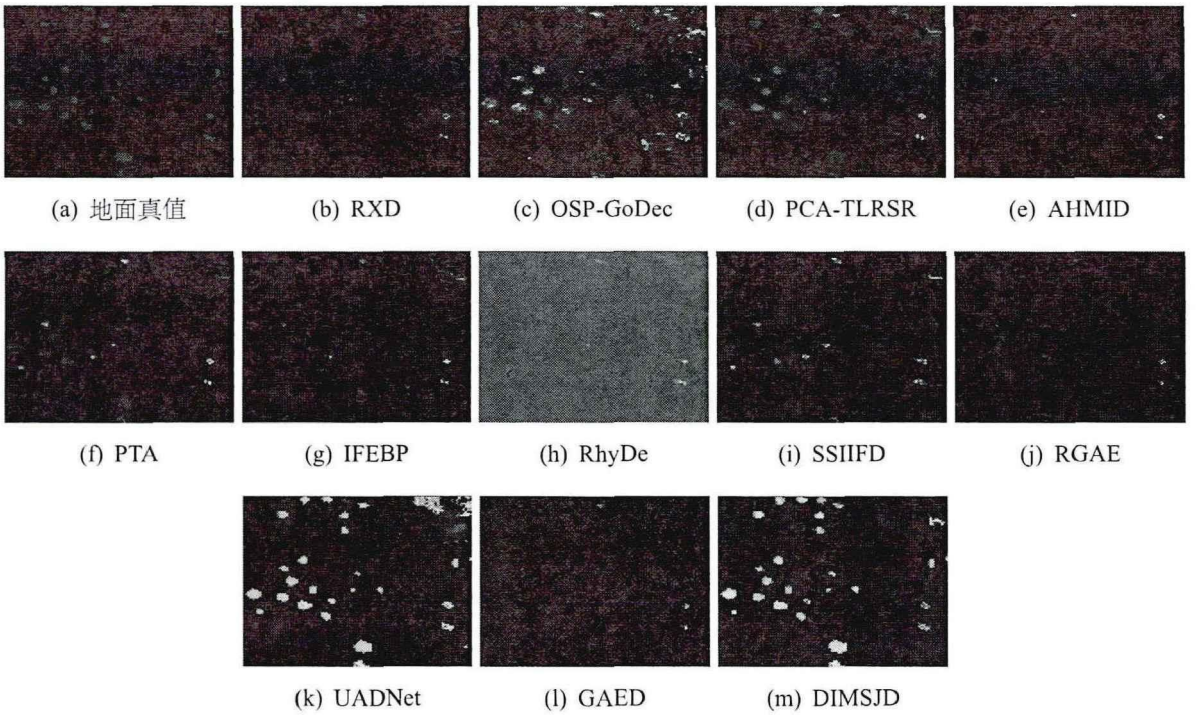

图 6.9 不同方法在 Texas Coast 数据上的异常检测结果

Fig. 6.9 HAD results of different methods on the Texas Coast

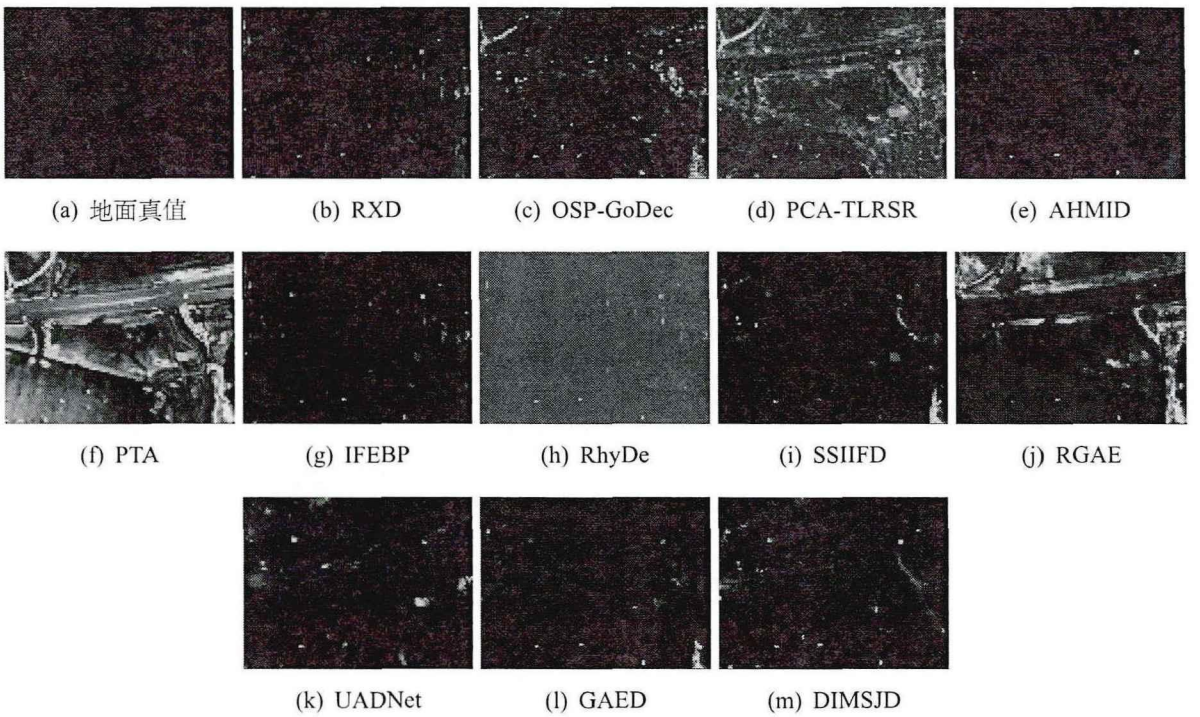

图 6.10 不同方法在 HYD-U 数据上的异常检测结果

Fig. 6.10 HAD results of different methods on the HYD-U

中国知网 https://www.cnki.net

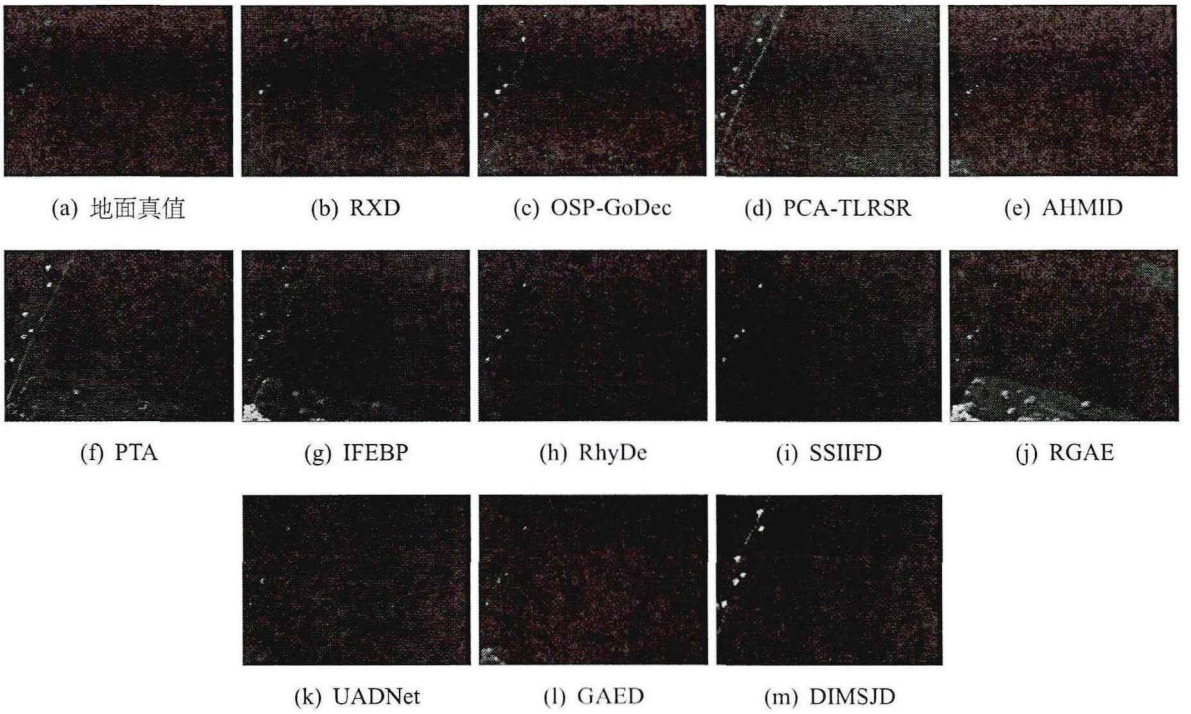

图 6.11　不同方法在 Pavia 数据上的异常检测结果
Fig. 6.11　HAD results of different methods on the Pavia

与定性评估相比，定量评估提供了更精确且客观的数据支持。为进行全面准确的定量分析，图6.12-6.17展示了根据图6.6-6.11中的十二种不同方法的异常检测结果的 3D ROC 曲线及其对应的三个 2D ROC 曲线。如图 6.12-6.17所示，RGAE、AHMID、PTA、RhyDe 和 RXD 等算法在 Cat Island、Pavia、Los Angeles-I 和 HYD-U 数据上的表现欠佳。同样，GAED 和 IFEBP 在 Cat Island、Pavia 和 Los Angeles-I 数据上的也未能取得理想效果。PCA-TLRSR、OSP-GoDec、SSIIFD 和 UADNet 这四种方法在 Los Angeles-I 数据上同样表现不佳。相比之下，本章所提出的 DIMSJD 方法在所有六个数据上均表现出稳定且优异性能。其 (P_d, P_f) ROC 曲线显著向左上角偏移，而 (P_D, τ) ROC 曲线趋向于左下角。这表明 DIMSJD 能够在背景抑制和异常检测之间实现有效平衡，显著提升检测性能。

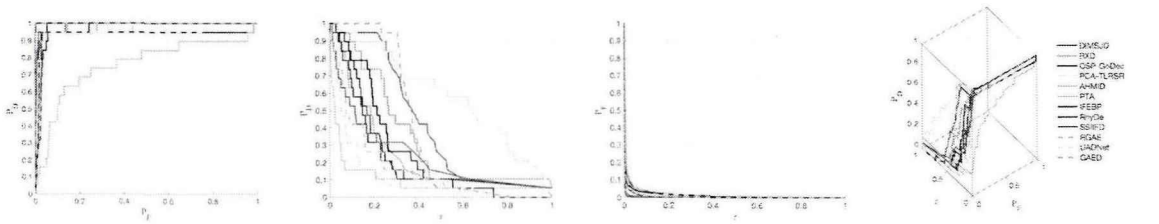

(a) (P_D, P_F) 2D ROC 曲线　(b) (P_D, τ)2D ROC 曲线　(c) (P_F, τ)2D ROC 曲线　(d) (P_D, P_F, τ)3D ROC 曲线

图 6.12　不同方法在 Cat Island 数据上的 ROC 曲线
Fig. 6.12　ROC curves of different methods for Cat Island

中国知网　https://www.cnki.net

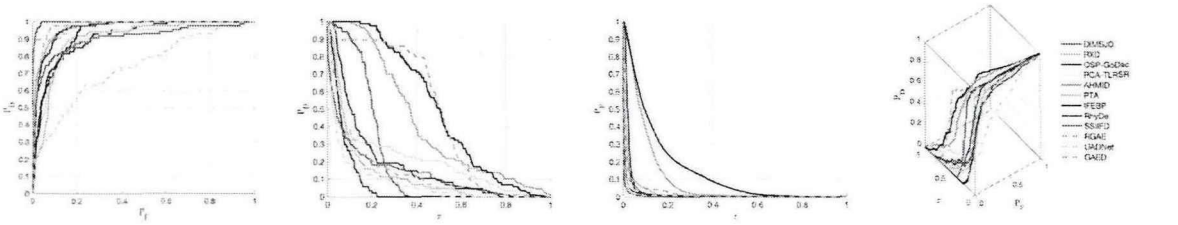

(a) 2D ROC 曲线 (P_D, P_F) (b) 2D ROC 曲线 (P_D, τ) (c) 2D ROC 曲线 (P_F, τ) (d) 3D ROC 曲线 (P_D, P_F, τ)

图 6.13 不同方法在 Los Angeles-I 数据上的 ROC 曲线

Fig. 6.13 ROC curves of different methods for Los Angeles-I

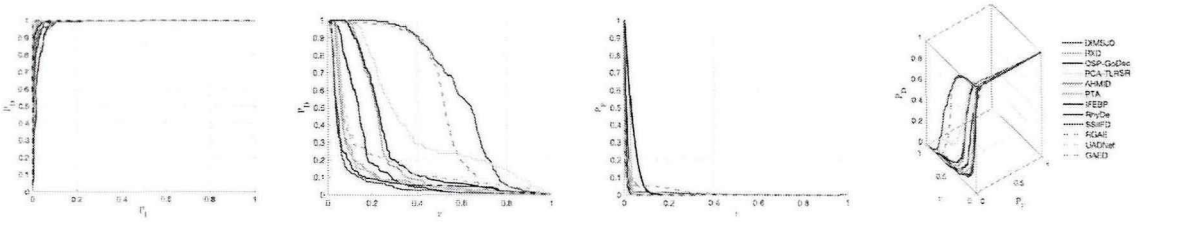

(a) 2D ROC 曲线 (P_D, P_F) (b) 2D ROC 曲线 (P_D, τ) (c) 2D ROC 曲线 (P_F, τ) (d) 3D ROC 曲线 (P_D, P_F, τ)

图 6.14 不同方法在 Texas Coast 数据上的 ROC 曲线

Fig. 6.14 ROC curves of different methods for Texas Coast

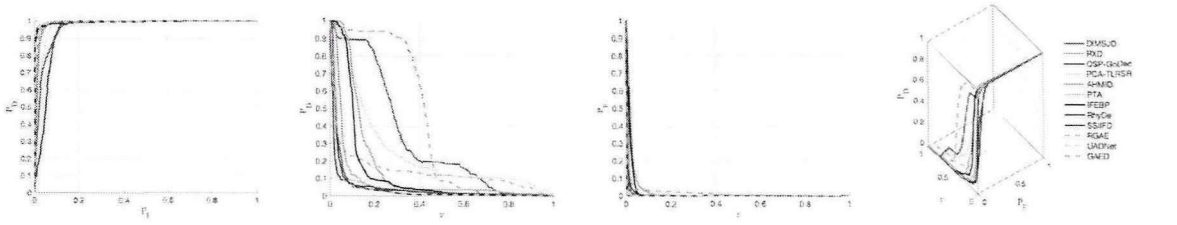

(a) 2D ROC 曲线 (P_D, P_F) (b) 2D ROC 曲线 (P_D, τ) (c) 2D ROC 曲线 (P_F, τ) (d) 3D ROC 曲线 (P_D, P_F, τ)

图 6.15 不同方法在 Los Angele-II 数据上的 ROC 曲线

Fig. 6.15 ROC curves of different methods for Los Angele-II

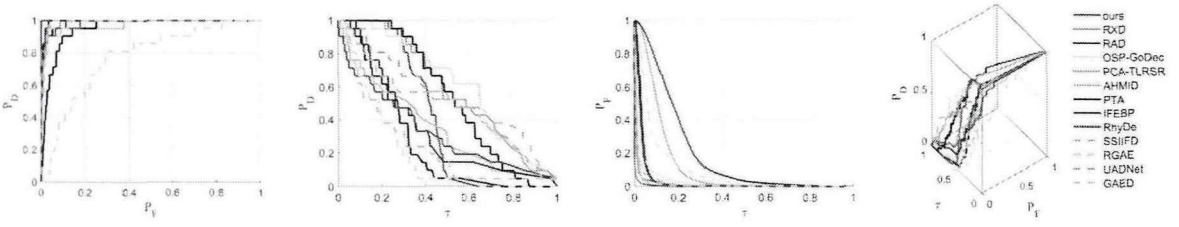

(a) 2D ROC 曲线 (P_D, P_F) (b) 2D ROC 曲线 (P_D, τ) (c) 2D ROC 曲线 (P_F, τ) (d) 3D ROC 曲线 (P_D, P_F, τ)

图 6.16 不同方法在 HYD-U 数据上的 ROC 曲线

Fig. 6.16 ROC curves of different methods for HYD-U

表 6.1-6.6中展示了根据图6.12-6.17 中的 ROC 曲线定量分析得到的 AUC 值表明，IFEBP、RhyDe、GAED 和 UADNet 的 AUC (P_f, τ) 值相对较低，且其在反映算

中国知网 https://www.cnki.net

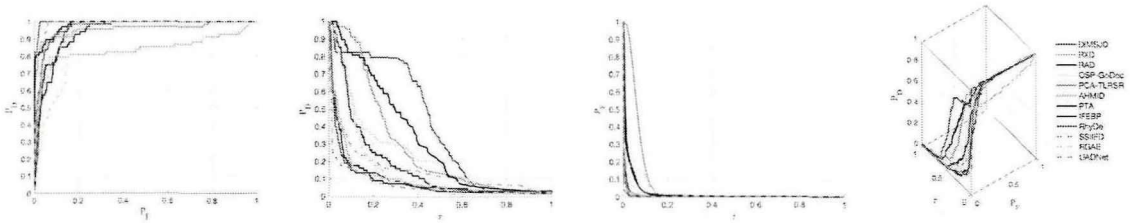

(a) 2D ROC 曲线 (P_D, P_F)　(b) 2D ROC 曲线 (P_D, τ)　(c) 2D ROC 曲线 (P_F, τ)　(d) 3D ROC 曲线 (P_D, P_F, τ)

图 6.17　不同方法在 Pavia 数据上的 ROC 曲线

Fig. 6.17　ROC curves of different methods for Pavia

法目标检测能力的 AUC (P_D, τ) 指标上表现不理想。这限制了它们的综合得分，导致 AUC (P_d, P_f) 和 AUC_{SNPR} 指标的表现不尽如人意。相比之下，PTA、PCA-TLRSR 和 OSP-GoDec 在 AUC (P_D, τ) 指标上取得相对突出的表现，但由于背景抑制不足，这些方法的 AUC (P_f, τ) 值较高。类似问题也出现在 RXD 和 SSIIFD 上。AHMID 在 Los Angele-II 和 Pavia 数据的 AUC (P_f, τ) 指标上表现优异，RGAE 在 Texas Coast 和 Los Angele-II 数据上表现良好。但它们较低的 AUC (P_D, τ) 值表明其异常目标检测能力有限，导致在 AUC (P_d, P_f) 和 AUC_{SNPR} 的整体得分不佳。相比之下，所提方法在异常检测和背景抑制之间实现了最佳平衡，表现出卓越性能。DIMSJD 在所有实验数据中均获得了最高的 AUC (P_d, P_f) 和 AUC_{SNPR} 值，并在几乎所有数据中取得 AUC (P_D, τ) 指标的最高得分。虽然其 AUC (P_f, τ) 指标并非在每个场景中都最优，但这并未影响方法的整体性能排名。这些结果与前述定性评估高度一致，表明所提方法在不同数据上均表现优异，能够有效保留不同尺度的异常像素并抑制干扰。这些优异表现得益于所提出的基于异常目标空间特征的多尺度背景字典构建方法，以及判别性增量字典策略的有效性。该策略通过利用不同波段组检测结果的一致性和互补性，能够准确捕捉感兴趣的异常像素，同时有效抑制不同场景中的非异常成分干扰。

综上所述，SSIIFD、AHMID、IFEBP、GAED、RhyDe 和 UADNet 的共同特点是背景抑制性能优于 RGAE、PCA-TLRSR 和 PTA，但对部分异常像素的抑制倾向限制了整体得分。RXD 和 OSP-GoDec 的结果相对稳定但未能取得突出性能，仍有明显提升空间。相比之下，所提 DIMSJD 方法在异常像素检测和背景抑制之间实现了最佳平衡，取得了最高的综合得分。

6.4.3　增量字典有效性验证分析

本小节旨在对所提出的 DID 策略的有效性进行系统性验证分析。需要特别说明的是，由于不同光谱波段所蕴含的信息具有独特性差异，目标物质的光谱反射特性在某些特定波段可能表现出更加显著的相应特征，这可能导致检测性能存在一定程度的波动。为准确评估 DID 策略的影响，本节实验采用固定光谱波段子集迭代，以排除波段变量对结果的影响，从而聚焦验证 DID 模块本身对检测性能的贡献。

图 6.18 所示实验结果表明，在不同数据上，AUC (P_d, P_f) 评估指标值随着 DID 迭

中国知网　https://www.cnki.net

表 6.2 Los Angeles-I 数据上不同方法的 AUC 值

Tab. 6.2 AUC Values of Different Methods on Los Angeles-I

AUC	RXD	OSP-GoDec	PCA-TLRSR	AHMID	PTA	IFEBP	RhyDe	SSIIFE	RGAE	UADNet	GAED	DIMSJD
(P_D,P_F)	0.8410	0.8171	0.9662	0.8937	0.9310	0.9602	0.8498	0.9233	0.7149	0.9862	0.8948	**0.9958**
(P_D,τ)	0.1826	0.1901	0.4223	0.1197	**0.5035**	0.1764	0.1330	0.1243	0.0759	0.4719	0.0697	0.2028
(P_F,τ)	0.0516	0.0136	0.0997	0.0227	0.1500	0.0271	**0.0077**	0.0102	0.0205	0.0210	0.0170	0.0099
SNPR	3.5411	13.9553	4.2341	5.2756	3.3563	6.5075	17.1783	12.1468	3.6967	**22.4841**	4.1068	20.5238

表 6.3 Texas Coast 数据上不同方法的 AUC 值

Tab. 6.3 AUC Values of Different Methods on Texas Coast

AUC	RXD	OSP-GoDec	PCA-TLRSR	AHMID	PTA	IFEBP	RhyDe	SSIIFE	RGAE	UADNet	GAED	DIMSJD
(P_D,P_F)	0.9938	0.9953	0.9973	0.9910	0.9964	0.9825	0.9805	0.9667	0.9972	0.9950	0.9777	**0.9992**
(P_D,τ)	0.1652	0.3927	0.2350	0.1115	0.2592	0.0931	0.0713	0.1652	0.1161	0.5237	0.1573	**0.6059**
(P_F,τ)	0.0075	0.0159	0.0375	0.0233	0.0373	0.0079	**0.0062**	0.0075	**0.0063**	0.0228	0.0174	0.0118
SNPR	22.0068	24.7490	6.2581	4.7957	6.9477	11.8203	11.5580	22.0068	18.5348	22.9361	9.0251	**51.2072**

代次数的增加呈现稳定提升趋势。这一现象清晰反映：1)DID 策略通过增量式字典学习能持续优化特征表示；2) 该策略对提升检测性能具有显著促进作用。更重要的是，这种性能提升在不同数据集上表现出一致性，验证了 DID 策略能够为高光谱异常检测任务提供一个既可靠又有效的解决方案框架。

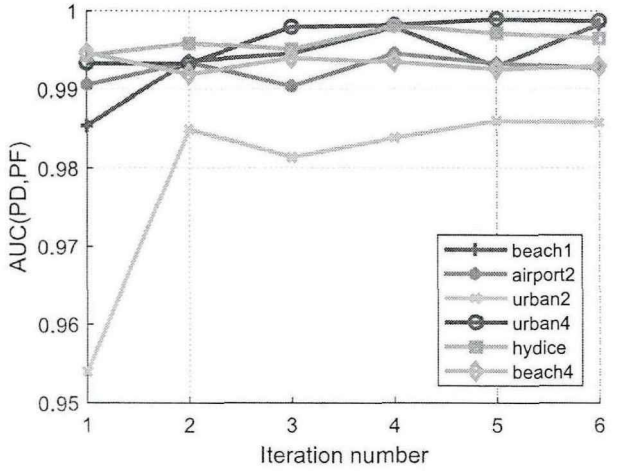

图 6.18 字典原子更新的有效性验证

Fig. 6.18 Validation of the effectiveness of updated dictionary atoms

中国知网 https://www.cnki.net

表 6.4 Los Angele-II 数据上不同方法的 AUC 值
Tab. 6.4 AUC Values of Different Methods on Los Angele-II

AUC	RXD	OSP-GoDec	PCA-TLRSR	AHMID	PTA	IFEBP	RhyDe	SSIIFE	RGAE	UADNet	GAED	DIMSJD
(P_D,P_F)	0.9863	0.9760	0.9865	0.9844	0.9937	0.9372	0.8510	0.9863	0.9289	0.9889	0.8537	**0.9963**
(P_D,τ)	0.0875	0.2544	0.1544	0.0592	0.1303	0.0501	0.0512	0.0875	0.0381	**0.4098**	0.0344	0.4070
(P_F,τ)	0.0111	0.0158	0.0237	0.0052	0.0159	0.0078	0.0061	0.0111	**0.0050**	0.0183	**0.0050**	0.0085
SNPR	7.8888	16.0828	6.5230	11.3083	8.1978	6.4260	8.4377	7.8888	7.5579	22.4023	6.8376	**47.6404**

表 6.5 HYD-U 数据上不同方法的 AUC 值
Tab. 6.5 AUC Values of Different Methods on HYD-U

AUC	RXD	OSP-GoDec	PCA-TLRSR	AHMID	PTA	IFEBP	RhyDe	SSIIFE	RGAE	UADNet	GAED	DIMSJD
(P_D,P_F)	0.9913	0.9948	0.9912	0.9783	0.9515	0.9947	0.9456	0.9864	0.7663	0.9881	0.9839	**0.9987**
(P_D,τ)	0.5067	**0.6110**	0.5848	0.3290	0.5393	0.3943	0.3162	0.2507	0.1945	0.5162	0.2376	0.3855
(P_F,τ)	0.0134	0.0301	0.1186	0.0122	0.1920	0.0365	**0.0073**	0.0360	0.0966	0.0194	0.0143	0.0128
SNPR	37.9412	20.2826	4.9325	26.9160	2.8087	10.7997	**43.2722**	6.9631	2.0139	26.6641	16.6412	30.1224

6.4.4 收敛分析

本小节引入相对误差 (Relative，RE) 作为评估指标，通过图6.19所绘制的收敛曲线对算法的经验收敛性进行系统分析。RE 在第 k 次迭代时的计算公式如下：

$$\mathrm{RE} = \frac{\left\|\mathbf{Y} - \mathbf{D}^{k+1} * \mathbf{B}^{k+1} - \mathbf{T}^{k+1} * \mathbf{A}^{k+1} - \mathbf{N}^{k+1}\right\|_F}{\|\mathbf{Y}\|_F} \tag{6.32}$$

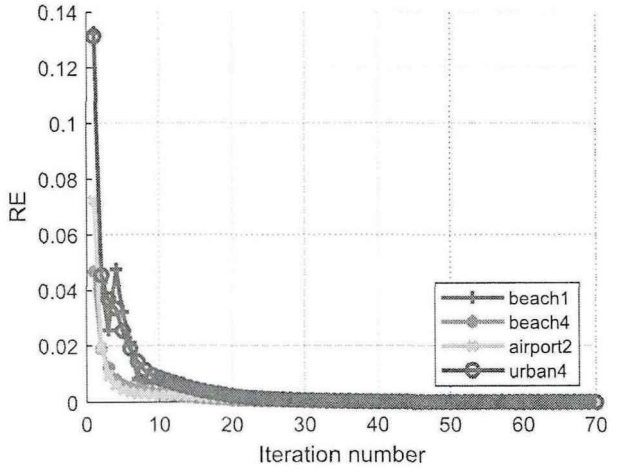

图 6.19 相对误差与迭代次数
Fig. 6.19 Relative errors versus iterations

中国知网 https://www.cnki.net

表 6.6 Pavia 数据上不同方法的 AUC 值
Tab. 6.6 AUC Values of Different Methods on Pavia

AUC	RXD	OSP-GoDec	PCA-TLRSR	AHMID	PTA	IFEBP	RhyDe	SSIIFE	RGAE	UADNet	GAED	DIMSJD
(P_D,P_F)	0.9513	0.9606	0.9587	0.8710	0.9831	0.9422	0.9205	0.8283	0.9118	0.7903	0.9286	**0.9959**
(P_D,τ)	0.1289	0.2270	0.2814	0.0964	0.3208	0.1733	0.0827	0.1424	0.1490	0.0615	0.0833	**0.4018**
(P_F,τ)	0.0232	0.0123	0.0667	0.0077	0.0179	0.0237	0.0061	0.0063	0.0263	**0.0056**	0.0089	0.0073
SNPR	5.5540	18.14331	4.2180	12.5800	17.9113	7.3135	13.5300	22.7300	5.6610	10.9392	9.4103	**55.0011**

图 6.19 清晰展示了 RE 值随着迭代次数增加的动态变化趋势。可以看到，当迭代次数达到 20 次时，所有数据的 RE 值均呈现稳定下降趋势，并逐渐收敛至接近零的领域范围内。这一现象验证了所提算法具有良好的收敛特性。

6.5 本章小结

本章针对高光谱异常检测任务中存在的背景和异常字典表征能力不足，以及异常特征对背景字典构建产生干扰等关键问题，提出了一种基于判别性增量多尺度联合字典的高光谱异常检测方法。该方法通过以下设计实现了性能突破：首先，通过构建多尺度背景字典，有效缓解了传统基于表示的异常检测方法中异常特征对背景建模造成的污染问题。多尺度设计使得背景字典能够更好地适应不同尺寸的异常目标，同时保持对背景特征的准确建模。其次，提出的基于波段组一致性和判别性增量优化策略，成功克服了实际应用中缺乏异常目标先验知识的限制。该策略通过充分利用不同波段间的互补信息，实现了在无监督条件喜爱的有效异常检测。在模型构建方面，DIMSJD 利用背景和异常字典原子定义的结构先验约束，显著增强了模型对背景和异常成分的分离能力。这种约束确保了字典能够更好地表征各自对应的特征空间。最后，通过引入深度聚类网络，DIMSJD 进一步强化了模型的鲁棒性。该网络能够有效消除残留的背景干扰，从而获得更纯净的异常检测结果。

在多组数据上的实验结果表明，与同样考虑了抗噪声干扰的 RhyDe 和 AHMID 相比，DIMSJD 在弱目标场景中依旧保持出色的检测性能，这充分证明了该方法能够有效区分异常目标和噪声干扰，在抑制噪声的同时有效保持感兴趣的异常目标。此外，与同样基于数据分解的 PTA 和 PCA-TLRSR 的相比，DIMSJD 展现出了更具竞争力的背景和异常的分离效果。总的来说，DIMSJD 通过上述设计，显著提高了异常目标检测的精度，在具有不同形状和尺寸异常目标的多样化场景中均表现出优异的检测性能。

中国知网 https://www.cnki.net

7 结论与展望

7.1 结论

本文针对总变分模型服务于不同高光谱图像处理时所面临的关键问题：一是如何构建适应像素强度变化的变分模型，以提高复原算法的细节保持能力；二是如何抑制去噪中的过度平滑效应，以提高去噪算法的局部结构与全局一致性；三是如何设计可同时保持异常信号且抑制冗余、噪声干扰的正则模型，以增强检测算法精度；围绕图像细节保持和任务导向，以提升高光谱遥感数据下游任务性能为目的，开展了基于正则化变分模型的高光谱图像复原和异常检测研究，并在多个公开数据集上进行充分实验，结果表明所提方法在定性和定量评价上具有显著优势。具体从四个方面进行了深入探讨，主要研究内容与结论包括：

(1) 基于局部极值约束总变分模型的高光谱图像去模糊算法。该方法以模糊图像暗通道先验为基础，通过深入分析模糊退化过程中像素间的相互作用，设计了自适应约束项，实现了图像纹理结构的像素级精细刻画。结合总变分正则化，进一步提出了基于模糊图像暗通道先验的局部极值约束总变分正则化模型。此外，基于所定义的自适应约束，构建了参数 λ 的自适应调整方式，实现了不同光谱波段权重的动态优化。在此基础上，提出了基于局部极值约束总变分模型的高光谱图像非盲去模糊方法。在多组自然图像、多光谱图像和高光谱图像数据上实验结果表明，所提方法能够有效避免精细纹理细节丢失和光谱失真现象，实现精确且稳定的复原效果。更重要的是，复原后的图像在后续数据分析任务中表现出显著的性能提升，验证了该方法在实际应用中的有效性与广泛适用性。

(2) 基于全局变分和局部结构低秩稀疏模型的高光谱图像去噪算法。该方法以高光谱数据的空间和光谱相关性为基础，通过定义局部结构低秩正则项，有效捕捉图像中的关键局部特征。同时引入相关总变分约束，构建融合全局变分和局部结构低秩稀疏模型的去噪模型，从而在去除噪声的同时，实现对数据内在结构的精确刻画。在多组模拟和真实高光谱图像数据上的实验结果表明，所提方法在多种噪声环境下均表现出良好的去噪性能与较强的鲁棒性。更重要的是，复原后的图像在后续的数据分析任务中显著提升了处理精度，验证了该方法在实际应用中的有效性与实用性。

(3) 基于反馈式波段组群和变分低秩稀疏模型的高光谱异常目标检测算法。该方法通过联合相关总变分和 $L_{2,1}$ 范数，实现背景与异常成分的有效分离。此外，提出基于波段组分解的异常目标检测方法，有效减少波段间的冗余信息并降低计算量。在此基础上，提出基于反馈式波段组群的异常检测算法，通过充分利用波段组之间的一致性和互补性，强化数据中潜在异常要素的表达能力。该算法避免了因波段选择导致的特征丢失问题。在多个高光谱数据集上的实验结果表明，所提方法能够有效抑制噪声和背景干扰，在复杂背景下仍能保持良好的检测性能，显著提升了异常检测的精度与稳定性。

(4) 基于结构先验与变分约束的判别性增量多尺度联合字典高光谱异常检测算法。

中国知网 https://www.cnki.net

针对不同场景中异常目标呈现出的不同尺度特性，本文构建了一种多尺度背景字典。通过在不同尺度下对数据进行降采样，有效抑制了异常特征对背景字典学习过程的干扰，提升了背景建模的鲁棒性。在此基础上，在表示模型中引入相关总变分约束与 $L_{2,1}$ 范数，以实现噪声抑制和结构保持的协同优化。同时，根据检测样本与字典原子之间的光谱相关性，设计了结构先验矩阵，进一步增强了模型对背景与异常成分的分离能力。为进一步提升检测精度，引入深度聚类网络对残差进行后处理，剔除其中的非异常成分，从而获得更加纯净和可靠的异常检测结果。在初步检测结果的基础上，提出判别性背景与异常增量字典更新策略。该策略利用检测样本与已有字典原子的相关性，动态添加具有代表性的背景和潜在异常原子，逐步构建具有高表征能力且低冗余的字典集合，从而有效避免异常信号在数据分解过程中被削弱。在多组高光谱数据上的实验结果表明，所提出方法能够有效抵抗非异常特征的干扰，在多种复杂背景下均表现出优异的检测性能，具有良好的实用价值。

上述研究围绕高光谱图像在获取过程中所受模糊与噪声干扰问题，针对现有方法在刻画数据底层结构特征以及匹配下游数据分析任务需求方面存在的不足，聚焦于高光谱图像复原与异常检测中的核心挑战，从退化机制分析、复原目标设定到任务需求导向等多个层面展开研究。研究内容从像素级处理出发，逐步拓展至结构块层次建模与波段组协同分析，构建了一个层次递进、任务驱动的技术体系。其中，研究内容一(第三章) 和研究内容二 (第四章) 主要致力于提升高光谱图像的质量与光谱信息的可靠性，为后续数据分析提供高质量的数据基础。研究内容三 (第五章) 提出了基于反馈式波段组群和变分低秩稀疏模型的高光谱异常目标检测算法，在抑制非期望噪声和背景干扰的同时，增强了潜在异常信号的表达能力，从而实现了较好的检测性能。研究内容四 (第六章) 则在其基础上引入多尺度背景建模策略，有效抑制异常目标对背景重建的干扰，提升了背景成分与异常成分之间的分离精度，从而显著改善了异常检测的整体性能。

整体而言，本研究通过多层次建模与任务引导相结合的方式，实现了高光谱图像从质量提升到智能分析的一体化处理框架，为复杂环境下高光谱数据的有效利用提供了理论支持与技术保障。

7.2 展望

尽管本文对变分模型在高光谱图像去模糊、去噪及异常检测中的应用进行了较为深入的分析与研究，并取得了一定的阶段性成果，但仍存在若干问题有待进一步探索与深入研究：

(1) 尽管本文所提出的模型在多个公开高光谱数据集上取得了良好的实验结果，但其在更复杂或动态变化环境下的泛化能力仍有待进一步验证。目前的实验主要基于现有公开数据集开展，尚未全面涵盖不同传感器成像机制以及复杂自然场景中的多样性特征，因而在实际应用中仍存在一定局限。未来的研究将重点围绕模型的跨传感器迁移能力和对复杂场景的适应性展开。计划引入具有不同光谱响应特性与成像条件的

中国知网 https://www.cnki.net

典型高光谱数据集，开展跨域迁移与鲁棒性评估实验，以系统评估模型在不同成像平台和环境条件下的实用性与推广潜力。同时，也将进一步考察模型在面对不同空间分辨率、噪声水平变化等现实干扰因素时的性能稳定性，探索其在多种实际约束条件下的适应能力，从而推动模型由理论研究向真实场景中工程化部署的有效转化。

(2) 当前研究中，模型参数主要依赖于交叉验证或人工调参等经验性手段进行设定，虽在实验层面取得了较好的复原与检测性能，但在实际应用中仍存在较大局限。一方面，参数选择过程耗时费力，缺乏通用性和可迁移性；另一方面，固定权重难以适应不同场景、不同数据分布下的任务需求，限制了模型的泛化能力与鲁棒性。因此，未来将重点探索引入自适应正则项权重学习机制，以提升模型的自动化程度和智能化水平。具体而言，可结合贝叶斯优化方法实现高效参数搜索空间建模；借助神经网络构建端到端的超参数预测模块，使模型能够根据输入数据动态调整正则项权重；进一步地，还可融合元学习策略，使模型具备对新任务快速适应的能力，从而实现从“经验驱动”向“数据驱动”乃至“任务驱动”的转变。该研究方向不仅有助于减少对人工调参的依赖，还将推动高光谱图像处理模型向更智能、更实用的方向发展，为复杂环境下遥感数据的自主解析提供有力支撑。

中国知网 https://www.cnki.net

参 考 文 献

[1] BIOUCAS-DIAS J M, PLAZA A, DOBIGEON N, et al. Hyperspectral unmixing overview: Geometrical, statistical, and sparse regression-based approaches[J/OL]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2012, 5(2): 354-379.

[2] 童庆禧, 孟庆岩, 杨杭. 遥感技术发展历程与未来展望[J]. 城市与减灾, 2018(06): 2-11.

[3] 张兵. 高光谱图像处理与信息提取前沿[J]. 遥感学报, 2016, 20(05): 1062-1090.

[4] 钟燕飞, 王心宇, 胡鑫, 等. 高光谱高空间分辨率遥感观测、处理与应用[J]. 测绘学报, 2023, 52(07): 1212-1226.

[5] CHANG C I, et al. Real-time progressive hyperspectral image processing[J]. Cham, Switzerland: Springer, 2016.

[6] 董月群, 冒建华, 梁丹, 等. 城市河道无人机高光谱水质监测与应用[J]. 环境科学与技术, 2021, 44(S1): 289-296.

[7] 杨丽丽, 王振鹏, 吴才聪. 基于多源数据的新疆棉田螨害大范围监测研究[J]. 光谱学与光谱分析, 2021, 41(12): 3949-3956.

[8] ZHUANG L, GAO L, ZHANG B, et al. Hyperspectral image denoising and anomaly detection based on low-rank and sparse representations[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-17.

[9] ZHANG Q, ZHENG Y, YUAN Q, et al. Hyperspectral image denoising: From model-driven, data-driven, to model-data-driven[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024, 35(10): 13143-13163.

[10] ZHANG Y, XIANG Y, BAI L. Generative adversarial network for deblurring of remote sensing image[C]//2018 26th International Conference on Geoinformatics. IEEE, 2018: 1-4.

[11] WANG X, CHEN J, RICHARD C, et al. Learning spectral-spatial prior via 3DDNCNN for hyperspectral image deconvolution[C]//ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2020: 2403-2407.

[12] DESHPANDE A M, ROY S. An efficient image deblurring method with a deep convolutional neural network for satellite imagery[J]. Journal of the Indian Society of Remote Sensing, 2021, 49(11): 2903-2917.

[13] 苏乐辉. 深度学习下模糊高光谱图像复原数学模型仿真[J]. 计算机仿真, 2023, 40(09): 167-170+302.

[14] WANG X, CHEN J, RICHARD C. Tuning-free plug-and-play hyperspectral image deconvolution with deep priors[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-13.

[15] GENG L, NIE X, NIU S, et al. Structural compact core tensor dictionary learning for multispec-tral remote sensing image deblurring[C]//2018 25th IEEE International Conference on Image Processing (ICIP). 2018: 2865-2869.

[16] CHANG Y, YAN L, ZHAO X L, et al. Weighted low-rank tensor recovery for hyperspectral image restoration[J]. IEEE Transactions on Cybernetics, 2020, 50(11): 4558-4572.

[17] CHANG Y, YAN L, CHEN B, et al. Hyperspectral image restoration: Where does the low-rank

中国知网 https://www.cnki.net

property exist[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(8): 6869-6884.

[18] GUO L, ZHAO X L, GU X M, et al. Three-dimensional fractional total variation regularized tensor optimized model for image deblurring[J]. Applied Mathematics and Computation, 2021, 404: 126224.

[19] LIAO Z, ZHANG W, CHU Q, et al. Multispectral remote sensing image deblurring using auxiliary band gradient information[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-18.

[20] HAO J, XUE J, ZHAO Y, et al. Transformed structured sparsity with smoothness for hyperspectral image deblurring[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5.

[21] ZHAO X L, WANG F, HUANG T Z, et al. Deblurring and sparse unmixing for hyperspectral images [J]. IEEE Transactions on Geoscience and Remote Sensing, 2013, 51(7): 4045-4058.

[22] CHANG Y, FANG H, YAN L, et al. Joint blind deblurring and destriping for remote sensing images [C]//2013 IEEE International Conference on Image Processing. 2013: 469-473.

[23] FANG H, LUO C, ZHOU G, et al. Hyperspectral image deconvolution with a spectral-spatial total variation regularization[J]. Canadian Journal of Remote Sensing., 2017, 43(4): 384-395.

[24] CHEN Y, HE W, ZHAO X L, et al. Exploring nonlocal group sparsity under transform learning for hyperspectral image denoising[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-18.

[25] XIONG F, ZHOU J, TAO S, et al. SMDS-Net: Model guided spectral-spatial network for hyperspectral image denoising[J]. IEEE Transactions on Image Processing, 2022, 31: 5469-5483.

[26] CAO X, FU X, XU C, et al. Deep spatial-spectral global reasoning network for hyperspectral image denoising[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.

[27] WANG M, HE W, ZHANG H. A spatial–spectral transformer network with total variation loss for hyperspectral image denoising[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5.

[28] ZHANG Q, DONG Y, YUAN Q, et al. Combined deep priors with low-rank tensor factorization for hyperspectral image restoration[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5.

[29] YE J, XIONG F, ZHOU J, et al. Iterative low-rank network for hyperspectral image denoising[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-15.

[30] MAFFEI A, HAUT J M, PAOLETTI M E, et al. A single model CNN for hyperspectral image denoising[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(4): 2516-2529.

[31] XIONG F, ZHOU J, ZHOU J, et al. Multitask sparse representation model-inspired network for hyperspectral image denoising[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-15.

[32] LIU W, YOU J, LEE J. A classification-aware HSI denoising model with neural adversarial network [J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.

[33] 郑佳慧, 俞晓迪, 赵生妹, 等. 基于均值滤波的关联成像去噪[J]. 光学学报, 2022, 42(22): 49-56.

[34] 任松涛. 基于双边滤波的船舶图像混合域去噪方法[J]. 舰船科学技术, 2023, 45(14): 148-151.

[35] SHAO L, YAN R, LI X, et al. From heuristic optimization to dictionary learning: A review and

中国知网 https://www.cnki.net

comprehensive comparison of image denoising algorithms[J]. IEEE Transactions on Cybernetics, 2014, 44(7): 1001-1013.

[36] DABOV K, FOI A, KATKOVNIK V, et al. Image denoising by sparse 3-D transform-domain collaborative filtering[J]. IEEE Transactions on Image Processing, 2007, 16(8): 2080-2095.

[37] TUN M T, SUGIURA Y, SHIMAMURA T. Joint training of noisy image patch and impulse response of low-pass filter in cnn for image denoising[J]. Journal of Signal Processing, 2024, 28(1): 1-17.

[38] DIWAKAR M, SINGH P, GARG D. Edge-guided filtering based ct image denoising using fractional order total variation[J]. Biomedical Signal Processing and Control, 2024, 92: 106072.

[39] EFROS A, LEUNG T. Texture synthesis by non-parametric sampling[C]//Proceedings of the Seventh IEEE International Conference on Computer Vision: Vol. 2. 1999: 1033-1038.

[40] MAGGIONI M, KATKOVNIK V, EGIAZARIAN K, et al. Nonlocal transform-domain filter for volumetric data denoising and reconstruction[J]. IEEE Transactions on Image Processing, 2013, 22 (1): 119-133.

[41] YE M, QIAN Y, ZHOU J. Multitask sparse nonnegative matrix factorization for joint spectral–spatial hyperspectral imagery denoising[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 53(5): 2621-2639.

[42] CHANG C I, DU Q. Interference and noise-adjusted principal components analysis[J]. IEEE Transactions on Geoscience and Remote Sensing, 1999, 37(5): 2387-2396.

[43] PENG Y, SUO J, DAI Q, et al. Reweighted low-rank matrix recovery and its application in image restoration[J]. IEEE Transactions on Cybernetics, 2014, 44(12): 2418-2430.

[44] HE W, ZHANG H, ZHANG L, et al. Hyperspectral image denoising via noise-adjusted iterative low-rank matrix approximation[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2015, 8(6): 3050-3061.

[45] XIE Q, ZHAO Q, MENG D, et al. Multispectral images denoising by intrinsic tensor sparsity regularization[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 1692-1700.

[46] XUE J, ZHAO Y, LIAO W, et al. Nonlocal low-rank regularized tensor decomposition for hyperspectral image denoising[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(7): 5174-5189.

[47] ZHANG H, LIU L, HE W, et al. Hyperspectral image denoising with total variation regularization and nonlocal low-rank tensor decomposition[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(5): 3071-3084.

[48] HE W, YAO Q, LI C, et al. Non-local meets global: An iterative paradigm for hyperspectral image restoration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(4): 2089-2107.

[49] CHEN Y, HUANG T Z, HE W, et al. Hyperspectral image denoising using factor group sparsity-regularized nonconvex low-rank approximation[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-16.

[50] LIU Y Y, ZHAO X L, ZHENG Y B, et al. Hyperspectral image restoration by tensor fibered rank

中国知网 https://www.cnki.net

constrained optimization and plug-and-play regularization[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-17.

[51] WANG M, WANG Q, CHANUSSOT J, et al. Hyperspectral image mixed noise removal based on multidirectional low-rank modeling and spatial−spectral total variation[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(1): 488-507.

[52] CHEN Y, HE W, YOKOYA N, et al. Nonlocal tensor-ring decomposition for hyperspectral image denoising[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(2): 1348-1362.

[53] XIONG F, ZHOU J, QIAN Y. Hyperspectral restoration via l_0 gradient regularized low-rank tensor factorization[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(12): 10410-10425.

[54] YUAN Q, ZHANG L, SHEN H. Hyperspectral image denoising employing a spectral − spatial adaptive total variation model[J]. IEEE Transactions on Geoscience and Remote Sensing, 2012, 50 (10): 3660-3677.

[55] JIANG C, ZHANG H, ZHANG L, et al. Hyperspectral image denoising with a combined spatial and spectral weighted hyperspectral total variation model[J]. Canadian Journal of Remote Sensing, 2016, 42(1): 53-72.

[56] PENG J, XIE Q, ZHAO Q, et al. Enhanced 3DTV regularization and its applications on HSI denoising and compressed sensing[J]. IEEE Transactions on Image Processing, 2020, 29: 7889-7903.

[57] CHEN Y, CAO W, PANG L, et al. Hyperspectral image denoising via texture-preserved total variation regularizer[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-14.

[58] XU S, KE Q, PENG J, et al. Pan-denoising: Guided hyperspectral image denoising via weighted represent coefficient total variation[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-14.

[59] HE W, ZHANG H, SHEN H, et al. Hyperspectral image denoising using local low-rank matrix recovery and global spatial-spectral total variation[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2018, 11(3): 713-729.

[60] WANG Q, WU Z, JIN J, et al. Low rank constraint and spatial spectral total variation for hyperspectral image mixed denoising[J]. Signal Processing, 2018, 142: 11-26.

[61] WANGMINGHUA M, WANG Q, CHANUSSOT J. Tensor low-rank constraint and l_0 total variation for hyperspectral image mixed noise removal[J]. IEEE Journal of Selected Topics in Signal Processing, 2021, 15(3): 718-733.

[62] CHANG Y, YAN L, FANG H, et al. Simultaneous destriping and denoising for remote sensing images with unidirectional total variation and sparse representation[J]. IEEE Geoscience and Remote Sensing Letters, 2014, 11(6): 1051-1055.

[63] PENG J, WANG Y, ZHANG H, et al. Exact decomposition of joint low rankness and local smoothness plus sparse matrices[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(5): 5766-5781.

[64] YANG F, HU Q, SU X. Hyperspectral image denoising based on hyper-laplacian total variation in spectral gradient domain[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025, 63:

中国知网 https://www.cnki.net

1-17.

[65] RUDIN L. Nonlinear total variation based noise removal algorithms[J]. Physica D., 1992, 60(1): 259-268.

[66] QU Y, WANG W, GUO R, et al. Hyperspectral anomaly detection through spectral unmixing and dictionary-based low-rank decomposition[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(8): 4391-4405.

[67] 屈博, 郑向涛, 钱学明, 等. 高光谱遥感影像异常目标检测研究进展[J]. 遥感学报, 2024, 28(1): 42-54.

[68] REED I, YU X. Adaptive multiple-band CFAR detection of an optical pattern with unknown spectral distribution[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1990, 38(10): 1760-1770.

[69] KWON H, NASRABADI N M. Hyperspectral anomaly detection using kernel rx-algorithm[C]// 2004 International Conference on Image Processing, 2004. ICIP'04.: Vol. 5. IEEE, 2004: 3331-3334.

[70] MOLERO J M, GARZóN E M, GARCíA I, et al. Analysis and optimizations of global and local versions of the rx algorithm for anomaly detection in hyperspectral data[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2013, 6(2): 801-814.

[71] SCHAUM A. Joint subspace detection of hyperspectral targets[C]//2004 IEEE Aerospace Conference Proceedings (IEEE Cat. No.04TH8720): Vol. 3. 2004: 1824.

[72] CHANG C I, CHIANG S S. Anomaly detection and classification for hyperspectral imagery[J]. IEEE Transactions on Geoscience and Remote Sensing, 2002, 40(6): 1314-1325.

[73] LIAN J, WANG L, SUN H, et al. GT-HAD: Gated transformer for hyperspectral anomaly detection [J]. IEEE Transactions on Neural Networks and Learning Systems, 2025, 36(2): 3631-3645.

[74] YOUNG S S, LIN C H, LENG Z C. Unsupervised abundance matrix reconstruction transformer-guided fractional attention mechanism for hyperspectral anomaly detection[J/OL]. IEEE Transactions on Neural Networks and Learning Systems, 2025, 36(5): 9150-9164.

[75] WANG R, HU J. Gaussian-inspired attention mechanism for hyperspectral anomaly detection[J]. IEEE Geoscience and Remote Sensing Letters, 2025, 22: 1-5.

[76] WANG S, WANG X, ZHANG L, et al. Auto-ad: Autonomous hyperspectral anomaly detection network based on fully convolutional autoencoder[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.

[77] WU Z, PAOLETTI M E, SU H, et al. SMCNet: Sparse-inspired masked convolutional network for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-17.

[78] MA Z, ZHANG Y, LIAN Y, et al. Multiscale memory autoencoder and spatial filtering for hyperspectral anomaly detection[J]. IEEE Geoscience and Remote Sensing Letters, 2025, 22: 1-5.

[79] HE Z, HE D, XIAO M, et al. Convolutional transformer-inspired autoencoder for hyperspectral anomaly detection[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5.

[80] ZHONG J, XIE W, LI Y, et al. Characterization of background-anomaly separability with generative

中国知网 https://www.cnki.net

adversarial network for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(7): 6017-6028.

[81] JIANG T, XIE W, LI Y, et al. Weakly supervised discriminative learning with spectral constrained generative adversarial network for hyperspectral anomaly detection[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(11): 6504-6517.

[82] WANG J, GUO S, HUA Z, et al. CL-CaGAN: Capsule differential adversarial continual learning for cross-domain hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-15.

[83] ZHANG L, CHENG B. Fractional fourier transform and transferred cnn based on tensor for hyperspectral anomaly detection[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.

[84] 贾森, 刘宽, 徐萌, 等. 基于空谱多路自编码器的高光谱图像异常检测[J]. 遥感学报, 2024, 28(1): 55-68.

[85] LI C, ZHANG B, HONG D, et al. LRR-Net: An interpretable deep unfolding network for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-12.

[86] LI C, ZHANG B, HONG D, et al. Interpretable networks for hyperspectral anomaly detection: A deep unfolding solution[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-14.

[87] ZHAO C, LI C, FENG S, et al. A spectral－spatial anomaly target detection method based on fractional fourier transform and saliency weighted collaborative representation for hyperspectral images[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 13: 5982-5997.

[88] MA Y, FAN G, JIN Q, et al. Hyperspectral anomaly detection via integration of feature extraction and background purification[J]. IEEE Geoscience and Remote Sensing Letters, 2021, 18(8): 1436-1440.

[89] WANG M, HONG D, ZHANG B, et al. Learning double subspace representation for joint hyperspectral anomaly detection and noise removal[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-17.

[90] FENG R, LI H, WANG L, et al. Local spatial constraint and total variation for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-16.

[91] 孙菲, 厉小润, 赵辽英, 等. 基于 FrFT 变换和全变分正则化的异常检测算法[J]. 浙江大学学报: 工学版, 2022, 56(7): 1276-1284.

[92] FENG M, CHEN W, YANG Y, et al. Hyperspectral anomaly detection based on tensor ring decomposition with factors tv regularization[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-14.

[93] WANG M, GAO L, REN L, et al. Hyperspectral simultaneous anomaly detection and denoising: Insights from integrative perspective[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 13966-13980.

[94] BLOMGREN P, CHAN T. Color TV: total variation methods for restoration of vector-valued images [J]. IEEE Transactions on Image Processing, 1998, 7(3): 304-309.

中国知网 https://www.cnki.net

[95] CHENG Q, SHEN H, ZHANG L, et al. Inpainting for remotely sensed images with a multichannel nonlocal total variation model[J]. IEEE Transactions on Geoscience and Remote Sensing, 2014, 52 (1): 175-187.

[96] LI Y, SANTOSA F. A computational algorithm for minimizing total variation in image restoration [J]. IEEE Transactions on Image Processing, 1996, 5(6): 987-995.

[97] XU L, ZHENG S, JIA J. Unnatural l_0 sparse representation for natural image deblurring[C]//2013 IEEE Conference on Computer Vision and Pattern Recognition. 2013: 1107-1114.

[98] WANG M, WANG Q, CHANUSSOT J. Tensor low-rank constraint and l_0 total variation for hyperspectral image mixed noise removal[J]. IEEE Journal of Selected Topics in Signal Processing, 2021, 15(3): 718-733.

[99] CHANG Y, YAN L, FANG H, et al. Anisotropic spectral-spatial total variation model for multispectral remote sensing image destriping[J]. IEEE Transactions on Image Processing, 2015, 24(6): 1852-1866.

[100] LEFKIMMIATIS S, ROUSSOS A, MARAGOS P, et al. Structure tensor total variation[J]. SIAM Journal on Imaging Sciences, 2015, 8(2): 1090-1122.

[101] CANDÈS E J, LI X, MA Y, et al. Robust principal component analysis?[J]. Journal of the ACM (JACM), 2011, 58(3): 1-37.

[102] CHEN S Y, YANG S, KALPAKIS K, et al. Low-rank decomposition-based anomaly detection[C]// Algorithms and Technologies for Multispectral, Hyperspectral, and Ultraspectral Imagery XIX: Vol. 8743. SPIE, 2013: 171-177.

[103] ZHOU T, TAO D. Godec: Randomized low-rank & sparse matrix decomposition in noisy case[C]// Proceedings of the 28th International Conference on Machine Learning, ICML 2011. 2011.

[104] ZHANG Y, DU B, ZHANG L, et al. A low-rank and sparse matrix decomposition-based mahalanobis distance method for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(3): 1376-1389.

[105] LIU G, LIN Z, YAN S, et al. Robust recovery of subspace structures by low-rank representation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(1): 171-184.

[106] LIU G, LIN Z, YU Y. Robust subspace segmentation by low-rank representation[C]//Proceedings of the 27th international conference on machine learning (ICML-10). 2010: 663-670.

[107] XU Y, WU Z, LI J, et al. Anomaly detection in hyperspectral images based on low-rank and sparse representation[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(4): 1990-2000.

[108] CHANG C I. An effective evaluation tool for hyperspectral target detection: 3D receiver operating characteristic curve analysis[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59 (6): 5131-5153.

[109] LIM H, YU S, PARK K, et al. Texture-aware deblurring for remote sensing images using ℓ_0-based deblurring and ℓ_2-based fusion[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 13: 3094-3108.

[110] CAO S, TAN W, XING K, et al. Dark channel inspired deblurring method for remote sensing image [J]. Journal of Applied Remote Sensing, 2018, 12(1): 015012-015012.

中国知网 https://www.cnki.net

[111] HE K, JIAN S, TANG X. Single image haze removal using dark channel prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33(12): 2341-2353.

[112] ALONA, GOLTS, DANIEL, et al. Unsupervised single image dehazing using dark channel prior loss[J]. IEEE Transactions on Image Processing, 2020, 29: 2692-2702.

[113] LI C, QUO J, PANG Y, et al. Single underwater image restoration by blue-green channels dehazing and red channel correction[C]//Proceedings of the IIEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2016: 1731-1735.

[114] PAN J, SUN D, PFISTER H, et al. Deblurring images via dark channel prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(10): 2315-2328.

[115] YAN Y, REN W, GUO Y, et al. Image deblurring via extreme channels prior[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 6978-6986.

[116] GE X, TAN J, ZHANG L. Blind image deblurring using a non-linear channel prior based on dark and bright channels[J]. IEEE Transactions on Image Processing, 2021, 30: 6970-6984.

[117] RAMESHAN R M, CHAUDHURI S, VELMURUGAN R. High dynamic range imaging under noisy observations[C]//Proceedings of the IEEE International Conference on Image Processing (ICIP). 2011: 1333-1336.

[118] OLIVEIRA J P, BIOUCAS-DIAS J M, FIGUEIREDO M A T. Adaptive total variation image deblurring: A majorization–minimization approach[J]. Signal Process., 2009, 89(9): 1683-1693.

[119] SCHMIDT U, ROTH S. Shrinkage fields for effective image restoration[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2014: 2774-2781.

[120] WANG N, SHI W, FAN C, et al. An improved nonlocal sparse regularization-based image deblurring via novel similarity criteria[J]. International Journal of Advanced Robotic Systems, 2018, 15(3).

[121] REN W, ZHANG J, MA L, et al. Deep non-blind deconvolution via generalized low-rank approximation[J]. Proceedings of the Annual Conference on Neural Information Processing Systems (NeurIPS), 2018, 31: 295-305.

[122] WANG P, WANG Y, HUANG B, et al. Poissonian blurred hyperspectral imagery denoising based on variable splitting and penalty technique[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-14.

[123] KRISHNAN D, FERGUS R. Fast image deconvolution using hyper-laplacian priors[J]. Advances in neural information processing systems, 2009, 22.

[124] REN D, ZHANG H, ZHANG D, et al. Fast total-variation based image restoration based on derivative alternated direction optimization methods[J]. Neurocomputing, 2015, 170: 201-212.

[125] DONG W, LEI Z, SHI G. Nonlocally centralized sparse representation for image restoration[J]. IEEE Transactions on Image Processing, 2013, 22(4).

[126] ZHANG J, PAN J, LAI W S, et al. Learning fully convolutional networks for iterative non-blind deconvolution[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 6969-6977.

[127] REN D, ZHANG K, WANG Q, et al. Neural blind deconvolution using deep priors[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 3338-3347.

中国知网 https://www.cnki.net

[128] ZAMIR S W, ARORA A, KHAN S, et al. Multi-stage progressive image restoration[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 14821-14831.

[129] EBOLI T, MOREL J M, FACCIOLO G. Fast two-step blind optical aberration correction[C]//Proc. Eur. Conf. Comput. Vis. (ECCV). Springer, 2022: 693-708.

[130] ZHANG Z, CHENG Y, SUO J, et al. INFWIDE: Image and feature space wiener deconvolution network for non-blind image deblurring in low-light conditions[J]. IEEE Transactions on Image Processing, 2023, 32: 1390-1402.

[131] HENROT S, SOUSSEN C, BRIE D. Fast positive deconvolution of hyperspectral images[J]. IEEE Transactions on Image Processing, 2013, 22(2): 828-833.

[132] CHEN L, FANG F, WANG T, et al. Blind image deblurring with local maximum gradient prior[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 1742-1750.

[133] PAN J, SUN D, PFISTER H, et al. Blind image deblurring using dark channel prior[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 1628-1636.

[134] DONOHO D L. De-noising by soft-thresholding[J]. IEEE transactions on information theory, 1995, 41(3): 613-627.

[135] ZHANG H, CAI J, HE W, et al. Double low-rank matrix decomposition for hyperspectral image denoising and destriping[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-19.

[136] HE W, ZHANG H, ZHANG L, et al. Total-variation-regularized low-rank matrix factorization for hyperspectral image restoration[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(1): 178-188.

[137] PENG Y, MENG D, XU Z, et al. Decomposable nonlocal tensor dictionary learning for multispectral image denoising[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition. 2014: 2949-2956.

[138] BIOUCAS-DIAS J M, NASCIMENTO J M. Hyperspectral subspace identification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2008, 46(8): 2435-2445.

[139] CHANG C I, LIN C Y, CHUNG P C, et al. Iterative spectral–spatial hyperspectral anomaly detection [J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-30.

[140] LI Z, ZHANG Y, ZHANG J. Hyperspectral anomaly detection for spectral anomaly targets via spatial and spectral constraints[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-15.

[141] LI Z, ZHANG Y, ZHANG J. Tensor approximation with low-rank representation and kurtosis correlation constraint for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-13.

[142] LI L, SONG M, ZHANG Q, et al. Hyperspectral denoising via global variation and local structure low-rank model[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-13.

[143] XIONG F, ZHOU J, ZHOU J, et al. Multitask sparse representation model-inspired network for

中国知网 https://www.cnki.net

hyperspectral image denoising[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-15.

[144] SHANG X, CUI C, SUN X. Spectral-spatial hypergraph-regularized self-representation for hyperspectral band selection[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5.

[145] WANG M, WANG Q, HONG D, et al. Learning tensor low-rank representation for hyperspectral anomaly detection[J]. IEEE Transactions on Cybernetics, 2023, 53(1): 679-691.

[146] CHANG C I, CAO H, SONG M. Orthogonal subspace projection target detector for hyperspectral anomaly detection[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2021, 14: 4915-4932.

[147] CHANG C I, CAO H, CHEN S, et al. Orthogonal subspace projection-based go-decomposition approach to finding low-rank and sparsity matrices for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(3): 2403-2429.

[148] KUYBEDA O, MALAH D, BARZOHAR M. Rank estimation and redundancy reduction of high-dimensional noisy signals with preservation of rare vectors[J]. IEEE Transactions on Signal Processing, 2007, 55(12): 5579-5592.

[149] CHANG C I. Hyperspectral imaging: techniques for spectral detection and classification: Vol. 1 [M]. Springer Science & Business Media, 2003.

[150] HARSANYI J C, FARRAND W, CHANG C I. Detection of subpixel spectral signatures in hyperspectral image sequences[C]//Annual Meeting, Proceedings of American Society of Photogrammetry & Remote Sensing. 1994: 236-247.

[151] CHANG C I. A review of virtual dimensionality for hyperspectral imagery[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2018, 11(4): 1285-1305.

[152] SAUNDERS M A. Solution of sparse rectangular systems using LSQR and CRAIG[J]. BIT Numerical Mathematics, 1995, 35(4): 588-604.

[153] OTSU N. A threshold selection method from gray-level histograms[J]. IEEE Transactions on Systems, Man, and Cybernetics, 1979, 9(1): 62-66.

[154] CHANG C I, CHEN J. Hyperspectral anomaly detection by data sphering and sparsity density peaks [J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-21.

[155] CHANG C I. Hyperspectral anomaly detection: A dual theory of hyperspectral target detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-20.

[156] GUO T, HE L, LUO F, et al. Anomaly detection of hyperspectral image with hierarchical antinoise mutual-incoherence- induced low-rank representation[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-13.

[157] WANG S, WANG X, ZHANG L, et al. Deep low-rank prior for hyperspectral anomaly detection [J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-17.

[158] HUANG Z, KANG X, LI S, et al. Game theory-based hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(4): 2965-2976.

[159] LIU H, SU X, SHEN X, et al. MSNet: Self-supervised multiscale network with enhanced separation training for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote

中国知网 https://www.cnki.net

Sensing, 2024, 62: 1-13.

[160] LI L, LI W, QU Y, et al. Prior-based tensor approximation for anomaly detection in hyperspectral imagery[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(3): 1037-1050.

[161] SONG X, ARYAL S, TING K M, et al. Spectral–spatial anomaly detection of hyperspectral data based on improved isolation forest[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-16.

[162] LI W, DU Q. Collaborative representation for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 53(3): 1463-1474.

[163] XIANG P, ALI S, JUNG S K, et al. Hyperspectral anomaly detection with guided autoencoder[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-18.

[164] FAN G, MA Y, MEI X, et al. Hyperspectral anomaly detection with robust graph autoencoders[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.

[165] TU B, WANG Z, OUYANG H, et al. Hyperspectral anomaly detection using the spectral–spatial graph[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.

[166] CHANG C I. Effective anomaly space for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-24.

[167] MA X, ZHANG X, HUYAN N, et al. Background representation learning with structural constraint for hyperspectral anomaly detection[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.

[168] 屈博, 郑向涛, 钱学明, 等. 高光谱遥感影像异常目标检测研究进展[J]. 遥感学报, 2024, 28(01): 42-54.

[169] HUYAN N, ZHANG X, ZHOU H, et al. Hyperspectral anomaly detection via background and potential anomaly dictionaries construction[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(4): 2263-2276.

[170] CHENG T, WANG B. Total variation and sparsity regularized decomposition model with union dictionary for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(2): 1472-1486.

[171] WU Z, WANG B. Kernel-based decomposition model with total variation and sparsity regularizations via union dictionary for nonlinear hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-16.

[172] LI L, ZHANG Q, SONG M, et al. Feedback band group and variation low-rank sparse model for hyperspectral image anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-19.

[173] STRANG G. Introduction to linear algebra[M]. SIAM, 2022.

[174] PAN L, LI H C, MENG H, et al. Hyperspectral image classification via low-rank and sparse representation with spectral consistency constraint[J]. IEEE Geoscience and Remote Sensing Letters, 2017, 14(11): 2117-2121.

[175] ACHANTA R, SHAJI A, SMITH K, et al. SLIC superpixels compared to state-of-the-art superpixel

中国知网 https://www.cnki.net

methods[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012, 34(11): 2274-2282.

[176] WANG X, ZHONG Y, ZHANG L, et al. Spatial group sparsity regularized nonnegative matrix factorization for hyperspectral unmixing[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(11): 6287-6304.

[177] BAISANTRY M, SAO A K, SHUKLA D P. Discriminative spectral–spatial feature extraction-based band selection for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.

[178] LIU W, MA Y, WANG X, et al. UADNet: A joint unmixing and anomaly detection network based on deep clustering for hyperspectral image[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-19.

[179] JIANG K, XIE W, LEI J, et al. E2E-LIADE: end-to-end local invariant autoencoding density estimation model for anomaly target detection in hyperspectral image[J]. IEEE Transactions on Cybernetics, 2022, 52(11): 11385-11396.

[180] MA D, CHEN M, YANG Y, et al. Coarse-to-fine multiview anomaly coupling network for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-15.

[181] SUN H, WANG L, ZHANG L, et al. Hyperbolic space-based autoencoder for hyperspectral anomaly detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-15.

中国知网 https://www.cnki.net