分类号_____ 密　级_____

U D C _____

昆明理工大学

博士学位论文

基于水下光学图像清晰化的目标检测方法研究

研　究　生　姓　名　崔　峥

指导教师姓名、职称　那　靖

学　科　专　业　机械电子工程

研　究　方　向　机器人技术与应用

论　文　工　作
起　止　日　期　2022 年 9 月~2025 年 3 月

论 文 提 交 日 期　2025 年 3 月

中国知网 https://www.cnki.net

基于水下光学图像清晰化的目标检测方法研究

摘 要

水下光学成像系统作为理解和感知水下环境的重要工具之一，广泛用于水下目标自主搜寻以及水下目标探测等领域。然而，由于水介质对不同波长光的选择性吸收和散射效应、以及水中悬浮颗粒物等因素的耦合作用，导致水下光学图像普遍存在对比度低、颜色偏差、细节模糊和非均匀光照等降质问题，从而影响后续目标检测任务的精度和鲁棒性。因此，本论文针对波长选择性光吸收和散射效应导致的颜色失真、人工光源引入的非均匀照明以及不同退化类型水下图像中的非均匀退化等问题，研究图像清晰化方法以提升图像的整体视觉感知和对关键目标特征的敏感度。此外，目标检测是水下光学应用的另一项关键方法。传统的目标检测方法主要依赖于人工设计的特征信息，难以准确描述水下多尺度和非刚性变形的目标物体，从而影响了目标检测方法的检测精度和泛化性。水介质特有的光学衰减以及水下目标尺度变化大、遮挡与聚集等问题，进一步加剧了目标检测模型在水下场景中的性能。因此，本论文从改善水下降质图像的质量入手，针对三种退化类型的水下光学图像分别提出了相应的图像清晰化方法以提升图像的质量，并作为目标检测任务的预处理步骤，从而提高目标检测模型的检测精度和鲁棒性。基于上述分析，本论文的主要研究内容如下：

（1）针对水介质波长依赖性光吸收和散射效应导致的颜色偏差、低对比度和模糊等问题，提出基于局部白平衡和多尺度融合的水下图像清晰化方法。首先针对水介质对不同光谱区域光的吸收特性，将通道补偿策略和细化亮度图相结合，以改善水下光学图像中不同程度的色偏问题。其次，根据颜色校正图像的高频信息设计多尺度融合策略的输入图像，并采用统计学设计通用的清晰度权重图和亮度权重图以增强水下图像的视觉质量。本章方法在 UCCS、UIEB、UIQS 和 RISU 水下图像数据集上开展了广泛的定性与定量实验。定性结果表明，所提方法可有效校正水下图像中不同程度的颜色失真现象，并提升图像的纹理信息。此外，引入 UIQM、UCIQE、FADE、AG 和 EI 定量评价指标进一步验证本章方法在多样化水下环境中的有效性。

（2）针对水下非均匀照明问题，提出基于亮度图估计和自适应增益的水下图像清晰化方法。首先采用颜色空间变换和线性拉伸操作生成颜色转移图像，并引入

中国知网 https://www.cnki.net

最大衰减图动态调整水下图像的颜色信息，从而获得颜色校正图像。其次，通过施加结构权重矩阵以处理水下图像中非均匀照明的挑战。此外，通过引入积分图分解图像的低频信息，并提出自适应增益控制函数实现图像高频信息的自适应增强，以解决水下光学图像中纹理细节信息弱化的问题。实验结果表明，所提方法能够有效抑制水下非均匀照明的干扰。在工业水下环境进行的双目视觉标定实验中，该方法分别获得了 0.167 的重投影误差和 28.20mm 的实际测量距离值，均优于对比方法。

（3）针对不同类型水下光学图像降质过程中的非均匀退化问题，提出基于成像模型和衰减图引导的水下图像清晰化方法。首先构建了一个多颜色通道混洗模块以结合图像中不同颜色空间的视觉表征，并引入衰减图对不同类型图像的局部区域提供非均匀增强。随后，引入多分支结构和空洞卷积估计不同颜色通道的透射图，并将水下物理模型嵌入到统一的框架中以实现端到端水下图像增强。本章方法在 UIEB 测试、UIEB 挑战、EUVP、LSUI 和 SQUID 水下数据集上开展了全面的定性与定量实验。定性结果表明，所提方法能够有效改善不同类型水下光学图像的视觉感知效果，并提升了图像的全局和局部对比度。此外，引入全参考和无参考定量评价指标进一步验证本章方法在处理水下非均匀退化问题方法的能力。

（4）针对水下目标的堆叠、边缘模糊以及多种图像降质的问题，提出基于图像增强和多分支结构的水下目标检测方法。首先研究不同类型水下图像清晰化方法的适用情况，设计条件判定模块为目标检测网络提供高质量的输入图像。其次，为了解决水下目标尺度变化大、遮挡以及聚集等问题，通过引入拉普拉斯算子构建特征输入模块可捕获图像更深层次的边缘特征，并基于注意力机制和多尺度结构设计骨干网络和颈部网络，提高了水下目标检测模型的有效性和鲁棒性。实验结果表明，所提方法可显著提高目标检测模型在不同退化程度水下图像中的性能。此外，在水下抓取任务中，进一步验证了所提方法在实际水下环境中的适用性。

本文研究不仅从理论与应用的角度系统验证了所提出方法的有效性，还针对水下抓取任务构建了基于视觉的水下自动抓取实验平台，进一步验证了本论文方法在实际水下场景中的适用性。

关键词：水下图像清晰化；图像退化；图像融合；颜色空间变换；卷积神经网络

中国知网 https://www.cnki.net

Object Detection Method Based on Underwater Optical Image Sharpening

Abstract

The underwater optical imaging system is one of the important tools for understanding and perceiving the underwater environment, which is widely used in the autonomous search for underwater objects, underwater object detection and other fields. However, due to the selective absorption and scattering of the different wavelengths of light and the combined effects of microorganisms, underwater images often suffer from contrast reduction, color deviation, blurred details, and non-uniform illumination, which influences the accuracy and robustness of subsequent object detection tasks. Therefore, this thesis's dedicated underwater optical image sharpening method is studied to improve the overall visual perception of the image and sensitivity to key object features, including the color distortion caused by wavelength-dependent light absorption and scattering, the non-uniform illumination introduced by artificial light sources, and the non-uniform degradation in underwater images of different types. Additionally, object detection model is another key technology for underwater optical applications. Traditional object detection models depend on artificially designed feature information, but this feature information is incapable of adequately describing the underwater multi-scale and non-rigidly deformed objects, thus limiting the effectiveness and generalization of subsequent object detection models. Due to the unique characteristics of the water medium, the quality of underwater images may be degraded, and the multi-scale, occlusion, and aggregation characteristics of underwater objects also pose challenges to the performance of object detection models. Therefore, starting from improving the quality of degraded underwater images, three underwater optical image sharpening methods are proposed to enhance the quality of underwater images with different degradation types and serve as a preprocessing step for the object detection task, thus improving the detection accuracy and robustness of the object detection model. Based on the above analysis, the main research of this thesis is summarized as follows:

(1) Aiming at the problems of color deviation, low contrast and blur caused by

中国知网 https://www.cnki.net

wavelength-dependent light absorption and scattering effects, an underwater image sharpening method based on local white balance and multi-scale fusion is proposed. Firstly, a channel compensation strategy and a refined brightness map are combined to reflect the light absorption of the water medium in different spectral regions to correct the color deviation of underwater images. Secondly, a multi-scale fusion strategy is constructed based on the high-frequency information of the color-corrected image, and then a generalized sharpness and brightness weight map is designed based on a statistics method to enhance the visual quality of underwater images. Extensive qualitative and quantitative experiments have been conducted on the UCCS, UIEB, UIQS and RISU underwater image datasets. Qualitative results show that the proposed method can effectively correct various degrees of color distortion and enhance the texture details of the underwater images. Moreover, the UIQM, UCIQE, FADE, AG and EI quantitative evaluation metrics are introduced to further demonstrate the effectiveness of the proposed method in diverse underwater environments.

(2) Aiming at the problem of underwater non-uniform illumination, an underwater image sharpening method based on illumination map estimation and adaptive gain is proposed. Firstly, color space transformation and linear stretching operation are utilized to derive the color transfer image, and the maximum attenuation map is introduced to dynamically adjust the color information to obtain the color-corrected image. Then, the challenge of non-uniform in underwater images is tackled by imposing a structure weight matrix. In addition, the integral map is introduced to decompose the low-frequency information of the image, and an adaptive gain control function is proposed to adaptively enhance the high-frequency information to solve the problem of weakened texture detail in underwater optical images. Experimental results show that the proposed method can effectively suppress the interference of underwater non-uniform illumination. In the industrial underwater binocular vision calibration experiment, the proposed method obtains a reprojection error of 0.167 and an actual measurement distance value of 28.20mm, which are better than the comparison method.

(3) Aiming at the non-uniform degradation problem in the degradation process of underwater optical images with different types, an underwater image sharpening method based on imaging model and attenuation guidance is proposed. Firstly, a multi-color channel shuffle module is constructed to combine the visual representations of different

中国知网 https://www.cnki.net

color spaces, and an attenuation map is introduced to provide non-uniform enhancement for local regions of images with different types. Subsequently, a multi-branch structure and dilated convolution are introduced to estimate transmission maps for different color channels and integrate the underwater physical model into a unified framework to achieve end-to-end underwater image enhancement. Comprehensive qualitative and quantitative experiments have been conducted on the UIEB test, UIEB challenge, EUVP, LSUI and SQUID underwater datasets. Qualitative results show that the proposed method can effectively improve the visual perception of different types of underwater optical images and enhance the global and local contrast of the image. Moreover, full-reference and no-reference quantitative evaluation metrics are introduced to further verify the ability of the proposed method in dealing with underwater non-uniform degradation problems.

(4) Aiming at handling the problems of underwater target occlusion, edge blur and various image degradation, an underwater object detection method based on image enhancement and multi-branch structure is proposed. Firstly, the applicability of different underwater image sharpening methods is studied to provide high-quality images for the object detection network. Secondly, due to the multi-scale, occlusion, and aggregation of underwater targets, the Laplacian operator is introduced to construct the feature input module to enhance the edge features extract ability of the model. Moreover, the backbone and neck networks are designed based on the attention mechanism and multi-scale structure to improve the effectiveness and robustness of the underwater object detection model. Experimental results show the proposed method can significantly improve the performance of the target detection model in underwater images with different degradation levels. Moreover, the applicability of the proposed methods in actual underwater environments are further tested via underwater grasping tasks.

Throughout the thesis, the effectiveness of the proposed methods is verified both theoretically and in application. Moreover, the applicability of the proposed methods in actual underwater environments are further tested via underwater grasping tasks.

Key Words: Underwater optical image sharpening; Image degradation; Image fusion; Color space transformation; Convolutional neural network

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.2 水下图像清晰化方法研究现状.....3
1.2.1 基于成像模型的水下图像清晰化方法.....3
1.2.2 基于视觉先验的水下图像清晰化方法.....5
1.2.3 基于数据驱动的水下图像清晰化方法.....9
1.3 水下目标检测方法研究现状.....12
1.3.1 传统的水下目标检测方法.....12
1.3.2 基于 CNN 的水下目标检测方法.....13
1.4 主要研究内容.....15
1.5 论文组织结构.....16
第二章 水下光学成像及图像质量评价方法.....19
2.1 引言.....19
2.2 水下光学特性.....19
2.2.1 光在水介质中的传播.....19
2.2.2 光在水介质中的吸收效应.....20
2.2.3 光在水介质中的散射效应.....21
2.3 水下光学成像模型.....22
2.4 水下光学图像质量评价方法.....23
2.4.1 主观评价方法.....23
2.4.2 客观评价方法.....24
2.5 水下光学图像数据集.....28
2.6 本章小结.....30
第三章 基于局部白平衡和多尺度融合的水下图像清晰化方法.....31
3.1 引言.....31
3.2 基于细化亮度图引导的局部白平衡方法.....32
3.2.1 颜色转移图像的生成.....33
3.2.2 细化亮度图的估计.....34
3.2.3 基于细化光照图引导的融合策略.....35
3.3 基于高频控制因子的多尺度融合方法.....35
3.3.1 多尺度融合策略输入图像的生成.....36
3.3.2 权重图的设计.....37
3.3.3 多尺度图像融合框架.....38
3.4 实验结果与分析.....39

中国知网 https://www.cnki.net

3.4.1 主观定性实验.....40
3.4.2 客观定量实验.....44
3.4.3 局部细节分析.....46
3.4.4 消融实验.....47
3.4.5 应用实验.....48
3.5 本章小结.....49
第四章 基于亮度图估计和自适应增益的水下图像清晰化方法.....51
4.1 引言.....51
4.2 基于变分模型的局部自适应亮度校正方法.....52
4.2.1 颜色转移图像的生成.....52
4.2.2 基于暗通道先验变体的融合策略.....53
4.2.3 基于变分模型的亮度图估计.....54
4.3 基于自适应增益控制函数的高频增强方法.....56
4.3.1 自适应增益控制函数的设计.....56
4.3.2 颜色平衡策略的构建.....58
4.4 实验结果和分析.....58
4.4.1 主观定性实验.....59
4.4.2 客观定量实验.....60
4.4.3 局部细节分析.....61
4.4.4 消融实验.....61
4.4.5 应用实验.....63
4.5 本章小结.....65
第五章 基于成像模型和衰减图引导的水下图像清晰化方法.....67
5.1 引言.....67
5.2 修正的水下成像模型.....68
5.3 基于成像模型和衰减图引导的卷积神经网络架构.....69
5.3.1 基本环境光参数估计模块.....70
5.3.2 偏置环境光参数估计模块.....70
5.3.3 透射率估计模块.....72
5.3.4 损失函数.....73
5.4 实验结果与分析.....74
5.4.1 实验设置.....75
5.4.2 主观定性实验.....75
5.4.3 客观定量实验.....81
5.4.4 消融实验.....85
5.4.5 应用实验.....86
5.5 本章小结.....88
第六章 基于图像增强和多分支结构的水下目标检测方法.....91

中国知网 https://www.cnki.net

6.1 引言.....91
6.2 不同退化水下图像的光学特性.....92
6.3 基于注意力机制和多分支结构的目标检测方法.....96
6.3.1 输入模块.....97
6.3.2 骨干网络.....98
6.3.3 颈部网络.....99
6.3.4 头部网络.....100
6.4 实验结果与分析.....101
6.4.1 水下目标检测数据集.....101
6.4.2 实验设置.....102
6.4.3 对比实验.....103
6.4.4 消融实验.....105
6.4.5 水下目标检测定性结果.....106
6.5 水下环境的自动抓取实验.....107
6.5.1 实验平台搭建.....107
6.5.2 抓取流程.....110
6.5.3 实验结果.....111
6.6 本章小结.....112
第七章 结论与展望.....115
7.1 工作成果.....115
7.2 创新点总结.....117
7.3 工作展望.....117
参考文献.....119

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景及意义

海洋作为人类的生命起源，占据了地球 71%的面积，对海洋世界进行探索对人类的生产和生活有着重要意义[1]。近年来，海洋资源的勘探和利用已经成为国际社会的战略重心。自主水下载具（Autonomous Underwater Vehicles, AUVs）和无人水下载具（Unmanned Underwater Vehicles, UUV）作为海洋资源的勘探任务中的关键装备，主要依赖于声学、惯性和视觉等多种传感器进行智能决策[2-4]。由于视觉传感器具有非侵入性、被动性和高信息量，逐渐成为了主流的传感方式。视觉传感器通常通过搭载的水下光学相机感知周围的水下场景，因此获得具有高质量的光学图像或视频是准确感知和探索水下未知环境的先决条件。然而，受光在水介质中传播时的选择性吸收、散射和水中微生物等多种因素的共同作用，导致获取的水下图像往往具有低对比度、低亮度、颜色失真、噪声、细节模糊和非均匀照明等退化问题[5,6]。具体而言，水体对不同波长光的选择性吸收作用是引起水下光学图像颜色失真的主要因素，而光的前向散射和后向散射效应是导致水下光学图像出现模糊、雾状和能见度低的主要原因。如图 1.1 所示，原始水下光学图像存在不同程度的降质现象，相应的 RGB 直方图直观地反映出红色波长光遭受了严重衰减且每个通道的像素值分布情况。降质的水下图像会引起基于光学图像的水下设备失效，从而限制了基于光学图像的水下海洋勘探、设施检测、水下目标识别和检测等领域的发展[7-9]。

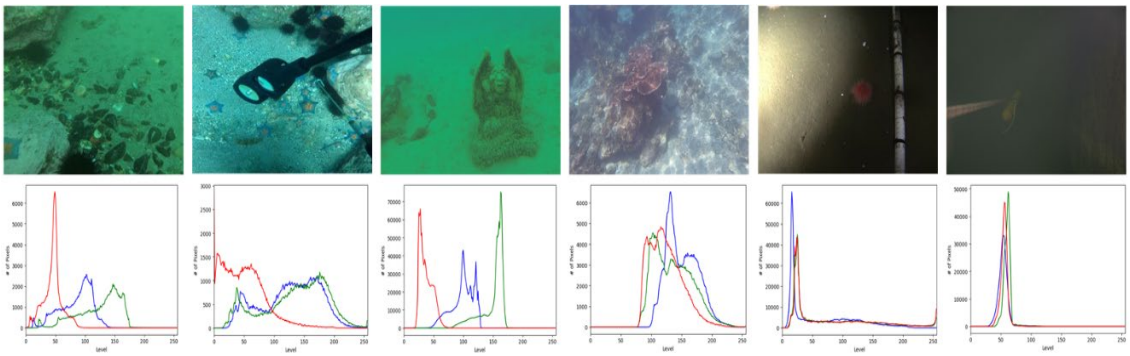


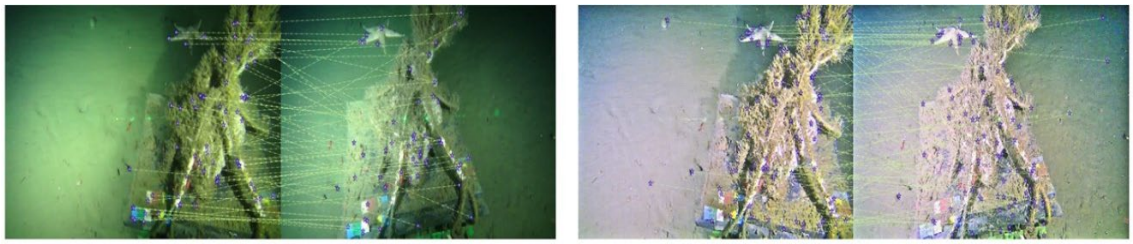
图1.1 退化的水下图像

Fig.1.1 Degraded underwater image

水下图像清晰化方法旨在针对性地提高水下图像的对比度、颜色以及纹理细节信息，从而满足后续依赖高质量输入图像任务的需求。如图 1.2 所示，高质量的

中国知网 https://www.cnki.net

水下图像可大幅提高特征点匹配视觉任务的性能。此外，增强的水下图像具有更加自然和清晰的外观，能够更好地反映水下环境的真实色彩和细节，从而提高了图像的可读性和可用性。综上所述，水下图像清晰化可在一定程度上提高水下图像质量，并符合人类视觉感知系统或满足后续计算机视觉任务的需求。因此，研究水下光学图像清晰化方法对于推动海洋资源探索、监测以及水下工程应用等领域具有重要的指导价值和实际意义。



(a) (b)

图1.2 SURF 特征点匹配：(a) 原始水下图像匹配 64 个点；(b) 复原图像匹配 96 个点

Fig.1.2 SURF feature points matching

(a) The raw underwater image matches 64 points (b) the restored image matches 96 points

尽管光学水下图像清晰化方法在探索海洋世界有着诸多的优点和广阔的应用前景。但是，由于水介质独特的光学特性，导致水下图像清晰化方法的研究存在挑战。近年来，学者们提出了许多基于水下光学图像的清晰化方法，大致可以分为基于成像模型的水下复原方法、基于视觉先验的图像增强方法和基于数据驱动的图像增强方法。基于成像模型的水下复原方法涉及建立水下退化模型，利用预先设计的先验知识估计模型参数后反解获得恢复的水下图像。这类方法在特定的水下场景中可有效还原高质量的图像，但由于对先验知识的严重依赖，导致在复杂多变的真实水下环境中复原效果较差。基于视觉先验的图像增强方法通过直接调整水下图像的像素值而无需依靠水下成像模型实现水下光学图像质量的提高。这类方法虽然可以有效提高水下图像的能见度和对比度，但忽略了水介质的成像过程，增强结果易出现过饱和和欠饱和的现象。得益于目前计算资源和数据量的日益提升，基于数据驱动的深度学习方法在计算机视觉的不同领域实现了巨大成功，同时也为水下图像清晰化任务带来了新的策略的视角。然而，在相同位姿的水下环境中同时获得退化和清晰的一对水下图像是难以实现的，限制了基于大规模配对样本训练适用于不同退化环境模型的能力。

因此，本文着重于研究基于水下光学图像清晰化的相关技术，旨在提高水下光学图像的信噪比和能见度，为后续基于光学图像的水下探索和水下视觉任务提供技术支持。在水下探索方面，光学图像清晰化方法可有效抑制色彩失真，提高图像

中国知网 https://www.cnki.net

的能见度和对比度，从而更好地理解和感知水下环境。在视觉任务方面，水下光学清晰化方法可为视觉任务提供高质量的输入图像，以提高水下目标检测和定位的精度，因此开展水下光学清晰化方法的研究对于水下自主巡检、水下管道缺陷检测和海洋军事等领域具有重要的应用价值。通过研究水下光学图像清晰化方法，以提高水下目标检测模型的检测性能，进一步推动水下自主作业和智能化的发展。

1.2 水下图像清晰化方法研究现状

现有的水下图像清晰化方法大致可以分为基于成像模型的水下复原方法、基于视觉先验的图像增强方法以及基于数据驱动的图像增强方法。本节将依次对水下图像清晰化方法的国内外研究现状进行全面的回顾和总结。

1.2.1 基于成像模型的水下图像清晰化方法

基于成像模型的水下复原方法旨在研究水下光学图像的退化机理，构建水下成像的物理模型，根据预先设计的先验知识估计水下成像模型参数后反解获得恢复水下图像的方法。基于成像模型的方法依赖于先验知识和当前水下环境条件的各种假设，导致现有的复原方法普适性和计算复杂性较差。该类方法根据参数估计方法的不同可分为基于特定硬件的水下复原方法和基于先验知识的水下复原方法两类。

（1）基于特定硬件的水下清晰化方法

在水下成像的过程中，偏振成像（Polarization Imaging）[10]、距离选通成像（Range-gated Imaging）[11]、荧光成像（Fluorescence Imaging）[12]和立体成像（Stereo Imaging）[13]等广泛用于水下光学图像的复原。偏振成像是一种被动成像的方法，其利用光的偏振特性分析水下环境中光的吸收效应和散射损失，从而通过水下成像模型实现水下图像复原。距离选通成像是一种主动成像的方法，利用水体的蓝绿光学窗口和距离选通成像的特性，广泛部署于浑浊场景的水下激光成像系统。然而，激光成像系统易受到环境干扰并且设备操作复杂，严重限制了在真实水下环境中的应用。荧光成像旨在研究水生环境中浮游植物的分布、珊瑚健康监测和其它水生现象的技术[14]。立体成像广泛应用于 AUVs 中，通过双目或多目相机获取多视角水下图像，并实时计算当前场景的深度信息，从而还原清晰的水下光学图像。综上所述，尽管该类方法在水下图像复原方面取得了宝贵的成就，但由于硬件设备操作繁琐且难以获取相同场景下序列图像等问题，导致该类方法难以广泛用于不同的水下场景。

中国知网 https://www.cnki.net

（2）基于先验知识的水下清晰化方法

该类方法首先根据预先设计的先验知识以估计水下成像模型的参数，并反解出清晰水下图像的方法。由于水下成像过程和自然环境的有雾图像成像具有相似性，因此许多去雾算法的思想广泛应用于改善光学水下图像的质量。

He 等[15]通过统计学提出了暗通道先验（Dark Channel Prior, DCP）理论，即对于一幅无雾图像，图像中的每个像素点所对应的 RGB 颜色通道中，总有一个通道的像素值很低。该先验可表示为：

$$J_{\text{dark}}(x)=\min_{y\in\Omega(x)}(\min_{c\in\{r,g,b\}}J^{c}(y))\rightarrow 0 \tag{1-1}$$

其中，J 表示任意一幅输入图像，Ω 为图像的局部区域的尺寸，通常设置为15×15 。

暗通道先验在室外去雾任务上的巨大成功，同时为水下图像复原任务带来了新的策略和视角。Chao 等[16]直接利用暗通道先验和成像模型以复原清晰的水下图像。虽然该方法可有效去除散射效应，但未考虑水介质对于光的选择性吸收效应，使得复原结果存在着严重的颜色失真。Chiang 等[17]使用暗通道先验增强水下图像并根据不同颜色通道的衰减特性进行补偿，同时考虑了人造光源的影响以恢复清晰的水下图像。Yao 等[18]提出一种改进的基于暗通道先验的水下图像复原方法，根据红色和蓝色通道之间的差异估计环境光，并计算不同通道的衰减系数，最后通过颜色校正去消除色偏现象。为了提高 DCP 在水下环境中的鲁棒性，Drews 等[19]分析了水介质对于不同波长光的吸收效应，提出一种仅使用绿色和蓝色通道计算暗通道的新方法。由于红光的波长最长，在水介质中传播的距离最短，其次是绿光，最后是蓝光。根据这一特性，水下图像中红色通道的像素强度总是低于其它通道，这可能导致传统暗通道方法不再适用。但红色通道中同样包含了重要的场景信息，因此需要对红色通道的像素值进行补偿。Galdran 等[20]提出了一种适用于水下光学图像的红色通道方法，该方法在校正颜色失真的同时恢复了图像的能见度，具有简单且鲁棒性强的优点。Yang 等[21]提出一种基于暗通道先验的水下图像复原方法，利用中值滤波和 DCP 分别估计透射率和环境光，并且引入额外的颜色校正方法以增强水下图像的颜色对比度。Carlevaris-Bianco 等[22]提出最大强度先验以消除光散射效应的影响，并利用水下图像三个颜色通道之间的衰减差异实现透射率图的估计。林森等[23]提出一种基于修正散射模型的水下图像复原方法，利用红通道先验和四叉树分级搜索算法分别估计透射率和环境光，最后通过修正的成像模型实现水下图像的复原。杨爱萍等[24]提出一种两步法的水下图像复原技术。该方法首先分析光在水中的衰减特性，设计适用于水下图像的颜色失真去除方法，其次利用散

中国知网 https://www.cnki.net

射系数与波长之间的关系以优化各通道的透射率，最后根据水下成像模型恢复清晰的水下图像。

上述基于暗通道先验的水下图像方法往往性能不佳，其原因在于水下图像中存在不同的光照条件和水介质的吸收效应，可能导致暗通道先验假设失效，从而影响参数估计的准确性并降低复原结果。Peng 等[25]分析了水下图像中光照条件导致暗通道先验失效的问题，提出了一种结合图像模糊度先验和光吸收的方法，用于估计水下透射率和场景深度。Berman 等[26]分析十类 Jerlov 水体类型的衰减特性，提出雾线先验解决水介质依赖光波长衰减的特性并重建水下图像。Li 等[27]提出基于最小信息损失和直方图分布先验的水下图像增强方法以提升人类感知和后续视觉任务。Akkaynak 等[28]基于水下依赖关系重新改进了水下成像模型，并且利用改进的水下成像模型实现了水下图像的颜色校正。虽然该算法可有效校正水下图像的色偏现象，但优化过程复杂，实时性较差。Song 等[29]提出基于水下光衰减先验的快速深度估计模型，并结合监督线性回归训练模型系数。该方法利用深度图以估计场景的透射率和环境光，从而实现水下真实场景的恢复。Xie 等[30]将模糊核先验与总变差项相结合，并通过多尺度策略细化模糊核，最后利用水下成像模型实现水下图像的去雾和去模糊。谢骏等[31]基于红通道稀疏先验实现水下图像的盲复原。该方法首先根据简化水下成像模型获得图像色彩恢复的导向图，通过建立变分能量方程和交替乘子法求解清晰的水下图像。这类方法在某些情况下可有效实现水下图像的复原，但它们严重依赖于预先设计的先验知识，当先验知识不适合当前水下场景的具体特征时，复原图像的结果往往质量较差。

1.2.2 基于视觉先验的水下图像清晰化方法

基于视觉先验的光学图像清晰化方法可以通过直接调整图像像素值，在不考虑水下成像模型的前提下，以提高水下图像视觉质量[32,33]。在研究初期，通常根据具体应用场景采用传统陆地图像处理技术直接应用于水下图像，以重新整合水下图像的像素值分布，从而改善水下图像的对比度。基于视觉先验的图像清晰化方法大致可以分为基于直方图技术、基于 Retinex 理论和基于融合策略的方法。

（1）基于直方图技术的水下图像清晰化方法

基于直方图技术的清晰化方法是以灰度映射为基础，旨在改善图像的像素灰度级分布以提高图像的对比度，如图 1.3 所示。直方图均衡化[34]是一种典型的图像对比度增强方法，具有简单、实时和自适应的优点。由于改进 HE 方法是一种全局处理技术，因此会导致部分区域对比度过度增强，而其它区域可能存在对比度压缩

中国知网 https://www.cnki.net

的现象。为了改进这一问题，Hitam 等[35]提出受限对比度自适应直方图均衡化方法，将图像分成多个局部区域，通过在每个区域中引入对比度限制和自适应调整策略以避免对比度过度增强并且保留图像的细节信息。这类基于直方图的水下清晰化方法，虽然能一定程度上提高图像的对比度，但水下图像具有多种退化因素，导致上述方法难以直接应用于水下图像清晰化任务中。

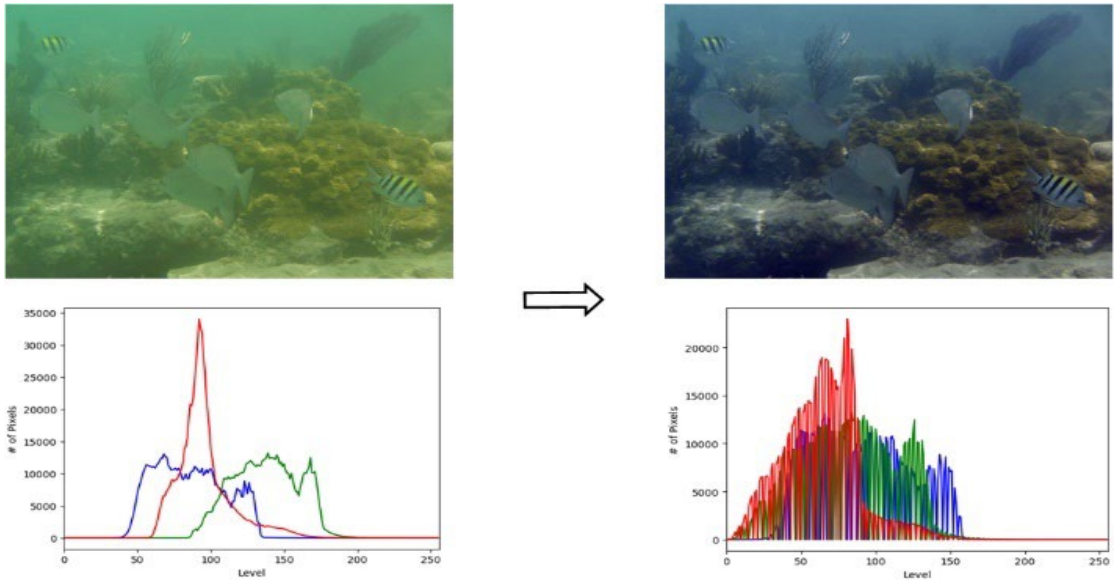


图1.3 基于直方图技术的清晰化方法

Fig.1.3 Sharpening method based on histogram technology

针对水下图像具有的对比度低、颜色失真、模糊等特点，学者们陆续提出许多针对水下图像的清晰化方法。Iqbal 等[36]提出一种基于滑动拉伸的水下图像增强方法，根据 RGB 和 HSI 色彩空间设计相应的直方图拉伸策略以还原水下图像的真实色彩并且提高对比度和亮度。Shamsuddin 等[37]针对水下图像的色彩失真问题，设计了手动和自动的颜色校正技术，并根据拉伸直方图的平均值增强水下图像的颜色分布。由于瑞利分布是水下图像直方图的最佳分布，因此 Ghani 等[38]提出基于瑞利拉伸和多颜色空间的水下图像增强方法以提高水下图像的质量。Garg 等[39]针对水下图像的模糊问题，提出了基于 CLAHE 和百分位数相结合的水下图像增强策略。该策略利用两种方法的生成图像进行结合以获得最终的增强结果，有效提高了水下图像的能见度和对比度。Huang 等[40]提出一种基于自适应参数估计的相对全局直方图拉伸方法以提高浅水图像的质量。针对水下图像的色偏和可见度低的问题，Zhang 等[41]提出了基于子区间变换和双区间直方图的水下图像增强方法，通过子区间线性变换以校正水下图像的色偏问题，并基于最优均衡阈值策略和线性融合方法获得高质量的水下图像。此外，退化的水下图像会导致目标检测器性能下降。因此，Li 等[27]将对比度增强和水下去雾算法相结合，提出一种面向目标检测任务

中国知网 https://www.cnki.net

的水下图像增强方法。该方法可依据不同的任务需求使用具有不同特点的增强版本。综上所述，基于直方图的水下图像增强方法可有效利用单幅图像的原有信息实现水下图像的对比度和能见度的提高。然而，这类方法仅从全局或者局部角度调整图像的像素值，并未考虑水下成像机理，往往产生非自然伪影、增强不足和增强过度等现象。

（2）基于 Retinex 理论的水下图像清晰化方法

最早由 Land[42]提出的 Retinex 理论认为，人眼可以感知近似一致的色彩信息，该性质称为色彩恒常性。如图 1.4 所示，假设一幅彩色图像可以分解为反射分量和入射分量的乘积。基于 Retinex 理论的增强方法的本质是去除入射分量对原始图像的干扰，从而获得清晰图像的过程。早期基于 Retinex 理论的尝试是应用于提高弱光图像的能见度，例如单尺度 Retinex（Single-Scale Retinex, SSR）和多尺度 Retinex（Multi-Scale Retinex, MSR）。上述方法均直接使用反射分量作为最终的增强结果，会损失图像本身所包含的一部分信息，使得增强结果出现不自然的外观。针对 SSR 和 MSR 的色偏问题，Rahman 等[43]提出多尺度视网膜颜色恢复方法（Multi-Scale Retinex with Color Restoration, MSRCR），将色彩恒常性与局部对比度或者亮度增强相结合以恢复接近真实场景的图像。

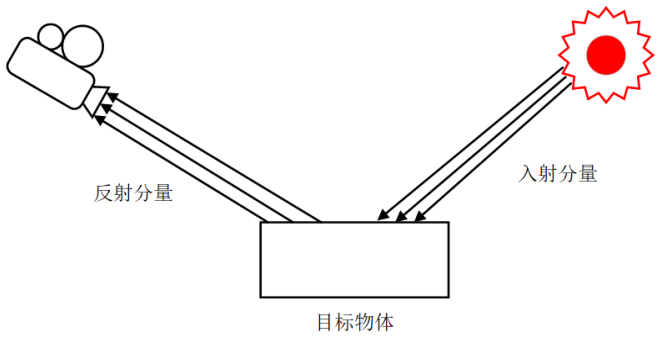


图1.4 Retinex 理论

Fig.1.4 Retinex theory

随着 Retinex 理论在图像增强领域的发展，许多研究人员在水下光学图像清晰化领域提出许多建设性的意见。例如，Fu 等[44]提出基于 Retinex 理论的水下图像增强方法。该方法根据 Retinex 变分框架分解水下图像获得反射分量和入射分量，利用不同的策略增强这两个分量，最后通过结合反射分量和入射分量获得最终的增强图像。针对水下图像模糊、对比度和能见度低的问题，Zhang 等[45]根据水下图像的特性拓展了 MSR 方法，利用 CIELAB 色彩空间中每个通道的特性采用双边和三边滤波器的组合，可显著提高不同浑浊程度水下光学图像的质量。Hassan 等[46]设计了一种改进 Retinex 理论的水下图像增强方法。该方法首先使用 CLAHE 对原

中国知网 https://www.cnki.net

始图像进行直方图拉伸操作以增强水下图像暗区域的对比度，并基于 Retinex 理论和双边滤波操作以获得最终的增强结果。Zhuang 等[47]提出一种基于贝叶斯 Retinex 方法，通过引入多阶梯度先验以估计反射图和照明图并反解获得清晰的水下图像。综上所述，基于 Retinex 理论的水下图像增强方法考虑了反射分量和入射分量，可在一定程度上解决水下图像中非均匀照明问题。然而，该类方法需要与其它图像处理方法相结合以获得较好的增强图像，因此设计过程较为复杂且普适性差。

（3）基于融合策略的水下图像清晰化方法

基于融合策略的水下光学清晰化方法通过使用不同的图像处理技术获得具有不同特点的输入图像，随后构建高斯和拉普拉斯金字塔进行加权融合以实现水下光学图像的增强，具体流程如图 1.5 所示。Ancuti 等[48]提出基于融合策略的水下图像增强方法，根据退化的水下图像生成颜色校正图像和对比度增强图像，并且定义了四幅权重图描述水下图像的特征，最后通过多尺度融合策略获得最终的增强结果。由于上述方法忽略了后向散射分量的影响，导致在浑浊、非均匀照明等极端环境的水下图像时增强效果不佳。针对上述问题，Ancuti 等[49]结合两步增强方法的思想[50]提出颜色平衡和融合的水下图像增强方法。该方法首先根据光的衰减特性提出一种水下白平衡方法，随后利用伽马校正和反锐化掩膜方法生成多尺度融合的输入图像，并基于对比度、显著度和饱和度构建权重图，最后通过多尺度融合策略重建水下图像。针对水下图像对比度低和色偏问题，Ma 等[51]提出一种基于 CLAHE 的多颜色空间融合方法。该方法利用 CLAHE 方法从 YIQ 和 HIS 色彩空间生成两幅对比度增强的图像，并根据 Sobel 边缘检测器进行权重计算以获得最终结果。Zhang 等[52]提出基于最小颜色损失和局部自适应对比度增强方法以解决水介质对光的吸收和散射效应。该方法利用最小颜色损失原则和最大衰减图引导的融合策略实现水下图像的色偏校正，随后引入积分图和平方积分图计算局部区域的均值和方差，最后针对轻微的色偏现象在 CIELAB 色彩空间中引入 a 通道和 b 通道的颜色平衡策略实现具有自然外观和能见度的增强图像。林森等[53]提出基于复原结构与增强纹理融合的水下图像清晰化方法，首先根据红通道补偿策略对原始图像进行颜色校正，随后利用相对总变差模型分解结构层和纹理层并设计加权融合策略得到清晰的水下图像。Marques 等[54]提出弱光水下图像增强方法，利用局部对比度信息和多尺度融合策略实现弱光条件下的水下图像恢复。综上所述，基于融合策略的水下图像增强方法可有效提高水下图像的能见度、纹理细节信息及抑制噪声等。然而，这类方法需要根据具体应用设计相应的融合图像和权重图，因此设计具有潜在应用价值的融合图像和权重图是该方法的重点。

中国知网 https://www.cnki.net

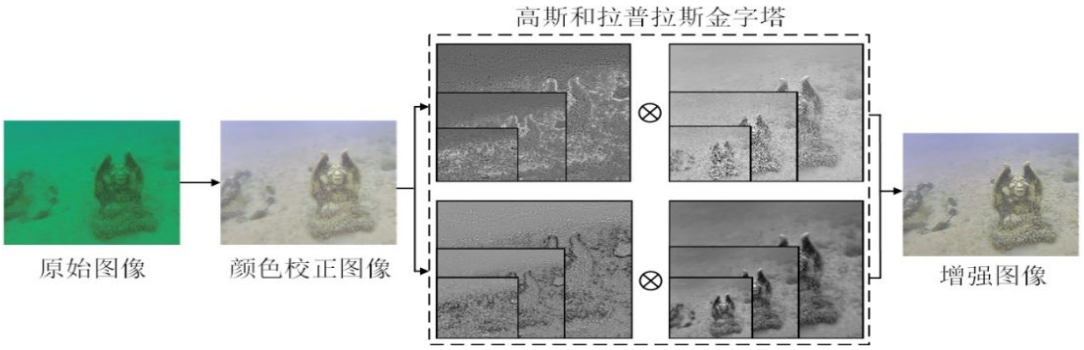


图1.5 基于融合策略的水下图像清晰化方法框架

Fig.1.5 Framework of underwater image sharpening method based on fusion strategy

1.2.3 基于数据驱动的水下图像清晰化方法

近年来，随着硬件设备和神经网络模型的快速发展，基于数据驱动的方法已广泛应用于各种计算机视觉任务中，因此越来越多的研究人员开始探索基于数据驱动的方法在水下光学图像增强等低级视觉任务领域的潜力[55,56]。此外，基于数据驱动的深度模型在应用于多样化和复杂的场景时，往往表现出更强的有效性和鲁棒性。然而，由于成对训练数据的不足和计算资源等因素限制了这类方法的实际应用。根据深度模型的基础设计，基于数据驱动的水下光学图像增强方法大致可分为基于生成对抗网络（Generative Adversarial Network, GAN）的水下图像增强方法和基于卷积神经网络（Convolutional Neural Network, CNN）的水下图像增强方法。

（1）基于 GAN 的水下图像清晰化方法

GAN 作为一种新型的神经网络模型，利用生成器与判别器之间的对抗策略学习数据之间的映射函数，广泛用于图像生成、图像合成和风格迁移等领域。由于 GAN 在图像域任务中的强大能力，通常用于解决水下光学图像的退化问题。

基于数据驱动的水下光学图像往往需要大量的数据集，然而水下光学成像模型受浑浊和光照条件等多种复杂因素的影响，导致难以合成逼真的水下图像数据集进行深度网络模型的训练。因此，针对水下成对数据集的匮乏，Li 等[57]利用陆地 RGB-D 图像通过 GAN 和水下成像模型生成逼真的水下图像，并且使用合成的水下图像和相应的参考图像用于二阶段网络的训练，实现了水下图像的颜色校正。受循环一致对抗网络的启发，Fabbri 等[58]提出一种水下 GAN 网络以生成成对的水下光学图像数据集。同时，利用水下光学成像模型的图像生成方法也逐渐引起研究者们的关注。Blasinski 等[59]提出一种三参数的水下光学成像模型以合成逼真的水下图像。Li 等[60]基于室内 NYU-V2 数据集[61]模拟了十种 Jerlor 类型的水下图像。进一步地，为了生成逼真的水下光学图像，Wang 等[62]分析了水介质对光的选择性

中国知网 https://www.cnki.net

吸收效应和后向散射效应，提出一种无监督的生成对抗网络用于生成具有颜色失真和雾霾效应的水下图像，并且利用合成数据集训练 U-Net 实现了水下光学图像的颜色恢复和去雾。虽然合成的水下图像与真实的水下图像相似，但合成的水下图像难以完整反映真实水下场景，导致使用合成数据训练的深度模型往往在真实水下场景中产生不自然的增强图像，甚至引入更加严重的颜色失真现象。因此，为了解决合成图像与真实图像之间的差异，Liu 等[63]通过引入对抗机制实现从原始图像到水下目标图像的映射。Duarte 等[64]使用牛奶、叶绿素和绿茶在水箱中模拟水下光学图像的退化过程并获得成对的水下数据集。Li 等[65]全面分析了真实水下场景的光学图像并且构建了一个水下图像增强基准数据集（Underwater Image Enhancement Benchmark, UIEB），其中包括 890 幅真实水下光学图像和相应的参考图像。此外，为了放松模型训练时对成对水下图像的需求，Li 等[66]提出一种弱监督的水下颜色转移模型。Ye 等[67]提出基于堆叠的条件 GAN 以端到端的方式学习水下图像和陆地图像之间的映射关系，该网络由雾检测子网络和颜色校正子网络两部分组成，可有效去除水下图像的模糊和颜色失真现象。针对 GAN 模型多个输出可能产生不真实复原图像的问题，Guo 等[68]提出一种多尺度密集 GAN 实现水下图像增强，该方法通过结合非饱和 GAN 损失函数、绝对误差损失函数和梯度损失函数以学习参考图像在特征域中的分布。Liu 等[69]基于多级特征融合提出通用的条件 GAN 以从多尺度的角度提取水下图像的特征信息。Islam 等[70]从运行效率的角度提出基于条件 GAN 的实时水下增强方法。然而，基于 GAN 的水下光学图像增强方法仍然无法避免 GAN 模型会产生多个不确定输出结果的本质，并且弱监督或者无监督的训练方式会导致模型的泛化性和鲁棒性较差。

（2）基于 CNN 的水下图像清晰化方法

得益于卷积神经网络模型在多种视觉任务中取得的巨大进步，研究人员开始深入研究该模型在水下图像清晰化方面的潜力[71]。该方法通过堆叠多个卷积层以监督学习的方式提取图像几何信息和语义信息的特征表征，并根据这些具有特定信息的特征实现不同的视觉任务。因此，根据网络训练方式的不同，可大致分为非端到端水下图像清晰化和端到端水下图像清晰化两部分。

图 1.6 为基于 CNN 的非端到端水下图像清晰化方法的流程图。这类方法利用卷积神经网络强大的非线性特征表征能力估计水下成像模型中的未知参数，并基于水下成像模型反演出清晰的水下图像。Cao 等[72]根据水下光学成像模型，搭建两个卷积神经网络结构估计环境光和场景深度以恢复水下光学图像。Chen 等[73]将深度学习与改进的水下成像模型相结合，提出一种新的水下图像增强方法。该方法首

中国知网 https://www.cnki.net

先根据改进的水下光学成像模型将水下图像增强过程分为后向散射估计和直接透射率估计两部分，其次基于 CNN 搭建相应的参数估计模块并使用监督学习得到模型的未知参数，最后利用水下成像模型实现水下光学图像的重建。针对水下光学图像的固有统计特征（颜色伪影和雾密度）的表征问题，Wang 等[74]提出基于 CNN 的框架来学习相关的分层统计特征并利用它们进行水下光学图像增强。此外，Yang 等[75]提出基于颜色转移的水下图像增强策略，通过学习参考图像和原始水下图像之间的潜在一致性自适应选择参考图像，随后基于参考图像利用颜色转移技术实现原始水下图像稳定的增强。然而，上述方法需要预先设置参考图像，并且使用特定的参考图像是从全局的角度实现颜色转移，因此它无法对水下光学图像中不同退化程度的区域提供差异化的引导。针对上述问题，Li 等[76]提出了一种无参考的水下光学图像增强方法，该方法通过预测六个基础颜色转移参数和相应的偏置矩阵实现水下图像视觉质量的提高。

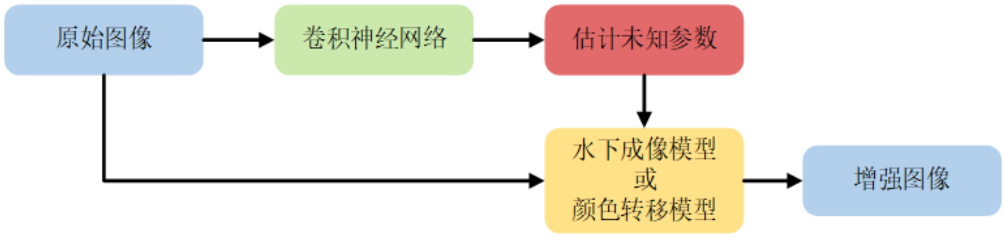


图1.6 基于 CNN 的非端到端水下图像清晰化方法框架

Fig.1.6 Framework of non-end-to-end underwater image sharpening method based on CNN

图 1.7 为基于 CNN 的端到端水下图像清晰化方法的流程图。该方法将原始水下图像或者其它补充图像输入到卷积神经网络模型，利用神经网络强大的非线性能力学习退化水下图像与参考水下图像之间的映射关系。Li 等[60]提出基于水下场景先验的水下图像增强方法。该方法根据十种 Jerlor 水类型的衰减因子、环境光和距离构建了合成水下图像数据集，随后以端到端的方式训练了十个水下图像增强模型，其中每种模型用于增强相应类型的水下光学图像。针对大部分卷积神经网络均采用 RGB 颜色空间设置，该颜色空间对图像亮度、饱和度等属性不敏感。为了解决上述问题，Wang 等[77]提出基于多颜色空间的水下卷积神经网络增强方法。该方法在单个 CNN 中集成了 RGB 颜色空间和 HSV 颜色空间以端到端的训练方法实现水下图像复原。为了获得更加多样化的特征表示，Li 等[78]提出一种基于介质透射图引导的多颜色空间的水下图像增强网络，在编码器-解码器结构的基础上引入多颜色空间和注意力机制相结合丰富编码器特征表示的多样性，并且设计介质透射图引导的解码器使网络更关注于图像中质量退化的区域。此外，考虑到同一水下场景下的图像通常具有相似的退化情况，因此相关图像可为彼此提供额外的互补

中国知网 https://www.cnki.net

信息并且缓解单一图像增强方法中可能存在的局限性。近年来，利用补充图像引入额外信息已逐渐成为水下光学图像增强领域的研究热点。Qi 等[79]提出了一种基于孪生编码器-解码器结构的水下图像协同增强网络实现端到端的水下光学图像协同增强任务。该网络设计孪生编码器结构以获得多级图像特征图，并引入相关特征匹配模块计算两个特征分支的相关系数，最后通过孪生解码器重构水下光学图像。为了从有限训练样本中进一步挖掘丰富的监督信息，Qi 等[80]引入语义信息作为区域特征学习的高层引导以实现水下图像清晰化。此外，针对水下单一参考图像训练的问题，Li 等[81]提出基于比较学习的水下图像增强框架，向多个参考图像中学习质量最优区域的特征。

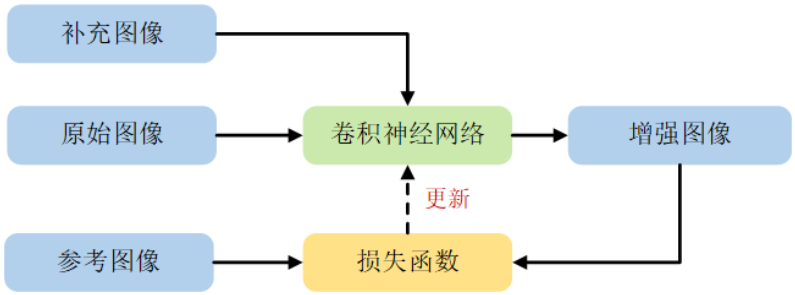


图1.7 基于 CNN 的端到端水下图像清晰化方法框架

Fig.1.7 Framework of end-to-end underwater image sharpening method based on CNN

综上所述，基于 CNN 的非端到端水下图像增强方法根据水下成像模型中的未知参数构建相应的网络结构以实现参数估计，最后根据水下光学成像模型反求得到清晰的图像。虽然该类方法可在一定程度上放松传统先验知识设计的问题，但设计相应的网络结构实现未知参数的准确估计仍然存在挑战。为此，研究者们尝试以端到端的学习方式实现水下图像的增强，利用卷积神经网络直接学习退化图像和参考图像之间的映射关系。然而，该方法需要大量的不同场景的水下光学数据集进行训练，并需要根据实际场景进行网络的设计和优化。

1.3 水下目标检测方法研究现状

1.3.1 传统的水下目标检测方法

目标检测是机器视觉领域中的核心任务之一，其目标是针对输入图像，利用设计好的特征工程，从而准确预测图像中目标的位置与类别信息。传统的水下目标检测方法主要包括图像预处理与特征工程两个关键方面。一方面，通常需要借助图像处理方法对原始水下图像进行预处理，以提升图像的对比度和辨识度；另一方面是通过人工设计特征工程以描述目标物体的信息，从而实现目标的分类识别和位置

中国知网 https://www.cnki.net

回归。

由于水下成像质量较差，检测前通常需要引入图像清晰化方法以改善图像的清晰度和对比度。Bartyzel 等[82]提出自适应 Kuwahara 滤波以平滑水下图像中噪声的同时保留细节边缘信息。Cai 等[83]利用大气散射模型和暗通道先验的思想，提出一种端到端的卷积神经网络结构 DehazeNet 以提升水下图像质量。上述预处理方法在一定程度上改善了水下图像的质量，从而为后续目标检测任务提供良好的输入基础。

在人工特征工程方面，Srividhya 等[84]利用灰度共生矩阵计算目标的纹理特征以表征水下图像中不同目标物体的结构差异。Bi 等[85]提出二维主成分分析方法，仅利用较少的特征维度即可有效表征水下目标信息，并抑制了分类器对异常特征的敏感性，从而提升识别的鲁棒性。此外，Chen 等[86]结合图像高亮区域的先验信息以增强特征的判别能力，并将图像中光源聚焦区域划分为感兴趣区域，从而实现对目标的初步识别。

虽然传统的水下目标检测方法在特定场景和目标中能够实现较为稳定的检测性能，但其对水下复杂多变环境的适应性较差，尤其难以应对水下图像中常见的模糊、低对比度和非均匀光照等退化问题，导致检测精度和鲁棒性的下降。因此，随着近年来卷积神经网络（Convolutional Neural Network, CNN）在各类高级视觉任务中的快速发展，基于 CNN 的水下目标检测方法逐渐成为研究主流，旨在提升水下目标检测方法在复杂环境下的鲁棒性和泛化能力。

1.3.2 基于 CNN 的水下目标检测方法

近年来，CNN 的兴起为水下目标检测带来了新的视角。得益于 CNN 在特征提取与特征表征方面的强大能力，显著提升了水下目标检测方法的准确性与鲁棒性。基于 CNN 的水下目标检测方法，通过堆叠卷积层、池化层和激活函数等基本处理单元从输入图像中汇聚信息，逐渐实现从低层几何特征向高层语义特征的转变。针对水下图像的特殊退化和目标特性，研究者在通用目标检测框架的基础上做了大量改进与扩展。根据检测过程中是否需要显式生成候选区域作为中间步骤，基于 CNN 的水下目标检测方法可大致分为双阶段目标检测方法与单阶段目标检测方法。

（1）双阶段目标检测方法

双阶段目标检测网络首先根据 R-CNN[87]（Region with CNN features, R-CNN）生成候选区域，随后将候选区域输入神经网络以提取高级特征信息，最后对候选区

中国知网 https://www.cnki.net

域进行类别分类和边界框的位置回归。然而，R-CNN 中候选区域生成过程独立于后续特征提取与分类步骤，导致整体检测流程分离，无法共享特征。为了解决上述问题，Faster R-CNN[88]引入了高效且准确的区域建议网络（Region Proposal Network, RPN）以实现统一的端到端目标检测任务。为了进一步拓展 Faster R-CNN 网络的功能，He 等[89]提出了 Mask R-CNN，实现了在检测目标的同时预测每个目标的分割掩膜。此外，为了提升候选区域特征对齐的精度，Mask R-CNN 中引入 RoI Align 操作以消除量化误差。Cascade R-CNN[90]采用由一系列检测子模型构成的级联结构，并通过在不同交并比（Intersection over Union, IoU）阈值下筛选的样本上进行逐级训练，以提升检测精度。Grid R-CNN[91]将每个候选区域划分为固定尺寸的网格，通过在网格内预测多个关键点的位置，并结合关键点的空间布局信息确定边界框，从而实现更细粒度的位置回归。综上所述，双阶段目标检测网络通常涉及候选区域生成，使得网络能够准确地提取目标物体的特征信息，从而提升网络的检测性能。

（2）单阶段目标检测方法

尽管双阶段目标检测方法在检测精度方面表现优异，但由于其需要显式生成候选区域，随后分阶段完成特征提取与分类回归任务，导致网络整体推理速度较慢，难以满足实时检测应用的需求。为了解决双阶段方法实时性的问题，研究者们提出了单阶段目标检测方法[92]。该方法舍弃了候选区域生成过程，直接在原始图像上进行类别预测与边界框回归，从而显著提升了推理速度。其中，YOLO[93]将目标检测任务视为统一的回归问题，直接学习从图像像素到边界框坐标与类别概率之间的映射关系，在保证检测准确率的同时提高了检测速度。SSD[94]引入多尺度特征图以处理不同尺度的目标物体，从而提高了模型对小目标的检测能力。CornerNet[95]通过 CNN 直接预测目标边界框左上角点和右下角点的位置，从而准确捕捉目标物体的空间位置关系，进一步提升了模型的定位精度和泛化能力。CenterNet[96]将每个检测框表示为一组三元组（左上角点、右下角点和中心点），并引入中心点作为辅助信息以验证角点匹配的准确性，从而提升了模型的准确率和召回率。

尽管上述基于 CNN 的目标检测方法在自然场景下取得了巨大的成功，但在水下环境中，由于水下光学图像对比度低、色彩失真、水下目标尺度变化大、遮挡以及聚集等因素，导致现有目标检测方法仍面临检测精度低、定位不准确等挑战[1]。因此，研究针对复杂水下环境中的目标检测方法，对提升水下工程应用的有效性和鲁棒性具有重要的理论意义与应用价值。

中国知网 https://www.cnki.net

1.4 主要研究内容

虽然现有的水下光学图像清晰化方法在消除色偏、提高对比度及能见度方面都有不少研究成果，但仍存在着一些问题亟待解决。因此，本论文从解决实际水下目标检测问题的角度出发，主要针对现有工作仍然存在的波长依赖性的光吸收和散射问题、水下非均匀照明的亮度图估计不稳定问题以及不同类型水下光学图像降质过程中的非均匀退化问题开展水下光学图像清晰化研究，并将水下图像清晰化方法作为目标检测网络的预处理步骤，从而提高水下目标检测的精度和鲁棒性。论文的总体框架及各章节组织结构如图 1.8 所示，主要研究内容包括：

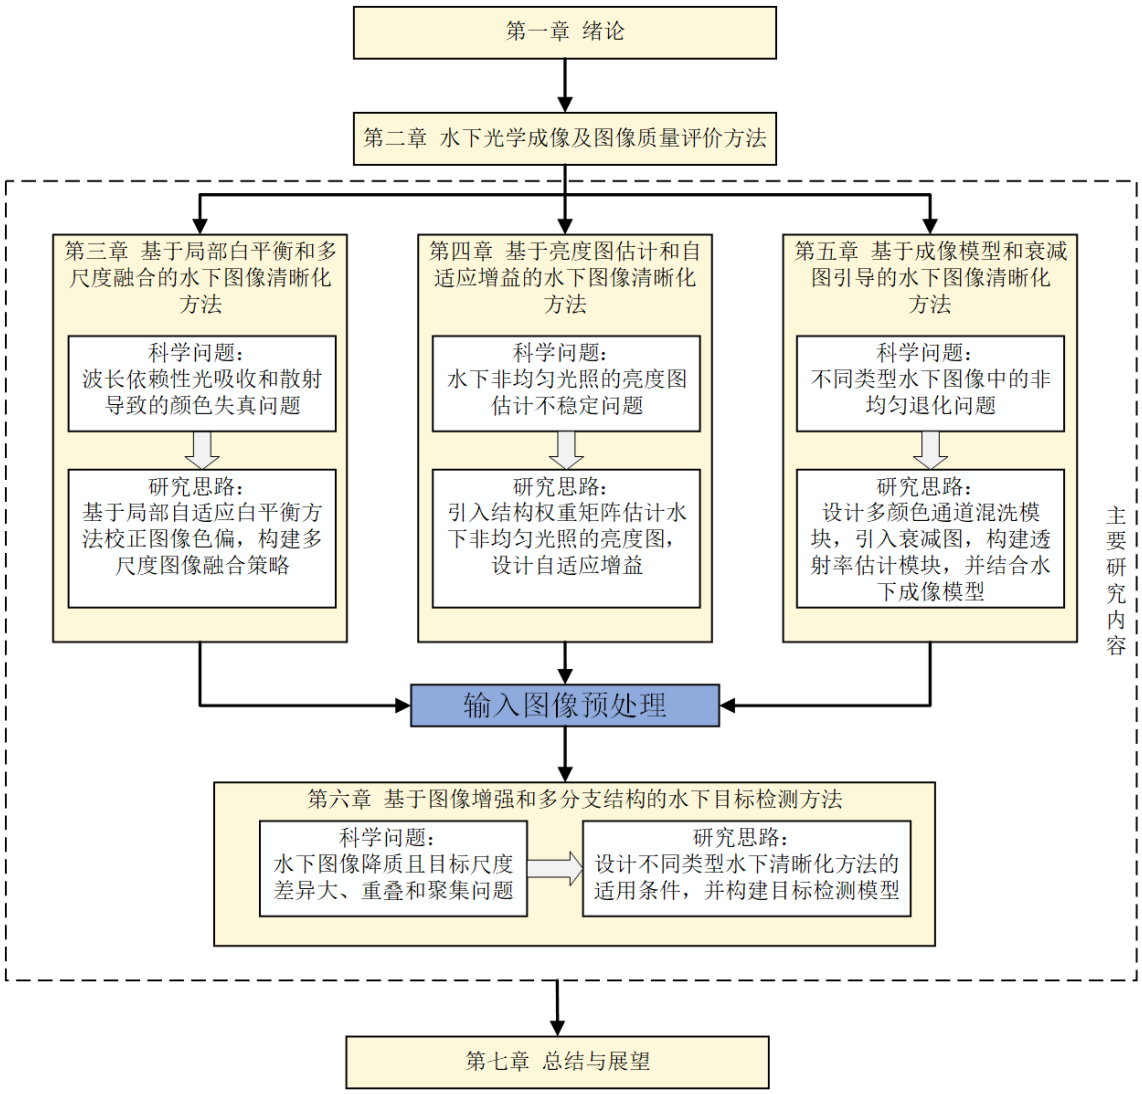


图1.8 论文结构示例图

Fig.1.8 The research flowchart of this thesis

（1）基于局部白平衡和多尺度融合的水下图像清晰化方法

在水下成像中，由于水介质对不同波长光的吸收、散射和折射等影响，导致光

中国知网 https://www.cnki.net

的传播路径发生显著变化，进而使得捕获的水下光学图像具有颜色失真、模糊和低对比度等问题。针对上述问题，研究利用自适应通道补偿策略和细化亮度图结合实现水下光学图像颜色校正的局部白平衡方法，并构建研究多尺度融合方法以及相应的权重图，在校正水下光学图像颜色失真的同时，尽可能地提高图像的对比度和细节信息。

（2）基于亮度图估计和自适应增益的水下图像清晰化方法

在水下环境中，随着水深的增加，自然光会快速衰减，因此通常采用人工光源作为照明设备以改善水下光学图像的能见度。然而，人工光源可能会引入非均匀照明、光斑效应以及颜色失真等问题。针对上述问题，研究基于变分模型的亮度图补偿方法，并研究自适应增益控制函数，以抑制水下光学图像中非均匀照明现象，并提升图像整体能见度和对比度。

（3）基于成像模型和衰减图引导的水下图像清晰化方法

水下光学图像质量退化的因素是复杂且多样的，与水域深度、浑浊度、悬浮颗粒浓度和光照条件等因素密切相关。针对水下光学图像中的非均匀退化问题，本文从水下成像模型出发，采用卷积神经网络以辨识成像模型中的未知参数并估计相应的偏置矩阵，从而赋予网络非均匀增强的能力，以实现局部和全局角度的增强。

（4）基于图像增强和多分支结构的水下目标检测方法

针对水下图像退化以及水下目标复杂的分布形式的问题，研究水下退化图像的特征差异，设计条件判定模块以利用最佳的清晰化方法进行增强，并针对水下目标物体往往存在多尺度、遮挡和聚集等问题，研究基于注意力机制和多尺度结构的目标检测网络，从而提升网络在复杂水下环境中检测的鲁棒性与普适性。

基于上述研究，针对水下目标抓取任务搭建了一个基于视觉的物理实验平台，进一步验证所提出的水下图像清晰化技术与目标检测网络在实际工程应用中的有效性与适用性。

1.5 论文组织结构

论文共分为七章，各章节安排总结如下。

第一章：首先介绍本课题的研究背景和意义，阐述了当前水下图像清晰化方法和水下目标检测方法的国内外研究现状，归纳总结现有水下光学图像清晰化方法和目标检测方法所存在的问题，并介绍本文各章的组织架构。

第二章：首先介绍水下光学特性，重点探讨了水介质中光的传播、吸收和散射效应，阐述水下光学成像模型的基本原理与数学描述，并归纳常用的水下光学图像

中国知网 https://www.cnki.net

质量评价方法与相关数据集。

第三章：针对水介质对波长依赖性光吸收和散射导致的色彩失真问题，提出基于局部白平衡和多尺度融合的水下图像清晰化方法。本章详细介绍基于通道补偿和亮度图引导的融合策略对水下图像进行颜色校正的局部白平衡方法，重点阐述基于多尺度图像融合框架的输入图像生成以及权重图设计。最后，通过定性实验、定量实验、消融实验以及应用实验进一步验证本章方法在水下光学图像颜色校正方面的有效性。

第四章：针对水下人工光源引入的非均匀照明问题，提出基于亮度图估计和自适应增益的水下图像清晰化方法。详细阐述基于变分模型的亮度图估计方法以解决水下非均匀照明所带来的挑战，重点介绍基于自适应增益的水下图像高频信息增强方法。最后，通过定性实验、定量实验、消融实验以及应用实验进一步验证本章方法对非均匀照明水下图像增强的有效性和优越性。

第五章：针对不同类型水下图像中非均匀退化问题，提出基于成像模型和衰减图引导的水下图像清晰化方法。详细阐述修正的水下成像模型，重点介绍基本环境光估计模块、偏置环境光估计模块和透射率估计模块的设计。最后，通过定性实验、定量实验、消融实验以及应用实验验证本章方法对非均匀退化水下图像的有效性。

第六章：针对水下目标物体往往存在多尺度、遮挡和聚集等问题，提出基于图像增强和多分支结构的水下目标检测方法。分析了不同类型水下图像自身的光学特性，设计条件判定模块以自适应选择最佳的图像增强方法，并详细介绍检测模型的输入模块、骨干网络、颈部网络以及头部网络四部分。最后，通过定性实验、定量实验、消融实验以及水下自动抓取实验进一步验证本章方法在水下目标检测任务中的有效性。

第七章：本文主要工作成果和创新进行总结，并展望未来研究工作和方向。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第二章 水下光学成像及图像质量评价方法

2.1 引言

光在水介质中传播时，受水介质的吸收效应和散射效应，导致获取的水下光学图像面临不同程度的退化。吸收效应是光在传播时由于水介质中分子或原子的作用而导致能量损失的现象，而散射效应是光在传播中因与水中悬浮颗粒物相互作用，从而改变其传播方向的过程。两种效应的共同作用导致水下光学图像存在颜色失真、低对比度、模糊和低能见度等问题。此外，人工光源作为水下环境常用的照明设备会造成水下光学图像面临非均匀照明、光斑效应和噪声等问题。降质的水下图像会引起基于光学图像的水下设备失效，从而限制了基于光学图像的水下应用领域的发展。因此，研究水下光学图像清晰化方法对推动水下科学研究和实际应用具有重要的价值和意义。作为后续章节研究的理论基础，本章将主要介绍水下光学特性、水下成像模型、水下光学图像质量评价及水下图像数据集。

2.2 水下光学特性

2.2.1 光在水介质中的传播

光在水介质中传播时，由于水介质对光的吸收、散射和折射等影响，一方面会引起能量的损失，另一方面则受到水中悬浮颗粒物导致光在传播路径上发生变化。在复杂且多变的水下环境中，有机物、无机盐、天然水体中的色素、悬浮颗粒物等物体的存在，均会导致光在水中传播时的强度和路径发生显著的变化。因此，水介质的吸收作用会导致光能量的衰减，散射会导致光传播时方向发生变化。此外，水介质吸收和散射作用的强弱也与水中溶解物和悬浮颗粒物之间的浓度密切相关。即使在清澈的水域类型中的光能衰减也很明显，其中在清澈的水域中短波长的蓝光（约 450nm 光谱附近）衰减较小，而在浑浊的水域中波长的绿光（约 550nm 光谱附近）衰减较小[97]。

在水下环境中，不同波长光能的衰减程度与深度成正比关系，即随着水深的增加，光能衰减的程度越大。在清澈的水域中，红光在水深为 5m 左右时几乎完全衰减。随后是橙光和黄光，分别在水深为 10m 和 20m 左右时完全衰减。最后由于绿色和蓝色光波长相对较长，因此在水介质中传播距离越远，其中绿光可传播至水深 30m 左右，而蓝光可达到 60m。如图 2.1 展示了不同波长光随着水深的逐步增加所

中国知网 https://www.cnki.net

剩余的能量。根据上述分析，若光能的衰减特性满足朗伯比尔定律（Lambert-Beer Law）[98]，则光能的衰减强度与传播距离之间呈指数关系，数学表达式可表示为：

$$E_r = E_o e^{-cr} \tag{2-1}$$

其中，E_o为入射光的强度，r为光在水中传播的距离，E_r为光在传播距离r处的强度，c为光衰减系数，其包含吸收系数和散射系数。在海洋中的清澈水域、近海水域和浑浊水域中的光衰减系数分别为0.05m^{-1},0.2m^{-1}和0.33m^{-1}。

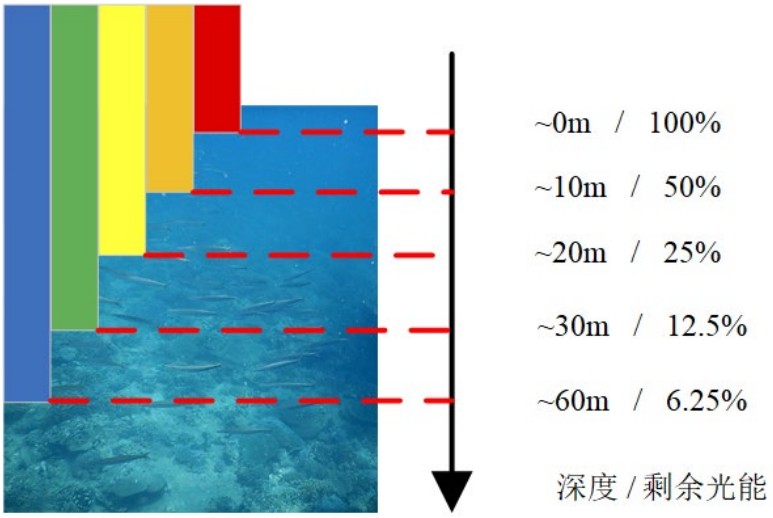


图2.1 不同波长光与水体深度之间的衰减关系

Fig.2.1 Attenuation relationship between different wavelengths of light and water depth

2.2.2 光在水介质中的吸收效应

在水介质中，由于水分子本身具有较强的吸收特性、高密度以及水中悬浮颗粒物质的影响，导致光在水介质中传播时能量迅速衰减，并且不同水域类型对光的吸收效应存在显著差异。除水介质本身的特性以外，还与水中浮游生物、黄色色素、非色素物质等成分密切相关。针对上述分析，光在水介质中的整体吸收系数可表示为：

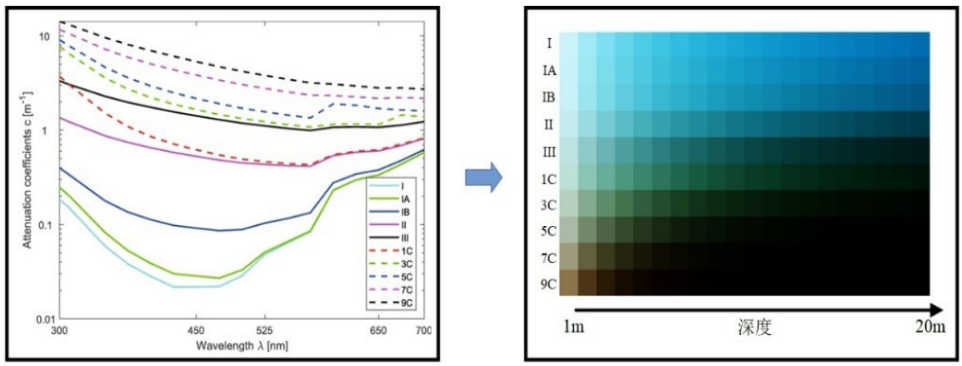
$$a(\lambda)=a_w(\lambda)+a_p(\lambda)+a_y(\lambda)+a_{npp}(\lambda) \tag{2-2}$$

其中，$a(\lambda)$代表光在水介质中受到的整体吸收系数，$a_w(\lambda)$为水介质本身的吸收分量，$a_p(\lambda)$为水介质中浮游生物所造成的吸收分量，$a_y(\lambda)$为水介质中黄色色素所引起的吸收分量，$a_{npp}(\lambda)$为水介质中非色素物质所导致的吸收分量。

Jerlov 等[99]根据水体的光学特性，将海水划分为十种不同的水体类型。其中，I、IA、IB、II 和 III 分别表示不同水域的水质类型，而 1C、3C、5C、7C 和 9C 则用于着重表示沿海水域的水类型。具体而言，I-III 用于表示从清澈到轻微浑浊的海水，而以 C 结尾则表示浑浊度由 1 至 9 递增的沿海水域。图 2.2(a)展示了不同水域

中国知网 https://www.cnki.net

类型对不同波长光的吸收[100]，其中横坐标代表不同波长的光，纵坐标为光的衰减系数。由图 2.2(a)可知，长波长光能最先被衰减，而短波长光可在水中传播的更远。图 2.2(b)展示了随着浑浊度和深度的逐渐增加，水介质对不同波长光的选择性吸收效应，从而导致获得的水下光学图像普遍具有绿色或者蓝色的外观。



(a) (b)

图2.2 不同水域类型对不同波长光的影响

Fig.2.2 Effects of different water types on light of different wavelengths

2.2.3 光在水介质中的散射效应

光在水中传播时，散射效应是导致水下光学图像退化的另一个重要原因。散射是由于水中悬浮颗粒物和溶解物质对光的相互作用，导致光的传播方向发生改变。根据光在传播过程中到达成像设备前方向的偏转程度，该空间分布特征可分为前向散射分量和后向散射分量两部分。前向散射分量是指光在水中传播时，由于水中颗粒物导致光原本的传播方向发生随机偏转从而被成像设备提前接受的部分。后向散射分量是指光在未到达目标物体前被反射回相机的部分，该分量是引起水下光学图像出现雾状、噪声和对比度低的主要原因。由于光在水中传播时主要受到水介质本身和悬浮颗粒物的散射效应，因此光在水介质中的散射系数可表示为：

$$S(\lambda)=S_w(\lambda)+S_{sp}(\lambda) \tag{2-3}$$

其中，$S_w(\lambda)$ 和 $S_{sp}(\lambda)$ 分别代表水介质本体和由于水中悬浮颗粒物所导致的散射分量。

此外，水介质对光散射效应的强度与悬浮颗粒物的浓度和形状等因素密切相关，并且不同波长光在水中受到的散射程度也有所差异。相较于长波长光，短波长光更容易受到散射的影响。通过上述因素的共同作用，水下光学图像质量呈现出不同程度的退化现象，该主要特点可归纳如下：

色彩偏差：水介质对不同波长光的选择性吸收效应，以及水中生物本身颜色信息的影响，使得光散射时引入额外的色彩，从而导致水下光学图像出现色彩偏差。

中国知网 https://www.cnki.net

雾状、低对比度：在不同水域环境下，由于水中悬浮颗粒物的影响，使得光在传播过程中发生散射效应，从而导致水下光学图像出现雾状和低对比度的问题，阻碍了后续基于光学图像视觉任务的特征提取。

非均匀照明：随着水深的不断增加，自然光会快速衰减，因此通常采用人工光源作为水下照明设备以改善水下光学图像的能见度。然而，使用人工光源会引入光照不均匀、光斑效应和伪影等问题。

非均匀退化：由于水介质自身的空间异质性以及多种退化因素的耦合影响，水下光学图像在空间域和强度域方面往往呈现出显著的非均匀退化特征。该退化程度主要随成像距离、图像中不同空间位置和水体深度呈动态变化，从而导致水下光学图像降质。

综上所述，水下光学图像普遍具有颜色失真、模糊、低对比度、非均匀照明和非均匀退化等降质问题，目前的水下图像清晰化技术并不能有效解决所有的图像降质问题，因此研究针对特殊场景的水下图像清晰化技术对于提高后续目标检测和定位精度具有重要的理论价值和实际意义。

2.3 水下光学成像模型

与大气环境不同，水介质本身对不同波长光的选择性吸收效应和散射效应，导致所获得的水下光学图像出现严重的退化现象。因此，研究水下光学成像的机理对于开展水下光学图像清晰化技术的研究奠定理论基础。本节将对水下光学成像模型进行详细介绍。

McGlamery[101]和 Jaffe[102]提出了经典的水下成像模型，以解释光在水介质中传播时图像平面上每个像素的辐照度。该成像模型由直接入射分量 E_d 、前向散射分量 E_f 和后向散射分量 E_b 三部分组成。因此，图像平面中每个像素点的总辐照度可表示为：

$$E_{total} = E_d + E_f + E_b \tag{2-4}$$

直接入射分量是指由水下目标直接反射而未发生散射进入成像设备上光的分量。由于水介质对不同波长光的选择性吸收效应，该分量是导致水下光学图像出现颜色色偏的主要原因。图像平面上每个像素点的直接入射分量可表示为：

$$E_d = J(x)e^{-\eta d(x)} = J(x)t(x) \tag{2-5}$$

其中，$J(x)$ 代表目标物体的辐照度，即待恢复图像。$d(x)$ 为相机与目标物体之间的相对距离，η 为当前水体本身吸收和散射效应的总衰减系数。项 $e^{-\eta d(x)}$ 为光在水介质中传播时的透射率，通常简称为透射率 $t(x)$ 。

中国知网 https://www.cnki.net

前向散射分量是指光在水介质中传播时发生随机偏转后被相机接受的部分，引起水下光学图像出现模糊现象。该分量可表示为：

$$E_f = (J(x)t(x)) \otimes g(x) \tag{2-6}$$

其中，$\otimes$ 为卷积操作，$g(x)$ 代表点扩散函数。该点扩散函数可定义为：

$$g(x) = [e^{-c_1 d(x)} - e^{-\eta d(x)}] F^{-1}\{e^{-c_2 d(x) f}\} \tag{2-7}$$

其中，c_1 和 c_2 分别为预定义的参数，通常根据经验进行设置。f 为图像的径向频率，F^{-1} 为逆傅里叶变换操作。

后向散射分量指光在水介质中传播时由于水中悬浮物反射回相机的部分，该分量是引起水下图像出现雾状和对比度低的主要原因。该分量可表示为：

$$E_b = A_\infty (1 - t(x)) \tag{2-8}$$

其中，A_∞ 代表图像的全局水下环境光。

通常，当目标物体与相机之间的距离足够近时，可忽略前向散射分量所带来的影响。因此，上述水下成像模型可简化为：

$$I(x) = J(x)t(x) + A_\infty (1 - t(x)) \tag{2-9}$$

其中，$I(x)$ 代表原始水下光学图像，$J(x)$ 代表待恢复图像，$t(x)$ 为透射率，A_∞ 为颜色向量，也可称为全局水下环境光。

2.4 水下光学图像质量评价方法

为了评估不同水下光学图像清晰化方法的性能，因此需要借助图像质量评价方法以准确、自动地评价增强图像的质量。图像质量评价方法可分为主观质量评价方法和客观图像质量评价方法两部分[103]。本节将对两种评价方法进行详细介绍。

2.4.1 主观评价方法

在水下光学图像清晰化技术的研究中，主观评价方法是用于评价增强图像质量的重要手段之一。主观评价方法依赖于人类的视觉感知系统和主观判断以评价一副图像质量的高低。这类方法通常需要邀请大量的观察者对不同水下清晰化方法所获得的增强图像进行打分评价，并计算相应图像的平均得分作为主观评价方法的结果。主观评价方法根据邀请者评价图像质量的方式，可分为绝对评价方法和相对评价方法两类。

1、绝对评价方法

绝对评价方法是指观察者根据参考图像，通过视觉感知不同水下清晰化方法的增强图像与参考图像之间的得分。表 2.1 展示了主观绝对评价方法的评分标准。

中国知网 https://www.cnki.net

表 2.1 主观绝对评价方法

Tab. 2.1 Subjective absolute evaluation method

质量等级	绝对评价指标	评分标准
1	低劣	严重阻碍视觉观察
2	较差	阻碍视觉观察
3	中等	明显感知到图像降质
4	良好	轻微感知到图像降质
5	优秀	无法感知到图像降质

2、相对评价方法

相对评价方法是指观察者在不利用参考图像的情况下，通过视觉感知不同水下清晰化方法所获得增强图像之间的质量对比。表 2.2 展示了主观相对评价方法的评分标准。

表 2.2 主观相对评价方法

Tab. 2.2 Subjective relative evaluation method

质量等级	绝对评价指标	评分标准
1	低劣	组内最差
2	较差	组内较差
3	中等	组内中等
4	良好	组内良好
5	优秀	组内优秀

2.4.2 客观评价方法

客观评价方法是指基于人类视觉系统的统计和数学模型，定量评价增强图像质量的方法[104]。该评价方法根据参考图像的可用性，可分为全参考评价方法和无参考评价方法。

1、全参考评价方法

在水下图像清晰化领域中，全参考评价方法是广泛用于定量衡量水下图像质量的重要手段之一。该方法通过计算增强图像与参考图像之间的像素值关系，以定量评价不同水下清晰化方法的性能。目前常用于衡量水下光学图像清晰化方法性能的全参考评价指标包括均方误差（Mean Square Error, MSE）[105]、峰值信噪比（Peak Signal to Noise Ratio, PSNR）、结构相似性（Structural Similarity Index, SSIM）[106]和基于块的对比度评价方法（Patch-based Contrast Quality Index, PCQI）[107]。

中国知网 https://www.cnki.net

（1）均方误差

均方误差（Mean Square Error, MSE）用于衡量参考图像与增强图像之间的像素差异，从而用于定量评估不同图像清晰化方法性能的指标。该指标可表示为：

$$MSE=\frac{1}{M\times N}\sum_{i=1}^{M-1}\sum_{j=1}^{N-1}[I_g(i,j)-I_e(i,j)]^2 \tag{2-10}$$

其中，I_g 和 I_e 分别代表参考图像和增强图像，M 和 N 分别为原始图像的高和宽。该指标值越低表明增强图像与参考图像之间越相似，质量越好。

（2）峰值信噪比

峰值信噪比（Peak Signal to Noise Ratio, PSNR）用于衡量参考图像与增强图像之间的差异以评估图像的失真程度。该指标可表示为：

$$PSNR=10\log_{10}\left(\frac{MAX^2}{MSE}\right) \tag{2-11}$$

其中，MAX 为图像的最大像素值，对于 8-bits 图像而言，MAX 设置为 255。MSE 为均方误差的结果。该指标值越高表明增强图像与参考图像之间的失真程度越小，与参考图像越相近。

（3）结构相似性

结构相似性（Structural Similarity Index, SSIM）是基于人类视觉感知的图像质量评价方法。该方法通过比较参考图像与增强图像之间的亮度、对比度和结构相似性以评估图像质量。该指标可表示为：

$$SSIM(x,y)=\frac{(2\mu_x\mu_y+C_1)(2\sigma_{xy}+C_2)}{(\mu_x^2+\mu_y^2+C_1)(\sigma_x^2+\sigma_y^2+C_2)} \tag{2-12}$$

其中，μ_x 和 μ_y 分别为增强图像和参考图像的像素均值，σ_x 和 σ_y 分别为增强图像和参考图像的像素方差，σ_{xy} 为两幅图像的协方差矩阵，C_1 和 C_2 为常数以避免分母为零的情况。该指标值越接近于 1，则表明增强图像的质量越高。

（4）基于块的对比度评价方法

基于块的对比度评价方法（Patch-based Contrast Quality Index, PCQI）通过分析图像局部块的对比度特征，从平均强度、信号强度和信号结构三个维度以衡量人类视觉系统对增强图像对比度变化的感知。该指标可表示为：

$$PCQI(i,j)=\frac{1}{M}\sum_{i=1}^{M}q_i(X_i,Y_i)\bullet q_c(X_i,Y_i)\bullet q_s(X_i,Y_i) \tag{2-13}$$

其中，M 代表局部图像块的数量，q_i 、q_c 和 q_s 分别代表平均强度、信号强度和信号结构三个函数。该指标值越高代表增强图像的对比度越好。

中国知网 https://www.cnki.net

2、无参考评价方法

在水下光学图像清晰化领域，由于参考图像难以获得，因此通常采用无参考水下图像质量评价方法以定量评估水下光学图像的质量。无参考评价方法是通过分析和统计图像本身特性设计相应的函数以评估增强图像的质量。目前常用于衡量水下光学图像清晰化方法性能的无参考评价方法包括平均梯度（Average Gradient, AG）[108]、边缘强度（Edge Intensity, EI）[109]、信息熵（Entropy）、水下图像质量评价指标（Underwater Image Quality Metric, UIQM）[110]、水下彩色图像质量评价指标（Underwater Color Image Quality Evaluation, UCIQE）[111]、色彩对比度雾密度评价指标（Colorfulness Contrast Fog Density Index, CCF）[112]和雾密度指数（FADE）[113]。

（1）平均梯度

平均梯度（Average Gradient, AG）通过计算图像中像素的梯度变化量，以衡量增强图像的锐化程度。该指标可表示为：

$$AG = \frac{1}{(M-1)(N-1)} \sum_{i=1}^{M-1} \sum_{j=1}^{N-1} \sqrt{\nabla_x I(i,j)^2 + \nabla_y (i,j)^2} \tag{2-14}$$

其中，∇_x 和 ∇_y 分别为图像水平和垂直方向上的梯度，M 和 N 分别代表图像的高和宽。该指标值越大表明增强图像的锐化程度越高。

（2）边缘强度

边缘强度（Edge Intensity, EI）是通过衡量图像中边缘的锐化程度，以评估增强图像的清晰度。该指标可表示为：

$$EI = \frac{1}{M \times N} \sum_{i=1}^{M-1} \sum_{j=1}^{N-1} E(i,j) \tag{2-15}$$

其中，E 表示基于 Canny 算子所获得二进制边缘图像的像素强度，M 和 N 为图像的高和宽。该指标值越大表明增强图像的清晰度越高。

（3）信息熵

信息熵（Entropy）为通过计算图像灰度值分布的概率，以评估增强图像信息量和复杂度的方法。信息熵的计算公式可表示为：

$$Entropy = -\sum_{i=0}^{255} p(i) \log_2 p(i) \tag{2-16}$$

其中，$p(i)$ 表示图像中灰度级为 i 出现的概率。该指标值越大表明增强图像的信息量越丰富。

（4）水下图像质量评价指标

中国知网 https://www.cnki.net

水下图像质量评价指标（Underwater Image Quality Metric, UIQM）是根据人眼视觉系统激励的启发，从水下图像退化机理和成像特点的角度，利用三种图像属性的线性组合以实现图像质量的评估。该评价指标的计算公式可表示为：

$$UIQM = Coeff_1 \times UICM + Coeff_2 \times UISM + Coeff_3 \times UIConM \tag{2-17}$$

其中，$UICM$ 、$UISM$ 和$UIConM$ 分别表示图像的色彩测量指标、清晰度测量指标和对比度测量指标。$Coeff_1$、$Coeff_2$ 和 $Coeff_3$ 分别为通过多元线性回归计算获得的相应指标的权重系数。该指标值越大表明增强图像在锐度、对比度和色彩度之间实现了越好的平衡。

（5）水下彩色图像质量评价指标

水下彩色图像质量评价指标（Underwater Color Image Quality Evaluation, UCIQE）将图像的色度、饱和度和对比度特征进行线性组合，以定量衡量水下光学图像的非均匀颜色失真、模糊和对比度。该指标的计算公式为：

$$UCIQE = c_1 \times \sigma_{chroma} + c_2 \times contrast_l + c_3 \times \mu_{saturation} \tag{2-18}$$

其中，c_1 、c_2 和 c_3 分别为相应分量的加权系数，σ_{chroma} 为增强图像的标准差，$contrast_l$ 为增强图像的对比度，$\mu_{saturation}$ 为增强图像饱和度的平均值。该指标值越高表明增强图像在色度、对比度和饱和度之间具有更好的平衡性。

（6）色彩对比度雾密度评价指标

色彩对比度雾密度评价指标（Colorfulness Contrast Fog Density Index, CCF）通过投票的方式来计算图像中的色彩指数、对比度指数和雾密度指数并进行相应的加权结合，从而定量衡量水下光学图像的质量。该指标可定义为：

$$CCF = \omega_1 \times Colorfulness + \omega_2 \times Contrast + \omega_3 \times Fogdensity \tag{2-19}$$

其中，ω_1、ω_2 和 ω_3 分别代表不同分量相应的权重系数，$Colorfulness$ 为水介质的吸收效应所引起的色彩指数，$Contrast$ 为水介质的前向散射效应所引起的对比度指数，$Fogdensity$ 为水介质的后向散射所引起的雾密度。该指标值越高表明增强图像在上述三个方面实现了越好的平衡效果。

（7）雾密度评价指标

雾密度评价指标是通过计算增强图像中雾密度的含量，以衡量不同清晰化方法对图像去模糊的程度。该指标的计算公式可表示为：

$$FADE = \sqrt{(v_1 - v_2)^{\mathrm{T}} \left(\frac{\sum_1 + \sum_2}{2} \right)^{-1} (v_1 - v_2)^{\mathrm{T}}} \tag{2-20}$$

其中，v_1 和 v_2 分别代表两个多元高斯模型的均值向量，$\sum_1$ 和 $\sum_2$ 分别代表两个多元高斯模型的协方差矩阵。该指标值越低表明增强图像的雾密度含量越少，从而反映

中国知网 https://www.cnki.net

图像清晰化方法的去模糊效果越好。

2.5 水下光学图像数据集

近年来，随着计算机视觉技术在图像识别、图像分割和目标检测等任务上的巨大成功，越来越多的研究人员开始研究针对水下光学图像清晰化任务的方法。然而，目前主流的基于深度学习的水下光学图像清晰化方法需要大规模的成对数据集进行模型训练。受益于上述方法的发展，本节总结了常用于验证水下光学图像清晰化方法的数据集。

根据数据集中水下光学图像的获取方式，可分为合成水下数据集和真实水下数据集两种。对于合成水下数据集而言，Li 等[57]提出基于水下光学成像模型的图像合成方法，通过陆地图像和相应的深度图利用 GAN 生成逼真的具有水下成像特点的图像，并利用合成数据集进行水下图像复原网络的训练，称为 WaterGAN。然而，由于合成水下图像无法完全反映真实水下场景的特点，因此着重介绍真实水下数据集。Liu 等[114]构建了真实水域的大规模图像数据集 RUIE（Real-world Underwater Image Enhancement, RUIE），其中包括三个不同特点的水下图像子集，分别是具有颜色失真的图像子集 UCCS（Underwater Color Cast Set, UCCS）、水下图像质量子集 UIQS（Underwater Image Quality Set, UIQS）和水下高级任务驱动子集 UHTS（Underwater Higher-level Task-driven Set, UHTS）。Berman 等[26]使用专业的水下成像设备和标准色卡在不同水域类型、深度和光照条件下拍摄 57 幅真实的水下图像，以定量评估不同水下清晰化方法对于真实图像的颜色失真校正能力。此外，Ancuti 等[49]使用 7 种专业的水下成像设备，获得含有标准色卡的水下光学图像，称为 ColorChecker7 水下数据集。Peng 等[115]构建了大规模的水下光学图像数据集，包含丰富的水下场景（例如光照条件、水域类别和目标类别等），并包括相应的参考图像，共计 5004 幅成对的真实水下图像，称为 LSUI（Large Scale Underwater Image, LSUI）。Li 等[65]通过网上搜索和自己拍摄的水下光学图像，构建了含有 950 幅不同水域、自然光或人工光的真实水下数据集，称为 UIEB。其中，850 幅原始图像提供了相应的参考图像，参考图像的获取方式是基于 12 种水下清晰化方法并通过人工投票的方式得到。此外，该数据集中还包括 60 幅未提供相应参考图像的具有挑战性的水下图像。Islam 等[70]使用 7 种专业的水下成像设备在不同能见度条件下获得成对和非成对的高质量和低质量的 20000 幅水下图像，该数据集称为 EUVP（Enhancement of Underwater Visual Perception, EUVP）。Marques 等[54]从同一海域的视频集中截取了 183 幅水下图像，构建了低光照水下数据集，称

中国知网 https://www.cnki.net

为 OceanDark。

此外，课题组利用自制的水下机械臂搭载的水下双目摄像机（BARLUS GY-H3F-6DHX10）在工业环境下采集了 66 幅具有不同深度和角度的水下图像，该数据集称为 RISU（Real Industrial Scene Underwater, RISU）。图 2.3 为课题组使用的整体实验设备。

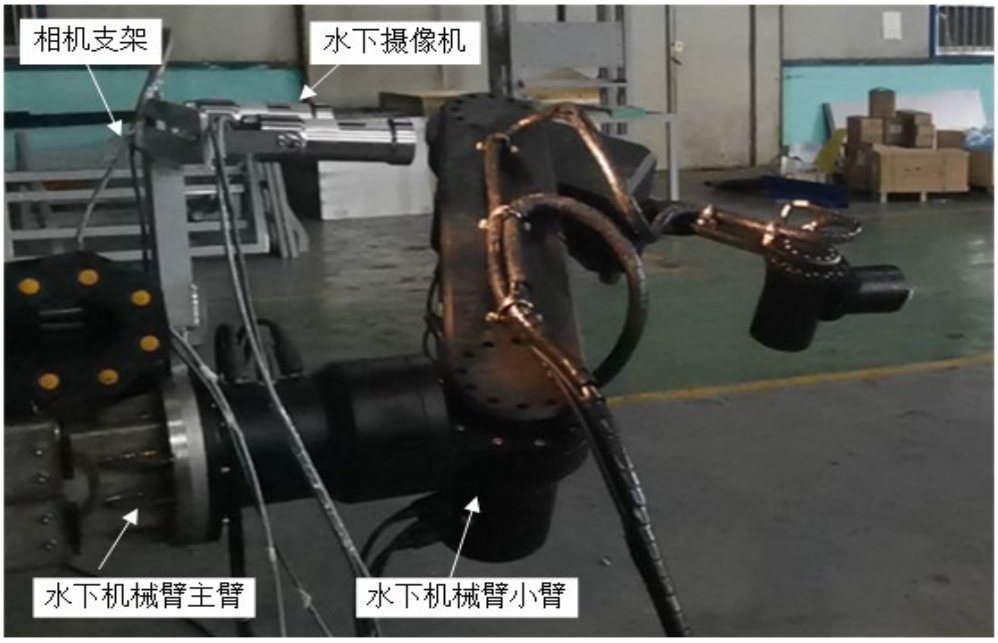


图2.3 水下整体实验设备

Fig.2.3 Underwater overall experimental equipment

本文的后续实验部分共选取了 UIEB、UCCS、UIQS、OceanDark、LSUI 以及 RISU 作为本文的数据集，以衡量各章清晰化方法的整体性能，部分水下图像示例如图 2.4 所示。上述基准数据集已广泛应用于不同清晰化技术的研究中，以验证不同清晰化方法的普适性和鲁棒性。本论文的定性与定量实验基于上述数据集展开，旨在全面评估不同清晰化方法在多种复杂水下环境下的有效性和鲁棒性。实验结果不仅为水下图像清晰化技术在实际工程应用中的性能提供有力的支持与理论依据，同时也为后续目标检测与自动抓取任务提供了高质量的输入数据。



图2.4 不同特点的水下光学图像

Fig.2.4 Underwater optical images with different characteristics

中国知网 https://www.cnki.net

2.6 本章小结

本章从水下光学的特性出发，首先着重介绍光在水介质中的传播、吸收以及散射效应，其次概述了水下光学成型模型和常用于主观和客观评价水下光学图像质量的指标，最后阐述了用于评估水下光学图像清晰化方法的数据集及本文在工业场景下构建的水下光学图像数据集。本章内容为后续水下图像清晰化技术研究和水下目标检测应用提供相关理论基础和数据支撑。

中国知网 https://www.cnki.net

第三章 基于局部白平衡和多尺度融合的水下图像清晰化方法

3.1 引言

在复杂且多变的水下环境中，由于水体本身对不同波长光的选择性吸收和散射效应，导致获得的水下光学图像具有绿色、蓝色及模糊的外观，严重限制了后续依赖于高质量输入图像的高级视觉任务。针对上述问题，通用的解决方案是将水下白平衡和图像融合技术相结合，以提升水下光学图像的质量[49,119]。然而，传统的水下白平衡方法未考虑水介质波长依赖性光吸收问题，导致增强图像引入额外的颜色信息或者颜色校正不准确。同时，光散射效应不仅降低图像的对比度，还引入模糊和雾霾现象，进一步影响后续视觉任务对于高质量输入图像的需求。此外，尽管图像融合技术能够通过结合多源信息显著改善水下光学图像的视觉质量，但该技术在实现时需根据特定水下应用设计合适的输入图像及权重图，从而影响了该技术的泛化性和普适性。

为了解决上述问题，本章提出了一种基于局部白平衡和多尺度融合的水下图像清晰化方法，该方法命名为 LAWB-MSF（Local Adaptive White Balance and Multi-Scale Fusion, LAWB-MSF）。具体而言，在 RGB 颜色空间，提出自适应通道补偿策略和线性拉伸以应对水介质吸收效应所导致的颜色失真问题，并获得拉伸图像。在此基础上，提出一种基于细化亮度图引导的融合策略，旨在充分利用拉伸图像和亮度图的优势，同时对局部颜色信息进行自适应调整，并抑制噪声干扰，从而获得白平衡图像。其次，为了改善进一步白平衡图像的对比度和纹理细节信息，设计了一种基于高频控制因子的锐化图像生成方法和一种多尺度融合方法。其中，前者将白平衡图像进行色彩空间变换，根据积分图快速计算 V 分量的局部均值以近似图像的低频分量，并引入高频控制因子融合低频和高频分量生成锐化图像。后者根据统计学方法构建清晰度和亮度权重图，并根据锐化图像和相应的权重图构建多尺度融合方法，以实现具有自然颜色和高能见度的增强图像。最后，定性与定量实验结果表明，所提方法可有效校正水介质中不同波长光的吸收差异所引起的颜色失真问题，并显著提升水下光学图像的清晰度和对比度。

LAWB-MSF 方法的整体流程如图 3.1 所示。

中国知网 https://www.cnki.net

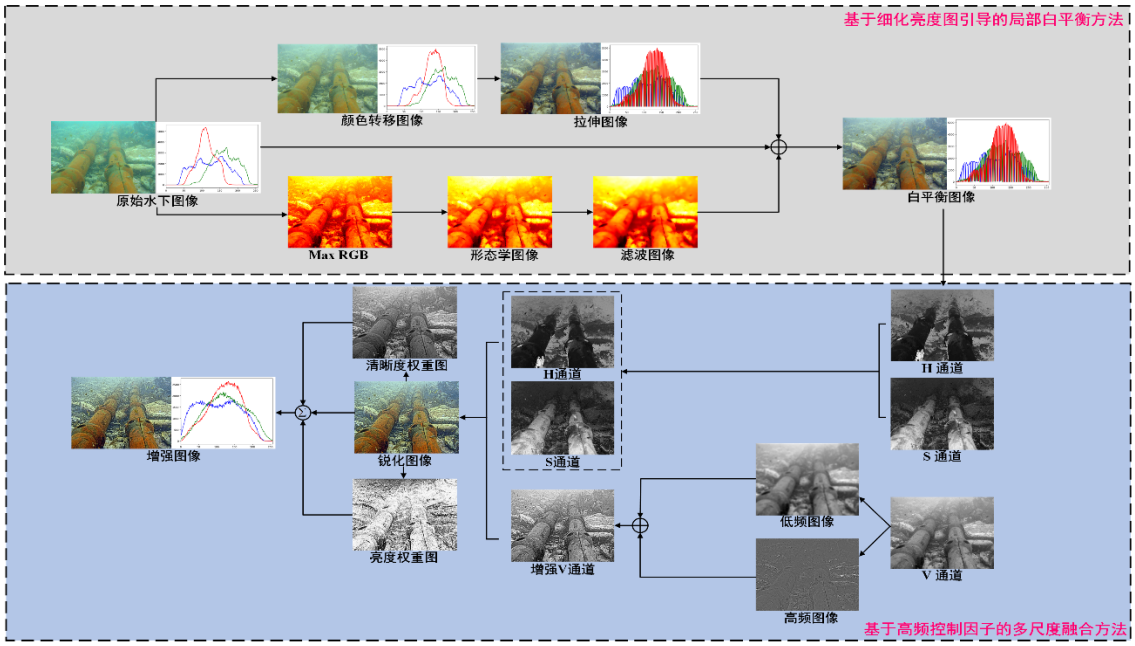


图3.1 所提方法的整体流程图

Fig.3.1 General workflow of the proposed method

3.2 基于细化亮度图引导的局部白平衡方法

由于水介质对不同波长光的吸收和散射效用，导致获得的原始水下光学图像通常具有颜色偏差、模糊和低对比度等退化问题。由于红色光在可见散谱中波长最长，因此在水中传播时受到的吸收和衰减最严重。而蓝色和绿色光波长较短，在水中能够穿透更远的距离，从而可保留更多的颜色与细节信息。图 3.2 展示了典型绿色、蓝色和蓝绿色外观的水下光学图像，其中包含每个颜色通道相应的直方图。

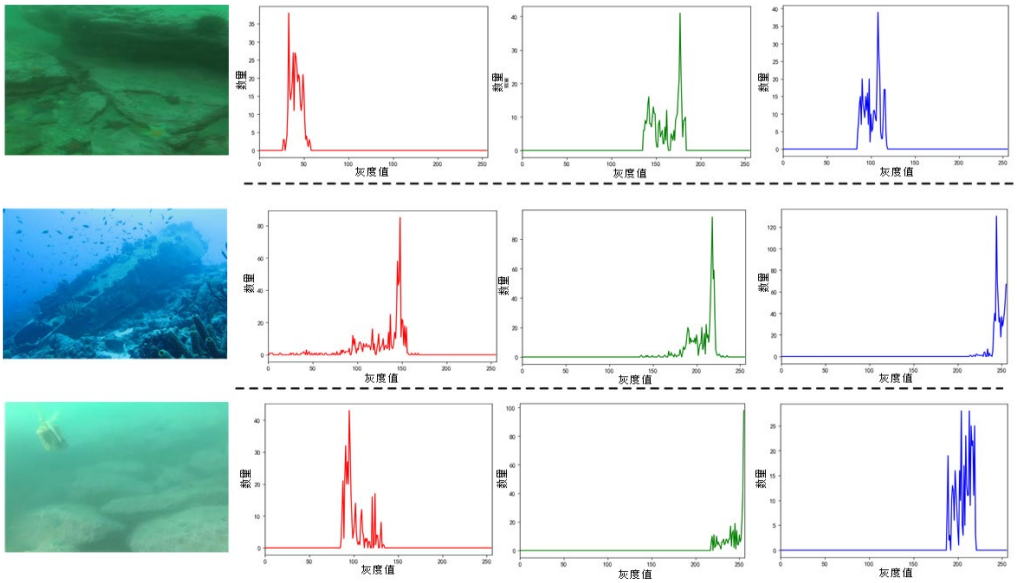


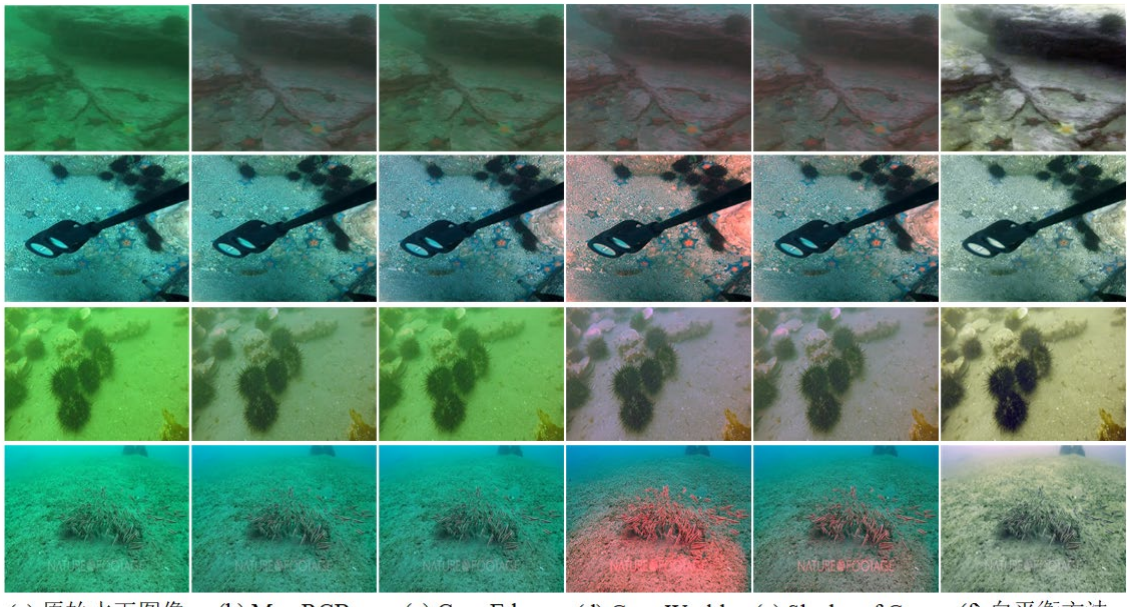
图3.2 具有不同外观的水下图像和相应的 RGB 直方图

Fig.3.2 Underwater images with different appearances and the corresponding RGB histograms

中国知网 https://www.cnki.net

通过分析图 3.2 中不同退化类型的水下图像可知，在偏绿色外观的水下图像中，绿色通道相比于其它通道会保留更加丰富的颜色信息。而在蓝色外观的水下图像中，蓝色通道会保留更多的颜色信息。此外，从各颜色通道的均值可知，在水下光学图像中总有一个通道的衰减程度远高于其它两个通道。综上所述，本节的目标是识别信息保留最丰富的颜色通道，该通道可以作为主颜色通道以自适应补偿衰减程度最严重通道的像素值。

传统白平衡方法对于不同颜色失真的水下图像校正结果如图 3.3 所示[116-119]。由于水介质独有的特性，传统白平衡方法难以有效校正图像的颜色失真现象并可能引入额外的颜色信息，如图 3.3(b)至图 3.3(e)所示。上述现象产生的原因可归因于传统白平衡方法主要面向陆地图像，而未考虑水介质对于不同波长的衰减特性，导致增强图像效果不佳。因此，本节提出一种局部白平衡方法以消除色偏的影响并保留水下图像固有的特性。该方法由三个核心部分组成：（1）构建自适应通道补偿策略以校正水下图像的颜色失真现象，从而生成颜色转移图像；（2）通过线性拉伸变换获得拉伸图像，以扩大颜色校正图像像素值的动态范围；（3）基于细化光照图引导的融合策略以结合原始水下图像、细化光照图和拉伸图像。



(a) 原始水下图像 (b) Max RGB (c) Gray Edge (d) Gray World (e) Shades of Gray (f) 白平衡方法

图3.3 不同白平衡方法的颜色校正图像

Fig.3.3 Color correction images of different white balance methods

3.2.1 颜色转移图像的生成

考虑到水介质对不同波长光的吸收作用，各颜色通道的衰减程度存在明显的差异[120]。根据上述现象，首先分别定义原始水下图像的红、绿和蓝通道的像素平

中国知网 https://www.cnki.net

均值：

$$\overline{I_c}=\frac{1}{HW}\sum_{i=1}^{H}\sum_{j=1}^{W}I_c(i,j),c\in\{R,G,B\} \tag{3-1}$$

其中，H 和 W 分别代表原始水下图像 I 的高和宽。对于蓝色外观的水下光学图像，短波长的蓝光相对于红光和绿光在水介质中传播的更远，因此蓝色通道颜色信息保留的更好。对于浑浊程度高的水下光学图像，由于散射会导致短波长光衰减程度高，因此在该情况下绿色通道颜色信息保留的更好。基于上述分析，本节根据每个通道的像素平均值确定主颜色通道，并利用它自适应补偿不同颜色通道的损失。因此，该自适应通道补偿策略可表示为：

$$\begin{cases}I_{Rc}(x,y)=I_R+(\overline{I}_G-\overline{I}_R)\times(1-I_R)\times I_G, & \overline{I_G}>\overline{I_B}\\ I_{Gc}(x,y)=I_G+(\overline{I}_B+\overline{I}_G)\times(1-I_G)\times I_B, & \overline{I_G}<\overline{I_B}\end{cases} \tag{3-2}$$

其中，I_R,I_G,I_B 分别代表原始水下图像的红、绿和蓝颜色通道，I_{Rc} 和 I_{Gc} 分别表示相应补偿后的红色和绿色通道。根据颜色补偿策略后获得的颜色通道，可导出初步的颜色校正图像，也可称为颜色转移图像。

颜色转移图像的灰度值分布普遍集中于整个灰度区间中的一半，因此影响了图像的对比度。为了进一步提高颜色转移图像中每个颜色通道的灰度占用率，本节引入线性拉伸操作使图像不同颜色通道的像素值尽可能地分布在整体灰度区间内，表达式为：

$$I_c^{LS}(x,y)=I_o^{\min}+(I_c^{CT}(x,y)-I_c^{\min})\frac{I_o^{\max}-I_o^{\min}}{I_c^{\max}-I_c^{\min}},c\in\{R,G,B\} \tag{3-3}$$

其中，I_c^{LS} 和 I_c^{CT} 分别代表拉伸图像和颜色转移图像，$I_o^{\min}$ 和 $I_o^{\max}$ 分别为拉伸图像灰度区间内的最小值和最大值。对于一幅 8 位深的图像而言，该值分别设置为 0 和 255。$I_c^{\min}$ 和 $I_c^{\max}$ 分别为颜色转移图像中每个颜色通道的最小像素值和最大像素值。

3.2.2 细化亮度图的估计

考虑到水体中悬浮颗粒物和微生物会影响光的强度和传播方向，导致拉伸图像中可能会引入额外的颜色信息。因此，本节提出一种基于细化亮度图引导的融合策略以局部调整输出图像的颜色和细节。该方法首先引入颜色恒常性方法[116]以获得初始亮度图。初始亮度图被定义为：

$$T(x,y)=\max_{c\in\{R,G,B\}}I_c(x,y) \tag{3-4}$$

其中，T 为初始亮度图，I 代表原始水下图像。值得注意的是，初始亮度图中普遍存在局部平滑的现象，这可能导致图像颜色信息分布不均匀，从而引起不自然的色

中国知网 https://www.cnki.net

偏或伪影。为了解决初始亮度图的局部平滑问题，本节构建形态学操作以生成细化亮度图，可以表示为：

$$T_{Refine}(x,y)=T(x,y)\circ B \tag{3-5}$$

其中，B 代表结构元素，$\circ$为形态学开运算。在亮度图细化过程中，选择形态学开运算是为了对图像进行平滑滤波，同时避免引入过度平滑和光晕现象。通过分析不同大小和形状的结构元素对细化亮度图的影响，最终选择大小为15×15的十字形作为结构元素。此外，由于细化亮度图可能受到高频噪声的干扰，采用引导滤波[121]可以有效抑制噪声，同时在图像中梯度变化不明显的局部区域处保持平滑，并增强图像的细节信息。上述滤波过程可描述为：

$$T_{output}(x,y)=a(x,y)\bullet V(x,y)+b(x,y) \tag{3-6}$$

其中，V 代表原始水下光学图像在 HSV 色彩空间中的 V 分量，T_{output} 代表最终的细化亮度图。其中参数a和b分别定义为：

$$\begin{cases} a=\dfrac{Cov(V(x,y),T_{Refine}(x,y))^{\omega}}{Var(V(x,y))^{\omega}+\varepsilon} \\ b=mean(T_{Refine}(x,y))^{\omega}-a\bullet mean(V(x,y))^{\omega} \end{cases} \tag{3-7}$$

其中，ω代表图像滤波窗口，设置为 5。$mean(\bullet)$为方框滤波操作，用于减少计算量。$\bullet$为逐像素相乘操作，参数ε设置为 0.004。

3.2.3 基于细化光照图引导的融合策略

基于上述分析，本节通过充分融合原始水下图像、拉伸图像和细化亮度图，以实现自适应地校正水下光学图像的颜色失真现象，并抑制由于前向散射效应产生的噪声问题。该融合策略可定义为：

$$I_c^{WB}=T_{output}I_c^{LS}+(1-T_{output})I_c \tag{3-8}$$

其中，T_{output}为最终的细化亮度图，I_c^{LS}和I_c分别代表拉伸图像和原始水下图像，c为红色、绿色和蓝色颜色通道，I_c^{WB}代表最终的白平衡图像。如图 3.3(f)所示，所提方法可有效校正水下光学图像中不同程度的颜色失真现象。

3.3 基于高频控制因子的多尺度融合方法

在第 3.2 节白平衡图像的基础上，采用基于高频控制因子的多尺度融合方法实现水下图像能见度和纹理细节信息的恢复，该方法主要由三个核心部分组成：（1）多尺度融合策略输入图像的生成；（2）设计相应的权重图；（3）构建拉普拉斯和高斯金字塔的多尺度图像融合框架。

中国知网 https://www.cnki.net

3.3.1 多尺度融合策略输入图像的生成

为了进一步提高增强图像的细节信息和对比度，本节提出一种基于高频控制因子的锐化图像生成方法。传统直方图均衡技术[122,123]虽然可有效提高图像的对比度，但容易产生增强不足和过度增强的现象。Ghani 等[124]提出基于瑞利分布的水下直方图拉伸方法通过拉伸和分离操作获得增强不足和过度增强的两幅图像，并根据两幅图像的特性进行融合以缓解上述问题。然而，该策略可能引入额外的颜色色调、局部欠曝光或过度曝光的问题。受文献[124]的启发，本节从图像局部区域块的角度出发，以实现图像高频信息从局部到全局的增强。图 3.4 展示了输入图像的生成流程。该方法首先将白平衡图像从 RGB 颜色空间转换为 HSV 颜色空间中，随后利用积分图计算 V 通道的平均值来近似获得图像的低频信息。图像的高频信息可通过原始 V 通道与低频信息相减获得。此外，引入高频控制因子以提高图像的高频分量。

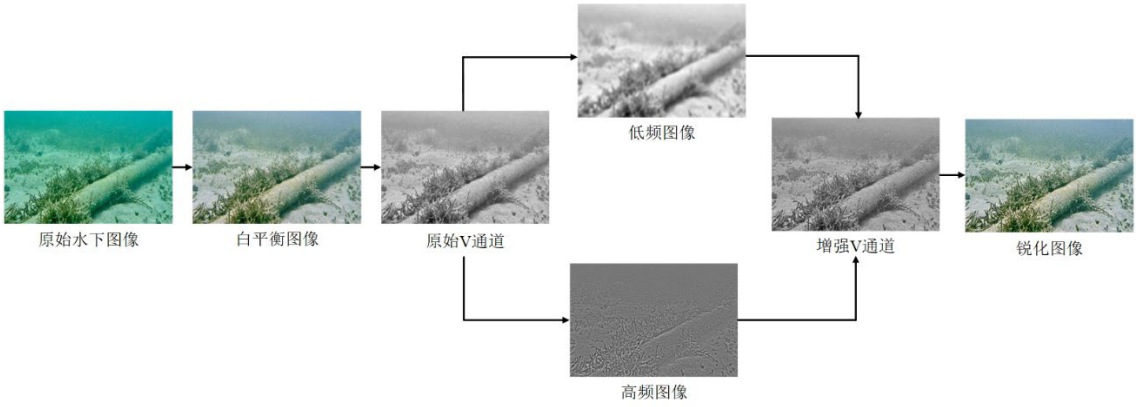


图3.4 锐化图像的生成流程图

Fig.3.4 Flowchart of sharpened image generation

首先将白平衡图像的 V 通道进行线性映射，该过程表示如下：

$$V_{new} = 2v_{wb} - 1 \tag{3-9}$$

其中，v_{wb} 代表白平衡图像在 HSV 色彩空间中的 V 通道，V_{new} 的动态范围被映射为 $[-1,1]$。随后，引入积分图操作以计算图像的低频分量，从而减少算法的计算复杂度。因此，该低频分量的计算表达式为：

$$V_L(x,y) = \frac{\sum_{x=i-h}^{i+h}\sum_{y=j-w}^{j+w} V_{new}(x,y)}{4hw}, i \in \mathbb{N}_{h:h+H-1}, j \in \mathbb{N}_{w:w+W-1} \tag{3-10}$$

其中，H 和 W 分别代表原始 V 通道的高和宽，h 和 w 分别为局部区域块的高和宽，$\mathbb{N}$ 为一个整数序列，$\sum_{x=i-h}^{i+h}\sum_{y=j-w}^{j+w} V_{new}(x,y)$ 是基于积分图计算的局部区域块中像素值的求和操作。上述方法将图像划分为相互重叠的局部区域块，在保证低频信息提取性能的同时保证了计算效率。综上所述，图像 V 通道的低频信息可以通过

中国知网 https://www.cnki.net

$V_L(x,y)$ 近似获取，则图像的高频信息可定义为：

$$V_H(x,y)=V_{new}(x,y)-V_L(x,y) \tag{3-11}$$

其中，V_{new} 为拓展值域后的 V 通道，V_L 为图像的低频信息，V_H 为图像的高频信息。为了提高图像的纹理细节信息，引入高频控制因子可以对图像高频信息进行增强。该过程可表示为：

$$V_{out}=(V_L(x,y)+GV_H(x,y)+1)/2 \tag{3-12}$$

其中，参数 G 为高频控制因子，V_{out} 代表增强后的 V 通道。最后，将 HSV 颜色空间转换回 RGB 颜色空间中以获得锐化图像，并将该图像作为拉普拉斯金字塔多尺度融合的输入。

3.3.2 权重图的设计

本节在锐化图像的基础上，通过设计清晰度和亮度权重图以描述输入图像的特征信息，使得通过多尺度融合方法所获得的增强图像具有高能见度和对比度。清晰度权重图旨在强调输入图像的高频信息。由于高频信息普遍集中于边缘、细节及灰度变化区域等图像中像素强度变化较大的区域，这就使得卷积核的选择成为了清晰度权重图设计的关键因素。综合上述分析，本节的目标是突出输入图像的高频信息部分，使得最终的增强图像具有丰富的纹理细节信息。受拉普拉斯滤波的启发，本节为了进一步强调图像的高频信息，将卷积核 $\mathcal{K}$ 设置为 $[0,1,0;\ 1,8,1;\ 0,1,0]$。因此，该清晰度权重图设计为：

$$W_S(x,y)=\mathcal{K}\otimes\frac{[G_I(x,y)]_R+[G_I(x,y)]_G+[G_I(x,y)]_B}{3} \tag{3-13}$$

其中，G_I 代表输入图像经过高斯滤波后的结果，$\otimes$ 为卷积运算。

亮度权重图旨在为曝光良好像素分配更高的增益因子以强调输入图像的亮度信息。对于高质量的水下光学图像，确保高能见度且避免曝光不足或过度曝光现象是至关重要。本节亮度权重图的设计是通过统计 UIEB 数据集中高质量参考图像的亮度信息来实现的。具体而言，每幅图像的亮度图通过公式(3-4)估计得到，并根据相应的亮度图计算均值和标准差。通过统计 890 幅高质量水下图像得到亮度图的平均值为 0.54，标准差为 0.23，水下图像的动态范围均归一化至 $[0,1]$ 之间。通过上述分析，亮度权重图设计为：

$$W_B(x,y)=\exp\left\{-\frac{(T(x,y)-0.54)^2}{2(0.23)^2}\right\} \tag{3-14}$$

其中，T 代表锐度图像的亮度图。

根据上述方法设计的清晰度和亮度权重图，相应的归一化权重图可定义为：

中国知网 https://www.cnki.net

$$\begin{cases} \bar{W}_S = W_S / (W_S + W_B) \\ \bar{W}_B = W_B / (W_S + W_B) \end{cases} \tag{3-15}$$

其中，W_S 和 W_B 分别代表清晰度权重图和亮度权重图，$\bar{W}_S$ 和 $\bar{W}_B$ 分别代表归一化的清晰度权重图和亮度权重图。

3.3.3 多尺度图像融合框架

根据第 3.3.1 节和第 3.3.2 节所获得的锐化图像和相应的归一化权重图，可直接利用锐化图像和相应的权重图进行加权融合，以生成最终的增强图像 $R(x)$。该过程可表示为：

$$R(x) = \bar{W}_S(x) \times I_S(x) + \bar{W}_B(x) \times I_S(x) \tag{3-16}$$

其中，$\bar{W}_S(x)$ 和 $\bar{W}_B(x)$ 分别代表归一化的清晰度和亮度权重图，$I_S(x)$ 代表生成的锐化图像。虽然直接融合锐化图像与权重图的方法能够一定程度上提升图像质量，但可能会引入伪影或光晕现象[48]。为了提高融合图像的视觉质量，目前广泛采用多尺度线性[125]或非线性滤波器[126]。然而，非线性滤波器的引入会显著增加算法的计算复杂度，限制了在实时应用中的可行性。因此，多尺度拉普拉斯和高斯金字塔[125]被广泛用于图像融合领域，以在不同尺度上提取和保留关键细节信息，且计算复杂度低。基于上述分析，构建拉普拉斯和高斯金字塔的多尺度图像融合框架以获得最终高质量的增强图像，具体过程可定义为：

$$R_M(x) = \sum_{n=1}^{2} G_k\{\bar{W}_n(x)\} L_k\{I_S(x)\} \tag{3-17}$$

其中，G_k 和 L_k 分别为高斯金字塔和拉普拉斯金字塔的层数。

为了验证多尺度融合策略与直接融合方法之间的差异，在不同基准水下数据集中利用无参考指标 UIQM 来定量衡量两种方法。如图 3.5 所示，红色为直接融合方法获得的定量评价指标值，蓝色为多尺度融合策略获得的定量评价指标值。

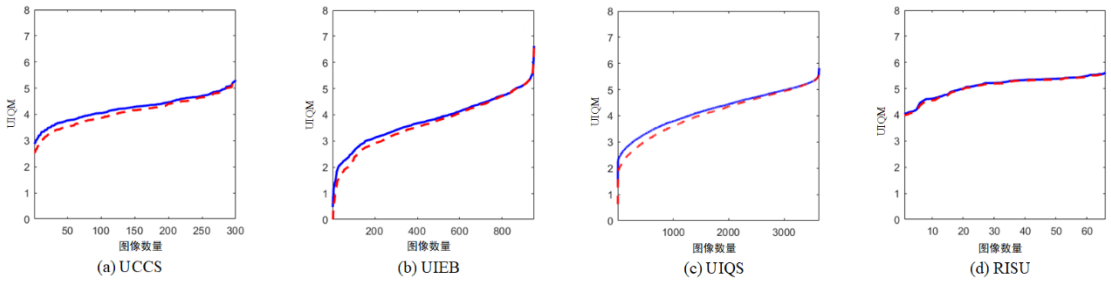


图3.5 直接融合和多尺度融合策略在不同水下数据集中的性能

Fig.3.5 Performance of direct and multi-scale fusion strategies in different underwater datasets

中国知网 https://www.cnki.net

观察可知，相比于直接融合的方法，多尺度融合策略可有效提高水下图像的质量。

3.4 实验结果与分析

本节首先讨论了不同局部区域块尺度和高频控制因子参数对最终增强效果的影响。其次，通过与目前主流水下光学图像清晰化方法在不同水下图像数据集中进行定性和定量的比较，以全面地评估所提方法的有效性和鲁棒性。最后，通过局部细节分析、消融实验以及实际应用实验进一步说明了本章方法的有效性。在比较实验中，本章方法与主流十种水下光学图像清晰化方法进行全面的对比，包括复原方法（UNTV[30]、IBLA[25]和 GDCP[127]）、增强方法（MLLE[52]、CBAF[49]、BRUIE[124]和 L2uwe[54]）以及数据驱动方法（Water-Net[65]、FUnIE-GAN[70]和 UD-Net[128]）。测试数据集采用 UCCS[114]、UIEB[65]、UIQS[114]和 RISU 水下数据集以定性和定量的衡量不同清晰化方法的增强性能。UCCS 数据集包含 300 幅具有不同外观的水下光学图像，用于评估不同方法的颜色校正能力。UIEB 数据集包含 950 幅不同水域类型和场景的水下光学图像，用于评估不同方法的普适性。UIQS 数据集包含 3630 幅不同色偏和能见度的水下光学图像，用于评估不同方法对于颜色校正和提高能见度方面的综合性能。RISU 数据集包含 66 幅不同深度和角度的水下光学图像，用于评估不同方法在工业水下环境中的鲁棒性。此外，本节选用五个常用于评价水下光学图像质量的无参考定量评价指标，分别是 UIQM[110]、UCIQE[111]、FADE[113]、AG[108]和 EI[109]。其中，UIQM 和 UCIQE 指标值越高，代表增强图像的视觉感知性能越好。FADE 指标值越小，代表增强图像的雾化程度越低。AG 和 EI 指标值越高，代表增强图像的能见度和边缘细节信息方面越好。

本节首先讨论了不同局部区域块尺度和高频控制因子参数设置对最终增强图像的影响。该实验采用 UCCS 和 UIQS 水下基准数据集，并选择 UIQM 定量评价指标以衡量不同参数设置对最终增强图像的影响。表 3.1 和表 3.2 展示了在 UCCS 和 UIQS 水下基准数据集中设置不同的局部区域块尺度 B 和高频控制因子 G 的定量评价结果。

表 3.1 在 UIEB 水下基准数据集上的参数敏感性分析

Tab. 3.1 Parameter sensitivity analysis on the UIEB underwater benchmark dataset

参数	B=6×6	B=10×10	B=14×14	B=18×18
G=1.1	4.055	4.105	4.102	4.088

中国知网 https://www.cnki.net

续表 3.1 在 UIEB 水下基准数据集上的参数敏感性分析

Tab. 3.1 Parameter sensitivity analysis on the UIEB underwater benchmark dataset (continued)

参数	B=6×6	B=10×10	B=14×14	B=18×18
G=1.2	4.426	4.468	4.456	4.432
G=1.3	4.561	4.576	4.554	4.524
G=1.4	4.560	4.544	4.511	4.474

表 3.2 在 UIQS 水下基准数据集上的参数敏感性分析

Tab. 3.2 Parameter sensitivity analysis on the UIQS underwater benchmark dataset

参数	B=6×6	B=10×10	B=14×14	B=18×18
G=1.1	4.065	4.112	4.108	4.094
G=1.2	4.359	4.394	4.380	4.358
G=1.3	4.432	4.436	4.413	4.385
G=1.4	4.383	4.357	4.324	4.290

综合分析表 3.1 和表 3.2 可知，在 LAWB-MSF 方法中 B 和 G 参数分别设置为 10×10 和 1.3 时可获得更稳定的增强性能。

3.4.1 主观定性实验

（1）UCCS 水下数据集

UCCS 数据集用于衡量不同清晰化方法的颜色校正能力。本节首先从 UCCS 中分别选择具有蓝绿色、蓝色和绿色外观的水下图像作为不同清晰化方法的输入图像。图 3.6 分别展示了使用 UNTV、IBLA、GDCP、MLLE、CBAF、BRUIE、L2uwe、Water-Net、FUnIE-GAN 和 UD-Net 十种清晰化方法所获得的增强图像。根据图 3.6 增强图像可知，对于蓝绿色外观的水下图像，UNTV、IBLA、GDCP 和 Water-Net 方法提高了水下图像的对比度，但 UNTV 方法存在蓝色色调，IBLA 方法对于绿色失真校正能力有限，GDCP 方法引入了红色色调，Water-Net 方法对于蓝色失真校正能力有限。BRUIE、L2uwe、FUnIE-GAN 和 UD-Net 方法提高了水下图像的纹理细节信息，但 BUUIE 和 UD-Net 方法均引入了红色色调，L2uwe 方法难以抑制图像的绿色失真，FUnIE-GAN 引入黄色色调。MLLE 和 CBAF 方法均可有效校正水下图像的颜色失真问题，但增强图像的纹理细节和对比度还有待进一步提升。对于蓝色外观的水下图像，UNTV、IBLA、L2uwe、Water-Net 和 FUnIE-GAN 方法的增强图像中均具有不同程度的蓝色色调，因此上述方法对于蓝色失真校正的能力有限。GDCP、MLLE、BRUIE 和 UD-Net 方法可有效提高图像对比度，但 GDCP 和

中国知网 https://www.cnki.net

BRUIE 方法引入了红色色调和区域暗区域，MLLE 和 UD-Net 方法存在微蓝色色调。CBAF 方法可有效校正蓝色失真，但由于蓝色散射的影响，导致增强图像产生模糊现象。对于绿色外观的水下图像，GDCP 和 L2uew 方法难以校正绿色失真。UNTV、IBLA、BRUIE、Water-Net、FUnIE-GAN 和 UD-Net 方法有效调整了绿色失真问题，但引入额外的颜色色调。MLLE 和 CBAF 方法可有效去除绿色色偏，但 CBAF 方法对于图像纹理细节方面增强不足，MLLE 方法引入局部暗区域。LAWB-MSF 方法不仅可有效去除各种颜色色偏的影响，还能明显改善图像的纹理细节信息和对比度。

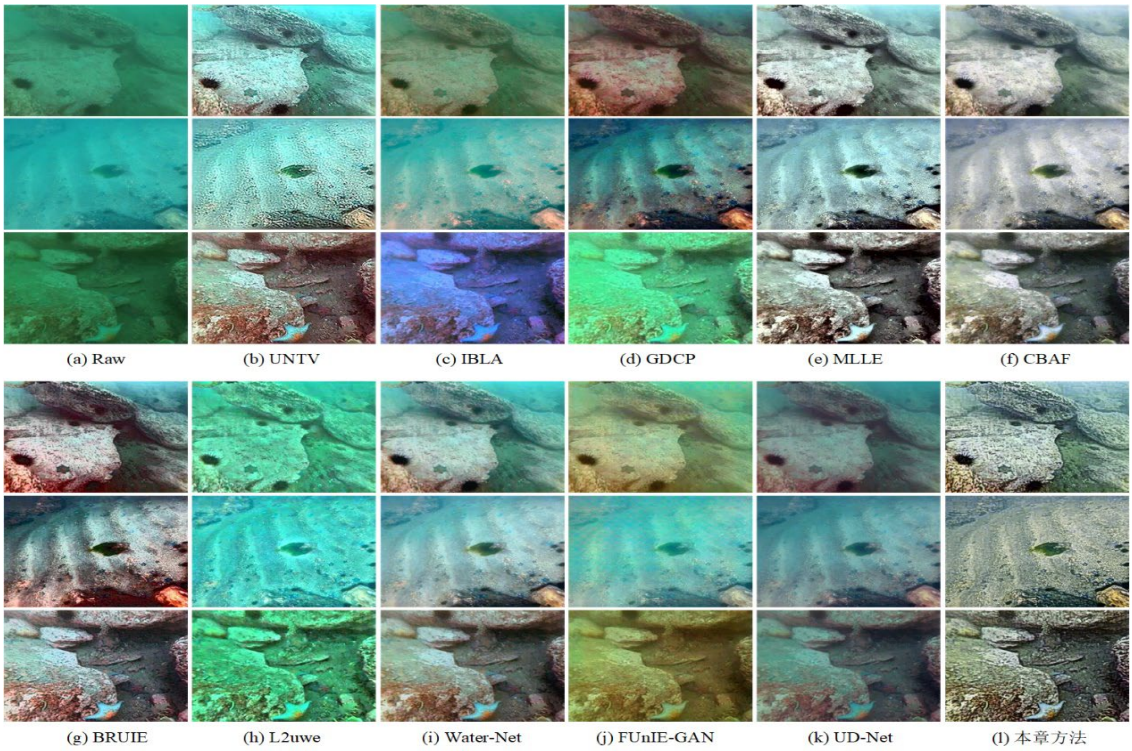


图3.6 主流水下清晰化方法在 UCCS 数据集上增强结果

Fig.3.6 Enhancement results of mainstream underwater sharpening methods on the UCCS dataset

（2）UIEB 水下数据集

为了进一步验证图像清晰化方法在不同水域类型和场景下的增强性能，本节从 UIEB 数据集中选择具有代表性的水下图像以验证不同方法的通用性和鲁棒性。如图 3.7 展示了模糊和深海场景的水下光学图像以及通过主流水下清晰化方法所获得的增强结果。根据图 3.7 相应的增强图像可以看出，对于具有模糊外观的水下图像，UNTV、CBAF 和 Water-Net 方法会导致图像整体偏暗，且 UNTV 方法引入额外的伪影现象。IBLA、GDCP 和 L2uwe 方法在抑制水介质后向散射效应的同时引入过度曝光现象。FUnIE-GAN 方法引入砖红色色调，UD-Net 方法无法有效去除模糊现象。虽然 MLLE 和 BRUIE 方法在去模糊和提高图像对比度方面具有良好的

中国知网 https://www.cnki.net

性能，但它们对于增强图像纹理细节信息的能力有限。对于深海场景的水下图像，IBLA、GDCP、MLLE、BRUIE、L2uwe、FUnIE-GAN 和 UD-Net 方法均无法改善该类水下光学图像的质量，其中伴随着过度增强、颜色失真和伪影的现象。UNTV 方法在一定程度上提高了图像的质量，但引入重影且还原目标颜色信息的能力有限。CBAF 和 Water-Net 方法的虽然可提高图像的能见度和整体视觉感知，但对于图像的纹理细节的增强能力有限。相比于上述方法，LAWB-MSF 方法有效校正了场景本身的颜色信息，并突出了图像的细节和能见度。

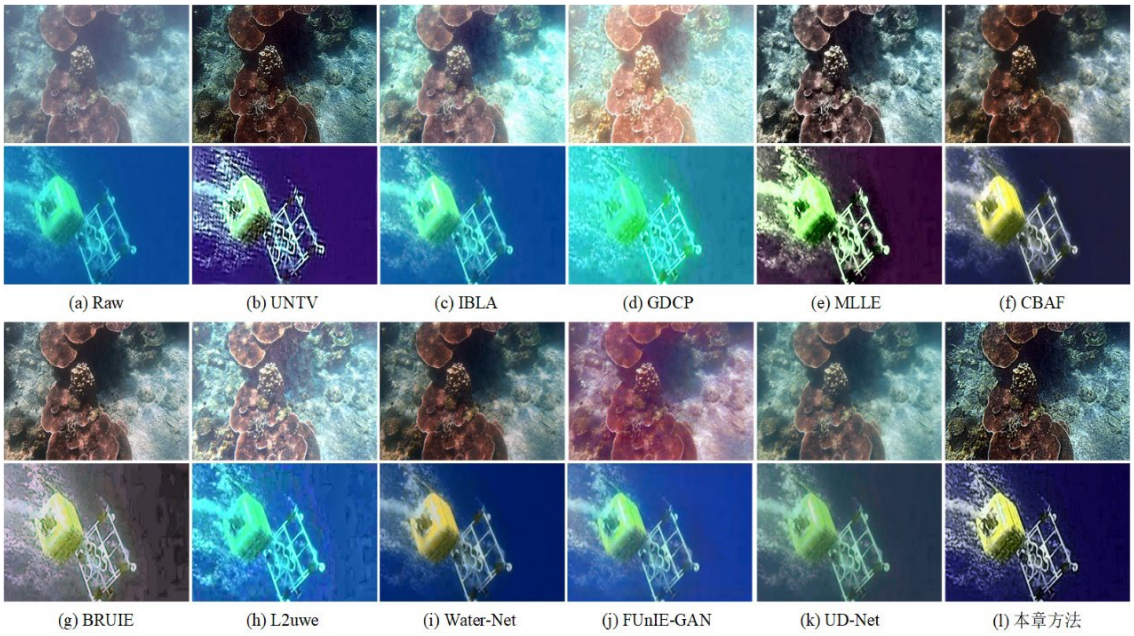


图3.7 主流水下清晰化方法在 UIEB 数据集上增强结果

Fig.3.7 Enhancement results of mainstream underwater sharpening methods on the UIEB dataset

（3）UIQS 水下数据集

此外，本节从 UIQS 数据集中选择具有丰富细节信息的水下光学图像以进一步验证不同图像清晰化方法的锐化能力。如图 3.8 所示，UNTV 方法可有效改善图像颜色失真的问题，但在图像背景处可能引入轻微的蓝色调。IBLA 方法难以有效校正绿色失真现象，且图像的对比度偏低。GDCP 方法的增强结果存在严重的过度曝光，且在增强图像中引入额外的暗红色调。MLLE 有效校正图像的色偏并改善局部对比度，但在图像的高亮区域处容易导致过度增强。CBAF 虽然校正了图像的色偏现象，但对于图像细节的锐化能力有限。BRUIE 提高了图像的对比度但引入额外的颜色信息。L2uwe 方法无法校正水下图像的颜色失真。Water-Net、FUnIE-GAN 和 UD-Net 方法可以显著降低色偏对增强图像的影响，但 Water-Net 和 UD-Net 方法在增强图像细节信息和锐化方面的能力有限，FUnIE-GAN 方法引入轻微的黄色调。相比于上述方法，LAWB-MSF 方法有效校正了图像的颜色失真，提高了图像

中国知网 https://www.cnki.net

的能见度和细节信息，并避免了饱和度不足和过度饱和现象。

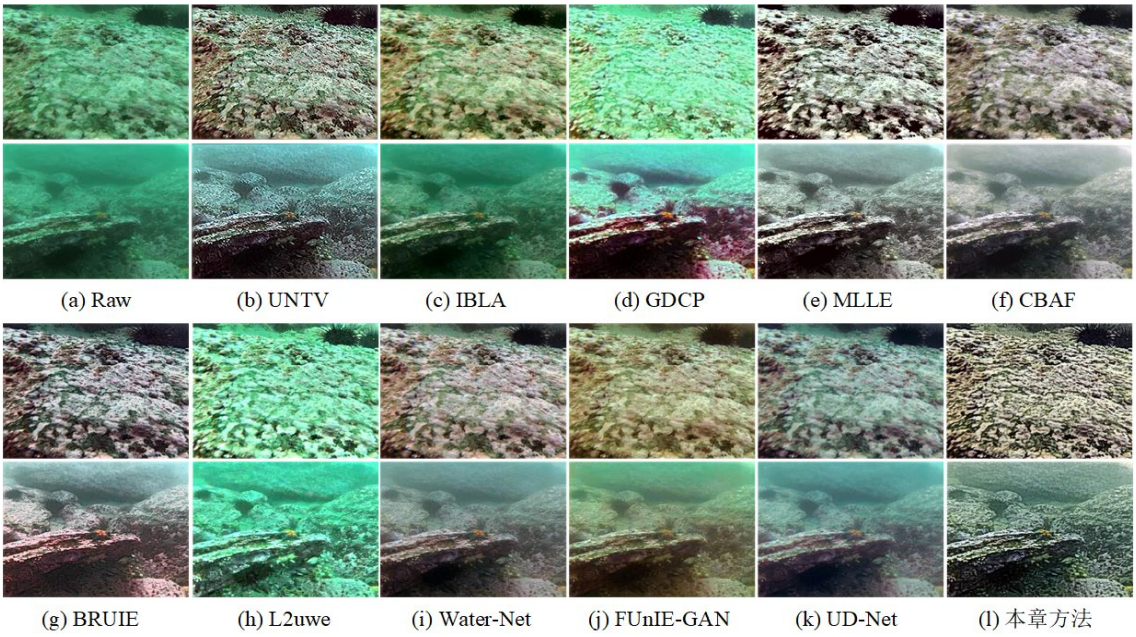


图3.8 主流水下清晰化方法在 UIQS 数据集上增强结果

Fig.3.8 Enhancement results of mainstream underwater sharpening methods on the UIQS dataset

（4）RISU 水下数据集

本节从 RISU 数据集中选择具有强后向散射类型的水下图像，以验证不同清晰化方法在实际应用中的性能。如图 3.9 展示了实际工业水下环境中的水下光学图像以及通过主流水下清晰化方法所获得的增强结果。

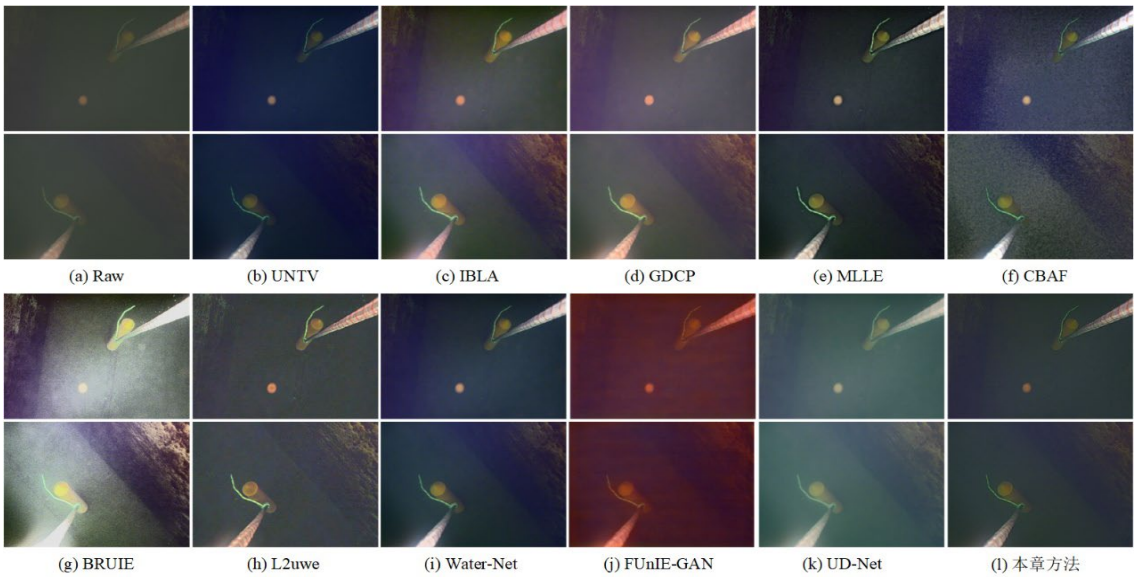


图3.9 主流水下清晰化方法在 RISU 数据集上增强结果

Fig.3.9 Enhancement results of mainstream underwater sharpening methods on the RISU dataset

根据图 3.9 相应的增强图像观察可知，UNTV 方法引入局部暗区域，且无法有效提高图像的整体亮度。IBLA、GDCP、MLLE、L2uwe 和 Water-Net 方法虽然有

中国知网 https://www.cnki.net

效提升了图像整体的可见性，但在处理靠近相机的区域时引入过度曝光现象。CBAF 方法虽然一定程度上去除了后向散射带来的模糊问题，但增强图像中引入了人工伪影现象。BRUIE 方法在目标区域处存在严重的过度增强。FUnIE-GAN 方法在增强图像中引入了额外的红色调。UD-Net 虽然有效提高了图像的能见度，但在去除工业水下环境中强后向散射方面的能力有限。相比于上述方法，LAWB-MSF 方法可有效抑制强后向散射带来的模糊问题。

3.4.2 客观定量实验

为了定量评估主流清晰化方法在不同特点水下光学图像上的增强性能，本节利用 UCCS、UIEB、UIQS 和 RISU 水下数据集进行了全面的定量比较。定量评价指标选择 UIQM、UCIQE、FADE、AG 和 EI 定量分析不同水下清晰化方法的有效性。由表 3.3 至表 3.6 的定量评价指标可知，所提方法在四个不同类型的水下数据集中均获得了有竞争力的实验结果，由此可以说明本章方法可有效提升不同退化类型水下光学图像的质量。具体而言，所提方法在四种水下数据集中获得了最佳的 FADE 评价指标，以及次优的 AG 和 EI 评价指标。在 UIQM、AG 和 EI 评价指标对比中，所提方法稍差于 BRUIE 和 FUnIE-GAN 方法。产生这一现象可归因于 BRUIE 和 FUnIE-GAN 方法通常在增强图像中引入额外的色彩信息和过度增强现象，从而引起 UIQM 指标中的 UISM 分量激增，导致获得了最高的 UIQM 值。UNTV 方法虽然获得了最高的 AG 指标，但该方法难以有效校正图像的颜色偏差并在图像增强的同时放大了内在噪声。所提方法在不同水下数据集中，均未获得最优的 UCIQE 值，产生这一现象的原因可归因于在实现水下光学图像颜色校正的同时可能使得图像中色度较为单一，从而影响所提方法的 UCIQE 值，但与 UNTV 方法所获得的最优值较为接近。

表 3.3 在 UCCS 水下数据集上的定量比较结果

Tab. 3.3 Quantitative comparison results on the UCCS underwater dataset

方法	UIQM	UCIQE	FADE	AG	EI
UNTV	3.980	0.593	0.297	132.294	6.085
IBLA	2.006	0.500	0.555	42.932	3.737
GDCP	2.480	0.531	0.485	47.282	3.955
MLLE	4.068	0.574	0.413	103.134	5.576
CBAF	3.814	0.541	0.776	58.439	4.574
BRUIE	4.649	0.593	0.383	95.511	5.602

中国知网 https://www.cnki.net

续表 3.3 在 UCCS 水下数据集上的定量比较结果

Tab. 3.3 Quantitative comparison results on the UCCS underwater dataset (continued)

方法	UIQM	UCIQE	FADE	AG	EI
L2uwe	1.246	0.461	0.294	77.393	5.282
Water-Net	3.501	0.556	0.650	51.352	4.480
FUnIE-GAN	4.056	0.503	0.448	38.493	3.812
UD-Net	3.653	0.504	0.759	38.921	3.653
本章方法	4.576	0.544	0.220	122.696	6.803

表 3.4 在 UIEB 水下数据集上的定量比较结果

Tab. 3.4 Quantitative comparison results on the UIEB underwater dataset

方法	UIQM	UCIQE	FADE	AG	EI
UNTV	3.349	0.608	0.363	117.843	4.729
IBLA	2.824	0.598	0.516	59.475	3.987
GDCP	2.664	0.603	0.361	57.676	3.610
MLLE	3.699	0.604	0.459	114.756	4.998
CBAF	3.627	0.591	0.664	61.257	4.174
BRUIE	4.328	0.586	0.582	88.784	4.949
L2uwe	2.420	0.558	0.343	96.684	5.257
Water-Net	3.434	0.571	0.570	50.865	3.992
FUnIE-GAN	4.488	0.564	0.420	49.665	4.057
UD-Net	2.961	0.544	0.712	45.249	3.634
本章方法	4.378	0.582	0.218	117.426	6.188

表 3.5 在 UIQS 水下数据集上的定量比较结果

Tab. 3.5 Quantitative comparison results on the UIQS underwater dataset

方法	UIQM	UCIQE	FADE	AG	EI
UNTV	4.050	0.599	0.283	127.448	5.905
IBLA	2.147	0.519	0.516	46.560	3.820
GDCP	2.592	0.535	0.503	49.433	3.874
MLLE	4.105	0.579	0.447	108.211	5.417
CBAF	3.783	0.545	0.753	60.336	4.464
BRUIE	4.577	0.593	0.388	98.809	5.503

中国知网 https://www.cnki.net

续表 3.5 在 UIQS 水下数据集上的定量比较结果

Tab. 3.5 Quantitative comparison results on the UIQS underwater dataset (continued)

方法	UIQM	UCIQE	FADE	AG	EI
L2uwe	1.559	0.480	0.296	84.715	5.328
Water-Net	3.659	0.563	0.620	53.834	4.499
FUnIE-GAN	4.286	0.516	0.407	40.884	3.849
UD-Net	3.815	0.519	0.744	41.552	3.696
本章方法	4.436	0.548	0.208	113.957	6.538

表 3.6 在 RISU 水下数据集上的定量比较结果

Tab. 3.6 Quantitative comparison results on the RISU underwater dataset

方法	UIQM	UCIQE	FADE	AG	EI
UNTV	5.122	0.507	0.339	63.322	5.232
IBLA	4.642	0.552	0.550	63.043	5.493
GDCP	4.364	0.493	1.225	17.504	1.661
MLLE	4.994	0.553	0.331	75.653	6.292
CBAF	5.358	0.560	0.539	78.515	6.450
BRUIE	5.193	0.551	0.477	108.962	6.669
L2uwe	5.146	0.530	0.393	92.864	7.234
Water-Net	5.160	0.540	0.572	43.929	5.005
FUnIE-GAN	6.286	0.485	0.485	17.956	2.128
UD-Net	3.849	0.466	1.093	27.033	3.744
本章方法	5.342	0.478	0.310	99.869	6.855

3.4.3 局部细节分析

对于高质量的水下光学图像而言，具有精细的局部细节信息对于后续计算机视觉任务的应用是至关重要的。因此，本节将对不同清晰化方法所获得的增强图像进行局部细节分析以进一步说明不同方法的有效性和实用性。图 3.10 展示了不同水下清晰化方法的局部细节图像。从增强图像的全局角度出发，所提方法有效抑制了原始图像的模糊和微蓝色的色偏现象，并避免图像中高亮度区域对最终增强图像的影响。从局部角度出发，所提方法保留了相邻像素间的相关性，在还原图像本身颜色信息的同时避免了额外的颜色失真，突出了图像的局部细节信息，如黄色和红色的局部区域放大图。

中国知网 https://www.cnki.net

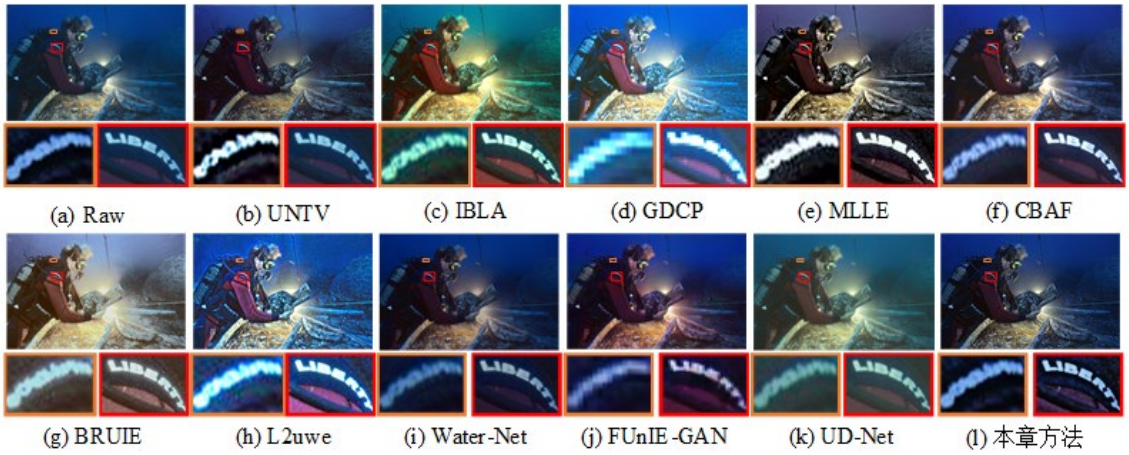


图3.10 主流水下清晰化方法的局部细节图像

Fig.3.10 Local detailed images of mainstream underwater sharpening methods

3.4.4 消融实验

为了验证所提方法中每个组件的有效性，本节在 UCCS、UIEB、UIQS 和 RISU 水下数据集上进行了一系列的消融实验。具体而言，分别消融自适应通道补偿策略、细化亮度图、高频控制因子和多尺度融合以获得最终的增强结果。如图 3.11 展示了在四个水下数据集上消融不同组件所获得的定性结果。

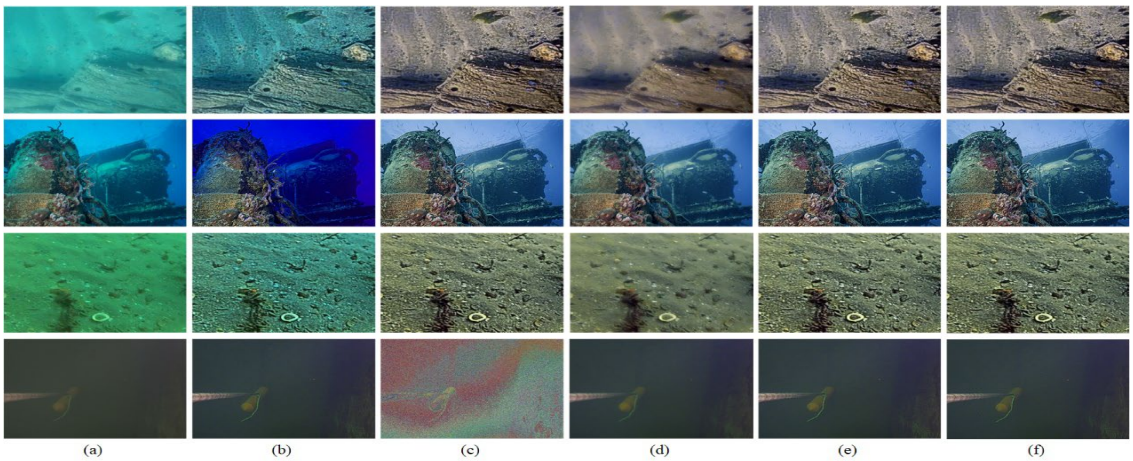


图3.11 消融实验的定性结果

Fig.3.11 Qualitative results of ablation experiments

由图 3.11(b)至图 3.11(e)观察可知，去除自适应通道补偿策略（Without Adaptive Channel Compensation Strategy, -w/o ACCS）后无法校正图像的色偏现象。去除细化亮度图（Without Refined Illumination Map, -w/o RIM）后无法去除图像中噪声的干扰。去除高频控制因子（Without High-frequency Control Factor, -w/o HCF）后图像产生模糊现象，难以提高图像的纹理细节信息。去除多尺度融合（Without Multi-scale Fusion, -w/o MSF）后增强图像具有不自然的外观。综上所述，包含上述所有

中国知网 https://www.cnki.net

组件的完整方法获得了令人满意的增强结果，如图 3.11(f)。

此外，本节使用 UIQM 评价指标对消融实验结果进行了定量评估。表 3.7 中的结果可以看出，包含完整组件的方法在四个数据集上实现了最均衡的增强性能，表明每个组件在提高所提方法的通用性和有效性方面均发挥着重要作用。

表 3.7 消融实验的定量比较结果

Tab. 3.7 Quantitative comparison results of ablation experiments

数据集	-w/o ACCS	-w/o RIM	-w/o HCF	-w/o MSF	完整方法
UCCS	3.403	4.577	3.317	4.530	4.576
UIEB	3.934	4.007	3.519	3.975	4.378
UIQS	3.437	4.427	3.405	4.383	4.436
RISU	5.335	3.123	4.492	5.303	5.342

3.4.5 应用实验

（1）水下低级视觉任务

为了进一步验证主流水下图像清晰化方法在实际工业水下场景中的鲁棒性与适应性，本节通过安装在机械臂主臂上的水下视觉采集设备获取不同深度、角度和目标物体的水下光学图像，整体实验设备如图 2.3 所示。

基于上述设备获得的水下图像，分别采用主流十种水下图像清晰化方法进行处理，并与本章所提方法进行对比分析。根据图 3.12 的增强图像可知，本章方法可有效地校正颜色失真现象，并显著提高水下图像的纹理信息并抑制噪声干扰。

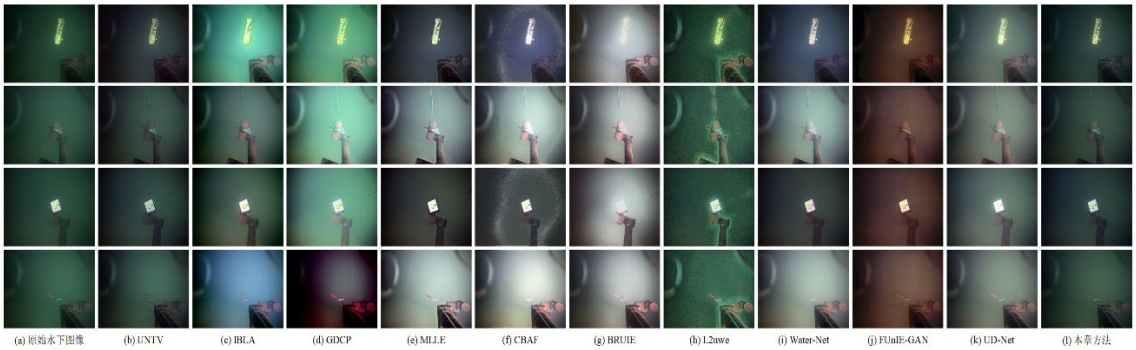


图3.12 水下低级视觉任务

Fig.3.12 Underwater low-level vision task

（2）水下高级视觉任务

图像分割旨在通过设计的特征信息将原始图像分成几个不相交且同质的区域。为了验证本章方法有助于提高图像分割的精度，本节采用基于超像素的模糊 C 均值聚类方法[129]实现水下图像的快速分割。如图 3.13 第三列和第四列展示了原始水

中国知网 https://www.cnki.net

下图像和增强图像作为输入时所获得的分割图像，证明所提方法作为预处理步骤时可有效提高图像的分割结果。

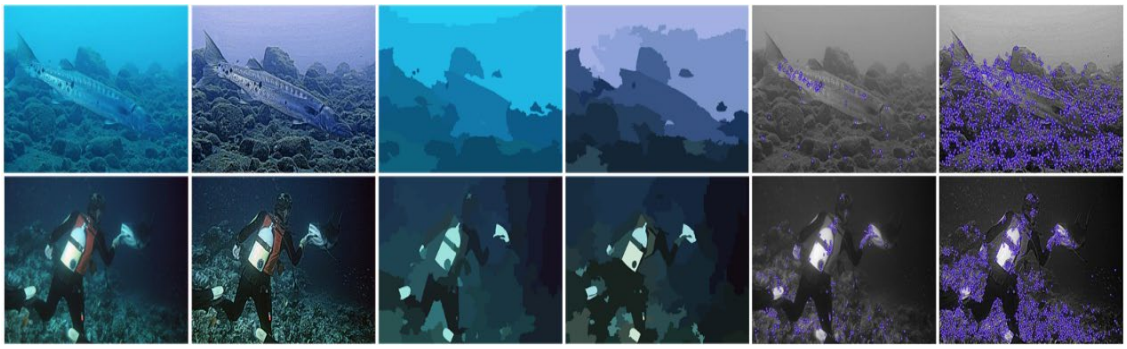


图3.13 水下高级视觉任务

Fig.3.13 Underwater high-level vision task

关键点检测作为计算机视觉中的基本任务，旨在计算图像中的关键点数目。具体而言，图像中提取的关键点数目越多有助于描述目标物体的轮廓和结构等特征信息，从而提高三维重建和人体姿态估计等高级视觉任务的性能。因此，本节采用 SURF 算法[130]分别从原始图像和增强图像中提取关键点，并计算相应关键点的数目。由图 3.13 第五列和第六列所示，原始水下图像获得的关键点数目分别为 69 和 300，而通过本章方法可显著提高关键点检测的数目，分别为 1417 和 1697。综上所述，所提方法可有助于提高后续高级水下视觉任务的性能，进一步证明该方法在水下实际应用中的重要性。

3.5 本章小结

针对水介质本身对不同波长光的选择性吸收和散射效应，本章提出一种基于局部白平衡和多尺度融合的水下图像清晰化方法。具体而言，针对水介质对不同光谱区域光的吸收特性，将自适应通道补偿和细化亮度图相结合，实现具有不同程度色偏水下图像的颜色校正。随后，根据积分图将白平衡图像分解为低频分量和高频分量，设计高频控制因子以获得多尺度融合策略的输入图像，并根据统计学方法设计清晰度权重图和亮度权重图以提高图像的细节信息和能见度。最后，在 UCCS、UIEB、UIQS 和 RISU 水下图像数据集上，通过定性和定量对比分析以及应用实验证明了本章方法的有效性和鲁棒性。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第四章 基于亮度图估计和自适应增益的水下图像清晰化方法

4.1 引言

相较于大气环境而言，水下环境具有更为复杂且多变的特性，并且光在水介质中传播时会受到水中物质的吸收和散射效应，导致水下光学图像能见度低。此外，在水下环境中，随着水深的增加，自然光会快速衰减，因此通常需要引入人工光源以改善水下光学图像的能见度。然而，人工光源传输的光线受到水介质本身吸收作用和悬浮颗粒物的散射作用，导致进入成像系统的光强度存在差异，从而产生光照不均匀的问题。并且人工光源容易导致水下光学图像中距离光源中心处过亮而其它区域过暗的现象，使得图像中的细节信息难以凸显，严重影响了图像的质量，而水介质本身的特性也会导致水下图像的颜色偏差和模糊。

受水介质特性和弱光（光照强度有限）的影响，水下光学图像普遍呈现出绿色、蓝色和局部暗区的现象。目前，针对弱光图像通用的解决方法包括直接放大法和基于 Retinex 理论两类。直接放大法[131]是直接对图像中像素值进行放大操作，以提高图像的全局亮度信息，但容易出现过度曝光或曝光不足的现象，导致增强图像丢失本身的细节信息。相比于直接放大法，基于 Retinex 理论的方法[116]将图像分解为照度分量和反射分量两部分，模拟了人类视觉系统对光照变化的适应能力，因此这类方法更适用于改善图像的亮度。Wang 等[132]通过扩展虚拟曝光增强器，并提出一种简单且高效的弱光图像增强方法。Zhang 等[45]拓展 MSR 算法到 LAB 色彩空间中，并根据每个通道的特点，使用双边和三边组合滤波器实现水下光学图像能见度的提高，但该方法在水下环境中容易引入额外的颜色失真，并且改善图像亮度的能力有限。Guo 等[133]提出一种通过细化亮度图的弱光图像增强方法，但该方法仅考虑大气环境下的弱光条件，难以适用于水下环境。综上所述，水下图像的非均匀照明使得传统弱光图像增强方法在水下场景中应用时存在挑战。

为了解决上述问题，提出了一种基于亮度图估计和自适应增益的水下图像清晰化方法，以提高非均匀照明影响下水下图像的能见度和清晰度，该方法命名为 BME-AG（Brightness Map Estimation and Adaptive Gain, BME-AG）。BME-AG 方法的整体结构如图 4.1 所示。具体而言，首先基于颜色空间变换和线性拉伸生成颜色转移图像，并引入最大衰减图以动态调整不同通道的颜色信息，从而有效改善水下图像中非均匀色偏现象。然后根据结构权重矩阵构建目标函数以自适应地调整不

中国知网 https://www.cnki.net

同通道的亮度值，并基于外点罚函数算法进行迭代求解以抑制水下图像中非均匀光照的挑战。同时，为了提高水下光学图像的清晰化和纹理信息，提出一种基于自适应增益控制函数的高频增强方法以实现对高频分量中不同像素自适应选择相应的增益系数，并设计颜色平衡策略以消除 H 和 S 颜色通道之间的信息差异，进而获得具有高质量的水下光学图像。

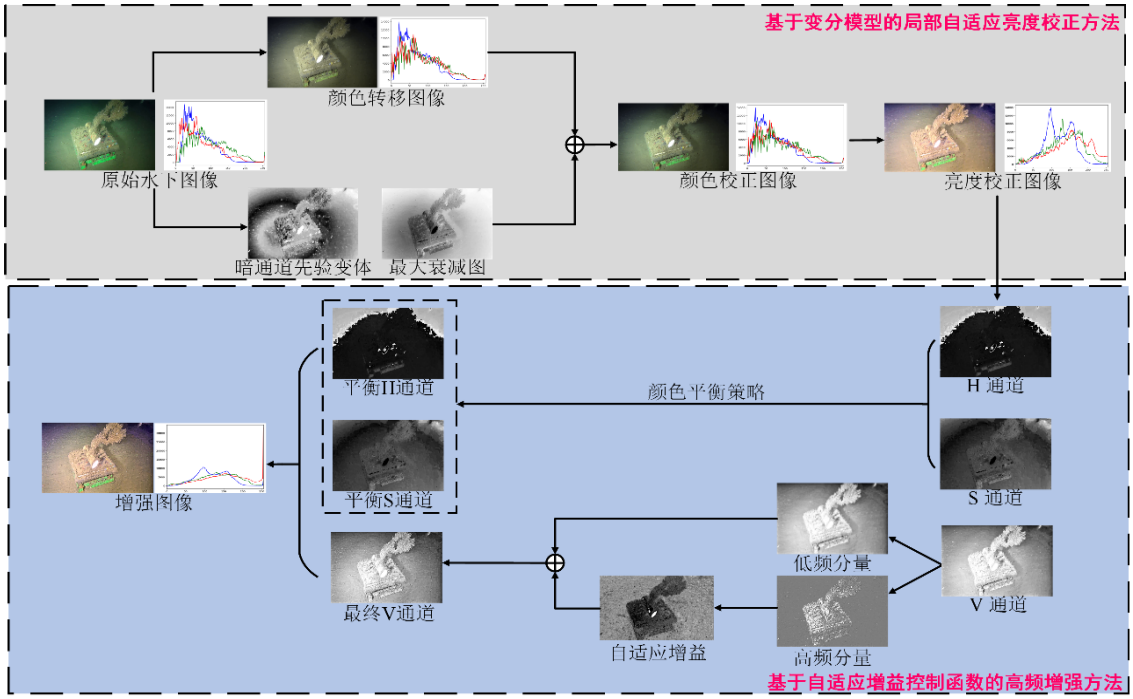


图4.1 所提方法的整体流程

Fig.4.1 The overall workflow of the proposed method

4.2 基于变分模型的局部自适应亮度校正方法

由于水介质对光的吸收和散射特性，以及有限照明的影响，水下光学图像通常呈现出蓝-绿色的整体色调，并具有局部黑暗区域。为了解决上述问题，本节提出一种基于变分模型的局部自适应亮度校正方法。该算法由三个核心部分组成：首先，基于颜色空间变换和线性拉伸快速获得颜色转移图像，以校正原始水下图像的色偏现象，并提高图像的对比度。其次，引入红通道先验估计不同颜色通道的衰减系数，以获得最大衰减图。最后，根据结构权重矩阵构建目标函数以自适应地调整不同通道的亮度，有效地去除图像中的局部暗区域。

4.2.1 颜色转移图像的生成

由于水介质本身的吸收作用，不同波长的光会发生衰减，即在水下光学图像的 RGB 色彩空间中，相应通道的像素强度降低。受 $l\alpha\beta$ 色彩空间的启发[134]，本节提

中国知网 https://www.cnki.net

出一种基于颜色空间变换的方法以获得颜色转移图像。该颜色空间变换的数学表达式为：

$$\begin{bmatrix} I_L \\ I_M \\ I_S \end{bmatrix} = \begin{bmatrix} 0.3811 & 0.5783 & 0.0402 \\ 0.1967 & 0.7244 & 0.0782 \\ 0.0241 & 0.1288 & 0.8444 \end{bmatrix} * \begin{bmatrix} I_R \\ I_G \\ I_B \end{bmatrix} \tag{4-1}$$

其中，I_R, I_G, I_B分别代表原始水下图像的红、绿和蓝颜色通道，I_L, I_M, I_S分别代表变换后的长，中和短波长通道，$*$为矩阵多项式乘法操作。由于经过颜色空间变换后图像的灰度区间主要集中在整个灰度区间的上半部分，从而导致图像对比度的降低。为了提高图像的对比度，引入线性拉伸提高图像灰度区间的占用率，具体操作如下：

$$I_c^S = I_o^{\min} + (I_c - I_c^{\min}) \frac{I_o^{\max} - I_o^{\min}}{I_c^{\max} - I_c^{\min}}, c \in \{L, M, S\} \tag{4-2}$$

其中，I_c^S代表颜色转移图像，$I_c^{\min}$和$I_c^{\max}$分别代表图像在 LMS 色彩空间中最小和最大的像素值，$I_o^{\min}$和$I_o^{\max}$分别表示待拉伸区间的间隔，设置为 0 和 1。

4.2.2 基于暗通道先验变体的融合策略

由于灰度世界假设忽略了水介质与波长依赖的光吸收特性，因此可能引入额外的颜色信息，如图 4.2 所示。在图 4.2(a)和图 4.2(b)中，基于暗通道先验的白平衡方法[49]（图 4.2 第二行）和局部自适应颜色校正方法[52]（图 4.2 第三行）在处理不同外观的水下图像时，容易在增强图像中引入额外的颜色色调和局部暗区域。为了解决上述问题，本节通过引入一种暗通道先验变体[20]估计不同颜色通道的衰减系数。该先验的数学定义为：

$$J_{RDCP}(x) = \min(\min_{y \in \Omega(x)} (1 - I_L^S(y)), \min_{y \in \Omega(x)} (I_M^S(y)), \min_{y \in \Omega(x)} (I_S^S(y))) \approx 0 \tag{4-3}$$

其中，I_L^S、I_M^S和I_S^S分别代表颜色转移图像的三个颜色通道，$\Omega(x)$为以x为中心的图像局部区域。此外，由于人工照明的引入会导致图像中部分像素强度过高，从而影响不同通道衰减系数的估计。因此，为了解决人工照明对水下图像的影响，可以在暗通道先验变体中引入饱和度。该饱和度定义为：

$$I_{Sat}^S = \frac{\max(I_L^S, I_M^S, I_S^S) - \min(I_L^S, I_M^S, I_S^S)}{\max(I_L^S, I_M^S, I_S^S)} \tag{4-4}$$

因此，联合饱和度的暗通道先验变体可表示为：

$$\begin{aligned} J_{RDCP-Sat}(x) = \min(&\min_{y \in \Omega(x)} (1 - I_L^S(y)), \min_{y \in \Omega(x)} (I_M^S(y)), \\ &\min_{y \in \Omega(x)} (I_S^S(y)), \min_{y \in \Omega(x)} (I_{Sat}^S(y))) \approx 0 \end{aligned} \tag{4-5}$$

中国知网 https://www.cnki.net

综上所述，本节使用暗通道先验变体以估计水下图像中每个颜色通道的衰减系数。具体而言，选择$J_{RDCP-Sat}$中最高的像素值作为每个颜色通道的衰减系数，并计算最大衰减图以生成融合策略的输入图像。具体计算过程如下式：

$$I^{A}_{\max} = \max\{A_L I^{S}_{L}, A_M I^{S}_{M}, A_S I^{S}_{S}\} \tag{4-6}$$

其中，A_L、A_M和A_S分别为不同颜色通道的衰减系数。随后，提出一种高效的图像融合策略，通过最大程度地结合最大衰减图与颜色转移图像之间的特征信息以实现局部自适应校正图像色偏的能力。因此，该融合策略可定义为：

$$I^{cc} = I^{A}_{\max} I_c + (1 - I^{A}_{\max}) I^{S}_{c} \tag{4-7}$$

其中，I^{S}_{c}代表颜色转移图像，$I^{A}_{\max}$为最大衰减图，I^{cc}代表颜色校正图像。图 4.2 第四行展示了本节方法获得的颜色校正图像。

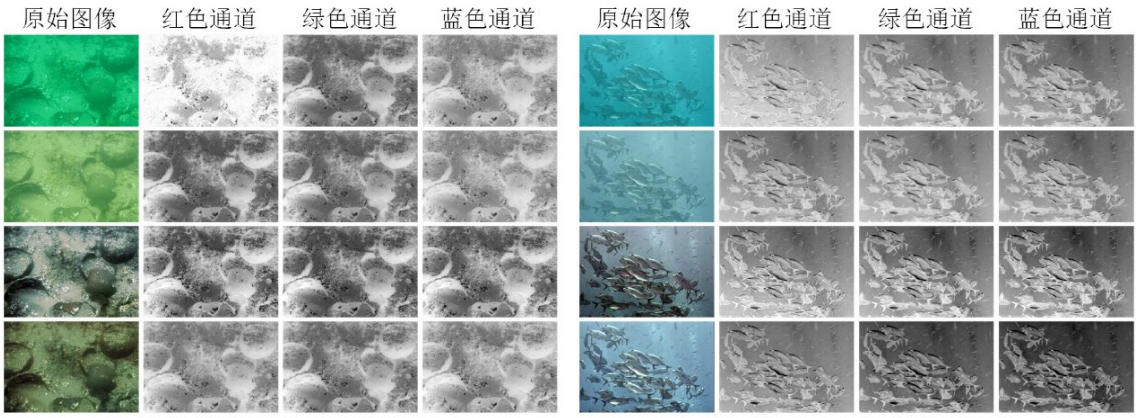


图4.2 不同颜色校正方法的结果以及相应的衰减图

Fig.4.2 Results of different color correction methods and corresponding attenuation maps

4.2.3 基于变分模型的亮度图估计

针对水下非均匀照明问题，本节提出一种基于变分模型的亮度图估计方法以进一步提高水下图像的可见性并保留图像的整体结构。首先，初始亮度图的定义为：

$$\hat{T}(x) = \max_{c \in \{R,G,B\}} I^{cc}(x) \tag{4-8}$$

其中，I^{cc}代表颜色校正图像，x代表图像中的像素位置。为了保留图像的整体结构和纹理细节信息，本节将变分项合并到原始模型中以获得细化亮度图。因此，整体优化模型可表示为：

$$\min_{T} \left\| \hat{T} - T \right\|_F^2 + \alpha \left\| W \circ \nabla T \right\|_1 \tag{4-9}$$

其中，α为平衡因子，$\|\bullet\|_F$和$\|\bullet\|_1$分别为弗罗贝尼乌斯和ℓ_1范数，W为权重矩阵，∇T为一阶导数滤波器，由水平分量和垂直分量两部分组成。操作$\circ$代表逐元素乘法。

中国知网 https://www.cnki.net

在公式(4-9)中，第一项$\left\|\hat{T}-T\right\|_F^2$代表保真度项，用于平衡初始亮度图和细化亮度图之间的差异。第二项$\alpha\left\|W\circ\nabla T\right\|_1$代表变分项，用于衡量图像的整体平滑度。因此，上式可改写为：

$$\min_{T,G}\left\|\hat{T}-T\right\|_F^2+\alpha\left\|W\circ\mathcal{Z}\right\|_1,\ s.t.\ h_1(T)=\nabla T-\mathcal{Z}=0 \tag{4-10}$$

基于公式(4-10)，构建外点罚函数方法以解决上述的等式约束优化问题。因此，公式(4-10)可进一步可改写为：

$$\Phi(T,r)=\left\|\hat{T}-T\right\|_F^2+\alpha\left\|W\circ\mathcal{Z}\right\|_1+r^{(t)}\sum_{v=1}^{p}[h_v(T)]^2 \tag{4-11}$$

其中，r为惩罚因子，是一个递增的正数序列。p设置为 1，h_v为等式约束。上述优化问题可通过迭代法进行求解，则具体更新过程如下：

1）更新T：根据公式(4-11)，选择与变量T相关的项，计算其导数并将整体设置为 0。上述过程可表示为：

$$2(T-\hat{T})+2r^{(t)}D^T(DT-\mathcal{Z}^{(t)})=0$$

$$\Downarrow$$

$$T=(2I+2r^{(t)}D^TD)^{-1}(2\hat{T}+2r^{(t)}D^T\mathcal{Z}^{(t)}) \tag{4-12}$$

其中，I代表与输入图像尺寸相同的单位矩阵，D和Z分别由水平和垂直两个分量组成。求解公式(4-12)中细化亮度图T的关键在于计算矩阵$2I+2r^{(t)}D^TD$的逆。然而，直接计算上述矩阵的逆矩阵会带来昂贵的计算消耗。为了解决上述限制，引入快速傅里叶变换（Fast Fourier Transform, FFT）提高计算速度。因此，求解细化亮度图T的过程可表示为：

$$T^{(t+1)}\leftarrow\mathcal{F}^{-1}\left(\frac{\mathcal{F}(2\hat{T}+2r^{(t)}D^T\mathcal{Z}^{(t)})}{2+2r^{(t)}\sum_{d\in\{h,v\}}\overline{\mathcal{F}(D_d)}\circ\mathcal{F}(D_d)}\right) \tag{4-13}$$

其中，$\mathcal{F}(\bullet)$代表将实数域的卷积操作转换到频率域乘法操作的 FFT 变换，$\mathcal{F}^{-1}(\bullet)$和$\overline{\mathcal{F}}(\bullet)$分别代表逆 FFT 变换和相应的共轭复数。

2）更新$\mathcal{Z}$：根据公式(4-12)，舍弃与$\mathcal{Z}$无关的项，则上述优化问题可简化为：

$$\mathcal{Z}^{(t+1)}\leftarrow\arg\min_{\mathcal{Z}}\alpha\left\|W\circ\mathcal{Z}\right\|_1+r^{(t)}\sum_{v=1}^{p}[h_v(T)]^2 \tag{4-14}$$

其中，$r^{(t+1)}\leftarrow cr^{(t)}$代表惩罚因子，$c$为递增系数。因此，公式(4-14)的封闭解可表示为：

$$\mathcal{Z}^{(t+1)}=S_{\frac{\alpha W}{2r^{(t)}}}[\nabla T^{(t+1)}] \tag{4-15}$$

中国知网 https://www.cnki.net

其中，$S_\theta[\bullet]$代表收缩操作，该运算可定义为$S_\theta[x]=\mathrm{sgn}(x)\max(|x|-\theta,0)$。$W$为权重矩阵，包含水平和垂直两个方向。

针对水介质所独有的特性，进一步考虑了不同波长光的衰减，即利用本身图像信息以细化亮度图。首先，根据颜色校正图像计算每个通道的像素平均值：

$$\overline{I}_c^{cc}=\frac{1}{HW}\sum_{i=1}^{H}\sum_{j=1}^{W}I_c^{cc}(i,j),c\in\{R,G,B\} \tag{4-16}$$

其中，H和W分别为颜色校正图像的高和宽。随后，图像的全局平均值可计算为：

$$\overline{I}_{mean}^{cc}=\frac{\overline{I}_R^{cc}+\overline{I}_G^{cc}+\overline{I}_B^{cc}}{3} \tag{4-17}$$

最后，对于不同颜色通道相应的细化亮度图可定义为

$$T_c^B(x,y)=\frac{\overline{I}_c^{cc}}{\overline{I}_{mean}^{cc}}T(x,y),c\in\{R,G,B\} \tag{4-18}$$

其中，T为细化亮度图。

综上所述，基于 Retinex 理论可获得最终的亮度校正图像，即：

$$I_c^{BC}(x,y)=I_c^{cc}(x,y)/T_c^B(x,y),c\in\{R,G,B\} \tag{4-19}$$

其中，I^{cc}代表颜色校正图像，T_c^B为不同颜色通道的细化亮度图，I_c^{BC}代表最终的亮度校正图像。

4.3 基于自适应增益控制函数的高频增强方法

尽管基于变分模型的局部自适应亮度校正方法对于恢复水下图像的颜色偏差和改善图像整体亮度是至关重要的，但对于水介质本身散射作用所引起的图像纹理和边缘细节丢失问题仍然存在挑战。受广义非锐化掩模（Generalized Unsharp Masking, GUM）[135]的启发，本节提出了一种基于自适应增益控制函数的高频增强方法以提高图像的高频信息。此外，为了恢复具有自然外观的水下图像，引入一种色彩平衡策略以平衡不同颜色通道之间的差异。

4.3.1 自适应增益控制函数的设计

传统高频增强方法通常通过引入高频控制因子改善图像的纹理和边缘细节信息，但该参数的选择往往依赖于大量实验的统计分析或是基于特定的先验知识进行设计。因此，这种方式在不同的水下环境中普适性较差，从而导致出现增强不足或过度增强的现象。针对上述问题，本节提出一种自适应增益控制函数以提高水下图像的高频细节信息。具体而言，首先将亮度校正图像从 RGB 色彩空间转换为 HSV 色彩空间。随后，将原始 V 通道的动态范围映射至区间$[-1,1]$之间。该映射

中国知网 https://www.cnki.net

操作如下：

$$v_e = 2I_v^{BC} - 1 \tag{4-20}$$

其中，I_v^{BC} 代表亮度校正图像的 V 通道，v_e 代表拓展值域后的 V 通道。计算 V 通道低频分量的方法与第 3.3.1 节相同，通过引入积分映射操作计算每个图像块的平均值。该计算过程可表示为：

$$v_{low} = \frac{\sum_{x=i-h}^{i+h}\sum_{y=j-w}^{j+w} v_e}{4hw},\ i \in \mathbb{N}_{h:h+H-1}, j \in \mathbb{N}_{w:w+W-1} \tag{4-21}$$

其中，H 和 W 分别表示原始水下图像的高和宽，h 和 w 分别表示局部图像块的高和宽。随后，引入对数比方法[136]表征图像原始 V 通道和低频分量部分，该非线性函数定义为：

$$\Phi(x) = \log(\frac{1+x}{1-x+\tau}) \tag{4-22}$$

其中，x 代表拓展 V 通道的灰度矩阵，τ 为一个极小的数以避免分母为 0 的情况。因此，图像的高频分量计算如下：

$$v_{high} = \Phi^{-1}(\Phi(V_e) - \Phi(v_{low})) \tag{4-23}$$

由上述分析可知，为了增强图像的纹理和边缘细节信息，本节在高频分量部分引入自适应增益控制函数，以实现在高频分量中对不同像素自适应选择相应的增益系数。则该函数的定义为：

$$\Gamma = \alpha + \beta e^{-|v_{high}|^{\rho}} \tag{4-24}$$

其中，ρ 是衰减率，α 和 β 定义为：

$$\begin{cases} \beta = (\theta_{\max} - \theta_{\min}) / (1 - e^{-1}) \\ \alpha = \theta_{\max} - \beta \end{cases} \tag{4-25}$$

其中，$\theta_{\max}$ 为最大增益值，$\theta_{\min}$ 为最小增益值。本节在提高图像高频分量的同时不希望平滑图像中的低频分量，因此 $\theta_{\min}$ 设置为 1。根据上述自适应增益控制函数对图像的高频分量进行增强，即：

$$v_h = \Phi^{-1}(\Gamma \bullet \Phi(v_{high})) \tag{4-26}$$

其中，$\bullet$ 为逐元素矩阵乘法操作，v_{high} 代表图像的高频分量，Γ 为 V 通道的自适应增益矩阵。

最后，融合图像低频和高频分量的最终 V 通道可表示为：

$$v_f = \frac{\Phi^{-1}(\Phi(v_{low}) + \Phi(v_h)) + 1}{2} \tag{4-27}$$

其中，v_f 代表最终的 V 通道，该通道的动态范围被映射回 $[0,1]$。

中国知网 https://www.cnki.net

为了定性分析不同$\theta_{\max}$对图像高频信息的影响，本节通过固定$\theta_{\min}=1$时设置不同$\theta_{\max}$获得图 4.3 所示的增强图像。观察可知，当$\theta_{\max}$值设置过小，会导致图像高频信息增强不充分，如图 4.3(c)和图 4.3(d)所示。然而，当$\theta_{\max}$值设置过大，虽然可有效增强图像的细节信息并避免过度饱和的现象，但会产生不自然的增强结果，如图 4.3(f)所示。通过综合统计分析后发现，当参数$\theta_{\max}$和局部块尺寸分别设置为 7 和5×5时，提出方法实现了鲁棒且平衡的增强效果。

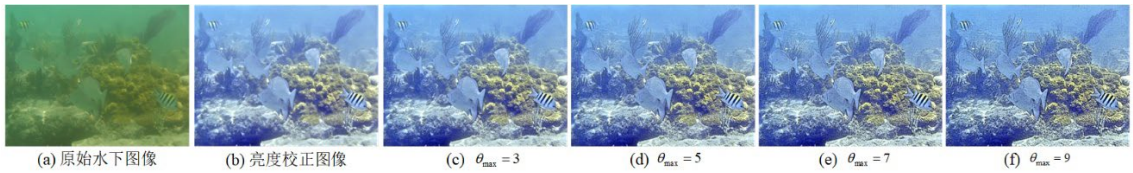


图4.3 设置不同$\theta_{\max}$所获得的增强结果

Fig.4.3 Enhancement results for different $\theta_{\max}$

4.3.2 颜色平衡策略的构建

此外，为了进一步获得具有自然外观的增强图像，本节引入简单且高效的颜色平衡策略以消除 H 和 S 颜色通道之间的信息差异。该平衡策略定义如下：

$$\begin{cases} I_{BS}=I_S+(\overline{I}_H-\overline{I}_S)\times(1-\overline{I}_H)\times\overline{I}_S, \overline{I}_H>\overline{I}_S \\ I_{BH}=I_H+(\overline{I}_S-\overline{I}_H)\times(1-\overline{I}_S)\times\overline{I}_H, \overline{I}_H<\overline{I}_S \end{cases} \tag{4-28}$$

其中，I_H和I_S分别代表亮度校正图像在 HSV 色彩空间中的 H 和 S 通道，$\overline{I}_H$和$\overline{I}_S$分别代表 H 和 S 通道的平均值。

4.4 实验结果和分析

为了验证所提方法的有效性，本节通过与目前主流的水下光学图像复原、增强和基于数据驱动的方法在水下弱光数据集中进行了定性和定量的比较。最后，通过局部细节分析、消融实验以及实际应用实验进一步说明了所提方法的有效性。具体而言，本章方法与主流十种水下光学图像清晰化方法进行了全面的对比实验，包括复原方法（IBLA[25]、GDCP[127]、UNTV[30]、CRUI[137]和 MILH[27]）、增强方法（BRUIE[124]、L2uwe[54]和 WDF-CHS[138]）和数据驱动方法（WaterNet[65]和 FUnIEGAN[70]）。测试数据集：选择 OceanDark 水下数据集[54]和工业水下数据集。OceanDark 数据集由加拿大海洋网络公司提供，包含 183 幅弱光水下图像，以评估不同方法对弱光图像的增强能力。此外，工业水下数据集是通过安装在机械臂主臂上的水下视觉采集设备获取水下图像数据，整体实验设备如图 2.3 所示。该数据集由 38 幅具有不同姿态的棋盘格图像组成，以评估不同方法在实际标定任务中的性

中国知网 https://www.cnki.net

能。定量评价指标：本节使用了六个常用于水下光学图像的无参考评价指标，分别是 AG[108]、EI[109]、CCF[112]、FADE[113]、UIQM[110]和 UCIQE[111]。

4.4.1 主观定性实验

本节使用 OceanDark 数据集以验证主流水下增强方法对不同光照强度图像的亮度校正能力。图 4.4(a)展示了在次优光照场景（人工照明、绿色外观、蓝绿色外观、非均匀照明、深海和后向散射）下捕获的六幅代表性水下图像。

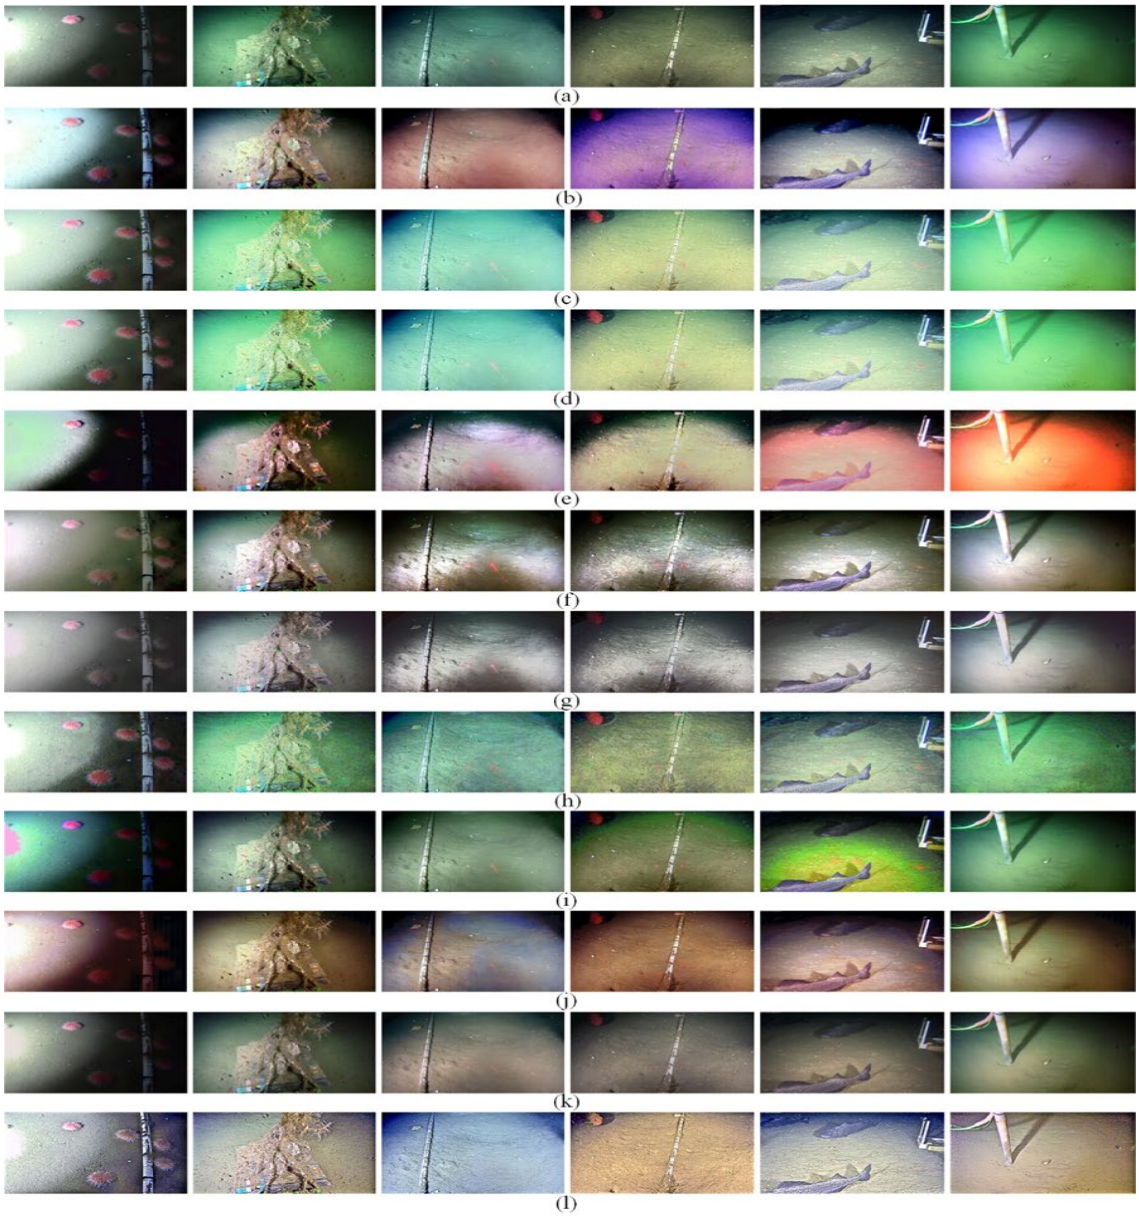


图4.4 不同清晰化方法在 OceanDark 数据集上的定性结果

Fig.4.4 Qualitative results of different sharpening methods on the OceanDark dataset

由图 4.4 观察可知，对于人工照明场景下的水下图像，主流水下清晰化方法 IBLA、GDCP、UNTV、CRUI、MILH、BRUIE、L2uwe、WDF-CHS、WaterNet 和

中国知网 https://www.cnki.net

FUnIEGAN 难以有效提高图像中局部黑暗区域的能见度。对于绿色外观的水下图像，GDCP、UNTV、WDF-CHS 和 L2uwe 方法无法有效校正图像的色偏。此外，由于水介质对不同波长光的吸收作用，导致水下光学图像中红色通道的信息丢失最严重。因此，常用的解决方案是利用其它颜色通道的信息补偿红色通道所丢失的像素值。然而，IBLA 和 CRUI 方法过度补偿了红色通道，导致增强结果中引入了额外的红色色调。虽然 GDCP 和 MILH 方法有效改善了图像的色偏现象，但对图像中局部暗区域的增强能力有限。基于数据驱动的方法（WaterNet 和 FUnIEGAN）受限于训练数据集中样本的多样性和分布，阻碍了它们对弱光水下图像的增强能力。综上所述，对于其它类型的水下弱光图像，主流方法生成的增强图像中往往会引入不同程度的颜色失真现象，并且改善能见度和细节信息方面的能力有限。相比而言，BME-AG 方法能够有效提高水下弱光图像的能见度和细节信息，同时减少颜色失真和伪影现象的出现，如图 4.4(l)所示。

4.4.2 客观定量实验

为了定量评估主流方法在水下弱光图像上的增强效果，本节采用六个无参考评价指标以衡量不同清晰化方法的性能。表 4.1 展示了本章方法与十种水下光学图像清晰化方法测试在 183 幅水下弱光图像的 AG、EI、CCF、FADE、UIQM 和 UCIQE 定量评价指标的平均值。由表 4.1 的数据可知，本章方法相比于其它水下清晰化方法在多数情况下获得了最优的 AG、EI、CCF、FADE、UIQM 和 UCIQE 定量评价指标，同时在所有评价指标中（除 FADE 指标）获得了最高的平均值。具体而言，UCIQE 指标用于定量评估增强图像的色度、饱和度和亮度。虽然主流方法可在一定程度上提高弱光图像的能见度，但容易引入过度饱和的现象，从而使得 UCIQE 指标中亮度分量激增，得到获得了最高的 UCIQE 指标。CCF 指标用于评估增强图像的色彩度、模糊度和雾度。由图 4.4 定性结果可知，IBLA 方法引入了严重的颜色失真，导致 CCF 指标中色彩度分量显著增加，因此获得了最高的 CCF 指标。UIQM 指标用于评估增强图像的清晰度、对比度和色彩饱和度。本章方法获得了最高的 UIQM 指标，证明了可有效提高水下弱光图像的对比度和清晰度。此外，所提方法获得了最低的 FADE 指标，验证了在去雾方面的有效性。

表 4.1 在 OceanDark 水下数据集上的定量比较结果

Tab. 4.1 Quantitative comparison results on the OceanDark underwater dataset

方法	AG	EI	CCF	FADE	UIQM	UCIQE
IBLA	29.973	2.513	29.069	0.770	2.156	0.596

中国知网 https://www.cnki.net

续表 4.1 在 OceanDark 水下数据集上的定量比较结果

Tab. 4.1 Quantitative comparison results on the OceanDark underwater dataset (continued)

方法	AG	EI	CCF	FADE	UIQM	UCIQE
GDCP	33.156	2.928	16.751	0.994	1.686	0.561
UNTV	46.968	2.809	21.098	0.712	3.022	0.546
CRUI	26.089	2.271	19.638	1.208	2.404	0.589
MILH	31.656	2.617	22.269	1.118	2.437	0.583
BRUIE	36.000	3.084	12.433	1.511	2.708	0.505
L2UWE	64.456	5.132	26.603	0.497	3.427	0.569
WDF-CHS	25.887	2.121	20.998	0.866	1.997	0.588
WaterNet	23.230	2.165	10.821	1.368	2.403	0.533
FUnIEGAN	25.457	2.403	20.533	0.719	3.336	0.587
本章方法	113.393	5.559	28.569	0.355	4.830	0.563

4.4.3 局部细节分析

对于水下视觉任务而言，具有精细细节和清晰边缘的增强图像有助于提高视觉任务的应用效果。因此，从全局和局部两方面比较不同水下清晰化方法和本章方法获得的增强图像，如图 4.5 所示。从全局视觉感知方面，本章方法显著提高了水下图像的亮度、对比度和可视性，并且有效校正了颜色失真现象。从局部细节方面，本章方法显著提高了图像的高频细节信息，如图 4.5 中蓝色框内的局部区域。

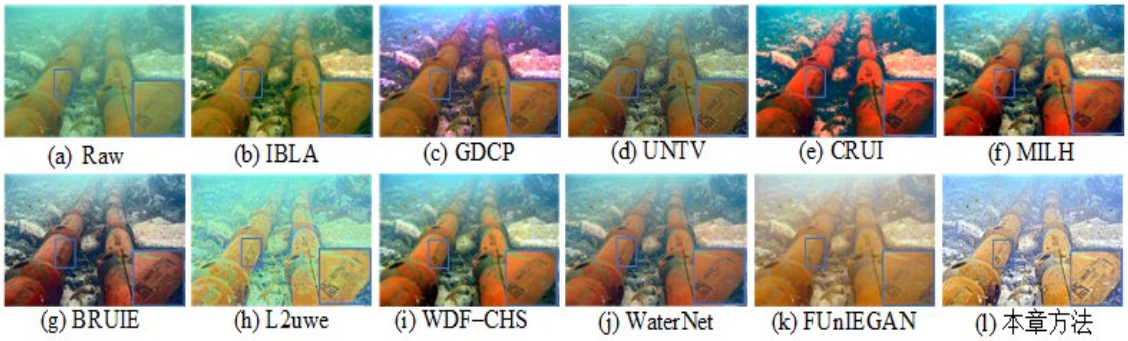


图4.5 主流水下清晰化方法的局部细节图像

Fig.4.5 Local detail images of mainstream underwater sharpening methods

4.4.4 消融实验

为了验证本章方法中每个核心模块对整体方法性能的影响，本节在 OceanDark 数据集上设计了一系列的消融实验，主要包括去除基于最大衰减图的色彩校正

中国知网 https://www.cnki.net

（Without Color Correction Image, -w/o CCI），去除基于变分模型的亮度图估计（Without Refined Illumination Image, -w/o RII），去除基于自适应增益控制的高频信息增强（Without Adaptive Gain Control Function, -w/o AGCF）和去除颜色平衡策略（Without Color Balance Strategy, -w/o CBS）。图 4.6 展示了本章方法通过依次消融上述四个核心模块在水下弱光图像的定性增强结果。观察可知，去除 CCI 模块无法有效校正水下图像的颜色偏差，去除 RII 模块无法显著改善水下图像的可见性和局部暗区域，去除 AGCF 模块对于提升水下弱光图像的高频细节信息能力不足，去除 CBS 模块无法校正增强图像中存在的轻微色彩偏差。包含全部核心模块的完整方法有效校正了颜色失真现象，提高了弱光图像的能见度并增强了图像的纹理细节信息。



图4.6 消融实验的定性结果

Fig.4.6 Qualitative results of ablation experiment

此外，为了进一步验证所提方法中各核心模块对最终增强性能的影响，本节设计了系统的消融实验。具体而言，构建了四个去除不同模块的消融模型，并采用六个定量指标以评估不同消融模型的增强性能。由表 4.2 数据可知，包含所有核心模块的本章方法在 OceanDark 数据集上获得最高的定量指标值，这表明每个模块在所提出的方法中均发挥着重要作用。

表 4.2 不同组件的定量消融结果

Tab. 4.2 Quantitative ablation results of different components

方法	AG	EI	CCF	FADE	UIQM	UCIQE
-w/o CCI	62.568	4.704	24.196	0.534	3.611	0.551
-w/o RII	49.041	3.870	18.633	0.567	3.584	0.549
-w/o AGCF	34.167	3.007	18.398	1.021	2.775	0.545
-w/o CBS	65.527	4.852	21.306	0.561	4.168	0.546
完整方法	91.694	5.372	25.420	0.418	4.637	0.555

中国知网 https://www.cnki.net

4.4.5 应用实验

（1）水下低级视觉任务

为了验证主流水下图像清晰化方法在实际工业水下场景中的鲁棒性与适应性，本节通过安装于机械臂主臂末端的水下视觉采集设备，在不同水深、拍摄角度和不同目标物体条件下获取了真实的水下光学图像，整体实验设备如图 2.3 所示。

基于上述设备获取到的水下图像，分别采用主流的十种水下图像清晰化方法进行图像增强处理，并与本章所提方法进行对比分析，如图 4.7 所示。由图 4.7 增强图像可知，本章方法可有效抑制水下非均匀照明的干扰，并显著改善水下光学图像的能见度和纹理信息。



图4.7 水下低级视觉任务

Fig.4.7 Underwater low-level vision task

（2）水下高级视觉任务

为了进一步验证所提方法在实际水下场景中的可行性，本节利用安装在水下机械臂上的双目相机采集不同位置和姿态的棋盘格图像，用于实现水下双目相机的标定任务。图 4.8 展示了通过左右水下相机获得的部分原始水下棋盘格图像。由于原始水下棋盘格图像具有能见度且模糊的特点，导致难以准确检测和匹配双目图像中相应的角点。

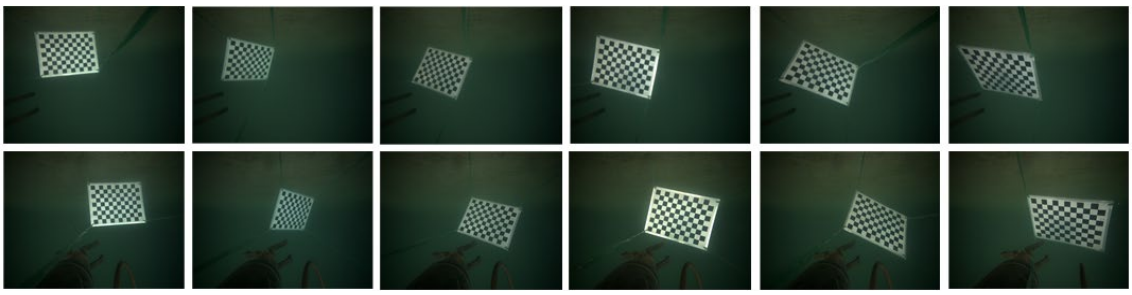


图4.8 原始水下棋盘格图像的部分示例

Fig.4.8 Partial examples of raw underwater checkerboard images

为了抑制退化水下图像对双目标定的影响，本节采用上述十种主流水下清晰

中国知网 https://www.cnki.net

化方法以提高原始图像的清晰度和能见度。选择图 4.8 中首幅水下棋盘格图像作为样本，通过十种主流水下清晰化方法和本章方法生成相应的增强图像，如图 4.9 所示。

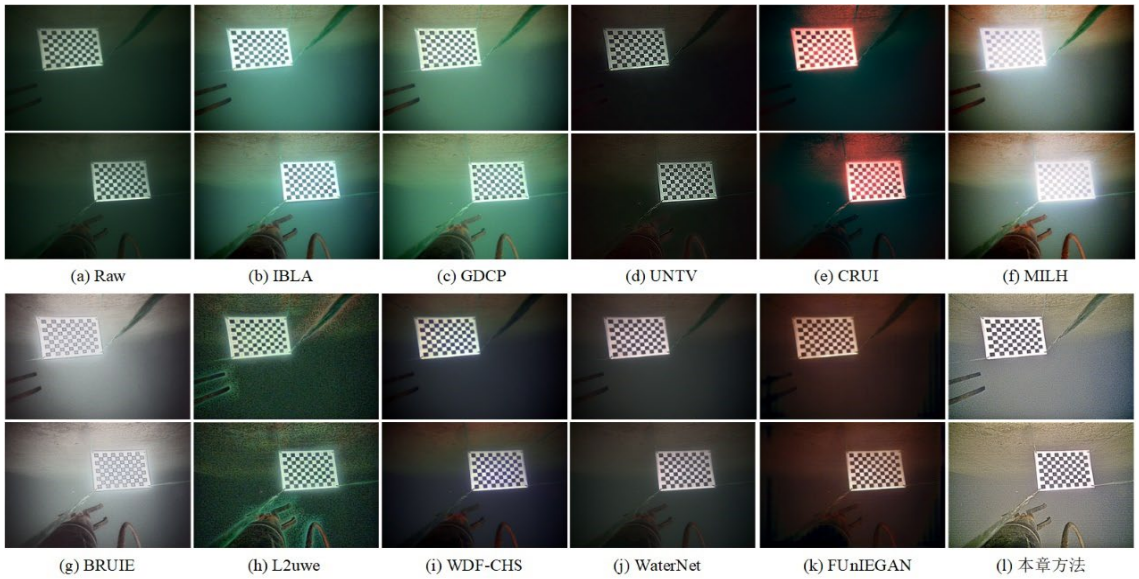


图4.9 不同方法在双目棋盘格图像上的视觉对比

Fig.4.9 Visual comparison of different underwater methods on binocular checkerboard images

由于水下图像的非参考定量指标在某些情况下与人眼视觉感知[65]不一致，因此引入重投影误差（Reprojection Error, RE）和实际测量距离值（Distance Values, DV）以实现不同清晰化方法有效性的定量评估。该实现的具体过程为：首先分别选择基于左右相机获得的原始水下棋盘格图像，并通过不同方法生成相应的增强图像。其次，引入基于光线追踪的水下标定方法[139]计算双目相机的内参数和外参数。最后，根据相机的内参数和外参数计算重投影误差，并估计图像中每个网格所代表的实际距离，其中每个网格的实际距离为 30mm，如表 4.3 所示。值得注意的是，由于 UNTV 方法获得的增强图像超过一半的图像中未检测到匹配的角点，因此该方法被排除。通过分析表 4.3 中数据可知，本章方法有效提高了水下相机标定参数的精度，证明了本章方法在实际水下应用的可行性。

表 4.3 水下双目测距实验

Tab. 4.3 Underwater binocular measurement experiment

	IBLA	GDCP	CRUI	MILH	BRUIE	L2uwe	WDF	Water	FUnIE	Ours
RE	0.183	0.171	0.224	0.292	0.185	0.188	0.189	0.174	0.182	0.167
DV	27.65	27.90	26.82	25.62	27.56	27.46	27.34	27.79	27.68	28.20

中国知网 https://www.cnki.net

4.5 本章小结

针对水下人工光源引入的非均匀照明问题，本章提出了一种基于亮度图估计和自适应增益的水下光学图像清晰化方法。为了解决水下图像中非均匀色偏的问题，首先基于颜色转移图像和最大衰减图以改善水下图像中非均匀色偏现象，并引入结构权重矩阵构建目标函数以解决水下图像中的非均匀照明问题。其次，为了解决水下图像中纹理和边缘细节丢失的问题，提出基于自适应增益控制函数的高频增强方法，并引入颜色平衡策略进一步校正增强图像中存在的轻微色彩偏差。定性和定量实验结果表明，本章方法可有效抑制非均匀照明的干扰，并有效提升图像的整体对比度和纹理细节信息。此外，在工业水下环境中的低级视觉任务和双目相机标定实验进一步验证了本章方法的有效性和鲁棒性。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第五章 基于成像模型和衰减图引导的水下图像清晰化方法

5.1 引言

水下光学图像质量退化的因素是复杂且多样的，与水域深度、浑浊度、悬浮颗粒浓度和光照条件等因素密切相关。在水下光学图像中经常出现非均匀退化，例如距离相机较远的区域往往具有更严重的色彩失真问题。上述因素导致获得的水下光学图像出现颜色失真、局部细节非均匀退化、全局对比度低等退化现象。近年来，水下图像清晰化方法致力于获取高质量的水下光学图像，以提高下游网络在各种海洋场景中的适用性和鲁棒性。为此，研究者们广泛开发了许多水下光学图像清晰化方法，大致可分为无成像模型、基于成像模型和基于数据驱动的三类方法。具体而言，无成像模型的水下清晰化方法直接根据水下图像特性来调整像素值，从而改善图像的对比度和色调。然而，这类方法忽略了水下物理模型的约束，容易导致增强图像出现欠饱和或过度增强的问题[140]。基于成像模型的水下清晰化方法依赖于人工设计的先验知识以估计水体的透射率和相关的未知参数，并反演水下成像过程，从而获得复原图像。然而，当人工设计的先验难以描述特定的水下场景时，这类方法难以获得理想的复原图像[141]。产生这一现象的原因可归因于：（1）人工设计的先验知识大多是针对特定水域设计的，泛化能力和鲁棒性有限；（2）水下成像模型的未知参数估计本质是一个病态问题；（3）仅考虑单一衰减系数难以反映水介质对不同波长光的选择性衰减特性。得益于深度学习在多个领域取得的显著成功，众多研究者对基于深度学习的水下图像清晰化领域进行了深入研究。与传统基于成像模型和无成像模型的水下清晰化方法相比，基于深度学习的方法由于本身强大的非线性特征表示能力，在水下图像清晰化领域中表现出更为强大的泛化性和高效性[142-145]。虽然现有的图像清晰化方法在增强退化水下图像质量方面的能力已经得到证明，但仍然存在以下挑战：（1）当水下成对训练样本数量有限时，模型准确学习退化域和清晰域之间的复杂映射关系具有挑战；（2）在不引入额外监督信息的前提下，模型在处理水下图像中非均匀退化问题的能力有限；（3）模型的计算效率是制约在实际水下应用的另一个重要因素。此外，忽略水下成像模型的约束和不同波长光的选择性衰减特性可能导致模型产生不稳定的增强结果。

根据上述分析，本章提出一种基于成像模型和衰减图引导的水下图像清晰化方法，从而解决水下光学图像的颜色失真和非均匀退化问题，该方法可命名为

中国知网 https://www.cnki.net

UIMPL（Underwater Imaging Model Parameter Learning, UIMPL）。UIMPL 模型的整体结构如图 5.1 所示。具体而言，该框架包括环境光估计和水下图像复原两个主要阶段。在环境光估计阶段，首先设计了一个浅层卷积神经网络学习三个基本的全局环境光参数，并用于水下图像复原的全局指导。同时，基于多颜色空间和相应的衰减图估计偏置环境光矩阵，以实现对图像中不同退化区域提供非均匀增强。在水下图像复原阶段，将混合环境光参数与原始水下图像相结合作为多分支结构的输入，并通过不同空洞率的空洞卷积获取丰富的上下文信息，从而计算不同颜色通道的透射率图。此外，将水下成像模型嵌入到整个网络框架以实现端到端的训练。最后，通过全面的定性、定量及应用实验进一步证明所提方法的有效性和鲁棒性。

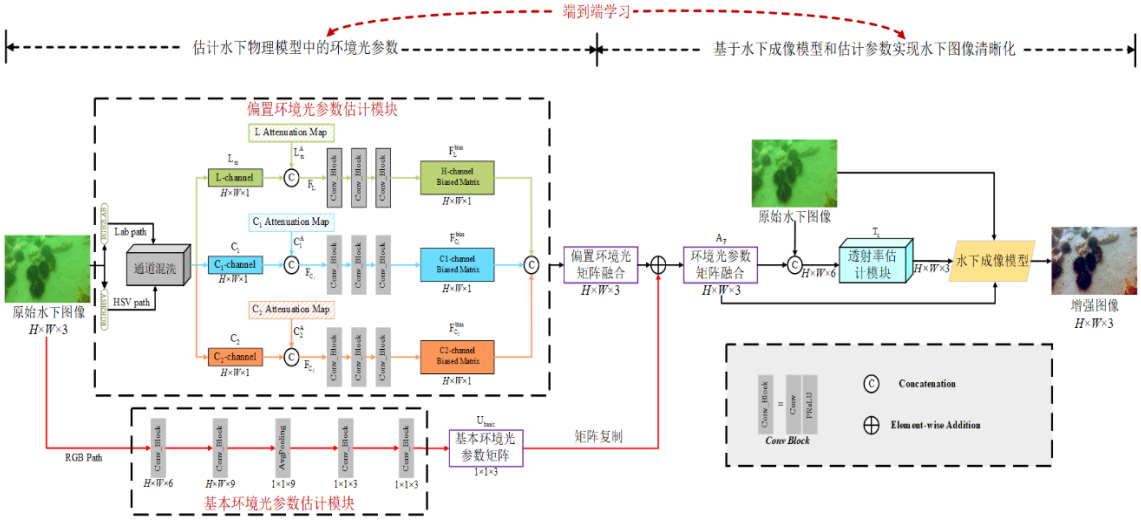


图5.1 所提方法的整体流程图

Fig.5.1 The overall workflow of the proposed method

5.2 修正的水下成像模型

尽管第 2.3 节简化的水下光学成像模型在一定程度上反映了光在水介质中的传播和物理过程，但忽略了不同波长光固有的衰减特性。在可见光谱中，水介质对可见光谱中的短波长（蓝光和绿光）吸收较弱，因此这些波长能够在水介质中传播得更远，而长波长（红橙光）进入介质中很快被吸收，导致红色光迅速衰减，使得水下光学图像容易失去原本的色彩。此外，随着深度的增加，光的衰减速度加快，可见光谱的传播距离逐渐缩短。因此，为了克服上述模型的局限性，Akkaynak 等[28]提出一种修正的水下成像模型来描述不同波长的光随着距离的变化而衰减的规律。该修正的水下成像模型可表示为：

$$I_R = J_E e^{-\eta_c^D d(x)} + A_\infty (1 - e^{-\eta_c^B d(x)}) \tag{5-1}$$

其中，η_c^D 和 η_c^B 分别为不同颜色通道的系数。该系数用于反映不同水体类型、距离、

中国知网 https://www.cnki.net

反射率和相机光谱响应等因素对光的吸收和散射效应。基于公式(5-1)，最终的复原图像可表示为：

$$J_E=(I_R-A_\infty)e^{-\eta_c^D d(x)}+A_\infty e^{(\eta_c^D-\eta_c^B)d(x)} \tag{5-2}$$

鉴于文献[66]中的实验可知，当物体距离相机超过 3m 时，η_c^D 和 η_c^B 可近似相等，即 $\eta_c^B\approx\eta_c^D$。因此，公式可重写为：

$$J_E=(I_R-A_\infty)e^{-\eta_c^D d(x)}+A_\infty \tag{5-3}$$

其中，J_E 代表物体本身的辐射度，即理想的清晰图像。I_R 代表退化的水下图像，A_∞ 为颜色向量，称为环境光。此外，项 $e^{-\eta_c^D d(x)}$ 称为透射率，反映了光衰减效应的强弱由系数 η_c^D 和传输距离 d 决定。受上述修正水下成像模型的启发，本章提出一个参数估计网络准确地估计模型中的未知参数，随后反演水下成像过程以获得高质量的图像。

5.3 基于成像模型和衰减图引导的卷积神经网络架构

由第 5.2 节介绍的水下成像模型可知，清晰的水下图像可通过透射率和环境光来恢复。为此，基于水下成像模型的重建策略核心在于如何拟合合适的未知参数以反映水介质对不同波长光所独有的特性。根据上述分析，本章所提出的参数估计网络可分为环境光参数估计模块和透射率估计模块两部分。在环境光参数估计模块，一幅原始水下图像分别经过基本环境光参数估计模块和偏置环境光参数模块。基本环境光参数估计模块仅使用原始水下图像作为模型的输入，随后经过四个由基础卷积模块和一个平均池化层构建的浅层网络以估计三个基本环境光参数，用于引导水下图像复原过程中的全局特征信息。偏置环境光参数估计模块首先基于多颜色空间变换的通道混洗模块生成三个具有不同特征的通道，随后将不同通道与相应的衰减图进行结合以预测环境光的偏置矩阵，从而对不同退化区域提供非均匀增强。在透射率估计模块中，首先将三个环境光偏置矩阵与基本环境光参数相结合。随后，将融合的环境光参数矩阵与原始水下图像进行堆叠操作生成六通道的输入到透射率估计模块以估计不同颜色通道的透射率。该模块引入不同空洞率的空洞卷积以扩大感受野，从而使模型可以学习丰富的上下文信息。最后，将原始水下图像、融合的环境光参数矩阵和相应的透射率输入至水下成像模型中，通过反演模型实现水下图像清晰化任务。值得注意的是，本章方法不需要引入额外的监督信息来引导模型的训练。接下来，将详细模型中每个模块的具体构建。

中国知网 https://www.cnki.net

5.3.1 基本环境光参数估计模块

受传统水下光学图像复原方法的启发，常用的估计方法可以通过构建卷积神经网络以获得不同颜色通道的环境光参数[73]。为此，本节设计了一系列标准卷积堆叠的神经网络以预测环境光的基本参数，从而为图像复原提供全局的引导信息，即：

$$U_{basic}=[A^r,A^g,A^b]\leftarrow\mathcal{B}(R^c) \tag{5-4}$$

其中，A^r、A^g 和 A^b 分别表示不同颜色通道相应的环境光参数的估计值，$\mathcal{B}$ 是由一系列卷积操作序列构建的浅层卷积神经网络，R^c 代表原始水下图像。U_{basic} 中的参数是针对图像中不同颜色通道所设计的，可作为基本环境光参数引导全局图像恢复。然而，由于基本环境光参数是基于图像全局信息引导进行图像复原的，因此无法对图像中非均匀退化区域实现局部质量增强。为此，本节设计了一个偏置环境光参数估计模块以解决非均匀退化区域增强的挑战。

5.3.2 偏置环境光参数估计模块

如果从全局角度引导水下图像复原，基本环境光参数的准确估计是至关重要的。然而，由于基本环境光仅包含三个可用参数，只能为相应颜色通道内的所有像素提供统一且无偏的复原效果。然而，光在水下传播时受到水介质的选择性吸收和散射的影响，且光在不同深度、距离和水体环境中的衰减程度不同，导致获得的水下图像在清晰度和色彩方面出现非均匀的退化现象。此外，水体中的悬浮颗粒物浓度的不均匀分布进一步加剧了光的散射和吸收程度，从而使得图像局部区域的对比度和亮度出现显著差异。综上所述，水下图像中不同区域因光衰减程度的不同而呈现出非均匀退化的问题，使得水下图像清晰化面临更高的复杂性和挑战。因此，本节提出一种多颜色通道混洗模块并结合相应的衰减图生成偏置环境光矩阵，从而为水下光学图像的不同退化区域提供非均匀的增强。

RGB 色彩空间虽然可有效处理水下图像中的散射问题，一定程度上改善图像的颜色失真等问题，但由于该色彩空间对图像亮度和饱和度等重要属性的不敏感性，导致在增强对比度、饱和度和亮度等质量退化问题的能力有限。因此，仅利用 RGB 色彩空间难以全面地提升图像的视觉质量，特别是对于非均匀退化的水下场景。受传统清晰化方法在各种色彩空间中操作的启发[145,146]，本节提出了一种基于多颜色空间的通道混洗模块。首先将同一幅水下图像转换至两个颜色空间（HSV 和 LAB）中以获取不同的视觉表征，如图 5.2 所示。由于在 RGB 色彩空间中的每个通道具有高度相关性，在一定程度上限制了在水下光学图像中处理复杂退化现象

中国知网 https://www.cnki.net

的能力，并且无法直接反映图像中亮度、饱和度和色调等属性。相比而言，HSV 色彩空间提供了更加直观和准确的图像属性表示能力。该色彩空间将图像的色调（Hue）、饱和度（Saturation）和亮度（Value）解耦为独立的分量以更准确地反映图像的不同特性，且符合人类的视觉感知。此外，LAB 色彩空间是一种基于人类视觉特性的色彩模型。该色彩空间将图像中亮度分量（Lightness）与颜色分量（绿色-红色分量 a^* 和蓝色-黄色分量 b^*）进行解耦，从而有助于处理图像中亮度与颜色失真之间的关系。

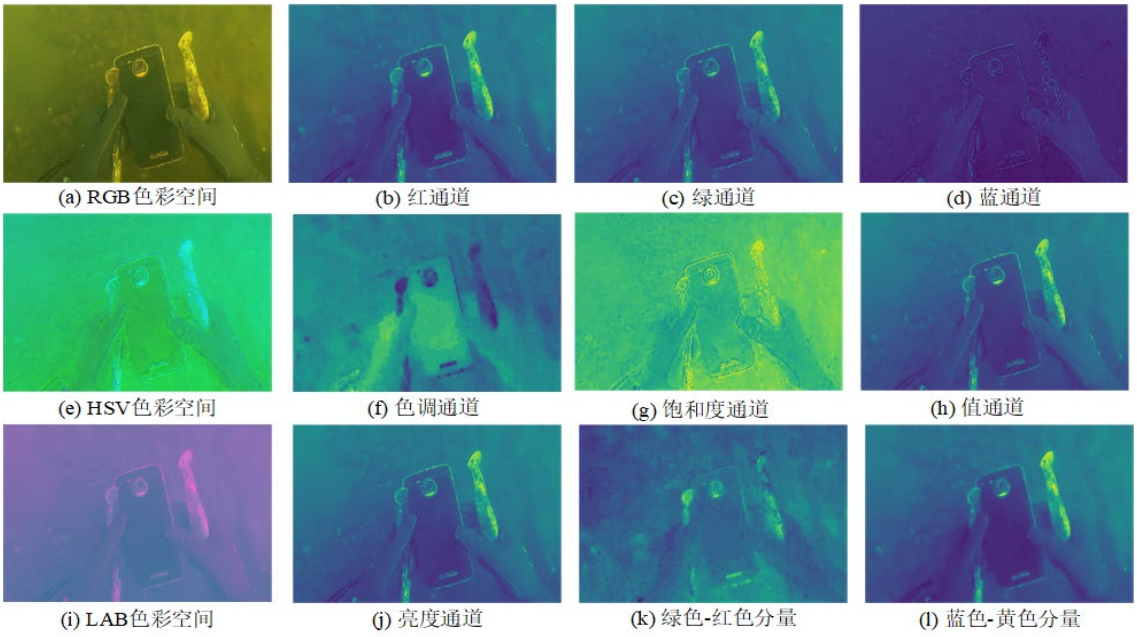


图5.2 不同颜色空间的可视化示例

Fig.5.2 Visualization examples of different color spaces

根据上述分析，本节将多颜色空间嵌入到统一的水下清晰化模型以校正水下图像的非均匀退化问题，并基于通道混洗策略融合不同色彩空间的信息。首先，将原始水下图像从 RGB 色彩空间转换为 HSV 和 LAB 色彩空间中，具体操作为：

$$\begin{aligned} L_1^{R(x)}, A_1^{R(x)}, B_1^{R(x)} &\leftarrow \mathrm{RGB2LAB}(R(x)) \\ H_1^{R(x)}, S_1^{R(x)}, V_1^{R(x)} &\leftarrow \mathrm{RGB2HSV}(R(x)) \end{aligned} \tag{5-5}$$

其中，$R(x)$ 代表原始水下图像。随后，通道混洗策略定义为：

$$\begin{cases} L_m = \dfrac{(L_1^{R(x)} + V_1^{R(x)})}{2} \\ C_1 = \dfrac{(A_1^{R(x)} + H_1^{R(x)})}{2} \\ C_2 = \dfrac{(B_1^{R(x)} + S_1^{R(x)})}{2} \end{cases} \tag{5-6}$$

其中，L_m、C_1 和 C_2 分别代表通过通道混洗操作后得到的新通道，动态范围被映射

中国知网 https://www.cnki.net

至$[0,1]$。在本章框架中，根据通道混洗来实现多色彩空间的嵌入，从而提取图像中的亮度和色调信息。此外，由于水体对光的选择性吸收和散射效应导致水下图像出现不同程度的色偏现象，且水下的低照度环境也是导致水下图像质量退化的另一个主要因素，因此本节引入衰减图作为引导估计不同通道的衰减等级。则相应通道的衰减图定义为：

$$\begin{cases} L_m^A = 1 - L_m \\ C_1^A = 1 - C_1 \\ C_2^A = 1 - C_2 \end{cases} \tag{5-7}$$

其中，L_m^A、C_1^A和C_2^A分别代表不同颜色通道的衰减图。随后，将通道混洗策略的输出与相应通道的衰减图进行沿通道维度的拼接操作，从而生成具有丰富图像属性的特征图，即：

$$\begin{cases} F_L = [L_m, L_m^A] \\ F_{C_1} = [C_1, C_1^A] \\ F_{C_2} = [C_2, C_2^A] \end{cases} \tag{5-8}$$

其中，L_m、C_1和C_2代表通道混洗策略的输出通道，L_m^A、C_1^A和C_2^A代表相应通道的衰减图，$[\cdot,\cdot]$为沿通道维度的拼接操作。为了融合不同通道的特征信息，本节设计了三个堆叠的基础卷积块进行特征提取，从而获得相应通道的偏置环境光参数矩阵。因此，不同通道的偏置矩阵可计算为：

$$[F_L^{bias}, F_{C_1}^{bias}, F_{C_1}^{bias}] \leftarrow \mathcal{C}(F_L), \mathcal{C}(F_{C_1}), \mathcal{C}(F_{C_2}) \tag{5-9}$$

其中，$[F_L^{bias}, F_{C_1}^{bias}, F_{C_2}^{bias}] \in \mathbb{R}^{H \times W \times 3}$分别代表不同通道上的偏置环境光参数矩阵，$\mathcal{C}(\bullet)$为三个堆叠的基础卷积块。随后，将基本环境光参数扩展至与原始水下图像相同的尺度，并与偏置环境光矩阵进行逐元素相加以实现图像的非均匀增强。该过程具体表示为：

$$A_F = [[A^r \oplus F_L^{bias}], [A^g \oplus F_{C_1}^{bias}], [A^b \oplus F_{C_2}^{bias}]] \tag{5-10}$$

其中，$[A^r, A^g, A^b] \in \mathbb{R}^{1 \times 1 \times 3}$分别代表不同通道的基本环境光参数矩阵。值得注意的是，不同通道的基本环境光参数矩阵是根据逐像素矩阵复制生成的，因此尺度大小与原始水下图像保持一致，从而实现基本环境光与偏置环境光参数的融合。$\oplus$为逐元素矩阵相加运算，$A_F \in \mathbb{R}^{H \times W \times 3}$代表融合后的环境光参数矩阵。

5.3.3 透射率估计模块

透射率通常用于描述光在水下场景中的传播过程，包括光照的衰减和散射程度，对于全面理解和分析水下场景中的信息具有重要意义。通过准确估计的透射率，可以有效反映光在水中的传播规律以校正因波长衰减差异导致的色偏，并可去除

中国知网 https://www.cnki.net

悬浮颗粒物引起的散射效应，从而有效提升水下图像的清晰化和对比度。然而，透射率的准确估计依赖于图像局部和全局上下文信息的提取能力。受空洞卷积的启发，本节提出的透射率估计模块采用不同扩张率的卷积分支构建以提取图像的多尺度特征信息，整体结构如图 5.3 所示。具体而言，首先将融合环境光和原始水下图像沿通道维度堆叠作为透射率估计模块的输入。随后，分别通过1×1卷积、具有三个扩张率(1, 2, 5)的多分支卷积和平均池化层生成具有不同感受野所提取的特征图信息，从而有助于从全局和局部的角度估计不同通道的透射率。最后将五个分支的输出特征图进行融合，再通过1×1卷积降低通道的维度，以获得相应通道的透射率。

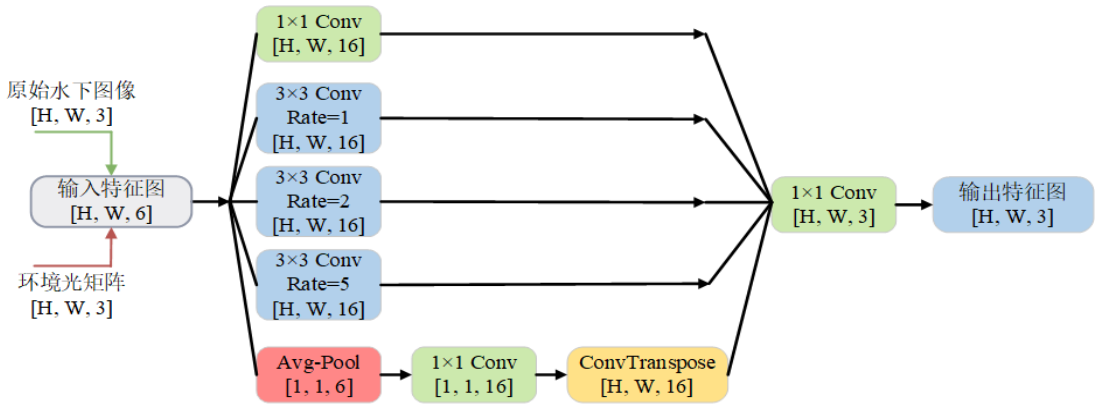


图5.3 透射率估计模块

Fig.5.3 Transmission estimation module

此外，本节将水下成像模型嵌入到统一的网络框架以实现端到端训练。具体而言，将估计得到的环境光参数矩阵和相应通道的透射率代入到水下成像模型中，根据模型反演计算出高质量的增强图像：

$$J_E=(I_R-A_F)T_c+A_F \tag{5-11}$$

其中，I_R代表原始水下图像，A_F为融合的环境光参数矩阵，T_c为不同通道的透射率，J_E代表最终的增强图像。

5.3.4 损失函数

针对水下图像清晰化任务，研究者们提出了许多用于模型训练的损失函数，以全面提升网络的有效性和鲁棒性。主流的损失函数根据水下场景的独有特性进行设计，例如颜色损失[77]、对比度损失[148]和感知损失[149]等。具体而言，颜色损失旨在通过约束图像的颜色分布以校正不同波长光因其光谱特性而导致的颜色失真，对比度损失旨在关注图像的边缘和纹理细节信息，感知损失通过进行高级特征间的匹配以提高水下图像的整体质量。然而，多损失函数的结合需根据不同水下任务

中国知网 https://www.cnki.net

对相应损失函数的权重进行精细微调以平衡各损失函数的贡献，从而提升最终增强结果的质量。为了充分体现模型结构的优越性，本章仅引入 ℓ_2 损失函数度量增强图像 I_e 和相应参考图像 I_g 之间的像素级误差。该损失函数定义为：

$$\ell_2=\frac{1}{HWC}\sum_{m=1}^{H}\sum_{n=1}^{W}\sum_{k=1}^{C}(I_e(m,n,k)-I_g(m,n,k))^2 \tag{5-12}$$

其中，H 和 W 分别代表原始图像的高和宽，C 代表原始图像的通道数量，设置为 3。

5.4 实验结果与分析

本节首先介绍了本章方法的实验设置。其次，在多个基准水下数据集上设计了全面的定性和定量实验，将本章方法与经典的传统和主流的基于数据驱动的水下图像清晰化方法进行了全面的比较与分析。最后，进行一系列的消融实验和应用实验以进一步验证不同清晰化方法的有效性和通用性。具体而言，所提方法与三种经典的传统和八种主流基于数据驱动的水下图像清晰化方法进行了广泛的对比实验，其中包括经典的传统方法（GDCP[127]、IBLA[25]和 CBAF[49]）和基于数据驱动方法（TCTL-Net[76]、TACL-Net[63]、Ucolor[78]、SGUIE-Net[80]、TOPAL[150]、U-shape[115]、FUnIE-GAN[70]和 WaterNet[65]）。上述方法均采用作者提供的官方代码和预训练权重进行设置，以保证对比实验的公平性。基准数据集分别采用 UIEB 测试、UIEB 挑战[65]、EUVP[70]、LSUI[115]和 SQUID[28]。具体而言，UIEB 测试数据集中包含 90 幅不同退化程度的成对水下图像，而 UIEB 挑战则是由 90 幅极端场景的水下图像组成，且没有相应的参考图像。EUVP 数据集包含了 20k 幅水下图像样本，涵盖了由多种成像设备、水下条件（水深、浑浊度、光照条件）和不同场景（水下生物、礁石、沉船等）所获得的高质量和低质量的光学图像。本节使用低质量未配对的水下图像作为测试数据集以衡量不同清晰化方法的有效性。LSUI 数据集包含 4279 幅不同水下环境的成对样本，涉及多种水下生物、珊瑚礁、船只残骸和人工设施等反映真实水下环境的多样性。此外，该数据集还着重关注于水下环境中拥有相对均匀光照到亮度极低条件下的光学图像。本节使用 LSUI 数据集中呈现的所有图像样本验证不同清晰化方法的通用性。SQUID 数据集涵盖了从四个潜水位置和深度下捕获的 57 幅具有不同水体（浅水、深水、海洋和湖泊）的双目立体图像。本节利用 SQUID 数据集中通过右相机所获得的所有具有彩色卡的未畸变水下图像来定性和定量验证不同清晰化方法的颜色校正能力。在定量评价指标方面，本节对于具有相应高质量参考图像的数据集（UIEB 测试和 LSUI 数据集），使用峰值信噪比（PSNR）

中国知网 https://www.cnki.net

和结构相似度（SSIM）[106]作为全参考评价指标以评估不同方法的增强性能。除SQUID 数据集以外，本节均使用五种无参考评价指标来评估不同清晰化方法的有效性，即水下图像质量评价指标（UIQM）[110]、色彩对比度雾密度评价指标（CCF）[112]、水下彩色图像质量评价指标（UCIQE）[111]、边缘强度（EI）[109]和平均梯度（AG）[108]。对于 SQUID 数据集，本节引入平均重现误差（Average Reproduction Errors, ARE）[26]计算不同清晰化方法的颜色校正精度。在全参考评价指标中，越高的 PSNR 和 SSIM 指标值表明增强图像在上下文信息和结构方面与参考图像越相似。在无参考评价指标中，越高的 UIQM 或 CCF 指标值反映了增强图像拥有较好的整体对比度和视觉感知。AG 或 UCIQE 指标值越高表明增强图像整体可见度和质量越好，而越高的 EI 得分则意味着图像拥有更加丰富的边缘细节信息。此外，ARE 指标值越低意味着清晰化方法的颜色校正能力越准确。

5.4.1 实验设置

本章基于 UIEB 成对数据集中随机采样 800 幅真实世界的水下图像和相应的参考图像监督训练所提网络模型，剩余的 90 幅水下图像作为测试集，记为 UIEB 测试。值得注意的是，本章模型仅使用 UIEB 来训练整个网络模型，且不使用任何数据增强方法和调整输入图像的尺寸。

本章模型采用 PyTorch 深度学习框架来实现，且不引入额外的预训练权重。本章训练时采用 Adam 优化器来优化模型参数，参数 β_1 和 β_2 分别设置为 0.9 和 0.999。学习率固定为 $1e-3$，且批大小设置为 1。整个模型训练共迭代 3000 轮。上述实验均在 Ubuntu16.04 系统下，使用一台 GPU 服务器（Nvidia GeForce GTX 3090 GPU、Intel Core i9-12900k CPU 和 128GB RAM）来实现。

5.4.2 主观定性实验

为了定性衡量不同水下清晰化方法的增强性能，本节在 UIEB 测试、UIEB 挑战、EUVP、LSUI 和 SQUID 基准数据集上进行了全面的定性实验。本节首先从 UIEB 测试数据集中选择了四幅具有不同退化特征的水下图像，如图 5.4 所示。其中涵盖了水下环境中常见的绿色外观、蓝色外观、蓝绿色外观和绿色-雾霾外观的水下图像。由图 5.4(b)至图 5.4(n)可知，对于传统的水下清晰化方法，GDCP 和 IBLA 方法难以有效校正水下图像中不同程度的颜色失真现象。虽然 CBAF 方法凭借有效的红通道补偿策略可在一定程度上校正水下图像的颜色偏差，但由于该方法仅考虑了红光的衰减，导致最终的增强图像整体色调单一且局部视觉效果偏暗。对于主流基于数据驱动的水下清晰化方法而言，TCTL-Net 有效改善了具有不同退化程

中国知网 https://www.cnki.net

度水下图像的视觉质量。然而，该方法对于绿色-雾霾的水下图像中引入了过度饱和的现象，如图 5.4(e)第四行所示。TACL-Net 在蓝色外观的水下图像中引入了人工伪影，如图 5.4(f)第二行所示。此外，如图 5.4(f)第三行具有蓝绿色外观的水下图像中，该方法未能有效校正蓝色色偏的现象。Ucolor 在具有绿色外观的水下图像中引入了额外的蓝绿色失真现象，且在具有蓝绿色外观的水下图像中未能有效校正蓝色色偏，如图 5.4(g)第一行和第三行所示。SGUIE-Net 需要引入额外的分割图以引导模型学习高级的特征信息，从而实现高质量的增强结果。然而，该方法的增强性能很大程度上依赖于分割图的准确性，如图 5.4(h)中第一行和第三行所示。TOPAL 是一种面向对象的水下清晰化方法，可能导致增强图像出现模糊和雾状的外观，如图 5.4(i)所示。U-shape 提供了良好的颜色校正能力，但对于去除水下图像中由于后向散射产生的雾状问题能力有限，如图 5.4(j)所示。FUnIE-GAN 难以抑制水下图像中不同程度的颜色偏差问题，如图 5.4(k)所示。Water-Net 在具有蓝绿色外观的水下图像中引入了网络效应且导致图像的整体视觉效果偏暗，如图 5.4(l)所示。相比而言，所提方法可稳定且有效地校正水下图像中不同程度的颜色偏差问题，并且未引入明显的过度增强和伪影现象。

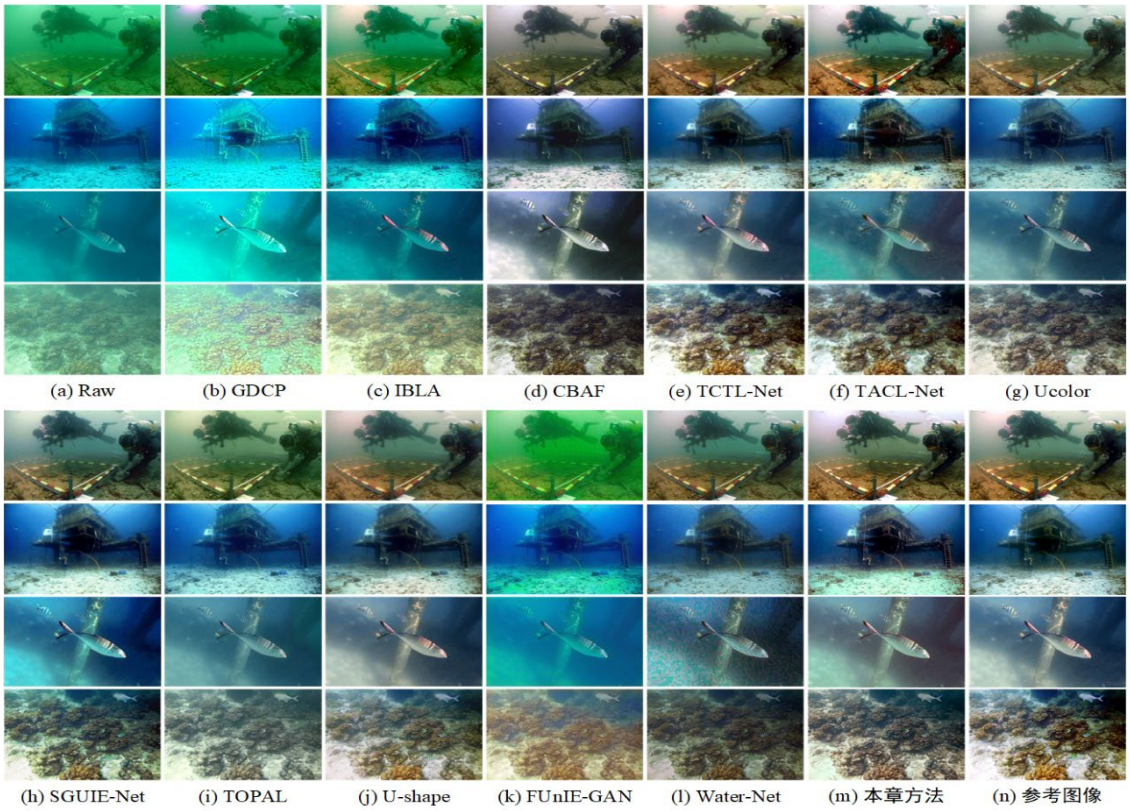


图5.4 不同清晰化方法在 UIEB 测试数据集上的定性结果

Fig.5.4 Qualitative results of different sharpening methods on the UIEB test dataset

为了进一步验证不同水下清晰化方法的鲁棒性和通用性，本节在 UIEB 挑战、

中国知网 https://www.cnki.net

EUVP 和 LSUI 基准数据集上分别进行了全面的定性实验。对于 UIEB 挑战数据集，图 5.5 展示了传统水下清晰化方法在处理具有严重色偏水下图像时的增强结果。由图 5.5 定量结果可知，GDCP 进一步加剧水下图像的颜色失真问题，且引入额外的颜色信息，导致增强结果偏离人类视觉的自然感知。IBLA 的增强图像出现了明显的颜色偏差，如图 5.5(c)中呈现的过量的绿色和蓝色。CBAF 虽然在一定程度上校正了颜色失真问题，但增强图像的色彩单一。



图5.5 传统方法在 UIEB 挑战数据集上的定性结果

Fig.5.5 Qualitative results of traditional methods on the UIEB challenge dataset

与上述传统水下清晰化方法相比，基于数据驱动的方法实现了更为鲁棒的颜色校正和对比度增强的能力，如图 5.6 所示。具体而言，除 FUnIE-GAN 和 Water-Net 外，所有基于数据驱动的方法均可在一定程度上校正水下图像中严重的颜色失真现象，但在浑浊环境的水下图像中则会导致不准确的颜色恢复，如图 5.6 第三行红色目标物体被褪色或引入紫色色调。相比之下，所提方法可有效地恢复不同退化程度的色偏现象且提高了整体对比度和细节信息，这归因于模型结构中多颜色空间的嵌入以及偏置参数矩阵的设计。

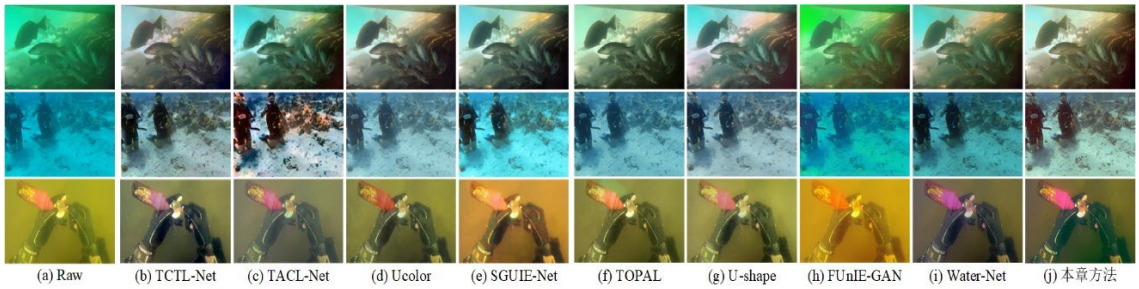


图5.6 基于数据驱动的清晰化方法在 UIEB 挑战数据集中的定性结果

Fig.5.6 Qualitative results of data-driven sharpening methods on the UIEB challenge dataset

中国知网 https://www.cnki.net

对于 EUVP 数据集，图 5.7 展示了传统水下图像清晰化在具有高后向散射的原始水下图像时的增强结果。观察可知，由于缺少监督信息的约束，传统方法往往引入额外的颜色信息，并且增强图像仍然存在明显的模糊区域和光晕效应。

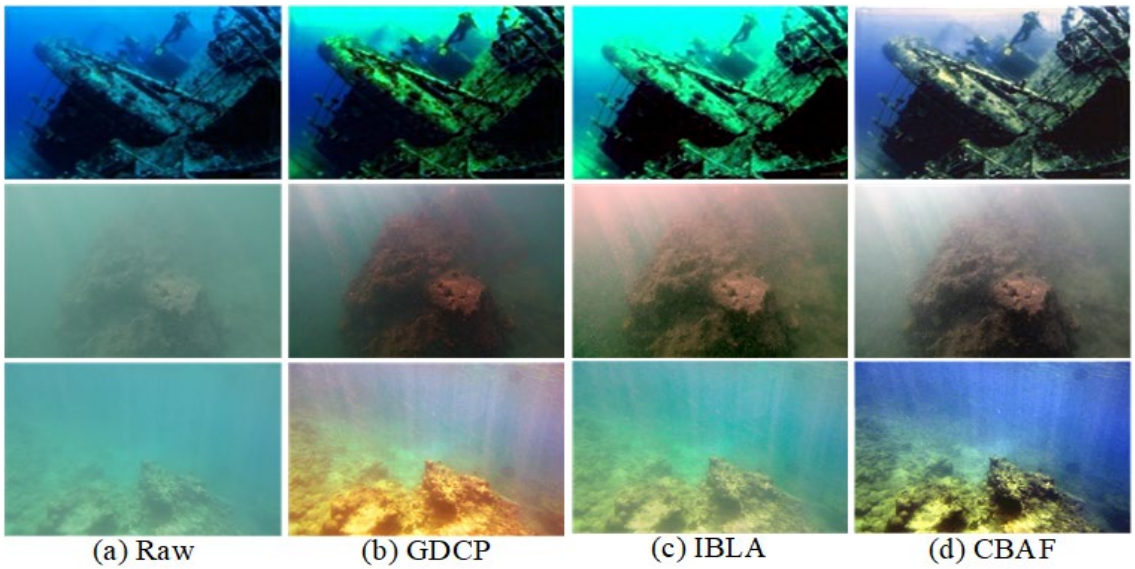


图5.7 传统方法在 EUVP 数据集上的定性结果

Fig.5.7 Qualitative results of traditional methods on the EUVP dataset

相比于传统方法，基于数据驱动的方法通过构建高效的学习机制和监督信息的约束，在一定程度上可有效地减少颜色偏差，并缓解因丁达尔效应造成的模糊和散射现象，从而提高水下图像的清晰度和视觉效果，如图 5.8 所示。然而，上述方法在提高水下图像清晰度的同时往往在背景中引入不必要的颜色信息，且产生网格效应。相比之下，所提方法可有效应对后向散射带来的退化问题，在没有过度饱和的情况下显著改善了图像整体的视觉质量和能见度，并且突出目标物体的细节信息，为人类感知水下复杂场景提供了高效且直观的视觉支持，如图 5.8(j)所示。

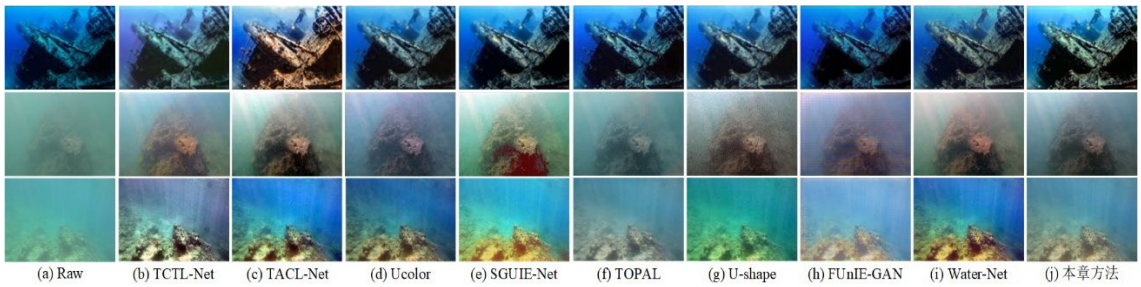


图5.8 基于数据驱动的清晰化方法在 EUVP 数据集上的定性结果

Fig.5.8 Qualitative results of data-driven sharpening methods on the EUVP dataset

对于 LSUI 数据集，图 5.9(a)展示了具有丰富水下场景的样本图像，包括不同水体类型以及弱光条件下的典型场景。上述图像呈现了水下环境中的复杂性和多样性，从而衡量不同水下清晰化方法在多种退化条件下的稳健性和适应性。图 5.9(b)

中国知网 https://www.cnki.net

至图 5.9(n)分别展示了不同水下清晰化方法的增强结果和相应的高质量参考图像。对于传统的水下图像清晰化方法而言，GDCP 和 IBLA 方法均难以准确校正水下图像的颜色失真现象，且无法处理水下图像中的非均匀退化。CBAF 方法虽然一定程度上抑制了水下图像的蓝色和绿色偏差，但该方法的增强图像整体色调单一且无法提高图像的能见度。相比于传统方法，基于数据驱动的水下清晰化方法一定程度上提高了图像的质量。然而，由于受训练数据样本数量和模型设计的限制，上述方法可能会引入不必要的颜色色调，同时在提高图像能见度方面的性能不足。例如，在图 5.9(f)和图 5.9(k)中第二行所示，增强图像中引入了红色和的绿色畸变，从而影响了整体视觉感知。相比之下，所提方法不仅显著提升了图像的能见度，并且准确恢复了图像的真实颜色信息。

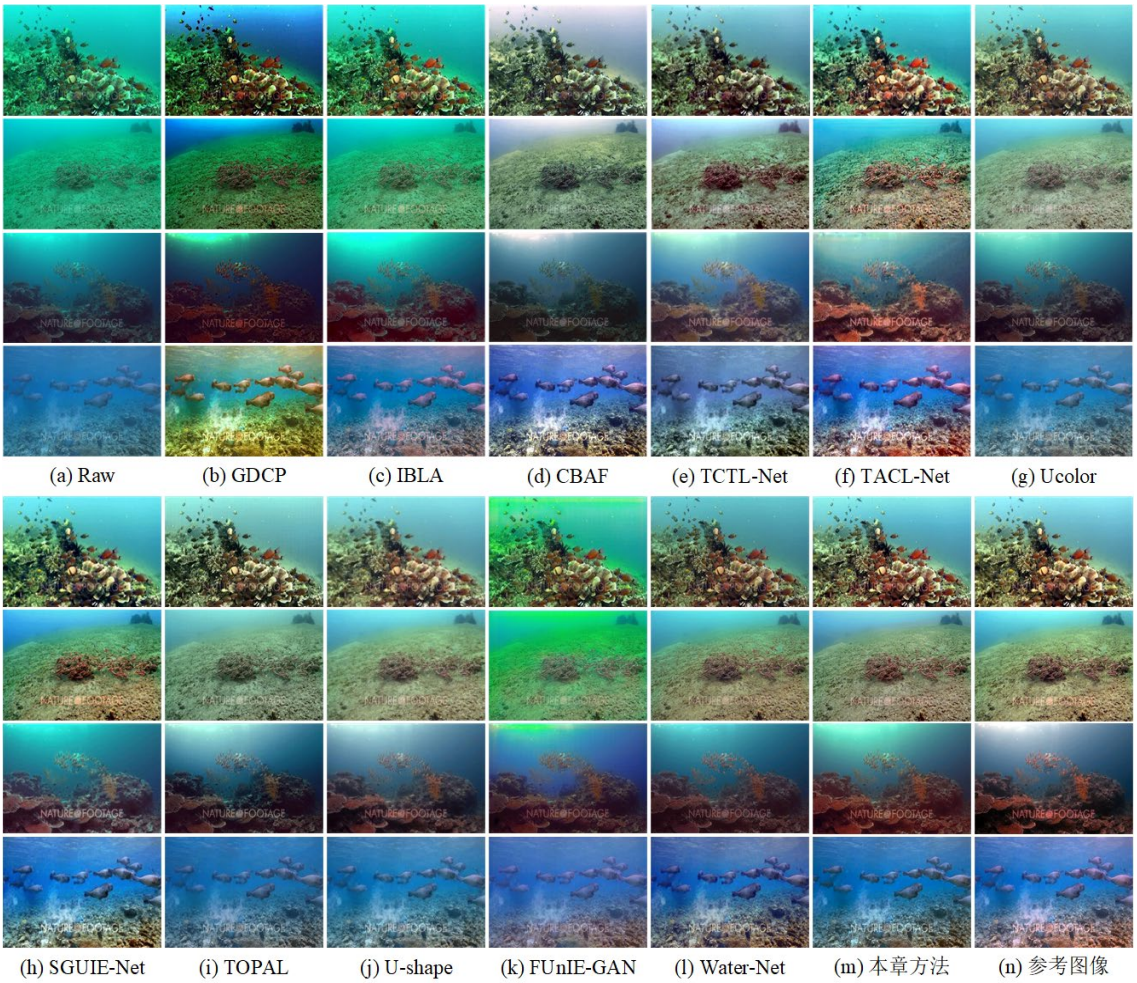


图5.9 不同清晰化方法在 LSUI 测试数据集上的定性结果

Fig.5.9 Qualitative results of different sharpening methods on the LSUI test dataset

对于 SQUID 数据集，图 5.10(a)展示了不同地点和深度下带有标准色卡的水下图像以定性比较基于数据驱动的水下清晰化方法在颜色校正方面的性能。在 SQUID 数据集中的所有图像均呈现出严重的视觉退化特征，其中包括细节模糊和

中国知网 https://www.cnki.net

具有严重蓝色和绿色退化现象的水下图像。上述现象对水下图像清晰化方法提出了重大的挑战，要求方法具有更强的鲁棒性和适应性，从而准确恢复的真实颜色和细节。

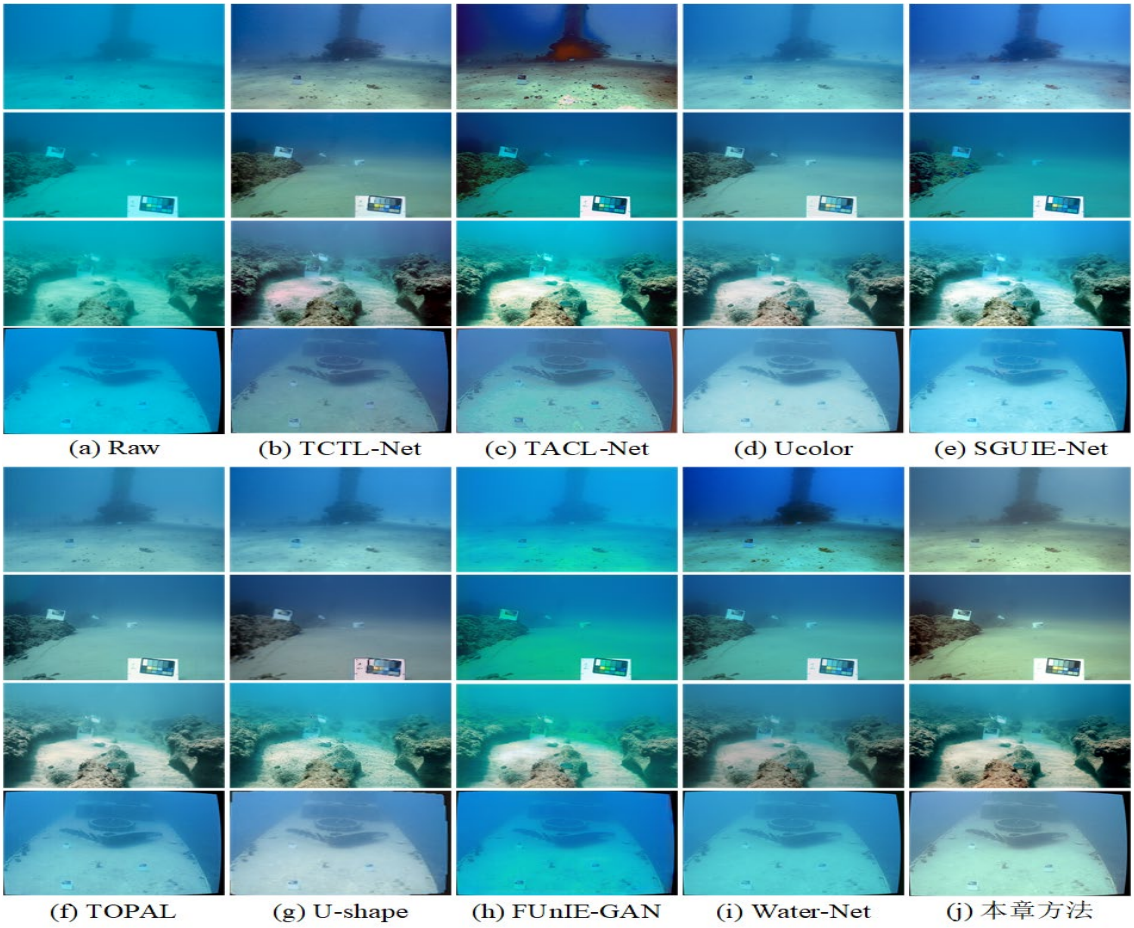


图5.10 基于数据驱动的清晰化方法在 SQUID 数据集上的定性结果

Fig.5.10 Qualitative results of the data-driven sharpening methods on the SQUID dataset

在基于数据驱动的方法中，对于直接学习失真域到清晰域映射的水下图像清晰化方法而言，由于严重退化图像在训练样本中出现的频率较低，导致模型对上述类型图像的处理能力有限。因此，上述直接学习映射关系的方法通常难以获得令人满意的增强结果，如图 5.10(b)至图 5.10(i)所示。例如，SGUIE-Net 通过引入语义分割图引导模型实现高质量的增强结果，但增强性能严重依赖于语义分割图像的准确性。Water-Net 通过白平衡、Gamma 校正和直方图均衡生成不同属性的图像，并根据门控融合网络以结合上述生成图像，从而有效改善了极端的颜色退化问题。相比而言，基于颜色迁移的水下清晰化方法（TCTL-Net）摒弃了传统直接学习校正映射的策略，通过利用有限的训练样本实现了更好的颜色校正能力。然而，基于颜色迁移的方式难以模拟水介质对不同波长光的选择性吸收和散射效应，导致最终的增强结果在复杂水下场景中仍存在不足，例如颜色信息还原不自然或细节信

中国知网 https://www.cnki.net

息丢失。相反，所提方法通过引入水下成像模型有效校正了水下图像的不均匀颜色退化现象，且未引入额外的人工色调，如图 5.10(j)所示。

5.4.3 客观定量实验

为了全面评估不同水下清晰化方法的增强性能，本节首先在 UIEB 测试和 LSUI 数据集上设计了一系列的定量对比试验。由于上述数据集提供了相应的高质量参考图像，因此本节结合全参考和无参考的水下评价指标，从多个维度定量分析不同清晰化方法在复杂且多样化水下场景中的性能。表 5.1 和表 5.2 展示了不同传统方法和基于数据驱动方法在 UIEB 测试和 LSUI 数据集上的平均定量得分。其中，红色下划线代表传统方法中各指标值的最优值，以直观地展示传统方法的性能。这些评价指标全面衡量了上述方法在增强图像质量、对比度、颜色校正及清晰度等多个维度上的性能。对于 UIEB 测试集而言，由表 5.1 中的全参考评价指标得分可知，本章方法获得了最优的 PSNR 评价指标值和次优的 SSIM 指标值。传统方法通过设计先验知识或基于图像特征对像素值进行直接操作生成最终的增强结果。虽然上述方法生成的过度校正图像与人类视觉系统不匹配，但增强图像的高对比、不自然的细节增强和通道间的平衡策略往往受到无参考指标的青睐，从而获得了更高的评分。此外，相比于其他基于数据驱动的方法，所提方法在五个无参考水下评价指标中的三个（CCF、EI 和 AG）获得了最优的定量结果，充分证明了本方法在颜色校正、边缘保留和增强图像清晰度方面的优势。

表 5.1 在 UIEB 测试数据集上的定量比较结果

Tab. 5.1 Quantitative comparison results on the UIEB test dataset

方法	PSNR	SSIM	UIQM	CCF	UCIQE	EI	AG	Average
GDCP	13.412	0.515	2.739	33.135	0.603	3.720	59.474	16.228
IBLA	18.574	0.655	2.934	38.529	0.599	4.102	61.330	18.103
CBAF	20.840	0.797	3.714	20.053	0.592	4.294	63.166	16.208
TCTL-Net	21.822	0.902	3.069	32.911	0.615	3.254	54.552	16.732
TACL-Net	21.403	0.757	2.954	23.103	0.621	3.123	51.060	14.717
Ucolor	21.858	0.814	3.371	18.185	0.569	3.865	50.871	14.281
SGUIE-Net	20.539	0.724	2.582	21.774	0.610	3.250	45.589	13.581
TOPAL	20.510	0.754	3.149	23.503	0.581	3.708	55.125	15.332
U-shape	19.832	0.694	2.971	17.117	0.563	2.971	43.928	12.582
FUnIE-GAN	17.603	0.582	3.859	18.274	0.568	4.144	50.968	13.714

中国知网 https://www.cnki.net

续表 5.1 在 UIEB 测试数据集上的定量比较结果

Tab. 5.1 Quantitative comparison results on the UIEB test dataset (continued)

方法	PSNR	SSIM	UIQM	CCF	UCIQE	EI	AG	Average
Water-Net	19.292	0.809	3.515	18.068	0.572	4.110	52.453	14.117
Ours	22.812	0.833	3.526	38.102	0.619	4.378	68.313	19.798

对于 LSUI 数据集而言，所提方法的整体性能优于其它基于数据驱动的对比方法。具体而言，本章方法在七个评价指标中有三个获得了最高得分，并且获得了最高的平均量化指标值，如表 5.2 所示。

表 5.2 在 LSUI 测试数据集上的定量比较结果

Tab. 5.2 Quantitative comparison results on the LSUI test dataset

方法	PSNR	SSIM	UIQM	CCF	UCIQE	EI	AG	Average
GDCP	13.293	0.512	2.768	35.334	0.598	4.888	83.508	20.128
IBLA	17.114	0.586	3.954	37.883	0.595	4.572	70.234	19.277
CBAF	20.824	0.708	3.925	24.225	0.579	4.727	73.806	18.399
TCTL-Net	19.326	0.681	3.576	30.615	0.592	4.365	65.722	17.840
TACL-Net	20.188	0.697	3.622	26.053	0.613	4.648	71.943	18.252
Ucolor	21.155	0.744	3.492	21.791	0.570	4.380	61.927	16.294
SGUIE-Net	19.793	0.661	3.018	27.490	0.606	4.413	67.796	17.682
TOPAL	20.081	0.736	3.484	27.369	0.573	4.435	69.684	18.052
U-shape	23.726	0.796	3.530	20.655	0.568	4.040	54.791	15.444
FUnIE-GAN	20.381	0.680	3.742	22.705	0.576	4.318	57.278	15.668
Water-Net	21.733	0.771	3.732	22.190	0.578	4.578	63.284	16.695
Ours	20.862	0.742	3.577	39.096	0.603	4.696	75.647	20.746

为了进一步评估不同方法的鲁棒性，在 UIEB 挑战和 EUVP 数据集上进行了全面的定量实验。表 5.3 展示了不同传统方法和基于数据驱动方法在 UIEB 挑战数据集上的平均量化分数。由表 5.3 分析可知，本章方法在所有基于数据驱动的方法中获得了最高的综合得分。具体来说，虽然传统方法相比于基于数据驱动方法在部分定量指标中获得了更高的量化分数，三种传统方法中的最高得分使用红色下划线标注。这一现象主要归因于传统方法通常是基于人类视觉感知特性进行优化，因此使得无参考指标中的某个分量值异常激增，从而导致更高的量化得分，而非真实反映水下图像质量的提升。相比之下，基于数据驱动的图像清晰化方法可以产生更

中国知网 https://www.cnki.net

加稳定且视觉上令人愉悦的增强图像，这得益于在训练过程中对多样化样本的学习和网络模型的设计。其中，本章方法在 UIEB 挑战数据集上获得了最优的全面性定量分数，得益于新的参数估计策略以及水下成像模型的嵌入，它无需学习复杂的失真域到清晰域之间的映射关系。

表 5.3 在 UIEB 挑战数据集上的定量实验结果

Tab. 5.3 Quantitative experimental results on the UIEB challenge dataset

方法	UIQM	CCF	UCIQE	EI	AG	Average
GDCP	0.999	26.381	0.573	1.986	30.993	12.186
IBLA	1.197	36.879	0.584	2.279	31.960	14.579
CBAF	2.337	14.827	0.574	2.410	32.946	10.618
TCTL-Net	1.409	22.295	0.576	1.695	28.869	10.968
TACL-Net	2.268	15.379	0.583	2.489	32.840	10.711
Ucolor	1.908	12.909	0.532	2.088	26.218	8.731
SGUIE-Net	1.555	16.911	0.577	1.775	22.354	8.634
TOPAL	1.888	14.679	0.534	1.917	26.626	9.128
U-shape	1.425	12.416	0.534	1.511	22.305	7.638
FUnIE-GAN	2.931	15.668	0.531	2.768	30.341	10.447
Water-Net	2.231	12.889	0.559	2.239	27.307	9.045
Ours	1.982	29.902	0.575	2.358	32.388	13.441

对于 EUVP 数据集而言，表 5.4 展示了不同传统方法和基于数据驱动方法在该数据集上的平均量化得分。由表 5.4 分析可知，虽然传统的水下清晰化方法仍然获得了最高的定量得分，但往往引入额外的色调或光晕现象，导致增强图像在视觉感知方面存在明显不足。相比之下，基于数据驱动的图像清晰化方法可有效校正水下图像的颜色失真，并显著提高对比度和能见度。其中，本章方法在多个定量指标上表现出色，除 UIQM 和 UCIQE 外，其余指标均获得了最高的得分，并且在所有非参考指标的综合评价方面也取得了最好的结果。需要说明的是，所提方法仅使用 UIEB 训练集作为整个模型的输入图像，而无需进行任何微调。

表 5.4 在 EUVP 数据集上的定量实验结果

Tab. 5.4 Quantitative experimental results on the EUVP dataset

方法	UIQM	CCF	UCIQE	EI	AG	Average
GDCP	2.457	39.939	0.606	5.157	96.310	28.893

中国知网 https://www.cnki.net

续表 5.4 在 EUVP 数据集上的定量实验结果

Tab. 5.4 Quantitative experimental results on the EUVP dataset (continued)

方法	UIQM	CCF	UCIQE	EI	AG	Average
IBLA	2.697	41.264	0.598	4.784	78.790	25.626
CBAF	3.967	25.820	0.586	4.971	81.301	23.329
TCTL-Net	3.629	32.280	0.594	4.638	72.350	22.698
TACL-Net	3.445	27.204	0.615	4.847	77.763	22.774
Ucolor	3.495	22.998	0.570	4.583	67.236	19.776
SGUIE-Net	2.956	29.665	0.610	4.585	75.003	22.563
TOPAL	3.317	29.763	0.577	4.657	77.941	23.251
U-shape	3.321	21.547	0.563	4.259	60.447	18.027
FUnIE-GAN	3.634	25.089	0.575	4.568	65.191	19.811
Water-Net	3.653	24.071	0.578	4.786	69.066	20.430
Ours	3.375	43.967	0.607	4.907	82.590	27.089

为了进一步分析所有基于数据驱动方法对水下图像颜色校正方面的性能，本节使用 SQUID 数据集进行了定量评估和比较。表 5.5 展示了所有基于数据驱动方法的平均重现误差。由表 5.5 分析可知，本章方法在四个子集中的两个子集实现了最低的平均重现误差指标，并且它在所有具有彩色图卡的图像上获得了最低的平均误差。相比于次优方法而言，本章方法在 SQUID 数据集中 Katzaa/Michmoret 位置的水下图像的误差百分比分别降低了 35%/29%。综上所述，所提方法在极端退化的水下场景中实现了更准确的颜色校正性能。

表 5.5 在 SQUID 数据集上的定量实验结果

Tab. 5.5 Quantitative experimental results on the SQUID dataset

方法	Kztza.	Nuchm.	Nachs.	Satil	Average
Raw	35.239	33.767	33.223	36.024	34.563
TCTL-Net	10.984	13.909	12.158	13.022	12.518
TACL-Net	27.566	28.336	30.292	28.950	28.786
Ucolor	16.885	20.143	23.088	16.432	19.137
SGUIE-Net	19.844	28.350	25.690	22.492	24.094
TOPAL	17.253	15.661	14.183	21.655	17.188
U-shape	12.033	14.284	22.654	15.848	16.205

中国知网 https://www.cnki.net

续表 5.5 在 SQUID 数据集上的定量实验结果

Tab. 5.5 Quantitative experimental results on the SQUID dataset (continued)

方法	Kztza.	Nuchm.	Nachs.	Satil	Average
FUnIE-GAN	32.267	29.459	29.074	33.669	31.117
Water-Net	23.991	21.148	18.609	22.756	21.626
Ours	7.090	9.776	17.002	15.212	12.270

5.4.4 消融实验

为了分析本章方法中每个组件的有效性，本节设计了一系列的消融实验，其中包括多颜色空间通道混洗模块（Multi-color Space Channel Shuffle Module, CSM）、偏置环境光参数估计模块（Biased Ambient Light Parameter Estimation Module, BEM）和衰减图（Attenuation Map, AM）。更具体地说：

（1）-w/o-CSM：在偏置环境光参数估计模块中不使用多颜色空间通道混洗模块。

（2）-w/o-HSV：在偏置环境光参数估计模块中不使用 HSV 色彩空间，意味着仅使用 LAB 颜色空间实现偏置环境光的估计。

（3）-w/o-AM：在通道混洗操作后得到的新通道中不使用相应的衰减图估计偏置环境光参数。

（4）-w/o-BEM：不使用偏置环境光参数估计模块，仅使用基本环境光参数估计模块生成最终的增强结果。

以上消融实验均使用 UIEB 数据集进行模型的训练，相应的实验设置与第 5.4.1 节保持一致。图 5.11 展示了模型通过消融不同组件在 LSUI 数据集上定性比较结果。

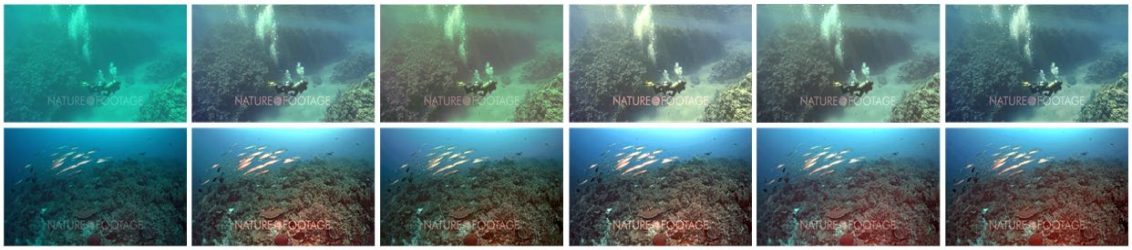


图5.11 消融实验的定性结果

Fig.5.11 Qualitative results of ablation experiment

由图 5.11(b)至图 5.11(e)观察可知，去除 CSM 模块的模型无法提供图像在不同颜色空间中的额外属性信息，从而削弱了模型的整体增强性能。此外，仅使用单一

中国知网 https://www.cnki.net

色彩空间（-w/o-HSV）可能会产生颜色伪影现象，并且色彩信息较为单一。去除相应通道的衰减图（-w/o-AM）无法为图像中不同区域提供差异性退化感知的能力，并且可能在图像的背景和高亮区域引入过饱和现象。完整模型与去除偏置环境光参数估计模块（-w/o-BEM）之间的比较突出了偏置环境光参数在估计不同通道透射率矩阵中的重要性。该模块的引入有助于模型生成更加全面的视觉效果和鲜艳的色彩信息，如图 5.11(f)所示。

此外，本节采用七个无参考定量评价指标以评估不同消融模型在 LSUI 数据集上的性能。表 5.6 展示了不同消融模型在 LSUI 数据集上的平均量化指标值。通过分析表 5.6 中数据可知，完整模型在 PSNR 和 SSIM 两个全参考指标中获得了最优和次优的定量得分。对于五个非参考定量评价指标而言，包含所有组件的完整模型实现了有效且均衡的增强性能，验证了所提每个组件的有效性。

表 5.6 不同消融模型在 LSUI 数据集上的定量结果

Tab. 5.6 Quantitative results of different ablation models on the LSUI dataset

方法	PSNR	SSIM	UIQM	CCF	UCIQE	EI	AG
-w/o-CSM	20.411	0.741	3.501	31.068	0.597	4.691	75.630
-w/o-HSV	20.643	0.718	3.644	38.236	0.576	4.545	67.400
-w/o-AM	20.326	0.748	3.686	35.764	0.609	4.848	81.405
-w/o-BEM	19.926	0.731	3.394	38.458	0.601	4.672	75.181
完整模型	20.862	0.742	3.577	39.096	0.603	4.696	75.647

5.4.5 应用实验

（1）水下低级视觉任务

为了验证主流水下图像清晰化方法在实际工业水下场景中的鲁棒性与适应性，本节通过安装于机械臂主臂末端的水下视觉采集设备，在不同水深、拍摄角度和不同目标物体条件下获取了真实的水下光学图像，如图 5.12(a)所示。由图 5.12(b)至图 5.12(j)分别展示了主流基于数据驱动的水下清晰化方法和本章所提方法在实际工业水下场景中的增强结果。观察可知，受限于训练样本的多样性和覆盖范围，主流基于数据驱动的水下图像清晰化方法在面对不同水体光学特性和非均匀退化的真实工业水下环境时，泛化能力往往较弱。相比而言，所提方法可有效改善不同类型水下光学图像的视觉感知、全局和局部对比度。

中国知网 https://www.cnki.net



图5.12 水下低级视觉任务

Fig.5.12 Underwater low-level vision task

（2）水下高级视觉任务

虽然本章方法主要针对水下低级视觉任务进行设计，但其也可以拓展至水下高级视觉任务中，通过提高输入图像的质量以改善后续任务的性能。本节使用主流的水下清晰化方法生成相应的高质量增强图像作为一系列水下高级视觉任务的输入，例如显著性检测[151]、人体姿态估计[152]和水下深度估计[153]。

图 5.13 展示了主流的水下清晰化方法所获得的增强图像以及在显著性检测任务中的表现。相比于其他方法，本章方法在保留图像细节方面表现出优越的性能，可实现更加精细的边缘检测结果，有助于为显著性检测框架的部署提供更高的准确性和可靠性，同时也证明了本章方法在高级视觉任务中的实用性。

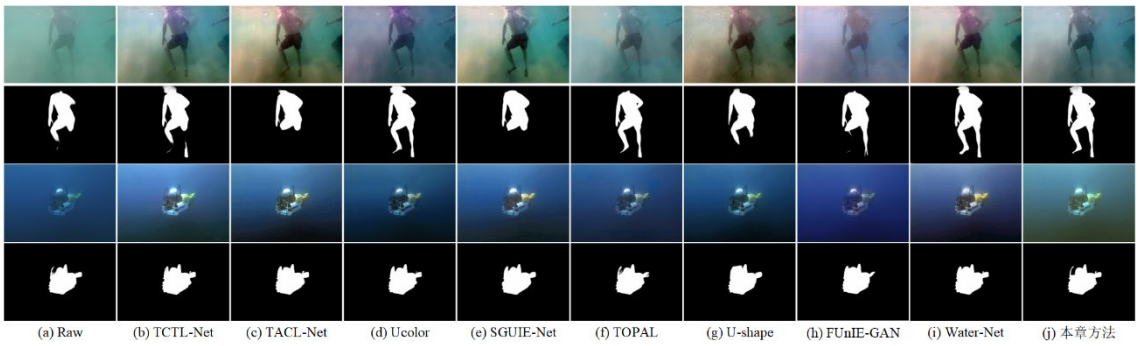


图5.13 水下显著性检测的应用示例

Fig.5.13 Application example of underwater saliency detection

对于人体姿态估计任务而言，通过本章方法生成的增强图像可显著提升关节点的检测精度。相比于其他水下清晰化方法，本章方法有效校正了颜色偏差并增强图像的细节信息，有助于提高人体姿态估计模型的鲁棒性和预测的可靠性，如图 5.14 所示。综上所述，本章方法不仅减少了由于水下图像质量退化引起的姿态估计误差，还提高了模型在多样化水下场景中的适应性，为后续水下人体行为分析和交互研究奠定了坚实的基础。

中国知网 https://www.cnki.net

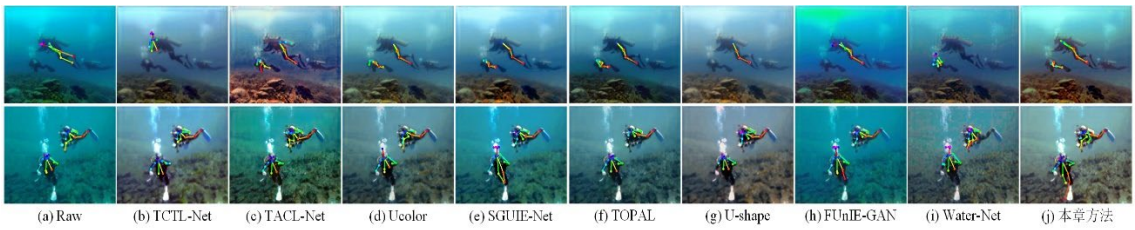


图5.14 水下人体姿态估计的应用示例

Fig.5.14 Application example of underwater human pose estimation

此外，由于水下图像视觉成像质量的降低，导致后续的深度估计任务面临诸多挑战，例如场景纹理模糊、颜色失真以及光学散射效应等问题，从而限制了开发精确深度估计算法的难度。因此，采用水下清晰化方法作为预处理步骤可有效地提高退化图像的质量，减少由于水介质对不同波长光的吸收和散射效应，从而为深度估计算法提供可靠的输入数据。如图 5.15 展示了不同水下清晰化方法所获得的增强结果和相应的深度估计图像。相比于其他方法而言，本章方法对退化的水下图像实现了良好的色彩增强和细节恢复，从而有助于生成更加精确和一致性的深度信息，为后续三维重建任务提供可靠的数据基础，推动了复杂水下环境中高质量三维模型的生成。

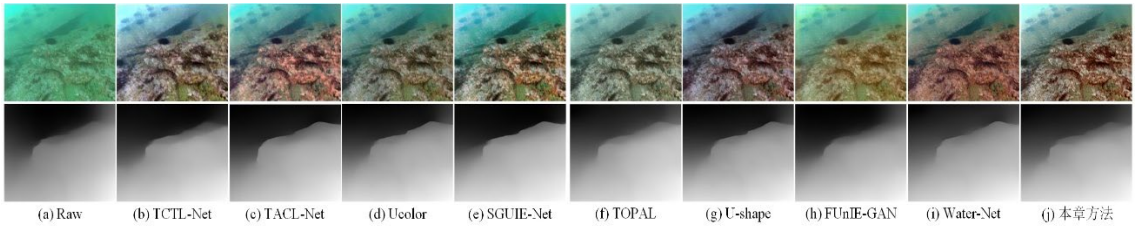


图5.15 水下深度估计的应用示例

Fig.5.15 Application example of underwater depth estimation

5.5 本章小结

针对水下光学图像中经常出现的非均匀退化问题，本章提出了一种基于成像模型和衰减图引导的水下图像清晰化方法。与直接学习退化域到清晰域之间映射的方法相比，本章方法侧重于从有限训练样本中估计水下成像模型的未知参数，以实现高效且鲁棒的水下图像增强。具体而言，首先提出了一种基于多颜色空间的通道混洗模块，用于提取同一幅图像在不同颜色空间下的多样化视觉表征。通过分析不同通道的特性，从而实现了通道间的融合与重组，有效提高了模型对不同图像属性的理解和表达能力。随后，引入相应通道的衰减图估计偏置环境光矩阵，从而根据图像中不同区域的退化特性实现了非均匀增强，提高了模型对退化水下图像的恢复能力。最后，利用多分支结构和空洞卷积将基本环境光参数、偏置环境光参数

中国知网 https://www.cnki.net

和原始图像相结合，以准确估计不同通道的透射图。此外，将水下成像模型集成到统一的框架来实现端到端策略，从而提高了模型的效率。在多个水下基准数据集（UIEB、EUVP、LSUI 和 SQUID）上的定性和定量实验证明了所提方法的有效性和鲁棒性，并且在低级和高级视觉任务上进一步说明本章方法的实用性。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第六章 基于图像增强和多分支结构的水下目标检测方法

6.1 引言

近年来，随着对海洋资源的开发和探索，水下目标检测技术在智能海洋应用中发挥着关键作用。然而，复杂的水下环境特性，例如水介质对光的吸收与散射、悬浮颗粒的干扰，以及水下目标物体的多尺度、遮挡和聚集等问题，严重制约了目标检测网络的性能。传统目标检测网络依赖于人工设计的先验特征，例如经典的梯度方向直方图（Histograms of Oriented Gradients, HoG）[154]和可变形部件模型（Deformable Part Model, DPM）[155]等。然而，这些方法对复杂场景下目标尺度的变化以及非刚性变形等鲁棒性较差，导致在水下场景下的检测性能往往不尽如人意。近年来，随着卷积神经网络在各种感知任务中的成功应用，研究人员致力于探索高效的检测框架、创新的学习策略以及即插即用的注意力机制模块，以增强模型的特征表征能力，从而提升水下目标检测网络的性能。目前的水下目标检测模型主要受到现有通用检测模型框架和水下图像清晰化方法的启发，通过结合两者的优势，从而改善水下目标检测的精度和鲁棒性[156]。然而，主流的水下光学图像清晰化方法并不能有效地增强所有退化类型的水下图像，显著弱化了目标物体的特征表征，从而限制了目标检测网络对关键特征的有效提取。此外，水下目标物体尺度变化大，且水介质的不透明性和拍摄角度的变化容易导致目标物体之间出现堆叠、边缘模糊和角点信息不清晰等问题，现有目标检测网络的特征转变能力有限。

针对上述问题，本章提出基于图像增强和多分支结构的水下目标检测方法，以提升退化水下图像的质量，并强化网络的特征表示能力，从而提高目标检测网络的精度，整体网络结构如图 6.1 所示。具体而言，首先对输入图像的光学特性进行分析，根据主要退化情况自适应选择相应最佳的水下清晰化方法以生成具有更高质量的图像作为检测网络的输入。随后，在增强图像基础上引入拉普拉斯算子设计输入模块，使网络模型能够捕获图像更深层次的边缘特征，以提升模型对关键目标特征提取的敏感度。同时，为了进一步提高模型的特征表示能力，构建了基于注意力机制和多分支结构的骨干网络和颈部网络，从而优化模型的特征提取和融合能力。最后，利用解耦检测头实现模型的回归和分类任务，有效提高了模型对水下多尺度目标的检测性能。实验结果表明，所提方法可显著提升水下目标检测网络的准确性和鲁棒性。此外，所提方法在水下自动目标抓取任务中也表现出良好的适应性与稳

中国知网 https://www.cnki.net

定性，有效提升了系统的整体性能。

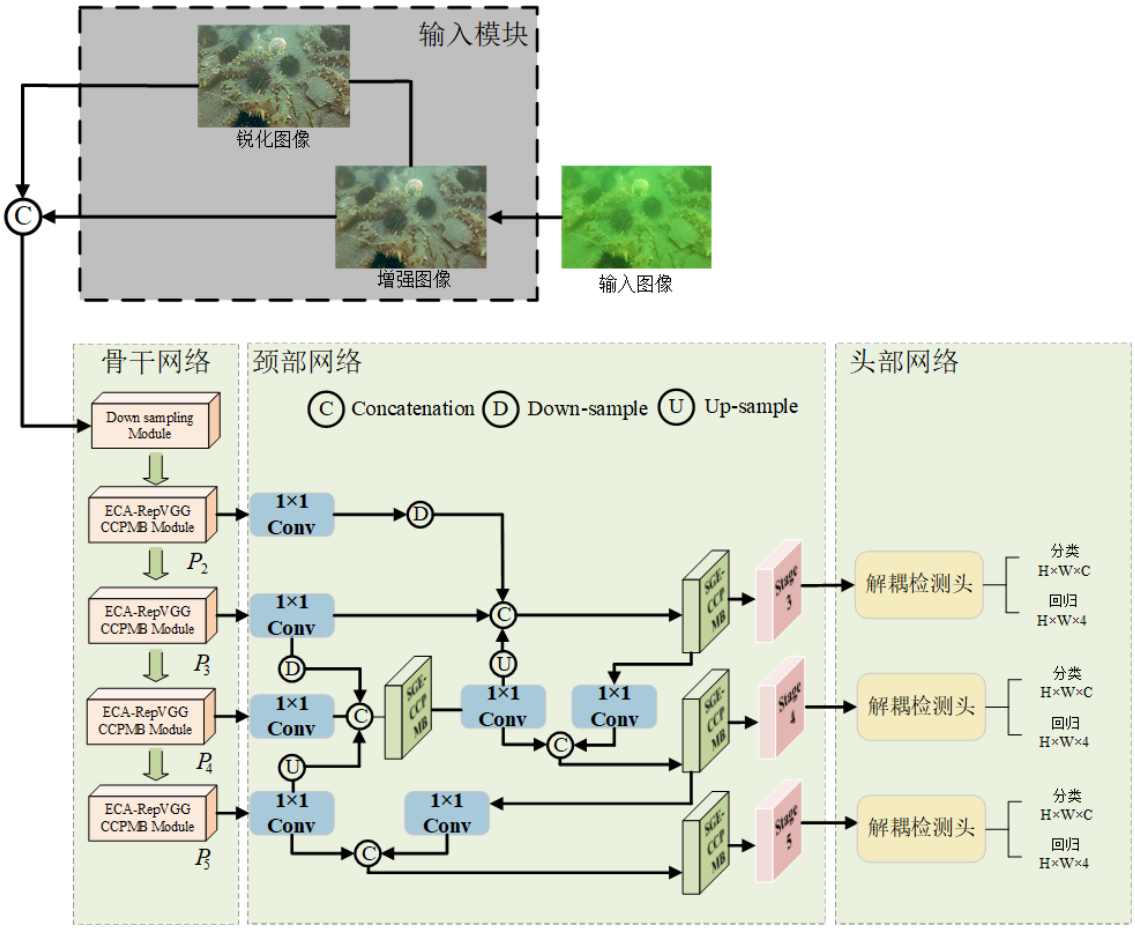


图6.1 所提方法的整体网络结构

Fig.6.1 The overall network structure of the proposed method

6.2 不同退化水下图像的光学特性

对不同退化水下图像的光学特性进行分析，并选择相应的图像清晰化方法，以为目标检测网络提供高质量的输入图像。如图 6.2 展示了具有不同光照条件的水下图像，其中包括典型的绿色低光照、全局低光照、光照不均匀以及人工光照环境下的水下图像。对于人类视觉感知系统而言，上述图像的光照问题显著影响对目标物体的辨识能力，同时降低了图像整体的细节表征质量，并且导致目标区域出现模糊或纹理细节信息丢失的问题。从退化图像的直方图分析可知，具有不同光照条件的水下图像，相应的三色直方图普遍集中于上半灰度区间，但各颜色通道直方图的峰值位置存在明显差异。对于该类水下图像，每个颜色通道的平均灰度值强度较小且分布范围较窄。综合上述分析，为了进一步定量评估不同色彩失真图像中每个颜色通道的灰度级分布特性，首先计算每个颜色通道的平均灰度值。上述计算过程可定义为：

中国知网 https://www.cnki.net

$$\overline{I}_c = \frac{1}{HW}\sum_{i=1}^{H}\sum_{j=1}^{W} I_c(i,j), c \in \{R,G,B\} \tag{6-1}$$

其中，H 和 W 分别代表输入图像的高度和宽度。随后，根据不同通道的平均灰度值将最大灰度值、中等灰度值和最小灰度值相应的颜色通道分别定义为信息衰减最小 $C_{\min}$、信息衰减次优 C_{mid} 和衰减最严重的通道 $C_{\max}$。最后，计算信息衰减最小颜色通道与信息衰减最严重颜色通道的平均灰度值差为 G_h。同时，信息衰减次优颜色通道与信息衰减最严重颜色通道的平均灰度值差为 G_m。此外，定义 G_h 在衰减最严重颜色通道中的占比为 K_h，G_m 在衰减最严重颜色通道中的占比为 K_m，相应的数学关系可表示为：

$$\begin{cases} K_h = \dfrac{C_{\min} - C_{\max}}{C_{\max}} = \dfrac{G_h}{C_{\max}} \\ K_m = \dfrac{C_{\mathrm{mid}} - C_{\max}}{C_{\max}} = \dfrac{G_m}{C_{\max}} \end{cases} \tag{6-2}$$

因此，当输入图像中不同颜色通道之间的灰度级占比在 $K_h + K_m < 2.225$ 时，则将该类图像视为光照不均匀的水下图像，采用 BME-AG 方法以生成相应的增强结果。

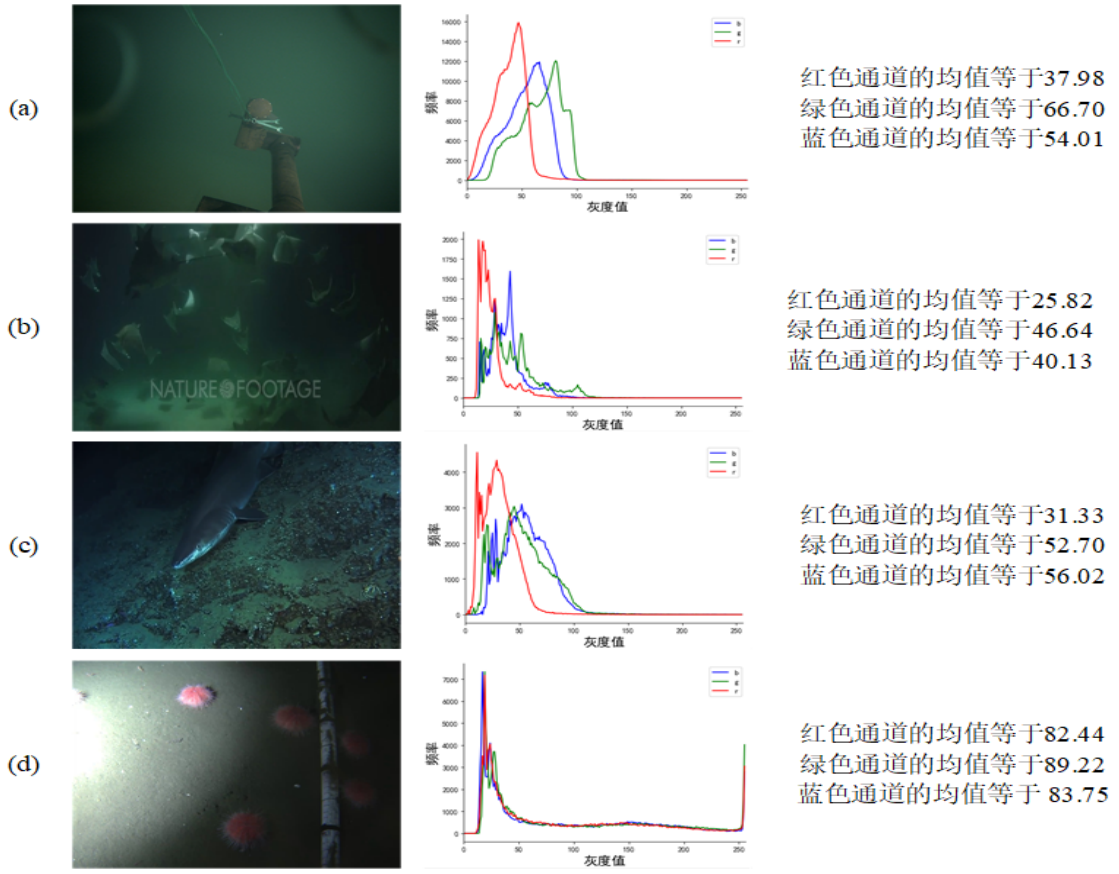


图6.2 不同光照条件水下图像的特性

Fig.6.2 Characteristics of underwater images with different lighting conditions

中国知网 https://www.cnki.net

图 6.3 展示了具有代表性颜色失真现象的水下图像，其中包括绿色、蓝色、黄色和蓝绿色外观的水下图像。对于人类视觉感知系统而言，上述图像的颜色失真现象显著降低了图像的视觉可读性和对图像内容的理解，并且弱化了目标检测网络对目标物体关键特征的提取能力。

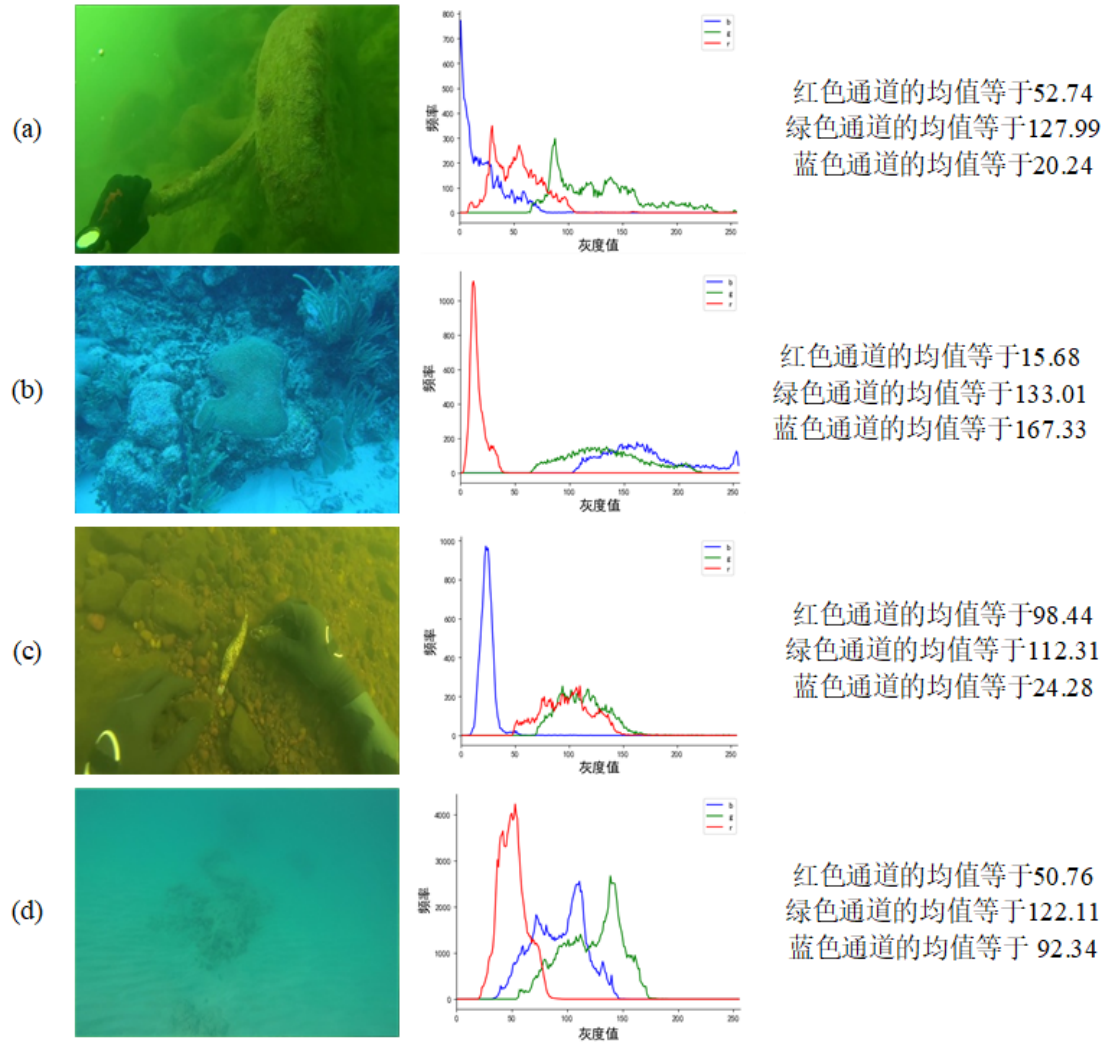


图6.3 单一色调水下图像的特性

Fig.6.3 Characteristics of single-tone underwater images

根据图 6.3 相应的直方图分析可知，对于具有绿色外观的水下图像，绿色通道的直方图通常在整个灰度区间范围内分布较广，而红色通道和蓝色通道的直方图普遍集中于上半灰度空间且分布范围较窄。对于具有蓝色外观的水下图像，绿色通道和蓝色通道具有更广的灰度值分布范围，蓝色通道相比于绿色通道的灰度值普遍集中于较高的灰度区间，而红色通道的灰度值分布相对较窄且集中于[0,50]的低灰度区间。对于具有黄色外观的水下图像，蓝色通道的灰度值广泛集中在小于 55 的低灰度区间，而红色通道和绿色通道的灰度值相对分布较广。对于具有蓝绿色外观的水下图像，三个颜色通道普遍集中在灰度区间的中心附近，在小于 75 和大于

中国知网 https://www.cnki.net

180 的灰度值几乎完全衰减。对于该类水下图像，本节引入图像熵以衡量输入图像信息的定量指标。具体而言，当输入图像的 $K_h+K_m \geq 2.225$ 且熵指标 $Entropy<7.244$ 时，则将该类图像视为具有单一色调的水下图像，采用 LAWB-MSF 方法以生成相应的增强结果。

图 6.4 展示了具有严重色偏和非均匀退化现象的水下图像，其中包括典型的严重色偏、下视场景、前视场景和存在强后向散射现象的水下图像。对于人类视觉感知系统而言，上述图像存在严重的色彩失真及纹理细节模糊和低能见度等问题，显著限制了人类对目标物体的辨识和解析能力。

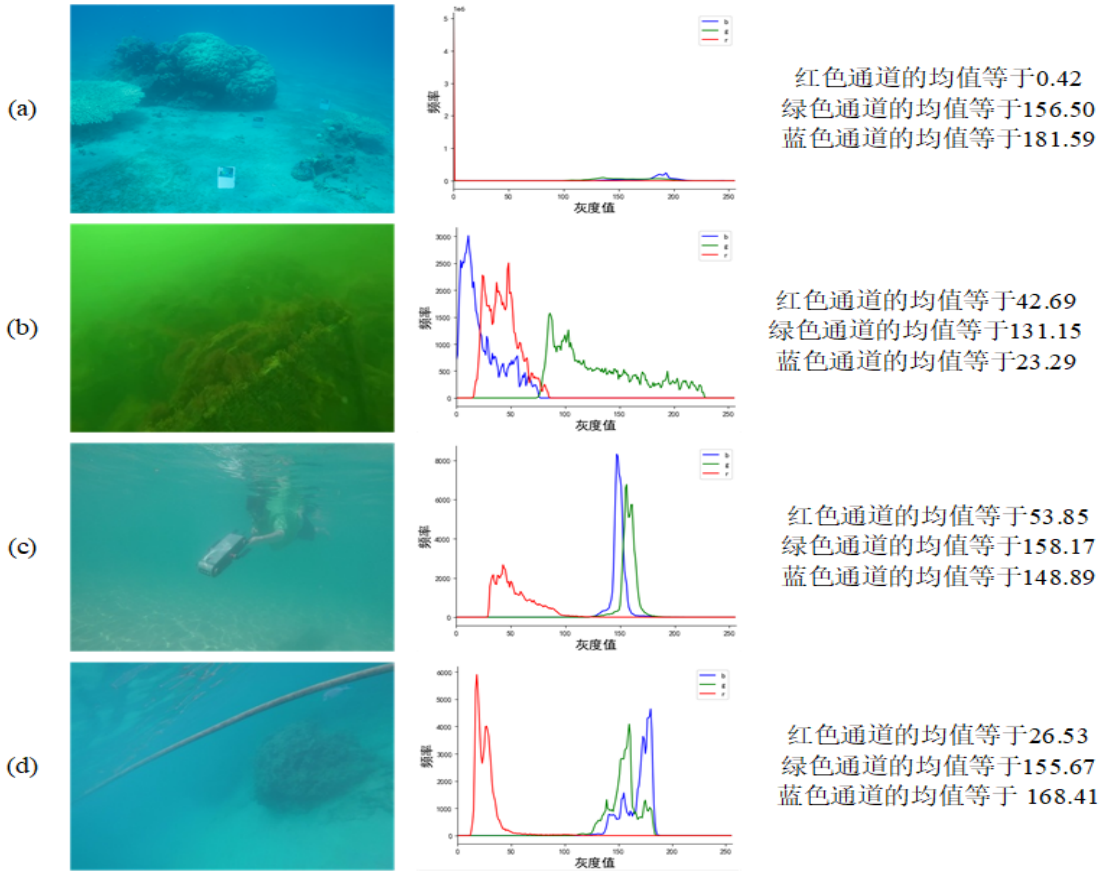


图6.4 严重色偏和非均匀退化水下图像的特性

Fig.6.4 Characteristics of underwater images with severe color cast and non-uniform degradation

根据图 6.4 相应的直方图分析可知，对于具有严重蓝色主导的水下图像，红色通道的直方图被严重衰减，而绿色通道和蓝色通道的直方图仅占据灰度区间内的一小部分，且图像整体视觉效果呈现模糊的现象。对于具有严重绿色主导的下视水下图像，红色通道和蓝色通道的灰度值分布主要集中在低灰度区间中，而绿色通道的灰度值则占据较宽的灰度区间，整体具有较高的灰度值范围。对于具有蓝绿色外观的前视水下图像，各个颜色通道的灰度值分布较窄，且集中于整个灰度区间的中低范围，表明该类图像整体对比度低、颜色信息受到一定程度的压缩。对于存在强

中国知网 https://www.cnki.net

后向散射的水下图像，三个颜色通道的灰度值分布分散且不均匀。在数字图像中，低灰度值的分布情况通常可作为衡量图像纹理丰富度的指标。因此，通过分析相应直方图分布情况可知，该类图像受到了水介质非均匀退化的影响，导致纹理细节信息的丢失。当输入图像的 $K_h+K_m \geq 2.225$ 且图像熵 $Entropy \geq 7.244$ 时，则将该类图像视为具有非均匀退化的水下图像，使用 UIMPL 方法以生成相应的增强结果。

基于上述对典型水下场景光学图像特性的分析，本文通过设置两种条件判定模块将不同退化类型的原始水下光学图像划分为三种处理方式，从而为后续目标检测网络提供高质量的增强图像以提升目标检测网络的精度和鲁棒性，整体流程如图 6.5 所示。

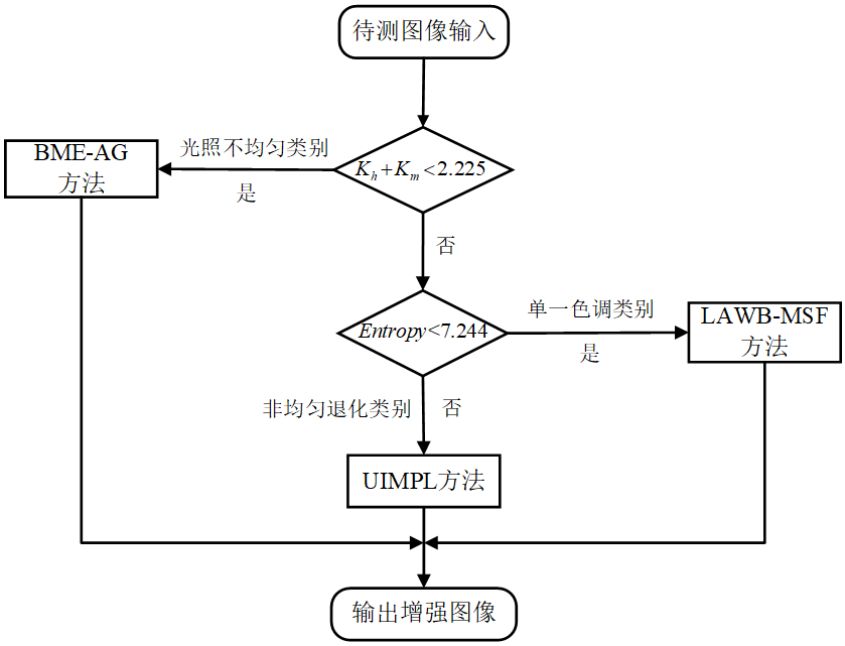


图6.5 不同图像清晰化方法的整体流程

Fig.6.5 The overall process of different image sharpening methods

6.3 基于注意力机制和多分支结构的目标检测方法

根据上述对不同退化程度水下图像分析的基础上，利用本文提出的图像清晰化方法对相应的输入图像进行预处理以显著改善图像的质量，并输入至水下目标检测网络中。此外，根据水下目标的特点，进一步优化了目标检测网络的结构以提高模型在复杂水下环境中的有效性和鲁棒性。本节提出的目标检测模型主要由输入模块、骨干网络（特征提取模块）、颈部网络（特征融合模块）和头部网络四部分组成。

中国知网 https://www.cnki.net

6.3.1 输入模块

在真实的水下环境中，由于水介质的高散射性、不透明性以及拍摄角度的局限性，导致水下图像中目标物体之间存在堆叠、边缘模糊和角点信息不清晰等现象，从而限制了目标检测网络对特征的有效学习和目标的辨识能力。尽管上述清晰化方法能够显著改善退化水下光学图像中的颜色失真、雾状效应和低对比度现象，但为了进一步提高模型对图像边缘细节特征的学习能力，本节提出一种基于锐化滤波器的输入模块。具体而言，在图像清晰化技术的基础上，引入锐化滤波器以对目标区域的边缘纹理信息进行强化表达，从而突出目标区域的细节特征且丰富输入特征的信息维度。

该输入模块的锐化滤波器采用拉普拉斯算子有效地捕捉图像中灰度变化较大的区域，从而强化目标物体的边缘细节特征且抑制背景干扰，为后续模型提供更加丰富的特征信息。具体而言，利用拉普拉斯算子对增强图像进行卷积以生成锐化图像，从而强化目标边缘特征和抑制环境干扰，进一步提高水下目标检测网络的精度和鲁棒性。受通道注意力机制[157]的启发，本节提出一种基于锐化滤波器的通道注意力模块。相比于传统通道注意力机制模块，该模块考虑了水下环境中所特有的颜色失真和纹理细节模糊等退化问题，同时具有计算效率高和实现简单的优势。该模块直接在通道维度方面将增强图像与锐化图像进行融合，从而全面地捕捉图像的细节信息和语义特征，整体结构如图 6.6 所示。需要说明的是，本章将输入模块置于骨干网络之前，旨在将增强图像与锐化图像合并为六通道图像，并作为目标检测网络的输入，从而突出目标物体的边缘细节信息。综上所述，本节设计的输入模块使模型在输入阶段就更多地关注目标区域的边缘特征，有效强化模型对目标区域的细节表征能力，从而提升模型在复杂水下环境的鲁棒性。与传统三通道的输入图像相比，该模块不仅保留与增强图像相似的高层语义特征信息，还引入额外的锐化轮廓特征增强了通道与关键信息之间的相关性，从而有助于后续模型对水下目标的特征学习和表达能力。

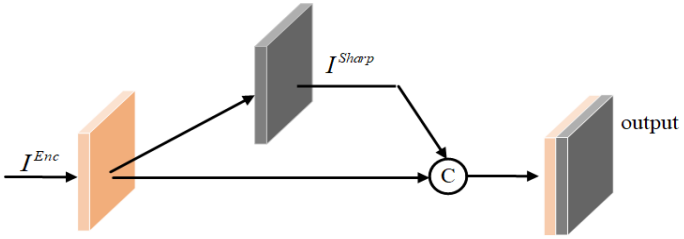


图6.6 输入模块的整体结构

Fig.6.6 Overall structure of the input module

中国知网 https://www.cnki.net

6.3.2 骨干网络

骨干网络作为目标检测框架中的核心的特征提取模块，负责从输入图像中提取多尺度、多层次的特征信息。该网络的结构设计对检测模型的性能和效率具有至关重要的影响。最近前沿算法通常采用通过设计更宽或者更深层的网络结构以提高模型的特征提取性能，但往往伴随着计算复杂度的显著增加，从而导致模型推理效率的降低[158-161]。此外，模型复杂的拓扑结构不利于硬件的并行计算，从而导致推理延迟的增加，并降低内存的利用率。尽管最近主流的轻量化神经网络采用深度可分离卷积[147]和通道混洗模块[162]有效减少模型参数量和计算复杂度，但增加了内存访问的成本，并且缺乏对不同架构设备的兼容。此外，浮点运算量（Floating-Point Operations, FLOPs）并不能准确反映模型的实际推理速度。因此，本节受重参数化技术[163]的启发，将训练阶段与推理阶段进行解耦，即转换不同结构的参数以实现复杂结构到简化结构之间的转换。具体而言，本节提出一种基于跨阶段和注意力机制的骨干网络以实现水下目标的特征提取。该骨干网络的基本组成模块如图 6.7 所示，其中包括下采样模块（Down-sampling Module, DM）、基于高效通道注意力的重参数化模块（Re-parameterization Module based on Efficient Channel Attention, ECA-RepVGG）和跨通道局部多分支模块（Cross Channel Partial Multi-branch, CCPMB）和高效通道注意力（Efficient Channel Attention, ECA）四部分。具体而言，下采样模块由一个3×3标准卷积和一对非对称卷积组成的多分支结果，其旨在实现快速且高效的特征下采样。该模块中的标准卷积用于提取图像中丰富的局部特征信息，非对称卷积则是用于分解高维卷积操作，在减少模型计算量的同时保留更多的图像特征信息，整体结构如图 6.7(a)所示。

受残差连接在深度网络中可有效缓解梯度消失问题的启发，本节提出一种基于高效通道注意力的重参数化模块以实现不同尺度特征的下采样操作[158]。该模块在训练阶段引入多分支结构和高效通道注意力机制，以关注图像中的目标特征区域，有效提高模型的感知能力。而在推理阶段，利用重参数化技术将多分支结构的参数转换为等价的单路径结构以减少模型的计算复杂度，从而提高推理效率，整体结构如图 6.7(b)所示。值得注意的是，该模块仅在模型下采样阶段（即：阶段 2 至阶段 5）时使用，以增强模型对不同尺度目标的关注能力。

受跨阶段局部网络（Cross stage partial network, CSPNet）的启发[164]，本节提出一种跨通道局部分支模块作为骨干网络中的核心特征提取组件，如图 6.7(c)所示。该模块通过拆分网络中的输入特征图，随后分散至不同的网络路径进行传播和融

中国知网 https://www.cnki.net

合，在保证梯度信息多样性和互补性的同时减少了冗余计算和模型的参数量，从而间接优化了梯度流的传播以提高模型的推理速度和准确率。具体而言，该模块首先将输入特征图沿通道维度划分为两部分，其中一部分通过多分支残差结构进行特征提取，而另一部分则直接与多分支残差结构的输出沿通道维度进行堆叠，以在减少模型计算量的同时强化全局语义信息和局部信息的特征表达。该多分支残差结构首先利用3×3卷积层对输入的局部特征图进行特征提取，随后使用1×1卷积层调整输出特征图的维度，以实现与主分支进行逐元素相加操作。最后，通过批量归一化（Batch Normalization, BN）操作对融合后的特征进行归一化以避免梯度消失和爆炸的问题。

高效通道注意力模块旨在通过捕获图像全局的语义信息来生成通道维度的权重分布，从而增强网络对图像中关键特征信息的关注能力，并抑制冗余信息的干扰，整体结构如图 6.7(d)所示。具体而言，该模块首先引入全局平均池化将输入特征图空间维度的信息压缩为通道维度的统计特征，以反映不同通道在全局上下文信息中的重要性。随后，通过3×3标准卷积以捕获不同通道间的局部特征关系，从而生成具有判别性的特征权重分布。最后，利用 Sigmoid 激活函数进行归一化，将特征图的权重值归一化至[0,1]之间，从而动态调整输入特征图中每个通道的贡献程度。值得注意的是，ECA 模块被添加至 ECA-RepVGG 模块和 CCPMB 模块的尾部以生成输出特征图。

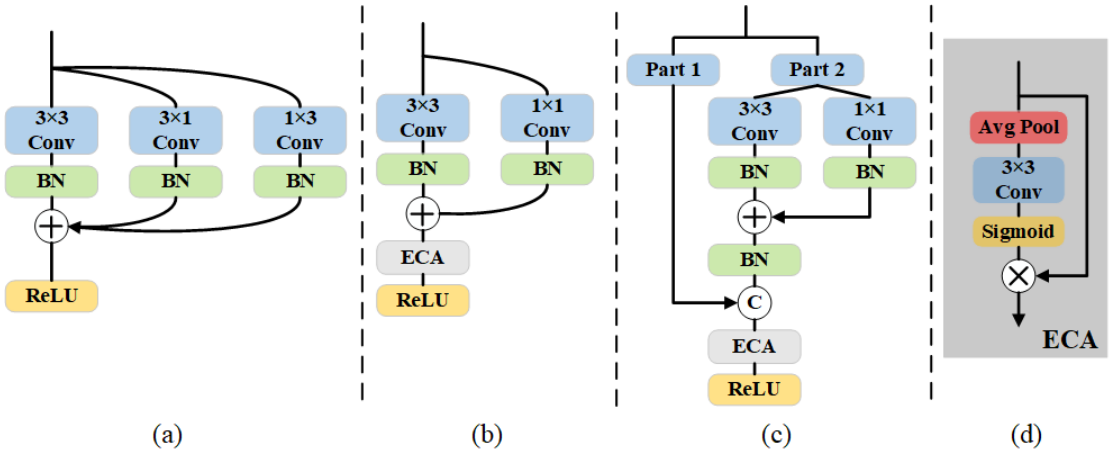


图6.7 骨干网络的基本组成模块

Fig.6.7 Basic module of the backbone network

6.3.3 颈部网络

在目标检测网络中，颈部网络作为连接骨干网络和头部网络之间重要的组成部件，旨在通过多尺度融合策略和特征增强等技术对骨干网络生成的特征图进行

中国知网 https://www.cnki.net

融合和优化，从而提高目标检测网络整体的性能[165]。为了提高目标检测框架中的信息流，本节提出一种基于空间组增强模块和 CCPMB 相结合的特征融合模块，整体结构如图 6.8 所示。具体而言，本节使用自底向上的路径逐层增强骨干网络中不同阶段生成的特征图，通过融合图像中浅层特征的细节信息和高层特征的语义信息，从而生成新的特征映射图。为此，利用 CCPMB 模块的优势，通过拆分和融合跨通道的梯度流以提高不同尺度特征的多样性和互补性，强化网络对感兴趣区域的关注能力以及学习目标与背景之间的差异信息，从而提高目标检测网络对水下小目标的检测能力。此外，将空间组增强模块（Spatial Group-wise Enhance, SGE）嵌入至 CCPMB 模块中，通过对特征图中每个语义组的空间位置生成相应的注意力因子以动态衡量每个子特征的重要性，从而强化每个语义组的特征表示能力并抑制环境噪声的干扰。因此，在颈部网络中，利用骨干网络中第二、三、四和五阶段生成的特征图，通过相应的上采样、下采样以及1×1卷积将高层特征与浅层特征进行融合后输入至 SGE-CCPMB 模块，从而实现模型对水下多尺度目标的感知和辨别能力。

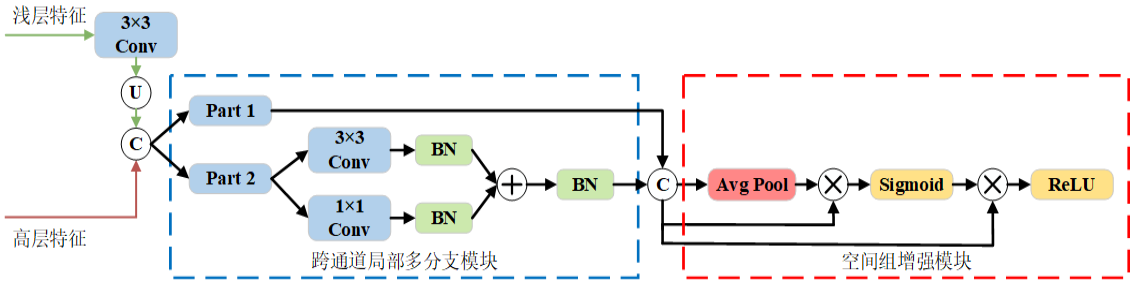


图6.8 特征融合模块

Fig.6.8 Feature fusion module

6.3.4 头部网络

头部网络用于对颈部网络生成的特征图进行预测，从而获得目标检测网络的最终结果，包括目标类别的置信度和边界框的位置信息。受 Double-Head[166]、FCOS[167]和 YOLOX[168]等方法通过解耦分类任务和回归任务以提高目标检测器性能的启发，本节引入一种高效的解耦头以生成最终的预测结果，整体结构如图 6.9 所示。

中国知网 https://www.cnki.net

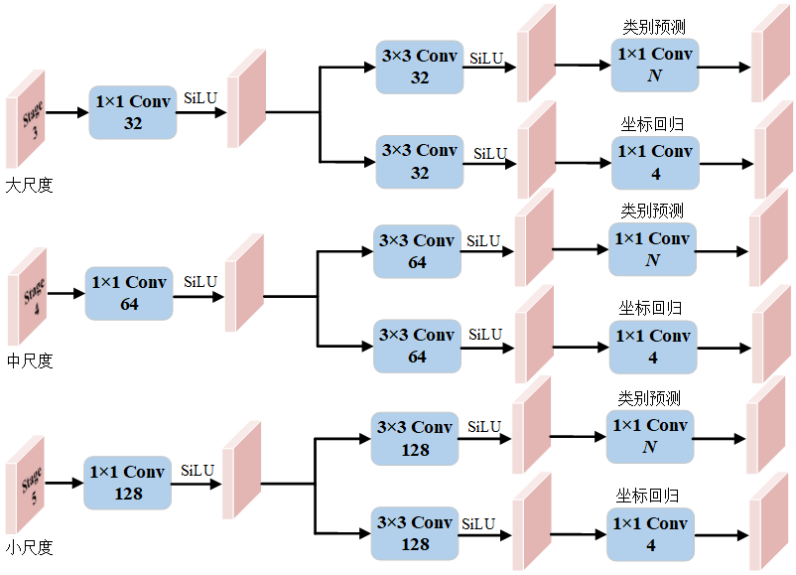


图6.9 头部网络整体结构

Fig.6.9 The overall structure of the head network

由图 6.9 观察可知，该头部网络由类别预测分支和坐标回归分支两部分组成，分别对颈部网络第三阶段至第五阶段生成的大、中和小尺度特征图进行处理。其中，类别预测分支和坐标回归分支均由单个3×3卷积层和单个1×1卷积层组成，以输出目标的类别置信度 N 和相应的位置信息。值得注意的是，该网络首先通过1×1卷积和 SiLU 激活函数对颈部网络生成的特征图进行通道维度调整和非线性映射，以强化特征表达。随后，将处理后的特征图分别输入至相应的分支以实现类别的预测和边界框的回归。综上所述，该解耦头有效减少了计算复杂度，并且充分利用了图像多尺度特征信息，从而提高了模型的检测性能。

6.4 实验结果与分析

本节首先介绍了所提目标检测方法使用的水下目标检测数据集和相关实验设置。其次，将本章方法与主流基于数据驱动的水下目标检测方法在上述数据集上进行了全面的比较与分析。最后，设计一系列的消融实验进一步验证本章方法的有效性和稳定性。

6.4.1 水下目标检测数据集

本章实验使用开源的水下目标检测数据集（UODD）以验证不同检测方法的性能[157]。具体而言，该数据集包含 19k 个水中常见的三类目标，包括海参、海胆和扇贝，如图 6.10 所示。其中训练图像共计 2560 幅，验证图像 128 幅以及测试图像 506 幅。该数据集的图像来源于真实环境的水下图像增强数据集（Real-world

中国知网 https://www.cnki.net

Underwater Image Enhancement Dataset, RUIE）[114]，其中包含丰富的水下目标样本和多种光学退化问题，如颜色失真、对比度低、弱光以及非均匀退化等。本节使用全部训练图像和验证图像进行不同网络模型的训练，并通过测试图像验证不同方法的检测性能。

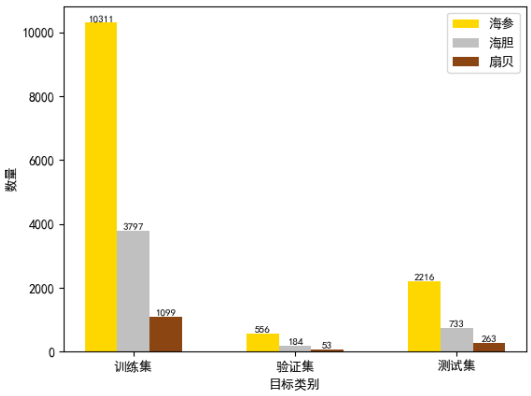


图6.10 水下目标检测数据集中不同类别的统计信息

Fig.6.10 Statistics of different categories in the underwater object detection dataset

6.4.2 实验设置

本章的目标检测网络是在 Ubuntu 16.04 操作环境下基于 PyTorch 框架进行编译，网络训练和测试均使用一台 GPU 服务器（Nvidia GeForce GTX 3090 GPU、Intel Core i9-12900k CPU 和 128GB RAM）实现，且不引入额外的预训练权重。本章模型在训练阶段采用带动量的随机梯度下降方法以优化模型参数，参数设置为 0.937，并引入余弦衰减策略来调整学习率。整个模型共迭代 400 轮，批大小设置为 32。每训练 20 次使用验证图像进行验证，以引导模型的收敛方向。锚框的形状和大小遵循该数据集 K-means 聚类算法所获得的默认设置，以更好地适应目标的分布特征[157]。此外，为了增强模型的泛化能力和鲁棒性，本章采用前三章提出的图像清晰化方法、图像翻转和主流的数据增强方法（Mosaic[169]和 Mixup[170]）扩充水下的训练样本数据。定量评价指标使用平均检测精度（Mean Average Precision, mAP）和平均召回率（Average Recall, AR）。其中，mAP 和 AR 在不同的交并比（Intersection Over Union, IoU）阈值下进行计算，以全面衡量不同模型的检测精度和目标的召回能力，AP 代表 IoU 分别为 $0.5, 0.55, \ldots 0.95$ 情况下的 mAP 平均值，$AP_{0.5}$ 和 $AP_{0.75}$ 分别代表 IoU 值为 0.5 和 0.75 情况下的 mAP 值，AR_1 表示每幅图像中每个类别仅保留 1 个的平均召回率，AR_{10} 表示每幅图像中每个类别最多保留 10 个的平均召回率。

中国知网 https://www.cnki.net

6.4.3 对比实验

本节通过与目前主流的目标检测方法（YOLO-CSAM[157]、YOLOv6-N[171]、YOLOv10-N[172]、YOLOv11-N[173]、YOLOv12-N[174]、FCOS[167]、ATSS[175]、CornerNet[95]、Faster R-CNN[88]、Mask R-CNN[89]、Cascade R-CNN[90]）进行比较，以验证所提方法在水下小目标检测任务中的有效性和鲁棒性。其中，单阶段目标检测方法中包括基于锚框和无锚框两类：基于锚框的方法（YOLO-CSAM、YOLOv6-N、YOLOv10-N、YOLOv11-N 和 YOLOv12-N）通过预定义的锚框预测目标的类别和位置，而无锚框的方法（FCOS、ATSS 和 CornerNet）则是直接回归目标的关键点或位置参数，以实现目标检测的任务。双阶段目标检测方法（Faster R-CNN、Mask R-CNN 和 Cascade R-CNN）首先通过区域建议网络（Region Proposal Network, RPN）生成候选区域，随后根据候选区域进行目标的分类和位置的回归。为了保证对比实验的公平性，本章均直接使用原论文作者在 UODD 数据集上提供的原始代码和相应预训练权重进行实验。表 6.1 展示了主流目标检测方法与相应骨干网络在 UODD 数据集中的平均检测精度。相比于基于锚框的方法，本章方法在 IoU 为 0.5,0.55,…0.95 的情况下平均检测精度分别显著提高了 3.2%、1.9%、2.5%、2%和 0.6%。此外，通过分析三类不同尺度的平均准确度，进一步验证本章方法在捕捉多尺度目标特征方面的有效性，同时显著提升在不同光学退化条件下目标的检测性能。对于无锚框的检测方法，本章方法在不同阈值下的平均检测精度方面展现出优越的性能。具体而言，CornerNet 和 FCOS 分别获得了无锚框检测方法中最高的 AP 和 AP_S 定量指标值，但这些指标值远小于本章方法所获得的结果。由于双阶段目标检测方法首先通过 RPN 网络生成候选框，随后再进行分类和回归任务，因此在精度方面通常具有较高的优势。然而，上述方法在水下目标检测任务中存在挑战，主要由于水下环境中存在复杂的光学退化以及目标尺度变化大等问题，导致 RPN 网络生成候选框的性能不佳，从而影响网络的最终检测精度。综上所述，所提方法通过设计高效的网络结构以及学习策略，充分结合大分辨率和小分辨率的特征图以捕获丰富的细节和语义信息，有效改善了目标检测网络在水下环境中的性能。

表 6.1 主流目标检测模型在 UODD 数据集上的平均检测精度

Tab. 6.1 Average detection accuracy of mainstream object detection models on the UODD dataset

方法	骨干网络	AP	$AP_{0.5}$	$AP_{0.75}$	AP_S	AP_M	AP_L
YOLO-CSAM	DarkNet-53	0.501	0.894	0.505	0.326	0.503	0.615
YOLOv6-N	EfficientRep	0.514	0.861	0.569	0.375	0.514	0.681

中国知网 https://www.cnki.net

续表 6.1 主流目标检测模型在 UODD 数据集上的平均检测精度

Tab. 6.1 Average detection accuracy of mainstream object detection models on the UODD dataset (continued)

方法	骨干网络	AP	$AP_{0.5}$	$AP_{0.75}$	AP_S	AP_M	AP_L
YOLOv10-N	CSPBottleneck	0.508	0.871	0.543	0.402	0.503	0.687
YOLOv11-N	CSPVariants	0.513	0.890	0.548	0.412	0.498	0.686
YOLOv12-N	AreaAttention	0.527	0.900	0.553	0.441	0.513	0.701
FCOS	ResNeXt-101	0.453	0.811	0.486	0.354	0.463	0.534
ATSS	ResNet-101	0.452	0.857	0.421	0.302	0.453	0.548
CornerNet	Hourglass-104	0.478	0.863	0.461	0.346	0.473	0.573
Faster R-CNN	ResNet-101	0.455	0.850	0.438	0.290	0.455	0.574
Mask R-CNN	ResNeXt-101	0.472	0.860	0.452	0.325	0.478	0.552
Cascade R-CNN	ResNet-101	0.463	0.853	0.438	0.293	0.462	0.589
本章方法	CCPMB	0.533	0.892	0.568	0.450	0.520	0.699

此外，引入平均召回率衡量不同模型在给定条件下正确检测到目标的能力。具体而言，通过计算不同阈值下的 AR 值以评估模型对不同尺度和位置的目标覆盖能力，如表 6.2 所示。相比于主流目标检测网络方法，除 AR_1 指标上获得次优结果外，本章方法在其余不同阈值设置下均获得了最高的召回率，证明了所提方法在复杂水下环境中对小目标和遮挡目标方面的有效性。

表 6.2 主流目标检测模型在 UODD 上的平均召回率

Tab. 6.2 Average recall of mainstream object detection model on the UODD dataset

方法	骨干网络	AR_1	AR_{10}	AR_{100}	AR_S	AR_M	AR_L
YOLO-CSAM	DarkNet-53	0.154	0.553	0.601	0.487	0.601	0.678
YOLOv6-N	EfficientRep	0.168	0.556	0.613	0.594	0.609	0.731
YOLOv10-N	CSPBottleneck	0.165	0.540	0.594	0.528	0.587	0.735
YOLOv11-N	CSP Variants	0.176	0.542	0.589	0.526	0.574	0.720
YOLOv12-N	AreaAttention	0.174	0.564	0.611	0.524	0.600	0.737
FCOS	ResNeXt-101	0.162	0.515	0.573	0.538	0.566	0.626
ATSS	ResNet-101	0.154	0.514	0.558	0.460	0.559	0.636
CornerNet	Hourglass-104	0.150	0.530	0.560	0.449	0.560	0.650
Faster R-CNN	ResNet-101	0.147	0.500	0.526	0.353	0.527	0.632

中国知网 https://www.cnki.net

续表 6.2 主流目标检测模型在 UODD 上的平均召回率

Tab. 6.2 Average recall of mainstream object detection model on the UODD dataset (continued)

方法	骨干网络	AR_1	AR_{10}	AR_{100}	AR_S	AR_M	AR_L
Mask R-CNN	ResNeXt-101	0.156	0.514	0.539	0.418	0.543	0.645
Cascade R-CNN	ResNet-101	0.152	0.507	0.532	0.372	0.531	0.643
本章方法	CCPMB	0.175	0.575	0.641	0.599	0.632	0.750

6.4.4 消融实验

本节通过一系列的消融实验，验证了针对不同水下退化特性所设计的图像清晰化方法对提升目标检测网络性能方面的有效性。具体而言，本节通过消融不同章节的水下清晰化方法，以研究不同预处理方法对整体目标检测模型的效用。此外，根据输入模块的设计理念，分别将原始图像与增强图像、原始图像、增强图像与锐化特征图以及增强图像与锐化特征图三种不同的融合策略作为目标检测模型的输入，以评估不同输入组合对整体目标检测模型的影响。

（1）消融不同水下图像清晰化方法

在部分实验中，首先对原始 UODD 数据集中的图像采用不同的水下清晰化方法进行预处理，以生成目标检测网络的输入图像。随后，根据不同清晰化方法所获得的增强图像，分别按照第 6.4.2 节所述的实验设置训练四个目标检测模型。值得注意的是，本部分消融实验未引入输入模块，仅使用增强图像作为目标检测网络的输入。表 6.3 展示了不同清晰化方法在 UODD 数据集中的平均检测精度和平均召回率。相比于原始水下图像而言，单独使用不同章节的水下图像清晰化方法可有效提高目标检测模型的检测性能，在 IoU 为 0.5,0.55,…0.95 情况下的平均检测精度分别提高了 2%、1%和 2.3%。上述实验验证了不同清晰化方法可显著抑制水下光学图像中的退化问题，从而提升目标检测模型的有效性和鲁棒性。此外，整体清晰化方法可显著改善不同特点水下图像的纹理细节和语义信息，从而增强模型对水下目标的特征学习和辨识能力，最终获得了最高的平均检测精度，进一步证明了高质量输入图像对于提升目标检测模型的性能是至关重要的。

表 6.3 定量比较不同清晰化方法在目标检测模型上的性能

Tab. 6.3 Quantitative comparison of the performance of different sharpening methods on the object detection model

方法	AP	$AP_{0.5}$	$AP_{0.75}$	AR_1	AR_{10}	AR_{100}
原始图像	0.480	0.871	0.479	0.144	0.528	0.603

中国知网 https://www.cnki.net

续表 6.3 定量比较不同清晰化方法在目标检测模型上的性能

Tab. 6.3 Quantitative comparison of the performance of different sharpening methods on the object detection model (continued)

方法	AP	$AP_{0.5}$	$AP_{0.75}$	AR_1	AR_{10}	AR_{100}
LAWB-MSF 方法	0.500	0.890	0.505	0.151	0.547	0.597
BME-AG 方法	0.490	0.883	0.493	0.151	0.540	0.589
UIMPL 方法	0.503	0.883	0.514	0.154	0.557	0.611
整体清晰化方法	0.507	0.888	0.524	0.153	0.554	0.614

（2）消融不同融合策略的输入模块

为了进一步验证所提输入模块对整体目标检测框架的有效性，本部分在 UODD 数据集中进行了以下消融实验，其中包括采用原始图像与增强图像相融合的输入模块（IM-a）、原始图像、增强图像与锐化特征图相融合的输入模块（IM-b）和增强图像与锐化特征图相融合的输入模块（IM-c）。更具体地说：

（a）-w/o IM-a: 在输入模块中使用原始图像与第六章清晰化方法所生成的增强图像按通道维度进行堆叠，以作为目标检测框架的输入。

（b）-w/o IM-b: 在输入模块中使用原始图像、第六章清晰化方法所生成的增强图像以及原始图像的锐化特征图按通道维度进行堆叠，以作为目标检测框架的输入。

（c）-w/o IM-c: 在输入模块中使用第六章清晰化方法所生成的增强图像与相应地锐化特征图按通道维度进行堆叠，以作为目标检测框架的输入。

由表 6.4 中数据可知，本章通过使用增强图像与相应地锐化特征图相结合的输入模块在平均检测精度和平均召回率上取得了有竞争力的结果，证明了输入模块可有效提高目标检测模型的性能，为水下自动抓取等工程应用提供有益的参考。

表 6.4 定量比较不同输入模块的性能

Tab. 6.4 Quantitative comparison of the performance of different input modules

方法	AP	$AP_{0.5}$	$AP_{0.75}$	AP_S	AP_M	AP_L
IM-a	0.527	0.889	0.572	0.609	0.627	0.742
IM-b	0.523	0.883	0.556	0.579	0.619	0.732
IM-c	0.533	0.892	0.568	0.599	0.632	0.750

6.4.5 水下目标检测定性结果

图 6.11 展示了本章方法在 UODD 测试数据集中不同退化程度图像的定性检测

中国知网 https://www.cnki.net

结果，其中第一行为具有不同退化程度的原始水下图像，第二行为本章方法的检测结果。观察可知，本章方法对于复杂水下环境中的不同尺度和遮挡目标均可被正确检测，验证了所提方法的有效性和鲁棒性。此外，如图 6.11 第六列显示，在目标与背景极为相似的情况下，模型容易出现误检或漏检现象。因此，后续将针对上述问题优化水下图像的预处理步骤并设计更为高效的学习策略，以进一步提升网络在极端水下环境下的感知和检测能力。

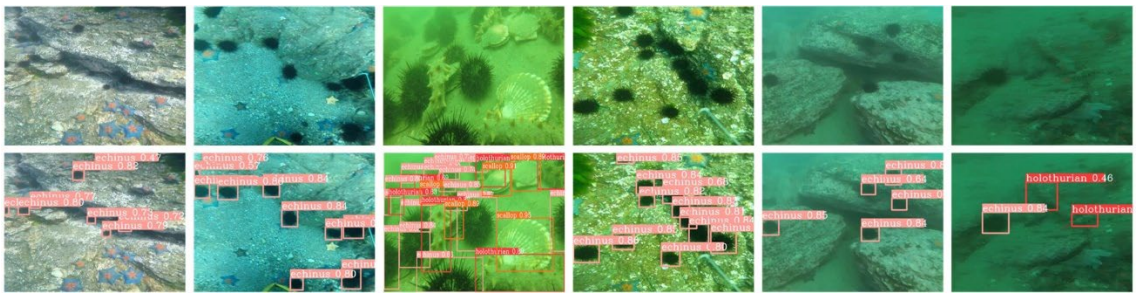


图6.11 水下目标检测的定性结果

Fig.6.11 Qualitative results of underwater object detection

6.5 水下环境的自动抓取实验

为了验证本论文研究的水下光学图像清晰化技术与目标检测网络在实际水下场景中的运行效果，本节搭建了物理实验平台。实验的核心内容在于对比水下图像清晰化处理前后的目标检测方法的鲁棒性。通过水下抓取实验，验证了本论文所提方法在水下目标抓取等工程应用任务中的有效性和实用性。

6.5.1 实验平台搭建

为了实现水下环境中的自动抓取，本节利用第二章所提的自制水下机械臂视觉实验平台进行相应的实验验证。图 6.12 展示了上述实验平台的整体框架。

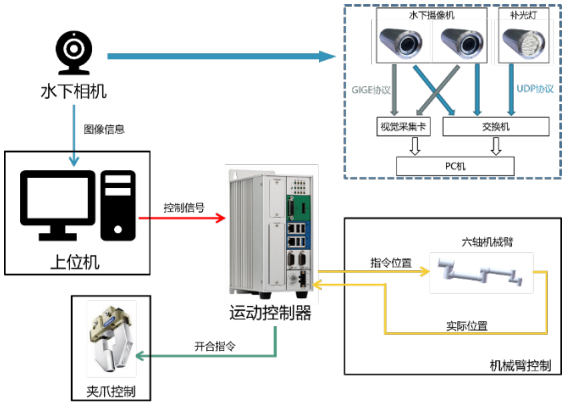


图6.12 整体实验平台框架

Fig.6.12 Overall experimental platform framework

中国知网 https://www.cnki.net

该实验平台主要由机械本体、控制系统、水下视觉系统、上位机和任务执行机构五部分组成，旨在验证所提出的水下图像清晰化技术与目标检测网络在水下抓取任务中的有效性。

（1）机械臂本体

图 6.13(a)展示了机械臂本体结构。该机械臂通过六个关节可调整末端执行机构在空间中的位姿，以实现三维空间中末端执行器的精细作业。为确保机械臂在水下的正常运行，对每个关节电机进行了防水密封，并在搭建的水下密封仓中进行了防水性测试，如图 6.13(b)所示。



(a) (b)

图6.13 水下机械臂本体

Fig.6.13 The body of the underwater robotic arm

（2）控制系统

控制系统以运动控制器为核心，通过接受光学传感器信号和上位机指令，利用运动控制算法对机械臂进行控制，并将设备实时状态反馈回上位机。图 6.14 展示了控制系统的硬件框架，其主要由一个运动控制器和六个伺服系统组成。

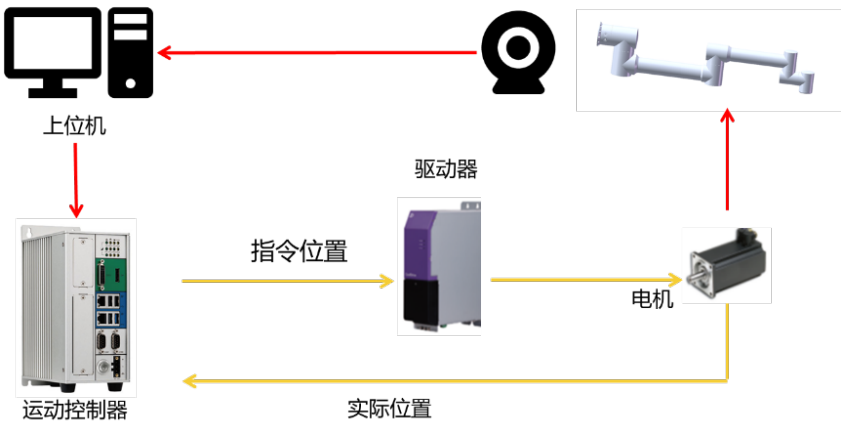


图6.14 整体控制系统

Fig.6.14 Overall control system

中国知网 https://www.cnki.net

在水下机械臂抓取系统中，双目相机会实时采集目标的图像信息，并计算目标的三维位姿。当上位机发送抓取指令时，根据目标与机械臂当前位置信息之间的误差，PID 控制器将调整机械臂的运动方向和速度。比例控制部分会根据当前误差提供即时修正，帮助机械臂快速响应目标位置。积分控制部分则会消除由于水流阻力等因素产生的稳态误差，确保机械臂能够最终精确到达目标。微分控制部分则能有效抑制机械臂运动过程中的震荡和过冲，保证运动过程的平稳。通过 PID 控制，机械臂将逐渐靠近目标，并最终完成抓取任务。

（3）水下视觉系统

水下视觉系统的硬件包括水下双目相机、光源、视觉采集卡和水下目标检测方法组成。水下双目相机固定安装在机械臂基座，与末端执行器形成眼在手外观测架构，整体结构如图 2.3 所示。为了提升水下抓取任务的精度，在视觉系统内外参标定阶段和目标位姿解算阶段都应用了本文所提出的水下图像清晰化方法，具体流程如图 6.15 所示。

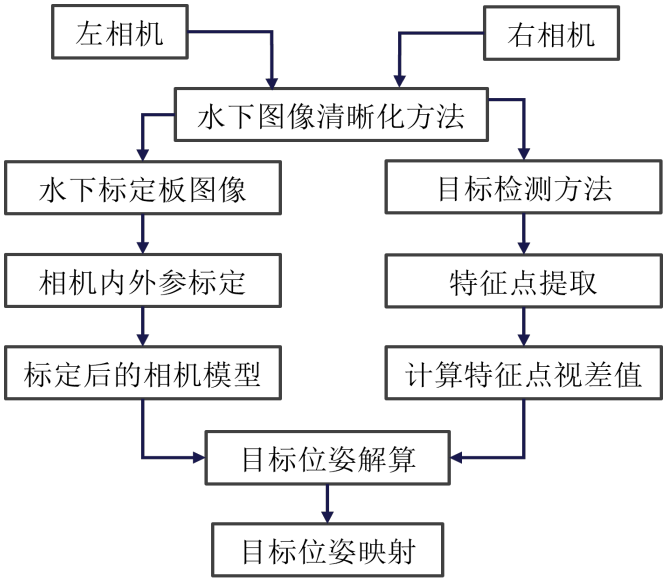


图6.15 水下视觉系统目标位姿解算流程图

Fig.6.15 Flowchart of object pose calculation for underwater vision system

在内外参标定阶段，通过视觉采集卡获取不同位姿的水下棋盘格图像传递到上位机中，如图 4.8 所示的原始棋盘格图像。随后，在上位机中使用本论文提出的基于亮度图估计和自适应增益的水下清晰化方法获得相应的增强图像，如图 4.9 所示。最后，将增强图像作为相机内外参标定算法的输入，从而获得精确的相机模型参数。

在目标抓取阶段，水下视觉系统首先根据水下双目相机采集目标物体的光学图像，并传输到上位机中。在上位机中，部署本论文提出的图像清晰化与目标检测

中国知网 https://www.cnki.net

方法以获得左、右目图像中目标物体的像素坐标，使用视差法和相机内参解算得到目标物体在相机坐标系的位姿 ${}^{c}x$。此外，根据相机外参，由位姿映射公式 ${}^{b}x = {}^{b}R_{c}\,{}^{c}x + {}^{b}t_{c}$，将目标在相机坐标系下的位姿映射到机械臂基坐标系下的位置，并将该坐标值传递至运动控制器以作为机械臂的控制信号。其中，${}^{b}R_{c}$ 和 ${}^{b}t_{c}$ 通过外参标定获得，分别代表相机坐标系相对于机械臂基坐标系的旋转矩阵和平移向量。

（4）实验平台上位机

该实验平台上位机软件采用 Qt 平台进行系统界面设计以实现 GUI 页面的事件互动。图 6.16 展示了上位机软件界面，通过人机交互图形化界面实时显示系统运行参数，监控系统运行状况，并返回水下视觉系统的影像信息。此外，上位机界面还包含机械臂运动控制指令下发模块，并整合了本论文所提出的图像清晰化与目标检测方法，为水下抓取实验验证提供了可视化的软件平台。



图6.16 上位机软件界面

Fig.6.16 PC software interface

6.5.2 抓取流程

基于上述实验平台，本部分将介绍基于本论文所提出的水下图像清晰化技术与目标检测方法进行水下自动抓取实验的具体操作流程，以验证所提方法在实际水下工程应用的有效性，如图 6.17 所示。抓取实验的具体步骤如下：

步骤一：相机采集水下光学图像，并针对水下成像时光照条件、颜色失真和模糊等问题，使用本章提出的清晰化技术对原始图像进行预处理（图像清晰化方法如图 6.5 所示），以提高图像的清晰度和细节信息，从而为后续目标检测方法提供高质量的图像输入；

中国知网 https://www.cnki.net

步骤二：在增强图像的基础上，利用本论文提出的基于注意力机制和多分支结构的目标检测网络进行水下目标检测，并结合视差法以及双目相机内外参计算目标在相机坐标系下的三维空间位姿信息；

步骤三：通过相机外参和机械臂的运动学参数，利用位姿映射算法将目标在相机坐标系中的位姿转换为机械臂基坐标系下的位姿，确保机械臂能够准确理解目标在三维空间中的位置；

步骤四：根据目标的位姿进行机械臂运动学逆解，计算机械臂抓取运动的期望关节角；

步骤五：根据计算出的关节角和期望轨迹，通过 PID 控制算法，精确控制机械臂的运动，使其顺利接近目标，并实现抓取。

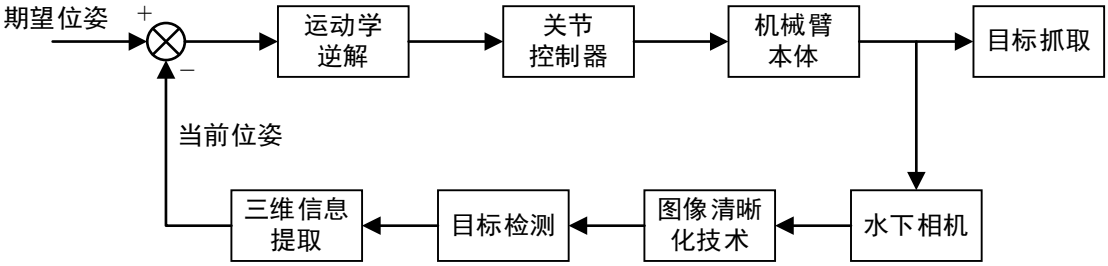


图6.17 水下抓取任务的整体流程

Fig.6.17 The overall process of the underwater grabbing tasks

6.5.3 实验结果

基于上述实验平台与抓取流程，本部分将进一步开展水下待检测目标的抓取实验，以验证所提方法在实际水下作业的效果。首先基于水下双目相机获取原始图像，如图 6.18(a)所示。随后，利用目标检测方法定位待检测目标，结果如图 6.18(b)所示。由图 6.18(b)观察可知，降质的水下图像难以有效检测到待抓取目标。



图6.18 原始水下图像的目标检测结果

Fig.6.18 Object detection results of the raw underwater images

为了进一步提升目标检测网络的鲁棒性，利用本章所提清晰化技术作为目标检测网络的预处理步骤，处理结果如图 6.19(a)所示。由图 6.19a)观察可知，所提方

中国知网 https://www.cnki.net

法可稳定且有效地校正水下图像中的颜色失真问题，同时提高了能见度和对比度。在上述增强图像的基础上，利用目标检测网络可实现目标位姿信息稳定且鲁棒的提取，检测结果如图 6.19(b)所示。通过图 6.18 和图 6.19 进一步验证了本论文方法可有效提升水下自动抓取任务的鲁棒性。

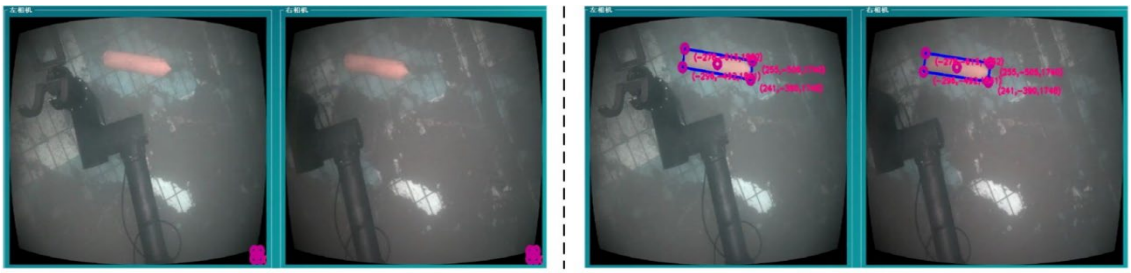


图6.19 增强图像的目标检测结果

Fig.6.19 Object detection results of the enhanced images

图 6.20 展示了实现水下自动抓取的整体流程。从实验结果可以观察到，在本论文所提方法的辅助下，水下机械臂能够准确感知待测目标物体的空间位置信息，并逐步调整自身姿态，以优化抓取轨迹。在整个自动抓取过程中，机械臂能够适应复杂的水下环境，实现了稳定、精准的水下目标抓取。上述实验结果进一步验证了所提方法在水下自动任务中的有效性和鲁棒性，为后续水下智能感知与自主操作研究提供了重要参考。



图6.20 水下自动抓取

Fig.6.20 Underwater automated grabbing

6.6 本章小结

针对水下光学图像降质以及水下目标物体的多尺度、遮挡和聚集等问题，提出了一种基于图像增强和多分支结构的水下目标检测方法。具体而言，首先分析了不同水下光学图像的退化特性，根据不同图像间的特征差异引入相应的图像清晰化方法以改善退化图像的对比度、颜色失真和细节模糊等问题。其次，为了增强目标检测网络对不同目标特征的学习和辨识能力，将增强图像与锐化图像沿通道维度进行融合以强化表达目标区域的边缘纹理信息。随后，设计基于通道和空间注意力

中国知网 https://www.cnki.net

机制的多分支结构进行目标的特征提取和表征，以突出目标区域的细节特征并丰富输入特征的信息维度，从而提升模型对水下多尺度、遮挡和聚集目标的检测能力。最后，引入解耦检测头优化模型的类别预测和坐标回归的独立性，从而提高模型的检测精度。在 UODD 水下数据集上广泛的定性和定量实证明了所提方法在目标检测任务中的有效性和鲁棒性。实验结果表明，本章方法在不同退化程度的水下图像中均能显著提高目标检测的性能。此外，在水下自动目标抓取任务中也表现出良好的适应性与稳定性，进一步验证了所提方法在复杂水下环境中应用的有效性和鲁棒性。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第七章 结论与展望

本论文研究基于水下光学图像的清晰化技术，旨在提高水下光学图像的信噪比和能见度，为后续基于光学图像的探测和分析提供高质量的数据支持。具体而言，针对水下成像中的波长依赖性光吸收和散射、非均匀照明和非均匀退化等水下图像的降质问题，提出三种水下清晰化方法以针对性地提升水下图像的质量，为后续目标检测任务提供高质量的输入数据。此外，由于水下目标具有多尺度、遮挡以及边缘模糊等问题，提出一种基于图像增强和多分支结构的目标检测方法以增强模型对水下关键目标的特征提取和辨识能力，从而显著提高模型在复杂水下场景中的检测精度和鲁棒性。综上所述，本论文从改善水下降质图像的质量入手，提出三种针对不同退化类型的水下光学图像清晰化方法以提高图像的质量。同时，将水下图像清晰化方法与目标检测任务相结合，以强化模型的特征提取和融合能力，从而提高模型的检测精度。定性、定量以及水下自动抓取实验验证了所提方法的有效性和鲁棒性。现将本论文所取得的主要成果、创新点以及未来的研究方向进行总结。

7.1 工作成果

本论文主要工作成果如下：

（1）基于局部白平衡和多尺度融合的水下图像清晰化方法

针对水介质本身对不同波长光的选择性吸收和散射效应等问题，提出一种基于局部白平衡和多尺度融合的水下图像清晰化方法。首先，为了解决水介质对不同光谱区域光的吸收特性，通过将通道补偿策略和细化亮度图相结合以校正水下图像中不同程度的颜色失真问题。其次，由于水介质的强散射效应导致的图像模糊问题，通过设计多尺度融合方法以提高水下图像的细节信息和能见度。在多尺度融合过程中，通过统计学设计清晰度权重图和亮度权重图，并利用拉普拉斯和高斯金字塔进行融合以生成最终的增强结果。该方法实验在 UCCS、UIEB、UIQS 和 RISU 数据集上时，其平均定量指标 UIQM、UCIQE、FADE、AG 和 EI 分别为 4.683、0.538、0.239、113.487 和 6.596。总体而言，综合定性、定量以及实际应用的实验结果表明，该方法可有效改善水下光学图像的质量。

（2）基于亮度图估计和自适应增益的水下图像清晰化方法

针对水下场景中由人工光源导致的非均匀照明问题，提出一种基于亮度图估

中国知网 https://www.cnki.net

计和自适应增益的水下图像清晰化方法。首先利用颜色转移图像和最大衰减图引导的融合策略以消除水下图像中的颜色失真问题。其次，借鉴变分模型的思想，引入结构权重矩阵解决水下图像中的非均匀照明问题。此外，引入积分图将亮度校正图像分解为低频分量和高频分量。并且构建一种基于自适应增益控制函数来自适应地增强图像的高频分量，以提高水下图像整体的纹理细节信息。最终，将增强后的高频分量与低频分量结合获得最终的结果。该方法实验在 OceanDark 水下数据集上时，其定量指标 AG、EI、CCF、FADE、UIQM 和 UCIQE 分别为 113.393、5.559、28.569、0.355、4.830 和 0.563。此外，在工业水下环境中的双目标定实验中，该方法在重投影误差和实际测量距离值方面分别获得了 0.167 和 28.20mm，均优于对比方法。总体而言，该方法在弱光水下图像的定性和定量指标方面均取得了较好的结果。

（3）基于成像模型和衰减图引导的水下图像清晰化方法

针对水下动态场景中质量退化的因素是复杂多样的，且同一幅图像中不同区域可能存在非均匀退化等问题，然而前文缺乏对水下成像模型中不同光谱区域下光线的物理特性开展深入的研究。因此，针对水下光学图像中的非均匀退化问题，提出一种基于成像模型和衰减图引导的水下图像清晰化方法。具体而言，首先构建一种基于色彩空间的多颜色通道混洗模块以生成三个具有不同特征的通道，从而充分结合图像中的色度、对比度、饱和度以及亮度等特征信息。随后，将不同特征的通道与其相应的衰减图进行结合以预测环境光的偏置矩阵，使得网络能够关注图像中不同位置和不同特性通道之间的退化程度，从而赋予模型处理水下图像中非均匀退化问题的能力。同时，提出透射率估计模块，通过多分支结构和空洞卷积将原始水下图像与融合的环境光参数相结合实现不同颜色通道透射率的估计。此外，将水下物理模型嵌入到统一的框架中，通过反演模型以实现端到端水下图像增强。该方法实验在 UIEB 测试、UIEB 挑战、EUVP、LSUI 和 SQUID 水下数据集上时，其定量评价指标 Average 分别为 19.798、13.441、27.089、20.746 和 12.270，均优于基于数据驱动的对比方法。总体而言，该方法在非均匀退化水下图像的定性和定量指标方面均取得了较好的结果。

（4）基于图像增强和多分支结构的水下目标检测方法

针对水下目标物体尺度变化大、遮挡以及水介质的光学特性导致目标物体边缘模糊和颜色失真等问题，提出一种基于图像增强和多分支结构的水下目标检测方法。首先根据输入图像的特点，结合前文三种水下图像清晰化方法与各方法的适用情况作为判别条件，从而为检测网络提供高质量的输入图像。其次，基于注意力

中国知网 https://www.cnki.net

机制和多分支结构设计骨干网络和颈部网络，以有效增强模型的特征提取和融合能力，从而提高水下目标检测精度。最后，引入解耦检测头实现模型的回归和分类任务。实验结果证明，所提方法能够准确地检测出水下不同尺度目标，且获得了53.3%的平均检测精度，均优于对比的目标检测模型。该性能优势得益于高效的网络结构以及专用的水下图像清晰化方法。此外，搭建水下自动抓取实验平台进一步验证所提方法在提升目标检测与定位精度方面的有效性，还证明了其可有效提升水下机械臂在实际工程应用中的有效性，从而为水下自主作业提供了坚实的技术支持与理论基础。

7.2 创新点总结

本论文主要创新点可归纳为以下 4 点：

（1）针对水下光学图像的颜色失真问题，提出了一种结合自适应通道补偿策略与细化亮度图引导融合的方法，同时引入高频控制因子生成锐化图像，设计了清晰度和亮度权重图，构建了多尺度图像融合框架，实现了绿色外观、蓝色外观和蓝绿色外观水下图像的颜色校正。

（2）针对水下光学图像的非均匀照明问题，将结构权重矩阵引入到变分模型中构建了目标函数，并提出了自适应增益控制函数，实现了弱光水下图像能见度和纹理信息的增强。

（3）针对水下光学图像的局部细节非均匀退化和全局低对比度问题，提出基于水下成像模型的端到端网络结构，构建了多颜色通道混洗模块，设计了基本环境光、偏置环境光以及透射率估计模块，实现了全局低对比度和局部非均匀退化水下光学图像的增强。

（4）针对水下光学图像中存在的不同降质类型以及水下目标的多尺度、遮挡与聚集问题，设计了相应的判别条件以选择最佳的水下清晰化方法，构建了深度卷积神经网络的目标检测模型，并设计了水下自动抓取实验验证了本论文图像清晰化和目标检测方法的有效性。

7.3 工作展望

本论文针对水下光学图像清晰化和目标检测问题展开了深入的理论分析和应用研究。尽管本论文对水下光学图像清晰化和目标检测方法提出了相应的解决方案，但该方向仍然存在一些亟待解决的问题需要后续进一步地深入研究和探索。结

中国知网 https://www.cnki.net

合本论文已取得的工作基础上，未来可以考虑从以下几个方面开展进一步地研究：

（1）针对水下光学图像中存在的不同程度的颜色失真问题，本论文采用局部白平衡方法和暗通道先验变体的融合策略，取得了较为准确的颜色校正结果。然而，鉴于水下图像中颜色失真问题的复杂性和多变性，还应进一步研究水下光谱衰减补偿和多模态融合技术，以提高该类方法颜色校正的准确性和鲁棒性。

（2）针对水下非均匀照明问题，本论文采用外点罚函数方法迭代求解不同通道的细化亮度图。然而，迭代求解方法会引入较大的计算复杂度，且难以保证算法的实时性。因此，未来可以从优化方法复杂度的角度出发，探讨更加鲁棒且高效的迭代或非迭代亮度图优化方法，并进一步研究在实际工业水下环境中的应用与部署。

（3）针对不同水下环境中的非均匀退化问题，本论文采用多色彩空间混洗和相应通道的衰减图关注于估计水下成像模型中的未知参数。虽然该方法可有效解决水下光学图像存在的颜色失真和非均匀退化问题，但在极端水下场景中准确校正颜色信息的能力仍然具有挑战。因此，未来可以从捕获图像中长距离依赖关系的角度进行更深入的建模研究，以增强模型对全局上下文信息的理解，从而提高模型在极端水下场景下的颜色校正精度和鲁棒性。

（4）针对水下目标检测模型，本论文采用图像清晰化技术和多分支结构以增强模型对关键目标特征提取的敏感度，从而提高检测器对水下目标的检测精度。然而，本文仅仅使用粗略的方式对输入图像的特性进行分类，忽略了不同退化水下图像之间可能存在的诸多共性和联系。因此，未来可以从如何精细区分不同退化类别的水下图像进行深入研究，并根据结果针对性地选择图像清晰化方法，以为目标检测网络提供高质量的输入图像。此外，将水下图像清晰化方法与目标检测模型进行联合学习也是未来研究的一个重要方向。

中国知网 https://www.cnki.net

参考文献

[1] 代成刚. 水下图像清晰化与目标识别检测技术研究[D]. 济南: 山东大学, 2021.

[2] 王博. 自主水下航行器的光视觉认知技术研究[D]. 哈尔滨: 哈尔滨工程大学, 2017.

[3] 么洪飞. 不确定条件下 UUV 态势感知、威胁评估与自主决策方法研究[D]. 哈尔滨: 哈尔滨工程大学, 2020.

[4] 陈鹏云. 多传感器条件下的 AUV 海底地形匹配导航研究[D]. 哈尔滨: 哈尔滨工程大学, 2016.

[5] Raveendran S., Patil M. D., Birajdar G. K. Underwater image enhancement: a comprehensive review, recent trends, challenges and applications[J]. Artificial Intelligence Review, 2021, 54: 5413-5467.

[6] Lu Huimin, Li Yujie, Zhang Yudong, et al. Underwater Optical Image Processing: a Comprehensive Review[J]. Mobile Networks and Applications, 2017, 22: 1204-1211.

[7] 刘妹琴, 韩学艳, 张森林等. 基于水下传感器网络的目标跟踪技术研究现状与展望[J]. 自动化学报, 2021, 47(2): 235-251.

[8] Yang Miao, Hu Jintong, Li Chongyi, et al. An in-depth survey of underwater image enhancement and restoration[J]. IEEE Access, 2019, 7: 123638-123657.

[9] 徐璠, 王贺升. 软体机械臂水下自适应鲁棒视觉伺服[J]. 自动化学报, 2023, 49(4): 744−753.

[10] Namer E., Shwartz S., Schechner Y. Y. Skyless polarimetric calibration and visibility enhancement[J]. Optics Express, 2009, 17(2): 472-493.

[11] Fournier G. R., Bonnier D., Forand J. L., et al. Range-gated underwater laser imaging system[J]. Optical Engineering, 1993, 32(9): 2185-2190.

[12] Jaffe J. S. Underwater optical imaging: The past, the present, and the prospects[J]. IEEE Journal of Oceanic Engineering, 2014, 40(3): 683-700.

[13] Shortis M., Abdo E. H. D. A review of underwater stereo-image measurement for marine biology and ecology applications[J]. Oceanography and Marine Biology, 2016: 269-304.

[14] Oh T., Sermsripong J., Hicks B. W. Using scuba for in situ determination of chlorophyll distributions in corals by underwater near infrared fluorescence

中国知网 https://www.cnki.net

imaging[J]. Journal of Marine Science and Engineering, 2020, 8(1): 53.

[15] He Kaiming, Sun Jian, Tang Xiaoou. Single image haze removal using dark channel prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 33(12): 2341-2353.

[16] Chao Liu, Wang Meng. Removal of water scattering[C]. IEEE International Conference on Computer Engineering and Technology, 2010: 35-39.

[17] Chiang J. Y., Chen Y. C. Underwater image enhancement by wavelength compensation and dehazing[J]. IEEE Transactions on Image Processing, 2011, 21(4): 1756-1769.

[18] Yao Bowen, Xiang Ji. Underwater image dehazing using modified dark channel prior[C]. IEEE Chinese Control and Decision Conference, 2018: 5792-5797.

[19] Drews P. L. J., Nascimento E. R., Botelho S. S. C., et al. Underwater depth estimation and image restoration based on single images[J]. IEEE Computer Graphics and Applications, 2016, 36(2): 24-35.

[20] Galdran A., Pardo D., Picón A., et al. Automatic red-channel underwater image restoration[J]. Journal of Visual Communication and Image Representation, 2015, 26: 132-145.

[21] Yang H. Y., Chen P. Y., Huang C. C., et al. Low complexity underwater image enhancement based on dark channel prior[C]. IEEE International Conference on Innovations in Bio-inspired Computing and Applications, 2011: 17-20.

[22] Carlevaris-Bianco N., Mohan A., Eustice R. M. Initial results in underwater single image dehazing[C]. IEEE Oceans, 2010: 1-8.

[23] 林森, 白莹, 李文涛等. 基于修正模型与暗通道先验信息的水下图像复原[J]. 机器人, 2020, 42(4): 427-435.

[24] 杨爱萍, 郑佳, 王建等. 基于颜色失真去除与暗通道先验的水下图像复原[J]. 电子与信息学报, 2015, 37(11): 2541-2547.

[25] Peng Y. T., Cosman P. C. Underwater image restoration based on image blurriness and light absorption[J]. IEEE Transactions on Image Processing, 2017, 26(4): 1579-1594.

[26] Berman D., Levy D., Avidan S., et al. Underwater single image color restoration using haze-lines and a new quantitative dataset[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 43(8): 2822-2837.

中国知网 https://www.cnki.net

[27] Li Chongyi, Guo Jichang, Cong Runmin, et al. Underwater image enhancement by dehazing with minimum information loss and histogram distribution prior[J]. IEEE Transactions on Image Processing, 2016, 25(12): 5664-5677.

[28] Akkaynak D, Treibitz T. Sea-thru: A method for removing water from underwater images[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2019: 1682-1691.

[29] Song Wei, Wang Yan, Huang Dongmei, et al. A rapid scene depth estimation model based on underwater light attenuation prior for underwater image restoration[C]. Advances in Multimedia Information Processing, 2018: 678-688.

[30] Xie Jun, Hou Guojia, Wang Guodong, et al. A variational framework for underwater image dehazing and deblurring[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(6): 3514-3526.

[31] 谢骏, 侯国家, 王国栋等. 基于红通道稀疏先验的水下图像盲复原[J]. 激光与光电子学进展, 2021, 58(16): 1610014.

[32] Ueki Y, Ikehara M. Underwater image enhancement based on the iteration of a generalization of dark channel prior[C]. IEEE Visual Communications and Image Processing, 2019: 1-4.

[33] Zhou Jingchun, Yang Tongyu, Zhang Weishi. Underwater vision enhancement technologies: A comprehensive review, challenges, and recent trends[J]. Applied Intelligence, 2023, 53(3): 3594-3621.

[34] Pizer S. M., Amburn E. P., Austin J. D., et al. Adaptive histogram equalization and its variations[J]. Computer vision, graphics, and image processing, 1987, 39(3): 355-368.

[35] Hitam M. S., Awalludin E. A., Yussof W. N. J. H. W., et al. Mixture contrast limited adaptive histogram equalization for underwater image enhancement[C]. IEEE International Conference on Computer Applications Technology, 2013: 1-5.

[36] Iqbal K., Salam R. A., Osman A., et al. Underwater Image Enhancement Using an Integrated Colour Model[J]. IAENG International Journal of Computer Science, 2007, 34(2): 239-244.

[37] Shamsuddin N. bt, Ahmad W. F. bt W., Baharudin B. b, et al. Significance level of image enhancement techniques for underwater images[C]. IEEE International Conference on Computer & Information Science, 2012, 1: 490-494.

中国知网 https://www.cnki.net

[38] Ghani A. S. A., Isa N. A. M. Underwater image quality enhancement through Rayleigh-stretching and averaging image planes[J]. International Journal of Naval Architecture and Ocean Engineering, 2014, 6(4): 840-866.

[39] Garg D., Garg N. K., Kumar M. Underwater image enhancement using blending of CLAHE and percentile methodologies[J]. Multimedia Tools and Applications, 2018, 77: 26545-26561.

[40] Huang Dongmei, Wang Yan, Song Wei, et al. Shallow-water image enhancement using relative global histogram stretching based on adaptive parameter acquisition[C]. MultiMedia Modeling: International Conference, 2018: 453-465.

[41] Zhang Weidong, Dong Lili, Zhang Tong, et al. Enhancing underwater image via color correction and bi-interval contrast enhancement[J]. Signal Processing: Image Communication, 2021, 90: 116030.

[42] Land E. H., McCann J. J. Lightness and retinex theory[J]. Journal of the Optical Society of America, 1971, 61(1): 1-11.

[43] Rahman Z., Jobson D. J., Woodell G. A. Retinex processing for automatic image enhancement[J]. Journal of Electronic Imaging, 2004, 13(1): 100-110.

[44] Fu Xueyang, Zhuang Peixian, Huang Yue, et al. A retinex-based enhancing approach for single underwater image[C]. IEEE International Conference on Image Processing, 2014: 4572-4576.

[45] Zhang Shu, Wang Ting, Dong Junyu, et al. Underwater image enhancement via extended multi-scale Retinex[J]. Neurocomputing, 2017, 245: 1-9.

[46] Hassan N., Ullah S., Bhatti N., et al. The Retinex based improved underwater image enhancement[J]. Multimedia Tools and Applications, 2021, 80: 1839-1857.

[47] Zhuang Peixian, Li Chongyi, Wu Jiamin. Bayesian retinex underwater image enhancement[J]. Engineering Applications of Artificial Intelligence, 2021, 101: 104171.

[48] Ancuti C., Ancuti C. O., Haber T., et al. Enhancing underwater images and videos by fusion[C]. 2012 IEEE Conference on Computer Vision and Pattern Recognition, 2012: 81-88.

[49] Ancuti C. O., Ancuti C., Vleeschouwer C. D., et al. Color balance and fusion for underwater image enhancement[J]. IEEE Transactions on Image Processing, 2017, 27(1): 379-393.

中国知网 https://www.cnki.net

[50] Fu Xueyang, Fan Zhiwen, Ling Mei, et al. Two-step approach for single underwater image enhancement[C]. IEEE International Symposium on Intelligent Signal Processing and Communication Systems, 2017: 789-794.

[51] Ma Jinxiang, Fan Xinnan, Yang S. X., et al. Contrast limited adaptive histogram equalization-based fusion in YIQ and HSI color spaces for underwater image enhancement[J]. International Journal of Pattern Recognition and Artificial Intelligence, 2018, 32(07): 1854018.

[52] Zhang Weidong, Zhuang Peixian, Sun Haihan, et al. Underwater image enhancement via minimal color loss and locally adaptive contrast enhancement[J]. IEEE Transactions on Image Processing, 2022, 31: 3997-4010.

[53] 林森, 迟凯晨, 唐延东. 基于复原结构与增强纹理融合的水下图像清晰化[J]. 控制与决策, 2022, 37(3): 635-644.

[54] Marques T. P., Albu A. B. L2uwe: A framework for the efficient enhancement of low-light underwater images using local contrast and multi-scale fusion[C]. IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2020: 538-539.

[55] 闫小红. 基于图像融合与深度网络模型的水下光学图像增强方法研究[D]. 大连: 大连海事大学, 2023.

[56] Anwar S., Li Chongyi. Diving deeper into underwater image enhancement: A survey[J]. Signal Processing: Image Communication, 2020, 89: 115978.

[57] Li Jie, Skinner K. A., Eustice R. M., et al. WaterGAN: Unsupervised generative network to enable real-time color correction of monocular underwater images[J]. IEEE Robotics and Automation Letters, 2017, 3(1): 387-394.

[58] Fabbri C., Islam M. J., Sattar J. Enhancing underwater imagery using generative adversarial networks[C]. IEEE International Conference on Robotics and Automation, 2018: 7159-7165.

[59] Blasinski H., Farrell J. A three parameter underwater image formation model[J]. Electronic Imaging, 2016, 28: 1-8.

[60] Li Chongyi, Anwar S., Porikli F. Underwater scene prior inspired deep underwater image and video enhancement[J]. Pattern Recognition, 2020, 98: 107038.

[61] Silberman N., Hoiem D., Kohli P., et al. Indoor segmentation and support inference from rgbd images[C]. European Conference on Computer Vision, 2012: 746–760.

[62] Wang Nan, Zhou Yabin, Han Fenglei, et al. UWGAN: Underwater GAN for real-

中国知网 https://www.cnki.net

world underwater color restoration and dehazing[J]. arXiv preprint arXiv:1912.10269, 2019.

[63] Liu Risheng, Jiang Zhiying, Yang Shuzhou, et al. Twin adversarial contrastive learning for underwater image enhancement and beyond[J]. IEEE Transactions on Image Processing, 2022, 31: 4922-4936.

[64] Duarte A., Codevilla F., Gaya J. D. O., et al. A dataset to evaluate underwater image restoration methods[C]. IEEE OCEANS 2016-Shanghai, 2016: 1-6.

[65] Li Chongyi, Guo Chunle, Ren Wenqi, et al. An underwater image enhancement benchmark dataset and beyond[J]. IEEE Transactions on Image Processing, 2019, 29: 4376-4389.

[66] Li Chongyi, Guo Jichang, Guo Chunle. Emerging from water: Underwater image color correction based on weakly supervised color transfer[J]. IEEE Signal Processing Letters, 2018, 25(3): 323-327.

[67] Ye Xinchen, Xu Hongcan, Ji Xiang, et al. Underwater image enhancement using stacked generative adversarial networks[C]. Pacific Rim Conference on Multimedia. Springer, 2018: 514-524.

[68] Guo Yecai, Li Hanyu, Zhuang Peixian. Underwater image enhancement using a multiscale dense generative adversarial network[J]. IEEE Journal of Oceanic Engineering, 2019, 45(3): 862-870.

[69] Liu Xiaodong, Gao Zhi, Chen B. M. MLFcGAN: Multilevel feature fusion-based conditional GAN for underwater image color correction[J]. IEEE Geoscience and Remote Sensing Letters, 2019, 17(9): 1488-1492.

[70] Islam M. J., Xia Youya, Sattar J. Fast underwater image enhancement for improved visual perception[J]. IEEE Robotics and Automation Letters, 2020, 5(2): 3227-3234.

[71] Wang Yang, Zhang Jing, Cao Yang, et al. A deep CNN method for underwater image enhancement[C]. IEEE International Conference on Image Processing, 2017: 1382-1386.

[72] Cao Keming, Peng Y. T., Cosman P. C. Underwater image restoration using deep networks to estimate background light and scene depth[C]. IEEE Southwest Symposium on Image Analysis and Interpretation, 2018: 1-4.

[73] Chen Xuelei, Zhang Pin, Quan Lingwei, et al. Underwater image enhancement based on deep learning and image formation model[J]. arXiv preprint arXiv:2101.00991,

中国知网 https://www.cnki.net

2021.

[74] Wang Yang, Cao Yang, Zhang Jing, et al. Leveraging deep statistics for underwater image enhancement[J]. ACM Transactions on Multimedia Computing, Communications, and Application, 2021, 17(3s): 1-20.

[75] Yang Hua, Tian Fei, Qi Qi, et al. Underwater image enhancement with latent consistency learning-based color transfer[J]. IET Image Processing, 2022, 16(6): 1594-1612.

[76] Li Kunqian, Fan Hongtao, Qi Qi, et al. TCTL-Net: Template-free color transfer learning for self-attention driven underwater image enhancement[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2024, 34(6): 4682-4697.

[77] Wang Yudong, Guo Jichang, Gao Huan, et al. UIEC^2-Net: CNN-based underwater image enhancement using two color space[J]. Signal Processing: Image Communication, 2021, 96: 116250.

[78] Li Chongyi, Anwar S., Hou Junhui, et al. Underwater image enhancement via medium transmission-guided multi-color space embedding[J]. IEEE Transactions on Image Processing, 2021, 30: 4985-5000.

[79] Qi Qi, Zhang Yongchang, Tian Fei, et al. Underwater image co-enhancement with correlation feature matching and joint learning[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(3): 1133-1147.

[80] Qi Qi, Li Kunqian, Zheng Haiyong, et al. SGUIE-Net: Semantic attention guided underwater image enhancement with multi-scale perception[J]. IEEE Transactions on Image Processing, 2022, 31: 6816-6830.

[81] Li Kunqian, Wu Li, Qi Qi, et al. Beyond single reference for training: Underwater image enhancement via comparative learning[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 33(6): 2561-2576.

[82] Bartyzel K. Adaptive kuwahara filter[J]. Signal, Image and Video Processing, 2016, 10: 663-670.

[83] Cai Bolun, Xu Xiangmin, Jia Kui, et al. Dehazenet: An end-to-end system for single image haze removal[J]. IEEE Transactions on Image Processing, 2016, 25(11): 5187-5198.

[84] Srividhya K., Ramya M. M. Accurate object recognition in the underwater images using learning algorithms and texture features[J]. Multimedia Tools and Applications,

中国知网 https://www.cnki.net

2017, 76: 25679-25695.

[85] Bi Pengfei, Xu Jian, Du Xue, et al. l2,p-norm sequential bilateral 2DPCA : a novel robust technology for underwater image classification and representation[J]. Neural Computing and Applications, 2020, 32: 17027-17041.

[86] Chen Zhe, Zhang Zhen, Bu Yang, et al. Underwater Object Segmentation Based on Optical Features[J]. Sensors, 2018, 18(1): 196.

[87] Girshick R., Donahue J., Darrell T., et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2014: 580-587.

[88] Ren Shaoqing, He Kaiming, Girshick R., et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 39(6): 1137-1149.

[89] He Kaiming, Gkioxari G., Dollar P., et al. Mask r-cnn[C]. IEEE International Conference on Computer Vision, 2017: 2961-2969.

[90] Cai Zhaowei, Vasconcelos N. Cascade r-cnn: Delving into high quality object detection[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2018: 6154-6162.

[91] Lu Xin, Li Buyu, Yue Yuxin, et al. Grid r-cnn[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2019: 7363-7372.

[92] Zhao Zhongqiu, Zheng Peng, Xu Shoutao, et al. Object detection with deep learning: A review[J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 30(11): 3212-3232.

[93] Redmon J., Divvala S., Girshick R., et al. You only look once: Unified, real-time object detection[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2016: 779-788.

[94] Liu Wei, Anguelov D., Erhan D., et al. Ssd: Single shot multibox detector[C]. European Conference on Computer Vision. Springer, 2016: 21-37.

[95] Law H., Deng Jia. Cornernet: Detecting objects as paired keypoints[C]. European Conference on Computer Vision. 2018: 734-750.

[96] Duan Kaiwen, Bai Song, Xie Lingxi, et al. Centernet: Keypoint triplets for object detection[C]. IEEE International Conference on Computer Vision, 2019: 6569-6578.

[97] 杨爱萍, 曲畅, 王建等. 基于水下成像模型的图像清晰化算法[J]. 电子与信息

中国知网 https://www.cnki.net

学报, 2018, 40(2): 298-305.

[98] Gordon H. R. Can the Lambert-Beer law be applied to the diffuse attenuation coefficient of ocean water?[J]. Limnology and Oceanography, 1989, 34(8): 1389-1409.

[99] Akkaynak D., Treibitz T., Shlesinger T., et al. What is the space of attenuation coefficients in underwater computer vision?[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2017: 4931-4940.

[100] Solonenko M. G., Mobley C. D. Inherent optical properties of Jerlov water types[J]. Applied Optics, 2015, 54(17): 5392-5401.

[101] McGlamery B. L. A computer model for underwater camera systems[C]. Ocean Optics VI. SPIE, 1980, 208: 221-231.

[102] Jaffe J. S. Computer modeling and the design of optimal underwater imaging systems[J]. IEEE Journal of Oceanic Engineering, 1990, 15(2): 101-111.

[103] Mohammadi P., Ebrahimi-Moghadam A., Shirani S. Subjective and objective quality assessment of image: A survey[J]. arXiv preprint arXiv:1406.7799, 2014.

[104] Shigwan S. S., Birajdar G. K. Objective image quality assessment using perceptual distortion for image retargeting[C]. IEEE International Conference on Next Generation Computing Technologies, 2015: 955-959.

[105] Wang Zhou, Bovik A. C. Mean squared error: Love it or leave it? A new look at signal fidelity measures[J]. IEEE Signal Processing Magazine, 2009, 26(1): 98-117.

[106] Wang Zhou, Bovik A. C., Sheikh H. R., et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.

[107] Wang Shiqi, Ma Kede, Yeganeh H., et al. A patch-structure representation method for quality assessment of contrast changed images[J]. IEEE Signal Processing Letters, 2015, 22(12): 2387-2390.

[108] Liu Risheng, Ma Long, Zhang Jiaao, et al. Retinex-inspired unrolling with cooperative prior architecture search for low-light image enhancement[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2021: 10561-10570.

[109] Azmi K. Z. M., Ghani A. S. A., Yusof Z. M., et al. Natural-based underwater image color enhancement through fusion of swarm-intelligence algorithm[J]. Applied Soft Computing, 2019, 85: 105810.

中国知网 https://www.cnki.net

[110] Panetta K., Gao Chen, Agaian S. Human-visual-system-inspired underwater image quality measures[J]. IEEE Journal of Oceanic Engineering, 2015, 41(3): 541-551.

[111] Yang Miao, Sowmya A. An underwater color image quality evaluation metric[J]. IEEE Transactions on Image Processing, 2015, 24(12): 6062-6071.

[112] Wang Yan, Li Na, Li Zongying, et al. An imaging-inspired no-reference underwater color image quality assessment metric[J]. Computers and Electrical Engineering, 2018, 70: 904-913.

[113] Choi L. K., You J., Bovik A. C. Referenceless prediction of perceptual fog density and perceptual image defogging[J]. IEEE Transactions on Image Processing, 2015, 24(11): 3888-3901.

[114] Liu Risheng, Fan Xin, Zhu Ming, et al. Real-world underwater enhancement: Challenges, benchmarks, and solutions under natural light[J]. IEEE Transactions on Circuits and systems for video technology, 2020, 30(12): 4861-4875.

[115] Peng Lintao, Zhu Chunli, Bian Liheng. U-shape transformer for underwater image enhancement[J]. IEEE Transactions on Image Processing, 2023, 32: 3066-3079.

[116] Land E. H. The retinex theory of color vision[J]. Scientific American, 1977, 237(6): 108-129.

[117] Weijer J., Gevers T., Gijsenij A. Edge-based color constancy[J]. IEEE Transactions on Jmage Processing, 2007, 16(9): 2207-2214.

[118] Buchsbaum G. A spatial processor model for object colour perception[J]. Journal of the Franklin institute, 1980, 310(1): 1-26.

[119] Finlayson G. D., Trezzi E. Shades of gray and colour constancy[C]. Color and Imaging Conference, 2004, 12: 37-41.

[120] Liu J, Zhang X. Parameter-adaptive compensation (PAC) for processing underwater selective absorption[J]. IEEE Signal Processing Letters, 2020, 27: 2178-2182.

[121] He Kaiming, Sun Jian, Tang Xiaoou. Guided image filtering[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012, 35(6): 1397-1409.

[122] Pisano E. D., Zong Shuquan, Hemminger B. M., et al. Contrast limited adaptive histogram equalization image processing to improve the detection of simulated spiculations in dense mammograms[J]. Journal of Digital Imaging, 1998, 11: 193-200.

[123] Cheng H. D., Shi X. J. A simple and effective histogram equalization approach to

中国知网 https://www.cnki.net

image enhancement[J]. Digital Signal Processing, 2004, 14(2): 158-170.

[124] Ghani A. S. A., Isa N. A. M. Underwater image quality enhancement through integrated color model with Rayleigh distribution[J]. Applied Soft Computing, 2015, 27: 219-230.

[125] Burt P. J., Adelson E. H. The Laplacian pyramid as a compact image code[J]. IEEE, Transaction on Communications, 1983, 3(4): 532-540.

[126] Farbman Z., Fattal R., Lischinski D., et al. Edge-preserving decompositions for multi-scale tone and detail manipulation[J]. ACM Transactions on Graphics, 2008, 27(3): 1-10.

[127] Peng Y. T., Cao Keming, Cosman P. C. Generalization of the dark channel prior for single image restoration[J]. IEEE Transactions on Image Processing, 2018, 27(6): 2856-2868.

[128] Saleh A., Sheaves M., Jerry D., et al. Adaptive uncertainty distribution in deep learning for unsupervised underwater image enhancement[J]. arXiv preprint arXiv:2212.08983, 2022.

[129] Lei Tao, Jia Xiaohong, Zhang Yanning, et al. Superpixel-based fast fuzzy C-means clustering for color image segmentation[J]. IEEE Transactions on Fuzzy Systems, 2018, 27(9): 1753-1766.

[130] Bay H., Ess A., Tuytelaars T., et al. Speeded-up robust features (SURF)[J]. Computer Vision and Image Understanding, 2008, 110(3): 346-359.

[131] Celik T., Tjahjadi T. Contextual and variational contrast enhancement[J]. IEEE Transactions on Image Processing, 2011, 20(12): 3431-3441.

[132] Wang Wencheng, Yan Dongliang, Wu Xiaojin, et al. Low-light image enhancement based on virtual exposure[J]. Signal Processing: Image Communication, 2023, 118: 117016.

[133] Guo Xiaojie, Li Yu, Ling Haibin. LIME: Low-light image enhancement via illumination map estimation[J]. IEEE Transactions on Image Processing, 2016, 26(2): 982-993.

[134] Reinhard E., Adhikhmin M., Gooch B., et al. Color transfer between images[J]. IEEE Computer Graphics and Applications, 2001, 21(5): 34-41.

[135] Deng Guang. A generalized unsharp masking algorithm[J]. IEEE transactions on Image Processing, 2010, 20(5): 1249-1261.

中国知网 https://www.cnki.net

[136] Pinoli J. C. A general comparative study of the multiplicative homomorphic, log-ratio and logarithmic image processing approaches[J]. Signal Processing, 1997, 58(1): 11-45.

[137] Berman D., Treibitz T., Avidan S. Diving into haze-lines: Color restoration of underwater images[C]. British Machine Vision Conference, 2017: 1-12.

[138] Hou Guojia, Pan Zhenkuan, Huang Baoxiang, et al. Hue preserving-based approach for underwater colour image enhancement[J]. IET Image Processing, 2018, 12(2): 292-298.

[139] Pedersen M., Bengtson S. H., Gade R., et al. Camera calibration for underwater 3D reconstruction based on ray tracing using Snell's law[C]. IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2018: 1410-1417.

[140] Zhang Weidong, Dong Lili, Xu Wenhai. Retinex-inspired color correction and detail preserved fusion for underwater image enhancement[J]. Computers and Electronics in Agriculture, 2022, 192: 106585.

[141] Wang Yi, Liu Hui, Chau L. P. Single underwater image restoration using adaptive attenuation-curve prior[J]. IEEE Transactions on Circuits and Systems I: Regular Papers, 2017, 65(3): 992-1002.

[142] Liu Hongmin, Ding Yan, Zeng Hui, et al. A Cascaded Multimodule Image Enhancement Framework for Underwater Visual Perception[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024: 1-13.

[143] Protas E., Bratti J. D., Gaya J. F. O., et al. Visualization methods for image transformation convolutional neural networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2018, 30(7): 2231-2243.

[144] Yang H. H., Huang K. C., Chen W. T. Laffnet: A lightweight adaptive feature fusion network for underwater image enhancement[C]. IEEE International Conference on Robotics and Automation, 2021: 685-692.

[145] Iqbal K., Odetayo M., James A., et al. Enhancing the low quality images using unsupervised colour correction method[C]. IEEE International Conference on Systems, Man and Cybernetics, 2010: 1703-1709.

[146] Naik S. K., Murthy C. A. Hue-preserving color image enhancement without gamut problem[J]. IEEE Transactions on Image Processing, 2003, 12(12): 1591-1598.

[147] Chen L. C., Papandreou G., Kokkinos I., et al. Deeplab: Semantic image

中国知网 https://www.cnki.net

segmentation with deep convolutional nets, atrous convolution, and fully connected crfs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(4): 834-848.

[148] Wang Tenghui, Wang Lili, Zhang En, et al. Underwater image enhancement based on optimal contrast and attenuation difference[J]. IEEE Access, 2023, 11: 68538-68549.

[149] Simonyan K., Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.

[150] Jiang Zhiying, Li Zhuoxiao, Yang Shuzhou, et al. Target oriented perceptual adversarial fusion network for underwater image enhancement[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 32(10): 6584-6598.

[151] Qin Xuebin, Zhang Zichen, Huang Chenyang, et al. Basnet: Boundary-aware salient object detection[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2019: 7479-7489.

[152] Cao Zhe, Simon T., Wei S. E., et al. Realtime multi-person 2d pose estimation using part affinity fields[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2017: 7291-7299.

[153] Ranftl R., Lasinger K., Hafner D., et al. Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 44(3): 1623-1637.

[154] Dalal N., Triggs B. Histograms of oriented gradients for human detection[C]. IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2005, 1: 886-893.

[155] Felzenszwalb P. F., Girshick R. B., McAllester D., et al. Object detection with discriminatively trained part-based models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2009, 32(9): 1627-1645.

[156] Lin Weihong, Zhong Jiaxing, Liu Shan, et al. Roimix: proposal-fusion among multiple images for underwater object detection[C]. IEEE International Conference on Acoustics, Speech and Signal Processing, 2020: 2588-2592.

[157] Jiang Lihao, Wang Yi, Jia Qi, et al. Underwater species detection using channel sharpening attention[C]. ACM International Conference on Multimedia, 2021: 4259-4267.

中国知网 https://www.cnki.net

[158] He Kaiming, Zhang Xiangyu, Ren Shaoqing, et al. Identity mappings in deep residual networks[C]. European Conference on Computer Vision. Springer, 2016: 630-645.

[159] Huang Gao, Liu Zhuang, Maaten L. V. D., et al. Densely connected convolutional networks[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2017: 4700-4708.

[160] Szegedy C., Liu Wei, Jia Yangqing, et al. Going deeper with convolutions[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1-9.

[161] Szegedy C., Vanhoucke V., Ioffe S., et al. Rethinking the inception architecture for computer vision[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2016: 2818-2826.

[162] Zhang Xiangyu, Zhou Xinyu, Lin Mengxiao, et al. Shufflenet: An extremely efficient convolutional neural network for mobile devices[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2018: 6848-6856.

[163] Ding Xiaohan, Zhang Xiangyu, Ma Ningning, et al. Repvgg: Making vgg-style convnets great again[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2021: 13733-13742.

[164] Wang C. Y., Liao H. Y. M., Wu Y. H., et al. CSPNet: A new backbone that can enhance learning capability of CNN[C]. IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2020: 390-391.

[165] Tan Mingxing, Pang Ruoming, Le Q. V. Efficientdet: Scalable and efficient object detection[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2020: 10781-10790.

[166] Wu Yue, Chen Yinpeng, Yuan Lu, et al. Rethinking classification and localization for object detection[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2020: 10186-10195.

[167] Tian Zhi, Shen Chunhua, Chen Hao, et al. Fcos: Fully convolutional one-stage object detection[C]. IEEE International Conference on Computer Vision, 2019: 9627-9636.

[168] Ge Zheng, Liu Songtao, Wang Feng, et al. Yolox: Exceeding yolo series in 2021[J]. arXiv preprint arXiv:2107.08430, 2021.

[169] Bochkovskiy A., Wang C. Y., Liao H. Y. M. Yolov4: Optimal speed and accuracy

中国知网 https://www.cnki.net

of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.

[170] Zhang Hongyi, Cisse M., Dauphin Y. N., et al. mixup: Beyond empirical risk minimization[J]. arXiv preprint arXiv:1710.09412, 2017.

[171] Li Chuyi, Li Lulu, Jiang Hongliang, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.

[172] Wang Ao, Chen Hui, Liu Lihao, et al. Yolov10: Real-time end-to-end object detection[J]. Advances in Neural Information Processing Systems, 2024, 37: 107984-108011.

[173] Khanam R., Hussain M. Yolov11: An overview of the key architectural enhancements[J]. arXiv preprint arXiv:2410.17725, 2024.

[174] Tian Yuejie, Ye Qixiang, Doermann D. Yolov12: Attention-centric real-time object detectors[J]. arXiv preprint arXiv:2502.12524, 2025.

[175] Zhang Shifeng, Chi Cheng, Yao Yongqiang, et al. Bridging the gap between anchor-based and anchor-free detection via adaptive training sample selection[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2020: 9759-9768.

中国知网 https://www.cnki.net