学校代码：10589

分 类 号：TP391

学　　号：21110810000038

密　　级：公开

海南大学

博 士 学 位 论 文

基于消化道疾病的共聚焦内窥镜图像分析算法研究

作 者 姓 名：周经俊

导 师 姓 名：刘谦

学 科 专 业：信息与通信工程

培 养 院 系：信息与通信工程学院

2025年5月28日

中国知网 https://www.cnki.net

A Dissertation Submitted to Hainan University for the Degree of Doctor

Research on Confocal Laser Endomicroscopy Image Analysis Algorithm for Based on GI Diseases

By ZHOU Jingjun

Supervisor: LIU Qian

Information and Communication Engineering

School of Information and Communication Engineering

May, 2025

中国知网 https://www.cnki.net

摘要

共聚焦内窥镜（Confocal Laser Endomicroscopy，CLE）作为一种新型光学活检成像技术，凭借其独特的细胞级分辨率和实时在体成像能力，已成为消化道肿瘤早期诊断的重要临床检查手段。然而，CLE探头的光纤束结构会影响图像质量，且病变形态复杂多样、组织边缘模糊，肿瘤病理分级的准确性高度依赖医师临床经验，而专业医师的培养周期较长，亟需解决上述问题。因此，开发消化道疾病早期精准诊疗的图像处理方法具有重要临床应用价值，其不仅能提升临床决策的准确性并降低人为失误，还能增强医疗资源匮乏地区在疾病早期发现和及时治疗方面的可及性。本文以消化道CLE医学图像为研究对象，围绕图像处理的全过程，开展了CLE图像去噪、分割和识别等关键技术研究，并结合其他模态消化道医学图像进行临床需求分析。具体研究内容如下：

（1）针对共聚焦内窥镜成像过程中产生各种形式的噪声，本研究提出了基于物理成像真实噪声统计分布特性的自监督去噪方法，摆脱了对配对无噪声干净图像的依赖。通过设计具有自适应区域权重与适度感受野动态调节的上下文感知核估计模块，有效应对噪声分布不均，构建了轻量级去噪模型CLENet。多尺度动态融合模块通过特征解耦与跨尺度交互实现上下文信息的动态校准。将上述模块集成到U型架构中，构建了高效去噪网络U-CLENet。实验结果表明，所提出的方法在保持较低计算复杂度的同时，其去噪性能与现有方法相当甚至更优，为后续CLE图像分析任务提供了高质量的预处理结果。

（2）针对消化道病变类型形态多样性及组织边界模糊等挑战，本研究提出了一种金字塔ViT多尺度混合结构的消化道图像分割方法PMHNet，通过将三个模块与金字塔Transformer结合，学习更强大且稳健的特征。这三个模块分别为包括密集门控连接模块（Dense Gated Connection，DGC），自多尺度交互融合模块（Self Multi-Scale Interaction Fusion，SMSF）和多尺度注意力解码模块（Multi-scale Attention Decoding，MAD），用于提取和融合医学图像的多尺度上下文信息。DGC通过密集门控特征融合机制级联局部语义特征，减少浅层背景特征干扰，缓解病灶尺寸与类型差异。SMSF利用自多尺度多头注意力融合局部与全局特征，引导网络关注感兴趣区域，应对病变

中国知网 https://www.cnki.net

与周围组织相似的问题。MAD通过级联多尺度语义特征，细化特征以实现精确分割。该方法在共聚焦内窥镜人体消化道腺体、共聚焦内窥镜动物结肠隐窝、病理图像腺体和电子内窥镜息肉分割任务分别取得了90.35%/94.68%、81.60%/89.81%、86.86%/92.65%和77.49%/84.31%的mIoU/mDice指标。定量与定性分析结果表明，PMHNet在分割准确性和泛化性方面均优于现有方法，为后续CLE图像分类任务提供了精准可靠的腺体解剖结构形态学依据以提升分类数据人工标注效率及模型可解释性。

（3）针对CLE图像数据集中存在的类间方差小和类内方差大及标注数据稀缺等挑战，本研究提出了一种聚类引导的双对比学习方法CTCL，旨在提高CLE图像的判别性表征，增强消化道CLE图像的分类性能。与传统对比学习方法不同，CTCL通过实例级和簇级双对比学习对齐更多语义相关且类别一致的样本，从而增强类内紧凑性和类间可分性，获得更具信息性的特征。此外，基于CLE的固有特性，本研究进一步提出将任意角度旋转和不同噪声的CLE图像分别视为同一实例，以增加特征的多样性。最后，通过端到端的期望最大化算法迭代优化CTCL框架。实验结果表明，CTCL在线性评估和小样本学习下游任务中分别取得了75.60%/78.45%和64.12%/77.37%的准确率，优于现自监督学习和监督学习方法，且展现出更优的鲁棒性和泛化性。

（4）针对CTCL缺乏对图像内及图像间局部相似区域相关性建模等挑战，本研究提出了一种结合对比学习和词袋模型的多任务学习方法CB-MTL，通过自监督学习更有效地从未标注的CLE图像中提取判别性表征。该方法的主任务为对比学习，学习具有变换不变的图像表征，辅助任务则采用词袋模型，捕捉与结构和内容相关的局部特征，增强对比学习的鲁棒性。通过这种方式，CB-MTL能够实现变换不变的预测，并有效地捕捉图像的结构和内容相关信息。实验结果表明，该方法在多个下游任务中取得77.61%/81.82%/75.83%的准确率，验证了词袋模型的有效性，并显著提升了CLE图像分析性能。值得注意的是，CB-MTL在CNN和Transformer架构中均表现优异，进一步表明了词袋模型能够显著提升对比学习的表征质量，且无需额外标注数据。

本研究构建的计算机辅助诊断系统在图像质量增强、病灶定位和病理分级分类等关键环节均取得了突破，有助于为消化道肿瘤的精准诊疗提供新的技术支撑。

关键词：消化道医学图像；深度学习；共聚焦内窥镜图像；图像去噪；图像分割；图像分类

中国知网 https://www.cnki.net

ABSTRACT

As a novel optical biopsy imaging technology, Confocal Laser Endomicroscopy (CLE) has become important clinical examination technique for early diagnosis of GI tumors due to its unique real-time imaging capability with cellular-level resolution. However, the fiber-optic bundle structure of the CLE probe affects the image quality, the morphology of lesion tissues is complex and diverse with blurred edge features, and the accuracy of tumor pathology grading is highly dependent on physicians' clinical experience, which requires a long period of professional training, and this presents an urgent need for improvement. Therefore, the development of image processing methods for the early and accurate diagnosis and treatment of GI diseases has significant clinical value, which which not only improves the accuracy of clinical decision-making and reduces human errors, but also enhances the accessibility of areas with scarce medical resources in terms of early disease detection and timely treatment. In this study, we take GI CLE medical images as the research object, focus on the whole process of image processing, conduct research on the key technologies of CLE image denoising, segmentation and recognition. In addition, utilizing GI medical images from other modalities, we integrated clinical requirements for further analysis and investigation. The specific research contents are as follows:

(1) For the various types of noise that CLE inevitably generates during the imaging process, a self-supervised denoising method based on physical imaging characteristics is proposed to eliminate the dependence on paired noise-free clean images. The context-aware kernel estimation module with adaptive region weighting and moderate sensory field dynamic adjustment is designed to effectively deal with the non-uniformity of noise distribution, and a lightweight denoising model CLENet is constructed. The multi-scale dynamic fusion module is designed to provide dynamic calibration of contextual information through feature decoupling and cross-scale interaction. Finally, we integrate two developed modules into a U-shaped backbone to build an efficient denoising network named U-CLENet. Both proposed methods achieve comparable or even better performance with low computational complexity to provide high-quality preprocessing results for subsequent CLE image analysis tasks.

(2) To address the challenges of morphological diversity and blurred tissue boundaries of GI lesions, a Pyramid Multi-Scale Hybrid Network PMHNet is proposed to learn more

中国知网 https://www.cnki.net

powerful and robust features through integrating three modules with Pyramid Transformer. The proposed modules include Dense Gated Connection (DGC), Self Multi-Scale Interaction Fusion (SMSF), and Multi-Scale Attention Decoding (MAD) for extraction and fusion of multiscale contextual information from medical images. The DGC employed a dense gated feature fusion mechanism to cascade local semantic feature information, which minimized shallow background noise and alleviates the variations in lesion size and type. Additionally, SMSF directed the network to focus on regions of interest by fusing local and global features through self-multi-scale multi-head attention, effectively mitigating the challenge posed by the similarity of lesions to surrounding tissues. Lastly, MAD refined features for accurate segmentation by cascading multi-scale semantic feature information. Experimental results show that PMHNet has achieved excellent performance on multiple datasets, and achieves mIoU/ mDice of 90.35%/94.68%, 81.60%/89.81%, 86.86%/92.65%, and 77.49%/84.31% in the CLE human GI glands, CLE animal colonic crypt, pathological image gland, and electronic endoscopic polyp segmentation tasks, respectively. The results of quantitative and qualitative analyses indicate that PMHNet outperformed existing methods in terms of segmentation accuracy and generalization to provide an accurate and reliable morphological basis of glandular anatomical structure for the subsequent CLE image classification task to improve the manual annotation efficiency and model interpretability.

(3) In order to address the challenges of small interclass variance and large intraclass variance and scarcity of labeled data in the CLE image dataset, a novel clustering-guided twin-contrastive learning framework CTCL is proposed to improve the discriminative representation of CLE images for GI tumor classification. Compared with traditional contrastive learning, CTCL aligns more semantically related and class-consistent samples by clustering, which improves intra-class tightness and inter-class variability to produce more informative representations. Furthermore, based on the inherent properties of CLE, we proposed to regard CLE images with any angle rotation and CLE images with different noises as the same instance, respectively, for increased variability and diversity of samples. Finally, the CTCL is iteratively optimized by an end-to-end expectation maximization algorithm. Experimental results show that CTCL achieved 75.60%/78.45% and 64.12%/77.37% top-1 accuracy on the linear evaluation protocol and few-shot classification downstream tasks, respectively, which outperform the existing state-of-the-art SSL and supervised methods, and exhibits better robustness and transferability.

(4) In response to challenges of CTCL lack of modeling the relevance of locally similar regions within and between images, a multi-task learning algorithm CB-MTL is proposed that combines contrastive learning and bag-of-words to learn more robust visual

中国知网 https://www.cnki.net

representations from unlabeled CLE data through self-supervised learning. The main task is a contrastive learning task for learning transformation-invariant representations, while the auxiliary task involves a bag-of-words objective to capture structural and content-related information from diverse local similarity regions to enhance the robustness and generalization of the main task. In this way, CB-MTL enables transform-invariant prediction and effectively captures structural and content-related information of images. Experimental results show that the method achieves 77.61%/81.82%/75.83% accuracy in multiple downstream tasks, validates the effectiveness of the bag-of-words, and significantly improves the CLE image analysis performance. Notably, CB-MTL works across both CNN and Transformer architectures and shows that BoW significantly improves the quality of representation for contrastive learning on both CLE image datasets without requiring additional annotations.

The computer-aided diagnosis system constructed in this study has made breakthroughs in crucial aspects of image quality enhancement, lesion localization and pathology grading and classification, which can help to provide new technical support for the precise diagnosis and treatment of GI tumors.

Key Words: GI medical image, Deep learning, Confocal laser endomicroscopy image, Image denoising, Image segmentation, Image classification

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 课题研究背景及意义.....1
1.2 共聚焦内窥镜成像技术.....3
1.3 共聚焦内窥镜技术国内研究应用进展.....6
1.4 国内外研究现状.....7
1.4.1 共聚焦内窥镜医学图像复原任务研究.....7
1.4.2 共聚焦内窥镜医学图像腺体分割任务研究.....12
1.4.3 共聚焦内窥镜医学图像分类任务研究.....14
1.5 本文的主要工作.....19
1.6 本文的结构安排.....20
2 基于上下文感知动态滤波的图像去噪方法.....23
2.1 引言.....23
2.2 核估计与自监督学习图像去噪概述.....25
2.2.1 核估计图像去噪.....25
2.2.2 自监督学习图像去噪.....25
2.3 上下文感知动态滤波自监督去噪方法.....26
2.3.1 真实噪声统计特性.....26
2.3.2 上下文感知核估计模块.....28
2.3.3 多尺度动态融合模块.....30
2.3.4 U-CLENet 结构.....32
2.4 实验分析.....33
2.4.1 实验设置.....33
2.4.2 非盲去噪.....35
2.4.3 盲去噪.....36
2.4.4 可视化分析.....38
2.4.5 消融实验.....40
2.4.6 讨论.....41
2.5 本章小结.....41
3 基于金字塔 ViT 多尺度混合结构的消化道图像分割方法.....43
3.1 引言.....43
3.2 U 型医学图像分割与视觉 Transformer 概述.....44
3.2.1 U 型医学图像分割.....44
3.2.2 视觉 Transformer.....45
3.3 金字塔 ViT 多尺度混合网络.....46

中国知网　https://www.cnki.net

3.3.1 金字塔 Transformer 46
3.3.2 密集门控连接模块 47
3.3.3 自多尺度交互融合模块 49
3.3.4 多尺度注意力解码模块 51
3.3.5 损失函数 52
3.4 实验分析 53
3.4.1 实验设置 53
3.4.2 人体消化道腺体分割实验 54
3.4.3 动物结肠隐窝分割实验 56
3.4.4 病理腺体分割实验 58
3.4.5 息肉分割实验 59
3.4.6 消融实验 63
3.4.7 讨论 66
3.5 本章小结 66
4 聚类引导的双对比学习图像分类方法 68
4.1 引言 68
4.2 聚类引导双对比学习方法 70
4.2.1 正样本对构建 70
4.2.2 双对比学习框架 71
4.2.3 期望最大化优化 76
4.2.4 小样本学习 76
4.3 实验分析 77
4.3.1 数据集 77
4.3.2 实验设置 79
4.3.3 模型评估 80
4.3.4 消融实验 82
4.3.5 可视化结果 83
4.3.6 讨论 84
4.4 本章小结 86
5 基于对比学习与词袋模型的多任务学习图像分类方法 87
5.1 引言 87
5.2 多任务学习与词袋模型概述 88
5.2.1 多任务学习 88
5.2.2 词袋模型 89
5.3 对比学习与词袋模型多任务学习方法 89
5.3.1 对比学习 90
5.3.2 词袋模型 91
5.3.3 优化目标 95

中国知网 https://www.cnki.net

5.4 实验分析.....95
5.4.1 数据集和评估指标.....95
5.4.2 实验设置.....95
5.4.3 模型评估.....97
5.4.4 消融实验.....100
5.4.5 可视化表征.....102
5.4.6 可视化视觉词.....103
5.4.7 讨论.....103
5.5 本章小结.....104
6 总结与展望.....105
6.1 工作总结.....105
6.2 研究展望.....107
参考文献.....109

中国知网 https://www.cnki.net

1 绪论

1.1 课题研究背景及意义

医学成像技术的发展可追溯至1895年，德国物理学家威廉·伦琴通过系统实验首次发现了X射线[1]，并成功实现人体内部结构的可视化呈现，这项里程碑式发现为现代医学影像诊断技术奠定了基础。随着20世纪科学的进步和发展，各种成像技术相继问世，不仅为临床医学带来了可视化和革命性的诊断工具，更为神经科学和生物医学研究发挥了重要作用。作为现代医学体系的重要组成部分，医学成像技术通过非侵入性方式实现人体结构与功能的可视化分析，显著提升了疾病诊断的准确性与治疗方案的针对性。近年来，成像技术的迭代更新持续推动该领域向更高精度和更低损伤方向发展，形成了多模态协同的诊断体系。现有常见的医学成像技术体系主要包括：X射线成像[1]、超声成像[2,3]、计算机断层扫描（Computed Tomography，CT）[4]、显微成像[5]和磁共振成像（Magnetic Resonance Imaging，MRI）[6]。这些技术凭借各自独特的优势，广泛应用于不同的临床诊断和科学研究，为医学领域提供了强有力的支持，特别是在疾病的早期筛查、精确定位及个性化治疗等方面发挥着不可替代的作用。

医学成像诊断的准确性受限于医学影像数据质量与临床医师的影像解析水平双重因素。作为现代临床诊疗体系的重要组成部分，医学影像解析为疾病筛查、干预策略制定及疗效评估提供客观依据。在临床决策过程中，医生需整合影像解析结论、实验室检测指标以及病史特征等多维度信息，构建完整的诊断证据链，进而制定个性化的治疗方案以及预后管理等闭环医疗行为，从而实现精确而有效的闭环医疗过程。具备精确且高效医学影像分析能力的医生和专家，必须经过严格的专业培训与实践积累，才能确保其分析结果的可靠性和临床应用的有效性[7]。同时，医学影像分析不仅消耗医生大量的时间和精力，还对其专业知识和临床经验提出了更高的要求。在临床实践中，医生通常需在有限时间内迅速且准确地识别影像中的病理学特征，判断病变的性质、范围和严重程度，并结合患者的临床资料进行全面的诊断评估。这一过程可能受工作疲劳、注意力分散等主观因素的影响，从而增加误诊或漏诊的风险[8]。此外，随着医学影像数据的复杂性和数据量的持续增长，仅依靠人工分析已难以应对这些挑战。

中国知网 https://www.cnki.net

以消化道医疗为例，消化道疾病是全球范围内发病率和死亡率较高的疾病之一，尤其是胃癌和结直肠癌等恶性肿瘤[9,10]。特别是在发展中国家，由于医疗资源相对匮乏、早期筛查和诊断手段不足，许多患者在疾病晚期才被确诊，导致预后较差[11]。临床经验表明，消化道癌早期多呈现非特异性临床表现，且临床诊断易受医师经验差异及技术条件限制影响，导致漏诊与误诊风险显著增加。由于早期诊断与患者预后生存率密切相关，实现病变的精准识别具有重要临床价值。然而，传统影像学分析方法受限于主观判读偏差及医疗资源可及性不足等问题，难以满足高效筛查需求。因此，亟需一种能够在早期阶段高效、准确识别病变的医学辅助工具，以辅助医生进行诊断，减少人为误差，优化临床决策流程。当前，人工智能和深度学习技术已展现出显著优势[12]，依托大规模影像数据的自动化分析，提升消化道疾病早期诊断的敏感性与特异性。

近十年来，得益于计算机硬件性能的显著提升，尤其是图形处理器（Graphics Processing Unit，GPU）和高性能计算技术的快速发展，基于人工智能（Artificial Intelligence，AI）和深度学习的医学影像分析研究在消化道疾病领域取得显著进展[13]。消化道AI医疗能够成为研究热点的原因除了消化道疾病的高发病率和复杂性对早期诊断和精确治疗的需求不断增加之外，还得益于腹腔镜和病理切片等影像技术提供了大规模且丰富的高质量结构化数据集。这些数据为AI算法开发与优化提供了坚实基础，使其能够在临床应用中实现更高效的病灶识别与诊断。同时，AI技术结合消化道影像学，提升了医生工作效率，降低了误诊率，从而在临床实践中得到广泛推广。然而，这些影像技术进行疾病筛查时，需对病变部位进行组织病理切片，存在操作成本高、并发症风险等问题，促使临床寻求更安全的替代方案。CLE的出现恰好弥补了这一缺陷，其作为新兴光学显微技术，自2004年首次应用于临床以来，逐渐成为消化道疾病诊断中的重要工具之一[14]。通过实现实时在体组织的细胞级别高分辨率成像，CLE能够对病变部位的血管、结缔组织及细胞或亚细胞结构的变化进行实时精确观察，即光学活检[15]。由于目前大多数CLE研究是由资深的内镜专家主导且CLE影像的判读和解释存在一定的学习曲线，这对于缺乏经验的内镜医生需要花费较长时间的训练和学习。同时，CLE图像形态与白光内窥镜图像存在较大差异，图像内容具有高度的不确定性，发现具有不同经验的医生的诊断结果显著不一致[16]。此外，由于CLE光纤头的单根光纤芯和包层的物理透射率不同导致成像质量受到不同程度的影响，并且CLE图像诊断病变类型主要是依赖于观察细胞的组织结构形态差异，这通常会干扰医生的观察甚至误导诊断结果，从而导致对肿瘤分级分类的疾病诊断提出了新的挑战[17]。因此，开发

中国知网 https://www.cnki.net

AI辅助判读系统，通过自动化分析工具帮助医生更高效、准确地解读影像，从而缩短学习曲线并提高诊断一致性，提升CLE在医学领域的应用潜力，从而能够更广泛地被应用于各种消化道疾病的早期筛查和精准诊断。

基于医学影像的人工智能辅助诊断涵盖数据集构建、数据预处理（数据增强和质量增强）、病灶分割及分类等多个关键环节。医学影像辅助分析技术通常分为传统方法和深度学习方法。传统方法依赖于手工设计的特征工程来提取图像的纹理、形状、边缘等特征，并使用支持向量机、随机森林等机器学习算法作为分类器完成最后的决策。这些方法对特征提取的依赖性较强，往往受限于特定任务的有效性和泛化能力。深度学习方法通过GPU并行计算与大规模数据集的支持，能够自动学习特征，无需人工干预即可完成病灶检测、分割和分类等任务。相比于传统方法，深度学习在处理复杂图像信息方面表现出较高的准确性和良好的泛化性。随着百万级医学影像数据库的建立和算力水平的指数级增长，深度学习已成为医学影像分析研究的主流范式。然而，由于CLE作为新型临床诊疗设备，相较于CT、MRI等成熟影像技术及传统内镜手段，其临床应用时间较短、技术迭代体系尚未完善，导致图像样本稀缺、标注数据获取困难（需依赖内镜医师经验且标注成本高昂）等核心挑战，致使深度学习方法易受缺乏高质量标注数据与样本规模有限的双重制约。本研究聚焦消化道人工智能辅助诊断领域，以CLE图像为主要研究对象，进行包括去噪、分割和分类一系列较为系统、全面和深入的研究，旨在突破现有方法在CLE影像解析中的技术瓶颈，辅助医生更高效、准确地解读CLE图像，从而实现早期筛查与精准诊断。

1.2 共聚焦内窥镜成像技术

共聚焦内窥镜成像技术的问世是内窥镜诊断领域的一项突破性进展，它将光学共聚焦显微镜的高分辨率与传统内窥镜的深部组织观察能力相结合，提供了微米级分辨率对粘膜细胞和亚细胞结构的在体实时观察[18]。共聚焦显微镜于1957年由Marvin Minsky发明，其通过采用逐点扫描和针孔光阑技术来实现高分辨率和高对比度的成像，其结构如图1.1所示。该系统将激光作为光源，通过物镜聚焦至样品的微小区域，激发样品中的荧光染料产生荧光。这些荧光沿相同路径反射回物镜并被引导至分束器，后者将荧光引导至针孔光阑。针孔光阑的设计仅允许来自样品焦平面的光通过，有效排除了来自焦外平面的散射光，从而仅收集来自焦平面的光信号。光信号被光检测器捕

中国知网 https://www.cnki.net

获，并转换为电信号，最终重建获得不同深度的光学切片图像[19]。共聚焦内窥镜成像技术的核心是由数万根光纤组成的光纤束，每根光纤都相当于一个单像素探测器。光纤束用于传输通过扫描光纤近端收集到的双向光信号。该技术的优势在于它无需活检即可实现“光学切片”，从而提供高度精确的组织微观结构图像。与传统内窥镜相比，共聚焦内窥镜成像技术不仅能够提高图像的空间分辨率和减少侵入性操作，还能直接识别微小病灶和早期癌变，降低误诊率和漏诊率。此外，这种实时在体显微成像的特点还能减少病理活检的等待时间以及降低术中和术后的并发症风险。这项技术在消化道、呼吸道和乳腺等部位的黏膜病变和早期癌变的筛查得到了广泛的临床应用。

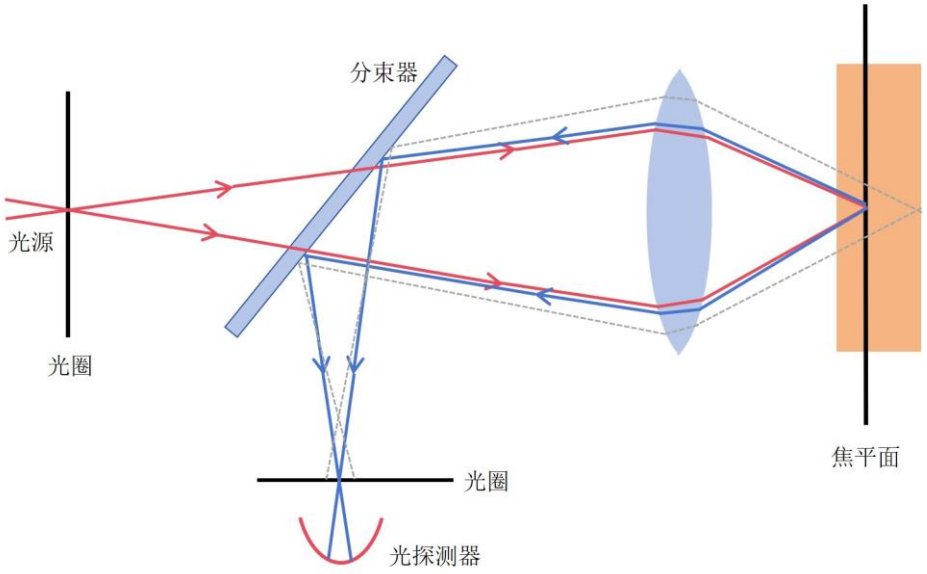


图1.1 共聚焦显微镜结构示意图

共聚焦内窥镜成像技术的结构如图1.2所示。该系统主要由激光器、光电探测器、共聚焦扫描系统、内窥镜探头、光学滤波器及图像处理单元组成。首先，激光器发射特定波长的激光，通过二向色镜将激光引导进入光路系统。接着，激光依次通过双轴共聚焦扫描系统和物镜，扫描目标区域。双轴共聚焦扫描系统的作用是通过X轴方向的频率为4 KHz振镜和Y轴方向的频率为12 Hz振镜，精确控制光纤束的逐行逐列扫描路径，确保仅对焦点所在的薄层进行成像，从而提高横向和纵向的空间分辨率。经过物镜聚焦后的激光进入内窥镜探头，用于激发已被特定荧光剂染色的成像组织。目前常用的荧光剂包括荧光素钠、盐酸吖啶黄、四环素和甲酚紫，其中荧光素钠为静脉注射，其余三者皆为表面喷洒。当激光照射被这些荧光剂染色的组织时，荧光剂发出携带组织信息的荧光信号，并通过光纤束沿原始光路返回，通过物镜再进入双轴共聚焦扫描系统。然后，二向色镜将这些信号引导至光电探测器，光电探测器将接收到的光

中国知网 https://www.cnki.net

信号转换为电信号。最终，图像处理单元对这些电信号进行分析和重构，并通过专用的算法来进行校准和重建，最终生成高分辨率的实时组织视频序列。重构方法通常采用插值技术和去模糊算法，以将蜂窝状采样信号平滑转换为连续的组织图像。此外，图中的光电探测器前的小孔与光纤束近端断面的物镜互为共轭，从而仅允许来自焦点平面上的反射信号通过，排除来自非焦点平面（即散射光或背景光）的干扰，从而增强成像的对比度和信噪比[15]。

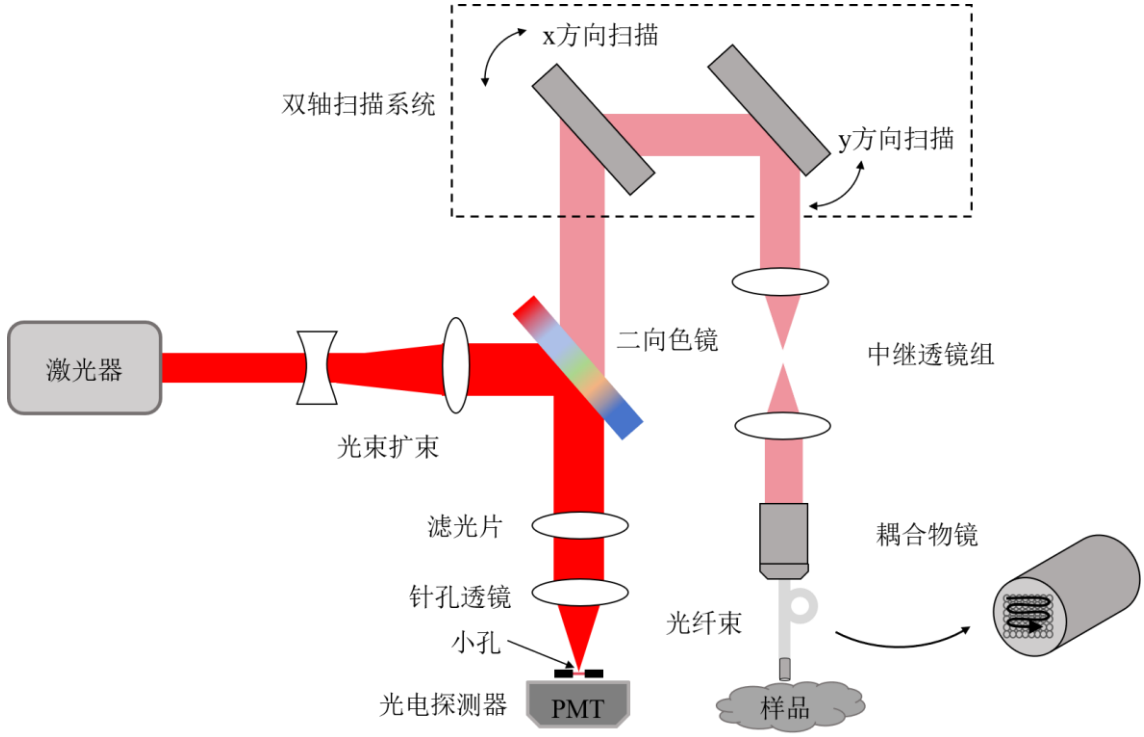


图1.2 共聚焦内窥镜结构示意图

目前，CLE可分为基于内镜的CLE（eCLE）和基于探头的CLE（pCLE）。eCLE是通过在内镜设备前端集成单光纤共聚焦显微技术，成像深度可调但速度慢；而pCLE是利用可通过传统内镜的活检通道插入由数千根光纤组成的光纤束微型探头实现，成像深度固定且速度相对较快。pCLE不仅能从白光内窥镜摄像头获得标准的表面成像视图外，还能够以前所未有的方式获得组织内细胞的在体显微图像。在pCLE检查过程中，患者通常会接受静脉注射荧光素钠（肺部检查除外），以提高组织切片的对比度。然后，临床医生通过白光内窥镜摄像头识别大致的异常区域，并将探头的尖端与该组织直接接触。通过光纤束传输的激光与组织相互作用后，探头物镜收集反射的荧光信号，从而重建高分辨率的显微图像。此外，由于eCLE和pCLE设备光学成像特性不一致，导致二者在采集和重建数据信号时光纤的工作模式和带来的噪声模型存在显著差异。前者需要处理单根光纤采集所引起的不规则信号，而后者需要处理由数千根

中国知网 https://www.cnki.net

光纤组成的光纤束生的不规则信号。在本研究中，所有采集的图像均来自pCLE设备。

1.3 共聚焦内窥镜技术国内研究应用进展

CLE作为一种高分辨率在体实时显微成像技术，自2013年被引入国内并首次应用于肺癌成像特征研究以来，其研究与应用范围已逐步扩展至消化系统、呼吸系统以及胰腺和胆道等领域的疾病诊断与评估。国内学者和相关企业的持续探索与深入合作，有效推进了CLE技术的国产化与设备迭代，实现了技术改进和多学科交叉融合，并在部分疾病的诊断标准制定和临床指南推荐中取得了重要突破。本文将从技术研究的实践优化、临床应用现状及临床指南纳入情况三个层面进行详细论述。

自2013年引进中国以来，国内学者对CLE技术进行了持续的系统性研究。在基础研究方面，致力于优化成像原理，以提升图像的分辨率和清晰度。华中科技大学付玲教授团队通过优化成像光路设计，显著提高了成像探头的视场分辨率和光信号采集效率以及成像质量[20]。同时，他们开发了系列图像处理算法，有效提升了图像分辨率与清晰度和实现组织关键结构特征的精准可视化[21]。此外，中国科学院苏州生物医学工程技术研究所的杨西斌教授团队在医用光学内窥成像领域取得了重要突破，通过精准调控激光光源参数和自主研发的光学耦合技术，实现了显微及内窥专用光纤的高效耦合，并开发智能图像处理算法，显著增强了组织结构对比度[22]。在国产化方面，国内相关企业与科研机构展开了深度合作，如精微视达医疗科技有限公司与华中科技大学等机构联合研发了具有自主知识产权的CLE设备，其核心性能达到或者超过进口设备，同时也在积极推进核心器件国产化，大幅降低了临床应用成本。此外，海斯凯尔也积极参与CLE技术研发，与清华大学等科研团队合作，在设备的小型化和智能化方面取得了显著进展，推动该技术在国内的广泛应用。

目前，CLE技术已在国内临床多学科领域实现广泛应用。在消化系统疾病诊疗中，该技术已被列为早期消化道肿瘤筛查与诊断的重要工具。胃镜检查中，CLE对可疑病灶进行实时显微成像，通过动态观察胃黏膜腺管开口形态特征及微血管网络分布模式，有助于术中实时诊断评估，为早期胃癌判别提供客观影像学依据，提高靶向活检效率[23]。在食管疾病诊断中，CLE高分辨率成像能清晰展示食管上皮细胞形态、排列方式以及微血管分布特征，有效识别早期食管癌及异型增生病变，实现精准定位活检，降低正常组织取样率[23]。在结直肠疾病诊断中，CLE可清晰显示结直肠黏膜隐窝结构，

中国知网 https://www.cnki.net

为炎症性肠病与结直肠肿瘤的鉴别提供重要依据[24]。在呼吸系统疾病领域，CLE不仅可用于肺癌的早期诊断与分期，特别是对支气管镜下难以获取病理的微小病变，可提供微观层面的诊断信息[25]。在肺部感染性疾病，如真菌性肺炎的诊断中，通过观察病原体形态及周围组织反应，可辅助临床诊断与治疗决策。在胰腺及胆道系统疾病诊疗中，CLE通过囊壁上皮结构的显微成像分析，可准确区分黏液性囊腺瘤与非肿瘤性胰腺囊肿，为制定个体化治疗方案提供关键依据[26]。现有临床证据表明，CLE技术通过提供实时在体显微成像，显著提高了多系统疾病的诊断准确率与治疗靶向性，已成为精准医学实践中的重要技术支撑。

随着医学证据的不断积累与临床应用体系的完善，CLE技术已被纳入多项权威临床诊疗指南。国家卫生健康委员会办公厅在2024年6月发布的《食管癌筛查与早诊早治方案（2024年版）》和《胃癌筛查与早诊早治方案（2024年版）》明确建议，食管癌和胃癌筛查首推采用普通白光内镜检查，对于发现的可疑病灶可应用特殊内镜技术，其中就包括CLE检查并进行活检。该方案明确指出，CLE技术可辅助医生更精准地判断病变情况，为早期食管癌和胃癌的诊断提供关键微观信息，有助于提升早期病变检出率。同时，《早期肺癌诊断中国专家共识（2023年版）》[27]指出，CLE可识别支气管内和肺实质内的异常病灶区域，在早期肺癌诊断流程中能辅助医生定位潜在病变，为后续诊断手段的实施提供方向。然而，该共识也指出，CLE难以仅凭图像区分病灶的良恶性，临床应用需结合组织病理学分析、影像学特征等多模态诊断手段，以提高早期肺癌诊断准确性。此外，《中国显微内镜消化系统疾病临床应用共识意见》强调，CLE通过实现细胞及亚细胞水平的实时在体显微观察，可精准解析胃肠道黏膜腺管开口结构与微血管密度分布特征，对早期胃癌、Barrett食管等癌前病变的定量诊断具有重要临床价值，为制定个体化诊疗方案提供循证依据[28]。这些指南的制定基于大量国内临床研究数据及专家共识，不仅规范了CLE技术的临床应用路径，更推动了该技术在疾病诊疗中的深化应用。

1.4 国内外研究现状

1.4.1 共聚焦内窥镜医学图像复原任务研究

图像复原技术旨在通过一系列后处理方法减少或消除图像在获取和传输过程中产生的失真和噪声，从而恢复图像的原始质量和细节，提高其信噪比。这些技术通常

中国知网 https://www.cnki.net

包括去噪、去模糊和超分辨率等，以应对由设备缺陷、环境干扰或传输错误等导致的图像退化问题，提升图像在应用中的有效性与准确性[29]。图像复原方法通常在频率域或空间域对退化算子进行逆运算。频率域技术基于傅立叶变换的频谱特征分析，能有效抑制周期性噪声与模糊，但在处理复杂的退化模型时存在局限性。空间域方法则通过直接在图像像素上操作来修复图像，包括使用各种空间滤波器和学习型增强技术来提升图像质量。

相较于其他成像方式，pCLE图像复原研究较少，主要原因是光纤束成像在临床领域尚属新颖。现有研究主要集中在消除图像伪影、提高图像超分辨及校正由图像网格不规则和软组织成像引起的非刚性形变导致的图像失真。这些研究涉及纯软件方法以及硬件解决方案。纯软件方法可大致分为基于重建的算法和基于学习的算法[30]。基于重建的方法主要依赖于先验知识或数学模型来学习图像退化的逆过程，从而恢复其原始状态。而基于学习的算法则通过稀疏编码、机器学习或深度学习等，学习大量图像退化与复原之间的复杂映射关系，以适应并处理多种未知或不规则的退化模式。

在硬件解决方案领域，Kyrish等人[31]提出了一种基于机械平台的成像方法，通过预设探头与样本之间的相对位移，按照预定采样策略实现图像的对齐与融合，从而生成高分辨率图像。这种方法通过物理手段增加采样点，显著提高了空间分辨率，并已通过分辨率板和生物样本实验验证。然而，该研究未充分考虑临床环境中难以精确控制探头位置的问题，这可能限制了其临床应用中的可行性和普及性。此外，Cheon等人提出了一种基于随机横向位移的图像融合方法[32]，用于光纤束成像中提升图像分辨率和质量。该方法通过精确控制光纤束的横向随机移动来采集多帧图像，并结合快速图像配准与融合技术，以消除像素化伪影，提高信噪比与分辨率。同样的，Vyas等人[33]则利用压电传感器产生探头微位移，通过采集精确微位移信号并应用Delaunay三角插值算法重建高分辨率图像。Chang等人[34]进一步提出了将双轴压电扫描器集成至光纤束末端，通过横向扫描捕获光纤核心间隙信号，突破传统系统分辨率限制，并结合基于特征的图像拼接配准方法提升分辨率和成像质量。Renteria等人[35]提出了采用旋转支架与相位仿射配准算法的系统，在图像质量优化与信噪比增强方面取得显著进展。Jeon等人[36]提出了一种结合定制化微型物镜和光纤束的高分辨率成像系统，并采用光谱编码方法突破光纤束的采样限制。该系统通过直径2.4毫米的微型物镜实施光谱编码，使各光纤核心对应特定波长，无需复杂机械扫描组件，有效解决传统成像中光纤核心间距造成的分辨率限制。尽管这些硬件方案在实验阶段展现出良好性能，但

中国知网 https://www.cnki.net

普遍存在计算复杂度高、伪影鲁棒性差等问题，难以满足临床实际应用需求。

基于重建的图像复原方法，其通过挖掘局部像素间的相关性对中心像素值进行估算与优化，从而实现图像的增强与复原。Zheng等人[37]提出了一种改进型非局部均值pCLE图像重建算法，该算法首先利用中值滤波器对中心像素点进行稳健估计，接着采用双线性插值算法对相邻中心像素实施插值运算，以消除蜂窝状伪影。此外，该算法还融入了改进的非局部均值方法，以进一步提升重建图像的分辨率和清晰度。Han等人[38]开发了一种基于图像先验学习的迭代优化方法，用于消除图像的像素化伪影。该方法采用近似贝叶斯框架和基于最大化后验概率准则，从观测图像中估计出理想的完整图像，有效解耦蜂窝伪影并提升图像质量。Shao等人[39]提出了一种基于光纤束的前向模型框架，该框架通过测量光纤点扩散函数、建立光纤映射关系、计算几何映射矩阵，并采用缩放共轭梯度法计算最大后验估计。同时，该框架还引入拉普拉斯平滑算子构建先验约束，最终实现从低分辨率图像中恢复高分辨率图像。

基于学习的算法通常依赖大量成对的退化与原始清晰图像作为训练数据，以建立退化与复原的映射关系。由于当时压缩感知技术在图像重建领域具有广泛的应用前景，Dumas等人[40]设计了一种基于稀疏重建算法的压缩感知框架，通过在物体和光纤束末端面共轭位置使用空间光调制器施加多个高分辨率掩模，采集各掩模图像后应用并行点扫描超采样压缩感知反演算法，从低分辨率图像中重建单幅高分辨率图像。类似的，Jiang等人[41]提出了一种基于块的压缩感知框架，通过将目标图像划分为多个覆盖光纤纤芯投影区域的小块，并对所有图像块进行独立且同步的压缩采样，由二维探测器记录强度信息，从而实现光纤束成像系统中的高效图像重建。在字典学习方面，Yuan等人构建了基于高/低分辨率图像对训练的耦合字典[42]，实现低分辨率图像高质量重建，有效解决了光纤核心间距引起的像素化伪影问题并提升分辨率。类似的，Liu等人[43]将图像复原建模为反卷积问题，结合总变分正则化先验知识的两步迭代收缩阈值算法[44]逐步去除图像中蜂窝状伪影并提高空间分辨率。为了降低计算复杂度，该团队[45]进一步提出了一种基于快速迭代收缩阈值算法[46]的图像重建模型，通过应用该算法最小化包含L_2范数的数据保真性项和正则化项的目标函数，实现成像分辨率与细节的有效恢复。尽管这些基于压缩感知等手工提取特征的方法在pCLE图像复原中取得了显著进展，但其普遍存在需要人工设置滤波器尺寸/形态、正则化项加权系数等参数的问题，这种对参数调整的高依赖性不仅增加了算法复杂度，也显著限制了这些方法在不同成像条件下的泛化能力。此外，这些方法的计算成本较高使其难以满足

中国知网 https://www.cnki.net

pCLE实时重建需求，从而限制了其在临床应用价值。

随着基于深度学习的方法在自然图像复原领域取得突破性进展[47]，一些基于深度学习的pCLE图像复原方法被提出以突破传统重建复原方法的局限性。这些方法主要侧重于从大量pCLE图像中学习隐含的复原模式，以应对由于设备光学特性和采样过程中引发的噪声干扰及模糊效应，从而提升图像信噪比、增强细节特征与对比度。这类方法使用大规模的数据来训练卷积神经网络（Convolutional Neural Networks，CNN）或其他深度神经网络，自动学习图像之间的复杂映射关系，从而实现更精准的图像复原。相较于上述传统的复原方法，深度学习方法具有更大的优势和潜力，为pCLE图像复原开辟了新范式。Shao等人构建了一种双传感器成像系统[48]，通过并行采集光纤束低分辨率图像和相应的光学显微镜高分辨率真实数据，从而能够在单个设备上同时对光纤束图像和真实数据进行成像，为后续的图像复原过程提供了高质量的参考数据。同时，开发了一个生成对抗图像复原网络，该网络通过对抗学习直接从低分辨率图像中重建出高分辨率、无固定蜂窝状伪影的高质量图像。得益于在单帧pCLE图像复原的成功，Shao等人提出了一种结合运动估计网络和三维卷积神经网络（3D CNN）的多帧pCLE图像重建方法[49]，首先通过运动估计网络最小化光度损失以估计输入光纤束图像序列之间的未知运动，克服传统方法在固定模式噪声干扰下的配准难题。随后，三维卷积神经网络利用对齐后的图像序列，通过空间-时间信息的深度挖掘以恢复图像序列中的高频信号和细节信息，从而实现高分辨率图像重建。该方法充分利用了多帧图像的数据，提高了图像复原的准确性和细节表现，从而生成具有更高质量的图像。然而，上述方法受限于复杂成像条件与pCLE数据的高度不确定性，实际临床应用面临挑战。Ravì等人提出了一种创新的单幅图像超分辨率方法[50]，该方法通过视频配准技术生成用于训练CNN的伪真实数据。该方法首先利用Delaunay线性插值和高斯噪声来模拟低分辨率图像的生成过程，从而产生与真实pCLE成像过程中产生的图像相似的低分辨率图像。这种模拟生成的数据被分别输入到FSRCNN[51]、EDSR[52]和SRGAN[53]以进行超分辨率重建训练。接着，Ravì等人又提出了一种基于物理的循环一致性的对抗无监督pCLE单幅图像超分辨率方法[54]。该方法通过引入物理采集的先验知识来生成真实的低分辨率图像，并采用循环一致性生成对抗网络来解决无法获取配对的低分辨率图像和高分辨率图像的问题。这种方法特别适用于缺少高分辨率训练数据的情况，能够通过对抗训练提高图像质量，同时确保被模拟退化的图像在物理属性上与原始低分辨率图像保持一致性。进一步，该团队提出了一种针对pCLE成像

中国知网 https://www.cnki.net

的无监督单幅图像超分辨率方法[55]，其核心在于采用了基于物理的Voronoise下采样核，并通过无监督方式训练的zero-shot网络来实现图像质量的提升。此方法特别考虑了pCLE成像中的光纤束非均匀采样模式，通过模拟真实的低分辨率图像生成过程，实现了在缺乏高分辨率真实图像的条件下，利用已有的低分辨率图像进行自监督学习和图像质量改进。Xu等人[56]提出了一种基于条件生成对抗网络的方法，通过均匀照明光纤束末端并对其进行归一化，以获取光纤束位置图，并将其与原始pCLE图像一同输入到生成网络中，引导生成网络聚焦于光纤区域及周围结构，同时辅助判别网络评估局部一致性，从而有效分离蜂窝状伪影与真实图像内容。此外，通过采用多尺度损失和感知损失，实现了对pCLE图像的有效重建和消除蜂窝状伪影，但实验仅基于仿真数据且未验证实际信号缺失场景。同样的，Yao等人[57]提出了一种基于元学习的卷积神经网络方法以去除蜂窝伪影和噪声。然而，该方法直接拿原始的pCLE图像作为输入，而临床中获取的图像往往是经过pCLE系统插值重建获得，因此在临床应用中面临挑战。最近，Zhang等人[58]提出了一种无需高分辨率真实图像参与的无监督的单幅图像超分辨率方法，其利用低分辨率图像的内部统计数据和外部跨模态图像先验知识，并引入了锐度感知对比生成对抗网络来进行稳定的通用内核学习，用于有效提升图像的分辨率和质量。虽然这些工作都引入了图像复原的概念来提高pCLE原始数据的空间分辨率或去除蜂窝状伪影以缓解pCLE光纤束成像的物理特性的限制，但未专门设计去除由pCLE图像采集和重建过程产生的噪声。

除了针对pCLE图像进行复原之外，一些研究还致力于eCLE图像和荧光共聚焦显微镜图像的去噪及蜂窝伪影消除。针对eCLE场景下难以获取无噪声真实图像的挑战，Izadi等人提出了一种基于U-Net[59]和白化噪声先验的盲去噪方法[60]，其利用编码器-解码器架构从噪声图像中提取信号和噪声的深层特征，并结合白化噪声先验正则项实现噪声与清晰图像的有效分离。模型通过构建噪声自相关性和平稳性损失函数，促使生成空间分布均匀且相互独立的噪声，同时借助分段常数和总变差正则化增强信号结构的完整性。随后，Izadi等人进一步提出了一种基于非局部贝叶斯框架的盲去噪方法[61]，该方法通过挖掘非局部相似图像块之间的统计关联性，基于贝叶斯深度学习框架构建无噪声图像块的高斯模型先验模型，并利用最大后验估计实现去噪图像块的逼近。这一过程涉及将相似非局部图像块输入DnCNN[62]以学习这些图像块的噪声模型参数，进而结合观测噪声块的统计特性进行贝叶斯推理。值得注意的是，该方法采用自监督学习策略，仅依赖于噪声图像即可完成模型训练，无需干净图像作为监督信号。然而，

中国知网 https://www.cnki.net

上述两种方法均假设eCLE图像噪声服从Poisson-Gaussian分布，与Ravì等人[54]揭示的真实pCLE图像噪声分布特性存在显著差异，导致在pCLE图像去噪任务中性能不佳。

总体而言，基于深度学习的pCLE图像复原方法（包括去噪、超分辨率等）展现出显著潜力，但其成熟度仍面临数据依赖性、噪声分布适配性及临床适用性等多重挑战，需在算法鲁棒性、计算效率与跨模态迁移能力方面持续突破。

1.4.2 共聚焦内窥镜医学图像腺体分割任务研究

共聚焦内窥镜成像技术，通过其在体细胞级别的成像能力，为消化道疾病的实时诊断与动态监测提供了革命性技术手段[18]。基于CLE图像的消化道腺体精准分割，能够对腺体的形态和空间分布进行详细的量化分析，有助于建立腺体结构异常与疾病进展之间的定量关系，为临床早期诊断、个体化治疗、预后评估及后续图像分类人工标注提供了客观依据。在目前的临床实践中，医生主要依据腺体的形态变化与组织密度的差异来判读CLE图像[63]。精确的腺体分割能够显著增强图像中异质性特征的辨识度，这对于良恶性肿瘤的鉴别诊断具有重要临床价值。因此，开发出高效且准确的CLE图像腺体组织分割算法对于辅助医生提升诊断准确性具有至关重要的意义。

现有CLE腺体分割领域的研究大多采用传统的图像处理技术或机器学习方法，包括阈值分割、边缘检测和区域生长等。Couceiro等人[64]提出一种用于检测和分割隐窝的算法，首先通过分析图像对称能量图谱的局部极值来定位隐窝中心，然后使用Canny边缘检测算子[65]提取轮廓并进行椭圆拟合，最后利用支持向量机（Support Vector Machine，SVM）[66]分类器实现分割。Mualla等人[67]提出了一种基于带通滤波器和分水岭算法的声带上皮细胞CLE图像检测方法，该方法通过人工调节带通滤波器参数来捕获细胞的不规则排列结构，并结合无参数分水岭算法实现细胞边界的精确分割，最后通过局部极小值搜索定位细胞中心。Boschetto等人[68]提出一种用于CLE图像绒毛分割的半自动方法，首先采用人工选定种子点结合四叉树分解来初始化绒毛的粗略分割，确保每个种子生成一个独立区域。随后，通过局部梯度强度的形态学优化与边缘精细化技术实现绒毛边界精准校正以获得每个绒毛区域的最终形状。此外，Boschetto等人[69]还开发了一种基于超像素的自动绒毛分割框架，首先采用简单线性迭代聚类算法生成纹理-色彩相似性约束的超像素单元，然后为每个超像素提取包括不同图像属性和纹理信息在内的37种特征，最后利用随机森林对超像素进行分类，并通过精细的后

中国知网 https://www.cnki.net

处理步骤对分割结果进行优化。这些方法虽然在某些情况下能够提供合理的分割结果，但通常依赖于手动调整参数，且在处理高度异质性和受到边界模糊、噪声干扰的复杂背景的CLE图像时效果有限。

近年来，深度学习的进步显著地促进了医学图像分割领域的发展，尤其是在临床决策支持系统中的应用[70]。在CLE腺体分割领域，陈等人[71]提出了一种基于U-Net[59]的自动分割方法，用于处理CLE图像中的结肠隐窝。随后，为了降低对人工标注的依赖，他们[71]进一步提出了一种采用半监督学习策略的方法，利用Pix2Pix[72]生成伪图像及其对应的伪标签，以扩充数据集并缓解数据不足的问题。最近，我们团队提出了一种高效的双分支非对称编码器-解码器网络模型[73]，专用于CLE结肠隐窝和组织病理结肠腺瘤图像的分割。该模型在编码器部分设计一个包含Focus操作和密集深度可分离卷积的双分支特征提取模块，以提取多尺度特征。此外，引入了特征融合引导模块来自适应地整合两个分支的特征，并通过局部多层感知模块去除噪声，以增强边缘细节。在解码器部分，利用密集深度可分离卷积实现了精确的分割。虽然目前基于深度学习的CLE腺体分割研究较少，但是针对组织病理切片腺体分割的深度学习方法[74,75]已取得显著进展，并可为CLE图像分析提供有益的借鉴。近年来引入视觉Transformer结构和提示学习的研究也逐渐被应用于腺体分割任务中，如Trans-UNet[76]、Swin-UNet[77]和S-SAM[78]等，展示出更强的全局建模能力和鲁棒性。这些研究成果不仅推动了病理图像分析的发展，也为CLE腺体分割任务提供了可借鉴的网络设计理念与优化策略。

综上可知，在大规模完善注释数据集可用时，监督式深度学习方法的分割效果明显优于传统方法。然而，针对医学影像领域普遍存在的标注数据匮乏问题，结合迁移学习、半监督学习及无监督学习将成为应对这一挑战的有效途径。同时，目前CLE图像的精确分割仍存在诸多难题，一方面是CLE图像常受噪声和动态伪影的影响以及组织结构对比度低，这些因素都极大地增加了图像处理的难度。另一方面，由于CLE图像的高度异质性，不同患者的图像特征可能存在显著差异，这使得通用模型的开发和应用变得更为复杂。此外，手工标注CLE图像容易受到标注者主观判断的影响，可能导致数据标注的不一致性和质量问题。

中国知网 https://www.cnki.net

1.4.3 共聚焦内窥镜医学图像分类任务研究

CLE图像分类任务可视为通过对采集和重建数据进行高层次语义解析，提取具有临床与生物学价值的特征信息，从而辅助医生做出诊断决策。由于CLE成像技术的特性，临床实践中常产生大量连续的视频帧序列（单个视频可超过1000帧），其中可能混杂无信息/中断帧、脱靶帧（非目标解剖结构）以及来自健康和病理结构的目标帧。这些数据的丰富性和多样性为临床诊断提供了宝贵资源，但同时也带来了若干核心挑战。首先，高帧率意味着需要处理和分析大量数据，这对人力和计算资源提出了很高的要求。其次，无效帧的干扰可能影响有效信息的提取，降低诊断过程的客观性。目前，CLE图像分类研究主要围绕图像识别与内容检索两大方向展开。图像识别主要通过特征提取与学习算法识别有价值帧，并将其归类至预设类别（如正常/异常或特定病理类型），该方向已形成较完整的技术体系。而基于内容的检索方法则致力于从大规模医学影像库中检索与查询条件匹配的图像或视频帧，旨在加速诊断流程并提升疾病识别的精度与效率。

现有研究已针对呼吸、消化道、口腔、胸部及泌尿系统等多部位开展CLE图像识别，辅助医生更准确地识别和分类各种病变。这些研究主要聚焦于通过使用传统的图像处理方法手工提取底层成像结构，并结合机器学习分类器实现预设病理类别的判别。同时，研究者们也广泛采用深度学习方法实现端到端的自动化特征学习与分类，以提高诊断的精度和效率。传统的图像处理方法，包括边缘检测[65]、纹理分析、局部二值模式（Local Binary Patterns，LBP）、尺度不变特征变换（Scale-Invariant Feature Transform，SIFT）[79]、快速鲁棒特征（Oriented-fast and Rotated Brief，ORB）[80]和频域以及稀疏降维技术等，通常被应用于从CLE图像中提取关键特征。这些特征之后被用来训练各种机器学习模型，如K近邻、SVM[66]、决策树和随机森林等，以识别不同的病变类型。同时，基于深度学习的方法，尤其是CNN能够在无需显式特征提取的情况下，直接从原始图像数据中自动学习判别病变的特征。这些模型包括但不限于LeNet[81]、AlexNet[82]和VGG[83]，其通过从大规模图像数据集中学习复杂的模式和层次结构，显著改进了分类任务的性能。

Srivastava等人[84,85]提出了一种用于pCLE图像卵巢癌自动识别的方法，通过一阶统计量、灰度共生矩阵（Gray-level Co-occurrence Matrix，GLCM）以及空间频率建模组织纹理特征，结合前向搜索与主成分分析筛选鉴别性特征，最终采用K近邻与线性

中国知网 https://www.cnki.net

判别分析实现正常与癌变组织分类。Petitjean等人[86]提出了一种基于SVM和递归特征消除的肺部pCLE图像识别框架，通过直方图统计、像素密度、结构形状及纹理特征从图像中提取120维特征集，并应用SVM和递归特征消除算法进行特征选择，以有效分类健康与异常肺组织。同样的，Desir等人[87–91]提出多种方法用于对肺部pCLE图像进行二分类，包括利用SVM结合基于先验知识的特征向量、引入多种纹理描述符增强分类准确性和增强级联分类器以实现实时图像分类，以及采用基于随机子窗口和极度随机树的随机森林算法。Desir等人[87]首先通过结合SVM与先验知识驱动的特征向量，并基于对影像特征的深入分析和理解来分类肺部影像，从而实现了对健康和病理状态的有效识别。随后，为了进一步提升SVM的性能，Desir等人[88]引入了多种纹理描述符，如LBP和GLCM等用于捕捉影像中的复杂纹理信息，以提升对肺部结构细微差异的感知能力。与此同时，他们还提出一种基于增强级联分类器的方法[89]，其采用LBP或GLCM用于捕捉影像中的复杂纹理信息并输入到由多个弱分类器级联组成的增强级联分类器，以改进分类过程的效率。此外，他们还探索了基于随机滑动窗口策略和极度随机树的随机森林的方法[90,91]，其通过在图像中随机选择窗口并采用LBP描述这些窗口，进而利用决策树的集成学习进行分类，以加快分类速度和减少过拟合的风险。Leonovych等人[92]针对在pCLE数据采集中的噪声干扰问题，提出了一种稀疏不规则局部二值模式，通过精确编码光纤束内中心点空间关系实现区分有价值的信息帧和非信息帧。进一步，Koujan等人[93]提出了一种基于LBP、SVM和错误校正输出码的肺部pCLE图像多分类方法。该方法首先对图像进行预处理、利用LBP提取旋转不变的纹理特征、采用错误校正输出码策略构建编码矩阵以将复杂的多类问题转换为多个二分类任务，最终使用SVM对肺部pCLE图像精准分类为正常弹性蛋白、异常弹性蛋白和细胞。Jaremenko等人[94]针对口腔pCLE图像二分类任务，提出了一种基于图像块的纹理特征分析方法。该方法首先将pCLE图像划分为多个小的图像块，并从中提取直方图、同质GLCM和LBP四类主要纹理特征，结合随机森林和SVM实现健康与病变组织的自动判别。Wan等人[95]开发了一个脑肿瘤pCLE图像的实时自动分类方法，该方法结合了SIFT、ORB、快速视网膜关键点和LBP等多种特征提取技术，以及局部性约束线性编码、局部聚合描述符（Vector of Locally Aggregated Descriptor，VLAD）[96]和Fisher Kernel[97]等编码方案，来优化特征描述符与视觉词之间的相关性，以提高对图像特征的判别性。最后，通过径向基函数核SVM完成分类决策。类似的，Kamen等人[98]提出采用SIFT和方向梯度直方图（Histogram of Oriented Gradient，HOG）提取脑组织图像

中国知网 https://www.cnki.net

的局部特征描述符并结合分层K-means对其进行量化。同时，为了提高视频流数据的处理效果，该方法引入了多数投票机制，显著提升视频流分类鲁棒性。此外，pCLE作为最初用于消化道疾病诊断的技术，在该领域已发展出多种基于传统方法的辅助诊断方法。这些方法主要针对pCLE图像进行分析与分类，并利用图像的纹理和结构特征来识别不同病变类型。Zubiolo等人[99]提出递归SVM树方法用于对消化道pCLE视频帧进行多分类。该方法通过递归学习策略构建SVM决策树，以将多分类问题逐步分解成二分类问题，从而实现线性复杂度的视频帧分类。在每个决策树的子节点中构建一个完整的加权无向图来代表当前的分类问题，并利用Stoer-Wagner算法找到最优的类别。最后，在整个树的构建过程中，所有类别被递归地分割，直到它们都能被正确分类。同样的，Boschetto等人[68]提出采用同态滤波、Sobel和Canny算子提取四类特征，并结合线性方法和朴素贝叶斯方法实现消化道pCLE图像的三分类。此外，Pushpak等人[100]提出采用阈值分割方法获取隐窝的形态学特征，并通过SVM对pCLE图像中的结肠息肉完成新生性与非新生性分类。这些方法主要依赖传统手工特征和专家知识实现二分类，多分类研究相对匮乏且识别精度有限，难以满足复杂临床需求。

随着深度学习的发展，以卷积神经网络和Vision Transformer（ViT）[101]为代表的模型在不同部位及各阶段肿瘤的pCLE图像识别中展现出了显著的性能提升。Hong等人[102]首次构建一个用于全自动食管Barrett上皮变化多分类的端到端的CNN架构，该模型受限于数据集规模，网络结构由4层卷积层和2层全连接层组成以防止过拟合。Vo等人[103]提出基于纹理特征与CNN结合的声带pCLE图像二分类方法，该方法采用HoG、GLCM、LBP、局部衍生模式（Local Derivative Pattern，LDP）以及LeNet-5[81]提取图像块特征后，采用Fisher[97]和VLAD[96]对其进行特征编码，并利用随机森林和SVM[66]实现分类决策。Aubreville等人[104]提出采用LeNet-5[81]和Inception-v3[105]分别用于图像块识别与预训练模型微调实现口腔癌检测。同样的，Izadyyazdanabadi等人[106]则采用AlexNet[82]和GoogleNet[107]实现脑部pCLE图像的诊断性与非诊断性分类。进一步，该团队[108]探讨不同微调策略对模型性能的影响，包括通过从头训练、浅层微调和深层微调不同的CNN模型实现脑部pCLE图像诊断性帧识别。同时，该研究还结合模型集成技术以提升模型的鲁棒性和准确性，并引入无监督方法定位图像中的关键组织学特征，从而优化术中图像分析。该研究证实了相对于从头开始完全训练CNN，在有限的医学图像数据库上采用微调预训练网络的浅层或深层策略可获得优于或等同于从头训练的分类性能。与Izadyyazdanabadi等人类似，Gessert等人[109]针对pCLE成像中常见

中国知网 https://www.cnki.net

的医学影像小样本问题，探索了在ImageNet数据集[110]上进行预训练的VGG-16[83]、Inception-v3[105]、DenseNet-121[111]和SE-ResNeXt-50[112]等多种CNN的迁移学习策略。他们采用部分冻结网络层、完全微调网络以及使用预训练网络作为固定特征提取器，有效地利用迁移学习来增强模型对结肠和腹膜pCLE图像的分类性能。此外，为了进一步提升模型的泛化性，该研究还引入了数据增强，如随机图像翻转和亮度对比度调整。Murthy等人[113]提出了一个用于脑肿瘤pCLE图像分类的级联深度置信网络，其采用多阶段学习框架逐步处理分类难度较大的样本，从而有效提高分类精确度。在每个阶段网络首先利用预训练模型筛选出高置信度样本，将其快速分类同时把低置信度的复杂样本推送到下一个阶段。这种逐级深入的方法使得网络能够集中资源处理那些置信度低的图像，避免在简单或明确的样本上浪费计算资源。

部分研究尝试通过引入其他模态的信息或者更高效的策略辅助pCLE图像的分析，以更全面地理解组织的形态和病理状态。Gu等人[114]提出了一种结合生成对抗网络和递归神经网络的迁移递归特征学习框架以实现对pCLE视频进行分类。第一阶段通过结合pCLE和对应组织区域的病理切片图像的生成对抗网络建立跨模态映射关系以提取判别性特征。在第二阶段采用递归神经网络处理变长和不规则形状的pCLE图像拼接，同时应用注意力机制以根据每帧特征嵌入的重要性赋予不同的权重来提高分类的准确性。该团队[115]进一步提出了一种基于随机路由归一化和邻域嵌入的框架用于自动对齐pCLE图像和病理切片图像之间的特征以提升乳腺pCLE图像的二分类性能。通过随机路由归一化进行特定域的归一化，从而对pCLE和病理切片图像的低级和中级特征进行有效对齐。此外，采用邻域嵌入优化嵌入空间中的距离来最大化类间距离和最小化类内距离，以实现跨成像模态的域不变性。鉴于pCLE视频相邻帧存在相关性，Lucas等人[116]提出利用基于ImageNet[110]预训练的Inception-v3[105]、Xception[117]和Inception-ResNet-v2[118]提取pCLE视频帧的关键特征，并将这些特征嵌入组合成序列输入到长短期记忆网络中进行分析，最后通过投票机制实现膀胱肿瘤实时分类。最新研究探索了ViT在pCLE图像分析中的潜力，Cao等人[119]提出了一种结合ResNet-50[120]和ViT-B/16[101]的混合模型用于对喉癌pCLE图像进行多分类。该模型首先利用ResNet-50进行深度特征提取，继而将其传递至ViT-B/16以通过自注意力机制整合解析图像的上下文信息，从而提升喉癌pCLE图像分类的准确性。目前，基于深度学习的pCLE图像消化道多分类研究仍较为有限，特别是自监督学习方法的应用亟待拓展。

CLE图像检索研究主要聚焦于关键帧的高效提取，从而优化临床诊断效率与可解

中国知网 https://www.cnki.net

释性。在特征提取方面，研究早期通过稠密检测器与SIFT[79]的融合[121]定位显著纹理区域并构建视觉词袋模型，后续进一步引入空间共现矩阵[122]和重叠加权视觉词袋策略[123]以建模时空关联并缓解非刚性形变干扰，但其计算复杂度与任务泛化性仍受限于光学配准技术与金标准缺失。针对低层视觉特征与高层临床语义间的"语义鸿沟"问题，André等人[124,125]通过量化二值化临床语义概念与视觉词的关联性，显著增强了检索结果与诊断需求的一致性。在交互式检索优化方面，Watcharapichat等人[126]将Gabor纹理分析与Wasserstein距离[127]结合，通过用户反馈驱动流形学习有效提升结肠疾病诊断的准确性和效率。类似的，Tafresh等人[128]基于运动学稳定性筛选具有诊断价值的子序列，以半自动化方式提升检索可重复性。此外，为了实现对CLE视频的客观评估，André等人[129]开发了一种基于感知相似性的评估工具。该方法首先通过生成用于量化评估CLE视频检索性能的基准事实数据，继而利用相似性距离学习方法优化视频视觉词向量映射，并最小化边缘损失函数调整视频对的权重参数，实验结果表明其与人类感知相似度具有显著相关性且优于传统视觉词袋方法。这些方法共同推动了CLE图像检索技术在临床实践中的应用。

随着深度学习在医学图像分析领域的显著进展，Gu等人[130]提出了一种多模态多视角特征嵌入方法，以提升CLE图像检索的准确性和效率。该方法通过多视角提取并整合了CLE图像及相关组织学图像的多源信息，并利用监督学习增强图像间的语义关联，实现了跨模态特征空间的深度对齐优化。进一步地，该团队还开发了一个基于深度图的多模态特征嵌入框架[131]，利用深度孪生神经网络深入分析CLE图像与组织学图像间的细微相似性和差异。通过图卷积精确建模特征间的拓扑结构，显著提高了乳腺组织的检索性能。

总之，现有研究主要集中在对特定解剖部位的良恶性进行分类，其通常通过传统手工特征提取结合机器学习算法，或者使用监督式深度学习算法来识别正常与异常组织图像。然而，针对消化道肿瘤发展过程的多阶段分类研究仍显不足，更具体地说，基于自监督学习的多阶段自动分类方法亟待探索，因为它可以减少医学图像标注的成本，并有助于更好地理解疾病的发展规律。因此，开发基于自监督学习的消化道肿瘤CLE图像的多阶段全自动分类方法将是未来研究的热点和趋势。

中国知网 https://www.cnki.net

1.5 本文的主要工作

医学影像在数据特征和临床应用方面与通用自然图像存在显著差异，这为人工智能技术高效地赋能医学影像辅助诊断提出了独特挑战。本研究以消化道CLE医学影像为主要研究对象，重点突破人工智能在消化道CLE医学影像辅助诊断中存在的三大关键问题：图像去噪、消化道腺体和隐窝分割及病理特征分类，旨在构建智能的CLE影像辅助诊断方法体系。此外，还以组织病理学图像和电子白光内窥镜图像为辅助研究载体，结合临床需求进行结肠腺体和消化道息肉分割研究。本文的主要研究内容包括：

（1）基于上下文感知动态滤波的图像去噪方法。由于共聚焦内窥镜受到光纤束物理结构的限制，导致在成像过程中不可避免地产生各种形式的噪声。针对这一问题，本研究提出了上下文感知核估计模块和多尺度动态融合模块，以去除CLE图像中存在的乘性噪声和加性白噪声。首先，构建真实噪声统计模型以准确表征CLE图像中的噪声分布，并构建了一个无需干净图像参与的自监督去噪模型。其次，针对CLE图像中噪声分布的不均匀性，设计了上下文感知核估计模块，并提出了轻量级去噪模型CLENet。此外，为了提升去噪效果，设计了一个多尺度动态融合模块，通过特征解耦和重新校准，以提供精确的上下文特征表征。最后，将上述两个模块集成到U型主干网络中，构建了U型结构的U-CLENet高效去噪网络。通过在多个CLE图像去噪数据集上对所提出的方法进行广泛验证，实验结果表明，其在保持较低计算复杂度的同时，取得了与现有方法相当甚至更优的性能，能够为后续CLE图像分析提供高质量的预处理结果。

（2）基于金字塔ViT多尺度混合结构的消化道图像分割方法。针对病变形态多样性和边界模糊等挑战，本研究提出了一个基于金字塔ViT多尺度混合网络PMHNet。该模型通过建立跨阶段特征复用机制，并重新探索先前层的历史信息，实现局部细节与全局语义的高效融合，从而显著提升复杂医学图像的分割效果。具体来说，PMHNet在以金字塔Transformer为主干的U型架构中创新性地集成密集门控连接模块，自多尺度交互融合模块和多尺度注意力解码模块，旨在应对消化道腺体和息肉分割过程中由于病变区域形状不规则和边缘模糊以及对比度较低等问题。这些模块协同工作以从医学图像中提取并融合多尺度上下文信息，同时对特征进行细化，从而实现精确的分割。所提出的方法在多个具有挑战性的医学图像分割任务中进行了广泛验证，实验结果表明其在多个分割任务中的性能与泛化性具有显著的竞争力，可为后续CLE图像分类提

中国知网 https://www.cnki.net

供精准可靠的腺体解剖结构形态学依据以提升分类标注效率并增强模型可解释性。

（3）聚类引导的双对比学习图像分类方法。针对类间方差小和类内方差大及标注数据稀缺等挑战，本研究提出了一种聚类引导的双对比学习框架CTCL，旨在构建更具判别性的特征表征以提升消化道CLE图像的分类性能。突破传统对比学习仅对齐随机增强视图的局限，CTCL通过聚类将更多语义相关且类别一致的样本对齐，以增强类内紧凑性和类间可分性，从而学习更多判别性的表征。此外，基于CLE图像的几何不变性和固有噪声特性，提出将任意角度旋转的CLE图像和不同噪声的CLE图像分别视为同一实例，以增加特征的多样性。最后，通过期望最大化算法对CTCL框架进行迭代优化。实验结果表明，该方法在多个下游任务中展现出卓越的泛化性和鲁棒性。

（4）基于对比学习与词袋模型的多任务学习图像分类方法。为了缓解CTCL缺乏对局部相似区域相关性建模等挑战，本研究提出了一种结合对比学习与词袋模型的多任务学习框架CB-MTL，通过自监督学习深度挖掘未标注的CLE图像的视觉表征，从而实现高效的CLE图像分析。该框架的主任务为对比学习，旨在通过强制对齐同一样本的不同实例，以获取变换不变性的图像表征。同时，辅助任务引入视觉词袋模型，通过捕捉与图像结构和内容相关的局部特征，为每张图像生成视觉词向量，进而引导对比学习任务学习更为鲁棒的视觉表征。通过这种方式，CB-MTL不仅能够进行变换不变的预测，还能有效地捕捉图像的结构和内容相关信息。所提出的方法在多个下游任务中进行了广泛验证，实验结果表明，词袋模型作为辅助任务能够有效地为主任务提供正则化，从而增强模型的泛化性，并显著提升CLE图像分析的性能。值得注意的是，在CNN与ViT主干架构的对比实验，CB-MTL均表现出良好的效果，进一步表明词袋模型任务能够显著改善对比学习的表征且无需依赖额外的标注数据。

1.6 本文的结构安排

本文主要围绕CLE医学图像分析展开，研究思路如图1.3所示。图像去噪作为基础预处理环节，能够显著提升图像质量，抑制成像过程中的噪声干扰，从而有效改善图像的视觉质量与结构可视性，为后续的图像分割与图像分类提供有力支撑。图像分割在此基础上进一步提取出腺体等关键解剖结构，为CLE图像分类任务提供精准的空间定位与形态学依据，提高人工分类标注的效率和增强模型的可解释性。全文的主要章节及内容安排如下：

中国知网 https://www.cnki.net

第一章引言。首先围绕本课题的研究背景和意义，阐释了人工智能辅助诊断的必要性，并详细阐述了共聚焦内窥镜成像技术的基本概念和原理及其国内研究应用进展，然后对传统方法和深度学习在共聚焦内窥镜医学图像去噪、分类和分割任务的国内外研究现状及未来发展趋势进行了系统梳理与深入剖析。最后对本文的主要研究工作和整体的结构安排进行了概要性说明。



图1.3 本文章节结构关系框图

第二章基于上下文感知动态滤波的图像去噪方法。为了应对CLE成像中由光纤束物理结构限制引发的图像质量退化问题，本研究提出了一种自监督的轻量级方法CLENet和一种基于U型结构并结合上下文感知核估计与多尺度动态融合模块的U-CLENet。CLENet和U-CLENet仅需单幅噪声图像及其真实噪声物理统计特性即可实现高效去噪，突破传统去噪方法对配对数据的依赖。具体来说，上下文感知核估计模块

中国知网 https://www.cnki.net

用于应对噪声分布的非均匀性问题和多尺度动态融合模块用于学习不同层次与类型的纹理信息，从而实现对CLE图像真实噪声的精准去除。

第三章基于金字塔ViT多尺度混合结构的消化道图像分割方法。针对消化道不同类型病变的形态异质性显著、病变区域与周围组织在形状和颜色上的高度相似性，导致分割准确性和鲁棒性受限的问题，本研究提出了一种基于金字塔多尺度混合网络的图像分割方法。该方法在编码器阶段引入密集门控连接模块，自多尺度交互融合模和多尺度注意力解码模块。通过与金字塔Transformer的深度融合，以有效提取并融合医学图像的多尺度上下文信息。同时，在解码器阶段引入多尺度注意力解码模块来减小语义差距并细化特征，从而实现更为精确的图像分割。

第四章聚类引导的双对比学习图像分类方法。针对CLE图像数据集中存在的类间方差小和类内方差大的核心挑战，以及从规模有限且无标注数据中学习有效特征空间的难点，本研究提出了一种聚类引导的双对比学习方法。该方法通过构建实例级和簇级双对比学习机制，协同充分利用语义相关且类别一致的样本，以有效增强类内紧凑性和类间可分性。同时，考虑到CLE的固有特性，将任意角度旋转的CLE图像和包括各种噪声的CLE图像分别视为同一实例，从而进一步提升模型的鲁棒性。此外，采用期望最大化算法对整个方法进行优化，以更好地提升分类性能。

第五章基于对比学习与词袋模型的多任务学习图像分类方法。为了应对当前CLE自动分类算法效率低下且未能有效建模局部相似区域相关性的问题，本研究提出了一个多任务学习方法用于CLE图像分类。该方法以对比学习为主任务和以词袋模型为辅助任务相结合，通过自监督学习从无标注数据中学习更稳健的视觉表征。该方法能够适用于以CNN或Transformer为主干的网络结构，在显著提升分类准确率与模型泛化性能的同时，可为CLE图像特征学习提供了一种新的解决方案。

第六章总结与展望。全面总结了本文的主要内容，并对后续的研究方向及其实现路径进行了深入探讨和前瞻性展望。

中国知网 https://www.cnki.net

2 基于上下文感知动态滤波的图像去噪方法

2.1 引言

由于CLE光纤束内部各纤芯及包层的物理透射率存在非均质性，导致成像过程中呈现不规则的准六边形蜂窝状结构特征，致使图像质量与临床视觉判读效果显著下降，从而对诊断准确性造成潜在影响（如图2.1（a）和（b）所示）。现有CLE图像重建算法主要基于德劳内三角剖分方法构建沃罗诺伊图谱，其原理是将单根光纤视为单元节点，通过距离测算实现线性插值完成图像重建。然而，分布于各光纤的噪声在重建过程中会同步生成具有沃罗诺伊图谱特征的干扰模式（“Voronoise”）[54,132]。此外，受采样与传输过程中外部环境因素影响，CLE图像信号还可能引入额外的加性噪声（如加性白高斯噪声，Additive White Gaussian Noise，AWGN）。目前，尚缺乏能够同时去除Voronoise和AWGN的有效方法，这在一定程度上限制了图像的清晰度和锐利度。改善图像质量对于增强计算机辅助诊断系统的准确性和可靠性具有重要价值，可为临床医生提供更精准的疾病诊断技术支持。

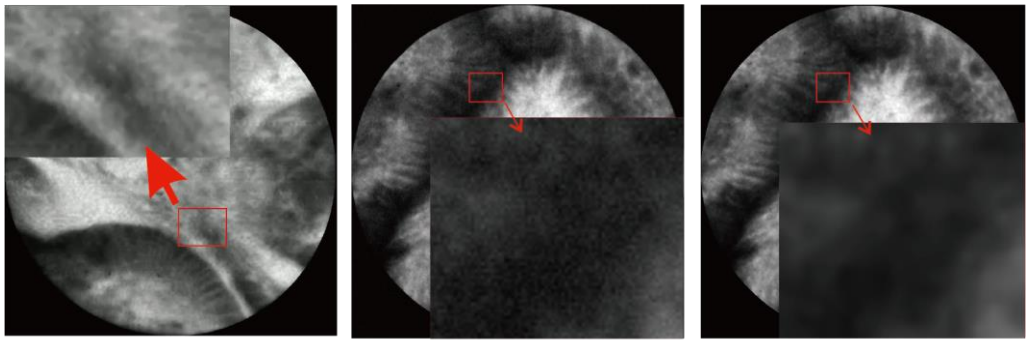


图2.1 CLE图像采集过程中产生的不规则蜂窝状结构及噪声

当前大多数方法[50,54,57,133]通过改善CLE图像的信噪比和对比度来减轻几何噪声伪影及不规则结构，从而优化图像质量。这些方法[50,54]大多属于单幅图像超分辨率，通过学习高分辨率与低分辨率图像对之间的映射关系以优化神经网络权重。然而，由于缺乏高倍率CLE光纤束探头，获取高分辨率图像仍然面临一定挑战。针对此问题，部分无监督单幅图像超分辨率方法[55]尝试在无需真实高分辨率图像作为监督信息的条件下实现CLE图像的超分辨率重建。此外，Butola等人[133]提出结合离散余弦变换与

中国知网 https://www.cnki.net

全变差的去噪方法，以消除CLE图像中固有的蜂窝伪影，进而改善图像质量。类似地，Yao等人[57]开发了基于元学习的CNN模型，旨在高效去除蜂窝状伪影并恢复CLE图像。事实上，由于临床获取的图像数据均需经过CLE系统处理，原始未处理CLE图像的获取仍具挑战性。此外，Izadi等人[60]假设CLE图像噪声服从泊松分布并据此设计去噪方法，而Ravi等人[50,54]指出实际CLE图像噪声统计分布应同时包含Voronoise和AWGN。因此，针对该噪声统计分布设计去噪方法具有必要性。此外，受限于光纤束物理结构的固有限制，通过CLE获取高质量图像仍然具有一定的挑战性。尽管大多数无需真实标签的去噪方法[134–138]主要集中于自然图像，但这些方法可能不适用于CLE图像。近期研究提出了若干针对CLE及显微镜图像的无需真实标签去噪方案[60,61,139]，旨在提升图像质量并实现预期性能。然而，这些方法仍沿用U-Net[59]、DnCNN[62]等通用框架，未能充分考虑CLE成像的固有特性，导致模型参数量较大。

为此，本研究提出了两种新颖的方法：自监督轻量级网络CLENet和基于U型架构集成上下文感知核估计与多尺度动态融合模块的U-CLENet。这些方法仅需单幅噪声图像结合真实噪声统计模型即可实现有效去噪。首先，为了精确建模CLE图像信号中的真实噪声特性，通过融合Voronoise乘性噪声与AWGN建立噪声统计分布模型，并基于真实噪声图像构建"有噪-更有噪"配对数据集。其次，设计了上下文感知核估计模块，该模块通过引入具有可学习区域权重的适度感受野机制，用于有效应对非均匀噪声分布问题。该模块通过像素重排下采样单元与上下文感知核估计单元的协同作用，引导网络聚焦关键特征并增强高频信息重建能力。第三，提出了多尺度动态融合模块，采用可变形卷积和多尺度扩张卷积，通过动态调整感受野形态捕获不同层次和类型的纹理信息，并借助通道与空间注意力机制实现特征图的自适应融合。最后，将上述模块集成于U型主干网络构建U-CLENet。实验结果表明，在相同训练基准下，该网络在两个消化道数据集上的去噪性能与现有方法相当甚至更优，且保持较低的计算复杂度。

CLENet由低频特征重建模块和高频特征上下文感知核估计模块组成。低频特征重建模块通过残差块组进行低频特征提取，高频特征上下文感知核估计模块则通过像素重排下采样与上采样块，以及上下文感知核估计块，旨在重建受Voronoise乘性噪声和AWGN干扰的高频特征。最终，融合两个模块输出的特征实现图像重建。作为轻量级模型，CLENet模型的参数量为0.3 M，在CLE图像去噪任务中不仅显著优于其他最先进的（State-Of-The-Art，SOTA）方法，同时保持较低的计算复杂度。

中国知网 https://www.cnki.net

2.2 核估计与自监督学习图像去噪概述

2.2.1 核估计图像去噪

卷积核估计方法一直是CNN在自然图像去噪领域的重要研究方向，其思路与传统图像处理方法（如BM3D[140]和WNNM[141]）具有内在关联性，通过基于邻域像素加权融合实现噪声抑制的核心思想。为了更好地建模真实噪声，KPN[142]通过逆伽马变换将RGB图像转换为多帧RAW图像，并采用联合高斯分布对快门噪声与读取噪声进行建模，进而通过空间自适应卷积与多帧RAW图像的卷积运算实现去噪。然而，该方法在卷积核尺寸方面存在固有局限性，导致平坦区域去噪效果欠佳。为此，MKPN[143]提出可分离卷积核估计方法，实现像素级动态核尺寸预测。进一步地，AME-KPN[144]引入CBAM模块[145]以细化多尺度特征和保留输入图像中的时空信息来提升模型性能。此外，Xu等人[146]提出将可变形卷积与MKPN结合，以减少图像和视频噪声。最近，Shen等人[147]提出动态卷积和多尺度动态模块，以增强高频和多尺度特征的学习。尽管这些方法在自然图像去噪领域取得了显著成效，但由于CLE图像在成像机理与采集条件方面与自然图像存在本质差异。因此，本章提出了面向CLE图像特性的上下文感知卷积核估计模型，通过学习判别性表征以提升去噪性能。

2.2.2 自监督学习图像去噪

监督式图像去噪的主要挑战在于构建大量的噪声-清晰图像对，这在实际应用中限制了其广泛推广，尤其是在生物医学图像领域。为此，已有研究提出仅利用噪声数据来训练模型。Deep Image Prior（DIP）[148]揭示了神经网络架构自身蕴含的自然图像先验特性，可实现对单幅噪声图像的无需干净图像重建，但其网络结构敏感性与迭代次数依赖性严重阻碍了实际应用。受掩码自编码器思想的启发，Noise2Noise[134]、Noise2Void[149]和Noise2Self[150]提出了通过构建掩膜区域预测任务构建自监督学习框架。进一步地，Noise2Same[136]提出了满足J不变性[134]的新型损失函数，而Self2Self[151]通过伯努利采样策略缓解自监督训练中存在的样本方差问题。另一方面，Neighbor2Neighbor[138]通过对部分样本的相似真实图像进行采样，从而生成噪声对用于自监督训练。然而，上述方法基于噪声零均值独立分布的前提假设，在应对CLE图像混合噪声时去噪性能显著退化。

中国知网 https://www.cnki.net

最近，Noisier2Noise[135]和NAC[137]提出通过向输入图像中注入不同噪声信号来构建训练图像对。然而，Noisier2Noise[135]依赖于先验噪声分布，而NAC主要集中于白噪声高斯分布。此外，Izadi等人提出一种自监督去噪方法[60]，该方法利用编码-解码结构（U-Net），并基于统一噪声先验设计的损失函数，在eCLE图像去噪任务中取得了最先进的性能。进一步地，Izadi等人提出一种非局部图像块贝叶斯均值滤波方法[61]，以最大化无噪声图像块的后验分布。该方法假设荧光共聚焦显微镜图像中的噪声为泊松-高斯噪声。类似地，Khademi等人[139]提出一种用于荧光共聚焦显微镜图像去噪的自监督学习方法，在特定成像场景中展现出应用潜力。然而，荧光共聚焦显微成像和CLE系统在组织结构表征、噪声分布特性及成像机制等方面存在本质差异。本研究所提出的方法用于CLE图像去噪，与其他方法相比具有轻量化的优势，并在性能与模型参数之间提供了最佳的平衡。

2.3 上下文感知动态滤波自监督去噪方法

本研究首先分析CLE数据的真实噪声统计分布特性，并据此构建用于CLE图像去噪方法研究的噪声数据集。接着，系统阐述所提出的上下文感知核估计模块和多尺度动态融合模块。最后，提出一种结合上下文感知核估计模块与多尺度动态融合模块的自监督去噪方法，旨在有效提升CLE图像的去噪重建效果。

2.3.1 真实噪声统计特性

训练一个监督式去噪模型 $f_\theta(\cdot)$ 通常需要大量成对的噪声图像和干净图像 $\{(x_0,y_0),(x_1,y_1),...,(x_N,y_N)\}$，其核心目标是通过最小化损失函数 $\mathcal{L}$，$\sum_{i=1}\mathcal{L}(f_\theta(x_i),y_i)$，从而获取全局最优的模型参数 θ^*：

$$\theta^*=\arg\min_\theta\sum_{i=1}\mathcal{L}(f_\theta(y_i),x_i), \tag{2.1}$$

其中 x_i 表示干净图像（实际临床场景中难以获取），y_i 表示对应的噪声图像。两者的数学关系可表述为 $y=x+n_o$，其中 n_o 通常为具有零均值和标准差 δ_o 的加性噪声，且满足 x 的均值和标准差远大于 n_o，即 $\mathbb{E}[x]\gg\mathbb{E}[n_o]$ 和 $Var[x]\gg Var[n_o]$。然而，受CLE光纤束物理结构的限制，实际应用中通常难以采集获取干净图像 x。进一步，Noisy-As-Clean[137]中提出向真实噪声图像 y 添加模拟噪声 n_s 以生成新的噪声图像 $z=y+n_s$。同

中国知网 https://www.cnki.net

时，假设模拟噪声 n_s 和真实噪声 n_o 在统计分布上高度接近，所以能够获得 $\mathbb{E}[z] \gg \mathbb{E}[n_s]$ 和 $Var[z] \gg Var[n_s]$。因此，通过模型学习建立 y 和 z 之间的映射关系，理论上也与 x 和 y 之间的关系一致，从而有效地消除了 y 中的噪声。虽然该方法在仅存在加性噪声的环境中具有可行性，但由于CLE图像中同时存在乘性噪声和加性噪声，导致基于均匀噪声分布假设的传统去噪方法不可避免地会产生偏差，难以有效应对真实临床场景中的复杂噪声。

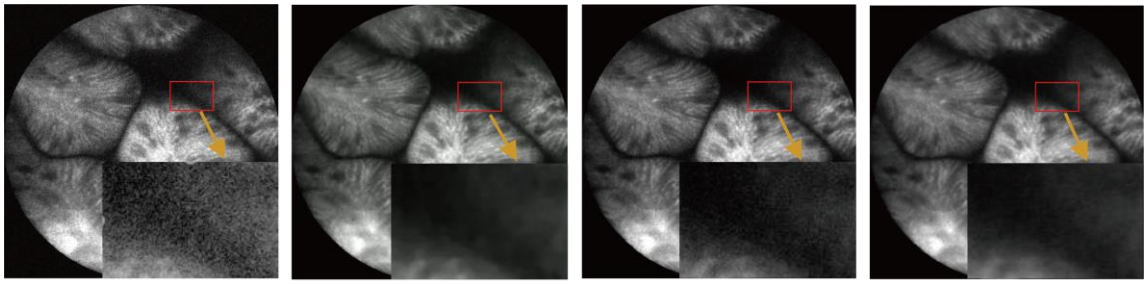


图2.2 NAC-DnCNN与本研究提出的方法在CLE_768数据集中对受Voronoise和AWGN（σ=15）混合噪声干扰图像的重建结果

如图2.2（a）所示，噪声对图像的影响较小，病灶轮廓和部分结构仍然保持可见性，这表明图像信号期望值和标准差远大于噪声。本研究所引入的噪声由零均值的AWGN和Voronoise混合构成，其噪声图像 y 的期望理论上应趋近于干净图像 x 的期望，即 $\mathbb{E}[y]=\mathbb{E}\left[x+n_o\right]=\mathbb{E}\left[x+x\odot n_{ov}+n_{og}\right]=(1+n_{ov})\mathbb{E}[x]+\mathbb{E}\left[n_{og}\right]\approx\mathbb{E}[x]$。由于 n_{og} 作为零均值的AWGN，并且假设 n_{ov} 足够小，那么上述等式成立。此外，噪声图像 y 和干净图像 x 之间的标准差关系为 $Var[y]=Var\left[x+n_o\right]=Var\left[x+x\odot n_{ov}+n_{og}\right]$。同理可得，$\mathbb{E}[z]=\mathbb{E}\left[y+n_s\right]=\mathbb{E}\left[y+y\odot n_{sv}+n_{sg}\right]=\mathbb{E}\left[y\odot(1+n_{sv})+n_{sg}\right]\approx\mathbb{E}[y]$,说明图像退化过程中保留的统计量 z 的期望值亦逼近 y。此外，y 和 z 之间的标准差关系可以表示为 $Var[z]=Var\left[y+n_s\right]=Var\left[y+y\odot n_{sv}+n_{sg}\right]$，$n_s=y\odot n_{sv}+n_{sg}$。由于本研究假设模拟噪声 n_s 的统计分布与 n_o 相似，并将其与噪声图像 y 叠加生成新的噪声图像 z，这意味着只要去噪模型能够学习 y 和 z 之间的非线性映射关系，就能有效地实现对图像 y 进行高效去噪。本研究将在第2.4节对此进行实证验证。

基于该理论框架推导可知，在自监督范式下基于噪声图像对 (z_i, y_i) 训练获得的模型最优参数应与监督范式采用噪声与干净图像对 (y_i, x_i) 训练所得的最优参数在理论上具有等价性。然而，CLE图像中实际存在的空间非均匀噪声分布，导致传统的假设

中国知网 https://www.cnki.net

噪声为均匀分布的去噪方法在应对此类非均匀噪声时存在显著局限性。如图2.2所示，对比了所提出方法与NAC-DnCNN[137]在受到Voronoise和AWGN（$\sigma=15$）共同干扰下的去噪效果。在相同的训练条件下，所提出方法能够有效抑制噪声和重建组织纹理细节，去噪图像质量评估指标显著优于NAC-DnCNN，后者重建的图像中仍然存在明显的噪声。注：为清晰展示去噪效果，各图像右下角均附有红色矩形框标注区域的局部放大图。接下来，将详细介绍所提出的上下文感知核估计模块。

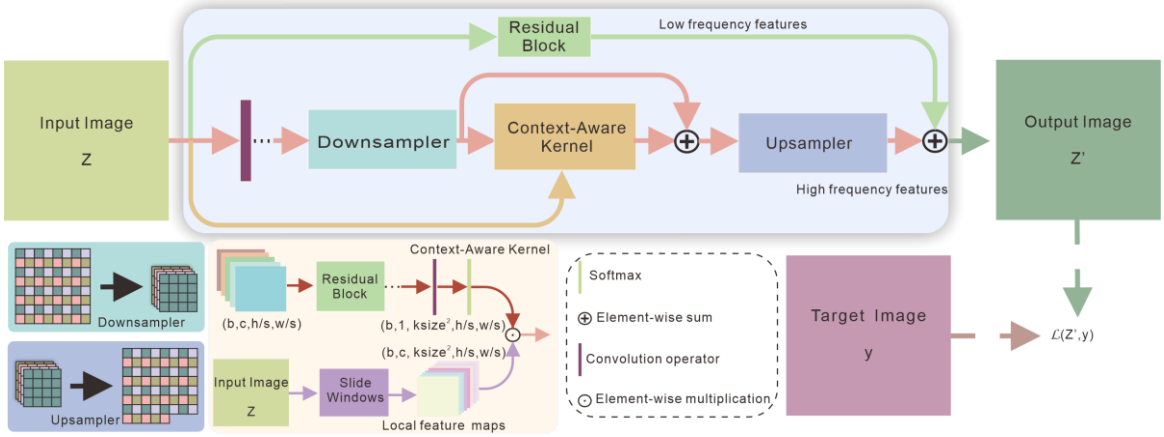


图2.3 基于上下文感知核估计的自监督去噪模型结构图CLENet

2.3.2 上下文感知核估计模块

由于CLE图像噪声特性与自然图像存在本质差异，其非高斯性特征主要源于CLE图像信号的非均匀分布呈现准六边形的不规则蜂窝结构。因此，本研究假设CLE图像中的噪声为由Voronoise与AWGN组成的混合噪声，其中Voronoise用于描述CLE光纤束固有蜂窝结构引起的噪声，而AWGN旨在表征图像采样过程中系统电子电路热噪声等硬件因素产生的随机干扰。这种噪声建模策略考虑了CLE图像特有的结构化噪声特征和传统传感器噪声的统计特性。

本研究提出的上下文感知核估计自监督去噪模型CLENet结构如图2.3所示。该模型由低频特征提取模块和高频特征提取模块构成。模型 $F(\cdot)$ 以模拟噪声图像 z_i 作为输入，通过端到端训练优化网络参数，建立 z 和 y 的非线性映射关系以实现去噪功能，其中输出 $\tilde{z}_i = F(z_i)$ 逼近理论干净图像 y_i。高频特征提取模块包括像素重排下采样运算、上下文感知核估计以及像素重排上采样运算。

（1）像素重排下采样运算。Zhou等人[152]假设真实世界中的噪声主要为空间相关的AWGN，并提出了像素重排下采样（$b,c,s\times w,s\times h \rightarrow b,s\times s\times c,w,h$），旨在打破噪

中国知网 https://www.cnki.net

声的空间相关性。像素重排下采样可视为像素重排上采样的逆过程。像素重排上采样[153]是将原始低分辨率像素划分为s^2个更小的像素，从而增加为s^2个特征图，随后根据一定的排列规则将这些小像素重新组合为与s^2个特征图对应的特征图（$b,s\times s\times c,w,h\rightarrow b,c,s\times w,s\times h$），以增加特征图的空间尺寸。与其他下采样方法相比，像素重排下采样能够更好地保留图像中的原始像素信息，从而提升图像重建的质量，如图2.3所示。在像素重排下采样运算中，本研究采用包含两个卷积层$f_{CNN}(\cdot)$和步长因子为s的像素重排运算PD_s：

$$y_{iPD}=PD_s(f_{CNN}(z_i)), \tag{2.2}$$

在两者之间引入了ReLU[154]。为了更好地保留图像的纹理和细节，本研究根据经验将步长因子设置为$s=2$以实现最佳性能。然而，由于CLE图像包含混合噪声，其中部分噪声信号出现在高频重建细节中，因此通过该运算只能提取较为粗糙的特征。

（2）上下文感知核估计。由于像素重排下采样可能导致输入中的有用高频信息丢失，从而引发重建图像出现混叠伪影。为此，本研究提出了上下文感知核估计方法，旨在细化表征并抑制像素重排下采样运算引入的伪影，从而改善重建图像的细节。具体来说，下采样后的特征y_{iPD}首先通过n个残差块进行处理，并在通道维度上进行*Softmax*运算：

$$y_{isoftmax}=Softmax(f_{res}(y_{iPD})), \tag{2.3}$$

其中$f_{res}(\cdot)$表示n个残差块，每个残差块包括两个卷积层，卷积层之间引入了BN和ReLU。Softmax运算用于归一化每个位置的特征$y_{ires}(k,j)$，$y_{isoftmax}(k,j)=\frac{\exp y_{ires}(k,j)}{\sum_{kszie^2}\exp y_{ires}(k,j)}$。

考虑到像素之间存在稀疏的局部相关性，为了更好地恢复像素重排下采样运算中丢失的高频信息，本研究采用滑动窗口提取局部图像块p，并通过适度尺寸的感受野建模像素之间的邻域关系。进一步地，对$y_{isoftmax}$和p_i进行逐元素相乘，以从输入中重构像素重排下采样运算中丢失的高频信息：

$$y_{ikernel}=y_{isoftmax}\otimes p_i. \tag{2.4}$$

最后，采用残差连接去除高频特征中的噪声：

$$y_{ihigh}=y_{ikernel}+y_{iPD}. \tag{2.5}$$

通过这种方式，该方法能够有效去除高频信息中的噪声和保留纹理细节，并避免产生伪影，从而缓解了像素重排下采样运算的去噪局限性，如图2.3所示。

中国知网 https://www.cnki.net

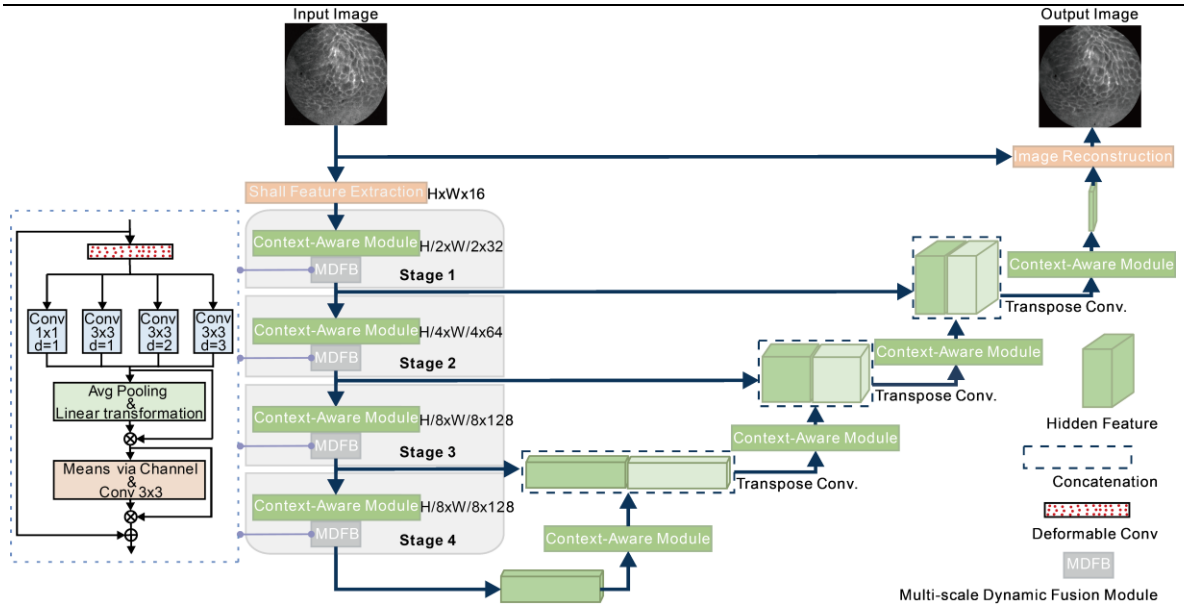


图2.4 U-CLENet模型结构图，由上下文核估计模块和多尺度动态融合模块构成的编码器以及主要由上下文核估计模块构成的解码器组成

（3）图像重建。通过上下文感知核估计优化后，能够获得相对干净的高频信息。此外，为了保持与输入相同的尺寸，采用像素重排上采样进行图像重建：

$$y_{iupsampler} = f_{upsampler}(y_{ihigh}). \tag{2.6}$$

与其他上采样方法相比，像素重排上采样[153]能够保留图像中的原始像素信息，并最大限度地减少引入人工伪影，从而提高重建图像的视觉质量。此外，本研究还应用了由n个残差块组成的低频特征提取模块 $f_{\text{low}}(\cdot)$，以细化低频信号中的特征，

$$y_{ilow} = f_{low}(z_i). \tag{2.7}$$

最后，将高频信号与低频信号融合，从而获取去噪图像 $\tilde{z}_i = y_i^{\text{low}} + y_i^{\text{upsampler}}$ 。

本研究旨在通过自监督学习策略在真实噪声分布场景下训练CLENet模型，为此采用Charbonnier损失[155]来优化CLENet：

$$\mathcal{L}\left(z_i, y_i\right) = \sqrt{\left\|z_i - y_i\right\|^2 + \varepsilon^2} \tag{2.8}$$

其中 y_i 表示“干净”图像， ε 为常数，在所有实验中根据经验设为10^{-3}。不同于广泛使用的 L_2 损失函数，Charbonnier损失函数能够更好地处理异常值，从而提升网络性能。

2.3.3 多尺度动态融合模块

多尺度动态特征的重校准和融合过程包含两个步骤，首先通过动态核生成模块以

中国知网 https://www.cnki.net

生成动态卷积核，然后进行多尺度动态特征的融合，其结构如图2.4所示。具体来说，本研究采用可变形卷积[156]生成动态卷积核，以提供强大的特征表示。可变形卷积允许通过在输入特征图上进行采样和偏移，自适应地调整卷积核中每个位置的采样点以及局部感受野各部分的特征聚合。与传统卷积相比，可变形卷积具有更强的灵活性，能够更有效地引导不同采样点的差异性特征表示。因此，通过采用卷积层 $f_{offset}(\cdot)$ 和σ 实现偏移量计算：

$$\Delta p_i, \Delta w = \sigma\left(f_{offset}\left(y_i \right)\right), \tag{2.9}$$

其中 σ 表示Sigmoid运算， Δp_i 表示卷积核中每个位置采样点的偏移量， Δw 为可学习的调制因子权重。接着，动态卷积核将第 i 个特征图 y_i 作为输入，并结合可学习的偏移量 Δp_i 和权重 Δw 来生成精细化的特征图 $y_i^{'}$：

$$y_i^{'} = f_{dynamic}(y_i, \Delta p_i, \Delta w). \tag{2.10}$$

通过这种方式，动态卷积核能够根据输入特征图自适应地调整偏移量和权重，从而获取细粒度的特征并过滤掉不必要的噪声，避免噪声对后续特征融合过程产生干扰。

整合多尺度动态特征是多尺度动态融合模块的第二步。首先，本研究采用1×1卷积操作并结合不同扩张率 $d=1,2,3$ 的3×3卷积，以提取多尺度特征及其相互关联的特征，从而生成四组新的特征 $y_i^k, k \in 1,2,3,4$。然而，由于这些特征具有不同的感受野，简单的拼接操作可能会导致信息丢失。为了充分利用这些多尺度特征，并探索通道与空间上下文之间的跨维度交互关系，本研究引入了通道注意力和空间注意力机制，以能够自适应地调整特征的通道信息和空间信息。具体来说，首先将特征 $y_i^k, k \in 1,2,3,4$ 在通道维度上进行拼接获得特征 y_i^{concat}，并通过全局平均池化提取特征的通道信息。随后，利用全连接层生成通道注意力图 A_c：

$$A_c = \sigma\left(f_c\left(\frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} y_i^{concat} \right)\right), \tag{2.11}$$

其中 H 和 W 分别表示特征图的高和宽， $f_c(\cdot)$ 和 σ 分别表示全连接层和Sigmoid。通道注意力图 A_c 与特征 y_i^{concat} 相乘，以获得加权后的通道信息：

$$y_i^{concat} = A_c \odot y_i^{concat}. \tag{2.12}$$

接下来，通过空间注意力机制进一步优化特征，使模型能够关注最相关的空间信息。首先在通道维度上进行均值操作以获取特征的空间信息，并通过7×7卷积生成空间注

中国知网 https://www.cnki.net

意力图 A_s：

$$A_s = \sigma\left(f_s\left(\frac{1}{C}\sum_{k=1}^{C} y_i^{concat} \right) \right), \tag{2.13}$$

其中 C 表示特征图的通道数，$f_s(\cdot)$ 为7×7卷积层。空间注意力图 A_s 与特征 y_i^{concat} 相乘，获得加权后的通道和空间信息 y_i：

$$y_i = A_s \otimes y_i^{concat}. \tag{2.14}$$

最终融合后的特征 y_i 用于重建干净图像。在此过程中，本研究采用局部残差以进一步改善信息流动。通过捕捉跨维度的相互依赖关系，所提取的多尺度动态特征能够被解耦和重新校准，以增强模型的判别性表征。

2.3.4 U-CLENet结构

U-CLENet模型采用编码器-解码器架构，其结构如图2.4所示。编码器主要负责提取判别性表征，由上下文核估计模块和多尺度动态融合模块组成。解码器则通过上下文核估计模块实现去噪图像重建。针对CLE图像受到非均匀分布的Voronoise和AWGN的污染，本研究通过上下文感知核估计模块（Context Aware Kernel Estimation Module，CAE）动态估计非平稳卷积核，实现噪声的自适应滤除。同时，多尺度动态融合模块（Multi-scale Dynamic Fusion Module，MDF）进一步对多尺度动态特征进行精细调整，实现多尺度动态特征的深度融合。相较于编码器，解码器通过上下文感知核估计模块实现去噪图像重建，其仅包含可变形卷积、并行的空间通道注意力单元以及无像素重排下采样运算的上下文感知核估计模块。其中，并行的空间通道注意力机制通过3×3分组卷积实现空间注意力建模，结合基于自适应平均池化与3×3卷积的通道注意力单元，两者通过逐元素相加实现特征融合。因此，U-CLENet模型结构可以表示为：

$$\hat{y} = f_{decoder}(f_{encoder}(y)) = f_{decoder}(f_{multi-scale}(f_{context-aware}(y))), \tag{2.15}$$

其中 $f_{encoder}(\cdot)$、$f_{decoder}(\cdot)$、$f_{context-aware}(\cdot)$ 和 $f_{multi-scale}(\cdot)$ 分别表示编码器、解码器、上下文感知核估计模块及多尺度动态融合模块。U-CLENet模型训练设置与CLENet类似，区别在于U-CLENet的学习率为10^{-4}。

中国知网 https://www.cnki.net

2.4 实验分析

基于CLE_768和CLE_512两个不同的消化道疾病CLE图像数据集进行广泛实验，旨在评估所提出的CLENet和U-CLENet的性能。值得注意的是，所提出的方法通过利用包含真实噪声n_o的图像y以生成具有模拟噪声n_s的图像对$\{(z,y)\}$。

2.4.1 实验设置

本研究所有实验均严格遵循Noisy-As-Clean[137]的假设。针对每个数据集分别进行盲去噪和非盲去噪两种实验。为了确保实验对比的公平性，所有方法均在相同的实验环境下重新训练。

（1）数据集。本研究采用CLE_768和CLE_512数据集，这些数据集均由Wang等人[15]设计的共聚焦内窥镜系统采集，其图像采集参数为横向空间分辨率1.4 μm和帧率4帧每秒（fps）。具体来说，CLE_768数据集包含210幅768×768像素的消化道灰度图像以及CLE_512数据集包括63幅512×512像素的消化道灰度图像。

（2）训练设置。针对真实环境图像处理中噪声水平难以确定性，尤其是存在乘性噪声时，噪声与信号的有效分离面临更大挑战，为此本研究通过非盲噪声和盲噪声模式系统评估去噪方法，旨在全面考察不同噪声条件下各方法的适应性。所有实验的目标在于学习如何从z中去除模拟噪声n_s，进而有效地消除图像y中的真实噪声n_o。

（3）测试设置。本研究严格遵循Noisy-As-Clean的测试基准，将含真实噪声n_o的图像y作为模型输入并获取对应的去噪图像$\tilde{y}=f_{\theta^*}(y)$。为了客观评估模型性能，采用结构相似性（Structural Similarity Index，SSIM）和峰值信噪比（Peak Signal-to-Noise Ratio，PSNR）作为评估指标，通过计算干净图像x与去噪图像$\tilde{y}$之间的SSIM和PSNR值来量化去噪效果。此外，本研究还引入了β指标[157]用以评估去噪图像$\tilde{y}$的边缘重建性能，该指标已被广泛应用于其他方法[158,159]的性能评估。较高的SSIM、PSNR和β指标均表明模型具有更优的去噪性能。

（4）实现细节。CLENet是一种轻量级模型，除非另有说明，其残差块数量设置为$n=2$，所有卷积核尺寸均为3×3。每个残差块由卷积层、BN、ReLU及卷积层组成。滑动窗口尺寸和像素重排下采样的步幅因子分别设为$ksize=21$和$s=2$。为了确保对比实验的公平性，本研究在CLE_768和CLE_512数据集上重新实现所有方法。所有模

中国知网 https://www.cnki.net

型参数均采用随机初始化策略，未使用预训练模型。训练过程中采用Adam优化器并将学习率设为10^{-3}。根据NAC-DnCNN[137]的实验设置，所有模型在每个测试图像上训练180个周期。类似于DnCNN[62]和NAC-DnCNN[137]，本研究对每张图像进行0°、90°、180°和270°的旋转以实现数据增强。所有实验均在Nvidia RTX3090 GPU和Intel Xeon W-2235 3.80 GHz CPU的硬件环境下完成，并使用PyTorch[160]实现。

表2.1 不同方法在CLE_768数据集上的去噪结果

噪声水平	f=174, σ=5			f=174, σ=15			参数量
度量指标	PSNR (dB)	SSIM	β	PSNR (dB)	SSIM	β	
BM3D[140]	28.67	0.8343	0.4269	28.43	0.7256	0.2845	-
WNNM[141]	28.68	0.8367	0.4316	28.35	0.7332	0.2984	-
DIP[148]	28.83	0.8931	0.4226	27.99	0.7832	0.2963	2.22
WhiteNNer[60]	38.23	0.9466	0.4586	35.69	0.8354	0.3155	17.26
NAC-DnCNN[137]	35.54	0.8974	0.4038	30.13	0.6266	0.2911	0.56
盲NAC-DnCNN[137]	35.19	0.8951	0.4009	30.17	0.6250	0.2924	0.56
ADF[147]	38.72	0.9413	0.5556	34.84	0.8125	0.3346	9.20
CLENet	36.68	0.9100	0.4301	33.73	0.7952	0.2971	0.33
盲CLENet	35.82	0.9011	0.4135	33.18	0.7783	0.2861	0.33
U-CLENet	39.25	0.9522	0.5676	35.19	0.8254	0.3433	7.14
盲U-CLENet	38.92	0.9506	0.5458	34.98	0.8162	0.3354	7.14
噪声水平	f=174, σ=25			f=174, σ=35			参数量
度量指标	PSNR (dB)	SSIM	β	PSNR (dB)	SSIM	β	
BM3D[140]	27.59	0.6948	0.1874	26.56	0.6752	0.1024	-
WNNM[141]	27.62	0.7030	0.1918	36.73	0.6924	0.1151	-
DIP[148]	27.65	0.7509	0.1925	26.82	0.7476	0.1232	2.22
WhiteNNer[60]	32.86	0.6892	0.1898	29.45	0.5553	0.1226	17.26
NAC-DnCNN[137]	26.74	0.4309	0.1512	24.50	0.3225	0.1036	0.56
盲NAC-DnCNN[137]	26.51	0.4037	0.1537	23.87	0.2720	0.1056	0.56
ADF[147]	31.63	0.6580	0.1952	29.27	0.5300	0.1255	9.20
CLENet	30.98	0.6491	0.1854	28.52	0.5078	0.1189	0.33
盲CLENet	30.58	0.6303	0.1868	28.46	0.5076	0.1242	0.33
U-CLENet	31.85	0.6667	0.1992	29.48	0.5319	0.1281	7.14
盲U-CLENet	31.62	0.6478	0.1997	29.03	0.5063	0.1291	7.14

U-CLENet的架构设计首先通过3×3卷积对输入图像进行初始特征提取。网络主体由四个级联的编码器模块和三个对应的解码器模块构成，其中编码器块负责提取判别

中国知网 https://www.cnki.net

性表征，解码器块用于去噪图像重建。每个编码器块由上下文感知核估计模块、多尺度动态融合模块以及像素重排下采样模块组成，其中像素重排下采样模块通过缩放因子$n=2$对特征图进行下采样。每个解码器块则由可变形卷积和上下文感知核估计模块构成，不包含像素重排下采样模块。编码器与解码器中的残差块数量均设置为$n=2$。滑动窗口尺寸和像素重排下采样的步幅因子分别设为$ksize=21$和$s=2$。最后一个不含像素重排下采样模块的编码器块与第一个解码器块相连接实现特征融合。该网络的训练基准与CLENet保持一致。

2.4.2 非盲去噪

本研究采用乘性Voronoise与AWGN构成的非盲混合噪声模型对CLENet和U-CLENet进行性能评估。由于Voronoise元胞结构对应CLE探头光纤的物理特性，实验设置每行和每列的Voronoise元胞数相同。根据Wang等人的研究[15]，本研究将元胞数设为f=174。为此，在由Voronoise元胞数为f=174和AWGN（标准差）$\sigma\in\{5,15,25,35\}$构成的非盲混合噪声环境下进行相关实验。

（1）对比方法。本研究在CLE_768和CLE_512数据集上将所提出的方法与BM3D[140]、WNNM[141]、WhiteNNer[60]、DIP[148]、NAC-DnCNN[137]及ADF[147]等SOTA去噪方法进行对比。

（2）结果分析。表2.1和表2.2分别报告了各方法在CLE_768和CLE_512数据集上对由Voronoise和不同标准差（$\sigma\in\{5,15,25,35\}$）的AWGN混合噪声的去噪结果。实验结果表明，U-CLENet在所有噪声水平下的PSNR、SSIM和β指标上均展现出较强的竞争力。以CLE_768数据集为例，在噪声标准差$\sigma\in\{5,15,25,35\}$下，U-CLENet相较于ADF[147]的PSNR分别提高了0.53 dB、0.35 dB、0.22 dB和0.21 dB。值得注意的是，虽然参数量高达17.26M的WhiteNNer[60]在PSNR和SSIM方面表现最优，但U-CLENet在β指标上实现了最佳性能。尽管WhiteNNer[60]的参数量是U-CLENet的2.4倍，但两者的性能相当，这充分体现了U-CLENet在参数效率方面的优越性。这些实验结果验证了所提出的模块能够有效集成到U型结构中，从而显著提升模型的去噪性能。此外，CLENet相较于NAC-DnCNN[137]在参数量减少了40%的同时，其性能仍得到显著提升。CLENet在Nvidia RTX3090 GPU上处理分辨率为768×768和512×512的CLE图像分别仅需0.23秒和0.18秒，展现出优异的计算效率与实时处理能力。虽然本方法未在所有噪

中国知网 https://www.cnki.net

声水平中的各项指标中取得最优结果，但其在性能与计算复杂度之间实现了较为合理的权衡。这在实际应用中具有重要意义，因为计算效率与模型复杂度是影响算法实用性的关键因素。此外，考虑到本研究使用的CLE视频帧率为4fps，这表明CLENet能够有效满足本研究中CLE视频帧的实时处理需求。

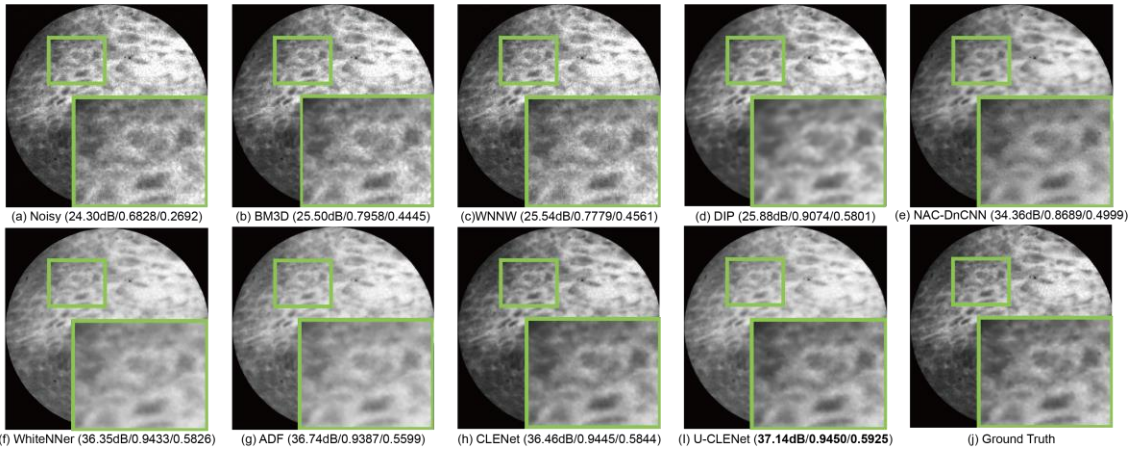


图2.5 不同方法在CLE_512数据集上对由Voronoise和标准差σ=5的AWGN混合而成的噪声的去噪结果可视化

图2.5和图2.6展示了不同方法的去噪结果可视化对比。不同方法的重建图像在视觉特征上表现出显著差异。具体来说，U-CLENet重建的图像中的边缘和纹理细节更加丰富，而WhiteNNer[60]和ADF[147]的结果则存在明显的平滑伪影和模糊现象。U-CLENet重建的去噪图像在视觉保真度方面达到更优水平，其细节恢复方面的优势与定量评估结果形成有力互证，进一步验证了该方法的有效性。

2.4.3 盲去噪

去除未知噪声的一个潜在解决方案是通过学习估计噪声方差，从而去除相应的噪声。然而，当噪声估计存在偏差时，去噪质量将显著劣化。为此，本研究在受到Voronoise和AWGN混合干扰的CLE图像上训练盲CLENet（Blind CLENet）和盲U-CLENet（Blind U-CLENet），其中AWGN的噪声标准差是未知的。训练策略、测试数据集和对比方法与第2.4.2节中的描述一致。此外，考虑到CLE成像系统中光纤束的物理特性（每根光纤独立采集图像信号），本研究建立了基于物理成像机理的先验约束：假设每根光纤独立产生Voronoise，从而消除元胞数f的不确定性（即f作为已知参数参与计算）。

（1）训练盲去噪模型。为了验证CLENet和U-CLENet去除真实噪声的有效性，本

中国知网 https://www.cnki.net

研究在受到Voronoise与一系列未知标准差AWGN混合污染的CLE图像上进行了训练。AWGN噪声的标准差σ采用高斯分布的随机采样策略，其取值范围限定于[0,55]以模拟实际噪声场景。本研究在同一训练集上使用不同标准差的AWGN分别训练CLENet和U-CLENet。此外，当AWGN的标准差超出该范围时，CLE图像将受到严重失真，从而无法提供有价值的信息。值得注意的是，图像中的噪声是由元胞数为f=174的Voronoise与一系列未知标准差σ的AWGN共同构成的混合盲噪声。

表2.2 不同方法在CLE_512数据集上的去噪结果

噪声水平	f=174, σ=5			f=174, σ=15			参数量
度量指标	PSNR (dB)	SSIM	β	PSNR (dB)	SSIM	β	
BM3D[140]	27.95	0.8356	0.7607	27.74	0.7445	0.6846	-
WNNM[141]	27.97	0.8363	0.7623	27.80	0.7474	0.6908	-
DIP[148]	27.38	0.8885	0.7634	27.09	0.8152	0.7166	2.22
WhiteNNer[60]	38.56	0.9631	0.8707	35.69	0.9354	0.7746	17.26
NAC-DnCNN[137]	34.59	0.9012	0.7453	29.78	0.6610	0.5341	0.56
盲NAC-DnCNN[137]	35.01	0.8988	0.7603	30.10	0.6550	0.6741	0.56
ADF[147]	37.52	0.9407	0.8707	33.79	0.8221	0.7746	9.20
CLENet	35.06	0.9139	0.7664	32.85	0.8192	0.7283	0.33
盲CLENet	33.27	0.9102	0.7185	31.59	0.8016	0.6538	0.33
U-CLENet	37.83	0.9502	0.8781	33.98	0.8317	0.7854	7.14
噪声水平	f=174, σ=25			f=174, σ=35			参数量
度量指标	PSNR (dB)	SSIM	β	PSNR (dB)	SSIM	β	
BM3D[140]	26.97	0.7143	0.5818	26.04	0.6966	0.3592	-
WNNM[141]	27.08	0.7158	0.5832	26.25	0.7053	0.3633	-
DIP[148]	26.57	0.7860	0.6038	25.20	0.6697	0.3599	2.22
WhiteNNer[60]	33.86	0.9009	0.5793	31.45	0.8753	0.3721	17.26
NAC-DnCNN[137]	26.42	0.4684	0.3739	24.11	0.3540	0.2463	0.56
盲NAC-DnCNN[137]	26.41	0.4492	0.3739	23.75	0.3204	0.2463	0.56
ADF[147]	30.79	0.6825	0.5733	28.53	0.5597	0.3701	9.20
CLENet	30.02	0.5296	0.5132	27.90	0.5470	0.3324	0.33
盲CLENet	29.55	0.6647	0.4878	27.71	0.5479	0.3253	0.33
U-CLENet	30.87	0.6897	0.5761	28.61	0.5608	0.3726	7.14

（2）结果分析。为了评估所提出的模型，本研究在与非盲去噪模式相同的测试图像上添加由Voronoise和不同标准差（$\sigma \in \{5,15,25,35\}$）AWGN构成的混合噪声。如表2.1和2.2所示，所提出的盲CLENet和U-CLENet模型无需预先估计噪声标准差即可

中国知网 https://www.cnki.net

直接对图像进行去噪。结果表明，盲U-CLENet在PSNR、SSIM及β指标均表现出具有竞争力的性能，展现出其对盲噪声图像的有效性。此外，除AWGN σ=5外，盲CLENet相较于盲NAC-DnCNN[137]展现出显著的性能提升，主要得益于所提出的上下文感知核估计模块对噪声分布的动态建模能力以及多尺度动态融合模块的特征整合机制。图2.6显示了不同方法对图像进行盲去噪的视觉效果，其中盲CLENet和U-CLENet在去噪效果和细节重建方面均表现出更为理想的视觉效果。这些定性与定量结果进一步表明了所提出模型在盲图像去噪中的优越性。

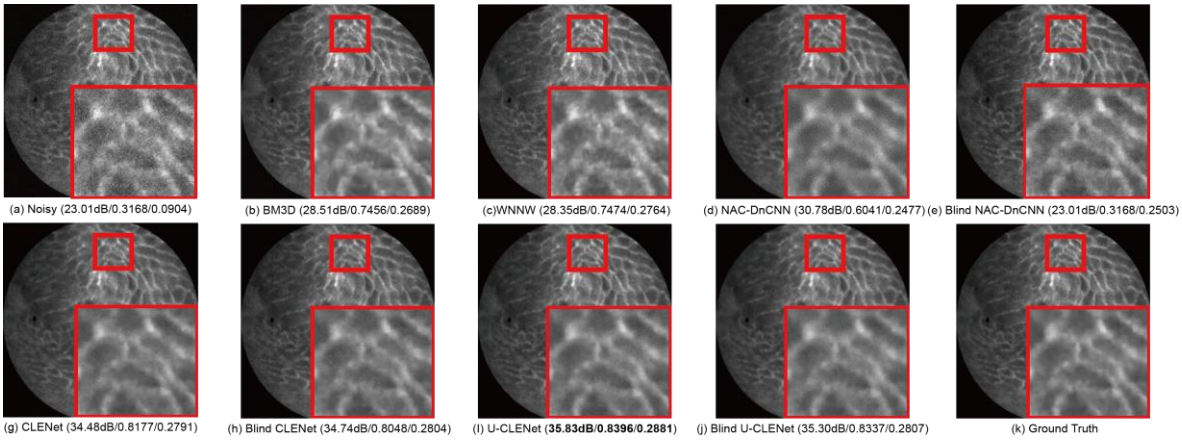


图2.6 不同方法在CLE_768数据集上对由Voronoise和标准差σ=15的AWGN混合污染图像的去噪结果可视化

表2.1和2.2中的结果表明，非盲去噪方法在PSNR、SSIM和 β 指标上的去噪效果优于盲去噪方法。这种性能差异主要源于盲去噪方法在训练阶段中的噪声统计分布特性具有随机性。实验结果验证了本研究提出的假设。尽管噪声成分复杂且包含非线性乘性噪声，所提出的方法仍能实现估计噪声分布与实际噪声分布之间的误差最小化并取得优异的去噪效果。然而，盲去噪过程中噪声分布估计的随机性可能导致去噪性能相较于非盲去噪过程出现轻微下降。该发现证实了准确建模噪声分布的相关性可有效缓解估计偏差。尽管盲去噪方法无法获得噪声水平的先验知识，且噪声分布估计中的固有随机性可能会引入额外变化，从而影响去噪性能。因此，最小化估计噪声分布与实际噪声分布之间的偏差，对于实现最佳去噪效果具有重要意义。

2.4.4 可视化分析

为了评估所提出模型在消化道疾病不同发展阶段的去噪性能，本研究在图2.7中展示了正常胃窦（Normal gastric antrum）、正常胃体（Normal gastric body）、肠上皮

中国知网 https://www.cnki.net

化生（Intestinal metaplasia）、萎缩性胃炎（Atrophic gastritis）、低级别瘤变（Low-grade intraepithelial neoplasia）和高级别瘤变（High-grade intraepithelial neoplasia）的可视化对比结果。例如，在萎缩性胃炎阶段，ADF[147]和U-CLENet重建的图像与真实无噪声图像高度一致，而其他对比方法处理后的图像仍存在显著噪声残留。值得注意的是，这些残留噪声在形态特征上与荧光素钠泄漏表现相似，可能对临床医生的诊断决策造成干扰。实验结果表明，本研究提出的方法能够有效抑制CLE图像中的噪声干扰，显著提升了图像质量，从而为后续的图像分割与图像分类提供更加清晰和可靠的输入数据。

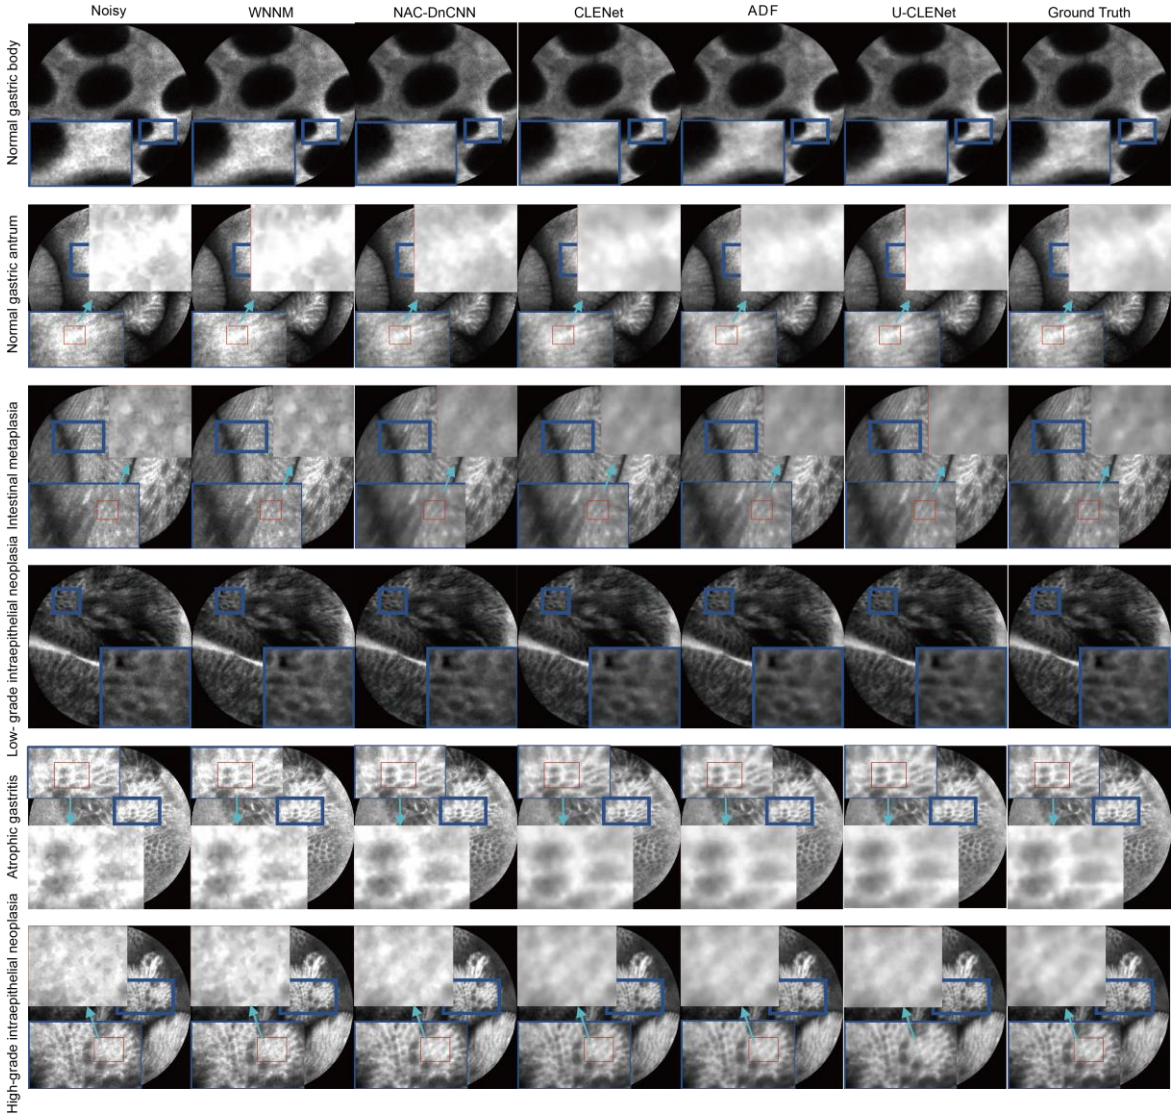


图2.7 不同方法对消化道疾病各发展阶段的CLE图像去噪效果的可视化对比

中国知网 https://www.cnki.net

2.4.5 消融实验

损失函数对模型性能具有重要影响。本文研究了L_2损失和Charbonnier损失[155]对所提出模型在CLE_512数据集上性能的影响。本研究在表2.3中报告了在AWGN σ=15和Voronoise f=174的性能对比。结果表明，采用Charbonnier损失[155]的模型相较于L_2损失实现了显著的性能提升。这可归因于Charbonnier损失[155]能够有效增强CLENet（包括CLENet和盲CLENet）对异常值的处理能力，同时抑制重建图像的过度平滑问题。因此，本研究最终Charbonnier损失作为所提出模型的损失函数。此外，本研究还探讨了上下文感知核估计模块对模型性能的影响。具体来说，将上下文感知核估计模块（记为$\text{CLENet}_{w/o}$）替换为包含5个残差块的模型结构，其参数量和计算复杂度与所提出方法相近。表2.3的实验结果表明，CLENet与$\text{CLENet}_{w/o}$之间存在显著的性能差异，这充分验证了上下文感知核估计模块能够有效应对CLE图像中噪声分布不均的问题。

表2.3 CLENet和盲CLENet中不同损失函数在CLE_512数据集的消融实验结果

损失函数	L_2损失		Charbonnier损失	
度量指标	PSMR (dB)	SSIM	PSMR (dB)	SSIM
$\text{CLENet}_{w/o}$	25.56	0.6324	26.95	0.6383
CLENet	31.68	0.7913	32.85	0.8192
盲CLENet	30.54	0.7724	31.59	0.8016

为了验证U-CLENet中的上下文感知核估计模块（CAE）和多尺度动态融合模块（MDF）的有效性，本研究设计并实施了一系列相关实验。结果如表2.4所示，移除这两个模块会导致PSNR、SSIM和β指标显著下降。具体而言，当同时移除CAE和MDF模块（记为w/o(CAE&MDF)）时，PSNR从37.83降至29.31，SSIM从0.9502降至0.8881，β从0.8781降至0.2613。为了进一步分析各模块的独立作用，本研究分别单独移除这些模块。当仅保留CAE模块时（记为w/(CAE)），模型性能显著提升，PSNR从29.31提升至36.80，SSIM从0.8881提升至0.9394，β从0.2613提升至0.8685。通过分析发现，CAE模块能够精准估计非均匀噪声分布，而MDF模块的引入通过解耦和细化噪声与纹理信息进一步增强模型性能，使PSNR从36.80提升至37.83，SSIM从0.9394提升至0.9502，β从0.8685提升至0.8781。实验结果充分表明，CAE和MDF可视为U-CLENet模型的关键组成部分，具有显著的潜力提升模型性能、改善图像细节和增强特征表示。这些结果为验证各模块的有效性提供了有力支撑。

中国知网 https://www.cnki.net

表2.4 U-CLENet中不同模块在CLE_512数据集的消融实验结果

模型	PSMR (dB)	SSIM	β
w/o(CAE&MDF)	29.31	0.8881	0.2631
w/(CAE)	36.80	0.9394	0.8685
w/(CAE&MDF)	37.83	0.9502	0.8781

2.4.6 讨论

根据表2.1和表2.2的实验结果，本研究提出的方法在有效去除噪声的同时，能够较好地保持CLE图像的边缘纹理。这一优势主要来自于网络架构中设计的自适应感受野机制，其通过动态调整不同纹理区域的去噪强度，实现了在噪声抑制与细节保留之间的良好权衡，为后续的图像分割与图像分类奠定良好基础。值得注意的是，临床实践中CLE检查通常以视频流形式呈现影像数据，这凸显了视频去噪研究的重要临床价值。然而，理论上虽然可将本方法通过逐帧处理方式应用于视频序列，但该方法可能由于缺乏对帧间时序关联性的建模而导致重建视频出现动态纹理模糊或帧间抖动等结构失真问题。因此，开发具备时序建模能力的视频去噪方法是未来研究的重要方向。初步研究表明，通过构建基于相邻帧输入与真实值的平均化训练策略，结合滑动窗口机制实现多帧信息的时序互补，可优化现有方法。此外，本方法还可通过引入时序相关模块进行扩展，利用跨帧注意力机制等构建帧间结构约束提升视频序列一致性，或者引入轻量化光流估计方法来捕捉亚像素级运动特征。在损失函数设计中，可以融合时序一致性约束项（如基于光流轨迹的循环一致性约束）来实现时空联合优化。然而，开发既能高效去除噪声又可保持CLE视频边缘纹理的去噪方法仍面临显著挑战，需要在模型复杂度与时序建模能力间建立动态平衡，同时还需在优化大规模数据集训练GPU内存占用过高和数据存储空间不足的问题。

2.5 本章小结

获取干净清晰的高质量CLE图像对于临床诊疗具有重要的应用价值。本研究设计了一个上下文感知核估计模块，该模块通过采用类似于可学习区域权重的适度感受野，有效应对了噪声非均匀分布的问题。此外，本研究还提出了一个多尺度动态融合模块，该模块通过特征解耦与细化，在扩大感受野的同时显著抑制了边缘模糊与细节丢失。最后，将这些模块集成到U型架构中，构建了用于CLE图像去噪的U型结构高效网络

中国知网 https://www.cnki.net

U-CLENet。实验结果表明，所提出的CLENet和U-CLENet不仅能有效去除噪声干扰，同时还能保留CLE图像中关键的边缘纹理，为后续CLE图像分析提供高质量的预处理结果。未来的研究将探讨该方法扩展至CLE视频去噪，以适应CLE基于视频流的信号采集特性。

本章工作创新点如下：

（1）本研究设计了一个上下文感知核估计模块，采用类似于可学习区域权重的适度感受野，旨在应对CLE图像中噪声分布不均的问题，并提出了一种轻量级的去噪模型CLENet。

（2）本研究开发了一种多尺度特征融合模块，通过结合可变形卷积以及多尺度通道和空间运算，对特征进行解耦与细化，从而扩展感受野并有效减少边缘特征退化。

（3）将上述两个模块引入U型架构中并提出了U-CLENet，所提出的方法在两个消化道CLE图像数据集上取得了具有竞争力的性能，并在性能与计算复杂度之间保持了良好的平衡，为后续CLE图像分析提供高质量的预处理结果。

（4）针对CLE图像中难以获得配对的噪声与清晰图像的问题，本研究提出了一种自监督学习策略，并构建了由Voronoise和AWGN组成的噪声统计分布，以模拟真实的CLE噪声环境，从而学习获得适合CLE图像的去噪模型。

中国知网 https://www.cnki.net

3 基于金字塔ViT多尺度混合结构的消化道图像分割方法

3.1 引言

胃癌、结直肠癌及食管癌作为消化道系统的三大恶性肿瘤，其高致死率与低早期诊断率严重威胁人民群众的生命健康。以结直肠癌为例，其发病数和死亡数在全球每年约有100万例[161]。消化道肿瘤患者在发病早期进行干预治疗的存活率高达90%，但随着病情的进展，存活率显著下降[162]。因此，早期发现和干预治疗对于改善患者预后具有决定性意义。目前，电子白光内窥镜和共聚焦内窥镜已成为消化道直观检查的常用手段，后者可提供与组织病理检查相媲美的实时在体显微成像[18]。然而，上述检测技术的诊断效能高度依赖操作者的临床经验，存在较高的漏诊与误诊风险[163]。为此，发展精准高效的医学影像分割技术不仅有助于客观量化病灶的形态学特征与空间分布规律，还能为临床诊断和后续图像分类标注提供可靠依据，同时在手术导航和疾病进展监测方面具有潜在的应用价值。

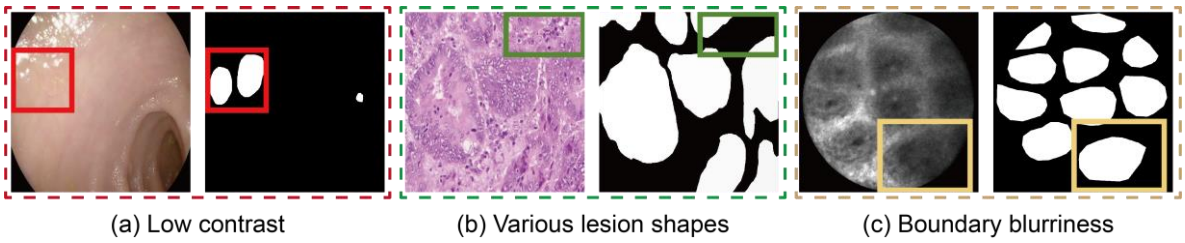


图3.1 消化道息肉和腺体分割所面临的挑战。（a）、（b）和（c）三种模态病变类型存在显著差异，（a）低对比度、（b）病变形态的多样性及（c）边缘的模糊性等问题

得益于计算机视觉和人工智能的快速发展，消化道腺体及息肉分割方法[73,164–169]已取得显著进展。然而，相较于常规自然场景分割任务，该领域仍面临独特挑战，如图3.1所示。首先，消化道腺体及息肉在颜色和纹理特征上与周围组织高度相似，导致其边缘模糊且精确定位困难。其次，目标区域在形状与尺寸上存在显著差异，致使模型难以生成稳定且准确的分割结果。最后，单张图像通常包含多个病灶目标，且目标与背景的尺度失衡，导致传统U型网络在多次下采样过程中易出现微小病灶拓扑结构信息严重丢失问题。针对共聚焦内窥镜和病理切片中的腺体和电子白光内窥镜中的息肉分割难题，研究人员提出了多种方法，其可分为传统图像处理方法[170,171]和深度学习方法[73,76,164–169,172]。相较于前者，后者无需手工提取特征即可实现复杂场景下腺体

中国知网 https://www.cnki.net

分割的端到端自动化处理，有力推动了该领域发展。当前主流方法大多基于CNN、Transformer或其混合架构，通过局部特征提取或全局依赖建模来实现全局关系捕捉与局部纹理识别。然而，现有方法在局部细节特征和全局语义信息的融合方面仍面临挑战，且存在感知区域适应性不足的问题，导致在解码过程的各阶段难以自适应地获取不同尺寸病灶的最佳表征，从而产生了次优的分割结果。

本研究提出了一种基于金字塔多尺度混合网络架构的医学图像分割方法PMHNet，旨在有效应对腺体和息肉分割任务中存在的病变形态异质性显著、病灶边缘模糊以及图像对比度低等挑战。该网络在以金字塔Transformer[173]为主干的U型架构中创新性地集成了三个关键模块，鼓励各阶段之间特征的重用和重新探索先前层的历史信息，融合局部细节与全局上下文特征，从而实现多尺度语义信息的协同优化。这三个模块分别为密集门控连接模块，自多尺度交互融合模块和多尺度注意力解码模块，用于提取和聚合不同类型医学图像的多尺度上下文信息。DGC通过级联局部语义特征信息并采用门控注意力，引导网络关注不同层次的特征信息，减少浅层特征噪声的干扰，增强语义特征表达能力。SMSF利用多尺度Transformer单元实现局部细节特征与全局上下文特征的跨尺度交互，通过将DGC的局部特征和金字塔Transformer的全局特征图分割成不同的尺寸和维度，生成并整合局部、全局及其混合注意力图，从而使网络更有效地聚焦于目标区域，增强语义特征的判别性，并减少因边缘低对比度带来的影响。DGC与SMSF的协同作用有助于模型更准确地定位不同尺寸病灶的边缘，缓解了因病灶形态多样导致的特征提取偏差问题。此外，MAD模块在解码阶段通过级联多尺度卷积捕获不同维度的语义特征信息，减小语义差距，并结合空间和通道注意力细化特征，有效缩小了不同层级间的语义鸿沟。所提出的方法在四个具有挑战性的医学图像分割任务中进行验证，包括基于私人数据集的共聚焦内窥镜图像中的人体消化道腺体分割、动物结肠隐窝分割和基于公共基准数据集的病理切片图像中的腺体分割以及结肠镜图像中的息肉分割。

3.2 U型医学图像分割与视觉Transformer概述

3.2.1 U型医学图像分割

医学图像分割旨在从医学图像中精确识别并划分不同器官、组织或病变区域，为临床诊疗提供可靠的定量分析依据[70]。在CNN中通常通过级联多个卷积层和上下采

中国知网 https://www.cnki.net

样层以完成特征提取和重建，其中深层阶段通过更大的感受野捕获全局上下文信息，而浅层阶段则保留高空间分辨率的局部细节特征。基于此，Long等人[174]首次将全卷积网络（Fully Convolutional Networks，FCN）引入医学图像分割，构建了基于编码-解码器框架的端到端分割架构。尽管FCN在医学图像分割中取得了一定成效，但在处理不同尺度特征和捕捉细节信息方面仍存在局限性。针对这一不足，Ronneberger等人[59]提出了U-Net结构，通过引入跳跃连接并设计对称的编码-解码器结构，将高分辨率特征直接传递到解码器的相应层，从而在重建过程中更好地恢复细节信息。该方法在多种医学影像模态的分割任务中均取得了良好效果。为了进一步提升分割精度，研究人员从多个维度对传统编码-解码器架构进行改进，包括利用注意力机制增强对关键特征的捕捉[169,175]，设计多分支并行架构以获取多样化的特征信息[73]，引入多尺度特征融合以更有效地处理不同尺寸的病变区域[168]，以及融合CNN与Transformer优势[76,164,176–178]的混合结构，以提升分割性能。尽管各种医学图像分割方法不断发展，但在复杂病变形态的精准分割方面仍面临形态差异显著、边界模糊等关键挑战。

3.2.2 视觉Transformer

视觉Transformer[101]凭借其卓越的表征能力和高效的计算性能，在计算机视觉领域引起了广泛关注，已在图像分类[101]、目标检测[179]和语义分割[173]等任务中展现出具有竞争力的性能。在医学图像分割领域，Cao等人[77]首次提出了一种纯基于Transformer的U型架构，通过采用Swin Transformer[179]替代传统U-Net[59]中的卷积块，从而有效提升分割效果。Wang等人提出了Pyramid Vision Transformer[173]，通过将金字塔结构融合到ViT中，以捕获多尺度上下文信息，进一步提升图像分类、目标检测和图像分割等任务的性能。与此同时，一些研究开始探索CNN与Transformer的融合，以同时发挥二者的优势来提升医学图像分割性能。Chen等人[76]提出将CNN和Transformer相结合的混合架构用于不同模态的医学图像分割任务并取得了可竞争的结果。Zhang等人[176]设计了一种融合CNN和Transformer的并行双分支U型网络，进一步验证了该混合策略在医学图像分割任务中的有效性。为了解决U-Net中编码器与解码器之间的信息不匹配问题，Wang等人[164]尝试引入通道交互融合Transformer，以探索多尺度的全局上下文，从而实现对腺体图像的精确分割。Yang等人[177]提出了一种结合CNN和Transformer的多尺度融合网络，通过建模局部和全局语义关系，缓解了手

中国知网 https://www.cnki.net

术器械分割领域的挑战。相较于混合单分支架构[164]或者混合并行双分支架构[76,176–178]，所提出的方法通过融合局部与全局多尺度处理优势，能够灵活地提取和聚合更多的语义信息，更全面地捕捉图像细节和整体特征，从而帮助模型更好地定位不同尺寸的病灶边缘，以应对复杂病变形态难以精确分割的问题。

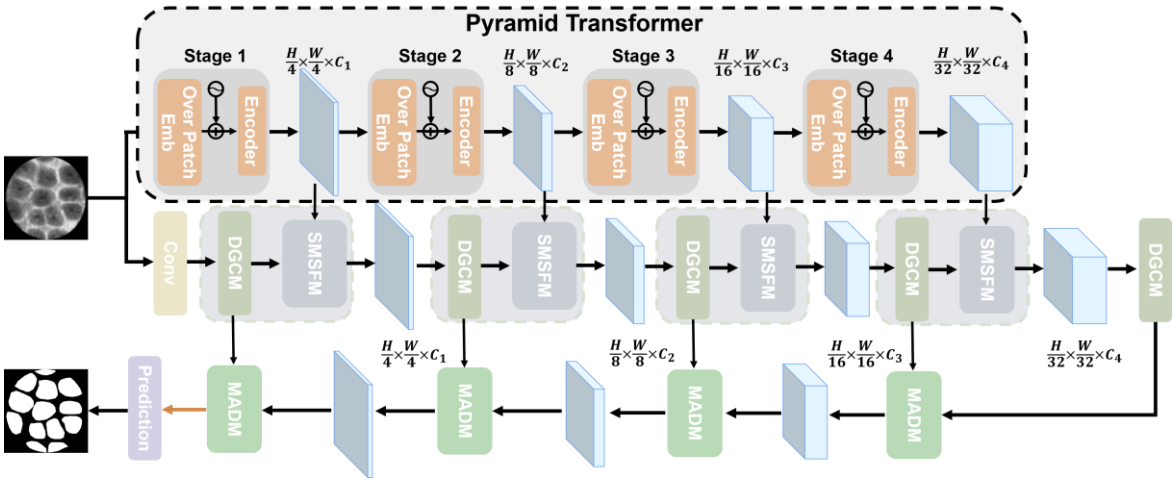


图3.2 PMHNet的整体结构图，该网络由两个并行的编码器和一个解码器构成。编码器部分包括金字塔Transformer、DGC以及SMSF模块，解码器部分则由MAD模块组成

3.3 金字塔ViT多尺度混合网络

本节将系统阐述金字塔ViT多尺度混合网络PMHNet网络架构的核心设计原理与实现机制，其整体结构如图3.2所示。该网络采用双编码器并行驱动的U型架构，由两个协同工作的编码器与一个多尺度注意力解码器构成。首先，介绍编码器中使用的金字塔Transformer。随后，深入探讨网络的各个模块，着重阐述密集门控连接模块如何有效融合多尺度密集特征信息，自多尺度交互融合模块如何聚合局部与全局特征，以及多尺度注意力解码模块如何对特征进行解码和细化以实现精确的分割。最后，介绍用于训练PMHNet的损失函数和优化策略。

3.3.1 金字塔Transformer

标准的视觉Transformer结构[101]首先将输入图像均匀划分为一系列非重叠的图像块，随后通过线性变换将这些图像块映射到固定维度的一维向量空间，形成一系列的token向量。接着，将位置编码添加到这些token向量中，以保留输入图像的空间位置信息。这些具有位置编码的token向量随后输入到多层Transformer模块中，每个模块包

中国知网 https://www.cnki.net

含多头自注意力[180]和前馈神经网络。其中，多头自注意力机制使模型能够捕捉输入图像的全局上下文信息，而前馈神经网络通过非线性变换增强模型的特征表达能力。此外，每个子层（自注意力层与前馈网络）前后分别引入LayerNorm和残差连接，以稳定训练过程。

由于标准视觉Transformer因特征图分辨率固定且较低，难以满足密集预测任务对高分辨率特征的需求，导致计算复杂度显著提高。为此，将金字塔结构引入到视觉Transformer，通过逐层递减序列长度有效降低计算成本，如图3.2所示。类似于CNN的主干网络，该结构采用逐步缩小的策略生成四个具有不同尺度的特征图，每个阶段的架构均包含图像块嵌入层和若干Transformer编码器层。然而，相较于CNN通过多种卷积算子获取多尺度特征，金字塔Transformer[173]通过使用不同尺寸的图像块来控制特征图的分辨率。具体来说，第 i 阶段的图像块尺寸为 $P_i \times P_i$，该阶段的输入特征图尺寸为 $H_i \times W_i \times C_i$ 被均匀划分为 $\frac{H_i \times W_i}{P_i \times P_i}$ 个图像块，其中 H_i、W_i 和 C_i 分别为输入特征图的高度、宽度和通道数。通过线性变换将输入特征图映射至 $\frac{H_i \times W_i}{P_i \times P_i} \times D_i$ 维向量空间，其中 D_i 为图像块向量的维度，实现特征图尺寸的灵活调整以构建金字塔结构。此外，每个Transformer编码器层通常包括多头注意力层和前馈层。然而，为了高效处理密集预测任务所需的高分辨率特征图，金字塔Transformer中引入空间缩减注意力（Spatial Reduction Attention，SRA）替代标准多头自注意力（Multi-Head Self-Attention，MHA），从而降低计算成本。SRA具有与MHA相似的结构，但其键和值的投影维度被缩减至 $\frac{H_i \times W_i \times D_i}{P_i^2 \times R^2}$，其中$R$为缩减比例。因此，SRA的计算复杂度和内存消耗被分别降至MHA的 $\frac{1}{R^2}$，从而显著提升了高分辨率特征图的处理效率。最后，将Transformer编码器的输出特征图转换为 $H_i \times W_i \times C_i$，其中 C_i 为第 i 阶段输出特征图的通道数。

3.3.2 密集门控连接模块

在医学图像分割任务中，模型需精准聚焦目标区域并有效抑制浅层特征噪声干扰，这对实现精确分割至关重要。然而，由于病灶形态学多样性（如尺寸差异、对比度变异等）导致小尺度或低信噪比病灶定位面临挑战，其主要源于编码器连续下采样引发特征图分辨率降低和细节信息丢失，使得深层特征中的边缘信息可能仅保留数个像素甚至完全消失，以及浅层特征携带的噪声与冗余背景信息随层级传导造成特征退化，

中国知网 https://www.cnki.net

从而影响分割的准确性。对此，当前主流解决方法包括输入更大尺寸图像或者通过残差连接直接融合浅深层特征。然而，前者显著增加计算与内存开销，后者则可能因深层语义信息与浅层背景特征直接叠加而引发特征混淆，导致特征表达不够精确。因此，本研究提出DGC模块，旨在有效滤除噪声的同时保留更多相关信息，如图3.3所示。

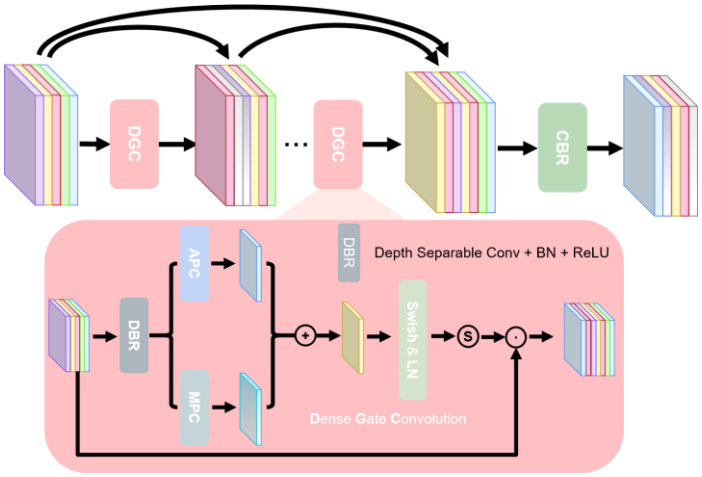


图3.3 DGC模块的结构图

在PMHNet的每个编码器中均引入DGC模块，用于提取和融合局部语义特征信息。该模块通过逐步融合多个卷积层的特征图，引导网络建立跨层级的特征感知机制。同时，采用门控注意力融合机制增强噪声区域与正常区域之间的特征差异性，有效减少特征融合过程中背景和噪声的干扰。具体来说，对于DGC模块中的第 i 层，首先接收 i -1层的特征图并进行通道维度拼接：

$$X_i = \text{Concat}(X_0, X_1, \cdots, X_{i-1}), \tag{3.1}$$

其中 X_i 表示DGC模块中第 i 层的特征图，Concat(·) 表示拼接操作。此设计实现了层间特征复用和历史信息挖掘，从而增强表征的丰富性和判别性。随后，将拼接后的特征图 X_i 输入到包含BN和ReLU的深度可分离卷积模块中，以提取局部语义特征信息：

$$X_i^{'} = F_\theta^d(X_i), \tag{3.2}$$

$F_\theta^d(\cdot)$ 和 $X_i^{'}$ 分别表示深度可分离卷积和相应的输出特征图。采用深度可分离卷积旨在降低计算成本和内存消耗，同时提升对高分辨率特征图的处理效率。接着，利用门控注意力对 $X_i^{'}$ 进行处理，以增强重要特征和抑制无关特征。门控注意力通过并行的全局最大池化和全局平均池化双路径，分别提取特征图的全局最大和平均特征。这些特征分别采用1×1卷积进行特征变换后相加：

$$X_i^a = F_\theta^g(X_i^{'}) + F_\theta^m(X_i^{'}), \tag{3.3}$$

中国知网 https://www.cnki.net

$F_\theta^g(\cdot)$ 和 $F_\theta^m(\cdot)$ 分别表示全局最大池化与1×1卷积以及全局平均池化与1×1卷积的组合操作。然后，使用Swish和BN对融合后的特征进行非线性变换。最终，通过1×1卷积和Sigmoid生成注意力权重图，并与 $X_i^{'}$ 进行逐元素相乘以增强多尺度特征间的相关性：

$$X_i^{''} = X_i + \text{Sigmod}(F_\theta^1(X_i^a)) \otimes X_i^{'}, \tag{3.4}$$

通过这种方式能够有效约束无关特征表示并抑制噪声干扰。通过多尺度特征融合和门控注意力，使得网络增强对目标区域的识别和定位，从而提升对相对较小或对比度较低的病变区域的准确分割效果。此外，DGC模块最后采用步长为2的卷积以降低特征图的空间分辨率。PMHNet中共包含五个DGC模块，每个模块分别由4、6、8、8和4个密集卷积层组成。这种设计通过逐步调整卷积层的数量，确保网络能够有效地提取并整合不同层次的特征，从而提升对低对比度且小尺寸病变的分割精度。

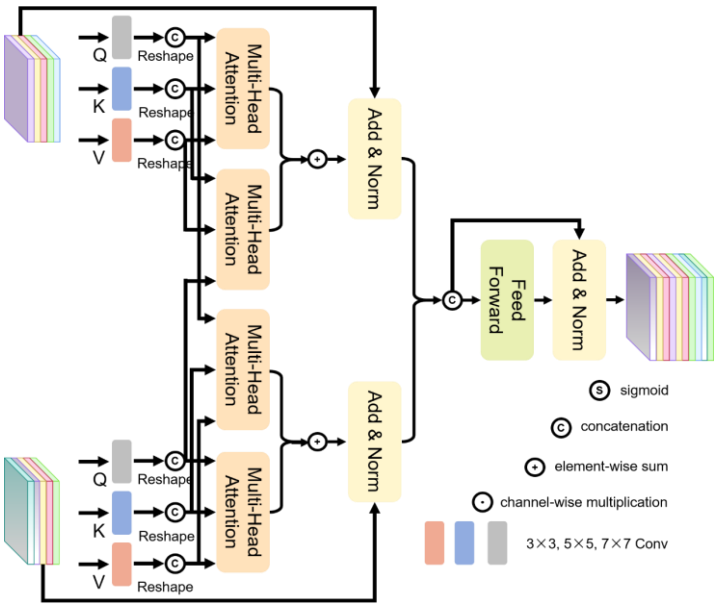


图3.4 SMSF模块的结构图

3.3.3 自多尺度交互融合模块

在医学图像分割任务中，模型需准确识别与分割病灶区域。然而，不同成像模态下病灶类型的显著差异性、病灶与周围组织的低对比度特性，导致模型难以实现目标区域的精确定位。此外，病灶尺寸和形态学特征的高度异质性进一步加剧了精确分割的难度。针对上述问题，现有研究[73,165,168,178]普遍采用多尺度特征融合策略，通过构建并行双分支结构或集成多尺度特征融合网络架构加以应对。这些方法通常基于特征拼接或逐元素相加实现分支特征融合，并借助注意力机制完成特征权重分配优化。然

中国知网 https://www.cnki.net

而，现有融合方式存在分支间特征交互不足的局限性，难以有效挖掘多尺度特征间的潜在关联特性，致使融合效果受限。为此，本研究提出SMSF模块，旨在高效聚合局部细节特征与全局语义信息，增强特征表征的判别性并优化目标区域的表示，其具体结构如图3.4所示。

PMHNet编码器中总共引入四个SMSF模块，用于融合DGC提取的局部细节特征与金字塔Transformer提取的全局语义特征。该模块采用并行结构设计，包含两组多头自注意力单元和两组多头交叉注意力（Multi-Head Cross-Attention，MHCA）单元，以实现特征的有效融合。具体来说，MHA单元通过自注意力机制分别增强局部特征分支与全局特征分支的内部表征能力，而MHCA单元则构建跨分支注意力机制，促进网络跨分支之间的交互，实现局部特征与全局特征的有效融合。这种双路径协同工作机制不仅保持了特征空间独立性的同时，通过动态注意力权重实现判别性特征的学习。SMSF模块的第 i 层接收来自DGC模块的特征图 X_i 和金字塔Transformer的特征图 Y_i，并采用不同尺寸的卷积核将 X_i 和 Y_i 分别转换为不同的特征向量 Q_i^s、K_i^s、V_i^s、Q_i^c、K_i^c 和 V_i^c：

$$\begin{aligned} Q_i^{xl} &= F_{\theta_{lx}}^{q}(Z), \\ K_i^{xl} &= F_{\theta_{lx}}^{k}(Z), \quad x \in \{s,c\}, Z \in \{X_i, Y_i\} \\ V_i^{xl} &= F_{\theta_{lx}}^{v}(Z), \end{aligned} \tag{3.5}$$

其中 $F_{\theta_{lx}}^{q}(\cdot)$ 表示 $3\times3, 5\times5, 7\times7$ 的卷积核，$F_{\theta_{lx}}^{k}(\cdot)$ 和 $F_{\theta_{lx}}^{v}(\cdot)$ 具有与其相同的结构。通过多尺度卷积获取不同的向量映射被统一映射至相同的向量空间，以促进特征融合。这些不同尺寸的卷积核用于捕捉特征图的局部和全局特征，其中小尺寸卷积核对细粒度的局部特征更敏感，而大尺寸卷积核有助于捕捉更广泛的上下文信息。随后，这些不同尺度的特征图被拼接起来，并分别传递至MHA单元和MHCA单元：

$$\begin{aligned} Q_i^{x} &= \mathrm{Concat}(Q_i^{x1}, Q_i^{x2}, Q_i^{x3}), \\ K_i^{x} &= \mathrm{Concat}(K_i^{x1}, K_i^{x2}, K_i^{x3}), \quad x \in \{s,c\} \\ V_i^{x} &= \mathrm{Concat}(V_i^{x1}, V_i^{x2}, V_i^{x3}), \end{aligned} \tag{3.6}$$

其中 Q_i^s、K_i^s、V_i^s、Q_i^c、K_i^c 和 V_i^c 分别表示MHA和MHCA的查询、键和值。上标1、2和3对应特征图 X_i 和 Y_i 在不同尺度的表征：

中国知网 https://www.cnki.net

$$\begin{aligned}\text{MHA}\ (Q_i^s, K_i^s, V_i^s) &= \text{Softmax}\left(\frac{Q_i^s K_i^{s\top}}{\sqrt{d}}\right)V_i^s,\\ \text{MHA}\ (Q_i^c, K_i^c, V_i^c) &= \text{Softmax}\left(\frac{Q_i^c K_i^{c\top}}{\sqrt{d}}\right)V_i^c,\end{aligned} \tag{3.7}$$

$$\begin{aligned}\text{MHCA}\ (Q_i^c, K_i^s, V_i^s) &= \text{Softmax}\left(\frac{Q_i^c K_i^{s\top}}{\sqrt{d}}\right)V_i^s,\\ \text{MHCA}\ (Q_i^s, K_i^c, V_i^c) &= \text{Softmax}\left(\frac{Q_i^s K_i^{c\top}}{\sqrt{d}}\right)V_i^c,\end{aligned} \tag{3.8}$$

$$\begin{aligned}Z_i^s &= \text{LN}(W_o(\text{MHA}(Q_i^s, K_i^s, V_i^s) + \text{MHCA}(Q_i^c, K_i^s, V_i^s)) + X_i),\\ Z_i^c &= \text{LN}(W_o(\text{MHA}(Q_i^c, K_i^c, V_i^c) + \text{MHCA}(Q_i^s, K_i^c, V_i^c)) + Y_i),\end{aligned} \tag{3.9}$$

其中W_o表示1×1的卷积投影矩阵，d表示查询和键的维度。前者（MHA单元）用于处理每个分支内的特征以增强局部和全局特征的表征，后者（MHCA单元）促进跨分支之间的交互，协同实现局部与全局特征的互补融合。最后，通过特征拼接完成聚合，形成包含多尺度信息的综合表征。该表征融合了来自不同感受野的多样化信息，使得模型能够同时捕捉到局部细节和全局上下文信息。聚合特征经多个全连接层构成的前馈网络进一步整合，学习不同特征之间复杂的关系，从而提升对医学图像中复杂病灶的表征能力：

$$\begin{aligned}Z_i &= \text{Concat}(Z_i^s, Z_i^c),\\ Z_i &= \text{LN}(Z_i + \text{MLP}(Z_i)),\end{aligned} \tag{3.10}$$

这种设计通过自多尺度多头注意力机制优化和细化特征表示，在保留多尺度特征多样性的同时有效提升模型的整体性能。

3.3.4 多尺度注意力解码模块

解码器作为U型架构的核心组件，负责对高层次语义特征进行解码和语义细化，最终实现目标区域的分割预测。本研究在PMHNet中引入MAD模块用于对多尺度、多维度的语义特征进行解码和细化，如图3.5所示。该模块主要由卷积运算单元、特征上采样单元以及双重注意力机制单元构成，旨在逐步恢复特征图的空间细节。具体来说，首先采用双线性插值将解码器特征图上采样至与对应编码器相匹配的空间分辨率，通过通道维度拼接实现跨尺度特征的初步融合。随后，利用四个级联的密集卷积块对融合特征进行处理，以充分挖掘和细化多尺度语义信息。为了进一步细化特征并抑制噪

中国知网 https://www.cnki.net

声干扰，在MAD模块中引入空间注意力和通道注意力，其中前者通过构建像素间的空间依赖关系实现特征图的空间加权校准，而后者则通过建模通道相关性完成特征图通道维度的特征自适应。通过这种方式，MAD模块能够有效整合关键特征并显著降低背景噪声干扰，最终1×1卷积层和Sigmoid处理输出精细化分割预测结果。

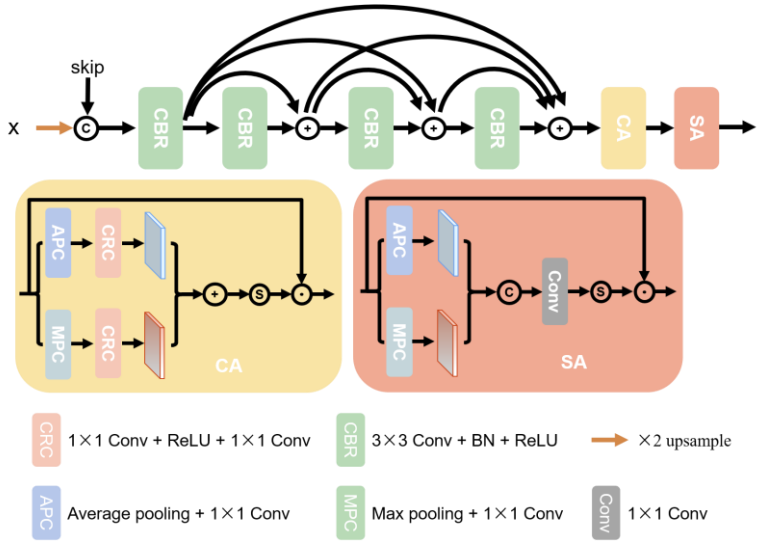


图3.5 MAD模块的结构图

3.3.5 损失函数

医学图像分割通常面临前景与背景分布不均衡以及病变形状多样等挑战。为此，本研究采用Dice与二元交叉熵（Binary Cross-Entropy，BCE）损失相结合来构建最终的损失函数：

$$\mathcal{L}_{Dice} = 1 - \frac{2\sum_{i}^{N} y_i \hat{y}_i + \epsilon}{\sum_{i}^{N} y_i + \sum_{i}^{N} \hat{y}_i + \epsilon}, \tag{3.11}$$

$$\mathcal{L}_{BCE} = -\sum_{i}^{N} y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i), \tag{3.12}$$

$$\mathcal{L} = \mathcal{L}_{Dice} + \mathcal{L}_{BCE}, \tag{3.13}$$

其中，y_i 和 $\hat{y}_i$ 分别表示第 i 个像素的真实标签与预测结果，ϵ 为避免数值不稳定而引入的微小常数。通过结合Dice损失与BCE损失，PMHNet能够有效且稳定地优化模型参数，进而在多种医学图像分割数据集上实现精准的分割效果。该损失函数的设计不仅有助于缓解类别不平衡问题，同时可提升模型对复杂形状病变的分割能力，从而增强模型的鲁棒性和泛化性。

中国知网 https://www.cnki.net

3.4 实验分析

为了评估PMHNet的有效性，本研究在三种不同成像技术的医学图像分割任务上进行大量实验，具体包括共聚焦内窥镜人体消化道腺体分割和动物结肠隐窝分割、病理图像腺体分割以及电子内镜图像息肉分割。

3.4.1 实验设置

（1）人体消化道腺体数据集。CLE人体消化道腺体分割数据集采用团队自研的CLE系统构建，数据源自不同医院的38例临床病例的医学影像采集，经严格筛选后保留718张代表性图像。这些图像通过多人使用LabelMe对腺体进行像素级标注，并综合多人标注结果以形成最终标注。由于图像尺寸不一致，所有图像均被重新采样至256×256像素以满足算法要求。数据集划分采用病例级随机分配策略，将病例分别划入训练集（26例）、验证集（4例）和测试集（8例），严格确保不同数据集间病例无重叠，从而规避数据泄露风险。需要特别说明的是，本数据集与第二章图像去噪研究及后续图像分类研究所用数据集在病例层面存在部分交集。

（2）动物结肠隐窝数据集。CLE动物结肠隐窝分割数据集是通过采用自主研发的pCLE系统对五只大鼠结肠进行离体成像，并最终筛选出151张CLE图像构成。每张图像包含约20至30个隐窝，且图像间无显著重叠以避免数据冗余。数据采集过程中系统采用488 nm激光照射，并通过静脉注射荧光素钠作为造影剂。系统视野为512.5 μm×512.5 μm，成像速度为2帧/每秒（fps），单帧灰度图像分辨率为892×892。通过多人使用LabelMe对隐窝进行像素级标注，并综合多人标注结果以形成最终标注。依据Zhou等人[73]的实验设置，数据集划分为三只大鼠采集的112张训练图像、一只大鼠采集的17张验证图像及一只大鼠采集的22张测试图像。在所有实验中，每张图像的尺寸均调整为256×256。

（3）GLAS数据集。GLAS数据集[181]是一个专用于结肠腺体组织分割任务的高质量病理影像数据集，包含16例结肠癌患者经苏木精-伊红（H&E）染色的165张高分辨率病理切片图像，其中85张用于训练，80张用于测试。所有图像均由经验丰富的病理学家手工标注腺体区域，涵盖形态多样的复杂腺体结构。由于图像尺寸不一致，所有图像均被重新采样至256×256像素以满足算法要求。遵照Chen等人[76]的实验设置，所有实验均进行三次五折交叉验证，并报告各项指标的均值和标准差。

中国知网 https://www.cnki.net

（4）息肉数据集。息肉数据集由Kvasir[182]、CVC-ClinicDB[183]、CVC-ColonDB[170]、EndoScene[162]和ETIS[184]五个公共数据集构成，包含来自不同医疗机构的2248张不同尺寸的临床图像。该数据集在临床实践中对共聚焦内窥镜和病理切片具有重要临床价值，因为在实际医疗过程中，医生通常需先通过电子白光内窥镜筛查定位息肉，再采用共聚焦内窥镜和病理切片进行详细显微成像。本研究严格遵循Zhang等人[176]的数据划分策略，将Kvasir和CVC-ClinicDB数据集随机分为90%用于训练（总共1450张）和10%用于测试（总共162张），剩余的三个数据集（CVC-ColonDB、EndoScene和ETIS）则用于额外验证和测试，以评估模型在不同数据集上的泛化性。根据Dai等人[168]的实验设置，所有图像重新采样为224×224，并在相同的数据划分策略下，采用不同随机种子进行重复实验，以准确可靠地评估各方法的性能。

（5）评价指标。为了全面评估不同方法的性能，本研究采用准确率（Accuracy，Acc）、F1分数（F1-score，F1）、平均交并比（mean Intersection over Union，mIoU）、平均Dice系数（mean Dice，mDice）、灵敏度（Sensitivity，Sen）以及95% Hausdorff距离（Hausdorff Distance 95%，HD95）六个评价指标。

（6）实验细节。本研究基于PyTorch[160]构建所提出的PMHNet模型，并在NVIDIA GeForce RTX 3090 GPU上完成所有实验。模型训练过程中采用AdamW优化器，学习率设置为1×10^{-4}，批次（mini-batch）大小为4，权重衰减系数为1×10^{-4}。此外，采用余弦模拟退火策略调整学习率，其周期参数T_0设置为10，T_{mult}设置为2。所有实验均训练200个周期，并采用相同的数据增强策略，包括随机水平与垂直翻转以及90°旋转。为了确保实验的公平性，所有方法均在相同实验环境中复现。由于实验环境与原始论文存在差异，结果可能与原论文提供的数据有所出入。

3.4.2 人体消化道腺体分割实验

为了验证PMHNet的有效性和对后续图像分类任务能够提供精准的腺体区域分割结果以提升分类标注效率及模型可解释性，本研究在CLE人体消化道腺体数据集上与十五种最先进的算法进行对比分析，包括U-Net[59]、U-Net++[185]、AttU-Net[175]、MultiResU-Net[186]、SETR[172]、Trans-UNet[76]、MedT[178]、Swin-UNet[77]、UCTransNet[164]、UNeXt[187]、CrosslinkNet[165]、SA2Net[166]、FusionUNet[167]、DAUNet[73]和I^{2}U-Net[168]。表3.1显示了不同方法在CLE人体消化道腺体数据集上的定量结果。实验结果表明，所

中国知网 https://www.cnki.net

提出的方法在所有评估指标上均取得了可竞争的性能。这主要包括以下两个原因，一方面是第二章的CLE图像去噪研究为腺体结构的准确分割提供了高质量的输入图像，有效抑制了背景噪声和成像伪影的干扰，从而提升了分割网络在边缘细节与微小结构识别上的鲁棒性。另一方面，PMHNet所设计的多尺度特征融合与层级注意机制能够充分地建模腺体的形态变异与复杂纹理特征，不仅增强了模型对不同尺度目标的感知能力，同时也提高了关键区域的响应强度，使得模型在应对腺体形态多样性方面表现出更强的适应性与泛化能力。PMHNet在本任务的优越表现不仅验证了其模型结构的有效性，也为后续的图像分类和临床辅助诊断提供了可靠的腺体解剖结构形态学依据。

表3.1 不同方法在人体消化道腺体数据集上的定量评估结果

方法	参数量 (M)	mIoU (%)	F1 (%)	Acc (%)	mDice (%)	Sen (%)
U-Net[59]	31.03	83.66	90.52	91.61	90.52	89.94
U-Net++[185]	34.96	82.68	89.85	90.89	89.85	91.21
AttU-Net[175]	57.16	81.79	89.10	90.70	89.10	88.09
MultiResU-Net[186]	7.25	83.66	90.49	91.34	90.49	94.19
SETR[172]	86.21	59.59	73.07	77.29	73.07	71.31
Trans-UNet[76]	93.23	85.51	91.41	92.50	91.41	91.55
MedT[178]	1.37	78.12	86.58	88.12	86.58	88.33
Swin-UNet[77]	41.38	86.92	92.55	93.09	92.55	95.06
UCTransNet[164]	66.24	86.05	92.05	92.87	92.05	94.00
UNeXt[187]	1.47	83.12	90.24	91.13	90.24	91.07
CrosslinkNet[165]	31.87	80.79	88.54	89.69	88.54	89.32
SA2Net[166]	19.29	85.18	91.33	92.39	91.33	92.10
FusionUNet[167]	25.80	85.86	91.89	92.77	91.89	93.28
DAUNet[73]	11.78	88.55	93.51	94.24	93.51	94.39
I^2U-Net[168]	27.49	85.59	91.48	92.55	91.48	93.77
PMHNet	76.28	90.35	94.68	95.44	94.68	95.30

不同方法在CLE人体消化道腺体数据集上的定性对比结果如图3.6所示。视觉对比分析结果表明，PMHNet能够准确识别不同形态的腺体结构，并在低对比度、形态复杂和不同尺寸的腺体组织上生成更加精确的分割边界。这些定量和定性结果充分验证了该方法能够有效挖掘判别性表征和建模腺体组织复杂的空间依赖关系，从而提升分割的鲁棒性与精度。进一步分析可见，PMHNet在处理边界模糊、腺体粘连或轮廓断裂等复杂情况时，依然能够保持良好的结构一致性和边缘清晰度，避免了其他方法中出现的结构丢失问题。该方法为后续图像分类、病变检测及临床辅助诊断等任务提

中国知网 https://www.cnki.net

供了高质量的结构化信息。鉴于基于CLE图像疾病的判定主要依赖于对细胞组织结构和形态差异的观察与分析，精确的腺体区域分割不仅有助于提取更具判别力的形态学特征，还能为后续图像分类数据标注和模型训练提供结构参考依据，从而在一定程度上提升分类任务的规范性与一致性及模型的可解释性。

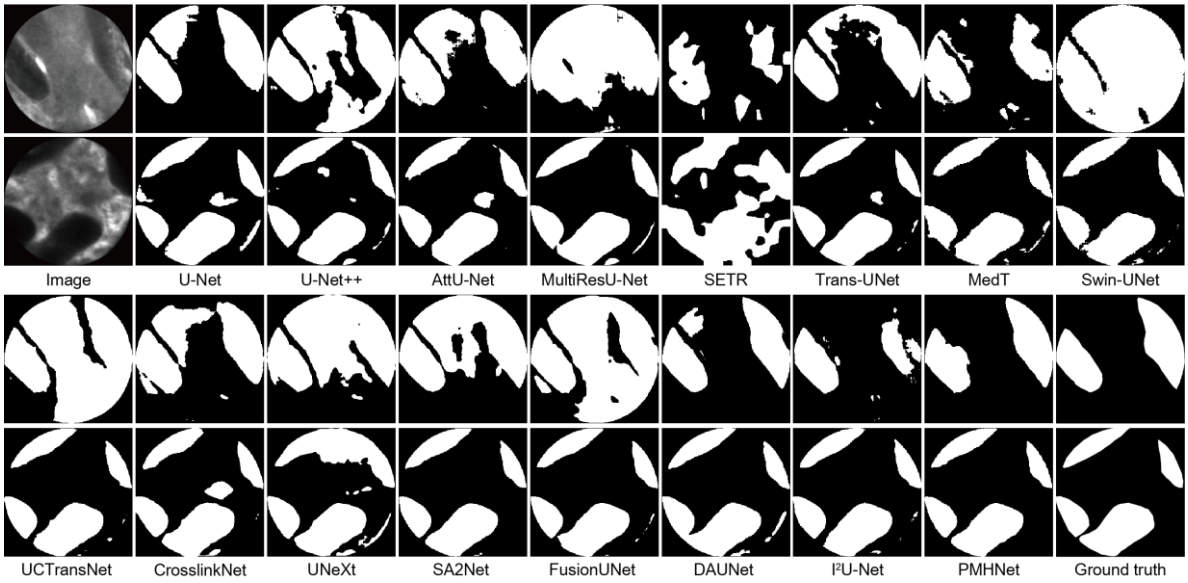


图3.6 不同方法在CLE人体消化道腺体数据集上的定性评估结果

3.4.3 动物结肠隐窝分割实验

为了验证PMHNet的有效性，本研究在CLE动物结肠隐窝数据集上与十五种最先进的算法进行对比分析，包括FCN[174]、U-Net[59]、U-Net++[185]、AttU-Net[175]、SETR[172]、Trans-UNet[76]、MedT[178]、Swin-UNet[77]、UCTransNet[164]、UNeXt[187]、CrosslinkNet[165]、SA2Net[166]、FusionUNet[167]和DAUNet[73]。表3.2报告了各方法在mIoU、mDice、Acc、F1和HD95等评估指标上的定量结果。实验结果表明，PMHNet在所有评估指标上均达到最优性能。具体来说，相较于U-Net、U-Net++和AttU-Net等单分支纯卷积方法，PMHNet在处理边缘模糊的隐窝和小隐窝时表现良好，这主要得益于DGC和双分支编码器，使模型能够更有效地捕获和利用局部和全局信息。此外，相较于UCTransNet和Trans-UNet等混合单分支或混合并行双分支方法，PMHNet在处理形状复杂且尺寸不一的隐窝时也展现出更强的适应性，主要归功于SMSF和MAD模块的作用，二者使得模型在确保高分割精度的同时有效保留了全局语义信息。进一步地，与专门为隐窝分割设计的DAUNet相比，PMHNet在mIoU和mDice上分别提升了0.11%和0.12%，充分验证了其在隐窝分割任务中的有效性和鲁棒性。

中国知网 https://www.cnki.net

表3.2 不同方法在动物结肠隐窝数据集上的定量评估结果

方法	参数量 (M)	mIoU (%)	F1 (%)	Acc (%)	mDice (%)	HD95 (mm)
FCN[174]	18.64	73.38	84.54	86.44	84.54	5.1734
U-Net[59]	31.03	73.85	84.86	87.82	84.86	7.3313
U-Net++[185]	34.96	74.98	85.57	87.54	85.57	6.5373
AttU-Net[175]	57.16	77.68	87.35	89.27	87.35	6.3603
MultiResU-Net[186]	7.25	78.52	87.87	89.64	87.87	7.6250
SETR[172]	86.21	57.78	73.07	70.37	73.07	9.0662
Trans-UNet[76]	93.23	78.10	87.61	89.42	87.61	5.0238
MedT[178]	1.37	73.57	84.64	87.03	84.64	8.0357
Swin-UNet[77]	41.38	72.48	83.93	86.00	83.93	5.6993
UCTransNet[164]	66.24	80.40	89.02	90.51	89.02	5.0610
UNeXt[187]	1.47	74.50	85.26	87.28	85.26	6.3126
CrosslinkNet[165]	31.87	74.71	85.38	87.10	85.38	6.4036
SA2Net[166]	19.29	80.11	88.30	90.37	88.30	5.1243
FusionUNet[167]	25.80	79.87	88.70	90.34	88.70	5.5802
DAUNet[73]	11.78	81.54	89.74	91.10	89.74	4.0907
PMHNet	76.28	81.60	89.81	91.26	89.81	4.1178

图3.7定性展示了各方法在CLE动物结肠隐窝数据集上的分割结果。实验结果表明，虽然几乎所有方法都能大致检测并分割出大部分隐窝，但PMHNet在应对边缘模糊、形态异质性和微小隐窝时能够展现出更精细的分割结果。这些定量和定性结果充分验证了该方法在CLE动物隐窝分割任务中的优越性能。

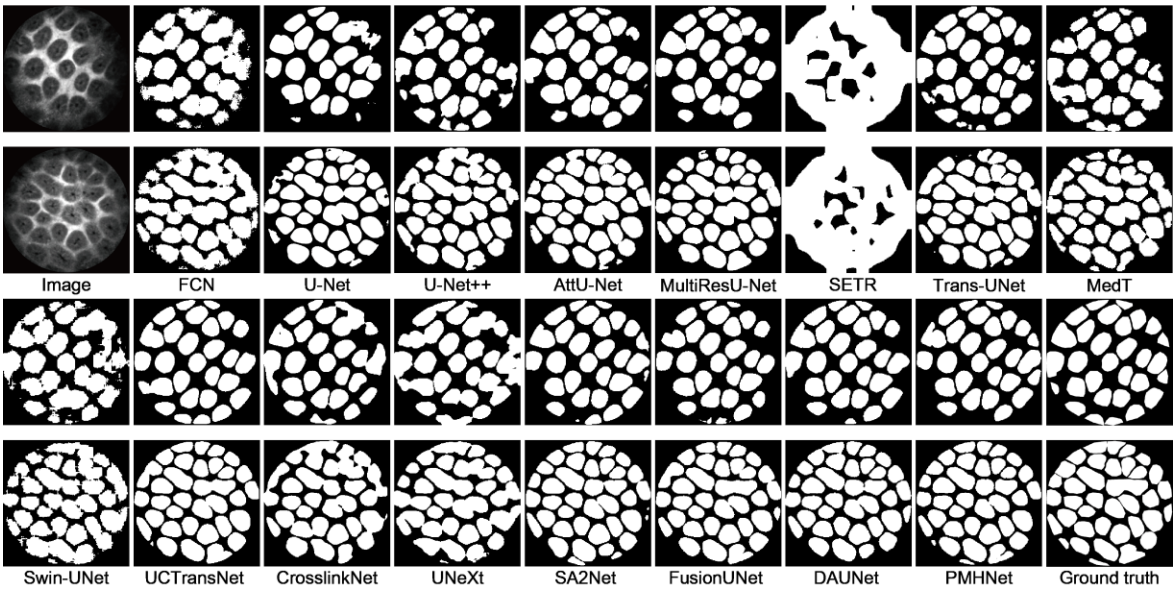


图3.7 不同方法在CLE动物结肠隐窝数据集上的定性评估结果

中国知网 https://www.cnki.net

3.4.4 病理腺体分割实验

在本节中，本研究基于GLAS数据集对PMHNet进行性能评估，并将其与十五种最先进的算法进行对比分析，包括FCN[174]、U-Net[59]、U-Net++[185]、AttU-Net[175]、SETR[172]、Trans-UNet[76]、MedT[178]、Swin-UNet[77]、UCTransNet[164]、UNeXt[187]、CrosslinkNet[165]、SA2Net[166]、FusionUNet[167]、DAUNet[73]和I^2U-Net[168]。表3.3展示了不同方法在GLAS数据集上的性能对比结果。实验结果表明，FCN、U-Net和U-Net++等方法的性能相对较低，主要原因在于它们未能充分利用多尺度特征信息。此外，基于纯Transformer的方法，如SETR、MedT和Swin-UNet，在处理形状复杂且尺寸不一的腺体分割时存在明显局限性，这主要源于这些方法未能有效捕捉和整合多尺度信息及难以有效建模腺体组织复杂的空间依赖关系，而这些因素对于实现精确分割腺体结构至关重要。同时，UCTransNet和Trans-UNet等混合架构方法通过协同融合局部细节与全局上下文信息，因此在性能上优于纯Transformer的方法。值得注意的是，本研究提出的PMHNet在所有评估指标上均优于现有最先进方法，充分表明了其在腺体分割任务中的有效性和鲁棒性。

表3.3 不同方法在GLAS数据集上的定量评估结果

方法	参数量(M)	mIoU (%)	F1 (%)	Acc (%)	mDice (%)	HD95(mm)
FCN[174]	18.64	64.44±1.18	77.56±0.91	76.62±1.74	77.56±0.91	24.28±1.99
U-Net[59]	31.03	67.26±2.65	78.66±2.26	78.72±2.99	78.66±2.26	23.86±4.59
U-Net++[185]	34.96	74.42±0.79	84.55±0.61	85.08±0.77	84.55±0.61	17.16±0.84
AttU-Net[175]	57.16	70.34±1.70	80.69±1.66	82.99±1.21	80.69±1.66	23.21±2.95
SETR[172]	86.21	59.25±0.65	73.75±0.49	70.32±0.78	73.75±0.49	24.87±1.39
Trans-UNet[76]	93.23	77.32±0.87	86.20±0.77	87.04±0.56	86.20±0.77	14.62±1.21
MedT[178]	1.37	66.86±1.02	79.12±1.02	79.88±0.69	79.12±1.02	20.50±1.01
Swin-UNet[77]	41.38	57.82±1.36	72.64±2.89	72.88±1.65	72.64±2089	24.26±2.17
UCTransNet[164]	66.24	82.34±1.04	89.64±0.74	90.26±0.67	89.64±0.74	12.88±1.29
UNeXt[187]	1.47	72.77±1.21	83.48±0.85	84.15±0.96	83.48±0.85	17.57±1.53
CrosslinkNet[165]	31.87	61.82±1.00	74.96±0.73	74.23±2.39	74.96±0.73	28.19±3.08
SA2Net[166]	19.29	82.98±1.01	90.01±0.85	90.04±0.60	90.01±0.85	12.76±1.19
FusionUNet[167]	25.80	81.33±0.99	88.92±0.75	89.56±0.59	88.92±0.75	14.17±1.23
DAUNet[73]	11.78	84.83±0.46	91.36±0.30	91.61±0.25	91.36±0.30	11.88±0.85
I^2U-Net[168]	27.49	80.61±0.89	88.53±0.58	89.00±0.46	88.53±0.58	12.80±0.91
PMHNet	76.28	86.86±0.73	92.65±0.46	92.81±0.34	92.65±0.46	9.06±1.68

图3.8定性地展示了各种方法在GLAS数据集上的分割结果。视觉结果表明，

中国知网 https://www.cnki.net

PMHNet能够准确识别不同腺体结构，并在低对比度、形态复杂和不同尺寸的腺体组织上生成更加精确的分割边界。这些优异的结果主要得益于PMHNet能够对判别性特征表征的深度挖掘。通过有效捕捉和整合多尺度信息及建模复杂的空间关系，该模型能够更好地应对组织形态异质和病理结构复杂的腺体，从而显著提升对不同尺寸和形状的腺体结构的语义感知与分割精度。



图3.8 不同方法在GLAS数据集上的定性评估结果

3.4.5 息肉分割实验

第四个应用聚焦于电子白光内窥镜检查图像中的息肉分割任务，该任务在临床实践中具有重要意义。该分割任务通过精准定位息肉形态边界，为后续的共聚焦内窥镜检查和病理分析提供了基础数据，辅助医生能够更有效地识别、分析和处理潜在的病变区域，从而为消化道疾病的诊断和手术提供更加精确的临床决策。为了评估PMHNet的有效性，本研究在五个息肉分割数据集上将其与最先进的方法进行对比分析，包括U-Net[59]、U-Net++[185]、AttU-Net[175]、MultiResU-Net[186]、Trans-UNet[76]、MedT[178]、Swin-UNet[77]、UCTransNet[164]、UNeXt[187]、PraNet[169]、CrosslinkNet[165]、SA2Net[166]、FusionUNet[167]、DAUNet[73]和I²U-Net[168]。在所使用的五个公共息肉数据集中，CVC-ClinicDB和Kvasir数据集分别包含用于训练和测试子集，EndoScene、ColonDB和ETIS数据集则仅用于测试。

中国知网 https://www.cnki.net

表3.4 不同方法在息肉数据集上的定量评估结果

方法	参数量(M)	Acc	mIoU	mDice	Sen	Acc	mIoU	mDice	Sen
		CVC-ClinicDB				Kvasir			
U-Net[59]	31.03	98.96	83.01	87.54	88.28	95.30	75.35	82.78	85.90
U-Net++[185]	34.96	98.40	80.89	86.47	86.69	95.59	77.66	85.49	88.28
AttU-Net[175]	57.16	98.92	84.61	89.54	89.80	95.86	78.37	84.95	87.70
MultiResU-Net[186]	7.25	98.28	73.50	80.80	84.38	95.66	73.94	82.10	86.20
Trans-UNet[76]	93.23	98.50	82.02	87.31	86.91	96.04	79.82	86.37	85.89
MedT[178]	1.37	97.58	72.74	79.66	78.58	92.39	62.35	72.68	76.03
Swin-UNet[77]	41.38	98.76	82.22	88.13	90.12	95.39	78.84	85.59	88.80
UCTransNet[164]	66.24	98.95	86.65	92.00	94.79	96.67	84.00	90.00	91.24
UNeXt[187]	1.47	98.45	78.14	84.86	86.35	94.51	71.04	79.74	82.53
PraNet[169]	30.50	97.00	83.55	88.55	91.03	94.07	83.90	89.03	88.99
CrosslinkNet[165]	31.87	98.46	77.24	82.73	83.57	91.48	70.26	78.20	86.53
SA2Net[166]	19.29	98.80	84.73	90.50	91.85	95.74	78.68	86.18	92.36
FusionUNet[167]	25.80	99.08	86.38	92.05	93.20	95.77	79.41	86.13	88.62
DAUNet[73]	11.78	98.41	82.03	87.79	90.60	96.39	81.73	88.15	91.28
I^2U-Net[168]	27.49	98.43	87.60	92.32	95.09	95.57	84.68	88.59	89.05
PMHNet	76.28	99.10	87.98	93.06	95.59	97.41	85.50	91.03	91.33
		EndoScene				CVC-ColonDB			
U-Net[59]	31.03	98.87	72.22	78.85	83.16	95.89	58.00	65.20	66.13
U-Net++[185]	34.96	98.33	70.52	78.59	88.04	95.39	56.96	65.69	70.96
AttU-Net[175]	57.16	98.53	72.08	79.75	87.47	95.97	59.33	66.57	67.59
MultiResU-Net[186]	7.25	98.76	73.03	81.43	89.33	94.92	48.69	56.49	62.37
Trans-UNet[76]	93.23	98.28	72.06	79.72	88.31	95.88	61.38	69.30	70.91
MedT[178]	1.37	96.39	47.65	55.45	65.36	93.79	41.36	49.44	53.78
Swin-UNet[77]	41.38	98.60	75.38	84.27	95.39	95.53	63.83	72.77	80.01
UCTransNet[164]	66.24	98.05	70.49	79.32	93.04	94.80	63.23	71.78	78.95
UNeXt[187]	1.47	98.27	64.62	73.89	77.65	94.83	47.65	55.73	58.46
PraNet[169]	30.50	98.78	78.35	85.75	96.01	94.83	62.84	69.89	71.82
CrosslinkNet[165]	31.87	98.35	65.03	73.59	83.69	95.46	53.40	61.67	63.42
SA2Net[166]	19.29	98.51	68.63	75.99	83.98	94.94	55.40	62.86	68.55
FusionUNet[167]	25.80	97.46	68.00	76.79	91.03	94.01	59.65	68.23	75.83
DAUNet[73]	11.78	97.91	74.36	81.52	95.93	94.94	66.44	74.72	83.98
I^2U-Net[168]	27.49	98.18	77.26	85.98	96.03	94.58	66.94	75.26	82.09
PMHNet	76.28	98.82	78.36	86.18	96.12	95.47	69.46	77.18	82.48

中国知网 https://www.cnki.net

续表3.4 不同方法在息肉数据集上的定量评估结果

方法	参数量(M)	Acc	mIoU	mDice	Sen	Acc	mIoU	mDice	Sen
		ETIS				Average			
U-Net[59]	31.03	97.34	40.69	46.44	51.88	97.27	65.85	72.16	75.07
U-Net++[185]	34.96	95.98	38.83	46.03	53.66	96.74	64.97	72.45	77.53
AttU-Net[175]	57.16	97.26	42.28	47.72	52.81	97.31	67.33	73.71	77.07
MultiResU-Net[186]	7.25	97.30	33.83	38.84	41.61	96.98	60.60	67.93	72.78
Trans-UNet[76]	93.23	97.54	51.00	57.87	64.33	97.25	69.26	76.11	79.27
MedT[178]	1.37	95.89	24.47	29.54	33.36	95.21	49.71	57.35	61.42
Swin-UNet[77]	41.38	93.54	44.23	51.10	63.46	96.36	68.90	76.37	83.56
UCTransNet[164]	66.24	95.96	55.80	64.05	75.81	96.89	72.03	79.45	86.77
UNeXt[187]	1.47	96.14	29.13	34.66	38.81	96.44	58.12	65.78	68.76
PraNet[169]	30.50	95.32	57.52	64.95	69.53	96.00	73.23	79.63	83.48
CrosslinkNet[165]	31.87	94.68	29.71	34.98	44.51	95.69	59.13	66.23	72.34
SA2Net[166]	19.29	96.68	45.25	51.33	62.76	96.93	66.54	73.37	79.90
FusionUNet[167]	25.80	91.41	33.20	40.60	56.54	95.55	65.33	72.76	81.04
DAUNet[73]	11.78	94.01	51.91	60.39	80.33	96.33	71.29	78.51	88.42
I^2U-Net[168]	27.49	97.20	58.69	68.31	76.74	96.79	75.03	82.09	87.80
PMHNet	76.28	97.11	66.15	74.12	88.14	97.58	77.49	84.31	90.73

表3.4和图3.9展示了不同模型在这些数据集上的定量分割与可视化结果。与现有方法相比，所提出的方法在定量和定性分析中均展现出具有竞争力的分割性能和良好的泛化性。具体来说，在可见（已参与训练和验证）数据集的测试集上，PMHNet在各项指标上均优于其他方法，表明其优秀的学习能力，这对于模型提取更具判别性的表征至关重要。以CVC-ClinicDB数据集为例，PMHNet的mIoU和mDice分别达到87.98%和3.06%，较基于CNN的最佳方法I^2U-Net分别提升了0.38%和0.74%，较基于Transformer的最佳方法Swin-UNet分别提升了5.76%和4.93%，较基于混合架构的最佳方法UCTransNet分别提升了1.33%和1.06%。在Kvasir数据集上，PMHNet的mIoU和mDice分别为85.50%和91.03%，较I^2U-Net分别提升了0.82% 和1.44%，较Swin-UNet分别提升5.68%和4.66%，较UCTransNet分别提升了1.5%和1.03%。值得注意的是，与经典的U-Net、U-Net++、AttU-Net和PraNet方法相比，PMHNet的性能提升更为显著。同时，PMHNet在未参与训练的数据集上也取得了最佳性能，进一步验证了其强大的泛化能力。例如，在CVC-ColonDB数据集上PMHNet的mIoU和mDice分别为69.46%和77.18%，较I^2U-Net分别提升了2.52%和1.92%，较Swin-UNet分别提升了5.63%和4.4%，较UCTransNet提升了6.23%和5.4%。综上所述，PMHNet在具有挑战性的息肉分割任

中国知网 https://www.cnki.net

务上优于SOTA方法，证明了其在息肉分割中的有效性和稳健性。此外，从图3.9中可以看出，针对不同类型的息肉数据集，PMHNet展现出更加稳定和可靠的性能，这进一步说明了所提出的方法具有出色的学习能力和泛化性。

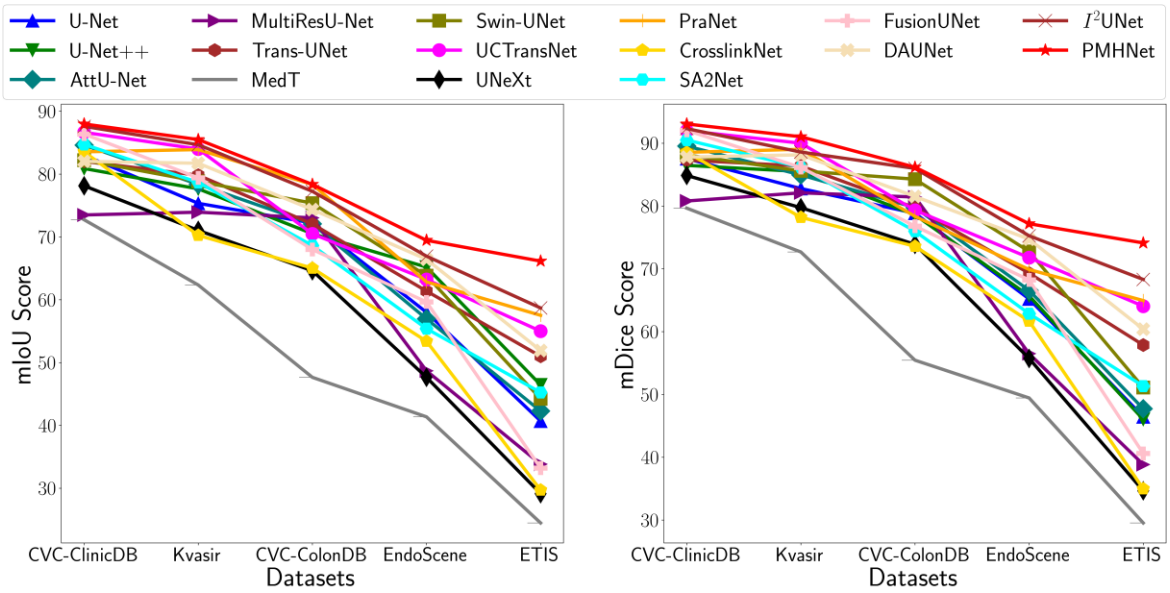


图3.9 不同方法在五个息肉数据集上的定量比较

此外，图3.10的可视化对比分析表明，PMHNet在各类息肉数据集中均展现出优异的边缘预测性能。相较于现有最先进方法，该模型能够更精确地捕捉和判别复杂的边缘区域特征，尤其在处理形态不规则或边界模糊的息肉样本时表现突出。这种增强的边缘预测能力不仅显著提高了整体分割的精度，同时有效降低了误分割和漏分割的发生概率，充分验证了该方法在多样化息肉数据集中的优越性。如表3.4和图3.9所示，PMHNet在小息肉分割任务中同样表现出色，这对于增强模型泛化性及提升结肠镜检查中易被忽略微小息肉的分割准确率具有重要临床价值。

学习能力和泛化能力。为了进一步评估不同方法的学习能力（Learning Ability，LA）与泛化能力（Generalization Ability，GA），本研究在息肉数据集上展开对比分析。图3.11展示了不同方法的LA和GA评估结果。相较于现有最先进方法，PMHNet不仅在可见数据集上表现优异，同时在未见过的数据集上仍能维持较高的分割性能，表明其具有强大的学习能力和泛化性。这种出色的学习能力使其能够从有限样本中高效提取更具判别性的表征，并成功地在形态各异的息肉数据集上实现泛化，从而有力证明了该方法在关键临床应用中的应用潜力与稳健性。

中国知网 https://www.cnki.net

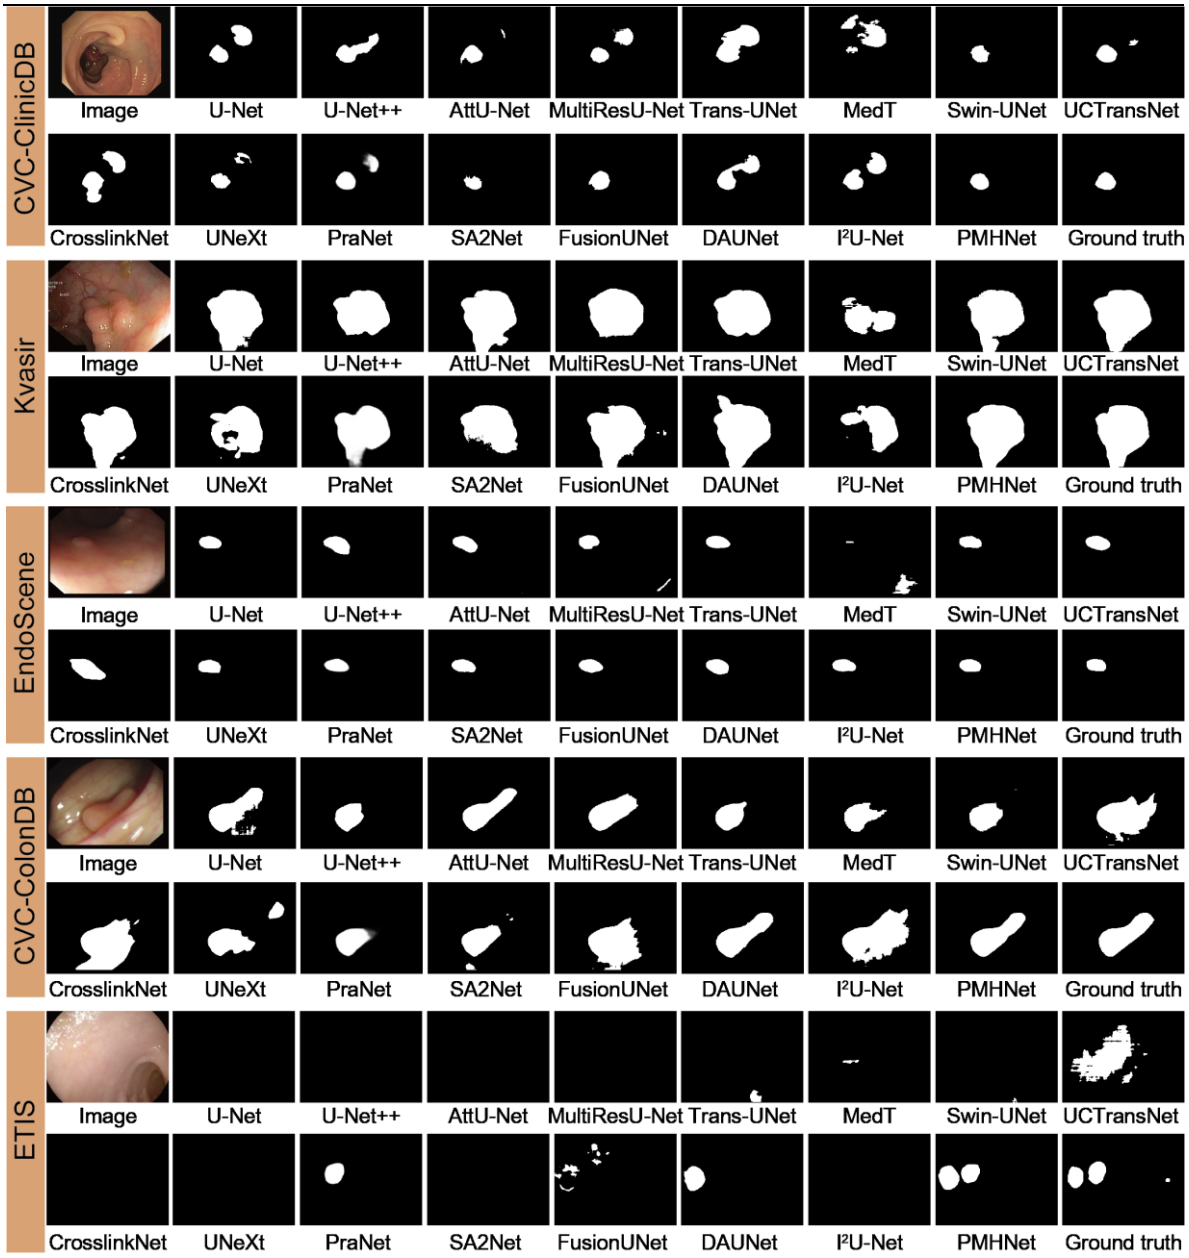


图3.10 不同方法在息肉数据集上的定性分割结果

3.4.6 消融实验

为了评估PMHNet中各模块的有效性，本研究在动物结肠隐窝数据集和GLAS数据集[181]上进行消融实验。实验采用mIoU、mDice和Acc作为性能评估指标，结果见表3.5。评估的模型包括：

基线：以U-Net[59]作为基线，并在此基础上设计所提出的方法。

模型1：将基线中的编码器模块替换为所提出的DGC模块。

模型2：在模型1的编码器中引入金字塔Transformer[173]，与DGC模块共同构建并

中国知网 https://www.cnki.net

行的双分支编码器，并通过特征拼接方式聚合两个分支的特征。

模型3：将模型2中的双分支特征拼接操作替换为所提出的SMSF模块。

模型4：将模型3中的解码器模块替换为所提出的MAD模块。

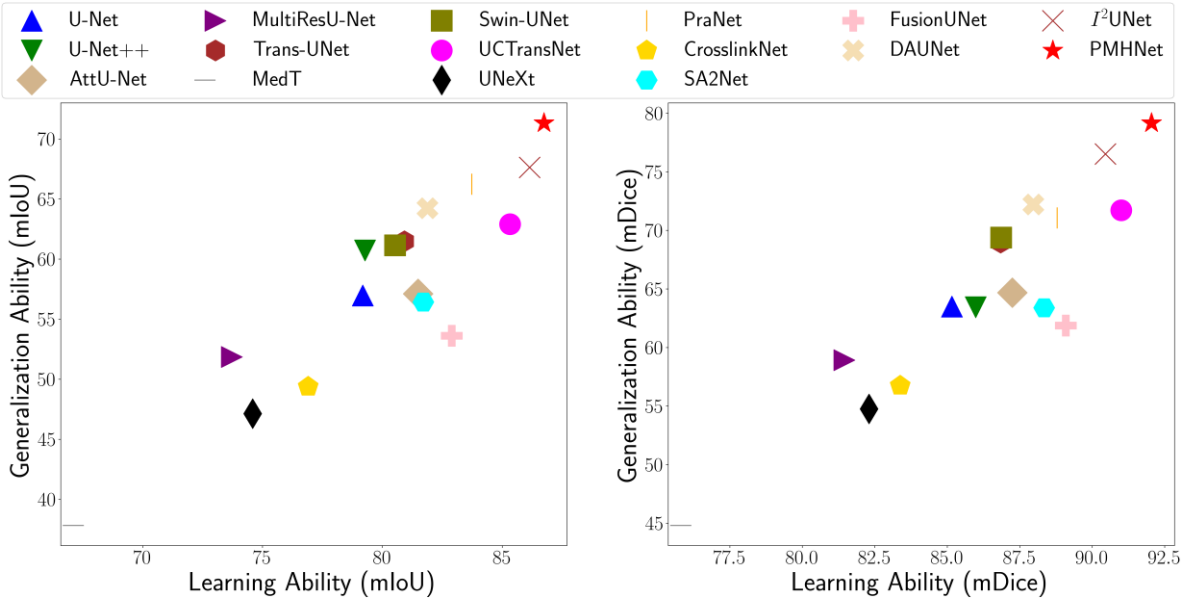


图3.11 各种方法在息肉分割数据集上的LA和GA分析，LA代表在CVC-ClinicDB和Kvasir数据集上评估的学习能力，GA代表在CVC-ColonDB、EndoScene和ETIS数据集上评估的泛化能力

表3.5报告了PMHNet中不同模块在动物结肠隐窝数据集和GLAS数据集的消融实验结果。基线和模型1的核心差异在于编码器部分，解码器部分完全一致。与基线相比，模型1在分割性能上有所提升且参数量略有增加，这验证了DGC模块在特征提取方面的有效性。模型1参数量的增加主要源于编码器和解码器之间的特征图采用特征拼接操作，以增强特征表征能力。为了进一步评估金字塔Transformer模块[173]和SMSF模块的有效性，本研究分别构建了模型2和模型3。模型2在模型1的基础上引入金字塔Transformer模块，模型3则在模型2的基础上添加SMSF模块。通过比较模型1-3的结果，发现引入金字塔Transformer模块和SMSF模块能够显著提高Acc、mIoU和mDice。这是因为DGC模块和金字塔Transformer模块能够分别提取不同层次的局部和全局特征，而SMSF模块能够交互和聚合不同维度的特征，从而提取更具判别性的高层次语义信息，帮助模型更好地关注有用特征并抑制冗余信息。最后，模型4是将MAD模块引入到解码器，以缩小特征语义差距并细化特征。通过比较模型3和4的结果可以看出，MAD模块通过多尺度自适应语义特征感知机制显著提升了模型的表征性，这表明MAD模块与本方法体系具有更优的适配性。模型4即PMHNet的最终架构，在动物结肠隐窝数据集和GLAS数据集上均展现出最优性能，充分验证了各模块的协同优化作用。

中国知网 https://www.cnki.net

表3.5 PMHNet中不同模块在动物结肠隐窝数据集和GLAS数据集的消融实验结果

方法	参数量(M)	动物结肠隐窝数据集			GLAS数据集		
		Acc	mIoU	mDice	Acc	mIoU	mDice
基线	31.03	88.24	76.16	86.35	89.31±0.64	81.24±1.33	88.94±1.02
模型1	89.58	90.66	80.71	89.22	90.36±0.36	82.80±0.69	89.94±0.45
模型2	58.04	90.72	80.98	89.43	92.19±0.27	85.69±0.51	91.87±0.32
模型3	87.38	90.96	81.31	89.63	92.48±0.29	86.40±0.28	92.34±0.15
模型4 (PMHNet)	76.28	91.26	81.60	89.81	92.81±0.34	86.83±0.73	92.65±0.46

与此同时，本研究通过图3.12展示了PMHNet不同模块在动物结肠隐窝数据集和GLAS数据集上的分割效果对比可视化结果。图中第一列至第五列依次为原始图像、参考标签以及各个模型的预测结果。可以看出，基线模型的预测结果虽然能够大致分割出目标区域，但仍存在大量噪声和边缘误分割现象。随着DGC、SMSF和MAD模块的逐步引入，模型逐步抑制浅层特征的噪声干扰并增强特征表征的判别性，表明这些模块均有助于提升分割性能。此外，最后一列的预测结果能够精确定位病变区域边界，还能有效应对周围组织和病变区域之间的相似性干扰，充分表明模型4在分割性能上的优势。因此，本研究选择模型4作为最终的网络架构。通过图3.12的可视化结果，可以直观地观察到各模块对分割效果的改善，进一步支持了前述消融实验中各模块有效性的结论。这些结果表明，PMHNet通过各模块的协同作用，显著提高了腺体和息肉分割的准确性和鲁棒性，具有良好的临床应用潜力。

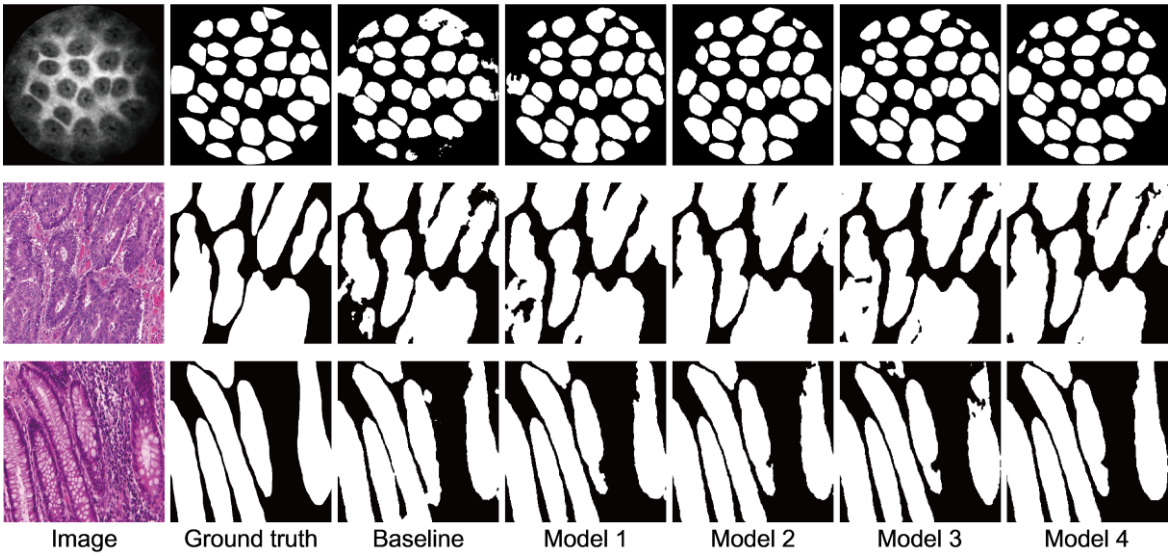


图3.12 PMHNet中不同模块在动物结肠隐窝数据集和GLAS数据集上的分割结果。模型1至模型4分别对应包含DGC、DGC+金字塔Transformer、DGC+金字塔Transformer+SMSF和DGC+金字塔Transformer+SMSF+MAD的不同模型。模型4为PMHNet的分割结果

中国知网 https://www.cnki.net

3.4.7 讨论

尽管所提出的方法在四个具有挑战性的医学图像分割任务中均展现出具有竞争力的分割性能，但其计算成本，尤其是推理时间方面仍需进一步优化。这主要是由于双路并行编码器架构导致的参数量过多。未来，我们计划设计一个轻量化且高效的模型结构，以满足临床实践中的实时处理需求。同时，我们也将尝试将神经架构搜索（NAS）和知识蒸馏技术整合到所提出的方法，通过自动优化特征提取路径和压缩冗余卷积核，以在保持分割精度的同时降低计算复杂度。值得注意的是，本研究在病理图像分割任务中观察到的性能波动（mIoU标准差±0.73%和mDice±0.46%）可能与训练数据的异质性相关，特别是在细胞形态多样性及染色差异方面，小样本数据集难以充分覆盖临床实际中的复杂情况。因此，鉴于本研究所采用的共聚焦内窥镜和病理图像分割数据集样本量有限，未来将基于大规模临床医学影像分割数据集对所提出的方法的有效性进行更全面的验证。此外，我们将探索边缘计算的部署方案，通过量化感知训练和自适应分辨率输入策略，实现临床场景下的实时处理与精准分割的有机统一。

3.5 本章小结

本章提出了一种用于消化道医学图像分割的金字塔Transformer并行多尺度特征混合网络PMHNet，由DGC，SMSF和MAD三个核心模块组成，展现了出色的学习能力和泛化性。该网络通过金字塔Transformer和DGC分别获取具有高分辨率特征图和高级语义的多尺度信息，同时SMSF通过聚合上下文和边缘特征信息，有效抑制了噪声干扰与信息冗余。这些设计模块有效缓解了不同模态医学图像中病灶形态异质性显著、病灶区域与周围组织对比度低以及病灶边缘模糊等问题，实现了病灶区域的准确定位和精确分割。实验结果表明，本方法在多个消化道公开数据集上均取得了具有竞争力的分割精度，充分验证了PMHNet在医学图像分割中的有效性和鲁棒性，为后续CLE图像分类提供了精准可靠的腺体解剖结构形态学指导，从而提升分类标注效率和增强模型可解释性。然而，由于该方法参数量较大且主要侧重于术中分割场景设计，在实时性方面仍需进一步优化。此外，该方法依赖大量高精度标注的医学图像数据，未来将重点探索轻量化无监督分割框架，以更好地适配临床术中场景的实时分割需求。

本章工作创新点如下：

（1）本研究提出了一个新型的金字塔多尺度混合网络PMHNet用于消化道息肉和

中国知网 https://www.cnki.net

腺体分割，该网络通过将三个设计好的模块与金字塔ViT相结合，以能够更有效地学习强大且鲁棒的表征。

（2）本研究设计了三个模块用于从医学图像中提取、聚合和解码多尺度上下文信息，以有效应对不同类型病变之间的显著差异、病变形态变化、模糊边缘以及对比度低等挑战。

（3）所提出的方法在四个具有挑战性的医学图像分割任务上进行了广泛实验验证，结果表明其在性能和泛化性上相较于现有的最先进方法具有可竞争性。

中国知网 https://www.cnki.net

4 聚类引导的双对比学习图像分类方法

4.1 引言

近些年，随着大规模高质量标注数据集的出现，机器学习在CAD领域取得了突破性进展[188]。然而，CLE计算机辅助诊断的早期研究[88,90]主要依赖人工特征提取和专家知识，通过结合KNN和SVM等传统分类器实现图像的二分类，其准确率有限且难以满足临床实际需求。最新研究表明，基于监督学习的深度学习方法[119]在CLE图像分析中取得了显著成效，但缺乏完善的大规模标注数据集仍是制约CLE计算机辅助诊断系统进一步发展的关键因素。此外，CLE图像包含复杂的形态学特征且呈现类间差异细微和类内差异显著的特性，显著增加了图像解析与人工标注的难度[18]。如图4.1所示，图（a）和（c）虽属同一类别却呈现显著形态差异，而分属不同类别的图（a）和（b）反而具有高度视觉相似性。现有研究尝试通过无监督学习来解决缺乏充分标注的CLE图像问题，主要利用多模态方法[115,130,131,189]来提取判别性特征。然而，这种方法通常需不同模态数据间的精确配准，这对CLE图像并非易事。为此，采用无需人工标注的自监督学习成为一种可行的解决方案[190]，其从数据中挖掘自身的监督信息来学习有效的视觉表征，从而改善CLE图像分析的准确性。

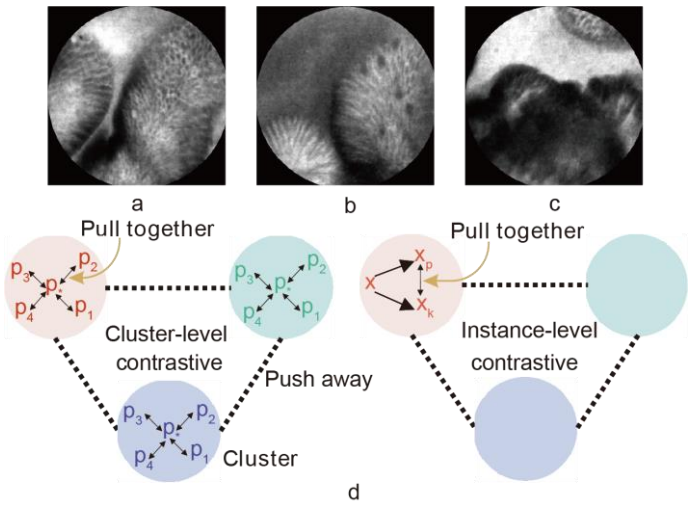


图4.1 来自SSL_CLE数据集的图像（a）、（b）和（c）。图（a）和图（c）虽属同一类别却在内容和形态上有明显差异，而图（a）和图（b）虽属不同类别却在内容和形态上高度相似。图（d）阐述了本研究提出方法的核心理念，其中每个圆圈代表一个簇

自监督学习（Self-Supervised Learning，SSL）通过设计代理任务从大规模未标注

中国知网 https://www.cnki.net

数据中挖掘监督信息，利用这些信息训练网络以获取适用于下游任务的判别性表征[191]。典型代理任务包括图像拼图[192]、内容预测[193]、图像旋转预测[194]、图像修复[195]和图像着色[196]等，旨在促使模型学习语义关联特征而非浅层不变性表征。当前，对比学习作为SSL的特殊范式，已在自然图像处理领域展现出与监督学习相媲美的性能[197]，其通过缩减同一实例不同视图间的距离并增大不同实例间的距离，实现了对相似实例的吸引及对不同实例的排斥。此外，部分对比学习方法[198–201]通过单实例双视图增强策略在无需负样本约束条件下仍取得显著效果，同时采用梯度停止[199]、互相关矩阵[200]和白化技术[201]等防止模型或维度崩塌，并通过集成MAE[202]、聚类[203–205]及mixup[190,206]等策略提升模型鲁棒性。SSL在自然图像领域的成功推动了其在医学图像分析中的应用[203,204]，目前已成功应用于CT分类[207]、MRI分割[208]和WSI检索[203]等任务，主要采用SimCLR[197]、MoCo[209]和BYOL[198]等通用对比方法，或结合特定预训练任务[210]及其他技术（例如聚类[203–205]和mixup[190,206]）来学习医学图像的表征。这表明SSL在医学图像分析领域的应用是可行且有效的。因此，本研究尝试将SSL引入CLE图像分析。然而，现有SSL驱动的CLE图像分析方法[115,131,190]普遍采用最初为自然图像设计的增强策略，这常常忽略了CLE图像的独特属性，导致特征表征的获取不尽理想。此外，这些方法[115,131,190]通常将为自然图像设计的模型结构引入CLE图像分析领域，这并未能充分考虑CLE图像中存在的大类内方差和小类间方差。针对上述问题，需重点考虑两个方面。在对比学习框架中，通常通过随机增强构建正样本对。然而，现有研究中的随机增强策略未考虑CLE图像的固有特性。例如，CLE图像通常在视场中呈圆形，意味着任何角度旋转的CLE图像都应视为同一实例。此外，由于光纤束的物理结构限制导致成像过程中不可避免地会产生噪声，因此具有不同噪声水平的CLE图像也应被视为同一实例[54]。更进一步，同一类别中的许多CLE图像在内容和形态上存在显著差异，而不同类别的图像在内容和形态上可能高度相似，如图4.1所示。然而，标准对比学习方法[197,209]通过最大化正样本对相似度与最小化负样本对相似度实现特征学习，但这种做法间接地削弱了同一类别中远距离样本之间的吸引力和不同类别的负样本之间的排斥力，导致次优结果。近期研究[211]证实自监督学习的性能，特别是对比学习，高度依赖数据内在特性，因此构建有效的自监督学习CLE图像分析方法必须深度耦合其模态特异性。

本研究提出了一个聚类引导的双对比学习方法CTCL，旨在应对CLE图像存在的显著类内异质性与细微类间差异问题。该框架通过进行特征空间内的语义相似度约束

中国知网 https://www.cnki.net

与类别一致性约束，动态筛选与实例语义相关且类别匹配的样本，同时滤除类别无关干扰样本，从而提升视觉表征的判别性。如图4.1（d）所示，相较于传统对比学习依赖单一正负样本对的优化策略，本研究从实例级和簇级两个维度出发，通过协同利用语义相关且类别一致的样本，以实现类内紧凑性与类间可分性。针对CLE图像的固有特性，本研究将任意角度旋转的CLE图像以及有无Voronoise和AWGN的CLE图像分别视为同一实例，以此有效增加视觉多样性并增强语义表征的鲁棒性，如图4.2所示。此外，本研究采用了期望最大化算法对CTCL进行迭代优化，包括E步通过K-means聚类估计原型中心和M步优化CTCL损失函数。为了验证该方法的有效性，本研究在线性评估和小样本分类等下游任务中，对CTCL预训练模型进行了全面评估。

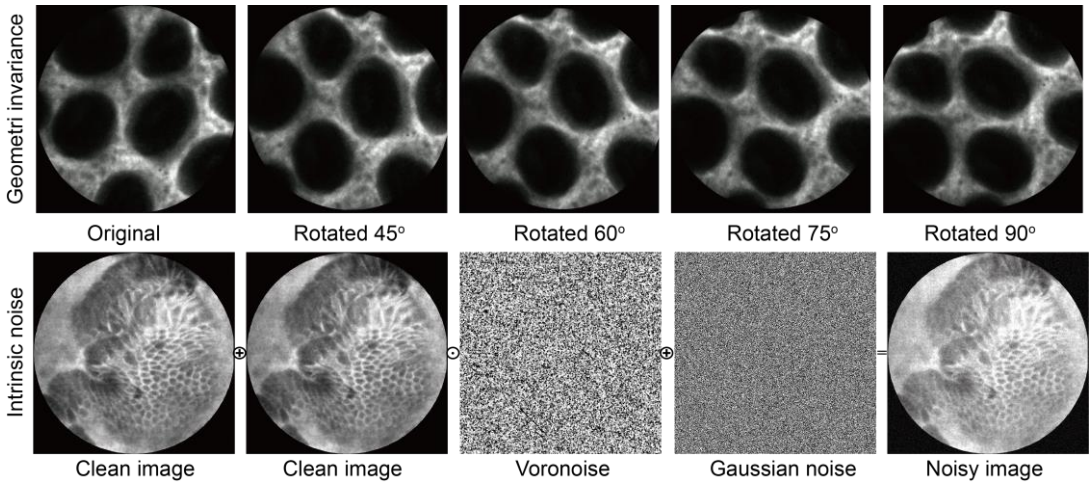


图4.2 CLE图像的固有特性

4.2 聚类引导双对比学习方法

4.2.1 正样本对构建

受近年来对比学习[197,199,205]发展的启发，本研究通过数据增强构建正样本对。具体来说，给定输入图像集合 x，分别从两个数据增强集合 τ 和 τ' 中随机采样两组增强算子并分别作用于 x，以生成两个具有相关性的增强实例 $x_p = \tau(x)$ 和 $x_k = \tau'(x)$。现有研究[197,205]表明，数据增强策略的选取对于对比学习方法的表征学习具有决定性影响。然而，现有针对自然图像设计的数据增强策略未能充分考虑CLE图像的固有特性。为此，本研究认为其特征空间应具备以下基本属性：

（1）几何不变性。临床采集CLE图像时，操作者会使用探头反复扫描病变组织，以便为临床医生提供准确诊断所需的图像信息。由于组织特征具有扫描方向不敏感性，

中国知网 https://www.cnki.net

经任意旋转或翻转后的图像应具有特征空间的一致性。类似地，在自监督学习过程中对图像进行任意角度旋转或翻转后得到的样本仍应视为同一实例，如图4.2所示。值得注意的是，在处理自然图像时通常仅通过90°整数倍旋转以避免信息丢失，而CLE图像特有的圆形视野使其可接受任意角度旋转而不影响实例一致性。

（2）固有噪声。受光纤束的物理结构限制，导致CLE在成像过程中不可避免地会引入各种噪声。CLE依赖光纤束内的光纤传递图像信号。由于光纤包层无法发送信号，因此生成的初始图像呈现出带有黑色边缘的蜂窝状图案。当前，CLE图像重建算法普遍采用德劳内三角剖分来构建Voronoi图以进行图像插值重建。在这一过程中，每根光纤被视为Voronoi图中的一个单元点（Cell），通过计算各点之间的近似度进行线性插值，以实现图像重建。然而，此方法在重建过程中，会导致独立分布在每根光纤上的噪声也具有Voronoi图的形式，形成Voronoise[54]。此外，CLE成像在采样和传输过程中受到外部环境影响可能会引入AWGN等随机噪声。鉴于此，本研究认为应当将具有不同噪声强度但反映相同组织特征的CLE图像视为同一实例以保留关键特征。

本研究根据构建的正样本对，分别采用参数共享的主干网络和基于指数加权平均机制（Exponential Moving Average,，EMA）更新参数的主干网络从增强样本中提取特征 $h = f(x)$，其中两种主干网络均采用ResNet-18[120]。

4.2.2 双对比学习框架

最近，自监督对比学习方法在计算机视觉领域取得了前所未有的成功[197,209]，这主要得益于设计一个样本量足够大且类别完善的负样本库。然而，该方法在CLE图像分析中的适用性面临显著挑战，主要由于CLE作为新兴的光学成像活检技术，难以构建满足要求的样本库。具体来说，CLE图像数据集中同类样本在形态和内容上呈现显著异质性，而不同类别样本间则存在高度视觉相似性。标准对比学习框架[197,209]通过将单张图像视为正样本，其余图像则被视为负样本以迫使它们与正样本图像进行距离约束。然而，Wang等人[212]指出，尽管该范式能有效缓解模型坍塌问题，但它不可避免地会引发类别冲突，导致最终学习到的表征是次优的，进一步削弱模型的判别性。

为了缓解此问题，本研究提出一种聚类引导的双对比学习框架CTCL，通过设计实例级对比（Instance-Level Contrastive，ILC）和簇级对比（Cluster-Level Contrastive，CLC）双模块，以优化标准对比学习范式。如前所述，假负样本可能会影响标准对比

中国知网 https://www.cnki.net

学习方法的性能。因此，在实例级对比模块中采用非对比学习架构[198,199]，通过最小化同一实例的两个不同增强视图之间的距离实现特征学习，无需构建存储负样本的存储库或队列，$D^*(x,x_+)=\min[D(x,x_+)]$，其中 $D(\cdot)$ 表示任意距离度量函数。受到Deepcluster[213]启发，所提出的簇级对比模块旨在获取具有判别性的聚类原型中心。该模块鼓励簇内所有样本尽可能靠近其质心，同时迫使该原型中心与其他原型中心保持尽可能远的距离，即迫使原型中心内的样本与其他原型中心的样本具有尽可能低的相似性，以有助于增强模型对不同类别特征的判别能力，从而提升学习效率和表征质量。

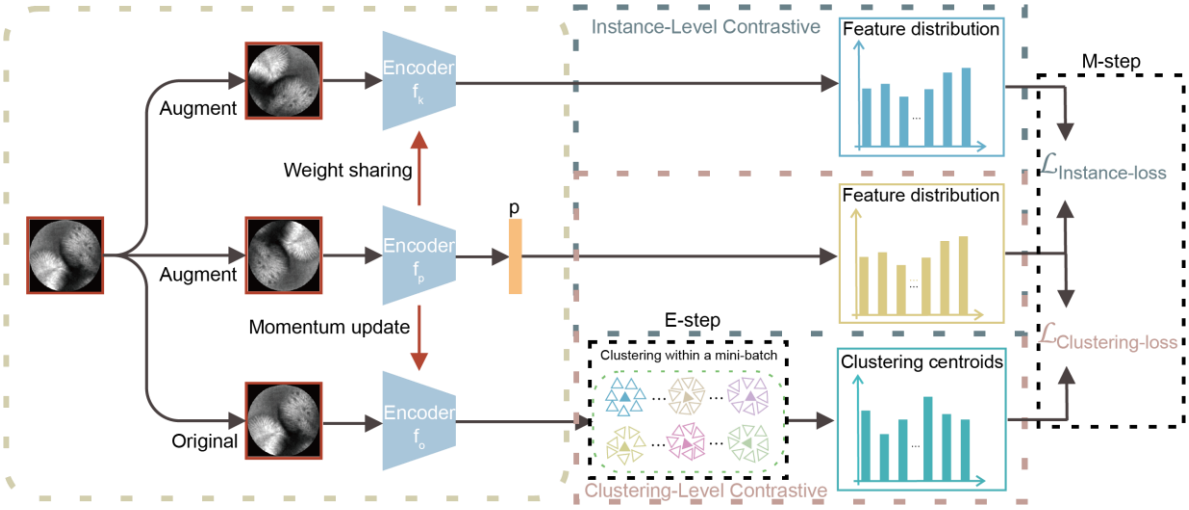


图4.3 聚类引导的双对比学习框架CTCL的结构图

本研究提出的CTCL框架由主干网络、实例级对比模块和簇级对比模块构成，其结构如图4.3所示。具体来说，首先通过数据增强构建正样本对，并利用主干网络将其映射至潜在的特征空间。然后，ILC和CLC分别进行实例级和簇级对比学习，并通过端到端期望最大化算法对CTCL进行优化：

$$L_{total}=L_{ILC}+L_{CLC} \tag{4.1}$$

其中 L_{ILC} 和 L_{CLC} 分别表示ILC和CLC的损失函数。值得指出的是，本研究未在优化过程中引入任何动态平衡因子，仅通过简单直接相加就能取得显著效果。关于期望最大化算法的优化细节将在4.2.3节进行详细阐述。

（1）实例级对比模块。一般来说，对比学习的核心目标在于最小化正样本对之间的距离，并最大化负样本对之间的距离[197]。理想情况下，同类别样本应被视为正样本对，而不同类别的样本则应被视为负样本对。然而，由于缺乏先验的标签信息，通常会将同一样本的不同数据增强视图视为正样本对，同时通过随机采样构建负样本对，这可能导致同类别样本被误认为负样本，从而获取次优的特征表示。为此，本研

中国知网 https://www.cnki.net

究采用非对比学习范式，仅需对同一样本执行两次随机增强，无需负样本存储库或者队列。具体来说，对于包含N张CLE图像$\{x_1,\cdots,x_i,\cdots,x_N\}$的训练批次，本研究首先对每张样本$x_i$分别进行两次随机数据增强以获得$x_{ip}$和$x_{ik}$，随后通过主干网络$f_p$和$f_k$分支分别将其编码至高级语义空间$h_{ip}=f_p(x_{ip})$和$h_{ik}=f_k(x_{ik})$。其中，$f_p(\cdot)$和$f_k(\cdot)$具有相同的参数与结构。需特别说明的是，训练过程中仅对$f_p(\cdot)$分支相关部分参数进行梯度更新，且x_{ip}与x_{ik}的位置可互换。然而，由于直接计算h_{ip}和h_{ik}之间的相似性会导致信息丢失，为此本研究引入了投影头$g_p(\cdot)$和$g_k(\cdot)$，通过两个非线性层将其分别投影至另一个空间$y_{ip}=g_p(h_{ip})$和$y_{ik}=g_k(h_{ik})$。此外，为了使$f_p(\cdot)$分支产生的特征表示更好的匹配$f_k(\cdot)$分支，引入一个预测器$P(\cdot)$用于将y_{ip}转换为$z_{ip}=P(y_{ip})$。最后，基于负余弦相似性来度量y_{ik}与z_{ip}之间的距离：

$$D(y_{ik},z_{ip})=-\frac{y_{ik}z_{ip}}{\|y_{ik}\|\|z_{ip}\|},i\in[1,N]. \tag{4.2}$$

通常，通过最小化上述相似性度量函数以实现y_{ik}与z_{ip}之间的特征分布对齐，其相应的损失函数L_{ILC}表示如下：

$$L_{ILC}=\frac{1}{N}\sum_{i=1}^{N}D(y_{ik},z_{ip}), \tag{4.3}$$

L_{ILC}计算批次内所有样本对的距离并取均值，以有效度量y_{ik}与z_{ip}之间的对齐程度，从而促进模型学习一致性的特征表示。

（2）簇级对比模块。CLE图像数据集中存在同类别图像在内容和形态上呈现显著差异，而不同类别图像在内容和形态上却表现出高度相似性。在特征空间中，同类别样本应聚集，而不同类别样本应分散。因此，在构建相似样本对时，x应与更多的同类别样本构成相似对，而不是类似于标准对比学习中仅通过对同一图像进行两次随机增强来构建相似对。对于聚类而言，各原型/簇应具备良好的可分性。假设数据集包含K个簇（K是预先设定的已知值），且假定每个样本仅属于其中一个簇。基于此，本研究提出一种改进的对比学习策略，即通过构建簇语义相关的跨图像同类样本对。该策略不仅增加了相似对的多样性，还缩小了同类图像之间的距离，同时扩大了不同类别之间的距离。如图4.3所示，除了$f_p(\cdot)$和$f_k(\cdot)$分支外，本研究还引入了第三个分支$f_o(\cdot)$。该分支直接输入未经数据增强的x，记为x_o。$f_o(\cdot)$与$f_k(\cdot)$具有相同的结构但参

中国知网 https://www.cnki.net

数不同，其中 $f_o(\cdot)$ 的参数通过EMA进行更新：

$$\theta_o = m\theta_o + (1-m)\theta_k \tag{4.4}$$

其中 θ_o 和 θ_k 分别表示 $f_o(\cdot)$ 与 $f_k(\cdot)$ 参数，并且 $m \in [0,1)$ 为EMA的平滑权重。

与RetCCL[203]采用存储库来存储负样本特征及计算原型中心不同，本研究直接对 $f_o(\cdot)$ 分支的批次特征向量进行在线聚类。通过将聚类所得的原型中心特征向量作为锚点，进而与同一簇内样本在 $f_p(\cdot)$ 分支上的特征向量构建相似对。该策略直接依赖当前批次的数据，有效增强了模型对数据特征的学习和动态适应能力。通过将原始样本 x 作为锚点，CTCL方法能够实现跨样本构建更多的相似对，在提升类内紧凑性和类间分离性的同时，相较于仅考虑 $f_p(\cdot)$ 和 $f_k(\cdot)$ 分支的增强样本对的传统方法，展现出更强的稳定性和可靠性。然而，考虑到训练初期聚类准确性可能未达到预期水平，CLC模块将在学习率的预热阶段[214]结束后加入训练过程，从而确保聚类过程能有效捕获语义一致的同类样本。

对于输入到 $f_o(\cdot)$ 分支的CLE图像集合 $\{x_{1o},\cdots,x_{io},\cdots,x_{No}\}$，其无需进行任何数据增强，直接将图像输入至该分支以获取相应的特征表示 $h_{io} = f_o(x_{io})$。随后，采用与 $g_k(\cdot)$ 结构一样但参数不同的投影头 $g_o(\cdot)$，将所得特征表示 h_{io} 映射至另一个潜在空间，即 $y_{io} = g_o(h_{io}), i \in [1,N]$。为了增强特征空间中同类别样本分布的紧密性，本研究采用K-means对 y_{io} 进行聚类，获取K个原型中心的特征向量 $C = Kmeans(y_{io}), i \in [1,N]$。基于此，将原型中心特征向量 $\{c_1,\cdots,c_k,\cdots,c_K\}$ 与同一批次中归属对应簇的样本构建相似对。具体来说，通过 $f_p(\cdot)$ 分支编码与原型中心 c_k 相关联的簇包含的m个样本 $\{x_1,\cdots,x_l,\cdots,x_m\}$，以获取相应的特征表示 $\{z_{1p},\cdots,z_{lp},\cdots,z_{mp}\}$，并分别与原型中心 c_k 的特征向量构建相似对。最后，采用余弦相似性来度量原型中心 $c_k, k \in [1,K]$ 与 $z_{lp}, l \in [1,m]$ 之间的距离，以强化同类样本在特征空间中的紧凑性：

$$D(c_k, z_{lp}) = -\frac{c_k z_{lp}}{\|c_k\|\|z_{lp}\|}. \tag{4.5}$$

基于上述距离度量准则，从而最小化同一簇内所有样本与原型中心之间的距离，其簇级对比损失 L_{CLC} 表示为：

$$L_{CLC} = \frac{1}{N}\sum_{k=1}^{K}\sum_{l=1}^{m} D(c_k, z_{lp}), \tag{4.6}$$

中国知网 https://www.cnki.net

其中K和m分别表示簇的数量和每个簇中的样本数（各簇的样本数动态变化）。值得注意的是，每个样本唯一对应一个簇。通过最小化L_{CLC}以促使簇内样本尽可能向原型中心聚合，同时间接地强迫不同原型中心相互远离，从而增强了不同类别样本间的可分性。此外，本方法与同类研究的核心差异将在4.3.6节深入探讨。

伪代码4.1

输入：无标签训练数据集$D=\{x\}$；

主干网络$f_p(\cdot)$、$f_k(\cdot)$和$f_o(\cdot)$；

投影头$g_p(\cdot)$、$g_k(\cdot)$和$g_o(\cdot)$；

预测器$P(\cdot)$；

输出：主干网络$f_p(\cdot)$

repeat
  E步：通过K-means聚类更新批次数据中每个样本的c_k
  M步：**repeat**
    for 小批次中的每个x_i **do**
      对x_i进行两次随机数据增强获得x_{ip}和x_{ik}
      采用公式4.2计算实例级相似度
      采用公式4.5计算簇级相似度
      计算公式4.3获得L_{ILC}
      计算公式4.6获得L_{CLC}
    end
    计算公式4.1获得L_{total}
    采用SGD优化器更新$f_p(\cdot)$、$g_p(\cdot)$和$P(\cdot)$；
    通过$f_p(\cdot)$和$g_p(\cdot)$的参数共享更新$f_k(\cdot)$和$g_k(\cdot)$；
    通过$f_k(\cdot)$和$g_k(\cdot)$的EMA更新$f_o(\cdot)$和$g_o(\cdot)$；
  until 整个数据集迭代完成
until 最大迭代次数

中国知网 https://www.cnki.net

4.2.3 期望最大化优化

通过期望最大化算法对CTCL参数进行优化，其中E步和M步的具体实现过程如下：

（1）E步：此步骤旨在为CTCL估计原型中心 c_k。具体来说，通过对 $f_o(\cdot)$ 分支提取的特征进行K-means聚类实现。该设计基于其直接编码原始输入 x，可生成稳定且一致的聚类结果。尽管CTCL需要对批次数据进行额外的K-means聚类以获取原型中心 c_k，但得益CTCL的批次规模相对较小，其相关计算开销和额外内存需求均可忽略不计。因此，CTCL在保证原型中心稳健性的同时，未引入显著计算负担，从而有效提升模型的整体性能与鲁棒性。

（2）M步：此步骤主要更新并优化由 L_{ILC} 和 L_{CLC} 构成的损失函数。参数更新过程通过以下方式实现：

$$\begin{aligned}\theta^p &\leftarrow \theta^p - \alpha\left(\frac{\partial \mathcal{L}_{ILC}}{\partial \theta} + \frac{\partial \mathcal{L}_{CLC}}{\partial \theta}\right) \\ \varphi &\leftarrow \varphi - \alpha\left(\frac{\partial \mathcal{L}_{ILC}}{\partial \varphi} + \frac{\partial \mathcal{L}_{CLC}}{\partial \varphi}\right)\end{aligned} \tag{4.7}$$

其中 θ^p 和 φ 分别表示主干网络和预测器 $P(\cdot)$ 的参数，α 为学习率。值得注意的是，该更新策略适用于具有 N 个训练样本的批次数据。CTCL的训练步骤如伪代码4.1所述。

4.2.4 小样本学习

在小样本学习中，本研究采用基于自监督学习获取的预训练模型，并基于片段式训练范式的小样本方法对模型进行微调。此方法旨在使模型能够处理CLE场景下的数据量限制和稀缺疾病分类任务，同时验证其泛化性。具体来说，小样本学习数据集可表示为$D=\{(x_1, y_1), (x_2, y_2), \ldots, (x_N, y_N)\}$，包含$N$个样本且每个类别具有若干样本。在训练阶段，首先从数据集中随机选择C个类，并从每个类别中选取K个样本（共$C\times K$个样本）构成支持集（Support Set，S）。随后，从这C个类的剩余数据中选取m个样本组成查询集（Query Set，Q）。由此构建的元学习任务要求模型能够从支持集的$C\times K$个样本中学习如何判别C个类的实例，该任务被称为C类K样本问题（C-Way K-Shot问题）。

本研究通过对预训练模型进行微调，使同一类别的所有样本能够映射到支持集嵌入空间中的一个均值向量，以此作为每个类别的原型中心[215]，类别c的原型中心P_c为：

中国知网 https://www.cnki.net

$$P_c = \frac{1}{|S_c|} \sum_{(x_i, y_i) \in S} f(x_i) \tag{4.8}$$

其中S_c表示类别c的支持集样本集合，$f(\cdot)$是通过预训练获得的模型。随后小样本分类问题转化为嵌入空间的最近邻问题，查询集Q中的样本q在所有类别上的距离分布为：

$$p(y=c \mid q) = \frac{\exp\left(-d\left(f(q), P_c\right)\right)}{\sum_{c'} \exp\left(-d\left(f(q), P_{c'}\right)\right)} \tag{4.9}$$

其中$d(\cdot)$表示欧氏距离度量准则。通过上式可以计算样本q与各类别原型中心P_c之间的距离分布。因此，小样本学习的损失函数$\mathcal{L}_{\text{few-shot}}$为：

$$\mathcal{L}_{\text{few-shot}} = d\left(f(q), P_c\right) + \log \sum_{c'} \exp\left(-d\left(f(q), P_{c'}\right)\right) \tag{4.10}$$

通过最小化$\mathcal{L}_{\text{few-shot}}$使模型有效优化嵌入空间的距离分布，从而提升小样本分类的性能。

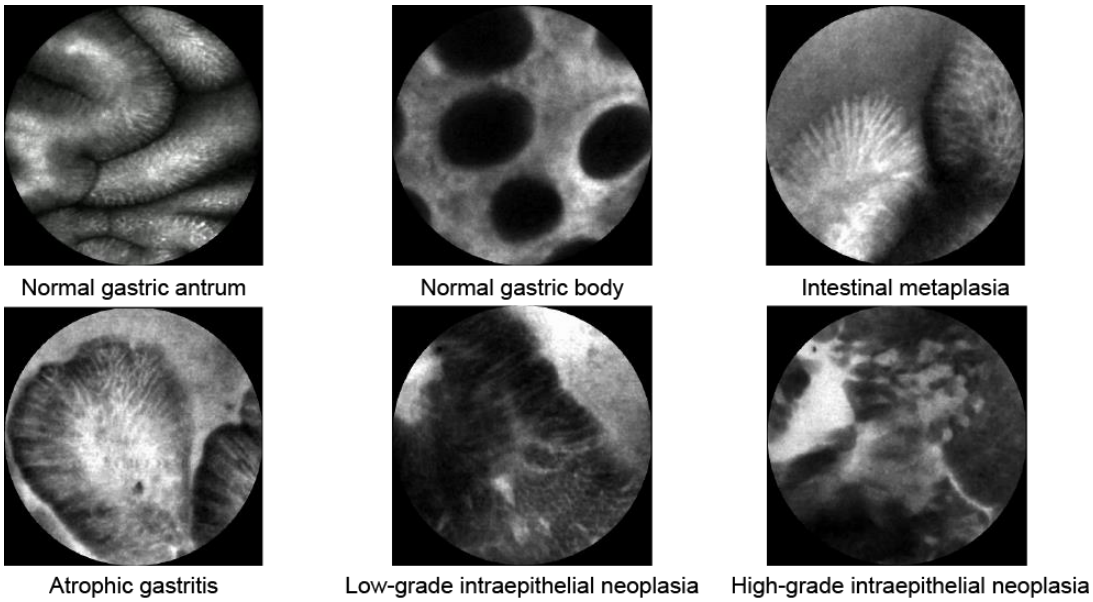


图4.4 SSL_CLE数据集中每个类别的典型示例，依次为正常胃窦（Normal gastric antrum）、正常胃体（Normal gastric body）、肠上皮化生（Intestinal metaplasia）、萎缩性胃炎（Atrophic gastritis）、低级别瘤变（Low- grade intraepithelial neoplasia）和高级别瘤变（High-grade intraepithelial neoplasia）

4.3 实验分析

4.3.1 数据集

本研究采用SSL_CLE和FS_CLE两个消化道CLE图像数据集进行实验。SSL_CLE

中国知网 https://www.cnki.net

数据集由两家医院提供，涉及86名患者共2369张图像。与提供SSL_CLE数据集的医院不同，FS_CLE数据集由另外两家医院提供。这些数据集的标注由具备丰富临床经验的消化内镜专科医师完成，标注依据统一的医学标准，确保了标签的准确性与一致性。图像标签判定主要依据细胞与组织结构的形态学特征，如腺体轮廓的完整性、腺体密度以及排列形态等指标。这些结构性指标与前述章节中腺体分割任务所关注的解剖区域在空间分布和形态特征上具有一致性，可为图像的判读提供结构依据，从而提升判定的一致性和判读效率。

（1）SSL_CLE数据集。SSL_CLE数据集是采用团队自研的CLE系统从86名患者中采集的，共包含2369张图像。这些图像包括肠上皮化生（405张）、低级别瘤变（277张）、高级别瘤变（167张）、萎缩性胃炎（568张）、正常胃窦（627张）以及正常胃体（325张）。各类型的典型图像见图4.4。训练图像取自70名患者，而测试图像来自另外16名患者，以防止信息泄露，训练集和验证集图像均选自同一组患者，测试集图像则选自不同的患者。为了确保实验结果的可重复性，本研究重复进行了多次实验。

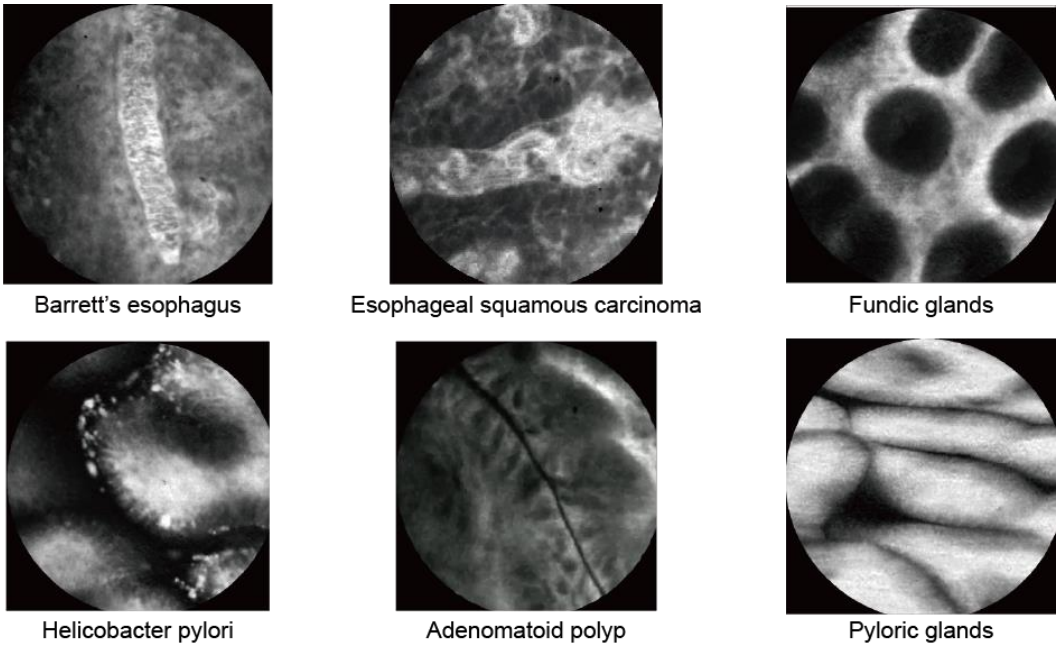


图4.5 FS_CLE数据集中部分类别的典型示例，依次为巴雷特食管（Barrett's esophagus）、食管鳞癌（Esophageal squamous carcinoma）、胃底腺（Fundic glands）、幽门螺杆菌（Helicobacter pylori）、腺瘤样肠息肉（Adenomatoid polyp）和幽门腺（Pyloric glands）

（2）FS_CLE数据集。FS_CLE数据集是由团队自研的CLE系统从20名患者中收集而来，包括巴雷特食管、管状腺瘤、食管鳞癌、幽门腺、增生性肠息肉、腺瘤样肠息肉、胃底腺、幽门螺杆菌、食管鳞状上皮等14个不同类别，每个类别大约包含40个样本。值得注意的是，FS_CLE数据集的类别与SSL_CLE数据集在类别构成上存在显

中国知网 https://www.cnki.net

著差异。图4.5展示了FS_CLE中部分类别的典型样本。该数据集主要用于小样本学习的下游任务，其中训练集涵盖8个类别，测试集包含6个类别。此外，为确保数据独立性，本研究避免从同一患者收集属于不同类别的样本，且训练集和验证集图像均选自同一组患者。

4.3.2 实验设置

（1）主干网络。由于SSL_CLE和FS_CLE都是小规模数据集，为了与其他SSL方法进行公平对比，本研究采用ResNet-18[120]作为编码器（$f_p(\cdot)$、$f_k(\cdot)$和$f_o(\cdot)$），并移除了全局平均池化后的所有层。投影头（$g_p(\cdot)$、$g_k(\cdot)$和$g_o(\cdot)$）和预测器$P(\cdot)$的结构分别采用FC-BN-ReLU-FC-BN-ReLU-FC-BN和FC-BN-ReLU-FC架构。此设计有助于有效降低模型参数量和避免过拟合，从而在不同数据集上实现更为稳定和公正的对比。

（2）实验细节。与先前的研究类似[199,209]，本研究采用随机梯度下降（Stochastic Gradient Descent，SGD）优化器和余弦衰减学习率策略对所有方法进行800个周期的训练，其中前10个周期用于学习率预热。基础学习率默认设定为0.02，并根据批次大小线性调整（学习率=基础学习率×$\frac{\text{批次大小}}{\text{默认批次大小}}$）。由于GPU内存限制，批次大小和默认批次大小均设为128。考虑到基于自然图像（如ImageNet[110]）的预训练模型与CLE医学图像在强度分布上存在差异，本研究选择从头开始训练模型。CTCL模型的其他参数包括：更新$f_o(\cdot)$分支的EMA系数m设为0.995，SGD的权重衰减为$5e^{-4}$，动量为0.9。根据数据集的类别，本研究设置簇数量K为6。所有实验均使用PyTorch[160]在NVIDIA RTX5000 GPU上完成。

（3）CTCL自监督学习设置。本研究采用与SimCLR[197]类似的数据增强策略，包括使用224×224且裁剪比例为0.2,1.0的随机裁剪（ResizedCrop）、颜色抖动（ColorJitter）、水平/垂直翻转（HorizontalFlip/VerticalFlip）以及高斯模糊（GaussianBlur）。考虑到CLE图像是从伪彩色视频序列帧中提取获得的，本研究未采用灰度变换（Grayscale）。此外，本研究还增加了以0.8概率进行任意角度旋转增强，以及以0.5概率添加由Voronoise和AWGN组成的噪声增强，分别对应第4.2.1节中提到的几何不变性和固有噪声。网络架构设计严格遵循SimSiam[199]，其中投影头（$g_p(\cdot)$、$g_k(\cdot)$和$g_o(\cdot)$）和预测器（$P(\cdot)$）分别设计为FC-BN-ReLU-FC-BN-ReLU-FC-BN和FC-BN-ReLU-FC结构，

中国知网 https://www.cnki.net

其投影维度和隐藏层维度分别设为2048和512。

在CTCL的下游任务中，本研究采用线性评估协议在SSL_CLE数据集上对CTCL预训练模型进行CLE图像分类评估。评估过程包括在冻结的预训练模型 $f_p(\cdot)$ 上训练一个或两个全连接层的线性分类器。该分类器采用动量为0.9、权重衰减为0的SGD优化器，训练100个周期，初始学习率设为0.01，并分别在第60个和80个周期将学习率减半。此外，本研究还采用与SimSiam[199]相同的数据增强策略，包括224×224的随机裁剪以及水平/垂直翻转。值得注意的是，无论采用一个全连接层还是两个全连接层，实验设置均保持完全一致。

（4）CTCL小样本学习设置。为了评估CTCL的鲁棒性和可迁移性，本研究在FS_CLE数据集上进行小样本学习下游任务。实验严格遵循Snell等人[215]的设置，将CTCL预训练模型作为基学习器，其输出维度和学习率分别设置为512和0.0005。所有实验均采用Adam优化器进行50个训练周期，且每10个周期将学习率减半。在训练和测试阶段，每个episode中各类别均包含10个查询样本用于模型评估。

表4.1 线性评估协议下各种方法在SSL_CLE数据集上的结果

方法	周期	一层分类器		两层分类器	
		线性评估	置信区间	线性评估	置信区间
Supervised[120]	100	72.44%	0.6832, 0.7658	74.36%	0.7034, 0.7838
AMDIM[216]	1000	67.56%	0.6322, 0.7188	70.32%	0.6608, 0.7454
MoCo[209]	800	67.63%	0.6331, 0.7195	72.51%	0.6838, 0.7663
SimSiam[199]	800	68.22%	0.6392, 0.7253	71.11%	0.6692, 0.7528
MixSiam[206]	800	62.22%	0.5774, 0.6671	62%	0.5752, 0.6648
TCL[217]	1000	71.18%	0.6699, 0.7536	73.39%	0.6931, 0.7747
SRCL[204]	800	68.07%	0.6377, 0.7237	71.18%	0.6699, 0.7535
Feature-level MixSiam[190]	800	74.33%	0.7031, 0.7835	76.89%	0.7299, 0.8078
CTCL	800	75.60%	0.7162, 0.7958	78.45%	0.7465, 0.8225

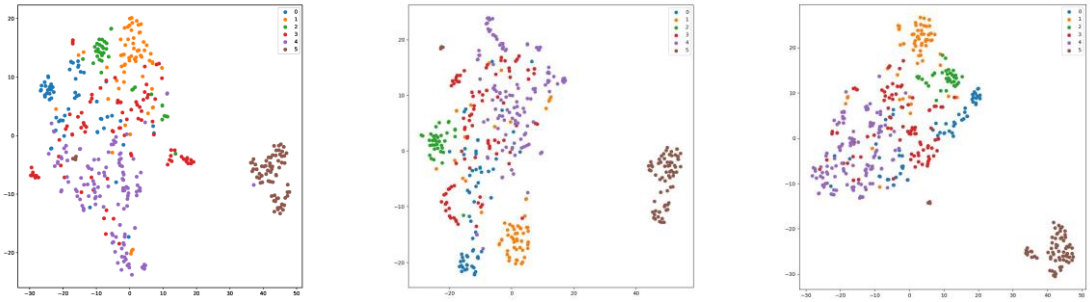
4.3.3 模型评估

（1）线性评估。本节采用线性评估协议在SSL_CLE数据集上系统比较CTCL模型与现有先进分类方法的性能差异。为了进行全面评估，对比方法包括：i) 监督学习方法[120]；ii) 对比学习方法[204,209]；iii) 非对比学习方法[199,206,216]；iv) 基于聚类的对比学习方法[217]；v) 专为CLE分类设计方法[190]。为了确保对比实验的公平性，除SRCL[204]

中国知网 https://www.cnki.net

因代码未公开需依据论文描述复现外，其余方法均基于原论文提供的代码在SSL_CLE数据集上重新实现，并尽最大努力复现相关结果。

基于SSL_CLE数据集的线性评估协议实验结果如表4.1所示。实验结果表明，无论是采用一个全连接层还是两个全连接层，CTCL均实现了显著的性能提升，这验证了该方法通过聚类实现具有较高语义相关性和类别一致性的样本进行更有效对齐方面的优势。具体来说，相较于非对比学习方法[199,206,216]，CTCL在一个全连接层和两个全连接层的评估中的性能均提升了约7%。同时，与监督学习方法[120]相比，CTCL也获得了约3%的性能提升。值得注意的是，CTCL在缓解假负样本引起的类别冲突问题上表现突出，其性能较对比学习方法[204,209]提升了约6%。虽然专为CLE设计的Feature-level MixSiam[190]取得显著改进，但传统通用表征学习方法仍难以有效适应CLE环境。尽管MixSiam[206]和Feature-level MixSiam[190]作为多分支对比学习方法，在图像空间和特征空间使用混合样本产生更具挑战性的样本或特征，但它们并未显著改善类内紧凑性和类间分离性以构建信息丰富的表征。相比之下，CTCL通过针对现有问题的处理，在CLE分类中带来了实质性的改进。此外，CTCL显著优于基于聚类的对比学习方法[217]和传统对比学习方法[204,209]，进一步验证了其在CLE图像分析中的有效性。这些结果表明，CTCL学习到的表征在判别性和鲁棒性方面均优于其他方法。



SimSiam　　Feature-level MixSiam　　CTCL

图4.6 SSL_CLE数据集上非对比学习方法、专为CLE设计的方法以及CTCL特征分布的t-SNE可视化分析结果

模型预测的置信度估计是通过量化预测的确定性或置信水平来进行的，这在医疗等高风险领域提高预测结果的可信度尤为关键。因此，本研究对CTCL模型进行了95%置信区间的统计分析，结果显示其性能始终优于其他方法。同时，本研究还利用t-SNE对非对比学习方法、专为CLE设计的方法以及CTCL的特征分布进行可视化分析，如图4.6所示。这种直观的分析揭示了CTCL在类内紧凑性和类间可分性方面的优越性，

中国知网 https://www.cnki.net

不仅进一步证实了该方法在特征判别性上的优势，并展示了CTCL模型的高稳健性和良好的可迁移性。

表4.2 各种方法在FS_CLE数据集上两种标准分类任务的结果

方法	5-Way 1-Shot	5-Way 5-Shot
ProtoNet+[215]	60.75%	72.62%
DN4[218]	61.59%	71.63%
SSLFL[219]	62.78%	73.64%
Feature-level MixSiam[190]	63.62%	74.37%
CTCL	64.12%	77.37%

（2）小样本学习。现有研究[219]表明，预训练模型对小样本学习具有显著促进作用。为了评估CTCL预训练模型的泛化性，本研究基于小样本学习下游任务进行实验验证。具体来说，本研究在FS_CLE数据集上进行了两种标准的小样本学习分类任务评估（5-Way 1-Shot和5-Way 5-Shot），并将其与现有方法（如ProtoNet+[215]、DN4[218]、SSLFL[219]和Feature-level MixSiam[190]）进行对比分析。为了确保实验的公平性，所有对比实验方法均采用原论文提供的代码在FS_CLE数据集上进行复现。如表4.2所示，CTCL模型在两种任务中均表现出显著的性能提升，这一结果有力证实了该方法具有优异的泛化性。

表4.3 CTCL各种模块在SSL_CLE数据集上的消融实验结果

方法	几何不变性	固有噪声	准确率
CTCL（无CLC）			64.16%
CTCL（无ILC）			68.31%
CTCL（原始）			69.01%
CTCL+几何	√		73.21%
CTCL+几何+固有	√	√	75.60%

4.3.4 消融实验

本节将通过详细的消融研究以深入探讨CTCL在CLE图像分类中的有效性。所有消融实验均在SSL_CLE数据集上进行。

（1）CTCL各种模块的有效性。为了验证CTCL模型中各核心模块的有效性，本研究设计了一系列消融实验。首先，建立基线模型分别仅保留实例级对比模块（CTCL（无CLC））或簇级对比模块（CTCL（无ILC））。随后，提出融合实例级和簇级对

中国知网 https://www.cnki.net

比模块（CTCL（原始）），并依次引入几何不变性（CTCL+几何）及固有噪声特性（CTCL+几何+固有）。详细的消融实验结果如表4.3所示。相较于基线模型（CTCL（原始）），融合实例级和簇级对比模块的CTCL（原始）模型表现出显著的性能提升，从而验证了双模块协同优化的有效性。具体来说，将实例级和簇级对比模块整合到CTCL模型中，使得模型的准确率（TOP-1）提高了约1%。同时，进一步引入几何不变性后（CTCL+几何），模型性能相较于CTCL（原始）提升了约4%。最后，整合固有噪声特性（CTCL+几何+固有），与CTCL+几何相比，其模型性能提升了约2%，如表4.3最后一行所示。实验结果充分展示了各个核心模块的重要性及其对模型整体性能的贡献。

表4.4 不同簇组数量*K*在SSL_CLE数据集上的分类结果

*K*值	6	8	10	15	20	25
准确率	75.60%	75.33%	74%	74%	74.45%	74.67%
置信区间	71.62,79.58	71.35,79.32	69.95,78.05	69.95,78.05	70.41,78.47	70.65,78.69

（2）簇数量*K*的影响。为了构建出更多同类别样本的相似对，以优化类内紧凑性和类间差异性，本研究引入了 $f_o(\cdot)$ 分支以将当前批次中的样本聚类成*K*个簇组。*K*值作为训练前需预先定义的超参数，其取值对模型性能具有潜在影响。为了探索*K*值对CTCL模型性能的影响，本研究开展了一系列实验，实验结果如表4.4所示。实验结果表明，CTCL的性能对簇组数量*K*的变化表现出较强的鲁棒性，但过度聚类可能会导致性能略有下降。基于实验验证和经验分析，本研究将*K*值设定为6，因其在实验中表现出最优性能。

4.3.5 可视化结果

为了深入理解不同方法的特征表达能力，本研究采用基于PyTorch的Grad-CAM方法[220]来生成类激活图（Class Activation Maps，CAM）。如图4.7所示，所选图像来自SSL_CLE数据集，涵盖不同病理类别，并且这些图像在模型训练过程中未被使用过。图中第一列为原始图像，后续各列依次展示了使用SimSiam[199]、Feature-level MixSiam[190]和CTCL生成的CAM以及相应的真实标签。这些CAM不仅揭示了不同方法对特定区域的响应，还有助于评估其在临床应用中的可解释性和可靠性。值得注意的是，CLE图像的病变类型诊断主要依赖于腺体和细胞的结构变化。因此，在标注真实标签时，第三章所提出的腺体分割方法提取图像中腺体与细胞区域的边界和形态特

中国知网 https://www.cnki.net

征可被用作重要的辅助依据，从而对腺体的形状、排列方式、大小分布以及细胞结构等方面进行更为细致和一致的分析与标注。定量分析表明，SimSiam和Feature-level MixSiam的CAM与感兴趣区域或异常区域的对齐存在偏差，而CTCL的CAM展现出与这些区域的高度相关性。例如，第二行展示的消化道低级别瘤变主要体现为腺体结构异常及管腔形态改变。SimSiam和Feature-level MixSiam的CAM在与异常区域的对齐上表现不佳，而CTCL的CAM则明显展示了与异常区域的高重叠性。这些结果表明，CTCL能够有效地理解图像中的主体空间分布，并为临床诊断消化道肿瘤学习到更具判别性的表征。此外，这些可视化结果进一步提升了对CTCL方法的可解释性，从而有助于提高辅助医疗决策的质量。

4.3.6 讨论

本节将系统阐述CTCL与现有工作[203,204,217]的核心差异及其局限性。CTCL采用非对比学习范式，避免了在实例级和簇级上建立存储负样本的内存库或队列，而现有方法普遍依赖此类显式负样本存储机制，具体差异如下：

（1）与TCL[217]的关系。虽然CTCL的结构与TCL的存在一些相似之处，但CTCL在三个关键方面与TCL有所不同。首先，在网络架构层面，CTCL采用三分支结构，而TCL则使用传统的孪生结构。其次，在优化机制层面，CTCL构建端到端期望最大化框架实现联合优化，而TCL则采用梯度下降以优化参数。最后，在聚类实现层面，CTCL通过辅助分支 $f_o(\cdot)$ 将当前批次中的样本聚类为K个簇组，而TCL则通过两个非线性层将特征映射至M维空间以实现聚类。

（2）与SRCL[204]的关系。CTCL与SRCL的主要区别在于损失函数和优化框架。CTCL通过显式簇级损失将更具语义相关性和类别一致性的样本对齐，而SRCL则依赖可能增加额外内存成本的队列实现此目的。此外，CTCL构建端到端期望最大化框架实现参数优化，而SRCL则采用梯度更新优化参数。

（3）与RetCCL[203]的关系。RetCCL需整个批次样本进行聚类来获取原型中心，并计算簇级的InfoNCE损失，从而应对类间的潜在冲突。相对地，CTCL仅对当前批次样本进行聚类，以获取原型中心，并将这些中心与语义相关且类别一致的样本对齐。此外，RetCCL使用基于实例的InfoNCE损失可能面临假负样本问题，而CTCL采用非对比SimSiam方法可以有效规避此问题。由于RetCCL在整个批次中进行聚类，而CTCL

中国知网 https://www.cnki.net

仅限于当前批次，因此RetCCL的计算复杂度明显高于CTCL。

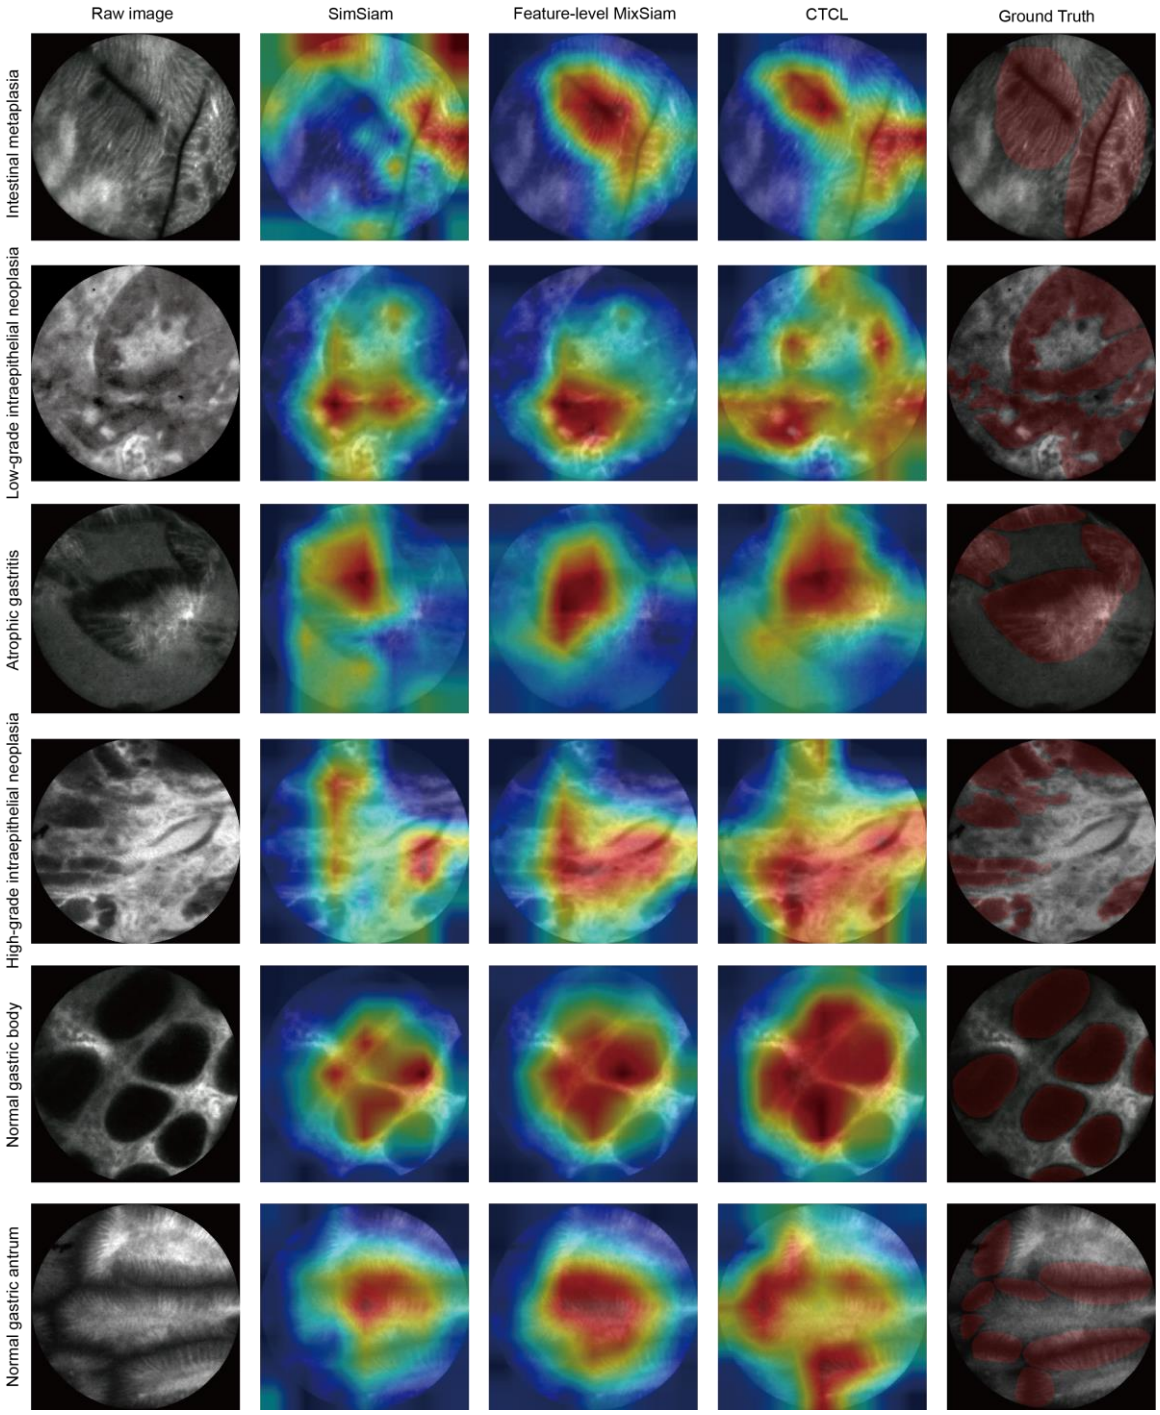


图4.7 各种方法在SSL_CLE数据集上对正常胃窦、正常胃体、肠上皮化生、萎缩性胃炎、低级别瘤变和高级别瘤变六个消化道疾病不同发展阶段的CAM结果。图中第一列为原始图像。从第二列到最后一列依次为SimSiam[199]、Feature-level MixSiam[190]和CTCL的CAM及相应的真实标签

尽管CTCL在医学影像分析中已取得了初步成效，但仍存在若干局限性。首先，现有实验大多基于两个规模较小且病变部位单一的数据集进行验证，为了更全面地评估该方法的通用性，未来需在包含跨中心、多病变类型的大规模医学影像数据库中进

中国知网 https://www.cnki.net

行全面验证。其次，CTCL中的聚类过程可能会导致计算开销和内存需求略有增加。然而，由于CTCL的批处理规模相对较小，且聚类数*K*根据数据集类别设定为6，因此这些额外的计算开销和内存需求可忽略不计。此外，聚类过程可能因伪标签错误而导致生成不准确的样本对。为此，未来计划探索引入基于置信度的自标注损失函数，通过更精确的聚类过程降低伪标签错误率，从而提升对比学习方法的鲁棒性和有效性。

4.4 本章小结

在这项工作中，针对CLE图像的形态学特征和有限视场，本研究提出了一种聚类引导的双对比学习方法CTCL，旨在通过自监督学习方式获取高信息密度和强判别性的视觉表征，从而提升消化道肿瘤诊断的准确性与效率。受传统对比学习存在语义偏差的假设启发，CTCL通过实例级和簇级语义一致性对齐的双重优化机制，显著增强了特征空间的类内聚合度与类间区分度。此外，考虑到CLE的固有特性，本研究进一步提出将任意角度旋转的CLE图像和包含各种噪声的CLE图像分别视为同一实例，以增强训练样本的表征多样性和数据鲁棒性。通过线性评估协议和小样本学习任务的实验验证表明，CTCL模型在两项下游任务中均展现出优异的性能。实验结果显示，与现有自监督学习方法和传统的监督学习基线相比，CTCL所学习的视觉表征在模型鲁棒性和泛化性方面具有显著优势。这些实证结果表明，CTCL可为病理学家提供自动化、快速且精准的辅助诊断工具，有助于全面评估消化道肿瘤的不同发展阶段。

本章工作创新点如下：

（1）本研究提出了一种名为CTCL新颖的自监督学习方法。该方法主要由实例级对比模块和簇级对比模块组成，旨在通过在潜在空间中为每个实例寻找更多语义相似且类别一致的样本，从而实现类间距离最大化和增强类内样本紧凑性。

（2）针对CLE图像的固有属性，本研究提出了将任意角度旋转的CLE图像和包括各种噪声的CLE图像分别视为同一实例，以此增加样本的可变性和多样性。

（3）通过采用EM方法对CTCL进行优化，所提出的方法在多个下游任务中取得了可竞争的性能。与现有的先进自监督学习方法及监督学习方法相比，CTCL展现出更高的鲁棒性和泛化性。

中国知网 https://www.cnki.net

5 基于对比学习与词袋模型的多任务学习图像分类方法

5.1 引言

已有研究尝试采用多模态学习[115,131]与对比学习[221]等策略来应对CLE图像缺乏高质量精准标注这一挑战。然而，CLE图像的内容和形态具有高度异质性，导致现有方法仍难以有效捕捉其语义特征差异，特别是类内差异性和类间相似性，这直接影响下游的CLE图像分析任务[131]，如图5.1所示。此外，通过图5.1的最后一行可以观察到，图像内及跨图像的局部相似区域包含着丰富的组织结构-内容关联特征，但现有方法如CTCL等尚未充分挖掘这些局部相关性。因此，有必要设计一种方法用于有效捕获图像内及图像间局部相似区域的细粒度特征，并通过增强类内紧凑性与类间可分性，进而提升学习无标注CLE图像的判别性表征。

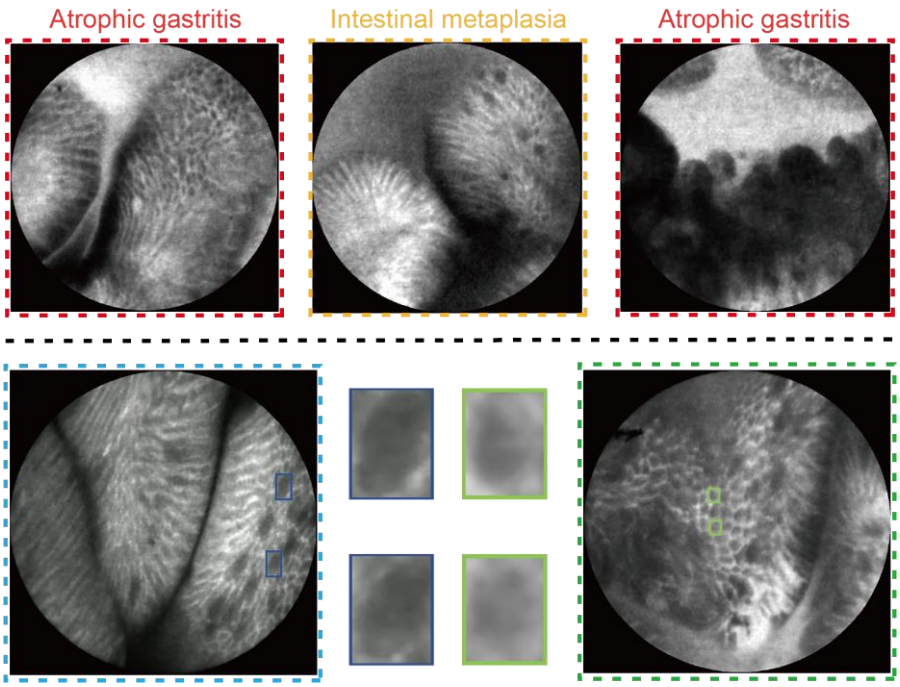


图5.1 消化道病理形态分析聚焦于形态差异与局部相似区域的特征对比。第一行首尾图像虽属同一类别，却在形态与内容层面呈现显著差异；而首行前两图虽分属不同类别，其形态特征与内容构成差异度反而较小。最后一行展示了图像内和图像间具有相似性的局部区域及其关联信息

多任务学习（Multi-task Learning，MTL）已广泛应用于计算机视觉领域，通过共享跨任务知识有效提升了模型的泛化性。研究表明，辅助任务可通过提供正则化约束增强主任务的性能。这些方法通过主任务与辅助任务的协同学习已在医学影像分析中

中国知网 https://www.cnki.net

取得显著成效，成功应用于图像分类[222]、分割[223]和检索[224]等任务。然而，此类方法通常依赖于大量标注数据，导致其在CLE图像分析中难以适用。针对医学影像标注成本高，自监督学习通过设计数据驱动的预训练任务，已证明能够从无标注数据中学习具有判别性的特征，并在MRI图像分割[208]、WSI检索[204]和CT分类[207]等任务中取得了前所未有的成功[204]。尽管现有研究表明SSL框架具备多任务表征学习潜力，但当前医学影像分析领域中的SSL方法[131,190]尚未深入探索辅助任务对主任务性能的影响，特别是在CLE图像分析中，由于组织形态学特征与成像模式的显著特异性，该问题的重要性更为凸显。综上所述，CLE图像分析领域仍缺乏基于SSL的多任务学习方法用于特征提取。

本研究提出了一种结合对比学习与词袋模型的多任务学习方法CB-MTL，旨在更高效地从无标注的CLE图像中提取视觉表征。该框架以对比学习为主任务，通过增强同一样本不同实例间的对齐一致性，学习具有变换不变的图像表征。作为辅助任务的词袋模型则从图像内和图像间的局部相似区域挖掘结构与内容相关的特征，如图5.1底部所示。该辅助任务通过为每张图像生成BoW向量，并借助多个非线性映射预测主任务表征，从而引导对比学习任务学习更为鲁棒的视觉表征。此外，本研究还引入了几何不变性和固有噪声，以增强视觉的多样性并获取更具语义价值的表征。实验结果表明，辅助BoW任务能够有效地为主任务提供正则化，从而提升其在CLE图像分析中的性能。无论在CNN还是Transformer架构中，CB-MTL都表现出优秀的效果，并在不同计算模型中展现出良好的鲁棒性和通用性。本研究期望为相关领域研究者提供新的思路，以开发适用于CLE图像的通用高效视觉表征提取方法。

5.2 多任务学习与词袋模型概述

5.2.1 多任务学习

多任务学习旨在通过跨任务共享领域特定的信息来提升模型的泛化性[225]，该方法通常并行处理主任务和辅助任务，在计算机视觉领域已获得广泛研究与应用[222]。在此过程中，辅助任务有助于模型学习到更多共享的或有益于主任务的鲁棒表征，例如对比学习[222]和图像分割[223]等。大量研究充分证明了辅助任务能够有效提升主任务的性能。经典的多任务学习通常基于监督学习或半监督学习，其主要区别在于辅助任务是否依赖于标注数据。然而，在缺乏完善标注数据的情况下，如何构建一种既能提

中国知网 https://www.cnki.net

升模型效能又具备良好泛化性的多任务学习框架，仍然是一个亟待突破的重要研究课题。本研究认为，基于自监督学习的多任务学习架构可作为潜在解决方案之一。

5.2.2 词袋模型

词袋模型（Bag-of-Words，BoW）作为经典的特征表示方法，广泛应用于自然语言处理[226]和计算机视觉[227,228]领域。在计算机视觉中，该方法通过将图像中多个局部特征的统计信息编码为向量表示，进而有效地描述图像内容[228]。BoW方法已被广泛研究，并通过实验证明其有效性。因此，BoW在过去得到了广泛应用[227,228]，并持续作为当前深度学习方法的重要组成部分[229–231]。具体而言，BoWNet[230]和OBoW[231]通过分别利用预训练教师模型和在线更新教师模型，引导学生模型重建相应的视觉词，从而实现无监督表示学习。受此启发，本研究提出将BoW引入对比学习框架，通过在自监督学习中结合重建任务和实例判别任务，从而实现上下文感知表征的学习。

5.3 对比学习与词袋模型多任务学习方法

本研究旨在从无标注的CLE图像集 $\mathcal{X}=\{x_i\}_{i=1}^{N}$ 中学习参数化模型 $f_\theta(\cdot)$，其中 x_i 表示图像集 $\mathcal{X}$ 中的第i张图像，N为图像总数。期望所学习的模型 $f_\theta(\cdot)$ 的表征：（1）具备足够的判别性以有效区分不同图像；（2）有效捕捉图像内部及跨图像的局部相似区域的结构和内容信息。前者可通过对比学习实现，促使同类图像表征相似，而不同类别的图像表征具有较大差异。后者则通过提升表征的质量，增强下游任务的泛化性，特别是在小样本学习的场景下。近期研究表明，具有优秀判别性的表征能够在数据规模有限的情况下显著提升下游任务的性能。因此，本研究提出CB-MTL，旨在通过整合对比学习和词袋模型协同实现上述目标。接下来，将详细阐述该框架的各个组成部分、目标函数及优化策略。

CB-MTL的结构如图5.2所示，其主要由对比学习主任务和词袋模型辅助任务两部分组成。主任务采用对比学习方法，旨在缩小同一图像不同实例之间的距离，从而学习具有判别性的表征。该过程无需显式判别不同图像，类似于在线教师-学生蒸馏方法，有效避免了对正负样本对的依赖。辅助任务则通过词袋模型进一步整合图像内部及跨图像局部相似区域的结构和内容信息。通过两个任务的协同优化，CB-MTL框架

中国知网 https://www.cnki.net

不仅能提升表征的判别性，还增强其对图像内部结构的捕捉能力，从而改善下游任务的泛化性。

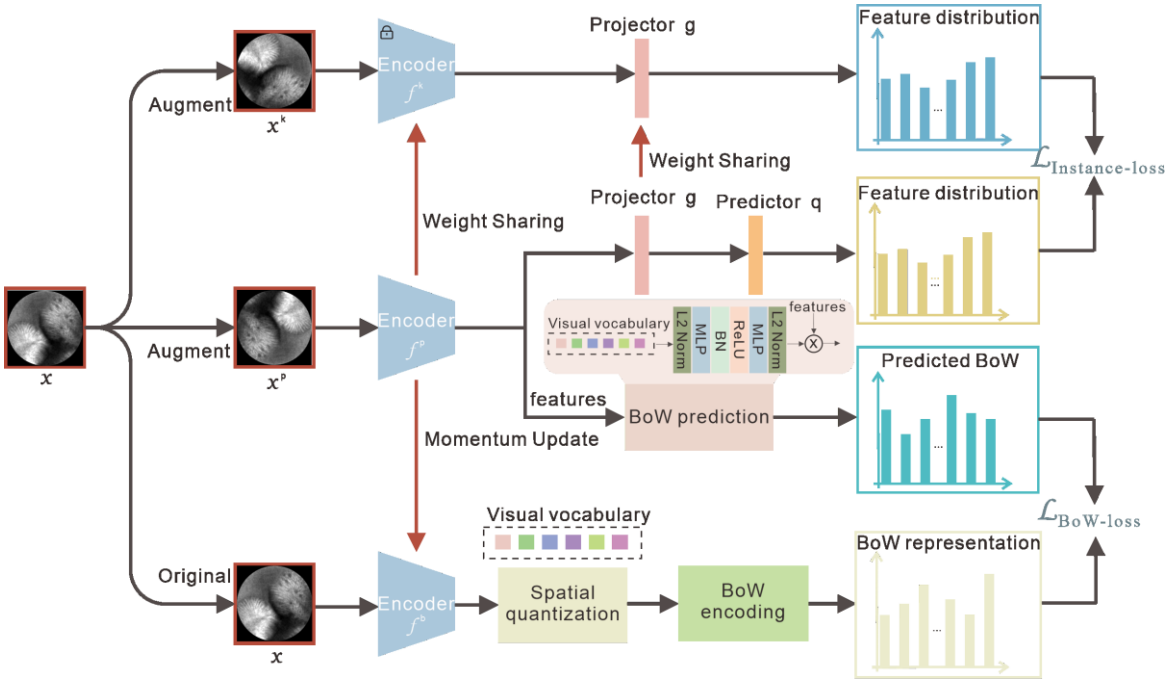


图5.2 CB-MTL的整体结构图，其同时进行特征分布一致性生成与词袋预测

辅助任务旨在通过词袋模型学习图像内部及跨图像不同局部相似区域的结构和内容相关信息。受相关研究[230,231]的启发，本研究提出将词袋模型整合到对比学习框架中，以学习具有上下文感知的表征。值得注意的是，CB-MTL中的词袋模型与传统词袋模型存在显著差异。传统词袋模型通常将图像中数百个局部特征的统计信息编码为向量表示并且其视觉词典是预定义且固定的。相反，本研究中的视觉词典并非固定不变，而是由模型在训练过程中在线动态更新。这一设计有效避免了传统方法中固定词典可能带来的限制，进一步提升了所学习表征的灵活性和适应性。通过动态更新视觉词典，CB-MTL框架能够更好地适应不同图像的多样性，捕捉更加细致和丰富的局部结构信息。此外，整合上下文感知表征有助于增强整体模型的判别性和泛化性。

5.3.1 对比学习

在CB-MTL中，主任务采用对比学习机制，其通过优化模型以判别不同实例，从而在特征空间中学习有效的表征。理想情况下，同类别特征应具有紧凑的类内分布，而不同类别特征应保持显著的类间距离。然而，由于缺乏标签先验，同一类别的图像可能会被误认为负样本，这可能会导致学习到次优特征。为此，本研究采用非对比学

中国知网 https://www.cnki.net

习的范式，旨在最大化同一图像的不同增强视图之间的互信息，从而消除存储负样本特征所需的存储库或队列，并避免由假负样本对引起的次优结果[199]。具体来说，给定一组大小为N的CLE图像集合$\{x_1,\cdots,x_i,\cdots,x_N\}$，首先对$x_i$分别施加两次随机数据增强$\mathcal{T}$，以生成两个不同的增强视图$x_i^p$和$x_i^k$，其中$\mathcal{T}$表示随机数据增强集。需要注意的是，$x_i^p$和$x_i^k$可以互换，这意味着两个增强视图的顺序不会影响模型性能。随后将x_i^p和x_i^k分别输入编码器$f_\theta^p(\cdot)$和$f_\theta^k(\cdot)$，以生成相应的特征h_i^p和h_i^k。$f_\theta^p(\cdot)$和$f_\theta^k(\cdot)$由主干网络$f_\theta(\cdot)$和投影头$g(\cdot)$组成，其中$f_\theta(\cdot)$用于提取输入图像的特征，$g(\cdot)$用于将特征映射到嵌入空间。值得注意的是，在训练过程中仅更新$f_\theta^p(\cdot)$的参数，且$f_\theta^p(\cdot)$和$f_\theta^k(\cdot)$之间共享参数以防止模型崩塌。由于直接计算h_i^p和h_i^k之间的相似性可能导致信息丢失，为此引入额外的预测器$q(\cdot)$，以将h_i^p非线性映射为$z_i^p=q(h_i^p)$。最后，采用负余弦相似度来计算z_i^p和h_i^k之间的相似性：

$$\mathcal{D}(z_i^p,h_i^k)=-\frac{z_i^p\cdot h_i^k}{\left\|z_i^p\right\|\left\|h_i^k\right\|}. \tag{5.1}$$

这样，通过最小化z_i^p和h_i^k的负余弦相似性，从而鼓励同一图像不同视图的表征趋于一致：

$$\mathcal{L}_{CL}=\frac{1}{N}\sum_{i=1}^{N}\mathcal{D}(z_i^p,h_i^k). \tag{5.2}$$

由于CLE图像在形态和内容上存在显著差异，仅仅考虑x_i^p和x_i^k之间的相似性难以确保学习到具有判别性的表征，这可能导致模型无法有效地捕捉图像的潜在语义结构。

5.3.2 词袋模型

词袋模型作为CB-MTL模型的辅助任务。已有大量研究证实，通过建模图像内及图像间的相似块可有效优化模型嵌入空间，以有效增强模型的等变性和局部性，进而提升模型的整体性能。因此，本研究将BoW[230,231]引入CB-MTL，旨在提高所学习表征的判别性和增强下游任务的泛化性。值得注意的是，本研究中主干网络$f_\theta^b(\cdot)$（不包括最后的自适应平均池化层）被视为特征提取器，用于提取输入图像的特征图，其参数通过指数加权移动平均（EMA）策略进行更新：

$$\theta^b=\beta\theta^b+(1-\beta)\theta^p, \tag{5.3}$$

中国知网 https://www.cnki.net

其中 θ^b 和 θ^p 分别表示 $f_\theta^b(\cdot)$ 和 $f_\theta^p(\cdot)$ 的参数，$\beta \in [0,1]$ 为EMA的系数，较大的 β（例如 $\beta = 0.99$）使得参数更新缓慢且持续，有助于避免 $f_\theta^b(\cdot)$ 参数的快速变化，从而稳定训练过程。$f_\theta^b(\cdot)$ 学习图像内及图像间的局部相似区域的结构和内容相关信息且无需依赖任何标签信息。

通常，BoW首先将输入图像的特征图量化为一组离散的视觉词，随后通过对这些视觉词进行聚类以构建视觉词典。最后，通过统计输入图像特征图中各视觉词的出现频次完成特征表达。具体来说，输入图像 x_i 的特征图表示为 $f_\theta^b(x_i) \in \mathbb{R}^{C\times H\times W}$，其中*C*、*H*和*W*分别表示通道数、高度和宽度，x_i 代表批次中第*i*张原始图像。接下来，利用通道平均池化对特征图 $f_\theta^b(x_i) \in \mathbb{R}^{C\times H\times W}$ 进行量化以获取表征整个图像的*C*维通用视觉词特征 $w_i \in \mathbb{R}^C$。与传统采用K-means将特征向量聚类为*K*个簇的量化方法不同，本研究采用一种基于队列的视觉词更新策略。具体来说，本研究维护一个大小为*K*的队列*Q*存储视觉词（视觉词典），其初始通过随机采样*K*个特征向量构建。在训练迭代过程中，使用当前批次中每张图像的特征 w_i 替换队列*Q*中最旧的特征，从而实现动态更新视觉词典。通过这种方式，词典中的视觉词在训练过程中持续更新，本质上构成动态聚类策略。相较于K-means，该视觉词更新策略具有以下优势：（1）基于队列的策略比K-means更易于实现且计算效率更高；（2）基于队列的策略无需显式聚类计算，因此在内存使用效率上比K-means更加高效；（3）K-means通常需要额外机制来缓解簇不平衡问题，而基于队列的策略自然规避了这一问题。随后，通过计算特征图 $f_\theta^b(x_i)$ 与视觉词典*Q*中各视觉词的欧氏距离，并应用*Softmax*将其转换为视觉词的概率分布：

$$A_i[\mu] = \frac{\exp(-\| f_\theta^b(x_i)[\mu] - Q_j \|_2^2 / \tau)}{\sum_{j=1}^{K} \exp(-\| f_\theta^b(x_i)[\mu] - Q_j \|_2^2 / \tau)}, \tag{5.4}$$

其中 $A_i \in \mathbb{R}^{K\times H\times W}$ 表示输入图像 x_i 的BoW概率分布，μ 为相应特征图的空间位置索引，$Q_j \in \mathbb{R}^C$ 表示视觉词典*Q*的第*j*个视觉词。最后在空间维度上对 $A_i \in \mathbb{R}^{K\times H\times W}$ 进行平均池化和L_2归一化处理，获得输入图像 x_i 的BoW分布 $P_i \in \mathbb{R}^K$：

$$P_i = \frac{1}{H\times W} \sum_{u=1}^{H\times W} A_i[u]. \tag{5.5}$$

该分布用于预测增强视图 x_i^p 的BoW分布，通过引导对比学习任务以学习更鲁棒的视觉表征。由于视觉词典*Q*中的视觉词在优化过程持续更新，本研究采用软映射替代硬

中国知网 https://www.cnki.net

映射将视觉词转换为概率分布，该机制作为硬映射的连续松弛能更灵活地表征视觉词与特征向量的关联关系。τ 是控制视觉词概率分布平滑度的系数，本实验设置 $\tau=0.2$。通过这种方式，即可获得输入图像 x_i 的视觉词分布 $P_i\in\mathbb{R}^K$。接下来将阐述 x_i^p 如何通过视觉词分布 $P_i\in\mathbb{R}^K$ 重构 x_i，进而辅助 $f_\theta^p(\cdot)$ 学习图像内及图像间不同局部相似区域的结构和内容相关信息。

为了学习有效的图像表征，$f_\theta^p(\cdot)$（删除最后一个自适应平均池化与投影头）以增强视图 x_i^p 作为输入，预测同一图像的视觉词分布。然而，考虑到训练过程中视觉词典的视觉词在迭代时会发生动态变化或替换，直接基于持续更新的视觉词典进行视觉词分布预测可能导致训练不稳定，从而获得次优的图像表征。为此，本研究引入动态词袋预测头，通过自适应地调整视觉词的权重以适应词典的动态更新[231]，该策略广泛应用于小样本学习中，用于仅通过有限的支持样本集生成新类别的分类权重。具体来说，首先利用 $f_\theta^p(\cdot)$ 获取增强视图 x_i^p 的特征图 $f_\theta^p(x_i^p)\in\mathbb{R}^{C\times H\times W}$，并通过通道平均池化获得$C$维特征向量 $f_\theta^p(x_i^p)\in\mathbb{R}^C$。接下来，采用由两个线性层组成的动态词袋预测头对增强视图 x_i^p 的视觉词分布进行预测，其中第一个线性层将当前视觉词的维度加倍，第二个线性层则将扩展后的维度缩减回原始维度。L_2归一化分别应用于第一之前和第二线性层之后，并在两者之间引入BN和ReLU以增强模型的稳定性和非线性。该预测头为当前词典生成预测权重 $H(Q_j)\in\mathbb{R}^K$，其中Q_j是词典第j个视觉词。最后，采用预测权重对特征向量 $f_\theta^p(x_i^p)\in\mathbb{R}^C$ 进行调整，从而获得增强视图 x_i^p 的最终视觉词分布 P_i^p：

$$P_i^p=\frac{\exp(\rho\cdot H(Q_j)^T\ f_\theta^p(x_i^p))}{\sum_{j=1}^{K}\exp(\rho\cdot H(Q_j)^T\ f_\theta^p(x_i^p))}. \tag{5.6}$$

其中系数ρ是用于等比例缩放预测权重 $H(Q_j)$，本实验设置ρ=8。动态词袋预测头具有以下两个优点：（1）为视觉词变换提供等变性，提升了动态变化词典的稳定性；（2）参数量与视觉词数量K无关，相较固定的词袋预测头更加灵活和高效，特别是当K较大时。最后，训练 $f_\theta^p(\cdot)$ 以最小化预测的视觉词分布 P_i^p 与“真实”的视觉词分布 P_i 之间的KL散度损失，从而有效地从 P_i 中“重建”输入图像 x_i：

$$\mathcal{L}_{BoW}=\frac{1}{N}\sum_{i=1}^{N}P_i^p\log\left(\frac{P_i^p}{P_i}\right) \tag{5.7}$$

中国知网 https://www.cnki.net

通过这种方式，$f_\theta^p(\cdot)$能够从图像内部及跨图像学习不同局部区域的结构和内容相关信息，从而改善学习表征的质量，进而提升下游任务的泛化性。

伪代码5.1

输入：无标签训练数据集$\mathcal{X}=\{x_i\}_{i=1}^N$，EMA系数$\beta$，平滑度$\tau$，缩放系数$\rho$，词典大小$K$，损失函数权重$\lambda$，随机数据增强集$\mathcal{T}$

初始化：编码器$f_\theta^p(\cdot)$、$f_\theta^k(\cdot)$和$f_\theta^b(\cdot)$；

预测器q(·)；

动态词袋预测头$H(\cdot)$；

视觉词典Q;

输出：编码器$f_\theta^p(\cdot)$

repeat
  for 小批次中的每个x_i **do**
    使用$\mathcal{T}$对x_i进行两次随机数据增强获得x_i^p和x_i^k
    采用公式5.2计算$\mathcal{L}_{CL}$
    计算视觉词特征$w_i \in \mathbb{R}^C$
    更新视觉词典Q
    采用公式5.4和5.5计算图像x_i的分布P_i
    采用公式5.6计算图像x_i^p的分布P_i^p
    采用公式5.7计算$\mathcal{L}_{BoW}$
  end
  采用公式5.8计算L
  采用SGD优化器更新$f_\theta^p(\cdot)$、q(·)和$H(\cdot)$
  通过对$f_\theta^p(\cdot)$进行参数共享更新$f_\theta^k(\cdot)$;
  通过公式5.3更新$f_\theta^b(\cdot)$
  until 整个数据集迭代完成
until 最大迭代次数

中国知网 https://www.cnki.net

5.3.3 优化目标

CB-MTL的损失函数如下：

$$\mathcal{L}=\mathcal{L}_{CL}+\lambda\mathcal{L}_{BoW}, \tag{5.8}$$

其中λ是用于平衡主任务与辅助任务的超参数，本研究设置$\lambda=2$。通过训练CB-MTL最小化损失函数$\mathcal{L}$，其具体的参数更新过程如下：

$$\begin{aligned}\theta^{p}&\leftarrow\theta^{p}-\alpha\left(\frac{\partial\mathcal{L}_{CL}}{\partial\theta}+\lambda\frac{\partial\mathcal{L}_{BoW}}{\partial\theta}\right)\\ \varphi&\leftarrow\varphi-\alpha\lambda\left(\frac{\partial\mathcal{L}_{BoW}}{\partial\varphi}\right)\end{aligned}, \tag{5.9}$$

其中φ表示辅助任务动态预测头的参数，α为学习率。值得注意的是，$f_{\theta}^{b}(\cdot)$参数更新通过 EMA 实现且未包含在上式中。考虑到训练早期阶段编码器可能无法有效提取图像特征，本研究采用线性预热策略，即在训练辅助任务中的动态预测头之前，预先对主任务进行若干个周期训练，以充分优化编码器参数，从而确保最终模型性能的稳定性和有效性。CB-MTL 的训练步骤如伪代码 5.1 所述。

5.4 实验分析

5.4.1 数据集和评估指标

本实验采用4.3.1节所述的两个CLE图像数据集，分别为SSL_CLE和FS_CLE数据集，评估指标包括Top-1准确率和95%置信区间。

5.4.2 实验设置

（1）模型结构。本研究基于PyTorch[160]实现CB-MTL模型，所有实验均在单个NVIDIA GeForce RTX 3090 GPU上完成。鉴于两个数据集的规模较小，分别选取ResNet-18[120]和ViT-S/16[101]作为主干网络$f_{\theta}(\cdot)$。具体来说，移除ResNet-18最后的全连接层和全局平均池化层以及删除ViT-S/16最后的全连接层。投影头$g(\cdot)$和预测器$q(\cdot)$分别由三层和两层全连接层构成，各层间依次加入批归一化（BN）和ReLU。对于ResNet-18，投影头和预测器的输出层和隐藏层维度分别设为2048和512。与MoCo-

中国知网 https://www.cnki.net

v3[232]类似，ViT-S/16的维度分别调整为256和4096。此外，动态BoW预测头由两层全连接层构成，其维度根据具体模型进行调整：ResNet-18为512和1024，ViT-S/16为384和768。

（2）实验细节。遵循先前的方法[197,232]，本研究在优化CB-MTL的两个模型时采用了不同策略：针对CNN架构采用动量为0.9的SGD优化器，并设置权重衰减系数为5×10^{-4}；对于ViT则选用AdamW优化器，采用相同动量系数，权重衰减设置为0.1。学习率采用余弦衰减策略进行调整。CNN和ViT-S/16的基础学习率分别默认设定为0.05和1.5×10^{-4}，并根据批次大小线性调整（学习率=基础学习率×$\frac{\text{批次大小}}{\text{默认批次大小}}$）。由于GPU内存限制，批次大小和默认批次大小均设为128。特别地，CB-MTL在前50个训练周期采用线性预热策略，旨在有效初始化特征提取器 $f_\theta^p(\cdot)$ 和预测器 $q(\cdot)$ 参数，从而为辅助任务构建相对精确的视觉词典。由于自然图像与CLE图像在强度分布上存在显著差异，CB-MTL在SSL_CLE数据集上从头开始训练，未采用基于ImageNet[110]预训练权重。本研究采用与Chen等人[197]相同的数据增强策略，包括随机裁剪、水平翻转、颜色抖动和高斯模糊。此外，还考虑到CLE图像的固有特性，如几何不变性和固有噪声[221]，在数据增强过程中以80%的概率对图像进行任意角度旋转，并以50%的概率加入由Voronoise和AWGN组成的噪声。此外，在实验中将动量系数 β 设为0.99，词袋模型的视觉词典大小K设为512。由于ViT-S/16通常采用最后一层的类token作为图像嵌入表征，为此在CB-MTL（ViT-S/16）中也遵循此设置，同时利用最后一层特征图（未包括类token）进行词袋模型计算。

（3）线性评估设置。为了评估CB-MTL的有效性，本研究基于SSL_CLE数据集采用线性评估协议进行图像分类任务验证。该协议广泛应用于自监督学习中，用于评估学习到的表征质量[199,209,232]。具体来说，本研究在冻结的预训练特征提取器 $f_\theta(\cdot)$ 上训练并测试线性分类器。该分类器由一层或两层全连接层构成，其中ViT-S/16仅使用一个全连接层。两个CB-MTL线性分类器均采用SGD优化器进行100个周期的训练。ResNet-18的初始学习率设为0.01，并分别在第60和第80个周期时减半，而ViT-S/16的初始学习率设为0.1，并通过采用余弦衰减学习率策略进行动态调整。本研究采用与Chen等人[197]相同的数据增强策略，包括随机裁剪和水平翻转。值得注意的是，无论是一层还是两层的线性分类器，其全连接层均采用相同的设置。

（4）小样本学习设置。为了验证CB-MTL（ResNet-18）在小样本场景下的泛化

中国知网 https://www.cnki.net

性，本研究基于FS_CLE数据集开展小样本分类下游任务实验。实验设置参照Snell等人[215]提出的1-shot和5-shot两种范式。具体来说，采用在SSL_CLE数据集上预训练的CB-MTL（ResNet-18）作为基学习器，去除其投影头 $g(\cdot)$ 和预测器 $q(\cdot)$，并在FS_CLE数据集上进行微调。微调过程中采用Adam优化器对CB-MTL进行50个训练周期，初始学习率设为5×10^{-4}，并且每10个周期学习率将减半。在训练和测试阶段，每个episode包含10个查询样本。

5.4.3 模型评估

为了评估CB-MTL的有效性，本研究基于SSL_CLE数据集进行线性评估、KNN评估及模型微调实验，同时在FS_CLE数据集上进行小样本学习的下游任务。

表5.1 各种方法（ResNet-18）在SSL_CLE数据集上的线性评估结果

方法	周期数	一层分类器		两层分类器	
		线性评估	置信区间	线性评估	置信区间
Supervised[120]	100	72.44%	0.6832, 0.7658	74.36%	0.7034, 0.7838
AMDIM[216]	1000	67.56%	0.6322, 0.7188	70.32%	0.6608, 0.7454
MoCo[209]	800	67.63%	0.6331, 0.7195	72.51%	0.6838, 0.7663
SimSiam[199]	800	68.22%	0.6392, 0.7253	71.11%	0.6692, 0.7528
BYOL[198]	1000	71.84%	0.6769, 0.7599	72.95%	0.6885, 0.7705
Obow[231]	800	72.28%	0.6815, 0.7641	73.84%	0.6978, 0.7789
TCL[217]	1000	71.18%	0.6699, 0.7536	73.39%	0.6931, 0.7747
Feature-level MixSiam[190]	800	74.33%	0.7031, 0.7835	76.89%	0.7299, 0.8078
CTCL[221]	800	75.60%	0.7162, 0.7958	78.45%	0.7465, 0.8225
CB-MTL	800	77.61%	0.7376, 0.8145	81.82%	0.7826, 0.8538

（1）线性评估。线性评估和KNN评估被广泛用于衡量自监督学习中所学表征的质量。具体来说，线性评估通过冻结预训练特征提取器 $f_\theta(\cdot)$ 并训练线性分类器实现，而KNN评估则基于相同冻结预训练特征提取器 $f_\theta(\cdot)$ 上训练KNN分类器。本研究采用线性评估和KNN评估在SSL_CLE数据集上对CB-MTL及其他最先进的方法进行性能评估。这些对比方法包括监督学习方法ResNet-18[120]，基于CNN的自监督学习方法AMDIM[216]、MoCo[209]、BYOL[198]、SimSiam[199]和TCL[217]，基于ViT的自监督学习方法MoCo-v3[232]、DiNO-v1[233]、MAE[202]和iBOT[234]，基于视觉词袋的方法Obow[231]，以及专为CLE设计的方法Feature-level MixSiam[190]和CTCL[221]。为了确保对比的公平

中国知网 https://www.cnki.net

性，所有方法在SSL_CLE数据集上重新实现，并严格沿用与原论文一致的实验设置。

表5.2 不同方法（ViT-S/16）在SSL_CLE数据集下基于线性评估协议的结果

方法	周期数	线性评估	KNN评估	置信区间
MoCo-v3[232]	800	73.39%	64.10%	0.6931,0.7747
DiNO-v1[233]	800	40.80%	38.14%	0.3596,0.4563
MAE[202]	800	37.69%	34.86%	0.3280,0.4259
iBOT[234]	800	57.43%	52.77%	0.5286,0.6199
CB-MTL	800	75.83%	67.41%	0.7185,0.7980

表5.1和表5.2展示了各种方法的线性评估结果。结果表明，CB-MTL（ResNet-18）在单层和两层全连接线性分类器下均实现了显著的性能提升，这证实了CB-MTL通过词袋模型辅助任务能够有效学习图像内和图像间局部相似区域的结构和内容信息。具体来说，CB-MTL（ResNet-18）在单层和两层全连接线性分类器下的性能分别较监督学习方法[120]提升了约5%和7%，表明其在无需标签信息的情况下能够学习到具有判别性的表征。此外，所提出的方法在单层和两层全连接线性分类器的评估中，相较于其他自监督学习方法也取得了显著提升。例如，CB-MTL（ResNet-18）的性能分别较SimSiam[199]提高约9%和10%。这些结果表明通用表示方法[202,232–234]可能不适用于CLE图像设置。值得注意的是，CB-MTL（ViT-S/16）的线性评估相比于最先进的方法也取得了显著的性能提升，这表明其词袋模型同样能够有效捕捉图像中和图像间局部相似区域的结构与内容信息，从而促进整体图像表征的学习。CB-MTL（ViT-S/16）在SSL_CLE数据集上获得与CB-MTL（ResNet-18）一致的优势表现，这进一步证实了其在学习判别性表征方面的通用性和有效性。然而，由于SSL_CLE数据集规模较小，ViT结构对数据量的敏感性导致了CB-MTL（ViT-S/16）在部分实验中相较于CB-MTL（ResNet-18）存在一定性能差距。总体来看，CB-MTL在与专为CLE设计的方法[190,221]的比较中亦展现出具有显著的竞争力，表明其为从CLE图像中提取通用且有效的视觉表征提供了新的研究视角。

基于先前的研究[199]，本研究对各种方法在SSL_CLE数据集上进行KNN评估，以进一步衡量所学习表征的质量。不同方法的KNN评估结果如表5.2所示。结果表明，CB-MTL方法相较于现有最先进的方法[202,232–234]，在KNN评估中均取得显著的性能提升，这表明该方法能够学习到更具判别性的表征。KNN评估结果与线性评估结果一致，进一步证实了CB-MTL在不同架构下学习判别性表征的有效性。此外，本研究通过95%置信区间的统计分析表明，CB-MTL在性能上显著优于现有最先进的方法，进一步凸

中国知网 https://www.cnki.net

显了该方法在辅助临床医生进行准确诊断决策方面的潜在应用价值。

表5.3 不同方法在SSL_CLE数据集中不同比例下的微调结果

方法	10%	20%	50%	100%
MoCo[209]	66.52%	66.74%	72.05%	72.73%
SimSiam[199]	62.97%	66.08%	70.51%	70.95%
BYOL[198]	76.50%	76.94%	78.38%	79.04%
Obow[231]	75.17%	75.39%	76.05%	76.05%
TCL[217]	63.85%	61.42%	56.98%	64.97%
CTCL[221]	74.94%	77.38%	77.83%	78.49%
CB-MTL	76.72%	78.27%	78.94%	79.16%

（2）模型微调。本研究分别选取了SSL_CLE数据集中10%、20%、50%和100%比例的数据对预训练的CB-MTL（ResNet-18）模型进行微调，以进一步评估其有效性。具体来说，本研究采用SGD优化器对预训练的CB-MTL（ResNet-18）模型训练100个周期，初始学习率设定为0.001，并分别在第60和第80个训练周期将学习率减半。其余超参数均与线性评估实验设置保持一致。微调评估的结果如表5.3所示，结果表明，相较于现有最先进的方法[198,199,209,217,221,231]，CB-MTL在不同数据比例下均实现了显著的性能提升，验证了其出色的泛化性。此外，这些结果与线性评估结果呈现一致趋势，进一步证实了CB-MTL在学习判别性表征方面的有效性。

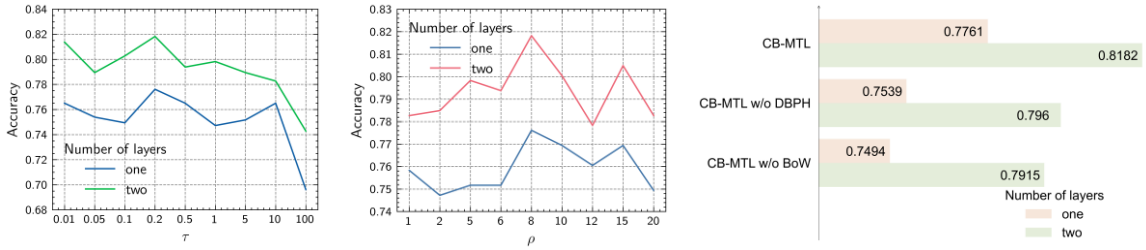
表5.4 不同方法在FS_CLE数据集的5-Way 1-Shot和5-Way 5-Shot任务中的分类结果

方法	5-Way 1-Shot	5-Way 5-Shot
ProtoNet+[215]	60.75%	72.62%
DN4[218]	61.59%	71.63%
SSLFL[219]	62.78%	73.64%
Feature-level MixSiam[190]	63.62%	74.37%
CTCL[221]	64.12%	77.37%
CB-MTL	64.62%	82.50%

（3）小样本学习。大量研究表明，预训练模型的嵌入表征可有效迁移至小样本学习任务[190,219,221]。为了评估CB-MTL的泛化性，本研究基于FS_CLE数据集开展小样本分类任务实验。在该数据集上复现了多种最先进方法，包括ProtoNet+[215]、DN4[218]、SSLFL[219]、Feature-level MixSiam[190]和CTCL[221]，并严格遵循原论文的实验设置。表5.4展示了各方法在FS_CLE数据集上两个标准小样本学习分类任务中的实验结果。结果表明，CB-MTL在5-Way 1-Shot和5-Way 5-Shot两个任务上均显著优于现有最先进方法[190,215,218,219,221]，尤其在5-Way 5-Shot任务上实现了5.13%的性能提升，这表明了CB-

中国知网 https://www.cnki.net

MTL具有更强的泛化性。这些结果与本研究核心的论断一致，即CB-MTL可将学习所得表征有效迁移至小样本学习任务，从而深入阐释模型的整体表现。



（a）不同平滑度τ　　（b）不同分布缩放ρ　　（c）CB-MTL各部分消融研究

图5.3 （a）不同概率分布平滑度对视觉词的影响；（b）动态预测头中不同分布缩放ρ对视觉词典的影响；（c）CB-MTL不同部分的消融实验。所有结果通过SSL_CLE数据集线性评估获得。

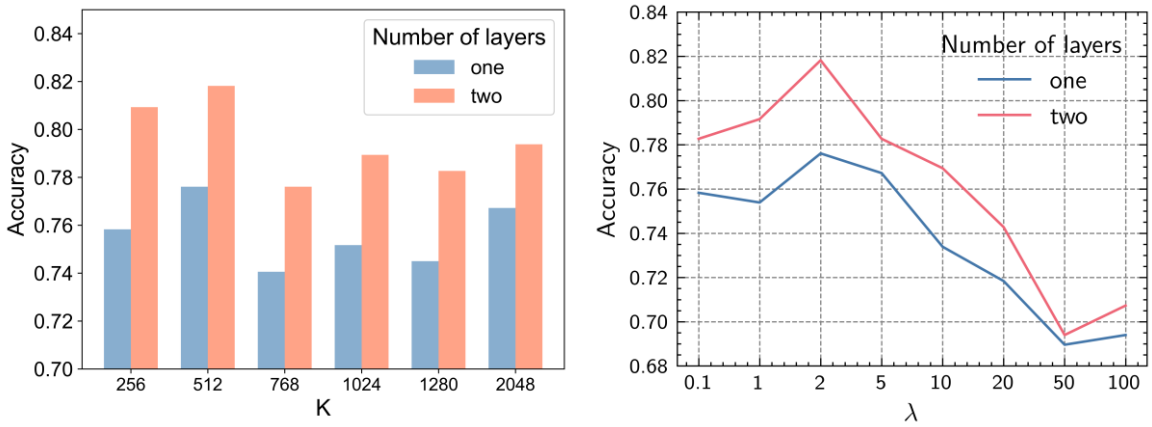
5.4.4 消融实验

（1）视觉词概率分布平滑度的影响。Softmax温度系数τ在对比学习中具有重要作用，其通过调节概率分布能有效提升特征嵌入的质量及模型的泛化性[197]。当τ较小时，正样本的概率分布趋于集中，而负样本的概率分布则更为分散，随着τ增大，正负样本的概率分布呈现反向变化趋势。作为调控词袋模型概率分布平滑度的关键参数，τ有助于CB-MTL更准确地聚焦于任务相关的视觉词，从而有效增强模型对判别性表征的学习。为了探究τ对CB-MTL性能的影响，本研究在SSL_CLE数据集上对不同的τ值（$\tau \in \{0.01, 0.05, 0.1, 0.2, 0.5, 1, 5, 10, 100\}$）进行了系列实验，实验结果如图5.3（a）所示。实验结果表明，不同的τ对CB-MTL的性能具有显著影响，且当τ从5增至100时，性能呈明显下降趋势。这主要是由于τ过大时会导致视觉词的概率分布过于平滑，弱化视觉词之间的差异性表征。相反，当τ=0.2时，无论采用一层还是两层全连接层的线性分类器均可获得较为理想的性能平衡。

（2）动态词袋预测头分布缩放ρ的影响。本研究还对CB-MTL中的超参数ρ进行深入探讨。该参数作为权重缩放系数，通过对预测权重$H(Q_j)$进行等比例调节，以评估不同缩放水平下模型性能的变化。为此，本研究在SSL_CLE数据集上对不同ρ值（$\rho \in \{1, 2, 5, 6, 8, 10, 12, 15, 20\}$）进行实验。结果如图5.3（b）所示，模型性能随$\rho$值变化呈现显著波动，其中当$\rho$=8时，模型性能达到最佳。其原因在于，当$\rho$过大时会导致较大的预测权重$H(Q_j)$被过度放大，从而削弱较小预测权重的贡献作用；相反，当ρ过小则会抑制较大的预测权重对关键特征信息的有效表达。

中国知网 https://www.cnki.net

（3）CB-MTL中各组成部分的影响。为了探讨CB-MTL中各组成部分对模型性能的影响，本研究通过在SSL_CLE数据集上设计了包含不同组成部分的消融实验，包括移除词袋辅助任务的CB-MTL（记为CB-MTL w/o BoW），以及移除动态词袋预测头的CB-MTL（记为CB-MTL w/o DBPH）。如图5.3（c）所示，CB-MTL w/o BoW的性能最差，表明了词袋模型辅助任务在学习判别性表征方面具有重要作用。CB-MTL w/o DBPH虽性能次之，但其结果验证了动态词袋预测头通过自适应地调整视觉词典的权重，从而有效适应视觉词的动态变化。最后完整的CB-MTL取得了最佳性能，这证实了该方法通过协同多特征空间的自监督学习，能够有效提取具有判别性的视觉表征。



（a）不同视觉词典大小K　　（b）不同损失函数权重λ

图5.4 （a）不同视觉词典大小K的影响；（b）CB-MTL中损失函数权重λ的消融实验。所有结果通过SSL_CLE数据集线性评估获得

（4）视觉词典大小K的影响。词袋模型的视觉词典大小K是用于控制视觉词典中视觉词数量的超参数。该视觉词典由训练图像中学习所得的视觉词构成，旨在引导CB-MTL聚焦于相关局部相似区域的结构与内容信息，从而增强所学习表征的判别性。在训练过程中，视觉词典通过队列机制实现持续更新，其更新方式与MoCo中的存储库[209]具有相似性。为了探究K值对模型性能的影响，本研究针对$K \in \{256, 512, 768, 1024, 1280, 2048\}$进行实验验证。不同$K$值实验结果如图5.4（a）所示。实验结果表明，$K$值的不同设定会显著影响模型性能，且当$K$=512时，采用一层/两层全连接层的线性分类器达到最优性能。这是由于当K过小时导致视觉词典过于稀疏，部分相关视觉词难以有效表征；而当K过大时则可能引入过多无关的视觉词，削弱特征的判别能力。

（5）损失函数权重λ的影响。最后，有效平衡不同损失函数的贡献对于模型性能至关重要。损失函数权重λ是一个超参数，用于调节主任务和辅助任务的相对重要性。为了探讨该超参数对模型性能的影响，本研究在SSL_CLE数据集上对不同λ进行实验，

中国知网 https://www.cnki.net

$\lambda \in \{0.1, 1, 2, 5, 10, 20, 50, 100\}$，实验结果如图5.4（b）所示。结果表明，不同$\lambda$对CB-MTL性能产生显著影响，且$\lambda$=2为最佳性能。因此，本研究将$\lambda$设置为2，以便在主任务和辅助任务之间实现有效的贡献平衡，从而使CB-MTL能够更好地学习判别性表征。

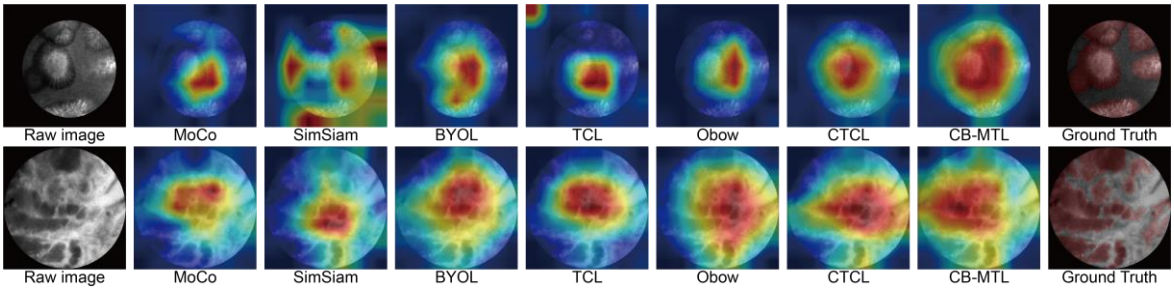


图5.5 不同方法在SSL_CLE数据集上的CAM结果。图中第一列为原始图像，第二至最后一列分别为MoCo、SimSiam、BYOL、TCL、Obow、CTCL、CB-MTL（ResNet-18）的CAM以及相应的真实标签

5.4.5 可视化表征

为了进一步定性分析CB-MTL的有效性，本研究采用类激活图[220]对包括CB-MTL（ResNet-18）、MoCo[209]、BYOL[198]、SimSiam[199]、TCL[217]、Obow[231]及CTCL[221]等多种方法在SSL_CLE数据集上学习到的表征进行可视化分析。图5.5展示了这些方法生成的CAM，皆在揭示不同方法对病变区域的关注程度，从而评估其在临床应用中的可解释性和可靠性。图中第一列为输入图像，随后依次展示了MoCo[209]、BYOL[198]、SimSiam[199]、TCL[217]、Obow[231]、CTCL[221]及CB-MTL（ResNet-18）的CAM，最后一列为相应的真实标签。需要指出的是，真实标签采用红色掩膜标注病变区域，以突出腺体与细胞形态在病变类型判定中的关键作用。标注过程中可参考第三章提出的腺体分割方法，辅助提取图像中腺体及细胞区域的边界与形态特征，从而进行更为高效的标注。结果显示CB-MTL（ResNet-18）的CAM更为聚焦于病变区域，且与真实标签的重叠度更高。这表明CB-MTL能够理解目标的空间分布，并学习出有助于临床诊疗的判别性表征。然而，MoCo[209]、BYOL[198]、SimSiam[199]、TCL[217]、Obow[231]和CTCL[221]的CAM未能充分关注感兴趣的区域，进一步表明了CB-MTL（ResNet-18）通过自监督学习能够从多个特征空间中学习判别性表征。CAM与线性评估的结果一致，从定性角度进一步验证了CB-MTL的有效性。因此，这些发现将有助于提高临床决策的质量和模型的可解释性。此外，CB-MTL（ViT-S/16）也能取得类似的结果，在未来的研究中将对此进行深入探讨。

中国知网 https://www.cnki.net

5.4.6 可视化视觉词

为了深入探讨CB-MTL的有效性，本研究在SSL_CLE数据集上对其学习到的视觉词进行了可视化分析。通过基于词袋模型的辅助任务引导对比学习，促使CB-MTL能够有效聚焦于相关的视觉特征，从而增强表征的判别性。由于视觉词在训练过程中持续动态更新，本研究在图5.6中展示了CB-MTL在SSL_CLE数据集训练结束时所学习到的视觉词的可视化结果。具体来说，通过从图像中提取多个局部图像块实现视觉词可视化，并选取与各视觉词相关性最高的前六个局部图像块进行展示。实验结果表明，CB-MTL所学习到的视觉词能够有效编码具有语义一致性的高层次特征，如腺体区域、背景区域及噪声区域，验证了其能够有效捕捉图像内及图像间的局部相似区域的结构和内容信息，从而有助于整体图像表征的学习。

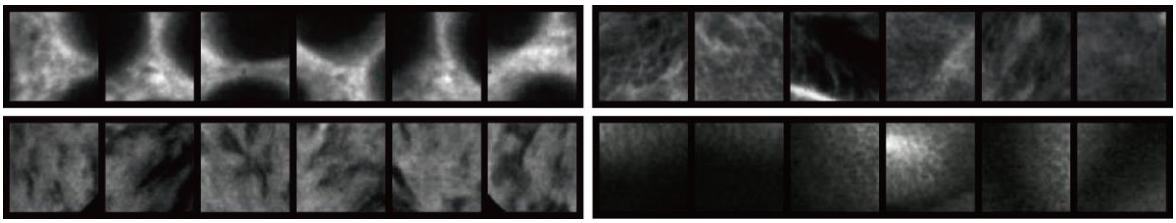


图5.6 CB-MTL在SSL_CLE数据集上训练完成后生成的视觉词典，其中每个视觉词对应六个匹配程度最高的图像块

5.4.7 讨论

本研究提出的方法虽然与现有研究[222,229–231]存在一定相关性，但在架构设计与应用场景上存在本质的区别。该方法受近期对比学习进展的启发，通过并行执行对比学习任务和词袋模型任务，采用自监督学习方式从CLE图像的多个特征空间中学习判别性表征，并在CLE图像的多个分类任务基准测试中取得了显著的性能优势。然而，现有研究[222,229–231]主要集中于依赖标签信息的多任务学习[222]，或通过自监督学习构建词袋模型以学习图像表征[229–231]。此外，本方法实现了从多个特征空间（包括CNN和ViT）中学习判别性表征的能力，这突破了以往主要聚焦于CNN架构的研究。

尽管本研究提出的方法已展现出具有竞争力的性能，但仍存在若干亟待解决的不足之处。首先，在临床实践中探头运动引发的组织形变可能导致成像质量下降，进而影响模型性能。其次，由于CLE成像具有显著的异质性，当数据集规模有限时，训练集与测试集间的分布差异可能会显著削弱模型的泛化性。为了解决这些问题，未来计

中国知网 https://www.cnki.net

划引入图像配准和形变校正算法来应对组织形变，并通过建立更大规模且更具代表性的CLE图像数据集来提升模型的鲁棒性和通用性。同时，也将在更广泛的范围内验证其泛化性。最后，考虑到目前所学的表征主要通过图像分类任务进行评估，这尚不足以充分验证其有效性，未来将深入探索其在CLE图像分割、检索等下游任务中的潜力。

5.5 本章小结

判别性表征学习在CLE图像分析中至关重要。本研究提出了一种高效的多任务学习方法CB-MTL，旨在提升CLE图像分析的性能。实验表明，BoW模块能够轻易集成到现有的对比学习框架中，无需额外约束即可显著提升模型性能。该模块通过为每张图像生成视觉词向量，有效辅助对比学习任务捕获图像特征表征，其有效性通过可视化学习结果的对比分析得到了进一步验证。此外，本研究还引入了融合几何不变性和固有噪声的数据增强策略，以有效增强模型表征的鲁棒性。在SSL_CLE和FS_CLE数据集上的大量实验结果表明，CB-MTL在线性评估、模型微调和小样本学习等下游任务中均取得了先进性能。通过验证该方法在CNN和ViT主干网络上的适用性，不仅证实了其架构的通用性，同时证明其易于扩展到其他医学图像分析任务。未来，将进一步探讨该方法在CLE视频检索和分类任务中的应用潜力，以更好地满足临床实践需求。

本章工作创新点如下：

（1）本研究提出了一种新颖的多任务学习方法CB-MTL，该方法包括一个对比学习任务（主任务）和一个词袋模型任务（辅助任务），旨在通过自监督学习从未标注的CLE图像中学习更鲁棒的视觉表征并增强其泛化性。

（2）本研究引入了词袋模型辅助任务，旨在利用图像内及图像间的多样化局部相似区域的结构与内容相关信息以提升主任务的性能。

（3）实验结果表明，该方法在多个下游任务中均取得可竞争的性能，并具有为CLE图像特征学习提供新思路的潜力。

（4）本研究验证了该方法在CNN和ViT架构下均表现出良好的效果，并且具有处理不同模型的鲁棒性和通用性。

中国知网 https://www.cnki.net

6 总结与展望

6.1 工作总结

消化道疾病的早期诊断对临床治疗具有重要意义。本论文以消化道医学图像为研究对象，围绕辅助医生提升诊断准确率为中心点，以CLE图像作为主要研究载体，从CLE成像原理、病理状态与医学图像特征关系的基本原理出发，对消化道CLE图像开展去噪、分割和识别一系列较为系统、全面和深入的研究，并结合其他模态的消化道医学图像，依据临床需求进行分析与研究。本学位论文的主要研究内容包括以下几个部分：

（1）针对CLE成像过程中由于光纤束物理结构限制而产生各种形式的噪声问题，本研究提出了一种自监督轻量级去噪方法CLENet，以及一个基于U型结构的高效去噪网络U-CLENet。通过建模CLE图像中乘性噪声与加性白噪声组成的真实噪声统计分布模型，构建了一个无需干净图像的自监督去噪框架。具体来说，首先设计了一个上下文感知核估计模块，通过采用类似自适应区域权重的适度感受野，有效缓解了噪声分布的空间异质性问题。其次，CLENet采用了轻量化网络设计，在保持较低计算复杂度的同时显著提升了去噪效率。接下来，通过多尺度动态融合模块实现特征解耦与跨尺度交互，完成上下文信息的动态校准。最后，将这些模块集成到U型架构中，构建了U-CLENet去噪网络。实验结果表明，所提出的方法在多个CLE图像去噪数据集上以较低计算成本达到或超越现有方法性能，有助于提升消化道不同肿瘤分期CLE图像的视觉质量，为后续CLE图像分析任务提供高质量的预处理结果。

（2）金字塔Transformer在处理高分辨率特征图以进行密集预测任务时展现出其高效性。因此，本研究提出了一种基于金字塔ViT的多尺度混合网络架构PMHNet，有效缓解了医学图像分割中病变形态异质性显著、病灶边缘模糊及组织对比度低等挑战。该架构通过整合密集门控连接模块、自多尺度交互融合模块、多尺度注意力解码模块以及金字塔ViT到U型架构中，构建了一个多分支并行网络，并实现了多尺度上下文语义信息的有效提取与融合。具体来说，密集门控连接模块通过级联局部语义特征信息，引导网络关注不同层次的特征信息，在抑制浅层特征噪声干扰的同时增强了语义

中国知网 https://www.cnki.net

特征的判别性。接着，自多尺度交互融合模块利用多头自注意力和多头交叉注意力，实现了金字塔ViT提取的多尺度上下文全局信息和DGC局部细节特征的有效融合，从而提升了网络对不同尺寸病灶边缘的定位精度并缓解了低对比度组织的辨识难题。最后，多尺度注意力解码模块通过级联多尺度卷积和空间-通道双重注意力，在解码器中有效捕获了多维精细化语义特征信息，弥合了不同层级间的语义鸿沟，获取了精细化的分割预测结果。实验结果表明，PMHNet在消化道腺体、隐窝及消化道息肉等多个具有挑战性的医学图像分割任务中均表现出了优越的性能和良好的泛化性。该方法精确的结构区域定位能力不仅满足了多样化医学图像分割的实际需求，也为后续图像分类任务中的病灶区域标注提供了高质量的结构先验，显著提升了分类标注的效率与准确性，进一步增强了模型的可解释性与临床可用性。

（3）针对CLE图像数据集中类间方差小、类内方差大以及标注数据稀缺的问题，本研究提出了一个聚类引导的双对比学习方法CTCL。该方法通过实例级和簇级对比学习的协同作用，动态筛选与实例语义相关且类别一致的样本，有效提升了类内特征的紧凑性与类间特征的可分离性。同时，考虑到CLE图像的固有特性，本研究进一步提出了将任意角度旋转的CLE图像以及包含各种噪声的CLE图像分别视为同一实例，从而增强了样本的可变性和多样性。通过期望最大化算法对CTCL框架进行迭代优化，并在线性评估和小样本分类等下游任务中广泛验证了其鲁棒性与泛化性。实验结果表明，该方法在辅助医生进行消化道肿瘤的自动化快速诊断和提升病理分期判读准确性方面展现出巨大的潜力。

（4）学习判别性表征在CLE图像分析中至关重要。为此，本研究提出了一个结合对比学习与词袋模型的多任务方法CB-MTL。该方法采用了自监督学习策略，从无标注的CLE图像中提取具有判别性的特征，实现了高效的图像分析。该方法以对比学习作为主任务，通过对同一图像的不同实例进行对齐，从而学习了变换不变的图像表征。同时，通过引入一个基于视觉词袋模型的辅助任务，来捕捉图像内及图像间局部相似区域的结构和内容相关特征，并生成视觉词向量，从而有效引导了对比学习任务获取更鲁棒的视觉表征。通过在图像分类的线性评估、模型微调以及小样本分类等下游任务进行广泛实验验证，结果表明了CB-MTL在CNN和ViT架构下均能显著提升表征质量与模型的泛化性，具有为自监督学习在医学图像分析提供新思路的潜力。

中国知网 https://www.cnki.net

6.2 研究展望

尽管本文在基于共聚焦内窥镜消化道医学图像智能分析算法领域虽取得了阶段性成果，但仍存在若干值得深入探索和改进的空间：

（1）在目前的CLE图像处理中，由于光纤束的物理特性，CLE成像过程中不可避免地会引入噪声，这给图像特征的提取和模型的训练效果带来了挑战。考虑到病理图像和显微镜图像在纹理和组织成像方面与CLE图像具有形态学相似性，未来尝试探索采用图像生成或虚拟病理技术来实现跨模态图像间的转换，具体来说，通过将病理图像或显微镜图像转换为CLE图像，用以指导CLE图像去噪和特征提取。这样的转换不仅有助于改进图像的重建质量，还能提高CLE系统的成像深度获取更深层次的微观结构信息，从而大幅提升图像分析的准确性和可靠性。

（2）当前的CLE图像分割研究面临着数据集规模有限和模型参数过多的挑战，这限制了其在临床实时应用中的潜力。为了应对标注数据不足的问题，计划构建一个涵盖不同解剖部位、多中心和病理分期的标准化CLE图像数据库。此外，还将探索无监督学习或弱监督学习方法，以减少对大量手工标注数据的依赖。同时，我们将尝试结合神经架构搜索技术来设计高效的轻量化模型，以降低算法的计算复杂度，从而提高实时运行的效率。

（3）现有的分类算法主要基于单模态的CLE图像进行决策，这与临床上的多维度诊断模式相比存在显著的差异。为此，计划构建一个包含CLE图像、病理全景图像、电子内窥镜结果、电子健康档案及实验室检查数据的多模态临床数据库。同时，设计开发一个通用的多模态学习框架，该框架能够从不同类型的医学图像和非图像数据中学习共同的特征，以挖掘多模态数据之间的内在联系。这些多模态数据能够提供更为全面的临床信息，对于提高诊断的准确性和可靠性具有重要意义。此外，计划还将多模态学习框架与临床决策支持系统集成，设计一个智能辅助决策平台，该平台将为临床医生提供更加精确的诊断建议，减少人为错误，并显著提升诊断的效率和准确性。

（4）在本研究中，由于数据集的规模相对较小且关注的病变部位较为单一，未来的研究将着重于扩大数据集的规模，并涵盖更多种类的病变部位，同时还将融合来自不同医疗中心的数据。这种方式使得模型能够学习到更多样化的疾病特征，从而提升在处理复杂病例时提高诊断的准确性。此外，通过整合多源数据，减少数据偏差，增强模型在不同临床环境下的泛化能力和稳定性。这些措施将有助于提升诊断系统在

中国知网 https://www.cnki.net

多样化临床场景中的适用性，推动计算机辅助诊断技术在医疗领域的广泛应用。

（5）本研究的算法主要聚焦于分析CLE图像。然而，在临床实践中，CLE系统通常是以视频帧序列形式呈现采集数据，这其中包含了大量的低质量且缺乏诊断价值的图像。这些图像不仅给医生的工作增加了负担，还可能对后续诊断模型的准确性产生影响。为了解决这一问题，未来我们尝试开发设计有效的图像质量评估方法，以更好地理解图像序列中的动态变化，从而实现实时识别出高质量、有诊断价值的图像。此外，CLE图像分析不应局限于单一帧图像，还需考虑图像序列中相邻图像之间的关系以及时序信息。通过将时序信息与图像特征相结合，我们能够捕捉到不同时间尺度下的图像特征相关性，进而提升临床应用中CLE图像分析的准确性和可靠性。

中国知网 https://www.cnki.net

参考文献

[1] Warren B E. X-ray diffraction[M]. Courier Corporation, 1990.

[2] Jensen J A. Medical ultrasound imaging[J]. Progress in biophysics and molecular biology, 2007, 93(1-3): 153-165.

[3] 许国强, 方英, 厉有名, 等. 微型超声探头对消化道疾病的诊断价值[J]. 中国内镜杂志, 2002(1): 4-6+9.

[4] Buzug T M. Computed tomography[M]//Springer Handbook of Medical Technology. Berlin, Heidelberg: Springer Berlin Heidelberg, 2011: 311-342.

[5] Flusberg B A, Cocker E D, Piyawattanametha W, *et al*. Fiber-optic fluorescence imaging[J]. Nature Methods, 2005, 2(12): 941-950.

[6] Vlaardingerbroek M T, Boer J A. Magnetic resonance imaging: Theory and practice[M]. Springer Science & Business Media, 2013.

[7] Nodine C F, Kundel H L, Mello-Thoms C, *et al*. How experience and training influence mammography expertise[J]. Academic Radiology, 1999, 6(10): 575-585.

[8] 郑光远, 刘峡壁, 韩光辉. 医学影像计算机辅助检测与诊断系统综述[J]. 软件学报, 2018, 29(5): 1471-1514.

[9] Filho A M, Laversanne M, Ferlay J, *et al*. The globocan 2022 cancer estimates: Data sources, methods, and a snapshot of the cancer burden worldwide[J]. International Journal of Cancer, 2025, 156(7): 1336-1346.

[10] 周家琛, 郑荣寿, 王少明, 等. 2020年中国和世界部分国家主要消化道肿瘤负担比较[J]. 肿瘤综合治疗电子杂志, 2021, 7(2): 26-32.

[11] 杜奕奇, 李兆申. 我国消化道早癌筛查的挑战和展望[J]. 第二军医大学学报, 2020, 41(1): 1-5.

[12] 涂仕奎, 杨杰, 连勇, 等. 关于智能医疗研究与发展的思考[J]. 科学, 2017, 69(3): 9-11.

[13] Ali H, Muzammil M A, Dahiya D S, *et al*. Artificial intelligence in gastrointestinal endoscopy: A comprehensive review[J]. Annals of Gastroenterology, 2024, 37(2): 133-141.

[14] Kiesslich R, Goetz M, Vieth M, *et al*. Confocal laser endomicroscopy[J]. Gastrointestinal Endoscopy Clinics of North America, 2005, 15(4): 715-731.

[15] Wang J, Yang M, Yang L, *et al*. A confocal endoscope for cellular imaging[J]. Engineering, 2015, 1(3): 351-360.

[16] Ellebrecht D B, Heßler N, Schlaefer A, *et al*. Confocal laser microscopy for in vivo intraoperative application: Diagnostic accuracy of investigator and machine learning strategies[J]. Visceral Medicine, 2021, 37(6): 533-541.

[17] Martirosyan N L, Eschbacher J M, Kalani M Y S, *et al*. Prospective evaluation of the utility of intraoperative confocal laser endomicroscopy in patients with brain neoplasms using fluorescein

中国知网 https://www.cnki.net

sodium: Experience with 74 cases[J]. Neurosurgical Focus, 2016, 40(3): E11.

[18] Perperidis A, Dhaliwal K, McLaughlin S, *et al*. Image computing for fibre-bundle endomicroscopy: A review[J]. Medical Image Analysis, 2020, 62: 101620.

[19] Paddock S W. Confocal laser scanning microscopy[J]. Biotechniques, 1999, 27(5): 992-1004.

[20] 李华. 大视场共聚焦内窥成像方法研究[D]. 华中科技大学, 2021.

[21] 董香江. 共聚焦内窥图像质量分析算法研究[D]. 华中科技大学, 2023.

[22] Xu B, Yang X, Liu J, *et al*. Real-time correction of transverse dislocation and distortion in probe-based confocal laser endomicroscopy imaging[J]. Optics Communications, 2022, 522: 128653.

[23] 汤泊夫, 年媛媛, 党彤. 激光共聚焦显微内镜在消化系统疾病中的应用进展[J]. 中华消化内镜杂志, 2022, 39(02): 164-168.

[24] 何新龙, 龚帅, 薛寒冰. 共聚焦激光显微内镜在结直肠疾病中的应用进展[J]. 中华消化内镜杂志, 2024, 41(02): 164-168.

[25] 冯家欣, 周子青, 李时悦. 共聚焦激光显微内镜在呼吸系统疾病中的应用研究进展[J]. 中华结核和呼吸杂志, 2021, 44(3): 260-266.

[26] 李璇璇, 狄扬, 郝思介, 等. 细针型共聚焦激光显微内镜在胰腺囊性病变中应用的研究进展[J]. 胃肠病学, 2018, 23(12): 705-710.

[27] 佚名. 《早期肺癌诊断中国专家共识(2023年版)》[J]. 中华医学信息导报, 2023, 38(3).

[28] 左秀丽, 许树长, 王林恒, 等. 中国显微内镜消化系统疾病临床应用共识意见[J]. 胃肠病学, 2023, 28(02): 91-106.

[29] Banham M R, Katsaggelos A K. Digital image restoration[J]. IEEE Signal Processing Magazine, 1997, 14(2): 24-41.

[30] Szczotka A B. Online super-resolution for fibre-bundle-based confocal laser endomicroscopy[D]. UCL (University College London), 2021.

[31] Kyrish M, Kester R, Richards-Kortum R, *et al*. Improving spatial resolution of a fiber bundle optical biopsy system[C]//BiOS. San Francisco, USA: SPIE, 2010: 755807.

[32] Cheon G W, Cha J, Kang J U. Random transverse motion-induced spatial compounding for fiber bundle imaging[J]. Optics Letters, 2014, 39(15): 4368-4371.

[33] Vyas K, Hughes M, Rosa B G, *et al*. Fiber bundle shifting endomicroscopy for high-resolution imaging[J]. Biomedical Optics Express, 2018, 9(10): 4649-4664.

[34] Chang Y, Lin W, Cheng J, *et al*. Compact high-resolution endomicroscopy based on fiber bundles and image stitching[J]. Optics Letters, 2018, 43(17): 4168-4171.

[35] Renteria C, Suárez J, Licudine A, *et al*. Depixelation and enhancement of fiber bundle images by bundle rotation[J]. Applied Optics, 2020, 59(2): 536-544.

[36] Jeon H, Pawlowski M E, Tkaczyk T S. High-resolution endomicroscopy with a spectrally encoded miniature objective[J]. Biomedical Optics Express, 2019, 10(3): 1432-1445.

[37] Zheng Z, Cai B, Kou J, *et al*. A honeycomb artifacts removal and super resolution method for fiber-optic images[C]//Advances in Intelligent Systems and Computing, IAS 2016. Shanghai, China:

中国知网 https://www.cnki.net

Springer, 2017: 771-779.

[38] Han J H, Yoon S M. Depixelation of coherent fiber bundle endoscopy based on learning patterns of image prior[J]. Optics Letters, 2011, 36(16): 3212-3214.

[39] Shao J, Liao W C, Liang R, *et al*. Resolution enhancement for fiber bundle imaging using maximum a posteriori estimation[J]. Optics Letters, 2018, 43(8): 1906-1909.

[40] Dumas J P, Lodhi M A, Taki B A, *et al*. Computational endoscopy—a framework for improving spatial resolution in fiber bundle imaging[J]. Optics Letters, 2019, 44(16): 3968.

[41] Jiang Z, Zhao X, Wen Y, *et al*. Block-based compressed sensing for fast optic fiber bundle imaging with high spatial resolution[J]. Optics Express, 2023, 31(11): 17235-17249.

[42] Yuan H, Zhang X, Wang F, *et al*. Resolution enhancement for flexible microscopic imaging based on dictionary learning[J]. Optics Express, 2020, 28(23): 35047-35060.

[43] Liu J, Zhou W, Xu B, *et al*. Honeycomb pattern removal for fiber bundle endomicroscopy based on a two-step iterative shrinkage thresholding algorithm[J]. AIP Advances, 2020, 10(4): 045004.

[44] Bioucas-Dias J M, Figueiredo Má A T. A new twist: Two-step iterative shrinkage/thresholding algorithms for image restoration[J]. IEEE Transactions on Image Processing, 2007, 16(12): 2992-3004.

[45] Liu J, Zhou W, Xu B, *et al*. Restoration for fiber bundle endomicroscopy using a fast iterative shrinkage-thresholding algorithm[C]//Conference on Biomedical Optics. Beijing, China: SPIE, 2020: 110.

[46] Beck A, Teboulle M. A fast iterative shrinkage-thresholding algorithm with application to wavelet-based image deblurring[C]//2009 IEEE International Conference on Acoustics, Speech and Signal Processing. Taipei, China: IEEE, 2009: 693-696.

[47] Su J, Xu B, Yin H. A survey of deep learning approaches to image restoration[J]. Neurocomputing, 2022, 487: 46-65.

[48] Shao J, Zhang J, Huang X, *et al*. Fiber bundle image restoration using deep learning[J]. Optics Letters, 2019, 44(5): 1080.

[49] Shao J, Zhang J, Liang R, *et al*. Fiber bundle imaging resolution enhancement using deep learning[J]. Optics Express, 2019, 27(11): 15880.

[50] Ravì D, Szczotka A B, Shakir D I, *et al*. Effective deep learning training for single-image super-resolution in endomicroscopy exploiting video-registration-based reconstruction[J]. International Journal of Computer Assisted Radiology and Surgery, 2018, 13(6): 917-924.

[51] Dong C, Loy C C, Tang X. Accelerating the super-resolution convolutional neural network[C]//Proceedings of the 14th European Conference on Computer Vision. Amsterdam, The Netherlands: Springer, 2016: 391-407.

[52] Lim B, Son S, Kim H, *et al*. Enhanced deep residual networks for single image super-resolution[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops. Honolulu, USA: IEEE, 2017: 1132-1140.

[53] Ledig C, Theis L, Huszár F, *et al*. Photo-realistic single image super-resolution using a generative

中国知网 https://www.cnki.net

adversarial network[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, USA: IEEE, 2017: 105-114.

[54] Ravì D, Szczotka A B, Pereira S P, *et al*. Adversarial training with cycle consistency for unsupervised super-resolution in endomicroscopy[J]. Medical Image Analysis, 2019, 53: 123-131.

[55] Szczotka A B, Shakir D I, Clarkson M J, *et al*. Zero-shot super-resolution with a physically-motivated downsampling kernel for endomicroscopy[J]. IEEE Transactions on Medical Imaging, 2021, 40(7): 1863-1874.

[56] Xu B, Liu J, Zhou W, *et al*. Fiber bundle image restoration using conditional generative adversarial network[C]//Conference on AI in Optics and Photonics. Beijing, China: SPIE, 2020: 312.

[57] Yao B, Huang B, Li X, *et al*. Depixelation and image restoration with meta-learning in fiber-bundle-based endomicroscopy[J]. Optics Express, 2022, 30(4): 5038-5050.

[58] Zhang C, Gu Y, Yang G Z. Contrastive adversarial learning for endomicroscopy imaging super-resolution[J]. IEEE Journal of Biomedical and Health Informatics, 2023, 27(8): 3994-4005.

[59] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//The 18th International Conference on Medical Image Computing and Computer-Assisted Intervention. Munich, Germany: Springer, 2015: 234-241.

[60] Izadi S, Mirikharaji Z, Zhao M, *et al*. Whitenner-blind image denoising via noise whiteness priors[C]//2019 IEEE/CVF International Conference on Computer Vision Workshop. Seoul, Korea (South): IEEE, 2019: 476-484.

[61] Izadi S, Hamarneh G. Patch-based non-local bayesian networks for blind confocal microscopy denoising[C]//The 23rd International Conference on Medical Image Computing and Computer-Assisted Intervention. Lima, Peru: Springer, 2020: 46-55.

[62] Zhang K, Zuo W, Chen Y, *et al*. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising[J]. IEEE Transactions on Image Processing, 2017, 26(7): 3142-3155.

[63] Pilonis N D, Januszewicz W, di Pietro M. Confocal laser endomicroscopy in gastro-intestinal endoscopy: Technical aspects and clinical applications[J]. Translational Gastroenterology and Hepatology, 2022, 7: 7.

[64] Couceiro S, Barreto J P, Freire P, *et al*. Description and classification of confocal endomicroscopic images for the automatic diagnosis of inflammatory bowel disease[C]//Machine Learning in Medical Imaging. Berlin, Heidelberg: Springer, 2012: 144-151.

[65] Canny J. A computational approach to edge detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1986, PAMI-8(6): 679-698.

[66] Cortes C, Vapnik V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273-297.

[67] Mualla F, Schöll S, Bohr C, *et al*. Epithelial cell detection in endomicroscopy images of the vocal folds[C]//International Multidisciplinary Microscopy Congress. Antalya, Turkey: Springer, 2014: 201-205.

[68] Boschetto D, Mirzaei H, Leong R W L, *et al*. Semiautomatic detection of villi in confocal endoscopy for the evaluation of celiac disease[C]//2015 37th Annual International Conference of

中国知网 https://www.cnki.net

the IEEE Engineering in Medicine and Biology Society. Milan, Italy: IEEE, 2015: 8143-8146.

[69] Boschetto D, Mirzaei H, Leong R W L, *et al*. Superpixel-based automatic segmentation of villi in confocal endomicroscopy[C]//2016 IEEE-EMBS International Conference on Biomedical and Health Informatics. Las Vegas, USA: IEEE, 2016: 168-171.

[70] Azad R, Aghdam E K, Rauland A, *et al*. Medical image segmentation review: The success of u-net[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(12): 10076-10095.

[71] 陈伟彬. 共聚焦内窥镜图像中结肠隐窝分割算法研究[D]. 华中科技大学, 2022.

[72] Isola P, Zhu J Y, Zhou T, *et al*. Image-to-image translation with conditional adversarial networks[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, USA: IEEE, 2017: 5967-5976.

[73] Zhou J, Xiong H, Liu Q. A novel dual-branch asymmetric encoder–decoder segmentation network for accurate colonic crypt segmentation[J]. Computers in Biology and Medicine, 2024, 173: 108354.

[74] Zhang Q, Li Y, Xue C, *et al*. Glandsam: Injecting morphology knowledge into segment anything model for label-free gland segmentation[J]. IEEE Transactions on Medical Imaging, 2025, 44(2): 1070-1082.

[75] Jehanzaib M, Almalioglu Y, Ozyoruk K B, *et al*. A robust image segmentation and synthesis pipeline for histopathology[J]. Medical Image Analysis, 2025, 99: 103344.

[76] Chen J, Mei J, Li X, *et al*. Transunet: Rethinking the u-net architecture design for medical image segmentation through the lens of transformers[J]. Medical Image Analysis, 2024, 97: 103280.

[77] Cao H, Wang Y, Chen J, *et al*. Swin-unet: Unet-like pure transformer for medical image segmentation[C]//Proceedings of the 17th European Conference on Computer Vision. Tel Aviv, Israel: Springer, 2023: 205-218.

[78] Paranjape J N, Sikder S, Vedula S S, *et al*. S-sam: Svd-based fine-tuning of segment anything model for medical image segmentation[M]//The 27th Medical Image Computing and Computer Assisted Intervention. Marrakesh, Morocco: Springer, 2024: 720-730.

[79] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.

[80] Rublee E, Rabaud V, Konolige K, *et al*. Orb: An efficient alternative to sift or surf[C]//2011 International Conference on Computer Vision. Barcelona: IEEE, 2011: 2564-2571.

[81] Lecun Y, Bottou L, Bengio Y, *et al*. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[82] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C]//Twenty-sixth Annual Conference on Neural Information Processing Systems (NeurIPS 2012). Lake Tahoe, USA: Curran Associates, Inc., 2012: 1097-1105.

[83] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//3rd International Conference on Learning Representations. San Diego, USA: Computational and Biological Learning Society, 2015: 1-14.

中国知网 https://www.cnki.net

[84] Srivastava S, Rodríguez J J, Rouse A R, *et al*. Computer-aided identification of ovarian cancer in confocal microendoscope images[J]. Journal of biomedical optics, 2008, 13(2): 024021-024021.

[85] Srivastava S, Rodriguez J J, Rouse A R, *et al*. Analysis of confocal microendoscope images for automatic detection of ovarian cancer[C]//IEEE International Conference on Image Processing. Genoa, Italy: IEEE, 2005, 1: I-1113.

[86] Petitjean C, Benoist J, Thiberville L, *et al*. Classification of in-vivo endomicroscopic images of the alveolar respiratory system[C]//Proceedings of the IAPR Conference on Machine Vision Applications. Yokohama, JAPAN: HAL, 2009: 471-474.

[87] Désir C, Petitjean C, Heutte L, *et al*. Using a priori knowledge to classify in vivo images of the lung[C]//Advanced Intelligent Computing Theories and Applications. With Aspects of Artificial Intelligence. Berlin, Heidelberg: Springer, 2010, 6216: 207-212.

[88] Désir C, Petitjean C, Heutte L, *et al*. An svm-based distal lung image classification using texture descriptors[J]. Computerized Medical Imaging and Graphics, 2012, 36(4): 264-270.

[89] Hebert D, Desir C, Petitjean C, *et al*. Detection of pathological condition in distal lung images[C]//2012 9th IEEE International Symposium on Biomedical Imaging. Barcelona, Spain: IEEE, 2012: 1603-1606.

[90] Desir C, Petitjean C, Heutte L, *et al*. Classification of endomicroscopic images of the lung based on random subwindows and extra-trees[J]. IEEE Transactions on Biomedical Engineering, 2012, 59(9): 2677-2683.

[91] Heutte L, Petitjean C, Désir C. Pruning trees in random forests for minimizing non detection in medical imaging[C]//Handbook of Pattern Recognition and Computer Vision. WORLD SCIENTIFIC, 2016: 89-107.

[92] Leonovych O, Koujan M R, Akram A, *et al*. Texture descriptors for classifying sparse, irregularly sampled optical endomicroscopy images[C]//Medical Image Understanding and Analysis. Southampton, UK: Springer, 2018: 165-176.

[93] Koujan M R, Akram A, McCool P, *et al*. Multi-class classification of pulmonary endomicroscopic images[C]//2018 IEEE 15th International Symposium on Biomedical Imaging. Washington, USA: IEEE, 2018: 1574-1577.

[94] Jaremenko C, Maier A, Steidl S, *et al*. Classification of confocal laser endomicroscopic images of the oral cavity to distinguish pathological from healthy tissue[C]//Bildverarbeitung für die Medizin 2015. Berlin, Heidelberg: Springer, 2015: 479-485.

[95] Wan S, Sun S, Bhattacharya S, *et al*. Towards an efficient computational framework for guiding surgical resection through intra-operative endo-microscopic pathology[C]//The 18th International Conference on Medical Image Computing and Computer-Assisted Intervention. Munich, Germany: Springer, 2015: 421-429.

[96] Jegou H, Douze M, Schmid C, *et al*. Aggregating local descriptors into a compact image representation[C]//2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. San Francisco, USA: IEEE, 2010: 3304-3311.

中国知网 https://www.cnki.net

[97] Osborne M R. Fisher's method of scoring[J]. International Statistical Review/Revue Internationale de Statistique, 1992: 99-117.

[98] Kamen A, Sun S, Wan S, *et al*. Automatic tissue differentiation based on confocal endomicroscopic images for intraoperative guidance in neurosurgery[J]. BioMed Research International, 2016, 2016: 1-8.

[99] Zubiolo A, Malandain G, André B, *et al*. A recursive approach for multiclass support vector machine application to automatic classification of endomicroscopic videos[C]//2014 International Conference on Computer Vision Theory and Applications. Lisbon, Portugal: IEEE, 2014: 441-447.

[100] Taunk P, Atkinson C D, Lichtenstein D, *et al*. Computer-assisted assessment of colonic polyp histopathology using probe-based confocal laser endomicroscopy[J]. International Journal of Colorectal Disease, 2019, 34(12): 2043-2051.

[101] Dosovitskiy A, Beyer L, Kolesnikov A, *et al*. An image is worth 16x16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations. Vienna, Austria: ICLR, 2021: 1-12.

[102] Hong J, Park B yong, Park H. Convolutional neural network classifier for distinguishing barrett's esophagus and neoplasia endomicroscopy images[C]//2017 39th Annual International Conference of the IEEE Engineering in Medicine and Biology Society. Jeju, Korea (South): IEEE, 2017: 2892-2895.

[103] Vo K, Jaremenko C, Bohr C, *et al*. Automatic classification and pathological staging of confocal laser endomicroscopic images of the vocal cords[C]//Bildverarbeitung für die Medizin 2017. Berlin, Heidelberg: Springer, 2017: 312-317.

[104] Aubreville M, Goncalves M, Knipfer C, *et al*. Patch-based carcinoma detection on confocal laser endomicroscopy images - a cross-site robustness assessment[C]//The 11th International Joint Conference on Biomedical Engineering Systems and Technologies. Funchal, Portugal: SCITEPRESS - Science and Technology Publications, 2018: 27-34.

[105] Szegedy C, Vanhoucke V, Ioffe S, *et al*. Rethinking the inception architecture for computer vision[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, USA: IEEE, 2016: 2818-2826.

[106] Izadyyazdanabadi M, Belykh E, Martirosyan N, *et al*. Improving utility of brain tumor confocal laser endomicroscopy: Objective value assessment and diagnostic frame detection with convolutional neural networks[C]//Medical Imaging 2017: Computer-Aided Diagnosis. Orlando, USA: SPIE, 2017, 10134: 651-659.

[107] Szegedy C, Liu W, Jia Y, *et al*. Going deeper with convolutions[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition. Boston, USA: IEEE, 2015: 1-9.

[108] Izadyyazdanabadi M, Belykh E, Mooney M, *et al*. Convolutional neural networks: Ensemble modeling, fine-tuning and unsupervised semantic localization for neurosurgical CLE images[J]. Journal of Visual Communication and Image Representation, 2018, 54: 10-20.

[109] Gessert N, Bengs M, Wittig L, *et al*. Deep transfer learning methods for colon cancer classification

中国知网 https://www.cnki.net

in confocal laser microscopy images[J]. International Journal of Computer Assisted Radiology and Surgery, 2019, 14(11): 1837-1845.

[110] Deng J, Dong W, Socher R, *et al*. Imagenet: A large-scale hierarchical image database[C]//2009 IEEE Conference on Computer Vision and Pattern Recognition. Miami, FL: IEEE, 2009: 248-255.

[111] Huang G, Liu Z, Van Der Maaten L, *et al*. Densely connected convolutional networks[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, USA: IEEE, 2017: 2261-2269.

[112] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, USA: IEEE, 2018: 7132-7141.

[113] N. Murthy V, Singh V, Sun S, *et al*. Cascaded deep decision networks for classification of endoscopic images[C]//SPIE Medical Imaging. Orlando, USA: SPIE, 2017: 101332B.

[114] Gu Y, Vyas K, Yang J, *et al*. Transfer recurrent feature learning for endomicroscopy image recognition[J]. IEEE Transactions on Medical Imaging, 2018, 38(3): 791-801.

[115] Gu Y, Xu Y, Huang X, *et al*. Toward robust histology-prior embedding for endomicroscopy image classification[J]. IEEE Transactions on Medical Imaging, 2022, 41(11): 3242-3252.

[116] Lucas M, Liem E I M L, Savci-Heijink C D, *et al*. Toward automated in vivo bladder tumor stratification using confocal laser endomicroscopy[J]. Journal of Endourology, 2019, 33(11): 930-937.

[117] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, USA: IEEE, 2017: 1800-1807.

[118] Szegedy C, Ioffe S, Vanhoucke V, *et al*. Inception-v4, inception-resnet and the impact of residual connections on learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. San Francisco, USA: AAAI Press, 2017, 31(1): 4278-4284.

[119] Cao R, Shang H, Zhang L, *et al*. Transformer for computer-aided diagnosis of laryngeal carcinoma in pCLE images[C]//2021 International Conference on Networking Systems of AI. Shanghai, China: IEEE, 2021: 181-188.

[120] He K, Zhang X, Ren S, *et al*. Deep residual learning for image recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, USA: IEEE, 2016: 770-778.

[121] Andre B, Vercauteren T, Perchant A, *et al*. Endomicroscopic image retrieval and classification using invariant visual features[C]//2009 IEEE International Symposium on Biomedical Imaging: From Nano to Macro. Boston, USA: IEEE, 2009: 346-349.

[122] André B, Vercauteren T, Perchant A, *et al*. Introducing space and time in local feature-based endomicroscopic image retrieval[C]//Medical Content-Based Retrieval for Clinical Decision Support. Berlin, Heidelberg: Springer, 2010: 18-30.

[123] Andre B, Vercauteren T, Buchner A M, *et al*. Endomicroscopic video retrieval using mosaicing and visualwords[C]//2010 IEEE International Symposium on Biomedical Imaging: From Nano to Macro. Rotterdam: IEEE, 2010: 1419-1422.

[124] André B, Vercauteren T, Ayache N. Content-based retrieval in endomicroscopy: Toward an

中国知网 https://www.cnki.net

efficient smart atlas for clinical diagnosis[C]//Medical Content-Based Retrieval for Clinical Decision Support. Berlin, Heidelberg: Springer, 2012: 12-23.

[125] Andre B, Vercauteren T, Buchner A M, *et al*. Learning semantic and visual similarity for endomicroscopy video retrieval[J]. IEEE Transactions on Medical Imaging, 2012, 31(6): 1276-1288.

[126] Watcharapichat P. Image processing and classification algorithm to detect cancerous cells morphology when using in-vivo probe-based confocal laser endomicroscopy for the lower gastrointestinal tract[J]. Department of Computing. Imperial College, 2012, 65.

[127] Kantorovich L V. Mathematical methods of organizing and planning production[J]. Management Science, 1960, 6(4): 366-422.

[128] Kohandani Tafresh M, Linard N, André B, *et al*. Semi-automated query construction for content-based endomicroscopy video retrieval[C]//The 17th International Conference on Medical Image Computing and Computer-Assisted Intervention. Boston, USA: Springer, 2014: 89-96.

[129] André B, Vercauteren T, Buchner A M, *et al*. Retrieval evaluation and distance learning from perceived similarity between endomicroscopy videos[C]//The 14th International Conference on Medical Image Computing and Computer-Assisted Intervention. Toronto, Canada: Springer, 2011: 297-304.

[130] Gu Y, Yang J, Yang G Z. Multi-view multi-modal feature embedding for endomicroscopy mosaic classification[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition Workshops. Las Vegas, USA: IEEE, 2016: 1315-1323.

[131] Gu Y, Vyas K, Shen M, *et al*. Deep graph-based multimodal feature embedding for endomicroscopy image retrieval[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(2): 481-492.

[132] Vercauteren T. Image registration and mosaicing for dynamic in vivo fibered confocal microscopy[D]. École Nationale Supérieure des Mines de Paris, 2008.

[133] Butola A, Joshi R, Usmani K, *et al*. Discrete cosine transform and total variation denoising based optimization approach for pixelation removal in fiber optic imaging system[C]//3D Image Acquisition and Display: Technology, Perception and Applications. Optica Publishing Group, 2020: JW2A-10.

[134] Lehtinen J, Munkberg J, Hasselgren J, *et al*. Noise2noise: Learning image restoration without clean data[C]//The 35th International Conference on Machine Learning. Stockholm, Sweden: PMLR, 2018: 2965-2974.

[135] Moran N, Schmidt D, Zhong Y, *et al*. Noisier2noise: Learning to denoise from unpaired noisy data[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos, USA: IEEE, 2020: 12061-12069.

[136] Xie Y, Wang Z, Ji S. Noise2same: Optimizing a self-supervised bound for image denoising[C]//Thirty-fourth Annual Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2020: 20320-20330.

中国知网 https://www.cnki.net

[137] Xu J, Huang Y, Cheng M M, *et al*. Noisy-as-clean: Learning self-supervised denoising from corrupted image[J]. IEEE Transactions on Image Processing, 2020, 29: 9316-9329.

[138] Huang T, Li S, Jia X, *et al*. Neighbor2neighbor: Self-supervised denoising from single noisy images[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville, USA: IEEE, 2021: 14776-14785.

[139] Khademi W, Rao S, Minnerath C, *et al*. Self-supervised poisson-gaussian denoising[C]//2021 IEEE Winter Conference on Applications of Computer Vision. Waikoloa, USA: IEEE, 2021: 2130-2138.

[140] Dabov K, Foi A, Katkovnik V, *et al*. Image denoising by sparse 3-d transform-domain collaborative filtering[J]. IEEE Transactions on Image Processing, 2007, 16(8): 2080-2095.

[141] Gu S, Zhang L, Zuo W, *et al*. Weighted nuclear norm minimization with application to image denoising[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition. Columbus, USA: IEEE, 2014: 2862-2869.

[142] Mildenhall B, Barron J T, Chen J, *et al*. Burst denoising with kernel prediction networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, USA: IEEE, 2018: 2502-2510.

[143] Marinč T, Srinivasan V, Gül S, *et al*. Multi-kernel prediction networks for denoising of burst images[C]//2019 IEEE International Conference on Image Processing. Taipei, China: IEEE, 2019: 2404-2408.

[144] Zhang B, Jin S, Xia Y, *et al*. Attention mechanism enhanced kernel prediction networks for denoising of burst images[C]//2020 IEEE International Conference on Acoustics, Speech and Signal Processing. Barcelona, Spain: IEEE, 2020: 2083-2087.

[145] Woo S, Park J, Lee J Y, *et al*. Cbam: Convolutional block attention module[C]//Proceedings of the 15th European Conference on Computer Vision. Munich, Germany: Springer, 2018: 3-19.

[146] Xu X, Li M, Sun W, *et al*. Learning spatial and spatio-temporal pixel aggregations for image and video denoising[J]. IEEE Transactions on Image Processing, 2020, 29: 7153-7165.

[147] Shen H, Zhao Z Q, Zhang W. Adaptive dynamic filtering network for image denoising[C]//Proceedings of the AAAI Conference on Artificial Intelligence. Washington, USA: AAAI Press, 2023, 37(2): 2227-2235.

[148] Lempitsky V, Vedaldi A, Ulyanov D. Deep image prior[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, USA: IEEE, 2018: 9446-9454.

[149] Krull A, Buchholz T O, Jug F. Noise2void - learning denoising from single noisy images[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, USA: IEEE, 2019: 2124-2132.

[150] Batson J, Royer L. Noise2self: Blind denoising by self-supervision[C]//The 36th International Conference on Machine Learning. Long Beach, USA: PMLR, 2019: 524-533.

[151] Quan Y, Chen M, Pang T, *et al*. Self2self with dropout: Learning self-supervised denoising from single image[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos, USA: IEEE, 2020: 1887-1895.

中国知网 https://www.cnki.net

[152] Zhou Y, Jiao J, Huang H, *et al*. When awgn-based denoiser meets real noises[C]//Proceedings of the AAAI Conference on Artificial Intelligence. New York, USA: AAAI Press, 2020, 34(07): 13074-13081.

[153] Shi W, Caballero J, Huszár F, *et al*. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, USA: IEEE, 2016: 1874-1883.

[154] Nair V, Hinton G E. Rectified linear units improve restricted boltzmann machines[C]//The 27th International Conference on Machine Learning. Madison, USA: Omnipress, 2010: 807-814.

[155] Barron J T. A general and adaptive robust loss function[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, USA: IEEE, 2019: 4326-4334.

[156] Zhu X, Hu H, Lin S, *et al*. Deformable convnets v2: More deformable, better results[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, USA: IEEE, 2019: 9300-9308.

[157] Sattar F, Floreby L, Salomonsson G, *et al*. Image enhancement based on a nonlinear multiscale method[J]. IEEE Transactions on Image Processing, 1997, 6(6): 888-895.

[158] Hao X, Gao S, Gao X. A novel multiscale nonlinear thresholding method for ultrasonic speckle suppressing[J]. IEEE Transactions on Medical Imaging, 1999, 18(9): 787-794.

[159] Ai D, Yang J, Chen Y, *et al*. Multiresolution generalized n dimension pca for ultrasound image denoising[J]. BioMedical Engineering OnLine, 2014, 13(1): 112.

[160] Paszke A, Gross S, Massa F, *et al*. Pytorch: An imperative style, high-performance deep learning library[C]//Thirty-Third Annual Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates, Inc., 2019, 721: 8026-8037.

[161] Akimoto N, Ugai T, Zhong R, *et al*. Rising incidence of early-onset colorectal cancer — a call to action[J]. Nature Reviews Clinical Oncology, 2021, 18(4): 230-243.

[162] Vázquez D, Bernal J, Sánchez F J, *et al*. A benchmark for endoluminal scene segmentation of colonoscopy images[J]. Journal of Healthcare Engineering, 2017, 2017: 1-9.

[163] Huang Y J, Dou Q, Wang Z X, *et al*. 3-d roi-aware u-net for accurate and efficient colorectal tumor segmentation[J]. IEEE Transactions on Cybernetics, 2020, 51(11): 5397-5408.

[164] Wang H, Cao P, Wang J, *et al*. Uctransnet: Rethinking the skip connections in u-net from a channel-wise perspective with transformer[C]//Proceedings of the AAAI Conference on Artificial Intelligence. US: AAAI Press, 2022, 36(3): 2441-2449.

[165] Yu Q, Qi L, Gao Y, *et al*. Crosslink-net: Double-branch encoder network via fusing vertical and horizontal convolutions for medical image segmentation[J]. IEEE Transactions on Image Processing, 2022, 31: 5893-5908.

[166] Fiaz M, Heidari M, Anwer R M, *et al*. Sa2-net: Scale-aware attention network for microscopic image segmentation[C]//The 34th British Machine Vision Conference. Aberdeen, UK: BMVA Press, 2023: 730-738.

[167] Li Z, Lyu H, Wang J. Fusionu-net: U-net with enhanced skip connection for pathology image

中国知网 https://www.cnki.net

segmentation[C]//The 16th Asian Conference on Machine Learning. Hanoi, Vietnam: PMLR, 2024: 694-706.

[168] Dai D, Dong C, Yan Q, *et al*. I2u-net: A dual-path u-net with rich information interaction for medical image segmentation[J]. Medical Image Analysis, 2024: 103241.

[169] Fan D P, Ji G P, Zhou T, *et al*. Pranet: Parallel reverse attention network for polyp segmentation[C]//The 23rd International Conference on Medical Image Computing and Computer-Assisted Intervention. Lima, Peru: Springer, 2020: 263-273.

[170] Tajbakhsh N, Gurudu S R, Liang J. Automated polyp detection in colonoscopy videos using shape and context information[J]. IEEE Transactions on Medical Imaging, 2015, 35(2): 630-644.

[171] Sasmal P, Iwahori Y, Bhuyan M K, *et al*. Active contour segmentation of polyps in capsule endoscopic images[C]//2018 International Conference on Signals and Systems. Bali, Indonesia: IEEE, 2018: 201-204.

[172] Zheng S, Lu J, Zhao H, *et al*. Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville, USA: IEEE, 2021: 6877-6886.

[173] Wang W, Xie E, Li X, *et al*. Pvt v2: Improved baselines with pyramid vision transformer[J]. Computational Visual Media, 2022, 8(3): 415-424.

[174] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos, USA: IEEE, 2015: 3431-3440.

[175] Oktay O, Schlemper J, Folgoc L L, *et al*. Attention u-net: Learning where to look for the pancreas[C]//Medical Imaging with Deep Learning. Amsterdam, The Netherlands: PMLR, 2018:1-10.

[176] Zhang Y, Liu H, Hu Q. Transfuse: Fusing transformers and cnns for medical image segmentation[C]//The 24th International Conference on Medical Image Computing and Computer-Assisted Intervention. Berlin, Heidelberg: Springer, 2021: 14-24.

[177] Yang L, Gu Y, Bian G, *et al*. Tmf-net: A transformer-based multiscale fusion network for surgical instrument segmentation from endoscopic images[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 72: 1-15.

[178] Valanarasu J M J, Oza P, Hacihaliloglu I, *et al*. Medical transformer: Gated axial-attention for medical image segmentation[C]//The 24th International Conference on Medical Image Computing and Computer-Assisted Intervention. Berlin, Heidelberg: Springer, 2021: 36-46.

[179] Liu Z, Lin Y, Cao Y, *et al*. Swin transformer: Hierarchical vision transformer using shifted windows[C]//2021 IEEE/CVF International Conference on Computer Vision. Montreal, Canada: IEEE, 2021: 9992-10002.

[180] Vaswani A, Shazeer N, Parmar N, *et al*. Attention is all you need[C]//Thirty-First Annual Conference on Neural Information Processing Systems. Long Beach, USA: Curran Associates, Inc., 2017: 6000-6010.

中国知网 https://www.cnki.net

[181] Sirinukunwattana K, Pluim J P, Chen H, *et al*. Gland segmentation in colon histology images: The glas challenge contest[J]. Medical image analysis, 2017, 35: 489-502.

[182] Jha D, Smedsrud P H, Riegler M A, *et al*. Kvasir-seg: A segmented polyp dataset[C]//26th International Conference on Multimedia Modeling. Daejeon, Korea (South): Springer, 2020: 451-462.

[183] Bernal J, Sánchez F J, Fernández-Esparrach G, *et al*. Wm-dova maps for accurate polyp highlighting in colonoscopy: Validation vs. saliency maps from physicians[J]. Computerized medical imaging and graphics, 2015, 43: 99-111.

[184] Silva J, Histace A, Romain O, *et al*. Toward embedded detection of polyps in wce images for early diagnosis of colorectal cancer[J]. International Journal of Computer Assisted Radiology and Surgery, 2014, 9: 283-293.

[185] Zhou Z, Rahman Siddiquee M M, Tajbakhsh N, *et al*. Unet++: Redesigning skip connections to exploit multiscale features in image segmentation[J]. IEEE Transactions on Medical Imaging, 2020, 39(6): 1856-1867.

[186] Ibtehaz N, Rahman M S. Multiresunet: Rethinking the u-net architecture for multimodal biomedical image segmentation[J]. Neural networks, 2020, 121: 74-87.

[187] Valanarasu J M J, Patel V M. Unext: Mlp-based rapid medical image segmentation network[C]//The 25th International Conference on Medical Image Computing and Computer-Assisted Intervention. Singapore: Springer, 2022: 23-33.

[188] Litjens G, Kooi T, Bejnordi B E, *et al*. A survey on deep learning in medical image analysis[J]. Medical Image Analysis, 2017, 42: 60-88.

[189] Gu Y, Vyas K, Yang J, *et al*. Unsupervised feature learning for endomicroscopy image retrieval[C]//The 20th International Conference on Medical Image Computing and Computer-Assisted Intervention. Quebec City, Canada: Springer, 2017: 64-71.

[190] Zhou J, Dong X, Liu Q. Boosting few-shot confocal endomicroscopy image recognition with feature-level mixsiam[J]. Biomedical Optics Express, 2023, 14(3): 1054-1070.

[191] Xiao Z, Xing H, Zhao B, *et al*. Deep contrastive representation learning with self-distillation[J]. IEEE Transactions on Emerging Topics in Computational Intelligence, 2024, 8(1): 3-15.

[192] Noroozi M, Favaro P. Unsupervised learning of visual representations by solving jigsaw puzzles[C]//Proceedings of the 14th European Conference on Computer Vision. Amsterdam, The Netherlands: Springer, 2016: 69-84.

[193] Doersch C, Gupta A, Efros A A. Unsupervised visual representation learning by context prediction[C]//2015 IEEE International Conference on Computer Vision. Santiago, Chile: IEEE, 2015: 1422-1430.

[194] Gidaris S, Singh P, Komodakis N. Unsupervised representation learning by predicting image rotations[C]//The Sixth International Conference on Learning Representations. Vancouver, Canada: Springer, 2018: 1-14.

[195] Pathak D, Krähenbühl P, Donahue J, *et al*. Context encoders: Feature learning by

中国知网 https://www.cnki.net

inpainting[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, USA: IEEE, 2016: 2536-2544.

[196] Larsson G, Maire M, Shakhnarovich G. Learning representations for automatic colorization[C]//Proceedings of the 14th European Conference on Computer Vision. Amsterdam, The Netherlands: Springer, 2016: 577-593.

[197] Chen T, Kornblith S, Norouzi M, *et al*. A simple framework for contrastive learning of visual representations[C]//The 37th International Conference on Machine Learning. JMLR.org, 2020: 1597-1607.

[198] Grill J B, Strub F, Altché F, *et al*. Bootstrap your own latent a new approach to self-supervised learning[C]//Thirty-fourth Annual Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2020: 21271-21284.

[199] Chen X, He K. Exploring simple siamese representation learning[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville, USA: IEEE, 2021: 15745-15753.

[200] Zbontar J, Jing L, Misra I, *et al*. Barlow twins: Self-supervised learning via redundancy reduction[C]//The 38th International Conference on Machine Learning. Austria: PMLR, 2021: 12310-12320.

[201] Ermolov A, Siarohin A, Sangineto E, *et al*. Whitening for self-supervised representation learning[C]//The 38th International Conference on Machine Learning. Austria: PMLR, 2021: 3015-3024.

[202] He K, Chen X, Xie S, *et al*. Masked autoencoders are scalable vision learners[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New Orleans, USA: IEEE, 2022: 15979-15988.

[203] Wang X, Du Y, Yang S, *et al*. Retccl: Clustering-guided contrastive learning for whole-slide image retrieval[J]. Medical Image Analysis, 2023, 83: 102645.

[204] Wang X, Yang S, Zhang J, *et al*. Transformer-based unsupervised contrastive learning for histopathological image classification[J]. Medical Image Analysis, 2022, 81: 102559.

[205] Caron M, Misra I, Mairal J, *et al*. Unsupervised learning of visual features by contrasting cluster assignments[C]//Thirty-fourth Annual Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2020: 9912-9924.

[206] Guo X, Zhao T, Lin Y, *et al*. Mixsiam: A mixture-based approach to self-supervised representation learning[A]. arXiv preprint arXiv:2111.02679, 2021.

[207] Sowrirajan H, Yang J, Ng A Y, *et al*. Moco pretraining improves representation and transferability of chest x-ray models[C]//Medical Imaging with Deep Learning. Lübeck, Germany: PMLR, 2021: 728-744.

[208] Ouyang C, Biffi C, Chen C, *et al*. Self-supervised learning for few-shot medical image segmentation[J]. IEEE Transactions on Medical Imaging, 2022, 41(7): 1837-1848.

[209] He K, Fan H, Wu Y, *et al*. Momentum contrast for unsupervised visual representation learning[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los

中国知网 https://www.cnki.net

Alamitos, USA: IEEE, 2020: 9726-9735.

[210] Koohbanani N A, Unnikrishnan B, Khurram S A, *et al*. Self-path: Self-supervision for classification of pathology images with limited annotations[J]. IEEE Transactions on Medical Imaging, 2021, 40(10): 2845-2856.

[211] Stacke K, Unger J, Lundström C, *et al*. Learning representations with contrastive self-supervised learning for histopathology applications[J]. The Journal of Machine Learning for Biomedical Imaging, 2022(23): 1-33.

[212] Wang X, Liu Z, Yu S X. Unsupervised feature learning by cross-level instance-group discrimination[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville, USA: IEEE, 2021: 12581-12590.

[213] Caron M, Bojanowski P, Joulin A, *et al*. Deep clustering for unsupervised learning of visual features[C]//Proceedings of the 15th European Conference on Computer Vision. Munich, Germany: Springer, 2018: 132-149.

[214] Li J, Zhou P, Xiong C, *et al*. Prototypical contrastive learning of unsupervised representations[C]//The Ninth International Conference on Learning Representations. Vienna, Austria: ICLR, 2021: 4-8.

[215] Snell J, Swersky K, Zemel R. Prototypical networks for few-shot learning[C]//Thirty-First Annual Conference on Neural Information Processing Systems. Long Beach, USA: Curran Associates Inc., 2017: 4080-4090.

[216] Bachman P, Hjelm R D, Buchwalter W. Learning representations by maximizing mutual information across views[C]//Thirty-Third Annual Conference on Neural Information Processing Systems. Vancouver, Canada: Curran Associates Inc., 2019: 15535-15545.

[217] Li Y, Yang M, Peng D, *et al*. Twin contrastive learning for online clustering[J]. Int. J. Comput. Vision, 2022, 130(9): 2205-2221.

[218] Li W, Wang L, Xu J, *et al*. Revisiting local descriptor based image-to-class measure for few-shot learning[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, USA: IEEE, 2019: 7253-7260.

[219] Chen D, Chen Y, Li Y, *et al*. Self-supervised learning for few-shot image classification[C]//2021 IEEE International Conference on Acoustics, Speech and Signal Processing. Toronto, Canada: IEEE, 2021: 1745-1749.

[220] Selvaraju R R, Cogswell M, Das A, *et al*. Grad-cam: Visual explanations from deep networks via gradient-based localization[C]//2017 IEEE International Conference on Computer Vision. Venice, Italy: IEEE, 2017: 618-626.

[221] Zhou J, Dong X, Liu Q. Clustering-guided twin contrastive learning for endomicroscopy image classification[J]. IEEE Journal of Biomedical and Health Informatics, 2024, 28(5): 2879-2890.

[222] Li J, Zhao G, Tao Y, *et al*. Multi-task contrastive learning for automatic ct and x-ray diagnosis of covid-19[J]. Pattern Recognition, 2021, 114: 107848.

[223] Bhattarai B, Subedi R, Gaire R R, *et al*. Histogram of oriented gradients meet deep learning: A

中国知网 https://www.cnki.net

novel multi-task deep network for 2d surgical image semantic segmentation[J]. Medical Image Analysis, 2023, 85: 102747.

[224] Zhao X, Li H, Shen X, *et al*. A modulation module for multi-task learning with applications in image retrieval[C]//Proceedings of the 15th European Conference on Computer Vision. Munich, Germany: Springer, 2018: 415-432.

[225] Ruder S. An overview of multi-task learning in deep neural networks[A]. arXiv preprint arXiv:1706.05098, 2017.

[226] Zhao R, Mao K. Fuzzy bag-of-words model for document representation[J]. IEEE Transactions on Fuzzy Systems, 2018, 26(2): 794-804.

[227] Perronnin F, Dance C. Fisher kernels on visual vocabularies for image categorization[C]//2007 IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos, USA: IEEE, 2007: 1-8.

[228] Csurka G, Dance C, Fan L, *et al*. Visual categorization with bags of keypoints[C]//Workshop on Statistical Learning in Computer Vision, 8th European Conference on Computer Vision. Prague, Czech Republic, 2004, 1(1-22): 1-2.

[229] Arandjelović R, Gronat P, Torii A, *et al*. Netvlad: Cnn architecture for weakly supervised place recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(6): 1437-1451.

[230] Gidaris S, Bursuc A, Komodakis N, *et al*. Learning representations by predicting bags of visual words[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos, USA: IEEE, 2020: 6926-6936.

[231] Gidaris S, Bursuc A, Puy G, *et al*. Obow: Online bag-of-visual-words generation for self-supervised learning[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville, USA: IEEE, 2021: 6826-6836.

[232] Chen X, Xie S, He K. An empirical study of training self-supervised vision transformers[C]//2021 IEEE/CVF International Conference on Computer Vision. Montreal, Canada: IEEE, 2021: 9620-9629.

[233] Caron M, Touvron H, Misra I, *et al*. Emerging properties in self-supervised vision transformers[C]//2021 IEEE/CVF International Conference on Computer Vision. Montreal, Canada: IEEE, 2021: 9630-9640.

[234] Zhou J, Wei C, Wang H, *et al*. Image bert pre-training with online tokenizer[C]//The Tenth International Conference on Learning Representations. Online: ICLR, 2022: 1-12.

中国知网 https://www.cnki.net