大连海事大学
DALIAN MARITIME UNIVERSITY

博士学位论文

DOCTOR DISSERTATION

论文题目：基于表征学习的水下图像清晰化方法研究

英文题目：Research on Underwater Image Clarification Methods Based on Representation Learning

作　　者：张得欢

指导教师：张维石

学位类别：工学博士

专业名称：计算机科学与技术

研究方向：计算机软件与理论

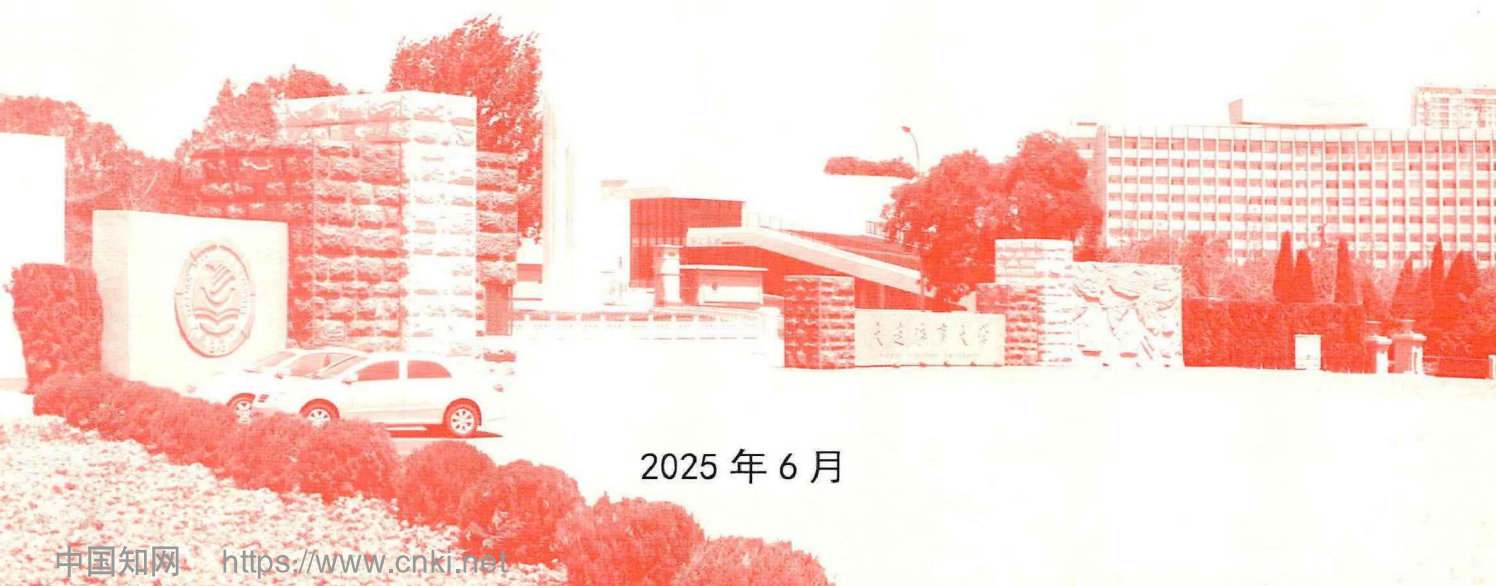

2025 年 6 月

中国知网 https://www.cnki.net

博 士 学 位 论 文

基于表征学习的水下图像清晰化方法研究

Research on Underwater Image Clarification Methods Based on Representation Learning

作 者 姓 名：张得欢

学　　号：0120210090

指 导 教 师：张维石　教授

学 科 专 业：计算机科学与技术

学 位 类 别：工学博士

培 养 单 位：信息科学技术学院

答 辩 时 间：2025 年 06 月 03 日

大连海事大学

Dalian　Maritime　University

中国知网　https://www.cnki.net

创 新 点 摘 要

1. 针对水下局部深度与光衰减耦合关系建模不准确问题，提出基于光衰减表征的自适应颜色校正方法。以水下成像物理模型为基础，分析光衰减在不同水深与水质条件下的空间差异性特征，建模底层像素级表征，采用图像空间划分策略提取局部光照区域，构建空间可变的颜色补偿因子场。采用双线性插值策略实现区域补偿因子的平滑扩展，避免全局校正方法中存在的前景过度补偿与背景恢复不足问题。实验结果表明，在复杂水深与非均匀光照场景下具备较强的颜色还原能力与结构一致性，为水下图像的物理一致性恢复提供有效支撑。

2. 针对不同尺度下图像退化的主导因素难解析问题，提出基于内监督协同引导的多尺度图像清晰化方法。该方法构建多分辨率编码-解码结构，以分层感知策略获取局部纹理细节与全局场景结构，建模语义表征，基于双分支上下文注意力机制增强局部细节和全局语义的表征能力。采用自适应选择性内在监督模块，约束尺度间融合过程中重点保留有效结构特征，抑制噪声干扰与冗余增强，增强尺度间特征交互与信息聚合。实验结果表明，该方法与代表性方法相比在全参考指标提升 9.5%，有效克服结构还原能力与泛化性方面的不足，实现对不同尺度退化特征的精准感知与响应增强，在复杂水下场景下表现出更强的细节恢复与场景稳健性。

3. 针对水下图像清晰化过程中存在的物理建模与优化目标间的表征空间不一致问题，提出基于场景引导的水下图像清晰化方法。该方法通过光照-反射分解模型构建真实场景的物理表征空间，建模场景表征。联合原始图像和场景多表征空间，建模多尺度场景语义，通过上下文融合机制设计的多表征空间解码器实现一致性学习与融合增强。该方法保留场景结构细节，保持模型的稳健物理约束性与高可解释能力，提升模型的泛化稳定性与复杂光照场景下的适应能力。实验结果表明，该方法与代表性方法相比在全参考指标提升 3.2%，在复杂光照场景下表现出良好的稳定性和适应性。

4. 针对水下序列图像中因流变扰动与多源运动引发的帧间结构错位与时序信息失配问题，提出基于跨帧表征对齐的水下序列图像清晰化方法。该方法从时序维度集成跨帧特征建模机制，采用自适应跨帧特征对齐模块实现帧间图像的动态结构对齐与语义一致性。通过自适应跨帧特征方法对多帧间场景信息进行优化融合，采用时空注意力机制增强帧间关键区域表征。实验结果表明，该方法在720p分辨率下推理速度达到0.237秒，在序列水下场景下有效提升图像清晰度，适用于实际应用中的高动态视频增强任务。

中国知网 https://www.cnki.net

摘　要

由于水体介质对光的吸收和散射效应，水下光学图像存在色彩失真、多尺度退化、光照不均、动态场景适应性不足等问题，严重影响水下目标检测、环境场景感知与重建、无人潜器定位、导航等水下计算机视觉高级任务的准确性。现有水下图像清晰化方法在局部深度与光衰减解耦、多尺度语义建模、物理一致性、结构表达能力和动态场景适应性等方面仍存在不足，导致在复杂水下环境中的适应性较差。针对上述问题，论文开展基于表征学习的水下图像清晰化方法研究，构建从静态图像到序列图像、从感知表征到机制对齐的多维建模框架，涵盖空间维度、多尺度语义维度、场景维度与时序动态维度，以提升图像清晰度、语义一致性及跨场景泛化能力。

论文的主要研究内容及成果如下：

1. 基于光衰减表征的水下图像自适应颜色校正方法研究。针对局部深度与光衰减耦合关系建模不准确问题，深入分析水体中光传播机理，提出基于光衰减表征的水下图像自适应颜色校正方法。设计局部图像块划分策略自适应计算补偿因子，结合双线性插值技术实现全局平滑扩展，在不同深度场景下实现更加精准的颜色校正。使用通道色偏因子构建颜色重建机制，有效解决全局恢复过程中的前景过度补偿与背景恢复不足等问题，提升水下图像的色彩保真度与视觉一致性，在复杂水下环境中表现出更强的自适应能力与鲁棒性。实验结果表明，在非均匀色彩退化和复杂水下环境下，实现更加自然、平滑的色彩恢复；结合图像清晰化方法设计预处理有效性实验，验证所提出方法在图像清晰化任务中的有效性。

2. 基于内监督协同多尺度表征的水下图像清晰化方法研究。针对不同尺度下图像退化的主导因素难解析问题，从结构建模角度构建多尺度编码器-解码器框架融合多分辨率图像信息，提出基于内监督协同多尺度表征的水下图像清晰化方法。基于双分支的内在上下文注意力机制建模多尺度语义特征，针对局部细节表征与全局上下文建模问题，提出综合特征注意力方法与分辨率引导内在注意力方法，设计分层上下文感知特征提取机制，深度建模图像空间的上下文关联，以提升整体图像理解与建模能力。基于自适应选择性内在监督特征模块自适应筛选多尺度特征中的有效信息，抑制冗余和噪声干扰，增强多尺度特征融合能力和提升特征融合的鲁棒性。设计多退化损失函数，在不同尺度阶段联合优化像素级误差与感知一致性，实现细节与结构的协同恢复。实验结果表明，在 UIEB、U45、LSUI 等多个水下图像数据集上，PSNR、SSIM、UIQM、CCF 等综合指标上优于现有方法，在全参考指标上与代表性方法相比提升 9.5%的客观值，有效提升图像的清晰度和增强结构稳定性。

中国知网　https://www.cnki.net

3. 基于场景表征引导的水下图像清晰化方法研究。针对表征空间差异与优化目标冲突问题，从表征机制融合角度创新性地采用双输入编解码结构，提出基于场景表征引导的水下图像清晰化方法，从原始图像表征空间与场景表征空间中建模语义信息。在解码阶段设计基于上下文信息的多级集成方法，融合原始图像表征空间和反射分量表征空间的特征信息，优化全局光照分布与局部纹理重建，有效抑制伪影生成。采用平滑 L1 损失与感知损失的联合优化策略，在像素级精度与语义一致性间实现平衡。实验结果表明，该方法在 UIEB 数据集的全参考指标与代表性方法相比提升 3.2%的客观值，设计显著性目标检测实验验证该方法在检测任务的有效性，为复杂水下环境图像清晰化提供高效鲁棒的解决方案。

4. 基于跨帧表征对齐的水下序列图像清晰化方法。针对动态水下环境流变扰动与跨帧结构错位问题，提出基于跨帧表征对齐的水下序列图像清晰化方法。该方法集成时序维度，利用可变形卷积动态校正跨帧间的流变失准，解决运动模糊导致的信息错位；结合时空特征优化注意力机制，通过通道与空间双分支注意力动态加权跨帧特征，降低运动噪声并增强关键区域表征。使用 Charbonnier 损失与 VGG 感知损失平衡像素级重建精度与语义一致性。实验结果表明，该方法在 MVUI 数据集的 PSNR 与 SSIM 分别达到 28.83 dB 与 0.96，在 720p 分辨率下推理速度达 0.237 秒。设计图像分割任务与显著性检测任务的应用测试，验证该方法在复杂水下场景中目标检测等实用价值，适用于海洋探测、智能水下机器人等实际应用场景。

基于表征学习的水下图像清晰化在色彩保真度、细节增强、动态场景适应性、物理一致性与计算效率等关键指标上表现出明显优势，本研究有助于推进水下计算机视觉领域的技术创新与理论发展，为跨设备、跨水域的泛化应用提供有效的技术支撑。研究成果可广泛应用于水下目标检测、生态环境监测、海洋资源勘探以及智能水下机器人导航等任务，为水下智能感知系统的实用化和规模化部署奠定理论与技术基础。

关键词：水下图像；表征学习；图像清晰化；注意力机制

中国知网 https://www.cnki.net

ABSTRACT

Due to the absorption and scattering effects of the water medium on light, underwater optical images often suffer from color distortion, multi-scale degradation, uneven illumination, and insufficient adaptability to dynamic scenes. These issues severely affect the accuracy of high-level underwater computer vision tasks such as target detection, environmental perception and reconstruction, and autonomous underwater vehicle localization and navigation. Existing underwater image clarification methods still exhibit limitations in local depth and light attenuation decoupling, multi-scale semantic modeling, physical consistency, structural representation capability, and dynamic scene adaptability, resulting in poor performance in complex underwater environments. To address these challenges, this thesis conducts research on underwater image clarification methods based on representation learning and constructs a multi-dimensional modeling framework that spans from static to sequential images and from perceptual representation to mechanism alignment, covering spatial, multi-scale semantic, scene, and temporal dynamic dimensions to enhance image clarity, semantic consistency, and cross-scene generalization capability.

The main research contents and contributions of this thesis are summarized as follows:

1. Adaptive Color Correction Method Based on Light Attenuation Representation. To tackle the inaccurate modeling of the coupling relationship between local depth and light attenuation, the propagation mechanism of light in water is thoroughly analyzed, and the adaptive color correction method based on light attenuation representation is proposed. A local image patch partitioning strategy is designed to adaptively compute compensation factors, combined with bilinear interpolation for global smoothing, achieving more accurate color correction across different depth scenarios. A channel color bias factor is introduced to construct a color reconstruction mechanism, effectively addressing issues such as overcompensation of foregrounds and insufficient background recovery in global restoration processes, thereby improving color fidelity and visual consistency. Experimental results demonstrate that the proposed method achieves more natural and smooth color restoration under non-uniform degradation and complex underwater conditions. Preprocessing experiments combined with image clarification tasks further verify the effectiveness of the proposed method.

2. Underwater Image Clarification Method via Self-supervised Collaborative Multi-scale Representation. To address the difficulty in analyzing dominant degradation factors across different scales, a multi-scale encoder-decoder framework is constructed to fuse multi-resolution image information, and underwater image clarification method via self-supervised collaborative multi-scale representation is proposed. A bifocal intrinsic-context attention is

中国知网 https://www.cnki.net

designed to model multi-scale semantic features, addressing both local detail representation and global context modeling. Comprehensive feature attention and resolution-guided intrinsic attention module are proposed, alongside a adaptive selective intrinsic supervision feature method to deeply model spatial context associations, enhancing overall image understanding and modeling capabilities. An adaptive selective intrinsic supervision module is introduced to filter effective information from multi-scale features, suppressing redundancy and noise while improving multi-scale feature fusion robustness. A multi-degradation loss function is designed to jointly optimize pixel-level errors and perceptual consistency at different scales, achieving collaborative restoration of details and structures. Experimental results show that the proposed method outperforms existing methods on UIEB, U45, and LSUI datasets, achieving a 9.5% improvement in comprehensive objective metrics such as PSNR, SSIM, UIQM, and CCF, significantly enhancing image clarity and structural stability.

3. Underwater Image Clarification Method Guided by Scene Representation. To address the conflict between representation space differences and optimization objectives, this method innovatively adopts a dual-input encoder-decoder structure and proposes underwater image clarification method guided by scene representation, modeling semantic information from both the original image and scene representation spaces. During decoding, a multi-stage integration method based on contextual information is designed to fuse features from the original image representation and reflectance component spaces, optimizing global illumination distribution and local texture reconstruction while effectively suppressing artifact generation. A joint optimization strategy combining smooth L1 loss and perceptual loss is employed to balance pixel-level accuracy and semantic consistency. Experimental results show a 3.2% improvement over representative methods on the UIEB dataset in full-reference metrics. Additionally, salient object detection experiments demonstrate the method's effectiveness in detection tasks, providing an efficient and robust solution for underwater image clarification in complex environments.

4. Cross-Frame Representation Alignment for Underwater Image Sequence Clarification Method. To address flow disturbance and cross-frame structural misalignment issues in dynamic underwater environments, this thesis proposes a cross-frame representation alignment for underwater image sequence clarification method. The method integrates temporal information and employs deformable convolutions to dynamically correct inter-frame flow misalignments, mitigating motion blur-induced information displacement. A spatiotemporal feature optimization attention mechanism is incorporated, using dual-branch channel and spatial attention to dynamically weight cross-frame features, reducing motion noise and enhancing key region representations. The Charbonnier loss and VGG perceptual loss are jointly optimized to balance pixel-level reconstruction accuracy and semantic consistency.

中国知网 https://www.cnki.net

Experimental results show that the method achieves 28.83 dB in PSNR and 0.96 in SSIM on the MVUI dataset, with an inference speed of 0.237 seconds at 720p resolution. Application tests on image segmentation and salient object detection tasks verify the method's practical value in underwater target detection under complex scenarios, demonstrating its applicability in tasks such as marine exploration and intelligent underwater robotics.

The representation learning-based underwater image clarification framework proposed in this thesis demonstrates significant advantages in color fidelity, detail enhancement, dynamic scene adaptability, physical consistency, and computational efficiency. This research contributes to advancing technological innovation and theoretical development in underwater computer vision, providing effective technical support for generalized applications across different devices and water environments. The outcomes of this thesis can be widely applied to underwater target detection, ecological environment monitoring, marine resource exploration, and intelligent underwater robot navigation, laying a theoretical and technical foundation for the practical deployment and large-scale application of underwater intelligent perception systems.

Key Words: Underwater Image; Representation Learning; Image Clarification; Attention Mechanism

中国知网 https://www.cnki.net

目 录

1 绪论.....1
1.1 研究背景.....1
1.2 国内外相关研究.....3
1.2.1 基于先验知识的水下图像清晰化方法.....3
1.2.2 无先验约束的水下图像清晰化方法.....6
1.2.3 基于表征学习的水下图像清晰化方法.....8
1.3 存在的问题.....12
1.4 研究内容与研究框架.....13
1.4.1 论文研究内容.....13
1.4.2 论文研究框架.....15
1.5 论文组织与结构.....17
2 相关理论与方法.....19
2.1 水下图像成像模型.....19
2.1.1 基于人类视觉的 Retinex 理论.....19
2.1.2 水下图像成像模型.....21
2.2 卷积神经网络.....22
2.2.1 非线性激活.....22
2.2.2 归一化与标准化.....23
2.2.3 残差连接.....23
2.3 水下图像评价指标.....23
2.3.1 全参考指标.....24
2.3.2 无参考指标.....27
2.4 本章小结.....30
3 基于光衰减表征的水下图像自适应颜色校正方法.....31
3.1 ACCM 方法提出.....31
3.2 基于图像块的局部自适应颜色复原方法.....33
3.3 基于通道色偏因子的全局颜色重建方法.....36
3.3.1 色偏因子的数学建模与理论分析.....36
3.3.2 全局颜色重建的优化方法.....37
3.4 ACCM 算法设计.....39
3.5 实验结果与分析.....39
3.5.1 定性质量评价.....39
3.5.2 定量质量评价.....43
3.5.3 ACCM 预处理的有效性.....44

中国知网 https://www.cnki.net

3.6 本章小结.....46
4 基于内监督协同多尺度表征的水下图像清晰化方法.....49
4.1 SCMR-Net 方法提出.....49
4.2 基于双分支的内在上下文注意力方法设计.....51
4.2.1 综合特征注意力方法.....52
4.2.2 分辨率引导的内在注意力方法.....53
4.2.3 分层上下文感知特征提取方法.....55
4.3 自适应选择性内在监督特征方法设计.....56
4.4 面向图像清晰化网络的多阶段损失函数设计.....57
4.4.1 平均绝对误差损失函数.....57
4.4.2 感知损失函数.....57
4.4.3 均方误差损失函数.....57
4.4.4 综合损失函数.....57
4.5 SCMR-Net 算法设计.....58
4.6 实验结果与分析.....61
4.6.1 实验设置说明.....61
4.6.2 对比实验分析.....62
4.6.3 消融实验分析.....69
4.6.4 效率分析.....71
4.7 本章小结.....72
5 基于场景表征引导的水下图像清晰化方法.....73
5.1 SRG-Net 方法提出.....73
5.2 基于 Retinex 模型的反射图像估计方法.....75
5.3 基于多尺度场景目标提取方法.....76
5.4 基于上下文信息的多级集成方法设计.....79
5.5 多表征空间特征恢复方法设计.....81
5.6 损失函数设计.....82
5.7 SRG-Net 算法设计.....82
5.8 实验结果与分析.....86
5.8.1 实验设置说明.....86
5.8.2 定性质量评价.....86
5.8.3 定量质量评价.....92
5.8.4 模型组件有效性评估.....95
5.8.5 效率分析.....99
5.9 显著性目标测试.....100
5.10 本章小结.....101
6 基于跨帧表征对齐的水下序列图像清晰化方法.....103
6.1 CFRA-Net 方法提出.....103

中国知网 https://www.cnki.net

6.2 自适应跨帧特征对齐方法设计 105
6.3 多尺度特征提取方法设计 106
6.4 时空特征优化方法设计 107
6.5 多尺度特征恢复方法设计 109
6.6 面向跨帧序列图像的损失函数设计 109
6.7 CFRA-Net 算法设计 110
6.8 实验结果与分析 112
6.8.1 实验设置说明 112
6.8.2 定性实验分析 113
6.8.3 定量实验分析 116
6.8.4 消融实验分析 118
6.8.5 效率分析 120
6.9 应用测试 122
6.9.1 图像分割任务 122
6.9.2 显著性检测任务 123
6.10 本章小结 124
7 结论与展望 125
7.1 结论 125
7.2 展望 127
参考文献 129

中国知网 https://www.cnki.net

图表目录

图目录

图 1.1 典型水下退化图像 1
图 1.2 水下图像清晰化促进跨域视觉任务统一表征的示意图 2
图 1.3 基于表征学习的水下图像清晰化方法研究框架 16
图 2.1 水下图像成像模型 21
图 3.1 基于光衰减表征的水下图像自适应颜色校正方法架构图 32
图 3.2 绿色均匀退化场景颜色校正结果的视觉对比图 40
图 3.3 绿色非均匀退化场景颜色校正结果的视觉对比图 41
图 3.4 蓝色非均匀退化场景颜色校正结果的视觉对比图 42
图 3.5 浅滩非均匀退化场景颜色校正结果的视觉对比图 42
图 3.6 UPRC 数据集真实水下图像颜色校正结果的视觉对比图 43
图 3.7 绿色场景不同水下图像清晰化方法结合 ACCM 预处理的视觉对比结果 45
图 3.8 蓝色场景不同水下图像清晰化方法结合 ACCM 预处理的视觉对比结果 45
图 3.9 UPRC 不同水下图像清晰化方法结合 ACCM 预处理的视觉对比结果 46
图 4.1 基于内监督协同多尺度表征的水下图像清晰化网络架构图 50
图 4.2 基于双分支的内在上下文注意力机制架构图 51
图 4.3 综合特征注意力模块架构图 52
图 4.4 分辨率引导的内在注意力模块架构图 54
图 4.5 分层上下文感知特征提取模块架构图 55
图 4.6 自适应选择性内在监督特征方法架构图 56
图 4.7 SCMR-Net 方法架构图 59
图 4.8 SCMR-Net 方法与对比方法在各种数据集的定性比较结果 62
图 4.9 SCMR-Net 和对比方法在绿色场景中增强结果和 RGB 直方图对比结果 66
图 4.10 SCMR-Net 和对比方法在蓝色场景中增强结果和 RGB 直方图对比结果 67
图 4.11 SCMR-Net 和对比方法在浅水域场景中增强结果和 RGB 直方图对比结果 68
图 4.12 Stage 的消融实验主观结果 71
图 5.1 基于场景表征引导的水下图像清晰化网络架构图 74
图 5.2 多尺度场景目标提取模块架构图 77
图 5.3 空间-通道注意力机制架构图 78

中国知网 https://www.cnki.net

图 5.4 基于上下文信息的多级集成模块架构图 79
图 5.5 SRG-Net 方法架构图 84
图 5.6 SRG-Net 方法与对比方法在 UIEB 数据集的主观结果 87
图 5.7 SRG-Net 方法与对比方法在 MABLs 数据集的主观结果 90
图 5.8 SRG-Net 方法与对比方法在 MABLs 数据集的直方图对比结果 91
图 5.9 SRG-Net 网络架构消融实验的对比结果 97
图 5.10 SRG-Net 模块内部的消融实验对比结果 98
图 5.11 SRG-Net 方法与对比方法在 MABLs 数据集的直方图对比结果 100
图 6.1 基于跨帧表征对齐的水下序列图像清晰化网络架构图 104
图 6.2 时空特征优化方法架构图 107
图 6.3 CFRA-Net 方法架构图 112
图 6.4 CFRA-Net 与对比方法在拍摄视角向下的可视化比较结果 113
图 6.5 CFRA-Net 与对比方法在拍摄视角平行的可视化比较结果 114
图 6.6 CFRA-Net 与对比方法在低后向散射图像的可视化比较结果 114
图 6.7 CFRA-Net 与对比方法在自然光图像的可视化比较结果 115
图 6.8 CFRA-Net 与对比方法在高后向散射图像的可视化比较结果 115
图 6.9 CFRA-Net 与对比方法的可见边缘像素数量可视化比较结果 119
图 6.10 CFRA-Net 与对比方法在图像分割任务的可视化对比结果 122
图 6.11 CFRA-Net 与对比方法在显著性检测任务的可视化比较结果 123

表目录

表 3.1 海洋水体中 Jerlov 水类型的 $\beta(\lambda)$ 值 34
表 3.2 沿海水体中 Jerlov 水类型的 $\beta(\lambda)$ 值 34
表 3.3 不同数据集测试图像和对比方法的 K 指标对比结果 44
表 4.1 SCMR-Net 方法与对比方法在 UIEB Val 数据集的全参考指标对比结果 63
表 4.2 SCMR-Net 方法与对比方法在 UIEB Val 数据集的无参考指标对比结果 64
表 4.3 SCMR-Net 方法与对比方法在 U45 数据集的无参考指标对比结果 64
表 4.4 SCMR-Net 方法与对比方法在 LSUI 数据集的全参考指标对比结果 65
表 4.5 SCMR-Net 方法与对比方法在 LSUI 数据集的无参考指标对比结果 65
表 4.6 不同阶段的消融研究定量结果 69

中国知网 https://www.cnki.net

表 4.7 BICA 模块的消融研究定量结果 70
表 4.8 ASISF 模块的消融研究定量结果 70
表 4.9 损失函数的消融研究定量结果 70
表 4.10 SCMR-Net 方法与对比方法在 UIEB 数据集的效率分析结果 71
表 5.1 SRG-Net 与现有对比方法在 UIEB Val 数据集的无参考指标对比结果 92
表 5.2 SRG-Net 与现有对比方法在 UIEB Val 数据集的全参考指标的对比结果 93
表 5.3 SRG-Net 与现有对比方法在 UIEB Test 数据集的无参考指标对比结果 94
表 5.4 SRG-Net 与现有对比方法在 MABLs 数据集的无参考指标对比结果 94
表 5.5 SRG-Net 与现有对比方法在 U45 数据集的无参考指标对比结果 95
表 5.6 SRG-Net 网络结构消融实验的全参考指标对比结果 96
表 5.7 SRG-Net 各模块消融实验的全参考指标对比结果 98
表 5.8 SRG-Net 各损失函数消融实验的全参考指标对比结果 99
表 5.9 SRG-Net 与现有对比方法的模型参数、推理时间和评测指标对比结果 100
表 6.1 CFRA-Net 方法与对比方法在 MVUI 数据集的客观指标对比结果 117
表 6.2 输入架构模块中消融实验的客观指标对比结果 118
表 6.3 CFRA-Net 模块中消融实验的客观指标对比结果 118
表 6.4 特征优化模块中 STA 模块数量消融实验的客观指标对比结果 120
表 6.5 CFRA-Net 方法与对比方法在 MVUI 数据集的效率分析结果 121

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景

国家“十四五”规划将海洋强国战略纳入国家发展蓝图。《“十四五”海洋经济发展规划》和《“十四五”智能制造发展规划》明确提出要加强智能水下探测设备的研制，提高水下信息感知能力，推动水下计算机视觉及智能水下机器人技术的发展。《中国制造 2025》明确提出将海洋工程装备列为重点发展方向，强调水下高精度成像技术作为深海探测装备智能化的核心基础。国家自然科学基金、科技部深海和极地关键技术与装备专项等重点项目持续支持水下视觉技术研究，旨在突破“卡脖子”技术，实现自主可控。国家政策与规划为海洋环境感知与水下智能装备发展提供重要的战略机遇。

随着“海洋强国”战略的深入实施与智慧海洋体系的加速构建，水下图像作为海洋环境感知与智能装备作业的重要信息载体，在海洋资源勘探、海洋生态监测、水下工程施工、智能潜器导航等任务中发挥着不可替代的作用[1,2]。水下图像清晰化作为基础性的底层感知技术，直接影响上层视觉任务的鲁棒性和可靠性，是构建水下智能装备的重要支撑[3,4]。

作为探索海洋的载体，水下图像面临复杂多变的成像环境，常受到光谱吸收、后向散射、光照变化、水流扰动等多源因素的影响，导致观测图像出现色彩失真、对比度下降、细节模糊以及结构错位等多重退化现象[5]，如图 1.1 所示。特别在深水区、浑浊水体及动态环境中，水下图像退化特征具有强烈的空间非均匀性和尺度耦合性，表现出明显的时序动态性，给水下图像清晰化研究带来巨大挑战[6]。

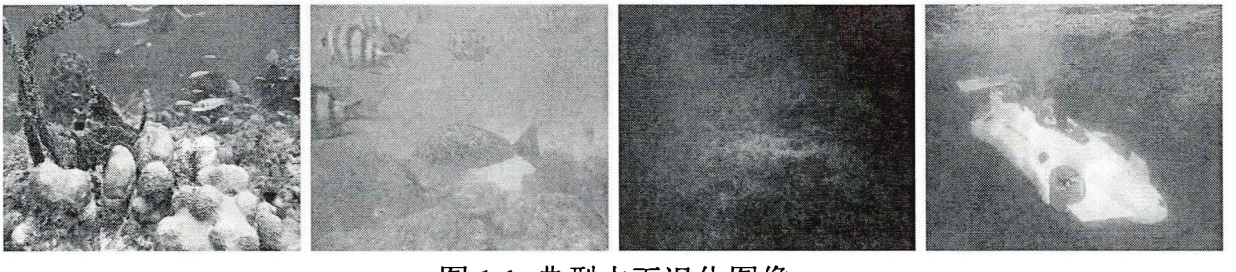

图 1.1 典型水下退化图像

Fig. 1.1 Typical underwater degraded image

由于水下成像环境具有高度复杂性和多变性，不同水域的浑浊度、光照条件、颗粒物浓度等光学特性差异，以及不同设备间的传感器特性、镜头参数、白平衡设置等差异，导致水下图像在空间水域维度和设备维度上表现出显著的表征域差异（Domain Gap），

中国知网 https://www.cnki.net

如图 1.2 所示。域差异不仅影响水下图像的视觉质量，严重制约基于深度学习的水下目标检测、目标追踪等高阶视觉任务的泛化能力。

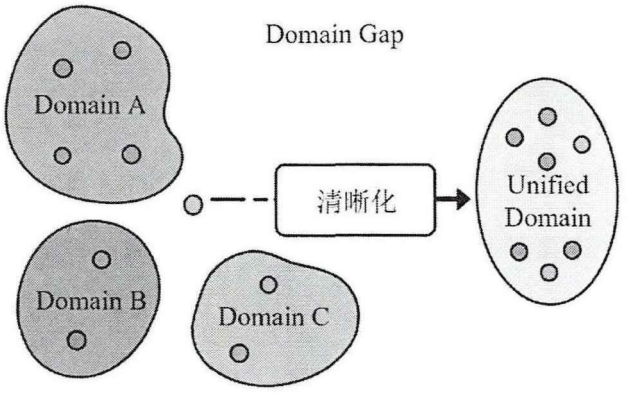

图 1.2 水下图像清晰化促进跨域视觉任务统一表征的示意图

Fig. 1.2 Illustration of underwater image clarification enabling unified representation domain for cross-domain visual tasks

为解决水下图像的复杂退化问题，将其统一到标准化的表征空间，研究者围绕基于先验知识的水下图像清晰化方法、无先验约束的水下图像清晰化方法、基于表征学习的水下图像清晰化方法等开展深入研究。基于先验知识的水下图像清晰化方法研究依赖于物理先验知识[7]，利用水下成像过程中的光学特性进行图像恢复，能够在一定程度上解决颜色失真与对比度下降等问题，但普遍依赖统计先验，限制在复杂水域条件下的适用性。部分研究则探索无先验约束的方式[8]，尽管在图像细节增强方面取得一定成效，但由于难以适配不同水域和设备的特性变化，往往导致图像质量波动较大，限制复杂环境下图像细节恢复与高层语义理解的能力。

随着人工智能的发展，基于表征学习的方法为水下清晰化提供新的研究方向[9]。通过学习水下图像在空间、尺度、物理、语义和时序等多维度的结构与规律，实现面向机制建模、可解释增强的清晰化策略。图像表征为图像中蕴含的颜色、纹理、边缘等底层特征，尺度关系、空间上下文等中层结构，以及目标结构、光照场景等高层语义进行建模和编码，形成对图像退化机制、结构属性和语义目标的可计算、可识别、可泛化的特征表示体系[10,11]。表征学习为水下图像清晰化提供一种更具灵活性、鲁棒性的框架，能够处理更复杂的水下环境中成像退化问题。

虽然表征学习可以显著提升水下清晰化方法，但在面对高复杂度水下退化环境时，现有方法仍面临以下科学挑战：（1）局部深度与光衰减之间的耦合关系建模不准确。水

中国知网 https://www.cnki.net

下图像中不同区域受光谱衰减影响程度差异显著，限制颜色补偿的物理一致性与区域自适应能力。（2）不同尺度下图像退化的主导因素难解析。水下图像在多个尺度层次上表现出异构退化现象，缺乏尺度间退化结构、噪声来源与感知敏感度缺乏系统性建模，多尺度语义特征融合效率低下，信息冗余或缺失问题突出。（3）图像物理表征空间与优化目标冲突。物理模型强调成像机制可解释性，深度模型强调增强效果与感知性能，二者在特征空间分布、训练目标和损失函数上存在不一致，融合策略缺乏统一理论支撑。（4）动态水下环境中的流变扰动与跨帧结构错位问题。水下序列图像存在显著的结构变形、目标错位和局部模糊现象，具有非线性、区域依赖等特点，导致图像帧间信息利用不足。

论文针对上述科学问题，开展基于表征学习的水下图像清晰化方法研究，从物理建模与结构感知出发，融合尺度、空间与时序信息，构建具有可解释性、鲁棒性和跨场景适应能力的图像清晰化方法模型。论文研究对推动水下计算机视觉从感知走向认知具有理论价值，为实际应用中的水下目标检测、目标追踪等高阶视觉任务提供坚实的技术支持。通过构建标准化的水下图像表征空间，研究成果将为智能水下系统的应用提供关键支撑，并为海洋资源的勘探、生态监测、海洋工程建设等任务提供更为精准的视觉感知能力。对于提升水下作业的智能化水平、保障海洋权益以及推动智慧海洋的建设具有重要意义。

1.2 国内外相关研究

在复杂多变的水体环境中，大量溶解物与悬浮物对光的吸收和散射作用是影响水下光学图像质量的主要因素，吸收作用会导致图像成像距离短和颜色失真问题，散射作用会导致图像对比度降低和细节信息丢失[12]。针对上述问题，近年来国内外相关学者开展基于先验知识的水下图像清晰化方法、无先验约束的水下图像清晰化方法、基于表征学习的水下图像清晰化方法等研究[13]。

1.2.1 基于先验知识的水下图像清晰化方法

基于先验知识的水下图像清晰化方法根据水下光学图像的衰退过程进行数学建模，通过输入图像设计先验知识估计成像物理模型参数，反演水下光学图像的衰退过程，求取清晰图像。此类方法充分考虑水下光学图像退化的影响因素。根据物理模型的不同，该类方法包括基于简单成像模型的水下图像清晰化方法、基于复杂水下成像模型的水下图像清晰化方法。

1) 基于简单成像模型的水下图像清晰化方法

中国知网 https://www.cnki.net

在基于简单成像模型的水下图像清晰化方法中，最具有代表性的是 He 等人提出的暗通道算法[14]（Dark Channel Prior, DCP），DCP 的先验信息是在图像小块中至少有一个像素在某些颜色通道中具有较低的值，并使用最小值来估计距离。但在水中因红色的衰减速率高于蓝色和绿色，在很多水下场景中，先验不成立，因此在 DCP 的基础上，Carlevaris-Bianco 等人[15]通过不同通道的光照在水下传播时衰减程度不同，根据每个图像块中红色通道的最大值与蓝色和绿色通道的最大值之间的差异，移除光照散射对水下图像造成的影响。

结合水下光选择性衰减的特点 Chiang 等人[16]考虑到水下红色通道的传输最低，假设恢复的传输是红色通道的传输；Drews 等人[17]基于蓝色和绿色通道设计出水下暗通道先验估计水下场景的传输。Galdran 等人[18]提出基于红色饱和度的先验知识，结合反转红色通道和饱和度来估计传输。由于水的类型不容易确定，所以反转红色通道水下图像复原算法采用光谱均匀透射法。Perez 等人[19]对水下自主航行器的 DCP 变化进行评估。Li 等人[20]提出新的全局背景光估计算法和回归模型的介质传输估计算法。Peng 等人[21]提出单图像恢复的暗通道先验泛化，通过使用场景环境光差，计算场景的透射率，在图像成像模型（Image Formation Model, IFM）中加入自适应颜色校正。Song 等人[22]通过获得场景深度图，并使用线性模型估计背景光。

由于简单成像模型中未考虑水下场景，近年来，不同的学者对水下图像的退化模型进行建模。例如，Trucco 等人[23]基于 Jaffe-McGlamery 水下成像数学模型提出一种自调的水下图像复原滤波器，假设水下图像收到均匀光照且只受到前向散射的影响。Hou 等人[24]结合水下光学属性与传统图像复原方法，通过估计光照散射参数复原水下图像。Serikawa 等人[25]提出沿着光照传播路径进行能量补偿，用以解决水下图像受到的散射和颜色偏差等影响。Zhao 等人[26]利用水下图像退化与水的光学性质，通过水下图像的背景颜色来获得水下传播介质的光学属性。Lu 等人[27]提出波长补偿的方式来复原水下图像。

基于透射图的估计方法，Li 等人[28]基于最小信息损失原理估计三颜色通道介质透射图，基于大气光和估计的透射图复原水下图像。Peng 等人[29]假设水下光散射造成的模糊度随着距离的增加而增加，因此通过图像的模糊度来估计场景距离。Peng 和 Cosman[30]基于图像模糊和光吸收估计水下场景深度，在 IFM 中对水下图像进行恢复和增强。以上的方法考虑水下图像成像的特点和不同波长的选择性估计，但未考虑直接分量和后向散射分量衰减系数之间的差异。

2) 基于复杂水下成像模型的水下图像清晰化方法

中国知网 https://www.cnki.net

简单的图像成像模型无法精准刻画水下图像的退化过程，由于图像清晰化结果的质量与物理模型的准确性相关，Akkaynak[31]提出一种改进的复杂水下成像模型，充分考虑后向散射分量与直接分量衰减系数之间的差异。Akkaynak[32]在文献[31]的基础上提出Sea-thru 方法，使用深色像素及其已知距离信息估计后向散射，利用空间变化光源的估计值，得到与距离相关的衰减系数。基于改进的水下图像成像模型，Zhou 等人[33]提出基于反向散射像素先验和颜色恢复方法，以解决模糊和颜色退化问题。

与大多数只考虑直接透射和后向散射分量的方法不同，Xie 等人[34]提出红色通道先验引导变分框架，红色通道先验引导变分框架增加前向散射分量，将归一化总变分项和模糊核的稀疏先验知识结合在一起，为避免局部最小值，该方法采用乘法器的交替方向法来加速整个过程解决生成的非光滑优化。Zhou[35]基于复杂成像模型[31]进行图像复原，该模型考虑直接分量和后向散射之间的透射率差异，以生成更准确的水下复原图像。

针对不同水体条件下光衰减特性差异对图像恢复效果的影响，Li 等人[36]提出一种基于多水体衰减建模与自适应颜色对比增强的水下图像恢复方法。该方法通过估算蓝-红与蓝-绿通道的衰减比率，对多种预定义水体类型分别进行图像重建，并设计自动选择算法从多个候选恢复结果中基于颜色分布选择最优图像，基于颜色-对比度自适应校正策略，用于纠正色偏并增强图像细节与对比度。Xiao 等人[37]通过估计复杂水下成像模型衰减系数和后向散射系数进行水下图像清晰化，将模型中系数简化为与距离相关的函数，并设计距离与最暗通道之间的关系来估计水下图像成像模型中的相关系数，有效地抑制恢复结果中的颜色偏差和失真。此外为提高深度估计的精度，提出使用模糊线索构建深度方向重聚焦的代价函数，减少高信噪比环境对深度信息提取的影响，有效提高深度估计的精度和鲁棒性。Mathiazhagan 等人[38]结合多种水下图像去雾策略设计水下序列增强方法，重点关注水下图像欠曝光，集成 DCP 与近似暗通道先验两种先验知识对水下图像进行复原，但该方法仅使用单幅图像作为输入，未考虑前后帧间的时序和场景补充信息。

基于先验知识的水下图像清晰化方法通过对成像过程进行分析，利用统计先验作为额外的约束来补偿信息损失，运用逆运算对成像模型进行处理，以获得清晰的图像，并从成像原理的角度提高图像质量。然而，目前的复原方法通常依赖于先验知识，如透射图和大气光的估计。在缺乏足够的先验知识或先验知识不准确的情况下，无法获得正确的复原结果。由于成像模型中包含两个及以上的参数，多个参数估计误差的叠加会错误引导水下图像清晰化过程。

中国知网 https://www.cnki.net

1.2.2 无先验约束的水下图像清晰化方法

无先验约束的水下图像清晰化方法包括基于直方图均衡化的水下图像清晰化方法、基于 Retinex 理论的水下图像清晰化方法、基于多尺度融合的水下图像清晰化方法等。

1) 基于直方图均衡化的水下图像清晰化方法

Kim[39]提出亮度保持双直方图均衡方法，对图像进行分解，分别在输入均值附近进行均衡化操作，解决增强图像局部区域亮度不均匀的问题，有效的减少噪声的放大。Reza[40]在自适应直方图均衡化的基础上提出对比度限制自适应直方图。Ancuti[41]提出一种基于相反颜色通道重建丢失通道的颜色通道补偿方法。Kim[42]采用对数映射函数作为约束函数，通过确定具有原始图像特征的控制参数来控制对比度增强率，提出基于对数函数映射的直方图均衡方法。Ding[43]在 Dong[44]的基础上提出图像梯度场双区间均衡化，将图像梯度场按照阈值分为两个区间，分别进行直方图均衡化，最后使用矩阵变换法重建图像，可使图像细节均匀的分布在各灰度级。但因为其没有考虑水下图像的颜色失真问题，基于直方图均衡化的方法不能有效的解决水下图像的清晰化问题，只对光照相对较好的场景有效。

基于水下图像的退化特性，Zhou 等人[45]提出颜色校正和三种区间直方图拉伸方法解决水下图像中的颜色偏置和低对比度问题。Zhuang 等人[46]开发一种具有反射和光照的多阶梯度先验的贝叶斯视网膜方法，以提高视觉感知。Zhang 等人[47]提出一种有效的水下图像增强方法（MLLE），该方法利用最小颜色损失和最大衰减图引导的融合原理来调整输入图像的颜色和纹理。Fu 等人[48]设计一种两阶段的水下图像增强方法，解决增强水下图像的两个子问题，颜色偏色和细节模糊。

然而，大多数基于直方图均衡化的水下图像清晰化方法忽略图像退化和场景深度之间的关系，应用于整个图像会引入伪影、颜色失真或过度曝光。

2) 基于 Retinex 理论的水下图像清晰化方法

基于 Retinex 理论的水下图像清晰化方法通过模拟人类的视觉系统，将水下环境的退化视为光照的变化。基于 Retinex 理论 Fu 等人[49]进行水下图像增强方法，首先进行色彩校正，然后使用有效的交替方向优化策略分离入射分量和反射分量，使用不同操作对入射分量和反射分量进行提高，最后合并得到增强后图像。

结合 CIELAB 色彩空间中各通道特性，Zhang 等人[50]提出一种基于扩展多尺度 Retinex 理论模型的水下图像增强方法 LAB-MSR，引入双边滤波与三边滤波进行联合增强，提升水下图像的细节和对比度。基于偏微分理论，Nnolim 等人[51]提出一种基于改进型偏微分方程的增强方法，采用模糊同态算法实现水下图像的光照校正。Zhang 等人[52]提出多尺度 Retinex 理论模型驱动的多通道卷积颜色恢复清晰化技术，结合二次引导滤

中国知网 https://www.cnki.net

波以降低图像噪声，并使用白平衡处理减弱光照干扰。Zhou 等人[53]提出一种基于 Retinex 理论的拉普拉斯金字塔去雾方法，通过增强反射分量并与矫正后的入射光分量进行融合，实现最终图像复原。

基于变分理论，Zhuang 等人[54]提出超拉普拉斯反射先验启发 Retinex 理论变分模型来增强水下图像，利用反射率一阶和二阶梯度的 L1/L2 范数惩罚，建立超拉普拉斯反射率先验，通过利用稀疏促进和完全综合反射来增强突出结构和精细细节。Yu 等人[55]提出基于变分建模的水下图像复原方法，该方法基于 Retinex 理论将水下图像分解为反射图像与光照分量，并设计两个低秩正则项以约束其梯度变化。引入加权明暗通道融合算法与中上通道先验，分别用于背景光与透射图的估计。采用交替方向乘子法实现快速迭代求解。Dai 等人[56]提出基于变分的水下图像清晰化方法，基于 Retinex 理论引入噪声项构建变分优化模型。该方法设计正则项用于分离入射光照和反射分量，同时抑制噪声的干扰。然后引入两阶段的处理策略，对于分离入射光照和反射分量分别处理，基于参数优化生成最后的清晰化结果。

尽管基于 Retinex 理论的方法能够有效增强图像对比度与细节，但其忽略水下成像过程中的散射、吸收与深度衰减等物理机制，导致色彩还原有限、建模能力不足。该类方法通常依赖手工设计的变分理论或滤波器，在处理复杂水下环境时鲁棒性和自适应性较差，难以满足端到端高效清晰化的实际需求。

3) 基于多尺度融合的水下图像清晰化方法

基于多尺度融合的水下图像清晰化方法通过输入一张图像，经过不同的预处理操作得到具有不同特征的图像，通过融合策略进行多个图像的融合增强。Mertens[57]等人基于对比度、饱和度和最佳曝光度提出一种多尺度融合算法，选择和混合图像的最佳部分，在解决图像曝光的同时保持图像的对比度。Ancuti[58]等人在文献[57]的基础上提出一种基于全局对比度、局部对比度、显著性和曝光度的水下图像增强算法，对输入的水下图像进行预处理，生成颜色修正和对比度增强的两个融合图像。基于预处理图像进行多尺度融合，可以有效降低噪声水平，提高全局对比度。Shen[59]等人提出一种拉普拉斯金字塔方法，充分考虑融合图像的局部对比度权值、全局对比度权值、曝光测量和显著权值，可以产生更好的色彩外观和更多的纹理细节。Lu[60]等人提出高浊度水下图像 SR 算法，通过自相似性的 SR 算法获得散点和散点图像的高分辨率图像，使用凸融合规则来恢复最终的高分辨率图像，该算法具有较好的色彩一致性和明显的边缘增强效果。Ancuti[61]在文献[58]的基础上提出一种水下图像增强方法，从原始图像中获取色彩补偿图像和白平衡后图像作为融合图像，基于图像的全局对比度、显著性和饱和度进行多尺度融合得到最后结果图，增强后的图像具有更好的黑暗区域曝光性、全局对比度和边缘清晰度。

中国知网 https://www.cnki.net

Zhou 等人[62]提出一种基于多特征先验融合的图像增强方法，通过设计一种基于自适应标准差的色彩校正方法，实现基于水下图像的色彩偏移校正。利用伽玛校正幂函数和空间线性调整，从单幅退化图像中获得一组人工曝光图序列，增强暗区亮度和结构细节。

基于多尺度梯度域增强与 Gamma 校正，Mishra 等人[63]对白平衡后的图像进行亮度分量分解，将图像从 RGB 空间转换至 YCbCr 空间，并利用加权最小二乘滤波器对亮度分量 Y 进行基础层 - 细节层分解，分别对基准层和细节层采用 Gamma 校正与梯度增强策略进行处理，最终融合重构增强图像。

基于主成分分析，Jitendra P. Sonawane 等人[64]提出一种基于颜色通道自适应权重分配的水下图像增强方法，引入一种改进的模糊对比度增强方法，根据各通道权重自适应确定增强因子，并通过主成分分析融合策略对增强结果进行综合优化提升整体图像的色彩与对比度。Zhang 等人[65]提出基于前景与背景主成分融合的水下图像增强方法。该方法首先通过基于 CIELab 颜色空间的颜色均衡策略校正颜色偏移，随后在校正后的图像上分别采用基于百分位最大值的对比度增强与多层透射图估计的清晰化策略，生成对比度增强的前景图与清晰化后的背景图。最终，利用主成分分析融合前景与背景子图，获得高可视性清晰化结果。

1.2.3 基于表征学习的水下图像清晰化方法

基于表征学习的水下图像清晰化方法主要包括基于物理模型的水下图像清晰化方法、无模型的水下图像清晰化方法。

1) 基于物理模型的水下图像清晰化方法

基于物理模型的水下图像清晰化方法通常需要基于先验知识等策略估计水下图像的透射图和参数，其估计值适应性较差。因此将表征学习方法与物理模型相结合，主要利用卷积神经网络出色的特征提取能力来求解成像模型中的参数值，如透射图、大气光等模型参数。在水下图像复原过程中，使用卷积神经网络（Convolutional Neural Network，CNN）取代传统方法中使用的假设或先验知识，如暗通道先验理论。模型通常分为两部分：首先将原始图像输入卷积神经网络进行特征提取特征，估计得到透射图；然后从计算中通过透射图提取出清晰的图像清晰化，将原始图像输入光学成像模型进行反演计算。

基于卷积神经网络，Cai 等人[66]提出 DehazeNet，利用卷积神经网络提取水下图像的透射图，并基于大气散射模型进行图像复原，实现端到端的单幅图像清晰化。Shin 等人[67]同时学习水下图像的透射图和背景光，代入到水下成像模型反演出清晰图像。Barbosa 等人[68]通过利用 DehazeNet[69]估计传输率，使用图像质量指标来指导恢复过程。Ding 等[70]采用自适应色彩校正算法对色彩失真进行补偿。利用 CNN 网络对色彩校正后的图像进行深度图估计，直接转换为透射图像进行图像复原。Wang 等[71]提出基于 CNN

中国知网 https://www.cnki.net

的水下图像清晰化网络 UIE-NET，UIE-NET 网络可以从输入的水下图像中估计颜色校正后的图像和透射图像，同时训练颜色校正和清晰化过程，在训练过程中，采用像素干扰策略抑制区域块中包含的小纹理干涉信息。

由于水下图像难以获得相应的参考图像，Barbosa 等[72]未采用成对数据集，采用一组图像质量指标来指导基于 CNN 网络的恢复过程。通过对模拟数据的处理来恢复图像，避免测量真实场景数据的困难。Hou 等人[73]同时学习透射图和场景残差，并从蓝色和绿色通道估计全局背景光。该模型包括用于透射图像估计的数据驱动残差结构和用于水下照明平衡的知识驱动场景残差计算方法，并对图像进行色彩校正。Cao 等[74]构建深度神经网络，直接从输入图像中估计学习背景光和透射图像，然后利用大气模型实现图像清晰化。Wang 等人[75]提出并行卷积神经网络，包括两个并行分支：一个传输估计网络、一个全局环境光估计网络。该网络采用跨层连接和多尺度估计，防止光晕现象，保持边缘特征。

基于先验知识，Liu 等人[76]基于传输的图像增强任务的统一公式，设计一个复合展开框架生成混合图像层传播，将多个深度训练的先验信息集成到迭代传播方案中，通过深度模型识别不同应用的特定任务属性和数据分布。WaterNet[77]基于原始图像以及伽玛校正、直方图均衡和白平衡程序的结果作为网络输入，并设计一个门控融合网络用于融合四个输入图像的置信图。基于多个颜色空间，Li 等人[78]提出一种由透射图引导的多色彩空间编码网络 UColor，UColor 创新性地引入 GDCP[21]的透射图，以深化网络对更大距离特征信息的响应改善特定区域的特征。Srinath 等人[79]提出一个两阶段的框架来增强水下视频，第一阶段使用去噪扩散概率模型从未标记数据中学习生成先验，提取鲁棒性和描述性特征表示；在第二阶段，将上述先验引入到基于物理的图像公式中用于空间特征增强。为提升水下单帧和序列图像清晰度和在海洋探测中的适用性。Pooja Honnutagi 等人[80]提出集成多种优化策略的水下图像与视频增强方法，通过拉普拉斯方差检测模糊帧；随后基于水下光衰减先验 ULAP 进行深度估计，深度系数由 CMVBSO 算法进行优化；在此基础上，将模糊值、图像帧与深度信息输入自适应特征融合卷积网络，并结合 MRLLO 算法进行训练，利用 T2FCS 算法完成像素级增强。

基于偏振图像 Shen 等人[81]提出一种无监督水下图像恢复网络 U2PNet，基于一个场景的拼接偏振图像，通过两个子网络分别估计透射率和背景光，基于水下图像成像模型复原清晰图像。基于 RGBD 数据集类型，Nathan 等人[82]使用 RGBD 数据利用扩散模型提取先验知识，在颜色和深度的联合空间上训练一个无条件扩散模型先验，利用该先验和水下图像成像模型生成清晰的水下图像。

2) 无模型的水下图像清晰化方法

中国知网 https://www.cnki.net

近年来研究者开始探索无模型的表征学习方法，通过引入数据驱动的增强机制，不依赖具体的物理模型或固定先验，利用深度网络的高表达能力自动学习水下图像的退化规律与增强策略。Wang 等人[83]提出一个三阶段增强框架（Metalantis），该框架依次包括虚拟水下图像合成（Metamergence）、深度估计（Metalief）以及基于强化学习的物理模型配置（Metaebb），各阶段训练相互依赖，模拟水下图像退化过程。该方法利用合成数据驱动强化学习策略优化现有物理模型参数，实现对多样化水下场景的适应性增强。Wang 等人[84]提出一种基于强化学习的水下图像增强框架。该方法通过强化学习策略自动选择并组合多个增强算法及其参数配置，该框架将人类视觉感知与水下颜色先验引入奖励函数，实现无参考的增强质量评估。Zuo 等人[85]基于 Transformer 架构提出 UWSegFormer，该方法主要提升水下图像的语义分割能力，UWSegFormer 通过设计水下图像关注模块，通过通道自关注机制增强水下图像特征通道中高质量语义信息的表示，设计多尺度聚集注意模块，从高级特征中提取判别信息，将不同尺度的语义特征集合在一起，从而补偿水下物体细节的语义损失；最后引入边缘学习损失约束 UWSegFormer 模块的训练过程。

基于多个颜色空间，Xu 等人[86]基于 RGB 颜色空间和 HSV 颜色空间进行水下图像清晰化，提出统计估计网络（StatEstNet），StatEstNet 集成正则化技术、小规模卷积和输出阶段激活函数，有效地解决水下图像的颜色偏差和对比度降低问题，设计高效多尺度注意模块 Plus EMA+和深度特征提取模块 DFE，通过利用残差级联实现高级深度特征提取，并共同构成特征和细节增强网络 FeDeNet。基于 RGB 颜色空间和 Lab 颜色空间，Zhang 等人[87]提出轻量级的水下图像清晰化网络，设计多空间特征编码网络，使用基于强化学习的带宽分配网络在受限带宽条件下优化特征分布。

基于空域和频域空间特征信息，Liu 等人[88]基于频域信息和空域信息设计水下图像网络 FSformer，FSformer 基于 Transformer 结构提出一种频域-空域全局-局部 Transformer 模块 FSGLT，FSGLT 自适应地集成频率域和空间域的信息，更多地关注水下图像中严重退化的区域。为提取空域分支和频域分支上的深层特征，设计双支路特征增强模块 DBFEM，增强水下场景细节。Zhang 等人[89]同样基于频域信息和空域信息进行水下图像清晰化，提出跨域融合网络 CDF-UIE，使用空间-频率解耦块 SFD 对输入特征进行域解耦，通过跨域注意机制有效地融合空间和频域特征，在图像重建阶段同时利用粗尺度和细尺度信息。在损失函数中引入一个包含像素级、结构和感知约束的多尺度目标函数指导 CDF-UIE 的增强过程。Zhao 等人[90]提出新的水下图像增强框架 WF-Diff，充分利用频域信息和扩散模型的特性，设计基于小波的傅里叶信息交互网络 WFI2-net 和频率残差扩散调整模块 FRDAM，其中 WFI2-net 初步增强小波空间中的频率信息，FRDAM 细

中国知网 https://www.cnki.net

化初始增强图像的高低频信息。Zhang 等人[91]提出基于渐进式制导的联合畸变定位与恢复模型，采用两阶段框架，第一阶段专注于精确定位扭曲以获得精确位置。第二阶段利用第一阶段的位置信息进行有效的畸变恢复，并将全局、无失真和特定失真的信息纳入第二阶段网络的不同组成部分，逐步指导水下图像清晰化过程。

在水下序列图像清晰化中，Xie 等人[92]提出一个水下序列图像增强成对数据集 UVEB，基于 UVEB 数据集设计 UVENet 方法用于水下图像清晰化，UVENet 方法将目标帧和临近帧作为输入基于 Unet 架构在原分辨率空间和 4 倍下采样空间进行特征提取和图像复原，可以有效提取临近帧之间的特征。UVENet 虽然将目标帧的临近帧同时输入到网络模型中，实现一定程度上的时序信息提取，但其并未针对性地解决帧间的一致性约束与运动补偿问题。

此外，监督学习框架通常依赖于成对的退化与清晰图像进行训练，但在真实水下场景中，获取大规模高质量的标注数据集具有较大难度。因此，Li 等人[93]设计 WaterGAN 来生成合成水下图像训练数据集，并作为两阶段 CNN 网络来估计深度和恢复自然颜色。Uplavikar 等人[94]首先对模型进行训练，以确保模型的编码在图像中包含有有用的信息；然后进入分类器对整个网络进行联合对抗性训练。Li 等人[95]通过 IFM 将物理模型与水下场景的光学特性相结合，合成不同的水类型数据集，丰富水下配对图像数据集种类并提出一个轻量级的 CNN 水下卷积神经网络 UWCNN。TOPAL[96]提出一种基于恢复颜色偏色和增强对比度的水下图像增强方法。Ye 等人[97]利用无监督自适应网络来处理单目水下图像的联合水下深度估计和颜色校正问题。Lin 等人[98]首次利用具有注意力机制的多尺度可变形卷积网络进行水下图像增强。Fabbri 等人[99]通过 CycleGAN 提供一个无配对数据的训练集，用于增强水下图像。Chen 等人[100]使用 Hybrid Detection GAN 的统一网络来帮助生成有利于检测的图像，该网络由每个分支中的增强模型和检测前置器组成。然而，这些方法未能采用奇异输入来处理水下图像中的极端失真的情况。Qi 等人[101]提出一种新的水下图像协同增强方法，该方法结合相关特征匹配和基于表征学习的细化。最近，Wang 等人[102]提出一种新的领域自适应技术，利用对抗性学习来提高图像增强模型在不同水下环境中的可推广性。

通过对感兴趣目标区域与背景区域采用差异化压缩策略，Zheng 等人[103]基于感兴趣目标区域提出称为 FUVC 的水下序列图像编码框架，重点目标区域使用高质量编码压缩，背景则根据带宽条件采用低码率策略，解码端通过掩码检测与背景恢复模块融合图像，提升水下序列图像的清晰化效果。Boya 等人[104]基于 CycleGAN 提出一种无需成对样本的水下图像清晰化方法，该方法通过生成器将水下图像映射至清晰图像域，并利用

中国知网 https://www.cnki.net

判别器对真实图像与生成结果进行区分，结合特定设计的损失函数提升生成图像的真实感与上下文一致性，但是上述方法仍采用单帧输入，未考虑临近帧的信息补充。

基于表征学习的水下图像清晰化方法均取得显著的成果，然而仍存在一些问题需要解决。仍在利用多尺度关联特征方面存在不足，导致图像清晰化效果受限；不同尺度间特征的无监督学习容易引入冗余和无效特征累加，对清晰化效果产生不利影响；依赖统计先验的传统方法在面对极端复杂的水下环境时，易受到图像局部统计特性的干扰，导致模型失效。此外，当前多数水下序列图像清晰化方法多由单幅图像清晰化方法拓展，仍采用逐帧独立处理策略，难以有效应对水下场景中运动目标所带来的模糊与不连续性问题。

1.3 存在的问题

尽管现有水下图像清晰化方法在颜色复原、结构增强及感知优化等方面取得显著进展，但在应对复杂水下成像环境、提升模型泛化能力方面仍存在诸多瓶颈，限制其在多场景、多设备下的实用性与稳定性。具体而言，仍存在以下四个关键科学问题：

1) 局部深度与光衰减耦合关系建模不准确

水下成像过程中，光在水体中的传播受到水深、悬浮颗粒散射和局部光照变化等多因素的共同作用，呈现强烈的非线性耦合特性。目前缺乏精确描述像素级局部成像条件与颜色偏移之间耦合机制的理论模型。特别是在动态水体介质中，尚未系统解析由水深变化与颗粒物多重散射引起的像素级局部成像条件与颜色偏移之间的非线性耦合机制，成为限制空间非均匀色彩校正精度与区域自适应能力的核心瓶颈。

2) 不同尺度下退化主导因素难解析

水下图像在不同尺度层次上展现出异质的退化特征，小尺度区域常受高频噪声、微模糊等局部扰动影响，大尺度背景则面临低对比度和全局光照衰减问题。对多尺度退化主导因素的解析尚不充分，缺乏面向结构一致性的尺度融合策略，导致特征间协同不足，冗余干扰显著，结构还原精度不高，进而影响图像增强的稳定性和结构感知效果。

3) 表征空间差异难统一，物理建模与深度优化耦合冲突

物理建模与深度优化之间的有效融合仍是一个难点。物理建模可作为显式约束机制，引导图像增强过程更加符合成像机理，而深度学习则侧重于感知驱动的端到端优化，强调对增强结果的全局质量与语义一致性。然而，二者在特征表征空间、训练目标函数以及优化机制上存在潜在冲突。如何实现表征一致性引导下的物理感知协同建模，构建统一表征空间，是当前水下图像清晰化领域中的关键科学问题。

中国知网 https://www.cnki.net

4) 动态流变扰动下的帧间结构错位机制建模

在真实海洋环境中，水下序列图像常受到水体扰动、相机抖动与目标运动等流变扰动的共同影响，造成显著的帧间结构错位、局部模糊与时序信息不一致。这类扰动具有空间非稳定性和时间非平稳性，尤其是在低信噪比或复杂流场条件下，现有对扰动与运动耦合所引发的空间模糊建模不足，难以实现高精度的帧间对齐与动态清晰化，成为制约时序一致性建模能力的关键难题。

针对上述科学问题，论文重点关注如何结合自适应颜色校正、多尺度特征增强、多表征空间联合建模、时序一致性优化和多帧数据融合，提出多维递进式解决方案。基于空间维度，通过局部块划分与深度自适应补偿因子，解决全局校正的前景过补偿问题；在空间维度的基础上引入多尺度维度构建多分辨率编码器-解码器框架，结合基于双分支的内在上下文注意力机制提取多粒度退化特征；结合场景和原始图像多表征空间，充分挖掘图像中固有的物理场景表征，提升清晰化结果的物理合理性与语义一致性；提出自适应跨帧特征对齐方法和基于时空特征优化注意力，实现动态场景的时空协同增强。

论文通过逐层递进的技术设计，针对水下图像清晰化中的关键瓶颈问题开展研究，提升水下图像清晰化方法的鲁棒性和适用性，为复杂海洋环境下的视觉感知任务提供理论与技术支撑，以推动水下计算机视觉任务的发展。

1.4 研究内容与研究框架

水下图像在采集过程中常受到水体介质对光的吸收与散射作用影响，表现出色彩失真、对比度降低、细节模糊与光照非均匀等多重退化现象，不仅严重降低水下图像的视觉结果，也显著制约目标检测、语义分割、环境理解等下游视觉任务的性能表现，成为制约水下计算机视觉发展的关键瓶颈。特别是在复杂海洋环境下，现有图像清晰化方法在物理一致性、结构表达能力、动态适应性等面临显著挑战。

1.4.1 论文研究内容

为提升水下图像清晰化方法在多场景、多尺度、跨时序条件下的鲁棒性与泛化能力，论文围绕表征学习，构建多维感知建模增强策略。图像表征是指从水下退化图像中提取和建模能反映其空间结构、尺度层次、物理属性与动态行为的多维特征集合。表征内容不仅涵盖像素级纹理与边缘，还包括深层语义目标、场景固有属性、跨帧时序特征等，用以支持图像清晰化中各项感知增强任务的结构保持、噪声抑制与物理一致性重建。

论文的研究内容面向四个关键科学问题：局部深度与光衰减耦合关系建模不准确、不同尺度下退化主导因素难解析、多表征空间与优化机制冲突、动态水下场景中的流变

中国知网 https://www.cnki.net

扰动与跨帧结构错位问题，设计从静态图像到时序图像、从感知表征到机制对齐的系统性研究框架。

1) 基于光衰减表征的水下图像自适应颜色校正方法研究

针对现有水下图像颜色校正方法处理局部光谱衰减适应性不足的问题，开展光谱衰减表征研究。全局校正或固定物理先验难以准确建模局部深度变化、水体条件差异与选择性光吸收之间的耦合关系，导致颜色补偿过程中存在前景过补偿、背景恢复不足等问题。论文构建面向空间异构区域的颜色退化特征表征机制，以图像块为基本建模单元，建模像素级空间表征，提取局部区域的颜色偏移与光照强度变化特征。设计颜色补偿因子的区域估计方法，建立局部区域特征向像素级连续传播的平滑插值机制，实现区域与全图之间的校正一致性。论文拟解决构建具备物理解释性、区域响应能力与结构连续性的颜色偏移表征方式，刻画水下图像中局部深度与光衰减之间的复杂耦合规律。研究将为后续图像清晰化中的结构还原、色彩统一等任务提供准确、稳定的物理基础表征。

2) 基于内监督协同多尺度表征的水下图像清晰化方法研究

针对水下图像在多尺度层次上存在细节模糊、纹理缺失与全局对比度衰减等异构退化现象，且现有方法缺乏对尺度间退化主导因素的系统解析与自适应表征机制，开展面向多尺度表征的学习增强策略研究，系统建模图像中的多尺度语义特征。构建多分辨率编码器-解码器结构，提取不同尺度下的退化特征表征，重点建模局部纹理特征、边缘细节与整体结构分布的多尺度表达方式。设计基于双分支结构的上下文注意力机制，从高分辨率建模场景细节，从低分辨率感知全局语义，增强特征之间的跨尺度结构关联性。为解决多尺度信息融合过程中的表征冗余与噪声积累问题，构建选择性内在监督机制，对多尺度特征空间进行动态筛选与自适应抑制，优化多尺度语义表征的稳定性与判别性。构建具备多尺度表达能力、融合控制能力的退化表征体系，提升水下图像在复杂退化场景下的结构还原与细节重建性能。

3) 基于场景表征引导的水下图像清晰化方法研究

针对物理建模与深度网络在表征空间构成与优化目标设计的不一致问题，特别是在复杂光照条件下模型性能不稳定、缺乏物理合理性的难题，开展基于场景表征引导的水下图像清晰化方法研究，建模场景和原始图像多表征空间。基于 Retinex 成像模型，将图像分解为反射分量（代表场景固有属性）与光照分量（表征环境光扰动），构建基于物理成像机制的场景表征空间，提取光照不变、结构稳定的场景表达信息。结合 Unet 框架，设计多尺度场景特征提取机制，以强化图像在场景表征空间中的物体结构、边界信息等固有语义表征能力。为解决物理模型与数据驱动模型在表征空间上的分布不一致问题，提出多表征空间解码器，协同建模物理模型的结构引导信息与深度特征空间中的语

中国知网 https://www.cnki.net

义感知，在表征层实现物理合理性与感知泛化能力的统一。重点构建具备物理一致性、结构完整性与语义辨识能力的统一增强表征体系，推动水下图像清晰化方法由感知优化向机制融合范式转变。

4) 基于跨帧表征对齐的水下序列图像清晰化方法

针对水下动态场景中存在的水流波动、相机抖动、目标运动等流变扰动引发的运动模糊、帧间结构错位与时序信息不一致问题，开展基于跨帧表征对齐的水下序列图像清晰化方法研究，建模时空结构一致性的跨帧对齐表征。以时序动态表征建构为核心，设计自适应跨帧特征对齐方法引导跨帧流变特征对齐，构建序列图像中各帧之间的动态结构对应关系，消除运动扰动引起的模糊伪影，提取目标帧语义结构。构建时空特征优化机制，联合建模多帧图像中的时序演化特征与空间结构特征，增强时空维度的联合表征能力，提升模型在动态退化条件下的结构保持性与连续性表达能力。解决跨帧图像中因流变扰动导致的结构错位问题，通过建模帧间动态变化中的稳定结构表征实现多帧信息的时空一致性融合。构建具备流变运动适应能力、动态结构表达能力与连续性增强能力的时序一致性表征模型，提升水下图像清晰化方法在复杂动态环境下的稳定性与泛化性能。

1.4.2 论文研究框架

论文围绕水下图像清晰化过程中的关键退化机制与建模难题，构建层次递进、结构交叉的研究体系，研究框架如图 1.3 所示。基于对水体中光传播机理的深入分析，研究局部深度与光衰减之间的耦合关系，建立空间非均匀颜色退化的物理建模基础（研究内容 1），提出基于光衰减表征的水下图像自适应颜色校正方法，为后续多维表征提供依据。

在此基础，一方面从结构建模角度出发，开展多尺度图像退化联合解析与结构增强策略研究（研究内容 2），提出基于内监督协同多尺度表征的水下图像清晰化方法，强化特征空间对不同尺度语义的建模能力；另一方面，从表征机制融合角度出发，深入研究物理模型与深度网络在表征空间构成与优化目标导向上的不一致性问题，提出基于场景表征引导的水下图像清晰化方法，开展跨表征一致性建模方法研究（研究内容 3）。研究内容 2 提供多尺度语义特征的表达结构，研究内容 3 则约束这些特征在物理与感知语义之间的统一性与可训练性，两者协同决定表征质量与优化稳定性。

针对动态水下场景中存在的多源流变扰动与跨帧结构错位问题，在表征一致性建模基础上集成时序维度，提出基于跨帧表征对齐的水下序列图像清晰化方法，研究序列图像的结构对齐与清晰化一致性策略（研究内容 4）。上述四个研究内容形成物理建模为基础、结构建模与机制融合并进，时序建模为延伸的多维感知建模清晰化研究框架。

中国知网 https://www.cnki.net

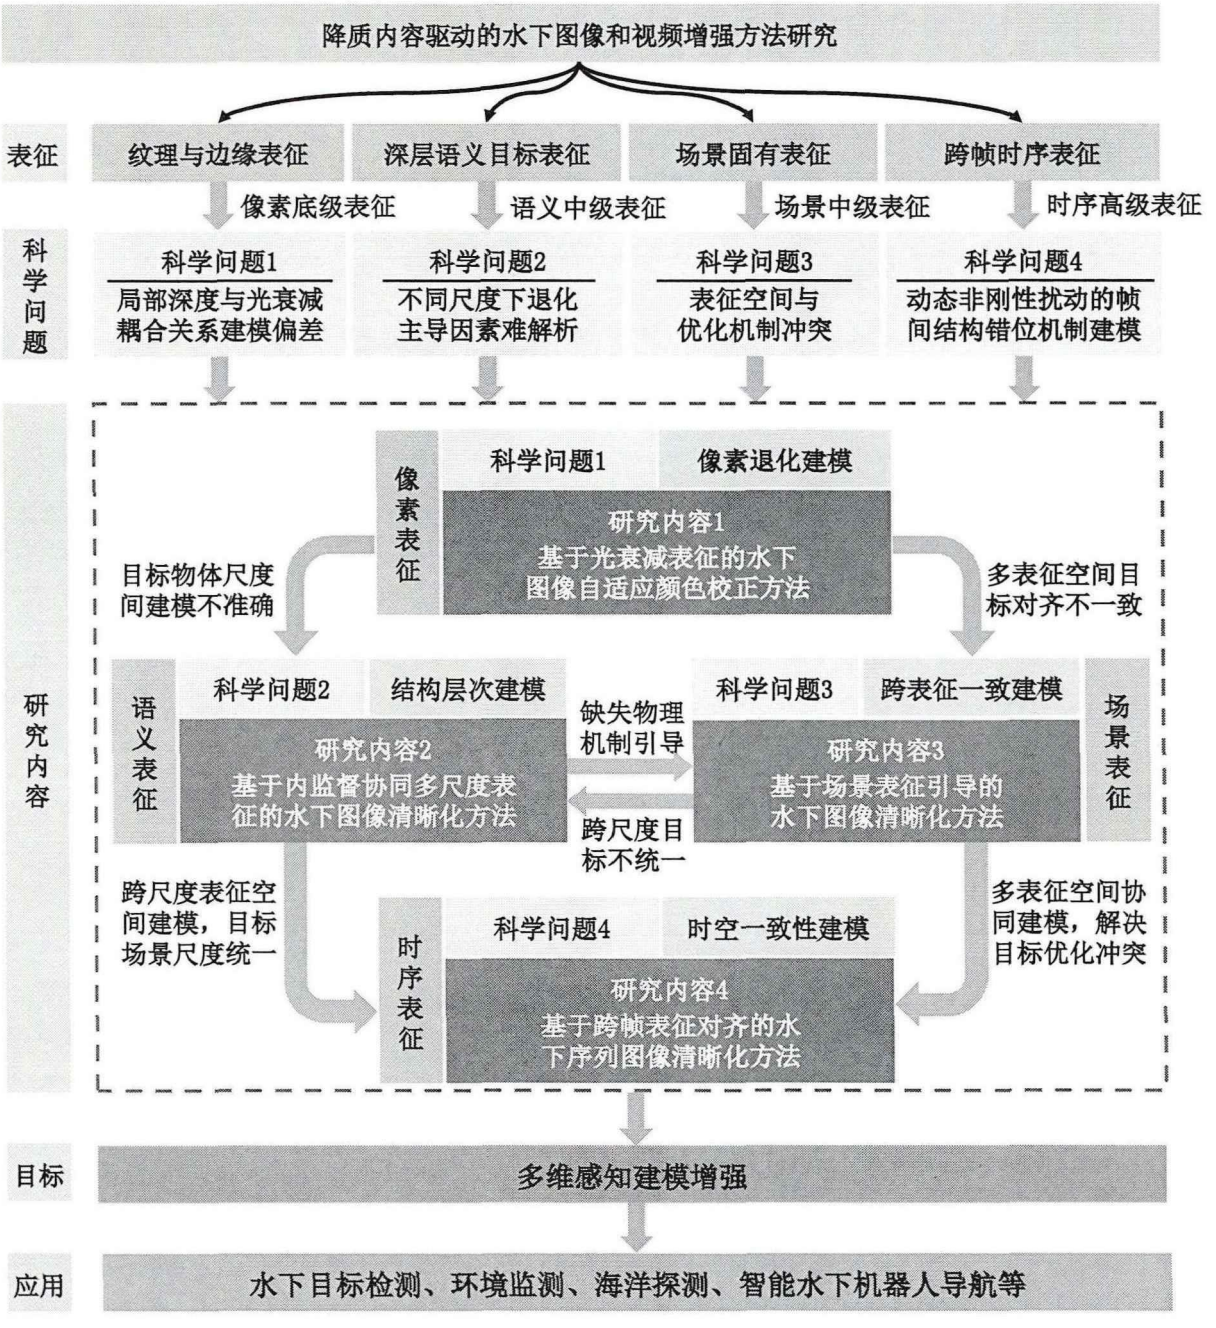

图 1.3 基于表征学习的水下图像清晰化方法研究框架

Fig. 1.3 Research framework of the underwater image clarification method based on representation learning

论文面向水下图像清晰化中存在的局部光衰减建模不准确、退化主导机制不明确、物理模型与网络目标不一致以及跨帧结构错位难对齐等关键技术瓶颈开展研究，提出基于表征学习的水下图像清晰化方法，所构建的表征驱动清晰化机制可为水下目标检测、

中国知网 https://www.cnki.net

海洋环境监测、无人潜航器导航等下游视觉任务提供稳定、真实、结构清晰的视觉输入支持。研究成果可广泛应用于水下遥感影像处理、海洋资源探测、水下考古修复、智能水下机器人视觉感知系统等领域，对支撑国家海洋科技战略、推动新一代智能化水下作业装备的发展具有重要的理论支撑意义与技术创新价值。

1.5 论文组织与结构

论文组织与章节安排如下：

第 1 章 绪论。阐述论文的研究背景、国内外相关研究现状及进展，凝练科学问题，概述论文的研究内容与框架，给出论文的组织与结构。

第 2 章 相关理论与方法。综述水下图像的主要退化机理，分析水下成像模型，介绍卷积神经网络，对水下图像评价指标进行系统梳理，为论文研究奠定理论基础。

第 3 章 基于光衰减表征的水下图像自适应颜色校正方法。针对水下图像的色彩偏移问题，提出基于光衰减表征的水下图像自适应颜色校正方法。结合水下成像模型，采用局部区域划分策略，并计算自适应颜色补偿因子，利用双线性插值扩展至全局，实现颜色的自适应校正，避免全局校正方法导致的色彩过度补偿问题。设计定性和定量实验，设计预处理有效性实验验证该方法为后续清晰化方法提供色彩校正基础。

第 4 章 基于内监督协同多尺度表征的水下图像清晰化方法。针对水下图像的多尺度退化，提出基于内监督协同多尺度表征的水下图像清晰化方法，构建多分辨率编码器-解码器框架，设计双分支内在上下文注意力机制，以增强局部细节和全局语义信息的协同表征，并通过自适应选择性内在监督模块抑制多尺度特征融合中的噪声干扰，实现更鲁棒的清晰化效果。为验证该方法的优越性，设计定性和定量测试；针对各个退化阶段、网络结构等设计消融实验。

第 5 章 基于场景表征引导的水下图像清晰化方法。针对水下光照影响及场景固有属性，利用 Retinex 理论将水下图像分解为反射分量（场景固有属性）和光照分量（环境光影响），提出基于场景表征引导的水下图像清晰化方法。通过多尺度场景目标提取模块和基于上下文信息的多级集成模块，增强数据驱动模型与物理机理的融合，提高方法的物理合理性和可解释性。通过在多个公开数据集的设置对比实验，验证所提出方法在图像清晰度、色彩还原与结构保持等方面的有效性。围绕关键组成部分设计消融实验，评估多尺度提取、上下文集成结构等在整体性能提升中的具体贡献，用于验证所提架构的必要性与实用价值。

第 6 章 基于跨帧表征对齐的水下序列图像清晰化方法。针对水下动态场景的时序不一致性和运动模糊问题，提出基于跨帧表征对齐的水下序列图像清晰化方法，采用可

中国知网 https://www.cnki.net

变形卷积进行跨帧特征动态对齐补偿运动伪影恢复场景信息，并通过基于时空特征优化注意力机制融合多帧图像信息和空间维度信息，提升时序一致性和动态场景的适应性，实现水下动态序列图像的时空协同增强。通过在 MVUI 数据集设计定性和定量对比实验。为验证各关键组成内容的有效性，设计多组消融实验，包括特征对齐模块、时空注意力机制、优化方法等。

第 7 章 总结与展望。总结论文的研究内容与贡献，展望未来的发展方向。

中国知网 https://www.cnki.net

2 相关理论与方法

本章主要围绕水下图像成像机理、卷积神经网络、水下图像质量评价方法展开综述。阐述水下图像的成像模型，包括基于人类视觉感知的 Retinex 理论和简单成像模型，介绍卷积神经网络，包括非线性激活、归一化与标准化、残差连接等，介绍水下图像质量评价指标，包括全参考指标、无参考指标等，为后续研究提供理论支撑。

2.1 水下图像成像模型

由于光在水体中的传播受到吸收和散射效应的影响，水下图像往往存在色彩失真、低对比度和模糊等问题。针对水下成像的复杂性，研究者们提出多种成像模型来建模光在水体中的传播机制，包括基于人类视觉的 Retinex 模型、水下图像成像模型。

2.1.1 基于人类视觉的 Retinex 理论

人类视觉系统（Human Vision System, HVS）能够在复杂的光照环境下稳定感知物体的颜色和结构，即使在光照变化较大的场景中，也能保持对物体表面颜色的不变感知，这一能力源于人类视觉对光照影响的去除能力，称为色恒常性[105]。由 Land 和 McCann 于 1971 年提出的 Retinex 理论是解释色恒常性的重要模型之一，基于视网膜（Retina）和大脑皮层的视觉信息处理机制，提出一种计算模型以模拟人类视觉的自适应增强特性。

Retinex 理论的核心思想是光照（Illumination）与反射率（Reflectance）的分离。在人类视觉系统中，视网膜的神经元对光照变化具有自适应能力，大脑皮层对物体表面属性进行高层次建模，从而使人类能够感知到相对稳定的颜色信息。基于 Retinex 理论图像 $I(x, y)$可以分解为两部分：

$$I(x,y) = R(x,y) \times L(x,y) \tag{2.1}$$

其中 $I(x, y)$表示由成像系统获取的图像强度，$R(x, y)$表示物体表面的反射率，即固有属性，与光照无关，$L(x, y)$表示场景中的光照分布。在理想情况下，去除光照成分 $L(x, y)$后，可恢复物体的真实反射率 $R(x, y)$，实现色恒常性和光照归一化。

1) 单尺度 Retinex

SSR（Single Scale Retinex）[106]通过使用对数变换和卷积操作来模拟人类视觉的对比增强机制：

$$R(x,y) = \log I(x,y) - \log[I(x,y) \otimes G(x,y)] \tag{2.2}$$

中国知网 https://www.cnki.net

其中 $G(x,y)$表示高斯核，用于估计输入图像 I 的光照分量 R，$\otimes$ 表示基于高斯核 G 的卷积操作。

SSR 可以有效去除光照分量的影响，但 SSR 方法采用固定尺度的高斯滤波，适应性不足。

2) 多尺度 Retinex

为解决 SSR 的尺度不稳定性问题，MSR（Multi-Scale Retinex）引入多种尺度的高斯滤波器进行加权融合[107]，其数学表达式如下：

$$R(x,y)=\sum_{i=1}^{n} w_i\left(\log I(x,y)-\log[I(x,y)\otimes G_i(x,y)]\right) \tag{2.3}$$

其中 $G_i(x,y)$ 表示不同尺度的高斯滤波核，w_i 表示权重系数，满足 $\sum_{i=1}^{3} w_i=1$。

MSR 在增强图像对比度的同时，有效保留图像的结构信息，成为 Retinex 理论的经典增强方法之一。

3) 带颜色恢复的多尺度 Retinex

MSRCR（Multi-Scale Retinex with Color Restoration）在 MSR 的基础上引入颜色恢复机制[108]，以防止 Retinex 算法导致的颜色失真，其增强后的图像计算公式为：

$$R_{CR}(x,y)=C(x,y)\cdot R(x,y) \tag{2.4}$$

其中 $C(x,y)$表示颜色恢复函数，用于补偿颜色失真问题，通常采用：

$$C(x,y)=\alpha\log(I(x,y)+\epsilon) \tag{2.5}$$

其中 α 和 ϵ 为经验参数。MSRCR 广泛应用于水下图像清晰化、低光图像增强、医学影像处理等图像处理领域。

4) 变分 Retinex 模型

变分 Retinex 模型[109]利用能量优化方法，通过建立全局约束和局部正则化来求解光照与反射率，优化公式如下：

$$E(R,L)=\|I-R\cdot L\|^2+\lambda\|\nabla L\| \tag{2.6}$$

其中，λ 表示正则化参数，用于光照估计，∇L 代表光照分布的梯度。

变分 Retinex 模型的核心思想是将图像的光照分布视为一个低频平滑分量，而反射率信息则包含高频纹理细节。通过构建能量函数并进行优化，该方法能够有效去除不均

中国知网 https://www.cnki.net

匀光照对图像的影响提高 Retinex 模型的鲁棒性。由于该模型对噪声具有较强的抑制能力，因此广泛应用于图像去噪和低光照图像清晰化等领域。

2.1.2 水下图像成像模型

光线在介质中传播受到散射和吸收的影响，导致成像设备所获取的图像对比度降低、颜色偏移、目标模糊等问题。如图 2.1 所示，成像系统所获取的图像 $I(x)$由三部分组成：直接衰减分量、后向散射分量和前向散射分量[110]，其中为物体表面的光强在传播过程中衰减，并伴随色偏和对比度下降。后向散射分量中大气环境中的散射光进入相机，使得远距离物体颜色趋向于背景光，前向散射指的是光在穿过介质时，光子因与颗粒的相互作用而发生偏折，但仍然沿着原始方向继续传播的分量。

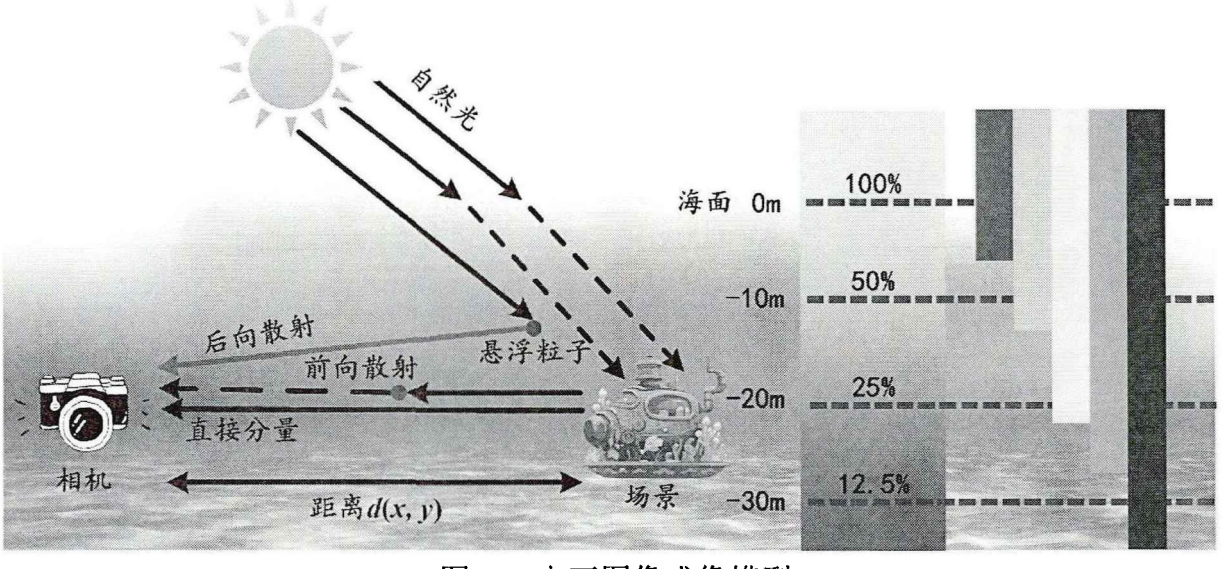

图 2.1 水下图像成像模型

Fig. 2.1 Underwater image formation model based on atmospheric scattering

水下图像成像模型的公式为：

$$I(x)=J(x)t(x)+A(1-t(x))+S(x) \tag{2.7}$$

其中 $I(x)$是成像系统获取的受介质影响的退化图像，$J(x)$是待恢复的无雾图像，A 是全局大气光，即远处天空的背景光照，$S(x)$表示前向散射分量，$t(x)$是透射率：

$$t(x)=e^{-\beta d(x)} \tag{2.8}$$

其中 β 是散射系数，$d(x)$表示场景深度。

前向散射分量的计算公式如下：

中国知网 https://www.cnki.net

$$S(x)=\int_0^{d(x)} J(x,s)\sigma_s e^{-\sigma_t s}ds \tag{2.9}$$

其中 $J(x,s)$表示沿着视线方向 s 处的场景辐射值，σ_s 是散射系数，描述光与大气颗粒的散射强度，σ_t 是总衰减系数，包括散射和吸收 $\sigma_t=\sigma_s+\sigma_a$。式(2.9)描述在不同深度处的场景辐射在光传播过程中发生散射过程，最终进入相机成像系统。

由于前向散射分量在光传播过程中仅发生轻微的角度偏折，并且其散射光仍然沿着原始方向传播，因此其对成像系统接收到的光强贡献相对较小。与后向散射相比，前向散射的影响通常不会显著改变图像的整体色彩或对比度，而是以较小的模糊效应表现出来。在多数实际应用中，由于前向散射的影响远小于直接衰减和后向散射，且其精确计算较为复杂，通常可以忽略不计，以简化成像模型。

2.2 卷积神经网络

卷积神经网络作为深度学习的重要分支[111]，已广泛应用于计算机视觉任务，如图像分类、目标检测和图像增强等，其核心思想是利用局部感受野、权值共享和层级特征提取等机制有效减少参数数量，增强模型的鲁棒性。

2.2.1 非线性激活

为增强模型的表达能力，CNN 常采用非线性激活函数，常用的激活函数包含：Sigmoid[112]、Tanh[113]、ReLU（Rectified Linear Unit）[114]、Leaky ReLU[115]、ELU (Exponential Linear Unit)[116]和 Swish[117]等。

1) Sigmoid 的公式为：

$$f(x)=\frac{1}{1+e^{-x}} \tag{2.10}$$

Sigmoid 的输出范围为(0,1)，适用于概率估计，但易导致梯度消失问题。

2) Tanh 的公式为：

$$f(x)=\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}} \tag{2.11}$$

Tanh 的输出范围为(-1,1)，相较于 Sigmoid 在零点附近的梯度（斜率）较大，收敛速度更快。

3) ReLU (Rectified Linear Unit) 的公式为：

$$f(x)=\max(0,x) \tag{2.12}$$

中国知网 https://www.cnki.net

ReLU 的计算简单，有效缓解梯度消失问题，但可能导致神经元死亡问题。

4) Leaky ReLU 是基于 ReLU 的修正，公式为：

$$f(x)=\begin{cases}\max(0,x), & \text{if } x>0\\ \alpha x, & \text{otherwise}\end{cases} \tag{2.13}$$

其中 α 表示正数，解决 ReLU 的神经元死亡问题。

5) ELU (Exponential Linear Unit)的公式如下：

$$f(x)=\begin{cases}x, & \text{if } x>0\\ \alpha(e^{x}-1), & \text{otherwise}\end{cases} \tag{2.14}$$

在网络优化过程中，ELU 可以更好的处理负值。

6) Swish 的公式如下：

$$f(x)=x\cdot\text{sigmoid}(x) \tag{2.15}$$

Swish 具备平滑性和非单调性，能够提高深度网络的表现。

2.2.2 归一化与标准化

CNN 通常使用批归一化 BN 技术稳定网络的训练过程，公式如下：

$$\hat{x}_i=\frac{x_i-\mu}{\sqrt{\sigma^2+\epsilon}} \tag{2.16}$$

其中 μ 和 σ^2 分别为均值和方差，ϵ 为数值稳定性参数。BN 能够加速训练收敛，并抑制内部协变量偏移。

2.2.3 残差连接

经典的 CNN 结构包括 ResNet[119]通过引入残差连接解决深度网络的梯度消失问题，其基本残差块定义如下：

$$Y=F(X)+X \tag{2.17}$$

其中，$F(X)$表示卷积变换，X 为输入特征映射。残差学习可以缓解由于神经网络过深导致的梯度消失问题，更深层次的建模复杂的特征学习过程。

2.3 水下图像评价指标

在水下图像处理领域，图像质量评价是衡量图像清晰化、复原及其他预处理方法有效性的重要参考。由于水下环境中的光学特性复杂，导致图像易受到色彩失真、模糊、

中国知网 https://www.cnki.net

对比度降低等多种退化因素的影响。因此，图像质量评价指标对于客观评估水下图像的视觉质量具有重要意义。水下图像质量评价指标可以分为全参考指标（Full-Reference Metrics）和无参考指标（No-Reference Metrics）。

2.3.1 全参考指标

全参考指标通常需要原始未退化的高质量图像作为参考，通过计算增强或复原后图像与参考图像之间的差异来评估恢复效果。

1) 峰值信噪比

峰值信噪比（Peak Signal-to-Noise Ratio，PSNR）用于衡量图像复原质量，反映复原图像与真实图像之间的差异，数值越大，图像质量越高[122]。PSNR 的计算基于图像的均方误差（Mean Squared Error，MSE）。计算公式为：

$$\mathrm{PSNR} = 10\log_{10}\left(\frac{MAX_I^2}{\mathrm{MSE}}\right) \tag{2.18}$$

其中 MAX_I 表示图像的最大像素值（对于 8 位图像为 255），MSE 表示均方误差，常用作图像清晰化误差度量，计算预测图像和真实图像之间的像素差异，值越小表示恢复效果越好。具体公式为：

$$\mathrm{MSE} = \frac{1}{H \times W}\sum_{j=1}^{W}\sum_{i=1}^{H}(J(i,j) - \hat{J}(i,j))^2 \tag{2.19}$$

其中，J 表示真实图像，$\hat{J}$ 表示基于内监督协同多尺度表征引导的水下图像清晰化模型预测值，(i,j) 表示像素索引位置，H 和 W 分别为真实图像 J 的高和宽。

2) 结构相似性指数

结构相似性指数（Structural Similarity Index Measure，SSIM）用于计算图像的结构相似性，SSIM 通过计算复原图像与真实图像亮度、对比度和结构信息之间的差异[123]。与 MSE 不同，SSIM 能够计算图像的视觉感知质量，特别是图像的结构一致性。SSIM 的公式为：

$$\mathrm{SSIM}(J,\hat{J}) = \frac{(2\mu_{\hat{J}} + C_1)(2\sigma_{\hat{J}J} + C_2)}{(\mu_{\hat{J}}^2 + \mu_J^2 + C_1)(\sigma_{\hat{J}}^2 + \sigma_J^2 + C_2)} \tag{2.20}$$

中国知网 https://www.cnki.net

其中 $\mu_{\hat{J}}$ 和 μ_J 分别是真实图像 J 和预测图像 $\hat{J}$ 的平均值，$\sigma_{\hat{J}}^2$ 和 σ_J^2 分别表示图像 J 和 $\hat{J}$ 的方差，$\sigma_{J\hat{J}}$ 为图像 J 和 $\hat{J}$ 之间的协方差，C_1 和 C_2 为两个稳定常数，用来避免分母为零的情况。

3) 视觉显著性引导指标

在图像质量评估中，视觉显著性引导指标（Visual Saliency-induced Index，VSI）综合考虑图像显著性、梯度幅值和色度信息，旨在更准确地反映人类视觉感知对图像质量的评估[124]。VSI 的计算公式如下：

$$\mathrm{VSI}=\frac{\sum_{(i,j)\in\Omega} S(i,j)\cdot VSm(i,j)}{\sum_{(i,j)\in\Omega} VSm(i,j)} \tag{2.21}$$

其中，$VSm(i,j)=\max(VS_J(i,j),VS_{\hat{J}}(i,j))$ 是用来加权每个区域显著性的值，下标 J 表示真实图像，$\hat{J}$ 表示预测图像，Ω 表示图像的空间域。$S(i,j)$表示对于真实图像 J 和预测图像 $\hat{J}$ 在每个像素位置(i,j)的局部相似性，具体的计算公式为：

$$S(i,j)=S_{VS}(i,j)\cdot[S_G(i,j)]^{\alpha}\cdot[S_C(i,j)]^{\beta} \tag{2.22}$$

其中 $S_{VS}(i,j)$ 为真实图像 J 和预测图像 $\hat{J}$ 在位置(i,j)处的显著性图相似性度量，$S_G(i,j)$ 表示梯度幅值相似性度量，$S_C(i,j)$ 是色度相似性度量；α 和 β 是用于调节梯度和色度特征相对重要性的参数。

(1) 显著相似性度量 $S_{VS}(i,j)$ 的具体计算公式为：

$$S_{VS}(i,j)=\frac{2\cdot VS_J(i,j)\cdot VS_{\hat{J}}(i,j)+C_1}{VS_J^2(i,j)+VS_{\hat{J}}^2(i,j)+C_1} \tag{2.23}$$

其中 $VS_J(i,j)$ 和 $VS_{\hat{J}}(i,j)$ 分别表示 J 和 $\hat{J}$ 的显著性图，C_1 为正常数。

(2) 梯度幅值相似性度量 $S_G(i,j)$ 的计算公式为：

$$S_G(i,j)=\frac{2\cdot G_J(i,j)\cdot G_{\hat{J}}(i,j)+C_2}{G_J^2(i,j)+G_{\hat{J}}^2(i,j)+C_2} \tag{2.24}$$

其中，$G_J(i,j)$ 和 $G_{\hat{J}}(i,j)$ 分别为 J 和 $\hat{J}$ 的在位置(i,j)处的梯度幅值，C_2 为正常数。

(3) 色度相似性度量 $S_C(i,j)$的计算公式为：

中国知网 https://www.cnki.net

$$S_C(i,j)=\frac{2\cdot M_J(i,j)\cdot M_{\hat{J}}(i,j)+C_3}{M_J^2(i,j)+M_{\hat{J}}^2(i,j)+C_3}\cdot\frac{2\cdot N_J(i,j)\cdot N_{\hat{J}}(i,j)+C_3}{N_J^2(i,j)+N_{\hat{J}}^2(i,j)+C_3} \tag{2.25}$$

其中，$M_J(i,j)$和$M_{\hat{J}}(i,j)$分别为J和$\hat{J}$的M通道色度分量，$N_J(i,j)$和$N_{\hat{J}}(i,j)$分别为N通道色度分量，C_3为常数。

4) 特征相似性指标

特征相似性指标（Feature Similarity Index Measure，FSIM）[125]的计算考虑两个重要的特征：相位一致性（Phase Congruency，PC）和梯度幅值（Gradient Magnitude，GM）。在图像的每个局部区域进行细粒度的相似性度量，进而提升评估结果的准确性。FSIM的计算公式如下：

$$\mathrm{FSIM}=\frac{\sum_{(i,j)\in\Omega}S_L(i,j)\cdot PC_m(i,j)}{\sum_{(i,j)\in\Omega}PC_m(i,j)} \tag{2.26}$$

其中，Ω表示图像中所有像素位置的集合，用于计算整个图像的相似度。$S_L(i,j)$表示局部相似性度量，结合相位一致性和梯度幅值相似性，定义为：

$$S_L(i,j)=[S_{PC}(i,j)]^{\alpha}\cdot[S_G(i,j)]^{\beta} \tag{2.27}$$

其中$S_{PC}(i,j)$反映相位一致性，通过结合位置(i,j)处的真实图像和两个主成分值计算得到：

$$S_{PC}(i,j)=\frac{2PC_J(i,j)\cdot PC_{\hat{J}}(i,j)+T_1}{PC_J^2(i,j)+PC_{\hat{J}}^2(i,j)+T_1} \tag{2.28}$$

其中$PC_J(i,j)$和$PC_{\hat{J}}(i,j)$分别表示图像J和$\hat{J}$在位置(i,j)处的主成分信息，T_1为用于增加稳定性的正常数。$PC_m(i,j)$表示加权主成分值，计算公式为：

$$PC_m(i,j)=\max(PC_J(i,j),PC_{\hat{J}}(i,j)) \tag{2.29}$$

$S_G(i,j)$计算几何平均相似度，表示为：

$$S_G(i,j)=\frac{2G_J(i,j)\cdot G_{\hat{J}}(i,j)+T_2}{G_J^2(i,j)+G_{\hat{J}}^2(i,j)+T_2} \tag{2.30}$$

其中$G_J(i,j)$和$G_{\hat{J}}(i,j)$分别表示图像J和$\hat{J}$在位置(i,j)处的几何平均值，T_2为用于稳定度量的正常数。

中国知网 https://www.cnki.net

α 和 β 表示权重参数。采用文献[125]中的设置，即 $\alpha=1$， $\beta=1$ 以简化公式。

5) 拓展特征相似性指数

拓展特征相似性指数 FSIMc 在 FSIM 的基础上考虑图像的色度信息，结合亮度、结构以及色度信息[125]，以提高在色彩丰富场景中的表现，实现更加全面的图像质量评估。FSIMc 的计算公式如下：

$$\mathrm{FSIMc}=\frac{\sum_{(i,j)\in\Omega} S_L(i,j)\cdot[S_C(i,j)]^{\lambda}\cdot PC_m(i,j)}{\sum_{(i,j)\in\Omega} PC_m(i,j)} \tag{2.31}$$

其中，$S_J(i,j)$ 表示图像在位置(i,j)处的局部相似性度量，λ 是一个常数参数，用于调整色度信息在整体相似性度量中的权重，通常设定为大于零的值。$S_C(i,j)$ 是图像在位置(i,j)处的色度相似性度量。$S_I(i,j)$=和 $S_Q(i,j)$ 具体公式如下：

$$S_I(i,j)=\frac{2I_J(i,j)\cdot I_j(i,j)+T_3}{I_J^2(i,j)+I_j^2(i,j)+T_3} \tag{2.32}$$

$$S_Q(i,j)=\frac{2Q_J(i,j)\cdot Q_j(i,j)+T_4}{Q_J^2(i,j)+Q_j^2(i,j)+T_4} \tag{2.33}$$

其中，T_3 和 T_4 为常数，用于调节色度分量的动态范围，通常设置为相同的数值，即：$T_3=T_4$。基于上述 $S_I(i,j)$ 和 $S_Q(i,j)$ 计算色度相似性度量 $S_C(i,j)$，具体计算公式如下：

$$S_C(i,j)=S_I(i,j)\cdot S_Q(i,j) \tag{2.34}$$

FSIMc 通过结合亮度、结构和色度信息，可以在处理图像中色彩丰富的区域时，提供比传统 FSIM 更为精确的质量评估。特别是在色彩信息对视觉感知具有重要影响的应用场景中，FSIMc 能够更好地反映图像的真实质量。

2.3.2 无参考指标

在真实水下环境中获取高质量的参考图像往往具有较大难度，因此依赖于参考图像的全参考质量指标难以广泛应用于水下图像的客观评价中。为解决该问题，近年来无参考图像质量评价指标逐渐成为水下图像增强和复原领域的重要工具。无参考指标无需依赖参考图像，可以直接基于图像本身的统计特征、视觉特性和物理属性，量化图像的色彩失真、对比度降低、细节模糊等问题，进而实现对水下图像清晰化效果的客观评价。

1) UIQM 水下图像质量评价指标

中国知网 https://www.cnki.net

UIQM（Underwater Image Quality Measure）用于衡量水下图像的质量。该指标综合考虑水下图像的色彩对比度、亮度和清晰度，能够较为全面地评估水下图像的视觉质量[126]。UIQM 由三个子指标组成：UICM（Underwater Image Colorfulness Measure）、UISM（Underwater Image Sharpness Measure）和 UIConM（Underwater Image Contrast Measure），其计算公式如下：

$$\mathrm{UIQM} = c_1 \times \mathrm{UICM} + c_2 \times \mathrm{UISM} + c_3 \times \mathrm{UIConM} \tag{2.35}$$

其中，c_1，c_2，c_3为权重系数。

(1) UICM

UICM 用于衡量水下图像的色彩丰富度，利用$l\alpha\beta$颜色空间来计算图像的色彩分布。公式如下：

$$\mathrm{UICM} = \mu_\alpha^2 + \mu_\beta^2 + \sigma_\alpha^2 + \sigma_\beta^2 \tag{2.36}$$

其中，μ_α和μ_β分别表示颜色通道α和β的均值，σ_α和σ_β表示对应的标准差。UICM 度量能够反映水下图像的色彩失真情况。

(2) UISM

UISM 主要用于衡量水下图像的清晰度，公式如下：

$$\mathrm{UISM} = \sum_{i,j} |\nabla^2 J(I,J)| \tag{2.37}$$

其中，$\nabla^2 J(i,j)$表示图像在像素位置(i,j)处的 Laplacian 梯度值。UISM 值越高，说明图像的细节更加清晰，边缘信息更加丰富。

(3) UIConM

UIConM 反映水下图像的对比度，利用直方图均衡度来计算图像的局部对比度。计算公式如下：

$$\mathrm{UIConM} = \frac{1}{H*W} \sum_{j=1}^{W} |\sum_{i=1}^{H} J(i,j) - \mu_J| \tag{2.38}$$

其中，$J(i,j)$表示像素点(i,j)处的强度值，μ_J表示全图的平均强度，$H*W$表示图像的总像素数。

UIQM 通过结合色彩、清晰度和对比度信息，为水下图像提供一种综合性的无参考质量评价标准，在水下图像增强和复原任务中具有广泛的应用价值。

2) UCIQE 水下图像颜色质量评估

中国知网 https://www.cnki.net

UCIQE（Underwater Color Image Quality Evaluation）是一种基于水下图像颜色分布和对比度特性的质量评价指标。UCIQE 主要用于衡量水下图像的色彩失真和对比度降低情况[127]，其计算基于 CIELAB 颜色空间，公式如下：

$$\mathrm{UCIQE} = c_1 \times \sigma_c + c_2 \times con_l + c_3 \times \mu_s \tag{2.39}$$

其中 σ_c 表示 CIELAB 颜色空间中色调分量 c 的标准差，计算图像的色彩分布范围；con_l 表示亮度通道 L 的对比度，定义为图像亮度直方图的 1%和 99%分位数之差；μ_s 表示饱和度通道 s 的均值，反映图像的整体色彩饱和度；c_1，c_2，c_3 为权重系数。

UCIQE 通过综合评估色彩对比度、亮度对比度和色彩饱和度，为水下图像质量提供一种有效的无参考评价方法。

3) CCF 颜色对比度雾度综合评价指标

CCF（Colorfulness, Contrast and Fog density）指标[128]通过结合色彩度、对比度和雾霾密度等因素，全面地评估水下图像的质量。计算公式为：

$$\mathrm{CCF} = \omega_1 \times \mathrm{Color} + \omega_2 \times \mathrm{Con} + \omega_3 \times \mathrm{F} \tag{2.40}$$

其中，ω_1, ω_2 和 ω_3 分别表示权重，Color 表示色彩度指标，Con 表示对比度指标，F 表示雾霾密度评估。

在色彩度的计算中，使用基于对数尺度的色彩转换方法，将 RGB 颜色空间转换到 lαβ 颜色空间评估图像的色彩损失。色彩度值的计算公式为：

$$\mathrm{Color} = \frac{\sqrt{\sigma_\alpha^2 + \sigma_\beta^2 + 0.3 \cdot \sqrt{\mu_\alpha^2 + \mu_\beta^2}}}{85.59} \tag{2.41}$$

其中 σ_α 和 σ_β 分别表示 $l\alpha\beta$ 颜色空间中色度 α 和 β 的方差，μ_α 和 μ_β 分别表示 $l\alpha\beta$ 颜色空间中色度通道 α 和 β 的均值。

通过计算所有边缘块的 RMS 对比度，以量化图像的模糊程度。对比度的计算公式为：

$$\mathrm{Con} = \sum_{k=1}^{K} \sqrt{\frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} (\hat{J}(i,j) - \mu_{\hat{J}}^k)^2} \tag{2.42}$$

其中 $\hat{J}(i,j)$ 表示预测图像中索引位置(i,j)的像素值，$\mu_{\hat{J}}^k$ 表示在第 k 个预测图像块中所有像素强度值的平均值，H 和 W 分别为图像块的高和宽，在论文中设置 H=64，W=64。K 表示所有被标识为边缘区域的图像块的总数。

中国知网 https://www.cnki.net

雾霾密度评估采用多元高斯模型拟合图像的统计特征，计算图像与参考图像之间的马氏距离，从而评估图像的雾霾程度。

CCF 指标能够综合考虑图像中的色彩、对比度和雾霾信息，通过加权求和的方式提供一个全面的图像质量评估标准。在水下图像处理领域，CCF 通过考虑色彩失真、模糊和雾霾等多个因素，能够更全面地反映图像质量的变化。但是现有的水下图像清晰化方法中，红色分量通常会被过度恢复，导致图像出现不真实的色彩还原。为避免这些方法导致的错误色彩恢复对图像质量评估结果的干扰，论文选择将色彩失真系数ω_1设置为 0，其他加权系数按照文献[128]中的设定：$\omega_2 = 0.61759$，$\omega_3 = 0.33988$。

4) CEIQ 图像对比度质量评价

CEIQ（Contrast Enhanced Image Quality）指标结合图像相似性、直方图基于熵的计算和交叉熵的特性，用于计算图像的质量[129]。通过图像的亮度、对比度、结构、直方图的交互关系，以全面评估图像的视觉效果。

2.4 本章小结

本章围绕水下图像成像机理、卷积神经网络、水下评价指标进行系统梳理。介绍水下图像的成像模型，包括基于 Retinex 理论的水下图像清晰化方法、水下图像成像模型。阐述卷积神经网络的基本构成。总结水下图像质量评价的关键指标，包括图像质量评价方法、针对水下场景优化的感知质量评价方法，为后续水下图像清晰化方法的定量评估提供依据。本章内容为后续水下图像清晰化方法研究奠定理论基础。

中国知网 https://www.cnki.net

3 基于光衰减表征的水下图像自适应颜色校正方法

水下图像在成像过程中因水体介质对光的选择性吸收与散射效应引发色彩失真、蓝绿色偏色以及对比度下降等，针对局部深度与光衰减耦合关系建模不准确问题，本章针对基于光衰减表征的水下图像自适应颜色校正方法（Adaptive Color Correction Method Based on Light Attenuation Representation, ACCM）开展研究。ACCM 充分建模水下图像在不同水深与光照条件下的局部色彩变化特征，基于空间维度对图像进行局部区域划分，提出自适应颜色补偿因子的设计策略；提出参考通道选择机制，针对水下不同深度与区域的色彩失真问题，设计基于图像块局部统计特性的自适应校正因子计算方法；结合双线性插值策略将局部颜色补偿因子扩展到整幅图像，实现空间维度的平滑过渡；提出基于通道色偏因子的全局颜色重建方法，通过在图像块中计算通道色偏因子并结合双线性插值策略提升图像色彩校正的自然性和一致性。通过本章旨在为后续水下图像清晰化提供高质量的色彩校正基础，提升水下图像在复杂水环境中的色彩保真度和视觉一致性，为后续图像清晰化与特征提取提供支持。

3.1 ACCM 方法提出

水下图像中普遍存在颜色失真、前景过度补偿与背景恢复不足的现象，其根本原因在于水体介质对不同波长光的选择性衰减与散射作用的非均匀性。现有方法难以准确建模局部深度变化与水下光谱衰减之间的耦合关系，导致颜色补偿过程缺乏空间适应性与物理一致性。因此，亟需研究水下光谱衰减机理与局部图像块特征间的交互作用机制，构建具备局部光环境认知能力的补偿策略。

根据水下成像模型，颜色的感知与场景深度密切相关，随着场景深度的增加，颜色偏差会变得更加严重，统一的全局颜色校正方法无法完全恢复不同深度场景下的颜色偏差。因此本章提出基于光衰减表征的水下图像自适应颜色校正方法，旨在有效地恢复不同深度水下图像的真实色彩。

经典的色彩校正方法包括 Max RGB[130]、灰度世界算法[131]、灰度边缘法[132]和灰度色调法[133]。这些方法通常假设环境光照分布均匀，并利用统计照明估计策略进行颜色补偿。然而，基于灰度假设的色彩校正方法[134,135]难以准确估计水下图像的真实照明情况。此外，由于水下光照的复杂性和场景深度的变化，全局色彩校正方法往往无法适应局部区域的不同退化情况，可能导致前景区域色彩校正过度，而后景区域仍存在明显的偏色现象。

中国知网 https://www.cnki.net

针对局部深度与光衰减耦合关系建模不准确问题，本章提出基于光衰减表征的水下图像自适应颜色校正方法，充分考虑水下光衰减的空间不均匀性，通过局部区域划分策略计算自适应颜色补偿因子，再利用双线性插值方法进行全局平滑扩展，从而保证不同水深区域的颜色校正能更加自然、平滑地过渡。相比于现有全局校正方法，本章提出的方法不仅能有效补偿水深变化导致的颜色选择性吸收问题，还能在局部区域内针对不同的退化程度进行精细调整，提高水下图像的色彩保真度和视觉一致性。

基于光衰减表征的水下图像自适应颜色校正方法的架构图如图 3.1 所示。

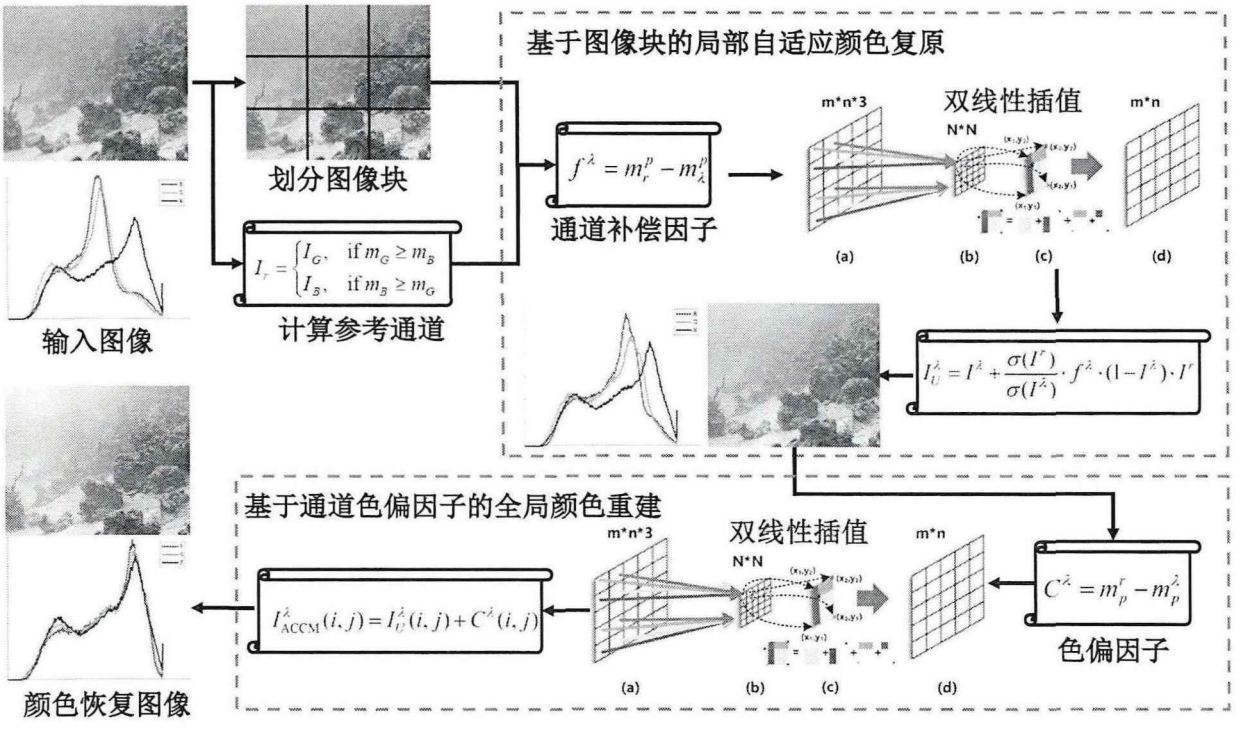

图 3.1 基于光衰减表征的水下图像自适应颜色校正方法架构图

Fig. 3.1 Framework diagram of the adaptive color correction method based on light attenuation representation

ACCM 分为以下两个主要组成部分：

1) **基于图像块的局部自适应颜色复原方法**：通过将水下图像划分为若干个 $N\times N$ 的图像块，每个图像块代表一个局部区域，具有一致的图像特征，便于进行局部的自适应颜色复原。在每个图像块内，通过参考通道的平均值判断退化最少的颜色通道作为参考通道。计算每个图像块的补偿因子后，采用双线性插值算法将这些补偿因子扩展到整个图像，从而为每个像素位置提供合适的恢复因子，这一过程确保退化图像的颜色恢复

中国知网 https://www.cnki.net

因子能根据局部深度差异进行优化，从而避免全局方法无法有效处理深度变化带来的过度恢复和恢复不足的问题。

2) **基于通道色偏因子的全局颜色重建方法**：由于局部恢复颜色后图像依然存在整体色偏，特别是在不同通道之间的色差，引入色偏因子，基于参考通道与其他恢复通道之间的色差进行校正，有效去除色彩失真。

通过结合补偿因子和通道色偏因子，基于光衰减表征的水下图像自适应颜色校正方**法能实现更为精确**的色彩校正，使图像的色彩恢复更加自然，接近真实场景的颜色。并**通过自适应调整**提高图像质量。该方法在处理不同水下场景时具有较强的自适应能力，尤其在深水和极端水下环境下，表现出较强的鲁棒性和色彩恢复能力。

3.2 基于图像块的局部自适应颜色复原方法

水下图像的色彩失真通常源于水体对不同波长光的选择性吸收和散射效应，颜色失真显著影响水下视觉任务的性能。水下图像色彩校正方法（如水下白平衡 UWB[61]和 IUWB[136]）采用全局颜色恢复因子，无法有效恢复因深度引起的色彩失真。为解决这一问题，本章提出基于图像块的局部自适应颜色复原方法，以提高对水下图像色彩失真规律的建模能力。

水下图像成像模型的退化公式为：

$$I^{\lambda} = J^{\lambda}(x,y)\cdot e^{-\beta(\lambda)d(x,y)} + (1-e^{-\beta(\lambda)d(x,y)})\cdot A^{\lambda} \tag{3.1}$$

其中，$I^{\lambda}(x,y)$是水下图像中λ通道的像素值，$\lambda \in \{R,G,B\}$，$J^{\lambda}(x,y)$ 是真实图像的像素值，$\beta(\lambda)$是波长λ的衰减系数，$d(i,j)$表示从场景中物体到相机的深度，A^{λ}是大气光。

为更精确地描述不同水体类型对光传输的影响，Jerlov 提出水体分类模型，根据水体的光学特性将海洋水体划分为 I、IA、IB、II、III 五种海洋水体类型，将沿海水体分为 1、3、5、7、9 共五种类型[138]。其中海洋水体中水质越接近 I 类，吸收和散射效应越弱，水体越清澈；水质越接近 III 类，光衰减越快，水体浑浊度越高。不同水类型的衰减系数$\beta(\lambda)$数值如表 3.1 和表 3.2 所示。

水下图像成像模型展示水下图像在不同深度下的光衰减特性。水下图像的色彩失真主要由场景深度的变化引起，尤其是在水下图像的背景区域，由于深度的不同，前景物体和背景海水的色偏差异显著。现有的全局恢复因子方法无法有效解决这一问题。基于此，提出基于图像块局部自适应颜色复原，利用文献[139]的理论假设每个图像块内的深度变化是平滑的。这种方法使得每个图像块可以拥有自适应的色彩恢复因子，从而避免全局颜色恢复因子无法适应局部深度差异的局限。

中国知网 https://www.cnki.net

表 3.1 海洋水体中 Jerlov 水类型的 $\beta(\lambda)$ 值

Tab. 3.1 The $\beta(\lambda)$ values of Jerlov water types in oceanic waters

	I	IA	IB	II	III
R	0.805	0.804	0.830	0.800	0.750
G	0.961	0.955	0.950	0.925	0.885
B	0.982	0.975	0.968	0.940	0.890

表 3.2 沿海水体中 Jerlov 水类型的 $\beta(\lambda)$ 值

Tab. 3.2 The $\beta(\lambda)$ values of Jerlov water types in coastal waters

	1	3	5	7	9
R	0.750	0.710	0.670	0.620	0.550
G	0.885	0.820	0.730	0.610	0.460
B	0.875	0.800	0.670	0.500	0.290

水下图像的衰减程度与图像中的深度有关，如公式(3.1)所示。深度 d 越大，波长衰减越严重。由于不同波长的光在水中的选择性吸收，不同深度的像素位置在图像中表现出不同程度的色偏，尤其是在图像的前景和背景区域。因此，水下图像中不同深度的区域应具有不同的恢复因子。

然而，UWB[61]和 IUWB[136]中的白平衡方法采用全局恢复因子，虽然可以有效恢复整体色偏，但会导致水下图像的背景区域无法完全恢复。因此，本章通过从图像块中确定每个像素的恢复因子来进行色彩恢复。图像块的大小可以根据图像的尺寸自动设置，并且通过以下公式进行计算：

$$p_m = \frac{m}{N} \tag{3.2}$$

$$p_n = \frac{n}{N} \tag{3.3}$$

其中 m 和 n 分别表示图像的高度和宽度，p_m 和 p_n 分别表示图像块的高度和宽度，而 N 是图像块的数量（本章中设定 $N=3$）。N 值越大，水下图像的色彩恢复效果越好。然而，当 N 值过大时，恢复后的水下图像可能出现“灰色”效果。通过公式(3.2)和(3.3)，图像块的大小会根据图像的实际尺寸进行自适应调整，确保有效合理建模每个图像块的深度信息，从而提高图像清晰化的精度。

中国知网 https://www.cnki.net

本章基于图像块计算通道恢复因子，根据表 3.1 和表 3.2 所示，在所有水类型中，大多数水类型中红通道的衰减值最多，因此本章选用蓝通道和绿通道作为参考通道。通过计算每个通道的平均值，选取具有最大平均值的通道作为参考通道：

$$I_r = \begin{cases} I_G, & \text{if } m_G \geq m_B \\ I_B, & \text{otherwise} \end{cases} \tag{3.4}$$

其中，m_G 和 m_B 分别是图像块中 G 通道和 B 通道的平均值，I_r 表示参考通道。通过计算不同通道的平均值，可以精准地判断出衰减最小的颜色通道用作白平衡恢复的参考通道。

基于参考通道计算每个图像块的通道恢复因子，计算公式如下：

$$f_\lambda^p(x,y) = m_r^p(x,y) - m_\lambda^p(x,y) \tag{3.5}$$

其中，$m_r^p(x,y)$ 是参考通道在图像块内的平均值，$m_\lambda^p(x,y)$ 是 λ 通道在图像块内的平均值。f 表示通道恢复因子，p 为水下图像划分的图像块，下标 r 表示参考通道，由式（3.4）获取，$\lambda \in \{R,G,B\}$。

图像块内使用统一的白平衡恢复因子会导致恢复图像出现块现象。此外，逐像素计算恢复因子的时间复杂度较高。因此使用双线性插值技术将该补偿因子应用到整个图像。在图像块中心点计算出的通道恢复因子 f_λ^p 基础上，为平滑地将这些局部补偿因子扩展到全图中任意像素位置 (x,y)，采用双线性插值方法，其计算公式如下：

$$f(x,y) = \frac{1}{(x_2-x_1)(y_2-y_1)} \sum_{i=1}^{2}\sum_{j=1}^{2} f_\lambda^p(p_{ij}) \cdot (x_{3-i}-x) \cdot (y_{3-j}-y) \tag{3.6}$$

其中 (x_1,y_1) 和 (x_2,y_2) 分别为包含当前像素 (x, y) 的图像块的左上角和右下角坐标；$f_\lambda^p(p_{ij})$ 表示周围四个图像块中心点的补偿因子（即 p_{11} 表示左上、p_{21} 表示右上、p_{12} 左下、p_{22} 右下）；(x,y) 为当前待插值位置；$(x_{3-i}-x)$ 和 $(y_{3-j}-y)$ 分别表示水平方向和垂直方向的距离权重。

公式(3.6)通过加权四个相邻图像块中心的补偿因子，实现对全图每个像素点的平滑插值，进而生成自适应的颜色补偿因子，有效提升局部颜色校正的精度避免块状伪影现象。该方法为每个像素位置设计自适应的通道恢复因子，不仅显著提升补偿因子的精度，还增强方法在不同水下场景下的适应性，改善水下图像的整体恢复效果与视觉质量。

中国知网 https://www.cnki.net

通道恢复因子可以通过公式（3.5）计算，然后采用双线性插值方法来计算图像块中每个像素的通道恢复因子。如图 3 所示，计算整个图像的通道恢复因子过程可以分为三个主要组成部分：

1) 将水下图像划分为 $N\times N$ 的图像块；

2) 通过公式（3.5）在每个图像块中计算通道恢复因子；

3) 通过双线性插值法，从 $N\times N$ 的图像块矩阵中获得 $m\times n$ 尺寸的通道恢复因子矩阵，矩阵中的每个值对应水下图像中每个像素的位置。

该补偿公式基于 UWB 方法[61]用于像素级别的补偿，旨在恢复水下图像因水体特性而产生的通道衰减问题：

$$I_U^{\lambda}(x,y)=I^{\lambda}(x,y)+\frac{\sigma(I^{r})}{\sigma(I^{\lambda})}\cdot F^{\lambda}(x,y)\cdot(1-I^{\lambda}(x,y))\cdot I^{r}(x,y) \tag{3.7}$$

其中 $I_U^{\lambda}(x,y)$ 表示初步白平衡结果，(x,y)代表图像中的位置索引。$I^{\lambda}(x,y)$ 是图像中 λ 通道的像素值，$I^{r}(x,y)$ 是参考通道的像素值，而 $\sigma(I^{\lambda})$ 代表 λ 通道的标准差。

3.3 基于通道色偏因子的全局颜色重建方法

通过基于图像块的局部自适应颜色复原进行计算后，白平衡处理有效地改善除参考通道之外的其他通道的像素值，特别是红色通道（R 通道）。然而，经过局部白平衡处理后，三通道的平均像素值仍存在差异，并且图像中仍然有一定的色偏问题。因此，为消除上述色偏，本章在每个图像块的通道补偿过程中引入一个通道色偏因子，用于全局颜色重建。

3.3.1 色偏因子的数学建模与理论分析

在初步白平衡处理后（公式 3.7），由于水下光衰减的空间异质性导致不同通道的残留偏差，图像仍存在整体色偏现象，为此，本节提出基于统计分布的色偏因子校正模型。

本方法的核心理论建立在以下三个基本理论：

1) 局部平稳性：要求每个图像块内的色偏分布具有空间一致性，即块内颜色偏差可视为均匀变化，允许通过分块建模捕捉局部退化特征，避免全局方法因空间异质性导致的校正偏差。

2) 参考通道可靠性：基于水下光衰减特性（公式 3.1），所选参考通道 r 的噪声干扰可忽略，其统计均值可以逼近真实场景的反射率均值（如公式 3.4 中通过比较 G/B 通

中国知网 https://www.cnki.net

道均值动态选择参考通道）；上述合理性源于红光在水下衰减最显著，而蓝绿光保留相对完整的光学特性，使得参考通道的均值具有较高的信噪比。

3) 线性可分离性：认为色偏噪声与真实颜色信号可通过线性叠加模型分离（公式3.8-3.9），这一假设简校正过程，并在水下多数场景中具有足够精度。

在局部图像块 p 内，颜色偏差服从线性叠加模型：

$$I_{\mathrm{UB}}^{\lambda}(x,y)=I_{\mathrm{true}}^{\lambda}(x,y)+C^{\lambda}(x,y),\quad \lambda\in\{R,G,B\} \tag{3.8}$$

其中 $I_{\mathrm{true}}^{\lambda}$ 为真实颜色值，C^{λ} 为残留色偏噪声。

由于参考通道 r 的衰减最小（由公式 3.4 选定），其残留噪声项 C^{λ} 显著小于其他通道可忽略不计，即 $C^{r}=0$。因此，基于灰度世界假设，可通过块内均值差的平方均值计算块内色偏因子。

根据灰度世界假设：

$$\frac{1}{|p|}\sum_{(x,y)\in p}\left(I_{\mathrm{true}}^{R}(x,y)\right)=\frac{1}{|p|}\sum_{(x,y)\in p}\left(I_{\mathrm{true}}^{G}(x,y)\right)=\frac{1}{|p|}\sum_{(x,y)\in p}\left(I_{\mathrm{true}}^{B}(x,y)\right) \tag{3.9}$$

将 $C^{r}=0$ 和公式(3.9)代入到公式(3.8)中计算块内色偏因子：

$$C_{p}^{\lambda}=\frac{1}{|p|}\sum_{(x,y)\in p}\left(I_{\mathrm{UB}}^{\lambda}(x,y)-I_{\mathrm{UB}}^{r}(x,y)\right) \tag{3.10}$$

其中 C_{p}^{λ} 代表色偏因子。

3.3.2 全局颜色重建的优化方法

为提升色偏校正的鲁棒性，根据每个图像块得到的色偏因子 C_{p}^{λ} 进行双线性插值得到每个像素位置的色偏因子 C^{λ}，插值公式同公式(3.6)。强化对红光衰减区域（如深水区）的色偏校正精度，最终解析退化为：

$$I_{\mathrm{ACCM}}^{\lambda}(x,y)=I_{\mathrm{UB}}^{\lambda}(x,y)-C^{\lambda}(x,y) \tag{3.11}$$

其中，$I_{\mathrm{ACCM}}^{\lambda}(x,y)$ 表示基于光衰减表征的水下图像自适应颜色校正方法的颜色校正结果。通过引入通道色偏因子的结合，ACCM 方法设计的色偏因子 C^{λ} 具有良好的统计一致性，作为图像块内颜色残差估计，保证颜色补偿的准确性与稳健性。

本章提出的 ACCM 方法通过考虑局部图像块统计与深度自适应性，显著提升色彩校正的理论完备性。基于图像块的局部补偿因子可以捕捉不同深度区域的色偏特征，避免全局假设的局限性；利用双线性插值技术保留局部校正精度，并保证运行效率，实现

中国知网 https://www.cnki.net

补偿因子的空间平滑过渡，有效抑制块状伪影；色偏因子校正通过统计建模块内残差分布，消除通道间残留偏差。

Algorithm 3.1: Adaptive Color Correction Method Based on Light Attenuation Representation (ACCM)

Input: Underwater image $I \in \mathbb{R}^{H\times W\times 3}$, block number N

Output: Color-corrected image $I_{\text{ACCM}} \in \mathbb{R}^{3\times H\times W}$

// **Step1:** Image block partitioning

Blocks $\leftarrow$ SplitIntoBlocks(I, N) // Image block partitioning

// **Step2:** Reference channel computation

for each block $p \in$ Blocks :

    $m_G \leftarrow \text{Mean}(p_G)$

    $m_B \leftarrow \text{Mean}(p_B)$

    if $m_G \geq m_B$

        r = G

    else:

        r = B

    end if

end for

// **Step3:** Local adaptive color restoration

for each channel $\lambda \in \{R, G, B\}$:

    $f_\lambda^p \leftarrow \text{Mean}(p_r) - \text{Mean}(p_\lambda)$

    $F_{\text{map}} \leftarrow \text{BilinearInterpolation}(\{f_\lambda^p\}, \text{Blocks})$

    for each pixel (x, y) :

        for each channel λ :

$$I_{\text{WB}}^{\lambda}(x,y) \leftarrow I^{\lambda}(x,y) + \frac{\sigma(I^r)}{\sigma(I^{\lambda})} \cdot F_{\text{map}}^{\lambda}(x,y) \cdot (1 - I^{\lambda}(x,y)) \cdot I^r(x,y)$$

        end for

    end for

end for

// **Step4:** Global color reconstruction

for each block $p \in$ Blocks :

    $C_\lambda^p \leftarrow \text{Mean}(I_{\text{WB},p}^r - I_{\text{WB},p}^\lambda)$

end for

for each channel $\lambda \in \{R, G, B\}$:

    $C_{\text{map}}^\lambda \leftarrow \text{BilinearInterpolation}(\{C_p^\lambda\}, \text{Blocks})$

    $I_{\text{ACCM}}^\lambda \leftarrow I_{\text{WB}}^\lambda + C_{\text{map}}^\lambda$

end for

Return I_{ACCM}

中国知网 https://www.cnki.net

3.4 ACCM 算法设计

ACCM 旨在解决由于水体对光的选择性吸收和散射造成的水下图像色彩失真问题。针对传统全局色彩校正方法难以适应不同深度场景退化差异的局限性，通过建模水下图像的空间非均匀性，实现对不同深度区域的颜色自适应校正。

ACCM 将图像划分为多个局部图像块，根据每个块中退化程度较轻的参考通道计算颜色补偿因子。再通过双线性插值将补偿因子平滑扩展到整幅图像，实现深度感知的颜色复原，避免传统全局方法在深浅区域存在的过度或不足校正问题。针对局部校正后仍存在的整体色偏问题，引入通道间色偏因子，在参考通道的引导下对其他通道进行再校正，提升色彩一致性与自然度。算法如 Algorithm 3.1 所示。

ACCM 方法由以下四部分构成：

1) 图像块划分：将输入水下图像划分为若干不重叠的局部图像块，便于基于局部特征进行补偿因子的计算。

2) 参考通道选择：在每个图像块内，依据 G 通道与 B 通道的均值选择参考通道。

3) 局部自适应颜色复原：基于图像块中的均值计算补偿因袭，为消除块效应并提升补偿的连续性，采用双线性插值方法将局部补偿因子平滑扩展至整幅图像，实现像素级别的自适应补偿，完成初步的白平衡和颜色恢复操作，显著改善水下图像的颜色偏移问题。

4) 全局颜色重建：在初步颜色校正结果基础上，对各图像块内的色彩偏差进行修正，避免由于不同块的色彩分布差异而引起的全局不一致性，最获得高保真度的校正图像。

3.5 实验结果与分析

本节基于定性质量和定量评价验证 ACCM 方法的有效性，为验证 ACCM 方法的鲁棒性，使用 UIEB[77]、UPRC[140]、MABLs[166]、UFO120[141]和 U45[156]数据集进行实验说明，其中 UPRC[140]数据由 Zhangzidao 采集的真实数据组成。

3.5.1 定性质量评价

为验证所提出色彩校正方法的有效性，对多个不同水下场景的原始图像进行实验分析。如图 3.2 到图 3.6 所示。测试图像包括均匀退化的图像（图 3.2），和具有挑战性的非均匀退化图像（图 3.3、图 3.4、图 3.5），和 UPRC 数据集中真实的水下场景（图 3.6）。为展示基于光衰减表征的水下图像自适应颜色校正方法的性能，本节与现有的先进色彩

中国知网 https://www.cnki.net

校正方法进行对比，包括水下白平衡（UWB）[61]、GI[134]、MSGP[135]、IUWB[136]、WaterNet中的白平衡方法[77]、C5[142]和 CBLA[137]。

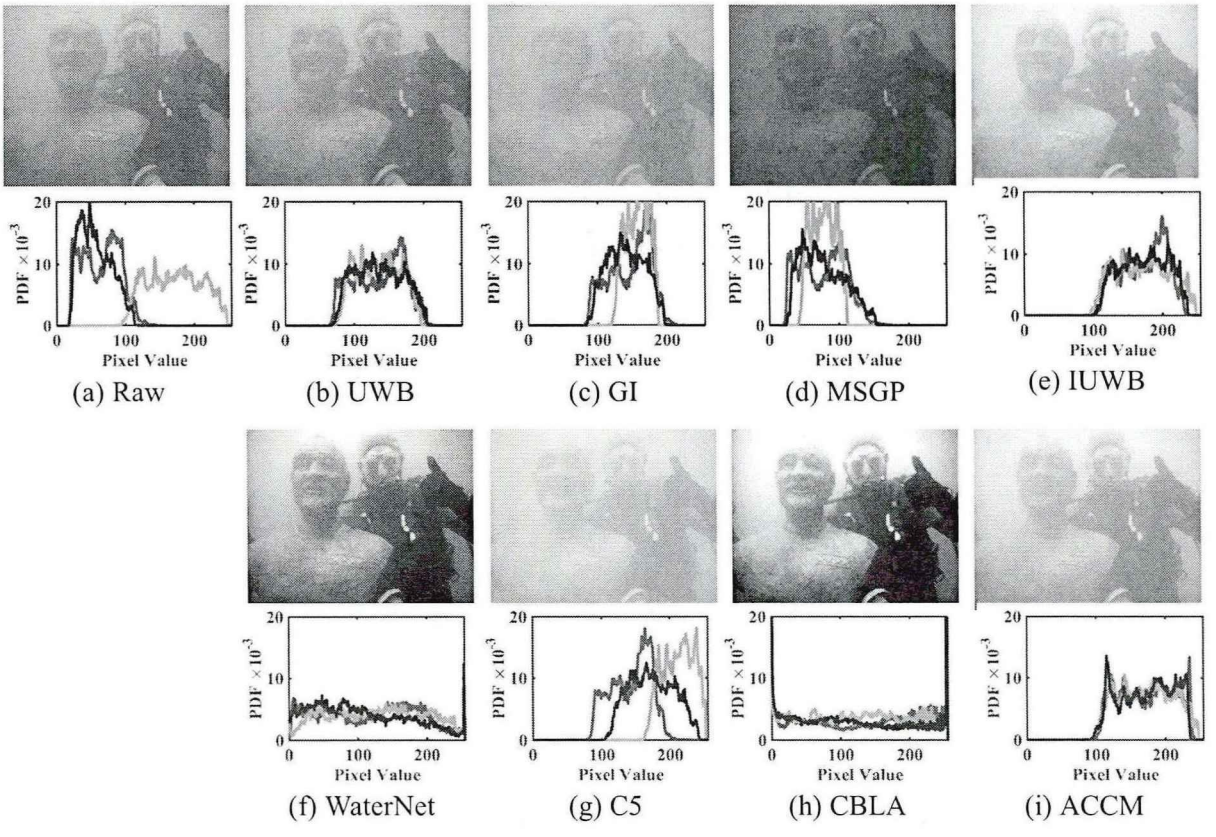

图 3.2 绿色均匀退化场景颜色校正结果的视觉对比图

Fig. 3.2 Visual comparison of color correction results in green uniformly degraded underwater scenes

图 3.2 中展示不同方法处理后的图像及其对应的三通道（RGB）直方图，直观反映各对比方法和 ACCM 方法对图像色彩分布的影响，图 3.2 中 (a) 表示原始水下图像，(b) 为 UWB 的视觉结果，(c) 为 GI[134]的视觉结果，(d) 展示 MSGP[135]的视觉结果，(e) 为 IUWB[136]的视觉结果，(f) 为 WaterNet[77]中所用白平衡策略的视觉结果，(g) C5[142]的视觉结果，(h) CBLA[137]中所用白平衡策略的视觉结果，(i) 本章所提出的 ACCM 的视觉结果。

如图 3.2 所示，在均匀退化的图像中，UWB、GI、WaterNet、IUWB 和 ACCM 的表现较好，但 MSGP、CBLA 在复杂水下环境下未能正确恢复图像的色彩，本章提出的

中国知网 https://www.cnki.net

ACCM 方法在去除背景色偏方面表现优越。如图 3.3 所示，ACCM 方法可以有效恢复后景部分的色偏，未在前景部分引入不正确红色和黄色。

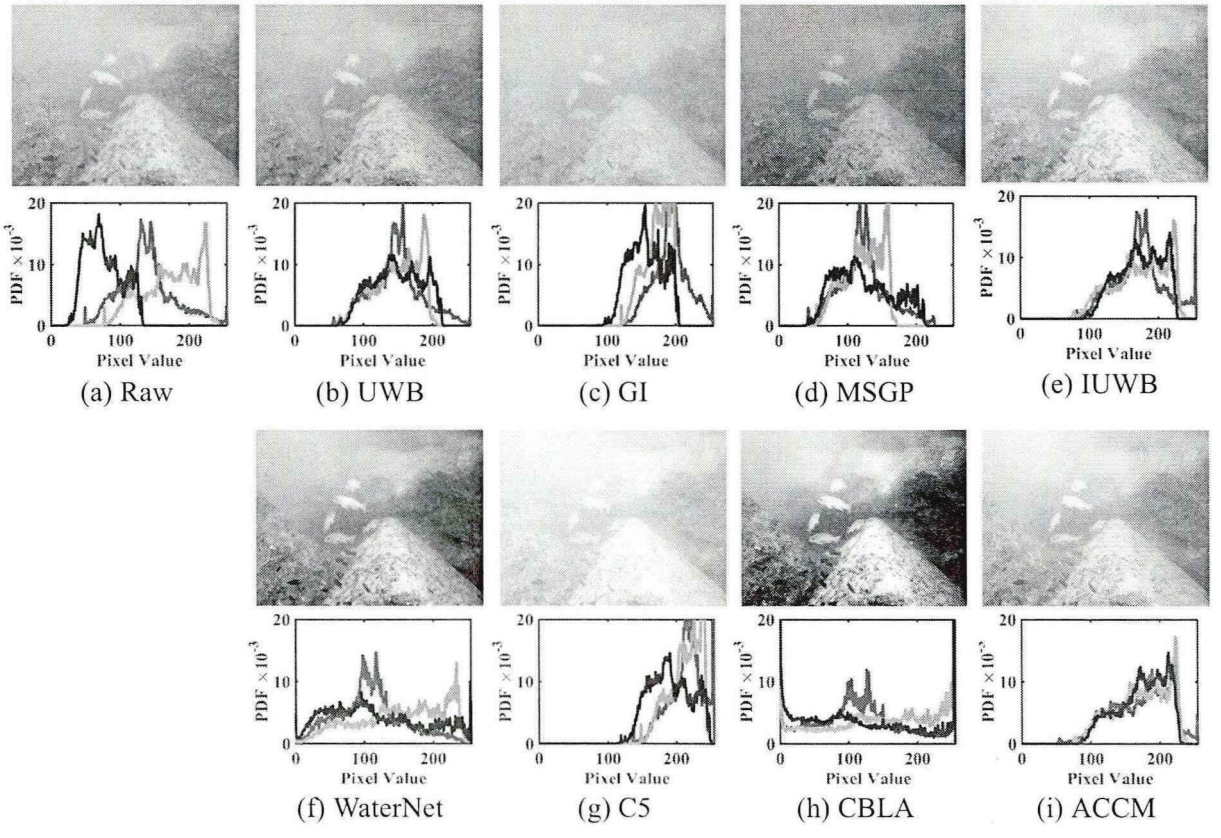

图 3.3 绿色非均匀退化场景颜色校正结果的视觉对比图

Fig. 3.3 Visual comparison of color correction results in green non-uniformly degraded underwater scenes

在非均匀退化的图 3.4 中，现有的方法都在前景部分引入错误的颜色，WaterNet 全局色彩平衡未能有效去除背景色偏。图 3.4 的三通道直方图显示，WaterNet 所用的白平衡策略仍然存在严重的蓝色偏色，其蓝色通道的分布显著偏离红色和绿色通道，表明该方法在处理非均匀退化情况时的适应性不足。

由于水下图像的训练数据量相对较少，C5 仅能在图像 3.6 中恢复正确的色彩。相比之下，ACCM 方法可以有效去除背景区域的色偏（如图 3.3 到图 3.6 所示），并且避免在前景区域的过度恢复，避免引入额外的红色或黄色失真。三通道直方图验证 ACCM 方法的有效性，在调整 RGB 通道的直方图分布时，保持参考通道的分布形态，验证 ACCM 方法在不丢失图像色彩信息的情况下，精确恢复图像色彩。

中国知网 https://www.cnki.net

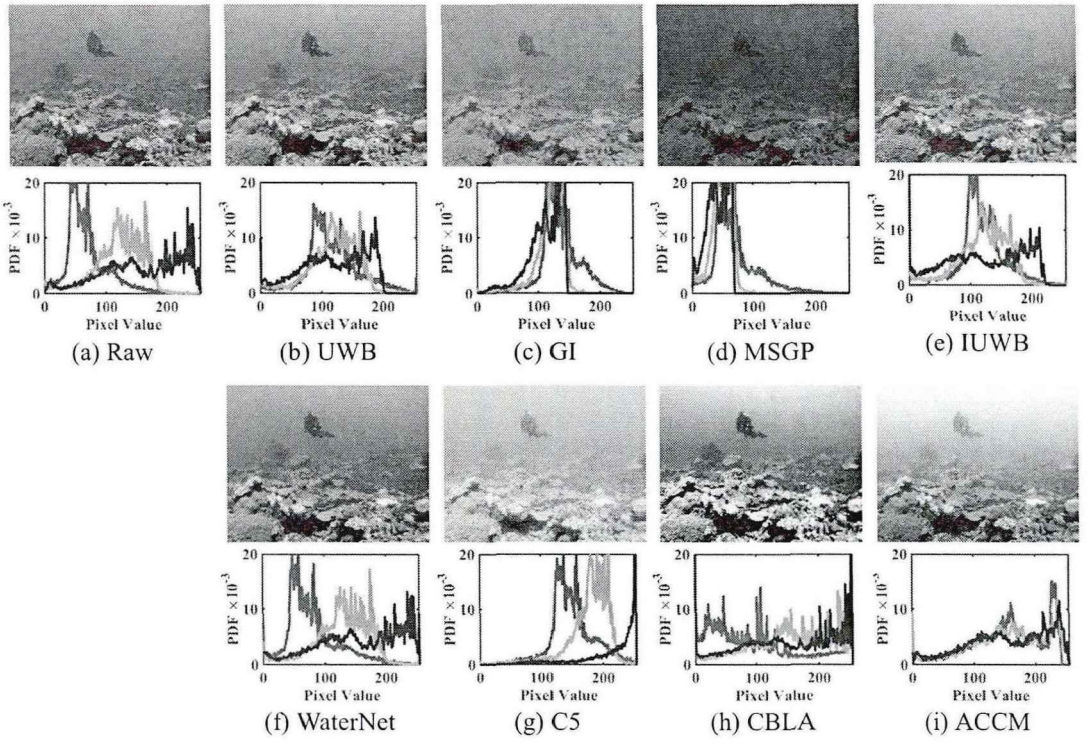

图 3.4 蓝色非均匀退化场景颜色校正结果的视觉对比图

Fig. 3.4 Visual of color correction results in blue non-uniformly degraded scenes

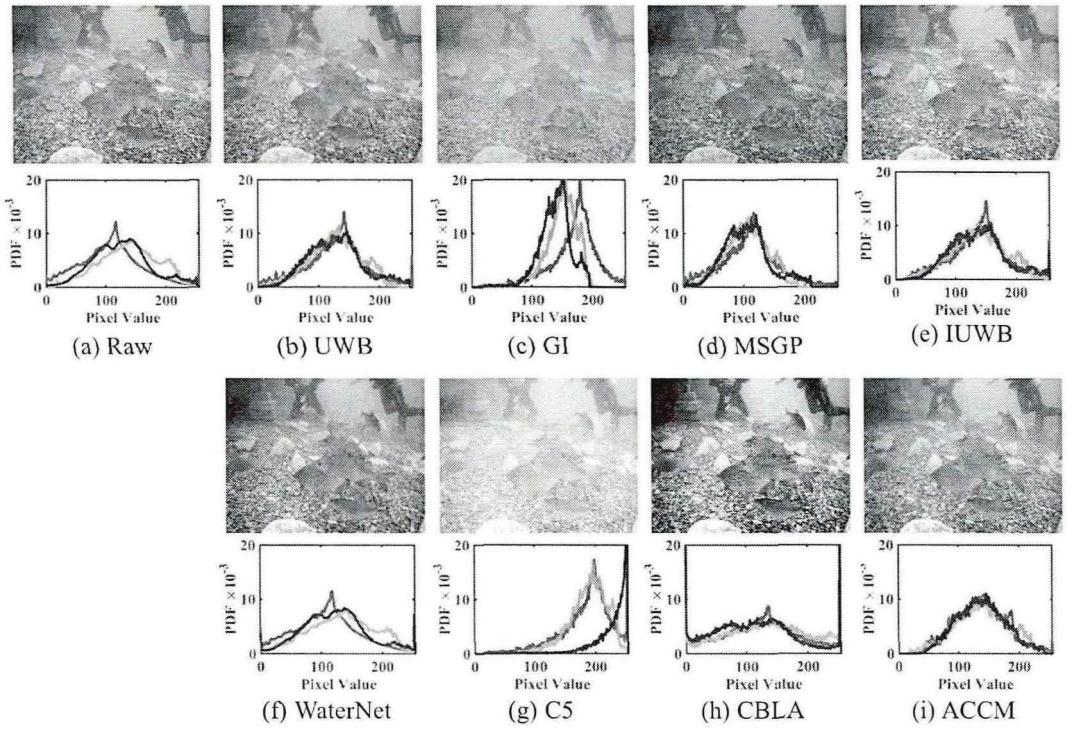

图 3.5 浅滩非均匀退化场景颜色校正结果的视觉对比图

Fig. 3.5 Visual of color correction results in shallow non-uniformly degraded scenes

中国知网 https://www.cnki.net

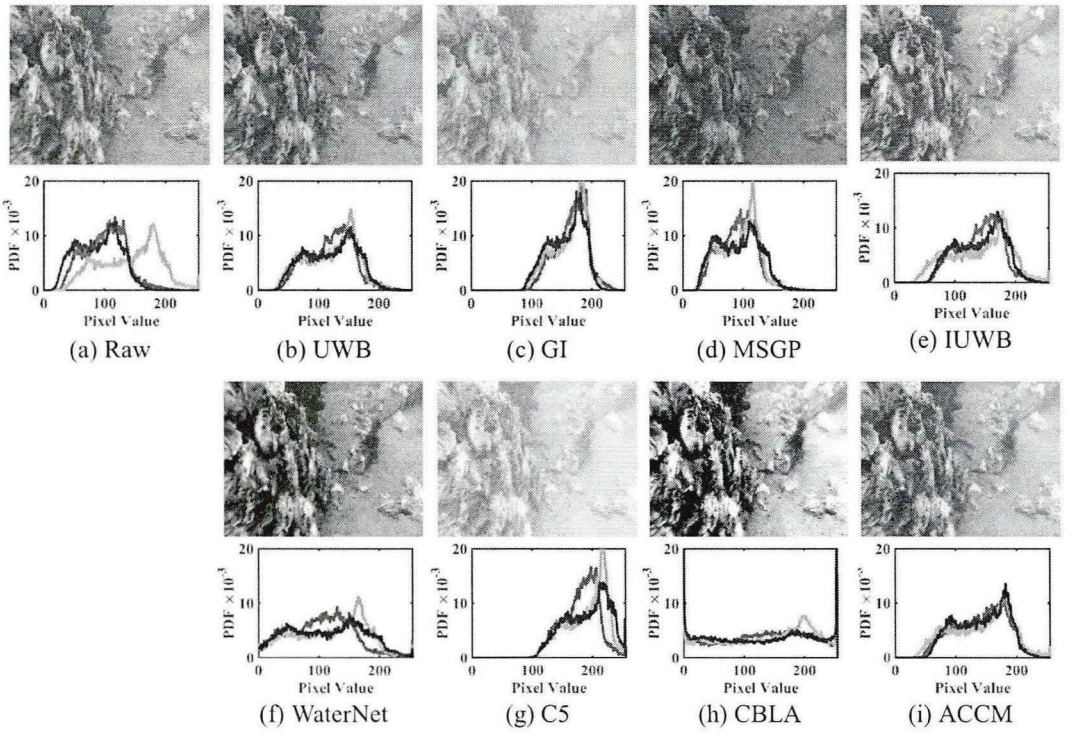

图 3.6 UPRC 数据集真实水下图像颜色校正结果的视觉对比图

Fig. 3.6 Visual of color correction results for real underwater images in UPRC dataset

3.5.2 定量质量评价

为进行定量评估，采用三种指标展示 ACCM 方法的有效性，其中包括 K[143]色彩校正指标，用来评估色彩校正结果。K 值越小，表示色偏越小，色彩恢复越接近真实。表 3.3 展示指标 K 的平均值。本章选择 UIEB 的 Test 数据集、UPRC[140]中 UCCS 的 Green、Blue_Green、Green 三种不同水下环境子数据集、MABLs[166]、UFO120[141]和 U45[156]数据集进行计算，从表 3.3 中可以看出，ACCM 方法的 K 值最小，表明 ACCM 在色偏控制方面表现最佳，相比其他色彩校正可以更好地恢复图像色彩，尤其是在背景区域的色偏问题上具有显著优势。

定量评估结果充分验证ACCM方法在水下图像色彩校正和清晰化处理中的有效性，在不同水下场景中（如均匀退化和非均匀退化），ACCM 均表现出较好的色彩恢复能力，尤其在背景区域的色偏去除上有显著优势。验证 ACCM 方法在水下图像色彩校正任务中的有效性和鲁棒性，验证其在实际应用中能够更好地处理水下图像的色彩失真问题。

中国知网 https://www.cnki.net

表 3.3 不同数据集测试图像和对比方法的 K 指标对比结果

Tab. 3.3 Comparison of K metric results of test images from different datasets and comparison methods

	UIEB	Blue	Blue_Green	Green	MABLs	UFO120	U45
Raw	4.193	7.283	6.739	9.847	4.929	2.072	4.359
UWB	2.554	4.704	4.826	7.422	3.329	1.481	3.224
GI	0.897	1.064	0.834	0.905	1.083	0.935	1.069
MSGP	1.500	2.416	1.222	0.980	1.708	1.262	1.275
IUWB	0.191	0.143	0.099	0.145	0.131	0.160	0.165
WaterNet	1.004	1.369	0.560	0.496	0.820	0.851	0.814
C5	2.093	2.471	1.158	2.935	2.262	0.990	2.550
CBLA	0.544	0.543	0.355	0.314	0.715	0.419	0.855
ACCM	**0.099**	**0.108**	**0.074**	**0.055**	**0.090**	**0.114**	**0.105**

3.5.3 ACCM 预处理的有效性

为验证 ACCM 在水下图像处理中的广泛适用性，本节将 ACCM 作为预处理方法，结合现有的先进经典的水下图像复原方法和清晰化方法进行测试。实验采用 UIEB[77]和 UPRC 数据集中的水下图像，并评估不同方法组合的效果，水下图像复原方法和清晰化方法包括本节将所提出的 ACCM 方法用作经典的水下图像清晰化方法的预处理方法，如 SDCP[144]、DIRS[145]、TSP[48]和 BRI[46]。结果如图 3.7、图 3.8、图 3.9 所示，从左到右为：原始水下退化图像、SDCP[144]、ACCM+SDCP、DIRS[145]、ACCM+DIRS、TSP[48]、ACCM+TSP、BRIE[46]和 ACCM+BRIE。上述组合方法从多个角度评估所提出的 ACCM 作为预处理方法的效果，特别是在色彩恢复和图像清晰化方面的表现。

图 3.7、图 3.8、图 3.9 展示的原始水下图像受传输介质散射效应的影响，导致图像能见度较低且色彩严重失真。实验结果表明，所有方法在视觉效果的增强方面都有明显的改善。然而，部分图像清晰化方法仍然存在色彩恢复问题，具体表现为：SDCP 方法在图 3.7 和图 3.8 的前景区域引入错误的红色偏色，而通过使用 ACCM 作为预处理方法，可以有效去除前景区域的色偏（见图 3.7）。DIRS 方法主要在前景区域引入黄色偏色，并导致图像过曝，然而通过 ACCM 预处理，可以有效减轻过曝光现象，并确保色彩恢复的准确性。TSP 方法在前景区域依然存在一定的色偏，在图 3.9 中整体呈现红色偏色，ACCM 可以有效去除 TSP 中的红色偏色。BRIE 方法在图 3.7 中引入黄色偏差，并且背景颜色不均匀，通过 ACCM 预处理，可以有效去除前景区域的黄色失真，并改善背景区域的色彩均衡性。

中国知网 https://www.cnki.net

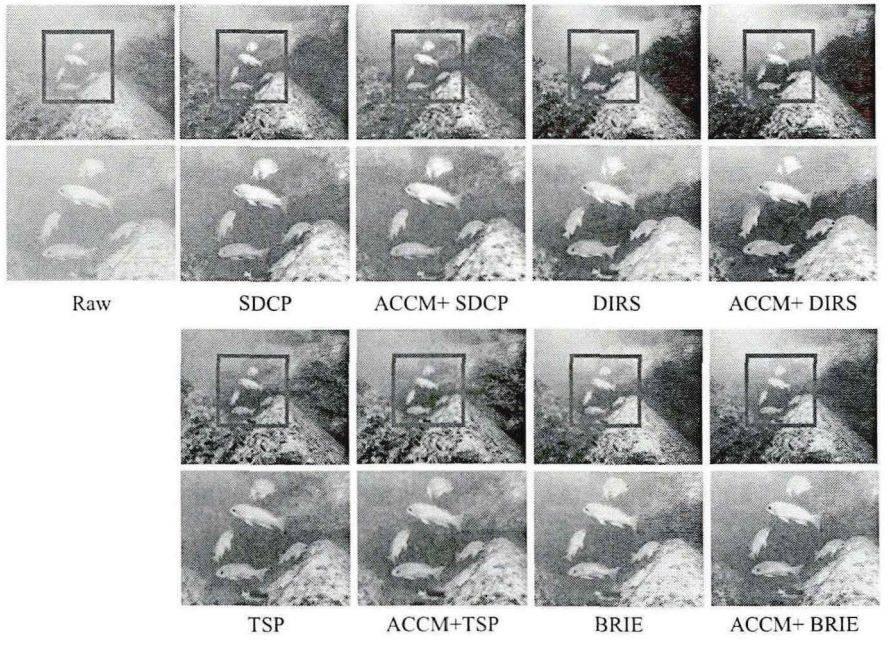

图 3.7 绿色场景不同水下图像清晰化方法结合 ACCM 预处理的视觉对比结果

Fig. 3.7 Visual comparison results of different underwater image clarification methods with ACCM preprocessing in the green scene

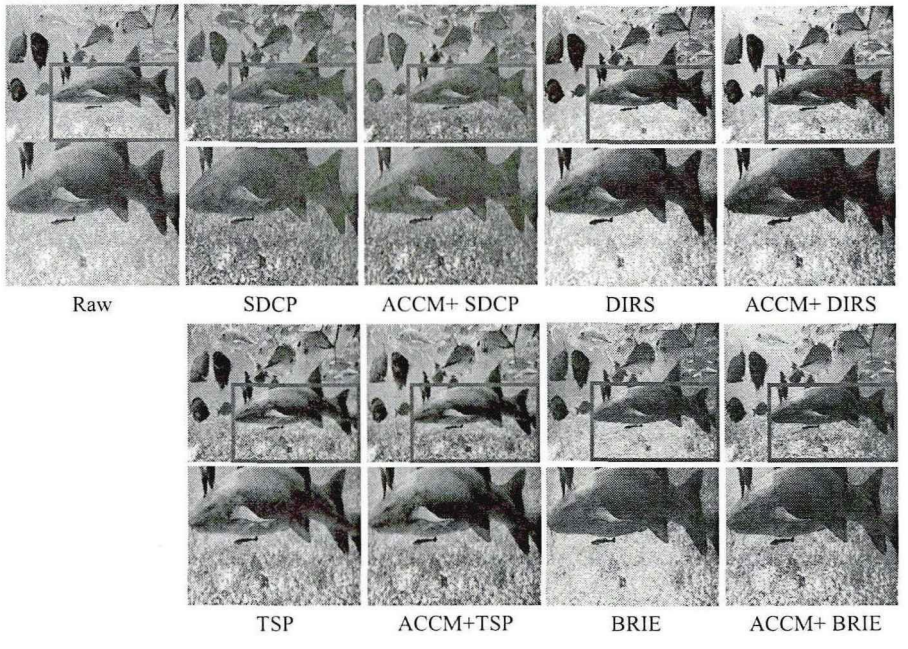

图 3.8 蓝色场景不同水下图像清晰化方法结合 ACCM 预处理的视觉对比结果

Fig. 3.8 Visual comparison results of different underwater image clarification methods with ACCM preprocessing in the blue scene

中国知网 https://www.cnki.net

通过图 3.7 到图 3.9 可以看出，先使用 ACCM 进行预处理，然后使用 SDCP、DIRS 等方法可以有效的处理水下图像清晰化问题。ACCM 方法通过像素级的颜色恢复操作，避免由于全局颜色校正导致的前景过度恢复和后景场景的恢复不足问题。

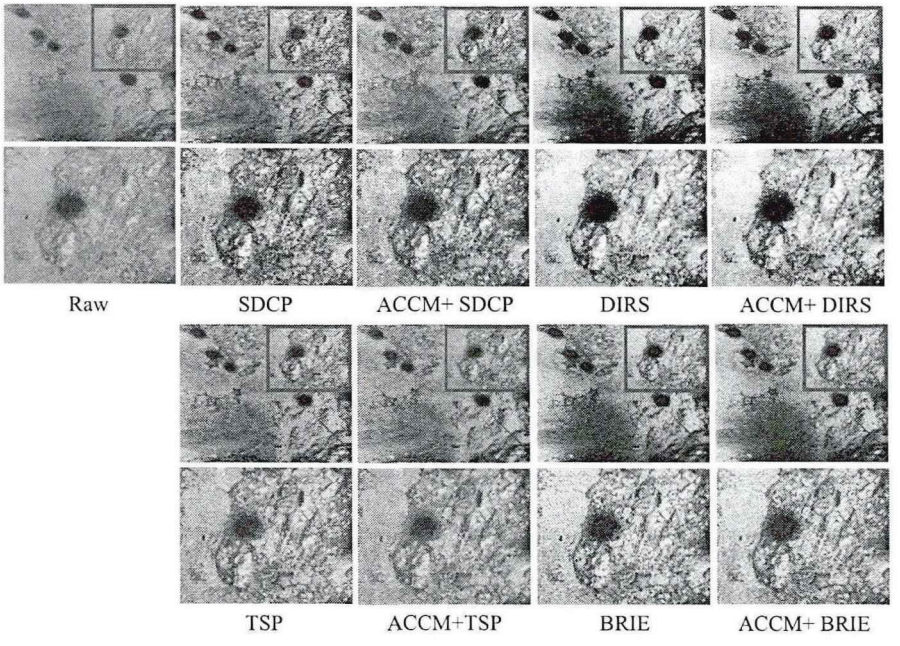

图 3.9 UPRC 不同水下图像清晰化方法结合 ACCM 预处理的视觉对比结果

Fig. 3.9 Visual comparison results of different underwater image clarification methods with ACCM preprocessing on the UPRC dataset

本节实验结果表明，ACCM 方法在水下图像处理中具有广泛的应用前景，不仅能够实现高质量的色彩恢复，还可以作为清晰化方法的预处理策略，提升水下图像去雾、目标检测、语义分割等水下视觉任务的性能，为未来的水下计算机视觉研究提供新的思路和解决方案。

3.6 本章小结

本章提出基于光衰减表征的水下图像自适应颜色校正方法。该方法基于对水下图像成像机理的深入分析，针对不同深度区域设计差异化的颜色补偿增益，以适应图像中由于光衰减变化所造成的局部色偏。在此基础上，分别对前景和背景区域进行针对性优化，有效去除水下图像中的色彩失真，恢复更为自然、真实的图像色彩。实验结果表明，该方法在色彩校正效果方面显著优于现有主流色彩恢复技术，尤其在处理具有非均匀色彩

中国知网 https://www.cnki.net

退化的水下图像时，能够更有效地消除背景区域的色偏，并避免前景区域的过度补偿，确保色彩过渡的自然性与图像细节的完整性。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

4 基于内监督协同多尺度表征的水下图像清晰化方法

在复杂的水下环境中，光学图像的质量受溶解物质和悬浮颗粒对光吸收与散射效应的双重制约[146,147]。吸收效应导致可视距离缩短和颜色失真[148]，而散射效应显著削弱图像对比度与细节层次[149]。水下退化过程具有显著多尺度特性，不同粒径的悬浮颗粒（如浮游生物、沉积物）及湍流运动在不同空间尺度上对光传播产生差异化干扰[150,151]等方面，而微米级颗粒则在局部区域导致高频细节丢失。尽管现有深度学习方法在一定程度上改善图像恢复效果，但在跨尺度退化建模、全局上下文感知以及特征融合的鲁棒性方面仍存在显著不足，缺乏结构一致性引导的特征增强机制。

针对上述问题，本章针对基于内监督协同多尺度表征的水下图像清晰化方法（Underwater Image Clarification Method via Self-supervised Collaborative Multi-scale Representation, SCMR-Net）开展研究。该方法通过多尺度编码器-解码器框架，结合双分支内在上下文注意力机制与自适应选择性特征融合，实现跨尺度退化特征的精准建模与高效恢复。具体而言，SCMR-Net 采用四级分辨率输入捕捉光衰减与颗粒噪声的跨尺度退化模式，通过基于双分支的内在上下文注意力机制增强全局上下文感知能力，综合特征注意力通过像素与通道加权增强局部细节，分辨率引导注意力利用低分辨率特征扩展感受野，捕捉全局光照与空间依赖。分层上下文感知模块融合标准卷积与膨胀卷积的优势，提取长程空间关联特征。此外，引入自适应选择性特征融合模块，通过内在监督动态筛选多尺度特征中的有效信息，抑制噪声干扰。多阶段联合损失函数则平衡像素级误差、感知一致性及均方误差，确保细节恢复与全局结构的协同优化。

4.1 SCMR-Net 方法提出

水下图像存在从局部到全局多层次、多频率的复杂退化现象，其本质为水体颗粒密度空间分布的非均匀性与光传播路径的动态变化。现有方法难以解析不同尺度下图像退化的主导因素，缺乏对尺度间退化特征分布规律与冗余噪声干扰机制的统一建模能力。因此，亟需研究多尺度图像退化的形成机理与结构特征跨尺度一致性的表达方式，以构建具备自适应信息筛选能力的增强模型。

本章针对基于内监督协同多尺度表征的水下图像清晰化方法（SCMR-Net）开展研究，SCMR-Net 的网络架构图如图 4.1 所示。为建模图像场景的尺度相关特征，基于内监督协同多尺度表征的水下图像清晰化方法构建多尺度编码器-解码器框架充分提取不同尺度上的表征信息。通过四个阶段引入多尺度低分辨率图像表征空间。所提的多尺度编码器建模低分辨率表征空间关键信息，另一方面基于不同尺度的输入图像提取多尺度

中国知网 https://www.cnki.net

场景特征，充分融合图像场景的全局上下文信息与局部细节特征，为后续处理阶段的建模与优化提供稳定而丰富的特征基础。

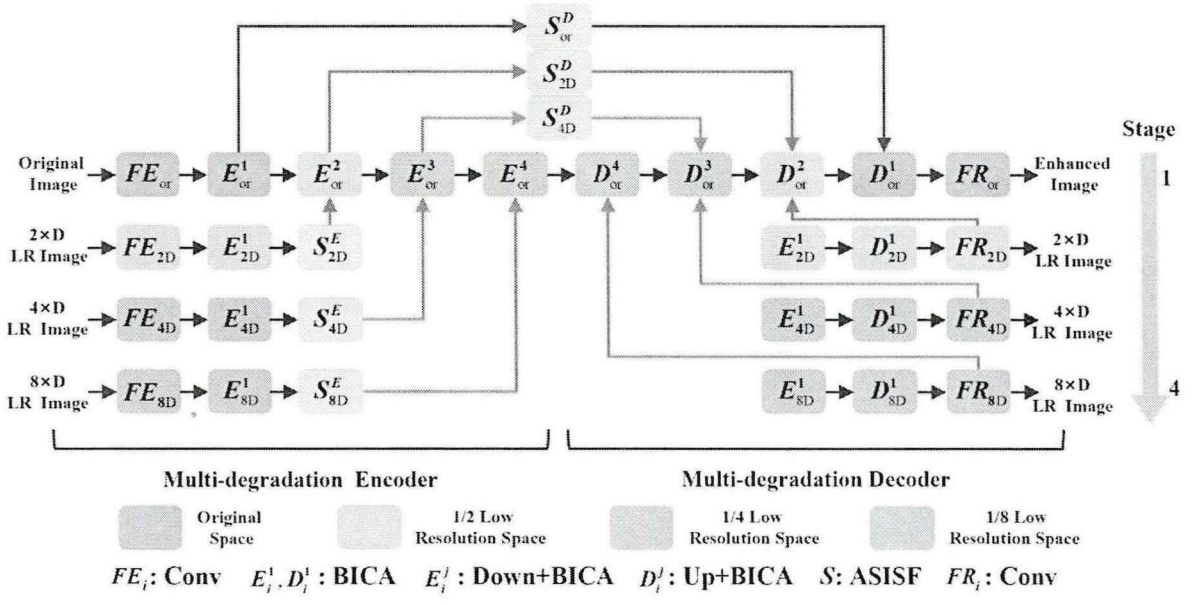

图 4.1 基于内监督协同多尺度表征的水下图像清晰化网络架构图

Fig. 4.1 Framework diagram of underwater image clarification network via self-supervised collaborative multi-scale representation

为增强特征细节表达，编解码器中提出基于双分支的内在上下文注意力机制（Bifocal Intrinsic-Context Attention, BICA），融合全局与局部特征信息。该机制使用综合特征注意力方法提取图像特征，并结合分辨率引导的监督机制，提升细节增强效果，保持较高的计算效率，提取图像场景表征信息。

多尺度解码器在设计上与其编码器部分对应，解码器不仅融合来自编码器的残差信息，还引入场景信息以捕捉输入图像中的多尺度场景细节退化特征，为避免场景叠加导致的信息冗余与特征表达混淆的问题，提出自适应选择性内在监督特征模块（Adaptive Selective Intrinsic Supervision Feature Method, ASISF）。该模块在解码过程中对低分辨率特征进行监督与选择性传播，自适应调整其权重，有效保留与恢复任务最相关的特征信息，抑制由于多尺度信息叠加引起的模糊干扰，提升多尺度信息融合的有效性，增强清晰化结果的结构稳定性与细节保真度。

通过四阶段的多尺度编解码器设计、基于双分支的内在上下文注意力机制和自适应选择性内在监督特征方法的协同设计，SCMR-Net 能够有效应对不同尺度和类型的图像退化，提升水下图像的清晰度与细节增强能力，在复杂退化条件下展现出优异的清晰化

中国知网 https://www.cnki.net

性能。SCMR-Net 设计面向图像清晰化网络的多阶段损失函数，通过约束和优化多个尺度的表征信息和清晰化过程，有效地利用不同尺度的场景恢复信息，提高场景细节和结构的恢复效果，避免某一特定尺度特征所导致的过度依赖问题，从而使 SCMR-Net 在多种水下场景与退化条件下展现出较强的泛化能力与适应性能。

与现有单一尺度处理方法不同，SCMR-Net 基于多尺度联合优化图像场景细节，通过多低分辨率表征空间引入多场景细节信息，实现更加全面的特征恢复与增强。SCMR-Net 不仅提升图像的整体清晰度与结构还原能力，增强在不同尺度退化场景下的适应性与鲁棒性。

4.2 基于双分支的内在上下文注意力方法设计

基于双分支的内在上下文注意力方法的架构图（Bifocal Intrinsic-Context Attention Module, BICA）如图 4.2 所示，包含细节分支和上下文关系分支。细节分支旨在建模空间维度信息，包括综合特征注意力模块（Comprehensive Feature Attention Module, CFA）和分辨率引导的内在注意力模块（Resolution-Guided Intrinsic Attention Module, ReGIA）。

综合特征注意力模块使用空间注意力和通道注意力基于通道维度和空间维度提取特征，引导网络关注场景细节区域和语义特征。保证方法效率，提取更丰富和感受野更大的表征信息，设计分辨率引导的内在注意力模块，基于低分辨率空间内在监督，扩大表征提取的感受野，有效捕捉多尺度场景细节。

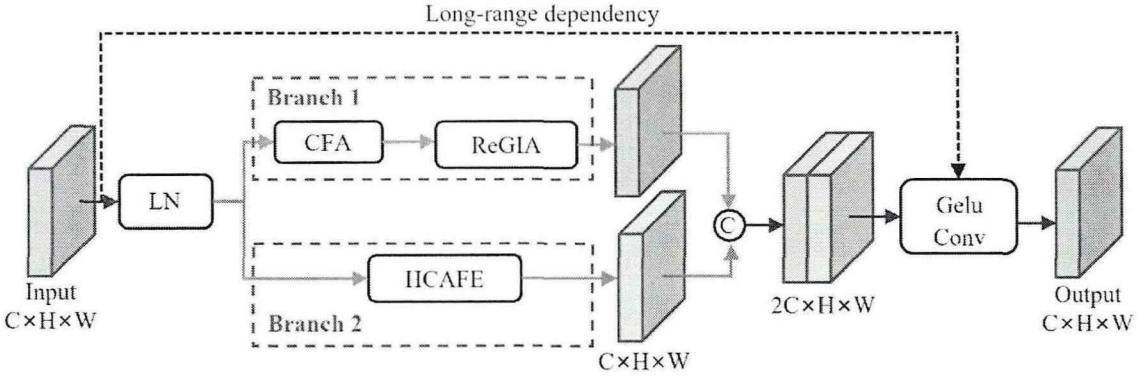

图 4.2 基于双分支的内在上下文注意力机制架构图

Fig. 4.2 Architecture diagram of bifocal intrinsic-context attention

在上下文关系分支中，设计分层上下文感知特征提取模块（Hierarchical Context-Aware Feature Extraction Module, HCAFE），采用分层特征提取结构，结合膨胀卷积有效扩大感受野，在不增加参数量的情况下捕获多尺度上下文表征，增强网络对稀疏区域、

中国知网 https://www.cnki.net

远距离像素依赖的感知能力。在处理水下图像的结构模糊与边界不清等问题时，更好地保持场景一致性和语义完整性。

4.2.1 综合特征注意力方法

综合特征注意力方法通过像素注意力（Pixel Attention, PA）和通道注意力（Channel Attention, CA）两个子方法来实现水下图像特征的增强和有效提取。综合特征注意力模块如图 4.3 所示。

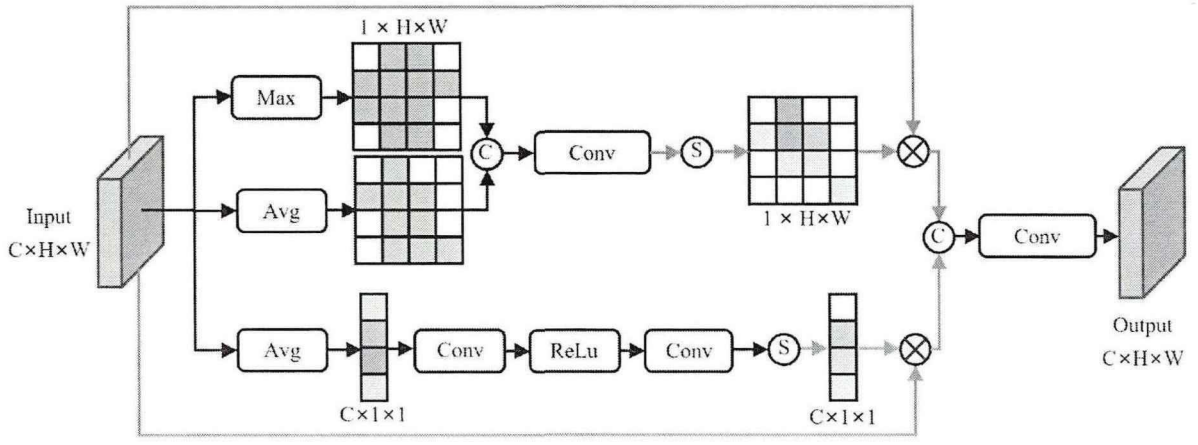

图 4.3 综合特征注意力模块架构图

Fig. 4.3 Architecture diagram of comprehensive feature attention

像素注意力主要关注像素级别的特征关系，通过捕捉特征中像素之间的相互依赖表征关系，提升基于内监督协同多尺度表征引导网络的场景细节恢复能力。像素注意力方法通过计算尺寸为$1\times H\times W$ 的权重矩阵$W_p \in \mathbb{R}^{1\times H\times W}$来实现像素之间的关系建模。具体公式如下所示：

$$W_p = \sigma(\text{Conv}(\text{Concat}(\text{Avg}(\text{LN}(F)),\text{Max}(\text{LN}(F))))) \tag{4.1}$$

其中，$F \in \mathbb{R}^{C\times H\times W}$表示输入特征，Avg(.)表示平均池化操作，Max(.)表示最大池化操作，Concat 表示在通道维度上拼接操作，$\text{Concat}(\text{Avg}(\text{LN}(F)),\text{Max}(\text{LN}(F))) \in \mathbb{R}^{2C\times H\times W}$，Conv 表示卷积操作，$\sigma(.)$表示 Sigmoid 函数：

$$\sigma(x) = \frac{1}{1+e^{-x}} \tag{4.2}$$

通过计算像素注意力权重增强输入特征：

中国知网 https://www.cnki.net

$$F_p = W_p \times F \tag{4.3}$$

其中，×表示点对点相乘，F_p表示经过像素注意力机制增强后的特征。

通道注意力模块强调通道间的关系和依赖性，捕捉通道间的相互联系，具体公式如下：

$$W_c = \sigma(\text{Conv}(\text{GeLu}(\text{Conv}(\text{Avg}(F))))) \tag{4.4}$$

其中，Avg(.)表示平均池化，$W_c \in \mathbb{R}^{C\times 1\times 1}$是通道的权重。$W_c$的作用是对输入特征图的各个通道进行加权，从而突出重要通道并抑制不相关的通道信息：

$$F_C = W_C \times F \tag{4.5}$$

通过通道权重矩阵W_C对输入特征图F进行加权，高相关性的通道分配较高的权重，抑制低相关性的通道，从而确保网络能够专注于关键特征抑制无关信息，有效地提升网络对通道内特征的敏感性，帮助模型在图像清晰化过程中准确捕捉重要的通道特征，增强图像清晰化效果。

在通道注意力和像素注意力获得各自的加权特征后，通过结合这两者的结果，进行特征融合操作，以便获得更全面、更综合的特征表示：

$$F_{CFA} = \text{Conv}(\text{Concat}(F_P, F_C)) \tag{4.6}$$

基于通道注意力和像素注意力的输出特征图进行拼接操作，结合两种不同注意力机制所提取的关键信息，确保建模通道之间的依赖关系及像素之间的细节特性。通过卷积操作（Conv）增强融合后的特征图，保持空间结构的完整性。

综合特征注意力模块通过基于像素注意力和通道注意力的特征融合，结合拼接和卷积操作，模型能够获得更为综合和精准的特征表示，不仅提升特征的表达能力，还增强网络对关键特征的关注，在复杂的水下图像清晰化任务中能够取得更优的性能。

4.2.2 分辨率引导的内在注意力方法

水下图像局部细节优化受到相邻像素上下文细节的显著影响。然而，为控制网络复杂度，现有方法通常使用 3×3 尺寸卷积核进行高效特征提取。尽管 3×3 尺寸卷积核有较高的计算效率，但较小的感受野限制网络捕捉广泛上下文细节的能力。为解决这一局限性并扩展感受野，本章提出分辨率引导的内在注意力模块（ReGIA），ReGIA 的架构图如图 4.4 所示。

ReGIA 通过引入低分辨率特征来扩大原分辨率分支的感受野，公式如下所示：

中国知网 https://www.cnki.net

$$F_{\mathrm{Re}} = \sigma(\mathrm{Conv}(\mathrm{up}(\mathrm{Conv}(\mathrm{Down}(F_{\mathrm{CFA}}))))) \times F_{\mathrm{CFA}} \tag{4.7}$$

其中 Down 表示下采样操作，Conv 为卷积核为 3 的卷积操作，Up 表示上采样操作，σ 表示 Sigmiod。

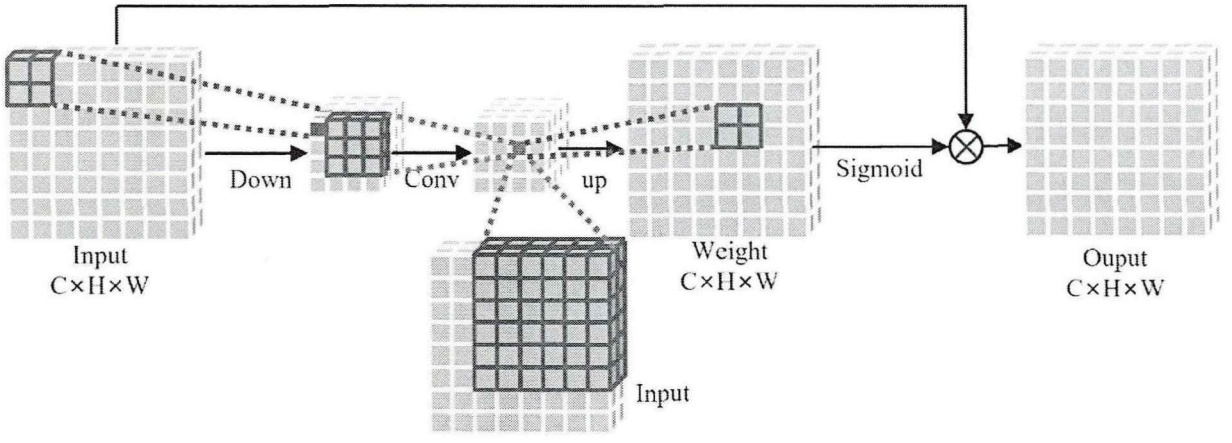

图 4.4 分辨率引导的内在注意力模块架构图

Fig. 4.4 Architecture diagram of resolution-guided intrinsic attention module

在水下图像进行优化的阶段，为有效捕捉更为广泛的上下文信息与长期依赖关系，通过 Down 操作进行下采样，进而降低输入图像的分辨率，得到低分辨率的特征图，借助对低分辨率特征图做卷积操作，对比直接对原始分辨率特征图处理而言，使用经下采样处理的特征图进行卷积可获取更大范围的上下文信息，协助网络领会图像里的全局信息，提升其对长距离信息的依赖性。

借助上采样操作将卷积后的低分辨率特征图还原到和输入特征一致的空间分辨率，既恢复图像的细节数据，保留由低分辨率图像捕获的广泛上下文信息，使用 Sigmoid 函数对经过上采样的特征图做归一化处理，将其作为权重矩阵，保证生成的特征图权重矩阵的值处在 0 到 1 范围，用于融合初始的高分辨率特征图，保证在保留局部细节之际，加入全局上下文内容，该融合过程对在增强图像质量时有效整合局部与全局特征信息有帮助。

分辨率引导的内在注意力模块的核心想法是借助低分辨率潜在空间学习特征权重数据，并利用更大范围的感受野来建模图像里的上下文细节，采用扩展卷积核的感受空间，分辨率引导的内在注意力模块可让网络不仅增强原始图像表征空间特征的相关性，还能在更大的上下文感受野中建模更丰富的特征。

中国知网 https://www.cnki.net

4.2.3 分层上下文感知特征提取方法

有效建模水下图像中的空间上下文关系对于提升清晰化质量具有重要意义，能够更准确地捕捉结构特征与语义线索，增强图像的可解释性与感知一致性。为建模图像各个区域的空间依赖关系，引入分层上下文感知特征提取模块，直接在原始特征空间里面进行相关操作，采用不同感受野对图像表示特征进行提取。

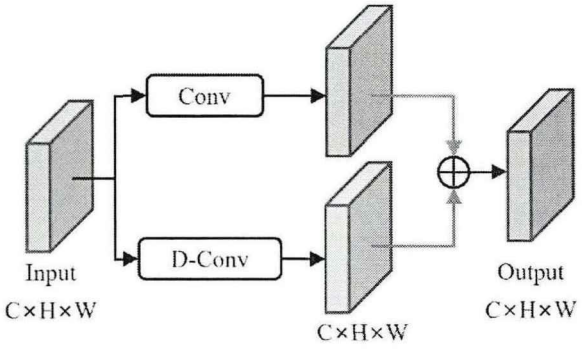

图 4.5 分层上下文感知特征提取模块架构图

Fig. 4.5 Architecture diagram of hierarchical context-aware feature extraction module

分层上下文感知特征提取模块级联使用卷积与膨胀卷积，有效拓展感受野去提取上下文信息。膨胀卷积是在卷积核的各个部分之间设置膨胀因子，增大感受野的覆盖范围。通过膨胀卷积，分层上下文感知特征提取模块可在原始特征空间里获取长距离上下文特征信息，架构图如图 4.5 所示。

分层上下文感知特征提取模块公式所示：

$$F_H = \text{Conv}(\text{Conv}(F) + \text{D-Conv}(F)) \tag{4.8}$$

其中 Conv(.)表示标准卷积，D-Conv(.)为膨胀卷积，$F \in \mathbb{R}^{C\times H\times W}$ 表示输入特征，$F_H \in \mathbb{R}^{C\times H\times W}$ 表示增强后的特征。

分支一（综合特征注意力模块与分辨率引导的内在注意力模块）以及分支二（分层上下文感知特征提取模块）借助各自结构和功能达成互补，共同提升图像清晰化效果，分支一基于像素注意力机制和通道注意力机制在空间、通道维度分别增强特征信息。采用低分辨率特征图引导的注意力机制，提升 SCMR-Net 对全局上下文信息的建模能力，而分辨率引导的内在注意力模块借助不同分辨率特征图之间的融合，在更大感受野之下提取全局信息，增强对于水下图像的复杂环境感知力。分支一的主要任务是对全局信息进行引导以及综合上下文，保证图像重建过程中细节质量与结构完整。

中国知网 https://www.cnki.net

分支二（分层上下文感知特征提取模块）直接在原始特征空间，采用把标准卷积和膨胀卷积结合起来的形式来提取更广泛的上下文特征，膨胀卷积采用在卷积核之间引入空洞的方式，让特征提取过程可覆盖更大范围的像素空间，由此在不增加计算量的前提下获取更多的上下文信息。

4.3 自适应选择性内在监督特征方法设计

将低分辨率编码器和解码器提取的特征信息融入原始分辨率分支时，应避免无关表征信息对于图像重建的干扰。本节提出自适应选择性内在监督特征方法，用于约束低分辨率表征空间的特征传递，架构图如图 4.6 所示。自适应选择性内在监督特征将低分辨率表征空间的特征特征选择性融合到高分辨率表征，对图像特征进行加权融合，在保留全局上下文信息的时候，切实抑制噪声与冗余信息的干扰。

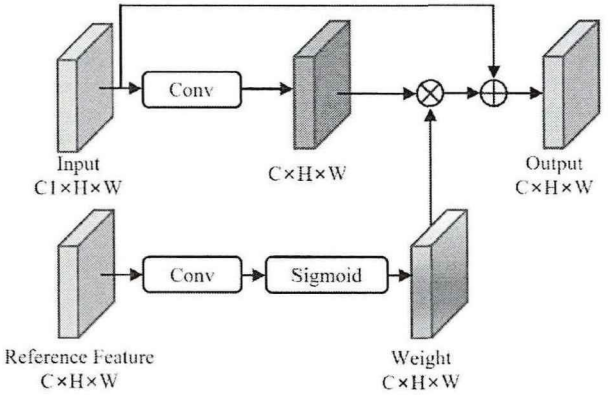

图 4.6 自适应选择性内在监督特征方法架构图

Fig. 4.6 Architecture diagram of adaptive selective intrinsic supervision feature method

自适应选择性内在监督特征模块结合低分辨率与高分辨率表征空间的特征，通过内在监督策略增强对退化特征的建模能力。通过设计的自适应加权机制，有效筛选与图像清晰化任务高度相关的信息，例如场景物体信息等，抑制噪声、模糊等干扰因素，从而提升清晰化的准确性与效率。

在水下图像中强噪声与复杂失真条件下，自适应选择性内在监督特征方法能够引导网络关注于最具判别性的场景特征区域，动态识别关键特征并进行有效约束网络，在多尺度、复杂退化环境中依然保持对有效信息的准确提取。通过上述选择性引导，自适应选择性内在监督特征方法可以显著增强网络对特征冗余的抑制能力，实现更精细、稳定的图像清晰化效果，为水下图像清晰化任务以及后续高级视觉任务提供更强的鲁棒性与泛化能力。

中国知网 https://www.cnki.net

4.4 面向图像清晰化网络的多阶段损失函数设计

在水下图像清晰化中，图像的退化通常表现为多尺度的退化模式。因此，本节设计多阶段损失函数，约束不同尺度的编解码器。

4.4.1 平均绝对误差损失函数

平均绝对误差损失函数 L_1 通过计算预测图像与真实图像之间的绝对差异来衡量图像清晰化中的误差[153]。公式如下所示：

$$L_1 = \sum_{j=1}^{W}\sum_{i=1}^{H}|J(i,j)-\hat{J}(i,j)| \tag{4.9}$$

其中，J 表示真实图像，$\hat{J}$ 表示基于内监督协同多尺度表征引导的水下图像清晰化模型预测值，(i,j) 表示像素位置，H 和 W 分别为真实图像 J 的高和宽。

4.4.2 感知损失函数

感知损失 L_{pre} 通过计算预测图像和经过 VGGNet[154]处理后的特征图之间的差异，用于优化预测图像的高级语义特征，公式如下所示：

$$L_{\text{pre}} = \sum_{j=1}^{W1}\sum_{i=1}^{H1}\left\|\phi(J(i,j))_L-\phi(\hat{J}(i,j))_L\right\|_2^2 \tag{4.10}$$

其中，ϕ 表示 VGGNet 的特征提取函数，$\phi(J)_L$ 和 $\phi(\hat{J})_L$ 分别表示真实图像和预测图像在第 L 层的特征图，在本章中 $L=16$，$W1$ 和 $H1$ 为第 L 层特征的宽和高。

4.4.3 均方误差损失函数

均方误差损失函数 L_{mse} 则通过计算预测图像和真实图像之间的均方误差优化像素级恢复[155]。公式如下所示：

$$L_{\text{mse}} = \frac{1}{H\times W}\sum_{j=1}^{W}\sum_{i=1}^{H}(J(i,j)-\hat{J}(i,j))^2 \tag{4.11}$$

4.4.4 综合损失函数

为综合优化这些目标，每个阶段的损失函数 L^k 结合上述三个损失函数。在每个编解码器阶段，损失函数为：

$$L^k = L_1^k + 0.2\times L_{\text{pre}}^k + L_{\text{mse}}^k \tag{4.12}$$

中国知网 https://www.cnki.net

其中，L_1^k、L_{pre}^k和L_{mse}^k分别是第k阶段的L_1、L_{pre}和L_{mse}损失。

SCMR-Net的总损失函数通过对所有阶段的损失进行求和得到，以确保在四个阶段的训练过程中，网络能够综合考虑各类损失函数的贡献，从而实现多尺度、多层次的图像清晰化优化。

$$L=\sum_{k=1}^{4}L^k \tag{4.13}$$

通过多阶段损失函数在多个分辨率的场景中分别优化图像清晰化的各个阶段。每个阶段的损失函数专注于不同尺度下的特征学习，使得网络能够更加精确地捕捉到水下图像中的多层次退化模式。具体而言，在低分辨率图像的处理阶段，损失函数能够有效引导网络学习建模全局结构信息，而在高分辨率图像的处理阶段，损失函数则专注于细节和局部特征的恢复。有效约束保持各个阶段的特征一致性，约束各个分辨率阶段的图像的清晰化。

此外，多阶段损失函数的使用可以有效缓解由过度依赖某一特定尺度特征所导致的过拟合问题，使得增强方法能够在面对不同水下环境和退化条件时，仍保持较好的适应性。这种多尺度的损失优化策略，使得图像清晰化方法在面对复杂的水下场景时，能够实现更加全面和鲁棒性的效果，尤其在细节恢复和全局结构重建方面，均能够获得较好的平衡。

4.5 SCMR-Net算法设计

基于内在监督协同多尺度表征引导的水下图像清晰化方法 SCMR-Net 的模块图如图4.7所示，核心流程分为基于多尺度的编码器设计、基于双分支的内在上下文注意力的特征增强、自适应选择性特征融合、多阶段解码重建及多阶段联合损失优化五个组成部分。

1) 基于多尺度的编码器：输入退化水下图像通过四级下采样生成多分辨率输入表征空间（包括原始分辨率），编码器分别提取对应尺度的特征。低分辨率输入表征空间建模大尺度光散射信息，高分辨率输入表征空间则更聚焦于水下图像场景细节与纹理恢复。

2) 基于双分支的内在上下文注意力机制（BICA）：每个尺度特征通过双分支机制优化。综合特征注意力分支（CFA）结合像素级与通道级注意力，分别增强空间细节与抑制冗余通道；分辨率引导注意力分支（ReGIA）通过低分辨率特征扩展感受野，捕捉

中国知网 https://www.cnki.net

全局上下文依赖；分层上下文感知分支（HCAFE）利用标准卷积与膨胀卷积融合，提取跨尺度空间关联特征。双分支输出融合后生成兼具局部敏感性与全局一致性的增强特征。

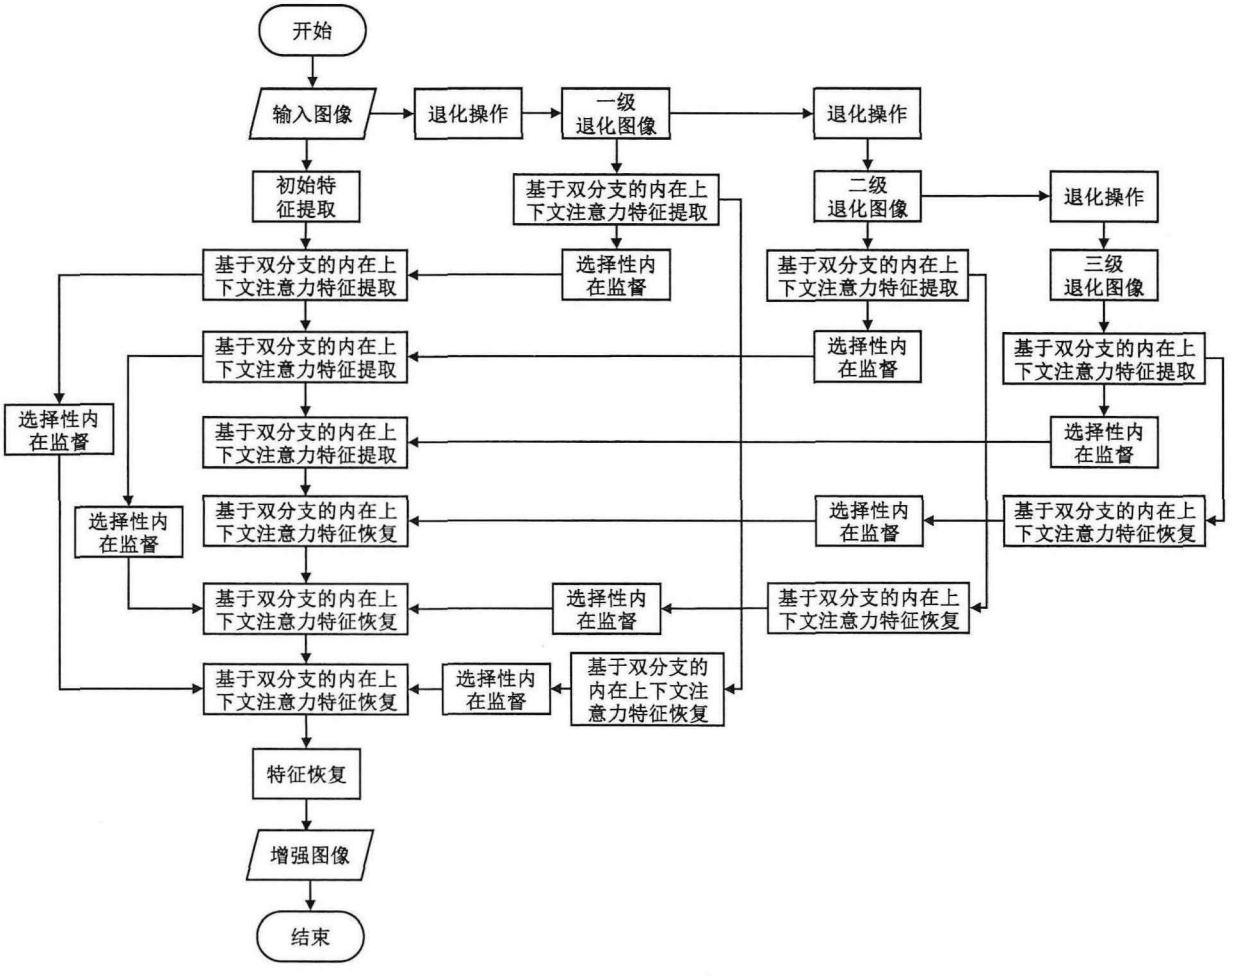

图 4.7 SCMR-Net 方法架构图

Fig. 4.7 The framework of the SCMR-Net algorithm

3) 自适应选择性内在监督特征（ASISF）：引入内在监督机制，动态筛选多尺度特征中有效信息。通过对比低分辨率的特征与高分辨率参考特征，自适应调节特征传播权重，抑制噪声干扰并保留关键退化模式，确保跨尺度融合过程中特征的相关性与鲁棒性。

4) 多阶段解码与重建：解码器通过四级上采样逐步恢复图像分辨率，每级融合当前尺度特征与上一级输出，利用跳跃连接传递残差信息，实现从粗到细的渐进式重建。保持最终输出的颜色一致性，显著提升细节清晰度与结构完整性。

5) 多尺度联合损失优化：设计多退化损失函数，联合优化各尺度输出。L1 损失约束像素级误差，抑制伪影；感知损失基于预训练网络特征差异保持语义一致性；均方误

中国知网 https://www.cnki.net

差损失平滑细节恢复过程。多阶段损失加权求和，引导网络在不同分辨率下平衡全局结构与局部细节的恢复需求，提升复杂水下场景的适应能力。

Algorithm 4.1: SCMR-Net

Input: Degraded underwater image $I \in \mathbb{R}^{3\times H\times W}$

Output: Restored image $I_{re} \in \mathbb{R}^{3\times H\times W}$

Parameters: Multi-stage levels $K=4$

// **Step1:** Multi-scale Encoding:

$\{I_1, I_2, I_3, I_4\} \leftarrow \text{Downsample}(I, K)$ // I_1 is original resolution

for k=2 to K do: // Downsample Resolution

$F_1^k \leftarrow \text{Conv}(I_k)$

$F_{\text{down}}^k \leftarrow \text{BICA}(F_1^k)$

end for

$F_1 \leftarrow \text{Conv}(I_1)$ // Original Resolution

$F_{or}^2 \leftarrow \text{ASISF}(\text{Down}(\text{BICA}(F^1)), DF_{\text{down}}^2) + \text{Down}(\text{BICA}(F^1))$

$F_{or}^3 \leftarrow \text{ASISF}(\text{Down}(\text{BICA}(F_{or}^2)), DF_{\text{down}}^3) + \text{Down}(\text{BICA}(F_{or}^2))$

$F_{or}^4 \leftarrow \text{ASISF}(\text{Down}(\text{BICA}(F_{or}^3)), DF_{\text{down}}^4) + \text{Down}(\text{BICA}(F_{or}^3))$

// **Step2:** Multi-scale Decoding:

for k=2 to K do: // Downsample Resolution

$DF_{\text{down}}^k \leftarrow \text{BICA}(F_{\text{down}}^k)$

end for

$DF_{or}^4 \leftarrow \text{BICA}(F_{or}^4)$ // Original Resolution

$DF_{or}^3 \leftarrow \text{Up}(\text{ASISF}(DF_{or}^4, DF_{\text{down}}^4) + DF_{or}^4)$

$DF_{or}^{3,1} \leftarrow \text{ASISF}(DF_{or}^3, DF_{\text{down}}^3)$

$DF_{or}^{3,2} \leftarrow \text{ASISF}(DF_{or}^3, F_{or}^3)$

$DF_{or}^{3,3} \leftarrow DF_{or}^{3,1} + DF_{or}^{3,2} + DF_{or}^3$

$DF_{or}^2 \leftarrow \text{Up}(\text{BICA}(DF_{or}^{3,3}))$

$DF_{or}^{2,1} \leftarrow \text{ASISF}(DF_{or}^2, DF_{\text{down}}^2)$

$DF_{or}^{2,2} \leftarrow \text{ASISF}(DF_{or}^2, F_{or}^2)$

$DF_{or}^{2,3} \leftarrow DF_{or}^{2,1} + DF_{or}^{2,2} + DF_{or}^2$

$DF_{or}^1 \leftarrow \text{Up}(\text{BICA}(DF_{or}^{2,3}))$

$DF_{or}^{1,1} \leftarrow \text{ASISF}(DF_{or}^1, F^1) + DF_{or}^1$

$DF_{or} \leftarrow \text{BICA}(DF_{or}^{1,1})$

$I_{re} \leftarrow \text{Conv}(DF_{or})$

Return I_{re}

中国知网 https://www.cnki.net

本节设计的基于内监督协同多尺度表征引导的水下图像清晰化算法，如 Algorithm 4.1 所示，其中基于双分支的内在上下文注意力机制 BICA 算法见 Algorithm 4.2。

Algorithm 4.2: BICA

Input: Feature $F_1 \in \mathbb{R}^{B\times C\times H\times W}$

Output: Enhanced Feature $F_{en} \in \mathbb{R}^{B\times C\times H\times W}$

1: $F^1_{CFA} \leftarrow \text{Conv}(\text{Concat}(\text{PA}(F_1),\text{CA}(F_1)))$ // Pixel Channel Attention

2: $F^1_{ReGIA} \leftarrow \text{Up}(\text{Conv}(\text{Down}(F^1_{CFA})))\times F^1_{CFA}$ // Resolution-Guided Attention

3: $F^1_{HCAFE} \leftarrow \text{Conv}(\text{Conv}(F_1)+\text{DConv}(F_1)$ // Hierarchical Context-Aware

4: $F_{en} \leftarrow \text{Concat}(F^1_{ReGIA}, F^1_{HCAFE})$

5: Return F_{en}

通过多尺度特征建模、注意力引导的特征增强、自适应融合策略及多目标联合优化，SCMR-Net 在颜色校正、细节恢复与跨尺度鲁棒性方面显著优于现有方法，为复杂水下环境下的图像清晰化提供高效解决方案。

4.6 实验结果与分析

本节主要针对基于内监督协同多尺度表征的水下图像清晰化方法进行实验验证，首先对于本章的训练所用的数据集、实验参数进行说明，然后使用现有的先进水下图像清晰化方法与所提出的水下图像清晰化方法进行对比，从主观角度和客观指标进行分析；其次对于所提出的方法和对比方法进行效率评估；最后基于消融实验验证本章提出的图像清晰化方法各个组件的有效性。

4.6.1 实验设置说明

本节采用多个不同的水下图像数据集，具体有 UIEB[77]有参考数据集、U45[156]无参考数据集和 LSUI[157]有参考数据集，本节所用的数据集覆盖多种涉水环境下各异的退化类型。其中 UIEB[77]数据集包含 890 对图像和 60 张挑战退化水下图像。参考 Ucolor[78]的训练策略和数据集划分策略，选用 800 对水下图像作为训练集，90 张成对水下图像作为测试集，可以切实支持水下图像清晰化模型的训练及测试，U45 和 LSUI 数据集给出不同水下环境状态下的图像，验证 SCMR-Net 水下图像清晰化模型的鲁棒性与泛化性。

本章方法基于 PyTorch 框架，采用 NVIDIA Tesla V100 GPU、Intel(R) Xeon(R) Silver 4114 CPU 和 32GB 的内存开展训练，把图像随机裁剪成分辨率为 256×256 进行训练。采用 BatchSize 为 44、学习率 0.0002 的配置，使用 AdamW 进行优化，为保证 SCMR-Net 在测试的时候生成和原始图像尺寸相同的输出，采用边界填充等方式的技术，这些

中国知网 https://www.cnki.net

训练参数和数据预处理手段保证模型可有效学习水下图像里的各种退化特征，因而在图像清晰化的进程中给出高质量的清晰化结果。

4.6.2 对比实验分析

本节采用多个客观评估指标对 SCMR-Net 模型的性能进行全面评估，具体为峰值信噪比（PSNR）[122]、结构相似性指数（SSIM）[123]、均方误差（MSE）[123]、视觉相似性指数（VSI）[124]、特征相似性度量（FSIM）[125]、颜色一致性因子（CCF）[128]和水下图像质量评估指标 UIQM[126]和 UCIQE[127]。

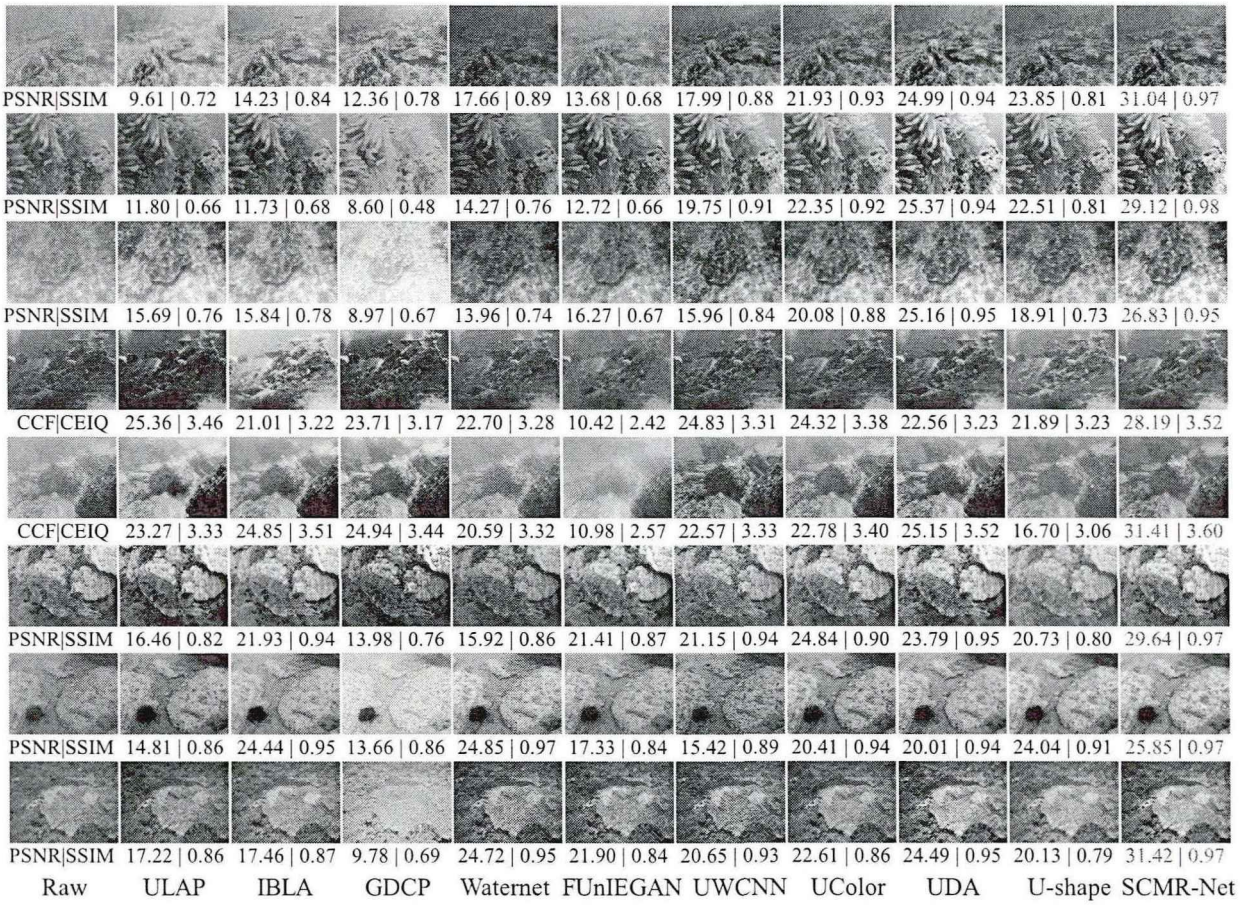

图 4.8 SCMR-Net 方法与对比方法在各种数据集的定性比较结果

Fig. 4.8 Qualitative comparison between state-of-the-art methods and the SCMR-Net on various datasets

为水下图像清晰化工作设定全面的评估体系，更全面地组合上述各项指标，本节设计综合评价指标“ALL_no”和“ALL_f”，公式如下：

中国知网 https://www.cnki.net

$$All_no = UIQM+CCF+CEIQ \tag{4.14}$$

$$All_f = PSNR\text{-}MSE+SSIM+VSI+FSSIM+FSIMc \tag{4.15}$$

其中指标ALL_no主要是无参考的综合图像指标，指标ALL_f是用于有参考图像（Ground Truth，GT）的数据集UIEB[77]。ALL_no和ALL_f指标通过将越高越好的指标的总和减去越低越好的指标来计算，从而提供一个全方位的性能评估方法。为避免颜色对评估指标的影响（例如在图4.8中ULAP方法的影响），本章在计算CCF时去除颜色分量。

实验结果如图4.8所示，SCMR-NET在视觉质量和量化性能指标上均优于其他方法。通过结合这些指标，SCMR-NET在多个数据集上展示出色的性能，能够恢复图像细节，保持图像的全局一致性和视觉自然性。尽管基于物理模型的水下图像复原方法ULAP[22]、IBLA[30]和GDCP[21]方法在特定场景下能够取得一定的复原效果，但此类方法通常依赖于较强的物理先验假设，受限于水下场景的高度多样性和复杂性，上述先验假设在实际应用中易错误估计，进而导致对物体深度或光照条件的误判。如图4.8中浅滩场景，光线的变化严重影响先验知识的准确性，限制基于复原方法在复杂场景中的泛化能力与适应性，在光照不均、悬浮物干扰或多目标重叠等复杂环境下表现不稳定。

表4.1 SCMR-Net方法与对比方法在UIEB Val数据集的全参考指标对比结果

Tab. 4.1 The SCMR-Net method and comparison methods on the full-reference metrics results of the UIEB Val dataset

	PSNR	MSE	SSIM	VSI	FSIM	FSIMc	ALL_f
ULAP	15.913	0.174	0.745	0.947	0.915	0.878	19.224
IBLA	17.988	0.143	0.805	0.958	0.928	0.899	21.435
GDCP	13.386	0.228	0.747	0.943	0.901	0.865	16.614
WaterNet	17.349	0.144	0.813	0.966	0.908	0.899	20.791
FUnIEGAN	17.114	0.150	0.701	0.941	0.891	0.858	20.355
UWCNN	17.985	0.134	0.844	0.966	0.923	0.903	21.487
UColor	20.962	0.097	0.863	<u>0.971</u>	0.931	<u>0.920</u>	24.550
UDA	<u>21.484</u>	<u>0.096</u>	<u>0.873</u>	0.970	<u>0.932</u>	0.918	<u>25.081</u>
U-Shape	20.462	0.100	0.792	0.959	0.892	0.883	23.888
SCMR-Net	**23.710**	**0.075**	**0.922**	**0.983**	**0.967**	**0.957**	**27.464**

WaterNet[77]通过白平衡、直方图均衡化和Gamma校正生成预处理图像，并从训练数据集中学习预处理图像和原始输入图像的融合策略以实现水下图像清晰化。尽管WaterNet在一定程度上实现图像清晰化，但其性能受限于预处理方法的有效性，导致在某些极端情况下鲁棒性有限。

中国知网 https://www.cnki.net

表 4.2 SCMR-Net 方法与对比方法在 UIEB Val 数据集的无参考指标对比结果

Tab. 4.2 The SCMR-Net method and comparison methods on the no-reference metrics results of the UIEB Val dataset

	UIQM↑	UCIQE↑	CCF↑	CEIQ↑	ALL_no↑
ULAP	2.259	0.604	24.145	3.209	30.217
IBLA	2.490	0.606	23.841	3.283	30.220
GDCP	2.670	0.592	23.026	3.208	29.496
WaterNet	2.917	0.606	20.042	3.101	26.666
FUnIEGAN	3.092	0.564	20.416	3.307	27.379
UWCNN	3.011	0.554	20.360	3.090	27.015
UColor	3.049	0.591	21.827	3.209	28.676
UDA	2.897	**0.612**	**26.220**	**3.372**	**33.101**
U-Shape	**3.131**	0.576	21.966	3.235	28.908
SCMR-Net	3.015	0.607	26.012	3.369	33.003

表 4.3 SCMR-Net 方法与对比方法在 U45 数据集的无参考指标对比结果

Tab. 4.3 The SCMR-Net method and comparison methods on the no-reference metrics results of the U45 dataset

	UIQM↑	UCIQE↑	CCF↑	CEIQ↑	ALL_no↑
ULAP	2.282	0.588	22.069	3.192	28.131
IBLA	2.388	0.595	21.598	3.249	27.830
GDCP	2.275	0.597	22.736	3.191	28.799
WaterNet	2.957	0.601	20.391	3.186	27.135
FUnIEGAN	2.495	0.545	12.931	2.785	18.756
UWCNN	3.064	0.554	21.418	3.213	28.249
UColor	3.148	0.586	22.100	3.283	29.117
UDA	2.878	**0.607**	25.449	3.392	32.326
U-Shape	**3.175**	0.571	21.284	3.254	28.284
SCMR-Net	3.121	0.605	**25.489**	**3.397**	**32.612**

FUnIEGAN[158]使用生成对抗网络（GAN）来进行图像清晰化操作，尽管具备高效清晰化图像的能力，但由于其结构设计相对简化，缺乏对复杂多尺度纹理与局部细节的精细建模能力，难以应对 UIEB 数据集中多样化、非均匀的退化特性，尤其在图像细节还原与结构一致性方面存在显著不足。UColor[78]基于 GDCP 的透射图引导水下图像清晰化过程，在一定程度上提升图像的结构还原能力。然而，由于水下成像过程中场景中物

中国知网 https://www.cnki.net

体信息、局部亮度异常等因素会对透射图估计造成干扰，易导致透射图存在误判或估计偏差，进而影响图像复原效果的稳定性。

表 4.4 SCMR-Net 方法与对比方法在 LSUI 数据集的全参考指标对比结果

Tab. 4.4 The SCMR-Net method and comparison methods on the full-reference metrics results of the LSUI dataset

	PSNR	MSE	SSIM	VSI	FSIM	FSIMc	ALL_f
ULAP	17.677	0.142	0.760	0.959	0.925	0.894	21.073
IBLA	17.555	0.149	0.784	0.957	0.925	0.894	20.966
GDCP	13.284	0.229	0.710	0.935	0.886	0.850	16.436
WaterNet	19.990	0.109	0.839	0.971	0.931	0.918	23.540
FUnIEGAN	21.129	0.101	0.778	0.962	0.920	0.900	24.588
UWCNN	20.368	0.102	0.851	0.970	0.940	0.921	23.948
UColor	21.786	0.087	0.848	0.973	0.940	0.928	25.388
UDA	20.288	0.104	0.842	0.968	0.931	0.912	23.837
U-Shape	20.491	0.102	0.775	0.960	0.900	0.888	23.912
SCMR-Net	**21.984**	**0.089**	**0.870**	**0.975**	**0.948**	**0.933**	**25.621**

表 4.5 SCMR-Net 方法与对比方法在 LSUI 数据集的无参考指标对比结果

Tab. 4.5 The SCMR-Net method and comparison methods on the no-reference metrics results of the LSUI dataset

	UIQM ↑	UCIQE ↑	CCF ↑	CEIQ ↑	ALL_no ↑
ULAP	2.324	0.611	24.004	3.160	30.099
IBLA	2.567	0.616	24.135	3.282	30.600
GDCP	2.572	0.610	24.304	3.227	30.713
WaterNet	2.865	0.605	20.531	3.123	27.124
FUnIEGAN	2.895	0.585	21.484	3.195	28.159
UWCNN	2.976	0.561	21.254	3.147	27.938
UColor	2.984	0.593	22.331	3.259	29.167
UDA	2.833	**0.617**	**25.942**	**3.361**	**32.753**
U-Shape	**3.038**	0.576	21.849	3.246	28.709
SCMR-Net	2.917	0.602	24.727	3.323	31.569

UDA[159]和 U-shape[157]基于 Transformer 和 Unet 架构，可以在一定程度上增强水下图像场景信息的可视化程度，但 SCMR-Net 采用多尺度特征融合策略，可以在不同尺度

中国知网 https://www.cnki.net

场景信息的范畴内建立更有效的多尺度场景表征学习机制，在面对复杂和多样变化的水下环境时表现出更强的适应性。

表 4.1 到表 4.5 展示不同方法在 UIEB[77]、U45[156]和 LSUI[157]三个数据集的定量评估结果，涵盖六个全参考指标和四个无参考指标。经过表 4.1 和表 4.4 可以看出，SCMR-Net 方法在 UIEB 和 LSUI 数据集的全参考指标中取得最优值。

虽然在表 4.2 和表 4.5 中 SCMR-Net 方法在 UIEB 和 LSUI 数据集中的无参考指标低于 UDA[159]，但是综合全参考指标和无参考指标，SCMR-Net 仍然取得最优值，UDA[159]方法虽然在多个场景中取得清晰的结果，但是在 LSUI 数据集中表现出较低的泛化性，如图 4.8 中图像 6 和 7，UDA 方法未能正确的恢复水下图像中的绿色偏色，从而导致无参考指标中 UIQM 和 UCIQE 的数值虚高。

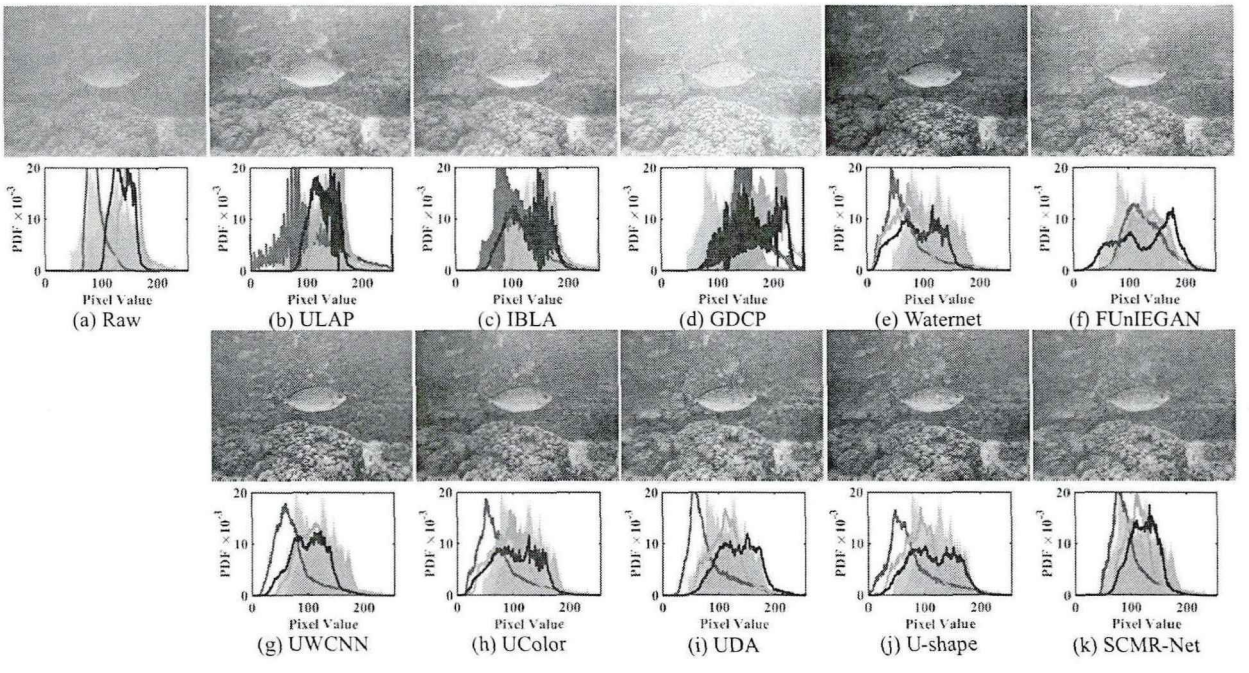

图 4.9 SCMR-Net 和对比方法在绿色场景中增强结果和 RGB 直方图对比结果

Fig. 4.9 The results and RGB histogram in green scenes of state-of-the-art methods and SCMR-Net

为验证 SCMR-Net 方法在色彩恢复和图像场景优化方面的有效性，本节在图 4.9、图 4.10、图 4.11 给出 RGB 直方图与 UIEB 数据集中真实图像的对比展示，图 4.9、图 4.10、图 4.11 分别对应绿色场景、蓝色场景、浅滩水域场景。RGB 直方图的曲线呈现出对应对比方法的结果图像 RGB 直方图，而带有填充部分的曲线则对应真实图像的 RGB 直方图。图 4.9、图 4.10、图 4.11 可直观察觉到不同方法在颜色恢复上的差别，由于

中国知网 https://www.cnki.net

SCMR-Net 采用多尺度表征提取，在还原图像颜色信息及细节方面体现出更高精准度，其 RGB 直方图跟真实图像的 RGB 直方图趋势更加相似，展现其在水下图像清晰化方面的优势。从图 4.9、图 4.10 以及图 4.11 中可观察到，SCMR-Net 在多个水下场景里实现最理想的视觉恢复效果，在细节上维持图像的全局一致性。

包括 ULAP[22]、IBLA[30]和 GDCP[21]在内的其他方法，受限于固定先验知识的设想，没有足够的灵活性去复原复杂水下环境中获取的图像，图像颜色及细节的恢复出现偏差，从图 4.9、图 4.10 以及图 4.11 观察到，ULAP[22]、IBLA[30]和 GDCP[21]所恢复图像与真实图像的 RGB 直方图差异较大，ULAP[22]通过计算 R 通道与 G 或 B 通道最大强度值之间的差异来估计水下场景深度，导致在图 4.11 中明亮的气泡部分错误恢复为红色。IBLA[30]采用基于光吸收和图像模糊的深度估计方法，较好地避免光照条件的影响，但 IBLA[30]基于图像的模糊度估计深度，导致在图 4.10 中潜水员的氧气瓶位置错误估计。

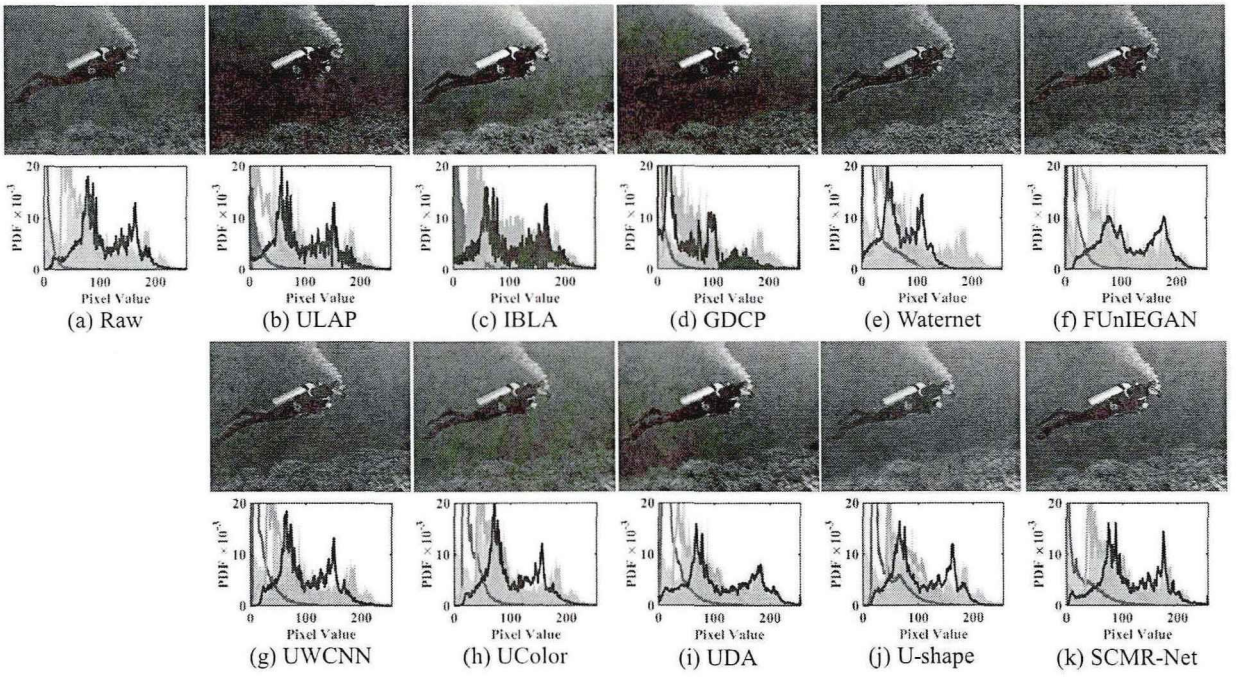

图 4.10 SCMR-Net 和对比方法在蓝色场景中增强结果和 RGB 直方图对比结果

Fig. 4.10 The results and RGB histogram in blue scenes of state-of-the-art methods and SCMR-Net

GDCP[21]通过计算图像的梯度图来识别不同区域的变化，结合颜色信息和深度图来优化水下图像的深度估计，综合考虑颜色和深度的计算，但是仍在浅滩场景图 4.11 中产生错误复原方式。WaterNet[77]、FUnIEGAN[158]和 UWCNN[95]即使在一定程度上对水下

中国知网 https://www.cnki.net

图像质量进行改善，但因为其网络架构和训练数据的局限，还是存在较为明显的结构跟颜色偏差。尤其是鉴于这些方法的设计没有充分考虑图像里场景尺度的不同，上述方法面对各类水下场景时的鲁棒性不强，虽然 WaterNet[77]在提高图像亮度和对比度方面表现佳，但是受限于白平衡、直方图增强和 Gamma 预处理方法获取的图像，在某些极端的场景下，例如图 4.10 中潜水员身体的细节错误增强导致伪影现象。

UColor[78]即便在图像恢复质量方面取得一定效果，但当恢复红色通道时，依然出现一定的误差，UColor[78]方法虽能对某些水下场景的颜色失真进行有效复原，但依旧存在对特定颜色通道恢复能力的限制，尤其是在复杂光照与颜色出现失真的情况下。上述实验结果验证 SCMR-Net 可以有效恢复水下图像的颜色，增强场景的多尺度细节，尤其是在面对复杂水下环境的时候，呈现出色的灵活性与高效性。

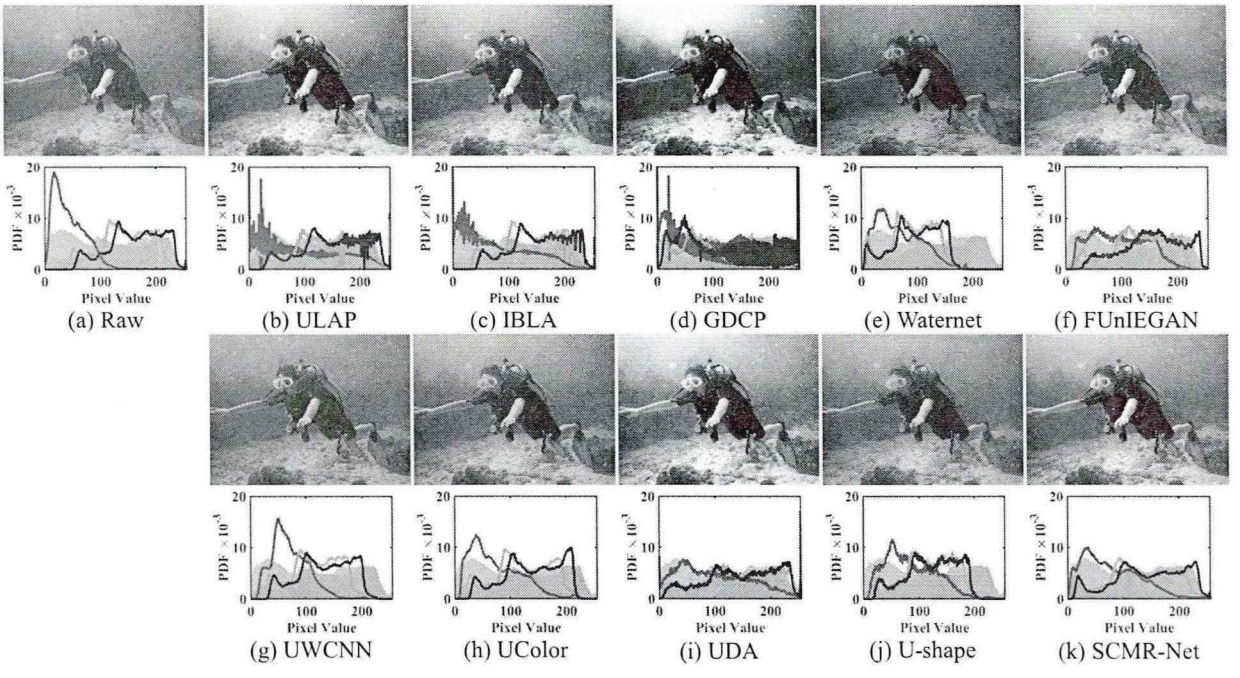

图 4.11 SCMR-Net 和对比方法在浅水域场景中增强结果和 RGB 直方图对比结果

Fig. 4.11 The results and RGB histogram in shallow scenes of state-of-the-art methods and SCMR-Net

此外，SCMR-Net 通过基于多分支的内在上下文注意力机制，能够在多个尺度层次上捕捉图像的细节，使得图像清晰化效果更加全面、精细，不仅能提高局部细节的恢复能力，还能保持图像的全局一致性，从而显著提升水下图像的视觉质量。SCMR-Net 方

中国知网 https://www.cnki.net

法充分利用多尺度表征空间的优势，确保图像清晰化过程中既能细致处理局部特征，又能保持图像整体的一致性。

4.6.3 消融实验分析

本节基于 UIEB 数据集的测试集进行消融实验，展示在不同阶段退化的影响，具体结果见表 4.6。此外，本节还分别对 BICA 架构中的各个组成部分（如表 4.7 所示）、SCMR-Net 中的 ASISF 模块（如表 4.8 所示）、不同损失函数（如表 4.9 所示）进行消融研究。

表格中粗体字表示最高得分，下划线字体表示第二高得分。Stage 数量的消融结果如表 4.6 和图 4.12 所示，图 4.12 (a)表示原始图像，图 4.12 的(b)-(e)对应表 4.6 中的 1-4 行，用于体现 Stage 数量对清晰化性能指标的影响。随着 Stage 数量的增加，SCMR-Net 的图像清晰化性能和多尺度特征提取能力逐步提升。性能指标在 Stage 数量为 4 时达到峰值，当引入 Stage5 时性能下降，由于 Stage 5 的像素分辨率为 16×16，在语义上退化为粗略轮廓或无意义的全局信号，当参与像素级监督和高分辨率融合，会引入噪声或冗余信息，破坏已稳定的语义结构，导致梯度扰动，训练难以收敛。因此本章选择四个阶段的决策。

表 4.6 不同阶段的消融研究定量结果

Tab. 4.6 Quantitative results of ablation studies for the four different stages

Stage1	Stage2	Stage3	Stage4	Stage5	PSNR↑	SSIM↑	ALL↑
√					22.790	0.916	23.706
√	√				22.872	0.915	23.787
√	√	√			23.248	0.915	24.163
√	√	√	√		**23.710**	**0.922**	**24.631**
√	√	√	√	√	23.311	0.916	24.227

表 4.7 展示基于双分支的内在上下文注意力机制的消融实验，其中分辨率引导的内在注意力模块 ReGIA 通过引入低分辨率引导空间，能够有效聚焦图像中的关键特征，抑制无关信息，从而增强图像清晰化的精确度。分层上下文感知特征提取模块 HCAFE，采用标准卷积和膨胀卷积相结合的方式来提取更广泛的上下文特征。从表 4.8 中可以明显看出，ASISF 提供的内在指导在图像清晰化过程中起到关键作用，有效地过滤无关特征，提高图像清晰化的效果。

中国知网 https://www.cnki.net

表 4.7 BICA 模块的消融研究定量结果

Tab. 4.7 Quantitative results of ablation studies for the BICA model

CA	SA	ReGIA	HCAFE	PSNR↑	SSIM↑	ALL↑
	√	√	√	21.219	0.901	22.120
√		√	√	23.352	0.917	24.269
√	√		√	22.673	0.907	23.580
√	√		√	23.276	0.911	24.186
√	√	√	√	**23.710**	**0.922**	**24.631**

为验证本章中使用的损失函数的有效性，进行消融实验，逐一去除 L_1、L_{pre} 和 L_{mse} 损失函数，全参考指标见表 4.9。实验结果充分验证多阶段损失函数在水下图像清晰化中的重要作用，尤其是 L_1 损失函数在减少恢复过程中产生的伪影和纹理失真方面起到重要的作用。L_{pre} 和 L_{mse} 损失函数确保图像的细节恢复，保持清晰化图像的全局一致性，提升图像的质量。

表 4.8 ASISF 模块的消融研究定量结果

Tab. 4.8 Quantitative results of ablation studies for the ASISF model

En	En to De	De	PSNR↑	SSIM↑	ALL↑
	√	√	23.021	0.915	23.936
√		√	23.697	0.919	24.615
√	√		23.122	0.914	24.036
√	√	√	**23.710**	**0.922**	**24.631**

表 4.9 损失函数的消融研究定量结果

Tab. 4.9 Quantitative results of ablation studies for the loss function

L_1	L_{pre}	L_{mse}	PSNR↑	SSIM↑	ALL↑
	√	√	23.257	0.915	24.172
√		√	22.905	0.912	23.817
√	√		23.151	0.919	24.069
√	√	√	**23.710**	**0.922**	**24.631**

通过上述的消融实验，验证 SCMR-Net 在水下图像清晰化任务中的各个模块和多阶段损失函数的有效性。通过分辨率引导的内在注意力模块和自适应选择性内在监督特征方法，不仅提升图像的质量，未增加过多的计算量，使得 SCMR-Net 模型能够在复杂的水下环境下进行高效的图像复原。

中国知网 https://www.cnki.net

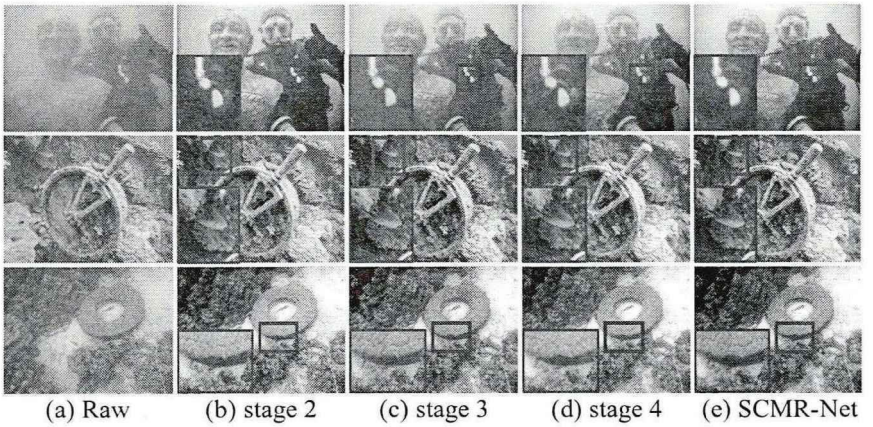

图 4.12 Stage 的消融实验主观结果

Fig. 4.12 Subjective results of ablation experiments on number of stages

4.6.4 效率分析

表 4.10 展示运行时间（Time）、Quality（见表 4.1 和表 4.2 中，Quality 指标代表 UIEB 验证集上的综合质量评分，即 Quality = ALL_no+ ALL_f）、综合评分（Agg）的全面分析。

表 4.10 SCMR-Net 方法与对比方法在 UIEB 数据集的效率分析结果

Tab. 4.10 The SCMR-Net method and comparison methods on the efficiency evaluation result of the UIEB dataset

	Time↓	Quality↑	Agg↑
ULAP	0.358	49.441	49.083
IBLA	9.134	51.656	42.522
GDCP	0.163	46.109	45.946
WaterNet	0.091	47.455	47.364
FUnIEGAN	**0.003**	47.733	47.730
UWCNN	0.050	48.502	48.452
UColor	0.577	53.226	52.649
UDA	0.100	58.374	58.273
U-Shape	0.109	52.997	52.887
SCMR-Net	0.061	**60.466**	**60.405**

为综合评估推理速度和水下图像清晰化性能，本节提出综合评分（Agg），具体计算方式为：

中国知网 https://www.cnki.net

$$Agg = ALL_no + ALL_f\text{-}Time \tag{4.15}$$

其中，Agg 提供一种更全面又公正的性能评估，即便 SCMR-Net 在推理速度未获最高分，但依旧达到 16.4744 FPS，可满足实时处理的要求。而且从表 4.10 里能够看出，SCMR-Net 取得 Agg 最高分，验证 SCMR-Net 在高级水下视觉任务里的适用性，SCMR-Net 能较高效率增强水下图像，保证图像清晰化的高质量水平，为水下视觉任务的后续发展提供关键的技术支撑。

4.7 本章小结

本章提出基于内监督协同多尺度表征的水下图像清晰化方法，该方法能够高效地捕捉多尺度场景信息，从复杂的水下场景中学习出有效的特征表示，通过基于双分支的内在上下文注意力机制、分辨率引导的内在注意力机制与内在监督的方式，充分利用图像场景中固有的尺度相关特征。为确保不同尺度间信息的有效融合，将低分辨率输入与原始分辨率输入进行融合，从而增强多尺度场景信息的利用。为减少无关场景带来的干扰，使用自适应选择性内在监督特征模块，旨在精确调节特征传播过程，从而提高图像复原精度。多阶段损失函数在训练过程中为网络提供多重引导，通过在每个阶段进行优化和约束，增强网络在不同尺度下利用信息的能力，利用多尺度细节来丰富水下图像中的场景信息，提高图像清晰化的质量和稳定性。

实验结果表明，该方法与代表性方法相比在全参考指标中提升 9.5%，在多个水下数据集上均取得显著的性能提升，在细节恢复、多尺度对比度优化、色彩保真度等指标整体优于现有方法，特别是在高浑浊度和强散射光环境下，依然能够保持优异的清晰化效果。这充分验证在空间维度的基础上集成多尺度建模对于退化过程表征的重要性，有效突破现有方法在单尺度建模上的局限性，为水下图像清晰化提供更加稳健、高效的解决方案。

中国知网 https://www.cnki.net

5 基于场景表征引导的水下图像清晰化方法

水下图像在海洋资源勘查、生态监测及水下工程等领域具有重要的应用价值。然而，因水体对光的强吸收与散射效应[161]，水下图像呈现颜色失真、对比度降低、细节模糊等清晰化问题[162]。当前部分方法尝试融合物理先验与深度网络，但融合过程多为浅层拼接或特征并联，未能在表征空间上建立统一的分布结构，也未解决训练目标之间的冲突问题，导致网络收敛性弱、可解释性差。如何实现表征一致性引导下的物理感知协同建模，仍是水下图像增强中的核心挑战。

为解决上述挑战，本章提出基于场景表征引导的水下图像清晰化方法（Underwater Image Clarification Method Guided by Scene Representation, SRG-Net）。该方法基于 Retinex 理论分离入射光分量与反射分量，结合多尺度特征建模和基于上下文信息的多级集成机制实现水下图像的高保真恢复。SRG-Net 采用双输入结构，分别将原始图像与反射图像输入独立编码器，借助多尺度场景目标提取模块，捕获不同尺度下跨表征空间的丰富特征信息，并通过空间-通道注意力机制，强化关键区域的特征表征能力。在解码阶段，利用跨表征空间的特征融合策略，有效提升重建清晰图像的精度，抑制伪影产生。训练过程中结合平滑 L1 损失与感知损失的联合优化，保证像素级恢复精度，强化图像的语义一致性，约束 SRG-Net 的视觉自然性与稳定性。

5.1 SRG-Net 方法提出

现有水下图像清晰化方法采用端到端深度学习框架，或者基于水下成像模型参数的反向推导来估计清晰图像。端到端方法虽然能够通过深度网络自动学习特征表征，但往往存在冗余特征拟合和噪声干扰的问题，导致网络可能收敛到局部无效特征，从而影响增强的稳定性和鲁棒性。为提高水下图像清晰化方法的泛化能力，近年来研究者结合水下成像物理模型和先验知识增强方法对不同场景的适应性。

先验知识主要包括基于水下成像模型的先验和基于 Retinex 理论的先验。水下成像模型先验通常依赖于统计特性或成像条件，在特定环境下能够较好地恢复图像，但由于水体光学特性的复杂性，这类先验难以适用于所有水下环境，导致增强方法的鲁棒性较低。相比之下，Retinex 理论基于人类视觉系统的感知机制，通过将图像分解为反射分量（场景固有属性）和光照分量（环境光影响），能够去除光照影响并恢复物体的真实颜色和纹理[163,164]。与水下成像模型先验相比，Retinex 理论先验不依赖于图像统计信息和特定水体成像条件，对不同水下场景具有更强的适应性和鲁棒性。

中国知网 https://www.cnki.net

物理模型具有可解释性，但在未知场景下参数估计困难，而深度学习模型虽具强拟合能力却易引入伪影，问题根源在于物理成像过程与神经网络学习机制在表征空间与优化目标上的不一致性。目前缺乏对物理规律引导下深层特征演化机制的系统性认识。因此需研究水下成像物理约束如何影响深度特征分布的边界与收敛路径，探索物理感知驱动的端到端网络结构设计原则。

基于上述研究，本章针对基于场景表征引导的水下图像清晰化方法开展研究，SRG-Net 通过融合水下表征空间和场景表征空间增强水下图像。在复杂的水下环境中，基于 Retinex 模型采用多尺度高斯滤波器来估计入射分量[39][60][143][144]，入射分量估计比图像成像模型参数估计更具鲁棒性，能够避免因先验估计不准确而导致网络的不稳定性。

基于 Retinex 理论引导的水下图像清晰化的网络架构图如图 5.1 所示。主要包括：反射图像估计方法、原始图像表征空间编码器、场景表征空间编码器和多表征空间解码器，反射图像估计模块用于计算水下图像的反射率。本章在空间维度和多尺度维度的基础上集成场景维度，利用场景先验知识优化水下图像增强，结合水下场景的语义结构和目标分布特征，充分提取原始图像和反射分量两个表征空间的特征信息。

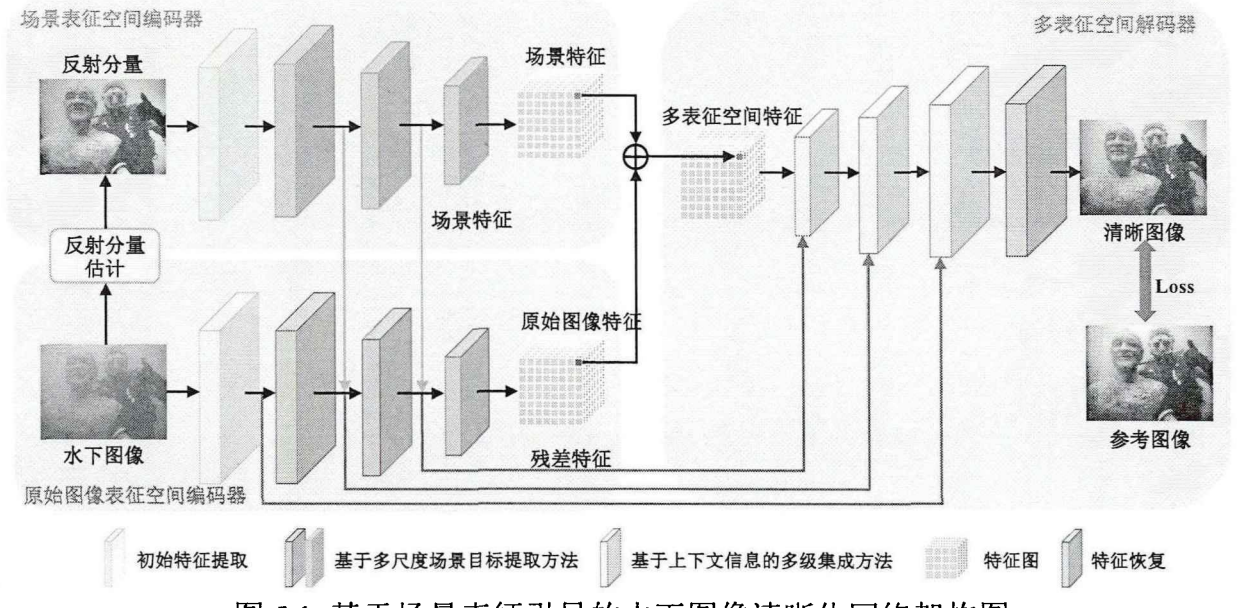

图 5.1 基于场景表征引导的水下图像清晰化网络架构图

Fig. 5.1 Framework diagram of underwater image clarification network guided by scene representation

在原始图像表征空间编码器和场景表征空间编码器阶段，提出多尺度场景目标提取方法（Multi-Scale Scene Target Extraction Module, MSTE），有效提取不同尺度上的场景

中国知网 https://www.cnki.net

信息，使得增强网络能够关注水下目标的真实物理特性。由于原始图像和反射图像都包含有助于清晰化图像的表征信息，因此在反射图像编码器和原始编码器中采用相同的网络架构。然而，由于水下图像和反射图像之间特征分布不均，本章摒弃参数共享策略，旨在分别学习水下图像和反射图像中不同的场景表征信息。在分别提取水下图像和反射图像的深层语义表征信息后，为在相同分辨率下整合同一像素区域的互补信息，SRG-Net采用对应的特征融合策略，并将融合结果作为水下图像重建的残差信息。该策略有助于减少信息损失，增强网络对于图像场景信息的感知能力，有效建模原始图像和场景多表征空间的关联互补关系，提升图像清晰化的准确性与一致性。

在多表征空间解码阶段中，提出基于上下文信息的多级集成方法（Context-Sensitive Multi-Level Integration Module, CSMLI），通过融合来自原始图像表征空间和场景表征空间的特征信息，协同建模场景信息、局部细节增强与全局语义优化，提升水下图像场景增强结果的物理一致性、语义连贯性与色彩校正能力。

综上所述，SRG-Net 充分考虑物理一致性和全局语义信息，通过原始图像表征空间和场景表征空间优化局部细节和对比度，能更精确地增强真实水下场景的信息，增进该方法的物理合理性与全局一致性水平。

5.2 基于 Retinex 模型的反射图像估计方法

由于水体折射和吸收的影响，水下图像中的真实场景物体信息无法完全传递至相机传感器。受 Retinex 理论的启发，本章将反射图像作为辅助输入，以增强水下图像的场景信息。与现有的图像清晰化网络相比，SRG-Net 充分利用水下图像中的场景物体特征信息，体现多表征空间融合中的独特优势。

根据 Retinex 理论[105]，水下图像 I 可视为入射分量 L 和反射图像 R 的乘积，即：

$$I = L \times R \tag{5.2}$$

其中，L 表示图像中的入射分量，R 为场景物体的反射图像。

在 SRG-Net 中采用多尺度反射图像估计方法[107]来分解反射图像和入射分量，将其作为图像预处理的一部分。具体而言，将图像转换到频域进行处理，以减少计算复杂度。在频域中，SRG-Net 设计 K 个尺度的高斯滤波器来估计水下图像中的入射分量：

$$R = f(\sum_{k=1}^{K} w_k \{\log I - \log[F_k * I]\}) \tag{5.3}$$

中国知网 https://www.cnki.net

其中，F_k 表示第 k 个高斯核，K 表示尺度数量，*表示卷积操作，在本章中设置 $K=3$，w_k 是高斯滤波器的权重系数，表示在进行反射率估计时，每个高斯核滤波器对图像信息的影响程度，在本章中设置 $w_k = 1/K$，$f(.)$为反射图像估计函数：

$$f(I) = \beta\{\log(\alpha I) - \log(R)\} \tag{5.4}$$

其中，β 和 α 是手动设定的常数，用于控制反射图像估计的尺度和强度。

为避免反射图像中出现负像素值，SRG-Net 采用增益 G_a 和偏置 O 来校正反射率图像：

$$R = G_a \times R + O \tag{5.5}$$

其中，G_a 和 O 为常数。

反射图像作为水下物体的固有特征，有大量与图像清晰化相关的关键信息。通过设计合理的网络架构，SRG-Net 能够有效地将反射图像与原始图像不同表征的信息进行融合，使得网络能够从更丰富的场景表征信息中学习，提升对水下图像复杂场景和细节的捕捉能力。不仅减少深度学习模型的复杂性，还提升 SRG-Net 的鲁棒性和适应性，能够更好地处理复杂的水下环境下的图像清晰化任务。

5.3 基于多尺度场景目标提取方法

SRG-Net 分别将反射图像信息输入到场景表征空间编码器中，原始图像则输入到原始图像表征空间编码器中。为从场景表征空间和原始图像表征空间中提取互补的信息，SRG-Net 采用相同的网络结构，但两个表征空间的编码器未采用共享权重策略。

在原始图像表征空间编码器、场景表征空间编码器中分别对输入图像和反射图像进行初始特征提取处理。具体而言，采用卷积核大小 3×3，卷积步幅为 1，padding 为 1 的卷积层，将输入水下图像和反射分量转换为 16 通道的特征空间，有助于捕捉水下环境中关键细节和局部特征，从而为后续对原始图像及其反射图像的联合建模提供更加稳定和有效的特征基础。

为提取多分辨率的特征信息，SRG-Net 设计多尺度场景目标提取模块（Multi-Scale Scene Target Extraction Module, MSTE），该模块有效提取输入特征中的图像物体信息。多尺度场景目标提取模块的结构如图 5.2 所示。由于水下场景中存在不同尺度的物体，场景物体的大小和形状差异较大，若使用相同的卷积核提取不同尺度的物体特征，会影响水下图像的获取和处理效果。

中国知网 https://www.cnki.net

因此，为更好地捕获不同尺度物体的信息，并提高对不同尺度物体特征的感知能力，SRG-Net 设计 TriFuse 卷积操作，采用多尺寸的卷积核，包括 1×1 卷积层、3×3 卷积层和 5×5 卷积层，以提取多感受野下的特征信息，从而生成具有丰富上下文表达能力的 TriFuse 特征图。

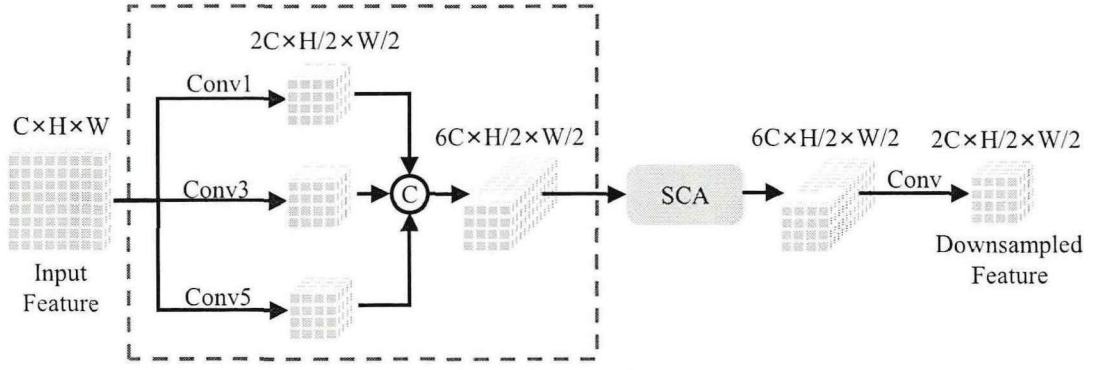

图 5.2 多尺度场景目标提取模块架构图

Fig. 5.2 Architecture diagram of multi-scale scene target extraction module

TriFuse 卷积操作有助于捕捉图像中不同尺度的结构与语义信息，增强网络对复杂场景的理解与表征能力，表达式为：

$$F_{Tri} = \text{Concat}(\text{GeLU}(\text{Conv1}(F)), \text{GeLU}(\text{Conv3}(F)), \text{GeLU}(\text{Conv5}(F))) \tag{5.6}$$

其中，Conv1 表示 1×1 卷积核，Conv3 表示 3×3 卷积核，Conv5 表示 5×5 卷积核，GeLU 表示激活函数，F 表示输入特征，F_{Tri} 表示经过 Trifuse 操作的增强特征。

在获取 TriFuse 特征图后，将多个特征图沿通道维度进行拼接，提供包含更多信息的全局特征表示，使多尺度场景目标提取方法能够在多个尺度上建模数据的复杂性和多样性。多尺度场景目标提取方法有助于捕捉水下环境中的各种细节和特征，从而提升网络在提取水下图像及其相应反射图像场景信息的建模能力。

为增强 TriFuse 特征中关键信息的感知能力，多尺度场景目标提取模块在多尺度提取后引入空间-通道注意力机制（SCA），架构图如图 5.3 所示，SCA 中的通道注意力机制用于为不同尺度的通道分配权重，而像素注意力机制则增强通道中的像素特征信息。最后，通过卷积操作融合多尺度的通道信息，以获得丰富的特征信息。

SCA 通过引入通道注意力机制，有效捕捉图像中关键的通道信息与结构特征，实现三种尺度特征的深度融合。该机制能够自适应地分配像素级通道权重，强化图像中目标区域的表征能力。考虑到水对光的选择性吸收作用，水下图像常表现出明显的蓝绿色偏

中国知网 https://www.cnki.net

色，通道注意力机制在此背景下能够更精准地处理颜色信息与特征分布，有助于提升图像的颜色恢复效果和整体视觉质量。

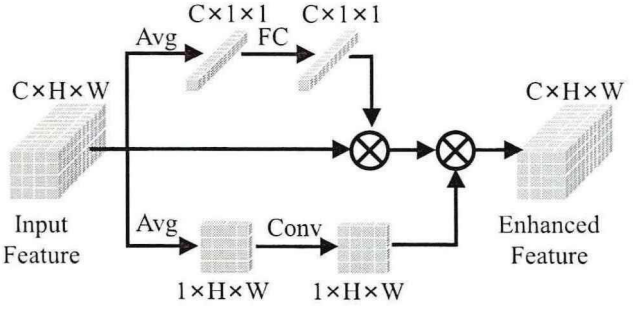

图 5.3 空间-通道注意力机制架构图

Fig. 5.3 Architecture diagram of spatial channel attention mechanism

具体而言，对 TriFuse 特征进行通道维度上的平均池化，具体计算式为：

$$CW_C = \frac{1}{H \times W} \sum_{i}^{H} \sum_{j}^{W} F_{Tri}(i, j) \tag{5.7}$$

其中 $CW \in \mathbb{R}^{C\times1\times1}$，$C$ 表示特征通道，H 和 W 分别表示特征图的高度和宽度。

利用全连接层和激活函数建模多个通道之间的权重关系：

$$CA = \sigma(\mathrm{FC}_2(\mathrm{Gelu}(\mathrm{FC}_1(CW)))) \tag{5.8}$$

其中，GeLU 表示激活函数，$\sigma(\cdot)$ 表示 Sigmoid 函数，用于将权重归一化到[0, 1]区间。FC_1 和 FC_2 表示全连接层，其输出大小分别为 C/r 和 C，本章中设置 $r=4$，用以减少 SRG-Net 方法的计算成本。$CW \in \mathbb{R}^{C\times1\times1}$ 是通道注意力图，在获得空间注意力机制后，传播到整个特征空间的每一个像素位置，维度为 $CA \in \mathbb{R}^{C\times H\times W}$。

在处理水下图像时，图像中的信息分布具有显著的不均匀性。水下物体往往承载更多的特征信息，而背景则通常含有较少的有效信息。为有效提取并增强这些关键信息，采用像素级的注意力机制进行特征增加。对 TriFuse 特征进行像素级的平均池化，得到 $SW \in \mathbb{R}^{1\times H\times W}$：

$$SW(x, y) = \frac{1}{C} \sum_{i}^{C} F_{Tri}(c, x, y), \ i \in [1, C] \tag{5.9}$$

其中，C 表示通道数量。

中国知网 https://www.cnki.net

通过卷积操作和激活函数自适应地计算每个像素的特征信息：

$$SA = \sigma(\text{Conv}(\text{Gelu}(\text{Conv}(SW)))) \tag{5.10}$$

其中，SA 表示空间注意力权重矩阵，Conv 表示 3×3 的卷积。

在获得通道注意力权重 CA 和空间注意力权重 SA 后，基于多特征场景目标提取方法通过以下方式增强 TriFuse 特征：

$$F_T = F \times CA \times SA \tag{5.11}$$

其中，×表示逐元素相乘，F_T 表示增强后的潜在特征向量，用于多表征空间编码器。

5.4 基于上下文信息的多级集成方法设计

图像通常包含层次丰富且多样的信息，低层特征主要提供边缘、纹理等细节信息，而高层特征则包含更为抽象的语义信息，有助于描述图像中的结构与语义关系。为有效恢复图像中不同层次的信息，尤其针对水下图像中因水体介质和光照条件变化所导致的复杂失真问题，本节提出基于上下文信息的多级集成方法（Context-Sensitive Multi-Level Integration Module, CSMLI）。该方法融合转置卷积、标准卷积以及空间-通道联合注意力机制，旨在重建多分辨率特征表示，强化上下文信息的传递与整合。通过多层次特征的逐级融合，能够有效抑制现有方法中伪影现象，从而提升水下图像的整体恢复质量与结构一致性。

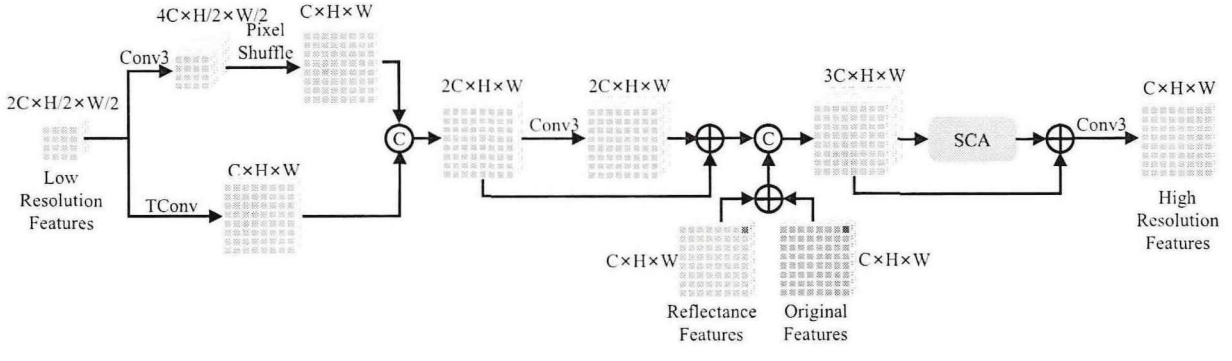

图 5.4 基于上下文信息的多级集成模块架构图

Fig. 5.4 Architecture diagram of context-sensitive multi-level integration module

图 5.4 展示基于上下文信息的多级集成方法的架构。该模块通过结合反卷积与常规卷积实现上采样，并引入卷积操作与 PixelShuffle 操作以有效缓解伪影现象。反卷积在上采样过程中有助于恢复更精细的像素级信息；场景表征空间特征与原始图像表征空间

中国知网 https://www.cnki.net

特征通过逐元素加法进行融合，用于捕捉同一像素位置上的互补特征，增强局部细节表达。

与卷积层相比，反卷积通常在现有的 UNet 网络[120][121]中用于解码潜在特征向量，保持端到端训练，实现空间分辨率的恢复。反卷积相比于标准卷积，更擅长于还原图像中精确的像素位置与空间结构信息。然而，反卷积在上采样时由于感受野重叠，引入非局部连接，进而造成图像畸变与视觉伪影。因此，基于上下文信息的多级集成方法采用卷积与反卷积结合的方式，在反卷积的基础上引入 3×3 卷积操作和 PixelShuffle，以细化重建特征、缓解伪影产生，PixelShuffle 操作不仅提升空间分辨率，还有效减少由插值不均或通道重排引发的结构性伪影，增强图像清晰化的整体效果与稳定性。

综上，通过将反卷积的空间重建能力与卷积的局部细节提取能力相结合，CSMLI 能够更准确地还原水下图像中的关键结构与细节，为实现高质量图像清晰化提供有效的解码支持。具体公式如下：

$$F_{conv} = \mathrm{PS}(\sigma(\mathrm{Conv}_3(F_T))) \tag{5.12}$$

$$F_{tran} = \mathrm{TConv}(F_T) \tag{5.13}$$

$$F_{up} = \mathrm{BN}(\mathrm{Concat}(F_{conv}, F_{tran})) \tag{5.14}$$

$$F_{up} = F_{up} + \sigma(\mathrm{Conv}_3(F_{up})) \tag{5.15}$$

其中，F_{conv} 表示通过卷积层获得的特征，PS(.)为 PixelShuffle 操作，F_{tran} 表示通过反卷积层获得的特征，TConv 表示反卷积的核，F_{up} 表示融合后的多级集成特征。CSMLI 的最终输出通过深度融合两个层级的输出得到的。BN（BatchNorm）表示批归一化。CSMLI 可以增强特征表示建模能力。

为更好地结合像素级信息并避免伪影的影响，引入来自编码器的残差特征信息，包括原始图像的表征空间特征 F_I 与反射图像表征空间的特征 F_{Re}，通过逐元素加法将多个表征空间特征信息在相应位置进行结合，更好地融合来自多个特征图的信息：

$$F_e = F_{Re} + F_I \tag{5.16}$$

为增强网络的非线性表达能力并获得更好的特征表示，采用特征拼接的方式，结合来自多个分辨率的特征信息（F_{up} 和 F_e）：

$$F_m = \mathrm{Concat}(F_{up}, F_e) \tag{5.17}$$

中国知网 https://www.cnki.net

其中，F_{Re}和F_I分别表示来自反射图像编码器和原始图像编码器的残差特征，F_m表示多分辨率的信息。

采用空间-通道注意力（Spatial-Channel Attention，SCA）机制和残差连接来增强F_m：

$$F_{de} = \sigma(\mathrm{Conv}_3(\mathrm{SCA}(F_m) + F_m)) \tag{5.18}$$

其中，SCA 表示空间-通道注意力机制的增强操作，F_{de}表示 CSMLI 的最终输出。

基于上下文信息的多级集成模块能够有效地融合来自多个尺度的特征信息，从而提升图像清晰化的精度和细节保留。CSMLI 模块结合反卷积、卷积和空间-像素注意力机制，以更准确地恢复水下图像中的像素位置，避免现有解码器中出现的伪影问题，增强图像的特征建模能力，使得网络能够更好地捕捉和重建图像中的细节信息。

5.5 多表征空间特征恢复方法设计

多表征空间特征恢复模块用于通过基于上下文信息的多级集成模块处理过的多层次特征映射恢复为最终的输出图像。该模块不仅需要融合来自原始图像表征空间和反射图像表征空间的特征信息，需结合来自不同层的多分辨率特征和保持图像的空间一致性和细节恢复能力，以实现高质量的图像清晰化效果，生成符合物理约束和视觉感知的水下图像。

在特征恢复模块的初始阶段，对输入特征进行层归一化，公式如下：

$$\hat{F}_{de} = \frac{F_{de} - \mu}{\sigma + \epsilon} \cdot \gamma + \beta \tag{5.19}$$

其中，μ与σ分别为均值和标准差，γ与β为可学习的尺度和偏移参数，$\hat{F}_{de}$表示层归一化后的特征。

采用具有自适应特性的卷积操作，并结合 GeLU 激活函数引入非线性映射能力，能够避免梯度消失问题，提升网络的表达能力。公式为：

$$RF_1 = \mathrm{GeLU}(\mathrm{Conv}(\hat{F}_{de})) \tag{5.20}$$

特征恢复的最后阶段，使用 SCA 通过对不同空间位置和通道赋予动态权重，优化特征的表示：

$$RF_2 = \mathrm{SCA}(RF_1) \tag{5.21}$$

中国知网 https://www.cnki.net

通过卷积操作与 Tanh 激活函数对特征进行像素级的特征恢复。使用卷积层整合来自多个尺度层的特征信息，并通过 Tanh 函数对输出值进行归一化约束，从而符合图像像素值的标准化要求，具体公式如下：

$$E = \text{Tanh}\ (\text{Conv}(RF_2)) \tag{5.22}$$

其中 E 表示基于场景表征引导的水下图像清晰化方法预测结果。

5.6 损失函数设计

为更好地保留增强图像中的细节信息，并确保恢复结果具有更高的视觉质量，本章采用像素级的 $smooth_{L1}$ 损失函数[165]和感知损失函数 L_{VGG}。相较于均方误差损失函数（L_{MSE}），$smooth_{L1}$ 损失对离群值不敏感、平滑且可导。$smooth_{L1}$ 的公式为：

$$smooth_{L1} = \begin{cases} 0.5(E-\hat{J})^2 & \text{if } \left|E-\hat{J}\right| < 1 \\ \left|E-\hat{J}\right| - 0.5 & \text{otherwise} \end{cases} \tag{5.23}$$

其中，E 表示 SRG-Net 的清晰化结果，$\hat{J}$ 为真实参考图像。

引入感知损失 L_{VGG}，提升清晰化结果的视觉效果和特征感知质量[154]：

$$L_{VGG} = \sum_{j=1}^{W1}\sum_{i=1}^{H1}\left\|\phi(E(i,j)) - \phi(G(i,j))\right\|_2^2 \tag{5.24}$$

其中 ϕ 表示 VGG 网络的第 16 层特征映射，$W1$ 和 $H1$ 为第 16 层特征的宽和高。

综合考虑像素级损失和感知损失，定义总损失函数 L：

$$L = smooth_{L1} + \lambda \times L_{VGG} \tag{5.25}$$

其中，λ 为权重，本章中设置 $\lambda = 0.2$。

5.7 SRG-Net 算法设计

基于 Retinex 理论引导的水下图像清晰化深度学习方法的核心目标是通过融合多尺度场景特征与反射分量，解决水下图像因吸收、散射导致的低对比度与颜色失真，SRG-Net 的模块图如图 5.5 所示。SRG-Net 的算法如 Algorithm 5.1 所示，SRG-Net 采用双编码器输入策略，分别从原始退化图像表征空间和 Retinex 理论生成的场景场景表征空间中提取不同表征空间的深层语义特征，通过独立编码器捕捉多表征空间的互补信息用于多表征编码器。

中国知网 https://www.cnki.net

Algorithm 5.1: SRG-Net

Input: Degraded underwater image $I \in \mathbb{R}^{3\times H\times W}$

Reflectance image $R \in \mathbb{R}^{3\times H\times W}$ // via Algorithm 5.2 MSRCR

Output: Enhanced image $E \in \mathbb{R}^{3\times H\times W}$

// **Step1: Original Encoder**

$F_{or}^{1} \leftarrow \mathrm{GeLU}(\mathrm{Conv}(I))$ // $F_{or}^{1} \in \mathbb{R}^{B\times 16\times H\times W}$

$F_{or}^{2} \leftarrow \mathrm{MSTE}(F_{or}^{1})$

$F_{or}^{3} \leftarrow \mathrm{MSTE}(\mathrm{Down}(F_{or}^{2}))$

$F_{or}^{4} \leftarrow \mathrm{MSTE}(\mathrm{Down}(F_{or}^{3}))$

$F_{or}^{5} \leftarrow \mathrm{MSTE}(\mathrm{Down}(F_{or}^{4}))$

// **Step2: Reflection Encoder**

$F_{R}^{1} \leftarrow \mathrm{GeLU}(\mathrm{Conv}(R))$ // $F_{R}^{1} \in \mathbb{R}^{B\times 16\times H\times W}$

$F_{R}^{2} \leftarrow \mathrm{MSTE}(F_{R}^{1})$

$F_{R}^{3} \leftarrow \mathrm{MSTE}(\mathrm{Down}(F_{R}^{2}))$

$F_{R}^{4} \leftarrow \mathrm{MSTE}(\mathrm{Down}(F_{R}^{3}))$

$F_{R}^{5} \leftarrow \mathrm{MSTE}(\mathrm{Down}(F_{R}^{4}))$

// **Step3: Dual-representation Decoder**

$F_{E}^{5} \leftarrow F_{or}^{5} + F_{R}^{5}$

$D^{4} \leftarrow \mathrm{CSM}(F_{E}^{5})$

$F_{E}^{4} \leftarrow F_{or}^{4} + F_{R}^{4}$

$D_{E,1}^{4} \leftarrow \mathrm{Concat}(F_{E}^{4}, D^{4})$

$D_{E}^{4} \leftarrow \sigma(\mathrm{Conv}(\mathrm{SCA}(D_{E,1}^{4}) + D_{E,1}^{4}))$

$D^{3} \leftarrow \mathrm{CSM}(D_{E}^{4})$

$F_{E}^{3} \leftarrow F_{or}^{3} + F_{R}^{3}$

$D_{E,1}^{3} \leftarrow \mathrm{Concat}(F_{E}^{3}, D^{3})$

$D_{E}^{3} \leftarrow \sigma(\mathrm{Conv}(\mathrm{SCA}(D_{E,1}^{3}) + D_{E,1}^{3}))$

$D^{2} \leftarrow \mathrm{CSM}(D_{E}^{3})$

$F_{E}^{2} \leftarrow F_{or}^{2} + F_{R}^{2}$

$D_{E,1}^{1} \leftarrow \mathrm{Concat}(F_{E}^{2}, D^{2})$

$D_{E}^{1} \leftarrow \sigma(\mathrm{Conv}(\mathrm{SCA}(D_{E,1}^{2}) + D_{E,1}^{2}))$

// **Step4: Feature Restoration**

$\hat{D}_{E}^{1} \leftarrow \dfrac{D_{E}^{1} - \mu}{\sigma + \epsilon} \cdot \gamma + \beta$

$RF_{1} \leftarrow \mathrm{GeLU}(\mathrm{Conv}(\hat{D}_{E}^{1}))$

$RF_{2} \leftarrow \mathrm{SCA}(RF_{1})$

$E \leftarrow \mathrm{Tanh}(\mathrm{Conv}(RF_{2}))$

Return E

中国知网 https://www.cnki.net

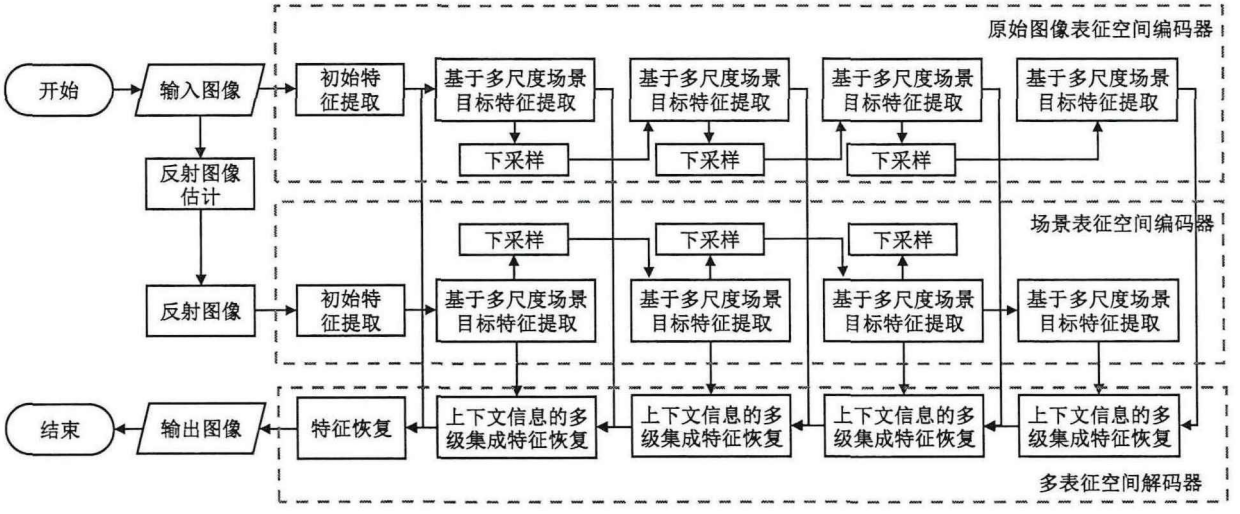

图 5.5 SRG-Net 方法架构图

Fig. 5.5 The framework of the SCMR-Net algorithm

基于 Retinex 模型的反射图像估计方法的算法见 Algorithm 5.2，论文采用鲁棒性的 MSRCR 算法分离入射分量和反射分量，MSRCR 方法通过对数域中的多尺度加权处理，分离图像的场景信息，引入颜色恢复项以缓解 Retinex 模型在水下环境中导致的色彩失真问题。其中反射分量主要反映水下图像的场景信息，将其作为 Algorithm 5.1 的辅助输入可以避免水体介质变化的干扰。

Algorithm 5.2: Multi-Scale Retinex with Color Restoration (MSRCR)

Input: Degraded underwater image $I \in \mathbb{R}^{3\times H\times W}$

Output: Reflectance image $R \in \mathbb{R}^{3\times H\times W}$

Parameters:

Gaussian kernels number: $K = 3$

1: $f(I) \leftarrow \beta \log(\alpha I) \leftarrow \beta\left\{\log(\alpha I) - \log\left(\sum_{j=1}^{N} I_j\right)\right\}$

2: $w_k \leftarrow \frac{1}{K}$

3: $R_1 \leftarrow f(\sum_{k=1}^{K} w_k\{\log I - \log[F_k * I]\})$

4: $R \leftarrow Ga \times R + O$

5: Return R

在多表征空间编码器中，为提升对水下图像中多尺度目标的感知与表达能力，设计基于多尺度场景目标提取方法 MSTE，算法见 Algorithm 5.3 所示，MSTE 利用不同尺度

中国知网 https://www.cnki.net

的特征融合策略增强水下场景中目标物体的目标边缘与纹理信息等局部细节、背景轮廓与空间关系等全局结构表达，提升 SRG-Net 对于不同尺度下水下场景的清晰化能力。

Algorithm 5.3: MSTE

Input: Feature $F \in \mathbb{R}^{B\times C\times H\times W}$

Output: Enhanced Feature $F_{\text{en}} \in \mathbb{R}^{B\times C\times H\times W}$

1: $F^1 \leftarrow \text{GeLU}(\text{Conv}_1(F))$

2: $F^3 \leftarrow \text{GeLU}(\text{Conv}_3(F))$

3: $F^5 \leftarrow \text{GeLU}(\text{Conv}_5(F))$

4: $F_1 \leftarrow \text{Concat}(F^1, F^3, F^5)$

5: $F_{\text{en}} \leftarrow \text{SCA}(F_1)$ // via Algorithm 5.4 SCA

6: Return F_{en}

基于多尺度场景目标提取方法结合空间-通道注意力机制自适应加权关键区域的特征响应，空间-通道注意力机制 SCA 算法见 Algorithm 5.4 所示，空间注意力机制 SA 通过强化图像中目标区域的表征能力，抑制背景噪声与无效信息干扰。通道注意力机制 CA 能够更精准地处理颜色信息与特征分布，有助于提升图像的颜色恢复效果和整体视觉质量。

Algorithm 5.4: SCA

Input: Feature $F \in \mathbb{R}^{B\times C\times H\times W}$

Output: Enhanced Feature $F_{\text{SCA}} \in \mathbb{R}^{B\times C\times H\times W}$

1: $CW \leftarrow \dfrac{1}{H\times W}\sum_{x}^{H}\sum_{y}^{W} F(x,y)$

2: $CA \leftarrow \sigma(\text{FC}_2(\text{Gelu}(\text{FC}_1(CW))))$

3: $SW(x,y) \leftarrow \dfrac{1}{C}\sum_{i}^{C} F(x,y),\ i \in [1,C]$

4: $SA \leftarrow \sigma(\text{Conv}(\text{Gelu}(\text{Conv}(SW))))$

5: $F_{\text{SCA}} \leftarrow F \times CA \times SA$

6: Return F_{SCA}

在解码阶段，使用基于上下文信息的多级集成方法融合多表征空间的特征，算法如 Algorithm 5.5 所示，融合来自原始图像表征空间和反射图像表征空间的特征信息，结合来自不同层的多分辨率特征和保持图像的空间一致性和细节恢复能力，实现高质量的图像清晰化效果。

中国知网 https://www.cnki.net

Algorithm 5.5: CSM

Input: Feature $F \in \mathbb{R}^{B\times C\times H\times W}$

Output: Enhanced Feature $F_{\mathrm{CSM}} \in \mathbb{R}^{B\times C\times H\times W}$

1: $F_1 \leftarrow \mathrm{PS}(\sigma(\mathrm{Conv}(F)))$

2: $F_2 \leftarrow \mathrm{TConv}(F)$

3: $F_3 \leftarrow \mathrm{Concat}(F_1, F_2)$

4: $F_4 \leftarrow F_3 + \sigma(\mathrm{Conv}(F))$

5: $F_{\mathrm{CSM}} \leftarrow \mathrm{SCA}(F_4)$ // via Algorithm 5.4 SCA

10: Return F_{CSM}

SRG-Net 训练过程中联合优化像素级 $smooth_{L1}$ 损失与基于 VGG 网络的感知损失 L_{VGG}，确保增强结果在像素精度与视觉感知质量上的平衡。

5.8 实验结果与分析

5.8.1 实验设置说明

在训练过程中，本章采用 UIEB 数据集[77]。该数据集包含来自不同海洋场景的 890 对水下图像，60 张未配对的挑战图像。本章随机将 890 对图像分为训练集和测试集，其中 800 对作为训练集，90 对作为测试集。

本章选择现有的先进水下图像清晰化方法进行比较，包括基于物理模型的水下图像复原方法：IBLA[30]、ULAP[22]、GDCP[21]、SMBL[166]，基于深度学习的水下图像清晰化方法：WaterNet[77]、UWCNN[95]、Ucolor[78]、PUIE[160]、UIEC^2[167]。为保证实验数据和比较的公平性，本章基于划分的训练数据集重新训练 WaterNet[77]、UWCNN[95]、Ucolor[78]、PUIE[160]和 UIEC^2[167]模型。

与第四章相同，本章基于 Intel Xeon Silver 4114 CPU（32 GB 内存）和 NVIDIA Tesla V100 GPU 计算平台，并基于 PyTorch 深度学习框架实现 SRG-Net 网络模型的训练和推理，设置初始学习率 0.0001，使用 AdamW 进行优化，BatchSize 设置为 60，训练 750 epochs，把图像随机裁剪成分辨率为 256×256 进行训练。

5.8.2 定性质量评价

为全面评估 SRG-Net 的在水下图像清晰化能力，本节选取具有代表性的水下图像清晰化方法进行对比，涵盖基于物理模型的水下图像清晰化方法和基于深度学习的水下增强方法。图 5.6 展示 SRG-Net 与现有的对比方法在 UIEB 数据集[77]中的增强结果。图 5.6 中展示多个典型水下场景，包括绿色调水域（Raw 1-3）、蓝色调水域（Raw 4-6）、浅水区域（图 5.6 Raw 7-9）。实验结果表明，在所有测试图像中，SRG-Net 方法的增强结

中国知网 https://www.cnki.net

果在色彩恢复、细节保留和全局光照均衡性方面均优于其他方法。特别是在存在较强颜色偏移或低对比度的场景下，SRG-Net 仍能稳定地恢复自然色彩，并显著提升图像的可视化质量。

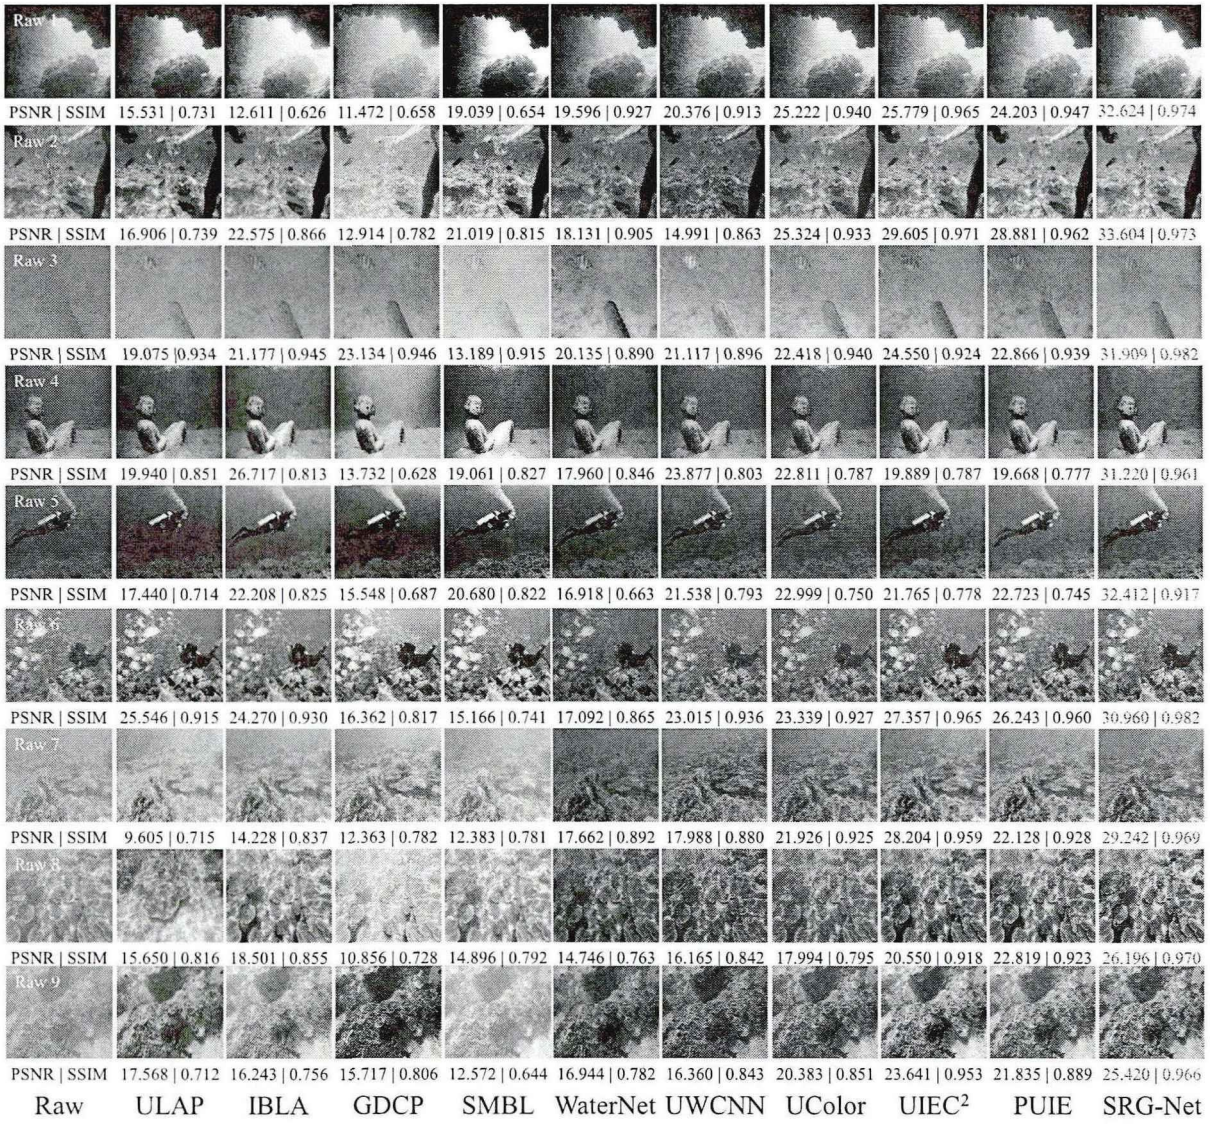

图 5.6 SRG-Net 方法与对比方法在 UIEB 数据集的主观结果

Fig. 5.6 Subjective Results of the proposed SRG-Net and Comparison Methods on the UIEB Dataset

为验证 SRG-Net 在复杂水下环境中的适应能力，在多个具有代表性的场景（如岩石、水下潜水员、珊瑚礁、鱼群等）上测试其增强性能，实验结果表明 SRG-Net 在多种水下环境下均能保持较高的增强质量和较强的鲁棒性。基于物理模型的水下图像清晰化

中国知网 https://www.cnki.net

方法主要依赖水下成像物理模型和统计先验来恢复图像，包括 ULAP[22]、GDCP[21]、IBLA[30]和 SMBL[166]方法。

然而，由于这些方法的先验知识通常是基于特定数据统计获得的，在不同水下环境下可能存在较大的不稳定性。例如，ULAP[22]通过计算 R 通道与 G 或 B 通道最大强度值之间的差异来估计水下场景深度，而 GDCP[21]计算图像的梯度图来识别不同区域的变化，结合颜色信息和深度图来优化水下图像的深度估计。尽管基于复原的水下图像清晰化方法在部分场景下能够有效恢复图像，但在光照复杂或水体介质变化较大的环境中，ULAP[22]和 GDCP[21]的恢复效果易受干扰，如图 5.6 中的 Raw 3、7、8 和 9 所示，恢复后的图像仍然存在严重的颜色失真或低对比度问题。

IBLA[30]采用基于光吸收和图像模糊的深度估计方法，较好地避免光照条件的影响，但其估计的传输特性受限于物体表面的光滑程度，在某些极限场景（如图 5.6 Raw 1）中恢复效果不稳定。SMBL[166]结合水下暗通道先验进行传输估计，并通过 ULAP[22]估计图像中的场景深度，相较于其他物理模型方法，SMBL[166]清晰化结果的整体亮度更高，导致丢失高像素值范围的细节信息，与 SRG-Net 相比存在某些场景下存在细节丢失的问题。

相比之下，基于深度学习的水下图像清晰化方法通过利用大规模水下数据集进行端到端的特征学习，避免基于物理模型的水下图像复原方法中参数估计导致的模型不稳定性。WaterNet[77]通过四种预处理输入（原始图像、白平衡图像、直方图均衡化图像和 Gamma 校正图像）进行增强，导致增强结果在某些场景下仍然存在较明显的色偏和亮度不足的问题。例如，在图 5.6 的 Raw 3 中，WaterNet[77]的预处理策略未能充分适应复杂的水下光照条件，使得增强后的图像整体偏暗且色彩校正不准确。由于 UWCNN[95]网络的参数较少，导致模型的特征提取能力不足，无法学习到复杂的水下退化模式，因此其增强结果通常表现为亮度较低、对比度不足的问题。

UColor[78]通过多种颜色空间处理策略改善水下图像的颜色恢复能力，但相比于 SRG-Net 引入的 Retinex 理论，其依赖的场景深度估计先验仍存在不稳定性。例如，在 Raw 3 场景中，UColor[78]生成不正确的红色色调，说明 UColor[78]方法在某些水下场景下仍存在色彩偏移的问题。UIEC^2[167]在某些场景下能够获得较为清晰的视觉效果，但与 SRG-Net 相比，其增强结果在特定情况下仍然存在色彩偏差，并且在细节保留方面存在一定不足。例如，在图 5.6 的 Raw 3 和 Raw 9 中，UIEC^2[167]仍然出现颜色不均衡和目标细节模糊的问题。相比之下，SRG-Net 在编码器部分引入多尺度场景目标提取模块，该模块能够从不同的水下场景中提取更丰富的细节信息，从而提升模型对水下环境的表征能力。

中国知网 https://www.cnki.net

得益于更精细的多尺度特征提取和深度表征学习，SRG-Net 在恢复水下场景时能够更准确地保留目标细节，并有效校正色彩偏差，使得增强后的图像在视觉一致性和细节表达方面优于 UIEC^2[167]。由于 PUIE[160]不依赖先验信息，PUIE[160]在颜色恢复方面表现出较高的鲁棒性，能够有效地减少水下环境中的色偏问题。然而，与 SRG-Net 引入的场景信息表征空间相比，PUIE[160]在对比度增强和水下场景细节恢复方面仍存在一定局限性。SRG-Net 通过结合 Retinex 理论和反射图像估计模块能够更精准地分离和增强水下图像中的场景信息，结合原始图像表征空间，从而在复杂水下环境中更稳定地提升图像的对比度，并增强场景信息的局部和全局细节表达。相比之下，PUIE[160]在某些场景下仍然存在亮度不均衡和细节模糊的问题，而 SRG-Net 在色彩恢复的基础上，提升水下图像的结构清晰度和视觉一致性，在多种水下条件下均具有更优的增强效果和更强的泛化能力。

图 5.6 中展示对比方法和 SRG-Net 在 UIEB 数据集上的 PSNR（峰值信噪比）[122]和 SSIM（结构相似性）[123]定性评估结果，SRG-Net 在所有测试图像上的数值均优于其他对比方法，表明其在恢复图像细节和全局结构方面具有更强的能力。PSNR 反映增强图像与参考图像 GT 之间的误差大小，较高的 PSNR 验证 SRG-Net 能够更准确地恢复图像中的真实信息。SSIM 主要衡量增强图像与参考图像的结构相似性，SRG-Net 在 PSNR 和 SSIM 指标上的优势表明其增强结果在保留边缘结构和图像内容一致性方面优于现有方法。

为验证 SRG-Net 在更加复杂的水下环境中的适用性，本节在 MABLs 数据集[166]上进行测试（如图 5.7）。与 UIEB 数据集相比，MABLs 数据集[166]包含更多具有挑战性的水下场景，包括绿色水域场景（图 5.7 Raw 1-2）、蓝色水域场景（图 5.7 Raw 3-4）、雾霾影响的水域场景（图 5.7 Raw 5-6）、受特殊水下介质影响的黄色水域场景（图 5.7 Raw 7-8）。

实验结果表明，在多个数据集、多个极端环境下，SRG-Net 均能实现高质量的图像增强效果，验证其在不同水下场景中的稳定性和鲁棒性。此外，为量化不同方法的增强效果，图 5.7 展示各方法在 MABLs 数据集[166]上的 CCF[128]和 CEIQ[129]指标评估结果，对各方法在单个场景下的增强性能进行评估。SRG-Net 在所有测试场景中的 CCF[128]和 CEIQ[129]数值均高于其他方法。CCF 综合衡量图像的对比度、雾霾密度和色彩信息，SRG-Net 的 CCF[128]得分较高表明其能够有效去除水下图像的雾霾效应，并提升图像的视觉清晰度。CEIQ[129]主要用于衡量增强后的图像质量，较高的 CEIQ[129]值验证 SRG-Net 在不同水下环境中的增强效果更符合人类视觉感知，能够生成更自然、清晰的图像。综合来看，客观指标的评估结果验证 SRG-Net 在水下图像清晰化任务中的有效性和鲁棒性。

中国知网 https://www.cnki.net

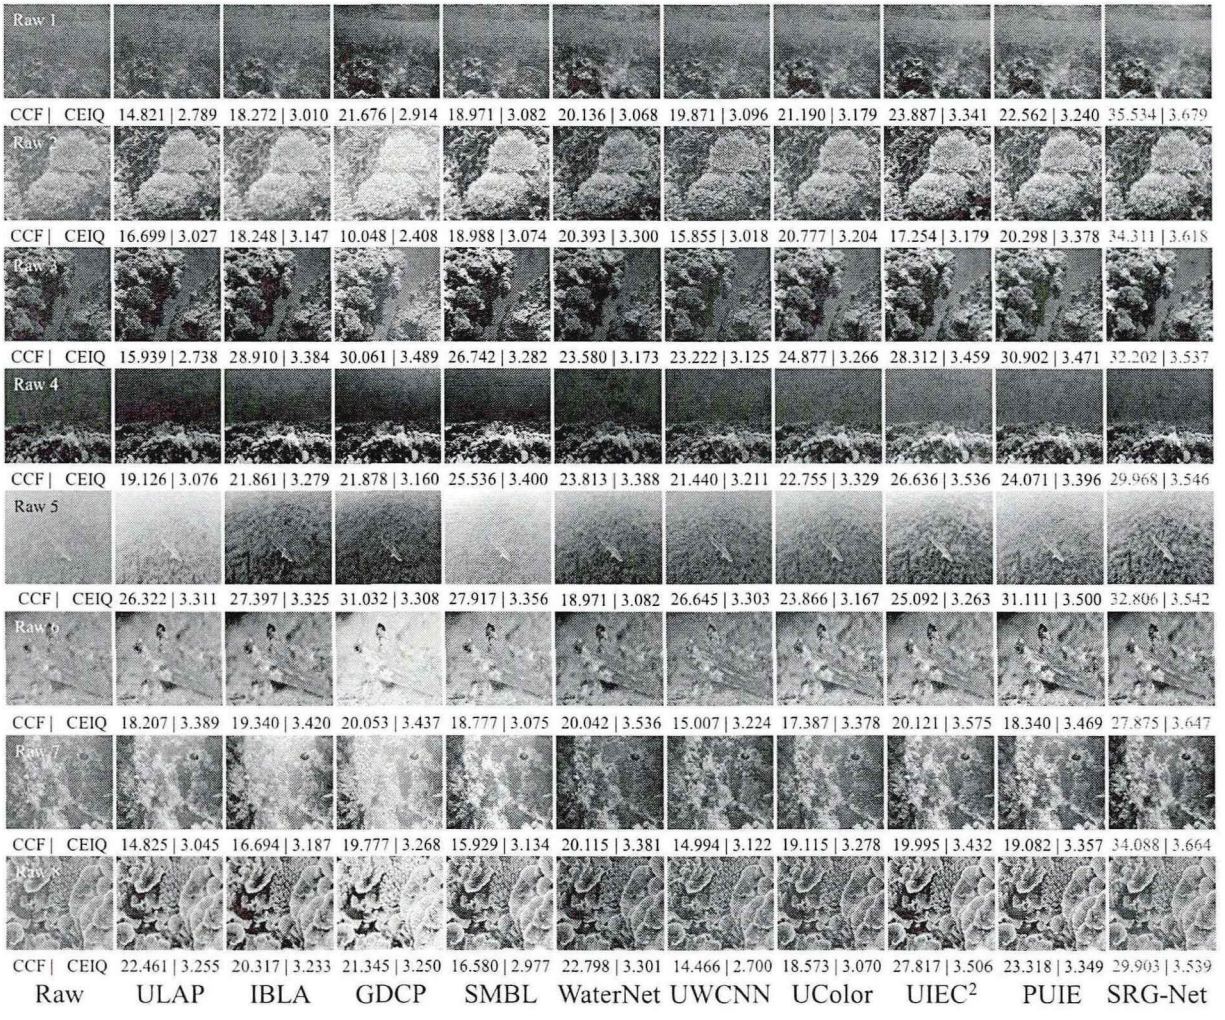

图 5.7 SRG-Net 方法与对比方法在 MABLs 数据集的主观结果

Fig. 5.7 Subjective Results of the proposed SRG-Net and Comparison Methods on the MABLs Dataset

值得注意的是，CCF 指标[128]综合考虑图像的对比度（C）、雾霾密度（F）和色彩丰富度（CF），其计算公式如下：

$$\mathrm{CCF} = w_1 \times C + w_2 \times F + w_3 \times CF \tag{5.26}$$

然而，在水下图像清晰化任务中，部分方法在恢复过程中可能会引入颜色偏差（如 ULAP[22]在图 5.6 中的结果）。因此，为避免错误恢复的颜色对评估结果的影响，本节在计算 CCF 时设定 $w_3 = 0$，即仅考虑对比度和雾霾密度两个因素，以更加准确地衡量增强方法的实际有效性。

中国知网 https://www.cnki.net

为验证 SRG-Net 的增强效果，本节采用 RGB 直方图分析方法（如图 5.8），通过比较清晰化图像与参考图像 GT 的 RGB 直方图分布，量化 SRG-Net 在色彩恢复方面的表现。

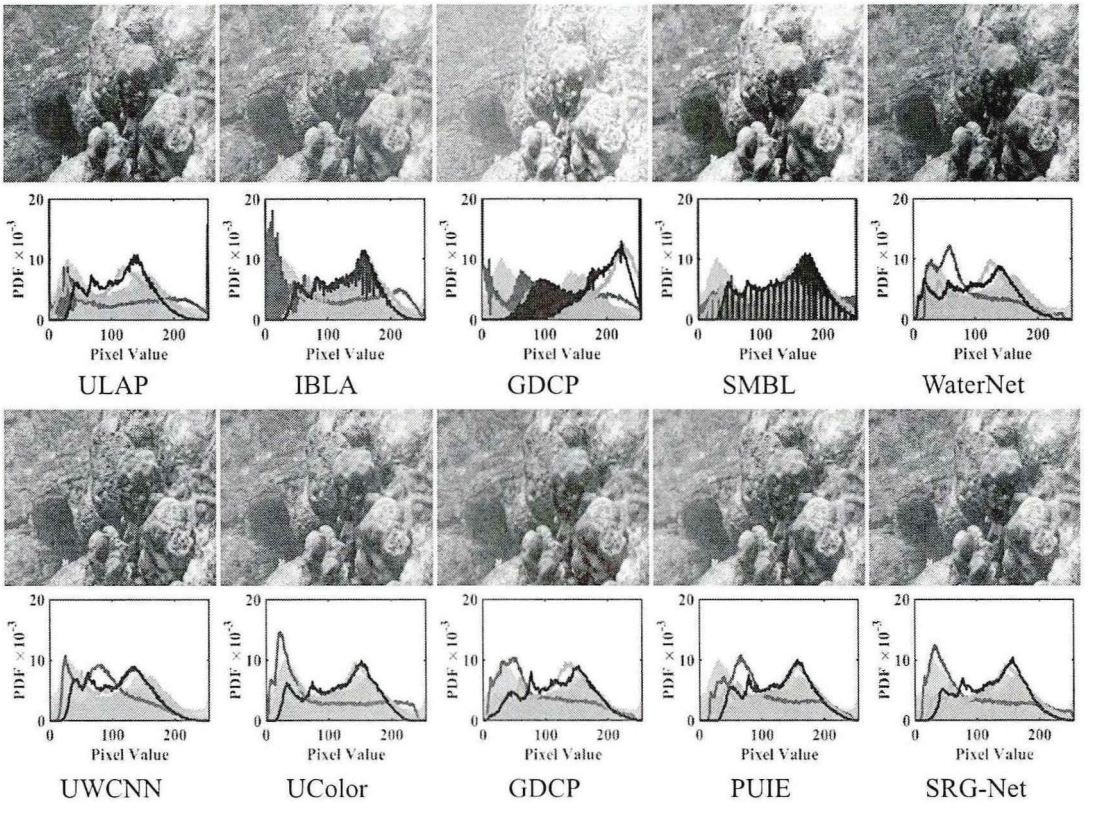

图 5.8 SRG-Net 方法与对比方法在 MABLs 数据集的直方图对比结果

Fig. 5.8 Histogram Comparison Results of the proposed SRG-Net and Comparison Methods on the MABLs Dataset

直方图中实体颜色填充部分表示参考图像的 RGB 直方图，折线部分表示上方测试图像的 RGB 直方图。相比于现有的基于物理模型的水下图像复原方法（ULAP[22]、IBLA[30]、GDCP[21]、SMBL[166]），基于深度学习的水下图像清晰化方法在 RGB 直方图分布上更接近参考图像。特别地，SRG-Net 在三个颜色通道上的峰值与趋势均最接近参考图像，表明其增强结果在色彩保真度和全局光照一致性方面均优于现有方法。实验结果验证 SRG-Net 在水下图像清晰化任务中的有效性。

综上所述，实验结果表明 SRG-Net 在多种水下场景下均展现出卓越的增强能力，并在多个客观指标和主观评估方面均优于现有方法。通过深度多表征空间学习，SRG-Net

中国知网 https://www.cnki.net

能够自适应地提取水下图像的关键特征，并结合 Retinex 理论提高色彩恢复能力，使得增强后的图像在视觉质量上更接近真实水下场景，验证本章方法的有效性和鲁棒性。

5.8.3 定量质量评价

为全面评估 SRG-Net 的水下图像清晰化效果，本节采用三种无参考图像质量评估指标（UIQM[126]、CCF[128]和 CEIQ[129]）、六种全参考图像质量评估指标（PSNR[122]、MSE[122]、SSIM[123]、VSI[124]、FSIM[125]、FSIMc[126]）进行测试和验证。

UIQM 主要衡量水下图像的清晰度、对比度和色彩保真度，CCF 结合对比度（Contrast）、雾霾密度（Fog Density）和色彩丰富度（Colorfulness）进行综合评估，CEIQ 则针对增强后图像的对比度感知质量进行测量。对于这些无参考指标而言，UIQM、CCF 和 CEIQ 的数值越高，说明增强后图像的视觉质量越好。

表 5.1 SRG-Net 与现有对比方法在 UIEB Val 数据集的无参考指标对比结果

Tab. 5.1 Comparison results of no-reference metrics between state-of-the-art methods and SRG-Net in UIEB Val dataset

	UIQM↑	CCF↑	CEIQ↑	ALL_no↑
ULAP	2.259	24.145	3.209	29.613
IBLA	2.490	23.841	3.284	29.615
GDCP	2.670	23.027	3.208	28.905
SMBL	2.543	<u>25.614</u>	3.307	<u>31.464</u>
WaterNet	2.917	20.042	3.101	26.060
UWCNN	3.011	20.360	3.090	26.461
UColor	**3.050**	21.827	3.209	28.086
UIEC^2	**3.050**	24.823	**3.388**	31.261
PUIE	3.036	23.855	3.336	30.227
SRG-Net	<u>3.039</u>	**26.223**	<u>3.379</u>	**32.641**

本节在多个水下数据集上进行测试，包括 UIEB 中 Val 验证数据集（见表 5.1 和表 5.2）、具有挑战性的无参考测试集（共 60 张水下图像，见表 5.3）、MABLs[166]（见表 5.4）数据集和 U45[156]（见表 5.5）数据集。其中除 UIEB 中验证数据集外均无参考图像，因此仅在 UIEB Val 数据集中进行全参考指标评价，其余数据集没有提供参考图像，只使用无参考图像评价指标进行对比。

为更全面综合评价，本节提出综合评价指标 ALL_no 和 ALL_f，其中指标 ALL_no 为无参考的图像指标集合，指标 ALL_f 用于有参考图像 GT 的数据集 UIEB，具体的计算公式如下：

中国知网 https://www.cnki.net

$$ALL_no = UIQM+CCF+CEIQ \tag{5.27}$$

$$ALL_f = PSNR-MSE+SSIM+VSI+FSIM+FSIMc \tag{5.28}$$

其中 ALL_no 和 ALL_f 指标带有越大越好的指标被赋予系数 1，而对于越小越好的指标被赋予系数-1，并据此计算不同方法的整体得分，从而提供一个全方位的性能评估方法。

根据表 5.1 的数据，在 UIEB 验证集中，UColor[78]在 UIQM 指标[126]上的得分高于 SRG-Net。然而，UColor[78]受到基于 GDCP[21]物理模型的限制，导致在图 5.6 的 Raw 3 场景中错误地恢复前景区域的红色成分。尽管这一错误的色彩增强提高 UIQM 指标得分，但实际上并未真实提升图像的质量，反而引入额外的色彩失真问题。相比之下，SRG-Net 采用 Retinex 理论进行光照校正，并结合多尺度场景目标提取模块进行多尺度特征增强，使得其增强结果在色彩保真度和全局光照一致性方面更具稳定性和鲁棒性。

表 5.2 SRG-Net 与现有对比方法在 UIEB Val 数据集的全参考指标的对比结果

Tab. 5.2 Comparison results of full-reference metrics between state-of-the-art methods and SRG-Net in UIEB Val dataset

	PSNR	MSE	SSIM	VSI	FSIM	FSIMc	ALL_f↑
ULAP	15.913	0.174	0.745	0.947	0.915	0.878	19.224
IBLA	17.988	0.143	0.805	0.958	0.928	0.899	21.435
GDCP	13.386	0.228	0.747	0.943	0.901	0.865	16.614
SMBL	16.597	0.160	0.795	0.960	0.921	0.897	20.010
WaterNet	17.349	0.144	0.813	0.966	0.908	0.899	20.791
UWCNN	17.985	0.134	0.844	0.966	0.923	0.903	21.487
UColor	20.962	0.097	0.864	0.971	0.931	0.920	24.551
$UIEC^2$	22.830	0.079	0.903	0.979	0.953	0.943	26.529
PUIE	22.133	0.082	0.895	0.979	0.954	0.944	25.823
SRG-Net	**23.622**	**0.075**	**0.922**	**0.984**	**0.968**	**0.958**	**27.379**

此外，表 5.1 中 $UIEC^2$[167]在 CEIQ[129]评估指标上取得较高的分数，表明其在对比度失真的图像清晰化方面具有一定的优势。然而，在更全面地考察多种图像特性（如色彩偏移、目标细节和场景结构表示）后，SRG-Net 仍然能够在多个关键指标上保持更优的整体表现。例如，在图 5.6 的 Raw 3 和 Raw 9 场景中，$UIEC^2$[167]仍然存在色彩偏移问题，而 SRG-Net 能够更全面地解决水下图像清晰化中的各种挑战，包括色彩偏移校正、细节增强、场景结构的精确恢复。

表 5.2 展示 SRG-Net 方法与其他对比方法在 UIEB 验证集上的全参考质量评估指标结果。实验结果表明，SRG-Net 在所有全参考评价指标上均取得最优表现，充分验证 SRG-

中国知网 https://www.cnki.net

Net 在水下图像清晰化任务中的有效性。相比于现有的水下图像清晰化方法，SRG-Net 基于 Retinex 理论提取场景表征空间，结合原始图像表征空间进行多表征空间学习，更精确地恢复水下图像的场景结构、对比度和细节信息，使得清晰化的图像在视觉质量上更接近真实水下场景。

表 5.3 SRG-Net 与现有对比方法在 UIEB Test 数据集的无参考指标对比结果

Tab. 5.3 Comparison results of no-reference metrics between state-of-the-art methods and SRG-Net in UIEB Test dataset

	UIQM↑	CCF↑	CEIQ↑	ALL_no↑
ULAP	1.511	16.726	2.784	21.021
IBLA	1.834	20.250	3.180	25.264
GDCP	2.110	18.573	3.121	23.804
SMBL	1.904	20.206	3.142	25.252
WaterNet	2.399	16.279	2.983	21.661
UWCNN	2.514	14.996	2.836	20.346
UColor	2.481	16.826	3.053	22.360
UIEC^2	2.588	20.395	**3.340**	26.323
PUIE	2.548	19.009	3.249	24.806
SRG-Net	**2.754**	**20.650**	3.202	**26.606**

表 5.4 SRG-Net 与现有对比方法在 MABLs 数据集的无参考指标对比结果

Tab. 5.4 Comparison results of no-reference metrics between state-of-the-art methods and SRG-Net in MABLs dataset

	UIQM↑	CCF↑	CEIQ↑	ALL_no↑
ULAP	2.200	20.045	3.025	25.270
IBLA	2.233	20.662	3.124	26.019
GDCP	2.437	21.477	3.151	27.065
SMBL	2.238	22.725	3.166	28.129
WaterNet	2.795	19.616	3.111	25.522
UWCNN	2.902	18.427	3.001	24.330
UColor	2.879	19.788	3.142	25.809
UIEC^2	2.830	22.923	3.331	29.084
PUIE	**2.940**	21.847	3.266	28.053
SRG-Net	2.871	**22.998**	**3.270**	**29.139**

中国知网 https://www.cnki.net

根据表 5.1 的数据，在 UIEB 验证集中，UColor[78]在 UIQM 指标[126]上的得分高于 SRG-Net。然而在图 5.6 的 Raw 3 场景中错误地恢复前景区域的红色成分，导致 UIQM 错误的提高。相比之下，SRG-Net 采用 Retinex 理论进行光照校正，并结合多尺度场景目标提取模块进行多尺度特征增强，使得其增强结果在色彩保真度和全局光照一致性方面更具稳定性和鲁棒性。

因此，仅依赖单一指标进行评估可能会存在偏差，本节基于全参考和无参考中的各项指标，通过加权计算 ALL_no 和 ALL_f 综合评分，以更加全面地衡量各水下图像清晰化方法的整体增强效果。从表 5.1 到表 5.5 中综合指标来看，SRG-Net 在 UIEB Val、UIEB Test、MABLs 数据集中均取得最高的 ALL_no 或 ALL_f 综合评分，指标结果表明 SRG-Net 在色彩恢复、对比度增强和图像细节保留等方面均优于其他水下图像清晰化方法，验证 SRG-Net 的有效性、鲁棒性，可以泛化应用在未参与训练的数据集。

表 5.5 SRG-Net 与现有对比方法在 U45 数据集的无参考指标对比结果

Tab. 5.5 Comparison results of no-reference metrics between state-of-the-art methods and SRG-Net in U45 dataset

	UIQM ↑	CCF ↑	CEIQ ↑	ALL_no ↑
ULAP	2.282	22.069	3.192	27.543
IBLA	2.388	21.598	3.249	27.235
GDCP	2.275	22.736	3.191	28.202
SMBL	2.388	21.598	3.249	27.235
WaterNet	2.957	20.391	3.186	26.534
UWCNN	3.064	21.418	3.213	27.695
UColor	<u>3.148</u>	22.100	3.283	28.531
UIEC^2	3.125	<u>24.791</u>	**3.437**	<u>31.353</u>
PUIE	**3.192**	23.154	3.359	29.705
SRG-Net	3.109	**25.534**	<u>3.426</u>	**32.069**

5.8.4 模型组件有效性评估

为验证 SRG-Net 各个关键模块的有效性，本节进行系统性的消融实验，采用六种全参考质量评估指标（PSNR、MSE、SSIM、VSI、FSIM、FSIMc）进行量化分析。其中，PSNR、SSIM、VSI、FSIM 和 FSIMc 的值越高，表明增强后图像质量越优，而 MSE 值越低则表明恢复误差越小。此外，通过计算 ALL_f 综合评分，通过在每个质量评估指标前添加不同的权重系数，衡量整体增强效果。

中国知网 https://www.cnki.net

在消融实验中，针对 SRG-Net 的网络结构、内部模块和损失函数进行消融实验分析，具体实验设置如下：

1) SRG-Net 结构消融实验：分别移除或替换 MSTE（多尺度场景目标提取模块）、CSMLI（基于上下文信息的多级集成模块）和反射分量编码器（Reflectance Encoder），以验证这些模块在特征提取和增强恢复中的重要性（表 5.6）。

2) 模块内部消融实验：探究 MSTE 和 CSMLI 内部的卷积结构、注意力机制和上采样策略对水下图像清晰化效果的影响（表 5.7）。

3) 损失函数消融实验：分析 $smooth_{L1}$ 损失函数与感知损失 L_{VGG} 的作用，探究不同损失函数对清晰化效果的影响（表 5.8）。

表 5.6 SRG-Net 网络结构消融实验的全参考指标对比结果

Tab. 5.6 Comparison results of full-reference metrics of ablation experiments on the network architecture of SRG-Net

	PSNR	MSE	SSIM	VSI	FSIM	FSIMc	ALL_f↑
RP MSTE	22.868	0.078	0.915	0.982	0.965	0.954	26.606
RP CSMLI	22.628	0.079	0.913	0.982	0.964	0.954	26.362
RP RF	22.587	0.084	0.905	0.980	0.959	0.948	26.295
WO RF	22.428	0.085	0.901	0.979	0.956	0.945	26.124
SRG-Net	**23.622**	**0.075**	**0.922**	**0.984**	**0.968**	**0.958**	**27.379**

图 5.9 展示 SRG-Net 网络架构的消融实验结果，从左到右分别为：(a) 原始图像，(b) 替换 MSTE，(c) 替换 CSMLI，(d) 替换反射图像编码器，(e) 去除反射图像编码器，(f) SRG-Net，(g) 真实图像（GT）。表 5.6 给出客观评估指标。当移除 MSTE 和 CSMLI 时，网络的增强能力显著下降，验证 MSTE 和 CSMLI 模块在潜在特征提取和特征恢复过程中起到关键作用（如 Raw 3 场景的细节丢失）。此外，当直接移除反射图像编码器时，虽然网络参数量有所减少，但从图 5.9 可显看出，增强后的水下图像在颜色校正和细节恢复方面均出现严重的退化，验证 Retinex 先验信息的引入对于恢复水下场景信息至关重要。

此外，本节将反射率分量替换为原始图像（RP RF），实验结果表明，替换为原始图像降低网络对光照分量和场景信息的建模能力，导致增强后的图像在色彩分布和细节表达方面存在明显损失。相比于移除或替换 SRG-Net 的关键模块，完整的 SRG-Net 方法清晰化后的图像更接近于真实场景，验证 SRG-Net 的整体架构的有效性，体现在水下图像清晰化任务中的有效性。

中国知网 https://www.cnki.net

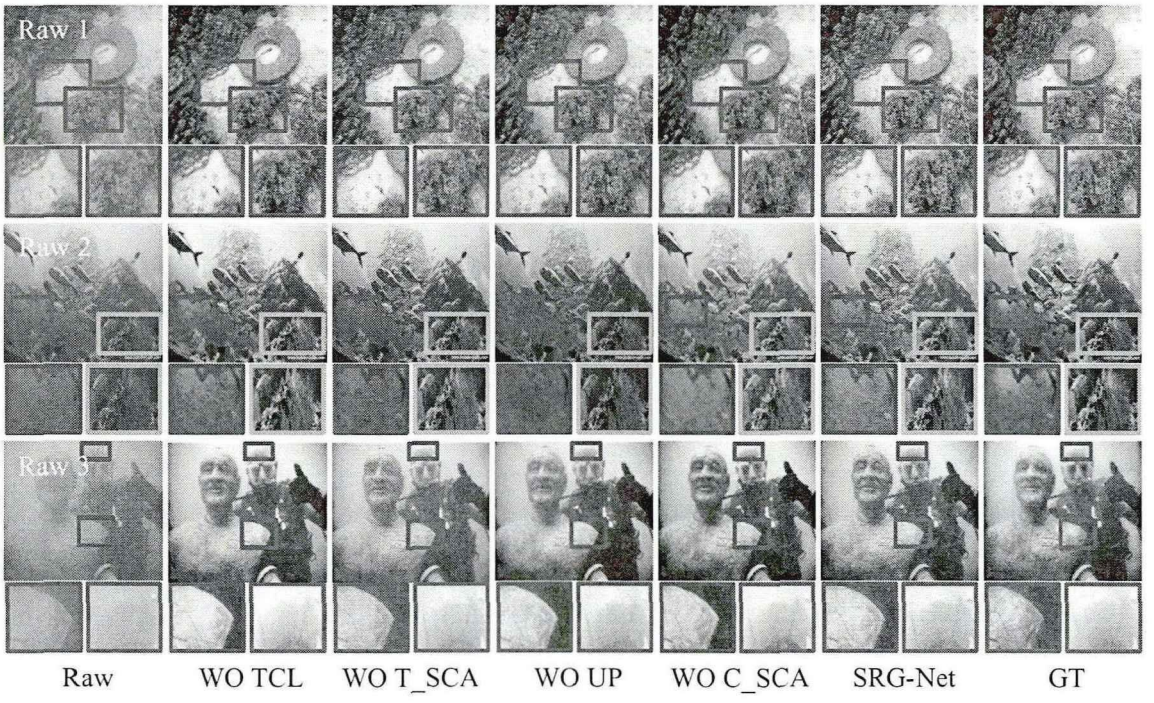

图 5.9 SRG-Net 网络架构消融实验的对比结果

Fig. 5.9 The comparison results of ablation experiments on the network architecture of SRG-Net

表 5.7 和图 5.10 展示 SRG-Net 模块内部的消融实验结果。图 5.10 从左到右分别为：(a) 原始图像，(b) 去除 TriFuse 多尺度卷积层，(c) 去除 MSTE 中的 SCA 机制，(d)去除上采样中的卷积和 PixelShuffle 分支，(e) 去除 CSMLI 中的 SCA 机制，(f) SRG-Net，(g) 真实图像 GT。在该实验中：

1) 移除 MSTE 中的 TriFuse 多尺度卷积层（WO TCL），实验结果表明，在 Raw 3 场景中，去除 TriFuse 结构后，整体图像虽然亮度较高，但缺乏细节信息，特别是在紫色框中的字母区域，其清晰度明显下降。

2) 移除 MSTE 和 CSMLI 中的注意力机制（WO T_SCA 和 WO C_SCA），结果显示，网络无法准确提取细节信息，例如帽子上的字母信息变得模糊，验证注意力机制对特征表达的优化作用。

3) 移除 CSMLI 中的上采样卷积和 PixelShuffle（WO UP），实验结果表明，在图 10 的 Raw 2 和 Raw 3 场景中，增强图像出现明显的伪影（蓝色和绿色的色块），说明上采样分支在恢复高质量特征信息中起到重要作用。通过表 5.7 中的定性实验结果表明，

中国知网 https://www.cnki.net

在移除 CSMLI 的上采样卷积和 PixelShuffle 后，PSNR 下降明显，验证其在像素级的细节重建和结构信息恢复有重要作用。

表 5.7 SRG-Net 各模块消融实验的全参考指标对比结果

Tab. 5.7 Comparison results of full-reference metrics of ablation experiments on the module of SRG-Net

	PSNR	MSE	SSIM	VSI	FSIM	FSIMc	ALL_f↑
WO TCL	23.311	0.076	0.919	0.983	0.966	0.957	27.060
WO T_SCA	23.284	0.078	0.916	0.984	0.967	0.958	27.031
WO UP	23.215	0.078	0.919	0.983	0.967	0.957	26.963
WO C_SCA	23.301	0.077	0.916	0.982	0.965	0.955	27.042
SRG-Net	**23.622**	**0.075**	**0.922**	**0.984**	**0.968**	**0.958**	**27.379**

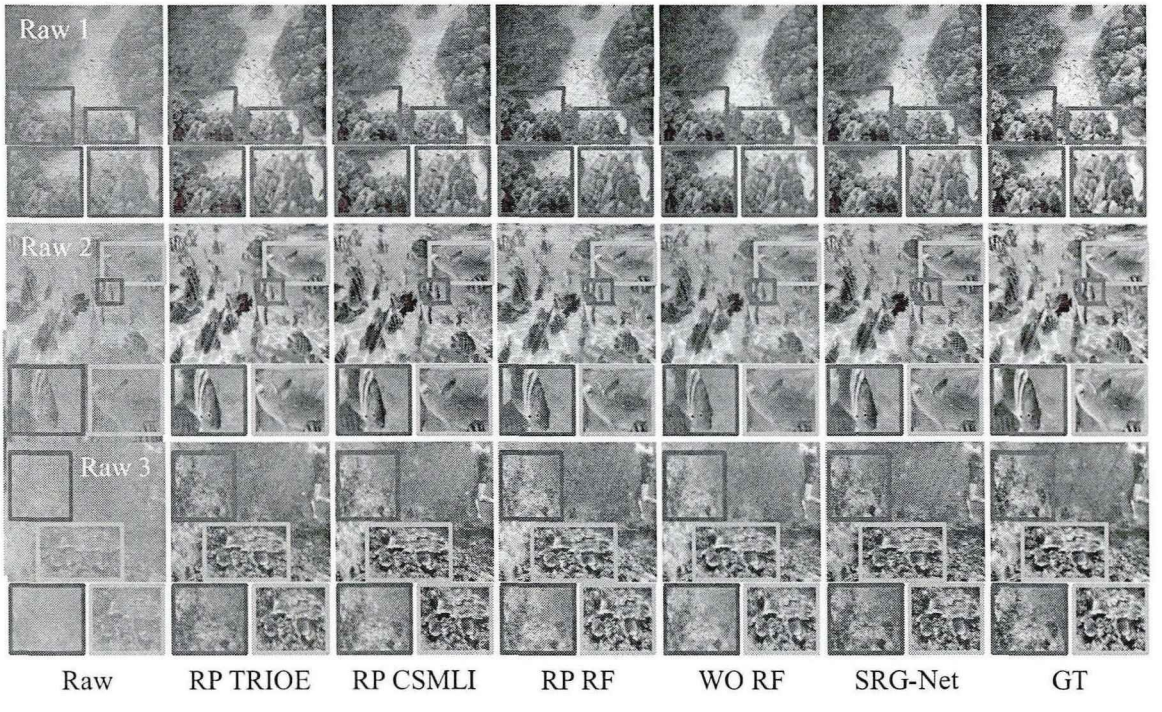

图 5.10 SRG-Net 模块内部的消融实验对比结果

Fig. 5.10 The comparison results of ablation experiments on the internal modules in SRG-Net

综上所述，MSTE 和 CSMLI 通过多尺度特征提取、注意力增强以及高质量特征恢复在 SRG-Net 网络中发挥关键作用，验证本章所设计模块的有效性与合理性。

表 5.8 展示本章所用的不同损失函数对 SRG-Net 增强效果的作用，实验结果表明移除 $smooth_{L1}$ 或 L_{VGG} 感知损失均会影响网络的性能：

中国知网 https://www.cnki.net

1) 仅使用 $smooth_{L1}$ 损失函数时，PSNR 和 SSIM 指标明显下降。$smooth_{L1}$ 主要关注像素级精度，但忽略图像的感知一致性，会导致增强后的图像在像素值上接近原始图像，但缺乏真实水下场景的视觉特征和细节信息。

2) 仅使用感知损失 L_{VGG} 时，在像素级精度和对比度恢复方面有所下降（MSE 值显著增大）。仅依赖感知损失 L_{VGG} 可能会导致像素级细节丢失，进而影响整体的图像清晰化效果。

表 5.8 SRG-Net 各损失函数消融实验的全参考指标对比结果

Tab. 5.8 Comparison results of full-reference metrics of ablation experiments on the loss functions of SRG-Net

	PSNR↑	MSE↓	SSIM↑	VSI↑	FSIM↑	FSIMc↑	ALL_f↑
$smooth_{L1}$	23.001	0.078	0.909	0.981	0.961	0.950	26.724
L_{VGG}	22.091	0.087	0.910	0.982	0.965	0.954	25.815
ALL	**23.622**	**0.075**	**0.922**	**0.984**	**0.968**	**0.958**	**27.379**

实验结果表明，SRG-Net 的多尺度场景目标提取模块、基于上下文信息的多级集成模块、Retinex 先验信息及注意力机制在水下图像清晰化任务中均发挥关键作用。完整的 SRG-Net 结构能够更准确地恢复水下图像的色彩信息、对比度和细节，并显著提高增强图像的视觉质量。

5.8.5 效率分析

为验证 SRG-Net 方法在实时性和计算效率方面的优越性，本节对比分析 SRG-Net 与现有的主流方法的模型参数规模（Model Parameters）、推理时间（Inference Time）、图像质量评估指标，结果如表 5.9 所示。此外，为直观展示实时性能与整体增强效果之间的关系，本节引入综合评分（ALL），其定义如下：

$$\text{ALL} = \text{ALL_f}+\text{ALL_no-Time} \tag{5.29}$$

综合评分 ALL 在考虑增强方法的图像质量提升能力和推理速度，提供更为全面的综合评价标准。

尽管 SRG-Net 在推理速度方面未达到最快，但其在多个评估指标上均取得优越的表现，充分验证其在水下图像清晰化任务中的有效性。通过综合考虑水下图像清晰化方法的恢复质量和推理速度，SRG-Net 取得较高的综合评分，验证其在推理速度与增强质量之间达到最好的平衡。

中国知网 https://www.cnki.net

表 5.9 SRG-Net 与现有对比方法的模型参数、推理时间和评测指标对比结果

Tab. 5.9 Comparison results of model parameters, inference time, and metrics between state-of-the-art methods and SRG-Net

	Params(M)↓	Time(s)↓	PSNR↑	MSE↓	SSIM↑	ALL↑
ULAP	-	0.358	15.913	0.174	0.745	16.126
IBLA	-	9.134	17.988	0.143	0.805	9.516
GDCP	-	0.163	13.386	0.228	0.747	13.742
SMBL	-	3.070	16.597	0.160	0.795	14.162
WaterNet	1.100	0.091	17.349	0.144	0.813	17.927
UWCNN	**0.039**	0.050	17.985	0.134	0.844	18.645
UColor	148	0.576	20.962	0.097	0.864	21.153
UIEC^2	0.522	0.041	22.830	0.079	0.903	23.613
PUIE	1.400	**0.018**	22.133	0.082	0.895	22.928
SRG-Net	6.300	0.020	**23.622**	**0.075**	**0.922**	**24.449**

通过综合评分 ALL 验证 SRG-Net 可以用于实际应用场景，例如水下目标检测、水下机器人导航、无人潜航器（AUV）视觉系统等，具备广泛的适用性和工程价值。

5.9 显著性目标测试

为验证 SRG-Net 在实际应用中的可行性，采用 SVAM 方法[167]进行显著性目标检测测试，测试结果如图 5.11 所示。SVAM 通过整合水下图像中的多种语义和多尺度视觉特征检测显著目标。

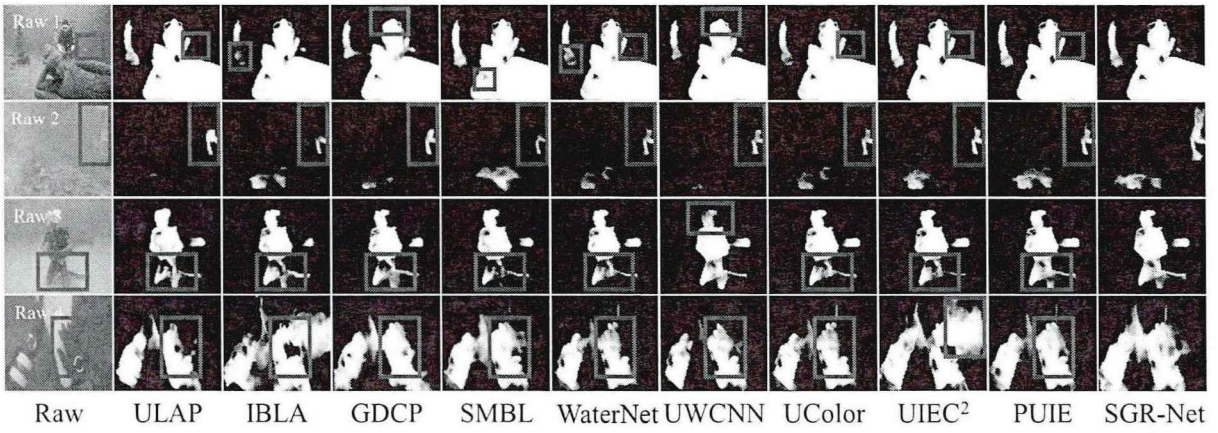

图 5.11 SRG-Net 方法与对比方法在 MABLs 数据集的直方图对比结果

Fig. 5.11 Histogram comparison results of the proposed SRG-Net and comparison methods on the MABLs dataset

中国知网 https://www.cnki.net

SRG-Net 结合 Retinex 理论来引导网络的增强方向，在场景目标信息提取方面较其他方法更具优势。如图 5.11 中红色框所示，SRG-Net 显著提升水下目标检测的准确性。例如，在图 5.11 中 Raw 1 场景中，SRG-Net 能够更清晰地检测到小型鱼类，在 Raw 2 和 Raw 3 中准确检测到潜水员，而在 Raw 4 中能够精确识别潜水员的手指形状。

Retinex 理论的引导与多表征空间学习机制使得 SRG-Net 在水下目标检测任务中取得最好的结果。不同于现有的水下图像清晰化方法，SRG-Net 采用原始图像与反射图像的双输入策略，并在编码器部分引入多尺度场景目标提取模块，以对两种输入的多尺度特征进行有效编码。通过这种方式，SRG-Net 能够更全面地恢复水下场景信息，使得后续的高级视觉任务（如目标检测、目标跟踪和语义分割）更容易捕获关键目标特征。这种跨表征空间融合方法不仅提升图像的对比度和结构信息，优化视觉感知一致性，使得水下目标在特征空间中的分离性更强，进而有效提升目标检测的准确率。

5.10 本章小结

本章提出的 SRG-Net 以水下原始图像和反射图像作为双输入，结合 Retinex 理论与 UNet 结构，在增强过程中充分利用反射图像编码器进行特征建模。针对水下图像的多尺度目标信息提取问题，本章在编码器部分提出多尺度场景目标提取模块，能够在多个尺度上高效提取物体信息，以提升水下图像的清晰度与对比度。编码器能够精准捕获恢复图像的潜在特征向量，并通过解码器中的基于上下文信息的多级集成模块实现高效的信息解码。基于上下文信息的多级集成模块通过结合上采样与注意力机制，不仅能有效减少伪影，还能够在恢复过程中精准重建像素级信息。该模块融合原始图像特征及反射分量特征，利用注意力机制优化特征表达，从而实现更稳定、清晰的水下图像清晰化。

实验结果表明，SRG-Net 与代表性方法相比在全参考指标提升 3.2%，在去除水下图像色偏、提高图像质量方面具有显著优势。SRG-Net 均明显优于当前主流水下图像清晰化方法，验证其在多种复杂水下场景下的有效性和鲁棒性。此外，消融实验证实 SRG-Net 的网络架构及各个关键模块在提升增强效果方面的重要贡献，说明多尺度场景目标提取模块、Retinex 先验信息建模、基于上下文信息的多级集成模块对水下图像的恢复质量起到关键作用。本章采用 SVAM 方法进行水下目标检测的高级视觉任务实验，展示 SRG-Net 在高级视觉任务（如水下目标检测、目标跟踪、语义分割等）中的应用潜力，验证其在水下计算机视觉任务中的广泛适用性。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

6 基于跨帧表征对齐的水下序列图像清晰化方法

水下图像常因复杂的光照散射、吸收效应及悬浮颗粒干扰呈现出颜色偏移、对比度下降和模糊等清晰化问题[168]，严重制约目标检测、场景理解等高层视觉任务的性能[169]。水下序列图像常受到水体扰动、相机抖动、目标运动等流变扰动的共同作用，导致帧间结构错位、运动模糊及时序信息失配等问题。现有方法难以适应水下动态场景中偏移、运动模糊等复杂退化模式，未充分建模动态流变扰动下的帧间结构错位信息，对时序信息的利用不足，且在计算效率上面临显著挑战。

针对上述问题，本章提出基于跨帧表征对齐的水下序列图像清晰化方法（Cross-Frame Representation Alignment for Underwater Image Sequence Clarification Method, CFRA-Net），旨在通过多帧时序信息的协同优化提升增强鲁棒性。该方法的核心是提出自适应跨帧特征对齐模块，利用可变形卷积动态调整多帧特征的空间对齐方式，有效缓解运动模糊与偏移带来的信息错位。设计基于时空特征优化注意力机制，通过通道与空间维度的联合优化增强跨帧特征的互补性与细节保留能力。在网络架构层面，结合编解码结构与多尺度特征融合策略，从全局光照分布到局部纹理信息进行分层恢复，并通过混合损失函数平衡像素级精度与语义级一致性。

6.1 CFRA-Net 方法提出

水下序列图像在动态环境下易受到相机抖动、目标运动与水体扰动的共同影响，其本质机制为空间流变失准与时序信息失配的叠加耦合。现有增强方法缺乏对时空结构协同变形规律与跨帧语义一致性保持机制的深入建模，导致图像清晰化存在模糊、错位与跳帧等问题。因此亟需研究动态水下场景中流变运动的形成规律与跨帧语义结构约束机制，以支撑鲁棒的视频图像增强方法构建。

为提高水下图像清晰化的稳定性和适应性，利用水下序列图像的时序信息，进行跨帧特征对齐和时空协同优化，是突破当前水下图像清晰化瓶颈的关键。基于此，本章针对基于跨帧表征对齐的水下序列图像清晰化方法开展研究，网络架构图如图 6.1 所示，通过可变形卷积进行跨帧动态特征对齐，并结合基于时空特征优化注意力优化时序信息融合，使得增强结果在多个时间帧之间保持一致性，减少运动伪影，提升水下序列图像的清晰度与稳定性。

基于跨帧表征对齐的水下序列图像清晰化方法主要包括以下四个关键组成部分：自适应跨帧特征对齐方法（Feature Alignment）、多尺度特征提取方法（Feature Extraction）、时空特征优化方法（Feature Refinement）、多尺度特征恢复方法（Feature Restoration）。

中国知网 https://www.cnki.net

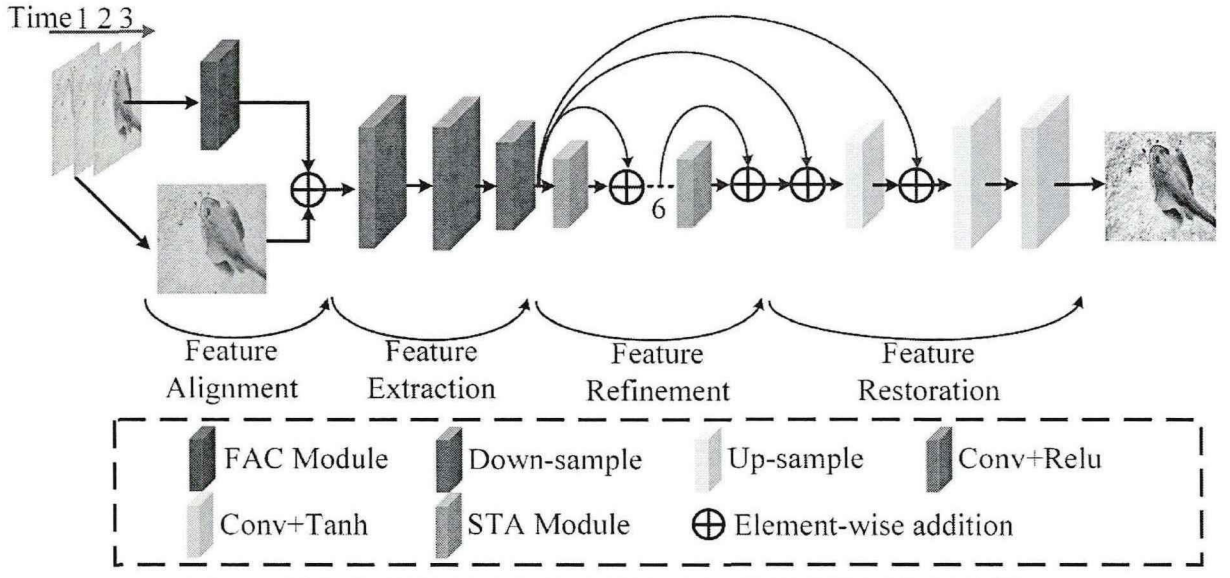

图 6.1 基于跨帧表征对齐的水下序列图像清晰化网络架构图

Fig. 6.1 Framework diagram of cross-frame representation alignment for underwater image sequence clarification

自适应跨帧特征对齐模块旨在实现跨时间域不同帧之间的特征对齐，以充分挖掘时间序列中的局部与全局表征信息，增强网络对跨帧信息的建模能力。考虑到水下图像的退化过程通常具有较强的时间相关性，合理的特征对齐不仅有助于缓解由于相机抖动、水体扰动或目标运动引起的运动模糊，提升跨帧特征融合的稳定性与一致性，从而有效增强动态场景下的图像清晰化效果。

由于水下环境的光学衰减具有显著的频率依赖性，而单一尺度的特征提取难以全面表征图像中的细节与结构信息，本章设计多尺度自适应表征提取模块，以充分捕获图像在不同尺度下的深层表征信息，该模块通过多层卷积提取不同感受野范围内的特征，从而提高网络对复杂退化模式的鲁棒性。

在特征提取的基础上，设计时空特征优化模块，该模块包含八个时空特征优化（Spatio-Temporal Attention, STA）模块。对提取的特征进行细粒度增强，其中通道注意力不仅用于衡量不同通道的重要性，还特别针对跨帧的融合信息进行动态加权，从而提升不同帧间的特征一致性和互补性。此外，空间注意力通过自适应调整各像素点的权重，有助于增强局部结构信息的保真度。通过结合这两种注意力机制，基于时空特征优化注意力模块能够更精准地保留重要的跨帧表征信息，并有效抑制无关噪声，从而提升水下图像的增强效果。

中国知网 https://www.cnki.net

多尺度特征恢复模块利用从特征提取模块获取的多尺度特征，实现水下清晰图像的高质量重建。该模块通过跳跃连接保留底层特征信息，结合高级特征进行逐步恢复，从而提升序列图像的细节保真度。

6.2 自适应跨帧特征对齐方法设计

典型的水下成像模型可表示为：

$$I(x,\lambda)=J(x,\lambda)T(x,\lambda)+A(1-T(x,\lambda)) \tag{6.1}$$

其中 $I(x,\lambda)$ 表示 λ 通道 x 索引位置水下图像像素值，$\lambda\in\{R,G,B\}$，$J(x,\lambda)$ 表示清晰图像在 λ 通道 x 索引位置的像素值，$T(x,\lambda)=e^{-\beta_\lambda d(x)}$ 为透射率，其中 β_λ 是介质衰减系数，$d(x)$ 表示 x 索引位置的场景深度，A 表示背景光，$A(1-T(x,\lambda))$ 代表后向散射分量。

由于跨帧序列图像之间的物理位移，同一物体在不同帧中的像素点坐标存在较大差异，且图像中的动态目标（如鱼类）也会发生移动。现有卷积通常依赖固定感受野来适应物体的形变，而缺乏灵活的空间变换能力，难以直接适用于跨帧特征对齐。为解决这一问题，本章提出自适应跨帧特征对齐方法，该方法基于可变形卷积灵活调整感受野以适应不同帧图像间的特征差异。

可变形卷积的关键在于利用偏移量（offset）进行自适应感受野调整，具体计算方式如下：

$$O=\mathrm{Conv}_{3\times3}(I) \tag{6.2}$$

其中，O 为偏移量映射，$\mathrm{Conv}_{3\times3}$ 表示 3×3 的标准卷积操作。通过偏移量调整，可变形卷积能够灵活地进行空间偏移，使整个卷积运算等效于流变空间变换。

此外，可变形卷积的掩码（mask）计算如下：

$$M=2\times\sigma(\mathrm{Conv}_{3\times3}(I)) \tag{6.3}$$

其中，σ 表示 Sigmoid 激活函数，$I=Cat(I_t,I_{t-1},I_{t+1})$，$I\in\mathbb{R}^{B\times3C\times H\times W}$，Cat 代表特征拼接操作，本章中根据通道维度进行拼接，B 代表网络的批次大小（batch size），C 代表输入特征的通道数，在本章中选定 C=3，每张输入图像包含 RGB 三个通道。H 和 W 分别表示输入图像的高度和宽度。M 为像素级动态权重，用于增强重要特征并抑制无关信息。

基于上述偏移量与掩码，采用以下可变形卷积操作进行特征对齐：

$$F_1=\mathrm{DConv}\left(I,\ O,\ M\right) \tag{6.4}$$

中国知网 https://www.cnki.net

其中 DConv 代表可变形卷积操作，F_1 为经过特征对齐的输出特征，$F_1 \in \mathbb{R}^{B\times C\times H\times W}$。

本章提出的自适应跨帧特征对齐模块能够为目标帧提供跨帧的特征信息，有助于后续特征提取与复原过程的优化，在特征学习过程中构建一致表征信息，提高特征对齐的准确性。跨帧特征可能受到视角变化、运动模糊及流变失准的影响，而目标帧提供结构完整的先验信息，使得网络能够进行更有效的特征补偿与校正。因此为优化目标帧的特征学习，将对齐后的目标帧特征输入后续网络，具体计算如下：

$$F_2 = F_1 + I_t \tag{6.5}$$

其中，+代表像素级逐点加法操作，$F_2 \in \mathbb{R}^{B\times C/3\times H\times W}$。

在特征学习过程中，目标帧的加入可以增强网络的对比学习能力，能够在多帧表征信息之间建立更为稳健的对齐机制，提高最终图像的清晰化质量。

6.3 多尺度特征提取方法设计

在自适应跨帧特征对齐模块中，跨帧图像的特征已实现有效对齐，并与目标帧的特征进行融合。在此基础上，特征提取模块旨在提取和学习跨帧增强特征，以恢复高质量的目标帧图像。受到 UNet 结构的启发，采用编解码结构，过逐层压缩和上采样的方式实现特征的逐级提取与还原。该结构已在多项水下图像清晰化任务中表现出优越的性能，具备良好的特征表达能力和结构恢复能力，适用于处理图像退化复杂、语义结构丰富的水下动态场景。

为充分利用跨帧表征信息，设计多尺度特征提取方法，用于在特征空间内高效提取丰富的局部与全局表征信息。在特征提取过程中，利用标准卷积提取原始尺寸的图像特征：

$$F_2^1 = \mathrm{GeLU}(\mathrm{Conv}_{7\times 7}(F_2)) \tag{6.6}$$

其中，$\mathrm{Conv}_{7\times 7}$ 代表一个核大小为 7×7 的卷积操作，F_2^1 代表提取的初始特征，$F_2^1 \in \mathbb{R}^{B\times 64\times H\times W}$，GeLU 表示 GeLU 激活函数。

为提升特征表示能力，在特征提取模块中使用不同尺度的卷积操作，以增强多尺度信息的融合和学习能力。相比于现有方法仅依赖单尺度特征，本方法通过多尺度特征学习策略，在不同空间分辨率下提取全局与局部信息，在特征提取模块采用两次下采样操作，以提高特征表达的鲁棒性和泛化能力，公式如下：

$$F_2 = \mathrm{ReLU}(\mathrm{Conv}_{3\times 3,2}(F_2^1)) \tag{6.7}$$

中国知网 https://www.cnki.net

$$F_3 = \mathrm{ReLU}(\mathrm{Conv}_{3\times3,2}(F_2)) \tag{6.8}$$

其中，$\mathrm{Conv}_{3\times3,2}$代表步长为 2 的 3×3 卷积操作，$F_2$ 代表下采样后尺寸减半的特征图，$F_2 \in \mathbb{R}^{B\times128\times\frac{H}{2}\times\frac{W}{2}}$，$F_3$ 代表二次下采样后的特征图，$F_3 \in \mathbb{R}^{B\times256\times\frac{H}{4}\times\frac{W}{4}}$。采用小尺寸 3×3 卷积核，保证计算效率，维持足够的特征学习能力。多尺度表征学习理论表明，在不同尺度下提取特征可以有效提高网络对不同尺寸目标的感知能力，并增强模型在复杂退化场景下的适应性。

从表征学习的视角出发，多尺度信息的融合有助于提升网络的特征判别能力。大尺寸卷积核能够捕捉更广泛的背景信息，但同时可能导致对小目标细节的丢失。为此，在特征提取模块中引入不同尺度的卷积操作，既保留局部细节特征，又有效建模大范围的全局信息，从而更加精确地学习水下图像中的光照分布、纹理特性与边缘结构。

6.4 时空特征优化方法设计

尽管特征提取模块能够有效学习到多尺度的特征表示，但由于水下图像复杂的光照条件和散射效应，仍可能导致部分特征信息不足，影响增强效果。为此，本章提出特征优化模块，提升特征的表达能力。该模块基于时空特征优化注意力机制，结合像素级特征优化、通道注意力增强和空间注意力自适应调控，以更精准地增强水下图像的表征能力，架构图如图 6.2 所示。

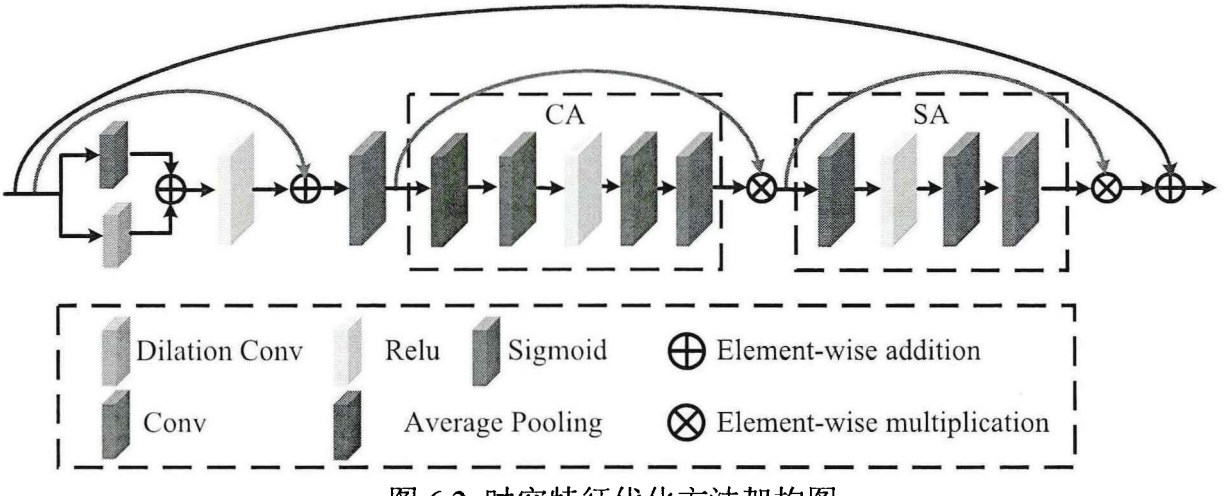

图 6.2 时空特征优化方法架构图

Fig. 6.2 Architecture diagram of spatio-temporal feature optimization attention module

中国知网 https://www.cnki.net

引入膨胀卷积来扩展特征的感受野，以获取更密集的特征信息，提高像素空间的细节表达能力：

$$F_4^1 = \mathrm{Conv}(\mathrm{ReLU}(\mathrm{D_Conv}(F_i) + \mathrm{Conv}(F_i)) + F_i) \tag{6.9}$$

其中，Conv 为标准卷积操作，D_Conv 为膨胀卷积，F_i 为输入特征，在第一层时空特征优化注意力机制中，F_i=F_3。膨胀卷积能够扩大感受野而不会增加额外计算量，从而在更大范围内提取水下图像的细节信息。在较低分辨率的特征图上，局部信息的损失较为严重，标准卷积操作难以有效捕捉远距离依赖关系，而膨胀卷积能够在不增加计算复杂度的情况下扩大感受野，使得网络在有限的层数内获取更丰富的全局信息。

基于通道注意力增强时序维度特征表达公式如下：

$$F_4^2 = \sigma(\mathrm{Conv}(\mathrm{ReLU}(\mathrm{Conv}(\mathrm{Avg}(F_4^1))))) \times F_4^1 \tag{6.10}$$

其中，σ 为 Sigmoid 激活函数，Conv 为卷积操作，Avg()表示全局平均池化。

在自适应跨帧特征对齐方法的设计中，本章提出基于通道维度的跨帧信息整合策略。由于本章将不同帧的序列图像沿通道维度拼接，因此使用基于通道注意力机制能够显式构建多帧间的时空关联性，对水下退化过程的多帧联合表征建模。式(6.10)中设计的通道注意力机制本质上是基于全局上下文感知的特征选择器，该模块通过全局平均池化提取空间维度信息，再通过两层全连接层建立通道间的非线性依赖关系。这种机制使得本方法能够动态评估不同序列帧中通道特征的重要性，特别是针对水下环境中因波长选择性衰减导致的 R、G、B 通道异质性退化，实现对有效跨帧特征的强化与噪声通道的抑制。

在动态水下场景中，当相邻帧包含目标运动或视角偏移时，该机制能够通过最大化互信息准则，自适应地选择具有高信息量的帧间互补特征。例如，当目标区域在某一帧因散射效应严重模糊时，注意力权重会倾向于增强其他帧中对应区域的清晰特征。这种动态特征选择能力与可变形卷积的几何自适应特性形成互补，通道注意力在特征空间实现信息优化，可变形卷积在几何空间完成形变补偿，二者共同构建跨帧对齐的双重优化机制。

空间注意力基于卷积神经网络的局部感受野理论，通过建立像素级空间相关性模型来解决非均匀退化，公式如下：

$$F_4^3 = \sigma(\mathrm{Conv}(\mathrm{ReLU}(\mathrm{Conv}(F_4^2)))) \times F_4^2 \tag{6.11}$$

通过局部卷积操作实现计算效率与局部结构保持的平衡。通过 Sigmoid 激活函数生成空间权重矩阵，使网络能够聚焦于具有高梯度信息的边缘区域和受散射影响较小的清

中国知网 https://www.cnki.net

晰区域。空间选择性增强机制与通道注意力形成正交互补，二者通过级联方式实现特征空间的精细化调控，最终达到退化特征与清晰特征的最优分离。

此外，为避免梯度消失问题，本章方法采用残差连接机制：

$$F_4^{S1} = F_4^3 + F_3 \tag{6.12}$$

该模块由八个基于时空特征优化注意力模块组成，下一个模块的输入为上一个模块的输出，即公式(6.8)中的输入特征 F_i 更改为上一个分支的输出。通过逐步细化特征表示，确保增强后的图像能够保留完整的全局结构信息，获取增强后的特征，恢复局部细节，有效地利用跨帧信息，提高水下图像清晰化的稳定性和鲁棒性。

6.5 多尺度特征恢复方法设计

特征恢复模块旨在充分利用特征提取模块和特征优化模块提取的特征信息，生成高质量的增强图像。基于特征提取模块的架构，提高网络的计算效率并优化恢复效果。由于水下图像的复杂退化模式，防止上采样过程导致的部分关键信息丢失，尤其是在深层网络中，浅层提取的细节信息无法完整地传递至最终清晰化图像。跳跃连接能够直接将浅层特征传递至高层特征映射，有助于保留细节信息，提高图像结构的完整性，增强图像的空间一致性，从而提升增强质量。具体而言，恢复特征的计算公式如下：

$$R_2 = \mathrm{ReLU}(\mathrm{TConv}(F_4 + F_3)) \tag{6.13}$$

$$R_1 = \mathrm{ReLU}(\mathrm{TConv}(R_2 + F_2)) \tag{6.14}$$

$$\hat{J} = \mathrm{Tanh}(\mathrm{Conv}(R_1 + F_1)) \tag{6.15}$$

其中，TConv(•)代表转置卷积，用于特征恢复过程中的上采样操作，$\hat{J}$ 表示恢复的清晰图像。在水下图像清晰化任务中，由于散射和光吸收导致的纹理模糊，使用转置卷积可以更好地恢复图像结构，确保生成的增强图像在空间层次上的连贯性。能够自适应地调整特征图的局部信息，保留序列图像中相邻帧的相关性，有助于增强网络对时间序列数据的感知能力，避免图像清晰化过程中出现不稳定的伪影。

6.6 面向跨帧序列图像的损失函数设计

为确保生成的水下序列图像在视觉效果上的优化，本节结合 Charbonnier Loss 和 VGG 感知损失，以平衡结构恢复与视觉感知质量。损失函数定义如下：

$$L = L_{char} + \alpha L_{per} \tag{6.16}$$

中国知网 https://www.cnki.net

其中，L_{char} 代表 Charbonnier Loss，L_{per} 代表 VGG 感知损失，α 为权重系数，论文中设定为 0.2。

使用 Charbonnier Loss[170]约束水下清晰化网络的细节信息，公式如下：

$$L_{char} = \sqrt{\| \hat{J} - J \|^2 + \epsilon^2} \tag{6.17}$$

其中，$\hat{J}$ 代表通过基于跨帧表征对齐的水下图像，J 代表真实的无退化参考图像，ϵ 经验设定为10^{-6} 以避免数值不稳定。

Charbonnier Loss 可视为平滑的 L_1 损失，相比于传统的 L_2 损失，其对异常值的鲁棒性更强。水下图像通常受限于非均匀光照、悬浮颗粒引起的散射和偏色等问题，导致某些区域的像素值偏离自然分布。由于 Charbonnier Loss 具有更小的梯度变化，在优化过程中能够有效抑制异常像素点对损失计算的影响，增强模型对不确定性区域的鲁棒性，保留更多细节信息。

为优化清晰化图像的视觉感知质量，本章引入 VGG 感知损失[154]，其定义如下：

$$L_{per} = \sum_{j=1}^{W1} \sum_{i=1}^{H1} \left\| \phi(\hat{J}(i,j)) - \phi(J(i,j)) \right\|_2^2 \tag{6.18}$$

其中，$\phi(\cdot)$ 表示预训练的 VGG 网络的第 16 层卷积特征映射。

6.7 CFRA-Net 算法设计

CFRA-Net 的算法实现以端到端方式整合跨帧特征对齐、多尺度表征学习与时空优化机制，旨在解决水下序列图像中因复杂退化导致的色彩失真、模糊及运动伪影问题，算法如表 6.1 所示，CFRA-Net 方法架构图如图 6.3 所示。CFRA-Net 算法将输入的三帧水下图像（当前帧及其相邻帧）沿通道维度拼接，利用可变形卷积模块自适应对齐多帧间的特征信息，动态补偿因视角偏移或目标运动引起的流变失准，从而增强目标帧的时空一致性。

在多尺度特征提取阶段，CFRA-Net 通过多级下采样操作逐步捕获不同尺度的表征信息。全局上下文信息由浅层卷积层提取，而深层卷积层则聚焦于语义特征的抽象，形成从局部细节到全局结构的层次化表征。为优化退化特征，算法引入级联的时空特征优化注意力模块，通过通道注意力动态分配不同特征通道的权重抑制冗余噪声并突出关键信息，提取不同帧之间的互补信息；空间注意力则自适应调整各空间位置的权重，强化边缘与纹理的保真度。上述注意力机制通过残差连接与原始特征融合，确保优化过程稳定且高效。

中国知网 https://www.cnki.net

Algorithm 6.1: CFRA-Net

Input: Degraded underwater sequence image $I=\{I_{t-1},I_t,I_{t+1}\}\in\mathbb{R}^{3C\times H\times W}$

Output: Restored image $\hat{J}\in\mathbb{R}^{H\times W\times 3}$

// **Step 1**: Cross-frame feature alignment:

$I_{cat}\leftarrow \text{Concat}(I_{t-1},I_t,I_{t+1})$ // Channel-wise concatenation

$O\leftarrow \text{Conv}_{3\times3}(I_{cat})$ // Compute deformable offsets

$M\leftarrow 2\times\sigma(\text{Conv}_{3\times3}(I_{cat}))$ // Dynamic mask

$F_{align}\leftarrow \text{DeformConv}(I_{cat},O,M)$ // Adaptive alignment

$F_2\leftarrow F_1+I_t$ // Target frame fusion

// **Step 2**: Cross-frame feature alignment:

$F_1\leftarrow \text{ReLU}(\text{Conv}_{7\times7}(F_{align}))$ // Global context $F_1\in\mathbb{R}^{B\times64\times H\times W}$

$F_2\leftarrow \text{ReLU}(\text{Conv}^{\downarrow}_{3\times3}(F_1))$ // Downsample $F_2\in\mathbb{R}^{B\times128\times\frac{H}{2}\times\frac{W}{2}}$

$F_3\leftarrow \text{ReLU}(\text{Conv}^{\downarrow}_{3\times3}(F_2))$ // Downsample $F_3\in\mathbb{R}^{B\times256\times\frac{H}{4}\times\frac{W}{4}}$

// **Step 3**: Spatio-temporal Feature Optimization:

for i=1 to 8 do: // Iterative Feature Optimization

  if i=1

    $F_{Si}\leftarrow F_3$

  else

    $F_{Si}\leftarrow F_4^{S(i-1)}$

  end if

  $F_{Si}^1\leftarrow \text{Conv}(\text{ReLU}(\text{D_Conv}(F_{Si})+\text{Conv}(F_{Si}))+F_{Si})$

  $F_{Si}^2\leftarrow \sigma(\text{Conv}(\text{ReLU}(\text{Conv}(\text{Avg}(F_{Si}^1)))))\times F_{Si}^1$

  $F_{Si}^3\leftarrow \sigma(\text{Conv}(\text{ReLU}(\text{Conv}(F_{Si}^2))))\times F_{Si}^2$

  $F_4^{Si}\leftarrow F_{Si}^3+F_{Si}$

end for

// **Step 4**: Multi-scale decoder:

$R_2\leftarrow \text{ReLU}(\text{TConv}(F_4^{S8}+F_3))$

$R_1\leftarrow \text{ReLU}(\text{TConv}(R_2+F_2))$

$\hat{J}\leftarrow \text{Tanh}(\text{Conv}(R_1+F_1))$

Return $\hat{J}$

多尺度特征恢复阶段通过转置卷积逐步上采样恢复图像分辨率，并结合跳跃连接将编码器中保留的浅层高频纹理细节与深层语义光照分布信息深度融合，避免上采样过程中的信息丢失。CFRA-Net 通过非线性激活函数将优化后的特征映射至目标 RGB 色彩空间生成色彩自然、细节清晰的目标帧增强图像。

中国知网 https://www.cnki.net

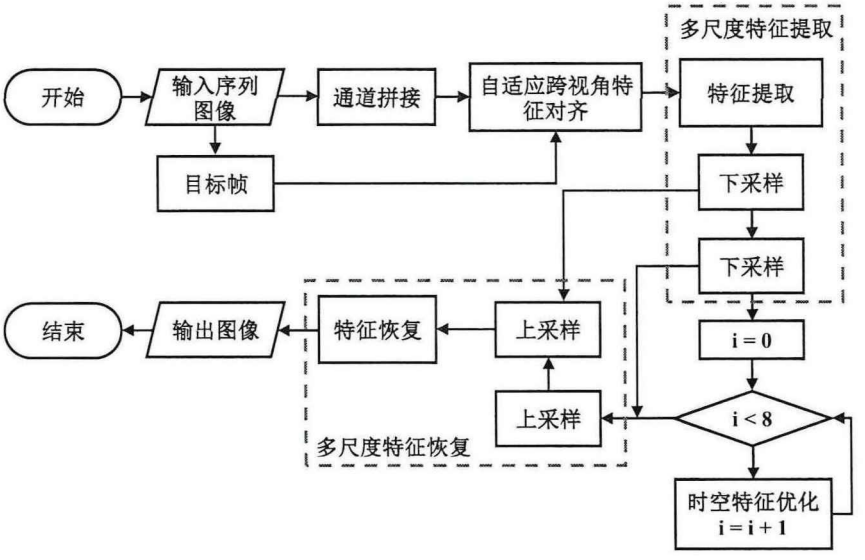

图 6.3 CFRA-Net 方法架构图

Fig. 6.3 The framework of the CFRA-Net algorithm

6.8 实验结果与分析

6.8.1 实验设置说明

为全面验证本章提出的基于跨帧表征对齐的水下图像清晰化网络（CFRA-Net）的有效性，本章基于现有的开放水下视频提出 MVUI 数据集，MVUI 数据集是通过从高质量水下视频中收集序列图像构建而成，通过考虑水下环境的复杂性，涵盖不同类型的水下光照条件和散射特征，使得模型能够学习更具鲁棒性的表征。本章方法在 MVUI 数据集进行定性和定量实验评估。

MVUI 数据集的训练集和验证集数据划分借鉴 UIEB 数据集的训练策略。MVUI 数据集包含 1733 对水下序列图像用于训练，100 对水下序列图像用于测试，图像分辨率统一为 1280×720。

为确保评估的全面性，本章对比当前主流的水下图像清晰化与复原方法，包括基于传统模型的图像清晰化方法、基于物理模型的图像复原方法、基于深度学习的增强方法。对比方法包括水下图像增强方法：CBE[171]、TEBCF[172]、MLLE[47]。基于物理模型的水下图像复原方法：ULAP[22]、SDCP[144]、HLP[173]。基于深度学习的水下图像清晰化方法：Water-Net[77]、UWCNN[95]、Ucolor[78]。以保证实验的公平性，其中基于深度学习的方法使用 MVUI 数据集重新训练。

中国知网 https://www.cnki.net

所有实验均在 Intel Xeon 4215 @3.20GHz CPU（32GB RAM）和 Tesla V100 GPU 的服务器上进行，本章的深度学习框架采用 PyTorch。网络训练使用 AdamW 优化器，初始学习率设为 0.0003，批量大小（BatchSize）设定为 40，并进行 900 epochs 训练以优化模型。训练过程中，采用指数学习率衰减策略，以提高模型的收敛性和稳定性。

为客观评估基于跨帧表征对齐的水下序列图像清晰化方法及各对比方法的水下图像清晰化性能，本章进行定性和定量实验。在定量评估中，采用以下全参考（Full-reference）和无参考（No-reference）图像质量评价指标进行测量，其中全参考指标包括 PSNR[122]和 SSIM[123]，PSNR[122]反映增强后图像与参考图像之间的均方误差，值越高表示增强效果越接近参考图像。SSIM[123]衡量图像在结构、对比度、亮度三个方面的相似性，取值范围[0, 1]，值越接近 1，表示清晰化图像与参考图像的相似度越高。

无参考指标包括 UCIQE[127]和 UIQM[126]，UCIQE[127]和 UIQM[126]主要用于衡量水下图像的清晰度、色彩保真度及对比度，对无法获取参考图像的水下场景尤为适用，用于评估水下图像清晰化的视觉效果。

6.8.2 定性实验分析

为验证本章提出的基于跨帧表征对齐的水下图像清晰化网络（CFRA-Net）在可视化效果上的优势，本章在 MVUI 数据集上，与当前最先进的水下图像清晰化方法进行对比实验，以展示所提网络在不同复杂水下环境下的鲁棒性。相关可视化结果如图 6.4 到图 6.8 所示。

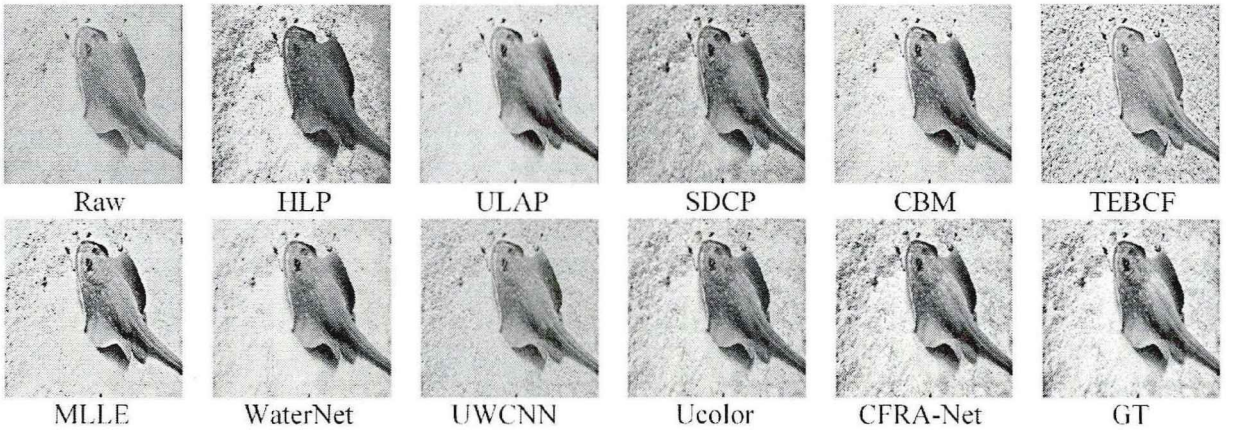

图 6.4 CFRA-Net 与对比方法在拍摄视角向下的可视化比较结果

Fig. 6.4 Results of the visual comparisons of CFRA-Net method with Comparison methods on the downward-looking image

中国知网 https://www.cnki.net

ULAP[22]、SDCP[144]等基于物理模型的水下图像复原方法难以处理场景中具有强烈光斑的场景，并且在严重的绿色-蓝色（G-B）偏色环境下表现不佳，甚至加剧颜色失真。基于物理模型的水下图像复原方法依赖于对光学衰减的先验假设，而水下光照环境高度复杂，传统的成像模型难以准确拟合这些不确定因素。

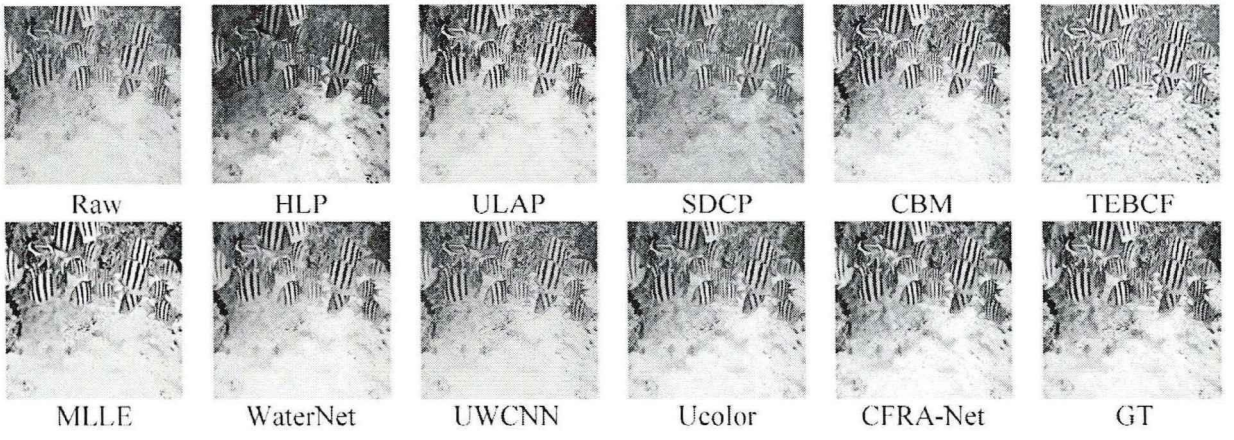

图 6.5 CFRA-Net 与对比方法在拍摄视角平行的可视化比较结果

Fig. 6.5 Results of the visual comparisons of CFRA-Net method with comparison methods on the forward-looking image

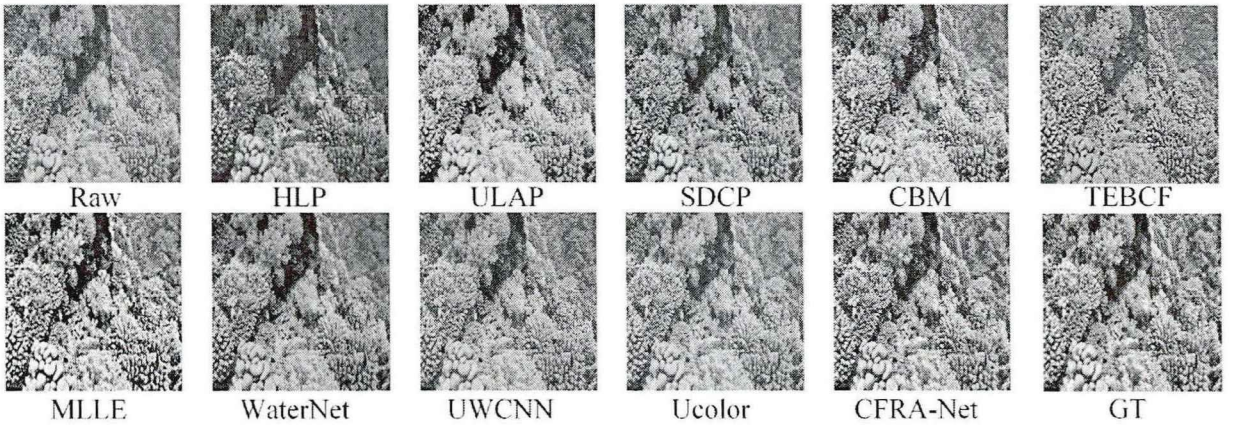

图 6.6 CFRA-Net 与对比方法在低后向散射图像的可视化比较结果

Fig. 6.6 Results of the visual comparisons of CFRA-Net method with Comparison methods on low backscatter images.

此外，当 G-B 最大强度与 R 通道的强度值相对较小时，基于物理模型的方法难以准确估计场景深度，导致增强效果欠佳。如图 6.5、图 6.6、图 6.7 和图 6.8 所示，ULAP[22]

中国知网 https://www.cnki.net

方法提升图像清晰度，但是在后景和前景区域引入红色偏色，影响最终的水下图像复原质量。

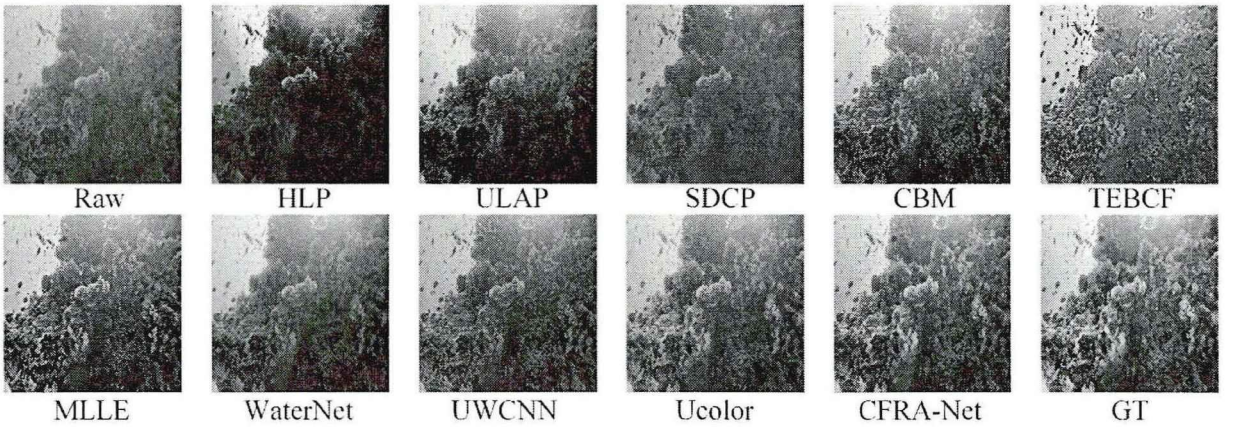

图 6.7 CFRA-Net 与对比方法在自然光图像的可视化比较结果

Fig. 6.7 Results of the visual comparisons of CFRA-Net method with Comparison methods on the natural light images.

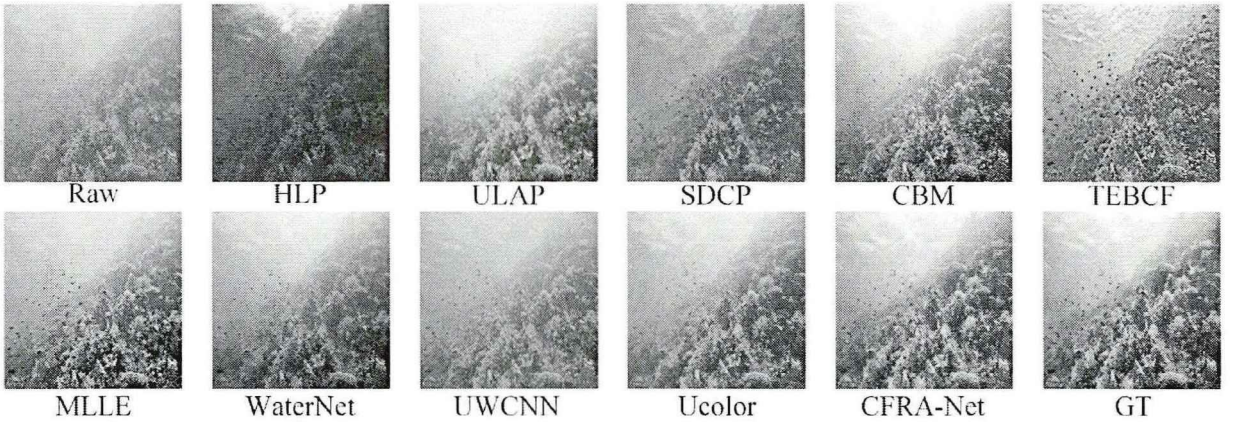

图 6.8 CFRA-Net 与对比方法在高后向散射图像的可视化比较结果

Fig. 6.8 Results of the visual comparisons of CFRA-Net method with Comparison methods on high backscatter images

TEBCF[172]方法在视觉上虽然能产生增强效果，但忽略光衰减的帧间相关性，导致不同帧间的颜色校正结果不一致，从而产生过度增强现象。此外，基于最大衰减图的增强方法在处理具有白色目标或均匀背景的图像时表现较差，无法正确恢复图像的层次感。

中国知网 https://www.cnki.net

MLLE[47]方法虽然能够一定程度上改善图像质量，但仍然难以在复杂水下环境中提供稳定的增强效果，可能会引入不必要的红色失真，如图 6.5 中结果所示。

基于深度学习的水下图像清晰化方法：Water-Net[77]、UWCNN[95]、Ucolor[78]，可以从大量数据中学习水下图像退化过程，根据数据集的数据分布可以适应于不同水下光照条件的水下场景。然而，现有的深度学习方法仍然存在一定局限性，在极端条件下的增强能力有限。

本章提出的基于跨帧表征对齐的水下序列图像清晰化方法（CFRA-Net）充分利用跨帧表征对齐，通过自适应跨帧特征对齐模块整合多帧图像的信息，基于可变形卷积避免序列图像之间的运动模糊，提高网络在复杂环境下的增强稳定性。此外，基于时空特征优化注意力机制优化通道信息与空间信息的融合，其中通道注意力机制融合多帧之间的特征信息，使得清晰化后的水下图像在色彩、对比度和清晰度方面更符合人眼感知。

定性实验结果表明，基于跨帧表征对齐的水下序列图像清晰化方法能够在复杂水下环境中生成更加自然、细节丰富的增强图像，避免传统物理模型方法的失真问题，并在增强效果上优于现有的深度学习对比方法，在序列图像中具有更强的帧间一致性。因此，CFRA-Net 在水下清晰化图像清晰化任务中展现出卓越的泛化能力和视觉质量提升能力，为后续计算机视觉任务（如水下目标检测、图像分割等）提供更加可靠的高质量数据输入。

6.8.3 定量实验分析

为全面评估本章提出的基于跨帧表征对齐的水下序列图像清晰化方法（CFRA-Net），本节采用两种全参考图像质量评价指标（PSNR 和 SSIM）和两种无参考（No-reference）图像质量评价指标（UCIQE 和 UIQM），对 CFRA-Net 与当前对比方法在跨帧数据集上的表现进行定量分析。

PSNR（峰值信噪比）数值越高，表示增强后的图像内容越接近参考图像，增强质量越好。SSIM（结构相似性指标）数值越高，表示增强图像能够更好地保留原始图像的结构信息。此外，无监督参考指标 UCIQE 和 UIQM 主要衡量水下图像的整体质量，其中 UCIQE 关注图像的色调分布、对比度和清晰度，而 UIQM 则评估颜色保真度、锐度和对比度。理论上，UCIQE 和 UIQM 数值越高，表明图像质量越优。然而，在水下图像清晰化任务中，UCIQE 和 UIQM 指标存在一定的局限性，往往忽略色彩失真和伪影的影响。因此，本章将这两个指标作为参考指标，并结合视觉效果进行综合评估，提出一个综合指标 ALL，ALL = PSNR+SSIM+UIQM+UCIQE。ALL 指标的数值越大证明清晰化图像质量越高。

中国知网 https://www.cnki.net

表 6.1 展示 CFRA-Net 及对比方法在全参考和无参考指标在 MVUI 数据集的平均性能。CFRA-Net 在全参考 PSNR（28.28 dB）和 SSIM（0.96）上达到最优值，并在多个无参考指标上取得较大幅度的提升。较高的 PSNR 和 SSIM 说明 CFRA-Net 网络具有更优的学习能力，能够有效恢复水下序列图像的场景信息，与现有的先进方法相比与真实图像最为接近。

表 6.1 CFRA-Net 方法与对比方法在 MVUI 数据集的客观指标对比结果

Tab. 6.1 Objective metrics results of CFRA-Net and comparative methods on the MVUI dataset

	PSNR↑	SSIM↑	UIQM↑	UCIQE↑	ALL↑
HLP	15.00	0.67	2.43	**0.66**	18.76
ULAP	15.51	0.68	2.12	<u>0.65</u>	18.96
SDCP	17.27	0.79	3.09	0.59	21.74
CBM	22.06	<u>0.86</u>	2.78	0.65	26.35
TEBCF	18.24	0.80	2.79	0.62	22.45
MLLE	18.95	0.76	2.00	<u>0.65</u>	22.36
WaterNet	20.46	0.83	2.82	0.62	24.73
UWCNN	19.98	0.85	<u>3.20</u>	0.56	24.59
UColor	<u>22.62</u>	<u>0.86</u>	**3.26**	0.59	<u>27.33</u>
CFRA-Net	**28.83**	**0.96**	2.93	0.64	**33.36**

此外，为验证 CFRA-Net 的鲁棒性，本章还对比对比方法在 UCIQE 和 UIQM 指标上的表现，结果见表 6.1。尽管 SDCP[144]方法在 UCIQE 和 UIQM 指标上略高于 CFRA-Net，但 SDCP[144]方法在对比度增强方面表现不佳，甚至可能导致色彩失真（如图 6.4 所示）。此外，HLP[173]方法基于人工设计的先验信息，极度依赖于获取的水下序列图像的像素值，受限于不同场景信息的表达，难以处理复杂的水下退化模式，并可能引入额外的颜色偏移。对比方法都是基于单幅水下图像清晰化方法的拓展，未考虑水下序列图像之间的时空信息。

如表 6.1 所示，CFRA-Net 方法在 ALL 指标上取得最高值，其中在 PSNR 和 SSIM 指标上显著优于现有方法，表明其能够更有效地恢复水下序列图像的场景细节和结构。UCIQE 和 UIQM 作为无参考水下图像指标，虽然在数值上存在不是最优值，但结合主观视觉结果分析，相比较于对比方法 CFRA-Net 依然能够生成更加自然的增强图像。因此，CFRA-Net 具有更高的泛化能力和稳定性，为水下计算机视觉任务提供更加可靠的高质量数据输入。

中国知网 https://www.cnki.net

6.8.4 消融实验分析

为验证 CFRA-Net 各个模块的有效性和必要性，本章进行消融实验，主要包括输入架构消融实验、模块内消融实验和网络架构消融实验。为确保公平性和可比性，本节所有消融实验均采用相同的损失函数，损失函数如章节 6.7 所示。

在输入架构消融实验中主要研究多帧输入对增强性能的影响，消融结果如表 6.2 所示。

表 6.2 输入架构模块中消融实验的客观指标对比结果

Tab. 6.2 The objective metrics results of ablation experiments in the input architecture module

	PSNR↑	SSIM↑	ALL↑
Single-input	27.06	0.92	27.98
CFRA-Net	**28.83**	**0.96**	**29.79**

表 6.2 中 Single-input 表示单帧输入，指仅输入单张图像，即在自适应跨帧特征对齐模块仅使用目标帧。在仅保留单帧输入时，PSNR 和 SSIM 均显著下降，表明跨帧特征对齐对于多帧输入的增强效果至关重要。FAM 模块能够充分利用多帧之间的互补信息，提高增强的稳定性。

在网络架构消融实验中，重点分析以下核心组成部分的贡献：

1) 自适应跨帧特征对齐模块 FAC，消融实验结果如表 6.3 所示；
2) 时空特征优化模块 STA，结果如表 6.3 所示。
3) 基于时空特征优化注意力迭代数量，结果如表 6.4 所示；

表 6.3 CFRA-Net 模块中消融实验的客观指标对比结果

Tab. 6.3 The objective metrics results of ablation experiments in the CFRA-Net network module

	PSNR↑	SSIM↑	ALL↑
FAC->Conv	28.00	0.95	28.95
w/o SA+PA	27.02	0.95	27.97
STA->Conv+SE	25.99	0.94	26.93
CFRA-Net	**28.83**	**0.96**	**29.79**

表 6.3 中 FAC -> Conv 表示将自适应跨帧特征对齐模块中的可变形卷积替换为标准卷积，w/o SA + PA 表示去除基于时空特征优化注意力中的空间注意力（SA）和通道注

中国知网 https://www.cnki.net

意力（PA）。在自适应跨帧特征对齐模块中，将可变形卷积替换为标准卷积后，PSNR和 SSIM 指标下降，可变形卷积在自适应跨帧特征对齐模块中通过灵活调整卷积核的采样位置，从而适应多帧图像间的运动变化。这种自适应能力使得可变形卷积能够更精确地对齐不同帧之间的特征信息，有效缓解因运动模糊或场景动态变化导致的物体偏移问题，进而提升多帧信息的有效融合。

表 6.3 中 STA -> Conv + SE 表示将基于时空特征优化注意力替换为标准卷积加 SE 注意力结构，由表 6.3 可见水下序列图像的清晰化质量下降，表明 STA 机制能够更有效地融合通道信息和空间信息，提升图像清晰度和色彩一致性。通道注意力机制在帧间信息融合中发挥关键作用，能够自适应地分配跨帧特征的权重，充分整合不同帧的场景补充信息，抑制冗余或噪声信息。确保时间序列中的特征一致性，提升序列图像清晰化网络的稳健性和泛化能力。

在水下图像清晰化任务中，边缘信息的完整性对于图像质量至关重要。水下环境中的光学散射和复杂的光照条件可能导致边缘模糊和纹理丢失，而有效的增强方法应能够恢复清晰的边缘结构。因此，本章通过计算可见边缘像素数量来评估不同消融实验方案在边缘保持能力方面的差异。如图 6.9 所示，对于 Single-input、STA→Conv＋SE、FAC→Conv、w/o SA＋PA、CFRA-Net 及 Ground Truth，所提取的可见边缘像素数量分别为 286,621，293,948，294,762，294,786，299,093 和 301,845。其中，与 Ground Truth 之间的差值依次为 15,224，7,897，7,083，7,059 和 2,752，表明 CFRA-Net 的增强结果更接近真实场景，并且各组件的引入均有效提升增强效果。

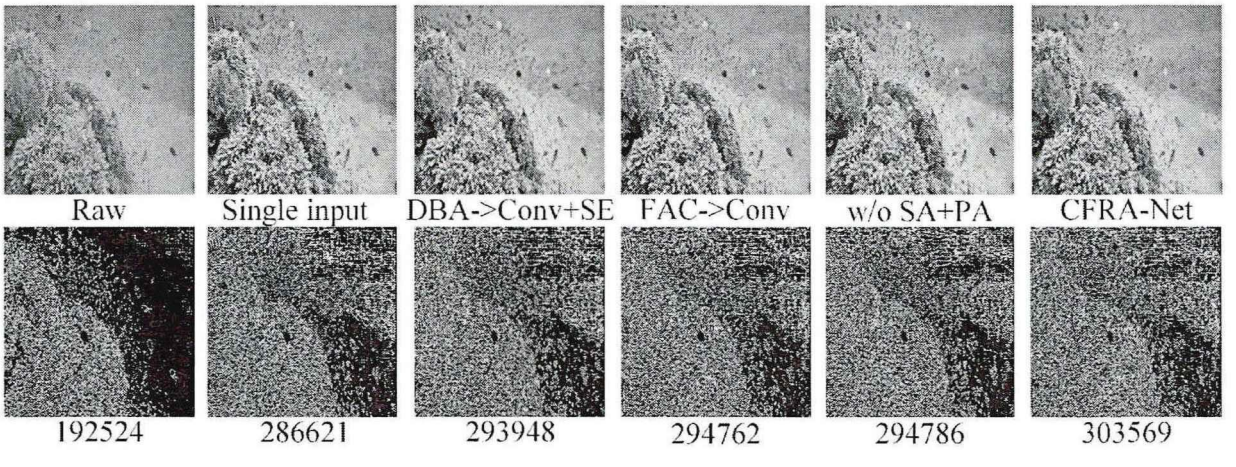

图 6.9 CFRA-Net 与对比方法的可见边缘像素数量可视化比较结果

Fig. 6.9 The visual comparison results of the number of visible edge pixels of CFRA-Net method with comparative methods on the MVUI dataset

中国知网 https://www.cnki.net

为研究特征优化模块中 STA 数量的最优配置，本章对不同数量的 STA 进行消融实验，结果如表 6.4 中所示。适量增加 STA 层数能够提升网络的特征提取能力，使得图像清晰化更稳定，当 STA 模块串联 8 层时，能够取得最佳的增强效果。然而当 STA 层数超过 9 层时，网络性能趋于饱和甚至略有下降，过多的 STA 模块可能引入不必要的计算开销，影响特征的有效性。因此，本章最终选择 8 个 STA 模块作为最优配置，以在增强效果与计算复杂度之间取得平衡。

表 6.4 特征优化模块中 STA 模块数量消融实验的客观指标对比结果

Tab. 6.4 The objective metrics results of number of STA modules ablation experiment in the feature refinement module

	PSNR↑	SSIM↑	ALL↑
4	27.75	0.95	28.70
5	28.20	0.95	29.15
6	28.28	**0.96**	29.24
7	28.31	0.95	29.26
8	**28.83**	**0.96**	**29.79**
9	28.05	0.95	29.00

综上所述，消融实验结果表明 CFRA-Net 在各个模块的协同作用下，能够更有效地增强水下图像的细节、对比度和色彩信息，并且超越现有先进对比方法的性能。因此，CFRA-Net 具备更强的泛化能力，适用于不同拍摄视角下的复杂水下环境的序列图像清晰化任务，具有较强的鲁棒性。

6.8.5 效率分析

表 6.5 展示 CFRA-Net 与不同对比方法在 MVUI 数据集上的平均推理时间对比。本实验输入图像尺寸一致，所有实验均在 Intel(R) Xeon(R) 4215 CPU @3.20GHz（32GB RAM）和 Tesla V100 GPU 上运行。从实验结果可见，UWCNN 方法在 GPU 上推理速度最快，而 CFRA-Net 的推理时间位列第二，虽然 CFRA-Net 基于多帧输入，但是 CFRA-Net 中仅设计两次下采样，仅在原始分辨率和最低分辨率两个分支进行特征提取操作，保证高质量增强，降低计算复杂度。

具体而言，减少下采样次数能够有效降低计算冗余，使得网络保持足够的全局信息感知能力，避免深度卷积计算的累积误差。此外，在原始分辨率和最低分辨率两个尺度上进行特征提取，能够确保浅层特征（如边缘、纹理）与深层特征（如光照、结构）得

中国知网 https://www.cnki.net

到合理融合，而不引入额外的计算开销，既提升清 9 晰化效果，又降低推理时间，使得 CFRA-Net 在计算资源受限的环境下仍能高效运行。

表 6.5 CFRA-Net 方法与对比方法在 MVUI 数据集的效率分析结果

Tab. 6.5 Efficiency analysis results of CFRA-Net and comparative methods on the MVUI dataset

	Params↑	Time↓	Metric↑	Agg↑
HLP	-	142.675	18.76	-123.915
ULAP	-	17.837	18.96	1.123
SDCP	-	12.173	21.74	9.567
CBM	-	3.425	26.35	22.925
TEBCF	-	38.684	22.45	-16.234
MLLE	-	1.600	22.36	20.760
WaterNet	1.100	0.354	24.73	24.376
UWCNN	**0.039**	**0.110**	24.59	24.480
UColor	148	2.709	27.33	24.621
CFRA-Net	4.3	0.237	**33.36**	**33.123**

另一方面，基于物理模型的方法和部分非物理模型方法由于需要估计先验知识、计算复杂参数，并进行繁琐的推理过程，因此推理时间相对较长。例如，Haze-line 方法[173]依赖物理模型估算两个额外的全局衰减比参数，导致计算复杂度显著增加。而 Ucolor[78]采用多色彩空间编码器网络和介质传输引导解码器网络，需要等待三个分支计算完成，导致运行时间较长。实验结果表明，CFRA-Net 的推理时间仅为 Ucolor 方法[78]的 1/13，展现更高的计算效率。

值得注意的是，本章节基于 MVUI 数据集中 720p 图像进行推理时间测试，与其他章节的运行时间测试略有差异。在相同测试环境下，CFRA-Net 展现 0.237s 的平均推理时间。为综合评估增强方法的运行效率与图像质量，本节引入综合评价指标（Agg），定义如下：

$$\mathrm{Agg} = \mathrm{Metric}\text{-}\mathrm{Time} \tag{6.19}$$

其中，Metric 代表 PSNR、SSIM、UCIQE、UIQM 图像质量评价指标，Metric 数值参考表 6.2 中的 ALL 指标，Time 代表推理时间。Agg 指标能够量化方法保证高质量增强，优化计算效率的能力。

根据表 6.5 结果表明，CFRA-Net 在综合评价指标 Agg 指标上取得最优值，实验结果表明本章方法在增强水下序列图像的质量与推理时间之间达到最优平衡，能够保证高

中国知网 https://www.cnki.net

质量序列图像清晰化，具备实时性，在 720p 的分辨率图像达到 4.22 fps，适用于计算资源受限的水下视觉应用。

6.9 应用测试

由于水下环境的复杂性，包括光散射、色偏和低对比度问题，增强方法的有效性直接影响下游任务的性能。因此，本节探讨水下图像清晰化方法在实际视觉任务中的应用。

6.9.1 图像分割任务

图 6.10 展示不同水下图像清晰化方法对语义分割任务的影响。实验采用基于超像素的快速模糊 C 均值聚类（Superpixel-based Fast Fuzzy C-Means, FCM）[53]，在清晰化后的水下图像上直接测试分割效果。

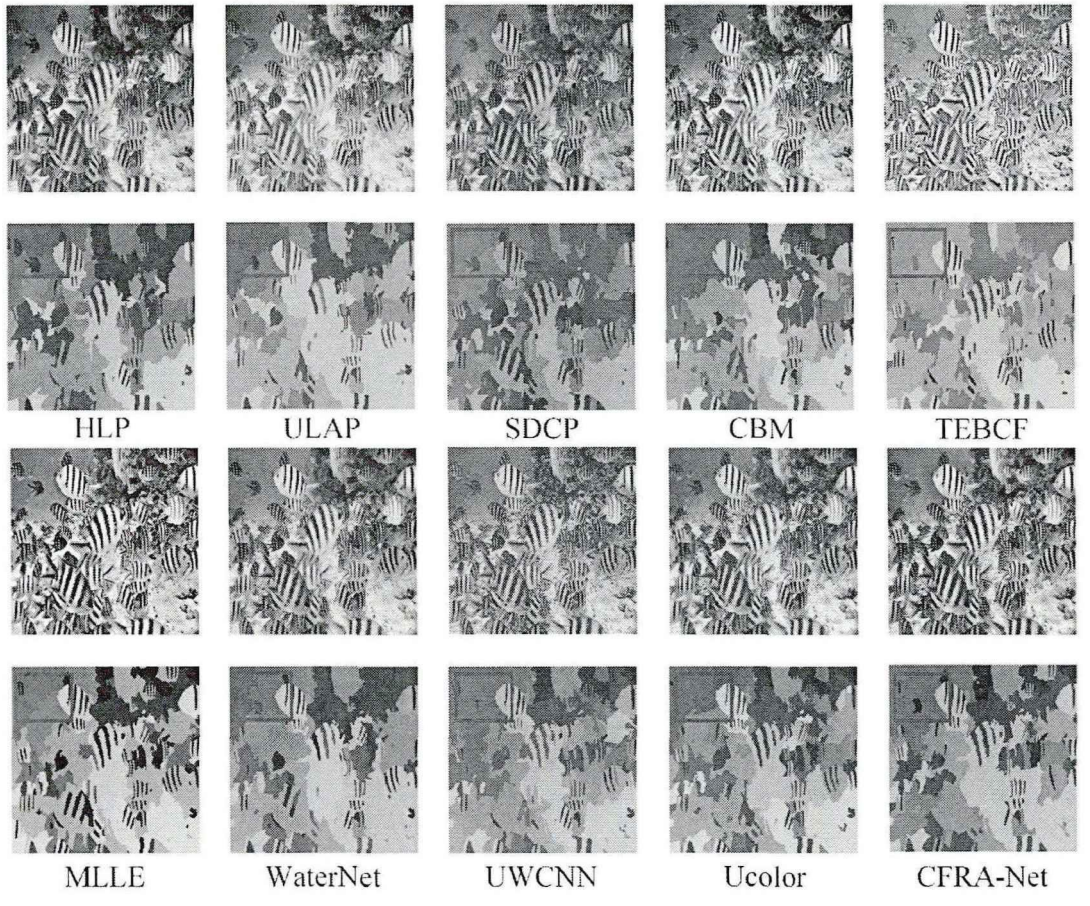

图 6.10 CFRA-Net 与对比方法在图像分割任务的可视化对比结果

Fig. 6.10 Comparison results of the semantic segmentation of CFRA-Net method with comparative methods on the MVUI dataset

中国知网 https://www.cnki.net

从实验结果可以观察到，CFRA-Net方法能够更好地保持图像的结构信息，使得FCM图像分割算法获得更加精准的分割结果，特别是红框部分的鱼类，CFRA-Net 在实现更精准的鱼类检测，避免后景区域的错误检测。相比之下，其他增强或复原方法往往会破坏图像的局部空间结构，导致分割算法无法正确识别物体边缘，影响最终的分割质量（如图 6.10 所示）。CFRA-Net 采用跨帧表征对齐策略，增强后的图像能够更真实地保留局部空间信息，增强结果可以提高图像分割任务的准确性。

6.9.2 显著性检测任务

图 6.11 展示不同的对比方法在 MVUI 数据集的显著性检测任务结果。实验采用频率调谐显著性区域检测（Frequency-Tuned Salient Region Detection, FSRD）[54]方法，基于颜色和亮度特征，输出全分辨率的显著性检测结果，并保留显著目标的清晰边界。

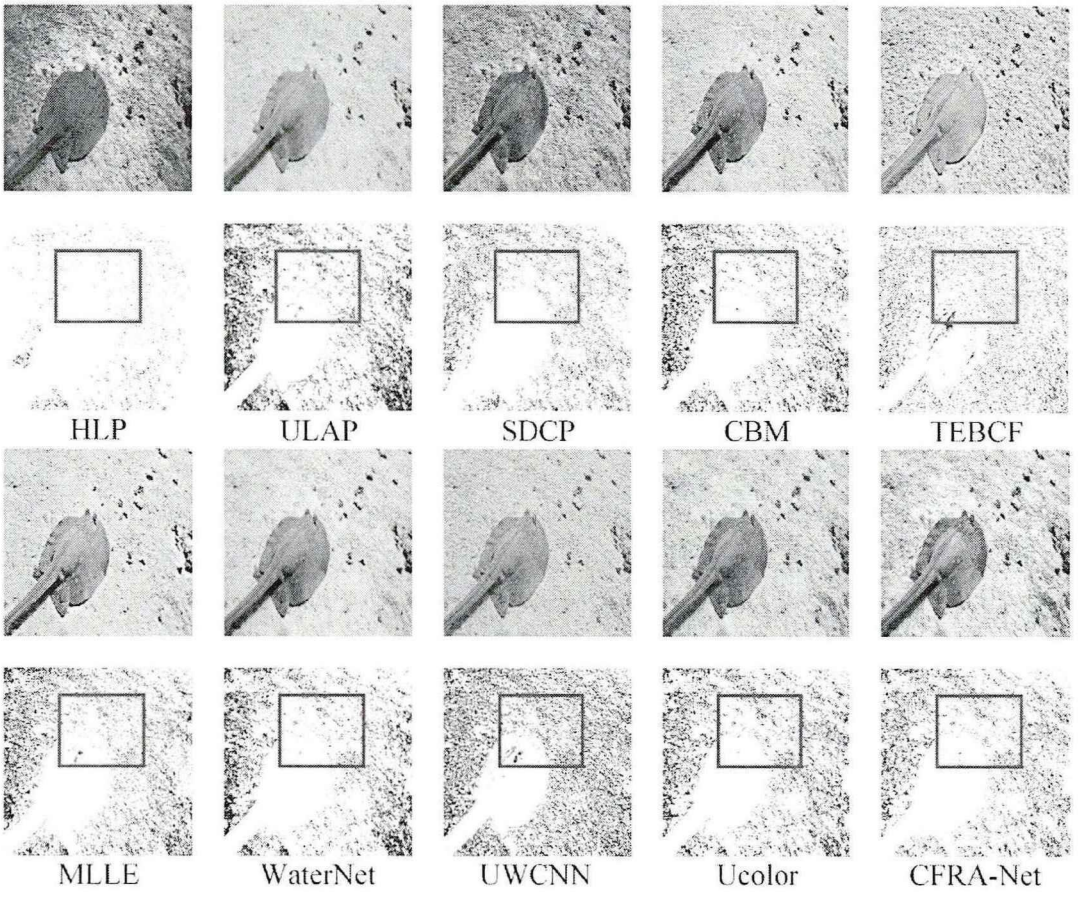

图 6.11 CFRA-Net 与对比方法在显著性检测任务的可视化比较结果

Fig. 6.11 Comparison results of the salient region detection of CFRA-Net method with comparative methods on the MVUI dataset

中国知网 https://www.cnki.net

实验结果表明，CFRA-Net 方法能够增强更准确的细节信息，使 FSRD 显著性检测算法生成更稳定的显著性区域。相比之下，其他方法由于增强过程中引入意外的颜色偏差和模糊细节，导致显著性区域的边界不清晰，影响最终检测效果。上述结果表明，CFRA-Net 通过基于时空特征优化注意有效优化通道和空间信息的融合，使得增强后的图像在视觉感知层面上更加符合实际场景，提高显著性检测任务的可靠性。

上述水下图像在高级视觉任务中的应用测试表明，CFRA-Net 作为一种水下视觉感知增强方法为后续计算机视觉任务提供更高质量的输入数据。在语义分割任务中，CFRA-Net 方法能够保持图像的结构信息，提高分割精度；在显著性检测任务中，CFRA-Net 通过优化特征表征，使得显著性区域更加清晰。综合来看，CFRA-Net 提升水下图像的视觉质量，为下游计算机视觉任务提供更鲁棒的输入，为未来水下视觉感知任务提供新的视角。

6.10 本章小结

本章提出基于跨帧表征对齐的水下序列图像清晰化方法，该方法利用跨帧表征对齐学习的思路，通过端到端的方式训练整个增强模型。采用多帧数据输入，使用基于可变性卷积的自适应跨帧特征对齐模块动态调整跨帧特征的对齐方式，提升多帧信息融合的准确性。特征优化模块采用基于时空特征优化注意力，分别在通道维度和空间维度对特征进行加权优化分别在通道维度和空间维度对特征进行加权优化，有效增强不同帧之间的信息。其中，通道注意力机制在多帧信息融合过程中起到至关重要的作用，能够自适应地调整来自不同帧的特征权重，增强关键信息，抑制无关背景或噪声信息。动态流变扰动下的帧间结构错位机制建模机制确保模型能够充分利用多帧之间的互补信息，提高整体特征表示能力，进而增强水下图像的视觉清晰度与色彩一致性。

特征恢复模块结合跨尺度特征融合机制，基于高层次的上下文信息能够更有效地补充低层次的纹理信息，从而在增强过程中减少模糊和伪影的产生。这些模块的协同作用使得 CFRA-Net 在克服输入信息不足问题，能够有效恢复水下图像的细节与色彩，提高视觉质量，并确保增强过程具备高效性和鲁棒性。

实验结果表明，CFRA-Net 在 MVUI 数据集上取得当前最优性能，PSNR 达到 28.28dB，SSIM 为 0.96，并且在 720p 图像上的处理速度为 0.237s，满足实时处理需求。相比于现有方法，CFRA-Net 有效克服时序信息利用不足的问题，在图像细节保留和色彩还原方面均表现出色，为后续的水下计算机视觉目标检测、图像分割任务等提供更高质量的输入数据，为未来的水下序列增强任务提供新的研究方向。

中国知网 https://www.cnki.net

7 结论与展望

7.1 结论

论文围绕水下图像清晰化问题，针对水下成像过程色彩失真、多尺度退化、光照影响、动态场景适应性不足等科学问题，针对基于表征学习的水下图像清晰化方法开展研究。基于多维建模策略，针对局部适应性受限、多尺度退化建模局限、物理一致性缺失、动态场景适应性不足等问题，建模空间维度、多尺度语义维度、场景维度、时序维度信息，形成涵盖静态与动态场景的完整解决方案，系统性地提升水下图像的质量、清晰度和鲁棒性。论文在多个公开数据集及真实水下场景中进行充分实验验证，定性和定量实验结果表明所提出的方法与成果在水下图像清晰化任务中具有显著优势。

主要研究内容如下：

1) 基于光衰减表征的水下图像自适应颜色校正方法

针对局部深度与光衰减之间的耦合关系建模不准确问题，从颜色校正的角度出发，开展基于光衰减表征的水下图像自适应颜色校正方法研究，建模底层像素空间表征。基于水下成像物理模型分析不同水深下的色偏退化规律，对图像进行局部区域划分，计算区域内的恢复因子和通道色偏因子。利用双线性插值方法将恢复因子和通道色偏因子扩展至全局，以实现颜色平滑过渡，避免现有全局校正方法容易引入的前景色彩过度补偿问题。该方法可以自适应不同水深和不同光照条件，提高色彩还原的准确性和一致性。实验结果表明，该方法与代表性方法相比在 K 指标提升 37.6%，在复杂水下环境下该方法展现出良好的颜色校正能力，显著降低蓝绿色偏色情况，重建更符合真实视觉感知的色彩分布，为后续图像清晰化任务奠定稳健基础。

2) 基于内监督协同多尺度表征的水下图像清晰化方法

由于水下成像受到多尺度退化效应的影响，导致图像在不同尺度上的清晰度和对比度均有不同程度的下降。针对不同尺度下图像退化的主导因素难以解析问题，提出基于内监督协同多尺度表征的水下图像清晰化方法，系统建模图像多尺度语义表征。设计多分辨率编码器-解码器框架，设计双分支的内在上下文注意力机制，分别从局部细节与全局语义两个维度联合增强特征表达能力，提升对细粒度纹理与大尺度结构信息的感知与恢复效果。引入自适应选择性内在监督模块，针对多尺度特征进行动态筛选与优化，有效抑制冗余噪声干扰，强化关键特征的信息流动，提升编解码器特征空间的表达质量。实验结果表明，该方法与代表性方法相比在全参考指标提升 9.5%，在多类型水下图像上

中国知网 https://www.cnki.net

均实现更优的清晰化效果，尤其在高浑浊与强散射环境中展现出更强的鲁棒性与多尺度细节还原能力。

3) 基于场景表征引导的水下图像清晰化方法

数据驱动方法在水下图像增强中缺乏物理一致性指导，易导致视觉失真；物理建模方法则受限于参数估计误差。针对图像物理表征空间与优化目标冲突问题，提出基于场景表征引导的水下图像清晰化方法，建模场景表征提升增强过程的物理合理性与语义一致性。基于 Retinex 模型对水下图像进行光照分解，将图像分离为反射分量（场景固有属性）与光照分量（环境光影响），有效去除环境光干扰，更准确地恢复场景固有信息。基于原始图像和场景多表征空间，结合多尺度场景目标提取模块和基于上下文信息的多级融合模块，优化水下图像的固有场景表征建模与清晰化效果。实验结果表明，该方法与代表性方法相比在全参考指标提升 3.2%，能够有效提升水下图像清晰化方法的物理一致性，特别是在复杂光照环境下，该方法的清晰化结果更加稳定，有效避免伪影和色彩漂移问题。

4) 基于跨帧表征对齐的水下序列图像清晰化方法

现有水下序列图像增强方法在动态场景下的适应性较差，面临运动模糊、帧间错位、时序不一致性等问题。针对上述挑战，提出基于跨帧表征对齐的水下序列图像清晰化方法，建模时序高级表征，解决动态水下环境中的流变扰动与跨帧结构错位。采用可变形卷积实现跨帧动态特征对齐以补偿运动伪影，并结合基于时空特征优化注意力机制，分别从时间维度和空间维度建模，以提升时序信息的稳定性和动态场景的增强效果。实验结果表明，基于跨帧表征对齐的水下序列图像清晰化方法在 720p 分辨率下推理速度达到 0.237 秒，在动态水下场景中的清晰化效果明显优于现有方法，并在计算效率方面取得显著优化，具有良好的应用潜力，适用于水下目标检测、环境监测、水下机器人导航等应用场景。

针对水下图像清晰化的科学问题，提出基于表征学习的水下图像清晰化方法，通过多维建模策略，基于像素低级表征、多尺度语义中级表征、场景中级表征、时序高级表征系统解决复杂水下环境下的图像退化挑战，提升水下图像的质量和适用性。实验结果表明，论文提出的方法在多个典型水下数据集上均取得显著的性能提升，尤其在高悬浮颗粒、强散射光照、多目标运动等复杂水下环境中，仍能保持稳定且高质量的清晰化效果。为水下目标检测、环境感知、智能水下机器人等任务提供可靠的视觉输入支撑。研究成果不仅可服务于海洋资源勘探、水下机器人自主导航、海洋生态监测等国家重大应用需求，也为水下计算机视觉领域的理论研究与工程实践提供新的范式与技术路径。

中国知网 https://www.cnki.net

7.2 展望

尽管基于表征学习的水下图像清晰化方法在多种典型数据集和复杂退化场景下取得显著性能提升，并从多尺度协同建模、场景物理先验融合及跨帧时序一致性优化等维度构建系统性框架，但在通用性、效率性与鲁棒性方面仍存在一些亟待突破的技术瓶颈。

SCMR-Net 虽融合内监督机制与多尺度结构增强，兼顾细节保留与颜色恢复，但模型在高精度要求下仍具有较大参数量，当前的轻量化设计（如深度可分离卷积）尚无法满足资源受限平台（如水下无人机、嵌入式设备）对低功耗、高速推理的严格需求。SRG-Net 通过引入 Retinex 理论引导反射分量建模，在提升物理一致性方面取得一定效果，但该模型依赖反射图估计的精度。CFRA-Net 在建模跨帧一致性和动态场景结构方面展现出较强的表达能力，但当前特征对齐模块主要基于可变形卷积实现局部动态响应，在处理相邻帧严重退化或语义突变情况下，存在特征错配风险。

未来的研究将围绕多模态数据融合、跨模态学习、自监督学习、实时计算优化、水下机器人与自主水下航行器应用等方面展开，提升水下图像清晰化的适应性、鲁棒性和可解释性。

多模态与跨模态水下图像清晰化将成为未来研究的重要方向。单一光学成像受水体介质的吸收和散射等光学特性影响较大，而声学成像虽然能够穿透浑浊水域，但分辨率较低，难以提供清晰的视觉信息。因此，未来的研究将重点探索光学数据与声学数据的融合，通过结合光学成像的高分辨率特性与声学成像的强穿透能力，实现对水下场景的更全面理解。开发基于深度学习的跨模态特征对齐与融合方法，使模型能够充分利用不同模态的数据优势，以提升水下图像的可视化质量，为水下遥感、自动水下探测、智能水下机器人视觉等任务提供更强大的感知能力。

当前深度学习方法高度依赖大规模高质量的标注数据，但水下环境复杂多变，获取高质量标注数据的成本极高，甚至在某些深海或未知水域等特殊环境中难以获取足够的数据样本。因此，未来的研究将探索基于表征学习的自监督策略，例如对比学习和生成对抗网络，通过在无标签数据中挖掘潜在特征模式，减少对人工标注的依赖。利用多模态数据约束构建更有效的伪标签机制，以提高自监督学习方法的稳定性和泛化能力，更适用于复杂水下场景。

未来的研究将致力于将论文提出的多维递进式增强框架扩展到更广泛的计算机视觉应用中，尤其是在水下机器人和自主水下航行器等领域。随着水下自主探测与作业任务的不断增加，对水下视觉系统的鲁棒性、泛化性和实时性提出更高要求。论文的方法可与深度强化学习结合，用于优化水下机器人在复杂环境中的导航与目标检测能力，探索多传感器融合策略，如激光雷达-光学相机-声呐融合，提升水下机器人在低光、强散

中国知网 https://www.cnki.net

射环境下的感知能力。此外，未来还可结合图神经网络提升对水下场景的结构化建模能力，以增强智能机器人在复杂环境中的智能交互与决策能力。

综上所述，未来的研究将围绕多模态融合、自监督学习、计算效率优化和机器人视觉增强等核心方向展开，以“智能感知-高效计算-系统协同”为核心，提升水下图像清晰化方法的鲁棒性、适应性和实时性，为水下遥感、环境监测、智能自主机器人等应用提供更加高效、智能的解决方案，推动水下图像清晰化技术从实验室研究走向海洋产业应用，助力我国海洋资源开发与权益维护能力的全面提升。

中国知网 https://www.cnki.net

参 考 文 献

[1] 李学龙. 涉水光学[J]. 中国科学信息科学, 2024, 54(2): 227-280.

[2] 李学龙. 涉水视觉[J]. 电子学报, 2024, 52(4): 1041-1082.

[3] 周玲,刘庆敏,金凯杰,等. 水下图像复原和增强方法研究进展[J]. 中国图象图形学报,2025, 30(01): 51-65.

[4] 周景春,张得欢,张维石. 经典和先进的水下图像去雾方法综述（英文）[J]. Frontiers of Information Technology & Electronic Engineering, 2020, 21(12): 1745-1770.

[5] Zhou J, Sun J, Li C, et al. HCLR-Net: hybrid contrastive learning regularization with locally randomized perturbation for underwater image enhancement[J]. International Journal of Computer Vision, 2024, 132(10): 4132-4156.

[6] Wang H, Zhang W, Bai L, et al. Metalantis: A comprehensive underwater image enhancement framework[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 65: 5618319.

[7] 郝雅丽, 侯国家, 李月梅, 等.基于全变分和颜色平衡的水下图像复原[J]. 激光与光电子学进展, 2023, 60(16): 137-144.

[8] 杨宁,苏海冰,张涛.自适应水下图像增强算法[J]. 激光与光电子学进展, 2024, 61(08): 344-352.

[9] Zhao C, Cai W, Dong C, et al. Wavelet-based fourier information interaction with frequency diffusion adjustment for underwater image restoration. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition[C]. 2024: 8281-8291.

[10] Yang J, Li C, Li X. Underwater image restoration with light-aware progressive network. Proceedings of the ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)[C]. 2023: 1-5.

[11] Li J, Wang J, Li B, et al. MWPRFN: Multilevel wavelet pyramid recurrent fusion network for underwater image enhancement[J]. Displays, 2025: 103050.

[12] Zhang W, Wang H, Ren P, et al. MACT: Underwater image color correction via minimally attenuated channel transfer[J]. Pattern Recognition Letters, 2025, 187: 28-34.

[13] Li H, Wang H, Zhang Y, et al. Underwater image captioning: Challenges, models, and datasets[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2025, 220: 440-453.

[14] He K, Sun J, Tang X. Single image haze removal using dark channel prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 33(12): 2341-2353.

[15] Carlevaris-Bianco N, Mohan A, Eustice R M. Initial results in underwater single image dehazing. Proceedings of the Oceans 2010 Mts/IEEE Seattle[C]. 2010: 1-8.

[16] Chiang J Y, Chen Y C. Underwater image enhancement by wavelength compensation and dehazing[J]. IEEE Transactions on Image Processing, 2011, 21(4): 1756-1769.

[17] Drews P, Nascimento E, Moraes F, et al. Transmission estimation in underwater single images. Proceedings of the IEEE International Conference on Computer Vision Workshops[C]. 2013: 825-830.

[18] Galdran A, Pardo D, Picón A, et al. Automatic red-channel underwater image restoration[J]. Journal of Visual Communication and Image Representation, 2015, 26: 132-145.

[19] Perez J, Sanz P J, Bryson M, et al. A benchmarking study on single image dehazing techniques for underwater autonomous vehicles. Proceedings of the OCEANS 2017-Aberdeen. IEEE[C]. 2017: 1-9.

中国知网 https://www.cnki.net

[20] Li C, Guo J, Guo C, et al. A hybrid method for underwater image correction[J]. Pattern Recognition Letters, 2017, 94: 62-67.

[21] Peng Y T, Cao K, Cosman P C. Generalization of the dark channel prior for single image restoration[J]. IEEE Transactions on Image Processing, 2018, 27(6): 2856-2868.

[22] Song W, Wang Y, Huang D, et al. A rapid scene depth estimation model based on underwater light attenuation prior for underwater image restoration. Proceedings of the Advances in Multimedia Information Processing-PCM 2018: 19th Pacific-Rim Conference on Multimedia, Hefei, China, September 21-22, 2018, Proceedings, Part I 19. Springer International Publishing[C]. 2018: 678-688.

[23] Trucco E, Olmos-Antillon A T. Self-tuning underwater image restoration[J]. IEEE Journal of Oceanic Engineering, 2006, 31(2): 511-519.

[24] Hou W, Gray D J, Weidemann A D, et al. Automated underwater image restoration and retrieval of related optical properties. Proceedings of the 2007 IEEE International Geoscience and Remote Sensing Symposium[C]. 2007: 1889-1892.

[25] Serikawa S, Lu H. Underwater image dehazing using joint trilateral filter[J]. Computers & Electrical Engineering, 2014, 40(1): 41-50.

[26] Zhao X, Jin T, Qu S. Deriving inherent optical properties from background color and underwater image enhancement[J]. Ocean Engineering, 2015, 94: 163-172.

[27] Lu H, Li Y, Zhang L, et al. Contrast enhancement for images in turbid water[J]. JOSA A, 2015, 32(5): 886-893.

[28] Li C, Guo J, Wang B, et al. Single underwater image enhancement based on color cast removal and visibility restoration[J]. Journal of Electronic Imaging, 2016, 25(3): 033012.

[29] Peng Y T, Zhao X, Cosman P C. Single underwater image enhancement using depth estimation based on blurriness. Proceedings of the 2015 IEEE International Conference on Image Processing (ICIP)[C]. 2015: 4952-4956.

[30] Peng Y T, Cosman P C. Underwater image restoration based on image blurriness and light absorption[J]. IEEE Transactions on Image Processing, 2017, 26(4): 1579-1594.

[31] Akkaynak D, Treibitz T. A revised underwater image formation model. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. 2018: 6723-6732.

[32] Akkaynak D, Treibitz T. Sea-Thru: A Method for Removing Water From Underwater Images. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. 2019: 1682-1691.

[33] Zhou J, Yang T, Ren W, et al. Underwater image restoration via depth map and illumination estimation based on a single image[J]. Optics Express, 2021, 29(19): 29864-29886.

[34] Xie J, Hou G, Wang G, et al. A variational framework for underwater image dehazing and deblurring[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(6): 3514-3526.

[35] Zhou J, Yang T, Chu W, et al. Underwater image restoration via backscatter pixel prior and color compensation[J]. Engineering Applications of Artificial Intelligence, 2022, 111: 104785.

[36] Li J, Zhu X, Zheng Y, et al. Underwater image restoration based on light attenuation prior and color-contrast adaptive correction[J]. Image and Vision Computing, 2024, 150: 105217.

[37] Xiao B, Gao X, Huang H. Optimizing Underwater Image Restoration and Depth Estimation with Light Field Images[J]. Journal of Marine Science and Engineering, 2024, 12(6): 935.

中国知网 https://www.cnki.net

[38] Mathiazhagan J, Gauni S, Mohan R. Underwater video transmission with video enhancement using reduce hazing algorithm[J]. Journal of Optical Communications, 2024, 45(2): 379-388.

[39] Kim Y T. Contrast enhancement using brightness preserving bi-histogram equalization[J]. IEEE transactions on Consumer Electronics, 1997, 43(1): 1-8.

[40] Reza A M. Realization of the contrast limited adaptive histogram equalization (CLAHE) for real-time image enhancement[J]. Journal of VLSI Signal Processing Systems for Signal, Image and Video Technology, 2004, 38(1): 35-44.

[41] Ancuti C O, Ancuti C, De Vleeschouwer C, et al. Color channel compensation (3C): A fundamental pre-processing step for image enhancement[J]. IEEE Transactions on Image Processing, 2019, 29: 2653-2665.

[42] Kim W, Jeong J, You J. Contrast enhancement using histogram equalization based on logarithmic mapping[J]. Optical Engineering, 2012, 51(6): 067002.

[43] 丁畅, 董丽丽, 许文海. 图像梯度场双区间均衡化的细节增强[J]. 电子学报, 2017, 45(5): 1165-1174.

[44] 董丽丽, 丁畅, 许文海. 基于局部梯度场均衡化的图像增强方法[J]. 光电子. 激光, 2016, 27(5): 557-565.

[45] Zhou J, Pang L, Zhang W. Underwater image enhancement method based on color correction and three-interval histogram stretching[J]. Measurement Science and Technology, 2021, 32(11): 115405.

[46] Zhuang P, Li C, Wu J. Bayesian retinex underwater image enhancement[J]. Engineering Applications of Artificial Intelligence, 2021, 101: 104171.

[47] Zhang W, Zhuang P, Sun H H, et al. Underwater image enhancement via minimal color loss and locally adaptive contrast enhancement[J]. IEEE Transactions on Image Processing, 2022, 31: 3997-4010.

[48] Fu X, Fan Z, Ling M, et al. Two-step approach for single underwater image enhancement. Proceedings of the 2017 IEEE International Symposium on Intelligent Signal Processing and Communication Systems (ISPACS)[C]. 2017: 789-794.

[49] Fu X, Zhuang P, Huang Y, et al. A retinex-based enhancing approach for single underwater image. Proceedings of the 2014 IEEE International Conference on Image Processing (ICIP)[C]. 2014: 4572-4576.

[50] Zhang S, Wang T, Dong J, et al. Underwater image enhancement via extended multi-scale Retinex[J]. Neurocomputing, 2017, 245: 1-9.

[51] Nnolim U A. Improved partial differential equation-based enhancement for underwater images using local–global contrast operators and fuzzy homomorphic processes[J]. IET Image Processing, 2017, 11(11): 1059-1067.

[52] Zhang W, Dong L, Pan X, et al. Single Image Defogging Based on Multi-Channel Convolutional MSRCR[J]. IEEE Access, 2019, 7: 72492-72504.

[53] Zhou J, Zhang D, Zou P, et al. Retinex-Based Laplacian Pyramid Method for Image Defogging[J]. IEEE Access, 2019, 7: 122459-122472.

[54] Zhuang P, Wu J, Porikli F, et al. Underwater image enhancement with hyper-laplacian reflectance priors[J]. IEEE Transactions on Image Processing, 2022, 31: 5442-5455.

[55] Yu Q, Hou G, Zhang W, et al. Contour and texture preservation underwater image restoration via low-rank regularizations[J]. Expert Systems with Applications, 2025, 262: 125549.

中国知网 https://www.cnki.net

[56] Dai C, Li D, Chen C, et al. Robust underwater imaging model and automatic parameter optimization for underwater image restoration[J]. Engineering Applications of Artificial Intelligence, 2025, 151: 110651.

[57] Mertens T, Kautz J, Van Reeth F. Exposure fusion: A simple and practical alternative to high dynamic range photography. Proceedings of the Computer graphics forum. Oxford, UK: Blackwell Publishing Ltd[C]. 2009, 28(1): 161-171.

[58] Ancuti C, Ancuti C O, Haber T, et al. Enhancing underwater images and videos by fusion. Proceedings of the 2012 IEEE Conference on Computer Vision and Pattern Recognition[C]. 2012: 81-88.

[59] Shen J, Zhao Y, Yan S, et al. Exposure fusion using boosting Laplacian pyramid[J]. IEEE Transactions Cybernetics, 2014, 44(9): 1579-1590.

[60] Lu H, Li Y, Nakashima S, et al. Underwater image super-resolution by descattering and fusion[J]. IEEE Access, 2017, 5: 670-679.

[61] Ancuti C O, Ancuti C, De Vleeschouwer C, et al. Color balance and fusion for underwater image enhancement[J]. IEEE Transactions on Image Processing, 2017, 27(1): 379-393.

[62] Zhou J, Zhang D, Zhang W. Underwater image enhancement method via multi-feature prior fusion[J]. Applied Intelligence, 2022, 52(14): 16435-16457.

[63] Mishra A K, Kumar M, Choudhry M S. Fusion of multiscale gradient domain enhancement and gamma correction for underwater image/video enhancement and restoration[J]. Optics and Lasers in Engineering, 2024, 178: 108154.

[64] Sonawane J P, Patil M D, Birajdar G K. Adaptive rule-based colour component weight assignment strategy for underwater video enhancement[J]. The Imaging Science Journal, 2024, 72(8): 957-978.

[65] Zhang W, Liu Q, Feng Y, et al. Underwater image enhancement via principal component fusion of foreground and background[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2024.

[66] Cai B, Xu X, Jia K, et al. Dehazenet: An end-to-end system for single image haze removal[J]. IEEE Transactions on Image Processing, 2016, 25(11): 5187-5198.

[67] Shin Y S, Cho Y, Pandey G, et al. Estimation of ambient light and transmission map with common convolutional architecture. Proceedings of the OCEANS 2016 MTS/IEEE Monterey[C]. 2016: 1-7.

[68] Barbosa W V, Amaral H G B, Rocha T L, et al. Visual-quality-driven learning for underwater vision enhancement. Proceedings of the 2018 25th IEEE international conference on image processing (ICIP) [C]. 2018: 3933-3937.

[69] Cai B, Xu X, Jia K, et al. Dehazenet: An end-to-end system for single image haze removal[J]. IEEE Transactions on Image Processing, 2016, 25(11): 5187-5198.

[70] Ding X, Wang Y, Zhang J, et al. Underwater image dehaze using scene depth estimation with adaptive color correction. Proceedings of the OCEANS 2017-Aberdeen[C]. 2017: 1-5.

[71] Wang Y, Zhang J, Cao Y, et al. A deep CNN method for underwater image enhancement. Proceedings of the 2017 IEEE International Conference on Image Processing (ICIP) [C]. 2017: 1382-1386.

[72] Barbosa W V, Amaral H G B, Rocha T L, et al. Visual-quality-driven learning for underwater vision enhancement. Proceedings of the 2018 25th IEEE International Conference on Image Processing (ICIP)[C]. 2018: 3933-3937.

[73] Hou M, Liu R, Fan X, et al. Joint residual learning for underwater image enhancement. Proceedings of the 2018 25th IEEE International Conference on Image Processing (ICIP)[C]. 2018: 4043-4047.

中国知网 https://www.cnki.net

[74] Cao K, Peng Y T, Cosman P C. Underwater image restoration using deep networks to estimate background light and scene depth. Proceedings of the 2018 IEEE Southwest Symposium on Image Analysis and Interpretation (SSIAI)[C]. 2018: 1-4.

[75] Wang K, Hu Y, Chen J, et al. Underwater image restoration based on a parallel convolutional neural network[J]. Remote sensing, 2019, 11(13): 1591.

[76] Liu R, Hou M, Liu J, et al. Compounded layer-prior unrolling: A unified transmission-based image enhancement framework. Proceedings of the 2019 IEEE International Conference on Multimedia and Expo (ICME)[C]. 2019: 538-543.

[77] Li C, Guo C, Ren W, et al. An underwater image enhancement benchmark dataset and beyond[J]. IEEE Transactions on Image Processing, 2019, 29: 4376-4389.

[78] Li C, Anwar S, Hou J, et al. Underwater image enhancement via medium transmission-guided multi-color space embedding[J]. IEEE Transactions on Image Processing, 2021, 30: 4985-5000.

[79] Srinath S, Chandrasekar A, Jamadagni H, et al. UnDIVE: Generalized Underwater Video Enhancement Using Generative Priors[J]. arXiv preprint arXiv:2411.05886, 2024.

[80] Honnutagi P, Laitha Y S, Mytri V D. Optimized underwater light attenuation prior-based depth estimation and adaptive feature fusion CNN for underwater image and video enhancement[J]. Applied Soft Computing, 2024, 167: 112308.

[81] Shen L, Xia H, Zhang X, et al. U 2 PNet: An unsupervised underwater image-restoration network using polarization[J]. IEEE Transactions on Cybernetics, 2024.

[82] Nathan O B, Levy D, Treibitz T, et al. Osmosis: RGBD diffusion prior for underwater image restoration. Proceedings of the European Conference on Computer Vision. Cham: Springer Nature Switzerland[C]. 2024: 302-319.

[83] Wang H, Zhang W, Bai L, et al. Metalantis: A comprehensive underwater image enhancement framework[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024.

[84] Wang H, Zhang W, Ren P. Self-organized underwater image enhancement[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2024, 215: 1-14.

[85] Zuo X, Jiang J, Shen J, et al. Improving underwater semantic segmentation with underwater image quality attention and muti-scale aggregation attention[J]. Pattern Analysis and Applications, 2025, 28(2): 1-12.

[86] Xu S, Cong Q, Tang S, et al. StatEstNet and FeDeNet: A Hybrid Framework for Underwater Image Enhancement[J]. Digital Signal Processing, 2025: 105170.

[87] Zhang Z, Liu G, Wang M, et al. Deep Joint Source-Channel Coding of Underwater Image Enhancement in AUV Swarms[J]. IEEE Communications Letters, 2025.

[88] Liu D, Rao Y, Zhu J, et al. FSformer: fusing frequency and spatial domain transformer network for underwater image enhancement[J]. Multimedia Systems, 2025, 31(2): 168.

[89] Zhang H, Xu H, Yu X, et al. CDF-UIE: Leveraging Cross-Domain Fusion for Underwater Image Enhancement[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025.

[90] Zhao C, Cai W, Dong C, et al. Wavelet-based fourier information interaction with frequency diffusion adjustment for underwater image restoration. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition[C]. 2024: 8281-8291.

中国知网 https://www.cnki.net

[91] Zhang J, Chen W, Lin Z, et al. Underwater image restoration based on progressive guidance[J]. Signal Processing, 2024, 223: 109569.

[92] Xie Y, Kong L, Chen K, et al. Uveb: A large-scale benchmark and baseline towards real-world underwater video enhancement. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition[C]. 2024: 22358-22367.

[93] Li J, Skinner K A, Eustice R M, et al. WaterGAN: Unsupervised generative network to enable real-time color correction of monocular underwater images[J]. IEEE Robotics and Automation letters, 2017, 3(1): 387-394.

[94] Uplavikar P M, Wu Z, Wang Z. All-in-One Underwater Image Enhancement Using Domain-Adversarial Learning. Proceedings of the CVPR workshops[C]. 2019: 1-8.

[95] Li C, Anwar S, Porikli F. Underwater scene prior inspired deep underwater image and video enhancement[J]. Pattern recognition, 2020, 98: 107038.

[96] Jiang Z, Li Z, Yang S, et al. Target oriented perceptual adversarial fusion network for underwater image enhancement[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 32(10): 6584-6598.

[97] Ye X, Li Z, Sun B, et al. Deep joint depth estimation and color correction from monocular underwater images based on unsupervised adaptation networks[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2019, 30(11): 3995-4008.

[98] Lin Y, Zhou J, Ren W, et al. Autonomous underwater robot for underwater image enhancement via multi-scale deformable convolution network with attention mechanism[J]. Computers and Electronics in Agriculture, 2021, 191: 106497.

[99] Fabbri C, Islam M J, Sattar J. Enhancing underwater imagery using generative adversarial networks. Proceedings of the 2018 IEEE International Conference on Robotics and Automation (ICRA)[C]. 2018: 7159-7165.

[100] Chen L, Jiang Z, Tong L, et al. Perceptual underwater image enhancement with deep learning and physical priors[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2020, 31(8): 3078-3092.

[101] Qi Q, Zhang Y, Tian F, et al. Underwater image co-enhancement with correlation feature matching and joint learning[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(3): 1133-1147.

[102] Wang Z, Shen L, Xu M, et al. Domain adaptation for underwater image enhancement[J]. IEEE Transactions on Image Processing, 2023, 32: 1442-1457.

[103] Zheng Y, Luo J, Chen W, et al. FUVC: A flexible codec for underwater video transmission[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024.

[104] Boya S, Nallaball R C S, Leke S, et al. Enhancing of underwater image and video using CycleGAN. Proceedings of the AIP Conference Proceedings[C]. 2025, 3237(1).

[105] Land E H, McCann J J. Lightness and retinex theory[J]. Journal of the Optical society of America, 1971, 61(1): 1-11.

[106] Jobson D J, Rahman Z, Woodell G A. Properties and performance of a center/surround retinex[J]. IEEE Transactions on Image Processing, 1997, 6(3): 451-462.

中国知网 https://www.cnki.net

[107] Rahman Z, Jobson D J, Woodell G A. Multi-scale retinex for color image enhancement. Proceedings of 3rd IEEE International Conference on Image Processing (ICIP)[C]. 1996, 3: 1003-1006.

[108] Jiang B, Woodell G A, Jobson D J. Novel multi-scale retinex with color restoration on graphics processing unit[J]. Journal of Real-Time Image Processing, 2015, 10: 239-253.

[109] Zhou J, Chen S, Zhang D, et al. Adaptive variational decomposition for water-related optical image enhancement[J]. ISPRS journal of photogrammetry and remote sensing, 2024, 216: 15-31.

[110] Alsakar Y M, Sakr N A, El-Sappagh S, et al. Underwater image restoration and enhancement: a comprehensive review of recent trends, challenges, and applications[J]. The Visual Computer, 2024, 2024: 1-49.

[111] Hu X, Shi M, Wang W, et al. Demystify transformers & convolutions in modern image deep networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 47(4): 2416 - 2428.

[112] Han J, Moraga C. The influence of the sigmoid function parameters on the speed of backpropagation learning. Proceedings of the International workshop on artificial neural networks[C]. Berlin, Heidelberg: Springer Berlin Heidelberg. 1995: 195-201.

[113] Shen S L, Zhang N, Zhou A, et al. Enhancement of neural networks with an alternative activation function tanhLU[J]. Expert Systems with Applications, 2022, 199: 117181.

[114] Sandfeld S. A Gentle Introduction to Deep Learning[M]//Materials Data Science: Introduction to Data Mining, Machine Learning, and Data-Driven Predictions for Materials Science and Engineering. Cham: Springer International Publishing, 2023: 497-532.

[115] Xu J, Li Z, Du B, et al. Reluplex made more practical: Leaky ReLU. Proceedings of the 2020 IEEE Symposium on Computers and Communications (ISCC)[C]. 2020: 1-7.

[116] Devi T, Deepa N. A novel intervention method for aspect-based emotion Using Exponential Linear Unit (ELU) activation function in a Deep Neural Network. Proceedings of the 2021 5th International Conference on Intelligent Computing and Control Systems (ICICCS)[C]. 2021: 1671-1675.

[117] Cai S. Adashift: Learning discriminative self-gated neural feature activation with an adaptive shift factor. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition[C]. 2024: 5947-5956.

[118] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.

[119] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. 2016: 770-778.

[120] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation. Medical Image Computing and Computer-assisted Intervention-MICCAI 2015: 18th International Conference[C]. Munich, Germany, October 5-9, 2015, Proceedings, Part III 18. Springer International Publishing, 2015: 234-241.

[121] Zhou Z, Rahman Siddiquee M M, Tajbakhsh N, et al. Unet++: A nested u-net architecture for medical image segmentation. Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support: 4th International Workshop, DLMIA 2018, and 8th International Workshop, ML-CDS 2018, Held in Conjunction with MICCAI 2018[C]. Granada, Spain, September 20, 2018, Proceedings 4. Springer International Publishing, 2018: 3-11.

中国知网 https://www.cnki.net

[122] Korhonen J, You J. Peak signal-to-noise ratio revisited: Is simple beautiful? Proceedings of the 2012 Fourth International Workshop on Quality of Multimedia Experience[C]. 2012: 37-38.

[123] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.

[124] Zhang L, Shen Y, Li H. VSI: A visual saliency-induced index for perceptual image quality assessment[J]. IEEE Transactions on Image Processing, 2014, 23(10): 4270-4281.

[125] Zhang L, Zhang L, Mou X, et al. FSIM: A feature similarity index for image quality assessment[J]. IEEE Transactions on Image Processing, 2011, 20(8): 2378-2386.

[126] Panetta K, Gao C, Agaian S. Human-visual-system-inspired underwater image quality measures[J]. IEEE Journal of Oceanic Engineering, 2015, 41(3): 541-551.

[127] Yang M, Sowmya A. An underwater color image quality evaluation metric[J]. IEEE Transactions on Image Processing, 2015, 24(12): 6062-6071.

[128] Wang Y, Li N, Li Z, et al. An imaging-inspired no-reference underwater color image quality assessment metric[J]. Computers & Electrical Engineering, 2018, 70: 904-913.

[129] Fang Y, Ma K, Wang Z, et al. No-reference quality assessment of contrast-distorted images based on natural scene statistics[J]. IEEE Signal Processing Letters, 2014, 22(7): 838-842.

[130] Land E H. The retinex theory of color vision[J]. Scientific american, 1977, 237(6): 108-129.

[131] Buchsbaum G. A spatial processor model for object colour perception[J]. Journal of the Franklin institute, 1980, 310(1): 1-26.

[132] Van De Weijer J, Gevers T, Gijsenij A. Edge-based color constancy[J]. IEEE Transactions on Image Processing, 2007, 16(9): 2207-2214.

[133] Finlayson G D, Trezzi E. Shades of gray and colour constancy. Proceedings of the Color and imaging conference[C]. 2004, 12: 37-41.

[134] Qian Y, Kamarainen J K, Nikkanen J, et al. On finding gray pixels. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition[C]. 2019: 8062-8070.

[135] Qian Y, Pertuz S, Nikkanen J, et al. Revisiting gray pixel for statistical illumination estimation[J]. arXiv preprint arXiv:1803.08326, 2018.

[136] Moon S W, Lee H S, Eom I K. Improvement of underwater colour correction using standard deviation ratio[J]. Electronics Letters, 2020, 56(20): 1051-1054.

[137] Jha M, Bhandari A K. CBLA: Color balanced locally adjustable underwater image enhancement[J]. IEEE Transactions on Instrumentation and Measurement, 2024.

[138] Jerlov N G. Marine optics[M]. Elsevier, 1976.

[139] Berman D, Avidan S. Non-local image dehazing. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. 2016: 1674-1682.

[140] Liu C, Li H, Wang S, et al. A dataset and benchmark of underwater object detection for robot picking. Proceedings of the 2021 IEEE international conference on multimedia & expo workshops (ICMEW) [C]. 2021: 1-6.

[141] Islam M J, Luo P, Sattar J. Simultaneous enhancement and super-resolution of underwater imagery for improved visual perception[J]. arXiv preprint arXiv:2002.01155, 2020.

[142] Afifi M, Barron J T, LeGendre C, et al. Cross-camera convolutional color constancy. Proceedings of the IEEE/CVF International Conference on Computer Vision[C]. 2021: 1981-1990.

中国知网 https://www.cnki.net

[143] Li F, Wu J, Wang Y, et al. A color cast detection algorithm of robust performance. Proceedings of the 2012 IEEE Fifth International Conference on Advanced Computational Intelligence (ICACI)[C]. 2012: 662-664.

[144] Lee H S, Moon S W, Eom I K. Underwater image enhancement using successive color correction and superpixel dark channel prior[J]. Symmetry, 2020, 12(8): 1220.

[145] Abdul Ghani A S, Mat Isa N A. Underwater image quality enhancement through composition of dual-intensity images and Rayleigh-stretching[J]. SpringerPlus, 2014, 3(757): 1-14.

[146] Liu R, Jiang Z, Yang S, et al. Twin adversarial contrastive learning for underwater image enhancement and beyond[J]. IEEE Transactions on Image Processing, 2022, 31: 4922-4936.

[147] Kang Y, Jiang Q, Li C, et al. A perception-aware decomposition and fusion framework for underwater image enhancement[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 33(3): 988-1002.

[148] Guo C, Wu R, Jin X, et al. Underwater ranker: Learn which is better and how to be better. Proceedings of the AAAI Conference on Artificial Intelligence[C]. 2023, 37(1): 702-709.

[149] Zhou J, Liu Q, Jiang Q, et al. Underwater camera: Improving visual perception via adaptive dark pixel prior and color correction[J]. International Journal of Computer Vision, 2023, 2023: 1-19.

[150] Zhou J, Pang L, Zhang D, et al. Underwater image enhancement method via multi-interval subhistogram perspective equalization[J]. IEEE Journal of Oceanic Engineering, 2023, 48(2): 474-488.

[151] Ma L, Jin D, An N, et al. Bilevel fast scene adaptation for low-light image enhancement[J]. International Journal of Computer Vision, 2023, 2023: 1-19.

[152] Khan M D R, Kulkarni A, Phutke S S, et al. Underwater image enhancement with phase transfer and attention. Proceedings of the 2023 International Joint Conference on Neural Networks (IJCNN)[C]. 2023: 1-8.

[153] Pathak D, Krahenbuhl P, Donahue J, et al. Context encoders: Feature learning by inpainting. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition[C]. 2016: 2536-2544.

[154] Johnson J, Alahi A, Fei-Fei L. Perceptual losses for real-time style transfer and super-resolution. Proceedings of the Computer Vision-ECCV 2016: 14th European Conference[C]. Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part II 14. Springer International Publishing. 2016: 694-711.

[155] Dong C, Loy C C, He K, et al. Image super-resolution using deep convolutional networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 38(2): 295-307.

[156] Li H, Li J, Wang W. A fusion adversarial underwater image enhancement network with a public test dataset[J]. arXiv preprint arXiv:1906.06819, 2019.

[157] Peng L, Zhu C, Bian L. U-shape transformer for underwater image enhancement[J]. IEEE Transactions on Image Processing, 2023, 32: 3066-3079.

[158] Islam M J, Xia Y, Sattar J. Fast underwater image enhancement for improved visual perception[J]. IEEE Robotics and Automation Letters, 2020, 5(2): 3227-3234.

[159] Shen Z, Xu H, Luo T, et al. UDAformer: Underwater image enhancement based on dual attention transformer[J]. Computers & Graphics, 2023, 111: 77-88.

[160] Fu Z, Wang W, Huang Y, et al. Uncertainty inspired underwater image enhancement. Proceedings of the European Conference on Computer Vision[C]. Cham: Springer Nature Switzerland, 2022: 465-482.

中国知网 https://www.cnki.net

[161] Cao J, Peng W, Liu Y, et al. ERD: Encoder-Residual-Decoder Neural Network for Underwater Image Enhancement[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2025.

[162] Wang H, Köser K, Ren P. Large foundation model empowered discriminative underwater image enhancement[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025.

[163] Tang C, von Lukas U F, Vahl M, et al. Efficient underwater image and video enhancement based on Retinex[J]. Signal, Image and Video Processing, 2019, 13: 1011-1018.

[164] Zhou J, Yao J, Zhang W, et al. Multi-scale retinex-based adaptive gray-scale transformation method for underwater image enhancement[J]. Multimedia Tools and Applications, 2022, 81(2): 1811-1831.

[165] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 39(6): 1137-1149.

[166] Song W, Wang Y, Huang D, et al. Enhancement of underwater images with statistical model of background light and optimization of transmission map[J]. IEEE Transactions on Broadcasting, 2020, 66(1): 153-169.

[167] Islam M J, Wang R, Sattar J. SVAM: Saliency-guided visual attention modeling by autonomous underwater robots[J]. arXiv preprint arXiv:2011.06252, 2020.

[168] Cao J, Zeng Z, Zhang X, et al. Unveiling the underwater world: CLIP perception model-guided underwater image enhancement[J]. Pattern Recognition, 2025: 111395.

[169] Pramanick A, Sur A, Saradhi V V. Harnessing multi-resolution and multi-scale attention for underwater image restoration[J]. The Visual Computer, 2025: 1-20.

[170] Lai W S, Huang J B, Ahuja N, et al. Fast and accurate image super-resolution with deep laplacian pyramid networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 41(11): 2599-2613.

[171] Yuan J, Cao W, Cai Z, et al. An underwater image vision enhancement algorithm based on contour bougie morphology[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 59(10): 8117-8128.

[172] Yuan J, Cai Z, Cao W. TEBCF: Real-world underwater image texture enhancement model based on blurriness and color fusion[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-15.

[173] Berman D, Levy D, Avidan S, et al. Underwater single image color restoration using haze-lines and a new quantitative dataset[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 43(8): 2822-2837.

中国知网 https://www.cnki.net