学号：B21020072



长春理工大学

Changchun University of Science and Technology

博士学位（毕业）论文

散射介质退化图像复原技术研究

研 究 生 ： 董伟达

学科专业 ： 仪器科学与技术

指导教师 ： 王春艳教授

二〇二五年五月

中国知网 https://www.cnki.net

分类号：TP391　　密　级：公开
U D C：004.93　　编　号：

散射介质退化图像复原技术研究

学位授予单位及代码：长春理工大学（10186）

学科专业名称及代码：仪器科学与技术(0804)

研究方向：光电检测技术与质量控制

申请学位级别：博士

研究生姓名：董伟达

指导教师姓名：王春艳 教授

论文起止时间：2022 年 07 月— 2025 年 03 月

中国知网 https://www.cnki.net

The Research on Degraded Image Restoration Techniques in Scattering Media

by

Dissertation submitted to

Changchun University of Science and Technology

in partial fulfillment of the requirements

for the degree of

Doctor of Philosophy

Supervisor

Professor **Chunyan Wang**

May, 2025

中国知网 https://www.cnki.net

摘　要

摄像是人类获取外部信息的主要手段之一。高质量的图像富含大量的有用信息，不仅能够辅助人们做出相应的决策和判断，而且可以促进计算机视觉任务需求的提升。然而受云、雾和水体等散射介质的干扰，使成像设备采集的图像发生不同程度的退化，丢失大量有用信息，难以被决策者和计算机视觉领域充分利用。因此，通过图像复原技术获取高质量的清晰图像，已经成为机器视觉领域亟需解决的突出问题。近年来，深度学习驱动下的视觉任务处理能力显著提升，尤其在图像识别、分割精度与目标跟踪等领域取得重要突破。在图像复原任务中，深度学习技术也发挥了重要作用。主要体现在特征提取与学习、端到端复原、生成对抗网络、Transformer架构、多任务学习与泛化能力的提升等方面。

因此，本文基于深度学习相关理论，针对受薄云、雾和水体三类散射介质的干扰而获取的退化图像复原问题展开研究，具体研究内容如下：

(1) 针对现有去雾技术在复原自然场景有雾图像时存在色彩失真、去雾过度等问题，提出基于多尺度注意力特征增强的图像去雾技术。该技术通过有效结合注意力机制、上下文增强模块和高效空间金字塔模块，分别构建了注意力特征增强模块和多尺度特征增强模块。注意力特征增强模块用以解决注意力机制提取特征过程中丢失细节信息的问题，其不但能够通过注意力机制自适应的提取重要通道特征和与雾和高频信息相关的像素特征，并且能够有效捕捉上下文信息，抑制冗余信息。多尺度特征增强模块是对注意力特征增强模块的进一步补充，其结合了高效空间金字塔模块和注意力特征增强模块，该模块具备注意力特征增强模块的全部优势，同时能够获取不同尺度的特征信息，从而增强网络的表达能力。实验结果表明，复原出的自然场景有雾图像取得了较好的去雾效果，颜色信息保留完整，优于现有的先进去雾技术。

(2) 针对现有去雾技术在复原遥感场景有雾图像时存在细节信息丢失严重等问题，提出基于细节增强的遥感图像去雾技术。该技术是一个改进的5阶段U-Net型网络结构，利用提出的细节增强块替换U-Net中的卷积块。细节增强块主要包含多尺度细节增强单元和阶梯式注意力细节增强单元，用以获取遥感图像的多尺度特征，关注全局共享信息及与位置相关的局部信息，增强细节信息。同时在该技术中嵌入了SK Fusion、并行归一化模块和软重构，以分别用来融合深浅层特征、增强网络拟合能力，调整并重建清晰遥感图像。实验结果表明，该技术能够有效的保留图像细节信息，具有较好的鲁棒性。

(3) 针对现有去云雾技术在复原遥感场景中有雾或薄云图像时存在云雾去除不彻底、纹理信息缺失严重等问题，提出基于逆认知学习的遥感图像去云雾技术。该技

中国知网　https://www.cnki.net

术中的多尺度逆认知学习块是整个网络的核心组件，其能够有效的提取图像的多尺度信息，对不均匀分布的云雾特征进行自适应约束，它与 SK Fusion 和软重建技术等组件的共同作用，复原出了高质量的遥感图像。其中，在多尺度逆认知学习块中为反向模拟人脑从整体到局部认知图像过程，设计了逆认知学习模块以逐步的实现从局部到全局的特征学习。为有效对云雾特征进行约束，设计了并行云雾约束模块，实现了对云雾信息强有力的约束。实验结果表明，该技术具有很好的去云雾能力，纹理等细节信息保留较好，复原的遥感图像更接近现实世界视觉效果。

(4) 针对水下图像存在颜色失真和模糊等问题，提出基于门控融合 Transformer 的水下图像复原技术。该技术是以门控融合 Transformer 块为核心的 U-Net 型网络，用以获取水下图像的全局信息，增强细节信息。在门控融合 Transformer 块中，通过引入的通道像素自注意力和移位窗口像素自注意力实现通道特征和像素特征的双重关注，利用提出的注意力前馈网络，整合并增强细节信息，实现不同层间的细节互补。为避免局部细节信息的丢失，提出门控融合连接器替换常用的跳跃连接，进一步提升网络恢复图像细节的能力。此外，将提出的深层环境适配器嵌入门控融合 Transformer 块中，以灵活的对输入特征重要信息进行关注，提升网络的表征能力。实验结果表明，该技术有效的复原了退化水下图像，恢复了水下图像的颜色信息，增强了水下图像的局部细节，明显提升了图像质量。

关键词：深度学习；散射介质；退化图像；图像去云雾；水下图像复原

中国知网 https://www.cnki.net

ABSTRACT

Photography is one of the main means for human beings to obtain external information. High-quality images are rich in useful information, which can not only assist people to make appropriate decisions and judgments, but also promote the improvement of computer vision task requirements. However, due to the interference of cloud, fog, water and other scattering media, the images captured by imaging devices are degraded to varying degrees, and a large number of useful information is lost, which is difficult to be fully utilized by decision makers and computer vision fields. Therefore, it has become an urgent problem to be solved in the field of machine vision to obtain high quality and clear images through image restoration technology. In recent years, the ability of visual task processing driven by deep learning has been significantly improved, especially in the fields of image recognition, segmentation accuracy and target tracking. Deep learning technology also plays an important role in image restoration tasks. It is mainly reflected in feature extraction and learning, end-to-end restoration, generation of antagonistic networks, Transformer architecture, multi-task learning and generalization capabilities.

Therefore, based on the theory of deep learning, this paper studies the restoration of degraded images obtained by the interference of three kinds of scattering media, namely, thin clouds, fog and water.

(1) Aiming at the problems of color distortion and over-defogging in the restoration of foggy images in natural scenes by existing defogging technologies, an image defogging technology based on multi-scale attention feature enhancement is proposed. By effectively combining the attention mechanism, the context enhancement module and the efficient spatial pyramid module, the attention feature enhancement module and the multi-scale feature enhancement module are constructed respectively. The attention feature enhancement module is used for solving the problem that detail information is lost in the feature extraction process of the attention mechanism, and can not only adaptively extract important channel features and pixel features related to fog and high-frequency information through the attention mechanism, but also effectively capture context information and inhibit redundant information. The multi-scale feature enhancement module is a further supplement to the attention feature enhancement module, which combines the efficient spatial pyramid module and the attention feature enhancement module. The module has all the advantages of the attention feature enhancement module, and can obtain feature information of different scales, thereby enhancing the expressive power of the network. The experimental results show that the restored natural scene images with fog achieve good defogging effect, and color information is kept intact, which is better than existing advanced defogging technology.

(2) The existing defogging technology has the problem of serious loss of detail information when restoring the foggy image of the remote sensing scene.

中国知网 https://www.cnki.net

In this paper, a remote sensing image defogging technique based on detail enhancement is proposed. This technique is an improved 5-stage U-Net type network structure, which uses the proposed detail enhancement block to replace the convolution block in U-Net. The detail enhancement block mainly comprises a multi-scale detail enhancement unit and a stepped attention detail enhancement unit, and is used for acquiring multi-scale characteristics of a remote sensing image, paying attention to global shared information and location-related local information, and enhancing detail information. At the same time, SK Fusion and parallel normalization module are embedded in this technology to fuse deep and shallow features and enhance the fitting ability of the network, respectively. The soft reconstruction technology is used to adjust and reconstruct clear remote sensing images. The experimental results show that the technique can effectively preserve the image details and has good robustness.

(3) In order to solve the problems of incomplete cloud and fog removal and serious lack of texture information when the existing cloud and fog removal technology is used to restore the remote sensing scene with fog or thin cloud, a remote sensing image cloud and fog removal technology based on inverse cognitive learning is proposed. The multi-scale inverse cognitive learning block in the technology is the core component of the whole network, which can effectively extract the multi-scale information of the image and carry out adaptive constraint on the cloud and mist characteristics of uneven distribution. With the joint action of SK Fusion and soft reconstruction technology, the high-quality remote sensing image is restored. In that multi-scale inverse cognitive learn block, an inverse cognitive learning module is design to realize feature learning from the whole to the whole step by step in order to reversely simulate the image cognitive process of the human brain from the whole to the part. In order to effectively constrain the cloud and fog characteristics, a parallel cloud and fog constraint module is designed to achieve a strong constraint on cloud and fog information. The experimental results show that the technology has a good ability to remove cloud and fog, texture and other details are better preserved and the restored remote sensing image is closer to the visual effect of the real world.

(4) Aiming at the problems of color distortion and blur in underwater images, an underwater image restoration technology based on gated fusion Transformer is proposed. The technology is a U-shaped network with a gated fusion Transformer block as the core, which is used to obtain the global information of underwater images, and enhance detail information. In the gated fused Transform er block, the channel pixel self-attention and the shift window pixel self-attention are introduced to realize the dual attention of channel features and pixel features, and the proposed attention feed-forward network is used to integrate and enhance the detail information, so as to realize the detail complementarity between different layers. In order to avoid the loss of local detail information, a gated fusion connector is proposed to replace the commonly used skip connection, which further improves the ability of the network to recover detail information. In addition, the proposed deep

中国知网 https://www.cnki.net

environment adapter is embedded into the gated fusion Transformer block to flexibly focus on the important information of the input features and improve the representation ability of the network. The experimental results show that the technology can effectively restore the degraded underwater image, restore the color information of the underwater image, enhance the local details of the underwater image, and significantly improve the image quality.

Key words: deep learning; scattering media; degraded image; image cloud removal; underwater image restoration

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 课题背景及研究意义.....1
1.2 国内外研究现状.....2
1.2.1 图像去云雾研究现状.....2
1.2.2 水下图像复原研究现状.....7
1.3 本文主要研究内容.....10
1.4 本文结构安排.....12
第 2 章 图像退化及复原相关理论研究.....15
2.1 光在散射介质中的退化机理.....15
2.1.1 散射及散射介质概述.....15
2.1.2 介质对光学成像的衰减作用.....16
2.1.3 散射介质对光学成像的影响.....17
2.2 云雾天及水下退化图像复原理论.....19
2.2.1 图像复原理论概述.....19
2.2.2 云雾天图像复原理论.....19
2.2.3 水下图像复原理论.....24
2.3 基于深度学习的图像复原机理.....29
2.3.1 神经网络基础理论.....29
2.3.2 U-Net 型网络.....32
2.3.3 Transformer.....33
2.3.4 Vision Transformer.....36
2.4 云雾及水下图像数据集.....37
2.4.1 自然场景图像去雾数据集.....37
2.4.2 遥感场景图像去雾及去薄云数据集.....41
2.4.3 水下场景图像数据集.....43
2.5 复原图像质量评价.....45
2.5.1 主观质量评价.....46
2.5.2 客观质量评价.....46
2.6 本章小结.....48
第 3 章 基于多尺度注意力特征增强的图像去雾技术研究.....49
3.1 引言.....49
3.2 网络架构设计.....50
3.2.1 通道注意力.....51
3.2.2 像素注意力.....52

中国知网 https://www.cnki.net

3.2.3 上下文增强模块.....53
3.2.4 去雾融合块.....53
3.2.5 损失函数.....57
3.3 实验验证与结果分析.....58
3.3.1 数据集选择和相关实验细节.....58
3.3.2 定量比较.....59
3.3.3 定性比较.....60
3.3.4 参数量及计算量比较.....63
3.4 消融研究.....63
3.5 本章小结.....64
第 4 章 基于细节增强的遥感图像去雾技术研究.....65
4.1 引言.....65
4.2 网络架构设计.....66
4.2.1 细节增强块.....67
4.2.2 SK Fusion 和软重建技术.....71
4.2.3 损失函数.....71
4.3 实验验证与结果分析.....71
4.3.1 数据集选择和相关实验细节.....72
4.3.2 定量比较.....73
4.3.3 定性比较.....74
4.3.4 参数量及计算量比较.....78
4.4 消融研究.....78
4.5 本章小结.....79
第 5 章 基于逆认知学习的遥感图像去云雾技术研究.....81
5.1 引言.....81
5.2 网络架构设计.....82
5.2.1 编码器.....83
5.2.2 瓶颈层.....86
5.2.3 解码器.....87
5.2.4 软重建.....88
5.2.5 损失函数.....88
5.3 实验验证与结果分析.....88
5.3.1 数据集选择和相关实验细节.....89
5.3.2 定量比较.....90
5.3.3 定性比较.....91
5.3.4 参数量及计算量比较.....96
5.4 消融研究.....96
5.5 本章小结.....98

中国知网 https://www.cnki.net

第 6 章 基于门控融合 Transformer 的水下图像复原技术研究 99
6.1 引言 99
6.2 网络架构设计 100
6.2.1 门控融合 Transfomer 块 101
6.2.2 门控融合连接器 105
6.2.3 损失函数 106
6.3 实验验证与结果分析 106
6.3.1 数据集选择和相关实验细节 107
6.3.2 定量比较 107
6.3.3 定性比较 109
6.3.4 参数量及计算量比较 111
6.4 消融研究 112
6.5 本章小结 113
第 7 章 总结与展望 115
7.1 全文研究工作总结及创新点 115
7.1.1 研究工作总结 115
7.1.2 创新点 117
7.2 未来研究工作展望 118
参考文献 119

中国知网 https://www.cnki.net

插图索引

图 1.1 退化图像示例图 2
图 1.2 论文主要研究内容架构图 12
图 2.1 光在散射介质中的退化过程 16
图 2.2 光波波长与海水体积衰减系数关系图 17
图 2.3 水下图像成像模型 18
图 2.4 光强随场景深度的变化关系 20
图 2.5 大气散射模型示意图 21
图 2.6 部分暗通道示例图 22
图 2.7 暗通道技术去除自然场景中的雾 22
图 2.8 暗通道技术去除遥感场景中的雾 23
图 2.9 暗通道技术去除薄云 23
图 2.10 DehazeNet 网络架构图 24
图 2.11 DehazeNet 去雾结果 24
图 2.12 红通道先验技术复原结果 26
图 2.13 WaterNet 网络架构图 27
图 2.14 WaterNet 复原水下图像结果 27
图 2.15 UShape Transformer 的网络架构 28
图 2.16 UShape Transformer 复原水下图像结果 28
图 2.17 端到端的退化图像复原技术流程图 29
图 2.18 CNN 发展脉络图 30
图 2.19 CBAM 结构图 31
图 2.20 Inception 模块结构图 32
图 2.21 接受场块结构图 32
图 2.22 U-Net 网络架构图 33
图 2.23 U-Net 在 ISBI 挑战赛的分割结果 33
图 2.24 Transformer 示意图 34
图 2.25 多头注意力 35
图 2.26 缩放点乘注意力 35
图 2.27 Vision Transformer 结构图 37
图 2.28 ITS 数据集示例图 38
图 2.29 OTS 数据集示例图 39
图 2.30 HSTS 测试集示例图 39

中国知网 https://www.cnki.net

图 2.31 SOTS 合成室内及室外测试集示例图 40
图 2.32 RTTS 数据集示例图 40
图 2.33 NHHAZE 数据集示例图 41
图 2.34 Satehaze1K 数据集示例图 42
图 2.35 HRSD 数据集示例图 43
图 2.36 RICE-I数据集示例图 43
图 2.37 UIEB 数据集示例图 44
图 2.38 LSUI 数据集示例图 44
图 2.39 U45 数据集示例图 45
图 2.40 UPoor 数据集示例图 45
图 3.1 多尺度注意力特征增强去雾网络架构图 50
图 3.2 最大池化过程示例图 51
图 3.3 平均池化过程示例图 51
图 3.4 通道注意力结构图 51
图 3.5 像素注意力结构图 52
图 3.6 上下文增强模块结构图 53
图 3.7 去雾融合块结构图 54
图 3.8 多尺度注意力增强模块结构图 54
图 3.9 普通卷积和扩张卷积对比图 55
图 3.10 高效空间金字塔模块结构图 55
图 3.11 Relu 激活函数 56
图 3.12 PRelu 激活函数 56
图 3.13 注意力特征增强模块结构图 57
图 3.14 网络训练学习曲线 59
图 3.15 在 SOTS-outdoor 数据集上的定性结果 61
图 3.16 在 NHHAZE 数据集上的定性结果 61
图 3.17 在 RTTS 数据集上的定性结果 62
图 3.18 在真实世界图像上的定性结果 62
图 4.1 细节增强去雾网络架构图 67
图 4.2 细节增强块结构图 68
图 4.3 PNM 结构图 69
图 4.4 阶梯式融合像素注意力结构图 70
图 4.5 网络训练学习曲线 72
图 4.6 在 SateHaze1k-thin 数据集上定性结果 75

中国知网 https://www.cnki.net

图 4.7 在 SateHaze1k-moderate 数据集上的定性结果 75
图 4.8 在 StaeHaze1k-thick 数据集上的定性结果 76
图 4.9 在 LHID 数据集上的定性结果 76
图 4.10 在 DHID 数据集上的定性结果 77
图 4.11 真实世界遥感有雾图像定性结果 77
图 5.1 逆认知学习网络架构图 82
图 5.2 多尺度逆认知学习块结构图 83
图 5.3 逆认知学习模块结构图 84
图 5.4 并行云雾约束模块结构图 85
图 5.5 特征注意力结构图 86
图 5.6 网络训练学习曲线 89
图 5.7 在 SateHaze1k 数据集上的定性结果 92
图 5.8 在 RICE-I 数据集上的定性结果 93
图 5.9 在 RRSD 数据集上的定性结果 94
图 5.10 在 AID 数据集上的定性结果 95
图 5.11 在 UC Merced Land 数据集上的定性结果 95
图 5.12 在现实世界中的定性结果 96
图 5.13 同通道模块结构图 97
图 5.14 串行云雾约束模块结构图 98
图 6.1 门控融合 Transformer 网络架构图 100
图 6.2 门控融合 Transformer 块结构及其组件图 101
图 6.3 移位窗口像素自注意力过程图 103
图 6.4 环境适配器结构图 103
图 6.5 深层环境适配器 104
图 6.6 注意力前馈网络结构图 105
图 6.7 门控融合连接器 105
图 6.8 在 Test90 测试集上的定性结果 109
图 6.9 在 Test400 测试集上的定性结果 110
图 6.10 在 U45 数据集上的定性结果 110
图 6.11 在 U60 数据集上的定性结果 111
图 6.12 在 Upoor 数据集上的定性结果 111

中国知网 https://www.cnki.net

附表索引

表 2.1 大气环境的相关属性及其对可见光传输特性的干扰 20
表 2.2 RESIDE 数据集 38
表 3.1 在 SOTS-outdoor 数据集上的定量结果 59
表 3.2 在 NHHAZE 数据集上的定量结果 60
表 3.3 每种网络模型的参数量及计算量 63
表 3.4 在 SOTS-outdoor 数据集的消融研究定量结果 63
表 4.1 在 SateHaze1k 数据集上的定量结果 73
表 4.2 在 HRSD 数据集上的定量结果 74
表 4.3 每种网络模型的参数量及计算量 78
表 4.4 在 DHID 数据集上的消融研究定量结果 78
表 5.1 在 SateHaze1k 数据集上的定量结果 90
表 5.2 在 RICE-I 数据集上的定量结果 91
表 5.3 每种网络模型的参数量及计算量 96
表 5.4 在 RICE-I 数据集上的消融研究定量结果 97
表 6.1 在 Test90 和 Test400 测试集上的定量结果 108
表 6.2 在 U45、U60 和 UPoor 数据集上的定量结果 108
表 6.3 每种网络模型的参数量及计算量 111
表 6.4 在 Test90 数据集上的消融研究结果定量结果 112

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 课题背景及研究意义

视觉、听觉和嗅觉是人类感知和获取外部信息的主要手段，而 80~85%的外部信息是利用视觉方式获取。图像中富含大量的颜色、轮廓和纹理等底层信息以及事物、场景等高层语义信息，展现了图像信息在当今社会的普遍重要性。随着数字电子技术的快速发展，电子监控设备、航天相机、计算机、数码相机、水下相机和手机等光学成像设备已广泛的应用于军事领域和日常生活中，但由于成像设备自身精度不足或受到外部环境等影响，导致图像质量退化，限制了更进一步的图像分割[1,2]、目标定位[3,4]和图像识别[5,6]等任务的发展。

不同散射介质具有不同的光学性质。当光的传输路径中包含密度不均匀或者大量细小颗粒的散射介质时，将会进行散射，进而发生图像退化现象。恶劣环境下拍摄的图像模糊和颜色失真都是由于介质对光的散射作用而造成。云、雾和水体等不均匀的介质均被视为散射介质。诸如这些散射介质具备随机性和无序性，导致光线在它们之中传输时发生了散射。光学成像设备接收的光线在经过散射干扰后，其获取的图像往往呈现为清晰度差、对比度低和颜色失真等情形，退化图像示例如图 1.1 所示。天气阳光明媚时，大气环境中的散射介质对光学成像设备产生的干扰微乎其微。天气恶劣时，大气环境中的散射介质运动剧烈，对光线的传输干扰较大，加大了获取成像目标有用信息的障碍。如何克服恶劣大气环境和水下作业发生的散射现象，拍摄高质量图像，是计算机视觉等实际应用亟需解决的问题[7]。

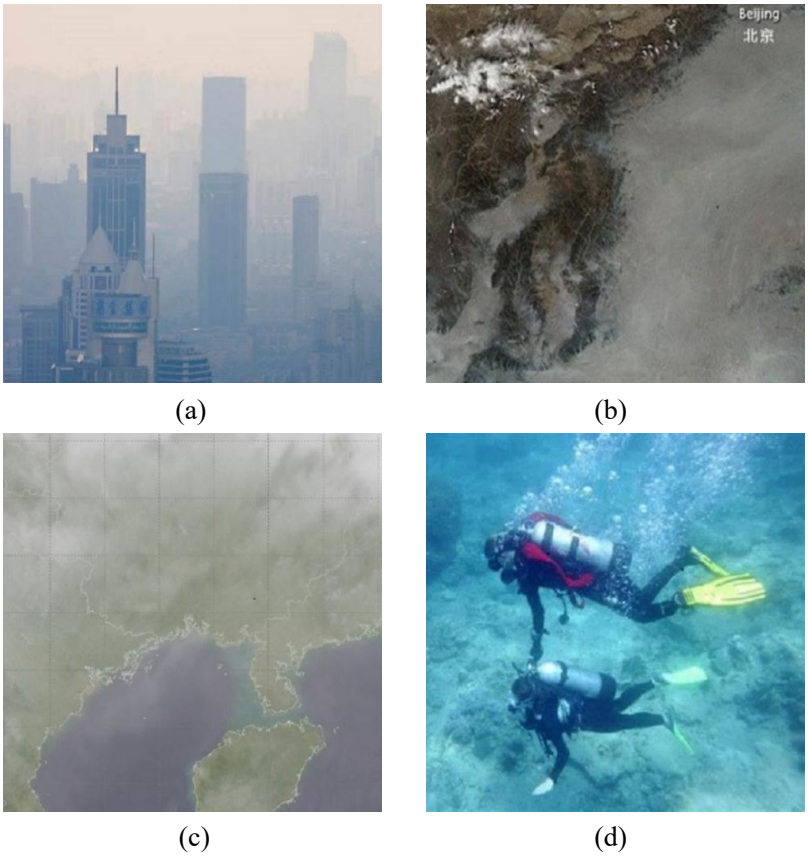
图像去云雾的目的是去除退化图像中散射介质的影响，提升图像的清晰度、颜色饱和度，增强图像的细节信息，获取更多的有用信息，以便于复原图像在小区监控、地质勘探、自动驾驶、城市规划、灾害监测、智能交通等实际应用中发挥最大的作用。如在小区监控时，由于受到雾的遮挡，监控摄像头会获取模糊图像，将难以区分远处的行人，使得监控形如摆设。在交通管理时，由于雾的影响导致分辨车辆和车牌信息存在极大的困难，难以对违规车辆形成有效的监督和处罚。在遥感成像时，由于云雾的散射作用，遥感图像不能及时的、清晰的记录城市发展变化和洪水、火灾等灾害的影响范围和程度，无法为城市规划提供数据支持和辅助灾害管理及救援工作。

水下图像是人类利用计算机视觉来揭秘和研究水下世界的主要技术手段之一。全球 70%以上的面积被海洋占据，针对海洋世界资源的开发、研究和利用现已成为世界各发达和沿海国家的重点攻关项目。大量学者针对海洋高新技术、水下环境探测、水体资源调查等方面开始广泛而深入的研究。海体产业的发展从环境、经济、

中国知网 https://www.cnki.net

考古和人文等不同方面牵动着人类社会，关乎生物生存环境的可持续发展。海洋资源勘测和开发的必要条件是具有充分的、清晰的水下影像。因此，水下图像复原技术在水下勘探、水下机器人等领域中发挥着至关重要的作用。如利用水下图像复原技术，能够有效的、安全的确定诸如石油、天然气等资源的位置和规模，指导资源探测和开发工作。通过水下图像，科学家能够更深入的了解水体环境和丰富的海洋生物，推动海洋科学的进步。然而相比于大气环境，水下环境更为特殊，退化现象更为严重，矫正颜色失真现象更加困难。

综上所述，图像去云、去雾和水下图像复原在日常生活、资源勘探、城市规划和灾后重建等多个方面发挥着重要作用，研究如何从云、雾和水下图像中重建原始清晰图像，具有极其重要的现实意义和应用价值。



(a) (b)

(c) (d)

图 1.1 退化图像示例图

(a) 自然雾天图像 (b) 遥感雾天图像 (c) 遥感薄云图像 (d) 水下图像

1.2 国内外研究现状

1.2.1 图像去云雾研究现状

在日常生活中，成像系统收集的图像往往会受到多种干扰因素的影响，导致图像质量出现不同程度的退化。其中，天气干扰是影响成像系统正常工作的主要因素

中国知网 https://www.cnki.net

之一，其由于存在不均匀介质散射的作用使传播光线的特性发生改变，严重影响了图像的清晰度和可用性。

从物理学角度来说，云雾都属于大气气溶胶范畴，是由悬浮于地球大气中的微小颗粒构成的复杂混合物。这些颗粒具有较高的稳定性，其沉降速率相对较低，能够在空气中长时间保持悬浮状态。其大小范围一般在$10^{-1}\mu m \sim 10^{2}\mu m$之间，既包括液态离子，也包含固态离子。根据云层的形态和厚度差异，遥感影像中的云可分为薄云和厚云两大类。薄云覆盖区域通常具有较大的空间范围，其影像数据一般同时包含云层与地表景物的混合信息。相比之下，厚云及其阴影区域由于云层光学厚度较高，导致影像中地表景物的辐射信息几乎完全被遮蔽。薄云和厚云在影像中往往展现出不同特征，针对它们的处理方法也需相应调整。由于雾和薄云对可见光产生的散射处理几乎一致，一般情况下图像去雾技术在去薄云方面也能取得较好的效果。大量的图像去雾技术也可以被用来去薄云[8,9]。而厚云几乎遮挡了遥感影像中的大部分信息，去除难度更大，需要其他区别于雾和薄云的方法才能有效去除[10]。因此在本文中，将雾和薄云两种散射介质引起的图像退化问题视为同一种退化现象，并将它们看作同一问题进行介绍和研究。

目前，图像去云雾技术主要包含图像增强技术和基于物理模型的图像复原技术[11]。前者通过分析像素点强度，重新排列不同像素点的强度值以提升图像对比度，增强图像[12]。此类技术能够依靠场景需求对一些传统的图像处理技术进行改进，不受场景变化的影响便能实现提升图像质量的需求。目前仍普遍应用于遥感、医疗和监控领域。然而，该类技术尽管能够有效的提升图像对比度，但是增强后的图像往往缺失部分信息，造成图像失真。后者根据对目标成像的退化过程构建大气散射模型，依赖先验信息逆推真实情景图像。此类技术在近些年来受到广泛的关注，大量学者对其进行了研究[13]。其复原的图像视觉效果自然，近似于真实情景，有效的恢复了成像目标的颜色和强度特征。

图像增强早期主要通过改进图像分布以使图像突显出感兴趣的图像信息或者满足人眼的视觉效果。经典的增强算法有直方图均衡化[14]、锐化[15]、小波变换[16]、曲波变换[17]和 Retinex[18]等。这类技术无需基于有雾图像的退化模型，而是通过增强图像的对比度与色彩饱和度来实现去雾。

直方图均衡化是一种基于像素灰度值重新分布的图像增强技术。其核心原理是通过对图像强度值进行非线性映射，使灰度分布趋于均匀化。对于有雾图像而言，由于其固有的低对比度特性，像素强度值往往集中在较窄的范围内，在直方图上表现为单一且狭窄的峰值分布。通过直方图均衡化处理，能够有效扩展灰度值密集区域的分布范围，同时对稀疏区域进行压缩，从而实现直方图的均匀化分布，达到增强图像对比度的目的。然而受场景、天气的干扰，雾气浓度一般难以预知，当图像

中国知网 https://www.cnki.net

中存在局部较浓雾气时，该技术去雾效果难以满足人们的期望。Kim 等人[19]提出了局部直方图均衡化方法，其核心思想是将图像划分为多个子区域，并对每个子区域分别进行直方图均衡化处理，以实现局部细节的增强。然而，这种基于分块的处理方式容易在块与块之间产生明显的边界效应，同时计算效率较低。为解决这一问题，Kim 等人[20] 等人进一步改进算法，提出了子块部分重叠的均衡化方法。该方法有效缓解了边界效应，并且提升了计算效率。

同态滤波理论[21]分别对低频和高频分量进行滤波处理，通过抑制低频信息并增强高频信息来提升图像的整体对比度，从而达到图像增强的目的。然而，由于该方法未充分考虑有雾图像的局部特征信息，其在局部区域增强方面的表现较为有限。小波变换通过多尺度分解将图像按频率特性划分为多个子图像，随后针对这些子图像分别进行去雾处理。曲波变换通过小波系数将能量进一步分解为多维能量分量，能够更好的增强图像的边缘特征。

Retinex 理论具备色彩及亮度恒定、局部对比度提高和动态范围压缩等优势[22]。基于 Retinex 理论进行去雾主要包含三类，分别是单尺度 Retinex（Single Scale Retinex，SSR）算法[23]、多尺度 Retinex（Multi-scale retinex，MSR）算法[24]和伴随颜色恢复的多尺度 Retinex（Multi-Scale Retinex with Color Restoration，MSRCR）算法[25]。SSR 算法利用高斯滤波处理通道信息来获取光照分量，然后收集反射分量，通过限制低频信息，保存高频信息的方法实现图像增强。MSR 利用加权平均对光照分量进行估计，因此相比于 SSR 算法，MSR 在图像保真和细节保留等方面有更好的效果。MSRCR 算法是在 MSR 基础上改进的增强方法。该算法通过融合低尺度 Retinex 的动态范围压缩能力与高尺度 Retinex 的色调恢复特性，提升了低质量图像的视觉效果，但不适用于亮度较低的图像。

基于增强的去雾技术无需对雾天场景的物理参数进行复杂估计，仅通过图像处理技术即可实现去雾效果。然而，由于缺乏对雾天图像退化机理的深入研究和分析，此类方法的去雾性能存在明显局限性。具体表现为复原后的图像容易出现颜色失真、细节丢失等问题，导致视觉效果与真实场景存在较大偏差，难以满足实际应用需求。

基于物理模型去雾技术隶属于图像复原范畴，该类技术大多数依靠 Nayer 和 Narasimhan 提出的大气散射模型[26-28]（Atmospheric scattering model，ASM）实现图像去雾。ASM 包含目标图像、清晰图像、大气光值和透射率等参数，其中仅目标图像是已知参数。因此通过 ASM 进行图像去雾属于一种不适定问题，研究人员通常需要引入先验知识，通过估计大气光值和透射率等参数，实现对有雾图像的复原。

Tan 等人[29]指出清晰图像相较于雾化图像存在更高的对比度，提出通过最大化局部对比度技术实现图像去雾。这一技术被认为是基于先验知识的最早研究工作之

中国知网 https://www.cnki.net

一。Fattal 等人[30]提出了一种基于场景辐射的去雾方法，他们假设目标物体表面阴影与透射率在局部范围内不相关，通过推导场景辐射中平行和垂直大气光的两个分量来估计大气光和透射率，然后将其代入大 ASM 以获取去雾图像。基于物理模型的去雾技术最为众多学者所熟知的是 2009 年 He 等人[31]提出的暗通道先验（Dark Channel Prior，DCP）理论，该理论的出现引发当时在去雾领域中极大的轰动。He 等人通过对大量无雾图像的统计分析，发现了一个重要规律：在排除天空区域的局部区域中，至少有一个颜色通道的像素强度值趋近于零，他们将这一规律称为“暗通道”，并基于此规律较好的估计了大气光和透射率这两个关键参数，从而实现了图像复原。此后，大量学者基于暗通道先验理论进行一系列去雾方法的优化和改进[32]。Jiang 等人[33]以暗通道先验为基础，进一步研究其在亮白区域内去雾性能较差的成因，提出利用容差机制对图像透射率进行修正，该方法实现了对图像中亮白区域有雾情况下的有效去除。Xu 等人[34]提出通过亮通道修正大气光值，并结合暗通道来恢复清晰图像。

大量学者通过统计分析有雾和无雾图像并发现规律和共性，还提出了部分其他先验知识来解决图像中的雾移除问题。Zhu 等人[35]通过观察分析有雾图像，发现图像中的像素亮度和饱和度之间呈现一定的变化规律，提出了颜色衰减先验（Color Attenuation Prior, CAP）技术，该技术利用颜色衰减先验建立线性模型，能够较好的恢复深度信息。Berman 等人[36]通过分析通过同时分析有雾和无雾图像，发现当雾出现时，无雾图像的像素簇会变成雾霾线，从而提出了一种非局部先验来表征干净图像。Bui 等人[37]通过在图像空间中的雾像素簇中融入建立的颜色椭球体，提出了颜色椭球先验（Color Ellipsoid Prior, CEP）技术，该技术能够根据椭球的几何特征对透射率进行估计，有效的避免了像素过饱和现象。Singh 等人[38] 针对复杂场景和浓雾条件下纹理细节易丢失的问题，提出了梯度轮廓先验（Gradient Profile Prior, GPP）技术。利用 GPP 对场景深度图进行估计，并结合各向异性对透射率进行估计，弥补了 DCP 在恢复包含天空场景的有雾图像时出现的失真问题。Xu 等人[39]针对遥感图像提出了一种迭代去雾技术，该技术定义了“虚拟深度”这一概念，它有助于测量物体的表面覆盖范围，可以通过迭代过程估算遥感图像的传输图来实现图像去雾。

基于物理模型的去雾技术大多都是通过观察分析大量有雾或无雾图像，得出一定规律，并将这一规律作为先验信息来对大气光或透射率进行估计，从而根据 ASM 获取无雾图像，该类去雾技术有较强的可解释性。然而，其去雾性能的好坏受到先验信息的限制。若依赖先验信息计算出的大气光或透射率值和真实情况下的大气光或透射率值存在较大的差值，去雾效果将会受到较大的影响，会发生去雾过度、颜色失真和伪影等问题。

现如今，是处于高科技发展的时代，人工智能领域影响着社会生活中的方方面

中国知网 https://www.cnki.net

面，深度学习作为人工智能领域下的关键技术之一，也被学者们大量的应用于图像去雾任务中，并取得了不错的成果。CAI 等人[40]提出了 DehazeNet 单图像去雾网络，首次将卷积神经网络引入到图像去雾任务中。该技术通过多尺度特征图和最大池化等操作估算透光率，然后根据大气散射模型对模糊图像进行清除。与传统的去雾技术相比，这一去雾技术大大提高了移除图像中雾的能力。Ren 等人[41]设计了粗尺度网络和细尺度网络模型，通过提取粗透射图和细透射图并融合实现去雾。Li 等人[42]提出了一体化网络（All-in-One Dehazing Network，AODNet）。他们将大气散射模型中的大气光值和透过率两个参数统一起来，转化为一个新的变量，利用轻量级卷积估计该变量并生成去雾图像。Liao 等人[43]提出了用于夜间去雾的 HDPNet，通过估计雾密度图来恢复无雾图像。Chen 等人[44]提出了一种门控聚合网络，利用空洞卷积增加图像感受野，聚合图像的语义信息，成功解决了网络伪影问题。Mei 等人[45]提出了一种渐进式特征融合网络（Progressive Feature Fusion Network，PFFNet）。该网络通过直接学习从观察到的模糊图像到无模糊图像的高度非线性变换函数来实现去雾。Shao 等人[46]提出了域自适应去雾网络，通过双向变换网络将图像从一个域变换到另一个域，以减少合成域与真实域之间的误差，解决网络伪影问题。Qin 等人[47]提出了一种端到端的特征融合注意网络（Feature Fusion Attention network，FFANet），设计了一种新颖的特征注意模块，可以有效地聚合浓雾和高频区域，在恢复合成雾图像方面取得了优异效果。Liu 等人[48]提出了 GridDehazeNet 去雾网络，该网络可以生成具有更好多样性和更多相关特征的学习输入，通过一种新颖的基于注意力机制的多尺度估计，有效地缓解了传统多尺度方法中经常遇到的瓶颈问题。Wang 等人[49]改进了特征提取和增强特征映射，提出了一种基于两种原理的多尺度视觉引导上下文聚合网络，取得了更好的去雾效果。Sheng 等人[50]基于 CIELAB 颜色空间，提出了一种用于单幅图像去雾的多尺度残差注意网络，提高了去雾方法的颜色恢复能力。Zhou 等人[51]提出了一种基于注意力的特征融合去雾网络，利用基于注意力的残差密集块来增强低光雾图像细节。Chen 等人[52]提出了一种由细节增强卷积和内容引导注意力组成的细节增强注意块来增强特征学习，从而提高去雾性能。Song 等人[53]通过分析 Swin 变压器，改进归一化层、激活函数等方式，提出了 DehazeFormer，取得了较好的去雾效果。Lu 等人[54]使用了多尺度平行的大卷积内核模块，并增强了平行注意模块，以解决不均匀的雾分布问题。Guo 等人[55]提出了一个新的自定进度的半课程注意力网络（Self-Paced Semi-Curricular Attention Network，SCANet）。该网络的重点是通过构建注意力生成器网络来增强雾化区域。Li 等人[56]设计了一个两阶段的先粗后细的去雾网络，以提高光学遥感图像的质量。Zhang 等人[57]提出了一种新的动态协同推理学习框架，可以显著地从密集模糊的遥感图像中恢复真实的地表信息。Sun 等人[58]提出了一种部分暹罗多尺度双编解码器去雾网络，通过部分暹罗框架和多尺度双

中国知网 https://www.cnki.net

编解码器信息融合模块来解决去雾图像的颜色偏差问题。Song 等人[59]提出了一种遥感图像去雾变换器架构。该架构利用细节补偿的转移注意力来捕捉全局和局部区域依赖关系，以优化图像内容的恢复。Lu 等人[54]设计了 MixdehazeNet。该网络采用 U-Net 网络作为骨架，通过并行的卷积核和注意力来提高网络的去雾性能。

基于深度学习的图像去雾技术取得了显著进展，具有广阔的应用前景，能够对自然场景图像中的雾，遥感场景中的云及雾进行有效处理，并取得了不错的视觉效果。然而这类技术在复原云雾分布不规则的场景图像或者浓雾场景图像时仍然具有一定的缺陷，其去雾性能受样本图像或图像本身质量所限制。当与训练样本不同的有雾图像数据集或真实有雾图像比较时，由于图像的透射率或雾分布等产生了变化。这些已训练成功的网络模型的去雾效果会明显下降，一般会发生去雾不明显、颜色失真等情形。

1.2.2 水下图像复原研究现状

水下图像质量显著下降，且颜色衰减现象极为明显，这与在大气中成像存在本质差异。由于水下环境的特殊性，图像在采集和处理过程中呈现出独特的特征，这些特征必须被充分考虑。目前，水下图像复原技术主要分为两类，一种是基于物理模型的复原技术，另一种是基于学习的复原技术。

在基于物理模型的水下图像复原技术研究中，Trucco 等人[60]以 Jaffe-McGlamery 水下成像模型为基础，提出了一种自适应简化滤波技术。该技术通过最大化全局对比度选取滤波器的最佳参数。然而，这一技术的有效性依赖于两个关键假设：一是水下环境的光照分布均匀，二是图像退化仅由前向散射引起。这些假设条件在实际应用中通常难以完全满足，从而制约了该技术的普适性和实用性。张等人[61]提出了一种基于大气湍流模型的水下图像复原技术。该技术利用大气湍流模型模拟水下光传播的退化过程，从而实现对图像的复原。Fattal[62]提出了一种基于颜色线的方法，用于估计水下图像中雾化效应的浊度。该方法通过分析图像中的颜色分布特征，结合马尔可夫随机场模型，实现了对雾化前图像的复原。由于水下图像与雾天图像在成像模型和视觉特征上存在一定相似性，许多学者将基于暗通道先验的去雾技术扩展应用于水下图像复原任务中。He 等人[31]通过暗通道先验对深度图进行估计，随后利用引导滤波优化深度图，从而生成无雾图像。杨等人[63]提出了一种针对水下图像颜色衰减和雾化效应的复原技术。该技术以暗通道先验为理论基础，分别校正 RGB 颜色通道，通过散射效应与光线波长之间的关系估计透射率，解决了水下图像色彩失真问题。Singh 等人[64]基于暗通道先验理论，提出了一种可见性复原模型。该模型通过引入增益干涉滤波器，显著提升了计算效率，同时增强了边缘保持能力。Drews 等人[65]考虑水下图像中红色通道的严重衰减可能导致暗通道先验图计算误差。为了

中国知网 https://www.cnki.net

解决这一问题，他们在计算暗通道先验图时仅利用蓝绿通道信息，并提出了一种新的水下图像去散射技术，称为水下暗通道先验（Underwater Dark Channel Prior，UDCP）技术。UDCP 方法通过排除红色通道的影响，有效减少了红通道过度衰减在图像复原过程中引入的偏差。Galdran 等人[66]提出了一种自动红通道水下图像复原技术。该技术通过对环境光和透射图取逆，并结合蓝绿通道信息，利用成像模型生成去散射图像。Peng 等人[67]提出了一种泛化暗通道先验（Generalization of the Dark Channel Prior，GDCP）技术。该技术通过分析场景环境光差异来估计透射率图，同时结合色彩校正技术改善图像颜色。Ancuti 等人[68]提出增强水下图像和视频的融合技术。该技术根据融合原理从退化图像中获取输入和权重值，改善了水下图像的细节和边缘特征。

基于物理模型的水下图像复原技术主要根据水下光学成像数学模型，通过结合假设条件、先验知识和水下光学属性来估计模型参数，进而实现高质量图像的重建。然而，这类方法主要存在以下两个限制，一是所采用的水下成像模型通常过于理想化，难以准确反映复杂多变的实际水下环境；二是假设条件和先验知识对光照变化的适应性不足，使得模型在动态光照条件下的表现较差。尽管这些方法在一定程度上能够恢复水下图像的真实性，但仍面临准确性低、鲁棒性弱和灵活性有限等问题。这些局限严重制约了基于物理模型的方法在实际生活中的应用。

基于学习的水下图像复原技术近年来取得大量的研究成果，根据网络结构的不同，一般将基于学习的水下图像复原技术分为基于卷积神经网络（Convolutional Neural Network，CNN）的水下图像复原技术、基于生成对抗网络（Generative Adversarial Network，GAN）的水下图像复原技术和基于 Vision Transformer 的水下图像复原技术[69]。

(1) 基于 CNN 的水下图像复原技术

基于 CNN 的水下图像复原技术分为两种类型，一种是先利用 CNN 估计传输图等成像模型，再复原水下图像的非端到端技术。例如 Ding 等人[70]提出了一种结合水下光学成像模型的复原技术。该技术首先利用自适应颜色校正技术消除图像中的色彩失真，以恢复水下场景的自然色彩。然后利用 CNN 估算传输图和背景光，从而生成清晰的水下图像。Hou 等人[71]提出了一种基于残差 CNN 的水下图像复原技术。该技术采用数据驱动的方式学习传输图，有效捕捉了水下图像的退化特征。Lin 等人[72]提出了一种双阶段网络。该网络在第一阶段将水下物理模型嵌入网络，有效处理了水平畸变。在第二阶段，设计了衰减系数优先注意块，解决了水下光吸收和散射问题。Xue 等人[73]提出了一种多分支聚合网络。该网络通过构建物理模型来利用分析出的水下退化因子，从而恢复清晰的图像。

另一种是不依靠人工先验信息，通过 CNN 直接建模退化图像和清晰图像之间的

中国知网 https://www.cnki.net

映射关系的端到端技术。例如 Li 等人[74]根据水下场景先验，提出了一种轻量级的水下图像复原网络，能够实时处理水下图像和视频。Wang 等人[75]提出了一种双色空间的水下图像增强 CNN。该网络通过将 RGB 颜色空间与 HSV 颜色空间整合到一个统一的框架中，实现了对水下图像的有效复原。Li 等人[76]提出了一种基于 CNN 的水下图像基准模型，称为 WaterNet。该网络采用封闭式融合网络体系结构来学习置信图，较好的解决了水下图像色偏问题。Naik 等人[77]提出了一种用于增强水下图像的压缩网络，该网络主要由串联的密集卷积块组成，解决了水下图像技术计算昂贵且内存密集的问题。Li 等人[78]提出了一种通过中等传输引导的多色空间嵌入水下图像增强技术。该技术通过将不同颜色空间的特征纳入统一结构来丰富特征的多样性，同时结合注意力机制和中等变速器来提升对图像质量衰落区域的响应，明显提升了水下图像质量。

基于 CNN 的非端到端技术在一定程度上克服了基于物理模型技术的局限性，尤其是在某些水下场景中，传统方法因先验假设失效而表现不佳。然而，由于当前对水下环境的科学认知尚不完善，物理模型的构建可能存在偏差，导致这些方法在处理不同水域类型的水下图像时泛化能力和普适性不足。因此，部分学者提出了基于 CNN 的端到端技术。这种技术摒弃了对物理模型的依赖，直接学习从水下降质图像到清晰图像的映射关系。尽管基于 CNN 的端到端技术得到了大量采用，但其性能在很大程度上依赖于针对特定环境的网络设计。只有通过针对性的网络结构设计，才能取得较好的复原效果。

(2) 基于 GAN 的水下图像复原技术

GAN 在数据生成方面具有出色的表现，其在水下图像复原任务中取得了大量较好的成果。Li 等人[79]提出一种无监督的水下生成对抗网络。该网络通过空中图和深度图建立合成水下图像，然后将其进行训练，实现了水下图像颜色的校正。Fabbri 等人[80]提出了一种水下生成对抗网络来复原水下图像，以增强水下机器人的视觉感知能力。Guo 等人[81]提出了密集生成对抗网络来提升水下图像质量。该网络通过结合对抗、梯度和 L1 损失，描述了清晰图像的分布特性。Islam 等人[82]提出了一种实时水下图像增强监督技术，该技术通过配对和非配对训练模式，能够快速处理水下图像。Yang 等人[83]提出了一种基于多尺度特征提取器的条件生成对抗网络，该网络通过双重鉴别器来同时捕获局部和全局语义信息，从而生成更加真实可信的重构结果。Liu 等人[84]提出了一种对象引导的双对抗对比学习技术。该技术通过双边约束闭环对抗增强模块来解决对配对数据的依赖问题，以实现视觉友好的水下图像复原。

基于 GAN 的水下图像复原技术一般使用无监督训练方式，通过生成器和判别器的有效结构设计，生成高度逼真视觉效果的水下图像。然而，由于训练数据通常是未配对的，导致模型在学习过程中缺乏稳定性。这种不稳定性会在生成图像中引入

中国知网 https://www.cnki.net

伪影，从而影响复原图像的质量。

(3) 基于 Vision Transformer 的水下图像复原技术

2017 年，Vaswani 等人[85]提出了一种基于自注意力机制的 Transformer 模型，该模型在自然语言处理领域取得了突破性进展。2021 年，Dosovitskiy 等人[86]提出了视觉 Transformer（Vision Transformer, ViT）结构，并将其使用在图像分类任务中，获得了不错的效果。此后，Transformer 得到迅猛发展，学者们开发了大量 Vision Transformer 模型为基础的网络架构以应用于机器视觉领域[87-89]。

大量的以 Vision Transformer 模型为基础的图像复原技术也被用来解决水下图像退化问题。例如 Peng 等人[90]首次将 Transformer 引入到水下图像复原任务中，提出了 U-shape Transformer 水下图像复原技术。该技术将设计的两种不同类型的 Transformer 模块结合使用，增强了网络对颜色通道和空间区域的关注。Ren 等人[91]提出了一种端到端多任务网络，同时解决了水下图像复原和超分辨率任务。该网络将 Swin Transformer 嵌入到 U-Net 架构中，增强了模型对全局特征的捕获能力。Shen 等人[92]提出了双注意力 Transformer 的水下图像复原技术。该技术将通道自注意力 Transforme 与像素自注意力 Transformer 结合使用，从而能够高效编解码水下图像特征，进而恢复清晰的水下图像。Wen 等人[93]提出了全局和局部相结合的 Transformer 结构用来实现水下图像复原。该技术通过全局自注意力和局部自注意力分别对全局和局部信息进行有效关注，利用环境适配器适应复杂的水下环境，取得了较好的水下图像复原效果。

尽管基于 Vision Transformer 的水下图像复原技术，已能够与在机器视觉领域处于霸主地位的 CNN 相比肩，然而该模型目前仍处于初始研究阶段。视觉 Transformer 在水下图像复原领域的应用潜力尚未完全释放，仍存在许多亟待解决的问题和改进空间。

1.3 本文主要研究内容

本文围绕对光学成像设备受散射介质（雾、薄云和水体）干扰而采集到的退化图像复原问题展开研究。国内外研究现状表明，仅基于图像增强技术，不考虑散射介质造成图像退化的深层次原因，清晰化图像能力有限。基于物理模型的复原方法虽能描述介质散射机理，但面临先验知识的依赖性与场景适应性之间的矛盾，实际应用中大气光和透射率估计偏差易导致雾残留及色彩失真等现象。相比之下，基于深度学习的图像复原技术通过端到端的学习退化及清晰图像之间的复杂映射关系，在跨介质复原任务中展现出显著优势。

因此，本文深入分析了雾、薄云和水体三种散射介质对光传播过程中造成的散射和衰减作用，重点研究了现有基于物理模型的散射介质退化图像复原技术和基于

中国知网 https://www.cnki.net

深度学习的散射介质退化图像复原技术。依托深度学习技术在图像复原任务中恢复的图像质量更高、细节信息更完整、视觉效果更类似于真实场景的优势，分别针对自然场景中的雾、遥感场景中的雾和薄云以及水体三类散射介质造成的图像退化问题，提出了相应的基于深度学习的图像复原技术，实现了对海、陆、空三种不同空间维度采集的退化图像的复原，本文的主要研究内容架构如图 1.2 所示。具体研究内容如下：

(1) 图像退化机制及现有图像复原相关理论研究。本文深入分析了散射和散射介质及其对光传播过程造成的散射和衰减而导致的光强度减弱机理。研究了图像复原相关理论及其在含有雾、薄云和水体三类散射介质场景中的图像复原技术，如暗通道和红通道等基于物理模型的去雾和水下图像复原技术以及 DehazeNet、WaterNet 和 U-Shape Transformer 等基于深度学习的技术。介绍了深度学习相关理论，重点研究了 U-Net 网络、Transformer 和 Vision Transformer 两个模型，阐述了薄云、有雾和水下图像数据集的构建方式和数据集图像内容，说明了主观质量评价和客观质量评价两类图像质量评价方式，列举了部分客观质量评价指标。

(2) 基于多尺度注意力特征增强的图像去雾技术研究。针对现有的去雾技术恢复有雾图像存在的色彩失真、去雾不彻底等问题，提出了基于多尺度注意力特征增强的图像去雾技术。首先对通道注意力模块、像素注意力和上下文增强模块进行深入研究，然后将它们进行有效结合构建了注意力特征增强模块。该模块通过分析不同像素和不同通道特征之间的关系，自适应的分配像素和通道特征间的权重，使网络更着重分析和处理有价值的及信息量更大的像素和通道特征。然后以注意力特征增强模块为基础，进一步引入高效金字塔模块，从而构建多尺度注意力增强模块。该模块不但具有注意力特征增强模块能够自适应关注特征的优势，而且增大了感受野，能够有效的避免细节信息的丢失，减少伪影的发生。最后将多尺度注意力增强模块嵌入到去雾融合块中，以增加网络的深度，实现更好的去雾性能。

(3) 基于细节增强的遥感图像去雾技术研究。针对现有的遥感图像去雾技术存在细节信息丢失严重等问题，提出了基于细节增强的遥感图像去雾技术。首先为了能够获取图像的多尺度信息并具备大的感受野，保留图像的细节信息，设计了多尺度细节增强单元。其次为了能够匹配遥感图像不均匀的雾分布的特性，自适应的提取雾信息，防止恢复过程中重要细节信息的损失过大，设计了阶梯式注意力细节增强单元。最后，通过构建细节增强块来融合这两个单元的优势，以确保复原的遥感图像保留更多的细节信息。此外，引入了 SK Fusion 和软重构技术，以进一步提升网络的去雾性能。

(4) 基于逆认知学习的遥感图像去云雾技术研究。针对现有的遥感图像去云雾技术存在云雾去除不彻底、纹理信息缺失严重等问题，依据雾和薄云具有相近的成像

中国知网 https://www.cnki.net

特性，提出了基于逆认知学习的遥感图像去云雾技术。首先根据人脑对图像的认知是一个从整体图像到局部分析和注意的复杂过程，设计了一个简单的从局部学习到整体学习的逆认知学习模块，该模块能够以递进的方式逐步的提取局部特征信息和整体特征信息。然后设计了一个简单的并行的云雾约束模块，以加强在提取特征过程中对雾和薄云特征的约束。最后以这两个模块为基础，为进一步提取图像的多尺度信息，综合考虑局部细节和全局信息，构建了多尺度逆认知学习块。

(5) 基于门控融合 Transformer 的水下图像复原技术研究。针对水下图像存在颜色失真和模糊等问题，提出了基于门控融合 Transformer 的水下图像复原技术。首先对以门控融合 Transformer 块为核心组件的 U-Net 型网络进行研究，通过融合通道自注意力和移位窗口像素自注意力来替换传统的自注意力机制，以获取通道特征和像素特征。其次设计了注意力前馈网络，以对输入特征进行自适应关注和重新整合，增强网络的学习能力。然后为避免 Transformer 模型仅仅过多关注水下图像的全局信息，忽视重要细节信息的问题，提出门控融合连接器来替换传统的跳跃连接方式，以减少关键局部细节信息的丢失。最后为使网络进一步适应复杂的水下场景图像，在门控融合 Transformer 块中嵌入深层环境适配器来进一步增强对重要信息的关注。

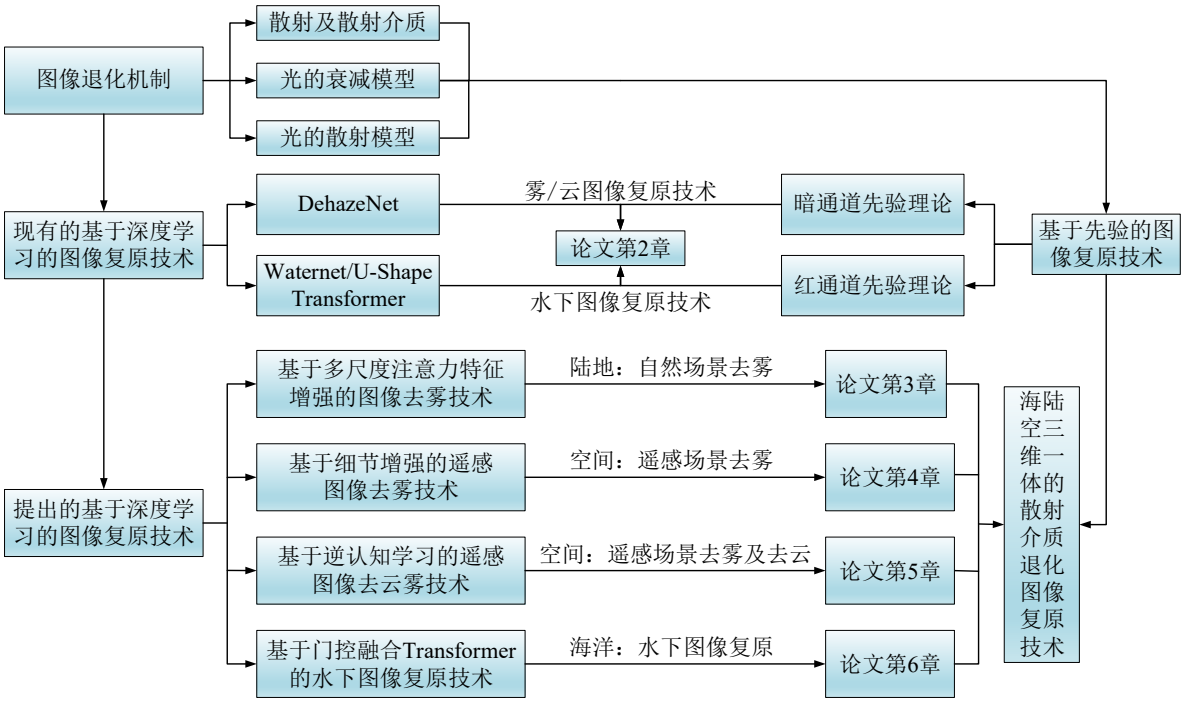


图 1.2 论文主要研究内容架构图

1.4 本文结构安排

本文总计包含七个章节，具体安排如下：

第 1 章：绪论。本章节首先介绍了受雾、云和水体干扰的退化图像复原的实际应用价值和研究意义，然后分别详细梳理了到目前为止的国内外图像去云雾和水下图

中国知网 https://www.cnki.net

像复原技术，回顾了基于图像增强的去云雾技术，基于物理模型的去云雾及水下图像复原技术和基于学习的去云雾及水下图像复原技术，最后概述了本文的主要研究内容，构建了论文主要研究内容架构图。

第 2 章：图像退化及复原相关理论研究。本章节先介绍了光在散射介质中的退化机理，其次阐述了受云、雾及水体三种散射介质的影响而导致的退化图像复原的理论，接着回顾了与本文相关的深度学习技术复原图像的相关理论，然后介绍了图像去云雾和水下图像复原任务中常用的公开数据集以及相关的评价方法和指标，最后对本章内容进行了小结。

第 3 章：基于多尺度注意力特征增强的图像去雾技术研究。首先对本章的研究内容进行了简要的概述。接着分别介绍了通道注意力、像素注意力和上下文增强模块，其次着重介绍了去雾融合块，该模块中包含了设计的多尺度注意力增强模块和注意力特征增强模块。然后介绍了本章去雾技术的实验结果和相应的结果比较和分析。最后对本章内容进行了小结。

第 4 章：基于细节增强的遥感图像去雾技术研究。首先对本章的主要研究内容进行了简要的概述。其次重点介绍了基于细节增强的遥感图像去雾网络，包括 SK Fusion、软重建和细节增强块。其中细节增强块中包括多尺度细节增强单元和阶梯式注意力细节增强单元。然后介绍了本章技术的实验结果和相应的结果比较和分析。最后对本章内容进行了小结。

第 5 章：基于逆认知学习的遥感图像去云雾技术研究。首先对本章的主要内容进行了简要说明。其次系统的介绍了基于逆认知学习的遥感图像去云雾网络，包括编码器、瓶颈层和解码器以及它们的核心组件多尺度逆认知学习块。然后阐述了本章技术的实验结果和相应的结果比较和分析。最后对本章内容进行了小结。

第 6 章：基于门控融合 Transformer 的水下图像复原技术研究。首先对本章的重点研究内容进行了简要概述。其次介绍了基于门控融合 Transformer 的水下图像复原网络，接着重点阐述了门控融合 Transformer 块和门控融合连接器。然后介绍了本章技术的实验结果和相应的结果比较和分析。最后对本章内容进行了小结。

第 7 章：总结与展望。对本文的主要研究工作进行了总结，详细列出并说明了本文的创新点以及未来工作的侧重方向。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 2 章 图像退化及复原相关理论研究

图像退化是指图像在采集、传输或存储过程中因各种因素导致质量下降的现象，通常表现为模糊、噪声和失真等现象。图像复原是指通过技术从退化图像中恢复出高质量清晰图像的过程。图像退化为理解和解决图像质量下降问题提供重要基础，图像复原效果高度依赖于对图像退化过程的理解和建模，二者共同构成了图像质量提升的核心问题。

2.1 光在散射介质中的退化机理

2.1.1 散射及散射介质概述

电磁波谱中的光波在理论上能够在各向同性均匀介质中实现无干扰传播。然而，现实环境中并不具备这种理想化的传播条件。实际上，介质的光学特性在空间维度上必然呈现非均匀性，当光波与这些非均匀介质相互作用时，其传播路径会发生偏转，这一物理过程被定义为光的散射。自然界中普遍存在由于光的散射引发的各类现象。以晴朗夜空中恒星的闪烁为例，这种现象源于恒星发出的光在穿越地球大气层时，受到大气湍流的扰动而发生散射，导致光线传播方向改变，从而产生视觉上的闪烁效果。值得注意的是，在月球表面无法观测到类似的恒星闪烁现象，这是由于月球表面是真空，光在其中传播时不会发生散射。根据光在传播过程中波长是否发生变化，散射现象可分为弹性散射和非弹性散射两类。在弹性散射中，光的波长保持不变，主要包括瑞利散射、米氏散射以及分子散射等。而在非弹性散射中，光的波长会发生改变，典型例子包括康普顿散射、拉曼散射和布里渊散射等。在这些散射现象中，瑞利散射和米氏散射是最为常见的两种类型。当散射粒子的尺寸小于入射光波长的十分之一时，主要发生瑞利散射；而当粒子尺寸与入射光波长相当或更大时，主要发生米氏散射。这一原理可以解释大气中云雾呈现白色的原因：云雾中的水滴尺寸与可见光波长相接近，从而引发了显著的米氏散射。

在光传输过程中，能够使光发生强烈散射作用的介质被称为强散射介质。日常生活中常见的强散射介质包括密集云层、浓雾、大雪以及牛奶等。当光波通过这类介质时，通常都会发生强散射作用。当光穿过具有非均匀特性的散射介质时，其传播路径会发生偏转，同时光的空间分布、相位特征以及偏振状态等物理性质也会发生随机变化。因此，在通过此类介质进行目标观测时，图像的分辨率和质量往往会显著下降。

中国知网 https://www.cnki.net

2.1.2 介质对光学成像的衰减作用

诸如云、薄雾和水体等富有细小颗粒物的散射介质一般能通过建立物理模型进行描述，其中最为广泛使用的物理模型是朗伯比尔定律（Lamhert-Beer law）[94]。朗伯比尔定律指出光传播时的介质对光的吸收和散射导致的光能量损失或光强度衰减受介质厚度的影响，与其成正比。光在散射介质中的退化过程如图 2.1 所示，图中 I_0 表示入射光强，D 表示介质厚度，I 表示出射光强。

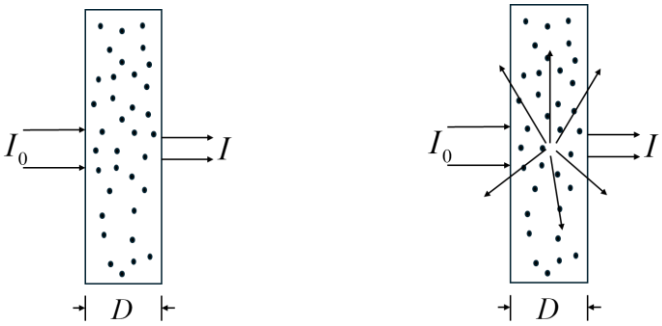


图 2.1 光在散射介质中的退化过程

(a) 介质对光的吸收衰减过程 (b) 介质对光的散射衰减过程

光传播时经过不同散射介质的作用将会发生不同程度的衰减，衰减模型如式(2-1)所示：

$$I = I_0 e^{-\varepsilon D} \tag{2-1}$$

其中，ε 为介质的衰减系数，它为散射系数 s 和吸收系数 a 的总和，表示光每传播单位距离时，受介质吸收和散射作用所丢失的能量总和，单位为 m^{-1}。

散射包含了散射函数 $\beta(\varphi)$ 在不同角度 φ 上全部散射因子的叠加：

$$s = 2\pi \int_0^{\pi} \beta(\varphi) \sin\varphi d\varphi \tag{2-2}$$

可见光中包含各种不同波长的光，不同波长的光在同样的散射介质中传播一般情况下也会产生不同的结果，这表明介质对光的吸收和散射存在选择性。

通常情况下，相同的散射介质对不同波长的光表现出不同的光学特性。这意味着介质在吸收和散射光时具有选择性。尽管大气和水体同属散射介质，但它们在可见光范围内的吸收与散射特性并不完全相同。

在可见光传播过程中，大气对其吸收作用较弱。因此，人们所观察到的天空呈现蓝色，主要是由于大气对不同波长的光存在选择性散射。根据 Ryaelihg 散射定律[95]，波长 λ 和散射系数 s 的关系可表示为：

$$s(\lambda) \propto 1/\lambda^{\kappa} \quad (0 \le \kappa \le 4) \tag{2-3}$$

其中，κ 为一个变量，它被散射介质的颗粒大小和分布情况所影响，颗粒越小，κ 越大。在晴朗天气中，可见光波长要比大气中的颗粒显得较大，此刻 $\kappa \approx 4$。这表明在

中国知网 https://www.cnki.net

晴朗环境下，散射系数主要受光的波长影响。较短波长的光，如青色、蓝色和紫色，更容易被散射，而较长波长的光，如黄色、橙色和红色，则具有更强的透射能力，能够穿透大气分子和微小颗粒，保持传播方向，不易被散射。由于底层大气分子对蓝光的散射较为显著，因此天空呈现蔚蓝色。然而，在雾霾等恶劣天气条件下，大气中含有大量的悬浮微粒，其尺寸远大于可见光的波长，此时 $\kappa \approx 0$。在这种情况下，散射系数几乎不再受波长变化的影响。此时可以认为恶劣天气下的大气对可见光的散射不再具有选择性，从而导致图像整体呈现灰白色。

在水体环境中，可见光的波长远小于海水介质中的微粒。因此，海水对光的散射不具有选择性，即不同波长的光具有相同的散射系数 $s(\lambda)$。然而，海水对光的吸收却是选择性的。蓝光和绿光的衰减较弱，它们的体积衰减系数 c 较小。需要注意的是，水下图像通常呈现蓝绿色，主要原因是蓝光和绿光的波长受到海水的吸收较少（即吸收系数 a 较低）。图 2.2 展示了光波波长 λ 与海水体积衰减系数 c 的关系[95]，从中可以直观地看出不同波长的光在海水中的衰减程度。

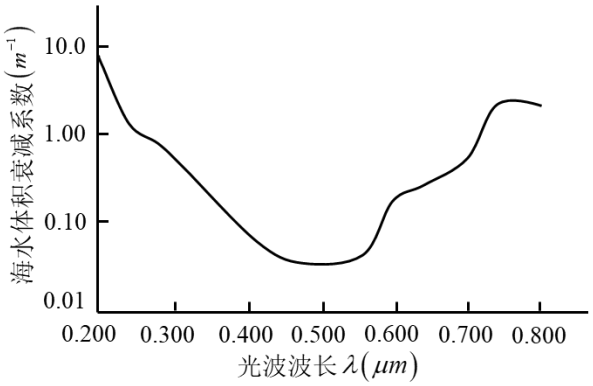


图 2.2 光波波长与海水体积衰减系数关系图

由于水下场景的独特性，水下成像效果通常不如大气成像效果[96]。水体对不同波长的光具有不同的吸收效果，导致水下图像比受到云、雾等散射介质的影响所成的图像复原起来更为困难和复杂，不但需要提升水下图像的对比度，还需要复原颜色信息。

2.1.3 散射介质对光学成像的影响

根据角度的不同一般将散射划分前向散射和后向散射[97]。图 2.3 为水下图像的成像模型。成像传感器分别收集到了直接入射光、前向散射光和后向散射光。前向散射与反射光线的传播方向几乎相同，这会导致图像的模糊。后向散射引入了噪声和雾化，是云雾天气和水下图像质量下降的主要原因。

中国知网 https://www.cnki.net

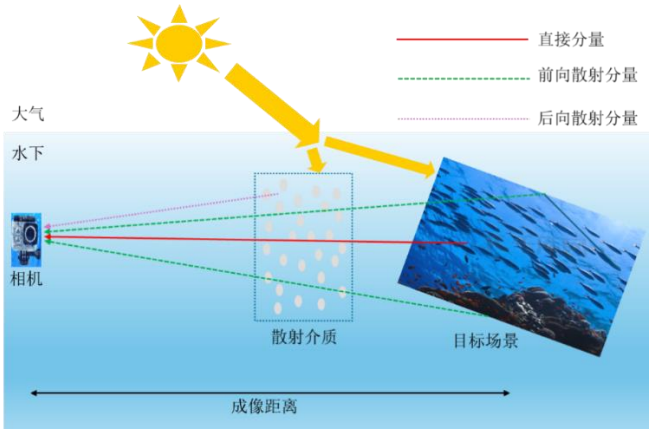


图 2.3 水下图像成像模型

根据 Jaffe-McGlamery[98]提出的成像模型，成像传感器所采集到的经过散射衰减的目标图像可以表示为三个分量的线性叠加，具体形式如式(2-4)所示：

$$E_r = E_d + E_f + E_b \tag{2-4}$$

其中，E_d 为直接分量，指的是未经过散射介质散射，而是由物体直接反射回来的光；E_f 为前向散射分量，指的是物体反射的光在较小角度范围内发生散射衰减后，依然被成像传感器接收到的光。E_b 为后向散射分量，指的是光源发出的光未直接到达目标物体，而是被周围环境中的物质（如水中的悬浮颗粒）散射衰减后，进入成像传感器的光。

(1) 前向散射对光学成像的影响

光在传播过程中会受到大气或水体等不均匀散射介质的影响，使光的传播方向发生改变。当光的传播方向与光学成像传感器采集光的方向几乎相同时，称为前向散射，在图 2.3 中用绿色的虚线表示。前向散射又可划分为两部分，一部分前向散射的光分量叠加到了入射光分量上，增加了目标的辐射量，因此这部分散射传感器采集到更高质量的图像。然而，另一部分前向散射分量在小角度范围内会导致目标物体反射的光发生扩散，从而使得成像传感器捕捉到的图像变得模糊。由于前向散射光与照明光几乎是同步传播的，因此，距离选通技术在抑制前向散射光对成像影响方面的效果有限[99]。

(2) 后向散射对光学成像的影响

图 2.3 中的粉色虚线为后向散射分量，后向散射是指光尚未传播到成像目标便被散射介质以大角度改变传播方向，从而进入成像传感器的光强。当车辆在恶劣雾霾天气中行驶时，驾驶人员一般会打开尾灯并关闭前灯，这样的操作能够使后方车辆驾驶人员对前方有较为清晰的视野。如果打开前灯，恶劣雾霾环境强烈的后向散射光强会使路面能见度变的很低[100]。由于水下环境的复杂性和特殊性，水下的后向散射比雾天更加显著，尤其是在深水区域，需要依赖人工光源。光源功率越大，后向

中国知网 https://www.cnki.net

散射光的强度也越强。因为后向散射光是影响成像距离的主要因素[101]，因此在处理云雾天气和水下图像问题时，主要任务是克服后向散射对图像质量的影响。

2.2 云雾天及水下退化图像复原理论

2.2.1 图像复原理论概述

在数字图像处理领域，图像增强技术因其不依赖于特定的图像退化机制，具有较为广泛的适用性，能够在多种应用场景中有效提高图像的视觉对比度。与此不同，图像复原技术是通过建模光学成像系统的退化过程，利用场景的先验知识推测图像退化的逆过程，从而恢复出高质量的原始图像。这种技术不仅有助于更深入地解析图像中所蕴含的信息，还能为后续算法处理提供较为清晰的输入数据。虽然图像增强与复原在某些方面存在交叉领域，但前者主要侧重于主观视觉效果的改善，而后者更注重客观真实性的恢复。

图像复原技术的起源可追溯至20世纪苏联和美国的空间探索项目。在20世纪50至 60 年代，数字信号处理领域的理论进展为早期图像复原技术奠定了基础。随着技术的发展，诸如状态空间理论、ARMA 模型、非线性参数辨识和自适应控制理论等方法，进一步丰富了图像退化问题的描述，并提供了更多解决方案。要实现高质量的图像复原，准确理解成像过程中的退化机制及其逆过程，并基于此构建合理的退化模型至关重要。复原效果的优劣在很大程度上取决于所建立的物理模型的精确性以及先验信息的准确程度。

近年来，随着 CNN、小波分析等现代方法的出现，图像复原技术得到了显著的发展与拓展。这些新兴技术不仅丰富了该领域的研究内容，还极大地扩展了其应用范围。目前，图像复原技术已在通信、气象观测、天文研究和医疗影像等多个领域被广泛的应用，展现出巨大的实用价值和发展潜力。

2.2.2 云雾天图像复原理论

大气中存在不同颗粒的散射介质是造成不同天气现象的主要原因之一，由于这些颗粒的类型、大小和分布状态的不同，导致产生了不同的大气环境。因此，颗粒的类型、大小和分布与天气情况存在明显的对应关系。在表 2.1 中，列出了本文研究的不同大气环境的相关属性及其对可见光传输特性的干扰。

从气象学上来说，雾、霾和云主要在能见度和含水量等方面有着一定的区分，雾、霾位于低空之中，在本文第三章中主要研究了低空下的自然场景中的去雾技术。而从遥感物理学来说，雾、霾对可见光波段有着相同的散射特性，它们可以被当成低空中的云，均为游离在大气中的小水滴或冰晶构成的水汽凝结物，对遥感图

中国知网 https://www.cnki.net

像的退化程度大致相同，成像特性与薄云几乎一致，因此在本文中，首先在第四章中研究了受雾干扰的遥感图像复原技术，然后在第五章中将雾和薄云看成同一种退化现象，对受到雾和薄云干扰的遥感图像复原技术进行研究。由于雾和薄云存在相同的成像机制，同样在本节中将雾和薄云当成同一种散射介质并对其成像机制以及基于物理模型的去雾技术和基于学习的去雾技术进行研究。

表 2.1 大气环境的相关属性及其对可见光传输特性的干扰

大气环境	颗粒类型	半径（μm）	浓度（cm^3）	对可见光传播的干扰
空气	分子	10^{-4}	10^{-19}	小
霾	粒子	$10^{-2}\sim1$	$10^{-3}\sim10$	较小
雾	小水滴	$1\sim10$	$10\sim100$	中度
云	水滴或冰晶	$10\sim30$	100 以上	较大

在云雾场景下，成像设备所成的图像发生退化的主因原因是光发生了散射和衰减。因此，Narasimhan 等人[102]将大气颗粒对成像目标的干扰划分为两个部分，一部分是目标反射的光在经过大气颗粒散射后仍能传播到成像传感器，这部分光称为入射光直接衰减部分；另一部分是由于周围环境光对目标产生的干扰，称为大气光部分。其模型表达式如式(2-5)所示：

$$E(d,\lambda)=E_0e^{-\beta(\lambda)d}+E_\infty(\lambda)\left(1-e^{-\beta(\lambda)d}\right) \tag{2-5}$$

其中，λ 表示光的波长，d 表示场景深度，$E(d,\lambda)$ 表示成像传感器采集到的能量，$\beta(\lambda)$ 表示波长为 λ 的光线的散射系数，E_0 为成像目标反射的光强度，$E_\infty(\lambda)$ 为无穷远的大气光强。$E_0e^{-\beta(\lambda)d}$ 是代表第一部分的直接衰减项，$E_\infty(\lambda)\left(1-e^{-\beta(\lambda)d}\right)$ 是代表第二部分的大气光模型，它们的光强随场景深度的变化关系如图 2.4 所示。

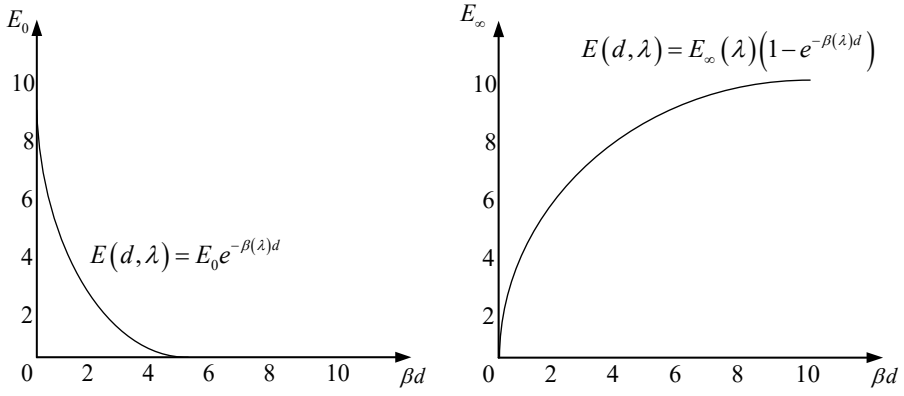


图 2.4 光强随场景深度的变化关系
(a) 直接衰减项 (b) 大气光模型

上述两个部分共同组成的模型称作大气散射模型，一般用来描述薄云和雾天的

中国知网 https://www.cnki.net

成像机制，其模型示意图如图 2.5 所示。为了简单，大量研究人员经常使用另一种简化的方式来表述此模型，如式(2-6)所示：

$$I(x)=J(x)+A(1-t(x)) \tag{2-6}$$

其中，x 表示图像中像素点的坐标，$I(x)$ 表示传感器采集到的受云、雾干扰的退化模糊图像，A 表示大气光强，用来描述来自大气本身的辐射亮度。$t(x)$ 表示透射率，用来描述光穿过大气后的衰减程度，它随着成像目标到传感器距离的增大而减小，$J(x)$ 表示清晰图像。

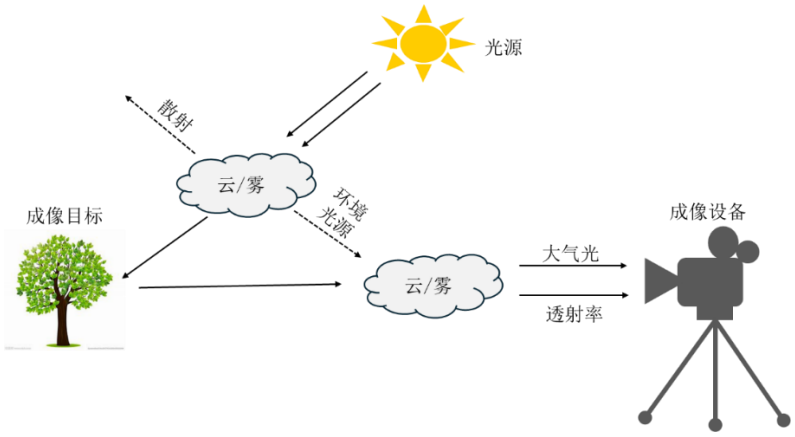


图 2.5 大气散射模型示意图

He 等人[31]通过统计分析 5000 多幅室外无雾的自然图像，提出了暗通道先验理论，该理论认为室外无雾图像中的大多数局部斑块包含一些像素，这些像素在至少一个颜色通道中的强度非常低，并且近似于 0，这些像素点即为图像的暗通道，部分示例图如图 2.6 所示，其表达式如式(2-7)所示：

$$J_{dark}(X)=\min_{y\in\Omega(X)}\left(\min_{C\in\{R,G,B\}}J^{C}(y)\right)\to 0 \tag{2-7}$$

其中，$\Omega(x)$ 表示局部窗口，它以 X 作为中心点，C 表示图像中任意一个色彩通道，$J^{C}(y)$ 表示在 C 通道中的强度，$J_{dark}(X)$ 即为图像中的暗通道。

对大气散射模型式(2-6)左右两端同时取暗通道，得到：

$$\min_{y\in\Omega(X)}\left(\min_{C}\frac{I^{C}(y)}{A^{C}}\right)=\tilde{t}(x)\min_{y\in\Omega(X)}\left(\min_{C}\frac{J^{C}(y)}{A^{C}}\right)+1-\tilde{t}(x) \tag{2-8}$$

因此根据暗通道先验理论得到估计透射率 $\tilde{t}(x)$ 为：

$$\tilde{t}(x)=1-\min_{y\in\Omega(X)}\left(\min_{C}\frac{I^{C}(y)}{A^{C}}\right) \tag{2-9}$$

然而，最小值滤波会引发块状效应，此处得到的透射率仅为粗略估计。为了解决这一问题，He 等人采取了软抠图[103]的方法对透射率进行进一步细化。但是这种方

中国知网 https://www.cnki.net

法需要较大的内存并且消耗较多时间。为避免这一问题，他们随后提出使用引导滤波[104]来细化透射率，这有效减少了时间消耗。

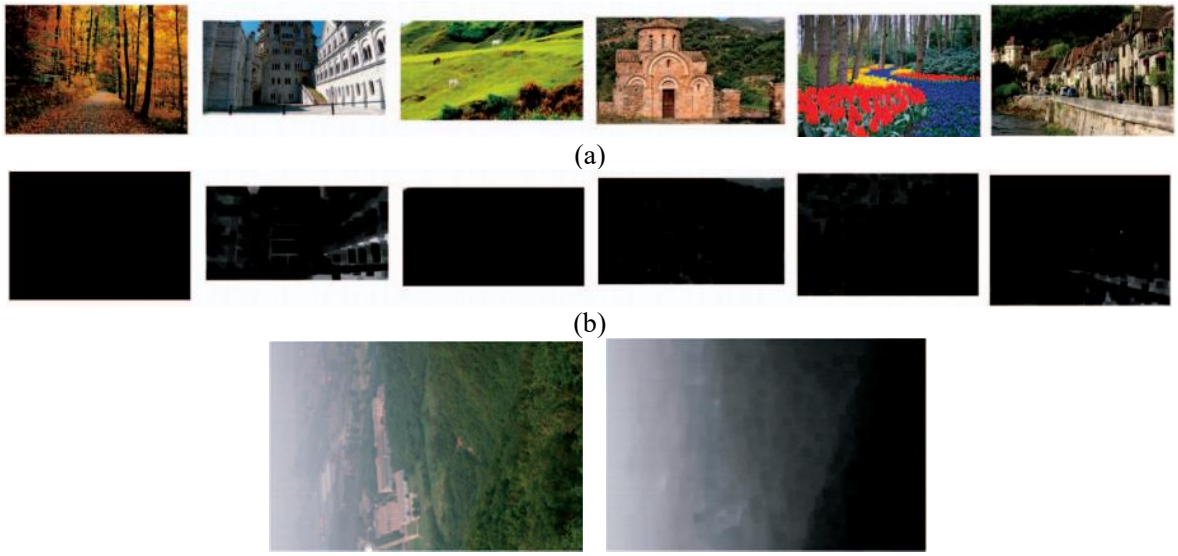


图 2.6 部分暗通道示例图
(a) 原图 (b) 图像暗通道图 (c) 不符合暗通道理论的图

透射率被估计出来后，He 等人将原图中对应暗通道里最强 0.1%像素点坐标的值设置为大气光值，进而根据式(2-10)复原清晰的无雾图像，复原的数学模型如式(2-10)所示：

$$J(x)=\frac{I(x)-A}{\max\left(t(x),t_0\right)}+A \tag{2-10}$$

其中，t_0 为保护因子，用来避免因透射率 $t(x)$ 过小以致复原的图像发生失真现象，一般令 $t_0=0.1$。经过暗通道技术去除自然场景中的雾、遥感场景中的雾和去薄云结果分别如图 2.7、2.8 和 2.9 所示。



图 2.7 暗通道技术去除自然场景中的雾
(a) 原图 (b) 暗通道技术复原图

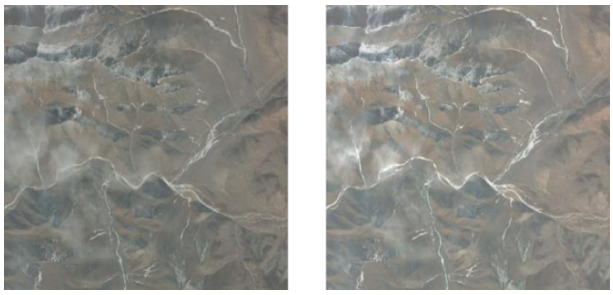
中国知网 https://www.cnki.net



(a) (b)

图 2.8 暗通道技术去除遥感场景中的雾

(a) 原图 (b) 暗通道技术复原图



(a) (b)

图 2.9 暗通道技术去除薄云

(a) 原图 (b) 暗通道技术复原图

在暗通道技术提出后，大量相关领域的研究人员对该技术进行了一系列的改进，然而去雾的理论基础依旧是暗通道先验，这些方法仍然受到先验条件的限制。后来神经网络得以兴起，大量学者开始尝试利用深度学习技术进行去雾，以复原清晰的图像。Cai 等人[40]提出的 DehazeNet 是使用深度学习技术进行图像去雾的首次尝试。他们提出了一个能够进行训练的端到端的系统，来估计受散射介质干扰后的透射率，并生成中间透射率图，最后通过大气散射模型复原清晰的无雾图像。该网络的总体架构如图 2.10 所示，它由特征提取（Feature Extraction）、多尺度映射（Multi-scale Mapping）、局部极值（Local extremum）和非线性回归（Non-linear Regression）四个部分构成，包含了 3 个卷积层、一个最大池化、一个 Maxout 单元和一个 BReLU 激活函数。Maxout 单元层用于特征提取，生成与雾相关的特征，BRelu 激活函数用来提高复原无雾图像的质量。

DehazeNet 的去雾结果如图 2.11 所示。此外，其他等诸如 AODNet[42]、FFANet[47]和 GridDehazeNe[48]等一系的基于深度学习的去雾技术也取得了较好的去雾效果。

中国知网 https://www.cnki.net

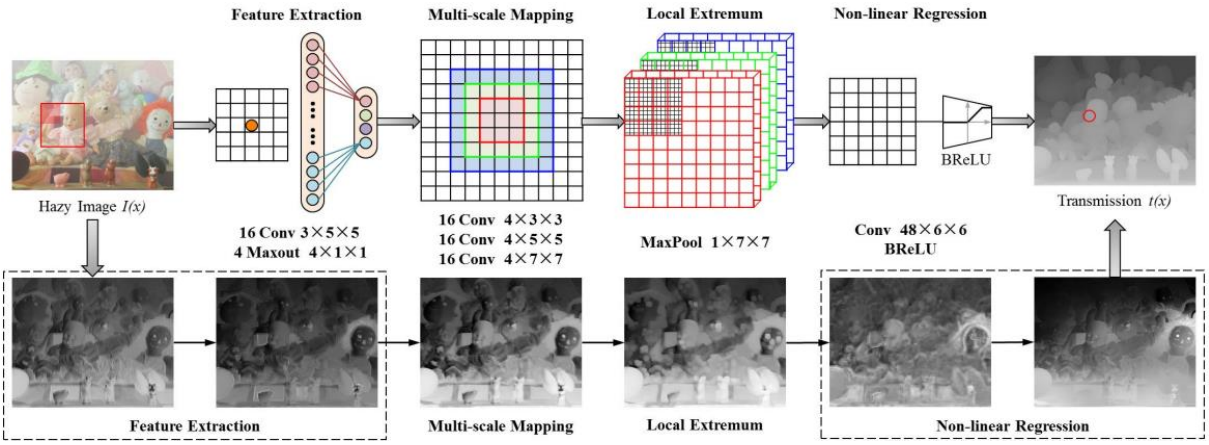


图 2.10 DehazeNet 网络架构图



(a) (b)

图 2.11 DehazeNet 去雾结果

(a) 原图 (b) DehazeNet 复原图

2.2.3 水下图像复原理论

在 2.2.1 中所述，后向散射是造成水下图像模糊、清晰度下降的主要因素。此外，在水下成像中，成像目标和成像传感器的距离通常很近，这导致前向散射分量对水下成像几乎没有影响，因此为更简便的分析模型，大多数的研究人员都会将 Jaffe-McGlamery 模型的前向散射分量移除[60,105]。于是，式(2-4)简化为：

$$E_r = E_d + E_b \tag{2-11}$$

该模型通过与大气散射模型式(2-6)进行同样的推导后，可表示为：

$$I_c(x) = J_c(x)t(x) + B_c\left(1 - t(x)\right) \tag{2-12}$$

其中，x 为像素点的坐标，$c \in (R,G,B)$，它为 RGB 图像通道中的其中之一，$I_c(x)$ 为成像传感器在水下采集的图像，$J_c(x)$ 为清晰的水下图像，B_c 表示背景光，$t(x)$ 为成像目标在水下的透射率。

式(2-12)这一水下成像模型与薄云、雾天气下的大气散射模型几乎相同，不同之处是由于水体这一散射介质对不同波段的光的吸收程度不同，因此需要分别考虑不同波段下光的衰减情况，以计算成像目标反射光的不同辐照度。根据图 2.2 光波波长与海水体积衰减系数的关系，可以发现在光的波长大约为 500nm 时，这一波段的光

中国知网 https://www.cnki.net

波为蓝绿光，此时的衰减系数最小，水体对光的吸收使得光强每秒衰减约 4%，其他波段的光则表现出更加剧烈的衰减。

由于不同波段的光在水下的衰减系数不同，许多学者开发了针对水下图像的复原技术。Galdran 等人[66]基于式(2-12)水下成像模型，提出了自动红通道水下图像复原技术。该技术通过结合不同波长的衰减特性和散射模型，从而构建了以下水下成像物理模型：

$$\begin{cases} 1-I_R = t\left(1-J_R\right)+\left(1-t\right)\left(1-B_R\right) \\ I_G = tJ_G+\left(1-t\right)B_G \\ I_B = tJ_B+\left(1-t\right)B_B \end{cases} \tag{2-13}$$

依据暗通道先验理论，提出“红色暗通道先验条件”，物理模型如式(2-14)所示：

$$J_{\mathrm{Red}} = \min\left(\min_{y\in\Omega(x)}\left(1-J_R\left(y\right)\right), \min_{y\in\Omega(x)}\left(J_G\left(y\right)\right), \min_{y\in\Omega(x)}\left(J_B\left(y\right)\right)\right) \approx 0 \tag{2-14}$$

联立水下成像模型和红通道先验以实现水下图像复原，复原过程如下，首先对水下环境的背景光进行估计。计算 RGB 图像的红通道同时寻找红通道最大像素点的坐标 x_r，将该坐标位置的光强值设置为背景光的取值，因此背景光表示为：

$$\begin{aligned} B &= \left(I_R\left(x_r\right), I_G\left(x_r\right), I_B\left(x_r\right)\right) \\ I_{\mathrm{Red}}\left(x_r\right) &\geq I\left(x_r\right), \forall x \end{aligned} \tag{2-15}$$

对水体下的透射率进行估计，依据“红色暗通道先验条件”，这一背景光对应环境下的透射率为：

$$\begin{cases} t_R\left(x\right) = 1-\min\left(\dfrac{\min\limits_{y\in\Omega(x)}\left(1-I_R\left(x\right)\right)}{1-B_R}, \dfrac{\min\limits_{y\in\Omega(x)} I_G\left(x\right)}{B_G}, \dfrac{\min\limits_{y\in\Omega(x)} I_B\left(x\right)}{B_B}\right) \\ t_G\left(x\right) = \left(t_R\left(x\right)\right)^{\lambda_G} \\ t_B\left(x\right) = \left(t_R\left(x\right)\right)^{\lambda_B} \end{cases} \tag{2-16}$$

其中，λ_G 和 λ_B 为两个常量，它们与在水中不同波段的光的传播能力相关。

透射率和背景光全部估计出来后，最后根据建立的式(2-13)水下成像模型，求解复原图像，其表达式为：

中国知网 https://www.cnki.net

$$\begin{cases} J_R(x)=\dfrac{I_R(x)-B_R}{\max\left(t_R(x),t_0\right)}+B_R \\ J_G(x)=\dfrac{I_G(x)-B_G}{\max\left(t_G(x),t_0\right)}+B_G \\ J_B(x)=\dfrac{I_B(x)-B_B}{\max\left(t_B(x),t_0\right)}+B_{\mathrm{B}} \end{cases} \tag{2-17}$$

其中，t_0 为保护因子，用来避免透射率发生过饱和现象。经过红通道先验复原方法恢复的水下图像结果示例如图 2.12 所示，该方法通过对暗通道先验算法的改进，有效解决了水下图像的偏色问题。



(a) (b)

图 2.12 红通道先验技术复原结果
(a) 原图 (b) 水下图像复原结果

基于先验的水下图像复原技术多数都是依据波长的衰减特性、背景光和成像模型来恢复水下图像。尽管这些技术取得了一定的效果，但它们通常需要大量的假设和先验条件，限制较多，因此在实际水下系统中的应用面临较大挑战。深度学习技术具有广泛的适用性，它不但被用于解决去雾和去云问题，在水下图像复原任务中也被大量的学者所研究和使用。比较经典的基于深度学习水下图像复原技术是 Li 等人提出的 WaterNet[76]网络，其网络架构如图 2.13 所示。该网络对水下图像使用白平衡（White Balance，WB）、直方图均衡化（Histogram Equalization，HE）和伽马校正（Gamma Correction，GC）三个算法来生成 WaterNet 网络的三个输入。将这三个算法生成的输入图像和原始水下图像共同输入到 WaterNet 中来预测置信度图。

中国知网 https://www.cnki.net

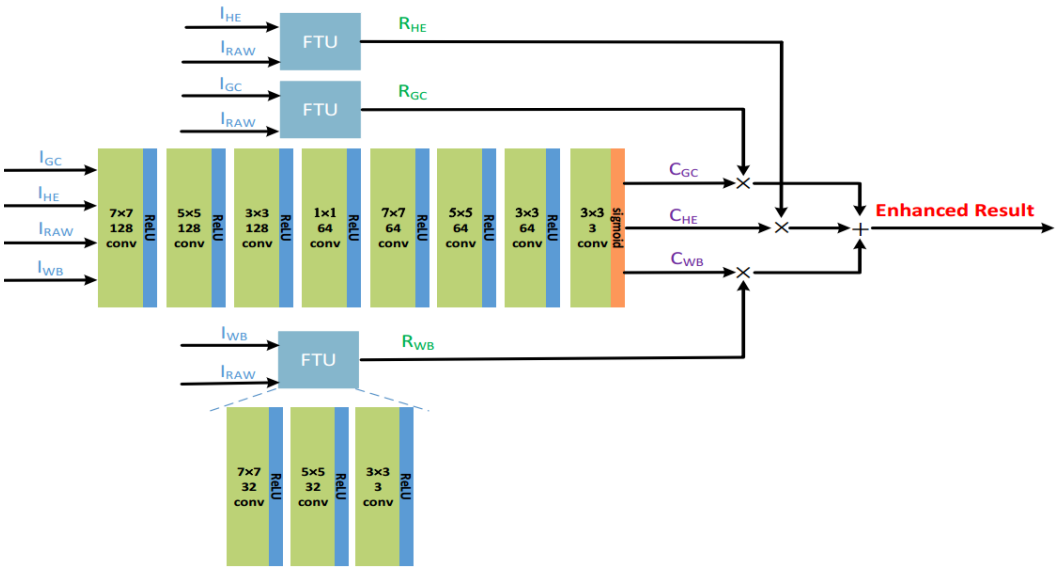


图 2.13 WaterNet 网络架构图

Li 等人利用他们设计的特征转换单元（Feature Transformation Units，FTU）细化这三个输入，以减少 WB、HE 和 GC 算法带来的偏色和伪影。最后，将细化的三个输入乘以三个学习到的置信度图，得到最终的水下图像复原结果，复原结果示例图如图 2.14，其数学模型如式(2-18)所示：

$$J_w = I_{WB} \otimes C_{WB} + I_{HE} \otimes C_{HE} + I_{GC} \otimes C_{GC} \tag{2-18}$$

其中，J_w表示经 WaterNet 复原的清晰水下图像，I_{WB}、I_{HE}和I_{GC}为原始水下图像经过 WB、HE 和 GC 算法处理后的结果，$\otimes$表示矩阵的逐元素相乘，C_{WB}、C_{HE}和C_{GC}表示学习到的置信度图。



(a) (b) (c) (d) (e)

图 2.14 WaterNet 复原水下图像结果

(a) 原始图像 (b) WB 算法结果 (c) HE 算法结果 (d) GC 算法结果

(e) WaterNet 复原水下结果

近两年，Transformer 模型受到广泛的关注，有学者着手将 Transformer 模型应用于图像复原领域中。Peng 等人[90]针对水下光的吸收和散射导致成像质量不佳的问题，首次将 Transformer 模型引入到水下图像复原任务中，提出了 U-shape Transformer，其网络架构如图 2.15 所示。

中国知网 https://www.cnki.net

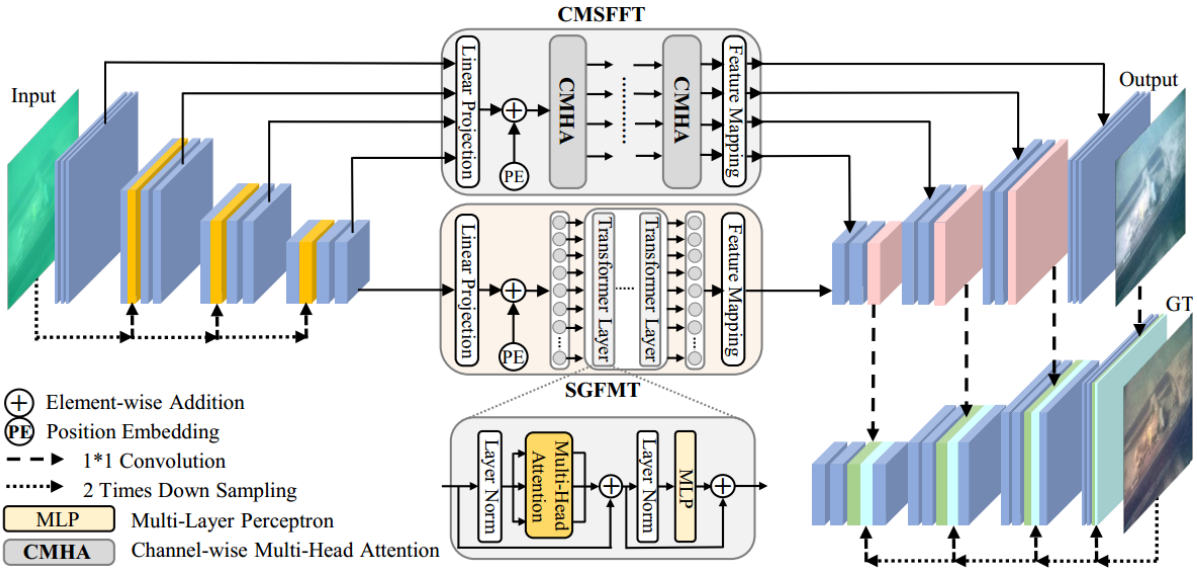
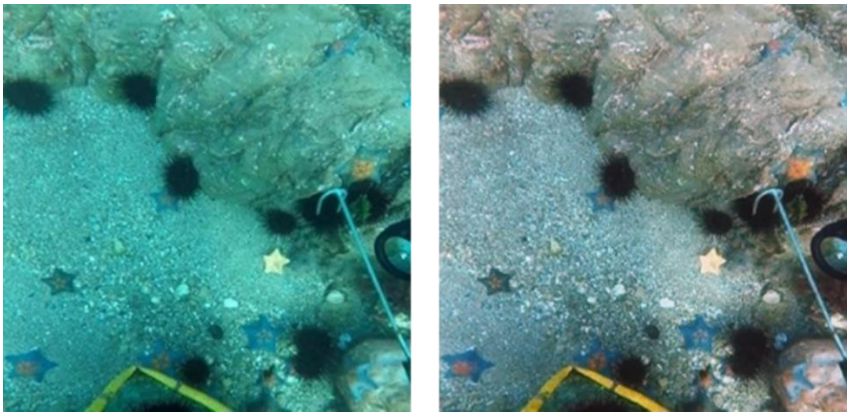


图 2.15 UShape Transformer 的网络架构

该网络旨在通过适当考虑水下图像在不同颜色通道和空间区域的不一致衰减特性来生成高视觉效果的水下图像。它集成了通道级多尺度特征融合变换器（Channel-wise Multi-Scale Feature Fusion Transformer，CMSFFT）模块和空间级全局特征建模变换器（Spatial-wise Global Feature Modeling Transformer，SGFMT）模块，提升了网络对衰减剧烈的颜色通道和空间区域的注意力，从而提升水下图像的质量，复原的水下图像如图 2.16 所示。此外，一些其它基于学习的水下图像复原技术也取得了不错的效果，如 UColor[78]、UGAN[80]、和 WaterFormer[93]等。相比于基于物理模型的水下图像复原技术，基于学习的复原技术取得了更好的复原效果，恢复的图像更符合真实场景。然而基于学习的技术获取清晰的水下参考图像较为困难，难以建立大规模的水下图像数据集，限制了该技术的发展。



(a) (b)

图 2.16 UShape Transformer 复原水下图像结果
(a)原始图像 (b)UShape Transformer 复原结果

中国知网 https://www.cnki.net

2.3 基于深度学习的图像复原机理

2.3.1 神经网络基础理论

(1) 卷积神经网络

深度学习是人工智能发展的核心技术之一，它的成功归功于神经网络能够进行学习和训练。在本论文的后续去云雾及水下图像复原技术中，主要按照图 2.17 一样的流程对由于云、薄雾和水体导致的退化图像进行端到端的学习和训练，从而得到复原的高质量图像。

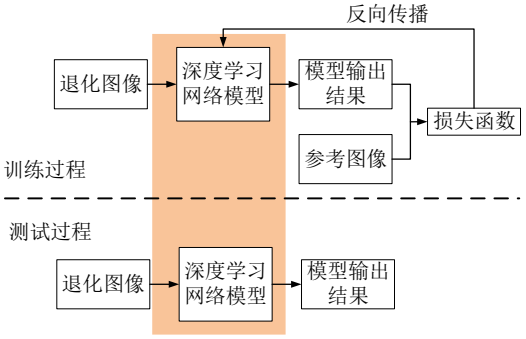


图 2.17 端到端的退化图像复原技术流程图

在本文中，端到端的退化图像复原技术的流程包含两个过程，分别为训练过程和测试过程。训练过程依次按照以下五个步骤执行：（1）为网络模型中能够进行学习的参数赋予初始值；（2）将受到由于薄云、雾和水体等散射介质造成的退化图像输入搭建完成的网络模型中进行计算并输出结果；（3）通过损失函数计算输出结果和相应的参考图像之间的差值；（4）进行反向传播并更新网络参数；（5）重复步骤 2~4，直到网络完全收敛，停止训练。

网络训练过程结束后，通过已训练完成的网络模型对退化图像进行复原，获取高质量图像，即测试过程。在测试过程中，只需将退化图像输入深度学习网络模型中，经过其计算后即可直接得到复原图像。

CNN 主要由输入层、卷积层、激活函数、池化层和输出层等组成。CNN 通过卷积核对输入图像进行卷积操作，利用步长定义窗口的移动，从而提取图像不同位置的特征。随着网络层数的增加，图像特征的提取呈现出由浅入深的层级过程。此外，卷积核参数的共享特性使得卷积层在学习过程中能够显著减少参数数量，从而提高网络的训练效率。

与其它神经网络不同的是，CNN 能够通过卷积和池化自动化的提取特征，无需人工干预，提取的特征是经过网络选择的结果，更适用于处理图像数据，其权重通过特征映射生成。其它神经网络的特征多数需经过人工选择后再映射至相应的权重值，自动化程度较低，适用于处理多种数据类型类型。近十年来，CNN 技术蓬勃发

中国知网 https://www.cnki.net

展，各种 CNN 网络架构层出不穷，本章简单列举了 CNN 在不同领域及一些经典 CNN 架构，如图 2.18 所示。

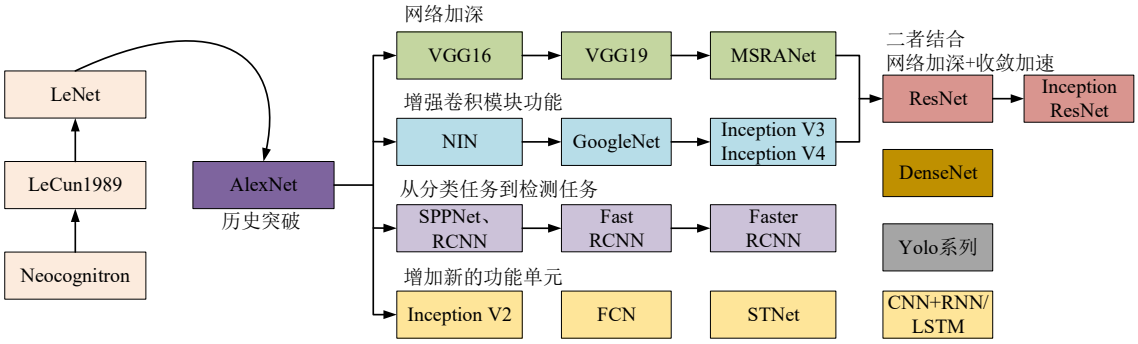


图 2.18 CNN 发展脉络图

(2) 注意力机制

当人们观察感兴趣目标时，人眼经常被注意力所影响，一般会优先对具有高度区分性场景区域进行关注，并在大脑中进行分析及处理。这类关注无需附加更多的认知努力，是一种自然进行的过程。上述找到引起人类视觉注意力的显著区域过程可以表述为：

$$Attention = G\left(H\left(x\right),x\right) \tag{2-19}$$

其中，$H\left(x\right)$ 表示注意力的形成过程，对应于对区分度高的区域进行关注。$G\left(H\left(x\right),x\right)$ 表示基于注意力 $H\left(x\right)$ 对输入 x 进行处理，可以描述为对感兴趣区域进行处理并获取有价值信息的过程。

上述忽略无关区域的干扰，主要对关键区域进行重点关注的方法称为注意力机制。因此，大量学者致力于将注意力机制引入到神经网络中，以使网络对图像中关键区域进行重点关注。根据注意力机制作用的侧重点，通常将其分为四种类型：通道注意力、空间注意力、时间注意力和分支注意力。有时根据网络的需求，学们还会将不同类型的注意力进行组合，如通道—空间注意力等，以提升网络的性能。通过使用不同类型的注意力，便能够对数字图像中不同区域或不同通道获取不同的权重值，以对重点感兴趣区域进行处理。下面以卷积块注意力模块[106]为例（Convolutional Block Attention Module，CBAM）进行介绍，其是最为经典的注意力模块之一，广泛的被应用于图像分割和图像识别等多种图像处理任务中。图 2.19 为 CBAM 的结构图。

中国知网 https://www.cnki.net

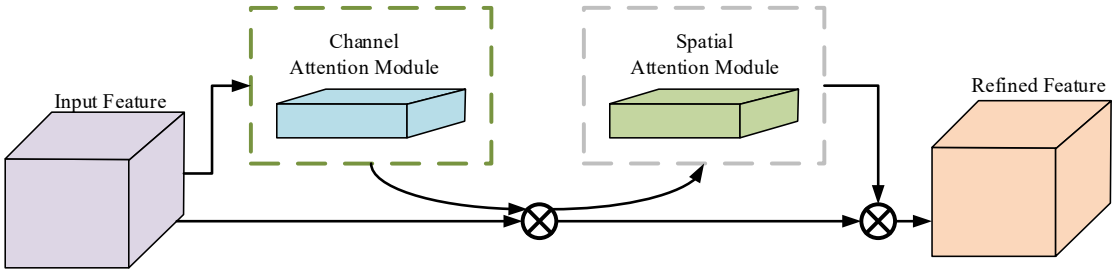


图 2.19 CBAM 结构图

如图 2.19 所示，CBAM（Convolutional Block Attention Module）主要包含两个子模块：通道注意力模块（Channel Attention Module，CAM）和空间注意力模块（Spatial Attention Module，SAM）。CAM 用于计算不同通道特征的重要性，从而区分各通道之间的特征；而 SAM 则用于计算不同像素在空间上的重要性，以捕捉图像的空间结构特征。在 CBAM 中，其输入是网络中传递的一个中间特征图。首先，输入特征（Input Features）通过 CAM 计算得到通道注意力权重，并将该权重应用于输入特征图。然后，经过 CAM 加权后的特征图被传递至 SAM，进一步计算空间注意力权重，并将其作用于特征图上。最终，经过 CAM 和 SAM 的串行处理，特征图实现了自适应的细化，从而得到精细特征（Refined Feature）。通过大量消融实验，作者发现这种串行注意力机制的方式其效果优于并行效果，并且 SAM 置于 CAM 之后更佳。

在深度学习中，注意力机制已被广泛的应用于不同网络结构中。在本文所提出的去雾及水下图像复原技术中，同样通过提出或引入注意力机制挖掘有价值的特征信息，提升网络的整体性能。

(3) 多尺度特征

多尺度特征是指通过在不同尺度上分析数据，提取出图像或数据在不同层次上的信息。一般大尺度特征捕捉整体结构，而小尺度特征更加关注细节。例如在一幅图像中包含人、树木和房屋。如果不进行任何额外操作，直接处理整幅图像，此时图像中包含其含有的全部特征信息，因此提取到的特征是全局特征。如果截取图像中的不同部分，比如图像中包含人的区域，此时仅为图像一部分，将其倍增至与原图像相同尺寸，再进行处理，此时获取的特征仅为关于人的局部特征。全局特征更加关注图像的整体属性，而局部特征更加关注细节部分，如边缘、纹理等。获取多尺度特征方式多数通过上采样或者下采样对输入图像放大或缩小，或者利用不同大小的卷积核获取不同大小分辨率的特征。例如在 ILSVRC2014 比赛分类项目获得第一名的 GoogLeNet[107]，其提出的 Inception 模块是早期多尺度特征应用的成功案例，其结构如图 2.20 所示。该结构分别应用 1×1 卷积、3×3 卷积、5×5 卷积和最大池化来获取不同尺度的特征，从而实现对全局特征和细节特征的有效提取。

中国知网 https://www.cnki.net

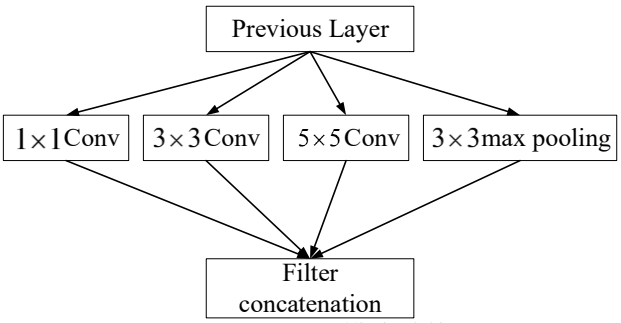


图 2.20 Inception 模块结构图

此后，Liu 等人受到 Inception 模块的启发，结合扩张卷积进一步提出了接受场块[108]，其结构如图 2.21 所示。与 Inception 模块相比，其首先利用1×1 卷积改变通道数，然后信息流向多分支卷积和扩张卷积的组合结构。在每个分支上，特定大小的卷积核之后连接相对应的扩张卷积。最后将所有分支的特征图进行融合。实验证明，该模块能够有效的提取特征，增强网络的性能。

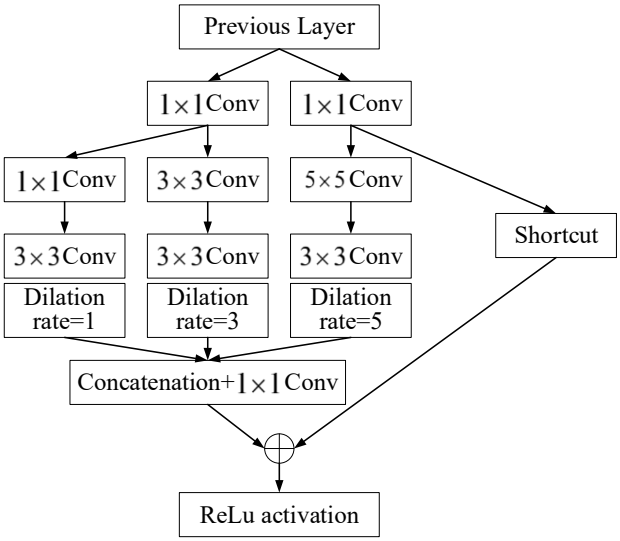


图 2.21 接受场块结构图

在本文第三章和第四章去雾技术研究中，同样通过应用不同大小的卷积核或结合扩张卷积的方式获取多尺度特征，从而能够开发和挖掘不同分辨率下的特征细节和上下文信息，针对全局信息和局部信息进行学习，以增强网络的整体性能，提升模型的鲁棒性。

2.3.2 U-Net 型网络

2015 年，Ronneberger 等人[109]开发了一种应用于医学影像分割的卷积神经网络，即 U-Net 网络。自从该网络提出后，以其优良的表现性能，被应用于多种图像处理任务中[109-112]。图 2.22 展示了 U-Net 网络结构。

中国知网 https://www.cnki.net

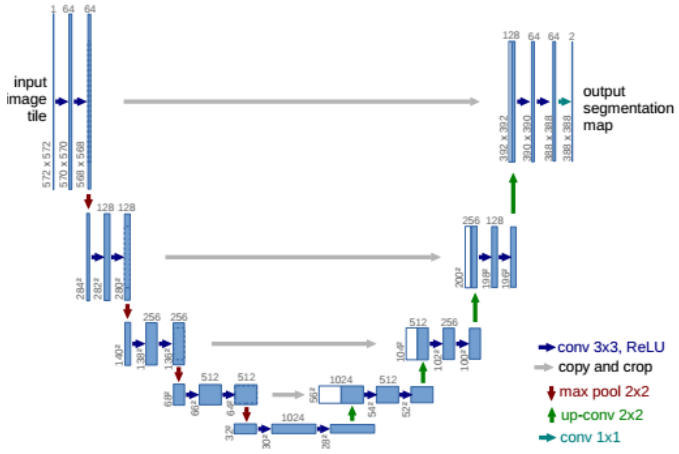
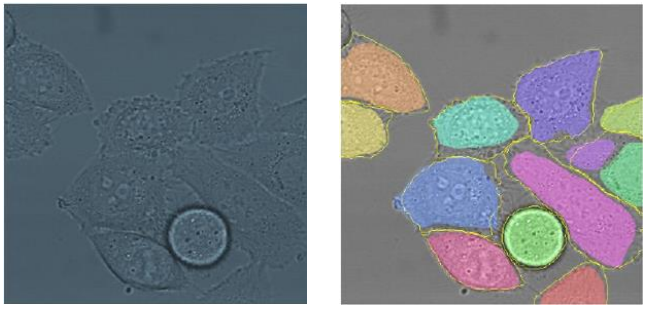


图 2.22 U-Net 网络架构图

根据图 2.22 可以看出，U-Net 采用的是编码—解码结构。在编码器（Encoder）中，主要包括卷积和最大池化（max pool）操作，前者用于提取图像特征，后者则用于降低分辨率和增加通道数。每个卷积操作后连接一个 ReLU 激活函数，该方式有助于提升神经网络的拟合能力。解码器（Decoder）则由卷积和上采样操作组成，前者同样用来提取特征，后者则用来提升分辨率和减少通道数。此外，为能够将网络中的特征信息进行高效共享，编码器和解码器在每一级相对应的卷积层都利用跳跃连接进行融合，以便将浅层网络中的边缘、纹理等细节信息传递至深层网络，从而实现在解码过程中减少细节信息的损失。最后，通过1×1 卷积降低维度并输出分割结果。通过 U-Net 分割图像的示例如图 2.23 所示，图中真实分割线通过黄色实线表示。可以发现，U-Net 网络的分割效果明显，边缘、纹理清晰，结果较为准确。



(a) (b)

图 2.23 U-Net 在 ISBI 挑战赛的分割结果
(a) 输入图像 (b) 分割结果

在本论文第 4、5 和第 6 章遥感图像去云雾技术和水下图像复原技术中，同样使用了 U-Net 型网络架构。这些网络是以 U-Net 网络为骨架，通过设计的特征提取模块替换 U 型网络中的卷积核构建而成。

2.3.3 Transformer

近年来，Transformer 模型因其并行计算、能够有效建立长距离依赖关系的优

中国知网 https://www.cnki.net

势，得到大量学者的关注。目前广泛的应用于自然语言处理和机器视觉等多项任务中，并取得了良好的性能和优异的处理结果。

Transformer 采取的同样是编码—解码架构，其结构如图 2.24 所示。Encoder 通过 N 个模块堆积而成，每个模块主要由多头注意力（Multi-head attention）、前馈（Feedforward）网络和层归一化（Layer Normalization）组成。多头注意力和前馈网络都通过残差连接来融合它们的输入和输出，再利用层归一化进行规范化操作。Decoder 与 Encoder 相同，同样叠加了 N 个模块。除了多头注意力和前馈网络外，在 Decoder 中还应用了掩模多头注意力（Masked Multi-Head Attention），仍然通过残差连接方式融合其输入和输出。掩模的核心功能是在预测序列中当前向量的输出时，确保该预测仅依赖于序列中当前位置之前的已知向量，而不是依赖于后续未知向量。数据通过 Decoder 后，依次经过线性层和 Softmax 函数，最终输出概率值。位置编码（Positional Encoding）用于为序列中的不同位置向量提供编码信息，将这些编码与输入向量相加后送入编码器。这种方式使得网络能够识别并区分序列中各个位置的向量。

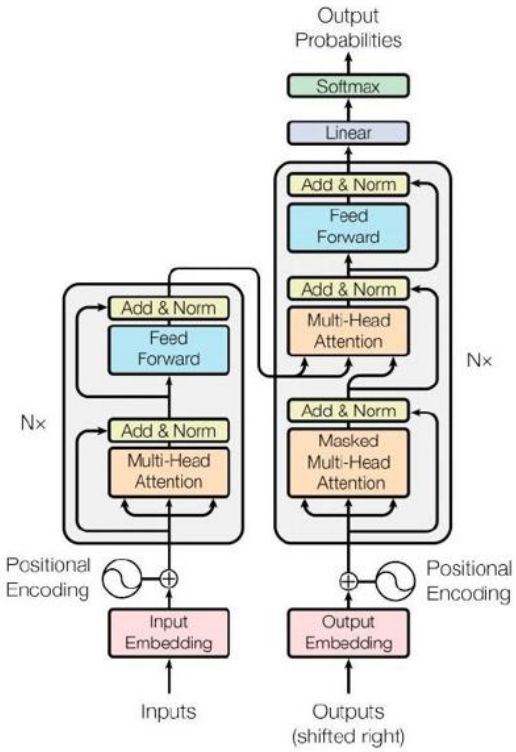


图 2.24 Transformer 示意图

Transformer 中最主要的创新之处是多头注意力，其结构如图 2.25 所示。多头注意力主要由多个缩放点乘注意力（Scaled Dot-Product Attention）和线性层（Linear）构成。缩放点乘注意力用于计算注意力权重，捕获序列中不同位置之间的依赖关系。Linear 用来进行特征变换，为注意力机制提供输入，并为其输出进行处理。

中国知网 https://www.cnki.net

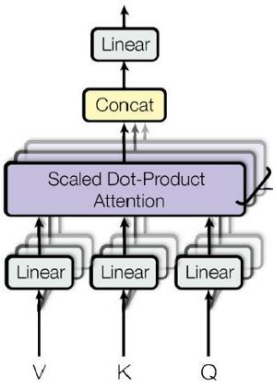


图 2.25 多头注意力

缩放点乘注意力结构如图 2.26 所示，首先通过 Linear 操作将输入向量映射成查询（Query，Q）向量、键（Key，K）向量和值（Value，V）向量，其次根据 Q 向量依次查询相对应的 K 向量，然后利用尺度缩放（Scale）获取每一个 V 向量相应的权重，最终得到输出向量。其中，“MatMul”表示矩阵相乘。该过程可用式(2-20)进行描述。

$$Attention\left(Q,K,V\right)=\text{softmax}(\frac{QK^{T}}{\sqrt{d_{k}}})V \tag{2-20}$$

其中，T 为转置操作，d_k 代表向量维度。

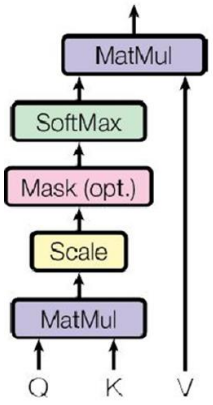


图 2.26 缩放点乘注意力

Transformer 中另一个重要的模块是前馈网络，该网络一般是 Linear 操作和激活函数构成的多层感知机（Multilayer Perceptron，MLP）。由于 Transformer 中未使用递归或卷积操作，因此无法捕获序列中向量位置。尽管将向量位置打乱，其输出结果总是相似。为解决这一问题，Transformer 模型采用位置编码操作来对不同位置的向量进行编码，从而使模型能够感知向量在序列中的位置。常见的位置编码方法主要包括三种：相对位置编码[85]，固定位置编码[113]和可学习位置编码[114]。在 Transformer 中，Vaswani 等人采用了固定位置编码方式，通过正弦和余弦函数来对位置进行编码，其表达式如式(2-21)和式(2-22)所示：

中国知网 https://www.cnki.net

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) \tag{2-21}$$

$$PE_{(pos,2i)} = \cos\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) \tag{2-22}$$

其中，pos 为向量位置，d_{model} 为向量维度，i 代表向量的第 i 个维度。通过这种编码方式，位置编码的维度与正弦信号相对应，从而有助于模型学习不同向量之间的位置关系。因为对任意固定偏移量 τ 而言，$PE_{pos+\tau}$ 能够表示成 PE_{pos} 的线性函数。

2.3.4 Vision Transformer

Transformer 最初被提出是用来解决自然语言处理任务，因该类型任务使用的数据信号一般是一维序列，而机器视觉任务中的图像数据属于二维信号，导致 2021 年之前 Transforme 在机器视觉任务中使用较少。因此以前处理机器视觉任务时大多采用卷积神经网络，然而卷积操作存在两个缺陷，一是卷积操作更为注重获取图像的局部信息，无法对感受野范围之外的特征进行建模，感知全局信息较为困难。另一个是卷积核和图像间不能依靠图像内容进行相应的调整，因此利用相同的卷积核恢复不同部分的图像块可能难以取得较好的结果。

针对上述问题，Dosovitskiy 等人[86]提出了 Vision Transformer 模型，该模型未使用卷积操作便成功的解决图像分类任务，且取得了较好的结果，能够堪比当时最优卷积神经网络的性能，其结构如图 2.27 所示。由于 Transforme 要求其输入数据是一维信号，然而图像为二维信号，因此首先需要将图像进行分块处理，通过 Linear 层将其映射为一维信号后，再将映射后的一维信号输入至 Transformer 编码器中。设图像尺寸为 $C \times H \times W$，其中 C 为图像通道数，H 为图像高度，W 为图像宽度。若经分块处理后的图像块大小为 $P \times P$，则图像可划分为 $N = \frac{H \times W}{P^2}$ 个图像块，其转换为一维序列后的长度为 N，一维序列中包含的任意向量的维度为 $P^2 \times C$。经过 Vision Transformer 编码器后，利用多层感知机输出结果，最终实现图像分类。

中国知网 https://www.cnki.net

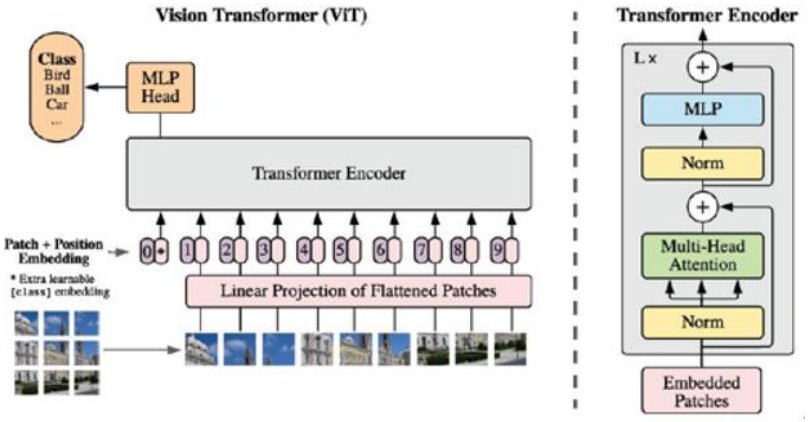


图 2.27 Vision Transformer 结构图

在本文第 6 章水下图像复原技术研究中，设计的门控融合 Transformer 块是以 Vision Transformer 模型为基础设计而成，笔者将 Vision Transformer 模型中的多头注意力替换为通道自注意力和移位窗口像素自注意力的联合应用方法，将多层感知机替换为设计的注意力前馈网络。然而与 Vision Transformer 模型不同的是，在本文第 6 章中未应用位置编码方法对图像像素位置信息进行编码。

2.4 云雾及水下图像数据集

在基于学习的图像复原技术中，图像数据发挥着重要作用。只有具备大量的用于训练的图像样本，神经网络才能够学习从低质量图像到高质量图像的映射关系，从而实现图像去云雾、水下图像复原等任务。目前，在图像去云雾和水下图像复原任务中，一般使用合成图像和真实图像数据集对网络模型进行训练和测试。合成云雾数据集一般是通过人工选取清晰图像，再根据大气散射模型生成相应的有雾图像。而由于水下清晰、自然的图像难以获取，合成水下图像一般通过人工选取退化的水下图像，再根据一系列的水下图像增强及复原技术生成相应的清晰水下图像，从而构成退化水下图像和清晰水下图像数据对。真实云雾数据集和水下图像数据集一般用于对训练完成的网络模型进行测试，以验证构建的网络模型的有效性、泛化性和鲁棒性。

2.4.1 自然场景图像去雾数据集

REalistic Single Image DEhazing（RESIDE）数据集[115]是去雾领域中最为常用的自然场景数据集之一，它包含大规模的室内及室外环境下的有雾及无雾图像对，以及一些于室外环境拍摄的真实有雾图像。RESIDE 数据集一共包括五个子数据集，分别是室内训练集（Indoor Training Set，ITS），室外训练集（Outdoor Training Set，OTS）、合成客观测试集（Synthetic Objective Testing Set，SOTS）、混合主观测试集

中国知网 https://www.cnki.net

（Hybrid Subjective Testing Set，HSTS）和现实任务驱动测试集（Real-world Task-driven Testing Set，RTTS）。RESIDE 数据集的详细组成信息如表 2.2 所示。

表 2.2 RESIDE 数据集

RESIDE 的子数据集	图像数量	真实/合成	室内/室外
ITS	13990	合成	室内
OTS	313950	合成	室外
SOTS	500	合成	室内/室外
HSTS	20	真实/合成	室外
RTTS	4322	真实	室外

2.4.1.1 室内训练集

ITS 数据集是 Li 等人从 NYU2[116]和 Middlebur[117]数据集中选取 1399 张室内无雾图像，通过大气散射模型生成对应的有雾图像而构成。在合成有雾图像过程中，随机从$[0.7,1.0]$范围内选取大气光值，随机从$[0.6,1.8]$范围内选取大气散射系数。每张无雾图像生成含有不同雾度的 10 张有雾图像，因此 ITS 数据集总计有 13990 张有雾图像。图像示例如图 2.28 所示，前三行为合成有雾图像，最后一行为清晰图像。



图 2.28 ITS 数据集示例图

2.4.1.2 室外训练集

OTS 数据集是 Li 等人首先从互联网中挑选 8970 张清晰无雾室外图像，然后通过大气散射模型生成对应的有雾图像而构成。

中国知网 https://www.cnki.net

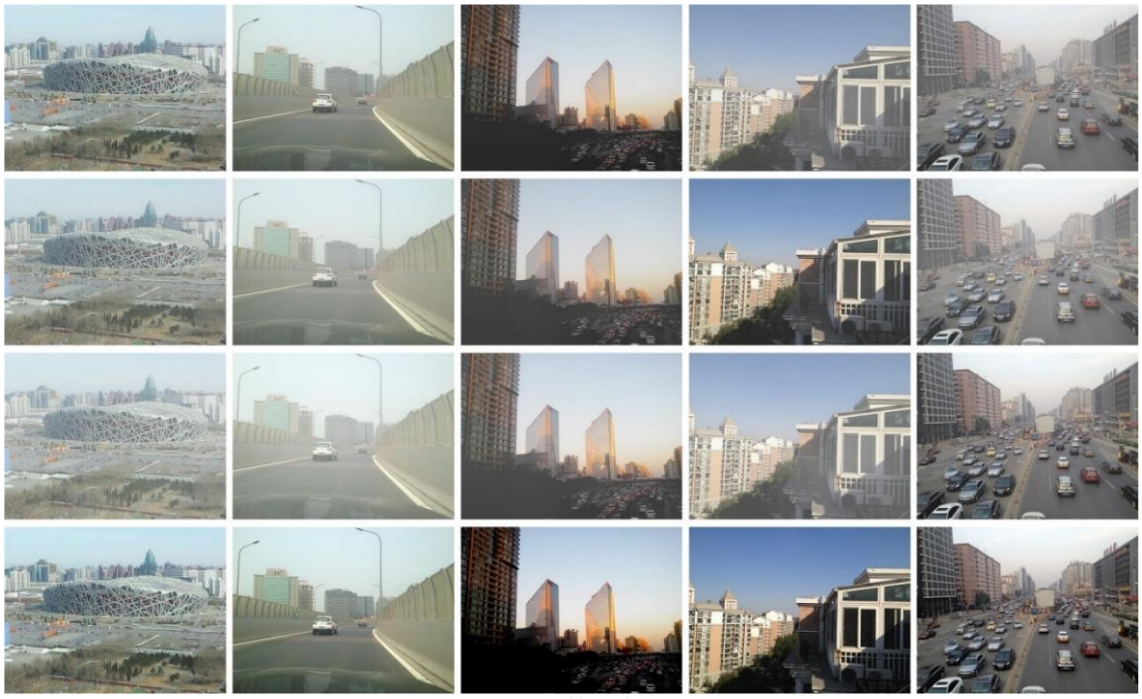


图 2.29 OTS 数据集示例图

在合成有雾图像过程中，随机从$[0.8,0.85,0.9,0.95,1.0]$五个值中选择其中之一作为大气光值，随机从$[0.04,0.06,0.08,0.1,0.12,0.16,0.2]$七个值中选择其中之一作为大气散射系数。每张无雾图像生成对应的 35 张有雾图像，因此 OTS 数据集总计包含 313950 张有雾图像。OTS 数据集图像示例如图 2.29 所示，其中前三行为合成有雾图像，第四行为对应的清晰图像。

2.4.1.3 混合主观测试集

HSTS 数据集由真实和合成室外场景和有雾图像各 10 张组成，其图像示例如图 2.30 所示，其中第一行为合成有雾图像，第二行为真实有雾图像。



图 2.30 HSTS 测试集示例图

中国知网 https://www.cnki.net

2.4.1.4 合成客观测试集

SOTS 数据集分别包含 500 张室内无雾图像和 500 张室外无雾图像，分别命名为 SOTS-indoor 数据集和 SOTS-outdoor 数据集。该数据集同样根据大气散射模型为每张图像生成对应的清晰图像。SOTS-indoor 数据集和 SOTS-outdoor 数据集示例如图 2.31 所示，其中前两行为合成室内有雾图像及其对应的清晰图像，后两行为合成室外有雾图像及其对应的清晰图像。

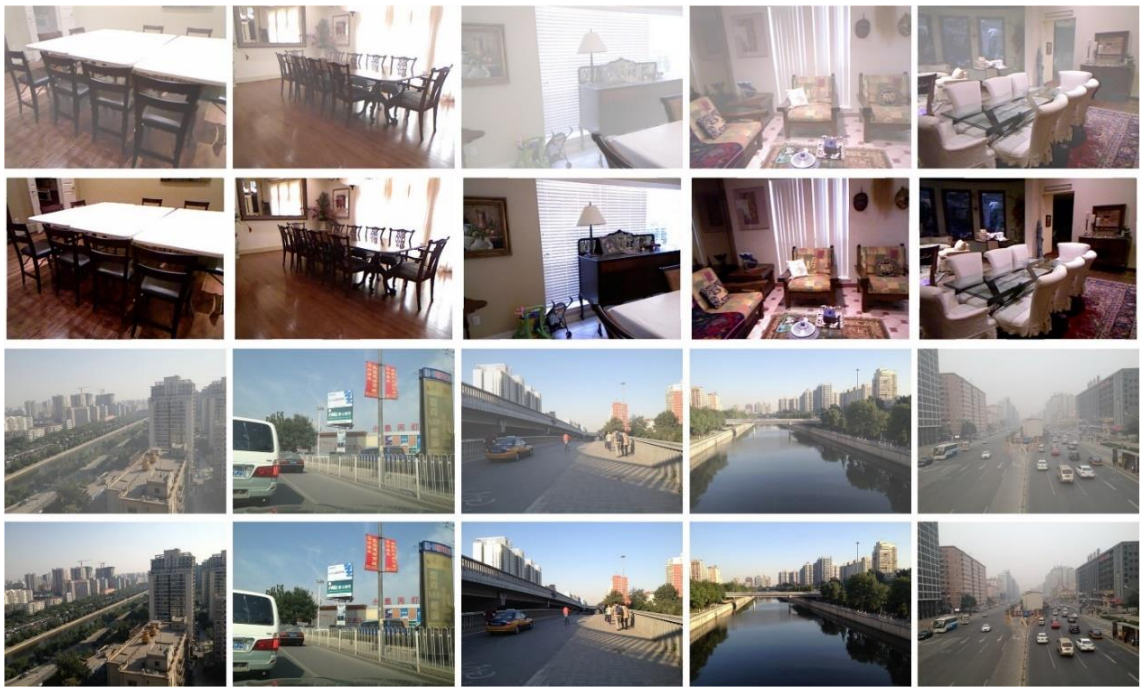


图 2.31 SOTS 合成室内及室外测试集示例图

2.4.1.5 现实任务驱动测试集

RTTS 包含 4322 张真实室外有雾图像，其内含有大量的交通和驾驶场景有雾图像，其图像示例如图 2.32 所示。

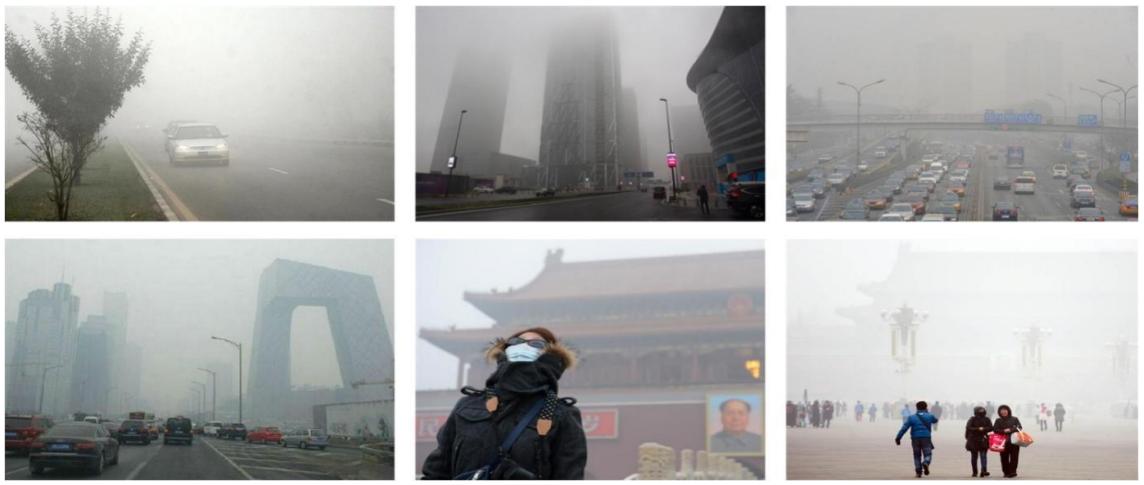


图 2.32 RTTS 数据集示例图

中国知网 https://www.cnki.net

2.4.1.6 NHHAZE 数据集

NHHAZE 数据集[118]是由 Ancuti 等人于 2020 年所构建。该数据集与 RESIDE 数据集的构建方法不同，它是 Ancuti 等人通过雾霾生成器来建立多场景的雾霾环境，再利用高清图像采集设备在同一场景下获取不同时刻的图像，从而建立有雾和无雾图像数据对。NHHAZE 数据集的图像示例如图 2.33 所示，其中第一行表示有雾图像，第二行表示相对应的无雾图像。



图 2.33 NHHAZE 数据集示例图

2.4.2 遥感场景图像去雾及去薄云数据集

2.4.2.1 SateHaze1K 数据集

SateHaze1k 数据集[119]由三个具有不同雾度图像的子数据集组成，分别称为 SateHaze1k-thin、SateHaze1k-moderate 和 SateHaze1k-thick。SateHaze1k-thin 主要由受薄雾（Thin fog）遮挡的合成遥感图像对组成，SateHaze1k-moderate 主要由受中度雾（Moderate fog）遮挡的合成遥感图像对组成，SateHaze1k-thick 主要由受厚雾（Thick fog）遮挡的合成遥感图像对组成。

在薄雾遮挡的合成图像中，雾掩模来自于原始真实云图像提取的雾。在中度雾遮挡的合成图像中，样本为薄雾和中度雾的重叠。在厚雾遮挡的合成图像中，其传输图来自于浓雾。在每个子数据集中，分为训练集、验证集和测试集。其中每个子数据集中的训练集包含 320 对 RGB 图像，验证集包含 35 对 RGB 图像，测试集包含 45 对 RGB 图像，图像尺寸均为512×512。图 2.34 为薄雾、中度雾和厚雾的示例图。其中第一列和第二列分别为薄雾图像及其对应的清晰图像，第三列和第四列分别为中度雾图像及其对应的清晰图像，第五列和第六列分别为浓雾图像及其对应的清晰图像。

中国知网 https://www.cnki.net



图 2.34 Satehaze1K 数据集示例图

2.4.2.2 HRSD 数据集

HRSD 数据集[57]于 2022 年被 Li 等人建立，用于解决遥感图像雾移除问题。该数据集包含两个子数据集，分别为轻度雾图像数据集（Light Hazy Image Dataset，LHID）和密集雾图像数据集（Dense Hazy Image Dataset，DHID）。LHID 数据集是 Li 等人从 Google Earth 中捕获的大规模遥感图像数据集中选择 35017 幅遥感图形成的训练数据集，分辨率为 0.2-153m，大小为512×512。同时根据大气散射模型，使大气光值$A=[0.7,1]$，透射率$t=[0.35,0.65]$，通过随机采样的方式生成对应的模糊图像。其中测试集图像为 500 对，其示例如图 2.35 第一行和第二行所示，其中第一行为有雾图像，第二行为对应的清晰图像。

DHID 数据集是 Li 等人首先从真实有雾遥感图像中提取 500 个不同的传输图。然后从 DLR 3k 慕尼黑车辆航拍图像数据集（DLR 3k Munich Vehicle Aerial Image Dataset，MVAID）中裁剪大小为512×512的清晰图像。其中 MVAID 数据集是由具有 55 种类型，大小为5616×3744的车辆、空中图像组成，地面采样距离约为$0.13m$。最后将提取到的传输图和随机大气光$A\in[0.7,1]$添加至清晰图像，从而生成 14990 幅图像，其中 14490 幅图像作为训练集，500 幅图像作为测试集，其示例图如图 2.35 第三行和第四行所示，其中第三行为有雾图像，第四行为对应的清晰图像。

中国知网 https://www.cnki.net



图 2.35 HRSD 数据集示例图

2.4.2.3 RICE-I 数据集

RICE-I数据集[120]是 Lin 等人首先从 Google Earth 上采集图像，从而构建的去云图像数据集，该数据集通过设置是否显示云层得到相应的有云和无云图像，然后将获取的图像大小裁剪为512×512 大小，总共由 500 对图像组成，其示例图如图 2.36 所示。其中第一行为有雾图像，第二行为对应的清晰图像。

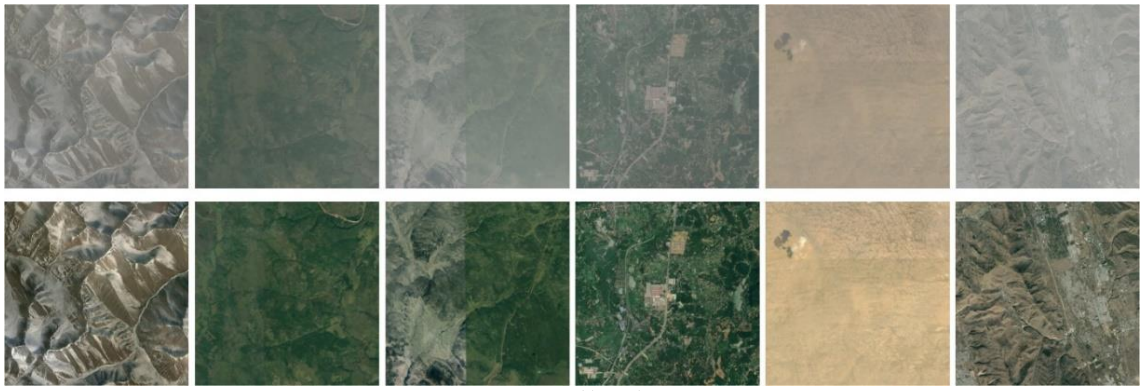


图 2.36 RICE-I数据集示例图

2.4.3 水下场景图像数据集

2.4.3.1 水下图像增强基准数据集

水下图像增强基准（Underwater Image Enhancement Benchmark，UIEB）数据集

中国知网 https://www.cnki.net

[76]是 Li 等人通过互联网而获取，其对应的地面真实图像是通过以前的图像增强技术以及手动选择产生。具体来说，通过给定的水下图像，使用几种水下图像复原和增强技术获取相应的清晰水下图像。最优结果是根据几位志愿者投票选择，并将这一结果作为地面真实图像。该数据集总共包含 950 张图像，其中将 890 张通过图像增强或复原技术生成相应的地面真实图像，另外 60 张作为具有挑战性的基准数据集。图 2.37 为 UIEB 数据集的示例图，其中第一行和第二行分别为水下图像及相对应的、生成的参考图像，第三行为挑战性的基准数据集图像，该数据集没有对应的地面真实图像。



图 2.37 UIEB 数据集示例图

2.4.3.2 大规模水下图像数据集

Peng 等人[90]考虑现有的水下图像数据缺乏，于 2022 年构建了大规模水下图像（Large-Scale Underwater Image，LSUI）数据集。该数据集选择了具有丰富的水下场景、不同的水类型、照明条件以及目标类别的水下图像。依次经过 18 种水下图像增强或复原技术清晰化水下图像和多名志愿者投票，对每个生成的参考图像进行评分，从而确定最终对应的生成清晰水下图像。LSUI 数据集包含 4279 张多场景、多类型的水下图像及其对应的高质量图像，其示例图如图 2.38 所示，其中第一行为水下图像，第二行为对应的高质量图像。



图 2.38 LSUI 数据集示例图

中国知网 https://www.cnki.net

2.4.3.3 U45 数据集

U45 数据集[121]是由南京信息工程大学创建的一个公开水下测试数据集，包含 45 张真实水下图像，其中含有绿色、蓝色和有雾三种类型图像，旨在模拟水下图像的颜色偏移、低对比度和雾状效应，其示例图如图 2.39 所示。

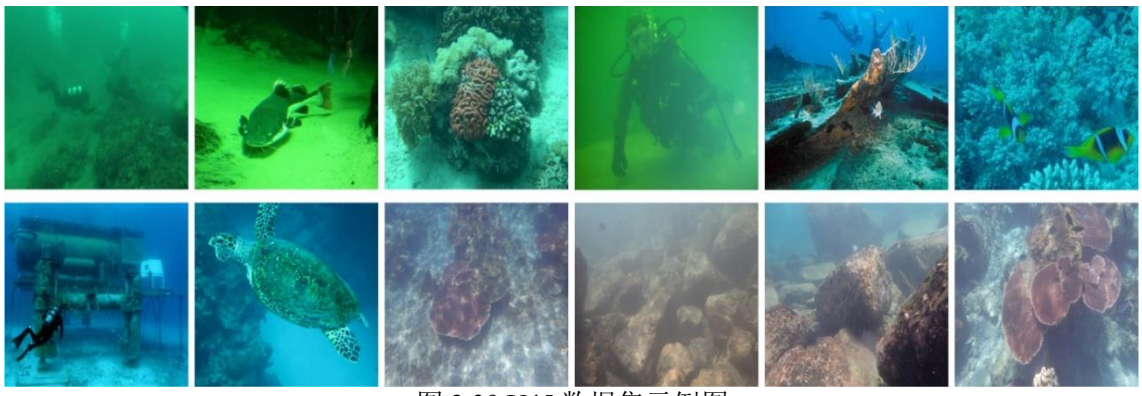


图 2.39 U45 数据集示例图

2.4.3.4 UPoor 数据集

UPoor 数据集[122]是 Peng 等人从互联网收集水下图像，进而构建的水下图像测试数据集。该数据集由 200 张现实世界的水下图像组成，包含蓝绿色、低照明、模糊和有雾等类型的水下图像，且视觉质量较差，其示例图如图 2.40 所示。



图 2.40 UPoor 数据集示例图

2.5 复原图像质量评价

为了对不同复原技术的性能进行合理评估，通常使用图像的主观质量评价和客观质量评价两种方法。主观质量评价通过直接依赖观察者的感受和反馈来评估图像质量，主要依据个人的主观判断，因此具有较强的主观性。相对而言，客观质量评价则通过构建数学评价指标对复原图像进行量化分析，能够实现自动化评估。这种方法有助于研究者定量分析复原图像与真实图像之间的差异，因此具有较高的客观性。

中国知网 https://www.cnki.net

2.5.1 主观质量评价

主观质量评价是利用人眼直接观测通过算法复原的低质量图像，依靠个人的主观感觉来评价算法复原图像的效果，属于直观的图像质量评价方法。当复原图像质量区别明显时，能够比较准确的判断复原算法性能的好坏。但是当复原图像质量区别不显著时，人眼经常难以更为准确的判断和分析不同复原技术的细节和颜色恢复程度等。在这种情况下，主观因素对不同复原技术的评价结果会产生较大影响。不同的评价者一般具有不同的兴趣偏好，知识体系，专业方向，细节特征关注，导致想要获得统一的评价结果较为困难，这类评价方法缺失了一定程度的客观性。

2.5.2 客观质量评价

客观评价指标通常通过建立数学模型来推导量化结果，从而评估复原图像的质量。这种评价方式具有较强的说服力，因为它能够提供一致且可重复的评估标准。根据是否需要清晰的参考图像，客观图像质量评价指标可以分为两类：有参考评价指标和无参考评价指标。

2.5.2.1 有参考评价指标

(1) 均方误差(Mean Squared Error, MSE)是用来衡量估计值与真实值之间差异的指标，表示复原图像和参考图像之间的累计平方误差，其表达式为：

$$\mathrm{MSE}=\frac{1}{HW}\sum_{i=1}^{H}\sum_{j=1}^{W}\left[X\left(i,j\right)-Y\left(i,j\right)\right]^{2} \tag{2-23}$$

其中，X 表示复原图像，Y 表示清晰的参考图像，HW 表示图像分辨率。MSE 的值越小，图像质量越好，复原图像和真实图像之间的差异越小。

(2) 峰值信噪比(Peak Signal to Noise Ratio, PSNR)常用来评估复原图像与参考图像之间的失真程度，其表达式为：

$$\mathrm{PSNR}=10\times\log_{10}\left[\frac{\left(2^{n}-1\right)^{2}}{\mathrm{MSE}}\right] \tag{2-24}$$

其中，n表示各个像素的比特数，灰度图像一般令$n=8$，RGB 图像一般令$n=24$。PSNR 的值越高，复原图像和参考图像之间的失真程度越小。

(3) 结构相似度(Structural Similarity, SSIM)[123]是一种用于衡量两幅图像之间相似度的指标，它不仅考虑了像素间的差异，还综合考虑了亮度、对比度和结构信息之间的关系，其表达式为：

中国知网 https://www.cnki.net

$$\mathrm{SSIM}(x,y)=\frac{(2u_xu_y+C_1)(2\sigma_{xy}+C_2)}{(u_x^2+u_y^2+C_1)(\sigma_x^2+\sigma_y^2+C_2)} \tag{2-25}$$

其中，u_x 和 u_y 分别代表复原图像 x 和参考图像 y 的平均值，σ_x 和 σ_y 分别代表 x 和 y 的标准差，σ_{xy} 代表协方差，C_1 和 C_2 为常数。SSIM 的取值范围为 0~1，其值越接近 1，复原图像与参考图像的相似度越高。

(4) 学习感知图像块相似度[124]（Learned Perceptual Image Patch Similarity，LPIPS）是用来衡量图像之间感知相似度的指标。LPIPS 是一种基于深度学习的图像相似度度量方法，它通过学习感知特征来评估图像之间的差异，从而更准确地模拟人类视觉系统对图像的感知。在本文中，主要利用训练好的 AlexNet 网络，输入复原图像和参考图像，从 n 层提取特征堆栈，并在通道维度上进行单位归一化。通过向量 φ_n 缩放激活通道，并计算 L2 距离。最后在空间上进行平均求和。LPIPS 表达式为：

$$d(J_G,J)=\sum_n\frac{1}{H_nW_n}\sum_{h,w}\left\|\varphi_n\cdot\left(y_{hw}^n-y_{0hw}^n\right)\right\|_2^2 \tag{2-26}$$

其中，J_G、J 分别是参考图像和复原图像，$y_{hw}^n,y_{0hw}^n\in R^{H_n*W_n*C_n}$，$\varphi_n\in R^{C_n}$。LPIPS 值越小，图像之间感知相似度越高。

2.5.2.2 无参考评价指标

无参考评价指标一般基于图像的内在特性或统计规律来评价图像质量的好坏，不需要参考图像，能够比较灵活的被使用。在本文中无参考图像评价指标主要用于评价经过水下图像复原技术恢复图像的质量，主要介绍两个常用的水下图像评价指标：水下图像质量评价指标（Underwater Image Quality Measures, UIQM）[125]和水下彩色图像质量评价指标（Underwater Color Image Quality Evaluation, UCIQE）[126]。

(1) UIQM 是一种典型的融合指标，它融合了图像的色度属性 UICM、清晰度属性 UISM 和对比度属性 UIConM 三个度量指标，其表达式为：

$$UIQM=C_1\times UICM+C_2\times UISM+C_3\times UIConM \tag{2-27}$$

其中，C_1，C_2 和 C_3 为 UIQM 进行融合的三个权重系数，在现实情景应用时一般令 $C_1=0.0282$，$C_2=0.2953$ 及 $C_3=3.5753$。UIQM 值越高，代表复原图像质量越好。

(2) UCIQE 利用线性模型整合了 CIELab 色彩空间下的色度、饱和度和对比度度量，能够综合考虑图像的颜色特征，其表达式为：

$$UCIQE=c_1\times\sigma_c+c_2\times con_l+c_3\times\mu_s \tag{2-28}$$

其中，σ_c，con_l 和 μ_s 分别代表色度的标准差、亮度的对比度及饱和度的均值。分别令 $c_1=0.4859$，$c_2=0.2745$ 及 $c_3=0.2576$，它们表示相应的权重系数。UCIQE 的值越

中国知网 https://www.cnki.net

大，表明复原图像在色度、对比度和饱和度方面取得了相对不错的视觉效果。

2.6 本章小结

本章介绍了散射介质及光在散射介质中传播时的退化机理，着重描述了一些受薄云、雾和水体三类散射介质的影响而导致的退化图像复原技术，包括传统方法和基于学习的方法，并给出了相应的复原结果。围绕本文重点应用的深度学习技术，介绍了神经网络的基本理论及 U-Net 网络模型和 Transformer 模型的基本理论，阐述了薄云、雾和水体的图像数据集以及相关图像质量评价方法，为后文的理论方法以及实验结果评价奠定基础。

中国知网 https://www.cnki.net

第 3 章 基于多尺度注意力特征增强的图像去雾技术研究

在本章中，首先阐述了基于多尺度注意力特征增强的图像去雾技术提出的背景。其次对网络架构及其组件进行了详细的说明，包括网络的总体结构，设计的去雾融合块、多尺度注意力增强模块和注意力特征增强模块。然后通过实验验证了提出的基于多尺度注意力特征增强的图像去雾技术的有效性，实验包括在合成有雾图像数据集和真实有雾图像数据集的定量和定性实验，以及消融实验。最后对本章节阐述的主要内容进行了总结。

3.1 引言

分析第 2 章中描述的大气散射模型，可以发现该模型主要受到两个因素的影响：大气光值和透射率。因此，很多传统方法都是通过先验知识分别对这两个因素进行估计求解，最后利用大气散射模型复原清晰图像。He 等人[31]依靠暗通道先验估计大气光值和透射率。Meng 等人[127]通过引入图像内容约束改进暗通道先验，增强了去雾图像的纹理。然而基于手工特征一般比较单一，提取图像中复杂的特征信息时总是受到一定程度的限制，往往难以实现理想的去雾效果。

深度学习技术现已广泛的应用于图像去雾任务。Li 等人[42]对大气散射模型进行变换，提出使用一个新的变量代替大气光和透射率图以避免对它们的估计。但是该技术利用了小网络结构以致未能充分考虑复杂情形的有雾图像，在一些情形下存在色彩失真等现象。Qu 等人[128]通过网络直接学习有雾和无雾图像的映射关系，构建了 pix2pix 网络实现去雾，但该技术存在去雾过度等现象。受注意力机制的启发，Tian 等人[129]提出注意力引导的神经网络用来去噪，降低了模型复杂性。Chen 等人[130]提出了基于特征注意力机制的超分辨重建网络，将注意力与特征提取模块进行了有效结合，重建的图像取得了较好的效果。

基于上述分析，为克服去雾过程中存在的色彩失真、去雾过度等问题，尽可能的重建高质量图像。本章通过引入注意力机制并结合多尺度策略，提出了基于多尺度注意力特征增强（Multi-scale Attention Feature Enhancement，MAFE）的图像去雾技术。该技术的核心组件是提出的注意力特征增强（Attention Feature Enhancement，AFE）模块，它包含了通道注意力（Channel Attention，CA）、像素注意力（Pixel Attention，PA）和上下文增强模块 Context Enhancement Module，CEM），能够赋予关注对象区域更高的权重，抑制无用信息的干扰，增强上下文信息。同时，以注意力特征增强模块为基础，与高效空间金字塔（Efficient Spatial Pyramid，ESP）模块有效结合，从而构建多尺度注意力增强（Multi-scale Attention Enhancement，MAE）模

中国知网 https://www.cnki.net

块，以获取不同尺度的特征信息，弥补注意力特征增强模块造成有用信息的损失，提升网络的去雾性能。本章提出的去雾技术主要有以下贡献：

(1) 提出一种基于多尺度注意力特征增强的图像去雾技术。该技术依靠多尺度信息和注意力机制，自适应的关注有雾图像和高频信息，更好的保留细节信息。由于其无需依赖大气散射模型，因此不受估计的大气光值的影响，能够有效解决颜色失真问题。

(2) 提出注意力特征增强模块，该模块能够灵活的关注有雾图像的高频信息，增强上下文信息的相关性，抑制冗余信息，补偿损失的细节信息。

(3) 提出多尺度注意力增强模块，该模块以注意力特征增强模块为基础，结合使用高效空间金字塔模块，实现图像多尺度特征的充分提取和利用，扩展感受野，提升去雾图像质量。

(4) 在合成和现实世界的有雾图像上的实验结果表明，本章技术在去雾性能方面取得了先进水平，去雾效果显著，很好地保留了图像颜色等信息。

3.2 网络架构设计

本章提出的多尺度注意力特征增强去雾网络（Multi-scale Attention Feature Enhancement Dehazing Network，MAFENet）如图3.1所示。MAFENet主要由3×3卷积、去雾融合块（Dehazing Fusion Block，DFB）、CA、PA和CEM[131]组成。其中，DFB是构成该网络的主要组件，在其内部同样使用了CA、PA和CEM，它被用来提取图像的多尺度信息，能够实现对雾信息和高频信息的有效提取，提升网络的去雾能力。CA和PA分别被用来自适应的对关键通道特征和像素特征进行重点关注。CEM用于弥补注意力机制导致的细节损失，增强上下文信息，抑制冗余信息。

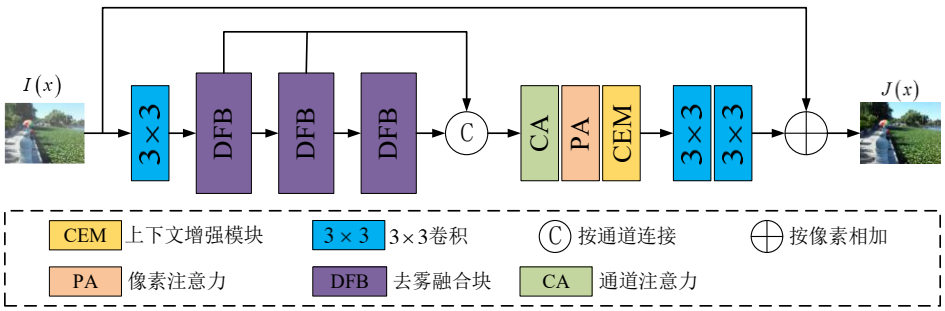


图 3.1 多尺度注意力特征增强去雾网络架构图

MAFENet的输入是具有RGB通道的有雾图像$I(x)$，其首先通过一个3×3卷积来提取浅层特征并生成具有多通道的特征图。其次这一特征图依次通过三个DFB以获取特征信息并加深网络深度，增强网络的泛化能力。然而随着网络逐渐加深，会丢失大量细节信息，因此将三个DFB提取的特征在通道方向上连接起来，从而实现深层和浅层信息的融合，在提取丰富特征的同时保留更多细节。然后将融合的深层和浅层特征依

中国知网 https://www.cnki.net

次传递至CA、PA和CEM中，从而进一步整合融合特征，获取有价值信息，减少冗余信息干扰。最后信息流依次通过两个3×3 卷积，同时利用全局跳跃连接防止梯度消失，从而重建清晰的无雾图像$J(x)$。

3.2.1 通道注意力

池化（Pooling）通常用于减少特征图的空间尺寸，降低参数量和计算成本，保留重要信息。最大池化（Max Pooling）和平均池化（Average Pooling）是神经网络中最常用的两种池化操作。最大池化是对邻域内特征点取最大，能够很好地保留图像的纹理特征，其过程示例如图3.2所示。最大池化首先在前向传播过程中获取特征图邻域内的最大像素值，同时记录最大值的索引位置，然后在反向传播过程中将这一像素值填充到前向传播中值最大的索引位置，最后其它位置填充0。

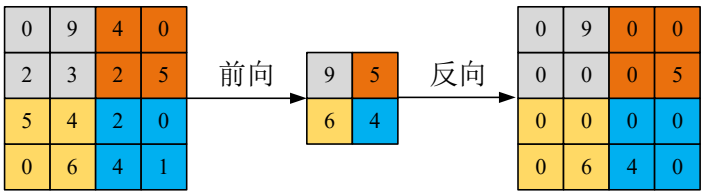


图 3.2 最大池化过程示例图

平均池化是对邻域内的特征点取平均值，在保留图像的背景信息方面有较好的效果，其过程示例如图3.3所示。平均池化在前向传播过程中首先计算特征图邻域内的平均像素值，然后在反向传播过程时将获得的值平均分配给每一个索引位置。

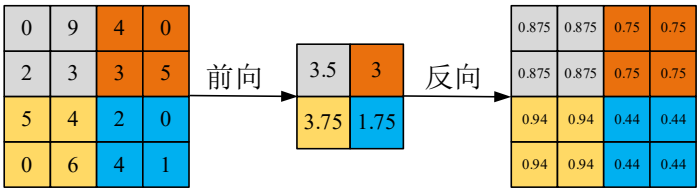


图 3.3 平均池化过程示例图

传统的通道注意力模块一般采用平均池化聚合空间信息，这可能导致图像大量细节信息的丢失。最大池化是收集独特对象的另一种手段。本章将平均池化和最大池化同时应用到通道注意力中，以两种不同池化方式获取图像的不同通道特征，然后将它们融合以保留更多的细节信息，通道注意力结构如图3.4所示。

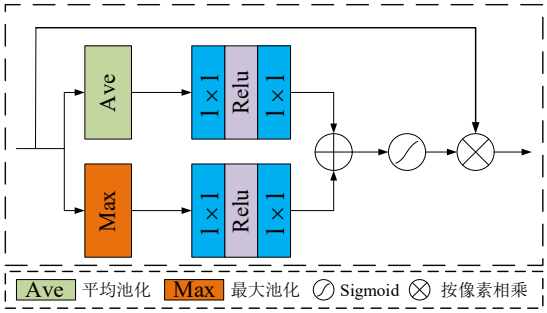


图 3.4 通道注意力结构图

中国知网 https://www.cnki.net

首先，利用平均池化和最大池化聚合特征图的空间信息以获得不同的通道描述符。平均池化和最大池化分别由式(3-1)和(3-2)所示：

$$g_a = H_a\left(F_c^*\right) = \frac{1}{H \times W}\sum_{i=1}^{H}\sum_{j=1}^{W} X_c\left(i,j\right) \tag{3-1}$$

$$g_m = H_m\left(F_c^*\right) = max\left(X_c\left(i,j\right)\right) \tag{3-2}$$

其中，F_c^* 为输入特征图，$X_c\left(i,j\right)$ 为第 c 个通道 X_c 在 $\left(i,j\right)$ 位置的值，H_a 表示平均函数，H_m 表示最大值函数。

其次，为了关注更多图像细节，采用两个卷积层和一个Rule激活函数对两条路径上的通道特征进行融合，融合特征如式(3-3)所示：

$$C_f = conv_p\left(\delta\left(conv_p\left(g_a\right)\right)\right) + conv_p\left(\delta\left(conv_p\left(g_m\right)\right)\right) \tag{3-3}$$

其中，C_f 表示融合的通道特征，δ 表示 Relu 函数，$conv_p$ 表示逐点卷积，用来调整通道数。

然后，利用 Sigmoid 函数，分配不同通道的权重，如式(3-4)所示：

$$A_c = \sigma\left(C_f\right) \tag{3-4}$$

其中，A_c 为融合特征的权重值，σ 为 sigmoid 函数。

最后，将输入特征图 F_c 逐像素与权重值 A_c 相乘，获得输出结果 F_c，如式(3-5)所示：

$$F_c = F_c^* \otimes A_c \tag{3-5}$$

3.2.2 像素注意力

像素注意力具有灵活关注图像中浓雾像素和高频区域的能力，它包含两个1×1 卷积、Relu和Sigmoid函数，其结构如图3.5所示。

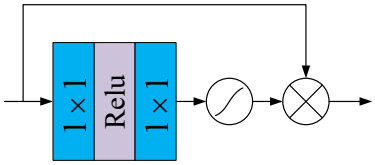


图 3.5 像素注意力结构图

1×1 卷积用于将特征图形状逐步从 $C \times H \times W$ 变换为 $1 \times H \times W$ 。PA的过程如式(3-6)所示：

$$\mathrm{PA} = \sigma\left(conv_p\left(\delta\left(conv_p\left(F_{PA}^*\right)\right)\right)\right) \tag{3-6}$$

其中，F_{PA}^* 是PA的输入特征。进而 F_{PA}^* 和PA逐元素相乘，最终得到PA的输出特征

中国知网 https://www.cnki.net

F_{PA}。

$$F_{PA} = F_{PA}^{*} \otimes PA \tag{3-7}$$

3.2.3 上下文增强模块

CEM 的结构如图 3.6 所示，其主要由1×1 卷积、3×3 卷积、下采样（Downsample）、最大池化和上采样（Upsample）组成。

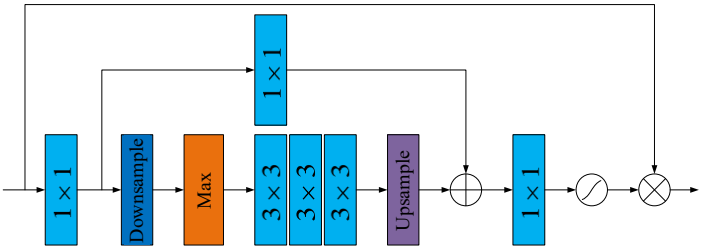


图 3.6 上下文增强模块结构图

CEM 的输入特征首先通过1×1 卷积改变通道数，重新整合特征。然后信息流顺次流过下采样、最大池化、3×3 卷积和上采样操作。其中下采样是一个步长为 2 的3×3 卷积，用来减少特征图空间尺寸，捕获大范围的上下文信息。最大池化的卷积核大小为 7，步长为 3，能够进一步增大感受野，同时忽略一些不重要的冗余信息。串联的 3 个3×3 卷积能够加深网络深度，加强对深层特征信息的获取。上采样用来对特征信息进行重建。然后分别通过两个1×1 卷积调整通道数以便于信息融合以及对融合后的信息进行整合。最后通过 sigmoid 函数获取经过上述操作后的特征图权重，并与原始输入特征逐像素相乘，从而获得增强了上下文信息的输出特征。其执行过程如式(3-8)所示：

$$F_{cem} = f_{cem}\left(F_{cem}^{*}\right) \in R^{H\times W\times C} = F_{cem}^{*} \otimes \sigma\left(f_{1\times1}\left(f_{1\times1}\left(f_{1\times1}\left(F_{cem}^{*}\right)\right) + \tilde{F}_{cem}^{*}\right)\right) \tag{3-8}$$

其中，f_{cem} 表示 CEM 处理过程，F_{cem}^{*} 和 F_{cem} 分别表示 CEM 的输入和输出，$f_{1\times1}$ 表示1×1 卷积，$\tilde{F}_{cem}^{*} \in R^{H\times W\times C}$ 表示 CEM 中进行以下六个连续操作后的输出：下采样→最大池化→3×3 卷积→3×3 卷积→3×3 卷积→上采样。

3.2.4 去雾融合块

去雾融合块主要由MAE模块、3×3 卷积和跳跃连接组成，如图3.7所示。根据经验，在DFB中使用四个连续的MAE模块，这不仅能够增加网络深度和表达能力以提升去雾性能，而且可以保证网络的参数大小保持相对较低。跳跃连接用来防止随着深度的增加导致梯度消失，从而加快训练速度。DFB执行过程如式(3-9)所示：

$$F_{D} = F_{D}^{*} + conv\left(\mathrm{MAE}_{k}\left(F_{D}^{*}\right)\right) \tag{3-9}$$

中国知网 https://www.cnki.net

其中，F_{D}^{*}为 DFB 的输入，F_{D}为 DFB 的输出，$conv$为步长为 1 的3×3 卷积，MAE_{k}为顺次使用 MAE 模块的个数，在本章去雾技术中k设置为 4。

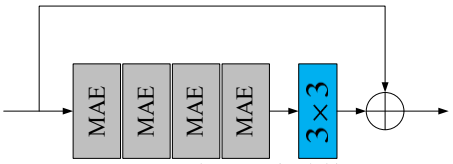


图 3.7 去雾融合块结构图

MAE 模块的结构如图 3.8 所示。在 MAE 中，输入特征首先经过一个局部残差（Local Residual，LR），以增强网络稳定性并聚焦有价值的特征信息。其次得到的信息并行地流入至 AFE 模块和 ESP 模块中，AFE 模块用于自适应提取关键有用信息，ESP 模块用于提取多尺度信息并消除网格伪影。然后将两条支路得到的特征图按通道连接，以实现多尺度信息对 AFE 模块获取的信息的进一步补充，减少信息在流经 AFE 模块时细节信息的损失。最后利用一个3×3 卷积重新整合特征、降低通道数并输出。MAE 模块的执行过程如式(3-10)所示：

$$F_{M}=conv(cat(\mathrm{AFE}(\mathrm{LR}(F_{M}^{*})),conv(\mathrm{ESP}(\mathrm{LR}(F_{M}^{*})))))\tag{3-10}$$

其中，F_{M}^{*}表示 MAE 模块的输入特征，F_{M}表示 MAE 模块的输出特征，$conv$表示3×3 卷积，cat表示按通道连接特征图。下面分别对 ESP 模块和 AFE 模块进行详细介绍。

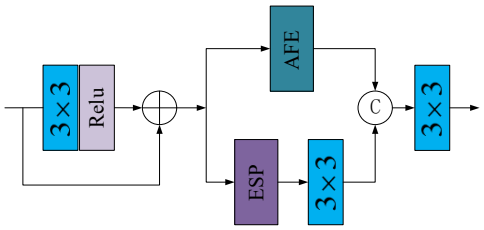


图 3.8 多尺度注意力增强模块结构图

(1) 高效空间金字塔模块

不同尺度图像特征具有不同的语义信息，充分提取和利用多尺度特征可以有效提高去雾图像的质量。与使用不同大小的普通卷积核来调整感受野大小相比，扩张卷积可以在不引入其他计算和参数的情况下达到同样的性能，图 3.9 展示了扩张卷积和普通卷积的对比情况。其是一种特殊形式的标准卷积，通过在卷积核中的每个像素之间插入零（或空洞）来增加核的有效感受野。对于扩张率为r的$n\times n$扩张卷积核，核的有效大小为$\left[(n-1)r+1\right]^{2}$。扩张率特指像素之间的零（或空洞）数量。由于扩张率，只有$n\times n$像素参与卷积运算，从而降低计算成本，同时增加有效核大小。

中国知网 https://www.cnki.net

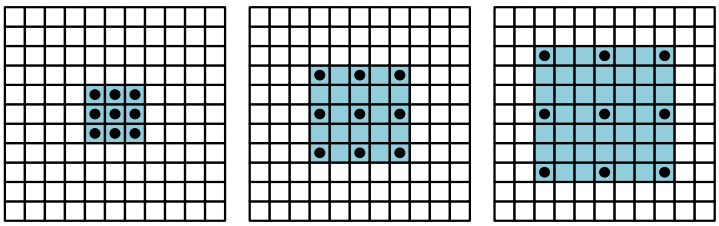


图 3.9 普通卷积和扩张卷积对比图

(a) 卷积 (b) 扩张率为 2 的扩张卷积 (c) 扩张率为 3 的扩张卷积

Mehta 等人[132]提出了 ESP 模块，它相当于一种卷积分解形式，结构如图 3.10 所示，其将标准卷积分解为逐点卷积和空洞卷积的空间金字塔。逐点卷积应用1×1卷积将高维特征图投影到低维空间。然后，空洞卷积的空间金字塔同时使用 η 、$n\times n$ 的空洞卷积核对这些低维特征图进行重新采样，每个卷积核的空洞率为 $2^{\eta-1}$，其中 $\eta=(1,2,\cdots,\eta)$。这种分解方法能够大大减少 ESP 模块所需的参数数量和内存，同时保留较大的有效感受野，感受野大小为 $\left[(n-1)2^{\eta-1}+1\right]^2$。因每个空洞卷积核都学习具有不同感受野的权重，类似于空间金字塔，因此此类金字塔卷积运算称为空洞卷积式的空间金字塔。尽管连接扩张卷积的输出会为 ESP 模块提供较大的有效感受野，但它会引入不必要的棋盘格或网格伪影。为解决 ESP 中的网格伪影，利用分层特征融合（Hierarchical feature fusion，HFF）连接不同扩张率内核获得的特征图。为改善网络内的梯度流，使用元素求和将输入和输出特征图组合在一起。最后依次通过批归一化（Batch Normalization，BN）和 PRelu 激活函数缓解梯度消失问题。

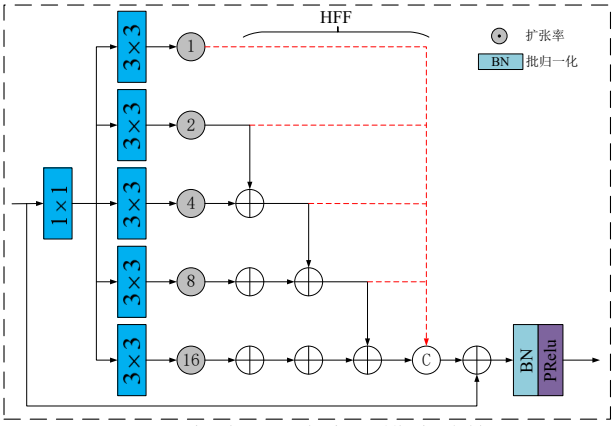


图 3.10 高效空间金字塔模块结构图

激活函数在神经网络模型学习过程中具有至关重要的作用，其被用于在网络模型进行学习时引入非线性因素，使网络能够学习和表示更为复杂的模式和关系。Relu 是目前常用的激活函数之一，一般情况下，指代数学中的斜坡函数，其表达式如式(3-11)所示，它能够将所有的负值置为 0，而其余的值保持不变，对应的函数图像如图 3.11 所示。

$$\mathrm{Relu}(x)=\max(0,x) \tag{3-11}$$

中国知网 https://www.cnki.net

其中，x为输入值，$\mathrm{Relu}(x)$为输出值。

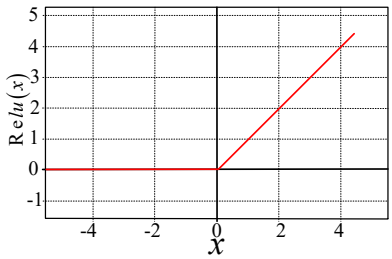


图 3.11 Relu 激活函数

PRelu 激活函数式 Relu 激活函数的一种变体，相比于 Relu 函数，PRelu 函数设置了一个可学习的参数，以调整输入值为负数时的输出，缓解 Relu 函数在负输入值部分的梯度消失问题，能够使网络自适应地调整激活函数的形状，提高网络模型的灵活性。PRelu 函数表达式如式(3-12)所示，对应的函数图像如图 3.12 所示。

$$\mathrm{PRelu}(x)=\begin{cases}\delta x & x<0\\ x & x\geq 0\end{cases} \tag{3-12}$$

其中，x表示输入，δ表示可学习的参数，一般小于 1，$\mathrm{PRelu}(x)$表示输出。在本章 ESP 模块中的 PRelu 函数中，将δ设置为 0.25。

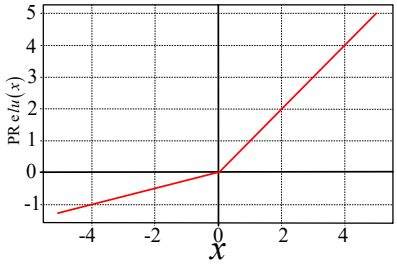


图 3.12 PRelu 激活函数

(2) 注意力特征增强模块

AFE模块是为弥补现有注意力机制在图像处理过程中总是丢失部分细节信息所设计的。该模块主要由LR、CA、PA和CEM组成，其结构如图3.13所示。首先，令F_A^*为AFE模块的输入特征图，将其输入局部残差中以避开雾和低频区域，聚焦有用信息，如式(3-13)所示。

$$F_1=\mathrm{LR}\left(F_A^*\right) \tag{3-13}$$

其次，提取的信息在经过一个3×3 卷积后分别输入到两条支路中，在一条支路中通过 CA 来重新分配通道权重，对有用的通道特征进行重点关注。在另一条支路中通过 PA 重新分配像素权重，对重点有雾的像素特征进行自适应关注，增强对不均匀雾分布的灵敏度，并将其传递至 CEM 中以增强感受野，提升上下文信息的相关性。两条支路信息流传递过程如式(3-14)所示：

中国知网 https://www.cnki.net

$$\begin{aligned} F_2 &= \mathrm{CA}\left(F_1\right) \\ F_2^* &= \mathrm{CEM}\left(\mathrm{PA}\left(F_1\right)\right) \end{aligned} \tag{3-14}$$

然后，将两条支路获得的特征信息按像素相加，以实现对重点通道信息和像素信息的融合，如式(3-15)所示：

$$F_3 = F_2 + F_2^* \tag{3-15}$$

最后，为进一步保留浅层局部细节信息，避免梯度消失，通过局部跳跃连接融合浅层和深层信息后再进行输出，如式(3-16)所示：

$$F_A = F_1 + F_3 \tag{3-16}$$

其中，F_A 表示 AFE 模块的输出。

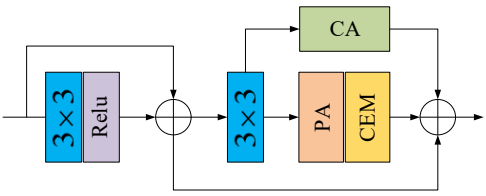


图 3.13 注意力特征增强模块结构图

值得说明的是，在 AFE 模块中尽管 PA 可以聚焦高频信息，但是 PA 在浅层特征上的感受野有限，难以保证后续的特征学习充足的上下文信息。因此在 AFE 模块中，将增强注意力机制的 CEM 连接至 PA 之后，以增大感受野，捕获更多的上下文信息，抑制无用冗余信息。

3.2.5 损失函数

为规范本章去雾网络在训练过程时的学习方向，将 L1 损失和感知损失组合使用作为整个训练过程的损失函数。L1 损失用于校正图像之间的像素差异，感知损失用于规范人类视觉感知效果。总损失函数如式(3-17)所示：

$$Loss = \lambda_1 L_1 + \lambda_p L_p \tag{3-17}$$

其中，λ_1 和 λ_p 分别表示 L1 损失和感知损失的权重。本章以 L1 函数作为主要损失函数，感知损失函数在深度特征层面对去雾图像和原始清晰图像进行微调。根据经验，将 λ_1 和 λ_p 分别设置为 1 和 0.04。

L1 损失又被称为平均绝对值误差，是一种逐像素比较差异并取绝对值的回归模型，其表达式如式(3-18)所示：

$$L_1 = \frac{1}{N}\sum_{\mathrm{n}=1}^{N}\sum_{c=1}^{3}\left|I_c\left(n\right) - I_c^{gt}\left(n\right)\right| \tag{3-18}$$

式中，N 为训练集中的样本数量，c 为通道数，$I_c\left(n\right)$ 为经过本章去雾网络恢复后的

中国知网 https://www.cnki.net

无雾图像，$I_c^{gt}(n)$为原始无雾清晰图像。L1 函数能够制造稀疏特征，将无用特征的权重置 0，具有特征选择作用。

在图像复原任务中，感知损失广泛的应用于两幅图像之间的感知差异，能够获得较为丰富的细节信息。本章采用 VGG-16 作为感知损失的预训练网络，感知损失通过 VGG-16 输出的特征图进行计算，其表达式如式(3-19)所示：

$$L_p=\sum_{i=1}^{3}\frac{1}{C_jH_jW_j}\left\|\varphi_j(J)-\varphi_j(J_{dehaze})\right\| \tag{3-19}$$

式中，φ_j表示 VGG-16网络中第 j 层的特征图，尺寸大小为$C_j\times H_j\times W_j$，J 表示清晰图像，J_{dehaze}表示经过本章网络恢复后的无雾图像。

3.3 实验验证与结果分析

在本节中，详细描述了实验中所使用的数据集和相关实验细节，将本章去雾技术与其他先进的去雾技术进行了比较，并对本章技术进行消融研究。

3.3.1 数据集选择和相关实验细节

本章去雾技术主要在RESIDE数据集上进行实验。该数据集由五个子集组成，包括两个训练集和三个测试集。对于训练，选择OTS作为主要训练集，其中包含8970张清晰的室外图像，每张图像与35张雾化图像组合，共计313,950张合成雾天图像。为进一步验证真实场景中的去雾性能，还选择真实世界NHHAZE数据集进行训练。对于测试，选择SOTS-outdoor用于合成雾天图像测试，NHHAZE和RTT数据集用于真实雾天图像测试。

本章技术在训练和测试阶段都采用了带有NVIDIA RTX8000 GPU的Pytorch框架。提出的网络在RGB通道中训练，为增强训练数据集，随机将数据集图像进行90、180、270度旋转和水平翻转。当本章去雾网络进行训练时，利用Adam优化器更新网络参数，通过预处理将图像大小调整为240×240，批处理大小设置为4。整个网络在OTS训练集和NHHAZE训练集上进行5×10^5步训练。

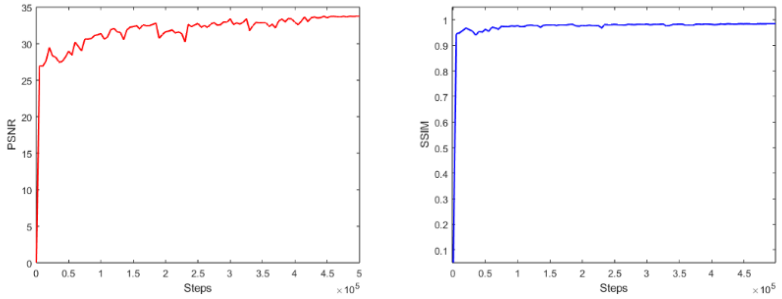
初始学习率设为 0.0001，采用余弦退火策略将学习率从初始值调整到 0。具体来说，假设总步长为τ，初始学习率为η，学习率η_s将通过以下策略自适应更新。

$$\eta_s=\frac{1}{2}\left(1+\cos\left(\frac{\tau_s\pi}{\tau}\right)\right)\eta \tag{3-20}$$

通过每训练5000步获取一次PSNR和SSIM值来绘制学习曲线，如图3.14所示，横坐标表示训练步数，纵坐标分别表示对应的PSNR和SSIM值。当训练5×10^5步时，PSNR和SSIM值趋于平稳，停止学习。当训练4.45×10^5步时，PSNR和SSIM值达到最

中国知网 https://www.cnki.net

大值，选择此时的模型作为最佳训练模型。



(a) (b)

图 3.14 网络训练学习曲线

(a) PSNR 学习曲线 (b) SSIM 学习曲线

3.3.2 定量比较

将本章提出的去雾技术与以下先进的去雾技术进行比较：DCP[31]、CAP[35]、AODNet[42]、DehazeNet[40]、GridDehazeNet[48]和FFANet[47]。 利 用PSNR、SSIM及LPIPS三个常用的图像去雾评价指标进行定量评价。

不同去雾技术在 SOTS-outdoor 数据集上的定量结果如表 3.1 所示，加粗字体表示最佳结果。

表 3.1 在 SOTS-outdoor 数据集上的定量结果

去雾技术	SOTS-outdoor		
	PSNR	SSIM	LPIPS
DCP	21.81	0.858	0.052
CAP	22.09	0.882	0.042
AODNet	20.29	0.876	0.088
DehazeNet	22.46	0.851	0.039
GridDehazeNet	30.86	0.981	0.005
FFANet	33.38	0.980	0.004
本章技术	**33.74**	**0.984**	**0.004**

从表 3.1 中可以发现，DCP、CAP、AODNet、DehazeNet 的结果较差，它们的 PSNR 值都小于 30.00dB，SSIM 值都不超过 0.900，LPIPS 值远大于 0.030。GridDehazeNet 和 FFANet 的结果相对较好，但相比于本章去雾技术的 PSNR 和 SSIM 值仍略有不足，本章去雾技术实现了最佳的去雾性能，在 SOTS-outdoor 上的 PSNR 和 SSIM 分别为 33.74 dB 和 0.984，LPIPS 值仅为 0.004。定量地证明了所提技术在合成有雾图像上的去雾优势，取得了较好的去雾结果。

为进一步定量地证明本章去雾技术的优良性能，随机选取 NHHAZE 数据集中的四幅真实雾天图像进行定量评估，如表 3.2 所示，加粗字体表示最佳结果，下划线字体表示次佳结果。与其它去雾技术相比，本章去雾技术获得了最佳的 PSNR、SSIM 和 LPIPS 值。如在表 3.2 的图像 1 中，与去雾性能次佳的 FFANet 相比，PSNR 值提升

中国知网 https://www.cnki.net

2.49dB，SSIM 值提升 0.003，LPIPS 值降低 0.003。

表3.2 在NHHAZE数据集上的定量结果

去雾技术	指标	图像1	图像2	图像3	图像4
DCP	PSNR	13.36	11.83	11.69	13.84
	SSIM	0.483	0.408	0.497	0.535
	LPIPS	0.386	0.492	0.460	0.345
CAP	PSNR	13.52	12.62	12.10	14.15
	SSIM	0.488	0.406	0.499	0.530
	LPIPS	0.396	0.498	0.448	0.342
DehazeNet	PSNR	12.48	11.16	10.77	12.94
	SSIM	0.471	0.372	0.488	0.523
	LPIPS	0.410	0.534	0.477	0.357
AODNet	PSNR	13.38	14.56	11.50	14.27
	SSIM	0.458	0.425	0.461	0.456
	LPIPS	0.439	0.537	0.475	0.434
GridDehazeNet	PSNR	12.77	12.13	10.42	13.65
	SSIM	0.485	0.400	0.504	0.541
	LPIPS	0.413	0.497	0.446	0.385
FFANet	PSNR	18.65	18.86	17.00	19.85
	SSIM	0.660	0.610	0.662	0.725
	LPIPS	0.217	0.288	0.264	0.167
本章技术	PSNR	**21.14**	**20.88**	**18.09**	**22.34**
	SSIM	**0.663**	**0.626**	**0.665**	**0.728**
	LPIPS	**0.213**	**0.282**	**0.260**	**0.159**

3.3.3 定性比较

每种去雾技术在SOTS-outdoor测试集上的定性结果如图3.15所示，与地面真实图像相比，CAP、DCP和DehazNet存在明显的去雾过度现象，如它们恢复的第一行图像中间的路面。AODNet存在颜色偏移、去雾图像较为模糊的情况，如它恢复的第四行图像表现为淡粉色，第五行图像整体显的模糊。GridDehazeNet和FFANet取得的结果更加接近地面真实图像，然而仔细观察可以发现，GridDehazeNet和FFANet的去雾结果呈现出细微的雾残留，比地面真实图像显的更白，如它们恢复的第一行图像和第二行图像的地面。本章去雾技术能够恢复图像中更多的细节信息，去雾程度合适，其结果与地面真实图像更相近。

中国知网 https://www.cnki.net



(a) (b) (c) (d) (e) (f) (g) (h) (i)

图 3.15 在 SOTS-outdoor 数据集上的定性结果

(a) 雾图 (b) DCP (c) CAP (d) DehazeNet (e) AODNet (f) GridDehazeNet (g) FFANet (h) 本章技术 (i)地面真实

为进一步验证本章去雾技术在真实有雾图像上的去雾性能，分别在NHHAZE、RTTS数据集以及在互联网上收集的真实世界有雾图像进行了测试。每种去雾技术在NHHAZE数据集上的定性结果如图3.16所示。



(a) (b) (c) (d) (e) (f) (g) (h) (i)

图 3.16 在 NHHAZE 数据集上的定性结果

(a) 雾图 (b) DCP (c) CAP (d) DehazeNet (e) AODNet (f) GridDehazeNet (g) FFANet (h) 本章技术 (i) 地面真实

通过图3.16可以发现，DCP、CAP、DehazeNet和AODNet去雾效果不明显，残留了大量的雾，难以获取图像中有价值的信息。GridDehazeNet带有明显的颜色失真现象。FFANet和本章去雾技术都取得了更好的去雾效果。然而与本章技术相比，FFANet伴随更多的雾遗留，如它恢复的第一行图像树木的左上角，在局部区域明显遗留大量雾。本章去雾技术效果明显，在局部和整体复原效果方面优于其它去雾技术。

每种去雾技术在RTTS数据集上的定性结果如图3.17所示，由于RTTS数据集没有相应的地面真实图像，因此本章未对该数据集进行定量分析，仅进行了定性比较。

中国知网 https://www.cnki.net

DCP，CAP和DehazeNet明显的去雾过度，图像整体偏暗，如它们恢复的第三行图像的路面。AODNet发生了偏色现象，如它恢复的第四行图像表现为淡红色。GridDehazeNet的去雾效果不均匀，在局部区域含有大量阴影，如它恢复的第四行图像的上方。FFANet仍旧残留了大量的雾，去雾效果不明显，如它恢复的第二行图像的草坪。本章去雾技术具有更好的色彩保真度，在局部和整体都有较好的去雾效果，与真实情景更为相似。



(a) (b) (c) (d) (e) (f) (g) (h)

图 3.17 在 RTTS 数据集上的定性结果

(a) 雾图 (b) DCP (c) CAP (d) DehazeNet (e) AODNet (f) GridDehazeNet (g) FFANet (h) 本章技术

每种去雾技术在真实世界有雾图像中的定性结果如图3.18所示。



(a) (b) (c) (d) (e) (f) (g) (h)

图 3.18 在真实世界图像上的定性结果

(a) 雾图 (b) DCP (c) CAP (d) DehazeNet (e) AODNet (f) GridDehazeNet (g) FFANet (h) 本章技术

通过图3.18可以发现，DCP和CAP存在严重的去雾过度现象，如它们恢复的第三行图像的礁石。DehazeNet和AODNet色彩失真较为严重，如它们恢复的第一行图像，DehazeNet整体表现为淡绿色，AODNet表现为浅粉色。GridDehazeNet在局部去雾方面效果一般，丢失了图像的纹理信息，如它恢复的第一行图像的右上角和第二行图像中的树。FFANet的去雾效果不明显，如它恢复的第三行图像与原始雾图相比几乎没有变化。本章去雾技术能够更好地保留图像的色彩和纹理信息，在局部细节

中国知网 https://www.cnki.net

恢复方面也较为出色。

3.3.4 参数量及计算量比较

每种神经网络模型的参数量和计算量如表 3.3 所示。在深度学习网络模型中，浮点计算量（Floating Point operations，Flops）一般可以衡量一个网络模型的时间复杂度，其表示模型完成一次前向传播所需的计算量。模型的运行速度和硬件需求均受到 FLOPs 的影响。参数量（Parameters，Params）一般用来衡量模型的空间复杂度，其是指模型中所有学习的权重和偏置的总数。网络模型的内存占用和存储需求均受到参数量的影响。在表 3.3 中，本章去雾技术的 Flops 值较大，说明本章网络对计算机的硬件有一定的需求。本章技术的参数量低于 FFANet，这表明本章网络模型所需内存与其他复杂去雾网络相比相对较少。

表 3.3 每种网络模型的参数量及计算量

去雾技术	Params/$\times 10^6$	Flops/$\times 10^9$
DCP	—	—
CAP	—	—
AODNet	0.01	0.10
DehazeNet	0.01	0.45
GridDehazeNet	0.96	452.01
FFANet	4.46	505.43
本章技术	3.07	679.31

3.4 消融研究

为验证本章所提出的MAE和AFE模块的有效性，在SOTS-outdoor数据集上进行一系列消融实验来对本章去雾网络不同模块的性能进行验证。在消融研究中，将图像大小裁剪为96×96作为输入，训练2×10^5步，其它配置与本章的实验细节相同。表3.4显示了不同模块在SOTS-outdoor数据集上的定量评估结果，其中粗体数字表示最佳结果。

表 3.4 在 SOTS-outdoor 数据集的消融研究定量结果

去雾技术	PSNR	SSIM	LPIPS
Baseline	26.71	0.951	0.026
Baseline+ESP	28.97	0.966	0.024
Baseline+CEM	29.19	0.969	0.024
Baseline+ESP+CEM	**29.50**	**0.971**	**0.023**

首先，构建一个没有ESP和CEM的基线网络，在表3.4中表示为“Baseline”。然后，将ESP和CEM分别添加到Baseline网络中，在表3.4中分别表示为“Baseline+ESP”和“Baseline+CEM”。最后，将ESP和CEM同时添加到Baseline网络中，此时为本章去雾网络，在表3.4中表示为“Baseline+ESP+CEM”。

中国知网 https://www.cnki.net

根据表3.4在SOTS-outdoor数据集上的消融研究结果，可以得出以下结论：

(1) 当移除本章网络中的 ESP 模块和 CEM 模块，即为 Baseline 网络时，获取的 PSNR、SSIM 和 LPIPS 三项定量指标结果最差，表明该网络模型去雾性能一般。

(2) 当将 ESP 模块融入 Baseline 网络中，即为“Baseline+ESP”网络时，与 Baseline 网络的指标结果相比，PSNR 提升了 2.26 dB，SSIM 提升 0.015，LPIPS 降低 0.002，表明 ESP 模块的引入能够显著提升网络的去雾能力。

(3) 当将 CEM 融入至 Baseline 网络时，此时网络中包含本章提出的 AFE 模块。与 Baseline 网络去雾结果相比，PSNR 提升 2.48 dB，SSIM 提升 0.018，LPIPS 降低 0.002，证明了本章提出的 AFE 模块提升网络去雾性能的有效性。

(4) 当将 ESP 和 CEM 同时融入 Baseline 网络中时，此时包含本章提出的 MAE 模块，网络模型为本章提出的去雾技术。在表 3.4 中 PSNR 和 SSIM 值最高，LPIPS 值最低，这一结果证明了本章提出的 MAE 模块能够进一步提升网络的去雾能力，本章提出的去雾技术具有很好的去雾性能。

3.5 本章小结

本章提出了一种端到端的多尺度注意力特征增强图像去雾网络，能够很好地保留图像颜色、纹理等信息，有效的去除自然场景图像中的雾。该网络的主要组成结构是去雾融合块，其内包含了提出的多尺度注意力增强模块和注意力特征增强模块。注意力特征增强模块能够自适应的对雾信息及高频信息进行重点关注，增强上下文信息，减少冗余信息。多尺度注意力增强模块结合了高效空间金字塔模块和注意力特征增强模块，它们的结合使用使得该模块不但具有注意力特征增强模块的全部优势，还能够进一步提取多尺度信息，减少恢复的图像产生伪影。在合成雾天数据集、真实雾天数据集以及现实世界雾天图像上对本章提出的去雾技术进行了定量和定性评估。实验结果表明本章提出的去雾技术实现了最佳去雾效果，很好地保留了图像颜色信息，恢复的图像更加自然、真实。通过消融研究，验证了本章引入和提出的不同模块的有效性，这些模块能够有效提升网络的去雾能力。

中国知网 https://www.cnki.net

第 4 章 基于细节增强的遥感图像去雾技术研究

在第 3 章中，主要复原自然场景情况下的有雾图像。相比于自然场景去雾，遥感图像因其场景复杂性更高，获取难度更大，导致去除遥感图像的雾具有更大的挑战，因此本章提出了一种用于移除遥感图像中存在的雾的技术。在本章中，首先阐述了基于细节增强的遥感图像去雾技术提出的背景。其次对网络架构及其组件进行了详细的说明，包括网络的总体结构，设计的多尺度细节增强单元、阶梯式注意力细节增强单元和细节增强块，引入的 SK Fusion 和软重建技术。然后通过实验验证了提出的基于细节增强的遥感图像去雾网络的有效性，实验包括在合成有雾遥感图像数据集和真实有雾遥感图像数据的定量和定性实验，以及消融实验。最后对本章阐述的主要内容进行了总结。

4.1 引言

随着空间对地观测技术的快速发展，地球表面信息的获取方式发生了革命性的变化。卫星等太空探测器获取了大量具有高空间和光谱分辨率的遥感图像[133]。遥感图像包含丰富的地表信息，广泛地应用于地质勘探[134,135]、城市规划[136,137]、气象观测[138,139]等各个领域。然而，当光学遥感成像传感器捕捉地球表面穿过大气的反射光时，不可避免地会受到雾、雨、云等大气粒子的干扰。这些粒子吸收和散射反射光，导致遥感图像出现纹理模糊、对比度低、颜色失真等问题[140]。遥感图像质量的下降给后续的图像分析和理解等计算机视觉任务带来了巨大的障碍[141]。因此去除遥感图像中的雾、提高遥感图像质量具有重要的研究意义和应用价值。

近年来，图像去雾技术得到了广泛的研究，大量的去雾技术被提出。目前，这些去雾技术可以分为两类，分别是基于先验的去雾技术和基于学习的去雾技术。基于先验的去雾技术根据先验假设估计透射图和全局大气光，然后利用大气散射模型恢复清晰图像。这些技术取得了良好的去雾效果。然而，在现实世界有雾环境中，先验知识的最优选择仍不清楚。这些先验与图像统计数据的符合程度以及它们如何影响去雾性能仍然未知。随着深度学习的快速发展，基于学习的去雾技术得到了广泛研究。虽然现有的基于学习的技术取得了显著成功，但其中大多数都是从自然场景图像中去雾[142,143]。与地面拍摄的自然场景图像相比，遥感图像通常规模更大、场景更复杂。遥感图像的雾强度分布更加多变且不规则，这为去除遥感图像中的雾带来了更大的挑战。因此，现有的自然场景去雾技术可能不适用于复原模糊的遥感图像，复原遥感图像的细节信息损失较为严重[144]。

因此，本章提出了一种用于遥感图像的细节增强去雾网络（Detail-Enhanced

中国知网 https://www.cnki.net

Dehazing Network，DEDNet）。该网络以 U-Net 为骨架，包含多个细节增强块（Detail Enhancement Block，DEB）。DEB 是一个类似于 Transformer 架构的块，主要由设计的多尺度细节增强单元（Multi-Scale Detail Enhancement Unit，MSDEU）和阶梯式注意力细节增强单元（Stepped Attention Detail Enhancement Unit，SADEU）两部分组成。本章利用设计的 MSDEU 替换 Transformer 中的多头自注意机制，利用设计的 SADEU 替换 Transformer 中的前馈网络。MSDEU 不仅可以提取输入雾图的不同尺度特征，而且具有较大的感受野。在 MSDEU 中，通过扩张率为 1、4、9 和 16 的扩张卷积来整合全局特征和细节特征，利用简单的局部残差来增强图像中的高频细节信息和边缘信息。在 SADEU 中，通过通道注意力（Channel Attention，CA）从原始特征中提取全局共享信息，利用像素注意力（Pixel Attention，PA）从原始特征中提取与位置相关的局部信息。受 FFANet 中提出的像素注意力机制的启发，在 SADEU 中进一步设计了深层像素注意力（Deep Pixel Attention，DPA）和浅层像素注意力（Shallow Pixel Attention，SPA）。它们与像素注意力并行连接，实现了从深层、中层和浅层三个不同层级关注雾和高频信息。此外，设计了一种新颖的并行归一化模块(Parallel Normalization Module，PNM)，将它集成到网络架构中有助于增强对外观变化的鲁棒性，同时保留与内容相关的信息。本章将 PNM 分别嵌入到 MSDEU 和 SADEU 中，以提高 DEDNet 的泛化能力和鲁棒性。总而言之，本章主要贡献如下：

(1) 设计了一种新颖的多尺度细节增强单元，它能够提取输入图像的多尺度特征，融合全局特征和细节特征。其内的并行扩张卷积具有较大的感受野和长建模能力，使网络能够在较宽的空间尺度捕获上下文信息，有效增强图像细节。

(2) 设计了一种新颖的阶梯式注意力细节增强单元，它能够自适应地从深、中、浅三个层级关注图像的高频信息，灵活处理雾分布不均匀的图像，更适合用于遥感图像去雾。

(3) 设计了一种新颖的并行归一化模块，能够同时学习与内容相关且不受外观变化影响的特征，有效提高网络的泛化能力和鲁棒性。

(4) 设计了一种新颖的基于细节增强的遥感图像去雾网络，将 MSDEU 和 SADEU 嵌入到 DEDNet 中，以处理遥感场景中有雾图像移除问题。在具有挑战性的遥感图像数据集（SateHaze1k 和 HRSD）上进行实验，本章遥感图像去雾技术优于现有先进的去雾技术，能够更有效地去除遥感图像中的雾，更好地保留图像的细节信息。

4.2 网络架构设计

本章针对遥感有雾图像提出的 DEDNet 网络架构如图 4.1 所示。DEDNet 是一个改进的 5 阶段 U-Net 型网络，本章通过设计的 DEB 替换 U-Net 中的卷积块。DEB 由 MSDEU 和 SADEU 组成，用于自适应地提取多尺度、边缘和其它精细信息。此外，

中国知网 https://www.cnki.net

先前的研究[53]提出了 SK Fusion 和软重建（Soft Recon.），它们展示了更好的特征融合能力和对雾信息的软约束能力，因此利用 SK Fusion 融合跳跃分支和主分支，并使用软重建进行图像重建以提高 DEDNet 的去雾性能。

DEDNet 的输入是尺寸为 $H\times W$ 的遥感有雾 RGB 图像 I，其首先经过一个3×3卷积提取浅层特征信息并将其通道数转换为 C。然后特征信息流经五阶段的 DEB 结构，DEB 用来提取多尺度信息，增强细节信息，提升对有用信息的关注。在每两个阶段的 DEB 之间插入下采样（Down-sampling）和上采样（Up-sampling），下采样采用步长为 2 的3×3卷积，将特征图尺寸逐步从 $H\times W$ 降低至 $\frac{H}{4}\times\frac{W}{4}$，通道数从 C 提升至 $4C$，上采样采用逐点卷积和 PixelShuffle 串行连接的方式，将尺寸从 $\frac{H}{4}\times\frac{W}{4}$ 逐步恢复至 $H\times W$，通道数从 $4C$ 逐步恢复至 C。为进一步保留浅层细节信息，在每次上采样后采用 SK Fusion 融合浅层和深层信息。最后通过一个3×3卷积重建图像，并使用 Soft Recon.技术进行微调，从而输出清晰的无雾遥感图像 J。其中，在图 4.1 中的 $\times N_i$ 表示在每个阶段顺次连接 DEB 的数量，$i=(1,2,3,4,5)$。下面分别对 DEDNet 中的主要组件 DEB、SK Fusion 和软重建进行介绍。

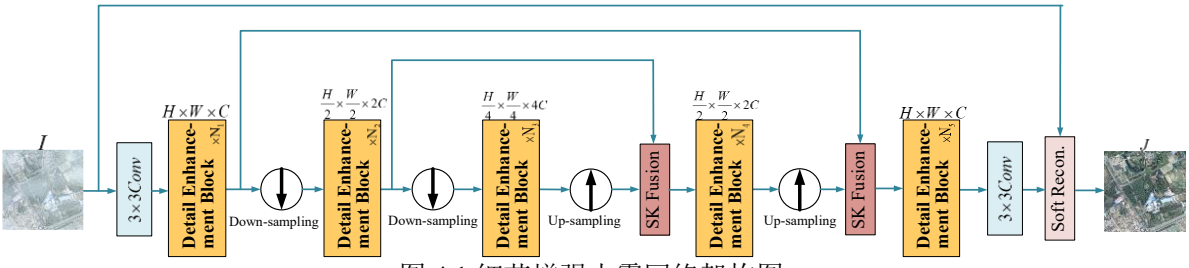


图 4.1 细节增强去雾网络架构图

4.2.1 细节增强块

DEB 的结构如图 4.2 所示，它由多 MSDEU 和 SADEU 组成。MSDEU 可以获取图像的多尺度信息，捕获不同区域的雾，恢复图像的纹理细节。SADEU 能够有效的处理复杂多变，雾分布不规则的遥感雾图，同时关注原特征的全局共享信息和与位置相关的局部信息，突出图像的高频、边缘等细节信息。此外，在 DEB 中嵌入了 PNM。这一集成方法允许 DEB 学习不受外观变化影响的特征，同时保留与内容相关的特征。下面分别对 MSDEU、PNM 和 SADEU 进行介绍。

(1) 多尺度细节增强单元

MSDEU 的结构如图 4.2(a)所示，它能够获取输入特征的多尺度信息和较大的感受野，增强细节信息。首先，令 F^* 为 MSDEU 的原始输入特征，利用 PNM 对其进行归一化。

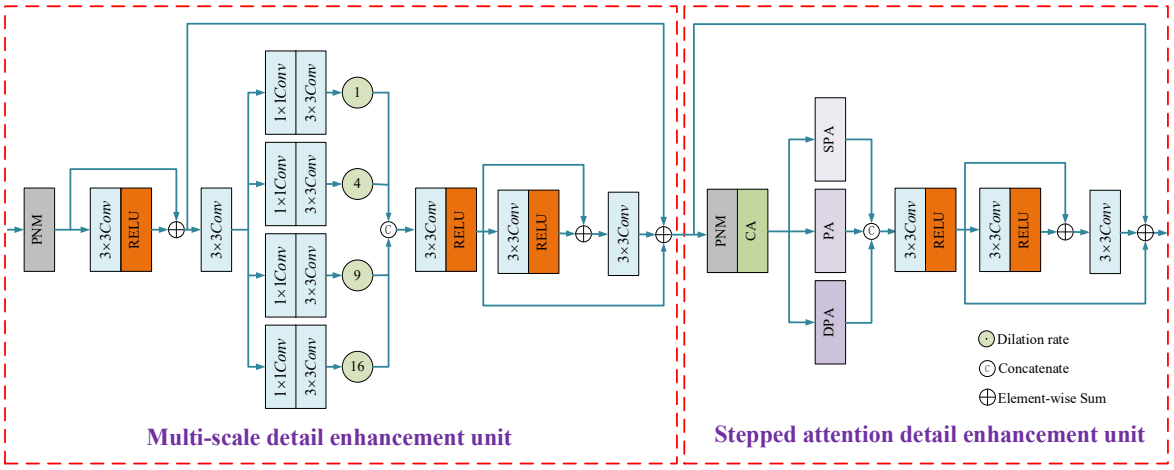
中国知网 https://www.cnki.net

$$\overset{\vee}{F} = \mathrm{PNM}\left(F^{*}\right) \tag{4-1}$$

PNM 结合了实例归一化和批归一化，可以提高网络的泛化能力和鲁棒性，防止过拟合。然后，使用局部残差（Local residual，LR）初步增强细节信息的提取。

$$F_1 = \overset{\vee}{F} + \sigma\left(Conv3\left(\overset{\vee}{F}\right)\right) \tag{4-2}$$

其中，σ 为 RELU 非线性函数，$Conv3$ 为 3×3 卷积。



(a) (b)

图 4.2 细节增强块结构图

(a) 多尺度细节增强单元 (b) 阶梯式注意力细节增强单元

受到 Chalavadi 等人[145]提出的分层扩张网络（Hierarchical Dilated Network，HDN）的启发，本章将 1×1 卷积与并行扩张卷积连接起来，以学习不同尺度的信息。小扩张卷积专注于恢复纹理细节信息，而大扩张卷积具有较大的感受野和远距离建模信息的能力。它更注重全局特征和大片模糊区域。

$$F_2 = Concat\left(Conv_i\left(Conv1\left(Conv3\left(F_1\right)\right)\right)\right) \tag{4-3}$$

其中，$Conv_i$ 是扩张率（Dilation rate）为 $i=(1,4,9,16)$ 的 3×3 卷积，$Conv1$ 为逐点卷积，$Concat$ 表示按通道连接（Concatenate）。此时在通道维度上连接了多尺度特征，F_2 的通道数是 F_1 的四倍。因此，利用 3×3 卷积来融合连接的多尺度信息，将通道数转换为与 F_1 相同数量。RELU 函数用于防止梯度消失。

$$F_3 = \sigma\left(Conv3\left(F_2\right)\right) \tag{4-4}$$

为增强融合后具有多尺度特征的细节信息，再次使用局部残差来捕捉细节特征，经过 3×3 卷积后与 F_1 和 F_3 求和，以此方式实现多尺度特征融合前后的细节信息的二次增强。

$$F_4 = Conv3\left(F_3 + \sigma\left(Conv3\left(F_3\right)\right)\right) + F_3 + F_1 \tag{4-5}$$

中国知网 https://www.cnki.net

(2) 并行归一化模块

受 Wang 等人[146]的启发，本章设计了 PNM，其结构如图 4.3 所示。PNM 结合了实例归一化和批归一化。实例归一化允许网络学习不受外观变化影响的特征，批归一化则有助于保留与内容相关的特征。PNM 结合了两种技术的优点，以增强网络的去雾性能。在 PNM 中，首先对输入特征 F_{in} 进行处理以生成中间特征 F_{mid}。其次，PNM 将 F_{mid} 的通道分成两等份，其中一半通道形成特征 F_{mid1}，另一半通道形成特征 F_{mid2}。在 F_{mid1} 分支中，使用实例归一化（Instance Normalization，IN）和 SELU 非线性函数，而在 F_{mid2} 分支中，应用可学习参数的批归一化（Batch Normalization，BN）和 SELU 非线性函数。SELU 函数可以通过调整均值和方差实现内部归一化，有效加快网络的收敛速度。然后将两个分支得到的特征进行融合，这样既可以保留和内容相关的特征，又可以学习到不受外观变化影响的特征。最后使用一个 3×3 卷积整合特征并通过跳跃连接来防止梯度消失，从而得到 PNM 的输出特征 F_{out}。

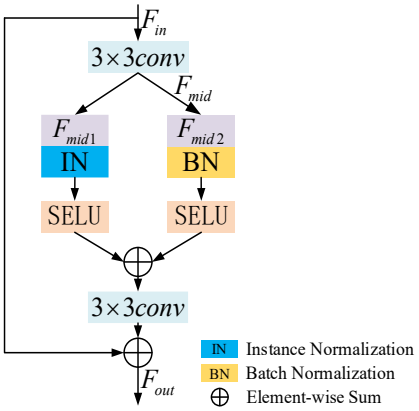


图 4.3 PNM 结构图

(3) 阶梯式注意力细节增强单元

SADEU 结构如图 4.2(b)所示，其主要由 PNM、CA、不同深度的像素注意力和局部残差组成，具有关注全局信息，自适应的提取雾信息、增强细节信息的能力。令 $\overline{F}$ 为 SADEU 的输入特征，利用 PNM 对其进行规范化，即 $\overset{\vee}{F}=\mathrm{PNM}\left(\overline{F}\right)$。CA 可以有效地提取全局信息，为不同的通道特征分配不同的权重。本章使用 FFA 中的 CA 来重新分配输入通道特征 $\overset{\vee}{F}$：

$$F_{S1}=\mathrm{CA}\left(\overset{\vee}{F}\right) \tag{4-6}$$

PA 能够自适应地提取分布不均匀的雾，有效聚焦与位置相关的局部特征，适用于处理雾分布不均匀的遥感图像，其结构如图 4.4(b)所示。设计的 SPA 和 DPA 结构

中国知网 https://www.cnki.net

分别如图 4.4(a)和(c)所示。

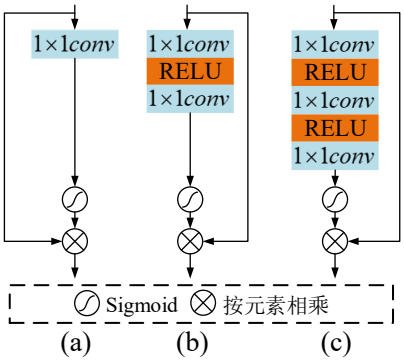


图 4.4 阶梯式融合像素注意力结构图
(a) SPA (b) PA (c) DPA

设 F_{S1} 的特征图形状为 $H\times W\times C$。在 SPA 中，特征图的形状经过1×1卷积后变为 $H\times W\times 1$。在 PA 中，特征图的形状经过第一个1×1卷积变为 $H\times W\times \frac{C}{8}$，经过第二个1×1卷积后特征图形状变为 $H\times W\times 1$。在 DPA 中，经过第一个1×1卷积后的特征图形状为 $H\times W\times \frac{C}{4}$，经过第二个1×1卷积后的特征图形状为 $H\times W\times \frac{C}{16}$，经过第三个1×1卷积后的特征图形状为 $H\times W\times 1$。SPA、PA 和 DPA 的执行过程分别如式(4-7)、(4-8)和(4-9)所示：

$$\mathrm{SPA}=F_{S1}*\delta\left(conv1\left(F_{S1}\right)\right) \tag{4-7}$$

$$\mathrm{PA}=F_{S1}*\delta\left(conv1\left(\sigma\left(conv1\left(F_{S1}\right)\right)\right)\right) \tag{4-8}$$

$$\mathrm{DPA}=F_{S1}*\delta\left(conv\left(\sigma\left(conv\left(\sigma\left(conv\left(F_{S1}\right)\right)\right)\right)\right)\right) \tag{4-9}$$

其中，δ 是 Sigmoid 函数，用于分配权重。由于 SPA、PA 和 DPA 像一个阶梯，并将它们在通道方向上连接，因此本章将它们的整体命名为阶梯式融合像素注意力（Stepped Fusion Pixel Attention，SFPA）。SPA、PA 和 DPA 能够分别从深、中、浅三个层级关注雾信息分布，将其进行融合可以更有效地提取雾信息。

$$\mathrm{PA}_{\mathrm{Fusion}}=Concat\left(\mathrm{SPA},\mathrm{PA},\mathrm{DPA}\right) \tag{4-10}$$

此时 $\mathrm{PA}_{\mathrm{Fusion}}$ 的形状为 $H\times W\times 3C$，因此使用一个3×3卷积融合连接后的不同像素注意力关注的雾信息，并将通道数转换为 C，RELU 函数用来防止梯度消失。

$$F_{S2}=\sigma\left(Conv3\left(\mathrm{PA}_{\mathrm{Fusion}}\right)\right) \tag{4-11}$$

最后使用一个局部残差来增强像素关注后的雾信息，然后将其与一个3×3卷积的输出和输入特征 $\overline{F}$ 相加，实现对有雾区域的重点关注和细节信息的保留。

$$F_{S3}=Conv3\left(\sigma\left(Conv3\left(F_{S2}\right)\right)+F_{S2}\right)+F_{S2}+\overline{F} \tag{4-12}$$

中国知网 https://www.cnki.net

4.2.2 SK Fusion 和软重建技术

Song 等人[53]设计了一个通过通道注意力来融合多个分支的 SK Fusion 技术。SK Fusion 技术实现过程如下：令两个需被融合的输入特征图分别为 x_1 和 x_2，利用线性层 $f(\cdot)$ 将 x_1 投影到 $\hat{x}_1$，通过全局平均池化 $GAP(\cdot)$、多层感知机（Multilayer Perceptron，MLP）$f_{mlp}(\cdot)$、Softmax 和拆分（Split）操作来获取融合权重。其中 MLP 依次由 Linear-ReLU-Linear 的连接方式构成。融合权重获取方式如式(4-13)所示：

$$\{w_1, w_2\} = \text{Split}\left(\text{Softmax}\left(f_{mlp}\left(GAP\left(\hat{x}_1 + x_2\right)\right)\right)\right) \tag{4-13}$$

得到权重 $\{w_1, w_2\}$ 后，通过式(4-14)将 $\hat{x}_1$，x_2 与额外的短残差进行融合。

$$y = w_1\hat{x}_1 + w_2x_2 + x_2 \tag{4-14}$$

当前图像去雾网络一般直接预测重建图像 $J(x)$ 或全局残差 $R(x) = J(x) - I(x)$ 获得重建图像。Song 等人分析退化模型是一个近似值，因此在没有强约束的前提下引入先验将有益于去除图像中的雾。因此，他们将大气散射模型重写为式(4-15)：

$$J(x) = K(x)I(x) + B(x) + I(x) \tag{4-15}$$

其中，$K(x) = 1/t(x) - 1$，$B(x) = -(1/t(x) - 1)A$。驱动网络预测 $\text{O} \in R^{H\times W\times 4}$，将 O 拆分为 $K \in R^{H\times W\times 1}$ 和 $B \in R^{H\times W\times 3}$。因此，网络能够对 $K(x)$ 和 $B(x)$ 之间的关系进行软约束。这种弱先验允许网络预测全局残差，即 $K(x) = 0$ 时，$B(x) = R(x)$。为简便起见，将式(4-15)称为软重建。

4.2.3 损失函数

现如今多数的去雾网络都利用多种损失函数来优化网络，如同时使用 MSE 损失和感知损失等。然而在一些去雾技术中，简单的 L1 损失在图像恢复任务中取得了极佳的性能。因此在本章遥感图像去雾网络训练过程中，仅使用 L1 损失来规范 DEDNet 在训练过程中的学习方向，修正图像之间像素差异。

$$\text{L1} = \|J - GT\|_1 \tag{4-16}$$

其中，J 是经 DEDNet 恢复的无雾遥感图像，GT 是地面真实遥感图像。

4.3 实验验证与结果分析

在本节中，详细描述了实验中所使用的数据集和相关实验细节，将本节去雾技术与其它先进的去雾技术进行比较，并对本章去雾技术进行消融研究。

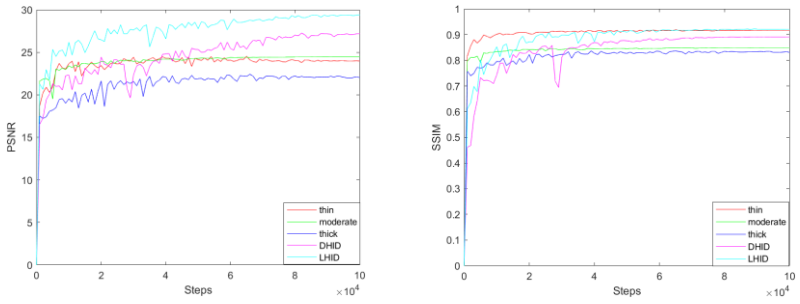
中国知网 https://www.cnki.net

4.3.1 数据集选择和相关实验细节

本章选择两个公开的合成有雾遥感数据集 SateHaze1k[119]和 HRSD 遥感数据集[57]评估本章提出的遥感图像去雾技术。SateHaze1k 数据集由三个具有不同雾程度的子数据集组成：SateHaze1k-thin、SateHaze1k-moderate 和 SateHaze1k-thick。在下文分别用 thin、moderate 和 thick 来表示 SateHaze1k-thin、SateHaze1k-moderate 和 SateHaze1k-thick 三个子数据集。thin、moderate 和 thick 分别由受薄雾、中度雾和浓雾遮挡的遥感图像组成。在每个子数据集中，选择 320 张 RGB 图像作为训练集，45 张 RGB 图像作为测试集。HRSD 由两个子数据集组成：轻度雾图像数据集（LHID）和密集雾图像数据集（DHID）。选取 LHID 数据集中的 30517 张图像作为训练集，500 张图像作为测试集。DHID 包含 14990 张图像，其中 14490 张图像作为训练集，500 张图像作为测试集。

本章通过带有 NVIDIA RTX8000 GPU 的 Pytorch 框架来训练和测试本章遥感图像去雾技术。通过随机旋转 90，180，270 度和水平反转的方式来增强训练数据集。本章网络的输入是由被裁剪为 240×240 大小的 RGB 遥感图像组成。在 DEB 中，设置 $[N_1,N_2,N_3,N_4,N_5]=[2,2,4,2,2]$，对应的嵌入通道数为 $[32,64,128,64,32]$。采用 Adam 优化器（$\beta_1=0.9,\beta_2=0.999$）更新网络参数，在每一个子数据集上对本章提出的 DEDNet 进行 1.0×10^5 步的训练，批大小设置为 4。初始学习率设置为 1.0×10^{-4}，利用余弦退火策略逐渐将初始学习率降低到 0。

图 4.5 显示了本章网络在五个子数据集训练过程中通过每 1000 步获得的 PSNR 和 SSIM 值而绘制的学习曲线。图 4.5(a)表示 PSNR 随步长的变化过程，图 4.5(b)表示 SSIM 随步长的变化过程。从图 4.5 中可以发现，本章技术在 LHID 数据集上实现了最好的学习性能，而在 thick 数据集上实现了最差的学习性能。这是由于 thick 数据集图像中存在大量的雾，使得去雾更为困难。而 LHID 数据集中图像的雾度较低，因此去雾相对容易。总体而言，本章去雾技术在训练过程中表现出稳定的性能。



(a) (b)

图 4.5 网络训练学习曲线

(a) PSNR 学习曲线 (b) SSIM 学习曲线

中国知网 https://www.cnki.net

4.3.2 定量比较

将本章提出的去雾技术与以下七种先进的去雾技术进行比较：DCP[31]、AODNet[42]、PFFNet[45]、FCTFNet[56]、GridDehazeNet[48]、SCANet[55]和FFANet[47]。评价指标与第3章相同，通过PSNR、SSIM和LPIPS三个常用的图像去雾评价指标进行定量评价。

在 SateHaze1k 数据集上的定量评估结果如表 4.1 所示，其中粗体数字表示最佳结果，下划线数字表示次佳结果，斜体数字表示最差结果。本节提供了具有不同雾程度数据集的 PSNR、SSIM 和 LPIPS 值及其平均值（average）。

表 4.1 在 SateHaze1k 数据集上的定量结果

去雾技术	指标	thin	moderate	thick	average
DCP	PSNR	*15.99*	*14.75*	*10.99*	*13.91*
	SSIM	0.835	0.821	0.617	0.758
	LPIPS	0.10	0.13	0.27	0.17
AODNet	PSNR	18.47	17.63	15.75	17.28
	SSIM	0.863	0.855	0.742	0.820
	LPIPS	0.08	0.12	0.23	0.14
FCTFNet	PSNR	19.71	23.10	18.56	20.46
	SSIM	0.875	0.926	0.800	0.867
	LPIPS	0.10	0.06	0.20	0.12
PFFNet	PSNR	16.01	18.59	16.06	16.89
	SSIM	*0.821*	*0.688*	*0.575*	*0.695*
	LPIPS	*0.17*	*0.49*	*0.61*	*0.42*
GridDehaze Net	PSNR	19.36	21.91	17.83	19.70
	SSIM	0.857	0.905	0.773	0.845
	LPIPS	0.09	0.07	0.20	0.12
FFANet	PSNR	<u>24.26</u>	<u>25.39</u>	<u>21.83</u>	<u>23.83</u>
	SSIM	<u>0.910</u>	0.930	<u>0.836</u>	<u>0.892</u>
	LPIPS	<u>0.06</u>	0.08	0.16	0.10
SCANet	PSNR	19.70	24.75	18.40	20.95
	SSIM	0.882	<u>0.934</u>	0.812	0.876
	LPIPS	<u>0.06</u>	<u>0.05</u>	<u>0.13</u>	<u>0.08</u>
本章技术	PSNR	**24.81**	**25.65**	**22.46**	**24.31**
	SSIM	**0.924**	**0.939**	**0.857**	**0.907**
	LPIPS	**0.05**	**0.05**	**0.13**	**0.08**

通过表 4.1 可以发现，本章去雾技术在 thin、moderate 和 thick 数据集上实现了最先进的去雾性能。与薄雾和中雾相比，本章去雾技术对浓雾的去雾效果略低。浓雾会导致更严重的图像退化，因此去除遥感图像中的浓雾更为困难。DCP 和 PFFNet 的去雾性能最差。FFANet 和 SCANet 都取得了较好的去雾效果。然而，与使用本章去雾技术获得的去雾结果相比，它们仍略显不足。如在 thick 数据集上，

中国知网 https://www.cnki.net

本章技术的 PSNR 和 SSIM 比次佳的 FFANet 的 PSNR 和 SSIM 值分别高 0.63dB 和 0.021。这些结果展示了本章技术在遥感图像去雾性能方面富有竞争力。

在 HRSD 数据集上的定量评估结果如表 4.2 所示，其中粗体、下划线和斜体数字分别表示最佳、次佳和最差结果。通过表 4.2 可以发现，DCP 在 LHID 和 DHID 数据集上的 PSNR 和 SSIM 值最低，性能最差。PFFNet 的 LPIPS 值最大，与地面真实图像的感知相似性最差。GridDehazeNet 和 FFANet 去雾各有优势，但从 average 可以发现，FFANet 表现出更高的 PSNR 值，表明图像质量更好。而 GridDehazeNet 展现出更好的 SSIM 和 LPIPS 值，表明与地真实图像相似度更高。本章技术在 DHID 和 LHID 数据集上都取得了最好的结果，除了在 LHID 数据集上的 PSNR 略低于 FCTFNet。尽管 FCTFNet 在 LHID 数据集上实现了最好的 PSNR，但它在 DHID 数据集上的表现不佳，表明该技术去雾性能不稳定。

表 4.2 在 HRSD 数据集上的定量结果

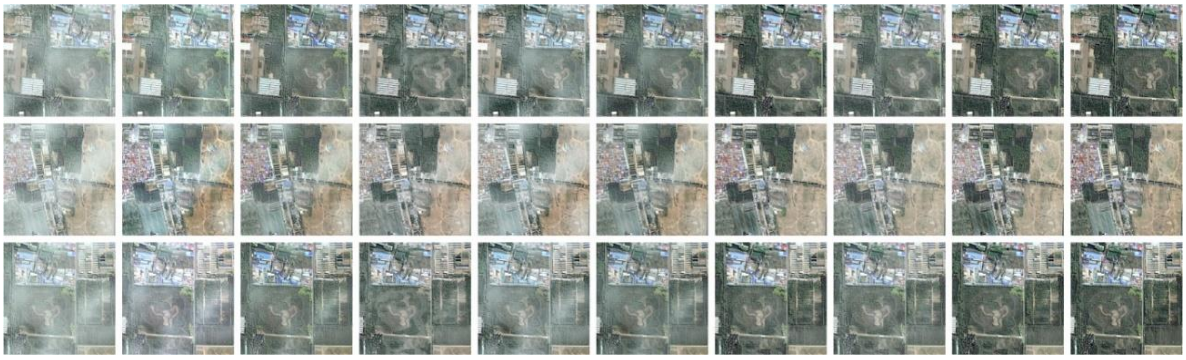
去雾技术	LHID			DHID			average		
	PSNR	SSIM	LPIPS	PSNR	SSIM	LPIPS	PSNR	SSIM	LPIPS
DCP	*17.03*	*0.723*	0.16	*14.23*	*0.661*	0.28	*15.63*	*0.692*	0.22
AODNet	21.46	0.808	0.11	17.05	0.731	0.18	19.26	0.770	0.15
FCTFNet	**28.33**	0.874	0.09	22.52	0.833	0.12	25.43	0.854	0.11
PFFNet	22.31	0.770	*0.22*	19.12	0.680	*0.35*	20.72	0.725	*0.29*
GridDehazeNet	26.10	0.864	0.07	25.75	0.870	0.09	25.93	0.867	0.08
FFANet	27.38	0.866	0.09	27.07	0.863	0.09	27.22	0.864	0.09
SCANet	25.16	0.847	0.08	23.26	0.789	0.19	24.21	0.818	0.14
本章技术	27.91	**0.877**	**0.07**	**27.26**	**0.886**	**0.09**	**27.59**	**0.882**	**0.08**

综合分析表 4.1 和表 4.2，SCANet 和 FFANet 在 SateHaze1k 数据集上表现出良好的去雾性能。然而在 HRSD 数据集，GridDehazeNet 展现了比 SCA-Net 和 FFANet 更好的结果。不同于 SCANet、FFANet 和 GridDehazeNet 适用于不同的数据集，本章技术在 SateHaze1k 和 HRSD 上均实现了最佳的去雾性能，具有更好的鲁棒性。这些结果突出了本章去雾技术在处理遥感图像方面具有稳定且强大的去雾能力。

4.3.3 定性比较

每种去雾技术在 thin 测试集上的定性结果如图 4.6 所示。DCP 和 PFFNet 去雾效果一般，有大量的雾残留。AODNet、FCTFNet、GridDehazeNet 和 SCANet 实现了一定程度的去雾效果，但与地面真实图像相比，整体恢复效果仍然遗留了少量的雾。FFANet 展现了较好的去雾性能，然而相比于地面真实图像，FFANet 恢复的第一行图像右侧中间的草地明显偏白。本章去雾技术恢复的遥感图像展现了与真面真实图像更为相近的结果，实现了更高程度的细节还原。

中国知网 https://www.cnki.net



(a) (b) (c) (d) (e) (f) (g) (h) (i) (j)

图 4.6 在 SateHaze1k-thin 数据集上定性结果

(a) 雾图 (b) DCP (c) AODNet (d) FCTFNet (e) PFFNet (f)GridDehazeNet
(g) FFANet (h) SCA-Net (i) 本章技术 (j) 地面真实

每种去雾技术在 moderate 测试集上的定性结果如图 4.7 所示。中等程度的雾遮挡了遥感图像中的部分重要信息。DCP 展现了一般的去雾性能，有大量的雾遗留在恢复的图像。AODNet 去雾过度，恢复的图像整体表现较暗。PFFNet 存在明显的颜色失真现象，例如恢复的第一行图像右上角的屋顶。FCTFNet、GridDehazeNet、FFANet 和 SCANet 都取得了较好的去雾效果。但是与地面真实图像相比，FCTFNet 恢复的第三行图像的草地颜色变化较大，GridDehazeNet 恢复的第二行图像略微偏暗，FFANet 恢复的第一行图像右侧中间草地有一个明显的圆形阴影，SCANet 恢复的第一行图像左侧中间屋顶明显更红。相比之下，本章去雾技术取得了较为出色的效果，展示了更好的色彩保真度，保留了更接近地面真实图像的纹理细节。



(a) (b) (c) (d) (e) (f) (g) (h) (i) (j)

图 4.7 在 SateHaze1k-moderate 数据集上的定性结果

(a) 雾图 (b) DCP (c) AODNet (d) FCTFNet (e) PFFNet (f)GridDehazeNet
(g) FFANet (h) SCA-Net (i) 本章技术 (j) 地面真实

每种去雾技术在 thick 测试集上的定性结果如图 4.8 所示。该数据集主要由被浓雾遮挡的遥感图像组成，丢失了大量的纹理细节信息。DCP 恢复的图像仍然有大量的雾残留。AODNet 表现出明显的颜色失真，如加重了蓝色屋顶颜色深度，且纹理细节也表现较差。PFFNet 和 GridDehazeNet 在恢复的图像中显示出明显的偏色现象，如与地面真实图像相比，它们恢复的图像蓝色屋顶的颜色信息几乎完全丢失。FCTFNet、SCANet 和 FFANet 都恢复了较好的图像质量。然而相比于地面真实图

中国知网 https://www.cnki.net

像，FCTFNet 和 SCANet 恢复的图像整体表现更白，依旧有少量的雾存在。FFANet 恢复的第一行图像左侧地面局部偏白。本章去雾技术在整体结构、局部细节和色彩保真度方面与地面真实图像表现出更高的相似度。



(a) (b) (c) (d) (e) (f) (g) (h) (i) (j)

图 4.8 在 StaeHaze1k-thick 数据集上的定性结果

(a) 雾图 (b) DCP (c) AODNet (d) FCTFNet (e) PFFNet (f)GridDehazeNet (g) FFANet (h) SCA-Net (i) 本章技术 (j) 地面真实

每种去雾技术在 LHID 测试集上的定性结果如图 4.9 所示。DCP 和 AOD 恢复的图像存在明显的过度去雾现象，例如它们恢复的第一行和第二行图像。PFFNet 和 SCANet 恢复的第二行图像下方草地绿色偏重，局部细节处理不佳。GridDehazeNet 恢复的第三行图像局部遗留少量雾，如其恢复的第三行图像中间河道表现偏白。FCTFNet 和 FFANet 均展现了较好的去雾效果，然而相比于地面真实图像，FCTFNet 恢复的第一行图像中间的马路略微偏白，FFANet 恢复的第二行图像中间草地的孔洞明显较大。本章去雾技术在局部和整体去雾性能方面表现最佳，图像细节丰富，有效提升了遥感图像的整体质量。



(a) (b) (c) (d) (e) (f) (g) (h) (i) (j)

图 4.9 在 LHID 数据集上的定性结果

(a) 雾图 (b) DCP (c) AODNet (d) FCTFNet (e) PFFNet (f)GridDehazeNet (g) FFANet (h) SCA-Net (i) 本章技术 (j) 地面真实

每种去雾技术在 DHID 测试集上的定性结果如图 4.10 所示。DHID 由被密集均匀的雾而遮挡的遥感图像组成。DCP 恢复的图像仍然模糊，难以分辨图像的细节信息。AODNet 恢复的图像明显丢失大量的纹理细节特征。PFFNet 恢复的图像未能保留原有图像的色彩，如它恢复的第一行和第三行图像。SCANet 恢复的图像在局部

中国知网 https://www.cnki.net

区域存在一定程度的色偏现象和表现为暗色调，如其恢复的第一行图像下方中间的楼顶为绿色，恢复的第三行图像中上方的楼顶阴影较重。FCTFNet 和 FFANet 恢复的图像仍然局部区域遗留少量雾，如它们恢复的第二行图像中间区域。GridDehazeNet 恢复的第一行图像左侧白色楼顶有少量阴影。本章去雾技术在颜色保真和纹理细节方面具有极佳的表现，尤其是在恢复屋顶颜色和浓雾下的草坪颜色方面展现了非常好的性能。



(a) (b) (c) (d) (e) (f) (g) (h) (i) (j)

图 4.10 在 DHID 数据集上的定性结果

(a) 雾图 (b) DCP (c) AODNet (d) FCTFNet (e) PFFNet (f)GridDehazeNet (g) FFANet (h) SCA-Net (i) 本章技术 (j) 地面真实

为测试本章去雾技术在真实遥感图像中的去雾性能，统一使用在 LHID 数据集下的预训练模型恢复真实遥感有雾图像，如图 4.11 所示。



(a) (b) (c) (d) (e) (f) (g) (h) (i)

图 4.11 真实世界遥感有雾图像定性结果

(a) 雾图 (b) DCP (c) AODNet (d) FCTFNet (e) PFFNet (f)GridDehazeNet (g) FFANet (h) SCA-Net (i) 本章技术

通过图 4.11 可以发现，DCP 恢复的图像仍然存在大量的雾，图像仍然显得较为模糊。AODNet 发生了明显的去雾过度现象，恢复的图像表现过暗。FCTFNet 恢复的第三行图像表现略白，残留了少量的雾。PFFNet 和 SCANet 存在轻微的过度去雾现象，它们恢复的第三行图像四周的草地表现更暗。GridDehazeNet 取得了较好的去雾结果，但是其恢复的第一行图像右下角的地面阴影略微较重。FFANet 恢复的第二行图像颜色变化较为明显，其马路两侧展现为绿色。本章技术恢复的图像在颜

中国知网 https://www.cnki.net

色、纹理保留等方面显示了出色的结果，更符合真实世界的视觉效果。

4.3.4 参数量及计算量比较

每种神经网络模型的参数量和计算量如表 4.3 所示。从表中可以发现，本章网络的 Flops 值较大，表明本章网络模型训练时需要较高的硬件配置才能快速计算。参数量相比于 PFFNet 略低，表明本章网络模型所占内存相对较少。然而本章网络在定量和定性实验中均取得了优异的结果，这表明本章去雾技术需要牺牲一定程度的计算量从而获取高质量的清晰图像。

表 4.3 每种网络模型的参数量及计算量

去雾技术	Params/$\times 10^6$	Flops/$\times 10^9$
DCP	—	—
AODNet	0.01	0.10
FCTFNet	0.16	35.32
PFFNet	20.85	408.02
GridDehazeNet	0.96	452.01
FFANet	4.46	505.43
SCANet	2.39	31.04
本章技术	15.26	552.27

4.4 消融研究

为验证本章去雾技术及其组件的有效性，在 DHID 数据集上进行消融研究，以分析本章的 MSDEU、SADEU 和 PNM 的性能，定量评估结果如表 4.4 所示，其中粗体数字表示最佳结果。为加快训练速度，将 RGB 图像大小裁剪为 60×60 作为输入，其他配置与 4.3.1 节中的实验细节保持一致。

首先构建一个基本网络，该网络中移除了局部残差、PNM 和 SFPA，在表 4.4 中表示为“Base”。然后在“Base”网络中顺次添加局部残差、PNM 和 SFPA，在表 4.4 中表示为“Base+LR”、“Base+LR+PNM”和“Base+LR+PNM+SFPA”。此外，分别将本章去雾网络中的 SK Fusion 和软重建移除（without，w/o），以验证它们对网络去雾性能的影响，在表 4.4 表示为“w/o SK Fusion”和“w/o Soft Recno.”。

表 4.4 在 DHID 数据集上的消融研究定量结果

去雾技术	DHID		
	PSNR	SSIM	LPIPS
Base	18.76	0.649	0.17
Base+LR	19.02	0.700	0.20
Base+LR+PNM	22.84	0.848	0.18
w/o SK Fusion	22.15	0.833	0.12
w/o Soft Recno.	23.13	0.852	0.12
Base+LR+PNM+SFPA	**23.21**	**0.852**	**0.12**

根据表 4.4 在 DHID 数据集上的消融研究结果，可以得出以下结论：

(1) 当本章去雾技术不包括局部残差、PNM 和 SFPA 时，PSNR 和 SSIM 最低，图

中国知网 https://www.cnki.net

像失真严重，质量最差。然而 LPIPS 值相对较低，表明与真实图像的感知相似度较高。

(2) 当将局部残差添加到“Base”网络时，PSNR 和 SSIM 得到提升，图像质量得到改善，证明了局部残差能够提升图像的细节信息。然而 LPIPS 大幅度增加，未能很好的保持与地面真实图像的感知相似性。

(3) 当将局部残差和 PNM 同时添加到“Base”中时，此时网络中包含了本章设计的 MSDEU。与“Base”网络结果相比，PSNR 和 SSIM 值得到了大幅度提升，PSNR 增加 4.08 dB，SSIM 增加 0.203，图像质量得到明显提升，证明 PNM 和 MSDEU 能够有效的提升网络的去雾性能，恢复遥感模糊图像的细节信息。

(4) 当将局部残差、PNM 和 SFPA 同时添加到“Base”中时，此时网络中包含 SADEU，为本章设计的去雾网络。相比于“Base+LR+PNM”网络的结果，PSNR 和 SSIM 得到进一步提升，LPIPS 大幅度的减少，证明了 SADEU 和本章去雾网络的有效性，在增强图像细节、提升图像质量的同时，能够很好的保持与地面真实图像的感知相似性。

(5) 当移除本章网络中的 SK Fusion，将其替换为常用的按像素相加融合方法时，与本章去雾网络结果相比，PSNR 和 SSIM 值减少较多，分别减少了 1.06dB 和 0.019。这一结果充分证明 SK Fusion 的引入能够有效提升网络的去雾性能。

(6) 当将 Soft Recno.从本章网络中移除时，尽管其 SSIM 和 LPIPS 结果与本章网络结果相同，然而 PSNR 下降 0.08dB。这一结果表明 Soft Recno.能够对生成的图像进行微调，进一步提升图像质量。

4.5 本章小结

在本章中，提出了一种细节增强的去雾网络用来解决遥感图像中的雾移除问题。该网络主要由包含多尺度细节增强单元和阶梯式注意力细节增强单元的细节增强块组成。多尺度细节增强单元用来获取多尺度信息，保留细节特征。阶梯式注意力细节增强单元自适应的处理遥感图像中不均匀分布的雾，输出有用特征到 U-Net 骨架。为提升模型的稳定性和泛化能力，在网络中设计并嵌入了一种新颖的并行归一化模块。消融研究表明，多尺度细节增强单元可以有效地捕获与雾相关的信息，实现较好的去雾性能。阶梯式注意力细节增强单元能够关注并增强去雾过程中的有用信息，进一步提升去雾效果，改善遥感图像质量。在 SateHaze1k 和 HRSD 遥感图像去雾数据集上的实验结果表明，本章去雾技术取得了最先进的去雾效果，极大程度的恢复了图像的细节信息。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 5 章 基于逆认知学习的遥感图像去云雾技术研究

在第 4 章中，主要进行了遥感图像去雾技术研究。在遥感图像中，不但会受到低空中雾的影响，而且会受到高空中云的影响。从遥感物理来讲，雾和薄云具有相近的成像特性，因此本章将雾和薄云视为同一种图像退化问题进行研究。在本章中，首先阐述了基于逆认知学习的遥感图像去云雾技术提出的背景，其次对该技术及其相关组件进行了详细说明，然后通过实验验证了提出的基于逆认知学习的去云雾网络的有效性，以及消融实验。最后对本章阐述的主要内容进行总结。

5.1 引言

遥感成像技术因其具有强大的收集地面数据信息的能力，成为热点研究领域之一。由于高空中复杂的云层或者低空中雾的遮挡，使得光学遥感成像设备拍摄的图像存在清晰度差、对比度低、冗余信息严重等问题。这些干扰信息极大地限制了遥感图像数据的利用。尽管一些去云雾技术已经被提出用来提升遥感影像的质量，但它们仍然存在云雾去除不彻底、纹理信息缺失严重等问题。

因此，本章构建了一个用于去除遥感图像中雾和薄云的新型网络，即逆认知学习网络（Inverse Cognitive Learning Network，ICLNet）。该网络不但在遥感图像去雾方面取得了很好的效果，而且在去除薄云方面具有强有力的竞争力。提出的 ICLNet 以 U-Net 型网络为基础框架，并在其中嵌入设计的多尺度逆认知学习块（Multiscale Inverse Cognitive Learning Block，MSICLB）。MSICLB 贯穿整个 ICLNet 网络架构，主要由不同尺度的并行卷积、特征注意力（Feature Attention，FA）、并行云雾约束模块（Parallel Cloud and Fog Constraint Module，PCFCM）和逆认知学习模块（Inverse Cognitive Learning Module，ICLM）组成。并行卷积采用3×3 卷积、5×5 卷积、9×9 卷积提取输入有云或雾图的多尺度信息，融合了小卷积捕获的局部细节信息和大卷积捕获的全局信息，具有较大的感受野。PCFCM 可以有效地抑制云雾并增强图像的细节信息。ICLM 模拟人脑认知图像的逆过程，从遥感云雾图像的局部特征逐渐学习到全局特征，实现对云雾信息的逐步约束。FA 融合了通道注意力和像素注意力，可以实现对全局特征和与位置相关的局部特征的自适应关注，有效提取不规则分布的云雾，适用于处理云雾强度分布不均匀的遥感图像。本章主要贡献如下：

(1) 提出了一种新颖的多尺度逆认知学习块。它能够提取遥感云雾图像的多尺度特征，融合全局和局部细节信息，自适应地关注遥感图像中的不均匀云雾分布，逐步对云雾进行约束，有效保留图像中的纹理等细节信息。

(2) 提出了一种新颖的并行云雾约束模块。它利用并行的3×3 卷积对提取的云雾

中国知网 https://www.cnki.net

信息进行整合，可以对云雾信息进行强有力的约束，并增强图像中的细节信息。

(3) 提出了一种新颖的逆认知学习模块。它逐步的从局部特征到全局特征进行学习，在不同的深度和广度通道特征上约束遥感图像中的云雾。

(4) 提出了一种新颖的逆认知学习网络用于移除遥感图像中的云雾。将 MSICLB 嵌入 ICLNet 中以恢复遥感场景中的云雾图像。在公开可用的遥感图像去雾数据集（StateHaze1k）和去云数据集（RICE-I）上进行实验，本章技术优于其他先进的去云雾技术，能够有效的移除遥感图像中的雾和薄云。

5.2 网络架构设计

本章提出的逆认知学习网络整体结构如图 5.1 所示。该网络是一个 U 型网络，主要由编码器（Encoder）、瓶颈（Bottleneck）层、解码器（Decoder）和软重构（Soft Recon.）四部分组成。

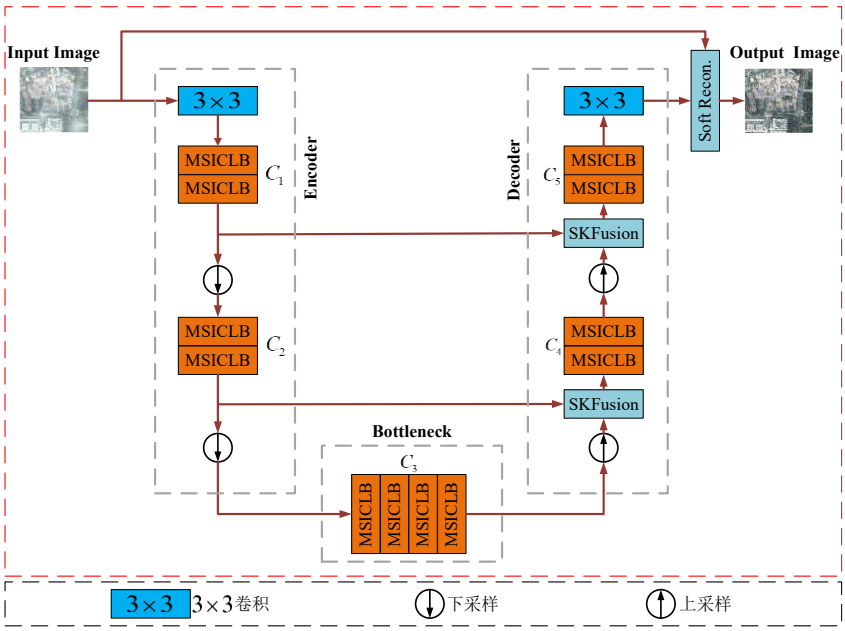


图 5.1 逆认知学习网络架构图

输入图像（Input Image）首先经过编码器将 RGB 图像转换为特征图，并逐步提取特征，提升特征图通道数。接着信息流入瓶颈层，瓶颈层由四个串连的 MSICLB 组成，用来加深特征的提取，进一步对云雾特征信息加强约束。然后通过解码器来逐步重构图像。与编码器不同的是，解码器中额外增加了 SK Fusion，它被用来将编码器中的浅层信息和解码器中的深层信息进行融合，以保留浅层中的细节信息。最后将编码器重建图像与输入图像通过软重构技术进行微调，从而得到输出图像。其中，图中的 $C_i\left(i=1,2,3,4,5\right)$ 表示特征图通道数，将其设置为 $\left[C_1,C_2,C_3,C_4,C_5\right]=\left[32,64,128,64,32\right]$。下面分别对逆认知学习网络中的各部分进行介绍。

中国知网 https://www.cnki.net

5.2.1 编码器

编码器主要由一个3×3卷积，MSICLB和下采样组成。在编码器中，3×3卷积用来将输入的遥感云雾图像转换为特征图，提取浅层特征信息。下采样采用步长为2的3×3卷积，用来增加通道数，减少输入图像尺寸，降低计算量。MSICLB不但是本章网络的核心组件，而且也是编码器、瓶颈层和解码器的主要组成模块。编码器进行特征提取的过程可用式(5-1)表示：

$$F_{Enc}=\mathcal{H}_{Enc}\left(I\right),I\in R^{3\times H\times W} \tag{5-1}$$

其中，I 为输入图像（Input Image），F_{Enc} 表示编码器的输出特征图，$\mathcal{H}_{Enc}$ 表示编码器，其内包含3×3卷积、下采样和 MSICLB 三种操作。下面主要对 MSICLB 进行介绍。

MSICLB 的结构如图 5.2 所示，其主要包含不同大小的卷积核、PCFCM、ICLM 和 FA。

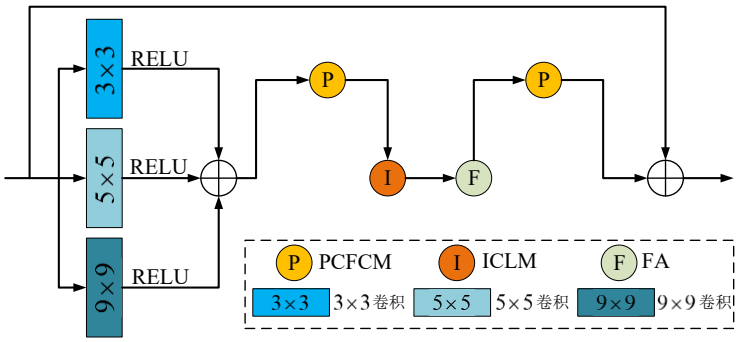


图 5.2 多尺度逆认知学习块结构图

MSICLB使用不同尺度的卷积核提取图像的多尺度信息。大卷积核用于增加感受野，关注全局特征，小卷积核用于关注局部细节。本章将 PCFCM 和 ICLM 嵌入到MSICLB中，使其能够增强对云雾信息的约束，保留细节信息，并从不同的深度和广度通道特征中逐步学习具有多尺度信息的融合特征。在 MSICLB 中，FA 的引入使其具有自适应处理不规则云雾信息的能力，实现了对全局信息和与位置相关的局部信息的灵活关注。

首先，令 F_M^* 为 MSICLB 的初始输入特征，使用并行的3×3卷积、5×5卷积和9×9卷积提取多尺度特征并进行融合。其次，通过 PCFCM 约束具有多尺度特性的、融合的云雾信息，保留细节信息。

$$F_{M1}=\mathrm{PCFCM}\left(\varepsilon\left(conv_3\left(F_M^*\right)\right)+\varepsilon\left(conv_5\left(F_M^*\right)\right)+\varepsilon\left(conv_9\left(F_M^*\right)\right)\right) \tag{5-2}$$

其中，$conv_i\left(i=3,5,9\right)$ 分别表示3×3卷积、5×5卷积和9×9卷积，ε 表示 RELU 激活函数。

中国知网 https://www.cnki.net

然后，F_{M1}顺次流经 ICLM 和 FA，从而在不同的深度和广度通道特征约束增强的多尺度融合信息中的雾，对遥感图像中分布不均匀的雾进行不均衡处理，关注全局共享信息和与位置相关的局部信息。

$$F_{M2}=\mathrm{FA}\left(\mathrm{ICLM}\left(F_{M1}\right)\right) \tag{5-3}$$

最后，再次使用 PCFCM 进一步约束雾信息，增强细节信息，通过跳跃连接以避免梯度消失。

$$F_{M}=\mathrm{PCFCM}\left(F_{M2}\right)+F_{M}^{*} \tag{5-4}$$

其中，F_M 是 MSICLB 的输出特征。下面分别对 MSICLB 中的 ICLM、PCFCM 和 FA 三个组件进行介绍。

(1) 逆认知学习模块

人脑对图像的认知是一个从整体图像到局部分析和注意的复杂过程。基于此过程，本章设计了一个从局部到全局的卷积神经网络学习模块，即 ICLM，其结构如图 5.3 所示。

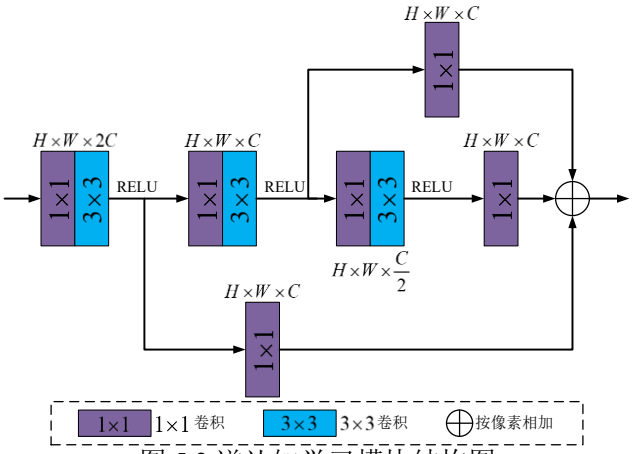


图 5.3 逆认知学习模块结构图

尽管 ICLM 与 GoogLeNet[107]等网络模块有类似的流程，然而 ICLM 与它们不同。ICLM 主要应用1×1 卷积和3×3 卷积。1×1 卷积用于修改通道数，而 3×3 卷积用于提取特征。ICLM 不同于 GoogLeNet 一样使用池化操作来减少参数数量。虽然池化可以减少参数数量，但也会导致细节信息的大量丢失，从而严重影响图像恢复的质量。为进一步保留图像的细节信息，通过融合 ICLM 中每个3×3 卷积提取的浅层和深层特征，使本章技术更适合图像去雾等低级计算机视觉任务。

考虑一个基本事实：通道数越多，图像输出特征越多，在深度上更加关注图像的小范围的局部特征。通道数越少，图像输出的特征越少，在广度上更加关注图像的区域特征。因此，做出以下三个简单假设。

(a) 深度通道特征：通道特征数量较多，更加关注图像局部小区域的不同特征。

(b) 中度通道特征：通道特征数量一般较多，更加关注图像稍大的区域特征。

中国知网 https://www.cnki.net

(c) 广度通道特征：通道特征数量较少，更加关注整幅图像的全局特征。

令 F_I^* 为 ICLM 的原始输入特征图，形状为 $H\times W\times C$。首先使用逐点卷积将其形状转换为 $H\times W\times 2C$，增加其通道数以划分更多特征，然后使用 3×3 卷积和 RELU 激活函数来约束信息，在深度通道特征上对雾、云等信息进行约束。

$$F_{I1}=\varepsilon\left(conv_3\left(conv_p\left(F_I^*\right)\right)\right) \tag{5-5}$$

其中，$conv_p$ 表示逐点卷积，$conv_3$ 表示 3×3 卷积，ε 表示 RELU 激活函数。F_{I1} 的形状为 $H\times W\times 2C$。

其次，利用同样的方法通过逐点卷积将 F_{I1} 的形状转换为 $H\times W\times C$。然后依次使用 3×3 卷积和 RELU 函数，在中度通道特征上约束云雾信息。

$$F_{I2}=\varepsilon\left(conv_3\left(conv_p\left(F_{I1}\right)\right)\right) \tag{5-6}$$

其中，F_{I2} 的形状为 $H\times W\times C$。

然后，逐点卷积将 F_{I2} 的形状转换为 $H\times W\times\frac{C}{2}$，再使用 3×3 卷积和 RELU 函数，在广度通道特征上约束云雾信息。

$$F_{I3}=\varepsilon\left(conv_3\left(conv_p\left(F_{I2}\right)\right)\right) \tag{5-7}$$

其中，F_{I3} 的形状为 $H\times W\times\frac{C}{2}$。

最后，分别使用逐点卷积将 F_{I1}、F_{I2} 和 F_{I3} 的形状转化为 $H\times W\times C$，并进行求和，以保留深度、中度和广度通道特征上学习到的云雾信息。

$$F_I=conv_p\left(F_{I1}\right)+conv_p\left(F_{I2}\right)+conv_p\left(F_{I3}\right) \tag{5-8}$$

其中，F_I 是 ICLM 的输出特征。

(2) 并行云雾约束模块

遥感图像受到云雾的影响，导致遥感图像丢失了原有的细节信息。受 DenseNet[147]的启发，设计了 PCFCM，其结构如图 5.4 所示。

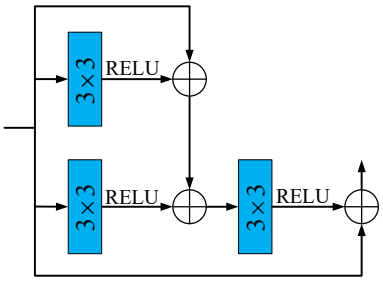


图 5.4 并行云雾约束模块结构图

不同于通过单路径传输输入特征并融合作为下一层输入的密集连接机制，

中国知网 https://www.cnki.net

PCFCM 利用3×3卷积的双分支结构将提取的云雾特征与输入特征融合并传递到下一阶段。然后，使用3×3卷积整合提取的云雾信息并将其与原始输入信息融合，实现深层和浅层信息的交互，保留细节信息并增强对云雾信息的关注。

令 F_P^* 为 PCFCM 的初始输入特征，分别传入两个分支，在第一个分支中，利用局部残差提取 F_P^* 的特征信息。

$$F_{P1} = \varepsilon\left(conv_3\left(F_P^*\right)\right) + F_P^* \tag{5-9}$$

将第一个分支得到的特征信息 F_{P1} 传递到第二个分支。在第二个分支中，使用3×3卷积和 RELU 提取特征，然后与第一个分支中局部残差得到的特征 F_{P1} 求和，保证特征信息结构的相似性，并凸显云雾信息。

$$F_{P2} = \varepsilon\left(conv_3\left(F_P^*\right)\right) + F_{P1} \tag{5-10}$$

进一步利用3×3卷积和RELU整合增强的云雾信息 F_{P2}，并与输入特征 F_P^* 相加，以保留浅层细节信息并再次增强云雾信息。

$$F_P = \varepsilon\left(conv_3\left(F_{P2}\right)\right) + F_P^* \tag{5-11}$$

其中，F_P 表示 PCFCM 的输出特征。

(3) 特征注意力

FA 主要由通道注意力（Channel Attention）和像素注意力（Pixel Attention）两部分组成，通道注意力能够自适应的为通道特征分配不同权重，从而实现对通道特征的不平等关注，有效捕获云雾图像中的关键信息。像素注意力主要用来针对遥感图像中云雾不均匀分布情况，以关注更多与位置相关的局部特征，如云雾或图像中的高频区域。通过这两个注意力的共同作用，使得 FA 能够同时关注通道和像素特征，增强对遥感图像中有价值信息的关注，适用于处理不规则的云雾图像。

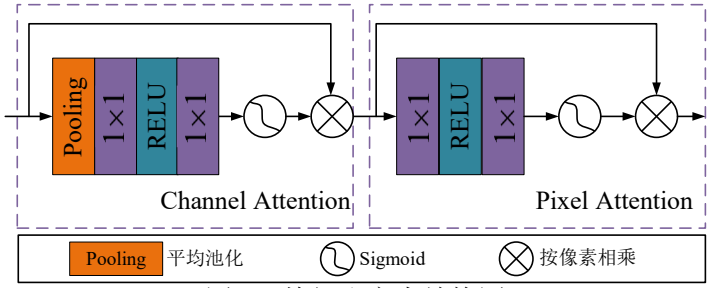


图 5.5 特征注意力结构图

5.2.2 瓶颈层

在大多数网络模型中，一般直接将编码器的最后一层输出特征图作为解码器的输入特征图。然而这种直连方式会导致无法对编码器存在的丰富特征进行充分而有效的挖掘。此外，输入云雾遥感图像在经过编码器逐步下采样后，编码器的输出特

中国知网 https://www.cnki.net

征图分辨率会变低，丢失遥感云雾图像原有的结构信息，故通过解码器重建时难以获取准确的目标边界。

因此，为进一步深入挖掘编码器中的有用信息，为解码器提供更为有效的特征图，用以复原潜在的清晰图像。在本章网络设计的编码器和解码器之间添加了一个瓶颈层。在本章网络中，将瓶颈层设置为四个顺次连接的MSICLB，这样既可以增加网络的深度，又可以充分对图像特征进行有效学习，避免由于使用较多的网络层结构，过度增加网络深度，导致梯度消失或大量特征信息丢失等问题。瓶颈层的执行过程如式(5-12)所示：

$$F_{Dec}^{*}=\mathcal{H}_{B}\left(F_{Enc}\right) \tag{5-12}$$

其中，F_{Enc} 表示编码器的输出特征图，F_{Dec}^{*} 表示解码器的输入特征图，$\mathcal{H}_{B}$ 表示瓶颈层，其为四个连续的 MSICLB 操作。

5.2.3 解码器

解码器相当于编码器的逆过程，用来逐步细化输出，从粗糙特征逐步重建精细特征。相比于编码器主要是交替连接的 MSICLB 和下采样结构，在解码器中的上采样和 MSICLB 之间引入了 SK Fusion 技术，以将编码器中的浅层信息和解码器中的深层信息进行有效融合，从而提升网络重建细节信息的能力。解码器的特征重建过程可用式(5-13)表示：

$$F_{Dec}=\mathcal{H}_{Dec}\left(F_{Dec}^{*}\right) \tag{5-13}$$

其中，F_{Dec} 表示解码器的输出特征图，且 $F_{Dec}\in R^{4\times H\times W}$，$\mathcal{H}_{Dec}$ 表示解码器，其包含上采样、MSICLB、SK Fusion 和3×3 卷积四种操作。

在解码器中，通过1×1 卷积和 PixelShuffle 顺次连接的方式实现上采样。输入上采样中的特征首先经过1×1 卷积调整为目标通道数，然后利用 PixelShuffle 进行像素重排，从而实现高分辨率的特征图输出。为保留浅层网络中的细节信息，本章与第四章相同，同样使用了 SK Fusion 来融合深层和浅层信息。下面对 SK Fusion 的实现过程进行详细介绍。

设两个需要被融合的编码器中的浅层输入特征图和解码器中的深层输入特征图分别为 x_1 和 x_2，首先利用线性层 $f(\cdot)$ 将 x_1 投影到 $\hat{x}_1$，然后通过全局平均池化、MLP、Softmax 和拆分操作来获取融合权重，如式(5-14)所示：

$$\left\{w_1,w_2\right\}=\mathrm{Split}\left(\mathrm{Softmax}\left(f_{mlp}\left(GAP\left(\hat{x}_1+x_2\right)\right)\right)\right) \tag{5-14}$$

其中 GAP 表示全局平均池化，Split 表示拆分操作，f_{mlp} 表示多层感知机，它由 Linear-ReLU-Linear 三个连续操作组成。最后利用权重 $\left\{w_1,w_2\right\}$ 通过式(5-15)将 $\hat{x}_1$，x_2

中国知网 https://www.cnki.net

与额外的短残差进行融合，从而得到 SK Fusion 的输出特征 y 。

$$y = w_1\hat{x}_1 + w_2x_2 + x_2 \tag{5-15}$$

5.2.4 软重建

在本章中使用的软重建技术的输入分别是原始输入的遥感云雾图像和经编码器重建的特征图 $F_{Dec} \in R^{4\times H\times W}$ 。将大气散射模型改写后的软重建表达式如式(5-16)所示：

$$J(x) = K(x)I(x) + B(x) + I(x) \tag{5-16}$$

其中，$I(x)$ 为输入的云雾遥感图像，$J(x)$ 为复原的清晰图像，$K(x) = 1/t(x) - 1$，$B(x) = -(1/t(x) - 1)A$ 。软重建主要通过式(5-16)对 $K(x)$ 和 $B(x)$ 之间的关系进行软约束。

在软重建的实现过程中，首先将编码器的输出特征图 $F_{Dec} \in R^{4\times H\times W}$ 拆分为 $K \in R^{H\times W\times 1}$ 和 $B \in R^{H\times W\times 3}$，然后将输入云雾遥感图像 $I(x)$、$K(x)$ 和 $B(x)$ 代入式(5-16)中，最终得到清晰的无云雾图像 $J(x)$。与其他图像重建网络直接使用跳跃连接的方式重建图像相比，软重建是一种进一步改写的大气散射模型，并依据此模型使网络能够对 $K(x)$ 和 $B(x)$ 之间的关系进行软约束，从而实现遥感图像的复原。

5.2.5 损失函数

卷积神经网络一般用来解决分类问题和回归问题，图像去雾属于一个经典的回归问题。回归问题常用的损失函数是通过欧拉损失函数来求解。然而，利用欧拉损失函数进行训练的卷积神经网络容易导致输出的复原图像发生模糊等现象。因此，为避免欧拉损失函数导致的这一问题，本章遥感去雾技术通过 L1 损失函数训练神经网络。L1 损失函数如式(5-17)所示：

$$\mathcal{L}_1 = \frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{3}\left|\tilde{J}_c(i) - J_c(i)\right| \tag{5-17}$$

其中，$\tilde{J}_c(i)$ 是使用本章网络恢复的清晰遥感图像，$J_c(i)$ 是地面真实遥感图像，N 为训练集中样本数量。

5.3 实验验证与结果分析

在本节中，详细描述了实验中所使用的数据集和相关实验细节，将本章技术与其他先进去云雾进行比较，并对本章去云雾技术进行消融研究。

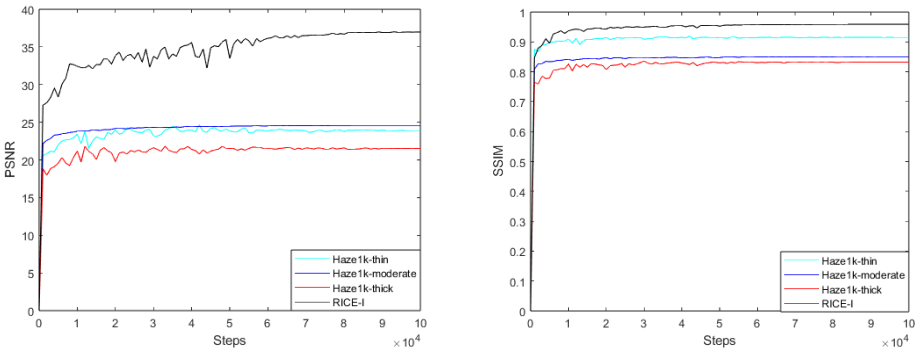
中国知网 https://www.cnki.net

5.3.1 数据集选择和相关实验细节

为评估本章去云雾技术的有效性，选择在公开的遥感去雾数据集 SateHaze1k 和去云数据集 RICE-I 上进行实验。SateHaze1k 包含三个子数据集 SateHaze1k-thin、SateHaze1k-moderate 和 SateHaze1k-thick。在下文分别用 thin、moderate 和 thick 来分别表示 SateHaze1k-thin、SateHaze1k-moderate 和 SateHaze1k-thick 三个子数据集。这三个子数据集分别由受薄、中、厚雾等级影响的遥感图像和相应的清晰图像组成。在每个子数据集中，将 320 幅图像设置为训练集，45 幅图像设置为测试集。RICE-I 数据集包含 500 对图像，每对由一张薄云图像和一张相应的无云图像组成。在 RICE-I 数据集中随机选择 420 幅图像作为训练集，80 幅图像作为测试集。

在训练和测试的实现中，深度学习框架为 Pytorch，GPU 为 NVIDIA RTX8000。利用随机旋转 90，180，270 度和水平反转的方式来增强训练数据。本章网络的输入是 RGB 遥感图像，图像大小被裁剪为 240×240。Adam 优化器（$\beta_1=0.9,\beta_2=0.999$）被用来优化提出的 ICLNet。分别在 thin， moderate、thick 和 RICE-I 数据集上进行 1.0×10^5 步的训练。批大小设置为 4，初始学习率设置为 1.0×10^{-4}，采用余弦退火策略将初始学习率逐渐降低到 0。

图 5.6 展示了本章网络在四个子数据集训练过程中通过每 1000 步获得的 PSNR 和 SSIM 值而绘制的学习曲线。图 5.6(a)表示 PSNR 随步长的变化过程，图 5.6(b)表示 SSIM 随步长的变化过程。图中“Haze1k-thin”表示 thin 数据集，“Haze1k-moderate”表示 moderate 数据集，“Haze1k-thick”表示 thick 数据集。



(a) (b)

图 5.6 网络训练学习曲线
(a) PSNR 学习曲线 (b) SSIM 学习曲线

从图 5.6 中可以发现，本章技术在 RICE-I数据集上实现了最好的学习性能，在 thick 数据集上实现了最差的学习性能。这是因为 thick 数据集中图像受到大量的雾遮挡，使去雾更为困难。另一方面，RICE-I数据集的云较薄且分布比较均匀，因此去云相对容易。总体而言，本章技术在训练过程中表现出稳定的学习性能。

中国知网 https://www.cnki.net

5.3.2 定量比较

将本章去云雾技术与 DCP[31]、AODNet[42]、PFF-Net[45]、FCTFNet[56]、GridDehazeNet[48]、SCANet[55]和 FFANet[47]七种先进的去雾技术进行比较。其中，DCP 是传统的基于物理模型的去雾技术，其余六种为基于深度学习的去云雾技术。为尽可能的进行更为公平的比较，本章用于对比的去云雾技术均使用作者公开的官方代码进行训练和测试。每种去云雾技术在 SateHaze1k 数据集的定量结果如表 5.1 所示，表中粗体、下划线和粗体数字分别表示最佳、次佳和最差结果。在表 5.1 中还提供了每种技术在 thin、moderate 和 thick 数据集上的平均结果（average）。

表 5.1 在 SateHaze1k 数据集上的定量结果

去雾技术	指标	thin	moderate	thick	average
DCP	PSNR	*15.99*	*14.75*	*10.99*	*13.91*
	SSIM	0.835	0.821	0.617	0.758
	LPIPS	0.10	0.13	0.27	0.17
AODNet	PSNR	18.47	17.63	15.75	17.28
	SSIM	0.863	0.855	0.742	0.820
	LPIPS	0.08	0.12	0.23	0.14
FCTFNet	PSNR	19.71	23.10	18.56	20.46
	SSIM	0.875	0.926	0.800	0.867
	LPIPS	0.10	0.06	0.20	0.12
PFFNet	PSNR	16.01	18.59	16.06	16.89
	SSIM	*0.821*	*0.688*	*0.575*	*0.695*
	LPIPS	*0.17*	*0.49*	*0.61*	*0.42*
GridDehazeNet	PSNR	19.36	21.91	17.83	19.70
	SSIM	0.857	0.905	0.773	0.845
	LPIPS	0.09	0.07	0.20	0.12
SCANet	PSNR	19.70	24.75	18.40	20.95
	SSIM	0.882	<u>0.934</u>	0.812	0.876
	LPIPS	<u>0.06</u>	<u>0.05</u>	<u>0.13</u>	<u>0.08</u>
FFANet	PSNR	<u>24.26</u>	<u>25.39</u>	**21.83**	<u>23.83</u>
	SSIM	<u>0.910</u>	0.930	<u>0.836</u>	<u>0.892</u>
	LPIPS	<u>0.06</u>	0.08	0.16	0.10
本章技术	PSNR	**24.59**	**25.67**	<u>21.78</u>	**24.01**
	SSIM	**0.923**	**0.937**	**0.859**	**0.906**
	LPIPS	**0.05**	**0.05**	**0.12**	**0.07**

通过表 5.1 可以发现，DCP 处理受薄雾、中雾和厚雾遮挡的遥感图像的 PSNR 值最低，图像失真最严重。PFFNet 处理受薄雾、中雾和厚雾遮挡的遥感图像的 SSIM 和 LPIPS 值最差，说明 PFFNet 恢复的图像与地面真实图像最不相似。FFANet 在 PSNR 和 SSIM 两个指标上取得了较佳的结果，但它在 thin、moderate 和 thick 数据集上的 LPIPS 值相比于 SCANet 的 LPIPS 较大。尽管 FFANet 和 SCANet 均取得了较好的结

中国知网 https://www.cnki.net

果，但与本章技术的结果相比，仍略显不足。如在 thin 数据集上，本章技术的 PSNR 和 SSIM 比次佳的 FFANet 的 PSNR 和 SSIM 分别高 0.33dB 和 0.013。本章技术的 LPIPS 比次佳的 SCANet 的 LPIPS 低 0.01。本章去云雾技术在三种受不同雾程度遮挡的数据集上均取得了最佳的结果，除了 thick 数据集，它的 PSNR 值是第二好。综合而言，本章技术在 average 列中均取得了最好的结果，去雾性能最为稳定。这些结果充分说明了本章技术在遥感图像上的去雾性能富有竞争性。

每种去云技术在 RICE-I 数据集的定量结果如表 5.2 所示，其中粗体表示最佳结果。DCP 的 PSNR 值和 SSIM 值最小，分别为 16.33dB 和 0.767，恢复的图像质量最差。PFFNet 的 LPIPS 值最大，不能很好的保持与地面真实图像的感知相似性。SCANet 取得了最佳的 LPIPS 值，但与本章技术相比，它的 PSNR 和 SSIM 值较低。本章技术的 PSNR 和 SSIM 值分别比 SCANet 的 PSNR 和 SSIM 值高 3.03dB 和 0.011。FFANet 取得了较好的结果，它的 SSIM 和 LPIPS 值和本章技术取得的结果相同，但本章技术的 PSNR 值比 FFANet 的 PSNR 值高 1.22dB。这些结果充分显示了本章技术在 RICE-I 数据集上具有卓越的去薄云性能。

表 5.2 在 RICE-I 数据集上的定量结果

去雾技术	PSNR	SSIM	LPIPS
DCP	16.33	0.767	0.15
AODNet	20.90	0.864	0.10
PFFNet	24.50	0.821	0.25
FCTFNet	31.09	0.932	0.11
GridDehazeNet	28.39	0.921	0.03
SCANet	33.91	0.949	**0.02**
FFANet	35.72	0.960	0.03
本章技术	**36.94**	**0.960**	0.03

综合分析表 5.1 和表 5.2，DCP 和 PFFNet 在四个子数据集上的去雾效果最差，FCTFNet 和 GriddehazeNet 表现稍好，SCANet 和 FFANet 各有所长，效果较好。各去云雾技术在 thick 数据集的 PSNR 和 SSIM 值均最低，在 RICE-I 数据集的 PSNR 和 SSIM 值最高，说明厚雾图像修复难度较大，在 RICE-I 数据集上修复效果更为理想。与 SateHaze1k 数据集相比，每种技术在 RICE-I 数据集上具有更好的去云效果。总体而言，与在不同子数据集上表现出相对较好效果的 SCANet 和 FFANet 不同，本章技术不仅取得了最好的去云雾效果，而且在去云雾性能方面表现出更高的稳定性。

5.3.3 定性比较

在本节中，将提出的 ICLNet 与其他七种最先进的去云雾技术在 SateHaze1k 和 RICE-I 遥感图像测试集上进行定性比较。

每种技术在 SateHaze1k 数据集上的定性结果如图 5.7 所示。第一行和第二行是在 thin 测试集上的定性结果，第三行和第四行是在 moderate 测试集上的定性结果，第五

中国知网 https://www.cnki.net

行和第六行是在 thick 测试集上的定性结果。在 thin 测试集中，DCP 和 PFFNet 没有明显的去雾效果，在它们恢复的图像中遗留了大量的雾。AODNet 和 GridDehazeNet 具有一定的去雾效果，但在一些局部区域仍然存留少量的雾。FCTFNet 和 SCANet 具有明显的去雾效果，在它们恢复的图像中不能明显地发现遗留的雾。但与地面真实图像相比，它们恢复的图像更白，未能保留与地面真实图像一致的颜色特征。FFANet 很好的恢复了受薄雾遮挡的 RS 图像，然而它们在图像的部分区域去雾效果仍略有不足。如 FFANet 恢复的第一行图像左侧中间的草地和第二行图像下方中间的地面，相比地面真实图像，它们显得稍微更白。本章技术去雾彻底，恢复的图像与地面真实图像更接近，很好的提升了受薄雾遮挡的遥感图像质量。



(a) (b) (c) (d) (e) (f) (g) (h) (i) (j)

图 5.7 在 SateHaze1k 数据集上的定性结果

(a) 雾图 (b) DCP (c) AODNet (d) PFFNet (e) FCTFNet (f) GridDehazeNet (g) SCANet (h) FFANet (i) 本章技术 (j) 地面真实

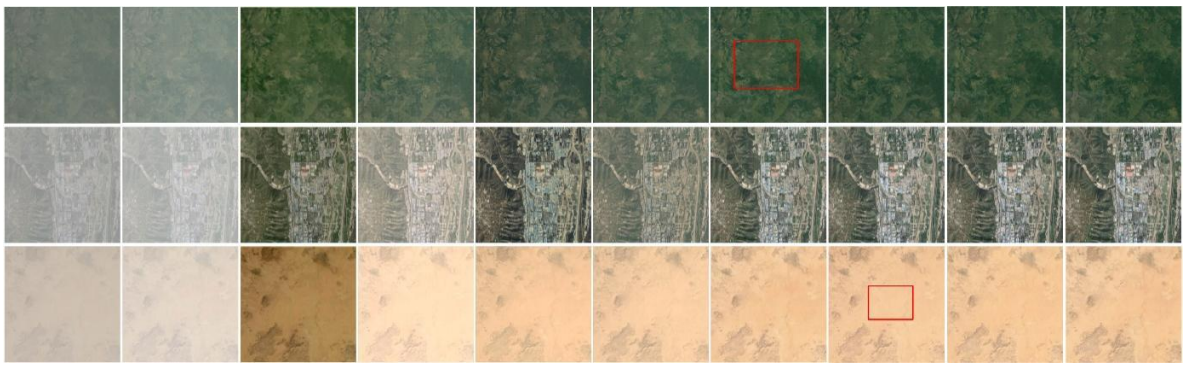
在 moderate 测试集中，DCP 的去雾性能一般，残留的雾仍然遮挡遥感图像大量的细节信息。AODNet 恢复的图像较暗，严重改变了图像原有的视觉外观。PFFNet 丢失了图像中局部区域的色彩信息。如在第三行中，地面真实图像中的蓝色屋顶被改变成深绿色。FCTFNet、GridDehazeNet、SCANet 和 FFANet 均展现了较好的去雾性能，有效的恢复了受到中等程度雾遮挡的遥感图像。然而，它们恢复的图像在一些区域的色彩和纹理保留方面，与地面真实图像有不同程度的差异。如在第三行中，FCTFNet 恢复的图像的右下角的红色屋顶，相比于地面真实图像表现的更红。在第四行中，GridDehazeNet 恢复的图像右侧中间的草地，相比于地面真实图像显得

中国知网 https://www.cnki.net

过于光滑，丢失了草地的纹理细节。在第四行中，SCANet 恢复的图像左侧中间屋顶更红，发生了色彩偏移现象。在第三行中，FFANet 恢复的图像中间偏右的草地上有一个明显的黑色阴影。本章技术在颜色和纹理保留方面与地面真实图像更为相似，很好的还原了受中等程度雾遮挡的遥感图像。

在 thick 测试集中，DCP 具有一定的去雾效果，但它恢复的图像仍然有大量的雾残留。AODNet、PFFNet 和 GridDehazeNet 发生了明显的颜色失真现象，未能较好的保留图像原有的色彩信息。FCTFNet 和 SCANet 取得了较好的去雾结果，然而它们恢复的图像相比于地面真实图像整体较白，且丢失了大量的纹理细节信息。例如在第五行中，FCTFNet 和 SCANet 恢复的图像左侧地面偏白。在第六行中，FCTFNet 和 SCANet 恢复的图像中间地面显得过于光滑，丢失了地面的纹理特征。FFANet 取得了很好的去雾结果，但与地面真实图像相比，它恢复的图像在局部区域略白。例如在第六行中，FFANet 恢复的图像中间地面较白。本章技术恢复的受到厚雾遮挡的遥感图像展现了与地面真实图像更为相似的结果，实现了更高程度的纹理和颜色等细节信息的还原，有效增强了遥感图像的质量。

每种技术在 RICE-I 数据集上的定性结果如图 5.8 所示。DCP 恢复的图像仍然受到大量的雾遮挡，图像质量较差。AODNet 发生了过度去雾现象，导致恢复的图像整体展现暗色调。PFFNet 恢复的图像整体较白，仍然残留了少量的雾。FCTFNet 颜色偏移程度较大。如在第一行中，它恢复的图像相比于地面真实图像显得更暗。GridDehazeNet 未能很好的保留图像的纹理细节信息。如在第二行中，它恢复的图像中间的房屋表现较为模糊。SCANet 和 FFANet 均取得了较好的去雾效果。然而 SCANet 恢复的图像的红色框位置相比于地面真实图像展现的绿色更浅。FFANet 恢复的图像的红色框位置相比于地面真实图像表现的较白。本章技术很好的保留了图像的纹理细节和局部颜色信息，恢复的图像与地面真实图像保持了极高的相似度，大幅度的提升了受云遮挡的遥感图像质量。



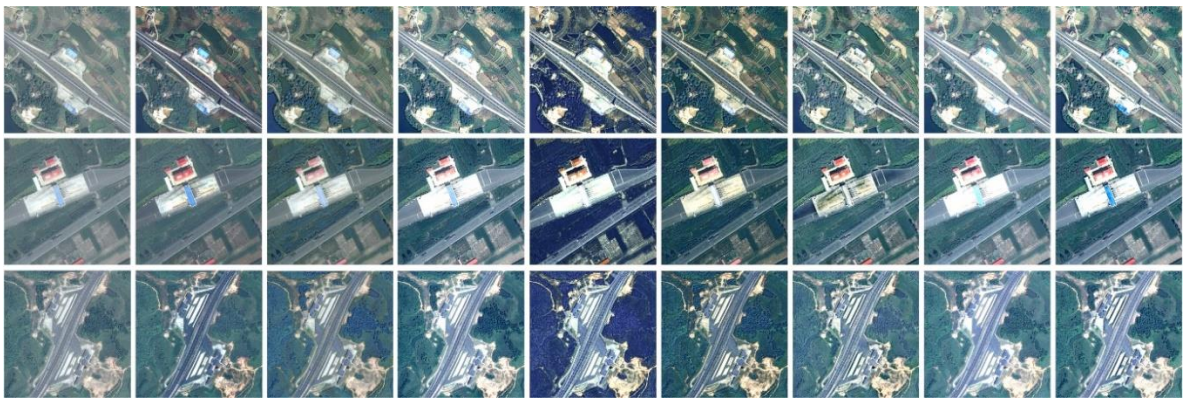
(a) (b) (c) (d) (e) (f) (g) (h) (i) (j)

图 5.8 在 RICE-I 数据集上的定性结果

(a) 雾图 (b) DCP (c) AODNet (d) PFFNet (e) FCTFNet (f) GridDehazeNet (g) SCANet (h) FFANet (i) 本章技术 (j) 地面真实

中国知网 https://www.cnki.net

为评估本章技术在真实遥感图像中去除云雾的效果，分别从 RRSD 数据集、AID[148]数据集和 UC Merced Land[149]数据集中选取模糊的遥感图像，这些模糊图像均是由于薄云或雾的遮挡而导致的图像退化。然后统一使用在 RICE-I 薄云数据集上训练的预训练模型对这些图像进行恢复。每种技术在 RRSD 数据集上的定性结果如图 5.9 所示。



(a) (b) (c) (d) (e) (f) (g) (h) (i)

图 5.9 在 RRSD 数据集上的定性结果

(a) 雾图 (b) DCP (c) AODNet (d) PFFNet (e) FCTFNet (f) GridDehazeNet (g) SCANet (h) FFANet (i) 本章技术

通过图 5.9 可以发现，DCP 和 GridDehazeNet 去雾过度，恢复后的图像较暗。与雾图相比，AODNet 恢复的图像去云效果不明显。FCTFNet 恢复的图像有明显的色彩失真。SCANet 恢复的图像出现局部色移现象，如第二排图像中间的屋顶由蓝色变为白色。PFFNet、FFANet 和本章技术都获得了良好的恢复效果。然而，PFFNet 和 FFANet 恢复的图像在局部区域有轻微的雾残留，例如第一行恢复图像中间的道路表现得略白。本章技术中的 MSICLB 通过有效地约束和学习云雾特征，使本章网络具有强大的云雾去除能力。通过本章技术恢复的图像看起来更清晰，具有出色的去雾性能。

每种技术在 AID 数据集上的定性结果如图 5.10 所示。DCP 复原的图像有大量的云残留，AODNet 复原的第一行图像明显丢失了纹理细节信息，FCTFNet 复原的第一行图像出现了色彩偏移，GridDehazeNet 复原的第二行图像中间的红色屋顶变白，SCANet 复原的第三行图像中间的蓝色集装箱纹理细节保留较差。PFFNet 和 FFANet 的复原效果较好，但是第三行复原的图像中间表现较白，且仍有少量云残留。本章网络中的 PCFCM 在接受原始输入信息的同时，通过双分支 3×3 卷积提取云雾信息，避免了大量的细节信息丢失。因此，本文技术在明显提升图像整体质量的同时，有效地保持了图像的颜色特征和纹理特征。

中国知网 https://www.cnki.net



(a) (b) (c) (d) (e) (f) (g) (h) (i)

图 5.10 在 AID 数据集上的定性结果

(a) 云图 (b) DCP (c) AODNet (d) PFFNet (e) FCTFNet (f) GridDehazeNet (g) SCANet (h) FFANet (i) 本章技术

每种去云雾技术在 UC Merced Land 数据集上的定性结果如图 5.11 所示。DCP 恢复的第三行图像无明显的去云效果，AODNet 和 GridDehazeNet 恢复的第二行图像道路上有更多的阴影。PFFNet 恢复的第一行图像显的模糊。FCTF-Net 和 FFANet 恢复的图像存在明显的色彩失真，例如它们恢复的第三行图像中的草地变成棕色。SCANet 的恢复效果更好，但是它恢复的第一行图像右上角的草地包含大面积的阴影。由于本章网络在 MSICLB 中引入了 FA，使得本章去云技术可以自适应地关注全局信息和与位置相关的局部信息。因此，本章技术恢复的图像更加清晰，并且对全局和局部细节的恢复都展现了更高的水平。



(a) (b) (c) (d) (e) (f) (g) (h) (i)

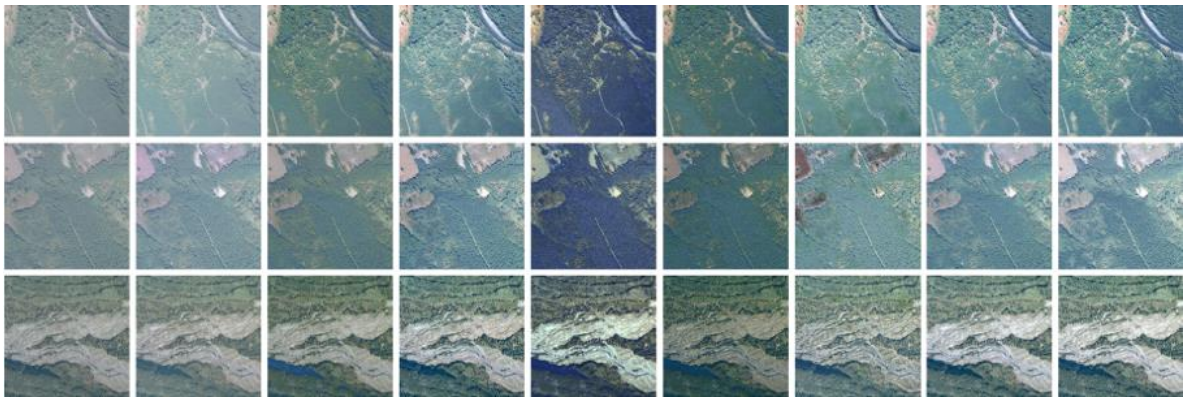
图 5.11 在 UC Merced Land 数据集上的定性结果

(a) 云图 (b) DCP (c) AODNet (d) PFFNet (e) FCTFNet (f) GridDehazeNet (g) SCANet (h) FFANet (i) 本章技术

为进一步证明本章技术在去除遥感图像云雾方面的泛化能力，笔者从美国地质调查局（United States Geological Survey，USGS）收集了真实遥感云图以进行定性结果比较。图 5.12 展示了每种技术在 USGS 图像上的定性结果。DCP 的去云处理能力最差。AODNet 和 GridDehazeNet 去云过度，它们恢复的图像显示较暗。SCANet 在局部区域产生较多阴影，例如其在第二行中恢复的图像。与云图相比，FCTFNet 恢

中国知网 https://www.cnki.net

复的图像颜色变化很大。PFFNet，FFANet 和本章技术都表现出优异的去云效果。然而，与 PFFNet 和 FFANet 相比，本章技术可以更完美地恢复图像的纹理细节，例如第一行中的草地。这要归功于本章网络中的 ICLM，由于它逐步的学习云雾特征，同时将浅层细节信息融入深层信息，实现图像中的纹理和其他精细细节的有效保留。



(a) (b) (c) (d) (e) (f) (g) (h) (i)

图 5.12 在现实世界中的定性结果

(a) 云图 (b) DCP (c) AODNet (d) PFFNet (e) FCTFNet (f) GridDehazeNet (g) SCANet (h) FFANet (i) 本章技术

5.3.4 参数量及计算量比较

每种神经网络模型的参数量和计算量如表 5.3 所示。从表中可以发现，本章网络模型的 Params 值少于 PFFNet，Flops 值少于 PFFNet，FFANet 和 GridDehazeNet。这一结果表明相比于大型复杂网络 PFFNet 和 FFANet，本章网络模型所需的硬件配置和内存需求相对较低。同时，结合定量和定性结果而言，由于在本章去雾技术中嵌入了较少的 MSICLB，且其结构较为简单，因此只需较少的参数量和计算量，就能具有高水平的云雾移除性能，得到高质量的清晰遥感图像。

表 5.3 每种网络模型的参数量及计算量

去雾技术	Params/$\times 10^6$	Flops/$\times 10^9$
DCP	—	—
AODNet	0.01	0.10
PFFNet	20.85	408.02
FCTFNet	0.16	35.32
GridDehazeNet	0.96	452.01
SCANet	2.39	31.04
FFANet	4.46	505.43
本章技术	9.81	321.66

5.4 消融研究

为验证本章去云雾网络及其组件的有效性，在 RICE-I 数据集上进行消融研究。为加快训练速度，将输入 RGB 图像大小裁剪为 72×72，其它配置本章实验细节保持一致。

中国知网 https://www.cnki.net

表 5.4 是在 RICE-I 数据集上进行的消融研究定量结果，加粗数字代表最佳结果。首先从 MSICLB 中移除 ICLM 和 PCFCM，将此时的网络作为基础网络，在表中用“Base”表示。其次将 ICLM 和 PCFCM 分别加入基本网络中，在表中分别表示为“Base+ICLM”和“Base+PCFCM”。接着将移除逐点卷积的 ICLM 加入 Base+PCFCM，此时 ICLM 在同一个通道中学习云雾特征，移除逐点卷积的 ICLM 模块命名为同通道模块（Same Channel Module，SCM），在表中表示为“Base+PCFCM+SCM”，SCM 结构如图 5.13 所示。再次将网络中的 ICLM 替换为 Inception 模块（其结构为图 2.20），在表中表示为“Base+Inception+PCFCM”。然后将网络中的 PCFCM 修改成串行云雾约束模块（Serial Cloud and Fog Constraint Module，SCFCM），在表中表示为“Base+ICLM+SCFCM”。最后将 ICLM 和 PCFCM 都加入 Base 中，在表中表示为“Base+ICLM+PCFCM”，此时网络为本章提出的网络。

表 5.4 在 RICE-I 数据集上的消融研究定量结果

去雾技术	PSNR	SSIM	LPIPS
Base	34.57	0.953	0.02
Base+ICLM	35.39	0.955	0.02
Base+PCFCM	35.28	0.954	0.02
Base+PCFCM+SCM	35.45	0.955	0.02
Base+Inception+PCFCM	35.66	0.955	0.02
Base+ICLM+SCFCM	35.38	0.955	0.02
Base+ICLM+PCFCM	**35.76**	**0.956**	**0.02**

ICLM 的有效性：“Base+ICLM”网络是在“Base”网络的基础上添加了提出的 ICLM。与“Base”网络相比，它的 PSNR 和 SSIM 值分别提高了 0.82dB 和 0.002。这一结果显著说明 ICLM 能够如同人脑对简单图像认知的逆过程来学习特征信息，从深度、中度和广度通道特征中约束云雾信息，增强网络的去云雾能力。此外，将网络中的 ICLM 替换为 Inception 模块后，在表 5.4 中表示为“Base+Inception+PCFCM”。与本章网络相比，它的 PSNR 和 SSIM 更低，分别降低了 0.10dB 和 0.001。这一结果表明与 Inception 模块相比，本章提出的 ICLM 更适用于图像去云雾任务。值得注意的是，该消融研究是在图像大小为 72×72 的情况下进行，随着图像尺寸的增大，ICLM 将会进一步展现出比 Inception 模块更佳的学习性能。

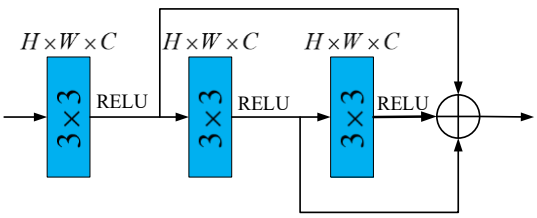


图 5.13 同通道模块结构图

PCFCM 的有效性：“Base+PCFCM”网络是在“Base”网络的基础上添加了提出

中国知网 https://www.cnki.net

的 PCFCM。与“Base”网络相比，其 PSNR 和 SSIM 分别提高了 0.71dB 和 0.001。这一结果表明提出的 PCFCM 能够对云雾形成较强的约束，从而有效提高网络的去云雾效果，增强图像的细节恢复。此外，笔者建立了一个 PCFCM 的变体结构 SCFCM 进行实验，其结构如图 5.14 所示。该模块将 3×3 卷积依次连接起来以约束云雾特征。与本章网络相比，其 PSNR 和 SSIM 值分别降低了 0.38dB 和 0.001。这一结果表明本章设计的具有双分支并行结构的 PCFCM 具有更好的云雾约束性能。

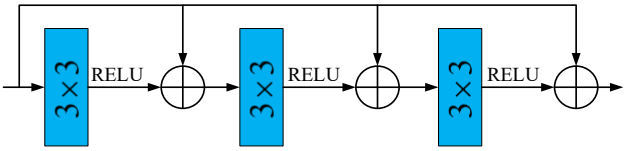


图 5.14 串行云雾约束模块结构图

MSICLB 与本章网络的有效性：在 Base 网络中添加 ICLM 和 PCFCM 后，此时网络中包含本章构建的 MSICLB，网络为本章提出的网络。结果表明本章提出的 MSICLB 通过提取图像的多尺度信息、增强细节信息、从不同深度和广度约束云雾、兼顾全局和局部特征，有效提升了网络的去云雾能力。本章网络取得了最佳的 PSNR 和 SSIM 值。为进一步验证本章设计的 MSICLB 的重要作用，通过“Base+PCFCM+SCM”网络进行去雾，其 PSNR 和 SSIM 值分别比本章网络结果低 0.31dB 和 0.001。这一结果不但充分证明了 ICLM 模拟人脑学习的逆过程的成功，而且展示了 ICLM 和 MSICLB 抑制云雾信息的出色能力，可以有效提升遥感图像的质量。

5.5 本章小结

在本章工作中，提出了一种新颖的用于去除遥感图像中薄云和雾的逆认知学习网络。该网络主要由编码器、瓶颈层、解码器和软重建组成。编码器、解码器和瓶颈层中的核心组件是本章提出的多尺度逆认知学习块。多尺度逆认知学习块集成了模拟人脑逆认知学习过程的逆认知学习模块、对云雾信息进行有力约束的并行云雾约束模块和能够自适应关注通道特征和像素特征的特征注意力。因此，多尺度逆认知学习块能够灵活的对不均匀分布的云雾信息进行有效关注，逐步地从深度、中度和广度通道特征上学习云雾信息，实现纹理等细节信息的有效增强。在 SateHaze1k 和 RICE-I 公开遥感图像数据集上的实验表明，本章提出的逆认知学习网络实现了最先进的去雾效果，去雾彻底、纹理信息保留较好，与地面真实图像最为相似，恢复的遥感图像更加自然、真实。通过消融研究，验证了本章提出的不同模块的有效性，这些模块能够较好的提升网络的去雾性能。

中国知网 https://www.cnki.net

第 6 章 基于门控融合 Transformer 的水下图像复原技术研究

由于水下环境的复杂性，其复原难度要比恢复受大气散射介质干扰的图像更为困难，因此本章进一步对水下场景退化图像复原技术进行研究。在本章中，首先阐述了基于门控融合 Transformer 的水下图像复原技术提出的背景其次对该技术及其相关组件进行了详细说明，包括网络的总体结构、门控融合 Transformer 块及其组件、门控融合连接器。然后通过实验验证了提出的门控融合 Transformer 水下图像复原技术的有效性，实验包括在合成水下图像数据集和真实水下图像数据集的定量和定性试验、以及消融实验。最后对本章阐述的主要内容进行总结。

6.1 引言

海洋面积广阔，占据地球表面积的 70%左右，富含大量的矿产资源和生物资源，探索并开发海洋资源越来越引起世界范围的重视。水下图像复原技术对水下探索至关重要，其广泛的被应用于海底考古，海底资源开发和海底电缆维护等任务中[150]。然而，由于复杂的水下环境以及面临的光照不足，光发生的吸收和散射作用严重等问题，导致采集的图像存在色彩失真和细节模糊等质量问题，降低了图像的互操作性，增大了从水下图像中获取有价值信息的难度[151]。

因此为解决水下图像存在的颜色失真和模糊等问题，尽可能的获取高质量水下图像，本章提出了基于门控融合 Transformer（Gated Fusion Transformer，GF-Former）的水下图像复原技术，将 Transformer 模型与卷积神经网络有效结合，从而实现在提取全局信息的同时增强对局部细节的关注。基于门控融合的 Transformer 模型是一个 U-Net 型网络，其主要由设计的门控融合 Transformer 块（Gated Fusion Transformer，GF-Trans Block）和门控融合连接器（Gated Fusion Connection Machine，GFCM）组成。GFCM 是一个以 CNN 为基础而设计的模块，能够更为有效的提取浅层局部细节信息并将其融合至深层。GF-Trans Block 将引入的通道自注意力（Channel Self-Attention，CSA）、移位窗口像素自注意力（Shifted Window Pixel Self-Attention，SW-PSA）与设计的注意力前馈网络（Attention Feedforward Network，AFN）和深层环境适配器（Deep Environment Adaptor，DEA）进行有效结合，实现了对水下图像有价值信息的有效提取。在 AFN 中，将注意力机制的空间和通道挤压与激励（Spatial and Channel Squeeze & Excitation，SCSE）模块与门控前馈网络（Gated-Dconv Feed-forward Network，GDFN）结合，以进一步加强对有用信息的关注。为适应复杂水下环境的需求，通过 DEA 来深入提取信息并提升特征图的灵活性。综合而言，本章主要贡献如下：

中国知网 https://www.cnki.net

(1) 提出了一种新颖的注意力前馈网络，该网络能够对空间和通道特征进行不平等关注，增强有用信息的权重并对信息流进行整合，以实现不同层级信息之间的互补。

(2) 提出了一种新颖的深层环境适配器，该适配器能够进一步深入的提取特征并灵活的应对复杂环境，提升网络自适应水下环境的能力。

(3) 提出了一种新颖的门控融合连接器，通过该连接器替换传统的跳跃连接方式，将门控融合 Transformer 块提取的浅层信息传递至深层，提升局部细节信息的有效利用。

(4) 提出了一种新颖的基于门控融合 Transformer 的水下图像复原网络，该网络以门控融合 Transformer 块为核心组件，实现了水下图像质量的有效提升。在合成和真实水下图像数据集上进行实验，提出的基于门控融合 Transformer 的水下图像复原技术优于其它先进技术，复原图像与参考水下图像更为接近。

6.2 网络架构设计

本章设计的门控融合 Transformer 水下图像复原网络是一种 U-Net 型网络架构，主要由3×3卷积、GF-Trans Block、GFCM、下采样和上采样组成，其架构如图 6.1 所示。

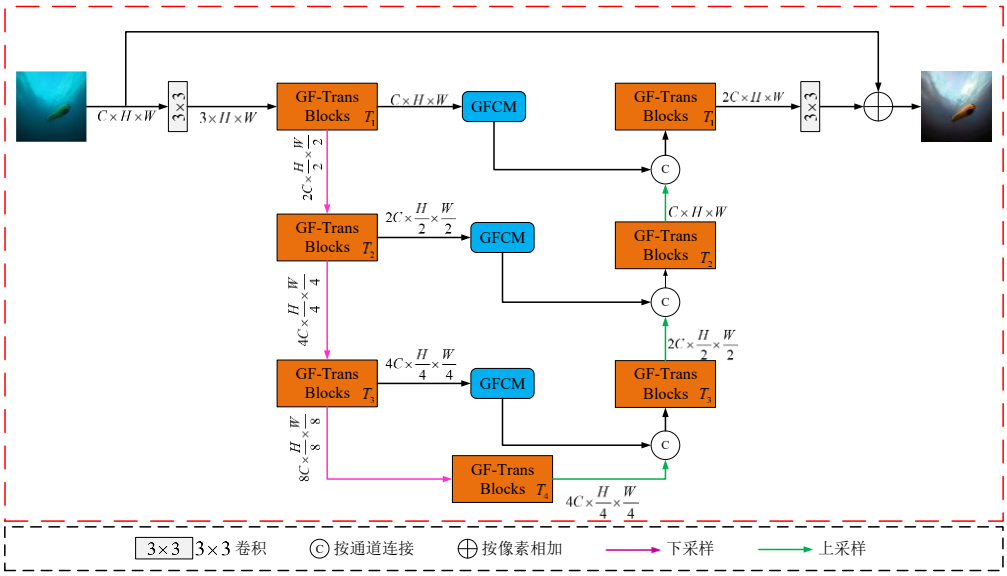


图 6.1 门控融合 Transformer 网络架构图

退化的 RGB 水下图像 $I_{UW}\in R^{3\times H\times W}$ 首先通过一个3×3卷积提取浅层特征并将其大小转换为 $C\times H\times W$，其中 C 表示特征图通道数，$H\times W$ 为空间维度。然后将这一浅层特征依次传递到 GF-Trans Block 中，在每个 GF-Trans Block 之间穿插了下采样和上采样。下采样用于降低分辨率、增加通道数，减少计算量。上采样用于特征重建，恢复缺失的信息。其中，在 T_4 阶段中的 GF-Trans Block 中，嵌入了设计的深层环境适

中国知网 https://www.cnki.net

配器，以增强网络对复杂水下环境的适应性。为保证浅层中有价值的特征信息传递到深层，通过 GFCM 连接浅层网络和深层网络，从而实现浅层细节信息的提取及其与深层信息的融合。最后利用一个 3×3 卷积和跳跃连接来重建图像，从而得到复原的清晰水下图像。

6.2.1 门控融合 Transfomer 块

由于水体对不同波长光的吸收和散射作用，使得水下图像部分颜色通道信息丢失严重，不同通道特征存在不同的加权信息。此外，退化的水下图像一般分布不均匀，退化程度较低的区域对应的权重与退化程度严重的区域像素差异较大。因此，受 Shen 等人[92]的启发，在本章提出的 GF-Trans Block 中同样引入了通道自注意力和移位窗口像素自注意力，以实现对通道特征和像素特征的双重关注，其它主要组件还包括深层环境适配器、层归一化（Layer Norm）、全局平均池化（AvgPool）和注意力前馈网络。其结构如图 6.2(a)所示。

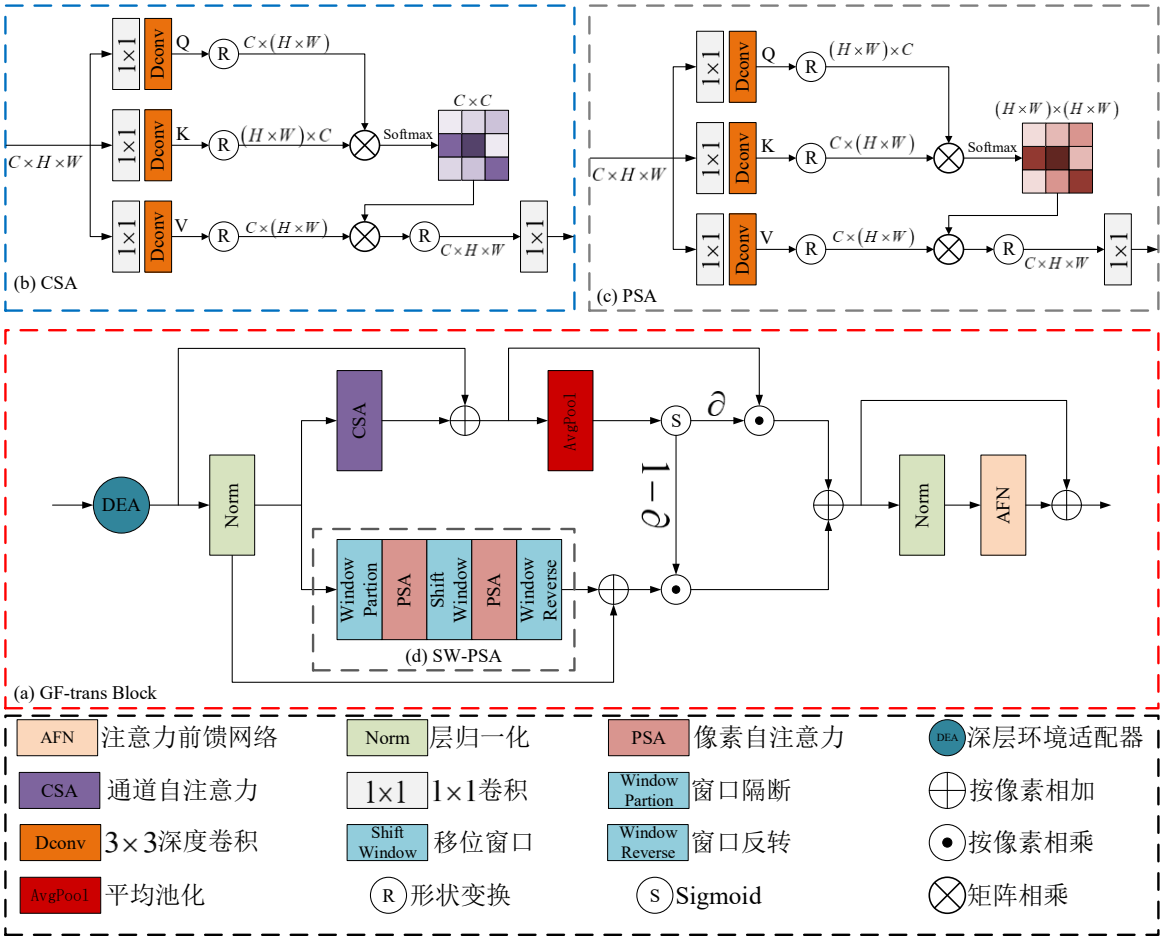


图 6.2 门控融合 Transformer 块结构及其组件图

(a) GF-Trans Block 结构图 (b) 通道自注意力 (c) 像素自注意力 (d) 移位窗口像素自注意力

与常规的 Transformer 结构不同，本章提出的 GF-Trans Block 的输入信息首先流

中国知网 https://www.cnki.net

入 DEA 中，以灵活的学习复杂的水下环境特征。其次在自注意力机制中，通过并行的 CSA 和 SW-PSA 分别对通道维度特征和像素维度特征进行有效关注。然后获取的通道特征和像素特征并不是通过简单的相加方式进行融合，而是先对通道特征取平均值，再通过 Sigmoid 函数获取权重参数∂，将通道特征和像素特征分别与∂和$1-\partial$相乘，以实现通道特征和像素特征的有效融合，提升水下图像复原的效果。最后使用本章提出的 AFN 替换常规的具有连接层的前馈网络，增强对局部细节特征的学习能力。下面分别对 GF-Trans Block 中的主要组件 CSA、SW-PSA、DEA 和 AFN 进行介绍。

(1) 通道自注意力

CSA 结构如图 6.2(b)所示，首先在 CSA 中生成查询（Query, Q），键(Key，K)和值（Value, V）投影。为降低计算复杂度并使网络自适应输入图像的大小，将卷积嵌入到 CSA 中，用来强调上下文信息。Q、K 和 V 的定义如式(6-1)所示：

$$\mathrm{Q,K,V} = Dconv_{\mathrm{Q,K,V}}\left(Conv_{\mathrm{Q,K,V}}\left(F_C^*\right)\right) \tag{6-1}$$

其中，$Conv$ 表示逐点卷积，$Dconv$ 表示 3×3 深度卷积，F_C^* 表示 CSA 的输入特征。获取 Q、K 和 V 后，通过形状变换转换它们的形状，最终 CSA 的定义如式(6-2)所示：

$$CSA\left(\mathrm{Q,K,V}\right) = Conv\left(\mathrm{Softmax}\left(\frac{\mathrm{QK}^T}{\sqrt{d}}\right)\cdot V\right) \tag{6-2}$$

其中，$\mathrm{Q,K,V} \in R^{C\times HW}$，$d$ 表示可学习的缩放参数。

(2) 移位窗口像素自注意力

像素自注意力（Pixel Self-Attention，PSA）一般在局部窗口内计算，窗口通过不重叠的方式均匀的分割图像，由于基于窗口的 PSA 缺失了跨窗口的连接，导致建模能力受到限制，PSA 的结构如图 6.2(c)所示。因此，为实现跨窗口连接，使窗口与窗口之间进行通信，本章引入了 SW-PSA，交替使用常规窗口（Regular Window，RW）和SW-PSA，获取退化水下图像的局部区域特征信息，其结构如图6.6(d)所示。移位窗口像素自注意力中的 Q、K、和 V 的计算与通道自注意力的计算方式类似，其 Q、K、V 的定义如式(6-3)所示：

$$\mathrm{Q,K,V} = Conv_{\mathrm{Q,K,V}}\left(Dconv_{\mathrm{Q,K,V}}\left(F_P^*\right)\right) \tag{6-3}$$

其中，$Conv$ 表示逐点卷积，$Dconv$ 表示 3×3 深度卷积，F_P^* 表示 PSA 的输入特征。计算出 PSA 的 Q、K、和 V 值之后，PSA 的定义如式(6-4)所示：

$$PSA\left(\mathrm{Q,K,V}\right) = Conv\left(\mathrm{V}\cdot\mathrm{Softmax}\left(\frac{\mathrm{Q}^T\mathrm{K}}{\sqrt{s}}\right)\right) \tag{6-4}$$

中国知网 https://www.cnki.net

其中，s 表示输入特征的分辨率。

图 6.3 展示了移位窗口的变换过程，首先对常规窗口进行隔断（Partion），以计算局部窗口的像素自注意力。其次，通过移动边缘像素获得移位窗口，以实现跨窗口连接，并在移位窗口中计算 PSA。SW-PSA 过程如式(6-5)和(6-6)所示：

$$P = \mathrm{PSA}\left(RW\left(F_P^*\right)\right) \tag{6-5}$$

$$S = WR\left(\mathrm{PSA}\left(SW\left(P\right)\right)\right) + F_P^* \tag{6-6}$$

其中，RW 表示常规窗口，WR 表示反向窗口，SW 表示移位窗口。在 SW-PSA 中，首先计算常规窗口下的像素自注意力，然后对常规窗口进行变换，得到移位窗口。与 Swin-Transformer[152]相似，对 SW-PSA 执行掩码（Mask）操作，以控制划分的块之间的信息交互，避免不必要信息的传递，提升计算效率。

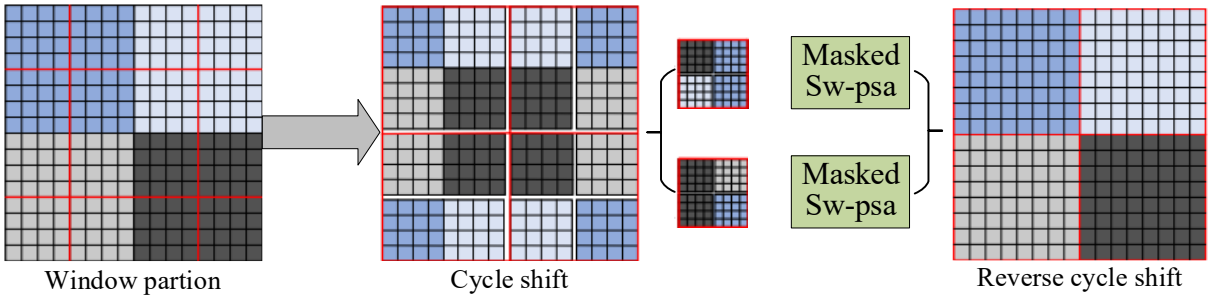


图 6.3 移位窗口像素自注意力过程图
(a) 窗口隔断 (b)循环移位 (c)逆循环移位

(3) 深层环境适配器

Wen 等人[93]为处理各种水下环境中退化的图像，提出了环境适配器（Environment Adaptor，EA）来灵活适应不同的水下环境，在水下图像复原任务中取得了较好的效果，其结构如图 6.4 所示。适配器的核心是形状为 $E \times C$ 的可学习环境嵌入，其中 E 是可能的环境类型数，C 是深度特征维度。深度特征首先从可学习的环境嵌入中经过选择过程，在线性层（Linear）和 Softmax 处理后与环境对齐。随后，将选定的环境嵌入与深度特征逐像素相乘并作为偏差项进行积分。该方法能够提高特征图的灵活性，有助于提高水下图像复原性能。

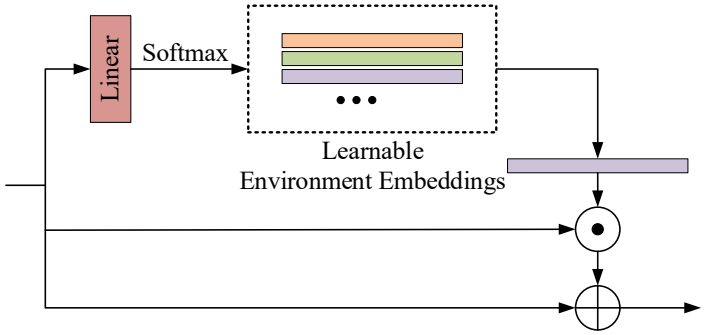


图 6.4 环境适配器结构图

中国知网 https://www.cnki.net

本章考虑环境适配器仅仅处理了在 Transformer 模型中提取的全局信息，忽视了局部细节信息。因此，以环境适配器为基础，结合卷积神经网络，进一步设计了 DEA，其结构如图 6.5 所示。令深层环境适配器的输入为 F_{dea}^{*}，首先通过3×3 卷积提取局部特征。

$$F_{dea}^{1}=conv\left(F_{dea}^{*}\right) \tag{6-7}$$

其中，$conv$ 表示3×3 卷积。然后将获得的特征 F_{dea}^{1} 分两条支路传递。一条支路经过环境适配器以适应并灵活学习复杂的水下图像特征。另一条支路经过两个3×3 卷积和 SELU 激活函数增加网络深度，通过 Sigmoid 函数分配权重后，与原始输入特征相乘，以增强对原始输入特征重要局部信息的关注，提升网络的表征能力。

$$\begin{aligned} F_{dea}^{2}&=F_{EA}\left(F_{dea}^{1}\right)\\ F_{dea}^{3}&=F_{dea}^{*}\times\varepsilon\left(conv\left(\mathrm{SELU}\left(conv\left(F_{dea}^{1}\right)\right)\right)\right) \end{aligned} \tag{6-8}$$

其中，ε 表示 Sigmoid 激活函数。最后将两条支路上获得的特征相加，从而实现深层局部特征对环境适配器获取的特征的有效补充。

$$F_{dea}=F_{dea}^{2}+F_{dea}^{3} \tag{6-9}$$

其中，F_{dea} 是深层环境适配器的输出特征。

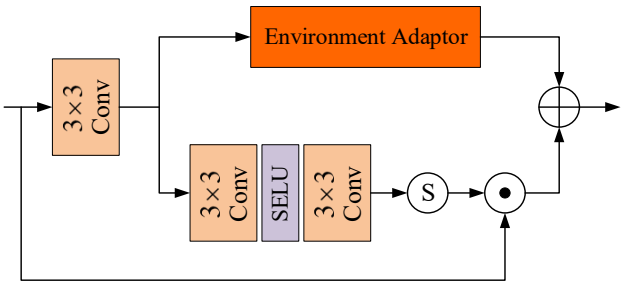


图 6.5 深层环境适配器

(4) 注意力前馈网络

以往的前馈网络多是针对每个像素位置独立的执行相同操作。一般使用两个1×1 卷积，一个用于成倍数的增加通道数量，另一个用于将通道压缩回输入维度，同时在隐藏层中使用非线性。Zamir等人[153]对前馈网络进行了改进，提出了GDFN，他们通过门控机制和深度卷积（Depth-wise Convolution，DConv）来学习图像的局部结构，在图像超分辨率任务中取得了较好的效果，其结构如图 6.6(b)所示。然而由于水下环境复杂，图像细节特征损失较为严重。单纯的 GDFN 难以弥补细节信息的损失，因而本章进一步设计了 AFN。该网络包含 SCSE 模块和 GDFN，如图 6.6 所示。SCSE 模块的结构如图 6.2(a)所示，它被用来对空间维度特征和通道维度特征进行自适应关注，将输入信息流进行整合，增强有用细节信息的权重，再将信息流传递至门控前馈网络。GDFN用来控制各个层的信息流，能够实现不同层与其它层细节的互

中国知网 https://www.cnki.net

补。从而 AFN 能够最大程度的有效学习水下图像细节特征，其过程如式(6-10)所示：

$$F_{AFN} = \mathrm{GDFN}\left(\mathrm{SCSE}\left(F_{AFN}^{*}\right)\right) \tag{6-10}$$

其中 F_{AFN}^{*} 为注意力前馈网络的输入特征，F_{AFN} 为输出特征。

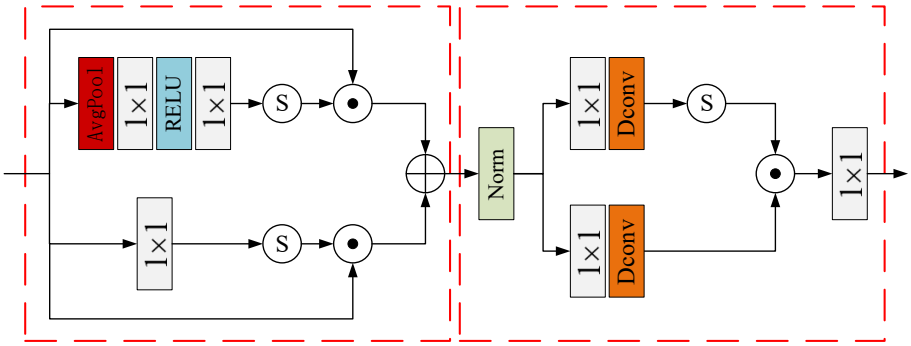


图 6.6 注意力前馈网络结构图
(a) 空间和通道挤压与激励模块 (b) 门控前馈网络

6.2.2 门控融合连接器

在大多数的 U-Net 型网络结构中，一般通过跳跃连接将浅层信息传递到深层，以保留细节信息。然而在以 Transformer 模型为基础的 U-Net 型网络结构中，更多的是处理图像全局信息，忽视了局部细节信息，仅仅通过跳跃连接来维持此种网络模型中细节信息的传递，难以获得理想的效果。

为解决这一问题，本章提出了一个简单的门控融合连接器，将浅层的关键局部细节信息传递至深层网络中。相比跳跃连接，这一传递方式能够更好的恢复水下图像的细节，在 6.4 节中证明了该连接器的有效性，其结构如图 6.7 所示。

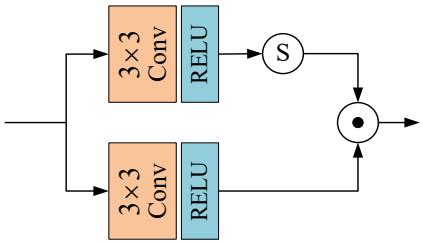


图 6.7 门控融合连接器

由于卷积神经网络能够更有效的捕获局部特征，因此设计的 GFCM 主要以 CNN 为基础，将其与 Transformer 结合使用，以解决 Transformer 模型对局部细节信息忽视的问题。令 GFCM 的输入特征 $F_{GFusion}^{*}$ 分两条支路进行传递，首先在两条支路中均通过 3×3 卷积和 RELU 函数提取浅层关键局部细节信息。

$$\begin{aligned} F_1 &= \mathrm{RELU}\left(conv\left(F_{GFusion}^{*}\right)\right) \\ F_2 &= \mathrm{RELU}\left(conv\left(F_{GFusion}^{*}\right)\right) \end{aligned} \tag{6-11}$$

中国知网 https://www.cnki.net

其中，*conv*表示3×3卷积，然后其中一条支路利用Sigmoid函数获取关键局部细节特征的权值，控制信息的流动。

$$w = \varepsilon \times F_1 \tag{6-12}$$

其中，ε表示 Sigmoid 函数。最后将这一权值w与另一条支路的细节特征相乘并输出，从而实现对关键局部细节信息的有效控制。

$$F_{GFusion} = w \times F_2 \tag{6-13}$$

6.2.3 损失函数

为训练本章提出的水下图像复原技术，组合使用 L1 损失和结构相似度损失作为整个训练过程的总损失函数，其定义如式(6-14)所示：

$$\varsigma = \varsigma_{L1} + \varsigma_{SSIM} \tag{6-14}$$

其中，ς_{L1}表示 L1 损失，ς_{SSIM}表示结构相似度损失。

在多数的图像到图像转换模型中，一般利用像素级差异（如均方误差或 L1 损失函数）进行训练。由于 L1 损失的值与 SSIM 损失函数更具兼容性，因此直接使用 L1 损失，如式(6-15)所示：

$$\varsigma_{L1} = \left\| \hat{G} - G \right\|_1 \tag{6-15}$$

其中，G表示参考水下图像，$\hat{G}$表示恢复的水下图像。

尽管基于像素级差异的损失函数容易使模型实现更高的峰值信噪比，然而此类方法一般存在伪影，会使恢复的水下图像细节过于平滑。因此为解决此问题，同时考虑对比度和结构等高级别的信息，使用了 SSIM 损失函数。更为准确的说，为计算恢复的水下图像和参考水下图像之间的结构和纹理相似性，结合使用了 SSIM 相似度得分，其定义式如式(6-16)所示：

$$\mathrm{SSIM}(m,n) = \frac{(2u_{\mathrm{m}}u_{\mathrm{n}} + C_1)(2\sigma_{mn} + C_2)}{(u_m^2 + u_n^2 + C_1)(\sigma_m^2 + \sigma_n^2 + C_2)} \tag{6-16}$$

其中，u_m和u_n分别表示参考水下图像和生成水下图像之间的平均值，σ_m和σ_n表示两图像间的标准差，σ_{mn}表示协方差，C_1和C_2为常数。因此 SSIM 损失可用式(6-17)表示：

$$\tau_{SSIM} = 1 - \mathrm{SSIM}(m,n) \tag{6-17}$$

6.3 实验验证与结果分析

在本节中，详细描述了实验中所使用的数据集和相关实验细节，将本章技术与其他先进水下图像复原技术进行比较，并对本章技术进行消融研究。

中国知网 https://www.cnki.net

6.3.1 数据集选择和相关实验细节

本章在公开的水下图像数据集 UIEB 数据集和 LSUI 数据集中进行训练和测试。UIEB 数据集包含 890 张水下图像及其对应的参考图像。本章从 UIEB 数据集中随机选取 800 张图像作为训练集，剩余 90 张图像作为测试集，重新命名为 Test90 测试集。LSUI 数据集包含 4279 张水下图像及其对应的参考图像，随机选取其中 3879 张图像作为训练集，剩余 400 张图像作为测试集，命名为 Test400 测试集，以进行全参考质量的评估。为进一步证明本章水下图像复原技术有效的泛化能力，利用 U45、UPoor200 和 UIEB 中具有挑战性的测试数据集进行无参考质量评估测试。其中 UIEB 中具有挑战性的测试集包含 60 张质量较差的水下图像，将该测试集记为 U60。U45 中包含 45 张图像，图像中存在蓝色、绿色和雾霾等多个水下场景。UPoor200 是从互联网收集和整理的数据集，包含 200 幅视觉质量较差的真实水下图像。

在训练和测试过程中，本章水下图像复原网络在 NVIDIA RTX8000 GPU 上运行，通过 Pytorch 框架实现，所有图像分辨率大小均被调整为256×256。训练时采用 AdamW 优化器（$\beta_1=0.9,\beta_2=0.999$, 权重衰减为$1\times10^{-4}$），初始学习率设置为$3.0\times10^{-4}$，通过余弦退火策略逐渐降低到$1.0\times10^{-6}$，总计训练 1500 个 epoch。通过渐进式学习方式[153]，从128×128的块大小和 64 的批大小开始训练，然后逐步扩展块尺寸，同时减小批大小。在本章技术中，设置$[T_1,T_2,T_3,T_4]=[2,2,2,2]$，$T_i\,(i=1,2,3,4)$表示依次连接 GF-Trans Block 的个数。它们相对应的自注意力头数和通道数分别设置为$[1,2,4,8]$和$[32,64,128,256]$。需注意的是，本章技术仅在T_4阶段对应的 GF-Trans Block 中使用了提出的深层环境适配器。

6.3.2 定量比较

将本章提出的水下图像复原技术与以下七种先进的水下图像复原技术进行比较。其中包括GDCP[67]和Fusion[68]两种传统技术，WaterNet[76]、Ucolor[78]和Shallow[77]三种基于卷积神经网络技术以及UShape[90]和WaterFormer[93]两种基于Transformer模型技术。为尽可能的进行公平比较，本章使用作者公开的官方代码在UIEB训练集和LSUI训练集上对基于学习的复原技术进行训练。评价指标不仅使用PSNR、SSIM和LPIPS对Test90和Test400进行了全参考评估，而且使用UIQM和UCIQE对U45、U60和UPoor200数据集进行了无参考质量评价。

表 6.1 展示了不同水下图像复原技术在 Test90 和 Test400 测试集的全参考定量评估结果。其中粗体、下划线和斜体数字分别表示最佳、次佳和最差结果。GDCP 在两个数据集上均取得了最差的 PSNR、SSIM 和 LPIPS，表明在水下图像复原任务表现不佳，难以恢复高质量的水下图像。相比于其他方法，WaterFormer 取得了次佳的成

中国知网 https://www.cnki.net

绩，然而在 Test90 数据集上 Ucolor 的 PSNR 值略优于它。本章技术取得了最佳的复原性能，尽管在 Test400 数据集上的 LPIPS 值略差于 WaterFormer，但是它的 PSNR 值突破了 26.5dB，在两个数据集上表现的整体性能远优于其它复原技术。

表 6.1 在 Test90 和 Test400 测试集上的定量结果

复原技术	Test90			Test400		
	PSNR	SSIM	LPIPS	PSNR	SSIM	LPIPS
GDCP	*13.188*	*0.768*	*0.252*	*13.724*	*0.745*	*0.310*
Fusion	22.507	0.918	0.093	18.944	0.849	0.210
WaterNet	20.816	0.900	0.105	22.699	0.897	0.164
Ucolor	23.020	0.919	0.086	21.486	0.882	0.169
Shallow	18.735	0.820	0.216	22.107	0.866	0.206
UShape	20.864	0.845	0.136	25.068	0.878	0.103
WaterFormer	22.987	0.923	0.083	25.998	0.937	**0.079**
本章技术	**23.34**	**0.925**	**0.079**	**26.570**	**0.938**	0.081

表 6.2 展示了不同水下图像复原技术在 U45、U60 和 UPoor 数据集上的无参考定量评估结果。其中粗体、下划线和斜体数字分别表示最佳、次佳和第三名的结果。可以发现，基于学习的方法 UShape、Shallow 和 Ucolor 在三个数据集上的 UIQM 分别取得了前三名的效果，但是本章技术的 UIQM 与它们的结果相差不大，如在 U45 数据集上本章技术的 UIQM 仅比取得最佳的 UShape 方法低 0.092。传统水下图像复原技术在 UCIQE 指标上取得了较好的成绩，在 U60 和 UPoor 数据集上分别名列第一和第二，本章技术取得了第三的成绩。仅比较基于学习的技术，本章技术在 UCIQE 上均取得了最佳结果。

表 6.2 在 U45、U60 和 UPoor 数据集上的定量结果

复原技术	U45		U60		UPoor	
	UIQM	UCIQE	UIQM	UCIQE	UIQM	UCIQE
GDCP	2.245	0.532	1.999	0.544	2.032	**0.559**
Fusion	2.764	**0.577**	1.923	**0.549**	2.260	0.556
WaterNet	3.033	0.503	2.157	0.483	2.480	0.485
Ucolor	*3.100*	0.516	*2.165*	0.481	*2.564*	0.502
Shallow	3.105	0.466	2.280	0.442	2.690	0.447
UShape	**3.121**	0.518	**2.715**	0.499	**2.908**	0.509
WaterFormer	3.019	*0.548*	2.041	0.514	2.342	0.536
本章技术	3.029	0.554	2.076	*0.517*	2.366	*0.538*

综合分析表 6.1 和表 6.2，本章技术在合成水下图像数据集上取得了最佳结果，传统方法 GDCP 表现最差。而在真实水下图像数据集上，尽管本章技术在基于学习的技术中的 UIQM 指标上表现一般，但在 UCIQE 值方面均取得了最佳结果。综合而言，本章水下图像复原技术整体性能更为稳定，整体结果优于其他先进的水下图像复原技术。

中国知网 https://www.cnki.net

6.3.3 定性比较

在本节中，将本章技术与其它七种先进的水下图像复原技术在公开的水下图像数据集上进行了定性比较。

图 6.8 展示了不同技术在 Test90 测试集上的定性结果。GDCP 存在明显的曝光严重现象。Fusion 恢复出了清晰的图像，但视觉效果与地面真实图像差异较大。WaterNet 和 Shallow 恢复的第一行图像仍然显的较为模糊，恢复效果一般。Ucolor 局部细节恢复效果一般，如它恢复的第二行图像下方的圆盘状物体颜色与地面真实图像颜色有较大差异。UShape 恢复的第三行图像背景颜色较暗。WaterFormer 存在轻微的颜色偏移现象，如它恢复的第二行图像左上角的海水背景显的较白。本章技术无论在背景颜色还是局部细节方面都展现了良好的恢复性能，尤其恢复的第二行和第三行图像，与参考图像基本相似。



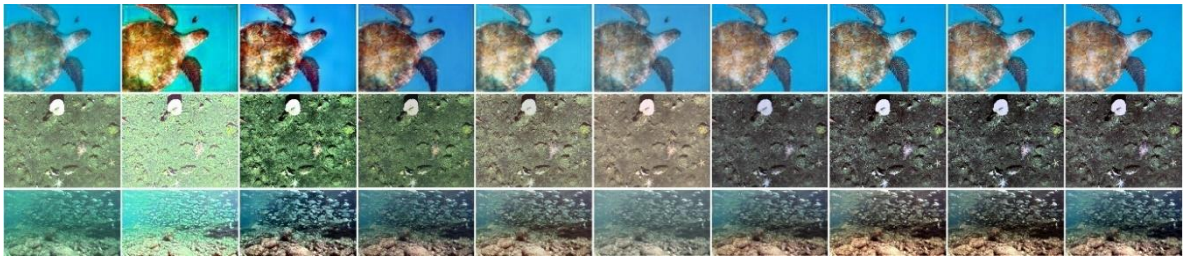
(a) (b) (c) (d) (e) (f) (g) (h) (i) (j)

图 6.8 在 Test90 测试集上的定性结果

(a) 原图 (b) GDCP (c) Fusion (d) WaterNet (e) Ucolor (f) Shallow (g) UShape (h) WaterFormer (i) 本章技术 (j) 参考图像

图 6.9 展示了不同技术在 Test400 测试集上的定性结果。通过图 6.9 可以发现，GDCP 曝光严重，图像质量一般。Fusion 和 WaterNet 未能解决恢复的第二行水下图像呈现为绿色的问题。Ucolor 和 Shallow 发生明显的色偏现象，如它们恢复的第二行图像与地面真实图像差异较大。UShape 恢复的图像依旧带有一定的模糊问题，它们比地面真实图像显的略白。WaterFormer 和本章技术均取得了较好的复原结果，但是相比参考图像，本章技术恢复的图像比 WaterFormer 具有更多的纹理细节，如恢复的第一行图像海龟的龟背，第三行图像中的鱼群。本章技术在复原水下图像细节、颜色恢复等方面明显优于其它先进技术。

中国知网 https://www.cnki.net



(a) (b) (c) (d) (e) (f) (g) (h) (i) (j)

图 6.9 在 Test400 测试集上的定性结果

(a) 原图 (b) GDCP (c) Fusion (d) WaterNet (e) Ucolor (f) Shallow (g) UShape (h) WaterFormer (i) 本章技术 (j) 参考图像

图 6.10 展示了不同技术在 U45 数据集上的定性结果。GDCP 恢复的图像明显质量最差。Fusion 恢复的图像有较高的对比度，但它们明显现实场景不匹配，且发生了局部色彩偏移现象，如恢复的第二行图像海龟下面的水表现为粉色。Shallow 恢复的图像整体显的较为模糊。WaterNet、Ucolor 和 WaterFormer 在恢复的第一行图像中还略微偏向于绿色，未能很好的处理水下绿色图像复原问题。UShape 和本章技术都取得了较好的视觉效果，然而相比于本章技术恢复的第三行图像，UShape 恢复的图像整体上表现更为模糊。本章技术解决了水下图像的颜色偏移和细节模糊问题，很好的提升了水下图像视觉性能。



(a) (b) (c) (d) (e) (f) (g) (h) (i)

图 6.10 在 U45 数据集上的定性结果

(a) 原图 (b) GDCP (c) Fusion (d) WaterNet (e) Ucolor (f) Shallow (g) UShape (h) WaterFormer (i) 本章技术

图 6.11 展示了在 U60 数据集上的定性结果。GDCP 恢复的图像色彩偏差较为严重。Fusion 恢复的第三行图像场景偏暗，与现实世界场景匹配度较差。WaterNet 和 UShape 恢复的第二行图像地面略微偏红色，不符合真实场景。Ucolor 恢复的第三行图像较为模糊。Shallow 恢复的图像朦胧感较为严重。WaterFormer 恢复的第二行图像地面略微偏暗。本章技术有效的校正了色彩偏差，细节恢复方面优于其它技术。

中国知网 https://www.cnki.net

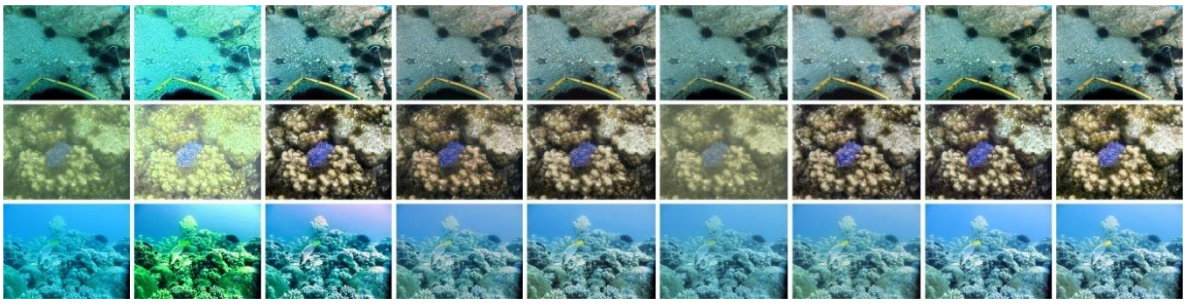


(a) (b) (c) (d) (e) (f) (g) (h) (i)

图 6.11 在 U60 数据集上的定性结果

(a) 原图 (b) GDCP (c) Fusion (d) WaterNet (e) Ucolor (f) Shallow (g) UShape (h) WaterFormer (i) 本章技术

图 6.12 展示了在 Upoor 数据集上的定性结果。GDCP 恢复的图像亮度过高。Fusion 恢复的第三行图像右上角颜色局部偏移，表现为粉色。WaterNet 和 Ucolor 恢复的第一行图像整体偏暗。Shallow 恢复的第二行图像较为模糊。UShape 恢复的第三行图像比 WaterFormer 和本章技术显的略暗。WaterFormer 恢复的第二行图像在纹理细节方面明显不如本章技术，如紫花周边的石头。本章技术展示了更明显的细节丰富性，在视觉感官上与现实场景更为接近。



(a) (b) (c) (d) (e) (f) (g) (h) (i)

图 6.12 在 Upoor 数据集上的定性结果

(a) 原图 (b) GDCP (c) Fusion (d) WaterNet (e) Ucolor (f) Shallow (g) UShape (h) WaterFormer (i) 本章技术

6.3.4 参数量及计算量比较

每种网络模型的参数量和计算量如表 6.3 所示。

表 6.3 每种网络模型的参数量及计算量

复原技术	Params/$\times 10^6$	Flops/$\times 10^9$
GDCP	—	—
Fusion	—	—
WaterNet	24.81	193.7
Ucolor	157.4	443.85
Shallow	0.2	216.3
UShape	65.6	66.2
WaterFormer	30.9	425.6
本章技术	34.1	490.0

从表 6.3 中可以发现，本章网络模型的参数值比 Ucolor 和 UShape 的参数值少，Flops 值取得较大的结果。这表明本章网络模型需要相对较高的硬件配置才能实现较

中国知网 https://www.cnki.net

快的计算速度，占用的内存相对较小。结合定量和定性结果而言，本章网络模型需要较少的参数量和较高的计算量实现水下图像的恢复，从而得到清晰、自然的水下图像。

6.4 消融研究

为验证本章技术每个组件的有效性，在 Tes90 测试集上进行了一系列消融实验，如表 6.4 所示。消融实验训练配置与本章实现细节保持一致。构建的消融实验包含以下子网络：

(1) w/o CSA：将通道自注意力从本章网络中移除（without，w/o）。

(2) w/o SW-PSA：将移位窗口像素自注意力从本章网络中移除。

(3) w/o DEA：将本章网络中的深层环境适配器移除，其被替换为环境适配器。

(4) w/o GFCM：将本章网络中的门控融合连接器移除，其被替换为跳跃连接。

(5) w/o AFN：将本章网络中的注意力前馈网络移除，其被替换为门控前馈网络。

(6) 本章技术：本章提出的水下图像复原技术，包含以上五个移除的组件。

表 6.4 在 Test90 数据集上的消融研究结果定量结果

复原技术	Test90		
	PSNR	SSIM	LPIPS
w/o CSA	18.89	0.859	0.174
w/o SW-PSA	23.03	0.921	0.083
w/o DEA	22.94	0.922	0.079
w/o GFCM	23.06	0.922	0.081
w/o AFN	20.71	0.891	0.123
本章技术	**23.34**	**0.925**	**0.079**

通过观察表 6.4，可以证明本章水下图像复原网络相关组件的有效性。

通道自注意力的有效性：当将通道自注意力从本章网络中移除时，相比于本章网络结果，PSNR 下降 4.45dB，SSIM 下降 0.066，LPIPS 上升 0.095。这一结果说明通道自注意力对本章网络复原水下图像的性能影响较大，能够大幅度提升水下图像质量。

移位窗口像素自注意力的有效性：当将移位窗口像素自注意力从本章网络中移除时，尽管其 PSNR、SSIM 和 LPIPS 值与本章结果差异不大，但网络整体性能仍有小幅度的提升，说明 SW-PSA 能够对网络的性能进行微调，进一步改善图像质量，增强恢复图像的细节信息。

深层环境适配器的有效性：当将瓶颈阶段的深层环境适配器替换为环境适配器时，相比于本章网络结果，其 PSNR 和 SSIM 值有明显的下降。这一结果不仅证明了深层环境适配器能够增强水下图像的质量，而且体现了深层环境适配器能够比环境

中国知网 https://www.cnki.net

适配器更好的提升网络性能，表明其在适应水下复杂环境方面具有更强能力，能够关注更多的水下图像有用信息。

门控融合连接器的有效性：当将门控融合连接器替换为常用的跳跃连接方式时，相比于本章网络结果，PSNR 下降 0.28dB，SSIM 下降 0.003，LPIPS 上升 0.002。这一结果表明以 CNN 为基础而设计的门控融合连接器，能够有效传递浅层网络中的关键局部细节信息至深层网络，进一步提升复原图像质量，在图像的细节保留方面具有一定的提升效果。

注意力前馈网络的有效性：当将注意力前馈网络替换为门控前馈网络时，相比于本章网络结果下降幅度较大，其 PSNR 下降 2.63dB，SSIM 下降 0.034，LPIPS 上升 0.044。这一结果展示了本章设计的注意力前馈网络的重要性，能够很好地提升网络的整体性能。同时，该结果也证明了相比于门控前馈网络，注意力前馈网络自适应的分配空间和通道信息权重的方式，能够更好地捕获水下图像的有价值信息，增强图像质量。

6.5 本章小结

在本章工作中，提出了一个基于门控融合 Transformer 的水下图像复原技术。该技术是以视觉 Transformer 理论为基础的 U-Net 型网络，主要由本章设计的门控融合 Transformer 块组成。在门控融合 Transformer 块中集成了引入的通道自注意力和移位窗口像素自注意力以及提出的注意力前馈网络和深层环境适配器，能够有效的关注全局通道特征和像素特征，加强对复杂水下环境图像重点有用特征的学习。此外，提出一个简易的门控融合连接器，以传递浅层网络中的重要局部信息至深层，避免 Transformer 架构对局部信息的忽视。在合成和真实水下图像数据集上的实验结果表明，本章技术实现了优异的水下图像复原效果，明显的提升了水下图像质量，校正了水下图像的颜色偏差，有效的丰富了水下图像细节。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 7 章 总结与展望

在本章中，首先对本文的主要研究工作进行了总结，然后全面总结了本文的创新之处，最后对下一步的研究重点和方向进行了展望。

7.1 全文研究工作总结及创新点

7.1.1 研究工作总结

图像是人类最主要的感知方式之一，带有丰富的诸如颜色、轮廓和纹理等关键信息，在日常生活、资源开发等方面具有至关重要的作用。图像质量的退化严重影响了人们对图像中重要信息的认识和利用，同时为计算机后续的视觉应用任务带来了障碍。因此，复原由于雾、云和水体等散射介质影响而采集的退化图像一直被广泛而深入的研究。本文以深度学习技术作为复原图像的核心手段，围绕受薄云、雾和水体影响的退化图像复原问题展开研究，取得了一些有价值的研究成果。本文完成的主要研究工作总结如下：

(1) 针对图像退化机制及复原相关理论展开研究。首先研究了散射介质及其导致图像退化的原因及模型，其次分析并研究了受云、雾及水体影响的退化图像复原理论及相关方法，然后介绍了与本文相关的神经网络基础理论及部分网络模型，最后说明了本文使用的图像数据集及评价方法和指标，为后续研究奠定基础。

(2) 针对现有去雾技术在复原自然场景有雾图像时存在色彩失真、去雾过度等问题，设计了基于多尺度注意力特征增强的图像去雾技术。在该技术中，设计的多尺度注意力增强模块和注意力特征增强模块能够充分利用图像中的多尺度特征，弥补注意力机制损失的细节信息。引入的上下文增强模块和注意力机制确保了足够的上下文信息进行特征学习，自适应的关注重点有用特征，从而使得该技术具有较高的去雾能力。大量的定量和定性实验证明了该技术具有较好的去雾性能，颜色信息保留完整，去雾程度适中。消融实验验证了提出的多尺度注意力特征增强模块和注意力特征增强模块的有效性。

(3) 针对现有去雾技术在复原遥感场景有雾图像时存在细节信息丢失严重等问题，设计了基于细节增强的遥感图像去雾技术。该技术能够不依赖大气散射模型，端到端的复原遥感有雾图像，有效的保留图像细节信息。设计了多尺度细节增强单元，该单元能够充分利用多尺度信息，融合全局特征和细节特征以实现细节信息的增强。构造了阶梯式注意力细节增强单元，该单元能够通过融合浅层和深层网络重点关注的特征信息，实现全局共享信息和与位置相关的局部信息的关注，进一步保留细节信息。建立的并行归一化模块进一步提升了网络的整体去雾性能。在公开的

中国知网 https://www.cnki.net

合成有雾图像数据集和真实有雾图像数据集中对该遥感图像去雾技术进行验证，实验结果表明该技术具有很好的去雾性能，复原出的图像细节信息更加丰富，颜色更贴近实际场景。消融实验证明了设计的多尺度细节增强单元、阶梯式注意力细节增强单元和并行归一化模块的有效性。

(4) 针对现有去云雾技术在复原遥感场景中有雾或薄云图像时存在云雾去除不彻底、纹理信息缺失严重等问题，设计了基于逆认知学习的遥感图像去云雾技术。该技术通过学习图像的多尺度信息，递进式的学习全局信息和局部信息，对云雾特征进行约束，实现了有雾或薄云图像的清晰化，去除了雾或薄云对遥感图像重要信息的干扰。具体来说，通过模拟人脑认知图像是从整体到局部的这一过程，设计了逆认知学习模块，以递进的方式从精细细节特征逐步学习全局特征，更为有效的学习与云雾相关的信息。设计了并行云雾约束模块，通过双分支的信息传递方式实现浅层信息和深层信息的交互，对云雾特征进行强有力的约束。设计的多尺度逆认知学习块融合了逆认知学习模块、并行云雾约束模块和特征注意力，能够在提取多尺度特征的同时自适应的调整对云雾特征的关注，增强网络的去云雾效果，改善网络的去云雾性能。在公开的合成有雾或薄云图像数据集以及从一些遥感数据集中随机选取的有雾或薄云真实图像上进行验证，实验结果表明该技术具有较强的去雾和去薄云能力，有效的恢复了图像的纹理和颜色等信息，复原的图像与真实场景更为一致，具有更高的图像质量和视觉效果。消融实验证明了逆认知学习模块，并行云雾约束模块和多尺度逆认知学习块的有效性。

(5) 针对水下图像存在的颜色失真和模糊等问题，设计了基于门控融合Transformer的水下图像复原技术。该技术是一个以Transfomer模型为基础的U-Net型网络架构，能够以端到端的方式实现退化水下图像的清晰化，解决了水下图像颜色偏移，模糊等问题。具体来说，在该技术中嵌入了设计的门控融合 Transfomer 块。该模块结合了通道自注意力、移位窗口像素自注意力和设计的注意力前馈网络，实现了通道特征和像素特征的有效融合，增强了网络对局部细节信息的关注。为弥补 Transformer 架构对局部信息的忽视，设计了以 CNN 为基础而构建的门控融合连接器。该连接器能够将浅层重点局部细节信息融合至深层，有效弥补了网络损失的关键细节信息。此外，在门控融合 Transformer 块中嵌入了深层环境适配器，进一步增强了网络对复杂水下环境的学习能力。在公开的水下图像合成数据集和真实水下图像数据集上进行验证，实验结果表明该技术有效的复原了退化的水下图像，复原图像的颜色和纹理等细节更接近现实场景。消融实验证明了设计的门控融合连接器、注意力前馈网络和深层环境适配器的有效性。

中国知网 https://www.cnki.net

7.1.2 创新点

针对以上研究工作，其中体现的主要创新点如下：

(1) 提出了基于多尺度注意力特征增强的图像去雾技术。该技术最主要的两个模块是设计的注意力特征增强模块和多尺度注意力特征增强模块。在注意力特征增强模块中，主要包含注意力机制和引入的上下文增强模块，通过注意力机制实现对有用特征的重点关注，通过上下文增强模块确保网络能够充分的学习上下文信息。然而注意力特征增强模块仍然会损失部分细节信息，因此将高效空间金字塔模块与注意力特征增强模块进行有效结合，构建多尺度特征增强模块，用以提取多尺度信息，进一步弥补损失的细节信息，增强网络的去雾能力。实验结果显示该技术在自然场景去雾任务中取得了先进水平。

(2) 提出了基于细节增强的遥感图像去雾技术。该技术中提出的多尺度细节增强单元和阶梯式注意力细节增强单元是该技术的主要组件。多尺度细节增强单元通过具有不同扩张率的卷积核提取多尺度特征，实现不同区域雾信息的捕捉，恢复图像的纹理细节。阶梯式注意力细节增强单元改进了像素注意力，对像素注意力关注的重点特征进行了浅层与深层的融合，能够有效的处理遥感图像中复杂多样的雾分布情况，突出图像中的细节信息。此外，设计的并行归一化模块既可以保留和内容相关的特征，又可以学习到不受外观变化影响的特征，进一步提升了网络的学习能力。由于它们的共同作用，最终使网络实现了有雾遥感图像端到端的清晰化恢复。实验结果表明该技术有效增强了图像的细节信息，达到了遥感场景图像去雾任务的先进水平。

(3) 提出了基于逆认知学习的遥感图像去云雾技术。该技术以 U-Net 型网络为骨架，嵌入了提出的多尺度逆认知学习块。该模块结合了提出的并行云雾云约束模块、逆认知学习模块以及引入的特征注意力和具有不同大小的并行卷积核，从而使网络能够递进式的进行局部细节到整体特征的学习，对雾和薄云特征进行强有力的约束，有效的提取不均匀分布的雾信息。最终以它核心构建出的基于逆认知学习的遥感图像去云雾网络成功复原出清晰干净的无雾或无云图像。实验结果展示了该网络的去雾或去薄云效果优于现有的去云雾技术，复原出的图像更加自然、真实。

(4) 提出了基于门控融合 Transformer 的水下图像复原技术。该技术是一个 U-Net 型网络结构，其核心结构是设计的门控融合 Transfomer 块。在门控融合 Transfomer 块中，主要引入了通道自注意力和移位窗口像素自注意力来提取全局信息，提出注意力前馈网络来自适应的关注和整合关键有用信息，增强细节信息。通过提出的门控融合连接器替换 U-Net 型网络中传统的跳跃连接方式，将浅层关键细节信息传递至深层网络，有效弥补了损失的细节信息。同时在门控融合 Tranformer 块中嵌入了提出的深层环境适配器，以进一步增强网络对水下复杂环境灵活的适应能力，提升网络的

中国知网 https://www.cnki.net

学习能力。

7.2 未来研究工作展望

本文开发了多个基于深度学习的图像复原技术，有效恢复了受薄云、雾和水体影响而退化的图像，取得了阶段性的成果。然而在实际应用中存在诸多复杂的场景，仍然还有一些亟需处理的问题，需要开发一些新的技术或构建新的数据来解决。因此，笔者下阶段的研究将从以下方面进行拓展与完善：

(1) 本文提出的复原技术在实验中都利用了成对的合成的退化图像和清晰图像进行网络模型的训练，属于有监督学习。而在实际应用的多数场景中，难以获取大量的相应清晰图像，本文技术将不再适用于处理此种情况。因此，进一步研究退化机制的本质特性，解析图像复原任务中深层次的监督机制，仅需给定的退化图像，无需对应的清晰图像，通过研究无监督学习复原技术恢复高质量图像，是本文后续研究的一个重点方向。

(2) 当下的遥感有雾数据集、薄云云数据集和水下图像数据集较少，尽管已经有几种公开的数据集，如 Satehaze1k 有雾数据集、RICE-I薄云数据集和 UIEB 水下数据集等，但它们包含的数据量较少，最多成对样本数不足 800 张，数据规模较小。大规模的训练样本对有助于神经网络具有更好的泛化能力，充分的捕捉数据中的模式和特征，防止过拟合发生。因此，如何构建一个大规模的遥感有雾、薄云和水下图像数据集，是下一步的重点研究任务，有助于推动图像复原领域的发展。

(3) 在本文中提出的复原技术分别解决了去雾、去薄云和水下图像等单一场景的复原问题，而实际的图像背景中往往包含多种导致图像退化的因素，如同时包含雨、雾和云的场景，运动中采集的水下图像带来额外的运动噪声情形，此时仅仅依靠这些单一场景的复原技术将难以取得理想的效果，仍然会残留雨、雾、云、噪声等退化因素。近年来。多模态技术取得了一定的进展。多模态技术能够利用不同类型的数据模态，实现不同模态信息之间的互补。因此，进一步以多模态技术为基础，开发一种能够处理多种退化类型的一体化图像恢复技术具有一定的现实意义。

中国知网 https://www.cnki.net

参考文献

[1] Chen C, Wang C, Liu B, et al. Edge intelligence empowered vehicle detection and image segmentation for autonomous vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(11): 13023-13034.

[2] Xiao X, Zhao Y, Zhang F, et al. BASeg: Boundary aware semantic segmentation for autonomous driving[J]. Neural Networks, 2023, 157: 460-470.

[3] Liu X, Wang L. MSRMNet: Multi-scale skip residual and multi-mixed features network for salient object detection[J]. Neural Networks, 2024, 173: 106144.

[4] Yang B, Zhang X, Zhang J, et al. EFLNet: Enhancing Feature Learning Network for Infrared Small Target Detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-11.

[5] Fan X, Zhang Y, Lu Y, et al. Parformer: Transformer-based multi-task network for pedestrian attribute recognition[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2023, 34(1): 411-423.

[6] Wu P, Wang Z, Li H, et al. KD-PAR: A knowledge distillation-based pedestrian attribute recognition model with multi-label mixed feature learning network[J]. Expert Systems with Applications, 2024, 237: 121305.

[7] Dong Z, Zheng D, Huang Y, et al. A polarization-based image restoration method for both haze and underwater scattering environment[J]. Scientific Reports, 2022, 12(1): 1836.

[8] Li C, Yu H, Zhou S, et al. Efficient dehazing method for outdoor and remote sensing images[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023, 16: 4516-4528.

[9] Song T, Fan S, Li P, et al. Learning an effective transformer for remote sensing satellite image dehazing[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5.

[10] 周丽雅. 受云雾干扰的可见光遥感影像信息补偿技术研究[D]; 解放军信息工程大学, 2011.

[11] 吉辉, 胡辽林, 韩志超. 基于双支残差特征融合的图像去雾算法[J]. 计算机辅助设计与图形学学报, 2023, 35(02): 320-8.

[12] 靳阳阳, 韩现伟, 周书宁, 等. 图像增强算法综述[J]. 计算机系统应用, 2021, 30(06): 18-27.

[13] Katsaggelos AK. Digital image restoration [M]. Springer Publishing Company, Incorporated, 2012.

[14] Kaur M, Kaur J, Kaur J. Survey of contrast enhancement techniques based on histogram equalization[J]. International Journal of Advanced Computer Science and Applications, 2011, 2(7).

[15] Demir Y, Kaplan NH. Low-light image enhancement based on sharpening-smoothing image filter[J]. Digital Signal Processing, 2023, 138: 104054.

[16] Zhang D, Zhang D. Wavelet transform[J]. Fundamentals of image data mining: Analysis, Features, Classification and Retrieval, 2019: 35-44.

[17] Ma J, Plonka G. The curvelet transform[J]. IEEE signal processing magazine, 2010, 27(2): 118-33.

[18] Parihar AS, Singh K. A study on Retinex based method for image enhancement[C]. 2018 2nd International Conference on Inventive Systems and Control (ICISC), IEEE, 2018: 619-624.

[19] Kim TK, Paik JK, Kang BS. Contrast enhancement system using spatially adaptive histogram equalization with temporal filtering[J]. IEEE Transactions on Consumer Electronics, 1998, 44(1): 82-97.

[20] Kim J-Y, Kim L-S, Hwang S-H. An advanced contrast enhancement using partially overlapped

中国知网 https://www.cnki.net

sub-block histogram equalization[J]. IEEE transactions on circuits and systems for video technology, 2001, 11(4): 475-484.

[21] Joy N, Johnson J. Fast image dehazing method based on homomorphism filtering and contrast enhancement[J]. Int J Sci Res Eng Trends, 2019, 5: 305-9.

[22] 向文鼎. 雾天及海洋环境下的图像增强与复原技术研究[D], 中国科学院大学, 2019.

[23] Wu H, Tan Z. An image dehazing algorithm based on single-scale retinex and homomorphic filtering[C]. Communications, Signal Processing, and Systems: Proceedings of the 8th International Conference on Communications, Signal Processing, and Systems 8th, Springer, 2020: 1482-1493.

[24] Gao Z, Zhai Y. Image Dehazing Based on Multi-scale Retinex and Guided Filtering[C]. 2022 International Conference on Image Processing, Computer Vision and Machine Learning (ICICML), IEEE, 2022: 123-136.

[25] Parthasarathy S, Sankaran P. An automated multi scale retinex with color restoration for image enhancement[C]. 2012 National Conference on Communications (NCC), IEEE, 2012: 1-5.

[26] An S, Huang X, Cao L, et al. A comprehensive survey on image dehazing for different atmospheric scattering models[J]. 2024, 83(14): 40963-40993.

[27] Ju M, Ding C, Ren W, et al. IDE: Image dehazing and exposure using an enhanced atmospheric scattering model[J]. 2021, 30: 2180-2192.

[28] Ju M, Zhang D, Wang XJTVC. Single image dehazing via an improved atmospheric scattering model[J]. 2017, 33: 1613-1625.

[29] Tan RT. Visibility in bad weather from a single image[C]. 2008 IEEE conference on computer vision and pattern recognition, IEEE, 2008: 1-8.

[30] Fattal R. Single image dehazing[C], SIGGRAPH, 2008.

[31] He K, Sun J, Tang X. Single image haze removal using dark channel prior[J]. IEEE transactions on pattern analysis and machine intelligence, 2010, 33(12): 2341-2353.

[32] Nair D, Sankaran PJJoVC, Representation I. Color image dehazing using surround filter and dark channel prior[J]. 2018, 50: 9-15.

[33] 蒋建国, 侯天峰, 齐美彬. 改进的基于暗原色先验的图像去雾算法[J]. 电路与系统学报. 2011, 16(02): 7-12.

[34] Xu Y, Guo X, Wang H, et al. Single image haze removal using light and dark channel prior[C]. 2016 IEEE/CIC International Conference on Communications in China (ICCC), IEEE, 2016: 1-6.

[35] Zhu Q, Mai J, Shao L. A fast single image haze removal algorithm using color attenuation prior[J]. IEEE transactions on image processing, 2015, 24(11): 3522-3533.

[36] Berman D, Avidan S. Non-local image dehazing[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 1674-1682.

[37] Bui TM, Kim WJIToIP. Single image dehazing using color ellipsoid prior[J]. 2017, 27(2): 999-1009.

[38] Singh D, Kumar V, Kaur MJAI. Single image dehazing using gradient channel prior[J]. 2019, 49(12): 4276-4293.

[39] Xu L, Zhao D, Yan Y, et al. IDeRs: Iterative dehazing method for single remote sensing image[J]. Information Sciences, 2019, 489: 50-62.

[40] Cai B, Xu X, Jia K, et al. Dehazenet: An end-to-end system for single image haze removal[J]. IEEE transactions on image processing, 2016, 25(11): 5187-5198.

[41] Ren W, Pan J, Zhang H, et al. Single image dehazing via multi-scale convolutional neural networks

中国知网 https://www.cnki.net

with holistic edges[J]. International Journal of Computer Vision, 2020, 128: 240-59.

[42] Li B, Peng X, Wang Z, et al. Aod-net: All-in-one dehazing network[C]. Proceedings of the IEEE international conference on computer vision, 2017: 4770-4778.

[43] Liao Y, Su Z, Liang X, et al. Hdp-net: Haze density prediction network for nighttime dehazing[C]. Pacific Rim Conference on Multimedia, Springer, 2018: 469-480.

[44] Chen D, He M, Fan Q, et al. Gated context aggregation network for image dehazing and deraining[C]. 2019 IEEE winter conference on applications of computer vision (WACV), IEEE, 2019: 1375-1383.

[45] Mei K, Jiang A, Li J, et al. Progressive feature fusion network for realistic image dehazing[C]. Computer Vision–ACCV 2018: 14th Asian Conference on Computer Vision, Perth, Australia, December 2–6, 2018, Revised Selected Papers, Part I 14, Springer, 2019: 203-215.

[46] Shao Y, Li L, Ren W, et al. Domain adaptation for image dehazing[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 2808-2817.

[47] Qin X, Wang Z, Bai Y, et al. FFA-Net: Feature fusion attention network for single image dehazing[C]. Proceedings of the AAAI conference on artificial intelligence, 2020: 11908-11915.

[48] Liu X, Ma Y, Shi Z, et al. Griddehazenet: Attention-based multi-scale network for image dehazing[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2019: 7314-7323.

[49] Wang N, Cui Z, Su Y, et al. Multiscale supervision-guided context aggregation network for single image dehazing[J]. IEEE Signal Processing Letters, 2021, 29: 70-84.

[50] Sheng J, Lv G, Du G, et al. Multi-scale residual attention network for single image dehazing[J]. Digital Signal Processing, 2022, 121: 103327.

[51] Zhou Y, Chen Z, Sheng B, et al. AFF‐Dehazing: Attention‐based feature fusion network for low‐light image Dehazing[J]. Computer Animation and Virtual Worlds, 2021, 32(3-4): 2011.

[52] Chen Z, He Z, Lu Z-M. DEA-Net: Single image dehazing based on detail-enhanced convolution and content-guided attention[J]. arXiv preprint arXiv:230104805, 2023.

[53] Song Y, He Z, Qian H, et al. Vision transformers for single image dehazing[J]. IEEE Transactions on Image Processing, 2023, 32: 1927-1941.

[54] Lu L, Xiong Q, Chu D, et al. MixDehazeNet: Mix Structure Block For Image Dehazing Network[J]. arXiv preprint arXiv:230517654, 2023.

[55] Guo Y, Gao Y, Liu W, et al. SCANet: Self-Paced Semi-Curricular Attention Network for Non-Homogeneous Image Dehazing[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 1884-1893.

[56] Li Y, Chen X. A coarse-to-fine two-stage attentive network for haze removal of remote sensing images[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 18(10): 1751-1765.

[57] Zhang L, Wang S. Dense haze removal based on dynamic collaborative inference learning for remote sensing images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-16.

[58] Sun H, Luo Z, Ren D, et al. Partial Siamese with Multiscale Bi-codec Networks for Remote Sensing Image Haze Removal[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023.

[59] Song T, Fan S, Li P, et al. Learning an effective transformer for remote sensing satellite image dehazing[J]. IEEE Geoscience and Remote Sensing Letters, 2023.

[60] Trucco E, Olmos-Antillon AT. Self-tuning underwater image restoration[J]. IEEE Journal of Oceanic Engineering, 2006, 31(2): 511-519.

[61] 张赫, 徐玉如, 万磊, 等. 水下退化图像处理方法[J]. 天津大学学报. 2010, 43(09): 827-833.

中国知网 https://www.cnki.net

[62] Fattal R. Dehazing using color-lines[J]. ACM transactions on graphics, 2014, 34(1): 1-14.
[63] 杨爱萍, 郑佳, 王建, 等. 基于颜色失真去除与暗通道先验的水下图像复原[J]. 电子与信息学报, 2015, 37(11): 2541-2537.
[64] Singh D, Kumar V. Single image haze removal using integrated dark and bright channel prior[J]. Modern Physics Letters B, 2018, 32(04): 1850051.
[65] Drews P, Nascimento E, Moraes F, et al. Transmission estimation in underwater single images[C]. Proceedings of the IEEE international conference on computer vision workshops, 2013: 825-30.
[66] Galdran A, Pardo D, Picón A, et al. Automatic red-channel underwater image restoration[J]. Journal of Visual Communication and Image Representation, 2015, 26: 132-145.
[67] Peng Y-T, Cao K, Cosman PC. Generalization of the dark channel prior for single image restoration[J]. IEEE Transactions on Image Processing, 2018, 27(6): 2856-2868.
[68] Ancuti C, Ancuti CO, Haber T, et al. Enhancing underwater images and videos by fusion[C]. 2012 IEEE conference on computer vision and pattern recognition, IEEE, 2012: 81-88.
[69] 闫小红. 基于图像融合与深度网络模型的水下光学图像增强方法研究[D], 大连海事大学 2023.
[70] Ding X, Wang Y, Zhang J, et al. Underwater image dehaze using scene depth estimation with adaptive color correction[C]. OCEANS 2017-Aberdeen, IEEE, 2017: 1-5.
[71] Hou M, Liu R, Fan X, et al. Joint residual learning for underwater image enhancement[C]. 2018 25th IEEE international conference on image processing (ICIP), IEEE, 2018: 4043-4047.
[72] Lin Y, Shen L, Wang Z, et al. Attenuation coefficient guided two-stage network for underwater image restoration[J]. IEEE Signal Processing Letters, 2020, 28: 199-203.
[73] Xue X, Li Z, Ma L, et al. Investigating intrinsic degradation factors by multi-branch aggregation for real-world underwater image enhancement[J]. Pattern recognition, 2023, 133: 109041.
[74] Li C, Anwar S, Porikli F. Underwater scene prior inspired deep underwater image and video enhancement[J]. Pattern recognition, 2020, 98: 107038.
[75] Wang Y, Guo J, Gao H, et al. UIEC^ 2-Net: CNN-based underwater image enhancement using two color space[J]. Signal Processing: Image Communication, 2021, 96: 116250.
[76] Li C, Guo C, Ren W, et al. An underwater image enhancement benchmark dataset and beyond[J]. IEEE transactions on image processing, 2019, 29: 4376-4389.
[77] Naik A, Swarnakar A, Mittal K. Shallow-uwnet: Compressed model for underwater image enhancement (student abstract)[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021: 15853-15844.
[78] Li C, Anwar S, Hou J, et al. Underwater image enhancement via medium transmission-guided multi-color space embedding[J]. IEEE Transactions on Image Processing, 2021, 30: 4985-5000.
[79] Li J, Skinner KA, Eustice RM, et al. WaterGAN: Unsupervised generative network to enable real-time color correction of monocular underwater images[J]. IEEE Robotics and Automation letters, 2017, 3(1): 387-394.
[80] Fabbri C, Islam MJ, Sattar J. Enhancing underwater imagery using generative adversarial networks[C]. 2018 IEEE international conference on robotics and automation (ICRA), IEEE, 2018: 7159-7165.
[81] Guo Y, Li H, Zhuang P. Underwater image enhancement using a multiscale dense generative adversarial network[J]. IEEE Journal of Oceanic Engineering, 2019, 45(3): 862-870.
[82] Islam MJ, Xia Y, Sattar J. Fast underwater image enhancement for improved visual perception[J]. IEEE Robotics and Automation Letters, 2020, 5(2): 3227-3234.

中国知网 https://www.cnki.net

[83] Yang M, Hu K, Du Y, et al. Underwater image enhancement based on conditional generative adversarial network[J]. Signal Processing: Image Communication, 2020, 81: 115723.

[84] Liu R, Jiang Z, Yang S, et al. Twin adversarial contrastive learning for underwater image enhancement and beyond[J]. IEEE Transactions on Image Processing, 2022, 31: 4922-4936.

[85] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[86] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. International Conference on Learning Representations, 2021: 1-21.

[87] Chen D-J, Hsieh H-Y, Liu T-L. Adaptive image transformer for one-shot object detection[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 12247-12256.

[88] Hu D, Zhang Y, Zhu J, et al. TRANS-Net: Transformer-enhanced residual-error alternative suppression network for MRI reconstruction[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-13.

[89] Hu J-F, Huang T-Z, Deng L-J, et al. Fusformer: A transformer-based fusion network for hyperspectral image super-resolution[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.

[90] Peng L, Zhu C, Bian L. U-shape transformer for underwater image enhancement[J]. IEEE Transactions on Image Processing, 2023, 32: 3066-3079.

[91] Ren T, Xu H, Jiang G, et al. Reinforced swin-convs transformer for simultaneous underwater sensing scene image enhancement and super-resolution[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-16.

[92] Shen Z, Xu H, Luo T, et al. UDAformer: Underwater image enhancement based on dual attention transformer[J]. Computers & Graphics, 2023, 111: 77-88.

[93] Wen J, Cui J, Yang G, et al. Waterformer: A global–local transformer for underwater image enhancement with environment adaptor[J]. IEEE Robotics & Automation Magazine, 2024, 31(1): 29-40.

[94] Houghton JT. The physics of atmospheres [M]. Cambridge University Press, 2002.

[95] 默斯顿. 水中摄影学: 理论与实践[M]. 北京: 科学出版社, 1980.

[96] 孙传东, 高立民,张建生, 等. 水的光学特性及其对水下成像的影响[J]. 应用光学, 2000, (04): 39-46.

[97] 郑冰, 孙骁禾, 粟京. 一种水下激光成像的新方法[J]. 中国海洋大学学报(自然科学版), 2006, (01): 119-122.

[98] Cheng C-Y, Sung C-C, Chang H-H. Underwater image restoration by red-dark channel prior and point spread function deconvolution[C]. 2015 IEEE international conference on signal and image processing applications (ICSIPA), IEEE, 2015: 110-105.

[99] 钟森城, 李泽仁, 王荣波. 前向散射对激光水下成像的影响[J]. High Power Laser and Particle Beams, 2012, 24(1): 61-74.

[100] 李建. 水下图像后向散射噪声的去噪问题研究 [D]. 中国海洋大学, 2009.

[101] Marshall LR. Blue-green lasers plumb the mysteries of the deep[J]. Laser focus world, 1993, 29(4): 185-197.

[102] Nayar SK, Narasimhan SG. Vision in bad weather[C]. Proceedings of the seventh IEEE international conference on computer vision, IEEE, 1999: 820-827.

中国知网 https://www.cnki.net

[103] Zhang D, Ju M, Wang X. A fast image daze removal algorithm using dark channel prior[J]. Acta Electronica Sinica, 2015, 43(7): 1437-1443.

[104] He K, Sun J, Tang X. Guided image filtering[J]. IEEE transactions on pattern analysis and machine intelligence, 2012, 35(6): 1397-1409.

[105] Ai-ping Y, Jia Z, Jian W, et al. Underwater image restoration based on color cast removal and dark channel prior[J]. Journal of Electronics and Information Technology, 2015, 37(11): 2541-2537.

[106] Woo S, Park J, Lee J-Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision (ECCV), 2018: 3-19.

[107] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2015: 1-9.

[108] Liu S, Huang D. Receptive field block net for accurate and fast object detection[C]. Proceedings of the European conference on computer vision (ECCV), 2018: 385-400.

[109] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]. Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18, Springer, 2015: 234-241.

[110] Beeche C, Singh JP, Leader JK, et al. Super U-Net: A modularized generalizable architecture[J]. Pattern recognition, 2022, 128: 108669.

[111] Chen J, Mei J, Li X, et al. TransUNet: Rethinking the U-Net architecture design for medical image segmentation through the lens of transformers[J]. Medical Image Analysis, 2024, 97: 103280.

[112] Chen Y, Xia R, Yang K, et al. MICU: Image super-resolution via multi-level information compensation and U-net[J]. Expert Systems with Applications, 2024, 245: 123111.

[113] Qin Q, Yan J, Wang Q, et al. Etdnet: An efficient transformer deraining model[J]. IEEE Access, 2021, 9: 119881-119893.

[114] Chen H, Wang Y, Guo T, et al. Pre-trained image processing transformer[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021: 12299-12310.

[115] Li B, Ren W, Fu D, et al. Benchmarking single-image dehazing and beyond[J]. IEEE Transactions on Image Processing, 2018, 28(1): 492-505.

[116] Silberman N, Hoiem D, Kohli P, et al. Indoor segmentation and support inference from rgbd images[C]. Computer Vision–ECCV 2012: 12th European Conference on Computer Vision, Florence, Italy, October 7-13, 2012, Proceedings, Part V 12, Springer, 2012: 746-760.

[117] Scharstein D, Szeliski R. High-accuracy stereo depth maps using structured light[C]. 2003 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2003 Proceedings, IEEE, 2003.

[118] Ancuti CO, Ancuti C, Timofte R. NH-HAZE: An image dehazing benchmark with non-homogeneous hazy and haze-free images[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops, 2020: 444-435.

[119] Huang B, Zhi L, Yang C, et al. Single satellite optical imagery dehazing using SAR image prior based on conditional generative adversarial networks[C]. Proceedings of the IEEE/CVF winter conference on applications of computer vision, 2020: 1806-1813.

[120] Lin D, Xu G, Wang X, et al. A remote sensing image dataset for cloud removal[J]. arXiv preprint arXiv:190100600, 2019.

[121] Li H, Li J, Wang W. A fusion adversarial underwater image enhancement network with a public test dataset[J]. arXiv preprint arXiv:190606819, 2019.

中国知网 https://www.cnki.net

[122] Peng W, Zhou C, Hu R, et al. Raune-Net: a residual and attention-driven underwater image enhancement method[C]. International Forum on Digital TV and Wireless Multimedia Communications, Springer, 2023: 15-27.
[123] Wang Z, Bovik AC, Sheikh HR, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.
[124] Zhang R, Isola P, Efros AA, et al. The unreasonable effectiveness of deep features as a perceptual metric[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 586-595.
[125] Panetta K, Gao C, Agaian S. Human-visual-system-inspired underwater image quality measures[J]. IEEE Journal of Oceanic Engineering, 2015, 41(3): 541-51.
[126] Yang M, Sowmya A. An underwater color image quality evaluation metric[J]. IEEE Transactions on Image Processing, 2015, 24(12): 6062-6071.
[127] Meng G, Wang Y, Duan J, et al. Efficient image dehazing with boundary constraint and contextual regularization[C]. Proceedings of the IEEE international conference on computer vision, 2013: 617-624.
[128] Qu Y, Chen Y, Huang J, et al. Enhanced pix2pix dehazing network[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 8160-8168.
[129] Tian C, Xu Y, Li Z, et al. Attention-guided CNN for image denoising[J]. Neural Networks, 2020, 124: 117-129.
[130] Chen Y, Liu L, Phonevilay V, et al. Image super-resolution reconstruction based on feature map attention mechanism[J]. Applied Intelligence, 2021, 51: 4367-4380.
[131] Wang S, Zhou T, Lu Y, et al. Contextual transformation network for lightweight remote-sensing image super-resolution[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-13.
[132] Mehta S, Rastegari M, Caspi A, et al. Espnet: Efficient spatial pyramid of dilated convolutions for semantic segmentation[C]. Proceedings of the european conference on computer vision (ECCV), 2018: 552-568.
[133] Arun PV, Buddhiraju KM, Porwal A, et al. CNN-based super-resolution of hyperspectral images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(9): 6106-6121.
[134] Han W, Li J, Wang S, et al. Geological remote sensing interpretation using deep learning feature and an adaptive multisource data fusion network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.
[135] Zhang L, Song L, Du B, et al. Nonlocal low-rank tensor completion for visual data[J]. IEEE transactions on cybernetics, 2019, 51(2): 673-685.
[136] Pan Z, Xu J, Guo Y, et al. Deep learning segmentation and classification for urban village using a worldview satellite image based on U-Net[J]. Remote Sensing, 2020, 12(10): 1574.
[137] Shao Z, Tang P, Wang Z, et al. BRRNet: A fully convolutional neural network for automatic building extraction from high-resolution remote sensing images[J]. Remote Sensing, 2020, 12(6): 1050.
[138] Han Y, Li Z, Huang C, et al. Monitoring droughts in the Greater Changbai Mountains using multiple remote sensing-based drought indices[J]. Remote Sensing, 2020, 12(3): 530.
[139] Rousta I, Olafsson H, Moniruzzaman M, et al. Impacts of drought on vegetation assessed by vegetation indices and meteorological factors in Afghanistan[J]. Remote Sensing, 2020, 12(15): 2433.
[140] Ebel P, Xu Y, Schmitt M, et al. SEN12MS-CR-TS: A remote-sensing data set for multimodal

中国知网 https://www.cnki.net

multitemporal cloud removal[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.

[141] Guo J, Yang J, Yue H, et al. RSDehazeNet: Dehazing network with channel refinement for multispectral remote sensing images[J]. IEEE Transactions on geoscience and remote sensing, 2020, 59(3): 2535-2549.

[142] Huang P, Zhao L, Jiang R, et al. Self-filtering image dehazing with self-supporting module[J]. Neurocomputing, 2021, 432: 57-69.

[143] Wang C, Shen H-Z, Fan F, et al. EAA-Net: A novel edge assisted attention network for single image dehazing[J]. Knowledge-Based Systems, 2021, 228: 107279.

[144] Huang Y, Chen X. Single remote sensing image dehazing using a dual-step cascaded residual dense network[C]. 2021 IEEE International Conference on Image Processing (ICIP), IEEE, 2021: 3852-3866.

[145] Chalavadi V, Jeripothula P, Datla R, et al. mSODANet: A network for multi-scale object detection in aerial images using hierarchical dilated convolutions[J]. Pattern Recognition, 2022, 126: 108548.

[146] Wang T, Zhao L, Huang P, et al. Haze concentration adaptive network for image dehazing[J]. Neurocomputing, 2021, 439: 75-85.

[147] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 4700-4708.

[148] Xia G-S, Hu J, Hu F, et al. AID: A benchmark data set for performance evaluation of aerial scene classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(7): 3965-3981.

[149] Yang Y, Newsam S. Bag-of-visual-words and spatial extensions for land-use classification[C]. Proceedings of the 18th SIGSPATIAL international conference on advances in geographic information systems, 2010: 270-279.

[150] Cheng Z, Fan G, Zhou J, et al. FDCE-Net: underwater image enhancement with embedding frequency and dual color encoder[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2024.

[151] Khan R, Mishra P, Mehta N, et al. Spectroformer: Multi-domain query cascaded transformer network for underwater image enhancement[C]. Proceedings of the IEEE/CVF winter conference on applications of computer vision, 2024: 1454-1463.

[152] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2021: 10012-10022.

[153] Zamir SW, Arora A, Khan S, et al. Restormer: Efficient transformer for high-resolution image restoration[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 5728-5739.

中国知网 https://www.cnki.net