DOCTORAL DISSERTATION XIDIAN UNIVERSITY

西安电子科技大学

博士学位论文

数据驱动的低质量图像鲁棒性目标识别方法

作者姓名 杨州

指导教师姓名、职称 董伟生 教授

申请学位类别 工学博士

中国知网 https://www.cnki.net

学校代码 10701　　学　号 21171110623
分 类 号 TP39　　密　级 公开

西安电子科技大学

博士学位论文

数据驱动的低质量图像鲁棒性目标识别方法

作者姓名：杨州

一级学科：计算机科学与技术

二级学科（研究方向）：计算机科学与技术

学位类别：工学博士

指导教师姓名、职称：董伟生 教授

学　　院：人工智能学院

提交日期：2025 年 06 月

中国知网 https://www.cnki.net

Data-Driven Methods for Robust Object Recognition on Low-Quality Images

A dissertation submitted to

XIDIAN UNIVERSITY

in partial fulfillment of the requirements

for the degree of Doctor of Philosophy

in Computer Science and Technology

By

Zhou Yang

Supervisor: Weisheng Dong Title: Professor

June 2025

中国知网 https://www.cnki.net

摘　要

随着计算机视觉的快速发展，目标识别技术（分类、检测、分割等）已广泛应用于自动驾驶、智能监控、医疗影像分析和工业检测等领域。深度学习模型通常依赖大规模高质量图像，以提取丰富的特征信息。然而，在真实场景中图像质量易受多种因素影响，包括成像系统的低分辨率与热噪声、环境光变化与恶劣天气、以及运动目标导致的模糊与失焦等。这些低质量图像极大增加了特征提取的难度。特征信息缺乏可能引起识别目标混淆，导致模型以高置信度误识别。而在许多实际应用中，算法需在低质量图像条件下依然保持高识别精度，以确保系统的稳定性与可靠性。因此，提升目标识别算法在低质量图像上的鲁棒性具有重要的现实意义。

目前，已有多种方法致力于提升低质量图像下的目标识别鲁棒性，主要包括图像预处理、特征增强和数据增广等策略。图像预处理通过去噪、超分辨率、去模糊、去雨雾和暗光增强等技术改善图像质量，常与识别网络联合训练以提升性能，但其效果受限于退化类型的多样性，且双阶段处理计算开销较大。特征增强方法利用清晰-退化图像对重建深层语义特征，提升特征表达能力，尽管高效，但简单的重建损失难以区分各区域对识别的重要性。数据增广和域泛化则通过特定训练策略提升模型对未知退化的适应性，具备较强泛化能力，然而其复杂的模型结构和精心设计的增广策略降低了算法的实用性，同时由于缺乏对数据分布的建模，可能引入大量无效样本，训练成本增加但性能提升有限。

综上，现有鲁棒性识别技术虽提升了低质量图像的可用性，但仍面临**计算复杂度高**、**判别性特征提取不足**、**依赖成对数据**，及**依赖特定退化假设**等问题，整体性能仍存在瓶颈。为此，本文以数据为驱动，分别探究**退化数据的不确定性**、**数据的本征表示**和**难样本数据的分布**，围绕低质量图像的鲁棒性识别展开研究，提出三种创新算法，在数据依赖上逐步优化：**从依赖成对图像数据，到混合非成对输入，最终摆脱仿真退化图像的依赖**，显著提升了识别的鲁棒性与实用性。本文的主要研究内容与创新点如下：

1. 针对现有的基于特征增强的低质量图像鲁棒识别方法通常采用教师-学生网络结构，并使用 L_2 - 范数作为蒸馏约束，未能考虑到低质图像**数据分布的不确定性**以及特征中不同区域的重要性等问题，本文提出了一种基于特征不确定性建模的自蒸馏方法。具体地，本方法首先提出仅使用一个模型的自特征蒸馏框架，将成对的清晰-仿真退化图像数据同时输入到该网络中进行特征提取。其次，对退化特征引入了数据不确定性建模机制，旨在更精确地识别图像数据中的困难区域，自适应地调整蒸馏损失。针对难以恢复的特征区域增加蒸馏损失的权重，改善特征重建的质量。大量

中国知网　https://www.cnki.net

实验结果表明，与现有的国内外先进方法相比，所提出的方法能够更有效地重建低质量图像中的重点判别性区域特征，显著提升了鲁棒识别性能。

2. 针对现有的低质量图像鲁棒性识别方法依赖成对的清晰-退化图像数据进行训练，算法适用性、可移植性较弱等问题，受稀疏表示学习和矢量量化算法的启发，本文围绕**数据的本征表示**展开研究，提出基于向量量化的图像质量无关特征表示学习方法。该方法首先在网络中添加一个码本（字典）模块来量化模型提取的的深层语义特征。量化过程实现了对特征数据中本质信息的建模，去除了冗余的噪声干扰。定性和定量实验结果均表明，所提出的方法实现了在无需成对图像数据的训练模式下，能够提取数据中的质量无关的表示，相较于其他国内外方法在多个鲁棒性基准测试集上准确性更优，且适用性更强。

3. 针对基于特征重建等方法依赖仿真退化数据，以及数据增广和域泛化方法缺乏对模型如何受分布变化影响的深入认知等问题，基于**易混淆难样本数据分布**，本文提出生成近邻类梯度扰动困难样本数据的对抗训练方法。具体地，使用与样本真实标签相邻的易混淆类别的梯度来扰动输入图像，生成对抗数据样本进行训练，并结合类间距离加权损失函数来增大类间分散性。该方法鼓励模型从易出错的数据中学习更具弹性的特征，增强其对不同数据分布变化的鲁棒性。在各种模型架构和基准数据集的广泛实验中，本方法相较于国内外先进方法拥有更优越的性能，更少的迭代训练次数，且无需引入额外的训练参数。

关键词：深度学习，图像分类，目标检测，退化图像，神经网络鲁棒性，不确定性，矢量量化，对抗训练

中国知网 https://www.cnki.net

ABSTRACT

With the rapid development of computer vision, object recognition technologies—including classification, detection, and segmentation—have been widely applied in fields such as autonomous driving, intelligent surveillance, medical image analysis, and industrial inspection. Deep learning models typically rely on large-scale, high-quality images to extract rich feature representations. However, in real-world scenarios, image quality is often degraded by various factors, including low resolution and thermal noise from imaging systems, changes in ambient lighting and adverse weather conditions, as well as motion-induced blur and defocus. These low-quality images substantially increase the difficulty of feature extraction. The lack of informative features can lead to target confusion and high-confidence misrecognition. In many practical applications, recognition algorithms are required to maintain high accuracy even under low-quality image conditions to ensure the stability and reliability of the overall system. Therefore, improving the robustness of object recognition algorithms for low-quality images is of significant practical importance.

Recently, various methods have been proposed to enhance the robustness of object recognition under low-quality image conditions, mainly including image preprocessing, feature enhancement, and data augmentation strategies. Image preprocessing improves image quality through techniques such as denoising, super-resolution, deblurring, deraining, and low-light enhancement, and is often jointly trained with recognition networks to improve performance. However, its effectiveness is limited by the diversity of degradation types, and the two-stage processing introduces significant computational overhead. Feature enhancement methods reconstruct deep semantic features using paired clean and degraded images to improve feature representation. Although efficient, simple reconstruction losses struggle to distinguish the importance of different regions for recognition. Data augmentation and domain generalization improve the model’ s adaptability to unknown degradations through specific training strategies and offer strong generalization ability. However, their complex model architectures and carefully designed augmentation strategies reduce practical usability. In addition, due to the lack of modeling of data distributions, they may introduce a large number of ineffective samples, increasing training cost with limited performance improvement.

In summary, although existing robust recognition techniques have improved the usability of

中国知网 https://www.cnki.net

low-quality images, they still face several challenges, including **high computational complexity**, **insufficient extraction of discriminative features**, **dependence on paired data**, and **reliance on specific degradation assumptions**, which hinder further performance improvements. To address these issues, this work adopts a data-driven approach, focusing on **the uncertainty of degraded data**, **the intrinsic representation of data**, and **the distribution of hard samples**. This work investigates robust recognition under low-quality image conditions and proposes three novel algorithms that progressively reduce data dependency: **from relying on paired image data, to using mixed unpaired inputs, and ultimately removing the reliance on synthetically degraded images**, thereby significantly improving both the robustness and practicality of recognition. The main research contributions and innovations of this work are as follows:

1. To address the limitations of existing feature enhancement-based robust recognition methods, which typically adopt a teacher-student architecture and employ L_2-norm as the distillation constraint—without considering the **uncertainty in the data distribution** of low-quality images and the varying importance of different feature regions—this work proposes a self-distillation method based on feature uncertainty modeling. Specifically, a self-feature distillation framework using only a single model is proposed, in which paired clean and synthetically degraded images are simultaneously fed into the network for feature extraction. A data uncertainty modeling mechanism is introduced into the degraded features to more accurately identify difficult regions in the image and adaptively reweight the distillation loss. The distillation loss is emphasized in regions where features are hard to recover, improving the quality of feature reconstruction. Extensive experiments show that, compared with existing state-of-the-art methods, the proposed method more effectively reconstructs key discriminative regions in low-quality images and significantly enhances robust recognition performance.

2.To address the limitations of current robust recognition methods for low-quality images that rely on paired clean-degraded image data—leading to limited algorithm applicability and transferability—this work investigates the **intrinsic representation of data** and proposes a vector quantization-based quality-invariant feature learning method. Inspired by sparse representation learning and vector quantization techniques, the proposed method introduces a codebook (dictionary) module into the network to quantize the deep semantic features extracted by the model. This quantization process models the essential information in the feature data and eliminates redundant noise. Both qualitative and quantitative results

中国知网 https://www.cnki.net

demonstrate that the proposed method can extract quality-invariant representations from data without requiring paired images for training, and achieves better accuracy across multiple robustness benchmarks compared to other state-of-the-art approaches, while also providing stronger applicability.

3.To address the limitations of feature reconstruction-based methods that rely on synthetic degraded data, and the lack of explicit modeling of distributional shifts in data augmentation and domain generalization approaches, this work focuses on the **distribution of hard-to-classify confusing samples** and proposes an adversarial training method that generates difficult samples using gradient perturbations from neighboring classes. Specifically, the method perturbs the input image using gradients corresponding to easily confused categories that are adjacent to the true label, generating adversarial training samples. A class-wise distance-weighted loss is incorporated to increase inter-class dispersion. This method encourages the model to learn more robust features from error-prone data and enhances its robustness to distributional variations. Extensive experiments on various model architectures and benchmark datasets demonstrate that the proposed method outperforms existing approaches, requires fewer training iterations, and introduces no additional parameters.

Keywords: Deep Learning, Image Classification, Object Detection, Degraded Images, Robustness of Neural Network, Uncertainty, Vector Quantization, Adversarial Training

中国知网 https://www.cnki.net

插图索引

图 1.1 真实场景可能包含的部分图像退化种类示意图 2
图 1.2 本文主要工作及其组织结构框架图 8
图 2.1 仿真低质量图像及其对应的退化严重程度示例 15
图 2.2 真实低质量图像数据集 ExDark 与 RTTS 部分图像示例 16
图 2.3 其他鲁棒性基准数据集图像示例 17
图 2.4 基于图像复原的低质量图像识别方法示意图 18
图 2.5 Ada-YOLO[8]方法的网络结构 20
图 2.6 基于增强特征表示的低质量图像识别方法示例 22
图 2.7 FSR-GAN[13]方法的网络结构 23
图 2.8 DDP[14]方法的网络结构 23
图 2.9 几种不同的增广方法生成的图像示例 25
图 2.10 IoU 的计算，PR 曲线及 AP 值示例 26
图 2.11 Mnist 数据（左）及其 t-SNE 降维（右）分布示意图 28
图 2.12 CAM 类别激活图计算示例 31
图 2.13 Grad-CAM 基于梯度的类别激活图计算示例 31
图 3.1 HQ 与 LQ 图像的特征激活热力图示例 34
图 3.2 基于不确定性建模的自蒸馏特征表示增强方法框架示意 38
图 3.3 HQ 特征与重建的 HQ-like 特征及二者的归一化绝对值差异图示例 39
图 3.4 MSE 损失函数与不确定性加权的损失函数对比示意图 40
图 3.5 不确定性估计模块的网络结构示意图 41
图 3.6 本方法对常见数据增广方法的扩展示意图 46
图 3.7 COCO 数据集上低分辨小目标检测结果对比 47
图 3.8 不同方法提取的 HQ 和 LQ 图像深层语义特征可视化对比 48
图 3.9 不同方法提取的 HQ 和 LQ 特征的语义分布对比 49
图 3.10 不同退化严重程度下退化图像的不确定度-样本数量分布 50
图 4.1 清晰与退化图像模型的类别激活区域图示例 52
图 4.2 压缩编码中的向量量化过程示意图 54
图 4.3 通道注意力，空间注意力机制示例 56
图 4.4 特征拼接及自注意力机制特征融合模块示意图 60
图 4.5 基于向量量化的图像质量无关的特征表示学习方法框架 61

中国知网 https://www.cnki.net

图 4.6 ImageNet-C 基准数据集上每种损坏类型的不同方法的详细前 1 准确度结果 66
图 4.7 同一类图像不同退化种类的特征分布图 68
图 4.8 不同类图像的清晰-退化特征分布示意图 68
图 4.9 不同方法的类别激活图对比示例 69
图 4.10 不同方法的类别激活图对比示例（续） 70
图 4.11 真实场景对应模糊图像类别激活图对比示例 71
图 5.1 分布外数据错误预测的统计分析 77
图 5.2 各种退化下错误预测类与真实类的相似度序 k 与样本数量的关系图 78
图 5.3 各图像在各退化下的像素强度分布统计图 80
图 5.4 基础视觉大模型与 ViT-base 模型的类间相似度对比图 81
图 5.5 本章方法与标准对抗训练的区别示意图 82
图 5.6 基于近邻类梯度扰动的对抗训练方法示意图 84
图 5.7 ImageNet-D 部分图像数据示例 87
图 5.8 各方法在真实低质场景的目标检测结果对比展示 89

中国知网 https://www.cnki.net

表格索引

表 3.1 所提出方法的各模块有效性验证分析实验结果 43
表 3.2 不同损失平衡权重 λ 取值对退化图像的准确度影响实验结果 43
表 3.3 样本级及空间像素级不确定性估计的实验结果对比 43
表 3.4 ImageNet-C 数据集不同测试集上各方法整体性能对比 44
表 3.5 ImageNet-C 已知退化测试集上的各方法性能对比 45
表 3.6 ImageNet-C 未知退化测试集上的各方法性能对比 45
表 3.7 本章方法与各数据增广方法结合的性能对比 46
表 3.8 本章方法在低分辨率目标检测上的实验结果 47
表 4.1 本章方法各模块对模型低质图像的识别性能影响 64
表 4.2 本章方法与其他方法的参数量和计算效率对比 65
表 4.3 码本大小及对应参数量对模型性能的影响 65
表 4.4 ImageNet-C 数据集不同测试集上各方法整体性能对比 65
表 4.5 ImageNet-C 中 4 种未知退化测试集上的各方法性能对比 67
表 4.6 本章方法与数据增广算法的结合性能对比 67
表 5.1 多个鲁棒性基准测试集下各方法的性能对比 87
表 5.2 各个方法在 IN-C 和 IN-D 上的性能对比 88
表 5.3 各方法在 ImageNet-C 测试集上 19 种退化的详细性能对比 88
表 5.4 各方法在真实低质场景的目标检测 mAP 性能对比 90
表 5.5 本章方法的各模块对低质图像识别的性能验证 91
表 5.6 超参数 k 和 λ 的消融性实验结果 91

中国知网 https://www.cnki.net

符号对照表

符号	符号名称
$\boldsymbol{x}$	清晰图像
$\boldsymbol{x'}$	退化图像
f	目标识别模型
y	图像类别标签
c	类别 c
C	类别总数
θ	不确定度/标准差
Θ	模型参数
$\boldsymbol{z}$	清晰/高质量特征
$\boldsymbol{z'}$	退化特征
$\hat{\boldsymbol{z}}$	重建特征
∇	梯度
λ	权重惩罚因子
$\mathcal{L}$	损失函数
$\mathcal{N}$	正态分布
$\mathcal{P}$	泊松分布
N	样本数量/像素个数
W	全连接层权重/权重矩阵
$\boldsymbol{\alpha}$	稀疏表示系数向量
$\boldsymbol{k}$	key 张量
$\boldsymbol{q}$	query 张量
$\boldsymbol{v}$	value 张量
k	相似度序
$\mathcal{M}$	类间相似度矩阵
η	对抗攻击步长

中国知网 https://www.cnki.net

lr	学习率
y_c	真实标签
y_p	对抗攻击标签
α	类间相似度权重超参

中国知网 https://www.cnki.net

缩略语对照表

缩略语	英文全称	中文对照
Loss	Loss Function	损失函数
DNNs	Deep Neural Networks	深度神经网络
CNNs	Convolutional Neural Networks	卷积神经网络
ERM	Empirical Risk Minimization	经验风险最小化
IID	Independent Identically Distribution	独立同分布
OOD	Out Of Distribution	分布外
IR	Image Restoration	图像复原
VLM	Vision-Language Model	视觉语言模型
DM	Diffusion Model	扩散模型
GAN	Generative Adversarial Networks	生成对抗网络
FFT	Fast Fourier Transform	快速傅里叶变换
iFFT	Inverse Fast Fourier Transform	逆快速傅里叶变换
AT	Adversarial Training	对抗训练
mIoU	mean Intersection over Union	平均交并比
mAP	mean Average Precision	平均精确度
TP	True Positive	真阳率
FP	False Positive	假阳率
FN	False Negative	假阴率
mCE	mean Corruption Error	平均退化错误率
t-SNE	t-Distributed Stochastic Neighbor Embedding	t 分布随机邻接嵌入
KL	Kullback-Leibler divergence	KL 散度
CAM	Class Activation Map	类别激活图
Grad-CAM	Gradient-weighted CAM	基于梯度的类别激活图
T2I	Text to Image	文本到图像

中国知网 https://www.cnki.net

HQ	High-Quality Images	高质量图像（清晰图像）
LQ	Low-Quality Images	低质量图象（退化图像）
MSE	Mean-Squared-Error	均方误差
EU	Epistemic Uncertainty	认知不确定性
AU	Aleatoric Uncertainty	偶然不确定性
VQ	Vector Quantization	向量量化
SA	Self-Attention	自注意力机制

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 课题的研究背景与意义.....1
1.2 课题的研究现状与挑战.....4
1.3 本文的研究内容与章节安排.....6
1.3.1 研究内容及创新点.....6
1.3.2 章节和内容安排.....7
第二章 低质量图像的退化建模与鲁棒性目标识别方法.....11
2.1 退化模型及基准测试集.....11
2.1.1 图像退化模型.....11
2.1.2 低质量图像基准测试集.....14
2.2 鲁棒性目标识别方法.....17
2.2.1 基于图像复原的方法.....17
2.2.2 基于增强特征表示的方法.....21
2.2.3 基于数据增广的方法.....24
2.3 鲁棒性评估指标.....26
2.4 模型特征可视化与可解释性分析方法.....28
2.4.1 t-SNE.....28
2.4.2 CAM.....29
2.4.3 Grad-CAM.....30
2.5 本章小结.....31
第三章 基于数据特征不确定性建模的鲁棒目标识别方法.....33
3.1 引言.....33
3.2 方法简介及相关基础知识.....33
3.3 基于特征表示增强的低质量图像目标识别.....36
3.4 基于数据不确定性建模的特征表示增强.....38
3.4.1 退化特征的不确定性.....38
3.4.2 自特征蒸馏网络结构与训练目标函数.....41
3.5 实验结果.....42
3.5.1 实验设置.....42
3.5.2 消融实验及复杂度分析.....43
3.5.3 鲁棒性分类的实验结果.....44
3.5.4 扩展数据增广训练实验结果.....46
3.5.5 低分辨率图像目标检测实验.....47
3.5.6 特征可视化结果分析.....48

中国知网 https://www.cnki.net

3.5.7 不确定性估计的有效性验证.....49
3.6 本章小结.....50
第四章 基于数据本征表示学习的鲁棒目标识别方法.....51
4.1 引言.....51
4.2 方法简介及相关基础知识.....51
4.3 基于向量量化的低质量图像本征表示学习方法.....57
4.3.1 混合低质量数据的本征表示.....57
4.3.2 量化特征融合及判别性增强.....59
4.3.3 整体网络框架及损失函数.....61
4.4 实验结果.....63
4.4.1 实验设置.....63
4.4.2 消融实验及复杂度分析.....64
4.4.3 鲁棒性分类的实验结果.....65
4.4.4 鲁棒性分析.....66
4.4.5 本质特征的可视化分析.....68
4.5 本章小结.....71
第五章 基于生成语义近邻难样本数据的鲁棒目标识别方法.....73
5.1 引言.....73
5.2 方法简介及相关基础知识.....73
5.3 分布外数据的统计分析.....75
5.3.1 错误预测统计.....75
5.3.2 像素值分布偏移.....76
5.3.3 类间相似性分析.....81
5.4 基于生成近邻类扰动数据的对抗训练方法.....81
5.4.1 近邻类易混淆扰动样本生成.....81
5.4.2 与标准对抗训练的区别：对比分析.....82
5.4.3 类间距离加权损失函数.....83
5.4.4 整体网络框架和训练流程.....84
5.5 实验结果.....85
5.5.1 实验设置.....85
5.5.2 鲁棒性分类的实验结果.....87
5.5.3 真实低质场景的目标检测结果.....89
5.5.4 消融实验及方法效率分析.....90
5.6 本章小结.....92
第六章 总结与展望.....93
6.1 研究总结.....93
6.2 研究展望.....94
参考文献.....97

中国知网 https://www.cnki.net

第一章　绪论

1.1 课题的研究背景与意义

目标识别任务，旨在从成像设备采集到的数字图像输入中，依据模型或算法提取的特征，对感兴趣的目标进行分类、定位、或分割等。随着深度学习及计算机视觉技术的不断发展，目标识别算法愈发成熟。部分识别模型在一些基准测试集上的性能已超越人类水平，在许多实际应用中已成为不可或缺的组成部分，以实现应用系统的自动化和智能化。举例来说，自动驾驶系统依赖目标识别算法进行感知理解，其性能直接影响后续的决策规划执行等；智能监控系统中需要目标识别算法对特定模式进行识别，如人员徘徊检测、行人摔倒识别、设备故障告警等；医疗影像分析系统需要对病灶区域识别和定位，为医生提供诊断参考；工业自动化系统依靠智能化识别算法进行异常/缺陷检测、流水线执行等，以减轻机械化、重复化操作的人力资源浪费。综上所述，目标识别算法是智能系统的基石，其准确性和稳定性是系统有效性和可靠性的保障。

基于深度学习的目标识别算法通常依赖于大量标注完备的图像数据，这些数据通常来源于网络搜集或真实拍摄的高质量清晰图像。通过构建损失函数（Loss Function，Loss）并训练包含大量参数的深度神经网络模型（Deep Neural Networks，DNNs），实现端到端（End to End）的目标识别任务。模型的训练过程主要基于经验风险最小化（Empirical Risk Minimization, ERM）理论。即当模型在训练集上的损失函数收敛至一个较小的值时，其在测试集上的性能通常也表现较好。这一过程可以通过以下数学公式进行描述：

$$f_{\boldsymbol{\theta}}^{*} = arg\min_{\boldsymbol{\theta}} \mathbb{E}[\mathcal{L}(f_{\theta}(\boldsymbol{x}), y)], \tag{1-1}$$

公式中，$\boldsymbol{x}$ 表示输入图像，y 表示对应的类别标签，$f_{\boldsymbol{\theta}}$ 表示参数为 $\boldsymbol{\theta}$ 的目标识别模型，$\mathcal{L}$ 为损失函数，用于量化模型的输出 $f_{\boldsymbol{\theta}}(\boldsymbol{x})$ 与真实标签 y 之间的误差。为了确保通过训练优化得到的模型在未知的测试集数据上仍能表现出较高的性能，经验风险最小化方法依赖于一个关键的基本假设：训练数据和测试数据必须满足独立同分布（Independent and Identically Distributed, IID）条件：

$$P_{tr}(\boldsymbol{X}, \boldsymbol{Y}) = P_{te}(\boldsymbol{X'}, \boldsymbol{Y'}), \tag{1-2}$$

其中 tr，te 分别代表训练（Training）和测试（Testing）。$P(\cdot)$ 为联合概率分布。这

中国知网　https://www.cnki.net



高斯噪声　　运动模糊　　雾图　　亮度过曝

图 1.1　真实场景可能包含的部分图像退化种类示意图

一假设要求训练数据和测试数据在统计上相互独立，且来源于相同的概率分布，即它们共享相同的数据生成机制和统计特性。这一假设是经验风险最小化理论的基础，它确保了在分布一致的条件下，模型通过最小化训练集上的损失函数，能够有效地捕捉数据的内在特征和类别之间的判别边界，模型在训练集上学习到的统计规律能够有效地泛化到测试集上，进而在测试集上表现出较高的分类准确率和鲁棒性。大量文献研究和实验结果表明，当训练数据和测试数据的分布保持一致时，基于经验风险最小化原则训练的识别模型能够展现出与理论预期高度一致的优越性能。

然而，如图 1.1 所示，在真实场景下采集到的图像常常因各种因素而受到严重退化，导致图像成像质量远低于理想状态。低质量图像通常包括噪声、模糊、低分辨率、低对比度、亮度变化以及复杂的环境干扰等。例如，自动驾驶系统中的摄像头由于天气因素（如雨雪、雾霾）或复杂的光照条件，往往会捕获到低质量图像；类似的，安防监控中的图像由于设备限制或环境影响，可能包含模糊或噪声，导致目标识别的准确率显著下降；在医疗影像领域，低质量的 X 光片、CT 图像或 MRI 图像可能因为噪声干扰或分辨率不够、被测对象移动而产生成像模糊等，给医生的诊断带来困难，进而影响患者的后续治疗效果。这些问题的存在，使得整个模型的训练和测试过程不再遵循式 (1-2) 的 IID 假设，即测试数据是分布外（Out-Of-Distribution，OOD）的：

$$P_{tr}(\boldsymbol{X}, \boldsymbol{Y}) \neq P_{te}(\boldsymbol{X'}, \boldsymbol{Y'}). \tag{1-3}$$

在这种条件下，即使模型在训练数据上获得了较高的准确度，由于测试数据与训练集有较大的分布差异，模型在测试集上的性能也难以保证。而且，从图像的视觉感知效果上，图像退化使得图像的细节信息丢失，其关键特征难以被有效提取，目标识别方法在面对这些退化图像时，往往表现出较差的性能。

此外，基于深度学习的目标识别方法往往依赖于高质量的图像数据和大量的标注数据，而在许多实际场景中，低质量图像数据较为常见，且很难获得大规模对应的标注数据。例如，在灾难场景、事故发生后的环境监控、低光照环境下的安防监控等

中国知网　https://www.cnki.net

领域，罕见的疾病病理学图像等，图像质量较差且标注数据匮乏，这使得对应的目标识别方法的适用性受到极大限制。综上所述，这些低质量图像的存在，不仅给目标识别算法带来了挑战，还影响了系统的稳定性和可靠性。因此，如何在缺乏大量低质量图像标注数据的情况下，提升模型在低质量图像下的鲁棒性目标识别性能，不仅是计算机视觉领域中的重要研究方向之一，也是许多实际应用中提高系统稳定性的关键。

对于低质量图像的鲁棒性识别，研究的核心在于如何应对图像退化带来的影响，保持目标识别的准确性和鲁棒性。即在未知的、退化图像的条件下，保持较高的识别性能。因此，对于分布外（OOD）的鲁棒性目标识别问题，有如下的目标：

$$\begin{aligned} \boldsymbol{f}_{\boldsymbol{\theta}}^{*} &= arg\min_{\boldsymbol{\theta}} \mathbb{E}_{\boldsymbol{x},y\in P_{te}}[\mathcal{L}(\boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{x}),y)] \\ s.t. &P_{te}(\boldsymbol{X},\boldsymbol{Y}) \neq P_{tr}(\boldsymbol{X'},\boldsymbol{Y'}). \end{aligned} \tag{1-4}$$

现有的许多方法在一定程度上缓解了图像降质的问题，如通过图像去噪、超分辨率重建、图像增强等技术来改善图像质量，但这些方法通常是针对特定类型的图像退化进行设计，并且效果往往依赖于退化模型的假设，难以广泛适应各种实际场景中的低质量图像。另外，该方法恢复出的图像往往可能仍与训练集存在较大的数据分布差异，即使视觉感知质量得到了提升，对于识别网络的性能提升也可能有限。并且联合图像复原模型和目标识别模型的低质量图像识别方法计算量较大，实际系统难以部署。

在应对低质量图像的鲁棒识别问题时，还有一些方法聚焦于直接提升模型提取的特征质量。如基于成对图像的特征重建方法、基于数据增广或迁移学习的方法被提出并应用。这些方法只需要用部分数据微调目标识别模型即可获得性能提升。额外参数少，训练额外耗时相对较低，因而受到广泛关注。基于成对图像的特征重建方法通过使用清晰图像与退化图像的对映关系，将清晰图像的特征作为教师网络输出，指导学生网络学习退化图像的特征。然而，这种方法在实际应用中存在一定的局限性。首先，成对图像的获取往往需要大量的标注数据，这在一些应用场景中是不可行的；其次，成对图像的特征蒸馏假设两种图像之间具有明确的一一对应关系，而在复杂的低质量图像场景下，图像之间的退化模式可能并不对称，且特征区域间的识别重要性不同，导致模型在这种假设下表现不佳。

与此相对，基于数据增广或迁移学习的方法通过对清晰图像进行各种形式的增广（如旋转、缩放、裁剪、仿真退化，对抗攻击等），创建出更多样化的训练样本，并结合迁移学习方法将源领域的知识迁移到目标领域，从而提升模型的泛化能力。这种方法的优点在于无需成对图像的依赖，能够通过增广生成更多变异样本，提高模型的鲁棒性。然而，尽管这种方法在数据稀缺的情况下表现较好，仍然面临一些挑战。

中国知网　https://www.cnki.net

首先，数据增广依赖于模型对增广图像的多样化训练，然而增广样本可能无法覆盖所有可能的退化类型，导致模型在面对未见过的退化模式时仍然表现不佳；其次，迁移学习的效果高度依赖于源领域和目标领域的相似性，当两个领域差异较大时，迁移学习的性能也会受到显著影响。此外，现有的工作通常缺乏对数据增广策略有效性的系统消融研究。尽管数据增广是提升低质量图像识别性能的有效手段之一，但不同增广策略在不同任务和数据集上的效果差异较大。因此，深入探讨各种数据增广方法的有效性及增广数据的分布对模型性能的具体贡献，对于优化低质量图像的鲁棒识别方法具有重要的意义。

针对上述低质量图像鲁棒性识别算法的不足之处，本文围绕低质量图像的目标识别问题展开研究，深入探究低质数据的不确定性、非成对不同质量图像数据的本质特征提取、易混淆难样本数据的类别分布等内容，并提出相应的三种创新的鲁棒性目标识别方法。专注于低质量图像的特征建模与优化。实验结果表明，本文提出的方法对于低质量图像的识别性能显著优于国内外先进的相关工作。接下来本节首先对低质量图像的鲁棒性识别方法的研究进展和现状进行综述。

1.2 课题的研究现状与挑战

（1）基于图像复原的低质量图像目标识别

基于图像复原（Image Restoration，IR）的低质量图像识别方法旨在通过对退化图像进行修复或增强，使其质量接近于清晰图像，从而提升目标识别的准确性。这类方法通常结合图像复原网络，进行图像去噪、去模糊、超分辨率、暗光增强等操作，以处理噪声、模糊、低光照等退化问题，并将恢复后的图像输入识别网络中进行目标识别。传统方法通常将图像复原与识别任务分离，专注于单一退化类型的处理。例如，SwinIR[1]利用 Swin Transformer 架构，通过多尺度特征处理机制在去噪、超分辨率等任务中取得了显著效果；NAFNet[2]提出了一种简单的基线模型，通过去除非线性激活函数降低了计算量，同时提升了复原效果；AirNet[3]则设计了一个多合一图像恢复网络，能够处理多种退化类型，无需先验知识。然而，研究表明，仅提升图像视觉质量并不总能改善识别性能，因为复原图像与清晰图像之间可能存在分布偏移[4-5]。例如，文献[4]指出，去雾等复原方法甚至可能对分类性能产生负面影响。

为解决这一问题，研究者提出了识别友好的图像复原方法，将图像复原与识别任务联合优化。例如，URIE[6]提出了一种通用且兼容识别任务的图像增强网络，能够处理多种退化类型，并通过联合损失函数同时优化图像质量和识别性能。类似地，MAET[7]通过多任务自动编码变换模型，在低光照条件下同时预测图像退化参数和目标检测结果，显著提升了检测性能。此外，Ada-YOLO[8-9]框架通过端到端联合训练图

中国知网 https://www.cnki.net

像复原模块与目标检测器，在恶劣天气条件下实现了显著的性能提升。这些方法的核心思想是通过联合损失函数同时优化复原与识别任务。

近年来，多模态视觉-语言模型（Vision-Language Model，VLM）和扩散模型的引入为图像复原提供了新的解决思路。例如，PromptIR[10]通过文本提示编码退化信息，动态指导恢复网络，在去噪、去雨和去雾任务中取得了最先进的结果；SeeSR[11]利用语义提示增强预训练的文本到图像模型，生成富有细节且语义正确的超分辨率图像；AutoDIR[12]则结合隐空间扩散模型（Diffusion Model，DM）和盲图像质量评估模块，实现了对多种未知退化的自动检测与恢复。这些方法通过结合视觉信息与语言文本描述，进一步提升了图像复原的效果。

尽管基于图像复原的低质量图像识别方法在恶劣环境下显著提升了识别性能，但仍面临一些挑战。首先，现有方法通常针对单一退化类型，难以处理复杂场景中的多种退化；其次，复原图像与清晰图像之间的分布偏移问题尚未完全解决；最后，先复原再识别的两阶段框架计算效率较低，难以实际部署。

（2）基于增强特征表示的低质量图像目标识别

文献[13-15]指出，低质量图像识别性能下降的根本原因在于特征退化。为此，研究者提出了通过增强特征表示来提升识别性能的方法，直接对低质量图像进行特征蒸馏或重建，恢复关键信息，缩小低质量与高质量图像之间的分布差异。这类方法避免了像素级复原的计算冗余，通过在特征空间优化，直接恢复图像的重要特征，从而提升目标识别能力。

针对低分辨率小目标识别问题，文献[13]提出了特征超分辨率方法（FSR-GAN），通过特征生成网络和判别器的对抗训练，将小尺寸目标的弱特征转化为更具辨识能力的特征。实验表明，FSR-GAN 显著提升了小目标的表征能力，在分辨率降至原始 1/64 时，检索准确率提高了 25% 。文献[14]提出了深度退化先验（DDP）模型，通过特征去漂移模块（FDM）学习低质量与高质量图像特征之间的映射关系。DDP 在 ImageNet-C 数据集上显著提升了分类准确率，尤其在有限数据场景下表现优异。文献[15]则提出了一种基于可逆神经网络的训练范式，通过两阶段训练生成干净且鲁棒的特征，提升了低质量图像的识别性能。

这些方法的优势在于直接增强特征表示，避免了像素级重建的计算开销，但其依赖高质量与低质量图像的配对数据，且在复杂退化场景下的适应性仍有待提升。

（3）基于图像增广的低质量图像目标识别

在真实场景中，尤其是在恶劣天气条件下，低质量图像及其标注数据往往较为稀缺。基于图像增广的低质量图像识别方法通过组合、剪贴或利用扩散模型（DM）

中国知网　https://www.cnki.net

生成增广数据，模拟不同数据分布，扩展训练数据并增强模型鲁棒性。传统方法如 MixUp[16]和 CutMix[17]通过线性组合或剪切粘贴生成新样本，而 AugMix[18]和 AutoAugment[19]则通过随机增强或强化学习优化增强策略。近年来，生成对抗网络[20]（Generative Adversarial Networks，GAN）和扩散模型（如 DiffMix[21]）被用于生成更逼真的增广图像，尤其在目标检测任务中表现出色。此外，对抗训练[22-23]（Adversarial Training，AT）通过生成对抗扰动图像，不仅提升了模型对对抗攻击的鲁棒性，还增强了其在低质量图像上的适应能力。迁移学习则通过在高质量图像数据集上预训练模型，并通过少量微调适应低质量图像，进一步提升了识别性能。数据增广与迁移学习的结合，尤其在缺乏低质量退化数据的情况下，能够显著提高模型的泛化能力和识别准确性。

1.3 本文的研究内容与章节安排

1.3.1 研究内容及创新点

近年来，研究者们提出了多种低质量图像的鲁棒性识别方法，包括基于图像恢复的识别、基于特征增强的识别，以及基于数据增广、对抗训练和迁移学习的鲁棒性识别方法，这些方法在一些低质量图像的基准测试集上的目标识别性能取得了显著提升。然而，现有的低质量图像鲁棒性识别方法仍然存在一些值得关注的问题。首先，尽管基于图像去噪、超分辨率重建等图像复原方法在一定程度上缓解了图像质量下降的影响，但这些方法大多依赖于特定的退化模型，难以应对各种复杂和动态的低质量图像。此外，采用先恢复再识别的策略通常计算量较大，导致其在实际应用中难以广泛部署。其次，现有基于成对图像特征蒸馏的方法未充分考虑退化特征的不确定性以及不同特征区域在目标识别中的重要性，从而限制了特征表达的增强效果。这使得模型在处理低质量图像时，往往难以在关键区域上获得足够的辨识力。最后，现有基于图像增广或迁移学习的方法大多缺乏对源域数据分布有效性的认知。即，如何生成合适的增广数据以提升模型的泛化能力仍然是一个挑战。没有明确的数据分布生成策略，往往会导致增广样本的多样性和模型训练的效果不尽如人意。这些问题在一定程度上限制了低质量图像鲁棒性目标识别性能的进一步提升，因此，迫切需要新的方法来解决上述挑战。

针对现有的低质量图像鲁棒识别方法存在的问题，本文提出了三种创新的鲁棒性识别方法，旨在提升低质量图像在实际应用中的识别性能。本文的主要工作如下：

1. 针对现有基于图像复原的双阶段方法计算量大，基于成对图像特征重建方法未充分考虑退化数据的不确定性以及不同特征区域在目标识别中的重要性的问题，本文提出了一种基于特征不确定性建模的自蒸馏方法。在传统的特征重建方法中，通常

中国知网 https://www.cnki.net

忽略了低质量图像中特定区域的识别难度差异，导致模型在某些关键区域的特征重建效果较差。通过引入不确定性建模，本文方法能够自适应地识别并关注图像中具有较高不确定性的区域，自适应地对这些区域赋予更高的蒸馏权重，从而有效提升了低质量图像的特征重建精度。通过这种方式，模型不仅能够更好地恢复低质量图像特征中的难以重建的细节，还能在多种低质量图像环境中保持较高的识别能力。

2. 针对现有的特征增强方法通常需要依赖于成对的清晰-仿真退化图像作为输入，以清晰图像的特征作为监督指导。但在实际应用中，图像的退化类型和程度往往复杂且动态变化，且难以获得成对输入，导致现有方法的适应性差的问题，本文提出了一种基于向量量化的图像质量无关的表示学习方法。通过在向量量化变分自编码器框架下对混合质量图像进行特征学习，将不同质量输入图像的特征分布编码映射至同一空间，构建了一种不依赖于图像质量的稳定表征，有效缓解了图像特征中噪声和退化带来的干扰影响。与传统的依赖成对图像的训练方法不同，本文方法能够在无需成对清晰-仿真退化图像的情况下，提取出具有较高鲁棒性的特征，显著提升了低质量图像的目标识别性能。

3. 针对现有数据增广对抗训练等方法缺乏对增广数据分布有效性的认知问题，本文提出了一种基于近邻样本梯度扰动的对抗训练方法。传统的对抗训练方法通常通过梯度负向生成远离真实标签的对抗样本来提高模型的鲁棒性，但这种方法生成的图像数据分布是未定的，增广数据对特定模型的有效性未知。在真实低质量图像的识别中往往无法充分针对特定模型的弱点进行设计，即易出错、泛化差的类别，导致模型鲁棒性提升有限。本文通过引入近邻样本梯度扰动策略，有效生成对特定类别具有挑战性的对抗样本，使得训练过程能够关注针对特定模型的数据分布空间中的易错困难样本。通过在训练过程中引入这些高难度的对抗样本，模型能够更好地适应低质量图像的退化特性，从而在复杂环境中具有更强的鲁棒性。此外，本方法不依赖于特定的退化模型，无需生成各种仿真退化图像，而是通过扰动生成分布多样的对抗样本，进一步提升了模型在实际应用中的泛化能力。

本文提出的核心算法在输入数据要求上逐步优化，从成对的清晰-仿真低质图像到混合不同质量图像，再到无需任何仿真退化的扰动图像。这一递进过程构建了一个更为全面的低质量图像鲁棒性识别框架，为低质量图像的识别问题提供了新的解决思路。

1.3.2 章节和内容安排

本文的组织结构和章节安排如图所示：

第一章 绪论

主要介绍低质量图像的鲁棒性识别技术背景和研究意义，目前国内外相关工作

中国知网　https://www.cnki.net

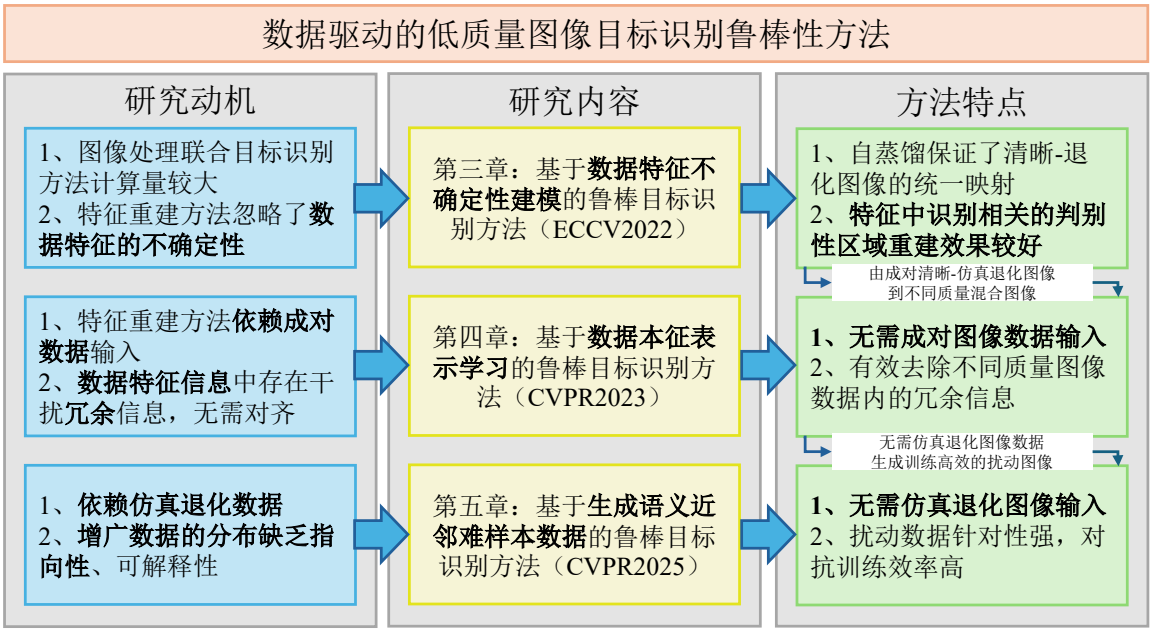


图 1.2　本文主要工作及其组织结构框架图

的研究进展及综述，本文的主要工作及后续的章节安排等。

第二章 现有低质量图像鲁棒性识别方法简介

本章首先简要介绍了低质量图像及其退化模型，并介绍相关基准评测集，评价指标和可视化方法等。然后介绍了在低质量图像上进行鲁棒性识别的方法，包括基于图像复原的鲁棒识别、基于特征蒸馏的鲁棒识别、基于数据增广的鲁棒识别等。

第三章 基于数据特征不确定性建模的鲁棒目标识别方法

本章首先将低质量图像的特征增强过程形式化为最大后验概率估计问题，并构建了一个联合分类与特征恢复的优化目标。随后，围绕特征重建任务，介绍了一种依赖成对图像的特征蒸馏方法，并分析了其潜在局限性。在此基础上，引入数据不确定性建模思想，提出一种基于特征不确定性的自蒸馏策略以及相应的自适应加权损失函数。最后，本文在多个典型鲁棒性评估基准上对所提出方法的有效性进行了系统实验和性能评估。

第四章 基于数据本征表示学习的鲁棒目标识别方法

本章首先介绍了基于向量量化的稀疏字典表示学习在数字信号处理中去冗余的重要作用，并回顾了离散向量量化的变分自编码器的相关工作。接着，结合低质量图像特征去冗余和数据本征表示学习的目标，提出了一种新的图像质量不敏感的特征表示学习方法。该方法无需成对图像，而是将混合质量的图像输入映射至同一分布空间，并进行特征表示增强。最后，本章详细介绍了该方法的整体框架和训练目标函数，并在多个鲁棒性基准测试集上对其性能进行分析和验证。

第五章 基于生成语义近邻难样本数据的鲁棒目标识别方法

中国知网　https://www.cnki.net

本章首先介绍了基于数据增广和对抗训练的鲁棒性识别方法。接着，进行了不同模型在不同退化低质量图像上的测试，并观察和统计了发生预测错误的图像及其标签。通过分析，发现错误预测通常发生在真实标签值附近，且不同模型在面对低质量图像时，存在特定类别的敏感性差异。这一观察表明，低质量图像的误分类往往集中在易混淆的类别边界区域。基于这一发现，本文进一步提出了近邻类梯度对抗扰动的方法。该方法通过生成与当前样本相似但更加具有挑战性的对抗样本数据，利用这些样本对模型进行训练，从而增强模型对边界区域的鲁棒性。具体而言，近邻对抗扰动通过计算邻近样本之间的梯度信息，扰动那些易于被误分类的图像，迫使模型更加关注难以识别的区域，提升模型在低质量图像下的辨识能力。最后，在多个鲁棒性基准测试集上验证了该方法的有效性和优势。

第六章 总结与展望

本章对提出的三个方法进行总结，分析其各自优缺点及方法间的内在联系。并结合近期国内外涌现的视觉基础大模型及文本-视觉多模态模型对未来的这一研究方向进行展望。

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net

第二章　低质量图像的退化建模与鲁棒性目标识别方法

在实际应用中，图像常常受到噪声、模糊、低分辨率、光照变化等多种因素的影响，导致图像质量显著下降。因此，对低质量图像等分布外数据进行鲁棒性目标识别是计算机视觉领域中的一项关键挑战。为了应对这一问题，近年来研究者们提出了多种方法来提升模型在低质量图像下的识别能力。这些方法大致可以分为图像恢复、特征增强、数据增广、对抗训练以及迁移学习等几大类。基于图像恢复的方法通常通过去噪、超分辨率重建等手段改善图像质量，从而间接提高目标识别性能；而特征增强方法则致力于通过对低质量图像的特征进行增强或复原，改善模型的识别效果。数据增广与对抗训练方法则通过生成多样化的训练数据，增强模型对未知或退化数据的适应能力，进一步提升其鲁棒性。本章接下来将首先介绍相关的退化模型、基准测试集、评价指标及可视化方法，随后系统回顾现有的低质量图像鲁棒性识别方法。具体地，首先介绍基于图像恢复与特征增强的相关研究，并分析其在图像质量恢复与特征提取方面的优势与局限；接着，探讨数据增广、对抗训练和迁移学习方法，重点分析其在低质量图像处理中的应用效果及面临的挑战。最后，在对这些方法进行综合分析的基础上，为后续提出的改进方法奠定理论支撑和实践依据。

2.1 退化模型及基准测试集

2.1.1 图像退化模型

低质量图像通常是指因多种因素（如传感器噪声、模糊、光照不足、压缩失真等）导致视觉质量下降的图像。这些因素不仅可能引起图像细节丢失、纹理模糊和对比度下降，还可能导致结构扭曲、颜色失真，甚至信息的局部缺失，从而显著影响目标识别模型的特征提取与判别能力。此外，低质量图像可能会导致模型对特征的不稳定响应，增加错误分类的风险，甚至在某些情况下使模型以较高置信度将目标误分类，严重影响识别精度和鲁棒性。

在实际应用中，低质量图像广泛存在于多种复杂场景中，例如夜间监控、恶劣天气下的自动驾驶、医学成像中的低剂量 X 射线或超声波图像、远程遥感观测、视频压缩存储以及高速运动目标的拍摄等。这些场景中的图像质量退化通常受到多种因素的叠加影响，具有高度的不确定性和复杂性。因此，为了模拟和研究低质量图像对目标识别的影响，并提升识别算法在复杂退化条件下的鲁棒性，通常需要构建相应的退化模型来刻画不同类型的质量退化过程。退化模型不仅能够帮助分析不同类型的退化对识别任务的影响，还可以用于合成多样化的低质量图像数据，以扩充训练数据

中国知网　https://www.cnki.net

集，提高模型在不同退化条件下的适应能力。此外，在性能评估阶段，基于退化模型构建标准化测试集，有助于全面衡量算法在不同退化场景下的稳健性。

低质量图像的退化模型通常可以分为几种典型类型，包括噪声污染、运动模糊、天气退化（如雨、雪、雾）、对比度变化、光照不足或过曝，以及低比特率压缩导致的损失性失真等。每种退化模型对应不同的退化源，影响图像质量的方式各异。一般而言，噪声和模糊是低质量图像中最常见的退化类型，前者主要表现为图像像素级别的随机干扰，后者则导致目标边缘模糊、纹理细节丢失。下面将重点介绍这两类退化模型，并分析其对目标识别任务的影响。

（1）噪声退化模型

噪声是低质量图像中最常见的退化类型，在低光照条件或传感器性能较差的情况下尤为显著。噪声的产生通常与传感器的长期工作、过高的热度导致的热噪声、以及电路元件之间的相互影响有关。噪声在图像中表现为孤立的像素点或像素块，造成图像像素值与真实场景或理想图像之间的随机扰动，进而影响图像的可视效果。

常见的噪声模型主要分为加性噪声和乘性噪声两大类。也可依据其是否与原始图像信号相关进行分类。其中，高斯噪声是最为常见的加性噪声类型，它假设每个像素值都受到独立同分布的高斯噪声影响。高斯噪声通常表现为全局性的图像干扰，导致细节模糊和对比度降低，尤其在图像的低对比度区域，噪声的影响更为显著。椒盐噪声，也称脉冲噪声，通常由图像传感器、传输信道或解码处理等环节引起，表现为图像中的随机亮暗点或色彩突变。它通常模拟了传感器或通信过程中出现的错误，如数据传输丢包或图像压缩过程中的信息损失。泊松噪声则与图像的采集过程密切相关，尤其在低光照环境下尤为明显。其噪声水平随着光强度的变化而变化，常见于低照度图像或医学成像等领域。与高斯噪声不同，泊松噪声的强度与图像的实际像素值相关，因此在较亮区域，噪声较低；而在较暗区域，噪声则相对较强。另外，在雷达系统成像领域常见的是乘性噪声。本文仅讨论常见的自然可见光图像的加性噪声情况。总体来说，噪声退化模型可以用如下公式表示：

$$\boldsymbol{x'} = \boldsymbol{x} + \epsilon, \tag{2-1}$$

其中 $\boldsymbol{x}$ 为清晰图像，$\boldsymbol{x'}$ 为观测到的含噪图像，$\epsilon \in \mathcal{N}(\mu, \sigma^2)$ 是满足均值为 μ 方差为 σ^2 的高斯分布，或者 $\epsilon \in \mathcal{P}oisson(\boldsymbol{x})$ 满足噪声强度与输入有关的泊松分布。

（2）模糊退化模型

模糊退化是低质量图像中常见的图像质量问题，通常在拍摄过程中，由于多种因素，如相机抖动、焦距不准确或景物快速运动等，导致图像模糊。模糊现象会导致图

中国知网 https://www.cnki.net

像细节丧失、轮廓不清晰、边缘模糊，从而显著降低图像的辨识度，影响后续目标识别和其他计算机视觉任务的准确性。模糊退化通常通过卷积运算建模，根据不同的退化源和原因，使用不同的模糊核来构成相应的模糊类型。

常见的模糊类型主要包括高斯模糊、运动模糊和散焦模糊三种。高斯模糊是最为常见的图像模糊类型，它通过将图像与高斯模糊核进行卷积，产生平滑效果，使得图像的细节逐渐模糊，且对比度降低。尽管高斯模糊常用于图像去噪处理，但它也会导致图像在视觉上变得不清晰，尤其是在低对比度区域。运动模糊通常发生在相机或物体之间的相对运动下，在动态场景中尤为常见，例如长时间曝光、拍摄高速移动物体或手持设备抖动时。运动模糊的特点是产生方向性模糊，图像中的物体或边缘会沿着运动方向延伸，形成条纹或拖影效果。散焦模糊则是由焦距不准确或镜头调焦不当引起的，通常表现为图像的某些区域失焦，导致图像出现明显的模糊效果。散焦模糊的特点是图像的某一部分保持清晰，而其他部分由于焦距误差而变得模糊。这种模糊尤其常见于低质量的成像设备或焦距调整不精确的情况下。如上所述，模糊退化可以通过如下公式进行建模：

$$\boldsymbol{x}' = \mathcal{B}(\boldsymbol{x}, \boldsymbol{k}) + \boldsymbol{n}, \tag{2-2}$$

其中 $\boldsymbol{x}$ 为清晰图像，$\boldsymbol{x}'$ 是观测到的模糊图像。$\mathcal{B}(\cdot, \boldsymbol{k})$ 表示具有模糊核 $\boldsymbol{k}$ 的模糊算子，通常以卷积的方式实现。$\boldsymbol{n}$ 则表示加性高斯噪声。

除此之外，常见的图像退化类型还包括雨雪雾霾、低/过曝光、图像压缩失真等。自然天气因素如雨雪雾霾会导致图像的模糊和对比度降低，同时增加遮挡和噪声，从而使得目标识别更加困难。低曝光和过曝光是图像退化中常见的亮度失衡问题。过度曝光会导致图像的高光区域细节丧失，造成图像的部分区域出现纯白色或过曝，而低曝光则使图像整体变暗，细节不清，无法有效辨识。图像压缩失真则在图像压缩过程中产生，特别是在压缩率较高时，图像细节容易丧失，并且出现明显的图像块效应，影响图像的质量和可识别性。

这些退化类型的出现不仅使图像的视觉效果下降，也直接影响了后续的目标识别、图像分割、物体检测等计算机视觉任务的准确性与鲁棒性。退化后的图像可能会导致细节丧失、对比度降低、噪声增加等问题，进而使得视觉模型难以提取有效特征，从而影响模型在低质量图像上的识别性能。因此，如何应对这些退化类型，恢复图像质量并提高识别准确性，成为了当前计算机视觉领域中的重要研究问题。

为了应对低质量图像带来的挑战，通常可以在模型的微调训练阶段，基于上述退化模型，仿真生成各种退化图像数据。这一过程有助于模型在面对各种退化场景时，提升其泛化能力。具体来说，对于一个已有的清晰图像数据集 $\mathcal{D} = \{\boldsymbol{x}, y\}$，其中 $\boldsymbol{x}$ 是清晰的原始图像，y 是对应的所属类别标签。训练过程中，可以使用多个退化函数

中国知网　https://www.cnki.net

模型 $\Phi = \{\varphi_0, \varphi_1, \varphi_2, \ldots, \varphi_n\}$ 来生成不同类型的退化图像。每个退化函数 φ_k 对应一种特定的退化类型，如模糊、噪声或压缩等。给定一张原始图像 $\boldsymbol{x}$，退化后的图像 $\boldsymbol{x}'$ 可以通过以下公式生成：

$$\boldsymbol{x}' = \varphi_k(\boldsymbol{x}), \tag{2-3}$$

其中，单位变换函数 φ_0 满足 $\boldsymbol{x} = \varphi_0(\boldsymbol{x}) = I(\boldsymbol{x})$，并包含在函数集合 Φ 中。该函数用于在训练集中保留原始的干净图像，确保在微调过程中模型在干净图像上的性能不下降，防止灾难性遗忘现象的出现。

综上所述，图像的退化模型在低质量图像识别任务中发挥了至关重要的数据层面作用。它能够有效模拟现实场景中常见的图像质量下降情况，并为识别模型提供多样化的训练数据。通过引入不同类型的退化（如噪声、模糊、压缩等），所生成的仿真退化图像能够帮助模型学习各种退化条件下的特征模式，从而提升其对低质量图像的适应能力和泛化能力。这不仅使模型能够在复杂环境下保持较稳定的识别性能，还为评估不同方法的鲁棒性提供了标准化的测试手段。

2.1.2 低质量图像基准测试集

为了评估低质量图像鲁棒性识别算法的性能，研究者们创建了多个基准测试集。这些测试集通常可分为两种类型的图像数据：一类是通过退化模型仿真生成的低质量图像，另一类则是来自实际场景中的真实低质量图像。通过这两种图像数据，基准测试集能够更全面地模拟真实世界中的图像质量问题，进而帮助评估算法在多种退化情境下的鲁棒性和识别能力。

（1）仿真低质量图像基准数据集

文献[24]中提出了一种包含 5 个大类、19 种细分退化类型的退化模型，用于构建仿真退化图像的测试集。这 5 个大类包括噪声、模糊、天气、数字退化以及其他退化类型。具体的 19 种细分退化类型分别为：高斯噪声、散粒噪声、脉冲噪声；散焦模糊、毛玻璃模糊、运动模糊、变焦模糊；雪、霜、雾、亮度变化；对比度变化、弹性形变、块像素化、JPEG 压缩失真；斑点噪声、高斯模糊、溅射效应、饱和度变化等。每种退化类型还依据退化权重参数设置了 1 到 5 级的退化严重程度，其中 5 级表示最严重的退化。图 2.1 展示了部分退化类型和相应的退化等级。

基于这一工作，研究者们在多个现有数据集上通过退化模型仿真生成了多个退化图像基准测试集。如：CIFAR-10-C（-C 代表 with Corruption），CIFAR-100-C，ImageNet-C，COCO-C，CityScapes-C，Foggy CityScapes 等。下面将一一对其简要介绍。

对于图像分类任务，CIFAR-10 和 CIFAR-100 是广泛使用的小型基准数据集[25]。

中国知网 https://www.cnki.net



图 2.1　仿真低质量图像及其对应的退化严重程度示例

CIFAR-10 包含 10 个类别，CIFAR-100 则包含 100 个类别，且数据集中的图像分辨率较低，通常为 32×32 像素。研究者们通过在这些数据集上引入不同类型的退化，创建了相应的“CIFAR-10/100-C”数据集，以便快速验证算法在低质量图像上的有效性。类似地，ImageNet-C 是针对 ImageNet 数据集[26]进行退化扩展的版本。该数据集通过在 ImageNet 图像中加入不同强度和类型的退化，旨在测试模型在处理各种图像质量退化时的鲁棒性。此外，ImageNet-C 还提供了低质量图像识别鲁棒性的评价指标——平均退化错误率（mean Corruption Error, mCE），该指标被广泛应用于深度学习模型的鲁棒性测试中。

对于目标检测和图像分割任务，COCO 数据集[27]是一个广泛使用的标准数据集，包含大量标注的图像，涵盖多种日常场景和物体类别，为评估模型在复杂环境中的表现提供了丰富的样本和挑战。CityScapes 数据集[28]则专注于城市街景，特别适用于自动驾驶和城市环境中的目标检测与分割任务。该数据集提供了高质量的清晰图像，并对多个目标进行了精确标注。为应对低质量图像的挑战，COCO-C 和 CityScapes-C 作为这两个数据集的退化版本，通过在原始图像中引入不同程度的退化因素（如噪声、模糊和遮挡等），旨在评估模型在低质量图像上的检测与分割鲁棒性。此外，Foggy CityScapes[29]是 CityScapes 数据集的另一个衍生版本，模拟了雾霾环境中的城市街景。该数据集特别适用于测试和评估模型在恶劣气候条件下，尤其是在雾霾等干扰下的目标识别鲁棒性，帮助推动自动驾驶和城市交通场景中的低质量图像目标检测、分割研究。

中国知网　https://www.cnki.net



图 2.2　真实低质量图像数据集 ExDark 与 RTTS 部分图像示例

（2）真实低质量图像基准数据集

除了仿真退化图像外，一些研究者还采集了真实场景中的低质量图像数据集，以进一步评估模型在实际应用中的表现。例如，ExDark[30]是一个专门为低光照条件下目标检测任务设计的数据集，涵盖从极低光环境到暮光环境等 10 种不同光照条件下的图像。该数据集包含 5891 张训练图像和 1472 张测试图像，涉及 12 个类别，并提供详细的目标标注框。ExDark 旨在模拟实际场景中低光环境对图像质量及目标检测性能的影响。RTTS 数据集[31] 则采集了 4322 张来自真实世界的自然雾霾图像，主要涵盖交通和驾驶场景，专注于交通相关类别，如汽车、自行车、摩托车、人、公共汽车等，并提供详细的目标框标注。ACDC（Adverse Conditions Dataset for Car Driving）数据集[32] 包含了在雾霾、雨天、雪天及夜间等恶劣天气和环境条件下拍摄的图像，每种退化条件提供了 1000 张左右训练集和 400 张测试集，特别适用于评估自动驾驶场景中低质量图像的目标检测与语义分割性能。由于 RTTS 和 ACDC 这两个数据集的目标类别已包含在 CityScapes 数据集的类别中，它们也常用于评估模型在复杂环境中的鲁棒性及域泛化能力。图 2.2 展示了这些真实场景中的低质量图像样本。通过比较图 2.1 和 2.2 可以发现，真实低质量图像与仿真退化图像之间仍存在一定的视觉差异，尤其是在含雾图像中，雾的浓度通常与场景像素深度分布密切相关。可以预见，基于仿真退化图像微调训练的模型在真实场景中的性能提升仍然有限，但通过引入更符合物理特性的退化模型，有望进一步提升模型在真实低质量图像上的泛化能力。

（3）其他鲁棒性基准数据集

除了上述仿真或真实的低质量图像数据集外，在域泛化[33]、域自适应[34]以及神经网络对抗攻击[22,35]等其他研究领域，也有一些数据集被用来评估模型的鲁棒性和

中国知网　https://www.cnki.net


绘画风格Painting


线条风格Sketch


艺术风格Art


卡通风格Cartoon

（a）ImageNet-R不同风格图像示例


香蕉0.0003→0.97


吉普车
0.0004→0.67


蘑菇 0.0007→0.96


链条 0.0008→0.99

（b）ImageNet-A对图像添加扰动使其分类概率变化

图 2.3　其他鲁棒性基准数据集图像示例

泛化能力。例如，ImageNet-R 和 ImageNet-A 等。ImageNet-R[36]是 ImageNet 的一个子集，包含 200 个类别，涵盖草图、艺术、绘画、玩具等多种不同风格的图像；而 ImageNet-A[37]则包含经过对图像类别标签进行对抗攻击生成的攻击样本。这些数据集的设计旨在测试模型在图像风格变化或对抗攻击情况下的鲁棒性。图 2.3 展示了这两个数据集中的部分图像。可以看到，ImageNet-R 中的图像风格差异较大，这对模型的图像风格适应性提出了挑战；而 ImageNet-A 的特点是图像干扰极其隐蔽，尽管人眼难以察觉，但模型的识别却会受到显著影响，导致误识别风险增高。如图所示，给图像添加人眼无法察觉的扰动后，一些图像本不可能属于的类，模型倾向于高置信度的输出。对抗攻击的具体实现及其影响将在第五章中进行详细讨论。

在本文的实验中，除了在低质量退化图像上进行算法验证外，还结合了这些跨域数据集，以全面评估模型在多种挑战性条件下的表现。

2.2 鲁棒性目标识别方法

2.2.1 基于图像复原的方法

基于图像复原的低质量图像识别方法旨在通过对低质量图像进行修复或增强，使其质量接近于清晰图像，从而提升目标识别的准确性。这类方法通常结合图像复原网络，进行图像去噪、图像去模糊、图像超分辨率、暗光图像增强等，以处理噪声、

中国知网　https://www.cnki.net

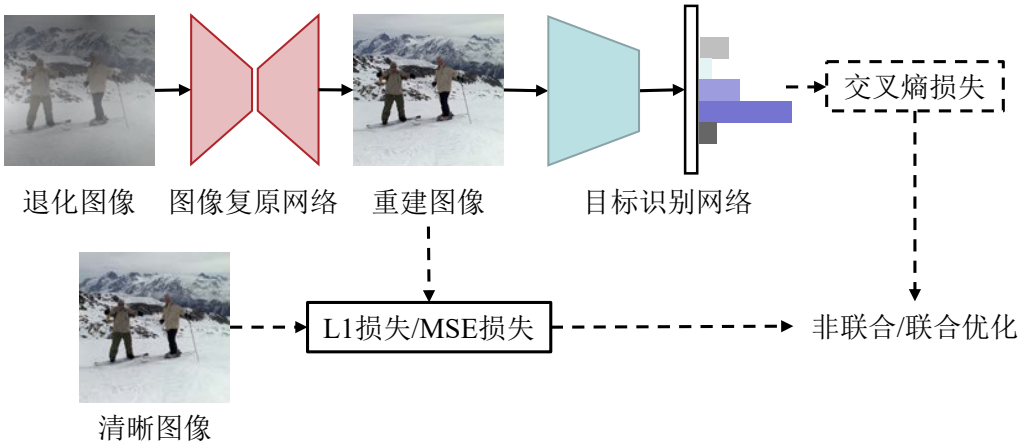


图 2.4　基于图像复原的低质量图像识别方法示意图

模糊、低光照等退化问题，并将恢复的图像输入识别网络中进行识别任务。其通常依据是否联合识别损失函数进行优化分为识别无关的图像复原与识别友好的图像复原。基于图像复原的低质量图像目标识别算法流程图如图 2.4 所示。

（1）复原与识别无关的方法

传统的基于图像复原的低质量图像识别方法通常专注于从退化图像中恢复清晰图像，以提升识别性能，并且通常固定识别网络的参数。即图像复原与后续识别任务是分割开的，不具有内在联系的。图像复原的工作包括文献[1-3,10-12,38-41]，涉及了多个图像复原领域的先进研究。以下是这些工作的简要概述：

文献[38]提出了多阶段图像恢复框架，通过逐步学习恢复函数来平衡空间细节和高级上下文信息的需求。该框架采用了编码器-解码器结构和高分辨率分支来学习上下文特征，并通过一种新颖的逐像素自适应设计来重新加权局部特征，同时利用侧向连接和信息交换来保留上下文信息。达到了在多个图像恢复任务上的显著性能提升。文献[1]提出了基于 Swin Transformer[42] 模型的图像复原方法（SwinIR）。该方法利用 Transformer 结构，包含了三个部分：浅层特征提取器，深层特征提取器和高质量图像重建器。结合多尺度特征处理机制，处理图像复原任务（如去噪、超分辨率等），在图像的细节恢复和高频特征的恢复上取得了明显的提升。文献[2]一种简单的基线模型 NAFNet，提出非线性激活函数在图像恢复中并不是必需的，可以通过直接乘法或者删除来代替。该模型相较于之前的图像复原网络计算量大大降低，图像的视觉效果也得到明显提升。文献[3]提出了一个由基于对比的退化编码器（CBDE）和退化引导恢复网络（DGRN）两个神经模块组成的多合一图像恢复网络（AirNet），在一个网络中恢复各种退化的图像，不受损坏类型和程度的先验限制，只使用观察到的损坏图像进行推理。在多个真实图像恢复数据集上都取得了不错的效果。

近年来，随着多模态视觉-语言模型（Vision-Language-Model，VLM）和扩散模

中国知网　https://www.cnki.net

型（Diffusion Model）的提出，为图像复原领域提供了新的解决思路。这些模型能够结合视觉信息与语言描述，甚至引入生成模型来进一步提升图像复原效果。例如，文献[39]将大规模预训练的视觉-语言模型（CLIP[43]）与图像恢复网络相结合，提出了一种多任务框架，可用于特定的退化和统一图像恢复问题。通过训练退化感知模块（DA-CLIP），能够准确分类不同的退化类型并与现有的恢复模型集成，产生在不同退化下具有视觉吸引力的图像复原结果。文献[40]提出了一种名为 Prompt-In-Prompt Learning 的通用图像恢复方法，该方法通过同时学习高级的感知相关提示词和低级的基本恢复提示词，以有效地应对不同类型的图像退化。文献[11]提出了名为 SeeSR 的方法，用于解决真实世界图像超分辨率问题。SeeSR 利用语义提示来增强预训练的文本到图像（Text to Image，T2I）模型的生成能力，以生成富有细节并且语义正确的图像。实验也证明了 SeeSR 在生成真实细节方面的优越性能。文献[10]提出了一种基于提示的图像复原方法 PromptIR ，使用提示来编码特定于退化的信息，然后用于动态指导恢复网络。该方法能够推广到不同的退化类型和严重等级，同时在图像去噪、去雨和去雾方面取得了最先进的结果。文献[12]提出了一种基于隐空间扩散模型[44]的一体化图像恢复框架（AutoDIR），它可以自动检测和处理多个未知的退化。其首先利用盲图像质量评估模块（BIQA）来自动检测和识别未知的主要图像退化类型。然后，在 BIQA 的指导下，使用一个 All-in-One Image Editing （AIR）模块处理多种退化图像的恢复。最后，提出了一种结构校正模块（SCM）来恢复被 AIR 失真的图像细节。

这些研究通过不同的模型架构和策略，推动了图像复原技术的发展，不仅提升了图像复原任务的性能，还拓展了其在多种高级语义视觉任务中的应用。

（2）识别友好的图像复原方法

然而，文献[4]指出，仅依靠去雾等图像复原方法几乎无法改善分类性能，甚至可能有害，因为训练分类模型时的高质量图像与通过复原得到的图像之间依然存在分布偏移。文献[5]和文献[6]也提到，单纯提升图像视觉质量并不总能显著提高后续识别模型的准确度。其根本原因在于复原后的图像在数据分布上与识别模型所使用的原始清晰图像分布仍有较大差异，这导致识别性能的提升受限。此外，现有图像恢复技术通常仅针对单一类型的退化，处理包含多种退化类型的图像时效果提升有限，仍面临较大挑战。

基于这一认识，研究者们提出了基于识别友好的图像恢复方法。即同时考虑图像增强和识别任务的综合方法[5-6]。具体而言，图像去噪和高级视觉任务传统上通常是独立处理的，而文献[5]则首次将这两者结合起来，并探索其相互影响。作者首先提出了一种卷积神经网络（CNN）用于图像去噪，取得了最先进的去噪性能。随后，提出了一种深度神经网络架构，通过级联去噪模块和多个高级视觉任务模块，并采用联合

中国知网　https://www.cnki.net

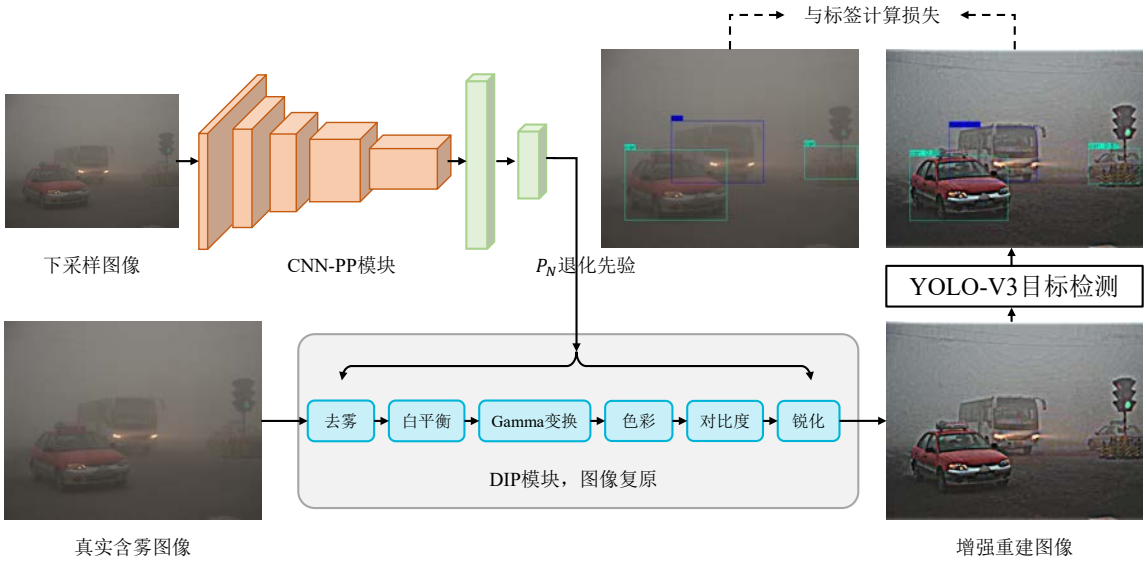


图 2.5　Ada-YOLO[8]方法的网络结构

损失函数进行优化。实验表明，图像去噪有效提升了噪声图像在识别任务中的性能。同时，在高层视觉信息的引导下，去噪网络能够生成更加视觉吸引的结果。这项工作首次通过深度学习方法，结合图像语义，同时提升图像去噪和高级视觉任务的性能。

文献[6]提出了一个通用且兼容识别任务的图像增强网络 URIE 。该网络可以附加在现有识别模型的前端，增强失真的输入，进而提升模型性能，而无需重新训练。URIE 不仅能够处理各种图像退化类型，并且与任何现有识别模型兼容，而且具有“识别友好性”。即，它的训练目标不仅关注图像感知质量，还旨在提升后续识别模型的鲁棒性。实验结果表明，URIE 能够有效应对各种潜在的图像失真，并显著提高现有模型在五个不同识别任务上的表现。

识别友好的低质量图像复原方法的核心是通过联合损失函数进行图像恢复与分类任务的优化，具体公式可表示为：

$$L_{total} = L_1(g(\boldsymbol{x}), \boldsymbol{x_{gt}}) + \lambda * L_2(f(g(\boldsymbol{x})), y), \tag{2-4}$$

其中，$g(\cdot)$ 为图像复原网络，$\boldsymbol{x_{gt}}$ 为对应的清晰图像，$f(g(\boldsymbol{x}))$ 为增强图像经过识别网络后的输出，y 为识别任务的标签。在分类任务中，y 为图像类别，目标检测任务中为图像中的物体包围框和类别信息。L_1 为图像复原损失，通常是均方误差（MSE）或者平均绝对误差（MAE）。L_2 为识别损失函数，根据任务不同可能是交叉熵（BCE）或者交并比（IOU）或者 Sørensen-Dice[45] 系数损失等。

同样，在低光照图像的目标检测任务中，文献[7]提出了一种新型的多任务自动编码变换（MAET）模型，旨在提升黑暗环境下的目标检测性能。MAET 模型通过自监督学习的方式，探索光照转化中的内在模式，考虑了物理噪声模型和图像信号

中国知网　https://www.cnki.net

处理（ISP）对实际光照退化的影响，从而对图像退化模型的参数（如白平衡、亮度、Gamma 系数等）进行编码和解码。该模型同时预测低光照图像的退化参数和目标检测任务。基于这种表示，MAET 能够通过解码边界框坐标和类别信息，精准执行目标检测。该框架与主流目标检测架构兼容，能够通过常见的目标检测数据集（如 VOC[46] 和 COCO[27]）进行端到端训练。实验结果表明，MAET 在合成数据集和真实数据集上均表现出优异的性能，验证了其有效性。文献[8-9]提出了一种新的图像自适应 YOLO (Ada-YOLO) 框架，该框架能够自适应地增强每一张图像，以提升目标检测、分割性能。如图 2.5 所示，作者设计了一个考虑恶劣天气条件的检测器损失可导的图像处理（DIP）模块，并采用小型卷积神经网络来预测图像复原时所需的参数（如白平衡，对比度、饱和度等）。通过端到端联合训练图像复原模块 DIP 与 YOLOv3[47] 目标检测器，以弱监督的方式学习到适合的 DIP ，从而增强图像进行目标检测。实验表明，Ada-YOLO 框架在雾霾和低光等恶劣天气条件下具有显著的检测、分割性能提升，证明了其在真实场景中的有效性。

综上所述，基于图像复原的低质量图像识别方法通过对图像进行恢复或增强，以改善图像质量，从而提升识别性能。其核心思想是通过恢复退化图像的视觉信息，优化下游目标识别任务。该方法的优点在于不仅能够显著改善低质量图像中的视觉质量，还使得目标识别模型在恶劣环境下能够取得更好的性能。然而，这些方法也存在一些局限性：首先，图像复原可能未能有效消除不同类型退化的多样性，导致复原图像与原始图像之间仍然存在分布偏移，从而影响后续任务的性能提升；其次，先图像复原再进行识别的方法，网络模型参数总量较大，计算效率低，难以实际部署应用。

2.2.2 基于增强特征表示的方法

文献[13-15]指出，低质量图像的识别性能下降的根本原因在于特征的退化。因此，部分研究者提出了通过增强特征表示来提升低质量图像识别性能的方法。这些方法直接对低质量图像进行特征蒸馏或特征重建，旨在有效恢复图像的关键信息，从而改善目标识别能力。通过使用配对数据学习特征映射关系，从高质量图像中提取有价值的特征并将其传递至低质量图像的网络，这类方法能够缩小低质量图像与高质量图像之间的分布差异，帮助模型更好地学习到目标的高层语义信息。此外，特征增强方法通过在特征空间进行优化，直接恢复图像的重要特征，而非简单地在像素空间进行图像复原，从而避免了可能的计算冗余，提高了效率。这一类基于增强特征表示的低质量图像识别方法的整体流程如图 2.6 所示：在原始识别模型中嵌入特征增强模块后，再进行目标识别任务的输出。

针对低分辨率小目标的识别问题，文献[13]提出了一种新颖的特征超分辨率方法（FSR-GAN），旨在通过增强小目标图像的特征表征来提升识别性能。在低分辨率小

中国知网　https://www.cnki.net

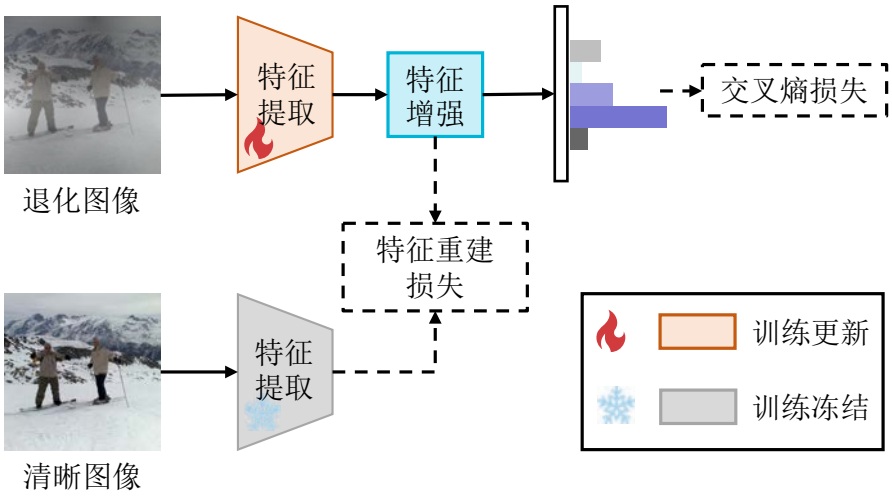


图 2.6　基于增强特征表示的低质量图像识别方法示例

目标的识别中，由于其纹理信息较少且细节模糊，一直是计算机视觉领域中的重要挑战。这类目标提供的特征信息有限，使得模型难以从中学习到具有辨识度的表征，进而显著影响识别精度。现有研究主要集中在通过图像超分辨率技术在像素空间提升低分辨率图像的视觉质量。然而，这类方法在小尺寸图像上效果有限，且对识别性能的提升较为微弱。为了解决这一问题，FSR-GAN 从特征表示的角度入手，构建了一个特征增强网络。FSR-GAN 主要由两个子网络组成：特征生成网络 G 和特征判别器 D 。特征生成网络 G 能够发掘小尺寸目标与大尺寸目标之间的潜在分布关系，将小尺寸图像的弱特征转化为更具辨识能力的特征，从而显著提升小目标的表征能力。同时，通过特征判别器 D 的对抗训练，FSR-GAN 进一步优化了生成的特征，使其更加适应目标识别任务。在多个数据集上的实验结果表明，FSR-GAN 能够有效提升小目标特征的区分能力。即使在查询图像分辨率降至原始分辨率的 $1/64$ 时，FSR 方法增强的特征在不同分辨率下仍然实现了显著的检索性能，与原始查询特征相比，检索准确率提高了 25% 。这些成果表明，FSR-GAN 在小目标识别和图像检索任务中具有显著的优势，为低分辨率小目标的识别提供了有效的解决方案。

考虑到低质量图像在特征退化和分布偏移上的显著挑战，文献[14]结合特征表示空间的统计特性，提出了一种针对低质量图像分类的深度退化先验（Deep Degradation Prior, DDP）模型。DDP 通过统计观察发现，即使来自不同图像的块在特征表示空间中具有相似的结构特性，其分布在相同退化条件下仍表现出一致性。此外，低质量图像和高质量图像的相应块在退化边缘上的分布具有统一属性。基于这一发现，作者设计了一个特征去漂移模块（Feature De-drifting Module, FDM），用于学习低质量图像与高质量图像深度特征表示之间的映射关系，并将其作为深度退化先验应用于低质量图像分类任务。由于统计属性与具体图像内容无关，DDP 可以在没有语义标签监

中国知网　https://www.cnki.net

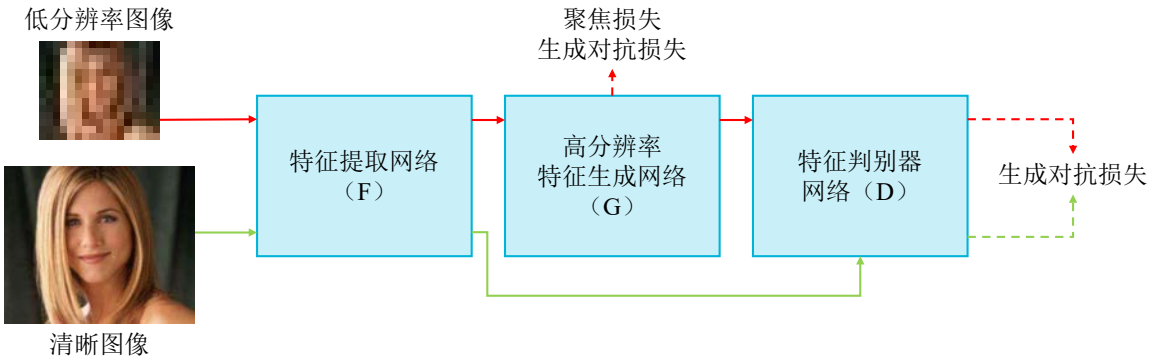


图 2.7　FSR-GAN[13]方法的网络结构

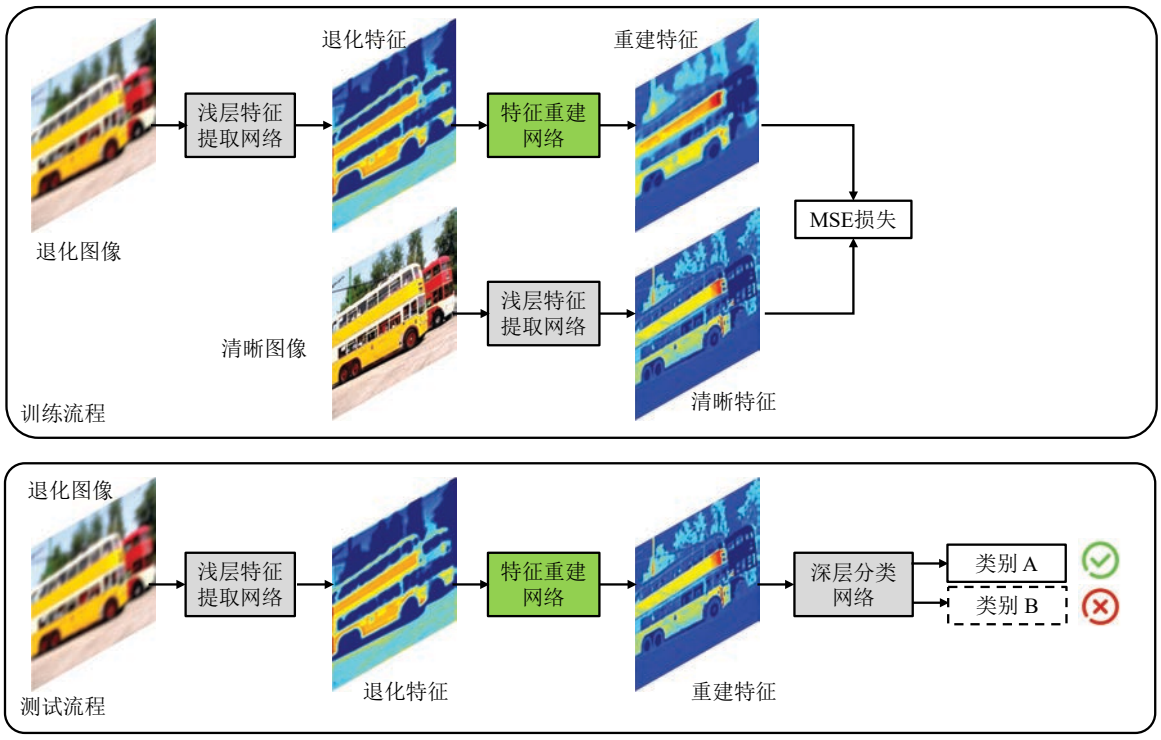


图 2.8　DDP[14]方法的网络结构

督的有限图像训练集上进行学习，并以“插件”模块的形式集成到现有分类网络中，从而提升模型在退化图像上的性能。实验表明，DDP 在基准数据集 ImageNet-C 上的表现显著优于传统方法。在各种退化条件下，DDP 能够将预训练分类网络的准确率提升 20% 以上。即使在仅使用 10 张 CUB-C 数据集的极端有限场景下，DDP 仍能将 VGG16 在 ImageNet-C 上的准确率从 37% 提升至 55% 。这些结果显示，DDP 在低质量图像分类任务中具有显著效果，为低质量图像的特征表示学习提供了新的解决思路。

为解决传统数据增广训练方法因策略简单而导致的模型仅学习到不同退化之间平均分布的问题，文献[15]提出了一种基于可逆神经网络的新型训练范式，以提高深

中国知网　https://www.cnki.net

度图像识别网络在低质量图像上的鲁棒性。该方法分为两个阶段：在第一阶段，作者训练了一个可逆网络，仅使用干净图像，并在识别任务目标下生成干净的特征；在第二阶段，利用该可逆网络的反转部分作为解码器，将其附加到新的识别网络中，并在编码器-解码器架构下联合考虑识别和重建目标进行训练。在这一阶段，模型同时使用干净图像和退化图像进行优化，以学习重建干净特征的能力。这种两阶段方案使得网络能够通过可逆解码器从高质量图像中生成干净且鲁棒的特征，进而提升低质量图像的识别性能。实验结果表明，该方法在图像分类和人脸识别任务中表现出优异的鲁棒性，为应对低质量图像识别问题提供了一种有效的解决方案。

综上所述，基于增强特征表示的低质量图像识别方法通过优化特征空间的表示，有效改善了低质量图像的识别性能。这类方法的优势在于能够直接增强图像特征的辨识能力，同时避免了像素级图像复原带来的计算冗余。然而，这些方法通常依赖于高质量和低质量图像的配对数据，并在面对多种复杂退化类型时可能表现出适应性不足。

2.2.3 基于数据增广的方法

在真实场景中，尤其是在恶劣天气条件下的图像识别任务中，低质量图像及其标注数据往往较为稀缺。基于图像增广的低质量图像识别方法通过组合、剪贴，甚至利用扩散模型生成的增广数据来模拟不同的数据分布，从而扩展训练数据并增强模型的鲁棒性。而迁移学习则通过在高质量图像数据集上预训练的模型，并通过少量定制化的微调，帮助模型更好地适应低质量图像。这两种方法及其结合，能够有效提高低质量图像的识别性能，尤其是在训练集缺乏低质量退化数据的情况下。

数据增广[16-19,48-51]是一种利用现有数据通过人工设计的转换生成具有不同分布的新样本的技术，旨在提高模型的泛化性能。传统方法通过旋转、缩放和平移等变换生成增强图像，并通常使用各种策略将它们组合在一起。MixUp[16]和 CutMix[17]通过线性组合或剪切粘贴来组合新的增强图像。APR[49]通过交换图像频域的幅度和相位谱生成增强图像。Augmix[18]随机对图像执行不同的数据增强操作，然后将它们混合成最终的增强输出。AutoAugment[19]第一次使用强化学习的方式寻找最佳的数据增强策略。近期，生成网络的出现使得在训练过程中使用模型生成额外的数据进行增强成为可能。DeepAugment[36]使用生成对抗网络（GAN），而 Diffmix[21]和文献[52]则使用扩散模型生成增强图像，包括针对目标检测任务的特定可控生成。图 2.9 给出了上述部分算法在 ImageNet 数据上生成的增广图像示例。

另外。针对神经网络对抗攻击提出的对抗防御训练（Adversarial Training，AT）也可以视为一种数据增强方法。它不仅能够增强模型对对抗攻击的鲁棒性，还能提升模型在低质量图像数据上的适应能力。对抗训练的主要思想是生成基于梯度的对抗扰

中国知网 https://www.cnki.net

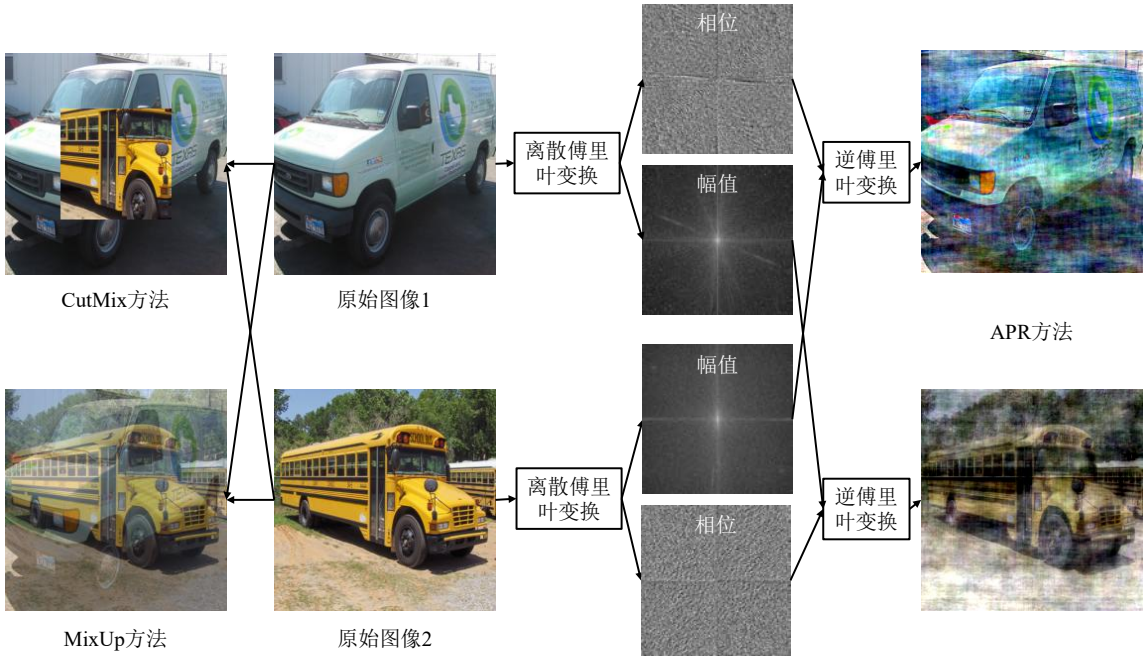


图 2.9　几种不同的增广方法生成的图像示例

动，用于目标网络，使得扰动后的输入图像产生错误输出。对抗训练则是利用这些扰动图像使模型变得更加鲁棒。Buckman 等人[53] 和 Su 等人[54] 将对抗训练定义为一个最小化-最大化问题：

$$\min_{\boldsymbol{\theta}} \mathbb{E}_{(\boldsymbol{x},y)\sim\mathcal{D}} \left[\max_{\boldsymbol{x}',\ ||\boldsymbol{x}'-\boldsymbol{x}||\leq\epsilon} \mathcal{L}_{ce}(\boldsymbol{\theta}, \boldsymbol{x}', y) \right], \tag{2-5}$$

其中 $\boldsymbol{x}'$ 是一个扰动后的图像，$\boldsymbol{\theta}$ 表示模型参数，ϵ 用于控制扰动的范围。为了确保扰动后的图像在满足上述最小化-最大化条件的同时接近原始图像，$\boldsymbol{x}'$ 被定义如下：

$$\boldsymbol{x}' = \boldsymbol{x} + \eta * sign(\nabla_{\boldsymbol{x}} \mathcal{L}_{ce}(\boldsymbol{\theta}, \boldsymbol{x}, y)), \tag{2-6}$$

其中 η 是步长，∇ 表示梯度。对抗训练则是期望生成的扰动图像仍能够被模型正确识别，因此有对应的损失函数及模型参数更新公式为：

$$\mathcal{L}_{AT} = \frac{1}{B} \sum_{i=1}^{B} \mathcal{L}_{ce}(f(\boldsymbol{\theta}, \boldsymbol{x}'_i), y_i). \tag{2-7}$$

$$\boldsymbol{\theta}^* = \boldsymbol{\theta} - lr \cdot \nabla_{\boldsymbol{\theta}} \mathcal{L}_{\mathcal{AT}}. \tag{2-8}$$

其中 B 为一个训练批次的样本数量，lr 为学习率。许多研究[22-23,55]已证明对抗训练在提高模型对抗攻击鲁棒性方面的有效性。同时，DAT[23]进一步表明，通过对抗训练

中国知网　https://www.cnki.net

获得的视觉表征在多个分布外数据集（OOD）上表现出色，包括低质量图像数据，显示了其在提升低质量图像识别能力方面的潜力。

2.3 鲁棒性评估指标

为了全面评估低质量图像鲁棒性识别方法的性能，研究者们通常使用以下评价指标：

准确率（Accuracy）：准确率是最常用的评估指标之一，表示模型正确预测的样本数占总样本数的比例。虽然它较为简单，但可以有效反映模型的整体识别性能。其计算公式如下所示：

$$Accuracy = \frac{N_C}{N}, \tag{2-9}$$

其中，N_C 为 Number of Correct Predictions，是指正确分类的样本数，N 是 Total Number of Predictions 即参与预测的样本数即样本总数。

平均交并比（mean Intersection over Union，mIoU）：平均交并比是图像分割任务中的重要评估指标，表示模型预测区域与真实区域之间的重叠程度。它用于衡量模型对物体分割的准确度。通常是对图像中的每个类计算其预测的区域与真值区域的交并比，再进行平均。其计算公式为：

$$mIOU = \frac{1}{C}\sum_{i}^{C}\frac{S_i \cap M_i}{S_i \cup M_i}, \tag{2-10}$$

其中 S_i 为类别 i 的分割预测区域，M_i 为类别 i 的真实值掩码区域，C 为类别总数。

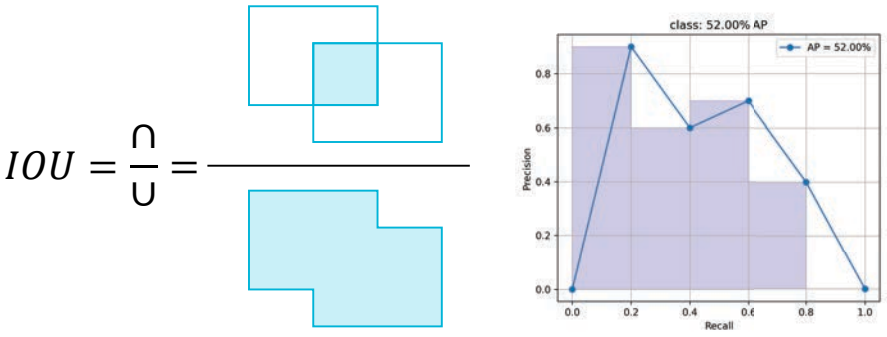


图 2.10　IoU 的计算，PR 曲线及 AP 值示例

平均精确度（mean Average Precision，mAP）：平均精确度是目标检测任务中常用的评估指标。它综合了模型的精确度（Precision）和召回率（Recall），衡量模型在各个类别上的整体性能。精确度和召回率的定义如下：

中国知网　https://www.cnki.net

$$\begin{aligned} Precision &= \frac{TP}{TP+FP}, \\ Recall &= \frac{TP}{TP+FN}, \end{aligned} \tag{2-11}$$

其中 TP（True Positive）为预测正确的（边界框所属类别预测正确，且预测边界框与真实标注框 IoU 大于某个阈值），FP（False Positive）为分别预测类别正确但 IoU 不符合阈值 / IoU 符合阈值但预测类错误，FN（False Negative）是未被检测出的目标。通常 $TP+FN$ 即所有真实标注框的数量。对于目标检测任务，通常根据不同的 IoU 阈值进行 TP，FP，FN 的判定，然后对于每个类别，统计计算其精确度和召回率，并绘制得到每个类的精确度-召回率曲线——PR 曲线（Precision-Recall Curve），通过计算 PR 曲线的面积得到每个类的平均精确度 AP_i，并对所有类别的值进行平均。mAP 的计算公式为：

$$mAP = \frac{1}{C}\sum_{i}^{C} AP_i. \tag{2-12}$$

图 2.10 给出了 IoU 的计算方式，PR 曲线的示例，以及 AP 值即曲线下面积的计算示例。

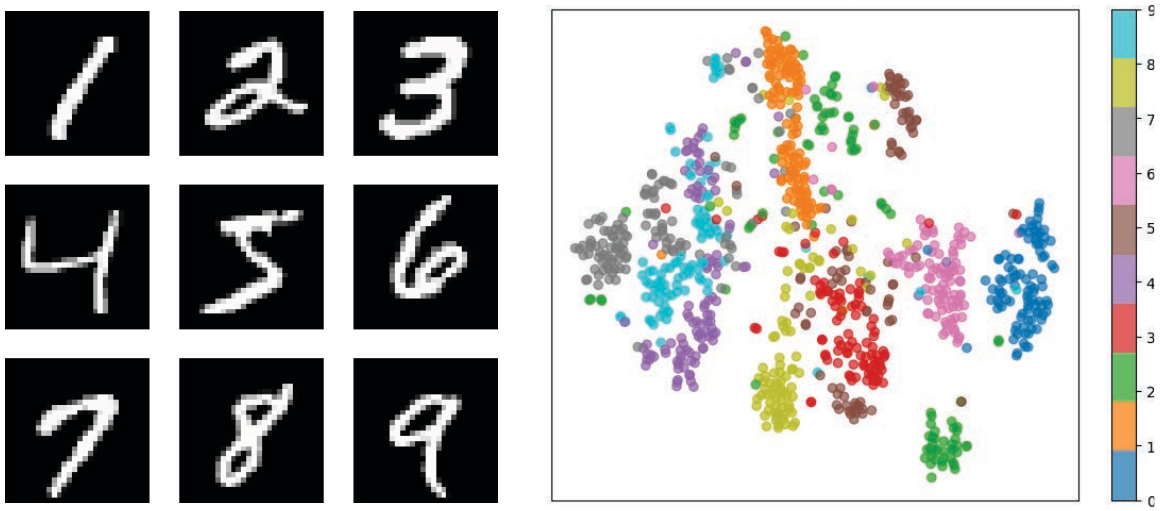
平均退化错误率（mean Corruption Error，mCE）：低质量图像鲁棒性评估通常通过测试模型在不同退化类型下的性能来进行。一个重要的指标是平均退化错误率，由文献[24]给出，用于衡量模型在低质量图像上对不同退化类型的鲁棒性和识别性能。它通过计算模型在每种退化类型下，不同退化严重程度的错误率来衡量。具体地，其计算公式为：

$$mCE = \frac{1}{15}\sum_{c=1}^{15} \frac{\sum_{s=1}^{5} Err_{c,s}}{\sum_{s=1}^{5} Err_{c,s}^{AlexNet}}, \tag{2-13}$$

其中 c 代表不同的退化类型，s 为退化严重程度，Err 代表错误率，通常由 $1-Accuracy$ 得到。注意，这里的错误率需要用 AlexNet 模型[56]的在这些退化图像上的分类错误率进行标准化以保证对比的公平性。

通过上述评价指标，研究者能够全面评估低质量图像识别方法在不同任务和退化条件下的鲁棒性与准确性。这些指标不仅有助于评估模型在标准数据集上的表现，还能有效检验其在真实应用场景中的适应能力与稳定性。在低质量图像识别的研究中，准确率、mAP、mIoU、mCE 等评价标准相互补充，能够为模型性能的全面优化提供重要依据，推动相关算法的深入发展与创新。

中国知网　https://www.cnki.net



（a）Mnist数据集示例图像　　（b）t-SNE降维可视化结果

图 2.11　Mnist 数据（左）及其 t-SNE 降维（右）分布示意图

2.4 模型特征可视化与可解释性分析方法

为了验证算法的有效性，通常还可以通过对模型提取的低质量图像退化特征分布进行可视化，或观察特征中的激活区域来直观地评估模型的表现。这些方法包括 t-SNE（t-Distributed Stochastic Neighbor Embedding，t-分布随机邻域嵌入）可视化、类别激活图（Class Activation Map）以及 Grad-CAM 激活图（Gradient-weighted Class Activation Map）。t-SNE 被广泛用于高维特征的降维和可视化，以便更好地理解模型如何对不同的输入进行特征学习。类别激活图（CAM）通过显示模型在进行分类时关注的区域，从而帮助研究者了解模型在做出决策时关注的图像部分。而 Grad-CAM 则进一步提供了更细粒度的视角，能够揭示神经网络在不同层次上如何响应输入图像中的不同区域。这些可视化方法能够帮助研究者深入理解模型的决策过程，验证模型是否能够提取有效的判别性特征表示。

2.4.1 t-SNE

t-SNE[57]是一种非线性降维技术，广泛用于高维数据的可视化。它通过保留数据点之间的局部相似性，将高维数据映射到二维或三维空间，从而便于观察数据的聚类结构和分布特性。t-SNE 适合可视化高维特征空间中的聚类效果，例如模型提取的深层语义判别性特征等。其计算方法如下：

首先计算高维空间中的相似度：对于高维空间中的每个数据点 $\boldsymbol{x}_i$，高斯分布给予其附近的点较高的概率值，而离得远的点则会有较低的概率值，因此可以使用高斯

中国知网　https://www.cnki.net

分布条件概率计算其与其它数据点 $\boldsymbol{x_j}$ 的相似度 $p_{j|i}$：

$$p_{j|i} = \frac{\exp(-||\boldsymbol{x_i} - \boldsymbol{x_j}||^2/2\sigma_i^2)}{\sum_{k\neq i}\exp(-||\boldsymbol{x_i} - \boldsymbol{x_k}||^2/2\sigma_i^2)}, \tag{2-14}$$

其中，σ_i 是通过困惑度（perplexity）参数调整的高斯分布方差参数。然后可以得到一个对称的相似度矩阵：

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}. \tag{2-15}$$

然后在低维空间初始化一些可以更新的点，保证点数量相同，低维空间通常是二维（平面）或三维（空间）。在高维数据降维到低维空间的过程中，数据点之间的距离关系往往会发生显著变化。由于低维空间的维度限制，点与点之间的可用空间大幅减少，容易导致数据点分布过于密集，形成所谓的“拥挤问题”。如果直接采用高斯分布来计算低维空间中点与点之间的相似度，远离的点之间的相似度可能会被过度放大，从而影响降维结果的可视化效果。为了解决这一问题，t-SNE 采用了一种基于 t 分布的相似度计算方法。与高斯分布相比，t 分布在尾部具有更重的概率密度，能够更好地平衡低维空间中点与点之间的距离关系，从而缓解拥挤问题，提升降维结果的可视化效果。在低维空间计算数据点 y_i 和 $\boldsymbol{y_j}$ 之间的相似度 $\boldsymbol{q_{ij}}$ 的公式为：

$$q_{ij} = \frac{(1 + ||\boldsymbol{y_i} - \boldsymbol{y_j}||^2)^{-1}}{\sum_{k\neq l}(1 + ||\boldsymbol{y_k} - \boldsymbol{y_l}||^2)^{-1}}. \tag{2-16}$$

接下来优化迭代更新低维表示：通过最小化高维和低维数据点的相似度分布之间的 KL 散度（Kullback-Leibler divergence）来优化低维表示：

$$\mathrm{KL}(P||Q) = \sum_{i\neq j} p_{ij}\log\frac{p_{ij}}{q_{ij}}. \tag{2-17}$$

最后使用梯度下降法迭代更新低维空间中的点 y_i。图 2.11 给出了基于 python 的 Scikit-Learn 库的 t-SNE 示意图。图中左侧可视化了经典的 Mnist 手写数字数据集的部分图像，像素为 28×28 。右侧为使用 Scikit-Learn 的 t-SNE 算法直接对每张图像所有像素值降为到二维平面的一个点实现的效果，可以观察到 t-SNE 能很好地捕捉数据中的潜在特征及分布特点，如数字“1”的图像很好的聚类到一起（同一个颜色的点），是一个有效的可视化方法。

2.4.2 CAM

CAM 是一种可视化技术，初始设计用于显示神经网络（CNN）在分类、检测、分割等识别任务中关注图像中的哪些区域。它通过将最后一个卷积层的特征图与全连接层的权重相结合，生成一个热力图，指示模型对特定类别的关注区域。图 2.12 给

中国知网　https://www.cnki.net

出了 CAM 计算的相关系过程示意图。其计算方法如下：首先获取最后一个卷积层的特征图。假设最后一个卷积层的输出为 $f_k(x,y)$，其中 k 表示通道索引，$k \in (0,K)$，(x,y) 表示空间位置。然后获取全连接层的权重。假设全连接层的权重为 w_k^c，其中 c 表示类别，k 表示通道索引。最终将全连接层权重作为激活权重与特征图相乘，计算类别激活图：即，对于类别 c，计算每个空间位置 (x,y) 的激活值：

$$\text{CAM}_c(x,y) = \sum_k w_k^c \cdot f_k(x,y). \tag{2-18}$$

后处理阶段可以将结果进行归一化再上采样，使其与输入图像大小一致。并使用热力图颜色映射进行展示。图 2.12 展示了 CAM 的计算过程。

2.4.3 Grad-CAM

Grad-CAM（Gradient-weighted Class Activation Map）是 CAM 的扩展版本，也适用于任何深度神经网络 DNNs 结构，而不仅限于特定架构例如需要全连接层。它通过计算目标类别对最后一个卷积层输出特征图的梯度，生成一个加权热力图，显示模型对特定类别的关注区域。其计算方法如下：获取最后一个卷积层的特征图：假设最后一个卷积层的输出为 $f_k(x,y)$，其中 k 表示通道索引，(x,y) 表示空间位置。第二步是计算目标类别的梯度：对于目标类别 c，计算其相对于特征图 $f_k(x,y)$ 的梯度：$\frac{\partial y_c}{\partial f_k(x,y)}$，其中 y_c 是类别 c 的得分。然后计算通道权重，即对每个通道 k，计算全局平均梯度值：

$$\alpha_k^c = \frac{1}{h*w} \sum_x^h \sum_y^w \frac{\partial y_c}{\partial f_k(x,y)}, \tag{2-19}$$

其中 h,w 是特征图的空间尺寸。最终，和 CAM 计算方式类似，对特征图进行加权求和，得到类别 c 的 Grad-CAM 热力图：

$$\text{Grad-CAM}_c(x,y) = \sum_k \alpha_k^c \cdot f_k(x,y). \tag{2-20}$$

后处理中同样可以将 Grad-CAM 热力图进行归一化再进行上采样，使其与输入图像大小一致，便于可视化。图 2.13 给出了 Grad-CAM 的计算方法。可以看出与基础 CAM 不同，其通常需要进行一次反向传播，再设计保存该特征图及其梯度进行可视化。

综上所述，t-SNE、CAM 和 Grad-CAM 是深度学习中用于增强模型可解释性的重要工具。t-SNE 通过降维将高维特征可视化，展示特征分布的聚类效果；CAM 利用卷积层特征图和全连接层权重生成类别激活图，直观显示模型关注的关键区域；而 Grad-CAM 则通过梯度加权的方式生成类别激活图，适用于任意 CNN 结构，能够更精确地揭示模型对特定类别的关注区域。这些方法共同为研究人员提供了深入理解

中国知网 https://www.cnki.net

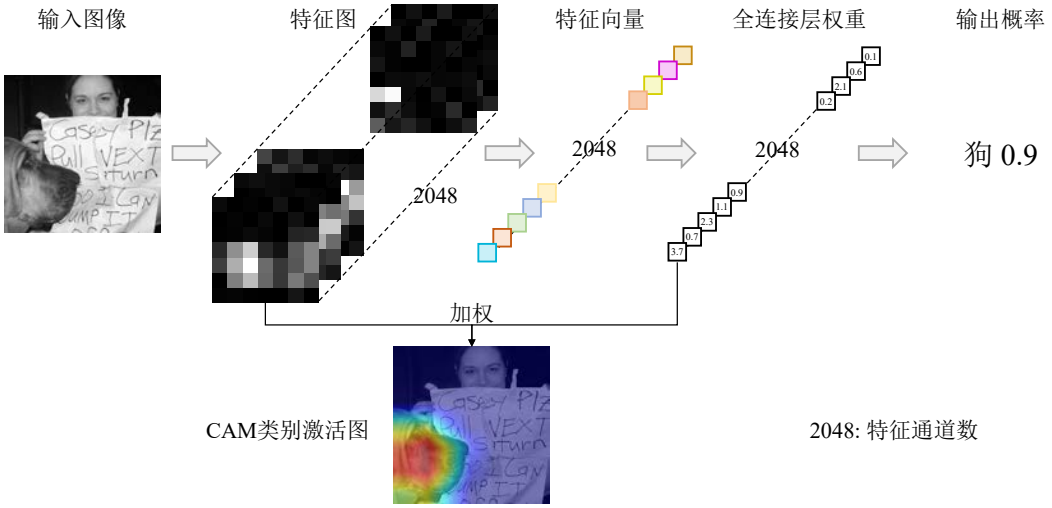


图 2.12　CAM 类别激活图计算示例

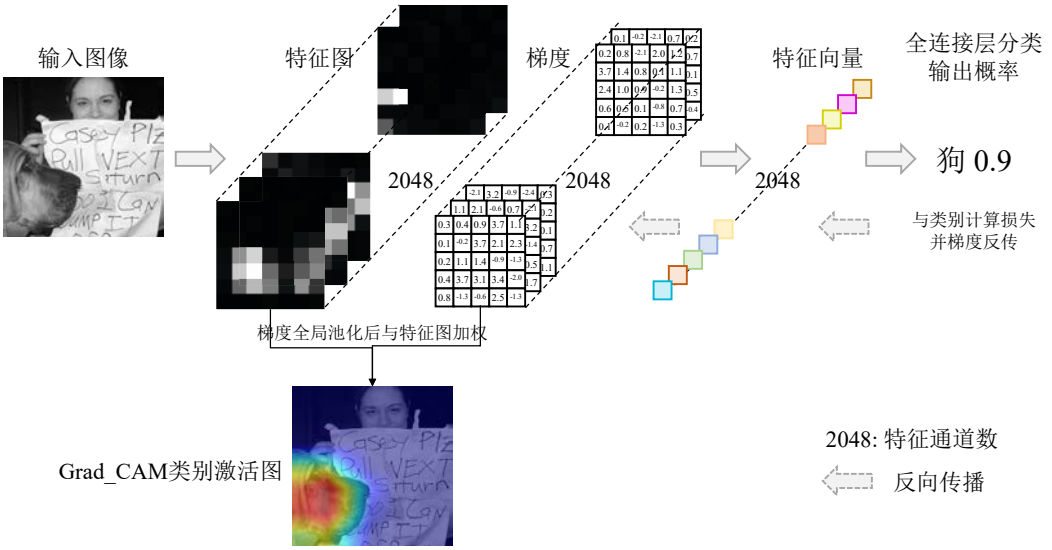


图 2.13　Grad-CAM 基于梯度的类别激活图计算示例

模型行为和决策过程的有效手段，提升了深度学习模型的可解释性和透明度。

2.5 本章小结

本章首先介绍了退化模型、基准测试集、评价指标以及可视化方法等基础概念，为低质量图像鲁棒性识别的研究提供了理论框架和评估标准。然后，系统回顾了现有的低质量图像鲁棒性识别方法，涵盖了基于图像恢复、特征增强、数据增广、对抗训练和迁移学习等技术。通过分析这些方法的优缺点，揭示了它们在处理低质量图像时面临的挑战与局限性。最后，通过对现有方法的全面讨论，本章为后续提出的改进方法奠定了理论基础，并为低质量图像识别领域的进一步研究提供了重要参考。

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net

第三章　基于数据特征不确定性建模的鲁棒目标识别方法

3.1 引言

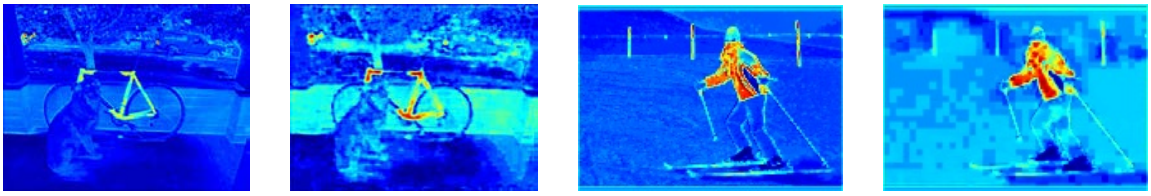
低质量图像识别面临的主要挑战在于图像模糊、噪声和低分辨率等因素导致的细节丢失，使得模型难以有效提取关键特征，从而影响识别性能。传统方法通常通过先进行图像增强，再进行目标识别的策略来提升模型性能，但这种方法通常伴随着较高的计算开销。并且在处理不同类型的图像退化时，通常需要为每种退化类型设计专门的图像复原模型，这不仅增加了计算复杂度，还可能导致单一模型在应对其他退化类型时的表现不佳，从而限制了其泛化能力。因此，研究者们提出在特征空间进行特征重建，增强特征表示的方法，通常采用 $L2$ 范数作为训练约束，使得从退化图像中提取的特征更接近高质量图像的特征。但由于其对特征中的每个像素施加的约束一致，在一些困难区域，特征重建效果较差。

针对上述问题，本章提出了一种基于数据不确定性建模的自蒸馏特征表示增强方法。该方法通过引入不确定性建模来增强图像特征在受到干扰情况下的表示能力。具体而言，在标准识别模型中，本章提出了一种新颖的自蒸馏框架，利用高质量图像特征来蒸馏对应的退化特征，并根据退化源的多样性进行不确定性建模。通过在蒸馏损失中增加不确定性较大的，难以恢复的特征区域的权重，增强了模型对困难区域的学习能力，从而避免了特征重建过程中可能出现的过度计算与信息损失。与传统的图像增强再识别方法相比，本方法直接在特征空间中进行优化，既降低了计算复杂度，又能更准确地保留低质量图像中的有效信息。与基于 $L2$ 范数的特征增强方法相比，本方法能够聚焦于关键特征区域，显著提升模型的泛化能力。大量实验结果表明，本方法能够显著提升低质量图像目标识别任务中的表现，尤其在处理模糊、噪声或分辨率差的恶劣天气图像时，展现了更高的鲁棒性与准确性。

3.2 方法简介及相关基础知识

尽管深度学习在图像识别领域取得了快速进展[56,58-63]，但图像退化对视觉识别任务的影响仍然未得到充分研究。深度模型在高质量图像（High-Quality Images, HQ）上的性能表现良好，但在低质量图像（Low-Quality Images, LQ）出现时性能通常会显著下降。最近关于图像分类[24]、目标检测[64]和语义分割[65]模型的鲁棒性基准研究表明，标准的卷积神经网络模型的性能对图像质量非常敏感。例如，标准的 ResNet50[60]在 ImageNet-C 上的平均退化错误率（mCE）高达 76.7%[24]；以 ResNet50 为骨干网络的 Faster-RCNN[61]在目标检测任务中，HQ 和 LQ 图像上的平均精度（mAP）分别为 36.3

中国知网　https://www.cnki.net



清晰图像1特征　模糊图像1特征　清晰图像2特征　模糊图像2特征

图 3.1　HQ 与 LQ 图像的特征激活热力图示例

和 18.2[64]；而 DeepLabv3+[58]在带有散粒噪声图像的语义分割任务中，仅有 6.6 的平均交并比（mIoU）[65]。这表明，当训练数据与测试数据之间存在较大的分布差异时，训练集上的精度不再能够有效代表测试集上的性能。

针对退化图像识别的传统方法通常首先尝试恢复损坏的图像。事实上，包括图像去噪、去模糊、超分辨率、去雾以及其他图像增强方法在内的各种图像恢复技术已经被深入的研究，以提高退化图像的视觉质量。然而，图像的**视觉质量**与**识别质量**之间存在本质的差异——例如，一张面部被局部遮挡的照片可能具有最高的视觉质量，但在面部识别的场景下，却是困难的低质量图像。相关研究[6,14]已经证明，视觉感知的改善并不能保证后续高层视觉任务的准确度大幅提高。此外，现有的图像恢复技术大多集中于单一类型的退化问题，而如何从多种退化类型中有效恢复图像，仍然是一个亟待解决的挑战。

基于对潜在特征空间中的统计观察（如图 3.1 所示），低质图像的特征激活区域发生了偏移，可能在错误的背景或纹理区域激活值较大。这将导致模型无法正确根据特征进行判别和决策。当前退化图像识别领域的最先进方法倾向于直接对损坏的图像的特征表示进行处理。相关研究表明，通过缩小退化图像特征与对应的清晰图像特征之间的分布距离，即在特征空间中使得退化图像的表示尽可能接近高质量图像的表示，可以有效提升图像识别模型的鲁棒性。另外，受到知识蒸馏技术在神经网络压缩中的成功应用[66-67]的启发，本章提出了一种在特征空间中进行自蒸馏的框架。知识蒸馏通过将模型的知识从复杂的“大模型”转移到简单的“小模型”中，已被证明在提升模型性能、降低计算复杂度方面具有显著优势。在传统的知识蒸馏中，通常通过软标签（Soft-label）来传递教师模型的信息，而在图像识别任务中，尤其是处理低质量图像时，关键是通过高质量图像的特征表示来指导模型从退化图像中提取关键的有识别意义的特征。因此，本章的自蒸馏框架直接优化退化图像的特征空间，利用低质量图像与高质量图像的内在联系，通过构建特征空间中的监督关系使得模型能够在训练过程中逐步学习高质量图像的特征表示，从而在低质量图像的识别任务中表现出更强的鲁棒性。

本方法的另一个贡献在于通过对退化过程的建模来识别图像特征的**不确定性**[68]。

中国知网　https://www.cnki.net

在以往的研究中，对于高质量特征的近似估计通常是确定性的，即大多数方法采用常见的**均方误差**（MSE）损失函数，将特征的分布（方差）视为一个确定的常数，这导致在退化过程的假设发生变化时（如从单一退化类型扩展到多种可能退化），模型的泛化能力较差。因此，传统的特征重建方法往往不能有效应对复杂的图像退化情境。为了解决退化建模中的这一问题（例如，针对包含多种退化类型的图像），本章提出在特征重建过程中引入一个由标准深度神经网络构成的新分支，用于估计特征分布的不确定性（方差），并通过加权损失函数重新约束重建过程。这一方法使得模型能够显式地识别图像特征中的不确定性区域，并将更多学习权重赋予那些难以恢复的困难区域。通过这种方式，模型能够更好地聚焦于高质量图像中的关键特征，从而提升低质量图像的识别性能。与传统的基于固定假设的重建方法相比，本章提出的方法不仅能够更准确地捕捉退化图像中有价值的信息，还能够在不同退化类型下表现出更强的鲁棒性和更好的泛化能力。

在多个基准测试集的大量实验结果表明，所提出的方法在面对多种复杂退化情况下，尤其是模糊、噪声、恶劣天气等图像上的识别任务中，展现了显著的性能提升，证明了该方法在退化图像识别中的有效性和优势。在介绍该方法之前，本章先对低质量图像的识别方法简单回顾，并介绍不确定性建模的相关工作。

（1）低质量图像的目标识别方法

文献[5]和[6]分别针对噪声图像和雨雾图像，同时考虑了图像复原和识别，采用了图像恢复和分类的联合损失函数来约束模型训练。文献[13]提出了一个特征超分辨率生成对抗网络（GAN），旨在从小尺寸图像中生成高分辨率特征，并增强特征的区分能力。该方法有效规避了传统图像复原方法的局限性，通过在特征空间内直接优化图像表示。基于这一方向，近期的研究[14]提出了特征去漂移模块，旨在修正浅层预训练网络中由退化引起的特征漂移。通过深度退化先验，将图像识别任务转化为基于特征的重建问题，从而在特征级别进行退化修复和映射。文献[15]尝试利用可逆神经网络[69]将用于识别的特征变换回图像域并施加约束，从低质量图像中提取高质量图像相似的特征。另有研究提出了基于迁移学习或测试时微调的算法，对低质量图像的识别结果进行修正。例如，文献[70]提出了一种改进的交叉熵损失函数 RPL，用于测试时训练，通过计算预测的伪标签与模型输出的损失（自我学习），逐步修正模型在推理过程中的预测结果。

（2）不确定性学习

相关文献[68,71-78]中研究了两种类型的不确定性建模：一种是认知不确定性（Epistemic Uncertainty，EU）或模型不确定性，它表示由于模型参数不确定或训练数据不

中国知网　https://www.cnki.net

足而导致的预测不确定性。换句话说，认知不确定性反映了模型在其知识库之外的推断过程，通常可以通过更多的训练数据或者更复杂的模型来减小。一些方法[74,78-79]通过贝叶斯神经网络或神经元随机丢弃（dropout）操作来建模模型不确定性，以此模拟不同模型参数下的推断不确定性，从而有效提高模型在未知的多样化不确定数据分布条件下的鲁棒性。

另一种是偶然不确定性（Aleatoric Uncertainty，AU）或数据不确定性，它源自观测数据本身的固有噪声。偶然不确定性表示的是由于测量噪声、环境干扰或数据本身的模糊性等因素导致的随机波动。与认知不确定性不同，偶然不确定性无法通过增加数据量或改进模型来消除，因为它是数据本身的固有属性。大多数研究[68,73,76-77,80]通过对数据本身的方差建模来表征这种不确定性。这些方法通过引入概率模型（如高斯分布或贝叶斯估计）来量化数据的固有噪声，进而学习数据中包含的不确定性信息。这使得模型不仅能关注数据的期望输出，还能够识别哪些区域或样本受噪声影响较大，应予以关注，从而有效提高模型对噪声和退化数据的鲁棒性。

3.3 基于特征表示增强的低质量图像目标识别

针对现有的双阶段低质量图像识别方法中存在的计算量较大、泛化性不足以及现有特征重建方法未充分考虑特征区域重要性差异的问题，本章提出了一种基于不确定性建模的自蒸馏特征表示增强方法。通过建模退化图像特征的不确定性，并动态调整模型对特征困难区域的关注，从而有效引导模型在退化图像中学习高质量特征表示，显著提升图像识别性能。本节先介绍基于特征表示增强的低质量图像识别方法原理，在下一节介绍基于不确定性建模的自特征蒸馏网络框架及各模块设计。

在图像识别任务中，通常的目标是从理想的高质量图像 $\boldsymbol{x}$ 中正确识别出其对应的标签 y。然而，在实际的应用场景中，由于噪声干扰、运动模糊、压缩伪影等多种退化因素的影响，往往只能获得低质量的退化图像 $\tilde{\boldsymbol{x}}$。因此，如何从这些低质量观测图像 $\tilde{\boldsymbol{x}}$ 中准确识别出正确的类别标签 y，就成为了退化图像识别中的一个核心挑战。

一些先前的研究[13-15]已经表明，退化图像的特征会显著降低识别性能。为进一步验证这一点，本文对从高质量图像和退化图像中分别提取了对应的特征进行了可视化分析。图 3.1 展示了在 ImageNet-C 验证集上，使用 t-SNE[57]进行的特征嵌入可视化结果。实验结果表明，在高质量图像中（图中用点表示），同一类别的特征分布（标记为相同颜色）彼此紧密相邻，表现出较强的类内一致性；而在退化图像中（图中用三角形表示），同一类别的特征分布显著分散，并且与高质量图像中的同一类别特征存在明显的分离，表现出较弱的类内一致性。此外，退化对特征表示的影响也会随着数据集的不同而有所变化。这些现象表明，退化影响了特征的分布，导致特征的类内一致性降低。

中国知网 https://www.cnki.net

基于这一观察，本文旨在构建一种能够在多种退化类型下表现良好的模型，该模型通过同时恢复近似高质量的特征 $\boldsymbol{z}$ 并估计标签 y 来实现。令 $\boldsymbol{z}$ 和 $\tilde{\boldsymbol{z}}$ 分别表示对应 HQ 图像 $\boldsymbol{x}$ 和 LQ 图像 $\tilde{\boldsymbol{x}}$ 的特征表示，可以将标签 y 与特征 $\boldsymbol{z}$ 的估计建模为最大后验概率（MAP）估计框架：

$$\operatorname{argmax} p(\boldsymbol{z}, y \mid \tilde{\boldsymbol{x}}) = \operatorname{argmax} p(y \mid \boldsymbol{z}, \tilde{\boldsymbol{x}}) p(\boldsymbol{z} \mid \tilde{\boldsymbol{x}}), \tag{3-1}$$

其中，本文使用贝叶斯公式将原问题转化为两个子问题：即图像识别 $p(y \mid \boldsymbol{z}, \tilde{\boldsymbol{x}})$ 和特征重建 $p(\boldsymbol{z} \mid \tilde{\boldsymbol{x}})$。

为了解决这一问题，本文使用深度学习方法进行联合估计优化。具体地，鲁棒分类器（由参数 $\boldsymbol{\Theta_1}$ 参数化）可以表示为 $f(\cdot; \boldsymbol{\Theta_1})$，其目标是将输入的退化图像 $\tilde{\boldsymbol{x}}$ 映射到正确的类别标签 y。其中，$g(\cdot; \boldsymbol{\Theta_2})$ 表示分类器中的骨干网络（由参数 $\boldsymbol{\Theta_2}$ 参数化），该网络能够从退化图像 $\tilde{\boldsymbol{x}}$ 中恢复出接近高质量的特征 $\hat{\boldsymbol{z}}$，即 $\hat{\boldsymbol{z}} = g(\tilde{\boldsymbol{x}}; \boldsymbol{\Theta_2})$。

针对方程 (3-1) 中的项 $p(y \mid \boldsymbol{z}, \tilde{\boldsymbol{x}})$，由于在测试阶段无法直接获得高质量图像的理想特征 $\boldsymbol{z}$，因此采用从退化图像 $\tilde{\boldsymbol{x}}$ 中恢复的近似高质量特征（HQ-like）$\hat{\boldsymbol{z}}$ 进行近似，即 $p(y \mid \boldsymbol{z}, \tilde{\boldsymbol{x}}) \approx p(y \mid \hat{\boldsymbol{z}}, \tilde{\boldsymbol{x}})$。由于 $\hat{\boldsymbol{z}}$ 是通过 $g(\tilde{\boldsymbol{x}}; \boldsymbol{\Theta_2})$ 计算得到的，基于概率独立性原理，可得 $p(y \mid \hat{\boldsymbol{z}}, \tilde{\boldsymbol{x}}) = p(y \mid \tilde{\boldsymbol{x}})$。随后，对方程 (3-1) 取对数并重新整理公式，可以得到：

$$\log[p(\boldsymbol{z}, y \mid \tilde{\boldsymbol{x}})] \approx \log[p(y \mid \tilde{\boldsymbol{x}})] + \log[p(\boldsymbol{z} \mid \tilde{\boldsymbol{x}})]. \tag{3-2}$$

通过这种方式，使用深度学习来训练优化最大化似然项 $\log[p(\boldsymbol{z}, y|\tilde{\boldsymbol{x}})]$，可以转变成优化以下目标损失函数：

$$(\boldsymbol{\Theta_1}, \boldsymbol{\Theta_2}) = \underset{\boldsymbol{\Theta_1}, \boldsymbol{\Theta_2}}{\operatorname{argmin}} L_1(y, f(\tilde{\boldsymbol{x}}; \boldsymbol{\Theta_1})) + \lambda * L_2(\boldsymbol{z}, g(\tilde{\boldsymbol{x}}; \boldsymbol{\Theta_2})), \tag{3-3}$$

其中，L_1 为分类任务的损失函数，通常采用交叉熵损失，而 L_2 损失则用于在成对的高质量和低质量图像输入中，以高质量图像的特征 $\boldsymbol{z}$ 作为监督，重建低质量图像的特征 $\hat{\boldsymbol{z}}$。在本文的实验中，采用多任务学习策略[15,81]对整个网络进行训练，λ 为平衡这两个任务的权重超参数。为了更有效地通过深度神经网络优化公式 (3-3) 中的联合损失函数，本章接下来提出了一种结合不确定性学习的新型自特征蒸馏方法。

中国知网　https://www.cnki.net

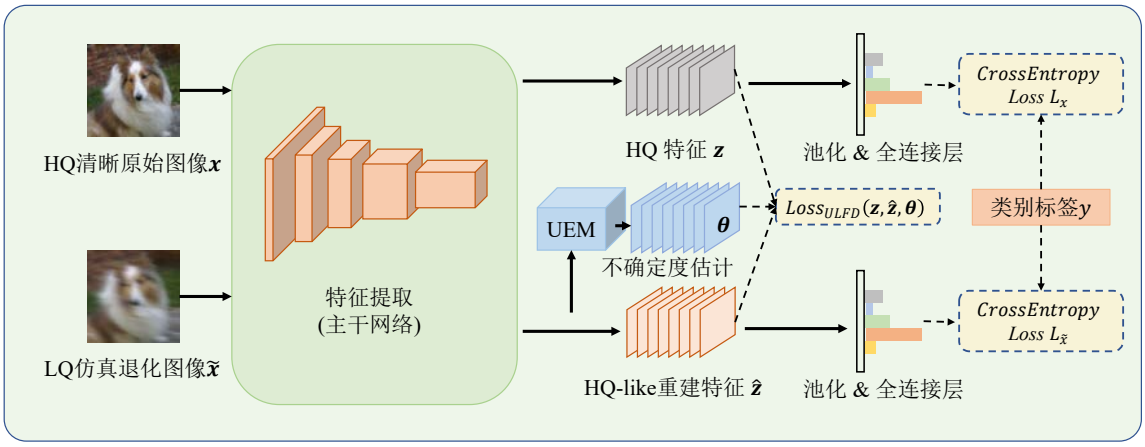


图 3.2　基于不确定性建模的自蒸馏特征表示增强方法框架示意

3.4 基于数据不确定性建模的特征表示增强

3.4.1 退化特征的不确定性

基于上述理论分析，公式 (3-3) 中第二项的优化目标在于从退化图像 $\tilde{x}$ 中提取近似高质量（HQ-like）的特征表示 $\hat{z}$。为实现这一目标，本研究设计了一种自特征蒸馏框架用于 HQ-like 特征的估计。具体而言，如图 3.2 所示，该框架采用在 HQ 数据集上预训练的深度神经网络作为特征提取基准。在模型训练阶段，高质量图像及其对应的模拟退化图像被并行输入共享权重的骨干网络进行特征提取。通过特征蒸馏机制，约束提取特征（z 和 $\hat{z}$）在特征空间的分布一致性，从而增强模型在低质量图像条件下的分类鲁棒性。

鉴于退化类型的多样性以及特征重建问题固有的病态性质（ill-posed），学习 HQ-like 特征的任务具有一定的挑战性，这一现象在纹理和边缘区域尤为明显（参见图 3.3 (g) 和图 3.3 (h)）。当前最先进的 QualNet 方法[15]采用可逆神经网络[69]将特征映射转换至图像域进行处理。本研究提出了一种新的解决思路：考虑到退化过程的多样性，图像数据输入的不确定性不可避免地导致提取的特征表示的不确定性，这一现象为特征恢复问题提供了新的研究视角。

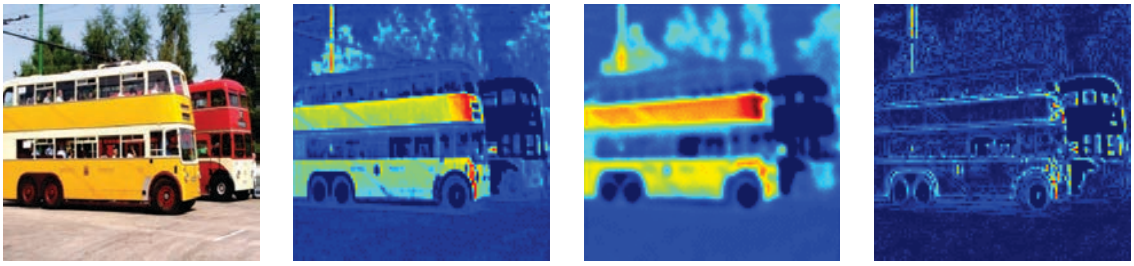
假设从相应图像中提取的特征图的每个像素位置都遵循高斯分布，均值为 $\hat{z}_i$，标准差为 θ_i。为有效量化特征重建过程中的数据不确定性，可建立如下观测模型：通过估计的类似高质量特征 $\hat{z}_i$ 和目标高质量特征 z_i 之间的高斯似然函数进行建模：

$$z_i = \hat{z}_i + \epsilon * \theta_i, \tag{3-4}$$

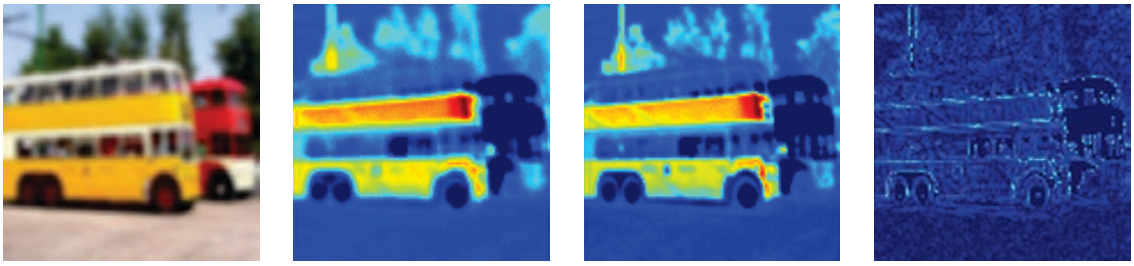
其中，ϵ 表示满足零均值和单位方差的正态分布。

传统的特征蒸馏方法通常使用均方误差损失函数（MSE 损失，也称 $L2$ 范数）来

中国知网　https://www.cnki.net



(a) HQ 清晰图像　(c) HQ 清晰特征　(e) DDP方法重建的特征　(g) 差值 | HQ-DDP |



(b) LQ 模糊退化图像　(d) LQ 退化特征　(f) 本章方法重建的特征　(h) 差值 | HQ-Ours |

图 3.3　HQ 特征与重建的 HQ-like 特征及二者的归一化绝对值差异图示例

进行确定性估计。即：

$$\min(\frac{1}{N}\sum||\boldsymbol{z}_i-\hat{\boldsymbol{z}}_i||_2^2). \tag{3-5}$$

显然，MSE 损失将方程 (3-4) 中的方差项视作为统一常数，优化目标是降低特征的整体方差。即假设 HQ 特征 $\boldsymbol{z}_i$ 与恢复的 HQ-like 特征 $\hat{\boldsymbol{z}}_i$ 之间的差异信号的方差是处处恒定的。然而，正如图 3.3 (g) 和图 3.3 (h) 所示，图像中的不同区域（例如，边缘、纹理和背景）可能具有不同的特征变化和噪声水平。在实际应用中，方差通常是不均匀的，尤其是在复杂的图像中，背景、边缘和纹理区域的噪声可能具有不同的特征。而假设方差为常数忽略了这些区域的局部差异，因此，均方误差损失对高斯似然函数中每个特征像素的方差恒定的假设是不合适的。

为了避免方差恒定的假设，本文提出了同时估计每个像素位置的 HQ-like 特征 $\hat{\boldsymbol{z}}_i$ 及其不确定性（即方差 $\boldsymbol{\theta}_i$）。对于给定的低质量图像 $\tilde{\boldsymbol{x}}_i$，希望从中重建出 HQ-like 特征，通过高斯分布概率密度函数来表示公式 (3-1) 中的似然函数，以及概率独立性原理，可以得到：

$$p(\boldsymbol{z}_i|\tilde{\boldsymbol{x}}_i)=p(\boldsymbol{z}_i\,|\,\tilde{\boldsymbol{x}}_i,\boldsymbol{\theta}_i)=p(\boldsymbol{z}_i\,|\,\hat{\boldsymbol{z}}_i,\boldsymbol{\theta}_i)=\frac{1}{\sqrt{2\pi}\boldsymbol{\theta}_i}exp\left(-\frac{||\boldsymbol{z}_i-g(\tilde{\boldsymbol{x}}_i;\boldsymbol{\Theta_2})||^2}{2{\boldsymbol{\theta}_i}^2}\right), \tag{3-6}$$

其中，$g(\tilde{\boldsymbol{x}}_i;\boldsymbol{\Theta_2})=\hat{\boldsymbol{z}}_i$ 表示重建出的 HQ-like 特征（均值），$\boldsymbol{\theta}_i$ 是估计的不确定性（方差）。这两者都可以通过深度卷积神经网络（DCNN）分别进行学习。

基于不确定性 $\boldsymbol{\theta}$ 在特征图中的稀疏性观察，如图 3.3 (g) 和图 3.3 (h) 所示，本文

中国知网　https://www.cnki.net

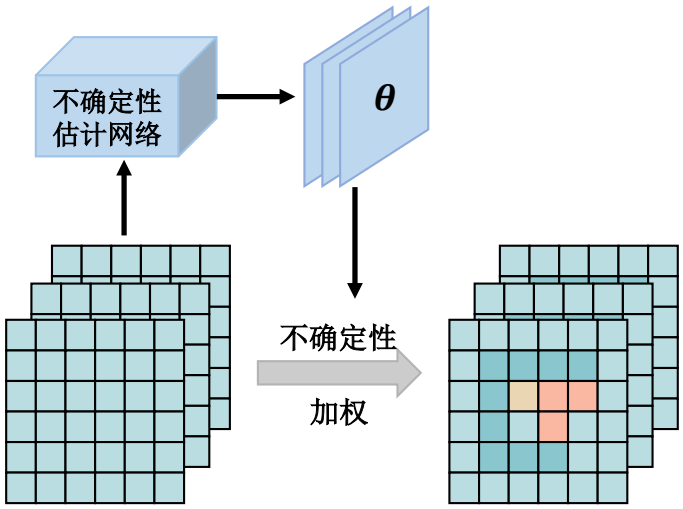


图 3.4 MSE 损失函数与不确定性加权的损失函数对比示意图

提出在方差的不确定性估计 $\boldsymbol{\theta}_i$ 上施加 **Jeffrey's 先验**[82]：即 $p(\boldsymbol{\theta}_i) \propto \frac{1}{\boldsymbol{\theta}_i}$，其表达式为：

$$\begin{aligned} p(\boldsymbol{z}_i, \boldsymbol{\theta}_i \mid \tilde{\boldsymbol{x}}_i) &\propto p(\boldsymbol{z}_i \mid \tilde{\boldsymbol{x}}_i, \boldsymbol{\theta}_i) p(\boldsymbol{\theta}_i) \\ &\propto \frac{1}{\sqrt{2\pi}\boldsymbol{\theta}_i} \exp\left(-\frac{||\boldsymbol{z}_i - g(\tilde{\boldsymbol{x}}_i; \boldsymbol{\Theta_2})||^2}{2{\boldsymbol{\theta}_i}^2}\right) \frac{1}{\boldsymbol{\theta}_i}. \end{aligned} \tag{3-7}$$

然后，忽略公式中的一些系数项，进行整理可得带有 Jeffrey's 先验的对数似然函数可以表示为：

$$\log p(\boldsymbol{z}_i, \boldsymbol{\theta}_i \mid \tilde{\boldsymbol{x}}_i) \propto -\frac{||\boldsymbol{z}_i - g(\tilde{\boldsymbol{x}}_i; \boldsymbol{\Theta_2})||^2}{2{\boldsymbol{\theta}_i}^2} - \log {\boldsymbol{\theta}_i}^2. \tag{3-8}$$

为了实现上述思想，本文提出在主干网络的末尾添加一个用于不确定性估计的分支网络（UEM），如图 3.2 中蓝色高亮的部分所示，以及图 3.5 所示的不确定性估计模块的神经网络结构。因此，方程 (3-8) 中的最大似然估计问题可以转化为以下基于不确定性学习的最小化特征蒸馏（ULFD）损失函数：

$$L_{ULFD} = \sum \frac{||\boldsymbol{z}_i - g(\tilde{\boldsymbol{x}}_i; \boldsymbol{\Theta_2})||^2}{2{\boldsymbol{\theta}_i}^2} + \log {\boldsymbol{\theta}_i}^2. \tag{3-9}$$

如图 3.2 由于高质量图像和成对的退化图像同时输入到主干网络中进行特征提取，获得高质量特征 $\boldsymbol{z}_i$ 和重建的特征 $\hat{\boldsymbol{z}}_i = g(\tilde{\boldsymbol{x}}_i; \boldsymbol{\Theta_2})$，同时估计出特征的不确定性 $\boldsymbol{\theta}_i$。

从公式 (3-9) 可以看出，学习到的方差 $\boldsymbol{\theta}_i$ 可以用于衡量重建的 HQ-like 特征 $\hat{\boldsymbol{z}}_i$ 与 HQ 特征 $\boldsymbol{z}_i$ 之间的接近程度。对于那些 $\hat{\boldsymbol{z}}_i$ 与 $\boldsymbol{z}_i$ 相距较远的区域，网络会估计出较大的方差，以减少误差项 $\frac{||\boldsymbol{z}_i - \hat{\boldsymbol{z}}_i||^2}{\boldsymbol{\theta}_i^2}$。当 $\hat{\boldsymbol{z}}_i$ 容易学习时，损失函数中的第二项 $\log {\boldsymbol{\theta}_i}^2$ 起主导作用，网络倾向于使 $\boldsymbol{\theta}_i$ 变小。这一机制类似于人类视觉中的注意力，使得网络能

中国知网 https://www.cnki.net

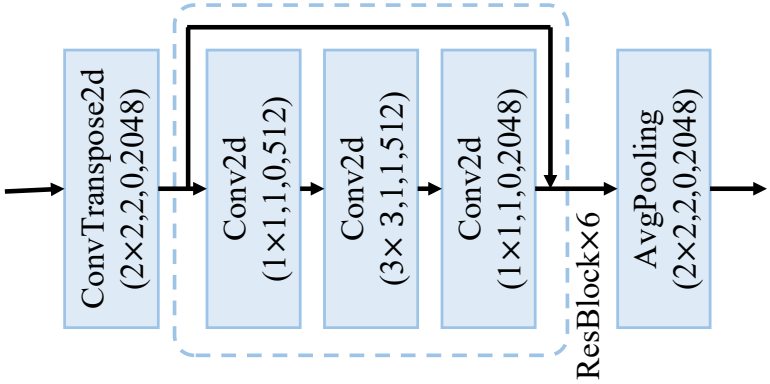


图 3.5　不确定性估计模块的网络结构示意图

够专注于重建特征中的困难区域[83]进行重点重建。

3.4.2 自特征蒸馏网络结构与训练目标函数

本章所提出的基于不确定性建模的自蒸馏特征表示增强算法的整体网络结构如图 3.2 所示。该网络框架结合了图像特征蒸馏和不确定性学习的设计。输入为成对的高质量（HQ）图像和仿真模拟的低质量（LQ）图像，首先通过特征提取主干网络提取深层语义特征。高质量图像的特征作为参考，退化图像被重建为类似高质量图像的特征（HQ-like 特征），并通过不确定性估计模块（UEM）处理困难区域。UEM 模块通过估计特征的方差，帮助模型聚焦于高不确定性的困难区域，从而提高模型在低质量图像上的识别能力。最终，经过全连接层和全局平均池化层处理，输出分类标签，完成图像分类任务。在训练过程中，使用不确定性加权的特征蒸馏损失函数（L_{ULFD}）优化 HQ 特征与 HQ-like 特征之间的差异，同时通过交叉熵损失函数（L_{CE}）进行分类任务的优化。

关于重建特征的位置，本章分别尝试了对识别网络中不同深度的特征进行重建，包括深层语义特征以及类似文献[14]中提到的浅层特征等。由于深层特征在提升分类器精度方面被证明更为有效（详细信息见第 3.5 节的消融实验部分）。因此，相关实验中最终使用在高质量图像上预训练的标准深度神经网络作为基线模型，并在用于特征提取的主干网络末尾（分类网络前）添加一个不确定性估计模块（UEM）来估计方差。

UEM 网络模块的详细设计如图 3.5 所示。由于深层网络的特征图分辨率较低，本节首先引入一个转置卷积层来扩展特征空间分辨率，这一操作类似于解码器的作用。接着，使用六个残差块来学习不确定性（方差）。类似于[60]中提到的瓶颈架构，本方法通过在残差块中使用 1×1 卷积来减少参数数量并降低最终特征图的维度。最后，使用一个平均池化层来保持输出维度与原始特征维度一致。为了稳定训练过程，本方

中国知网　https://www.cnki.net

法在不确定性网络分支中估计 $\boldsymbol{\sigma_i} = \log \boldsymbol{\theta_i}^2$ 而非直接估计 $\boldsymbol{\theta_i}$。因此，基于不确定性学习的特征蒸馏损失函数（公式 (3-9) ）可以重新表述为：

$$L_{ULFD} = \sum exp(-\boldsymbol{\sigma_i})||\boldsymbol{z_i} - g(\tilde{\boldsymbol{x}}_i; \boldsymbol{\Theta_2})||^2 + 2\boldsymbol{\sigma_i}. \tag{3-10}$$

综上所述，整个网络通过多任务学习策略[15]进行训练，即采用不确定性加权的特征重建损失与识别损失联合训练。将公式 (3-10) 代入公式 (3-3) 即

$$\begin{aligned} L &= L_{CE} + \lambda * L_{ULFD} \\ &= -y \log f(\boldsymbol{x}; \boldsymbol{\Theta_1}) - y \log f(\tilde{\boldsymbol{x}}; \boldsymbol{\Theta_1}) \\ &+ \lambda * \sum exp(-\boldsymbol{\sigma_i})||\boldsymbol{z_i} - g(\tilde{\boldsymbol{x}}_i; \boldsymbol{\Theta_2})||^2 + 2\boldsymbol{\sigma_i}, \end{aligned} \tag{3-11}$$

其中，L_{CE} 表示交叉熵损失，λ 是用于调节多任务联合损失权重的超参数。

3.5 实验结果

3.5.1 实验设置

数据集及评价指标：为了验证提出的基于不确定性建模的自蒸馏特征表示增强方法的性能，本章在低质量退化图像识别任务上进行了充分的实验。低质量图像识别任务的目标是尽可能准确地识别部分已知或完全未知退化类型的低质量图像数据。本章通过模拟 ImageNet-C 文献[24]中描述的多种退化类型（第 2.1.2 节详细介绍），生成退化图像并评估模型的鲁棒性。这些退化类型涵盖了不同形式的包括噪声、模糊、天气、数字退化等，能够有效考察模型在各种退化条件下的表现。具体地，对于 ImageNet-C 的 19 种退化类型，本实验选取前 15 种退化作为**已知退化**类型用于训练，后 4 种作为**未知退化**用于评估模型的鲁棒性。

如第 2.3 节所述，为了评估网络在这些退化条件下的鲁棒性，本实验采用了平均退化错误率（mCE)[24]作为 ImageNet-C 测试集的评价指标，并对所有实验中的 mCE 结果进行了归一化处理。同时，实验中也报告了模型的精确度（Top-1 Accuracy）指标，用于直观的对比其他方法，也用于评估模型是否过度拟合到低质量图像上而对原始清晰图像数据产生了灾难性遗忘。

模型训练设置：在本节的实验中，对于 15 种已知退化类型，训练时进行随机采样，并对 ImageNet 训练集的原始清晰图像进行该退化操作，单张图像不重复地随机进行 3 次退化操作。模型接受成对的原始清晰图像与对应的仿真退化图像作为输入，采用所提出的算法框架完成训练。本节在多个模型架构上进行了实验，如 ResNet50[60]和 ResNeXt101[84]，这些架构在图像识别任务中应用广泛，且使用了 ImageNet-1K[26]数据集进行了预训练。本实验采用了 Adam 优化器[85]，初始学习率设置为 0.001，并在

中国知网 https://www.cnki.net

训练过程中经过 5k、12.5k 和 25k 迭代时分别将学习率除以 10。模型共训练了 40k 次迭代（大约 10 个 epoch），每次迭代的批大小为 256。根据第 3.5.2 节中描述的消融实验，公式 (3-11) 中的超参数 λ 被设置为 0.1。

3.5.2 消融实验及复杂度分析

在本节中，首先讨论了特征重建时应选择浅层特征还是深层语义特征的问题。通过简单的对比实验发现，使用浅层特征进行重建在退化数据上的精度比使用深层语义特征低 4.5%。因此，本章所提出的方法选择重建识别网络的深层语义特征。接着，进行了多项消融实验，探讨了在所提出的方法中，哪些模块对性能提升有显著贡献。实验中将方法大致分为两个模块：**自特征蒸馏**和**不确定性估计**，并分别验证它们对实验性能的影响。

在没有添加任何模块的情况下，表示仅使用退化图像对模型进行微调，并且只通过交叉熵损失进行优化。仅添加自特征蒸馏模块表示使用公式 (3-5) 所述的均方误差（MSE）损失函数进行约束，即进行确定性估计。添加自特征蒸馏和不确定性估计两个模块表示为图 3.2 中所示的本文提出的方法，其中通过公式 (3-11) 中的联合损失函数同时学习 HQ-like 特征（均值）和其不确定性（方差）。所有模型均在 ResNet50 架构下进行训练和测试。实验使用了[24]中的 15 种退化类型进行训练。实验结果见表 3.1。

表 3.1　所提出方法的各模块有效性验证分析实验结果

自特征蒸馏模块	✗	✓	✓
不确定性估计模块	✗	✗	✓
清晰图像的精确度（Top-1 Accuracy）↑	75.11%	75.81%	**76.23%**
ImageNet-C 平均退化错误率（mCE）↓	51.31%	49.50%	**46.37%**

表 3.2　不同损失平衡权重 λ 取值对退化图像的准确度影响实验结果

不同 λ 的取值	0	0.01	0.1	1
退化图像的精确度↑	58.43%	62.37%	**63.44**%	62.78%

表 3.3　样本级及空间像素级不确定性估计的实验结果对比

估计样本级别的不确定度	mCE: 46.93%
估计空间像素级别的不确定度 (本章方法)	**mCE: 46.37%**

其次，对于公式 (3-11) 中的损失函数平衡权重项 λ，本节研究了其对模型最终识别精度的影响，并对四个不同的值进行了经验性选择。实验结果见表 3.2。根据以上实验结果，最终选择了 $\lambda = 0.1$。此外，还比较了样本级不确定性（维度为 $B \times 1 \times 1 \times 1$）

中国知网　https://www.cnki.net

和空间级不确定性（本文方法，维度为 $B \times C \times h \times w$）的鲁棒性指标 mCE 值，结果如表 3.3 所示（值越低越好）。结果表明，样本级不确定性的性能略逊于采用的空间级不确定性。这是因为样本级不确定性无法聚焦于特征中的困难区域，导致特征细节恢复效果稍差。

关于额外添加的不确定性估计模块带来的额外计算开销影响，本实验对训练时间进行了详细分析。在本实验设置中，训练数据的批量大小设置为 512，并使用了 4 块 NVIDIA GeForce RTX 3090 GPU。关于训练时长的分析结果表明，使用所提出的不确定性估计模块（UEM）时，训练速度略有下降，平均每批次训练时间为 **1.37 秒**，总训练时间为 **2.5 GPU 天**，而在没有该模块的情况下，训练速度为 **1.14 秒/批次**，总训练时间为 **2.2 GPU 天**。实验结论认为：尽管在训练中引入了该模块，但其带来的计算开销在整体训练过程中是可接受的，且在测试阶段无需进行不确定性估计，因此去除不确定性估计模块后，不会产生额外的计算成本。

3.5.3 鲁棒性分类的实验结果

为了验证本章所提出方法在各种退化图像上的泛化能力，本节将该方法与当前最先进的相关方法进行了比较，包括基于特征表示增强的 DDP[14]和 QualNet[15]方法，基于图像复原的 URIE[6]方法，以及基于传统蒸馏的 KD VID[86]方法，并使用 ImageNet-C 作为基准数据集。实验设置与相关文献中的设置保持一致，通过细致的实验过程，成功复现了这些方法的结果。在本章所提出的自特征蒸馏网络中，不确定性估计模块（UEM）被用来提升模型在多种退化情况下的特征重建鲁棒性。为了进一步验证 UEM 的有效性，设计了对比性实验，其中网络被修改为确定性模型，通过去除 UEM 分支并仅使用传统的均方误差损失（MSE）进行训练。通过这种方式，实验可以清晰地对比带有和不带有 UEM 模块的模型在退化图像识别中的性能差异，从而验证所提出方法在提升模型鲁棒性和准确度方面的有效性。

表 3.4 ImageNet-C 数据集不同测试集上各方法整体性能对比

方法	网络结构	清晰图像↑	已知退化↑	未知退化↑	平均错误率 mCE↓
基线模型[60]	ResNet50	**76.82%**	39.17%	47.11%	76.5%
DDP[14]		72.15%	48.21%	50.73%	62.78%
URIE[6]		73.80%	55.10%	56.50%	55.70%
KD VID[86]		74.85%	-	-	51.29%
QualNet50[15]		75.43%	61.08%	58.10%	50.34%
本章方法（去除不确定性）		75.81%	61.65%	60.23%	49.50%
本章方法（包含不确定性）		76.23%	**63.44%**	**62.90%**	**46.37%**
基线模型[84]	ResNeXt101	**79.68%**	47.08%	55.53%	69.76%
QualNet101[15]		77.81%	65.47%	63.28%	42.61%
本章方法（去除不确定性）		78.35%	66.81%	65.30%	41.23%
本章方法（包含不确定性）		79.04%	**69.16%**	**67.83%**	**39.50%**

中国知网 https://www.cnki.net

表 3.5　ImageNet-C 已知退化测试集上的各方法性能对比

方法	网络结构	噪声			模糊			
		高斯	散粒	脉冲	散焦	毛玻璃	运动	变焦
基线模型[60]	ResNet50	29.29%	27.03%	23.81%	38.75%	26.78%	38.67%	36.24%
QualNet50[15]		59.83%	60.28%	59.79%	56.20%	57.38%	60.81%	59.83%
本章方法		**62.36%**	**62.67%**	**61.93%**	**59.44%**	**57.94%**	**62.75%**	**61.37%**
基线模型[84]	ResNeXt101	39.12%	36.61%	34.80%	42.87%	28.29%	44.59%	42.17%
QualNeXt101[15]		61.18%	60.06%	60.92%	60.21%	58.61%	**69.65%**	**69.93%**
本章方法		**67.42%**	**67.70%**	**67.29%**	**63.92%**	**63.60%**	69.07%	69.76%

方法	网络结构	天气				数字			
		雪	霜	雾	亮度	对比度	弹性形变	块像素化	JPEG 压缩
基线模型[60]	ResNet50	32.53%	38.14%	45.84%	68.02%	39.06%	45.25%	44.79%	53.41%
QualNet50[15]		59.29%	59.45%	61.89%	68.22%	58.74%	60.94%	66.55%	64.36%
本章方法		**59.91%**	**60.53%**	**64.67%**	**72.98%**	**61.14%**	**63.95%**	**70.37%**	**69.60%**
基线模型[84]	ResNeXt101	36.49%	41.82%	48.87%	69.66%	41.97%	48.84%	53.98%	59.68%
QualNeXt101[15]		**68.38%**	66.63%	69.62%	**75.71%**	67.41%	**70.23%**	72.62%	68.18%
本章方法		67.40%	**67.69%**	**71.46%**	75.61%	**69.86%**	69.24%	**74.82%**	**72.64%**

表 3.6　ImageNet-C 未知退化测试集上的各方法性能对比

方法	网络结构	精确度 Top-1 Accuracy ↑			
		斑点噪声	高斯模糊	溅射效应	饱和度变化
基线模型[60]	ResNet50	35.49%	49.16%	41.87%	61.92%
QualNet50[15]		63.50%	52.59%	54.56%	61.75%
本章方法（去除不确定性）		65.25%	55.39%	56.33%	63.95%
本章方法（包含不确定性）		**66.44%**	**58.59%**	**58.65%**	**67.92%**
基线模型[84]	ResNeXt101	47.92%	57.94%	48.72%	67.52%
QualNeXt101[15]		64.21%	57.24%	62.48%	69.19%
本章方法（去除不确定性）		68.70%	61.25%	60.37%	70.86%
本章方法（包含不确定性）		**71.23%**	**64.87%**	**63.04%**	**72.18%**

表 3.4 展示了本章所提出方法在 ImageNet-C 测试集上的表现，明显优于这些相关方法。**清晰图像**、**已知退化**、**未知退化**分别表示在高质量图像、训练集中已见的 15 种退化图像和训练中未见的 4 种未知退化图像上的 top-1 分类精度。为了验证模型的泛化性和鲁棒性，本节使用了两种常见的分类神经网络架构，ResNet50[60]和 ResNeXt101-32x8d[84]，并进行了实验比较。表 3.5 展示了模型在各个已知退化类型下的性能表现，表 3.6 详细展示了在训练时未见过的 4 种退化类型下模型的鲁棒性表现。值得注意的是，本章所提出的方法不仅在清晰图像上的性能下降较小，且在多种退化类型的处理上展现了更强的鲁棒性，相较于其他方法表现出显著优势，进一步验证了本章方法在提高模型鲁棒性和应对各种图像退化的有效性。

中国知网　https://www.cnki.net

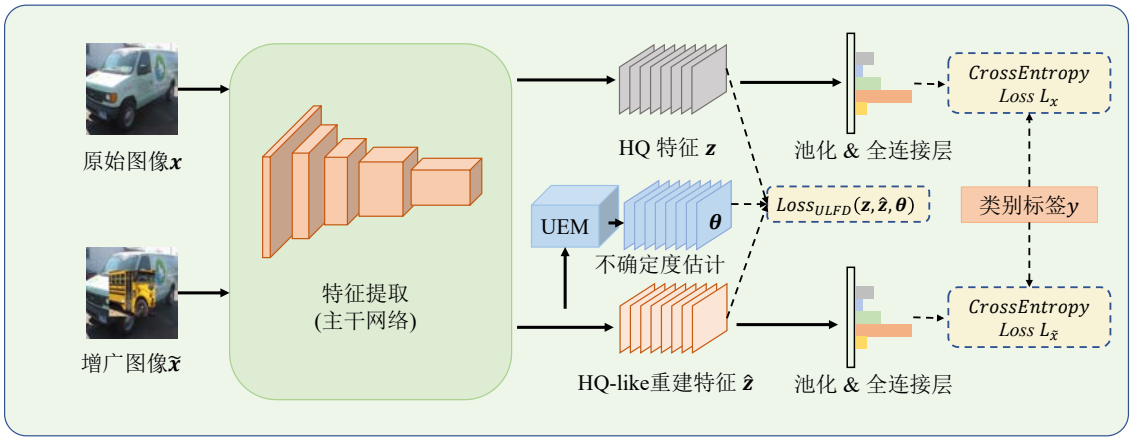


图 3.6　本方法对常见数据增广方法的扩展示意图

3.5.4 扩展数据增广训练实验结果

数据增广方法，如前所述，是一种通过合成增强图像并将这些增强图像与原始图像一起用于训练网络的技术，旨在通过引入具有不同数据分布的样本来提高识别准确率和模型的鲁棒性。与常见的增广训练方法相比，本章所提出的框架的主要区别在于，引入了自特征蒸馏操作和不确定性估计分支。因此，本方法可以轻松地扩展到现有的增广训练流程中，从而进一步提升模型在各种退化条件下的表现和鲁棒性。

表 3.7　本章方法与各数据增广方法结合的性能对比

方法	清晰图精确度↑	退化图错误率 mCE↓
DeepAugment[36]	74.60%	60.31%
DeepAugment+ **本章方法**	**74.83%**	**59.04%**
Augmix[18]	75.38%	65.30%
Augmix+ **本章方法**	**75.40%**	**64.37%**
DeepAugment+Augmix[36]	73.64%	53.50%
DeepAugment+Augmix+ **本章方法**	**73.81%**	**52.47%**

在本实验设计中，输入图像对不再是清晰图像和使用退化模型生成的已知的 15 种退化类型的仿真退化图像，而是包含一张原始清晰图像和通过常见数据增广方法（如平移缩放剪贴等）生成的对应图像（增广图像的示例见第 2.2.3节），即测试集种所有的退化类型在训练时均未知。实验中结合的增广方法包括 Augmix[18]、DeepAugment[36]和 DeepAugment+Augmix[36]。在实验中使用基于不确定性估计的特征蒸馏来增强增广图像的特征表示。图 3.6 给出了本方法对传统图像增广方法的扩展示意图。表 3.7 展示了将本章所提出的方法与数据增广的结合，并与传统增广方法进行比较的结果。通过在训练过程中引入自特征蒸馏和不确定性估计模块，并共同训练整个网

中国知网　https://www.cnki.net

络，模型在清晰图像上的识别准确性和低质图像上的鲁棒性得到了提升，验证了所提方法在增强数据训练中的有效性。

3.5.5 低分辨率图像目标检测实验

在低分辨率图像的目标检测任务中，图像的细节信息缺失和特征模糊性会导致模型对目标边界、类别判别等关键信息的学习变得困难，进而影响检测性能。为此，本文采用基于不确定性建模的自特征蒸馏方法，以增强模型对低分辨率图像的鲁棒性。在实验部分，本节使用下采样方法构建了低分辨率目标检测数据集，对基于不确定性建模的自特征蒸馏方法进行评估，并将其与主流检测模型进行对比。具体地，我们首先在全分辨率图像上训练教师模型，并利用其特征对低分辨率学生模型进行蒸馏，同时引入不确定性建模，对学生模型的特征不确定性进行估计。在蒸馏过程中，我们对不同层级特征同时估计不确定性，并进行动态加权，使模型在学习过程中更加关注稳定特征，从而减少低分辨率导致的信息损失。

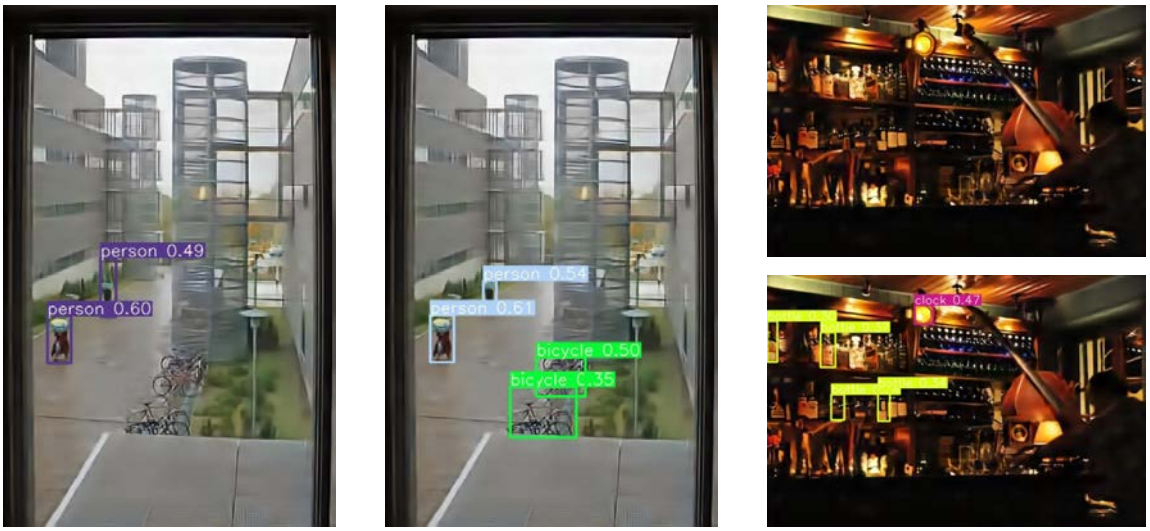


图 3.7　COCO 数据集上低分辨小目标检测结果对比

表 3.8　本章方法在低分辨率目标检测上的实验结果

方法	COCO-C 数据集的 mAP	方法	COCO-C 数据集的 mAP
FasterRCNN 基线模型	18.0	YOLO-V5s 基线模型	37.0
退化图像微调	22.4	退化图像微调	44.2
winter 方法	26.3	winter 方法	45.2
Graph-KD 方法	25.9	Graph-KD 方法	46.1
本章方法	**28.9**	本章方法	**47.4**

在本节实验中，比较了相关方法分别在 Faster R-CNN[61]及 YOLO-V5[87]两种类型的检测框架上的性能。其中，Faster R-CNN 在清晰图像即 COCO 原始测试集上的 mAP

中国知网　https://www.cnki.net

性能为 37.4，而加入了许多训练技巧的 YOLO-V5s 在 COCO 清晰图像上的 mAP 为 54.0，但是将这二者直接用于退化的低分辨率图像上时，性能显著下降。表 3.8 为两个框架下各方法的 mAP 数值结果对比。左右分别为以 Faster R-CNN 和 YOLO-V5s 作为基准模型的检测结果。实验结果表明，该方法在多个数据集上均能有效提升目标检测性能，相较于传统特征蒸馏以及图关系特征蒸馏方法，在 mAP 指标上实现了 1 3% 的提升。图 3.7 展示了 COCO 数据集上的部分低分辨率小目标检测结果对比，两对图像中，左侧和上侧分别为微调方法，右侧和下侧分别为本章方法。实验结果表明，引入不确定性建模后，模型能够更有效地聚焦于判别性特征区域，增强对小目标和模糊目标的检测能力，进一步提升了其在低分辨率场景下的鲁棒性。

3.5.6 特征可视化结果分析

为验证特征重建方法的有效性，本节通过一系列可视化实验对特征进行了观察。首先，本节使用本章所提出的方法训练的网络提取了高质量（HQ）图像和低质量（LQ）图像的深层语义特征图（空间分辨率为 7×7），并对特征图中的 12 个随机选择的通道进行了展示，并进行了归一化处理。

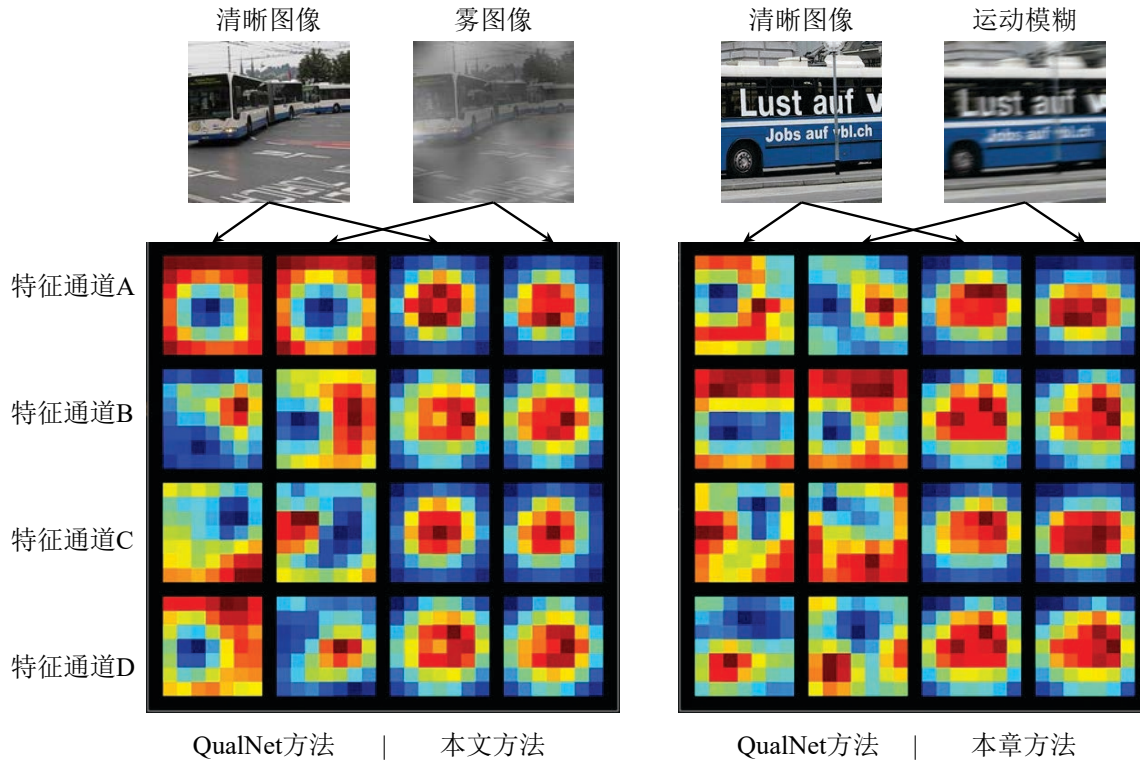
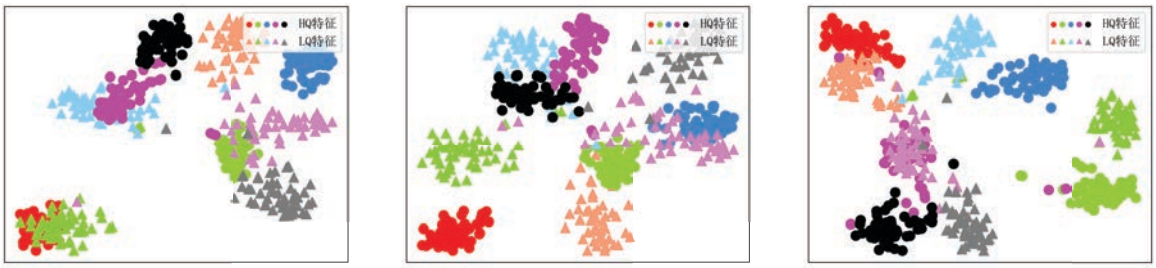


图 3.8 不同方法提取的 HQ 和 LQ 图像深层语义特征可视化对比

如图 3.8 所示，第一行是从清晰图像中提取的特征图，第二行是从相应退化图像中提取的特征，第三行是通过本章方法重建的特征。观察结果表明，通过本章所提出的方法，从低质量图像提取的几乎所有特征图都得到了较好的重建，与从清晰图像中

中国知网 https://www.cnki.net

提取的特征图相似。这表明，所提出的方法能够显著恢复退化图像的特征，使其接近原始清晰图像的特征，从而改善模型在退化图像上的识别精度。



基准模型　　QualNet方法　　本章方法

图 3.9　不同方法提取的 HQ 和 LQ 特征的语义分布对比

此外，本实验还将本章所提出的方法与当前最先进的方法 QualNet 进行了特征分布可视化的对比。具体地，实验中随机选取了 ImageNet-1K[26]验证集中的五个类别，并采用文献[24]中的低对比度退化方法，设置退化严重度为 3，生成相应的退化图像。接着，将这两组图像输入到训练好的分类器中，提取其用于分类的深层语义特征，并进行 t-SNE 降维可视化。图 3.9 展示了特征分布的可视化结果，其中彩色符号代表从相应类别的图像中提取的特征向量，相同颜色表示来自同一类别的特征。点标记表示 HQ 特征，三角标记表示 LQ 特征。可见，本章所提出的方法能够更好地聚集同一类别的低质量图像和高质量图像的特征，显著提升了分类器在退化图像上的鲁棒性。这进一步验证了所提方法在退化图像识别任务中的有效性。

3.5.7 不确定性估计的有效性验证

为了探究不确定性学习如何在每个图像 $\tilde{\boldsymbol{x}}$ 上工作，本节在空间和通道维度上对学习到的该图像的特征不确定性（方差）图 $\boldsymbol{\theta}_i$ 进行了平均，即，

$$\theta_{\tilde{x}} = \frac{1}{CHW}\sum_{c=1}^{C}\sum_{h=1}^{H}\sum_{w=1}^{W}\boldsymbol{\theta}_{c,h,w}, \tag{3-12}$$

作为该样本的不确定性整体表示。实验在 ImageNet-C[24]的两种退化，不同的退化严重等级上计算了每个样本的不确定性值。得到的不确定性和样本数量关系如图 3.10 所示。从图中可以发现，估计的不确定性 $\theta_{\tilde{x}}$ 与退化的严重程度密切相关。图像退化越严重，难以识别的样本越多，相应的 $\theta_{\tilde{x}}$ 值也越大。这一点与文献 DUL[73]中相关结论类似。另外，结合表 3.5 和表 3.6 中的溅射和运动模糊两种退化类型的精确度结果（58.65% 和 62.75%），以及比较图 3.10 中对应的不确定数值分布，可以观察到，模型对溅射退化的识别准确性低于运动模糊的情况，且对应的具有较大不确定性值（难样本）的样本数量更多。这些实验结果支持了在第 3.4.1 节中所述的观点，即不确定性

中国知网　https://www.cnki.net

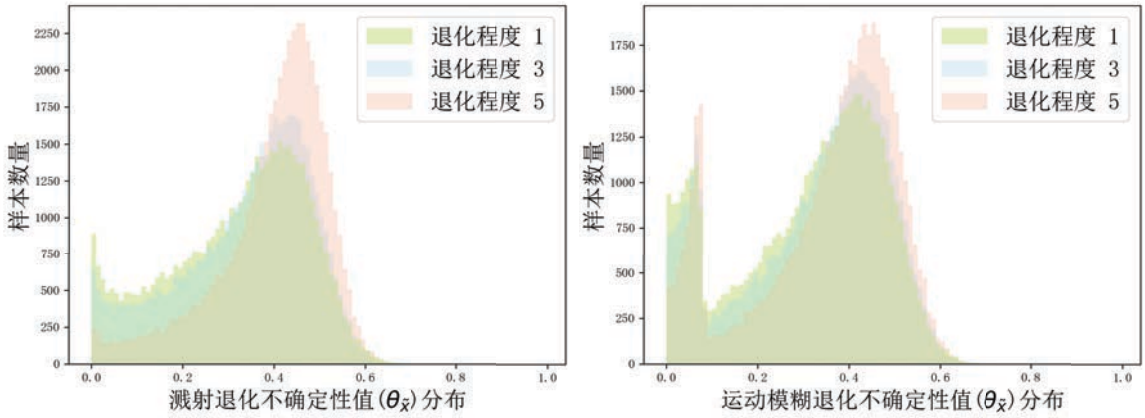


图 3.10 不同退化严重程度下退化图像的不确定度-样本数量分布

度量了 HQ-like 特征重建的难度，从而使分类器能够更加关注难样本，提高在高严重度退化数据上的表现。

3.6 本章小结

本章提出了一种创新的基于不确定性建模的自蒸馏特征表示增强方法，旨在提升低质量图像识别任务中的模型鲁棒性。本方法首次引入不确定性估计模块（UEM）与自特征蒸馏操作，聚焦于重建困难的特征区域，能够有效重建多种退化图像的特征，增强其语义表示能力，从而显著提升模型对低质量图像的识别性能。具体地，数据方面，使用清晰图像仿真生成已知类型的退化图像，并将这一成对图像输入模型。模型方面，在清晰图像特征的监督下，通过共享模型参数的自蒸馏方式对低质量图像进行特征重建。为了充分挖掘退化图像中特征统计分布的不确定性，本章结合最大后验概率利用高斯分布建模特征像素各区域位置可能的方差，并提出自适应地对困难区域赋予更高权重的特征重建损失函数，从而提升模型在高严重度退化图像上的特征重建能力。通过一系列实验验证表明，所提方法在多个退化类型下表现出较强的鲁棒性，尤其在高严重度的退化图像上，模型的识别精度和鲁棒性得到了显著提升。

尽管本方法在一定程度上缓解了低质图像带来的性能下降影响，但仍存在一定的局限性，即方法要求成对的图像输入，实际应用场景难以获得清晰的对应图像。在本文接下来的工作中将针对这一局限性进一步展开研究。

中国知网 https://www.cnki.net

第四章　基于数据本征表示学习的鲁棒目标识别方法

4.1 引言

尽管基于成对图像特征蒸馏的方法在低质量图像识别中取得了一定进展，但仍然面临若干挑战。首先，成对图像蒸馏依赖于从清晰图像和对应退化图像中提取的成对数据进行特征对齐。然而，在实际应用中，获取大规模成对图像数据常常面临高昂的成本和较大的数据获取难度，尤其是在多种退化类型和不同严重程度的情况下。其次，即使可以获得成对数据，由于退化图像的特征与清晰图像的特征差异通常较大，导致特征对齐变得异常复杂。尤其是当图像退化严重时，期望通过损失函数将退化图像的特征直接逼近清晰图像的特征变得更加困难，模型收敛缓慢，且容易陷入局部最优解，特征重建效果较差。因此，基于成对图像蒸馏的方法不仅对高质量数据依赖性强，而且在面对严重退化图像时，训练优化的挑战显著增加，从而影响其在低质量图像识别任务中的有效性和泛化能力。

针对上述问题，本章提出了一种基于数据本征表示学习的低质量图像特征量化方法。通过引入特征向量的量化表示，能够有效去除不同质量图像特征中的冗余及干扰信息，提升特征表示能力。具体来说，本方法在识别网络中引入一个用于存储各种特征组元的码本模块，用于对深层特征进行量化。训练过程中，输入图像包含清晰图像以及各种严重程度的仿真退化图像，经过特征提取后，使用码本中的特征组元对所有图像特征进行量化表示，映射到统一的特征空间。随后将量化后的特征与原始特征拼接，并设计自注意力模块用于进一步增强特征的表达能力。这一过程使得模型能够学习到一个更加鲁棒、质量无关的特征表示。与基于成对图像的特征蒸馏方法不同，本方法不再依赖清晰图像和退化图像的成对关系，显著提升了训练过程的灵活性。此外，本方法通过将不同质量的特征表示映射到统一的离散空间，对清晰和退化图像的特征同时进行联合优化，有效地保留了共同的识别关键特征，缩小特征差异，而非强制将退化图像的特征逼近清晰图像的特征，降低了训练优化难度，提升了模型对各种退化图像的适应能力，显著提高了低质量图像的识别准确度。在多个不同的基准测试集上的实验结果表明，本方法在特征空间中能够很好地聚集多种退化下的同类图像，显著提高了不同质量图像之间的特征一致性，识别准确率也相应大幅提升。

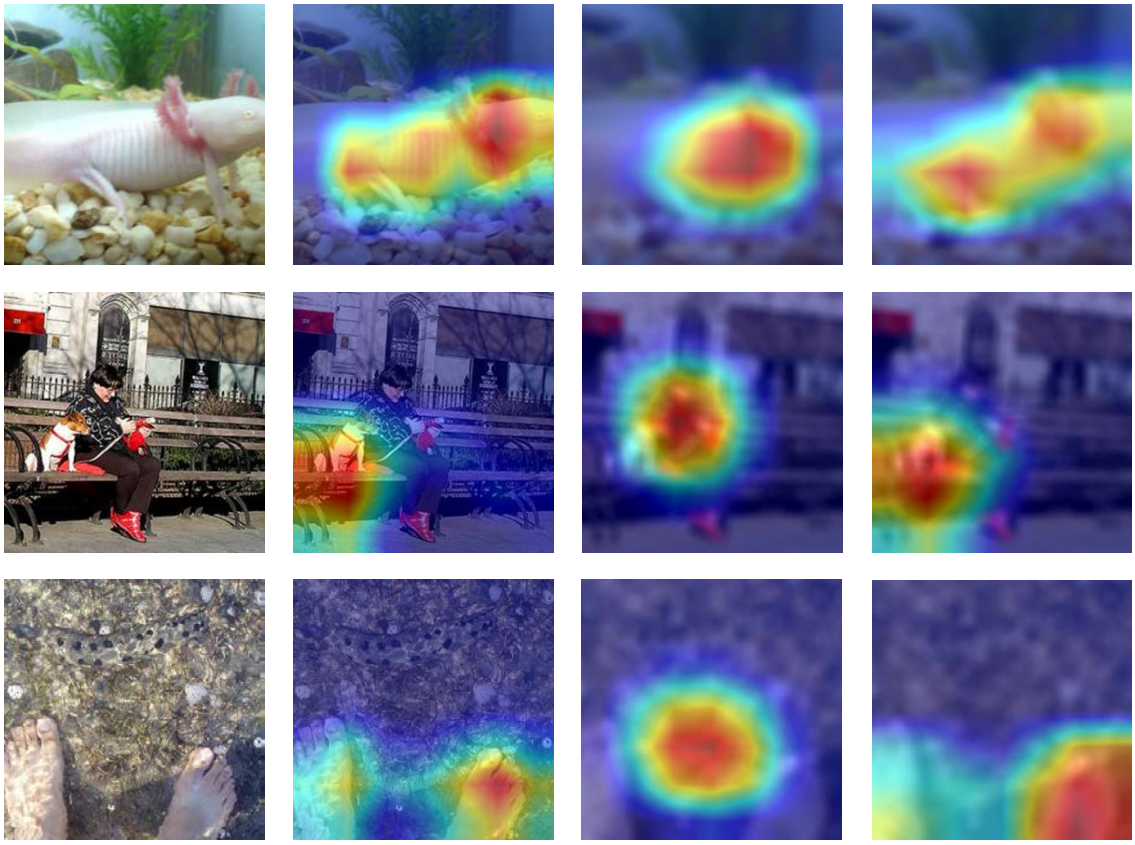
4.2 方法简介及相关基础知识

近年来，深度卷积神经网络（DCNN）在许多计算机视觉任务中取得了显著的进展，包括图像分类[26,56,60,62]、目标检测[61,63]以及图像分割[58-59]等任务。尽管在一些数

中国知网　https://www.cnki.net

据集上，深度模型的表现已经超过了人类，但其在面对低质量图像时的鲁棒性依然存在不足[88-89]。研究表明[24,36,90-91]，尽管深度模型在高质量数据上经过训练能够取得很好的表现，但当其在实际应用中遇到低质量数据时，性能往往显著下降。这些低质量数据通常包含常见的图像退化现象，如模糊、噪声、光照变化以及恶劣天气等。举例来说，经典的 ResNet50 模型在清晰的 ImageNet 验证集上的准确率为 76%，然而，当在同一测试数据集加入高斯噪声时，其平均准确率降至 30% 以下，展现出深度模型在低质量图像上的脆弱性，易受退化干扰。

如图 4.1 所示，图像质量对模型的类别激活区域有着显著的影响。具体来说，低质量图像可能导致模型过度关注图像中的不完整或错误区域，例如在失焦模糊的图像中，模型可能会错误地将注意力集中在不相关的区域，进而做出错误的预测。深度退化先验（DDP）[14]进一步表明，深度特征表示空间中的退化是导致模型性能下降的主要原因，因而，探索退化特征与清晰特征之间的映射关系，对于提高下游分类或检测任务的表现具有重要的意义。



(a) 清晰图像　(b) 清晰图像类激活图　(c) QualNet在模糊图像上的激活图　(d) 本章方法在模糊图像上的激活图

图 4.1　清晰与退化图像模型的类别激活区域图示例

为增强低质量图像的特征表示，现有的解决方案通常依赖于成对图像训练方法，

中国知网　https://www.cnki.net

即通过对齐清晰图像和退化图像的特征来进行特征重建。这类方法，如 DDP[14]和 QualNet[15]，以及如上一章提出的基于不确定性建模的自蒸馏特征表示增强方法等，采用高质量图像特征作为监督信息，并通过蒸馏方法[67,86,92-93]来改进低质量图像的特征表示，从而提升识别的准确度。

尽管基于成对图像的特征蒸馏方法在学习低质量与高质量特征之间的映射关系方面取得了一定进展，但这类方法仍面临诸多挑战。首先，从数据层面来看，这类方法严重依赖于大规模成对训练数据，然而在实际应用场景中，获取精确对齐的成对图像（即同一场景的低质量版本和高质量版本）往往存在较大困难，这不仅增加了数据采集的成本，也限制了模型在实际场景中的适用性。其次，从特征对齐的角度来看，现有方法在强制对齐过程中往往不加区分地使低质量图像的所有特征都向清晰图像的特征逼近，这种做法虽然在一定程度上提升了特征的一致性，但也带来了明显的弊端：模型可能会过度关注与识别任务无关的特征（如背景纹理、色彩分布、光照条件等），这些特征虽然对图像质量较为敏感，且属于难以重建的区域（如上一章节所述），却与目标类别的判别信息缺乏直接关联。这种不加区分的特征对齐方式会导致特征空间中出现大量冗余信息，不仅降低了特征重建的效果，还可能引入噪声干扰，从而影响模型的训练过程。更为严重的是，这些冗余特征的存在不仅无法为分类任务提供有效的判别信息，反而会增加模型的训练难度，导致优化过程更容易陷入局部最优解，使得模型难以从退化图像中提取出真正具有判别性的关键特征。因此，基于成对图像的特征蒸馏方法在低质量图像识别任务中仍面临着数据依赖性强、训练效率低、优化困难等多重挑战。

为了解决上述问题，受稀疏表示和字典学习（Sparse Coding）的启发，稀疏编码能够通过少量基向量的线性组合有效表示高维数据，从而去除冗余信息并提取本质特征，且其在图像复原[94-95]、压缩感知和特征提取等领域有着广泛的应用。而向量量化（Vector Quantization, VQ）是压缩编码领域的常见算法，其本质上是稀疏表示的一种特殊的极简情况，即稀疏表示系数为一维独热编码向量[96]。类似于稀疏表示在图像复原中的应用，VQ 的压缩-重建学习框架也有助于去除信号中的噪声和冗余信息，并学习对识别至关重要的特征。基于此，本章提出引入向量量化（Vector Quantization, VQ）来进一步优化特征表示增强的过程，通过离散化特征表示来减少冗余信息的干扰，从而学习一种与图像质量无关的特征表示。具体而言，向量量化将连续的低质量和图像特征映射到有限的离散码本空间，强制模型专注于学习与任务相关的判别性特征，同时抑制与识别任务无关的背景、颜色和光照等冗余特征。这种离散化操作不仅能够提升特征表示的紧凑性和鲁棒性，还能降低模型对成对数据的依赖，从而缓解数据获取的难题。随后，由于直接硬量化（选择和替换）可能会丢失部分有用信息，本章提出将量化后的特征与原始特征拼接，并使用自注意力模块进一步增强质量无

中国知网　https://www.cnki.net

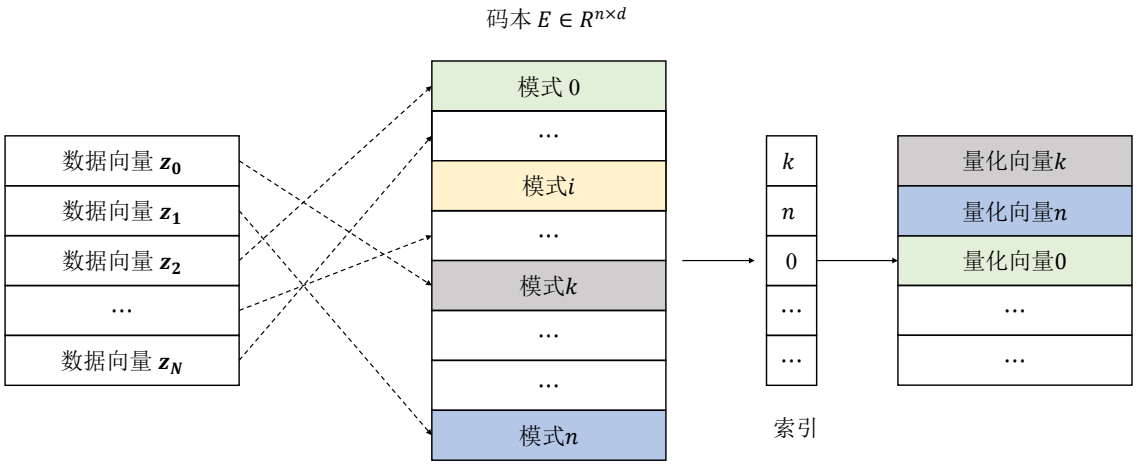


图 4.2 压缩编码中的向量量化过程示意图

关的表示，同时削弱无关特征的影响。通过将向量量化与特征蒸馏相结合，本章方法旨在提高低质量图像识别任务中的特征重建效果和模型优化效率，为后续的识别任务提供更干净、更具判别性的特征表示。

在正式介绍本文方法之前，首先简要介绍向量量化（Vector Quantization, VQ）和注意力机制（Attention Mechanism）的基础知识及其相关应用。

（1）向量量化与本征表示

稀疏表示压缩编码旨在通过从已学习的字典中获取稀疏系数向量来有效地表示输入信号。字典中的组件可以被视为信号的不同原子。稀疏表示学习具有许多优势，如消除信号中的噪声、增强表示的鲁棒性，并可用于压缩感知。已有许多工作将稀疏表示应用于图像去噪[94]、超分辨率[95]等任务。而向量量化作为经典的压缩编码方法[97]，是一种将连续的高维特征空间离散化为有限码本（Codebook）的技术。广泛用于信号处理和模式识别，特别是在图像压缩、语音编码以及自然语言处理等领域中。

如图 4.2 所示，其核心思想是通过构建一个包含有限数量向量的码本，将输入的高维特征映射到码本中最接近的向量（称为量化向量），这一过程实现了信息的压缩，能够有效减少数据表示中的冗余性，从而实现特征的压缩和离散化表示。通常，向量量化需要一个码本和预设的量化策略，其中欧氏距离常被用作量化策略的核心度量方式。即通过计算输入数据向量与码本中各个向量之间的欧氏距离，可以找到最相似的码本向量来替代原始输入数据向量，从而实现特征的量化表示。即，对于输入数据向量 $\tilde{\boldsymbol{z}}$，假设已经有一个预先学习好的码本 $E \in \mathbb{R}^{n\times d}$，其中包含多个模式，量化可

中国知网 https://www.cnki.net

以使用以下公式得到其对应的索引：

$$\begin{aligned} \hat{\boldsymbol{z}} =& E(\tilde{\boldsymbol{z}}) = \boldsymbol{e_k}, \\ & \text{where } k = \arg\min_i \|\tilde{\boldsymbol{z}} - \boldsymbol{e_i}\|_2^2, \end{aligned} \tag{4-1}$$

其中 n 表示码本中的向量数量，d 表示每个向量的维度，$\boldsymbol{e_i}$ 是码本中的第 i 个元素。在解码时，使用索引 k 从码本中提取向量 $\boldsymbol{e_k}$ 完成向量量化，并且 $\boldsymbol{e_k}$ 通常被表示为 $\hat{\boldsymbol{z}}$，即量化后的特征向量。

作为一种失真编码方法，向量量化要求码本能够很好地表示各种输入，类似于一个过完备字典。显然，一个好的码本在向量量化中起着至关重要的作用。因此，如何获得一个较好的码本是向量量化方法的关键问题之一。最经典的码本生成方法是基于聚类算法，例如 K 均值（K-Means）算法。通过对训练数据中的特征向量进行聚类，将聚类中心作为码本中的向量。这种方法能够使码本向量尽可能覆盖输入数据的分布，从而减少量化误差。近期，VQ-VAE[98]（Vector Quantized Variational Autoencoder）通过在变分自编码器中构建了神经网络作为码本，来学习图像的离散视觉表示。方法中使用了梯度直通估计器[99]与 VQ 损失、commit 损失和图像重建损失对整个模型进行端到端训练。该方法能够有效地通过深度学习模型训练的方式学习图像的离散特征分布，并广泛应用于许多生成模型中。之后的许多相关研究者[97,100-102]表明，学习离散表示不仅有助于视觉理解，还能提高模型的鲁棒性。在这一研究方向上，离散特征表示学习已广泛应用于图像超分辨率、对抗训练、文本-图像生成等许多视觉任务中[23,103-107]。

（2）注意力机制

注意力源于人类感知的启发，即人类在处理复杂信息时会优先关注某些重要的信息，而忽略其余部分。注意力机制是一种模拟人类视觉注意力的计算模型，能够动态地分配权重以关注输入数据中的重要部分。其核心思想是通过计算特征之间的相关性，为不同特征分配不同的重要性分数，从而增强对关键信息的提取能力。注意力机制最初在自然语言处理领域机器翻译的对齐过程中取得了显著成功[108]，随后被广泛应用于计算机视觉任务中，如图像分类、目标检测和图像生成等。在图像处理任务中，如果图像中的所有信息都被均等学习而没有任何优先级，模型往往会发生过拟合，导致在新测试数据上的泛化能力差。因此，尤其在识别任务中，研究者希望模型通过注意力机制能够更多地关注图像中的显著物体本身，专注于与任务相关的判别性区域，同时帮助模型忽略背景和其他不相关信息。

SE-Net[109]提出了一个特征的通道级注意力模块，通过显式建模通道间的依赖关系来增强特征的表达能力。SE-Net 首先通过全局平均池化（Global Average Pooling）

中国知网　https://www.cnki.net

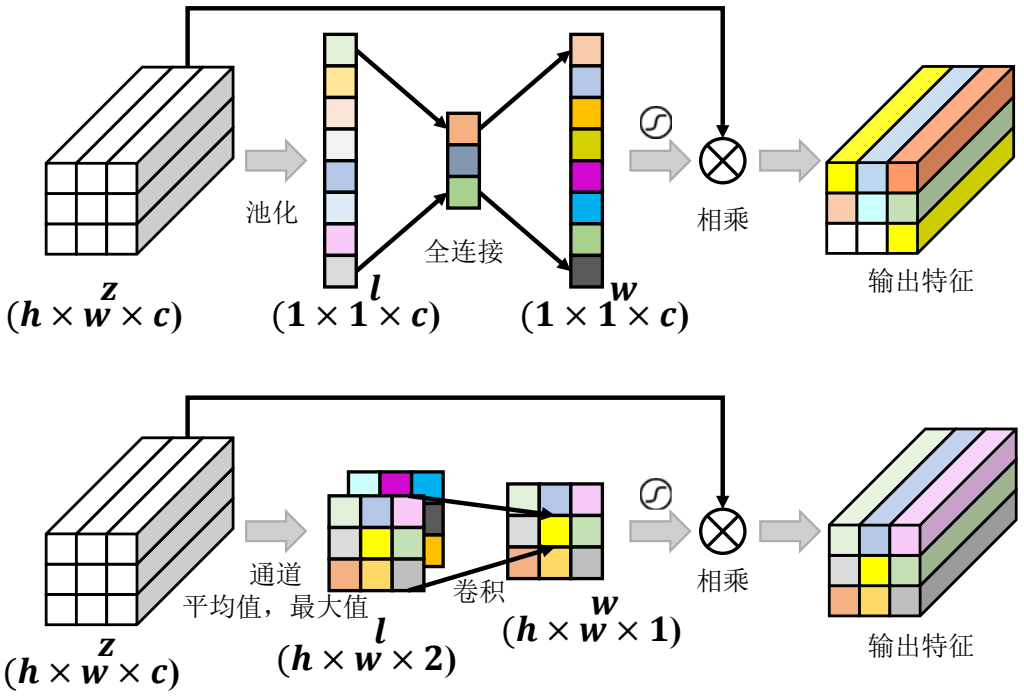


图 4.3　通道注意力，空间注意力机制示例

压缩空间维度信息，生成通道描述符；随后利用全连接层和非线性激活函数学习通道间的非线性关系，并为每个通道分配一个权重；最后通过加权操作重新校准通道特征，从而突出重要通道并抑制不相关通道。这种通道注意力机制能够有效提升模型对特征通道的选择性，在图像分类等任务中取得了显著效果。

CBAM[110]进一步扩展了注意力机制的应用范围，提出了卷积块注意力模块（Convolutional Block Attention Module），将通道注意力与空间注意力相结合。CBAM 首先通过通道注意力模块对特征图的通道维度进行加权，随后通过空间注意力模块对特征图的空间维度进行加权。空间注意力模块通过计算特征图在空间位置上的相关性，生成一个空间权重图，从而突出特征图中的重要区域。这种结合通道和空间注意力的设计能够更全面地捕捉特征图中的关键信息，显著提升了模型的性能。

自注意力机制（Self-Attention）最早在自然语言处理（NLP）中由[111]提出，随后被引入计算机视觉领域。自注意力机制通过计算特征图内部所有位置之间的相似度及匹配关系，能够捕捉特征信息中的长距离依赖并增强特征的表达能力。自注意力机制首先通过线性变换将输入特征映射为查询（Query）、键（Key）和值（Value）三个向量空间；随后通过计算查询与键之间的点积相似度，生成注意力权重矩阵；最后利用注意力权重对值进行加权求和，得到增强后的特征表示。这种机制能够动态地捕捉特征图中的全局上下文信息，并在图像生成、目标检测等任务中表现出色。

图 4.3 给出了上述常见的空间注意力、通道注意力以及自注意力的计算示意图。如图所示，通道注意力、空间注意力和自注意力机制分别从不同维度增强了特征表示

中国知网　https://www.cnki.net

的能力。通道注意力关注特征通道间的关系，空间注意力关注特征空间位置的重要性，而自注意力则通过全局上下文建模捕捉长距离依赖关系。这些注意力机制的结合与创新为模型设计提供了丰富的工具，显著提升了计算机视觉任务的性能。

近期，受到自注意力机制成功的启发，许多研究[42,112-114]将自注意力架构引入计算机视觉任务，称为视觉变换器（ViTs）。这使得机器学习在许多视觉任务中的表现性能达到了新的高度[42,114-115]。部分研究[116-117]还表明，自注意力模块能够强化相关特征，忽略局部差异，从而提高模型的鲁棒性。

综上所述，向量量化和注意力机制在深度学习中的应用有着重要的地位，前者能够有效去除冗余信息并提升特征表示能力，后者通过动态调整特征的重要性进一步提升模型的表达能力和泛化能力。本章将这两者结合，提出了一个新的方法，通过向量量化去不同质量特征中的冗余信息，并结合自注意力机制进一步增强质量无关的特征表示，从而有效提升低质量图像的识别性能。

4.3 基于向量量化的低质量图像本征表示学习方法

4.3.1 混合低质量数据的本征表示

对于低质量图像识别问题，由于实际应用场景的测试集退化类型未知且复杂，当训练集仅包含单一的清晰图像时模型的泛化性可能较差，鲁棒性低。为了模拟测试数据的潜在不同分布，生成具有多样化退化特征的训练数据集成为了提高低质量图像识别效果的一种有效策略。因此，对于给定一个包含图像 $\boldsymbol{x}$ 及其对应标签 y 的干净数据集 $D=\{(\boldsymbol{x},y)\}$，可以使用多种退化函数模型 $\Phi=\{\varphi_0,\varphi_1,\varphi_2,\ldots,\varphi_n\}$ 生成不同的退化图像用于训练。生成的仿真退化图像可以表示为：

$$\tilde{\boldsymbol{x}}=\varphi_k(\boldsymbol{x}), \tag{4-2}$$

其中，集合 $\boldsymbol{\Phi}$ 中包含恒等映射函数 $x=\varphi_0(x)$，用以保留原始的清晰图像。这些包含清晰与退化的不同质量图像会被输入模型进行训练，增强深度特征的表示能力，以期在多种常见的退化条件下实现良好的泛化性能。

假设图像 $\tilde{\boldsymbol{x}}$ 从主干网络提取的深度特征为 $\tilde{\boldsymbol{z}}$，则训练目标为交叉熵损失函数：

$$L_{ce}=-\log\frac{\exp(H(\tilde{\boldsymbol{z}})_c)}{\sum_c\exp(H(\tilde{\boldsymbol{z}})_c)}, \tag{4-3}$$

其中 $H(\cdot)$ 表示分类头网络，其输出为 logit 向量，c 是特征 $\tilde{\boldsymbol{z}}$ 的类别标签。

如在第 2.2.2 节和第 3.2 节中所述，许多研究表明，特征的退化是低质量图像识别性能下降的主要原因。低质量图像（如模糊、噪声、低分辨率等）会导致特征表示的不完整或失真，从而影响模型对目标类别的判别能力。因此，本章的核心思想是通

中国知网　https://www.cnki.net

过设计一种鲁棒的特征学习框架，使模型能够从低质量图像中提取出与图像质量无关的特征表示，从而提升模型在低质量图像识别任务中的性能。假设图像的质量无关特征向量 $\hat{\boldsymbol{z}}$ 可以通过若干特征（原子）的线性组合来表示：

$$\hat{\boldsymbol{z}} = \sum_{i=0}^{n} \alpha_i \cdot \boldsymbol{e_i} = \alpha_0 \cdot \boldsymbol{e_0} + \alpha_1 \cdot \boldsymbol{e_1} + \cdots + \alpha_n \cdot \boldsymbol{e_n}. \tag{4-4}$$

这种假设基于稀疏表示和字典学习的理论基础，即高维数据可以通过少量基向量的线性组合来有效表示。即，如果这些特征原子构成一个过完备空间 $E \in \mathbb{R}^{n \times d}$，则可以通过 E 进行稀疏表示：

$$\hat{\boldsymbol{\alpha}} = arg\min_{\boldsymbol{\alpha}} ||\boldsymbol{\alpha}||_0, \ \ s.t. \ E \cdot \boldsymbol{\alpha} \approx \hat{\boldsymbol{z}}. \tag{4-5}$$

通过构建一个合适的特征表示空间，模型能够从低质量图像中提取出与高质量图像一致的判别性特征，从而克服图像质量退化带来的负面影响。

对于退化图像，获得的特征可以看作是质量无关 $\hat{\boldsymbol{z}}$ 的噪声版本，即 $\tilde{\boldsymbol{z}} = \hat{\boldsymbol{z}} + \boldsymbol{\epsilon}$，其中 $\boldsymbol{\epsilon}$ 遵循均值为零、标准差为 σ 的高斯分布。这种噪声可能来源于图像采集过程中的模糊、噪声干扰或分辨率下降等因素，导致特征表示偏离真实值。从 $\tilde{\boldsymbol{z}}$ 恢复 $\hat{\boldsymbol{z}}$ 是一个最大后验概率（MAP）问题。为了求解这一问题，可以借助稀疏表示的理论框架，通过以下优化目标来实现：

$$\hat{\boldsymbol{\alpha}} = arg\min_{\boldsymbol{\alpha}} ||\tilde{\boldsymbol{z}} - E \cdot \boldsymbol{\alpha}||_2^2 + \lambda \cdot ||\boldsymbol{\alpha}||_0. \tag{4-6}$$

在这个优化目标中，第一项是重建误差项，旨在使稀疏表示 $E \cdot \boldsymbol{\alpha}$ 尽可能接近观测到的噪声特征。由于噪声特征具有不确定性，而字典中特征原子是固定的，这一项保证了特征的压缩表示，即保留关键特征成分，去除无关变化不定的噪声信息。第二项是稀疏正则化项，用于约束表示系数 $\boldsymbol{\alpha}$ 的稀疏性，即尽可能使用少量的基向量（原子）来表示特征；λ 是正则化系数，用于平衡重建误差和稀疏性之间的权重。通过求解这一优化问题可以得到稀疏表示系数，进而恢复出质量无关的特征。然后，质量无关的特征可以表示为 $\hat{\boldsymbol{z}} = E \cdot \hat{\boldsymbol{\alpha}}$。类似于稀疏表示学习，可以通过构建一个过完备的特征空间和稀疏表示系数，使模型学习到重要的特征，并消除冗余信息。

在公式 (4-6) 中，有两个关键变量需要学习：过完备空间 E（即字典）和稀疏表示系数 $\boldsymbol{\alpha}$。传统的稀疏字典学习方法通常采用交替优化策略，即交替更新字典 E 和系数 $\boldsymbol{\alpha}$。然而，这种方法在计算上较为复杂，尤其是在深度神经网络中，难以实现端到端的训练。为了克服这一挑战，本文受到离散向量量化（Vector Quantization, VQ）的启发，提出了一种简化的优化策略，即可以将系数 $\boldsymbol{\alpha}$ 直接设为一个独热编码的 one-hot 向量。这种设定使得公式 (4-6) 中的稀疏正则化项 $||\boldsymbol{\alpha}||_0$ 变为常数，从而简化了优化

中国知网 https://www.cnki.net

问题。尽管这种操作可能会导致特征向量的一些信息失真，但可以通过后续的改进（如第 4.3.2 节中所述）来缓解这一问题。通过将 $E \cdot \boldsymbol{\alpha}$ 替换为 $\hat{\boldsymbol{z}}$，公式 (4-6) 可以简化为 $min||\tilde{\boldsymbol{z}} - \hat{\boldsymbol{z}}||_2^2$，即最小化噪声特征 $\tilde{\boldsymbol{z}}$ 与质量无关特征 $\hat{\boldsymbol{z}}$ 之间的重建误差。这一优化目标与 VQ-VAE[98]中的向量量化损失函数形式相同。

VQ-VAE 通过引入一个称为码本（Codebook）的参数化模块来学习离散表示空间。码本由一组可学习的向量组成，每个向量代表离散特征空间中的一个点。VQ-VAE 的向量量化损失函数定义如下：

$$L_{vq} = ||\hat{\boldsymbol{z}} - sg(\tilde{\boldsymbol{z}})||_2^2, \tag{4-7}$$

其中 $sg(\cdot)$ 表示停止梯度操作，$\hat{\boldsymbol{z}}$ 是量化后的向量，即码本中与输入特征最接近的向量。通过最小化这一损失函数，码本能够逐渐学习到输入数据的离散表示空间。

本章方法将公式 (4-7) 和公式 (4-1) 结合作为训练目标，从而实现了基于深度神经网络的端到端码本学习。具体地，本章方法首先在识别模型中引入码本模块，并利用大量包含清晰图像和退化图像的增强数据进行联合训练，使模型能够学习到与图像质量无关的、具有判别性的特征表示。

本章使用方法的优势在于：（1）通过将稀疏表示系数 $\boldsymbol{\alpha}$ 设为 one-hot 向量，简化了优化过程，避免了传统稀疏字典学习中复杂的交替优化过程，使模型能够通过梯度下降法进行端到端训练；（2）码本模块通过学习离散表示空间，能够有效去除噪声和冗余信息，从而提升特征表示的鲁棒性；（3）无需成对数据输入，通过联合训练清晰图像和退化图像，模型能够更好地适应图像质量的变化，从而在实际应用中表现出更强的实用性和泛化能力。

4.3.2 量化特征融合及判别性增强

在标准的向量量化中，通常会将输入特征 $\tilde{\boldsymbol{z}}$ 直接替换为量化后的向量 $\hat{\boldsymbol{z}}$，并将其输入到后续网络中进行进一步处理。这种直接替换的操作虽然简单高效，但也存在明显的局限性。然而，如公式 (4-1) 和第 4.3.1 节所示，向量量化通过独热编码（One-hot Encoding）的方式选择码本空间中最接近的向量。与稀疏表示选择多个基向量的线性组合不同，这种只取单一码本向量的硬性选择机制不可避免地会导致一些有用信息的丢失。由于 one-hot 编码的离散性，量化过程会忽略输入特征中与码本向量不完全匹配的细节信息，而这些信息可能对后续任务（如图像识别）有一定的贡献。例如，输入特征 $\tilde{\boldsymbol{z}}$ 中未被量化向量完全捕捉的细微纹理或局部结构信息，可能在识别任务中起到关键作用。因此，直接替换操作虽然简化了量化过程，但也可能削弱特征表示的完整性和判别能力。

使用量化的特征直接进行识别的初步实验结果也表明，尽管量化后的向量 $\hat{\boldsymbol{z}}$ 包

中国知网　https://www.cnki.net

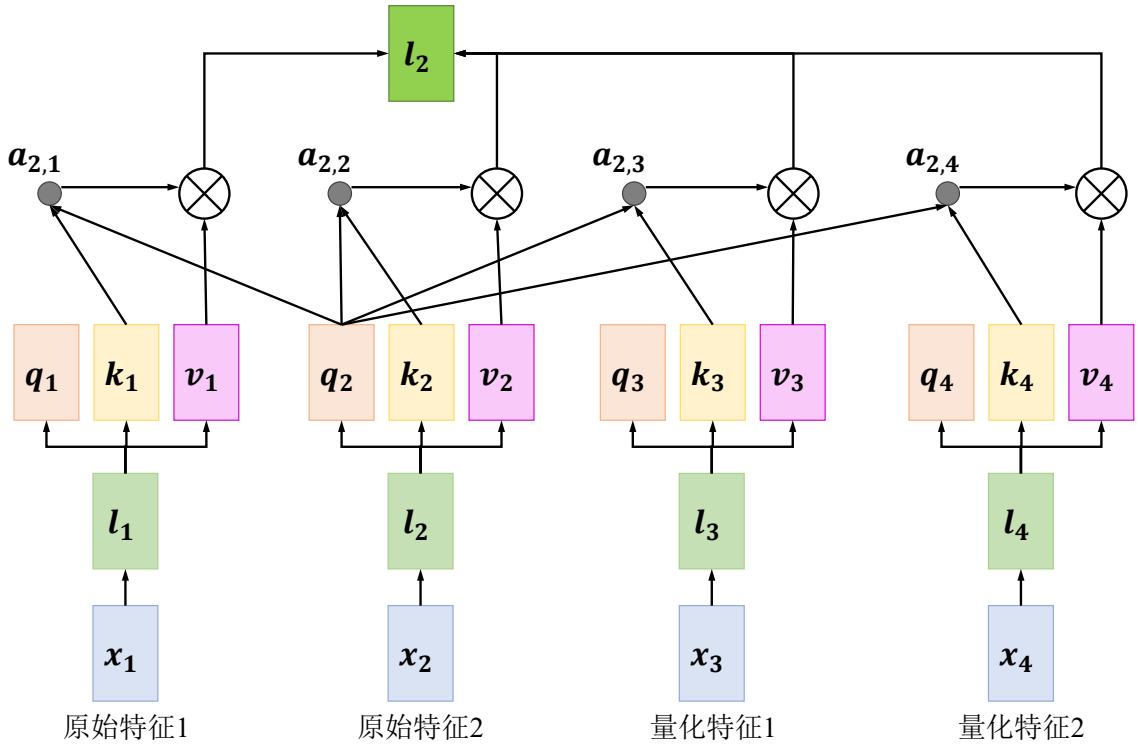


图 4.4 特征拼接及自注意力机制特征融合模块示意图

含了与图像质量无关的判别性特征，但其性能提升仍然有限。其主要原因可能是独热编码的离散性使得量化过程过于严格，导致部分连续特征信息丢失；直接替换可能完全丢弃原始特征中的细节信息，而这些信息在某些情况下可能对识别任务有帮助；在训练初期，码本可能尚未完全学习到输入数据的分布特性，导致量化结果不够准确。

基于上述分析，本节提出将原始输入特征 $\tilde{z}$ 与量化后的向量 $\hat{z}$ 进行融合，以补充量化过程中丢失的信息，并进一步提升特征表示的效果。即将 $\tilde{z}$ 和 $\hat{z}$ 在特征维度上进行拼接，构建一个更丰富的特征表示。这种融合策略通过保留原始特征 $\tilde{z}$，可以避免量化过程中丢失的细节信息，从而增强特征的表达能力。并且，由于量化向量 $\hat{z}$ 提供了与图像质量无关的鲁棒特征，而原始特征 z 则包含了更多的细节信息，二者的结合能够显著提升特征的多样性和判别性。另外，在码本训练不充分的训练初期，原始特征 z 可以作为量化向量 $\hat{z}$ 的有效补充，从而提升训练过程的稳定性。第 4.4.2 节中精心设计了多个关于特征融合的对比消融实验，包含将特征直接替换，相加及拼接等融合方法，依据实验结果最终选择将量化向量 $\hat{z}$ 与原始特征 z 进行拼接。实验结果也表明，这种融合策略能够显著提升模型在低质量图像识别任务中的性能，同时增强特征表示的鲁棒性和判别性。

如第 4.3.1 节所述，在低质量图像识别任务中，模型需要更多地关注图像中目标本身的特征，同时忽略背景及其他无关信息。为了进一步增强提取的与质量无关的特

中国知网 https://www.cnki.net

征表示，上述拼接后的特征 $concat(\hat{\boldsymbol{z}}, \boldsymbol{z})$ 被输入到一个自注意力模块中。自注意力机制通过动态建模特征内部的关系，能够捕捉长距离依赖并增强关键特征的表达能力。具体实现中，如图 4.4 所示，本章方法使用三个独立的多层感知机（MLP）网络从拼接特征中分别学习查询（Query, $\boldsymbol{q}$）、键（Key, $\boldsymbol{k}$）和值（Value, $\boldsymbol{v}$）特征。即将拼接的特征映射到不同的特征空间，从而为自注意力计算提供多样化的表示。随后，通过计算查询 $\boldsymbol{q}$ 与键 $\boldsymbol{k}$ 之间的相似度，并经过 Softmax 函数归一化，生成注意力权重矩阵。该权重矩阵用于对值 $\boldsymbol{v}$ 进行加权求和，得到自注意力模块的输出 $\boldsymbol{z_{sa}}$，其数学表达公式为：

$$\boldsymbol{z_{sa}} = softmax(\boldsymbol{k} \cdot \boldsymbol{q}^T / \sqrt{2}) \cdot \boldsymbol{v}. \tag{4-8}$$

自注意力模块能够自适应地聚焦于与识别任务相关的关键特征，同时抑制背景及其他无关信息的干扰。这种机制不仅改善了第 4.3.1 节中描述的与质量无关的特征表示，还进一步增强了特征的判别能力。通过全局上下文建模，自注意力模块能够捕捉目标特征之间的长距离依赖关系，从而弥补向量量化过程中可能丢失的细节信息。最终，经过自注意力增强的特征 $\boldsymbol{z_{sa}}$ 被输入分类器网络，生成最终的分类结果。

4.3.3 整体网络框架及损失函数

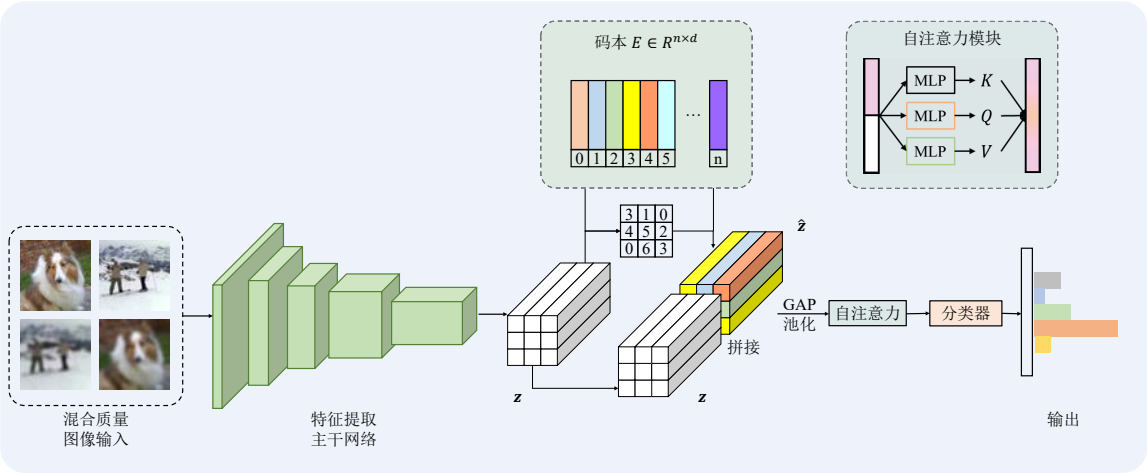


图 4.5　基于向量量化的图像质量无关的特征表示学习方法框架

整体网络框架：本方法的整体结构如图 4.5 所示。模型的批量输入包括清晰图像和通过仿真生成的退化图像构成非成对的混合质量图像输入，用于增加训练数据的多样性。退化图像通过第 4.3.1 节中描述的公式 (4-2) 生成，该公式通过退化模型模拟了多种常见的图像退化类型（如模糊、噪声和低分辨率等），从而确保模型能够适应实际场景中的复杂退化情况。

在特征提取阶段，输入图像首先通过一个预训练的骨干网络（如 ResNet 或 Trans-

中国知网　https://www.cnki.net

former）提取高维特征 $\tilde{\boldsymbol{z}}$。随后，计算特征 $\tilde{\boldsymbol{z}}$ 与码本中所有向量之间的相似度，并选择最相似的码本向量作为量化特征 $\hat{\boldsymbol{z}}$。这一向量量化过程可以通过公式 (4-1) 表示，其核心思想是将连续特征空间离散化为有限的码本空间，从而去除冗余信息并增强特征的鲁棒性。随后，本章采取将原始特征 $\tilde{\boldsymbol{z}}$ 与量化后所得特征 $\hat{\boldsymbol{z}}$ 拼接，通过全局平均池化（Global Average Pooling，GAP）转换为向量，然后输入到自注意力模块中，进行质量无关的判别性特征表示的进一步自适应增强。输出特征可通过公式 (4-8)获得。最后，融合增强后的特征表示通过全连接层分类器得到最终的分类结果。

损失函数设计：在模型的训练过程中，损失函数设计方面，为了优化码本模块中的参数，使用公式 (4-7) 定义的向量量化损失函数，该损失函数通过最小化输入特征 $\tilde{\boldsymbol{z}}$ 与量化特征 $\hat{\boldsymbol{z}}$ 之间的差异，驱动码本向量逐渐逼近输入特征的分布。除了公式 (4-7) 中定义的向量量化损失（VQ 损失）外，标准的 VQ-VAE 向量量化框架还引入了一个编码约束损失（Commitment Loss），作为对编码器（即主干网络）的参数优化进行额外约束。编码约束损失的定义如下：

$$L_{cmt} = ||\tilde{\boldsymbol{z}} - sg(\hat{\boldsymbol{z}})||_2^2. \tag{4-9}$$

该损失函数通过最小化骨干网络输出的特征 $\tilde{\boldsymbol{z}}$ 与量化特征 $\hat{\boldsymbol{z}}$ 之间的差异，确保骨干网络的输出与码本嵌入空间保持一致。编码约束损失的作用主要体现在以下两个方面：在训练过程中，编码约束损失能够防止主干网络输出的特征 $\tilde{\boldsymbol{z}}$ 与码本向量之间的差异过大，从而避免模型陷入局部最优解或坍塌到无效状态；通过约束主干网络的输出特征 $\tilde{\boldsymbol{z}}$ 尽可能接近量化特征 $\hat{\boldsymbol{z}}$，编码约束损失能够确保特征表示在码本嵌入空间中的一致性，从而提升特征表示的稳定性和鲁棒性。

综上所述，本章方法的整体训练目标由三项损失函数组成，分别是公式(4-3)、(4-7)和 (4-9) 中的交叉熵损失、量化损失和约束损失。总损失函数可以表示为：

$$L_{total} = L_{vq} + \beta \cdot L_{cmt} + \lambda \cdot L_{ce}, \tag{4-10}$$

其中 β 是约束损失的权重，可以根据 VQ-VAE[98]中的原始设置将 β 设为 0.25，λ 是平衡损失的权重，本章算法通过实验结果经验性地将其设置为 1。模型使用总损失函数进行端到端训练。

通过上述设计，模型无需依赖成对图像即可从由清晰图像和退化图像组成的多种混合质量图像中学习到与图像质量无关的判别性特征表示。具体地，模型通过将清晰图像和退化图像的特征映射到统一的离散空间，并在这一过程中通过压缩量化表示消除特征中的冗余信息，随后使用分类识别损失函数捕捉关键的判别性特征。这使得模型能够学习到一种质量无关的特征表示，能够适应不同质量的图像，显著提升其在低质量图像上的识别能力和鲁棒性。

中国知网 https://www.cnki.net

4.4 实验结果

为了验证本章所提出算法的性能，除了在低质量图像的测试集上进行实验外，本节还通过引入多个分布外数据集进行广泛的测试。此外，为了更深入地理解算法的工作机制和表现，本节还对一系列特征结果进行了可视化展示。这些可视化结果将有助于进一步揭示算法在不同场景下的泛化能力及其对低质量图像的处理效果。具体的实验结果将在后续部分详细展开。

4.4.1 实验设置

数据集和评价指标：ImageNet-C 基准数据集[24]包含 5 个大类、19 种细分退化类型的退化模型，用于构建仿真退化图像的测试集。这 5 个大类包括噪声、模糊、天气、数字退化以及其他退化类型。具体的 19 种细分退化类型分别为：高斯噪声、散粒噪声、脉冲噪声；散焦模糊、毛玻璃模糊、运动模糊、变焦模糊；雪、霜、雾、亮度变化；对比度变化、弹性形变、块像素化、JPEG 压缩失真；斑点噪声、高斯模糊、溅射效应、饱和度变化等。每种退化类型还依据退化权重参数设置了 1 到 5 级的退化严重程度，其中 5 级表示最严重的退化。本章方法还在分布偏移验证集 ImageNet-R[36]和对抗扰动数据集 ImageNet-A[37]上了测试。ImageNet-R 包含素描、艺术、绘画、玩具等风格共计 200 类的图像，而 ImageNet-A 提供了 ImageNet 的对抗攻击扰动的样本。

如第 2.3 节所述，对于 ImageNet-C 数据集，平均退化错误率（mCE）是该低质量图像分类的度量标准，可以通过以下公式计算：

$$mCE = \frac{1}{15}\sum_{c=1}^{15}\frac{\sum_{s=1}^{5} Err_{c,s}}{\sum_{s=1}^{5} Err_{c,s}^{AlexNet}}, \tag{4-11}$$

其中 c 表示退化类型的索引，s 表示严重度级别。注意，错误值是通过与同一验证集上的基础 AlexNet 模型的错误值进行归一化得到的。对于分布外数据集 ImageNet-R 和 ImageNet-A，本节报告模型的精确度指标作为性能评估依据。

训练设置：在本方法中，ResNet-50[60]和 ResNeXt-101[84]被选为骨干网络，这两种网络结构在图像识别任务中表现出色，能够有效提取多层次的特征表示。ResNet-50 通过残差连接缓解了深层网络的梯度消失问题，而 ResNeXt-101 则通过分组卷积进一步提升了特征的多样性和表达能力。对于码本 $E \in R^{n\times d}$，参数设置为 $n = 10000$ 和 $d = 2048$，其中 n 表示码本中向量的数量，d 表示每个向量的维度。这种设置能够在保证码本表达能力的同时，避免过高的计算复杂度。

在优化策略方面，采用 Adam 优化器[85]，其初始学习率设置为 0.001。Adam 优化器结合了动量法和自适应学习率的优点，能够在训练初期快速收敛，并在后期保持稳定性。为了进一步提升训练效果，使用余弦退火（cosine annealing）函数作为学习

中国知网　https://www.cnki.net

率调整策略。余弦退火策略通过周期性地调整学习率，能够有效避免模型陷入局部最优解，并加速收敛过程。

实验配置中，批量大小设置为 512，以充分利用硬件资源并提升训练效率。训练过程在 4 块 Nvidia GeForce RTX 3090 显卡上进行，这些显卡的高计算性能和显存容量能够支持大规模数据的并行处理。需要注意的是，本节中对比方法的部分结果是根据其原始论文复现的，以确保实验结果的公平性和可比性。

4.4.2 消融实验及复杂度分析

首先，本节通过一系列消融实验对本方法中各模块对低质量图像识别性能的影响进行验证分析。实验将本章所提出的方法模块分为三个主要部分：码本模块、特征融合模式和自注意力模块。其中，未使用码本的实验设置是通过生成的退化数据对基础模型进行微调，作为对比的基线模型。在特征融合模式中，测试了三种不同策略：（1）“replace”模式，即直接用量化后的特征向量替换原始特征向量，这是标准向量量化的典型做法；（2）“add”模式，将量化特征与原始特征相加；（3）“concat”模式，将量化特征与原始特征在通道维度上进行拼接，这也是本方法最终采用的融合策略。

实验结果如表 4.1 所示，其中“clean”和“mCE”分别表示模型在清晰图像和退化图像上的 top-1 准确率及平均分类误差（mCE）。从实验结果可以看出，“concat 拼接”模式在各项指标上均优于其他特征融合策略。这一现象可能归因于拼接操作能够最大限度地保留原始特征中的细节信息，同时引入量化特征的鲁棒性，从而实现特征信息的互补。相比之下，“replace 替换”模式由于完全丢弃了原始特征，可能导致关键信息的丢失；而“add 相加”模式则可能因特征值的简单叠加而造成信息混淆，影响特征的判别能力。此外，实验结果还表明，码本模块和自注意力模块的引入均对性能提升有显著贡献，验证了各模块设计的有效性。

表 4.1 本章方法各模块对模型低质图像的识别性能影响

是否包含码本	特征融合模式	自注意力模块	clean 精确度↑	错误率 mCE↓
✗	-	-	73.1	53.7
✓	replace 替换	✗	74.3	50.1
✓	add 相加	✗	74.7	48.9
✓	concat 拼接	✗	76.2	45.7
✓	concat 拼接	✓	**76.6**	**43.1**

为了进一步评估本方法的计算效率，验证方法的实用性，实验还统计了训练过程中的参数量和浮点运算量（FLOPS）。由于本方法采用即插即用的设计，新增的计算开销主要来自码本模块和自注意力模块。如表 4.2 所示，与基础模型及对比方法

中国知网 https://www.cnki.net

表 4.2　本章方法与其他方法的参数量和计算效率对比

方法	平均错误率 mCE ↓	参数量 #Params.	计算量 #FLOPS
Baseline[60]	53.7	$\mathbf{2.5 \times 10^7}$	**4.11G**
QualNet[15]	50.3	1.2×10^8	14.46G
本章方法	**43.1**	5.8×10^7	4.13G

表 4.3　码本大小及对应参数量对模型性能的影响

码本大小 n	参数量 #Params.	清晰图像精确度 clean ↑	退化图像平均错误率 mCE ↓
$n = 1k$	4.0×10^7	76.1	45.7
$n = 10k$	5.8×10^7	76.6	43.1
$n = 100k$	2.4×10^8	76.6	42.9

QualNet 相比，本方法引入的额外参数量和 FLOPS 处于可接受范围内，在显著提升性能的同时保持了较高的计算效率。此外，实验还对码本大小 n 的设置进行了深入研究，相关分析结果详见表 4.3 内容。为平衡参数量与计算开销，本节最终选取码本大小为 $E \in R^{10000 \times 2048}$。这些实验结果表明，本方法在性能与效率之间取得了良好的平衡，为低质量图像识别任务提供了一种有效的解决方案。

4.4.3 鲁棒性分类的实验结果

在本节中，对提出的方法与其他最先进的方法进行了比较，以验证模型在低质量图像识别中的有效性。选取了几种近期的相关方法，如 DDP[14]、URIE[6]和 QualNet[15]，以及前一章所述的不确定性特征蒸馏方法，并确保实验训练设置与这些方法一致。通过在两种主干网络架构（ResNet-50 和 ResNeXt-101）上测试准确率（越高越好）和平均退化错误率（mCE，越低越好），评估了模型在 ImageNet-C 验证集上的表现。

表 4.4　ImageNet-C 数据集不同测试集上各方法整体性能对比

方法	主干网络	清晰图像	已知退化	未知退化	平均退化错误率 mCE ↓
基线模型[60]	ResNet50	76.1	39.1	46.7	76.7
DDP[14]		72.1	48.2	50.7	62.8
URIE[6]		73.8	55.1	56.5	55.7
QualNet[15]		75.4	61.1	58.1	50.3
不确定性蒸馏		76.2	63.4	62.9	46.4
本章方法		**76.6**	**65.6**	**63.9**	**43.1**
基线模型[60]	ResNeXt101	79.6	47.1	55.5	69.7
QualNet[15]		77.8	65.5	63.3	42.6
不确定性蒸馏		79.0	69.2	67.8	39.5
本章方法		**80.3**	**69.6**	**68.5**	**37.9**

如表 4.4 所示，“清晰图像”、“已知退化”和“未知退化”分别表示在清晰图像、

中国知网　https://www.cnki.net

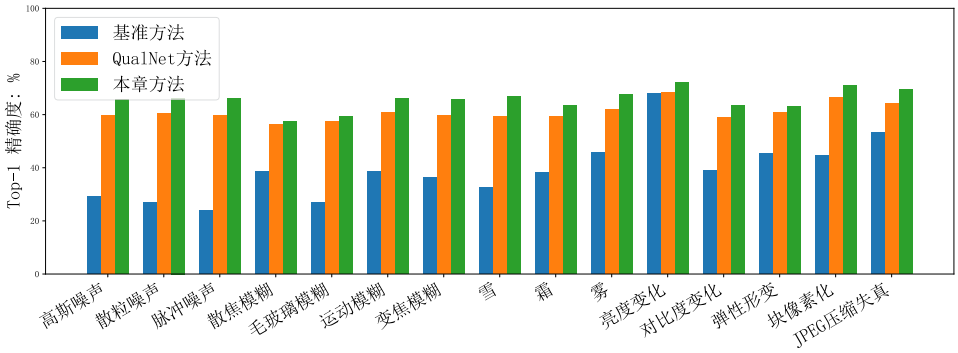


图 4.6 ImageNet-C 基准数据集上每种损坏类型的不同方法的详细前 1 准确度结果

训练过程中已知的 15 种退化类型图像以及 4 种未知退化类型图像上的平均 top-1 准确率。“mCE”（平均退化错误率）已按照第 4.4.1 节开头描述的方法进行了归一化处理。15 种退化类型的详细 top-1 准确率如图 4.6 所示。实验结果表明，本方法不仅在低质量图像上表现优异，同时还提升了清晰图像的识别准确率，进一步验证了本方法的有效性和鲁棒性。

实验结果表明，所提出方法在低质量图像识别任务中展现出显著优势，不仅在已知退化类型上取得了稳定的识别性能，还在未知退化类型上表现出较强的泛化能力。此外，该方法在清晰图像上的准确率同样有所提升，进一步证明了其在提取判别性特征时的有效性。这些结果充分验证了所提出方法在复杂退化环境中的鲁棒性，并表明其能够在各种图像质量下提取目标的关键判别性特征。

4.4.4 鲁棒性分析

本节对所提出方法的鲁棒性进行测试。首先，模型在训练过程中未见过的 4 种 ImageNet-C[24]退化类型（斑点噪声、高斯模糊、溅射和饱和度）上直接进行测试。这些退化类型模拟了实际场景中可能出现的复杂图像退化情况，能够有效评估模型对未知退化类型的泛化能力。所有对比方法均采用与本方法相同的训练设置，以确保实验的公平性。通过表 4.5 中的结果可以看出，所提出方法在低质量图像上的识别准确率显著优于其他方法。本方法在斑点噪声和饱和度等退化类型上表现尤为突出，这主要归功于向量量化模块和自注意力机制的联合优化，使得模型能够更好地捕捉与图像质量无关的判别性特征。此外，本方法在高斯模糊和溅射退化类型上也展现了较强的鲁棒性，进一步验证了其在处理多样化退化场景中的有效性。实验结果表明，所提出方法不仅能够有效应对已知退化类型，还能在未知退化类型上保持较高的识别性能，为低质量图像识别任务提供了一种可靠的解决方案。

为了进一步验证所提出方法的鲁棒性，实验还在 ImageNet-R[36]和 ImageNet-A[37]两个基准数据集上展开。ImageNet-R 数据集包含多种艺术风格的图像（如素描、玩具

中国知网 https://www.cnki.net

表 4.5　ImageNet-C 中 4 种未知退化测试集上的各方法性能对比

方法	斑点噪声	高斯模糊	溅射效应	饱和度变化
基线模型[60]	35.5	49.2	41.9	60.2
AugMix[18]	50.6	47.2	53.3	61.5
ANT[118]	58.1	43.1	52.4	61.3
DeepAugment[36]	61.1	52.1	53.8	61.5
QualNet[15]	63.5	52.6	54.6	61.7
不确定性蒸馏	66.4	58.6	58.6	67.9
本章方法	**68.4**	**59.1**	**59.3**	**68.8**

表 4.6　本章方法与数据增广算法的结合性能对比

方法	清晰图像	ImageNet-C ↓	ImageNet-A	ImageNet-R
基线模型[60]	76.1	76.7	0.0	36.2
+ 本章方法	**76.6**	**71.1**	**3.7**	**38.6**
DeepAugment[36]	76.6	60.4	3.5	42.2
+ AugMix[18]	75.8	53.5	3.9	46.8
+ DAT[23]	77.1	50.8	**6.8**	47.8
DAu+AM+ 本章方法	**77.4**	**48.7**	5.9	**49.3**

和绘画），主要用于评估模型在分布偏移数据上的泛化能力；ImageNet-A 则通过生成 ImageNet 验证集的对抗样本来测试模型的鲁棒性。得益于所提出方法的即插即用特性，本实验将其与其他方法结合，以验证其是否能够进一步提升性能。值得注意的是，在这一部分的实验中，仅采用与基准模型相同的增广训练策略，**未使用任何退化图像进行额外训练**。实验结果如表 4.6 所示，表明在结合所提出方法后，模型在分布转移数据上的性能显著提升。尽管所提出方法在 ImageNet-A 上的表现略低于 DAT[23]，但 DAT 采用了对抗训练策略，而所提出方法并未引入额外的对抗训练机制，相较之下结果仍然具有一定的竞争性。

综上所述，通过在多种未知退化类型、分布偏移数据以及对抗样本上的测试，全面验证了所提出方法在低质量图像识别任务中的鲁棒性和泛化能力。实验结果表明，该方法不仅能够在训练过程中未见过的退化类型上保持较高的识别性能，还能有效适应风格变化显著的数据集，进一步提升模型在复杂现实场景中的适用性。此外，与现有方法相比，所提出方法在无需额外对抗训练的情况下，即可在 ImageNet-A 等具有挑战性的对抗样本上展现出竞争性性能，表明其在增强模型稳健性方面的潜力。总体而言，本方法通过优化特征提取和表示学习，使得模型能够更好地捕捉图像内容的关键信息，而不受退化因素的干扰，为低质量图像识别提供了一种有效且通用的解决方案。

中国知网　https://www.cnki.net

4.4.5 本质特征的可视化分析

本节通过多种可视化分析方法，系统地验证了所提出方法能够有效学习到与图像质量无关的特征表示，并展示了其在低质量图像识别任务中的优势。

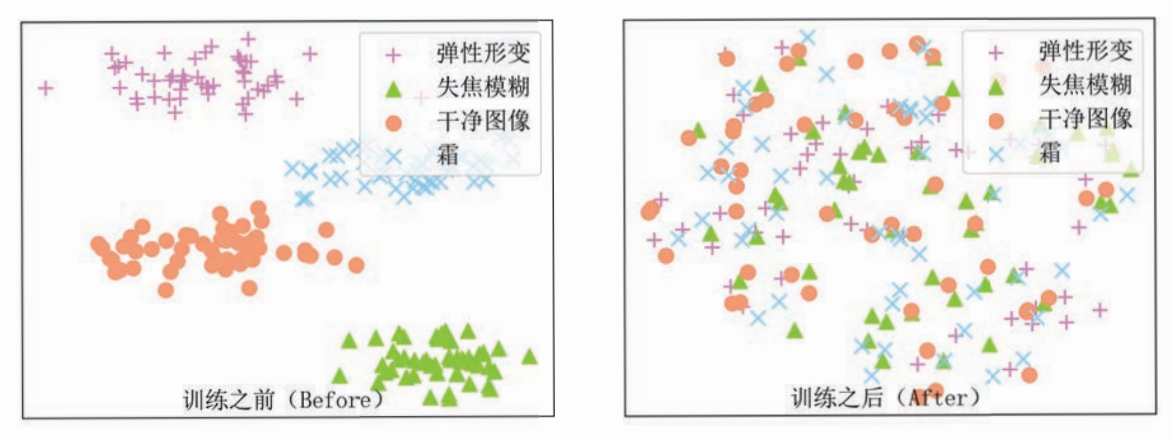


图 4.7　同一类图像不同退化种类的特征分布图

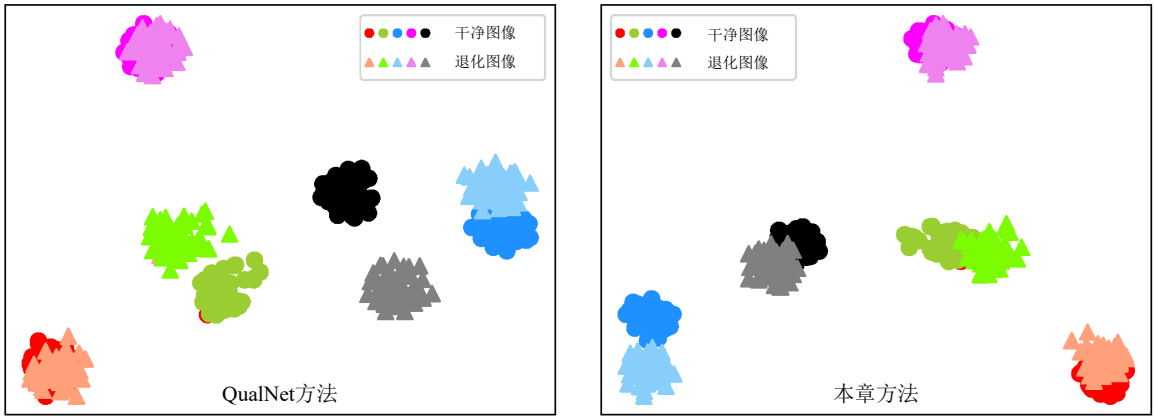


图 4.8　不同类图像的清晰-退化特征分布示意图

首先，采用 t-SNE[57]对特征分布进行可视化分析，结果分别展示在图 4.7 和图 4.8 中。在图 4.7 中，“模型训练前”是指未使用本章方法训练的基线模型。如图所示，尽管特征是从同一类别的图像中提取的，在不同的退化影响下，其分布较为分散，这种分散性可能导致多数样本处于分类边界外，使得低质量图像识别性能下降。“模型训练后”特征分布图所示，通过本章所提出方法，尽管受各种图像退化影响，特征分布仍然能够较为集中，表明模型能够更好地捕捉与类别相关的判别性特征，而不是与图像质量、退化种类相关的特征。图 4.8 进一步展示了所提出方法相较于 QualNet 方法的优势：无论输入图像是清晰的还是退化的，来自同一类别的特征在嵌入空间中均表现出更好的聚集性。这些结果表明，所提出的方法能够有效地提取与图像质量无关的特征表示。

中国知网　https://www.cnki.net

此外，通过 Grad-CAM[119-120]对模型的关注区域进行可视化分析。图 4.9 和图 4.10 展示了 ImageNet-C 测试集中的部分图像，图 4.11 则展示了真实场景中采集的模糊退化图像。从图中可以看出，与其他方法相比，所提出方法的类别激活区域能够更准确地聚焦于与类别相关的关键区域，而较少受到低质量图像中噪声或退化区域的干扰。这一定性结果进一步验证了所提出方法在提取质量无关特征方面的有效性，并表明其在面对常见退化类型时具有更强的鲁棒性。

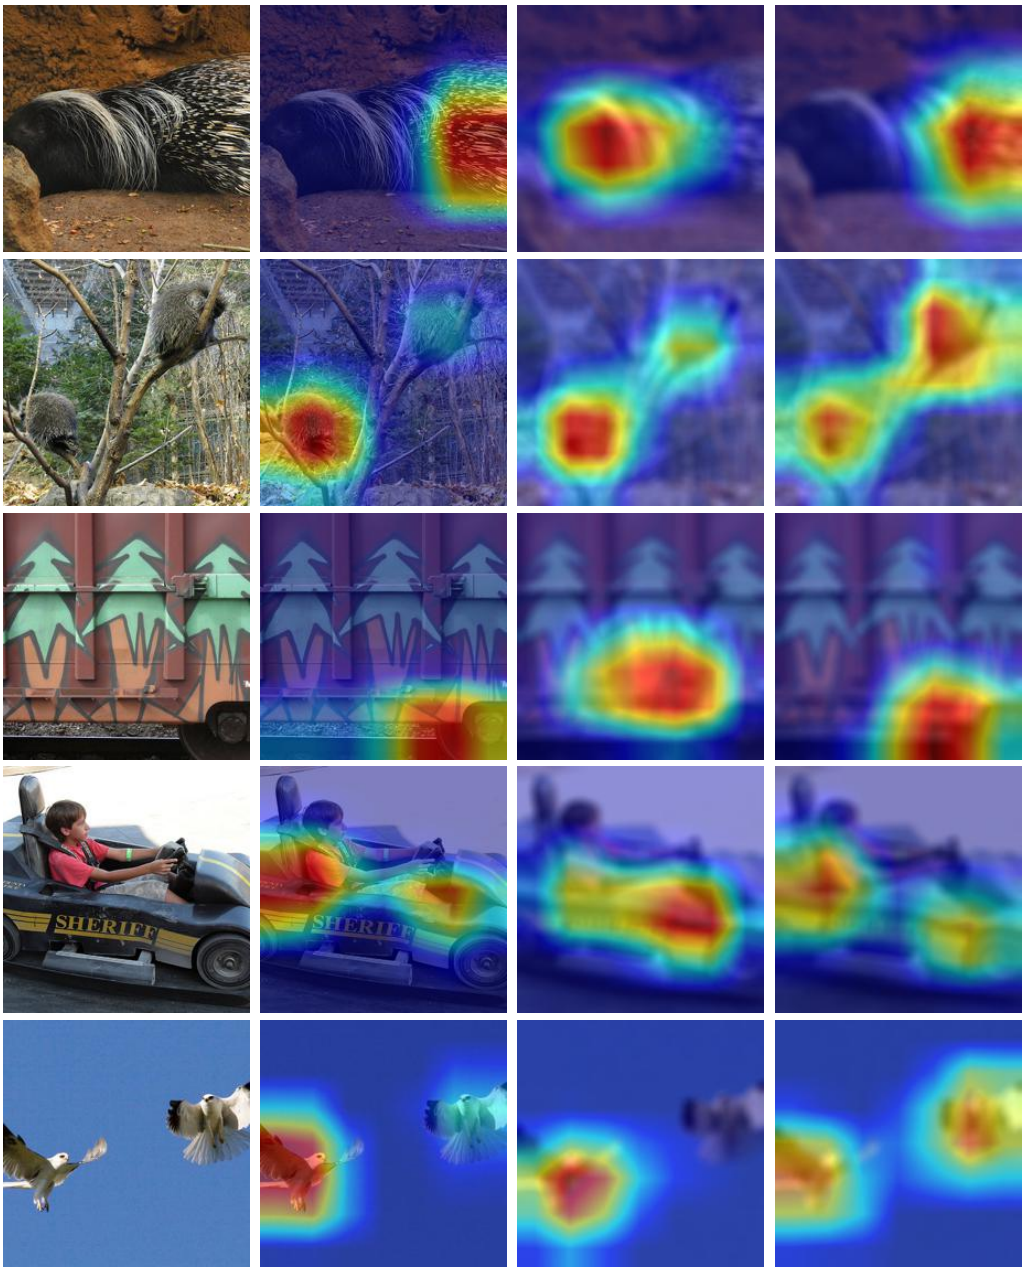


图 4.9　不同方法的类别激活图对比示例

中国知网　https://www.cnki.net

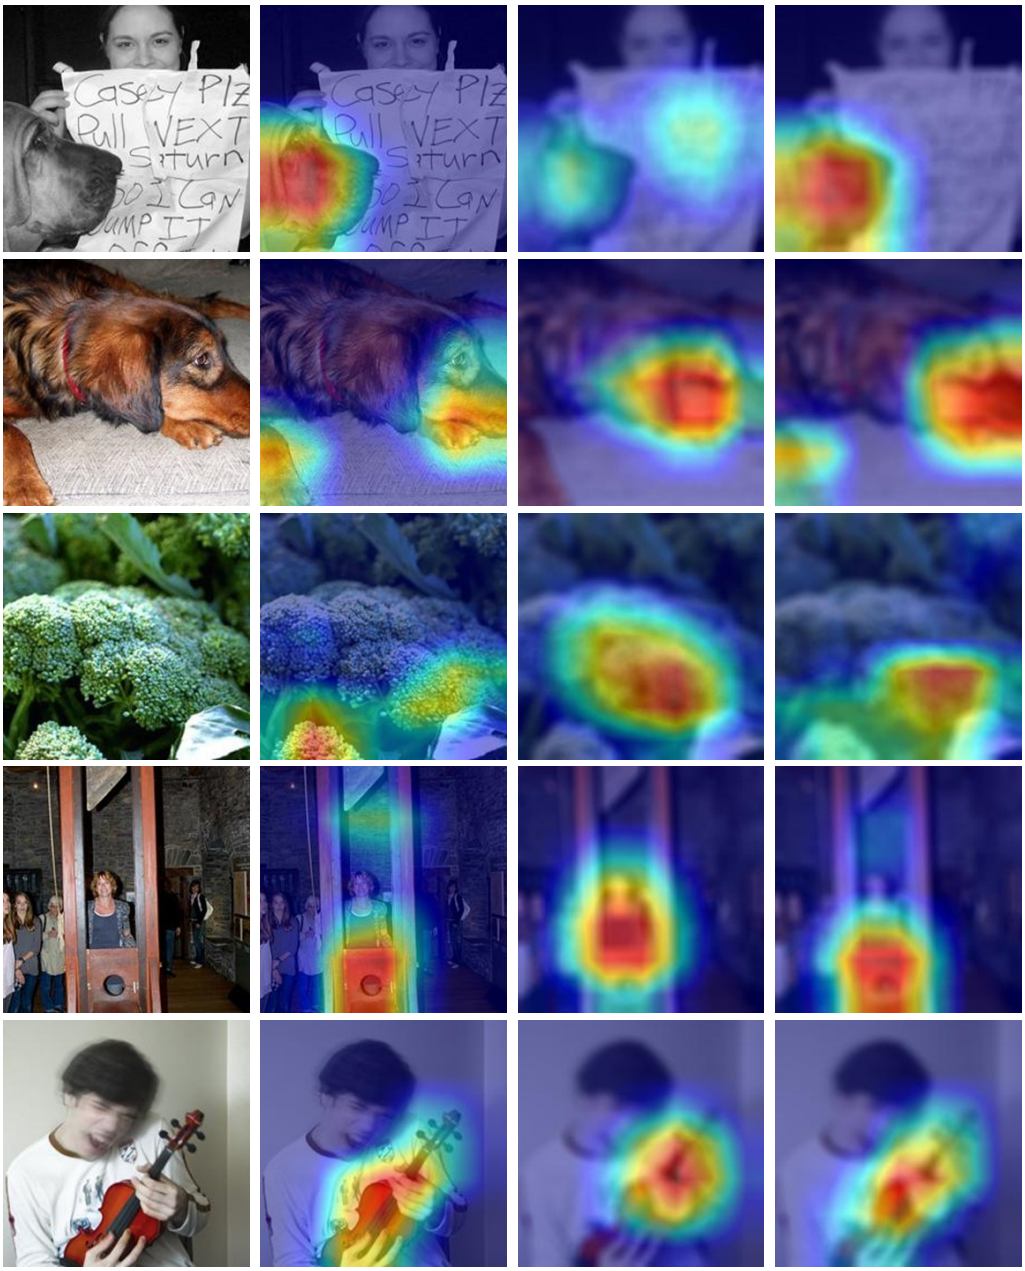


图 4.10 不同方法的类别激活图对比示例（续）

中国知网 https://www.cnki.net

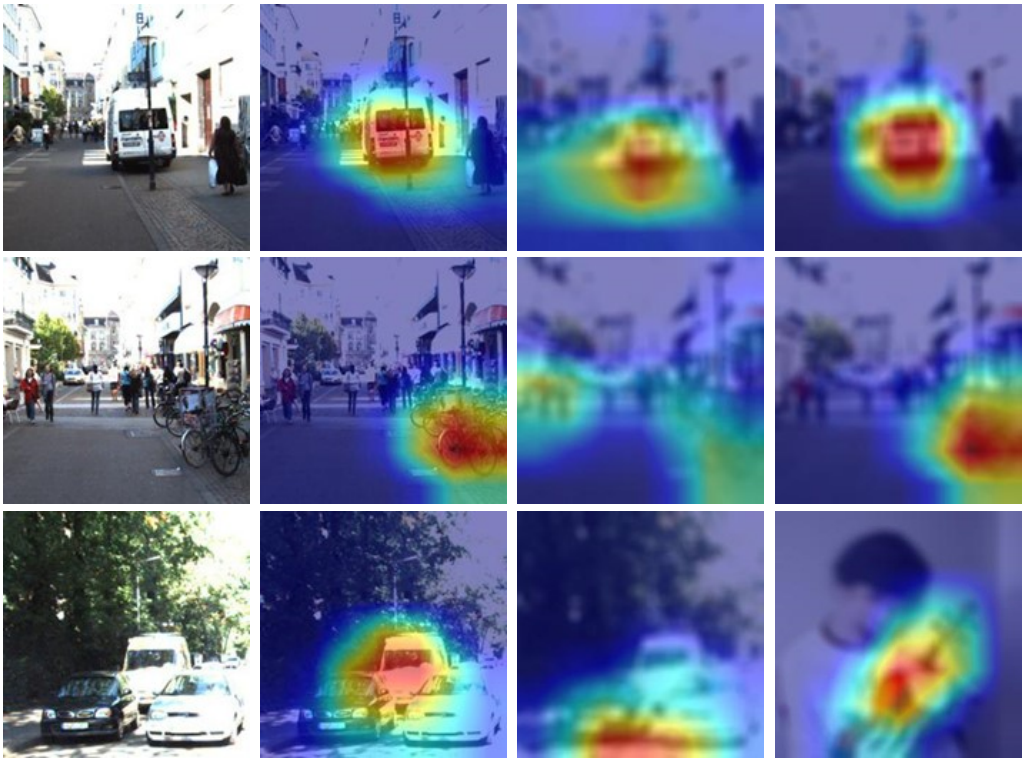


图 4.11　真实场景对应模糊图像类别激活图对比示例

综上所述，可视化分析结果从特征分布和关注区域两个角度，全面验证了所提出方法在提取与图像质量无关的特征表示方面的有效性。具体而言，特征分布分析表明，所提出方法能够在不同质量的图像输入下保持较为稳定的特征空间映射，使同类别样本在特征空间中更加紧凑，同时增强类间区分度，降低由图像质量变化引起的特征偏移。此外，关注区域的可视化进一步证明了该方法能够有效捕捉关键目标区域，而非受到低质量因素（如噪声、模糊或对比度变化）的干扰，从而提升模型的判别能力。这些结果不仅展示了所提出方法在低质量图像识别任务中的优势，还进一步表明，该方法能够在复杂真实场景中保持较强的鲁棒性，并具有良好的泛化能力，为低质量图像下的目标识别提供了可靠的技术支持。

4.5 本章小结

本章提出了一种基于向量量化离散表示学习和自注意力机制的即插即用方法，用于低质量图像识别。与传统的基于特征蒸馏的方法不同，本章的方法受压缩编码稀疏表示的启发，采用离散向量量化（VQ）将清晰图像和多种退化图像的特征映射到同一离散空间，通过压缩表示和去除冗余信息，从而提取质量无关的特征，显著提升了模型的鲁棒性。为了进一步增强特征表示能力，避免硬量化丢失部分信息对特征学习

中国知网　https://www.cnki.net

造成影响，本章提出了一种拼接量化特征与原始特征的策略，并结合自注意力模块进行融合，这一方法能够进一步加强模型对关键信息的提取。通过在多个实验设置下的验证，实验结果表明本方法展示了显著的优越性。尽管基于 VQ 的方案取得了理想的实验结果，但简单地选择与输入特征向量最相似的码本项进行量化的策略是否最优，仍值得进一步探讨。虽然本方法曾尝试选择多个最相似的项（例如，top-k 相似项），但并未显著改进模型性能效果。因此，基于 VQ 的质量无关表示学习优化仍是一个值得深入研究的方向。此外，在量化过程中，为获得图像数据的本征表示，通常需要引入多种仿真退化数据进行训练，以增强模型对不同质量图像的适应能力。然而，这一策略也存在一定局限性。一方面，仿真退化难以完全覆盖真实场景中复杂多变的图像退化模式，导致模型在面对未见退化类型时泛化能力不足；另一方面，大量仿真数据的生成与训练不仅增加了计算成本，也降低了算法在实际部署中的灵活性与效率。因此，过度依赖仿真退化数据在一定程度上制约了本征表示学习方法的广泛适用性和实用价值。在本文接下来的内容中，将更深入地探讨分布外数据的特性，重点分析其在低质量图像识别任务中对模型鲁棒性带来的挑战与影响。此外，本文还将围绕如何有效模拟分布外扰动、挖掘潜在的难样本区域，以及提升模型对分布变化的适应能力展开研究，进一步验证所提方法在复杂退化场景下的适用性与鲁棒性。

中国知网 https://www.cnki.net

第五章　基于生成语义近邻难样本数据的鲁棒目标识别方法

5.1 引言

近期的一些方法，如数据增强、对抗训练和迁移学习，在解决由于训练-测试数据分布变化导致的模型性能下降问题上展现了潜力。然而，这些方法通常需要在数据或模型设计方面进行精心规划，并且缺乏对分布变化影响的充分认识。特别是基于数据不确定性建模的成对图像特征表示增强方法和基于数据本征表示学习的特征向量量化方法，它们通常依赖于通过退化模型生成部分退化图像数据，并设计不确定性估计模块或向量码本模块来提高模型对退化图像提取的特征表示能力。尽管这些方法在低质量图像识别中取得了一定进展，但它们在处理非退化图像或测试数据分布差异较大的情况下，仍面临有限的识别性能和额外的数据开销等问题。

针对上述问题，本章首先对大量各种退化类型以及分布外测试集数据的模型错误推理结果进行统计分析，分析其预测标签与真实标签的相关性，并得出以下重要结论：由分布外数据往往集中于模型的分类边界附近，即大多数错误预测发生于真实值的附近。受此启发，本章提出了一种基于近邻类损失梯度扰动的对抗训练方法(GFN)。本方法通过引入与邻近类别相关的梯度扰动，增强了模型对样本间相似性的理解。在训练过程中，对于每个样本，方法会对其邻近类别的样本施加梯度扰动，增加模型对这些类别边界样本的训练关注，从而提升模型在面对各种潜在的分布外数据时的分类鲁棒性。具体地，本方法通过计算模型对样本的类别估计与邻近类别的标签之间的损失值并进行梯度反传生成扰动，然后在训练中通过引导模型更加关注这些邻近类别的样本，进而实现对抗训练。与传统的对抗训练方法不同，本方法不是随意地将样本推离真实值的扰动，而是利用邻近样本的梯度信息来动态调整扰动的方向和强度，从而减少冗余扰动样本，提升训练的高效性，并能模拟潜在的数据分布，进一步提高模型的整体鲁棒性。在多个不同的基准测试集及分布外数据集上的实验结果表明，本方法通过近邻类梯度扰动生成的样本进行对抗训练，能高效地提升模型的鲁棒性，提升对分类边界潜在分布数据的识别精度。

5.2 方法简介及相关基础知识

本章旨在研究如何在不使用任何退化模型生成仿真图像的情况下，提升模型在低质量图像上的识别鲁棒性。与传统方法依赖于退化模型来生成训练数据以模拟分布外变化不同，本章提出了一种新的方法，通过梯度扰动生成扰动图像，从而模拟出与训练数据分布不同的图像变化。与已有的退化生成策略相比，这种方法无需依赖大

中国知网　https://www.cnki.net

规模的仿真退化图像，而是利用近邻类别之间的相似性，通过对图像应用梯度扰动来增强模型对分类边界的潜在分布变化的适应能力。这种方式不仅避免了对退化图像的依赖，还能够生成更加多样化且具有挑战性的训练数据，从而显著提升模型在分布外数据上的泛化能力。

理论上，模型训练通常依赖于经验风险最小化（Empirical Risk Minimization, ERM）[121]，其目标是通过最小化训练集上的损失函数来提升模型在未见测试数据上的泛化能力。ERM 的核心假设是训练数据和测试数据满足独立同分布（Independent Identically Distribution, IID）条件。然而，在实际应用中，这一假设往往难以成立。当模型面对分布外（Out-of-Distribution, OOD）数据时，例如退化图像、攻击扰动或风格变化，其性能通常会显著下降，因为这些数据分布与训练数据分布存在显著差异，而模型并未针对这些分布变化进行专门优化。因此，提升模型的鲁棒性需要设计新的方法，确保即使在训练数据和测试数据分布发生偏离时，模型仍能在测试集上保持稳定的性能。这一问题可以形式化表示为：

$$\begin{aligned} \boldsymbol{f}_{\boldsymbol{\theta}}^{*} = \arg\min_{\boldsymbol{f}_{\boldsymbol{\theta}}} \mathbb{E}_{\boldsymbol{X},\boldsymbol{Y}\in P_{te}}[\mathcal{L}(\boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{X}),\boldsymbol{Y})] \\ s.t. P_{te}(\boldsymbol{X},\boldsymbol{Y}) \neq P_{tr}(\boldsymbol{X'},\boldsymbol{Y'}), \end{aligned} \tag{5-1}$$

其中，$\boldsymbol{f}_{\boldsymbol{\theta}}$ 表示具有参数 $\boldsymbol{\theta}$ 的模型，$P_{te}(\cdot)$ 和 $P_{tr}(\cdot)$ 分别表示测试数据和训练数据的分布。$\mathcal{L}$ 为损失函数，通常为交叉熵损失函数。

鲁棒学习的一个重要研究方向是设计复杂的数据增强策略，通过利用现有训练集生成具有多样化分布的数据，帮助模型学习更具鲁棒性的特征表示，从而提升其处理分布外样本的能力。传统的数据增强方法，例如 Mixup[16] 和 CutMix[17]，通过线性插值混合两幅图像或通过剪切和粘贴不同图像的区域来生成新的数据分布。与之相比，对抗训练[22]则通过对原始数据施加基于梯度的扰动，生成具有挑战性的对抗样本。再约束模型在这些对抗性样本上输出正确的结果从而而提升模型的鲁棒性。然而，这些方法缺乏对特定类型数据分布扰动的系统性分析，无法明确解释哪些扰动类型最有利于增强模型的鲁棒性，从而在一定程度上限制了其可解释性和通用性。

近期，一些方法涉及对神经网络的结构进行分析和修改，例如 transformer 架构进行修改或在 token 级别添加新模块。例如，FAN[116]通过信息瓶颈理论分析了视觉 transformer（ViT）和传统卷积神经网络 CNN 的鲁棒性，得出 transformer 的鲁棒性更强，并确定结构中的自注意力层是影响模型鲁棒性的关键因素，从而提出了全新的全注意力网络。TAPADL[122]则通过引入 token 平均池化层来减少输入图像中的高斯噪声影响，从而实现平滑输入。然而，值得注意的是，这些网络模型结构的修改可能属于非标准方法，某些操作可能缺乏并行计算的支持，从而导致计算时间大幅增加，

中国知网 https://www.cnki.net

这可能会限制它们作为通用解决方案的可行性。

为了解决这些问题，需要考虑以下几个方面：1) 分布变化对模型输出，特别是在分类任务中的影响是什么？2) 如何生成能够有效引起类似影响的训练数据？基于公式 (5-1) 和经验风险最小化（ERM）原理，如果模型在来自多样化分布的数据上进行训练，并且这些分布能够紧密接近潜在的测试分布，那么其鲁棒性可能会得到显著提升。3) 如何通过生成的数据和精细化的损失函数来进一步增强模型的鲁棒性?

因此，本章设计了一系列实验来探讨这些问题。通过实验结果和统计分析，可以得出结论：大多数由于分布变化引起的分类错误主要集中在接近真实值的区域，也就是说，误分类往往会落入与真实标签语义相似的类别中。此外，相关实验还观察到，视觉基础大模型表现出比更易受攻击的模型更大的类间距离，这有助于提高模型的鲁棒性。基于这些观察结果，本章提出了一种梯度扰动方法，针对邻近类生成有效的训练数据，通过对原始输入图像施加这些扰动。这些基于梯度的扰动增加了数据被误分类到邻近类别的概率，有效模拟了模型在测试期间可能遇到的分布外（OOD）条件。此外，本章引入了一个基于类间距离加权的损失函数，以微调模型参数，建立一个更加分散的类别分布，提高模型在扰动数据下做出准确预测的能力。从而提高了模型的整体鲁棒性。

5.3 分布外数据的统计分析

大量研究表明，模型在分布外（OOD）数据上的性能可能会显著下降。为了深入了解模型在 OOD 数据上的表现和误差来源，本节的目标是探究错误预测与真实标签之间的相关性，以及这些 OOD 数据的潜在分布。为此，本章设计并进行了以下实验。

5.3.1 错误预测统计

本节首先探索了 OOD 数据对模型预测的影响。由于文献[116]证实相同参数量的情况下，视觉 transformer（vision transformer，ViTs）相比卷积神经网络（CNN）有更好的鲁棒性。因此，本章均基于 transformer 架构进行实现。

对于一个预训练的 ViT-Base 模型 $\boldsymbol{f_\theta}$，其参数为 $\boldsymbol{\theta}$，对于一个 ImageNet 测试集中的清晰图像 $\boldsymbol{x}$ 和相应的真实标签 c，以及一个来自 ImageNet-C 数据集的对应的退化图像 $\tilde{\boldsymbol{x}}$。本节将这些分布外的退化图像输入预训练模型进行推理，并收集那些在使用清晰图像时正确分类，但在使用退化图像时被错误分类的图像，即有错误集合：

$$S = \{\tilde{\boldsymbol{x}} | \boldsymbol{f_\theta}(\tilde{\boldsymbol{x}}) = y_p \neq y_c,\ \boldsymbol{f_\theta}(\boldsymbol{x}) = y_c\}. \tag{5-2}$$

这确保了在集合 S 中，错误分类仅归因于退化效应，而不是模型在某些清晰图像上

中国知网　https://www.cnki.net

的固有限制。

图 5.1（a）和图 5.1（b）展示了清晰图像、真实标签和相应的退化图像错误预测。从图中可以观察到，错误分类的类别与其真实标签上在存在一定的语义相似性（例如，信标和钻井平台）。本节实验还可视化了特征空间中的类别嵌入特征 $\boldsymbol{z_c}$ 分布。类别嵌入即每个类别所有图像的均值或中心特征，通常是对该类所有图像提取的判别性特征求平均得到；或者使用分类器的全连接层权重代替：

$$\begin{aligned} \boldsymbol{z_c} &= \frac{1}{N}\sum_{i}^{N} \boldsymbol{z_{ci}},\ where\ \boldsymbol{z_{ci}} = \boldsymbol{f_\theta}(\boldsymbol{x_{ci}}) \\ or\ &= W_c \in \mathbb{R}^{1\times d}, where\ W \in \mathbb{R}^{C\times d}. \end{aligned} \tag{5-3}$$

如图 5.1 (d) 所示，错误预测的类别在语义特征空间的分布也较为接近。这进一步支持了前述 **“错误分类的类别与其真实标签上在存在一定的语义相似性”** 的结论。此外，本节在多个数据集上进行了广泛的统计分析，以排除这一结论偶然性。对于每个类别嵌入 $\boldsymbol{z_c} \in \mathbb{R}^{1\times d}$，计算其与其他类别嵌入的相似性，得到相似性矩阵 $\mathcal{M} \in \mathbb{R}^{C\times C}$，其中 $\mathcal{M}_{ij} =< \boldsymbol{z_i}, \boldsymbol{z_j} >, i, j \in \{1, \ldots, C\}$ 表示类别 i 与类别 j 之间的余弦相似度。然后，对于图像 $\tilde{\boldsymbol{x}} \in S$，可以通过以下公式获得其错误预测类别 p 与其真实标签 c 之间的相似性排名索引 k：

$$k = rank(\mathcal{M}_{cp}), \mathcal{M}_{cp} \in sorted(\mathcal{M}_{c1}, \ldots, \mathcal{M}_{cC}). \tag{5-4}$$

也就是说，错误分类发生在与真实类别最相似的第 k 类内。对于 S 中的每个样本，本节都计算了其相似度排名 k，并在图 5.1（e）中展示了排名 k 的样本数量的直方图。更多结果可见图 5.2 。相似度序及其样本数量统计分布直方图的计算过程可以总结为算法 5.1 及算法 5.2 中的伪代码计算流程模块。

如图 5.2 对应的多个退化造成的错误预测类相似度序与样本数量统计分布图表明，大多数错误预测集中在前 k 个最相似类别内，其中许多样本的错误预测相似度排名 $k < 20$（共 1000 个类别）。这足以表明，当模型在自然环境中的退化影响下对图像发生预测错误时，预测类别通常与真实类别在语义特征上具有较高的相似性。

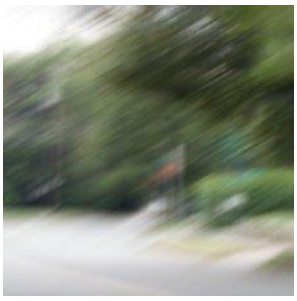
5.3.2 像素值分布偏移

为深入探究退化图像与清晰图像之间的像素分布特性差异，本节通过统计分析对比了高质量图像与退化图像的像素强度分布特征。具体而言，对图像数据集中每个图像像素值对应的像素频率分布进行定量分析。如图 5.1（c）所示，实验结果表明退化图像的像素值分布整体保持原有形态，但呈现出系统性偏移，这种偏移可能表现

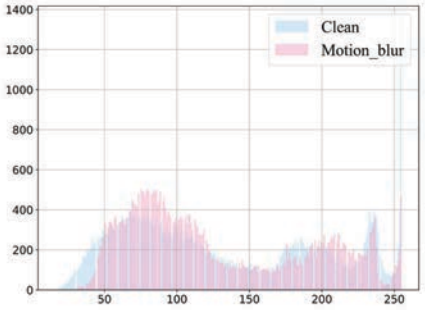
中国知网 https://www.cnki.net



(a) 清晰图像1



(b) 交通灯 汽车反光镜



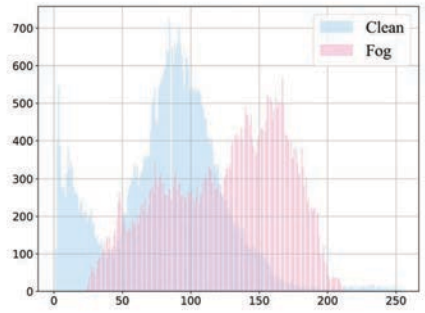
(c) 图像1像素强度分布



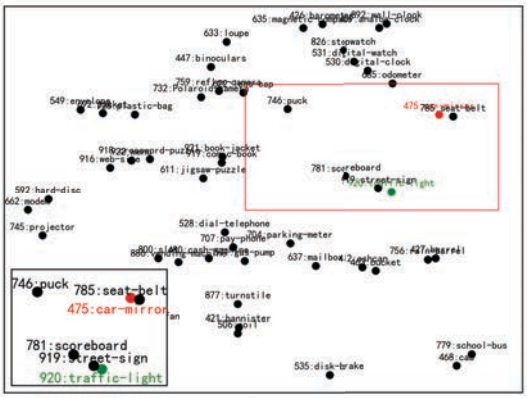
(a) 清晰图像2



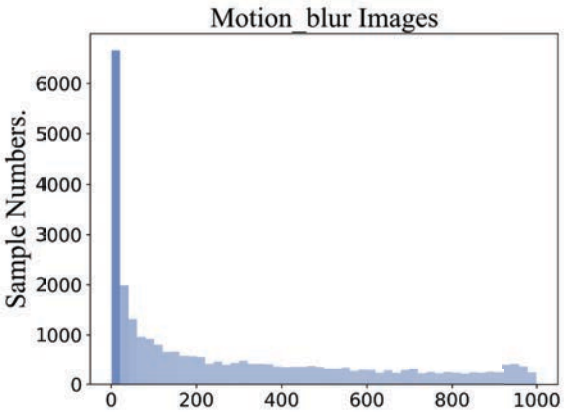
(b) 灯塔 钻井平台



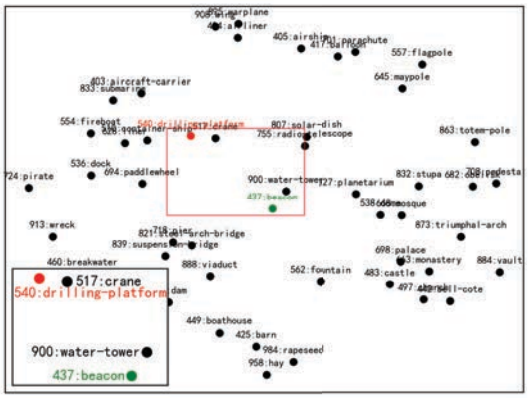
(c) 图像2像素强度分布



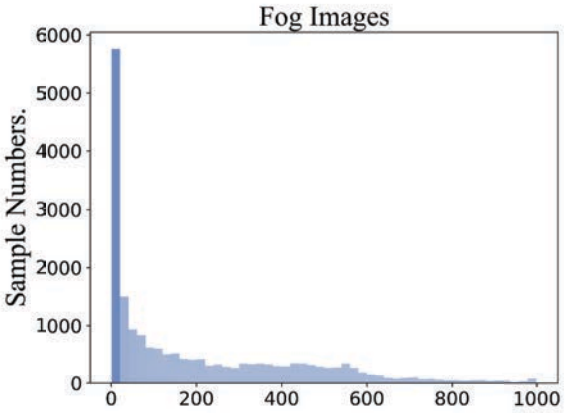
(d) 图像1类向量分布



(e) 图像1错误预测与真值的相似度序$\boldsymbol{k}$



(d) 图像2类向量分布



(e) 图像2错误预测与真值的相似度序$\boldsymbol{k}$

图 5.1　分布外数据错误预测的统计分析

中国知网　https://www.cnki.net

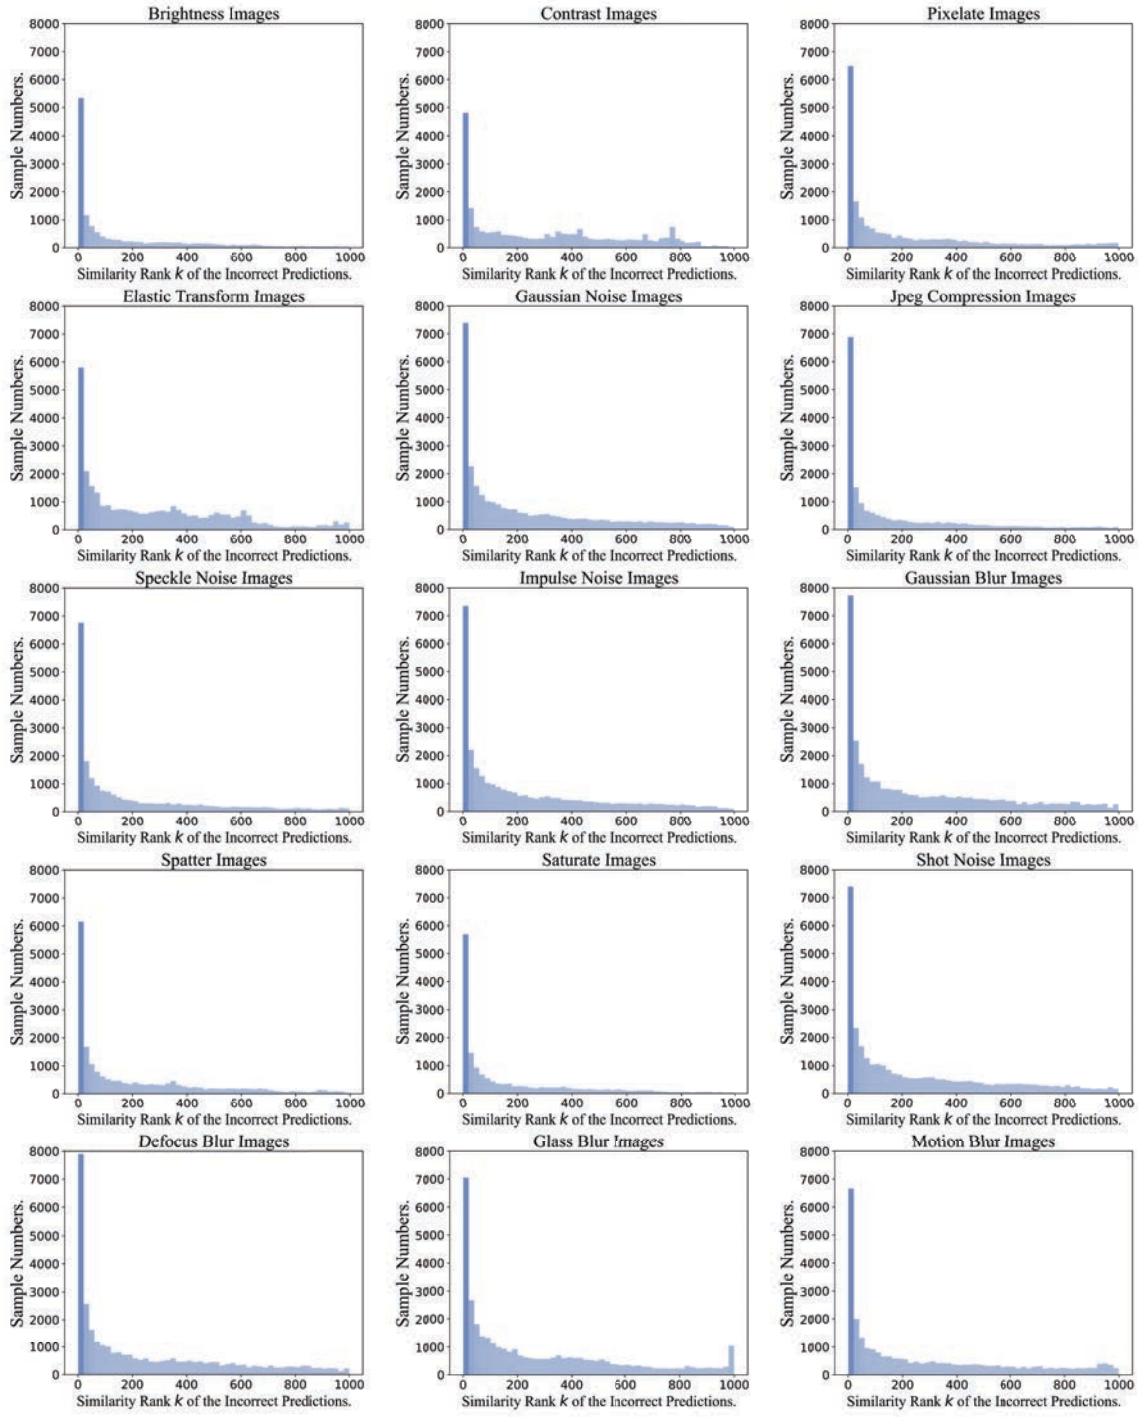


图 5.2 各种退化下错误预测类与真实类的相似度序 k 与样本数量的关系图

中国知网 https://www.cnki.net

算法 5.1　计算错误预测类别 p 与真实类别 c 间的相似度序 k

输入: 类别嵌入向量 $\{\boldsymbol{z}_i\}_{i=1}^{C} \in \mathbb{R}^d$, 真实类别 c, 预测类别 p.

输出: 错误预测类别与真实类别之间的相似度序 k。

% 第 1 步: 计算相似度矩阵 $\mathcal{M}$。
for $i \in \{1, \ldots, C\}$ **do**
    for $j \in \{1, \ldots, C\}$ **do**
        $\mathcal{M}_{ij} \leftarrow \boldsymbol{z}_i \cdot \boldsymbol{z}_j^T$
    end for
end for
% 第 2 步: 提取真实类别 c 所在行的相似度向量。
$\boldsymbol{m} \leftarrow \mathcal{M}[c, :] \leftarrow \{\mathcal{M}_{c1}, \mathcal{M}_{c2}, \ldots, \mathcal{M}_{cC}\}$
% 第 3 步: 对类别 c 的相似度向量中每个值排序。
$\boldsymbol{m}_{\text{sorted}} \leftarrow \text{Sort}(\boldsymbol{m}, \text{descending})$
% 第 4 步: 得出预测类别 p 的对于真实类别 c 的相似度 k。
$k \leftarrow \text{Index}(\mathcal{M}_{cp}, \boldsymbol{m}_{\text{sorted}})$
返回 $k \in \{1, \ldots, C\}$

算法 5.2　相似度序 k 的频数统计分布直方图计算

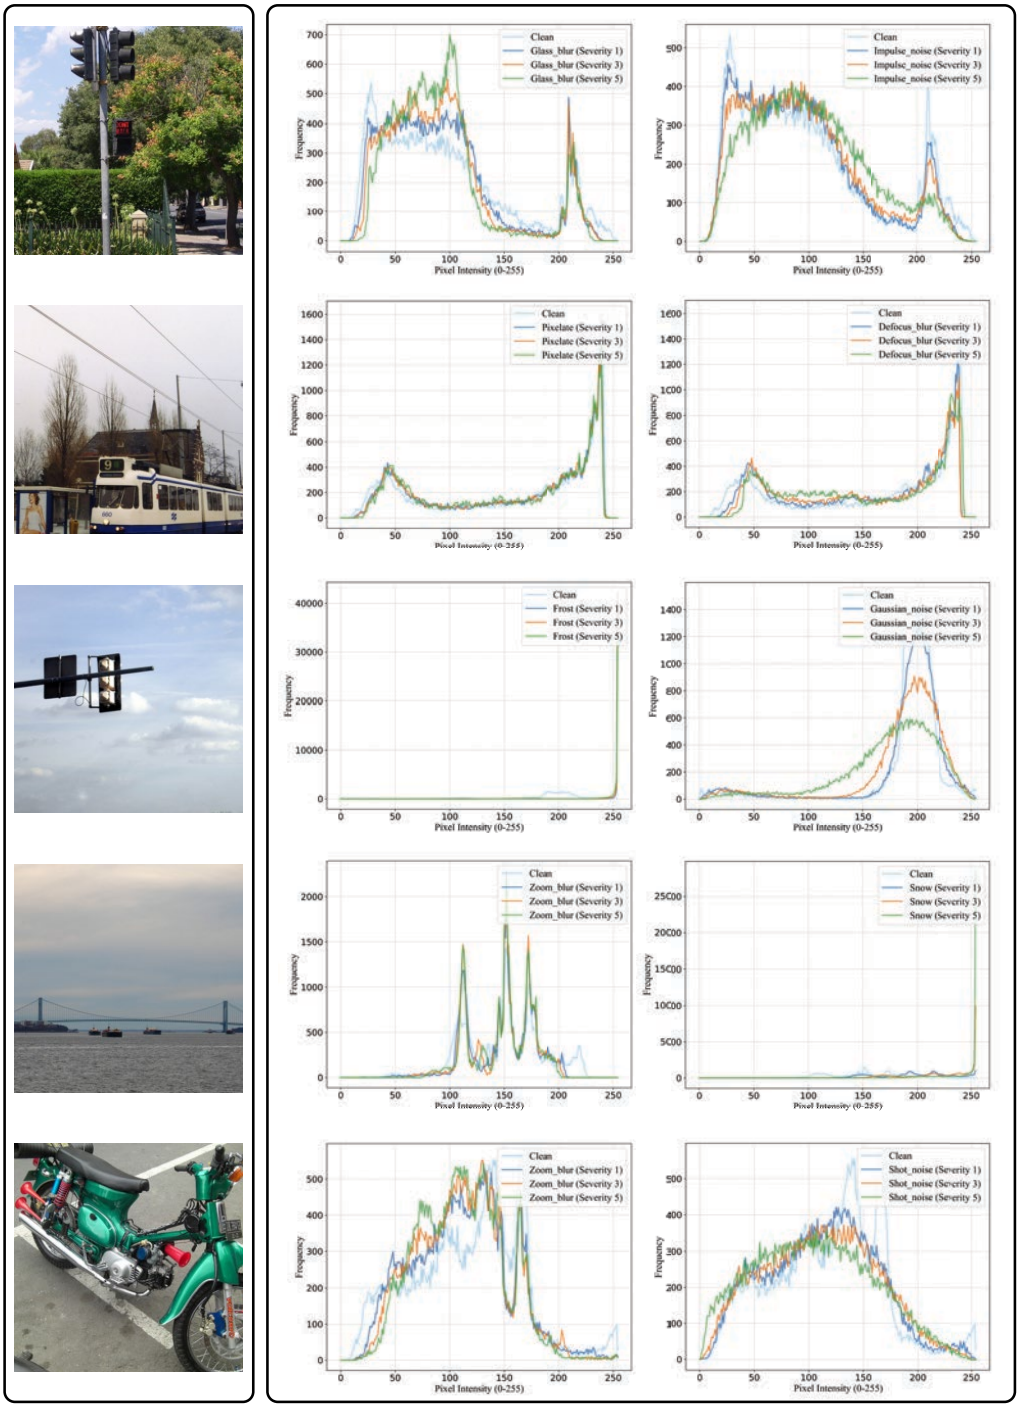
输入: 预测错误的图像集合 $\mathcal{S} = \{\boldsymbol{x}_i, p_i, y_i\}_{i=1}^{N}$, 其中 $\{y_i\}$ 是真实标签，$\{p_i\}$ 为预测错误的类别。

输出: 预测类别与真实类别的相似度序 k 的频数统计分布直方图。

初始化各个序的频数为 0: $H_k \leftarrow \mathbf{0}$ for all ranks $k \in \{1, \ldots, C\}$.
使用算法 5.1 计算相似度矩阵 $\mathcal{M}$
for 每个样本 $(\boldsymbol{x}_i, p_i, y_i)$ in 预测错误的图像集合 $\mathcal{S}$ **do**
    提取真实标签 y_i 与其他类别的相似度向量: $\boldsymbol{m} \leftarrow \mathcal{M}[y_i, :]$
    将相似度进行排序: $\boldsymbol{m}_{\text{sorted}}$
    使用算法 5.1 计算预测类别与真实类别的相似度序 k: $k \leftarrow \text{Index}(\mathcal{M}_{y_i, p_i}, \boldsymbol{m}_{\text{sorted}})$
    将相似度序 k 对应的频数统计量加一: $H_k \leftarrow H_k + 1$
end for
返回 直方图 H_k

为正向或负向的均匀平移。这一发现表明，图像退化过程中的扰动主要作用于全局像素强度层面，而不会显著改变图像的内在结构特征。从更深层次来看，这种扰动效应主要体现在全局亮度调整或对比度变化等整体性特征上，而非对图像的空间关系或结构模式产生根本性改变。这一现象为理解模型的错误分类行为提供了重要启示：由于图像的核心语义特征在退化过程中保持相对稳定，其语义特征分布可能也仅发生了部分偏移，使得模型在分类时倾向于将退化图像归类至与真实类别在语义空间相近的类别。更多详细的像素分布对比示例可参见图 5.3 。

中国知网　https://www.cnki.net



(a) 清晰图像　　(b) 像素强度分布受各种退化的影响

图 5.3　各图像在各退化下的像素强度分布统计图

中国知网　https://www.cnki.net

5.3.3 类间相似性分析

为深入探究高鲁棒性模型的特征表示特性，本研究对标准 ViT-Base 模型与高鲁棒性 DINOv2 模型[123]的类间相似性进行了可视化对比分析。其中，DINOv2 模型是基于大规模数据集 LVD-142M[123]通过自监督学习范式训练得到，其在 ImageNet-C 基准测试中展现出优异的性能表现：清晰图像准确率达到 84.6%，鲁棒性准确率为 72.1%。

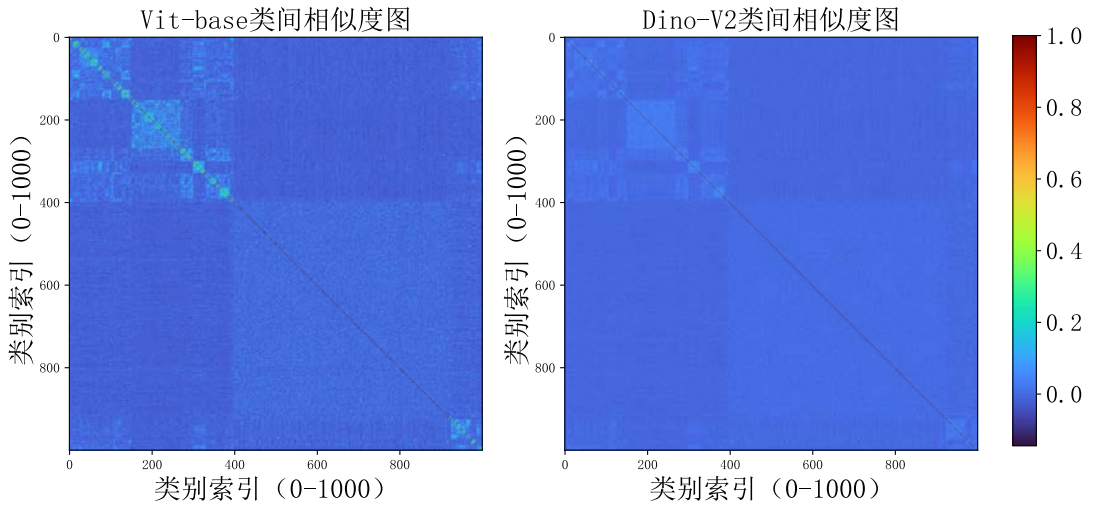


图 5.4　基础视觉大模型与 ViT-base 模型的类间相似度对比图

如图 5.4 所示，通过对比分析可得出以下重要发现：在 ViT-Base 模型中，部分类别与其语义邻近类别之间存在较高的特征相似性，这种现象在 DINOv2 模型中显著减弱。这一观察结果表明，ViT-Base 模型在分类决策时更容易在相似类别间产生混淆，而 DINOv2 模型通过其优化的训练策略，学习到了更具判别性的类间特征表示，有效降低了类别间的混淆概率。

基于上述实验结果，可以得出以下结论：模型的错误分类行为并非随机分布，而是呈现出特定的模式特征，即错误预测往往集中在与真实类别语义相近的类别范围内。具有较强鲁棒性的模型通过建立更大的类间距离和更小的类间相似性，形成了更为清晰的决策边界，从而显著降低了错误分类的发生概率。这一发现为理解模型鲁棒性提供了新的视角，也为后续改进模型性能指明了方向。

5.4 基于生成近邻类扰动数据的对抗训练方法

5.4.1 近邻类易混淆扰动样本生成

基于第 5.3 节的实验观察结果，该研究为设计更有效的训练策略提供了重要的理论指导。具体而言，对于给定图像 $\boldsymbol{x}$，可生成其退化版本 $\boldsymbol{x}'$，该图像具有很高的概率

中国知网　https://www.cnki.net

被错误分类为邻近类别。通过重点处理这些近邻错误分类样本，能够更准确地模拟实际应用中的分布变化，应对样本处于分类边界的情况，从而显著提升模型的鲁棒性。基于此，给定预训练网络 $\boldsymbol{f_\theta}$ 和带有标签 y_c 的清晰输入图像 $\boldsymbol{x}$，本节方法旨在生成满足 $\boldsymbol{f_\theta}(\boldsymbol{x'}) = y_p$ 的图像 $\boldsymbol{x'}$，其中 p 表示与 c 最相似的前 k 个类别之一。为实现这一目标，采用基于输入梯度的优化方法，其数学表达如下：

$$\boldsymbol{x'} = \boldsymbol{x} - \eta * sign(\nabla_{\boldsymbol{x}} \mathcal{L}_{ce}(\boldsymbol{\theta}, \boldsymbol{x}, y_p)), \tag{5-5}$$

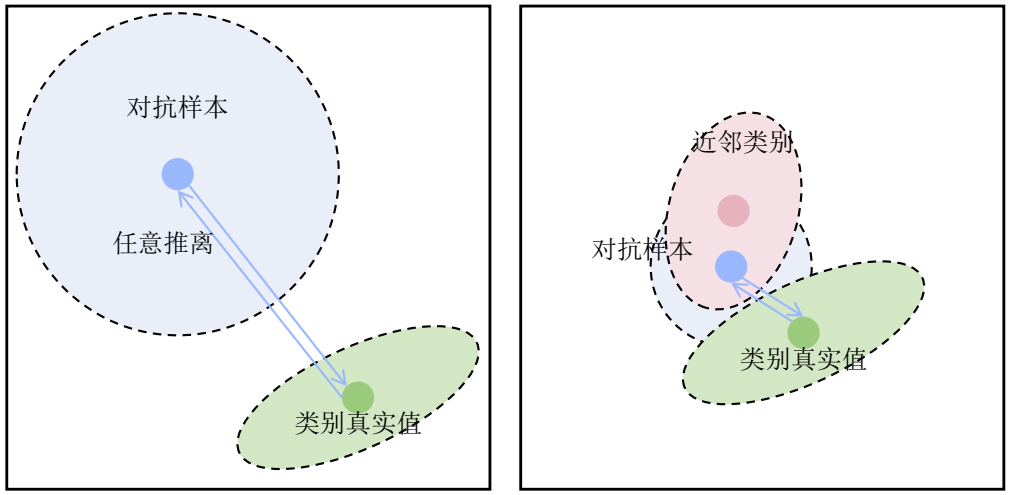
其中，η 表示优化步长，$\mathcal{L}_{ce}$ 为交叉熵损失函数，$\nabla_{\boldsymbol{x}}$ 表示输入 $\boldsymbol{x}$ 的梯度。由于负梯度方向能够有效最小化损失函数，因此生成的 $\boldsymbol{x'}$ 能够引导模型预测输出邻近类别 p，从而实现预期的训练目标。

在训练中，通过约束模型在上述扰动数据 $\boldsymbol{x'}$ 上产生正确类别预测（即类别 c）来优化模型参数，其优化目标可表示为：

$$\boldsymbol{\theta}^* = \arg\min_{\boldsymbol{\theta}} \ \mathcal{L}_{ce}(\boldsymbol{x'}, y_c). \tag{5-6}$$

本方法的核心流程可总结为：首先利用公式 (5-5) 生成梯度扰动图像，随后通过公式 (5-6) 确保模型对这些扰动图像保持正确的分类能力。

5.4.2 与标准对抗训练的区别：对比分析



(a) 标准的对抗训练　　(b) 近邻类对抗训练

图 5.5　本章方法与标准对抗训练的区别示意图

如第 2.2.3 节所述，针对神经网络对抗攻击的防御性训练策略，其核心目标在于提升模型在对抗样本下的鲁棒性，同时保持模型在干净样本上的原始性能。该训练策略的数学表达可表示为如下公式 (5-7) 的形式：

中国知网　https://www.cnki.net

$$\boldsymbol{x}' = \boldsymbol{x} + \eta * sign(\nabla_{\boldsymbol{x}} \mathcal{L}_{ce}(\boldsymbol{\theta}, \boldsymbol{x}, y)). \tag{5-7}$$

对比公式 (5-5) 和 (5-7)，以及图 5.5 可以看出，这两种方法在计算对抗扰动时的目标类别选择上存在本质差异。从梯度方向和优化目标的角度分析，本节提出的方法（公式 (5-5)）通过将输入扰动引导至邻近类别 y_p，有效模拟了视觉或语义相关类别间的细微差异，并通过对抗训练强化模型对这些相似类别的区分能力，从而系统性地提升模型的鲁棒性。相比之下，标准对抗训练方法（公式 (5-7)）则致力于将输入从真实类别 y 推离，其主要目标是防止模型在对抗性条件下产生显著偏差导致的极端错误分类。这种差异反映了两种方法的不同应用场景：标准对抗训练主要针对人为设计的对抗攻击，而本节方法则更适用于处理自然场景中常见的图像退化问题。本节方法通过有目的地将输出引导至邻近类别，实现更聚焦且高效的训练过程。这种创新的训练策略使模型能够有效学习潜在的分布外数据结构特征，通过提升模型在不同数据分布间的泛化能力，显著增强了模型的鲁棒性。

5.4.3 类间距离加权损失函数

基于第 5.4.1 节提出的近邻样本对抗训练框架，本方法的创新性主要体现在通过生成具有类别导向性的扰动数据，显著提升了模型在特征空间中对语义相似类别的区分能力。结合第 5.3 节的理论分析以及图 5.4 的实验结果，可以得出以下重要结论：（1）类别间的混淆现象主要集中于特征空间中距离较近的语义相似类别之间，这种现象在图像退化条件下尤为显著；（2）传统方法在处理类别间相似性时存在固有局限性，而近期发展的视觉基础大模型（如 DINOv2）通过在更大规模、更丰富多样的数据集上进行预训练，获得了更大的类间距离，在处理由图像退化引起的相似类别错误预测问题时表现出更强的鲁棒性；（3）通过设计有针对性的训练策略，能够有效改善模型的决策边界，提升其在复杂场景下的泛化能力。基于这些研究发现，本节提出了一种通过系统性扩大类别间距离来增强模型鲁棒性的优化策略，本方法通过重构损失函数的优化空间，不仅能够有效降低类别间的混淆概率，还能显著提升模型在实际应用场景中的可靠性和稳定性。

基于上述理论分析和实验验证，本节提出一种创新的类间距离加权损失函数（Inter-Class Distance Weighted Loss, ICDW-Loss）。本方法的核心思想是通过构建自适应损失权重矩阵，在特征空间中对距离较近的相似类别对施加差异化的误分类惩罚，从而增强模型在决策边界处的特征判别能力。加权损失函数的设计主要基于以下三个关键考虑因素：（1）类别相似性度量：利用特征空间中类原型的相对距离，建立可量化的类别相似度评估体系；（2）动态权重分配机制：基于类别相似度构建动态权重调整函数，对易混淆类别对实施渐进式惩罚策略；（3）梯度稳定性保障：通过引入

中国知网　https://www.cnki.net

权重平滑约束，确保训练过程中的梯度稳定性，避免模型收敛困难。基于上述设计原则，本节提出了一种基于类别相似度排序的指数衰减权重项，其数学表示如下：

$$\boldsymbol{w} = (w_1, \ldots, w_p, \ldots, w_C), w_p = \alpha^k, 0 < \alpha < 1, \tag{5-8}$$

其中，α 为可调节的超参数，其取值范围限定在 $(0,1)$ 区间；k 表示预测类别 p 与真实标签 c 在特征空间中的相似性排序，由公式 (5-4) 及算法 5.1 所定义和计算。该加权策略具有以下特性：类别相似度越高，对应的 k 值越小，则权重 w_p 越大。例如，当 $\alpha = 0.5$ 时，错误预测类为第二相似类别的权重为 $0.5^2 = 0.25$，而第 20 个相似类别的权重则降至 $0.5^{20} \approx 9 \times 10^{-7}$。这种指数加权的设计能够实现对相似类别的差异化惩罚，有效扩大类别间的决策边界，从而显著提升模型的鲁棒性和泛化能力。这种创新性的设计机制使得模型能够更有效地学习具有判别性的类别特征表示，特别是在处理易被错误分类至邻近语义相似类别的扰动图像时表现出显著的鲁棒性提升。

5.4.4 整体网络框架和训练流程

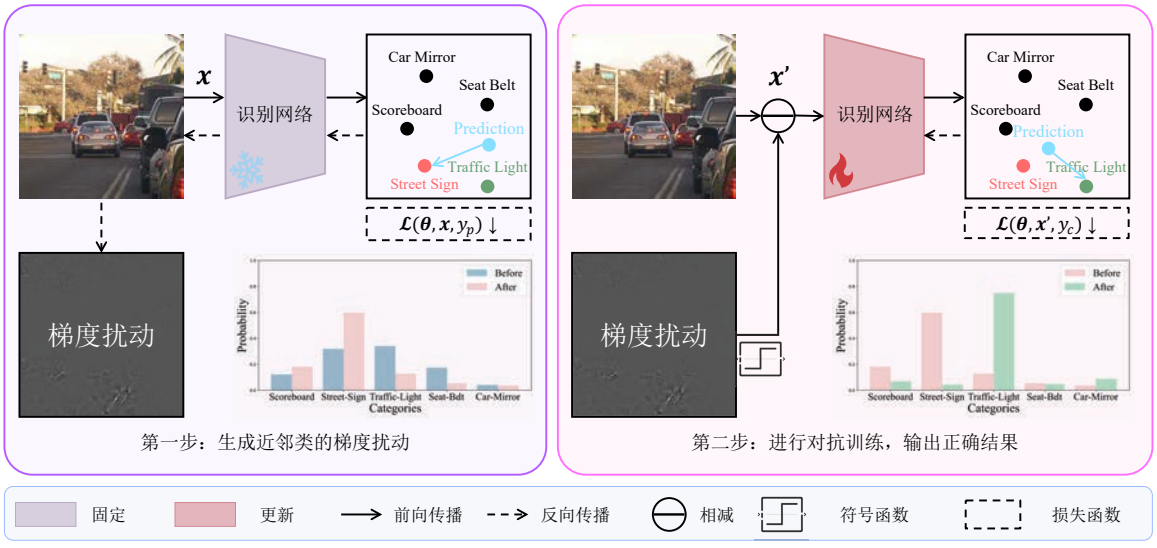


图 5.6 基于近邻类梯度扰动的对抗训练方法示意图

整体框架如图 5.6 所示。由于从头训练模型耗时较长，本章利用现成的预训练模型进行高效的微调。在第一步，对于给定的清晰图像 $\boldsymbol{x}$ 和标签 y_c，首先将图像张量设置为可微分的（即，`x.requires_grad=True`），并将其输入到模型中。接着，从前 k 个最相似的类别中随机选择一个类别 p 作为目标，计算模型输出与该类别的交叉熵损失，并根据公式 (5-5) 进行反向传播，获得梯度和扰动后的图像 $\boldsymbol{x'}$。在此过程中，模型仅参与反向传播，而不更新其参数。随后，本章方法将扰动图像 $\boldsymbol{x'}$ 重新输入到模型中，微调模型参数进行训练，以正确地将 $\boldsymbol{x'}$ 分类为其对应的真实标签 c。这

中国知网 https://www.cnki.net

一过程通过最小化上述第 5.4.3 节提出的类间距离加权的分类损失来实现：

$$\mathcal{L}_{ce}(y_c, \boldsymbol{f_\theta}(\boldsymbol{x'})) = -y_c * \boldsymbol{w} * \log(softmax(\boldsymbol{f_\theta}(\boldsymbol{x'}))). \tag{5-9}$$

整体训练流程如图 5.6 和算法 5.3 所示。该训练过程采用迭代优化策略，通过多轮次的图像输入、近邻目标类别选择、梯度扰动、训练纠正与模型更新，确保模型能够持续且稳定地将易混淆的扰动图像正确分类回其真实标签，提升模型的鲁棒性。

算法 5.3　基于近邻类梯度扰动的对抗训练方法

输入： 训练数据 $\{\boldsymbol{x}, y\}$, 学习率 lr, 类别相似度矩阵 $\mathcal{M}$, 具有参数 $\boldsymbol{\theta}$ 的模型 f, 相似度序阈值 k, 扰动步长 η，损失惩罚因子 α。

输出： 模型更新后的参数 $\boldsymbol{\theta}^*$。

$\boldsymbol{x}.requires_grad = True$
for 每个小批次数据 $\{\boldsymbol{x}_B, y_B\}$ in 训练数据集 **do**
  for 每个样本 $\{\boldsymbol{x}_i, y_i\}$ in 小批次数据 **do**
    % 第 1 步：获取相似类别 p.
    $\boldsymbol{m} \leftarrow \{\mathcal{M}_{y_i 1}, \ldots, \mathcal{M}_{y_i C}\} \leftarrow \mathcal{M}[y_i, :]$
    $value, index \leftarrow \boldsymbol{m}.topk(k)$
    $idx = random.randint(0, k-1)$
    $p \leftarrow index[idx]$
    % 第 2 步：生成对抗样本.
    for 每一步 in 总扰动步数 **do**
      $\boldsymbol{x'}_i \leftarrow \boldsymbol{x}_i - \eta * sign(\nabla_{\boldsymbol{x}_i} \mathcal{L}_{ce}(\boldsymbol{\theta}, \boldsymbol{x}_i, y_p))$
      $\boldsymbol{x}_i \leftarrow \boldsymbol{x'}_i$
    end for
  end for
  % 第 3 步：进行对抗训练.
  $w_p = \alpha^{idx}$
  $\mathcal{L} \leftarrow w_p * \frac{1}{B} \sum_{i=1}^{B} \mathcal{L}_{ce}(f(\boldsymbol{\theta}, \boldsymbol{x'}_i), y_i)$
  $\boldsymbol{\theta}^* \leftarrow \boldsymbol{\theta} - lr \cdot \nabla_{\boldsymbol{\theta}} \mathcal{L}$
end for
返回 更新后的模型参数 $\boldsymbol{\theta}^*$.

5.5 实验结果

5.5.1 实验设置

数据集和评价指标： 在实验设置方面，本节实验严格遵循模型鲁棒性评估的标准范式。即与之前几章的算法不同，本章所有实验无需在训练集中使用图像退化模型生成退化仿真图像，而是在图像训练阶段仅使用高质量 ImageNet 图像进行梯度扰动生

中国知网　https://www.cnki.net

成，而在评估阶段则采用多个分布外基准数据集进行综合测试，包括低质量退化图像数据集 ImageNet-C[24]、ImageNet-P[24]、分布外测试集 ImageNet-R[36]，对抗攻击测试集 ImageNet-A[37]以及由扩散模型生成的非真实数据 ImageNet-D[124]。其中，ImageNet-C 基准数据集涵盖了 15 种常见的图像退化类型，通过归一化的平均退化误差（mCE）进行评估，较低的指标值对应更好的鲁棒性表现。

与 ImageNet-C 不同，ImageNet-P 通过为每个 ImageNet 验证图像生成时序扰动序列来评估模型的动态鲁棒性，使用平均翻转率（mean Flip Rate, mFR）进行评估，主要用于衡量模型在面对图像扰动时的预测稳定性。其定义如下：给定一个包含 N 个样本的测试集，对于每个样本 $\boldsymbol{x}_i$，生成 T 个连续的扰动版本 $\{\boldsymbol{x}_i^1, \boldsymbol{x}_i^2, ..., \boldsymbol{x}_i^T\}$。mFR 的计算公式为：

$$\text{mFR} = \frac{1}{N}\sum_{i=1}^{N}\left(\frac{1}{T-1}\sum_{t=1}^{T-1}\mathbb{I}[f(\boldsymbol{x}_i^t) \neq f(\boldsymbol{x}_i^{t+1})]\right), \tag{5-10}$$

其中，$f(\cdot)$ 表示模型的预测函数，$\mathbb{I}[\cdot]$ 是指示函数，当条件成立时取值为 1，否则为 0。T 表示扰动序列的长度，N 表示测试样本数量。

该指标反映了模型在连续扰动下的预测一致性：较低的 mFR 值表明模型在面对图像扰动时能够保持更稳定的预测结果，即具有更好的鲁棒性。在 ImageNet-P 基准测试中，mFR 是评估模型动态鲁棒性的核心指标之一。

此外，如前第 2.1.2 节所述，ImageNet-R 专注于艺术渲染图像的鲁棒性评估，包含草图、绘画、玩具等多种艺术表现形式；而 ImageNet-A 则提供对抗样本用于测试模型在对抗攻击下的鲁棒性。而 ImageNet-D 是一个全新的基于扩散模型生成的合成图像数据集，旨在评估神经网络在合成数据上的鲁棒性。该数据集通过扩散模型（Diffusion Models）生成高质量的合成图像，这些图像在视觉上与真实图像非常接近，但在细节和分布上可能存在差异，从而为评估模型的鲁棒性提供了一个新的基准。包含背景（background），纹理（texture），材质（material）等三种不同风格的 1000 类合成图像。图 5.7 展示了数据集中的部分图像。在本节实验中，报告这三个数据集的 top-1 分类准确率作为评价指标，以全面评估模型在不同挑战性场景下的性能表现。

实现细节：鉴于 Transformer 架构在计算机视觉领域的广泛应用，本节实验基于视觉 Transformer（ViT）模型展开。实验采用随机梯度下降法（SGD）[125]作为优化器，其初始学习率设置为 0.001，动量参数为 0.9，权重衰减系数为 5e-4。学习率调度策略采用余弦退火函数，以确保训练过程的稳定性。实验设置批量大小为 48，并在 4 块 Nvidia GeForce RTX 3090 GPU 上完成训练过程。对于关键超参数的设置，梯度扰动的步长 η 固定为 0.01。基于第 5.5.4 节的消融实验结果，确定 top k 值为 20，同时公式 (5-8) 中的权重系数 α 设置为 0.5。

中国知网 https://www.cnki.net



背景（background）：生成一些物体在不太可能的背景中



材质（material）：生成一些物体有着不寻常的材质



纹理（texture）：生成一些物体有着不寻常的纹理

图 5.7　ImageNet-D 部分图像数据示例

表 5.1　多个鲁棒性基准测试集下各方法的性能对比

方法	参数量 (M)	计算量 (G)	推理时长 (ms)	IN Acc. ↑	IN-C mCE ↓	IN-P mFR ↓	IN-A Acc. ↑	IN-R Acc. ↑
ViT-B[112]	86.4	16.8	4.8	76.3	52.2	32.2	31.7	50.7
DeiT-B[113]	86.4	16.8	4.8	78.4	47.4	31.8	27.6	45.3
Swin-B[42]	87.8	15.4	17.3	83.4	54.4	32.7	35.8	46.6
RVT-B (ViT-B)[117]	91.8	17.7	5.3	82.6	46.8	31.9	28.5	48.7
FAN-B-Hybrid[116]	50.4	11.7	20.8	83.9	46.1	31.3	39.6	52.7
RSPC (FAN)[126]	50.5	11.7	21.0	84.2	44.5	30.0	41.1	53.4
TAPADL (FAN)[122]	50.7	11.8	21.5	84.3	43.7	29.2	42.3	54.6
本章方法 (ViT-B)	86.4	16.8	4.8	79.9	41.4	27.1	42.0	55.9
本章方法 (FAN)	50.4	11.7	20.8	**86.4**	**39.8**	**26.3**	**46.4**	**57.7**

5.5.2 鲁棒性分类的实验结果

本节通过基准数据集上的对比实验，验证了所提出方法在鲁棒性方面的性能优势。实验选取了当前最具代表性的几种 SOTA 方法进行对比，包括 FAN[116]、RVT[117] 和 TAPADL[122]，以全面评估所提出方法在计算效率和准确性方面的表现。实验结果如表 5.1 所示。为确保对比实验的公平性，主要采用复现结果与原始论文报告结果相结合的方式，其中部分数据直接引用自对比方法的原始论文。

表 5.1 的实验结果表明，所提出的方法具有良好的架构适应性和性能提升效果。

中国知网　https://www.cnki.net

方法 / 数据集	ViT-B[112]	Augmix[18]	DeepAug.[36]	FAN[116]	TAPADL[122]	**Ours**
IN-C (mCE) ↓	52.2	50.3	49.9	46.7	43.1	**41.4**
IN-D (Acc) ↑	14.9	12.5	14.2	18.1	17.4	**20.1**

表 5.2 各个方法在 IN-C 和 IN-D 上的性能对比

在 ViT-Base 模型上的实验显示，本方法将清晰图像的 top-1 准确率从 76.3% 提升至 79.9%。同时，在鲁棒性基准数据集 IN-C、IN-P、IN-R 和 IN-A 上也观察到了显著的性能改进。当采用更先进的 FAN[116]模型作为骨干网络时，本方法同样展现出优异的性能表现，充分证明了其通用性和泛化能力。

进一步分析各方法的计算效率，表 5.1 详细对比了参数数量、GFLOPs 和推理时间等指标。实验发现，尽管 FAN 骨干网络在参数数量和计算复杂度方面具有优势，但其对 transformer 的非标准修改限制了模型的并行计算能力，导致推理时间显著增加。具体而言，FAN 在 GPU 上进行 100 次推理需要 20.8ms，而标准 ViT-Base 模型在相同条件下仅需 4.8ms。值得注意的是，基于 ViT-B 骨干网络的所提出方法在性能上超越了使用 FAN 的 SOTA 方法 TAPADL，例如在 ImageNet-C 数据集上的 mCE 指标从 43.7% 提升至 41.4%。基于这些发现，后续实验均采用标准的 ViT-Base 模型进行。

表 5.3 各方法在 ImageNet-C 测试集上 19 种退化的详细性能对比

方法	平均精确度	噪声			模糊				气候	
		高斯	散粒	脉冲	失焦	毛玻璃	运动	变焦	雪	霜
ViT-Base	59.20	59.27	56.39	58.44	51.20	45.29	58.39	46.01	43.09	44.78
FAN-B-H	65.75	67.70	67.18	67.98	57.95	47.20	62.58	56.11	64.79	63.34
TAPADL(FAN)	66.71	**67.83**	**68.94**	**68.73**	57.69	48.19	65.34	57.73	**65.71**	**64.87**
本章方法 (ViT-B)	**67.56**	64.79	63.05	63.55	**63.21**	**56.21**	**67.39**	**58.31**	61.75	61.51

方法	平均精确度	气候		数字				其他			
		雾	亮度	对比度	弹性形变	块像素化	JPEG 压缩	斑点噪声	高斯模糊	溅射效应	饱和度变化
ViT-Base	59.20	69.55	73.06	71.41	58.22	67.27	66.67	63.91	54.06	66.68	71.06
FAN-B-H	65.75	69.76	78.86	70.69	60.07	62.10	69.29	71.23	60.82	73.64	77.99
TAPADL(FAN)	66.71	70.92	79.25	71.52	60.48	65.71	70.26	**71.76**	60.13	**74.25**	**78.10**
本章方法 (ViT-B)	**67.56**	**74.49**	**79.78**	**73.50**	**64.17**	**74.53**	**72.17**	70.61	**65.27**	72.19	77.19

为深入分析所提出方法的性能特点，表 5.3 详细对比了 TAPADL 和所提出方法在 ImageNet-C 的 15 种退化类型下的详细表现。实验结果表明，TAPADL 由于增加了额外的卷积层，在处理基于噪声的失真时表现出明显优势，这主要归因于卷积操作引入的平滑效应。为验证这一假设，实验将 3x3 均值滤波器集成到所提出方法中进行对比。结果表明，所提出方法能够有效处理各种未见过的退化图像，而非局限于特定类型的退化，展现出更强的泛化能力。

中国知网 https://www.cnki.net

5.5.3 真实低质场景的目标检测结果

本节进一步在基准鲁棒性目标检测数据集上对所提出方法进行了全面评估，评估数据集包括：（1）COCO-C（基于 MS-COCO[27]构建，包含与 ImageNet-C 类似的图像退化类型）；（2）Foggy-CityScapes[29]（由 Cityscapes 数据集生成的合成雾霾图像）；（3）RTTS[31]（真实场景雾霾图像）；（4）ExDark[30]（真实场景低光图像）。实验采用目标检测任务中广泛使用的整体平均精度（mAP）作为评估指标。

在实验设置方面，对于合成基准数据集 COCO-C 和 Foggy-CityScapes，采用原始清晰图像进行训练，并在退化图像上进行测试。针对真实世界数据集 RTTS 和 ExDark，由于 COCO 与这些数据集共享类别标签，实验采用 COCO 数据集进行一致性训练，并在 RTTS 和 ExDark 上进行测试验证。检测模型的构建基于 `mmdet` 框架[127]，其中主干网络采用第 5.5.2 节中微调的模型，并包含完整的颈部 neck 特征提取模块和头部 head 分类及检测模块。为增强模型的鲁棒性，训练过程中引入了第 5.4.1 节描述的梯度扰动图像生成策略，同时特别增加了针对背景类别的扰动处理，以解决感兴趣区域（Region of Interest，ROI）被误分类为背景的常见问题。

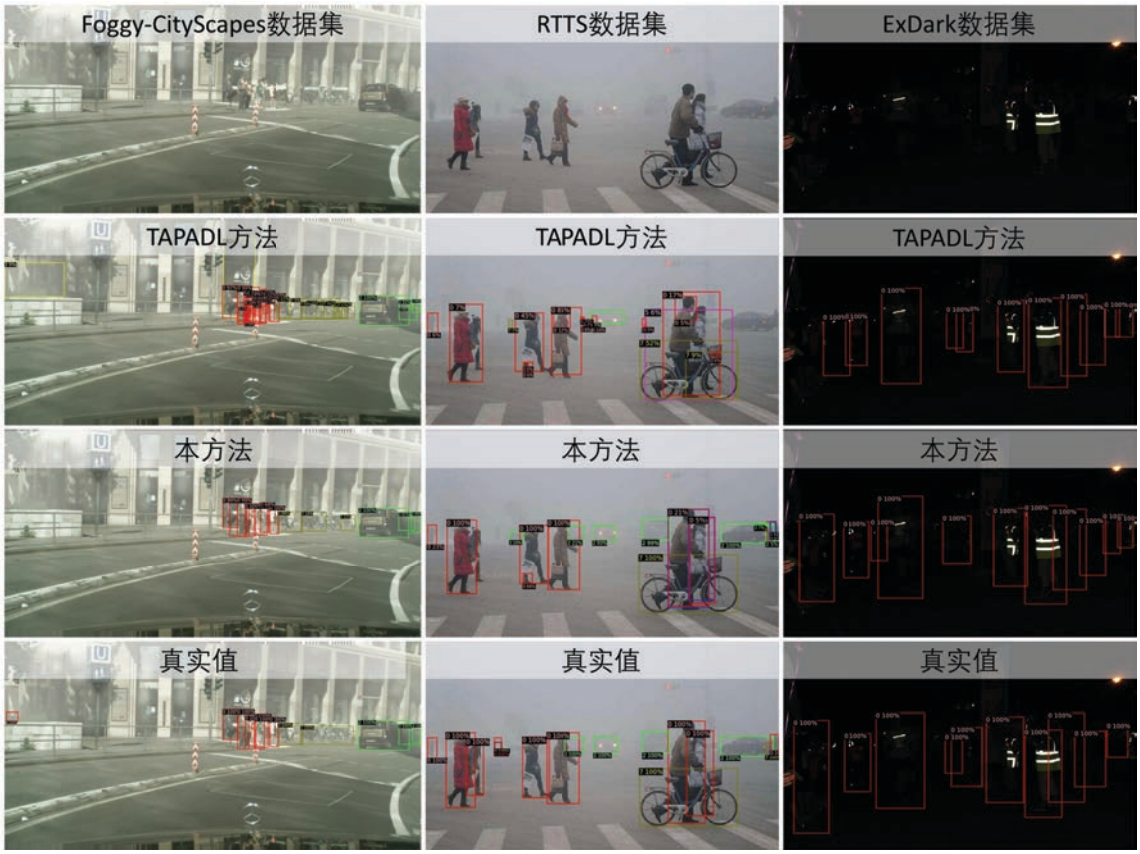


图 5.8　各方法在真实低质场景的目标检测结果对比展示

实验结果如表 5.4 所示，同时在图 5.8 中展示了 RTTS 和 ExDark 数据集上的典型检测结果可视化示例。通过对比分析可以得出以下重要发现：所提出的方法在目标

中国知网　https://www.cnki.net

表 5.4 各方法在真实低质场景的目标检测 mAP 性能对比

方法	COCO-C	Foggy-Cityscapes	RTTS	ExDark
FAN[116]	39.0	37.5	43.1	52.6
TAPADL[122]	40.2	38.3	43.7	53.4
本章方法	**41.7**	**39.1**	**44.5**	**54.3**

检测任务中展现出显著的性能优势，具体表现为：（1）在复杂退化条件下（如雾霾、低光照）的漏检率显著降低；（2）对遮挡和模糊目标的检测精度明显提升；（3）在保持较高召回率的同时，有效控制了误检率。这些改进主要归因于所提出方法在以下方面的优化：（1）通过梯度扰动训练增强了模型对退化特征的鲁棒性；（2）针对背景类别的特殊处理策略有效减少了漏检；（3）多尺度特征融合机制提高了对小目标和模糊目标的检测能力。实验结果表明，所提出方法在保持较高检测效率的同时，显著提升了在复杂场景下的目标检测性能。

5.5.4 消融实验及方法效率分析

在 (1) 节中，首先通过系统性的消融实验验证了所提出方法中各个组件的有效性。随后，(2) 节深入分析了公式 (5-8) 中关键超参数 k 和 α 对模型性能的影响机制。最后，(3) 节从理论和实验两个维度探讨了所提出方法能够在少量样本和有限迭代次数下取得显著性能提升的内在原因。

（1）方法各模块的验证分析

所提出方法包含两个核心组件：邻近类别梯度扰动机制和基于类间距离加权的损失函数。为深入探究扰动策略的有效性，设计了以下三个对比实验：

基线模型：采用未经微调的原始预训练 ViT-Base 模型作为基准，用于评估各改进组件的性能增益。

标准无目标对抗训练：该设置遵循传统对抗训练范式，如公式 (5-7) 所示，通过引入无特定目标的扰动，将模型预测推离真实标签，从而增强模型对任意对抗性变化的防御能力。

邻近类梯度扰动：如公式 (5-5) 所示，即本章方法，通过有目的地将模型预测引导至语义相似的邻近类别，实现更精准的扰动策略。这种设计充分利用了 5.3 节中观察到的现象：由于分布变化导致的错误预测通常发生在语义相近的类别之间。

此外，实验还验证了 5.4.3 节提出的基于类间距离加权损失函数的有效性。具体而言，对比分析了标准交叉熵损失与公式 (5-9) 定义的加权损失的性能差异。表 5.5 汇总了所有消融实验的结果，结果表明所提出的每个模块均对提升模型识别性能和鲁棒性具有显著贡献。

中国知网 https://www.cnki.net

表 5.5　本章方法的各模块对低质图像识别的性能验证

方法/模块	扰动目标	损失加权	IN (Acc) ↑	IN-C (mCE) ↓
基准模型	✗	✗	76.3	52.2
标准对抗训练	无特定目标	✗	77.6 (+1.3)	48.7 (-3.5)
仅近邻扰动	近邻类别	✗	79.1 (+2.8)	43.5 (-8.7)
本章方法	近邻类别	✓	**79.9** (+3.6)	**41.4** (-10.8)

表 5.6　超参数 k 和 λ 的消融性实验结果

精确度 α 取值 / k 取值	$\alpha=0.9$	$\alpha=0.7$	$\alpha=0.5$	$\alpha=0.2$	$\alpha=0.1$
$k=10$	47.1	48.3	51.3	50.7	50.1
$k=20$	49.5	50.1	**51.9**	51.2	50.8
$k=30$	50.1	51.2	51.7	51.0	50.3
$k=40$	50.2	50.6	51.5	50.4	29.7
$k=50$	50.4	50.9	51.4	50.8	50.1

（2）超参数 k 和 α 的设置选择

针对超参数 k 和 α 的选取，通过搜索策略对参数空间进行系统性探索。具体地，在退化严重度为 5 的运动模糊图像上进行快速验证实验。对于 k 和 α 分别进行了 $k=10, k=20, k=30, k=40, k=50$ 以及 $\alpha=0.9, \alpha=0.7, \alpha=0.5, \alpha=0.2, \alpha=0.1$ 等各自五种不同的设置，最终确定最优参数组合为 $k=20$ 和 $\alpha=0.5$。参数选择过程的详细实验结果见表 5.6，其中展示了不同参数配置下的模型性能变化。

（3）方法收敛性分析

在鲁棒分类实验中观察到，使用 ImageNet-1k 全部图像进行 10 个训练周期（约 1.28×10^7 次迭代）微调的结果与仅采用 5000 张图像（5000 次迭代）训练得到的结果相近。这一现象表明，所提出的方法能够通过少量样本和有限训练迭代有效提升预训练模型的鲁棒性。以下两个关键因素共同促成了这种高效性：

优化空间的约束：标准训练优化过程可表示为经验风险最小化问题：

$$\min_{\boldsymbol{\theta}} \mathbb{E}_{(\boldsymbol{x'},y)\in D}[\mathcal{L}(\boldsymbol{f_\theta}(\boldsymbol{x'}), y)] \tag{5-11}$$

与传统对抗训练（如式 (5-7)）相比，所提出的方法通过约束扰动方向，将对抗样本引导至邻近相似类别（即 $\boldsymbol{f_\theta}(\boldsymbol{x'})=y_p$，其中 y_p 与 y 语义相近），显著降低了优化空间的复杂性。这种约束机制带来以下优势：（1）对抗样本的学习难度降低，减少了所需的梯度更新次数；（2）将对抗扰动限制在较小范围内，使损失函数曲线更加平滑，从而提高了优化效率。

中国知网　https://www.cnki.net

损失惩罚的精细化：所提出的类间距离加权损失函数通过风险敏感机制优化了模型的学习过程。具体而言，该加权策略对类间距离较小的易混淆类别赋予更高权重，使模型优先增强对这些高风险区域的判别能力。这种自适应权重分配机制具有以下特点：（1）集中模型能力于关键决策边界；（2）减少对简单样本的过度拟合；（3）提高训练数据的利用效率。

上述两个机制的协同作用使得模型能够在少量训练数据和有限迭代次数的情况下实现鲁棒性提升，显著提高了训练效率。这一特性对于实际应用场景中的模型部署和更新具有重要意义。

进一步的，本章方法所带来的额外计算开销主要是对抗样本的生成部分。在这一过程中需要依据网络参数及输出重新计算类间相似度并进行多次梯度反向传播生成扰动。首先，本方法评估了三种类别相似度的拓扑构建策略：（a）仅在训练初始阶段计算一次相似度，并固定下来；（b）每个训练轮次（epoch）重新计算，（c）每次迭代（iteration）重新计算。在 IN-C 数据集上的对应 mCE 值（越低越好）分别为 $43.9, 42.2, 41.3$，额外的计算开销也对应的依次增加。最终，本章选择在图5.6的第一步中**直接对清晰样本的输出概率进行排序**以近似类别相似性，即概率第一大的作为最相似类别，以此类推，而非使用类别嵌入的向量乘法进行余弦相似度的计算。这种方式最终得到 41.4 的 mCE 结果。额外训练开销约为每张图像 $\sim 12ms$（其中相似度重计算耗时 $< 1ms$），额外的计算开销主要来自梯度反传添加扰动的过程，可通过减少扰动步数进行缓解（详见算法5.3）。总体而言，由于本算法采用微调策略，无需对大规模数据进行重新训练，其引入的额外计算开销亦保持在可接受范围内。

5.6 本章小结

本章提出了一种创新的鲁棒性增强方法，通过融合邻近类别梯度扰动机制和类间距离加权损失函数，有效提升了模型在真实场景下的鲁棒性表现。大量实验结果表明，本方法具有以下优势：显著增强了模型对分布偏移的适应能力；在合成退化数据集（如 ImageNet-C）和合成分布外数据集（如 ImageNet-D）上均取得了突破性性能提升，且能提升真实场景如雾、黑夜低光照的目标检测性能；具有良好的架构通用性，可适用于多种网络结构；仅需少量训练数据和较低计算成本即可实现显著性能提升。

从理论角度来看，邻近类别梯度扰动样本本质上属于易混淆类别（即难样本），而现有研究表明难样本的有效利用能够显著提升模型鲁棒性。基于这一发现，未来研究方向包括：开发更精细的难样本挖掘策略，以实现更有针对性的扰动样本生成；探索潜空间或流形正则化方法，增强模型对分布外（OOD）样本的鲁棒性；结合自监督学习策略，学习丰富的特征表示，进一步提升模型在有限标注数据下的鲁棒性表现。

中国知网 https://www.cnki.net

第六章　总结与展望

6.1 研究总结

在真实场景中，视觉图像的成像质量常受光照变化、恶劣天气、运动模糊以及传感器噪声等多种因素的影响，导致深度模型的识别能力大幅下降。相比于传统深度学习方法中训练数据与测试数据服从相同分布的目标识别算法，能够适应测试数据分布偏移，尤其是在低质量图像上保持稳定性能的目标识别算法，具有更突出的实际应用价值。因此，提高目标识别算法在低质量图像条件下的鲁棒性，成为保障计算机视觉系统有效性和稳定性的关键。

现有的基于低质量图像的目标识别方法主要包括图像重建、特征增强和数据增广等策略。图像重建方法通常依赖超分辨率、去噪、去模糊等技术提升图像质量，以降低退化对识别性能的影响。然而，这类方法往往需要高质量-低质量图像对作为监督信号，并且主要针对单一退化类型效果较优，在复杂、多变的退化条件下难以保证重建质量的稳定性。此外，由于重建过程与识别任务解耦，该方法需先进行图像复原再进行目标识别，导致计算开销较大。特征增强方法则通过设计特征重建监督损失，使模型直接在深度特征空间中恢复退化图像的语义信息，从而提升识别能力。然而，现有方法通常未能充分考虑不同特征区域的重要性，可能导致模型在学习过程中忽略关键判别性特征。数据增广方法则通过仿真退化生成多样化的训练样本，以提升模型对不同退化条件的适应能力。然而，由于仿真退化与真实退化仍存在分布差异，且当前方法尚缺乏对不同退化分布有效性的精确建模，这可能影响模型在实际应用场景中的泛化能力。因此，现有方法在面对真实复杂退化环境时仍存在泛化性不足、对特定退化类型依赖性较强等问题，限制了其在实际应用中的有效性。针对上述挑战，本文致力于提升目标识别模型在低质量图像上的鲁棒性，围绕特征不确定性建模、图像质量无关特征学习以及基于近邻类梯度扰动的对抗训练展开研究。具体而言，本文的主要研究内容和创新点如下：

1、本文首先针对基于特征增强的低质量图像识别方法所面临的特征重要性问题，提出了一种基于特征不确定性建模的自蒸馏方法。不同于传统的教师-学生框架，该方法在单个网络内实现自蒸馏，通过同时输入清晰图像与仿真退化图像，确保模型在提升低质量图像特征表达能力的同时，仍能保持对清晰图像的识别性能。此外，该方法引入不确定性建模，以适应低质量图像特征分布的波动性。对于难以恢复的区域或在识别任务中具有较高重要性的特征区域，自适应地提高蒸馏损失权重，引导模型聚焦于关键判别性特征。这一策略有效增强了低质量图像的特征重建能力，使模型在面

中国知网　https://www.cnki.net

对多种复杂退化条件时，依然能够保持卓越的识别性能。

2、针对现有方法对成对清晰-仿真退化图像训练的依赖问题，本文借鉴稀疏表示学习与向量量化的思想，提出了一种基于向量量化的图像质量无关特征表示学习方法。该方法在模型结构中引入码本模块，对提取的深层语义特征进行量化，从而降低退化图像特征中的噪声干扰，并提升其判别性。在特征融合过程中，进一步引入自注意力机制，使模型能够更精准地区分关键信息与无关干扰，从而增强特征表达能力。实验结果表明，该方法无需依赖成对的清晰-退化图像进行训练，即可在多个低质量图像数据集上取得优于现有方法的性能，展现出较强的泛化能力。

3、此外，针对数据增强及前述特征增强方法在处理低质量图像时对仿真退化数据的依赖性，本文提出了一种基于近邻类梯度扰动的对抗训练方法。首先，通过分布外数据的推理实验分析分类错误的分布特性，发现模型的错误预测主要集中在真实类别的相邻类。基于这一观察，本文在对抗训练过程中引入相邻类别的梯度信息来生成扰动样本，从而引导模型更关注易混淆类别之间的判别能力。同时，结合类间距离加权损失，进一步增强模型对难分类区域的区分能力。该方法在多个基准数据集和不同网络架构上均展现出优越的性能，不仅显著提升了模型的鲁棒性，还有效减少了特征增强方法中增强模块的额外计算开销，使训练与测试过程更加高效。

6.2 研究展望

低质量图像目标识别算法在实际应用系统中扮演着至关重要的角色，确保了系统在极端条件下的识别稳定性与鲁棒性。近年来，国内外研究者提出了多种创新的低质量图像识别方法，在识别准确率上取得了显著提升。尽管这些方法取得了显著成效，但仍然存在计算效率低、数据依赖性强、对判别性特征及数据分布认知不足等一系列问题。针对这些问题，本文提出的三种方法为鲁棒性目标识别领域提供了新的思路，并在不同层面上突破了现有方法的局限性。通过从特征建模、表示学习和对抗训练三个角度系统性地优化了模型在低质量图像环境下的表现，使其能够在更广泛的真实场景中稳定运行。本研究不仅为目标识别模型的鲁棒性提升提供了有效的解决方案，也为后续研究奠定了基础。然而，本文所提出的算法尚未解决低质量图像目标识别领域的所有问题，仍存在一定的局限性。展望未来，低质量图像目标识别领域仍有若干值得深入探索的方向：

1、针对本文提出的三种算法，仍有许多值得探索的问题：在基于不确定性建模的自特征蒸馏方法中，本文对特征的不确定性进行了估计，但尚未进一步尝试将该不确定性值作为模型输出的置信度指标。具体来说，当模型给出高不确定度的输出时，算法使用者可以选择拒绝该结果，这将使得算法更加实用。对于基于向量量化的图像质量无关特征表示学习算法，目前尚缺乏对表示系数的深入探索以及对码本利用率

中国知网 https://www.cnki.net

的研究。如何通过使用稍多的码本组元来实现更好的量化表示，并提升码本的使用效率，值得在后续研究中深入探讨。至于基于近邻梯度扰动的对抗训练方法，虽然本文提出了一种简易的类间距离加权损失函数，但如何生成更有效的扰动样本，利用困难样本挖掘技术，或使用更优的难样本加权损失函数（如 Focal-loss 等），也是未来研究的可能方向。

2、在本文撰写的阶段，基于扩散模型的数据生成方法在低质量图像目标识别领域展现出巨大的潜力。已有研究者构建了基于扩散生成的数据集，如 ImageNet-D 等。许多前沿研究聚焦于利用扩散模型生成多样化且具有一定分布差异的图像，作为数据增广手段，以提升模型的鲁棒性。同时，基于扩散模型的图像修复、去噪和超分辨率技术也已取得显著进展。因此，在训练阶段，如何生成与实际场景更为接近的图像，以有效提高模型对不确定性和干扰的适应能力，值得进一步探讨。同时，能否利用扩散模型的生成能力，直接补充低质量图像中丢失的判别性特征，仍是一个值得深入探索的方向。

3、在本文撰写的阶段，基于自然语言处理的大语言模型和多模态视觉-语言模型呈指数型增长。许多前沿研究聚焦于结合海量数据，利用更大的网络架构构建基础模型，如视觉基础模型 Dino、Dinov2 以及多模态视觉-语言模型 CLIP、Blip 等。本文作者对相关模型进行了初步探索，但由于计算量和硬件要求等方面的限制，探索仍显有限。如第五章所述，已知的是，相关视觉基础模型因在海量数据上进行训练，其鲁棒性极强，对于分布外数据的性能差异仅在 5% 10% 之间。如何进一步提升这些模型在低质量图像和极端场景中的适应能力，或者如何利用这些视觉基础大模型来显著提升小模型在低质量图像中的表现，仍是一个值得深入探讨的方向。

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net

参考文献

[1] LIANG J, CAO J, SUN G, et al. Swinir: Image restoration using swin transformer[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 1833-1844.

[2] CHEN L, CHU X, ZHANG X, et al. Simple baselines for image restoration[C]//European conference on computer vision. 2022: 17-33.

[3] LI B, LIU X, HU P, et al. All-in-one image restoration for unknown corruption[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 17452-17462.

[4] PEI Y, HUANG Y, ZOU Q, et al. Does haze removal help cnn-based image classification?[C]// Proceedings of the European conference on computer vision (ECCV). 2018: 682-697.

[5] LIU D, WEN B, LIU X, et al. When image denoising meets high-level vision tasks: A deep learning approach[J]. arXiv preprint arXiv:1706.04284, 2017.

[6] SON T, KANG J, KIM N, et al. Urie: Universal image enhancement for visual recognition in the wild[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part IX 16. 2020: 749-765.

[7] CUI Z, QI G J, GU L, et al. Multitask aet with orthogonal tangent regularity for dark object detection [C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 2553-2562.

[8] LIU W, REN G, YU R, et al. Image-adaptive YOLO for object detection in adverse weather conditions[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 36: 2. 2022: 1792-1800.

[9] LIU W, LI W, ZHU J, et al. Improving nighttime driving-scene segmentation via dual image-adaptive learnable filters[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2023, 33(10): 5855-5867.

[10] POTLAPALLI V, ZAMIR S W, KHAN S H, et al. Promptir: Prompting for all-in-one image restoration[J]. Advances in Neural Information Processing Systems, 2024, 36.

[11] WU R, YANG T, SUN L, et al. Seesr: Towards semantics-aware real-world image super-resolution [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 25456-25467.

[12] JIANG Y, ZHANG Z, XUE T, et al. Autodir: Automatic all-in-one image restoration with latent diffusion[C]//European Conference on Computer Vision. 2025: 340-359.

[13] TAN W, YAN B, BARE B. Feature super-resolution: Make machine see more clearly[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 3994-4002.

中国知网 https://www.cnki.net

[14] WANG Y, CAO Y, ZHA Z J, et al. Deep degradation prior for low-quality image classification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 11049-11058.

[15] KIM I, HAN S, BAEK J W, et al. Quality-agnostic image recognition via invertible decoder[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 12257-12266.

[16] ZHANG H. mixup: Beyond empirical risk minimization[J]. arXiv preprint arXiv:1710.09412, 2017.

[17] YUN S, HAN D, OH S J, et al. Cutmix: Regularization strategy to train strong classifiers with localizable features[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 6023-6032.

[18] HENDRYCKS D, MU N, CUBUK E D, et al. Augmix: A simple data processing method to improve robustness and uncertainty[J]. arXiv preprint arXiv:1912.02781, 2019.

[19] CUBUK E D, ZOPH B, MANE D, et al. Autoaugment: Learning augmentation strategies from data [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 113-123.

[20] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.

[21] ISLAM K, ZAHEER M Z, MAHMOOD A, et al. DiffuseMix: Label-Preserving Data Augmentation with Diffusion Models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 27621-27630.

[22] MADRY A. Towards deep learning models resistant to adversarial attacks[J]. arXiv preprint arXiv:1706.06083, 2017.

[23] MAO X, CHEN Y, DUAN R, et al. Enhance the visual representation via discrete adversarial training[J]. Advances in Neural Information Processing Systems, 2022, 35: 7520-7533.

[24] HENDRYCKS D, DIETTERICH T. Benchmarking neural network robustness to common corruptions and perturbations[J]. arXiv preprint arXiv:1903.12261, 2019.

[25] KRIZHEVSKY A, HINTON G, et al. Learning multiple layers of features from tiny images[J]. 2009.

[26] DENG J, DONG W, SOCHER R, et al. Imagenet: A large-scale hierarchical image database[C]// 2009 IEEE conference on computer vision and pattern recognition. 2009: 248-255.

[27] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft coco: Common objects in context[C]// European conference on computer vision. 2014: 740-755.

[28] CORDTS M, OMRAN M, RAMOS S, et al. The cityscapes dataset for semantic urban scene un-

中国知网 https://www.cnki.net

derstanding[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 3213-3223.

[29] SAKARIDIS C, DAI D, VAN GOOL L. Semantic foggy scene understanding with synthetic data [J]. International Journal of Computer Vision, 2018, 126: 973-992.

[30] LOH Y P, CHAN C S. Getting to know low-light images with the exclusively dark dataset[J]. Computer Vision and Image Understanding, 2019, 178: 30-42.

[31] LI B, REN W, FU D, et al. Benchmarking single-image dehazing and beyond[J]. IEEE Transactions on Image Processing, 2018, 28(1): 492-505.

[32] SAKARIDIS C, DAI D, VAN GOOL L. ACDC: The adverse conditions dataset with correspondences for semantic driving scene understanding[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10765-10775.

[33] WANG J, LAN C, LIU C, et al. Generalizing to unseen domains: A survey on domain generalization [J]. IEEE transactions on knowledge and data engineering, 2022, 35(8): 8052-8072.

[34] LONG M, CAO Y, WANG J, et al. Learning transferable features with deep adaptation networks [C]//International conference on machine learning. 2015: 97-105.

[35] GOODFELLOW I J, SHLENS J, SZEGEDY C. Explaining and harnessing adversarial examples [J]. arXiv preprint arXiv:1412.6572, 2014.

[36] HENDRYCKS D, BASART S, MU N, et al. The many faces of robustness: A critical analysis of out-of-distribution generalization[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 8340-8349.

[37] HENDRYCKS D, ZHAO K, BASART S, et al. Natural adversarial examples[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 15262-15271.

[38] ZAMIR S W, ARORA A, KHAN S, et al. Multi-stage progressive image restoration[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 14821-14831.

[39] LUO Z, GUSTAFSSON F K, ZHAO Z, et al. Controlling vision-language models for universal image restoration[J]. arXiv preprint arXiv:2310.01018, 2023, 3(8).

[40] LI Z, LEI Y, MA C, et al. Prompt-in-prompt learning for universal image restoration[J]. arXiv preprint arXiv:2312.05038, 2023.

[41] WANG L, WU C, WANG L. DAP-LED: Learning Degradation-Aware Priors with CLIP for Joint Low-light Enhancement and Deblurring[J]. arXiv preprint arXiv:2409.13496, 2024.

[42] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.

中国知网 https://www.cnki.net

[43] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. 2021: 8748-8763.

[44] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10684-10695.

[45] DICE L R. Measures of the amount of ecologic association between species[J]. Ecology, 1945, 26(3): 297-302.

[46] EVERINGHAM M, ESLAMI S M A, VAN GOOL L, et al. The Pascal Visual Object Classes Challenge: A Retrospective[J]. International Journal of Computer Vision, 2015, 111(1): 98-136.

[47] FARHADI A, REDMON J. Yolov3: An incremental improvement[C]//Computer vision and pattern recognition: vol. 1804. 2018: 1-6.

[48] LOPES R G, YIN D, POOLE B, et al. Improving robustness without sacrificing accuracy with patch gaussian augmentation[J]. arXiv preprint arXiv:1906.02611, 2019.

[49] CHEN G, PENG P, MA L, et al. Amplitude-phase recombination: Rethinking robustness of convolutional neural networks in frequency domain[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 458-467.

[50] LIU Z, LI S, WU D, et al. Automix: Unveiling the power of mixup for stronger classifiers[C]// European Conference on Computer Vision. 2022: 441-458.

[51] QIN H, JIN X, ZHU H, et al. Sumix: Mixup with semantic and uncertain information[J]. arXiv preprint arXiv:2407.07805, 2024.

[52] FANG H, HAN B, ZHANG S, et al. Data augmentation for object detection via controllable diffusion models[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2024: 1257-1266.

[53] BUCKMAN J, ROY A, RAFFEL C, et al. Thermometer encoding: One hot way to resist adversarial examples[C]//International conference on learning representations. 2018.

[54] SU D, ZHANG H, CHEN H, et al. Is robustness the cost of accuracy?–a comprehensive study on the robustness of 18 deep image classification models[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 631-648.

[55] BAI Y, MEI J, YUILLE A L, et al. Are transformers more robust than cnns?[J]. Advances in neural information processing systems, 2021, 34: 26831-26843.

[56] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.

[57] VAN DER MAATEN L, HINTON G. Visualizing data using t-SNE.[J]. Journal of machine learning research, 2008, 9(11).

中国知网 https://www.cnki.net

[58] CHEN L C, ZHU Y, PAPANDREOU G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 801-818.

[59] HE K, GKIOXARI G, DOLLÁR P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.

[60] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[61] REN S, HE K, GIRSHICK R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28: 91-99.

[62] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.

[63] TAN M, PANG R, LE Q V. Efficientdet: Scalable and efficient object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 10781-10790.

[64] MICHAELIS C, MITZKUS B, GEIRHOS R, et al. Benchmarking robustness in object detection: Autonomous driving when winter is coming[J]. arXiv preprint arXiv:1907.07484, 2019.

[65] KAMANN C, ROTHER C. Benchmarking the robustness of semantic segmentation models[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 8828-8838.

[66] CHO J H, HARIHARAN B. On the efficacy of knowledge distillation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 4794-4802.

[67] HEO B, KIM J, YUN S, et al. A comprehensive overhaul of feature distillation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 1921-1930.

[68] KENDALL A, GAL Y. What uncertainties do we need in bayesian deep learning for computer vision?[J]. arXiv preprint arXiv:1703.04977, 2017.

[69] ARDIZZONE L, KRUSE J, WIRKERT S, et al. Analyzing inverse problems with invertible neural networks[J]. arXiv preprint arXiv:1808.04730, 2018.

[70] RUSAK E, SCHNEIDER S, GEHLER P, et al. Adapting ImageNet-scale models to complex distribution shifts with self-learning[J]. arXiv preprint arXiv:2104.12928, 2021.

[71] BISHOP C M, QAZAZ C S. Regression with input-dependent noise: A Bayesian treatment[J]. Advances in neural information processing systems, 1997: 347-353.

[72] GOLDBERG P W, WILLIAMS C K, BISHOP C M. Regression with input-dependent noise: A Gaussian process treatment[J]. Advances in neural information processing systems, 1997, 10: 493-499.

[73] CHANG J, LAN Z, CHENG C, et al. Data uncertainty learning in face recognition[C]//Proceedings

中国知网 https://www.cnki.net

of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 5710-5719.

[74] GAL Y, GHAHRAMANI Z. Dropout as a Bayesian approximation: Insights and applications[C]// Deep Learning Workshop, ICML: vol. 1. 2015: 2.

[75] HE Y, ZHU C, WANG J, et al. Bounding box regression with uncertainty for accurate object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 2888-2897.

[76] LAKSHMINARAYANAN B, PRITZEL A, BLUNDELL C. Simple and scalable predictive uncertainty estimation using deep ensembles[J]. arXiv preprint arXiv:1612.01474, 2016.

[77] SHI Y, JAIN A K. Probabilistic face embeddings[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 6902-6911.

[78] ZAFAR U, GHAFOOR M, ZIA T, et al. Face recognition with Bayesian convolutional networks for robust surveillance systems[J]. EURASIP Journal on Image and Video Processing, 2019, 2019(1): 1-10.

[79] NEAL R M. Bayesian learning for neural networks: vol. 118[M]. Springer Science & Business Media, 2012.

[80] NING Q, DONG W, LI X, et al. Uncertainty-driven loss for single image super-resolution[J]. Advances in Neural Information Processing Systems, 2021, 34: 16398-16409.

[81] MAO C, GUPTA A, NITIN V, et al. Multitask learning strengthens adversarial robustness[C]// Computer Vision–ECCV 2020: 16th European Conference. 2020: 158-174.

[82] FIGUEIREDO M A. Adaptive Sparseness Using Jeffreys Prior.[C]//NIPS. 2001: 697-704.

[83] HUANG Y, SHEN P, TAI Y, et al. Improving face recognition from hard samples via distribution distillation loss[C]//European Conference on Computer Vision. 2020: 138-154.

[84] XIE S, GIRSHICK R, DOLLÁR P, et al. Aggregated residual transformations for deep neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1492-1500.

[85] KINGMA D P, BA J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.

[86] AHN S, HU S X, DAMIANOU A, et al. Variational information distillation for knowledge transfer [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 9163-9171.

[87] Ultralytics. ultralytics/yolov5: v7.0 - YOLOv5 SOTA Realtime Instance Segmentation[EB/OL]. 2022. https://doi.org/10.5281/zenodo.7347926.

[88] DODGE S, KARAM L. Understanding how image quality affects deep neural networks[C]//2016 eighth international conference on quality of multimedia experience (QoMEX). 2016: 1-6.

中国知网 https://www.cnki.net

[89] GEIRHOS R, TEMME C R M, RAUBER J, et al. Generalisation in humans and deep neural networks[J]. arXiv preprint arXiv:1808.08750, 2018.

[90] VASILJEVIC I, CHAKRABARTI A, SHAKHNAROVICH G. Examining the impact of blur on recognition by convolutional networks[J]. arXiv preprint arXiv:1611.05760, 2016.

[91] DODGE S, KARAM L. A study and comparison of human and deep learning recognition performance under visual distortions[C]//2017 26th international conference on computer communication and networks (ICCCN). 2017: 1-7.

[92] HINTON G, VINYALS O, DEAN J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv:1503.02531, 2015.

[93] XU T B, LIU C L. Data-distortion guided self-distillation for deep neural networks[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 33: 01. 2019: 5565-5572.

[94] ELAD M, AHARON M. Image denoising via sparse and redundant representations over learned dictionaries[J]. IEEE Transactions on Image processing, 2006, 15(12): 3736-3745.

[95] YANG J, WRIGHT J, HUANG T S, et al. Image super-resolution via sparse representation[J]. IEEE transactions on image processing, 2010, 19(11): 2861-2873.

[96] TURIAN J, RATINOV L, BENGIO Y. Word representations: a simple and general method for semi-supervised learning[C]//Proceedings of the 48th annual meeting of the association for computational linguistics. 2010: 384-394.

[97] GRAY R. Vector quantization[J]. IEEE Assp Magazine, 1984, 1(2): 4-29.

[98] VAN DEN OORD A, VINYALS O, et al. Neural discrete representation learning[J]. Advances in neural information processing systems, 2017, 30.

[99] BENGIO Y, LÉONARD N, COURVILLE A. Estimating or propagating gradients through stochastic neurons for conditional computation[J]. arXiv preprint arXiv:1308.3432, 2013.

[100] NASRABADI N M, KING R A. Image coding using vector quantization: A review[J]. IEEE Transactions on communications, 1988, 36(8): 957-971.

[101] CSURKA G, DANCE C, FAN L, et al. Visual categorization with bags of keypoints[C]//Workshop on statistical learning in computer vision, ECCV: vol. 1: 1-22. 2004: 1-2.

[102] MAO C, JIANG L, DEHGHANI M, et al. Discrete representations strengthen vision transformer robustness[J]. arXiv preprint arXiv:2111.10493, 2021.

[103] RAZAVI A, VAN DEN OORD A, VINYALS O. Generating diverse high-fidelity images with vq-vae-2[J]. Advances in neural information processing systems, 2019, 32.

[104] PENG J, LIU D, XU S, et al. Generating diverse structure for image inpainting with hierarchical VQ-VAE[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 10775-10784.

中国知网 https://www.cnki.net

[105] ESSER P, ROMBACH R, OMMER B. Taming transformers for high-resolution image synthesis [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 12873-12883.

[106] PENG Z, DONG L, BAO H, et al. Beit v2: Masked image modeling with vector-quantized visual tokenizers[J]. arXiv preprint arXiv:2208.06366, 2022.

[107] GU S, CHEN D, BAO J, et al. Vector quantized diffusion model for text-to-image synthesis[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10696-10706.

[108] BAHDANAU D. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.

[109] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.

[110] WOO S, PARK J, LEE J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.

[111] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[112] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.

[113] TOUVRON H, CORD M, DOUZE M, et al. Training data-efficient image transformers & distillation through attention[C]//International Conference on Machine Learning. 2021: 10347-10357.

[114] HE K, CHEN X, XIE S, et al. Masked autoencoders are scalable vision learners[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 16000-16009.

[115] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]// European conference on computer vision. 2020: 213-229.

[116] ZHOU D, YU Z, XIE E, et al. Understanding the robustness in vision transformers[C]//International Conference on Machine Learning. 2022: 27378-27394.

[117] MAO X, QI G, CHEN Y, et al. Towards robust vision transformer[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 12042-12051.

[118] RUSAK E, SCHOTT L, ZIMMERMANN R S, et al. A simple way to make neural networks robust against diverse image corruptions[C]//European Conference on Computer Vision. 2020: 53-69.

[119] ZHOU B, KHOSLA A, LAPEDRIZA A, et al. Learning deep features for discriminative localization[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 2921-2929.

[120] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-cam: Visual explanations from deep

中国知网 https://www.cnki.net

networks via gradient-based localization[C]//Proceedings of the IEEE international conference on computer vision. 2017: 618-626.

[121] VAPNIK V N. An overview of statistical learning theory[J]. IEEE transactions on neural networks, 1999, 10(5): 988-999.

[122] GUO Y, STUTZ D, SCHIELE B. Robustifying token attention for vision transformers[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 17557-17568.

[123] OQUAB M, DARCET T, MOUTAKANNI T, et al. Dinov2: Learning robust visual features without supervision[J]. arXiv preprint arXiv:2304.07193, 2023.

[124] ZHANG C, PAN F, KIM J, et al. Imagenet-d: Benchmarking neural network robustness on diffusion synthetic object[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 21752-21762.

[125] ROBBINS H, MONRO S. A stochastic approximation method[J]. The annals of mathematical statistics, 1951: 400-407.

[126] GUO Y, STUTZ D, SCHIELE B. Improving robustness of vision transformers by reducing sensitivity to patch corruptions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 4108-4118.

[127] CHEN K, WANG J, PANG J, et al. MMDetection: Open MMLab Detection Toolbox and Benchmark[J]. arXiv preprint arXiv:1906.07155, 2019.

中国知网 https://www.cnki.net



西安電子科技大學
XIDIAN UNIVERSITY

地址：西安市太白南路2号
邮编：710071
网址：www.xidian.edu.cn

中国知网 https://www.cnki.net