中国科学技术大学

博士学位论文



知识驱动的图像复原方法研究

作者姓名： 肖杰

学科专业： 数据科学（信息与通信工程）

导　　师： 查正军 教授

完成时间： 二〇二五年五月二十九日

中国知网 https://www.cnki.net

University of Science and Technology of China

A dissertation for doctor's degree



Research on Knowledge-driven Image Restoration Methods

Author: Xiao Jie

Speciality: Data Science (Information and Communication Engineering)

Supervisor: Prof. Zha Zheng-Jun

Completion date: May 29, 2025

中国知网 https://www.cnki.net

创新性说明

图像复原是计算机视觉领域的重要研究方向。本文面向图像复原提出知识驱动的创新方法。（1）针对自注意力复原模型中平移不变性缺失的问题，提出了基于随机偏移窗口的自注意力，通过局部关联性知识和平移不变性知识的驱动，实现了高精度的图像复原效果；（2）针对自注意力复原模型缺乏结构感知和复杂度高的问题，提出了内容-结构协同的多尺度自注意力，通过内容-结构知识和多尺度关联知识的驱动，实现了在复杂退化场景下高保真的图像复原；（3）针对自注意力复原模型缺乏退化噪声分布不均匀而难建模的问题，提出了基于随机置换的自注意力，通过同质化排列知识和非局部关联性知识的驱动，提升了非均匀退化的图像复原精度；（4）针对退化过程繁杂而泛化性差的问题，提出了概率引导的通用图像复原推理采样方法，通过引入与退化过程无关的图像知识，实现了对未知类型低质量图像的有效复原。部分研究成果发表于 T-PAMI、NeurIPS、CVPR 等 CCF-A 类国际期刊和会议。1 篇论文入选 ESI 高被引论文、热点论文。

中国知网 https://www.cnki.net

摘要

图像复原作为计算机视觉领域的重要研究方向，近年来在理论方法与实际应用层面均获得持续关注。随着深度学习技术在视觉表征学习领域的突破性进展，基于数据驱动的图像复原方法已取得显著的性能提升。然而，现有方法仍面临着图像内容结构复杂和退化干扰过程繁杂的挑战，前者源于采集场景的多样性以及采集条件的差异性，如光照条件、设备参数等变量因素，后者体现在不同类型的退化过程具有独特的物理机制，且多种退化模式可能同时出现，这两类问题显著增加了图像复原问题的求解难度。

针对上述挑战，本文提出基于知识驱动的图像复原方法，从图像内蕴先验知识驱动和预训练模型外源知识驱动两个维度展开研究。首先，建立图像复原计算模型的层次化表征机制，构建多层级感知计算模型，通过挖掘图像空间中的跨尺度和多维度的内容结构知识，增强了模型对图像内容结构的感知能力与噪声模式判别能力，提升了模型的鲁棒性能；其次，基于在大规模清晰图像数据上预训练的扩散模型，提出了概率引导的图像先验知识驱动方法。通过对退化过程无关的清晰图像先验知识的挖掘，增强了模型对未知退化过程的泛化能力，提升了模型的适应性能。本文主要研究工作如下：

（1）基于随机窗口自注意力的图像复原方法。基于自注意力的图像复原模型在局部尺度关系建模和退化位置的平移不变性方面存在缺陷。该工作分析发现，造成该缺陷的原因是引入了固定偏移的局部窗口，破坏了图像局部窗口间的等价性，进而影响了局部尺度依赖关系的提取与建模。针对此问题，探索面向自注意力计算的窗口偏移策略，通过引入偏移分布替代固定偏移值，实现了任意偏移窗口的等价处理，从而补偿了局部信息和平移不变性的缺失。进一步，将所设计的随机窗口策略与自注意力结合，构建了随机窗口自注意力计算模型，并为其提出了定制的训练和推理策略。理论上研究了随机偏移窗口划分策略对感受野的修正效应，实验验证了随机窗口自注意力在多种图像复原任务中的性能优势。

（2）基于多尺度协作自注意力的图像复原方法。传统的基于自注意力的图像复原模型存在难以建模图像结构信息、捕捉图像全局上下文关系时复杂度高的问题。为此，该工作提出了一种内容-结构双分支协作的新型计算机制。以局部-全局的多尺度知识为引导，设计了窗内-窗间互补的自注意力，兼顾局部信息的精确提取与全局上下文建模能力，增强了图像复原模型的多尺度协作表征能力，最终实现了对内容-结构知识和多尺度知识联合驱动的图像复原方法，并在多个图像复原基准数据集上验证了所提出方法的有效性。此外，所提出的内容-结构与局部-全局建模的范式为设计更先进的图像复原模型提供了新的思路。

中国知网 https://www.cnki.net

（3）基于随机置换自注意力的图像复原方法。该工作发现了退化噪声在图像空间中的非均匀分布与主流图像复原模型中的权重共享机制不兼容的问题。为了解决这一问题，该工作设计了互逆的随机函数：随机置换和逆随机置换函数，并构造了图像空间到同质化空间的映射，有效规避了权重共享机制与噪声非均匀分布的冲突。理论分析表明，随机置换函数能够突破局部窗口划分对建模距离的限制。基于此，构建了高效的稀疏自注意力机制，增强了模型在建模标记（Token）间长程依赖关系的能力，实现了对同质化知识和非局部关联知识联合驱动的图像复原方法。该工作从局部性先验知识出发，结合局部窗自注意力和稀疏自注意力，构建了混沌窗口自注意力的基础计算模块。在图像去阴影的基准数据集上验证了同质化空间中自注意力处理非均匀分布噪声的有效性，且在多个图像复原基准数据集上的实验结果验证了所提出的混沌窗口自注意力的有效性。

（4）预训练扩散模型先验引导的图像复原方法。基于在预训练扩散模型中关于图像质量的概率假设，该工作提出了一种推理阶段的图像复原方法。在推理阶段，该方法提升图像在预训练扩散模型中隐变量表征的概率，以图像隐变量表征的概率为媒介，引入了与退化过程无关的清晰图像先验知识，有效地缓解了判别式图像复原方法泛化性差的问题。具体而言，核心设计是一种概率引导的图像复原推理采样算法。该采样算法以提升图像隐变量表征的概率为代理，挖掘并利用扩散模型在大规模数据集上预训练获取的图像先验知识。同时，该采样算法可以兼容已知退化过程和未知退化过程两种场景。理论分析证明，所提出的采样算法能够稳定提升图像在扩散模型中的概率，并收敛到高概率集合。实验结果表明，所提出的方法无需依赖具体退化过程，也不需要专门的配对数据监督训练，能有效地应对多种退化类型，实现高泛化的图像复原效果。

综上，本文从内蕴先验和外源知识的角度，探索了知识驱动的图像复原方法，提升了图像复原模型的表征能力和泛化能力。在多个图像复原基准数据集上的实验结果验证了所提出方法的优越性，为基于深度学习的图像复原方法的进一步研究提供了新的视角和思路。

关键词：图像复原；自注意力；多尺度表征；扩散模型；深度学习

中国知网 https://www.cnki.net

ABSTRACT

Image restoration, as a vital research direction in computer vision, has garnered sustained attention in both theoretical development and practical applications in recent years. With the breakthrough progress of deep learning in visual representation learning, data-driven image restoration methods have achieved significant performance improvements. However, existing approaches still face challenges arising from the complexity of image content structures and the intricacy of degradation processes. The former stems from the diversity of acquisition scenarios and the variability of capture conditions, such as lighting environments and device parameters. The latter lies in the fact that different types of degradation follow distinct physical mechanisms, and multiple degradation patterns may co-occur. These two categories of issues substantially increase the difficulty of solving image restoration tasks.

To address the aforementioned challenges, this study proposes a knowledge-driven approach to image restoration, exploring two dimensions: intrinsic knowledge derived from image priors and extrinsic knowledge introduced by pretrained models. First, a hierarchical representation mechanism for image restoration is established, leading to the construction of a multi-level perceptual computing model. By mining cross-scale and multi-dimensional content structure knowledge within the image space, the model's capabilities in perceiving image structures and distinguishing noise patterns are enhanced, thereby improving its robustness. Second, based on diffusion models pretrained on large-scale high-quality image datasets, a probabilistic prior-guided image restoration method is proposed. By leveraging degradation-independent priors learned from clean images, the model's generalization ability to unknown degradation processes is significantly strengthened, resulting in improved adaptability. The main contributions of this work are as follows:

(1) Stochastic Window Self-attention for Image Restoration. Self-attention-based image restoration models exhibit limitations in modeling local-scale dependencies and maintaining translation invariance at degraded regions. This study identifies the root cause of these limitations as the use of fixed-offset local windows, which disrupts the equivalence between image regions and impairs the extraction and modeling of local-scale relationships. To address this issue, a window offset strategy tailored for self-attention is explored. By introducing a distribution of offsets in place of fixed values, the proposed method enables equivalent processing across arbitrarily shifted windows,

中国知网 https://www.cnki.net

thereby compensating for the loss of local information and translation invariance. Building on this strategy, a randomized window self-attention mechanism is developed, along with dedicated training and inference procedures. Theoretically, the effect of random offset windows on receptive field adjustment is analyzed. Experiments demonstrate the superior performance of the proposed method across various image restoration tasks.

(2) Multi-Scale Collaborative Self-attention for Image Restoration. Conventional self-attention-based image restoration models face challenges in effectively modeling image structural information and suffer from high computational complexity when capturing global contextual dependencies. To address these issues, this work proposes a novel content-structure dual-branch collaborative computation mechanism. Guided by multi-scale knowledge at both local and global levels, a complementary self-attention design is introduced, incorporating both intra-window and inter-window interactions. This design enables accurate extraction of local details while enhancing the modeling of global context, thereby improving the model's capability for multi-scale collaborative representation. The resulting method achieves image restoration driven jointly by content-structure knowledge and multi-scale contextual cues. Extensive experiments on multiple benchmark datasets validate the effectiveness of the proposed approach. Moreover, the introduced paradigm of content-structure and local-global modeling offers new insights for developing more advanced image restoration models.

(3) Random Shuffle Self-attention for Image Restoration. This work identifies an incompatibility between the non-uniform spatial distribution of degradation noise and the weight-sharing mechanisms commonly employed in mainstream image restoration models. To address this issue, two mutually invertible random functions, Random Shuffle and Inverse Shuffle , are designed to construct a mapping from the image space to a homogenized space. This mapping effectively mitigates the conflict between weight sharing and noise non-uniformity. Theoretical analysis shows that the Random Shuffle function overcomes the modeling distance limitation imposed by local window partitioning. Building on this foundation, an efficient sparse self-attention mechanism is developed to enhance the model's capability in capturing long-range dependencies among tokens, enabling an image restoration framework jointly driven by homogenized knowledge and non-local correlations. Grounded in the prior of locality, the proposed method integrates local window self-attention with sparse self-attention to form the core computational module of Chaotic Window Self-Attention. Experiments on standard shadow removal datasets demonstrate the effectiveness of the proposed self-attention mechanism in handling non-uniform noise within the homogenized space, and extensive eval-

中国知网 https://www.cnki.net

uations on multiple image restoration benchmarks further validate the effectiveness of Chaotic Window Self-Attention.

(4) Image Restoration Guided by Prior Knowledge from Pre-Trained Diffusion Models. Based on the probabilistic assumption of image quality embedded in pretrained diffusion models, this work proposes an image restoration method applied during the inference stage. In the inference phase, the method improves the probability of the latent representation of the image under the pretrained diffusion model. By leveraging the probability of the image's latent representation as a medium, degradation-independent priors of clean images are introduced, effectively alleviating the poor generalization issue commonly observed in discriminative image restoration approaches. Specifically, the core design is a probabilistic-guided inference sampling algorithm for image restoration. This sampling algorithm enhances the probability of the image's latent representation as a surrogate objective, thereby extracting and utilizing prior knowledge learned by the diffusion model through pretraining on large-scale datasets. Moreover, the algorithm is compatible with both known and unknown degradation scenarios. Theoretical analysis proves that the proposed sampling strategy can stably increase the probability of the image within the diffusion model and converge to a high-probability set. Experimental results demonstrate that the proposed method does not rely on specific degradation models or paired supervised training data, and it is capable of handling various degradation types effectively, achieving high generalization in image restoration tasks.

In summary, this dissertation explores knowledge-driven image restoration methods from the perspectives of intrinsic priors and extrinsic knowledge, thereby enhancing the representational and generalization capabilities of image restoration models. Experimental results on multiple benchmark image restoration datasets validate the superiority of the proposed approaches, offering new perspectives and insights for the further development of deep learning-based image restoration methods.

KEY WORDS: Image Restoration, Self-Attention, Multi-scale Representation, Diffusion Model, Deep Learning

中国知网 https://www.cnki.net

目 录

第 1 章 引言.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 判别式图像复原方法.....3
1.2.2 生成式图像复原方法.....5
1.2.3 图像复原面临的挑战.....7
1.3 研究内容与主要贡献.....8
1.4 论文结构.....12
第 2 章 基于随机窗口自注意力的图像复原方法.....13
2.1 概述.....13
2.2 背景.....15
2.2.1 视觉 Transformer.....15
2.2.2 自注意力.....16
2.3 方法设计.....18
2.3.1 随机窗口自注意力.....19
2.3.2 随机窗口策略的建模范围分析.....21
2.4 实验结果与分析.....23
2.4.1 基本设置.....24
2.4.2 实验结果.....26
2.4.3 分析实验.....29
2.5 本章小结.....33
第 3 章 基于多尺度协作自注意力的图像复原方法.....34
3.1 概述.....34
3.2 背景.....36
3.3 方法设计.....37
3.3.1 内容-结构双分支自注意力.....38
3.3.2 前馈网络.....41
3.3.3 窗内-窗间自注意力.....41
3.3.4 整体网络架构.....43
3.4 实验结果与分析.....45
3.4.1 实现细节.....45
3.4.2 实验结果.....45
3.4.3 消融实验.....50
3.5 本章小结.....56

中国知网 https://www.cnki.net

第 4 章 基于随机置换自注意力的图像复原方法 57
4.1 概述 58
4.2 方法设计 62
4.2.1 随机置换函数与逆随机置换函数 62
4.2.2 同质化空间自注意力 63
4.2.3 结构增强的前馈网络 64
4.2.4 Homo Former 模型架构 65
4.2.5 混沌窗口自注意力 66
4.2.6 训练策略 70
4.2.7 推理策略 70
4.2.8 复杂度分析 72
4.2.9 Homo Former-Local 模型架构 73
4.3 实验结果与分析 73
4.3.1 实验设置 73
4.3.2 空间非均匀分布的图像退化去除 76
4.3.3 更多图像复原任务 80
4.4 本章小结 90
第 5 章 预训练扩散模型先验引导的图像复原方法 91
5.1 概述 92
5.2 背景 94
5.2.1 扩散模型 94
5.3 方法设计 95
5.3.1 一致性设计 97
5.3.2 真实性设计 97
5.3.3 结合两者 101
5.4 实验结果与分析 103
5.4.1 实验设置 103
5.4.2 已知退化过程的图像复原 103
5.4.3 未知退化过程的图像复原 104
5.4.4 实际应用的拓展 107
5.4.5 概率提升的验证 108
5.4.6 消融实验 109
5.4.7 讨论 110
5.5 本章小结 115
第 6 章 总结与展望 116
6.1 论文总结 116
6.2 未来展望 118
参考文献 120

中国知网 https://www.cnki.net

插图和附表清单

图 1.1 图像信息处理与分析是人工智能领域的重要任务 2
图 1.2 图像复原面临的挑战 7
图 1.3 主要研究内容 9
图 1.4 全文组织结构 12

图 2.1 固定窗口策略破坏窗口的等价性和损失局部关系的示意图 14
图 2.2 随机偏移的局部窗口示意图 18
图 2.3 随机窗口策略的有效感受野示意图 22
图 2.4 固定窗口策略和随机窗口策略的感受野对比图 22
图 2.5 模型结构框架图 24
图 2.6 不同方法图像去雨视觉效果 27
图 2.7 不同方法图像去噪视觉效果 28
图 2.8 不同方法图像去模糊视觉效果 29
图 2.9 平移不变性的验证 29
图 2.10 固定窗口策略和滑动窗口策略对比图 32
图 2.11 不同策略的特征图可视化 32
图 2.12 性能与计算的平衡 33
图 2.13 训练损失变化图 33
图 2.14 PSNR 变化图 33

图 3.1 内容-结构双分支自注意力的计算图 38
图 3.2 窗内自注意力和窗间自注意力互补感受野的示意图 41
图 3.3 模型架构图 44
图 3.4 在 Rain200H 数据集上的图像去雨视觉效果 47
图 3.5 在 Rain200L 数据集上的图像去雨视觉效果 48
图 3.6 在 SPA-Data 数据集上的图像去雨视觉效果 49
图 3.7 在 Internet-Data 数据集上的图像去雨视觉效果 49
图 3.8 在 RainDS-Syn 数据集上的图像去雨视觉效果 49
图 3.9 在 SIDD 数据集上的图像去噪视觉效果 50
图 3.10 特征图的可视化 51
图 3.11 内容建模分支和结构建模分支的滤波特性分析 52
图 3.12 窗间自注意力的注意力图的可视化 53
图 3.13 模型参数量对性能的影响 55

中国知网 https://www.cnki.net

图 3.14 窗间自注意力的相对位置编码的可视化 55

图 4.1 图像阴影在空间分布不均匀的建模难点示意图 59
图 4.2 偏移窗口自注意力和混沌窗口自注意力的对比图 60
图 4.3 同质化空间自注意力计算图 64
图 4.4 结构增强的前馈网络层的计算图 64
图 4.5 HomoFormer 模型结构图 65
图 4.6 基于随机置换的自注意力的训练策略示意图 70
图 4.7 基于随机置换的自注意力的推理策略示意图 71
图 4.8 HomoFormer-Local 的模型结构图 73
图 4.9 在 ISTD+ 数据集的图像去阴影视觉效果 77
图 4.10 在 SRD 数据集的图像去阴影视觉效果 77
图 4.11 在 SBU 数据集上的图像去阴影视觉效果 78
图 4.12 特征可视化 79
图 4.13 蒙特卡洛采样样本数量的影响 80
图 4.14 不确定度分布和误差分布的可视化 81
图 4.15 基于 SPA-Data 数据集的图像去雨视觉效果 83
图 4.16 在 SIDD 数据集的图像去噪的视觉效果 84
图 4.17 基于 GoPro 数据集的图像去模糊视觉效果 86
图 4.18 性能与推理时间的权衡 87
图 4.19 窗口尺寸对性能的影响 88
图 4.20 偏移窗口多头自注意力和混沌窗口自注意力的建模范围对比图 88
图 4.21 随机置换扩展到卷积神经网络 89

图 5.1 方法概览图 93
图 5.2 已知退化过程场景下的采样算法示意图 96
图 5.3 未知退化过程场景下的采样算法示意图 96
图 5.4 保方差采样算法示意图 103
图 5.5 保方差采样提升隐变量概率示意图 103
图 5.6 已知退化过程场景下在多个图像复原任务上的复原效果图 105
图 5.7 已知退化过程场景下在傅里叶相位恢复上的复原效果图 105
图 5.8 附带噪声的图像超分的视觉效果图 108
图 5.9 JPEG 压缩伪影矫正的视觉效果图 109
图 5.10 在多种图像复原任务上的视觉效果图 110
图 5.11 在实际的图像复原应用的效果图 110
图 5.12 隐变量的可视化 111

中国知网 https://www.cnki.net

图 5.13 不同 η_g 策略对性能的影响 111
图 5.14 基于 Stable Diffusion 的图像超分和去噪效果图 112
图 5.15 基于 Stable Diffusion 的 JPEG 压缩伪影矫正效果图 113
图 5.16 在未知退化过程场景下的多种图像复原任务的复原效果图 114
图 5.17 复原失败的案例 115

表 2.1 在 SPA-Data 数据集上的图像去雨定量结果 25
表 2.2 在 GoPro 数据集上的图像去模糊定量结果 26
表 2.3 图像去噪的定量结果 26
表 2.4 不同策略训练阶段的时间复杂度和空间复杂度 30
表 2.5 不同策略推理阶段的时间复杂度和空间复杂度 30

表 3.1 在基准数据集上图像去雨定量结果 47
表 3.2 在 RainDS 数据集上的定量结果 48
表 3.3 在 AGAN-Data 数据集上的图像去雨滴定量结果 48
表 3.4 在 SIDD 数据集上的图像去噪定量结果 49
表 3.5 结构建模分支的消融分析 52
表 3.6 最大建模距离对性能影响 52
表 3.7 窗间自注意力的消融分析 54
表 3.8 归一化类型的消融分析 54
表 3.9 推理时间和 FLOPs 对比 55

表 4.1 训练阶段不同自注意力机制的复杂度 72
表 4.2 推理阶段不同自注意力机制的复杂度 72
表 4.3 在 SRD 数据集上的图像去阴影定量结果 74
表 4.4 在 ISTD+ 数据集上的图像去阴影的定量结果 75
表 4.5 在 ISTD 数据集上图像去阴影的定量结果 77
表 4.6 基于 ISTD+ 数据集的消融实验 79
表 4.7 在 SPA-Data 数据集上的图像去雨的定量结果 82
表 4.8 在 SIDD 数据集上图像去噪的定量结果 82
表 4.9 在 GoPro 数据集上图像去模糊的定量结果 85
表 4.10 在 SIDD 数据集上的结构建模消融研究 86
表 4.11 本文方法在 SIDD 数据集上图像去噪性能对比 87

表 5.1 已知退化过程场景下在 ImageNet 数据集上图像复原的定量结果 ... 104
表 5.2 已知退化过程场景下在 CelebA 数据集上图像复原的定量结果 104
表 5.3 在 CelebA 数据集上附加高斯噪声的图像超分的定量结果 107

中国知网 https://www.cnki.net

表 5.4　在 ImageNet 数据集上附加高斯噪声的图像超分的定量结果 …… 107
表 5.5　在 CelebA 数据集上 JPEG 压缩伪影矫正的定量结果 …… 108
表 5.6　在 LSUN bedroom 数据集上的 JPEG 压缩伪影矫正的定量结果 …… 108
表 5.7　在 SIDD 数据集上的图像去噪定量结果 …… 109
表 5.8　η_l 和 η_g 策略的消融结果 …… 111

中国知网　https://www.cnki.net

符号与缩略语说明

MSA, Multi-head Self-Attention　多头自注意力

FFN, Feed-Forward Network　前馈网络

Dconv, Depth-wise convolution　逐通道卷积

MLP, Multi-Layer Perceptron　多层感知机

SDE, Stochastic Differential Equation　随机微分方程

ODE, Ordinary Differential Equation　常微分方程

$\boldsymbol{y}$　退化图像

$\boldsymbol{x}$　清晰图像

$\hat{\boldsymbol{y}}$　复原图像

$s \times s$　局部窗口尺寸

$H \times W$　图像分辨率

C　标记的维度

DBMSA　双分支多头自注意力

W-MSA　局部窗口多头自注意力

HomoMSA　同质化空间多头自注意力

$\mathrm{Par}(\cdot)$　局部窗口划分函数

$\mathcal{G}(\cdot)$　退化过程的函数

$\mathcal{F}(\cdot)$　复原模型的函数

$\mathcal{S}(\cdot)$　随机置换函数

$\mathcal{I}(\cdot)$　逆随机置换函数

$\boldsymbol{\epsilon}_\theta(\cdot)$　扩散模型的去噪模型

$\mathcal{L}(\cdot)$　损失函数

$\mathrm{softmax}(\cdot)$　softmax 函数

$\mathrm{GELU}(\cdot)$　GELU 函数

$\mathrm{concat}(\cdot)$　张量拼接函数

$\mathbb{E}[\xi]$　随机变量 ξ 的数学期望

$\sum_{i=1}^{n} a_i$　序列 $\{a\}_{i=1}^{i=n}$ 累计求和

中国知网　https://www.cnki.net

第 1 章　引言

1.1　研究背景及意义

随着成像技术、通信技术和云计算技术的飞速发展，现代社会每天都在不断产生海量的图像数据。如图 1.1 所示，这些图像涵盖了各个领域和场景，例如摄影、医疗影像、自动驾驶、交通监控、安全监控以及无人机侦察等。图像不仅仅是信息的载体，它们在当今信息化社会中扮演着至关重要的角色。图像作为一种重要的信息媒介，广泛应用于各个行业，帮助人类更好地理解和应对复杂的现实世界。例如，在医疗领域，医学影像的分析对于疾病的早期诊断和治疗方案的选择至关重要；在自动驾驶系统中，实时获取并分析环境图像是确保行车安全的关键；在安全监控和交通管理中，图像和视频监控技术能够帮助及时发现异常情况并采取有效措施。从人类感知角度来看，视觉系统是最主要的感官之一，人体通过眼睛获取的视觉信息占据了感官信息的绝大部分。事实上，视觉不仅仅是感知周围环境的工具，还是理解世界的重要途径。人类大脑能够通过对图像信息的解析，识别物体、判断距离、分析场景等，这使得图像在认知和决策过程中占据了核心地位。因此，图像的质量和处理效果直接影响到人类对外部世界的理解和对复杂问题的解决能力。

在图像采集过程中，图像质量往往受到多种退化干扰因素的影响，这些因素会显著降低图像的可用性和清晰度。例如，设备抖动或被摄对象的运动是常见的影响因素之一。在动态场景下，摄像设备的轻微抖动或目标的快速移动可能导致图像的模糊，使得细节难以辨识。这种模糊现象不仅影响观感，还给后续的图像分析任务，如目标检测和识别，带来了困难；图像压缩是一种常见的退化因素。为了降低图像的存储和传输成本，常常采用图像压缩技术，然而，压缩过程可能会导致图像细节的丢失，尤其是在高压缩比的情况下。压缩过程中，图像的色彩、纹理和形状等细节信息可能被损害，进一步降低了图像的质量，此外，压缩后的图像还可能出现明显的伪影，这对于后续图像分析及视觉计算任务构成了严重挑战；设备老化也是影响图像质量的一个重要因素。随着使用时间的增长，摄像设备的光学组件和传感器可能会发生退化，这可能导致图像分辨率的降低，图像中噪声水平的增加，甚至颜色失真。例如，镜头的老化可能导致光学畸变，传感器的退化则可能使得图像信噪比降低，进而影响图像的清晰度和真实还原度；恶劣的天气条件，如雨、雪和雾霾等，对光学系统的干扰也是一个不可忽视的因素，强降水、积雪或雾霾天气会显著减弱传感器捕捉到的光线，导致图像的亮度降低和对比度减弱，甚至可能造成关键物体的遮挡或完全消失。在这种情况下，图像处理系统可能难以准确地提取出有用信息，影响后续分析结果的准确性。这

中国知网　https://www.cnki.net

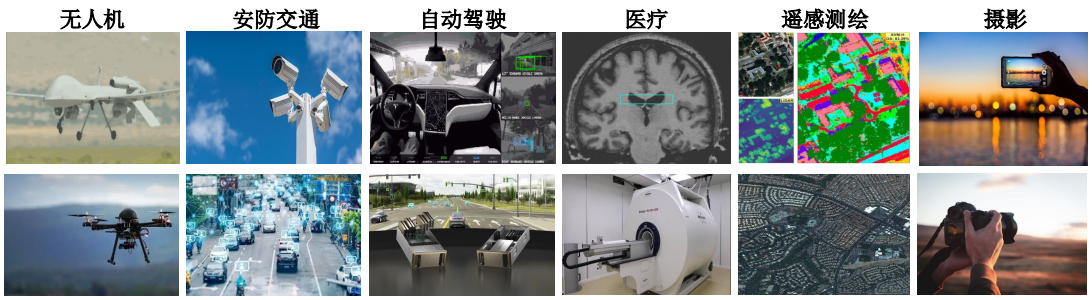


图 1.1　图像信息处理与分析是人工智能领域的重要任务

些退化因素不仅影响图像的主观视觉效果，还会直接干扰图像处理与分析系统的性能，导致检测、识别和分类任务的准确率下降。特别是在涉及安全监控、医学影像、自动驾驶等关键应用领域，图像质量的退化可能限制了系统在各种复杂环境中的应用效果。因此，如何有效地修复这些退化因素，提高图像质量，成为了当前图像处理研究中的一个重要课题。

全球科技公司也持续投入对图像复原和增强技术的研究与开发。例如，NVIDIA 推出基于深度学习的超采样技术（Deep Learning Super Sampling，DLSS），在游戏、实时渲染、虚拟现实等领域有广泛应用；Adobe Photoshop 基于深度学习技术，实现了图像中的损坏或缺失部分的自动修复；阿里巴巴联合国际奥委会 IOC 通过技术对奥运历史人物的老照片和视频影像进行修复与上色并发布了奥运主题影片《To the Greatness of HER》；华为智能手机利用 AI 技术优化图像拍摄，实现在低光环境、快速抓拍等条件下拍摄清晰照片。同时，《中华人民共和国国民经济和社会发展第十四个五年规划和 2035 年远景目标纲要》中提出的科技前沿领域攻关指引相契合，特别是在图像图形领域的创新方面；国务院发布的《新一代人工智能发展规划》（国发〔2017〕35 号）中明确提出对“面向真实世界的主动视觉感知及计算”研究的要求，这也说明了图像复原技术是人工智能的发展重点，将深刻改变人类社会生活、改变世界。

1.2　国内外研究现状

图像复原的目标是基于观测的退化图像，恢复出清晰的高质量图像。国内外研究人员在该领域进行了长期而深入的探索。传统方法通过分析退化图像的特性，提炼出相关的先验知识[1-5]，包括局部性先验[6-7]、全局性先验[3,8]和多尺度先验[5]，以指导和约束图像复原过程。传统的图像复原方法包括滤波方法（如中值滤波、维纳滤波[9]）、频域方法[10]、去卷积方法[11]、变分方法[12]等。然而，这些方法在设计上通常高度依赖于研发人员的经验和直觉，导致自动化程度低，执行过程耗时且费力。此外，由于退化过程在不同场景下的复杂性和多样性，传统方法往往难以有效建模，从而限制了适用范围。近年来，深度学习技术[13]的

中国知网　https://www.cnki.net

飞速发展为图像复原领域带来了显著进展[14-16]。依据模型学习的分布类型，现有图像复原方法可分为判别式图像复原方法和生成式图像复原方法。首先介绍判别式图像复原方法并分析其优缺点；其次介绍生成式图像复原方法，并分析这类方法的优缺点；最后，结合研究现状，深入探讨图像复原的关键难点，并提出相应的解决思路。为表述准确，本文引入以下符号定义：用 $\boldsymbol{x}$ 表示清晰图像，$\boldsymbol{y}$ 表示退化图像，$\hat{\boldsymbol{y}}$ 表示复原结果。

1.2.1　判别式图像复原方法

判别式图像复原是指直接学习退化图像到清晰图像的映射关系，即通过监督学习的方式训练图像复原模型（表示为 $\mathcal{F}(\cdot)$），以建模条件分布 $p(\boldsymbol{x}|\boldsymbol{y})$。在判别式图像复原中，退化图像 $\boldsymbol{y}$ 被输入到已训练的神经网络中，期望输出图像复原结果 $\hat{\boldsymbol{y}} = \mathcal{F}(\boldsymbol{y}) \sim p(\boldsymbol{x}|\boldsymbol{y})$。在深度学习时代，基于深度神经网络的判别式建模方法在计算机视觉和学科交叉等多个领域取得了显著进展。同样，在图像复原领域，与传统的图像处理算法相比，判别式图像复原方法在特定的图像复原任务上取得了性能突破。判别式图像复原的过程包含四个关键阶段：

- **数据收集阶段。**收集包含（退化图像，清晰图像）配对的数据集。该阶段要求退化图像与清晰图像具有严格的对应关系。同时，为了保证算法在推理阶段的性能，还要求训练数据集中的退化图像与推理阶段部署场景下的退化图像服从同一分布。
- **模型搭建阶段。**搭建具有丰富表征能力的神经网络作为图像复原模型。常用的神经网络模型通常包括卷积神经网络[17]、图神经网络[18]、Transformer[19-24]和 Mamba[25-27]等。
- **模型训练阶段。**以最大似然或最大后验为目标，采用神经网络优化算法（如 SGD 算法[28]和 Adam 算法[29]）优化图像复原模型的可学习参数。在模型达到预设的收敛标准后，保存训练完成的模型权重。
- **模型推理阶段。**输入待处理的退化图像，加载训练完成的模型权重，通过图像复原模型推理算法得到清晰图像。

现有的判别式图像复原方法的研究主要围绕上述四个关键阶段展开。为了更系统地梳理相关研究，本节依据这四个阶段对现有工作进行分类。

数据收集阶段主要研究如何搭建数据的收集系统以及数据预处理方法[30-33]。例如，Wang 等人[33]提出一种半自动的数据收集方法，利用真实雨滴图像序列的时序先验和人工监督构建了一个大规模的高质量真实雨滴数据集，显著提升了现有去雨方法的性能；Ai 等人[32]利用预训练大模型构建了包含一百万张高质量图像的大规模数据集，并结合正负提示进行数据删选，数据集具有隐私安全、高质量和多样等优点，实现模型泛化能力的提升。

中国知网　https://www.cnki.net

模型训练阶段和模型推理阶段研究图像复原的训练和推理方法。例如，Wang 等人[34]在训练过程中引入对抗损失生成更逼真的纹理和减少伪影；Zhang 等人[35]通过展开半二次分裂（half-quadratic splitting, HQS）算法设计图像复原模型，提升图像超分的灵活性和有效性；Xiao 等人[36]和 Fu 等人[37] 提出利用持续学习技术[38]的图像复原[37]，顺序地处理不同的图像退化，构建开放的图像复原系统，以应对动态环境和提升复原泛化性；Li 等人[39]采用了因果推断的后门准则，学习对退化不变的特征表示，提升了图像复原模型在不同退化类型和程度上的泛化能力；Zhu 等人[40]通过两阶段训练策略学习退化的一般性和特定性特征，提出了高效的统一图像复原模型，有效地处理多种天气相关的图像退化问题；Saharia 等人[41]通过扩散模型的迭代去噪过程实现了图像超分，适用于多种放大因子和输入分辨率，在人脸和自然图像超分辨率任务中均表现出色，其生成的图像具有较高的逼真度；Saharia 等人[42]提出通用的图像到图像扩散模型框架，无需针对特定任务进行超参数调整或架构定制，在图像上色、修复（image inpainting）、扩展和 JPEG 压缩伪影矫正等多个图像到图像翻译任务上表现出色；Luo 等人[43]设计均值回归随机微分方程，训练过程中利用神经网络学习分数函数（score function）[44]，在感知质量和视觉效果上取得了显著提升；Yue 等人[45]构造马尔可夫链，通过转移残差的方式实现在低分辨率图像和高分辨率图像之间的转换，显著减少了图像超分任务所需的扩散步骤，在合成和真实世界数据集上均取得了优异的性能；Wang 等人[46]通过利用预训练的文本到图像扩散模型中的先验知识，结合时间感知编码器、可控特征包装模块和渐进聚合采样策略，实现了在真实世界图像超分辨率任务中的显著性能提升；Lin 等人[47]利用扩散模型，通过“退化去除 → 信息再生”两阶段设计，在盲图像复原任务上实现了高质量的图像复原，并在多个真实世界和合成数据集上取得了优异的性能；Potlapalli 等人[48]通过使用提示（prompts）来编码特定退化的信息，并动态引导复原网络，从而提高模型的泛化能力。

模型搭建阶段主要研究如何引入图像复原的先验信息，构造具有强大表征能力的图像复原模型。例如，Dong 等人[49]证明了卷积神经网络在图像超分任务上的巨大优势；Zhang 等人[50]将基于残差卷积神经网络应用到图像去噪任务上，并且取得了优异的性能；Fu 等人[51-52]和 Yang 等人[53-54]证明了卷积神经网络在图像去雨上相比于传统算法具有更优越的性能；Ren 等人[55]提出了针对图像去雾的多尺度卷积神经网络，并且取得了优异的性能；研究人员通过多尺度特征增强[55-57]和多阶段逐步优化策略[58]引入卷积神经网络中，显著提升了图像复原模型在不同任务中的复原能力；Chen 等人[59]提出无显式的非线性激活函数的 NAFNet，通过网络整体结构和内部组件的简化，在图像超分、图像去噪和图像去模糊任务上实现了优异的性能；Liu 等人[60]提出非局部的递归神经网

中国知网　https://www.cnki.net

络（Recurrent Neural Network, RNN），用于改善图像去噪和超分辨率等任务的性能。视觉 Transformer 也在各种图像复原任务上取得非常卓越的性能，包括 Chen 等人[61]引入了图像处理 Transformer 模型 IPT，通过 “大规模数据集预训练 → 专用的数据集微调” 的范式，在图像去雨、图像超分和图像去雾任务上实现了优异的效果，但是由于其高昂的时间复杂度和空间复杂度，IPT 仅处理小分辨率的图像块（48×48）；Liang 等人[62]引入了基于 Swin Transformer 的图像复原模型 SwinIR，由于局部窗口的引入，SwinIR 的时间复杂度和空间复杂度大大减低，SwinIR 在图像超分、图像去噪和图像 JPEG 压缩伪影矫正任务上取得优异的效果；Wang 等人[63]提出将 Swin Transformer 嵌入到经典的 U-Net 结构中，提出图像复原模型 Uformer，在图像去雨、图像去噪、图像去模糊和图像去摩尔纹任务上实现优越的性能；Zamir 等人[64]提出 Restormer，其凭借通道维度的自注意力机制以及 Transformer 的高效范式，在图像去雨、去噪、去模糊任务上实现了进行了验证；Li 等人[65]提出了在垂直和水平空间内的自注意力，通过建模图像的全局、区域和局部层次结构，提升了多种图像复原任务的性能；Zhang 等人[23]提出了基于 X 形状自注意力的视觉 Transformer 架构，通过结合空间维度和通道维度的 Transformer 模块，在图像去噪任务上均取得了先进的性能；Guo 等人[66]和 Shi 等人[67]通过引入局部卷积和通道注意力机制，有效地解决了标准 Mamba 在图像复原中的局部像素遗忘和通道冗余问题，在图像超分和图像去噪等多个图像复原任务上均取得了优异的性能。

得益于深度神经网络强大的表征能力，判别式图像复原方法通常能够在特定场景和特定退化类型下（即推理阶段数据与训练阶段数据分布相同）取得优异的性能。然而，由于受限于推理阶段数据与训练阶段数据服从独立同分布的基本假设，判别式图像复原方法在推理阶段的泛化性能受到限制。此外，图像复原模型的复用代价较高：当推理阶段数据分布与训练阶段数据分布不同时，需要重新收集配对数据集并重新训练模型。

1.2.2　生成式图像复原方法

生成式图像复原方法通过神经网络建模清晰图像的先验分布 $p(\boldsymbol{x})$，先验分布可以通过数据上学习获取或通过生成网络的内在结构隐式地获取[68-69]，它们通常可以将配对的（退化图像，清晰图像）训练数据[43,45,70-71]的要求放宽到未配对的（退化图像，清晰图像）[72]、仅有清晰图像[73]以及仅有退化图像[74-78]。由于学习过程与特定退化过程解耦，相较于判别式图像复原方法，生成式图像复原方法的表现出较高的泛化性[79]。它们通常在推理阶段利用图像先验不断迭代优化以获得清晰图像，一类图像复原方法是从数据中学习通用的去噪器[73,80-83]，并将其用作优化算法中的代理算子，实现到其他退化过程的泛化。例如，Kawar[84]通

中国知网　https://www.cnki.net

过结合朗之万动力学和牛顿法，并利用去噪器，为解决带噪声的线性逆问题提出了一种新的随机采样方法，在图像去模糊、超分和压缩感知等任务上展示了出色的性能；Sun 等人[82]利用去噪器替代传统优化算法中的代理算子，从而在迭代过程中实现图像重建；Zhang 等人[83]通过训练一个通用的深度去噪器先验，并将其应用于插件式图像复原框架中，实现了在多种图像复原任务上的优异性能。另一类图像复原方法是基于生成对抗网络（Generative Adversarial Network，GAN）[85] 学习清晰图像的先验[86-88]，通过优化隐变量或生成对抗网络的权重，最小化生成图像（经过退化过程处理）与输入退化图像之间的距离。例如，Daras 等人[87]从初始隐变量开始，逐步优化到更接近像素的中间层，逐步扩展生成模型的范围，在图像修复（image inpainting）、去噪、超分等图像复原问题上取得显著效果；Pan 等人[88]利用生成对抗网络捕获的图像先验知识，利用生成对抗网络的逆向（GAN inversion）操作，允许生成对抗网络在复原过程中动态微调，从而实现灵活和准确的图像复原。

近年来，扩散模型[89-95]在图像生成领域取得了显著进展。扩散模型也被广泛用于解决各类逆问题[41-42,44,46,84,96-104]。这类方法将扩散模型视为图像先验，并利用预设退化过程，在采样阶段迭代优化实现图像复原。例如，Song 等人[98]针对医学成像中的线性逆问题，通过在扩散模型采样算法中，加入基于观测数据的近端优化问题的求解，实现了计算机断层扫描（computed tomography，CT）和磁共振成像（magnetic resonance imaging，MRI）的图像重建；Kawar 等人[105]针对线性逆问题，在谱域中执行扩散采样，从而实现判别并生成缺失信息，后续工作[106]将该算法扩展到非线性的 JPEG 压缩伪影去除；类似地，Wang 等人[107]提出了一种零样本图像求解器，在反向扩散过程中对零空间中采样以解决线性图像复原问题；Zhu 等人[100]将传统的插件式图像复原方法与扩散采样框架相结合，利用扩散模型作为生成去噪器先验，采用半二次分裂算法解耦数据项和先验项，并在迭代过程中分别求解，实现了高效且高质量的图像复原效果；Mardani 等人[104]通过变分推断框架，将扩散模型作为数据先验，将测量模型表示为似然函数，实现了高质量的图像复原和高效的采样过程；Cohen 等人[102]通过指导机制和优化采样策略，生成具有语义意义的多样化输出，同时保持了图像的质量和一致性；Chung 等人[108]和 Fei 等人[109]则利用退化过程引导隐变量更新，以确保采样得到的图像与退化图像的一致性，从而应对更一般非线性退化问题。

生成式图像复原的优点在于模型训练过程与退化过程解耦，且仅需使用清晰图像数据进行训练，从而提升图像复原的泛化性。相比于判别式图像复原方法，生成式图像复原方法的模型复用代价更低。生成式图像复原方法的难点[89]在于：（1）图像数据维度高，维数灾难（curse of dimensionality）[110]导致生成高维数据困难；（2）图像分布复杂，导致模型学习过程的样本复杂度较高[79]。高样

中国知网　https://www.cnki.net

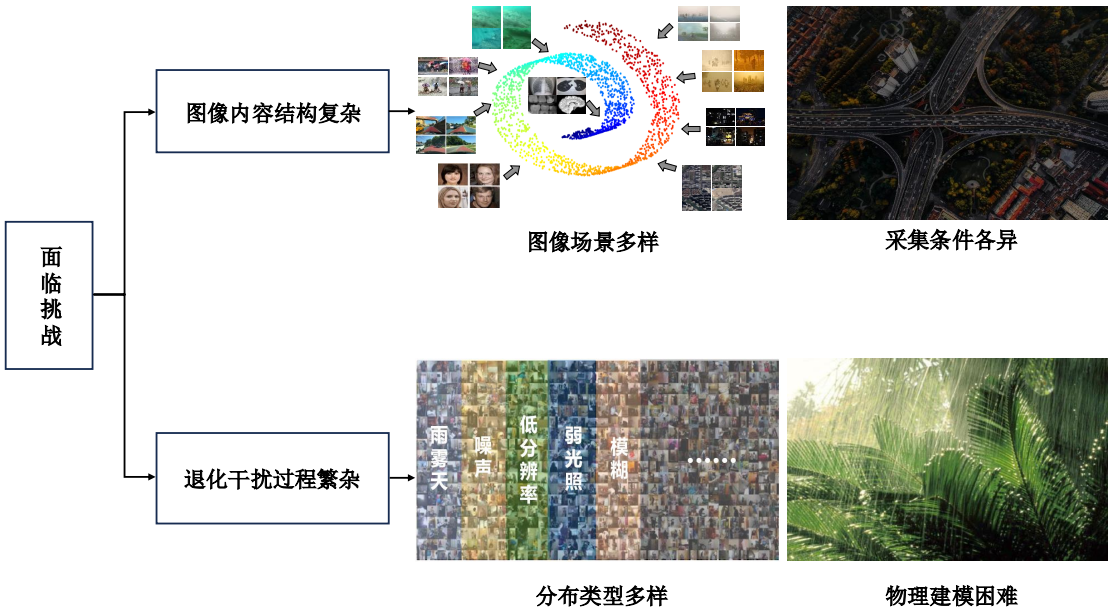


图 1.2　图像复原面临的挑战

本复杂度使得模型直接学习清晰图像分布 $p(\boldsymbol{x})$ 困难。

1.2.3　图像复原面临的挑战

图像复原旨在通过数学建模与算法优化，从受噪声、模糊等退化因素影响的图像中重构出高质量的清晰图像。图像复原问题通常是一个不适定的逆问题（ill-posed inverse problem），即解可能不唯一。如图 1.2 所示，图像复原的难点可以从两个方面概括：

- **图像内容结构复杂。**图像涵盖的场景多样性是图像内容结构复杂的一个重要原因。随着图像采集技术的不断进步，图像数据所涉及的场景从室内外环境、城市风貌到自然景观以及医疗和工业等专业领域各不相同。此外，图像的采集条件，如环境的天气、光照和阴影条件，以及采集设备（如相机、传感器等）的性能和参数设置，也会影响图像内容结构的复杂性。
- **退化干扰过程繁杂。**不同类型的退化过程（如模糊、噪声、低分辨率和压缩失真等）各自具有独特的物理机制和统计特性，并且常在实际场景中交织出现。这种退化类型的多样性和叠加性显著增加了图像复原问题的求解复杂度。此外，如何准确描述和估计这些退化过程是图像复原的一大难题，退化过程描述不准确将直接影响复原效果。

上述难点为利用深度学习技术解决图像复原问题带来了极大的挑战，另一方面，也对图像复原方法提出了两个方面的要求：

- 判别能力要求。即图像复原模型具有足够强大的表征能力，有效地区分退化图像中的噪声成分和清晰图像的有用信息成分。
- 泛化能力要求。即图像复原模型能够适应其他图像或退化场景。泛化能力

中国知网　https://www.cnki.net

的挑战来自两个方面：推理阶段和训练阶段图像分布的差异，以及退化过程的差异。训练数据集中的数据难以全面、真实地反映部署环境下的退化过程，从而导致训练阶段和推理阶段的数据分布存在偏差。因此，图像复原方法需要设计更通用的复原准则，而不是针对某一特定类型的退化，以消除数据分布和退化分布偏差的影响。

本文提出了知识驱动的图像复原方法，针对上述判别能力和泛化能力的需求，分别研究图像内蕴先验知识驱动和预训练模型外源知识驱动方法。为了提升判别能力，研究增强图像复原模型的内蕴结构跨尺度表征能力，以实现在丰富的表征空间中区分退化信息和图像信息。由于图像复原模型采用深度神经网络实现，判别能力提升对神经网络提出以下要求：

- 内容自适应的表征能力。由于图像分布和退化过程较为复杂，模型应具备内容自适应的建模能力，以针对不同的输入图像进行特异性处理。
- 局部信息建模能力。图像具有局部性先验，即一个像素与其周围像素存在较强的相关性。因此，当某个像素受到噪声污染时，可以通过其周围像素推断其真实值。同时，已有的神经网络成功案例（如卷积神经网络）已证明局部性先验在图像处理中具有显著的有效性。
- 全局上下文建模能力。不同类型的噪声在空间上的分布范围差异大，且图像的语义、风格等在全局范围内存在相关性。因此，全局上下文建模能力有助于区分退化图像中的干净信息和退化信息，减小图像语义缺失与误判，从而提高图像复原效果。
- 高效处理高维数据的能力。随着拍摄设备的不断进步，图像数据通常具有较高的维度（如 1024×1024）。因此，图像复原模型应具备高效处理高维数据的能力。

本文聚焦于具有自适应表征能力的基础模型——Transformer，研究如何在模型设计中嵌入图像内蕴的先验知识，挖掘图像空间的先验信息，增强模型对内蕴结构的跨尺度表征能力，从而更好地满足图像复原的需求。针对泛化能力的提升，本文研究如何迁移和利用在大规模数据集上预训练扩散模型的图像先验知识，通过分析扩散模型的内部表示和采样机制，综合考虑图像复原的一致性和真实性要求，设计具有通用性的概率引导图像复原的推理采样框架，通过对退化无关的清晰图像知识的挖掘，提升图像复原的泛化性能。

1.3　研究内容与主要贡献

综合国内外研究现状和图像复原的难点分析，本文以“知识驱动”为核心思想，系统引入多种类型的先验知识，以提升模型的表征能力与泛化性能。具体而

中国知网　https://www.cnki.net

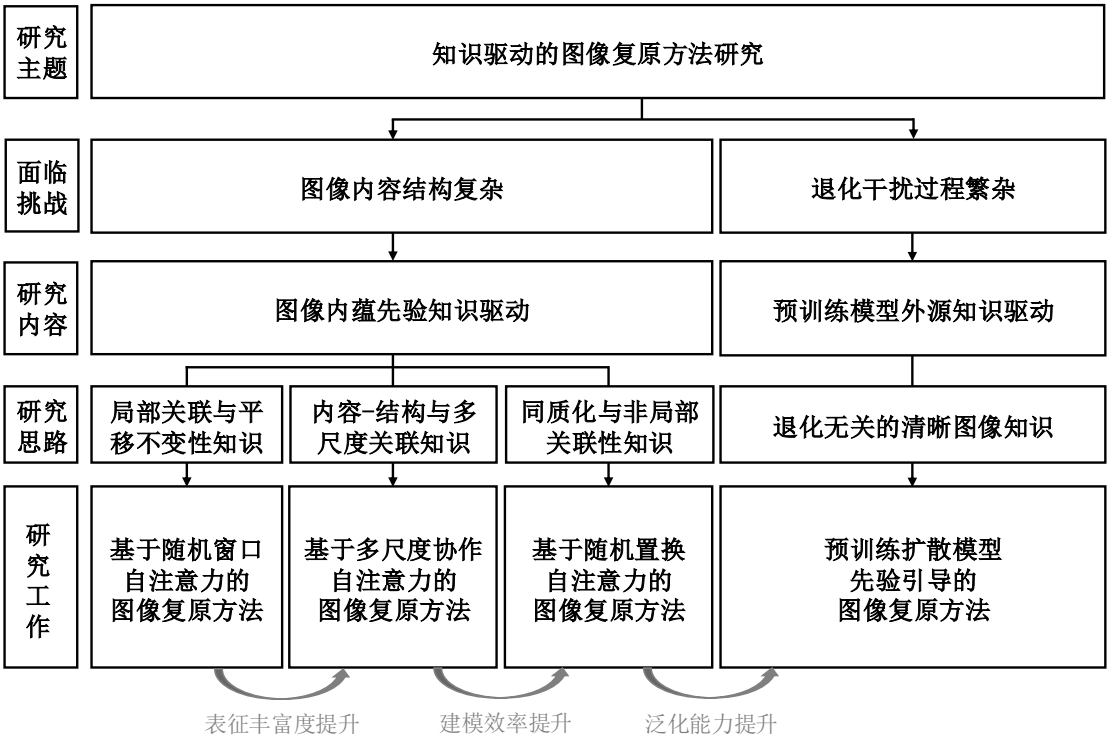


图 1.3　主要研究内容

言，本文所使用的知识可分为以下两类：（1）图像内蕴知识：源于图像本身的统计结构与空间规律，主要包括局部关联与平移不变性知识、内容-结构与多尺度关联知识、同质化与非局部关联性知识等。这类知识通过随机窗口划分、多分支与多尺度协作结构、自注意力重排列机制等手段显式建模，从而实现对内蕴知识驱动的图像复原。（2）预训练模型外源知识：来自预训练模型或大规模数据分布的外部知识，主要体现在扩散模型中蕴含的清晰图像分布先验。本文借助概率引导机制，在不依赖退化过程先验的前提下，充分挖掘预训练扩散模型中的图像生成知识，有效提升了模型在未知退化场景下的复原能力。本文从这两类知识出发，构建了的知识驱动的图像复原方法，贯穿于模型设计与推理策略之中，实现了从局部到全局、从显式建模到隐式引导的知识融合与利用，以提升图像复原模型的判别能力和泛化能力，从而实现高泛化性和高保真的图像复原。

如图 1.3 所示，本文具体的研究内容及其主要贡献为：

- **基于随机窗口自注意力的图像复原方法。**针对图像复原 Transformer 模型在局部尺度依赖关系建模能力不足和平移不变性缺失的问题，分析得出其原因在于固定窗划分策略的局限性。为了解决这些问题，该工作引入了随机偏移的窗口划分策略，取代固定偏移的窗口划分策略，提出了新颖的随机窗自注意力机制，并构建了随机窗口 Transformer（称为 Stoformer）。为了应对模型中随机偏移引入的随机因素，在训练阶段，提出从随机偏移分布中采样得到随机偏移样本，并基于该样本设计了高效的训练策略；在推

中国知网　https://www.cnki.net

理阶段，设计了逐层期望传播方法，实现了对随机偏移数学期望的高效近似。该工作通过引入窗口的随机偏移分布在图像空间引入了局部关联性知识和平移不变性知识。理论与实验验证了随机窗口 Transformer 不仅具备可靠的局部尺度依赖关系建模能力，同时能够保持退化位置的平移不变性。该工作还详细分析了固定窗口策略、滑动窗口策略和随机窗口策略的优缺点，并在图像去雨、去噪和去模糊任务中验证了 Stoformer 在图像复原任务中的有效性。

- **基于多尺度协作自注意力的图像复原方法。**该工作发现自注意力无法独立地建模图像结构信息，提出了结构建模与内容建模双分支协作计算机制。基于局部窗口自注意力的 Transformer 模型的时间复杂度和空间复杂度随着图像分辨率呈线性关系（$\Theta(HW)$），能够高效处理高分辨率退化图像，但牺牲了对图像全局上下文的感知能力。而 Transformer 模型直接应用到图像复原问题时，其时间复杂度和空间复杂度与图像分辨率呈二次方关系（$\Theta\left((HW)^2\right)$），这会导致在处理高分辨率图像时出现显存溢出（Out of Memory，OOM）和训练时间过长的问题。综合考虑图像像素相关性的局部性先验、退化和图像内容的全局相关性先验，该工作进一步提出了窗内-窗间自注意力计算模块，窗内-窗间自注意力通过感受野互补建模，在图像空间中引入了对内容-结构知识和多尺度关联性知识。结合 U-Net 经典架构，构建了具有丰富表征能力的 Transformer 模型（Local-Global Transformer，LGT）。与 Stoformer 相比，LGT 不再局限于建模局部尺度的依赖关系，而具备更丰富的多尺度表征能力。理论分析表明，窗内-窗间自注意力将时间复杂度和空间复杂度从 $\Theta\left((HW)^2\right)$ 降低为 $\Theta\left((HW)^{\frac{3}{2}}\right)$。实验验证了 LGT 在处理复杂退化问题中的有效性以及内容-结构双分支建模的互补作用。
- **基于随机置换自注意力的图像复原方法。**该工作研究了一种特殊的退化类型——退化噪声在图像空间中的非均匀分布，并分析了其面临的挑战，即退化噪声的非均匀分布与图像复原模型的权重共享机制之间的冲突。为了解决这一问题，该工作提出了两种新型的随机函数：随机置换函数和逆随机置换函数，它们实现了图像空间与同质化空间之间的双向映射。通过将图像空间中非均匀的退化噪声映射到同质化空间中的均匀分布，成功避免了与权重共享机制不兼容的问题，从而构建了能够处理非均匀退化噪声的 Transformer（称为 HomoFormer）。在图像去阴影任务中，验证了 HomoFormer 在处理非均匀分布退化噪声方面的有效性。此外，该工作从理论上证明了随机置换函数和逆随机置换函数能够高效建模图像间标记（Token）的长程依赖关系，并利用这两个函数构造了高效的稀疏自注意力机制，可以以线性时间复杂度和空间复杂度（即 $\Theta(HW)$）建模长程依赖关系的建模。该

中国知网　https://www.cnki.net

工作采用“局部建模 → 全局建模”的多尺度建模范式，结合局部窗自注意力和稀疏自注意力构建了新型的混沌窗口自注意力基础模块，实现了同质化知识和非局部关联性知识联合驱动的图像复原方法。基于混沌窗口自注意力，结合 U-Net 架构进一步提出了增强局部建模能力的 HomoFormer，称为 HomoFormer-Local。与 LGT 相比，HomoFormer-Local 具有更强的跨尺度交互能力及更高的建模效率。大量实验结果表明，HomoFormer-Local 在多个图像复原任务（包括图像去噪、图像去雨和图像去模糊）中表现出卓越的性能。

- **预训练扩散模型先验引导的图像复原方法。**前三章的研究工作基于一个基本假设：预先收集退化图像与清晰图像的配对数据集，并且训练阶段和推理阶段的数据是同分布的。然而，这一假设使得推理阶段的图像复原性能受到训练阶段图像退化过程的限制。同时，由于配对数据集所包含的场景有限，难以满足同分布的假设，从而限制了模型的泛化能力。该工作探讨了一种生成式图像复原方法：通过神经网络模型直接学习清晰图像的先验分布，并设计了生成式图像复原推理建模方法，以提升图像表征概率的方式挖掘并利用预训练扩散模型的清晰图像先验知识，引入了对退化无关的清晰图像知识，从而提升图像复原的泛化性。在生成式图像复原方法中，模型的训练过程与退化过程无关，同时，清晰图像可以广泛收集，涵盖多个场景，因此具有更强的泛化能力。近年来，基于扩散模型的图像生成取得了显著进展。该工作基于清晰图像在扩散模型中具有高概率的假设，提出了无需监督训练的推理阶段图像复原方法 DreamClean。DreamClean 依赖预训练扩散模型的清晰图像先验知识，提出了基于通用概率准则的推理采样算法，称为保方差采样。保方差采样算法兼容两种场景：已知退化过程和未知退化过程。在已知退化过程的情况下，提出了将现有的基于扩散模型的图像复原采样算法与保方差采样结合的推理方法；在未知退化过程的情况下，提出了通过 ODE 逆过程采样获得能够表征图像信息的隐变量，并结合保方差采样与 ODE 采样的推理方法完成图像复原。DreamClean 是一种无需监督训练且不依赖于退化过程的通用图像复原框架，能够在多种退化类型下实现高保真图像复原。DreamClean 具有严谨的理论支撑，证明了保方差采样能够稳定提升图像在扩散模型中的概率，并最终收敛到高概率集合。得益于扩散模型对丰富图像先验知识的学习，DreamClean 在处理多种退化类型时，复原质量优于现有方法。

中国知网　https://www.cnki.net

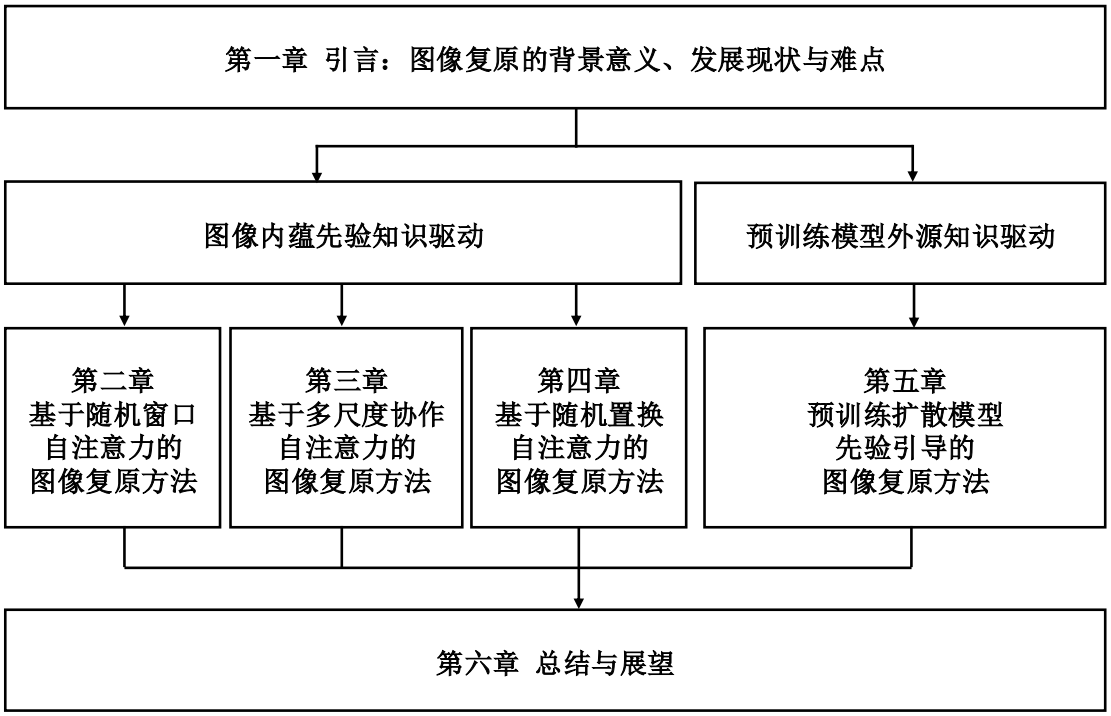


图 1.4　全文组织结构

1.4　论文结构

本文分为六个章节，组织结构如图 1.4 所示：

第一章　引言

本章主要研究图像复原的背景意义、国内外发展现状和面临挑战。通过图像复原任务难点分析，引出本文的研究主题、研究内容、研究思路和研究方法。

第二章　基于随机窗口自注意力的图像复原方法

本章内容主要包括对背景、研究思路和方案的概述，相关工作的介绍，随机窗口自注意力的方法设计，实验与分析和本章小结。

第三章　基于多尺度协作自注意力的图像复原方法

本章内容主要包括对研究思路和方案的概述，内容-结构双分支协作自注意力结构和窗内-窗间多尺度协作自注意力的设计，实验与分析和本章小结。

第四章　基于随机置换自注意力的图像复原方法

本章内容主要包括对研究思路和方案的概述，随机置换函数和逆随机置换函数的介绍、自注意力方法设计及其性质分析，实验与分析和本章小结。

第五章　预训练扩散模型先验引导的图像复原方法

本章内容主要包括对背景、研究思路和方案的概述，基于扩散模型的生成式图像复原方法设计，理论分析，实验与分析和本章小结。

第六章　总结与展望

本章对本文的工作进行了总结，并结合人工智能的发展现状，对未来的研究方向进行了探讨和展望。

中国知网　https://www.cnki.net

第 2 章　基于随机窗口自注意力的图像复原方法

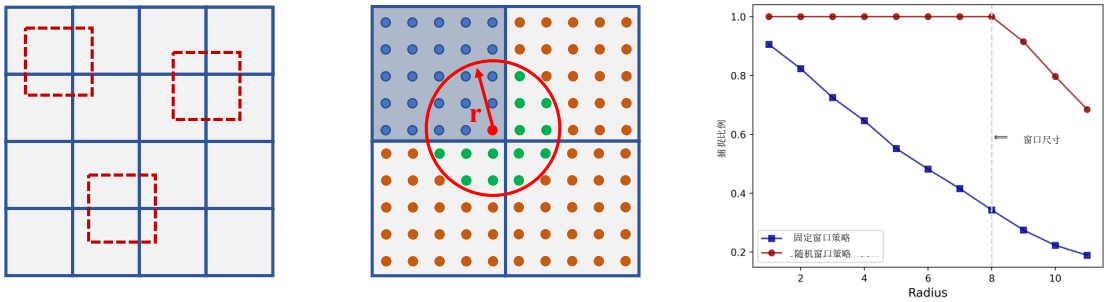
本章探讨如何增强图像复原 Transformer 模型在局部尺度上的表征能力。Transformer 凭借强大的表征能力在图像复原领域取得了显著进展。然而，现有基于 Transformer 的方法尚未充分考虑图像复原任务的特殊性：（1）图像中的像素值具有局部相关性，即某个像素的灰度值或颜色值通常受到其邻域像素的影响；（2）图像复原方法应具有对退化位置的平移不变性，无论退化发生在图像的哪个位置，复原结果均应保持一致，即复原效果不应依赖于退化的位置。然而，现有基于 Transformer 的图像复原方法通常采用基于固定窗口策略的局部窗口自注意力机制或全局注意力机制。当处理高分辨率图像时，这两种方案均难以有效捕捉局部关系，并破坏了对退化位置的平移不变性。为了解决这些问题，本章分析了局部关系损失的根源在于固定窗口划分破坏了窗口间的等价性，进而提出了一种新型的基于随机偏移窗口的自注意力机制。具体而言，首先引入了一种基于随机偏移分布的窗口划分策略，以替代固定偏移的窗口划分策略，并将其应用于注意力机制，构建了新型的随机窗口注意力。结合前馈网络，搭建了图像复原 Transformer 模型，称为 Stoformer。在模型训练阶段，本章提出了从随机偏移分布中进行采样，利用随机偏移样本实现高效的模型训练；在模型推理阶段，本章设计了逐层期望传播算法，实现了对随机偏移变量的数学期望的高效近似。Stoformer 不仅具备对局部依赖关系的完整建模能力，还能够对退化位置保持平移不变性，因而在图像空间中引入了局部关联性知识和平移不变性知识。实验验证了随机窗口策略能够等价地处理任意偏移的窗口，从而克服平移不变性缺失的问题。实验结果表明，Stoformer 在多种图像复原任务（包括图像去雨、去噪和去模糊）上均提升了性能。

2.1　概述

图像复原旨在从退化图像中恢复出清晰图像，是智能视觉领域的研究热点，并为各种下游视觉任务奠定了基础。图像复原方法应满足平移不变性（Translation Invariance）的基本约束：无论退化发生在图像的何处，复原结果均应保持一致性和准确性。平移不变性是图像复原的基本要求。相比于多层感知机（Multi-Layer Perceptron，MLP），卷积神经网络（Convolutional Neural Network，CNN）凭借其共享参数的局部卷积核和滑动窗口机制，能够满足平移不变性的要求。因此，卷积神经网络在图像复原任务中具有天然的优势[50,83,111-119]。

另一方面，基于 Transformer[61-62,64,120] 的图像复原方法中，所采用的自注意力机制可分为两类：经典的全局自注意力和局部窗口自注意力。然而，这两种方

中国知网　https://www.cnki.net



(a) 固定窗口策略划分破坏窗口间的等价性　(b) 固定窗口策略无法捕捉完整的局部信息　(c) 随机窗口策略和固定窗口策略捕捉局部关系的比例对比

图 2.1　固定窗口策略破坏窗口的等价性和损失局部关系的示意图

式在处理高分辨率图像时均无法满足平移不变性的要求，并且未能充分提取和建模完整的局部信息。首先，分析局部窗口自注意力。局部窗口自注意力将图像（或特征图）划分为固定且不重叠的局部窗口，并在每个局部窗口内计算自注意力，窗口间的模型权重共享。代表性方法包括 Uformer[120] 和 SwinIR[62]。固定窗口划分策略对具有特定偏移的窗口施加了人工先验，从而破坏了窗口间的等价性。如图 2.1(a) 所示，在处理局部窗口时，模型参数的权重共享仅适用于具有特定偏移的窗口（即蓝色窗口），而对于任意偏移的窗口（即红色窗口），其处理方式则不同。因此，这种策略破坏了窗口间的等价性，无法满足平移不变性的要求。图 2.1(b) 直观地展示了固定窗口策略无法建模完整的局部关系。假设采用欧几里得距离作为距离度量，考虑由半径为 r 的圆圈所覆盖的邻域空间。对于某个特定的标记（位于图 2.1(b) 中心的红色点），邻域空间内的标记（绿色点）无法参与局部窗口自注意力的计算，导致这些标记之间的关系未被建模，从而造成局部关系的大量丢失。随着邻域空间的扩展（即半径 r 增加），信息损失将愈加严重。图 2.1(c) 展示了固定窗口策略所捕捉的局部关系占邻域空间中总关系的比例。在理想情况下，当特征图被划分为大小为 $s \times s$ 的局部窗口时，距离小于 s 的标记之间的关系应当能够被完整地建模。然而，由于图像复原任务中输入图像的分辨率通常较高，并且全局注意力的时间复杂度和空间复杂度与图像分辨率呈二次方关系，因此在实际应用中，全局注意力通常仅适用于较小分辨率的图像块（例如，IPT[61] 中为 48×48）。而将高分辨率图像分割成小分辨率的图像块会导致平移不变性的缺失，论述过程与前述固定窗口策略类似，同样，将高分辨率图像分割成小分辨率的图像块也会导致大量损失局部性依赖关系。

一个直接的解决方案是采用滑动窗口策略，类似于卷积神经网络，通过局部窗口扫描整个特征图。然而，滑动窗口策略会在显存和计算速度方面带来巨大的开销。为了解决这一问题，本章提出了一种新型的随机窗口策略，旨在使 Transformer 能够等价地处理任意偏移的窗口，从而完整地建模局部关系。具体地，本章引入带有随机偏移的窗口划分策略，以替代原有的固定窗口划分策略，

中国知网　https://www.cnki.net

通过引入随机偏移，所有窗口被等价处理，从而满足了平移不变性和局部性建模的要求。如图 2.1(c) 所示，随机窗口策略能够完整地捕捉局部关系，直至邻域空间的半径达到窗口大小。值得注意的是，与滑动窗口策略不同，通过对随机偏移分布进行采样，训练基于随机窗口自注意力的 Transformer 模型所消耗的时间和显存开销与固定窗口策略相当。在推理阶段，本章设计了逐层期望传播算法（Layer Expectation Propagation，LEP），以近似模型对随机偏移的期望。通过这一算法，推理过程能够同时满足平移不变性和捕捉完整局部性关系的要求。

2.2　背景

2.2.1　视觉 Transformer

近年来，Transformer[19,121] 在自然语言处理（Natural Language Processing，NLP）领域的巨大成功，视觉 Transformer[20,122-129] 在计算机视觉领域也逐渐成为基础的模型结构。ViT[20] 将图像展开为标记序列（Token Sequence），并在其上应用经典的 Transformer 模型进行图像分类，与卷积神经网络相比，虽然获得了优异的结果，但由于缺乏正确的归纳偏置（Reductive Bias），ViT 严重依赖大规模图像数据集 JFT-300M[130] 的预训练。至此以后，视觉 Transformer 结构在计算机视觉任务上大放异彩。例如，DETR[131] 建立了新的端到端的目标检测的 Transformer 框架，MaskFormer[132] 引入了统一语义分割、实例分割、全景分割的 Transformer 结构。在生成模型领域，Transformer 也发挥重要的作用，Esser 等人[133] 通过 Transformer 模型建立了高分辨率图像生成的新基准，Diffusion Transformer（DiT）[94,134] 发现了 Transformer 模型在图像生成领域的规模定律（Scaling Law），并实现了高分辨率的图像生成；在视频生成领域，Transformer 作为基础模型，实现了高质量、高帧率的视频生成[135-136]；在多模态领域，研究人员利用 Transformer 作为基础模型实现包括视觉和文本的多模态的理解[137-139]。为了引入合理的归纳偏置以提高训练和推理效率，Swin Transfromer[124] 提出了基于局部窗口的注意力机制，并建立了一种高效的视觉 Transformer 模型结构。Swin Transformer 在图像分类、目标检测和语义分割方面取得了显著的进展，同时 Swin Transformer 由于其利用局部窗口的自注意力，相比于经典 Transformer，显著降低了时空复杂度，具有极大的效率优势，因此更适用于底层图像处理。受高层视觉任务的启发，研究人员开发了适用于低层视觉的 Transformer[61-62,64,120]。

然而，这些方法通常直接将高层视觉设计（例如局部窗口自注意力）迁移到低层视觉任务中，而未充分考虑底层视觉的特性。正如前面所述，与卷积神经网络不同，底层视觉 Transformer 无法等价地处理任意偏移的窗口，也无法无损建模局部性关系。此外，类似于卷积神经网络的滑动窗口策略会在显存和计算速度

中国知网　https://www.cnki.net

上带来巨大的负担。因此，开发一种高效的机制，以弥补 Transformer 在平移不变性和局部性建模方面的不足，对于低层视觉任务至关重要。

2.2.2　自注意力

Transformer 由交替的自注意力层（Self-Attention，SA）和多层感知机层（MLP）组成，其中自注意力层是 Transformer 的核心组件之一。本节将回顾自注意力层的数学原理，涵盖经典的全局自注意力和局部窗口自注意力变体，并分析自注意力的时间复杂度和空间复杂度，以及置换等变性的性质。

2.2.2.1　全局自注意力

自注意力是一种基于键值对（key-value pairs）提供的上下文，将查询张量（Query）映射为输出张量的基本计算模块，其中查询张量、键张量和值张量都由输入张量经过线性映射获得，因而称为自注意力。其常见的实现是缩放点积自注意力（scaled dot-product attention），具有形式：

$$\mathrm{MSA}(\boldsymbol{y}) = \mathrm{softmax}\left(\frac{\boldsymbol{y}W^{Q}(\boldsymbol{y}W^{K})^{T}}{\sqrt{d_k}}\right)\boldsymbol{y}W^{V}. \tag{2.1}$$

令输入张量为 $\boldsymbol{y} \in \mathbb{R}^{B\times L\times C}$，其中 B 表示批量大小，L 表示标记序列的长度，C 表示标记的维度，自注意力首先通过线性映射（可学习参数记作 $W^{Q} \in \mathbb{R}^{C\times C}$、$W^{K} \in \mathbb{R}^{C\times C}$ 和 $W^{V} \in \mathbb{R}^{C\times C}$）分别计算查询张量 Q、键张量 K 和值张量 V。随后，通过查询张量和键张量的缩放点积计算自注意力矩阵，其中缩放因子为键张量的维度的平方根。自注意力矩阵经过 softmax 函数归一化后生成权重矩阵，用以对值张量加权聚合。上述自注意力计算过程的时间复杂度和空间复杂度分析如下：

$$\text{时间复杂度：}\quad \left.\begin{aligned} &K = \boldsymbol{y}W^{K} \Rightarrow BLC^2 \\ &Q = \boldsymbol{y}W^{Q} \Rightarrow BLC^2 \\ &V = \boldsymbol{y}W^{V} \Rightarrow BLC^2 \\ &A = \frac{QK^{T}}{\sqrt{d_k}} \Rightarrow BL^2C \\ &\mathrm{softmax}(A)V \Rightarrow BL^2C \end{aligned}\right\} \Rightarrow \Theta\left(BLC^2 + BL^2C\right), \tag{2.2}$$

$$\text{空间复杂度：}\quad \left.\begin{aligned} &K = \boldsymbol{y}W^{K} \Rightarrow BLC + C^2 \\ &Q = \boldsymbol{y}W^{Q} \Rightarrow BLC + C^2 \\ &V = \boldsymbol{y}W^{V} \Rightarrow BLC + C^2 \\ &A = \frac{QK^{T}}{\sqrt{d_k}} \Rightarrow BL^2 \\ &\mathrm{softmax}(A)V \Rightarrow BLC \end{aligned}\right\} \Rightarrow \Theta\left(BLC + BL^2\right). \tag{2.3}$$

中国知网　https://www.cnki.net

图像复原中，一般有 $L = HW$，带入式 (2.2) 和式 (2.3) 可得，时间复杂度为 $\Theta\left(BHWC^2 + BH^2W^2C\right)$ 和空间复杂度为 $\Theta\left(BHWC + BH^2W^2\right)$。自注意力通常用于建模全局交互。然而，其时间复杂度和空间复杂度与标记数量呈二次关系（$\Theta\left(L^2\right)$）。在图像复原任务中，标记数量通常对应于输入图像的像素数量，这导致在计算和显存成本上产生极大的负担。

自注意力的另一个关键性质是其无法利用位置信息，即自注意力的处理结果和输入标记序列的排序无关：若将自注意力输入标记序列做随机置换，等价于对自注意力的输出结果做同样的随机置换，将这一性质称为置换等变性。若 $\mathcal{S}(\cdot)$ 表示随机置换函数，则有

$$\boldsymbol{z} = \mathrm{MSA}(\boldsymbol{y}) \Rightarrow \mathcal{S}(\boldsymbol{z}) = \mathrm{MSA}(\mathcal{S}(\boldsymbol{y})). \tag{2.4}$$

为弥补对位置建模的缺陷，研究人员提出多种位置编码方法，例如绝对位置编码（Absolute Positional Encoding）[19]、相对位置编码（Relative Positional Encoding）[124,140-141]等。为了增强表征的多样性，自注意力可以被扩展为多头自注意力（Multi-head Self-Attention, MSA）[19]。

2.2.2.2　局部窗口自注意力

局部窗口自注意力即将局部性先验[17]——计算机视觉任务中广泛使用的先验知识——引入到自注意力机制中。局部窗口自注意力[124,142]将参与计算的标记的范围限制在局部窗口内。Swin Transformer[124]采用局部窗口自注意力（Window Multi-head Self-Attention，W-MSA）利用局部性先验，减少了自注意力的时间复杂度和空间复杂度。为了实现窗口之间的交互，Swin Transformer 还引入了偏移窗口策略（Shifted window strategy），提出了偏移窗口自注意力（Shifted Window Multi-head Self-Attention，SW-MSA）。通过将自注意力限制在局部范围内，Swin Transformer 相对于输入分辨率的复杂度被降低为线性。W-MSA 的计算过程为

$$\text{W-MSA}(\boldsymbol{y}) = \mathrm{MSA}(\mathrm{W}(\boldsymbol{y})). \tag{2.5}$$

其中，$\mathrm{W}(\boldsymbol{y})$ 函数将输入张量 $\boldsymbol{y}$ 划分为不重叠的窗口。假设局部窗口的尺寸为 $s \times s$。将 $L = s^2$ 带入式 (2.2)，并且共有 $\frac{HW}{s^2}$ 个自注意力计算，因此局部窗口自注意力的复杂度为

$$\begin{aligned} \text{时间复杂度：}\ & \Theta\left(\frac{HW}{s^2} \times \left(Bs^2C^2 + Bs^4C\right)\right) \\ & = \Theta\left(BHWCs^2\right), \end{aligned} \tag{2.6}$$

$$\begin{aligned} \text{空间复杂度：}\ & \Theta\left(\frac{HW}{s^2} \times \left(Bs^2C + Bs^4\right)\right) \\ & = \Theta\left(BHWC + BHWs^2\right). \end{aligned} \tag{2.7}$$

中国知网　https://www.cnki.net

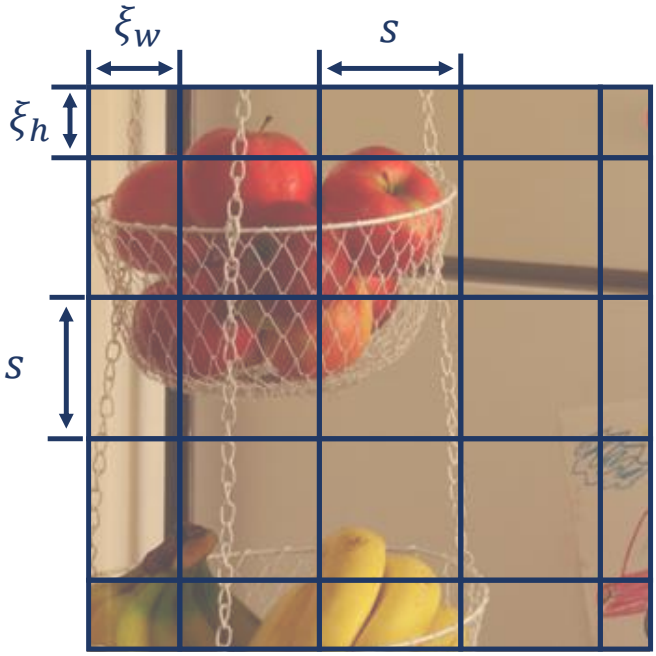


图 2.2　随机偏移的局部窗口示意图

注：局部窗口的尺寸为 $s \times s$，偏移量为 (ξ_h, ξ_w)。

尽管局部窗口自注意力显著地减少经典自注意力的时间复杂度和空间复杂度，但它牺牲了建模全局上下文的能力。同理，为了增强表征的多样性，局部窗口自注意力也可以被扩展为多头局部窗口自注意力[19]。

2.3　方法设计

Transformer 凭借其强大的表征能力在图像复原任务中取得了优异的性能。然而，由于时间复杂度和空间复杂度随图像分辨率有二次方关系，图像复原中的 Transformer 通常采用局部窗口自注意力。然而，正如上述分析，现有的固定窗口策略无法等价地处理任意偏移窗口，即固定窗口策略破坏了局部窗口自注意力对窗口处理的平移等价性（Translation Equivalence）①，并使其无法完整地建模局部依赖关系，进而破坏了 Transformer 对退化位置的平移不变性。

如图 2.2 所示，具有任意偏移 (ξ_h, ξ_w) 的局部窗口应该被等价的处理。也即，任意偏移的窗口间在平移不变性和局部性建模方面的作用是相同的，应该被等价地处理。在固定窗口策略中，某些特定划分（例如偏移量为 $(0,0)$ 或 $\left(\frac{s}{2}, \frac{s}{2}\right)$ 的窗口）占据了全部的优先级，而如上分析，简单地舍弃其他偏移的窗口是不合理的。本节提出了随机窗口策略，通过随机窗口策略，所有的窗口划分均被等价地处理。基于采样随机偏移的样本，模型可以被高效地训练。在推理阶段，本节提出了逐层期望传播算法，以近似模型输出对随机偏移的数学期望，最终证明随机窗口策略满足了平移不变性和局部关系建模的要求。

①平移不变性是图像复原任务的要求，而平移等价性是网络层的性质，即它对平移能做出等价地处理。

中国知网　https://www.cnki.net

2.3.1　随机窗口自注意力

为了提升计算效率，Swin Transformer 通常采用基于局部窗口的注意力机制，同时使用固定偏移窗口策略来实现相邻窗口之间的交互。具体而言，特征图被划分为非重叠的窗口，随后，在局部窗口内计算自注意力。假设窗口划函数分记为 $\mathrm{Par}(\cdot; s, \xi_h, \xi_w)$，其中局部窗口的大小为 s，整个窗口划分的偏移为 (ξ_h, ξ_w)（见图 2.2）。Swin Transformer 的计算过程可以被表述为

$$\boldsymbol{z}_l = \mathrm{MSA}(\mathrm{Par}(\boldsymbol{y}_{l-1}; s, 0, 0)) + \boldsymbol{y}_{l-1}, \tag{2.8a}$$

$$\boldsymbol{y}_l = \mathrm{FFN}(\boldsymbol{z}_l) + \boldsymbol{z}_l, \tag{2.8b}$$

$$\boldsymbol{z}_{l+1} = \mathrm{MSA}(\mathrm{Par}(\boldsymbol{y}_l; s, \frac{s}{2}, \frac{s}{2})) + \boldsymbol{y}_l, \tag{2.8c}$$

$$\boldsymbol{y}_{l+1} = \mathrm{FFN}(\boldsymbol{z}_{l+1}) + \boldsymbol{z}_{l+1}. \tag{2.8d}$$

其中，$\boldsymbol{z}_l$ 和 $\boldsymbol{y}_l$ 分别表示第 l 层自注意力（MSA）和前馈网络（FFN）的输出。为了使公式表达简洁，在式 (2.8) 中忽略了层归一化（Layer Normalization，简称为 LN）。可以发现，即使所有的窗口划分所包含的信息是等价的，但是固定窗口策略仅在每层中保留一个固定的划分配置，这会导致窗口平移等价性的缺失，最终造成破坏对模型对退化位置的平移不变性和局部性信息的丢失。

基于任意偏移窗口划分应被等价处理的基本理念，本节将固定的偏移值替换为随机偏移分布，进一步提出了随机窗口 Transformer（Stochastic Window Transformer，Stoformer），结合前馈网络的计算过程如下

$$\boldsymbol{z}_l = \mathrm{MSA}(\mathrm{Par}(\boldsymbol{y}_{l-1}; s, \xi_h^l, \xi_w^l)) + \boldsymbol{y}_{l-1}, \quad (\xi_h^l, \xi_w^l) \sim \mathbb{U}(\mathbb{R}_\xi), \tag{2.9a}$$

$$\boldsymbol{y}_l = \mathrm{FFN}(\boldsymbol{z}_l) + \boldsymbol{z}_l, \tag{2.9b}$$

其中，集合 $\mathbb{R}_\xi$ 是所有的偏移 $\left(\xi_h, \xi_w\right)$ 的集合，$\mathbb{U}(\cdot)$ 表示均匀分布。考虑到窗口偏移的周期性，$\mathbb{R}_\xi$ 可以简化为

$$\mathbb{R}_\xi := [0, \cdots, s-1] \otimes [0, \cdots, s-1]. \tag{2.10}$$

其中，$\otimes$ 表示笛卡尔积。$\left(\xi_h^l, \xi_w^l\right)$ 服从均匀分布 $\mathbb{U}\left(\mathbb{R}_\xi\right)$。在训练过程中，从均匀分布中采样得到偏移样本后训练模型。假设自注意力层的总数为 N，不同层的随机偏移 $\left\{\left(\xi_h^l, \xi_w^l\right)\right\}_{l=0}^{N-1}$ 是设计为独立同分布的，以确保在不同层级上能够实现建模完整的局部关系以及任意偏移的窗口的等价处理。通过这种处理，在训练阶段，尽管每一层都考虑了所有可能的偏移配置，但单次前向传播仅需要一组偏移样本，从而使得 Stoformer 能够被高效地训练。

由于引入了随机偏移分布，模型每次前向传播输出的结果不一致，最直接的方法即计算模型输出对随机偏移的数学期望作为推理结果。接下来证明取数学

中国知网　https://www.cnki.net

期望的方法确实有助于提升复原性能。为了简化表示，将 $\left\{\left(\xi_h^l, \xi_w^l\right)\right\}_{l=0}^{N-1}$ 统称为 ξ。使用 L_2 范数的平方作为评估拟合能力。因此，给定退化图像 $\boldsymbol{y}$ 和对应的清晰图像 $\boldsymbol{x}$，模型输出 $\mathcal{F}(\boldsymbol{y}, \xi)$ 的期望损失由式 (2.11) 给出

$$\mathop{\mathbb{E}}_{\xi}\left[\|\mathcal{F}(\boldsymbol{y}, \xi) - \boldsymbol{x}\|_2^2\right] \tag{2.11a}$$

$$= \mathop{\mathbb{E}}_{\xi}\left[\|\mathcal{F}(\boldsymbol{y}, \xi) - \mathbb{E}_{\xi}\left[\mathcal{F}(\boldsymbol{y}, \xi)\right] + \mathbb{E}_{\xi}\left[\mathcal{F}(\boldsymbol{y}, \xi)\right] - \boldsymbol{x}\|_2^2\right] \tag{2.11b}$$

$$= \mathop{\mathbb{E}}_{\xi}\left[\|\mathcal{F}(\boldsymbol{y}, \xi) - \mathbb{E}_{\xi}\left[\mathcal{F}(\boldsymbol{y}, \xi)\right]\|_2^2\right] + \|\mathbb{E}_{\xi}\left[\mathcal{F}(\boldsymbol{y}, \xi)\right] - \boldsymbol{x}\|_2^2 \tag{2.11c}$$

$$\geqslant \|\mathop{\mathbb{E}}_{\xi}\left[\mathcal{F}(\boldsymbol{y}, \xi)\right] - \boldsymbol{x}\|_2^2. \tag{2.11d}$$

从式 (2.11b) 到式 (2.11c) 的推导利用了 $\mathcal{F}(\boldsymbol{y}, \xi) - \mathbb{E}_{\xi}\left[\mathcal{F}(\boldsymbol{y}, \xi)\right]$ 是与 $\mathbb{E}_{\xi}\left[\mathcal{F}(\boldsymbol{y}, \xi)\right] - \boldsymbol{x}$ 独立，因而有

$$\mathop{\mathbb{E}}_{\xi}\left[\left\langle \mathcal{F}(\boldsymbol{y}, \xi) - \mathop{\mathbb{E}}_{\xi}\left[\mathcal{F}(\boldsymbol{y}, \xi)\right], \mathop{\mathbb{E}}_{\xi}\left[\mathcal{F}(\boldsymbol{y}, \xi)\right] - \boldsymbol{x} \right\rangle\right] = 0. \tag{2.12}$$

其中 $\langle \cdot, \cdot \rangle$ 是内积操作。可以得出结论，L_2 范数作为度量时，模型输出对随机偏移取数学期望（即对应于 $\mathbb{E}_{\xi}\left[\mathcal{F}(\boldsymbol{y}, \xi)\right]$）有助于降低误差、提升性能。因此，在推理阶段，模型输出应该对随机偏移的后验分布计算均值，其精确的推理过程是

$$\mathcal{F}(\boldsymbol{y})^{\text{test}} = \sum_{\xi_h^0, \xi_w^0, \cdots, \xi_h^{N-1}, \xi_w^{N-1}} \mathcal{F}\left(\boldsymbol{y}; \xi_h^0, \xi_w^0, \cdots, \xi_h^{N-1}, \xi_w^{N-1}\right) \mathbb{U}\left(\xi_h^0, \xi_w^0, \cdots, \xi_h^{N-1}, \xi_w^{N-1}\right) \tag{2.13a}$$

$$= \sum_{\left(\xi_h^{N-1}, \xi_w^{N-1}\right)} \cdots \sum_{\left(\xi_h^0, \xi_w^0\right)} \mathcal{F}\left(\boldsymbol{y}; \xi_h^0, \xi_w^0, \cdots, \xi_h^{N-1}, \xi_w^{N-1}\right) \mathbb{U}\left(\xi_h^0, \xi_w^0\right) \cdots \mathbb{U}\left(\xi_h^{N-1}, \xi_w^{N-1}\right), \tag{2.13b}$$

其中，$\mathcal{F}(\cdot)$ 表示图像复原 Transformer 模型，$\mathbb{U}(\cdot)$ 是均匀分布。式 (2.13) 的推导基于 $\left\{\left(\xi_h^l, \xi_w^l\right)\right\}_{l=0}^{N-1}$ 是独立的。根据式 (2.13)，单次精确推理需要进行 $\boldsymbol{\Theta}\left(s^{2N}\right)$ 次的前向传播，精确推理的计算开销随着深度 N 的增加而呈指数级增长，需要大量的计算资源。为了处理计算量过大的问题，本节提出一种近似推理算法，这种算法也应保证平移等价性和维持局部关系建模，并且替代精确的推理过程。受到 Dropout 近似方法[143]启发，本节提出了高效的逐层期望传播算法，作为原始的

中国知网　https://www.cnki.net

精确推理过程的近似。逐层期望传播算法的数学表述为

$$\boldsymbol{z}_l^{\text{test}} = \sum_{\left(\xi_h^l,\xi_w^l\right)} \text{MSA}\left(\text{Par}\left(\boldsymbol{y}_{l-1}^{\text{test}}; s, \xi_h^l, \xi_w^l\right)\right) \mathbb{U}\left(\xi_h^l, \xi_w^l\right) + \boldsymbol{y}_{l-1}^{\text{test}} \tag{2.14a}$$

$$= \mathop{\mathbb{E}}_{\left(\xi_h^l,\xi_w^l\right)\sim\mathbb{U}} \left[\text{MSA}\left(\text{Par}\left(\boldsymbol{y}_{l-1}^{\text{test}}; s, \xi_h^l, \xi_w^l\right)\right)\right] + \boldsymbol{y}_{l-1}^{\text{test}}, \tag{2.14b}$$

$$\boldsymbol{y}_l^{\text{test}} = \text{FFN}\left(\boldsymbol{z}_l^{\text{test}}\right) + \boldsymbol{z}_l^{\text{test}}. \tag{2.14c}$$

根据式 (2.14)，单次近似推理仅需要一次前向传播期望信号，等价需要约 $\Theta\left(s^2N\right)$ 次前向传播，大大加速了推理过程。下面将论证随机窗口策略能够保持平移不变性并无损地建模局部关系。

平移不变性。在训练阶段，随机窗口策略能对任意偏移的窗口作出等价地处理，消除了固定窗划分导致的某些特定偏移窗口占据全部的优先级（如图 2.1 中的蓝色窗口）。因此，随机窗口策略能够在训练过程中维持平移不变性。在推理阶段，依据逐层期望传播算法，每个标记能够像卷积层一样从其邻域空间聚合信息。因此，推理阶段的平移不变性也能够被维持。第 2.4.3.1节也提供了实验结果验证随机窗口策略的平移不变性。

局部关系建模。如前所述，固定窗口策略中多数具有相同信息量的窗口会被简单地丢弃，因此会导致局部关系建模的损失。如图 2.1(a) 所示，存在一些标记对，它们的距离足够小，但并未被划分到同一个局部窗口中，导致了其间关系的无法建模。相比之下，采用随机窗口策略时，窗口的偏移是随机的，对于任意标记对，只要它们之间的距离小于窗口大小，就存在一些划分，使它们在同一个窗口中。如图 2.1(c) 所示，当邻域空间的半径不大于窗口大小时，随机窗口策略能够捕捉完整的局部关系，而固定窗口策略则有严重的局部关系损失。在推理阶段，所提出的逐层期望传播算法也同等考虑了所有偏移的窗口，因此也能够确保无损地建模局部关系，实现了图像空间中局部关联性知识的补偿。

模型集成效应。与固定窗口策略相比，实验结果证明随机窗口策略可以带来性能提升。除了补偿了局部信息损失和平移等价性之外，性能提升的另一个解释是，使用随机窗口可以看作是在隐式地训练固定窗口 Transformer 的集成模型[144]。每个自注意力层包含 s^2 个窗口划分，因此有 s^{2N} 种可能的模型组合。对于每批量训练数据，从 s^{2N} 个模型中随机采样一个配置进行更新优化。在推理阶段，所有模型通过逐层期望传播算法隐式地集成。

2.3.2　随机窗口策略的建模范围分析

本节证明所提出的随机窗口策略可以模拟滑动窗口策略的建模范围，首先对于一个查询标记，探讨了随机窗口策略为其带来的感受野的两个关键性质：（1）

中国知网　https://www.cnki.net

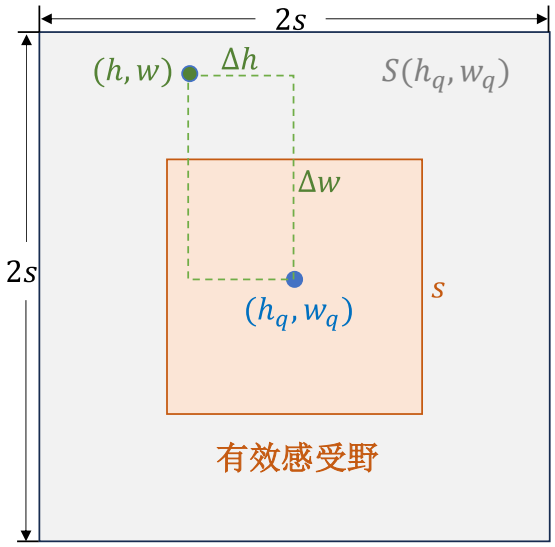
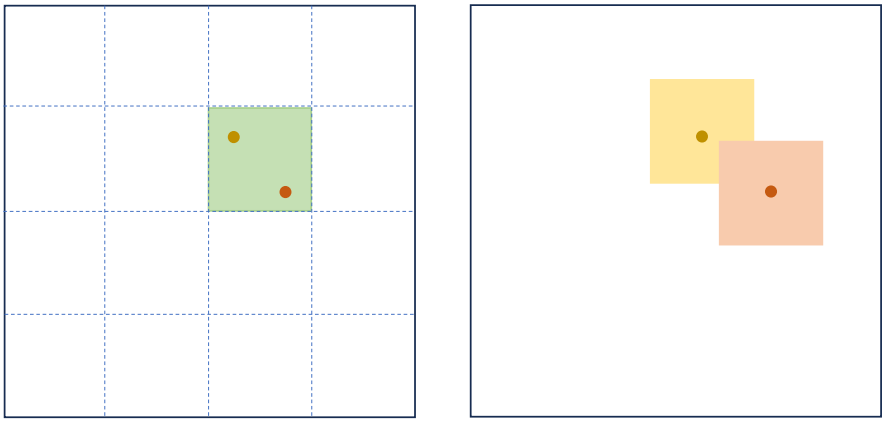


图 2.3　随机窗口策略的有效感受野示意图

注：查询标记的位置是 (h_q, w_q)，即蓝色圆点。



(a) 固定窗口策略　　**(b) 随机窗口策略**

图 2.4　固定窗口策略和随机窗口策略的感受野对比图

有效感受野，包括其形状和大小；（2）空间对称性。感受野大小定义为有效捕获的标记的数量。由于随机偏移，目标标记被查询标记捕获而建模关系是随机的。可以证明，目标标记被捕获的概率与查询标记的距离成正比，且有效捕获的标记数量为 $s \times s$，感受野以查询标记为中心。正式地，有如下定理

定理 2.1　随机窗口策略的有效感受野大小为 $s \times s$，其中 s 为窗口大小。感受野以查询标记为中心具有左右和上下翻转的对称性。

证明　考虑一个位置为 (h_q, w_q) 的查询标记，如图 2.3所示，被随机窗口策略捕获的目标标记 (h, w) 构成集合 $S\left(h_q, w_q\right)$ 表示为

$$S\left(h_q, w_q\right) = \left\{(h, w) \middle| |h - h_q| < s, |w - w_q| < s\right\}. \tag{2.15}$$

由于局部窗口偏移是采样自均匀分布，对于任意目标标记，其位置为 (h, w)，被

中国知网　https://www.cnki.net

捕获并且与查询标记的交互的概率，记作 $p\left((h,w)\to\left(h_q,w_q\right)\right)$，表示为

$$\begin{aligned}&p\left((h,w)\to\left(h_q,w_q\right)\right)\\&=\left(1-\min\left(\frac{\left|h-h_q\right|}{s},1\right)\right)\left(1-\min\left(\frac{\left|w-w_q\right|}{s},1\right)\right).\end{aligned}\tag{2.16}$$

有效感受野中的标记数量 $\left|S\left(h_q,w_q\right)\right|$ 可以按如下方式计算

$$\left|S\left(h_q,w_q\right)\right|=\sum_{(h,w)}p\left((h,w)\to\left(h_q,w_q\right)\right)\times 1\tag{2.17a}$$

$$=\sum_{(h,w)\in S\left(h_q,w_q\right)}\left(1-\frac{\left|h-h_q\right|}{s}\right)\left(1-\frac{\left|w-w_q\right|}{s}\right)\tag{2.17b}$$

$$=\left[\sum_{\Delta h=-(s-1)}^{s-1}\left(1-\frac{|\Delta h|}{s}\right)\right]\left[\sum_{\Delta w=-(s-1)}^{s-1}\left(1-\frac{|\Delta w|}{s}\right)\right]\tag{2.17c}$$

$$=s^2.\tag{2.17d}$$

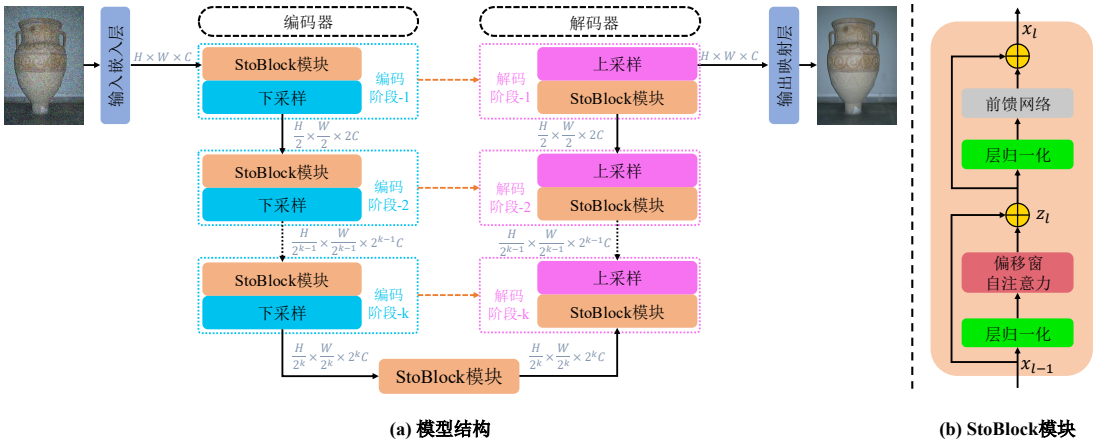
因此，随机窗口策略的有效感受野大小为 $s\times s$。在上述推导中，式 (2.17b) 可由将式 (2.16) 的 $p\left((h,w)\to\left(h_q,w_q\right)\right)$ 和式 (2.15) 的 $S\left(h_q,w_q\right)$ 代入式 (2.17a) 得到。结合随机偏移沿高度和宽度方向的空间对称性（如图 2.3 所示），可以得到感受野也以查询标记为中心具有高度和宽度方向的翻转对称性。 ∎

定理 2.1 揭示了随机窗口策略在以下方面与滑动窗口策略是等效的：（1）它们的感受野大小相等；（2）每个查询标记都有其各自以查询标记为中心的感受野。相比之下，尽管固定窗口策略的感受野大小为 $s\times s$，与随机窗口策略相同，但固定窗口策略的感受野在一个局部窗口内的所有查询标记之间是共享的，与随机窗口策略不同，如图 2.4 所示。

2.4　实验结果与分析

图像复原任务涵盖去噪、去模糊、去雨等多个典型子任务，尽管在表现形式上存在差异，但其本质均可统一建模为从退化图像中重建清晰图像的逆问题建模框架。这些任务之间在退化机制、建模难点和恢复策略上既存在内在联系，也具有各自的特殊性。从共性角度看，它们均面临两个核心挑战：一是图像信息的丢失与扭曲，二是复原过程的多解性与不确定性。在建模策略上，这些任务普遍依赖对图像结构信息与内容信息的综合建模，具有一定程度的可迁移性与方法通用性。因此，从统一视角设计通用复原机制具有理论价值和应用潜力。同时，各子任务在退化模型与数据分布上具有显著差异。图像去噪主要针对空间分布均匀的随机扰动（如高斯噪声），属于局部细节恢复问题；图像去模糊涉及光学

中国知网　https://www.cnki.net



(a) 模型结构　　(b) StoBlock模块

图 2.5　模型结构框架图

或运动退化引发的全局或区域性模糊，具有结构模糊性强、恢复路径不唯一的特点；图像去雨则面对非结构化的局部遮挡（如雨条纹），退化模式具有高度不规则性，挑战在于区分前景雨滴与背景内容。这些差异使得三类任务分别代表了随机扰动、运动退化和遮挡干扰三种典型的图像退化范式。 基于上述分析，本文选择图像去噪、去模糊与去雨作为代表性实验任务，目的是在涵盖多种退化机制与挑战类型的基础上，系统验证所提出模型在不同退化条件下的表现，确保所构建机制在多任务场景下具有实际应用价值与扩展前景。

2.4.1　基本设置

2.4.1.1　模型结构

Stoformer 提供了一种有效且高效的方式将图像空间的先验知识（即局部性和平移等价性）整合到 Transformer 中，满足图像复原任务平移不变性的要求。对于需要像素级预测的图像复原任务，挖掘这些先验知识对性能和效率的提升尤为重要。为了验证所提出的随机窗口策略的有效性，Stoformer 采用广泛应用的 U 型模型架构[145-146]。Stoformer 不仅继承了 Transformer 丰富的、内容自适应的表征能力，还建模了完整的局部关系和实现了图像复原的平移不变性。图 2.5 展示了 Stoformer 整体的模型结构图。

2.4.1.2　实现细节

损失函数。训练过程中采用的损失函数是 Charbonnier 损失[147]，其数学表达式为

$$\mathcal{L}(\hat{\boldsymbol{y}}, \boldsymbol{x}) = \sqrt{\|\hat{\boldsymbol{y}} - \boldsymbol{x}\|_2^2 + \epsilon^2}, \tag{2.18}$$

其中，$\hat{\boldsymbol{y}}$ 和 $\boldsymbol{x}$ 分别是模型输出的图像和清晰图像。常数 ϵ 设置为 10^{-3}。

训练细节。 Stoformer 采用四级编码器-解码器结构。编码器中 StoBlock 数

中国知网　https://www.cnki.net

表 2.1　在 SPA-Data 数据集上的图像去雨定量结果

方法	SPA-Data	
	PSNR	SSIM
GMM[148]	34.30	0.9428
DDN[51]	36.97	0.9604
SPANet[33]	40.24	0.9811
JORDER-E[116]	40.78	0.9811
RCDNet[149]	41.47	0.9834
SPAR[150]	44.10	0.9872
Uformer-FF[120]	47.80	0.9925
Uformer-FE	46.95	0.9917
Stoformer-SF	<u>48.85</u>	<u>0.9935</u>
Stoformer-SE	**48.97**	**0.9938**

量为 $\{1, 2, 8, 8\}$，而解码器中 StoBlock 数量配置与编码器相对称。通道数设置为 32，窗口大小为 8×8。模型使用 Adam 优化器（$\beta_1 = 0.9, \beta_2 = 0.999$）训练模型，初始学习率设置为 3×10^{-4}，并通过余弦退火策略逐渐降低至 1×10^{-6}。训练样本通过水平翻转和 90°、180° 或 270° 的旋转进行数据增强。Stoformer 在两个 Nvidia 3090 GPU 上训练 120 个周期，批量大小为 16，并在全尺寸测试图像上评估 PSNR。

2.4.1.3　模型变体

为了验证了随机窗口策略的有效性，本节引入了四个 Stoformer 变体：Stoformer-FF、Stoformer-FF、Stoformer-SF 和 Stoformer-SE。第一个符号表示是否在训练时采用随机窗口策略（S: 随机窗口策略；F: 固定窗口策略），第二个符号表示是否在推理时采用逐层期望传播算法（E: 逐层期望传播算法；F: 固定窗口策略）。所有实验固定窗口使用偏移窗口的方式来实现（计算方式见式 (2.8)）。Stoformer-FF 在训练和推理时均采用固定窗口策略，因此对应 Uformer，为了与已有工作对比，Stoformer-FF 和 Stoformer-FE 分别命名为 Uformer-FF 和 Uformer-FE。这些模型变体的不同仅体现在训练策略和推理策略，模型的结构设计是相同的。在定量结果表格中，用**加粗**标注最优的结果，用<u>下划线</u> 标注次优的结果。

中国知网　https://www.cnki.net

表 2.2　在 GoPro 数据集上的图像去模糊定量结果

方法	GoPro		HIDE	
	PSNR	SSIM	PSNR	SSIM
Nah 等人[30]	29.08	0.914	25.73	0.874
DeblurGAN[112]	28.70	0.858	24.51	0.871
DeblurGAN-v2[151]	29.55	0.934	26.61	0.875
DBGAN[152]	31.10	0.942	28.94	0.915
IPT[61]	32.52	-	-	-
MPRNet[58]	32.66	0.959	30.96	0.939
SPAIR[150]	32.06	0.953	30.29	0.931
IR-SDE[43]	30.70	0.901	-	-
IR-CM[153]	29.87	0.950	-	-
Uformer-FF[120]	32.80	0.959	30.73	0.937
Uformer-FE	31.62	0.950	29.94	0.928
Stoformer-SF	33.17	0.963	30.91	0.940
Stoformer-SE	**33.24**	**0.964**	**30.99**	**0.941**

表 2.3　图像去噪的定量结果

方法	CBSD68			Kodak24			McMaster			Urban100		
	$\sigma=15$	$\sigma=25$	$\sigma=50$	$\sigma=15$	$\sigma=25$	$\sigma=50$	$\sigma=15$	$\sigma=25$	$\sigma=50$	$\sigma=15$	$\sigma=25$	$\sigma=50$
IRCNN[154]	33.86	31.16	27.86	34.69	32.18	28.93	34.58	32.18	28.91	33.78	31.20	27.70
FFDNet[155]	33.87	31.21	27.96	34.63	32.13	28.98	34.66	32.35	29.18	33.83	31.40	28.05
DnCNN[50]	33.90	31.24	27.95	34.60	32.14	28.95	33.45	31.52	28.62	32.98	30.81	27.59
VDN[156]	33.90	31.35	28.19	-	-	-	-	-	-	-	-	-
FuncNet[157]	34.28	-	-	35.25	-	-	-	-	-	-	-	-
DRUNet[83]	34.30	31.69	28.51	35.31	32.89	29.86	35.40	33.14	30.08	34.81	32.60	29.61
IRSDE[43]	-	31.14	-	-	32.14	-	-	32.39	-	-	-	-
Restormer[64]	34.39	31.78	28.59	35.44	33.02	30.00	35.55	33.31	30.29	35.06	32.91	30.02
Uformer-FF[120]	34.34	31.73	28.52	35.32	32.91	29.83	35.53	33.35	30.34	35.04	32.83	29.66
Uformer-FE	34.30	31.73	28.50	35.22	32.90	29.80	35.40	33.22	30.18	35.00	32.78	29.61
Stoformer-SF	35.10	32.40	29.13	35.50	33.08	30.00	36.00	33.83	30.80	35.37	33.14	30.00
Stoformer-SE	**35.13**	**32.47**	**29.16**	**35.53**	**33.12**	**30.03**	**36.03**	**33.86**	**30.84**	**35.42**	**33.19**	**30.06**

2.4.2　实验结果

2.4.2.1　图像去雨

首先在图像去雨任务上验证了随机窗口策略的效果。除了上述四个 Stoformer 变体外，还包括了七种现有的去雨方法：GMM[148]、DDN[51]、SPANet[33]、

中国知网　https://www.cnki.net

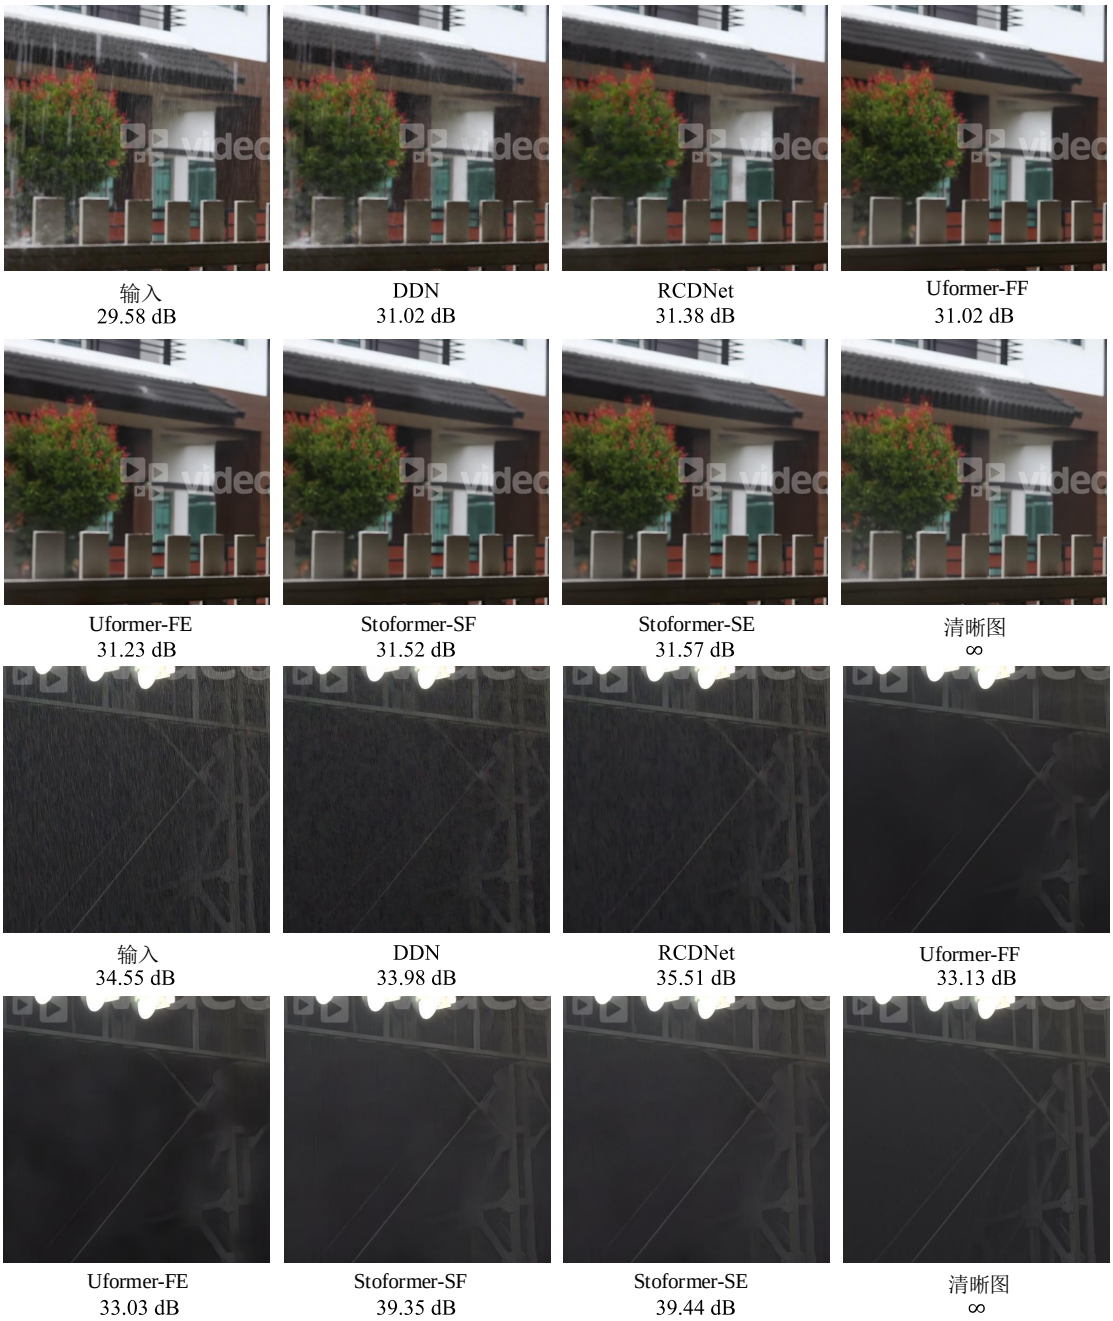


图 2.6　不同方法图像去雨视觉效果

JORDER-E[116]、RCDNet[149]、SPAIR[150]和 Uformer[120]。所有基线方法都在 SPA-Data[33] 数据集上进行评估，模型在 SPA-Data 的训练集上训练。 定量性能对比见表 2.1。图 2.6 展示了在 SPA-Data 测试集上图像去雨的视觉效果对比。

2.4.2.2　图像去噪

本节基于基准数据集进行在高斯噪声去除实验，数据集包括 Set12[50]、BSD68[158]、Urban100[159]、Kodak24[160] 和 McMaster[161]。训练数据是混合数据集，预处理流程与 Restormer[64]一致。对比的基线方法包括：IRCNN[154]、FFDNet[155]、DnCNN[50]、VDN[156]、FuncNet[157]、DRUNet[83]和 Restormer[64]。与

中国知网　https://www.cnki.net

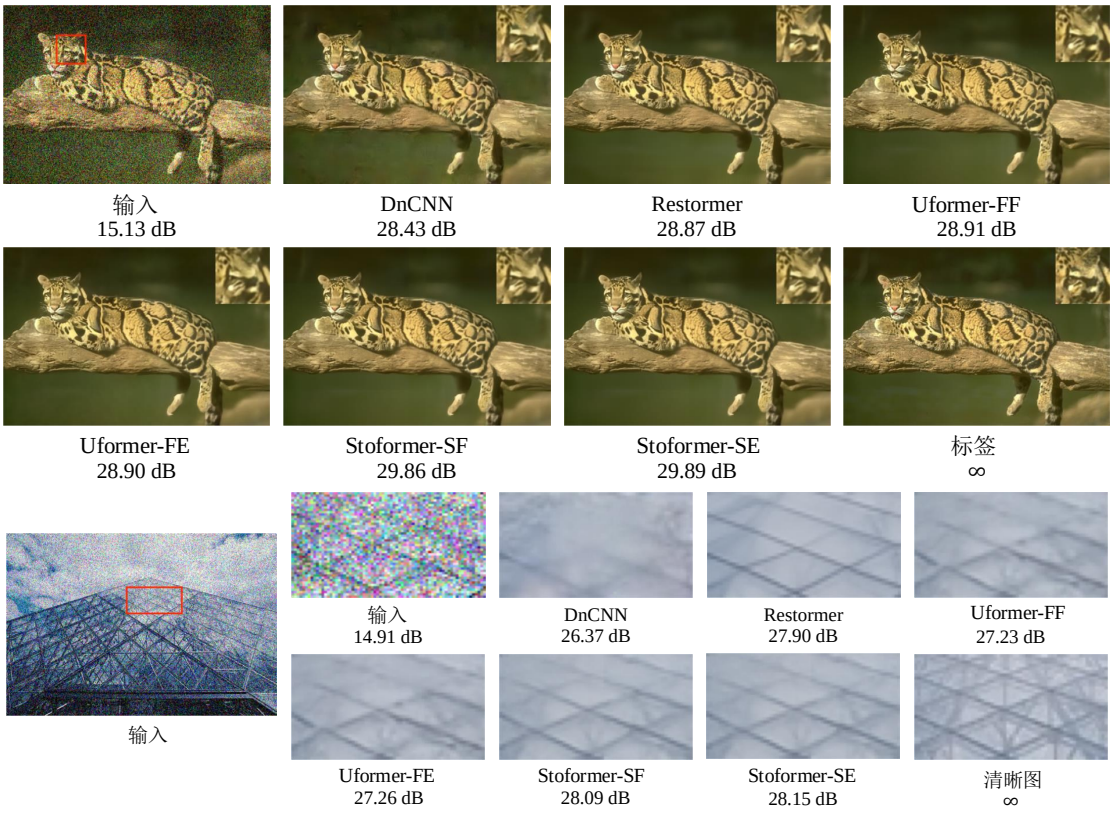


图 2.7　不同方法图像去噪视觉效果

已有研究[50,154,156]一致，本节训练了一个模型来处理不同噪声等级。表 2.3 展示了现有方法和 Stoformer 变体在 RGB 图像去噪上的客观结果。图 2.7 展示了在 BSD68 数据集上图像去噪的视觉效果对比。

2.4.2.3　图像去模糊

本节基于基准数据集 GoPro[30]和 HIDE[162]上进行图像去模糊实验。模型仅在 GoPro 训练数据集上训练，并直接在 GoPro 数据集和 HIDE 数据集上进行评估。比较的方法包括 Nah 等人[30]、DeblurGAN[112]、DeblurGAN-v2[151]、DBGAN[152]、MPRNet[58]和 SPAIR[150]。表 2.2 给出了不同图像去模糊方法和 Stoformer 变体的 PSNR 和 SSIM 的结果。图 2.8 展示了在 GoPro 测试集上不同图像去模糊方法的视觉效果对比。

基于以上图像复原的实验结果，可以得出以下结论：

- Uformer-FF 与 Uformer-FE 对比: 若在训练时没有采用随机窗口策略，直接在推理阶段应用逐层期望传播算法会显著降低性能，这表明直接应用推理阶段的逐层期望传播算法，即使增加了计算量，但是仍无法提升性能，训练阶段的随机窗口样本的采样也是至关重要的。
- Uformer-FF 与 Stoformer-SF 对比: 即使在推理阶段没有采用逐层期望传播算法，单独采用训练阶段的随机窗口训练也有助于提高性能。这是因为

中国知网　https://www.cnki.net

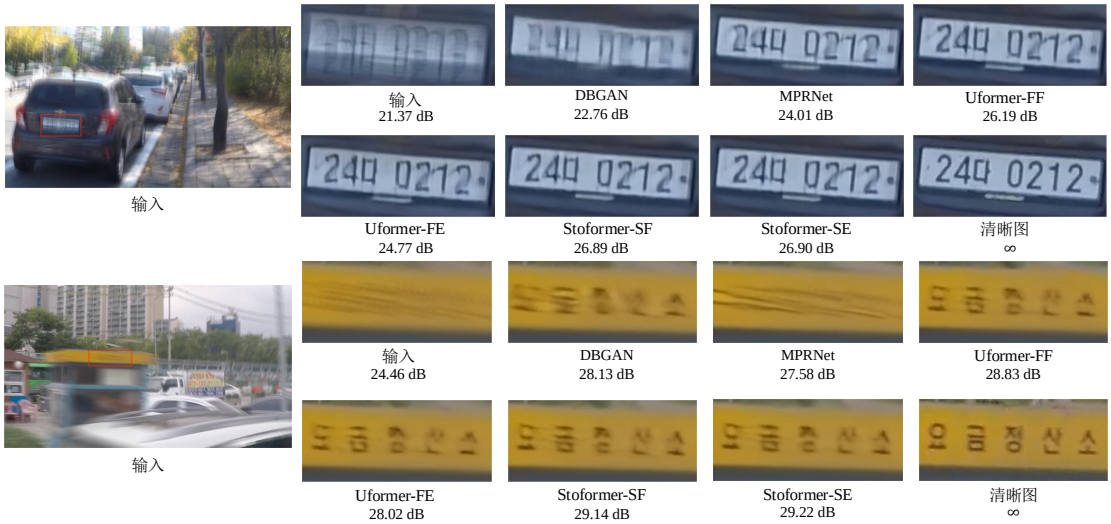


图 2.8　不同方法图像去模糊视觉效果

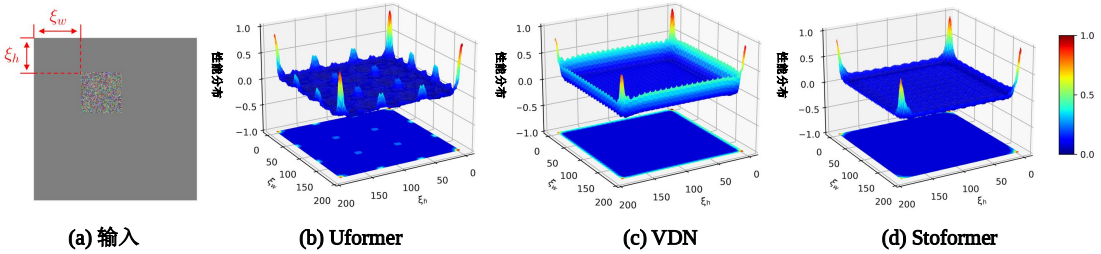


图 2.9　平移不变性的验证

Uformer-FF 丢失的大量局部信息被 Stoformer-SF 重新挖掘并利用。

- Stoformer-SE 与其他方法对比：结合训练时的随机窗口策略和推理时的逐层期望传播算法的模型实现了最优的性能。

2.4.3　分析实验

2.4.3.1　验证平移不变性

为了说明固定窗口策略破坏了平移不变性并验证本章提出的随机窗口策略对平移不变性的修复效果，本节设计实验进行验证：在一个 8-位纯色图像上添加了一个高斯噪声块，图像块大小为 256×256，像素值设置为中值 127，高斯噪声的标准差为 $\sigma=50$，高斯噪声块的分辨率为 64×64。以 1 为步幅移动高斯噪声块，一共获得了 $192\times192=36864$ 张带高斯噪声的图像。随之，分别使用固定窗口的 Transformer（即 Uformer-FF）和随机窗口的 Transformer（即 Stoformer-SE）对这些带噪声的图像去噪处理，利用清晰图像计算输出图像的 PSNR，并归一化到 $[0,1]$，并结合相应的噪声偏移 (ξ_h,ξ_w) 绘制 PSNR 的变化图。图 2.9 中展示了 PSNR 随着噪声块位置的变化图。

为了进一步突出随机窗口 Transformer 能修复平移不变性，本节还比较了一

中国知网　https://www.cnki.net

表 2.4　不同策略训练阶段的时间复杂度和空间复杂度

策略	时间复杂度	空间复杂度	平移等价性 & 局部性
固定窗口	$\Theta\left(BHWCs^2+BHWC^2\right)$	$\Theta\left(BHWC+BHWhs^2\right)$	✗
滑动窗口	$\Theta\left(BHWCs^2+BHWC^2\right)$	$\Theta\left(BHWCs^2+BHWhs^2\right)$	✓
随机窗口	$\Theta\left(BHWCs^2+BHWC^2\right)$	$\Theta\left(BHWC+BHWhs^2\right)$	✓

注：B 表示批量大小，(H,W,C) 表示特征图尺寸，s 为局部窗尺寸，h 为自注意力头数。

表 2.5　不同策略推理阶段的时间复杂度和空间复杂度

策略	时间复杂度	空间复杂度	平移等价性 & 局部性
固定窗口	$\Theta\left(BHWCs^2+BHWC^2\right)$	$\Theta\left((BHWC+BHWhs^2\right)$	✗
滑动窗口	$\Theta\left(BHWCs^2+BHWC^2\right)$	$\Theta\left(BHWCs^2+BHWhs^2\right)$	✓
随机窗口	$\Theta\left(BHWCs^4+BHWC^2\right)$	$\Theta\left(BHWC+BHWhs^2\right)$	✓

注：B 表示批量大小，(H,W,C) 表示特征图尺寸，s 为局部窗尺寸，h 为自注意力头数。

个基于卷积神经网络的经典去噪模型 VDN[156]，由于卷积神经网络的滑动窗口策略，它能够较好地确保平移不变性。图 2.9 表明，由于采用固定窗口策略，Uformer 的 PSNR 分布存在较大的变化；而 Stoformer 则显著地平滑了分布。Stoformer 和 VDN 的分布相对均匀，表明随机窗口策略和滑动窗口策略在修复平移不变性方面表现相似。同时注意到，由于图像边界处的上下文差异，所有方法的 PSNR 都会在图像边界上都有显著变化。

2.4.3.2　复杂度分析

为了分析随机窗口策略的效率优势，本节详细分析基于单个注意力层的随机窗口策略的时间复杂度和空间复杂度。具体地，本节将对比随机窗口策略、固定窗口策略、和滑动窗口策略，并分析它们训练阶段和推理阶段的复杂度。在训练阶段，随机窗口策略在推理速度和显存开销上与固定窗口策略一致，如表 2.4 所示。但是，固定窗口策略会破坏平移等价性和且无法完整地建模局部性关系。滑动窗口策略能够修复平移等价性和局部性关系的建模，但会遭遇巨大的显存负担，通常会导致显存溢出。相比之下，随机窗口策略在训练时保持高效，同时补偿平移等价性和局部关系的缺失。在推理阶段，如表 2.5 所示，固定窗口策略可以高效地推理，但会带来平移不变性破坏和局部关系损失的问题。与滑动窗口策略相比，随机窗口策略需要更多的计算，但显存开销更低。

对于滑动窗口策略，每个查询都对应一组特定的值和键（如图 2.10(b)）。这与固定窗口策略不同，后者在局部窗口的所有查询中具有相同的值和键（如图 2.10(a)）。每个查询具有不同上下文的直接后果是巨大的显存开销。滑动窗

中国知网　https://www.cnki.net

口策略的自注意力算法实现见算法 2.2；固定窗口策略的自注意力算法实现见算法 2.1。具体而言，假设特征的分辨率为 $H \times W$，局部窗口的尺寸为 $s \times s$，滑动窗口策略的键张量和值张量的显存占用将是固定窗口策略的 s^2 倍。由于图像复原任务中的分辨率通常较高，这种巨大的显存使用常常导致显存溢出问题。此外，研究工作[124,142]表明，尽管计算复杂度为 $\Theta(HW)$，滑动窗口策略在深度学习加速器上缺乏内核优化，运行时间速度较慢。值得注意的是，随机窗口策略的复杂度与图像分辨率成线性关系，因而 Stoformer 可以高效的处理高分辨率图像。

算法 2.1 基于固定窗口的自注意力实现

```
import torch.nn.functional as F
def FixedWindowAttention(x, win_size):
        C = x.shape[-1]
        x = F.unfold(x, kernel_size=win_size,stride=
           win_size)
        q, k, v = to_qkv(x)
        q = q * (C ** -0.5)
        attn = (q @ k.transpose(-2, -1))
        attn = softmax(attn + relative_position_bias)
        out = attn @ v
        return out
```

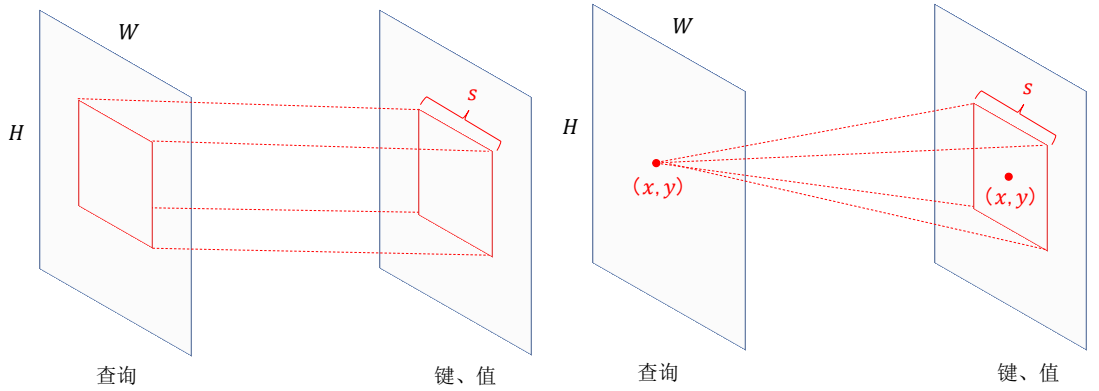
算法 2.2 基于滑动窗口的自注意力实现

```
import torch.nn.functional as F
def SlidingWindowAttention(x, win_size):
        C = x.shape[-1]
        q, k, v = to_qkv(x)
        k, v = pad(k), pad(v) # pad for keeping shape
        k = F.unfold(k, kernel_size=win_size, stride=1)
        #extra memory cost(win_size^2 X)
        v = F.unfold(v, kernel_size=win_size, stride=1)
        q = q * (C ** -0.5)
        attn = (q @ k.transpose(-2, -1))
        attn = softmax(attn + relative_position_bias)
        out = attn @ v
        return out
```

2.4.3.3　消除块状伪影

特定偏移的窗口（如式 (2.8) 的 $(0,0)$ 和 $\left(\frac{s}{2},\frac{s}{2}\right)$）在固定窗口策略中占据全部的优先级，无法等价地处理任意偏移的窗口，因此，模型中的特征图通常会包含块状伪影；相比之下，随机窗口策略等价地处理所有偏移窗口，具有平移等价性。因此，随机窗口策略应可以消除块状伪影。如图 2.11 所示，固定窗口策略学到的特征图包含明显的块状伪影，而使用随机窗口策略则能够按预期消除伪影。

中国知网　https://www.cnki.net



(a) 固定窗口策略　　(b) 滑动窗口策略

图 2.10　固定窗口策略和滑动窗口策略对比图

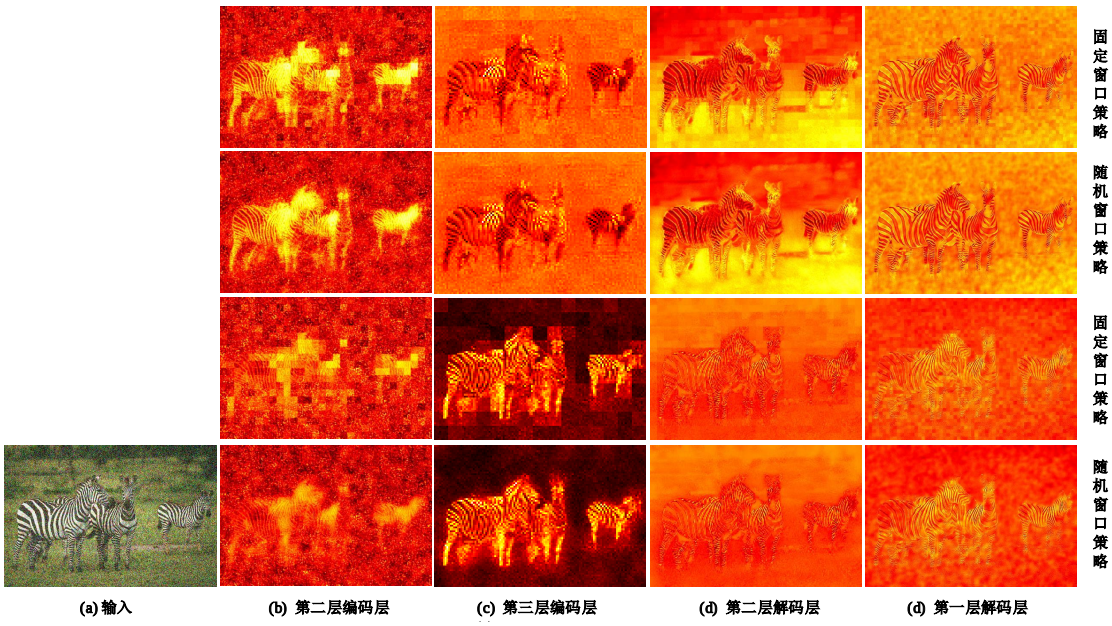


图 2.11　不同策略的特征图可视化

2.4.3.4　逐层期望传播的计算与性能的平衡

相比于精确求解数学期望，逐层期望传播算法显著地加速了推理过程，但仍然需要对自注意力进行 $s \times s$ 次计算并取平均。这里探讨了计算的数量对模型性能的影响。图 2.12 展示了随着计算次数增加，模型性能和推理阶段的浮点运算量（FLOPs）的变化趋势。FLOPs 的统计基于输入分辨率 256×256 的图像。图 2.12 显示，随着计算次数的增加，PSNR 首先迅速上升，随后趋于饱和，而 FLOPs 则随着特征数量线性增加，这提供了模型性能与 FLOPs 的权衡机制。根据图 2.12，计算次数可从 64 降至 8 可以同时保持相对较高的性能和高效的推理。

中国知网　https://www.cnki.net

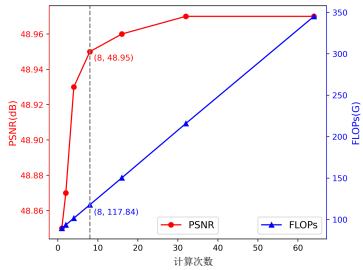


图 2.12　性能与计算的平衡

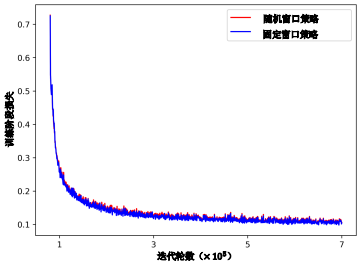


图 2.13　训练损失变化图

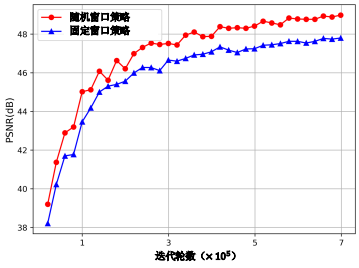


图 2.14　PSNR 变化图

2.4.3.5　提升模型泛化能力

图 2.13 展示了在 SPA-Data 数据集上训练过程中的损失曲线，图 2.14 展示了训练过程中在 SPA-Data 测试集上的 PSNR 变化。与固定窗口策略相比，随机窗口策略在测试集上获得了更高的 PSNR，同时两者训练损失趋势相似，表明随机窗口策略提升了模型的泛化能力。

2.5　本章小结

本章指出了现有图像复原的 Transformer 在局部性关系建模和平移不变性的维持方面的不足，并探讨了增强图像复原 Transformer 模型在局部尺度上表征能力的方法。分析认为，问题的根源在于固定窗口策略，它破坏了窗口间的平移等价性，并导致局部信息的丢失。为了解决这些问题，本章提出了一种随机窗口策略：通过用随机偏移分布替代固定偏移，并将该策略集成到自注意力机制中。通过在训练中采用具有随机偏移的窗口划分，能够等价地处理任意偏移的窗口，从而修复平移不变性问题并完整建模局部信息，在图像空间中引入了局部关联性和平移不变性知识。基于随机偏移自注意力，本章构造了图像复原 Transformer 模型（称为 Stoformer）。在训练阶段，本章提出从随机偏移分布中采样得到随机偏移样本，并基于这些样本设计了高效的训练策略；在推理阶段，本章提出了一种高效的逐期望传播方法，用于近似计算模型输出对随机偏移的数学期望。实验结果表明，所提出的 Stoformer 在多种图像复原任务中表现出了优越的性能。

本章工作的部分内容已发表在机器学习领域权威国际会议 Advances in Neural Information Processing Systems（NeurIPS）。

中国知网　https://www.cnki.net

第 3 章　基于多尺度协作自注意力的图像复原方法

当 Transformer 模型直接应用于图像复原问题时，时间复杂度和空间复杂度随着图像分辨率的平方关系增长，即 $\Theta\left((HW)^2\right)$，这在实际应用中可能导致显存溢出、训练时间过长等问题。而基于局部窗口自注意力的 Transformer 模型，其时间复杂度和空间复杂度随着分辨率线性关系增长，即 $\Theta(HW)$，能够高效地处理高分辨率退化图像。然而，局部窗口自注意力仅能建模局部窗口内的标记间相关性，牺牲了全局建模能力。图像内容通常具有全局相关性，同时复杂退化具有大范围、物理机制复杂、难以显式建模等特点。因此，图像复原 Transformer 模型能够高效地捕捉并建模全局依赖关系至关重要。经典的自注意力在建模图像结构信息方面存在困难。本章提出了一种结构建模与内容建模双分支协作的计算机制，通过这种方式，模型能够实现感知图像的结构以及数据自适应的建模。考虑到图像像素的局部性先验和图像内容的全局相关性先验，本章进一步提出了一种窗内-窗间自注意力机制，结合了局部相关性和全局相关性的多尺度建模能力，在图像空间中引入了内容-结构知识和多尺度关联性知识。基于 U-Net 经典架构，本章最终构建了一种针对图像复原任务的 Transformer 模型——Local-Global Transformer（LGT）。大量的实验结果表明，与现有图像复原方法相比，在处理复杂退化（如图像去雨，特别是包含雨线、雨滴等多种雨效应的复杂场景以及真实世界的图像去噪）时，LGT 在定量指标和主观评估上均表现出更优越的性能。

3.1　概述

图像内容通常具有全局相关性，即在大尺度的图像区域内，视觉特征（如颜色、纹理和形状等）往往呈现出一定的连贯性和一致性。全局相关性是图像复原中重要先验信息，对识别图像语义和判别退化信息具有重要作用。通过利用全局相关性先验，图像复原模型能够有效判别退化信息和恢复缺失信息，确保输出图像的结构完整性和视觉连贯性。此外，复杂的退化过程（如图像噪声或恶劣天气造成的降质）背后的物理机制通常极为复杂，难以显式建模，且这些退化现象往往在空间大尺度上与图像呈现出复杂的耦合关系。因此，对于图像复原模型而言，能提供全局上下文并以此高效地建模与聚合全局信息，是至关重要的。

Transformer 模型因其强大的表征能力（如全局依赖关系建模能力和内容自适应的表征能力）而受到广泛关注。传统的 Transformer 模型通过自注意力机制建模图像中任意位置标记之间的关系，全局性建模使 Transformer 能够捕捉图像中标记的长程依赖关系，从而有效地处理图像复原中的复杂退化现象。然而，直接将 Transformer 应用于图像复原问题会导致时间复杂度和空间复杂度过

中国知网　https://www.cnki.net

高。具体而言，Transformer 的时间复杂度和空间复杂度随着图像分辨率的增加呈二次方关系增长，即假设图像的分辨率为 $H \times W$，其时间复杂度和空间复杂度为 $\Theta\left((HW)^2\right)$。这种二次关系复杂度使 Transformer 在处理高分辨率图像时，面临严重的显存溢出和计算资源消耗过大的问题，尤其在实际应用中，训练和推理的代价过高的问题尤为突出。经典的 Transformer 缺乏视觉任务的归纳偏置（Reductive Bias），因此需要在大规模数据集上预训练才能取得与卷积神经网络相当的性能[20,61]。另一方面，近年来一些研究工作提出基于局部窗口自注意力机制的 Transformer 模型[124,142]，限制了自注意力机制的计算范围，仅在局部窗口内建模标记的相关性。与传统全局自注意力模型相比，局部窗口自注意力模型的时间复杂度和空间复杂度显著降低，随着分辨率的增长呈线性增加，即为 $\Theta(HW)$，从而显著提高了计算和显存效率。因此，局部窗口自注意力模型在处理高分辨率图像时，能够更高效地利用计算资源，并避免了显存溢出等问题。然而，局部窗口自注意力机制仅能建模局部窗口内标记间相关性，忽略了图像中大尺度信息的建模。尽管局部窗口自注意力能够有效处理图像中局部区域的恢复（如细节恢复和纹理处理），但在面对具有空间大尺度特点的图像退化问题时，其表征能力受到限制。例如，在图像去雨任务中，雨线通常呈现出空间上的大尺度延展性，并且容易与图像背景发生复杂的耦合关系，仅依赖局部信息难以在大范围内实现一致且精确的复原效果。因此，在保证计算效率的同时尽可能保留全局建模能力，是将 Transformer 模型应用于图像复原的难点。

图像内容信息是指组成图像的标记的具体张量值，通常与图像的像素强度、纹理细节、色彩分布等视觉显著性直接相关。这些内容信息决定了图像的视觉呈现细节，对图像复原任务中恢复纹理、颜色、边缘等底层特征具有直接影响。图像结构信息则侧重于图像中各个标记在空间域中的排列顺序和相对位置关系。它描述了图像中各组成部分之间的几何布局、形态构型与空间组织模式，直接影响对图像形状、轮廓以及语义的感知。例如，即使图像中所有标记的数值保持不变，若其空间排列被打乱，则将难以从中识别出原有的语义信息。这说明结构信息对于视觉感知的完整性至关重要。在图像复原任务中，内容信息有助于提升局部区域的像素级重构质量，而结构信息则有助于保持全局一致性和语义连贯性。特别是在退化图像的复原过程中，仅依赖像素层面的重构往往无法恢复准确的图像结构，容易导致视觉伪影或语义失真。因此，实现内容信息与结构信息的联合建模和互补补偿，是提升图像复原质量的关键方法之一。 经典的 Transformer 无法独立建模和挖掘结构信息，因此本章提出了结构建模与内容建模双分支协同的新型计算机制。研究表明，结构建模可通过卷积高效实现，内容建模则可通过自注意力机制实现。通过卷积和自注意力的协作，模型能够从内容与结构两个维度提取并建模图像的信息。基于图像局部窗口内的像素相关性以及内容的全

中国知网　https://www.cnki.net

局性先验，本章进一步提出了新型的窗内-窗间自注意力机制。窗内-窗间自注意力不仅能够在局部范围内捕捉标记间的依赖关系，还能通过全局感知建模图像中跨区域的长程交互，从而兼顾复原结果的精度和一致性。在此基础上，本章结合经典的 U-Net 架构，提出了一种针对图像复原任务的 Transformer 模型，称为 Local-Global Transformer（LGT）。U-Net 架构凭借其编码-解码结构和跳跃连接，具有效率高、性能优等的特点。通过将窗内-窗间自注意力机制与 U-Net 架构结合，LGT 模型能够充分利用图像的全局上下文信息，恢复图像的局部细节，从而在多种复杂图像退化场景下实现显著的复原效果。同时，由于引入了有效的视觉归纳偏置，LGT 避免了昂贵的预训练过程。大量实验结果表明，LGT 在处理复杂图像退化问题时，尤其是图像去雨（复杂雨效应，包含雨线、雨滴）和图像去噪，表现出明显的优势。此外，实验分析表明，内容建模分支和结构建模分支在信息处理方面具有互补效应，为图像复原模型的设计提供了新的视角和思路。

本章的主要贡献包括：

- 分析了现有基于 Transformer 的图像复原方法在结构信息建模方面的不足，提出一种结构信息与内容信息双分支协作的自注意力计算模型，并通过实验验证了双分支建模的互补作用。
- 基于图像的局部性先验和全局性先验，设计了一种互补的窗内-窗间自注意力机制，实现对多尺度特征的协同建模，能够兼顾局部尺度的细节恢复与全局尺度的退化判别。
- 提出了一种新型的图像复原 Transformer 模型，称为 Local-Global Transformer（LGT）。通过引入合理的归纳偏置，LGT 不仅具备强大的表征能力，还避免了经典 Transformer 昂贵的预训练过程。
- 实验验证了 LGT 的有效性。LGT 在处理复杂图像退化问题时，尤其是在图像去雨（包括复杂雨效应的耦合，如雨线、雨滴）等退化复杂的场景中，表现出明显的优势。
- 提出了内容-结构建模与局部-全局建模的设计理念，并通过实验验证了其有效性，为图像复原模型的设计提供了新思路。

3.2　背景

近年来，针对视觉 Transformer 在建模局部细节与全局关系时的效率与性能问题，研究者提出了多种融合策略，包括：（1）滑动窗口机制，在局部窗口内建模局部注意力，通过窗口滑动实现全局连接，提升局部性建模效率。SwinIR[62]将 Swin Transformer 结构应用于图像复原，增强局部细节还原能力。HAT[163]在 Swin 基础上进一步引入多层特征聚合，提升超分辨率性能。（2）交叉窗口机制，局

中国知网　https://www.cnki.net

部窗口内建模，同时在横向/纵向建立长条形窗口，强化远距离依赖建模。CSwin Transformer[164]引入横纵交叉注意力，比标准窗口连接更高效捕捉远距离关系。SwinV2[165]在 Swin 上扩展，适配更大窗口、引入连续连接机制，进一步提升全局感知能力。（3）金字塔式降采样建模，通过逐步降低分辨率，扩大感受野，减少计算量，同时维持全局建模能力。PVT[123] 多尺度特征提取，每层逐步降低分辨率，适应高分辨率输入。SegFormer[166]基于 PVT 理念，用于高效图像分割，强调金字塔多尺度表征。（4）动态注意力，在自注意力中引入动态位置选择或变形卷积思想，灵活选择局部 + 全局感兴趣区域。Deformable DETR[167]将动态采样机制应用于自注意力，提升长距离建模效率。（5）混合注意力，局部窗口 + 全局特征直接融合，实现局部细节与全局摘要同时建模。局部窗口 + 全局特征直接融合，实现局部细节与全局摘要同时建模。MaxViT[168]同时施加局部和全局注意力，提升大尺寸图像处理能力。CoaT[169]将卷积特征与不同尺度的注意力融合，兼顾局部感知和全局推理。

本文提出的内容-结构双分支协作自注意力机制，在局部-全局基本思想基础上进行了进一步创新，与已有方法相比，具有以下主要区别：

- 显式双分支设计：通常在同一路径内隐式融合局部和全局特征，而本文通过内容建模分支与结构建模分支的独立设置，使局部纹理细节与大尺度结构轮廓能够在不同子空间内专注建模，从源头上解耦特征冲突，提升表达能力。
- 协作式融合机制：本文设计了窗内-窗间互补注意力机制，内容分支负责局部细节恢复，结构分支捕捉跨区域关联，并通过协作融合动态调整特征流动方向，优于简单加权或堆叠式融合方式。

因此，本文方法不仅在架构设计上实现了对局部与全局特征建模路径的创新分离，综合考虑了退化图像的结构建模与内容建模，在功能实现上更好地满足了图像复原任务对结构细节同时优化的双重需求。

3.3　方法设计

本节详细介绍 LGT 中的模型设计细节。图像是一类高度结构化的数据，结构信息构建图像语义发挥重要作用，提取并建模结构信息对图像复原是十分重要的。经典自注意力机制依靠内容信息建模，而无法有效地建模结构信息。针对这个问题，第 3.3.1 节提出了内容-结构双分支自注意力的基本模块。具体地，分析结构建模方法并提出利用卷积层实现结构信息的建模、自注意力层实现内容信息的建模的双分支建模方法。内容-结构双分支注意力作为自注意力基础的计算模块，用以搭建后续的窗内-窗间自注意力以及图像复原网络。第 3.3.2 节引入

中国知网　https://www.cnki.net

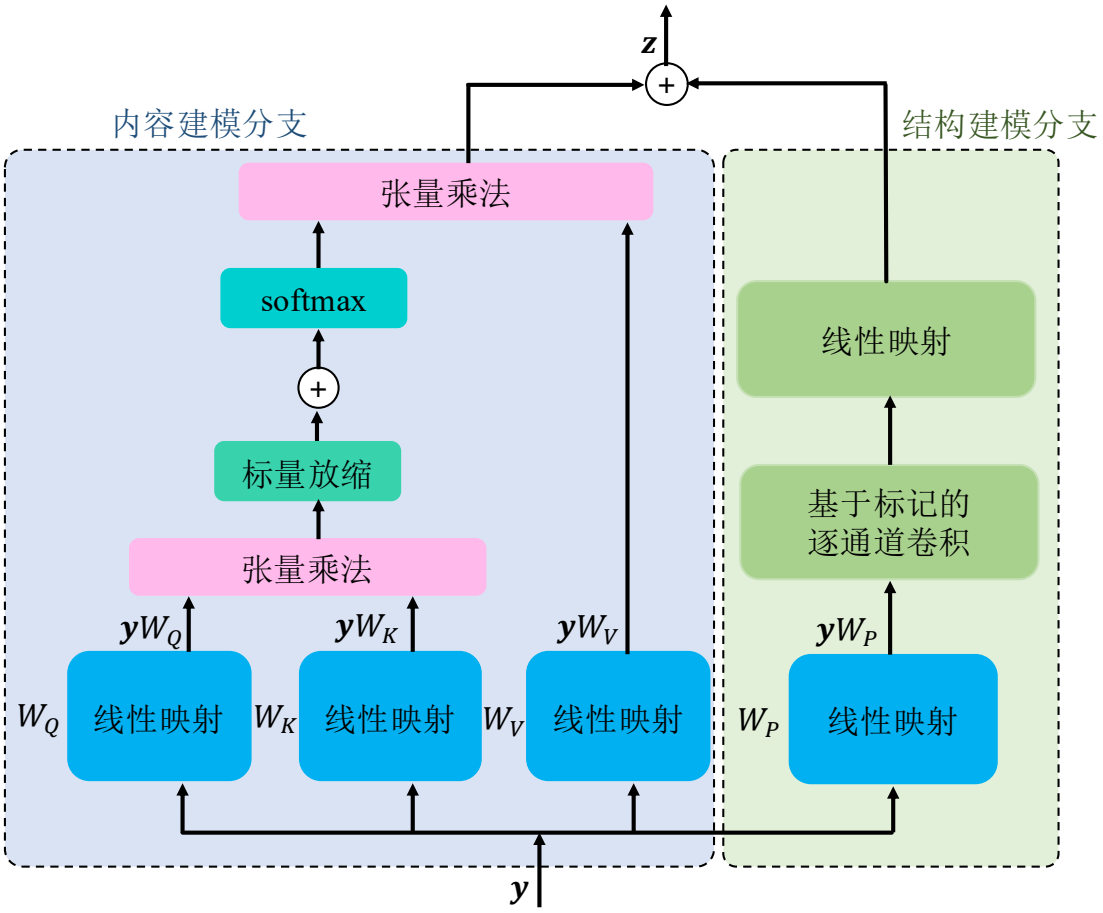


图 3.1　内容-结构双分支自注意力的计算图

Transformer 中前馈网络层，采用引入逐通道卷积层实现局部增强的前馈网络。受启发于图像局部窗口内像素间的相关性以及图像内容的全局相关性，第 3.3.3 节提出了一种新型的窗内-窗间自注意力机制。窗内-窗间自注意力机制通过窗内自注意力在局部范围内捕捉标记间的依赖关系，有利于恢复细节纹理；通过窗间自注意力建模窗口间的长程交互，极大地扩展了模型的建模范围，实现大尺度范围内退化信息的建模。两者结合，窗内-窗间自注意力机制有效提升图像复原效果的精度与一致性。基于上述基础模块，第 3.3.4 节介绍图像复原 Transformer 模型（LGT）的构建方法。

3.3.1　内容-结构双分支自注意力

首先，本节将自注意力的数学表达扩展到二维图像中，随后，分析了其在结构建模方面的局限性，并基于此引入内容-结构双分支协作的自注意力机制（Dual Branch Multi-head Self-Attention，DBMSA）。

对于图像数据，标记（Token）排列在 2D 平面上。设 $\boldsymbol{y} \in \mathbb{R}^{H\times W\times C}$ 为输入张量，由 $H \times W$ 个标记组成，每个标记的维度为 C。为了保持符号简洁，引入一个 2D 索引向量：如果 $\mathbf{t} = (i, j)$，则 $\boldsymbol{y}_{\mathbf{t},:}$ 代表 $\boldsymbol{y}_{i,j,:}$。一个自注意力层将 $\boldsymbol{y}$ 映射

中国知网　https://www.cnki.net

到一个新的标记构成的 2D 平面张量 $\boldsymbol{z} \in \mathbb{R}^{H \times W \times C}$

$$\boldsymbol{z}_{\mathbf{t},:} = \sum_{\mathbf{k} \in \mathcal{N}_{\text{sa}}} \text{softmax}(A)_{\mathbf{t},\mathbf{k}} (\boldsymbol{y} W_V)_{\mathbf{k},:}, \tag{3.1}$$

其中，$\mathcal{N}_{\text{sa}}$ 表示自注意力计算的区域：$[1, \cdots, H] \otimes [1, \cdots, W]$，$\times$ 表示标量的乘法，$\otimes$ 表示集合的笛卡尔积；$W_V \in \mathbb{R}^{C \times C}$ 是线性映射的参数矩阵，作用是将 $\boldsymbol{y}$ 映射为值张量（value）；张量 A 为注意力权重，通过查询张量（query）和键张量（key）点积操作计算[19]，即

$$A = \frac{\boldsymbol{y} W_Q (\boldsymbol{y} W_K)^T}{\sqrt{D_k}}. \tag{3.2}$$

W_Q 和 $W_K \in \mathbb{R}^{C \times C}$ 是线性映射的参数矩阵，分别将输入张量映射为查询张量和键张量。D_k 为键张量的维度，即为 C。实际应用中，为了增强自注意力的表征能力，将自注意力机制实现为多头版本，多头自注意力中不同的注意力头可以独立地提取并建模来自不同表征空间的信息[19]，最终，通过线性映射实现了不同注意力头特征的融合

$$\boldsymbol{z} = \underset{h \in [1, \cdots, N_h]}{\text{concat}} \left[\text{softmax}(A^h) \left(\boldsymbol{y} W_V^h \right) \right] W_O, \tag{3.3}$$

其中，$\text{concat}_{h \in [1, \cdots, N_h]}$ 为张量拼接函数，即拼接不同的注意力头的输出张量，N_h 是自注意力头的数量，W_O 是用于线性变换的参数矩阵。A^h 表示第 h 个自注意力头权重张量，其形式为

$$A^h = \frac{\boldsymbol{y} W_Q^h \left(\boldsymbol{y} W_K^h \right)^T}{\sqrt{D_k^h}}, \tag{3.4}$$

其中，W_Q^h、$W_K^h \in \mathbb{R}^{C \times \frac{C}{N_h}}$ 和 $W_V^h \in \mathbb{R}^{C \times \frac{C}{N_h}}$ 是第 h 个头的参数矩阵，D_k^h 表示键张量头的维度，其值为 $\frac{C}{N_h}$，$W_O \in \mathbb{R}^{C \times C}$ 为不同注意力头的融合矩阵。根据式 (3.3) 和式 (3.4)，多头自注意力首先将输入张量通过 N_h 个不同的线性变换映射到查询张量、键张量和值张量。基于这些查询张量、键张量和值张量，执行并行的注意力操作以得到每个注意力头的结果。最后，将不同的注意力头的输出结果进行拼接并融合得到最终的输出值。自注意力的一个关键特性是它对标记序列重新排序是等变的，即其输出不依赖于输入标记的排列方式[170]。这个性质决定了自注意力无法建模结构信息，标记通常代表图像中的像素或图像块，而其结构信息在构建图像语义时起着至关重要的作用。Swin Transformer[124] 通过将相对位置编码引入到注意力权重张量 A 来建模位置信息

$$\boldsymbol{z}_{\mathbf{t},:} = \sum_{\mathbf{k} \in \mathcal{N}_{\text{sa}}} \text{softmax} \left(A + B \right)_{\mathbf{t},\mathbf{k}} \left(\boldsymbol{y} W_V \right)_{\mathbf{k},:}, \tag{3.5}$$

中国知网　https://www.cnki.net

其中，$\boldsymbol{B} \in \mathbb{R}^{H\times W\times H\times W}$ 是相对位置编码张量，通过查询张量和键张量的相对位置进行索引，即 $\left(\text{query}_h, \text{query}_w, \text{key}_h, \text{key}_w\right)$。高度和宽度维度方向的相对位置分别位于范围 $[-H+1, H-1]$ 和 $[-W+1, W-1]$，因此，通过梯度反传学习相关位置编码张量 $\hat{\boldsymbol{B}} \in \mathbb{R}^{(2H-1)\times(2W-1)}$，并从 $\hat{\boldsymbol{B}}$ 中索引的值来组成 $\boldsymbol{B}$ 中的值。然而，式 (3.5) 中位置建模和内容建模共享相同的值表示空间，即位置建模和内容建模用于加权相同的值表示 $\boldsymbol{y}\boldsymbol{W}_V$，这会位置建模和内容建模间形成不理想的折衷。内容信息和结构信息在视觉系统中具有不同的神经加工路径。例如，Livingstone 等人[171]提出，人类初级视觉皮层在处理边缘、纹理等结构信息与色彩、形状等内容信息时存在显著的区域分工。因此，在图像建模中采用内容-结构双分支机制（DBMSA），符合人类视觉认知的功能划分，也有助于模型更有效地捕捉图像不同层次的信息特征。 DBMSA 的数学表示如式 (3.6) 所示

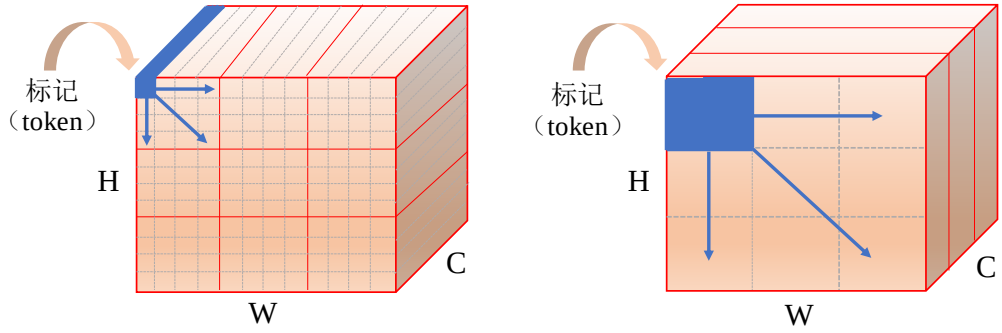
$$\boldsymbol{z}_{\mathbf{t},:} = \underbrace{\sum_{\mathbf{k}\in\mathcal{N}_{\text{sa}}} \text{softmax}\left(A+B\right)_{\mathbf{t},\mathbf{k}} \left(\boldsymbol{y}\boldsymbol{W}_V\right)_{\mathbf{k},:}}_{\text{内容建模}} + \underbrace{\sum_{\mathbf{k}\in\mathcal{N}_{\text{st}}} w_{\mathbf{t}-\mathbf{k}} \odot \left(\boldsymbol{y}\boldsymbol{W}_P\right)_{\mathbf{k},:}}_{\text{结构建模}}. \tag{3.6}$$

其中，$\boldsymbol{W}_P \in \mathbb{R}^{C\times C}$ 是参数矩阵，旨在将 $\boldsymbol{y}$ 映射为用于结构建模的值表示张量，$\mathcal{N}_{\text{st}}$ 是结构建模的计算区域，$w_{\mathbf{t}-\mathbf{k}}$ 是一个权重张量，通过相对位置 $\mathbf{t}-\mathbf{k}$ 索引，依靠标记间相对位置关系提取并建模图像结构信息。需要注意的是，在式 (3.6) 中，若 $\boldsymbol{B}=\boldsymbol{0}$，自注意力会退化为传统的基于内容的自注意力，因此，保留了相对位置编码张量 $\boldsymbol{B}$ 会赋予模型更强的表征能力。为了模型的计算和推理效率，将 w 的最大建模距离裁剪到 $\sigma \in \mathbb{N}$，即对于 $w_{\mathbf{t}-\mathbf{k}}$，将索引 $\mathbf{t}-\mathbf{k}$ 限制在 $\mathcal{N}(\sigma) = [-\sigma, \cdots, \sigma] \otimes [-\sigma, \cdots, \sigma]$ 范围内，基于此，式 (3.6) 可以重新表述为

$$\boldsymbol{z}_{\mathbf{t},:} = \sum_{\mathbf{k}\in\mathcal{N}_{\text{sa}}} \text{softmax}\left(A+B\right)_{\mathbf{t},\mathbf{k}} \left(\boldsymbol{y}\boldsymbol{W}_V\right)_{\mathbf{k},:} + \sum_{\mathbf{k}\in\mathcal{N}(\sigma)} w_{\mathbf{k}} \odot \left(\boldsymbol{y}\boldsymbol{W}_P\right)_{\mathbf{t}+\mathbf{k},:}. \tag{3.7}$$

通过限制最大建模距离，可以发现式 (3.7) 右侧的第二项等价于尺寸为 $(2\sigma+1)\times(2\sigma+1)$ 卷积核的、应用于二维标记平面的卷积。因此，卷积可以补偿自注意力机制的图像空间结构感知，同时，卷积作为一种基础的网络层，可以在主流深度学习平台上（如 Pytorch）高效地实现。在实际应用中，为了节省计算和显存，将卷积实现为逐通道卷积（Depth-wise convolution），用于在标记空间实现结构信息建模；其后的前馈网络主要在标记的通道维度计算，与自注意力交互的维度互补，旨在更新标记内部的信息，实现标记的迭代与进化。图 3.1 展示了所提出的 DBMSA 的详细流程图。双分支计算模块可以很容易地扩展到多头版本：对每个注意力头并行执行上述描述的双分支计算，拼接每个注意力头输出，并最终通过线性变换融合不同注意力头的输出。

中国知网　https://www.cnki.net



(a) 窗内自注意力　　(b) 窗间自注意力

图 3.2　窗内自注意力和窗间自注意力互补感受野的示意图

注：标记用蓝色标记，标记在红色实线划分的区域内交互。

3.3.2　前馈网络

前馈网络（Feed-Forward Network, FFN）是 Transformer 的关键组成部分，FFN 的经典范式为利用线性层对每个标记维度扩展、非线性激励函数做非线性变换、和利用线性层对每个标记维度压缩。在经典 FFN 范式的基础上，局部增强的 FFN（Locally-enhanced Feed-Forward Network，LeFF）[172]在维度扩展层和压缩层之间引入了 3×3 逐通道卷积来增强局部性信息建模。假设 $\boldsymbol{z}_l^m \in \mathbb{R}^{H\times W\times C}$ 表示第 l 个编码块或解码块中第 m 个 LeFF 层的输入，对标记的处理流程是首先通过线性层映射和 GELU 激活函数[173] 扩展到更高维度 $\tilde{\boldsymbol{z}}_l^m \in \mathbb{R}^{H\times W\times kC}$，其中 k 是扩展比例；其次，使用核大小为 3×3 的逐通道卷积和 GELU 激活函数进行处理，输出为 $\hat{\boldsymbol{z}}_l^m \in \mathbb{R}^{H\times W\times kC}$；最后，处理后的标记经过线性层被重新映射回原始维度，得到输出 $\boldsymbol{y}_l^m \in \mathbb{R}^{H\times W\times C}$。综上所述，LeFF 的计算过程可表述为

$$\tilde{\boldsymbol{z}}_l^m = \mathrm{GELU}\left(\mathrm{MLP}\left(\boldsymbol{z}_l^m\right)\right), \tag{3.8a}$$

$$\hat{\boldsymbol{z}}_l^m = \tilde{\boldsymbol{z}}_l^m + \mathrm{GELU}\left(\mathrm{DConv}\left(\tilde{\boldsymbol{z}}_l^m\right)\right), \tag{3.8b}$$

$$\boldsymbol{y}_l^m = \mathrm{MLP}\left(\hat{\boldsymbol{z}}_l^m\right). \tag{3.8c}$$

3.3.3　窗内-窗间自注意力

窗内-窗间自注意力机制包括窗内自注意力和窗间自注意力。窗内自注意力和窗间自注意力中标记定义和交互范围的可视化如图 3.2 所示。窗内自注意力在局部窗内进行自注意力计算标记的交互，而窗间自注意力将局部窗口视作标记，在全局范围内建模窗口间的交互。窗内自注意力和窗间自注意力在建模范围上是互补的。受启发于金字塔层级建模策略，窗内-窗间自注意力串联方式连接，窗内自注意力捕捉精细局部特征，而窗间部分负责建模全局关联，通过串联结构实现由局部到全局的逐层融合。第 2章 的随机窗口自注意力探索了局部依赖关系的建模方案，而无法有效地感知图像空间内大尺度长程依赖关系；反之，窗内-窗

中国知网　https://www.cnki.net

间自注意力则侧重局部关系与全局依赖的互补建模。

3.3.3.1　窗内自注意力

图像中的像素的依赖关系通常呈现出局部性的特点，即邻近区域的像素具有强的相关性，诸如纹理、颜色或亮度等视觉特征往往在局部范围内保持一致或呈现渐变趋势。局部性先验在图像复原中发挥着重要作用，能够有效引导模型捕捉图像中的细节与局部结构信息。例如，局部性先验已被内置于到卷积神经网络（CNN）中，即使用大小为 $k \times k$ 卷积核从局部区域聚合信息，并以一定的步幅滑动遍历整张图像。卷积神经网络在实践中的成功应用证明了局部性先验对图像复原的有效性[17,174-175]。

与卷积神经网络不同，研究工作表明[20,61]，Transformer 是一种通用的基础模型，缺乏视觉任务的归纳偏置，需要从大量视觉数据中预训练获取。该预训练过程消耗大量的硬件、时间与数据资源。受 Swin Transformer[124]的启发，局部性先验可由局部窗口自注意力的方式直接嵌入 Transformer。图 3.2(a) 是窗内自注意力的标记的定义及其交互范围的示意图，特征图被划分为非重叠的窗口，并且来自同一局部窗口的标记参与自注意力的计算。此外，在窗内自注意力前使用层归一化[176]，并且采用残差连接以减轻网络的学习负担，提高模型的训练效率。结合第 3.3.2 节中的 LeFF 前馈网络，窗内自注意力-前馈网络整体的计算过程可以表示为

$$\boldsymbol{z}_l^m = \boldsymbol{y}_l^{m-1} + \text{InWin-DBMSA}\left(\text{LN}\left(\boldsymbol{y}_l^{m-1}\right)\right), \tag{3.9a}$$

$$\boldsymbol{y}_l^m = \boldsymbol{z}_l^m + \text{LeFF}\left(\text{LN}\left(\boldsymbol{z}_l^m\right)\right). \tag{3.9b}$$

上式中，InWin-DBMSA $(\cdot)$ 表示窗内双分支自注意力，LN $(\cdot)$ 表示层归一化，$\boldsymbol{y}_l^{m-1}$ 表示第 l 编码块或解码块中第 m 个自注意力层的输入，$\boldsymbol{y}_l^m$ 表示第 l 编码块或解码块中第 m 个自注意力层的输出。

3.3.3.2　窗间自注意力

图像的全局性先验即图像中的像素在全局范围显存在的依赖关系或相关性。这一先验假设基于图像的整体结构和语义信息，即图像的不同区域之间可能存在长程的、跨区域的依赖关系。图像的全局性先验能够帮助模型从宏观角度捕捉图像的上下文、语义信息和空间关联性，为图像复原任务提供全局的上下文指引，影响退化信息和图像信息的判别，进而影响图像复原的性能。

第 3.3.3.1 节引入了窗内自注意力机制，然而，窗内自注意力仅能建模局部窗口内标记间的局部关系，不具有全局性的上下文信息。为了弥补这一缺陷，本节引入窗间自注意力，如图 3.2(b) 所示，一个局部窗口被视为一个标记，窗间的

中国知网　https://www.cnki.net

依赖关系用双分支自注意力建模。为了节省计算和显存，窗间双分支自注意力机制中 标记的划分以逐通道的方式（Depth-wise）执行，如图 3.2(b) 所示。类似于逐通道卷积，每一个通道的窗口被视作一个标记，且在空间维度上交互，建模窗口间关系的模型参数是共享的。LeFF 用于沿通道方向做特征融合，其交互方向与窗间自注意力正交。与窗内自注意力类似，窗间自注意力也采用残差连接和层归一化提升模型训练效率。结合第 3.3.2 节中的前馈网络模块，窗间自注意力-前馈网络整体的计算过程表示为

$$\boldsymbol{z}_l^{N_i} = \boldsymbol{y}_l^{N_i} + \text{CrossWin-DBMSA}\left(\text{LN}\left(\boldsymbol{y}_l^{N_i}\right)\right), \tag{3.10a}$$

$$\boldsymbol{y}_l = \boldsymbol{z}_l^{N_i} + \text{LeFF}\left(\text{LN}\left(\boldsymbol{z}_l^{N_i}\right)\right). \tag{3.10b}$$

其中，CrossWin-DBMSA(·) 表示窗间双分支自注意力，$\boldsymbol{y}_l^{N_i}$ 表示第 l 编码块或解码块中最后一个前馈网络模块的输出，$\boldsymbol{z}_l^{N_i}$ 是第 l 编码块或解码块中窗间自注意力层的输出，$\boldsymbol{y}_l$ 代表第 l 编码块或解码块的最终输出。

3.3.3.3　建模效率分析

由第 2 章知，自注意力机制的时间复杂度和空间复杂度为 $\Theta\left(L^2C\right)$，L 代表标记序列的长度，C 代表标记的维度。假设局部窗口的尺寸大小为 $s\times s$，特征图的空间分辨率为 $H\times W$，对于窗内自注意力，标记序列的长度为 $s\times s$，标记的维度为 C，共有 $\frac{H}{s}\times\frac{W}{s}$ 个窗内自注意力，窗内自注意力的复杂度为

$$\Theta\left(s^4C\times\frac{H}{s}\times\frac{W}{s}\right)=\Theta\left(s^2HWC\right). \tag{3.11}$$

对于窗间自注意力，标记序列的长度为 $\frac{H}{s}\times\frac{W}{s}$，标记的维度为 $s\times s$，共有 C 个窗间自注意力，窗间自注意力的复杂度为

$$\Theta\left(\frac{H^2W^2}{s^4}\times s^2\times C\right)=\Theta\left(\frac{H^2W^2C}{s^2}\right). \tag{3.12}$$

因此，窗内-窗间自注意力的总复杂度为 $\Theta\left(s^2HWC+\frac{H^2W^2C}{s^2}\right)$。根据算术平均与几何平均不等式，有如下不等式

$$s^2HWC+\frac{H^2W^2C}{s^2}\geqslant 2\left(HW\right)^{\frac{3}{2}}C, \tag{3.13}$$

当 $s=(HW)^{\frac{1}{4}}$ 时，等式成立。此时，窗内-窗间自注意力的时间复杂度和空间复杂度为 $\Theta\left((HW)^{\frac{3}{2}}C\right)$。

3.3.4　整体网络架构

LGT 的整体结构如图 3.3 所示，是一个对称的层次化的（Hierarchical）编码器-解码器网络，编码器和解码器间具有跳跃连接以提升模型训练效率。LGT 处

中国知网　https://www.cnki.net

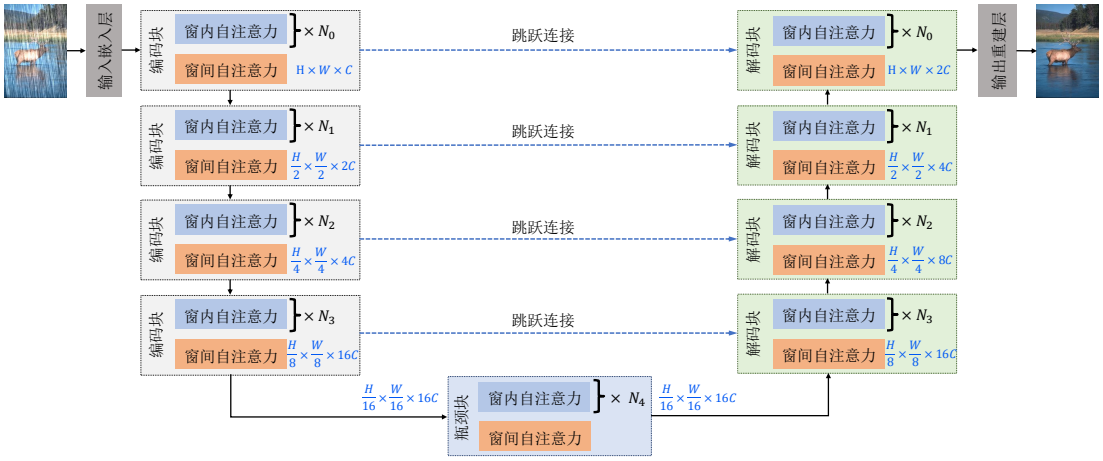


图 3.3　模型架构图

注：每个编码块和解码块由 N_i 个窗内自注意力和一个窗间自注意力构成。通过窗内和窗间自注意力互补的建模范围，LGT 能够在每个编码块和解码块捕获长程依赖关系。

理图像的具体流程是，输入图像首先通过输入嵌入层，该嵌入层由一个标准的 3×3 卷积层和一个非线性激活函数组成，目的是完成图像空间到标记空间的映射，实现图像标记的提取；其次，标记序列输入到 LGT 的主干网络中，主干网络是通过编码器模块和解码器模块堆叠构成的。每个编码器模块和解码器模块在特定分辨率处理标记序列。在编码阶段，空间分辨率以 2× 的速率逐渐减小，同时通道维度 2× 的速率逐渐增加；在解码阶段，空间分辨率以 2× 的速率逐渐增加，同时通道维度 2× 的速率逐渐减小。最后，解码后的标记序列通过输出重建层被映射为复原的图像，输出重建层由一个标准的 3×3 卷积层构成。

与标记维度恒定的经典视觉 Transformer[20] 不同，LGT 显著的特点之一是层次化（Hierarchical）结构。层次化结构是视觉处理系统中的一个重要的结构，层次化结构中浅层提取底层的特征，深层负责处理具有抽象的、强语义和复杂性的特征[174,177-178]。受 Swin Transformer[124] 启发，LGT 在模型中引入了局部性、全局性的先验知识，并为图像复原任务构建了专门的 Transformer 架构。LGT 还采用了跳跃连接（skip-connection）方案，连接编码块和对应的解码块，以减小信息的损失。由于长程关系建模仍有 $\Theta(HW)^{\frac{3}{2}}$ 的复杂度，为了提升模型的训练与推理效率，本章将采用“窗内自注意力为主，窗间自注意力为辅”的策略。即每个编码器模块和解码器模块由 $N_{i\in[0,1,2,3,4]}$ 个级联的窗内自注意力模块和一个窗间自注意力模块组成。如图 3.2 所示，窗内自注意力旨在捕捉局部窗口内的局部关系，而窗间自注意力则通过建模跨窗口的依赖关系获取全局上下文。因此，LGT 可以在每个编码阶段和解码阶段增强局部性信息建模，同时能够获得图像的全局上下文。

中国知网　https://www.cnki.net

3.4　实验结果与分析

3.4.1　实现细节

LGT 包含 4 个编码块，1 个瓶颈块，以及 4 个解码块，分别由 $N_{i=0,1,2,3,4}$ 个窗内自注意力模块和 1 个窗间自注意力模块构成。$\{N_0, N_1, N_2, N_3, N_4\}$ 设置为 $\{3,3,2,2,1\}$，9 个基础编码块、瓶颈块和解码块的自注意力头数设置为 $\{1,2,4,8,16,16,8,4,2\}$，初始通道数 C 设置为 32，前馈网络中通道扩展比例设置为 4。模型优化过程中采用 Adam 优化器[29]，训练批量大小为 8。在训练过程中，图像被随机裁剪成尺寸为 128×128 的图像块，随机应用水平翻转（概率 $p=0.5$）和垂直翻转（概率 $p=0.5$）的方式进行数据增强，学习率初始值为 1×10^{-4}，在 4×10^5 次迭代后，降低为 1×10^{-5}，整个训练过程需要 5×10^5 次迭代。在推理阶段，将测试图像裁剪为 128×128 的不重叠的图像块，对于沿轴方向进行剪切后的最后一批图像块，需要利用前面图像的内容进行填充，以满足 128×128 的分辨率要求。为了确保公平比较，所有基线方法都在相同处理过的测试集上进行评估。在定量结果的表中，用**加粗**标注最优的结果，用<u>下划线</u>标注次优的结果。值得注意的是，图像复原的推理时间并不会因为图像块的划分而显著增加。由于高的时间复杂度和空间复杂度，Transformer 难以直接处理高分辨率退化图像。一个可行的策略是将图像裁剪为图像块，LGT 分别处理每个图像块，可以减少由高分辨率输入带来的计算和处理负担。考虑一幅分辨率为 $H\times W$ 的图像，LGT 的计算复杂度为 $\Theta\left((HW)^{\frac{3}{2}}\right)$。然而，如果输入图像被裁剪为固定大小的图像块，单个图像块的处理时间仅依赖于图像块的大小，与分辨率 $H\times W$ 无关。图像块的总数为 $\frac{HW}{s^2}$，其中 $s\times s$ 是图像块的大小。因此，利用这种图像块分割策略能以 $\Theta\left((s\times s)^{\frac{3}{2}}\times\frac{HW}{s^2}\right)=\Theta(HWs)$ 的时间复杂度和空间复杂度处理整张图像。

3.4.2　实验结果

3.4.2.1　图像去雨

在图像去雨任务上验证 LGT，使用的图像去雨基准数据集包括：Rain200H[53]、Rain200L[53]、DDN-Data[52]、DID-Data[179]、SPA-Data[33] 和 Internet-Data[33]。对比的基线方法包括：GMM[180]、JCAS[181]、DDN[52]、NLEDN[182]、RESCAN[183]、PreNet[184]、JORDER-E[54]、Syn2Real[185]、RCD-Net[186]、MSPFN[57]、CCN[31]、MPRNet[58]、Uformer-S[120]、SwinIR[62] 和 Restormer[64]。Rain200H 和 Rain200L 是 Yang 等人[53]提出的两个基准数据集，它们分别包含不同程度雨线污染的图像，每个数据集包括 1800 张训练图像和 200 张测试图像。DDN-Data 数据集包含 1000 张清晰图像，这些图像分别来自 UCID 数据集[187]、BSD 数据集[188]以及 Google 图像搜索，用于合成 14000 对

中国知网　https://www.cnki.net

退化雨图-清晰图数据。DID-Data 数据集[179]包含 12000 对具有三种不同雨密度的训练图像，以及 1200 张测试图像。SPA-Data 数据集是 Wang 等人[33]提出的真实世界的雨图数据集，包含 638,464 张训练图像，以及 1000 对测试图像。Internet-Data 数据集[33]包含 147 张真实世界的雨图像，且没有配对的清晰图像，主要用于评估模型的泛化能力。除了雨线数据集，AGAN-Data 数据集是由 Qian 等人[189]收集的雨滴数据集，包含 1110 对退化图-清晰图数据。对比的基线方法包括：Eigen 等人[190]、Pix2Pix[146]、AttentGAN[189] 和 Quan 等人[191]。考虑更复杂的退化场景，雨天环境中拍摄的图像包含雨线、雨滴等复杂雨效应，Quan 等人[31]提出了 RainDS 数据集，RainDS 数据集包含不同类型雨噪声的图像及其对应的清晰图像，雨噪声大致分为雨线（RS）、仅有雨滴（RD）和两者都有（RDS）。RainDS 包含两个子集：RainDS-Syn 和 RainDS-Real。RainDS-Syn 是一个合成数据集，包含 3600 对被雨线和雨滴污染的图像和对应的清晰图像，这些图像的采集场景是基于自动驾驶数据集中的第一人称视角驾驶场景。RainDS-Real 是在真实雨场景中采集的数据集，包含 750 对雨图像及其配对的清晰图像。

表 3.1 展示 LGT 与其他方法在基准图像去雨数据集上的性能对比，LGT 的 PSNR 和 SSIM 指标显著优于现有的图像去雨方法。例如，在 Rain200H、Rain200L、DDN-Data、DID-Data 和 SPA-Data 数据集上，LGT 与 MPRNet[58]对比，PSNR 分别提高了 1.48 dB、1.39 dB、0.5 dB、0.88 dB 和 1.65 dB。此外，NLEDN[192]也引入了全局建模模块，与 NLEDN 相比，LGT 实现了显著的性能提升，可以从两个方面进行解释：首先，NLEDN 的全局建模模块缺乏建模结构的机制；其次，卷积操作仅依赖于位置信息和固定权重来聚合信息，缺乏对内容的自适应性建模，因而灵活性不足，无法有效地处理复杂多样的雨噪声。相比之下，LGT 通过内容-结构双分支建模方法可以图像内容的自适应建模和图像结构信息的提取，同时，LGT 也具有全局依赖关系的建模能力。此外，LGT 在很多数据集上超过了基于 Transformer 的图像复原方法。例如，在 Rain200H、Rain200L、DDN-Data 和 DID-Data 数据集上，与 SwinIR[62]比较，LGT 的 PSNR 分别提高了 0.48 dB、0.67 dB、0.8 dB 和 1.05 dB。表 3.3 展示 LGT 与其他基线方法在雨滴效应去除的定量对比。真实雨天场景下拍摄的图像通常同时受到多种雨噪声例如雨滴和雨线的污染。由于雨滴和雨线在形状和结构上存在显著差异，因此，雨线和雨滴联合去除既具有挑战性，也具有实际意义。为了进一步验证 LGT 的优越性，LGT 在 RainDS 数据集上进行性能评估。如表 3.2 所示，LGT 在处理更复杂雨噪声污染的图像时取得了优异的性能。LGT 在合成数据集 RainDS-Syn 和真实世界数据集 RainDS-Real 超越了基线方法。例如，LGT 在 RainDS-Syn 和 RainDS-Real 数据集的联合去除雨滴和雨线（RDS）任务中，对比经典的卷积神经网络 MPRNet，PSNR 提高了 1.88 dB 和 0.48 dB；在 RainDS-Syn 数据集上，与 PreNet 对比，LGT

中国知网　https://www.cnki.net

表 3.1　在基准数据集上图像去雨定量结果

方法	Rain200H		Rain200L		DDN-Data		DID-Data		SPA-Data	
	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
GMM[180]	14.71	0.4298	28.99	0.8752	28.45	0.8371	25.14	0.8284	35.30	0.9377
JCAS[181]	14.87	0.4713	30.05	0.8968	27.56	0.8674	24.73	0.8579	35.91	0.9411
DDN[52]	26.36	0.8028	34.93	0.9578	30.16	0.8874	31.31	0.8849	38.90	0.9640
NLEDN[182]	29.51	0.8905	38.56	0.9804	32.05	0.9176	33.64	0.9208	43.18	0.9811
RESCAN[183]	27.45	0.8207	35.08	0.9594	30.94	0.8818	32.00	0.8924	40.24	0.9724
PreNet[184]	29.04	0.8904	37.12	0.9755	32.75	0.9273	33.37	0.9192	40.20	0.9788
JORDER-E[54]	28.58	0.8756	36.90	0.9726	32.08	0.9110	33.23	0.9070	40.97	0.9794
Syn2Real[185]	29.04	0.8878	35.30	0.9679	30.79	0.8930	31.54	0.8956	39.63	0.9709
RCDNet[186]	29.79	0.8934	39.82	0.9840	32.89	0.9234	33.88	0.9194	40.62	0.9738
MSPFN[57]	29.66	0.8901	39.48	0.9838	32.93	0.9230	33.45	0.9266	42.93	0.9832
CCN[31]	29.99	0.9138	38.26	0.9812	32.67	0.9252	32.13	0.9238	41.94	0.9770
MPRNet[58]	30.76	0.9075	39.89	0.9847	33.46	0.9284	34.24	0.9327	45.00	0.9897
Uformer-S[120]	30.80	0.9105	40.20	0.9860	33.14	0.9312	34.46	0.9333	46.13	0.9913
SwinIR[62]	31.76	0.9151	40.61	0.9871	33.16	0.9312	34.07	0.9313	44.97	0.9890
Restormer[64]	31.39	0.9164	40.58	0.9872	**34.04**	**0.9340**	**35.20**	**0.9363**	46.25	0.9911
LGT	**32.24**	**0.9312**	**41.28**	**0.9882**	33.96	0.9336	35.12	0.9348	**46.65**	**0.9916**

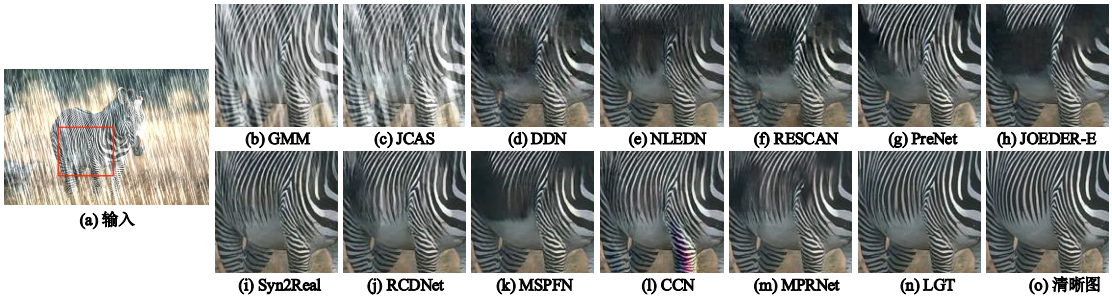


图 3.4　在 Rain200H 数据集上的图像去雨视觉效果

分别在雨线数据集（RS）、雨滴数据集（RD）和联合数据集（RDS）上 PSNR 分别提高了 5.43 dB、4.85 dB 和 4.77 dB。这些实验结果证明，LGT 在单图像去雨任务中能够超越现有的方法，取得更精确的图像复原结果。

图 3.4 展示了 LGT 处理密集型雨线的退化图像的视觉效果，得益于灵活且强大的表征能力，LGT 能够从局部和全局区域提取更多具有判别性的特征。因此，LGT 在去除雨条纹的同时保留更多图像细节，达到了最佳的视觉效果。图 3.5 展示了 LGT 处理稀疏型雨线污染的退化图像的视觉效果。图 3.6 展示了 LGT 处理真实世界的退化雨图像的视觉效果。LGT 能够去除雨噪声，同时保留更多细节（例如，图像中的白色条纹）。为了评估模型的泛化能力，将在 Rain200H 上训练的模型处理真实世界的 Internet-Data。图 3.7 展示了 LGT 处理真实世界的退化雨

中国知网　https://www.cnki.net

表 3.2　在 RainDS 数据集上的定量结果

方法	RainDS-Syn						RainDS-Real					
	RS		RD		RDS		RS		RD		RDS	
	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
GMM[180]	26.66	0.7808	23.04	0.7934	21.50	0.6689	23.73	0.5595	18.60	0.5539	21.35	0.5756
JCAS[181]	26.46	0.7858	23.15	0.8108	20.91	0.6705	24.04	0.5560	18.18	0.5549	21.22	0.5845
DDN[52]	30.41	0.8694	27.92	0.8849	26.85	0.7957	24.85	0.6826	23.12	0.6418	22.47	0.6057
NLEDN[182]	36.24	0.9576	34.87	0.9573	32.13	0.9168	27.02	0.7230	24.71	0.6709	24.06	0.6503
RESCAN[183]	30.99	0.8869	29.90	0.9072	27.43	0.8180	26.70	0.6829	24.23	0.6373	23.23	0.5872
PreNet[184]	36.63	0.9681	34.58	0.9640	32.21	0.9336	26.43	0.7294	24.42	0.6789	23.57	0.6490
JORDER-E[54]	33.65	0.9245	33.51	0.9435	30.05	0.8700	26.56	0.7133	24.34	0.6618	23.54	0.6286
Syn2Real[185]	33.26	0.9340	30.53	0.9163	29.90	0.9072	26.27	0.7043	24.67	0.6638	24.05	0.6341
RCDNet[186]	39.37	0.9772	37.57	0.9738	34.63	0.9449	26.71	0.7180	24.74	0.6692	24.00	0.6394
MSPFN[57]	38.61	0.9752	36.93	0.9732	34.08	0.9470	26.45	0.7270	24.49	0.6810	24.11	0.6510
CCN[31]	39.17	0.9810	37.30	0.9757	34.79	0.9570	27.46	0.7367	25.14	0.7008	24.93	0.6791
MPRNet[58]	40.99	0.9836	37.22	0.9739	35.10	0.9570	27.51	0.7355	25.26	0.7013	25.03	0.6823
Uformer-S[120]	40.88	0.9727	37.20	0.9673	35.07	0.9550	27.01	0.7298	25.39	0.7005	24.94	0.6876
SwinIR[62]	40.67	0.9739	38.14	0.9675	35.03	0.9523	27.53	0.7425	25.69	0.7010	25.05	0.6813
Restormer[64]	41.56	0.9809	38.96	0.9768	36.21	0.9626	27.57	0.7438	25.49	0.7045	25.11	0.6879
LGT	**42.06**	**0.9879**	**39.43**	**0.9809**	**36.98**	**0.9687**	**27.90**	**0.7451**	**26.08**	**0.7088**	**25.51**	**0.6961**

表 3.3　在 AGAN-Data 数据集上的图像去雨滴定量结果

方法	Eigen 等人[190]	Pix2Pix[146]	AttentGAN[189]	Quan 等人[191]	LGT
PSNR	21.31	27.20	31.59	31.37	**31.87**
SSIM	0.7572	0.8359	0.9170	0.9183	**0.9313**

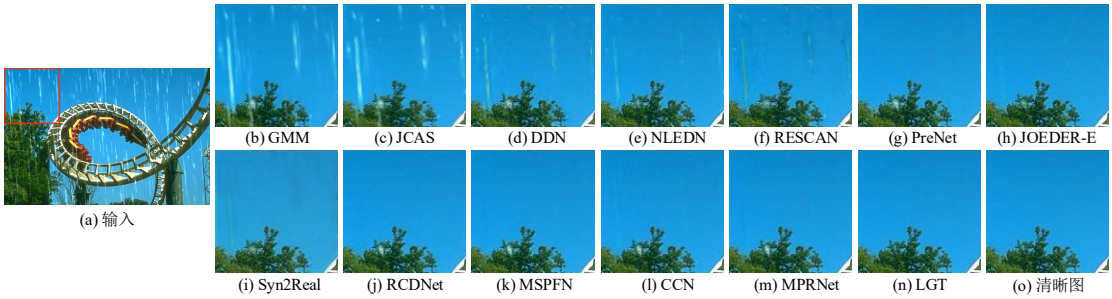


图 3.5　在 Rain200L 数据集上的图像去雨视觉效果

图像的视觉效果，与其他方法相比，LGT 取得了最好的视觉效果。图 3.8 展示了 LGT 处理复杂的雨噪声（雨线和雨滴）污染的退化图像的视觉效果，与其他方法相比，LGT 可以同时处理多种雨噪声，同时不会在背景上造成模糊。

中国知网　https://www.cnki.net

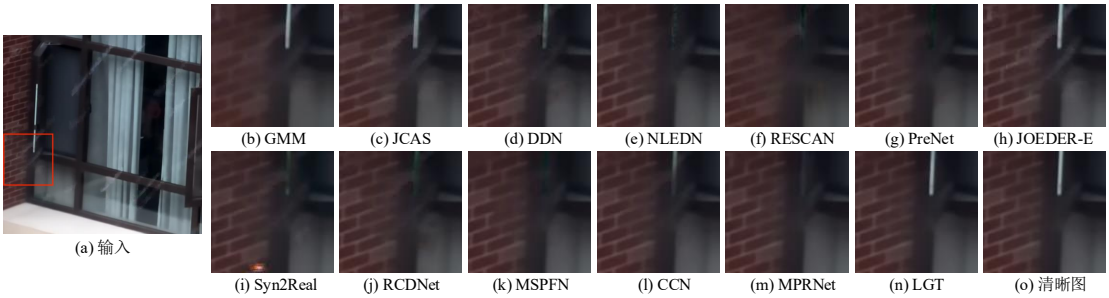


图 3.6　在 SPA-Data 数据集上的图像去雨视觉效果

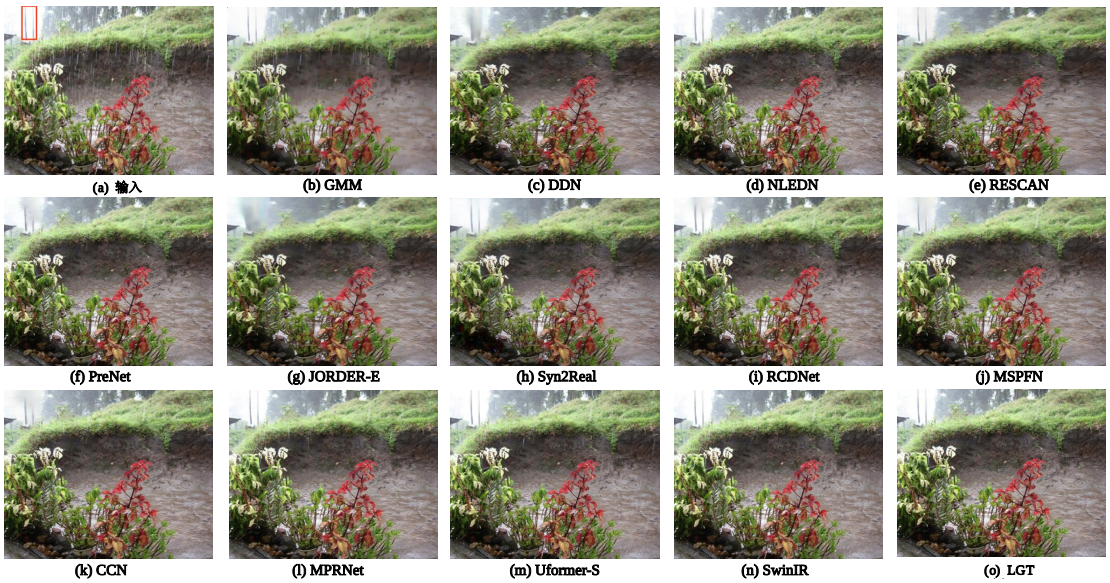


图 3.7　在 Internet-Data 数据集上的图像去雨视觉效果

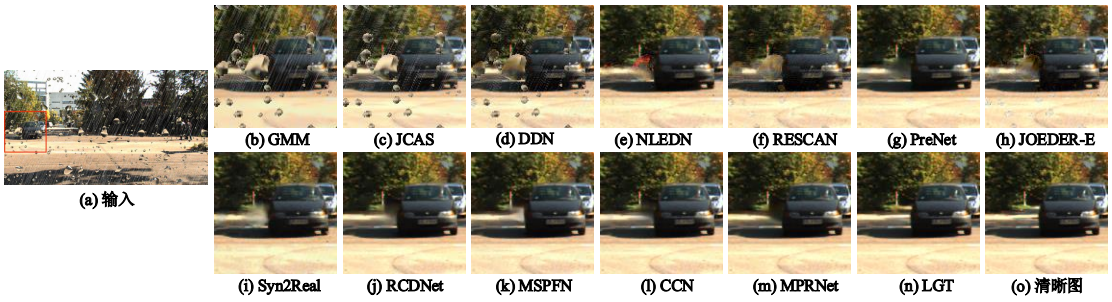


图 3.8　在 RainDS-Syn 数据集上的图像去雨视觉效果

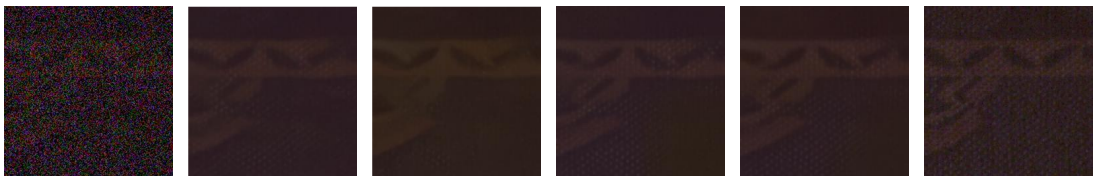
表 3.4　在 SIDD 数据集上的图像去噪定量结果

方法	BM3D[1]	DnCNN[50]	VDN[156]	DANet[193]	CycleISP[194]	MIRNet[115]	DeamNet[195]	MPRNet[58]	DAGL[196]	Uformer-S[120]	LGT
PSNR	25.65	23.66	39.28	39.47	39.52	39.72	39.35	39.71	38.94	39.77	**39.79**
SSIM	0.685	0.583	0.956	0.957	0.957	**0.959**	0.955	0.958	0.953	**0.959**	**0.959**

3.4.2.2　图像去噪

LGT 的模型设计融合了多种合理的视觉先验，因此可以应用于多种图像复原任务。本节探究 LGT 在图像去噪任务上的性能。为了验证 LGT 的表征能力，考

中国知网　https://www.cnki.net



(a) 输入　(b) MIRNet　(c) MPRNet　(d) Uformer　(e) LGT　(f) 清晰图

图 3.9　在 SIDD 数据集上的图像去噪视觉效果

虑真实世界的噪声退化场景，在真实世界噪声数据集 SIDD[197] 上评估 LGT 的性能，基线模型包括：BM3D[1]、DnCNN[50]、VDN[156]、DANet[193]、CycleISP[194]、MIRNet[115]、DeamNet[195]、MPRNet[58]、DAGL[196] 和 Uformer[120]。表 3.4 是在 SIDD 数据集上 LGT 与其他方法图像去噪性能的定量对比。可以得出结论，相较于基线方法，LGT 在真实世界去噪任务中仍取得优异的性能。

3.4.3　消融实验

在本节通过消融实验分析 LGT 中各设计的作用。在默认设置下，实验基于图像去雨基准数据集 Rain200H。

3.4.3.1　结构建模分支

如前所述，自注意力对标记序列的处理结果是与标记序列的顺序无关的，这导致自注意力无法提取并建模结构信息。然而，对于计算机视觉任务，图像像素或图像块被视作标记，其位置对于构建图像语义至关重要。研究表明[124,140]，与绝对位置编码相比，相对位置建模能够获得更好的性能。Swin Transformer[124] 在注意力张量 $\boldsymbol{A}$ 中引入了额外的相对位置编码 $\boldsymbol{B}$。然而，这种方法位置和内容建模利用相同的值表示空间。与将位置信息整合到输入内容（绝对位置编码）或注意力图（相对位置编码）中的方法不同，LGT 将结构建模视为一个独立的分支，并为捕捉结构关系建立单独的值表示空间，利用高效的逐通道卷积层实现结构信息建模。如表 3.5 所示，$\boldsymbol{M}_a$ 是没有任何位置编码信息的模型变体，$\boldsymbol{M}_b$ 和 $\boldsymbol{M}_c$ 分别表示使用相对位置编码和结构建模分支的模型变体。表 3.5 揭示了无相对位置编码（$\boldsymbol{M}_a$）会导致 PSNR 下降超过 0.6 dB，SSIM 下降超过 0.01。此外，使用独立的结构建模分支（$\boldsymbol{M}_c$）比使用相对位置编码（$\boldsymbol{M}_b$）的模型有更优越的性能。最后，结合两者的模型（LGT）取得了最佳的结果。

特征图的可视化。为了进一步探究所提出的结构建模分支的机理，图 3.10 展示了 LGT 模型中特征图的可视化。基于雨图像输入，图 3.10 分别展示了来自第一个编码块和最后一个解码块（见图 3.3）的第一个窗内自注意力处理后的特征图。特别地，这些特征分别由内容建模分支（图 3.1 的左支）、结构建模分支（图 3.1 的右支）和最终的内容-结构双分支自注意力输出的特征。观察图 3.10，可以得出以下结论：

中国知网　https://www.cnki.net

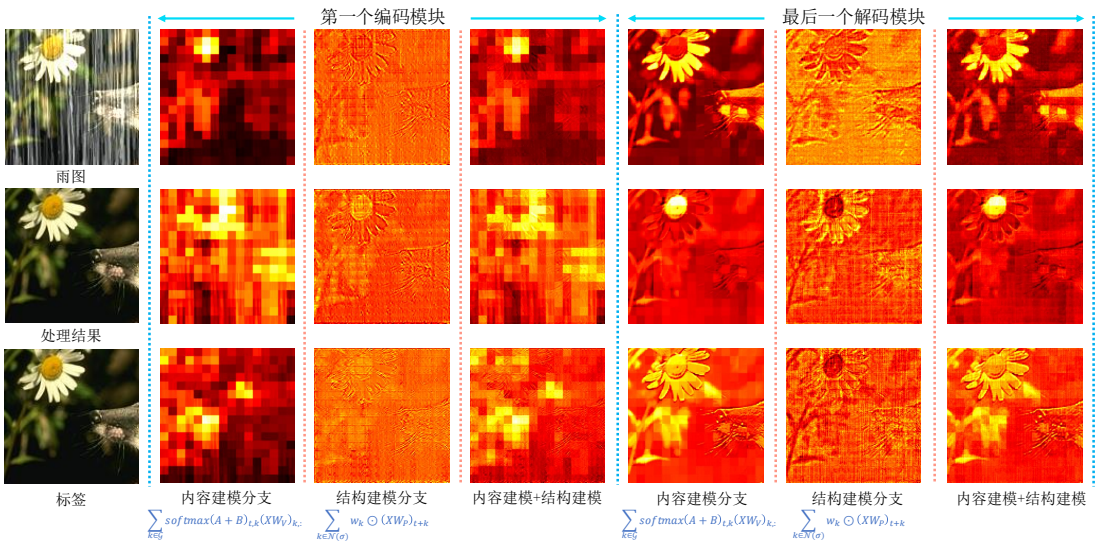


图 3.10　特征图的可视化

- 内容建模分支（第二列和第五列）可以关注待恢复图像的不同区域。第一个编码块的特征中，图像信息和雨噪声信息开始分离；在最后解码块的特征中，有意义的图像背景部分得到了进一步的增强，同时雨噪声被去除。
- 结构建模分支（第三列和第六列）可以提取更多的图像纹理信息，有助于实现复原更多的图像细节，进而实现更精确的图像复原效果。
- 结合结构建模和内容建模的双分支（第四列和第七列）可以提取并建模兼具语义和细节的多层次的特征，不仅能够更好地判别图像信息和雨噪声信息，同时还能保留更多图像纹理信息。

频域分析。除了特征图的可视化，图 3.11 从信号处理角度分析了双分支自注意力的功能。具体而言，对输入特征以及内容建模分支和结构建模分支输出的特征分别进行了离散傅里叶变换（DFT），并且在频域分析双分支建模的滤波行为。如图 3.11 所示，内容建模分支滤除高频信号成分，起到了低通滤波器的作用。然而，抑制高频会不可避免地导致图像纹理的丧失。与内容建模分支不同，结构建模分支起到了高通滤波器的作用，这为内容建模分支损失的高频纹理细节提供了补偿。结构建模分支可以利用位置信息提取特征，图 3.11 表明，结构建模分支可以保留高频结构信息。值得注意的是，结构建模分支是用逐通道卷积实现的，内容建模分支是用自注意力实现的，这说明从信号处理的角度，卷积和自注意力是互补的。这个结论与近期的研究成果一致[198-199]，这些研究也发现了自注意力的低通滤波特性，以及卷积和自注意力的滤波行为的互补性。

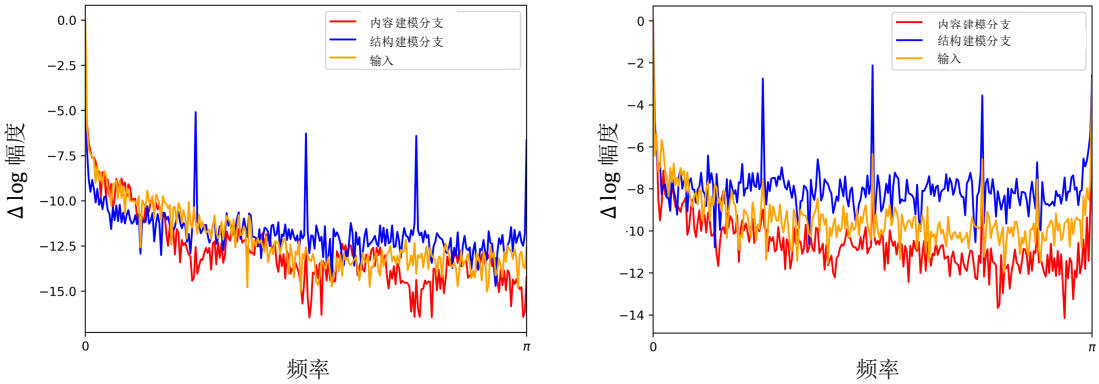
3.4.3.2　最大建模距离的影响

为了提升模型训练和推理效率，第 3.3.1 节将最大相对位置距离限制为 σ。这里研究该最大距离对模型性能的影响，结果如表 3.6 所示，可以发现，当 $\sigma = 2$

中国知网　https://www.cnki.net

表 3.5　结构建模分支的消融分析

模型变体	M_a	M_b	M_c	LGT
相对位置编码	✗	✓	✗	✓
结构建模分支	✗	✗	✓	✓
PSNR	31.61	32.02	32.18	32.24
SSIM	0.9209	0.9301	0.9311	0.9312



(a) 第一个编码模块的相对幅度谱　　(b) 最后一个解码模块的相对幅度谱

图 3.11　内容建模分支和结构建模分支的滤波特性分析

时，模型的性能最佳；而当 $\sigma > 2$ 时，模型无法进一步提升性能。考虑到模型的计算和存储需求会随着建模距离 σ 增加而增大。在实验中，σ 默认设置为 2。

表 3.6　最大建模距离对性能影响

σ	0	1	2	3	4
PSNR	31.84	32.00	32.24	31.16	31.15
SSIM	0.9260	0.9276	0.9312	0.9307	0.9308

3.4.3.3　窗间自注意力的有效性验证

从全局区域聚合信息并为图像复原中提供有效的上下文有助于提升模型对图像信息和退化信息的判别，进而提升模型性能。尽管 LGT 的层次化设计能够带来更大的感受野，但模型在特定层只能从局部区域获取特征，无法获得有效的上下文信息。这些局部特征所造成判别误差将在网络中传播而无法及时修正，造成误差的积累，最终导致图像复原结果不理想。为了补偿窗内自注意力的局部感受野，LGT 引入了窗间自注意力机制，用于建模跨窗口的关系。基于窗间自注意力，模型感受野范围大大增加。本小节设计了两个模型变体来验证窗间自注意力模块的有效性。为了突出窗间自注意力模块的作用并控制模型大小对实验

中国知网　https://www.cnki.net

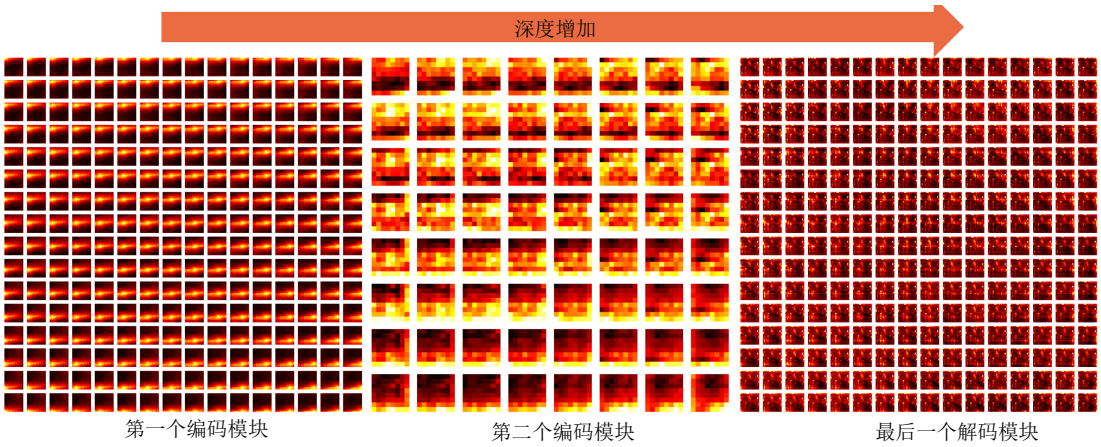


图 3.12　窗间自注意力的注意力图的可视化

结果的影响，分别用窗间自注意力（DBMSA）、窗内自注意力（InWin-DBMSA）和偏移窗口自注意力[124]（SW-DBMSA）替代窗间自注意力。表 3.7 中，可以发现，窗间自注意力带来了 0.32 dB 的性能提升（InWin-DBMSA 对比 CrossWin-DBMSA），窗内自注意力带来 1.56 dB 的性能提升（DSMSA 对比 CrossWin-DBMSA），因此，窗内自注意力发挥了更大的作用。在保证局部关系建模的基础上，增加注意力的建模范围，有利于进一步提升性能。论述如下：窗内自注意力只能在每个编码和解码阶段建模局部窗口内的依赖关系，而偏移窗口自注意力则能够捕捉相邻窗口之间的关系。因此，这些变体获得的感受野的大小排序为：InWin-DBMSA < SW-DBMSA < CrossWin-DBMSA。表 3.7 展示了这些变体在基准数据集 Rain200H[53] 上的性能对比。根据这些结果，可以得出以下结论：（1）LGT 在 PSNR 和 SSIM 方面表现最佳，验证了窗间自注意力的有效性。（2）性能排序为：InWin-DBMSA < SW-DBMSA < CrossWin-DBMSA，这一排序与感受野大小的排序一致。这些结果为建模全局特征对图像复原性能提供了实验依据。

窗间自注意力使 LGT 能够在任意的编码和解码阶段可以具有全局信息作为建模上下文。这里通过窗间自注意力图的可视化验证模型是否利用了全局建模能力。图 3.12 展示了来自 LGT 不同深度的窗间自注意力的注意力图。这里主要研究 LGT 对窗间自注意力全局建模能力的利用程度，为了消除对特定输入内容的影响，从 Rain200H 数据集中随机挑选了 100 张测试图像，随后记录了窗间自注意力中的平均注意力图，即 $\mathrm{softmax}(\boldsymbol{A}+\boldsymbol{B})$。图 3.12 展示了来自第一个编码块、第二个编码块和最后一个解码块的注意力图。图 3.12 中注意力图的排列是根据其查询标记所在位置排列。第二个编码模块注意力图数量小于第一个编码模块和最后一个解码模块，这是因为经过下采样，第二个编码模块特征图的分辨率降低。如图 3.12 所示，在第一个编码块中，模型也能学习类卷积的局部感受野。当进入第二个编码块时，注意力图展现出不规则的非局部模式，对于最后一个解码块，模型能够捕捉到远距离且复杂的关系。

中国知网　https://www.cnki.net

表 3.7　窗间自注意力的消融分析

自注意力变体	DBMSA	InWin-DBMSA	SW-DBMSA	CrossWin-DBMSA
PSNR	30.68	31.92	32.08	32.24
SSIM	0.9034	0.9282	0.9304	0.9313

表 3.8　归一化类型的消融分析

归一化类型	GN	BN	IN	LN
PSNR	29.78	30.84	30.81	32.24
SSIM	0.9148	0.9172	0.9184	0.9312

3.4.3.4　归一化类型的影响

本节探究在高层视觉任务中 Transformer 的归一化类型的影响。消融实验比较了默认的层归一化[176]（Layer Normalization，LN）与几种典型的归一化方法：批归一化[200]（Batch Normalization，BN）、组归一化[201]（Group Normalization，GN）和实例归一化[202]（Instance Normalization，IN）。在 GN 中，组数设置为 4。如表 3.8 所示，LN 作为视觉 Transformer 的默认选择，取得最优的性能。

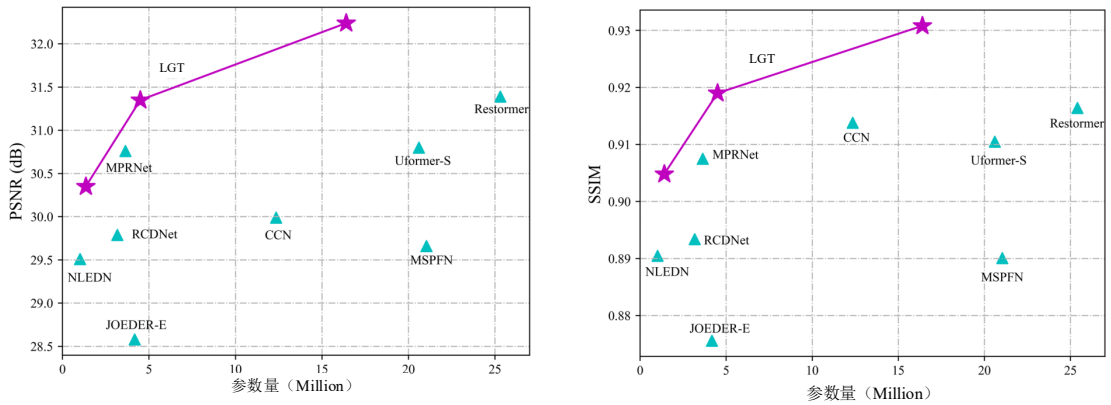
3.4.3.5　模型参数量的影响

本节探究模型参数量对性能的影响。通过改变通道的维度构建了一系列模型。具体而言，将图 3.3 中的 C 设置为 8、16 和 32，对应的模型大小分别为 1.4 M、4.5 M 和 16.4 M。在 Rain200H 数据集上进行了评估，并与几种基线方法进行比较，结果如图 3.13 所示。可以发现，LGT 在不同模型参数量下的表现更优。表 3.9 中比较了 LGT（$C = 32$）与其他基于卷积神经网络和基于 Transformer 的方法的浮点运算数（FLOPs）和推理时间对比，所处理的图像分辨率为 256×256。可以看出，LGT 实现了相对较低的计算成本和运行时间。对于基于 Transformer 的图像复原模型，LGT 推理速度略慢于 Uformer-S，但如表 3.1 所示，LGT 具有明显的性能优势。与基于卷积神经网络的方法（如 MPRNet 和 MSPFN）相比，LGT 在较小的 FLOPs 下能够获得更好的性能。

3.4.3.6　相对位置编码可视化

图 3.14 中提供了相对位置编码的可视化。具体地，考虑窗间自注意力的学到的相对位置编码 B，窗间自注意力建模了跨窗口依赖关系。图 3.14 展示了第

中国知网　https://www.cnki.net

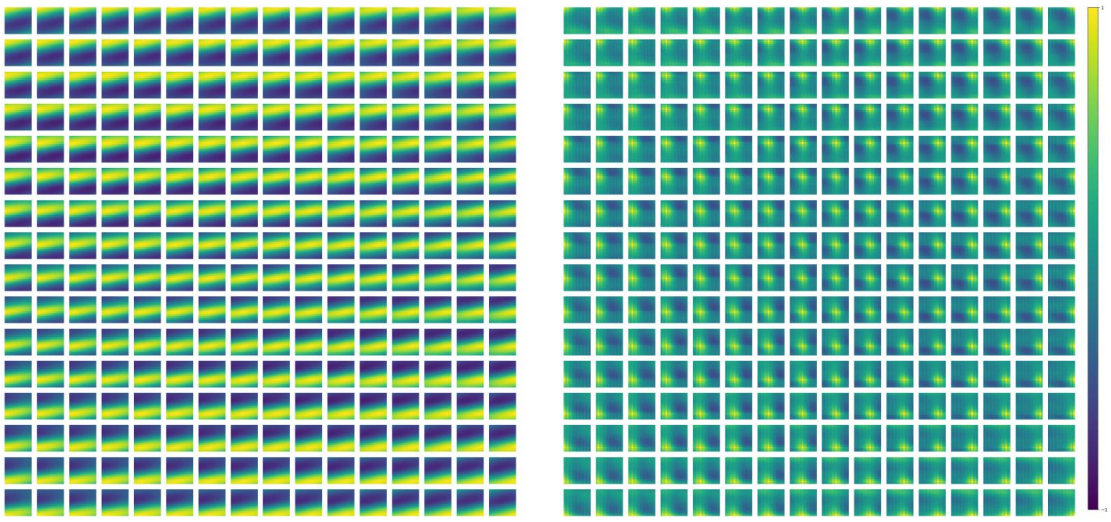


(a) PSNR随模型参数量变化趋势　　(b) SSIM随模型参数量变化趋势

图 3.13　模型参数量对性能的影响

表 3.9　推理时间和 FLOPs 对比

方法	DDN	JORDER-E[54]	PReNet[184]	MSPFN[57]	MPRNet[58]	Uformer-S[120]	SwinIR[62]	Restormer[64]	LGT
FLOPs（G）	3.75	26.65	66.45	595.5	175.8	43.8	238.0	174.7	61.9
推理时间（s）	0.05	0.25	0.09	0.41	0.10	0.19	0.51	0.28	0.28



(a) 第一个编码块　　**(b) 最后一个解码块**

图 3.14　窗间自注意力的相对位置编码的可视化

一个编码块和最后一个解码块的相对位置编码，可以发现，较近的窗口倾向于具有更相似的位置编码。进一步地，随着网络的深度的增加，位置编码的相似度有增加的趋势，即图 3.14(b) 中位置编码的相似度高于图 3.14(a) 中的相似度（直观上，图 3.14(b) 的颜色更浅，波动更小）。这是因为深层的输入可能通过集成来自浅层的位置信息嵌入，包含了足够的位置信息，因此对位置编码的需求弱于模型的浅层。

中国知网　https://www.cnki.net

3.5　本章小结

本章首先分析经典自注意力无法提取并建模结构信息，并基于此提出了内容-结构双分支自注意力，将内容建模和结构建模解耦，实现对图像内容的自适应建模以及对图像和退化结构的感知。本章以内容-结构双分支自注意力为基础模块，进一步引入了窗内-窗间自注意力机制，窗内自注意力建模局部窗内标记间的依赖关系，利用图像像素的局部性先验，窗内自注意力可以增强对图像细节和纹理的感知，窗间自注意力建模窗口间的依赖关系，建模范围与窗内自注意力互补，可以提供全局上下文指引，在图像空间中实现了多尺度建模能力的补偿，增强了对图像信息和退化信息的判别能力。本章最终提出了一种新型的图像复原 Transformer 模型，称为 Local-Global Transformer（LGT）。理论分析得出窗内-窗间自注意力可以降低自注意力的时间复杂度和空间复杂度。实验观察验证了内容-结构双分支结构具有互补的滤波作用。实验结果证明，LGT 在图像去雨、图像去噪任务上取得优异的性能。大量的实验发现，包括注意力建模范围随模型深度的规律、相对位置编码随模型深度的规律、自注意力和卷积的互补特性等，为下一代图像复原模型的设计提供了新的视角。

本章工作的部分内容已发表在计算机视觉及模式识别领域著名期刊 IEEE Transactions on Pattern Analysis and Machine Intelligence（T-PAMI）。

中国知网　https://www.cnki.net

第 4 章　基于随机置换自注意力的图像复原方法

图像复原中一类经典的退化噪声在图像空间中呈现非均匀分布。考虑训练和推理效率，图像复原模型通常采用参数共享的方式处理退化图像。本章分析发现，图像空间中退化噪声的非均匀分布与图像复原模型的权重共享机制相冲突，这导致在不同程度的退化噪声之间产生次优的折衷。为了解决这一问题，本章提出了一对互逆的随机函数：随机置换函数和逆随机置换函数。具体而言，随机置换函数会随机重新排列图像空间中的标记，而逆随机置换函数是随机置换函数的逆操作，负责将图像标记 (Token) 恢复成原始排列。经过随机置换变换后，非均匀分布的噪声扩散至整个图像空间，随机置换后的空间中称为同质化空间。在同质化空间中，退化噪声呈现均匀化分布的模式，图像复原模型能够以参数共享的方式有效处理。结合随机置换和局部窗口自注意力，设计了同质化空间自注意力机制，规避了折衷的问题。由第 3 章得知，卷积层依赖相对位置关系进行建模运算，因此，引入卷积层来建模图像的结构信息。本章构建了用于处理非均匀退化噪声的 Transformer，称为 HomoFormer。图像阴影是典型的空间分布不均匀的退化噪声，因此，本章通过图像去阴影任务验证了 HomoFormer 在处理非均匀噪声的有效性。大量的实验结果表明，HomoFormer 能够高效地处理阴影图像（具有线性时间复杂度和空间复杂度），有效地应对建模阴影的非均匀性和多样性的挑战，并且与基线方法相比，取得了更优越的性能。

随机置换函数和逆随机置换函数不仅能够更好地处理非均匀分布的退化噪声，还能高效地建模图像标记间的长程依赖关系。第 3 章中的窗内-窗间自注意力通过互补感受野的多层级处理，对参与计算的标记序列长度优化，将经典注意力的 $\Theta\left((HW)^2\right)$ 降低至 $\Theta\left((HW)^{\frac{3}{2}}\right)$。本章证明，通过利用随机置换函数和逆随机置换函数能够构造全局稀疏自注意力，可以进一步将建模标记间的长程依赖关系的时间复杂度和空间复杂度降低为线性（即 $\Theta(HW)$）。具体而言，受自注意力机制的置换等变性（即对输入的标记序列应用随机置换，等价于对输出执行相同的随机置换）的启发，在由随机置换构造的同质化空间中，无需引入额外的参数和计算，利用局部窗口自注意力就能够有效地建模长程依赖关系。实验发现，对于更多的图像复原任务（如图像去噪），HomoFormer 的性能难以与现有基线图像复原方法相媲美。进一步分析表明，HomoFormer 缺少挖掘局部性依赖的能力，导致复原精度的损失。因此，为处理更一般的图像复原任务，本章构建了局部建模增强版 HomoFormer，称为 HomoFormer-Local，通过交替应用局部窗口自注意力和同质化空间自注意力，在图像空间中实现了同质化知识和非局部关联性知识驱动的图像复原模型。与第 3 章的方法相比，HomoFormer-Local 实现了

中国知网　https://www.cnki.net

更丰富的跨尺度交互和更优的建模效率。大量实验结果表明，HomoFormer-Local 在多种图像复原任务（包括图像去噪、去雨和去模糊）中展现了卓越的性能。

4.1　概述

图像复原任务中一类经典的噪声在图像空间中呈现明显的非均匀分布，如图 4.1 中阴影分布只在图像的部分区域。本章首先以图像去阴影为例，研究非均匀分布的退化问题的难点与解决方案。阴影现象在自然场景中十分常见，当光源部分或完全被遮挡时，采集的图像中会出现阴影。图像阴影不仅损害了图像的视觉质量，还对严重限制下游的计算机视觉任务的性能，如目标跟踪[203]、目标检测[204]、人脸识别[205] 等。因此，图像去阴影任务具有具有重要的实际意义。图像去阴影的挑战之一是阴影退化的形状复杂多样且在图像空间中呈现非均匀分布的模式。这些特性使得主流的图像复原模型（如卷积神经网络和基于局部窗口自注意力的 Transformer）难以实现阴影区域的阴影去除和清晰区域的图像保留之间的权衡。如图 4.1 所示，不同图像区域被阴影污染的程度不同，因此对模型的要求不同：在阴影区域，模型的训练目标是阴影去除，并且增强被遮挡的图像背景；在无阴影区域，模型的训练目标是保留清晰的图像信息；在更一般的不同程度污染的阴影区域，模型的训练目标是在保留图像信息和去除阴影间做出权衡。在不同区域间，模型参数是共享的，这会导致次优的折衷。

为了克服上述挑战，一个直接的解决方案是使用具有空间异质性的模型，也即模型能够根据阴影的不同程度做出自适应性的处理。一个合理的选择是经典的视觉 Transformer[20,61]，它通过利用全局自注意力机制，能够自适应地处理图像。尽管经典的视觉 Transformer 适合解决空间异质性的问题，但是视觉 Transformer 的时间复杂度和空间复杂度随着输入图像分辨率的二次方关系增长。在图像复原任务中，输入图像的分辨率较高（例如 840×640），限制了经典的视觉 Transformer 的直接应用。基于局部窗口自注意力的 Transformer[124]能够以线性复杂度高效地处理退化图像，但在处理图像空间分布不均匀的阴影退化时，仍然受到权重共享机制和分布不均匀间矛盾的限制。

本章工作探索上述难点的解决方案。权重共享是现有主流模型的重要机制，已经被图像复原模型广泛地采用，因此研究思路转变为开发新的策略改变退化噪声的非均匀分布，以更好地兼容权重共享机制。为了实现这一目标，本章引入随机置换函数（$\boldsymbol{S}(\cdot)$）直接将噪声非均匀分布的原始图像空间映射为噪声均匀分布的同质化空间，为了最终得到有意义的图像，需要将同质化空间处理后的特征映射回图像空间，因此引入逆随机置换函数（$\boldsymbol{I}(\cdot;\boldsymbol{S})$），逆随机置换函数是随机置换函数的逆函数，用于实现同质化空间到原始图像空间的映射。具体而言，随

中国知网　https://www.cnki.net

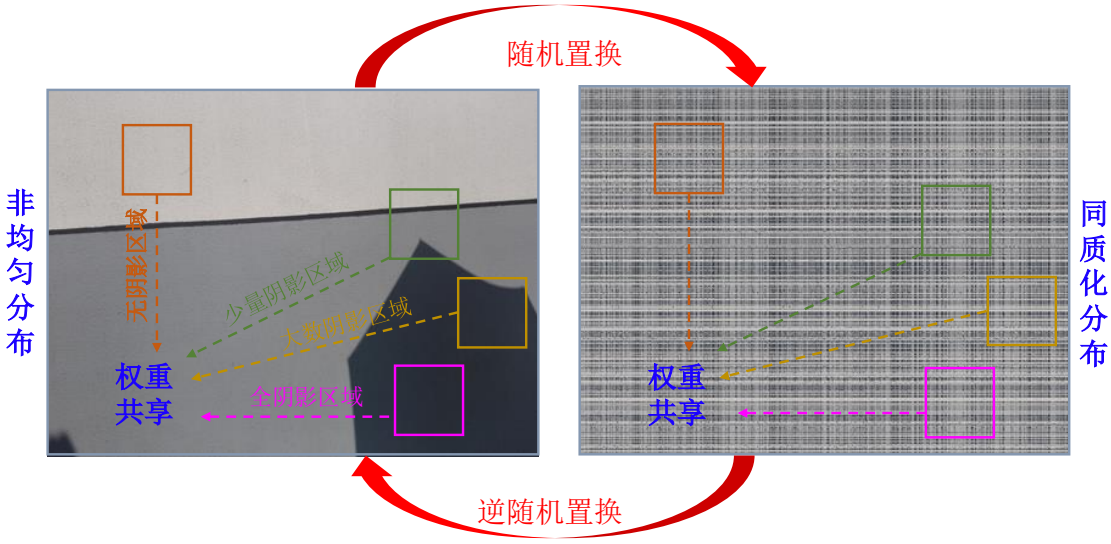


图 4.1　图像阴影在空间分布不均匀的建模难点示意图

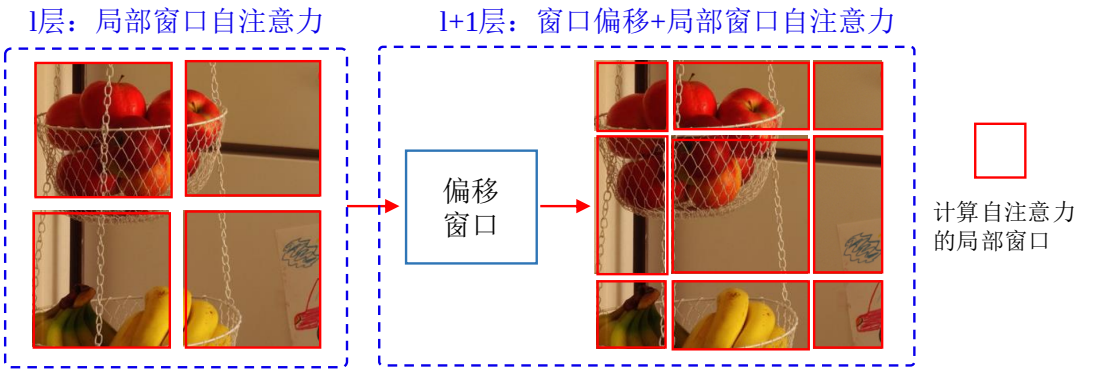
注：阴影的非均匀分布与权重共享矛盾，共享权重模型在处理不同退化程度区域时，会导致次优的折衷。随机置换函数构建同质化的空间，实现与权重共享的兼容。

机置换函数通过将标记随机重新排列，每个标记以相同的概率分配到任意位置，从而实现非均匀分布退化噪声的同质化。另一方面，标记的随机重新排列彻底破坏了图像的语义信息（见图 4.1，随机置换后图像语义丧失）。因此，在同质化空间中经过处理后，需要映射回原始图像空间。研究发现随机置换函数存在逆函数，因此可以通过其逆函数恢复标记的原始位置，实现到图像空间的映射，重建图像语义。随机置换函数和逆随机置换函数可以被简洁地实现，而不会引入额外的模型参数量和计算量。

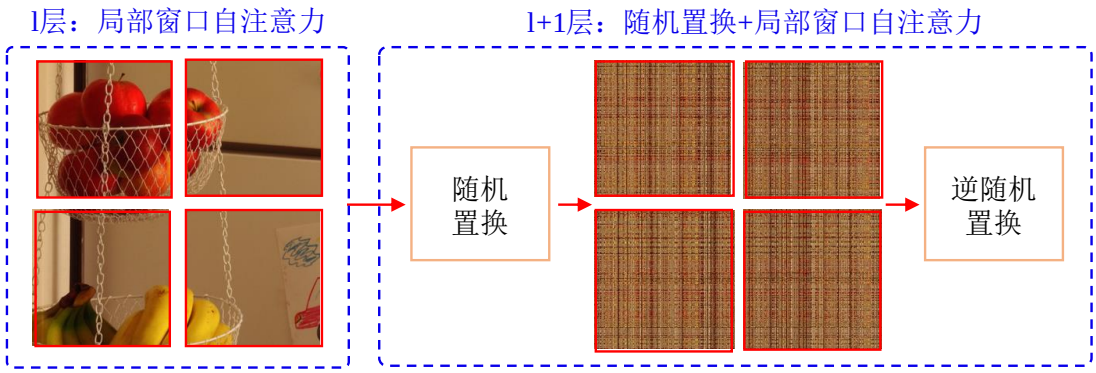
随机置换函数和逆随机置换函数提供了图像空间和同质化空间相互映射的途径，且不会损失任何信息。如图 4.1 所示，同质化空间能够更好地与权重共享机制兼容。一个潜在的问题是由于随机置换函数破坏了图像的结构，在同质化空间中的网络层无法基于位置的信息来计算和建模依赖关系，同时考虑到计算和显存效率，选择局部窗口自注意力层[124]（并且不使用位置编码）作为同质化空间中的基本网络层。同理，已有研究表明[206]，卷积层可以依靠相对位置关系建模结构信息，为了建模图像结构信息并提升计算和显存效率，除在同质化空间的局部窗口自注意力层外，还应在图像空间中使用逐通道卷积层建模结构信息。最终，为了应对退化噪声分布不均匀的问题，本章提出了一种新型的基于同质化空间的 Transformer，称为 HomoFormer，分析得出，HomoFormer 不仅具有线性时空复杂度和强大的表征能力，还能巧妙地避开建模非均匀分布的阴影退化的挑战。大量的实验结果验证了 HomoFormer 处理非均匀分布退化噪声问题的优越性，并分析了 HomoFormer 的预测误差区域等性质（见第 4.3.2.5 节）。

HomoFormer 在图像去阴影任务上取得优异的性能，然而在更多的图像复原任务上（如图像去噪、图像去模糊等）表现不如现有的图像复原模型。本章进一

中国知网　https://www.cnki.net



(a) 偏移窗口自注意力示意图



(b) 混沌窗口自注意力示意图

图 4.2　偏移窗口自注意力和混沌窗口自注意力的对比图

步分析随机置换函数的性质，具体而言，随机置换函数打破距离的约束，使任意距离的标记间的关系被同等地建模，理论证明得出随机置换函数可以极大地扩展局部窗口自注意力的建模范围，但是局部窗口自注意力包含标记数量有限①，因此随机置换函数结合局部窗口自注意力实现了一种稀疏的全局自注意力。接下来的问题是：为何基于同质化空间自注意力落后于已有的基于局部窗口自注意力的 Transformer[62,120]？为了回答这个问题，首先分析 HomoFormer 和现有基于局部窗口自注意力的 Transformer 的差异。基于局部窗口自注意力的 Transformer 将输入图划分为互不重叠的局部窗口，并将自注意力计算限制在局部窗口内。同时，一些研究[124,207]采用了偏移窗口策略实现相邻窗口间标记的交互。基于局部窗口自注意力的 Transformer 的时间和空间复杂度与输入图像分辨率呈线性关系，使其能高效地处理高分辨率图像。而 HomoFormer 缺少局部性的归纳偏置，因此推测引入局部建模能力的 HomoFormer（称为 HomoFormer-Local）可以取得更优异的性能。如图 4.2 所示，与已有的偏移窗口策略不同，随机置换策略在空间维度上的随机打乱标记的顺序，由于仍然是采取局部窗口自注意力的配置，基于随机置换的自注意力仍然保留了时间和空间复杂度，但是通过对输入标记进行随机置换的方式极大地扩展自注意力的计算范围。基于局部窗口的多头自注意

① 假设局部窗口尺寸 $s \times s$，标记数量为 s^2。

中国知网　https://www.cnki.net

力被称为局部窗多头自注意力（Window Multi-head Self-Attention，W-MSA）；结合偏移窗口的版本称为偏移窗口多头自注意力（Shifted Window Multi-Head Self-Attention，SW-MSA）；结合随机置换的多头自注意力被称为混沌窗多头自注意力（Chaotic Window Multi-head Self-Attention，CW-MSA）。[①] 由于标记在空间上的随机置换会破坏语义信息，因此在通过混沌窗多头自注意力后，须进行相应的逆随机置换操作以精确恢复标记的原始排列。在训练阶段，模型可被凭借采样得到随机置换样本被高效地训练；在推理阶段，受启发于 Dropout[143]，计算每个混沌窗多头自注意力的期望，通过计算蒙特卡洛平均（Monte Carlo Average）来近似混沌窗口自注意力的数学期望值，这保证了在推理时，随着蒙特卡洛样本增加，混沌窗口自注意力的输出的均值能趋近真实的数学期望值。与第 3 章的互补感受野的方法相比，HomoFormer-Local 利用稀疏自注意力在模型层级实现了全局上下文的感知，具有更优的跨尺度交互能力和建模效率。大量实验结果表明，HomoFormer-Local 在多种图像复原任务（包括图像去噪、去雨和去模糊）中均展现出卓越的性能。

本章的主要贡献包括：

- 分析了建模非均匀分布退化噪声的难点，并指出了非均匀噪声模式难以兼容权重共享机制的问题。
- 设计了随机置换函数和逆随机置换函数，实现了图像空间到同质化空间的映射，能够在不丢失信息的情况下完成非均匀噪声的同质化，提出了同质化空间自注意力，规避了不兼容问题。
- 构建了 HomoFormer 模型，能够有效完成非均匀退化噪声（以图像去阴影为例）的图像复原，较基线方法取得了更优越的性能。
- 分析发现随机置换函数能够在不引入额外参数量与计算量的情况下极大地扩展建模范围，结合局部性先验，提出了混沌窗口自注意力，在图像空间实现丰富的跨尺度交互，进一步提出了 HomoFormer-Local 模型，成功地在更多图像复原任务上取得优异的性能。
- 设计了基于随机置换的自注意力训练策略和推理策略。在训练阶段，每个输入标记序列都会通过独立的随机置换样本和相应的逆随机置换样本，模型的每次优化仅需考虑一组随机置换样本，从而实现高效的训练。在推理阶段，通过蒙特卡洛平均（Monte-Carlo Average）的方式近似模型输出对随机置换的数学期望。
- 在多个图像复原任务（包括图像去雨、去噪和去模糊）上，实验结果验证了 HomoFormer-Local 的优越性，同时探讨了随机置换对图像复原模型的其他性质，如长程建模能力、预测误差分布以及性能与推理代价的平衡。

[①]混沌窗口多头自注意力的命名原因是参与自注意力计算的标记在图像空间是随机抽取的。

中国知网　https://www.cnki.net

4.2　方法设计

第 4.2.1 节中引入了随机置换函数和逆随机置换函数，随机置换函数实现图像空间到同质化空间的映射，图像空间中非均匀分布的噪声在同质化空间中呈现均匀分布的模式，逆随机置换函数负责同质化空间映射回图像空间；第 4.2.2 节中将随机置换和逆随机置换与局部窗口自注意力机制结合，在同质化空间计算局部窗口自注意力；第 4.2.3 节中引入前馈网络，前馈网络中利用逐通道卷积层建模图像结构；基于基本的同质化空间自注意力层和前馈网络层，第 4.2.4 节构造了处理噪声非均匀分布的图像复原模型 HomoFormer；第 4.2.5 节引入了混沌窗口自注意力，并从理论上证明了其全局建模的能力；第 4.2.6 节提出了同质化空间自注意力和混沌窗口自注意力的训练阶段策略；第 4.2.7 节提出了同质化空间自注意力和混沌窗口自注意力的推理阶段策略；第 4.2.8 节分析了同质化空间自注意力和混沌窗口自注意力的时间复杂度和空间复杂度；第 4.2.9 节引入了可以适用于更多图像复原任务的 Transformer 模型 HomoFormer-Local。

4.2.1　随机置换函数与逆随机置换函数

一类典型的图像退化例如阴影退化在空间中呈现非均匀分布，这种非均匀分布和主流模型的权重共享特性不兼容。为了解决退化非均匀分布和权重共享机制间的矛盾，本节提出了随机置换函数与逆随机置换函数，并以此为基础构建同质化空间。在同质化空间中，退化噪声为均匀分布，避免了不兼容的问题。随机置换函数的作用是将输入标记序列随机重新排列，而逆随机置换函数则恢复标记序列的原始顺序。严格地，随机置换函数定义如下：

定义 4.1 (随机置换函数)　若 $\boldsymbol{y}, \boldsymbol{x} \in \mathbb{R}^{H\times W\times C}$ 分别代表输入和输出张量，$\mathbf{m}$ 为 $\boldsymbol{y}$ 的前两维的索引，m 为对应的 $\boldsymbol{x}$ 前两维的索引，$S: \boldsymbol{y} \mapsto \boldsymbol{x}$ 是随机置换函数，则有 $\boldsymbol{x}_{\mathrm{m},:} = S(\boldsymbol{y})_{\mathrm{m},:} = \boldsymbol{y}_{\mathbf{m},:}$，即 $\boldsymbol{x} \in \mathbb{R}^{H\times W\times C}$ 的元素对应于 $\boldsymbol{y} \in \mathbb{R}^{H\times W\times C}$ 的元素的随机排列。

经过随机置换后，每个标记都有相同的概率出现在图像空间的任意位置。因此，随机置换函数可以同质化非均匀分布的阴影退化，从而消除了对权重共享模型的矛盾。另一方面，图像语义和标记序列的排列顺序密切相关，随机置换函数破坏了标记序列的原始顺序，也即破坏了图像语义。因此，在同质化空间中处理后，需映射回图像空间，恢复标记序列的原始顺序，以使其与原始图像空间对齐。基于此引入逆随机置换函数，其定义为随机置换的逆函数。

定义 4.2 (逆随机置换函数)　若 $S(\cdot)$ 代表随机置换函数，$S(\cdot)$ 的逆随机置换函数 $\mathcal{I}(\cdot; S)$ 定义为 $\mathcal{I}(S(\boldsymbol{y}); S) = \boldsymbol{y}$。

如上所述，逆随机置换函数能够抵消随机置换函数引起的标记随机排序。若 $\boldsymbol{y} \in \mathbb{R}^{H\times W\times C}$ 是噪声非均匀分布的退化图像，$S(\boldsymbol{y})$ 对 $\boldsymbol{y}$ 中的元素在前两维（即

中国知网　https://www.cnki.net

标记序列）随机重新排列，因此，$\mathcal{S}(\boldsymbol{y})$ 中阴影退化在图像空间呈现均匀分布的模式，即 $\mathcal{S}(\cdot)$ 实现图像空间到同质化空间的映射。此外，由于随机置换函数和逆随机置换函数仅涉及元素的重新排序，可以在现代加速器（如 GPU）上非常高效的实现，不会引入额外的参数和 FLOPs。随机置换函数和逆随机置换函数可以被简洁地实现，其 Python 实现见算法 4.1 和算法 4.2。

算法 4.1 随机置换的 Python 实现

```
import random
def random_shuffle(x):
    B, H, W, C = x.shape
    H_shuffle = random.shuffle(list(range(0, H))) #shuffle
        index
    W_shuffle = random.shuffle(list(range(0, W)))
    shuffle_x = x[:, H_Shuffle, :, :] #shuffle on H
    shuffle_x = shuffle_x[:, :, W_Shuffle, :]#shuffle on W
    return shuffle_x, (H_shuffle, W_shuffle)
```

算法 4.2 逆随机置换的 Python 实现

```
def inverse_shuffle(x, (H_shuffle, W_shuffle)):
    B, H, W, C = x.shape
    H_Index, W_Index = list(range(0, H)), list(range(0, W)
        )
    inverse_x[:, :, W_Shuffle, :] = x[:, :, W_Index, :]#
        inverse for W
    inverse_x[:, H_Shuffle, :, :] = inverse_x[:, H_Index,
        :, :]#inverse for H
    return inverse_x
```

4.2.2　同质化空间自注意力

尽管局部窗口自注意力具有高效的计算和显存，由于阴影退化模式的多样性以及在图像空间分布的不均匀性，局部窗口自注意力的权重共享特性使其在图像去阴影任务中不适用。本节引入随机置换函数和逆随机置换函数，图像空间被随机置换函数映射为同质化空间，阴影退化在同质化空间均匀分布。图 4.3 展示了详细的计算图。具体而言，输入标记序列 $\boldsymbol{y}^m$ 首先通过随机置换函数 $\mathcal{S}(\cdot)$ 将图像空间的 $\boldsymbol{y}^{m-1}$ 映射为同质化空间的 $\tilde{\boldsymbol{y}}^{m-1}$；其次，同质化空间的 $\tilde{\boldsymbol{y}}^{m-1}$ 输入到局部窗口自注意力中，处理后得到同质化空间的输出 $\tilde{\boldsymbol{z}}^m$；最后，同质化空间的输出 $\tilde{\boldsymbol{z}}^m$ 通过逆随机置换函数 $\mathcal{I}(\cdot;\mathcal{S})$ 映射为图像空间的输出 $\boldsymbol{z}^m$。综上，同质化空间自注意力（HomoMSA）计算过程可以表示为：

$$\boldsymbol{z}^m = \text{HomoMSA}\left(\boldsymbol{y}^{m-1}\right): \begin{cases} \tilde{\boldsymbol{y}}^{m-1} = \mathcal{S}\left(\boldsymbol{y}^{m-1}\right), \\ \tilde{\boldsymbol{z}}^m = \text{W-MSA}\left(\tilde{\boldsymbol{y}}^{m-1}\right), \\ \boldsymbol{z}^m = \mathcal{I}\left(\tilde{\boldsymbol{z}}^m;\mathcal{S}\right). \end{cases} \tag{4.1}$$

中国知网　https://www.cnki.net

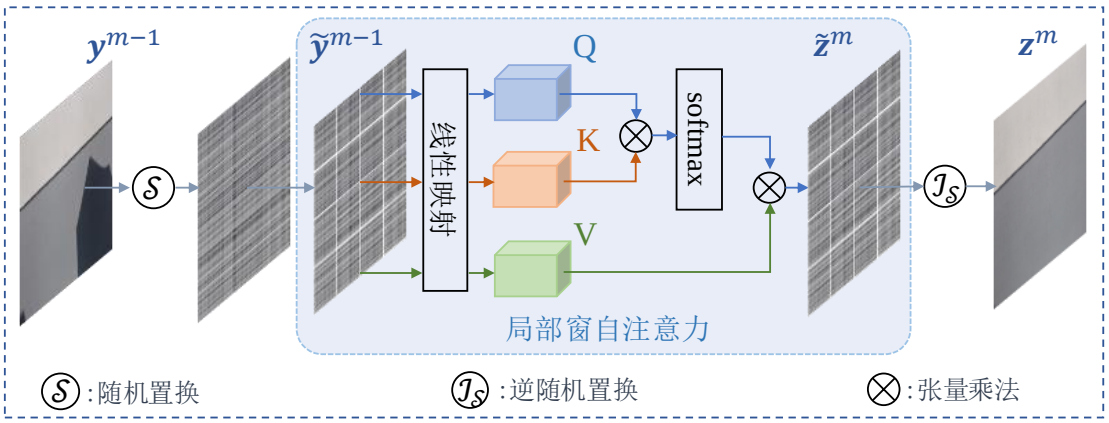


图 4.3　同质化空间自注意力计算图

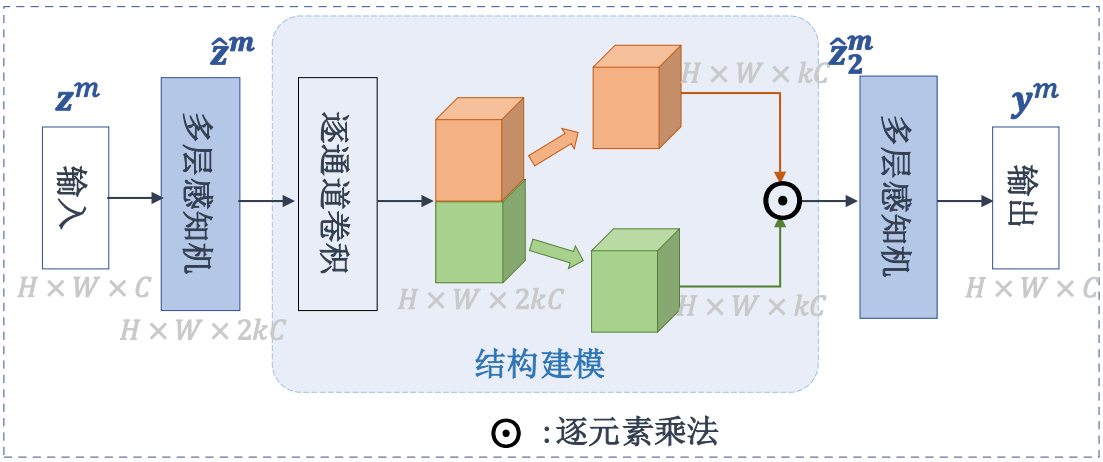


图 4.4　结构增强的前馈网络层的计算图

其中 W-MSA (·) 表示局部窗多头自注意力函数。一个潜在的问题是，随机置换引起的标记位置的随机性是否会造成自注意力训练的不稳定。由第 2.2.2 节知，自注意力的一个重要性质是置换等变性[170]，即对输入标记序列做随机排序，自注意力的输出也会做同样的随机排序，而输出结果的内容都是相同的。因此，自注意力可以有效地处理同质化空间的标记序列，而不会受到随机置换函数的随机性的干扰。与经典的局部窗口自注意力[124]不同，经过随机置换，标记的位置关系不再可靠，同质化空间中不再能利用相对位置编码，导致结构信息未被充分挖掘[208]。由第 3.3.1 节的研究可知，卷积利用相对位置关系提取并建模特征，因此在模型中加入卷积即可实现图像结构信息的挖掘。

4.2.3　结构增强的前馈网络

Transformer 的经典范式是：自注意力层负责标记间交互 → 前馈网络层负责标记的更新。在经典的 Transformer 架构中，前馈网络层由两个多层感知机（MLP）实现。考虑到同质化空间自注意力无法建模结构信息，为了增强模型对图像结构的建模能力，在前馈网络中加入额外的卷积层，因此该前馈网络层命名为结构增

中国知网　https://www.cnki.net

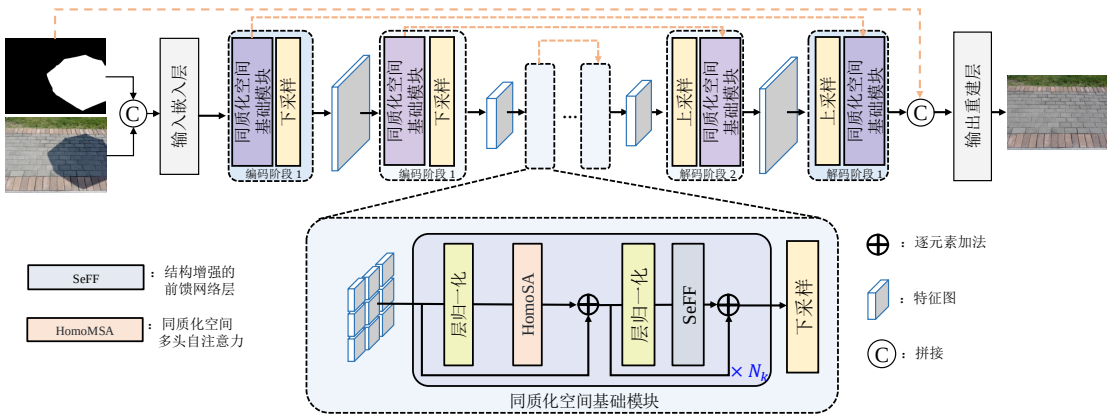


图 4.5　HomoFormer 模型结构图

强的前馈网络层（Structure-Enhanced FeedForward Network，SeFF）。在两个多层感知机之间插入高效的逐通道卷积层，并且加入逐元素点乘实现结构自适应性的建模，计算图如图 4.4 所示。结构增强的前馈网络层的计算过程如下：

$$\boldsymbol{y}^m = \mathrm{SeFF}\left(\boldsymbol{z}^m\right): \begin{cases} \hat{\boldsymbol{z}}^m = \mathrm{MLP}(\boldsymbol{z}^m), \\ \hat{\boldsymbol{z}}_2^m = \mathrm{DConv}_1(\hat{\boldsymbol{z}}^m) \odot \mathrm{DConv}_2(\hat{\boldsymbol{z}}^m), \\ \boldsymbol{y}^m = \mathrm{MLP}(\hat{\boldsymbol{z}}_2^m). \end{cases} \tag{4.2}$$

其中，$\mathrm{DConv}_{1,2}(\cdot)$ 表示逐通道卷积，$\odot$ 表示逐元素相乘。

4.2.4　HomoFormer 模型架构

基于同质化空间自注意力层和结构增强的前馈网络层，由 Transformer 的“自注意力 → 前馈网络”的经典架构，本节首先构建同质化空间基础模块，其计算流程为：

$$\boldsymbol{z}_l^m = \boldsymbol{y}_l^{m-1} + \mathrm{HomoMSA}\left(\mathrm{LN}\left(\boldsymbol{y}_l^{m-1}\right)\right), \tag{4.3a}$$

$$\boldsymbol{y}_l^m = \boldsymbol{z}_l^m + \mathrm{SeFF}\left(\mathrm{LN}\left(\boldsymbol{z}_l^m\right)\right). \tag{4.3b}$$

式中，$\mathrm{HomoMSA}(\cdot)$ 代表同置换空间的局部窗口自注意力，$\mathrm{SeFF}(\cdot)$ 表示结构增强的前馈网络，$\mathrm{LN}(\cdot)$ 表示层归一化。同质化空间基础模块被嵌入到广泛应用于图像复原的 UNet 架构中[145-146]，以构建最终的 HomoFormer 模型。HomoFormer 的整体模型结构如图 4.5 所示。

为了证明 HomoFormer 的有效性，本节控制损失函数的影响，训练 HomoFormer 的损失函数是单独的 Charbonnier 函数[147]，而不是复杂的损失函数混合[209-210]。Charbonnier 函数的数学表达式为：

$$\mathcal{L}(\hat{\boldsymbol{y}}, \boldsymbol{x}) = \sqrt{\|\hat{\boldsymbol{y}} - \boldsymbol{x}\|_2^2 + \epsilon^2}, \tag{4.4}$$

式 (4.4) 中，$\hat{\boldsymbol{y}}$ 和 $\boldsymbol{x}$ 分别表示输出图像和清晰图像。常数 ϵ 设定为 10^{-3}，以确保数值稳定性。

中国知网　https://www.cnki.net

4.2.5　混沌窗口自注意力

HomoFormer 在处理非均匀分布退化噪声（以图像去阴影为例）时可以取得优异的性能，然而，在更多的图像复原任务上，HomoFormer 无法取得和最新基线模型相当的性能，需要做进一步的改进。本节分析随机置换在扩展建模范围的作用，并从理论上证明，随机置换能将局部窗口自注意力的建模范围从局部窗口扩展到全局范围；分析得出 HomoFormer 性能落后的原因是无法建模标记间的局部性依赖关系，结合局部窗口自注意力，提出了混沌窗口自注意力，形成了“局部建模 → 全局建模”的基础建模范式（第 3 章验证了该建模范式的有效性）。

4.2.5.1　随机置换突破局部范围限制

本节证明随机置换函数可以使基于局部窗口的自注意力建模全局标记的依赖关系，与第 3 章中建模全局依赖关系的窗间自注意力不同，基于随机置换的自注意力是一种稀疏的全局自注意力，时间和空间复杂度为 $\Theta(HW)$，相比窗口-窗间自注意力的 $\Theta\left((HW)^{\frac{3}{2}}\right)$ 复杂度，具有更优的训练和推理效率，更适配高分辨率的图像处理。在通过局部窗口自注意力之前，对输入标记序列作随机置换，尽管自注意力计算仍然限制在一个局部的窗口内，但窗口内的标记均匀地抽取自图像的全局空间，因此是一种稀疏的自注意力。下面论证局部窗口自注意力结合随机置换可以建模长程依赖关系，首先假设局部窗口的分辨率远小于与输入图像分辨率，严格地，引入局部窗口划分的假设：

假设 4.1 (局部划分假设)　对于局部窗口的自注意力，局部窗口的尺寸 $s \times s$ 满足 $s \ll H$ 和 $s \ll W$，其中 $H \times W$ 是输入图像的分辨率。

随机置换使得自注意力能够整合来自整个图像标记的信息。为了严格地描述长程依赖关系的建模能力，随机置换后位于同一局部窗口的标记集合定义以及标记之间的距离度量定义如下：

定义 4.3 (混沌集)　将随机置换 S 后位于同一局部窗口内的标记的集合表示为混沌集 $C(S)$，即 $C(S)=\left\{\left(\mathbf{m}_1,\mathbf{m}_2\right)\right\}$：索引 $\mathbf{m}_1$ 和 $\mathbf{m}_2$ 的标记在随机置换 S 后位于同一局部窗口。

定义 4.4 (距离度量)　定义索引为 $\mathbf{m}_1$ 和 $\mathbf{m}_2$ 的标记之间的距离为

$$d_S(\mathbf{m}_1,\mathbf{m}_2)=\begin{cases}\|\mathbf{m}_1-\mathbf{m}_2\|_2, & \text{若}\quad \left(\mathbf{m}_1,\mathbf{m}_2\right)\in C(S),\\ \infty, & \text{若}\quad \left(\mathbf{m}_1,\mathbf{m}_2\right)\notin C(S).\end{cases} \tag{4.5}$$

在式 (4.5) 中，∞ 表示距离无穷大，无法捕获交互，不参与建模距离的推导。将对于索引为 $\mathbf{m}_1$ 的标记随机置换捕获的距离的期望表示为 $d\left(\mathbf{m}_1\right)$，其定义为：

$$d\left(\mathbf{m}_1\right)=\mathbb{E}_{\mathbf{m}_2|(\mathbf{m}_1,\mathbf{m}_2)\in C(S)}\left[d_S\left(\mathbf{m}_1,\mathbf{m}_2\right)\right]. \tag{4.6}$$

中国知网　https://www.cnki.net

$d\left(\mathbf{m}_1\right)$ 衡量的是对于索引为 $\mathbf{m}_1$ 的标记通过随机置换捕获的其他标记的期望距离。可以证明 $d\left(\mathbf{m}_1\right)$ 的渐近下界是 $\Omega\left(\frac{\sqrt{2}}{4}(H+W)\right)$。严格地，有如下定理：

定理 4.1　$d\left(\mathbf{m}_1\right)$ 的下界为

$$\begin{aligned}&\frac{\sqrt{2}}{4(HW-1)}\left[Hm_{w_1}\left(m_{w_1}+1\right)+Wm_{h_1}\left(m_{h_1}+1\right)+\right.\\&\left.H\left(W-m_{w_1}\right)\left(W-m_{w_1}-1\right)+W\left(H-m_{h_1}\right)\left(H-m_{h_1}-1\right)\right],\end{aligned}\tag{4.7}$$

其中 $\mathbf{m}_1=(m_{h_1},m_{w_1})$。

证明　每个标记以相等的概率与索引为 $\mathbf{m}_1=(m_{h_1},m_{w_1})$ 的标记位于同一窗口。因此，距离的期望可计算为：

$$d\left(\mathbf{m}_1\right)=\mathbb{E}_{\mathbf{m}_2|(\mathbf{m}_1,\mathbf{m}_2)\in\mathcal{C}_S}\left[d_S\left(\mathbf{m}_1,\mathbf{m}_2\right)\right]\tag{4.8a}$$

$$=\frac{1}{HW-1}\sum_{h=0}^{H-1}\sum_{w=0}^{W-1}\sqrt{\left(h-m_{h_1}\right)^2+\left(w-m_{w_1}\right)^2},\tag{4.8b}$$

根据均值不等式

$$\sqrt{\frac{x^2+y^2}{2}}\geqslant\frac{x+y}{2},\tag{4.9}$$

$d(\mathbf{m}_1)$ 的下界为：

$$d(\mathbf{m}_1)=\frac{1}{HW-1}\sum_{h=0}^{H-1}\sum_{w=0}^{W-1}\sqrt{\left(h-m_{h_1}\right)^2+\left(w-m_{w_1}\right)^2}\tag{4.10a}$$

$$\geqslant\frac{1}{HW-1}\sum_{h=0}^{H-1}\sum_{w=0}^{W-1}\frac{\sqrt{2}}{2}\left(|h-m_{h_1}|+|w-m_{w_1}|\right).\tag{4.10b}$$

注意到

$$\sum_{w=0}^{W-1}|w-m_{w_1}|\tag{4.11a}$$

$$=\sum_{w=0}^{m_{w_1}}\left(m_{w_1}-w\right)+\sum_{w=m_{w_1}}^{W-1}\left(w-m_{w_1}\right)\tag{4.11b}$$

$$=\frac{m_{w_1}\left(m_{w_1}+1\right)}{2}+\frac{\left(W-m_{w_1}\right)\left(W-m_{w_1}-1\right)}{2},\tag{4.11c}$$

中国知网　https://www.cnki.net

以及

$$\sum_{h=0}^{H-1}\left|h-m_{h_1}\right| \tag{4.12a}$$

$$=\sum_{h=0}^{m_{h_1}}\left(m_{h_1}-h\right)+\sum_{h=m_{h_1}}^{H-1}\left(h-m_{h_1}\right) \tag{4.12b}$$

$$=\frac{m_{h_1}\left(m_{h_1}+1\right)}{2}+\frac{\left(H-m_{h_1}\right)\left(H-m_{h_1}-1\right)}{2}, \tag{4.12c}$$

因此可以得到

$$\begin{aligned} d\left(\mathbf{m}_1\right) \geqslant \frac{\sqrt{2}}{4(HW-1)}\Big[&Hm_{w_1}\left(m_{w_1}+1\right)+Wm_{h_1}\left(m_{h_1}+1\right)\\ &+H\left(W-m_{w_1}\right)\left(W-m_{w_1}-1\right)+W\left(H-m_{h_1}\right)\left(H-m_{h_1}-1\right)\Big]. \end{aligned} \tag{4.13}$$

从而完成证明。 ∎

定理 4.1 的推论如下：

推论 4.2　设 $\bar{d}\left(\mathbf{m}_1\right)$ 表示由一个局部窗口捕获的交互的平均距离，则有

$$\bar{d}(\mathbf{m}_1)\approx d\left(\mathbf{m}_1\right). \tag{4.14}$$

证明　一个局部窗口捕捉的标记的平均距离为

$$\bar{d}\left(\mathbf{m}_1\right)=\frac{1}{s^2-1}\sum_{i=1}^{s^2-1} d\left(\mathbf{m}_1|HW-i\right). \tag{4.15}$$

$d\left(\mathbf{m}_1|HW-i\right)$ 表示当剩余标记总数为 $HW-i$ 时的期望距离。根据 假设 4.1，当 $i\in[2,s^2-1]$ 时，可以得到如下近似：

$$d\left(\mathbf{m}_1|HW-i\right)\approx d\left(\mathbf{m}_1|HW-1\right)=d\left(\mathbf{m}_1\right). \tag{4.16}$$

因此，可以通过以下公式近似 $\bar{d}\left(\mathbf{m}_1\right)$：

$$\bar{d}\left(\mathbf{m}_1\right)=\frac{1}{s^2-1}\sum_{i=1}^{s^2-1} d\left(\mathbf{m}_1|HW-i\right) \tag{4.17a}$$

$$\approx\frac{1}{s^2-1}\sum_{i=1}^{s^2-1} d\left(\mathbf{m}_1|HW-1\right) \tag{4.17b}$$

$$=\frac{1}{s^2-1}\sum_{i=1}^{s^2-1} d\left(\mathbf{m}_1\right) \tag{4.17c}$$

$$=d\left(\mathbf{m}_1\right). \tag{4.17d}$$

从而完成证明。 ∎

中国知网　https://www.cnki.net

根据推论 4.2，通过局部窗口捕获的交互平均距离为 $\Omega((H+W))$，从而能够捕获近似全局交互。

自注意力的置换等变性说明可以通过随机置换结合局部窗口自注意力建模长程依赖关系。然而，如前所述，图像的标记的排列结构包含了图像的语义信息。由于标记的原始位置对图像语义信息的构建至关重要，因此处理后的结果须进行作逆随机置换，以确保与输入标记顺序的严格对齐。随机置换和逆随机置换构成了一对可逆变换对，不会造成任何信息损失。随机置换导致自注意力无法建模标记间的结构关系。为了弥补结构建模能力的不足，在随机置换之前加入高效的逐通道卷积层[206]，图 4.6 展示了详细的计算流程。基于随机置换的同质化自注意力，具有线性的时间和空间复杂度，同时建模长程依赖关系。为了增强表征丰富度，混沌窗口自注意力可以扩展为多头版本。

4.2.5.2　混沌窗口自注意力的结构

HomoFormer 在图像去阴影任务上取得了优异的性能，能够有效地去除图像阴影并保持阴影区域和非阴影区域的一致性。然而，在更一般的图像复原任务（如图像去噪、图像去模糊等）上，HomoFormer 的性能相较于主流的图像复原模型（如 Uformer）仍存在差距。因此，需分析 HomoFormer 的不足并调整、优化以提高其通用性。如上所述，理论上证明了随机置换能使局部窗口自注意力突破局部建模范围的限制。为了理解随机置换的原理，引入图像标记相关性的假设：

假设 4.2 (全局标记相关性假设)　一张图像的全局范围的所有标记间均具有相关性。即图像的标记集合 $X \in \mathbb{R}^{H\times W\times C}$ 中任意两个标记记作 $X_{h_i,w_i,:}$ 和 $X_{h_j,w_j,:}$ 之间具有相关性，其中 $i \neq j$。

基于随机置换的局部窗口自注意力随机捕捉来自图像全局范围的数量为 $s\times s$ 的标记，并建模依赖关系。基于假设 4.2，取自图像空间的任意两个标记（$X_{h_i,w_i,:}$ 和 $X_{h_j,w_j,:}$）间具有相关性。因此，随机置换实现了一种全局稀疏性建模。实验发现，在更一般的图像复原任务上，以随机置换的局部窗口自注意力为基础模块搭建的 Transformer 性能明显落后于主流的 Transformer（比如 Uformer、SwinIR）。接下来，探究基于这种稀疏的全局自注意力的 Transformer 性能落后的原因。

Swin Transformer 是采用“局部窗 → 偏移窗”的配置。这种建模方式可以引入图像的局部性先验，也显著减小了时间复杂度和空间复杂度。同时，第 2 章和第 3 章证明了局部性建模对图像复原的有效性。基于以上分析，推测 HomoFormer 性能落后的原因是缺少局部性归纳偏置。因此，一个增强 HomoFormer 的方案为将局部窗口自注意力引入 HomoFormer，形成“局部窗口自注意力 → 同质化空间自注意力”的建模范式，该注意力机制称为混沌窗口自注意力，如图 4.2 所示。混沌窗口自注意力的计算由局部窗口自注意力和基于随机置换的局部窗口自注

中国知网　https://www.cnki.net

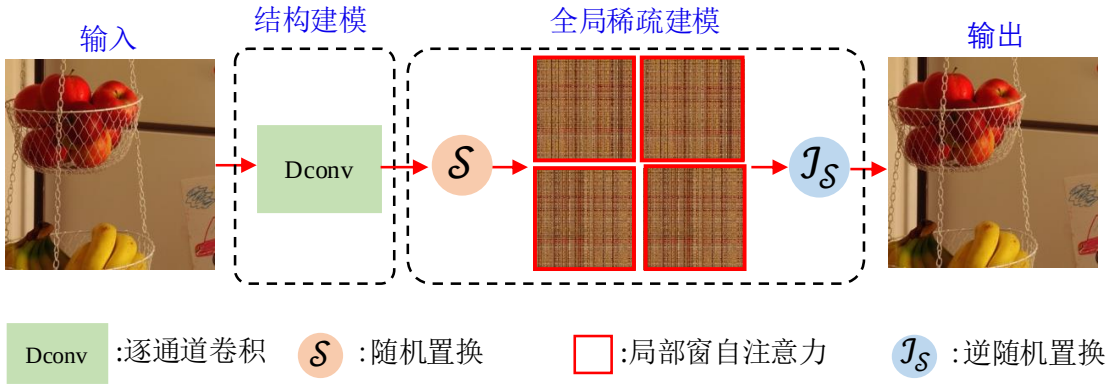


图 4.6　基于随机置换的自注意力的训练策略示意图

意力组成

$$\text{局部窗口自注意力：}\begin{cases} \boldsymbol{z}^{m-1} = \text{W-MSA}\left(\text{LN}\left(\boldsymbol{y}^{m-2}\right)\right) + \boldsymbol{y}^{m-2}, \\ \boldsymbol{y}^{m-1} = \text{SeFF}\left(\text{LN}\left(\boldsymbol{z}^{m-1}\right)\right) + \boldsymbol{z}^{m-1}. \end{cases} \tag{4.18}$$

$$\text{同质化空间自注意力：}\begin{cases} \boldsymbol{z}^{m} = \text{HomoMSA}\left(\text{LN}\left(\boldsymbol{y}^{m-1}\right)\right) + \boldsymbol{y}^{m-1}, \\ \boldsymbol{y}^{m} = \text{SeFF}\left(\left(\text{LN}\left(\boldsymbol{z}^{m}\right)\right) + \boldsymbol{z}^{m}. \end{cases} \tag{4.19}$$

4.2.6　训练策略

在局部窗口注意力中引入随机置换，以打破局部建模距离的限制。局部窗口划分减小自注意力中标记的数量，因而减小自注意力的时间和空间复杂度。通过随机置换函数，任何一对标记都有相同的概率进入同一个的局部窗口，而不受距离的影响，从而为建模稀疏的长程交互奠定基础。为了符号简洁，使用 $\tilde{\boldsymbol{y}}$ 来表示经过随机置换后的图像空间的标记序列 $\boldsymbol{y}$。由于随机置换函数和逆随机置换函数引入随机因子，需要针对同质化空间自注意力和混沌自注意力设计专门的训练算法。如图 4.6 所示，同质化空间自注意力的训练过程是：（1）随机置换采样，得到随机置换样本和对应的逆随机置换样本；（2）输入图像特征 $\boldsymbol{y}$ 利用随机置换样本映射到随机置换的版本 $\tilde{\boldsymbol{y}}$；基于局部窗口自注意力处理随机置换后的标记序列得到输出 $\tilde{\boldsymbol{z}}$，（3）最后用相应的逆随机置换样本映射回图像空间。上述训练流程如图 4.6 所示。通过随机置换函数，同质化空间自注意力能以相同的概率建模任何一对标记之间的交互。因此，从数学期望意义上，同质化空间自注意力能够建模长程交互关系。同时，尽管具有近似全局的建模范围，由于训练过程中，同质化空间自注意力仅依赖随机置换的样本，模型仍然可以高效地训练。

4.2.7　推理策略

同质化空间自注意力和混沌窗口自注意力中的随机置换函数和逆随机置换函数引入了随机因子，根据贝叶斯理论，图像复原结果应对应模型预测结果对随

中国知网　https://www.cnki.net

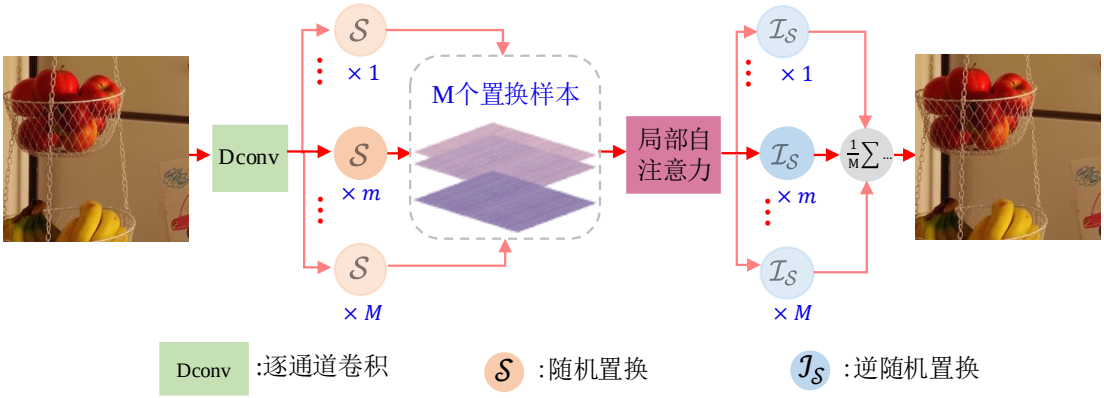


图 4.7　基于随机置换的自注意力的推理策略示意图

机因子的数学期望，然而，模型每层的随机置换函数都是独立分布的，显式地对模型的预测结果取数学期望的计算量随着模型深度指数级的增加。因此，用蒙特卡洛均值近似该数学期望值。即

$$\mathcal{F}^{\text{test}}(\boldsymbol{y}, \mathcal{S}) = \mathop{\mathbb{E}}_{\mathcal{S}}\left[\mathcal{F}(\boldsymbol{y}, \mathcal{S})\right] \tag{4.20a}$$

$$\approx \frac{1}{M}\sum_{i=1}^{M}\mathcal{F}\left(\boldsymbol{y}; \mathcal{S}_i\right). \tag{4.20b}$$

式中，$\mathcal{F}(\cdot)$ 代表图像复原模型。然而，式 (4.20) 中是有计算冗余的：即前馈网络层（SeFF）中无随机因子，但是经历了多次前向传播。受 Dropout 方法[143]的启发，整个模型的期望可以通过逐层的期望近似。因此，针对单独的 HomoMSA 层计算期望是合理的，其形式为：

$$\text{HomoMSA}^{\text{test}}\left(\boldsymbol{y}^m\right) = \mathop{\mathbb{E}}_{\mathcal{S}}\left[\text{HomoMSA}\left(\boldsymbol{y}^m; \mathcal{S}\right)\right]. \tag{4.21}$$

然而，根据式 (4.21) 计算 $\text{HomoMSA}^{\text{test}}$ 需要枚举所有可能的随机排列结果，这在实际计算中代价过高。一种对数学期望值的近似方法是蒙特卡洛平均（见式 (4.22) ）。具体过程是：对输入 $\boldsymbol{y}^m$ 进行 M 次独立的随机置换，独立计算 M 次 HomoMSA 的输出，并对这些输出取平均以获得数学期望的蒙特卡洛均值的估计。当 $M \to \infty$ 时，该估计值依概率收敛至真实期望值。

$$\text{HomoMSA}^{\text{test}}\left(\boldsymbol{y}^m\right) \approx \frac{1}{M}\sum_{i=1}^{M}\text{HomoMSA}\left(\boldsymbol{y}^m; \mathcal{S}_i\right). \tag{4.22}$$

根据式 (4.22)，推理时间会随着蒙特卡洛样本数 M 而线性增加。然而在深度学习加速器（GPU）上，多个前向传播过程可被并行执行以显著降低推理阶段耗时。具体而言，可通过以下方式实现加速：将输入数据载入 GPU 后，构造包含 M 个相同输入的批量数据；随后，HomoMSA 在批量维度上进行独立随机置换

中国知网　https://www.cnki.net

表 4.1　训练阶段不同自注意力机制的复杂度

方法	时间复杂度	空间复杂度	建模长程依赖关系
MSA	$\Theta\left(BH^2W^2C+BHWC^2\right)$	$\Theta\left(BhH^2W^2+BHWC\right)$	✓
W-MSA	$\Theta\left(BHWCs^2+BHWC^2\right)$	$\Theta\left(BhHWs^2+BHWC\right)$	✗
HomoMSA	$\Theta\left(BHWCs^2+BHWC^2\right)$	$\Theta\left(BhHWs^2+BHWC\right)$	✓

表 4.2　推理阶段不同自注意力机制的复杂度

方法	时间复杂度	空间复杂度	建模长程依赖关系
MSA	$\Theta\left(BH^2W^2C+BHWC^2\right)$	$\Theta\left(BhH^2W^2+BHWC\right)$	✓
W-MSA	$\Theta\left(BHWCs^2+BHWC^2\right)$	$\Theta\left(BhHWs^2+BHWC\right)$	✗
HomoMSA	$\Theta\left(MBHWCs^2+MBHWC^2\right)$	$\Theta\left(MBhHWs^2+MBHWC\right)$	✓

操作。通过单次前向传播后对批量维度取平均，即可直接获得蒙特卡洛估计值。HomoMSA 在推理阶段的流程图见图 4.7。基于此，模型的推理过程为：

$$\boldsymbol{z}^m=\boldsymbol{y}^{m-1}+\mathrm{HomoMSA}^{\mathrm{test}}\left(\mathrm{LN}\left(\boldsymbol{y}^{m-1}\right)\right) \tag{4.23a}$$

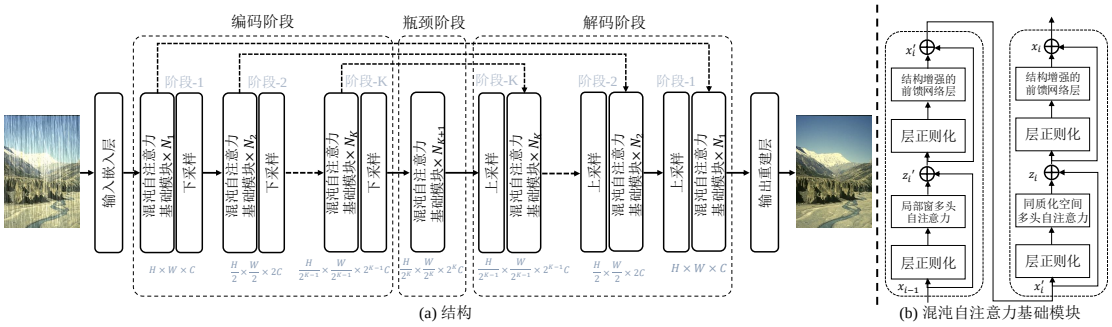
$$\approx \boldsymbol{y}^{m-1}+\frac{1}{M}\sum_{i=1}^{M}\mathrm{HomoMSA}\left(\mathrm{LN}\left(\boldsymbol{y}^{m-1}\right);\mathcal{S}_i\right), \tag{4.23b}$$

$$\boldsymbol{y}^m=\boldsymbol{z}^m+\mathrm{SeFF}\left(\mathrm{LN}\left(\boldsymbol{z}^m\right)\right). \tag{4.23c}$$

4.2.8　复杂度分析

本节详细地分析同质化空间自注意力（HomoMSA）和混沌窗口自注意力的时间和空间复杂度。表 4.1 和表 4.2 展示了复杂度以及是否可以建模长程依赖关系，并与 MSA（经典多头自注意力机制）、W-MSA（基于局部窗口的多头自注意力机制）对比。首先引入符号定义：$\boldsymbol{B}$: 待处理数据批量大小，$\boldsymbol{H}\times\boldsymbol{W}$: 特征图分辨率，$\boldsymbol{C}$：通道数，$s$: 局部窗口分辨率，$h$: 注意力头数，$\boldsymbol{M}$: 蒙特卡洛样本数。对于 MSA，训练阶段和推理阶段复杂度是一致的，输入张量 $\boldsymbol{y}\in\mathbb{R}^{B\times HW\times C}$，参数张量 $\boldsymbol{W}_h^Q\in\mathbb{R}^{C\times\frac{C}{h}}$、$\boldsymbol{W}_h^K\in\mathbb{R}^{C\times\frac{C}{h}}$、$\boldsymbol{W}_h^V\in\mathbb{R}^{C\times\frac{C}{h}}$ 和 $\boldsymbol{W}^O\in\mathbb{R}^{C\times C}$，不难得出其时间复杂度为 $\Theta\left(BH^2W^2C+BHWC^2\right)$，其空间复杂度为 $\Theta\left(BhH^2W^2+BHWC\right)$，经典 MSA 可以建模长程依赖关系。对于 W-MSA，训练阶段和推理阶段复杂度相同，由于自注意力中标记的数量限制为 $s\times s$，其时间复杂度为 $\Theta\left(BHWCs^2+BHWC^2\right)$，存储复杂度为 $\Theta\left(BhHWs^2+BHWC\right)$。由于局部窗口的限制，W-MSA 无法建模长程依赖关系。同时，由于 SW-MSA 仅引入偏移窗口，因此复杂度和 W-MSA 相同。在训练阶段，HomoMSA 在计算速度和显存占用上与 W-MSA 保持相同复杂度；在推理阶段，HomoMSA 运行了 $\boldsymbol{M}$ 次，因此复杂度是 W-MSA 的 $\boldsymbol{M}$

中国知网　https://www.cnki.net



(a) 结构　(b) 混沌自注意力基础模块

图 4.8　HomoFormer-Local 的模型结构图

倍。HomoMSA 由于引入随机置换，可以建模长程依赖关系。综上，尽管 MSA 能够捕获长程交互关系，但是时间复杂度随输入分辨率呈平方关系增长。相比之下，HomoMSA 在保持高效训练的同时，仍具备建模全局交互的能力。推理阶段，W-MSA 虽然能以特征图分辨率的线性复杂度完成推理，但仍只能建模局部交互关系。而 HomoMSA 的在推理阶段复杂度与输入分辨率呈线性关系，且相较于训练阶段需额外乘以蒙特卡洛样本数 $\boldsymbol{M}$。混沌窗口自注意力是 W-MSA 和 HomoMSA 交替而成，因此，混沌窗口自注意力的时间复杂度和空间复杂度与同质化空间自注意力相同。

4.2.9　HomoFormer-Local 模型架构

本章提出的混沌窗口自注意力能够以特征图分辨率的线性复杂度建模长程交互关系。在图像复原任务中，局部相关性与全局内容的相关性对恢复清晰图像均很重要。因此，理想的图像复原模型需具有局部交互和全局上下文建模能力。基于此，在 HomoFormer 基础上引入局部窗口自注意力机制增强对局部关系的提取，即引入混沌窗口自注意力（即式 (4.18) 和式 (4.19)）代替同质化空间自注意力（即式 (4.3)）。最终的 Transformer 模型称为 HomoFormer-Local，兼具精确局部特征提取与非局部交互的建模，在图像空间实现了跨尺度交互的补偿。HomoFormer-Local 的模型整体结构如图 4.8 所示。

4.3　实验结果与分析

4.3.1　实验设置

4.3.1.1　模型变体

由于随机置换操作引入了随机性，实验进行五次评估，并计算定量指标。实验中发现，标准差远小于报告的指标的精度，因此实验表格中忽略了标准差。此外，考虑到随机置换引入的随机因子，根据贝叶斯理论，需要边缘化（Marginalize）随机因子。第 4.2.7 节中引入了推理策略，为了验证取数学期望的作用，设计

中国知网　https://www.cnki.net

表 4.3　在 SRD 数据集上的图像去阴影定量结果

方法	阴影区域			非阴影区域			全区域		
	PSNR	SSIM	MAE	PSNR	SSIM	MAE	PSNR	SSIM	MAE
输入图像	18.96	0.871	36.69	31.47	0.975	4.83	18.19	0.829	14.05
Guo 等人[211]	-	-	29.89	-	-	6.47	-	-	12.60
DeshadowNet[212]	-	-	11.78	-	-	4.84	-	-	6.64
DSC[213]	30.65	0.960	8.62	31.94	0.965	4.41	27.76	0.903	5.71
DHAN[214]	33.67	0.978	8.94	34.79	0.979	4.80	30.51	0.949	5.67
Fu 等人[209]	32.26	0.966	8.55	31.87	0.945	5.74	28.40	0.893	6.50
Jin 等人[215]	34.00	0.975	7.70	35.53	0.981	3.65	31.53	0.955	4.65
BMNet[210]	35.05	0.981	6.61	36.02	0.982	3.61	31.69	0.956	4.46
SG-ShadowNet[216]	-	-	7.53	-	-	2.97	-	-	4.23
ShadowFormer[217]	36.91	**0.989**	5.90	36.22	**0.989**	3.44	32.90	0.958	4.04
ShadowDiffusion[218]	38.72	0.987	4.98	37.78	0.985	3.44	34.73	0.970	3.63
Li 等人[219]	**39.33**	0.985	6.09	35.61	0.967	2.97	33.17	0.941	3.83
HomoFormer	38.81	0.987	**4.25**	39.45	0.988	2.85	35.37	**0.972**	3.33
HomoFormer-MC	38.64	0.987	4.33	**40.04**	**0.989**	**2.76**	**35.50**	**0.972**	**3.29**

了两个模型变体：HomoFormer：表示未采用贝叶斯推理，单次前向传播的结果，HomoFormer-MC：表示采用蒙特卡洛均值（Monte-Carlo Avarage）作数学期望的近似；HomoFormer-Local 表示未采用贝叶斯推理，将随机置换层设置为偏移窗口的单次前向传播的结果，HomoFormer-Local-MC 表示采用蒙特卡洛均值（Monte-Carlo Avarage）作数学期望的近似。蒙特卡洛样本的数量默认值为 8。

4.3.1.2　数据集

图像去阴影是一个典型的噪声在空间非均匀分布的图像复原任务，图像去阴影实验主要基于三个公开数据集：

- ISTD[225]和 ISTD+ 数据集[222]包含了 1870 组图像三元组（阴影图像、无阴影图像和阴影掩码），其中 1330 组数据用于训练，540 组数据用于测试。
- SRD 数据集[212]由 2680 组训练样本和 408 组测试样本组成。由于 SRD 缺乏真实的阴影掩码，在训练阶段和测试阶段直接使用 DHAN[214]提供的公开 SRD 阴影掩码。
- SBU 数据集[226]是真实世界的场景下的图像去阴影数据集，用来验证模型的泛化性能。

图像去雨任务采用真实世界拍摄的 SPA-Data[33]数据集；图像去噪任务采用真实世界的噪声 SIDD[197]数据集；图像去模糊任务采用 GoPro[30]数据集训练，

中国知网　https://www.cnki.net

表 4.4　在 ISTD+ 数据集上的图像去阴影的定量结果

方法	阴影区域 MAE	非阴影区域 MAE	全区域 MAE
输入图像	40.2	2.6	8.5
Guo 等人[211]	22.0	3.1	6.1
DeshadowNet[212]	15.9	6.0	7.6
ST-CGAN[220]	13.4	7.7	8.7
ShadowGAN[221]	12.4	4.0	5.3
SP+M-Net[222]	7.9	3.1	3.9
Param+M+D-Net[223]	9.7	3.0	4.0
G2R[224]	7.3	2.9	3.6
Fu 等人[209]	6.5	3.8	4.2
Jin 等人[215]	10.3	3.5	4.6
BMNet[210]	5.6	2.5	3.0
SG-ShadowNet[216]	5.9	2.9	3.4
ShadowFormer[217]	5.2	2.3	2.8
ShadowDiffusion[218]	**4.9**	2.3	2.7
Li 等人[219]	5.9	2.9	3.3
HomoFormer	5.0	2.3	2.7
HomoFormer-MC	5.0	**2.2**	**2.6**

在 GoPro[30]测试集、HIDE[162]、RealBlur-R[227] 和 RealBlur-J[227]数据集上进行性能评估。

4.3.1.3　评估指标

为了与其他方法进行定量比较，根据已有的研究[209,211,215,225]，计算模型处理后的图像和清晰图像之间在 LAB 颜色空间的平均绝对值误差（Mean Absolute Error，MAE）。对于 MAE 指标，其值越低意味着误差越小，即复原效果越好。此外，还采用峰值信噪比（PSNR）和结构相似性（SSIM）来评估不同方法在 RGB 空间中的性能。对于 PSNR 和 SSIM 指标，值越高意味着复原结果越精确。与已有工作的一致，将图像的分辨率调整为 256×256，获得定量结果。对于更多的图像复原任务，包括图像去噪、图像去雨、图像去模糊，采用峰值信噪比（PSNR）和结构相似性（SSIM）来评估不同方法在 RGB 空间中的性能。在定量结果的表中，用**加粗**标注最优的结果，用下划线 标注次优的结果。

中国知网　https://www.cnki.net

4.3.2　空间非均匀分布的图像退化去除

4.3.2.1　基于 ISTD+ 数据集的性能比较

表 4.4 中展示了在 ISTD+ 数据集[222]上与其他图像去阴影方法的 MAE 指标对比。比较的基线方法涵盖了传统的阴影去除方法：Guo 等人[211]，和基于深度学习的方法：DeshadowNet[212]，ST-CGAN[220]，ShadowGAN[221]，SP+M-Net[222]，Param+M+D-Net[223]，G2R[224]，Fu 等人[209]，Jin 等人[215]，BMNet[210]，SG-ShadowNet[216]，以及 ShadowFormer[217]。为了保证公平比较，所有比较方法的结果从原论文中获得。表 4.4 表明，HomoFormer 比其他基线方法取得了更低的 MAE，因此，获得更精确的复原结果。例如，相较于 BMNet[210]，取得了 0.4 的提升。此外，相比于 HomoFormer，采用蒙特卡洛平均的 HomoFormer-MC 在阴影区域和非阴影区域均取得了更好的结果。图 4.9 展示了基于 ISTD+ 数据集的图像去阴影的视觉效果，与其他方法相比，HomoFormer 的复原结果具有更少的边界伪影。

4.3.2.2　基于 SRD 数据集的性能比较

表 4.3 中展示基于 SRD 数据集[212]的定量性能对比，比较的基线方法包括 Guo 等人[211]，DeshadowNet[212]，DSC[213]，DHAN[214]，Fu 等人[209]，Jin 等人[215]，BMNet[210]，SG-ShadowNet[216]，ShadowFormer[217]，Li 等人[219]，以及 ShadowDiffusion[218]。本章提出的 HomoFormer 在图像去阴影任务中表现最佳，取得了最低的 MAE、最高的 PSNR 和 SSIM 值。与 ShadowFormer[217]相比，HomoFormer 的 PSNR 值从 32.90 dB 提高至 35.37 dB。此外，图 4.10 提供了基于 SRD 数据集的图像去阴影的视觉效果对比。可以看出，HomoFormer 能够在取得更优的阴影去除效果，同时能减小阴影区域和无阴影区域边界处的伪影。

4.3.2.3　基于 SBU 数据集的性能比较

为了验证模型的泛化能力，利用 ISTD+ 数据集上预训练的模型，在 SBU 数据集[226]上性能评估。图 4.11 展示了视觉效果对比。可以看出，相比于其他方法，HomoFormer 取得精确和一致的阴影去除效果。

中国知网　https://www.cnki.net

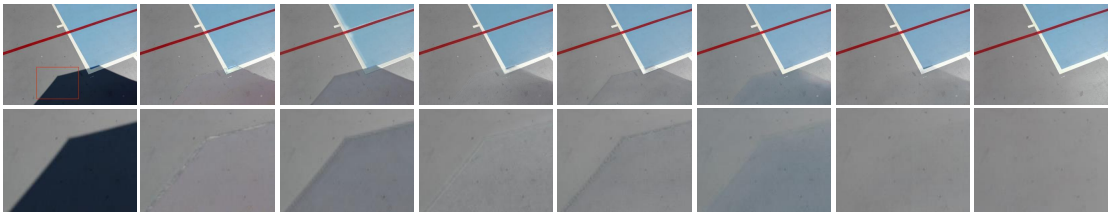


图 4.9　在 ISTD+ 数据集的图像去阴影视觉效果

第一行：全图像的视觉效果。第二行：第一行中红框标注的区域的放大图。

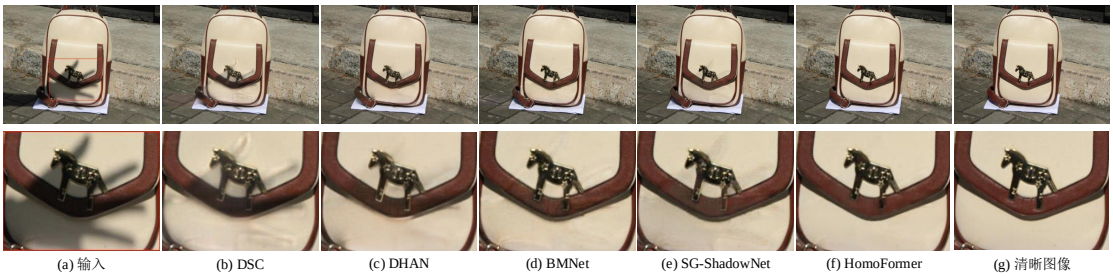


图 4.10　在 SRD 数据集的图像去阴影视觉效果

第一行：全图像的视觉效果。第二行：第一行中红框标注的区域的放大图。

4.3.2.4　基于 ISTD 数据集上的性能比较

表 4.5 提供了 ISTD 数据集上的定量比较。HomoFormer 的表现仍具有竞争力，但并非最优。其原因是 ISTD 数据集中的训练对存在光照不一致性。然而，随机置换操作使得 HomoFormer 难以适应光照的变化。

表 4.5　在 ISTD 数据集上图像去阴影的定量结果

方法	阴影区域 MAE	非阴影区域 MAE	全区域 MAE
输入图像	40.2	2.6	8.5
Guo 等人[211]	18.65	7.76	9.26
ST-CGAN[220]	9.99	6.05	6.65
ShadowGAN[221]	12.67	6.68	7.41
G2R[224]	10.72	7.55	7.85
Fu 等人[209]	7.91	5.51	5.88
Jin 等人[215]	11.43	**3.81**	6.57
BMNet[210]	7.60	4.59	5.02
ShadowFormer[217]	<u>6.16</u>	<u>3.90</u>	<u>4.27</u>
ShadowDiffusion[218]	**4.13**	4.14	**4.12**
HomoFormer	6.85	4.24	4.49

中国知网　https://www.cnki.net



(a) 输入　(b) SP+M+I-Net　(c) ShadowFormer　(d) SG-ShadowNet　(e) HomoFormer

图 4.11　在 SBU 数据集上的图像去阴影视觉效果

4.3.2.5　消融研究与分析

为了验证 HomoFormer 各模块设计的作用，并研究随机置换的性质及其为图像复原带来的优点，本节基于在 ISTD+ 数据集[222]上进行消融实验和分析。

随机置换的影响。为了研究随机置换的效果，设计了一个未采用随机置换和逆随机置换的模型变体：去除了随机置换函数和逆随机置换函数，即为基于局部窗口自注意力的 Transformer。表 4.6 表明，移除随机置换后，阴影区域（+1.4）、非阴影区域（+0.2）以及整体区域（+0.3）的 MAE 均显著增加，即性能显著降低，这表明随机置换函数有助于更精确地去除阴影退化并保持图像的非阴影区域。如上分析，其原因是随机置换函数能够同质化阴影退化的非均匀分布，更兼容权重共享的局部窗口自注意力机制。

为了更深入了解随机置换的行为，图 4.12 可视化了默认的 HomoFormer 配置和移除随机置换的变体模型的中间特征。图 4.12 中展示了来自第一个编码层和最后一个解码层一个注意力头的特征。移除随机置换后，局部窗口自注意力机制必须依靠同一套的参数来在不同阴影程度的区域之间找到次优的权衡（见图 4.1 ）。实验中可以观察到这一效应：对于来自第一个编码层的特征（图 4.12 中的第 2-3 列），没有随机置换的模型变体，高亮显示的区域几乎丢弃了所有纹理信息，不利于实现精确复原的效果；而最后一个解码层的特征将被用于构建最终的复原图像，因此，最后一个解码层特征应该尽可能包含清晰区域和细节纹理，而排除阴影退化带来的伪影。观察最后一个解码层的特征，可以发现带有随机置换的 HomoFormer 能够完成阴影退化特征的去除和清晰特征的保留。综合这些观察，与去除随机置换的模型变体相比，默认的 HomoFormer 的特征在模型浅层（第 2 列和第 3 列）包含更多的细节纹理，在模型深层（第 4 列和第 5 列）则展现出更加真实的内容。可以得出结论，随机置换保留更多的图像纹理和更少的伪影，有助于提取更有效的特征。

结构建模的影响。由于在局部窗口自注意力中舍弃了结构信息，基于卷积层

中国知网　https://www.cnki.net

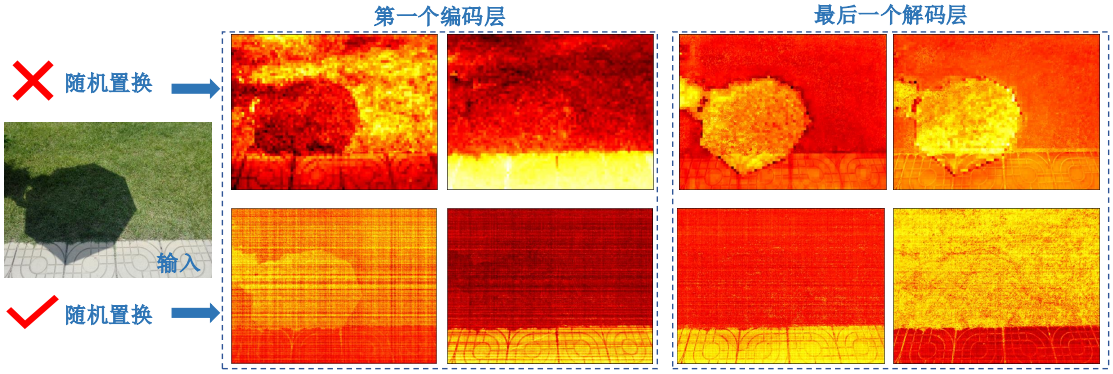


图 4.12　特征可视化

依赖相对位置关系进行局部加权的机理，同时为了降低模型的计算和显存开销，在模型设计中加入了逐通道卷积层建模结构信息。为了验证逐通道卷积层的作用，设计了未采用逐通道卷积的模型变体，表 4.6 表明，去掉结构建模（即移除逐通道卷积）显著降低了性能。

表 4.6　基于 ISTD+ 数据集的消融实验

变体	阴影区域 MAE	非阴影区域 MAE	全区域 MAE
– 随机置换	6.4	2.5	3.0
– 结构建模	5.6	2.5	2.9
HomoFormer（默认）	5.0	2.3	2.7

注：“– 随机置换”表示移除随机置换，“– 结构建模”表示移除结构建模。

不确定性可以预测误差。不确定度（Uncertainty）在计算机视觉任务中发挥重要作用[228]。对于图像去阴影任务，不确定度可以评估预测结果的置信度。由于其随机置换固有的随机因素，HomoFormer 为估计不确定度提供了一种自然的方案：多次处理同一张图像，由于随机置换的随机因素，每次处理结果是有差异的，基于不同的处理结果计算标准差作为不确定度。随机置换带来的不确定度可以用来预测复原图像 $\mathcal{F}(\boldsymbol{y})$ 和清晰图像 $\boldsymbol{x}$ 之间的误差分布，即：

$$\text{Uncertainty}(\mathcal{F}(\boldsymbol{y})) \rightarrow |\boldsymbol{x} - \mathcal{F}(\boldsymbol{y})| \tag{4.24}$$

为了验证这一点，图 4.14 分别可视化了模型估计的不确定度 $\text{Uncertainty}(\mathcal{F}(\boldsymbol{y}))$，和清晰图像的误差分布 $|\boldsymbol{x} - \mathcal{F}(\boldsymbol{y})|$，可以发现基于随机置换的 HomoFormer 可以不依赖于清晰图像而估计不确定度，图 4.14 中所示，不确定度和误差分布有高度的一致性，这对于实际应用场景具有重要意义。

蒙特卡洛样本数量的影响。为了边缘化随机因子，本章提出利用蒙特卡洛平均来近似数学期望。理论上，随着蒙特卡洛样本数量趋于无穷大，蒙特卡洛平均值将接近真实期望值。在 SRD 数据集上实验验证蒙特卡洛样本数量的影响，

中国知网　https://www.cnki.net

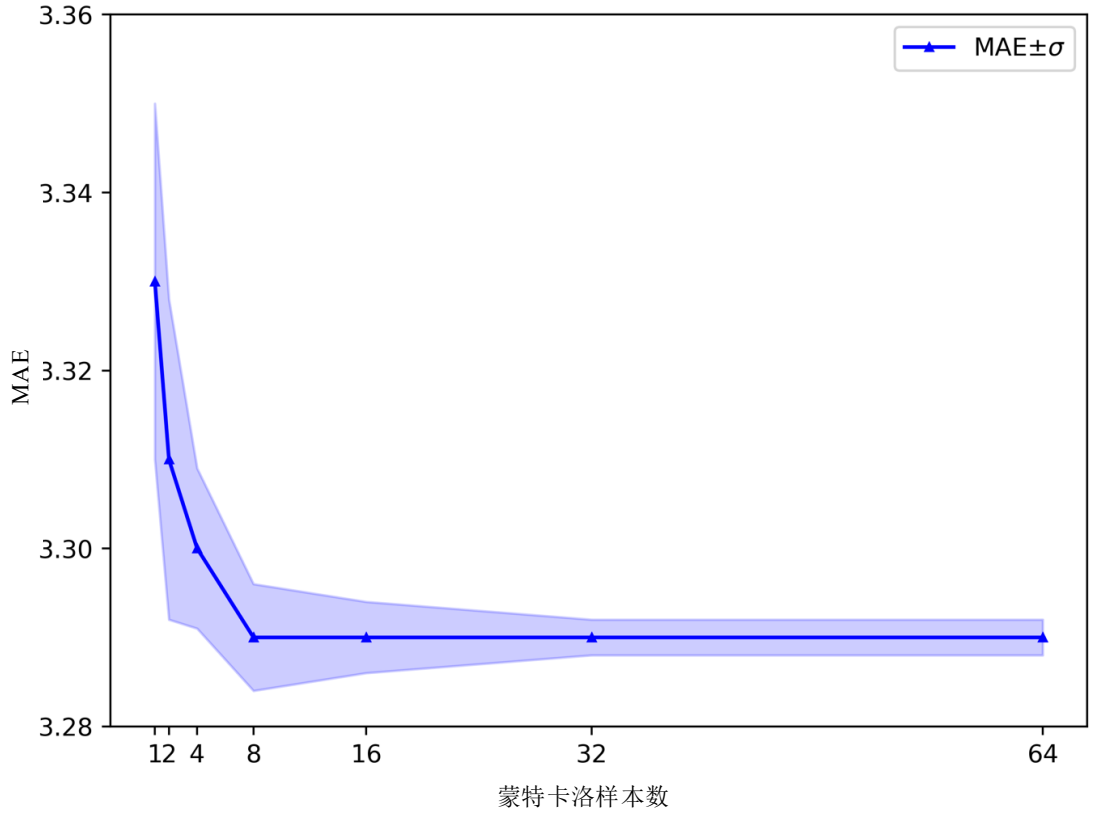


图 4.13　蒙特卡洛采样样本数量的影响

图 4.13 显示，随着蒙特卡洛样本数量的增加，性能首先提升随后趋于稳定，样本数为 8 可以达到性能和计算效率较好的平衡。

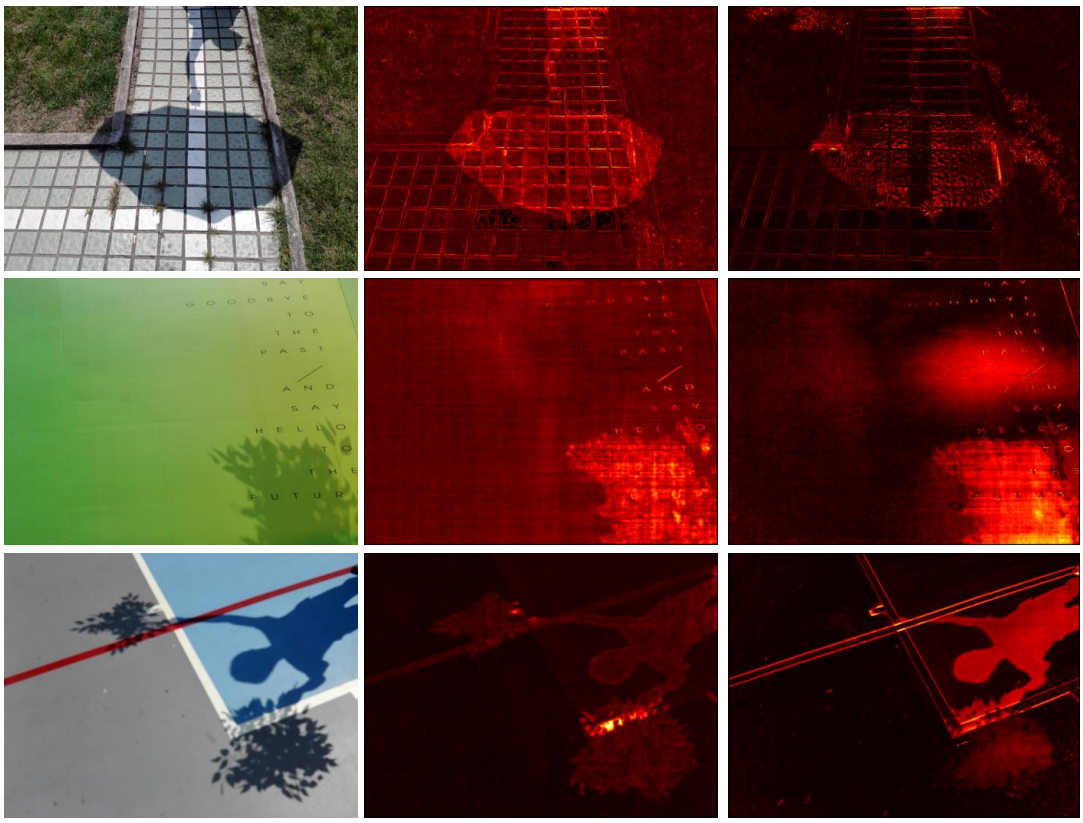
4.3.3　更多图像复原任务

HomoFormer 利用随机置换同质化空间分布非均匀的阴影分布，因此在图像去阴影任务中取得优异的性能。然而，在更一般的图像复原任务上无法取得和现在最优方法相当的性能。以图像去噪为例，HomoFormer 在 SIDD 数据集上取得 PSNR 为 39.70 dB，低于基于卷积神经网络的 MPRNet[229]（39.71 dB）和基于 Swin Transformer 的 Uformer[63]（39.89 dB）。为了增强 HomoFormer 在挖掘局部依赖关系的能力，将局部窗口自注意力引入 HomoFormer，提出了 HomoFormer-Local，本节验证 HomoFormer-Local 在更多的图像复原任务上包括图像去雨、图像去噪和图像去模糊的性能。

4.3.3.1　图像去雨

图像去雨实验是基于真实世界的 SPA-Data 数据集[150]， SPA-Data 数据集包含 638K 个训练对和 1000 张测试图像。除两种 HomoFormer-Local 变体外，本节还比较了六种经典的去雨基线方法：GMM[148]、DDN[51]、SPANet[33]、JORDER-E[116]、RCDNet[149]以及 SPAIR[150]。为了验证随机置换在训练阶段的

中国知网　https://www.cnki.net



(a) 输入　(b) 不确定度分布　(c) 误差分布

图 4.14　不确定度分布和误差分布的可视化

作用，本节也将推理阶段的蒙特卡洛均值策略应用于 Uformer，引入 Uformer 变体，称为 Uformer-MC。表 4.7 展示了各方法的图像去雨的性能对比，可以发现 HomoFormer-Local 取得最优的性能，同时没有经过随机置换的训练，直接将蒙特卡洛均值应用到 Uformer 降低模型在图像去雨性能；图 4.15 显示，与其他方法相比，HomoFormer-Local-MC 在去除雨线的同时更完整地保留了图像纹理。

4.3.3.2　图像去噪

图像去噪实验是基于真实世界噪声 SIDD 数据集[197]。为证明 HomoFormer-Local 的有效性，对比了多种基线方法：BM3D[1]、RIDNet[230]、VDN[156]、DANet[193]、CycleISP[194]、MIRNet[115]、MPRNet[58]、NBNet[229]和 Uformer[120]。为了验证随机置换在训练阶段的作用，本节也将推理阶段的蒙特卡洛均值策略应用于 Uformer 上，引入 Uformer 变体，称为 Uformer-MC。表 4.8 展示了基线方法以及 HomoFormer-Local 变体在真实图像去噪任务中的 PSNR 和 SSIM。可以发现 HomoFormer-Local-MC 取得最优的性能，同时没有经过随机置换的训练，直接将蒙特卡洛均值应用到 Uformer 降低模型在图像去噪性能；图 4.16 展示了与其他方法的视觉比较结果，可以看出，HomoFormer-Local-MC 取得了纹理更清晰、色偏更小的图像复原结果。

中国知网　https://www.cnki.net

表 4.7　在 SPA-Data 数据集上的图像去雨的定量结果

方法	SPA-Data	
	PSNR	SSIM
GMM[148]	34.30	0.9428
DDN[51]	36.97	0.9604
SPANet[33]	40.24	0.9811
JORDER-E[116]	40.78	0.9811
RCDNet[149]	41.47	0.9834
SPAIR[150]	44.10	0.9872
Uformer[63]	<u>48.80</u>	**0.9935**
Uformer-MC	47.91	<u>0.9927</u>
HomoFormer-Local	48.08	0.9923
HomoFormer-Local-MC	**49.19**	**0.9935**

表 4.8　在 SIDD 数据集上图像去噪的定量结果

方法	SIDD	
	PSNR	SSIM
BM3D[1]	25.65	0.685
RIDNet[230]	38.71	0.914
VDN[156]	39.28	0.909
DANet[193]	39.47	0.918
CycleISP[194]	39.52	0.957
MIRNet[115]	39.72	0.959
MPRNet[58]	39.71	0.958
NBNet[229]	39.75	<u>0.959</u>
MAXIM[231]	<u>39.96</u>	**0.960**
Uformer[120]	39.89	**0.960**
Uformer-MC	39.35	0.956
HomoFormer-Local	39.60	0.958
HomoFormer-Local-MC	**40.00**	**0.960**

中国知网　https://www.cnki.net



(a) 输入
PSNR

(b) DDN
31.24 dB

(c) RCDNet
31.25 dB

(d) Uformer
31.38 dB



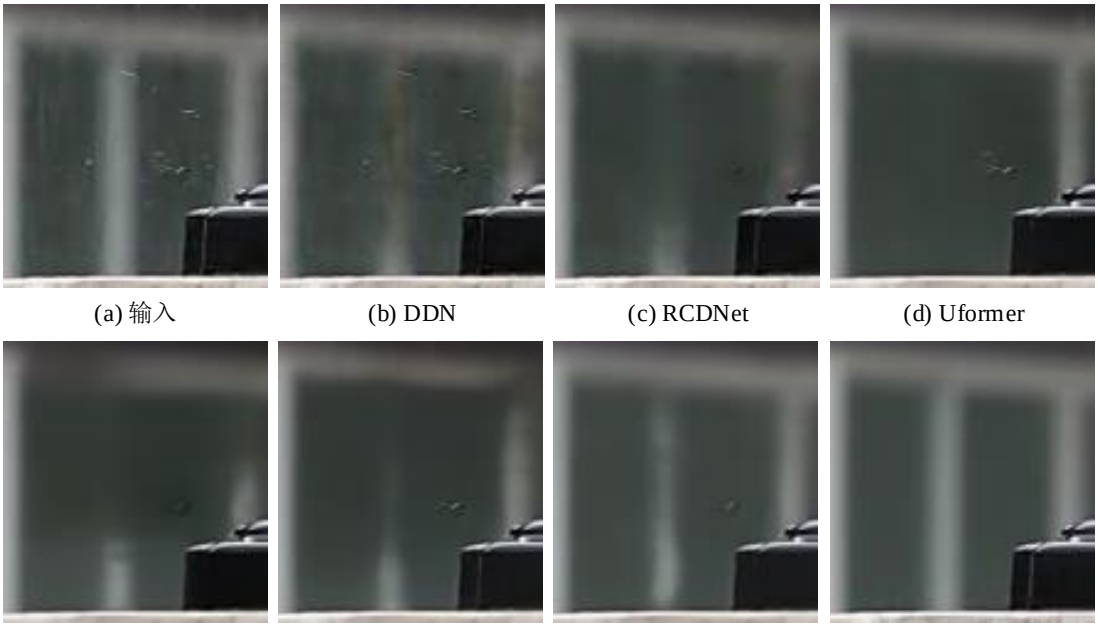
(e) Uformer-MC
28.79 dB

(f) HomoFormer-Local
30.89 dB

(g) HomoFormer-Local-MC
35.48 dB

(h) 清晰图像
∞

(a) 在全尺寸图像上的视觉效果



(a) 输入

(b) DDN

(c) RCDNet

(d) Uformer

(e) Uformer-MC

(f) HomoFormer-Local

(g) HomoFormer-Local-MC

(h) 清晰图像

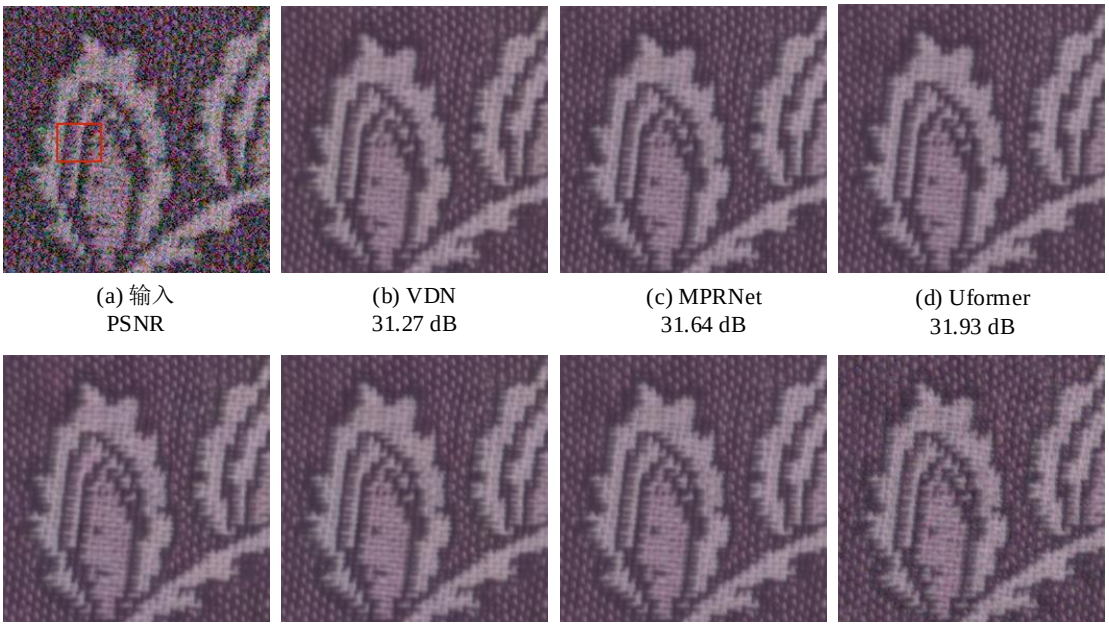
(b) 图 4.15(a) 中的标记区域的放大图

图 4.15　基于 SPA-Data 数据集的图像去雨视觉效果

4.3.3.3　图像去模糊

图像去模糊实验中，模型在 GoPro[30] 训练集训练，在 GoPro[30]、HIDE[162]、RealBlur-R[227] 和 RealBlur-J[227] 数据集上性能评估。基线方法包括：Xu 等人[232]、Nah 等人[30]、DeblurGAN[112]、Zhang 等人[233]、SRN[234]、DeblurGAN-v2[151]、DMPHN[220]、DBGAN[152]、MPRNet[58]、SPAIR[150]、DGUNet+[235]、MAXIM[231]、

中国知网　https://www.cnki.net



(a) 输入
PSNR

(b) VDN
31.27 dB

(c) MPRNet
31.64 dB

(d) Uformer
31.93 dB

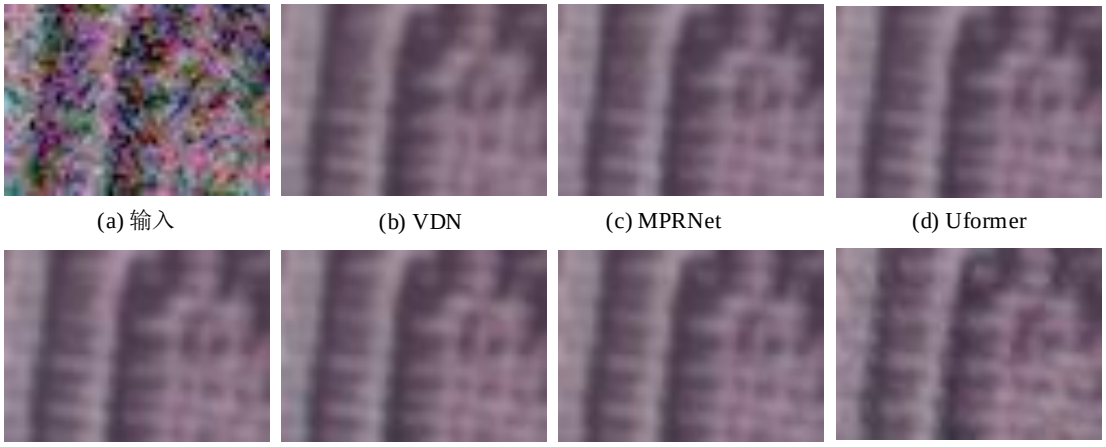
(e) Uformer-MC
31.66 dB

(f) HomoFormer-Local
31.74 dB

(g) HomoFormer-Local-MC
32.11 dB

(h) 清晰图像
∞

(a) 在全尺寸图像上的视觉比较



(a) 输入

(b) VDN

(c) MPRNet

(d) Uformer

(e) Uformer-MC

(f) HomoFormer-Local

(g) HomoFormer-Local-MC

(h) 清晰图像

(b) 图 4.16(a) 中的放大区域

图 4.16　在 SIDD 数据集的图像去噪的视觉效果

Restormer[64] 和 Uformer[120]。为了验证随机置换在训练阶段的作用，本节也将推理阶段的蒙特卡洛策略应用于 Uformer 上，引入 Uformer 和 Uformer-MC。表 4.9 展示了不同基线去模糊方法及 HomoFormer-Local 的变体在 PSNR 和 SSIM 对比；可以发现 HomoFormer-Local-MC 取得最优的性能，同时没有经过随机置换的训练，直接将蒙特卡洛均值应用到 Uformer 降低模型在图像去模糊性能；图 4.17 展示了来自 GoPro[30] 数据集的图像去模糊视觉效果，可以看出，HomoFormer-Local-MC 保留更多的图像细节，如能更清晰地复原车牌中的“2”和车牌的矩形形状。

中国知网　https://www.cnki.net

表 4.9　在 GoPro 数据集上图像去模糊的定量结果

方法	GoPro		HIDE		RealBlur-R		RealBlur-J		Average	
	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
Xu 等人[232]	21.00	0.741	-	-	34.46	0.937	27.14	0.830	-	-
Nah 等人[30]	29.08	0.914	25.73	0.874	32.51	0.841	27.87	0.827	28.80	0.864
DeblurGAN[112]	28.70	0.858	24.51	0.871	33.79	0.903	27.97	0.834	28.74	0.867
Zhang 等人[233]	29.19	0.931	-	-	35.48	0.947	27.80	0.847	-	-
SRN[234]	30.26	0.934	28.36	0.915	35.66	0.947	28.56	0.867	30.71	0.915
DeblurGAN-v2[151]	29.55	0.934	26.61	0.875	35.26	0.944	28.70	0.866	30.03	0.905
DMPHN[220]	31.20	0.940	29.09	0.924	35.70	0.948	28.42	0.860	31.10	0.918
DBGAN[152]	31.10	0.942	28.94	0.915	-	-	-	-	-	-
MPRNet[58]	32.66	0.959	30.96	0.939	35.99	0.952	28.70	0.873	32.08	0.931
SPAIR[150]	32.06	0.953	30.29	0.931	-	-	28.81	0.875	-	-
DGUNet+[235]	33.17	0.963	**31.40**	**0.944**	-	-	-	-	-	-
Restormer[64]	32.92	0.961	31.22	0.942	36.19	0.957	28.96	0.879	32.32	0.935
Uformer[120]	33.05	0.962	30.89	0.940	36.19	0.956	29.06	0.884	32.30	0.936
Uformer-MC	31.74	0.953	29.77	0.928	35.40	0.944	28.01	0.852	31.23	0.919
HomoFormer-Local	32.36	0.954	30.42	0.936	35.75	0.951	28.40	0.866	31.74	0.928
HomoFormer-Local-MC	**33.38**	**0.965**	31.25	0.943	**36.34**	**0.958**	**29.19**	**0.890**	**32.54**	**0.939**

4.3.3.4　实验分析

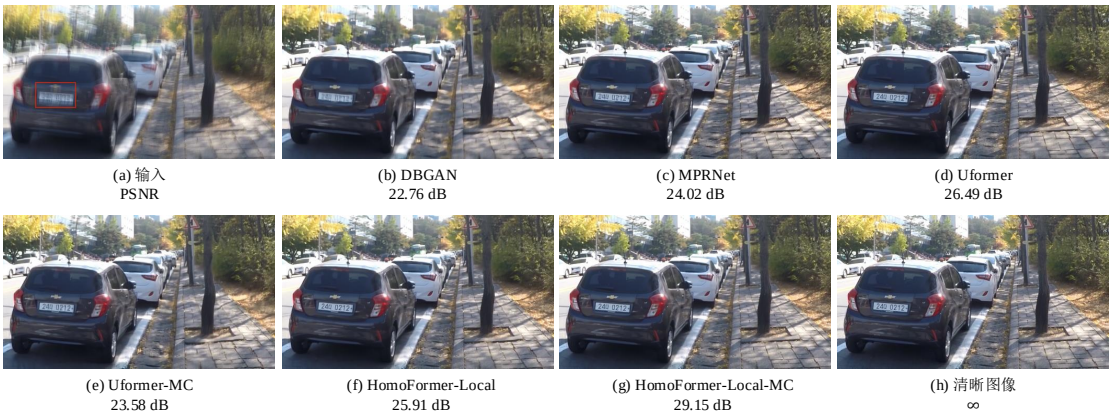
推理时间与性能的权衡。这里分析了蒙特卡洛均值样本数、推理时间、模型性能三者之间的权衡关系。实验基于 SIDD 数据集[197]，实验重复 5 次，记录“均值 ± 标准差”。图 4.18 揭示了当蒙特卡洛样本数 M 增加时，PSNR 与推理时间的变化趋势。观察可得出以下结论：

- 当 $M = 16$ 时，推理时间仅增加约 4 倍，而非 16 倍，这是因为蒙特卡洛均值可以并行的计算。
- 即使单样本（$M = 1$）情况下，与基于偏移窗口自注意力策略的基线相比，HomoFormer-Local-MC 仍能获得性能提升。

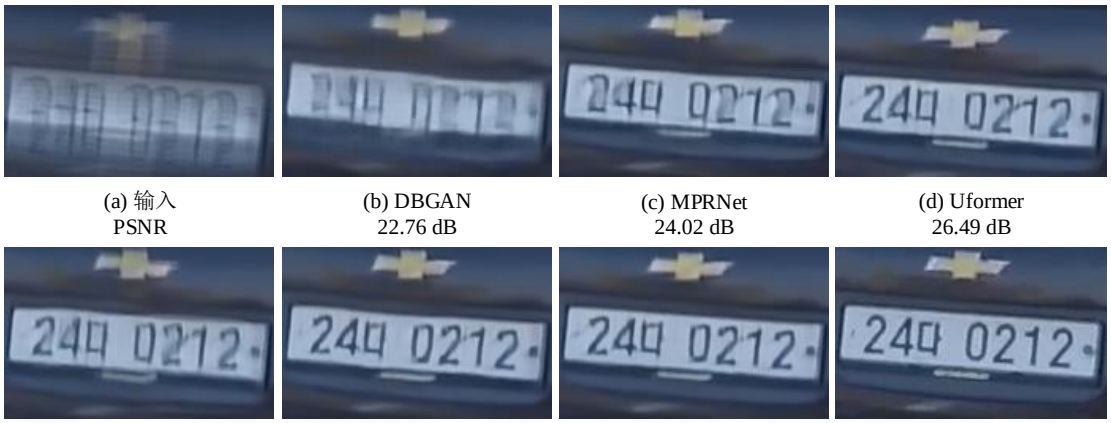
结构建模的有效性。为了利用图像结构信息，HomoFormer-Local 采用研究[206] 提出的逐通道卷积层进行结构建模。表 4.10 展示了在 SIDD 数据集上验证逐通道卷积对结构建模效果的消融实验结果。实验表明，该设计可通过建模相对位置依赖关系提升最终性能。

与前两章方法比较。这里将本章的方法与前两章方法在复杂度、性能、适应性等方面进行综合对比。在效率方面，HomoFormer 能够以线性复杂度处理退化图像，与 Stoformer 的复杂度相同，超过 LGT；在建模范围方面，HomoFormer 与 LGT 相同，均能建模全局依赖关系，超过 Stoformer；可以得出结论，相比于 Stoformer 和 LGT，HomoFormer 能够以更低的复杂度完成全局依赖关系建模。在

中国知网　https://www.cnki.net



(a) 在全尺寸图像上的视觉比较



(b) 图 4.17(a) 中的放大区域

图 4.17　基于 GoPro 数据集的图像去模糊视觉效果

表 4.10　在 SIDD 数据集上的结构建模消融研究

变体	PSNR	SSIM
− DConv	39.93	0.960
+ DConv	40.00	0.960

注：“−DConv” 表示移除 DConv，“+DConv” 表示利用 DConv 做结构建模。

性能方面，在 SIDD 数据集上，与 Stoformer 和 LGT 相比，HomoFormer 取得了最优的性能。

注意力建模范围可视化。为验证对长程依赖关系的建模能力，图 4.20 展示了不同自注意力机制的建模范围的对比。可观察到：偏移窗口多头自注意力的建模范围被严格限制在局部窗口内，而引入随机置换的混沌窗口自注意力能够突破窗口划分带来的局部限制，捕获长程依赖关系，同时可以观察到标记是稀疏的，因此混沌窗口自注意力是一种稀疏的全局注意力。

不同窗口尺寸下对性能的影响。假设 4.1 中提出用以计算自注意力的局部窗

中国知网　https://www.cnki.net

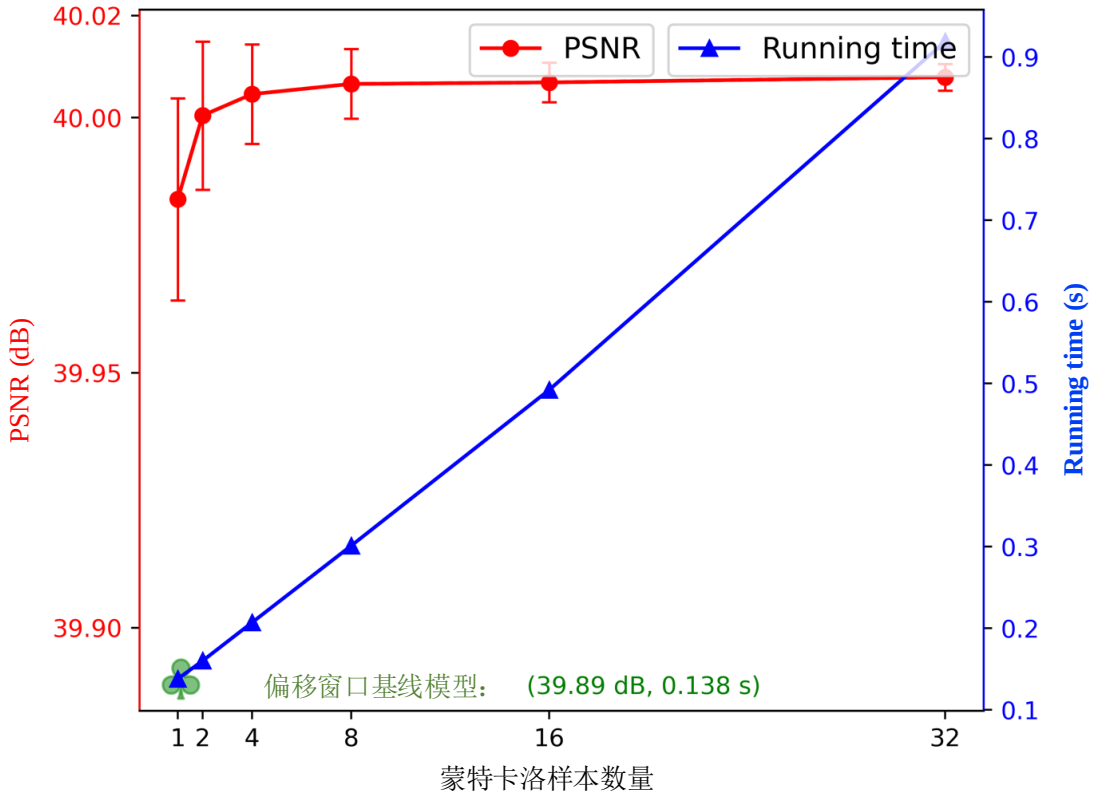


图 4.18　性能与推理时间的权衡

表 4.11　本文方法在 SIDD 数据集上图像去噪性能对比

方法	Stoformer	LGT	HomoFormer
性能（PSNR）	39.90	39.93	40.00
复杂度	$\Theta(HW)$	$\Theta\left((HW)^{\frac{3}{2}}\right)$	$\Theta(HW)$
建模范围	局部	全局	全局

口尺寸远小于图像的分辨率，而推论4.2 证明局部窗口自注意力可以建模全局依赖关系。本节进一步验证：和偏移窗口自注意力对比，在不同窗口分辨率下，混沌窗口自注意力能保持一致的性能优势。基于 SIDD 数据集[197] 的真实图像去噪实验表明（窗口分辨率选取 $\{2\times 2, 4\times 4, 8\times 8\}$，仍满足假设 4.1 的局部划分假设），如图 4.19 所示，和偏移窗口自注意力相比，混沌窗口自注意力在不同窗口尺寸下均具有一致的优势。这是因为随机置换函数对建模距离的扩展，以此提供了获取图像全局的上下文信息的途径，增强了对退化信息和清晰图像信息判别性，进而提升图像复原性能。

将随机置换扩展到卷积神经网络。 HomoFormer 和 HomoFormer-Local 的优越的性能证明了随机置换能扩展局部窗口自注意力的建模范围，增强其建模能力。接下来的一个问题是，是否可以将随机置换和卷积操作结合，增强卷积的建

中国知网　https://www.cnki.net

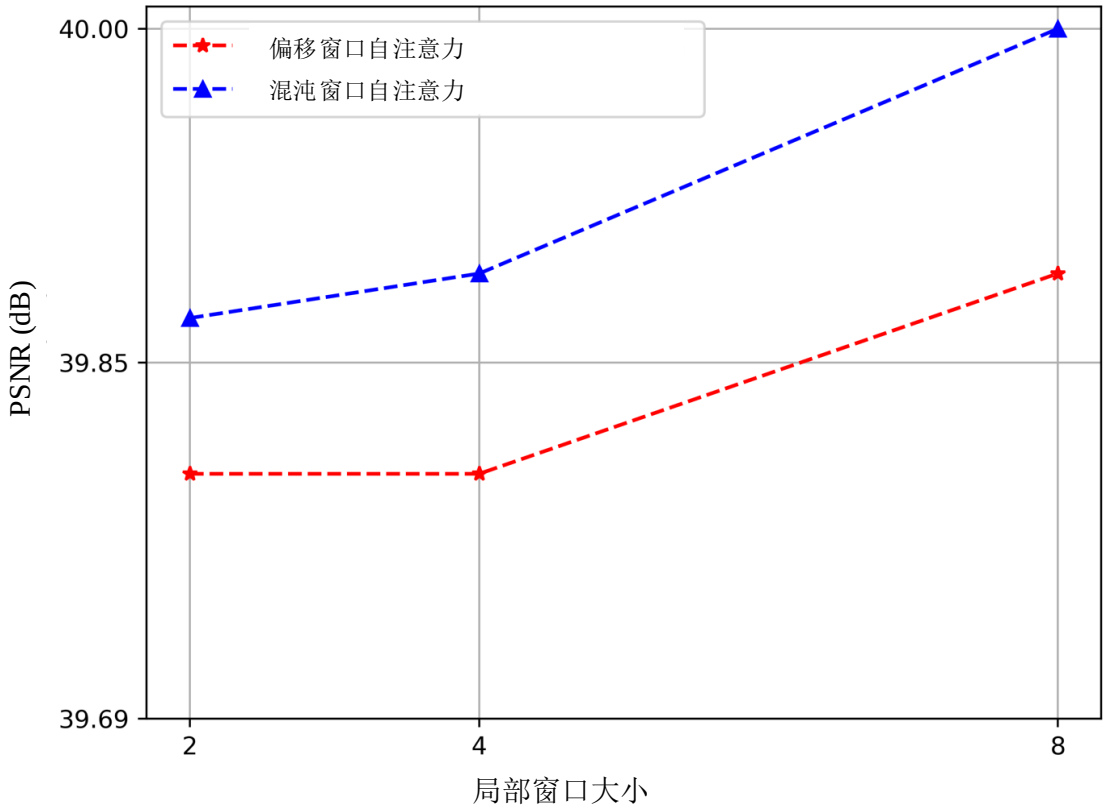
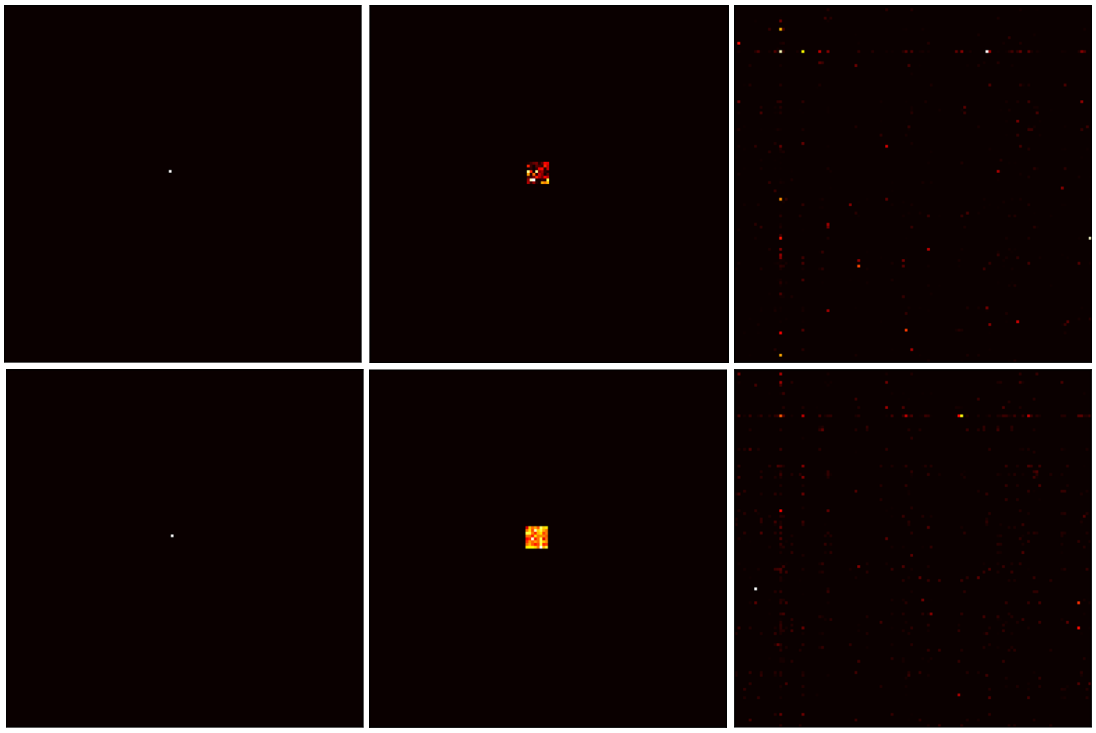


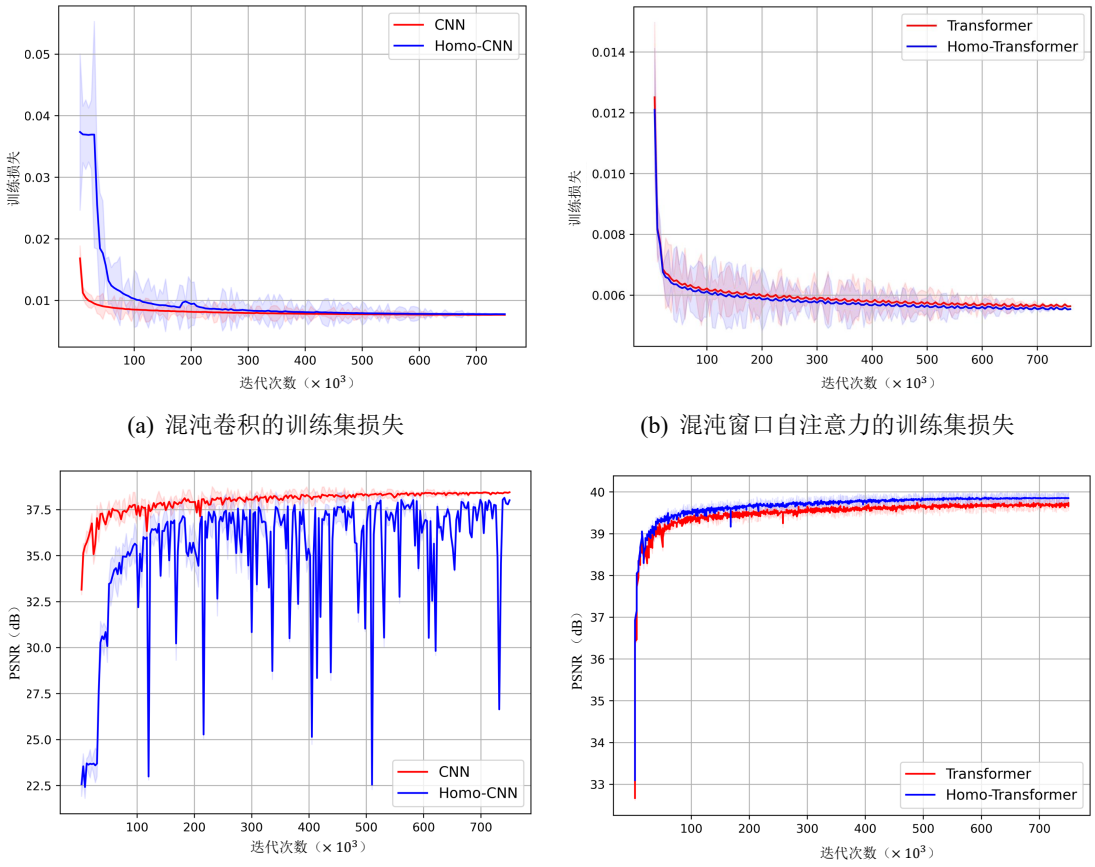
图 4.19　窗口尺寸对性能的影响



(a) 查询（Query）　(b) 偏移自注意力的建模范围 (c) 混沌自注意力的建模范围

图 4.20　偏移窗口多头自注意力和混沌窗口自注意力的建模范围对比图

中国知网　https://www.cnki.net



(a) 混沌卷积的训练集损失　(b) 混沌窗口自注意力的训练集损失

(c) 混沌卷积的验证集性能　(d) 混沌窗口自注意力的验证集性能

图 4.21　随机置换扩展到卷积神经网络

模能力？为了探索随机置换和卷积结合的可能性，本节再次沿用“局部建模 → 全局建模”的建模理念将随机置换扩展到卷积神经网络（CNN），设计了混沌卷积层：交替使用常规卷积和集成随机置换与逆随机置换的卷积。本节采用经典的 DnCNN[50] 作为基本模型结构，并通过将随机置换和逆随机置换引入其一半卷积层，以此方式引入的 DnCNN 版本称为 Homo-CNN。为了和自注意力层比较，同时控制自注意力窗口大小和卷积核大小接近，本章将 Homo-CNN 和局部窗口大小为 4 的 HomoFormer-Local 比较。实验基于图像去噪 SIDD 数据集[197]。图 4.21 展示了训练过程中的损失曲线和验证集上的 PSNR 曲线。图 4.21(a) 显示，随机置换导致卷积神经网络在训练过程中损失函数震荡，对卷积神经网络造成了训练困难。相比之下，如图 4.21(b) 所示，当随机置换结合 Transformer 时，损失函数持续降低并收敛，训练过程更加平稳。图 4.21(c) 显示，随机置换导致卷积神经网络在验证集数据上的性能不稳定且更差，这与 Transformer 有所不同（图 4.21(d)）。这些结果与自注意力的置换等变性相符，自注意力不依赖相对位置建模依赖关系，因此随机置换标记序列后仍可以有效的建模，然而卷积层建模依赖相对位置，所以随机置换和卷积层结合会有训练和测试性能不稳定的问题。

中国知网　https://www.cnki.net

4.4　本章小结

本章从研究处理非均匀分布退化噪声的处理方法出发，通过设计基于随机置换的自注意力表征增强方法，实现了空间上的跨尺度信息补偿。首先，针对退化噪声在图像空间呈现非均匀分布的图像复原问题，分析并定位了其难点：退化噪声在图像空间的非均匀分布与主流的权重共享机制不兼容。为此，本章进一步设计了随机置换函数和逆随机置换函数，构造了图像空间与同质化空间之间的映射，将图像空间中非均匀分布的噪声退化映射到同质化空间中，并利用局部窗口自注意力在同质化空间内挖掘并建模内容信息。基于此，构建了一种新型的基于局部窗口的 Transformer，命名为 HomoFormer，用于图像去阴影。HomoFormer 不仅在输入图像分辨率上的时间复杂度和空间复杂度具备线性效率优势，还成功克服了建模非均匀分布阴影退化的挑战。大量实验验证了 HomoFormer 在图像去阴影任务中的性能优势。除了同质化非均匀分布的作用外，本章证明了随机置换函数和逆随机置换函数还能高效地建模长程依赖关系，进而实现稀疏的全局自注意力。与第 3 章中提出的窗间自注意力相比，时间复杂度和空间复杂度由 $\Theta\left((HW)^{\frac{3}{2}}\right)$ 进一步降低至 $\Theta(HW)$。为了将 HomoFormer 应用于更多的图像复原任务，基于 HomoFormer，本章引入了局部建模增强的图像复原模型 HomoFormer-Local，在图像空间中实现了非局部关联性的补偿。针对随机置换和逆随机置换，本章设计了专门的基于随机置换样本的训练策略和基于蒙特卡洛均值的推理策略，以确保模型在训练和推理过程中均能保持高效性。实验结果表明，HomoFormer-Local 在经典图像复原任务（包括图像去噪、去雨和去模糊）中展现出卓越的性能。实验分析发现，相比于依赖相对位置关系建模的卷积层，由于自注意力的置换等变性，HomoFormer 和 HomoFormer-Local 几乎不受随机因子的干扰，训练损失能够稳定下降并收敛，验证集上的性能亦稳步提升并最终收敛。

本章工作的部分内容已发表在机器学习和计算机视觉领域权威国际会议 International Conference on Machine Learning（ICML）和 IEEE Conference on Computer Vision and Pattern Recognition（CVPR）。

中国知网　https://www.cnki.net

第 5 章　预训练扩散模型先验引导的图像复原方法

前三章的研究主题是增强图像复原模型的跨尺度表征能力，研究方案是将图像空间域先验知识嵌入模型，补偿建模中的信息损失，以赋予模型稳健的判别能力。然而，前三章的工作基于一个基本假设：推理场景中的图像与训练场景中的图像遵循相同的分布。即，图像复原模型直接学习判别过程 $p(\boldsymbol{x}|\boldsymbol{y})$。判别式图像复原方法的优点在于条件分布 $p(\boldsymbol{x}|\boldsymbol{y})$ 的样本复杂度较低[79]（Sample Complexity），使得优化过程相对较为简单；其缺点则在于图像复原模型的优化过程与退化过程相关，因此推理阶段的图像复原性能受到训练阶段图像退化过程的限制；同时，由于训练数据集中的场景具有一定的局限性，难以满足独立同分布的假设，判别式图像复原方法不利于提升模型的泛化能力。另一种图像复原范式是生成式的建模方法：利用深度神经网络直接拟合清晰图像的分布，依据贝叶斯定理 $p(\boldsymbol{x}|\boldsymbol{y}) \propto p(\boldsymbol{y}|\boldsymbol{x})p(\boldsymbol{x})$，设计生成式图像复原推理建模方法，其中 $p(\boldsymbol{x})$ 为神经网络建模的清晰图像先验分布，$p(\boldsymbol{y}|\boldsymbol{x})$ 由图像的退化过程决定。生成式的图像复原方法的优点是神经网络直接学习清晰图像分布，模型的训练过程和退化过程无关，同时，清晰图像可以被广泛的收集，可以涵盖了多个场景，因此有更强的泛化能力；缺点是模型直接学习清晰图像分布，样本复杂度高，因此模型优化难度更大。近年来，图像生成模型（如扩散模型[90]）取得显著进展，神经网络拟合图像先验分布的技术逐渐成熟。基于生成式图像复原在泛化能力方面的优势，本章聚焦于利用在大规模数据上预训练模型学习的先验知识，研究具有高泛化能力的生成式图像复原推理建模方法，以概率为媒介引入了退化无关的清晰图像知识，增强了图像复原方法的泛化性能。从实际问题的需求出发，本章考虑两种设置：

- 设置一：已知退化过程 $p(\boldsymbol{y}|\boldsymbol{x})$，结合图像先验分布 $p(\boldsymbol{x})$，设计图像复原推理建模方法，推理过程中引入退化过程 $p(\boldsymbol{y}|\boldsymbol{x})$ 的监督，从后验分布 $p(\boldsymbol{x}|\boldsymbol{y})$ 中采样，从而完成图像复原。
- 设置二：未知退化过程 $p(\boldsymbol{y}|\boldsymbol{x})$，基于图像先验分布 $p(\boldsymbol{x})$ 设计通用的采样方法，通过采样得到的复原结果，使其服从后验分布 $p(\boldsymbol{x}|\boldsymbol{y})$。

本章基于清晰图像在扩散模型中具有较高概率的基本假设，提出了一种图像复原推理建模方法，称为 DreamClean，DreamClean 依赖于扩散模型学习清晰图像的先验分布 $p(\boldsymbol{x})$，并提出了一种基于概率准则的推理采样算法，称为保方差采样（Variance Preservation Sampling, VPS），保方差采样可以兼容上述两种设置，成功实现无需监督训练且无需退化过程的通用图像复原框架，在多种退化类型下均能实现高保真图像复原。具体而言，DreamClean 将退化图像嵌入预训练扩

中国知网　https://www.cnki.net

散模型的隐变量空间，并利用保方差采样算法依据概率准则引导扩散模型采样过程。得益于扩散模型丰富的图像先验知识，DreamClean 能够同时处理多种退化类型，其图像复原质量较现有方法有显著提升。DreamClean 具有严谨的理论支撑，证明了保方差采样能稳定地提升图像在扩散模型中的概率，并收敛到高概率集合。实验结果表明，在未知退化过程和已知退化过程两种设置下，DreamClean 均展现出显著的优势。特别是在缺失退化过程知识的极端场景下，DreamClean 仍能获得清晰的图像。

5.1　概述

图像复原的目标是从观测的退化图像 $\boldsymbol{y}$ 中推理出合理的清晰图像 $\boldsymbol{x}$。图像复原是经典的不适定逆问题（ill-posed problem），即可能存在多个合理的清晰图像 $\boldsymbol{x}$ 经过退化过程得到同一退化图像 $\boldsymbol{y}$。合理的复原图像 $\hat{\boldsymbol{y}}$ 应该满足两个要求，（1）真实性要求：复原图像 $\hat{\boldsymbol{y}}$ 服从清晰图像 $\boldsymbol{x}$ 分布，即 $\hat{\boldsymbol{y}} \sim p(\boldsymbol{x})$；（2）一致性要求：复原图像 $\hat{\boldsymbol{y}}$ 应该和退化图像 $\boldsymbol{y}$ 具有一致性，假设 $\mathcal{G}(\cdot)$ 表示退化过程，即若 $\mathcal{G}(\boldsymbol{x}) = \boldsymbol{y}$，应有 $\mathcal{G}(\hat{\boldsymbol{y}}) = \boldsymbol{y}$。近年来，相较于经典的图像复原方法，基于深度学习的图像复原方法已经展现出显著的性能提升。基于深度学习的图像复原范式可以分为判别式图像复原和生成式图像复原。判别式图像复原方法通常依赖预先收集的（退化图像 $\boldsymbol{y}$，清晰图像 $\boldsymbol{x}$）配对的数据集训练模型，学习退化图像到清晰图像的映射，即拟合分布 $p(\boldsymbol{x}|\boldsymbol{y})$。判别式图像复原方法的优势是图像复原模型直接基于退化图像学习复原过程，模型学习过程样本复杂度低[79]（Sample Complexity），因此模型优化过程相对容易；然而，判别性图像复原方法的性能受限于数据独立同分布的假设：训练阶段的数据分布应与推理阶段的数据分布一致，且训练阶段的退化过程与推理阶段的退化过程应该一致。这类判别性图像复原方法的训练阶段存在两个特点：（1）配对的数据集中包含的特定的退化过程，退化过程和训练过程耦合，（2）配对数据集收集困难，难以获得大规模、多场景的配对数据集。推理阶段可能存在退化过程与训练阶段的退化过程不一致和图像分布和训练阶段图像分布不一致，违反了独立同分布的假设，影响模型的泛化性，进而导致推理阶段模型性能受限。在实际应用中，当测试数据偏离预设训练数据的分布时，这些方法的性能往往会显著下降，弥补措施是重新收集配对数据集并重新训练模型，然而这个过程既耗时又昂贵。

生成式图像复原依赖清晰图像数据集，利用神经网络直接拟合清晰图像分布，即建模清晰图像先验分布 $p(\boldsymbol{x})$。根据贝叶斯定理[236]有 $p(\boldsymbol{x}|\boldsymbol{y}) \propto p(\boldsymbol{y}|\boldsymbol{x})\,p(\boldsymbol{x})$，在推理阶段，若已知退化过程 $p(\boldsymbol{y}|\boldsymbol{x})$，可通过求解最大后验（Maximum a Posterior, MAP）问题（即 $\max p(\boldsymbol{x}|\boldsymbol{y})$）获得清晰图像。生成式图像复原的优点是模型训练

中国知网　https://www.cnki.net

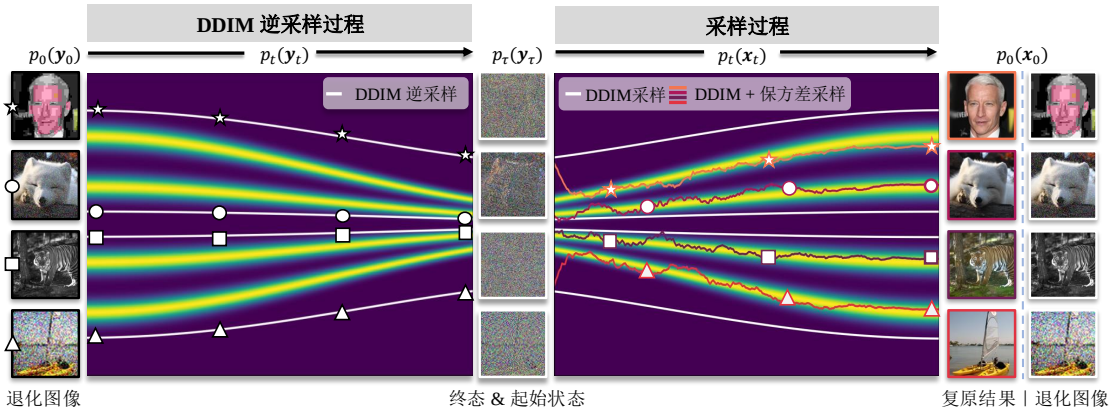


图 5.1　方法概览图

注：DDIM 逆采样及其采样能够重建输入图像，从而得到输入图像的隐变量表示。保方差采样引导低概率隐变量向邻近的高概率区域移动，从而得到清晰图像，同时保持与输入退化图像的一致性。

过程和退化过程解耦，且仅需要清晰图像数据训练，这有利于生成式图像复原方法泛化性的提升；缺点是模型学习过程样本复杂度高[79]，原因是（1）图像数据维度高，维数灾难[110]使建模过程困难；（2）图像内容复杂，包括图像场景、光照、风格等复杂多变。高样本复杂度造成模型直接学习清晰图像先验分布困难。近年来，图像生成模型（如扩散模型[89-94,237]、流模型[238-241]、一致性模型[242-245]、自回归模型[133,246-248]、掩码预测模型[249-250]）取得突破，随之，基于图像生成模型的生成式图像复原方法[105,107,251]也取得显著进展。例如，DDRM[105]利用清晰图像训练的扩散模型[91]，处理线性退化场景，并利用线性退化的 SVD 分解，在谱空间采样获得和退化图像具有一致性的清晰图像。然而，这类方法因破坏了扩散模型的采样动力学无法保证采样的图像满足真实性的要求；同时在实际应用中，退化过程可能过于复杂，难以物理建模，或者由于计算成本高而无法应用[79]，这些难点都会限制这类生成式图像复原方法的应用。此外，由于变分自编码器[252]（Variational Auto Encoder, VAE）的编码器会复杂化退化过程，这类方法无法应用到基于 VAE 编码空间训练的扩散模型[93]。

为充分挖掘扩散模型的图像先验、释放扩散模型的生成潜力，本章提出通用的概率引导的图像复原推理建模方法，称为 DreamClean。DreamClean 的一个基本假设是在清晰图像数据集上训练的扩散模型中，清晰图像对应的隐变量位于高概率区域，而退化图像对应的隐变量位于低概率区域。因此提升扩散模型中隐变量的概率就可以提升图像的质量，并且不依赖具体的退化过程。DreamClean 是一种新型的生成式图像复原框架，无需依赖配对数据集，且不要求对特定退化过程进行显式或隐式假设，因此对多种退化类型具有较强的泛化性。如图 5.10 所示，DreamClean 可处理包括经典的线性退化场景（包含图像超分、图像去模糊和图像着色）、含噪声的线性退化场景（包含附带泊松噪声、高斯噪声的图像超

中国知网　https://www.cnki.net

分）、非线性退化场景（复杂的 JPEG 伪影校正[253]）以及复杂恶劣天气退化（包含雨、雪和雨滴）的多种退化类型。

DreamClean 的核心是保方差采样算法（Variance Preservation Sampling，VPS），提升退化图像在扩散模型中隐变量的概率，以此提升图像的视觉质量。具体的过程是：（1）利用扩散模型学习清晰图像的分布 $p(\boldsymbol{x})$；（2）采用扩散模型的常微分方程（ODE）采样算法的逆向采样过程得到保留输入图像信息的隐变量，尽管隐变量无法直接恢复清晰图像，但其可保留输入图像的信息，为后续采样提供良好初始化；（3）利用保方差采样算法，引导退化图像的低概率隐变量向邻近高概率区域移动，从而生成清晰的图像。上述过程中，DreamClean 利用 ODE 采样的逆采样过程实现无需特定退化过程即可得到一致性的解决方案。值得注意的是，DreamClean 不要求已知具体的退化过程，因此可与像素空间或 VAE 编码的隐空间中预训练的扩散模型兼容。DreamClean 还可完成极端退化场景下的图像复原任务，如复杂的 JPEG 伪影校正、附带噪声的 16 倍的图像超分等；保方差采样与现有的利用退化过程的图像复原方法正交，即保方差采样也可利用退化过程得到保真度更高的复原结果。本章从理论上证明了保方差采样的收敛性，实验结果验证了 DreamClean 在多种复杂场景下的性能均展现了显著的优势。

5.2　背景

5.2.1　扩散模型

去噪扩散概率模型（Denoising Diffusion Probabilistic Models，DDPMs）[90,254]是一类旨在通过模型分布 $p\left(\boldsymbol{x}_0\right)$ 逼近数据分布 $q\left(\boldsymbol{x}_0\right)$ 的隐变量模型。DDPMs 包含两个对称的过程，即 T 步前向扩散过程：向数据中逐步添加高斯噪声平滑数据分布；以及 T 步逆向生成过程：通过从带高斯噪声的数据中逐步去除噪声最终完成数据采样。

前向扩散过程是一个逐渐加噪的马尔可夫过程：

$$q\left(\boldsymbol{x}_{1:T}|\boldsymbol{x}_0\right):=\prod_{t=1}^{T}q\left(\boldsymbol{x}_t|\boldsymbol{x}_{t-1}\right),\quad q\left(\boldsymbol{x}_t|\boldsymbol{x}_{t-1}\right):=\mathcal{N}\left(\boldsymbol{x}_t;\sqrt{1-\beta_t}x_{t-1},\beta_t\boldsymbol{I}\right), \tag{5.1}$$

其中，$\beta_1,\cdots,\beta_T$ 是噪声调度方案（noise schedule），取值是标量，$\mathcal{N}$ 是标准高斯分布。前向扩散过程的一个重要的性质是，基于式 (5.1)，给定 x_0，x_t 的分布具有如下简单的形式：

$$q\left(\boldsymbol{x}_t|\boldsymbol{x}_0\right)=\mathcal{N}\left(\boldsymbol{x}_t;\sqrt{\bar{\alpha}_t}\boldsymbol{x}_0,\left(1-\bar{\alpha}_t\right)\boldsymbol{I}\right), \tag{5.2}$$

中国知网　https://www.cnki.net

式 (5.2) 中，α_t、$\bar{\alpha}_t$ 与 β_t 的关系为：

$$\alpha_t = 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{i=0}^{t} \alpha_t. \tag{5.3}$$

逆向生成过程对应从噪声到图像的演变（即图像的采样），采样的起点是标准高斯噪声 $p\left(\boldsymbol{x}_T\right) = \mathcal{N}\left(\boldsymbol{x}_T; 0, \boldsymbol{I}\right)$，采样过程是具有马尔可夫性的去噪过程：

$$p_\theta\left(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t\right) \approx q\left(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t, \boldsymbol{x}_0\right) = \mathcal{N}\left(\boldsymbol{x}_{t-1}; \boldsymbol{\mu}_\theta\left(\boldsymbol{x}_t, \boldsymbol{x}_0\right), \sigma_t^2 \boldsymbol{I}\right), \tag{5.4}$$

通过重参数化（Reparameteration），$\boldsymbol{\mu}_\theta(x_t, x_0)$ 和 σ_t^2 具有闭式解：

$$\boldsymbol{\mu}_\theta(\boldsymbol{x}_t, \boldsymbol{x}_0) = \frac{1}{\sqrt{\alpha_t}}\left(\boldsymbol{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta\left(\boldsymbol{x}_t, t\right)\right), \quad \sigma_t^2 = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t. \tag{5.5}$$

$\boldsymbol{\epsilon}_\theta\left(\boldsymbol{x}_t, t\right)$ 为预测标准噪声的神经网络。Song 等人[44] 证明了上述的逆向生成过程等价于一个连续时间随机过程的离散化，可以通过以下逆向时间的随机微分方程（Stochastic Differential Equation，SDE）描述：

$$\mathrm{d}\boldsymbol{x}_t = \left[f\left(t\right)\boldsymbol{x}_t - g^2\left(t\right)\nabla_{\boldsymbol{x}_t}\log p_t\left(\boldsymbol{x}_t\right)\right]\mathrm{d}t + g\left(t\right)\mathrm{d}\bar{\boldsymbol{w}}_t, \tag{5.6}$$

式 (5.6) 的求解方向时 $t = T \to 0$，$\bar{\boldsymbol{w}}_t$ 是逆向时间的标准维纳过程（Wiener Process），$f\left(t\right)$ 和 $g\left(t\right)$ 具有数学表达式：

$$f\left(t\right) = \frac{1}{2}\frac{\mathrm{d}\log\bar{\alpha}(t)}{\mathrm{d}t}, \quad g\left(t\right) = \left(1 - \bar{\alpha}\left(t\right)\right)\frac{\mathrm{d}}{\mathrm{d}t}\frac{1-\bar{\alpha}\left(t\right)}{\bar{\alpha}\left(t\right)}. \tag{5.7}$$

$\bar{\alpha}\left(t\right)$ 是离散噪声调度 $\bar{\alpha}_t$ 的连续函数版本。对于逆向时间的随机微分方程，Song 等人[44] 进一步证明了存在一个对应的概率流常微分方程（Probability Flow Ordinary Differential Equation，PF ODE），它与逆向时间的随机微分方程具有相同的边缘分布 $p_t\left(x_t\right)$，PF ODE 的数学形式为：

$$\mathrm{d}\boldsymbol{x}_t = \left[f\left(t\right)\boldsymbol{x}_t - \frac{1}{2}g^2\left(t\right)\nabla_{\boldsymbol{x}_t}\log p_t\left(\boldsymbol{x}_t\right)\right]\mathrm{d}t. \tag{5.8}$$

概率流常微分方程（PF ODE）求解过程对应从高斯噪声中生成图像的演化过程。在不引起误解的情况下，为了表述简洁，下文将 PF ODE 进一步简称为 ODE。

5.3　方法设计

本节详细阐述 DreamClean 方法。由第 5.2.1 节知，扩散模型是一类概率模型，首先引入基于扩散模型对退化图像和清晰图像的概率假设，

假设 5.1 (概率假设)　若扩散模型在清晰图像数据集上训练，退化图像在扩散模型中具有低概率，清晰图像在扩散模型中具有高概率。

中国知网　https://www.cnki.net

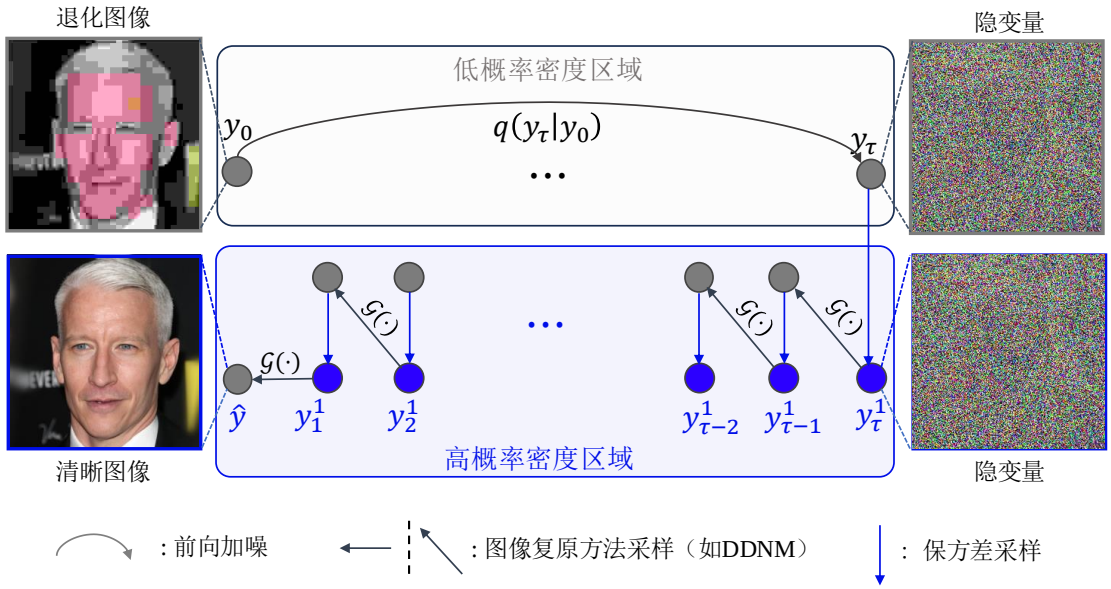


图 5.2　已知退化过程场景下的采样算法示意图

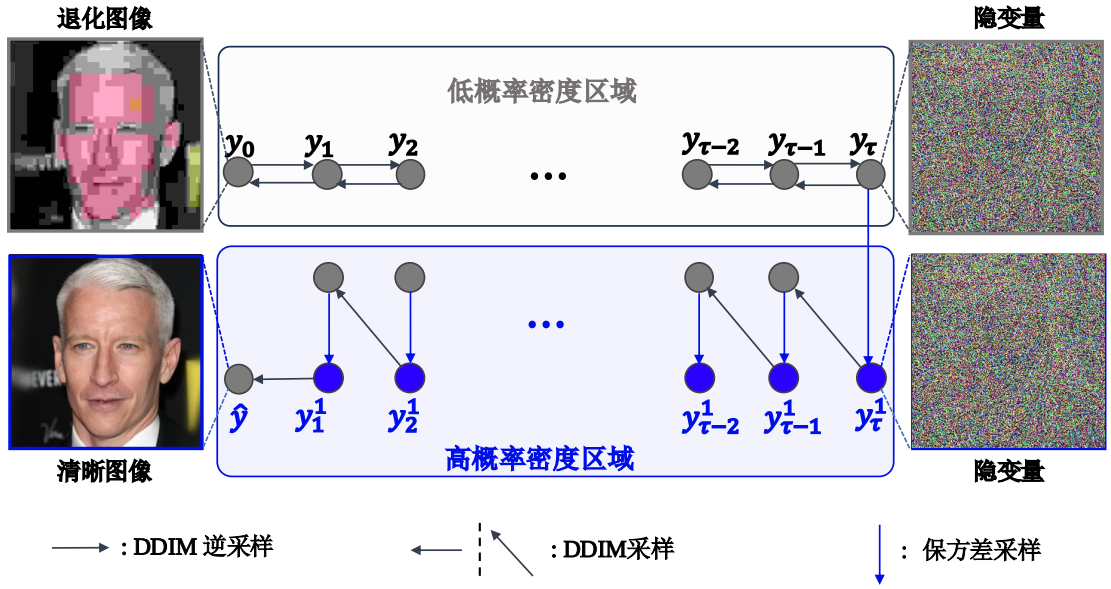


图 5.3　未知退化过程场景下的采样算法示意图

假设 5.1 可从实验观察上验证：若对清晰图像训练的扩散模型采样，采样得到清晰图像的概率远远大于得到退化图像的概率。假设 5.1 表明扩散模型为退化图像和清晰图像提供了概率角度上的分割，反之，若能提升退化图像的概率，则有可能提升图像的视觉质量。DreamClean 核心思路是设计算法提升退化图像 $\boldsymbol{y}$ 在扩散模型中的隐变量 $\{\boldsymbol{y}_t\}_{t=1}^{t=T}$ 的概率，因此提升图像视觉质量，最终实现图像复原。根据图像复原结果真实性的要求和一致性的要求，下面分别阐述 DreamClean 在保证复原图像的一致性和真实性方面的设计。

中国知网　https://www.cnki.net

5.3.1　一致性设计

若已知退化过程 $\boldsymbol{x}=\mathcal{G}(\boldsymbol{y})$，DreamClean 可利用已有的一致性保持方法，下面考虑未知退化过程的场景中的一致性保持方法。基于 ODE 采样算法是可逆的，也即，对于给定的图像 $\boldsymbol{y}$，存在一系列隐变量 $\{\boldsymbol{y}_t\}_{t=1}^{t=T}$，以任何一个隐变量 $\boldsymbol{y}_t$ 为起点，可以利用 ODE 采样算法重构输入图像（如图 5.1 中的白色轨迹）。这个性质表明 ODE 轨迹上的隐变量应该包含关于输入图像的信息。另一方面，当从预训练的扩散模型中进行采样时，会生成高质量的图像，意味着这些隐变量位于低概率区域。基于此，如图 5.3 所示，DreamClean 提出利用 ODE 轨迹上的隐变量作为初始化，并设计一个轨迹修正算法，这些隐变量从低概率区域移动到附近的高概率区域。本章选择 DDIM[255] 作为默认的 ODE 采样方法。假设退化图像为 $\boldsymbol{y}$，DDIM 逆采样可以将 $\boldsymbol{y}$ 映射到隐变量 $\boldsymbol{y}_\tau$，即 $\boldsymbol{y}_\tau=\mathrm{DDIM}^{-1}(\boldsymbol{y};\tau)$，其中 $0<\tau\leqslant T$ 表示 ODE 逆采样的程度参数。单步 DDIM 逆采样的计算过程是：

$$\text{DDIM 逆采样步：}\ \boldsymbol{y}_{t+1}=\sqrt{\bar{\alpha}_{t+1}}\left(\frac{\boldsymbol{y}_t-\sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}_\theta\left(\boldsymbol{y}_t,t\right)}{\bar{\alpha}_t}\right)+\sqrt{1-\bar{\alpha}_{t+1}}\boldsymbol{\epsilon}\left(\boldsymbol{y}_t,t\right). \tag{5.9}$$

$\mathrm{DDIM}^{-1}(\cdot;\tau)$ 根据式 (5.9) 迭代 DDIM 逆采样步实现，迭代范围 $t=0,1\cdots,\tau-1$。

5.3.2　真实性设计

在得到 ODE 轨迹上低概率隐变量 $\boldsymbol{y}_\tau$ 后，DreamClean 设计了保方差采样用以提升隐变量的概率，并通过 ODE 采样算法逐步去噪以得到清晰图像。保方差采样的单步迭代的数学表达式为：

$$\text{保方差采样步：}\ \boldsymbol{y}_t^m=\boldsymbol{y}_t^{m-1}+\eta_l\nabla\log p_t(\boldsymbol{y}_t^{m-1})+\eta_g\boldsymbol{\epsilon}_g^m, m=1\cdots M, \boldsymbol{y}_t^0=\boldsymbol{y}_t, \tag{5.10}$$

式 (5.10) 中，η_l 和 η_g 是标量，决定了更新的步幅，需要满足以下约束：

$$\eta_l=\gamma\left(1-\bar{\alpha}_t\right),\quad \eta_g=\sqrt{\gamma\left(2-\gamma\right)}\sqrt{1-\bar{\alpha}_t}. \tag{5.11}$$

$0<\gamma<1$ 是一个标量，是决定步长的参数，而 $\bar{\alpha}_t$ 是在式 (5.2) 和式 (5.3) 中定义的噪声调度方案。式 (5.11) 中 η_l 和 η_g 的关系对于复原退化图像至关重要。直观地，如图 5.4 所示，给定初始隐变量，该隐变量位于低概率区域，保方差采样引导隐变量由低概率区域朝附近的高概率区域移动。高概率区域的隐变量遵循扩散模型采样的动力学机制。因此，通过逐步修正隐变量的概率，保方差采样能够生成清晰的图像。式 (5.10) 中的 $\nabla\log p(\boldsymbol{y}_t^{m-1})$ 可以通过预训练的扩散模型得到[256-257]。具体地，该梯度项（也称为分数函数，score function[44]）与预训练扩

中国知网　https://www.cnki.net

散模型预测的噪声 $\boldsymbol{\epsilon}_\theta$ 之间存在以下关系：

$$\nabla \log p_t\left(\boldsymbol{y}_t^{m-1}\right)=-\frac{\boldsymbol{\epsilon}_\theta\left(\boldsymbol{y}_t^{m-1}, t\right)}{\sqrt{1-\bar{\alpha}_t}}. \tag{5.12}$$

当 η_l 和 η_g 满足式 (5.11) 中的关系时，保方差采样会收敛到附近的高概率集合，从而得到复原结果 $\hat{\boldsymbol{y}}$。由于扩散模型的隐变量通常是高维的，受启发于信息理论中典型集的概念[258-259]，假设 $\boldsymbol{x}_0$ 是清晰图像，$\boldsymbol{x}_0$ 引导的高概率集合定义为

定义 5.1 (高概率集合)　对于 $\delta>0$、$t>0$ 和清晰图像 $\boldsymbol{x}_0 \in \mathbb{R}^N$，$\boldsymbol{x}_0$ 引导的高概率集合 $\mathcal{T}_t^N\left(\boldsymbol{x}_0;\delta\right)$ 定义如下：

$$\mathcal{T}_t^N\left(\boldsymbol{x}_0;\delta\right)=\left\{\boldsymbol{x}_t:\left|-\frac{1}{N}\log p_t\left(\boldsymbol{x}_t|\boldsymbol{x}_0\right)-H\right|\leqslant\delta\right\}. \tag{5.13}$$

其中，$p_t\left(\boldsymbol{x}_t|\boldsymbol{x}_0\right)=\prod_{i=1}^N p_t\left(x_{t,i}|x_{0,i}\right)$，$x_{t,i}$ 和 $x_{0,i}$ 分别表示 $\boldsymbol{x}_t$ 和 $\boldsymbol{x}_0$ 的第 i 个元素，H 是分布 $\mathcal{N}(0,1-\bar{\alpha}_t)$ 的香农熵（shannon entropy）。

为了阐述高概率集合的意义，引入新变量 $v_{t,i}=x_{t,i}-\sqrt{\bar{\alpha}_t}x_{0,i}$。由于给定 $\boldsymbol{x}_0$ 时，$\boldsymbol{x}_t$ 的各个元素是条件独立的，因此 $\left\{v_{t,i}\right\}$ 是独立同分布的，且 $v_{t,i}\sim\mathcal{N}\left(0;1-\bar{\alpha}_t\right)$。假设 H 是分布 $\mathcal{N}\left(0;1-\bar{\alpha}_t\right)$ 的香农熵，根据大数定理有

$$\begin{aligned}
-\frac{1}{N}\log p_t\left(\boldsymbol{x}_t|\boldsymbol{x}_0\right)&=-\frac{1}{N}\log p_t\left(x_{t,0},x_{t,1},\cdots x_{t,N}|x_{t,0},x_{t,1},\cdots x_{t,N}\right) &\text{(5.14a)}\\
&=-\frac{1}{N}\log p_t\left(v_{t,0},v_{t,1},\cdots v_{t,N}\right) &\text{(5.14b)}\\
&\to H\quad \text{依概率收敛。} &\text{(5.14c)}
\end{aligned}$$

对于高分辨率图像，N 通常是很大的（如 512×512）。因此，高概率集合包含了大部分的概率。根据大数定理，对于足够大的 N，$\boldsymbol{x}_t\in\mathcal{T}_t^N\left(\boldsymbol{x}_0;\delta\right)$ 的概率会趋近于 1。也即，$\mathcal{T}_t^N\left(\boldsymbol{x}_0;\delta\right)$ 是一个由清晰图像 $\boldsymbol{x}_0$ 引导的隐变量组成的集合，其概率可以足够大。可以证明，保方差采样中的 η_l 和 η_g 在满足式 (5.11) 定义的关系时，会将退化图像的隐变量移动到附近清晰图像的高概率集合中。

定理 5.1　对于 $\delta>0$ 和清晰图像 $\boldsymbol{x}_0$，当 η_l 和 η_g 满足式 (5.11) 中的约束时，存在一个 ODE 逆采样程度参数 $0<\tau\leqslant T$，使得通过保方差采样得到的 $\boldsymbol{y}_\tau^M$ 满足当 $M\to\infty$ 时，$\boldsymbol{y}_\tau^M\to\mathcal{T}_\tau^N(\boldsymbol{x}_0;\delta)$。

证明　在保方差采样的每次迭代中，如式 (5.10) 所定义，$\boldsymbol{y}_t^{m-1}$ 通过梯度项 $\eta_l\nabla\log p_t(\boldsymbol{y}_t^{m-1})$ 和噪声项 $\eta_g\boldsymbol{\epsilon}_g^{m-1}$ 进行更新。对于任意 $\boldsymbol{y}_t\in\mathbb{R}^N$，梯度项 $\nabla\log p_t(\boldsymbol{y}_t)$

中国知网　https://www.cnki.net

化为如下形式：

$$\nabla \log p_t\left(\boldsymbol{y}_t\right) = \frac{\nabla p_t\left(\boldsymbol{y}_t\right)}{p_t\left(\boldsymbol{y}_t\right)} \tag{5.15a}$$

$$= \frac{1}{p_t\left(\boldsymbol{y}_t\right)} \int \nabla_{\boldsymbol{y}_t} p_t\left(\boldsymbol{y}_t|\boldsymbol{x}\right) p_0\left(\boldsymbol{x}\right) \mathrm{d}\boldsymbol{x} \tag{5.15b}$$

$$= \frac{1}{p_t\left(\boldsymbol{y}_t\right)} \int \frac{\sqrt{\bar{\alpha}_t}\boldsymbol{x} - \boldsymbol{y}_t}{1-\bar{\alpha}_t} p_t\left(\boldsymbol{y}_t|\boldsymbol{x}\right) p_0\left(\boldsymbol{x}\right) \mathrm{d}\boldsymbol{x} \tag{5.15c}$$

$$= \frac{1}{1-\bar{\alpha}_t}\left(\sqrt{\bar{\alpha}_t}\mathbb{E}\left[\boldsymbol{x}|\boldsymbol{y}_t\right] - \boldsymbol{y}_t\right), \tag{5.15d}$$

其中 $p_t\left(\boldsymbol{y}_t|\boldsymbol{x}\right) = \mathcal{N}\left(\boldsymbol{y}_t; \sqrt{\bar{\alpha}_t}\boldsymbol{x}, \left(1-\bar{\alpha}_t\right)\mathbf{I}\right)$，$p_0\left(\boldsymbol{x}\right)$ 表示清晰图像分布，$\mathbb{E}\left[\boldsymbol{x}|\boldsymbol{y}_t\right]$ 是给定噪声等级图像 $\boldsymbol{y}_t$ 条件下的清晰图像 $\boldsymbol{x}$ 的期望值，它可以表示为：

$$\mathbb{E}\left[\boldsymbol{x}|\boldsymbol{y}_t\right] = \int \boldsymbol{x} \frac{p_t\left(\boldsymbol{y}_t|\boldsymbol{x}\right)}{p_t\left(\boldsymbol{y}_t\right)} p_0\left(\boldsymbol{x}\right) \mathrm{d}\boldsymbol{x} \tag{5.16a}$$

$$= \int \boldsymbol{x} \frac{\mathcal{N}\left(\boldsymbol{y}_t; \sqrt{\bar{\alpha}_t}\boldsymbol{x}, \left(1-\bar{\alpha}_t\right)\mathbf{I}\right)}{\int \mathcal{N}\left(\boldsymbol{y}_t; \sqrt{\bar{\alpha}_t}\boldsymbol{x}', \left(1-\bar{\alpha}_t\right)\mathbf{I}\right) p_0\left(\boldsymbol{x}'\right) \mathrm{d}\boldsymbol{x}'} p_0\left(\boldsymbol{x}\right) \mathrm{d}\boldsymbol{x} \tag{5.16b}$$

$$= \int \boldsymbol{x} \frac{\exp\left(-\frac{1}{2\left(1-\bar{\alpha}_t\right)}\left\|\boldsymbol{y}_t - \sqrt{\bar{\alpha}_t}\boldsymbol{x}\right\|_2^2\right)}{\int \exp\left(-\frac{1}{2\left(1-\bar{\alpha}_t\right)}\left\|\boldsymbol{y}_t - \sqrt{\bar{\alpha}_t}\boldsymbol{x}'\right\|_2^2\right) p_0\left(\boldsymbol{x}'\right) \mathrm{d}\boldsymbol{x}'} p_0\left(\boldsymbol{x}\right) \mathrm{d}\boldsymbol{x}. \tag{5.16c}$$

假设 $\boldsymbol{y}_t$ 是清晰图像 $\boldsymbol{x}_0$ 按照噪声调度方案的加噪结果，数学形式为 $\boldsymbol{y}_t = \sqrt{\bar{\alpha}_t}\boldsymbol{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}$，那么在式 (5.16c) 中，$\left\|\boldsymbol{y}_t - \sqrt{\bar{\alpha}_t}\boldsymbol{x}\right\|_2^2$ 可以近似为：

$$\left\|\boldsymbol{y}_t - \sqrt{\bar{\alpha}_t}\boldsymbol{x}\right\|_2^2 = \bar{\alpha}_t\left\|\boldsymbol{x}_0 - \boldsymbol{x}\right\|_2^2 + \left(1-\bar{\alpha}_t\right)\left\|\boldsymbol{\epsilon}\right\|_2^2 + 2\sqrt{\bar{\alpha}_t\left(1-\bar{\alpha}_t\right)}\boldsymbol{\epsilon}\cdot\left(\boldsymbol{x}_0 - \boldsymbol{x}\right) \tag{5.17a}$$

$$\approx \bar{\alpha}_t\left\|\boldsymbol{x}_0 - \boldsymbol{x}\right\|_2^2 + \left(1-\bar{\alpha}_t\right)\left\|\boldsymbol{\epsilon}\right\|_2^2, \tag{5.17b}$$

噪声项 $\boldsymbol{\epsilon}$ 与 $\boldsymbol{x}_0 - \boldsymbol{x}$ 近似正交。因此，可以得到：

$$\left\|\boldsymbol{y}_t - \sqrt{\bar{\alpha}_t}\boldsymbol{x}'\right\|_2^2 \approx \bar{\alpha}_t\left\|\boldsymbol{x}_0 - \boldsymbol{x}'\right\|_2^2 + (1-\bar{\alpha}_t)\left\|\boldsymbol{\epsilon}\right\|_2^2. \tag{5.18}$$

中国知网　https://www.cnki.net

将式 (5.17b) 和式 (5.18) 代入式 (5.16c)，可以得到 $\mathbb{E}\left[\boldsymbol{x}|\boldsymbol{y}_t\right]$ 的近似：

$$\mathbb{E}\left[\boldsymbol{x}|\boldsymbol{y}_t\right] \approx \int \boldsymbol{x} \frac{\exp\left(-\frac{1}{2(1-\bar{\alpha}_t)}\left(\bar{\alpha}_t\|\boldsymbol{x}_0-\boldsymbol{x}\|_2^2+(1-\bar{\alpha}_t)\|\boldsymbol{\epsilon}\|_2^2\right)\right)}{\int \exp\left(-\frac{1}{2(1-\bar{\alpha}_t)}\left(\bar{\alpha}_t\|\boldsymbol{x}_0-\boldsymbol{x}'\|_2^2+\left(1-\bar{\alpha}_t\right)\|\boldsymbol{\epsilon}\|_2^2\right)\right) p_0\left(\boldsymbol{x}'\right)\mathrm{d}\boldsymbol{x}'} p_0\left(\boldsymbol{x}\right)\mathrm{d}\boldsymbol{x} \tag{5.19a}$$

$$= \int \boldsymbol{x} \frac{\exp\left(-\frac{\bar{\alpha}_t}{2\left(1-\bar{\alpha}_t\right)}\|\boldsymbol{x}_0-\boldsymbol{x}\|_2^2\right)}{\int \exp\left(-\frac{\bar{\alpha}_t}{2\left(1-\bar{\alpha}_t\right)}\|\boldsymbol{x}_0-\boldsymbol{x}'\|_2^2\right) p_0\left(\boldsymbol{x}'\right)\mathrm{d}\boldsymbol{x}'} p_0\left(\boldsymbol{x}\right)\mathrm{d}\boldsymbol{x} \tag{5.19b}$$

$$= \int \boldsymbol{x} \frac{\mathcal{N}\left(\boldsymbol{x}_0;\boldsymbol{x},\frac{1-\bar{\alpha}_t}{\bar{\alpha}_t}\mathbf{I}\right)}{\int \mathcal{N}\left(\boldsymbol{x}_0;\boldsymbol{x}',\frac{1-\bar{\alpha}_t}{\bar{\alpha}_t}\mathbf{I}\right) p_0\left(\boldsymbol{x}'\right)\mathrm{d}\boldsymbol{x}'} p_0\left(\boldsymbol{x}\right)\mathrm{d}\boldsymbol{x} \tag{5.19c}$$

$$= \frac{1-\bar{\alpha}_t}{\bar{\alpha}_t}\nabla_{\boldsymbol{x}_0}\log r_t\left(\boldsymbol{x}_0\right)+\boldsymbol{x}_0, \tag{5.19d}$$

其中

$$r_t\left(\boldsymbol{x}_0\right) \triangleq \int \mathcal{N}\left(\boldsymbol{x}_0;\boldsymbol{x},\frac{1-\bar{\alpha}_t}{\bar{\alpha}_t}\mathbf{I}\right) p_0\left(\boldsymbol{x}\right)\mathrm{d}\boldsymbol{x}. \tag{5.20}$$

从式 (5.19d) 可以看出，$\mathbb{E}\left[\boldsymbol{x}|\boldsymbol{y}_t\right]$ 近似地只依赖于 $\boldsymbol{y}_t$ 中的图像成分 $\boldsymbol{x}_0$。

因此，可以通过将 $\boldsymbol{y}_t = \sqrt{\bar{\alpha}_t}\boldsymbol{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}$ 和式 (5.19d) 代入式 (5.15d) 来得到 $\nabla \log p_t(\boldsymbol{y}_t)$ 的近似值：

$$\nabla \log p_t(\boldsymbol{y}_t) \approx \frac{\nabla_{\boldsymbol{x}_0}\log r_t(\boldsymbol{x}_0)}{\sqrt{\bar{\alpha}_t}} - \frac{\boldsymbol{\epsilon}}{\sqrt{1-\bar{\alpha}_t}}. \tag{5.21}$$

根据式 (5.21) 和关系 $\boldsymbol{y}_t^{m-1} = \sqrt{\bar{\alpha}_t}\boldsymbol{x}_0^{m-1} + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}^{m-1}$，可以从更新规则式 (5.10) 得到 $\boldsymbol{y}_t^m$ 的表达式为：

$$\boldsymbol{y}_t^m \approx \sqrt{\bar{\alpha}_t}\left(\boldsymbol{x}_0^{m-1}+\frac{\eta_l}{\bar{\alpha}_t}\nabla\log r_t(\boldsymbol{x}_0^{m-1})\right) + (\sqrt{1-\bar{\alpha}_t}-\frac{\eta_l}{\sqrt{1-\bar{\alpha}_t}})\boldsymbol{\epsilon}^{m-1} + \eta_g\boldsymbol{\epsilon}_g^m \tag{5.22a}$$

$$= \sqrt{\bar{\alpha}_t}\underbrace{\left(\boldsymbol{x}_0^{m-1}+\frac{\eta_l}{\bar{\alpha}_t}\nabla\log r_t(\boldsymbol{x}_0^{m-1})\right)}_{\boldsymbol{x}_0^m} + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}^m, \tag{5.22b}$$

其中等式成立是因为两个独立的高斯噪声的线性组合仍然是高斯分布，并且它们的方差满足：

$$1-\bar{\alpha}_t = (\sqrt{1-\bar{\alpha}_t}-\frac{\eta_l}{\sqrt{1-\bar{\alpha}_t}})^2 + \eta_g^2, \tag{5.23}$$

这由式 (5.11) 中定义的 η_l 和 η_g 之间的关系所保证。

中国知网　https://www.cnki.net

通过将式 (5.22b) 与 $\boldsymbol{y}_t^{m-1}=\sqrt{\bar{\alpha}_t}\boldsymbol{x}_0^{m-1}+\sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}^{m-1}$ 比较，可以发现噪声成分的方差保持不变。对于图像成分 $\boldsymbol{x}_0^m$，更新规则 $\boldsymbol{x}_0^m=\boldsymbol{x}_0^{m-1}+\frac{\eta_l}{\bar{\alpha}_t}\nabla\log r_t(\boldsymbol{x}_0^{m-1})$ 是梯度上升法，其中优化目标是 $\log r_t\left(\boldsymbol{x}_0\right)$，步长为 $\frac{\eta_l}{\bar{\alpha}_t}$。因此，$\boldsymbol{x}_0^m$ 会收敛到 $\log r_t\left(\boldsymbol{x}_0\right)$ 的局部最大值，记为 $\boldsymbol{x}_0^*$，并且满足以下条件：

$$\nabla\log r_t\left(\boldsymbol{x}_0^*\right)=0, \tag{5.24}$$

注意到 $r_t\left(\boldsymbol{x}_0\right)$ 表示通过向清晰图像分布 p_0 添加具有方差 $\frac{1-\bar{\alpha}_t}{\bar{\alpha}_t}$ 的高斯噪声所引起的分布，如式 (5.20) 所定义。因此，对于较小的的 t（对应于较小的方差），在图像服从混合狄拉克分布假设下，$\log r_t(\boldsymbol{x}_0)$ 的最大值将与清晰图像重合。

最终，可以得出结论，$\boldsymbol{y}_t^M$ 将进入 $\mathcal{T}_t^N\left(\boldsymbol{x}_0^*;\left|\delta_{\pm}\right|\right)$，对于某些小的 $\delta_{\pm}$ 和足够大的 $\boldsymbol{M}$，通过验证：

$$-\frac{1}{N}\log p_t\left(\boldsymbol{y}_t^M|\boldsymbol{x}_0^*\right) \tag{5.25a}$$

$$=-\frac{1}{N}\log\frac{1}{\left(2\pi\left(1-\bar{\alpha}_t\right)\right)^{N/2}}\exp\left(-\frac{1}{2(1-\bar{\alpha}_t)}\|\sqrt{\bar{\alpha}_t}\boldsymbol{x}_0^M+\sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}^M-\sqrt{\bar{\alpha}_t}\boldsymbol{x}_0^*\|_2^2\right) \tag{5.25b}$$

$$=\frac{1}{2}\log 2\pi\left(1-\bar{\alpha}_t\right)+\frac{1}{2N(1-\bar{\alpha}_t)}\|\sqrt{\bar{\alpha}_t}\left(\boldsymbol{x}_0^M-\boldsymbol{x}_0^*\right)+\sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}^M\|_2^2 \tag{5.25c}$$

$$\rightarrow\frac{1}{2}\log 2\pi\left(1-\bar{\alpha}_t\right)+\frac{1}{2}+\delta_{\pm}. \tag{5.25d}$$

最后这个极限成立，随着 $\boldsymbol{M}$ 的增加，$\boldsymbol{x}_0^M\rightarrow\boldsymbol{x}_0^*$。$\delta_{\pm}=\frac{1}{2}(\frac{\|\boldsymbol{\epsilon}^M\|}{N}-1)$ 很小，因为当 N 很大时，$\frac{\|\boldsymbol{\epsilon}^M\|}{N}\approx 1$，由图像的高维性和大数定理保证。 ∎

定理 5.1 表明，保方差采样能够将退化图像的隐变量修正到附近的高概率集合，遵循扩散模型的采样动力学，从而生成清晰图像。

5.3.3　结合两者

基于预训练的扩散模型，DreamClean 提出概率提升为引导的通用图像复原推理采样的方法。本章围绕图像复原的一致性和真实性两个目标，针对已知退化过程和未知退化过程两种场景，设计两种 DreamClean 算法，分别记为 DreamClean-B（未知退化过程）和 DreamClean-S（已知退化过程）。

已知退化过程。假设退化过程为 $\mathcal{G}(\cdot)$，退化图像记作 $\boldsymbol{y}$，对应的清晰图像记作 $\boldsymbol{x}$，即有：

$$\boldsymbol{y}=\mathcal{G}(\boldsymbol{x}). \tag{5.26}$$

由于退化过程 $\mathcal{G}(\cdot)$ 已知，可以依靠此函数实现复原结果的一致性，而无需借助 ODE 逆采样。上述的保方差采样算法是通用的，修正图像隐变量的概率，可以

中国知网　https://www.cnki.net

直接应用到基于扩散模型的图像复原采样过程中。如图 5.2 所示，具体地过程为：（1）选择加噪程度参数 τ，依据扩散模型的噪声调度方案（式 (5.2)）对退化图像 $\boldsymbol{y}$ 直接加噪，得到隐变量 $\boldsymbol{y}_\tau \sim q\left(\boldsymbol{y}_\tau|\boldsymbol{y}\right)$；（2）采用保方差采样算法，修正隐变量概率；（3）采用现有的基于扩散模型图像复原采样步，降低噪声等级；（4）重复（2）、（3）步，直到噪声等级降到 0，获得复原图像 $\hat{\boldsymbol{y}}$。以 DDNM[107] 为例，考虑线形退化过程：$\boldsymbol{y}=\boldsymbol{A}\boldsymbol{x}$，令 $\boldsymbol{A}^{-}$ 是 $\boldsymbol{A}$ 的伪逆（pseudo-inverse），满足 $\boldsymbol{A}\boldsymbol{A}^{-}\boldsymbol{A}=\boldsymbol{A}$，DreamClean-S 由 DDNM 的采样算法和保方差采样算法构成

$$\text{保方差采样步：}\quad \boldsymbol{y}_t^m=\boldsymbol{y}_t^{m-1}+\eta_l\nabla\log p_t(\boldsymbol{y}_t^{m-1})+\eta_g\boldsymbol{\epsilon}_g^m, m=1\cdots M, \boldsymbol{y}_t^0=\boldsymbol{y}_t. \tag{5.27}$$

$$\text{DDNM 采样步：}\quad \begin{cases} \boldsymbol{y}_{0|t}=\frac{1}{\sqrt{\bar{\alpha}_t}}\left(\boldsymbol{y}_t-\boldsymbol{\epsilon}_\theta\left(\boldsymbol{y}_t,t\right)\sqrt{1-\bar{\alpha}_t}\right), \\ \hat{\boldsymbol{y}}_{0|t}=\boldsymbol{A}^{-}\boldsymbol{y}+\left(\boldsymbol{I}-\boldsymbol{A}^{-}\boldsymbol{A}\right)\boldsymbol{y}_{0|t}, \\ \boldsymbol{y}_{t-1}=\frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}\hat{\boldsymbol{y}}_{0|t}+\frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\boldsymbol{y}_t+\sigma_t\boldsymbol{\epsilon}, \boldsymbol{\epsilon}\sim\mathcal{N}(0,\boldsymbol{I}). \end{cases} \tag{5.28}$$

未知退化过程。对于很多图像复原任务，图像退化过程难以物理建模，式 (5.28) 由于缺失 $\mathcal{G}(\cdot)$ 信息而无法应用，因此，需要考虑未知退化过程的图像复原问题。若未知退化过程，无法利用 $\mathcal{G}(\cdot)$ 的性质保证和输入退化图像的一致性。由 DDIM 逆采样的隐变量可以重建输入图像知，该隐变量包含足够的图像信息，因此，可以用来保证一致性。如图 5.3 所示，输入图像先经过 DDIM 逆采样得到图像的隐变量表征 $\boldsymbol{y}_\tau=\text{DDIM}^{-1}\left(\boldsymbol{y};\tau\right)$，并在每个 DDIM 采样步之前进行一次保方差采样修正，即

$$\text{保方差采样步：}\quad \boldsymbol{y}_t^m=\boldsymbol{y}_t^{m-1}+\eta_l\nabla\log p_t(\boldsymbol{y}_t^{m-1})+\eta_g\boldsymbol{\epsilon}_g^m, m=1\cdots M, \boldsymbol{y}_t^0=\boldsymbol{y}_t \tag{5.29}$$

$$\text{DDIM 采样步：}\quad \begin{cases} \boldsymbol{y}_{0|t}=\frac{1}{\sqrt{\bar{\alpha}_t}}\left(\boldsymbol{y}_t-\boldsymbol{\epsilon}_\theta\left(\boldsymbol{y}_t,t\right)\sqrt{1-\bar{\alpha}_t}\right), \\ \boldsymbol{y}_{t-1}=\sqrt{\bar{\alpha}_{t-1}}\hat{\boldsymbol{y}}_{0|t}+\sqrt{1-\bar{\alpha}_{t-1}}\boldsymbol{\epsilon}_\theta\left(\boldsymbol{y}_t,t\right). \end{cases} \tag{5.30}$$

综上，DDIM 逆采样找到一个有足够输入图像信息的隐变量作为初始化，之后交替运行保方差采样和 DDIM 去噪采样，保方差采样将其修正到附近清晰图像的高概率集合，DDIM 去噪采样逐渐降低隐变量噪声等级。DDIM 双向采样和保方差采样共同实现了图像复原一致性和真实性的目标。

中国知网　https://www.cnki.net

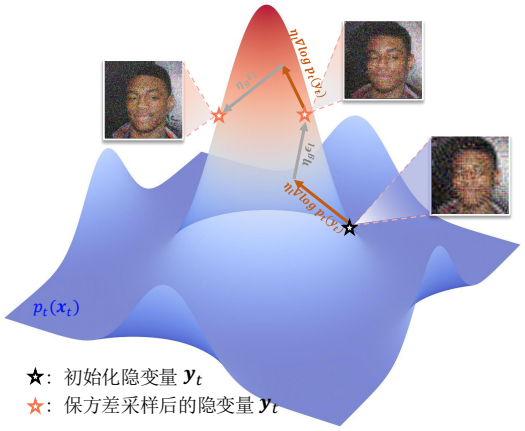


图 5.4　保方差采样算法示意图

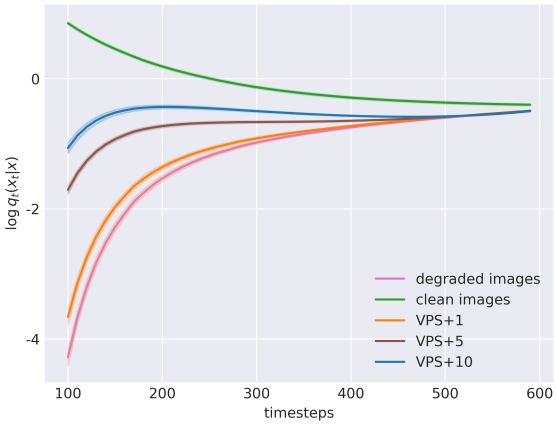


图 5.5　保方差采样提升隐变量概率示意图
注：VPS+n 表示采用 n 步 VPS。

5.4　实验结果与分析

5.4.1　实验设置

本节通过实验验证 DreamClean 的有效性。DreamClean 使用的扩散模型包括基于 ImageNe 数据集[260]预训练的扩散模型[91]、基于 CelebA 数据集[261]预训练的扩散模型[90]、基于 LSUN bedroom 数据集[262]预训练的扩散模型[91] 和基于互联网图像数据预训练的扩散模型 Stable Diffusion[263]。DDIM 采样步数（从 $t = 999$ 到 $t = 0$）默认值为 $N = 100$。评估指标包括：平均峰值信噪比（PSNR）和结构相似性指数（SSIM）作为一致性度量，使用感知相似度指标（Learned Perceptual Image Patch Similarity，LPIPS）作为感知度量，使用函数调用次数（Number of Function Evaluations，NFEs）评估算法效率，PSNR 和 SSIM 越大、LPIPS 和 NFEs 越小代表算法表现越好，实验内容包括：

- 已知退化过程的图像复原实验（第 5.4.2 节）。
- 未知退化过程的图像复原实验（第 5.4.3 节）。
- 验证 DreamClean 可以扩展到真实退化场景（第 5.4.4 节）。
- 验证 DreamClean 将隐变量优化到更高概率区域（第 5.4.5 节）。
- η_l 和 η_g 关系的消融实验（第 5.4.6 节）。

在定量结果的表中，用**加粗**标注最优的结果，用下划线 标注次优的结果。

5.4.2　已知退化过程的图像复原

与已有的工作一致，DreamClean 可以利用退化过程监督采样过程的隐变量，以此实现与输入退化图像一致的复原结果。由于退化过程已知，不需要使用 DDIM 逆采样过程来维持一致性，而是采用式 (5.2) 直接加噪得到隐变量。

为了验证 DreamClean 与已有的基于扩散模型的图像复原方法正交，基于 ImageNet 1K[260] 数据集和 CelebA 1K[261] 数据集，在经典有附加噪声（高斯

中国知网　https://www.cnki.net

表 5.1　已知退化过程场景下在 ImageNet 数据集上图像复原的定量结果

任务	图像去模糊（均匀模糊核）	图像去模糊（高斯模糊核）	图像上色	图像修补
方法	PSNR↑ / SSIM↓ / LPIPS↓	PSNR↑ / SSIM↓ / LPIPS↓	LPIPS↓	PSNR↑ / SSIM↓ / LPIPS↓
输入	18.35 / 0.26 / 0.87	17.79 / 0.31 / 0.71	0.54	12.32 / 0.46 / 0.40
DPS[108]	– / – / –	24.64 / 0.67 / 0.30	–	22.14 / 0.73 / 0.26
DDRM[105]	25.09 / 0.71 / **0.30**	27.82 / 0.80 / **0.24**	0.25	23.09 / **0.83** / 0.13
DDNM[107]	24.28 / 0.65 / 0.40	26.43 / 0.75 / 0.29	0.33	23.12 / 0.82 / 0.13
DreamClean-S	**26.78** / **0.75** / 0.33	**28.92** / **0.82** / **0.24**	**0.11**	**23.18** / **0.83** / **0.11**

注：↑表示值越大性能越好；↓表示值越小性能越好。

表 5.2　已知退化过程场景下在 CelebA 数据集上图像复原的定量结果

任务	图像去模糊（均匀模糊核）	图像去模糊（高斯模糊核）	图像上色	图像修补
方法	PSNR↑ / SSIM↓ / LPIPS↓	PSNR↑ / SSIM↓ / LPIPS↓	LPIPS↓	PSNR↑ / SSIM↓ / LPIPS↓
输入	19.21 / 0.31 / 0.86	18.06 / 0.34 / 0.73	0.61	12.18 / 0.40 / 0.42
DPS[108]	– / – / –	28.83 / 0.81 / 0.11	–	22.72 / 0.82 / 0.13
DDRM[105]	28.06 / 0.80 / **0.13**	30.52 / 0.85 / **0.08**	0.13	23.24 / 0.85 / 0.09
DDNM[107]	28.98 / 0.82 / 0.14	30.37 / 0.85 / 0.11	0.13	23.23 / 0.85 / 0.09
DreamClean-S	**31.17** / **0.88** / **0.13**	**32.71** / **0.91** / 0.09	**0.10**	**24.71** / **0.87** / **0.07**

注：↑表示值越大性能越好；↓表示值越小性能越好。

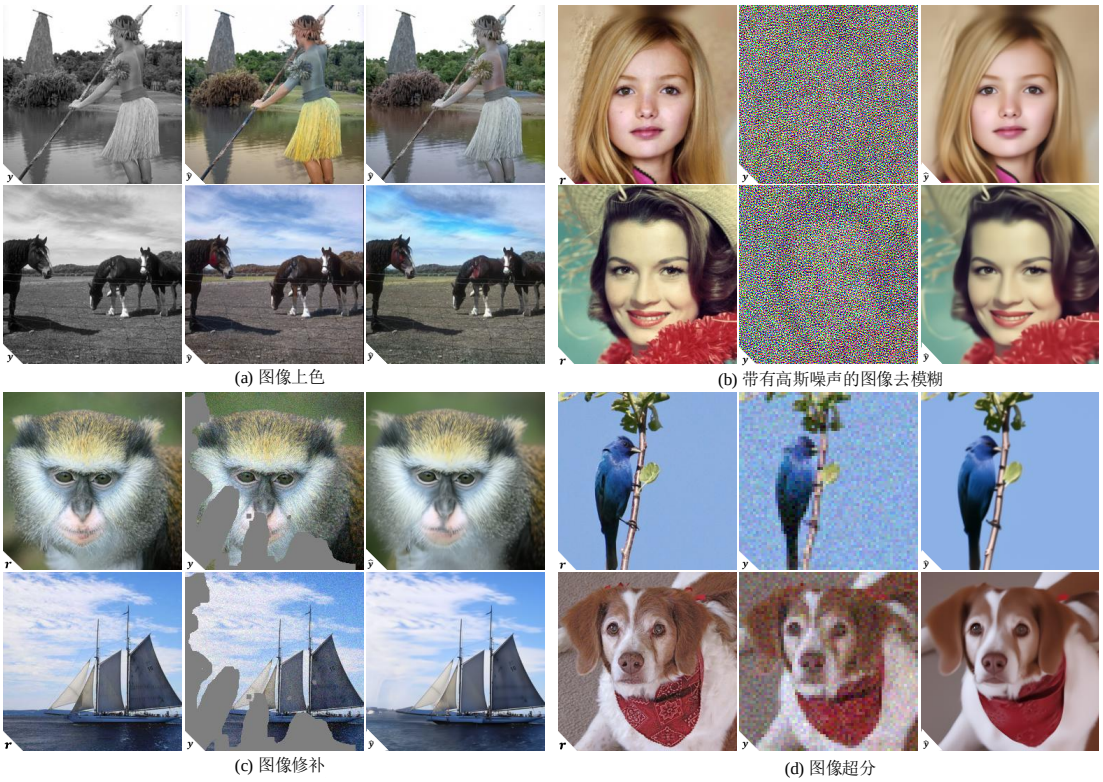
噪声标准差 $\sigma = 0.05$）的线性图像复原任务上实验，包括图像去模糊（均匀模糊核和高斯模糊核）、图像上色和图像修补（image inpainting）。这里采用 DDNM[107] 中的利用退化过程的方法，在零空间中进行图像采样。表 5.1 展示了基于 ImageNet 数据集的定量结果对比，表 5.2 展示了基于 CelebA 数据集的定量结果对比，图 5.6 展示了在多种图像复原任务上的视觉处理效果。进一步地，为了验证保方差采样可以与多种图像复原采样方法兼容，还采用 DPS[108] 中的利用退化过程做引导（guidance）的方法，在傅里叶相位恢复（fourier phase retrieval）任务上实验，图 5.7 展示了傅里叶相位恢复任务上的图像复原效果，可见 DreamClean 仍然能够结合已有的图像复原采样方法利用退化过程的知识，采样得到清晰的图像。

基于以上结果，可以发现 DreamClean 的保方差采样与已有的利用退化过程的图像复原监督采样算法结合，以此实现与输入退化图像一致的复原结果。

5.4.3　未知退化过程的图像复原

对于更一般的图像复原任务，图像的退化过程是未知的或难以显式地物理建模，因此，难以在采样过程中利用退化过程实现和退化图像的一致性。DreamClean-B 提出可以采用 ODE 逆采样的隐变量初始化来实现在更通用的图像复原任务中的一致性。本节在实验上验证 DreamClean 在未知退化过程场景下

中国知网　https://www.cnki.net



(a) 图像上色　(b) 带有高斯噪声的图像去模糊

(c) 图像修补　(d) 图像超分

图 5.6　已知退化过程场景下在多个图像复原任务上的复原效果图

注：$\boldsymbol{r}$ 表示参考图像，$\boldsymbol{y}$ 表示退化图像，$\hat{\boldsymbol{y}}$ 表示 DreamClean 复原后的结果。

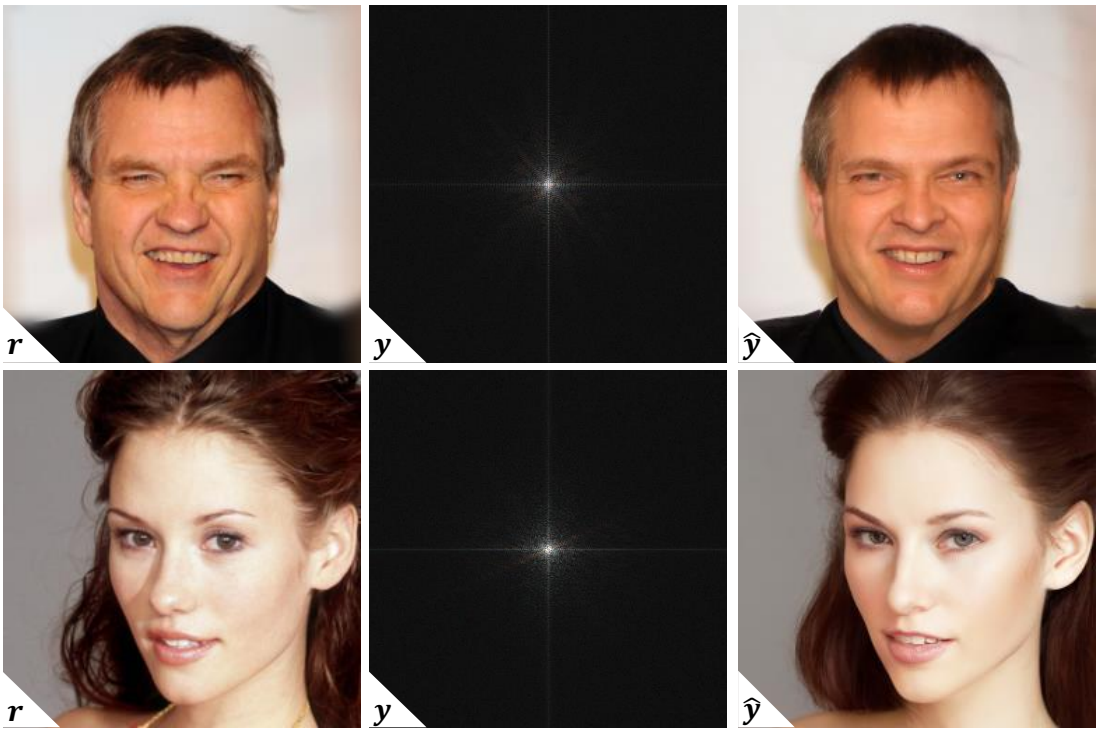


图 5.7　已知退化过程场景下在傅里叶相位恢复上的复原效果图

注：$\boldsymbol{r}$ 表示参考图像，$\boldsymbol{y}$ 表示退化图像，$\hat{\boldsymbol{y}}$ 表示 DreamClean 复原后的结果。

中国知网　https://www.cnki.net

的图像复原能力。为了与现有方法进行定量比较，在经典的图像复原任务上进行实验，包括线性退化过程（图像超分、图像去模糊）、附带噪声的线性退化过程（附带噪声的图像超分）和复杂的非线性退化过程复杂，包括：图像去噪、JPEG 压缩伪影矫正和恶劣天气造成的退化去除。

在附带噪声的图像超分任务中，使用 4× 平均池化下采样器和 $\sigma = 0.05$ 的加性高斯噪声。实验基于 ImageNet 1K[260] 和 CelebA 1K[261] 数据集。基线方法包括：RED[80]、DGP[88]、SNIPS[84]、DDRM[105]、DDNM[107] 和 DPS[108]。为了公平比较，使用 100 次函数评估重新运行了 DDRM。逆向强度 τ 设置为 300，γ 设置为 0.05，M 设置为 1。因此，当退化模型未知时，DreamClean 需要 90 次函数评估（30 次用于 DDIM 逆向采样、30 次用于 DDIM 采样和 30 次用于保方差采样）。DreamClean-B 表示采样过程中未利用退化过程 $\mathcal{G}(\cdot)$。图 5.8 是 DreamClean-S 与其他方法在附带高斯噪声的图像超分任务上的视觉效果对比。

在 JPEG 压缩伪影矫正任务中，使用多次非对齐 JPEG 压缩来模拟真实世界的 JPEG 压缩场景，具体地，使用级联 JPEG 压缩，质量因子 $\mathrm{QF} = (10, 20, 40)$，其中 8×8 的块分别偏移 $(0, 3, 6)$ 像素。实验基于 CelebA 1K[261] 数据集和 LSUN bedroom 验证集[262]。基线方法包括 QGAC[264]、FBCNN[253] 和 DDRM-JPEG[106]。DDRM 在原论文中使用了 20 次函数评估。为了公平比较，使用 100 次函数评估重新复现了 DDRM-JPEG。FBCNN 是监督学习的方法，使用预训练模型直接推理。对于 DDRM-JPEG 和 DDNM，选择最严重压缩情况的 $\mathrm{QF} = 10$ 作为推理时的退化模型。DreamClean-B 表示采样过程中未利用退化过程。图 5.9 是 DreamClean-S 与其他方法在 JPEG 压缩伪影矫正任务上的视觉效果对比。

表 5.3、表 5.4、表 5.5 和表 5.6 展示了与基线方法的定量对比结果，可以得出如下结论：

- 对于附带噪声的图像超分任务，即使未知退化过程，DreamClean-B 仍能有效提升图像质量（与输入相比），甚至能够超过利用一些退化过程的方法（例如 SNIPS）。同时若利用退化过程，DreamClean-S 能够取得更优的性能。
- 对于复杂 JPEG 压缩伪影矫正任务，DreamClean-B 的表现优于监督学习方法（如 QGAC 和 FBCNN）以及无监督方法（如 DDRM-JPEG 和 DDNM）。

图 5.10 展示了各种图像复原任务上的视觉结果。图 5.16 展示了更多在各种图像复原任务上的主观实验结果，图像复原任务涵盖了经典的线性退化场景（图像着色、图像超分和图像去模糊）、附带噪声的线性退化场景（高斯噪声去除、泊松噪声去除、附带高斯噪声和泊松噪声的图像超分）、非线性退化场景（多次 JPEG 压缩伪影的矫正[253]），以及复杂的恶劣天气退化场景（包括雨、雪和雨滴）。可以发现，DreamClean 能够在各类任务上都具有显著的图像复原结果，同时保持与输入退化图像的高度相似性。

中国知网　https://www.cnki.net

表 5.3　在 CelebA 数据集上附加高斯噪声的图像超分的定量结果

方法	PSNR ↑	SSIM ↑	LPIPS ↓	NFEs ↓
输入	23.64	0.51	0.64	0
DGP[88]	18.40	0.40	0.70	1500
SNIPS[84]	26.38	0.74	0.20	1000
DPS[108]	24.42	0.70	0.17	1000
DDRM[105]	<u>29.21</u>	<u>0.83</u>	<u>0.09</u>	100
DDNM[107]	29.17	0.82	<u>0.09</u>	100
GDP[109]	24.38	0.71	0.15	1000
DreamClean-B	27.23	0.77	0.12	90
DreamClean-S	**30.19**	**0.84**	**0.08**	60

注：高斯噪声标准差 $\sigma = 0.05$，4 倍图像超分（4×SR）。
↑ 表示值越大性能越好；↓ 表示值越小性能越好。

表 5.4　在 ImageNet 数据集上附加高斯噪声的图像超分的定量结果

方法	PSNR ↑	SSIM ↑	LPIPS ↓	NFEs ↓
输入	21.85	0.47	0.58	0
DGP[88]	9.50	0.12	0.93	1500
RED[80]	22.90	0.49	NA	100
DPS[108]	24.42	0.70	0.36	1000
DDRM[105]	<u>25.67</u>	<u>0.73</u>	<u>0.30</u>	100
DDNM[107]	25.56	0.72	<u>0.30</u>	100
GDP[109]	24.33	0.67	0.39	1000
DreamClean-B	24.31	0.67	0.40	90
DreamClean-S	**25.84**	**0.74**	**0.23**	60

注：高斯噪声标准差 $\sigma = 0.05$，4 倍图像超分（4×SR）。
↑ 表示值越大性能越好；↓ 表示值越小性能越好。

5.4.4　实际应用的拓展

本节验证 DreamClean 可以拓展到更复杂的实际应用中。首先，基于 SIDD 数据集[197]上进行真实场景的图像去噪实验。为了进行定量比较，基线方法包括原始输入图像和经典去噪方法 BM3D[265]。表 5.7 显示，DreamClean 能够有效地处理真实世界噪声（与输入相比提高了 +8.26 dB）。此外，图 5.11 展示了 DreamClean 在更多图像复原应用中的效果，包括恢复受恶劣天气影响的图像、旧

中国知网　https://www.cnki.net

表 5.5　在 CelebA 数据集上 JPEG 压缩伪影矫正的定量结果

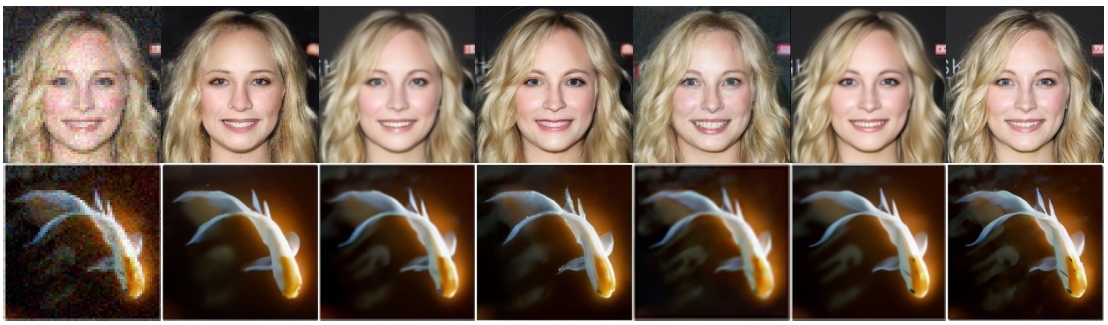
方法	PSNR ↑	SSIM ↑	LPIPS ↓	NFEs ↓
输入	24.79	0.69	0.41	0
QGAC[264]	24.28	0.68	0.32	1
FBCNN[253]	26.37	0.77	0.24	1
DDNM[107]	24.40	0.66	0.31	100
DDRM-JPEG[106]	26.41	0.77	**0.20**	100
DreamClean-B	**27.58**	**0.82**	**0.20**	90

注：↑表示值越大性能越好；↓表示值越小性能越好。

表 5.6　在 LSUN bedroom 数据集上的 JPEG 压缩伪影矫正的定量结果

方法	PSNR ↑	SSIM ↑	LPIPS ↓	NFEs ↓
输入	23.39	0.68	0.34	0
QGAC[264]	23.41	0.69	0.34	1
FBCNN[253]	24.10	0.73	**0.31**	1
DDNM[107]	22.73	0.66	0.33	100
DDRM-JPEG[106]	24.06	0.73	0.32	100
DreamClean-B	**24.35**	**0.74**	**0.31**	90

注：↑表示值越大性能越好；↓表示值越小性能越好。



(a) 输入　(b) DPS　(c) DDRM　(d) GDP　(e) DreamClean-B　(f) DreamClean-S　(g) 清晰图像

图 5.8　附带噪声的图像超分的视觉效果图

照片恢复以及真实世界的图像去噪。

5.4.5　概率提升的验证

对于隐变量 $\boldsymbol{y}_t$，通过 $\log p_\theta\left(\boldsymbol{y}_t\right)$ 来评估其在预训练扩散模型下的概率。给定 $\boldsymbol{x}_0$，可以通过 $\log q_t\left(\boldsymbol{y}_t|\boldsymbol{y}_0\right)$ 来代替 $\log p_\theta\left(\boldsymbol{y}_t\right)$ 作为概率评估。将附加高斯噪声的图像超分作为默认的图像复原任务，并记录 CelebA 1K 数据集上的平均结果和

中国知网　https://www.cnki.net



(a) 输入　(b) FBCNN　(c) DDRM-JPEG　(d) Dreamclean　(e) 清晰图像

图 5.9　JPEG 压缩伪影矫正的视觉效果图

表 5.7　在 SIDD 数据集上的图像去噪定量结果

方法	PSNR↑	SSIM ↑	LPIPS ↓
输入	23.66	0.35	0.58
BM3D[265]	25.65	0.68	–
DreamClean-B	31.92	0.76	0.23

注：↑ 表示值越大性能越好；↓ 表示值越小性能越好。

标准差。图 5.5 显示，与清晰图像相比，退化图像的隐变量位于低概率区域，而保方差采样会逐渐提升它们的概率。图 5.12 还提供了在中不同时间步隐变量的可视化。可以发现，在保方差采样算法的驱动下，具有 JPEG 压缩伪影的隐变量被转化为具有类高斯噪声的清晰图像外观，这符合扩散模型的采样动力学。

5.4.6　消融实验

本节对式 (5.11) 中的 η_l 和 η_g 的约束进行了消融研究。假设 η_l 仍然保持形式 $\eta_l = \gamma(1-\bar{\alpha}_t)$，研究了 η_g 的两种替代方式：$\eta_g = 0$ 和 $\eta_g = \sqrt{2\gamma(1-\bar{\alpha}_t)}$。前者对应于普通的梯度上升，后者则对应于经典的朗之万动力学[89]（Langevin dynamics）。在 CelebA 数据集上进行噪声 4× 超分辨率任务。表 5.8 和 图 5.13 展示了定量和视觉上的比较。可以看到，保方差采样的调度方式取得了最佳的定量结果和视觉效果。值得注意的是，普通的梯度上升无法生成图像，这是因为它破坏了扩散模型采样动力学，无法将隐变量优化到接近清晰图像的高概率集合区域。

中国知网　https://www.cnki.net

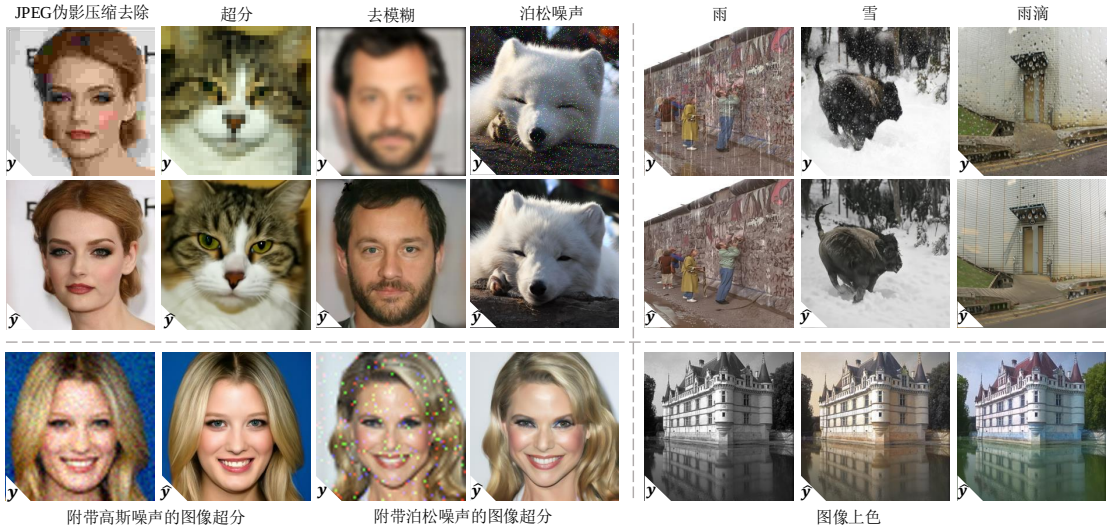


图 5.10　在多种图像复原任务上的视觉效果图

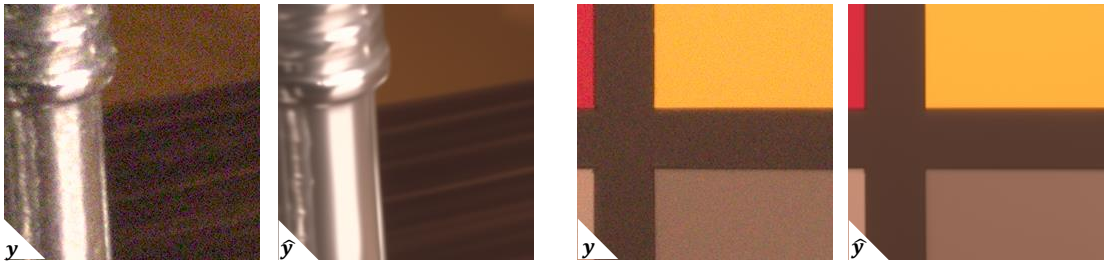
注：$\boldsymbol{y}$ 表示退化图像，$\hat{\boldsymbol{y}}$ 表示 DreamClean 复原后的结果。



(a) 恶劣天气



(b) 旧照片修复



(c) 图像去噪

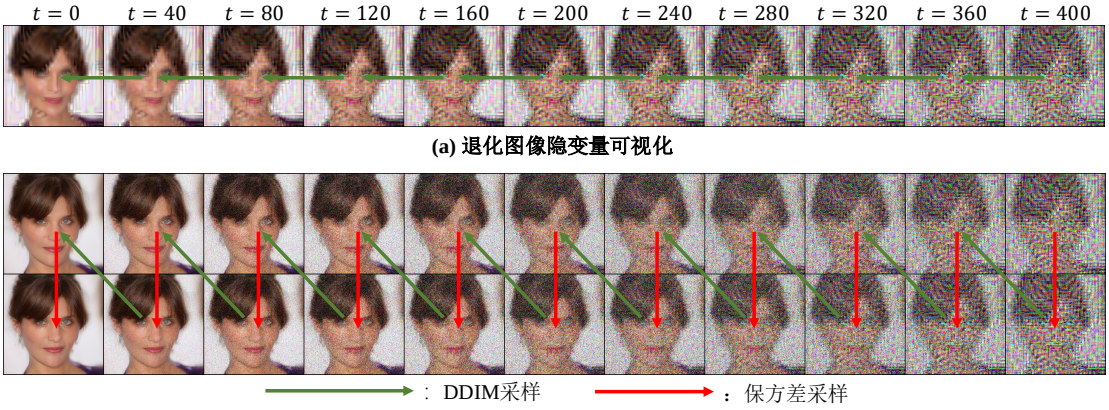
图 5.11　在实际的图像复原应用的效果图

注：$\boldsymbol{y}$ 表示退化图像，$\hat{\boldsymbol{y}}$ 表示 DreamClean 复原后的结果。

5.4.7　讨论

现有的基于扩散模型的图像复原采样方法挖掘像素空间的扩散模型的图像先验，难以利用在 VAE 编码空间的扩散模型的图像先验。其原因是 VAE 编码

中国知网　https://www.cnki.net



(a) 退化图像隐变量可视化

(b) DreamClean 采样过程中隐变量可视化

图 5.12　隐变量的可视化

表 5.8　η_l 和 η_g 策略的消融结果

策略	PSNR ↑	SSIM ↑	LPIPS ↓
0	26.31	0.75	0.24
$\sqrt{2\gamma\left(1-\bar{\alpha}_t\right)}$	26.84	0.72	0.16
$\sqrt{\gamma(2-\gamma)\left(1-\bar{\alpha}_t\right)}$	27.23	0.77	0.12



图 5.13　不同 η_g 策略对性能的影响

器会使在像素空间形式简单的图像退化过程更复杂化。例如，由于 VAE 编码器是非线性映射，像素空间中线性退化过程在 VAE 编码空间不再具有线性关系。DreamClean 可以不依赖退化过程实现图像复原，因此可以与 VAE 编码空间的扩散模型结合。为了探究 Dreamclean 利用 VAE 编码空间的扩散模型的潜力，本节将 DreamClean 与经典的 Stable Diffusion[263]结合。结果如图 5.14 和图 5.15 所示，尽管输入图像遭受严重损毁，DreamClean 仍然能够生成内容相似的清晰图像，然而，由于 VAE 编码器的复杂映射，DreamClean 的在复原结果一致性方面性能受限，实验结果表现为图中的细节无法精确地保持一致。

DreamClean 核心是扩散模型为退化图像和清晰图像提供概率意义上的判别，因此设计保方差采样驱动退化图像的隐变量由低概率区域移向高概率区域，这一

中国知网　https://www.cnki.net

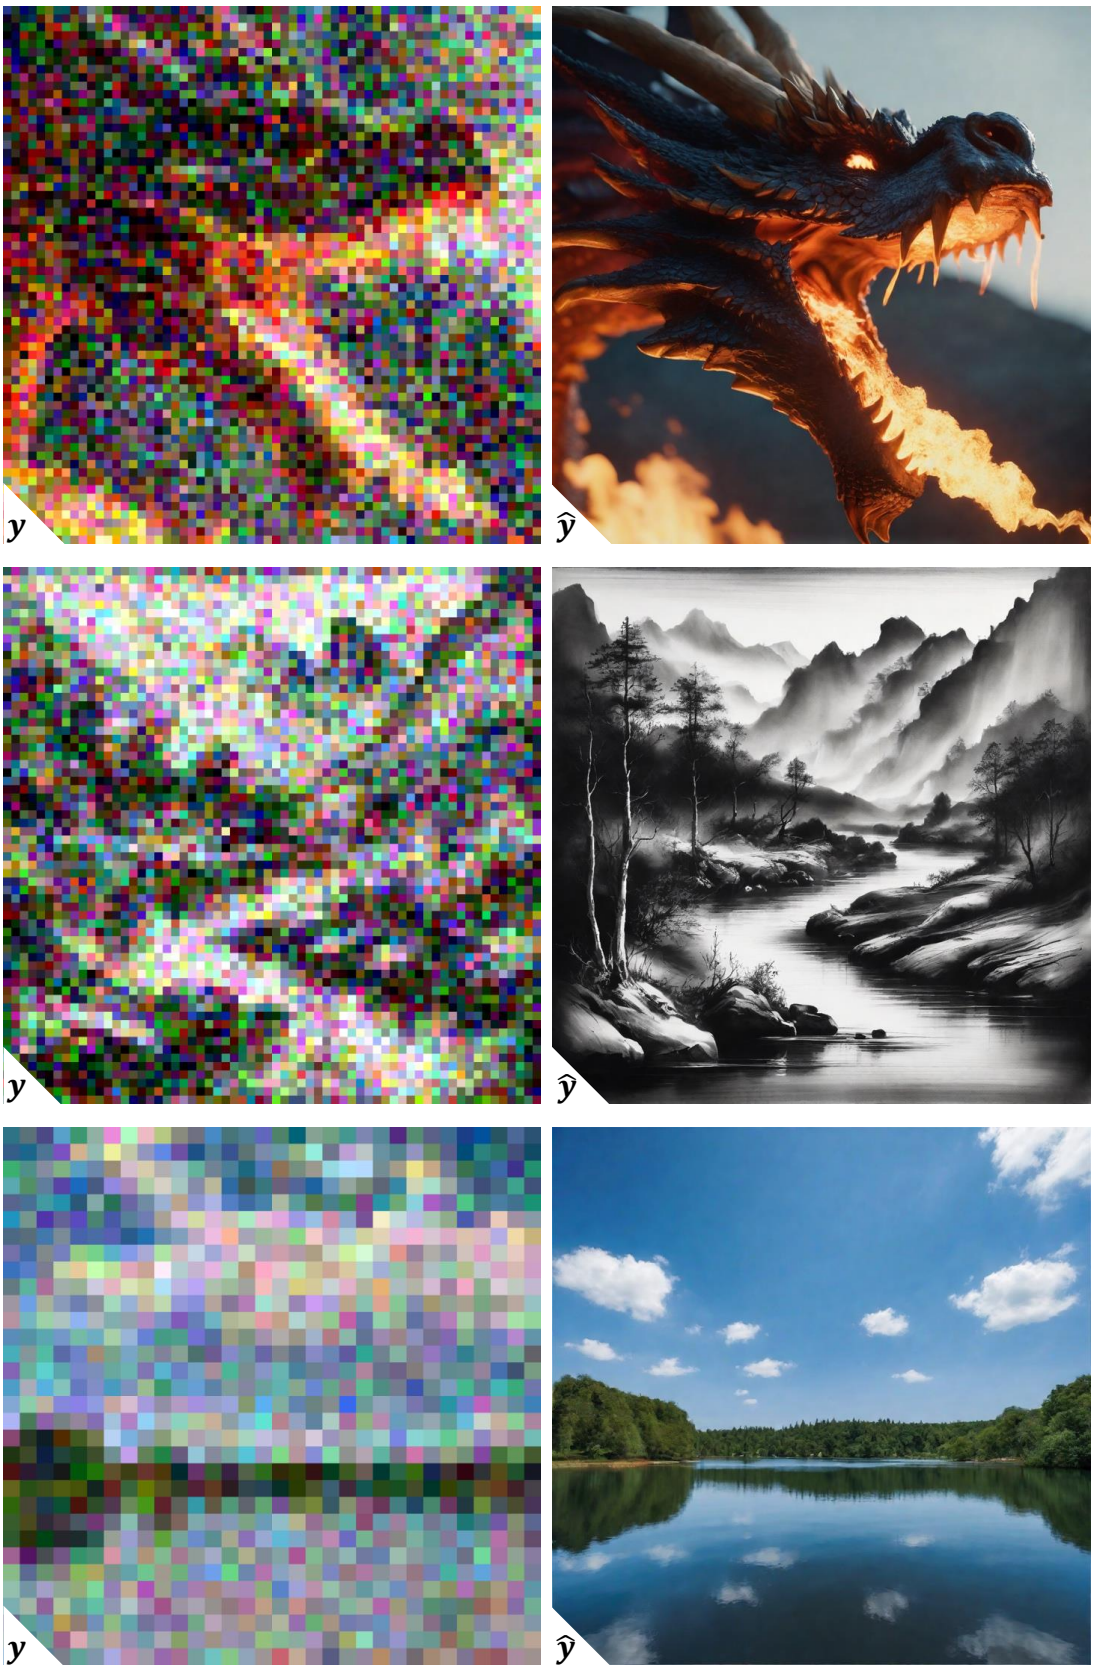


图 5.14　基于 Stable Diffusion 的图像超分和去噪效果图

注：图像分辨率为 1024×1024。$\boldsymbol{y}$ 表示退化图像，$\hat{\boldsymbol{y}}$ 表示 DreamClean 复原后的结果。

中国知网　https://www.cnki.net

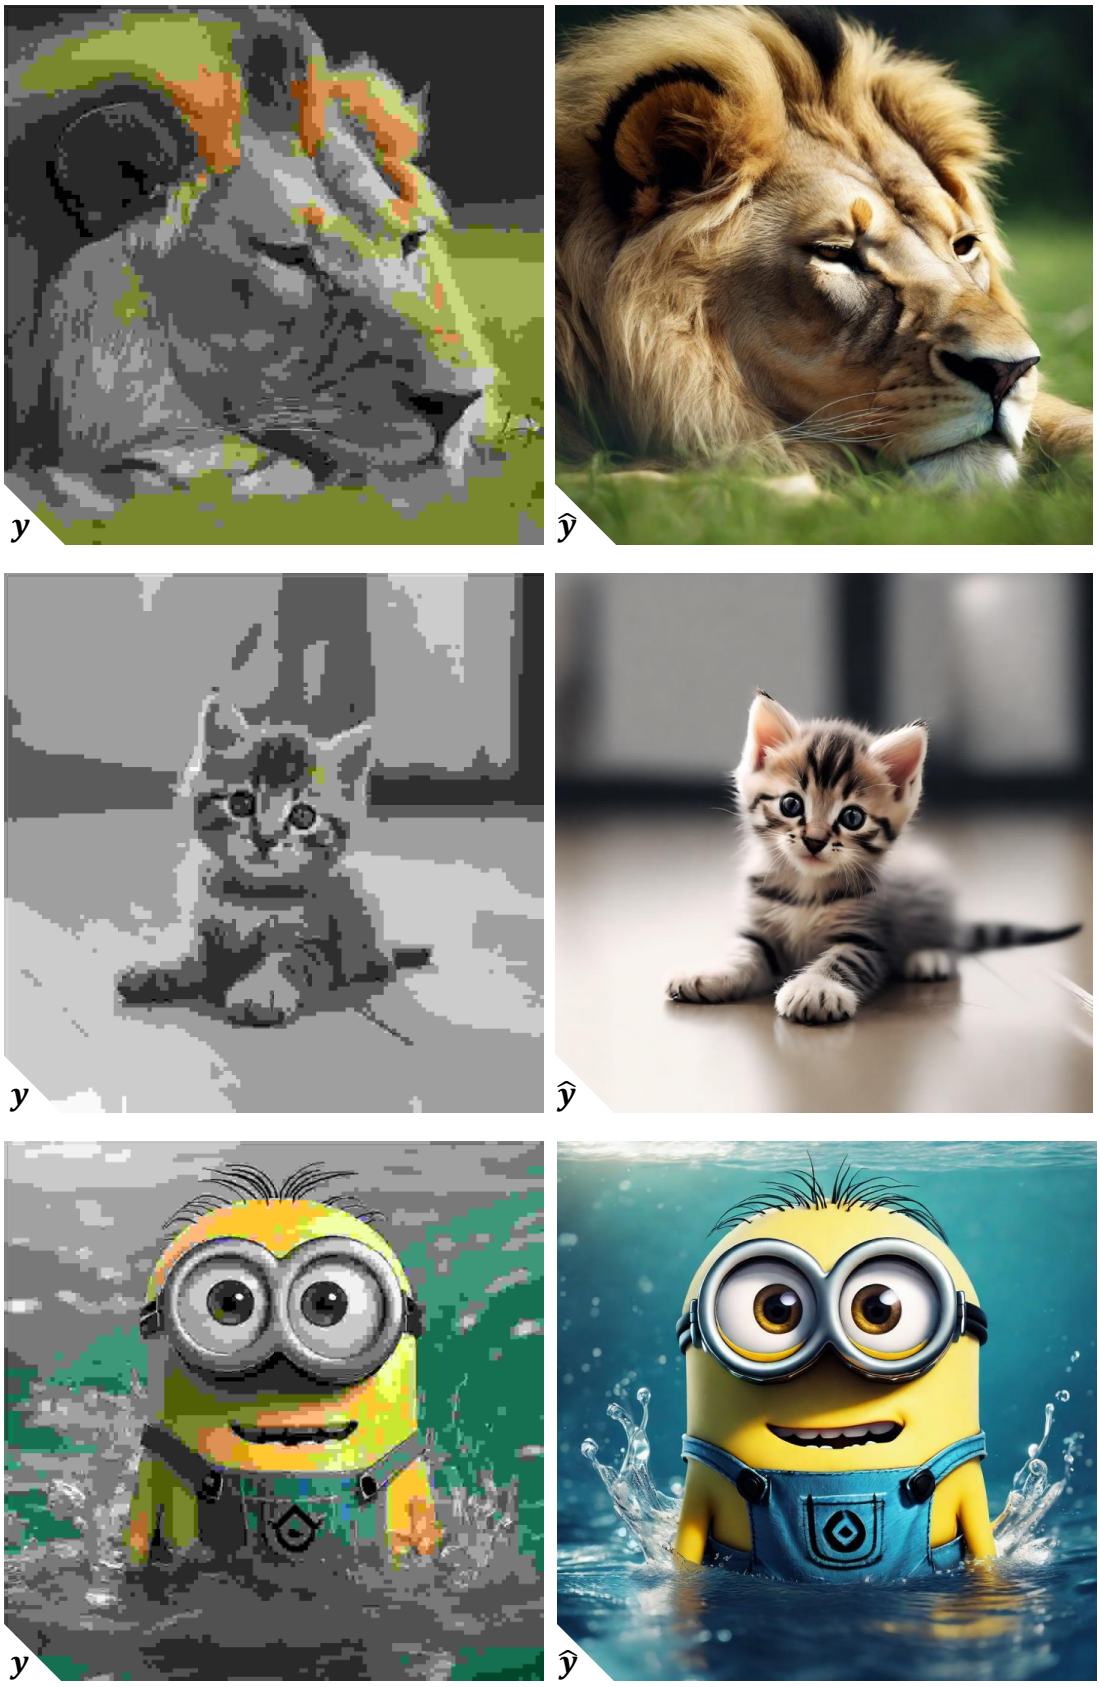


图 5.15　基于 Stable Diffusion 的 JPEG 压缩伪影矫正效果图

注：图像分辨率为 1024×1024。$\boldsymbol{y}$ 表示退化图像，$\hat{\boldsymbol{y}}$ 表示 DreamClean 复原后的结果。

中国知网　https://www.cnki.net

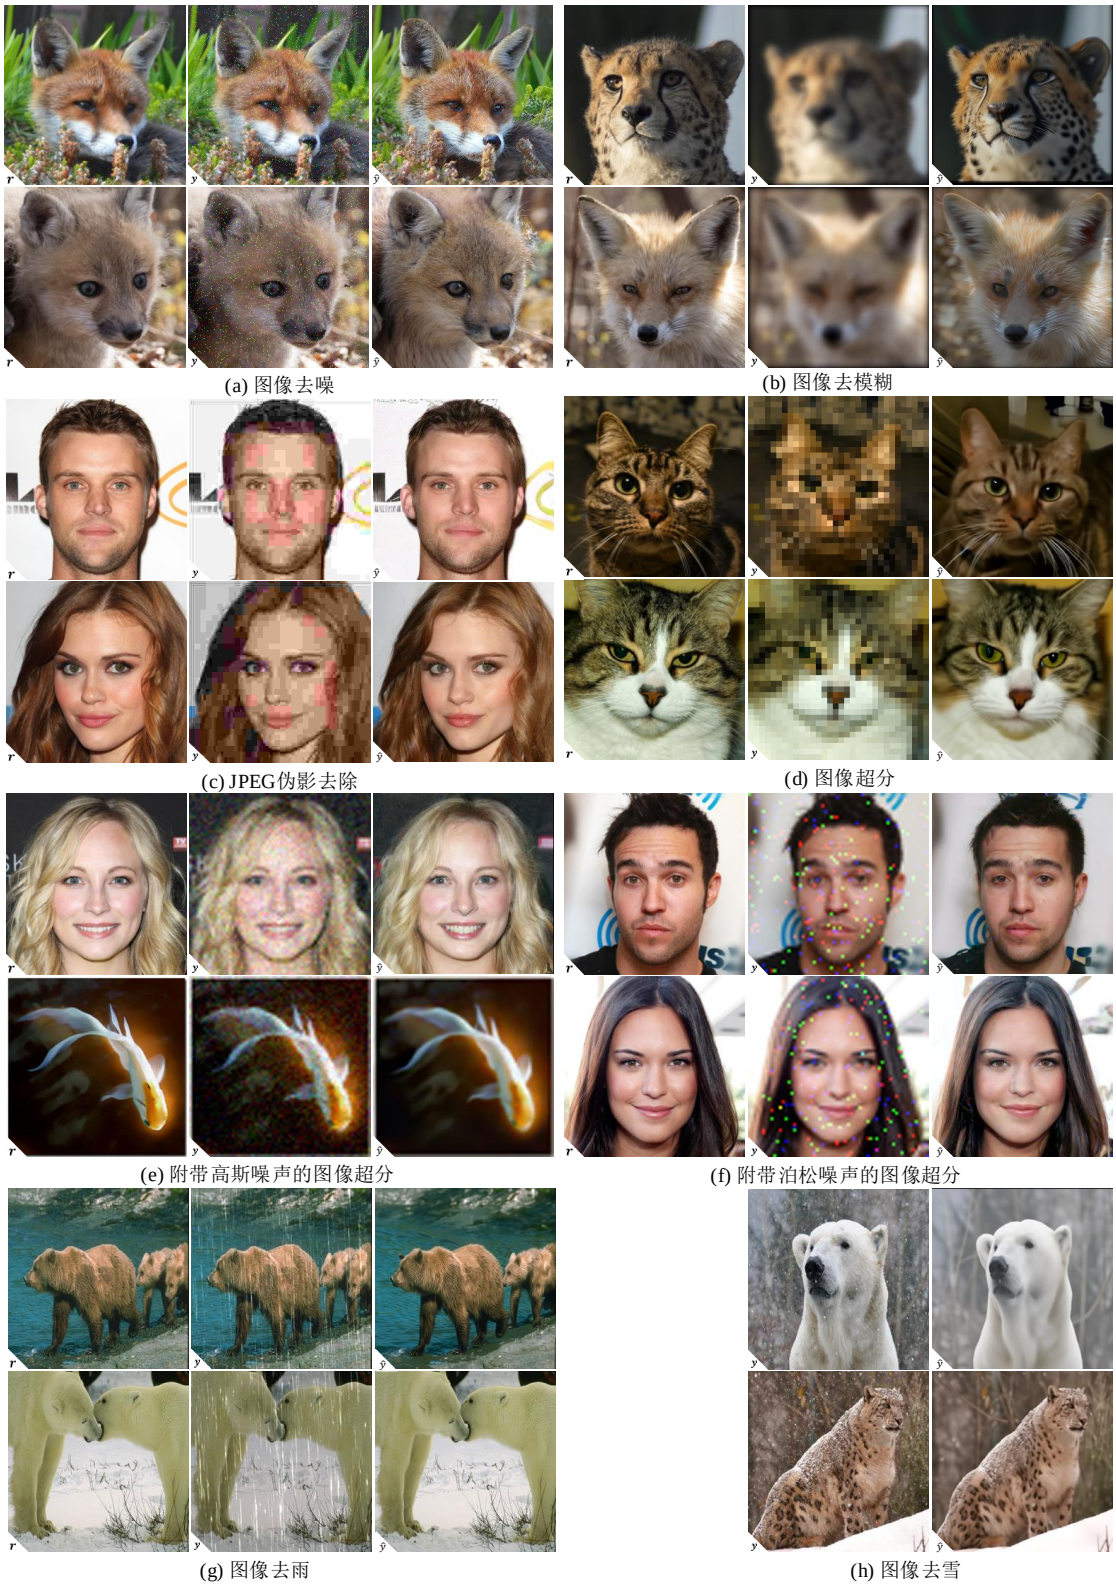


图 5.16　在未知退化过程场景下的多种图像复原任务的复原效果图

注：$\boldsymbol{r}$ 表示参考图像，$\boldsymbol{y}$ 表示退化图像，$\hat{\boldsymbol{y}}$ 表示 DreamClean 复原后的结果。可见 DreamClean 能处理线性退化、附加高斯噪声的线性退化、非线性退化和复杂恶劣天气退化。

方法具有较强的泛化性，且极大缓解了对退化过程的依赖。然而，DreamClean 仍然受限于现有生成模型面临的挑战，如幻觉问题[266-268]。在图 5.17 中展示了一

中国知网　https://www.cnki.net

个复原失败案例。DreamClean 使用在 ImageNet 上预训练的扩散模型[91]，图中的场景严重偏离 ImageNet 训练集包含的场景，因此，在图像去雾时，DreamClean 出现严重的幻觉，倾向于生成原图中不存在的内容。



图 5.17　复原失败的案例

5.5　本章小结

生成模型是人工智能领域最前沿的研究领域之一，并且近年来取得显著进展。本章提出基于预训练扩散模型的图像复原推理采样方法，充分挖掘并利用了预训练扩散模型跨分布的先验知识。基于实验观察，本章提出了一个基本假设：在清晰图像数据集上训练的扩散模型能够在概率意义上对退化图像和清晰图像进行有效地判别。该假设实现了图像视觉质量与其在扩散模型中概率意义的深度绑定，实现了退化无关的图像先验知识驱动的图像复原，即通过提升退化图像在扩散模型中隐变量的概率的方式提升图像的质量，从而达到图像复原的目的。具体而言，基于预训练的扩散模型，本章引入了无需监督训练且无需依赖退化过程的通用图像复原框架（称为 DreamClean），以概率为媒介实现了对退化无关的图像先验知识的补偿。DreamClean 从图像复原的一致性和真实性出发，提出了实现复原一致性的 ODE 逆采样方法和提升概率的保方差采样算法，从而在未知退化过程的场景下实现高质量的图像复原。保方差采样算法还可兼容已知退化过程场景的图像复原采样方法，进一步提升复原一致性。DreamClean 具有完善的理论保证，并在各种退化类型中取得了明显的效果。

本章工作的部分内容已发表在机器学习领域权威国际会议 International Conference on Learning Representations（ICLR）。

中国知网　https://www.cnki.net

第 6 章　总结与展望

6.1　论文总结

随着数字化时代的到来，图像作为重要的信息载体，在各个领域中发挥着关键作用。然而，图像在获取、传输和存储过程中常常受到噪声、模糊、压缩损失等因素的干扰，导致图像质量下降，影响信息的完整性和可用性。图像复原旨在从退化图像中恢复丢失的细节和结构信息，从而提升图像的视觉质量和信息保真度。传统的图像复原方法主要依赖信号处理和手工设计的特征提取，自动化程度较低，执行过程既耗时又费力。近年来，随着深度学习和生成模型的快速发展，图像复原技术取得了显著进展。基于深度学习的图像复原方法能够自动学习图像特征，为解决复杂的退化问题提供了新的思路。然而，这些方法也面临着多方面的挑战，可以归纳为图像内容结构复杂与退化干扰过程繁杂。针对两个挑战，本文围绕知识驱动的图像复原方法，从图像内蕴先验知识驱动策略和预训练模型外源知识驱动策略两个维度展开研究，旨在提升图像复原模型的判别能力和泛化能力。为了提升图像复原模型对图像的跨尺度表征能力，本文聚焦于具有自适应表征能力的 Transformer 模型，建立图像复原计算模型的层次化表征机制，构建多层级感知计算模型，在图像空间实现跨尺度和多维度（包括图像内容与结构）的知识挖掘，增强模型对图像内容结构的感知能力与噪声模式判别能力。基于局部信息与平移不变性知识、内容-结构与多尺度关联性知识、以及同质化分布与非局部关联性知识的充分挖掘与利用，本文展开了如下研究工作：

（1）基于随机窗口自注意力的图像复原方法。图像空间中的局部窗口之间具有“对称性”，即它们应当被等价处理。该工作发现，传统的固定窗口划分策略破坏了这种“对称性”，导致图像复原 Transformer 模型在局部依赖关系建模和保持平移不变性方面存在缺陷。为了解决这些问题，该工作提出了一种基于随机偏移的窗口划分策略，替代传统的固定偏移窗口方案，并将其与自注意力机制结合，设计出一种新型的随机窗自注意力机制，等价地处理任意偏移的窗口，实现了局部关联性知识和平移不变性知识联合驱动的图像复原。基于这一机制，构建了随机窗口 Transformer（称为 Stoformer）。此外，针对随机偏移分布的随机因素，该工作提出了定制的训练和推理策略。具体而言，在训练阶段，从随机偏移分布中采样得到随机偏移样本，提出了一种基于偏移样本的高效训练方法；在推理阶段，为了高效地计算模型对随机偏移的数学期望，设计了逐层期望传播算法。实验结果和理论分析表明，Stoformer 增强了对局部依赖关系的建模能力，实现了对局部信息的无损建模，能够维持退化区域的平移不变性，恢复了图像空间中窗口的对称性，并在图像去雨、去噪和去模糊任务中验证了 Stoformer 的有效性。

中国知网　https://www.cnki.net

（2）基于多尺度协作自注意力的图像复原方法。在第 1 章中分析指出，图像复原模型应具备局部信息建模能力、全局上下文建模能力、内容自适应表征能力以及高效处理高维数据的能力。经典的 Transformer 模型具有全局上下文建模能力，但其建模的时间复杂度和空间复杂度与图像分辨率呈二次方关系；而局部自注意力的 Transformer 模型虽然能将时间复杂度和空间复杂度降低为线性关系，但牺牲了全局上下文的建模能力。此外，该工作研究发现，传统的自注意力机制难以独立提取和建模数据的结构信息。为了解决这些问题，本文提出了一种内容-结构双分支协作的新型计算机制，并基于该机制进一步设计了窗内-窗间互补的自注意力，兼顾了局部信息提取和全局上下文信息建模的能力，引入了内容-结构知识和多尺度关联性知识。最终，该工作构建了具有层次化表征能力的 Transformer 模型（称为 LGT）。理论分析表明，窗内-窗间的多尺度协作自注意力能够将时间复杂度和空间复杂度从 $\Theta\left((HW)^2\right)$ 降低到 $\Theta\left((HW)^{\frac{3}{2}}\right)$，实验结果揭示了窗间自注意力的全局建模特性及内容-结构双分支建模的协作互补作用，为设计更先进的图像复原模型提供了新的思路。大量的图像复原实验结果验证了 LGT 处理复杂退化问题的有效性。

（3）基于随机置换自注意力的图像复原方法。该工作关注一类经典的图像复原问题——退化噪声在图像空间中的非均匀分布。一个典型的例子是图像去阴影任务，其中退化噪声的非均匀分布使得主流图像复原模型中的权重共享机制无法兼容，从而限制了图像复原模型在这种退化场景下的复原效果。为了解决这一问题，本文提出了一对新型的互逆随机函数：随机置换函数和逆随机置换函数。随机置换函数实现了图像空间到同质化空间的映射，而逆随机置换函数则是其逆映射，实现同质化空间到图像空间的映射。在同质化空间中，退化噪声均匀分布。通过引入随机置换函数，成功规避了权重共享机制与非均匀噪声分布之间的冲突，进而提出了能够有效处理非均匀退化噪声的 Transformer 模型（称为 HomoFormer）。在图像去阴影任务中，HomoFormer 在处理非均匀退化噪声方面表现出了明显的优势。此外，本文在理论上证明了随机置换函数和逆随机置换函数能够高效建模图像标记（Token）之间的长程依赖关系，并通过这两个函数构建了高效的稀疏自注意力机制，使得模型能够以线性时间复杂度和空间复杂度（即 $\Theta(HW)$）建模图像标记间的长程依赖关系。该工作还遵循了“局部建模 → 全局建模”的建模范式，结合局部窗自注意力和稀疏自注意力，构建了混沌窗口自注意力，实现了同质化知识和非局部关联性知识驱动的图像复原，并在此基础上提出了增强局部建模的 HomoFormer，称为 HomoFormer-Local。大量实验结果表明，HomoFormer-Local 能有效地处理包括图像去噪、图像去雨和图像去模糊的多种图像复原任务。

在预训练模型外源知识驱动方面，本文提出以概率为媒介的图像先验知识

中国知网　https://www.cnki.net

驱动方法，实现了退化过程无关的清晰图像知识驱动的图像复原，增强图像复原方法对未知退化过程的泛化能力。具体而言，本文展开了以下研究工作：

（4）预训练扩散模型先验引导的图像复原方法。该工作研究了基于生成模型（即扩散模型）的图像复原方法，利用神经网络模型直接学习清晰图像的分布，设计了新型的生成式图像复原推理建模框架（DreamClean）。近年来，基于扩散模型的图像生成技术取得了显著进展。扩散模型的训练过程与退化过程相互解耦，且清晰图像的数据集可以大规模收集，并可涵盖多种场景，因此预训练的扩散模型蕴含了丰富的图像先验知识。该工作基于实验观察，提出清晰图像在扩散模型中具有高概率、退化图像在扩散模型中具有低概率的假设。基于这种具有通用性的概率假设，进一步设计了一种概率引导的图像先验知识驱动方法，实现了对退化无关的清晰图像知识的挖掘，因而可以提升模型的泛化能力。DreamClean 无需在配对数据集上训练模型，方法核心是一种基于概率假设的推理采样算法，称为保方差采样。保方差采样可适用于已知退化过程和未知退化过程两种不同的场景：在已知退化过程场景下，利用现有基于扩散模型的图像复原采样算法实现输出结果的一致性，利用保方差采样实现采样结果的真实性；在未知退化过程场景下，采用 ODE 逆采样过程得到含有图像表征信息隐变量，以此实现采样结果的一致性，并通过保方差采样算法保证采样结果的真实性。作为一种无需在配对的（退化图像，清晰图像）数据集上监督训练且不依赖于退化过程的通用图像复原框架，DreamClean 在不同类型的退化过程下实现高保真度的图像复原。理论分析证明，保方差采样能稳定提升图像在扩散模型中的概率，并收敛到高概率集合。实验结果表明，DreamClean 通过图像先验知识的挖掘，在多种退化过程下均展现出优异的复原效果，相比现有方法取得更优的泛化性能。

6.2　未来展望

本文的研究方法与深度学习技术的发展密切相关。结合人工智能的突破，基于本文已有成果，下一步可在跨模态与多任务协同的图像复原、用户引导的图像复原、轻量级的图像复原等方向展开研究。

（1）多任务与多模态协同的图像复原。本文在图像去噪、去模糊、去雨等任务上分别设计并验证了多种知识驱动机制，但当前仍采用任务特定模型训练，缺乏统一建模视角。多任务学习框架致力于发掘多个代理任务之间的相关性（例如图像去噪、图像超分、图像深度预测、图像分割等），实现了共享特征表征的学习。这不仅提高了模型的训练效率，还通过任务间的协同作用，促进了模型对不同退化类型的适应能力。多任务学习能够在统一的框架下同时优化多个目标，避免了传统方法中任务之间的独立训练，从而提升了复原结果的鲁棒性和准确性。

中国知网　https://www.cnki.net

同时，本文仅依赖图像信息完成图像复原，近年来，多模态的人工智能系统取得了巨大进展，如文生图模型[94]，文生图视频模型[136] 和视觉语言模型[269]等，证明了不同模态数据之间具有互补和相互支撑的潜力。现有的图像复原方法多依赖于单一模态信息（即图像模态），而多模态方法则可以通过整合来自不同模态的数据，如图像、文本、视频和事件信号等其他感知信号[48,270-273]，能够在复原过程中提供更丰富的上下文信息，从而提高复原精度。这种方法特别适用于图像退化较严重的场景，利用多源信息的互补性来弥补单一模态的不足。

（2）用户引导的图像复原。 本文的图像复原方法通常依赖于深度神经网络来处理退化图像，这些方法的复原结果往往无法与用户的偏好对齐。相比之下，用户引导的图像复原能够通过引入用户的直观指导（如标注区域、指定目标或调整参数等），在图像复原过程中发挥更大的作用，从而实现更符合用户需求的复原结果。此外，该类方法引入了人类的先验，有助于进一步提升图像复原方法的性能。用户引导的图像复原还具备广泛的应用潜力，特别是在需要高精度和特定需求的领域，如医学影像分析、艺术品修复、遥感图像处理等。在这些领域，用户可能拥有独特的背景知识或任务需求，能够为图像复原过程提供重要的指导。因此，结合用户引导的图像复原方法，能够显著提升复原质量和任务完成效率，推动图像复原技术在多个实际场景中的应用和发展。此类方法不仅能够提高复原效果的个性化和定制化，还能增强用户的控制感和参与感，提升复原系统的可用性和用户体验。现有扩散模型已广泛用于文本生成图像、风格控制图像合成，说明其本质具备可控生成潜力。同时，基于强化学习的后训练（post-train）[274]可能作为对齐人类偏好的有效方法。

（3）轻量级的图像复原。 轻量级的图像复原方法旨在通过设计高效且计算负担较低的模型，以实现在资源受限的环境下执行图像复原任务。现有的图像复原方法通常依赖于复杂的深度神经网络，这些模型虽然能够提供高质量的复原效果，但在处理高分辨率图像时存在显著的计算和存储开销，难以满足边缘设备和移动设备等场景中的实际需求。因此，轻量级图像复原方法通过减少模型的参数量、降低计算复杂度、软硬件协同以及优化内存使用等方式，能够在保证复原性能的同时，极大提高计算效率，降低硬件资源的消耗，同时，轻量级模型能够减少能源消耗，提高处理速度，满足实时性要求，极大提升用户体验和系统效率。通过研究图像复原模型部署到资源受限的环境中，能够使图像复原技术更加普及，推动其在智能手机、无人机、物联网设备等终端上的实际应用。近年已有轻量化 ViT[275]、MobileDiffusion[276]等模型方案证明大模型也可通过剪枝 + 蒸馏达到高性能低复杂度的目标。同时，图像复原任务具备局部性强的特性，适合稀疏建模和可分离计算。

中国知网　https://www.cnki.net

参考文献

[1] DABOV K, FOI A, KATKOVNIK V, et al. Image denoising by sparse 3-d transform-domain collaborative filtering[J]. IEEE Transactions on Image Processing, 2007, 16(8): 2080-2095.

[2] KRISHNAN D, FERGUS R. Fast image deconvolution using hyper-laplacian priors[C]// Advances in Neural Information Processing Systems: Vol. 22. 2009.

[3] DONOHO D L, JOHNSTONE I M. Ideal spatial adaptation by wavelet shrinkage[J]. Biometrika, 1994, 81(3): 425-455.

[4] ELAD M, AHARON M. Image denoising via sparse and redundant representations over learned dictionaries[J]. IEEE Transactions on Image Processing, 2006, 15(12): 3736-3745.

[5] BURT P J, ADELSON E H. The laplacian pyramid as a compact image code[J]. IEEE Transactions on Communications, 1983, 31(4): 532-540.

[6] KEYS R G. Cubic convolution interpolation for digital image processing[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1981, 29(6): 1153-1160.

[7] FERGUS R, SINGH B, HERTZMANN A, et al. Removing camera shake from a single photograph[J]. ACM Transactions on Graphics, 2006, 25(3): 787–794.

[8] BUADES A, COLL B, MOREL J M. A non-local algorithm for image denoising[C]//IEEE Conference on Computer Vision and Pattern Recognition: Vol. 2. 2005: 60-65 vol. 2.

[9] JÄHNE B. Digital image processing[M]. Springer Science & Business Media, 2005.

[10] DONOHO D. De-noising by soft-thresholding[J]. IEEE Transactions on Information Theory, 1995, 41(3): 613-627.

[11] KUNDUR D, HATZINAKOS D. Blind image deconvolution[J]. IEEE Signal Processing Magazine, 1996, 13(3): 43-64.

[12] RUDIN L I, OSHER S, FATEMI E. Nonlinear total variation based noise removal algorithms [J]. Physica D: nonlinear phenomena, 1992, 60(1-4): 259-268.

[13] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. nature, 2015, 521(7553): 436-444.

[14] 汪文靖, 杨文瀚, 方玉明, 等. 恶劣场景下视觉感知与理解综述[J]. 中国图象图形学报, 2024, 29(6): 1667-1684.

[15] 王珮, 朱宇, 闫庆森, 等. 真实场景图像去模糊：挑战与展望[J]. 中国图象图形学报, 2024, 29(12): 3501-3528.

[16] 王泽龙, 吴宇航, 李健, 等. 面向图像处理逆问题的扩散模型研究综述[J]. 国防科技大学学报: 1-20.

[17] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[C]//PEREIRA F, BURGES C J C, BOTTOU L, et al. Advances

中国知网 https://www.cnki.net

in Neural Information Processing Systems: Vol. 25. 2012.

[18] CORSO G, STARK H, JEGELKA S, et al. Graph neural networks[J]. Nature Reviews Methods Primers, 2024, 4(1): 17.

[19] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017: 5998-6008.

[20] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations. 2021.

[21] CHEN Z, ZHANG Y, GU J, et al. Recursive generalization transformer for image super-resolution[C]//International Conference on Learning Representations. 2024.

[22] ZHOU S, CHEN D, PAN J, et al. Adapt or perish: Adaptive sparse transformer with attentive feature refinement for image restoration[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2024: 2952-2963.

[23] ZHANG J, ZHANG Y, GU J, et al. Xformer: Hybrid x-shaped transformer for image denoising[C]//International Conference on Learning Representations. 2024.

[24] ZHAO H, GOU Y, LI B, et al. Comprehensive and delicate: An efficient transformer for image restoration[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2023: 14122-14132.

[25] GU A, DAO T. Mamba: Linear-time sequence modeling with selective state spaces[A]. 2023. arXiv: 2312.00752.

[26] GUO H, GUO Y, ZHA Y, et al. Mambairv2: Attentive state space restoration[A]. 2024. arXiv: 2411.15269.

[27] DAO T, GU A. Transformers are ssms: generalized models and efficient algorithms through structured state space duality[C]//International Conference on Machine Learning. 2024.

[28] BOTTOU L. Large-scale machine learning with stochastic gradient descent[C]//Proceedings of COMPSTAT. 2010: 177-186.

[29] KINGMA D P, BA J. Adam: A method for stochastic optimization[C]//International Conference on Learning Representations. 2014.

[30] NAH S, HYUN KIM T, MU LEE K. Deep multi-scale convolutional neural network for dynamic scene deblurring[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2017: 3883-3891.

[31] QUAN R, YU X, LIANG Y, et al. Removing raindrops and rain streaks in one go[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2021: 9147-9156.

[32] AI Y, ZHOU X, HUANG H, et al. Dreamclear: High-capacity real-world image restoration with privacy-safe dataset curation[C]//Advances in Neural Information Processing Systems.

中国知网 https://www.cnki.net

2024.

[33] WANG T, YANG X, XU K, et al. Spatial attentive single-image deraining with a high quality real rain dataset[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2019: 12270-12279.

[34] WANG X, YU K, WU S, et al. Esrgan: Enhanced super-resolution generative adversarial networks[C]//European Conference on Computer Vision Workshops: Vol. 11133. 2018: 0-0.

[35] ZHANG K, GOOL L V, TIMOFTE R. Deep unfolding network for image super-resolution [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 3217-3226.

[36] XIAO J, ZHOU M, FU X, et al. Improving de-raining generalization via neural reorganization [C]//IEEE International Conference on Computer Vision. 2021: 4987-4996.

[37] FU X, XIAO J, ZHU Y, et al. Continual image deraining with hypergraph convolutional networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(8): 9534-9551.

[38] VAN DE VEN G M, TUYTELAARS T, TOLIAS A S. Three types of incremental learning [J]. Nature Machine Intelligence, 2022, 4(12): 1185-1197.

[39] LI X, LI B, JIN X, et al. Learning distortion invariant representation for image restoration from a causality perspective[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2023: 1714-1724.

[40] ZHU Y, WANG T, FU X, et al. Learning weather-general and weather-specific features for image restoration under multiple adverse weather conditions[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2023: 21747-21758.

[41] SAHARIA C, HO J, CHAN W, et al. Image super-resolution via iterative refinement[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(4): 4713-4726.

[42] SAHARIA C, CHAN W, CHANG H, et al. Palette: Image-to-image diffusion models[C]// ACM International Conference on Computer Graphics and Interactive Techniques. 2022: 1-10.

[43] LUO Z, GUSTAFSSON F K, ZHAO Z, et al. Image restoration with mean-reverting stochastic differential equations[C]//International Conference on Machine Learning. 2023.

[44] SONG Y, SOHL-DICKSTEIN J, KINGMA D P, et al. Score-based generative modeling through stochastic differential equations[C]//International Conference on Learning Representations. 2021.

[45] YUE Z, WANG J, LOY C C. Resshift: Efficient diffusion model for image super-resolution by residual shifting[J]. Advances in Neural Information Processing Systems, 2023, 36: 13294-13307.

中国知网 https://www.cnki.net

[46] WANG J, YUE Z, ZHOU S, et al. Exploiting diffusion prior for real-world image super-resolution[J]. International Journal of Computer Vision, 2024, 132(12): 5929-5949.

[47] LIN X, HE J, CHEN Z, et al. Diffbir: Toward blind image restoration with generative diffusion prior[C]//European Conference on Computer Vision. 2025: 430-448.

[48] POTLAPALLI V, ZAMIR S W, KHAN S H, et al. Promptir: Prompting for all-in-one image restoration[C]//Advances in Neural Information Processing Systems: Vol. 36. 2023: 71275-71293.

[49] DONG C, LOY C C, HE K, et al. Image super-resolution using deep convolutional networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 38(2): 295-307.

[50] ZHANG K, ZUO W, CHEN Y, et al. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising[J]. IEEE Transactions on Image Processing, 2017, 26(7): 3142-3155.

[51] FU X, HUANG J, DING X, et al. Clearing the skies: A deep network architecture for single-image rain removal[J]. IEEE Transactions on Image Processing, 2017, 26(6): 2944-2956.

[52] FU X, HUANG J, ZENG D, et al. Removing rain from single images via a deep detail network [C]//IEEE Conference on Computer Vision and Pattern Recognition. 2017: 1715-1723.

[53] YANG W, TAN R T, FENG J, et al. Deep joint rain detection and removal from a single image [C]//IEEE Conference on Computer Vision and Pattern Recognition. 2017: 1357-1366.

[54] YANG W, TAN R T, FENG J, et al. Joint rain detection and removal from a single image with contextualized deep networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 42(6): 1377-1393.

[55] REN W, PAN J, ZHANG H, et al. Single image dehazing via multi-scale convolutional neural networks with holistic edges[J]. International Journal of Computer Vision, 2020, 128 (1): 240-259.

[56] REN W, LIU S, ZHANG H, et al. Single image dehazing via multi-scale convolutional neural networks[C]//European Conference on Computer Vision. 2016: 154-169.

[57] JIANG K, WANG Z, YI P, et al. Multi-scale progressive fusion network for single image deraining[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2020: 8346-8355.

[58] ZAMIR S W, ARORA A, KHAN S, et al. Multi-stage progressive image restoration[C]// IEEE Conference on Computer Vision and Pattern Recognition. 2021: 14821-14831.

[59] CHEN L, CHU X, ZHANG X, et al. Simple baselines for image restoration[C]//European Conference on Computer Vision. 2022: 17-33.

[60] LIU D, WEN B, FAN Y, et al. Non-local recurrent network for image restoration[C]// Advances in Neural Information Processing Systems: Vol. 31. 2018.

中国知网 https://www.cnki.net

[61] CHEN H, WANG Y, GUO T, et al. Pre-trained image processing transformer[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2021: 12299-12310.

[62] LIANG J, CAO J, SUN G, et al. SwinIR: Image restoration using swin transformer[C]//IEEE International Conference on Computer Vision Workshops. 2021: 1833-1844.

[63] WANG Z, CUN X, BAO J, et al. Uformer: A general U-shaped transformer for image restoration[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2022: 17683-17693.

[64] ZAMIR S W, ARORA A, KHAN S, et al. Restormer: Efficient transformer for high-resolution image restoration[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2022: 5728-5739.

[65] LI Y, FAN Y, XIANG X, et al. Efficient and explicit modelling of image hierarchies for image restoration[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2023: 18278-18289.

[66] GUO H, LI J, DAI T, et al. Mambair: A simple baseline for image restoration with state-space model[C]//European Conference on Computer Vision. 2024: 222-241.

[67] SHI Y, XIA B, JIN X, et al. Vmambair: Visual state space model for image restoration[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2025: 1-1.

[68] ULYANOV D, VEDALDI A, LEMPITSKY V. Deep image prior[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 9446-9454.

[69] JAGATAP G, HEGDE C. Algorithmic guarantees for inverse imaging with untrained network priors[C]//Advances in Neural Information Processing Systems: Vol. 32. 2019.

[70] JIANG H, LUO A, FAN H, et al. Low-light image enhancement with wavelet-based diffusion models[J]. ACM Transactions on Graphics, 2023, 42(6): 1-14.

[71] LUO Z, GUSTAFSSON F K, ZHAO Z, et al. Refusion: Enabling large-size realistic image restoration with latent-space diffusion models[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2023: 1680-1691.

[72] ENGIN D, GENÇ A, KEMAL EKENEL H. Cycle-dehaze: Enhanced cyclegan for single image dehazing[C]//IEEE Conference on Computer Vision and Pattern Recognition Workshops. 2018.

[73] VENKATAKRISHNAN S V, BOUMAN C A, WOHLBERG B. Plug-and-play priors for model based reconstruction[C/OL]//IEEE Global Conference on Signal and Information Processing. 2013: 945-948. DOI: 10.1109/GlobalSIP.2013.6737048.

[74] LEHTINEN J, MUNKBERG J, HASSELGREN J, et al. Noise2Noise: Learning image restoration without clean data[C]//International Conference on Machine Learning: Vol. 80. 2018: 2965-2974.

[75] BORA A, PRICE E, DIMAKIS A G. Ambientgan: Generative models from lossy measure-

中国知网 https://www.cnki.net

ments[C]//International Conference on Learning Representations. 2018.

[76] QUAN Y, CHEN M, PANG T, et al. Self2Self with dropout: Learning self-supervised denoising from single image[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2020.

[77] HUANG T, LI S, JIA X, et al. Neighbor2Neighbor: Self-supervised denoising from single noisy images[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2021: 14776-14785.

[78] MANSOUR Y, HECKEL R. Zero-shot noise2noise: Efficient image denoising without any data[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2023: 14018-14027.

[79] ONGIE G, JALAL A, METZLER C A, et al. Deep learning techniques for inverse problems in imaging[J]. IEEE Journal on Selected Areas in Information Theory, 2020.

[80] ROMANO Y, ELAD M, MILANFAR P. The little engine that could: Regularization by denoising (red)[J]. SIAM Journal on Imaging Sciences, 2017, 10(4): 1804-1844.

[81] CHANG J R, LI C L, PóCZOS B, et al. One network to solve them all —solving linear inverse problems using deep projection models[C]//IEEE International Conference on Computer Vision. 2017: 5888-5897.

[82] SUN Y, WOHLBERG B, KAMILOV U S. An online plug-and-play algorithm for regularized image reconstruction[J]. IEEE Transactions on Computational Imaging, 2019, 5(3): 395-408.

[83] ZHANG K, LI Y, ZUO W, et al. Plug-and-play image restoration with deep denoiser prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(10): 6360-6376.

[84] KAWAR B, VAKSMAN G, ELAD M. SNIPS: Solving noisy inverse problems stochastically [C]//Advances in Neural Information Processing Systems: Vol. 34. 2021: 21757-21769.

[85] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]// Advances in Neural Information Processing Systems: Vol. 27. 2014.

[86] BORA A, JALAL A, PRICE E, et al. Compressed sensing using generative models[C]// International Conference on Machine Learning. 2017: 537-546.

[87] DARAS G, DEAN J, JALAL A, et al. Intermediate layer optimization for inverse problems using deep generative models[C]//International Conference on Machine Learning. 2021.

[88] PAN X, ZHAN X, DAI B, et al. Exploiting deep generative prior for versatile image restoration and manipulation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(11): 7474-7489.

[89] SONG Y, ERMON S. Generative modeling by estimating gradients of the data distribution [C]//Advances in Neural Information Processing Systems: Vol. 32. 2019.

[90] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[C]//Advances in Neural

中国知网 https://www.cnki.net

Information Processing Systems: Vol. 33. 2020: 6840-6851.

[91] DHARIWAL P, NICHOL A. Diffusion models beat GANs on image synthesis[C]//Advances in Neural Information Processing Systems: Vol. 34. 2021: 8780-8794.

[92] RAMESH A, DHARIWAL P, NICHOL A, et al. Hierarchical text-conditional image generation with clip latents: Vol. 1[A]. 2022: 3. arXiv: 2204.06125.

[93] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2022: 10684-10695.

[94] ESSER P, KULAL S, BLATTMANN A, et al. Scaling rectified flow transformers for high-resolution image synthesis[C]//International Conference on Machine Learning. 2024: 503-28.

[95] CAO H, TAN C, GAO Z, et al. A survey on generative diffusion models[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 2814-2830.

[96] CHOI J, KIM S, JEONG Y, et al. ILVR: Conditioning method for denoising diffusion probabilistic models[C]//IEEE International Conference on Computer Vision. 2021.

[97] KADKHODAIE Z, SIMONCELLI E. Stochastic solutions for linear inverse problems using the prior implicit in a denoiser[C]//Advances in Neural Information Processing Systems: Vol. 34. 2021: 13242-13254.

[98] SONG Y, SHEN L, XING L, et al. Solving inverse problems in medical imaging with score-based generative models[C]//International Conference on Learning Representations. 2022.

[99] MURATA N, SAITO K, LAI C H, et al. GibbsDDRM: A partially collapsed Gibbs sampler for solving blind inverse problems with denoising diffusion restoration[C]//International Conference on Machine Learning. 2023: 25501-25522.

[100] ZHU Y, ZHANG K, LIANG J, et al. Denoising diffusion models for plug-and-play image restoration[C]//IEEE Conference on Computer Vision and Pattern Recognition Workshops. 2023: 1219-1229.

[101] ÖZDENIZCI O, LEGENSTEIN R. Restoring vision in adverse weather conditions with patch-based denoising diffusion models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(8): 10346-10357.

[102] COHEN N, MANOR H, BAHAT Y, et al. From posterior sampling to meaningful diversity in image restoration[C]//International Conference on Learning Representations. 2024.

[103] XU X, CHI Y. Provably robust score-based diffusion posterior sampling for plug-and-play image reconstruction[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024: 36148-36184.

[104] MARDANI M, SONG J, KAUTZ J, et al. A variational perspective on solving inverse prob-

中国知网 https://www.cnki.net

lems with diffusion models[C]//International Conference on Learning Representations. 2024.

[105] KAWAR B, ELAD M, ERMON S, et al. Denoising diffusion restoration models[C]// Advances in Neural Information Processing Systems: Vol. 35. 2022: 23593-23606.

[106] KAWAR B, SONG J, ERMON S, et al. JPEG artifact correction using denoising diffusion restoration models[C]//Advances in Neural Information Processing Systems Workshops. 2022.

[107] WANG Y, YU J, ZHANG J. Zero-shot image restoration using denoising diffusion null-space model[C]//International Conference on Learning Representations. 2023.

[108] CHUNG H, KIM J, MCCANN M T, et al. Diffusion posterior sampling for general noisy inverse problems[C]//International Conference on Learning Representations. 2023.

[109] FEI B, LYU Z, PAN L, et al. Generative diffusion prior for unified image restoration and enhancement[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2023: 9935-9946.

[110] GOODFELLOW I, BENGIO Y, COURVILLE A. Deep learning[M]. MIT Press, 2016.

[111] XU L, REN J S, LIU C, et al. Deep convolutional neural network for image deconvolution [C]//Advances in Neural Information Processing Systems: Vol. 27. 2014.

[112] KUPYN O, BUDZAN V, MYKHAILYCH M, et al. Deblurgan: Blind motion deblurring using conditional adversarial networks[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 8183-8192.

[113] DONG J, ROTH S, SCHIELE B. Deep wiener deconvolution: Wiener meets deep learning for image deblurring[C]//Advances in Neural Information Processing Systems: Vol. 33. 2020: 1048-1059.

[114] ZHANG Y, TIAN Y, KONG Y, et al. Residual dense network for image restoration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 43(7): 2480-2495.

[115] ZAMIR S W, ARORA A, KHAN S, et al. Learning enriched features for real image restoration and enhancement[C]//European Conference on Computer Vision. 2020: 492-511.

[116] YANG W, TAN R T, FENG J, et al. Joint rain detection and removal from a single image with contextualized deep networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020: 1357-1366.

[117] ZHANG Y, LI K, LI K, et al. Image super-resolution using very deep residual channel attention networks[C]//European Conference on Computer Vision. 2018: 286-301.

[118] DAI T, CAI J, ZHANG Y, et al. Second-order attention network for single image super-resolution[C/OL]//IEEE Conference on Computer Vision and Pattern Recognition. 2019: 11057-11066. DOI: 10.1109/CVPR.2019.01132.

[119] HARIS M, SHAKHNAROVICH G, UKITA N. Deep back-projection networks for super-

中国知网 https://www.cnki.net

resolution[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 1664-1673.

[120] WANG Z, CUN X, BAO J, et al. Uformer: A general u-shaped transformer for image restoration[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2022: 17683-17693.

[121] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2019: 4171-4186.

[122] TOUVRON H, CORD M, DOUZE M, et al. Training data-efficient image transformers & distillation through attention[C]//International Conference on Machine Learning. 2021: 10347-10357.

[123] WANG W, XIE E, LI X, et al. Pyramid vision transformer: A versatile backbone for dense prediction without convolutions[C]//IEEE International Conference on Computer Vision. 2021: 568-578.

[124] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//IEEE International Conference on Computer Vision. 2021: 10012-10022.

[125] YANG J, LI C, ZHANG P, et al. Focal attention for long-range interactions in vision transformers[C]//Advances in Neural Information Processing Systems: Vol. 34. 2021: 30008-30022.

[126] YU Q, XIA Y, BAI Y, et al. Glance-and-gaze vision transformer[C]//Advances in Neural Information Processing Systems: Vol. 34. 2021: 12992-13003.

[127] CHU X, TIAN Z, WANG Y, et al. Twins: Revisiting the design of spatial attention in vision transformers[C]//Advances in Neural Information Processing Systems: Vol. 34. 9355-9366.

[128] 田永林, 王雨桐, 王建功, 等. 视觉 Transformer 研究的关键问题: 现状及展望[J]. 自动化学报, 2022, 48(04): 957-979.

[129] 李文生, 张菁, 卓力, 等. 基于 Transformer 的视觉分割技术进展[J]. 计算机学报, 2024, 47(12): 2760-2782.

[130] SUN C, SHRIVASTAVA A, SINGH S, et al. Revisiting unreasonable effectiveness of data in deep learning era[C]//IEEE International Conference on Computer Vision. 2017: 843-852.

[131] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers [C]//European Conference on Computer Vision. 2020: 213-229.

[132] CHENG B, SCHWING A, KIRILLOV A. Per-pixel classification is not all you need for semantic segmentation[J]. Advances in neural information processing systems, 2021, 34: 17864-17875.

[133] ESSER P, ROMBACH R, OMMER B. Taming transformers for high-resolution image syn-

中国知网 https://www.cnki.net

thesis[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2021: 12873-12883.

[134] PEEBLES W, XIE S. Scalable diffusion models with transformers[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2023: 4195-4205.

[135] KONG W, TIAN Q, ZHANG Z, et al. Hunyuanvideo: A systematic framework for large video generative models[A]. 2024. arXiv: 2412.03603.

[136] YANG Z, TENG J, ZHENG W, et al. Cogvideox: Text-to-video diffusion models with an expert transformer[C]//International Conference on Learning Representations. 2025.

[137] LIU H, LI C, WU Q, et al. Visual instruction tuning[C]//Advances in Neural Information Processing Systems: Vol. 36. 2023: 34892-34916.

[138] WANG W, LV Q, YU W, et al. Cogvlm: Visual expert for pretrained language models[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024: 121475-121499.

[139] YUE X, NI Y, ZHANG K, et al. Mmmu: A massive multi-discipline multimodal understanding and reasoning benchmark for expert agi[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2024: 9556-9567.

[140] SHAW P, USZKOREIT J, VASWANI A. Self-attention with relative position representations[C]//Proceedings of Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2018: 464-468.

[141] BELLO I, ZOPH B, VASWANI A, et al. Attention augmented convolutional networks[C]//IEEE International Conference on Computer Vision. 2019: 3286-3295.

[142] RAMACHANDRAN P, PARMAR N, VASWANI A, et al. Stand-alone self-attention in vision models[C]//Advances in Neural Information Processing Systems: Vol. 32. 2019.

[143] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(56): 1929-1958.

[144] HUANG G, SUN Y, LIU Z, et al. Deep networks with stochastic depth[C]//European Conference on Computer Vision. 2016: 646-661.

[145] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C]//MICCAI. 2015: 234-241.

[146] ISOLA P, ZHU J Y, ZHOU T, et al. Image-to-image translation with conditional adversarial networks[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2017: 1125-1134.

[147] CHARBONNIER P, BLANC-FERAUD L, AUBERT G, et al. Two deterministic half-quadratic regularization algorithms for computed imaging[C/OL]//IEEE International Conference on Image Processing: Vol. 2. 1994: 168-172 vol.2. DOI: 10.1109/ICIP.1994.413553.

中国知网 https://www.cnki.net

[148] LI Y, TAN R T, GUO X, et al. Rain streak removal using layer priors[C/OL]//IEEE Conference on Computer Vision and Pattern Recognition. 2016: 2736-2744. DOI: 10.1109/CVPR.2016.299.

[149] WANG H, XIE Q, ZHAO Q, et al. A model-driven deep neural network for single image rain removal[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2020: 3103-3112.

[150] PUROHIT K, SUIN M, RAJAGOPALAN A, et al. Spatially-adaptive image restoration using distortion-guided networks[C]//IEEE International Conference on Computer Vision. 2021: 2309-2319.

[151] KUPYN O, MARTYNIUK T, WU J, et al. Deblurgan-v2: Deblurring (orders-of-magnitude) faster and better[C]//IEEE International Conference on Computer Vision. 2019: 8878-8887.

[152] ZHANG K, LUO W, ZHONG Y, et al. Deblurring by realistic blurring[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2020: 2737-2746.

[153] GONG X, MA J. Ir-cm: The fast and general-purpose image restoration method based on consistency model[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024: 75559-75584.

[154] ZHANG K, ZUO W, GU S, et al. Learning deep cnn denoiser prior for image restoration[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2017: 3929-3938.

[155] ZHANG K, ZUO W, ZHANG L. Ffdnet: Toward a fast and flexible solution for cnn-based image denoising[J]. IEEE Transactions on Image Processing, 2018, 27(9): 4608-4622.

[156] YUE Z, YONG H, ZHAO Q, et al. Variational denoising network: Toward blind noise modeling and removal[C]//Advances in Neural Information Processing Systems: Vol. 32. 2019.

[157] LUO F, WU X, GUO Y. Functional neural networks for parametric image restoration problems[C]//Advances in Neural Information Processing Systems: Vol. 34. 2021: 6762-6775.

[158] MARTIN D, FOWLKES C, TAL D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics [C/OL]//IEEE International Conference on Computer Vision: Vol. 2. 2001: 416-423 vol.2. DOI: 10.1109/ICCV.2001.937655.

[159] HUANG J B, SINGH A, AHUJA N. Single image super-resolution from transformed self-exemplars[C/OL]//IEEE Conference on Computer Vision and Pattern Recognition. 2015: 5197-5206. DOI: 10.1109/CVPR.2015.7299156.

[160] FRANZEN R. Kodak lossless true color image suite[EB/OL]. 1999. http://r0k.us/graphics/kodak/.

[161] ZHANG L, WU X, BUADES A, et al. Color demosaicking by local directional interpolation and nonlocal adaptive thresholding[J]. Journal of Electronic Imaging, 2011, 20(2): 023016-

中国知网 https://www.cnki.net

023016.

[162] SHEN Z, WANG W, LU X, et al. Human-aware motion deblurring[C]//IEEE International Conference on Computer Vision. 2019: 5572-5581.

[163] ZHANG G, ZHANG P, QI J, et al. Hat: Hierarchical aggregation transformers for person re-identification[C]//ACM International Conference on Multimedia. 2021: 516-525.

[164] DONG X, BAO J, CHEN D, et al. Cswin transformer: A general vision transformer backbone with cross-shaped windows[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2022: 12124-12134.

[165] LIU Z, HU H, LIN Y, et al. Swin transformer v2: Scaling up capacity and resolution[C]// IEEE Conference on Computer Vision and Pattern Recognition. 2022: 12009-12019.

[166] XIE E, WANG W, YU Z, et al. Segformer: Simple and efficient design for semantic segmentation with transformers[C]//Advances in Neural Information Processing Systems: Vol. 34. 2021: 12077-12090.

[167] ZHU X, SU W, LU L, et al. Deformable {detr}: Deformable transformers for end-to-end object detection[C]//International Conference on Learning Representations. 2021.

[168] TU Z, TALEBI H, ZHANG H, et al. Maxvit: Multi-axis vision transformer[C]//European Conference on Computer Vision. 2022: 459-479.

[169] XU W, XU Y, CHANG T, et al. Co-scale conv-attentional image transformers[C]//IEEE International Conference on Computer Vision. 2021: 9981-9990.

[170] CORDONNIER J B, LOUKAS A, JAGGI M. On the relationship between self-attention and convolutional layers[C]//International Conference on Learning Representations. 2020.

[171] LIVINGSTONE M S, HUBEL D H. Segregation of form, color, movement, and depth: anatomy, physiology, and perception.[J]. Science, 1988, 240 4853: 740-9.

[172] YUAN K, GUO S, LIU Z, et al. Incorporating convolution designs into visual transformers [C]//IEEE International Conference on Computer Vision. 2021: 579-588.

[173] HENDRYCKS D, GIMPEL K. Gaussian error linear units (gelus)[A]. 2016. arXiv: 1606.08415.

[174] LECUN Y, BOSER B, DENKER J S, et al. Backpropagation applied to handwritten zip code recognition[J]. Neural Computation, 1989, 1(4): 541-551.

[175] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.

[176] BA J L, KIROS J R, HINTON G E. Layer normalization[A]. 2016. arXiv: 1607.06450.

[177] HUBEL D H, WIESEL T N. Receptive fields of optic nerve fibres in the spider monkey[J]. The Journal of Physiology, 1960, 154.

[178] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection

中国知网 https://www.cnki.net

[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2117-2125.

[179] ZHANG H, PATEL V M. Density-aware single image de-raining using a multi-stream dense network[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 695-704.

[180] LI Y, TAN R T, GUO X, et al. Rain streak removal using layer priors[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2016: 2736-2744.

[181] GU S, MENG D, ZUO W, et al. Joint convolutional analysis and synthesis sparse representation for single image layer separation[C]//IEEE International Conference on Computer Vision. 2017: 1717-1725.

[182] LI G, HE X, ZHANG W, et al. Non-locally enhanced encoder-decoder network for single image de-raining[C]//ACM International Conference on Multimedia. 2018: 1056-1064.

[183] LI X, WU J, LIN Z, et al. Recurrent squeeze-and-excitation context aggregation net for single image deraining[C]//European Conference on Computer Vision. 2018: 254-269.

[184] REN D, ZUO W, HU Q, et al. Progressive image deraining networks: A better and simpler baseline[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2019: 3937-3946.

[185] YASARLA R, SINDAGI V A, PATEL V M. Syn2real transfer learning for image deraining using gaussian processes[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2020: 2726-2736.

[186] WANG H, XIE Q, ZHAO Q, et al. A model-driven deep neural network for single image rain removal[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2020: 3100-3109.

[187] SCHAEFER G, STICH M. UCID: an uncompressed color image database[C]//Storage and Retrieval Methods and Applications for Multimedia 2004: Vol. 5307. 2003: 472 - 480.

[188] ARBELáEZ P, MAIRE M, FOWLKES C, et al. Contour detection and hierarchical image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33 (5): 898-916.

[189] QIAN R, TAN R T, YANG W, et al. Attentive generative adversarial network for raindrop removal from a single image[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 2482-2491.

[190] EIGEN D, KRISHNAN D, FERGUS R. Restoring an image taken through a window covered with dirt or rain[C]//IEEE International Conference on Computer Vision. 2013: 633-640.

[191] QUAN Y, DENG S, CHEN Y, et al. Deep learning for seeing through window with raindrops [C]//IEEE International Conference on Computer Vision. 2019: 2463-2471.

[192] WANG X, GIRSHICK R, GUPTA A, et al. Non-local neural networks[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7794-7803.

中国知网 https://www.cnki.net

[193] YUE Z, ZHAO Q, ZHANG L, et al. Dual adversarial network: Toward real-world noise removal and noise generation[C]//European Conference on Computer Vision. 2020: 41-58.

[194] ZAMIR S W, ARORA A, KHAN S, et al. Cycleisp: Real image restoration via improved data synthesis[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2020: 2696-2705.

[195] REN C, HE X, WANG C, et al. Adaptive consistency prior based deep network for image denoising[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2021: 8596-8606.

[196] MOU C, ZHANG J, WU Z. Dynamic attentive graph learning for image restoration[C]//IEEE International Conference on Computer Vision. 2021: 4328-4337.

[197] ABDELHAMED A, LIN S, BROWN M S. A high-quality denoising dataset for smartphone cameras[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 1692-1700.

[198] PARK N, KIM S. How do vision transformers work?[C]//International Conference on Learning Representations. 2022.

[199] WANG P, ZHENG W, CHEN T, et al. Anti-oversmoothing in deep vision transformers via the fourier domain analysis: From theory to practice[C]//International Conference on Learning Representations. 2022.

[200] IOFFE S, SZEGEDY C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International Conference on Machine Learning. 2015: 448-456.

[201] WU Y, HE K. Group normalization[C]//European Conference on Computer Vision. 2018: 3-19.

[202] ULYANOV D, VEDALDI A, LEMPITSKY V. Instance normalization: The missing ingredient for fast stylization[A]. 2016. arXiv: 1607.08022.

[203] SANIN A, SANDERSON C, LOVELL B C. Improved shadow removal for robust person tracking in surveillance scenarios[C]//International Conference on Pattern Recognition. 2010: 141-144.

[204] NADIMI S, BHANU B. Physical models for moving shadow and object detection in video [J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2004, 26(8): 1079-1087. DOI: 10.1109/TPAMI.2004.51.

[205] ZHANG W, ZHAO X, MORVAN J M, et al. Improving shadow suppression for illumination robust face recognition[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(3): 611-624. DOI: 10.1109/TPAMI.2018.2803179.

[206] CHU X, TIAN Z, ZHANG B, et al. Conditional positional encodings for vision transformers

中国知网 https://www.cnki.net

[C]//International Conference on Learning Representations. 2023.

[207] TOLSTIKHIN I O, HOULSBY N, KOLESNIKOV A, et al. Mlp-mixer: An all-mlp architecture for vision[C]//Advances in Neural Information Processing Systems: Vol. 34. 2021: 24261-24272.

[208] BELLO I. Lambdanetworks: Modeling long-range interactions without attention[C]// International Conference on Learning Representations. 2021.

[209] FU L, ZHOU C, GUO Q, et al. Auto-exposure fusion for single-image shadow removal[C]// IEEE Conference on Computer Vision and Pattern Recognition. 2021: 10571-10580.

[210] ZHU Y, HUANG J, FU X, et al. Bijective mapping network for shadow removal[C/OL]// IEEE Conference on Computer Vision and Pattern Recognition. 2022: 5617-5626. DOI: 10.1109/CVPR52688.2022.00554.

[211] GUO R, DAI Q, HOIEM D. Paired regions for shadow detection and removal[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(12): 2956-2967. DOI: 10.1109/TPAMI.2012.214.

[212] QU L, TIAN J, HE S, et al. Deshadownet: A multi-context embedding deep network for shadow removal[C/OL]//IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2308-2316. DOI: 10.1109/CVPR.2017.248.

[213] HU X, FU C W, ZHU L, et al. Direction-aware spatial context features for shadow detection and removal[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019: 7454-7462.

[214] CUN X, PUN C M, SHI C. Towards ghost-free shadow removal via dual hierarchical aggregation network and shadow matting gan[C]//Association for the Advancement of Artificial Intelligence: Vol. 34. 2020: 10680-10687.

[215] JIN Y, SHARMA A, TAN R T. Dc-shadownet: Single-image hard and soft shadow removal using unsupervised domain-classifier guided network[C]//IEEE International Conference on Computer Vision. 2021: 5027-5036.

[216] WAN J, YIN H, WU Z, et al. Style-guided shadow removal[C]//European Conference on Computer Vision. 2022: 361-378.

[217] GUO L, HUANG S, LIU D, et al. Shadowformer: Global context helps image shadow removal[C]//Association for the Advancement of Artificial Intelligence: Vol. 37. 2023: 710-718.

[218] GUO L, WANG C, YANG W, et al. Shadowdiffusion: When degradation prior meets diffusion model for shadow removal[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2023: 14049-14058.

[219] LI X, GUO Q, ABDELFATTAH R, et al. Leveraging inpainting for single-image shadow

中国知网 https://www.cnki.net

removal[C]//IEEE International Conference on Computer Vision. 2023: 13009-13018.

[220] ZHANG H, DAI Y, LI H, et al. Deep stacked hierarchical multi-patch network for image deblurring[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2019: 5978-5986.

[221] HU X, JIANG Y, FU C W, et al. Mask-shadowgan: Learning to remove shadows from unpaired data[C]//IEEE International Conference on Computer Vision. 2019: 2472-2481.

[222] LE H, SAMARAS D. Shadow removal via shadow image decomposition[C]//IEEE International Conference on Computer Vision. 2019: 8578-8587.

[223] LE H, SAMARAS D. From shadow segmentation to shadow removal[C/OL]//European Conference on Computer Vision. 2020: 264–281. DOI: 10.1007/978-3-030-58621-8_16.

[224] LIU Z, YIN H, WU X, et al. From shadow generation to shadow removal[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2021: 4927-4936.

[225] WANG J, LI X, YANG J. Stacked conditional generative adversarial networks for jointly learning shadow detection and shadow removal[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 1788-1797.

[226] LE H, SAMARAS D. Physics-based shadow image decomposition for shadow removal [J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(12): 9088-9101. DOI: 10.1109/TPAMI.2021.3124934.

[227] RIM J, LEE H, WON J, et al. Real-world blur dataset for learning and benchmarking deblurring algorithms[C]//European Conference on Computer Vision. 2020: 184-201.

[228] KENDALL A, GAL Y. What uncertainties do we need in bayesian deep learning for computer vision?[C]//Advances in Neural Information Processing Systems: Vol. 30. 2017.

[229] CHENG S, WANG Y, HUANG H, et al. Nbnet: Noise basis learning for image denoising with subspace projection[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2021: 4896-4906.

[230] ANWAR S, BARNES N. Real image denoising with feature attention[C]//IEEE International Conference on Computer Vision. 2019: 3155-3164.

[231] TU Z, TALEBI H, ZHANG H, et al. Maxim: Multi-axis mlp for image processing[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2022: 5769-5780.

[232] XU L, ZHENG S, JIA J. Unnatural l0 sparse representation for natural image deblurring [C/OL]//IEEE Conference on Computer Vision and Pattern Recognition. 2013: 1107-1114. DOI: 10.1109/CVPR.2013.147.

[233] ZHANG J, PAN J, REN J, et al. Dynamic scene deblurring using spatially variant recurrent neural networks[C/OL]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 2521-2529. DOI: 10.1109/CVPR.2018.00267.

中国知网 https://www.cnki.net

[234] TAO X, GAO H, SHEN X, et al. Scale-recurrent network for deep image deblurring[C]// IEEE Conference on Computer Vision and Pattern Recognition. 2018: 8174-8182.

[235] MOU C, WANG Q, ZHANG J. Deep generalized unfolding networks for image restoration [C]//IEEE Conference on Computer Vision and Pattern Recognition. 2022: 17399-17410.

[236] GELMAN A, CARLIN J, STERN H, et al. Chapman & hall/crc texts in statistical science: Bayesian data analysis, third edition[M]. 2013.

[237] ZHOU L, LOU A, KHANNA S, et al. Denoising diffusion bridge models[C]//International Conference on Learning Representations. 2024.

[238] LIU Q. Rectified flow: A marginal preserving approach to optimal transport[A]. 2022. arXiv: 2209.14577.

[239] LIU X, GONG C, QIANG LIU. Flow straight and fast: Learning to generate and transfer data with rectified flow[C]//International Conference on Learning Representations. 2023.

[240] LIPMAN Y, CHEN R T Q, BEN-HAMU H, et al. Flow matching for generative modeling [C]//International Conference on Learning Representations. 2023.

[241] ALBERGO M S, VANDEN-EIJNDEN E. Building normalizing flows with stochastic interpolants[C]//International Conference on Learning Representations. 2023.

[242] SONG Y, DHARIWAL P, CHEN M, et al. Consistency models[C]//International Conference on Machine Learning: Vol. 202. 2023: 32211-32252.

[243] SONG Y, DHARIWAL P. Improved techniques for training consistency models[C]// International Conference on Learning Representations. 2024.

[244] KIM D, LAI C H, LIAO W H, et al. Consistency trajectory models: Learning probability flow ODE trajectory of diffusion[C]//International Conference on Learning Representations. 2024.

[245] LU C, SONG Y. Simplifying, stabilizing and scaling continuous-time consistency models [A]. 2024. arXiv: 2410.11081.

[246] CHANG H, ZHANG H, BARBER J, et al. Muse: Text-to-image generation via masked generative transformers[C]//Proceedings of the 40th International Conference on Machine Learning: Vol. 202. 2023: 4055-4075.

[247] YU J, XU Y, KOH J Y, et al. Scaling autoregressive models for content-rich text-to-image generation[J]. Transactions on Machine Learning Research, 2022.

[248] TIAN K, JIANG Y, YUAN Z, et al. Visual autoregressive modeling: Scalable image generation via next-scale prediction[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024: 84839-84865.

[249] YU L, CHENG Y, SOHN K, et al. Magvit: Masked generative video transformer[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2023: 10459-10469.

中国知网 https://www.cnki.net

[250] LI T, TIAN Y, LI H, et al. Autoregressive image generation without vector quantization[C]// Advances in Neural Information Processing Systems: Vol. 37. 2024: 56424-56445.

[251] SONG Y, SHEN L, XING L, et al. Solving inverse problems in medical imaging with score-based generative models[C]//International Conference on Learning Representations. 2022.

[252] KINGMA D P, WELLING M, et al. Auto-encoding variational bayes[J]. CoRR, 2013, abs/1312.6114.

[253] JIANG J, ZHANG K, TIMOFTE R. Towards flexible blind JPEG artifacts removal[C]//IEEE International Conference on Computer Vision. 2021: 4997-5006.

[254] SOHL-DICKSTEIN J, WEISS E, MAHESWARANATHAN N, et al. Deep unsupervised learning using nonequilibrium thermodynamics[C]//International Conference on Machine Learning. 2015: 2256-2265.

[255] SONG J, MENG C, ERMON S. Denoising diffusion implicit models[C]//International Conference on Learning Representations. 2021.

[256] HYVÄRINEN A, DAYAN P. Estimation of non-normalized statistical models by score matching[J]. Journal of Machine Learning Research, 2005, 6(24): 695-709.

[257] KARRAS T, AITTALA M, AILA T, et al. Elucidating the design space of diffusion-based generative models[C]//Advances in Neural Information Processing Systems: Vol. 35. 2022: 26565-26577.

[258] SHANNON C E. A mathematical theory of communication[J]. The Bell System Technical Journal, 1948.

[259] COVER T M, THOMAS J A. Elements of information theory (wiley series in telecommunications and signal processing)[M]. 2006.

[260] DENG J, DONG W, SOCHER R, et al. Imagenet: A large-scale hierarchical image database [C/OL]//IEEE Conference on Computer Vision and Pattern Recognition. 2009: 248-255. DOI: 10.1109/CVPR.2009.5206848.

[261] KARRAS T, AILA T, LAINE S, et al. Progressive growing of GANs for improved quality, stability, and variation[C]//International Conference on Learning Representations. 2018.

[262] YU F, SEFF A, ZHANG Y, et al. LSUN: Construction of a large-scale image dataset using deep learning with humans in the loop[A]. 2015. arXiv: 1506.03365.

[263] PODELL D, ENGLISH Z, LACEY K, et al. SDXL: improving latent diffusion models for high-resolution image synthesis[A]. 2023. arXiv: 2307.01952.

[264] EHRLICH M, DAVIS L, LIM S N, et al. Quantization guided JPEG artifact correction[C]// European Conference on Computer Vision. 2020: 293-309.

[265] DABOV K, FOI A, KATKOVNIK V, et al. Image denoising by sparse 3-D transform-domain collaborative filtering[J/OL]. IEEE Transactions on Image Processing, 2007, 16(8): 2080-

中国知网 https://www.cnki.net

2095. DOI: 10.1109/TIP.2007.901238.

[266] JESSON A, BELTRAN VELEZ N, CHU Q, et al. Estimating the hallucination rate of generative ai[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024: 31154-31201.

[267] AITHAL S K, MAINI P, LIPTON Z, et al. Understanding hallucinations in diffusion models through mode interpolation[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024: 134614-134644.

[268] JI Z, LEE N, FRIESKE R, et al. Survey of hallucination in natural language generation[J]. ACM computing surveys, 2023, 55(12): 1-38.

[269] BAI J, BAI S, CHU Y, et al. Qwen technical report[A]. 2023. arXiv: 2309.16609.

[270] SUN Z, FU X, HUANG L, et al. Motion aware event representation-driven image deblurring [C]//European Conference on Computer Vision. 2025: 418-435.

[271] LIN J, ZHANG Z, WEI Y, et al. Improving image restoration through removing degradations in textual representations[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2024: 2866-2878.

[272] AI Y, HUANG H, ZHOU X, et al. Multimodal prompt perceiver: Empower adaptiveness, generalizability and fidelity for all-in-one image restoration[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2024: 25432-25444.

[273] CHEN H, LI W, GU J, et al. Restoreagent: Autonomous image restoration agent via multimodal large language models[C]//Advances in Neural Information Processing Systems: Vol. 37. 2024: 110643-110666.

[274] SHAO Z, WANG P, ZHU Q, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models[A]. 2024. arXiv: 2402.03300.

[275] WU K, ZHANG J, PENG H, et al. Tinyvit: Fast pretraining distillation for small vision transformers[C]//European Conference on Computer Vision. 2022: 68-85.

[276] ZHAO Y, XU Y, XIAO Z, et al. Mobilediffusion: Instant text-to-image generation on mobile devices[C]//European Conference on Computer Vision. 2024: 225-242.

中国知网 https://www.cnki.net