中国科学技术大学

博士学位论文



面向图像复原的
自适应表征学习方法研究

作者姓名： 汪曦

学科专业： 控制科学与工程

导　　师： 查正军教授

完成时间： 二〇二五年十一月二十八日

中国知网 https://www.cnki.net

University of Science and Technology of China

A dissertation for doctor's degree



Research on Adaptive Representation Learning Methods for Image Restoration

Author: Xi Wang

Speciality: Control Science and Engineering

Supervisor: Prof. Zheng-Jun Zha

Completion date: November 28, 2025

中国知网 https://www.cnki.net

创新性说明

图像复原是计算机视觉领域中的基础研究方向。本文面向图像复原提出自适应表征学习的创新方法。针对退化类型多样且缺乏精确标注信息导致的退化类型难以识别问题，本文提出了一种基于无监督对比学习的退化感知机制，通过在特征空间构建相似性约束，引导模型自动聚合同类退化特征，实现对多样退化的自适应感知与区分，从而提升图像复原模型的针对性复原能力。针对全局信息捕获成本高问题，设计了空频域协同的全局与局部内容表征学习方法，结合频域的长程依赖建模与空域的局部细节感知，并通过自适应权重融合实现多尺度信息的有效聚合，从而提升图像复原模型对全局结构与局部细节的协调表征能力。针对退化特征与清晰内容特征耦合导致的表征干扰问题，构建了模块化分离的网络结构，并引入方向约束优化策略，引导模型在特征层面对退化去除与清晰内容重建进行解耦，有效提升模型在多变退化与清晰内容之间的适配能力与复原性能。部分研究成果发表于 ECCV、AAAI、TNNLS 等国际会议和期刊。

中国知网 https://www.cnki.net

摘要

图像在采集、存储与传输过程中，常因外部因素的干扰而引入退化，导致其清晰度与内容完整性受损。退化不仅降低了图像的视觉质量，还会影响依赖视觉信息的后续计算机视觉任务准确性，从而构成安全隐患。因此，能够提升视觉质量并保障后续任务性能的图像复原技术，具有重要的研究意义。有效的图像复原模型需具备消除退化与重构受损图像内容的能力。然而，实际场景中退化的多样性、内容的复杂性以及两者的高度耦合，对图像复原模型的自适应能力提出多方面挑战，具体而言：（1）退化类型的多样性要求图像复原模型具备差异化的退化去除能力，然而，退化类型标签难以精确标注，导致模型缺乏可靠的监督信息以区分不同退化，从而对模型的自适应退化感知与退化表征提取能力提出挑战；（2）自然图像细节纹理丰富且空间结构复杂，重构受损内容要求图像复原模型同时感知局部细节与全局结构，然而，现有方法受限于计算复杂度，难以有效感知全局信息，从而对模型的自适应多尺度内容表征的感知与提取能力提出挑战；（3）在退化层面，多样性退化需差异化去除，在内容层面，自然清晰图像共享一致的底层分布规律，允许一致性重构，图像复原模型需同时适配多变因素与不变分布，从而对模型的自适应表征解耦能力提出挑战。

针对上述挑战，本文以特征提取为基础，以网络框架为依托，以损失函数为约束，展开如下研究：

1. 针对退化类型多样且缺乏精确退化类型监督标签导致的退化感知困难问题，提出了基于无监督对比学习的自适应退化表征学习方法。具体而言，该方法通过构建正负样本对，以相同退化类型的图像块为正样本、不同退化类型的图像块为负样本，并在特征空间中约束正样本相互靠近、负样本相互远离，以此自动聚合同类退化特征，从而实现在无显式退化标签条件下，模型对多样性退化的自适应感知与区分。实验表明，该方法学习到的退化表征具有判别性，并在训练阶段未见的退化类型上表现出良好泛化性，有效提升模型差异化退化去除能力，从而提升图像复原整体性能。

2. 针对全局信息捕获计算复杂度高导致的多尺度内容表征感知困难问题，提出了基于空频域协同的自适应内容表征学习方法。具体而言，该方法设计了一种空频域协同的全局与局部表征学习策略，在频域基于线性复杂度的 Mamba 建模长距离依赖，并结合从低频到高频的扫描策略构建符合 Mamba 自回归特性的因果序列输入。同时，在空域基于卷积网络提取局部细节。最后，通过动态学习权重对全局与局部表征进行加权融合，从而实现模型对多尺度内容表征的自适应感知与提取。实验表明，该方法有效兼顾图像内容的结构一致性与细节保真

中国知网 https://www.cnki.net

度，从而提升图像复原的整体性能。

3. 针对退化去除多样性与图像清晰重构一致性并存导致的多变因素与不变分布耦合问题，提出了框架设计与优化约束相结合的自适应解耦表征学习方法。具体而言，该方法首先设计了模块化分离的网络框架，基于对特征通道统计特性的分析，将退化去除与内容重构在特征层面显式解耦为两个子模块。其中，退化去除模块基于退化的通道相关性，致力于消除多变性退化，内容重构模块基于内容的通道无关性，专注于重建不变性清晰内容。同时，在优化层面利用多变性与不变性的相对关系构建方向约束，将模型的参数更新限制在“消除多变退化、回归不变清晰内容”的正确复原方向上，从而实现对表征的自适应解耦，并有效收缩解空间。实验表明，该方法促使模型同时适配退化的多变因素与清晰内容的不变规律，从而提升图像复原的整体性能。

综上，本文围绕面向图像复原的自适应表征学习方法展开研究，系统分析了退化的多样性、内容的复杂性以及两者的耦合性所带来的挑战，并提出相应解决方法。在多个图像复原任务上的实验结果验证了所提方法的有效性，为后续基于自适应学习的图像复原研究提供了新的视角与思路。

关键词：图像复原，自适应表征学习，特征提取，框架设计，优化约束

中国知网 https://www.cnki.net

ABSTRACT

In the processes of image acquisition, storage, and transmission, external interferences often introduce degradation, resulting in reduced image sharpness and compromised content integrity. Such degradation not only diminishes the visual quality of images but also affects the accuracy of subsequent computer vision tasks that rely on visual information, thereby posing potential security risks. Therefore, image restoration techniques capable of enhancing visual quality and safeguarding the performance of downstream tasks hold significant research value.

An effective image restoration model must possess the ability to eliminate degradation and reconstruct impaired image content. However, in real-world scenarios, the diversity of degradations, the complexity of content, and the strong coupling between them impose multiple challenges on the adaptive capability of image restoration models. Specifically: (1) The diversity of degradation types requires image restoration models to have differentiated degradation removal capabilities. However, degradation type labels are difficult to annotate precisely, causing models to lack reliable supervision for distinguishing between different degradations. This poses challenges to the model's adaptive degradation perception and degradation representation extraction capabilities. (2) Natural images contain rich textures and complex spatial structures. Reconstructing damaged content requires image restoration models to simultaneously perceive local details and global structures. However, existing methods are limited by computational complexity, making it difficult to effectively perceive global information. This challenges the model's adaptive perception and extraction of multi-scale content representations. (3) At the degradation level, diverse degradations require differentiated removal, whereas at the content level, natural clear images share consistent underlying distribution patterns that allow consistent reconstruction. Therefore, image restoration models need to adapt to both variable factors and invariant distributions, posing challenges to the model's adaptive representation disentanglement capability.

In response to the above challenges, this dissertation develops the following studies, grounded in feature extraction, supported by network architecture, and constrained by loss functions:

1. To address the challenge of degradation perception caused by the diversity of degradation types and the lack of precise supervisory labels for degradation types, this dissertation proposes an adaptive degradation representation learning method based on

中国知网 https://www.cnki.net

unsupervised contrastive learning. Specifically, the method constructs positive and negative sample pairs by taking image patches of the same degradation type as positive samples and those of different degradation types as negative samples. By constraining positive samples to be close to each other and negative samples to be far apart in the feature space, this approach automatically clusters similar degradation features. In this way, it enables the model to achieve adaptive perception and discrimination of diverse degradations under the absence of explicit degradation labels. Experimental results show that the learned degradation representations are discriminative and exhibit good generalization to unseen degradation types during training, effectively enhancing the model's capability for differentiated degradation removal and improving the overall performance of image restoration.

2. To address the difficulty in perceiving multi-scale content representations caused by the high computational complexity of global information capture, this dissertation proposes an adaptive content representation learning method based on spatial–frequency domain collaboration. Specifically, the method designs a spatial–frequency collaborative strategy for joint global and local representation learning. In the frequency domain, long-range dependencies are modeled using a linear-complexity Mamba framework, and a scanning strategy progressing from low to high frequencies is applied to construct causal sequence inputs that conform to the autoregressive characteristics of Mamba. Meanwhile, in the spatial domain, convolutional networks are utilized to extract local details. Finally, the method dynamically learns weighting coefficients to fuse global and local representations, thereby realizing adaptive perception and extraction of multi-scale content representations. Experimental results show that this method effectively maintains structural consistency and detail fidelity in image content, thus improving the overall performance of image restoration.

3. To address the coupling problem between variable factors and invariant distributions caused by the coexistence of diverse degradation removal and consistent image reconstruction, this dissertation proposes an adaptive disentangled representation learning method that integrates framework design with optimization constraints. Specifically, the method first designs a modularly separated network architecture. Based on the statistical characteristics of feature channels, degradation removal and content reconstruction are explicitly disentangled at the feature level into two submodules. The degradation removal submodule focuses on eliminating variable degradations based on the channel correlation of degradation features, while the content reconstruction submodule concentrates on restoring invariant clear content based on the channel independence

中国知网 https://www.cnki.net

of content features. Meanwhile, at the optimization level, a directional constraint is constructed by leveraging the relative relationship between variable and invariant components, restricting parameter updates to the correct restoration direction—eliminating variable degradations and regressing toward invariant clear content. This enables adaptive disentanglement of representations and effectively narrows the solution space. Experimental results show that this method facilitates the model's simultaneous adaptation to variable degradation factors and invariant regularities of clear content, thereby improving the overall performance of image restoration.

In summary, this dissertation conducts research on adaptive representation learning methods for image restoration. It systematically analyzes the challenges arising from the diversity of degradations, the complexity of image content, and the coupling between them, and proposes corresponding solutions. Experimental results on multiple image restoration tasks verify the effectiveness of the proposed methods, providing new perspectives and insights for subsequent research on adaptive learning–based image restoration.

KEY WORDS: Image Restoration, Adaptive Representation Learning, Feature Extraction, Framework Design, Optimization Constraint

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 关键问题及挑战.....4
1.2.1 退化多样性.....5
1.2.2 内容复杂性.....6
1.2.3 内容-退化耦合性.....6
1.3 研究内容与创新点.....7
1.3.1 面向退化多样性的自适应退化表征学习方法.....7
1.3.2 面向内容复杂性的自适应内容表征学习方法.....8
1.3.3 面向内容-退化耦合性的自适应解耦表征学习方法.....9
1.4 本文结构安排.....9
第 2 章 相关知识概述.....12
2.1 退化图像成因与数据集介绍.....12
2.1.1 退化图像成因.....12
2.1.2 数据集介绍.....15
2.2 研究现状与不足.....20
2.2.1 研究现状.....21
2.2.2 现有工作不足.....27
2.3 图像复原评价准则.....28
2.3.1 定量评价.....28
2.3.2 定性评价.....29
2.4 本章小结.....29
第 3 章 面向退化多样性的自适应退化表征学习方法.....30
3.1 引言.....30
3.2 背景知识.....33
3.2.1 对比表示学习.....33
3.2.2 动量对比学习.....33
3.2.3 可逆网络.....34
3.3 方法介绍.....35
3.3.1 基于无监督对比学习的自适应退化表征学习.....35
3.3.2 基于退化表征引导的复原解码器.....36
3.3.3 损失函数.....38
3.4 实验与分析.....38
3.4.1 实验细节.....38

中国知网 https://www.cnki.net

3.4.2 实验结果.....40
3.4.3 方法分析.....43
3.4.4 消融实验.....47
3.4.5 局限性分析.....49
3.5 本章小结.....49
第 4 章 面向内容复杂性的自适应内容表征学习方法.....50
4.1 引言.....51
4.2 背景知识.....54
4.2.1 图像离散余弦变换.....54
4.2.2 状态空间模型.....54
4.3 方法介绍.....55
4.3.1 基于空频域结合的自适应内容表征学习.....55
4.3.2 基于频域的全局内容表征学习.....56
4.3.3 尺度自适应的频域表征学习.....58
4.3.4 基于空域的局部内容表征学习.....59
4.3.5 损失函数.....60
4.4 实验与分析.....61
4.4.1 实验细节.....62
4.4.2 实验结果.....64
4.4.3 方法分析.....65
4.4.4 消融实验.....69
4.4.5 局限性分析.....72
4.5 本章小结.....72
第 5 章 面向内容-退化耦合性的自适应解耦表征学习方法.....73
5.1 引言.....73
5.2 方法介绍.....75
5.2.1 退化去除模块.....76
5.2.2 内容重构模块.....77
5.2.3 退化映射损失函数.....78
5.3 实验与分析.....79
5.3.1 实验细节.....79
5.3.2 实验结果.....79
5.3.3 方法分析.....84
5.3.4 消融实验.....90
5.3.5 局限性分析.....92
5.4 本章小结.....93
第 6 章 总结与展望.....94
6.1 工作总结.....94

中国知网 https://www.cnki.net

6.2 研究展望.....95
参考文献.....98

中国知网 https://www.cnki.net

插图清单

图 1.1 成像设备的发展 …… 1
图 1.2 数字图像对个人生活及数字化社会均有关键影响 …… 1
图 1.3 数字图像的生命周期 …… 2
图 1.4 数字图像在采集、存储与传输环节均可能面临退化干扰 …… 2
图 1.5 模型驱动与数据驱动的图像复原方法 …… 3
图 1.6 图像复原面临的问题 …… 4
图 1.7 图像在采集、存储与传输环节产生的退化均具有多样性 …… 5
图 1.8 图像内部细节纹理丰富且空间结构复杂 …… 6
图 1.9 不同退化下图像的复原路径方向存在差异 …… 7
图 1.10 本文主要研究内容 …… 8
图 1.11 本文结构安排 …… 10

图 2.1 DIV2K 和 Flickr2K 数据集展示 …… 18
图 2.2 恶劣天气图像数据集展示 …… 19
图 2.3 JPEG 压缩图像测试数据集展示 …… 19
图 2.4 雨-雾-噪声图像测试数据集展示 …… 20
图 2.5 退化图像与其对应的清晰图像展示 …… 20
图 2.6 基于自适应学习的图像复原模型现有方法举例 …… 26
图 2.7 基于自适应学习的图像复原模型需要具备的能力 …… 27

图 3.1 图像的退化类型难以通过监督学习区分 …… 31
图 3.2 退化表征编码器 …… 32
图 3.3 DRNet 模型框架图 …… 35
图 3.4 多尺度信息无损融合模块 …… 37
图 3.5 DRNet 在 Raindrop 数据集与其他方法可视化对比 …… 40
图 3.6 DRNet 在 LIVE1 数据集与其他方法可视化对比 …… 42
图 3.7 退化表征编码器在 JPEG 压缩图像的 t-SNE 可视化 …… 45
图 3.8 退化表征编码器在恶劣天气图像的 t-SNE 可视化 …… 45
图 3.9 退化表征编码器泛化能力的 t-SNE 可视化 …… 46
图 3.10 退化表征编码器多层特征的 t-SNE 可视化 …… 46
图 3.11 退化表征编码器对于 JPEG 压缩图像的 Grad-CAM 可视化 …… 46
图 3.12 退化表征编码器对于恶劣天气图像的 Grad-CAM 可视化 …… 47
图 3.13 退化表征编码器特征层可视化 …… 48

中国知网 https://www.cnki.net

图 3.14 模型参数量比较 49

图 4.1 卷积的局限性 51
图 4.2 Transformer 的局限性 52
图 4.3 空间域 Mamba 的局限性 53
图 4.4 DCTMamba 模型框架图 56
图 4.5 全局状态空间模块 57
图 4.6 尺度自适应的频域表征学习 58
图 4.7 DCTMamba 在 Raindrop 数据集与其他方法可视化对比 61
图 4.8 DCTMamba 在 realsnow 数据集与其他方法可视化对比 62
图 4.9 DCTMamba 在 JPEG 图像测试数据集与其他方法可视化对比 64
图 4.10 二维图像的空间域非因果性与各向异性 66
图 4.11 图像 DCT 变换及其分段与重构示意图 66
图 4.12 不同尺寸图像绝对索引 67
图 4.13 不同尺寸图像相对索引 68
图 4.14 DCTMamba 中全局状态空间模块和局部残差块的特征图可视化 70
图 4.15 不同层 GLB 模块中 scale 参数分布图 71

图 5.1 图像复原中退化去除具有差异性、内容重构具有一致性 74
图 5.2 模型特征的通道统计特性 75
图 5.3 DDCNet 模型框架图 76
图 5.4 DDCNet 在 Outdoor-Rain 数据集与其他方法可视化对比 80
图 5.5 DDCNet 在 Raindrop 数据集与其他方法可视化对比 82
图 5.6 DDCNet 在 realistic 数据集与其他方法可视化对比 83
图 5.7 特征通道统计特性 85
图 5.8 退化信息主要位于幅值的定性和定量分析 86
图 5.9 不同恶劣天气与对应清晰图像的分布统计特性 87
图 5.10 恶劣天气与其对应清晰图像数据集的频域幅值统计图 88
图 5.11 退化图像到清晰图像的距离与方向 88
图 5.12 方向约束型损失函数 89
图 5.13 退化映射损失函数不足分析 93

中国知网 https://www.cnki.net

附表清单

表 2.1 本文使用训练数据集统计 17
表 2.2 本文使用测试数据集统计 17
表 2.3 本文不同实验配置中使用的数据集详情 18

表 3.1 DRNet 在 Outdoor-Rain 数据集的定量指标 39
表 3.2 DRNet 在 Raindrop 数据集的定量指标 39
表 3.3 DRNet 在 SnowTest100K-L 数据集的定量指标 40
表 3.4 DRNet 在 JPEG 图像复原的定量指标 41
表 3.5 DRNet 在雨-雾-噪声图像测试数据集的定量指标 42
表 3.6 DRNet 消融实验 48

表 4.1 DCTMamba 在 Outdoor-Rain 数据集的定量指标 60
表 4.2 DCTMamba 在 Raindrop 数据集的定量指标 60
表 4.3 DCTMamba 在 SnowTest100K-L 数据集的定量指标 61
表 4.4 DCTMamba 在 JPEG 图像测试数据集的定量指标 63
表 4.5 DCTMamba 在雨-雾-噪声图像测试数据集的定量指标 65
表 4.6 DCTMamba 消融实验 69
表 4.7 不同方法的参数量与计算复杂度对比 71

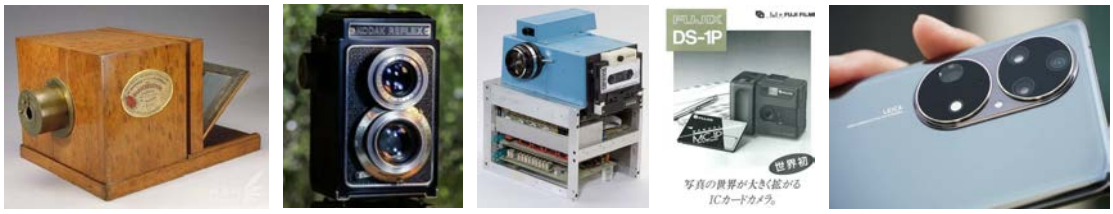
表 5.1 DDCNet 在 Outdoor-Rain 与 Rainidrop 数据集的定量指标 79
表 5.2 DDCNet 在 SnowTest100K-L 数据集的定量指标 80
表 5.3 DDCNet 在雨-雾-噪声图像测试数据集的定量指标 80
表 5.4 DDCNet 在 JPEG 图像测试数据集的定量指标 81
表 5.5 DDCNet 在 Outdoor-Rain 与 Rainidrop 数据集的感知指标 83
表 5.6 退化去除模块消融实验 90
表 5.7 内容重构模块消融实验 91
表 5.8 不同损失函数组合的比较实验 91
表 5.9 退化去除和内容重构模块顺序 91
表 5.10 模块数量 92
表 5.11 模型参数与计算复杂度对比 92

中国知网 https://www.cnki.net

第 1 章　绪论

1.1　研究背景及意义

随着成像技术的快速发展和成像设备的广泛普及，数字图像已成为推动信息社会发展的重要力量。如图1.1所示，1839 年，达盖尔银版摄影法的公开被视为现代摄影发展早期的重要里程碑，其促进了摄影技术的社会传播，并推动了早期商用照相机的生产与销售。之后的成像设备经历了从胶片到数码，再到智能终端的几次重大飞跃。19 世纪末，乔治·伊士曼推出卷筒胶片相机柯达，极大地简化了消费者的摄影过程。20 世纪，数字成像技术逐步兴起，1975 年，柯达公司的工程师史蒂文·萨松研制出世界上第一台独立便携式的数字静态相机原型。1988 年，富士展出的 FUJIX DS-1P 数字相机（原型机）是世界上第一台将数字图像记录在静态随机存取存储器上的相机，其设计理念为现代数字相机的架构蓝图奠定了基础。随后，数码相机快速发展，其极大提升了成像效率，推动数字成像走向实用化。



达盖尔相机　柯达胶片机　柯达数字相机　FUJIX DS-1P数字相机　智能设备

图 1.1　成像设备的发展

进入 21 世纪以来，智能手机的普及让高清摄像头成为日常标配，全球每天拍摄和分享的照片数量爆发式增长，无论是旅游打卡还是美食记录，数字图像已深度融入大众的生活场景，极大丰富了个人体验和社会交流形式。于此同时，如图1.2所示，随着安防监控[1-6]和智慧城市[7-12]建设推进，大量摄像头部署于街道、公园、广场等户外环境，为公共安全[13-18]提供保障。自动驾驶技术[19-21]的发展也进一步推动车载摄像头的实际应用。作为人工智能、计算机视觉及各类数据分析系统[22-28]的重要输入模态，图像信息已成为工业领域中自动化与智能化



图 1.2　数字图像对个人生活及数字化社会均有关键影响

中国知网　https://www.cnki.net

系统不可或缺的数据来源[29-30]。这些趋势意味着，数字成像的可靠性和完整性已经成为智能系统能否稳定运行的关键要素之一。

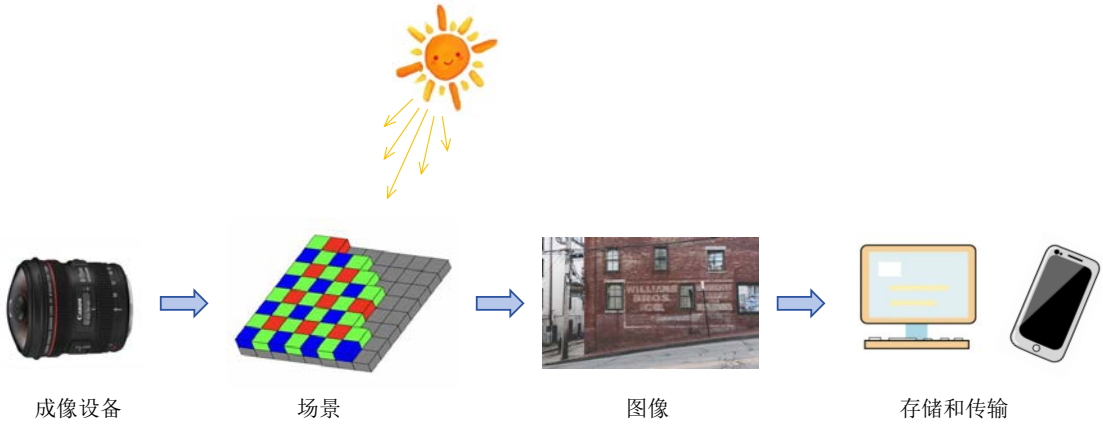


图 1.3　数字图像的生命周期

如图1.3所示，数字图像是由成像系统接收并记录来自场景的光信号（包括反射、透射等），经由光学成像与光电转换，再经过采样量化与数字处理生成可用于分析与应用的图像数据，随后通过存储与传输环节完成图像的保存与传播。然而，如图1.4所示，数字图像在采集、存储与传输环节均可能出现质量退化。户外采集图像时，雨、雾和雪[31-33]等天气会扰乱光的传播，空气中的水滴、雾气、雪花和悬浮颗粒会对光线产生散射与吸收，使信号减弱并发生偏折，进而在图像上产生退化，导致拍摄到的画面出现色彩失真和细节缺失等问题。另一方面，在像素信号的读出与数字化过程中，相机电路会产生小幅度的电子扰动，这些扰动会叠加到图像中，形成图像噪声。随后，为提高存储与传输效率，网络与应用平台往往对图像采用有损压缩（如 JPEG 有损压缩），该操作虽然能降低带宽与容量开销，但不可避免地带来块状伪影、振铃效应以及细节丢失。这些退化图像不仅影响了观赏效果，使画面缺乏视觉美感，同时也给依赖于对图像的理解与智能分析的应用和任务型场景带来挑战。例如，在自动驾驶[34-39]场景下，图像退化导致车道线或行人的识别变得困难，增加行车安全风险；而在安防监控中，图像细节的丢失可能造成异常事件识别的不准确，影响关键证据的留存。此外，在工业质检[40-41]领域，图像可能因为噪声干扰导致缺陷检测不准确，影响生产线的

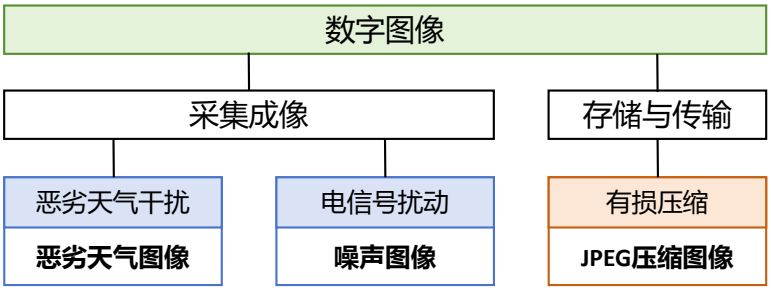


图 1.4　数字图像在采集、存储与传输环节均可能面临退化干扰

中国知网　https://www.cnki.net

智能判别效率与产品质量管控。因此，图像的退化问题已成为制约相关工业系统性能和安全性的重要瓶颈，图像复原成为计算机视觉研究领域的基础热门方向。

图像复原旨在从退化图像中重建高质量的清晰图像。早期的 ROF 全变分模型[42]以各向同性 TV 正则配合二范数数据保真，为后续以先验正则约束进行复原的方法提供了重要范式。基于这一思想，研究者们不断探索更强大的图像先验。随后，基于非局部自相似的非局部均值（Non-Local Means, NLM）[43]以及分块匹配与三维协同滤波的 BM3D[44]在高斯去噪任务上取得了出色的效果。针对 JPEG 有损压缩所引入的块效应与振铃伪影，研究者在 DCT 域提出结合量化一致性约束的重建策略，并发展出形状自适应 DCT（Shape Adaptive-DCT, SA-DCT）[45]等协同滤波方法，同时与稀疏表示和字典学习[46-48]相结合以缓解伪影问题。在恶劣天气图像复原方面，早在 19 世纪末至 20 世纪初，瑞利散射[49]与米散射[50]分别解释了天空的蓝色以及雾、霾等较大颗粒物对光线的散射效应，为后续研究奠定了物理基础。随后，研究者开始对这些过程进行可计算建模，如 Klassen[51]与 Nishita[52]提出的早期大气散射渲染算法，为基于物理的大气退化建模提供了理论与计算基础。将这些物理模型用于图像复原的系统化探索以 Narasimhan 和 Nayar[32]的工作为代表，他们于 2000 年代初开展了关于天气对视觉影响的研究，并尝试利用不同天气条件下拍摄的多张图像来恢复场景的三维结构与清晰外观，推动了基于物理模型的图像复原方法的系统化研究。

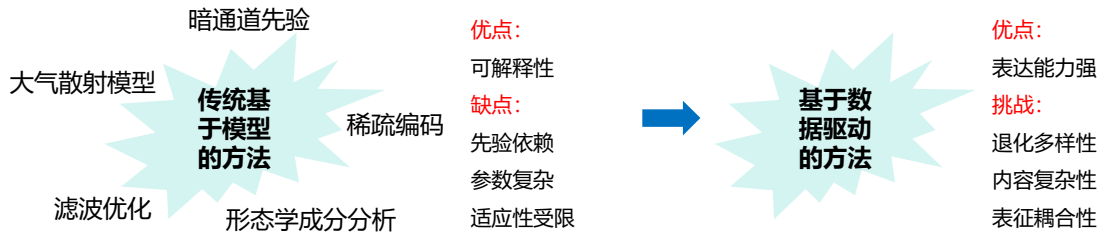


图 1.5　模型驱动与数据驱动的图像复原方法

物理先验方法[53-55]由于自身的固有限制，其局限性日益凸显。这类方法通常依赖于对退化场景的理想化假设，对先验参数获取的依赖也使得其在缺乏精确先验信息时性能明显下降。如图 1.5所示，鉴于上述不足，学术界和工业界逐步将关注点转向数据驱动的深度学习方法。自 2010 年以来，深度学习技术[56-62]在计算机视觉领域实现了突破，研究者们将卷积神经网络等[63-66]模型引入到图像复原任务，弱化对手工先验和固定参数的依赖，而是通过对海量数据的训练和学习，建模退化图像与清晰图像之间的复杂映射关系，大幅提升了图像复原效果。

然而，图像在采集与后续的存储和传输环节产生的退化均具有多样性，在采集环节中，外部成像环境（如雨、雾、雪等）因物理机理不同，对成像造成的遮挡与对比度下降各不相同。噪声的分布与强度也会随成像设备、ISO 与曝光

中国知网　https://www.cnki.net

条件而变化。在存储与传输环节，以 JPEG 有损压缩为例，不同的压缩质量因子（Quality Factor，QF）会导致退化程度与伪影类型（如块效应、振铃）的显著差异。与之对应，早期深度学习方法常为不同退化程度单独训练专用网络：恶劣天气图像复原模型分别针对雨[67]、雾[68]、雪[69]单独训练；噪声图像复原[70-71]中针对不同噪声方差训练独立模型；JPEG 压缩图像复原[72-73]则依据 QF 训练不同模型。这种退化专属的模式虽然提升了图像复原的针对性，但也带来诸多限制，模型数量随退化类型细分而增长，导致存储成本提高、模型冗余加剧。同时，专用模型难以适应复杂、动态的退化情形。并且，这类方法往往需要依赖人工判断或外部分类器选择具体模型，增加部署复杂度、降低自动化程度，与工业应用对灵活性与稳健性的要求存在偏差。因此，面向多样化退化的处理范式[74-77]成为了新的研究热点。然而，多样化并不意味着无差别的混合学习，各退化的内在差异显著，且退化因素与清晰图像内容高度耦合，导致表征干扰与优化冲突。基于此，模型需要具备对差异性与一致性表征的感知能力并有效解耦，为实现这一目标，本文面向图像复原的自适应表征学习方法展开研究，探讨了其中的关键挑战并提出了相应的解决方法。

1.2　关键问题及挑战

如上节所述，本文的研究围绕基于自适应解耦建模的图像复原方法展开。本节介绍研究中存在的问题与挑战。

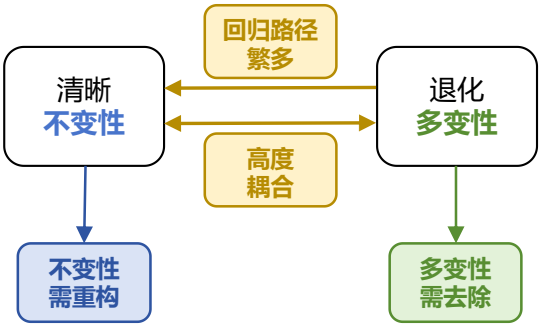


图 1.6　图像复原面临的问题

自然清晰图像虽具备丰富的细节与复杂的结构，但在底层统计上呈现出高度一致的模式，体现出稳定的“不变性”特征。与之相对，退化图像是清晰图像引入退化信息所导致的，其退化类型繁杂多样，表现为显著的“多变性”，并且退化成分与清晰图像内容高度耦合。如图 1.6所示，图像复原的本质，是将退化图像从“多变性”引导回清晰图像的“不变性”，因此，模型需要消除多变性（即去除退化信息），并回归不变性（即重构清晰图像的细节与结构）。在这个过程中，无论是多变性的感知，还是不变性的表征与重构，以及回归路径的约束，都

中国知网　https://www.cnki.net

各自蕴含挑战，而二者在相互作用中的耦合更进一步叠加复杂性，下面详细介绍这些挑战。

1.2.1　退化多样性

如前文所述，图像在采集与后续存储与传输环节产生的退化均具有多样性，如图 1.7所示。在户外成像环境中，退化多样性源自于各类天气现象独特的物理成因。例如，雨天时，密集或稀疏的雨条纹在曝光过程中叠加于场景，形成具有方向性的条纹结构，既遮挡物体细节，又因散射效应引发局部模糊与亮度非均匀。雾霾环境下，空气中大量微小颗粒与光线发生强散射效应，显著降低了图像的整体对比度和色彩饱和度，远处目标往往变得模糊难辨，并且雾天图像的退化呈现出明显的全局特性。雪天图像中的退化主要表现为多尺度、不规则分布的雪粒，并形成局部遮挡区域，导致目标边缘缺失和空间结构破坏，比起雨条纹和雨滴，雪粒的分布更加随机，形态更加复杂。在图像存储与传输中常用的有损压缩 JPEG 压缩中，不同的压缩质量因子（Quality Factor，QF）同样会带来不同的退化效应：当 QF 接近 100 时压缩伪影微不可见；而当 QF 接近 0 时，图像的大量信息会被量化抹除，块状伪影和颜色失真效应显著。



图 1.7　图像在采集、存储与传输环节产生的退化均具有多样性

注：QF 指的是 JPEG 压缩的质量因子（Quality Factor），其数值越小，压缩率越高。

这些退化差异不仅在视觉上各具独特表现，也会直接影响模型对图像的理解与复原。具体而言，模型面对退化类型与其表现形式的显著差异，需采用差异化的退化去除策略。然而，语义标签（如“雨”、“高压缩等级”）与视觉表征之间存在鸿沟，难以直接作为可学习的监督信号。同时，退化类型的视觉标签也难以准确标注。因此，在缺乏显式退化标签的前提下，模型如何自适应地感知退化类型并提取退化表征，是一个亟待解决的问题。

中国知网　https://www.cnki.net

1.2.2　内容复杂性

除了退化的多样性之外，实际场景中图像内容的复杂性同样对复原模型提出了挑战。自然图像包含丰富的细节纹理与复杂的空间结构关系，内容重构的本质是一个缺失信息补全的过程，要求模型同时感知邻域信息与全局关系，以实现精细细节重建，并确保物体间的空间关联与场景一致性。

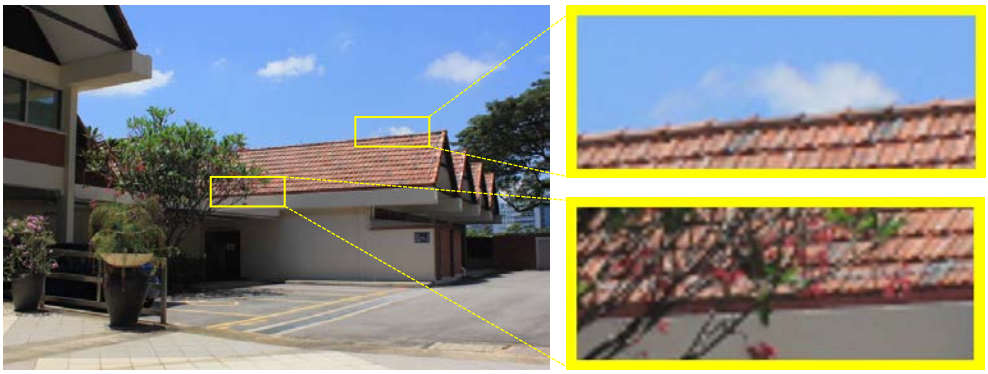


图 1.8　图像内部细节纹理丰富且空间结构复杂

以包含天空、房屋与树木的图像（图 1.8）为例，图中屋顶纹理细密，树木枝干纵横交错，此类细节的修复依赖对局部信息的有效捕获与建模，以精确还原纹理。与此同时，全局信息通过建模长距离依赖与整体布局，约束重建过程，确保场景结构一致性与合理性。比如，在云朵与屋顶的交界区域，只能感知局部信息的网络仅依据附近的颜色和纹理对损坏区域进行补全，而无法利用全局结构关系进行空间关系判断，这可能导致网络错误地将云朵纹理延伸并覆盖屋顶。而能够感知全局信息的网络则凭借对房屋与云朵间相对空间关系的理解，有效避免此类现象的发生。同理，在图像左侧，树枝与屋檐的交汇区域细节丰富，若无对全局结构关系的理解，复原结果可能会出现屋檐错误覆盖树枝的情况，具备全局关系建模能力的网络则能够准确还原二者的空间层次关系，使复原结果更加合理。因此，高质量的图像复原依赖于局部与全局信息的协同，但由于 Transformer 模型在全局建模上的计算复杂度过高，现有方法普遍采用窗口划分机制，由此导致跨窗口交互受限，从而限制了全局信息感知能力。因此，有效的全局与局部信息自适应协同感知是一个亟待解决的问题。

1.2.3　内容-退化耦合性

图像复原需要去除类型各异的退化，并重构因此受损的内容。这个过程中存在多变性与不变性的耦合，具体而言，一方面，面对多样化的退化类型，模型需要采用差异化的去除策略。另一方面，从宏观层面，自然图像在统计特性与结构分布上呈现出高度相似性，这种跨图像的共性使得模型能够以一致的方式实现对不同图像内容的有效重构。同时，如图1.9所示，多样化退化类型朝向清晰图

中国知网　https://www.cnki.net

像的优化方向存在差异。因此，图像复原模型必须同时兼顾多变因素与不变分布，这要求模型能够对表征施加约束以减少干扰，因此，如何实现自适应的表征解耦，这同样是一个亟待解决的问题。

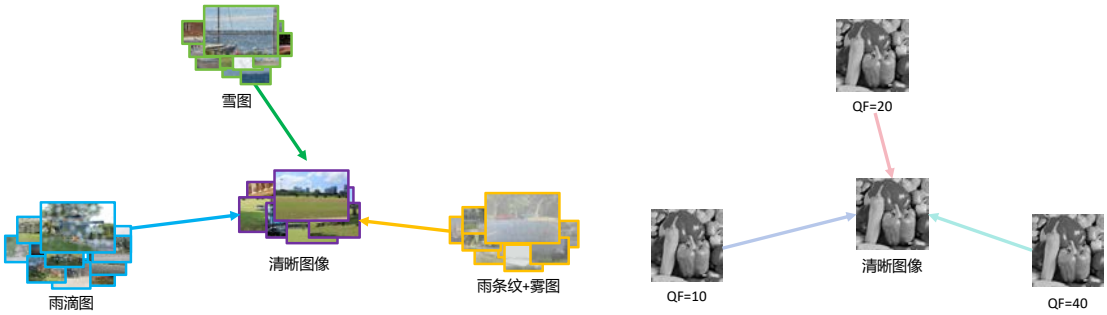


图 1.9　不同退化下图像的复原路径方向存在差异

注：QF 指的是 JPEG 压缩的质量因子（Quality Factor），其数值越小，压缩率越高。

1.3　研究内容与创新点

本文聚焦于自适应表征学习的图像复原方法，并在节 1.2中系统分析了该领域面临的关键挑战，即退化多样性、内容复杂性与内容-退化耦合性。具体而言，退化具有多样性且显式退化标签难以获取，对模型的自适应退化表征学习能力提出挑战；内容复杂需要全局与局部协同感知，然而现有全局建模方法计算复杂度高，对模型的自适应内容表征学习能力提出挑战；多变性退化与不变性内容分布的耦合导致特征干扰，同时多变性回归不变性路径繁多，对模型的自适应表征解耦能力提出挑战。针对上述挑战，本文从特征提取、框架设计与优化约束的角度提出了相应的解决方法，并在多项图像复原任务中验证其有效性。总体研究框架如图 1.10所示，接下来详细介绍各项研究内容。

1.3.1　面向退化多样性的自适应退化表征学习方法

当图像复原模型面临多种退化时，只有具备对不同退化类型的感知与区分能力，才能依据具体退化情形选择匹配的复原策略，因此，退化感知能力是图像复原模型的前提。然而，如节 1.2.1所述，能够被模型识别的显式退化类型标签难以精确标注，基于此，本文首先聚焦于在无显式退化标签的条件下，如何使模型自适应地感知退化类型。

具体而言，本文提出了一种基于无监督对比学习的自适应退化表征学习方法。该方法首先构建退化表征编码器，并同时输入多张不同退化类型的图像。随后，从这些退化图像中裁剪图像块以构建正负样本对，来自同一张图像的不同图像块视为相同退化，作为正样本，而来自不同图像的图像块则视为不同退化，作

中国知网　https://www.cnki.net

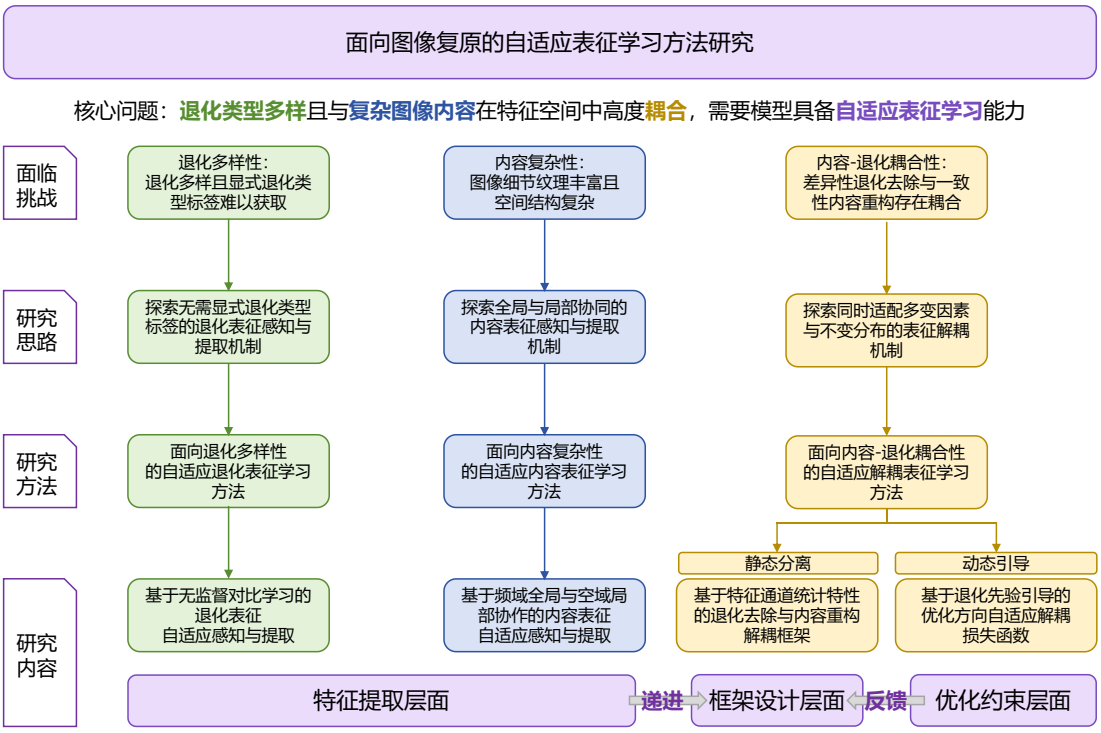


图 1.10　本文主要研究内容

为负样本。经退化表征编码器提取特征后，在特征空间中约束相同退化类型的图像块特征相互靠近，不同退化类型的图像块特征相互远离，以此避免依赖显式的退化类型标签，转而挖掘退化图像自身所蕴含的退化信息，从而实现自适应感知退化类型，并提取具有判别性的退化表征。最后，以一种信息无损的方式将提取到的判别性退化表征融入图像复原解码器，指导网络对多样退化类型图像进行针对性复原。实验结果表明，该方法在多个数据集上实现了不同退化类型在表征空间中的有效分离，同时在未参与训练的退化类型上也展现出良好的泛化能力。此外，在图像复原任务中的性能提升也进一步证实了所提方法的有效性。

1.3.2　面向内容复杂性的自适应内容表征学习方法

内容是图像的核心承载，其清晰重构是图像复原的根本目标，因此，内容感知能力是图像复原模型的基础保障。然而，如节 1.2.2所述，现有方法在全局信息感知方面仍存在不足。基于此，本文的第二项研究聚焦于如何自适应协同感知全局与局部内容信息。

具体而言，本文提出了一种空频域协同的自适应内容表征学习方法，其核心思想是基于频域提升全局建模能力，并结合空域加强局部细节刻画。在全局感知方面，基于线性复杂度的 Mamba 架构以建模长程依赖，并结合离散余弦变换（Discrete Cosine Transform, DCT），通过由低频到高频的顺序对特征进行序列化建模，建立符合 Mamba 自回归特性的因果关系：其中低频分量主要反映图像的

中国知网　https://www.cnki.net

整体亮度与结构，高频分量则补充边缘与纹理等细节。此外，为缓解图像尺寸差异而导致的频率基底密度不一致问题，设计了尺度自适应的频率分布归一化方法，以确保不同尺寸下特征表达的一致性。在局部感知方面，基于密集残差卷积网络以增强对纹理与边缘细节的提取。通过上述全局与局部感知过程，分别提取全局依赖表征与局部细节表征。最后，通过动态可学习权重，将全局与局部表征进行加权融合，从而实现多尺度内容的自适应表征学习。在多个图像复原基准数据集上的实验表明，该方法提升了图像复原整体性能，并兼顾细节清晰度与结构一致性。

1.3.3　面向内容-退化耦合性的自适应解耦表征学习方法

退化图像是在清晰图像的基础上引入退化并造成内容受损，因此，退化去除与内容重构共同构成了图像复原任务的关键。然而，如节 1.2.3所述，差异性退化去除与一致性内容重构在特征空间中的耦合导致表征干扰，从而加大了复原难度，基于此，本文第三项研究聚焦于如何自适应解耦表征。

具体而言，本文提出了一种面向内容-退化耦合的自适应解耦表征学习方法。该方法采用静态分离与动态引导相结合的策略。在静态分离层面，设计了模块化分离的网络框架，其核心思想源自一个观察，即图像中的退化与内容在通道统计特性上存在显著差异，其中，退化通常表现为通道相关性，而图像的内容则表现为通道无关性。基于此，将退化去除与内容重构显式分为两个子模块，前者致力于消除通道相关的退化，后者专注于重建通道无关的内容。在动态引导层面，提出了一种方向引导型的优化约束，将退化图像作为先验信息引入到损失函数中，并计算模型预测图像和目标清晰图像相对于退化图像的差值，得到“预测残差”与“目标残差”。通过度量“预测残差”与“目标残差”之间的余弦相似度，该约束确保网络输出与目标复原过程在方向上保持一致，从而指导模型消除多样性退化，并回归到不变性内容，实现了对不同恢复路径的解耦，有效收缩了解空间。实验结果表明，在静态分离与动态引导的协同作用下，该方法促使模型具备自适应解耦表征学习能力，使其能够同时适配退化去除的多样性与内容重构的一致性，从而提升图像复原的整体性能。

1.4　本文结构安排

如前文所述，本文以面向图像复原的自适应表征学习方法作为研究课题，为解决图像复原中存在的退化多样性、内容复杂性以及内容-退化耦合性带来的挑战围绕特征提取、网络框架搭建以及优化约束展开具体研究。本文的组织结构如图 1.11所示。

中国知网　https://www.cnki.net

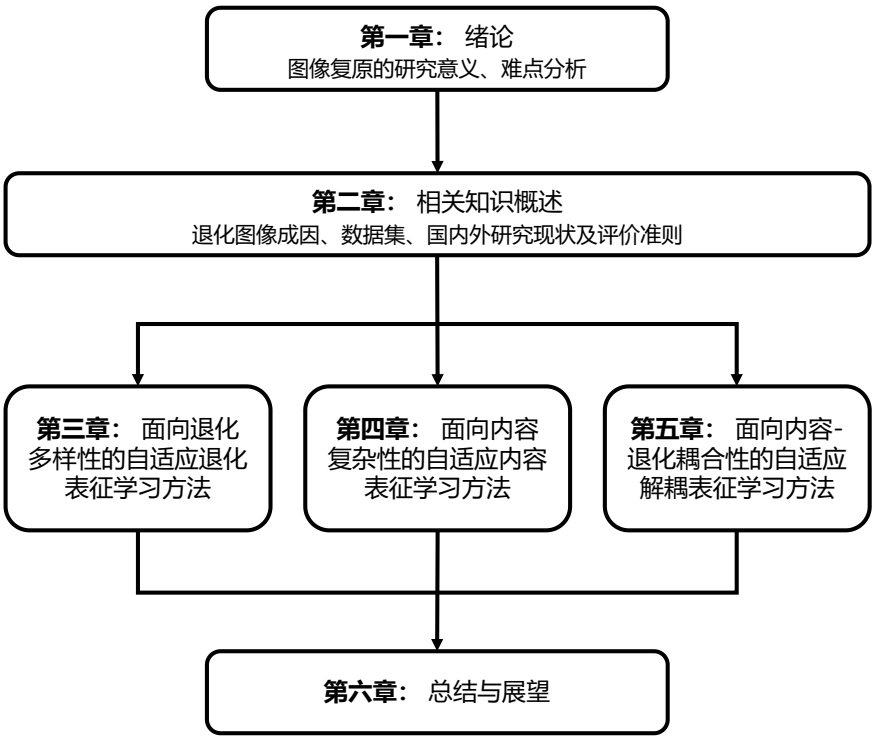


图 1.11　本文结构安排

第一章：绪论

本章介绍了图像复原的研究背景及意义，指出在实际场景中图像退化的多样性、内容的复杂性以及内容-退化之间的耦合性等关键挑战。针对这些问题，引出了本文所研究的自适应表征学习方法。

第二章：相关知识概述

本章首先梳理了与本文任务相关的退化图像成因与对应数据集，随后，介绍了图像复原研究现状并对现有方法的不足进行分析。最后，介绍了图像复原的评价准则。

第三章：面向退化多样性的自适应退化表征学习方法

本章针对图像面临的退化具有多样性问题，提出基于无监督对比学习的自适应退化表征学习方法，实现退化表征的自适应感知与提取，详细介绍了该方法的研究思路与具体实现，并通过实验验证其在图像复原任务上的有效性。

第四章：面向内容复杂性的自适应内容表征学习方法

本章针对图像内容复杂性问题，提出基于空频域结合的自适应内容表征学习方法，克服空间建模局限，提升全局与局部信息的协同感知能力，详细介绍了方法的具体实现流程，并通过实验验证其在图像复原任务上的有效性。

第五章：面向内容-退化耦合性的自适应解耦表征学习方法

本章针对内容-退化耦合性问题，提出自适应解耦表征学习方法，将框架层面的静态分离与优化层面的动态引导相结合，前者实现了退化去除与内容重构

中国知网　https://www.cnki.net

过程的模块化解耦，提升了模型的分工与协作能力；后者通过优化方向的约束，有效引导网络学习更加准确的复原路径。实验结果验证了该方法在提升复原效果方面的有效性。

第六章：总结与展望

本章对全文的研究内容进行了总结，指出了当前工作的不足，并对未来的研究方向进行了分析与展望。

中国知网　https://www.cnki.net

第 2 章　相关知识概述

上一章指出，图像在采集、存储与传输环节均可能受到外部条件的影响而产生退化。为验证所提出的图像复原方法，本文选取了其中具有代表性的几类退化图像，分别是：成像阶段受外部天气环境影响的恶劣天气图像，成像阶段在外部环境与成像电子设备共同作用下产生的噪声图像，以及为减少传输带宽与存储开销而采用 JPEG 有损压缩导致的压缩图像。这几类退化图像均面临退化多样性、内容复杂性以及内容-退化耦合性的挑战，下文依次介绍这些退化图像的成因、常用基准数据集以及针对这些退化图像的相关图像复原研究工作。

2.1　退化图像成因与数据集介绍

图像退化的多样性来源于其成因的差异，为此，本章将依次阐述不同退化的形成原因，并进一步介绍本文在相关实验中所采用的数据集。

2.1.1　退化图像成因

图像退化的多样性源于其对应成因的差异，且在表现形式与影响强弱上各不相同。下面分别介绍。

1. 恶劣天气图像成因

（1） 雨条纹 + 雾图像成因

雨水在下落过程中，在空气动力学力与表面张力作用下发生形变与振荡，其动态非球面结构会引起光线的复杂折射与离焦效应，相机在曝光过程中对这些快速光学变化进行时间积分，最终使得成像结果呈现条纹状退化并伴随整体成像质量下降。早期的雨条纹图像建模将带雨图像简单地视为干净背景与稀疏雨条纹的直接叠加，其数学表达式为：$I_R = I_C + S$，其中 I_R 表示含有雨条纹的图像，I_C 为无雨的背景图像，S 为雨条纹层。这种简单的建模方式虽然便于分析，但过于理想化，忽视了在降雨量较大时，雨水对光线散射与吸收作用引起的能见度下降和对比度减弱。针对这一问题，Li 等人[63]指出，在强降雨环境下，雨图像中除了明显的线性雨条纹外，还普遍存在“面纱效应”，其产生原因是视线路径上大量雨水的累积散射，使图像整体对比度下降、细节模糊，呈现出类似薄雾的视觉效果。因此，Li 等人[63]进一步提出了一个更为完整的强降雨模型，该模型同时考虑了雨条纹和雨积累的影响：

$$I_R = T \odot \left(I_C + \sum_{i=1}^{n} S_i \right) + (1 - T) \odot A, \tag{2.1}$$

中国知网　https://www.cnki.net

其中，I_R 表示雨退化图像，I_C 为无雨的清晰图像，$\sum_{i=1}^{n} S_i$ 是 n 个不同方向和强度的雨条纹层的叠加，T 为透射率图，描述因雨积累造成的成像衰减，其值随距离增大或雨密度变大而减小，从而产生雾化效应，A 表示全局大气光，$\odot$ 表示逐元素相乘。

（2） 雨滴图像成因

雨滴在形状、位置和大小上具有高度多样性，并不像雨条纹那样呈现规则的线状结构。Attentive GAN[78]将雨滴退化建模为背景与雨滴效应的复合：

$$I_{RD} = (1 - M) \odot I_C + M \odot R, \tag{2.2}$$

其中，I_{RD} 为受雨滴影响的图像，I_C 为无雨滴的清晰图像，M 为二值掩码（$M = 1$ 表示雨滴区域，$M = 0$ 表示背景区域），R 为雨滴效应成分，用以描述由背景折射与环境反射共同作用产生的雨滴成像特征，$\odot$ 为逐元素相乘。雨滴虽然整体透明，但由于其复杂的三维形态及折射特性，雨滴区域的像素融合了丰富的环境信息，使其外观显著区别于对应的背景。同时，摄像机通常聚焦于背景而非雨滴本身，导致雨滴区域大多呈现失焦模糊。

（3） 雾图像成因

雾图主要由大气中的散射效应引起，当光线从场景传播到相机时，会被空气中的悬浮颗粒散射，导致图像模糊、对比度降低。经典的大气散射模型[31]常用来描述雾天图像的成像过程：

$$I_H = J \odot T + A \odot (1 - T), \tag{2.3}$$

其中，I_H 表示雾退化图像，J 为无雾的清晰场景，$T \in [0, 1]$ 为透射率图，表示光线在传输过程中未被散射的比例，其大小受大气条件和场景深度影响，距离越远或雾越浓则 T 越小。A 是全局大气光，$\odot$ 表示逐元素相乘。

（4） 雪图像成因

雪以颗粒形式出现在图像中，会遮挡细节并降低清晰度。雪花具有显著的多样性，其密度、大小、形状、运动轨迹和透明度在同一场景中可能各不相同，其中既有半透明雪粒子引起的叠加与颜色偏差，也有不透明雪粒子造成的局部完全遮挡。因此，与雨和雾相比，雪导致的成像退化更加复杂。DesnowNet[69] 将含雪图像的退化过程建模为：

$$I_S = A \odot Z + I_C \odot (1 - Z), \tag{2.4}$$

其中，I_S 为含雪图像，I_C 为无雪背景图像，Z 为雪掩码，用于表示每个像素位置的雪效应透明度，其取值范围为 [0,1]，A 为色差图，反映雪粒子引起的颜色偏差，$\odot$ 表示逐元素乘法。

中国知网　https://www.cnki.net

2. JPEG 压缩图像成因

JPEG（Joint Photographic Experts Group）是一种有损图像压缩标准，其压缩流程主要包括以下步骤：

- 颜色空间转换与下采样：将输入的 RGB 图像转换到 YCbCr 颜色空间，其中 Y 为亮度分量，Cb, Cr 为色度分量。利用人眼对色度不敏感的特性，通常对色度分量进行下采样，在保证主观质量的同时降低数据量。由于亮度分量 Y 保留了大部分结构与纹理细节，且压缩伪影主要集中在该通道，因此现有 JPEG 压缩图像复原任务一般在 Y 通道进行。
- 分块与预处理：对每个分量分别划分为不重叠的 8×8 像素块；在基线 JPEG 中通常先对像素值执行平移中心化（例如减去 128）以便后续变换居中。
- 离散余弦变换（Discrete Cosine Transform, DCT）：对每个 8×8 块施加二维 DCT，将空间域信号映射为频域系数，实现能量在低频的集聚。DCT 公式为：

$$F(u,v)=\frac{C(u)C(v)}{4}\sum_{x=0}^{7}\sum_{y=0}^{7}f(x,y)\cos\left(\frac{(2x+1)u\pi}{16}\right)\cos\left(\frac{(2y+1)v\pi}{16}\right), \tag{2.5}$$

其中 $u,v,x,y\in\{0,\cdots,7\}$，$f(x,y)$ 为经中心化后的像素值，$F(u,v)$ 为 DCT 系数，$C(k)=\begin{cases}\frac{1}{\sqrt{2}}, & k=0\\ 1, & k\neq 0\end{cases}$。左上角 $F(0,0)$ 为直流（Direct Current, DC）分量，其余为交流（Alternating Current, AC）分量。

- 量化（有损）：使用压缩质量因子（Quality Factor, QF）缩放预定义的基准量化表得到实际量化表 $Q(u,v)$ 对 DCT 系数进行标度与取整，强化高频抑制、实现压缩：

$$F^{Q}(u,v)=\mathrm{round}\left(\frac{F(u,v)}{Q(u,v)}\right), \tag{2.6}$$

基于人眼对高空间频率细节敏感度较低的特性，量化表对频率索引较大的 DCT 系数分配更大的量化步长。

- 之字形扫描：将 8×8 的量化系数按从低频到高频的之字形顺序重排为一维序列，使前缀聚集更多非零项、后缀形成长零串，便于后续熵编码提升压缩率。
- 差分与行程编码：对每个块的 DC 系数做差分预测编码（与前一块 DC 之差），对 AC 系数采用零行程长度编码，将“零的个数 + 下一个非零幅值”的对表示为符号对以减少冗余。
- 熵编码：将 DC 差分类别与 AC 的游程长度-幅值对进行熵编码，基线 JPEG 常用霍夫曼编码，扩展模式可用算术编码，以进一步压缩码长，最终生成

中国知网　https://www.cnki.net

JPEG 比特流。

在 JPEG 压缩中，压缩质量因子 (Quality Factor, QF) $\in [0, 100]$ 通过缩放量化表来调控量化步长，从而影响压缩率与重建图像质量的平衡。较低的 QF 会放大量化步长，导致高频信息丢失严重，块效应与振铃伪影更为明显。较高的 QF 则缩小量化步长，使更多细节得以保留，主观质量更佳。

3. **噪声图像成因**

在彩色图像处理中，加性高斯白噪声（Additive White Gaussian Noise, AWGN）是用于刻画采集与传输过程中随机干扰的核心模型。其名称准确地概括了噪声的三项关键属性：一是加性，即噪声通过简单的加法叠加到干净的像素值上；在彩色图像中，这一操作通常分别且独立地作用于红（Red, R）、绿（Green, G）、蓝（Blue, B）三个通道。二是“白”，源于信号处理的类比，指噪声在各空间频率上功率均匀，意味着像素间的噪声样本在统计上近似独立。三是“高斯”，即噪声幅值服从通常以零为均值的高斯分布。这一分布假设可由中心极限定理支撑：当大量相互独立的随机物理过程（如相机传感器中电子的热运动）叠加时，其总体统计特性趋向于高斯形态。据此，在彩色图像中合成 AWGN 的典型做法是：生成高斯分布随机噪声矩阵，并与对应通道的原始像素逐点相加，从而得到包含加性高斯白噪声的观测图像。因此，对于像素位置 i 与通道 $c \in \{R, G, B\}$，噪声像素可写为：

$$y_{i,c} = x_{i,c} + n_{i,c}, \qquad E[n_{i,c}] = 0, \quad \forall\, i,\ c \in \{R, G, B\}, \tag{2.7}$$

空间“白”性质指不同像素位置之间在统计上独立，即

$$n_i \perp n_j \text{ 或 } E\left[n_i n_j^{\top}\right] = 0, \quad \forall\, i \neq j, \tag{2.8}$$

同时采用像素内的向量形式刻画加性与分布为

$$y_i = x_i + n_i, \qquad n_i \sim \mathcal{N}\left(0,\ \boldsymbol{\Sigma}\right), \quad \forall\, i, \tag{2.9}$$

其中 $y_i, x_i, n_i \in \mathbb{R}^3$ 分别为像素 i 处的观测、干净与噪声三通道向量。在独立同分布噪声假设下，三个通道噪声相互独立且方差一致，因此协方差矩阵为

$$\boldsymbol{\Sigma} = \sigma^2 I_3. \tag{2.10}$$

在 AWGN 模式下，噪声方差越大，则噪声幅度越高，导致可见失真加重，图像质量下降越明显。

2.1.2　数据集介绍

本文在恶劣天气图像复原、JPEG 图像复原和噪声图像复原进行实验，本节介绍所使用的数据集，表 2.1和 2.2中分别介绍了训练和测试数据集详情，表2.3中

中国知网　https://www.cnki.net

展示了实验设置详情。图 2.1、 2.2、 2.3和 2.4分别展示了每种数据集中的图片。下面分别对这些数据集以及本文所采用的实验设置进行介绍。

- Outdoor-Rain 数据集: Outdoor-Rain[63]数据集采用式 (2.1)进行雨条纹 + 雾图像建模，其包含 9,000 对配对的训练图像和 750 对配对的测试图像。
- RainDrop 数据集: RainDrop[78]数据集采用式 (2.2)进行雨滴图像建模，其包含 861 对配对训练图像和两个测试集：Test A 和 Test B，分别包含 58 对和 249 对配对图像。
- Snow100K 数据集: Snow100K[69]数据集采用式 (2.4)进行雪图像建模，其包含 50,000 对配对的训练图像，合成测试数据根据雪的密度分为三类：SnowTest100K-S、SnowTest100K-M 和 SnowTest100K-L，分别包含 16,611 对、16,588 对和 16,801 对配对图像，真实测试集 realistic 包含 1,329 张无配对标签的真实世界雪景图像。
- DIV2K 数据集: DIV2K[79] 数据集（DIVerse 2K）是图像复原任务的标准基准数据集。该数据集包含 1000 张高质量 2K 分辨率图像，划分为训练集 800 张、验证集 100 张、测试集 100 张。训练集与验证集提供公开的清晰图像及对应退化版本，测试集仅提供退化图像，其清晰图像不公开。DIV2K 数据集图像内容高度多样，覆盖自然风景、城市建筑、人像、动物、室内外场景等，其已成为图像复原领域最具影响力的数据集之一。
- Flickr2K 数据集: Flickr2K[80]数据集是面向图像复原研究的高分辨率图像集合，共包含 2,650 张清晰图像，抓取自 Flickr，覆盖自然风景、城市街景、建筑与纹理细节、室内外物体等。与 DIV2K 相比，Flickr2K 规模更大、来源更贴近真实网络摄影场景。
- WED 数据集: WED[81] 数据集最初为图像质量评估设计。该数据集包含 4744 张高质量清晰的自然图像，分辨率覆盖从 1024×768 到 1920×1080 等多种常见规格，其图像内容高度多样，覆盖自然风景、城市建筑、人像、动植物、室内外等广泛场景。与专为复原任务构建的数据集不同，WED 不提供预设的训练/验证/测试划分，且不自带退化版本。在图像复原研究中，研究者通常以这些清晰图像为源，自行施加噪声、JPEG 压缩等退化以构建训练对。
- LIVE1 数据集: LIVE1[82]数据集源自 LIVE Image Quality Assessment 数据库的 29 张自然场景图像，内容涵盖人造与自然结构。
- Classic5 数据集: Classic5[83]数据集是由 5 张经典自然图像构成的测试集，虽规模极小，但包含典型高频纹理与规则边缘，对方法在纹理保持、条纹伪影抑制与锐利边界重建方面的性能较为敏感。
- RESIDE 数据集: RESIDE[84]数据集是面向雾图像复原的标准基准，其训练

中国知网　https://www.cnki.net

部分由 ITS 与 OTS 两个子集构成，分别包含 110,000 对室内场景和 313,950 对室外场景的合成配对雾图像。其测试部分为 SOTS，分为 SOTS-Indoor 与 SOTS-Outdoor，两者各包含 500 对成对图像。

- Rain100L 数据集: Rain100L[85] 数据集的训练集包含 200 对图像，测试集包含 100 对图像，其用于评测在单一方向雨条纹场景下的雨图复原效果。
- BSD400 数据集: BSD400[86]数据集由 400 对彩色自然场景图像组成，常作为图像复原任务的训练集使用，其场景多样、纹理丰富。
- CBSD68 数据集: CBSD68[87]数据集源自 BSD68 的彩色高质量版本，包含 68 张图像，是用于噪声图像复原任务的标准测试集之一。其图像多来自自然场景，内容涵盖纹理、边缘、平坦区域等多样元素。

表 2.1　本文使用训练数据集统计

编号	数据集	用途	图像数量
1	Outdoor-Rain[63]	恶劣天气图像复原（雨条纹 + 雾）	9,000
2	RainDrop[78]	恶劣天气图像复原（雨滴）	861
3	Snow100K[69]	恶劣天气图像复原（雪）	50,000
4	DIV2K[79]	JPEG 压缩图像复原	800
5	Flickr2K[80]	JPEG 压缩图像复原	2,650
6	WED[81]	（JPEG 压缩、雨-雾-噪声）图像复原	4,744
7	BSD400[86]	雨-雾-噪声图像复原（噪声）	400
8	RESIDE[84]	雨-雾-噪声图像复原（雾）	313,950
9	Rain100L[85]	雨-雾-噪声图像复原（雨）	200

表 2.2　本文使用测试数据集统计

编号	数据集	用途	图像数量
1	Outdoor-Rain[63] (Test)	恶劣天气图像复原	750
2	Raindrop[78] (Test A)	恶劣天气图像复原	58
3	SnowTest100K-L[69]	恶劣天气图像复原	16,801
4	LIVE1[82]	JPEG 压缩图像复原	29
5	Classic5[83]	JPEG 压缩图像复原	5
6	BSDS500[86] (Test)	JPEG 压缩图像复原	200
7	CBSD68[87]	雨-雾-噪声图像复原	68
8	SOTS-Outdoor[84]	雨-雾-噪声图像复原	500
9	Rain100L[85] (Test)	雨-雾-噪声图像复原	100

恶劣天气图像复原中，在训练阶段，为保证各类别数据的均衡，本文从 Outdoor-Rain、RainDrop 和 Snow100K 训练数据集中各采样 9,000 对配对图像。对于图像数量不足 9,000 对的 RainDrop 数据集，通过重复复制的方式进行补齐。在测试阶段，本文使用 Raindrop 的 Test A 测试集、Outdoor-Rain 的全部测试集以

中国知网　https://www.cnki.net

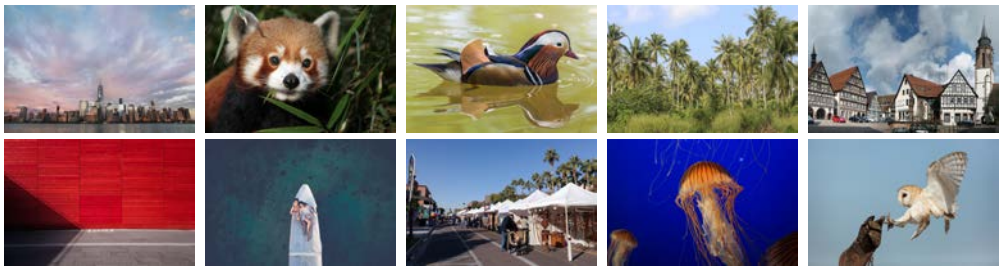
表 2.3　本文不同实验配置中使用的数据集详情

任务	训练数据集	测试数据集
恶劣天气图像复原	Outdoor-Rain, RainDrop, Snow100K	Outdoor-Rain (Test) RainDrop (Test A) SnowTest100K-L
JPEG 压缩图像复原	DIV2K, Flickr2K, WED	LIVE1 Classic5 BSDS500 (Test)
雨-雾-噪声图像复原	Rain100L, RESIDE, BSD400, WED	Rain100L (Test) SOTS-Outdoor CBSD68

及 Snow100K 的 SnowTest100K-L 测试集。

在 JPEG 图像复原任务中，本文采用 DIV2K, Flickr2K 与 WED 作为训练数据集，通过对清晰图像进行 JPEG 压缩以构建训练样本对。测试阶段在三个经典公开测试集 LIVE1、Classic5 与 BSDS500（Test）上评估模型性能，测试图像采用四个压缩质量因子（Quality Factor, QF），分别为 10、20、30 和 40。

在雨-雾-噪声图像复原任务中，训练数据来自 Rain100L、RESIDE、BSD400 与 WED，其中噪声样本通过在清晰图像上添加加性高斯白噪声合成。测试阶段在 Rain100L、SOTS-Outdoor 与 CBSD68 三个数据集上评估模型性能，其中噪声测试图像采用三种噪声水平标准差 σ，分别为 15、25 和 50。



(a) DIV2K 数据集展示



(b) Flickr2K 数据集展示

图 2.1　DIV2K 和 Flickr2K 数据集展示

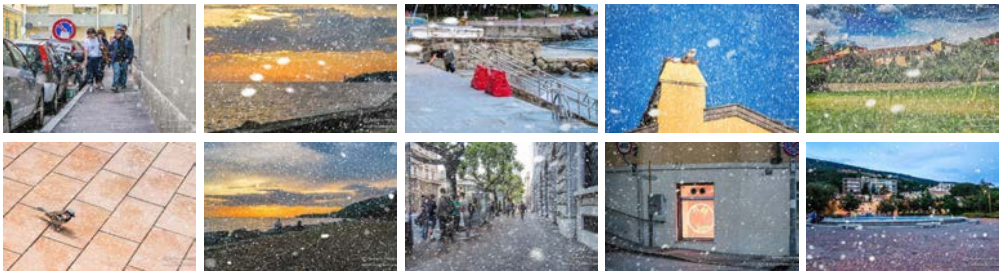
中国知网　https://www.cnki.net



(a) Outdoor-Rain 数据集展示



(b) Raindrop 数据集展示



(c) Snow100K 数据集展示

图 2.2　恶劣天气图像数据集展示



(a) LIVE1 数据集展示



(b) Classic5 数据集展示

图 2.3　JPEG 压缩图像测试数据集展示

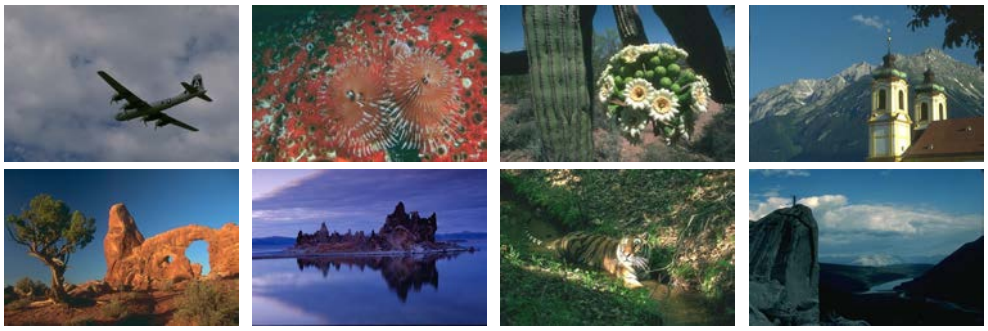
中国知网　https://www.cnki.net



(a) Rain100L 数据集展示



(b) SOTS-Outdoor 数据集展示



(c) CBSD68 数据集展示

图 2.4　雨-雾-噪声图像测试数据集展示

2.2　研究现状与不足

在 2.1中描述了退化图像的形成机制：在雨天、雾天或 JPEG 压缩等退化条件下，图像在成像或存储过程中受水滴、大气散射或量化过程等因素影响，最终形成退化图像。图像复原的目标是通过有效的方法，从退化图像中重建对应的清晰图像，去除各类退化因素，最大程度还原图像的原始内容与细节。

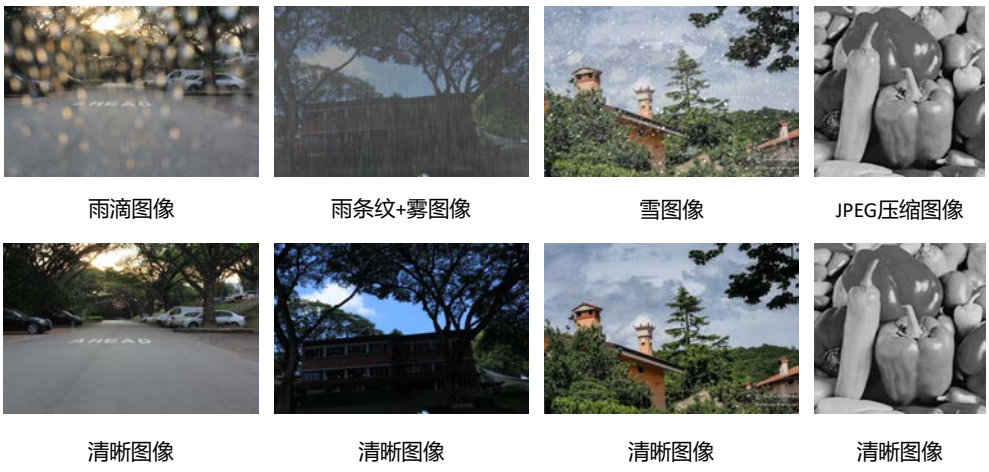


图 2.5　退化图像与其对应的清晰图像展示

需要特别说明的是，在图像复原领域内，“清晰图像”有着对应的含义。这

中国知网　https://www.cnki.net

里所说的“清晰图像”，是指在完全相同场景、视角和拍摄参数下，不含由成像阶段的物理退化或成像后的有损编码引起的失真或伪影（如雨水遮挡、雾浓度干扰，或 JPEG 压缩引入的块效应与振铃伪影等）的图像，如图 2.5所示。换句话说，清晰图像作为理想参考，对应的是没有任何退化影响下场景本身的内容。这一定义不同于日常语境下所说的“清晰”，后者通常指图像分辨率高或画面锐利。而在本领域的任务和数据集构建中，清晰图像与退化图像主要在是否包含退化因素上存在差异，其主要用于评估算法对图像的准确还原能力和复原效果。

针对本章前述的退化类型，本节介绍基于深度学习方法的相关图像复原任务研究进展，并在此基础上总结现有方法的不足之处。

2.2.1　研究现状

图像复原任务作为经典的计算机视觉底层任务，长期以来受到广泛关注。在基于深度学习的方法中，由于不同退化图像之间的退化模式存在差异，自然引出了一条直观的研究思路，即为每种退化类型分别训练一个独立模型。然而，该做法在一定程度上限制了模型的灵活性与适用范围。因此，越来越多的研究基于自适应学习方法，致力于使图像复原模型能够同时处理多种退化图像，从而进一步提升其实用性。下面分别对这些方法进行介绍。

1. 恶劣天气图像复原方法

在恶劣天气图像复原的深度学习方法中，早期的方法为雨图、雾图和雪图训练单独的模型，近期的研究方向转向了单一模型同时处理雨雾雪图片，下面分别介绍这些方法的现有工作。

（1） 单一天气图像复原方法

对于单幅雨图复原任务，Fu 等人[88]开创性地提出了深度细节网络，将卷积神经网络成功引入雨图复原领域。通过让网络专注于学习雨图中高频细节层中的雨条纹残差，显著提升雨条纹的去除效果。JORDER[85]通过一个多任务网络联合进行雨条纹检测与去除，为后续研究奠定了基础。为了更好地提升复原图像的视觉质量，PReNet[89]提出了一种更简洁高效的渐进式循环网络，证明了简单结构的有效性。MSPFN[90]利用多尺度金字塔结构与渐进式融合策略，有效处理不同大小的雨条纹。Zhang 等人[91]将生成对抗网络[92]（Generative Adversarial Network, GAN）引入雨图复原领域，他们利用条件 GAN 框架生成视觉上更逼真的图像，并加入了多尺度判别器与精炼的感知损失函数。MPRNet[93]作为一个通用的多阶段渐进式恢复框架，在雨图复原中展现出优异的性能。MSKSN[94]通过引入多尺度核选择网络，在保证性能的同时显著减少了模型参数。然而，卷积神经网络（Convolutional Neural Networks, CNNs）固有的局部感受野限制了其捕捉长距离依赖关系的能力。因此，DualGCN[95]首次将图卷积网络引入该领域，用以

中国知网　https://www.cnki.net

捕捉特征间的长程依赖关系，突破了传统卷积的局部性限制。Transformer[96]架构及其核心的自注意力机制以其长距离关系建模能力也被广泛应用于雨图复原领域。IDT[97]结合了 Transformer 与 CNNs 的各自优势，通过设计互补的窗口式和空间式自注意力模块，在高效捕捉局部特征的同时，也能建模全局依赖关系，在雨图复原方面取得了更好的效果。DRSformer[98]引入了 top-k 稀疏注意力机制，自适应地选择并仅保留最有用的一部分注意力值用于特征聚合，使得注意力过程更高效，此外，其还设计了混合尺度前馈网络以更好地捕捉多尺度特征。NeRD-Rain[99]首次将隐式神经表示（Implicit Neural Representation, INR）与多尺度 Transformer 结合，INR 将图像编码为连续函数，有助于学习通用的雨退化表示，通过在不同尺度分支之间共享 INR，模型能更好地处理复杂多变的真实雨图，提升模型的鲁棒性。

对于单幅雾图复原任务，早期的卷积神经网络（Convolutional Neural Networks, CNNs）模型主要沿着两条研究路径：一些方法利用 CNNs 来更精确地估计大气散射模型中的关键参数，如透射率图和大气光值。例如，MSCNN[100] 通过一个粗尺度网络估计透射率，再由一个细尺度网络进行精炼。另一部分方法则采用端到端学习，将有雾图像直接映射为清晰图像，从而绕开了对中间物理参数的复杂估计。AOD-Net[64] 构建了一个轻量级的 CNNs，能够直接生成去雾后的清晰图像，展示了端到端学习的巨大潜力。随着网络架构的演进，基于注意力机制的模型开始涌现。FFA-Net[68] 结合通道注意力和像素注意力，使网络能够自适应地关注有雾区域和重要的特征通道，显著提升了去雾性能。而 GridDehazeNet[101] 则设计了一个包含可训练预处理模块和基于注意力机制的网格化多尺度骨干网络，有效缓解了传统多尺度方法中的瓶颈问题。近年来，Transformer[96]架构因其卓越的长距离依赖建模能力，在雾图复原领域得到了广泛应用。DehazeFormer[102] 通过对 Swin Transformer[103] 的结构进行了优化，进一步提升了雾图复原的效果。MB-TaylorFormer[104]探索基于泰勒展开来构建线性化的 Transformer 网络，着重于高效地建模像素间的长距离依赖关系。

对于单幅雪图复原任务，DesnowNet[69]采用了两阶段的学习方式，通过一个多阶段网络分别处理半透明和不透明的雪花，并引入了对半透明度和色差属性的解耦估计。为了应对雪花多尺度和非透明性带来的挑战，JSTASR[105]通过尺寸感知和透明度感知模块，同时处理不同尺寸和透明度的雪花。该模型的一个关键创新在于将雪景图像的形成过程与雾气生成的大气散射模型相结合，考虑了由密集、微小雪花累积造成的面纱效应，从而实现了雪和雾的同步去除。Transformer[96]架构同样被引入雪图复原。SnowFormer[106]通过一个新颖的上下文交互模块来建模局部细节和全局信息之间的交互，并利用一个尺度感知聚合模块来捕捉不同尺寸的雪花信息，在多个雪图复原基准测试集中取得了显著的

中国知网　https://www.cnki.net

性能提升。

（2） 基于自适应学习的恶劣天气图像复原方法

出于实用性考虑，越来越多的研究开始关注利用单一模型同时复原多种恶劣天气图像。早期的探索中，Li 等人[74]率先提出了 All-in-One 框架，其核心思想是针对每种恶劣天气类型设计特定的任务编码器，并通过神经架构搜索来自动优化所有编码器提取的图像特征的处理流程，从而实现自适应恶劣天气图像复原。TransWeather[75]首次将 Transformer[96] 引入自适应恶劣天气图像复原任务，其采用更高效的单编码器-单解码器架构，在解码器中引入了可学习的天气类型嵌入作为查询，通过注意力机制自适应地处理不同的天气条件。另一种思路是利用知识蒸馏，Chen 等人[107]提出了一种新颖的两阶段训练策略：在第一阶段，将多个负责不同恶劣天气类型的“教师”网络的知识，通过一种协作式知识迁移机制，共同蒸馏至第二阶段的一个统一的“学生”网络中，这使得单一学生模型能够继承多个教师模型的综合能力，因此在恶劣天气图像复原任务中取得了优异效果。随着扩散生成式模型的兴起，WeatherDiffusion[108]首次将扩散模型应用于自适应恶劣天气图像复原任务，其采用基于图像块的引导式去噪过程，不仅能够生成高质量的复原结果，还使其能够灵活处理任意尺寸的图像，从而在恶劣天气复原任务上取得了先进性能。为了更好地平衡模型的通用性与特异性，Zhu 等人[109]提出了一种两阶段学习策略，在共享主干网络的基础上，于第二阶段为不同的天气类型自适应地添加少量特定参数，从而高效地实现对多种天气类型的复原。利用高质量先验信息也是一条重要的技术路线，AWRCP[110]利用从清晰图像中学习到的高质量码本先验，结合具有稀疏采样的可变形交叉注意力机制，在恢复生动的纹理细节和精准的背景结构方面表现出色。Tan 等人[111]利用预训练的 CLIP[112]模型提取天气先验，他们设计了空间自适应残差编码器来自适应地提取退化区域特征，并通过一个 CLIP 天气先验嵌入模块，将天气相关的语义信息融入网络，以指导复原过程。Histoformer[113] 基于一个关键观察，即恶劣天气退化在亮度维度上往往具有相似性，为此，其提出了直方图自注意力机制，通过按像素强度对空间特征进行排序并划分至不同强度区间，在区间间或区间内执行自注意力，以高效建模相似强度像素的长距离依赖；同时结合动态范围卷积，进一步提升图像复原性能。

2. JPEG 图像复原方法

在 JPEG 压缩图像复原的深度学习方法中，早期的方法为不同的压缩质量因子（Quality Factor, QF）训练单独的模型，近些年的研究方向转向了单一模型同时处理多种 QF，下面分别进行介绍。

中国知网　https://www.cnki.net

（1） 单一压缩因子 JPEG 图像复原方法

在基于深度学习的 JPEG 图像伪影去除方法中，一种早期的策略是为每个特定的质量因子（Quality Factor, QF）训练一个专用的模型。这类方法将 JPEG 压缩图像复原视为一个确定性的映射任务，针对固定的压缩等级进行优化。代表性的工作是由 Dong 等人提出的 ARCNN[114]，其是首个将卷积神经网络（Convolutional Neural Networks, CNNs）用于 JPEG 压缩图像复原的工作，使用一个四层卷积网络学习从压缩图像到无损图像的端到端映射。Guo 等人[115]提出构建双域表示，让网络在像素空间域与由离散余弦变换（Discrete Cosine Transform, DCT）得到的频率域中共同提取和融合特征。D3[116]同样采用了双域思想，但更侧重于构建轻量化网络以实现快速复原。MemNet[72]通过一个包含递归单元和门控单元的深度记忆模块，显式地挖掘先前状态的持久记忆来学习有效特征。Galteri 等人[65]则引入生成对抗网络（Generative Adversarial Network, GAN）框架，利用判别器来判断复原图像的真实性，旨在生成视觉上更自然的图像。为了提升 JPEG 图像复原速度，CAS-CNN[117]将多尺度约束方法融合到深度神经网络中。MWCNN[73] 创新性地将离散小波变换和逆小波变换分别替代传统的池化与上采样操作，从而在保留关键信息的同时有效降低特征维度，使网络能够在小波域中更高效地建模多尺度信息。RDN[118]通过构建残差密集块，在局部残差学习与密集连接的共同作用下充分利用层次化特征，实现了特征的高效重用与信息流动，从而在图像复原任务中取得了优异性能。Jin 等人[119]认为一个压缩输入可对应多个合理输出，因此提出了一对多网络框架，以生成多样化的复原结果。Egiazarian 等人[120]则从频率建模角度出发，通过估计图像的频率分布来重建缺失的高频成分，从而提升细节复原效果。CODE[121] 通过在低维空间聚合并传播全局依赖，大幅降低计算开销，在保持图像复原精度的同时显著提升了效率。

（2） 基于自适应学习的 JPEG 图像复原方法

为了提升方法的实用性并避免为每个压缩等级都训练和存储一个独立模型，越来越多的研究致力于设计能够处理多种压缩质量的单一模型。DnCNN[66] 采用深度残差学习框架，其核心思想是令网络直接学习并预测压缩伪影（即压缩图像与清晰图像之间的残差），并通过在包含多种质量因子样本的混合数据集上进行训练，该模型在训练完成后即可同时适用于不同质量因子的图像复原任务。DCSC[122]首先通过扩张卷积提取多尺度特征，以适应不同程度的伪影，然后通过一个模拟卷积稀疏编码优化过程的模块来分离伪影特征，最终从处理后的特征中重建图像，从而使单个模型能够应对多种压缩等级。Fan 等人[123] 提出解耦学习框架，以参数驱动权重生成并实现多算子联合训练。Fu 等人[124]提出可解释深度展开网络，融合像素回归先验与梯度语义判别先验，交替优化以实现 JPEG 压缩图像复原，为了进一步提升模型对不同压缩质量的适应性，研究者们尝试向

中国知网　https://www.cnki.net

网络显式提供压缩质量信息。例如，Kim 等人[125] 将压缩图像和对应的量化表作为双输入，使模型能自适应地处理不同压缩等级。AGARNet[126] 通过估计像素级的压缩质量因子，从而用一个网络覆盖了更大范围的压缩质量。QGAC[76] 将 JPEG 的量化表作为额外输入，并通过卷积滤波器流形来参数化网络权重，使模型能够根据具体的量化信息自适应地调整伪影去除策略。FBCNN[77] 则采用自回归方式预测压缩质量因子，并将预测结果送入控制模块以生成用于调节复原网络的参数，从而使单一模型能够灵活应对不同压缩程度的图像。

3. **雨-雾-噪声图像复原**

在基于深度学习的噪声、雨和雾图像复原研究中，早期方法通常针对不同噪声等级或针对雨和雾这两类退化类型分别训练专用模型；而近年来的工作则更注重构建单一模型，以同时适应多种噪声强度和雨雾图像的复原。针对雨图像和雾图像的相关复原方法已在前文中进行了介绍，下文介绍针对单一噪声等级的噪声复原方法，以及能够同时处理不同噪声等级和雨雾退化的单一模型方法。

（1） 单一噪声等级图像复原方法

早期的探索之一 TNRD[127] 在传统模型与深度学习间架起了桥梁，其将经典的非线性反应扩散模型的迭代过程展开为网络结构，并直接从数据中学习最优的滤波器和参数，从而创建了一个高效且可解释的复原框架。进入更深层的网络设计后，RPCNN[70] 基于自然图像中广泛存在的重复模式和自相似纹理这一理念，设计了能够识别并利用这些非局部重复图像块的网络，以更有效地分离信号与噪声。几乎在同一时期，为了优化深度网络的训练过程，BRDNet[71] 采用了 Sergey Ioffe 于 2017 年提出的批量重归一化（Batch Re-Normalization, BRN）技术，通过减少模型对小批量数据统计特性的依赖，增强了训练的稳定性，从而支持构建更深的网络并提升了去噪性能。DnCNN[66] 同样在噪声图像复原取得了良好的性能。随后，Transformer[96] 架构的引入标志着一个新的发展方向。IPT[128] 作为该领域的开创性工作之一，将在自然语言处理中取得巨大成功的 Transformer 架构带入底层图像处理。其通过在海量数据集上进行预训练，构建了一个庞大的图像复原模型，该模型仅需微调便可高效处理去噪、去雨等多种复原任务。SwinIR[129] 采用了计算效率更高的 Swin Transformer[103] 架构, 通过在局部的的窗口内计算自注意力，极大减小了计算复杂度，其在捕捉像素的局部和长距离依赖关系方面表现出色，为多种图像复原任务设立了新的技术标杆。

（2） 基于自适应学习的雨-雾-噪声图像复原方法

DL[130] 通过权重生成网络根据算子参数，动态生成并注入对基网络少量深层权重的改写，使同一模型在连续参数空间内统一处理多种退化类型，并且在此机制下，仅需微调少量深层权重即可完成快速图像复原。IDR[131] 先收集各退化的专属先验并通过可学习 PCA 与动态软路由进行成分化融合，将加性、乘性、

中国知网　https://www.cnki.net

卷积等共性物理成分统一到单一先验空间，从而以单一模型统一处理多种及混合退化，并在未知场景上展现良好泛化。ProRes[132] 通过为每种退化学习一组与图像同形的退化感知视觉提示（Degradation Visual Prompts），并在推理时将相应提示直接加到输入图像上，并可对多提示做线性加权组合，从而实现单一模型覆盖多种及复合退化类型。PromptIR[133] 通过引入可学习的退化提示向量（Degradation Prompts）来引导主干网络的特征提取与重建过程，使模型能够根据输入图像的退化特性动态调节复原策略，从而实现对多种退化类型的统一处理。NDR[134] 学习一个通用的神经退化表示，通过退化查询从输入特征自适应读取细粒度退化信息，并借由退化注入对特征进行内容感知调制，其结合恢复-退化双向联合优化，使单一模型可按输入自适应选择与组合处理路径，因而同时应对多种退化类型。Gridformer[135] 以网格化表征为核心，将图像划分为多个网格单元，并在网格级别执行自注意力和跨网格交互，以高效捕获长程依赖，同时，模型融合了局部卷积用于细节建模与全局 Transformer 用于上下文建模的互补优势，从而在单一框架下兼顾纹理重建与结构保持，实现对多种图像复原任务的适配。

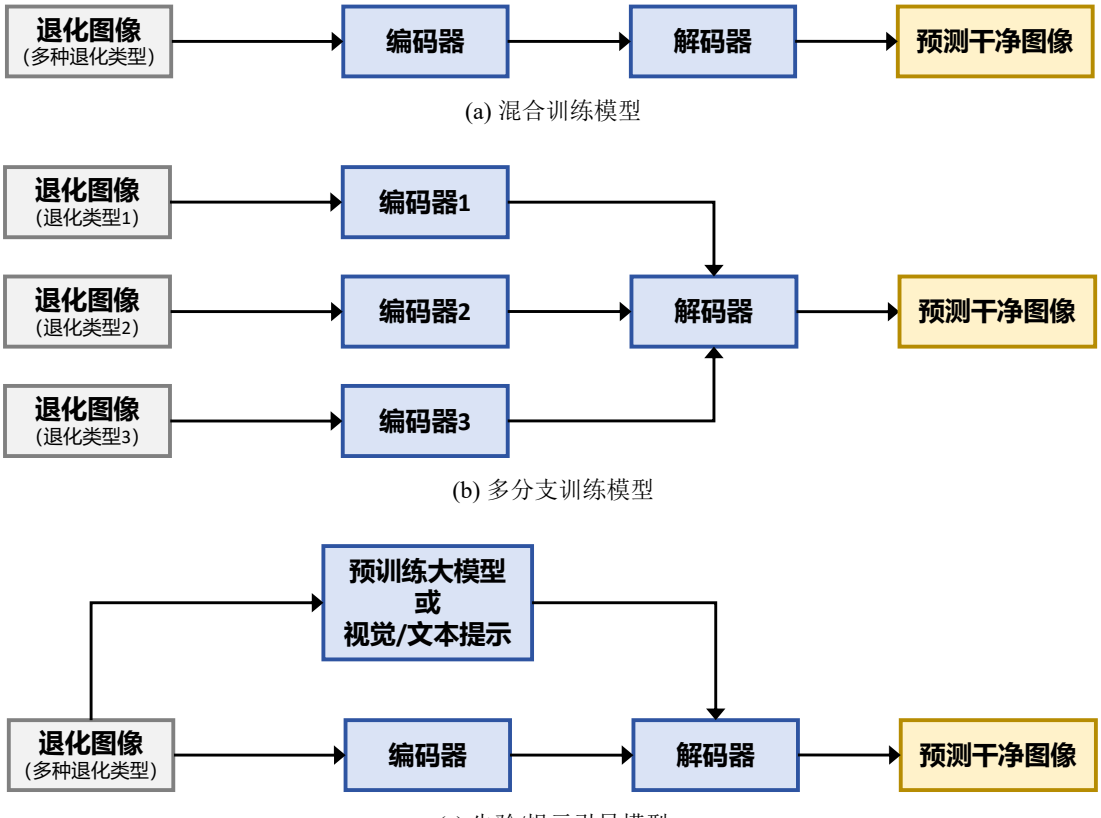


图 2.6　基于自适应学习的图像复原模型现有方法举例

中国知网　https://www.cnki.net

2.2.2　现有工作不足

本文致力于使用自适应模型处理不同退化程度的图像，尽管现有方法在该领域取得了诸多进展，但他们仍存在一些不足，总结为以下几点：

- 对于退化多样性，如图2.6所示，部分方法[66,108,110]在训练时仅仅将不同退化的图像数据集混合后一起输入网络，未考虑不同退化的差异性，导致模型在处理不同的退化图像时缺乏退化指导信息从而存在盲目性。静态多分支架构诸如 All-in-One[74]和 WGWS-Net[109] 等模型，通常为不同的退化类型分配专属的网络支路和处理模块。这种架构的扩展能力受限，每当需要模型处理新的退化类型时，就必须相应地增加参数量和网络复杂度。FBCNN[77] 以 10、20 等具体数值来表征压缩强度，但这种基于固定参数的描述方式过于简单化，难以充分反映图像在真实场景下复杂多变的压缩退化特性，此外，其采用有监督的训练方式预测压缩数值，使得模型在面对未见压缩条件时的适应性和泛化能力受到限制。Tan 等人[111] 在提取天气退化先验时依赖于预训练的 CLIP 模型，这一设计虽然能够利用外部知识，但需要额外的大规模参数支撑，显著增加了模型的计算成本。
- 对于内容复杂性，使用卷积网络的方法[107,109]感受野有限，难以充分捕获全局信息。全局 Transformer 虽能建模长程依赖，但自注意力的二次复杂度使计算和显存开销随图像尺寸急剧增长。而采用窗口注意力的方法[75,129]虽降低了计算开销，其感受野又被再次局限。
- 对于内容-退化耦合性，当前方法没有考虑到退化去除的差异性和内容重构的一致性，加大了单一模型处理不同退化类型图像的难度。并且，当前方法在使用损失函数对网络的参数优化进行约束时，没有考虑不同类型的退化通向对应清晰图像的方向差异性，导致约束缺乏针对性。

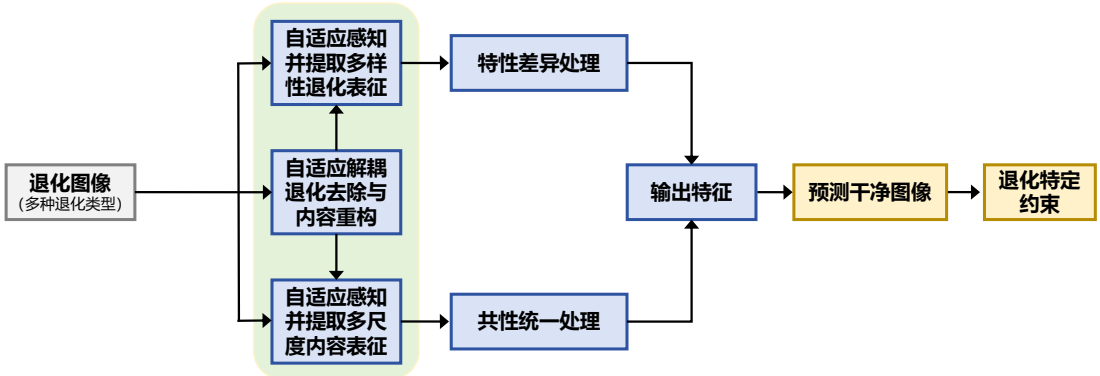


图 2.7　基于自适应学习的图像复原模型需要具备的能力

为了解决上述问题，本文指出，图像复原模型需具备以下能力，如图 2.7所示：首先，在特征提取层面，模型应具备退化感知能力，能够提取差异性的退化表征。并且模型需拥有全局与局部的内容感知能力，以完整理解图像的整体结构

中国知网　https://www.cnki.net

和精细细节。再者，在框架设计层面，为了降低模型学习的难度，模型应当能够将差异性与一致性的表征进行分离处理。最后，在网络优化层面，应针对不同的退化类型引入针对性的约束策略。本文的研究基于这些需求展开。

2.3　图像复原评价准则

在图像复原领域，复原效果的评价既依赖定量指标，也依赖可视化的主观视觉对比。下面分别对这两种评价方式进行介绍。

2.3.1　定量评价

在图像复原任务中，常用的客观评价指标主要包括峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）和结构相似性（Structural Similarity, SSIM）。在 JPEG 图像复原任务中，还有专门为其设计的评价指标块效应峰值性噪比（Block Effect Perceptual Peak Signal-to-Noise Ratio, PSNR-B）。这些指标能够有效衡量复原图像与参考清晰图像之间的相似度，从而评价复原方法的性能。

1. 峰值信噪比

峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）是衡量图像重构质量的重要指标之一，用于评估复原图像与原始图像在像素层面的差异。该指标基于两幅图像对应像素间差值的平方和的均值，即均方误差（Mean Squared Error, MSE）。其定义如下：

$$\mathrm{PSNR} = 10 \cdot \log 10 \left(\frac{MAX^2}{\mathrm{MSE}} \right), \tag{2.11}$$

其中，MAX 表示图像的最大像素值（对于 8 位图像通常为 255），而 MSE 则代表上述的均方误差。因其计算的简便性和明确的物理意义，PSNR 仍被广泛用作图像复原任务的基础评价基准。PSNR 值越高，说明两幅图像在数值上越接近。

2. 结构相似性

结构相似性[136]（Structural Similarity, SSIM）指标从亮度、对比度和结构等方面综合衡量两幅图像之间的相似度。该指标的设计旨在弥补 PSNR 等传统像素级误差度量与人类视觉感知不一致的问题，其核心假设是人类视觉系统高度适应于从场景中提取结构信息。在计算上，SSIM 通常作用于图像的局部窗口，并对所有窗口的计算结果取平均值以获得全局 SSIM。其计算方式如下：

$$\mathrm{SSIM}(I_1, I_2) = \frac{(2\mu_{I_1}\mu_{I_2} + C_1)(2\sigma_{I_1 I_2} + C_2)}{(\mu_{I_1}^2 + \mu_{I_2}^2 + C_1)(\sigma_{I_1}^2 + \sigma_{I_2}^2 + C_2)}, \tag{2.12}$$

其中，μ_{I_1} 和 μ_{I_2} 表示图像 I_1 和 I_2 的均值，$\sigma_{I_1}^2$ 和 $\sigma_{I_2}^2$ 表示方差，$\sigma_{I_1 I_2}$ 表示协方差，C_1 和 C_2 为防止分母为零的小常数。SSIM 的取值范围通常在 $[-1, 1]$ 之间，值越接近 1 表明两幅图像的结构信息越相似。

中国知网　https://www.cnki.net

3. 块效应感知峰值信噪比

块效应感知峰值信噪比[137]（Block Effect Perceptual Peak Signal-to-Noise Ratio, PSNR-B）是在传统 PSNR 的基础上引入对块效应（blocking artifacts）额外惩罚的一种指标，常用于评价 JPEG 这类块基压缩引入的方块化伪影。其基本思想是：在与原图的均方误差（Mean Squared Error, MSE）之外，显式度量跨越块边界的相邻像素差异与块内部相邻像素差异之间的偏离，若跨块差异显著更大，则说明块效应更强，应相应降低质量分数。为此，PSNR-B 将“块效应强度”（Blocking Effect Factor, BEF）加入到误差项中，形成块效应感知均方误差 $\mathrm{MSE}\boldsymbol{B} = \mathrm{MSE} + \lambda \cdot \mathrm{BEF}$，并代入与 PSNR 相同的对数形式得到最终指标：

$$\mathrm{PSNR\text{-}B} = 10 \cdot \log 10\left(\frac{\boldsymbol{MAX}^2}{\mathrm{MSE}\boldsymbol{B}}\right), \qquad \mathrm{MSE}\boldsymbol{B} = \mathrm{MSE} + \lambda \cdot \mathrm{BEF}, \tag{2.13}$$

其中 $\boldsymbol{MAX}$ 为像素最大值（8 位图像通常为 255），λ 为平衡项（常取 1）。在典型实现中，图像按 JPEG 的 8×8 块划分，分别统计水平和垂直方向上跨越相邻块边界的相邻像素强度差的均值 $\boldsymbol{D}\mathrm{inter}$ 与块内部相邻像素强度差的均值 $\boldsymbol{D}\mathrm{intra}$，以 $\mathrm{BEF} = \max\left(0,\ \boldsymbol{D}\mathrm{inter} - \boldsymbol{D}\mathrm{intra}\right)$ 量化块效应强度：当跨块差异大于块内差异时，BEF 为正，从而使 $\mathrm{MSE}\boldsymbol{B} > \mathrm{MSE}$、PSNR-B 低于 PSNR，更贴近人眼对方块化伪影的感知，当块效应不明显时，BEF 约为 0。

2.3.2　定性评价

在图像复原任务中，定性评价主要依赖视觉可视化对比来直观检验方法效果。常见做法是将待评算法的复原图像与退化图像、原始清晰图像以及若干代表性基线方法进行展示，辅以局部放大窗、差异热图等突出细节差异。由于定性评价强调人眼主观感受，通常在标准化显示条件下进行对比，选取具有代表性的多类场景，如纹理密集、色彩丰富等。

2.4　本章小结

本章首先阐述了几类退化图像的主要成因及相关数据集，为后续方法设计与实验验证提供了数据支撑。随后对当前图像复原领域的研究现状进行了系统介绍，归纳了现有方法的主要技术路线，并分析了其中的不足之处，如模型退化感知能力受限、长距离依赖建模能力不足等问题。最后，介绍了图像复原结果的评价准则，从定量与定性两方面阐明了衡量方法性能的标准，为后续章节的方法性能分析奠定了理论基础与评价依据。

中国知网　https://www.cnki.net

第 3 章　面向退化多样性的自适应退化表征学习方法

在图像复原任务中，退化类型具有多样性，会给图像带来不同影响，典型表现为对比度下降幅度与纹理丢失程度的差异等。然而，现有方法往往未能识别并区分这些差异，而是直接将不同退化类型的图像混合后输入同一模型进行复原，从而采取一刀切的处理策略，难以实现有针对性的退化去除，最终影响复原质量。为缓解这一问题，一些研究采用静态的多分支结构，为每一种退化类型单独设计处理分支。然而，多分支结构不仅导致模型参数增加，并且扩展性受限，缺乏灵活适应能力。因此，感知退化类型并据此指导模型进行针对性的退化去除，是提升图像复原性能的关键前提。然而在实际场景中，可以被模型识别的退化类型的显式标签难以获取，语义级标签（如“雨”、“高压缩”等）与图像特征存在语义鸿沟，二者缺乏可直接利用的监督映射关系，而视觉层面的退化类型标签难以精确标注，因此，在缺乏显式退化标签的前提下，如何使模型具备退化感知能力成为亟待解决的问题。

针对上述问题，本章提出了一种无需显式退化类型标签监督的方法，使模型能够直接从退化图像中挖掘退化信息。具体而言，本章基于无监督对比学习构建了退化表征编码器：将相同退化的图像块作为正样本、不同退化的图像块作为负样本，经由编码器提取特征后，约束正样本在特征空间中相互靠近、负样本相互远离，从而促使模型自主学习并感知判别性退化表征。在此基础上，本章进一步设计了退化表征引导的图像复原模型 DRNet，以实现对多种退化类型的针对性复原。实验结果显示，在多个图像复原基准数据集上，本章方法能够自适应感知退化并提取内容无关的退化表征，从而在多项复原任务中取得可竞争的性能。

3.1　引言

在数字图像的生命周期中，成像、存储与传输各环节均可能面临退化问题。例如，成像阶段受退化影响可能产生雨、雾等多样化退化。在存储与传输阶段，常采用有损压缩（如 JPEG 压缩）以节省带宽与存储空间，不同的压缩等级也会给图像带来不同的退化效应。各类退化对图像造成的影响具有差异性，因此需要针对性的处理策略。早期研究通常为每一类退化分别训练独立模型权重，比如在恶劣天气图像复原中给雨、雾和雪分别训练一个权重，在 JPEG 压缩图像复原中，给每个不同的压缩质量因子（Quality Factor, QF）训练不同的权重，但这种做法不仅使得模型冗余，其扩展性与灵活性也较差。随着研究推进，越来越多的工作转向以单一模型同时处理多种退化，从而提升模型的灵活性与适应性。

中国知网　https://www.cnki.net

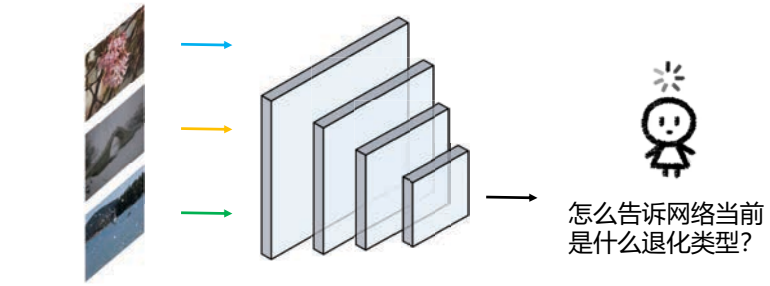


图 3.1　图像的退化类型难以通过监督学习区分

现有许多面向多退化的图像复原方法[108,110]在设计时未能充分考虑不同退化类型之间的差异，往往将多种退化图像直接混合后输入同一模型进行处理。虽然这种方式在一定程度上提升了模型的适用范围，但也带来了新的问题：由于模型难以感知和区分具体的退化类型，复原过程缺乏针对性，从而导致复原效果不够精确与稳健。为了提升模型对多种退化的区分能力，一些研究[74,109]引入了静态多分支结构，即在主干网络上设计多个分支通路，各自负责处理不同类型或不同程度的退化。然而，这一结构与完全独立权重的方法一样，依然面临缺乏灵活性且可扩展性受限的问题。基于以上分析，图像复原模型的核心问题在于：如何使模型能够感知输入图像的退化类型，并基于这一感知提取内容无关的退化表征，从而实施有针对性的退化去除策略。然而，如图3.1所示，用于描述退化程度的高级语义标签（例如“雨”、“高压缩等级”等）与图像表征之间存在显著的语义鸿沟，使得难以通过传统有监督学习利用这些标签指导模型区分退化类型；同时，在视觉表征层面获得的退化类型标签也难以精确标注。因此，图像复原模型面临的关键难点在于，如何设计合理的学习机制，使其即便在缺少显式退化类型标签的情况下，也能自主感知并区分多样化的退化模式。

针对上述问题，本章提出一种无监督的退化表征学习策略。该策略不依赖显式标签的监督约束，转向挖掘退化图像自身蕴含的退化特性。具体而言，本章构建退化表征编码器，将退化表征学习建模为图像到特征向量的转换，而不是直接进行退化类型的分类或数值回归。本章采用无监督对比学习训练退化表征编码器，如图 3.2所示，通过构建正负样本对，约束退化表征编码器在特征空间中拉近同类退化的正样本，远离异类退化的负样本。通过这种对比机制，网络无需依赖退化类型的显式标签，也能够自主聚合同类退化特征，远离异类退化特征，从而促使模型自适应感知退化，并提取出与内容无关、具有判别性的退化表征。相较于依赖显式标签的监督方法[77]，这一无监督对比学习策略能够充分挖掘不同退化类型之间的内在差异性，提升退化表征的判别性。并且使用该方法学习的特征空间具有连续性，模型能够自适应从已知退化类型外推到未知复杂退化情况。当模型面对训练场景中尚未出现过的退化类型时，也能借助已学特征关系进行

中国知网　https://www.cnki.net

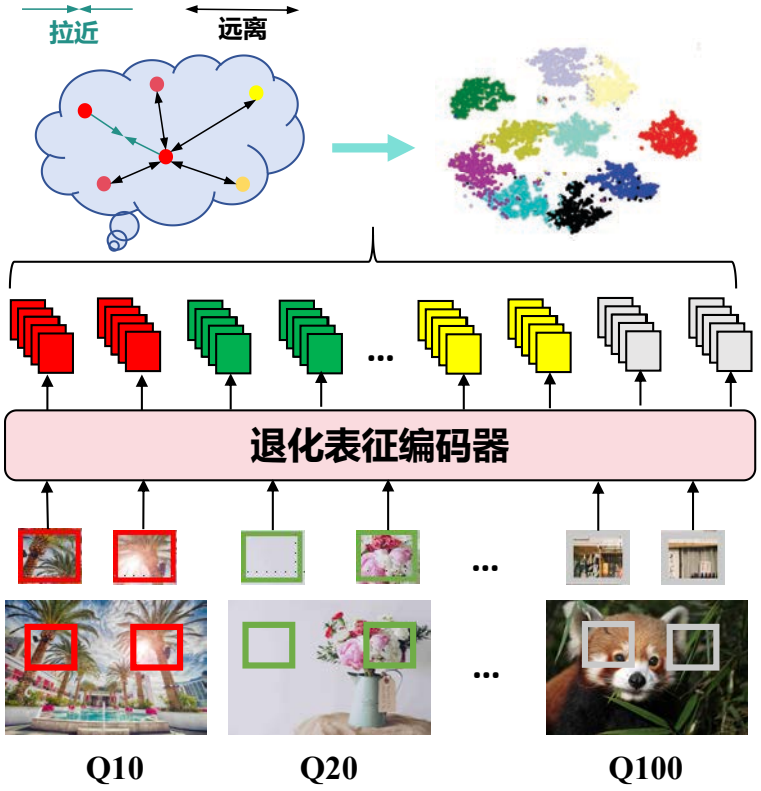


图 3.2　退化表征编码器

注：Q 表示 JPEG 压缩的压缩质量因子，Q 的数值越小，压缩程度越高。

合理推断，从而显著提升对未见退化类别的适应能力。在此基础上，本章还设计了退化特征引导的复原网络 DRNet。通过一种信息无损的方式，将退化表征编码器得到的退化表征集成到复原解码器中，使网络能够依据学习到的退化表征，采取有针对性的退化去除策略，从而实现自适应的图像复原。

本章的主要贡献包括：

- 提出了一种退化表征感知与提取策略，该策略基于无监督对比学习，无需依赖显式标注的退化类型标签，而是通过合理构建正负样本对，充分挖掘退化图像自身蕴含的退化特征信息。该方法能够有效捕捉和区分不同退化类型之间的内在差异，从而为图像复原提供稳健且具备判别性的退化表征基础。
- 设计了一种基于退化特征引导的图像复原机制，通过无损嵌入的方式，将无监督对比学习提取到的的退化表征作为指导信息融合至复原解码器中，从而实现针对不同退化类型的自适应复原，显著提升了模型在多种退化类型下的自适应能力。

中国知网　https://www.cnki.net

3.2　背景知识

本章方法基于对比学习与可逆网络实现，因此本节先介绍相关背景知识。

3.2.1　对比表示学习

在深度学习的发展过程中，监督学习取得了显著的成果，但其优异表现往往依赖于大量高质量的人工标注数据。但有时标签的获取成本高昂且耗时，难以覆盖所有场景。为应对这一问题，学者们开始研究无监督学习[138-143]，其核心目标是在没有人工标签的情况下，使模型能够自行挖掘数据中的潜在特征。在无监督学习中，表示学习[141,144-145]是一个重要分支，它的核心任务不是简单地对数据进行聚类或分组，而是希望模型能够自动学习到一种高效且紧凑的特征表示，这种特征表示既能够体现数据的本质属性，又能为下游的分类、检测等任务提供坚实的基础。

近年来，对比学习[144,146-147]已经成为无监督表示学习领域最为常用的方法之一。该方法的核心思想是通过对比不同样本之间的相对关系来学习特征空间。具体而言，它不直接关注单个样本的类别或标签，而是强调样本之间的相对关系，其目标在于构建一个特征空间，使得相似的样本对（即正样本对）在该特征空间中距离更近，而不相似的样本对（即负样本对）则尽量远离。这种方式能够引导模型利用整体数据分布，自主形成具有判别力的特征分布。对比学习的关键在于如何在没有人工标签的条件下构建正负样本对。在计算机视觉领域，常见的做法是利用数据增强策略来生成正负样本对。具体操作时，通常可以对同一张图片应用两种不同的随机增强操作（例如随机裁剪、旋转、颜色扰动等），这样得到的两幅图像，在像素分布上有所差异，但语义内容是一致的，因此被认为是相似的正样本对。而来自不同原始图片的图像因为语义层面的差异则视为负样本对。

3.2.2　动量对比学习

在早期的对比学习方法如 SimCLR[144]中，需要使用极大的训练批次来获取足够多的负样本，这对计算资源的要求极高。为了解决这一难题，He 等人提出了动量对比学习[147]（Momentum Contrastive Learning, MoCo），并获得了广泛应用。MoCo 的核心创新在于采用了动态队列结构和动量编码器机制。具体来说，MoCo 使用一个动态更新的队列存储历史批次中产生的负样本特征。每进行一次训练迭代时，当前批次得到的新负样本特征会被加入到队列之中，而最早的那些特征则会被移出，这一过程可表述为：

$$\mathrm{Q}_K \leftarrow \mathrm{Concat}\left(\mathrm{N}_K,\ \mathrm{Q}_K[:-B]\right), \tag{3.1}$$

中国知网　https://www.cnki.net

其中，N_K 代表当前批次新生成的负样本特征，$\mathrm{Q}_K[:-B]$ 表示原队列去除最旧的 B 个特征，B 为批次大小。这种设计允许模型在实际远小于理论需求的批次大小下，依然能够利用多个历史批次累积的大量负样本，从而大大减少对比学习对于计算资源的需求。此外，为保证队列中负样本特征的一致性，MoCo 引入了动量编码器，负样本编码器的参数通过主编码器权重的指数滑动平均进行更新，其更新公式如下：

$$\theta_k \leftarrow m \cdot \theta_k + (1-m) \cdot \theta_q, \tag{3.2}$$

其中，θ_q 表示查询编码器的参数，θ_k 为动量负样本编码器的参数，m 是动量系数。通过这种方式，可以有效降低负样本特征分布在训练过程中的剧烈波动，进而提高训练的稳定性和一致性。

对比学习通常用 InfoNCE 损失函数[140]作为优化目标，这一损失能够在促使模型实现拉近正样本，推远负样本的目标，其表达式如下：

$$L_q = -\log \frac{\exp\left(q \cdot k^+/\tau\right)}{\sum_{i=1}^{N_{neg}} \exp\left(q \cdot k_i^-/\tau\right)}, \tag{3.3}$$

其中，q 表示查询样本的特征表示，k^+ 表示正样本的特征，k_i^- 表示第 i 个负样本的特征，N_{neg} 为负样本数量，τ 是温度超参数，用于调整分布的平滑程度，$q \cdot k$ 为两特征向量之间的点积，度量了它们的相似度。

3.2.3　可逆网络

可逆神经网络（Invertible Neural Network, INN）[148-149]是一类具有双射性质的特殊神经网络，其核心目标是在前向与逆向映射之间建立严格的映射关系。具体而言，INN 在设计时确保前向函数 f 是数学上的可逆函数，即对于任意输出 y 都可以通过唯一的逆映射精确还原出输入 x。这使得网络在特征抽取与融合过程中不会丢失任何信息，有助于信息的无损传递与高效重构。INN 的理论基础源于概率论中的变量变换定理，通过将一个基础分布 $p_Z(z)$ 经过可逆函数 f 映射到复杂分布 $p_X(x)$，可以精确计算其概率密度：

$$p_X(x) = p_Z(f(x)) \left| \det\left(\frac{\partial f(x)}{\partial x}\right) \right|. \tag{3.4}$$

然而，直接求解高维雅可比矩阵 $\frac{\partial f(x)}{\partial x}$ 的行列式 $\det(\cdot)$，在实际中通常计算量巨大。为此，主流的可逆网络通常采用耦合层结构，将输入 x 按通道分为 x_1 和 x_2 两部分，利用部分保持不变、部分条件变换的构造，有效简化了雅可比行列式的计算复杂度。其加性耦合层变换表达式如下：

$$\begin{aligned} y_1 &= x_1 + F(x_2), \\ y_2 &= x_2 + G(y_1). \end{aligned} \tag{3.5}$$

中国知网　https://www.cnki.net

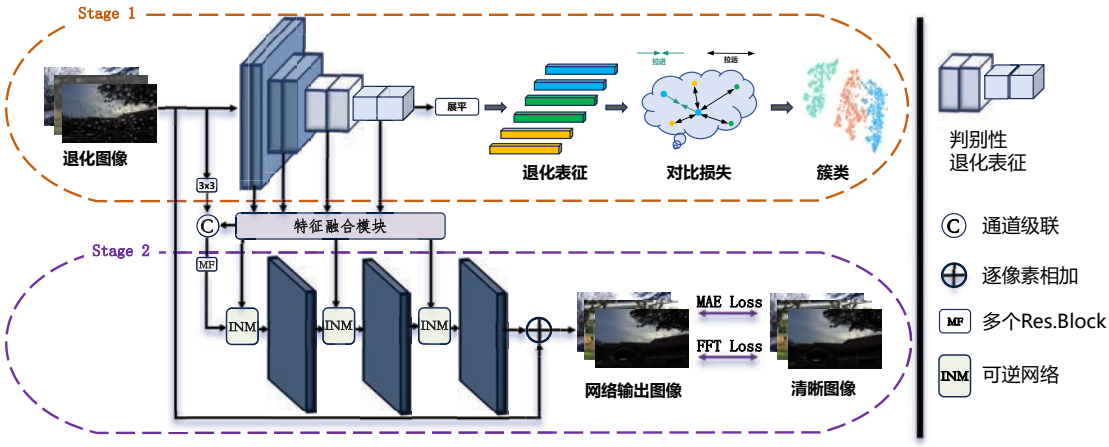


图 3.3　DRNet 模型框架图

其中，$F(\cdot)$ 和 $G(\cdot)$ 通常由可以学习的神经网络实现，分别根据 x_2 和 y_1 输出映射。由于加性耦合层的雅可比矩阵同样呈三角结构，其行列式恒为 1，因此能够无需复杂运算即可完成概率密度的高效求解，从而极大简化了逆向映射和概率建模的计算过程。

3.3　方法介绍

本章方法框架图如图3.3所示，本节首先介绍退化表征编码器的学习策略，进而说明其提取的表征如何用于图像复原。

3.3.1　基于无监督对比学习的自适应退化表征学习

本章采用无监督对比学习的方法，挖掘退化图像自身蕴含的判别性退化表征。为实现该目标，本章构建退化表征编码器，并设定同一张图像中的图像块具有相同的退化类型，而不同图像中的图像块则对应不同的退化类型。每张图像可裁剪出多个图像块，来自同一张图像的图像块被视为正样本，而不同图像的图像块则作为负样本。所有图像块输入退化表征编码器以提取特征，并在特征空间中进行对比学习约束，从而实现退化表征的提取。退化表征编码器采用多层级特征提取网络，其在四个层级上的输出特征分别记为 $\mathrm{E0}, \mathrm{E1}, \mathrm{E2}, \mathrm{E3}$，其训练步骤如下：

- 训练数据准备：在退化表征编码器的训练阶段，从每种退化类型的数据集中各随机选取一张图像，以此构成一个小批量，将该批次的大小记为 B，并用索引 $i = 1, 2, \cdots, B$ 标识其中的每一张图像。这样的批次构建方式保证了单个批次内包含多种退化类型的样本。
- 图像块裁剪：对每一张被选中的退化图像，随机裁剪得到两个非重合的图像块，分别记为 p_i^1 与 p_i^2，二者均来自第 i 张图像但对应不同的空间位置，

中国知网　https://www.cnki.net

由此可得两个图像块集合 $\{p_i^1\}_{i=1}^{B}$ 与 $\{p_i^2\}_{i=1}^{B}$。

- 退化表征提取：将上述两个图像块集合分别输入退化表征编码器，获得对应的表征向量集合 $\{c_i^1\}_{i=1}^{B}$ 与 $\{c_i^2\}_{i=1}^{B}$。
- 正负样本选取：在对比学习的构造中，对每个索引 i，将来自同一图像的表征对 (c_i^1, c_i^2) 设为“查询-正样本”对，其中 c_i^1 作为查询，c_i^2 作为正样本。同时，将其余图像（$j = 1, 2, \cdots, B$ 且 $j \neq i$）上随机裁剪得到的图像块对应的表征 c_j^1 与 c_j^2 视为负样本，用于与查询进行区分。
- 学习目标：理想情况下，应使 c_i^1 与 c_i^2 在表征空间中尽可能接近，从而加强同一图像内部（相同退化类型）的表征一致性；同时，使 c_i^1 与 c_j^1、c_j^2（$j \neq i$）尽可能分离，从而提升不同图像（不同退化类型）之间表征的可判别性。
- 负样本队列策略：借鉴 MoCo 的实现，本章采用一个队列来维护负样本表征。该队列用于动态存储近期训练中产生的负样本表征，当新批次到来时，将本批次对应的负样本表征加入队列。当队列达到既定容量时，最早进入的表征将被移出，以此在单个批次之外聚合更丰富的负样本集合。
- 损失函数：对比学习的目标通过如下损失进行度量与优化：

$$\mathcal{L}_{DRE} = -\sum_{i=1}^{B} \log \frac{\exp\left(c_i^1 \cdot c_i^2 / \tau\right)}{\sum_{j=1}^{N_{neg}} \exp\left(c_i^1 \cdot c_j^{1,2} / \tau\right)}. \tag{3.6}$$

其中，分子项衡量查询 c_i^1 与正样本 c_i^2 的相似度，τ 为温度参数，分母项对负样本队列中的 N_{neg} 个负样本表征 $c_j^{1,2}$ 的相似度进行求和。通过最大化分子相似度、最小化分母中负样本的聚合相似度，模型被约束去拉近正样本对、远离负样本对。

3.3.2　基于退化表征引导的复原解码器

获得退化表征后，为了充分利用这些信息，本章设计了一种退化表征引导的方式，将学习到的退化表征以信息无损的方式融合到复原解码器中。该解码器包含多尺度信息无损融合模块和复原模块。

1. 多尺度信息无损融合模块

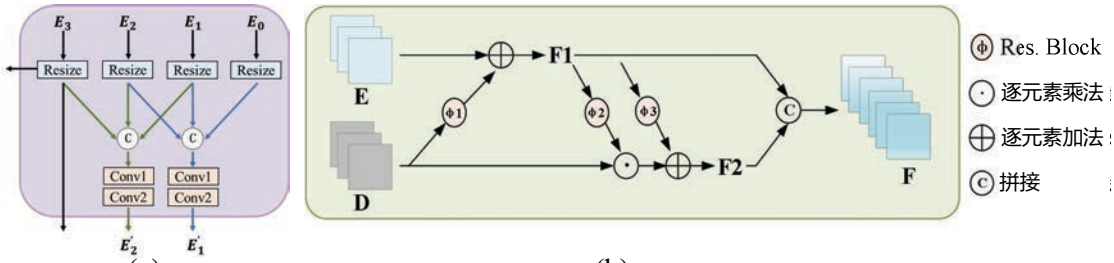
为了更好地将退化表征编码器学习到的判别性表征整合到后续的复原网络中，本章进一步设计了多尺度信息无损融合模块，如图 3.4所示。首先，由于网络不同尺度之间的特征存在密切关联，本章尽可能地融合来自退化表征编码器各尺度的特征图。具体而言，本章将编码器每个尺度的特征输入到编码器特征融合模块（Encoder Feature Fusion Module, EFFM），并将它们调整至相同的尺度。E1 和 E2 分别融合了相邻尺度的特征图。如果直接将这些特征图进行拼接后输入后续网络，会导致大量的计算，为了降低计算量，本章引入了两次卷积操作对其进

中国知网　https://www.cnki.net

行融合，输出的特征图分别记为 E_1' 和 E_2'，具体计算公式如下：

$$\begin{aligned} E_1' &= \mathrm{EFFM}[E_0, E_1, E_2], \\ E_2' &= \mathrm{EFFM}[E_1, E_2, E_3], \end{aligned} \tag{3.7}$$

其中，$[\cdot]$ 表示沿通道维度的拼接操作。



(a)　　(b)

图 3.4　多尺度信息无损融合模块

在对退化表征编码器进行特征融合之后，为了让其能够更好地适应后续的复原网络，本章在设计时不仅考虑了特征之间的有效融合，同时也关注了信息的无损传递。具体而言，退化特征与复原网络在表征空间上存在分布差异，直接拼接或融合容易造成特征适配不充分甚至部分信息丢失。因此，为了确保退化特征能够被充分且无损地注入复原过程，本章基于可逆网络设计了信息无损融合模块（Lossless Information Fusion Module, LIFM）。可逆网络具备信息无损的特性，能够在融合退化表征编码器与复原解码器特征的同时，保证每一层输入特征的信息可以被完整保留与还原，从而实现退化表征与复原网络特征的有效融合。在本章的模型中，共使用了三个信息无损融合模块，分别对应退化表征编码器特征融合后的三个输出特征。信息无损融合模块要求输入被划分为两部分，本章将来自 EFFM 的特征与后续复原解码器的特征分别作为输入，记为 $\boldsymbol{E}$ 和 $\boldsymbol{D}$。以其中一个模块为例，其执行以下操作：

$$\begin{aligned} \boldsymbol{F}_1 &= \boldsymbol{E} + \phi_1(\boldsymbol{D}), \\ \boldsymbol{F}_2 &= \boldsymbol{D} \odot \exp(\phi_2(\boldsymbol{F}_1)) + \phi_3(\boldsymbol{F}_1), \\ \boldsymbol{F} &= \mathrm{Concat}(\boldsymbol{F}_1, \boldsymbol{F}_2), \end{aligned} \tag{3.8}$$

其中 $\exp(\cdot)$ 和 $\odot$ 分别表示指数函数和逐元素乘法运算。本章采用残差块来实现 ϕ_1、ϕ_2 和 ϕ_3，每个残差块由两个 3×3 卷积层和中间的 LeakyReLU[150] 激活函数组成。

2. **复原模块**

每个可逆神经模块的输出都送入基于 RNAN[151] 构建的复原模块。网络随后应用卷积核大小为 1×1 的卷积层将特征恢复到原始图像通道数。最后，本章采用全局残差学习，将输入与预测图像相加，从而实现更快速的训练过程。

中国知网　https://www.cnki.net

3.3.3　损失函数

本章同时在空间域和频率域对图像复原模型进行约束。

1. 空间域损失函数

在空间域约束中，本章采用平均绝对误差损失函数，用于减小预测图像与真实图像之间的差距。具体定义如下：

$$\mathcal{L}_1 = \frac{1}{B}\sum_{i=1}^{B} \| I_{pre}^{i} - I_{gt}^{i} \|_1, \tag{3.9}$$

其中，I_{pre}^{i} 表示第 i 个预测图像，I_{gt}^{i} 表示第 i 个清晰图像，$\sum \| \cdot \|_1$ 表示取绝对值后再求和，B 表示一个小批次中的图像数量。

2. 频率域损失函数

在退化条件下，图像常常会出现高频细节被模糊或遮挡的情况，导致图像的纹理和边缘等频域信息受损。为了更好地恢复和约束图像在频率域上的细节，本章引入了频率域损失函数。

具体地，本章采用快速傅里叶变换将预测图像和真实图像转换到频域，再计算二者的差异。频域损失的定义如下：

$$\mathcal{L}_{FFT} = \frac{1}{B}\sum_{i=1}^{B} \left\| FFT(I_{pre}^{i}) - FFT(I_{gt}^{i}) \right\|_1, \tag{3.10}$$

其中，$FFT(\cdot)$ 表示对图像进行快速傅里叶变换。该损失项可以有效约束模型在频域上恢复更多的细节信息，提高退化图像的复原质量。

3. 总损失函数

将空间域损失和频率域损失进行加权组合，得到最终的总损失函数：

$$\mathcal{L}_{total} = \mathcal{L}_1 + \lambda \mathcal{L}_{FFT}, \tag{3.11}$$

其中，λ 为平衡两者权重的超参数，在本章的实验中取值为 0.1。

3.4　实验与分析

本节首先展示本章方法与其他方法在各图像复原任务上的定量与定性对比结果。随后，分析本章方法设计的合理性。接着，通过消融实验验证本章所提方法的有效性。最后，指出本章方法的不足之处。

3.4.1　实验细节

本章模型采用两阶段训练策略。第一阶段训练退化表征编码器时，在 JPEG 图像复原任务中，每次迭代输入图像的压缩质量因子（Quality Factor, QF）取值

中国知网　https://www.cnki.net

表 3.1　DRNet 在 Outdoor-Rain 数据集的定量指标

(a) 专用模型

方法	PSNR↑	SSIM↑
pix2pix[67]	19.09	0.71
HRGAN[63]	21.56	0.86
MPRNet[93]	21.90	0.85

(b) 自适应模型

方法	PSNR↑	SSIM↑
All-in-One[74]	24.71	0.90
TransWeather[75]	23.18	0.84
TKL&MR[107]	23.94	0.85
WGWS-Net[109]	25.31	0.90
Histoformer[113]	29.86	0.93
DRNet	30.20	0.93

表 3.2　DRNet 在 Raindrop 数据集的定量指标

(a) 专用模型

方法	PSNR↑	SSIM↑
pix2pix[67]	28.02	0.85
Attn.Gan[78]	30.55	0.90
CCN[152]	31.34	0.95

(b) 自适应模型

方法	PSNR↑	SSIM↑
All-in-One[74]	31.12	0.93
TransWeather[75]	28.98	0.90
TKL&MR[107]	30.75	0.91
WGWS-Net[109]	31.31	0.93
Histoformer[113]	31.25	0.94
DRNet	30.92	0.92

范围为 10 到 100，步长为 10；在恶劣天气复原任务中，每次迭代随机输入雨、雾和雪图像；在雨-雾-噪声图像复原任务中，每次迭代随机输入雨、雾、噪声标准差 15、噪声标准差 25 和噪声标准差 50 的图像。三个任务在第一阶段学习率均设为 1e-3，训练 200 个 epoch，并采用余弦退火将学习率衰减至 1e-5，随后冻结编码器权重。第二阶段训练复原解码器，三个任务训练设置相同，初始学习率为 1e-4，训练 500 个 epoch，使用周期 T=500 的余弦退火将学习率衰减至 1e-6，并采用 Adam 优化器[157]（$\beta_1 = 0.9$，$\beta_2 = 0.999$）进行参数更新。

中国知网　https://www.cnki.net

表 3.3　DRNet 在 SnowTest100K-L 数据集的定量指标

(a) 专用模型

方法	PSNR↑	SSIM↑
DetailsNet[153]	19.18	0.75
DesnowNet[69]	27.17	0.90
JSTASR[105]	25.32	0.81
DDMSNET[154]	28.85	0.88

(b) 自适应模型

方法	PSNR↑	SSIM↑
All-in-one[74]	28.33	0.88
TransWeather[75]	27.80	0.85
TKL&MR[107]	29.27	0.88
WGWS-Net[109]	29.71	0.89
Histoformer[113]	30.76	0.91
DRNet	30.01	0.90

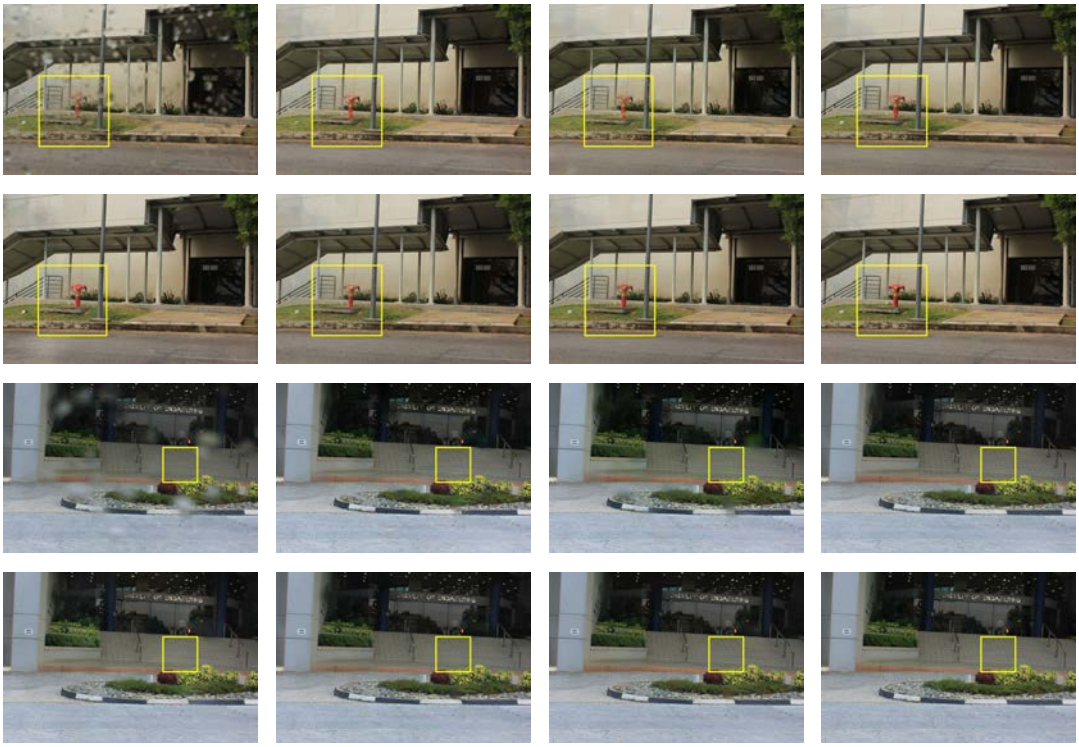


图 3.5　DRNet 在 Raindrop 数据集与其他方法可视化对比

注：从左上到右下依次是：输入图像，TKL&MR，TransWeather，WGWS-Net，Histoformer，DRNet，清晰图像。

3.4.2　实验结果

本章在恶劣天气图像复原、JPEG 图像复原以及雨-雾-噪声图像复原进行实验，定量结果和定向结果汇报如下。

中国知网　https://www.cnki.net

表 3.4　DRNet 在 JPEG 图像复原的定量指标

QF		方法	Classic5			LIVE1			BSDS500		
			PSNR↑	SSIM↑	PSNR-B↑	PSNR↑	SSIM↑	PSNR-B↑	PSNR↑	SSIM↑	PSNR-B↑
10	专用模型	输入图像	27.82	0.760	25.21	27.77	0.773	25.33	27.80	0.768	25.10
		ARCNN[114]	29.03	0.793	28.76	28.96	0.808	28.68	29.10	0.804	28.73
		MWCNN[73]	30.01	0.820	29.59	29.69	0.825	29.32	29.61	0.820	29.14
		RNAN[151]	29.96	0.819	29.42	29.63	0.824	29.13	29.08	0.805	28.48
		RDN[118]	30.03	0.819	29.59	29.70	0.825	29.37	29.24	0.808	28.71
	自适应模型	DnCNN[66]	29.40	0.803	29.13	29.19	0.812	28.90	29.21	0.809	28.80
		DCSC[122]	29.62	0.810	29.30	29.34	0.818	29.01	29.32	0.813	28.91
		QGAC[76]	29.84	0.812	29.43	29.51	0.825	29.13	29.46	0.821	28.97
		FBCNN[77]	30.12	0.822	29.80	29.75	0.827	29.40	29.67	0.821	29.22
		DRNet	30.16	0.822	29.85	29.80	0.827	29.44	29.70	0.822	29.27
20	专用模型	输入图像	30.12	0.834	27.50	30.07	0.851	27.57	30.05	0.849	27.22
		ARCNN[114]	31.15	0.852	30.59	31.29	0.873	30.76	31.28	0.870	30.55
		MWCNN[73]	32.16	0.870	31.52	32.04	0.889	31.51	31.92	0.885	31.15
		RNAN[151]	32.11	0.869	31.26	32.03	0.888	31.12	31.25	0.875	30.27
		RDN[118]	32.19	0.870	31.53	32.10	0.889	31.29	31.48	0.879	30.45
	自适应模型	DnCNN[66]	31.63	0.861	31.19	31.59	0.880	31.07	31.53	0.878	30.79
		DCSC[122]	31.81	0.864	31.34	31.70	0.883	31.18	31.63	0.880	30.92
		QGAC[76]	31.98	0.869	31.37	31.83	0.888	31.25	31.73	0.884	30.93
		FBCNN[77]	32.31	0.872	31.74	32.13	0.889	31.57	32.00	0.885	31.19
		DRNet	32.37	0.873	31.84	32.19	0.890	31.63	32.06	0.886	31.27
30	专用模型	输入图像	31.48	0.867	28.94	31.41	0.885	28.92	31.37	0.884	28.53
		ARCNN[114]	32.51	0.881	31.98	32.67	0.904	32.14	32.67	0.902	31.94
		MWCNN[73]	33.43	0.893	32.62	33.45	0.915	32.80	33.30	0.912	32.34
		RNAN[151]	33.38	0.892	32.35	33.45	0.915	32.22	32.70	0.907	31.33
		RDN[118]	33.46	0.893	32.59	33.54	0.916	32.62	32.83	0.908	31.60
	自适应模型	DnCNN[66]	32.91	0.886	32.38	32.98	0.909	32.34	32.90	0.907	31.97
		DCSC[122]	33.06	0.888	32.49	33.07	0.911	32.43	32.99	0.908	32.08
		QGAC[76]	33.22	0.892	32.42	33.20	0.914	32.47	33.07	0.912	32.04
		FBCNN[77]	33.54	0.894	32.78	33.54	0.916	32.83	33.37	0.913	32.32
		DRNet	33.60	0.895	32.89	33.62	0.918	32.91	33.45	0.914	32.41
40	专用模型	输入图像	32.43	0.885	29.92	32.35	0.904	29.96	32.30	0.903	29.49
		ARCNN[114]	33.32	0.895	32.79	33.61	0.920	33.11	33.55	0.918	32.78
		MWCNN[73]	34.27	0.906	33.35	34.45	0.930	33.78	34.27	0.928	33.19
		RNAN[151]	34.27	0.906	33.40	34.47	0.930	33.66	33.47	0.923	32.27
		RDN[118]	-	-	-	-	-	-	-	-	-
	自适应模型	DnCNN[66]	33.77	0.900	33.23	33.96	0.925	33.28	33.85	0.923	32.80
		DCSC[122]	33.87	0.902	33.30	34.02	0.926	33.36	33.92	0.924	32.92
		QGAC[76]	34.05	0.905	33.12	34.16	0.929	33.36	34.01	0.927	32.81
		FBCNN[77]	34.35	0.907	33.48	34.53	0.931	33.74	34.33	0.928	33.10
		DRNet	34.43	0.908	33.58	34.62	0.931	33.84	34.42	0.929	33.22

1. 恶劣天气图像复原

在 Outdoor-Rain 数据集上，为了评估本章提出的 DRNet 模型的雨 + 雾图像复原性能，将其与两类方法进行了比较。第一类是专用模型，包括 pix2pix[67]、HRGAN[63]和 MPRNet[93]。第二类是自适应图像复原模型，包括 All-in-One[74]、TransWeather[75]、TKL&MR[107]、WGWS-Net[109]以及 Histoformer[113]。如表3.1所示，本章方法在峰值信噪比（Peak Signal-to-Noise Ratio，PSNR）上达到了 29.94dB，

中国知网　https://www.cnki.net

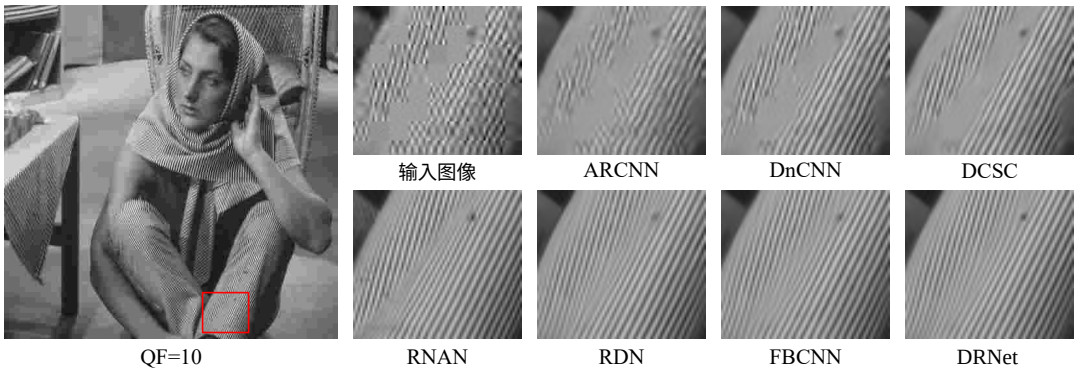


图 3.6　DRNet 在 LIVE1 数据集与其他方法可视化对比

表 3.5　DRNet 在雨-雾-噪声图像测试数据集的定量指标

方法	CBSD68[87]			SOTS[84]	Rain100L[85]	平均
	$\sigma=15$	$\sigma=25$	$\sigma=50$			
专用模型 (PSNR↑/SSIM↑)						
LPNet[155]	26.47/0.778	24.77/0.748	21.26/0.552	20.84/0.828	24.88/0.784	23.64/0.738
ADFNet[156]	33.76/0.929	30.83/0.871	27.75/0.793	28.13/0.961	34.24/0.965	30.94/0.904
DehazeFormer[102]	33.01/0.914	30.14/0.858	27.37/0.779	29.58/0.970	35.37/0.969	31.09/0.898
DRSformer[98]	33.28/0.921	30.55/0.862	27.58/0.786	29.02/0.968	35.89/0.970	31.26/0.902
自适应模型 (PSNR↑/SSIM↑)						
DL[130]	33.05/0.914	30.41/0.861	26.90/0.740	26.92/0.391	32.62/0.931	29.98/0.875
IDR[131]	33.89/0.931	31.32/0.884	28.04/0.798	29.87/0.970	36.03/0.971	31.83/0.911
ProRes[132]	32.10/0.907	30.18/0.863	27.58/0.779	28.38/0.938	33.68/0.954	30.38/0.888
PromptIR[133]	33.98/0.933	31.31/0.888	28.06/0.799	30.58/0.974	36.37/0.972	32.06/0.913
NDR[134]	34.01/0.932	31.36/0.887	28.10/0.798	28.64/0.962	35.42/0.969	31.51/0.910
Gridformer[135]	33.93/0.931	31.37/0.887	28.11/0.801	30.37/0.970	37.15/0.972	32.19/0.912
DRNet	34.03/0.931	31.38/0.886	28.12/0.796	30.37/0.978	38.41/0.983	32.46/0.915

取得了所有对比方法中的最佳性能。

在 RainDrop 数据集上，本章提出的 DRNet 模型同样与专用任务模型（pix2pix[67]，Attn.Gan[78]，CCN[152]）和自适应模型（All-in-One[74]，TransWeather[75]，TKL&MR[107]，WGWS-Net[109]，Histoformer[113]）进行了定量比较。

在 SnowTest100K-L 数据集上，如表3.3所示，DRNet 模型在两种不同的测试设置下与多种方法进行了对比，其中包括 DesnowNet[69]和 DDMSNET[154]等专用的雪图复原模型，以及一系列自适应模型。

本章方法与其他方法在 RainDrop 数据集的视觉效果对比如图3.5所示，可以看出本章方法更好的重建了楼梯处的纹理细节。

2. JPEG 压缩图像复原

在 JPEG 压缩图像复原任务上，本章基于三个经典数据集（Classic5、LIVE1、BSDS500）和多个压缩质量因子（QF $\in \{10, 20, 30, 40\}$）对本章提出的模型 DRNet 进行系统评估，并与两类代表性方法进行对比：一类为针对固定 QF 训练的专用模型，如 ARCNN[114]、MWCNN[73]、RNAN[151]、RDN[118]，另一类为统一应

中国知网　https://www.cnki.net

对多种 QF 的自适应模型，如 DnCNN[66]、DCSC[122]、QGAC[76]、FBCNN[77]。如表3.4所示，在不同数据集与 QF 设置下，DRNet 在 PSNR/SSIM/PSNR-B 指标上整体取得最优或并列最优表现。例如，在 Classic5 上，DRNet 在各 QF 均超过或持平 FBCNN[77]；在 LIVE1 和 BSDS500 上，DRNet 也在 SSIM 与 PSNR-B 上持续提升，显示出对 JPEG 图像更强的复原能力。

在 JPEG 图像复原任务的的 LIVE1 测试集上，本章与多种方法进行了定性对比。如图3.6所示，本章方法在条纹等细节的复原上表现更佳。

3. **雨-雾-噪声图像复原**

在雨-雾-噪声图像复原任务上，为全面评估本章提出的 DRNet 模型的跨退化恢复能力，本文将其与两类对比方法进行了定量比较。如表3.5所示，第一类为专用模型，包括 LPNet[155]、ADFNet[156]、DehazeFormer[102] 以及 DRSformer[98]，它们分别针对单一退化任务进行优化。第二类为自适应模型，包括 DL[130]、IDR[131]、ProRes[132]、PromptIR[133]、NDR[134] 以及 Gridformer[135]，可以根据输入退化类型自适应调整恢复策略。从表3.5中的 PSNR 和 SSIM 指标可以看出，DRNet 在不同类型的退化测试集性能超越的现有方法。

3.4.3　方法分析

为了训练退化表征编码器，本章采用将同一张退化图像中不同位置的图像块作为正样本的策略。下面以恶劣天气图像和 JPEG 压缩图像为例，分析该策略的可行性。

对于恶劣天气图像而言，成像通常发生在同一时刻、相同的外部条件下，因此其整体退化过程由统一的物理成像机制所主导，在空间维度上表现出连续性与关联性。具体到不同的天气类型：

- 雨天图像：雨的物理形态如倾斜角度和密度主要由风向、降雨强度等因素共同决定，这些因素在单次曝光期间通常保持稳定。Garg 与 Nayar 等人[158]通过物理与成像分析揭示，雨滴的空间分布规律与其高速运动在曝光期间的稳定性，会在图像中产生可预测的统计一致性。因此，雨退化在单幅图像内具有较强的全局相关性。早期研究中，Fu 等人[159]也指出，单张图像内的雨条纹分布往往呈现相似的统计模式，雨条纹在方向与尺度上具有显著的全局相关性。
- 雾天图像：雾图退化主要由大气散射模型刻画。根据 He 等人[160]提出的暗通道先验，描述场景光线穿透介质能力的透射率图是表征退化的关键。透射图在局部区域通常平滑，且数值与场景深度直接相关。由于场景深度多为连续变化，透射图呈现空间缓变的低频特性。因此，由透射图导致的能见度下降与颜色偏移等效应在相邻或相近图像块间不会突变，保证了全局

中国知网　https://www.cnki.net

退化的一致性。

- 雪天图像：雪天导致的退化更为复杂，通常由雪花颗粒、动态雪条纹以及类似薄雾的面纱效应的混合构成。尽管雪花的具体位置看似随机，但单幅图像内的整体退化特征往往一致：例如整体表现为“大而密集”或“小而稀疏”的雪花，并且其尺寸、密度与透明度在空间上具有较强相关性。基于这种全局一致性，DesnowNet[69]通过估计全局的雪类型参数或空间平滑的雪掩码来消除降雪影响。

对于 JPEG 压缩图像而言，同一张 JPEG 图像由相同的质量因子、量化表配置压缩，因此退化强度在全图范围内一致，不同位置的图像块共享相同的退化机制，下面详细解释：

- 分块处理（8×8 ）带来的空间周期一致性：JPEG 首先将图像划分为若干 8×8 的图像块，并对各块独立处理。这种全局一致的分块与对齐方式在整幅图像中引入稳定的 8 像素空间周期，使得块边界处更容易出现亮度的不连续与块状伪影，同时块内呈现相对平坦化的倾向。由于分块规则在整图范围内完全一致，边界相关的退化模式在不同位置重复出现，因而同一图像中任意两个位置的图像块在这类空间域伪影的统计特征上高度相似；
- DCT 与统一量化带来的频带选择性一致性：在每个 8×8 块上进行 DCT 后，会使用由统一质量因子（Quality Factor, QF）派生的固定量化表进行量化，各频带的量化步长在全图范围保持一致，普遍对高频分量更强抑制。这使得不同频带受到的量化强度在整幅图像中一致，都在边缘与细纹理区域出现相似的细节丢失与振铃现象。

综上所述，退化图像的退化过程遵循统一或缓变的规律，使得退化表征在同一张图片空间上具有相似性与可迁移性。因此，本章采用以同一退化图像中不同位置的图像块作为正样本的策略来训练编码器，旨在使其专注学习与内容无关的退化表征。

相应地，负样本取自不同图像上裁剪得到的图像块。为确保负样本在退化模式上具有足够的可分辨性，本章在训练退化表征编码器时对批次构成加以约束，即每个批次中的图像退化类型各不相同。具体地，在恶劣天气场景中，一个批次分别包含雨、雾、雪三类图像，雨、雾、雪分别由不同的物理过程主导，在结构模糊程度与条纹形态等方面存在本质差别，可作为天然的负样本依据。在 JPEG 压缩场景中，一个批次包含来源于不同压缩质量因子（Quality Factor, QF）的图像，由于在 JPEG 压缩中，质量因子与量化表直接决定各频带的量化步长，从而改变高频抑制强度与伪影的显著程度，不同压缩质量的图像在退化强度上呈现显著差异，较低 QF 导致更强的高频衰减与更明显的伪影，较高 QF 则保留更多细节且伪影显著减弱，因此不同 QF 的图像天然可作为负样本。通过上述批次中

中国知网　https://www.cnki.net

样本的控制机制，可以显式拉开负样本的退化分布，有效扩大不同样本之间的表征间隔，进而促进编码器学习到更具判别性的退化表征。

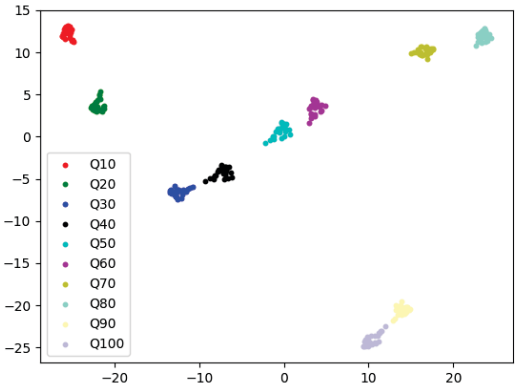


图 3.7　退化表征编码器在 JPEG 压缩图像的 t-SNE 可视化

注：Q 表示不同的 JPEG 压缩质量因子，Q 值越小，压缩越显著。本图可视化结果基于 LIVE1 数据集。

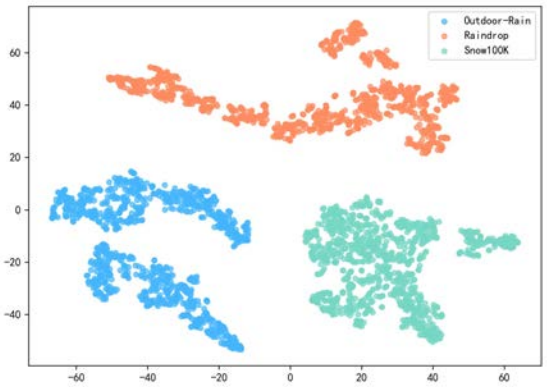


图 3.8　退化表征编码器在恶劣天气图像的 t-SNE 可视化

退化表征编码器训练完成后，本章采用 t-SNE[161] 对所学表征进行可视化，表征取自退化表征编码器最后一层。JPEG 压缩图像的表征可视化结果如图 3.7 所示，其中 QF 的取值范围为 10 到 100，步长为 10，可视化结果显示，退化表征编码器能够清晰地区分不同的 QF 水平。恶劣天气图像的表征聚类结果如图 3.8 所示，对应在该任务的三个测试集进行的可视化，结果表明，不同恶劣天气的退化表征区分明显，验证了编码器在提取判别性退化表征方面的有效性。

此外，本章通过引入训练阶段未出现过的压缩质量因子来验证退化表征编码器的泛化能力，具体而言，在 $\mathrm{QF} \in \{10, 20, \cdots, 100\}$ 上训练的模型，被用于对 $\mathrm{QF} \in \{5, 15, \cdots, 95\}$ 的图像进行 t-SNE 可视化，可视化同样基于退化表征编码器最后一层的输出。如图 3.9 所示，不同退化的特征被清晰区分，表明退化表征编码器在提取判别性退化表征方面具有良好的泛化能力。

本章进一步对退化表征编码器的中间层进行特征可视化。图 3.10 展示了恶

中国知网　https://www.cnki.net

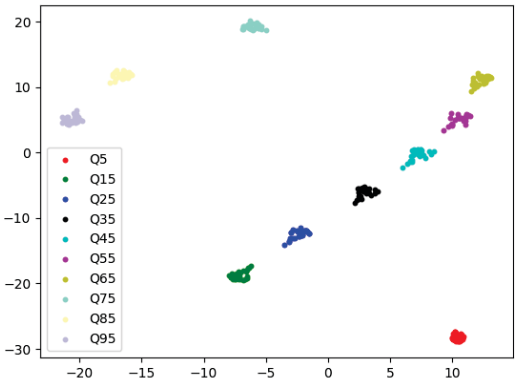


图 3.9　退化表征编码器泛化能力的 t-SNE 可视化

注：Q 表示不同的 JPEG 压缩质量因子，Q 值越小，压缩越显著。本图展示的压缩质量因子在训练时并未作为退化表征编码器输入，其可视化基于 LIVE1 数据集。

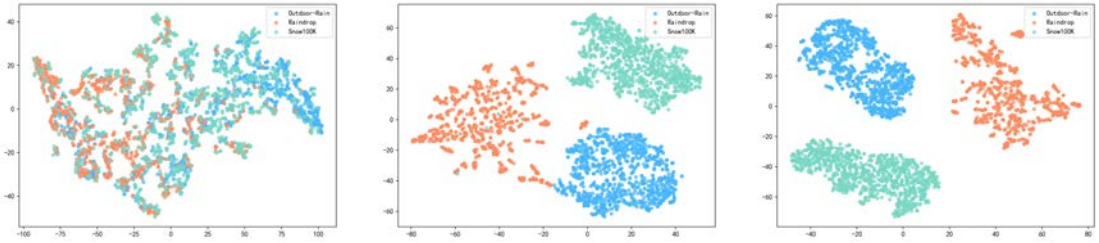


图 3.10　退化表征编码器多层特征的 t-SNE 可视化

注：从左到右一次是退化表征编码器第 1、第 2、第 3 个模块（由浅到深）的输出特征。本图可视化结果基于恶劣天气图像数据集。

劣天气图像复原任务的结果，包含三个子图，分别对应层 E0（左）、E1（中）和 E2（右）的输出。可以看到，E0 作为浅层特征尚未提取判别性的退化表征，而 E1 与 E2 已能够有效提取退化相关表征。

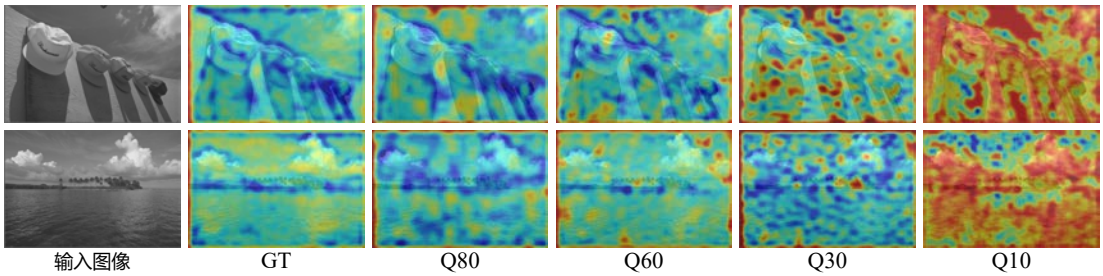
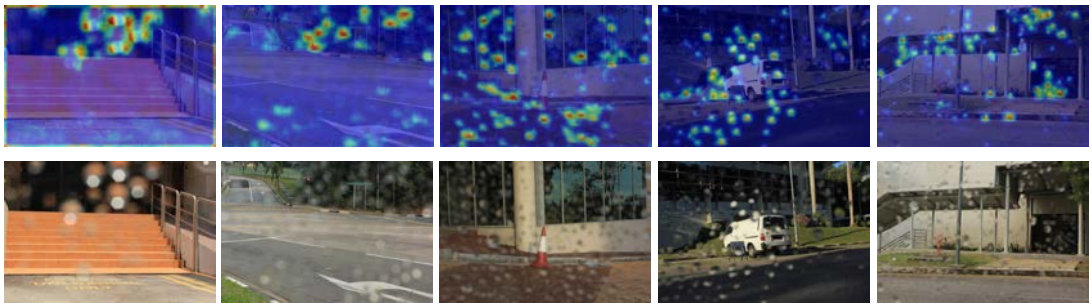


图 3.11　退化表征编码器对于 JPEG 压缩图像的 Grad-CAM 可视化

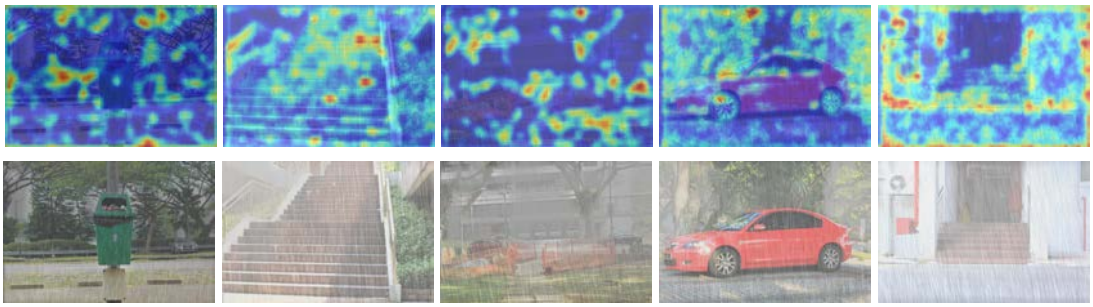
注：Q 表示不同的 JPEG 压缩质量因子，Q 值越小，压缩越显著。可视化基于 LIVE1 数据集。

本章进一步对退化表征编码器进行了 Grad-CAM 可视化[162]。结果表明，编码器主要关注图像中与退化相关的区域，在 JPEG 压缩复原任务中（图 3.11），退化表征编码器对压缩越严重（Q 值越小）的图像响应越强；在恶劣天气复原任务

中国知网　https://www.cnki.net



（a）RainDrop 数据集 Grad-CAM 可视化与对应图片



（b）Outdoor-Rain 数据集 Grad-CAM 可视化与对应图片



（c）Snow100K 数据集 Grad-CAM 可视化与对应图片

图 3.12　退化表征编码器对于恶劣天气图像的 Grad-CAM 可视化

中（图 3.12），退化表征编码器对雨滴、雪粒等退化成分呈现显著响应。上述可视化进一步验证了退化表征编码器对内容无关的退化特征具有感知能力。

3.4.4　消融实验

本章在消融实验的定量分析在 JPEG 压缩复原任务进行，对应指标如表 3.6所示，具体设置如下文所述。

1. **退化表征编码器**

退化表征编码器（Degradation Representation Encoder, DRE）生成具有判别性的表示，为后续的复原解码器提供引导。为验证退化表征编码器的有效性，本章比较了两阶段联合训练与两阶段分离训练两种策略：（1）移除整个退化表征编码器，记为 model-1；（2）不移除退化表征编码器，但不进行预训练，而是直接端到端训练整个模型，记为 model-2。定量评估结果表明，移除退化表征编码

中国知网　https://www.cnki.net

表 3.6　DRNet 消融实验

模型设置	DRE	DRE (预训练)	MILFM		FFT Loss	压缩质量因子			
			IFM	EFFM		Q10	Q20	Q30	Q40
model-1					✓	29.97/0.818/29.63	32.21/0.871/31.68	33.48/0.893/32.76	34.31/0.906/33.46
model-2	✓		✓	✓	✓	30.04/0.820/29.73	32.26/0.871/31.78	33.52/0.894/32.85	34.36/0.907/33.57
model-3(a)	✓	✓		✓	✓	30.11/0.821/29.77	32.30/0.872/31.74	33.55/0.894/32.81	34.39/0.907/33.52
model-3(b)	✓	✓			✓	30.09/0.821/29.72	32.30/0.872/31.72	33.54/0.894/32.78	34.37/0.907/33.48
model-4	✓	✓	✓	✓		30.03/0.819/29.66	32.21/0.871/31.69	33.50/0.893/32.77	34.32/0.906/33.51
DRNet	✓	✓	✓	✓	✓	30.16/0.822/29.85	32.37/0.873/31.84	33.60/0.895/32.89	34.43/0.908/33.58

注：消融实验定量分析基于 JPEG 压缩图像复原任务的 Classic5 数据集，指标依次为 PSNR/SSIM/PSNR-B。

器和不对其进行预训练都会导致模型性能下降。本节进一步对退化表征编码器的特征层进行可视化分析，可视化基于恶劣天气图像复原任务的 RainDrop 数据集，如图 3.13所示，模型在特征层中对退化区域呈现出显著的激活响应。

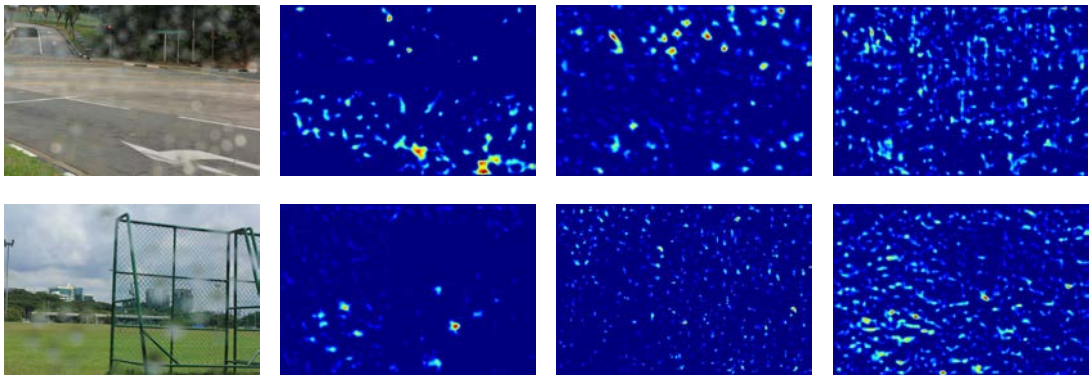


图 3.13　退化表征编码器特征层可视化

2. 多尺度信息无损融合模块

为有效利用退化表征编码器与其提取到的退化表征特征表示，本章采用多尺度信息无损融合模块（Multi-scale Information Lossless Feature Fusion Module, MILFM），将这些信息与后续的复原解码器进行融合。为证明该融合模块的有效性，本章将信息无损融合模块（Invertible Fusion Module, IFM）替换为拼接操作与卷积层，记为 model-3(a)；进一步地，本章将 IFM 与多尺度特征融合模块（Encoder Feature Fusion Module, EFFM）同时替换为拼接操作与卷积层以实现特征融合，记为 model-3(b)。这样一来，模型在参数量上差异不大。从获得的 PSNR 数值可以看出，若以简单拼接作为融合模块，模型性能会下降，而使用多尺度信息无损融合模块可以获得更好的图像复原效果。

3. 参数量比较

图 3.14中展示了本章方法与多种对比方法的模型参数规模对比。在 LIVE1 数据集的 QF=10 设置下，同时评测了各方法的参数量与 PSNR。结果显示，本章方法在参数规模与重建性能之间实现了更优的权衡。

中国知网　https://www.cnki.net

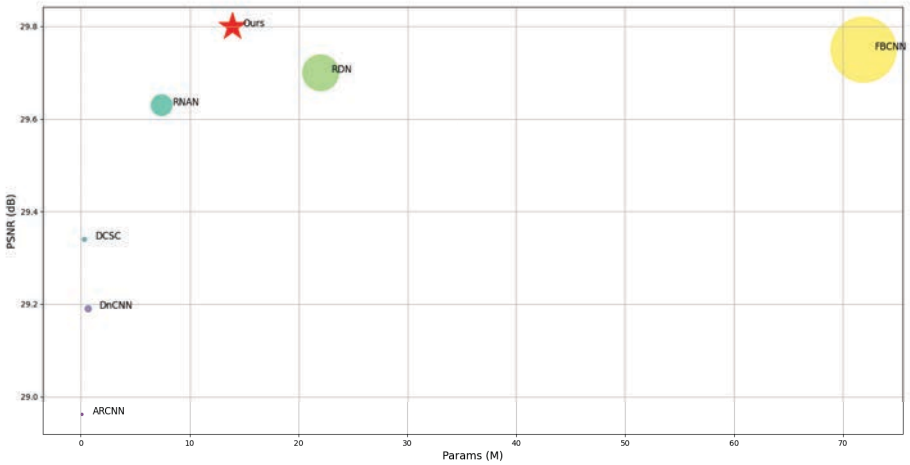


图 3.14　模型参数量比较

3.4.5　局限性分析

本章在训练退化表征编码器时，将同一张图片中不同位置的裁剪块视为正样本，是基于假设同一图像内各区域具有相近或一致的退化分布，虽然在分析部分探讨了该操作的合理性，且全局一致的退化现象更为常见。然而，当出现极端退化时导致全局退化不均匀，该假设可能被破坏，使正样本对之间的退化模式不匹配。具体而言，在混合退化场景中，多种退化类型（如雨条纹、压缩效应、噪声等）在同一图像内同时存在，且在空间分布密度与作用区域上差异显著。继续采用同一张图像上不同位置的图像块作为正样本，会与这种跨类型退化发生冲突，比如，高频条纹型雨条纹会被迫与低频透射衰减型模糊聚合，噪声主导区域又被错误对齐到压缩伪影区域，导致特征子簇难以稳定形成，判别边界随之模糊。退化表征层面的混淆进一步向复原网络传递错误引导，使其在不同退化类型与强度之间选择不匹配的处理方式，复原网络性能下滑，主客观质量同步下降。

3.5　本章小结

针对图像退化的多样性及显式退化标签难以获取的问题，本章提出了一种基于无监督对比学习的自适应退化表征学习方法。该方法通过构建正负样本对训练退化表征编码器，无需依赖显式退化类型标签，而是约束同类退化特征相互靠近、异类退化特征相互远离，从而促使模型自适应感知退化并提取判别性退化表征。随后，将学习到的退化表征以信息无损的方式嵌入复原解码器，作为动态先验引导模型根据退化类型进行自适应调节，实现对不同退化图像的针对性复原。实验结果表明，退化表征编码器能够有效感知退化差异并具备良好的泛化能力，在其引导下，图像复原模型的性能得到提升。本章工作的部分内容已发表在 ECCV 2022。

中国知网　https://www.cnki.net

第 4 章　面向内容复杂性的自适应内容表征学习方法

图像内容兼具丰富的纹理细节与复杂的空间结构关系。退化导致内容受损时，复原任务不仅要求模型借助邻域信息补充局部细节，还需把握整幅图像的空间结构，以避免与整体语义不一致的失真。因此，图像内容重构阶段对局部与全局信息的感知同等重要。卷积神经网络利用局部感受野在细节补全方面表现突出，但其对远距离像素间关系的感知能力有限。早期方法尝试引入空洞卷积来扩大感受野，尽管其提升了网络对长距离信息的感知，但实际受限于膨胀率设置，过大容易导致特征空间稀疏、信息丢失且感受野覆盖不均，还易出现网格伪影，因此难以建立真正有效的长距离依赖。

Transformer 结构能够直接建模任意位置间的长程依赖，被广泛应用于全局信息建模。但自注意力的二次复杂度使其在图像处理任务中的计算和内存消耗极为庞大。为此，大多数方法如 Swin Transformer 采用划分窗口来降低计算量。然而，这种窗口划分方式导致全局感知能力受限。近期提出的 Mamba 结构展现出高效的全局建模能力。其核心优势在于线性复杂度，能够在控制内存占用的同时，捕获更大范围的空间依赖。然而，Mamba 在设计上采用自回归式的序列建模方式。当其直接应用于二维图像时，往往需要在空间域内进行固定顺序的序列扫描（如从左到右、从上到下）。这种空间递归建模方式一方面会引入固定的因果先验，即每个像素只能依赖于扫描路径上已处理过的像素，无法获取之后扫描路径上的信息，使得模型对图像空间结构的表达受限。另一方面，这种扫描顺序还隐含了邻近优先的假设，即像素间的依赖随物理距离递减，只有紧邻像素的相互作用最为显著，而远距离区域的依赖在自回归建模中则被极大削弱。然而，自然图像的空间依赖关系实际上是非因果且各向异性的，一个像素可能同时关联多个不同方向、不同距离的区域。单一固定扫描路径不仅无法刻画复杂的长距离关联，还可能导致复原结果在不同方向上出现信息不足或结构偏差，影响整体复原质量。因此，空间域逐像素扫描所引入的固定因果和邻近优先先验，在复杂自然场景下难以满足高质量内容建模需求。

为了克服上述局限性，在全局信息感知中，本章提出将 Mamba 与频域处理相结合。具体而言，离散余弦变换（Discrete Cosine Transform, DCT）可将图像分解为不同频率成分，其中低频分量主要刻画整体轮廓与结构，高频分量则代表细节与纹理。基于此，本章采用由低频到高频的逐级扫描策略，先捕获全局结构，再逐步细化至局部纹理，从而建立符合 Mamba 自回归特性的序列间因果关系。此外，本章针对 DCT 绝对频率坐标随图像尺寸变化而导致基底密度不一致的问题，设计了跨尺度一致性的频域归一化方法，以保证不同尺寸图像的表征稳

中国知网　https://www.cnki.net

定性。最后，将全局表征与卷积网络提取的局部特征通过动态加权融合，实现了多尺度表征的自适应感知。本章在多尺度内容自适应感知机制的基础上构建图像复原模型 DCTMamba，实验结果表明，DCTMamba 在多项图像复原任务中展现出优越的性能。

4.1　引言

自然图像往往具有复杂的空间结构与丰富的纹理细节。当图像遭受外部因素干扰时，退化现象会破坏其内容。一方面，局部细节被削弱，纹理信息变得模糊；另一方面，遮挡或大范围低对比度会扰乱整体空间布局，削弱各区域之间的空间关联。局部信息的缺失与全局结构的模糊相叠加，导致图像内容不完整与失真，显著提升重构难度。理想的图像复原模型不仅需要借助邻近区域的信息以精细补全细节，还必须准确把握整体空间结构。因此，有效的图像复原依赖于对局部与全局信息的协同感知。

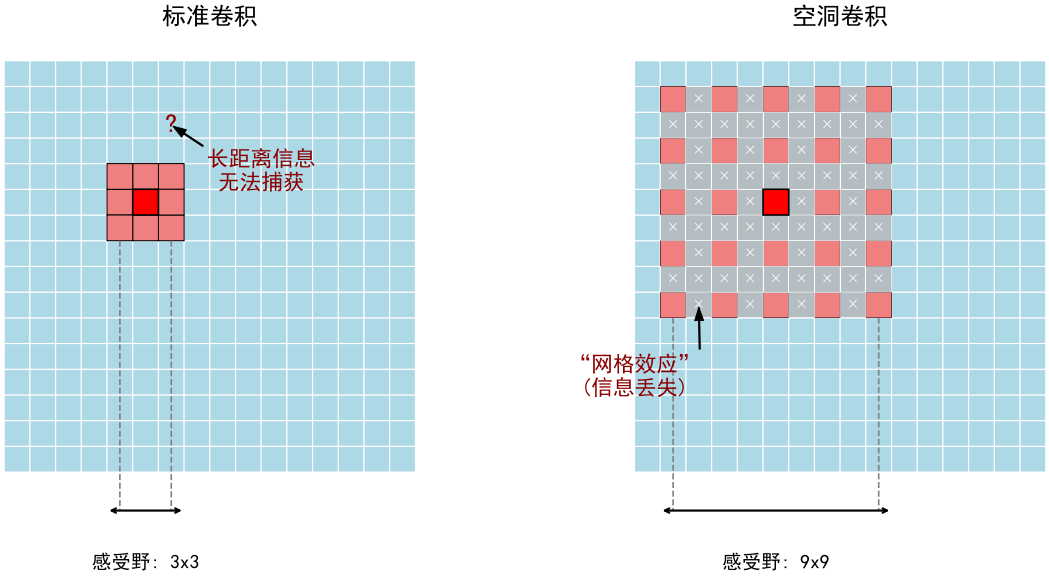


图 4.1　卷积的局限性

早期方法[74,101]主要采用卷积神经网络（Convolutional Neural Networks, CNNs）实现复原。CNNs 凭借局部感受野和参数共享机制，在细节补全上表现突出。但由于卷积核感受野有限（图 4.1左图），即便叠加多层扩大感受野，在实际应用中仍难以捕捉真正的长距离信息。后续提出的空洞卷积[163]虽然可以一定程度扩大感受野，但是其受限于膨胀率参数（图 4.1右图图），若过大则造成特征空间稀疏覆盖甚至信息断层，容易出现网格效应，导致复原图像出现伪影。

为克服 CNNs 的局部局限，学者们提出 Transformer[96]架构，如图 4.2所示，其可直接建模任意位置间的长程全局关系。然而，Transformer 的自注意力计算

中国知网　https://www.cnki.net

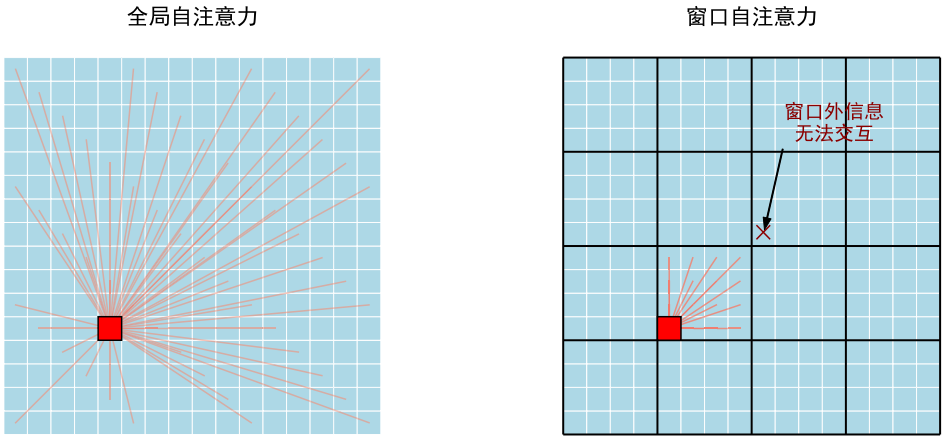


图 4.2　Transformer 的局限性

复杂度随输入像素数平方级增长，使其在图像复原任务中面临存储和算力的双重压力。因此，多数方法[98,129]（如 Swin Transformer 等）采用分割窗口机制，将图像划分为若干窗口，在每个窗口内部独立计算自注意力，并通过窗口重叠或交换，促进不同窗口的信息流通。虽然这种方法降低了单次计算开销，但不可避免地牺牲了窗口外的全局依赖建模能力。例如，图 4.2展示了窗口机制下，模型只能在有限的空间内捕获信息，窗口之间的信息交流非常有限，这制约了网络全局信息的有效感知。

近年来，Mamba[164]凭借其高效的长序列建模能力和近似线性的计算复杂度，在大规模序列建模任务中展现出优越性能。这一特性使其在自然语言处理（Natural Language Processing, NLP）任务中尤为有效，因为文本数据天然具备从前到后的因果序列关系。然而，当 Mamba 被应用于图像复原等二维视觉任务时，图像数据的非因果性与 Mamba 固有的自回归扫描机制难以兼容。以往工作[165-166]通常通过在图像空间域设置固定扫描路径的方式（如逐行或逐列）将二维图像转换为一维序列，以适配 Mamba 的自回归机制，如图 4.3所示。但是这种处理方式引入了不合理的空间先验：一是固定的因果先验，即每个像素点只能依赖于扫描路径上已经处理过的像素，对于路径上未到达的像素点则完全无法获取信息；二是邻近优先的先验，即自回归的扫描机制带来了空间中扫描距离越近的像素关系越紧密，扫描距离越远关系越稀疏，但是自然图像的像素分布并不符合这些先验。比如图像的左上区域需要右下区域的辅助信息，但由于自回归扫描还没有扫描到右下区域，左上的内容重构完全得不到来自右下方的信息辅助。另一方面，某些物体边缘或复杂交界，存在空间上紧邻但语义突变的像素，自回归机制却默认其强相关性，容易导致边缘模糊和伪影，降低恢复质量。因此空间域逐像素自回归扫描所带来的固定因果和邻近依赖假设，并不符合自然图像异

中国知网　https://www.cnki.net

向依赖的实际需求。

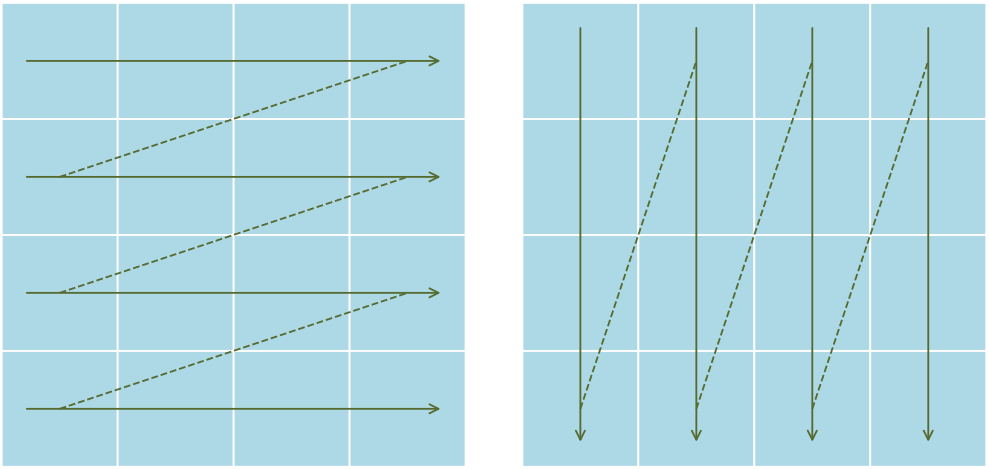


图 4.3　空间域 Mamba 的局限性

为突破上述限制，本章提出将 Mamba 与频域特征建模相结合，以增强全局信息感知能力，并在此基础上设计了一种空频域协同的自适应内容表征学习方法。具体而言，本章构建了空频域协同的全局与局部信息感知模块：在频域全局模块中，首先对特征进行离散余弦变换（Discrete Cosine Transform, DCT），将其分解为从低频到高频的有序频率分量，并依据这一顺序构建符合 Mamba 自回归特性的序列。然而，基于 DCT 的序列建模同时引入了一个新的挑战，频率基底坐标具有尺寸依赖性，即同一绝对坐标在小尺寸图像中可能对应中频分量，而在大尺寸图像中则偏向低频分量。这一差异会导致在固定分辨率上学习到的频率模式难以推广到其他分辨率。为此，本章提出了一种跨尺寸一致性的频域处理机制，通过将绝对坐标映射为相对坐标，从而有效解耦频率表示与图像尺寸，提升模型的跨尺寸感知与迁移能力。在时域局部模块中，引入 CNNs 以增强对局部上下文与细节纹理的建模能力。最后，本章通过可学习的动态权重机制，将频域全局表征与时域局部表征进行自适应加权融合，从而实现全局与局部信息的协同感知。在多项图像复原基准任务上的实验结果表明，该方法在量化指标和视觉质量方面均达到与主流方法相当的水平，并在细节恢复和结构保持上展现出更优的平衡性。

本章的主要贡献包括：

- 结合频域特性与 Mamba 优势，将离散余弦变换（Discrete Cosine Transform, DCT）引入 Mamba，并通过从低频到高频的扫描方式，在扫描序列间建立符合 Mamba 自回归特性的因果关系；
- 针对不同图像尺寸导致频率基底密度差异的问题，引入对 DCT 系数的归一化处理，以平衡各频率分量的贡献，确保在不同尺寸图像上实现感知一致性。

中国知网　https://www.cnki.net

4.2　背景知识

本章首先介绍方法设计中使用到的离散余弦变换和状态空间模型。

4.2.1　图像离散余弦变换

图像离散余弦变换（DCT）将图像从空间域转换到频域，表示为一系列不同频率余弦函数的和。对于一个尺寸为 $N \times N$ 的图像，其正向变换定义如下：

$$F(u,v) = \alpha(u)\alpha(v) \sum_{x=0}^{N-1} \sum_{y=0}^{N-1} f(x,y) \cos\left(\frac{(2x+1)u\pi}{2N}\right) \cos\left(\frac{(2y+1)v\pi}{2N}\right), \quad (4.1)$$

$$\alpha(k) = \begin{cases} \sqrt{1/N} & 若 k = 0, \\ \sqrt{2/N} & 若 k > 0, \end{cases}$$

其中 $u, v = 0, 1, \cdots, N-1$。α_u 和 α_v 是归一化因子，以确保变换是正交的。

其逆变换（IDCT）则从频率系数 $F(u,v)$ 重建图像，定义如下：

$$f(x,y) = \sum_{u=0}^{N-1} \sum_{v=0}^{N-1} \alpha(u)\alpha(v)F(u,v) \cos\left(\frac{(2x+1)u\pi}{2N}\right) \cos\left(\frac{(2y+1)v\pi}{2N}\right), \quad (4.2)$$

其中，$f(x,y)$ 是空间域坐标 (x,y) 处的像素值，$F(u,v)$ 是频域坐标 (u,v) 处的 DCT 系数。位于左上角的低频分量（u, v 坐标值较小）包含了图像最主要的结构信息，而位于右下角的高频分量（u, v 坐标值较大）则主要表示纹理细节。

从公式可以看出，DCT 的频率基向量受图像尺寸的影响，不同尺寸的图像在经过 DCT 后会展现出不同的频率基底分布密度。因此，在使用 DCT 进行图像复原时，必须充分考虑图像尺寸，以恰当处理 DCT 系数所代表的各层次细节和纹理信息。

4.2.2　状态空间模型

状态空间模型 (State Space Models, SSMs)[164,167-168] 因其在长程依赖建模中能够随序列长度进行线性扩展的能力而受到了广泛关注。结构化状态空间序列模型 (S4)[167] 是首批为此目的采用深度状态空间模型的模型之一。在此基础上，S5 层[169] 引入了多输入多输出状态空间模型和高效的并行扫描机制。Mehta 等人[170] 通过引入门控状态空间层进一步增强了 S4 模型。结构化状态空间序列模型（S4）[167] 主要受到连续线性时不变（LTI）系统[171] 发展的深刻影响。这类系统通过一个隐藏状态 $h(t) \in \mathbb{R}^N$ 将一维序列或函数 $x(t) \in \mathbb{R}$ 映射到 $y(t) \in \mathbb{R}$。这可以由以下线性常微分方程（ODE）正式描述：

$$\begin{aligned} h'(t) &= Ah(t) + Bx(t), \\ y(t) &= Ch(t) + Dx(t), \end{aligned} \quad (4.3)$$

中国知网　https://www.cnki.net

其中，N 表示状态大小，矩阵参数分别为 $A \in \mathbb{R}^{N\times N}$，$B \in \mathbb{R}^{N\times 1}$，$C \in \mathbb{R}^{1\times N}$，以及标量 $D \in \mathbb{R}$。

为了将式 (4.3) 应用于深度学习，通常需要执行离散化步骤，并使用时间尺度参数 Δ 将连续参数 A, B 转换为它们的离散对应项。一种常见的离散化技术是零阶保持（ZOH）规则，可表示为：

$$\begin{aligned} \bar{A} &= \exp(\Delta A), \\ \bar{B} &= (\Delta A)^{-1}(\exp(\Delta A) - I) \cdot \Delta B, \end{aligned} \tag{4.4}$$

离散化后，式 (4.3) 对于步长 Δ 的离散形式如下：

$$\begin{aligned} h_k &= \bar{A} h_{k-1} + \bar{B} x_k, \\ y_k &= C h_k + D x_k. \end{aligned} \tag{4.5}$$

然而，式 (4.5) 的公式描述了一个 LTI 系统，其参数对于变化的输入是固定的。为了克服这一限制，Mamba[164] 将数据依赖性引入状态空间模型，其中矩阵 B_k、C_k 和 Δ_k 根据输入数据计算得出。这种输入自适应的参数调整可以描述为：

$$\begin{aligned} B_k &= f_B(x_k), \\ C_k &= f_C(x_k), \\ \Delta_k &= \theta_A(P + f_A(x_k)), \end{aligned} \tag{4.6}$$

其中 $f_B(x_k)$、$f_C(x_k)$ 和 $f_A(x_k)$ 是将特征扩展到隐藏状态维度的线性函数，P P 为状态转移矩阵的基参数。

4.3　方法介绍

本章提出了一种空频域协同的自适应内容感知方法，以同时增强全局结构理解与局部细节感知能力。在全局表征学习中，通过将离散余弦变换（Discrete Cosine Transform, DCT）与线性复杂度的 Mamba 相结合，并采用从低频到高频的扫描顺序，在频率分量之间构建因果关系，从而实现由整体结构到细节纹理的渐进式表征学习。进一步地，考虑到 DCT 的频率分布密度依赖于输入图像的尺寸，提出尺度自适应的频域表征学习方法，以保证跨分辨率条件下表征的一致性与鲁棒性。在局部表征学习中，则基于空域卷积增强纹理与边缘的细节恢复能力。在上述方法驱动下，本章构建了 DCTMamba，整体网络结构如图 4.4 所示，本节详细介绍其中具体实现。

4.3.1　基于空频域结合的自适应内容表征学习

为实现空频域协同的自适应内容表征学习，本章设计了全局-局部协同模块（Global Local Block, GLB）其包含两个主要部分：一是基于频域的全局内容表征

中国知网　https://www.cnki.net

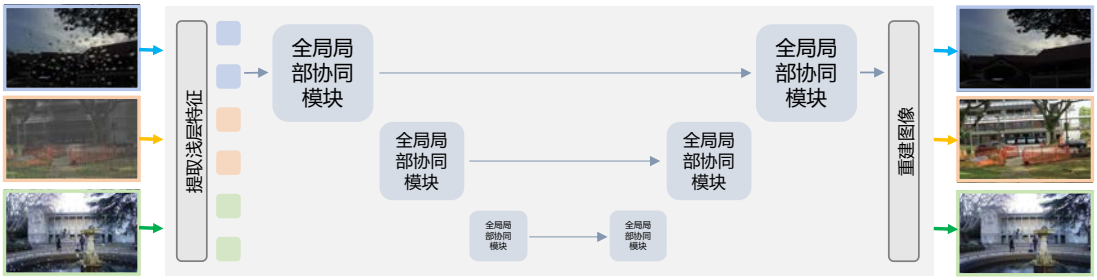


图 4.4　DCTMamba 模型框架图

学习设计的全局状态空间模块（Global State Space Block, GSSB），二是基于空域的局部内容表征学习设计的局部残差模块（Local Residual Block, LRB）。这两个分支并行运作，并且各自独立处理输入数据，从而提供多层次的信息提取。具体而言，GSSB 旨在捕获大范围内的上下文依赖，从而增强特征的上下文一致性。与此同时，LRB 专注于局部特征的重建，通过卷积层捕获输入图像的细节。在获得两个分支的特征表示后，它们首先分别与可学习的权重相乘，然后通过求和的方式进行合并，形成最终的输出特征。这种机制增强了模型的灵活性，使其能够自适应地调整全局和局部信息的贡献比例。设 $f_i \in \mathbb{R}^{H\times W\times C}$ 是第 i 个 GLB 模块的输入，该过程可分为并行两个支路：

第一个支路，经过 GSSB 获取全局上下文特征：

$$y_i^g = \mathrm{GSSB}(f_i). \tag{4.7}$$

第二个支路，经过 LRB 获取局部精细特征：

$$y_i^r = \mathrm{LRB}(f_i), \tag{4.8}$$

其中 $y_i^g,\ y_i^r \in \mathbb{R}^{H\times W\times C}$。

将全局和局部特征图加权后相加，得到最终输出特征：

$$y_i = s_i^g \cdot y_i^g + s_i^r \cdot y_i^r, \tag{4.9}$$

其中，$s_i^g,\ s_i^r \in \mathbb{R}^{1\times 1\times C}$ 是可学习的权重参数，以广播机制与特征相乘，$y_i \in \mathbb{R}^{H\times W\times C}$ 为融合后的输出特征。这样的加权方式可以保证模型能够自适应地融合全局信息与局部精细特征，提升特征表达能力。

4.3.2　基于频域的全局内容表征学习

本节介绍基于频域的全局内容表征学习构建的全局状态空间模块（Global State Space Block, GSSB），该模块的作用是捕获长距离依赖，通过将 Mamba 的序列扫描机制与图像的频域特性相结合，以实现更有效的图像分析与处理。本模块由尺度自适应状态空间模块构建，其结构如图 4.5所示，对于输入特征 $f_i \in \mathbb{R}^{H\times W\times C}$，分别会通过两个分支进行特征提取。

中国知网　https://www.cnki.net

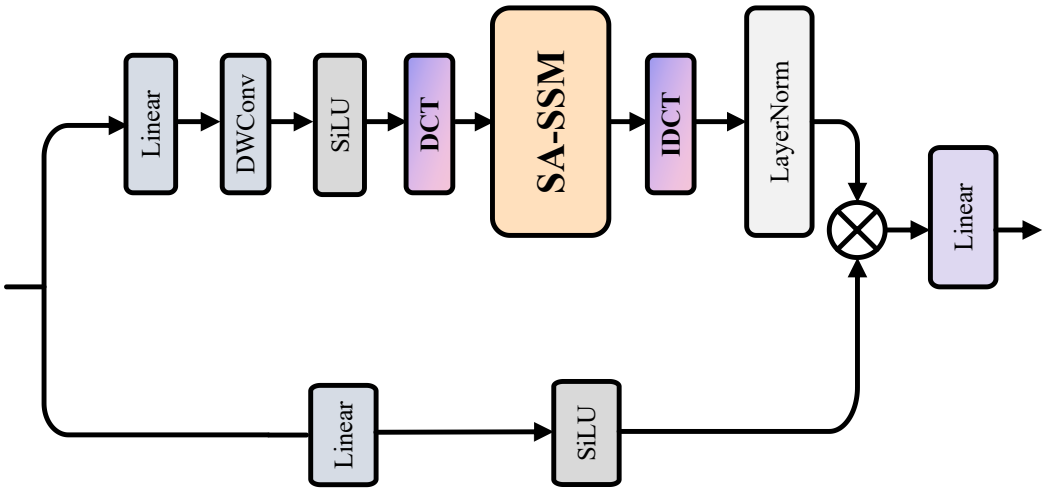


图 4.5　全局状态空间模块

第一个支路中在将特征 f_i 输入尺度自适应状态空间模块之前，先使用 DCT 将输入特征转换到频域，公式表达为：

$$f_i^d = \mathrm{DCT}\left(\mathrm{SiLU}\left(\mathrm{DWConv}\left(\mathrm{Linear}(f_i)\right)\right)\right), \tag{4.10}$$

其中，Linear 表示线性扩展操作，DWConv 表示深度卷积[172]（Depthwise Convolution），SiLU 为激活函数。之后，通过离散余弦变换（Discrete Cosine Transform, DCT）将图像分解为不同的频率分量，得到特征 f_i^d, 其中每个频率分量能够反映图像中不同层次的信息。低频分量通常代表了图像的整体结构和主要形状，而高频分量则包含了图像的细节和纹理特征。

将特征 f_i^d 输入自适应状态空间模块，在频域进行全局特征获取之后，再进行逆离散余弦变换（inverse Discrete Cosine Transform, iDCT）将特征变回空间域，再经由 LayerNorm[173]层处理后得到第一个支路的输出特征，公式表达为：

$$f_i^{g1} = \mathrm{LayerNorm}\left(\mathrm{iDCT}\left(\mathrm{SASSM}(f_i^d)\right)\right). \tag{4.11}$$

第二个分支对输入特征 f_k 进行线性扩展和 SiLU[174] 激活函数，得到特征 f_i^{g2}，公式表达为：

$$f_i^{g2} = \mathrm{SiLU}\left(\mathrm{Linear}(f_i)\right). \tag{4.12}$$

最后，将两个分支的特征通过 Hadamard 乘积聚合，并通过线性变换将通道恢复成原始数量，得到该模块输出特征 y_{k1}，公式如下：

$$y_i^g = \mathrm{Linear}(f_i^{g1} \odot f_i^{g2}), \tag{4.13}$$

其中，$\odot$ 表示 Hadamard 乘积，即对应元素相乘。

中国知网　https://www.cnki.net

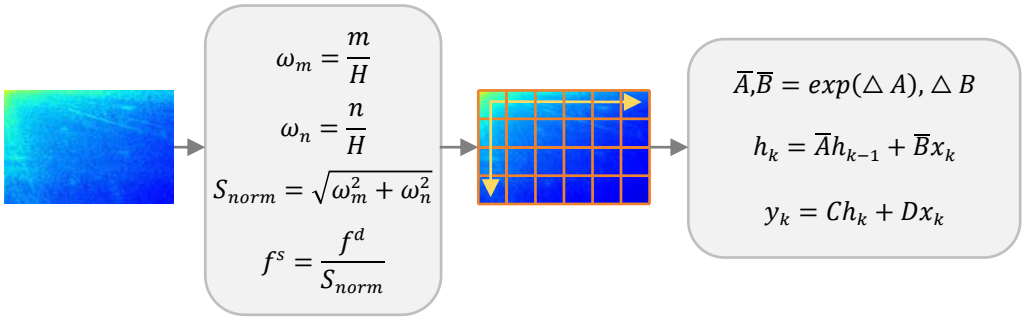


图 4.6　尺度自适应的频域表征学习

4.3.3　尺度自适应的频域表征学习

由于 DCT 的频率基向量分布密度依赖于图像的尺寸，不同的输入尺寸会导致 DCT 结果的差异，从而影响变换的一致性。因此，为了解决由于图像尺寸差异而引入的变换不一致性问题，本章介绍了一种归一化 DCT 系数的方法，如图 4.6所示。通过对 DCT 变换后的系数进行归一化，可以缓解因图像尺寸引起的影响，使得后续处理步骤能够获得稳健的一致性。

具体而言，DCT 系数的归一化过程依托于图像的尺寸进行。该归一化方法的关键在于计算每个 DCT 系数的相对位置，以便按比例调整其贡献。对于输入特征 $f_i^d \in \mathbb{R}^{H\times W\times C}$，公式如下所示：

$$
\begin{aligned}
\omega_m &= \frac{m}{H}, \quad m = \{0, 1, \cdots, H-1\}^T, \\
\omega_n &= \frac{n}{W}, \quad n = \{0, 1, \cdots, W-1\}, \\
S_{\text{norm}} &= \begin{cases} \sqrt{\omega_m^2 + \omega_n^2}, & \text{if } (m,n) \neq (0,0), \\ 1, & \text{if } (m,n) = (0,0), \end{cases} \\
f_i^s &= \frac{f_i^d}{S_{\text{norm}}},
\end{aligned}
\tag{4.14}
$$

其中，m 和 n 分别表示 DCT 系数在图像高度（H）和宽度（W）维度上的索引。通过对每个索引进行归一化处理，计算出相对位置 ω_m 和 ω_n，其结果为 $[0,1]$ 范围内的值。这样的处理使得不同尺寸图像的频率分量在一个统一的尺度上进行比较，进而提高变换的一致性。归一化因子 S_{norm} 的计算是通过对 ω_m 和 ω_n 进行平方和开方而得，该因子就反映了当前 DCT 系数的相对频率信息。当 m 和 n 都为 0 时，S_{norm} 被设定为 1，因为此时对应的 DCT 系数是直流分量，代表了图像的整体亮度。在归一化过程中，为了保持该分量的一致性且避免引入不必要的缩放，将其归一化因子设为 1，从而确保后续处理的稳定性和合理性。归一化后的 DCT 系数 f_i^s 是将原始 DCT 系数 f_i^d 除以归一化因子 S_{norm} 得到的。这个步骤确保所有的 DCT 系数都被调整为一致的尺度，缓解尺寸变化造成的影响。通过标

中国知网　https://www.cnki.net

准化每个频率分量，降低了不同图像在变换过程中的不一致性。最终，经过这一过程处理的 DCT 系数能够保证无论输入图像的实际尺寸如何，其变换后的结果都能保持相对一致性。

在完成尺度归一化之后，模块按从低频到高频的顺序依次扫描这些频率分量。在扫描的初期阶段，着重于低频分量，这些分量对应图像的基本形状和主要结构，之后逐渐过度到高频阶段，从而补充图像的边缘、纹理和细节信息。为了实现更加灵活和高效的扫描，本章采用了两种正交的扫描路径：一种是按行扫描，即从左到右处理每一行，然后移动到下一行；另一种是按列扫描，即从上到下处理每一列，然后移动到下一列。在行扫描模式中，扫描依次从第一行开始并向右进行，保持该行的垂直频率不变，同时水平频率从左到右递增。接着，进入下一行，继续重复这一过程，直到最后一行。而在列扫描模式中，扫描从第一列开始并向下进行，保持该列的水平频率不变，同时垂直频率从上到下递增，然后进入下一列并重复这一过程，直到最后一列。这一策略有利于提取各列中的细节和纹理信息，使得每一列在细化图像内容时都得以保留相应的结构特征。通过这种从粗到精的分步扫描方法，不仅能够有效提取主要特征，还能细致地展示图像的复杂性。这种从粗到精的扫描方式充分利用了频域特性，通过正交的从粗到精扫描路径，模型能够在频域上逐层聚焦于不同尺度的全局特征，从而有效捕获图像中的长距离依赖关系。

4.3.4　基于空域的局部内容表征学习

本节介绍基于空域的局部内容表征学习构建的局部残差模块（Local Residual Block, LRB），其主要作用是通过多层密集连接卷积结构充分提取局部空间特征。其输入特征为 $f_i \in \mathbb{R}^{H\times W\times C}$，经过 LRB 后的输出为 $y_i^r \in \mathbb{R}^{H\times W\times C}$。具体计算过程如下：

首先将输入特征 f_k 依次经过三层密集卷积和拼接操作：

$$\begin{aligned} f_k^{r1} &= \left[f_k,\ \mathrm{GELU}\left(\mathrm{Conv}_{3\times3}(f_k)\right)\right], \\ f_k^{r2} &= \left[f_k^{r1},\ \mathrm{GELU}\left(\mathrm{Conv}_{3\times3}(f_k^{r1})\right)\right], \\ f_k^{r3} &= \left[f_k^{r2},\ \mathrm{GELU}\left(\mathrm{Conv}_{3\times3}(f_k^{r2})\right)\right], \end{aligned} \tag{4.15}$$

其中，符号 $[\cdot]$ 表示沿通道维拼接。然后，拼接结果 f_k^{r3} 经过 1×1 卷积并与原始输入残差相加，得到输出：

$$y_i^r = \mathrm{Conv}_{1\times1}(f_k^{r3}) + f_k, \tag{4.16}$$

该模块通过密集连接结构充分聚合各层浅层和深层特征，并利用残差提升特征流动能力，从而有效增强了特征学习与表达能力。

中国知网　https://www.cnki.net

4.3.5　损失函数

在本章中，为了衡量网络输出图像与清晰图像之间的差异，采用了 Charbonnier 损失函数[175]。记 I_{in} 为输入的退化图像，I_{out} 为网络的输出结果，I_{gt} 为对应的清晰图像。Charbonnier 损失是一种对 $\mathcal{L}_1$ 的光滑近似，具备对异常值的鲁棒性，同时在零点处可导，有助于模型收敛。其具体形式如下：

$$\mathcal{L}_{char} = \frac{1}{B}\sum_{i=1}^{B}\sqrt{(I_{out}^{i} - I_{gt}^{i})^2 + \varepsilon^2}, \tag{4.17}$$

其中，B 表示一个批次的图像数量，I_{out}^{i} 和 I_{gt}^{i} 分别表示第 i 张输出图像和真实图像，ε 是防止数值不稳定的极小常数（本章取 $\varepsilon = 1 \times 10^{-3}$）。

表 4.1　DCTMamba 在 Outdoor-Rain 数据集的定量指标

(a) 专用模型

方法	PSNR↑	SSIM↑
pix2pix[67]	19.09	0.71
HRGAN[63]	21.56	0.86
MPRNet[93]	21.90	0.85

(b) 自适应模型

方法	PSNR↑	SSIM↑
All-in-One[74]	24.71	0.90
TransWeather[75]	23.18	0.84
TKL&MR[107]	23.94	0.85
WGWS-Net[109]	25.31	0.90
Histoformer[113]	29.86	0.93
DCTMamba	30.51	0.92

表 4.2　DCTMamba 在 Raindrop 数据集的定量指标

(a) 专用模型

方法	PSNR↑	SSIM↑
pix2pix[67]	28.02	0.85
Attn.Gan[78]	30.55	0.90
CCN[152]	31.34	0.95

(b) 自适应模型

方法	PSNR↑	SSIM↑
All-in-One[74]	31.12	0.93
TransWeather[75]	28.98	0.90
TKL&MR[107]	30.75	0.91
WGWS-Net[109]	31.31	0.93
Histoformer[113]	31.25	0.94
DCTMamba	31.26	0.92

中国知网　https://www.cnki.net

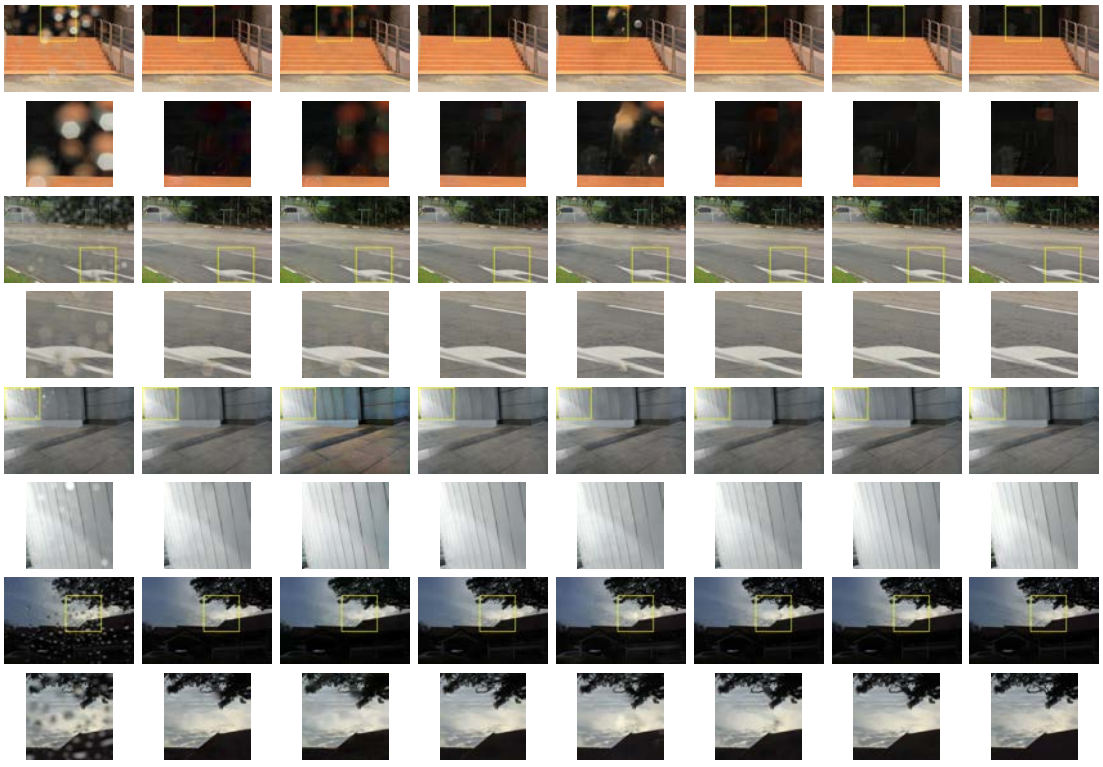
表 4.3　DCTMamba 在 SnowTest100K-L 数据集的定量指标

(a) 专用模型

方法	PSNR↑	SSIM↑
DetailsNet[153]	19.18	0.75
DesnowNet[69]	27.17	0.90
JSTASR[105]	25.32	0.81
DDMSNET[154]	28.85	0.88

(b) 自适应模型

方法	PSNR↑	SSIM↑
All-in-one[74]	28.33	0.88
TransWeather[75]	27.80	0.85
TKL&MR[107]	29.27	0.88
WGWS-Net[109]	29.71	0.89
Histoformer[113]	30.76	0.91
DCTMamba	30.13	0.90



（a）　（b）　（c）　（d）　（e）　（f）　（g）　（h）

图 4.7　DCTMamba 在 Raindrop 数据集与其他方法可视化对比

注：从（a）到（h）依次是：输入图像，TKL&MR，TransWeather，WGWS-Net，Histoformer，DCTMamba，清晰图像。

4.4　实验与分析

本节首先呈现本章方法与其他方法在各图像复原任务上的定量与定性对比结果。随后，本节解析各模块设计的依据。接着，本节通过消融实验检验本章方法的效能。最后，本节阐明本章方法的局限性。

中国知网　https://www.cnki.net

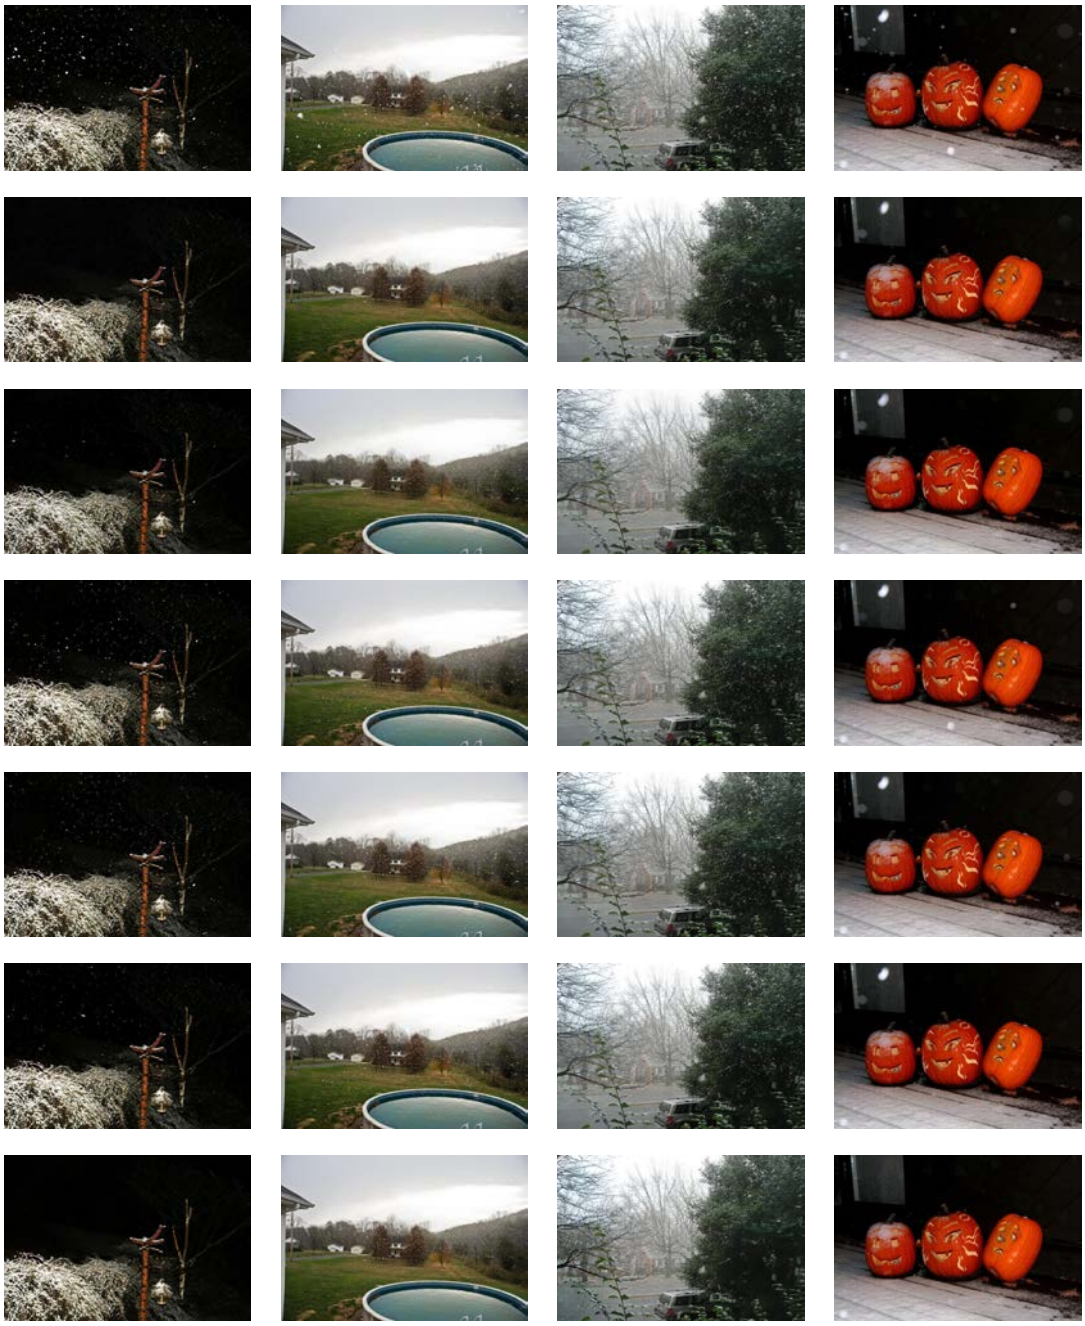


图 4.8　DCTMamba 在 realsnow 数据集与其他方法可视化对比

注：从上到下依次是：输入图像，TKL&MR，TransWeather，WGWS-Net，Histoformer，DCTMamba（该数据集无对应清晰图像）。

4.4.1　实验细节

DCTMamba 使用 Adam 优化器进行参数优化，学习率从 1e-4 采用余弦退火算法降至 1e-6，训练 300 个 epoch。训练过程中，输入图像被裁剪为 256×256 的图像块作为模型输入，每张训练图像会随机选择一种增强模式，包括原始图像、不同角度的旋转（90 度、180 度和 270 度）、垂直翻转，以及旋转与垂直翻转的组合。

中国知网　https://www.cnki.net

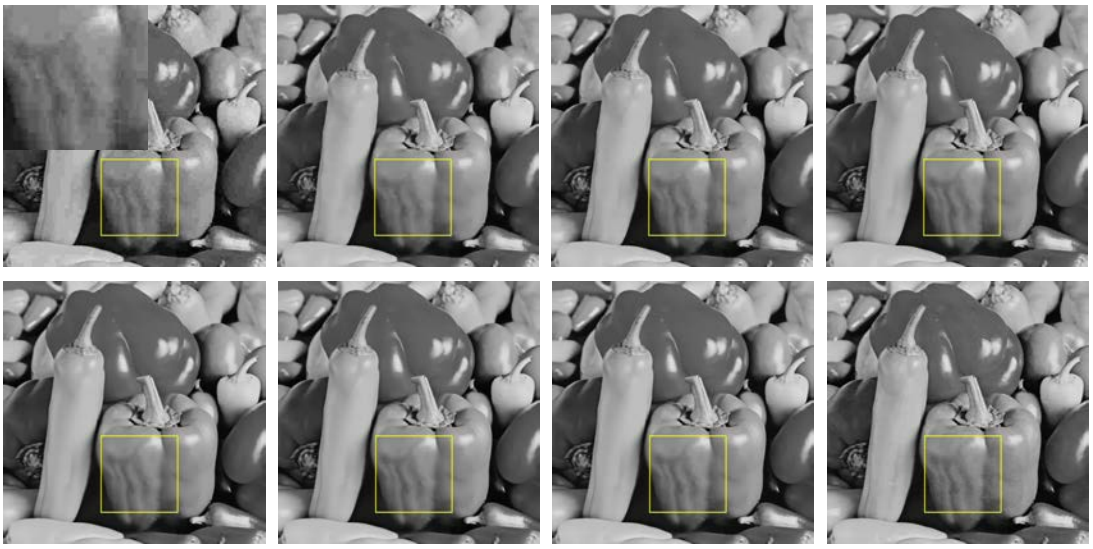
表 4.4　DCTMamba 在 JPEG 图像测试数据集的定量指标

数据集: Classic5[83]（PSNR↑ / SSIM↑ / PSNR-B↑）				
方法	QF=10	QF=20	QF=30	QF=40
专用模型				
输入图像	27.82/0.769/27.78	30.12/0.845/30.05	31.48/0.876/31.37	32.43/0.894/32.28
ARCNN[114]	29.03/0.793/28.76	31.15/0.852/30.59	32.51/0.881/31.98	33.32/0.895/32.79
MWCNN[73]	30.01/0.820/29.59	32.16/0.870/31.52	33.43/0.893/32.62	34.27/0.906/33.35
RDN[118]	30.03/0.819/29.59	32.19/0.870/31.53	33.46/0.893/32.59	-
CODE[121]	30.12/0.822/29.80	32.35/0.873/31.76	33.59/0.895/32.80	34.41/0.907/33.49
自适应模型				
DnCNN[66]	29.40/0.803/29.13	31.63/0.861/31.19	32.91/0.886/32.38	33.77/0.900/33.23
DCSC[122]	29.62/0.810/29.30	31.81/0.864/31.34	33.06/0.888/32.49	33.87/0.902/33.30
QGAC[76]	29.84/0.812/25.21	31.98/0.869/27.50	33.22/0.892/28.94	34.05/0.905/29.92
FBCNN[77]	30.12/0.822/29.80	32.31/0.872/31.74	33.54/0.894/32.78	34.35/0.907/33.48
DCTMamba	30.25/0.824/29.91	32.44/0.874/31.85	33.64/0.895/32.84	34.46/0.908/33.53

数据集: LIVE1[82]（PSNR↑ / SSIM↑ / PSNR-B↑）				
方法	QF=10	QF=20	QF=30	QF=40
专用模型				
输入图像	27.77/0.780/27.72	30.07/0.860/29.99	31.41/0.893/31.30	32.36/0.911/32.22
ARCNN[114]	28.96/0.808/28.68	31.29/0.873/30.76	32.67/0.904/32.14	33.61/0.920/33.11
MWCNN[73]	29.69/0.825/29.32	32.04/0.889/31.51	33.45/0.915/32.80	34.45/0.930/33.78
RDN[118]	29.70/0.825/29.37	32.10/0.889/31.29	33.54/0.916/32.62	-
CODE[121]	29.78/0.827/29.45	32.15/0.889/31.60	33.57/0.916/32.87	34.55/0.931/33.78
自适应模型				
DnCNN[66]	29.19/0.812/28.90	31.59/0.880/31.07	32.98/0.909/32.34	33.96/0.925/33.28
DCSC[122]	29.34/0.818/29.01	31.70/0.883/31.18	33.07/0.911/32.43	34.02/0.926/33.36
QGAC[76]	29.51/0.825/25.33	31.83/0.888/27.57	33.20/0.914/28.92	34.16/0.929/29.96
FBCNN[77]	29.75/0.827/29.40	32.13/0.889/31.57	33.54/0.916/32.83	34.53/0.931/33.74
DCTMamba	29.85/0.829/29.50	32.23/0.891/31.69	33.65/0.917/32.95	34.63/0.932/33.87

数据集: BSDS500[86]（PSNR↑ / SSIM↑ / PSNR-B↑）				
方法	QF=10	QF=20	QF=30	QF=40
专用模型				
输入图像	27.80/0.768/25.10	30.05/0.849/27.22	31.37/0.884/28.53	32.30/0.903/29.49
ARCNN[114]	29.10/0.804/28.73	31.28/0.870/30.55	32.67/0.902/31.94	33.55/0.918/32.78
MWCNN[73]	29.61/0.820/29.14	31.92/0.885/31.15	33.30/0.912/32.34	34.27/0.928/33.19
RDN[118]	29.24/0.808/28.71	31.48/0.879/30.45	32.83/0.908/31.60	-
CODE[121]	29.65/0.821/29.15	31.98/0.885/31.11	33.37/0.913/32.25	34.34/0.928/33.05
自适应模型				
DnCNN[66]	29.21/0.809/28.80	31.53/0.878/30.79	32.90/0.907/31.97	33.85/0.923/32.80
DCSC[122]	29.32/0.813/28.91	31.63/0.880/30.92	32.99/0.908/32.08	33.92/0.924/32.92
QGAC[76]	29.46/0.821/25.10	31.73/0.884/27.22	33.07/0.912/28.53	34.01/0.927/29.49
FBCNN[77]	29.67/0.821/29.22	32.00/0.885/31.19	33.37/0.913/32.32	34.33/0.928/33.10
DCTMamba	29.76/0.824/29.31	32.09/0.887/31.29	33.47/0.914/32.43	34.43/0.929/33.22

中国知网　https://www.cnki.net



Classic5 数据集



LIVE1 数据集

图 4.9　DCTMamba 在 JPEG 图像测试数据集与其他方法可视化对比

注：每个数据集中图像从左上到右下对应方法依次是：输入图像，ARCNN，DnCNN，RNAN，FBCNN，CODE，DCTMamba，清晰图像。

4.4.2　实验结果

本章同样在恶劣天气图像复原、JPEG 压缩图像复原和雨-雾-噪声图像复原进行定量和定性结果分析，数据集详细介绍见章节2.1.2.

1. 恶劣天气图像复原

本章在恶劣天气图像复原的定量结果如表 4.1, 4.2, 4.3所示。可以看到，本章方法在 Outdoor-Rain 的 PSNR 超越了之前的方法。本章在 Raindrop(图4.7) 和 realistic（图4.8) 数据集上与其他方法进行了可视化对比。结果表明，在 Raindrop 数据集上，本章方法能够恢复更多细节。在 realistic 数据集上，本章方法实现了

中国知网　https://www.cnki.net

表 4.5　DCTMamba 在雨-雾-噪声图像测试数据集的定量指标

方法	CBSD68[87]			SOTS[84]	Rain100L[85]	平均
	$\sigma=15$	$\sigma=25$	$\sigma=50$			
专用模型 (PSNR↑/SSIM↑)						
LPNet[155]	26.47/0.778	24.77/0.748	21.26/0.552	20.84/0.828	24.88/0.784	23.64/0.738
ADFNet[156]	33.76/0.929	30.83/0.871	27.75/0.793	28.13/0.961	34.24/0.965	30.94/0.904
DehazeFormer[102]	33.01/0.914	30.14/0.858	27.37/0.779	29.58/0.970	35.37/0.969	31.09/0.898
DRSformer[98]	33.28/0.921	30.55/0.862	27.58/0.786	29.02/0.968	35.89/0.970	31.26/0.902
自适应模型 (PSNR↑/SSIM↑)						
DL[130]	33.05/0.914	30.41/0.861	26.90/0.740	26.92/0.391	32.62/0.931	29.98/0.875
IDR[131]	33.89/0.931	31.32/0.884	28.04/0.798	29.87/0.970	36.03/0.971	31.83/0.911
ProRes[132]	32.10/0.907	30.18/0.863	27.58/0.779	28.38/0.938	33.68/0.954	30.38/0.888
PromptIR[133]	33.98/0.933	31.31/0.888	28.06/0.799	30.58/0.974	36.37/0.972	32.06/0.913
NDR[134]	34.01/0.932	31.36/0.887	28.10/0.798	28.64/0.962	35.42/0.969	31.51/0.910
Gridformer[135]	33.93/0.931	31.37/0.887	28.11/0.801	30.37/0.970	37.15/0.972	32.19/0.912
DCTMamba	34.06/0.931	31.45/0.888	28.27/0.802	33.24/0.982	37.76/0.981	32.96/0.917

对全局更优的重构。

2. JPEG 压缩图像复原

本章在 JPEG 压缩图像复原的定量结果如表 4.4所示, 其涵盖了 Classic5，LIVE1 和 BSDS500 三个常用测试基准数据集。在图4.9中展示了在 Classic5 与 LIVE1 数据集与其他方法的可视化对比，可以看到，本章方法对纹理状细节的复原更加精细。

3. 雨-雾-噪声图像复原

在雨-雾-噪声图像复原任务上，本章在三个测试数据集上进行评估：CBSD68、SOTS-Outdoor 与 Rain100L。其中 CBSD68 采用了 15、25 和 50 三种噪声标准差。各方法在不同数据集下的定量结果如表4.5所示。

4.4.3　方法分析

本节详细分析本章中各方法设计的动机与合理性。

1. 频域扫描分析

二维自然图像包含复杂的空间关系，具有显著的非因果性和各向异性。图像的非因果性体现在其空间依赖关系并非遵循单一的线性的先后顺序。例如在图 4.10中，右下角红色框内的绿色草坪与左上角红色框内的绿色草坪在语义上高度相关，共享相似的纹理和颜色特征。在进行图像修复任务时，这两个区域能够相互提供上下文信息作为辅助。然而，如果采用传统的空间域顺序扫描机制，例如从左上到右下的光栅扫描，模型在处理左上方的红色框时，无法获取右下方红色框的信息，从而丢失了这一重要的长程依赖关系。与此同时，图像内容的关联性表现出显著的各向异性。在图 4.10中黄色框标识的区域，图像内容在极短的空间距离内发生了语义上的突变，从灰色的砖石人行道跳变到绿色的草地。因此

中国知网　https://www.cnki.net

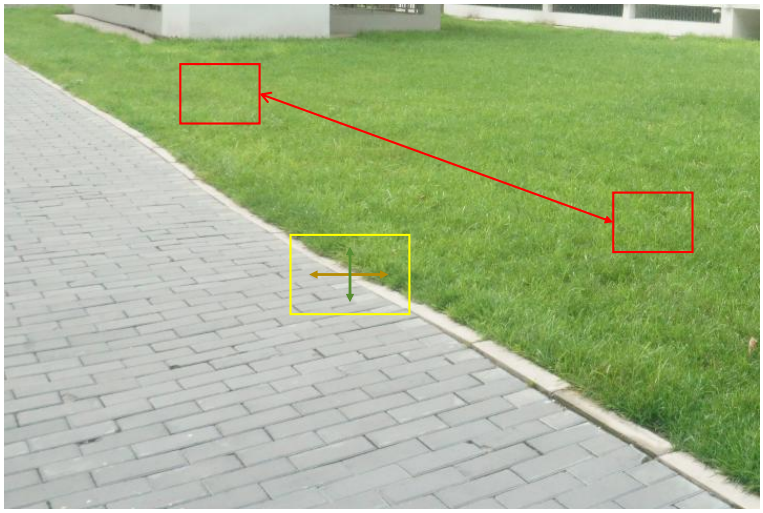


图 4.10　二维图像的空间域非因果性与各向异性

在该区域，沿着人行道边缘方向的像素之间的关联性很强，而在垂直于边缘的方向上，像素间的关联性则骤然降低。因此，一个合理的图像复原模型必须能够有效建模这种既非因果又具有各向异性的复杂空间依赖关系，而不是简单地将图像在空间域视为一维序列进行处理。



图 4.11　图像 DCT 变换及其分段与重构示意图

为了避免空间域扫描的局限性，本章探索了在频域中进行自回归的范式。如图 4.11所示，图像经过离散余弦变换（Discrete Cosine Transform, DCT）后，其系数从左上到右下的排列呈现出从低频到高频的顺序。图中将 DCT 系数分解为分频段 1 和分频段 2 两部分，并展示了它们各自对应的空间域图像。可以看出，低频分量代表图像的整体结构和轮廓，而高频分量则对应边缘、纹理等局部细节。这种从宏观结构到局部细节的过渡，为二维图像数据提供了一种因果性的序列顺序。因此，在频域中按照频率高低进行处理，建立了符合 Mamba 自回归特性的扫描序列。

中国知网　https://www.cnki.net

2. 归一化分析

如式 (4.1)所示，DCT 的结果与图像的空间分辨率直接相关。具体来说，这体现在频率分辨率上：当图像尺寸 N 增加时（例如从 64×64 增加到 512×512），频率索引 u 的取值范围也从 $0,\cdots,63$ 扩大到了 $0,\cdots,511$。这意味着整个频域空间被划分得更细密，相邻两个频率（例如，由 u 和 $u+1$ 定义的两个频率）之间的实际差距变小了。这个更小的距离带来了更强的频率表达能力，允许 DCT 使用更多的、间隔更密的基函数来更精确地描述和重构图像中微小的频率变化，即所谓的更精细的频率细节。然而，这种频率表达能力的提升，也给需要处理不同尺寸输入的神经网络模型带来了挑战。其核心问题在于，对于一个给定的绝对频率坐标 (u,v)，它所代表的物理意义会随着图像尺寸 N 的变化而改变。例如，坐标 $(25,25)$ 在 64×64 的图像中代表一个相对居中的频率，但在 512×512 的图像中则代表一个极低的频率。一个在绝对频率坐标上训练的模型将难以扩展到不同的分辨率，因为它学到的针对特定坐标的权重将被错误地应用。

为了解决这一问题，本章的核心思路是将对绝对频率坐标的学习，转换为对相对频率坐标的学习。通过这种方式，模型学习到的不再是针对某个绝对坐标（如 $(25,25)$）的固定权重，而是一个关于相对频率位置（如“靠近中心”、“处于中频带”）的通用处理策略，从而使其能够在任意分辨率的输入上都能实现稳健的性能。

为了更加清晰地说明尺度归一化的必要性，下面进行举例和图示说明，以 4×4 和 10×10 图像为例。在一维频率索引 u 和图像高度 N 进行分析。

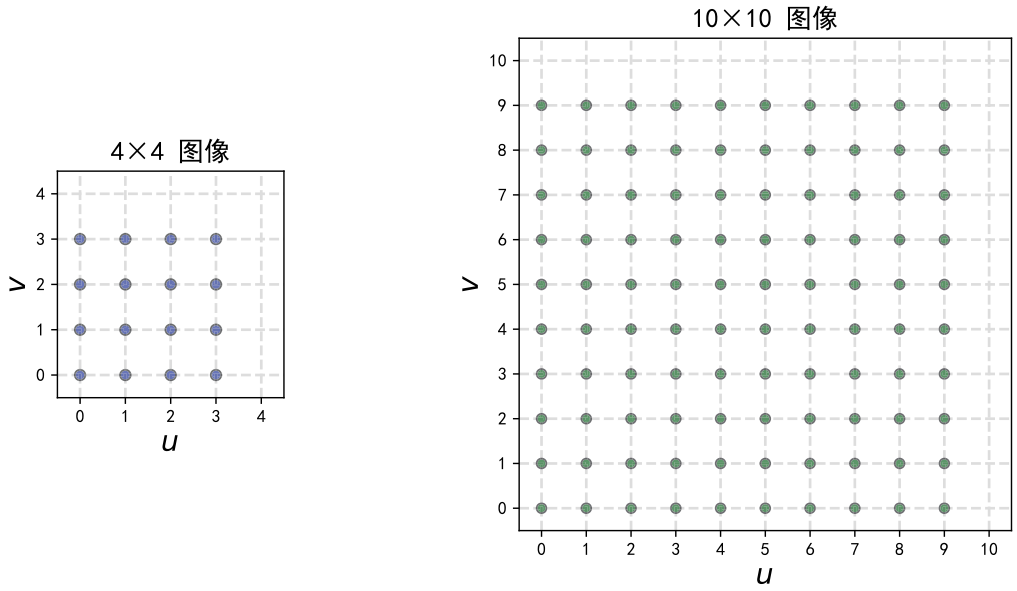


图 4.12　不同尺寸图像绝对索引

在进行尺寸归一化之前，如图 4.12所示，对于 4×4 的图像 $(N=4)$，绝对频率索引 u 为 $\{0,1,2,3\}$。而对于 10×10 的图像 $(N=10)$，绝对频率索引 u 为

中国知网　https://www.cnki.net

$\{0,1,2,3,4,5,6,7,8,9\}$。这表明，不同尺寸的图像在绝对频率索引上存在明显的差异。

在进行尺寸归一化 $p_u = u/N$ 之后，如图 4.13所示，对于 4×4 图像 $(N=4)$，其相对位置坐标为：

$$p_{u/N} = \{0/4, 1/4, 2/4, 3/4\}$$

这个操作将绝对索引映射到一个与尺寸无关的相对位置上，模型在处理时，不再关注绝对的 $u=0,1,2,3$，而是关注相对位置 $p_{u/N}=0,1/4,2/4,3/4$。例如，对于 $u=2$ 的输入，模型会将其识别为处于频谱中段 $2/4=1/2$ 相对位置的信号，并应用相对中频处理策略。对于 10×10 图像 $(N=10)$，同样将绝对索引映射到 $[0,1)$ 的相对位置坐标系中：

$$p_{u/N} = \{0/10, 1/10, 2/10, 3/10, 4/10, 5/10, 6/10, 7/10, 8/10, 9/10\}$$

假设对于 $u=5$ 的输入，模型也将其识别为处于频谱中段 $5/10=1/2$ 相对位置的信号，并同样应用相对中频处理策略。

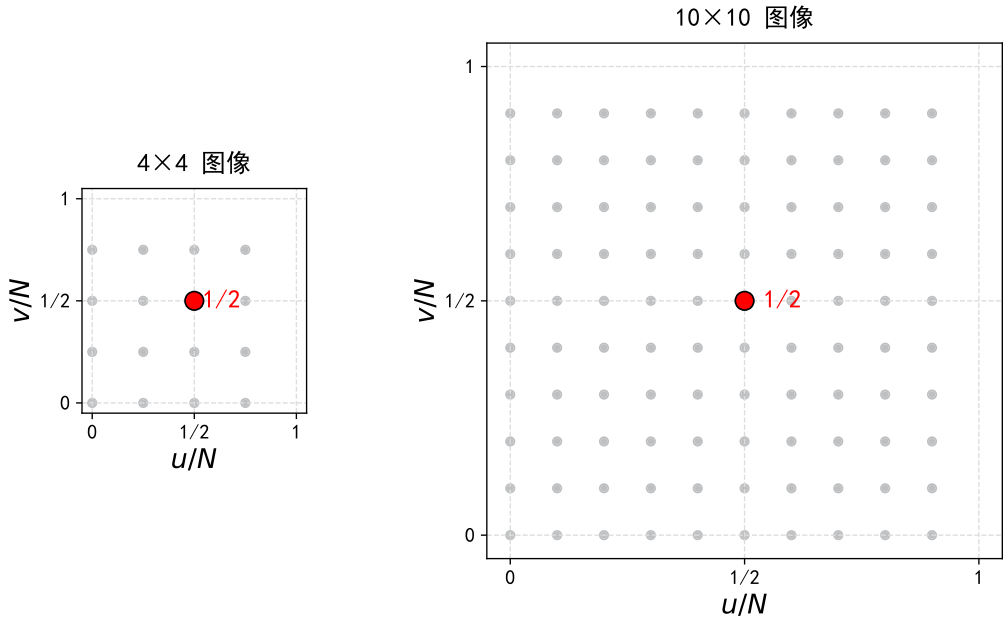


图 4.13　不同尺寸图像相对索引

尺度归一化操作实现了从绝对位置到相对位置的转变，如果仅用绝对索引处理信号，例如对于频率索引 $u=2$，在 4×4 图像中，$u=2$ 代表的是较中高的频率成分；而在 10×10 图像中，$u=2$ 却对应靠近低频的成分。如果模型学到的是 $u=2$ 要怎么处理，那么处理不同分辨率图像时，会把中高频信号和低频信号错误地套用相同策略，导致模型缺乏鲁棒性。

进行尺度归一化后，所有频域索引都被映射到了统一的相对位置区间 $[0,1)$。每一个频率分量，无论是什么尺寸图像，都被表示为相对位置 $p_{u/N}=u/N$，这让

中国知网　https://www.cnki.net

$p_{u/N}$ 总是落在 0 到 1 之间。相对分量无论来自哪种分辨率，在 $p_{u/N}$ 空间里都能对应。比如，$p_{u/N}$ 靠近 0，代表低频部分，通常包含图像整体框架信息；$p_{u/N}$ 在 0.5 附近，属于中频，对应结构或边缘特征；$p_{u/N}$ 靠近 1，其对应高频分量，通常描述细节和纹理。模型可以仅根据 $p_{u/N} \in [0,1)$ 的取值来制定处理方案。$p_{u/N}$ 靠近 0 的分量可以采用低频增强或平滑，$p_{u/N}$ 在中频区间内可以增强边缘或关注细节，$p_{u/N}$ 接近 1 时则采用降噪或其他高频专属策略。这样一来，尺度归一化使模型摆脱了绝对索引和固定频率的约束，对于同一相对频谱位置的分量，能够实现一致的处理。

4.4.4　消融实验

本章在恶劣天气图像数据集进行消融实验，定量指标基于 Outdoor-Rain 数据集，以验证所提方法的有效性，定量分析如表4.6 所示。

表 4.6　DCTMamba 消融实验

模型设置	LRB	GB	LW	DCT	SASSB	PSNR↑
Baseline	✓					29.91
Model-1		✓		✓	✓	30.02
Model-2	✓	✓	✓			30.25
Model-3	✓	✓		✓	✓	30.45
Model-4	✓	✓	✓	✓		30.41
DCTMamba	✓	✓	✓	✓	✓	30.51

1. **全局-局部协同模块**

为验证全局-局部协同模块（Global-Local Block, GLB）中全局模块的有效性，从该模块中移除了全局状态空间模块，将其记为“Baseline”。此外，本节还移除了局部残差模块（Local Residual Block, LRB），将其记为 Model-1。定量分析表明，同时包含局部与全局模块的网络表现更佳。

2. **全局状态空间模块**

为验证本章所提出全局状态空间模块（Global State Space Block，GSSB）的在频域内进行扫描的全局状态空间模块相较于直接时域扫描的优越性，本节进行了只在时域扫描的实验，记为 Model-2。实验结果表明，在频域进行扫描能够带来更优的性能。

3. **可学习加权参数**

在融合局部残差模块与全局模块时，本节进行固定权重与可学习权重（Learnable Weight，LB）两种方案的对比，将使用固定权重的模型记为 Model-3。在对局部残差模块与全局模块进行加权融合时，引入可学习加强参数相比固定权重取得更优效果。图4.14展示了两者在同一特征层上的可视化，可以看出二者关注重点不同。图4.15绘制了第 1、2、3 个 GLB 中 scale1 与 scale2 的参数对比，可见二者分别学得了不同的参数值，体现出自适应调节能力。

中国知网　https://www.cnki.net

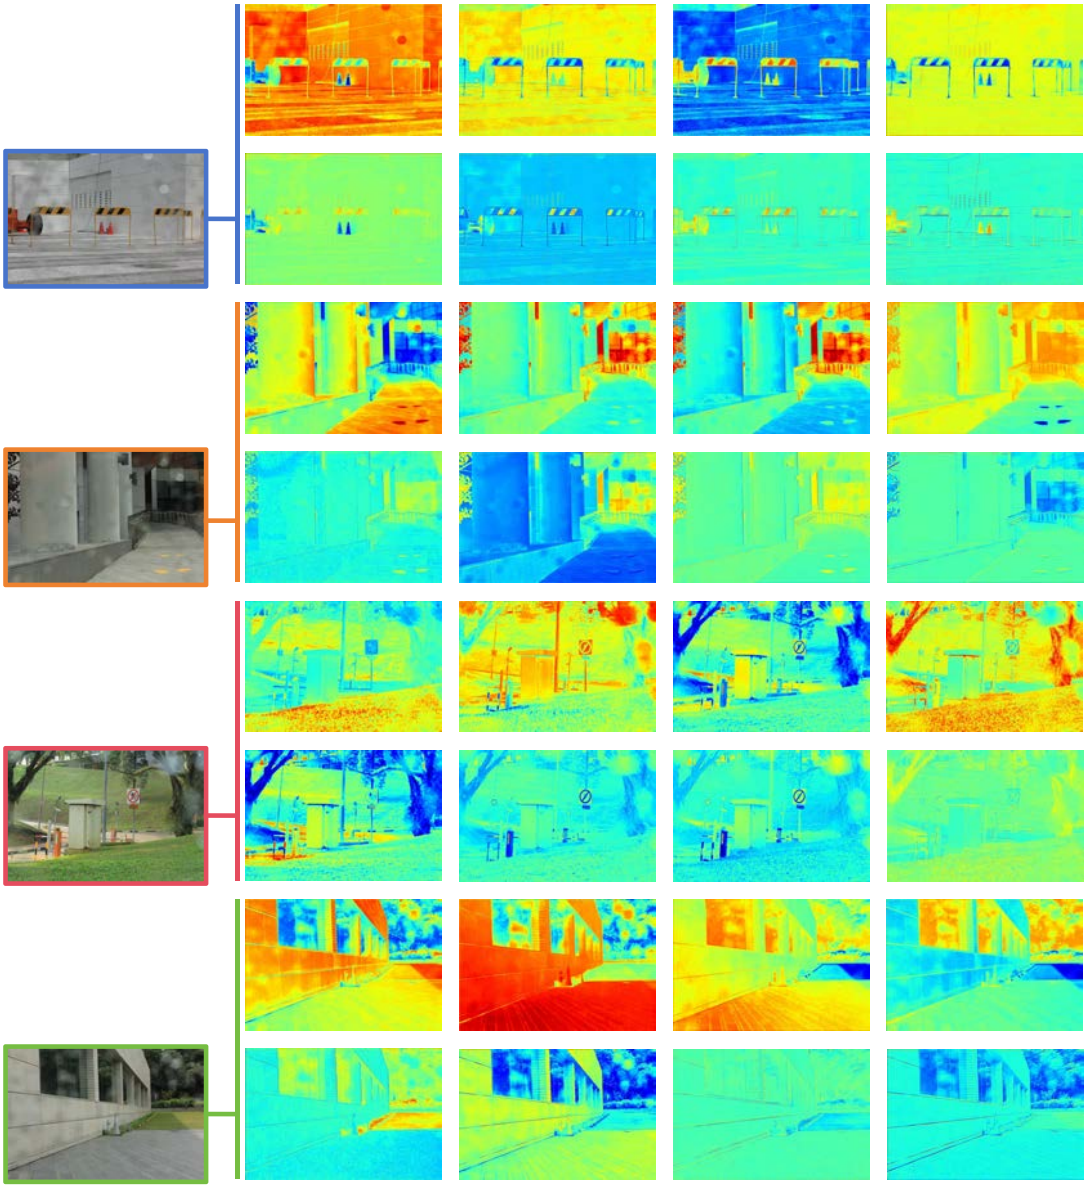


图 4.14　DCTMamba 中全局状态空间模块和局部残差块的特征图可视化

注：每张图对应的两行特征图中，上方为全局状态空间模块特征，下方为局部残差块特征

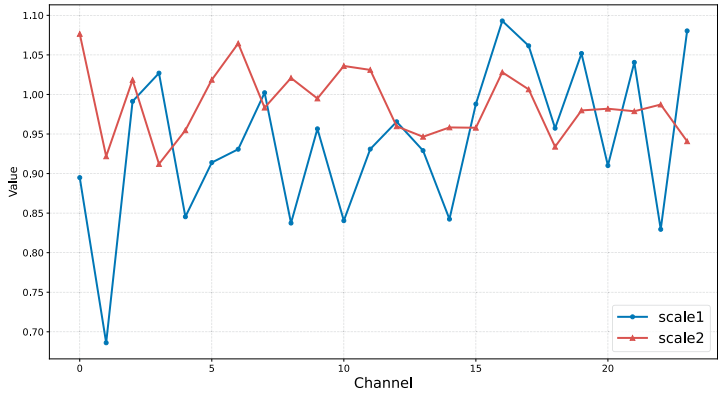
4. 尺度自适应状态空间模块

为验证所提出的尺度自适应状态空间模块（Scale-Adaptive State Space Block, SASSB）的有效性，本节从网络中移除了该操作，并将其记为 Model-4。定量实验分析显示，移除该操作后，网络性能有所下降。

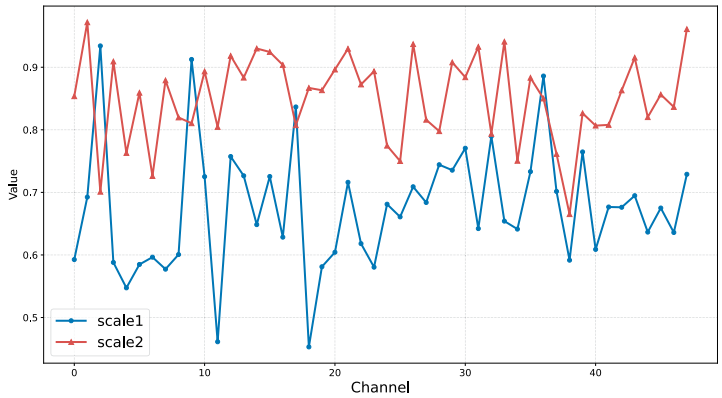
5. 参数量对比

在雨—雾—噪声图像复原任务中，本章对近年来具有代表性的方法从参数量、FLPOS、计算时间与 PSNR 进行了系统性比较，其中 FLOPS 和计算时间都基于 $3\times128\times128$ 的图像统计，并且计算时间在单张 NVIDIA GeForce RTX 4090 上取 200 张图像的平均数。如表 4.7中，DCTMamba 以 12.23M 的参数规模实现

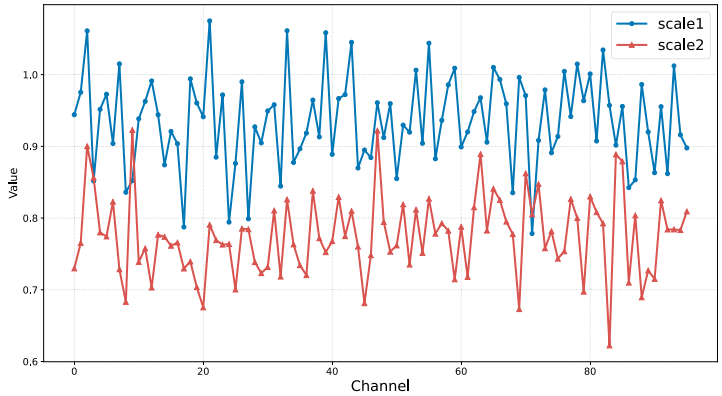
中国知网　https://www.cnki.net



(a) GLB1



(b) GLB2



(c) GLB3

图 4.15　不同层 GLB 模块中 scale 参数分布图

32.96 dB 的平均 PSNR，整体优于参数量更高的模型，在更小参数量的前提下获得更高的恢复性能。

表 4.7　不同方法的参数量与计算复杂度对比

方法	ProRes	PromptIR	NDR	Gridformer	DCTMamba
参数量 (M)	370.63	32.96	28.40	34.07	16.60
FLOPs (G)	-	43.18	38.36	92.34	29.07
Times (ms)	-	24	23	123	40
PSNR↑	30.38	32.06	31.51	32.19	32.96

中国知网　https://www.cnki.net

4.4.5　局限性分析

本章所提尺度归一化方法的局限性在于其对高频信息的抑制，在自然图像中，代表精细纹理和边缘的高频 DCT 系数其数值天然较为微弱。而此方法的设计恰好对这一频段应用了较大的归一化因子，这使得这些本就细微的信号量级被进一步衰减。这是由于该归一化优先考虑了实现均衡的频谱能量分布与跨尺寸的特征一致性，而这可能伴随着图像最精细细节的显著度降低。

针对上述局限性，一个可行的改进方案是引入可调节的抑制强度，将固定的归一化规则变为一个灵活的参数化策略。具体而言，可以将归一化因子从 S_{norm} 修改为 $S'_{\text{norm}} = (S_{\text{norm}})^{\alpha} + \epsilon$。在这个新方案中，$\alpha$ 是一个介于 0 和 1 之间的超参数，它直接控制着抑制曲线的陡峭程度：当 α 趋向于 1 时，其效果接近原方法；当 α 趋向于 0 时，则对高频的抑制作用变得十分温和。此外，加入一个微小的正常数 ϵ 可以保证分母不为零，增强了数值稳定性。通过将 α 视为一个可学习或可根据任务调整的参数，该方案能够在“保持高频细节”与“均衡频谱能量”之间取得更精妙的平衡，从而在不完全牺牲细节保真度的前提下，保留原方法的大部分优点，以适应更多样化的应用场景。

4.5　本章小结

针对现有方法在全局信息感知方面的局限，本章提出了一种基于空域与频域结合的自适应内容表征学习方法。该方法利用 Mamba 实现全局信息感知，并将其与离散余弦变换相结合，通过由低频到高频的顺序构建 Mamba 扫描序列间的因果性。同时，对频域特征进行尺度归一化处理，以保持对不同尺寸图像的一致性感知。最后，将全局表征与基于卷积神经网络的局部表征通过自适应加权融合，实现多尺度特征的协同感知。实验结果表明，该方法能够同时有效感知全局与局部信息，进而在多项图像复原任务中取得优异性能。本章工作的部分内容已发表在 AAAI 2025。

中国知网　https://www.cnki.net

第 5 章　面向内容-退化耦合性的自适应解耦表征学习方法

图像复原旨在去除退化干扰并重构受损内容，前两章分别探究了模型的退化感知与多尺度内容感知能力。然而，图像复原不仅是退化去除与内容重构的简单叠加，这两个过程在目标上存在差异因而构成了新的挑战。具体而言，不同类型的退化具有各自独特的形态与视觉特性，因而退化去除过程需要具备差异性。然而，清晰自然图像在底层统计特征与结构先验上普遍具有内在一致性，允许内容重构的一致性。因此，差异性和一致性共存导致的特征耦合，进一步提升了图像复原的复杂性。

针对上述挑战，本章提出了一种基于双重约束的解耦表征学习方法。具体而言，本章首先设计了一个模块化分离的网络框架，称为 DDCNet，其利用特征通道统计特性将退化去除与内容重构划分为两个子模块，从而有效减轻这两个过程间的特征干扰。同时，本章设计了退化映射损失函数，将退化图像本身引入优化项，以显式建模退化到清晰映射中的多路径差异，并通过方向约束缓解由此带来的特征耦合问题，从而为模型提供更明确的优化方向，实现表征的自适应解耦。在多个基准数据集上的实验结果验证了本章所提出方法的有效性。

5.1　引言

在图像复原的过程中，既需要去除图像上由退化因素造成的干扰，还需对受损内容进行重建，以恢复图像原有的清晰度与细节。不同类型的退化对图像的影响具有显著差异，例如雨天场景往往带来条纹状雨线干扰，而雾天则会导致整体对比度下降。因此，退化去除过程必须具备差异化的分析与处理能力。然而，在内容重构阶段，不同退化条件下的图像仍呈现出内在共性。一方面，对于同一场景而言，无论经历何种退化，其对应的原始清晰图像都是唯一的，这意味着复原的目标始终指向同一张高质量的场景图像。另一方面，对于不同场景而言，自然清晰图像普遍遵循共同的底层统计规律与结构先验，例如相似的像素分布、梯度统计模式以及边缘连续性等。这些一致性为跨退化条件的一致内容重构提供了基础。因此，退化去除差异性与内容重构一致性（图 5.1）的共存导致了表征层面的耦合与干扰，从而加剧了图像复原的复杂性。

为了解决上述问题，本章提出了基于双重约束的解耦表征学习方法，旨在减轻表征干扰以进一步提升图像复原模型性能。具体而言，本章首先提出了一种退化去除与内容重构解耦的图像复原框架 DDCNet。DDCNet 利用网络特征的通道统计特性，如图 5.2所示，在网络特征中，不同通道对于退化现象的响应各不相

中国知网　https://www.cnki.net

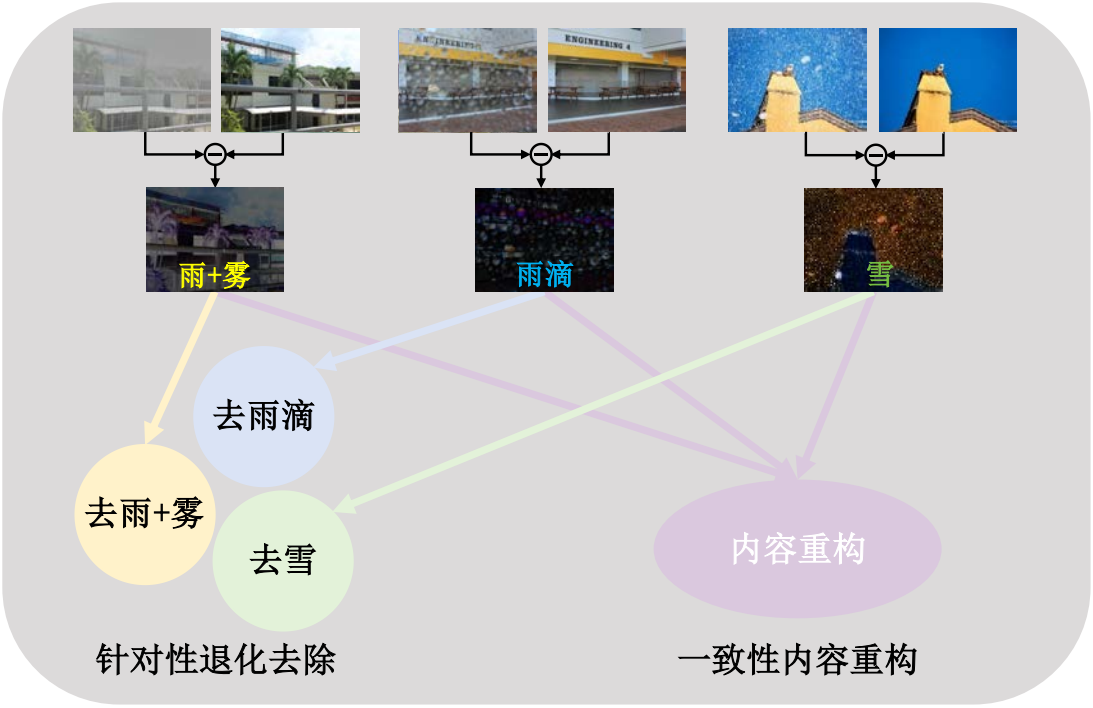


图 5.1　图像复原中退化去除具有差异性、内容重构具有一致性

同。而通过在通道维度上对特征进行均值操作，能够显著抑制由退化引入的干扰，从而提取与内容相关的特征。基于上述机制，DDCNet 采取模块化设计，将退化去除和内容重构两个过程解耦为两个模块，从而减少二者之间的特征耦合与干扰，提升模型的自适应性。在此基础上，DDCNet 进一步引入傅里叶变换作为辅助工具，分别强化上述两个核心模块的功能。在退化去除阶段，模型结合傅里叶幅值特征，能够更准确地解析和区分不同退化条件下的退化类型，从而实现更具针对性的退化去除；在内容重构阶段，充分利用全局傅里叶特性，有助于强化不同退化下内容表征的一致性重建，提高最终复原图像的质量。与此同时，考虑到不同退化分布会导致特征空间分布发生变化，DDCNet 引入自适应批量归一化过程，通过将退化信息作为动态调节因子，使特征分布能够随输入退化类型自适应调整，提升了模型在应对多样退化时的鲁棒性。

在模型优化方面，本章进一步观察到，不同退化类型下，退化图像与其对应清晰图像在优化方向上存在差异。例如，雪景复原更强调对多频段噪声的抑制，而雾霾场景下则需突出高频细节的恢复。图像复原领域常用损失函数如绝对误差损失不能对方向加以约束。为此，本章提出了退化映射损失函数。该函数将退化图像作为先验，通过计算预测残差（模型输出与退化图像之差）和目标残差（清晰图像与退化图像之差），并利用余弦相似度来对齐这两个残差向量，从而对优化方向进行约束。由此，模型在优化中同时兼顾退化去除的差异化需求与内容重构的一致性目标，进一步缓解特征耦合并提升复原性能。在多个公开基准数据集上的实验结果验证了本章所提出方法的有效性。

中国知网　https://www.cnki.net

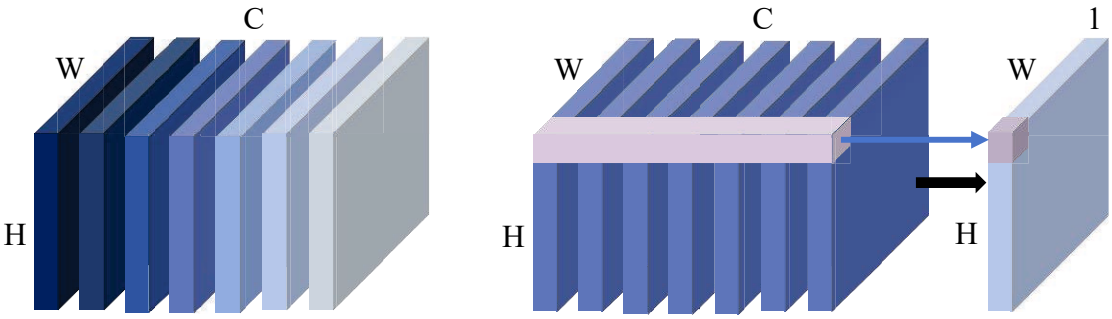


图 5.2　模型特征的通道统计特性

本章的主要贡献包括：

- 指出在多种退化条件下，分别处理退化去除与内容重构过程对于模型自适应能力的重要性。通过将这两个过程解耦分离，能够有效降低网络复原多种退化图像的复杂性；
- 利用通道统计特性，将退化去除和内容重构划分为相互独立的子模块，并引入傅里叶变换对着两个模块进行辅助；
- 针对不同退化下图像在优化方向上的差异，提出了退化映射损失函数。该损失函数将退化图像信息显式纳入优化项，对不同退化图像的优化路径进行解耦，提升图像复原模型的鲁棒性。

5.2　方法介绍

在本节中，首先将具体介绍如何将退化去除与内容重构细致划分为两个独立且模块化的处理过程，随后，将详细阐述傅里叶变换在网络各关键环节中的作用机理。同时，本节将深入介绍退化去除模块中针对多种退化条件下特征分布的自适应归一化策略，该机制能够使模型动态调整内部统计，从而更好地适配不同退化图像。本章最后提出了一种具备方向性的退化映射损失函数，并系统介绍了其在优化网络和提升图像恢复效果方面的具体应用方法与关键意义。本章提出的网络总体框架基于多尺度 U-Net 结构，整体包含三组编码器与解码器，各层主要由退化去除模块与内容重构模块协同构建，并辅以多层次的上采样和下采样操作，以强化网络的多尺度特征表示和传递能力。每个模块的输入和输出维度均保持不变。具体框架结构如图 5.3所示。在完整的处理流程中，退化去除模块面向不同类型退化导致的多样化特征通道分布差异，通过对特征通道的动态调整实现针对性的退化去除，并利用退化感知的归一化方法提升对多样退化的自适应能力。内容重构模块则着重于在通道无关空间内进行全局内容信息的聚合、重建和补全，强化恢复后图像的一致性和完整性。下文将分别对这两个核心模块的原理及实现细节进行详细介绍。

中国知网　https://www.cnki.net

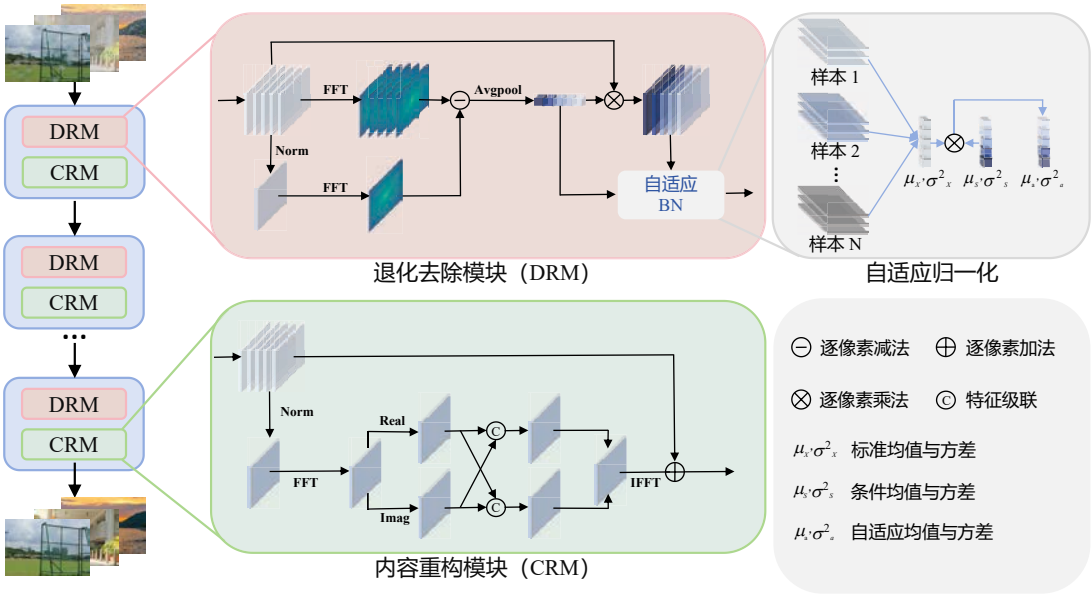


图 5.3　DDCNet 模型框架图

5.2.1　退化去除模块

不同退化形态对图像造成差异性的影响，这些机制与单一的线性退化过程有本质区别。比如在恶劣天气图像中，退化通常涉及大气光散射、视觉遮挡、运动模糊等多种物理因素的耦合作用，呈现出多样且非线性的表现形式。不同类型退化会以不同方式改变图像在频域的能量分布，如雨条的线性结构沿特定方向扰乱能量分布，破坏局部结构；雾气由于大气散射，造成能量抑制、对比度下降和丰富细节流失；雪花的随机和多尺度分布在各个频段上破坏原有能量模式，影响全局一致性等。为有效区分和处理上述多样退化特性，本节采用频域建模思路，旨在捕捉并解耦不同退化类型在频域中的表现差异，进而为后续的针对性退化去除过程的设计提供支撑。

具体而言，为了更好地捕捉和分析这些能量分布变化，本节采用傅里叶变换将特征从空间域转换到频域，从而使不同频率成分的分布特性能够更加直观地被呈现和度量。退化去除模块输入为空间域特征 $X \in \mathbb{R}^{H\times W\times C}$，其中 H 为特征高度、W 为特征宽度、C 为通道数，对每个通道独立施加二维傅里叶变换，获得频域特征 $\hat{X} \in \mathbb{R}^{H\times W\times C}$。其计算公式如下：

$$\hat{X}_{u,v,c} = \frac{1}{\sqrt{HW}} \sum_{h=0}^{H-1} \sum_{w=0}^{W-1} X_{h,w,c} \cdot e^{-j2\pi\left(\frac{h}{H}u+\frac{w}{W}v\right)}, \tag{5.1}$$

其中，$X_{h,w,c}$ 表示第 c 个通道在 (h,w) 坐标的值，u,v 为频域坐标。对得到的频域特征，进一步计算幅值谱，从而量化各频率成分的能量分布：

$$A = \sqrt{\mathrm{Re}(\hat{X})^2 + \mathrm{Im}(\hat{X})^2}, \tag{5.2}$$

其中 $\mathrm{Re}(\cdot)$ 和 $\mathrm{Im}(\cdot)$ 分别为复数特征的实部和虚部。

中国知网　https://www.cnki.net

在获得整体幅度特征后，需进一步区分各通道的退化特性。具体做法是，先对输入特征 X 在通道维度求均值得到 X_{ci}，用于表征不同通道间的共有信息。接着，对 X_{ci} 计算傅里叶幅度谱 A_{ci}，该特征作为通道无关的退化基准。随后，将 A 与 A_{ci} 作差，可有效突出每个通道独有的退化残差信息：

$$A_{deg} = A - A_{ci}. \tag{5.3}$$

这样，A_{deg} 每一通道所包含的成分，便专门捕捉了其独有的退化影响。为将上述通道差异性退化信息进一步提炼为用作通道间调制的条件向量，本节对 A_{deg} 先以全局平均池化 $g(\cdot)$ 处理，再依次通过两层全连接网络（f_{p1} 和 f_{p2}）、LeakyReLU[150] 和 Sigmoid 激活函数，最终形成通道条件向量 S_{con}：

$$S_{con} = \text{Sigmoid}(f_{p2}(\text{LeakyReLU}(f_{p1}(g(A_{deg}))))), \tag{5.4}$$

其中，$g(\cdot)$ 实现特征降维，f_{p1}, f_{p2} 为线性映射，Sigmoid 保证输出处于 [0,1] 区间，用于调节各通道特征响应。随后，将自适应条件向量 S_{con} 作用于原始输入特征 X 的各个通道，实现针对性地抑制或增强特定通道的特征，得到调制后的中间特征 X_d：

$$X_d = X \cdot S_{con}, \tag{5.5}$$

这种调制机制实现了通道相关的特征调制操作。

在特征调制基础上，为进一步提升模型应对不同退化分布的适应能力，本章设计了退化感知归一化机制。具体流程为：分别对调制特征 X_d 和退化残差信号 A_{deg} 在批次和通道维度统计均值和方差，分别记作 μ_X, σ_X^2 与 μ_S, σ_S^2，用于构建动态归一化参数：

$$\begin{aligned} \mu_a &= \mu_X + \gamma \cdot \mu_S, \\ \sigma_a^2 &= \sigma_X^2 + \gamma \cdot \sigma_S^2, \end{aligned} \tag{5.6}$$

其中 $\gamma = 1$，用以平衡两类统计量。归一化输出形式为：

$$X_n = \frac{X - \mu_{\text{a}}}{\sqrt{\sigma_{\text{a}}^2 + \epsilon}}, \tag{5.7}$$

其中，ϵ 是用于确保数值稳定的小常数（本章设为 1e−5）。通过将退化特征与主特征的统计量联合建模，模型能够更灵活地适应并校正特征分布，从而提升应对动态和复杂退化条件下的鲁棒性。

5.2.2　内容重构模块

内容重构阶段既需要充分捕捉细致的局部特征，也要保证全局结构的完整性与整体内容的一致性。为此，本章设计了局部-全局双分支的内容重构结构：其

中国知网　https://www.cnki.net

中局部分支采用标准卷积模块，专注于提取和恢复丰富的局部细节信息；全局分支则面向不同区域间的信息整合与整体内容表达。

全局分支中的目标是处理与退化无关的全局内容信息。受文献[176]启发，本节首先对退化去除模块输出的特征 X_n 在通道维度进行均值操作，生成单通道的特征映射 $X_s \in \mathbb{R}^{H\times W\times 1}$。这一操作不仅融合了跨通道的信息，还能显著削弱通道特有的退化残留干扰，使 X_s 更纯粹地反映内容本身。随后，将所得单通道特征 X_s 送入全局分支进行频域计算。具体实现上，首先通过二维实数傅里叶变换将 X_s 映射到频域，获得复数形式的特征张量 $\hat{X}_s$。由于其包含实部和虚部两部分信息无法直接进行数值运算，因此网络分别对实部和虚部进行两条路径的特征提取：一条是直接作用于实部与虚部本身；另一条则是交叉作用，即用实部生成虚部的修正量、用虚部生成实部的修正量，实现信息的交互补充。两路特征在频域中融合后，首先通过卷积层进一步整合，再组合形成新的复数频域特征。最后，经过二维逆傅里叶变换，将融合后的频域特征还原为空间域表达，并通过 3×3 卷积进一步聚合和细化特征，最终获得全局分支的输出特征图。借助傅里叶变换对全局信息的高效建模能力，这一过程进一步编码了特征的全局结构模式，有助于丰富内容的整体表达。最终，模型能够更有效地提取内容复原所需的核心信息，并在重建结果中保持跨通道的一致性与整体结构的协调。

5.2.3　退化映射损失函数

本章提出的退化映射损失函数，专门针对多种退化条件下的图像恢复任务设计，该损失函数具体步骤如下：设 I_{in} 为输入的退化图像，I_{out} 为网络输出图像，I_{gt} 为对应的清晰图像。在损失函数中引入退化条件下的图像，使网络在优化过程中能够全面考虑不同输入的影响，从而有效约束优化方向。通过这种方式，能够训练网络应对多种复杂场景，使其在各类退化退化条件下都具备良好的鲁棒性。具体而言，首先分别计算输入图像与网络输出之间的残差，以及输入图像与真实图像之间的残差。残差反映了需要通过网络校正的具体差异。关注残差能够让网络更好地理解去除退化所需进行的具体调整。网络输出的残差定义为：

$$R_{out} = \mathcal{A}(I_{out}) - \mathcal{A}(I_{in}), \tag{5.8}$$

真实值的残差定义为：

$$R_{gt} = \mathcal{A}(I_{gt}) - \mathcal{A}(I_{in}), \tag{5.9}$$

其中 $\mathcal{A}$ 表示对图像进行傅里叶变换后取幅值。随后，通过最大化这两组残差之间的余弦相似度，确保退化去除方向的一致性。余弦相似度衡量两个向量之间的方向一致性，最大化该值有助于引导网络输出的修正方向更加接近真实退化校正的路径。这不仅提升了网络对图像退化去除的准确性，也增强了其在多样退化

中国知网　https://www.cnki.net

条件下的鲁棒能力，从而提高模型整体表现。两组残差间的余弦相似度的计算方式如下：

$$R_{cs} = \frac{R_{out} \cdot R_{gt}}{\|R_{out}\| \|R_{gt}\|}, \tag{5.10}$$

其中 $R_{out} \cdot R_{gt}$ 表示两组残差的点积，$\|R_{out}\|$ 和 $\|R_{gt}\|$ 分别表示它们的模长。当 R_{cs} 越接近 1 时，R_{out} 与 R_{gt} 的方向更一致性，因此退化映射损失函数定义为：

$$\mathcal{L}_{DM}(I_{in}, I_{out}, I_{gt}) = 1 - R_{cs}. \tag{5.11}$$

5.3　实验与分析

本节首先展示本章方法在各图像复原任务上的定量与定性结果。进而，本节剖析各设计环节的合理性。在此基础上，本节执行消融实验以验证本章方法的有效性。最后，本节讨论本章方法的缺陷。

5.3.1　实验细节

本章的实验在四块 NVIDIA GTX 4090 显卡上进行，每轮训练时均对图像进行随机打乱。训练时首先从图像上随机裁剪大小为 224×224 的图像块，并结合随机旋转等数据增强策略。模型一共训练 300 轮，采用 Adam 优化器[157]，学习率从 2×10^{-4} 通过余弦退火策略逐步衰减至 1×10^{-6}。

表 5.1　DDCNet 在 Outdoor-Rain 与 Rainidrop 数据集的定量指标

任务类型	Outdoor-Rain			RainDrop		
	方法	PSNR↑	SSIM↑	方法	PSNR↑	SSIM↑
专用模型	pix2pix[67]	19.09	0.71	pix2pix[67]	28.02	0.85
	HRGAN[63]	21.56	0.86	Attn.Gan[78]	30.55	0.90
	MPRNet[93]	21.90	0.85	CCN[152]	31.34	0.95
自适应模型	All-in-One[74]	24.71	0.90	All-in-One[74]	31.12	0.93
	TransWeather[75]	23.18	0.84	TransWeather[75]	28.98	0.90
	TKL&MR[107]	23.94	0.85	TKL&MR[107]	30.75	0.91
	WGWS-Net[109]	25.31	0.90	WGWS-Net[109]	31.31	0.90
	Tan *et al.*[111]	28.70	0.94	Tan *et al.*[111]	29.98	0.95
	DDCNet	27.95	0.95	DDCNet	31.45	0.94

5.3.2　实验结果

本节介绍本章所提方法的定量和定性结果。

1. 定量结果

为评估本章网络的性能，采用了退化图像复原领域广泛认可的定量评估指标：PSNR、SSIM[136]和 PSNR-B[137]（仅用于 JPEG 压缩图像复原），这三个指

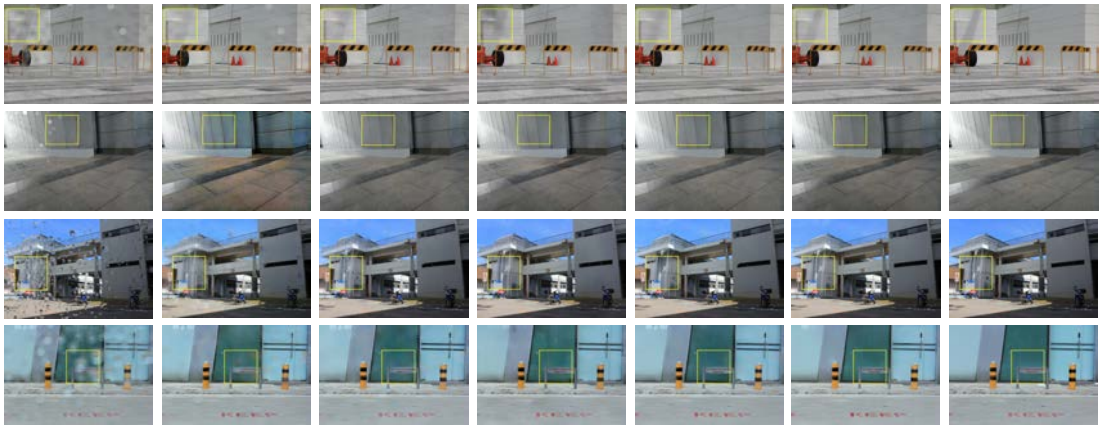
中国知网　https://www.cnki.net

表 5.2　DDCNet 在 SnowTest100K-L 数据集的定量指标

任务类型	方法	SnowTest100k-L	
		PSNR↑	SSIM↑
专用模型	DetailsNet[153]	19.18	0.75
	DesnowNet[69]	27.17	0.90
	JSTASR[105]	25.32	0.81
	DDMSNET[154]	28.85	0.88
自适应模型	All-in-one[74]	28.33	0.88
	TransWeather[75]	27.80	0.85
	TKL&MR[107]	29.27	0.88
	WGWS-Net[109]	29.71	0.89
	Tan *et al.*[111]	28.54	0.92
	DDCNet	30.76	0.95

表 5.3　DDCNet 在雨-雾-噪声图像测试数据集的定量指标

任务类型	方法	CBSD68[87]			SOTS[84]	Rain100L[85]	平均
		$\sigma=15$	$\sigma=25$	$\sigma=50$			
		PSNR↑/SSIM↑	PSNR↑/SSIM↑	PSNR↑/SSIM↑	PSNR↑/SSIM↑	PSNR↑/SSIM↑	PSNR↑/SSIM↑
专用模型	LPNet[155]	26.47/0.778	24.77/0.748	21.26/0.552	20.84/0.828	24.88/0.784	23.64/0.738
	DehazeFormer[102]	33.01/0.914	30.14/0.858	27.37/0.779	29.58/0.970	35.37/0.969	31.09/0.898
	DRSformer[98]	33.28/0.921	30.55/0.862	27.58/0.786	29.02/0.968	35.89/0.970	31.26/0.902
自适应模型	DL[130]	33.05/0.914	30.41/0.861	26.90/0.740	26.92/0.391	32.62/0.931	29.98/0.875
	IDR[131]	33.89/0.931	31.32/0.884	28.04/0.798	29.87/0.970	36.03/0.971	31.83/0.911
	ProRes[132]	32.10/0.907	30.18/0.863	27.58/0.779	28.38/0.938	33.68/0.954	30.38/0.888
	PromptIR[133]	33.98/0.933	31.31/0.888	28.06/0.799	30.58/0.974	36.37/0.972	32.06/0.913
	NDR[134]	34.01/0.932	31.36/0.887	28.10/0.798	28.64/0.962	35.42/0.969	31.51/0.910
	Gridformer[135]	33.93/0.931	31.37/0.887	28.11/0.801	30.37/0.970	37.15/0.972	32.19/0.912
	DDCNet	34.16/0.932	31.52/0.889	28.06/0.789	34.68/0.987	37.39/0.981	33.16/0.916



输入图像　TransWeather　TKL&MR　WeatherDiff　WGWS-Net　DDCNet　清晰图像

图 5.4　DDCNet 在 Outdoor-Rain 数据集与其他方法可视化对比

标的具体计算方式在节 2.3中有具体阐述。这些指标作为量化标准，用于衡量本章模型在处理多种退化条件下的有效性。评估过程中与针对特定退化条件设计的方法以及面向多种退化场景的一体化方法进行了比较。本章在恶劣天气图像复原的定量结果见表 5.1和表 5.2。在雨-雾-噪声图像复原的定量对比 5.3所示。在 JPEG 图像复原的定量对比如表 5.4所示。这些表格涵盖了专用退化图像复原方

中国知网　https://www.cnki.net

表 5.4　DDCNet 在 JPEG 图像测试数据集的定量指标

数据集: Classic5[83]（PSNR↑/SSIM↑/PSNR-B↑）				
方法	QF=10	QF=20	QF=30	QF=40
专用模型				
ARCNN[114]	29.03/0.793/28.76	31.15/0.852/30.59	32.51/0.881/31.98	33.32/0.895/32.79
RDN[118]	30.03/0.819/29.59	32.19/0.870/31.53	33.46/0.893/32.59	-
MWCNN[73]	30.01/0.820/29.59	32.16/0.870/31.52	33.43/0.893/32.62	34.27/0.906/33.35
CODE[121]	30.12/0.822/29.80	32.35/0.873/31.76	33.59/0.895/32.80	34.41/0.907/33.49
自适应模型				
DnCNN[66]	29.40/0.803/29.13	31.63/0.861/31.19	32.91/0.886/32.38	33.77/0.900/33.23
DCSC[122]	29.62/0.810/29.30	31.81/0.864/31.34	33.06/0.888/32.49	33.87/0.902/33.30
QGAC[76]	29.84/0.812/25.21	31.98/0.869/27.50	33.22/0.892/28.94	34.05/0.905/29.92
FBCNN[77]	30.12/0.822/29.80	32.31/0.872/31.74	33.54/0.894/32.78	34.35/0.907/33.48
DDCNet	30.24/0.825/29.88	32.41/0.874/31.82	33.61/0.895/32.85	34.42/0.908/33.54

数据集: LIVE1[82]（PSNR↑/SSIM↑/PSNR-B↑）				
方法	QF=10	QF=20	QF=30	QF=40
专用模型				
ARCNN[114]	28.96/0.808/28.68	31.29/0.873/30.76	32.67/0.904/32.14	33.61/0.920/33.11
RDN[118]	29.70/0.825/29.37	32.10/0.889/31.29	33.54/0.916/32.62	-
MWCNN[73]	29.69/0.825/29.32	32.04/0.889/31.51	33.45/0.915/32.80	34.45/0.930/33.78
CODE[121]	29.78/0.827/29.45	32.15/0.889/31.60	33.57/0.916/32.87	34.55/0.931/33.78
自适应模型				
DnCNN[66]	29.19/0.812/28.90	31.59/0.880/31.07	32.98/0.909/32.34	33.96/0.925/33.28
DCSC[122]	29.34/0.818/29.01	31.70/0.883/31.18	33.07/0.911/32.43	34.02/0.926/33.36
QGAC[76]	29.51/0.825/25.33	31.83/0.888/27.57	33.20/0.914/28.92	34.16/0.929/29.96
FBCNN[77]	29.75/0.827/29.40	32.13/0.889/31.57	33.54/0.916/32.83	34.53/0.931/33.74
DDCNet	29.82/0.828/29.44	32.19/0.890/31.58	33.60/0.917/32.83	34.57/0.931/33.74

数据集: BSDS500[86]（PSNR↑/SSIM↑/PSNR-B↑）				
方法	QF=10	QF=20	QF=30	QF=40
专用模型				
ARCNN[114]	29.10/0.804/28.73	31.28/0.870/30.55	32.67/0.902/31.94	33.55/0.918/32.78
RDN[118]	29.24/0.808/28.71	31.48/0.879/30.45	32.83/0.908/31.60	-
MWCNN[73]	29.61/0.820/29.14	31.92/0.885/31.15	33.30/0.912/32.34	34.27/0.928/33.19
CODE[121]	29.65/0.821/29.15	31.98/0.885/31.11	33.37/0.913/32.25	34.34/0.928/33.05
自适应模型				
DnCNN[66]	29.21/0.809/28.80	31.53/0.878/30.79	32.90/0.907/31.97	33.85/0.923/32.80
DCSC[122]	29.32/0.813/28.91	31.63/0.880/30.92	32.99/0.908/32.08	33.92/0.924/32.92
QGAC[76]	29.46/0.821/25.10	31.73/0.884/27.22	33.07/0.912/28.53	34.01/0.927/29.49
FBCNN[77]	29.67/0.821/29.22	32.00/0.885/31.19	33.37/0.913/32.32	34.33/0.928/33.10
DDCNet	29.70/0.823/29.15	32.05/0.887/31.12	33.43/0.914/32.26	34.437/0.929/33.06

法和自适应图像复原方法，全面对比了本章方法与现有主流方法的定量效果。同时，本章在 Outdoor-Rain 和 RainDrop 数据集上对 LPIPS 感知指标进行了对比评估，结果如表5.5所示，可以看出本章方法在感知质量上同样表现优异。

中国知网　https://www.cnki.net

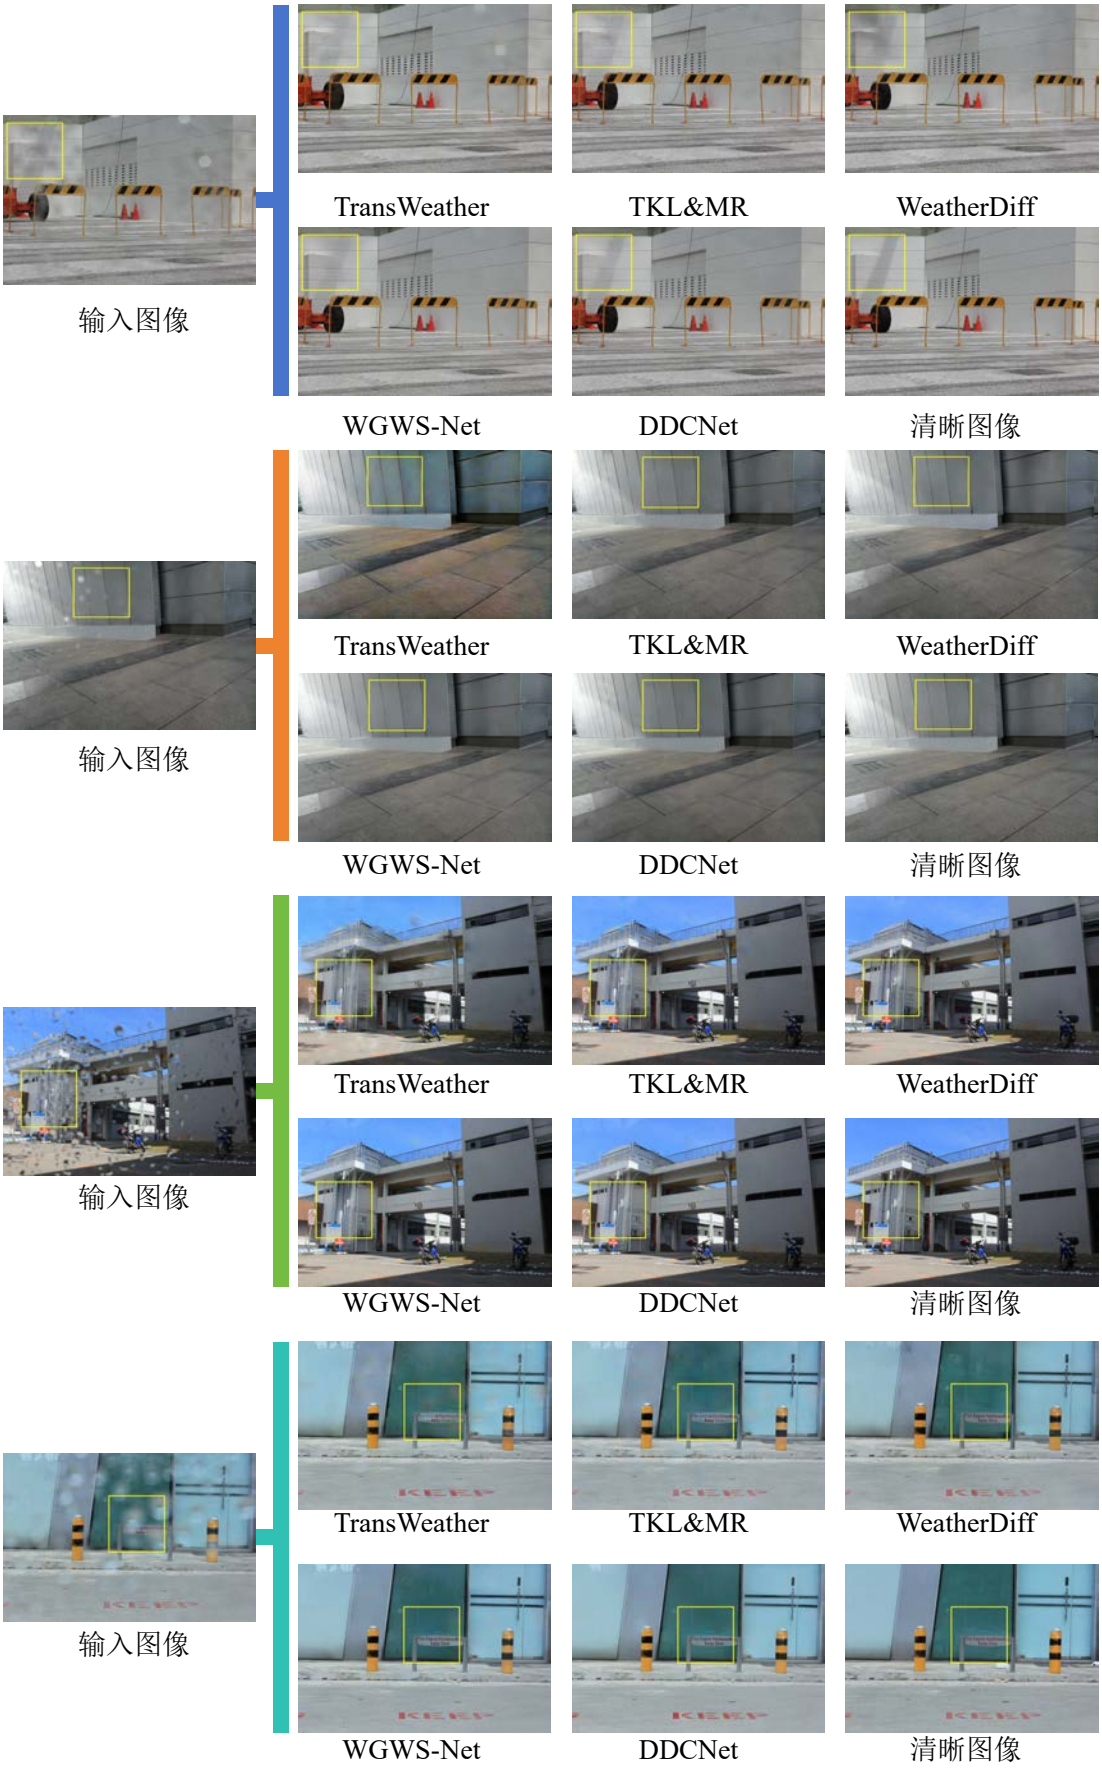
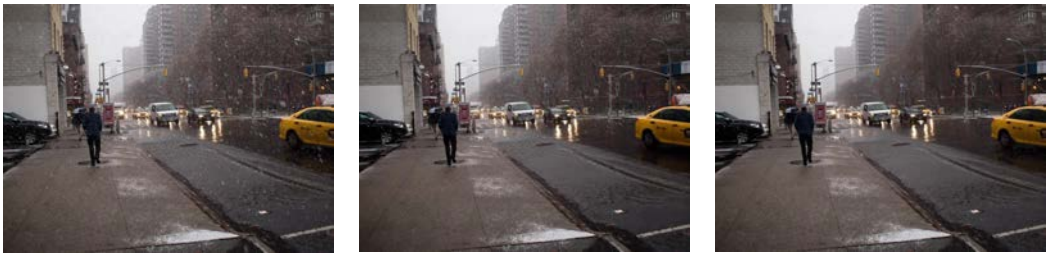
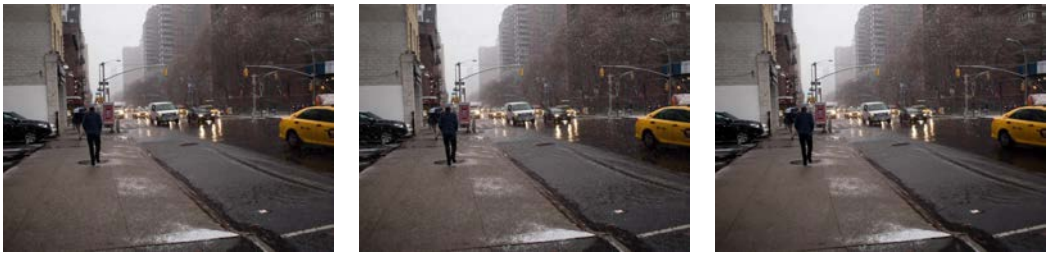


图 5.5　DDCNet 在 Raindrop 数据集与其他方法可视化对比

中国知网　https://www.cnki.net



输入图像　　TransWeather　　TKL&MR



WeatherDiff　　WGWS-Net　　DDCNet



输入图像　　TransWeather　　TKL&MR



WeatherDiff　　WGWS-Net　　DDCNet

图 5.6　DDCNet 在 realistic 数据集与其他方法可视化对比

表 5.5　DDCNet 在 Outdoor-Rain 与 Rainidrop 数据集的感知指标

方法 / 数据集	TransWeather	TKL&MR	WeatherDiff	WGWS-Net	DDCNet
Outdoor-Rain (LPIPS↓)	0.0785	0.1014	0.0846	0.0940	0.0748
Raindrop (LPIPS↓)	0.0872	0.0543	0.0590	0.0599	0.0590

2. 定性结果

此外，本章方法的视觉效果展示如图 5.4、图 5.5和图 5.6所示。上述可视化对比充分突显了本章方法在退化条件下提升图像整体清晰度及恢复纹理细节方面的有效性。从图 5.5可以看出，本章方法不仅成功去除了雨滴干扰，还显著恢

中国知网　https://www.cnki.net

复了图像中的纹理细节，尤其在物体边缘与轮廓的表现上更为突出。该结果表明，本章方法在面对雨滴干扰时能够更好地保留与重建图像细节，从而提升图像的整体质量。进一步来看，在图 5.6中，本章方法能有效减少全局范围内的雪花干扰，使恢复后的图像更加清晰。该现象进一步验证了本章方法在去除雪花噪声方面的优越性能，显著提升了图像的视觉效果和细节表现力。

5.3.3　方法分析

为深入解释本章的若干关键设计，本节进行一系列实验和可视化分析。首先分析如何利用通道统计特性实现退化去除与内容重构的分离。接着，解释在退化去除与内容重构中采用傅里叶变换的有效性。此外，还进一步探究采用自适应批归一化的合理性。最后，进一步利用退化映射损失函数对网络优化的合理性。

1. 通道特征解耦

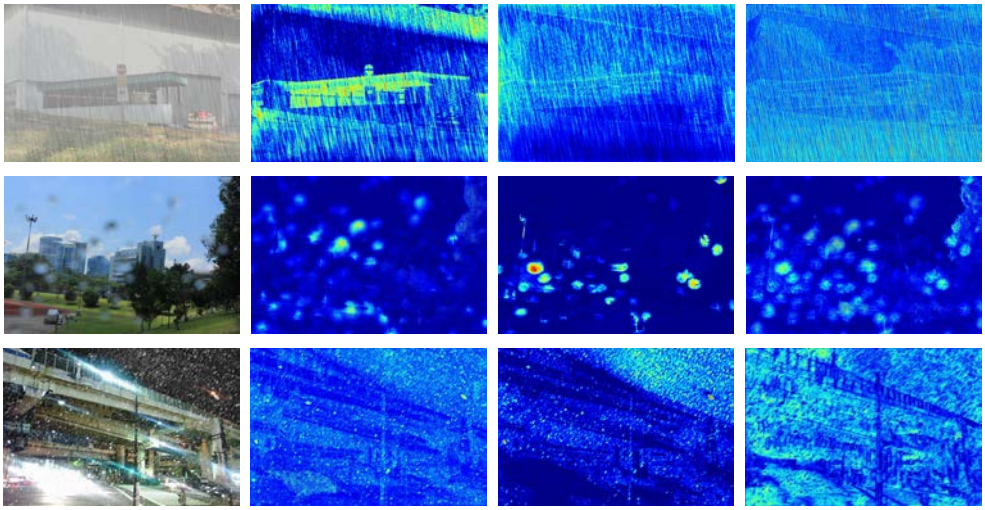
本节基于训练好的网络，对其通道统计特性进行了实验性分析，相关结果如图 5.7所示，旨在探究不同退化条件（雨、雾、雪）下，网络各层特征通道的统计属性及退化信息的分布特性。

图 5.7a展示了在不同退化图像输入下，各通道所包含退化信息的分布情况。可以观察到，不同通道对退化信息的敏感性存在明显差异：部分通道对退化的响应显著，而另一些通道则表现出较低的敏感性。这种统计性差异说明，网络的不同通道在表征退化信息时具有一定的特征选择性和分工。因此，通过适当调整通道间的关系，有望实现针对性的退化去除。图 5.7b则通过 t-SNE 可视化，对通道维均值操作前后的特征分布进行了比较。具体而言，随机选取每种退化图像各 200 张，分别送入网络，并在相同的特征层上沿通道维进行均值操作后，使用 t-SNE 投影到二维空间。左侧为均值操作前的可视化结果，特征分布呈现明显的聚类现象，不同退化场景间区分度较高，退化信息在特征空间中高度耦合。右侧为均值操作后的分布，退化带来的离散性明显减弱，内容信息更加突出。结果表明，通道均值操作能够有效削弱退化相关的分布特征，使网络特征表达更关注于内容信息。因此，后续的内容重构操作可在去除通道依赖（即通道均值处理后）的特征空间中进行，从而减小退化的影响。

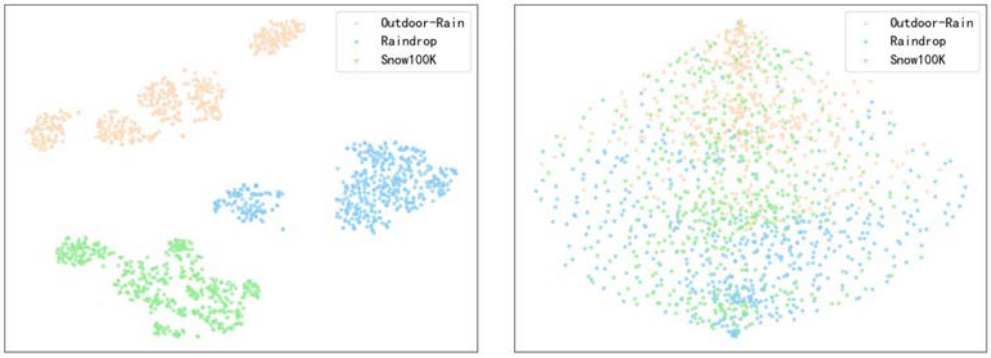
2. 退化去除

如文献[177]所述，图像退化信息主要集中于傅里叶域的幅值分量。为进一步验证和量化这一观点，本章设计并开展了幅值交换相关实验，实验流程和结果如图 5.8所示，分为定性与定量分析两部分。首先，定性实验侧重于直观验证退化属性与幅值分量的相关性。具体步骤如下：我们选取了典型的退化图像中的雾图及其对应的清晰图像，分别对它们进行快速傅里叶变换，将得到的傅里叶域幅值分量进行互换，即将退化图像的幅值与真实图像的幅值进行替换，再通过逆傅里

中国知网　https://www.cnki.net



(a) 不同的特征通道表现出不同水平的退化

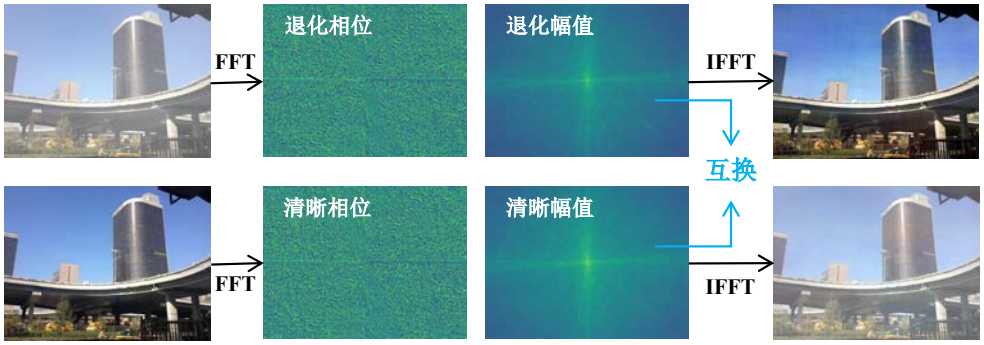


(b) 通道维度上的平均操作有助于抑制退化效应，增强内容信息的提取。左左图为未进行通道平均的特征 t-SNE 可视化，右图为通道平均后的特征 t-SNE 可视化。

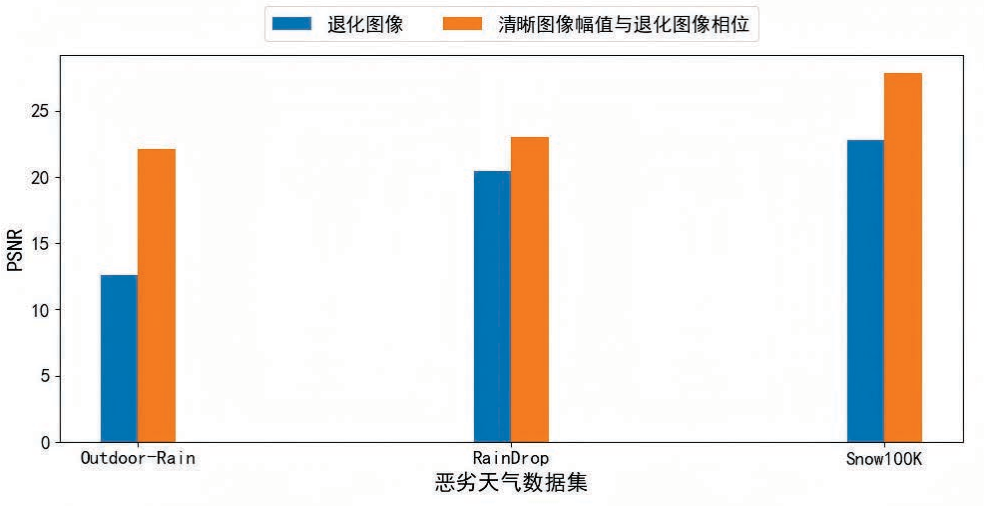
图 5.7　特征通道统计特性

叶变换重建图像。实验发现，经过幅值互换后，原本退化下的图像因获得了真实图像的幅值分量，其视觉效果表现出明显的去退化特征，图像更加清晰，反之，真实图像在换入退化图像的幅值分量后则出现明显的模糊与退化迹象。这充分说明，幅值可以捕获大部分图像的退化信息。进一步地，定量实验针对上述现象进行了系统的数值分析。具体实验设置为：从的三类退化数据集中，各随机采样 200 张退化图像，和其对应的干净版本。对于每对图像，分别提取其傅里叶域幅值分量，并将退化图像的幅值用其配对的真实图像幅值替代。然后以逆变换还原幅值交换后的图像，并将其与原真实图像计算峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）。所有交换结果的 PSNR 提升被统计汇总，实验结果如 5.8b所示。可以看到，通过幅值分量的交换，重建图像的 PSNR 相比原退化图像有显著提升，表明图像质量获得大幅度改善。该结果进一步印证了退化信息在幅值分量上的分布集中性。

中国知网　https://www.cnki.net



(a) 将雾图像的振幅与其对应清晰图像的振幅进行交换，“退化”和“清晰”的属性也随着幅值一同转移。



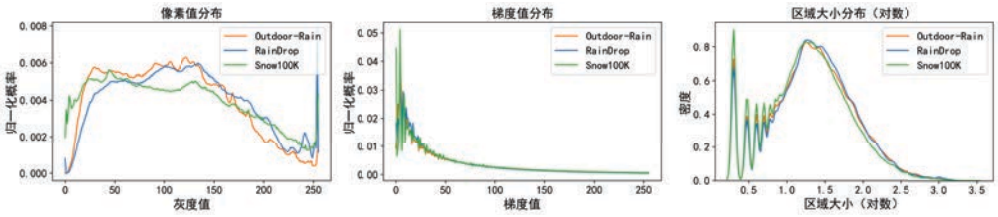
(b) 从 Outdoor-Rain、RainDrop、Snow100K 和对应的清晰图像数据集中各选取 200 张图像，将恶劣天气图像的幅值与其对应清晰图像的幅值进行交换，并计算平均 PSNR。结果显示，交换后 PSNR 显著提升，表明退化信息主要存在于幅值中。

图 5.8　退化信息主要位于幅值的定性和定量分析

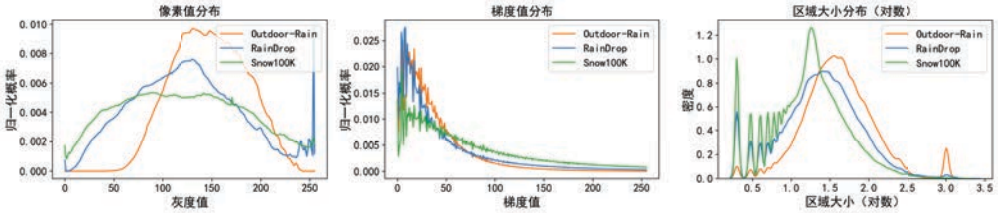
3. 内容重构

本节选用了三个统计量来验证图像底层内容的一致性，分别为灰度值分布、梯度分布和边缘连通域大小分布，如图 5.9所示。具体方法如下：首先，对每张图像进行灰度化处理，统计其像素灰度值的归一化直方图，用以反映整体亮度和对比度特性；其次，通过 Sobel 算子计算图像的梯度幅值，并对其进行归一化直方图统计，以量化纹理和边缘变化的分布；最后，通过 Canny 算子[178]提取图像边缘，计算边缘的连通域，并统计这些连通域大小的对数分布，来衡量图像的结构和物体连续性。实验结果表明，对于雨、雾、雪三类退化下的清晰图像数据集，这三种统计分布均高度接近，说明它们的底层内容在亮度、纹理与结构等方面具有一致性。而对于相应的退化图像数据集，这些统计量分布之间的差异明显

中国知网　https://www.cnki.net



(a) 清晰图像统计分布



(b) 退化图像统计分布

图 5.9　不同恶劣天气与对应清晰图像的分布统计特性

加大，揭示退化过程会扰动图像的底层分布特征，导致内容一致性下降。因此，为实现恢复清晰图像一致性内容的目标，本章针对不同退化图像提出采用一致性的内容重构方法是合理的。

4. **退化映射损失函数**

如图 5.10所示，本节从各退化数据集中随机选取 500 张图像，统计这些图像及其对应真实图像的幅值。结果清晰展示了不同退化条件下频域优化方向的显著差异。例如，受雪影响的图像在大多数频段上幅值大于对应清晰图像，因此雪图复原过程需有效抑制多个频段的噪声成分；而受雾霾影响的图像整体对比度降低，频谱集中于低频区域，雾图复原则需增强高频细节。这些现象表明，针对不同退化类型退化的图像，其频域恢复目标和优化侧重点都具有明显差异。因此本章提出基于向量化计算的退化映射损失函数。该损失不仅关注退化图像与清晰图像之间的数值差异，更在损失函数中显式约束恢复方向，使其与图像去退化目标相一致。具体而言，通过最大化退化与清晰图像在频域中残差向量的余弦相似度，引导网络在优化过程中朝着正确的频域恢复方向调整，从而更有效地提升退化图像的恢复效果。

相比之下，传统损失函数如 $\mathcal{L}_1$ 损失和感知损失[179]，虽然能够缩小退化图像与清晰图像之间的数值差距，但仅关注像素或特征空间的距离，忽略了优化方向的合理性。$\mathcal{L}_1$ 损失广泛应用于图像恢复任务，但由于其本质上仅仅最小化像素级的绝对误差，在面对多种退化下的复杂退化场景时，常常导致解的中值化现象，即输出结果趋向于所有可能解的中值，这会造成图像细节丢失和整体模糊。此外，$\mathcal{L}_1$ 损失只在像素层面进行绝对值差异的最小化，缺乏方向性指导；而感知损失虽然衡量高层特征之间的欧氏距离，但其本质仍是数值最小化，并未解决

中国知网　https://www.cnki.net

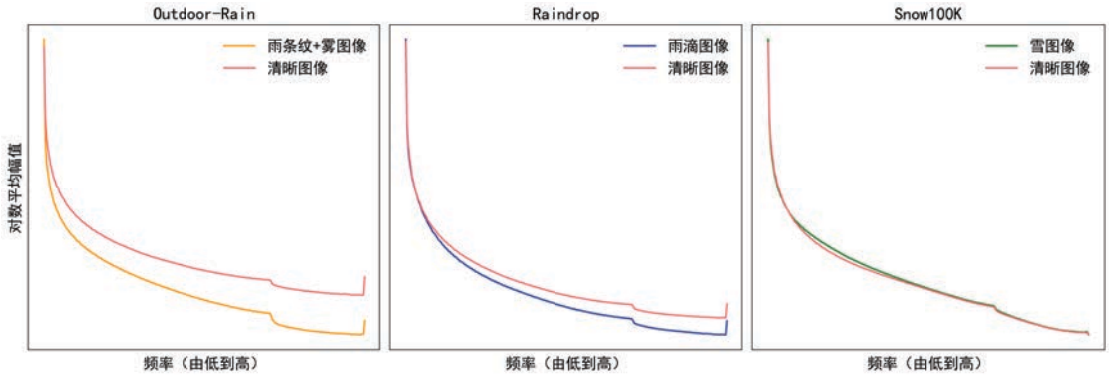


图 5.10　恶劣天气与其对应清晰图像数据集的频域幅值统计图

优化方向不合理的问题。针对上述不足，本章提出的退化映射损失函数，通过最大化网络输出残差与真实残差之间的余弦相似度，有效引导网络在恢复过程中产生与实际退化校正方向一致的修正内容。该方法不仅强调像素数值层面差异，还关注恢复路径的走向合理性，从而有效约束了解空间，减少了模糊和不确定解的出现。

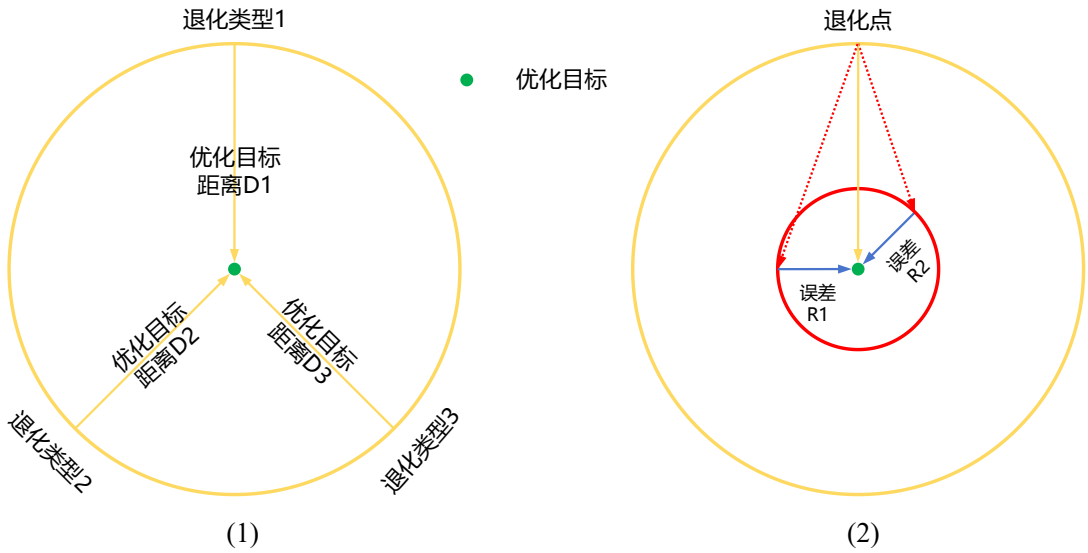


图 5.11　退化图像到清晰图像的距离与方向

接下来，举例详细说明退化损失函数中方向约束的意义。对于不同退化分布向干净分布优化的情形，如图 5.11(1) 所示, 其外部的黄色圆圈代表各种退化类型图像的分布，其中，分别中圆圈上的三个点表示“退化类型 1”“退化类型 2”和“退化类型 3”，圆心处的绿色点则表示清晰图像的分布。由圆心向三个退化类型的三条径向直线，分别对应三种退化类型到清晰图像之间的优化路径，在图中分别标注为“优化目标距离 D1”“优化目标距离 D2”和“优化目标距离 D3”。从图上可以看出，无论是哪一种退化类型，由圆圈上的退化分布点到圆心清晰图像分布点的距离 D1、D2、D3，实际对应的长度是一样的，这些不同的退化类型通向清晰图像分布的优化路径长度是相等的。这说明仅仅从标量距离来看，各种退

中国知网　https://www.cnki.net

化对于清晰图像的优化目标是一样的。然而，这些退化尽管通向清晰图像路径的标量距离相同，但是他们路径的方向各不相同。也就是说，从“退化类型 1”到清晰图像、从“退化类型 2”到清晰图像以及从“退化类型 3”到清晰图像的最优路径分别位于不同方向上。如果损失函数只考虑标量距离，而忽略了路径对应的方向，那么在优化时模型可能会把这些退化视为相同的类型, 无法约束每种退化类型都朝着属于自己特定的方向靠近清晰图像。

对于同一退化分布向干净分布优化的情形，如图 5.11(2) 所示，从圆圈上的同一点（即同一种退化类型）出发，有两条红色虚线分别代表两条不同的优化路径，其终点到绿色圆心（即清晰图像分布）的距离分别标注为“误差 R1”和“误差 R2”。可以看到，这两条路径的终点距离圆心相同，也就是说，它们的复原误差在标量距离上是相等的。然而，两条路径的方向却截然不同，分别对应着不同的修正方式。也就是说，在距离相同的前提下，方向的不同实际代表着完全不同的优化路径。因此，尽管误差的距离度量能够反映输出与目标之间的偏差大小，但仅依靠距离损失函数无法优化路径的方向进行约束。正如图中所示，距离圆心相同的点在误差圆周上有无数个，代表着不同方向的误差。只有当输出残差的方向大小与目标残差完全一致时，复原结果才可能达到最优。

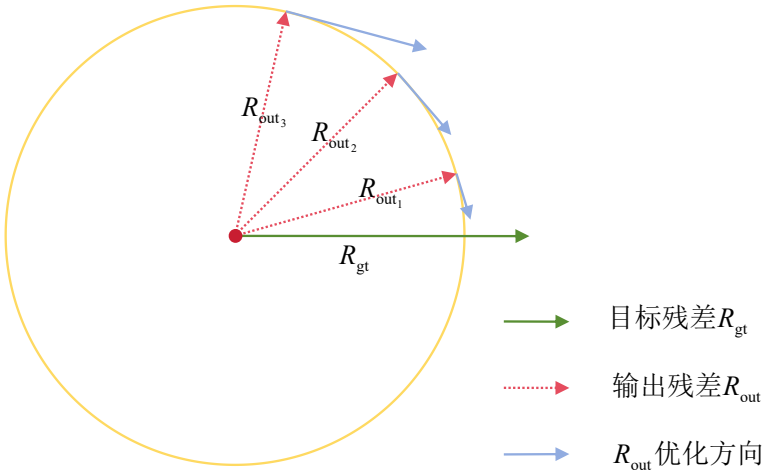


图 5.12　方向约束型损失函数

图 5.12更清晰的展示在退化映射损失函数的约束下输出残差的优化方向，如图所示：绿色的水平向量 R_{gt} 表示目标残差，即退化图像通向其清晰图像的距离和方向。与目标残差起点相同，且大小相同但方向不相同的三个红色虚线 R_{out_i}（i = 1,2,3）分别代表不同的输出残差。以这三个输出残差的长度作为半径绘制圆周，其与对应 R_{out} 末端的交点沿所在圆周切向绘制的蓝色向量，表示 R_{out} 的修正方向。该修正方向与对应的 R_{out} 红色向量相互垂直，促使其方向向 R_{gt} 对齐。从图中可以看出，这三个输出残差的长度是相同的，但它们与目标残差的夹角不同。根据该损失函数的特性，夹角越大，其对应的约束也就越强。图中向量与

中国知网　https://www.cnki.net

R_{gt} 的夹角大小关系为 $\theta_3 > \theta_2 > \theta_1$。因此，拥有最大夹角 θ_3 的向量 R_{out_3} 受到的修正力度最大，其对应的蓝色修正向量最长。夹角最小的 θ_1 的向量 R_{out_1} 因其方向与目标最接近，所以受到的约束最弱，其对应的蓝色修正向量最短。

综上所述，损失函数中引入方向约束具有实际意义，方向约束能够约束每种退化类型沿着各自的方向优化回清晰图像分布，确保每个退化类型都可以沿着最合适的路径实现有效复原。这种设计，有助于提升图像复原模型对于多种退化类型的准确性。

5.3.4　消融实验

本章在恶劣天气图像复原进行了消融实验，定量指标对比基于 Raindrop 数据集，以验证所提方法的有效性。

1. 退化去除模块

（1） 幅值指导作用分析

为验证傅里叶变换幅值信息在引导退化去除过程中的有效性，本章开展了一系列消融实验。首先，从所有退化去除模块中移除幅值引导（Amplitude Guidance, AG）步骤，得到修改后的模型，记为 Model-1。如表 5.6所示，定量指标表明了该操作的有效性。此外，为分析提取通道无关退化信息的重要性，本章移除了对特征进行归一化幅值减法（Normalized Amplitude Subtraction, NAS）的步骤，形成了另一个变体 Model-2。结果显示，去除 NAS 后，PSNR 下降，说明该操作对有效处理退化信息具有关键作用。

（2） 自适应批归一化

本章还探索了 BatchNorm 操作对调控退化信息的影响。具体分析了三种配置：完全移除 BatchNorm（称为 Model-3）、采用常规 BatchNorm（Model-4）以及采用自适应 BatchNorm（Adaptive BatchNorm, ABN）。定量分析结果显示，自适应 BatchNorm 较常规 BatchNorm 提升了 0.11dB PSNR，有效提升了网络整体性能，展示了其有效性。

表 5.6　退化去除模块消融实验

模型设置	AG	NAS	BN	ABN	PSNR
Model-1					31.16
Model-2	✓				31.21
Model-3	✓	✓			31.34
Model-4	✓	✓	✓		31.28
DDCNet	✓	✓		✓	31.45

2. 内容重构模块

为验证所提出内容重构模块的有效性，本章将网络中所有该模块替换为串联 RDBlock 形成的结构，得到变体 Model-5。如表 5.7所示，采用本章提出的内

中国知网　https://www.cnki.net

容重构模块后，PSNR 提升，进一步证实了该模块的有效性。此外，为论证基于傅里叶变换引入全局信息在内容重构中的优势，进一步移除傅里叶操作，得到 Model-6。实验结果表明傅里叶变换可带来额外的性能提升。

表 5.7　内容重构模块消融实验

模型设置	CR	FCR	PSNR
Model-5			31.23
Model-6	✓		31.32
DDCNet	✓	✓	31.45

3. 损失函数

本章还分析了不同损失函数组合对网络性能的影响。具体做法是先将 λ_2 和 λ_3 设为 0，分别考察每项损失的单独贡献。定量结果如表 5.8所示，本章提出的退化映射损失可提升网络性能 0.16dB，FFT 损失可带来 0.13dB 的提升，充分证明两者对网络整体性能均有提升作用。

表 5.8　不同损失函数组合的比较实验

配置	λ_{MAE}	λ_{DM}	λ_{FFT}	PSNR
1	1	0.1	0	31.33
2	1	0	0.1	31.29
3	1	0.1	0.1	31.45

4. 模块顺序

本章研究了退化去除模块与内容重构模块在整体网络结构中的排列顺序对性能的影响。本章采用退化去除模块与内容重构模块串联且先退化去除的方式。同时进行了内容重构模块置于前或两模块并联的对比实验。如表 5.9所示，实验结果表明不同排列下最终性能差异较小。

表 5.9　退化去除和内容重构模块顺序

配置	模块顺序	PSNR
1	DRM → CRM	31.45
2	CRM → DRM	31.44
3	DRM ↔ CRM	31.47

5. 模块数目

本章探究了网络中退化去除与内容重构模块数量的影响。如表 5.10所示，将一个退化去除模块与一个内容重构模块组合称为一个 DC Block，默认设置为 6 个 DC Block。分别将 DC Block 数设置为 3、4、5 和 6 进行实验，结果表明增加模块数量能够有效提升性能。

6. 参数量对比

在表 5.11中，本章对比了多种方法在参数量、FLOPs、运行时间与性能上的表现，主要与 All-in-One、TransWeather、TKL&MR 以及 Tan 等人方法在

中国知网　https://www.cnki.net

表 5.10　模块数量

配置	DC Block 的数量	PSNR
1	3	30.20
2	4	30.47
3	5	31.34
4	6	31.45

SnowTest100k-L 测试集上的结果进行了比较。其中，FLOPs 在输入尺寸 3×128×128 的条件下测得，运行时间在相同输入尺寸下统计，使用单张 NVIDIA GeForce RTX 4090，并取 200 张测试样本的平均值作为参考结果。结果显示，本章方法在保持较低参数量的同时实现了更高的重建质量，在模型规模与性能之间取得了最优平衡。

表 5.11　模型参数与计算复杂度对比

方法	All-in-One	TransWeather	TKL&MR	Tan *et al.*	DDCNet
参数量 (M)	44.0	38.1	28.7	126	17.1
FLOPs (G)	-	1.11	4.89	-	39.73
Times (ms)	-	6.9	11.5	-	27
PSNR (dB)	28.33	27.80	29.27	28.54	30.67

5.3.5　局限性分析

在本章所提出的退化映射损失函数中，对于输出残差方向相同但是模长不同的情况如图 5.13所示，绿色的目标残差向量 $\boldsymbol{R}_{gt}$ 保持不变，同时绘制了三个与其起点相同输出残差 $\boldsymbol{R}_{out_i}$（i = 1,2,3），他们的方向一致但模长不同：$||\boldsymbol{R}_{out_1}|| < ||\boldsymbol{R}_{out_2}|| < ||\boldsymbol{R}_{out_3}||$。由于这三个向量的方向完全相同，因此它们与目标残差 $\boldsymbol{R}_{gt}$ 所形成的夹角 θ 也是恒定相等的。图中以切向的蓝色向量表示每个 $\boldsymbol{R}_{out}$ 所受到的修正方向与力度。此时，修正力度的大小由 $\boldsymbol{R}_{out}$ 的模长决定。根据该损失函数的反向传播公式，修正力度与输出残差的模长成反比。因此，模长最小的向量 $\boldsymbol{R}_{out_1}$ 会受到最强的约束，这在图中表现为其对应的蓝色修正向量最长。与此相反，模长最大的向量 $\boldsymbol{R}_{out_3}$ 则会受到最弱的约束，其对应的蓝色修正向量也最短。处于中间状态的 $\boldsymbol{R}_{out_2}$ 所受的修正力则介于两者之间。这暴露了该损失函数设计的内在缺陷，其修正力度仅仅由 $\boldsymbol{R}_{out}$ 的绝对模长决定，而缺乏与目标模长 $\boldsymbol{R}_{gt}$ 进行比较的相对视角。理想的未来解决方案是：在保留其方向性约束优势的同时，消除参数优化梯度对输出模长的依赖。一个可能的实现方式是对原损失函数进行调整，通过将原始的余弦相似度损失 $(1-\cos(\theta))$ 乘以输出残差的模长 $||\boldsymbol{R}_{out}||$，可以得到一个新的损失函数 $\mathcal{L}_{new} = ||\boldsymbol{R}_{out}|| \cdot (1-\cos(\theta))$。经过数学推导，这个新损失函数的梯度将变为：$\nabla\mathcal{L}_{new} = \hat{u}out - \hat{u}gt$，即两个单位向量的差。该梯度的模长为 $||\nabla\mathcal{L}_{new}|| = 2\sin(\theta/2)$，其大小只与夹角 θ 有关，该损失函数施加的修正力

中国知网　https://www.cnki.net

度仅取决于方向偏差的大小，完全消除了与 $||\boldsymbol{R}_{out}||$ 的依赖关系。

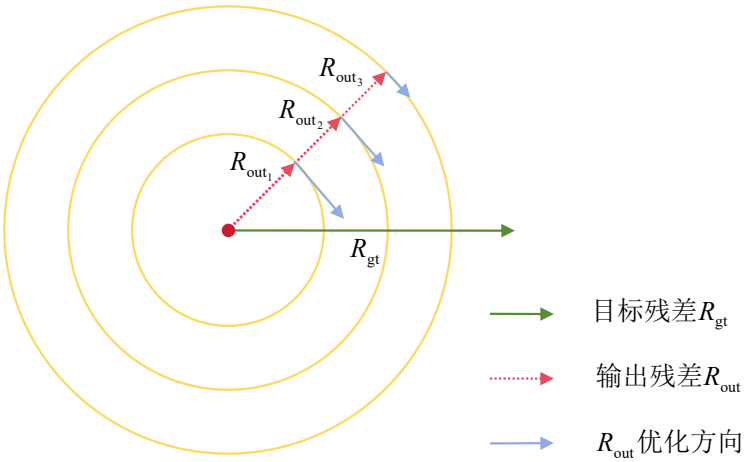


图 5.13　退化映射损失函数不足分析

5.4　本章小结

针对图像复原中差异性退化去除与一致性内容重构在特征层面耦合的问题，本章提出了一种融合框架设计与优化约束的表征解耦学习方法。在框架设计上，该方法利用特征通道的统计特性，将退化去除与内容重构显式划分为两个子模块。在优化约束上，将退化图像引入损失函数，构建方向约束型损失，以实现优化路径的解耦并有效缩减解空间。实验结果表明，该方法在多个图像复原基准数据集上均取得了优异的性能。本章工作的部分内容已发表在 TNNLS 2025。

中国知网　https://www.cnki.net

第 6 章　总结与展望

6.1　工作总结

近年来，随着数字成像设备的迅速发展与普及，数字图像已成为推动社会信息化与智能化的重要引擎。作为智能系统、安防监控、自动驾驶等应用的核心数据源，图像的质量与完整性直接影响下游任务的性能。然而，图像常受外部因素干扰而导致退化，出现内容损坏、细节丢失等问题，严重影响视觉观感与信息利用效果。这一问题的广泛存在促使图像复原成为学术界与工业界持续关注的重要研究方向。传统物理先验方法尝试以大气散射模型等物理规律刻画退化过程，但由于对场景与参数的理想化假设，难以应对复杂多变的退化情形。随着深度学习的发展，涌现出大量为特定退化类型设计的深度网络，并在复原效果上取得了显著提升，但此类为每种退化训练一个独立模型的做法冗余低效，且对现实场景中形态多样的退化缺乏足够的适应性。为回应上述挑战，基于自适应学习的图像复原方法近年来逐渐成为研究重点。通过构建单一架构以兼容多种退化类型，可简化模型部署难度、提升鲁棒性并提高应用效率。然而，现有自适应方法仍面临多重难题，包括退化差异性显著、复杂内容场景中的长程信息建模困难、退化去除与内容重构之间的特征耦合干扰，以及不同退化类型导致的优化方向差异。这些问题共同对图像复原模型构成挑战。针对上述问题，本文基于自适应表征学习方法，对退化多样性、内容复杂性、内容-退化耦合性提出相应研究方案。本文旨在提升模型对退化形式的感知与区分能力，强化多尺度依赖信息的协同建模，解耦退化去除与内容重构以降低特征干扰，并通过优化策略约束实现更高质量的图像复原。围绕上述目标，展开了如下研究工作：

1. 面向退化多样性的自适应退化表征学习方法

针对图像复原中退化类型多样且标签难以精确标注的问题，本文提出了一种基于无监督对比学习的自适应退化表征学习方法。该方法旨在挖掘退化图像中蕴含的退化信息，使网络能够自适应感知不同退化类型。具体而言，本文构建了退化表征编码器：将来自同一图像的图像块作为正样本，并在特征空间中约束其相互靠近，以学习该退化类型的内在特征；将来自不同图像的图像块作为负样本，并在特征空间中约束其相互远离，以辨别不同退化类型之间的边界。该方法仅通过退化图像即可构建训练样本，无需依赖显式退化标签即可学习到判别性退化表征。在此基础上，本文进一步提出退化表征引导的复原策略，通过将学习到的退化表征以信息无损的方式注入复原过程，实现对复原特征的自适应调制，从而使网络能够应对不同退化类型并进行有效复原。实验结果表明，该方法不仅在表征空间中实现了对不同退化类型的有效分离，而且在未见退化条件下仍保

中国知网　https://www.cnki.net

持良好的泛化能力，并进一步提升了图像复原的性能。

2. 面向内容复杂性的自适应内容表征学习方法

针对现有图像复原方法在全局信息感知方面的不足，本文提出了一种空频域协同的自适应内容表征学习方法，以提升模型对全局结构与局部细节的综合感知能力。具体而言，该方法在频域层面利用 Mamba 架构结合离散余弦变换，并对特征进行从低频到高频的排列方式建立序列间的因果性，同时通过跨尺寸一致性处理机制保证不同尺寸下的稳健表征，从而增强对全局结构的感知；在空域层面则利用卷积网络增强细节与纹理的表征能力。最后，通过动态加权融合，实现多尺度特征的自适应协同，从而提取更具表达力的内容表征。实验结果表明，该方法不仅在多项图像复原基准数据集上取得了优异的性能，还兼顾了细节恢复与全局结构的一致性。

3. 面向内容-退化耦合性的自适应解耦表征学习方法

针对图像复原中差异性退化去除与一致性内容重构在特征空间中耦合而导致的表征干扰问题，提出了一种基于双重约束的自适应解耦表征学习方法。该方法的核心思想在于，从框架设计与优化目标两个层面共同作用，以实现表征的自适应解耦。具体而言，在框架层面，基于对通道统计特性的分析，本文设计了模块化分离的解耦框架，将退化去除与内容重构显式划分为两个子模块：退化去除模块专注于抑制通道相关的退化因素，而内容重构模块则专注于恢复通道无关的内容，从而形成静态分离的约束。在优化层面，本文提出了退化映射损失函数，将退化图像作为先验引入损失函数，并通过对网络预测残差与优化目标残差之间的余弦相似度进行度量，以退化去除的差异化方向作为起点，逐步收敛到内容重构的一致性目标，从而在动态上为复原过程提供方向引导。通过静态分离与动态引导的双重约束，模型在减少表征耦合的同时，能够更好地兼顾退化去除的差异化需求与内容重构的一致性目标。实验结果表明，该方法在多个图像复原基准数据集上均取得了优异性能，验证了所提解耦表征学习策略的有效性。

6.2　研究展望

在本文的研究中，仍存在若干未解决的问题和局限性，总结如下：首先，当前的退化表征提取方法建立在同一图像内退化模式高度相似的假设之上，未能充分考虑现实场景中可能存在的局部退化差异，因而在面对极端复杂退化时表现有限，难以适应多变而开放的实际应用环境。其次，现有多尺度依赖建模主要依赖结构与频域信息的融合，尚未引入语义引导机制，从而限制了复杂语义场景下的理解能力。此外，虽然本文提出的三种主要方法分别针对不同挑战取得了一定成效，但尚未在同一框架中深入探讨它们之间的协同潜力，其整体融合效果仍

中国知网　https://www.cnki.net

有待进一步验证。再者，尽管复原结果在主客观指标上均有所提升，但与真实自然图像的细腻感和多样性仍存在差距，难以准确还原不同场景与丰富细节的真实感。最后，当前方法的参数规模较大，难以直接在资源受限的设备上部署，限制了其实际落地应用的可行性。因此，本文未来的研究工作拟从以下几个方面展开：

1. 通用图像复原模型

本文方法虽然能够通过单一模型覆盖多样退化（如同时处理雨、雾、雪，或适配不同强度的 JPEG 压缩），但在应对更复杂的退化情况或高度叠加的退化场景时仍显不足。这主要由于训练数据中缺乏复杂退化的配对样本，导致模型难以学习到对应的映射关系。针对这一挑战，后续研究可进一步探索完全无监督的图像复原方法，即仅依赖退化图像本身进行学习，不再依赖清晰图像作为监督信号。通过设计自约束机制或跨图像一致性建模，从退化图像分布中直接学习潜在的清晰结构规律。同时，可以探索将扩散模型[180-184]等生成技术融入复原过程，利用其在高维分布建模和细节生成方面的优势，为复原模型提供更强的生成先验和全局一致性保证。此外，未来研究还可在统一框架下系统探讨本文所提出的不同方法间的协同机制，以增强模型的整体适应性与泛化能力。这些探索有望突破当前复原模型在极端退化和复杂真实场景下的瓶颈，推动通用图像复原模型的进一步发展。

2. 感知驱动的图像复原评价指标

当前图像复原评价主要依赖 PSNR、SSIM 等传统像素级相似性指标，但这类指标往往难以衡量感知自然度和实际任务可用性，常出现指标虽高但视觉效果欠佳的情况。与此同时，这类参考型指标还依赖原始清晰图像作为基准，而在许多真实应用场景中往往缺乏可用的参考图像，导致难以直接计算 PSNR 等指标。为此，引入非参考质量评估（No-Reference IQA, NR-IQA）作为补充尤为重要，其可以在无参考的条件下获取与人类主观感知高度相关的质量评分，更贴近实际部署需求。未来的研究可以将感知质量建模与 NR-IQA 相结合，探索更加视觉友好的评价体系，以更好地评估复原结果的真实感与自然度；同时结合高层语义一致性评价，确保复原图像在全局语义和场景理解上的合理性。此外，还可以根据检测或识别等任务的性能反馈，构建与下游任务紧密结合的综合指标。这些方向的推进将有助于建立更全面、更合理的评价标准，为通用图像复原方法的优化和落地提供可靠支撑。

3. 高效可部署的图像复原模型

当前主流的图像复原模型在追求性能的同时，其庞大的网络规模与高昂的计算代价已成为在移动端和边缘设备上部署的关键瓶颈。为了缩小理论性能与实际应用之间的差距，未来的研究工作将更加侧重于模型的效率，并探索先进的

中国知网　https://www.cnki.net

轻量化框架设计，具体方法从以下几方面展开：一是借助模型剪枝、量化、知识蒸馏或结构重参数化等手段，在维持有竞争力的复原性能的同时，大幅减少模型的计算与存储开销。二是探索动态推理与自适应计算机制，使模型能够根据输入图像的退化程度或场景复杂度灵活分配计算资源，从而在保证效果的同时提升效率。三是考虑跨平台的高效部署，结合异构硬件（如 GPU、NPU、FPGA）的特性，优化模型的推理速度与能耗表现。通过这些方向的探索，有望实现真正可落地的高效复原模型，使图像复原技术能够更广泛地应用于移动端设备及智能监控等实际场景。

中国知网　https://www.cnki.net

参考文献

[1] SULTANI W, CHEN C, SHAH M. Real-world anomaly detection in surveillance videos [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 6479-6488.

[2] ZHONG J X, LI N, KONG W, et al. Graph convolutional label noise cleaner: Train a plug-and-play action classifier for anomaly detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 1237-1246.

[3] ZAHEER M Z, MAHMOOD A, ASTRID M, et al. Claws: Clustering assisted weakly supervised learning with normalcy suppression for anomalous event detection[C]//European Conference on Computer Vision. Springer, 2020: 358-376.

[4] WU P, LIU J, SHI Y, et al. Not only look, but also listen: Learning multimodal violence detection under weak supervision[C]//European Conference on Computer Vision. Springer, 2020: 322-339.

[5] RAMACHANDRA B, JONES M J, VATSAVAI R R. A survey of single-scene video anomaly detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(5): 2293-2312.

[6] HE S, LUO H, WANG P, et al. Transreid: Transformer-based object re-identification[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 14993-15002.

[7] EZZAT M A, ABD EL GHANY M A, ALMOTAIRI S, et al. Horizontal review on video surveillance for smart cities: Edge devices, applications, datasets, and future trends[J]. Sensors, 2021, 21(9): 3222.

[8] LUO W, XING J, MILAN A, et al. Multiple object tracking: A literature review[J]. Artificial Intelligence, 2021, 293: 103448.

[9] WANG Z, ZHENG L, LIU Y, et al. Towards real-time multi-object tracking[C]//European Conference on Computer Vision. Springer, 2020: 107-122.

[10] TANG Z, NAPHADE M, LIU M Y, et al. Cityflow: A city-scale benchmark for multi-target multi-camera vehicle tracking and re-identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 8789-8798.

[11] CHEN Y, JING L, VAHDANI E, et al. Multi-camera vehicle tracking and re-identification on ai city challenge 2019[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2019: 324-332.

[12] LIU H, RIVERA SOTO R A, XIAO F, et al. Yolactedge: Real-time instance segmentation on

中国知网 https://www.cnki.net

the edge[C]//Proceedings of the IEEE International Conference on Robotics and Automation. 2021: 9579-9585.

[13] ZHENG L, YANG Y, HAUPTMANN A G. Person re-identification: Past, present and future [A]. 2016.

[14] SUN Y, ZHENG L, YANG Y, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]//European Conference on Computer Vision. Springer, 2018: 480-496.

[15] YAO H, ZHANG S, ZHANG D, et al. Large-scale person re-identification as retrieval[C]// Proceedings of the IEEE International Conference on Multimedia and Expo. 2017: 1440-1445.

[16] YE M, SHEN J, LIN G, et al. Deep learning for person re-identification: A survey and outlook[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(6): 2872-2893.

[17] LENG Q, YE M, TIAN Q. A survey of open-world person re-identification[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2020, 30(4): 1092-1108.

[18] LI W, ZHAO R, XIAO T, et al. Deepreid: Deep filter pairing neural network for person re-identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2014: 152-159.

[19] XU H, CHEN J, MENG S, et al. A survey on occupancy perception for autonomous driving: The information fusion perspective[J]. Information Fusion, 2025, 114: 102671.

[20] XIANG C, FENG C, XIE X, et al. Multi-sensor fusion and cooperative perception for autonomous driving: A review[J]. IEEE Intelligent Transportation Systems Magazine, 2023, 15(5): 36-58.

[21] WANG X, LI K, CHEHRI A. Multi-sensor fusion technology for 3d object detection in autonomous driving: A review[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(2): 1148-1165.

[22] ZHOU P, HAN X, MORARIU V I, et al. Learning rich features for image manipulation detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 1053-1061.

[23] FRANK J, EISENHOFER T, SCHÖNHERR L, et al. Leveraging frequency analysis for deep fake image recognition[C]//Proceedings of the International Conference on Machine Learning. PMLR, 2020: 3247-3258.

[24] NARAYAN D, HIMANSHU, KAMAL R. Image forgery detection[C]//Proceedings of the International Conference on Disruptive Technologies. 2023: 549-552.

[25] KADHA V, BAKSHI S, DAS S K. Unravelling digital forgeries: A systematic survey on

中国知网 https://www.cnki.net

image manipulation detection and localization[J]. ACM Computing Surveys, 2025, 57(12): 1-36.

[26] MARRA F, GRAGNANIELLO D, COZZOLINO D, et al. Detection of gan-generated fake images over social networks[C]//Proceedings of the IEEE International Conference on Multimedia Information Processing and Retrieval. 2018: 384-389.

[27] YANG P, BARACCHI D, NI R, et al. A survey of deep learning-based source image forensics [J]. Journal of Imaging, 2020, 6(3): 9.

[28] VERDOLIVA L. Media forensics and deepfakes: An overview[J]. IEEE Journal of Selected Topics in Signal Processing, 2020, 14(5): 910-932.

[29] ZHOU L, ZHANG L, KONZ N. Computer vision techniques in manufacturing[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2023, 53(1): 105-117.

[30] 尹仕斌, 任永杰, 刘涛, 等. 机器视觉技术在现代汽车制造中的应用综述[J]. Acta Optica Sinica, 2018, 38(8): 0815001.

[31] NARASIMHAN S, NAYAR S. Chromatic framework for vision in bad weather[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition: Vol. 1. 2000: 598-605.

[32] NARASIMHAN S G, NAYAR S K. Vision and the atmosphere[J]. International Journal of Computer Vision, 2002, 48(3): 233-254.

[33] TAN R T. Visibility in bad weather from a single image[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2008: 1-8.

[34] CHEN L, WU P, CHITTA K, et al. End-to-end autonomous driving: Challenges and frontiers [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(12): 10164-10183.

[35] HU Y, YANG J, CHEN L, et al. Planning-oriented autonomous driving[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 17853-17862.

[36] ZHENG Z, CHENG Y, XIN Z, et al. Robust perception under adverse conditions for autonomous driving based on data augmentation[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(12): 13916-13929.

[37] YEONG D J, VELASCO-HERNANDEZ G, BARRY J, et al. Sensor and sensor fusion technology in autonomous vehicles: A review[J]. Sensors, 2021, 21(6): 2140.

[38] 王若萱, 吴建平, 徐辉. 自动驾驶汽车感知系统仿真的研究及应用综述[J]. 系统仿真学报, 2022, 34(12): 2507.

[39] 马忠贵, 李卓, 梁彦鹏. 自动驾驶车联网中通感算融合研究综述与展望[J]. 工程科学学报, 2023, 45(1): 137-149.

[40] SABERIRONAGHI A, REN J, EL-GINDY M. Defect detection methods for industrial prod-

中国知网 https://www.cnki.net

ucts using deep learning techniques: A review[J]. Algorithms, 2023, 16(2): 95.

[41] BERGMANN P, FAUSER M, SATTLEGGER D, et al. Mvtec ad—a comprehensive real-world dataset for unsupervised anomaly detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 9584-9592.

[42] RUDIN L I, OSHER S, FATEMI E. Nonlinear total variation based noise removal algorithms [J]. Physica D: Nonlinear Phenomena, 1992, 60(1-4): 259-268.

[43] BUADES A, COLL B, MOREL J M. A non-local algorithm for image denoising[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2005: 60-65.

[44] DABOV K, FOI A, KATKOVNIK V, et al. Image denoising by sparse 3-d transform-domain collaborative filtering[J]. IEEE Transactions on Image Processing, 2007, 16(8): 2080-2095.

[45] FOI A, KATKOVNIK V, EGIAZARIAN K. Pointwise shape-adaptive dct for high-quality denoising and deblocking of grayscale and color images[J]. IEEE Transactions on Image Processing, 2007, 16(5): 1395-1411.

[46] AHARON M, ELAD M, BRUCKSTEIN A. K-svd: An algorithm for designing overcomplete dictionaries for sparse representation[J]. IEEE Transactions on Signal Processing, 2006, 54 (11): 4311-4322.

[47] MAIRAL J, ELAD M, SAPIRO G. Sparse representation for color image restoration[J]. IEEE Transactions on Image Processing, 2008, 17(1): 53-69.

[48] MAIRAL J, BACH F, PONCE J, et al. Non-local sparse models for image restoration[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2009: 2272-2279.

[49] RAYLEIGH L. On the transmission of light through an atmosphere containing small particles in suspension, and on the origin of the blue of the sky[J]. The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science, 1899, 47(287): 375-384.

[50] MIE G. Beiträge zur Optik trüber Medien, speziell kolloidaler Metallösungen[J]. Annalen der Physik, 1908, 330(3): 377-445.

[51] KLASSEN R V. Modeling the effect of the atmosphere on light[J]. ACM Transactions on Graphics, 1987, 6(3): 215-237.

[52] NISHITA T, SIRAI T, TADAMURA K, et al. Display of the earth taking into account atmospheric scattering[C]//Proceedings of the Conference on Computer Graphics and Interactive Techniques. 1993: 175-182.

[53] 肖进胜, 王文, 邹文涛, 等. 基于景深和稀疏编码的图像去雨算法[J]. 计算机学报, 2019, 42(9): 2024-2034.

[54] 杨航, 吴笑天, 王宇庆, 等. 基于结构字典学习的图像复原方法[J]. 中国光学, 2017, 10

中国知网 https://www.cnki.net

(2): 207-218.

[55] 董慧颖, 方帅, 王欣威, 等. 基于物理模型的恶化天气下的图像复原方法及应用[J]. 东北大学学报 (自然科学版), 2005, 26(3): 217.

[56] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[C]//Advances in Neural Information Processing Systems: Vol. 25. 2012: 1097-1105.

[57] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[A]. 2014.

[58] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2015: 1-9.

[59] LIN M, CHEN Q, YAN S. Network in network[C]//International Conference on Learning Representations. 2014.

[60] HINTON G E, SRIVASTAVA N, KRIZHEVSKY A, et al. Improving neural networks by preventing co-adaptation of feature detectors[A]. 2012.

[61] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.

[62] GLOROT X, BENGIO Y. Understanding the difficulty of training deep feedforward neural networks[C]//Proceedings of the International Conference on Artificial Intelligence and Statistics. PMLR, 2010: 249-256.

[63] LI R, CHEONG L F, TAN R T. Heavy rain image restoration: Integrating physics model and conditional adversarial learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 1633-1642.

[64] LI B, PENG X, WANG Z, et al. Aod-net: All-in-one dehazing network[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2017: 4770-4778.

[65] GALTERI L, SEIDENARI L, BERTINI M, et al. Deep generative adversarial compression artifact removal[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2017: 4826-4835.

[66] ZHANG K, ZUO W, CHEN Y, et al. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising[J]. IEEE Transactions on Image Processing, 2017, 26(7): 3142-3155.

[67] ISOLA P, ZHU J Y, ZHOU T, et al. Image-to-image translation with conditional adversarial networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2017: 5967-5976.

[68] QIN X, WANG Z, BAI Y, et al. Ffa-net: Feature fusion attention network for single image

中国知网 https://www.cnki.net

dehazing[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020: 11908-11915.

[69] LIU Y F, JAW D W, HUANG S C, et al. Desnownet: Context-aware deep network for snow removal[J]. IEEE Transactions on Image Processing, 2018, 27(6): 3064-3073.

[70] XIA Z, CHAKRABARTI A. Identifying recurring patterns with deep neural networks for natural image denoising[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2020: 2426-2434.

[71] TIAN C, XU Y, ZUO W. Image denoising using deep cnn with batch renormalization[J]. Neural Networks, 2020, 121: 461-473.

[72] TAI Y, YANG J, LIU X, et al. Memnet: A persistent memory network for image restoration [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2017: 4539-4547.

[73] LIU P, ZHANG H, ZHANG K, et al. Multi-level wavelet-cnn for image restoration[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2018: 773-782.

[74] LI R, TAN R T, CHEONG L F. All in one bad weather removal using architectural search [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 3172-3182.

[75] JOSE VALANARASU J M, YASARLA R, PATEL V M. Transweather: Transformer-based restoration of images degraded by adverse weather conditions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 2343-2353.

[76] EHRLICH M, DAVIS L, LIM S N, et al. Quantization guided jpeg artifact correction[C]// European Conference on Computer Vision. Springer, 2020: 293-309.

[77] JIANG J, WANG K, CHEN S, et al. Towards flexible blind jpeg artifacts removal[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 4978-4987.

[78] QIAN R, TAN R T, YANG W, et al. Attentive generative adversarial network for raindrop removal from a single image[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 2482-2491.

[79] AGUSTSSON E, TIMOFTE R. Ntire 2017 challenge on single image super-resolution: Dataset and study[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2017: 1122-1131.

[80] TIMOFTE R, AGUSTSSON E, VAN GOOL L, et al. Ntire 2017 challenge on single image super-resolution: Methods and results[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2017: 1110-1121.

中国知网 https://www.cnki.net

[81] MA K, DUANMU Z, WU Q, et al. Waterloo exploration database: New challenges for image quality assessment models[J]. IEEE Transactions on Image Processing, 2017, 26(2): 1004-1016.

[82] SHEIKH H R, WANG Z, CORMACK L, et al. Live image quality assessment database release 2[EB/OL]. 2005. https://live.ece.utexas.edu/research/quality.

[83] ZEYDE R, ELAD M, PROTTER M. On single image scale-up using sparse-representations [C]//Proceedings of the International Conference on Curves and Surfaces. Springer, 2010: 711-730.

[84] LI B, REN W, FU D, et al. Benchmarking single-image dehazing and beyond[J]. IEEE Transactions on Image Processing, 2019, 28(1): 492-505.

[85] YANG W, TAN R T, FENG J, et al. Deep joint rain detection and removal from a single image [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2017: 1685-1694.

[86] ARBELáEZ P, MAIRE M, FOWLKES C, et al. Contour detection and hierarchical image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33 (5): 898-916.

[87] MARTIN D, FOWLKES C, TAL D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2001: 416-423.

[88] FU X, HUANG J, DING X, et al. Clearing the skies: A deep network architecture for single-image rain removal[J]. IEEE Transactions on Image Processing, 2017, 26(6): 2944-2956.

[89] REN D, ZUO W, HU Q, et al. Progressive image deraining networks: A better and simpler baseline[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 3932-3941.

[90] JIANG K, WANG Z, YI P, et al. Multi-scale progressive fusion network for single image deraining[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 8343-8352.

[91] ZHANG H, SINDAGI V, PATEL V M. Image de-raining using a conditional generative adversarial network[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2020(11): 3943-3956.

[92] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets [C]//Advances in Neural Information Processing Systems. 2014: 2672-2680.

[93] ZAMIR S W, ARORA A, KHAN S, et al. Multi-stage progressive image restoration[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 14821-14831.

中国知网 https://www.cnki.net

[94] ZHENG Y, YU X, LIU M, et al. Single-image deraining via recurrent residual multiscale networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(3): 1310-1323.

[95] FU X, QI Q, ZHA Z J, et al. Rain streak removal via dual graph convolutional network[C]// Proceedings of the AAAI Conference on Artificial Intelligence. 2021: 1352-1360.

[96] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017: 6000-6010.

[97] XIAO J, FU X, LIU A, et al. Image de-raining transformer[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(11): 12978-12995.

[98] CHEN X, LI H, LI M, et al. Learning a sparse transformer network for effective image deraining[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 5896-5906.

[99] CHEN X, PAN J, DONG J. Bidirectional multi-scale implicit neural representations for image deraining[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 25627-25636.

[100] REN W, LIU S, ZHANG H, et al. Single image dehazing via multi-scale convolutional neural networks[C]//European Conference on Computer Vision. Springer, 2016: 154-169.

[101] LIU X, MA Y, SHI Z, et al. Griddehazenet: Attention-based multi-scale network for image dehazing[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 7314-7323.

[102] SONG Y, HE Z, QIAN H, et al. Vision transformers for single image dehazing[J]. IEEE Transactions on Image Processing, 2023, 32: 1927-1941.

[103] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.

[104] QIU Y, ZHANG K, WANG C, et al. Mb-taylorformer: Multi-branch efficient transformer expanded by taylor formula for image dehazing[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 12756-12767.

[105] CHEN W T, FANG H Y, DING J J, et al. Jstasr: Joint size and transparency-aware snow removal algorithm based on modified partial convolution and veiling effect removal[C]// European Conference on Computer Vision. Springer, 2020: 754-770.

[106] CHEN S, YE T, LIU Y, et al. Snowformer: Context interaction transformer with scale-awareness for single image desnowing[C]//European Conference on Computer Vision. Springer, 2022: 567-584.

[107] CHEN W T, HUANG Z K, TSAI C C, et al. Learning multiple adverse weather removal via

中国知网 https://www.cnki.net

two-stage knowledge learning and multi-contrastive regularization: Toward a unified model [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 17632-17641.

[108] ÖZDENIZCI O, LEGENSTEIN R. Restoring vision in adverse weather conditions with patch-based denoising diffusion models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(8): 10346-10357.

[109] ZHU Y, WANG T, FU X, et al. Learning weather-general and weather-specific features for image restoration under multiple adverse weather conditions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 21747-21758.

[110] YE T, CHEN S, BAI J, et al. Adverse weather removal with codebook priors[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 12619-12630.

[111] TAN Z, WU Y, LIU Q, et al. Exploring the application of large-scale pre-trained models on adverse weather removal[J]. IEEE Transactions on Image Processing, 2024, 33: 1683-1698.

[112] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//Proceedings of the International Conference on Machine Learning. PMLR, 2021: 8748-8763.

[113] SUN S, REN W, GAO X, et al. Restoring images in adverse weather conditions via histogram transformer[C]//European Conference on Computer Vision. Springer, 2024: 111-129.

[114] WALLACE G K. The jpeg still picture compression standard[J]. IEEE Transactions on Consumer Electronics, 1992(1): xviii-xxxiv.

[115] GUO J, CHAO H. Building dual-domain representations for compression artifacts reduction [C]//European Conference on Computer Vision. Springer, 2016: 628-644.

[116] WANG Z, LIU D, CHANG S, et al. D3: Deep dual-domain based fast restoration of jpeg-compressed images[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2016: 2764-2772.

[117] CAVIGELLI L, HAGER P, BENINI L. Cas-cnn: A deep convolutional neural network for image compression artifact suppression[C]//Proceedings of the IEEE International Joint Conference on Neural Networks. 2017: 752-759.

[118] ZHANG Y, TIAN Y, KONG Y, et al. Residual dense network for image restoration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 43(7): 2480-2495.

[119] GUO J, CHAO H. One-to-many network for visually pleasing compression artifacts reduction [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2017: 3038-3047.

[120] YOO J, LEE S H, KWAK N. Image restoration by estimating frequency distribution of local patches[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern

中国知网 https://www.cnki.net

Recognition. 2018: 6684-6692.

[121] ZHAO H, GOU Y, LI B, et al. Comprehensive and delicate: An efficient transformer for image restoration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 14122-14132.

[122] FU X, ZHA Z J, WU F, et al. JPEG artifacts reduction via deep convolutional sparse coding [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2017: 576-584.

[123] FAN Q, CHEN D, YUAN L, et al. A general decoupled learning framework for parameterized image operators[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 43(1): 33-47.

[124] FU X, WANG X, LIU A, et al. Learning dual priors for jpeg compression artifacts removal [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 4086-4095.

[125] KIM Y, SOH J W, PARK J, et al. A pseudo-blind convolutional neural network for the reduction of compression artifacts[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2020, 30(4): 1121-1135.

[126] KIM Y, SOH J W, CHO N I. Agarnet: Adaptively gated jpeg compression artifacts removal network for a wide range quality factor[J]. IEEE Access, 2020, 8: 20160-20170.

[127] CHEN Y, POCK T. Trainable nonlinear reaction diffusion: A flexible framework for fast and effective image restoration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1256-1272.

[128] CHEN H, WANG Y, GUO T, et al. Pre-trained image processing transformer[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 12299-12310.

[129] LIANG J, CAO J, SUN G, et al. Swinir: Image restoration using swin transformer[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 1833-1844.

[130] FAN Q, CHEN D, YUAN L, et al. A general decoupled learning framework for parameterized image operators[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 43(1): 33-47.

[131] ZHANG J, HUANG J, YAO M, et al. Ingredient-oriented multi-degradation learning for image restoration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 5825-5835.

[132] MA J, CHENG T, WANG G, et al. Prores: Exploring degradation-aware visual prompt for universal image restoration[A]. 2023.

中国知网 https://www.cnki.net

[133] POTLAPALLI V, ZAMIR S W, KHAN S H, et al. Promptir: Prompting for all-in-one image restoration[C]//Advances in Neural Information Processing Systems: Vol. 36. 2023: 71275-71293.

[134] YAO M, XU R, GUAN Y, et al. Neural degradation representation learning for all-in-one image restoration[J]. IEEE Transactions on Image Processing, 2024, 33: 5408-5423.

[135] WANG T, ZHANG K, SHAO Z, et al. Gridformer: Residual dense transformer with grid structure for image restoration in adverse weather conditions[J]. International Journal of Computer Vision, 2024, 132(10): 4541-4563.

[136] WANG Z, BOVIK A, SHEIKH H, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.

[137] TADALA T, NARAYANA S E V. A novel psnr-b approach for evaluating the quality of de-blocked images[J]. IOSR Journal of Computer Engineering, 2012, 4(5): 40-49.

[138] WU Z, XIONG Y, YU S X, et al. Unsupervised feature learning via non-parametric instance discrimination[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 3733-3742.

[139] ZHUANG C, ZHAI A L, YAMINS D. Local aggregation for unsupervised learning of visual embeddings[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 6002-6012.

[140] VAN DEN OORD A, LI Y, VINYALS O. Representation learning with contrastive predictive coding[A]. 2018.

[141] HJELM R D, FEDOROV A, LAVOIE-MARCHILDON S, et al. Learning deep representations by mutual information estimation and maximization[A]. 2018.

[142] HENAFF O. Data-efficient image recognition with contrastive predictive coding[C]// Proceedings of the International Conference on Machine Learning. PMLR, 2020: 4182-4192.

[143] BACHMAN P, HJELM R D, BUCHWALTER W. Learning representations by maximizing mutual information across views[C]//Advances in Neural Information Processing Systems. 2019: 153-164.

[144] CHEN T, KORNBLITH S, NOROUZI M, et al. A simple framework for contrastive learning of visual representations[C]//Proceedings of the International Conference on Machine Learning. PMLR, 2020: 1597-1607.

[145] CHEN X, FAN H, GIRSHICK R, et al. Improved baselines with momentum contrastive learning[A]. 2020.

[146] DOSOVITSKIY A, SPRINGENBERG J T, RIEDMILLER M, et al. Discriminative unsupervised feature learning with convolutional neural networks[C]//Advances in Neural Information Processing Systems. 2014: 766-774.

中国知网 https://www.cnki.net

[147] HE K, FAN H, WU Y, et al. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 9729-9738.

[148] DINH L, KRUEGER D, BENGIO Y. Nice: Non-linear independent components estimation [A]. 2014.

[149] DINH L, SOHL-DICKSTEIN J, BENGIO S. Density estimation using real nvp[A]. 2016.

[150] MAAS A L, HANNUN A Y, NG A Y, et al. Rectifier nonlinearities improve neural network acoustic models[C]//Proceedings of the International Conference on Machine Learning: Vol. 30. 2013: 3.

[151] ZHANG Y, LI K, LI K, et al. Residual non-local attention networks for image restoration[A]. 2019.

[152] QUAN R, YU X, LIANG Y, et al. Removing raindrops and rain streaks in one go[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 9143-9152.

[153] DENG S, WEI M, WANG J, et al. Detail-recovery image deraining via context aggregation networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 14548-14557.

[154] ZHANG K, LI R, YU Y, et al. Deep dense multi-scale network for snow removal using semantic and depth priors[J]. IEEE Transactions on Image Processing, 2021, 30: 7419-7431.

[155] GAO H, TAO X, SHEN X, et al. Dynamic scene deblurring with parameter selective sharing and nested skip connections[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 3843-3851.

[156] SHEN H, ZHAO Z Q, ZHANG W. Adaptive dynamic filtering network for image denoising [C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 37. 2023: 2227-2235.

[157] KINGMA D P, BA J. Adam: A method for stochastic optimization[A]. 2014.

[158] GARG K, NAYAR S K. Vision and rain[J/OL]. International Journal of Computer Vision, 2007, 75(1): 3-27. DOI: 10.1007/s11263-006-0028-6.

[159] FU X, HUANG J, ZENG D, et al. Removing rain from single images via a deep detail network [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2017: 1715-1723.

[160] HE K, SUN J, TANG X. Single image haze removal using dark channel prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 33(12): 2341-2353.

[161] VAN DER MAATEN L, HINTON G. Visualizing data using t-sne[J]. Journal of Machine Learning Research, 2008, 9(11): 2579-2605.

中国知网 https://www.cnki.net

[162] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-cam: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2017: 618-626.

[163] YU F, KOLTUN V. Multi-scale context aggregation by dilated convolutions[C]//International Conference on Learning Representations. 2016.

[164] GU A, DAO T. Mamba: Linear-time sequence modeling with selective state spaces[A]. 2023.

[165] ZHU L, LIAO B, ZHANG Q, et al. Vision mamba: Efficient visual representation learning with bidirectional state space model[C]//Proceedings of the International Conference on Machine Learning. PMLR, 2024.

[166] LIU Y, TIAN Y, ZHAO Y, et al. Vmamba: Visual state space model[C]//Advances in Neural Information Processing Systems. 2024.

[167] GU A, GOEL K, RÉ C. Efficiently modeling long sequences with structured state spaces[A]. 2021.

[168] GU A, GOEL K, GUPTA A, et al. On the parameterization and initialization of diagonal state space models[C]//Advances in Neural Information Processing Systems. 2022: 35971-35983.

[169] SMITH J T, WARRINGTON A, LINDERMAN S W. Simplified state space layers for sequence modeling[A]. 2022.

[170] MEHTA H, GUPTA A, CUTKOSKY A, et al. Long range language modeling via gated state spaces[A]. 2022.

[171] WILLEMS J C. From time series to linear system—part i. finite dimensional linear time invariant systems[J]. Automatica, 1986(5): 561-580.

[172] CHOLLET F. Xception: Deep learning with depthwise separable convolutions[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2017: 1251-1258.

[173] BA J L, KIROS J R, HINTON G E. Layer normalization[A]. 2016.

[174] ELFWING S, UCHIBE E, DOYA K. Sigmoid-weighted linear units for neural network function approximation in reinforcement learning[J]. Neural Networks, 2018, 107: 3-11.

[175] CHARBONNIER P, BLANC-FéRAUD L, AUBERT G, et al. Two deterministic half-quadratic regularization algorithms for computed imaging[C]//Proceedings of the IEEE International Conference on Image Processing. 1994: 168-172.

[176] LI B, WU F, WEINBERGER K Q, et al. Positional normalization[C]//Advances in Neural Information Processing Systems. 2019: 1620-1632.

[177] HUANG J, LIU Y, ZHAO F, et al. Deep fourier-based exposure correction network with spatial-frequency interaction[C]//European Conference on Computer Vision. Springer, 2022: 163-180.

中国知网 https://www.cnki.net

[178] CANNY J. A computational approach to edge detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1986(6): 679-698.

[179] JOHNSON J, ALAHI A, FEI-FEI L. Perceptual losses for real-time style transfer and super-resolution[C]//European Conference on Computer Vision. Springer, 2016: 694-711.

[180] SOHL-DICKSTEIN J, WEISS E A, MAHESWARANATHAN N, et al. Deep unsupervised learning using nonequilibrium thermodynamics[C]//Proceedings of the International Conference on Machine Learning. PMLR, 2015: 2256-2265.

[181] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[C]//Advances in Neural Information Processing Systems. 2020: 6840-6851.

[182] SONG Y, SOHL-DICKSTEIN J, KINGMA D P, et al. Score-based generative modeling through stochastic differential equations[C]//International Conference on Learning Representations. 2021.

[183] NICHOL A, DHARIWAL P. Improved denoising diffusion probabilistic models[C]// Proceedings of the International Conference on Machine Learning. PMLR, 2021: 8162-8171.

[184] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10684-10695.

中国知网 https://www.cnki.net