单位代码：10359　　密　级：公开
学　　号：2020111064　　分类号：TP18

合肥工業大學

Hefei University of Technology

博士学位论文

DOCTORAL DISSERTATION

论文题目：面向复杂场景的无监督图像去模糊方法研究

学科专业：计算机科学与技术

作者姓名：赵 随 意

导师姓名：张召 教授

完成时间：2025 年 4 月

中国知网 https://www.cnki.net

单位代码：10359　　密　级：公开
学　　号：2020111064　　分类号：TP18

博 士 学 位 论 文

面向复杂场景的无监督图像去模糊方法研究

Research on Unsupervised Image Deblurring Methods for Complex Scenarios

作者姓名：赵 随 意　　导师姓名：张召 教授
申请学位：工学博士　　培养单位：合肥工业大学
学科专业：计算机科学与技术　　研究方向：数据挖掘与智能计算
提交日期：2025 年 4 月　　答辩日期：2025 年 5 月

答辩委员会主席：张海军　教授

评　　阅　　人：匿名　匿名　匿名　匿名　匿名

2025 年 4 月

中国知网　https://www.cnki.net

合　肥　工　业　大　学

博士学位论文

面向复杂场景的无监督图像去模糊方法研究

作者姓名：赵 随 意

申请学位：工学博士

研究方向：数据挖掘与智能计算

学科专业：计算机科学与技术

指导教师：张召 教授

2025 年 4 月

中国知网　https://www.cnki.net

A Dissertation Submitted to

Hefei University of Technology

in accordmance with the requirement

for the Degree of Doctor of Philosophy

Research on Unsupervised Image Deblurring Methods for Complex Scenarios

By

Suiyi Zhao

Hefei University of Technology

Hefei, Anhui, P.R.China

April, 2025

中国知网 https://www.cnki.net

同行评议专家名单

贾　伟	合肥工业大学	教授、博导
齐美彬	合肥工业大学	教授、博导
赵仲秋	合肥工业大学	教授、博导

同行评议专家名单

匿名	教授、博导
匿名	教授、博导
匿名	教授、博导

答辩委员会名单

主席：	张海军	哈尔滨工业大学	教授、博导
委员：	赵鸣博	东华大学	教授、博导
	贾　伟	合肥工业大学	教授、博导
	赵仲秋	合肥工业大学	教授、博导
	赵　洋	合肥工业大学	教授、博导

中国知网　https://www.cnki.net

摘　要

图像模糊作为一种普遍存在的视觉退化现象，不仅显著降低图像质量，更严重阻碍了视觉信息的有效提取与分析。图像去模糊技术旨在消除此类干扰，提升图像清晰度与可用性，对自动驾驶、视频监控及医学影像分析等领域具有重要应用价值。深度全监督方法凭借对大规模配对数据的学习能力，性能显著超越传统方法，但高质量配对数据获取困难且合成数据训练的模型在复杂场景下泛化性受限。相比之下，无监督去模糊方法无需配对数据，理论上具备更强适应性和应用潜力，但仍面临诸多挑战：（1）现有方法在追求清晰度的同时忽略了色彩保持，导致复原结果出现明显色差。更为关键的是，目前尚缺乏量化色差的评估指标，使得这一问题难以系统性解决；（2）现有方法通常依赖规模庞大的复杂网络来学习模糊域到清晰域的弱映射关系，计算开销过大、推理效率低，严重制约了其在资源受限场景中的实际应用；（3）模糊和低光照在真实环境中频繁共存，导致复合退化现象，现有方法在处理此类复合退化问题时效果欠佳，应用范围受限。

针对上述挑战，本文提出了一系列无监督图像去模糊方法，旨在增强无监督去模糊技术在各类复杂场景下的综合实用性。主要研究内容总结如下：

（1）针对无监督去模糊过程中的色彩失真问题，本文提出了一种新型色彩保持方法。该方法区别于一般的模糊到清晰映射范式，创新性地引入了模糊偏移估计和自适应校正机制，将去模糊任务转化为估计模糊偏移并对原始图像进行渐进式校正的过程。这种设计有效避免了端到端训练中常见的色彩崩溃问题，最大限度地保持了原始图像的色彩信息。此外，为解决色差评估指标缺乏的问题，本文提出了一种基于 HSV 色彩空间直方图峰值分析的新型指标。该指标通过综合考量峰面积、位置偏移及各颜色分量权重，可客观量化去模糊结果的色彩保真度，为无监督图像去模糊领域提供了更符合人类视觉感知的评估标准。

（2）针对现有无监督去模糊方法计算复杂度高、资源消耗大的问题，本文提出了一种基于频域对比损失约束的轻量级方法。该方法通过精心设计的轻量级域转换单元和无参频域对比单元，构建了一个参数量较少、具备实时推理速度的高效无监督去模糊模型。轻量级域转换单元在极大减少参数量的同时保持了模型的表达能力；无参频域对比单元则使复原结果在频域特征上逼近清晰图像，无需额外参数即可有效约束模型学习，提升复原质量。该方法不受一般无监督去模糊方法对图像分辨率和特定领域的限制，具备对各类模糊图像的优异泛化能力，能够适应多种场景和不同分辨率的图像处理需求，提升了无监督去模糊技术在资源受限环境下的应用潜力。

（3）针对现实场景中模糊与低光照频繁共存的问题，本文提出了一种可处理

中国知网　https://www.cnki.net

模糊和低光照复合退化的无监督方法。该方法基于噪声自回归机制，通过创新的双分支架构设计，实现了单一模型同时具备图像去模糊、低光照增强及复合退化处理的能力。该架构包含转换分支和回归分支：转换分支负责学习域间映射关系，完成退化图像到清晰图像的转换；回归分支则通过噪声自回归机制增强模型对低光照退化的理解和处理能力，同时有效抑制低光照环境中的噪声。该方法仅需非配对的模糊-清晰数据进行无监督训练，无需专门的低光照-正常光照配对数据或复合退化样本，便可完成模糊与低光照的复合退化处理。这一特性巧妙规避了一般方法对特定复合退化样本的依赖，显著降低了数据获取和训练成本，拓展了无监督图像去模糊技术的实际应用范围。

关键词：图像去模糊；无监督训练；色彩保持；轻量化设计；复合退化处理

中国知网 https://www.cnki.net

ABSTRACT

Image blur is a common visual degradation phenomenon that not only significantly reduces image quality but also severely hinders effective extraction and analysis of visual information. Image deblurring aims to eliminate such interference, enhancing image clarity and usability, with important applications in fields such as autonomous driving, video surveillance, and medical image analysis. Deep supervised methods have significantly outperformed traditional approaches by learning from large-scale paired data, but face challenges in acquiring high-quality paired data while models trained on synthetic data suffer from limited generalization in complex scenarios. In contrast, unsupervised deblurring methods require no paired data and theoretically possess stronger adaptability and application potential, yet still face several challenges: (1) Existing methods often neglect color retention while pursuing sharpness, resulting in obvious color distortion. More critically, there is currently a lack of evaluation metrics to quantify color distortion, making this problem difficult to systematically resolve; (2) Existing methods typically rely on large-scale complex networks to learn weak mappings between blurred and sharp domains, resulting in excessive computational overhead and low inference efficiency, severely limiting their practical application in resource-constrained scenarios; (3) Blur and low-light frequently coexist in real environments, leading to compound degradation phenomenon, and existing methods show unsatisfactory performance when dealing with such compound degradation, resulting in limited application scope.

To address these challenges, this dissertation proposes a series of unsupervised image deblurring methods aimed at enhancing the comprehensive practicality of unsupervised deblurring techniques in various complex scenarios. The main research contents are summarized as follows:

(1) To address the color distortion problem in the unsupervised deblurring process, a novel color retention method is proposed. Unlike general blurred-to-sharp mapping paradigms, this method innovatively introduces blur offset estimation and an adaptive correction mechanism, transforming the deblurring task into a process of estimating the blur offset and gradually correcting the original image. This design effectively avoids the common color collapse issues in end-to-end training and maximally preserves the color information of the original image. Additionally, to address the lack of color distortion evaluation metrics, a novel metric based on HSV color space histogram peak analysis is proposed. This metric comprehensively considers factors such as peak area, positional offset, and the weight of each color components to objectively quantify the color fidelity

中国知网 https://www.cnki.net

of the deblurred results, offering an evaluation standard more in line with human visual perception for the field of unsupervised image deblurring.

(2) To address the high computational complexity and resource consumption issues in existing unsupervised deblurring methods, a lightweight method based on frequency domain contrastive loss constraints is proposed. This method builds an efficient unsupervised deblurring model with relatively few parameters and real-time inference speed through a carefully designed lightweight domain conversion unit and a parameter-free frequency-domain contrastive unit. The lightweight domain conversion unit greatly reduces the number of parameters while maintaining the expressive capacity of the model; the parameter-free frequency-domain contrastive unit forces the recovered result to approximate the sharp image in terms of frequency characteristics without requiring additional parameters, effectively improving deblurring quality. This method is not restricted by image resolution or specific domains, and exhibits excellent generalization ability for various types of blurred images, meeting the processing requirements for multi-scenario and multi-resolution images and enhancing the applicability of unsupervised deblurring technology in resource-constrained environments.

(3) To address the common co-occurrence of blur and low-light conditions in real-world scenarios, an unsupervised method capable of handling compound degradation of blur and low-light is proposed. Based on noise self-regression mechanism, this method employs an innovative dual-branch architecture that enables a single model to simultaneously perform image deblurring, low-light enhancement, and compound degradation processing. The architecture comprises a transformation branch and a regression branch: the transformation branch learns domain-to-domain mapping relationships, converting degraded images to sharp images; the regression branch enhances the model's understanding and handling of low-light degradation through a noise self-regression mechanism, while effectively suppressing noise in low-light environments. This method requires only unpaired blurred-sharp data for unsupervised training, without requiring specialized "low-light"-"normal light" paired data or compound degradation samples, enabling it to handle combined blur and low-light degradation. This characteristic cleverly avoids the dependence of general methods on specific compound degradation samples, significantly reducing data acquisition and training costs, and expanding the practical application range of unsupervised image deblurring technology.

KEYWORDS: Image Deblurring; Unsupervised Training; Color Retention; Lightweight Design; Compound Degradation Processing

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景与意义.....1
1.2 研究目的与挑战.....3
1.3 本文的研究内容.....4
1.4 本文的组织结构.....6
第二章 图像去模糊研究现状.....8
2.1 模糊的形成过程.....8
2.2 传统图像去模糊.....9
2.2.1 非盲图像去模糊.....9
2.2.2 盲图像去模糊.....13
2.3 基于深度学习的图像去模糊.....16
2.3.1 基于 CNN 的全监督方法.....16
2.3.2 基于其他架构的全监督方法.....19
2.3.3 自监督和无监督方法.....22
2.4 图像去模糊数据集.....24
2.4.1 合成模糊数据集.....24
2.4.2 真实模糊数据集.....25
2.5 图像去模糊评价指标.....25
2.5.1 客观评价指标.....25
2.5.2 主观评价指标.....27
2.6 本章小结.....27
第三章 基于模糊偏移估计的无监督图像去模糊方法.....28
3.1 本章概述.....28
3.2 相关工作和理论基础.....30
3.2.1 生成对抗网络基本原理.....30
3.2.2 基于 GAN 的全监督方法.....31
3.2.3 基于 GAN 的无监督方法.....31
3.3 方法介绍.....32
3.3.1 网络架构.....32
3.3.2 模糊偏移估计网络.....33
3.3.3 自适应模糊矫正机制.....35
3.3.4 损失函数.....37
3.3.5 色差定量评估指标设计.....37
3.4 实验分析.....44

中国知网 https://www.cnki.net

3.4.1 实验设置.....45
3.4.2 实验结果及分析.....46
3.4.3 消融实验及分析.....49
3.5 本章小结.....49
第四章 基于轻量级域转换的无监督图像去模糊方法.....50
4.1 本章概述.....50
4.2 相关工作和理论基础.....52
4.2.1 去模糊网络的模块与结构设计.....52
4.2.2 基于频域信息的去模糊方法.....53
4.2.3 对比学习机制.....53
4.3 方法介绍.....54
4.3.1 网络架构.....54
4.3.2 轻量级域转换单元.....55
4.3.3 无参频域对比单元.....59
4.3.4 损失函数.....61
4.4 实验分析.....61
4.4.1 实验设置.....61
4.4.2 实验结果及分析.....63
4.4.3 消融实验及分析.....65
4.5 本章小结.....66
第五章 基于噪声自回归的无监督低光照图像去模糊方法.....67
5.1 本章概述.....67
5.2 相关工作和理论基础.....69
5.2.1 零参考的低光照增强方法.....69
5.2.2 全监督的复合退化处理方法.....69
5.2.3 噪声自回归技术.....70
5.3 方法介绍.....71
5.3.1 网络架构.....71
5.3.2 转换分支.....72
5.3.3 回归分支.....74
5.3.4 损失函数.....75
5.3.5 性能权衡.....75
5.4 实验分析.....76
5.4.1 实验设置.....76
5.4.2 实验结果及分析.....78
5.4.3 消融实验及分析.....80
5.5 本章小结.....82
第六章 总结与展望.....83

中国知网 https://www.cnki.net

6.1 本文工作总结.....83
6.2 未来工作展望.....84
参考文献.....85

中国知网 https://www.cnki.net

插图清单

图 1.1 不同种类的模糊图像示例 · · · · · 1
图 1.2 图像去模糊应用领域示意图 · · · · · 2
图 1.3 本文研究内容的整体框架图 · · · · · 5

图 2.1 代表性的图像去模糊方法分类 · · · · · 8
图 2.2 线性时不变系统示意图 · · · · · 9
图 2.3 传统图像去模糊的发展历程 · · · · · 9
图 2.4 反卷积求解时出现的振铃效应 · · · · · 10
图 2.5 维纳滤波和 TV 正则化的噪声抑制效果对比 · · · · · 11
图 2.6 经典的盲图像去模糊算法框架 · · · · · 13
图 2.7 基于深度学习的图像去模糊的发展历程 · · · · · 16
图 2.8 端到端方法和经典多尺度方法流程对比 · · · · · 17

图 3.1 无监督去模糊方法色彩保持能力对比 · · · · · 29
图 3.2 CRNet 模型结构示意图 · · · · · 32
图 3.3 模糊偏移估计网络结构示意图 · · · · · 34
图 3.4 模糊偏移产生过程渐变图 · · · · · 35
图 3.5 自适应模糊矫正原理示意图 · · · · · 37
图 3.6 HSV 空间中的颜色直方图示例 · · · · · 39
图 3.7 颜色直方图离散积分计算过程示意图 · · · · · 40
图 3.8 峰对齐过程示意图 · · · · · 42
图 3.9 色敏差指标异常情况示例 · · · · · 44
图 3.10 模糊图和清晰图的颜色直方图对比 · · · · · 44
图 3.11 在 GoPro 数据集上的可视化结果对比 · · · · · 45
图 3.12 在 CelebA 数据集上的可视化结果对比 · · · · · 47
图 3.13 在 CelebA 数据集上的局部细节效果对比 · · · · · 48

图 4.1 无监督去模糊方法综合性能对比 · · · · · 51
图 4.2 FCL-GAN 模型结构示意图 · · · · · 54
图 4.3 CycleGAN 在去模糊任务中的固有缺陷 · · · · · 56
图 4.4 基本元和残差元的不同组成形式对比 · · · · · 57
图 4.5 深度模型的不同结构对比 · · · · · 58
图 4.6 不同结构的参数量和计算量对比 · · · · · 58
图 4.7 不同程度的模糊和清晰图像在频域中的视觉效果 · · · · · 59

中国知网 https://www.cnki.net

图 4.8 不同相似度度量方式的对比 · · · · · 60
图 4.9 在 GoPro 数据集上的可视化结果对比 · · · · · 62
图 4.10 在 CelebA 数据集上的可视化结果对比 · · · · · 63
图 4.11 在 RealBlur-J 数据集上的可视化结果对比 · · · · · 64

图 5.1 不同多样化退化处理策略的对比 · · · · · 68
图 5.2 噪声自回归技术原理示意图 · · · · · 70
图 5.3 在不同退化上的处理结果对比 · · · · · 72
图 5.4 DEvUDP 模型结构示意图 · · · · · 72
图 5.5 有无 S 分支的模型处理结果对比 · · · · · 74
图 5.6 生成器的不同结构对比 · · · · · 75
图 5.7 在 GoPro 数据集上的去模糊结果可视化对比 · · · · · 77
图 5.8 在 LOL 数据集上的低光照增强结果可视化对比 · · · · · 78
图 5.9 在 LOL-Blur 数据集上的复合退化处理结果可视化对比 · · · · · 79
图 5.10 在多个任务上关于下采样的可视化消融实验结果 · · · · · 80

中国知网 https://www.cnki.net

表格清单

表 2.1 去模糊数据集属性对比 · 24

表 3.1 本章节的符号表 · 38
表 3.2 在 GoPro 数据集上的定量结果对比 · 46
表 3.3 在 CelebA 数据集上的定量结果对比 · 47
表 3.4 在 GoPro 数据集上的消融实验结果 · 49

表 4.1 在 GoPro 和 HIDE 数据集上的定量结果对比 · · · · · · · · · · · · · · · · 62
表 4.2 在 GoPro 数据集上关于推理时间和模型大小的对比 · · · · · · · · · · · · 62
表 4.3 在 CelebA 数据集上的定量结果对比 · 63
表 4.4 在 RealBlur 数据集上的定量结果对比 · 64
表 4.5 在 GoPro 和 CelebA 数据集上关于损失函数的消融实验结果 · · · · · · · 65
表 4.6 在 GoPro 数据集上关于元组合的消融实验结果 · · · · · · · · · · · · · · · 65
表 4.7 在 GoPro 数据集上关于不同结构的消融实验结果 · · · · · · · · · · · · · 65

表 5.1 在 GoPro 数据集上的去模糊结果定量对比 · · · · · · · · · · · · · · · · · 76
表 5.2 在 RealBlur-J 数据集上的去模糊结果定量对比 · · · · · · · · · · · · · · · 76
表 5.3 在 LOL 数据集上的低光照增强结果定量对比 · · · · · · · · · · · · · · · · 77
表 5.4 在 LOL-Blur 数据集上的复合退化处理结果定量对比 · · · · · · · · · · · · 78
表 5.5 在多个任务上的定量消融实验结果 · 80
表 5.6 在多个任务上关于 G^{-1} 的定量消融实验结果 · · · · · · · · · · · · · · · · 80
表 5.7 在多个任务上的超参分析定量结果 · 81

中国知网 https://www.cnki.net

主要缩略语对照表

缩略语	英文对照	中文对照
CV	Computer Vision	计算机视觉
DL	Deep Learning	深度学习
PSF	Point Spread Function	点扩散函数
NBID	Non-blind Image Deblurring	非盲图像去模糊
BID	Blind Image Deblurring	盲图像去模糊
MAP	Maximum A Posteriori	最大后验概率估计
WF	Wiener Filter	维纳滤波
TV	Total Variation	全变分正则化
WT	Wavelet Transform	小波变换
CNN	Convolutional Neural Networks	卷积神经网络
GAN	Generative Adversarial Networks	生成对抗网络
RNN	Recurrent Neural Networks	循环神经网络
SSM	State Space Model	状态空间模型
PSNR	Peak Signal-to-Noise Ratio	峰值信噪比
MSE	Mean Squared Error	均方误差
SSIM	Structural Similarity	结构相似性
LPIPS	Learned Perceptual Image Patch Similarity	感知图像块相似性
NIQE	Natural Image Quality Evaluator	自然图像质量评估器
NSS	Natural Scene Statistics	自然场景统计
MOS	Mean Opinion Score	平均意见得分
CSE	Color-Sensitive Error	色敏差
GT	Ground Truth	真值
BN	Batch Normalization	批归一化
IN	Instance Normalization	实例归一化
FFT	Fast Fourier Transform	快速傅里叶变换
IFFT	Inverse Fast Fourier Transform	快速傅里叶逆变换

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景与意义

随着数字图像技术的快速发展，图像已成为信息获取、生活记录以及思想交流的重要媒介。然而，在图像获取过程中，由于相机抖动、物体运动、对焦异常等多种因素，图像模糊问题普遍存在，严重影响了视觉质量。根据模糊形成原因的不同，图像模糊在现实生活中呈现多样化形式，如运动模糊①、散焦模糊、高斯模糊等，如图1.1所示。这些模糊现象不仅降低了图像的视觉美感，更严重地损害了图像中的关键信息，也给图像识别[1]、目标检测[2]、语义分割[3]、姿态估计[4] 等高级视觉任务带来了巨大挑战。



图 1.1 不同种类的模糊图像示例

Fig. 1.1 Examples of different types of blurred images

为应对上述问题，图像去模糊技术应运而生。该技术旨在从模糊图像中重建或恢复清晰的视觉内容，进而提升图像的整体质量、增强图像的视觉效果，是计算机视觉（Computer Vision, CV）和图像处理领域的重要研究课题之一。我国《新一代人工智能发展规划》[5] 明确强调了“复杂动态场景感知与理解”的战略重要性，其中图像去模糊作为关键任务受到广泛关注。在此背景下，“复杂场景”通常指包含多因素耦合、动态变化及退化机制未知的真实世界图像采集环境。具体而言，其涵盖但不限于以下特征：（1）多退化耦合性：模糊成因不局限于单一运动轨迹或

①运动模糊是最为普遍且难以避免的一种类型，它发生在成像设备的曝光期间，由于被摄物体和成像设备之间的相对运动，导致光线在感光元件上形成拖尾效应，使图像细节轮廓变得模糊不清。如无特殊说明，下文中的模糊均为运动模糊。

中国知网 https://www.cnki.net

散焦过程，而是与噪声、低光照、大气扰动等多种退化因素相互叠加；（2）动态不可预测性：被摄物体与成像设备存在非匀速相对运动，导致模糊核在空间域呈现非均匀分布特性；（3）场景异构性：既包含城市道路中高速运动的车辆与行人，也涉及自然场景下随风摆动的植被等多样化对象。这类复杂场景下的图像退化过程具有高度非线性与病态性，使得传统基于去模糊方法难以有效处理。因此，研究面向复杂场景的去模糊方法，不仅具有重要的理论价值，也在实际应用中展现出深远影响。如图1.2所示，该技术技术在消费电子、视频监控、自动驾驶、医学影像分析、文物保护等多个领域均有广阔应用前景。



图 1.2　图像去模糊应用领域示意图

Fig. 1.2　Schematic diagram of image deblurring application areas

在消费电子领域，智能手机和摄像机等设备用户对高质量图像的需求持续增长。去模糊技术不仅能够优化拍摄效果，还能在后期处理中有效复原模糊图像的清晰度，从而提升用户视觉体验。**在视频监控领域**，由于目标运动等因素导致的图像模糊问题普遍存在。去模糊技术能够显著提升监控画面的清晰度，从而增强安防、交通监控等领域的应用效果。高清、去模糊的画面有利于快速运动目标的识别、细节信息的提取，并为后续算法分析和司法取证提供可靠的技术支撑。**在自动驾驶领域**，车载摄像头和其他图像传感器采集的环境信息可能因动态场景变化、天气状况或传感器抖动而出现模糊，这对道路状况的实时评估带来了严峻挑战。图像去模糊技术为自动驾驶车辆提供更清晰的感知输入，提升目标检测和环

中国知网　https://www.cnki.net

境感知的可靠性，从而显著提高自动驾驶系统的安全性和智能水平。**在医学影像分析领域**，CT 和 X 射线成像的清晰度直接关系到诊断准确性。然而，成像设备或患者运动等原因可能导致影像模糊，进而掩盖重要的病变信息。图像去模糊技术可通过结合图像超分辨率技术复原模糊影像中的关键细节，为医生提供更清晰的诊疗依据，从而在辅助诊断、疾病筛查及医学研究中发挥重要作用。**在文物保护领域**，许多历史影像和文物照片由于保存条件或拍摄条件的限制而存在模糊现象。去模糊技术能够有效复原这些影像的原始细节，为历史研究者提供更清晰的信息，并促进文物数字化记录和文化遗产的长期保存，从而推动文化传承和艺术研究。

图像去模糊技术研究经历了从传统方法到深度学习（Deep Learning, DL）方法的演进历程。传统去模糊方法主要基于边缘特征和先验知识，如局部最大梯度先验[6]、暗通道先验[7] 等，这些方法在特定场景下能取得一定效果，但普适性不强且计算复杂度高。近年来，深度学习的兴起为图像去模糊带来了革命性突破，基于监督学习的深度网络[8-11] 通过大量模糊-清晰图像对的训练，显著提升了去模糊质量和效率。然而，这些有监督方法面临严峻挑战：一方面，获取真实场景下的模糊-清晰图像对极为困难，研究者往往依赖合成数据集进行训练；另一方面，合成数据与实际模糊存在域差异，导致模型在复杂真实场景中泛化能力不足。针对上述挑战，无监督图像去模糊方法逐渐成为研究热点。无监督去模糊不依赖配对训练数据，而是通过设计合理的损失函数、利用图像内在特性或引入对抗学习等方式，从非配对数据中学习去模糊能力。这种方法能够更好地适应各种复杂的真实模糊情况，具有重要的应用前景。因此，面向复杂场景的无监督图像去模糊研究不仅是学术前沿，也是解决实际问题的关键途径。

1.2 研究目的与挑战

鉴于图像去模糊技术在现代视觉应用中的重要性及研究现状，本章旨在探索面向复杂场景的无监督图像去模糊方法，以突破当前无监督方法在实际复杂场景应用部署中面临的关键瓶颈。基于深入分析，当前无监督去模糊方法所面临的核心挑战主要体现在以下三个维度：

（1）**色彩保真度和定量评价问题：**现有无监督图像去模糊方法在恢复图像清晰度的同时，往往导致原始图像色彩信息的严重失真。这种色彩失真现象不仅显著降低复原图像的视觉质量，还对后续图像分析和识别任务产生负面影响。具体而言，当前方法在构建从模糊域到清晰域的端到端映射过程中，忽略了模糊退化过程中色彩信息实际保留的物理特性，致使复原结果与原始图像之间存在显著色差。这种色彩不一致性不仅影响用户对去模糊结果的接受度，更使得相关技术难以应用于对色彩精度要求极高的专业领域，如医学影像分析、文物数字修复和精准色彩再现等场景。此外，学术界目前缺乏专门针对去模糊任务的色差量化评估

中国知网 https://www.cnki.net

标准，难以客观衡量方法在色彩保留方面的性能，进而阻碍了相关研究的有效推进和优化。因此，如何在无监督去模糊框架下有效保留原始图像的色彩信息，同时设计符合人类视觉感知特性的色差评估机制，已成为亟待解决的关键科学问题。

（2）**模型复杂度与实时性问题：**目前主流无监督图像去模糊方法普遍采用复杂网络架构和庞大参数规模，导致模型体积臃肿、推理耗时长，难以满足实际应用场景中对实时性和资源效率的严苛要求。这一问题具体表现在多个层面：首先，现有无监督去模糊模型通常依赖深层神经网络和域转换机制，参数量普遍达到数千万级别，使得模型在计算资源有限的移动设备和嵌入式系统上难以部署；其次，这些方法对输入图像的分辨率和领域特征存在较为严格的约束条件。由于训练过程中使用特定场景的数据，模型在面对多样化场景时往往表现出泛化能力不足的问题。同时，模型结构的过度复杂导致其难以处理高分辨率图像，这在实际应用中构成严重限制。再者，复杂的模型结构显著延长了推理时间，难以满足诸如视频监控和自动驾驶等对高实时性具有极高需求的应用场景。因此，如何在保证去模糊效果的前提下，显著降低模型复杂度，提升模型的通用性和实时处理能力，已成为无监督图像去模糊研究面临的另一重大挑战。

（3）**复合退化处理问题：**现实复杂场景中的模糊图像经常是和低光照共同作用的结果。具体而言，在低光照环境下，拍摄时相机通常需要延长曝光时间以捕获足够光线。然而，在这段延长的曝光过程中，轻微的相机晃动或者拍摄对象的细微移动均会被记录，从而导致最终图像也出现运动模糊现象。低光照和模糊的相互叠加，使得这类退化更加复杂且常见。然而，现有的无监督去模糊方法专注于单一模糊退化的处理，难以有效应对和低光照的复合退化情况。为解决复合退化问题，一些复合退化处理方法要么采取级联策略，先后应用不同的处理模型（增加了处理复杂度和累积误差），要么采取专门训练策略，收集大量特定的复合退化样本进行训练（增加了数据获取和训练成本）。因此，如何在无监督框架下同时有效处理低光照问题，并避免引入额外的数据和计算开销，成为实际复杂场景应用中亟待解决的挑战。

1.3 本文的研究内容

针对无监督图像去模糊领域所面临的关键挑战，本文从视觉质量、模型复杂度以及复杂场景适应性三个方面提出了三种创新性的无监督图像去模糊方法，分别对应“色彩保真度与定量评价”，“模型轻量化与实时性”和“复合退化处理”三类挑战。这一研究路径循序渐进，从**“视觉质量上的基础问题”**到**“部署和应用效率问题”**，再到**“复杂场景适应问题”**，旨在分段式系统性提升无监督图像去模糊技术在真实复杂场景中的实用性和应用范围，推动该技术的落地与拓展。图1.3展示了本文研究内容的详细框架。通过模糊偏移估计、轻量级域转换和噪声自回归

中国知网 https://www.cnki.net

应用等技术应用与创新，本文试图在不依赖高质量配对训练数据的条件下，为各类实际复杂场景提供高质量、高效率和高适应性的图像去模糊解决方案。下文将围绕这三种方法依次展开，详细介绍其设计思路。



图 1.3　本文研究内容的整体框架图

Fig. 1.3　Overall framework of the research contents in this dissertation

（1）基于模糊偏移估计的无监督图像去模糊方法。

针对无监督去模糊过程中严重的色彩失真问题，本文提出了一种新型的色彩保持网络，改变了一般的的无监督去模糊思路。不同于直接学习模糊图像到清晰图像的映射，该网络创新性地引入了模糊偏移估计机制以及自适应模糊校正机制，将去模糊任务转化为估计模糊偏移并对原始图像进行渐进式校正的过程，避免了端到端训练过程中的色彩崩溃，最大程度地保留了图像的原始色彩特征。同时，设计了金字塔全局模糊特征感知模块，该模块通过多尺度特征提取和全局上下文融合，能够有效捕获不同尺度的模糊模式和图像结构信息，增强了对复杂模糊场景的适应能力和色彩信息的保持能力。此外，为了解决色差评估指标缺乏的问题，本文提出了一种符合人类视觉感知的新型色差定量评估指标。鉴于图像中的色彩信息主要通过直方图中不同分量的“峰”来体现，该指标基于 HSV 色彩空间直方图的峰值分析进行构建，综合考虑了峰的面积、位置偏移以及各颜色分量的权重。相比于 PSNR 等传统性能指标，该指标能够更客观地衡量去模糊结果的色彩保持效果，为无监督图像去模糊领域的色彩质量评估提供了新的标准和方法。

（2）基于轻量级域转换的无监督图像去模糊方法。

针对现有无监督去模糊方法模型复杂、推理缓慢、资源消耗大的问题，本文

中国知网　https://www.cnki.net

提出了频域对比损失约束的轻量级无监督去模糊网络，在保证去模糊性能的同时，大幅降低了模型的复杂度。该网络基于创新设计的轻量级域转换单元和无参数频域对比单元，成功构建了一个体积仅为现有最先进模型 1/25、推理速度提升 5 倍的高效去模糊模型。轻量级域转换单元通过优化卷积层、归一化层、激活函数和残差连接的组合方式，实现了参数量大幅减少而不损失模型表达能力；同时，无参数频域对比单元在频域层面建立了潜在图像与清晰图像之间的相似性约束，迫使潜在图像在频域中不断逼近清晰图像，无需额外参数即可有效约束模型学习，提升复原质量。此外，该方法不受一般无监督去模糊方法对图像分辨率和特定领域的限制，表现出对各个领域模糊图像优异的通用性，并能够适应各种场景和不同分辨率的图像，大幅提升了无监督去模糊技术在资源受限环境下的应用潜力。

（3）基于噪声自回归的无监督低光照图像去模糊方法。

针对现实场景中模糊和低光照复合退化的普遍问题，本文提出了一种基于无监督去模糊范式的处理方法，通过创新性地整合噪声自回归技术，实现了单一去模糊模型同时处理低光照增强、图像去模糊及其复合退化的能力。该方法设计了双分支架构，包含转换分支和回归分支：转换分支负责学习域间映射关系，完成退化图像到清晰图像的转换；而回归分支则通过噪声自回归机制增强模型对低光照退化的理解和处理能力，以及对低光照环境中噪声的抑制能力。值得注意的是，该方法仅需非配对的模糊-清晰数据进行无监督训练，无需专门的低光照-正常光照配对数据或复合退化样本，便可完成模糊与低光照的复合退化处理。这一特性巧妙规避了传统方法对特定复合退化样本的依赖，显著降低了数据获取和训练成本。此外，通过灵活配置不同组件，如配置不同的网络结构，模型可在感知性能（视觉质量）和失真性能（量化指标）之间进行平衡调整，满足不同应用场景的需求，为实际应用环境下的模糊和低光照复合退化问题提供了一种高效且适应性强的解决方案，拓展了无监督图像去模糊方法的实际应用范围。

1.4 本文的组织结构

本文由六章组成，各章内容安排如下：

第一章：绪论。介绍了图像去模糊技术的研究背景及研究意义，阐述了图像模糊问题在实际复杂场景中的广泛存在及其对图像质量的影响。同时，明确了本文的研究目的与挑战，指出了当前无监督图像去模糊方法在实际复杂场景中的不足之处。本章还概述了全文的研究内容，包括基于模糊偏移估计、轻量级域转换和噪声自回归的无监督去模糊方法的研究与实现。

第二章：图像去模糊研究现状。系统回顾了图像去模糊的研究现状，从传统方法到深度学习方法进行了全面梳理。首先对非盲图像去模糊和盲图像去模糊的传统方法进行了分类介绍，包括直接法、迭代法以及基于边缘特征和先验知识的方

中国知网 https://www.cnki.net

法。接着重点讨论了基于深度学习的图像去模糊技术，涵盖了基于卷积神经网络的端到端和多尺度方法，以及基于循环神经网络、Transformer、扩散模型和 Mamba 等新型架构的方法。特别关注了自监督和无监督方法的最新进展。此外，本章还总结了常用的图像去模糊数据集和评价指标，为实验评估提供了参考依据。

第三章：基于模糊偏移估计的无监督图像去模糊方法。首先，总结了现有无监督去模糊方法在色彩保持方面的局限性，指出现有方法直接学习模糊图像到清晰图像的映射容易导致色彩失真问题；其次，介绍了本文提出的基于模糊偏移估计的新型框架，说明其如何通过模糊偏移估计和自适应模糊校正机制来避免端到端训练中的色彩崩溃问题；然后，从网络架构入手，详细阐述了金字塔全局模糊特征感知模块和模糊偏移估计子网络的设计，并分析了自适应模糊矫正机制的实现过程和模糊矫正方案的选择策略；特别地，本章还介绍了基于 HSV 色彩空间直方图峰值分析的色差定量评价指标，阐述如何从峰域误差、峰偏误差和分量加权三个维度逐步构建更符合人类视觉感知的评估体系；最后，通过全面的实验分析和消融研究，验证了所提方法在色彩保持和模糊去除方面的卓越性能，并量化了各模块对整体性能的贡献。

第四章：基于轻量级域转换的无监督图像去模糊方法。首先，分析了包含第三章方法的现有无监督去模糊方法在模型复杂度和计算效率方面的不足，指出现有方法在去模糊性能的过程中往往面临推理速度慢、资源消耗大的问题；其次，介绍了本文提出的轻量级域转换框架，说明其如何通过创新设计的轻量级域转换单元和无参频域对比单元实现高效去模糊的目标；然后，从网络架构入手，详细阐述了轻量级域转换单元的设计原理，包括其基本单元的轻量化实现和无参频域对比单元的工作机制；最后，通过系统的实验分析和消融实验，验证了所提方法在计算效率和去模糊效果之间的平衡性，并对各模块的贡献进行了深入分析。

第五章：基于噪声自回归的无监督低光照图像去模糊方法。首先，分析了模糊和低光照复合场景中存在的特殊挑战，指出包含第三章、第四章的单一去模糊方法很难处理该类挑战，且其他联合方法在处理模糊和低光照复合退化时往往需要依赖特定的配对数据，限制了其在复杂场景中的灵活性；其次，介绍了本文提出的基于噪声自回归的无监督方法，强调其通过双分支架构实现了单一模型对低光照增强、图像去模糊及其复合退化的同时处理能力；然后，从网络架构入手，详细阐述了转换分支和回归分支的设计思路，并分析了噪声自回归机制在低光照退化处理中的作用；最后，通过全面的实验分析和消融实验，验证了所提方法在低光照条件下的去模糊效果，并对各模块的功能和贡献进行了深入剖析。

第六章：总结与展望。系统总结了三种无监督图像去模糊方法的技术贡献，分析了它们在实际复杂场景中的优势。同时，基于当前研究和技术发展趋势，对无监督图像去模糊领域的未来研究方向进行了展望。

中国知网 https://www.cnki.net

第二章 图像去模糊研究现状

图像去模糊技术作为图像处理领域的研究热点之一，受到了广泛关注并取得了长足发展。从早期的基于传统数学模型的方法到当前主流的深度学习方法，经历了全方位的迭代革新。如图2.1所示，根据已知条件，传统的图像去模糊技术可以分为非盲去模糊和盲去模糊两类；基于深度学习的方法则从数据需求和网络架构设计的角度出发，划分为基于 CNN 的全监督方法、基于其他架构的全监督方法以及自监督和无监督方法。本章首先简述模糊的形成过程，然后从传统方法和深度学习方法两个维度，系统梳理国内外图像去模糊技术的研究现状与发展脉络。

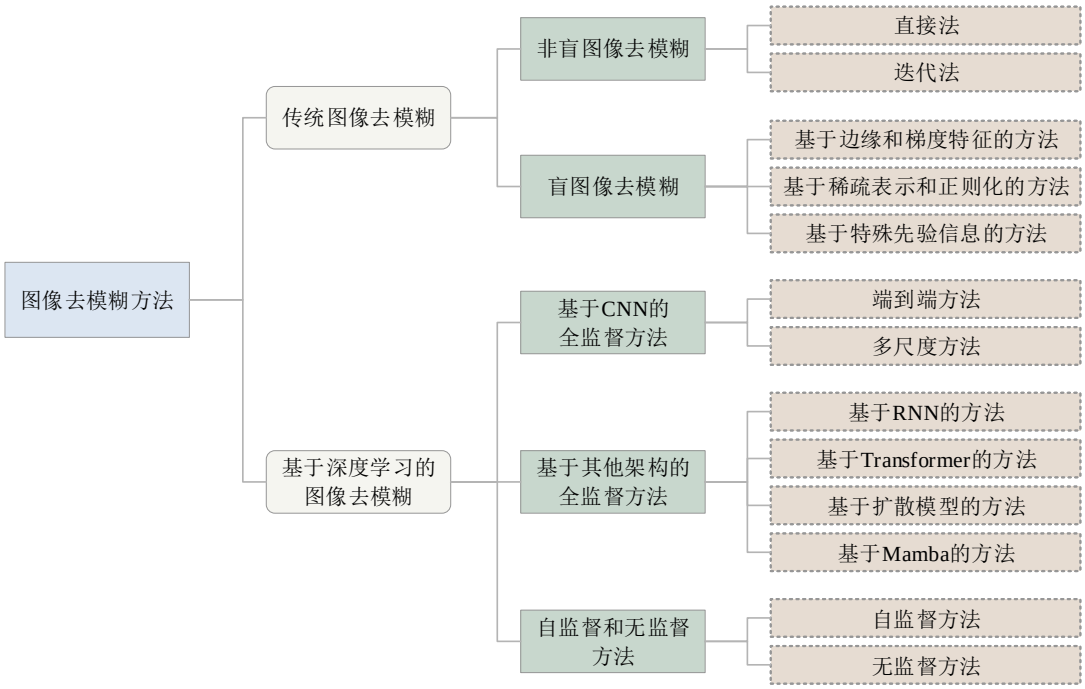


图 2.1　代表性的图像去模糊方法分类

Fig. 2.1　Classification of representative image deblurring methods

2.1 模糊的形成过程

图像模糊的形成过程可用线性时不变系统描述：

$$B = L * k + \gamma, \tag{2.1}$$

其中 B 表示观测到的模糊图像，L 表示清晰图像，k 表示点扩散函数（Point Spread Function, PSF），γ 表示系统中的噪声干扰，$*$ 表示卷积操作。图2.2直观呈现了线性时不变系统示意图。

中国知网 https://www.cnki.net

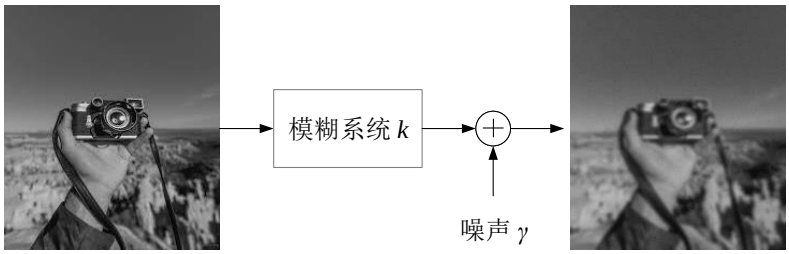


图 2.2　线性时不变系统示意图

Fig. 2.2　Diagram of linear time-invariant system

2.2 传统图像去模糊

传统图像去模糊方法主要基于数学模型和优化理论，不依赖于大规模数据训练，图2.3展示了传统图像去模糊的发展历程。根据式2.1，此类方法将去模糊问题视为一个求解逆问题的过程。根据 PSF 的可获知情况，传统图像去模糊方法主要分为两类：一类是非盲去模糊方法，即在已获知 PSF 的条件下恢复原始清晰图像；另一类是盲去模糊方法，需要在 PSF 未知情况下同步推导 PSF 及重建清晰图像。

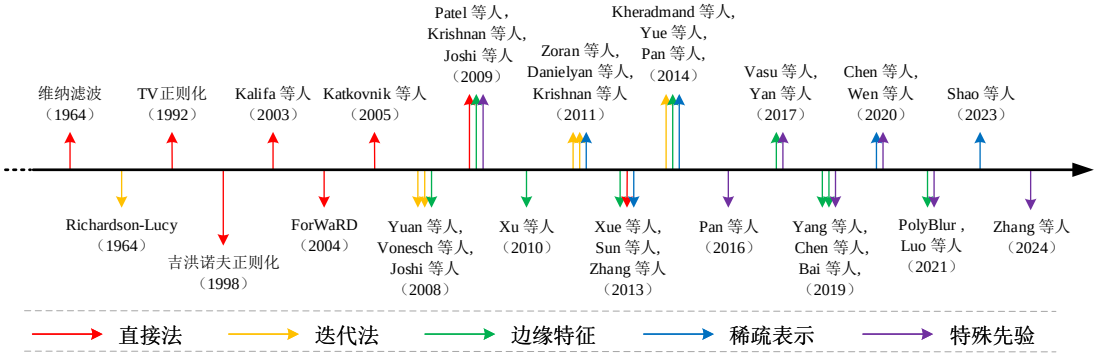


图 2.3　传统图像去模糊的发展历程

Fig. 2.3　Development history of traditional image deblurring

2.2.1 非盲图像去模糊

非盲图像去模糊（Non-blind Image Deblurring, NBID）旨在利用已知的 PSF 从模糊图像中恢复清晰图像，根据求解策略的不同，该类方法可划分为两大类别：直接法和迭代法[12]。直接法通常在频域中进行处理，具有计算高效的优点；而迭代法则通过不断优化目标函数，能够获得更高质量的复原结果，但计算复杂度较高。

（1） 直接法

直接法作为非盲图像去模糊的奠基性方法，其基本思想是将空间域中的卷积操作转换到频域中处理[13-20]，从而简化求解过程。根据卷积定理，空间域的卷积等价于频域中的乘积，即

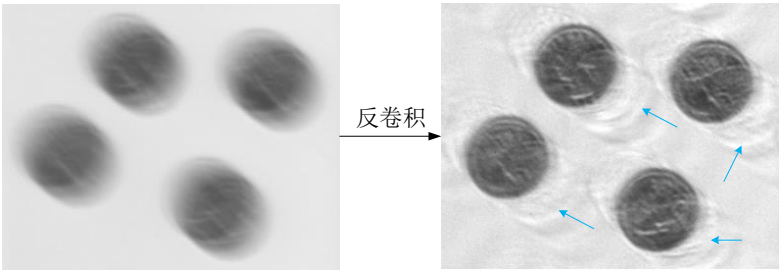
$$\mathcal{F}(B) = \mathcal{F}(L) \cdot \mathcal{F}(k) + \mathcal{F}(\gamma), \tag{2.2}$$

中国知网　https://www.cnki.net

其中 $\mathcal{F}$ 表示傅立叶变换算子。因此，图像去模糊在频域中的形式解为：

$$\hat{L} = \mathcal{F}^{-1}\left(\frac{\mathcal{F}(B)}{\mathcal{F}(k)}\right), \tag{2.3}$$

其中 $\mathcal{F}^{-1}$ 为傅立叶逆变换算子。然而，由于 PSF 在高频区域能量衰减以及噪声干扰，这种直接求逆（反卷积）会导致显著的噪声放大和振铃效应，如图2.4所示。



（a）模糊图　　（b）振铃效应（蓝色箭头指示处）

图 2.4　反卷积求解时出现的振铃效应

Fig. 2.4　Ringing artifacts in deconvolution

为了缓解这一问题，研究者提出了多种抑制噪声的改进算法。维纳滤波（Wiener Filter, WF）[13] 作为经典直接法代表，基于最小均方误差准则设计线性滤波器抑制噪声，其数学表达式为：

$$\hat{L} = \mathcal{F}^{-1}\left(\frac{\overline{\mathcal{F}(k)} \cdot \mathcal{F}(B)}{|\mathcal{F}(k)|^2 + \frac{S_L}{S_\gamma}}\right), \tag{2.4}$$

其中 S_L 和 S_γ 分别为清晰图像和噪声的功率谱。虽然维纳滤波在理论上能获得最优解，但实际应用中难以精确获取清晰图像的功率谱，限制了其实用性。相较而言，全变分（Total Variation, TV）正则化[20] 通过对图像梯度施加约束，能更有效地消除噪声（如图2.5所示），已成为图像复原领域的重要处理模型。

吉洪诺夫正则化[14] 是另一种经典的直接求解方法，提供了另一种解决思路，其通过在频域引入正则化项抑制高频噪声放大，其复原公式为：

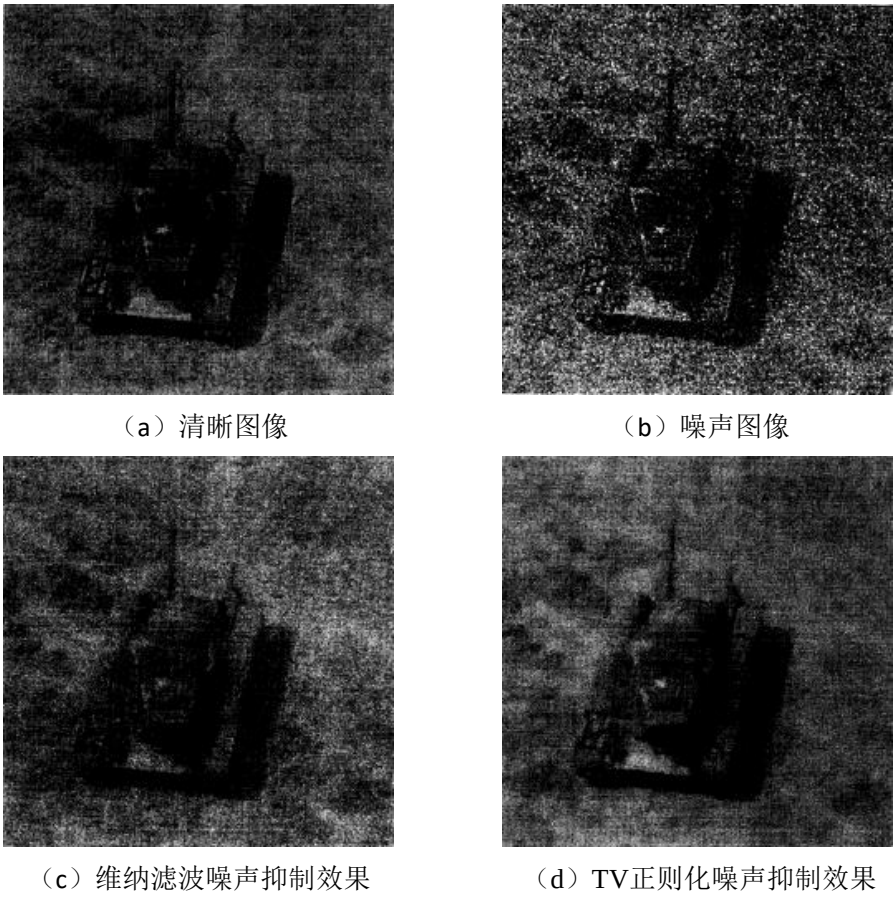
$$\begin{aligned}\hat{L} &= \mathcal{F}^{-1}\left(\frac{\overline{\mathcal{F}(k)} \cdot \mathcal{F}(B)}{|\mathcal{F}(k)|^2 + \lambda}\right) \\ &= \mathcal{F}^{-1}\left(\frac{|\mathcal{F}(k)|^2 \cdot \mathcal{F}(L)}{|\mathcal{F}(k)|^2 + \lambda}\right) + \mathcal{F}^{-1}\left(\frac{\overline{\mathcal{F}(k)} \cdot \mathcal{F}(\gamma)}{|\mathcal{F}(k)|^2 + \lambda}\right),\end{aligned} \tag{2.5}$$

其中 λ 为正则化参数。从优化角度看，这等价于求解问题：

$$\hat{L} = \arg\min_{L} \|B - L * k\|^2 + \lambda \|L\|^2 . \tag{2.6}$$

尽管吉洪诺夫正则化能在一定程度上抑制噪声，但其隐含的图像平滑性假设往往导致复原图像边缘模糊。针对此问题，Kalifa 等人[15] 提出基于镜像小波基的

中国知网　https://www.cnki.net



（a）清晰图像　（b）噪声图像

（c）维纳滤波噪声抑制效果　（d）TV正则化噪声抑制效果

图 2.5　维纳滤波和 TV 正则化的噪声抑制效果对比

Fig. 2.5　Comparison of noise suppression effects between wiener filtering and TV regularization

阈值反卷积方法，通过构建专门的正交基最小化估计风险，特别适用于卫星图像模糊处理，有效减少了边缘失真现象。

随着多尺度分析理论特别是小波分析的深入发展，基于变换域的非盲图像去模糊方法取得重大突破。Neelamani 等人[16] 提出的 ForWaRD 方法开创性地采用“反卷积-去噪”分离思路，首先应用吉洪诺夫正则化进行反卷积，随后在小波域对结果去噪。该方法巧妙结合了傅里叶域与小波域各自优势：傅里叶变换有效表征反卷积过程中的彩色噪声，而小波变换（Wavelet Transform, WT）则擅长表示分段平滑的信号和图像。通过在两个域中进行标量收缩实现噪声正则化，ForWaRD 方法在最小化均方误差同时，显著降低了传统反卷积方法中的伪影。

直接法的主要优势在于计算效率高、实现简单，适用于实时或近实时应用场景。然而，其核心局限在于难以有效处理遗留噪声问题，复原结果中常保留振铃伪影和噪声伪影。即使是较为先进的变换域方法，在处理复杂结构和大范围模糊时仍面临挑战，特别是当需要应对非高斯噪声或复杂模糊核时，直接法的性能往往显著下降。这些限制促使研究者转向更为灵活和强大的迭代法，以追求更加鲁棒和高质量的图像去模糊解决方案。

中国知网　https://www.cnki.net

（2） 迭代法

迭代法是非盲图像去模糊的另一重要技术路线，与直接法不同，迭代法通过构建合适的目标函数，并采用逐步优化的策略逐渐接近最优解[21-27]。此类方法主要基于变分法或贝叶斯估计理论，可更充分地整合图像先验知识，从而获得质量更高的复原结果。在变分框架中，图像去模糊问题可表述为能量函数最小化问题：

$$E(L) = D(B, k * L) + \lambda R(L), \tag{2.7}$$

其中 D 表示数据保真项，主要衡量重建图像与实际观测数据的符合度；R 表示正则化项，旨在融入图像先验信息以约束解空间；λ 为权重系数，用于平衡两项的相对重要性。不同迭代算法的主要差异体现在正则化项的选择与优化算法的设计上。

迭代法发展历程中，Richardson 等人[21] 提出的贝叶斯迭代方法（Lucy-Richardson，LR）具有里程碑意义。该方法将图像、点扩散函数以及退化图像视为概率分布，并借助贝叶斯定理实现逐步迭代复原。然而，LR 算法在噪声处理方面存在局限性，复原过程中会导致噪声被放大，且处理大尺寸模糊核时易产生振铃伪影。为解决这一问题，Yuan 等人[26] 提出了一种渐进式尺度间和尺度内的非盲图像反卷积方法。该方法以双边 Richardson-Lucy 边缘保持反卷积算法为基础，通过从粗尺度到精细尺度的渐进复原（尺度间），以及每个尺度内的渐进细节还原（尺度内），显著减少了振铃伪影，尤其适用于大尺寸模糊核的处理。

随着迭代法的深入发展，研究者开始探索更先进的图像先验模型。Zoran 等人[27] 将统计学习与图像复原相结合，提出了一种从自然图像块学习先验模型的方法。研究指出，能够为图像数据提供高似然估计的先验模型在图像复原任务中同样表现出色。基于此发现，该方法开发了一个通用框架，允许将任何基于图像块的先验知识应用于整幅图像的复原过程。其提出的基于高斯混合模型的先验在图像去噪、去模糊和复原等任务中，显著优于当时的其他通用先验方法，为迭代法引入了数据驱动的先验知识。与此同时，非局部图像特征的利用也为迭代去模糊带来了新突破。在 BM3D 算法[28] 成功应用于图像去噪的基础上，Danielyan 等人[22] 创新性地将非局部块匹配思想引入迭代去模糊领域。该研究构建了以 BM3D 框架为基础的分析与合成模型，并提出了两种不同的问题解决思路：其一依托单一目标函数最小化原则，其二则基于广义纳什平衡理论协调双目标函数。后一种方案成功实现了去模糊与去噪操作的解耦，使算法能更有效地处理复杂的图像退化。这一研究不仅拓展了 BM3D 框架的应用范围，也证实了非局部特征在图像去模糊中的重要价值。

迭代法的主要优势在于其理论基础扎实，能够灵活地整合各种先验知识，获得高质量的复原结果。随着计算机性能的提升和算法优化，如 Krishnan 等人[24] 和 Vonesch 等人[25] 提出的快速算法，计算效率问题正在逐步改善。然而，迭代法仍

中国知网 https://www.cnki.net

然较为耗时和复杂，适应场景也比较有限，这限制了该类方法的实际应用。

2.2.2 盲图像去模糊

盲图像去模糊（Blind Image Deblurring, BID）是一种在 PSF 未知的情形下，从模糊图像中恢复出清晰图像的技术。与非盲图像去模糊相比，BID 的挑战性更大，因为该类方法需要同时推导出模糊核和潜在的清晰图像，是一种典型的病态（ill-posed）问题，图2.6展示了一个经典的迭代估计模糊核和清晰图像的算法框架[29]。盲去模糊问题的根本困难在于：存在无穷多组模糊核与潜在图像的组合可产生相同的模糊观测结果。因此，有效的盲去模糊算法必须引入先验知识来约束解空间，如利用图像的边缘分布、梯度统计特性等自然图像固有属性，以提升算法的稳定性和复原精度。为此，研究者们提出了多种盲去模糊算法，主要可分为基于边缘和梯度特征的方法、基于稀疏表示和正则化的方法以及基于特殊先验信息的方法。

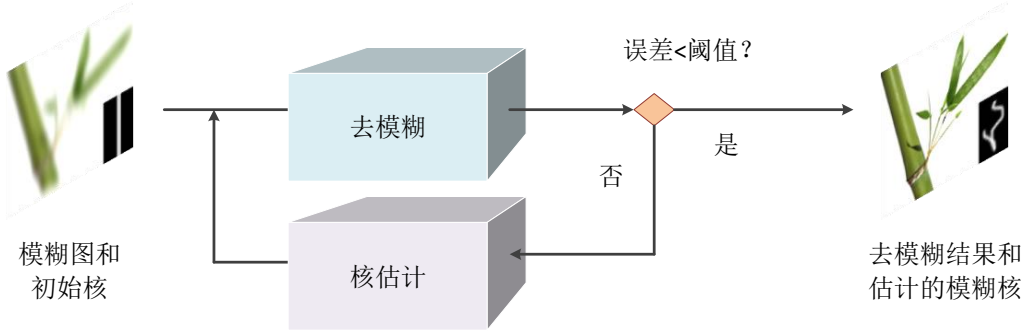


图 2.6　经典的盲图像去模糊算法框架

Fig. 2.6　Classic algorithm framework of blind image deblurring

（1） 基于边缘和梯度特征的方法

盲图像去模糊研究中，基于边缘和梯度特征的方法构成了一个重要分支，其核心思想是利用图像中的边缘和梯度信息来辅助模糊核的估计[6,30-37]。该类方法建立在一个基本观察之上：清晰图像通常具备锐利的边缘和丰富的细节，而模糊过程会导致这些特征变得平滑，高频信息减少。因此，边缘和梯度特征可作为评估图像清晰度的关键指标，为模糊核估计提供有效依据。

早期研究主要聚焦于从模糊图像中提取有效边缘信息。作为早期的代表性方法，Joshi 等人[30] 提出了一种通过预测锐利边缘来估计非参数化、空间可变的 PSF 的算法。该方法首先预测模糊输入图像的“锐利”版本，然后利用这两幅图像求解 PSF，可以处理由失焦、轻微相机运动和成像系统固有特性引起的模糊。这一研究开创了利用边缘信息进行盲去模糊的先河，为后续研究奠定了基础。

随着研究的深入，研究者们发现并非所有的边缘信息都对模糊核估计有益。Xu 和 Jia 等人[33] 指出强边缘在特定情况下反而可能降低核估计质量，并提出一种评估图像边缘在运动去模糊中有效性的新度量标准，以及相应的梯度选择机制以减

中国知网　https://www.cnki.net

轻潜在负面影响。这一发现促使后续研究者更加精细地利用边缘信息。Sun 等人[31]进一步引入基于图像块先验的模糊核估计策略，通过构建专门针对图像边缘和角点原语外观建模的图像块先验，获得更可靠的模糊核估计。

近年来，更为精细的边缘选择策略得到了发展。源于对模糊处理会降低图像局部区域梯度最大值的观察，Chen 等人[6] 提出了基于局部最大梯度先验的方法，得到了充分的数学分析和实验支持。Delbracio 等人[36] 的 PolyBlur 方法则专注于去除轻微模糊，通过多次应用估计的模糊来补偿原始模糊，实现了高效率的模糊去除。

总体而言，基于边缘和梯度特征的盲图像去模糊方法通过不断优化边缘选择策略、增强边缘与其他特征的融合以及深入研究边缘与模糊机制的关系，在提高模糊核估计精度和复原图像质量方面取得了显著进展。这些方法凭借其计算效率高、理论基础扎实和实用性强的特点，在盲图像去模糊领域占据了重要地位。

（2） 基于稀疏表示和正则化的方法

基于稀疏表示和正则化的盲图像去模糊方法是盲图像去模糊领域的核心技术路线之一，这类方法的基本思想是通过施加适当的稀疏约束或正则化项来减少解空间，从而使病态的盲去模糊问题变得可解[38-47]。这类方法的发展源于对图像先验知识的深入理解：自然图像在某些变换域通常表现为稀疏的，而模糊过程会破坏这种稀疏性。通过在盲去模糊过程中引入促进稀疏性的正则化项，可以引导解向清晰图像靠拢。

在稀疏表示框架下的方法发展历程中，Krishnan 等人[40] 基于归一化稀疏度量，率先提出了一种新的盲反卷积方法，该方法的突破在于设计了一种新型的图像正则化项，使得真实清晰图像在成本函数中能够达到最低值。这种设计使盲去模糊模型的成本函数表达更为简单，避免了额外方法的需要，算法速度快且鲁棒性强。这一研究标志着稀疏正则化在盲去模糊领域开始显现其潜力。随着研究的深入，Xu 等人[42] 提出了一个更为突破性的工作，他们观察到之前基于最大后验概率估计（Maximum A Posteriori, MAP）的模糊去除方法的成功部分源于它们隐式或显式地创建了包含显著图像结构的非自然表示。他们提出了一种数学上更严谨的 L0 稀疏表达方法，为运动模糊去除提供了新的解决路径。该方法无需在优化过程中引入额外的过滤操作，表现出能量快速下降的特点，使其在少量迭代后即可实现收敛。

近年来，研究人员开始探索更复杂的稀疏表示和正则化方法。Chen 等人[38] 注意到现实世界的噪声远比简单分布（如高斯或拉普拉斯）复杂得多，因此开发了一种新的增强稀疏模型 l_e，该模型由两个稀疏模型 l_1 和 l_0 发展而来，用于更好地拟合复杂的自然噪声。此外，该方法还建议使用 l_e 来正则化图像梯度。与广泛采用的 l_0 稀疏项相比，l_e 可以更有效地惩罚不重要的图像细节，在公共数据集和真实世界图像上的综合评估证明了该方法在速度和准确性方面优于现有方法。

中国知网 https://www.cnki.net

基于稀疏表示和正则化的盲图像去模糊方法展现了从简单到复杂、从均匀到非均匀模糊处理的演进路径。这些方法通过深入理解图像的稀疏特性，设计了越来越精细的正则化策略，有效地将病态问题转化为可解问题。随着对图像先验知识理解的深化和优化技术的发展，这类方法在处理复杂现实场景的模糊图像时展现出了强大的潜力，为盲图像去模糊领域提供了一条可靠且有效的技术路线。

（3） 基于特殊先验信息的方法

随着盲图像去模糊技术的不断发展，研究人员发现利用图像中固有的特殊先验信息可以显著提升去模糊效果[7,48-54]。这些先验信息通常捕捉了自然图像的统计特性或结构特征，为模糊核估计提供了有力的约束条件。值得注意的是，前两小节中讨论的边缘、梯度以及各种稀疏表示本质上也属于先验信息的范畴。本小节将重点介绍除上述两类先验外的特殊先验及其在盲图像去模糊中的应用价值。

颜色先验是一种早期探索的有效方法。Joshi 等人[48] 提出了一种基于局部颜色统计的约束框架，该方法要求每个像素的颜色必须是其邻域内两种主要颜色的线性组合。这种两色先验的优势在于它不仅能适应特定图像的内容特性，还能有效地将边缘锐度与边缘强度解耦，从而在去模糊和去噪方面取得了比专用方法更优的性能。针对人脸图像这一重要应用场景，Pan 等人[49] 提出了一种基于样本的最大后验概率去模糊算法，通过利用人脸结构特征来解决传统方法在纹理较少的人脸图像上效果不佳的问题。该方法避免了粗到细策略和特殊边缘选择，为特定领域的去模糊任务提供了新思路。

暗通道先验是近年来取得突破性进展的重要方法。Pan 等人[7] 首次发现模糊图像的暗通道相比清晰图像更加稀疏性降低，这一现象源于模糊过程中暗像素与周围高强度像素平均后变亮的特性。他们通过数学证明和实验验证了暗通道稀疏性变化是模糊过程的内在属性，并基于此提出了一种快速收敛且可扩展到非均匀去模糊的算法。随后，Yan 等人[50] 进一步拓展为极端通道先验，他们观察到清晰图像中的明亮像素在模糊后也会变暗，由此提出了亮通道先验概念。通过将亮通道先验与暗通道先验进行有机结合，同时利用图像中的高亮度与低亮度信息提升了算法鲁棒性。

近期研究进一步挖掘了更多具有区分性的先验信息。受到图像超分辨率领域中自示例先验的启发，Bai 等人[52] 证实了一个重要发现：将模糊图像降采样至足够粗糙程度后，所得图像与潜在清晰图像的低分辨率版本具有相似性。基于此发现，他们提出了多尺度潜在结构先验理论，规避了计算繁重的非凸先验问题，从而实现高效去模糊处理。Wen 等人[51] 开发了一种局部最小像素稀疏先验，发现清晰图像的部最小像素比模糊图像更稀疏，并设计了灵活高效的算法，避免了现有方法中的非严格近似解，在去模糊质量、稳健性和计算效率方面取得了显著提升。

从颜色先验、暗通道先验到多尺度潜在结构、局部最小像素和超像素分割先

中国知网　https://www.cnki.net

验，研究者们不断发掘图像中蕴含的丰富统计特性和结构信息，为盲去模糊提供了越来越有效的约束条件。这些先验方法各有其适用场景和技术优势，共同推动了盲图像去模糊技术的快速进步。

2.3 基于深度学习的图像去模糊

深度学习技术的快速进步为图像去模糊领域带来了颠覆性的突破。与传统方法相比，深度学习驱动的图像去模糊技术具有显著优势：它不需要明确计算模糊核，而是能够直接从海量数据中自动学习模糊与清晰图像间的转换关系，大幅提升了去模糊效果，同时扩大了应用范围，图2.7展示了基于深度学习的图像去模糊的发展历程。根据网络结构设计和训练方法的差异，这些技术可分为几个主要类别：基于卷积神经网络（Convolutional Neural Networks, CNN）的全监督方法、基于其他架构的全监督方法以及自监督和无监督方法，下面对这些方法展开详细介绍。

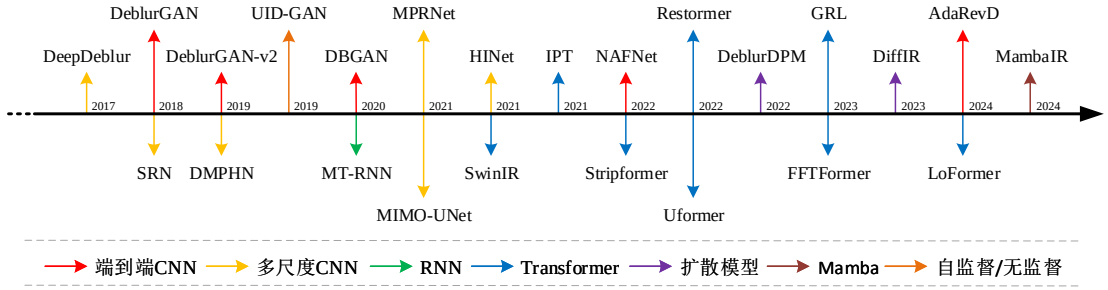


图 2.7　基于深度学习的图像去模糊的发展历程

Fig. 2.7　Development history of image deblurring based on deep learning

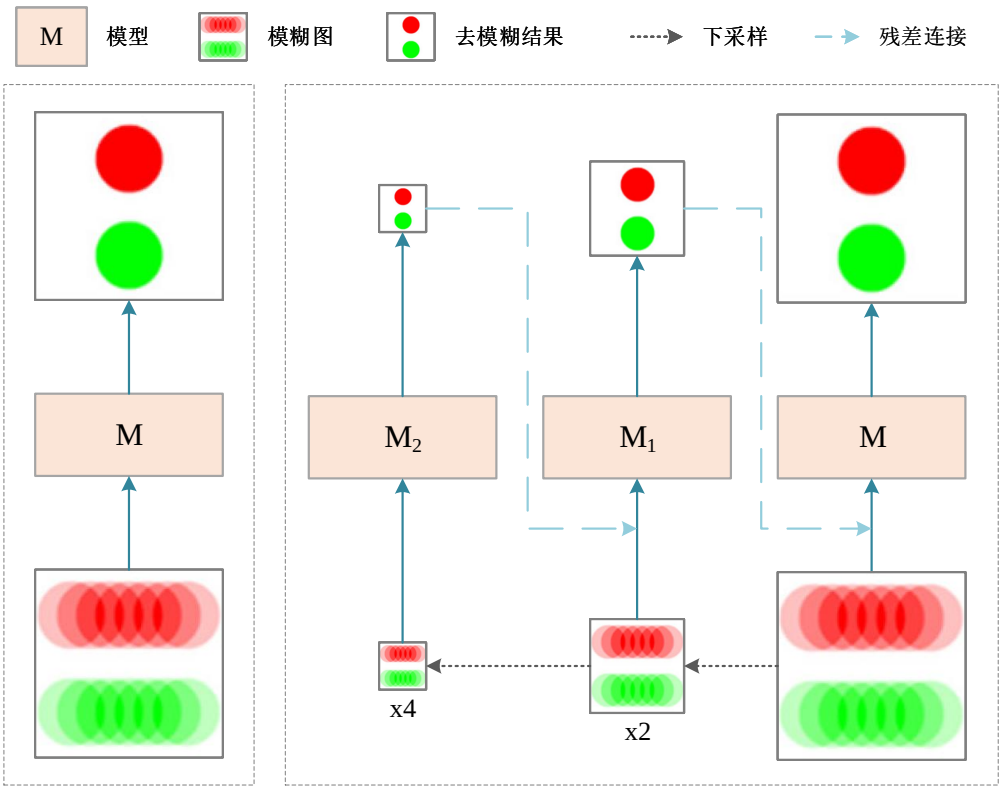
2.3.1 基于 CNN 的全监督方法

基于卷积神经网络（CNN）的全监督学习是图像去模糊领域的主导方法，相比于传统方法，其核心优势在于能够直接构建从模糊到清晰图像的映射关系。这类方法利用大规模标注数据集进行训练，在处理复杂模糊场景时表现出优异的效果。从网络架构设计角度，基于 CNN 的全监督方法主要分为两大类：端到端方法和多尺度方法，图2.8展示了端到端方法和经典多尺度方法的基本流程对比。

（1） 端到端方法

端到端的图像去模糊方法直接构建模糊到清晰图像的映射关系，无需中间环节，整个过程在统一的网络架构中完成[9-10,55-64]。早期的端到端去模糊网络主要关注如何构建有效的 CNN 架构来学习模糊与清晰图像之间的映射关系。Sun 等人[55]开创性地将 CNN 应用于非均匀运动模糊的去除，通过学习块级的运动模糊概率分布，并结合马尔可夫随机场进行密集非均匀运动模糊场推断，实现了对复杂非均匀运动模糊的去除。此后，任静静等人[62] 提出了一种快速 CNN 模型，通过傅里叶域预处理和小块图像训练，有效保留了高频纹理信息同时降低了计算复杂度。

中国知网　https://www.cnki.net



（a）端到端方法　　（b）经典多尺度方法

图 2.8　端到端方法和经典多尺度方法流程对比

Fig. 2.8　Comparison of workflow between end-to-end and classical multi-scale methods

随着研究的深入，生成对抗网络（Generative Adversarial Networks, GAN）[65]被引入图像去模糊领域，为端到端方法带来了新的突破。Kupyn 等人[9] 提出的 DeblurGAN 采用条件 GAN 和内容损失进行学习，在结构相似性和视觉效果方面达到了当时的最佳水平，同时处理速度比以往方法快 5 倍。随后，Kupyn 等人[10]进一步优化设计了 DeblurGAN-V2，采用了特征金字塔网络和双尺度判别器架构，在性能与效率之间实现了良好平衡，特别是在轻量级骨干网络配置下，可以实现接近实时的视频去模糊处理。

近年来，研究者们致力于提高端到端去模糊方法的性能和效率。Tsai 等人[59]提出了模糊感知注意力网络 BANet，通过区域自注意力机制和级联并行扩张卷积来聚合多尺度内容特征，实现了实时去模糊。Chen 等人[60] 则从简化模型的角度出发，构建了一个摒弃非线性激活函数的网络结构 NAFNet，该方法显著降低了计算负担，同时性能超越了当时领先的方法。最近，Mao 等人[61] 提出的自适应补丁退出可逆解码器 AdaRevD 进一步推动了图像去模糊的性能上限，通过继承训练好的编码器权重并重构可逆解码器，实现了更强大的解码能力。

总体而言，端到端的图像去模糊方法通过不断改进的网络架构、损失函数和训练策略，大幅提升了去模糊性能，同时也在效率、泛化能力和实时处理能力方面取得了显著进展。

中国知网　https://www.cnki.net

（2） 多尺度方法

在基于深度学习的图像去模糊研究中，多尺度算法相比端到端方法通常具备更复杂的网络结构以及更长的推理时间[8,11,66-76]。经典的多尺度方法是一类通过跨越不同尺度对图像模糊进行处理的关键技术分支[8,11,66,70]，这些方法通常结合了传统的“从粗到细”（coarse-to-fine）思想，通过分层逐步复原清晰图像，或者采用其他多尺度结构以实现更高效、更精确的去模糊目标。值得注意的是，为便于和端到端方法的最简形式区分，本章在经典多尺度的基础上将其他的代表性相对复杂的技术，如多分块[67,69]，多分支[71] 等，归入多尺度方法。

多尺度方法的研究起源于传统的能量优化方法，这些方法假设模糊核部分均匀或局部线性，限制了其对非均匀模糊场景的表现。以此为背景，Nah 等人[8] 提出了一种深度多尺度卷积神经网络 DeepDeblur，该模型能够端到端地处理由多种因素引起的模糊，并依赖新构建的大规模真实模糊数据集以优化模型性能。在实验中，该方法实现了动态场景去模糊的 SOTA 效果，显著提升了处理复杂模糊的能力。另一方面，Tao 等人[66] 进一步发展了“从粗到细”策略，推出了一种基于尺度递归的网络 SRN。该模型通过在金字塔式的尺度上逐层递归复原图像，其核心目标在于简化网络结构和参数量，同时提升训练效率。多尺度的递归框架在主流去模糊数据集上表现出优于端到端模型的定性和定量性能。

近几年的研究表明，多阶段结构对于逐步移除图像模糊颇具成效。Zamir 等人[69] 提出了 MPRNet，展示了多级架构如何通过逐层学习复原功能并利用全新信息交换策略来加强不同阶段之间的协作。同时，其引入像素级自适应设计，既保留了局部细节，又捕获混合的上下文信息。这种协作方法不仅适用于去模糊任务，还提供了良好的图像降噪和去雨效果。针对多尺度方法固有的高模型复杂度和推理时延问题，Cho 等人[11] 重新思考了粗到细方法，提出了基于 U-Net[77] 的轻量型多输入多输出架构 MIMO-UNet，单个编码器接收多尺度输入，单个解码器输出多尺度去模糊图像，并通过非对称特征整合技术高效地融合多尺度特征信息。此外，Kim 等人[72] 通过深入分析现有方法的局限性，提出了多尺度阶段网络 MSSNet。该网络通过模糊尺度自适应的阶段配置、跨尺度信息传递机制以及像素重组的多尺度处理方案，有效地克服了当前方法面临的各种技术挑战。

从频域的角度而言，针对传统 ResBlock[78] 在捕获低频信息和建模长距离信息方面的不足，Mao 等人[70] 提出了基于傅里叶变换的残差块，该模块能同时捕获长短期交互，并集成高低频残差信息，基于 MIMO-UNet 架构的深度残差傅里叶变换 DeepRFT 框架在多个数据集上取得显著提升。2023 年，Dong 等人[73] 提出了多尺度残差低通滤波网络 MRLPFNet，发现模糊图像与清晰图像之间的差异不仅包含高频内容还包含低频信息，通过基于自注意力机制的可学习低通滤波器自适应探索全局上下文，更好地建模了低频信息。

中国知网 https://www.cnki.net

多尺度方法已逐渐从单纯的“从粗到细”优化结构过渡到更高效的混合模型，结合了递归网络、空间注意以及自适应机制，从而在提升模型性能的同时有效降低了计算成本。这些改进使得多尺度方法成为图像去模糊领域的重要组成部分，其潜在的研究方向包括更轻量化的结构设计以及增强对各种模糊模式的泛化能力等。

2.3.2 基于其他架构的全监督方法

除卷积神经网络架构之外，研究者们也深度探索了其他网络架构在图像去模糊任务中的应用。这些架构凭借其独特的结构特性和信息处理能力，为图像去模糊领域带来了新的解决思路和技术突破。基于循环神经网络、Transformer、扩散模型和最近兴起的 Mamba 等架构的方法各具特色，在不同场景下展现出独特的优势和应用前景。

（1） 基于 RNN 的方法

循环神经网络（Recurrent Neural Networks, RNN）凭借其处理序列数据的独特能力，被研究人员广泛应用于图像和视频去模糊任务。基于 RNN 的去模糊方法的关键思想是利用 RNN 能够捕获时间依赖性的特点，在空间或时间维度上进行特征信息的迭代处理，实现模糊图像的高质量复原。[79-84]。

早期的基础性工作中，Zhang 等人[79] 和 Ren 等人[81] 提出空间变化循环神经网络架构，专门针对动态场景中的图像去模糊问题。该架构创新性地结合了三个卷积神经网络与一个循环神经网络，其中 RNN 模块作为特征图上的反卷积运算单元，能够隐式建模具有空间变化特性的去模糊过程。这种设计使网络能够有效处理由相机抖动和不同场景深度下的物体运动引起的空间变化模糊，即使模型规模较小，也能获得较大的感受野。特别是，Ren 等人进一步拓展了这一思路，开发了一维和二维 RNN 以更好地利用空间变化 RNN 的特性。

针对视频去模糊任务，Nah 等人[83] 提出了具有帧内迭代的循环神经网络。该方法通过迭代更新从过去帧传输的隐藏状态，使帧间关系能够被更好地利用，显著提高了去模糊精度。其创新之处在于重复使用 RNN 单元参数进行隐藏状态更新，而无需额外模块，实现了实时视频去模糊。此外，Park 等人[82] 探索了一种多时间（Multi-temporal）方法，通过利用高速相机捕获的时间分辨去模糊数据集，将严重的模糊现象分解为一系列较小的模糊，并在原始空间尺度上逐步去除模糊。这种方法可视为一种广义上的课程学习，使多种最先进的基于多尺度方法取得了改进性能。

总体而言，基于 RNN 的图像和视频去模糊方法从最初的空间变化 RNN 设计，到后来的帧内迭代策略、多时间方法以及多尺度双向传播技术，展现了该领域的迅速发展。研究重点逐渐从提高模型的表示能力转向提升时空信息整合效率以及降低计算成本，为复杂场景的实际应用提供了重要支持。

中国知网　https://www.cnki.net

（2） 基于 Transformer 的方法

随着 Transformer[85] 在自然语言处理领域取得的巨大成功，研究者们开始将其引入计算机视觉中[86]。Transformer 凭借其强大的长程依赖建模能力，在计算机视觉任务中的全局信息方面展现出独特优势，弥补了传统卷积神经网络结构感受野有限的不足[87-94]。

Liang 等人[87] 开创性地将 Transformer 架构应用于图像复原领域，并开发出 SwinIR 模型。该方法以 Swin Transformer[95] 为基础，通过采用窗口自注意力机制，有效降低了算力消耗，同时维持了出色的图像复原质量。Chen 等人[88] 构建了一种基于 Transformer 的预训练图像处理框架 IPT，该框架利用 ImageNet 构造大规模匹配数据集进行预训练，并设计了多头多尾结构，使模型能够灵活应对多种图像复原任务，如去噪、超分辨和去雨等。

针对计算效率问题，Zamir 等人[90] 提出了 Restormer，这是一种专为高分辨率图像复原设计的高效 Transformer 模型。通过对多头注意力机制和前馈网络核心结构的革新，Restormer 能够有效捕获远距离像素间的关联，并保持对大尺寸图像的适应性。类似地，Wang 等人[91] 提出了 U 形结构的 Transformer 网络 Uformer，该网络引入了局部增强窗口（LeWin）Transformer 模块和可学习的多尺度复原调节器，在减少计算资源消耗的同时，有效整合了局部细节和全局语义信息。Tsai 等人[89] 开发了首个专门针对去模糊任务的基于 Transformer 架构的经典去模糊方法——Stripformer，该方法构建了条内和条间注意力层，能够捕捉不同方向和强度的模糊模式。这种条状设计在保持高性能的同时，显著降低了计算成本。

近期的研究更多地关注频域处理与 Transformer 的结合。Kong 等人[93] 提出了一种基于频域的高效 FFTFormer，通过在频域中实现自注意力机制，将矩阵乘法转换为元素级乘法，大幅降低了计算复杂度。另外，Mao 等人[94] 提出了局部频域 Transformer——LoFormer，在频域中引入局部通道自注意力，同时处理低频和高频局部窗口内的互协方差，确保粗粒度结构和细粒度细节都能得到充分学习，有效解决了局部自注意力与全局建模之间的权衡问题。

综上所述，基于 Transformer 的图像去模糊方法正朝着更高效、更专业化的方向发展，通过各种设计优化和域知识融合，不断提升模型性能并降低计算成本，为实际复杂场景提供了更加实用的解决方案。

（3） 基于扩散模型的方法

扩散模型[96-99] 作为一种新兴的生成模型，近年来在图像去模糊领域展现出显著的潜力，其强大的生成能力为解决图像去模糊这一病态逆问题提供了新思路[100-108]。与传统方法和早期深度学习方法不同，扩散模型能够为模糊图像生成多种合理的清晰结果，更符合现实中图像去模糊的本质特性。

扩散模型在图像去模糊领域的应用始于 Whang 等人[100] 提出的条件扩散模型

中国知网 https://www.cnki.net

框架。该方法打破了传统去模糊方法只生成单一确定性结果的局限，采用“预测-优化”的方式，通过随机采样生成多样化的可能重建结果，显著提高了感知质量。这种方法不仅挑战了广泛使用的确定性重建策略，还实现了在保持较高 PSNR 等失真指标的同时，大幅提升感知质量。随后，Zhu 等人[101] 提出了 DiffPIR，将传统的即插即用方法与扩散采样框架相结合，进一步挖掘了扩散模型作为生成去噪先验的潜力，并在多种图像复原任务中展现了卓越的性能。

近期研究进一步探索了扩散模型与现有技术的融合可能。Wu 等人[105] 提出了基于隐式扩散的重模糊增强 ID-Blau 方法，通过生成多样化的模糊图像来增强训练数据，有效改善了现有去模糊模型的性能。Kong 等人[107] 则提出了潜在核预测网络，通过与条件扩散共同训练，学习空间变化的核来指导清晰图像在潜在空间的复原，增强了模型的去模糊效率和细节重建质量。此外，Liang 等人[108] 提出了较轻量级的 Adapter，有效利用预训练模型的强大生成能力，实现真实世界图像的高质量复原，为扩散模型在图像去模糊领域的实际应用提供了新的可能性。

基于扩散模型的图像去模糊方法代表了当前该领域的前沿研究方向。这类方法通过生成式建模思路有效解决了传统确定性方法在感知质量和多样性上的不足，但同时也面临计算效率、泛化能力和细节保留等挑战。近年来的研究在提升采样效率、加强结构引导和轻量化设计等方面取得了显著进展，逐步推动了扩散模型在图像复原和去模糊领域逐步走向实用化。

（4） 基于 Mamba 的方法

Mamba 架构[109] 是一种基于选择性结构状态空间模型（State Space Model, SSM）的创新设计，自 2024 年以来，基于 Mamba 架构的方法受到了广泛关注[110-116]。Mamba 模型在保持线性计算复杂度的同时能够建模长程依赖，为解决 CNN 和 Transformer 在全局感受野与计算效率之间的权衡困境提供了新思路。

Guo 等人[110] 提出的 MambaIR 是将 Mamba 模型应用于图像复原任务的先驱工作，该方法通过引入局部增强和通道注意力机制来改进原始 Mamba 模型，有效解决了标准 Mamba 在低层次视觉任务中面临的局部像素遗忘和通道冗余等挑战。与此同时，Gao 等人[111] 针对图像去模糊任务设计了一种聚合局部和全局信息的框架 ALGBlock，该框架通过结合选择性状态空间模型捕获全局特征，同时利用简化的通道注意力机制模拟局部连通性，进一步增强了特征表达能力。

为了进一步增强 Mamba 在图像复原中的性能，研究者们开始探索多方向感知和混合架构的应用。Shi 等人[114] 提出的 VmambaIR 通过设计全方位选择性扫描模块，有效克服了 SSM 的单向建模限制，该方法高效地建模了六个方向上的图像信息流，更好地利用了周围的复原信息。Peng 等人[116] 则关注到图像中不同区域的纹理复杂度与退化程度的关系，提出了纹理感知状态空间模型 TAMambaIR，通过调制状态空间方程的转移矩阵并聚焦于复杂纹理区域，在提高效率的同时增强了

中国知网　https://www.cnki.net

纹理感知能力。

除了单一架构的改进，研究人员也尝试将 Mamba 与其他成熟技术相结合。Luan 等人[113] 提出的 FMambaIR 将傅立叶变换与 Mamba 相结合，利用频域和空间域信息的互补性进行图像复原，有效感知全局退化特征。Wen 等人[115] 则设计了名为 MatIR 的 Mamba-Transformer 混合图像复原模型，通过交叉循环 Transformer 层和 Mamba 层提取特征，充分发挥两种架构的优势，其中引入的图像修复状态空间模块沿四条扫描路径遍历，显著提高了对长序列数据的处理效率。

总体而言，基于 Mamba 的图像去模糊方法凭借其线性计算复杂度和强大的长程依赖建模能力，为图像去模糊领域带来了新的研究范式。通过多方向扫描策略、纹理感知机制以及与其他架构的混合应用等创新，这些方法有效解决了传统模型在感受野和计算效率之间的权衡问题，展现出广阔的应用前景。

2.3.3 自监督和无监督方法

随着深度学习技术的不断发展，全监督方法在图像去模糊领域取得了显著成就。然而，获取大量高质量的模糊-清晰图像对仍然是一个严峻的挑战，这促使研究者们探索其他解决方案，以减少对标注数据的依赖。极少数的方法利用半监督学习[117] 方法实现图像去模糊，降低了对配对数据的依赖并尽可能保持去模糊效果。自监督和无监督方法则完全摒弃了成对数据的需求，通过探索图像内在特定，利用对抗学习、循环一致性约束等技术实现图像去模糊。

（1） 自监督方法

自监督方法通过利用退化图像本身作为监督信号训练模型[118-122]。早期的研究如 Chen 等人[118] 提出了 Reblur2deblur 框架，该方法通过自监督学习方式微调现有的去模糊网络，强制要求网络输出的清晰图像在基于光流再模糊后应当与原始模糊图像匹配。这种创新的方法巧妙地将光流信息引入自监督学习过程，有效地提高了去模糊性能，特别是在真实场景的视频去模糊任务中表现出色。该工作展示了如何利用视频序列中固有的时间一致性来改进去模糊效果，为后续的自监督去模糊研究开辟了新方向。

在解决真实世界光照不足环境下拍摄问题时，Zhang 等人[119] 提出了一种协作式自监督学习框架，同时利用短曝光噪声图像和长曝光模糊图像进行图像复原。该方法巧妙地利用了短曝光图像几乎没有模糊而长曝光图像噪声可忽略的互补特性，使去模糊和去噪任务能够相互促进。这种方法不需要清晰的参考图像作为监督信号，而是通过短曝光图像为去模糊提供监督，长曝光图像中的清晰区域则为去噪提供辅助监督，实现了高效的自监督学习。

更近期的研究进一步推动了自监督图像去模糊的边界。Jiang 等人[120] 提出了一种不确定性感知变量分解方法，通过将传统模糊函数公式化为多个变量的组合，

中国知网 https://www.cnki.net

从而精确刻画了模糊与清晰图像间的残差特征关系。该方法采用多步自监督去模糊框架，通过持续分解和组合输入图像，利用模糊伪影的不确定性生成多样化的伪模糊-清晰图像对用于自监督学习，有效解决了收敛慢的问题。

针对真实世界中空间变化的模糊核估计挑战，Fang 等人[122] 提出了一种基于流的运动先验的自监督非均匀核估计方法。该方法通过归一化流将运动模糊核场表示在潜空间中，设计 CNN 预测潜在编码而非直接预测运动核，并引入不确定性学习提高非均匀核估计的精度和鲁棒性。这种方法在实际应用中展现出卓越的性能和泛化能力，特别是在处理真实世界非均匀模糊图像时。

总体来看，这些自监督方法的共同特点是通过巧妙设计的框架将退化图像本身训练模型，在合成和实际场景中展现了其强大的适应性与应用潜力。

（2） 无监督方法

无监督图像去模糊方法利用非配对的数据进行去模糊，避免了真实场景中获取模糊-清晰图像对的困难问题[123-129]。这类方法依赖于不同领域的生成对抗网络、循环一致性损失、特征分离与重构等技术来解决无配对样本和缺少标注数据的问题，逐步摆脱对大量标注数据的依赖，展现出强大的潜力和灵活性。

早期的无监督图像去模糊研究主要受益于跨域图像转换技术的进步。2017 年，Yi 等人[123] 提出了 DualGAN 架构，通过构建原始 GAN 和对偶 GAN 形成闭环，实现了从模糊域到清晰域的无监督转换。同期，Kim 等人[124] 开发的 DiscoGAN 能够在无配对数据条件下能够识别跨域关联，在进行风格迁移的同时保持图像核心特征。Zhu 等人[125] 提出了 CycleGAN，创新性地引入了循环一致性损失，有效解决了无监督映射中的欠约束问题，使生成的清晰图像不仅在视觉质量上接近目标域，还能在反向映射后与原始域图像保持一致，提高了不同域之间的转换可靠性。这些方法为无监督图像去模糊奠定了基础框架。

Nimisha 等人[126] 在 2018 年率先提出了一种无监督去模糊算法，设计了一种针对特定类别数据的端到端去模糊网络，通过 GAN 学习清晰图像域的先验分布，并引入再模糊模块和梯度模块来稳定训练过程。这种方法巧妙地利用了模糊图像本身作为自引导，通过尺度空间梯度误差约束了生成清晰图像的解空间，在不同类别的图像上展现出良好的去模糊效果。随后，Lu 等人[127] 通过解耦表示进一步推进了无监督去模糊的发展，他们将内容特征和模糊特征分离，并采用 KL 散度损失尽可能确保提取的模糊属性中不含有效内容信息，同时设计了模糊分支结构并结合循环一致性损失机制来提升特定领域数据下的无监督性能。

近期的无监督去模糊研究更加注重利用深度学习的特性来提高模型性能。Tang 等人[128] 针对模糊核不精确的问题，提出了一种基于深度残差先验的半盲去模糊方法，该方法不依赖于数据集，而是通过未经训练的深度神经网络表达核心误差的先验，结合了深度先验和手工设计先验的优势，展现出对不同类型核误

中国知网　https://www.cnki.net

差的鲁棒性。

总体而言，无监督图像去模糊技术从早期的基于 GAN 的域转换方法发展到如今的解耦表示和自增强策略，展现出了不断进步的趋势。这些方法在解决真实世界复杂模糊情况下表现出越来越强的适应能力，解决了对大量配对训练数据的依赖，从而有效缓解了实际复杂场景中数据获取的难题。

2.4 图像去模糊数据集

深度学习驱动的图像去模糊技术进步高度依赖于数据集。这些数据集为算法开发、训练与性能评估奠定了关键基础。目前图像去模糊领域的主要数据集如下：

表 2.1　去模糊数据集属性对比

Tab. 2.1　Comparison of deblurring dataset attributes

名称	训练样本数	推理样本数	分辨率	包含真值	所属领域	类型
GoPro[8]	2,103	1,111	1280×720	是	自然场景	合成
HIDE[130]	6,397	2,025	1280×720	是	人物运动	合成
CelebA[131]	-	-	178×218	是	人脸	合成
RealBlur-J[132]	3,758	980	不固定	是	自然场景	真实
RealBlur-R[132]	3,758	980	不固定	是	自然场景	真实
RWBI[57]	0	3,112	不固定	否	自然场景	真实

2.4.1 合成模糊数据集

（1） GoPro 数据集

GoPro 数据集[8] 是目前去模糊研究领域的重要大规模动态场景模糊数据集，也是去模糊领域最主要的数据集。该数据集包含 3,214 张高分辨率模糊图像，通过对高速摄影机拍摄的短视频序列进行平均合成得到模糊图像。GoPro 数据集分为训练集（2,103 张）和测试集（1,111 张），图像分辨率为 1280×720 像素，覆盖了多种日常场景，包括纹理复杂的街景和各类建筑场景等。

（2） HIDE 数据集

HIDE（Human Instances in Diverse Environments）数据集[130] 专注于人物运动模糊场景，包含 8,422 对模糊-清晰图像对。该数据集特别关注人物运动引起的模糊，为人像去模糊研究提供了专门的数据支持。

（3） CelebA 数据集

CelebA 数据集[131] 是一个包含超过 20 万张高分辨率人脸图像的大型数据集。CelebA 数据集虽然不是专门为去模糊任务创建的，但它在一些研究中被用来生成合成模糊图像[127]，为便于描述，本文仍用 CelebA 代表该数据集。例如，类似于 DeblurGAN[9] 中引入的模糊合成方法，可以对 CelebA 数据集进行处理，生成带有运动模糊或其他模糊效果的图像，为去模糊任务提供训练和验证的数据。

中国知网 https://www.cnki.net

2.4.2 真实模糊数据集

（1） RealBlur 数据集

RealBlur 数据集[132] 是一个大规模的真实世界模糊图像数据集。该数据集通过特殊的摄影设备同时捕获模糊图像和对应的清晰参考图像，确保了真实模糊场景下的准确对齐。RealBlur 数据集分为 RealBlur-J（由 JPEG 图像组成）和 RealBlur-R（由原始图像组成）两个子集，总共包含约 4,000 对模糊-清晰图像对应样本。数据采集范围广泛，囊括了多种室内外场景，以及不同的光照条件和模糊程度。

（2） RWBI 数据集

RWBI（Real-World Blurry Images）数据集[57] 收集了大量真实世界中的模糊图像，这些图像均来自于实际拍摄场景中的自然模糊，而非人工合成。RWBI 数据集包含 3,112 张真实模糊图像（没有对应的清晰参考图像），覆盖了常见的模糊类型，包括运动模糊、散焦模糊以及混合模糊等多种形式。

2.5 图像去模糊评价指标

在图像去模糊研究中，评价指标对于客观衡量算法性能至关重要。这些定量指标通常可分为客观评价指标与主观评价指标两大类。前者基于数学模型，后者依赖人类视觉感知。

2.5.1 客观评价指标

（1） 峰值信噪比（PSNR）

峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）是图像质量评估领域中一种广泛应用的客观指标。它通过量化去模糊图像与参考图像之间的像素值差异来评价图像重建的效果，通常以均方误差（Mean Squared Error, MSE）为基础进行计算。从数值上看，PSNR 数值越大，意味着图像复原质量越优。PSNR 的计算表达式为：

$$\mathrm{PSNR} = 10 \cdot \log_{10}\left(\frac{MAX_I^2}{MSE}\right), \tag{2.8}$$

其中，MAX_I 是图像的最大可能像素值（例如：8 位图像为 255），MSE 代表均方误差：

$$\mathrm{MSE} = \frac{1}{m \times n}\sum_{i=0}^{m-1}\sum_{j=0}^{n-1}[I(i,j) - K(i,j)]^2, \tag{2.9}$$

其中，I 和 K 分别代表参考图像和去模糊图像，m 和 n 是图像的高度和宽度。尽管 PSNR 计算简单直观，但它基于像素级差异，无法很好地反映人类视觉系统对图像质量的感知，特别是在评估纹理和细节复原方面存在局限性。

中国知网　https://www.cnki.net

（2） 结构相似性（SSIM）

结构相似性指标（Structural Similarity Index, SSIM）[133] 基于人眼对图像结构信息具有较高敏感度的原理，从亮度、对比度及结构三个维度综合评估图像相似性。SSIM 的计算表达式如下：

$$\mathrm{SSIM}(x,y)=\frac{(2\mu_x\mu_y+C_1)(2\sigma_{xy}+C_2)}{(\mu_x^2+\mu_y^2+C_1)(\sigma_x^2+\sigma_y^2+C_2)}, \tag{2.10}$$

其中，μ_x 和 μ_y 是图像 x 和 y 的平均值，σ_x^2 和 σ_y^2 是对应图像的方差，σ_{xy} 两图像间的协方差，C_1 和 C_2 是用于避免分母为零的小常数。

SSIM 的数值范围在-1 到 1 之间，数值越高表示相似度越高。在实际操作中，通常通过滑动窗口技术计算图像局部区域的 SSIM 值，并取其平均值作为整幅图像的 SSIM 指标。相较于 PSNR，SSIM 因更贴近人类视觉感知，能够更精准地反映图像的视觉质量。

（3） 感知图像块相似性（LPIPS）

感知图像块相似性（Learned Perceptual Image Patch Similarity, LPIPS）[134] 采用深度学习框架来量化视觉感知差异。不同于传统的度量方式，它利用预训练神经网络（如 AlexNet[135]、VGG[136] 或 ResNet[78]）提取图像特征，然后计算特征空间中的距离，这种方法更接近人类对图像差异的感知。LPIPS 的计算公式可表示为：

$$\mathrm{LPIPS}(x,y)=\sum_l\frac{1}{H_lW_l}\sum_{h,w}\left\|\omega_l\odot\left(F_l^x(h,w)-F_l^y(h,w)\right)\right\|_2^2, \tag{2.11}$$

其中 F_l^x 和 F_l^y 分别是图像 x 和 y 在网络第 l 层的特征图，ω_l 是第 l 层的权重向量，$\odot$ 表示逐元素乘法，H_l 和 W_l 是特征图的高度和宽度。

LPIPS 数值越接近零，表明两幅图像在感知层面上的差异越小。相比于 PSNR 和 SSIM，LPIPS 能更好地捕捉人类视觉系统对纹理、边缘和语义内容的敏感度，也十分适用于评估模型的输出质量。

（4） 自然图像质量评估器（NIQE）

自然图像质量评估器（Natural Image Quality Evaluator, NIQE）[137] 是一种无参考（无需原始清晰图像）的图像质量评价指标。NIQE 基于自然场景统计（Natural Scene Statistics, NSS）模型，通过学习高质量自然图像的统计特征来构建质量感知模型。NIQE 的计算过程包括以下步骤：1）从待评估图像中提取局部块；2）计算每个块的 NSS 特征；3）将提取的特征与预先训练好的自然图像模型进行比较。NIQE 的得分计算公式如下：

$$\mathrm{NIQE}(x)=\sqrt{(\nu_x-\nu_n)^T\left(\frac{\Sigma_x+\Sigma_n}{2}\right)^{-1}(\nu_x-\nu_n)}, \tag{2.12}$$

中国知网 https://www.cnki.net

其中 ν_x 是待评估图像 x 的 NSS 特征均值向量，ν_n 是自然图像模型的 NSS 特征均值向量，Σ_x 是待评估图像 x 的 NSS 特征协方差矩阵，Σ_n 是自然图像模型的 NSS 特征协方差矩阵。

NIQE 得分越低，表示图像质量越高。作为无参考指标，NIQE 在没有原始清晰图像的情况下特别有用，如实际应用场景中的盲图像去模糊。但需注意的是，由于 NIQE 主要基于自然图像统计规律构建，对于特定类型图像的评估可能存在准确度不足的局限性。

2.5.2 主观评价指标

平均意见分数（Mean Opinion Score, MOS）是当前图像处理领域中最常用的主观评估指标，它通过收集多位评估者对图像质量的打分，然后取平均值来量化主观质量感知。MOS 评分通常采用以下步骤进行：1）准备评估环境：控制显示设备、观看距离、环境照明等因素，确保评估条件的一致性；2）选择评估者：招募足够数量（通常为 15-30 人）的评估者，应包括不同背景和专业水平的人员；3）评分标准：通常采用 5 分制或 9 分制评分系统；4）评分收集：向评估者展示去模糊图像，可能同时展示或不展示原始清晰图像作为参考，然后收集评分；5）数据处理：计算平均分数并进行统计分析。MOS 的计算公式如下：

$$\mathrm{MOS} = \frac{1}{N}\sum_{i=1}^{N} S_i, \tag{2.13}$$

其中，N 是评估者总数，S_i 是第 i 位评估者的评分。

MOS 评分的优势在于直接反映人类对图像质量的感知，能够捕捉到可能被客观指标忽略的细微质量差异。然而，MOS 评分也存在以下局限性：1）主观性：不同评估者对同一图像的评分可能存在差异；2）成本高：需要招募多位评估者，耗时且成本高；3）不可重复性：难以完全复现评估条件和结果；4）疲劳效应：长时间评估可能导致评估者疲劳，影响判断准确性。

2.6 本章小结

本章系统梳理了图像去模糊的研究现状，从传统方法到深度学习方法的演进历程。首先回顾了传统图像去模糊技术，包括基于滤波、正则化和稀疏表示等经典方法，分析了它们的原理、优势与局限性。随后重点探讨了基于深度学习的图像去模糊方法，涵盖了 CNN、RNN、Transformer 等架构的创新应用，展示了深度学习在处理复杂模糊场景时的显著优势。同时，本章还具体介绍了常用的图像去模糊数据集，包括合成与真实模糊数据集的特点与适用场景，为相关研究提供了数据基础。在评价体系方面，全面阐述了客观评价指标（如 PSNR、SSIM 等）与主观评价指标的应用方法与适用条件，为算法性能的科学评估提供了依据。

中国知网　https://www.cnki.net

第三章 基于模糊偏移估计的无监督图像去模糊方法

配对数据驱动的深度监督方法相比传统方法展现出独特的优势，然而，从特定分布（或领域）获取高质量配对数据成本很高，而且基于配对数据驱动的模型也很难推广到所有领域的模糊图像。这些局限性促使无监督去模糊方法的兴起。现有无监督方法的处理结果和原始图像之间存在较大的色差，这直接不仅带来了较差的视觉体验还直接降低了去模糊性能。为解决这一问题，本章提出了一种新型的无监督色彩保持网络（Color Retention Network, CRNet）。所提出的方法主要基于模糊偏移估计（Blur Offset Estimation, BOE）这一创新机制，具体而言，模糊偏移估计学习从模糊图像到运动偏移的映射，而非直接建立模糊到清晰图像的映射关系。然后基于学习到的运动偏移，即可对模糊图像执行自适应模糊校正（Adaptive Blur Correction, ABC）以复原清晰图像。模糊偏移估计和自适应模糊矫正的引入避免了端到端训练带来的色彩崩溃问题，从而最大程度地保持原始图像的色彩信息。为了进一步有效地保持色彩信息并提取模糊模式，本章还引入了一个新的模块，称为金字塔全局模糊特征感知（Pyramid Global Blur Feature Perception, PGBFP）。为了定量证明所提出的网络在色彩保持方面的有效性，本章还提出了一种符合人类感知的新型色差量化指标——色敏差（Color-Sensitive Error, CSE）。在多个数据集上的大量的定量和可视化实验表明，所提出的 CRNet 在无监督去模糊任务中可以获得最先进的去模糊和色彩保持性能。

3.1 本章概述

运动模糊现象在日常图像采集中普遍存在。当使用手持设备拍摄或捕捉快速移动目标时，由于相机抖动或物体运动，所获图像常呈现运动模糊特性。图像去模糊作为一种从模糊图像中消除伪影并恢复潜在清晰图像的技术过程，已在计算机视觉、医学影像及遥感等多领域引起广泛关注。传统去模糊算法通常涉及复杂的数学模型与迭代优化过程[21,36]，计算效率低下且对噪声敏感。随着深度神经网络技术的迅猛发展，基于深度学习的去模糊方法克服了传统方法的固有局限，并在多样化图像处理任务中展现出卓越的泛化能力。基于全监督学习范式的深度去模糊模型依托大规模模糊-清晰图像对训练集及深度神经网络的强大表征能力，在客观评价指标与主观视觉质量方面均实现了显著突破[8-10,58,69]。然而，此类方法面临两个根本性挑战：首先，特定应用领域的配对数据获取成本极高，需要精确的图像采集与配准技术；其次，基于配对数据训练的深度模型在跨域模糊场景中表现出泛化能力有限，难以适应复杂多变的实际应用环境。

无监督去模糊方法为解决上述问题提供了理论可行路径，但在处理自然图像时仍存在显著障碍，这主要源于自然图像内容与细节的固有复杂性。当前无监督

中国知网 https://www.cnki.net

模型普遍采用端到端架构直接生成清晰图像，过度强调纹理与边缘清晰度恢复而忽视色彩保真度，导致训练过程中关键色彩信息的严重损失，最终降低整体视觉体验质量。值得注意的是，即便采用配对数据训练的监督模型也程度不一地受到色差问题的影响。如图3.1（a）所示，现有无监督去模糊方法的处理结果普遍呈现明显色差。为解决这一问题，本章设计了一种无监督的色彩保持网络，可以在实现无监督去模糊的同时保持图像的原始色彩，如图3.1（c）所示。此外，值得注意的是，色差现象呈现出独特的感知特性：当色差显著时，人类视觉系统能够轻易识别，但难以精确量化；而当色差相对轻微时，人眼对色彩变化的敏感度又显著下降。因此，探索并设计有效的色差评估机制，用于量化无监督去模糊模型的色彩还原能力，对于推动该领域理论与实践发展也具备重要学术价值与应用意义。

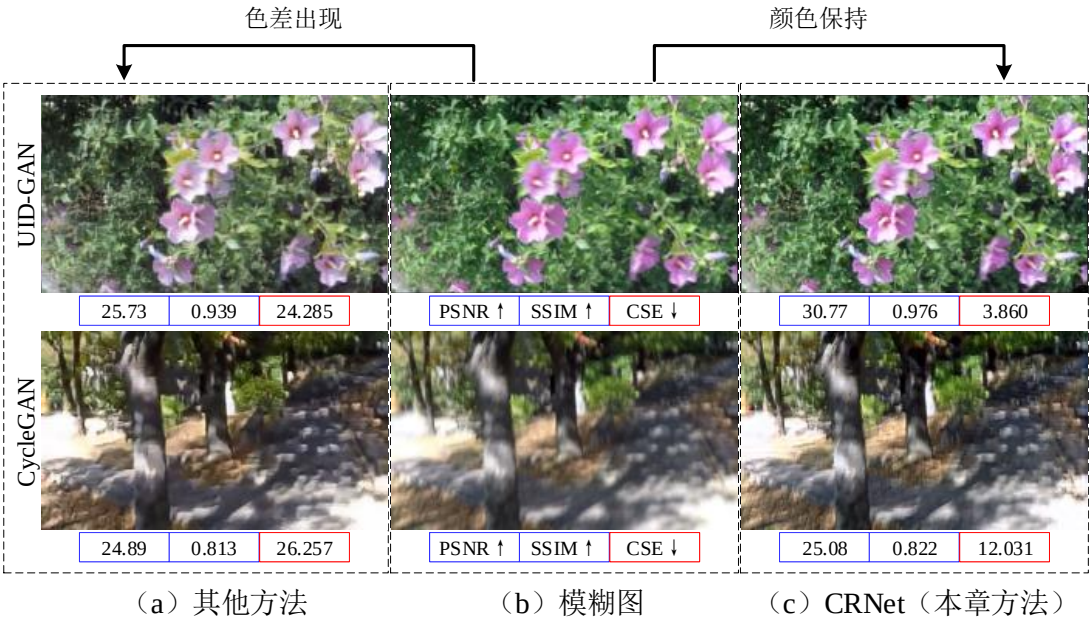


图 3.1　无监督去模糊方法色彩保持能力对比

Fig. 3.1　Comparison of color retention ability among unsupervised deblurring methods

本章提出一种针对无监督去模糊过程中色差问题的创新解决方案，同时建立了色差的有效量化方法。主要贡献如下：

- 无监督色彩保持网络（CRNet）的设计与实现。本章设计并实现了一种新颖的无监督色彩保持网络，该网络通过结合模糊偏移估计与自适应模糊校正方法，可有效保持图像中的色彩信息。CRNet 具备优异的领域适应能力，能够高效处理自然图像及特定领域图像。据调查，这是首次专门针对图像去模糊任务设计无监督色彩保持网络的研究。值得注意的是，本章提出的无监督色彩保持策略具有广泛的适用性，可扩展至其他存在色差问题的任务，如图像去雨、图像生成及基于图像转换的各类应用。
- 模糊偏移估计和自适应模糊矫正机制的设计与实现。为最大程度保持原始图

中国知网　https://www.cnki.net

像的色彩信息，本章提出一种新颖解决方案：首先学习从模糊图像到运动偏移的映射关系，随后利用获得的运动偏移执行自适应模糊校正以获得潜在清晰图像，从而有效保持色彩信息和细节特征。此外，本章设计了金字塔全局模糊特征感知（PGBFP）模块，用于感知非局部信息，进一步提升性能。

- 色敏差（CSE）评估指标的设计与实现。为量化色差并评估 CRNet 的色彩保持能力，本章基于颜色直方图引入了一种新型评估指标——色敏差。CSE 的客观评估结果与人类视觉感知高度一致，能够准确反映图像细节信息，相比广泛使用的 PSNR 和 SSIM 指标更为精确。值得强调的是，CSE 指标适用于评估无监督和全监督方法的色彩保持能力，具有广泛的应用前景。
- 实验验证与性能评估。大量实验结果验证了 CRNet 在整体复原性能和色彩保持方面的显著优势，尤其在复原图像细节特征方面表现卓越。在大量数据集上的测试有力支持了本章所提方法的实用价值和技术领先性。

3.2 相关工作和理论基础

图像去模糊相关的研究工作已经在第二章详细介绍，这里主要介绍和本章工作直接相关的相关工作和理论基础，包括：生成对抗网络基本原理、基于生成对抗网络的全监督去模糊方法以及基于生成对抗网络的无监督去模糊方法。

3.2.1 生成对抗网络基本原理

生成对抗网络（Generative Adversarial Networks, GAN）的核心思想来源于博弈论中的零和博弈（Zero-sum Game）理论。其基本架构由两个对抗性神经网络组成：生成器（Generator）：用于生成接近真实样本的虚假数据；判别器（Discriminator）：用于区分真实样本与生成的虚假样本。这两个网络形成了动态博弈系统，其中：生成器努力制造能够迷惑判别器的样本，而判别器则致力于准确辨别真伪样本。

从数学角度看，GAN 可以表述为一个极小极大博弈。设生成器为 G，判别器为 D，则 GAN 的目标函数可表示为：

$$\min_{G}\max_{D} V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}(x)}\left[\log D(x)\right] + \mathbb{E}_{z\sim p_z(z)}\left[\log\left(1 - D(G(z))\right)\right], \tag{3.1}$$

其中 $p_{\text{data}}(x)$ 代表真实数据的分布，$p_z(z)$ 是输入噪声的先验分布（通常是均匀分布或高斯分布），$G(z)$ 是生成器将噪声转换至数据空间的映射函数，$D(x)$ 是判别器输出样本为真实样本的概率。

GAN 训练采用交替进行模式：1. 训练判别器 D：固定生成器 G，最大化目标函数，提高 D 区分真假样本的能力：

$$\max_{D} V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}(x)}\left[\log D(x)\right] + \mathbb{E}_{z\sim p_z(z)}\left[\log\left(1 - D(G(z))\right)\right]; \tag{3.2}$$

中国知网 https://www.cnki.net

2. 训练生成器 G：固定判别器 D，最小化目标函数，提高 G 生成逼真样本的能力:

$$\min_G V(D,G) = \mathbb{E}_{z\sim p_z(z)}\left[\log\left(1 - D(G(z))\right)\right]. \tag{3.3}$$

在实际训练中，由于上述目标可能导致生成器梯度消失，通常在训练时将生成器的目标改为：

$$\max_G \mathbb{E}_{z\sim p_z(z)}\left[\log D(G(z))\right]. \tag{3.4}$$

从理论上讲，当 GAN 达到全局最优时，生成器能够完美模拟真实数据分布，即 $p_g = p_{data}$，此时判别器将无法区分样本真实与否，输出恒为 0.5。这表明博弈达到了纳什均衡点，两者都实现了各自策略的最优状态。

3.2.2 基于 GAN 的全监督方法

生成对抗网络（GAN）[65] 凭借其在图像生成领域的巨大成功，已成为深度去模糊模型研究的主要范式之一。当前主流的深度去模糊架构较多采用 GAN 作为基础框架。例如，Nah 等人[8] 提出的多尺度架构通过将小尺度图像与大尺度图像的上采样预测结果级联，作为下一尺度的输入，再结合 GAN 的对抗训练机制，有效保留了复原图像的细节。严格来说，Kupyn 等人设计的 DeblurGAN[9] 是首个显式基于 GAN 的端到端全监督去模糊模型，采用 WGAN-GP[138] 训练策略，实现了显著的去模糊效果。其改进版本 DeblurGAN-v2[10] 进一步引入特征金字塔网络（Feature Pyramid Network, FPN），并采用多种轻量级骨干网络（如 Inception-ResNet-v2[139] 和 MobileNetV2[140]），在降低模型计算复杂度的同时取得了更优异的性能。

3.2.3 基于 GAN 的无监督方法

然而，深度全监督去模糊网络的训练对大量标注数据的需求限制了其实用性，这些数据的获取往往困难且昂贵。为解决此问题，研究者们提出了多种基于 GAN 的无监督去模糊方法。Nimisha 等人[126] 首次提出专门针对去模糊任务的无监督 GAN 模型，该方法通过重模糊损失和多尺度梯度损失约束解空间，在合成数据集上展现出良好的效果。Lu 等人提出的 UID-GAN[127] 作为一种基于解耦机制的无监督去模糊模型，创新性地在模糊图像中分离内容属性与模糊属性，并在模糊编码器中引入 KL 散度损失，有效防止内容属性编码过程中混入模糊特征。此外，Yi 等人提出 DualGAN[123]，Kim 等人提出的 DiscoGAN[124] 以及 Zhu 等人提出的 CycleGAN[125] 虽然并非专为去模糊任务设计，但通过将清晰域（S-domain）与模糊域（B-domain）视为两个独立域，这些模型同样可以有效执行图像去模糊任务。DualGAN[123] 和 DiscoGAN[124] 的基本原理与经典 CycleGAN[125] 相似，但在生成器与判别器结构设计上各具特色，具备独特的优势。

中国知网　https://www.cnki.net

3.3 方法介绍

本章详细阐述 CRNet 的理论基础与架构设计，包括整体网络架构、色彩保持核心机制、损失函数等。

3.3.1 网络架构

CRNet 整体架构如图3.2所示，该架构由两个分支组成，分别是模糊分支和去模糊分支。其中，去模糊分支只主要功能分支，核心功能是执行去模糊任务，而模糊分支则通过对去模糊结果的辅助提升来优化整体性能。本章采用 A 和 B 表示未配对图像，并通过下标标识图像所属域。例如，A_S 和 B_S 代表清晰域（S-domain）中的未配对图像，而 A_B 和 B_B 则表示模糊域（B-domain）中的未配对图像。对于不需区分所属域的图像，统一使用 I 表示。

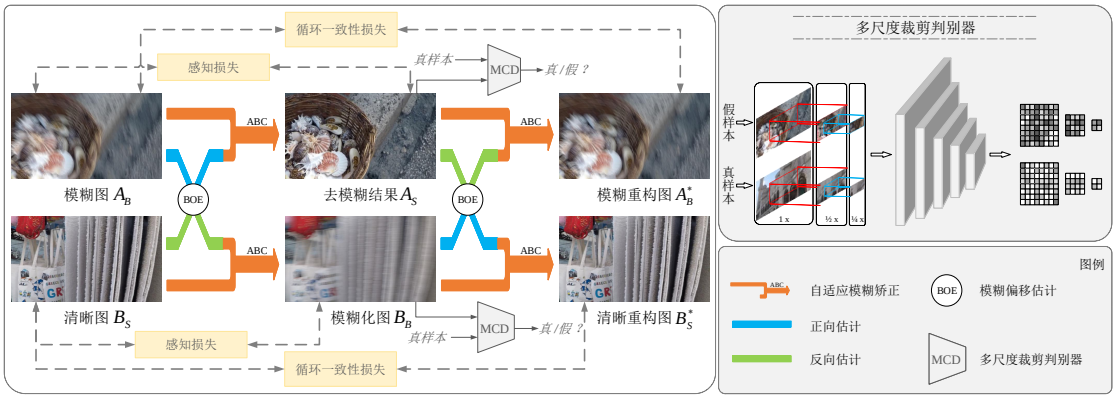


图 3.2　CRNet 模型结构示意图

Fig. 3.2　Structural diagram of the CRNet

CRNet 架构由三个核心组件构成：1）两个模糊偏移估计（BOE）子网络 G_{BS} 和 G_{SB}，分别用于处理模糊域和清晰域；2）自适应模糊校正（ABC）方案，用 F 表示；3）两个多尺度裁剪判别器 D_B 和 D_S，分别对应两个域。具体优化流程为：给定模糊图像 A_B 和清晰图像 B_S，G_{BS} 和 G_{SB} 分别生成相应的模糊偏移和逆模糊偏移。随后，自适应模糊校正方案 F 将模糊图像和清晰图像转换至对应的相反域。最终，D_B 和 D_S 负责区分各自域中的真实样本与生成样本。

值得强调的是，本架构在判别器设计上采用了创新性的多尺度方法。传统多尺度方法通常通过调整输入图像尺寸生成不同大小的图像，并基于此计算对抗损失。在此情境下，判别器仅可评估整体图像真实性，而忽略局部细节信息。这对去模糊任务而言存在局限性，因为人类视觉系统往往仅凭局部信息即可大概判断整体图像质量。因此，受注意力机制启发，本章提出了多尺度裁剪判别器（Multi-scale Cropping Discriminators, MCD）——传统多尺度判别器的改良版本。该方法通过裁剪减小图像尺寸，使判别器能够更精确地关注目标图像的局部细节特征。

本章提出的色彩保持网络（CRNet）通过模糊偏移估计和自适应模糊校正两个

中国知网　https://www.cnki.net

关键机制实现了有效的色彩保持。与传统无监督去模糊模型直接从模糊图像复原潜在图像的方法不同，CRNet 采用了“模糊图像 → 运动偏移（模糊偏移）→ 潜在图像”的创新处理路径。该方法首先建立从模糊图像到运动偏移的映射关系，继而基于获取的运动偏移参数，执行自适应模糊校正操作以重建潜在清晰图像。自适应模糊校正操作以原始图像为基础，在保持原始分辨率的条件下执行物理校正，无需额外的学习过程，从而有效避免了复原图像中可能出现的显著色差。同时，模糊偏移估计网络有效整合了自注意力机制，并引入了一种新的金字塔全局模糊特征感知（PGBFP）模块，用于捕获全局模糊信息，进一步增强了对图像色彩信息的保持能力。

3.3.2 模糊偏移估计网络

模糊偏移估计（Blur Offset Estimation, BOE）网络旨在通过设计深度神经网络从原始图像中获取模糊偏移信息。由于 CRNet 采用双分支结构，故 BOE 网络会根据不同输入生成相应的模糊偏移表示。如图3.3所示，BOE 网络由两个关键组件构成：金字塔全局模糊特征感知（PGBFP）模块和模糊偏移估计子网络。其中模糊偏移估计子网络在整个 BOE 阶段发挥核心作用，而 PGBFP 模块的结构设计需与子网络架构协同匹配。PGBFP 通过与不同尺度的子网络级联协作，共同完成模糊偏移的精确估计。为便于描述网络结构，本章引入级联层级（$\aleph$）的概念，用于表示 PGBFP 与子网络之间的信息交换频次。级联层级越高，信息交换越频繁。

（1） 金字塔全局模糊特征感知模块

卷积层作为卷积神经网络的核心组件，感受野不可避免地受到限制，导致其难以有效感知非局部信息，从而在某些任务中表现不佳。为克服这一局限性，SAGAN[141] 将注意力机制引入深度神经网络中。本章在此基础上提出金字塔全局模糊特征感知（Pyramid Global Blur Feature Perception, PGBFP）模块，专门用于学习全局模糊信息。与 SAGAN 的自注意力机制相比，PGBFP 对自注意力模块进行了进一步优化并将其有机集成到模型架构中。具体而言，在生成自注意力特征图后，PGBFP 直接将其输入至特制的下采样模块，该模块由 1×1 卷积和平均池化搭建而成，用于调整特征图的空间和通道维度，确保多个自注意力模块能够无缝连接。PGBFP 的详细结构如图3.3所示。

考虑到显存限制，本章将级联层级 $\aleph$ 设定为 3。对于第 i 个级联，定义 r_i 为子网络传递至 PGBFP 的特征图，m_i 为 PGBFP 传递至子网络的特征图，s_i 为待融合的内部特征图。级联操作要求 PGBFP 与子网络生成的特征图在尺寸上保持一致，即 $size(r_i) = size(m_i)$。此外，需满足 $size(r_i) = size(s_{i-1})$，以确保 r_i 与 s_{i-1} 能在

中国知网　https://www.cnki.net

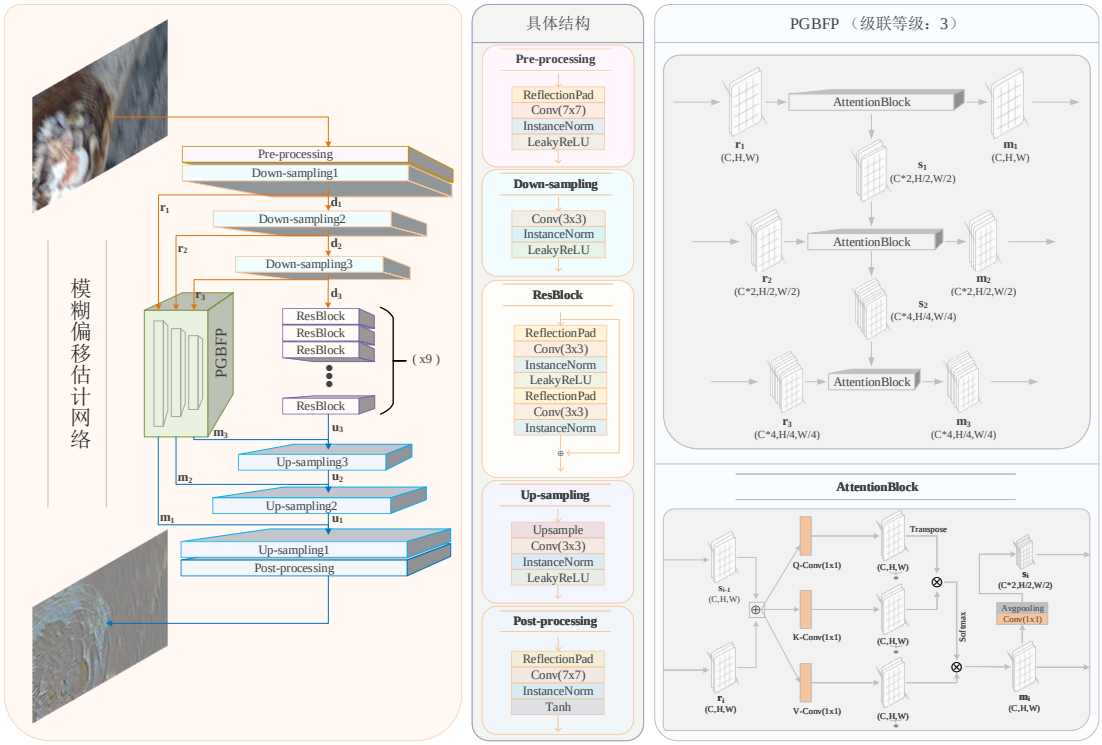


图 3.3　模糊偏移估计网络结构示意图

Fig. 3.3　Structural diagram of the blur offset estimation network

PGBFP 内部适当融合。PGBFP 的操作流程可表述如下：

$$\begin{cases} s_0 &= O, \\ n_i &= r_i + s_{i-1}, \\ m_i &= Softmax\left(\left(Q\left(n_i\right)\right)^T \cdot K\left(n_i\right)\right) \cdot V\left(n_i\right), \\ s_i &= A\left(S\left(m_i\right)\right), \end{cases} \tag{3.5}$$

其中 $i = 1, 2, \cdots, \aleph$，$Q(\cdot), K(\cdot), V(\cdot)$ 和 $S(\cdot)$ 为 1×1 卷积操作，$A(\cdot)$ 为平均池化操作，O 表示全零值特征图，$\cdot$ 表示矩阵乘法，而 $+$ 表示元素级加法。

对于具有特定级联层级的 PGBFP，其功能是根据输入特征图序列 $r_1, r_2, \cdots, r_{\aleph}$ 获取输出特征图序列 $m_1, m_2, \cdots, m_{\aleph}$。该过程可以通过以下公式简单表示：

$$m_i = PGBFP(r_i), i = 1, 2, \cdots, \aleph. \tag{3.6}$$

（2） 模糊偏移估计子网络

模糊偏移估计子网络的整体架构设计遵循经典的“编码-转换-解码”结构。具体而言，该子网络由预处理层、三个下采样层、九个残差块、三个上采样层以及后处理层组成。预处理层和后处理层通过 7×7 卷积核调整特征图的通道数，其中，预处理层通过较大的感受野在原始图像尺寸上提取信息，从而增强网络学习能力。而后处理层将实例归一化的仿射参数设置为可学习状态，并利用 Tanh 函数将特征值映射到区间 [-1, 1]。上下采样层均采用 3×3 卷积核，既可调整特征图的通道数，

中国知网　https://www.cnki.net

又可改变特征图的空间大小。上下采样层的数量则与级联结构的层级数量保持一致。在残差块设计上，采用实例归一化来替代传统的批量归一化框架，其余设置与标准残差块一致。

在第 i 个级联中，令 d_i 表示下采样层生成的特征图，u_i 表示上采样层生成的特征图。根据设计，d_i 与 r_i 相等（即 $d_i = r_i$），且 u_i 与 m_i 的尺寸保持一致（即 $size(u_i) = size(m_i)$）。因此，子网络在每个级联的处理过程可表述为：

$$\begin{cases} u_{\aleph} &= Res\left(d_{\aleph}\right), \\ m_i &= PGBFP\left(d_i\right), \\ u_{i-1} &= Upsampling_i\left(u_i + m_i\right), \end{cases} \tag{3.7}$$

其中 $i = 1, 2, \cdots, \aleph$，$Res(\cdot)$ 表示由 9 个残差块组成的模块，$UpSampling_i(\cdot)$ 表示第 i 个级联中的上采样层。

最终，BOE 网络根据非配对的模糊图像 A_B 和清晰图像 B_S，分别生成正向模糊偏移 f 和逆向模糊偏移 f^*：

$$\begin{aligned} f &= G_{BS}\left(A_B\right), \\ f^* &= G_{SB}\left(B_S\right). \end{aligned} \tag{3.8}$$

为深入理解模糊偏移在自适应模糊校正中的作用机制，图3.4展示了不同迭代次数下图像模糊偏移的可视化结果。观察表明，BOE 网络首先在初始阶段捕获图像的粗略轮廓。随着迭代次数增加，模糊图像与清晰图像之间的偏移细节逐渐被网络学习并呈现出更加精细的特征。这一过程直观地展示了模糊偏移估计的渐进优化特性。



图 3.4　模糊偏移产生过程渐变图

Fig. 3.4　Gradient diagram of blur offset generation process

3.3.3 自适应模糊矫正机制

自适应模糊校正机制在色彩保持方面发挥着至关重要的作用。该机制专注于为模糊偏移确定最佳校正方案，其独特之处在于除自适应因子外无需额外学习参数。正是由于该机制在物理层面直接对原始图像进行校正而非依赖大量学习参数，使得网络能够在训练过程中有效保持关键色彩信息。

中国知网　https://www.cnki.net

（1） 自适应模糊矫正计算过程

自适应模糊矫正的核心目标是构造一个校正函数 F，用于基于 BOE 阶段生成的模糊偏移数据对原始图像进行校正处理。通过将正常模糊偏移 f 与其逆向偏移 f^* 统一表示为 f，整个模糊矫正过程可以表示为：

$$F(I, f) = I \odot (f * \varphi), \tag{3.9}$$

其中 $\odot$ 表示校正方案，$*$ 表示乘法运算，φ 表示自适应因子。

自适应因子 φ 将模糊校正转化为一个动态自适应操作，可进一步增强模型的色彩保持能力。该因子初始值设为 0，经过训练后逐渐收敛至稳定值。从式3.9可见，φ 实质上充当模糊偏移的权重调节器。权重值越大，对原始图像的校正程度越强，同时丢失的色彩信息也越多。针对自适应因子的作用，可考察两种情况：1）不引入自适应因子（即直接将 φ 设为 1）：此时模糊偏移权重恒为 1，校正过程中会导致大量色彩信息丢失；2）引入自适应因子。φ 的参与提供了一个渐进的过程，即 φ 最初设置为 0，复原的图像将是原始图像，即没有色彩信息损失。在训练过程中，φ 将逐渐增加，这导致模糊偏移权重的增加。引入自适应因子：φ 的引入提供了一个渐进优化过程。初始阶段 φ 为 0，复原的图像完全保持原始图像的色彩信息。随着训练进行，φ 逐渐增大，模糊偏移权重相应提高。实验观察表明，φ 最终可稳定在约 0.55，较未引入自适应因子时降低 45%，充分证明了自适应因子在色彩保持中的显著价值。

（2） 模糊矫正方案选择

模糊校正方案存在多种可能性，每种方案对应于 ABC 阶段学习的不同类型模糊偏移。本章探讨了三种主要模糊偏移类型及其对应的校正方案：（1）残差校正：此方案采用逐元素加法操作，BOE 阶段生成与原始图像尺寸相同的残差图，随后通过原始图像与残差图的逐元素加法实现模糊校正；（2）逐元素加权校正：此方案基于逐元素乘法操作，BOE 阶段为原始图像中每个像素计算权重值，随后通过逐元素乘法实现模糊校正；（3）非局部注意力校正：此方案采用矩阵乘法操作，受注意力机制启发。具体而言，系统在每个通道上生成矩形注意力图，随后通过矩阵乘法实现模糊校正。图3.5展示了这三种模糊偏移类型及其对应的校正方案。元素级权重和残差模糊偏移均基于原始图像尺度设计，这种设计具有两个显著优势：首先，所得模糊偏移具有较高可解释性，偏移图中仍保持可识别的内容信息；其次，对应的校正方案实现简单，无需复杂计算过程。相比之下，非局部注意力模糊偏移理解难度更高，计算复杂度更大，且需要额外约束条件。通过定量比较分析，基于原始尺度的模糊偏移方案在性能表现上优于非局部注意力方案。

中国知网 https://www.cnki.net

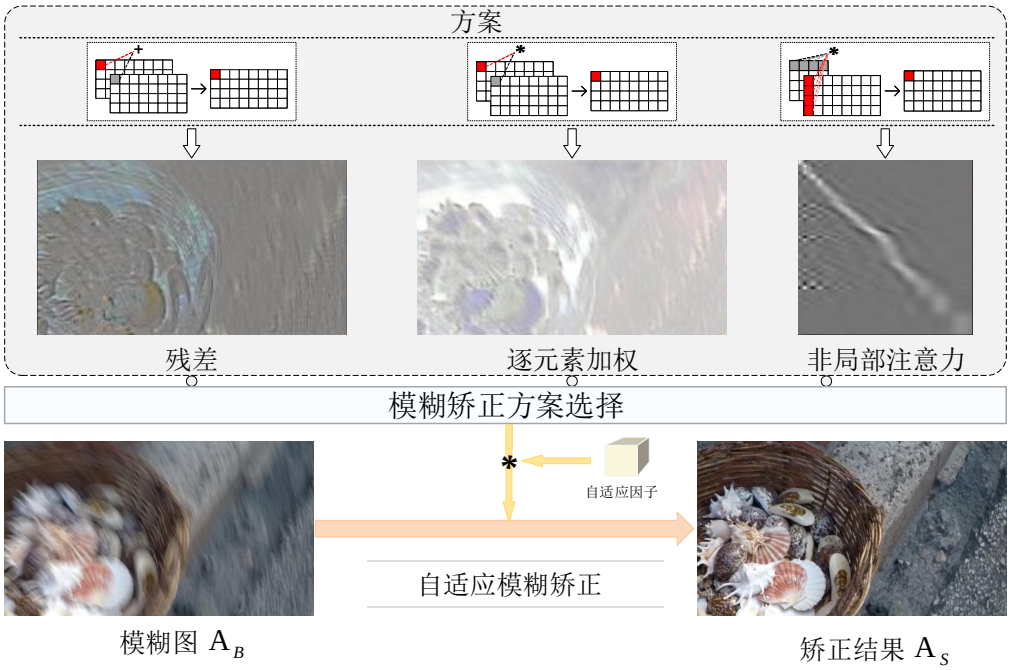


图 3.5　自适应模糊矫正原理示意图

Fig. 3.5　Schematic diagram of adaptive blur correction principle

3.3.4 损失函数

CRNet 的目标函数构建为多个损失函数项的加权组合：

$$\mathcal{L} = \lambda_{adv}\mathcal{L}_{adv} + \lambda_{cc}\mathcal{L}_{cc} + \lambda_{p}\mathcal{L}_{p}, \tag{3.10}$$

其中 $\mathcal{L}_{adv}$ 表示对抗损失，用于实现不同域间的图像转换；$\mathcal{L}_{cc}$ 代表循环一致性损失，确保保持原始图像的内容信息；$\mathcal{L}_{p}$ 为感知损失，旨在减轻去模糊过程中可能产生的伪影。$\mathcal{L}_{adv}$，$\mathcal{L}_{cc}$，$\mathcal{L}_{p}$ 分别作为相应损失项的权重因子，用于平衡各损失项对整体优化目标的贡献。这些损失函数在图像去模糊领域已得到广泛应用和验证，在本章的实验实施过程中，感知损失的计算基于在 ImageNet[142] 数据集上预训练的 VGG19[136] 网络架构。

3.3.5 色差定量评估指标设计

本章提出一种新型图像质量评估方法——色敏差（Color-Sensitive Error, CSE），用于精确量化复原图像与目标图像之间的色差。CSE 评估框架具有广泛适用性：在监督学习场景下，目标图像可采用真实图像（Ground Truth, GT）；而在无监督学习场景下的非配对数据中，目标图像则可采用原始模糊图像。这种灵活性使 CSE 度量能够同时适用于监督与无监督评估情境。从技术层面而言，CSE 度量基于图像颜色直方图构建。图像中出现频率较高的灰度值在直方图中形成峰值，而人类视觉系统对这些峰值的微小变化尤为敏感。因此，CSE 评估框架专门围绕直方图峰值特性设计，以更好地符合人类视觉感知机制。具体而言，CSE 的计算过程可表

中国知网　https://www.cnki.net

述为三个颜色分量 h、s 和 v 上误差的加权平均。每个分量的误差评估包含三个关键部分：1）峰域误差：测量两幅图像颜色直方图中对应峰值间的整体差异，主要从峰值高度与面积角度进行评估；2）峰偏误差：评估比较图像颜色直方图中主要峰值之间以及辅助峰值之间的位置偏移，重点关注峰值位置的角度；3）分量加权：用于优化各误差项的贡献度，提升整体评估准确性。

以下将详细阐述上述三个部分的具体实现。鉴于 CSE 指标的计算与推导涉及多个专业符号，表3.1中列出了本章使用的符号体系，以确保描述的清晰准确性。

表 3.1　本章节的符号表

Tab. 3.1　Symbol table of this chapter

符号	释义
C	HSV 色彩空间，$C=\{h,s,v\}$。
c	HSV 中的某个分量，$c\in C$。
V	HSV 中的整个颜色直方图，包含三个颜色直方图分量向量，$V=\{V^c\|c\in C\}=\{V^h,V^s,V^v\}$。可以添加下标来表示图像。
$\Delta^k V^c$	直方图向量 V^c 的 K 阶差分。特别地，$\Delta^1 V^c$ 表示为 ΔV^c。
$\sigma(V^c)$	向量 $\|V^c\|$ 的离散积分。
p	主峰：$\left((p)_x,(p)_y\right)$。
q	辅助峰：$\left((q)_x,(q)_y\right)$。
Q	辅助峰集合：$\left((q_1)_x,(q_1)_y\right),\cdots,\left((q_{N-1})_x,(q_{N-1})_y\right)$，其中 N 表示主峰和辅助峰的总数。
t	峰的统一表示：$\left((t)_x,(t)_y\right),t\in p\cup Q$。上标和下标分别表示某个分量和图像。
ω	整个颜色直方图中不同分量的权重，$\omega=\{\omega_c\|c\in C\}=\{\omega_h,\omega_s,\omega_v\}$。
γ	所有峰中不同峰的权重。上标和下标分别表示某个分量和峰类型。$\gamma=\{\gamma_t^c\|c\in C,t\in\{p,q\}\}=\{\gamma_p^h,\gamma_p^s,\gamma_p^v,\gamma_q^h,\gamma_q^s,\gamma_q^v\}$。

（1） 峰域误差

本节详细阐述峰域误差（Peak-Area Error, PAE）的计算方法。由于 HSV 颜色空间 $C=\{h,s,v\}$ 相较于 RGB 空间更接近人类视觉感知系统，因此色差量化过程在 HSV 空间中进行。给定 RGB 彩色图像 $I\in\mathbb{R}^{H\times W\times C}$，首先将其转换为 HSV 空间中的 $\tilde{I}\in\mathbb{R}^{H\times W\times C}$。对于任意 HSV 图像，三个分量 h、s、v 的值范围各不相同，对于每个分量 $c\in C$，其值宽度 R_c 定义为：

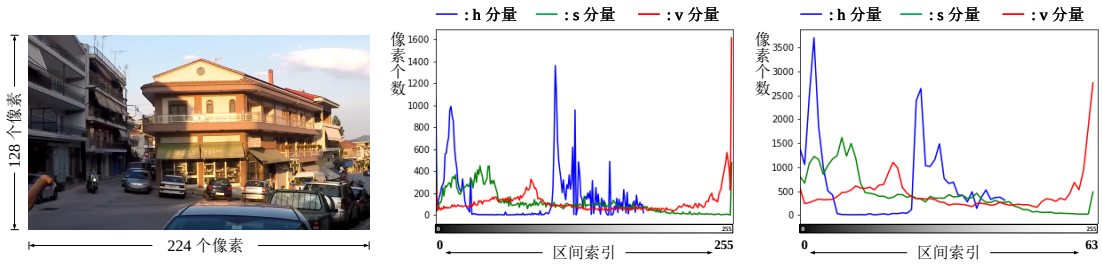
$$R_c=\sup_{z\sim Z^c}[z]-\inf_{z\sim Z^c}[z],\quad c\in C, \tag{3.11}$$

其中 $sup[\cdot]$ 和 $inf[\cdot]$ 分别表示上确界和下确界，Z^c 表示 c 分量的颜色直方图的所有可能分布。对于整型 HSV 图像，h 分量的值宽度为 180，而 s 和 v 分量的值宽度为 256。在计算颜色直方图之前，需设置 $histsize$ 因子，它决定了直方图向量中单个分区的长度。

图3.6展示了不同 $histsize$ 值下的颜色直方图示例。较大的 $histsize$ 产生更平

中国知网 https://www.cnki.net

滑的直方图，但可能不利于量化指标的准确表达。当 *histsize* 过大时，直方图间差异变小，且可能合并重要峰值，导致差异不明显。相反，较小的 *histsize* 产生更锐利的直方图，数值上更精确详细。然而，过小的 *histsize* 又会增加峰值确定的难度。经实验权衡，本章将 *histsize* 设置为 180 和 256 的最大公约数 4，以实现指标量化及直方图可视化的最佳效果。



（a）示例图像　（b）颜色直方图（histsize=1）　（c）颜色直方图（histsize=4）

图 3.6　HSV 空间中的颜色直方图示例

Fig. 3.6　Example of color histogram in HSV space

通过设定的 *histsize*，可获得一组颜色直方图向量 $V=\{V^c|c\in C\}$，涵盖图像 $\tilde{I}$ 的每个分量。每个分量上的分区数量 L_c 为每个分量上的分区数量（即向量 V^c 的长度）计算如下：

$$L_c=\frac{R_c}{histsize},\quad c\in C. \tag{3.12}$$

在颜色直方图中，峰值对人类视觉感知差异具有决定性作用。为突显峰值重要性并避免非峰值元素干扰计算，采用对 V^c 进行一阶差分的方法，通过以下公式获得差分向量 ΔV^c：

$$\begin{cases}\Delta^0 V^c=V^c, & c\in C,\\ \Delta^k V_i^c=\Delta^{k-1}V_i^c-\Delta^{k-1}V_{i+1}^c, & i=1,...,L_c-k,\end{cases} \tag{3.13}$$

其中 Δ^k 表示 k 阶差分，V_i^c 表示 V^c 的第 i 个元素。在过滤掉那些非峰值元素并获得差分向量 ΔV^c 后，可计算离散积分，间接反映直方图向量中所有峰值的高度和面积。具体而言，根据差分向量 ΔV^c 计算 $|\Delta V^c|$ 的离散积分 $\sigma\left(\Delta V^c\right)$：

$$\begin{aligned}\sigma\left(V^c\right)&=\sum_{i=1}^{L_c-1}\left(\frac{1}{2}\times\left(|V_i^c|+|V_{i+1}^c|\right)\times 1\right)\\&=\frac{1}{2}|V_1^c|+|V_2^c|+\cdots+|V_{L_c-1}^c|+\frac{1}{2}|V_{L_c}^c|\\&=\sum_{i=1}^{L_c}|V_i^c|-\frac{1}{2}\left(|V_1^c|+|V_{L_c}^c|\right),\quad c\in C,\end{aligned} \tag{3.14}$$

其中 V_i^c 表示 V^c 的第 i 个元素，$|\cdot|$ 表示绝对值操作。为便于理解，图3.7展示了两个从 V^c 到 $\sigma\left(\Delta V^c\right)$ 计算的比较示例。

中国知网　https://www.cnki.net

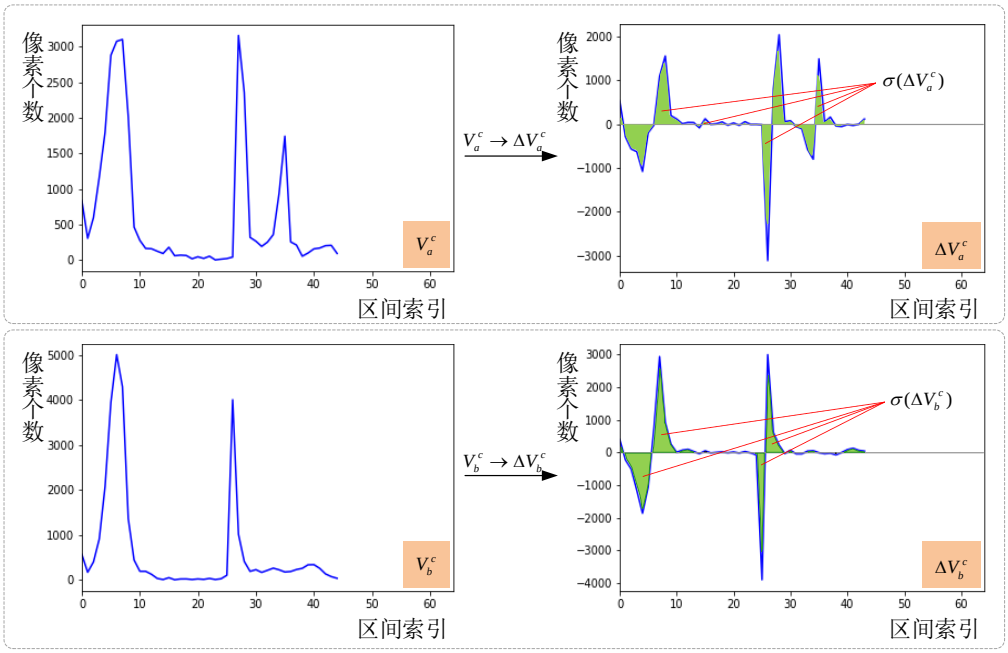


图 3.7　颜色直方图离散积分计算过程示意图

Fig. 3.7　Schematic diagram of color histogram discrete integration calculation process

类似地，给定两个 HSV 图像 $\tilde{I}_a \in \mathbb{R}H \times W \times C$ 和 $\tilde{I}_b \in \mathbb{R}^{H \times W \times C}$，可获得相应的颜色直方图向量 V_a^c 和 V_b^c，差分向量 ΔV_a^c 和 ΔV_b^c，以及各分量的离散积分 $\sigma\left(\Delta V_a^c\right)$ 和 $\sigma\left(\Delta V_b^c\right)$。最终，峰域误差（PAE）的计算公式为：

$$\begin{aligned} PAE_c &= |\sigma\left(\Delta V_a^c\right) - \sigma\left(\Delta V_b^c\right)|, \\ PAE &= \sum\nolimits_c PAE_c, c \in C. \end{aligned} \tag{3.15}$$

（2） 峰偏误差

峰偏误差（Peak Offset Error, POE）计算涉及峰值的数值处理，首先需明确峰值的统一表达式。给定一个颜色直方图向量 V^c，定义 $t^c = \left(\left(t^c\right)_x, \left(t^c\right)_y\right)$ 作为峰值点，其中 x 和 y 表示峰值位置和峰值高度。具体而言，$\left(t^c\right)_y$ 为 V^c 中的某个值，而 $\left(t^c\right)_x$ 是 V^c 中对应的索引。通常，V^c 中的峰值点 t^c 需要满足两个条件：①：$V^c_{(t^c)_x} > V^c_{(t^c)_x - 1}$，②：$V^c_{(t^c)_x} > V^c_{(t^c)_x + 1}$。特殊情况下，满足条件②的起始点或满足条件①的终止点也可视为峰值点。实际应用中，并非所有峰值点都具有实际意义，因值过小的峰值点可忽略不计。因此，POE 设计中仅选择值最高的主峰 p 及若干值次高的辅助峰 q，辅助峰集合表示为 $Q = \{q_1, q_2, ..., q_{N-1}\}$。值得注意的是，主峰为必需元素，而辅助峰则非必需，即 Q 可为空集。POE 度量需执行以下两个步骤：

峰定位。给定直方图向量 V^c，如何准确找到并定位峰值 p 和 q 是核心过程。本章提出一种峰定位算法以获取直方图向量 V^c 上所需的峰值，如算法1所示。具体实施包含三个顺序操作：1）创建空峰值集 T 用于存储峰值；2）将向量 V^c 按降序排序得到索引向量 idx，即 $V^c[idx[i]] >= V^c[idx[i+1]], i = 1, ..., L$；3）在向量 V^c 的起始点之前和终止点之后分别添加零元素，即 $V^c \leftarrow [0, V_1^c, V_2^c, ..., V_L^c, 0]$。随后，

中国知网　https://www.cnki.net

算法 1 峰定位

输入：
V^c - 任意向量
N - 指定的峰值点数量
输出：
T - 峰值点集合

$T \leftarrow \varnothing$
$L \leftarrow$ length (V^c)
$idx \leftarrow$Descending-argsort (V^c)
$V^c \leftarrow 0 \cup V^c \cup 0$
for $i \leftarrow 1$ to L **do**
  if $V^c[idx[i]] >= V^c[idx[i]+1]$ and $V^c[idx[i]] >= V^c[idx[i]-1]$ **then**
    $T \leftarrow T \cup (idx[i], V^c[idx[i]])$
    $N \leftarrow N - 1$
    if $N = 0$ **then**
      return T
    end if
  end if
end for
return T

遍历向量 idx 判断当前值是否满足峰值条件，若满足则将 $\left(idx[i], V^c[idx[i]]\right)$ 添加至 T。最终，当 T 中峰值数量达到指定最大值 N 或向量 idx 完成遍历时，返回峰值集 T。需强调的是，主峰为必需元素，即 N 应大于 1。本章设定 $N=2$，以获得主峰 p 和一个辅助峰 q。

峰对齐。获取主峰和辅助峰后，仍可能面临峰值错位问题，这将直接影响度量准确性。例如，给定两个向量 V_a^c 和 V_b^c，通过峰值定位获得 V_a^c 的峰值 p_a^c、q_a^c 和 V_b^c 的峰值 p_b^c、q_b^c。对于主峰 p_a^c 和 p_b^c，若 $\left|\left(p_a^c\right)_x - \left(p_b^c\right)_x\right|$ 较大，$\left|\left(p_a^c\right)_y - \left(p_b^c\right)_y\right|$ 较小，同时辅助峰也存在类似情况，则会出现峰值错位，如图3.8所示。可观察到 p_a 与 p_b 之间以及 p_b 与 p_s 之间均存在峰值错位，这将导致计算结果不准确。为解决此问题，本章设计了峰对齐算法，详见算法2，其中参数 ϑ 设为 0.3。

峰值偏移定义为两个峰值 x 坐标间的距离。考虑到不同类型峰值（主峰值和辅助峰值）的重要性差异，故根据它们的 y 坐标对这两种偏移类型进行加权。具体而言，给定两幅图像 $\tilde{I}_a, \tilde{I}_b \in \mathbb{R}^{H\times W\times C}$，基于 HSV 颜色空间各分量的颜色直方图向量 $\tilde{V}_a^c$ 和 $\tilde{V}_b^c$ 可获得对齐的峰值 t_a^c 和 t_b^c，$t \in (p \cup Q)$。主峰值和辅助峰值的权重 γ_t^c 定义如下：

$$\gamma_t^c = \frac{\left(t_a^c\right)_y + \left(t_b^c\right)_y}{\sum_t \left(\left(t_a^c\right)_y + \left(t_b^c\right)_y\right)}, c \in C, t \in (p \cup Q), \tag{3.16}$$

其中 γ_t^c 的上标和下标分别表示分量和峰值类型，即 $\gamma_t^c = \left\{\gamma_p^h, \gamma_p^s, \gamma_p^v, \gamma_{q_1}^h, \gamma_{q_1}^s, \gamma_{q_1}^v, ..., \gamma_{q_{N-1}}^h, \gamma_{q_{N-1}}^s, \gamma_{q_{N-1}}^v\right\}$。随后，峰值偏移可通过主峰

中国知网　https://www.cnki.net

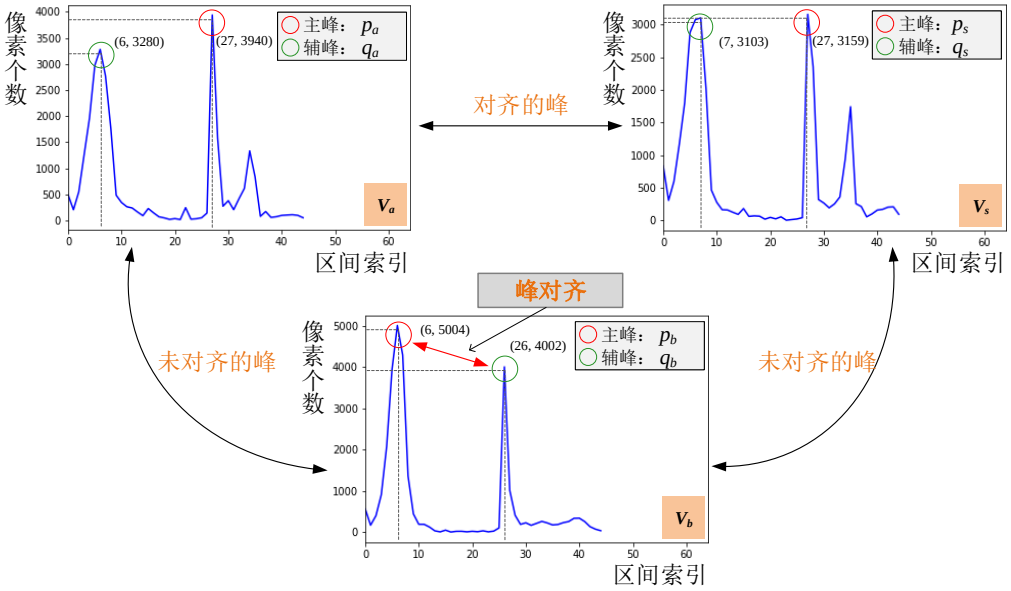


图 3.8　峰对齐过程示意图

Fig. 3.8　Diagram of peak aligning process

值和辅助峰值的加权和获得：

$$d_c = \gamma_p^c \left| \left(p_a^c\right)_x - \left(p_b^c\right)_x \right| + \sum_q \gamma_q^c \left| \left(q_a^c\right)_x - \left(q_b^c\right)_x \right|, c \in C. \tag{3.17}$$

基于上述分析，POE 度量正式定义如下：

$$\begin{aligned} POE_c &= e^{\sqrt{d_c}}, \\ POE &= \sum_c POE_c, \quad c \in C. \end{aligned} \tag{3.18}$$

（3） 分量加权和 CSE 指标

鉴于不同颜色分量对人类视觉感知的贡献存在差异性，本节对前述误差度量 PAE 和 POE 在分量维度上实施加权策略。类似于峰值权重设计，采用峰值数值构建分量权重，计算公式如下：

$$\omega_c = \frac{max\left(V_a^c\right) + max\left(V_b^c\right)}{\sum_c^C \left(max\left(V_a^c\right) + max\left(V_b^c\right)\right)}, \tag{3.19}$$

其中 $max(\cdot)$ 表示取最大值操作。

分量加权旨在突显各分量的差异化贡献，然而当直方图某分量呈现平坦分布或缺乏明显峰值时（如图3.9所示），分量加权将面临困境。理论上，这类情况下两直方图向量的预期误差应当较小，因为它们表现出相似性。实际上，尽管峰值不明显，峰定位算法仍会强制确定峰值位置，但这些“峰值”通常不准确，导致如图3.9所示的错误结果。因此，当目标图像直方图向量分布足够平坦时，本章将其视为平坦分量，采用均方根误差替代峰值累积误差进行计算，原因在于此类情况下峰值缺乏有效性。这种处理方式带来额外优势：仅当其他分量误差足够小时，平

中国知网　https://www.cnki.net

算法 2 峰对齐

输入：

$T_a = \{t_{a_1}, t_{a_2}, t_{a_3}, ..., t_{a_{N-1}}\}$ - 向量 a 的峰集，包含一个主峰 t_{a_1}，一个或多个辅峰

$T_b = \{t_{b_1}, t_{b_2}, t_{b_3}, ..., t_{b_{N-1}}\}$ - 向量 b 的峰集，包含一个主峰 t_{a_1}，一个或多个辅峰

ϑ - 决定是否执行对齐操作的阈值

输出：

$P_a = \{t_{a_1}, t_{a_2}, t_{a_3}, ..., t_{a_{N-1}}\}$ - 向量 a 对齐的峰集

$P_b = \{t_{b_1}, t_{b_2}, t_{b_3}, ..., t_{b_{N-1}}\}$ - 向量 b 对齐的峰集

$N_a \leftarrow |T_a|$
$N_b \leftarrow |T_b|$
if $N_a \neq N_b$ **then**
    $ERROR$
    return ;
end if
for $i \leftarrow 1$ to $N_a - 1$ **do**
    for $j \leftarrow i + 1$ to N_a **do**
        if $|(t_{a_i})_x - (t_{b_i})_x| < |(t_{a_i})_x - \left(t_{b_j}\right)_x|$ and
                $|\left(t_{a_j}\right)_x - \left(t_{b_j}\right)_x| < |\left(t_{a_j}\right)_x - (t_{b_i})_x|$ **then**
            continue
        end if
        $D \leftarrow 0.5 * |(t_{a_i})_y - \left(t_{a_j}\right)_y| + 0.5 * |(t_{b_i})_y - \left(t_{b_j}\right)_y|$
        $R \leftarrow 0.25 * \left((t_{a_i})_y + \left(t_{a_j}\right)_y + (t_{b_i})_y + \left(t_{a_j}\right)_y\right)$
        if $D/R <= \vartheta$ **then**
            $t_{a_i}, t_{a_j} \leftarrow t_{a_j}, t_{a_i}$
        end if
    end for
end for
return P_a, P_b

坦分量误差才会占主导地位，否则平坦分量仅占较小比例，这与初始利用峰值评估颜色差异的设计意图保持一致。本章定义当直方图某分量最大值小于整体最大值四分之一时，将其视为平坦分量。

随后，利用 R_c 进行归一化，并按以下方式计算特定分量上的 CSE：

$$CSE_c = \begin{cases} \frac{\omega_c}{R_c} \cdot e^{\sqrt{d_c}} \cdot |\sigma\left(\Delta V_a^c\right) - \sigma\left(\Delta V_b^c\right)| & \text{if not flat,} \\ \frac{\omega_c}{R_c} \sqrt{\frac{1}{L_c} \sum_{j=1}^{L_c} \left(\left(V_a^c\right)_j - \left(V_b^c\right)_j\right)^2} & \text{if flat.} \end{cases} \tag{3.20}$$

最终，整体 CSE 误差通过累积所有分量误差计算得出：

$$CSE = \sum\nolimits_c CSE_c, \quad c \in C. \tag{3.21}$$

注：PSNR 和 SSIM 作为广泛应用的图像去模糊质量评估指标，存在两个显著局限性：1）客观评估结果与人类感知存在不一致性，可能源于细节和颜色信息未得到充分考量；2）计算过程依赖成对数据。相比之下，本章提出的 CSE 指标基于 HSV 颜色直方图向量的统计原理构建，更贴近人类视觉感知且对颜色变化表现出

中国知网　https://www.cnki.net

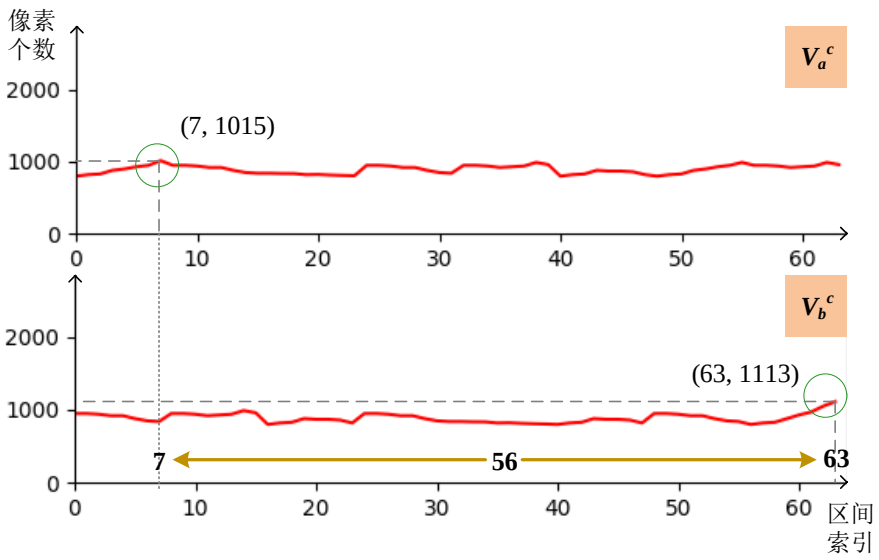
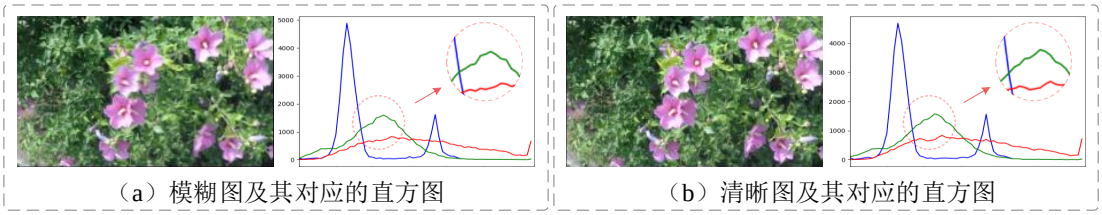


图 3.9　色敏差指标异常情况示例

Fig. 3.9　An example of abnormal situation in color sensitive error

更高敏感度。值得注意的是，虽然 CSE 指标初衷在于评估颜色保持能力，但其数值在一定程度上亦可反映复原图像的细节重建能力。此外，CSE 指标具有通用性，适用于评估不同类型去模糊模型，无论是否存在成对数据，包括无监督、全监督及半监督模型。具体而言，对于拥有清晰参考图像的成对数据，CSE 基于复原图像与清晰图像计算；对于缺乏清晰参考图像的非成对数据，可直接基于复原图像与原始模糊图像计算 CSE。这种处理方式的合理性源于一个关键观察：即使在模糊退化的情况下，原始模糊图像仍保持图像中大部分颜色信息，如图3.10所示。色彩特征的这种相对稳定性为 CSE 的无监督评估提供了可靠基础。



（a）模糊图及其对应的直方图　　（b）清晰图及其对应的直方图

图 3.10　模糊图和清晰图的颜色直方图对比

Fig. 3.10　Comparison of color histogram between blurred image and sharp image

3.4 实验分析

本章对 CRNet 进行了全面的定性与定量评估，并与相关模型进行了系统性比较。实验均在搭载 11GB 显存的 NVIDIA RTX 2080 Ti 显卡上进行。

中国知网　https://www.cnki.net

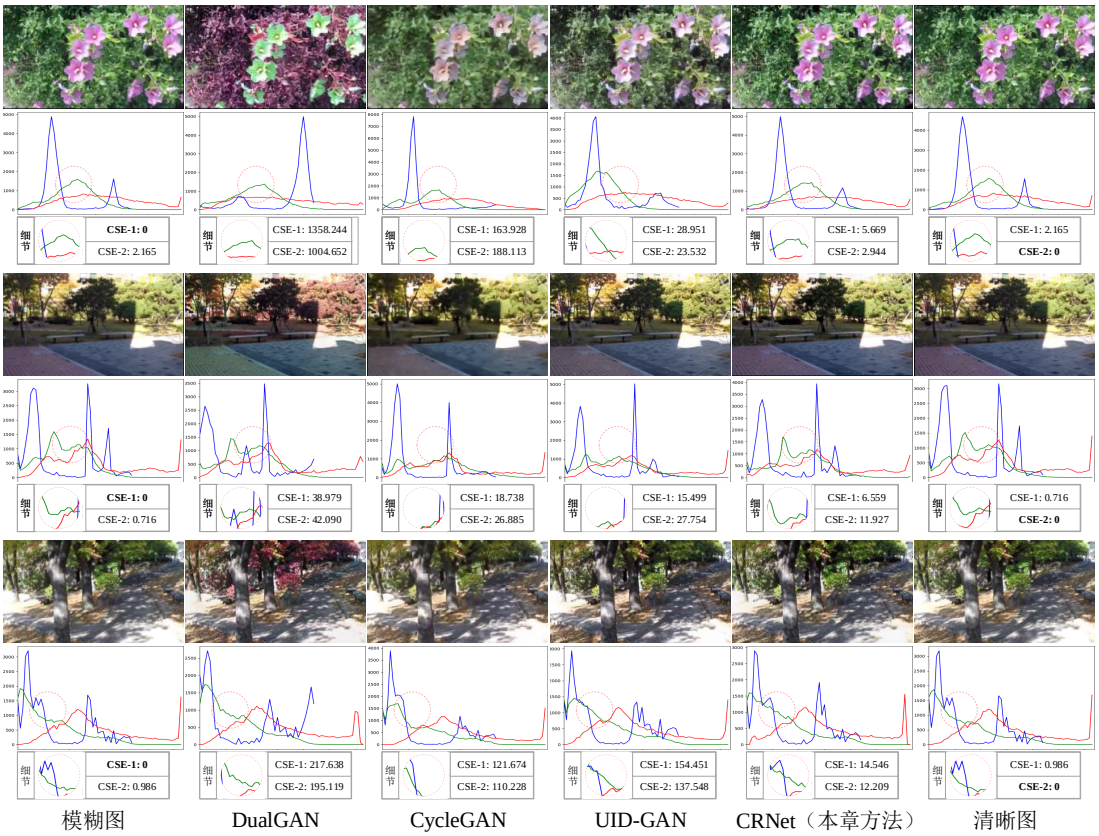


图 3.11　在 GoPro 数据集上的可视化结果对比

Fig. 3.11　Comparison of visualization results on the GoPro dataset

3.4.1 实验设置

数据集。本章评估采用两个广泛使用的图像数据集：自然图像数据集 GoPro[8] 和特定领域的人脸数据集 CelebA[131]。

评估方法。本章比较了三种代表性无监督方法：CycleGAN[125]、DualGAN[123] 和 UID-GAN[127]。评估在设置一致的情况下优先采用各官方发布的预训练模型；对于设置不一致或未提供预训练模型的情况，则依据原作者提供的代码和推荐配置重新训练以确保公平比较。

评估指标。本章评估采用了普遍认可的 PSNR 和 SSIM 度量指标，以及新提出的 CSE 指标。尽管本章主要探讨无监督去模糊任务（缺乏真实标签），但仍可利用原始模糊图像或清晰图像计算 CSE。具体而言，CSE-1 用于评估复原图像与模糊输入之间的色差，CSE-2 用于评估复原图像与清晰图像（真值）之间的色差。在结果展示中，符号 ↑ 表示该指标数值越高表明性能越好，而符号 ↓ 则表示该指标数值越低代表性能越好，最优性能用红色标记。

实现细节。所提出的去模糊模型基于 PyTorch[143] 实现。在训练阶段，CRNet 的权重因子 λ_{adv}、λ_{cc} 和 λ_p 分别设置为 1、20 和 0.1。训练过程采用 Adam 优化器[144] 优化模型，其中 $\beta_1 = 0.5$、$\beta_2 = 0.999$，初始学习率为 0.0002，前 40 个周期保

中国知网　https://www.cnki.net

表 3.2　在 GoPro 数据集上的定量结果对比

Tab. 3.2　Comparison of quantitative results on the GoPro dataset

方法	PSNR↑	SSIM↑	CSE-1↓	CSE-2↓
CycleGAN[125]	23.98	0.821	119.279	115.820
DualGAN[123]	25.21	0.879	184.122	179.318
UID-GAN[127]	26.79	0.883	58.642	56.358
CRNet	28.31	0.905	48.529	46.931

持恒定，后 40 个周期线性递减至 0。在判别器的前向传播中，遵循 CycleGAN[125] 设置样本缓冲池，使模型能够学习更一般的域间关系。在测试阶段，模糊偏移估计网络 G_{SB} 和判别器 D_S、D_B 将被移除。给定模糊图像 I_B，测试过程如下：

$$I_S = F\left(I_B, G_{BS}\left(I_B\right)\right). \tag{3.22}$$

3.4.2 实验结果及分析

（1） 在 GoPro 数据集上的结果

本章首先在广泛使用的自然图像数据集 GoPro 上评估各模型的图像去模糊性能。该数据集包含 2,103 对训练数据和 1,111 对测试数据，每对数据包括一张模糊图像和一张清晰图像，图像尺寸为 1280×720 像素。由于 GoPro 作为自然图像数据集，其视觉敏感度低于特定领域的数据集，因此未添加额外细节进行比较。

由于本章所提出的 CRNet 计算量较高（推理时为 102.49MACs），受限于显卡显存，难以在原始分辨率下进行评估，因此将原始图像调整为 128×128 像素用于训练。测试阶段将原始图像调整为 224×128 分辨率，以保持与原始图像相同的宽高比。

数值评估结果如表3.2所示，CRNet 在 PSNR、SSIM 及 CSE 指标方面均优于其他先进方法。然而，应当指出，各方法在 PSNR 和 SSIM 方面的性能提升普遍有限，这是因为 PSNR 和 SSIM 无法充分考量图像细节，难以显著区分性能差异。图3.11提供了四组可视化对比结果，每一组结果包含三部分：顶部展示了各个方法的图片对比；中部展示了顶部图片对应的颜色直方图，从颜色直方图中可以观察到峰信息；底部展示了中部直方图的部分放大细节以及顶部图片和输入/真值之间色敏差的数值结果。从图中可见，其他无监督方法未能有效保持图像的颜色信息，这一点通过可视化对比以及 CSE-1 和 CSE-2 的结果可得到证实。换言之，CRNet 不仅能获得更优的去模糊效果，同时有效保持了颜色信息。值得注意的是，CSE-1 和 CSE-2 之间各方法的性能排序保持一致，表明从原始模糊图像或真实清晰图像计算评估结果确实可行，这对于缺乏配对数据的场景尤为重要。

中国知网　https://www.cnki.net

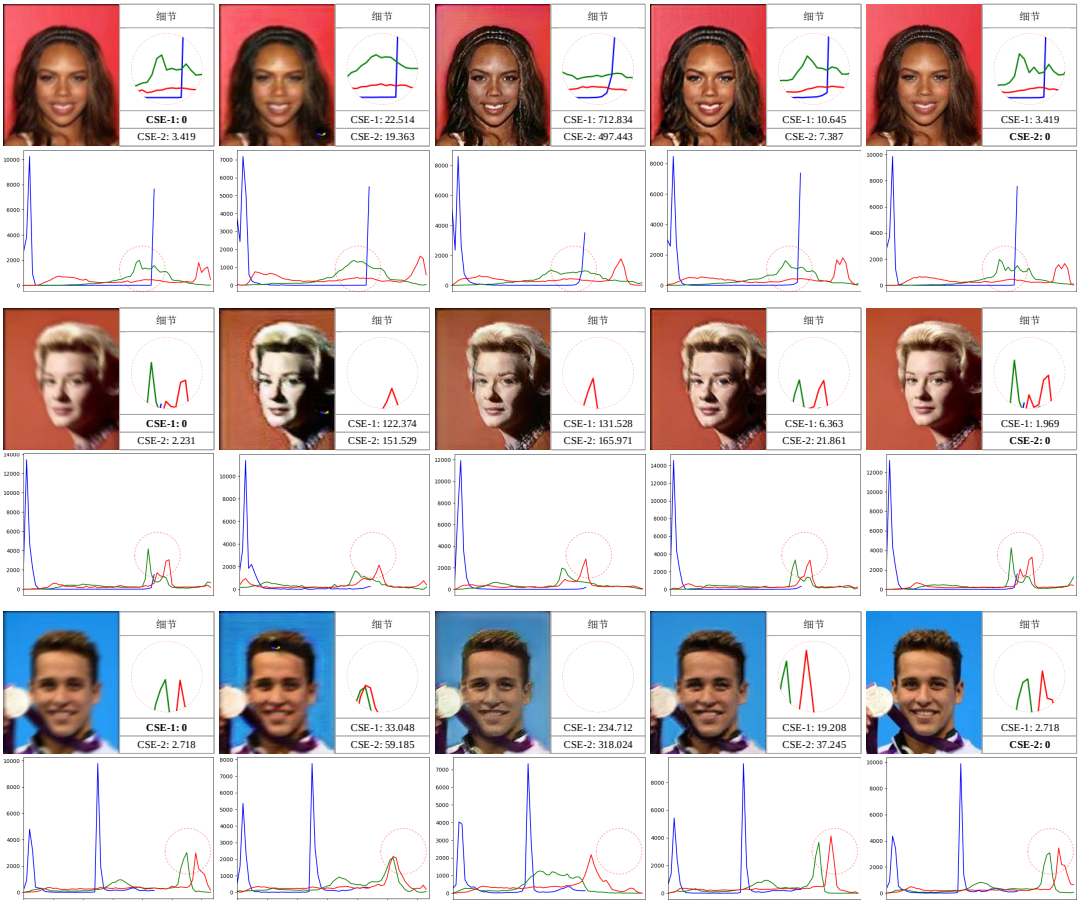


图 3.12　在 CelebA 数据集上的可视化结果对比

Fig. 3.12　Comparison of visualization results on the CelebA dataset

表 3.3　在 CelebA 数据集上的定量结果对比

Tab. 3.3　Comparison of quantitative results on the CelebA dataset

方法	PSNR↑	SSIM↑	CSE-1↓	CSE-2↓
CycleGAN[125]	19.30	0.621	473.269	543.421
DualGAN[123]	-	-	2433.757	2979.220
UID-GAN[127]	20.40	0.648	372.067	434.689
CRNet	20.39	0.652	265.946	336.152

（2） 在 CelebA 数据集上的结果

本章在领域特定的合成数据集 CelebA 上评估了各模型的去模糊能力。CelebA 作为一个包含 202,599 张清晰面部图像（尺寸 178×218）的人脸属性数据集，为实验提供了理想的基础。实验采用了经过对齐与裁剪的 CelebA 数据集版本[131]。由于该数据集仅包含清晰图像，因此遵循 DeblurGAN[9] 的算法生成运动模糊，参数设置包括 0.005 的随机抖动概率和 20 的最大运动长度。

训练阶段将原始图像调整至中间尺寸后裁剪为 128×128 像素，而测试阶段则在原始分辨率上执行去模糊处理。考虑到设置差异，直接使用作者提供的预训练

中国知网　https://www.cnki.net



图 3.13　在 CelebA 数据集上的局部细节效果对比

Fig. 3.13　Comparison of local detail effects on the CelebA dataset

模型会导致不公平地比较，故根据官方发布的代码在该数据集上重新训练了对比方法，确保实验公平性。

表3.3呈现了在 CelebA 数据集上的量化去模糊结果，部分视觉结果如图3.12所示。图中展示了三组人脸数据集上的去模糊结果，每一组结果均包含了视觉对比，直方图对比和局部直方图细节对比。从图中可观察到，其他无监督方法在还原图像中存在明显的色差问题，这一点在表中的 CSE-1 和 CSE-2 量化结果也得到了验证。相比之下，CRNet 在去模糊过程中能够有效保持原始图像的颜色信息，表现为更小的 CSE-1 和 CSE-2 值。数值结果分析显示，尽管 UID-GAN[127] 作为最先进的方法之一且专为领域特定数据集设计，CRNet 仍展现出极强的竞争力。特别值得一提的是，虽然 UID-GAN 的 PSNR 值略高，但这并不意味着还原图像的清晰度更佳。为验证这一点，图3.13展示了还原图像的局部细节，清晰表明尽管 UID-GAN 的 PSNR 值略高，其还原图像的细节实际上不如 CRNet。这一现象强调了同时进行定性和定量评估的必要性。此外，相较于 PSNR 和 SSIM 指标，CSE 指标评估出的性能差异更为显著，这归因于 CSE 充分考虑了颜色信息，而颜色信息可视为图像中包含的重要细节信息。

中国知网　https://www.cnki.net

表 3.4　在 GoPro 数据集上的消融实验结果

Tab. 3.4　Results of ablation study on the GoPro dataset

方法	双分支	MCD	感知损失	PGBFP	PSNR↑	SSIM↑
仅基于去模糊分支	✗	✗	✗	✗	27.03	0.887
添加双分支	✓	✗	✗	✗	27.92	0.899
添加 MCD	✓	✓	✗	✗	28.18	0.899
添加感知损失	✓	✓	✓	✗	28.16	0.902
添加 PGBFP	✓	✓	✓	✓	**28.31**	**0.905**
仅移除双分支	✗	✓	✓	✓	27.33	0.897
仅移除 MCD	✓	✗	✓	✓	28.02	0.901
仅移除感知损失	✓	✓	✗	✓	27.92	0.899
仅移除 PGBFP	✓	✓	✓	✗	28.16	0.902
包含所有元素	✓	✓	✓	✓	**28.31**	**0.905**
非局部注意力矫正	✓	✓	✓	✓	21.18	0.708
逐元素加权矫正	✓	✓	✓	✓	28.18	0.903
残差矫正	✓	✓	✓	✓	**28.31**	**0.905**

3.4.3 消融实验及分析

为了验证 CRNet 中各个组件和模块的有效性，本章开展了详细的消融实验，特别验证了四个核心组件对性能的影响：1）双分支；2）多尺度裁剪判别器；3）感知损失；4）PGBFP。实验数据表明，添加双模糊分支和 PGBFP 能显著提高去模糊性能，而移除仅使用单去模糊分支则会导致性能大幅下降。此外，本研究还探索了三种不同类型的模糊矫正：非局部注意力矫正、逐元素加权矫正和残差矫正。如表3.4下半部分所示，逐元素加权矫正和残差矫正均表现出强大的竞争力，效果优于非局部注意力矫正。

3.5 本章小结

本章深入探讨了无监督去模糊任务中的颜色保持和质量评估问题。从技术角度，提出了一个通用的无监督颜色保持网络 CRNet 和一个新的色差量化指标 CSE。CRNet 的去模糊架构通过创新性地结合模糊偏移估计网络和自适应模糊校正阶段，有效解决了色差问题。CSE 指标具有三大优势：首先，适用于有/无配对数据的监督/无监督设置；其次，量化结果更符合人类感知；第三，评估的性能差异比传统 PSNR 和 SSIM 指标更为显著。在自然图像和特定领域数据集上的广泛实验证明，CRNet 在去模糊和颜色保持方面均取得了优异性能。

中国知网　https://www.cnki.net

第四章 基于轻量级域转换的无监督图像去模糊方法

前章研究揭示了一类无监督去模糊方法中普遍存在的色差问题，即复原结果与原始模糊图像之间的明显色差。通过设计模糊偏移估计机制的色彩保持方法及相应的定量评价指标，该问题得到了有效解决。然而，现有无监督去模糊方法依然面临诸多实际应用障碍，包括模型体积庞大、推理效率低下以及对图像分辨率和领域的严格限制，这些因素显著阻碍了无监督去模糊技术在实际场景中的部署与应用。针对上述挑战，本章提出了一种轻量级且支持实时处理的无监督基准模型——频域对比损失约束的轻量级 CycleGAN 网络（FCL-GAN）。该模型具备多个突出优势：领域通用性、分辨率普适性以及显著的效率提升（比当前最先进模型轻量 25 倍，处理速度提升 5 倍）。为实现模型轻量化与性能优化的平衡，本章设计了两个创新性协作单元：1）轻量级域转换单元（Lightweight Domain Conversion Unit, LDCU）：专注于以参数高效方式实现模糊域与清晰域之间的图像转换；2）无参数频域对比单元（Parameter-free Frequency-domain Contrastive Unit, PFCU）：在频域层面探索模糊图像与清晰图像间的相似性度量和差异特征，且不引入额外参数负担。通过在多个图像数据集上进行的广泛实验验证，FCL-GAN 在去模糊效果、模型体积与推理速度三方面均表现出显著优势，为无监督图像去模糊技术的实际应用提供了可行解决方案。

4.1 本章概述

图像去模糊技术致力于从模糊图像中恢复清晰图像内容。传统基于优化的方法普遍假设潜在清晰图像遵循特定先验条件，并将去模糊问题转化为复杂优化问题求解过程[6-7,41,50,52]。然而，这类方法通常效果欠佳且推理时间冗长，严重制约了该类方法的实际价值。随着深度学习技术在各类视觉任务中的广泛应用[145-147]，配对数据驱动的深度全监督方法[8-9,11,57,66-69,71,90] 在图像去模糊任务中展现出显著优势。此类方法通常依赖大量合成的配对数据训练深度神经网络，而这些高质量配对数据正是全监督方法取得成功的关键因素。然而，人工采集配对数据不仅成本高昂，在现实应用场景中严格意义上的配对数据往往难以获取。这些客观限制促使研究者转向无监督深度方法的探索[118,126-127]。

无监督深度学习方法不需要配对数据即可完成去模糊，但往往技术难度更高、挑战更大。由于缺乏配对数据的强约束，现有倾向于设计规模庞大的深度模型来寻找输入与输出间的弱连接，这通常导致模型推理时间过长。此外，当前无监督模型通常在诸多限制条件下执行去模糊任务，如仅适用于特定图像领域[126-127]、依赖多帧图像进行训练[118] 以及只能处理低分辨率输入等。这些局限性直接制约了无监督方法的实际场景中的应用。

中国知网 https://www.cnki.net

本章针对上述问题，提出一个简单高效的深度无监督基准模型。从性能角度考虑，该基准模型满足以下条件：1）模型性能优异，达到无监督方法的最先进水平；2）模型结构轻量化，满足主流设备的配置要求；3）推理速度快，可在实时场景下工作（处理时间低于 33.33 毫秒/帧）。从突破现有限制角度考虑，该基准模型还满足：1）无图像域限制，适用于任意图像领域；2）无分辨率限制，能处理高分辨率图像；3）无多帧输入限制，支持单输入-单输出映射。图4.1中比较了与当前最先进方法的综合性能，清晰表明本章所提方法在多个方面均优于当前最先进技术。

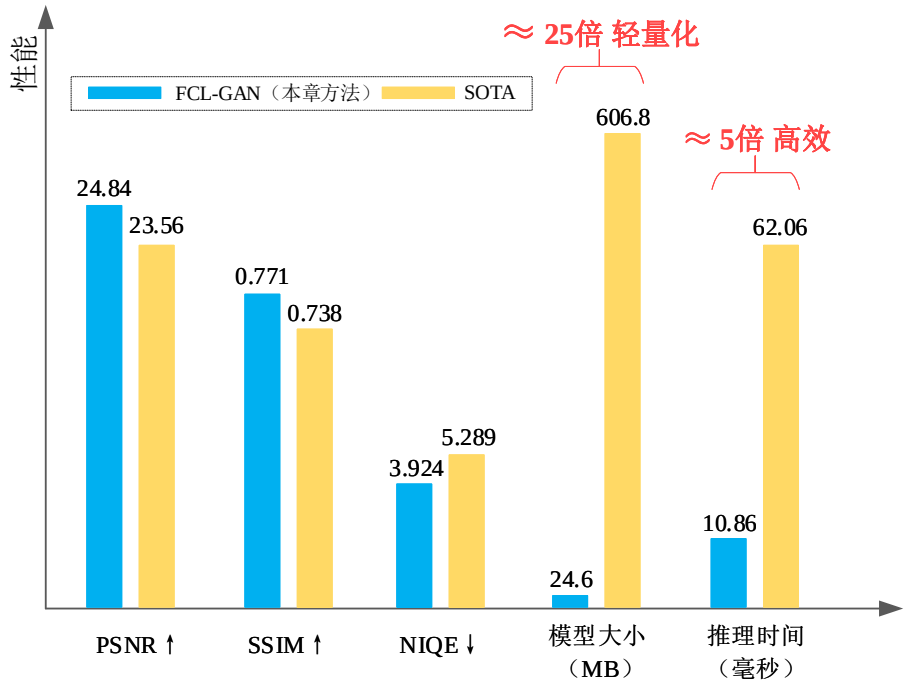


图 4.1　无监督去模糊方法综合性能对比

Fig. 4.1　Comparison of comprehensive performance among unsupervised deblurring methods

本章研究的核心贡献总结如下：

- 提出轻量型无监督去模糊新基准（FCL-GAN），并具备实时推理的能力。该方法通过频域对比损失约束的轻量级 CycleGAN 架构实现图像去模糊。研究设计的两个关键组件——轻量级域转换单元（LDCU）和无参频域对比单元（PFCU）协同工作，确保了模型的轻量级特性和实时处理能力，同时有效克服了现有无监督方法的局限性。这是首个兼具轻量级和实时特性的深度无监督去模糊方法，为该领域后续研究提供了一个基准。
- 针对传统 CycleGAN[125] 在去模糊任务中存在的色差严重、伪影明显及模型冗余等问题，本章对模型结构进行了系统性拆解与分析。在此基础上提出创新性的轻量级域转换单元（LDCU），该单元显著提升了模糊图像的处理质量，同时保持了轻量级和实时处理的优势。
- 引入频域对比学习（Frequency-domain Constrastive Learning, FCL）概念，设

中国知网　https://www.cnki.net

计无参数频域对比单元（PFCU），通过测量频域中潜在表示间的相似性作为对比约束，在不增加额外参数负担的前提下进一步提升去模糊效果。

- 在多个基准数据集上的广泛实验证明，FCL-GAN 在无监督去模糊领域取得了最先进性能，并展现出对真实世界模糊场景的卓越泛化能力。与现有最先进的方法相比，FCL-GAN 在模型体积（24.6MB 对比 606.8MB）和推理时间（0.011 秒对比 0.062 秒）方面均实现了显著优化。

4.2 相关工作和理论基础

图像去模糊相关的研究工作已经在第二章详细介绍，这里主要介绍和本章内容高度相关的图像去模糊相关工作和理论基础，包括：去模糊网络的模块与结构设计、基于频域信息的去模糊方法以及对比学习机制。

4.2.1 去模糊网络的模块与结构设计

近年来，卷积神经网络在图像去模糊任务中的应用取得了显著的进展，其模块设计和整体结构演变呈现出明确的技术发展脉络。**模块设计层面：**去模糊网络模块设计的重要转折始于 DeepDeblur[8] 这一里程碑式研究。该研究通过对比实验揭示了批量归一化（Batch Normalization, BN）层对去模糊任务的负面影响—移除 BN 层后，模型性能出现显著提升。这一发现对后续研究产生了深远影响，如 SRN[66] 等代表性工作均采纳了无 BN 设计范式，使“批量归一化不适用于图像去模糊”成为该领域的基本共识。在归一化策略方面，HINet 提出了颇具创新性的解决方案，打破了主流无归一化层的设计思路，首次在去模糊网络架构中引入实例归一化（Instance Normalization, IN）。这一创新被证明能有效提升模型性能，表明归一化技术的选择而非完全排除对去模糊效果至关重要。连接结构方面，DeblurGAN[9] 的研究强调了全局残差连接的核心作用。实验证据表明，移除残差连接会导致模型性能的显著下降，这一发现为后续网络设计提供了重要指导。**结构设计层面：**在网络整体结构设计上，DeepDeblur[8] 率先证实了多尺度技术相较于简单端到端结构的性能优势。这一结构设计理念被广泛采纳，形成了去模糊网络设计的主流范式。然而，传统多尺度结构存在推理延迟显著的固有缺陷。针对这一问题，MIMO-UNet[11] 提出了创新性解决方案，通过多输入多输出的设计思路，在概念层面实现了多尺度处理能力，同时保持端到端的网络结构。这一设计有效克服了传统多尺度方法的推理效率瓶颈，为高效去模糊网络的设计开辟了新路径。这些模块与结构设计的演进反映了图像去模糊领域对特定任务特性的深入理解，以及针对性优化策略的不断完善。随着研究的深入，这些设计原则将继续指导更高效、更精确的去模糊网络的开发。

中国知网 https://www.cnki.net

4.2.2 基于频域信息的去模糊方法

频域信息分析在图像去模糊技术中具有重要地位，这类方法通过系统性分析和处理图像的频率成分来实现清晰图像的复原。频域去模糊方法的基本理念建立在模糊过程主要影响图像高频成分这一观察基础上。频域信息作为图像复原领域的关键组成部分已得到广泛应用[11,70,148-149]。Song 等人[148] 通过构建小波空间注意力机制增强特征提取能力，有效改善了结构与边缘复原效果。Liu 等人[149] 则创新性地提出多层小波网络架构，专注于细节纹理和清晰结构的复原。尽管如此，去模糊领域对频域信息的利用仍显不足，存在较大的优化空间。目前，频域信息在去模糊方法中的应用主要体现为两种范式：一类是将频域损失函数（如频域 L1 损失）纳入优化目标，通过此类约束引导网络学习；另一类是在网络架构中直接整合频域变换与逆变换操作，使频域信息隐式融入学习过程。Cho 等人[11] 提出的频域重构损失通过将图像转换至频域并计算频域特征的 L1 范数来约束网络优化，显著提升了去模糊性能。Mao[70] 则通过引入残差快速傅里叶卷积模块（Residual FFT-Conv Block），在网络设计中显式整合快速傅里叶变换，虽然提高了去模糊效果，但同时也导致了训练与推理时间的明显增加。

4.2.3 对比学习机制

对比学习作为一种无监督学习范式，其核心机制在于通过样本间相似性与差异性的对比来提取具有判别力的特征表示。具体而言，该机制旨在将语义上接近的样本在特征空间中拉近，而将语义不同的样本在特征空间中推远。这一机制通常通过构建正样本对与负样本对来实现，其优化目标为使正样本对的特征表示距离最小化，同时使负样本对的特征表示距离最大化。这一学习过程常通过特定的对比损失函数来引导，其中 InfoNCE 损失是最为典型的代表，其数学表达式为：

$$\mathcal{L}_{\mathrm{NCE}} = -\log \frac{\exp(\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau)}{\sum_{k=1}^{N} \exp(\mathrm{sim}(\mathbf{z}_i, \mathbf{z}_k)/\tau)}, \tag{4.1}$$

其中，$\mathbf{z}_i$ 和 $\mathbf{z}_j$ 表示正样本对的特征向量，$\mathrm{sim}(\cdot)$ 通常为余弦相似度函数，τ 是一个温度超参数用于调控分布平滑度，N 是样本的总数。通过这种方式，模型能够在缺乏显式标注的条件下习得具有高判别能力的特征表示，在图像、文本等领域的无监督特征学习中得到广泛应用。

对比学习框架近年来已在计算机视觉领域展现出卓越的应用潜力。在高层视觉理解任务中，对比学习已成功应用于目标检测[150]、医学影像分割[151] 以及图像描述生成[152] 等领域，并取得了显著成效，引起学术界广泛关注。值得注意的是，对比学习的应用范围已从高层视觉理解任务扩展至底层视觉复原任务，并在图像去雾[153] 和图像去雨[154] 等领域达到了最先进水平。特别地，Chen 等人[154] 提出

中国知网　https://www.cnki.net

的 DCD-GAN 将对比学习引入无监督单帧图像去雨任务，通过在特征层面实施对比约束，有效提升了去雨效果，在无监督单帧图像去雨领域树立了新的性能标杆。对比学习作为一种强大的特征学习范式，通过其独特的对比机制，能够在无监督条件下捕获数据的内在结构，为各类视觉任务提供了新的解决思路和技术手段。

4.3 方法介绍

本章将详细介绍提出的轻量级且支持实时处理的无监督基准模型。

4.3.1 网络架构

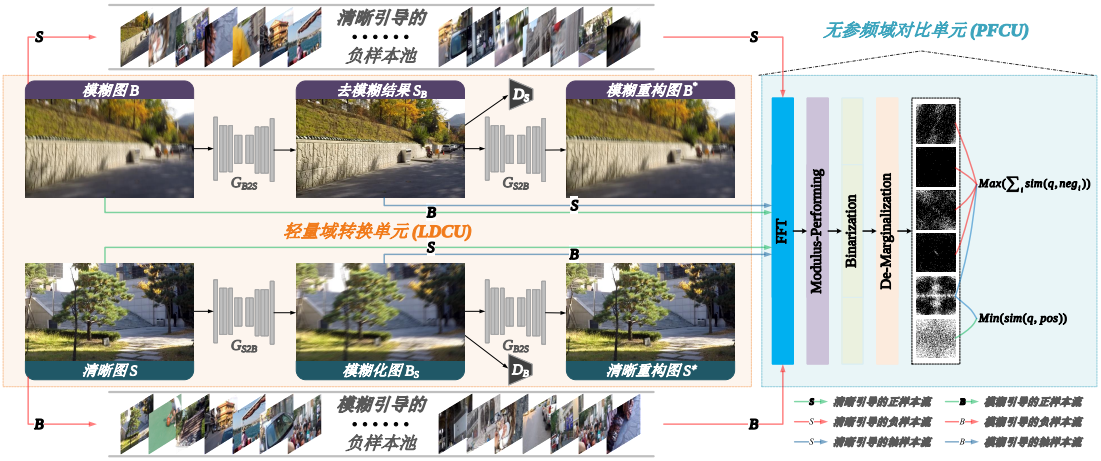


图 4.2　FCL-GAN 模型结构示意图

Fig. 4.2　Structural diagram of the FCL-GAN

图4.2中展示了 FCL-GAN 的架构和学习过程。该框架由两个关键协作单元组成：轻量级域转换单元（Lightweight Domain Conversion Unit, LDCU）和正样本引导对比学习单元（Parameter-free Frequency-domain Contrastive Unit, PFCU）。LDCU 作为轻量级单元，实现不同域图像间的相互转换；而 PFCU 则通过对比学习技术进行去模糊处理，使输出的锚点更接近正样本。以下详细阐述 LDCU 与 PFCU 间的交互机制。为便于理解，首先明确几个基本概念：

- **“流”**：指数据传输过程，例如，“正样本流”用于传输正样本及其潜在表示。当正样本为清晰图像时，该“流”被称为“清晰引导流”。
- **“样本池”**：用于存储先前训练轮次中使用的样本，样本池中的样本均为负样本。例如，在“清晰引导流”中，缓冲区内所有样本均为模糊图像。

LDCU 构成了 FCL-GAN 架构的基础，实现域间转换功能。如图 4.2 所示，LDCU 包含两个主要分支：即去模糊分支：$B \rightarrow S_B \rightarrow B^* \approx B$ 和模糊分支：$S \rightarrow B_S \rightarrow S^* \approx S$。与此对应，PFCU 对这两个分支施加不同的对比约束，即对去模糊分支应用清晰引导对比约束，对模糊分支应用模糊引导对比约束。以去模糊分支为例，潜在清晰图像 S_B、清晰图像 S 以及清晰引导负样本缓冲区中的图像分别作为锚点、正样本

中国知网　https://www.cnki.net

和负样本传入 PFCU，从而获取潜在表示。随后计算相似度并执行对比约束。值得注意的是，FCL-GAN 框架具有轻量级和实时性特点，这主要源于 LDCU 本身的轻量设计，以及 PFCU 在实际推理过程中不引入额外计算负担。

4.3.2 轻量级域转换单元

设 $\mathbb{D}_B$ 为模糊图像域，$\mathbb{D}_S$ 为清晰图像域，最终目标是将 $\mathbb{D}_B$ 中没有真值的图像映射到 $\mathbb{D}_S$。为此，本章引入轻量级域转换单元（LDCU）作为 FCL-GAN 的骨干网络。LDCU 包含两个生成器（G_{B2S} 和 G_{S2B}）及两个判别器（D_B 和 D_S）：G_{B2S}（G_{S2B}）负责将 $\mathbb{D}_B$（$\mathbb{D}_S$）中的图像映射到 $\mathbb{D}_S$（$\mathbb{D}_B$）；D_B（D_S）则负责判别 $\mathbb{D}_B$（$\mathbb{D}_S$）中图像的真实性。受到 DerainCycleGAN[155] 和 DCD-GAN[154] 的启发，本章设置了两个功能循环执行去模糊和模糊生成任务。以去模糊循环为例，给定 $\mathbb{D}_B$ 中的图像 $\boldsymbol{B}$，G_{B2S} 将 $\boldsymbol{B}$ 映射到 $\mathbb{D}_S$ 中的图像 $\boldsymbol{S}_B$，随后 G_{S2B} 将 $\boldsymbol{S}_B$ 重新映射回 $\mathbb{D}_B$ 中的图像 $\boldsymbol{B}^*$，即 $\boldsymbol{B}\rightarrow\boldsymbol{S}_B\rightarrow\boldsymbol{B}^*\approx\boldsymbol{B}$。在整个去模糊循环中，$D_S$ 用于判别 $\boldsymbol{S}_B$ 是否确实属于 $\mathbb{D}_S$。模糊生成循环则接受 $\mathbb{D}_S$ 中的图像进行逆向映射，即 $\boldsymbol{S}\rightarrow\boldsymbol{B}_S\rightarrow\boldsymbol{S}^*\approx\boldsymbol{S}$。

从本质上讲，在 $\mathbb{D}_B$ 和 $\mathbb{D}_S$ 间转换图像可视为图像到图像的翻译任务。作为该领域经典框架，CycleGAN[125] 具备强大的域间差异学习能力。然而，直接应用 CycleGAN 无法达到预期的去模糊效果，主要源于以下原因：1）网络架构不兼容性。与常规图像到图像翻译任务不同，去模糊方法的网络架构需经精心设计，即使微小的结构变化（如将批量归一化替换为实例归一化）也可能严重影响结果，这在先前的去模糊研究和本章额消融实验中得到验证；2）任务复杂度差异。传统图像到图像翻译任务（如斑马 ↔ 马、橙子 ↔ 苹果）通常具有明确的域间特征差异，深度网络可轻松学习这些差异。而图像去模糊的域间差异则更为复杂，这体现在模糊程度的多样性上。极端情况下，当模糊程度极高时，几乎无法从图像中提取任何有效信息；当模糊程度极低时，模糊图像几乎可视为清晰图像。因此，直接将 CycleGAN 应用于去模糊任务会导致色彩偏差、严重伪影和参数冗余等问题，如图4.3所示。

基于上述分析，本章致力于轻量级网络设计与效率提升。具体而言，对 LDCU 进行全面的递归分解，精细设计每个最小组件，并用这些组件重构整个单元。本章主要优化 LDCU 中的生成器，因其承担域转换的直接表征任务，是 LDCU 的核心组件。通常，在生成-判别结构中，生成器参数量远高于判别器，这源于充足参数能更好发挥深度神经网络的非线性映射能力。然而，当参数量达到一定阈值后，生成器性能趋于饱和，过多参数导致模型冗余，严重阻碍模型推理与部署。

为最小化模型冗余，本章从底层到顶层引入并执行以下操作：1）元设计；2）轻量级结构设计。下文将详细阐述这些操作方法。

中国知网　https://www.cnki.net

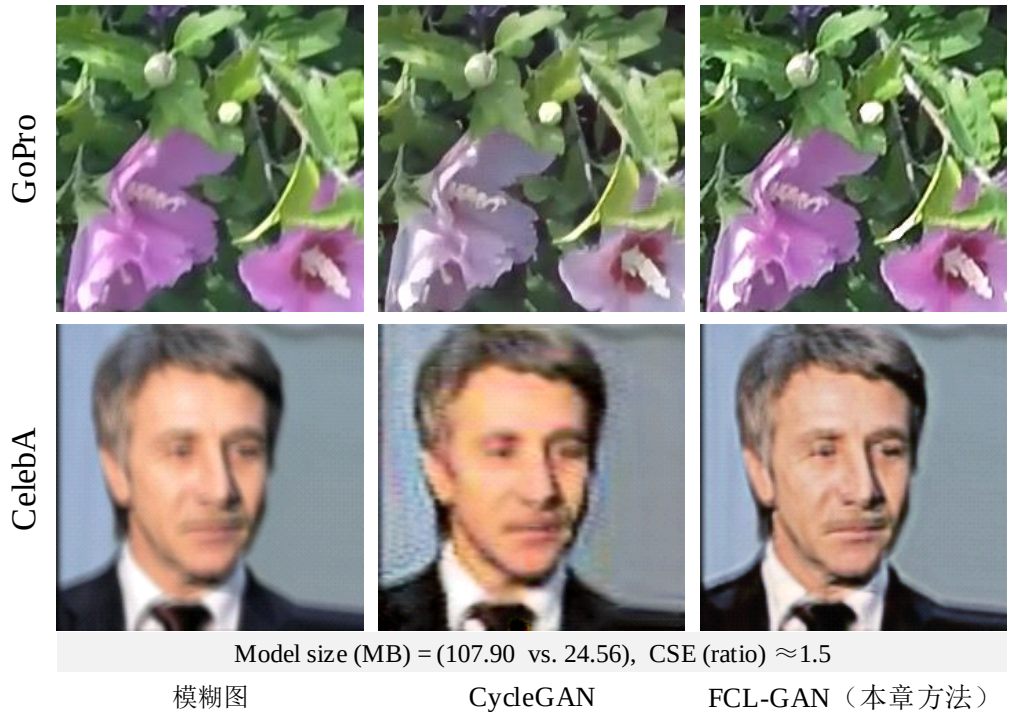


图 4.3　CycleGAN 在去模糊任务中的固有缺陷

Fig. 4.3　Inherent defects of CycleGAN in deblurring task

元[①]设计。卷积神经网络（CNN）由多种基础功能单元构成，这些单元包括卷积层、归一化层和激活层等，各自承担不同的功能任务。如何高效组织这些基础单元以构建有效的去模糊网络，是需要深入探究的关键问题。在 CNN 架构中，卷积层（Conv）和 ReLU 等激活函数通常被视为核心组件，它们分别赋予网络参数学习能力和非线性拟合能力。同时，归一化单元在网络架构设计中扮演着至关重要的角色，对去模糊模型的性能产生深远影响。

根据前述在本章相关工作中的讨论，在全监督去模糊任务中，研究者通常避免在模型结构中引入归一化单元（除少数研究如 HINet[71] 使用了实例归一化 IN），这是因为在强约束条件下，额外的归一化层可能会显著阻碍模型学习准确的“1 对 1”的“模糊 → 清晰”映射[8,66]。相比之下，图像到图像转换和风格迁移领域的研究倾向于采用实例归一化（IN）进行模型设计，因为这些任务本质上需要学习特定的“1 对 1”风格映射[123,125]。无监督去模糊任务呈现出独特的挑战，由于缺乏配对数据的强约束以及模糊程度的多样性，该任务实质上表现为“多对多”的风格映射问题。在此场景下，批量归一化（BN）通过对批次内多个样本进行统一处理，比实例归一化更适合捕捉域间全局差异特征，从而更有效地服务于无监督去模糊任务的需求。

基于上述理论分析，本章提出两种基本构建单元概念用于模型设计：基本元

[①]卷积神经网络由一系列不可分割的基础单元构成，包括卷积层、归一化层及激活层等。本章将这些基础单元的有效组合定义为“元”

中国知网 https://www.cnki.net

（BasicMeta）和残差元。基本元定义为不包含残差连接[78] 的基础结构单元，而残差元在其内部结构中至少包含一个残差连接。具体而言，基本元的设计采用以下结构：

$$Y = ReLU\left(BN\left(Conv\left(X\right)\right)\right), \tag{4.2}$$

其中 X 为输入特征，Y 为输出特征。对于残差元的设计，采用如下结构：

$$Y = X + Norm\left(Conv\left(BasicMeta\left(X\right)\right)\right), \tag{4.3}$$

其中 X 为输入特征，Y 为输出特征，$BasicMeta(\cdot)$ 为基本元操作，$Norm(\cdot)$ 为归一化层，本章取 BN 作为主要归一化策略。图4.4展示了不同形式基本元和残差元的结构对比。关于所提出的基本元和残差元的重要性及有效性，将在后续消融实验部分进行详细分析与验证。

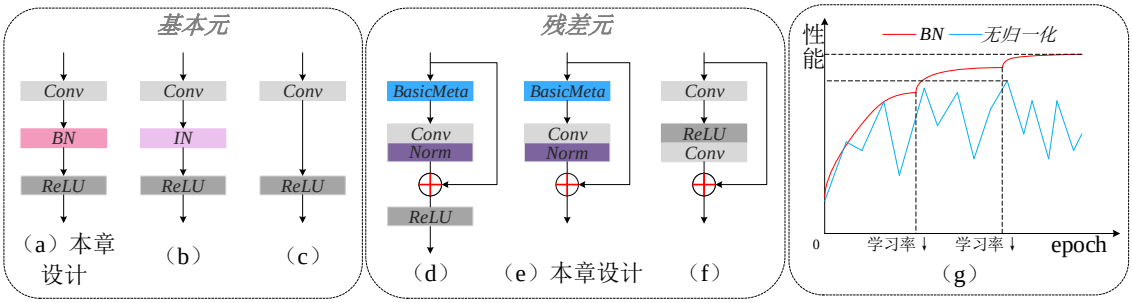


图 4.4　基本元和残差元的不同组成形式对比

Fig. 4.4　Comparison of different compositional forms of basic metas and residual metas

轻量级结构设计。现有端到端模型主要基于两种典型架构：单尺度结构[156]（见图4.5（a））或编码器-解码器结构[8]（见图4.5（b））。单尺度结构能够有效保持精确的空间信息，但在抽象图像高级语义内容方面存在局限性。相比之下，编码器-解码器结构擅长抽象内容信息，却难以完整保留图像的空间细节。在参数量相等的配置下，两种结构各有优劣。然而，从计算效率角度分析，单尺度结构因需在原始分辨率上进行全程计算，缺少降采样过程，导致推理速度较慢，难以满足实际去模糊应用种的实时处理需求。

基于对现有架构优缺点的深入分析，Zamir 等人[69] 尝试在编码器-解码器结构后附加原始分辨率处理模块，以平衡两种架构的优势。然而，这种方法虽然提升了性能，却同时引入了额外的参数负担和推理时间开销。受 Cho 等人[11] 的工作启发，本章提出一种创新架构——轻量级编码器-解码器（Lightweight Encoder-Decoder, LED），如图4.5（c）所示。LED 巧妙融合了编码器-解码器和单尺度结构的优势，既保留了编解码过程以有效抽象图像内容，又在较高分辨率层次上堆叠残差元，从而更好地保留空间细节信息。

图4.6（a）清晰呈现了 LED 与编码器-解码器的结构差异：传统编码器-解码器将残差元集中于深层网络，而本章提出的 LED 架构允许这些模块分布于浅层，形

中国知网　https://www.cnki.net

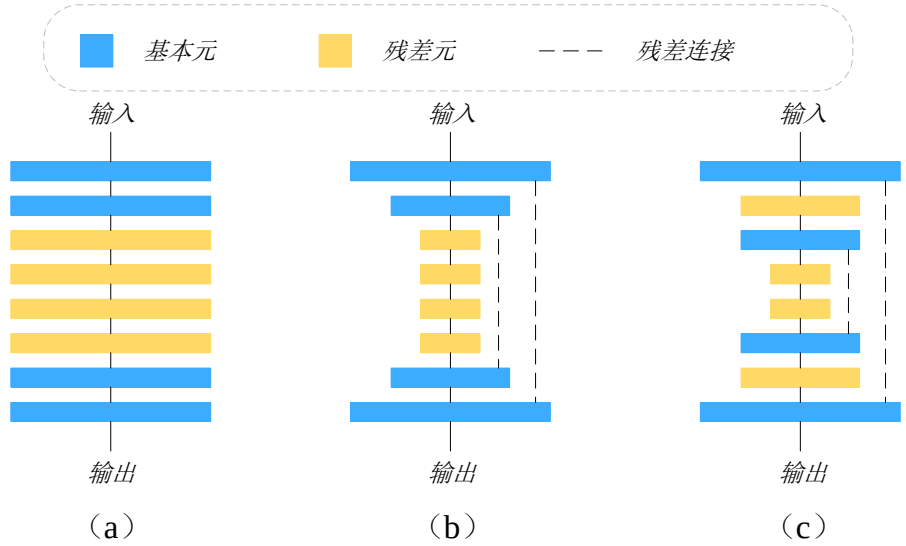


图 4.5　深度模型的不同结构对比

Fig. 4.5　Comparison of different structures of deep models

成更灵活的特征提取路径。图4.6（b）和（c）对比展示了两种结构在相同配置下的参数量和计算复杂度。值得注意的是，参数量方面，编码器-解码器结构与单尺度结构相当；计算量方面，编码器-解码器结构低于单尺度结构。然而，从图4.6的分析结果可见，LED 架构实现了显著的参数量降低，同时保持与编码器-解码器相当的计算复杂度。综上所述，LED 架构成功整合了编码器-解码器结构和单尺度结构的优势，在不增加计算负担的前提下实现了模型轻量化。后续的消融研究将进一步验证所提出 LED 结构的有效性。

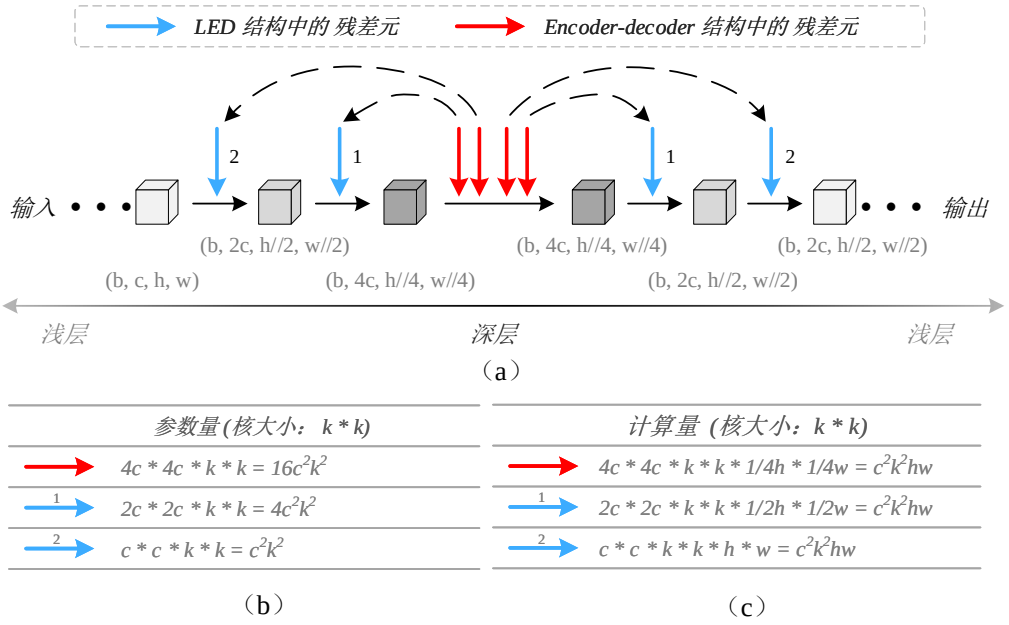


图 4.6　不同结构的参数量和计算量对比

Fig. 4.6　Comparison of parameter quantity and computational cost for different structures

中国知网　https://www.cnki.net

4.3.3 无参频域对比单元

频域分析为理解模糊与清晰图像的本质差异提供了独特视角。在空间域中，这些差异往往难以精确量化，而频域分析则揭示了一个关键特征：模糊图像本质上缺失了清晰图像所具备的高频信号成分。根据前述相关工作分析，现有研究虽已在图像去模糊任务中尝试利用频域信息，但主要局限于两种途径：一种是在潜在图像与真实图像间施加频域约束[11]，另一种是在模型架构中直接整合快速傅里叶变换（Fast Fourier Transform, FFT）及其逆变换（Inverse Fast Fourier Transform, IFFT）[70]。然而，这些方法不仅依赖于真实图像作为参照，其内部机制也缺乏足够的透明度和可解释性。

通过对大量模糊与清晰图像在频域表现的系统分析发现，在未经归一化处理的频域表示中，模糊图像倾向于呈现全黑状态，而清晰图像则趋于全白。更重要的是，模糊程度与频域图像的暗度呈正相关，如图4.7所示。尽管这一发现具有启发性，但在无监督条件下直接量化这种频域差异仍面临巨大挑战，因此对比学习方法成为解决此类问题的理想选择。

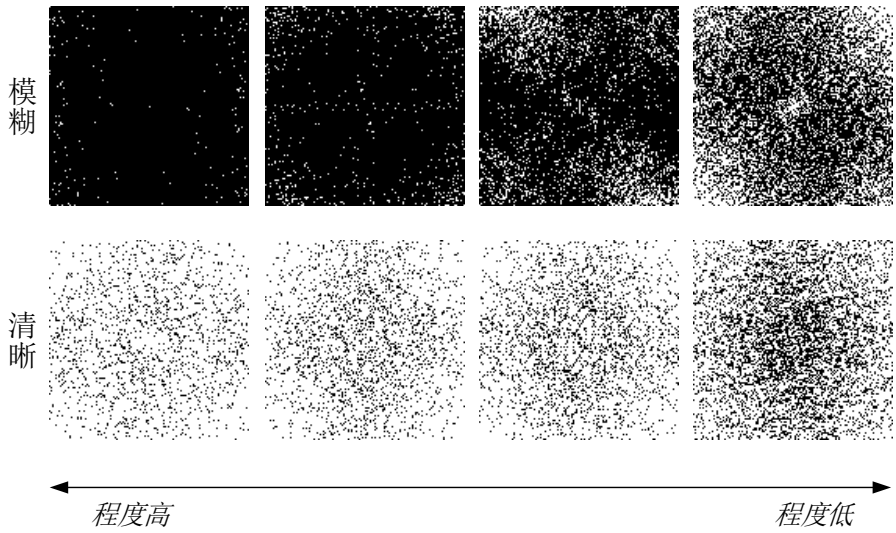


图 4.7　不同程度的模糊和清晰图像在频域中的视觉效果

Fig. 4.7　Visual effects of images with varying degrees of blur and sharpness in frequency domain

对比学习的有效实施需要解决两个核心问题：（1）如何获取样本的潜在表示？（2）如何度量潜在表示间的相似性？DCD-GAN[154] 通过增设专门分支获取潜在表示并采用余弦相似度计算距离，但这种设计容易导致模型过度关注附加分支而忽视主要任务目标。

本章基于轻量级设计原则，提出了一种创新的无参数频域对比单元（PFCU），用于实现高效的频域对比学习。如图4.2所示，PFCU 由四个关键组件构成：FFT 层、模计算层、二值层和去边缘化层。具体工作流程为：给定输入图像 I，FFT 层首先基于快速傅里叶变换将其转换为复数形式的频域表示 I_f。随后，模计算层对 I_f 取

中国知网　https://www.cnki.net

模，生成实数空间表示 I_r。二值层旨在根据 I_r 获取二值表示的 I_b。最后，去边缘化层保留 I_b 的中心区域，进一步突显频域特征变化，最终获得输入 I 的潜在表示 P_I。整个潜在表示获取过程可表述为：

$$P_I = PFCU(I). \tag{4.4}$$

获取图像的潜在表示后，计算潜在表示之间的相似度成为亟待解决的核心问题。值得注意的是，传统余弦相似度方法在本场景下存在明显局限性，主要体现在两方面：一是本场景下计算潜在表示过程中缺乏可学习参数，无法和余弦相似度方法协同优化；二是频域图像间的微小差异可能导致相似度得分不合理偏低，如图4.8所示。针对这一问题，本章提出一种基于黑色覆盖率差异的新型相似度度量方法。具体而言，给定两个潜在表示 P_1 和 $P_2 \in \mathbb{R}^{h\times w}$ 以及超参数 ω，首先将 P_1，P_2 进行分块处理，得到 P_{b1}，$P_{b2} \in \mathbb{R}^{\frac{h\times w}{\omega^2}\times\omega\times\omega}$，随后计算每个块的黑色覆盖率，获得 R_{b1}，$R_{b2} \in \mathbb{R}^{\frac{h\times w}{\omega^2}}$。单个块的黑色覆盖率计算如下：

$$R_b = \frac{\sum_{i=0}^{\omega}\sum_{j=0}^{\omega}(1-b_{i,j})}{\omega^2}, \tag{4.5}$$

其中 $b \in \mathbb{R}^{\omega\times\omega}$ 表示分块潜在表示中的一个块（即上述 P_{b1} 和 P_{b2} 中的块），$b_{i,j}$ 是 b 的第 i 行第 j 列元素，ω 是 b 的尺寸。

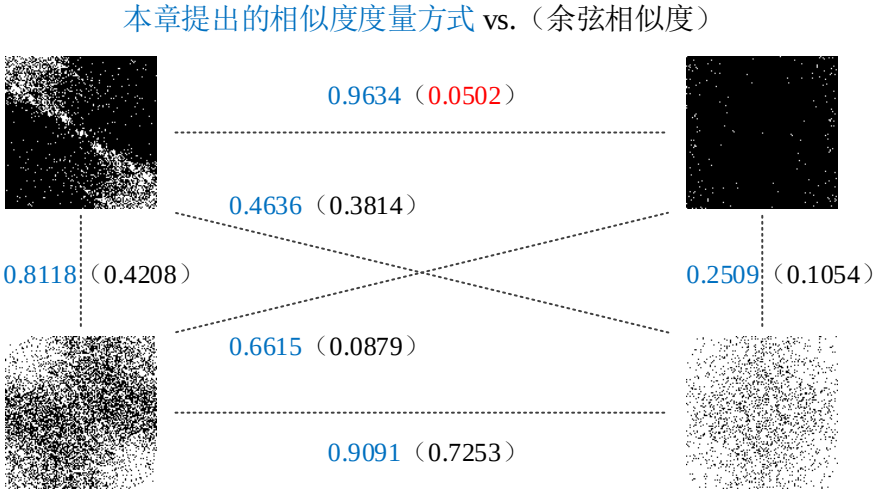


图 4.8　不同相似度度量方式的对比

Fig. 4.8　Comparison of different similarity measurement methods

基于获得的黑色覆盖率 R_{b1} 和 R_{b2}，在频域中定义相似度计算方式如下：

$$Sim = 1 - MSE(R_{b1}, R_{b2}). \tag{4.6}$$

为简化表述，用 $sim(p_1, p_2)$ 表示计算两个潜在表示（P_1、P_2）间相似度的完整

中国知网　https://www.cnki.net

过程。图4.8中展示了一些相似度的计算结果，证实了所提出的相似度计算方法较余弦相似度的显著优势。解决了潜在表示获取与相似度计算问题后，对比学习可有效应用于 FCL-GAN 框架。具体而言，给定一个锚点样本 p、一个正样本 p^+ 和几个负样本 p^-，训练过程中引入如下对比损失优化网络：

$$\mathcal{L}_{ctst}(p,p^+,p^-) = -log[\frac{e^{sim(p,p^+)/\tau}}{e^{sim(p,p^+)/\tau} + \sum_{n=1}^{N} e^{sim(p,p^-)/\tau}}], \tag{4.7}$$

其中 N 代表负样本数量，τ 为温度系数，在所有实验中设定为 0.07。

4.3.4 损失函数

除前述对比损失 $\mathcal{L}_{ctst}$ 外，本章还整合对抗损失 $\mathcal{L}_{adv}$，循环一致性损失 $\mathcal{L}_{cc}$ 和 TV 正则化 $\mathcal{L}_{tv}$ 共同约束训练过程。其中，TV 正则化 $\mathcal{L}_{tv}$ 仅作用于复原的清晰图像，以抑制噪声并保持结构一致性；而对抗损失、循环一致性损失和对比损失则同时应用于清晰与模糊两个图像域，确保双向转换的质量与稳定性。经过实验验证，这些损失函数的最优权重配比为：$\mathcal{L}_{total}=\mathcal{L}_{adv}+10*\mathcal{L}_{cc}+0.1*\mathcal{L}_{ctst}+0.1*\mathcal{L}_{tv}$。该配置能够在保持图像结构完整性的同时，有效去除模糊伪影并增强图像细节。

4.4 实验分析

本章对 FCL-GAN 进行了全面的定性与定量评估，并与相关模型进行系统性比较。基准模型基于 PyTorch 1.10 版本实现，所有实验均在配备 24G 显存的 NVIDIA RTX 3090 显卡上完成。

4.4.1 实验设置

数据集。本章评估采用四个广泛应用的图像数据集：自然图像数据集 GoPro[8]、人物感知模糊数据集 HIDE[130]、特定领域的人脸数据集 CelebA[131] 以及真实世界模糊数据集 RealBlur（包含 RealBlur-J 和 RealBlur-R 子集）[132]。这些数据集涵盖了不同场景和模糊类型，为全面评估去模糊方法性能提供了坚实基础。

评估方法。本章将 FCL-GAN 与十二种现有方法进行比较，这些方法涵盖了不同的技术路线：包括五种传统方法：Pan 等人[7,41,49] 提出的三种方法、Xu 等人[42] 提出的方法、Krishnan 等人[40] 提出的方法；四种配对数据驱动的全监督方法：Gong 等人[56] 提出的方法、DeblurGAN[9]、DeepDeblur[8]、SRN[66]；以及三种非配对数据驱动的无监督方法：DualGAN[123]、CycleGAN[125]、UID-GAN[127]。评估在设置一致的情况下优先采用各官方发布的预训练模型；对于设置不一致或未提供预训练模型的情况，则依据原作者提供的代码和推荐配置重新训练以确保公平比较。

评估指标。本章采用多维度评估体系，包括参考型、无参考型及色彩特性指标，以全面衡量图像增强模型性能。具体而言，评估采用两种广泛应用的参考指标（PSNR 和 SSIM[133]）、一种无参考指标（NIQE[137]）和一种色差指标（CSE）。

中国知网　https://www.cnki.net

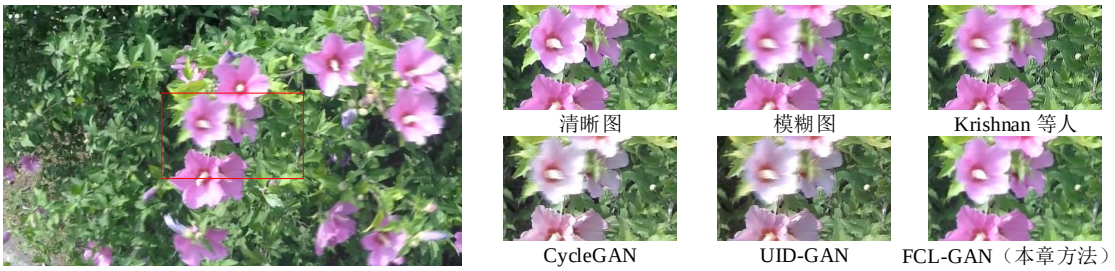


图 4.9　在 GoPro 数据集上的可视化结果对比

Fig. 4.9　Comparison of visualization results on the GoPro dataset

表 4.1　在 GoPro 和 HIDE 数据集上的定量结果对比

Tab. 4.1　Comparison of quantitative results on the GoPro and HIDE dataset

模式	方法	GoPro[8]				HIDE[130]		
		PSNR↑	SSIM↑	CSE↓	NIQE↓	PSNR↑	SSIM↑	CSE↓
全监督	Gong 等人[56]	26.40	0.863	-	-	-	-	-
	DeepDeblur[8]	29.08	0.914	-	4.921	25.73	0.874	-
	SRN[66]	30.26	0.934	-	4.834	28.36	0.915	-
无监督	CycleGAN[125]	22.54	0.720	2.676	4.359	21.81	0.690	3.300
	DualGAN[123]	22.86	0.722	4.384	4.176	-	-	-
	UID-GAN[127]	23.56	0.738	1.532	5.289	22.70	0.715	2.147
	FCL-GAN	24.84	0.771	1	3.924	23.43	0.732	1

表 4.2　在 GoPro 数据集上关于推理时间和模型大小的对比

Tab. 4.2　Comparison of inference time and model size on the GoPro dataset

指标	Gong 等人	DeepDeblur	SRN	CycleGAN	DualGAN	UID-GAN	FCL-GAN
推理时间（毫秒）	-	4330	1870	12.55	-	62.06	10.86
模型大小（MB）	39.00	89.40	27.50	107.90	324.20	606.80	24.56

值得强调的是，为精确量化各模型间性能差异，本章采用标准化比率法进行数据展示。该方法将性能最优模型的相应指标值标准化为基准值 1，其他模型则以相对于此基准的比率形式呈现。这种规范化处理方法使性能差距可视化，便于直观识别各方法的相对优劣势。此外，本章同步考察模型规模参数，以评估模型的轻量化程度；并通过 NVIDIA RTX 2080 Ti 显卡上的推理时间客观评估各模型在实际应用场景中的计算效率。在结果呈现中，符号 ↑ 表示该指标数值越高表明性能越佳，而符号 ↓ 则表示该指标数值越低代表性能越佳，最佳性能用红色标记。

实现细节。模型训练配置为 80 个 epoch，采用 Adam[144] 优化器，参数设置为 β_1=0.5 和 β_2=0.999。初始学习率为 0.0001，然后每训练 20 个周期衰减为原值的 1/2。数据增强策略包括：首先将图像统一裁剪为 256×256 尺寸，随后以 0.5 概率顺序执行水平翻转和垂直翻转。在对比学习框架中，每个轴样本对应的负样本数量设定为 8。值得注意的是，在推理阶段，为保持图像完整性和细节，方法直接处

中国知网　https://www.cnki.net



图 4.10　在 CelebA 数据集上的可视化结果对比

Fig. 4.10　Comparison of visualization results on the CelebA dataset

表 4.3　在 CelebA 数据集上的定量结果对比

Tab. 4.3　Comparison of quantitative results on the CelebA dataset

模式	方法	PSNR↑	SSIM↑	CSE↓
传统	Pan 等人[49]	15.16	0.380	-
	Xu 等人[42]	16.84	0.470	-
	Pan 等人[41]	17.34	0.520	-
	Pan 等人[7]	17.59	0.540	-
	Krishnan 等人[40]	18.51	0.560	-
全监督	DeblurGAN[9]	18.86	0.540	-
	DeepDeblur[8]	18.26	0.570	-
无监督	CycleGAN[125]	19.40	0.560	1.918
	UID-GAN[127]	20.81	0.650	2.279
	FCL-GAN	21.07	0.652	1

理原始尺寸图像而不进行裁剪，从而获取原始分辨率的去模糊结果。

4.4.2 实验结果及分析

（1） 在 GoPro 数据集上的结果

本章首先针对 GoPro 自然图像数据集进行了系统性的训练与评估实验，详细结果呈现于表4.1和图4.9。实验数据表明，FCL-GAN 模型在处理自然场景模糊图像方面展现出显著优势。该模型不仅在图像质量评估指标上全面超越现有深度无监督图像去模糊方法，同时在计算效率方面也具备突出表现。如表4.2所示，FCL-GAN 在推理时间与参数量这两个关键指标上实现了更为优化的平衡，表现出卓越的计算资源利用效率。这一系列实验结果充分证实了 FCL-GAN 框架在自然图像去模糊任务中的卓越性能和高计算效率，为实际应用场景提供了一种兼具效果与效率的解决方案。

（2） 在 HIDE 数据集上的结果

为系统评估各模型的跨数据集泛化能力，本章直接应用 GoPro 数据集上预训练的模型到 HIDE 人物感知模糊数据集。如表4.1所示，FCL-GAN 在此跨数据集应用场景中展现出显著的泛化性能优势，其去模糊效果明显优于同类深度无监督方

中国知网　https://www.cnki.net

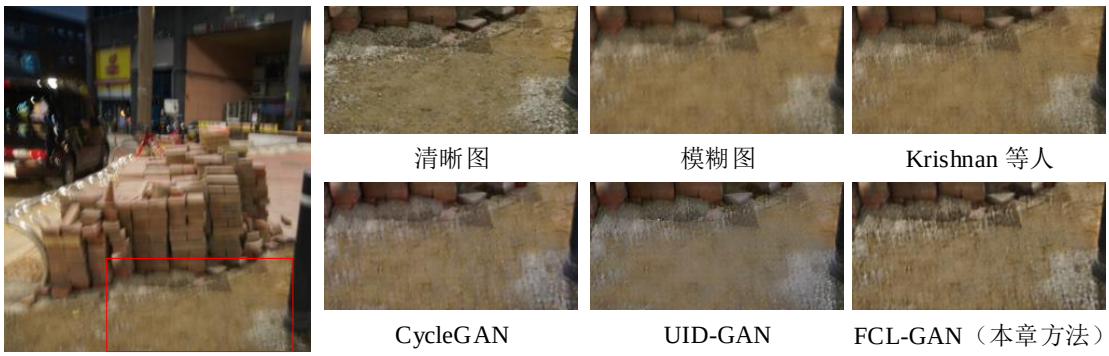


图 4.11　在 RealBlur-J 数据集上的可视化结果对比

Fig. 4.11　Comparison of visualization results on the RealBlur-J dataset

表 4.4　在 RealBlur 数据集上的定量结果对比

Tab. 4.4　Comparison of quantitative results on the RealBlur dataset

模式	方法	RealBlur-J[132]			RealBlur-R[132]		
		PSNR↑	SSIM↑	CSE↓	PSNR↑	SSIM↑	CSE↓
全监督	DeblurGAN[9]	27.97	0.834	-	33.79	0.903	-
	DeepDeblur[8]	27.87	0.827	-	32.51	0.841	-
无监督	CycleGAN[125]	19.79	0.633	2.898	12.38	0.242	3.024
	UID-GAN[127]	22.87	0.671	1.394	16.64	0.323	2.985
	FCL-GAN	25.35	0.736	1	28.37	0.663	1

法。这一实验结果有力地表明，FCL-GAN 所学习的去模糊特征表示具有更强的域适应能力，能够有效应对不同场景、不同成因下的模糊降质问题，充分证明了该模型在实际应用中的鲁棒性和适应性。

（3） 在 CelebA 数据集上的结果

为评估各方法处理特定领域模糊图像的能力，本章在 CelebA 人脸数据集上进行了专门的训练与测试。从表4.3和图4.10可以明确观察到，FCL-GAN 在所有无监督方法中再次取得最佳性能和视觉效果。值得注意的是，在这种特定领域场景下，深度无监督方法普遍优于部分深度监督方法。

（4） 在 RealBlur 数据集上的结果

为验证各模型应对真实世界模糊的处理能力，本章直接应用 GoPro 数据集上预训练的模型到 RealBlur 真实模糊数据集上进行测试，实验结果如表4.4和图4.11所示。定量分析结果明确表明，FCL-GAN 在所有无监督方法中表现最为出色，在关键图像质量指标上均取得领先。图4.11的视觉对比进一步证实，FCL-GAN 能够更有效地处理真实世界的复杂模糊图像，不仅能复原更多细节信息，还能保持更高的整体视觉质量。值得注意的是，直接利用在 GoPro 数据集上预训练好的模型，可以更纯粹地检验模型对不同真实模糊场景的泛化能力，避免因在目标数据集上重新训练而引入数据偏差，从而更客观地评估模型在应对真实世界模糊问题时的实

中国知网　https://www.cnki.net

表 4.5　在 GoPro 和 CelebA 数据集上关于损失函数的消融实验结果

Tab. 4.5　Ablation study results of loss functions on the GoPro and CelebA datasets

数据集	移除 $\mathcal{L}_{ctst}$		移除 $\mathcal{L}_{tv}$		FCL-GAN	
	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑
GoPro[8]	24.56	0.749	24.73	0.765	**24.84**	**0.771**
CelebA[131]	20.83	0.648	21.01	0.651	**21.07**	**0.652**

表 4.6　在 GoPro 数据集上关于元组合的消融实验结果

Tab. 4.6　Ablation study results of meta-combinations on the GoPro dataset

元组合	基本元	残差元	PSNR↑	SSIM↑
（a）+（d）	（a）	（d）	23.61	0.736
（a）+（e）	（a）	（e）	**24.84**	**0.771**
（b）+（d）	（b）	（d）	19.40	0.635
（b）+（e）	（b）	（e）	20.11	0.641
（c）+（d）	（c）	（d）	23.47	0.729
（c）+（e）	（c）	（e）	24.55	0.765
（c）+（f）	（c）	（f）	24.20	0.762

表 4.7　在 GoPro 数据集上关于不同结构的消融实验结果

Tab. 4.7　Ablation study results of different structures on the GoPro dataset

结构	PSNR↑	SSIM↑	模型大小↓	推理时间↓
编码器-解码器结构	24.66	0.763	50.30（MB）	15.19（毫秒）
单尺度结构	24.69	0.770	50.30（MB）	76.94（毫秒）
LED 结构	**24.84**	**0.771**	**24.56（MB）**	**10.86（毫秒）**

际性能。这种在真实模糊场景下的良好性能对模型得实际应用具有重要意义，也表明 FCL-GAN 具备处理实际环境中各种复杂模糊情况的能力。

4.4.3 消融实验及分析

本章通过消融实验，系统评估了所提出方法中各个组件的有效性，包括损失函数、基本元和残差元模块以及整体网络结构。实验在 GoPro[8] 和 CelebA[131] 数据集上进行，并基于客观指标进行量化分析。

（1） 损失函数的有效性

为验证本章所提出的损失函数设计的有效性，本研究在 GoPro 和 CelebA 数据集上对总变差损失函数 $\mathcal{L}_{tv}$ 和对比损失函数 $\mathcal{L}_{ctst}$ 分别进行了消融实验。表4.5中的实验结果清晰表明，两种损失函数组件均对模型性能产生了显著的积极影响。

中国知网　https://www.cnki.net

（2） 所设计的基本元和残差元的有效性

本章设计并验证了三种不同形式的网络基础构建模块，如图4.4所示。对于基本元模块，本研究系统性地考察了以下三种结构形式：（a）Conv-BN-ReLU 结构，（b）Conv-IN-ReLU 结构，以及（c）Conv-ReLU 结构。同时，对于残差元模块，本研究也探究了三种不同配置：（d）残差块的标准形式[78]；（e）是（d）的简化版本；（f）在图像全监督去模糊领域中应用最为广泛的结构形式[8,11,67]。

表4.6全面展示了基本元模块与残差元模块各种组合配置下的性能评估结果。通过系统分析，本研究得出以下适用于无监督图像去模糊任务的关键结论：1）归一化方法对性能提升的贡献程度依次为：批归一化（BN）> 无归一化 > 实例归一化（IN）；2）无监督训练模式中引入实例归一化可能会导致模型性能的显著下降；3）简化版本的残差元模块在无监督去模糊任务中表现更为出色。值得一提的是，实验数据显示无归一化方法与批归一化在某些指标上呈现出相近的性能表现。然而，深入的实验观察发现，无归一化策略往往导致训练过程不稳定，如图4.4（g）所示的训练波动曲线所证实。

（3） LED 结构的有效性

本章提出的轻量级效率去模糊网络（LED）结构与图4.5中展示的其他两种主流结构进行了全面比较，评估维度包括去模糊性能、模型参数量以及推理时间。表4.7详细呈现了这一多维度比较的结果。实验数据明确表明，本章提出的 LED 结构在保持更小模型体积和更快推理速度的同时，还实现了更优的去模糊性能。

4.5 本章小结

本章通过对现有无监督深度图像去模糊技术的全面分析，揭示了这些方法固有的局限性，并提出了一个轻量级实时无监督图像去模糊基线（FCL-GAN）。该基线基于创新设计的轻量级域转换单元和无参数频域对比单元，成功构建了一个高效去模糊模型。轻量级域转换单元通过基本单元和基本结构的轻量化设计，极大地减少了参数量的同时保持了模型的表达能力。通过在频域中系统研究模糊与清晰图像的本质差异，无参数频域对比单元引入了频域对比学习，在频域中迫使复原图像特征逼近清晰图像特征，进而提升去模糊效果。定量与定性评估结果均表明，所提出的方法在无监督图像去模糊领域取得了领先的性能表现，达到了当前最先进（SOTA）水平。在计算效率方面，FCL-GAN 在轻量级设计和实时推理性能上全面超越了现有的图像去模糊模型，无论是全监督还是无监督方法。具体而言，在 NVIDIA RTX 2080 Ti 显卡上，该方法能以极高效率处理 1280×720 高分辨率图像，仅需 0.011 秒，充分满足实时应用需求。

中国知网 https://www.cnki.net

第五章 基于噪声自回归的无监督低光照图像去模糊方法

前两章分别探讨了无监督图像去模糊中的色差问题和模型复杂度问题，并提出了相应解决方案：基于模糊偏移估计的色彩保留网络和基于频域对比损失的轻量级网络。本章继续深入研究，将视角聚焦于更为复杂的实际应用场景——低光照与模糊的复合退化现象。实际应用的复杂环境中，图像退化往往呈现复合特性，低光照与模糊的复合退化尤为普遍。针对此类复合退化，现有去模糊方法难以处理，复合退化处理方法通常采用以下策略：1）级联处理策略：先后应用不同处理模型，但这不仅增加计算复杂度，还容易产生误差累积；2）专门训练策略：针对特定复合退化数据训练专用模型，但这显著提高了数据获取难度。更为关键的是，这些方法严重依赖训练数据分布，当推理阶段的数据分布偏离训练数据时，处理效果往往显著下降。为克服上述局限，本章提出一种基于无监督去模糊范式的低光照图像去模糊方法（DEvUDP）。该方法的核心创新在于将噪声自回归技术融入无监督去模糊框架，构建一个能够同时处理多种退化（模糊，低光照以及复合退化）的统一模型。DEvUDP 采用双分支架构，转换分支学习退化图像到清晰图像的映射关系；回归分支则利用噪声自回归机制，提升模型对低光照退化的理解和处理能力，并抑制低光照噪声。DEvUDP 的显著优势在于其训练过程仅需不成对的模糊-清晰图像数据，无需低光照-正常光照配对数据或专门的复合退化样本，从而大幅降低了数据获取和训练成本。此外，通过灵活调整网络组件，该方法能够在感知性能（视觉质量）和失真性能（量化指标）之间取得平衡，以适应不同的应用需求。大量实验表明，DEvUDP 不仅能有效处理单一退化问题（如仅模糊或仅低光照），更在复合退化场景中展现卓越性能，为实际应用环境中的复杂退化问题提供了一种高效且适应性强的解决方案，进一步拓展了无监督图像去模糊技术的应用范围。

5.1 本章概述

图像复原与增强作为计算机视觉中的基础技术，旨在通过消除各类退化（如模糊、雨、雾及低光照）复原受损图像的视觉质量。随着深度学习技术的迅速发展，图像去模糊[8]、去雨[154-155]、去雾[157-158]、去噪[159-160]及低光照图像增强[147,161-163]等领域均取得了显著进展。这些技术通过针对性地处理特定退化现象，成功提升了图像质量和视觉效果。

然而，现实应用场景中的图像退化现象通常呈现为多种形式的复合作用，而非单一退化类型。特别是低光照与模糊的复合退化尤为常见且具有挑战性。针对复合退化问题，现有研究主要采用两种策略：级联处理策略和专门训练策略。

级联处理策略依次应用不同处理模型，将前置模型的输出作为后续模型的输入。考虑到现有方法的多样性，既可采用单一退化处理模型，也可使用多退化处理

中国知网 https://www.cnki.net

模型作为级联策略的组件。多退化处理模型虽不直接针对复合退化设计，但在实践中具有较广泛的适用性。此类模型可进一步分为两类：每个图像一种退化处理（ODPI）和一站式处理（AiO）。ODPI 方法（见图5.1（a））采用同构模型架构，针对每种单一的退化独立训练模型[60,69,87,90-92,164]。代表性工作如 MPRNet[69]、SwinIR[87] 和 GRL[92] 等，这些方法在各单一退化上表现出色，但需要为每种退化类型维护一个单独模型。AiO 方法（见图5.1（b））则致力于构建单个模型以处理多种退化类型，如 AirNet[165] 在包含多种单一退化数据的混合数据集上进行训练，实现了对多种单一退化的统一处理能力。然而，由于训练数据分布与特定推理场景数据分布的不一致性，其性能通常不及 ODPI 方法。尽管级联处理策略可实现复合退化处理，但该策略显著增加了计算复杂度，并在处理过程中产生误差累积，最终导致复原效果受限。

专门训练策略针对特定复合退化数据训练专用模型，这需要构建高质量的复合退化数据集，其中每个样本包含多种退化（Multi Degradation Per Image, MDPI）。MDPI 方法（见图5.1（c））专注于处理复合退化问题[166-172]，如 FSGN[167]、RLED-Net[168] 和 LEDNet[170] 等研究工作构建了特定任务的复合退化训练数据集，并设计了专门应对复合退化的网络架构。虽然 MDPI 方法能直接处理复合退化，但所需的复合退化数据难以大规模获取，显著提高了数据采集成本。此外，该方法对训练数据分布的依赖性较强，当推理阶段的数据分布偏离训练数据时，处理效果通常会显著降低。

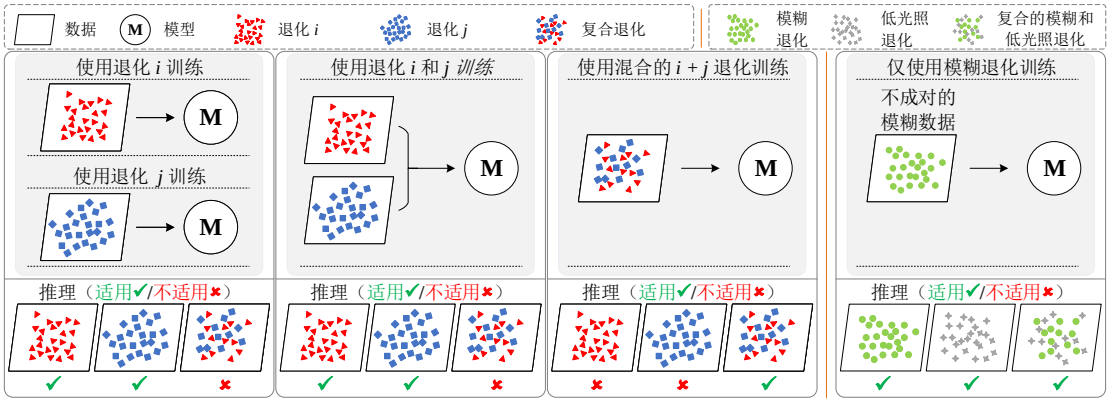


图 5.1　不同多样化退化处理策略的对比

Fig. 5.1　Comparison of different diversified degradation processing strategies

针对上述挑战，本章提出了一种基于噪声自回归的低光照图像去模糊方法（DEvUDP）。该方法通过将噪声自回归技术融入无监督去模糊框架，构建了能够同时处理单独和联合的去模糊与低光照增强任务的统一模型。DEvUDP 的核心优势在于：仅使用与去模糊相关的非配对数据进行训练，无需任何低光照相关数据，却能在推理阶段有效处理去模糊、低光照增强及其复合退化问题，显著提升了模型

中国知网　https://www.cnki.net

的泛化能力与应用灵活性。

本章的主要贡献包括：

- 提出了一种创新性策略，通过无监督去模糊范式实现去模糊和低光照增强的复合退化处理，显著降低数据收集和模型训练成本，同时缓解训练-推理数据分布差异带来的使用限制。
- 通过灵活配置不同组件（保持整体架构不变），提供了能够平衡感知性能（视觉质量）和失真性能（量化指标）的两种模式，以适应不同应用场景的需求。
- 在多个基准数据集上的广泛实验证明，DEvUDP 在无监督去模糊任务、无监督暗光增强任务以及复合退化处理任务均取得了最先进性能，并展现出对真实世界退化场景的良好泛化能力。

5.2 相关工作和理论基础

图像去模糊相关的研究工作已经在第二章详细介绍，这里主要介绍和本章内容高度相关的相关工作和理论基础，包括：零参考的低光照增强方法、全监督的复合退化处理方法以及噪声自回归技术。

5.2.1 零参考的低光照增强方法

零参考低光照图像增强（Zero-Reference LLIE）技术[162-163,173-174]仅依赖单一低光照输入图像进行处理，无需任何成对或未配对参照图像。Guo 等人[162]及 Li 等人[163]提出的系列方法首次将低光照图像增强重构为深度曲线估计问题，通过轻量级 DCE-Net 网络估计像素级曲线映射函数实现图像增强。这些方法的创新之处在于摒弃了传统配对数据依赖，而是通过精心设计的非参考损失函数隐式评估增强质量并指导网络优化。受视网膜理论（Retinex Theory）[175]启发，Liu 等人提出的 RUAS[173]方法创新性地融合了优化过程展开与神经架构搜索（NAS）[176]技术，构建了计算效率与增强效果兼具的网络结构。Ma 等人[174]提出了一种名为“自校准照明”（Self-Calibrated Illumination, SCI）的新框架，通过级联权重共享和自校准模块设计，实现了低光照图像增强的高效处理，在保证视觉质量的同时大幅降低计算成本，并且具有操作不敏感适应性和模型无关通用性，能够应用于各种复杂现实场景。零参考方法最显著的特征是其摆脱了对成对或未配对参照数据的依赖，这一点与本章提出的方法在数据支持机制上存在相似性，因此本章将这类方法作为实验比较的重要基准。

5.2.2 全监督的复合退化处理方法

复合退化处理旨在将同时受到多种退化因素影响的图像（如模糊 + 低光照、模糊 + 噪声、雨雾 + 低光照等）复原为清晰图像。处理此类退化主要有两种策略：一是级联处理策略：先后应用不同处理模型，但这不仅增加计算复杂度，还容易产生

中国知网　https://www.cnki.net

误差累积；二是专门训练策略，即针对特定复合退化数据训练一体化模型，相比级联处理策略性能更优，但提高了数据获取难度。该策略利用大量配对的复合退化图像和清晰图像进行训练，学习从退化图像到清晰图像的映射。Song 等人[167]提出了融合面部组件引导的深度 CNN 与基于示例的细节增强方法，同步解决模糊低分辨率人脸图像的超分辨率与去模糊问题。该方法巧妙利用人脸领域特定知识自动生成面部组件，有效克服了传统方法在处理低纹理区域时的局限性。Zhao 等人[169] 提出的 D2HNet 学习框架通过融合长短曝光图像解决夜间拍摄问题，采用两阶段 DeblurNet-EnhanceNet 架构在固定低分辨率上进行精确去模糊处理，有效缩小了合成训练数据与真实照片之间的域差距。Zhou 等人[170] 提出一种创新的数据合成流程和 LEDNet 网络，以解决夜间摄影中低光照增强与去模糊的联合任务，并构建了包含 12,000 对样本的 LOL-Blur 数据集为后续相关任务提供的新的数据基准。本章提出的方法与上述全监督复合退化处理方法有两个根本性区别：（1）本章设计的是一种无监督学习方法；（2）所设计的模型仅需单一去模糊任务数据驱动，训练过程中不依赖任何复合退化数据，显著降低了数据获取难度。

5.2.3 噪声自回归技术

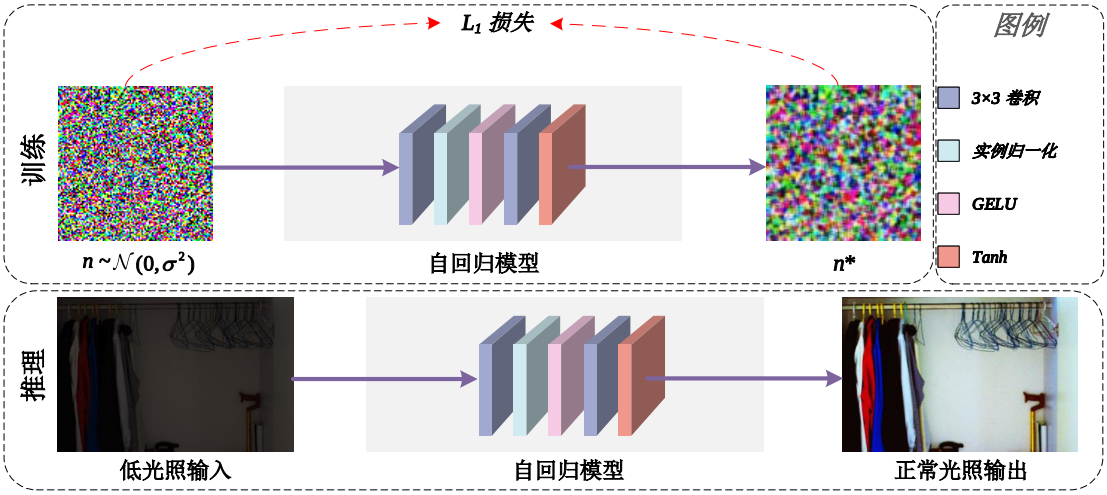


图 5.2　噪声自回归技术原理示意图

Fig. 5.2　Schematic diagram of noise self-regression technique principle

自回归技术[177-179] 的核心在于将输入本身作为监督信号，通过重建具有相似纹理特征的输出来实现自我学习。这类模型通常采用编码器-解码器结构，编码器负责将输入压缩为潜在表示，解码器则从该表示重建原始输入。重建误差（输入与重建输出之间的差异）作为训练信号，驱动模型提取输入数据的本质特征。噪声自回归（NoiSER）[180] 作为近期提出的自回归技术，为低光照图像增强提供了一种简洁高效的解决方案，其特点是无需任何低光照增强相关数据即可实现增强效果，如图5.2所示。该技术的关键流程包括：1）从均值为 0，方差为 δ^2 的高斯分布中随

中国知网　https://www.cnki.net

机采样噪声 n；2）构建包含实例归一化层且不含全局残差连接[78] 的深度网络；3）应用特定的像素级损失函数约束随机噪声与网络输出之间的关系。该回归过程可形式化表示为：

$$\arg\min_{\theta} \mathbb{E}_n\{L(f_\theta(n), n)\}, \tag{5.1}$$

其中 f_θ 是参数化映射簇，L 代表用于最小化重建误差的损失函数（本研究中采用 L_1 损失），且 $f_\theta(n)$ 与 n 的取值范围均限定在 [-1, 1] 区间内。深度自回归模型经过高斯噪声的自回归训练之后，具备了低光照增强的能力；在推理时，输入符合取值范围要求的低光照图像即可得到正常光照输出。

将噪声自回归技术整合到其他任务以实现联合处理的关键挑战在于噪声的选择策略。以本章去模糊任务为例，由于去模糊任务本身并不涉及高斯噪声输入，因此直接采样高斯噪声并施加重构约束本质上构成了一个多任务学习问题，这可能导致模型在原始去模糊任务上的性能出现一定程度的下降。考虑到噪声自回归技术中噪声形式的多样性，本章创新性地提出将自然图像作为模拟的高斯噪声，并通过隐式与显式两种实现方式应用噪声自回归技术，在进行去模糊处理的同时协同增强低光照图像。这种方法在一定程度上缓解了原始任务性能下降的问题，为多任务图像处理提供了新的技术路径。

5.3 方法介绍

实际应用场景中的模糊和低光照复合退化处理面临着光照条件和模糊程度均未知的挑战。在这种情况下，待处理图像可能呈现四种退化组合：（1）空退化；（2）复合退化；（3）仅模糊；（4）仅低光照。图5.1展示了现有的三种联合任务处理策略，然而这些策略在处理上述复杂情况时均显现出明显局限性。受噪声自回归技术（NoiSER）[180] 的启发，本章提出 DEvUDP 框架，该框架能够在最小化数据采集和训练成本的前提下，有效处理上述全部四种退化类型，其中空退化表示为模型输出应当保持输入图像的原始特性。本方法的核心创新在于仅依托无监督去模糊范式实现联合去模糊和低光照增强，避免了传统方法中的多模型融合复杂性。

图5.3直观展示了通用无监督去模糊方法 FCL-GAN 与本方法在处理不同退化类型时的视觉效果差异。图5.3（b）、（c）和（d）分别展示了本方法处理复合退化、仅模糊以及仅低光照情况的卓越能力，而图5.3（a）则证明本方法能够准确识别并完整保留无退化图像的原始特性，体现了对空退化的适应能力。以下将详细阐述 DEvUDP 框架的技术细节及其工作机制。

5.3.1 网络架构

设 $\mathbb{A}$ 和 $\mathbb{B}$ 分别表示两个不同的域，即模糊域和清晰域，让 $A \in \mathbb{A}$ and $B \in \mathbb{B}$ 表示相应域中具有不同内容的图像。DEvUDP 的联合去模糊和低光照图像增强（LLIE）

中国知网　https://www.cnki.net



图 5.3　在不同退化上的处理结果对比

Fig. 5.3　Comparison of processing results on different degradations

架构如图5.4的“训练”部分所示。从结构角度看，整体架构由两个生成器（G，G^{-1}）和一个判别器（D）构成。生成器 G 将模糊图像映射到清晰域，生成器 G^{-1} 则根据 G 的输出反向处理；判别器 D 负责识别图像是否真实属于特定域。从功能角度看，架构呈现非对称性，由两个关键分支组成：即转换分支（T 分支）和回归分支（S 分支）。这两个分支各司其职，相辅相成。

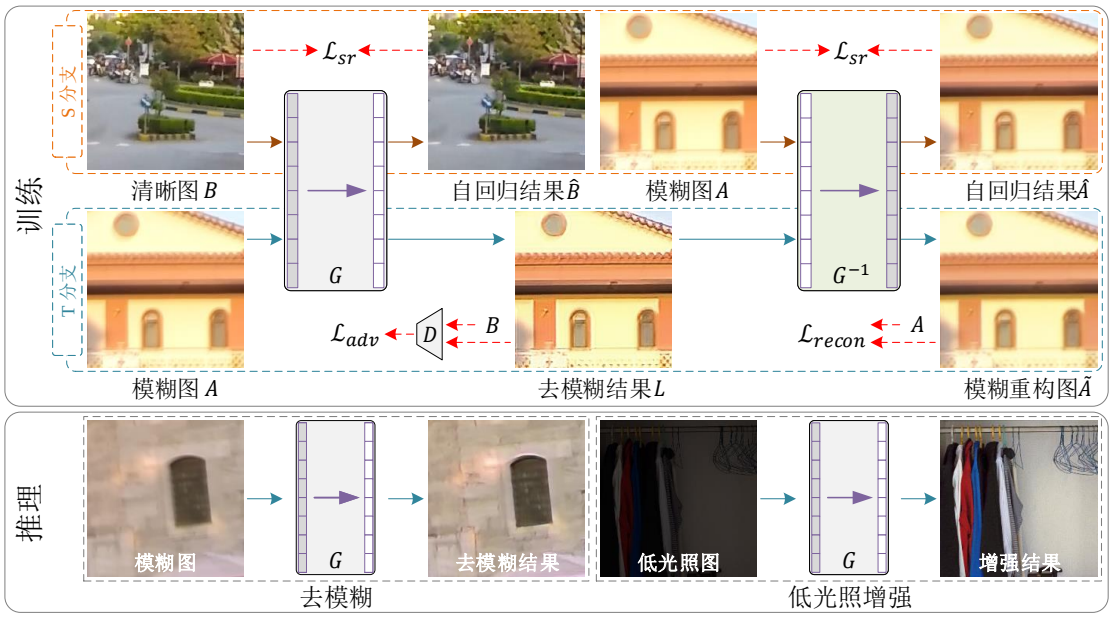


图 5.4　DEvUDP 模型结构示意图

Fig. 5.4　Structural diagram of the DEvUDP

5.3.2 转换分支

转换分支作为架构中的核心功能组件，旨在实现从模糊域到清晰域的图像转换，同时保持图像内容不变。具体而言，给定一个模糊图像 A，首先通过生成器 G

中国知网　https://www.cnki.net

生成潜在清晰图像 L：

$$L = G(A). \tag{5.2}$$

为使潜在清晰图像 L 更接近清晰域，给定清晰图像 B，采用 LSGAN[181] 对 L 施加对抗约束，其中 L 被视为假样本，而 $B \in \mathbb{B}$ 被视为真实样本。对抗约束表示如下：

$$\mathcal{L}_D = \frac{1}{2}\mathbb{E}_{B\sim p(B)}\left[(D(B)-1)^2\right] + \frac{1}{2}\mathbb{E}_{L\sim p(L)}\left[D(L)^2\right], \tag{5.3}$$

$$\mathcal{L}_G = \mathbb{E}_{L\sim p(L)}\left[(D(L)-1)^2\right], \tag{5.4}$$

其中 $p(B)$ 表示真实样本分布，$p(L)$ 表示假样本分布。

本章将对抗损失统一表示为 $\mathcal{L}_{adv}$。该损失函数基于生成对抗网络（GAN）框架，旨在确保生成图像与真实图像难以区分，从而促使生成器产生逼真输出。其具体定义如下：

$$\mathcal{L}_{adv} = \frac{1}{2}\mathbb{E}_{B\sim p(B)}\left[(D(B)-1)^2\right] + \frac{1}{2}\mathbb{E}_{L\sim p(L)}\left[D(L)^2\right] + \mathbb{E}_{L\sim p(L)}\left[(D(L)-1)^2\right]. \tag{5.5}$$

为确保潜在清晰图像 L 与模糊输入 A 的内容信息保持一致，需对 L 施加适当约束。然而，直接在 L 和 A 之间施加逐像素/特征约束会引入模糊特性。因此，本章引入辅助生成器 G^{-1} 实现与主生成器 G 相反的过程，输出重建图像 $\tilde{A}$：

$$\tilde{A} = G^{-1}(L). \tag{5.6}$$

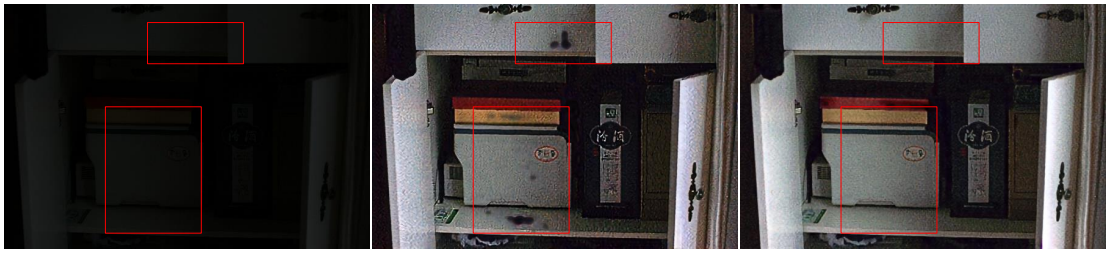
获得重建图像 $\tilde{A}$ 后，通过在 A 和 $\tilde{A}$ 之间施加像素级重建约束，间接保留 A 的内容信息而不引入模糊特性：

$$\mathcal{L}_{recon} = \|A - \tilde{A}\|_1, \tag{5.7}$$

其中 $\|\cdot\|_1$ 是 L_1 范数。T 分支的完整流程如图5.4中蓝色虚线区域所示。

T 分支虽基本实现了去模糊任务，但在低光图像增强方面仍有局限。实际上，T 分支已能在一定程度上调整图像亮度，原因主要有三方面[180]：1）生成器中包含实例归一化（IN）[182] 层（详见第5.3.5节）；2）模型映射区间设为 [-1, 1]，中值 0 落在正常光照范围内；3）$A \rightarrow \tilde{A} \approx A$ 过程隐式模拟了噪声自回归过程。根据 NoiSER[180] 的分析，更直接的解释为：1）生成器 G 具备重建相邻像素对比度的能力，并产生满足灰色世界假设[183] 的输出；2）生成器 G 中的 IN 有助于改善整体亮度。然而，T 分支无法保证处理结果与模型输入间具有与自回归相同的像素级对应关系，导致处理结果出现明显伪影和噪声，如图5.5（a）和图5.5（b）所示。因此，本章引入 S 分支显式实现自回归，而非隐式模拟。引入 S 分支后，噪声和伪影显著减少，如图5.5（a）和图5.5（c）所示。

中国知网　https://www.cnki.net



（a）低光照图　　（b）仅T分支　　（c）T分支和S分支

图 5.5　有无 S 分支的模型处理结果对比

Fig. 5.5　Comparison of processing results between models with and without S branch

5.3.3 回归分支

回归分支设计旨在有效减轻图像处理过程中的噪声和伪影，从而显著提升输出图像的视觉质量。在 T 分支架构中，主生成器 G 负责实现从模糊域到清晰域的映射转换，表示为 $G\colon \mathbb{A} \to \mathbb{B}$，而辅助生成器 G^{-1} 则执行相反方向的映射，即 $G^{-1}\colon \mathbb{B} \to \mathbb{A}$。这种结构设置使得对模糊图像直接在 G 上执行自回归操作（即 $G\colon \mathbb{A} \to \mathbb{A}$）会与 G 的基本功能产生本质冲突。具体而言，当输入模糊图像 $A \in \mathbb{A}$ 时，生成器 G 将面临域映射目标的不确定性。

为成功在 G 上执行自回归操作，同时避免引入额外的冲突，本章采用清晰图像 $B \in \mathbb{B}$ 在 G 上执行自回归，即 $G\colon \mathbb{B} \to \mathbb{B}$。这一措施也是 DEvUDP 模型能够在给定清晰图像时保持输入内容的关键（见图5.3（a））。具体实现过程中，给定清晰图像 $B \in \mathbb{B}$，通过生成器 G 的前向传播获取相应输出 $\hat{B}$：

$$\hat{B} = G(B). \tag{5.8}$$

随后，施加以下约束条件以实现对 G 的自回归操作：

$$\mathcal{L}_{sr}^{\mathbb{B}} = \|B - \hat{B}\|_1. \tag{5.9}$$

考虑到辅助生成器 G^{-1} 为 G 提供重要的后验信息，同样必须对 G^{-1} 执行模糊域中的自回归操作，表示为 $G^{-1}\colon \mathbb{A} \to \mathbb{A}$。对于输入的模糊图像 $A \in \mathbb{A}$，通过 G^{-1} 前向传播获得 $\hat{A}$，并执行相应的自回归约束：

$$\hat{A} = G^{-1}(A), \tag{5.10}$$

$$\mathcal{L}_{sr}^{\mathbb{A}} = \|A - \hat{A}\|_1, \tag{5.11}$$

这种双向自回归机制确保了整个模型在不同域间转换时的稳定性和一致性，有效提升了最终处理结果的质量。S 分支的完整流程如图5.4中橙色虚线区域所示。

从上述分析可见，本章提出的训练方法完全符合无监督去模糊范式的要求：1）仅使用未配对的模糊-清晰图像进行训练，不依赖任何其他数据源；2）采用的模型属于通用深度神经网络架构，未引入特定领域的专用结构；3）仅对架构施加常规

中国知网　https://www.cnki.net

对抗约束和 L_1 范数，未引入其他特定约束（如专门用于低光照图像增强的曝光控制约束[162-163]）。值得强调的是，尽管在训练阶段仅采用无监督去模糊范式，保持了方法上的简洁性，该预训练模型在实际应用中展现出了处理多种图像退化问题的卓越能力，能够有效应对模糊、低光照及其复合退化情况。这种多功能性主要归功于 NoiSER[180] 技术的巧妙整合，使得模型在保持范式纯粹性的同时，显著提升了实际应用价值。

5.3.4 损失函数

为实现 T 分支和 S 分支地最优协作，综合损失函数设计如下：

$$\mathcal{L}_{total} = \mathcal{L}_{adv} + \lambda_{recon}\mathcal{L}_{recon} + \lambda_{sr}(\mathcal{L}_{sr}^{\mathbb{A}} + \mathcal{L}_{sr}^{\mathbb{B}}), \tag{5.12}$$

其中 λ_{recon} 和 λ_{sr} 为可调节的权重系数，实验中分别采用 10 和 5 作为其最优值，以平衡各损失项的贡献度。

5.3.5 性能权衡

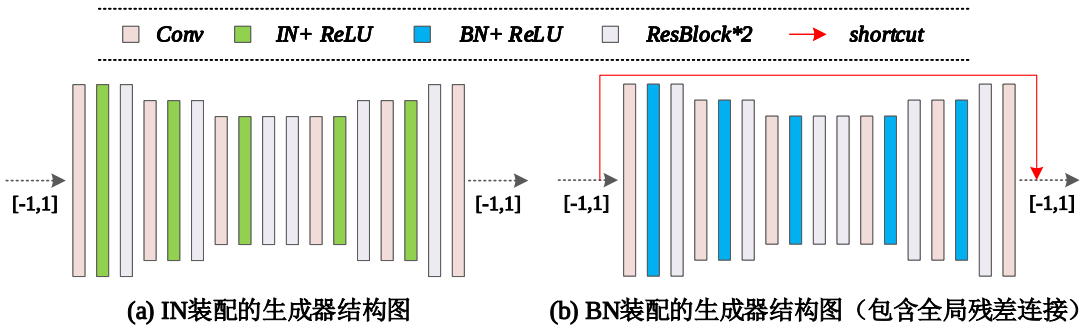


图 5.6　生成器的不同结构对比

Fig. 5.6　Comparison of different generator structures

遵循 LED 结构设计理念，图5.6（a）展示了生成器 G 的结构。值得注意的是，该结构满足三项关键条件：（1）无全局快捷连接；（2）采用实例归一化 IN 而非其他归一化层；（3）输入与输出像素范围均限定为 [-1, 1]。这些条件构成了架构能够有效处理低光照数据的基础。然而，正如在上一章的分析，由于引入实例归一化，无监督去模糊的失真性能①不可避免地处于相对较低水平。实际上，在图像复原与增强任务中，较低的失真性能并不必然意味着较差的感知性能②，反之亦然。实验发现，采用实例归一化相比不使用时能提供更优的感知性能。为同时考虑 DEvUDP 的失真性能，本章同时提供了一种替代方案，构建具备最先进去模糊失真性能但不具备增强能力的模型（记为 DEvUDP-DT），其结构如图5.6（b）所示。这一设计允许在特定应用场景下根据需求在失真性能与感知性能间进行适当权衡。

①失真性能指方法对输入图像的失真程度
②感知性能指方法针对人眼视觉效果的表现

中国知网　https://www.cnki.net

表 5.1　在 GoPro 数据集上的去模糊结果定量对比

Tab. 5.1　Quantitative comparison of deblurring results on the GoPro dataset

方法	PSNR↑	SSIM↑	MAE↓	LPIPS↓	推理时间 ↓	模型大小 ↓
CycleGAN[125]	22.54	0.720	13.95	0.243	12.55（毫秒）	107.90（MB）
UID-GAN[127]	23.56	0.738	11.38	0.289	62.06（毫秒）	606.80（MB）
FCL-GAN	24.84	0.771	9.63	0.239	10.86（毫秒）	24.56（MB）
DEvUDP	22.19	0.708	14.30	0.253	6.40（毫秒）	63.65（MB）
DEvUDP-DT	25.15	0.786	9.56	0.272	5.80（毫秒）	63.86（MB）
CRNet*	25.88	0.803	9.12	0.192	-	11.66（MB）
DEvUDP-DT*	26.69	0.822	8.54	0.205	-	63.86（MB）

表 5.2　在 RealBlur-J 数据集上的去模糊结果定量对比

Tab. 5.2　Quantitative comparison of deblurring results on the RealBlur-J dataset

方法	PSNR↑	SSIM↑	MAE↓	LPIPS↓
CycleGAN[125]	19.79	0.633	22.39	0.247
UID-GAN[127]	22.87	0.671	13.41	0.235
FCL-GAN	25.36	0.736	9.58	0.193
DEvUDP	19.75	0.617	22.18	0.261
DEvUDP-DT	25.87	0.790	8.69	0.201
CRNet*	24.05	0.715	13.02	0.146
DEvUDP-DT*	26.55	0.831	8.80	0.137

5.4 实验分析

本章对 DEvUDP 进行了全面的定性与定量评估，并与相关模型进行系统性比较。基准模型基于 PyTorch 1.10 版本实现，所有实验均在配备 40G 显存的 NVIDIA A100 显卡上完成。

5.4.1 实验设置

数据集。本章评估采用四个广泛应用的图像数据集：自然图像模糊数据集 GoPro[8]、真实世界模糊数据集 RealBlur（包含 RealBlur-J 和 RealBlur-R 子集）[132]、真实低光照数据集 LOL[161]、复合的模糊和低光照数据集 LOL-Blur[170]。这些数据集涵盖了去模糊、低光照增强和复合退化处理三种任务，为全面评估方法性能提供了坚实基础。

评估方法。本章将 DEvUDP 与十种现有方法进行比较，这些方法涵盖了不同的任务：包括四种无监督去模糊方法：CycleGAN[125]、UID-GAN[127]、CRNet（第三章方法）和 FCL-GAN（第四章方法）；六种传统/零参考的低光照图像增强方法：LIME[184]、Zhang 等人[185] 提出的方法、Zero-DCE[162]、Zero-DCE++[163]、RUAS[173] 和 SCI[174]。此外，为评估模型的复合退化处理能力，本章采用级联处理的策略组合上述去模糊和低光照增强方法。评估在设置一致的情况下优先采用各官方发布的预训练模型；对于设置不一致或未提供预训练模型的情况，则依据

中国知网　https://www.cnki.net



图 5.7　在 GoPro 数据集上的去模糊结果可视化对比

Fig. 5.7　Visualization comparison of deblurring results on the GoPro dataset

表 5.3　在 LOL 数据集上的低光照增强结果定量对比

Tab. 5.3　Quantitative comparison of low-light enhancement results on the LOL dataset

方法	PSNR↑	SSIM↑	MAE↓	LPIPS↓
LIME[184]	14.22	0.514	50.92	0.368
Zhang 等人[185]	14.02	0.513	51.91	0.372
Zero-DCE[162]	14.97	0.500	41.62	0.432
Zero-DCE++[163]	14.80	0.516	43.72	0.413
RUAS[173]	16.40	0.500	39.11	0.270
SCI[174]	14.02	0.508	52.36	0.388
DEvUDP	16.88	0.667	36.27	0.326

原作者提供的代码和推荐配置重新训练以确保公平比较。

评估指标。本章采用四种最广泛使用的评价指标（即 PSNR、SSIM[133]、MAE 和 LPIPS[134]）来衡量各方法的定量性能。此外，本章同步考察模型规模参数，以评估方法的轻量化程度；并通过 NVIDIA RTX 2080 Ti 显卡的推理时间评估各模型在实际应用场景中的计算效率。在结果呈现中，符号 ↑ 表示该指标数值越高表明性能越佳，而符号 ↓ 则表示该指标数值越低代表性能越佳；最佳性能用红色标记，次佳性能用蓝色标记。

实现细节。模型训练配置为 200 个 epoch，采用 Adam[144] 优化器，参数设置为 β_1=0.5 和 β_2=0.999。初始学习率为 0.0002，然后每 50 个周期衰减为初始学习率的 1/2。对于数据增强策略：首先将图像随即下采样到更小分辨率，随后统一裁剪为 256 × 256 尺寸，并以 0.5 概率执行水平翻转，不执行垂直翻转操作。在推理过程中，仅使用主生成器 G 来转换给定输入，如公式5.2所示。

中国知网　https://www.cnki.net



图 5.8　在 LOL 数据集上的低光照增强结果可视化对比

Fig. 5.8　Visualization comparison of low-light enhancement results on the LOL dataset

表 5.4　在 LOL-Blur 数据集上的复合退化处理结果定量对比

Tab. 5.4　Quantitative comparison of compound degradation processing results on the LOL-Blur dataset

方法	顺序	PSNR↑	SSIM↑	MAE↓	LPIPS↓
FCL-GAN → Zero-DCE[162]	D→E	9.07	0.515	86.03	0.495
Zero-DCE[162] → UID-GAN[127]	E→D	12.23	0.574	59.46	0.368
UID-GAN[127] → RUAS[173]	D→E	6.88	0.454	109.46	0.510
RUAS[173] → FCL-GAN	E→D	12.72	0.602	57.50	0.406
DEvUDP	-	18.03	0.653	28.14	0.323

5.4.2 实验结果及分析

本章对 DEvUDP 模型在三个关键任务上的性能进行了系统评估：图像去模糊、低光照图像增强（LLIE）及复合模糊和低光照处理。通过一系列严谨实验，全面验证了模型在这三个方面的处理能力。

（1） 去模糊实验结果

DEvUDP 模型在 GoPro 数据集[8] 训练集上进行训练，并分别在 GoPro 测试集和 RealBlur-J[132] 数据集上评估其拟合与泛化能力。表5.1和表5.2中展示了各个方法定量结果的对比。表格中方法右上角的 * 标记代表图像在推理前经过了下采样处理以降低分辨率（GoPro 数据集下采样至 640×360;RealBlur-J 下采样至 320×360），这主要考虑到 CRNet 处理高分辨率图像对硬件的要求较高，常规硬件难以满足。对于推理时间的度量，采用常规计算卡 NVIDIA RTX 2080 Ti。表格数据表明，DEvUDP 在大多数性能指标（如 PSNR）上均优于现有方法，充分证明了该模型在去模糊任

中国知网　https://www.cnki.net

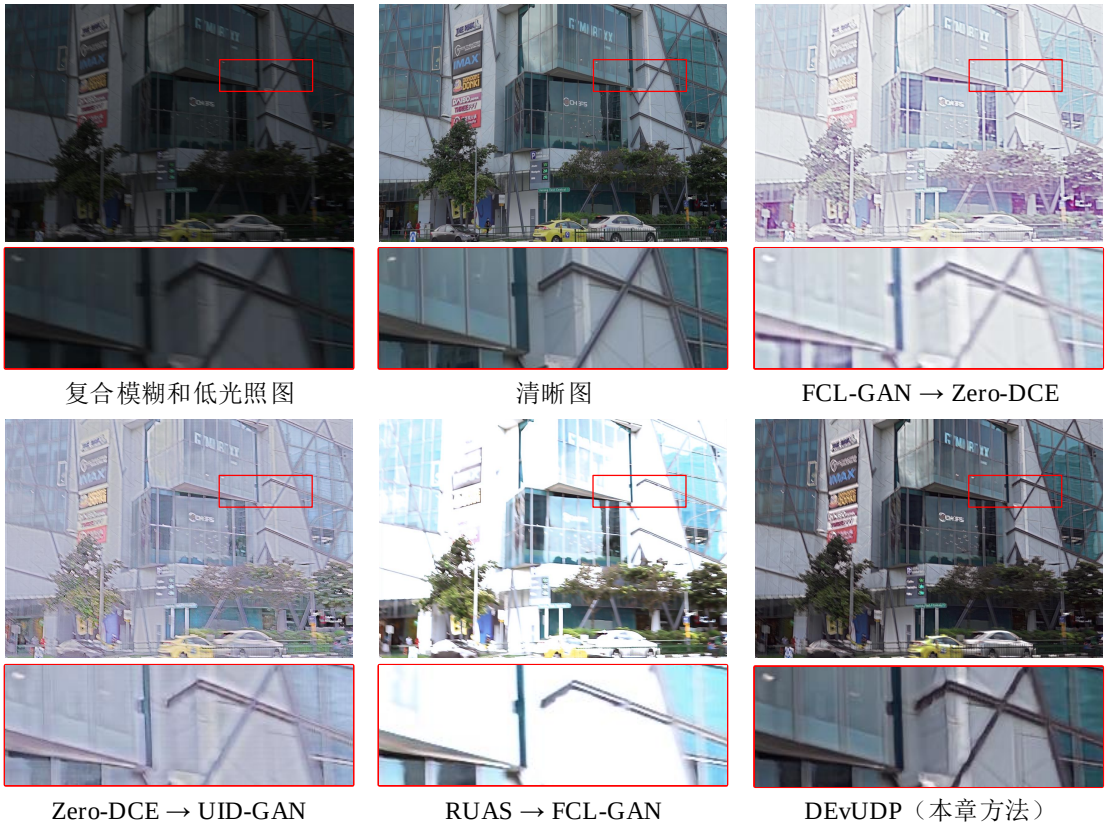


图 5.9　在 LOL-Blur 数据集上的复合退化处理结果可视化对比

Fig. 5.9　Visualization comparison of compound degradation processing results on the LOL-Blur dataset

务上具备卓越的拟合和泛化能力。在应用指标（如推理时间）上也表现优异，体现了 DEvUDP 巨大的实际应用潜力。图5.7呈现的视觉对比结果进一步表明，相比其他无监督方法，DEvUDP 能够产生更为清晰、视觉效果更佳的去模糊结果。

（2） 低光照增强实验结果

对于低光照增强任务，本章直接将在去模糊数据集 GoPro[8] 上预训练的模型应用于低光照图像增强任务，未进行任何特定于低光照增强任务的微调。表5.3和图5.8展示了 DEvUDP 与其他低光照增强方法在 LOL 数据集[161] 上的对比结果。实验表明，尽管 DEvUDP 仅通过无监督去模糊范式预训练，其仍在低光照增强任务上取得了优异表现，相较于其他传统方法或零参考的低光照增强专用方法，DEvUDP 实现了更优的定量结果和更为自然的视觉效果。

（3） 复合退化处理实验结果

鉴于目前缺乏处理复合退化的无监督方法，本章通过两种处理流程进行实验：1）去模糊后增强（D→E），和 2）增强后去模糊（E→D）。实验选取了两种先进的无监督去模糊方法（FCL-GAN（第四章方法）和 UID-GAN[127]）以及两种零参考 LLIE 方法（Zero-DCE[162] 和 RUAS[173]）交叉构建实验环，形成了两种 D→E 方法和两种 E→D 方法。

中国知网　https://www.cnki.net



图 5.10　在多个任务上关于下采样的可视化消融实验结果

Fig. 5.10　Visualization ablation study results of downsampling operation on multiple tasks

表 5.5　在多个任务上的定量消融实验结果

Tab. 5.5　Quantitative ablation study results on multiple tasks

行	方法	GoPro[8]		LOL[161]		LOL-Blur[170]		均值	
		PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑
1	移除 S 分支	22.02	0.695	16.29	0.607	**18.23**	0.645	18.85	0.649
2	移除下采样	22.12	**0.718**	15.48	0.636	18.12	**0.660**	18.57	0.672
3	DEvUDP	**22.19**	0.708	**16.88**	**0.667**	18.03	0.653	**19.03**	**0.676**

表 5.6　在多个任务上关于 G^{-1} 的定量消融实验结果

Tab. 5.6　Quantitative ablation study results of the G^{-1} on multiple tasks

方法	GoPro[8]		LOL[161]	
	PSNR↑	SSIM↑	PSNR↑	SSIM↑
移除 G^{-1}	21.91	0.689	15.13	0.643
包含 G^{-1}	**22.19**	**0.708**	**16.88**	**0.667**

实验直接应用在 GoPro[8] 上预训练的 DEvUDP 模型处理 LOL-Blur[170] 数据集上的复合退化。表5.4中的定量比较显示，DEvUDP 在所有评估指标上均显著优于其他方法组合。图5.9的视觉对比进一步证实：（1）从去模糊角度看，DEvUDP 处理后的结果更加清晰；（2）从低光照增强角度看，DEvUDP 能够获得更自然的结果。这些结果充分验证了 DEvUDP 处理复合退化的卓越能力，尽管其仅通过无监督去模糊范式训练。

5.4.3 消融实验及分析

（1） S 分支的有效性

为验证 S 分支的重要性，本章在三个任务上进行了消融研究：GoPro 数据集[8] 上的去模糊、LOL 数据集[161] 上的低光照图像增强以及 LOL-Blur 数据集[170] 上的复合退化处理。表5.5中第 1 行与第 3 行的对比结果定量证明了 S 分支的有效性，而图5.5的视觉对比也表明 S 分支对模型性能至关重要。

中国知网　https://www.cnki.net

表 5.7　在多个任务上的超参分析定量结果

Tab. 5.7　Quantitative results of hyperparameter analysis on multiple tasks

组别	超参	值	GoPro[8]		LOL[161]	
			PSNR↑	SSIM↑	PSNR↑	SSIM↑
1	学习率	0.0001	22.06	0.694	15.77	0.642
		0.0002	**22.19**	**0.708**	**16.88**	**0.667**
		0.0005	22.18	0.685	15.60	0.647
2	批次大小	2	22.14	0.684	15.59	0.631
		4	**22.19**	**0.708**	**16.88**	**0.667**
		8	21.77	0.676	15.88	0.643
3	λ_{recon}	5	22.14	0.688	15.34	0.648
		10	22.19	**0.708**	**16.88**	**0.667**
		20	**22.48**	0.700	16.08	0.642
4	λ_{sr}	5	22.19	0.708	**16.88**	0.667
		10	22.28	0.686	16.03	0.655
		20	**22.68**	**0.721**	16.08	**0.677**
5	裁剪尺寸	128×128	21.92	0.651	**16.90**	0.592
		256×256	22.19	0.708	16.88	**0.667**
		384×384	**22.49**	**0.714**	15.77	0.660

（2） 下采样操作的有效性

实验证明，在执行数据增强前对图像进行下采样（保持宽高比不变）能显著提升模型性能。表5.5中第 2 行与第 3 行的对比展示了下采样操作带来的定量性能提升，图5.10则直观显示下采样操作能使处理结果更加清晰。

（3） 在 G^{-1} 上自回归的有效性

自回归机制是本章方法中的关键技术，旨在增强图像去模糊质量。尽管回归模型 G 的必要性不言而喻，G^{-1} 作用仍需验证。为了评估在 G^{-1} 上自回归的必要性和影响，本章采用 GoPro 数据集进行了详细的消融研究。具体而言，比较了模型在有无 G^{-1} 自回归机制下的性能指标。表5.6中的结果显示，引入 $G{-}1$ 自回归机制在 PSNR 和 SSIM 两项指标上均带来显著提升，证实了该模块在 DEvUDP 框架中的重要作用。

（4） 超参分析

本章对多种超参数进行了敏感性分析，包括：（1）学习率；（2）批次大小；（3）重建损失权重 λ_{recon}；（4）自回归损失权重 λ_{sr}；（5）裁剪大小。在控制变量的条件下进行的实验结果见表5.7，表中的下划线代表本章所采用的超参数值。分析表明，1）对于学习率和批次大小两个超参而言，选定数值实验性能显著由于其他测试数值；2）对于重构损失权重超参，选定数值（λ_{recon}=10）的实验性能仅去模糊任务的 PSNR 指标略低于“λ_{recon}=10”，其他指标上均优于其他数值；3）对于自回归损失权重超参，选定数值（λ_{sr}=5）的实验性能虽然在去模糊任务的 PSNR，SSIM 指标和增强任务的 SSIM 指标均略低于“λ_{sr}=20”，但增强任务 PSNR 指标显著优于

中国知网　https://www.cnki.net

“λ_{sr}=20”；4）对于裁剪尺寸超参，选定数值（256×256）的综合表现优于其他数值。因此，当同时考虑去模糊和低光照增强两项任务的性能时，所选定的超参数设置是合理且有效的。

5.5 本章小结

本章提出了一种创新的无监督去模糊方法——DEvUDP，能够通过同一框架同时解决去模糊、低光照增强以及复合退化处理三类任务。该方法仅依赖不成对的去模糊相关数据进行训练，突破了传统方法对配对数据的依赖限制。实验结果表明，这种方法能够一站式处理模糊、低光照及其复合退化问题。该方法的有效性主要源于在无监督去模糊框架中巧妙融入噪声自回归技术，并通过双分支架构设计来分别隐式模拟和显式利用噪声自回归流程。此外，通过灵活配置不同网络组件，所提出的模型能够在失真性能（量化指标）和感知性能（视觉质量）之间实现平衡，以适应不同应用场景需求。在去模糊、低光照增强和复合退化处理的大量数据集上的实验证明了本章所提方法的优越性。总体而言，本章提出的方法为实际应用环境中的复杂图像退化问题提供了一种高效且适应性强的解决方案，为无监督图像去模糊技术在复杂场景中的应用拓展了新的可能性。

中国知网 https://www.cnki.net

第六章 总结与展望

6.1 本文工作总结

本文围绕“面向复杂场景的无监督图像去模糊方法研究”这一主题展开，致力于解决当前无监督图像去模糊技术在实际应用中面临的关键问题，包括色彩保真、模型复杂度与实时性、以及复杂退化场景的适应性等。通过提出三种创新性的无监督图像去模糊方法，分别聚焦于图像色彩保留、方法效率提升以及复合退化有效处理，系统性地提高了无监督图像去模糊方法在视觉质量、计算效率和场景适应性上的能力，推动该技术向实际落地迈进。本文的主要贡献如下：

（1）针对色彩保真度和定量评价问题，提出基于模糊偏移估计的无监督图像去模糊方法。针对无监督去模糊过程中常见的色彩失真问题，本文创新性地将去模糊任务转化为模糊偏移估计和渐进式模糊校正的过程，以最大程度地保留原始图像的色彩信息。此外，设计了金字塔全局模糊特征感知模块，可捕获多尺度模糊特性并增强模型的全局感知能力，同时提出了基于 HSV 色彩空间直方图峰值分析的新型色差评价指标，为色彩保留效果的量化评估提供了新的标准。实验结果表明，该方法显著提升了去模糊图像的视觉质量及色彩保真度。

（2）针对模型复杂度和实时性问题，提出基于轻量级域转换的无监督图像去模糊方法。针对传统方法中模型复杂度高、推理速度慢的缺陷，本文设计了轻量级域转换单元和无参数频域对比单元，通过优化网络结构显著减少参数量并提升推理性能。在保证去模糊效果的前提下，提出的方法将模型体积缩小至现有最先进模型的 1/25，推理速度提升了 5 倍，同时展示出对不同图像分辨率和应用场景的较强适应性。实验结果表明，该方法在计算效率与去模糊效果的平衡方面达到了更高水平，为资源受限环境下的实际部署提供了可能。

（3）针对复合退化处理问题，提出基于噪声自回归的无监督低光照图像去模糊方法。为应对低光照和运动模糊复合退化问题，本文提出了一种无监督低光照去模糊方法，基于噪声自回归机制构建双分支（转换分支和回归分支）网络架构协同去模糊。转换分支用于模糊去除，回归分支用于低光照增强与噪声抑制，该双分支结构显著提高了模型在复杂退化场景下的适应性。该方法无需依赖特定领域的复合退化配对数据，降低了数据获取成本和训练开销，同时实现了对低光照增强、去模糊及其复合退化的全方位处理。实验结果表明，该方法在模糊、低光照和复合退化场景均表现出优异的性能，拓展了无监督图像去模糊技术的应用范围。

综上所述，本文在无监督图像去模糊方法设计上，针对实际应用需求提出了创新性解决方案，从通用视觉质量提升到模型效率优化，再到复杂场景适应性增强，进行了深入探索，为相关领域的研究与应用提供了技术支持。

中国知网　https://www.cnki.net

6.2 未来工作展望

本文针对无监督图像去模糊任务提出了多项创新方法，并在解决实际应用中的一些关键问题方面取得了一定成效。然而，由于真实场景的复杂性和多样性，无监督图像去模糊仍然面临诸多挑战，仍有许多领域亟需进一步优化和突破。在现有工作的基础上，未来可以从以下几个方面开展深入研究与探索：

（1）多类型复合退化的统一处理框架。本文提出的方法虽然能有效处理模糊与低光照的复合退化，但真实场景中的图像退化往往更为复杂，可能同时包含模糊、噪声、低光照等多种退化因素。未来研究可探索建立一个统一的无监督处理框架，通过灵活的模块化设计和多任务学习策略，实现对多种复合退化类型的自适应处理。特别是可以考虑引入退化类型识别模块，根据图像特征自动判断主要退化类型并调用相应的处理策略，提高模型在真实场景中的适应性和鲁棒性。

（2）视频去模糊与时序信息利用。本文的研究主要针对单帧图像去模糊，未来可将研究扩展至视频序列去模糊领域。视频序列中包含丰富的时序信息，可以为模糊恢复提供额外线索。未来研究可探索如何在无监督框架下有效利用视频序列中的时序信息，设计具有时空感知能力的网络结构，以及适用于视频数据的无监督损失函数。特别是可以研究如何利用相邻帧之间的运动一致性和内容连贯性作为无监督训练信号，提升去模糊效果的同时保持视频时序连贯性。

（3）大规模预训练模型与无监督去模糊的结合。随着大规模预训练模型（如扩散模型、大型视觉基础模型等）的快速发展，未来研究可探索如何将这些模型中蕴含的丰富先验知识与无监督去模糊方法相结合。可考虑利用预训练模型作为先验知识提供者或特征提取器，辅助无监督去模糊训练，或通过参数高效微调技术将大模型适应于特定的去模糊任务。这种结合有望进一步提升无监督去模糊的效果，尤其是在复杂场景和极端条件下的表现。

（4）人类感知导向的评价体系完善。本文虽然提出了色差定量评估指标，但图像质量评价仍是一个多维问题。现有评价指标仍无法做到十分客观有效的评价，未来研究可进一步完善评价体系，结合人类视觉感知特性，设计更为全面的评价指标，涵盖色彩保真度，纹理保留、边缘清晰度、细节还原等多个维度。同时，探索如何将这些评价指标有机整合，形成符合人类视觉感知特性的综合评价体系。

中国知网 https://www.cnki.net

参考文献

[1] Flusser J, Lébl M, Šroubek F, Pedone M, Kostková J. Blur invariants for image recognition[J]. International Journal of Computer Vision, 2023, 131(9):2298-2315.

[2] Sayed M, Brostow G. Improved handling of motion blur in online object detection[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2021: 1706-1716.

[3] Aakanksha, Rajagopalan A N. Improving robustness of semantic segmentation to motion-blur using class-centric augmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2023: 10470-10479.

[4] Zhao Y, Rozumnyi D, Song J, Hilliges O, Pollefeys M, Oswald M R. Human from blur: Human pose tracking from blurry images[C]//Proceedings of the IEEE International Conference on Computer Vision. 2023: 14905-14915.

[5] 中华人民共和国国务院. 新一代人工智能发展规划[R/OL]. 2017. http://www.gov.cn/zhengce/content/2017-07/20/content_5211996.htm.

[6] Chen L, Fang F, Wang T, Zhang G. Blind image deblurring with local maximum gradient prior [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 1742-1750.

[7] Pan J, Sun D, Pfister H, Yang M H. Blind image deblurring using dark channel prior[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 1628-1636.

[8] Nah S, Hyun Kim T, Mu Lee K. Deep multi-scale convolutional neural network for dynamic scene deblurring[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 3883-3891.

[9] Kupyn O, Budzan V, Mykhailych M, Mishkin D, Matas J. Deblurgan: Blind motion deblurring using conditional adversarial networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 8183-8192.

[10] Kupyn O, Martyniuk T, Wu J, Wang Z. Deblurgan-v2: Deblurring (orders-of-magnitude) faster and better[C]//Proceedings of the IEEE International Conference on Computer Vision. 2019: 8878-8887.

[11] Cho S J, Ji S W, Hong J P, Jung S W, Ko S J. Rethinking coarse-to-fine approach in single image deblurring[C]//Proceedings of the IEEE International Conference on Computer Vision. 2021: 4641-4650.

[12] 胡张颖, 周全, 陈明举, 崔景程, 吴晓富, 郑宝玉. 图像去模糊研究综述[J]. 中国图象图形学

中国知网 https://www.cnki.net

报, 2024, 29(04):841-861.

[13] WIENER N. Extrapolation, interpolation, and smoothing of stationary time series with engineering applications[M]. The MIT Press, 1964.

[14] Hansen P C. Rank-deficient and discrete ill-posed problems: numerical aspects of linear inversion[M]. SIAM, 1998.

[15] Kalifa J, Mallat S, Rougé B. Deconvolution by thresholding in mirror wavelet bases[J]. IEEE Transactions on Image Processing, 2003, 12(4):446-457.

[16] Neelamani R, Choi H, Baraniuk R. Forward: Fourier-wavelet regularized deconvolution for ill-conditioned systems[J]. IEEE Transactions on Signal Processing, 2004, 52(2):418-433.

[17] Katkovnik V, Egiazarian K, Astola J. A spatially adaptive nonparametric regression image deblurring[J]. IEEE Transactions on Image Processing, 2005, 14(10):1469-1478.

[18] Patel V M, Easley G R, Healy D M. Shearlet-based deconvolution[J]. IEEE Transactions on Image Processing, 2009, 18(12):2673-2685.

[19] Xue F, Luisier F, Blu T. Multi-wiener sure-let deconvolution[J]. IEEE Transactions on Image Processing, 2013, 22(5):1954-1968.

[20] Rudin L I, Osher S, Fatemi E. Nonlinear total variation based noise removal algorithms[J]. Physica D: Nonlinear Phenomena, 1992, 60(1-4):259-268.

[21] Richardson W H. Bayesian-based iterative method of image restoration[J]. Journal of the Optical Society of America, 1972, 62(1):55-59.

[22] Danielyan A, Katkovnik V, Egiazarian K. Bm3d frames and variational image deblurring[J]. IEEE Transactions on image processing, 2011, 21(4):1715-1728.

[23] Kheradmand A, Milanfar P. A general framework for regularized, similarity-based image restoration[J]. IEEE Transactions on Image Processing, 2014, 23(12):5136-5151.

[24] Krishnan D, Fergus R. Fast image deconvolution using hyper-laplacian priors[J]. Advances in Neural Information Processing Systems, 2009, 22.

[25] Vonesch C, Unser M. A fast thresholded landweber algorithm for wavelet-regularized multidimensional deconvolution[J]. IEEE Transactions on Image Processing, 2008, 17(4):539-549.

[26] Yuan L, Sun J, Quan L, Shum H Y. Progressive inter-scale and intra-scale non-blind image deconvolution[J]. ACM Transactions on Graphics, 2008, 27(3):1-10.

[27] Zoran D, Weiss Y. From learning models of natural image patches to whole image restoration [C]//Proceedings of the IEEE International Conference on Computer Vision. 2011: 479-486.

[28] Dabov K, Foi A, Katkovnik V, Egiazarian K. Image denoising by sparse 3-d transform-domain collaborative filtering[J]. IEEE Transactions on image processing, 2007, 16(8):2080-2095.

[29] Shan Q, Jia J, Agarwala A. High-quality motion deblurring from a single image[J]. Acm Transactions on Graphics, 2008, 27(3):1-10.

中国知网 https://www.cnki.net

[30] Joshi N, Szeliski R, Kriegman D J. Psf estimation using sharp edge prediction[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2008: 1-8.

[31] Sun L, Cho S, Wang J, Hays J. Edge-based blur kernel estimation using patch priors[C]// Proceedings of the IEEE International Conference on Computational Photography. 2013: 1-8.

[32] Vasu S, Rajagopalan A. From local to global: Edge profiles to camera motion in blurred images [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4447-4456.

[33] Xu L, Jia J. Two-phase kernel estimation for robust motion deblurring[C]//Proceedings of the European Conference on Computer Vision. 2010: 157-170.

[34] Yang L, Ji H. A variational em framework with adaptive edge selection for blind motion deblurring[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 10167-10176.

[35] Yue T, Cho S, Wang J, Dai Q. Hybrid image deblurring by fusing edge and power spectrum information[C]//Proceedings of the European Conference on Computer Vision. 2014: 79-93.

[36] Delbracio M, Garcia-Dorado I, Choi S, Kelly D, Milanfar P. Polyblur: Removing mild blur by polynomial reblurring[J]. IEEE Transactions on Computational Imaging, 2021, 7:837-848.

[37] 段江永, 孟高峰, 向世明, 潘春洪. 边缘区域约束引导的运动模糊图像复原[J]. 计算机辅助设计与图形学学报, 2012, 24(08):1038-1046.

[38] Chen L, Fang F, Lei S, Li F, Zhang G. Enhanced sparse model for blind deblurring[C]// Proceedings of the European Conference on Computer Vision. 2020: 631-646.

[39] Shao W Z. Revisiting the regularizers in blind image deblurring with a new one[J]. IEEE Transactions on Image Processing, 2023, 32:3994-4009.

[40] Krishnan D, Tay T, Fergus R. Blind deconvolution using a normalized sparsity measure[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2011: 233-240.

[41] Pan J, Hu Z, Su Z, Yang M H. Deblurring text images via l0-regularized intensity and gradient prior[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2014: 2901-2908.

[42] Xu L, Zheng S, Jia J. Unnatural l0 sparse representation for natural image deblurring[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2013: 1107-1114.

[43] Zhang H, Wipf D. Non-uniform camera shake removal using a spatially-adaptive sparse penalty [C]//Proceedings of the Advances in Neural Information Processing Systems: volume 26. 2013.

[44] Zhang H, Wipf D, Zhang Y. Multi-image blind deblurring using a coupled adaptive sparse prior [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2013:

中国知网 https://www.cnki.net

1051-1058.

[45] 徐焕宇, 孙权森, 李大禹, 宣丽. 基于投影的稀疏表示与非局部正则化图像复原方法[J]. 电子学报, 2014, 42(07):1299-1304.

[46] 常振春, 禹晶, 肖创柏, 孙卫东. 基于稀疏表示和结构自相似性的单幅图像盲解卷积算法[J]. 自动化学报, 2017, 43(11):1908-1919.

[47] 孙涛, 李东升. 基于非凸的全变分和低秩混合正则化的图像去模糊模型和算法[J]. 计算机学报, 2020, 43(04):643-652.

[48] Joshi N, Zitnick C L, Szeliski R, Kriegman D J. Image deblurring and denoising using color priors[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2009: 1550-1557.

[49] Pan J, Hu Z, Su Z, Yang M H. Deblurring face images with exemplars[C]//Proceedings of the European Conference on Computer Vision. 2014: 47-62.

[50] Yan Y, Ren W, Guo Y, Wang R, Cao X. Image deblurring via extreme channels prior[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4003-4011.

[51] Wen F, Ying R, Liu Y, Liu P, Truong T K. A simple local minimal intensity prior and an improved algorithm for blind image deblurring[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2020, 31(8):2923-2937.

[52] Bai Y, Jia H, Jiang M, Liu X, Xie X, Gao W. Single-image blind deblurring using multi-scale latent structure prior[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2019, 30(7):2033-2045.

[53] Luo B, Cheng Z, Xu L, Zhang G, Li H. Blind image deblurring via superpixel segmentation prior[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(3):1467-1482.

[54] Zhang J, Yue Z, Wang H, Zhao Q, Meng D. Blind image deconvolution by generative-based kernel prior and initializer via latent encoding[C]//Proceedings of the European Conference on Computer Vision. 2024: 73-92.

[55] Sun J, Cao W, Xu Z, Ponce J. Learning a convolutional neural network for non-uniform motion blur removal[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 769-777.

[56] Gong D, Yang J, Liu L, Zhang Y, Reid I, Shen C, et al. From motion blur to motion flow: A deep learning solution for removing heterogeneous motion blur[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2319-2328.

[57] Zhang K, Luo W, Zhong Y, Ma L, Stenger B, Liu W, et al. Deblurring by realistic blurring [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2020:

中国知网 https://www.cnki.net

2737-2746.

[58] Rozumnyi D, Oswald M R, Ferrari V, Matas J, Pollefeys M. Defmo: Deblurring and shape recovery of fast moving objects[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2021: 3456-3465.

[59] Tsai F J, Peng Y T, Tsai C C, Lin Y Y, Lin C W. Banet: a blur-aware attention network for dynamic scene deblurring[J]. IEEE Transactions on Image Processing, 2022, 31:6789-6799.

[60] Chen L, Chu X, Zhang X, Sun J. Simple baselines for image restoration[C]//Proceedings of the European Conference on Computer Vision. 2022: 17-33.

[61] Mao X, Li Q, Wang Y. Adarevd: Adaptive patch exiting reversible decoder pushes the limit of image deblurring[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2024: 25681-25690.

[62] 任静静, 方贤勇, 陈尚文, 汪粼波, 周健. 基于快速卷积神经网络的图像去模糊[J]. 计算机辅助设计与图形学学报, 2017, 29(08):1444-1456.

[63] 黄彦宁, 李伟红, 崔金凯, 龚卫国. 强边缘提取网络用于非均匀运动模糊图像盲复原[J]. 自动化学报, 2021, 47(11):2637-2653.

[64] 白勇强, 禹晶, 李一秾, 肖创柏. 基于深度先验的盲图像去模糊算法[J]. 电子学报, 2023, 51(04):1050-1067.

[65] Goodfellow I, Pouget-Abadie J, Mirza M, Xu B, Warde-Farley D, Ozair S, et al. Generative adversarial nets[C]//Proceedings of the Advances in Neural Information Processing Systems: volume 27. 2014.

[66] Tao X, Gao H, Shen X, Wang J, Jia J. Scale-recurrent network for deep image deblurring [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 8174-8182.

[67] Zhang H, Dai Y, Li H, Koniusz P. Deep stacked hierarchical multi-patch network for image deblurring[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 5978-5986.

[68] Suin M, Purohit K, Rajagopalan A. Spatially-attentive patch-hierarchical network for adaptive motion deblurring[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2020: 3606-3615.

[69] Zamir S W, Arora A, Khan S, Hayat M, Khan F S, Yang M H, et al. Multi-stage progressive image restoration[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2021: 14821-14831.

[70] Mao X, Liu Y, Shen W, Li Q, Wang Y. Deep residual fourier transformation for single image deblurring[J]. ArXiv, 2021.

[71] Chen L, Lu X, Zhang J, Chu X, Chen C. Hinet: Half instance normalization network for image

中国知网 https://www.cnki.net

restoration[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops. 2021: 182-192.

[72] Kim K, Lee S, Cho S. Mssnet: Multi-scale-stage network for single image deblurring[C]// Proceedings of the European Conference on Computer Vision. 2022: 524-539.

[73] Dong J, Pan J, Yang Z, Tang J. Multi-scale residual low-pass filter network for image deblurring [C]//Proceedings of the IEEE International Conference on Computer Vision. 2023: 12345-12354.

[74] Gao X, Qiu T, Zhang X, Bai H, Liu K, Huang X, et al. Efficient multi-scale network with learnable discrete wavelet transform for blind motion deblurring[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2024: 2733-2742.

[75] Gao H, Dang D. Adaptive identification of blurred regions for accurate image deblurring[J]. ArXiv, 2025.

[76] 陈紫柠, 张宏怡, 曾念寅, 李寒. 融合注意力机制的模糊图像多尺度复原[J]. 中国图象图形学报, 2022, 27(05):1682-1696.

[77] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Proceedings of the Medical Image Computing and Computer-Assisted Intervention. 2015: 234-241.

[78] He K, Zhang X, Ren S, Sun J. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.

[79] Zhang J, Pan J, Ren J, Song Y, Bao L, Lau R W, et al. Dynamic scene deblurring using spatially variant recurrent neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 2521-2529.

[80] Zhu C, Dong H, Pan J, Liang B, Huang Y, Fu L, et al. Deep recurrent neural network with multi-scale bi-directional propagation for video deblurring[C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 36. 2022: 3598-3607.

[81] Ren W, Zhang J, Pan J, Liu S, Ren J S, Du J, et al. Deblurring dynamic scenes via spatially varying recurrent neural networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(8):3974-3987.

[82] Park D, Kang D U, Kim J, Chun S Y. Multi-temporal recurrent neural networks for progressive non-uniform single image deblurring with incremental temporal training[C]//Proceedings of the European Conference on Computer Vision. 2020: 327-343.

[83] Nah S, Son S, Lee K M. Recurrent neural networks with intra-frame iterations for video deblurring[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 8102-8111.

[84] 蒲泽栋, 马伟, 米庆. 面向视频去模糊的高效时空特征提取循环神经网络[J]. 计算机辅助

中国知网 https://www.cnki.net

设计与图形学学报, 2023, 35(11):1720-1730.

[85] Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez A N, et al. Attention is all you need[C]//Proceedings of the Advances in Neural Information Processing Systems: volume 30. 2017.

[86] Dosovitskiy A, Beyer L, Kolesnikov A, Weissenborn D, Zhai X, Unterthiner T, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//Proceedings of the International Conference on Learning Representations. 2021.

[87] Liang J, Cao J, Sun G, Zhang K, Van Gool L, Timofte R. Swinir: Image restoration using swin transformer[C]//Proceedings of the IEEE International Conference on Computer Vision Workshops. 2021: 1833-1844.

[88] Chen H, Wang Y, Guo T, Xu C, Deng Y, Liu Z, et al. Pre-trained image processing transformer [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2021: 12299-12310.

[89] Tsai F J, Peng Y T, Lin Y Y, Tsai C C, Lin C W. Stripformer: Strip transformer for fast image deblurring[C]//Proceedings of the European Conference on Computer Vision. 2022: 146-162.

[90] Zamir S W, Arora A, Khan S, Hayat M, Khan F S, Yang M H. Restormer: Efficient transformer for high-resolution image restoration[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2022: 5728-5739.

[91] Wang Z, Cun X, Bao J, Zhou W, Liu J, Li H. Uformer: A general u-shaped transformer for image restoration[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2022: 17683-17693.

[92] Li Y, Fan Y, Xiang X, Demandolx D, Ranjan R, Timofte R, et al. Efficient and explicit modelling of image hierarchies for image restoration[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2023: 18278-18289.

[93] Kong L, Dong J, Ge J, Li M, Pan J. Efficient frequency domain-based transformers for high-quality image deblurring[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2023: 5886-5895.

[94] Mao X, Wang J, Xie X, Li Q, Wang Y. Loformer: Local frequency transformer for image deblurring[C]//Proceedings of the ACM International Conference on Multimedia. 2024: 10382-10391.

[95] Liu Z, Lin Y, Cao Y, Hu H, Wei Y, Zhang Z, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE International Conference on Computer Vision. 2021: 10012-10022.

[96] Sohl-Dickstein J, Weiss E, Maheswaranathan N, Ganguli S. Deep unsupervised learning using nonequilibrium thermodynamics[C]//Proceedings of the International Conference on Machine

中国知网 https://www.cnki.net

Learning. 2015: 2256-2265.

[97] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[C]//Proceedings of the Advances in Neural Information Processing Systems: volume 33. 2020: 6840-6851.

[98] Song Y, Sohl-Dickstein J, Kingma D P, Kumar A, Ermon S, Poole B. Score-based generative modeling through stochastic differential equations[J]. Proceedings of the International Conference on Learning Representations, 2021.

[99] Song J, Meng C, Ermon S. Denoising diffusion implicit models[J]. Proceedings of the International Conference on Learning Representations, 2021.

[100] Whang J, Delbracio M, Talebi H, Saharia C, Dimakis A G, Milanfar P. Deblurring via stochastic refinement[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2022: 16293-16303.

[101] Zhu Y, Zhang K, Liang J, Cao J, Wen B, Timofte R, et al. Denoising diffusion models for plug-and-play image restoration[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2023: 1219-1229.

[102] Xia B, Zhang Y, Wang S, Wang Y, Wu X, Tian Y, et al. Diffir: Efficient diffusion model for image restoration[C]//Proceedings of the IEEE International Conference on Computer Vision. 2023: 13095-13105.

[103] Ren M, Delbracio M, Talebi H, Gerig G, Milanfar P. Multiscale structure guided diffusion for image deblurring[C]//Proceedings of the IEEE International Conference on Computer Vision. 2023: 10721-10733.

[104] Chen Z, Zhang Y, Liu D, Gu J, Kong L, Yuan X, et al. Hierarchical integration diffusion model for realistic image deblurring[C]//Proceedings of the Advances in Neural Information Processing Systems: volume 36. 2024.

[105] Wu J H, Tsai F J, Peng Y T, Tsai C C, Lin C W, Lin Y Y. Id-blau: Image deblurring by implicit diffusion-based reblurring augmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2024: 25847-25856.

[106] Liu X, Wang Y, Chen Z, Cao J, Zhang H, Zhang Y, et al. One-step diffusion model for image motion-deblurring[J]. ArXiv, 2025.

[107] Kong L, Zhang J, Zou D, Ren J, Wu X, Dong J, et al. Deblurdiff: Real-world image deblurring with generative diffusion models[J]. ArXiv, 2025.

[108] Liang H, Wang Z, Deng W. Diffusion restoration adapter for real-world image restoration[J]. ArXiv, 2025.

[109] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[J]. ArXiv, 2023.

[110] Guo H, Li J, Dai T, Ouyang Z, Ren X, Xia S T. Mambair: A simple baseline for image restora-

中国知网 https://www.cnki.net

tion with state-space model[C]//Proceedings of the European Conference on Computer Vision. 2024: 222-241.

[111] Gao H, Ma B, Zhang Y, Yang J, Yang J, Dang D. Learning enriched features via selective state spaces model for efficient image deblurring[C]//Proceedings of the ACM International Conference on Multimedia. 2024: 710-718.

[112] Guo H, Guo Y, Zha Y, Zhang Y, Li W, Dai T, et al. Mambairv2: Attentive state space restoration [J]. ArXiv, 2024.

[113] Luan X, Fan H, Wang Q, Yang N, Liu S, Li X, et al. Fmambair: A hybrid state space model and frequency domain for image restoration[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025.

[114] Shi Y, Xia B, Jin X, Wang X, Zhao T, Xia X, et al. Vmambair: Visual state space model for image restoration[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2025.

[115] Wen J, Hou W, Van Gool L, Timofte R. Matir: A hybrid mamba-transformer image restoration model[J]. ArXiv, 2025.

[116] Peng L, Di X, Feng Z, Li W, Pei R, Wang Y, et al. Directing mamba to complex textures: An efficient texture-aware state space model for image restoration[J]. ArXiv, 2025.

[117] Nimisha T, Rengarajan V, Ambasamudram R. Semi-supervised learning of camera motion from a blurred image[C]//Proceedings of the IEEE International Conference on Image Processing. 2018: 803-807.

[118] Chen H, Gu J, Gallo O, Liu M Y, Veeraraghavan A, Kautz J. Reblur2deblur: Deblurring videos via self-supervised learning[C]//Proceedings of the IEEE International Conference on Computational Photography. 2018: 1-9.

[119] Zhang Z, Xu R, Liu M, Yan Z, Zuo W. Self-supervised image restoration with blurry and noisy pairs[C]//Proceedings of the Advances in Neural Information Processing Systems: volume 35. 2022: 29179-29191.

[120] Jiang R, Han Y. Uncertainty-aware variate decomposition for self-supervised blind image deblurring[C]//Proceedings of the ACM International Conference on Multimedia. 2023: 252-260.

[121] Li J, Wang W, Nan Y, Ji H. Self-supervised blind motion deblurring with deep expectation maximization[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2023: 13986-13996.

[122] Fang Z, Wu F, Dong W, Li X, Wu J, Shi G. Self-supervised non-uniform kernel estimation with flow-based motion prior for blind image deblurring[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2023: 18105-18114.

[123] Yi Z, Zhang H, Tan P, Gong M. Dualgan: Unsupervised dual learning for image-to-image translation[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017:

中国知网 https://www.cnki.net

2849-2857.

[124] Kim T, Cha M, Kim H, Lee J K, Kim J. Learning to discover cross-domain relations with generative adversarial networks[C]//Proceedings of the International Conference on Machine Learning. 2017: 1857-1865.

[125] Zhu J Y, Park T, Isola P, Efros A A. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 2223-2232.

[126] Nimisha T M, Sunil K, Rajagopalan A. Unsupervised class-specific deblurring[C]//Proceedings of the European Conference on Computer Vision. 2018: 353-369.

[127] Lu B, Chen J C, Chellappa R. Unsupervised domain-specific deblurring via disentangled representations[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 10225-10234.

[128] Tang X, Zhao X, Liu J, Wang J, Miao Y, Zeng T. Uncertainty-aware unsupervised image deblurring with deep residual prior[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2023: 9883-9892.

[129] Chen L, Tian X, Xiong S, Lei Y, Ren C. Unsupervised blind image deblurring based on self-enhancement[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2024: 25691-25700.

[130] Shen Z, Wang W, Lu X, Shen J, Ling H, Xu T, et al. Human-aware motion deblurring[C]// Proceedings of the IEEE International Conference on Computer Vision. 2019: 5572-5581.

[131] Liu Z, Luo P, Wang X, Tang X. Deep learning face attributes in the wild[C]//Proceedings of the IEEE International Conference on Computer Vision. 2015: 3730-3738.

[132] Rim J, Lee H, Won J, Cho S. Real-world blur dataset for learning and benchmarking deblurring algorithms[C]//Proceedings of the European Conference on Computer Vision. 2020: 184-201.

[133] Wang Z, Bovik A C, Sheikh H R, Simoncelli E P. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4):600-612.

[134] Zhang R, Isola P, Efros A A, Shechtman E, Wang O. The unreasonable effectiveness of deep features as a perceptual metric[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 586-595.

[135] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C]//Proceedings of the Advances in Neural Information Processing Systems: volume 25. 2012.

[136] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [C]//Proceedings of the International Conference on Learning Representations. 2015.

[137] Mittal A, Moorthy A K, Bovik A C. No-reference image quality assessment in the spatial

中国知网 https://www.cnki.net

domain[J]. IEEE Transactions on Image Processing, 2012, 21(12):4695-4708.

[138] Gulrajani I, Ahmed F, Arjovsky M, Dumoulin V, Courville A C. Improved training of wasserstein gans[C]//Proceedings of the Advances in Neural Information Processing Systems: volume 30. 2017.

[139] Szegedy C, Ioffe S, Vanhoucke V, Alemi A. Inception-v4, inception-resnet and the impact of residual connections on learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 31. 2017.

[140] Sandler M, Howard A, Zhu M, Zhmoginov A, Chen L C. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 4510-4520.

[141] Zhang H, Goodfellow I, Metaxas D, Odena A. Self-attention generative adversarial networks [C]//Proceedings of the International Conference on Machine Learning. 2019: 7354-7363.

[142] Deng J, Dong W, Socher R, Li L J, Li K, Fei-Fei L. Imagenet: A large-scale hierarchical image database[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2009: 248-255.

[143] Paszke A, Gross S, Chintala S, Chanan G, Yang E, DeVito Z, et al. Automatic differentiation in pytorch[C]//Proceedings of the Conference on Neural Information Processing Systems Workshops. 2017: 1-4.

[144] Kingma D P, Ba J. Adam: A method for stochastic optimization[C]//Proceedings of the International Conference on Learning Representations. 2015.

[145] Ji Y, Zhang H, Zhang Z, Liu M. Cnn-based encoder-decoder networks for salient object detection: A comprehensive review and recent advances[J]. Information Sciences, 2021, 546: 835-857.

[146] Zhang Y, Zhang Z, Wang Y, Zhang Z, Zhang L, Yan S, et al. Dual-constrained deep semi-supervised coupled factorization network with enriched prior[J]. International Journal of Computer Vision, 2021, 129:3233-3254.

[147] Zhang Z, Zheng H, Hong R, Xu M, Yan S, Wang M. Deep color consistent network for low-light image enhancement[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2022: 1899-1908.

[148] Song X, Zhou D, Li W, Ding H, Dai Y, Zhang L. Wsamf-net: Wavelet spatial attention-based multistream feedback network for single image dehazing[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 33(2):575-588.

[149] Liu P, Zhang H, Zhang K, Lin L, Zuo W. Multi-level wavelet-cnn for image restoration[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops. 2018: 773-782.

中国知网 https://www.cnki.net

[150] Xie E, Ding J, Wang W, Zhan X, Xu H, Sun P, et al. Detco: Unsupervised contrastive learning for object detection[C]//Proceedings of the IEEE International Conference on Computer Vision. 2021: 8392-8401.

[151] Chaitanya K, Erdil E, Karani N, Konukoglu E. Contrastive learning of global and local features for medical image segmentation with limited annotations[C]//Proceedings of the Advances in Neural Information Processing Systems: volume 33. 2020: 12546-12558.

[152] Dai B, Lin D. Contrastive learning for image captioning[C]//Proceedings of the Advances in Neural Information Processing Systems: volume 30. 2017.

[153] Wu H, Qu Y, Lin S, Zhou J, Qiao R, Zhang Z, et al. Contrastive learning for compact single image dehazing[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2021: 10551-10560.

[154] Chen X, Pan J, Jiang K, Li Y, Huang Y, Kong C, et al. Unpaired deep image deraining using dual contrastive learning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2022: 2017-2026.

[155] Wei Y, Zhang Z, Wang Y, Xu M, Yang Y, Yan S, et al. Deraincyclegan: Rain attentive cyclegan for single image deraining and rainmaking[J]. IEEE Transactions on Image Processing, 2021, 30:4788-4801.

[156] Ren D, Zuo W, Hu Q, Zhu P, Meng D. Progressive image deraining networks: A better and simpler baseline[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 3937-3946.

[157] Qin X, Wang Z, Bai Y, Xie X, Jia H. Ffa-net: Feature fusion attention network for single image dehazing[C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 34. 2020: 11908-11915.

[158] Song Y, He Z, Qian H, Du X. Vision transformers for single image dehazing[J]. IEEE Transactions on Image Processing, 2023, 32:1927-1941.

[159] Lehtinen J, Munkberg J, Hasselgren J, Laine S, Karras T, Aittala M, et al. Noise2noise: Learning image restoration without clean data[C]//Proceedings of the International Conference on Machine Learning. 2018.

[160] Wang Z, Liu J, Li G, Han H. Blind2unblind: Self-supervised image denoising with visible blind spots[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2022: 2027-2036.

[161] Wei C, Wang W, Yang W, Liu J. Deep retinex decomposition for low-light enhancement[C]// Proceedings of the British Machine Vision Conference. 2018.

[162] Guo C, Li C, Guo J, Loy C C, Hou J, Kwong S, et al. Zero-reference deep curve estimation for low-light image enhancement[C]//Proceedings of the IEEE Conference on Computer Vision

中国知网 https://www.cnki.net

and Pattern Recognition. 2020: 1780-1789.

[163] Li C, Guo C, Loy C C. Learning to enhance low-light image via zero-reference deep curve estimation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(8): 4225-4238.

[164] Tu Z, Talebi H, Zhang H, Yang F, Milanfar P, Bovik A, et al. Maxim: Multi-axis mlp for image processing[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2022: 5769-5780.

[165] Li B, Liu X, Hu P, Wu Z, Lv J, Peng X. All-in-one image restoration for unknown corruption [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2022: 17452-17462.

[166] Zhang X, Dong H, Hu Z, Lai W S, Wang F, Yang M H. Gated fusion network for joint image deblurring and super-resolution[C]//Proceedings of the British Machine Vision Conference. 2018.

[167] Song Y, Zhang J, Gong L, He S, Bao L, Pan J, et al. Joint face hallucination and deblurring via structure generation and detail enhancement[J]. International Journal of Computer Vision, 2019, 127:785-800.

[168] Ren J, Zhang Z, Hong R, Xu M, Yang Y, Yan S. Seeing through the noisy dark: Towards real-world low-light image enhancement and denoising[J]. ArXiv, 2022.

[169] Zhao Y, Xu Y, Yan Q, Yang D, Wang X, Po L M. D2hnet: Joint denoising and deblurring with hierarchical network for robust night image restoration[C]//Proceedings of the European Conference on Computer Vision. 2022: 91-110.

[170] Zhou S, Li C, Change Loy C. Lednet: Joint low-light enhancement and deblurring in the dark [C]//Proceedings of the European Conference on Computer Vision. 2022: 573-589.

[171] Wan Y, Cheng Y, Shao M, Gonzalez J. Image rain removal and illumination enhancement done in one go[J]. Knowledge-Based Systems, 2022, 252:109244.

[172] Zhang Z, Cheng Y, Suo J, Bian L, Dai Q. Infwide: image and feature space wiener deconvolution network for non-blind image deblurring in low-light conditions[J]. IEEE Transactions on Image Processing, 2023, 32:1390-1402.

[173] Liu R, Ma L, Zhang J, Fan X, Luo Z. Retinex-inspired unrolling with cooperative prior architecture search for low-light image enhancement[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2021: 10561-10570.

[174] Ma L, Ma T, Liu R, Fan X, Luo Z. Toward fast, flexible, and robust low-light image enhancement[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2022: 5637-5646.

[175] Land E H. The retinex theory of color vision[J]. Scientific american, 1977, 237(6):108-129.

[176] Liu H, Simonyan K, Yang Y. Darts: Differentiable architecture search[C]//Proceedings of the

中国知网 https://www.cnki.net

International Conference on Learning Representations. 2019.

[177] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786):504-507.

[178] Welling M, Kingma D P. Auto-encoding variational bayes[C]//Proceedings of the International Conference on Learning Representations. 2014.

[179] Ulyanov D, Vedaldi A, Lempitsky V. Deep image prior[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 9446-9454.

[180] Zhang Z, Zhao S, Jin X, Xu M, Yang Y, Yan S, et al. Noise self-regression: A new learning paradigm to enhance low-light images without task-related data[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024.

[181] Mao X, Li Q, Xie H, Lau R Y, Wang Z, Paul Smolley S. Least squares generative adversarial networks[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 2794-2802.

[182] Ulyanov D, Vedaldi A, Lempitsky V. Instance normalization: The missing ingredient for fast stylization[J]. ArXiv, 2016.

[183] Buchsbaum G. A spatial processor model for object colour perception[J]. Journal of the Franklin institute, 1980, 310(1):1-26.

[184] Guo X. Lime: A method for low-light image enhancement[C]//Proceedings of the ACM International Conference on Multimedia. 2016: 87-91.

[185] Zhang Q, Nie Y, Zheng W S. Dual illumination estimation for robust exposure correction[C]// Computer graphics forum: volume 38. 2019: 243-252.

中国知网 https://www.cnki.net