中国科学技术大学

博士学位论文



面向视觉感知和语义理解的图像复原方法研究

作者姓名：　杨子正

学科专业：　控制科学与工程

导　　师：　赵峰 教授

完成时间：　二〇二五年五月三十日

中国知网　https://www.cnki.net

University of Science and Technology of China

A dissertation for doctor's degree



Research on Image Restoration Methods for Visual Perception and Semantic Understanding

Author: Yang Zizheng

Speciality: Control Science and Engineering

Supervisor: Prof. Zhao Feng

Completion date: May 30, 2025

中国知网 https://www.cnki.net

创新性说明

图像复原技术是计算机视觉领域的重要研究方向。图像复原技术旨在从遭受退化的低质量图像中恢复出清晰的高质量图像，对于提升视觉效果和下游识别任务性能具有重要意义。本文从视觉感知和语义理解两个角度出发，探索图像复原方法的设计方式，具体如下：

（1）针对现有的图像复原方法信息表征建模能力不足的问题，提出了基于扩散模型先验信息的图像复原方法。通过探索预训练扩散模型中丰富的视觉先验，并设计网络架构来有效集成这些先验信息以引导图像复原过程，从而提升图像复原效果。

（2）针对现有多视角图像复原方法中跨视角信息协同利用不充分的问题，提出了多视角空间关系探索的图像复原方法。通过由粗到细的方式对多视角图像间的对应关系进行探索，并对跨视角间信息进行精准的对齐和融合，从而有效提升多视角图像复原性能。

（3）针对现有识别驱动图像复原方法中语义引导机制不完善的问题，提出了面向视觉识别任务的多退化统一图像复原方法。考虑到不同退化在语义层面的差异化影响，针对性地设计网络结构，并将训练过程划分为目标清晰的两个阶段，从而显著提升了复原图像在下游视觉识别任务中的适配性。

（4）针对现有识别驱动图像复原方法中泛化性不足的问题，提出了基于视觉感知与语义优化协同的图像复原方法。通过在优化空间中探索视觉重建约束与语义恢复约束的关系，并进一步设计语义恢复约束函数和训练策略，从而显著提升图像复原网络针对下游视觉识别任务的泛化性。

本文从不同维度探索图像复原方法的设计范式，形成了从视觉效果提升到语义质量增强的完整技术体系，为图像复原技术在实际场景中的应用提供解决方案，并进一步推动图像复原技术的研究和发展。

中国知网 https://www.cnki.net

摘要

视觉是人类感知外界环境的主要途径，不仅对于人们的日常生活至关重要，同时也是计算机视觉系统分析和理解环境信息的核心基础。作为视觉信息的重要载体，图像在人类视觉感知与计算机视觉处理中都发挥着关键作用。然而，由于硬件配置以及拍摄环境等因素的影响，获取的图像可能会存在质量退化的问题，这不仅影响人类的视觉观感，也降低了后续计算机视觉系统对于图像信息理解的准确性。作为提升图像质量的关键手段，图像复原技术致力于从退化图像中重建出内容清晰的高质量图像，已成为计算机视觉领域的重要研究方向。近年来，随着深度学习的兴起，图像复原技术也得到了快速发展。即使如此，图像复原技术依然面临着重要挑战，例如如何进一步提升复原图像的视觉质量、如何提升复原图像针对各种计算机视觉系统的适配性和泛化性。为了解决上述挑战，本文从视觉感知和语义理解两个角度出发，探索图像复原方法的设计方式，其中，视觉感知侧重于提升复原图像的视觉质量与人类观感，而语义理解则强调复原图像针对各种下游视觉识别任务的适配性。本文旨在提升图像复原技术的多场景应用性，并推动图像复原技术的研究和发展。本文的主要研究内容和创新点如下：

（1）基于扩散模型先验信息的图像复原方法。针对当前图像复原方法信息表征建模能力不足的问题，本文提出了一种利用扩散模型中丰富的视觉先验引导图像复原的方法。本文首先对预训练扩散模型语义隐空间的特性进行探索，并揭示了该空间特征在不同时间步时对于退化图像信息的差异化表征能力：当时间步较小时，隐空间特征主要编码图像的底层内容；随着时间步的增大，隐空间特征逐渐聚焦于捕捉图像的退化特性。基于以上观察，本文提出了一种基于扩散模型隐空间特征引导的图像复原网络。该网络配有针对性设计的模块，可以有效集成不同时间步时扩散模型的语义隐空间特征，以精确引导网络进行底层内容的恢复与退化成分的去除。在多个图像复原任务上的实验结果验证了所提方法的有效性。

（2）基于多视角空间关系探索的图像复原方法。针对多视角图像复原中跨视角信息协同利用不充分的问题，本文提出了一种充分探索跨视角图像对应关系的方法。本文以双目图像复原作为切入点，利用 Transformer 架构在捕获长距离空间关系上的优势，提出了一个基于 Transformer 的双目图像复原网络，通过由粗到细的方式对双目图像间的关联性进行探索。该网络首先通过一个双目对齐模块，在水平极线约束下通过全局感受野建模左右视图之间的对应关系，并在特征层面将双目视图进行对齐。而后，通过一个双目融合模块在局部区域内进一步实现左右视角的信息交互，并实现跨视角信息的精准融合。在多个双目图像复原

中国知网 https://www.cnki.net

任务上的实验结果验证了所提方法的有效性。

（3）面向视觉识别任务的多退化统一图像复原方法。针对面向视觉识别任务的图像复原方法中语义引导机制不完善的问题，本文提出了一种可以有效增强图像内在语义的图像复原方法。本文从实际应用的角度出发，考虑到不同退化类型在语义层面造成的差异化影响，针对性的设计了一个内在语义增强模块。该模块首先将不同退化的语义特征映射到统一空间，而后利用输入退化特征的统计特性对其进行自适应的动态调整。同时，本文进一步提出了先验赋予优化策略，该策略将训练过程分为目标清晰的两个阶段。在第一阶段，通过预训练一个语义感知解码器来赋予模型感知清晰图像语义与退化图像语义的能力；在第二阶段，将语义感知解码器与内在语义增强模块级联，并单独训练内在语义增强模块，使其引导输入退化语义特征向着清晰图像语义特征靠拢。该方法可以在不需要事先了解退化类型和识别任务的条件下，从输入的退化图像中恢复出有效适配下游识别任务的清晰图像，具有较强的实用性。在多个图像复原任务和多种视觉识别任务上的实验结果证明了所提方法的有效性。

（4）基于视觉感知与语义优化协同的图像复原方法。针对现有识别驱动的图像复原方法泛化性不足的问题，本文提出了一种动态协同视觉重建与语义恢复的图像复原方法。本文利用图像重建损失约束与语义恢复约束共同训练图像复原网络，在优化空间中探索两者之间的关系，并提出了一种动态梯度校正策略。该策略能够根据两种约束优化方向的夹角对语义恢复约束的梯度进行动态校正，有效提升了图像复原网络针对下游识别任务的泛化性。同时，本文探索了语义恢复约束的计算方式，提出了一种内在语义一致性约束，通过匹配图像间语义相似度分布来有效引导复原图像的语义信息恢复。此外，本文还提出了一种清晰图像增强策略，通过对清晰图像进行适当扰动来增强语义恢复的鲁棒性。本文所提的训练框架可以无缝应用于现有的图像复原网络中，具有较强的通用性。大量的实验结果证明了所提方法的可以显著提升现有图像复原网络针对下游视觉识别任务的泛化性。

关键词：图像复原，视觉感知，语义理解，深度学习

中国知网 https://www.cnki.net

ABSTRACT

Vision is the primary pathway by which humans perceive the external environment. It is not only essential for daily life but also serves as the fundamental basis for computer vision systems to analyze and understand environmental information. As an important carrier of visual information, images play a critical role in both human visual perception and computer vision processing. However, due to factors such as hardware configurations and shooting conditions, acquired images may suffer from quality degradation, which not only affects human visual perception but also reduces the accuracy of downstream computer vision systems in understanding image content. As a critical approach to enhancing image quality, image restoration techniques aim to reconstruct high-quality images with clear content from degraded inputs, and have become a significant research focus in the field of computer vision. In recent years, with the rise of deep learning, image restoration has also developed rapidly. Even so, image restoration still faces significant challenges, such as how to further enhance the visual quality of restored images, and how to improve the adaptability and generalization of restored images for various computer vision systems. To address these challenges, this dissertation explores the design of image restoration methods from two perspectives: visual perception and semantic understanding. Visual perception focuses on improving the visual quality and human perception of restored images, while semantic understanding emphasizes the adaptability of restored images for various downstream visual recognition tasks. This dissertation aims to improve the applicability of image restoration techniques in various scenarios, and promote the research and development of image restoration. The main research contents and innovations of this work are as follows:

(1) Diffusion Prior-Based Image Restoration Method. To address the issue of existing image restoration methods in modeling information representation, this dissertation proposes to leverage the rich visual priors from pre-trained diffusion models to guide image restoration. The method first explores the semantic latent space properties of pre-trained diffusion models, and reveals its differentiated representation capabilities for degraded image at different time-steps: when the time-step is relatively small, the latent features primarily encode the underlying content; as the time-step increases, the latent features gradually focus on capturing the degradation characteristics of the image. Based on the observations, a diffusion latent feature-guided image restoration network is proposed. The network is equipped with delicately designed modules that can effec-

中国知网 https://www.cnki.net

tively integrate semantic latent features from diffusion models at different time-steps, precisely guiding the network to recover underlying content and remove degradation. Extensive experiments on multiple image restoration tasks validate the effectiveness of the proposed method.

(2) Image Restoration Method Based on Multi-View Spatial Relationship Exploration. To address the problem of insufficient cross-view information coordination in multi-view image restoration, this dissertation proposes a method that fully explores correspondence relationships between cross-view images. Taking stereo image restoration as the entry point, the method leverages the advantages of Transformer architecture in capturing long-range spatial relationships. A Transformer-based stereo image restoration network is proposed to explore correlations between stereo images through a coarse-to-fine manner. Specifically, the network first employs a stereo alignment module that models the correspondence between left and right views under the epipolar constraints with a global receptive field, aligning the stereo views at feature level. Then, a stereo fusion module further interacts information between stereo images within local areas, which achieves precise fusion of cross-view information. Extensive experiments on multiple stereo image restoration tasks validate the effectiveness of the proposed method.

(3) Multi-Degradation Unified Image Restoration Method for Visual Recognition Tasks. To address the limitations of semantic guidance mechanisms in image restoration methods for visual recognition tasks, this dissertation proposes an image restoration approach that can effectively enhance intrinsic semantics of images. From the perspective of practical application, this dissertation considers the different impacts caused by various degradation types at semantic level, and designs an intrinsic semantic enhancement module. This module first maps semantic features of different degradations into a unified space, and then modulate them dynamically with their statistical characteristics. Furthermore, a prior-ascribing optimization strategy is proposed, which separates the training process to two well-defined stages. In the first stage, a semantic-aware decoder is first pre-trained to endow the model with ability to perceive both clear semantics and degraded semantics. In the second stage, the pre-trained semantic-aware decoder is cascaded with the intrinsic semantics enhancement module, and the intrinsic semantics enhancement module is trained independently to guide the input degraded semantic features towards those of clear images. This method can recover clear images that effectively adapt to various downstream recognition tasks from degraded input without prior knowledge of degradation types or recognition tasks, demonstrating strong practicality.

中国知网 https://www.cnki.net

Extensive experiments on multiple image restoration tasks and various recognition tasks validate the effectiveness of the proposed method.

(4) Image Restoration Method Based on the Synergy of Visual Perception and Semantic Optimization. To address the limited generalization capability of existing recognition-driven image restoration methods, this dissertation proposes an approach that dynamically coordinates visual reconstruction and semantic recovery. In the framework, the image restoration network is jointly trained with image reconstruction constraint and semantic recovery constraint, exploring the relationship between these two objectives in optimization space. A dynamic gradient calibration is introduced, which dynamically adjusts the gradients of semantic recovery constraint based on the angle between the optimization direction of the two constraints. This strategy effectively enhances the generalization capability of image restoration network for downstream visual recognition tasks. Furthermore, this dissertation investigates the computation of semantic recovery constraint, and proposes an intrinsic semantic consistency constraint, which effectively guides the recovery of semantic information by matching the semantic similarity distributions between images. In addition, a clear image augmentation strategy is further proposed, which improves the robustness of semantic recovery by applying appropriate perturbations to clear images. The proposed training framework can be seamlessly integrated into existing image restoration networks, demonstrating strong versatility. Extensive experiments demonstrate that the proposed method can significantly improve the generalization capability of existing image restoration networks for downstream visual recognition tasks.

KEY WORDS: Image Restoration, Visual Perception, Semantic Understanding, Deep Learning

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 图像复原技术.....3
1.2.2 面向视觉识别任务的图像复原技术.....11
1.2.3 图像复原领域存在的问题.....14
1.3 本文研究内容和创新点.....16
1.4 本文组织结构.....17
第 2 章 基于扩散模型先验信息的图像复原方法.....20
2.1 引言.....20
2.2 扩散模型原理.....21
2.3 扩散模型先验信息探索与网络结构设计.....23
2.3.1 扩散模型语义隐空间特性探索.....23
2.3.2 基于扩散模型隐空间特征引导的图像复原网络.....27
2.3.3 损失函数.....28
2.4 实验分析.....29
2.4.1 数据集和评价指标.....29
2.4.2 实验设置.....31
2.4.3 性能比较.....31
2.4.4 消融实验.....38
2.5 本章小结.....40
第 3 章 基于多视角空间关系探索的图像复原方法.....41
3.1 引言.....41
3.2 双目图像成像原理.....43
3.3 多视角空间关系探索与网络结构设计.....44
3.3.1 整体模型描述.....44
3.3.2 双目对齐模块.....47
3.3.3 双目融合模块.....48
3.3.4 损失函数.....50
3.4 实验分析.....51
3.4.1 数据集和评价指标.....51
3.4.2 实验设置.....51
3.4.3 性能比较.....52
3.4.4 消融实验.....58

中国知网 https://www.cnki.net

3.5 本章小结.....59
第 4 章 面向视觉识别任务的多退化统一图像复原方法.....60
4.1 引言.....60
4.2 视觉理解任务.....62
4.3 面向识别任务的多退化统一处理图像复原方法设计.....64
4.3.1 整体模型描述.....64
4.3.2 内在语义增强模块.....65
4.3.3 先验赋予优化策略.....69
4.4 实验分析.....72
4.4.1 数据集和评价指标.....72
4.4.2 实验设置.....72
4.4.3 性能比较.....73
4.4.4 消融实验.....79
4.5 本章小结.....81
第 5 章 基于视觉感知与语义优化协同的图像复原方法.....82
5.1 引言.....82
5.2 视觉感知与语义优化协同的网络训练框架.....84
5.2.1 整体框架描述.....84
5.2.2 动态梯度校正策略.....85
5.2.3 内在语义一致性约束.....89
5.2.4 清晰图像增强策略.....90
5.3 实验分析.....92
5.3.1 数据集和评价指标.....92
5.3.2 实验设置.....93
5.3.3 性能比较.....93
5.3.4 消融实验.....99
5.4 本章小结.....102
第 6 章 总结与展望.....103
6.1 研究内容总结.....103
6.2 未来展望.....104
参考文献.....107

中国知网 https://www.cnki.net

插图清单

图 1.1 图像复原的示例 1
图 1.2 图像复原技术的研究意义 2
图 1.3 图像退化与复原 4
图 1.4 基于深度学习的图像复原方法流程框架 7
图 1.5 基于卷积神经网络和 Transformer 的图像复原方法 8
图 1.6 针对多类型退化的图像复原方法 9
图 1.7 基于扩散模型的图像复原方法 10
图 1.8 多视角图像复原方法 11
图 1.9 面向视觉识别任务的图像复原训练流程 12
图 1.10 基于特征学习的方法 13
图 1.11 面向视觉识别任务的图像复原方法框架 14
图 1.12 图像复原技术存在的问题和挑战 15
图 1.13 本文研究内容关系概览图 17
图 1.14 本文的组织结构 18

图 2.1 去噪扩散概率模型 22
图 2.2 扩散模型语义隐空间探索方法示意图 23
图 2.3 解码器 D_t 结构 24
图 2.4 有雾图像与清晰图像在语义隐空间和图像空间中 t-SNE 可视化 25
图 2.5 有雾-清晰图像对的语义隐空间特征分布转变可视化 25
图 2.6 暗光-正常光照图像的语义隐空间特征重建结果可视化 26
图 2.7 暗光-正常光照图像对的语义隐空间特征分布转变可视化 26
图 2.8 基于扩散模型隐空间特征引导的图像复原网络结构 27
图 2.9 不同方法在 SOTS 数据集上的图像去雾定性比较 34
图 2.10 不同方法在 Dense-Haze 数据集上的图像去雾定性比较 34
图 2.11 不同方法在 NH-HAZE 数据集上的图像去雾定性比较 34
图 2.12 不同方法在 LOL 数据集上的暗光图像增强定性比较 35
图 2.13 不同方法在 Rain100H 数据集上的图像去雨定性比较 37
图 2.14 不同 t_1 和 t_2 选择在 SOTS 数据集上对图像去雾性能的影响 38

图 3.1 双目立体视觉成像系统 43
图 3.2 双目图像中的水平极线约束 43
图 3.3 基于 Transformer 架构的双目图像复原网络 44

中国知网 https://www.cnki.net

图 3.4 Transformer 编码器结构 46
图 3.5 基于 Transformer 的双目对齐模块 48
图 3.6 基于 Transformer 的双目融合模块 49
图 3.7 双目图像复原网络中不同模块注意力计算方式对比 50
图 3.8 不同方法在 Flickr1024 数据集的 2 倍双目图像超分辨率定性比较 53
图 3.9 不同方法在 Flickr1024 数据集双目图像超分辨率定性差值比较 53
图 3.10 不同方法在 Flickr1024 数据集的 4 倍双目图像超分辨率定性比较 54
图 3.11 不同方法在 KITTI2012 数据集双目图像去模糊定性比较 55
图 3.12 不同方法在 KITTI2015 数据集双目图像去模糊定性比较 55
图 3.13 不同方法在 KITTI2012 数据集双目图像去雨定性比较 56
图 3.14 不同方法在 KITTI2015 数据集双目图像去雨定性比较 56
图 3.15 不同方法在双目图像去噪和复杂场景复原任务中定性比较 57

图 4.1 复原图像视觉质量与语义质量的关系 61
图 4.2 图像分类与目标检测概念介绍 63
图 4.3 面向视觉识别任务的多退化统一图像复原方法 64
图 4.4 退化归一化补偿模块 65
图 4.5 有雾图像和带噪图像傅里叶空间幅度谱分布可视化 67
图 4.6 傅里叶引导调制模块 68
图 4.7 先验赋予优化策略 70
图 4.8 不同语义感知解码器的预训练策略 71
图 4.9 图像复原方法在下游视觉识别任务上性能测试流程 73
图 4.10 不同方法在 CUB 数据集上去雾图像 VGG16 特征可视化 76
图 4.11 不同方法在 CUB 数据集上去噪图像 VGG16 特征可视化 76
图 4.12 不同方法在 CUB 数据集图像去雾后分类性能定量比较 78

图 5.1 已有识别任务驱动图像复原方法的与本章提出的方法比较 83
图 5.2 基于视觉感知与语义优化协同的图像复原方法 85
图 5.3 动态梯度校正策略 87
图 5.4 不同训练策略对应的优化轨迹 89
图 5.5 不同方法在 CUB 数据集上图像去雾定性比较 96
图 5.6 不同方法在 CUB 数据集上图像去噪定性比较 97
图 5.7 清晰图像增强策略消融实验 101
图 5.8 参数 τ 和参数 η 选择消融实验 102

中国知网 https://www.cnki.net

附表清单

表 2.1 不同方法在去雾数据集 SOTS 上定量比较 32
表 2.2 不同方法在去雾数据集 Dense-Haze 和 NH-HAZE 上定量比较 33
表 2.3 不同方法在 LOL 数据集上暗光图像增强定量比较 35
表 2.4 不同方法在 Rain100H 数据集上图像去雨定量比较 36
表 2.5 内容融合模块和退化感知增强模块在 PSNR 指标上的消融实验 39
表 2.6 不同特征空间在 PSNR 指标上的消融实验 40

表 3.1 不同方法在双目图像超分辨率任务中左视图定量比较 53
表 3.2 不同方法在双目图像超分辨率任务中左右视图平均定量比较 54
表 3.3 不同方法在双目图像去模糊任务中定量比较 55
表 3.4 不同方法在双目图像去雨任务中定量比较 56
表 3.5 不同方法在双目图像去噪和复杂场景复原任务中定量比较 57
表 3.6 双目图像对齐和双目图像融合模块消融实验 58
表 3.7 双目一致性损失函数消融实验 59
表 3.8 双目图像融合模块中邻域大小选择消融实验 59

表 4.1 不同方法在 CUB 数据集图像去雾后分类性能定量比较 74
表 4.2 不同方法在 CUB 数据集图像去噪后分类性能定量比较 75
表 4.3 不同方法在 CUB 数据集图像去雨后分类性能定量比较 75
表 4.4 不同方法在 CrowdHuman 数据集图像去雾后检测性能定量比较 77
表 4.5 不同方法在 CrowdHuman 数据集图像去噪后检测性能定量比较 77
表 4.6 不同方法在 CrowdHuman 数据集图像去雨后检测性能定量比较 78
表 4.7 内在语义增强模块在 Top-1V 准确率上的消融实验 80
表 4.8 先验赋予优化策略在 Top-1V 准确率上的消融实验 80
表 4.9 语义最大化约束在 Top-1V 准确率上的消融实验 80
表 4.10 语义感知解码器预训练方式消融实验 81

表 5.1 不同方法在 CUB 数据集图像去雾后分类性能定量比较 94
表 5.2 不同方法在 CUB 数据集图像去噪后分类性能定量比较 94
表 5.3 不同方法在 CUB 数据集图像去雨后分类性能定量比较 95
表 5.4 不同方法在 CrowdHuman 数据集图像去雾后检测性能定量比较 98
表 5.5 不同方法在 CrowdHuman 数据集图像去噪后检测性能定量比较 98
表 5.6 不同方法在 CrowdHuman 数据集图像去雨后检测性能定量比较 99

中国知网 https://www.cnki.net

表 5.7　不同方法在 CUB 数据集图像去雾与图像去噪后分类性能定量比较 100
表 5.8　动态梯度校正策略消融实验 …… 100
表 5.9　内在语义一致性约束消融实验 …… 101

中国知网 https://www.cnki.net

第 1 章　绪论

1.1　研究背景及意义

视觉是人类获取外界信息的主要途径，对人类的生存和发展具有不可替代的作用。通过视觉系统，人类能够快速、准确地捕捉外界环境中的丰富信息，从而完成对周围世界的认知，并辅助人类做出判断和决策。视觉不仅帮助人类感知物体的形状、颜色、运动和纹理，还赋予了人类理解复杂场景、预测动态变化的能力。图像作为视觉信息的重要载体，在人类的日常生活中扮演着不可或缺的角色。在另一方面，进入 21 世纪后，在人工智能的浪潮下，计算机视觉迅猛发展，并成为推动科技进步和社会发展的重要力量。通过高效处理和分析图像数据，计算机视觉技术在自动驾驶[1]、智能监控[2]、医疗诊断[3]以及图像生成[4]等领域展现了巨大的应用价值和潜力。而图像在这些计算机视觉系统中的作用，类似于其对人类视觉系统的作用：它是计算机获取和理解环境信息的核心支撑，是实现高层次任务（如目标识别、行为分析和场景理解）的基础。

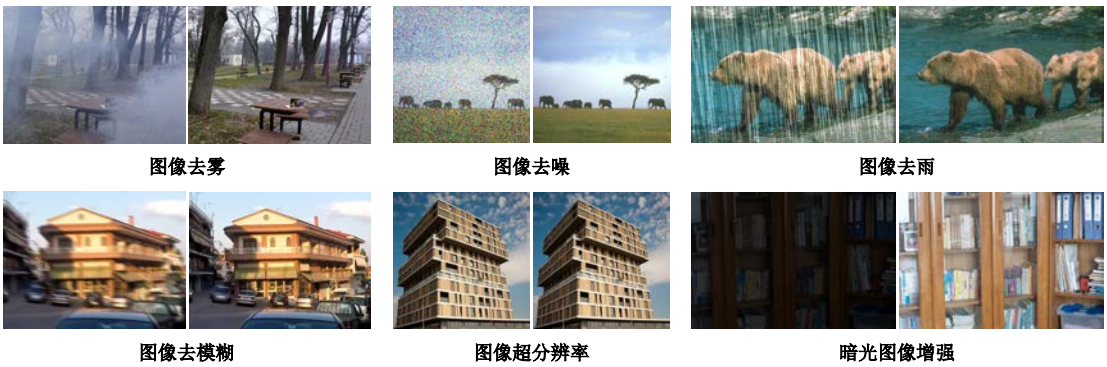


图 1.1　图像复原的示例

在计算机视觉领域，图像的获取大多依赖于部署在真实场景中的各种传感器。然而，受到硬件配置、拍摄环境以及传输方式等因素的影响，传感器采集到的图像质量可能会受到不同程度的损失，导致退化图像的产生。这不仅会降低图像的视觉质量，影响人类的观看体验，同时还会对后续计算机视觉系统对图像内容的准确理解和分析产生负面影响。为此，图像复原技术应运而生。图像复原技术通过一系列算法来去除低质量图像上的退化信息，同时恢复图像的纹理细节，从而获得高质量的清晰图像。近十年来，随着深度学习技术的发展，图像复原算法已经成为了一个热门的研究方向，并获得了广泛的应用。例如，在医学领域，通过图像复原技术去除医学影像中的噪声和伪影，从而更精准地展示病理特征，避免误诊[5]；在监控安全领域，利用图像复原技术提高摄像头捕获的人脸图像质量，从而提升人脸识别系统的准确率[6]；许多国内外的科技公司，如国内的华

中国知网　https://www.cnki.net

为、大疆、小米等，国外的谷歌、索尼等都在逐步加大对图像复原算法的投入。

图像复原技术旨在从遭受退化的低质量图像中恢复出内容清晰逼真的高质量图像。由于实际场景中退化类型的多样性，图像复原也演化出如图像去雾[7]、图像去雨[8]、图像去噪[9]、图像超分辨率[10]、图像去模糊[11]、暗光图像增强[12]等子任务，如图 1.1所示。经典图像复原技术往往基于数学模型和物理先验来实现图像的复原[13]。随着深度学习技术的快速发展，基于深度神经网络的图像复原方法逐渐成为主流。该类方法通常使用大量退化图像及其对应的清晰图像作为训练数据，通过端到端的方式训练神经网络，以学习退化图像到清晰图像的映射，其中比较有代表性的包括基于卷积神经网络（Convolution Neural Network，CNN）[14]和基于 Transformer[15]等架构的方法。尽管这些方法近年来取得了巨大成功，但在许多退化场景下，仍然面临着无法有效全面地去除图像中退化信息的问题，同时在准确恢复图像的纹理细节方面仍然有提升的空间。

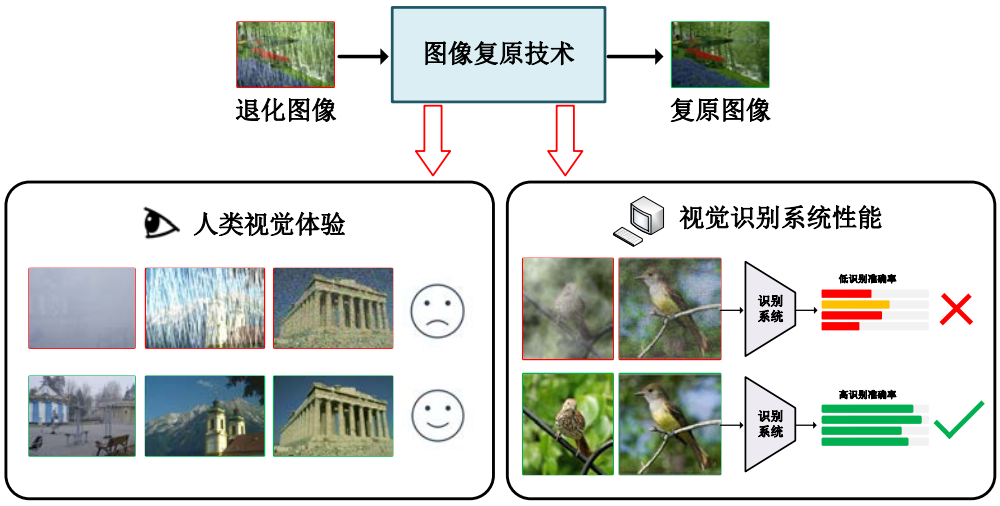


图 1.2　图像复原技术的研究意义

另一方面，当前图像复原研究大多以人类视觉感知为导向，以视觉质量为核心优化目标，以复原出视觉上更清晰逼真的图像，却往往忽略了对图像语义信息的精准复原。随着计算机视觉技术的快速发展，图像复原的应用场景已不在局限于服务人类视觉系统，而是越来越多地被用于支持语义驱动的高层视觉识别任务。而在这些高层识别任务中，仅依赖视觉层面提升并不能充分保障识别系统对图像内容的正确理解。而这种现象出现的核心原因，便是人类视觉与机器视觉之间的差异。人类视觉侧重于图像的整体感知质量，而机器视觉则往往对图像的内在语义特征更加敏感。在目前基于深度学习的图像复原方法中，通常将逐像素级的指标作为主要的度量手段来优化和评估图像复原网络的性能。这类度量方法大多强调图像低层细节修复与整体视觉效果的改善，如纹理、细节的重建和对比度的增强。但其对于图像内关键特征、场景语义和目标边界等高层次语义结构的关注不足，无法有效约束图像内在语义信息的恢复。例如，图像复原模型为了提

中国知网　https://www.cnki.net

升全局视觉观感而过度平滑某些区域，使得图像中不同物体之间的边界模糊，进而影响下游目标检测任务中回归框定位的准确性；同理，过渡的平滑又导致了某些高频信息的丢失，而这些信息恰恰是图像分类系统区分不同类别的关键判别性特征。如何设计一种面向视觉识别任务的图像复原方法，在图像复原过程中兼顾视觉质量与语义信息，在优化过程中有效协调视觉感知和语义理解，成为了图像复原领域一个亟待解决的重要问题。

综上所述，图像复原技术在计算机视觉领域中发挥着关键作用。通过图像复原技术，不仅可以增强退化图像的视觉质量，满足人类视觉系统的观感，同时还可以为下游视觉识别系统提供更加可靠的输入信号，从而提升系统的识别准确率，如图 1.2所示。因此，针对视觉感知和语义理解这两个方向，本文进行了系统地研究：一方面，围绕图像视觉质量的提升，尝试引入外界先验信息辅助图像恢复，并探索多视角场景下图像复原方法；另一方面，围绕图像内在语义信息的增强，设计语义信息的约束方式和针对性的训练策略，并探索视觉质量和语义质量在优化空间中的关系。本文旨在推动图像复原技术全面发展，为其在实际场景中的广泛应用提供技术支持。

1.2　国内外研究现状

计算机视觉领域的图像复原技术是通过图像处理技术对退化的图像进行修复和重建，从而恢复其原始清晰度和纹理细节的技术。当前，大多数的图像复原技术关注于提升图像的视觉质量，以更好的服务人类的视觉系统。而随着计算机视觉领域的快速发展，对于图像复原技术的要求已经不仅仅满足于人眼的感官，而是逐步发展成为面向下游高层视觉识别任务的支撑技术。作为一个能为更广泛的智能视觉系统提供支持的技术，面向视觉识别任务的图像复原技术获得了越来越多的关注。相比于传统的图像复原方法，这类方法更注重于重建能更高效服务于下游高层视觉识别任务的图像。尽管近些年许多研究都尝试解决这个问题，但是它们在实际应用中仍然面临各种挑战。下面分别依次介绍与图像复原技术以及面向视觉识别任务的图像复原技术相关领域的发展情况，以期对该领域有更加全面深入的认识。

1.2.1　图像复原技术

图像复原技术旨在提升受损图像的视觉质量，包括退化信息去除、噪声抑制、对比度调整以及细节修复等，以满足人类视觉系统的观感。在图像的采集和传输过程中，图像不可避免地会受到各种退化因素的影响导致其质量下降，该过

中国知网　https://www.cnki.net

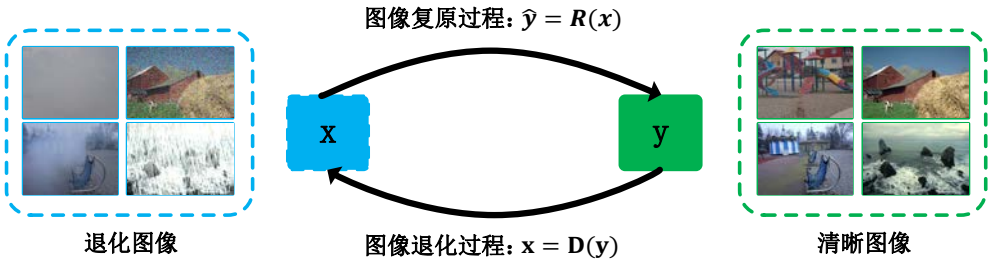


图 1.3　图像退化与复原

程可以表示为：

$$\mathbf{x} = \mathcal{D}(\mathbf{y}), \tag{1.1}$$

其中，$\mathbf{y}$ 表示高质量图像，其经由不同的退化过程 $\mathcal{D}$，得到相对应的不同退化低质量图像 $\mathbf{x}$。不同的退化过程 $\mathcal{D}$ 有不同的数学建模方式，例如：

对于图像去雾任务，人们通常采用大气散射模型来建模雾图的生成过程。该模型可以表示为：

$$I(x) = J(x)t(x) + A(1 - t(x)), \tag{1.2}$$

其中，$I(x)$ 代表有雾图像，$J(x)$ 代表无雾的清晰图像，A 代表全局大气光，而 $t(x)$ 代表场景透射率。而 $t(x)$ 又可以进一步表示为 $t(x) = e^{-\beta d(x)}$，其中 β 代表大气散射系数，而 $d(x)$ 代表场景深度信息。

对于图像去雨任务，雨图的退化过程通常建模为：

$$x = y + r, \tag{1.3}$$

其中，x 代表有雨图像，y 代表无雨的清晰图像，而 r 代表雨线带来的退化信息。雨线通常呈现为不同长短、不同粗细的连续线状或带状结构，以不同的倾斜方向随机分布在图像的不同位置。

而图像复原过程，就是设计图像复原算法，将退化后的低质量图像修复成原始的高质量图像，如图 1.3所示。该过程可以表示为：

$$\hat{\mathbf{y}} = \mathcal{R}(\mathbf{x}), \tag{1.4}$$

其中，$\mathcal{R}$ 表示图像复原模型，$\hat{\mathbf{y}}$ 表示修复后的高质量图像。图像复原技术作为计算机视觉领域的一个重要的任务，对各种视觉传感器在实际视觉领域中的应用至关重要，从而得到了广泛的关注。现有的图像复原方法可以根据是否基于数据驱动的方式进行算法设计分为两类：经典图像复原方法和基于深度学习的图像复原方法。其中，经典图像复原方法往往依赖于研究者手动设计的图像先验或数学模型，其在理论上具有较高可解释性和鲁棒性；近年来，基于深度学习的图像复原技术得到了更多的关注。该类方法通过大量数据进行端到端学习，通常可以

中国知网　https://www.cnki.net

在复杂退化条件下实现较优的复原性能，同时具备较高的算法稳定性。下面依次对这两类图像复原方法进行介绍。

（1）经典图像复原方法

基础思想。经典图像复原方法往往依赖于研究者手动设计的图像先验模型。而在求解过程中，这些方法往往利用最大后验概率 (Maximum A Posterior，MAP) 来从退化图像中恢复清晰图像。根据贝叶斯公式，后验概率分布可以表示为：

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)}, \tag{1.5}$$

其中，$P(y|x)$ 代表给定观测到的退化图像 x 条件下清晰图像 y 的后验概率，$P(x|y)$ 为似然函数，代表给定清晰图像 y 条件下观测到退化图像 x 的概率，$P(y)$ 为先验概率，代表有关清晰图像 y 的先验知识和假设，$P(x)$ 代表观测到的退化图像 x 的边缘似然。MAP 方法通过最大化后验概率 $P(y|x)$ 来预测潜在的清晰图像。由于 $P(x)$ 对于 y 来说是常数，故最大后验概率估计可以表示为：

$$\hat{y} = \arg\max_{y} P(x|y)P(y). \tag{1.6}$$

或者等价地表示为最优化问题：

$$\hat{y} = \arg\min_{y}(-\log P(x|y) - \log P(y)), \tag{1.7}$$

其中，$-\log P(x|y)$ 通常被称为数据保真项，而 $-\log P(y)$ 则被称为正则化项。数据保真项通常可以使用高斯分布进行建模，而作为经典图像复原方法核心之一的用于描述干净图像统计特性的先验 $P(y)$，则通常可以使用高斯分布，全变分 (Total Variation)，稀疏表示，以及马尔科夫随机场等进行建模。综合以上两个部分，MAP 估计可以表示为最优化问题：

$$\hat{y} = \arg\min_{y}\{\frac{1}{2\sigma^2}\|x - D(y)\|_2^2 + \lambda R(y)\}, \tag{1.8}$$

其中，σ^2 代表数据保真项在用高斯分布进行建模时的方差，D 代表退化过程，$R(y)$ 代表正则化函数，λ 代表权重系数。

相关研究。经典图像复原方法通常需要设计合理的图像先验来估计图像退化过程中的退化参数，并进一步通过求解退化过程的逆变换来重建清晰的高质量图像。例如，在图像去雾任务中，He 等人[13]在分析观察了大量户外无雾图像后，提出了暗通道 (Drak Channel Prior，DCP) 理论：在一幅无雾的清晰自然光图像中，在除了天空区域外的任意一个局部区域内，在 RGB 三个颜色通道中总会存在至少一个颜色通道中的像素值非常低，其值接近于 0。He 等人[13]利用暗通道先验为去雾任务设计了一种估计透射率 $t(x)$ 的方法，并选取暗通道图像中亮度

中国知网　https://www.cnki.net

较高的区域来估计全局大气光 A，再基于公式 1.2重建无雾的清晰图像。暗通道先验为大气散射模型中透射率 $t(x)$ 的估计提供了一种直观有效的方法，但其在面对天空等高亮区域时，暗通道先验的假设不再成立，容易导致去雾结果失真。Berman 等人[16]提出了一种非局部的图像去雾方法，他们通过统计分析发现，一幅无雾图像的颜色可以近似由几百种不同的颜色表示，而这些颜色在 RGB 空间中形成密集紧密的簇。在清晰图像中，每个颜色簇都变成 RGB 空间中的一条线，这些线被称为雾线。Berman 等人进一步利用雾线来重建无雾的清晰图像。Zhu 等人[17]提出了一种颜色衰减先验。在该理论中，雾霾的浓度与图像的亮度和饱和度之差呈正相关，即有雾区域通常表现为较高的图像亮度和较低的饱和度，而在无雾区域图像的亮度和饱和度之差通常接近于 0。基于这一先验，Zhu 等人构建了一个线性模型用于建模雾图的场景深度，并通过监督学习的方法来学习模型的参数，从而更精确地地恢复深度信息。Fattal[18]等人利用物体表面阴影和图像透射率不相关的先验假设，通过结合独立分量分析和马尔科夫建模对图像中的雾霾进行估计。然而，该方法在处理高浓度雾霾时存在一定局限性，容易导致去雾效果不理想。

除了以上介绍的常用于图像去雾领域的方法，另一类非常经典的方法便是基于 Land 于 1977 年提出 Retinex 理论[19]进行设计的。基于人类视觉系统在不同光照环境下对颜色感知的不变性，Retinex 理论假设观察到的图像可以分解为光照图和反射图，数学表示形式为:

$$S = I \odot R, \tag{1.9}$$

其中，S 代表观察到的图像，I 为光照图，代表了场景中的光照分量，R 为反射图，代表了物体表面的反射特性，$\odot$ 代表哈达玛积。Rahman 等人[20]提出使用多尺度 Retinex 对图像进行增强。该方法将图像分解为多个尺度的子图像，并对每个尺度分别进行亮度增强，通过融合多个尺度的增强结果得到最终的增强图像。Fu 等人[21]通过使用加权变分模型来估计反射图和光照图，在保留更多反射图细节的同时在一定程度上抑制噪声。Guo 等人[22]则通过 RGB 通道中的最大值来单独估计每个像素的亮度值，而后对得到的初始亮度图施加结构先验进行细化。Li 等人[23]则提出了一种鲁棒 Retinex 模型，在传统 Retinex 模型基础上额外考虑了噪声图，并提出一种利用增广拉格朗日乘子法的交替方向最小化算法。

经典图像复原方法拥有较强的模型可解释性，同时该类方法主要依赖于手动设计的先验知识和数学模型，对数据的依赖性较低。但是，经典图像复原方法中手动设计的图像先验通常基于一些对图像的假设，而这些先验可能无法充分表示出自然图像内在复杂的统计特征。同时，由于经典图像复原方法通常需要依赖于精确的图像退化模型，而真实场景下的图像退化过程往往十分复杂，而经典

中国知网　https://www.cnki.net

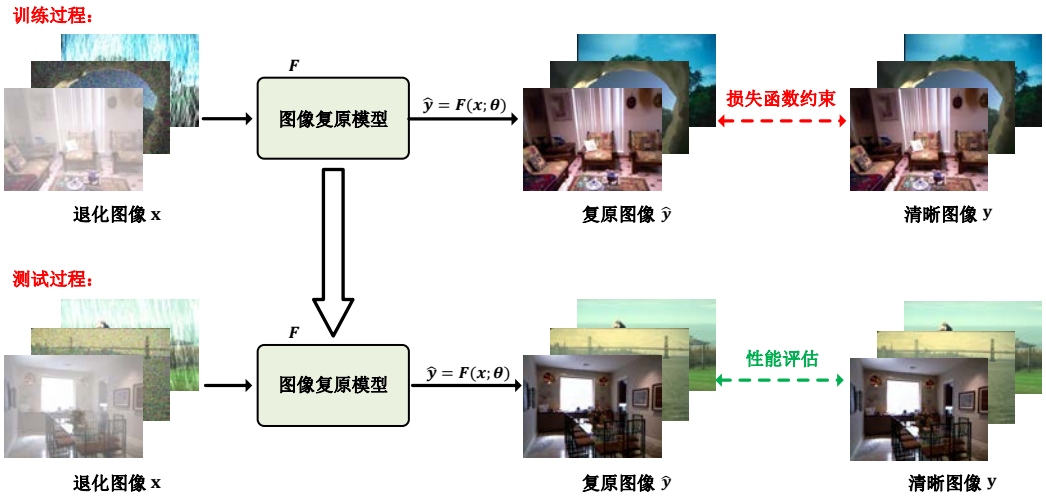


图 1.4　基于深度学习的图像复原方法流程框架

方法中的数学模型很难匹配这种复杂的退化过程，这就限制了经典图像复原方法在实际中的应用范围。

（2）基于深度学习的图像复原方法

基础思想。基于深度学习的图像复原方法通过利用大规模数据训练设计的神经网络模型，让网络自行学习从退化图像到清晰图像的映射关系。基于深度学习的图像复原方法一般采用端到端的训练方式，利用大量退化图像 x 及其对应的清晰原图像 y 来构成训练所需要的样本对，并利用参数为 θ 的神经网络 F 来学习它们之间的映射关系，这一过程可以表示为：

$$\hat{y} = F(x;\theta). \tag{1.10}$$

在训练过程中，可以通过最小化损失函数来更新模型参数 θ，该过程可以表示为：

$$\hat{\theta} = \arg\min_{\theta} \mathcal{L}(F(x;\theta), y), \tag{1.11}$$

其中，$\mathcal{L}$ 代表损失函数。训练完成之后，可以将训练好的图像复原网络应用到测试集上，评估图像复原网络的性能。图 1.4展示了基于深度学习图像复原方法的训练和测试流程。

相关研究。随着人工智能技术的发展，基于深度学习的图像复原算法逐渐成为主流。相比于经典图像复原算法，基于深度学习的图像复原算法利用神经网络从大量数据中自动学习和提取图像的特征，避免了研究者手动设计图像先验。这使得神经网络能够捕捉复杂多样的图像统计特性，显著提高了算法对现实世界中复杂场景退化的适应性。同时，基于深度学习的图像复原算法拥有更强大的非线性建模能力和更高的计算效率，使其在图像复原领域往往能取得比经典算法更高的恢复质量和更强的实用性。下面本文从不同角度梳理基于深度学习的图像复原算法的发展。

中国知网　https://www.cnki.net

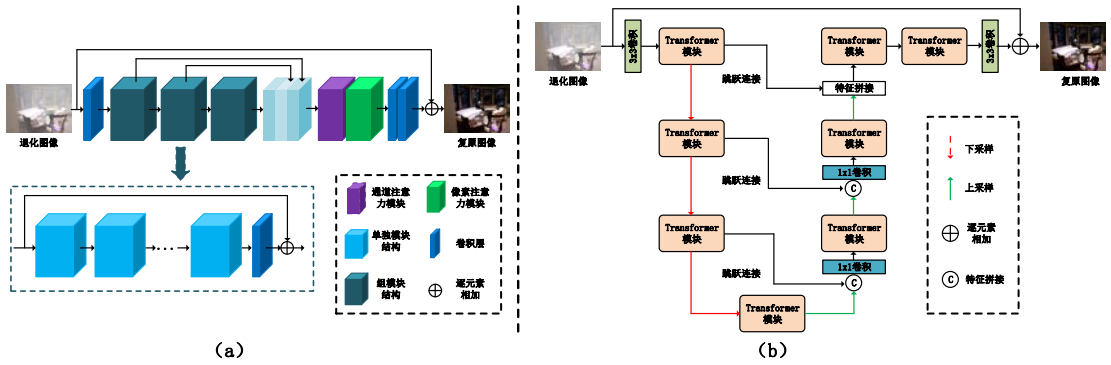


图 1.5　基于卷积神经网络和 Transformer 的图像复原方法，（a）来自于文献[7]，（b）来自于文献[15]

从模型结构层面，卷积神经网络（Convolution Neural Network，CNN）成为了使用最为广泛的网络模型架构之一，如图 1.5（a）所示。Dong 等人[14]首先尝试将卷积神经网络引入到图像复原领域中，通过堆叠少量的卷积层和非线性变换，从而实现低分辨率图像到高分辨率图像的端到端学习。Zhang 等人[24]同样尝试在图像去噪任务中使用卷积神经网络，该方法通过使用多层卷积神经网络配合归一化和非线性激活函数来学习噪声图像与清晰图像之间的残差。Lim 等人[10]则构建更深卷积神经网络并引入残差链接机制，增强模型的表征能力，同时移除归一化操作，避免其对图像原有信息的破坏。Ronneberger 等人[25]提出的 U-Net 也为图像复原任务的模型结构设计提供了重要参考。U-Net 的架构最初被用于图像分割，但其对称的编码器-解码器的结构设计使得模型可以有效融合多尺度信息，并通过跳跃链接将浅层特征传到深层，有助于细节信息的恢复。在此基础上，Zamir 等人[26]利用编码器-解码器的架构学习多尺度信息，通过设计了一个多阶段渐进式的训练策略来逐步提升复原图像的质量，并在多个图像复原任务上取得了很好的效果。Zhang 等人[27]也将注意力机制引入到模型设计中，通过在通道维度使用注意力机制，使得网络可以自适应地突出对图像复原较为关键的通道特征，有效提升了网络的表征能力。随着 Transformer[28]架构在计算机视觉领域的成功，许多研究工作也开始尝试将 Transformer 引入到图像复原任务中，如图 1.5（b）所示。例如，Chen 等人[29]基于 Transformer 开发出一种新的预训练模型，通过设计多头多尾的方式来分别处理不同的图像复原任务的输入输出，并使用同一个 Transformer 网络作为主干网络来复原图像。Wang 等人[30]则提出在非重叠的窗口中执行局部自注意力而不是执行全局自注意力，有效降低了高分辨率特征图上计算的复杂度，同时在前馈网络中引入卷积层以搞好地捕捉局部细节信息。Zamir 等人[15]通过多头转置注意力模块来建模全局信息，有效地降低了模型的计算复杂度，同时引入门控机制控制特征流动。

从具体任务层面，由于退化类型繁多，图像复原技术也相应地衍生多个子任务，如图像超分辨[10,27,31-35]、图像去噪[9,36-42]、图像去雾[13,16,18,43-51]、图像

中国知网　https://www.cnki.net

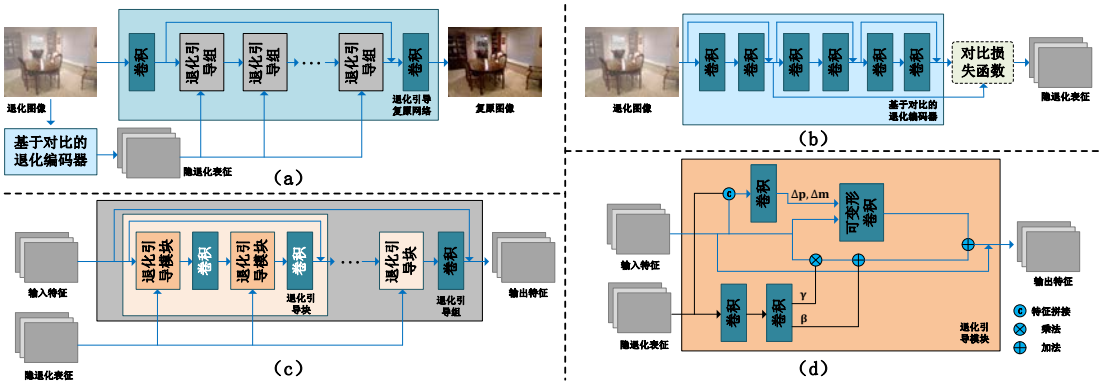


图 1.6　针对多类型退化的图像复原方法，图片源自文献[71]

去雨[52-61]以及图像去模糊[11,62-69]等。这些子任务通常会结合具体退化类型的特性，设计针对性的图像复原方法。然而，此类方法往往只针对某一特定退化时较为有效，却难以无法泛化到其他类型的退化场景中。也有一些研究工作尝试构建一个网络来涵盖多种类型退化的恢复。例如，Zamir 等人[26]等人利用卷积神经网络搭建图像复原模型并设计多阶段框架，使得该模型可以应用于多种图像复原任务。尽管如此，在实际使用时，这些网络往往仍然需要针对不同退化单独训练相应的模型，无法实现使用单个模型同时处理多种退化类型。这类一次仅能处理一种退化类型的图像复原方法在本文中统称为针对单一退化的图像复原方法。由于该类方法一次只能处理一种退化类型，这极大地限制了这些方法在多样化实际场景中的应用。在实际场景中，退化的类型是多种多样的。而如果单独针对每一种退化都设计训练相应的模型，将极大地提升模型的训练开销与实际部署的成本。因此，针对多类型退化的图像复原方法成为了热门的研究方向。该方法旨在使用一个模型同时处理多种类型的退化，以提升图像复原技术在实际应用中的实用性，如图 1.6所示。如 Li 等人[70]提出使用一个模型来同时处理多种天气退化。Chen 等人[29]通过设计多头、多尾和一个基模型的方式实现多种退化的复原。Li 等人[71]利用对比学习的方式在隐空间中区分不同类型的退化。Valanarasu[72]则使用 Transformer 架构来处理多种天气带来的图像退化。相比于针对单一退化的图像复原方法，该类针对多类型退化的图像复原方法在实际使用中有更好的灵活性。

从训练框架层面，基于重建式的端到端训练是图像复原方法的主流范式。例如，均方误差 (Mean Squared Error，MSE) 就常被用作损失函数来约束图像复原模型的训练[14,24]：

$$\mathcal{L}_{MSE} = \frac{1}{n}\|F(x;\theta) - y\|_2^2, \tag{1.12}$$

其中，F 代表图像复原网络，θ 代表网络参数，x 代表退化图像，y 代表清晰图像，n 代表图像中像素总个数。随着生成模型的出现发展，许多研究方法开始

中国知网　https://www.cnki.net

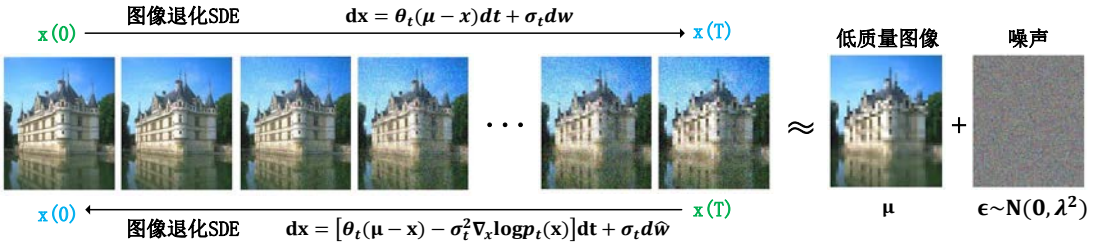


图 1.7　基于扩散模型的图像复原方法，图片源自文献[75]

尝试基于生成对抗网络 (Generative Adversarial Network，GAN)[73] 探索新的图像复原范式。例如，Kupyn 等人[11]将生成对抗网络引入去模糊任务中，训练生成器学习模糊图像到清晰图像之间的映射，并利用判别器判断输入图像是真实图像还是生成器去模糊后的复原图像，该方法显著提升了去模糊的效果。Ledig 等人[31]尝试在图像超分辨中引入生成对抗网络，利用生成对抗的训练方式使得超分后图像保留更多的高频细节，在实现较高倍率超分的同时拥有较好的视觉观感。Wang 等人[74]进一步引入残差密集连接并移除归一化操作，同时引入感知损失函数（Perceptual Loss）来约束网络的训练，显著提升了图像超分辨的效果。

近年来，基于扩散模型的图像复原方法探索也成为了热门的研究方向。扩散模型 (Diffusion Models，DM)[4,76] 作为一种新兴的生成范式，已经在图像生成[77-78]以及视频生成[79-80]等领域取得了巨大成功。以去噪扩散概率模型 (Denoising Diffusion Probabilistic Models，DDPM)[4]为例，其通过逐步向真实数据中加入噪声，并训练一个去噪网络用于逆向过程中的逐步去噪，从而学习和重构数据的潜在分布。基于扩散模型的图像复原方法可以大体分为两类。第一类方法通过将退化图像或者退化过程作为条件引入到扩散模型中，通过端到端重新训练一个扩散模型来实现图像复原，如图 1.7。例如，Saharia 等人[81]通过将低分辨率图像作为条件，引导扩散过程中去噪网络的去噪过程，通过逐步细化的方式生成高分辨率的图像，该方法可以实现较高倍率的超分。Yue 等人[82]对原始的扩散模型范式进行修改，利用马尔科夫过程建模高分辨率图像和低分辨率图像之间的残差，降低了逆向过程所需要的采样步骤，显著地提升了采样效率。Luo 等人[75]提出了一种基于随机微分方程的通用的图像复原方法，其通过构建均值回归的随机微分方程，将高质量图像转换为具有固定高斯噪声的退化图像，并通过进一步模拟相应的逆向随机微分方程重建出高质量图像。该类方法通常可以取得较好的图像复原效果。然而，由于该类方法需要从头重新训练扩散模型，其往往需要大量的计算资源和时间。第二类方法则是利用已经预训练好的扩散模型，通过利用退化过程来约束其逆向采样过程，从而恢复出高质量图像。例如，Chung 等人[83]提出了一种扩散后验采样，通过将扩散模型的采样过程以及退化模型相结合，有效地解决了非线性逆问题。Milanfar 等人[84]提出了一种提示器

中国知网　https://www.cnki.net

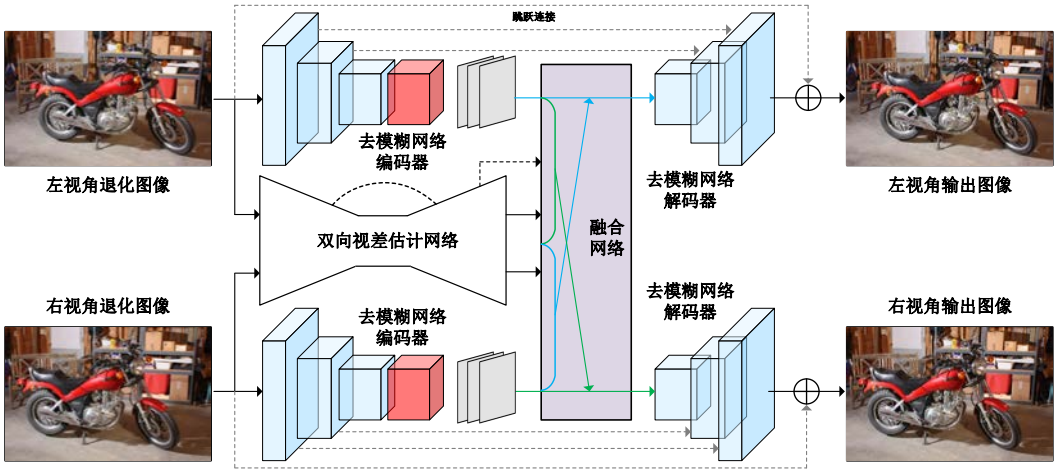


图 1.8　多视角图像复原方法，图片源自文献[85]

调整的方法，该方法使用文本-图像扩散模型作为先验，通过在扩散逆向过程中优化文本提示嵌入的方式使得生成的图像更加符合扩散先验，显著提升了图像复原的效果。该类方法虽然避免了重新训练扩散模型，然而，冗长耗时的逆向采样以及对精准退化模型的需求限制了它们在实际场景中的应用。

随着计算机视觉技术的快速发展，多视角成像系统获得了越来越多的关注。多视角成像系统通过多个摄像头从不同视角对同一场景进行拍摄，为各类视觉任务提供了丰富且互补的信息，并在实际场景中获得了广泛的应用。例如，在自动驾驶领域，多视角成像系统提供了全方位的环境感知能力，同时为精准的深度估计和障碍物定位提供支持，有助于提升自动驾驶系统的安全性和决策可靠性；在增强现实（Augmented Reality，AR）和虚拟现实（Virtual Reality，VR）领域，多视角成像系统为空间映射和实时交互提供了基础，可以有效提升场景的真实感与沉浸感。因此，多视角图像复原技术成为了热门的研究方向。与单张图像复原任务相比，多视角图像复原任务可以通过探索和融合不同视角图像间的信息，来实现各视角间图像的协同复原，如图 1.8所示。例如，Wang 等人[86]提出了视差注意力模块，在极线约束的条件下探索和捕捉不同视角图像之间的对应关系，从而实现了多视角图像间的信息交互与协同复原。Zhang 等人[87]通过融合多视角空间信息并结合语义信息，以实现多视角场景下的图像去雨。Wang 等人[88]利用可变形卷积来处理多视角成像系统中的视差问题，从而提升了多视角图像超分辨率任务的性能。Zhou 等人[85]通过估计视差来对齐不同视角图像的特征，并设计一个可学习的门控网络进行特征融合，从而实现多视角图像去模糊。

1.2.2　面向视觉识别任务的图像复原技术

面向视觉识别任务的图像复原技术是指在图像复原过程中，不仅要求提升图像的视觉质量，同时还要满足针对下游语义驱动的视觉识别任务（如图像分

中国知网　https://www.cnki.net

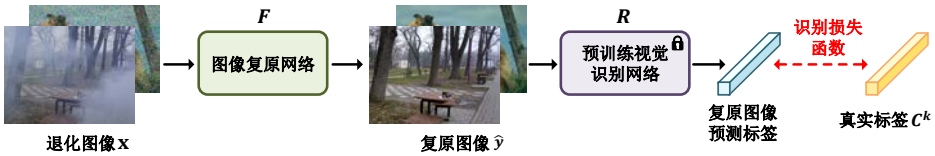


图 1.9　面向视觉识别任务的图像复原训练流程

类、目标检测等）的需求。与追求提升视觉效果的传统图像复原技术不同，面向视觉识别任务的图像复原技术在去除退化信息和修复纹理细节的同时，更加侧重于恢复和增强图像中的内在语义信息，以提升复原图像在下游视觉识别任务中的准确率和泛化性。

基础思想。面向视觉识别任务的图像复原技术追求对下游语义驱动的视觉识别任务的适配性。与传统图像复原技术不同，面向视觉识别任务的图像复原技术旨在训练一个参数为 θ 的图像复原网络 F，在给定一张退化图像 x 的条件下，使用带有类别标签 C^k 的下游高层视觉识别网络 R 评估网络复原结果 $F(x;\theta)$ 时，复原图像能够有较高的识别性能，这一过程可以表示为：

$$\hat{\theta} = \arg\min_{\theta} \mathcal{L}_{recog}(R(F(x;\theta)), C^k), \tag{1.13}$$

其中，$\mathcal{L}_{recog}$ 代表高层视觉识别网络 R 的识别损失函数。具体训练过程如图 1.9所示。在实际应用场景中，很多时候类别标签 C^k 是不可获得的。在这种情况下，网络的优化目标可以修改为约束复原图像 $F(x;\theta)$ 和对应清晰图像 y 在识别网络 R 中输出表征的一致性，这一过程可以表示为：

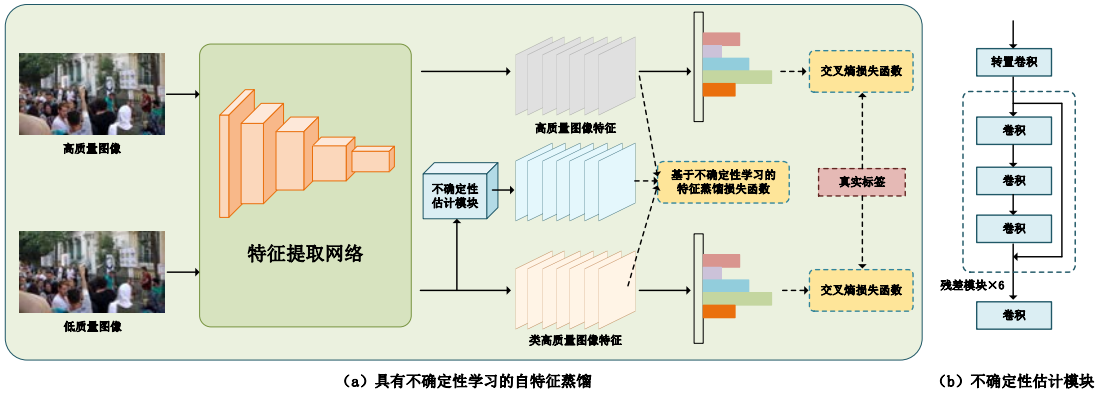
$$\hat{\theta} = \arg\min_{\theta} \mathcal{L}_{dis}(R(F(x;\theta)), R(y)), \tag{1.14}$$

其中，$\mathcal{L}_{dis}$ 代表识别网络 R 的两个输出之间的距离衡量方式。

相关研究。随着计算视觉技术的快速发展，如图像分类、目标检测以及图像分割等高层视觉识别技术已经得到了广泛的应用。现有的大多相关研究都是在输入图像是清晰高质量图像的理想条件下展开的。然而，通过在高质量图像上训练出的识别网络对遭受退化的低质量图像并不具有鲁棒性。在实际应用中，由于传感器缺陷或者环境干扰等因素的影响，传感器采集到的图像往往会出现质量的退化，而这也会进一步影响这些视觉识别系统的可靠性。因此，研究如何在退化环境中提升视觉识别系统的性能成为了当前计算视觉领域的重要研究方向之一。针对这一问题，目前主流的方法可以分为两大类：基于特征学习的方法和基于图像复原的方法。下面依次对这两种方法进行介绍。

基于特征学习的方法，其核心思想在于约束视觉识别网络学习退化不敏感的特征表示，使得识别网络可以自适应地从退化输入中提取关键语义信息。该类方法通常使用退化图像与高质量图像训练识别网络，通过对网络结构和训练方

中国知网　https://www.cnki.net



（a）具有不确定性学习的自特征蒸馏　　（b）不确定性估计模块

图 1.10　基于特征学习的方法，图片源自文献[89]

式进行设计，引导识别网络在退化输入条件下准确提取任务相关的关键语义特征同时抑制环境退化信息的干扰，如图 1.10所示。例如，Wang 等人[90]设计了一个特征去漂移模块，该模块学习低质量图像和高质量图像在分类网络浅层特征空间中的映射关系，并将其作为深度退化先验以提升低质量图像在现有分类网络中的准确率。Kim 等人[91]设计了一个两阶段的训练过程，该方法在第一阶段利用高质量图像预训练了一个可逆分类器，并在第二阶段将可逆分类器转换为解码器以监督目标分类器的训练，从而约束目标分类器学习退化不敏感的特征。Yang 等人[89]提出了一种具有不确定性建模的自特征蒸馏方法，该方法使用高质量图像的识别特征来蒸馏对应的退化图像特征，并根据退化源的多样性进行不确定性建模，从而更好从低质量退化特征中得到高质量特征以用于识别任务。Lee 等人[92]针对雾条件下的图像语义分割提出了一个雾通滤波模块，该方法将图像的有雾条件视作一种风格，通过交替优化雾通滤波模块和语义分割模型，逐渐缩小不同雾条件之间的风格差异，从而约束分割模型学习雾不变特征。基于特征学习的方法直接约束视觉识别网络从退化图像中学习关键语义特征，避免了先修复再识别的两阶段处理流程。但是，该类方法通常需要特定任务的识别模型以及具有语义标签的数据进行训练，而这两者在现实应用中往往是不可获得的，这极大地限制了该类方法在真实场景中的可推广性。

基于图像复原的方法则遵循了“先修复，再识别”的两阶段处理范式。该类方法通过设计专门的图像复原算法对遭受退化的低质量图像进行增强，而后将增强结果输入到后续的视觉识别系统中以提升性能，如图 1.11。与传统的图像复原方法相比，该类方法更侧重于增强图像的内在语义信息，以使其更有效地适配于下游的高层视觉识别任务。例如，Liu 等人[93]设计了一个图像去噪网络，并将其与已经预训练好的视觉识别模型进行级联，而后利用重建损失函数和识别损失函数对去噪网络进行联合优化，在提升网络去噪效果的同时增强了复原图像在各种高层视觉识别任务的准确性。Sharma 等人[94]探索了针对图像分类任务的图像增强方法，该方法使用卷积神经网络来模拟一系列增强过滤器，对图像中的

中国知网　https://www.cnki.net

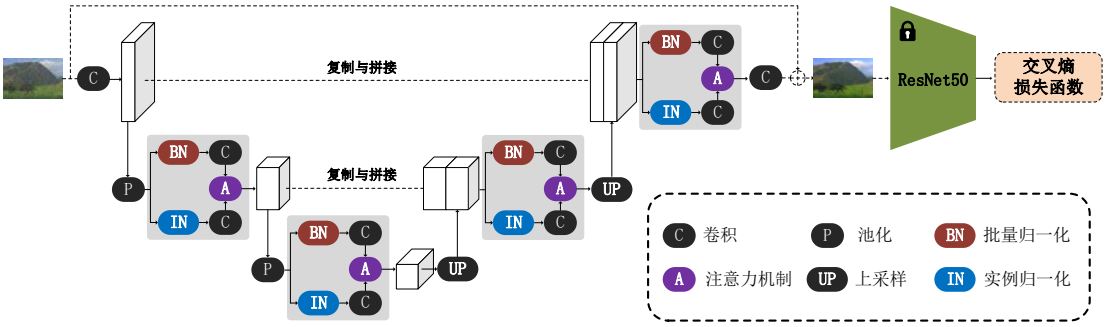


图 1.11　面向视觉识别任务的图像复原方法框架，图片源自文献[95]

特定细节进行学习增强，从而提升其在分类网络中的准确率。Son 等人[95]针对视觉识别任务提出了一个通用且统一的图像增强框架，该方法使用正则化和注意力机制赋予图像复原网络处理不同退化的能力，同时将复原网络与预训练的图像分类器级联，通过优化分类器的损失函数来训练复原网络，使得网络能够适配于下游不同的视觉识别任务。Wang 等人[96]针对暗光环境下的图像识别任务提出了一种非对称跨域自监督训练策略，该策略通过预训练代理任务的方式为暗光增强网络提供语义优化指导，从而使得暗光增强的图像能有效地适配于下游各种视觉识别任务。尽管基于图像复原的方法采用了两阶段的处理范式，即先修复图像再将复原图像输入识别系统，但考虑到图像复原模型的参数量往往相对较小，其相比于基于特征学习的方法具有更低的训练成本，同时也摆脱对特定任务识别模型和语义标签的强依赖。此外，利用图像复原方法复原出的清晰图像也可以同时应用于多种下游视觉识别任务，进一步增强了其在真实场景中的通用性和可扩展性。

1.2.3　图像复原领域存在的问题

综上所述，图像复原技术设计的复原方法和实际应用非常广泛，随着计算机技术的发展，新技术和新研究也层出不穷。但与此同时，图像复原技术也面临诸多问题和挑战，如图 1.12所示。例如，在一些退化场景中仍然无法全面彻底地去除退化信息、图像中细节纹理恢复不足以及无法有效适配于下游视觉识别任务等问题。为了更全面地促进图像复原技术的发展，本文将对图像复原领域仍然存在的问题进行总结，并在接下来的几章中去解决。

（1）图像复原过程中信息表征建模能力不足的问题。目前主流的图像复原方法采用端到端的训练方式，直接利用深度神经网络学习从退化图像到清晰图像之间的映射。这种训练方法通常使用单一网络捕捉和处理图像的全部信息，难以针对图像复原过程中的关键特征进行精细化建模。同时，这种训练方式对图像中内容信息和退化信息进行混合处理，缺乏对这两类信息的区分性表征。这导致图像复原网络难以彻底去除图像中复杂的退化成分，并且无法充分恢复图像的精

中国知网　https://www.cnki.net

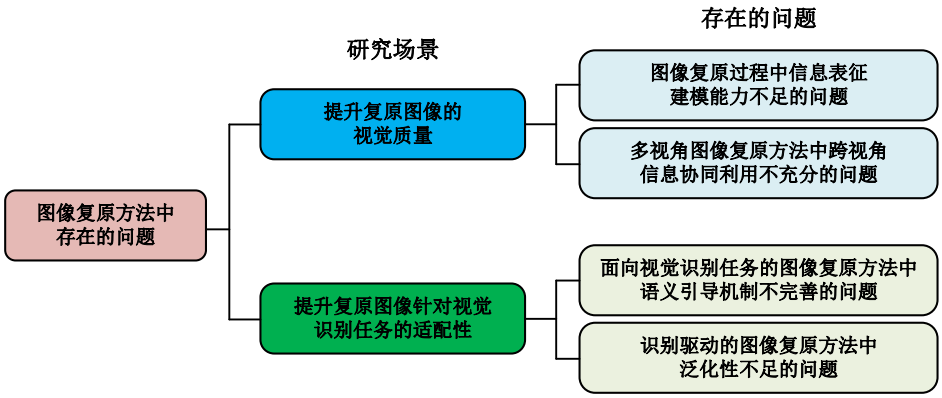


图 1.12　图像复原技术存在的问题和挑战

细纹理和细节内容，影响复原图像的最终质量。

（2）多视角图像复原中跨视角信息协同利用不充分的问题。随着成像系统的快速发展，多视角拍摄系统变得越来越普遍。因此，多视角图像复原技术变得越来越有应用价值，本文以双目图像复原任务为例进行探索。传统的单目图像复原方法往往将多视角的图像单独处理或进行简单的融合，未能充分探索多视角之间的对应关系。而现有的双目图像复原方法难以有效建模左右视角图像间的全局关联性，导致无法充分利用跨视角信息进行互补增强。同时，现有的双目信息融合方式过于粗糙，难以捕捉左右视角间的精细对应关系和信息互补特性。

（3）面向视觉识别任务的图像复原方法中语义引导机制不完善的问题。随着计算机视觉的快速发展，图像复原方法不仅需要关注视觉质量的提升，还需要考虑语义的恢复以提升对下游视觉识别任务的适配性。但是现有识别驱动的图像复原方法的语义引导机制存在明显不足。在许多识别驱动的图像复原方法中，语义信息的引入通常离不开对图像的语义标注。而这种对语义标签的依赖导致对数据标注的需要激增，人工成本和时间开销也随之显著提高。另外，在许多实际场景下，考虑到不同识别任务对语义标签需求的差异性等客观问题，获取丰富而准确的语义标签有时并不现实。而在无标签的条件下，现有的语义引导机制效率不高，这尤其体现在损失函数和训练策略的设计上。以损失函数为例，现有的语义损失函数大多基于像素级约束计算，这种计算方式对于语义信息的高层次约束不足，导致复原图像中语义信息无法得到有效的恢复。

（4）识别驱动的图像复原方法中泛化性不足的问题。现有的识别驱动的图像复原方法，无论是否需要语义标签，大多都需要依赖某一特定的预训练识别模型提供语义监督。而这导致训练出的图像复原网络容易过拟合到选定识别系统的模式上，进而导致其对下游未见过的识别系统泛化能力受限。另一方面，在训练过程中，网络会同时受到视觉质量和语义质量两个不同层级优化目标的约束。这两个损失函数的优化方向可能存在潜在的冲突，但是现在缺乏有效的协调机制来缓解这种冲突，这给图像复原网络的优化带来了困难。

中国知网　https://www.cnki.net

1.3　本文研究内容和创新点

本文针对基于深度学习的图像复原方法展开研究，遵循着从视觉质量导向到识别任务导向的递进宏观思路逐层深入研究，并在图 1.13展示了研究内容之间的逻辑关系。具体而言，在视觉质量导向的研究中，本文首先探究了经典的单张图像复原方法，并创新性地引入了预训练扩散模型中的先验知识来引导图像复原过程。随后，本文将研究维度拓展至多视角场景，并以双目场景为例探索了双目图像复原的方法。相比于单目图像，双目图像同时提供了左右两个视角的信息，提升了图像复原的复杂性，并对跨视角信息协同探索的方式提出了要求。这一阶段的研究构成了从传统单图复原到多视角信息探索的递进关系。接下来，在识别任务导向的研究中，本文首先针对传统图像复原方法对语义信息恢复效果不佳的问题进行改进，并针对性的设计了语义增强模块和对应的训练策略，实现了从视觉质量恢复到语义质量恢复的目标转换。之后，本文进一步在更高维度探索视觉质量和语义质量约束在优化空间中的关系，并提出了一个通用的训练框架，可以无缝套用到现有的图像复原网络中，实现从特定网络设计到通用训练框架的跃升。本文具体的研究内容和主要创新点如下：

（1）提出基于扩散模型先验信息的图像复原方法，针对现有的图像复原方法信息表征建模能力不足的问题。本文首先对扩散模型在图像复原领域的潜力进行讨论，并分析了现有基于扩散模型图像复原方法存在的问题。而后，本文探索了预训练扩散模型中的先验信息，并揭示了其语义隐空间特征在不同时间步时对于退化图像中不同信息表征的能力。基于此发现，本文针对性的设计了一个图像复原网络，并将扩散模型中带有特定信息的表征注入该网络作为指导，增强网络对不同信息的建模和处理能力，使其更有效地去除退化成分并恢复纹理细节。在多个不同的图像复原方法和数据集上的实验表明，所提算法能够显著提升图像复原的效果，并在定量和定性结果中都优于现有的图像复原方法。

（2）提出基于多视角空间关系探索的图像复原方法，针对现有多视角图像复原方法中跨视角信息协同利用不充分的问题。本文以双目图像复原为例，利用 Transformer 强大的捕获长距离空间依赖关系的能力，结合双目图像的水平极线约束，对双目视角间关联性的建模方式进行探索。本文采取由粗到细的方式对双目图像之间的信息进行交互，首先从全局视角捕获长距离对应关系，而后在局部邻域内提取细粒度特征以实现精准融合。在多个双目图像复原任务和双目公开数据集上的实验表明，所提方法在建模双目视角关联性以及双目图像复原性能上相比于现有方法具有更强的优势。

（3）提出面向视觉识别任务的多退化统一图像复原方法，针对现有的识别驱动图像复原方法中语义引导机制不完善的问题。本文从实际应用的角度出发，考

中国知网　https://www.cnki.net

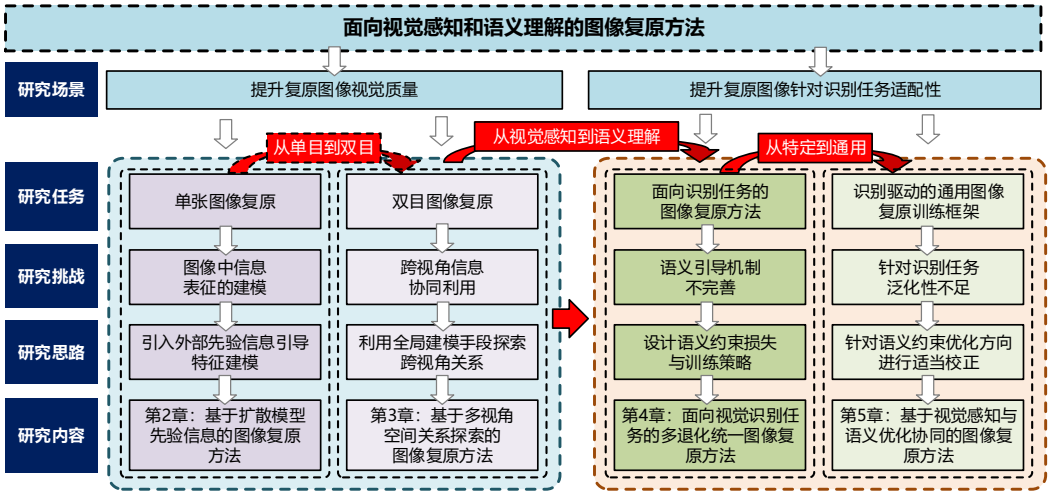


图 1.13　本文研究内容关系概览图

虑到不同退化类型在语义层面造成的不同影响，针对性地设计了一个内在语义模块，根据输入退化特征的统计分布，以动态的方式对其进行调制增强。同时，本文进一步提出了先验赋予优化策略以更高效地引导语义的恢复，首先赋予模型感知清晰图像语义与退化图像语义的能力，进而引导模型向着清晰图像的语义方向优化增强输入的退化特征，从而实现了从语义理解的角度对图像进行修复。本文提出的方法不但可以同时处理多种不同的退化，并且能够直接作为图像预处理器插入到现有的识别系统中。在多种退化类型和多个识别任务上的实验结果表明，所提方法能够有效提升复原图像在下游视觉识别系统中的适配性。

（4）提出基于视觉感知与语义优化协同的图像复原方法，针对现有识别驱动图像复原方法中泛化性不足的问题。本文从损失函数的角度出发，利用视觉重建约束与语义恢复约束共同训练图像复原网络，并在优化空间中探索两者的关系，提出了一种动态梯度校正策略，在提升图像复原网络针对下游未见过识别系统泛化性的同时，缓解两种约束在优化空间中潜在的冲突。同时，本文进一步探究了语义约束的计算方式，通过挖掘高层语义的统计特性并匹配图像间语义相似度分布来引导图像复原网络更准确地恢复图像的内在语义。此外，本文还提出了一种清晰图像增强策略，通过对清晰图像进行适当扰动来增强图像复原网络恢复语义的鲁棒性。本文提出的训练框架可以无缝套用到现有的图像复原网络中，具有较强的通用性。实验结果证明，相比于传统的训练范式，所提的训练范式可以显著提升图像复原网络针对下游视觉识别任务的适配性和泛化性。

1.4　本文组织结构

本文分为六章，从视觉感知和语义理解两个角度出发，对图像复原中存在的问题展开深入研究，论文结构如图 1.14所示。

中国知网　https://www.cnki.net

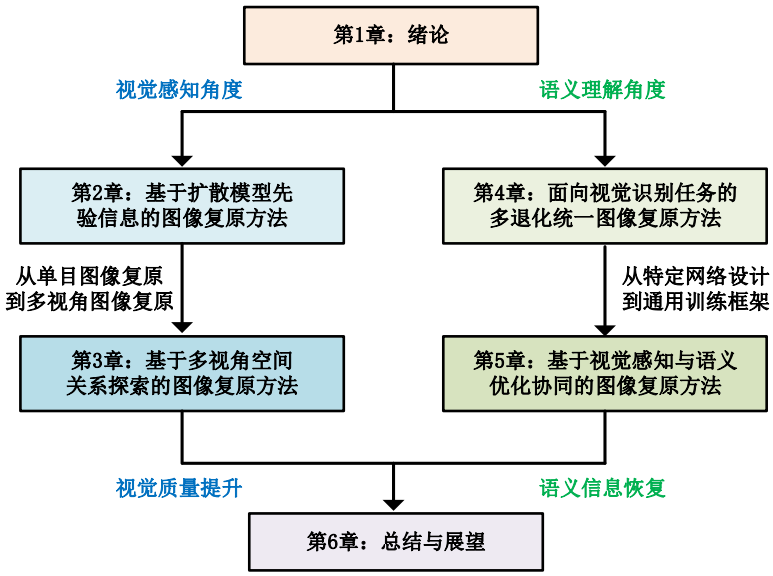


图 1.14　本文的组织结构

第 1 章是绪论部分。本章首先介绍了图像复原技术的研究背景及意义，并对国内外研究现状进行梳理。随后，总结了图像复原领域发展中仍然面临的一些问题。最后，对本文的主要研究内容和组织框架进行系统性介绍。

第 2 章是基于扩散模型先验信息的图像复原方法。本章首先介绍了扩散模型在图像复原领域中的应用，并分析了现有基于扩散模型的图像复原方法的问题。随后，介绍了对扩散模型先验信息的探索方式，并详细阐述了扩散模型语义隐空间特征在不同时间步下对于退化图像中不同信息的表征能力。接着，介绍了所提的基于扩散模型隐空间特征引导的图像复原网络，以及该网络如何利用扩散模型的先验信息作为指导来帮助图像复原过程。最后，通过实验，验证了所提方法在图像复原上的优异性能。

第 3 章是基于多视角空间关系探索的图像复原方法。本章首先介绍了双目成像系统的应用价值，并分析了现有双目图像复原方法仍然存在的问题。随后，介绍了所提的基于 Transformer 架构的双目图像复原网络及各部分设计细节，包括用于视角对齐的双目对齐模块以及用于信息融合的双目融合模块。接着，介绍了用于约束双目信息对齐的损失函数计算方式。最后，通过实验，验证了所提方法在双目图像复原任务上的可靠性。

第 4 章是面向视觉识别任务的多退化统一图像复原方法。本章首先介绍了传统图像复原方法在下游高层视觉识别系统中的适配性问题，并分析了现有解决方法仍然存在的挑战。随后，介绍了所提的面向视觉识别任务的多退化统一图像复原方法，引入了恢复语义信息的的内在语义增强模块，并介绍了先验赋予优化策略。最后，通过实验，验证了所提方法在下游视觉识别任务上的有效性。

第 5 章是基于视觉感知与语义优化协同的图像复原方法。本章首先介绍了

中国知网　https://www.cnki.net

现有识别驱动的图像复原方法在下游识别任务中泛化性差的问题，并分析了此问题出现的原因。随后，介绍了所提的动态梯度校正策略、内在语义一致性约束以及清晰图像增强策略三个核心设计的具体实现。这三个核心设计相互作用，从不同的角度提升图像复原网络针对下游识别任务的适配性和泛化性。最后，通过实验，验证了所提方法的有效性。

第 6 章是对全文的总结与展望。首先总结本文的主要研究内容和创新点，而后对图像复原技术的未来发展方向和趋势进行展望。

中国知网　https://www.cnki.net

第 2 章　基于扩散模型先验信息的图像复原方法

2.1　引言

图像复原技术旨在对遭受退化的低质量图像进行修复，从而得到内容清晰自然，细节纹理丰富的高质量图像。由于对于给定低质量退化图像存在无限多种可能的高质量图像解，导致图像复原问题为不适定问题且极具挑战性。传统的图像复原方法利用研究者手动设计的图像先验来估计清晰图像[13]。随着深度学习技术的发展，基于卷积神经网络和 Transformer 架构的方法在图像复原领域取得了显著成功[15,30,49,97]。然而，当前主流方法普遍采用的是端到端的训练范式，通过图像复原网络直接学习退化图像到清晰图像之间的映射关系。这种训练方式依赖单一网络学习和处理图像中的全部信息，增加了对关键特征建模的难度。

近年来，扩散模型（Diffusion Models）[4,76]作为一个新兴的生成范式，在图像生成领域展现出卓越的性能，并在如图像编辑[98-99]和个性化定制[100-102]等任务中取得了巨大成功。同时，扩散模型的出现也极大地拓展了图像复原任务的可能性，为解决图像复原方法中存在的信息表征建模能力不足问题提供了新的思路。目前，将扩散模型应用于图像复原的主流方法可以分为两种范式。第一种方法是从头开始重新训练一个基于特定退化条件的扩散模型[75,82]。这些方法通常将退化图像作为条件，并将其与噪声图像拼接，而后在扩散模型的逆向过程中隐式地引导扩散模型预测对应的高质量图像。这类方法往往能够取得较为优异的图像复原效果。然而，此类范式需要对整个扩散模型进行重新训练，而这一过程通常需要耗费大量的时间和计算资源。第二种方法则是利用已经预训练好的扩散模型，通过退化模型来约束其逆向采样过程，从而引导扩散模型输出高质量图像[83-84]。该类方法避免了对扩散模型的重新训练。然而，冗长的逆向采样过程以及对精准退化模型的需求都极大限制了该类方法在实际场景中的应用。

为了解决上述问题，本章尝试从从一个全新的视角探索扩散模型在图像复原任务中的潜力：**是否可以直接利用预训练扩散模型中蕴含的丰富知识来帮助图像复原过程，从而避免从头训练扩散模型或者冗长的逆向采样过程？**现有许多公开的扩散模型已经在大规模高质量数据集上进行了预训练，其模型中已经包含了丰富的视觉先验信息。如果能够以一种高效的方式将这些先验信息提取出来并将其整合到图像复原过程中，将进一步提升图像复原的效果。为此，本章重点研究预训练扩散模型的语义隐空间，并探索退化图像在该空间中的特性。已经有研究表明[103-105]，预训练扩散模型的语义隐空间特征在高层语义编辑方面表现出良好的性质。受此启发，本章旨在探索扩散模型语义隐空间是否同样具备满足低层图像复原所需的特性。具体而言，本章通过实验发现，随着扩散时间步长

中国知网　https://www.cnki.net

的变化，退化图像在语义隐空间中的表征也呈现渐进式变化：由最初主要编码图像的底层内容，逐渐演变为越来越多地捕捉图像的退化特性。

基于以上观察，本章进一步提出了一个全新的框架——基于扩散模型隐空间特征引导的图像复原网络，旨在利用扩散模型语义隐空间表征来实现高效的图像复原。本章提出的复原网络采用类似 U-Net[25] 的分层结构，使得网络能够学习多尺度特征从而提升图像复原的效果[15,30,106]。具体而言，为了增强对退化图像的底层内容恢复能力，本章设计了一个内容融合模块。该模块通过利用从语义隐空间中提取到的内容表征，辅助图像复原模型恢复图像的底层内容。此外，为了更有效地去除退化图像的退化成分，本章进一步提出了一个退化感知增强模块。该模块利用从语义隐空间中获得的退化表征作为引导，使得图像复原模型能够更精确地去除低质量图像中的退化信息。值得注意的是，与现有的基于扩散模型的图像复原方法[106-107]相比，本章提出的图像复原模型无需重新训练任何扩散模型，并且避免了冗长耗时的逆向采样过程。因此，本章提出的方法在保证图像复原效果的同时，显著降低了计算资源和时间的消耗，提高了图像复原的效率。

本章所提出的主要内容和贡献可以总结如下：（1）开创性地提出了一个基于扩散模型的图像复原新范式，通过利用预训练扩散模型隐空间中的高信息量的表征，引导图像复原网络高效地进行图像复原。（2）设计了探索扩散模型隐空间的方法，并揭示了退化图像隐空间表征的转换过程：随着扩散时间步的变化，退化图像的隐空间表征从主要编码图像内容逐渐转变为捕获图像退化特征。（3）基于扩散模型语义隐空间的特性，提出了内容融合模块和退化感知增强模块，分别利用从扩散模型语义隐空间中提取的特征来帮助图像复原网络完成图像内容的恢复和退化的去除。（4）在多个公开数据集的定性和定量实验证明了本章方法的优越性。此外，本章提出的方法避免了重新训练扩散模型以及冗长耗时的逆向采样，因此在计算资源消耗方面更加的高效。

本章的后续安排如下： 2.2节对扩散模型的基础概念进行介绍，以期对扩散模型的运作机理有初步了解； 2.3节以图像去雾为例，详细介绍了探索预训练扩散模型语义隐空间特性的方法，以及基于观察到现象设计的基于扩散模型隐空间特征引导的图像复原网络，包括内容融合模块和退化感知增强模块的具体实现。 2.4节在多个任务和公开数据集上验证了所提方法的有效性，并与现有的图像复原方法进行定量和定性的比较；最后， 2.5节对本章所提出的方法进行总结。

2.2　扩散模型原理

本节以去噪扩散概率模型（Denoising Diffusion Probabilistic Models, DDPM）[4] 为例，说明扩散模型的运作机理。去噪扩散概率模型的核心思想对数据逐步添

中国知网　https://www.cnki.net

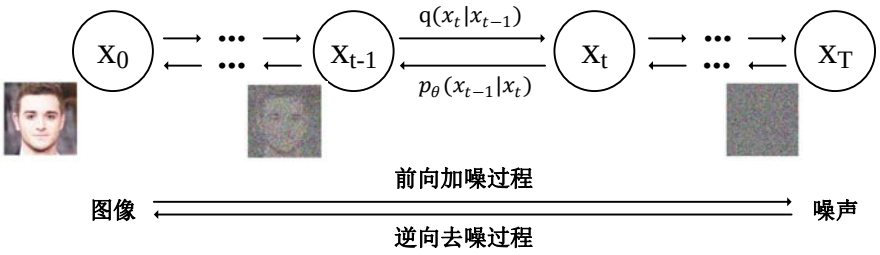


图 2.1　去噪扩散概率模型

加和消除噪声的方式来学习数据的分布，并生成新的样本。在具体实现上，去噪扩散概率模型包含一个拥有 T 步的前向加噪过程，以及对应的逆向去噪过程两个阶段，如图 2.1所示。

在前向加噪过程中，给定一张输入图像 x_0，以及对应的时间步 $t \in [0, T]$，便可以得到当前状态 x_t，这一过程可以表示为：

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t\mathbf{I}), \tag{2.1}$$

其中，x_t 代表在时间步 t 时的噪声图像，β_t 代表方差系数，$\mathbf{I}$ 代表单位矩阵。通过重参数化的方法，可以在给定初始状态 x_0 的前提下得到 x_t，这一过程可以表示为：

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)\mathbf{I}), \tag{2.2}$$

其中，$\alpha_t = 1 - \beta_t$，而 $\bar{\alpha}_t = \prod_{s=0}^{t} \alpha_s$。

在逆向去噪过程中，扩散模型旨在从当前状态 x_t 估计出之前状态 x_{t-1}。根据贝叶斯定理，该后验分布可以表示为：

$$p(x_{t-1}|x_t, x_0) = \mathcal{N}(x_{t-1}; \mu_t(x_t, x_0), \sigma_t^2\mathbf{I}), \tag{2.3}$$

其中，$\mu(x_t, x_0)$ 代表均值项，σ_t^2 代表方差项，这两者可以分别表示为：

$$\mu_t(x_t, x_0) = \frac{1}{\sqrt{\alpha_t}}(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon), \tag{2.4}$$

$$\sigma_t^2 = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t. \tag{2.5}$$

去噪扩散概率模型使用一个神经网络 ϵ_θ 来估计均值项 $\mu_t(x_t, x_0)$ 中的噪声项 ϵ。对于任意的时间步 $t \in [0, T]$，优化损失函数可以定义为：

$$L(\theta) = \|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon)\|_2^2. \tag{2.6}$$

在逆向过程中，去噪扩散概率模型通过迭代采样的方式从后验分布中获得之前状态 x_{t-1}。这使得去噪扩散概率模型可以从一个纯高斯噪声 $x_T \sim \mathcal{N}(0, \mathbf{I})$ 中生成样本 $x_0 \sim q(x_0)$，其中 $q(x_0)$ 代表训练数据集的分布。

中国知网　https://www.cnki.net

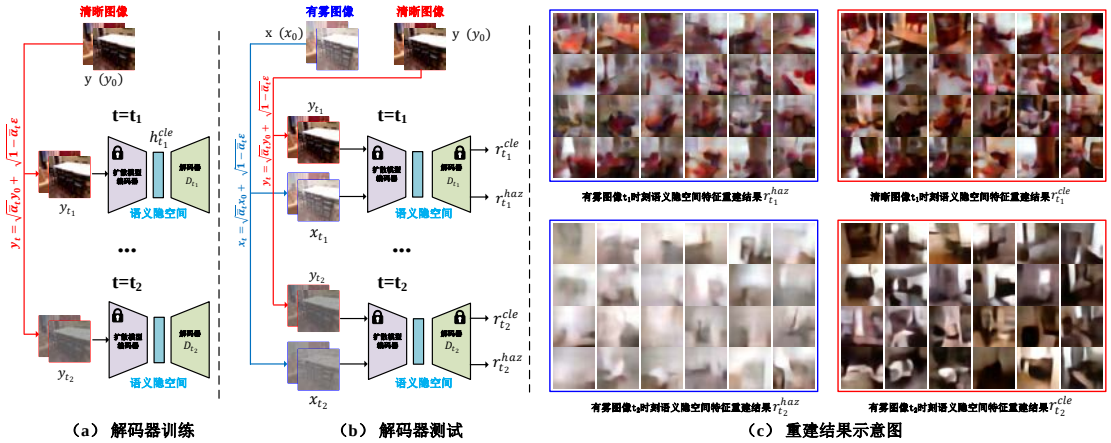


图 2.2　扩散模型语义隐空间探索方法示意图

2.3　扩散模型先验信息探索与网络结构设计

在本节中，首先以图像去雾为例，说明对预训练扩散模型语义隐空间的探索方法以及该隐空间表征的特性，同时展示了该特性在其他图像复原任务中的通用性。而后具体介绍所提的基于扩散模型隐空间特征引导的图像复原网络，包括所设计的内容融合模块和退化感知增强模块。最后，介绍训练所提网络所使用的损失函数。

2.3.1　扩散模型语义隐空间特性探索

在扩散模型中，公式 2.6中的去噪神经网络 ϵ_θ 通常采用 U-Net 结构[77]。已有研究表明，预训练扩散模型 U-Net 的瓶颈层（bottleneck layer）中蕴含丰富的语义信息，并可用于高层语义编辑[104]。本章将扩散模型瓶颈层特征空间称为扩散模型语义隐空间，并进一步挖掘该空间表征在低层图像复原任务中潜在的应用价值。为了方便探索，本节以首先以图像去雾，这一经典的图像复原任务为例，探索扩散模型语义隐空间特征的特性，并进一步拓展到其他图像复原任务中。同时，为了简化表达，首先定义一些变量。给定一张带雾图像 x 及其对应的清晰图像 y，根据公式 2.2，可以得到它们在时间步 t 时刻的噪声版本，分别记作 x_t 和 y_t，其中 $t \in [0, T]$。按照去噪扩散概率模型[4]中的标准设置，T 设置为 1000。需要注意的是，$x = x_0$ 且 $y = y_0$。而后，将 x_t 和 y_t 输入到参数固定的预训练扩散模型 ϵ_θ 中，可以获得对应的语义隐空间特征，分别记作 h_t^{haz} 和 h_t^{cle}，其中，上标“haz”和“cle”分别表示该隐空间特征是通过有雾图像和清晰图像得到的，而下标“t”则表示该隐空间特征对应的是时间步为 t。

为了探索扩散模型语义隐空间中有雾图像和清晰图像之间的关系，本节提出了一种解码器，用于将不同时间步时图像的语义隐空间特征映射回图像，如图 2.2所示。具体而言，对于每一个时间步 t，都训练一个对应的解码器 D_t，目

中国知网　https://www.cnki.net

的是将清晰图像的语义隐空间特征 h_t^{cle} 映射回无噪的清晰图像 y，该训练过程的损失函数可以表示为：

$$\mathcal{L}_t = \|D_t(h_t^{cle}) - y\|_1, \tag{2.7}$$

其中，$\|\cdot\|_1$ 代表 L1 范数。需要注意的是，只有高质量清晰图像的带噪版本 y_t 的语义隐空间特征 h_t^{cle} 参与了 D_t 的训练，而有雾图像及其对应的语义隐空间特征并不参与 D_t 的训练。通过这种方式，可以使得解码器 D_t 能够充分感知在时间步 t 时，语义隐空间特征 h_t^{cle} 是如何表示原始清晰图像 y。解码器 D_t 的具体结构如图 2.3所示。每个 D_t 由几组卷积层和残差通道注意力模块（Residual Channel Attention Block, RCAB）[27]组成，整体设计轻量且结构简单。

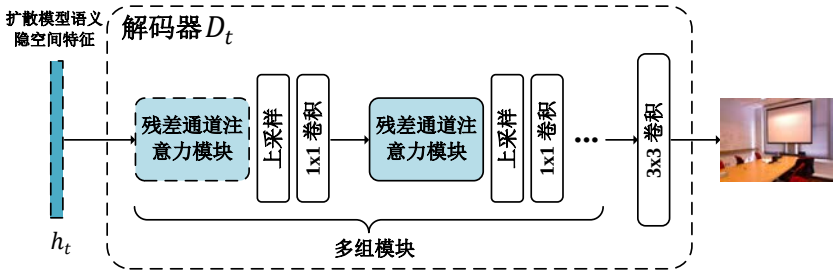


图 2.3　解码器 D_t 结构

训练完成之后，将有雾图像的语义隐空间特征 h_t^{haz} 输入到训练好的解码器 D_t 中，获得相应的重建结果，即 $r_t^{haz} = D_t(h_t^{haz})$，重建结果如图 2.2（c）中蓝色方框内的图像所示；同时，为了进行分析对比，清晰图像的语义隐空间特征 h_t^{cle} 也被输入到 D_t 并得到相应的重建结果，即 $r_t^{cle} = D_t(h_t^{cle})$，重建结果如图 2.2（c）中红色方框内图像所示。由于解码器 D_t 仅使用了清晰图像的语义隐空间特征进行了训练，因此不难理解 r_t^{cle} 在所有时间步 t 上都能够统一反映原始清晰图像的内容。然而，通过观察对比 r_t^{haz} 和 r_t^{cle} 可以发现，随着时间步 t 的变化，r_t^{haz} 能够表现出原始有雾图像 x 的不同特性。如图 2.2（c）中第一行所示，当时间步 t 较小（例如 $t = t_1$）时，蓝色框中的 $r_{t_1}^{haz}$ 主要表示原始图像 x 中的底层内容信息，这使得其与红色框中的 $r_{t_1}^{cle}$ 十分相似。这表明此时，无论是有雾图像的语义隐空间特征 $h_{t_1}^{haz}$ 还是清晰图像的特征 $h_{t_1}^{cle}$ 都主要编码图像的内容。然而，随着时间步 t 的增大（例如 $t = t_2$），$r_{t_2}^{haz}$ 的表征内容开始与 $r_{t_2}^{cle}$ 出现明显差异。如图 2.2（c）中第二行所示，红色框中的 $r_{t_2}^{cle}$ 仍然表示图像的内容，但是蓝色框中的 $r_{t_2}^{haz}$ 则主要反映原始雾图 x 中的雾霾特性。基于以上观察，可以得到如下结论：当时间步 t 较小时，有雾图像的扩散模型语义隐空间特征主要表示图像的底层内容信息；而随着时间步 t 的增大，该隐空间特征的关注重点逐渐转向表示有雾图像中的雾霾特性。通过精准地控制添加到退化图像 x 中的噪声，便可以利用预训练扩散模型获得不同时间步 t 时的语义隐空间特征，从而分离 x 中的不同成分。

为了进一步验证上述提出的结论，本节使用 t-SNE[108]可视化不同时间步 t

中国知网　https://www.cnki.net

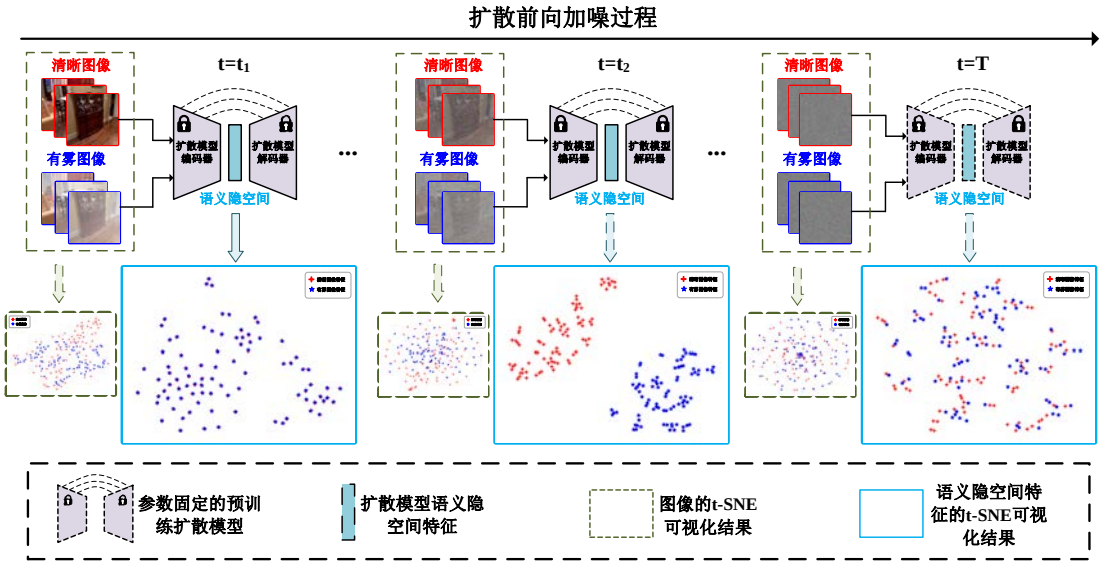


图 2.4　有雾图像与清晰图像在语义隐空间和图像空间中 t-SNE 可视化

时有雾-清晰图像对 (x_t, y_t) 的语义隐空间特征分布，如图 2.4所示。同时，为了进行对比，也展示了对应图像空间中的有雾-清晰图像对的 t-SNE 可视化结果。从图 2.4左侧第一张蓝色框图像可以看出，当时间步 t 较小时（例如 $t = t_1$），有雾图像的隐空间特征 h_t^{haz} 及其对应的清晰图像的隐空间特征 h_t^{cle} 紧密聚集在一起，而具有不同图像内容的特征对 (h_t^{haz}, h_t^{cle}) 则相互分离。这表明此时，无论是有雾图像的语义隐空间特征还是清晰图像的语义隐空间特征均主要表征图像的内容信息。而当时间步 t 较大时（例如 $t = t_2$），有雾图像的隐空间特征整体聚合，而清晰图像的隐空间特征也呈现出独立聚合的现象，如图 2.4中间第二张蓝色框图像所示。t-SNE 可视化的分析结果与上述利用解码器进行图像重建的结果一致，进一步证明了上述结论的准确性。实际上，随着时间步 t 的增大，语义隐空间特征 $h_{t_1}^{haz}$ 从主要编码图像底层内容逐渐过渡到主要表征图像退化特性，该过程连续且平滑，如图 2.5所示。作为对比，在图像空间中，所有时间步 t 下的 x_t 和 y_t 均表现出不规则的分布模式。值得注意的是，当时间步 t 取值过大时（例如 $t = T$），无论在扩撒模型的语义隐空间还是在原始的图像空间中，分布均表现出不规则的分布模式，如图 2.4右侧第三章组绿色和蓝色框图像所示。这是由于过大的噪声会同时抹除掉有雾图像中的内容信息和雾霾特性，进而导致分布的混乱。

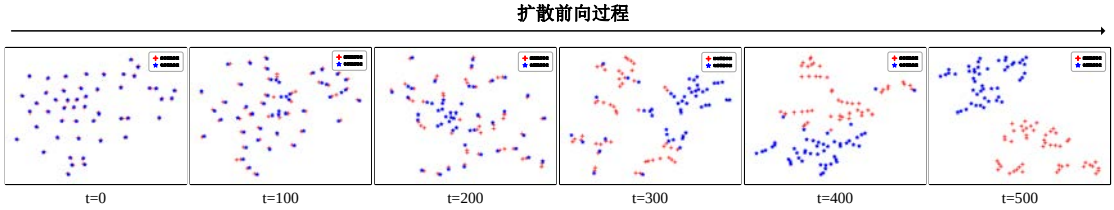


图 2.5　有雾-清晰图像对的语义隐空间特征分布转变可视化

上述现象在其他一些退化场景中同样明显，例如暗光照。本章采用与上述相

中国知网　https://www.cnki.net



图 2.6　暗光-正常光照图像的语义隐空间特征重建结果可视化

同的方法，探索暗光图像增强任务中的扩散模型语义隐空间特性。具体而言，本章采用 t 时刻带噪正常光图像 y_t 对应的语义隐空间特征 h_t^{nor} 来训练解码器 D_t，训练目标是重建无噪正常光图像 y，该过程可表示为：

$$\mathcal{L}_t = \| D_t(h_t^{nor}) - y \|_1. \tag{2.8}$$

随后，将暗光照图像的语义隐空间特征 h_t^{low} 和正常光照图像的特征 h_t^{nor} 输入到训练好的解码器 D_t 中，并分别得到重建结果 r_t^{low} 和 r_t^{nor}。图 2.6展示了不同时间步 t 下的重建结果。可以观察到，暗光图像的重建结果 r_t^{low} 与有雾图像的重建结果 r_t^{haz} 表现出了相似的特性：当时间步 t 较小时（如 $t = t_1$），$r_{t_1}^{low}$ 能够较好地反映出原始暗光图像 x 中底层的内容信息，其视觉效果与 $r_{t_1}^{nor}$ 相似，如图 2.6左侧紫色框中所示；而当时间步 t 较大时（如 $t = t_2$），如图 2.6右侧蓝色框所示，$r_{t_2}^{low}$ 中已经几乎不可见图像的底层内容信息，取而代之的是图像的暗光照特性。此外，图 2.7也展示了暗光图像语义隐空间特征在不同时间步 t 时的 t-SNE 可视化结果。可以观察到，随着时间步 t 的增大，暗光图像的语义隐空间特征 h_t^{low} 从编码底层图像内容逐渐转变为捕捉暗光照特性，这一趋势与图 2.5中的现象相似。

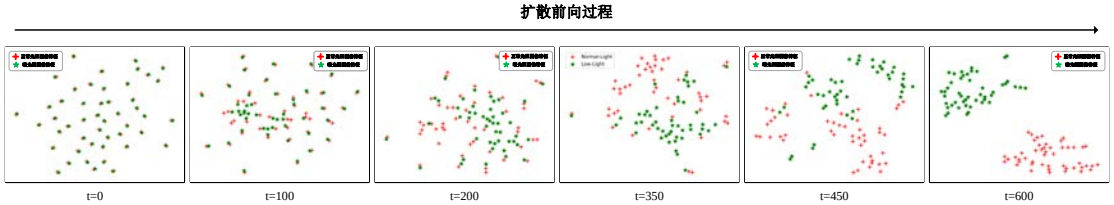


图 2.7　暗光-正常光照图像对的语义隐空间特征分布转变可视化

许多已有的研究已经证明[109-110]，扩散模型在逆向生成过程中遵循着由粗到细的生成机制。而本文认为本节中所展示出的扩散模型语义隐空间特性也正是源于这一生成机制。在扩散过程的早期阶段（即时间步 t 较小时），输入图像添加的噪声较少，扩散模型侧重于细粒度细节，从而使得其隐空间特征能够充分感知图像的底层内容信息。而在扩散过程的后期阶段（即时间步 t 较大时），输入图像添加的噪声较多，扩散模型更多地关注图像的整体属性，这使得其隐空间特征能够反映图像的全局退化信息，例如有雾图像中雾霾的特性。

中国知网　https://www.cnki.net

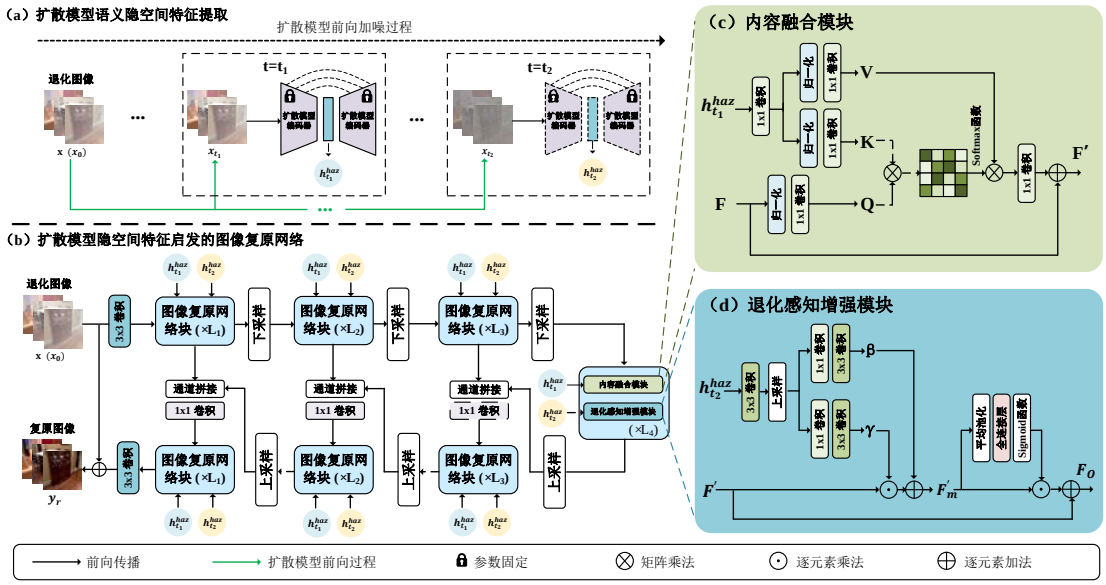


图 2.8　基于扩散模型隐空间特征引导的图像复原网络结构

2.3.2　基于扩散模型隐空间特征引导的图像复原网络

本章的 2.3.1节阐述了扩散模型语义隐空间针对图像复原的特性。以图像去雾为例，对于所有的时间步时的语义隐空间特征 h_t^{haz}（其中 $t \in [0,T]$），$h_{t_1}^{haz}$（即 $t=t_1$）和 $h_{t_2}^{haz}$（即 $t=t_2$）是最具代表性的。其中，前者主要表征了有雾图像 x 的底层内容信息，而后者主要刻画了 x 中雾霾的属性。关于 t_1 和 t_2 的具体选择将在 2.4.4节中详细说明。基于此，本节提出了一种基于扩散模型隐空间特征引导的图像复原网络。如图 2.8（b）所示，该网络采用 U-Net 结构，由多个子模块级联而成。每一个子模块包含一个内容融合模块和退化感知增强模块。其中，内容融合模块利用时间步较小时的隐空间特征 $h_{t_1}^{haz}$ 实现图像内容的恢复，而退化感知增强模块则利用时间步较大时的隐空间特征 $h_{t_2}^{haz}$ 进行雾霾的去除。下面详细介绍这两个模块的结构。

内容融合模块。为了有效利用扩散模型语义隐空间特征 $h_{t_1}^{haz}$ 中所蕴含的图像内容信息来帮助复原网络进行图像内容的恢复，本节提出了内容融合模块，如图 2.8（c）绿色框所示。具体来说，给定输入特征 $F \in \mathbb{R}^{\hat{H}\times\hat{W}\times\hat{C}}$ 和语义隐空间特征 $h_{t_1}^{haz} \in \mathbb{R}^{H'\times W'\times C'}$，首先设计卷积层将 $h_{t_1}^{haz}$ 映射到与 F 相同的维度，即 $h_{t_1}^{haz'} = W_c h_{t_1}^{haz}$，其中，$h_{t_1}^{haz'} \in \mathbb{R}^{H'\times W'\times\hat{C}}$，而 W_c 代表一个 1×1 的卷积核。之后，输入特征 F 被映射为查询向量 Q，而语义隐空间特征 $h_{t_1}^{haz'}$ 被映射为键向量 K 和值向量 V，该过程可以表示为：

$$Q = W_Q F, \quad K = W_K h_{t_1}^{haz'}, \quad V = W_V h_{t_1}^{haz'}, \tag{2.9}$$

其中，W_Q,W_K 和 W_V 都是 1×1 的卷积核。在此之后，查询向量 Q 的形状被重新调整为 $Q \in \mathbb{R}^{\hat{H}\hat{W}\times\hat{C}}$，键向量 K 和值向量 V 的形状也被重新调整为 $K,V \in \mathbb{R}^{H'W'\times\hat{C}}$。

中国知网　https://www.cnki.net

之后，最终输出 F' 可以通过以下形式表示：

$$F' = W_O \cdot Softmax(\frac{QK^T}{\sqrt{\hat{C}}}) \cdot V + F, \tag{2.10}$$

其中，W_O 同样是一个 1×1 的卷积核。通过这种基于注意力机制的特征交互方式，内容融合模块可以鼓励图像复原网络充分探索输入特征 F 和扩散模型语义隐空间特征 $h_{t_1}^{haz}$ 之间的对应关系，并进一步促使图像复原网络能够动态捕获 $h_{t_1}^{haz}$ 中蕴含的图像内容信息，从而更好地实现图像内容的恢复。

退化感知增强模块。本节设计了退化感知增强模块，以利用语义隐空间特征 $h_{t_2}^{haz}$ 作为引导实现退化信息的去除，如图 2.8（d）蓝色框所示。给定语义隐空间特征 $h_{t_2}^{haz}$，首先将其作为引导，通过类似空间特征转换（Spatial Feature Transform, SFT）[111]的方式对输入特征 F' 在空间维度进行动态增强。具体来说，首先对语义隐空间特征 $h_{t_2}^{haz}$ 进行空间上采样，使其与输入特征 F' 空间维度想匹配，而后使用卷积层对其进行变换，该过程可以表示为：

$$\gamma = W_\gamma \cdot UpSample(h_{t_2}^{haz}), \quad \beta = W_\beta \cdot Upsample(h_{t_2}^{haz}), \tag{2.11}$$

其中，W_γ 和 W_β 代表变换参数，具体实现为 1×1 卷积核和 3×3 卷积核的堆叠；γ 和 β 代表得到的仿射变换参数，其维度与输入特征 F' 相同。而后，利用 γ 和 β 对 F' 进行空间变换，该过程可以表示为：

$$F'_m = \gamma \odot F' + \beta. \tag{2.12}$$

空间维度增强之后，对得到的聚合特征 F'_m 进一步在通道维度上进行动态调制，该过程可以表示为：

$$F_o = \sigma(W_L \cdot \text{AvgPool}(F'_m)) \cdot F'_m + F', \tag{2.13}$$

其中，σ 代表 Sigmoid 激活函数，W_L 代表全连接层，而 AvgPool 代表平均池化操作。通过这种在空间和通道两个维度都进行调制的方式，退化感知增强模块可以促使图像复原网络充分感知并适应 $h_{t_2}^{haz}$ 中的退化特性，并在 $h_{t_2}^{haz}$ 的引导下对输入特征 F' 进行动态调节，从而实现退化信息的去除。

2.3.3　损失函数

每组退化图像对 (x, y) 的训练损失函数被定义为通过所提方法得到的复原图像与对应的高质量图像之间的距离。所以，整体优化目标可以表示为：

$$\mathcal{L} = \|y_r - y\|_1, \tag{2.14}$$

中国知网　https://www.cnki.net

其中，y_r 表示通过本章提出的图像复原方法对退化图像进行修复而得到的复原图像，$\|\cdot\|_1$ 代表 L1 范数。需要注意的是，预训练扩散模型 ϵ_θ 只被用来提取语义隐空间特征 $h_{t_1}^{haz}$ 和 $h_{t_2}^{haz}$，其网络参数在整个训练过程中是固定住的，并不参与更新过程。

2.4　实验分析

2.4.1　数据集和评价指标

（1）数据集

为了验证本章提出方法的有效性，本章选择在图像去雾，暗光图像增强，以及图像去雨三个任务上进行效果验证。对于图像去雾任务，本章选择在多个数据集上验证我们方法的有效性，包括合成数据集和真实场景数据集。对于合成场景去雾，本章采用 RESIDE[112]数据集进行训练与测试。具体来说，本章选择使用 RESIDE 数据集中的室内训练集（Indoor Training Set, ITS）进行图像复原网络的训练。该子集包含 13,990 张有雾图像，而这些有雾图像是通过 1,399 张清晰图像合成的。同时，本章选择使用 RESIDE 的合成目标测试集（Synthetic Objective Testing Set, SOTS）作为测试集。该子集包含 500 张室内和 500 张室外的有雾图像。其中，本章选择室内部分作为测试集。对于真实场景去雾，本章选择 Dense-Haze[113]与 NH-HAZE[114]数据集。这两个数据集均包含 55 组有雾-清晰图像对，其中 50 组图像对用于训练，其余 5 组图像对用于测试。对于暗光图像增强任务，本章选用 LOL-v1[115]和 LOL-v2 Real[116]两个数据集进行效果验证。其中，LOL-v1 数据集包含 485 组暗光-正常光图像对用于训练，15 组图像对用于测试。LOL-v2 Real 数据集包含 689 组暗光-正常光图像对用于训练，100 组图像对用于测试。对于图像去雨任务，本章选择在 Rain100H[57]数据集上进行效果验证。Rain100H 数据集包含 1,800 组有雨-清晰图像对用于训练，100 组图像对用于测试。

（2）评价指标

为了评估算法性能，本章主要采用峰值信噪比（Peak Signal-to-Noise Ratio, PSNR），结构相似性指数（Structural Similarity Index Measure，SSIM）[117]，以及学习感知图像块相似度（LPIPS）[118]三种不同的评估指标，这三种不同的指标被广泛用于定量衡量图像复原的效果。在暗光图像增强任务上，额外添加了 FID[119]指标，以更好地衡量各种基于扩散模型图像复原方法的性能。

PSNR 基于均方误差（Mean Squared Error，MSE）来衡量复原图像和高质量清晰图像之间的像素级差异，单位通常为分贝（dB）。其数值越高，通常意味着

中国知网　https://www.cnki.net

复原图像与高质量清晰图像越接近，失真程度越低。其计算方式可以表示为：

$$\mathrm{PSNR} = 10 \cdot \log_{10}(\frac{\mathrm{MAX}_I^2}{\mathrm{MSE}}), \tag{2.15}$$

其中，MAX_I 代表图像中最大可能像素值（例如，对于 8 位图像，$\mathrm{MAX}_I = 255$），MSE 表示均方误差，其计算方式可以表示为：

$$\mathrm{MSE} = \frac{1}{mn}\sum_{i=1}^{m}\sum_{j=1}^{n}[Y(i,j) - Y_r(i,j)]^2, \tag{2.16}$$

其中，Y 为高质量清晰图像，Y_r 为复原图像，m 和 n 分别为图像的行数和列数。

SSIM 从结构、亮度和对比度等方面评价复原图像和高质量清晰图像之间的相似性。它不仅关注像素差异，同时还考虑图像的局部结构信息，其值通常在 0 到 1 之间。SSIM 的值越大，证明复原图像越接近于高质量清晰图像，图像复原效果越好。其计算方式可表示为：

$$\mathrm{SSIM}(x,y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}, \tag{2.17}$$

其中，x 和 y 分别代表两幅图像的窗口，μ_x 和 μ_y 分别代表窗口内的均值，σ_x 和 σ_y 分别代表窗口内的标准差，σ_{xy} 代表窗口内的协方差，C_1 和 C_2 是为了防止分母为零而引入的小常数。

LPIPS 是一种基于深度神经网络提取的特征来衡量图像之间感知相似性的指标。与上面提到的 PSNR 和 SSIM 不同，LPIPS 侧重于捕捉人眼对图像内容和纹理的感知差异。其值越小，表示复原图像的视觉感知质量越高。LPIPS 通常使用一些在大规模数据集（例如 ImageNet）上预训练的深度神经网络（如 VGG, AlexNet 等）作为特征提取器，并通过比较网络多个层次之间的特征来衡量图像质量。其计算方式可表示为：

$$\mathrm{LPIPS}(x,y) = \sum_l w_l \cdot \|\phi_l(x) - \phi_l(y)\|_2^2, \tag{2.18}$$

其中，ϕ 为预训练神经网络，ϕ_l 表示该网络第 l 层特征，w_l 为权重。

FID 是一种广泛用于评估图像生成模型（如生成对抗网络，扩散模型等）生成图像质量的指标。其通过比较生成图像和真实图像在特定特征空间中的分布差异来定量反映生成图像与真实图像之间的相似性，其数值越低，说明生成图像越接近于真实图像。而特征空间通常选择为预训练的 Inception 网络[120]的某一层。其计算公式可表示为：

$$\mathrm{FID} = \|\mu_r - \mu_g\|_2^2 + \mathrm{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r\Sigma_g)^{1/2}), \tag{2.19}$$

中国知网　https://www.cnki.net

其中，μ_r 和 Σ_r 代表真实图像特征向量的均值和协方差矩阵，μ_g 和 Σ_g 代表生成图像特征向量的均值和协方差矩阵，Tr 表示矩阵的迹。

以上指标中，PSNR 和 SSIM 从像素值和局部结构层面衡量图像复原的效果，其数值更多的反映复原图像对高质量清晰图像的保真程度。而 LPIPS 和 FID 更侧重于从感知的角度反映图像复原的效果，其数值更多地反映人眼视觉系统对图像质量的评价。

2.4.2　实验设置

本章所涉及的实验均在一台 NVIDIA 3090Ti GPU 上运行完成。本章所提出的扩散模型隐空间启发的图像复原网络采用 Adam 优化器进行训练，其中参数 β_1 和 β_2 分别设定为 0.9 和 0.999。训练的总迭代轮数设置为 1,200。初始学习率设置为 2×10^{-4}，并每 300 轮衰减 0.5 倍。本章对输入图像进行尺寸调整并裁剪至 128×128 大小，同时以一定的概率进行随机水平翻转。每一次训练的批量大小设置为 40。在实验中，本章使用在 ImageNet[121] 预训练过的无条件去噪扩散概率模型[122] 来作为 ϵ_θ 提取语义隐空间特征。

2.4.3　性能比较

（1）图像去雾性能比较

对比的基准方法。为了证明本章提出方法在图像去雾任务上的有效性，本章引入若干图像去雾方法进行性能对比。其中包括经典图像去雾算法 DCP[13]，以及基于深度学习的图像去雾算法，包括 DehazeNet[123]，AOD-Net[47]，FFA-Net[7]，MSBDN[124]，AECR-Net[125]，MPRNet[26] 这些基于卷积神经网络结构的方法，和 SwinIR[126]，Restormer[15]，Dehamer[127] 这些基于 Transformer 架构的方法。同时，本章也引入了 IR-SDE[75] 和 ResShift[82] 两个基于扩散模型的图像复原方法以进行性能对比。

定量结果比较。表 2.1和表 2.2分别展示了在合成数据集 SOTS 和真实场景数据集 Dense-Haze、NH-HAZE 三个数据集上的定量数据评估指标。其中，加粗标注的数值代表最好的结果，下划线标注的数值代表次好的结果。上标“*”代表基于扩散模型的图像去雾方法。时间步 t_1 和 t_2 分别设置为 0 和 500，有关时间步的选取将在 2.4.4节中进行详细讨论。可以看出，本章提出的方法无论在合成场景中还是在真实场景中，都要综合优于其他先进的图像去雾方法。

具体来说，在合成场景的 SOTS 数据集上，本章提出的方法在使用更少参数的情况下，在 PSNR 指标上超过基于 Transformer 的方法 Restormer 和 Dehamer 分别 1.90dB 和 3.70dB。这充分证明了本章提出的方法出色的去雾重建效果。此外，相比于其他方法，本章提出的方法也实现了较低的 LPIPS 值。这表明了通过本章

中国知网　https://www.cnki.net

表 2.1　不同方法在去雾数据集 SOTS[112] 上定量比较

方法	SOTS			参数量
	PSNR	SSIM	LPIPS	
DCP[13]	15.09	0.765	0.069	-
DehazeNet[123]	20.64	0.800	0.242	0.01M
AOD-Net[47]	19.82	0.818	0.099	0.002M
FFA-Net[7]	36.39	0.989	0.005	4.68M
MSBDN[124]	33.79	0.984	0.029	31.35M
SwinIR[126]	24.93	0.932	0.049	0.91M
AECR-Net[125]	37.17	0.990	0.007	2.61M
MPRNet[26]	32.14	0.983	0.011	15.74M
Restormer[15]	38.43	0.989	0.009	26.13M
Dehamer[127]	36.63	0.988	0.005	132.50M
IR-SDE*[75]	23.40	0.927	0.023	537.21M
ResShift*[82]	29.06	0.950	0.017	114.65M
本章方法 *	**40.33**	**0.992**	**0.004**	8.63M

提出的方法复原得到的图像与人类视觉系统的感知更为一致。同时，相比于同为基于扩散模型的图像复原方法 IR-SDE 和 ResShift，本章提出的方法也在全部三个指标上显著领先。值得注意的是，与现有的基于扩散模型的去雾方法相比，本章提出的方法不仅拥有更优的性能，同时避免了对扩散模型的重新训练。此外，本章提出的方法还规避了推理过程中可能出现的冗长耗时的扩散模型逆向采样。

在真实场景数据集 Dense-Haze 和 NH-HAZE 上，可以看到，本章提出的方法去雾性能均超过或至少达到与现有先进图像去雾方法相当的水平。例如在 Dense-Haze 数据集中，本章提出的方法相较于 Restormer 和 Dehamer 在 PSNR 指标上分别实现了 1.8dB 和 0.35dB 的提升。同时也要比基于卷积神经网络的先进去雾方法 AECR-Net 在 PSNR 指标上领先 1.17dB。在 NH-HAZE 数据集中，本章方法在 PSNR 指标实现了与 Dehamer 相当的水平，同时在 SSIM 指标上超过了所有比较的去雾方法。另外，本章提出的方法在两个数据集上都实现了最佳的 LPIPS 值，这进一步证明了本章所提方法的有效性。

定性结果比较。为了进一步验证本章提出方法在图像去雾任务上的有效性，图 2.9，图 2.10和图 2.11分别展示了在 SOTS，Dense-Haze 和 NH-HAZE 数据集上的定性结果比较。可以看出，先进的图像去雾方法并没能有效地实现图像的去雾，而本章所提出的图像复原方法可以更准确地恢复图像的底层内容信息并且更有效地去除雾霾退化成分。

具体而言，从图 2.9中第一组定性结果中可以看出，DehazeNet，SWinIR 以及 IR-SDE 等方法都没能实现雾霾成分的完全去除，导致复原图像的部分区域仍然存在轻微的残留雾霾。MPRNet 等方法尽管在大部分区域实现了雾霾的去除，然而去雾后的图像在部分区域出现颜色偏差以及细节丢失的问题。例如，MPRNet

中国知网　https://www.cnki.net

表 2.2　不同方法在去雾数据集 Dense-Haze[113]和 NH-HAZE[114]上定量比较

方法	Dense-Haze			NH-HAZE		
	PSNR	SSIM	LPIPS	PSNR	SSIM	LPIPS
DCP[13]	10.03	0.386	0.605	10.57	0.520	0.399
DehazeNet[123]	13.84	0.425	0.637	16.62	0.524	0.529
AOD-Net[47]	13.14	0.414	0.599	15.40	0.569	0.495
FFA-Net[7]	14.39	0.452	0.498	19.87	0.692	0.365
MSBDN[124]	15.37	0.486	0.536	19.23	0.706	0.292
SwinIR[126]	12.20	0.510	0.639	16.15	0.623	0.479
AECR-Net[125]	15.80	0.466	0.537	19.88	0.707	0.278
MPRNet[26]	13.82	0.519	0.620	17.88	0.631	0.368
Restormer[15]	15.17	0.557	0.629	18.32	0.635	0.355
Dehamer[127]	16.62	0.560	0.480	**20.66**	0.684	0.230
IR-SDE*[75]	12.03	0.508	0.485	12.59	0.520	0.361
ResShift*[82]	13.67	0.517	0.576	16.26	0.625	0.327
本章方法 *	**16.97**	**0.584**	**0.406**	20.29	**0.738**	**0.217**

复原图像的椅背颜色与清晰图像相比存在明显差异。与基准方法相比，本章提出的方法在雾霾成分的去除上具有明显的改进，可以更加彻底地清除图像中的雾霾成分，同时更加精准地恢复底层的色彩信息和细节纹理，呈现出了更加清晰逼真的复原效果。

图 2.10和图 2.11展示了真实场景数据集下的去雾定性结果。相比于合成场景，真实场景数据集中的雾霾更加浓厚，底层信息受遮挡程度更高，去雾的难度也更大。例如，在 Dense-Haze 数据集中，AOD-Net 等方法无法移除雾霾成分，导致图像的底层信息仍然被遮挡，影响整体视觉质量。Restormer 等方法虽然成功移除了雾霾成分，然而无法有效恢复底层内容的色彩信息，导致复原的图像呈现较为单一色调，缺乏真实感。而在 NH-HAZE 数据集中，DCP、MSBDN、FFA-Net 和 Restormer 等方法复原的图像中有较为明显的雾霾成分残留。Dehamer 成功复原了大部分雾霾区域，然而仍然有部分未能成功去除，影响图像整体清晰度。相比之下，本章提出的方法能更加有效地移除雾霾成分，同时更准确地恢复底层的内容结构信息，证明了本章方法的有效性。

（2）暗光图像增强性能比较

对比的基准方法。为了进一步证明本章方法在暗光图像增强任务上的有效性，本章使用多个基于深度学习的暗光图像增强方法作为基准方法进行性能比较。其中，包括基于卷积神经网络的方法，例如 RetinexNet[115]，Zero-DCE[128]，EnlightenGAN[129]，URetinex-Net[12]，以及基于 Transformer 架构的方法，例如 Uformer[30]，Restormer[15]。本章同样引入基于扩散模型的图像增强方法用于性能对比，包括 WeatherDiff[130]，ResShift[82]，IR-SDE[75]和 GDP[131]。

定量结果比较。表 2.3展示了在 LOL-v1 和 LOL-v2 两个数据集上的暗光图

中国知网　https://www.cnki.net

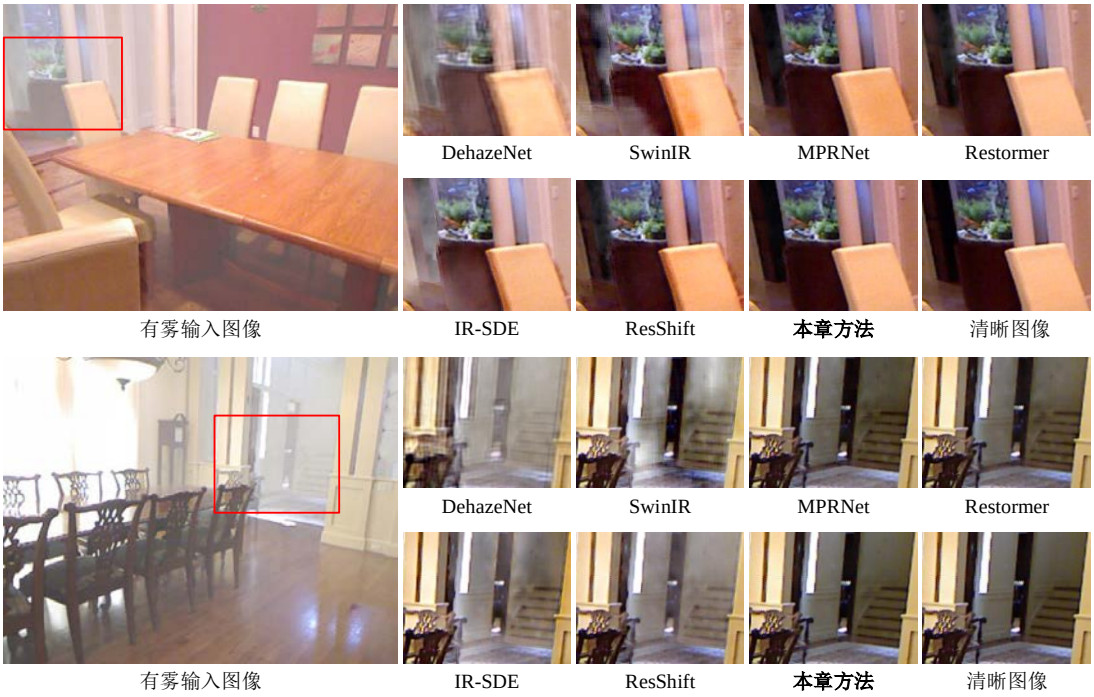


图 2.9　不同方法在 SOTS[112] 数据集上的图像去雾定性比较

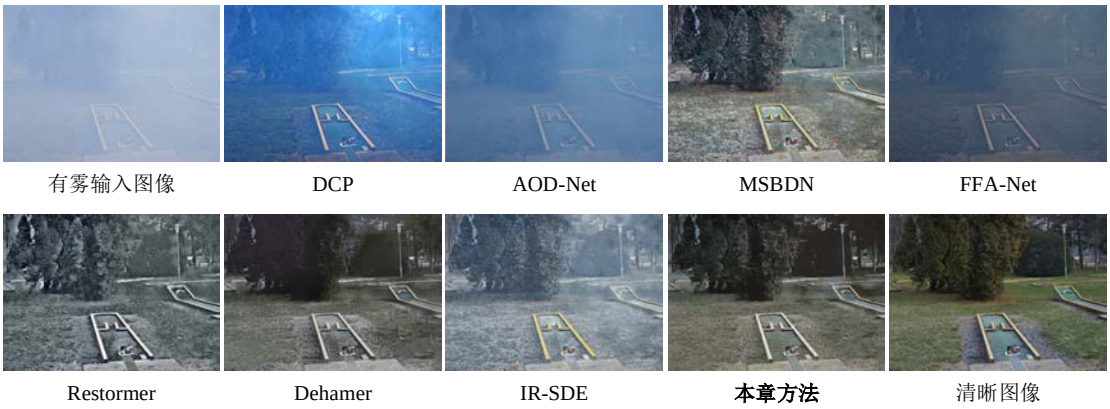


图 2.10　不同方法在 Dense-Haze[113] 数据集上的图像去雾定性比较

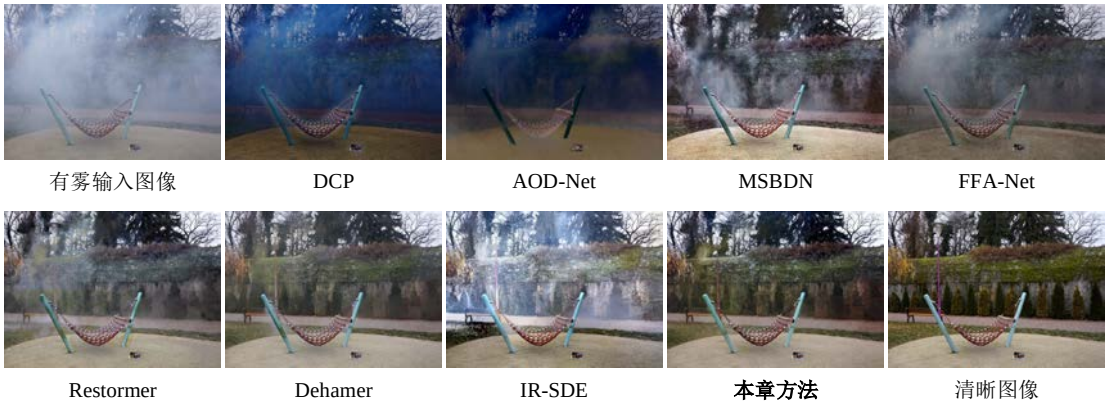


图 2.11　不同方法在 NH-HAZE[114] 数据集上的图像去雾定性比较

中国知网　https://www.cnki.net

表 2.3　不同方法在 LOL[115-116] 数据集上暗光图像增强定量比较

方法	LOLv1				LOLv2-Real			
	PSNR	SSIM	LPIPS	FID	PSNR	SSIM	LPIPS	FID
RetinexNet[115]	16.77	0.462	0.417	126.27	17.72	0.652	0.436	133.91
Zero-DCE[128]	14.86	0.562	0.372	87.24	18.06	0.580	0.352	80.45
EnlightenGAN[129]	17.61	0.653	0.372	94.70	18.68	0.678	0.364	84.04
URetinex-Net[12]	19.97	0.828	0.267	62.38	21.13	0.827	0.208	49.84
Uformer[30]	19.00	0.741	0.354	109.35	18.44	0.759	0.347	98.14
Restormer[15]	20.61	0.792	0.288	73.00	21.36	0.835	0.314	63.69
WeatherDiff* [130]	16.30	0.786	0.277	65.61	15.87	0.801	0.272	65.82
ResShift* [82]	19.23	0.735	0.225	61.21	20.41	0.704	0.218	60.72
IR-SDE* [75]	12.90	0.557	0.486	175.33	12.53	0.511	0.453	157.08
GDP* [131]	13.93	0.630	0.445	95.16	13.15	0.527	0.421	97.54
本章方法 *	**23.30**	**0.849**	**0.136**	**55.88**	**22.35**	**0.874**	**0.186**	**42.49**



图 2.12　不同方法在 LOL[115-116] 数据集上的暗光图像增强定性比较

像增强的定量数据评估指标。其中，加粗标注的数值代表最好的结果，下划线标注的数值代表次好的结果。上标“*”代表基于扩散模型的暗光图像增强方法。可以看到，本章提出的方法在两个数据集上的所有指标上都优于先进的暗光图像增强方法。例如，在 LOL-v1 数据集上和 LOLv2-Real 数据集上，本章方法比 Restormer 在 PSNR 指标上分别领先 2.69dB 和 0.99dB。同时，相比于基于扩散模型的图像复原方法，本章提出的方法无论是在衡量复原图像保真度的 PSNR 和 SSIM 指标上，还是在衡量图像视觉感知质量的 LPIPS 和 FID 指标上都显著领先。这证明了本章所提方法不仅可以精准复原暗光图像，同时还能保证复原图像优秀的视觉效果。

定性结果比较。图 2.12展示了不同方法暗光图像增强的定性比较结果。可以观察到，IR-SDE 无法有效增强输入的暗光图像，导致复原的图像出现严重的色偏。Restormer 等方法虽然成功增强了暗光图像，但是仍然难以准确恢复一些局部细节信息。相比之下，本章提出的方法不仅能够有效增强暗光区域的亮度，同时在细节纹理的复原方面表现更优，保证复原图像的视觉效果。

（3）图像去雨性能比较

对比的基准方法。本章进一步在图像去雨任务上证明了所提方法的有效

中国知网　https://www.cnki.net

性。本章选用了基于卷积神经网络的图像去雨方法作为基准方法，包括 DerainNet[132]、PReNet[56]和 MPRNet[26]。同时，本章也选择了基于扩散模型的图像复原方法 IR-SDE[75]作为基准方法进行对比。

定量结果比较。表 2.4展示了在 Rain100H 数据集上不同图像复原方法的定量数据评估指标。其中，加粗标注的数值代表最好的结果，下划线标注的数值代表次好的结果。上标“*”代表基于扩散模型的图像复原方法。可以看出，本章提出的方法在图像去雨任务上取得的较高的保真效果。具体来说，本章方法相较于 PReNet、MPRNet 和 IR-SDE 在 PSNR 指标上分别取得了 1.47dB、0.52dB 和 0.18dB 的提升，证明了本章提出方法在图像去雨任务上的有效性。同时，本章方法也与基于扩散模型的图像复原方法 IR-SDE 在 LPIPS 上取得了相当的性能，保证了优秀的视觉质量。

表 2.4　不同方法在 Rain100H[57] 数据集上图像去雨定量比较

Method	PSNR	SSIM	LPIPS
DerainNet[132]	14.85	0.587	0.573
PReNet[56]	29.46	0.899	0.128
MPRNet[26]	30.41	0.891	0.158
IR-SDE*[75]	<u>30.75</u>	<u>0.903</u>	**0.048**
本章方法*	**30.93**	**0.907**	<u>0.053</u>

定性结果比较。图 2.13展示了在 Rain100H 数据集上的定性结果比较。可以看出，Rain100H 数据集有雨图像中的雨线较长且分布密集，雨线的去除和底层内容的恢复面临较大难度。从图 2.13中第一行，第三行，第四行和第六行可以看到，MPRNet 虽然可以去除绝大部分雨线，但是其复原的图像中仍存在轻微的雨线残留痕迹。此外，残留的雨痕对图像内容结构造成影响，导致复原图像出现一定程度的形变。从图 2.13的第二行，第三行，和第六行可以观察到，IR-SDE 虽然更全面地去除了图像中的雨线，但是复原图像在局部细节处仍存在畸变。相比之下，本章提出的图像复原方法不仅可以更彻底地去除雨线退化，同时更加精准地恢复底层图像内容结构和纹理细节，显著提升了去雨图像的视觉质量，进一步证明了本章所提方法的有效性。

（4）与其他基于扩散模型的图像复原方法比较

本章将提出的基于扩散模型隐空间特征引导的图像复原网络与其他基于扩散模型的图像复原方法进行比较，这些方法大体可以分为两种范式。第一类方法是针对特定图像复原任务从头开始重新训练一个条件化的扩散模型[75,82]。这类方法往往可以取得卓越的图像复原性能，但由于去噪网络 ϵ_θ 通常包含大量参数，其参数规模一般远超现有的基于重建范式的图像复原网络，因此训练过程往往需要消耗极大的计算资源。第二类方法则是直接引导预训练好的扩散模型生成高质量目标图像[83-84]。这些方法基于后验采样，并在扩散模型逆向过程中施加

中国知网　https://www.cnki.net

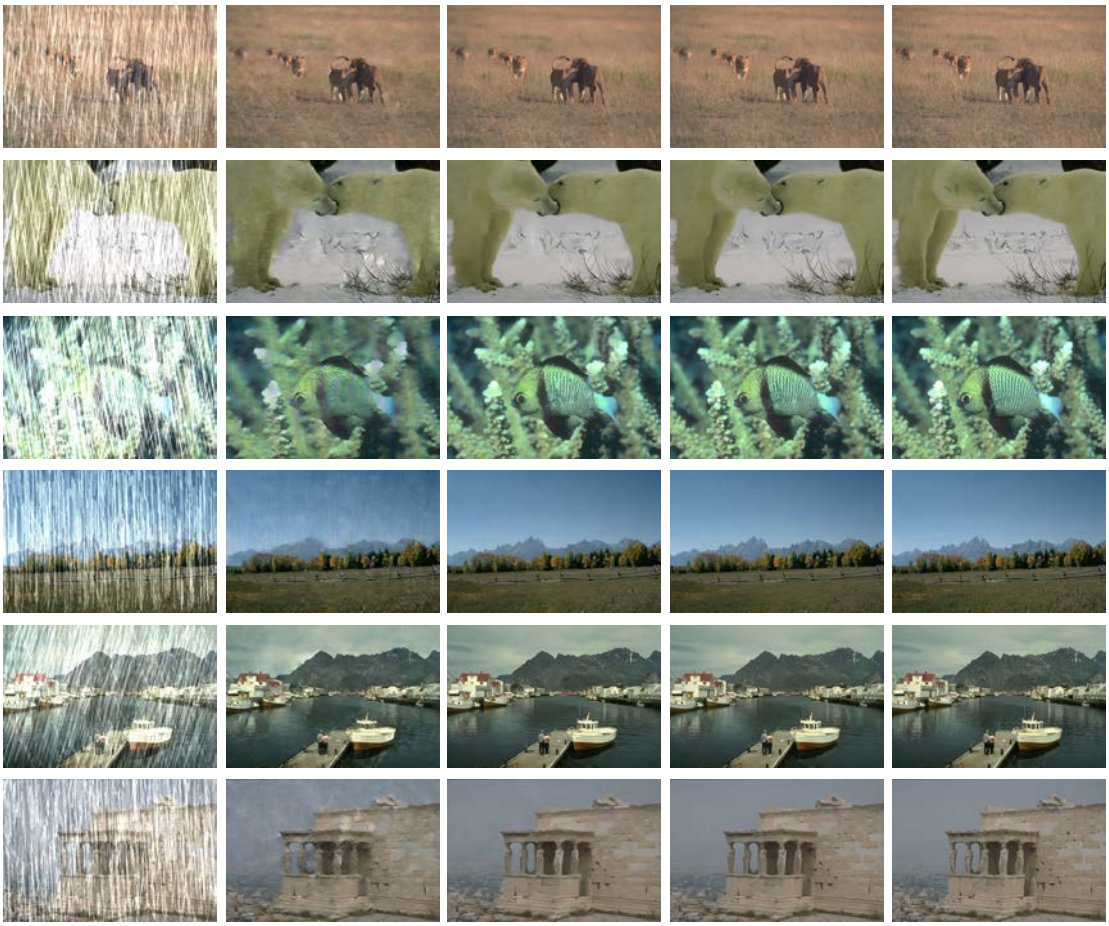
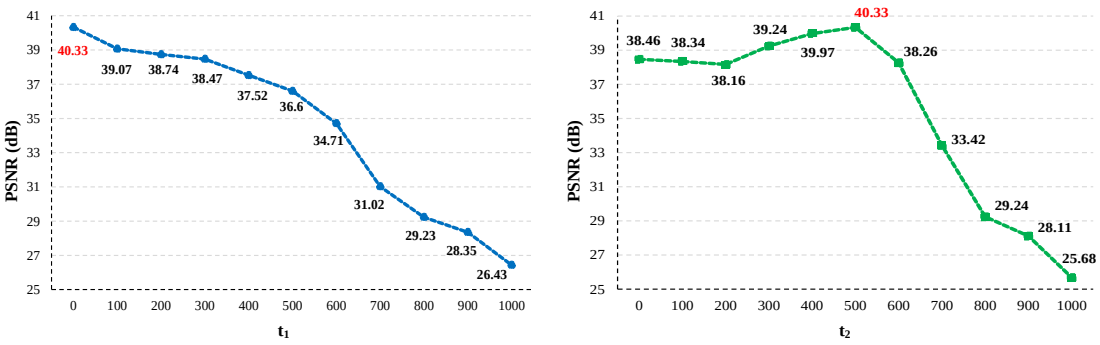


图 2.13　不同方法在 Rain100H[57] 数据集上的图像去雨定性比较

约束。相比于第一类方法，该策略避免了重新训练扩散模型的所需要的巨量计算消耗。然而，这类方法通常需要冗长耗时的采样过程来获得最终的目标图像。此外，这类方法通常需要精确的退化模型以引导逆向采样，而对于如本章中选择的图像去雾、暗光图像增强等任务而言，精确的退化模型往往难以获取。

除了以上两种主流范式外，近期有相关研究尝试将扩散模型与基于重建的图像复原网络[106,133]。该类方法通常分为两个阶段。在第一阶段，预训练一个扩散模型以构建先验信息；在第二阶段，将该先验信息整合到图像复原网络中进行训练。该类方法与本章提出的方法有一定的相似性。然而，该类方法仍然需要再第一阶段单独预训练一个新的扩散模型，而本章提出的方法直接利用了在 ImageNet 上预训练的通用扩散模型所蕴含的视觉先验信息来促进图像复原，极大提升了计算效率。同时，本章还探索了扩散模型先验知识的特性，使得本章所提出的方法具有更强的可解释性和可拓展性。综上所述，本章提出的方法既避免了重新训练扩散模型所需要的高昂计算成本，也规避了冗长耗时的扩散逆向采样过程。同时，本章方法探索了扩散模型语义隐空间的针对图像复原任务的特性，为图像复原范式的探索提供了新的思路。

中国知网　https://www.cnki.net



（a）t_1选择对图像去雾性能影响　　（b）t_2选择对图像去雾性能影响

图 2.14　不同 t_1 和 t_2 选择在 SOTS[112] 数据集上对图像去雾性能的影响

2.4.4　消融实验

利用预训练扩散模型语义隐空间特征来引导图像复原是本章方法的核心思路，本章将通过一系列消融实验来证明本章设计方法的合理性和有效性。本章的所有消融实验都选择在图像去雾任务上进行。

（1）时间步 t_1 和 t_2 的选择

在 2.3.2节中提到，需要选取两个最具代表性的语义隐空间特征 $h_{t_1}^{haz}$ 和 $h_{t_2}^{haz}$ 注入到图像复原网络中来引导图像复原过程。其中，$h_{t_1}^{haz}$ 旨在有效表征图像的底层内容，而 $h_{t_2}^{haz}$ 则专注捕捉雾霾的特性。而这就需要合理确定时间步 t_1 和 t_2 的取值。正如 2.3.1节所讨论的，不同时间步 t 下的扩散模型语义隐空间特征表现出不同的特性。随着时间步 t 的增大，隐空间特征经历了一个逐渐且连续的转换过程：从主要表征图像的底层内容逐渐过渡到主要反映图像的退化特性。图 2.5和图 2.7形象地反映了这一渐进的变化过程。从这一过程中也可以分析出，与其他时间步相比，对应于 $t=0$ 时刻的语义隐空间特征 h_0^{haz} 是最能代表输入有雾图像的底层内容信息。因此，在本章的图像去雾任务中，t_1 设置为 0。正如图 2.14（a）所展示的，$t_1=0$ 是最佳选择。

本章进一步研究了 t_2 的选择对于图像去雾的影响。实验结果表明，当 t_2 取值约为 500 时，本章提出的图像复原方法可以在图像去雾上达到最优性能。如图 2.14（b）所示，$t_2=500$ 相比于 $t_2=100$ 在 PSNR 上提升了 1.99dB，同时也比 $t_2=600$ 提升了 2.07dB。这与图 2.5中的特征分布结果相一致。当 t_2 取值较小时（例如 $t_2=300$），有雾图像的语义隐空间特征 $h_{t_2}^{haz}$ 和清晰图像的语义隐空间特征 $h_{t_2}^{cle}$ 交织在一起，这表明此时 $h_{t_2}^{haz}$ 无法有效地表征雾霾特性。而当 t_2 约为 500 时，$h_{t_2}^{haz}$ 出现了较为紧密的聚集现象，表明此时 $h_{t_2}^{haz}$ 能够有效捕捉并表示图像中的雾霾特性。需要注意的是，无论是 t_1 还是 t_2，当它们取值过大时（例如 $t_1=1000$ 或 $t_2=1000$），本章提出方法的去雾性能都会出现明显下降。这主要是由于此时过强的噪声导致原始有雾图像 x 中的大量信息被抹除，使得对应的语义隐空间特征难以有效发挥作用。

中国知网　https://www.cnki.net

表 2.5　内容融合模块和退化感知增强模块在 PSNR 指标上的消融实验

模型	内容融合模块	退化感知增强模块	SOTS	Dense-Haze	NH-HAZE
模型 1	×	×	36.65	14.32	18.11
模型 2	×	√	38.21	16.04	18.64
模型 3	√	×	38.44	16.15	19.16
本章方法	√	√	**40.33**	**16.97**	**20.29**

（2）内容融合模块和退化感知增强模块的有效性分析

本章提出的扩散模型语义隐空间启发的图像复原网络有两个核心模块，即内容融合模块和退化感知增强模块。其中，内容融合模块旨在利用 $h_{t_1}^{haz}$ 促进图像内容的恢复，而退化感知增强模块则利用 $h_{t_2}^{haz}$ 提升网络的去除退化的能力。为了评估这两个模块的有效性，本章设计了多个变体模型，如表 2.5所示。其中，模型 2 表示每个图像复原网络块中的内容整合模块被有近似参数量的自注意力（self-attention）模块替换；类似地，模型 3 表示每个图像复原网络块中的退化感知增强模块被有近似参数量的自注意力模块替换；而模型 1 则表示两个模块都被自注意力模块替换的情况。本章通过这三种实验配置，来探究每个模块对于提升图像复原效果的有效性。

从实验结果上可以看出，模型 2 和模型 3 在 SOTS、Dense-Haze 和 NH-HAZE 数据集上的 PSNR 值分别比模型 1 提高了 1.56dB、1.72dB、0.53dB 和 1.79dB、1.83dB、1.05dB。当同时加入两个模块时，本章方法在 SOTS、Dense-Haze 和 NH-HAZE 数据集上分别达到了 40.33dB、16.97dB 和 20.29dB，显著优于其他变体模型。这一实验结果充分证明了内容融合模块和退化感知增强模块具有互补性，并且二者都对本章提出的图像复原网络至关重要，共同提升了图像复原的性能。

（3）扩散模型语义隐空间特征有效性分析

为了进一步评估扩散模型语义隐空间特征在图像复原任务中的有效性，本章将其与其他特征空间进行对比。具体而言，本章不仅将语义隐空间与同一扩散模型中其他不同层的特征空间进行比较，同时也与其他预训练网络的特征空间进行对比。表 2.6展示了对比实验的结果。在与相同扩散模型不同层的对比实验中，模型 E 和模型 D 分别表示使用相同预训练扩散模型的编码器和解码器中提取的特征替换语义隐空间特征 $h_{t_1}^{haz}$ 和 $h_{t_2}^{haz}$。从实验结果可以看出，相较于编码器和解码器的特征，语义隐空间特征在 SOTS，Dense-Haze 和 NH-HAZE 数据集上的 PSNR 值分别提升了 3.81dB，3.11dB，2.76dB 和 1.23dB，0.53dB，0.41dB。这表明相比于扩散模型其他层的特征，语义隐空间的特征在图像复原任务中更为有效。在不同网络的对比实验中，本章选择了常用的 VGG16[134] 和 ResNet50[135] 作为基准模型。需要注意的是，为了确保公平性，这两个网络均在 ImageNet[121] 数据集上进行了预训练，而该数据集与本章方法中使用的扩散模型 ϵ_θ 的预训练数据集相同。在表 2.6中，模型 V 和模型 R 分别表示使用从 VGG16 和 ResNet50 特

中国知网　https://www.cnki.net

表 2.6　不同特征空间在 PSNR 指标上的消融实验

数据集	相同扩散模型不同层比较			不同预训练网络比较		
	模型 E	模型 D	本章方法	模型 V	模型 R	本章方法
SOTS	36.52	39.10	**40.33**	27.83	25.49	**40.33**
Dense-Haze	13.86	16.44	**16.97**	12.87	12.52	**16.97**
NH-HAZE	17.53	19.88	**20.29**	16.23	15.62	**20.29**

征空间中提取的特征替换掉扩散模型语义隐空间特征 $h_{t_1}^{haz}$ 和 $h_{t_2}^{haz}$。实验结果表明，相较于从其他预训练模型中提取的特征，来自预训练扩散模型语义隐空间中的特征能更有效地提升图像复原的性能。

2.5　本章小结

本章提出了一个基于扩散模型先验信息的图像复原方法。具体来说，本章首先系统探索了预训练扩散模型语义隐空间的特性，并揭示了退化图像在该空间的表征随着扩散时间步长的变化呈现渐进式变化：从主要编码图像的底层内容，到逐渐捕捉图像的退化特性。基于这一观察，本章设计了一个基于扩散模型隐空间特征引导的图像复原网络，通过针对性设计的模块有效整合扩散模型的语义特征，并利用其引导图像复原过程。在多个任务和数据集上的实验结果验证了本章所提方法在图像复原上的优异性能。本章所提的方法为图像复原范式的拓展提供了新的思路，并为进一步挖掘扩散模型在图像复原中的潜力提供了参考。本章部分内容在 2024 年发表于计算机视觉会议 European Conference on Computer Vision (ECCV)。

中国知网　https://www.cnki.net

第 3 章　基于多视角空间关系探索的图像复原方法

3.1　引言

在前一章中，探究了预训练扩散模型语义隐空间表征的特性，并利用该特性提升单张图像复原的效果。本章则在前一章单张图像复原的基础上更进一步，将研究视野拓展至更具挑战的多视角场景下的图像复原。多视角成像系统从不同位置和角度采集同一场景的图像，为视觉任务提供了丰富且互补的空间信息。而多视角图像复原技术也是基于这一特性，通过探索和融合多个视角间的互补信息，实现跨视角间图像的协同复原。在各类多视角成像系统中，双目成像系统因其在实际应用中的广泛部署具有特殊的研究价值。因此，双目图像复原作为经典且极具实用意义的多视角图像复原技术，成为了本章研究的重点。

近年来，研究者们设计了许多基于深度学习的方法[136-144]用于复原双目图像对，并取得了显著的成果。例如，Dai 等人[145]采用递归结构实现了图像超分辨和视差估计的联合处理；Wang 等人[86]设计了双向视差注意力模块，以实现双目图像间信息的高效交互。然而，这些方法大多基于卷积神经网络，受限于局部感受野，难以有效建模双目图像之间的全局关联性。一般来说，双目图像复原包含两个关键步骤：对齐与融合。以恢复左视图为例，首先需要将右视图特征变换到左视图以实现视角的对齐，而后将变换特征与左视图特征进行融合，从而利用不同视角间的信息进行图像复原。在此过程中，左视角被称为目标视角，右视角被称为源视角，而从右视图变换到左视图的特征被称为变换特征。而当下双目图像复原所面临的挑战主要体现在两个方面：（1）如何精准对齐左右视角以建模双目图像间的跨视角对应关系；（2）如何有效融合左右视角间的信息，以实现高质量的双目图像重建。

针对第一个跨视角特征对齐问题，当前方法可以分为基于视差估计和基于视差注意力两种思路。基于视差估计的方法[145]通过构建代价体（Cost Volume）来获得视差图（Disparity Map），并利用该视差图对左右两个视角进行对齐。该类方法将视差估计视为一个独立的过程，不仅增加了计算开销，同时在处理遮挡区域时表现较差。另一方面，基于视差注意力（Parallax Attention）的方法[86,138,140]采用交叉注意力（Cross-Attention）模块，在极线约束（Epipolar Constraint）条件下捕捉双目图像之间的关系，并据此进行特征对齐。该类方法在灵活性和鲁棒性方面表现更优。然而，由于这些方法仍然基于卷积神经网络架构，其局部感受野的限制使得它们难以有效建模全局的跨视角对应关系，从而影响双目图像复原的整体效果。

针对第二个跨视角信息融合的问题，通过上述的跨视角对齐，可以得到源视

中国知网　https://www.cnki.net

图特征通过对齐得到的变换特征。现有大多数方法[86,140]仅简单地将目标视图特征与来自源视图的变换特征拼接，随后通过若干卷积层进行特征融合。然而，这种直接的融合方式忽略了在对齐阶段可能引入的目标视图特征与变换特征之间的错位问题，导致信息交互效率低下，不同视角间的信息融合效果受限，从而影响了最终图像复原的性能。

为了解决上述问题，本章将研究思路转向 Transformer[28]架构。相比于卷积神经网络，Transformer 拥有更强的全局建模能力，能够更加全面精准地捕捉双目图像间的对应关系。因此，本章提出了一个基于 Transformer 架构的双目图像复原网络。该网络旨在充分利用双目图像左右视角间的关联性，以提升双目图像复原的质量。在本章提出的方法中，双目图像的信息交互采用由粗到细的方式进行，首先从全局视角捕捉长距离对应关系，并进一步在局部邻域内提取细粒度信息。具体而言，本章首先设计了一个基于 Transformer 架构的双目对齐模块，在特征层面对源视图和目标视图进行对齐。该模块能够在极线约束下通过全局感受野充分探索左右视图之间的对应关系。需要注意的是，在经过对齐操作后，目标视图的特征与源视图经过变换得到的变换特征应达到对齐状态。然而，由于两个特征在极线方向上对应像素之间仍然可能存在微小的视差，为此，本章设计了一个基于 Transformer 架构的双目融合模块，在局部区域内进一步实现双目图像间的信息交互。该融合模块在小范围水平邻域内学习两个特征图对应像素间的相关性，并精准地实现特征的融合。与传统的基于卷积神经网络的粗糙融合方法相比，本章提出的融合模块能够实现更加精准的特征融合。

本章的所提出的主要内容和贡献可以总结如下：（1）开创性地将 Transformer 架构引入到双目图像复原领域，通过利用 Transformer 强大地捕获长距离空间依赖关系的能力，对双目视角间的对应关系进行精准建模，从而提升双目图像的复原质量。（2）提出了基于 Transformer 架构的双目对齐模块，沿着极线方向对双目图像间的对应关系进行建模。同时设计了基于 Transformer 架构的双目融合模块，在特征层面实现跨视角信息的精准融合。（3）在多个公开数据集上进行了大量定量和定性实验，并通过实验结果证明了本章提出方法在双目图像复原任务上的有效性。

本章的后续安排如下： 3.2节对双目拍摄系统的基本原理以及双目图像复原技术进行介绍，以期对双目图像之间的关系有所了解，并对双目成像系统和双目图像复原任务有所熟悉；3.3节详细介绍了本章所提的基于 Transformer 架构的双目图像复原网络，并详细介绍了用于左右视角信息对齐的双目对齐模块，以及用于视角信息融合的双目融合模块。 3.4节在多个任务和公开数据集上验证了本章所提出方法的有效性，并与现有的单目和双目图像复原方法进行定量和定性的比较。最后， 3.5节对本章所提方法进行总结。

中国知网　https://www.cnki.net

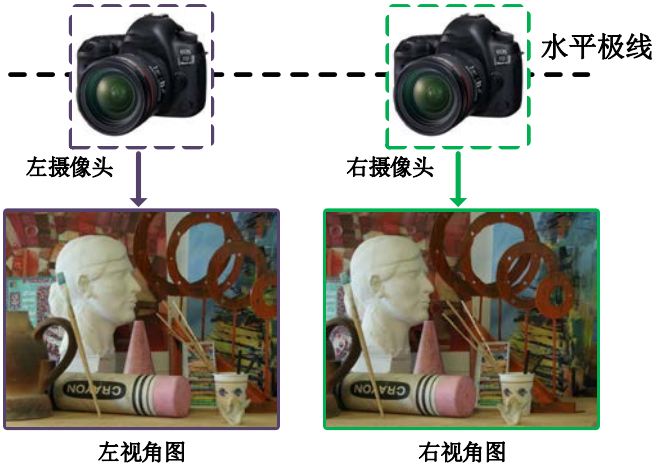


图 3.1　双目立体视觉成像系统

3.2　双目图像成像原理

双目图像是通过双目立体成像系统拍摄采集得到的。双目立体成像系统由左摄像头和右摄像头组成，两个摄像头通常按照同一水平线进行排列，用于获取同一场景的两张图像，如图 3.1所示。通过这种成像方式采集到的左视图 x_L 和右视图 x_R 带来了水平极线约束，即左视图中某个像素点 (i_L, j_L) 和其在右视图中的对应点 (i_R, j_R)，会满足条件 $j_L = j_R$。这意味着，当在右视图中寻找左视图 (i_L, j_L) 的匹配点时，只需要沿着水平方向搜索，而不需要在整个图像空间中寻找。而左右视图对应点的水平坐标之差通常被称为视差（Disparity），即 $d = i_L - i_R$。该视差与物体深度相关。

而在图像复原任务中，传统的单目图像复原是对单张退化图像进行复原，通常只能依靠该图像自身的内容进行推理。由于缺乏额外视角的信息补充，图像复原模型往往需要依赖图像内部自身的纹理结构信息进行修复。而双目图像复原任务则需要对左、右视角两幅退化图像进行修复。相比于单目图像复原，双目图像中视角间的互补信息使得左右图像在修复过程中可以互为参考。例如，如果左视图中某个区域受损，可以利用右视图中的对应区域信息进行补偿，从而提升复原质量。同时，在双目图像复原过程也需要满足上述提到的极线约束，确保左右视图结构的一致性。

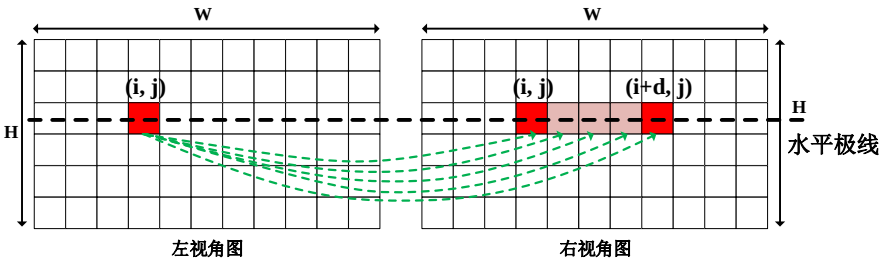


图 3.2　双目图像中的水平极线约束

中国知网　https://www.cnki.net

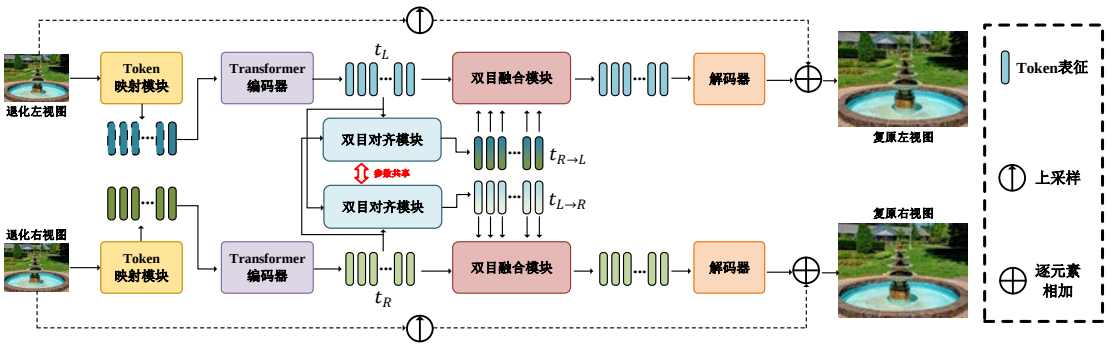


图 3.3　基于 Transformer 架构的双目图像复原网络

近年来，也有许多工作开始研究如何更好地进行双目图像的恢复。例如，Jeon 等人[146]采用级联结构，其中包含色度和亮度的超分子网络，并通过联合训练的方式学习视差先验。此外，也有许多工作[86,136,138,140,144,147]提出了多种视差注意力模块，旨在沿极线方向在像素级别上捕捉双目图像之间的对应关系并实现跨视图信息交互。视差估计是另一种常见的双目图像复原策略。Na 等人[137]设计了一种包含一个编码器和两个解码器的网络，能够同时执行深度估计和图像去雾任务。Zhou 等人[85]通过估计视差来对齐双目图像的特征，并利用一个可学习的门控网络自适应地融合特征。Dai 等人[145]指出，视差估计和双目超分辨是两个能够相互促进的任务。Yan 等人[142]进一步将估计的视差信息集成到卷积神经网络结构中，并提出特征调制密集模块以增强特征表达能力。

3.3　多视角空间关系探索与网络结构设计

在本节中，首先对本章提出的基于 Transformer 的双目图像复原网络的整体结构进行介绍。而后，具体介绍网络中的两个核心模块，即用于特征匹配的双目对齐模块和用于特征融合的双目融合模块。最后，介绍训练双目图像复原网络所使用的损失函数。

3.3.1　整体模型描述

（1）模型整体结构与前向传播流程

本章所提出的基于 Transformer 架构的双目图像复原网络的整体结构如图 3.3所示。其由一个 Transformer 编码器，一个双目对齐模块，一个双目融合模块，和一个卷积神经网络解码器组成。来自源视图的信息首先通过本章提出的双目对齐模块转换至目标视角，随后进一步通过本章提出的双目融合模块进行特征融合。需要注意的是，本章的网络结构具有高度的对称性，即针对左、右视图的网络分支共享相同的参数。

具体来说，对于一对给定的在 RGB 空间中的退化双目图像 $x_L \in \mathbb{R}^{H\times W\times 3}$

中国知网　https://www.cnki.net

（左视图）和 $x_R \in \mathbb{R}^{H\times W\times 3}$（右视图），本章旨在将它们恢复为对应的高质量清晰图像 y_L^r 和 y_R^r。给定退化双目图像 x_L 和 x_R，首先将它们送入到 token 映射模块中转换为对应的 token 表征，分别表示为 t_L 和 t_R。而后，这些 token 表征被送入到 Transformer 编码器中，以提取每个视图内的全局特征。关于 token 映射模块和 Transformer 编码器的具体结构，将在本节后半部分详细介绍。

在此之后，左视图和右视图的 token 表征被输入到本章提出的双目对齐模块中进行全局对应关系的建模，并得到转换后的 token 表征 $t_{R\to L}$ 和 $t_{L\to R}$。其中，$t_{R\to L}$ 表示右视图为源视图，对齐到左视图后的变换 token 表征，而 $t_{L\to R}$ 则表示左视图为源视图，对齐到右视图后的变换 token 表征。与传统 Transformer 中的全局交叉注意力模块不同，本章利用极线约束对双目图像的对应关系进行建模。随后，t_L，t_R，$t_{R\to L}$ 和 $t_{L\to R}$ 都被输入到双目融合模块中进行进一步的信息交互。在双目融合模块中，变换后的 token 表征 $t_{R\to L}$ 和 $t_{L\to R}$ 将分别与目标视图中的 t_L 和 t_R 进行融合，从而将源视图中的补充信息引入到目标视图中，以实现更加有效的图像复原。最后，采用基于卷积神经网络的解码器进行高质量图像的重建。该解码器由多个残差通道注意力模块组成，以恢复出高质量图像。在图像超分辨任务中，本章使用子像素层（Sub-Pixel Layer）来生成超分辨后的图像。

（2）Token 映射模块

Token 映射模块的作用是将原始 RGB 空间的图像映射为 Transformer 网络可以接受的 token 表征。而将图像转换为 token 表征的最常见方法是将图像划分为非重叠的图像块，然后通过线性投影将其映射为 token 表征[148]。然而，这种策略往往会带来较高的计算资源消耗和显存占用，对于轻量级的图像复原网络来说并不合适。因此，本章采用了一种新的 token 表征计算策略。具体而言，输入图像 x_L 和 x_R 首先通过多个堆叠的卷积层以提取浅层特征，并将其映射到 Transformer 对应的特征维度。通过该过程可以获得对应的特征表示 $F_L, F_R \in \mathbb{R}^{h\times w\times C}$。其中，$h$ 和 w 代表特征图的高度和宽度，C 代表特征图的通道维数。随后，对得到的特征图的空间维度进行展平，从而得到最终的 token 表征。如上所述，给定输入双目图像 $x_L, x_R \in \mathbb{R}^{H\times W\times 3}$，最终可以获得对应的 token 表征 $t_L, t_R \in \mathbb{R}^{P\times C}$，其中 $P = h \times w$，代表 token 表征的数量。

（3）Transformer 编码器

图 3.4展示了 Transformer 编码器的详细结构。本章采用了标准的 Transformer 模块作为编码器，以学习输入图像的全局特征。每个 Transformer 模块由多头自注意力（Multi-Head Self-Attention）模块和多层感知机（Multi-Layer Perceptron）组成，并在各个子模块中引入了跳跃连接。本章采用 LayerNorm[149] 作为归一化层，并使用 GELU[150] 作为非线性激活函数。此外，本章在 Transformer 编码器中添加了一维可学习的位置嵌入（position embedding）$p \in \mathbb{R}^C$ 以保留位置信息[29]。

中国知网　https://www.cnki.net

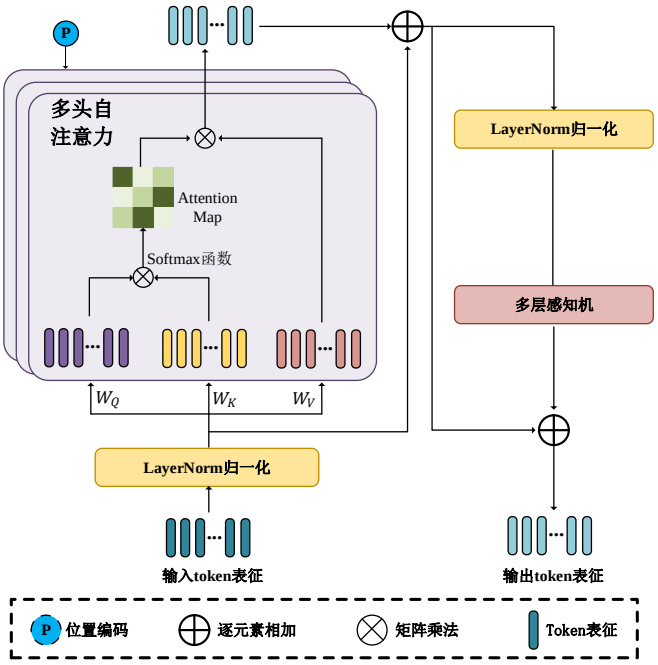


图 3.4　Transformer 编码器结构

每个 Transformer 模块中的前向传播过程可以表示为：

$$t^0 = \mathrm{TM}(x) + p, \tag{3.1}$$

$$\hat{t}^n = \mathrm{MHSA}(\mathrm{LN}(t^{n-1})) + t^{n-1}, \tag{3.2}$$

$$t^n = \mathrm{MLP}(\mathrm{LN}(\hat{t}^n)) + \hat{t}^n, \tag{3.3}$$

其中，TM 代表 token 映射模块，MHSA 代表多头自注意力模块，MLP 代表多层感知机，LN 代表 LayerNorm 归一化层。$n \in 1, ..., N$，其中 N 为 Transformer 编码器中 Transformer 模块的数量。

多头自注意力模块是 Transformer 编码器的核心组件之一，其结构如图 3.4所示。其通过在多个头中执行自注意力机制来捕捉不同的特征表示。具体来说，对于每个头，其输入 token 表征为 F，首先通过线性变换得到查询（Query）、键（Key）和值（Value）特征 Q，K 和 V，该过程可以表示为：

$$Q = W_Q F, \quad K = W_K F, \quad V = W_V F, \tag{3.4}$$

其中，W_Q，W_K 和 W_V 是可训练映射矩阵。而后，计算注意力输出：

$$\mathrm{head} = \mathrm{Attention}(Q, K, V) = \mathrm{Softmax}(\frac{QK^T}{\sqrt{C_k}})V, \tag{3.5}$$

其中，C_k 是单个头的注意力维度，通常设置为 $C_k = C/h$，C 代表 Transformer 维数，h 代表注意力头的数量。最终，将每个头的输出结果拼接并进一步映射，便可以得到最终的多头注意力输出，该过程可以表示为：

$$\mathrm{MHSA}(F) = W_O \cdot \mathrm{Concat}(\mathrm{head}_1, \mathrm{head}_2, ..., \mathrm{head}_h), \tag{3.6}$$

中国知网　https://www.cnki.net

其中，W_O 代表输出映射矩阵，Concat 代表拼接操作，head_i 代表第 i 个注意力头的输出。

3.3.2　双目对齐模块

在双目图像复原过程中，双目视图之间的对齐起着至关重要的作用。本章设计了一种基于 Transformer 架构的双目对齐模块，利用 Transformer 将源视图的特征对齐至目标视图，如图 3.5所示。不同于标准的 Transformer 模块计算图像中所有像素间关系的注意力计算方式，本章提出的双目对齐模块沿左右图像的极线方向计算像素间的注意力，以捕捉它们之间的水平对应关系。

本节以左视图作为目标视图，右视图作为源视图为例说明双目对齐模块的运作机理。给定左右视图的输入 token 表征 (t_L, t_R)，首先将左视图 token 表征映射为查询特征 Q，将右视图 token 表征映射为键、值特征 K、V，该过程可以表示为：

$$Q = W_Q \cdot t_L, \quad K = W_K \cdot t_R, \quad V = W_V \cdot t_R, \tag{3.7}$$

其中，$W_Q, W_K, W_V \in \mathbb{R}^{C\times C}$ 为可学习的映射矩阵。而后，计算查询特征 Q 和键特征 K 之间的相似度矩阵，并进一步通过 Softmax 函数进行归一化以得到注意力图。具体而言，针对一组批量大小为 B 的查询向量 $Q \in \mathbb{R}^{B\times P\times C}$，其中 $P = h\times w$，首先对其形状进行变换，得到 $Q \in \mathbb{R}^{Bh\times w\times C}$。键向量 K 也进行相同变换，得到 $K \in \mathbb{R}^{Bh\times w\times C}$。需要注意的是，这里将高度维度 h 与批次维度 B 进行合并，而宽度维度 w 保持独立。变换的目的是将注意力机制的计算限制在每一行内进行，使得目标视图中的每一个像素只与源视图中位于同一水平线上的像素进行交互，从而保证计算过程满足水平极线约束。而后，对键向量进行转置，使其转变为 $K \in \mathbb{R}^{Bh\times C\times w}$，并与查询向量进行缩放点积计算，以获得分数图。在此之后，再对该分数图应用 Softmax 函数从而得到最终的注意力图，该过程可以表示为：

$$\text{Attn_Map} = \text{Softmax}(\frac{QK^T}{\sqrt{C}}), \tag{3.8}$$

其中，$\text{Attn_Map} \in \mathbb{R}^{Bh\times w\times w}$，其代表源视图中每个像素对目标视图中各像素的贡献，同时也编码了双目图像之间的视差信息。

之后，将得到的注意力图应用于值向量中，可以得到输出结果，该过程可以表示为：

$$V_O = W_O \cdot (\text{Attn_Map} \cdot V), \tag{3.9}$$

其中，$W_O \in \mathbb{R}^{C\times C}$ 代表可学习映射矩阵。最后，特征通过一个带有残差连接的多层感知机得到最后的输出结果，该过程可以表示为：

$$V_O = \text{MLP}(\text{LN}(V_O)) + V_O. \tag{3.10}$$

中国知网　https://www.cnki.net

此时，得到的 V_O 代表从源视图映射到目标视图的 token 表征。本章提出的双目对齐模块以双向的方式进行计算，一方面用于获得从右视图到左视图的变换 token 表征 $t_{R\to L}$，另一方面也用于获得从左视图到右视图的变换 token 表征 $t_{L\to R}$。

可以看出，在标准的自注意力模块中，查询、键、值特征均是由同一张图像计算得到的，并且在计算注意力图时，并未引入任何空间的约束。相比之下，本节提出的双目对齐模块中使用了交叉注意力，查询特征由目标视图计算得到，而键和值特征则由源视图计算得到。同时，在计算注意力图时，引入了水平极线的约束，确保注意力机制遵循双目几何关系。需要注意的是，标准的交叉注意力模块通过全局探索来学习不同视图之间的关系，如图 3.7（a）所示。与之不同的是，本章提出的双目对齐模块则专注于捕捉双目图像之间的水平对应关系，如图 3.7（b）所示。

关于位置编码，本章在将 token 表征送入双目对齐模块的多头交叉注意力模块之前，对其添加了相对位置编码。需要注意的是，本章选择使用相对位置编码来表示像素之间的相对距离，而非绝对位置编码，这是因为相对位置编码能够更有效地处理大面积低频区域中像素之间的模糊相似性问题[151]。

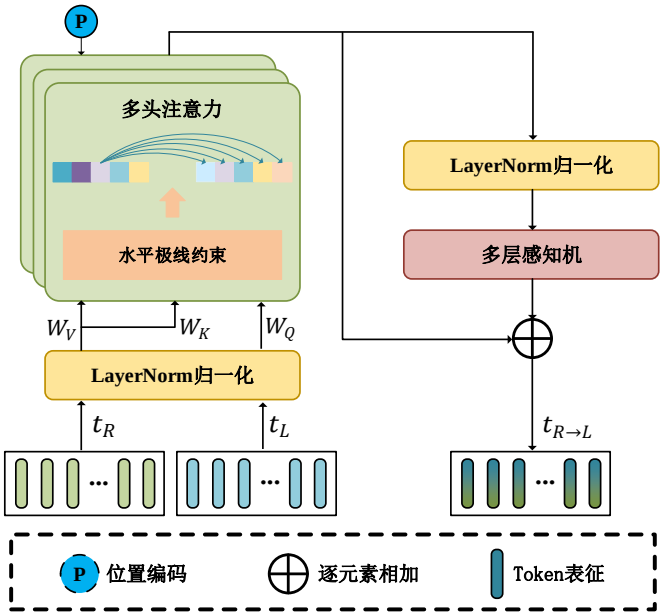


图 3.5　基于 Transformer 的双目对齐模块

3.3.3　双目融合模块

双目视图信息的融合在双目图像复原中同样起着至关重要的作用，其核心目标是整合来自目标视图的信息以及从源视图变换得到的信息。然而，现有方法通常直接将目标视图特征与变换得到的特征拼接，并输入到多个堆叠的卷积层中进行处理。这种粗糙的融合方式可能无法有效地整合双目信息，进而导致前期

中国知网　https://www.cnki.net

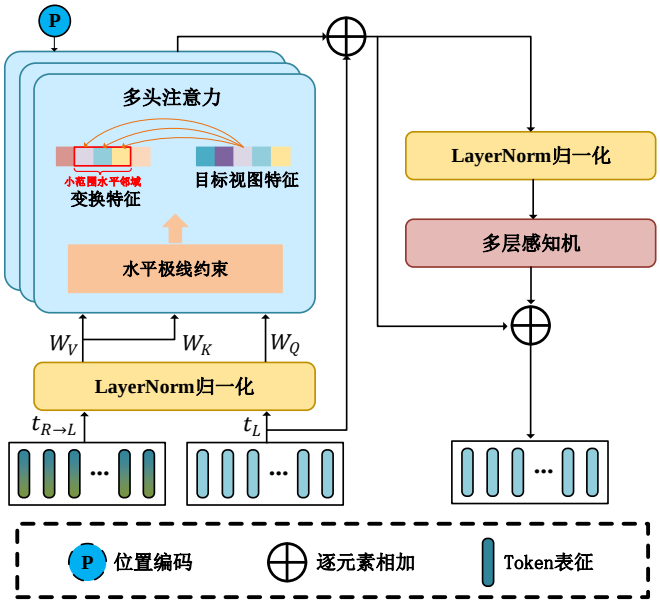


图 3.6　基于 Transformer 的双目融合模块

对齐阶段的误差出现积累，使后续的重建性能受到影响。为了解决这个问题，本节提出了一种双目融合模块，使用 Transformer 高效精准地聚合双目图像中的信息，如图 3.6所示。

在经过 3.3.2节中所提出的双目对齐模块处理后，目标视图特征 (t_L, t_R) 与变换后的特征 $(t_{R\to L}, t_{L\to R})$ 之间仍然可能存在一定程度的未对齐。然而，这种对应像素之间的未对齐误差通常不会很大，并且应受限于较小的水平邻域范围内。因此，对于目标视图特征中的每个像素，本节进一步在探索其与对应的变换特征中相应位置邻域内的对应关系，以进一步消除对齐误差。由于这种误差仅沿水平方向存在，因此，所提出的双目融合模块与双目对齐模块一样，满足水平极线约束。

具体来说，给定目标视图 token 表征 $t(t \in t_L, t_R)$ 以及对应的变换特征 $t_w(t_w \in t_{R\to L}, t_{L\to R})$，首先将给定目标视图 token 表征映射为查询特征，对应的转换特征映射为键和值特征，该过程可以表示为：

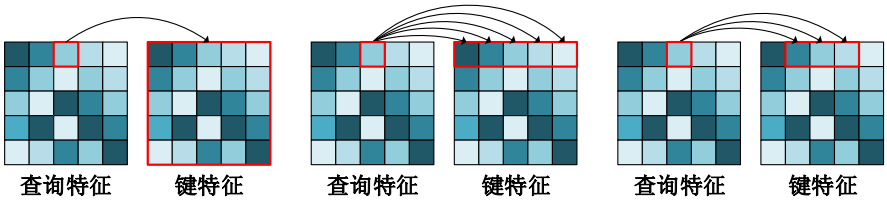
$$Q = W_Q \cdot t, \quad K = W_K \cdot t_w, \quad V = W_V \cdot t_w, \tag{3.11}$$

其中，W_Q，W_K 和 W_V 都为可学习的映射矩阵。而后，计算注意力图，该过程可以表示为：

$$\text{Attn_Map} = \text{Softmax}(\frac{Q(K \odot M)^T}{\sqrt{C}}), \tag{3.12}$$

其中，M 为一个由 0 和 1 构成的掩码，其用于确保 Q 中的每个像素只能与 K 中对应位置的水平邻域进行交互。$\odot$ 表示哈达玛积。得到注意力图后，后续的特征操作与 3.3.2中所描述的双目对齐模块的操作相似，完成整个注意力计算过程之

中国知网　https://www.cnki.net



（a）Transformer编码器模块中的注意力　（b）双目对齐模块中的交叉注意力　（c）双目融合模块中的交叉注意力

图 3.7　双目图像复原网络中不同模块注意力计算方式对比

后再通过多层感知机进行进一步映射，该过程可以表示为：

$$V_O = W_O(\text{Attn_Map} \cdot V) + t, \tag{3.13}$$

$$V_O = \text{MLP}(\text{LN}(V_O)) + V_O, \tag{3.14}$$

在本章所提出的双目图像复原网络中，尽管多头注意力机制在 Transformer 编码器、双目对齐模块和双目融合模块中都有应用，但其应用方式存在显著差异。如图 3.7所示，在 Transformer 编码器的自注意力模块中，查询特征中的每个像素值会与整个键特征进行交互，从而捕捉图像的全局特征。然而，在双目对齐模块的交叉注意力中，由于视差仅沿水平方向存在，所以查询特征中的每个像素仅能与键特征中处于同一水平极线上的像素进行交互。而在双目融合模块的交叉注意力中，交互的区域在满足极线约束的前提下被进一步压缩至对应像素的水平邻域内，从而实现对应区域信息的精准融合。

3.3.4　损失函数

重建损失函数。重建损失函数被定义为双目复原图像与其对应的双目高质量清晰图像之间的距离，具体计算公式可以表示为：

$$\mathcal{L}_{recon} = \|y_L^r - y_L\|_1 + \|y_R^r - y_R\|_1, \tag{3.15}$$

其中，y_L^r 和 y_R^r 分别代表修复的左视图和右视图，而 y_L 和 y_R 则代表对应与 y_L^r 和 y_R^r 的高质量清晰图像，$\|\cdot\|_1$ 代表 L1 范数。

双目一致性损失函数。在双目图像复原任务中，从源视图变换得到的信息应与目标视图充分对齐，即保证复原后左右图像间仍然满足双目几何条件。因此，本章提出了一种双目一致性损失函数，用以约束本章所提双目对齐模块和双目融合模块的训练，从而实现双目图像间高效的信息交互。具体而言，对于双目复原图像 y_L^r 和 y_R^r，可以利用它们分别得到注意力图 $M_{R\to L}$ 和 $M_{L\to R}$，该过程可以表示为：

$$M_{R\to L} = \text{Softmax}((y_L^r)^T \cdot y_R^r), \tag{3.16}$$

$$M_{L\to R} = \text{Softmax}((y_R^r)^T \cdot y_L^r), \tag{3.17}$$

中国知网　https://www.cnki.net

而后，将变换信息与对应的高质量清晰图像之间的距离作为双目一致性损失函数，该过程可以表示为：

$$\mathcal{L}_{cons} = \|M_{R\to L} \cdot y_R^r - y_L\|_1 + \|M_{L\to R} \cdot y_L^r - y_R\|_1, \tag{3.18}$$

最终损失函数。训练本章所提出的双目图像复原网络的最终损失函数为上述 $\mathcal{L}_{recon}$ 与 $\mathcal{L}_{cons}$ 的组合，该过程可以表示为：

$$\mathcal{L}_{total} = \mathcal{L}_{recon} + \lambda \mathcal{L}_{cons}, \tag{3.19}$$

其中，λ 代表平衡系数，根据经验在本章实验中设置为 0.01。

3.4　实验分析

3.4.1　数据集和评价指标

为了评估本章提出的双目图像复原网络的有效性，本章选择在三个常见的双目图像复原任务上进行测试，包括双目图像超分辨率、双目图像去模糊和双目图像去雨。本章使用的训练与测试数据大多通过对双目图像数据集进行仿真的方式获得的。对于双目图像超分辨率任务，本章选取 Middlebury 数据集[152]中的 60 张图像以及 Flickr1024 数据集[153]中的 800 张图像作为训练集。本章使用双三次插值（bicubic）下采样的方法生成低分辨率图像，并裁剪成 30×90 大小的图像块，裁剪步长设置为 20。测试集数据则由来自 Middlebury 数据集的 5 张图像、KITTI2012 数据集[154]的 20 张图像、KITTI2015 数据集[155]中的 20 张图像以及 Flickr1024 数据集的测试集组成。针对双目图像去模糊任务，本章通过对高质量清晰图像使用模糊核进行卷积以得到模糊图像。具体来说，使用的模糊核大小为 15×15，并且模糊核的标准差 σ 从区间 $[0.1, 0.4]$ 中随机采样。训练样本从 Middlebury 和 Flickr1024 数据集中裁剪得到的，裁剪的图像块尺寸为 30×90。测试数据选取与图像超分辨率相似的数据，包括来自 Middlebury、KITTI2012 和 KITTI2015 数据集中的图像。针对图像去雨任务，本章采用了与图像去模糊相似的操作，合成了双目雨图像。训练和测试数据来源于双目图像去模糊相同。为了衡量复原效果，本章采用了上一章中使用的峰值信噪比（PSNR）和结构相似性指数（SSIM）作为评测指标。

3.4.2　实验设置

为了提升本章提出的双目图像复原网络在图像复原任务上的能力，本章采用了以下的训练策略和参数配置。在训练过程中，使用 Adam 优化器。其中，参数 β_1，β_2，和 γ 分别设置为 0.9，0.999，和 0.5。初始学习率设置为 8×10^{-4}，并

中国知网　https://www.cnki.net

且随着训练迭代次数的增加逐步减小，这不仅可以确保训练过程的稳定，还有助于图像复原网络参数收敛到最优解。训练的总迭代轮数设置为 80。训练时每次迭代输入的批量大小设置为 40。在训练过程中，引入了图像随机水平或垂直翻转的数据增强技术，以增加数据多样性并提升图像复原模型对于不同方向图像特征的适应能力。本章所有的实验都在两张 NVIDIA 2080Ti GPU 上完成。

3.4.3　性能比较

（1）双目图像超分辨率性能比较

对比的基准方法。为了验证本章提出的双目图像复原方法在图像超分辨率上的有效性，本章引入若干图像超分辨率方法进行性能对比。其中即包括单目图像超分辨率方法，如 VDSR[156]，EDSR[10]，RDN[32] 以及 RCAN[27]，也包括双目图像超分辨率方法，如 StereoSR[146]，PASSRnet[140]，SRResNet+SAM[157]，以及 iPASSR[86]。为了公平比较，本章将这些方法在相同数据集上进行了重新训练。对于双目图像复原方法，由于其网络设计中包含了同时接受左视图和右视图的设计，所以左右视图的复原结果是一次性输出的。对于单目图像复原方法，由于其网络一次只能接受一张输入图像，所以本章分别将左右视图输入，而后分别得到左视图和右视图的复原结果。

定量结果比较。为了全面衡量本章所提方法在双目图像超分辨率上的性能，本章选择在 2 倍超分辨率和 4 倍超分辨率两个不同超分辨率倍率下验证本章方法的有效性。在计算定量指标时，本章既单独衡量左视图的视觉指标，同时也计算左视图与右视图两者指标的平均值。在单独计算左视图的 PSNR 与 SSIM 指标时，会裁剪掉左侧边界 64 个像素之后再进行评估。在计算双目图像对的平均 PSNR 和 SSIM 指标时，不进行边界裁剪。

表 3.1和表 3.2分别展示在 KITTI2012、KITTI2015、Middlebury 和 Flickr1024 四个数据集上，双目图像超分辨率任务中左视图和双目图像对平均评测结果。加粗标注的数值表示最好结果，下划线标注的数值表示次好结果。表 3.1同时标注了不同方法的网络参数量。可以看出，在 2 倍和 4 倍两个超分辨率任务上，本章提出的方法在 PSNR 和 SSIM 指标上超过了所有比较的方法，包括单目图像超分辨率的方法和双目图像超分辨率的方法，包括 iPASSR、PASSRnet 等基于卷积神经网络和极线约束注意力模块的双目图像超分辨率方法。以双目图像对平均评测指标为例，在 2 倍超分辨率任务中，本章方法相比于先进双目图像超分辨率方法 iPASSR，在 KITTI2012、KITTI2015、Middlebury 和 Flickr1024 数据集上，在 PSNR 指标上分别领先 0.05dB、0.12dB、0.44dB 和 0.03dB。即使是在难度更高的 4 倍超分辨率任务中，本章方法的定量评测指标也在四个数据集中领先与基准方法。这充分证明了本章所提双目图像复原网络在图像超分辨率任务上的有效性。

中国知网　https://www.cnki.net

表 3.1　不同方法在双目图像超分辨率任务中左视图定量比较

方法	超分倍数	左视图指标			参数量
		KITTI 2012	KITTI 2015	Middlebury	
		PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	
VDSR[156]	×2	30.17/0.9062	28.99/0.9038	32.66/0.9101	0.66M
EDSR[10]	×2	30.83/0.9199	29.94/0.9231	34.84/0.9489	38.6M
RDN[32]	×2	30.81/0.9197	29.91/0.9224	34.85/0.9488	22.0M
RCAN[27]	×2	30.88/0.9202	29.97/0.9231	34.80/0.9482	15.3M
PASSRnet[140]	×2	30.68/0.9159	29.81/0.9191	34.13/0.9421	1.37M
StereoSR[146]	×2	29.42/0.9040	28.53/0.9038	33.15/0.9343	1.08M
iPASSR[86]	×2	30.97/0.9210	30.01/0.9234	34.41/0.9454	1.37M
本章方法	×2	**31.02/0.9217**	**30.11/0.9246**	**34.87/0.9476**	1.37M
VDSR[156]	×4	25.54/0.7662	24.68/0.7456	27.60/0.7933	0.66M
EDSR[10]	×4	26.26/0.7954	25.38/0.7811	29.15/0.8383	38.9M
RDN[32]	×4	26.23/0.7952	25.37/0.7813	29.15/0.8387	22.0M
RCAN[27]	×4	26.36/0.7968	25.53/0.7836	29.20/0.8381	15.4M
PASSRnet[140]	×4	26.26/0.7919	25.41/0.7772	28.61/0.8232	1.42M
StereoSR[146]	×4	24.49/0.7502	23.67/0.7273	27.70/0.8036	1.42M
SRRes+SAM[157]	×4	26.35/0.7957	25.55/0.7825	28.76/0.8287	1.73M
iPASSR[86]	×4	26.47/0.7993	25.61/0.7850	29.07/0.8363	1.42M
本章方法	×4	**26.53/0.7964**	**25.75/0.7882**	**29.15/0.8372**	1.48M

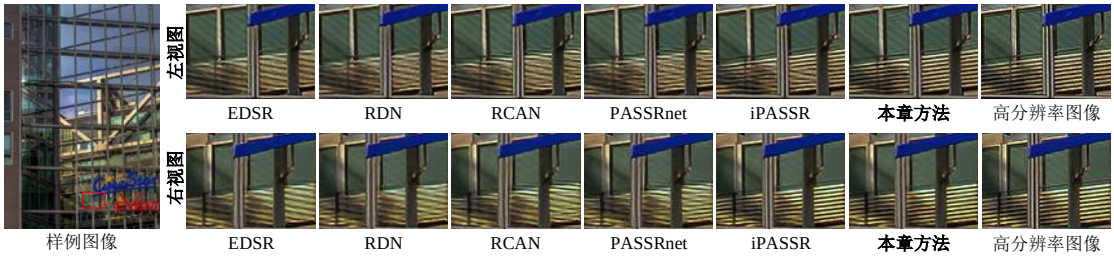


图 3.8　不同方法在 Flickr1024[153] 数据集的 2 倍双目图像超分辨率定性比较



图 3.9　不同方法在 Flickr1024[153] 数据集双目图像超分辨率定性差值比较

定性结果比较。图 3.8和图 3.10分别展示了不同方法 2 倍和 4 倍双目图像超分辨率的定性结果，而图 3.9则展示了使用不同方法得到的超分辨率图像与真实的高分辨率图像之间的差值。可以看到，许多方法难以恢复图像的细节信息和纹理边缘。例如在图 3.10中，EDSR、RDN、RCAN 和 PASSRnet 无法清晰恢复图像中文字细节，其中的字母出现明显的扭曲和失真。iPASSR 成功恢复了大部分文字内容，但是仍有部分区域显示模糊，影响视觉观感。而本章所提方法成功保

中国知网　https://www.cnki.net

表 3.2　不同方法在双目图像超分辨率任务中左右视图平均定量比较

方法	超分倍数	左右视图平均指标			
		KITTI 2012	KITTI 2015	Middlebury	Flickr1024
		PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
VDSR[156]	×2	30.30/0.9089	29.78/0.9150	32.77/0.9102	25.60/0.8534
EDSR[10]	×2	30.96/0.9228	30.73/0.9335	34.95/0.9492	28.66/0.9087
RDN[32]	×2	30.94/0.9227	30.70/0.9330	34.94/0.9491	28.64/0.9084
RCAN[27]	×2	31.02/0.9232	30.77/0.9336	34.90/0.9486	28.63/0.9082
PASSRnet[140]	×2	30.81/0.9190	30.60/0.9300	34.23/0.9422	28.38/0.9038
StereoSR[146]	×2	29.51/0.9073	29.33/0.9168	33.23/0.9348	25.96/0.8599
iPASSR[86]	×2	31.11/0.9240	30.81/0.9340	34.51/0.9454	28.60/0.9097
本章方法	×2	**31.16/0.9247**	**30.93/0.9355**	**34.95/0.9495**	**28.63/0.9103**
VDSR[156]	×4	25.60/0.7722	25.32/0.7703	27.69/0.7941	22.46/0.6718
EDSR[10]	×4	26.35/0.8015	26.04/0.8039	29.23/0.8397	23.46/0.7285
RDN[32]	×4	26.32/0.8014	26.04/0.8043	29.27/0.8404	23.47/0.7295
RCAN[27]	×4	26.44/0.8029	26.22/0.8068	29.30/0.8397	23.48/0.7286
PASSRnet[140]	×4	26.34/0.7981	26.08/0.8002	28.72/0.8236	23.31/0.7195
StereoSR[146]	×4	24.53/0.7555	24.21/0.7511	27.64/0.8022	21.70/0.6460
SRRes+SAM[157]	×4	26.44/0.8018	26.22/0.8054	28.83/0.8290	23.27/0.7233
iPASSR[86]	×4	26.56/0.8053	26.32/0.8084	29.16/0.8367	23.44/0.7287
本章方法	×4	**26.68/0.8077**	**26.42/0.8098**	**29.26/0.8392**	**23.52/0.7305**

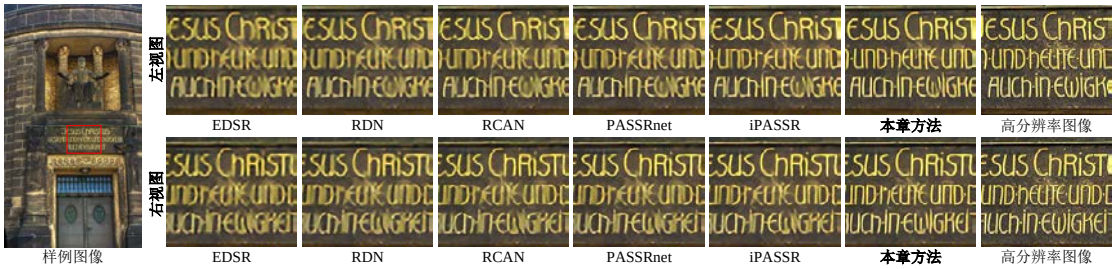


图 3.10　不同方法在 Flickr1024[153] 数据集的 4 倍双目图像超分辨率定性比较

持了文字区域的清晰度，拥有最清晰的视觉效果，这证明了本章所提方法对于双目图像内部纹理细节恢复的有效性。同时，从图 3.9可以看出，相比于其他方法，使用本章方法得到的超分辨率图像与真实的高分辨率图像之间的差异最小，这证明了所提方法在恢复双目图像内容上的准确性。

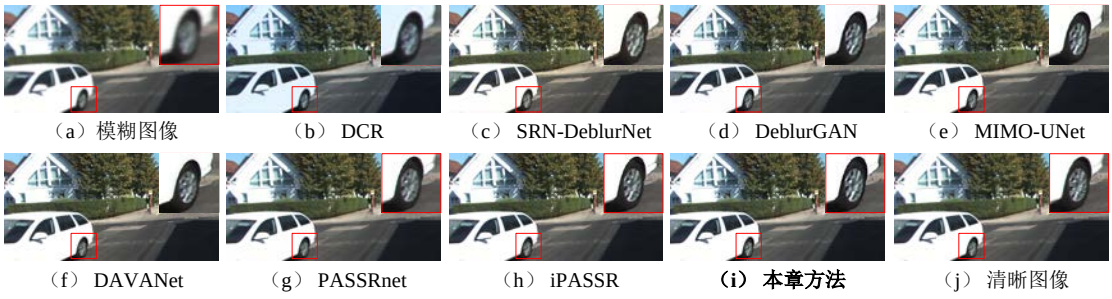
（2）双目图像去模糊性能比较

基准方法。为了进一步验证本章提出方法在双目图像去模糊任务上的有效性，本章选择了若干基于深度学习的图像去模糊方法用于比较，包括 DCR[158]，SRN-DeblurNet[159]，DeblurGAN[11]，MIMO-UNet[64]，DAVANet[85]，PASSRnet[140] 以及 iPASSR[86]。其中，PASSRnet 和 iPASSR 两个网络的原始设计是针对双目图像超分辨率任务。本章对这两个网络的结构进行了修改，删除了网络中上采样相关设计，并保留极线注意力模块这一核心组件。而后，利用双目模糊-清晰图像端到端地训练这两个网络。

中国知网　https://www.cnki.net

表 3.3　不同方法在双目图像去模糊任务中定量比较

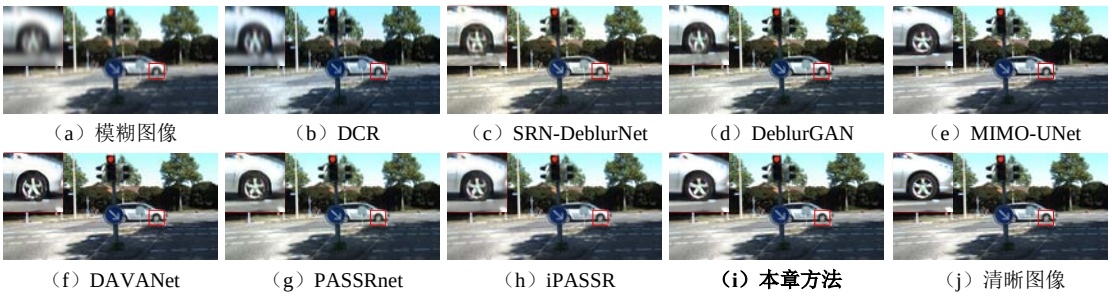
方法	KITTI2012		KITTI2015		Middlebury	
	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
DCR[158]	24.30	0.7759	24.02	0.7635	26.50	0.7543
SRN-DeblurNet[159]	26.80	0.8106	26.01	0.7971	28.25	0.8028
DeblurGAN[11]	27.20	0.8185	26.67	0.8220	28.90	0.8170
MIMO-UNet[64]	28.53	**0.8531**	27.72	0.8414	30.92	0.8502
DAVANet[85]	27.53	0.8278	26.99	0.8002	29.61	0.8181
PASSRnet[140]	28.28	0.8458	27.62	0.8188	30.35	0.8377
iPASSR[86]	28.54	0.8462	27.66	0.8324	30.74	0.8474
本章方法	**28.63**	0.8473	**27.80**	**0.8421**	**31.02**	**0.8516**



（a）模糊图像　（b）DCR　（c）SRN-DeblurNet　（d）DeblurGAN　（e）MIMO-UNet

（f）DAVANet　（g）PASSRnet　（h）iPASSR　**（i）本章方法**　（j）清晰图像

图 3.11　不同方法在 KITTI2012[154] 数据集双目图像去模糊定性比较



（a）模糊图像　（b）DCR　（c）SRN-DeblurNet　（d）DeblurGAN　（e）MIMO-UNet

（f）DAVANet　（g）PASSRnet　（h）iPASSR　**（i）本章方法**　（j）清晰图像

图 3.12　不同方法在 KITTI2015[155] 数据集双目图像去模糊定性比较

定量结果比较。表 3.3展示了不同方法在 KITTI2012,KITTI2015 和 Middlebury 三个数据集上双目图像去模糊的性能。表中数值均为左右视图指标平均结果。加粗标注的数值表示最好结果，下划线标注的数值表示次好结果。可以看到，本章提出的方法在三个数据集上都处于领先位置。值得注意的是，双目图像复原的基准方法 iPASSR 在双目图像去模糊任务中性能略微低于先进单目图像复原方法 MIMO-UNet。而本章提出的方法则在 KITTI2015 和 Middlebury 两个数据集上的 PSNR 和 SSIM 指标都超过 MIMO-UNet。在 KITTI2012 数据集上，本章所提方法在 PSNR 指标上超过 MIMO-UNet，在 SSIM 指标与其性能相当。

定性结果比较。图 3.11和图 3.12展示了本章方法和包括单目、双目图像复原方法在内的多个方法的定性比较结果。可以看出，相比与基准方法，本章所提出的方法能够从模糊图像中恢复出更加清晰图像。例如，从图 3.12可以看出，相比于双目图像复原方法 PASSRnet 和 iPASSR，本章方法可以恢复出更加清晰锐利

中国知网　https://www.cnki.net



（a）有雨图像　（b）DID-MDN　（c）DAF-Net　（d）DeHRain



（e）PASSRnet　（f）iPASSR　**（g）本章方法**　（h）清晰图像

图 3.13　不同方法在 KITTI2012[154] 数据集双目图像去雨定性比较



（a）有雨图像　（b）DID-MDN　（c）DAF-Net　（d）DeHRain



（e）PASSRnet　（f）iPASSR　**（g）本章方法**　（h）清晰图像

图 3.14　不同方法在 KITTI2015[155] 数据集双目图像去雨定性比较

表 3.4　不同方法在双目图像去雨任务中定量比较

方法	KITTI2012		KITTI2015		Middlebury	
	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
DID-MDN[58]	34.92	0.9510	34.86	0.9508	36.41	0.9699
DAF-Net[160]	35.81	0.9666	35.51	0.9584	38.72	0.9720
DeHRain[161]	35.57	0.9635	36.09	0.9616	39.66	0.9807
PASSRnet[140]	39.78	0.9891	38.85	0.9871	40.13	0.9840
iPASSR[86]	40.52	0.9899	40.17	0.9909	42.55	0.9915
本章方法	**40.75**	**0.9906**	**40.67**	**0.9914**	**44.05**	**0.9931**

的图像细节，拥有更好的视觉观感。这证明本章所提的双目对齐模块和双目融合模块在探索双目图像信息的有效性。

（3）双目图像去雨性能比较

对比的基准方法。为了进一步验证本章所提方法的有效性，本章进一步在双目图像去雨任务上验证了本章方法的有效性。本章选择了单目图像去雨方法 DID-MDN[58]，DAF-Net[160]，DeHRain[161]，以及双目图像复原方法 PASSRnet[140]和 iPASSR[86]作为基准方法用于比较。与上述图像去模糊类似，本章将 PASSRnet 与 iPASSR 的上采样设计删除，保证输入输出图像分辨率相同，同时保留极线注意力模块，并利用双目有雨-清晰图像训练这两个网络。

定量结果比较。表 3.4中展示了不同方法在 KITTI2012，KITTI2015 和 Mid-

中国知网　https://www.cnki.net

表 3.5　不同方法在双目图像去噪和复杂场景复原任务中定量比较

方法	图像去噪		复杂场景图像复原	
	左视图	左右视图平均	左视图	左右视图平均
	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
PASSRnet[140]	26.56/0.7518	27.02/0.7687	23.12/0.6336	23.51/0.6546
iPASSR[86]	26.86/0.7628	27.35/0.7803	23.55/0.6546	23.96/0.6758
本章方法	**27.27/0.7827**	**27.74/0.7983**	**23.81/0.6684**	**24.26/0.6902**



图 3.15　不同方法在双目图像去噪和复杂场景复原任务中定性比较

dlebury 三个数据集上双目图像去雨的定量结果。表中数值均为左右视图指标平均结果。加粗标注的数值表示最好性能，而使用下划线标注的数值表示次好结果。可以看出，本章所提方法在三个数据集上的 PSNR 和 SSIM 指标都优于其他方法。这证明了本章所提方法在双目图像去雨任务上的有效性。

定性结果比较。图 3.13和图 3.14展示了本章方法与其他先进图像去雨方法的定性比较结果。可以看出，本章所提的方法可以更好地恢复图像信息。例如，从图 3.13可以看出，现有基准方法复原的图像还是残留有明显的雨线痕迹。相比之下，本章的方法可以更加彻底地去除图像中的雨线退化并恢复图像纹理细节，这充分证明了本章所提方法在双目图像去雨任务上的有效性。

（4）其他场景下双目图像复原性能比较

除了以上三种双目图像复原场景，本章进一步测试了不同双目图像复原方法在图像去噪和多种退化同时共存的复杂场景图像复原这两个任务上的性能。本章选用 PASSRnet[140]和 iPASSR[86]两种双目图像复原方法作为用于对比的基准方法，并在 KITTI2015 数据集上测试双目图像去噪和复杂场景图像复原的性能。对于多种退化共存的复杂场景图像复原任务，本章对图像同时添加噪声和模糊以合成退化图像。相比于单一退化，多退化共存使得图像受到的退化影响更加复杂，相对应的图像复原过程也更具挑战。

表 3.5展示了不同方法在 KITTI2015 数据集上双目图像去噪和复杂场景下双目图像复原的定量结果。加粗标注的数值表示最好的性能。可以看出，本章所提的方法在图像去噪任务上的 PSNR 和 SSIM 指标都优于其他方法，这证明了本章方法在双目图像去噪任务上的有效性。即使是在更具挑战性的噪声与模糊共存

中国知网　https://www.cnki.net

的复杂场景双目图像复原任务上，本章方法的性能仍然由于基准方法，这进一步证明了本章方法在双目图像复原任务上的有效性。图 3.15展示了本章方法与其他双目图像复原方法的定性比较结果，其中，第一行为双目图像去噪的定性比较结果，第二行为复杂场景双目图像复原的定性比较结果。可以看出，本章所提的方法可以更好地恢复图像内容。

3.4.4　消融实验

本节通过一系列消融实验来证明本章设计的网络模块和损失函数的合理性和有效性。本章所有的消融实验都选择在 2 倍双目图像超分辨率任务上进行，实验测试数据集选择为 Middlebury，并选取左右图像平均指标作为评测结果。

（1）双目对齐模块和双目融合模块有效性分析

双目对齐模块和双目融合模块是本章所提双目图像复原网络的核心模块，前者负责跨视角特征对齐，后者负责信息融合。为了验证这两个模块的有效性，本节设计了多个变体模型，如表 3.6所示。其中，模型 2 表示将网络中双目对齐模块替换成传统的视差注意力模块来进行左右视图的特征对齐。模型 3 表示舍弃网络中双目融合模块，改为将目标视图特征与视差变换后的特征拼接，而后使用多层卷积层进行特征融合。而模型 1 则表示双目对齐模块与双目融合模块都被替换。从实验结果可以看出，与模型 1 相比，使用双目融合模块的模型 2 和使用双目对齐模块的模型 3 在 PSNR 指标上分别提升了 0.21dB 和 0.25dB，这证明了本章所提的双目对齐模块和双目融合模块可以更好地探索和融合双目图像之间的对应信息。当两种模块同时部署时，性能提升达到 0.48dB。实验结果证明了本章所提方法在双目图像复原任务上的有效性。

表 3.6　双目图像对齐和双目图像融合模块消融实验

方法	双目对齐模块	双目融合模块	PSNR	SSIM
模型 1	×	×	34.47	0.9450
模型 2	×	√	34.68	0.9470
模型 3	√	×	34.72	0.9473
本章方法	√	√	**34.95**	**0.9495**

（2）双目一致性损失函数有效性分析

为了更有效地保持双目视图之间的一致性，本章提出了一种双目一致性损失函数用于约束网络的训练。为了验证该损失函数的有效性，本节仅使用重建损失函数 $\mathcal{L}_{recon}$ 对网络进行重新训练，即表 3.7中的模型 4，并对比实验结果。如表 3.7所示，当不使用双目一致性损失函数后，左右视图的平均 PSNR 从 34.95dB 下降到 34.84dB。该结果证明了本章所提的双目一致性损失函数有助于更有效地实现双目图像复原。

（3）双目融合模块中邻域大小有效性分析

中国知网　https://www.cnki.net

表 3.7　双目一致性损失函数消融实验

方法	$\mathcal{L}_{recon}$	$\mathcal{L}_{cons}$	PSNR	SSIM
模型 4	√	×	34.84	0.9479
本章方法	√	√	**34.95**	**0.9495**

在 3.3.3节中提到，经过变换后的特征应与目标特征对齐，而对齐过程中出现的误差仅存在于对应像素的水平局部邻域内。由于邻域的大小需要手动设定，本节进一步研究了不同邻域大小的选择对双目融合模块性能的影响。需要注意的是，邻域的大小决定了键向量中需要与查询向量中对应像素进行交互的数量，如图 3.7（c）所示。表 3.8展示了双目融合模块中不同邻域大小对本章所提双目图像复原网络性能的影响。可以看到，当邻域大小设置为 5 时，网络取得了最佳性能。一方面，当邻域大小为 3 或 4 时，交互区域过小，无法充分覆盖可能的对齐误差区域。另一方面，当邻域大小增大至 6 或更大时，图像复原的性能未能获得进一步提升。这表明此时邻域已经足够覆盖目标视图特征与变换特征之间的对齐误差。因此，实验中双目融合模块的邻域大小确定为 5。

表 3.8　双目图像融合模块中邻域大小选择消融实验

邻域大小	3	4	5	6
PSNR	34.82	34.90	**34.95**	34.95
SSIM	0.9478	0.9487	**0.9495**	0.9492

3.5　本章小结

本章提出了一个基于多视角空间关系探索的图像复原方法。具体来说，本章以双目图像复原作为切入点，详细分析了现有双目图像复原过程中存在的问题，并提出了一个基于 Transformer 的双目图像复原网络。该网络通过由粗到细方式探索双目视图之间的关联性，首先利用 Transformer 强大的全局建模能力来捕捉左右视图之间的对应关系，而后在局部水平邻域内进行跨视图信息的精准融合。在多个双目图像复原任务和数据集上的定量和定性实验都验证了本章所提方法的有效性。本章内容在前一章的基础上更进一步，将图像复原的研究拓展至双目成像系统中，并为多视角图像复原技术的进一步发展提供了研究思路。本章部分内容在 2022 年发表于多媒体国际会议 ACM International Conference on Multimedia (ACMMM)。

中国知网　https://www.cnki.net

第 4 章　面向视觉识别任务的多退化统一图像复原方法

4.1　引言

在前面的两个章节中，本文着重探讨了以提升视觉质量为核心的图像复原方法，包括利用预训练扩散模型先验知识提升图像复原效果，以及在双目场景中利用 Transformer 增强跨视角图像关联性的建模。相关实验也证明了所提方法在提升图像视觉质量方面的有效性。然而，随着计算机视觉的快速发展，图像复原的目标已经不局限于提升图像视觉质量，而是要求图像复原技术能为基于语义理解的下游视觉识别任务提供可靠输入。这就要求图像复原方法能够有效恢复和增强图像的内在语义信息，以提升其在下游识别任务中的性能。因此，本章在前两章的研究上更进一步，探索面向高层视觉识别任务的图像复原方法。

近年来，深度学习在语义驱动的图像识别任务中取得了显著的成功，例如图像分类[121,134-135]，目标检测[162-165]以及图像分割[166-167]等任务。然而，现有的大多数方法依赖于使用高质量图像构建的公共数据集（例如 ImageNet[168]，CoCo[169]）进行训练，当这些方法应用于低质量退化图像（例如有雾、有雨或带噪图像）时，其性能往往会大幅下降。这主要是因为图像退化破坏了图像的统计特性，导致识别模型无法有效从中提取所需的语义特征用于识别。

针对上述问题，一种直观的解决方案是先对退化图像进行复原，而后再将复原的高质量图像输入到后续的识别系统中以提升性能。当前已有许多图像复原方法被提出，旨在提升退化图像的视觉质量[9,170]。然而，图像的视觉质量与其在下游高层识别任务中所需的语义质量存在本质上的差异。图 4.1展示了在 CUB 数据集[171]中，复原图像的视觉质量和语义质量的关系。可以看到，MPRNet[26]恢复的图像拥有更高的 PSNR 值，但是其分类准确率却低于本章提出的方法。这一现象也说明了，即使经过复原后的图像在视觉效果上更为出色，也未必能在下游的高层识别任务中取得令人满意的效果[89,95,172]。

另一种解决方案是直接引导视觉识别模型学习具有退化不变性的特征，使其可以直接应用于低质量图像，无需进行图像修复。为此，研究者构建了大量的相关数据集[173-175]。在相关研究中，最为常见的一种思路便是在缩小低质量图像和高质量图像的在特征空间中分布距离[89,91-92,95]。尽管该类方法取得了一定的进展，但是其中的大多数方法未能充分考虑不同退化类型在语义层面上带来的不同影响。此外，该类方法通常在训练过程依赖于特定识别任务的语义标签，或者仅能处理单一的退化类型和识别任务。这些问题都限制了该类方法在真实场景下对环境变化的及时适应能力以及对灵活高层任务的调整能力。

为了解决上述问题，本章提出了一种面向视觉识别任务的多退化统一图像

中国知网　https://www.cnki.net

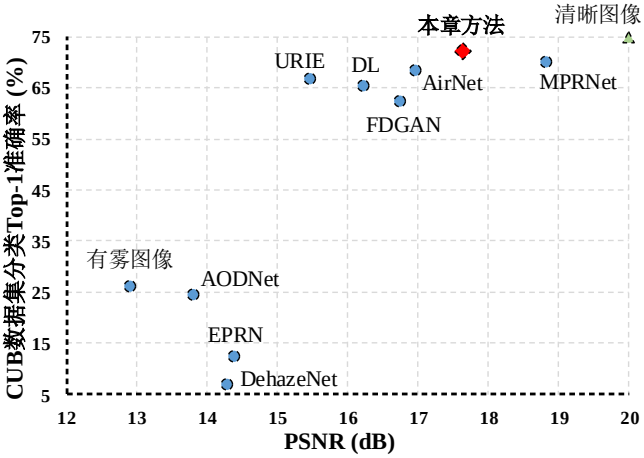


图 4.1　复原图像视觉质量与语义质量的关系

复原方法。本章提出的方法从实际应用的角度出发，旨在无需事先了解具体退化类型和下游识别任务的前提下，从给定的退化图像中恢复出对识别友好的高质量图像。这其中存在两个难点：一是不同的退化类型对于语义信息的影响具有差异性，网络需要拥有感知和处理不同退化影响下语义特征的能力；二是需要在复原图像过程中充分增强图像的内在语义信息，保证复原的图像能够有效适配于下游的识别任务。针对第一个问题，本章所提方法首先将受到不同退化影响的语义特征映射到同一表征空间，然后对这些语义特征进行优化以增强其中的语义信息。具体来说，本章设计了一种内在语义增强模块，该模块能够以一种动态的方式增强不同退化条件下的语义特征。该模块主要由以下两个子模块构成：一是退化归一化补偿模块，用于将受到不同退化类型影响的语义特征映射到同一个退化不变的特征空间中；二是傅里叶引导调制模块，该模块使用幅度谱中的统计特性引导特征的增强。针对第二个问题，本章进一步提出了一种先验赋予优化策略，旨在引导内在语义增强模块从语义理解的角度对输入退化特征进行增强。具体做法是，首先使用低质量图像和高质量图像作为训练样本，预训练一个语义感知解码器。在此过程中，为了充分利用语义信息并为内在语义增强模块的优化提供有效指导，本章在语义感知解码器的预训练过程中引入了相似性排序损失函数。随后，将预训练好的语义感知解码器的参数固定住，并将其与内在语义增强模块级联，促使内在语义模块增强受到退化影响的语义特征来提升语义解码器重建图像的质量。

本章所提出的主要内容和贡献可以总结如下：（1）本章从实际应用的角度出发，提出了一个面向视觉识别任务的多退化统一图像复原方法。该方法可以在未知退化类型和下游识别任务的条件下，从输入退化图像中恢复出有效适配下游识别任务的高质量图像。同时，该方法可以直接作为数据增强模块插入到高层识别任务中，有着优秀的使用性和泛化性。（2）考虑到不同退化类型在语义层面造成的不同影响，本章设计了一个内在语义增强模块，通过动态的方式对退化特征

中国知网　https://www.cnki.net

进行调制增强。(3) 提出了一种先验赋予优化策略，以增强图像复原模型在语义层面感知退化影响的能力。在该策略的指导下，内在语义增强模块可以从语义理解的角度对退化特征进行修复，从而增强复原图像的内在语义信息。(4) 在多个不同的下游视觉识别任务上证明了所提方法的有效性。实验结果证明，所提方法能够同时处理多种退化类型并提升多种下游视觉识别任务的识别效果。

本章的后续安排如下： 4.2节对本章用于验证性能的两个视觉识别任务，图像分类和图像检测进行介绍，以期对该领域有所了解； 4.3节详细介绍本章所提的面向视觉识别任务的多退化统一图像复原方法，包括内在语义增强模块和先验赋予优化策略。 4.4节在多种退化类型和多个下游识别任务上验证本章所提方法的有效性。最后， 4.5节对本章所提方法进行总结。

4.2　视觉理解任务

随着深度学习的快速发展，基于语义驱动的高层视觉识别任务，如图像分类、目标检测和图像分割等任务逐渐成为计算机视觉领域的研究热点，并在如自动驾驶、智能监控和医学影像分析等应用场景中发挥着重要作用。为了验证本章所提方法对于下游识别任务的适配性，本章选择图像分类和目标检测这两个经典的视觉识别任务作为验证框架。本节在这里对这两个任务各自的概念，训练目标和评测指标进行简要概述，以期对两个视觉任务有所了解。

(1) 图像分类

图像分类 (Image Classification) 是计算机视觉的基础任务之一，旨在将输入的图像分配到预定义的类别中，如图 4.2 (a) 所示。例如，在猫狗的二分类任务中，识别输入的图像是猫还是狗；或者在鸟类分类任务中，识别输入图像中的鸟属于哪种鸟类。随着深度学习的发展，基于深度神经网络的图像分类方法成为主流，如 VGG[134]、ResNet[135]、ViT[148] 等网络架构相继出现。这些网络模型在图像分类任务上取得了巨大成功，推动图像分类任务不断发展。

在训练图像分类模型时，交叉熵损失函数 (Cross-Entropy Loss) 是常用的损失函数。该损失函数通过度量模型预测的概率分布与真实概率分布之间的差异，来衡量模型输出的准确性。对于有 C 个类别的多分类任务，交叉熵损失函数的计算可以表示为：

$$\mathcal{L}_{ce} = -\sum_{i=1}^{C} y_i \log(\hat{y}_i), \tag{4.1}$$

其中，y_i 代表真实的标签，通常采用独热 (One-Hot) 编码，$\hat{y}_i$ 代表模型预测的概率。在测试分类性能时，常用的指标为 Top-1 准确率 (Top-1 Accuracy)。该指标通过比较分类网络预测正确的样本数和总样本数来评测分类性能，该指标的

中国知网　https://www.cnki.net

计算方式可以表示为：

$$\text{Top-1 准确率} = \frac{\text{正确预测的样本数}}{\text{总样本数}}, \tag{4.2}$$

该指标的数值越高，说明分类的效果越准确。

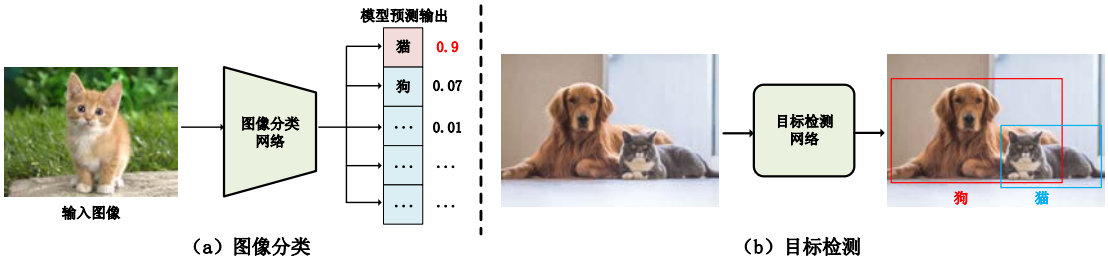


图 4.2　图像分类与目标检测概念介绍

（2）目标检测

目标检测（Object Detection）旨在从输入图像中找出所有感兴趣的目标，并确定它们的类别和位置，如图 4.2（b）所示。目标检测同样是计算机视觉领域的核心问题之一，并广泛用于自动驾驶、视频监控等领域。基于深度学习的目标检测算法主要分为两类：两阶段方法和单阶段方法。两阶段方法通常先生成候选区域，而后再进行分类和边界框的回归，代表性算法有包括 Fast R-CNN[176]，Faster R-CNN[164] 等；单阶段方法则是直接在整个图像上进行目标检测，无需生成候选区域，代表性算法包括 YOLO[177]，RetinaNet[163] 等。

在训练目标检测模型时，通常使用交叉熵损失函数作为分类损失函数，同时使用 L1 损失和 IoU 损失（Intersection over Union Loss）作为边界框回归损失函数。交叉熵损失函数已在公式 4.1中介绍。L1 损失函数用于计算真实边界框 $B = (x, y, w, h)$ 预测边界框 $\hat{B} = (\hat{x}, \hat{y}, \hat{w}, \hat{h})$ 之间的坐标误差，其计算过程可以表示为：

$$\mathcal{L}_{L1} = \|x - \hat{x}\|_1 + \|y - \hat{y}\|_1 + \|w - \hat{w}\|_1 + \|h - \hat{h}\|_1, \tag{4.3}$$

IoU 损失基于预测框和真实框的交并比进行优化，其计算过程可以表示为：

$$\mathcal{L}_{\text{IoU}} = 1 - \text{IoU}, \quad \text{IoU} = \frac{\text{预测框} \bigcap \text{真实框}}{\text{预测框} \bigcup \text{真实框}}, \tag{4.4}$$

在评估目标检测模型的性能时，常用的评价指标包括平均精度（Average Precision，AP），交并比（Jaccard Index，JI）以及漏检率（Miss Rate，MR）。其中，平均精度主要考虑检测器精度和召回之间的平衡，能够比较全面的反映目标检测模型在定位和分类方面的性能。而交并比主要评测检测器整体上对目标区域的覆盖情况。这两个指标的值越大，说明检测器性能越好。漏检率则是衡量检测器漏检目标的比例，其值越低，说明检测器性能越好。

中国知网　https://www.cnki.net

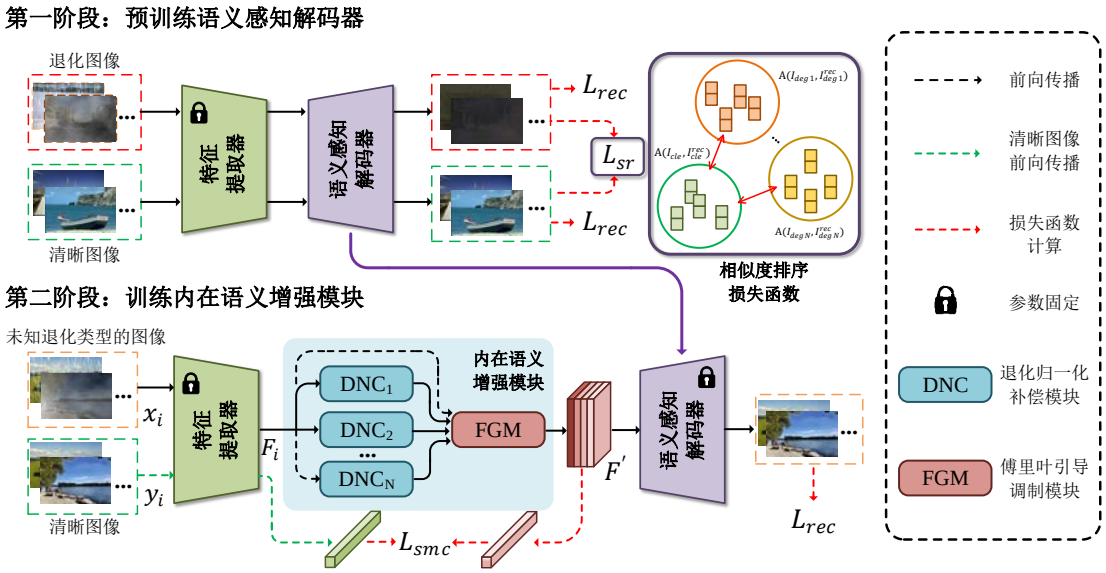


图 4.3　面向视觉识别任务的多退化统一图像复原方法

4.3　面向识别任务的多退化统一处理图像复原方法设计

在本节中，首先对本章所提的面向视觉识别任务的多退化统一图像复原方法的整体结构和前向传播过程进行介绍。而后，具体介绍该方法的网络模型设计和训练策略，包括内在语义增强模块和先验赋予优化策略。

4.3.1　整体模型描述

给定一个包含有 N 种退化类型的训练数据集 $D = \{(x_{i,j}, y_{i,j})_{j=1}^{M_i}\}_{i=1}^{N}$，其中，$x_{i,j}$ 代表属于第 i 种退化类型的第 j 张图像，$y_{i,j}$ 代表 $x_{i,j}$ 对应的清晰图像，而 M_i 代表第 i 种退化对应的样本数量。本章所提方法的目标是，给定一张未知退化类型的低质量图像 x_{deg}，恢复出能有效适配下游视觉识别任务的清晰图像 y^r。

本章所提的面向视觉识别任务的多退化统一图像复原方法的结构如图 4.3所示。可以看出，其包含一个特征提取器 f_{ext}，一个内在语义增强模块 f_{ISE} 和一个语义感知解码器 f_{SAD}。整个训练过程基于本章提出的先验赋予优化策略，该策略具体实现为一个两阶段的训练流程。

对于给定的退化图像 x_{deg}，首先通过固定参数的特征提取器来获得其退化语义特征 F_{deg}。而后，该特征输入到内在语义增强模块中进行特征修复。具体来说，F_{deg} 被输入到多分支退化归一化补偿模块中，将其映射到与退化无关的特征空间。同时，F_{deg} 也被输入到一个傅里叶引导调制模块，该模块利用 F_{deg} 中的统计特性对多分支退化归一化补偿模块的输出进行融合。此外，本章提出了一种先验赋予优化策略。该策略将模型的整个训练过程分为两个阶段。在第一阶段中，首先在退化图像和清晰图像上利用相似性排序损失函数对语义感知解码器 f_{SAD} 进行预训练，使 f_{SAD} 具备感知不同退化和清晰图像语义特征的能力。在第二阶

中国知网　https://www.cnki.net

段，将内在语义增强模块与预训练好的语义感知解码器级联，同时固定住语义感知解码器的参数，利用语义最大化损失函数来训练内在语义增强模块。

对于特征提取器 f_{ext}，需要使用在大规模数据集（例如 ImageNet[168]，CoCo[169]）上预训练的经典网络（例如 VGG16[134]，ResNet50[135]），以提供富含语义信息的表征空间。在本章所有实验中，选择使用在 ImageNet 上预训练的 VGG16 的浅层作为特征提取器 f_{ext}。由此，可以获得退化数据集 D 对应的语义特征集 $D' = \{(F_{i,j}, y_{i,j})_{j=1}^{M_i}\}_{i=1}^{N}$，其中，$F_{i,j}$ 代表由 f_{ext} 从 $x_{i,j}$ 中提取到的语义特征，即 $F_{i,j} = f_{ext}(x_{i,j})$。需要注意的是，由于特征提取器 f_{ext} 在整个训练过程中的参数都是固定的，所以 $F_{i,j}$ 与 $x_{i,j}$ 是一一对应的。

4.3.2　内在语义增强模块

如图 4.3所示，内在语义增强模块包含两个主要部分。一个是退化归一化补偿模块，用于将受到不同退化影响的特征映射到同一个退化无关的特征空间中。另外一个是傅里叶引导调制模块，根据输入特征统计特征来集成多分支退化归一化补偿模块的输出。

（1）退化归一化补偿模块

由于不同类型的退化在语义层面上的影响存在显著差异，本章引入了实例归一化（Instance Normalization，IN）来对齐不同退化的特征。该模块的具体结构如图 4.4所示。这里使用 F_i 代表属于第 i 种退化类型（$i \in \{1, ..., N\}$）的退化语义特征，而后使用实例归一化将其映射到退化不变特征空间中，该过程可以表示为：

$$F_i^n = \mathrm{IN}(F_i) = \gamma \frac{F_i - \mu(F_i)}{\sigma(F_i)} + \beta, \tag{4.5}$$

其中，$\mu(\cdot)$ 和 $\sigma(\cdot)$ 分别代表均值和标准差，γ 和 β 代表从数据中学到的参数，F_i^n 代表经过实例归一化后的特征。实例归一化可以有效过滤出实例特定的风格信息[2]。由于每一种退化都可以被视为一种风格，因此，可以通过实例归一化减少不同退化特征之间的风格差异，实现对不同退化特征的有效对齐。

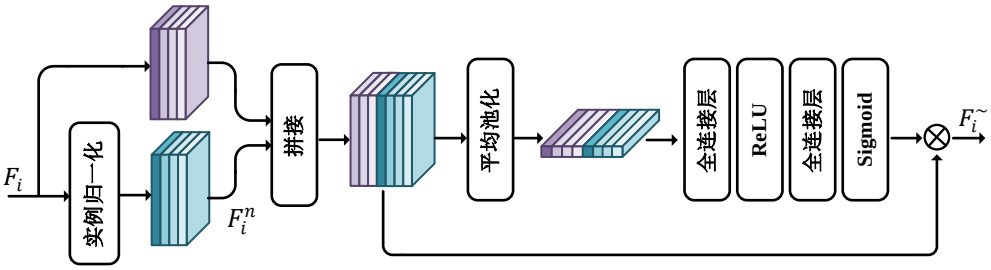


图 4.4　退化归一化补偿模块

然而，实例归一化会不可避免地丢失部分用于语义修复和图像重建的信息[2,178-179]。为了解决这一问题，本章将归一化前的原始特征与经过实例归一

中国知网　https://www.cnki.net

化处理后的特征进行融合，利用两者信息之间的互补性，从而保证归一化后特征的信息完整性。具体而言，针对特征 F_i^n，在通道维度上将其与归一化前的特征 F_i 进行拼接。而后，通过通道注意力的方式来探索两个特征之间的关联性。该过程可以表示为：

$$A_F = \text{sigmoid}(W_2 \cdot \text{relu}(W_1 \cdot \text{pooling}([F_i, F_i^n])), \tag{4.6}$$

$$\widetilde{F}_i = A_F \odot [F_i, F_i^n], \tag{4.7}$$

其中，W_2 和 W_1 代表两个全连接层，relu 和 sigmoid 分别代表 ReLU 激活函数和 Sigmoid 激活函数，pooling 代表全局平均池化操作，$[\cdot,\cdot]$ 代表特征在通道维度的拼接操作。通过以上操作，退化归一化补偿模块在去除退化差异的同时，保留了信息的完整性，保证了后续语义恢复和图像重建的准确性。

然而，单一的退化归一化补偿模块有时难以有效处理多种退化。这主要是由于不同退化对于语义特征分布的影响有很大差异，使得单一退化归一化补偿模块难以同时优化针对多种退化的归一化参数，进而导致其无法准确捕捉并规范化不同退化特征的统计特性。为了更灵活地应对复杂多变的退化情况，本章进一步提出了一种多分支的退化归一化补偿模块架构，如图 4.3中蓝色方框所示。具体而言，内在语义增强模块针对每种退化类型分别构建一个退化归一化补偿模块，从而形成多分支的退化归一化补偿架构。对于输入特征 F_i，将其输入到多分支退化归一化补偿模块中进行并行处理，并得到多分支输出结果，该过程可以表示为：

$$\widetilde{F}_i^1, ..., \widetilde{F}_i^N = \text{Multiple_Branch_DNC}(F_i), \tag{4.8}$$

其中，DNC 表示退化归一化补偿模块，$\widetilde{F}_i^j$ 代表第 j 个退化归一化补偿分支的输出结果。

（2）傅里叶引导调制模块

尽管退化归一化补偿模块对不同退化的特征进行了初步对齐，但仍然需要对其进行进一步更细致的调制。本章选择借助傅里叶变换来探索不同退化特征之间的关系。已有相关研究证明[180]，在经过傅里叶变换得到的频域空间中，图像的幅度谱有效反映图像的风格信息。这种性质也可以延展到图像复原领域，即退化图像通过傅里叶变换的幅度谱可以有效表示该图像的退化信息。为了进行验证，本章将遭受不同退化但是拥有相同内容结构的图像通过傅里叶变换映射到频率域，并观察它们的幅度谱，如图 4.5所示。观察可以发现，基于傅里叶变换得到的幅度谱中，有雾图像和带噪图像这两种不同退化类型的图像，其幅度谱的分布存在显著差异。这一现象也充分说明了利用傅里叶变换得到的幅度谱可以有效反映图像的退化特性。据此，本章提出了一个傅里叶引导调制模块，旨在利用输入特征的统计特性来指导特征的自适应调整。

中国知网　https://www.cnki.net

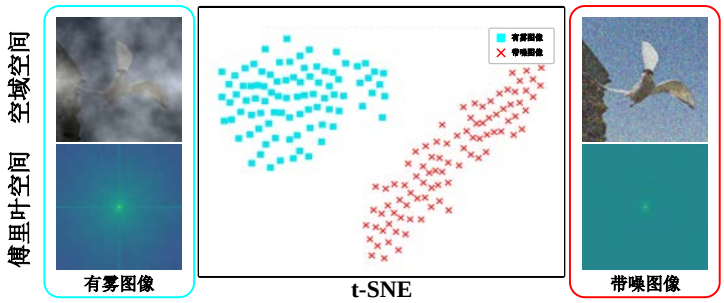


图 4.5　有雾图像和带噪图像傅里叶空间幅度谱分布可视化

傅里叶变换。本节首先回顾一下傅里叶变换的操作。给定一张空间大小为 $H \times W$ 输入图像 x，可以通过傅里叶变换 $\mathcal{F}(\cdot)$ 将其从空间域转换到频率域，该过程可以表示为：

$$\mathcal{F}(x)(u,v) = \sum_{h=0}^{H-1}\sum_{w=0}^{W-1} x(h,w)e^{-j2\pi(\frac{h}{H}u+\frac{w}{W}v)}, \tag{4.9}$$

其中，h 和 w 代表空间域中的坐标，u 和 v 代表频率域中的坐标，j 为虚数单位表示。傅里叶变换结果可以进一步表示为 $\mathcal{F}(x) = \mathcal{R}(x) + j\mathcal{I}(x)$，其中，$\mathcal{R}(x)$ 和 $\mathcal{I}(x)$ 分别表示 $\mathcal{F}(x)$ 的实部和虚部。根据实部和虚部，可以进一步得到幅度谱和相位谱，该过程可以表示为：

$$\mathcal{A}(x)(u,v) = [\mathcal{R}^2(x)(u,v) + \mathcal{I}^2(x)(u,v)]^{1/2}, \tag{4.10}$$

$$\mathcal{P}(x)(u,v) = \arctan[\frac{\mathcal{I}(x)(u,v)}{\mathcal{R}(x)(u,v)}], \tag{4.11}$$

其中，$\mathcal{A}(x)$ 代表幅度谱，$\mathcal{P}(x)$ 代表相位谱。

傅里叶引导调制模块。在介绍完傅里叶变换的基本操作后，本节进一步说明傅里叶引导调制模块的作用机理，如图 4.6所示。给定输入退化特征 F_i，首先通过傅里叶变换得到其频域表示 $\mathcal{F}(F_i)$，并进一步得到对应的幅度谱 $\mathcal{A}(F_i)$ 和相位谱 $\mathcal{P}(F_i)$。由于有关退化的特性主要都反映在幅度谱 $\mathcal{A}(F_i)$ 中，傅里叶引导调制模块便利用 $\mathcal{A}(F_i)$ 中的统计信息对输入的退化特征进行自适应的调整。具体来说，使用 1×1 的卷积层 W 从 $\mathcal{A}(F_i)$ 中提取退化信息，该过程可以表示为：

$$\mathcal{A}'(F_i)(u,v) = \mathcal{A}(F_i)(u,v) * W, \tag{4.12}$$

其中，$*$ 代表卷积操作。在此过程中，相位谱 $\mathcal{P}(F_i)$ 保持不变。在频率域提取到退化信息后，通过逆傅里叶变换 $\mathcal{F}^{-1}(\cdot)$，将得到的幅度谱 $\mathcal{A}'(F_i)$ 与未经处理的相位谱 $\mathcal{P}(F_i)$ 从频率域映射回空间域。而后，利用卷积层对得到空间域特征进行处理并通过 Softmax 函数以得到引导图 M。

随后，借助傅里叶引导调制模块生成的引导图 M 对上述多分支退化归一化补偿模块的输出进行融合,从而得到最终的输出特征 F_i',即 $F_i' = M \odot [\widetilde{F}_i^1, ..., \widetilde{F}_i^N]$。

中国知网　https://www.cnki.net

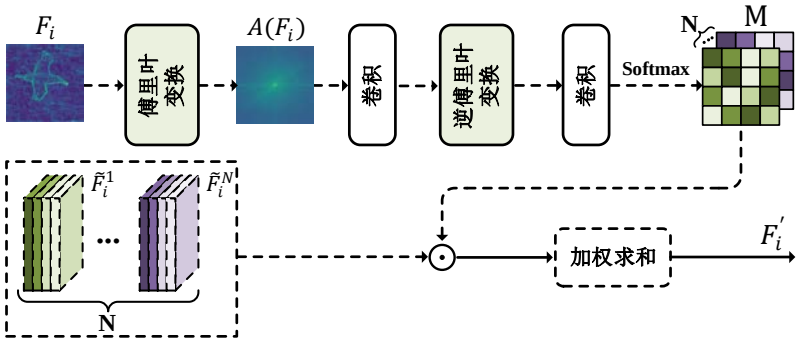


图 4.6　傅里叶引导调制模块

需要注意的是，在内在语义增强模块中，每一种退化类型被独立分配了一个退化归一化补偿模块。由于不同退化类型的信息分布存在显著差异，因此，针对不同退化类型分别配置退化归一化补偿模块能够更加灵活地处理不同退化特征，从而便于后续的语义恢复。随后，利用傅里叶引导调制模块基于统计特征生成的指导信号，以动态的方式融合多个并行退化归一化补偿模块的输出，使其能够依据输入图像的特性自适应地进行调整。相较于之前基于静态网络的方法[70-71]，本章所提的这种动态自适应架构具备更强的表示能力与灵活性，同时也促使内在语义增强模块隐式地挖掘不同退化修复过程之间的潜在关联性，提升其针对多种退化语义特征的修复能力。

（3）内在语义增强模块训练损失函数

为了进一步保持集成特征 $\boldsymbol{F}'$ 的语义特性，本章提出了语义最大化约束（Semantic Maximum Constraint，SMC），旨在将增强语义特征 $\boldsymbol{F}'$ 向着清晰图像对应特征 $\boldsymbol{F}'_{cle}$ 方向进行优化。首先使用最大池化（Max Pooling）操作分别提取两个特征中最具语义代表性的部分，该过程可以表示为：

$$f' = \text{MaxPooling}(\boldsymbol{F}'), \quad f'_{cle} = \text{MaxPooling}(\boldsymbol{F}'_{cle}). \tag{4.13}$$

而后，使用余弦相似度（cosine similarity）来衡量它们之间的语义距离，从而确保增强特征与清晰图像特征的语义一致性。该损失函数可以表示为：

$$\mathcal{L}_{sem} = 1 - \frac{f'}{\|f'\|_2^2} \cdot \frac{f'_{cle}}{\|f'_{cle}\|_2^2}, \tag{4.14}$$

其中，$\|\cdot\|_2^2$ 表示 L2 范数。传统的语义约束通常使用复原特征 $\boldsymbol{F}'$ 和清晰图像特征 $\boldsymbol{F}'_{cle}$ 之间的 L1 或 L2 距离作为损失函数，而这在计算过程中对特征中的每个像素赋予了相同的权重。与之不同的是，在语义最大化约束中，首先使用全局最大池化捕捉语义特征 $\boldsymbol{F}'$ 和 $\boldsymbol{F}'_{cle}$ 各个通道中最显著的激活值，而这通常代表了最重要的语义信息。而后，使用余弦相似度作为匹配约束，强调了这些关键激活信息的方向性匹配，从而避免了原始语义特征中可能存在的背景噪声的干扰。同

中国知网　https://www.cnki.net

时，使用该损失函数约束网络训练，可以使得内在语义增强模块更好地能够从语义层面增强输入的退化特征。

在图像层面的重建损失函数同样被引入用于约束内在语义增强模块的训练，重建损失函数可以表示为：

$$\mathcal{L}_{rec} = \| f_{SAD}(f_{ISE}(F')) - y \|_1, \tag{4.15}$$

其中，$\| \cdot \|_1$ 代表 L1 范数，y 代表特征 F' 对应的清晰图像，f_{SAD} 代表已经提前预训练好的语义感知解码器，其预训练过程将在 4.3.3节中进行详细叙述。而后，内在语义增强模块的整个训练损失函数可以表示为：

$$\mathcal{L}_{ISE} = \mathcal{L}_{sem} + \mathcal{L}_{rec}. \tag{4.16}$$

4.3.3　先验赋予优化策略

本章旨在从退化图像中恢复出既能适配于下游识别任务又具备可接受视觉质量的清晰图像。其中的核心挑战在于缩小低质量图像和高质量图像的语义表征差距。为此，本章提出了一个先验赋予优化策略，并将其实现为一个两阶段的训练方案。在第一阶段，首先预训练一个语义感知解码器，使其能够充分感知和捕捉图像中的高层语义信息，并能根据输入的语义特征重建出对应的图像。在第二阶段，将 4.3.2节中所提的内在语义增强模块与第一阶段预训练的语义感知解码器级联，并固定住语义感知解码器的参数，使用公式 4.16中的损失函数训练内在语义增强模块，从而引导其学习退化语义特征与清晰语义特征之间的映射。该训练策略如图 4.7所示。由于第二阶段针对内在语义增强模块的训练方式已在 4.3.2节中进行了详细说明，本节着重介绍第一阶段对于语义感知解码器的预训练过程。

具体来说，给定一张清晰图像 I_{cle} 和一张退化图像 I_{deg}，可以通过特征提取器 f_{ext} 分别提取它们的语义特征，得到 F_{cle} 和 F_{deg}。而后，将这两个特征送入到语义感知解码器 f_{SAD} 中，目标是重建出它们各自对应的图像 I_{cle} 和 I_{deg}，该过程可以表示为：

$$I_{cle}^{rec} = f_{SAD}(F_{cle}), \quad I_{deg}^{rec} = f_{SAD}(F_{deg}), \tag{4.17}$$

其中，I_{cle}^{rec} 和 I_{deg}^{rec} 分别表示从清晰图像语义特征 F_{cle} 和退化图像语义特征 F_{deg} 中重建出的图像，这里使用上标 rec 代表 f_{SAD} 重建的图像。而后，使用重建损失函数来约束语义感知解码器的训练，以确保其从语义特征重建对应图像的能力，该损失函数可以表示为：

$$\mathcal{L}_{rec}^{s} = \| I_{cle}^{rec} - I_{cle} \|_1 + \lambda \cdot \| I_{deg}^{rec} - I_{deg} \|_1, \tag{4.18}$$

中国知网　https://www.cnki.net

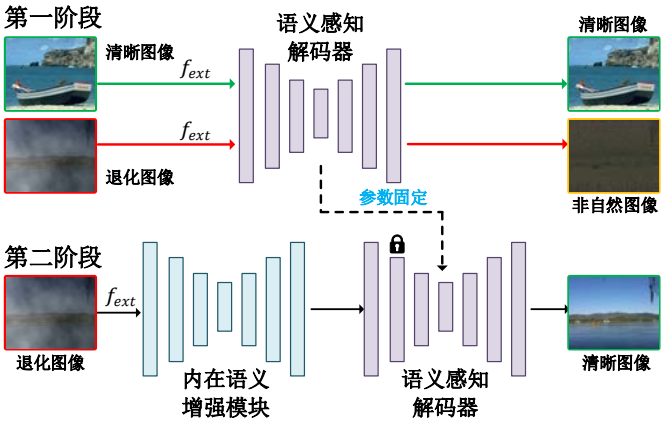


图 4.7　先验赋予优化策略

其中，λ 是平衡参数，在实验中根据经验设置为 0.1。

实际上，预训练期望达到的目标，便是由清晰图像语义特征 F_{cle} 重建图像 I_{cle}^{rec} 的质量要显著优于由退化图像语义特征 F_{deg} 重建图像 I_{deg}^{rec}。这不仅可以赋予 f_{SAD} 对输入不同语义特征的感知能力，同时创建了一个质量梯度，即输入 f_{SAD} 的语义特征越接近清晰图像的语义特征，其重建出的图像质量越高，反之，其重建出的图像质量越低。而这种质量梯度将在第二阶段为内在语义增强模块的训练提供明确的优化方向。为了实现这一目标，本章设计了一种相似度排序损失（Similarity Ranking Loss）。具体而言，对于清晰图像 I_{cle} 与其对应的重建图像 I_{cle}^{rec}，可以计算它们两者之间的相对相似度，该过程可以表示为：

$$A(I_{cle}, I_{cle}^{rec}) = \frac{I_{cle} \cdot I_{cle}^{rec}}{\|I_{cle}\|_2^2 \cdot \|I_{cle}^{rec}\|_2^2}, \tag{4.19}$$

其中，$A(\cdot)$ 代表计算两张图像之间相对相似度的函数。通过相同的方式，也可以计算得到退化图像 I_{deg} 和其重建图像 I_{deg}^{rec} 之间的相似度 $A(I_{deg}, I_{deg}^{rec})$。

随后，本章采用了一种排序度量方法来计算两种相似度之间的距离，并在此基础上构建相似度排序损失函数，该过程可以表示为：

$$\mathcal{L}_{sr} = max(0, -(A(I_{cle}, I_{cle}^{rec}) - A(I_{deg}, I_{deg}^{rec})) + m), \tag{4.20}$$

其中，m 代表一个阈值，在实验中根据经验设置为 1.0。而预训练语义感知解码器的整体优化函数可以表示为：

$$\mathcal{L}_{SAD} = \mathcal{L}_{rec}^{s} + \mathcal{L}_{sr}. \tag{4.21}$$

通过以上的预训练赋予语义感知解码器感知清晰图像和退化图像语义特征的能力，使其能够作为一种语义先验来指导内在语义增强模块的训练。预训练完成之后，将内在语义增强模块与语义感知解码器级联，并固定住语义感知解码器的参数，利用公式 4.16中的损失函数，使内在语义增强模块对输入的退化语义特

中国知网　https://www.cnki.net

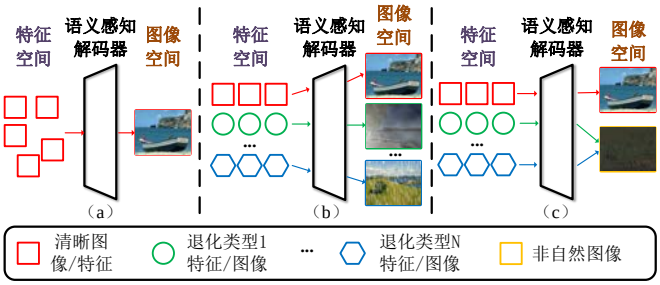


图 4.8　不同语义感知解码器的预训练策略

征进行增强，使其向着清晰图像语义特征的方向不断靠拢。先验赋予优化策略将整个训练过程拆分为两个子阶段，并为语义感知解码器和内在语义增强模块分别提供了明确的优化目标，有效避免了直接进行端到端训练可能带来的不稳定性问题。

需要注意的是，相似度排序损失函数 L_{sr} 保证了语义感知解码器在输入语义特征质量与重建图像质量之间的单调关系。具体来说，预训练希望语义感知解码器在清晰和退化组成的域 $\mathcal{X}=\{cle, deg_1, ..., deg_N\}$ 内保持单调性，即输入语义感知解码器的语义特征退化程度越高，语义感知解码器重建出的图像质量越低。这将显著增强语义感知解码器对于不同输入语义特征的区分能力。其训练原理如图 4.8（c）所示。此外，在图 4.8（a）和图 4.8（b）中展示了两种其他可能的预训练方案。在图 4.8（a）展示的方案中，只使用清晰图像的语义特征来训练语义感知解码器，这种方法难以保证语义感知解码器对退化图像语义特征的感知能力。而这可能会导致一个严重的问题——在输入退化图像语义特征时，语义感知解码器可能会重构出一张具有较高视觉质量但是却缺乏语义信息的图像，进而影响其在下游视觉识别任务中的性能。另外一种可能的预训练方案是利用清晰图像和退化图像的语义特征共同训练语义感知解码器。训练的目标是重建出对应的图像，即清晰图像的语义特征重建出对应的清晰图像，退化图像的语义特征重建出对应的退化图像，如图 4.8（b）所示。这种训练方式保证了语义感知解码器的单射性质，确保了在域 $\mathcal{X}$ 内语义特征到图像的映射是一一对应的。然而，这对语义感知解码器的参数量和能力提出了要求，因为其不但要具备感知和理解不同输入语义特征的能力，同时还要求其能根据输入的语义特征精准重建对应的图像。而作为本章所提方法的一部分，语义感知解码器应该保持结构简单且参数轻量，以确保其在实际部署时的计算效率。

通过重新审视语义感知解码器便可以发现，预训练过程希望赋予语义感知解码器感知不同输入语义特征的能力，并能从无退化的语义特征中重建能有效适配下游识别任务的高质量图像。严格的一一映射并非必要。基于以上分析，本章在预训练语义感知解码器时引入了相似度排序损失函数进行约束，其目的是鼓励语义感知解码器将清晰图像的语义特征映射回对应的高质量清晰图像，而将各

中国知网　https://www.cnki.net

种退化图像的语义特征映射到一个不符合自然图像分布的流形空间中，如图 4.8（c）所示。从另一个角度来看，该预训练方式将域 $\mathcal{X}$ 简化为了 $\mathcal{X}' = \{cle, deg\}$，并只要求语义感知解码器在域 $\mathcal{X}'$ 内保持单调性即可。该预训练策略有效降低了语义感知解码器所需的复杂性和参数量。

4.4　实验分析

4.4.1　数据集和评价指标

为了验证本章方法的有效性，在三中常见的图像退化环境下（分别为雾霾、噪声和降雨）对图像分类和目标检测这两个下游视觉识别任务上进行了广泛的测试。针对图像去雾任务，本章使用 RESIDE[112]作为训练数据集。该数据集在 2.4.1节中进行过介绍，这里不再赘述。针对图像去雨任务，本章使用 Rain100L[181]作为训练数据集，其包含 1,800 组有雨-清晰图像对用于训练，100 组有雨-清晰图像对用于测试。针对图像去噪任务，本章使用 BSD400[182]和 WED[183]数据集的组合形式作为训练集。其中，BSD400 和 WED 数据集中分别包含了 400 和 4,744 张自然图像。由于本章所提的方法是利用单一模型同时处理多种退化类型，所以训练数据集为上述数据集的组合。在验证复原图像在视觉识别任务中的性能时，针对图像分类任务，选择 CUB[171]数据集作为测试分类性能的数据集。该数据集是一个用于鸟类分类的数据集，其中包含有 200 种鸟类的 11,788 张图像。其中，5,994 张图像用来训练，5,794 张图像用于测试。而针对目标检测任务，本章选择 CrowdHuman[184]数据集用来验证目标检测性能。该数据包含 15,000 张图像用于训练，4,370 张图像用于验证以及 5,000 张图像用于测试。

本章所提方法旨在从退化图像中恢复出能有效适配下游识别任务且具有可接受视觉效果的高质量图像。具体的评价指标分为针对视觉质量的评价指标和针对识别质量的评价指标。针对视觉质量的评价指标仍然采用上述章节中使用过的峰值信噪比（PSNR）和结构相似性指数（SSIM）。在测试识别任务上的性能时，分别使用识别任务特定的评价指标。针对分类任务，本章采用 Top-1 准确率（Top-1 Accuracy）作为评估分类性能的指标。针对目标检测任务，本章采用的平均精度（Average Precision，AP），交并比（Jaccard Index，JI）以及漏检率（Miss Rate，MR）作为评价指标。这些指标已在 4.2节中进行了介绍，在此不在赘述。

4.4.2　实验设置

本章选择使用 Adam 优化器进行训练，其中参数 β_1、β_2 和 γ 分别设置为 0.9、0.999 和 0.5。训练的初始学习率设置为 2×10^{-4}。学习率会随着训练迭代次数的增加逐渐减小，以确保训练过程的稳定，同时帮助复原网络参数收敛至最优

中国知网　https://www.cnki.net

解。第一阶段和第二阶段的训练迭代轮数分别设置为 600 和 1,200。每次迭代的输入批量大小设置为 40。在输入网络之前，图像会经过尺寸调整，被随机裁剪为 128×128 的图像块。在训练过程中，引入了图像随机水平翻转的数据增强技术，以增加训练样本的多样性。本章所有模型均在一块 NVIDIA 3090Ti GPU 上训练完成。

4.4.3　性能比较

（1）图像分类任务上性能提升

实验流程。本节在最基础的视觉识别任务——图像分类任务上验证本章所提方法在下游视觉识别系统上的优越性。这里首先介绍不同图像复原方法在下游分类系统上的性能评估流程，如图 4.9所示。首先，本章在清晰的 CUB 训练集上预训练 VGG16[134]和 ResNet50[135]两个网络，作为两个不同的下游识别系统以充分评估复原图像对于分类任务的适配程度。同时，使用上述 4.4.1节中提到的图像复原数据集训练图像复原模型。而后，将训练好的图像复原模型应用于退化的 CUB 测试集，以得到复原 CUB 测试集。最后，将复原 CUB 测试集应用于预训练的 VGG16 和 ResNet50，以评估图像复原模型复原的图像对于这两个识别系统的适配性。本章使用与 ImageNet-C[173]相同的方式合成退化图像。与之前的一些工作[89,91,95]不同，本章在训练图像复原模型过程中没有引入任何面向特定识别任务的语义标注信息。

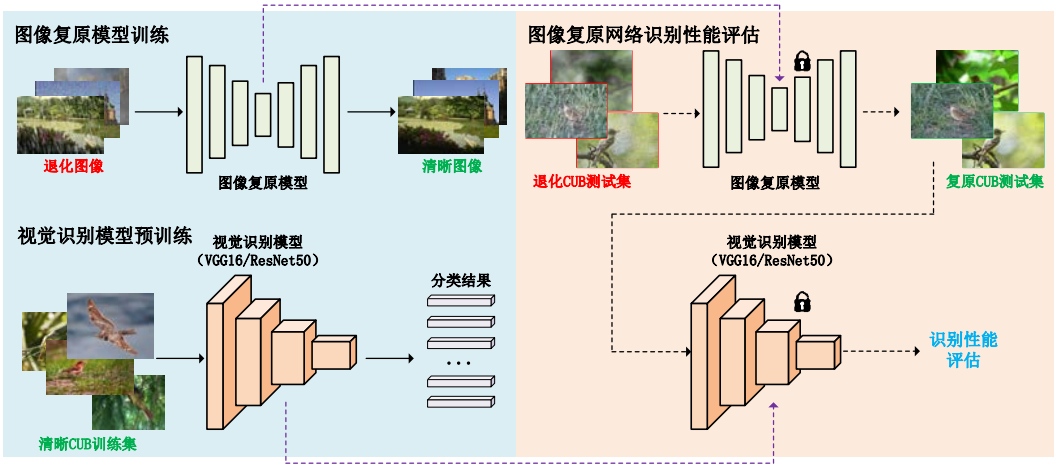


图 4.9　图像复原方法在下游视觉识别任务上性能测试流程

对比的基准方法。本章所提的面向视觉识别任务的多退化统一图像复原方法可以能够处理多种退化类型。因此，为了确保对比的公平性，本章将所提方法分别与针对单一退化和针对多类型退化的图像复原方法进行了比较。在针对单一退化的场景下，只是用对应退化的数据集训练复原模型。例如，在针对图像去雾任务中，只是用 RESIDE[112]数据集训练图像复原模型。在针对多类型退化的场景下，

中国知网　https://www.cnki.net

表 4.1　不同方法在 CUB[171] 数据集图像去雾后分类性能定量比较

	方法	分类性能		视觉性能		参数量
		Top-1V	Top-1R	PSNR	SSIM	
针对单一退化图像复原方法	DehazeNet[123]	6.67	17.24	14.29	0.5225	0.01M
	AODNet[47]	24.01	42.06	13.28	0.6415	0.002M
	EPDN[185]	12.05	25.93	14.39	0.6864	17.38M
	FDGAN[186]	62.04	74.23	16.76	0.7545	13.98M
	FFANet[7]	62.32	74.56	16.82	0.7658	4.68M
	DL*[187]	64.93	75.24	16.23	0.7567	2.09M
	MPRNet*[26]	70.38	78.62	**19.23**	**0.8134**	15.74M
	AirNet*[71]	68.67	77.14	17.42	0.7981	8.93M
	本章方法 *	**72.26**	**80.67**	17.72	0.7853	2.73M
针对多类型退化图像复原方法	DL[187]	65.62	75.95	16.18	0.7316	2.09M
	MPRNet[26]	69.59	78.15	**18.83**	**0.8000**	15.74M
	AirNet[71]	68.19	76.81	16.97	0.7692	8.93M
	本章方法	**72.11**	**80.55**	17.64	0.7790	2.73M

使用多种退化混合的数据集训练复原模型，具体来说，是将图像去雾、图像去噪以及图像去雨数据集进行混合作为训练图像复原模型的数据集。在图像去雾任务中, 本章选择 DehazeNet[123], AODNet[47], EPRN[185], FDGAN[186], FFANet[7] 以及 DDP[90] 作为针对单一退化的图像复原基准方法, 同时选择 DL[187], MPRNet[26] 以及 AirNet[71] 作为针对多类型退化的图像复原基准方法。在图像去噪任务中, 本章选择 CBM3D[188], DnCNN[189], IRCNN[24], FFDNet[9] 以及 BRDNet[190] 作为针对单一退化的图像复原基准方法，同时选择 DL[187]，MPRNet[26] 以及 AirNet[71] 作为针对多种类型退化的图像复原基准方法。在图像去雨任务中，本章选择 DIDMDN[58]，UMRL[191]，SIRR[192]，MSPFN[193] 以及 LPNet[8] 作为针对单一退化的图像复原基准方法，同时选择 MPRNet[26] 和 AirNet[71] 作为针对多种类型退化的退化的图像复原基准方法。

定量比较结果。表 4.1，表 4.2和表 4.3分别展示了在 CUB 数据集上图像去雾、图像去噪和图像去雨三种场景下复原的图像，在两个预训练分类器 VGG16 和 ResNet50 上的分类性能。其中, Top-1V（%）和 Top-1R（%）分别表示在 VGG16 和 ResNet50 分类器上的 Top-1 准确率。其中，加粗标注的数值表示最好结果，下划线标注的数值表示次好结果。在图像去雾与图像去噪两个任务中，本章在保持模型结构不变的前提下，将针对多类型退化的图像复原方法在这些单一退化复原任务上训练并测试性能，并使用上标“*”进行表示。需要特别强调的是，在本章的实验设置中，识别相关的性能指标（例如，Top-1V 与 Top-1R）是要比视觉性能指标（例如，PSNR 和 SSIM）更加重要的。可以看到，在三种不同的图像复原任务中，本章所提方法在图像分类性能上均优于其他图像复原方法。例如，将本章方法应用于图像去雾任务时，复原图像在 Top-1V/Top-1R 指标上相比与

中国知网　https://www.cnki.net

表 4.2　不同方法在 CUB[171] 数据集图像去噪后分类性能定量比较

	方法	分类性能		视觉性能		参数量
		Top-1V	Top-1R	PSNR	SSIM	
针对单一退化图像复原方法	CBM3D[188]	20.16	25.41	22.67	0.5237	-
	DnCNN[189]	24.48	38.92	23.01	0.5474	0.56M
	IRCNN[24]	26.98	43.37	25.52	0.7121	0.19M
	FFDNet[9]	22.69	37.51	25.16	0.6982	0.85M
	BRDNet[190]	25.05	41.96	26.28	0.7552	1.12M
	Restormer[15]	29.18	47.54	**27.46**	**0.7972**	26.13M
	DL*[187]	24.84	40.48	26.47	0.7654	2.09M
	MPRNet*[26]	25.23	42.35	27.05	0.7894	15.74M
	AirNet*[71]	27.85	45.98	26.57	0.7696	8.93M
	本章方法 *	**31.95**	**49.97**	26.35	0.7648	2.73M
针对多类型退化图像复原方法	DL[187]	25.12	42.07	26.33	0.7635	2.09M
	MPRNet[26]	25.18	42.51	**26.74**	**0.7764**	15.74M
	AirNet[71]	27.77	45.72	26.42	0.7653	8.93M
	本章方法	**32.00**	**50.26**	26.41	0.7669	2.73M

表 4.3　不同方法在 CUB[171] 数据集图像去雨后分类性能定量比较

	方法	分类性能		视觉性能		参数量
		Top-1V	Top-1R	PSNR	SSIM	
针对单一退化图像复原方法	DIDMDN[58]	50.29	62.35	18.63	0.6845	0.37M
	UMRL[191]	55.89	68.59	20.80	0.7197	0.98M
	SIRR[192]	73.34	81.19	27.56	0.8655	2.58M
	MSPFN[193]	73.46	81.26	27.68	0.8664	13.35M
	LPNet[8]	73.56	81.37	27.73	0.8692	0.008M
针对多类型退化图像复原方法	MPRNet[26]	74.25	82.03	**28.54**	**0.8844**	15.74M
	AirNet[71]	73.08	81.65	27.45	0.8693	8.93M
	本章方法	**74.68**	**82.21**	27.41	0.8805	2.73M

MPRNet 和 AirNet 分别提升了 2.52%/2.4% 和 3.92%/3.74%。同时，在最具挑战性的图像去噪任务上，本章方法相比于 MPRNet 和 AirNet 也分别领先 6.82%/7.75% 和 4.23%/4.54%。而在图像去雨任务中，尽管优势不是十分显著，但本章方法相较于 MPRNet 和 AirNet 仍然实现了 0.43%/0.18% 和 1.6%/0.56% 的准确率提升。这充分证明了本章所提方法复原的图像可以更好地适配下游的视觉识别任务。需要注意的是，本章提出的面向视觉识别任务的多退化统一图像复原方法可以利用单一模型同时处理多种不同的退化。在表 4.1、表 4.2和表 4.3中“针对多类型退化图像复原方法”一栏中的“本章方法”，指的是同一个模型。

定性结果比较。为了验证本章提出的方法对于分类器的影响，本章进一步可视化不同复原图像在 VGG16 分类器中间层的特征。图 4.10和图 4.11分别展示了在不同方法在图像去雾和图像去噪两个任务中复原的图像在 VGG16 中的特征图。复原图像的特征图与清晰图像的特征图越接近，说明该复原图像的内在语义

中国知网　https://www.cnki.net

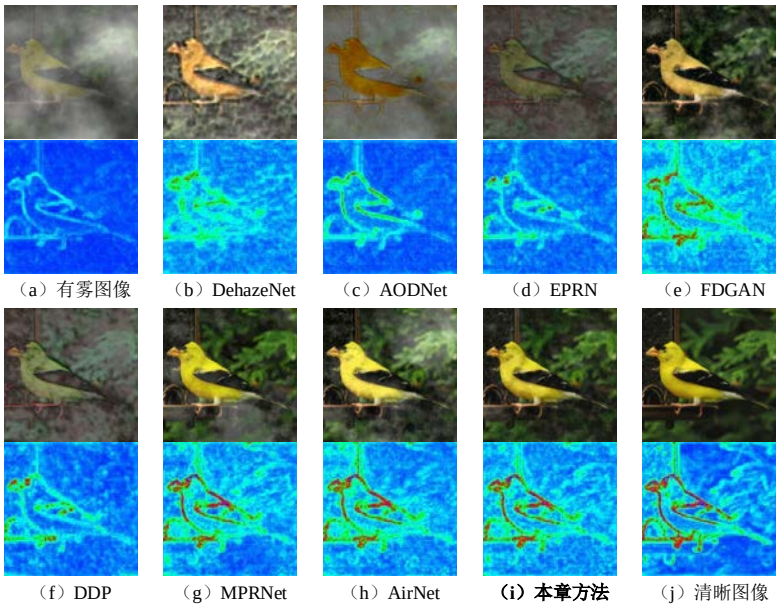


图 4.10　不同方法在 CUB[171] 数据集上去雾图像 VGG16 特征可视化

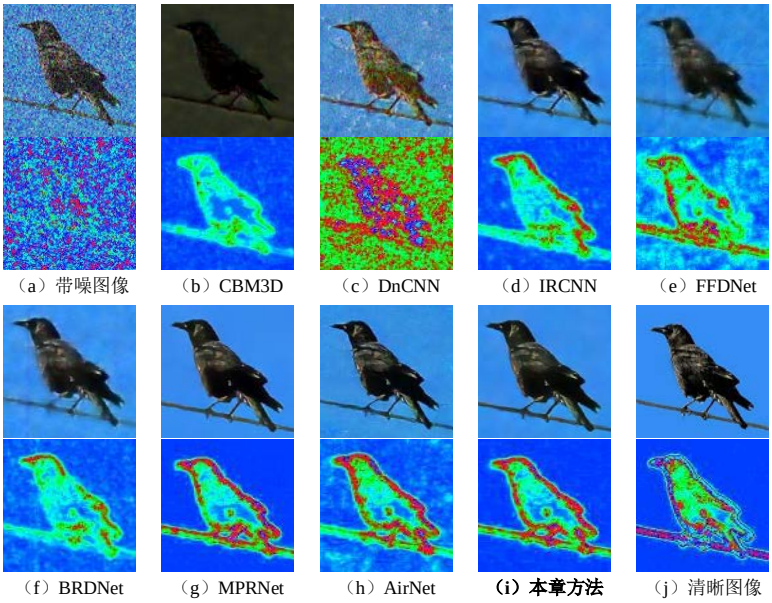


图 4.11　不同方法在 CUB[171] 数据集上去噪图像 VGG16 特征可视化

恢复越充分。可以看到，本章提出的方法能够更好地复原图像的内在语义，使得分类网络更准确的捕捉图像中用于识别的判别性特征。

（2）目标检测任务上性能提升

实验流程。本章进一步在目标检测任务上验证所提方法的有效性。在目标检测任务中的性能评估流程与上述在图像分类任务中的性能评估流程基本一致。首先在清晰的 CrowdHuman 训练集上预训练 RetinaNet[163] 作为下游识别系统。同时，训练图像复原网络。而后，将训练好的图像复原网络应用于退化的 CrowdHuman 测试集，得到复原 CrowdHuman 测试集。最后，将复原 CrowdHuman 测试集应用于预训练的 RetinaNet 中，以评估复原图像对于目标检测系统的适配性。退化图

中国知网　https://www.cnki.net

表 4.4　不同方法在 CrowdHuman[184] 数据集图像去雾后检测性能定量比较

	方法	检测性能			视觉性能	
		AP	JI	MR	PSNR	SSIM
针对单一退化图像复原方法	DehazeNet[123]	46.77	41.39	85.53	13.13	0.4935
	AODNet[47]	61.08	53.18	75.79	12.13	0.5638
	EPDN[185]	55.45	47.69	81.04	13.26	0.5784
	FDGAN[186]	74.75	63.43	65.32	17.27	0.7956
	FFANet[7]	74.71	63.11	65.56	17.35	0.7986
针对多类型退化图像复原方法	MPRNet[26]	78.64	66.52	63.60	**19.27**	**0.8569**
	AirNet[71]	78.24	65.87	64.03	19.00	0.8427
	本章方法	**79.33**	**67.58**	**63.21**	18.25	0.8256

表 4.5　不同方法在 CrowdHuman[184] 数据集图像去噪后检测性能定量比较

	方法	检测性能			视觉性能	
		AP	JI	MR	PSNR	SSIM
针对单一退化图像复原方法	CBM3D[188]	48.51	41.93	83.69	20.15	0.5426
	DnCNN[189]	56.48	48.89	78.62	22.59	0.5529
	IRCNN[24]	59.08	50.76	78.12	24.10	0.6739
	FFDNet[9]	57.88	50.63	78.27	23.94	0.6773
	BRDNet[190]	58.05	50.98	78.20	24.52	0.6874
针对多类型退化图像复原方法	MPRNet[26]	58.98	51.61	76.89	**24.98**	**0.7221**
	AirNet[71]	59.36	51.95	77.08	24.66	0.7126
	本章方法	**59.80**	**52.57**	**75.89**	24.69	0.7160

像的合成方式与图像分类相同，这里不再赘述。

对比的基准方法。针对图像去雾，本章选择针对多个单一退化的图像复原方法作为比较的基准方法，包括 DehazeNet[123]，AODNet[47]，EPDN[185]，FDGAN[186]和 FFANet[7]；针对图像去噪，本章选择 CBM3D[188]，DnCNN[189]，IRCNN[24]，FFDNet[9]和 BRDNet[190]作为用于比较的基准方法；针对图像去雨，本章选择 DIDMDN[58]，UMRL[191]，SIRR[192]，MSPFN[193]和 LPNet[8]作为基准方法。同时，针对这三个任务，都引入针对多类型退化的图像复原方法 MPRNet[26]和 AirNet[71]作为进一步比较。

定量结果。表 4.4、表 4.5和表 4.6分别展示了在 CrowdHuman 测试集上去雾、去噪和去雨之后的目标检测结果。其中，AP、JI 和 MR 分别代表平均精度、交并比以及漏检率。加粗标注的数值表示最好结果，下划线标注的数值表示次好结果。可以看出，在目标检测的相关指标上，本章提出的方法在三种不同退化情况下都取得了最好的性能。需要注意的是，表 4.4、表 4.5和表 4.6中的“本章方法”与表 4.1、表 4.2和表 4.3中“针对多类型退化图像复原方法”一栏中的“本章方法”，指的是同训练好一个模型。这进一步证明本章提出方法在针对下游不同高层识别任务的泛化性和有效性。

（3）与已有识别驱动的图像复原方法对比

中国知网　https://www.cnki.net

表 4.6　不同方法在 CrowdHuman[184] 数据集图像去雨后检测性能定量比较

	方法	检测性能			视觉性能	
		AP	JI	MR	PSNR	SSIM
针对单一退化图像复原方法	DIDMDN[58]	74.44	63.10	67.89	22.72	0.7865
	UMRL[191]	76.36	64.49	66.51	23.16	0.8089
	SIRR[192]	78.05	66.26	64.47	26.21	0.8651
	MSPFN[193]	78.21	66.54	63.99	26.44	0.8720
	LPNet[8]	78.28	66.68	63.79	26.48	0.8731
针对多类型退化图像复原方法	MPRNet[26]	78.49	66.81	63.73	**27.41**	**0.8934**
	AirNet[71]	77.76	66.29	64.53	26.61	0.8792
	本章方法	**78.68**	**67.20**	**63.51**	26.53	0.8886

本章进一步将所提方法与现有的识别驱动的图像复原方法进行比较。具体而言，选择在 CUB 数据集上的图像分类任务，将本章方法与 URIE[95] 进行对比。URIE 针对性地设计了图像复原网络结构，并将该图像复原网络与已经预训练好的识别任务模型级联，通过最小化识别损失函数来训练图像复原网络。需要注意的是，URIE 在训练过程中引入了额外的语义标签，而本章所提方法则无需语义标签。图 4.12展示了本章方法与 URIE 的在 CUB 数据集上图像去雾后分类性能定量比较结果。可以看出，本章方法相比于基准方法 URIE 在 Top-1V 和 Top-1R 两个指标上分别提升 5.81% 和 2.95%，进一步验证了本章方法的有效性。

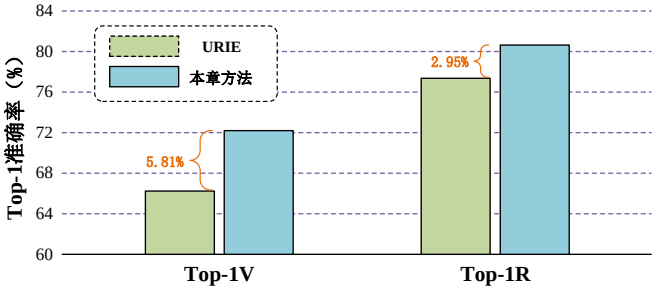


图 4.12　不同方法在 CUB[171] 数据集图像去雾后分类性能定量比较

（4）更多讨论

从图像分类和目标检测的性能比较可以看出，本章方法复原的图像能够更有效地适配于下游的视觉识别任务。传统的图像复原方法主要从视觉质量增强的角度修复退化图像，而非从面向识别任务的角度。因此，这些方法在视觉指标上可能表现更优，但是在识别准确率上却难以令人满意。例如在表 4.1和表 4.2中，MPRNet 在 PSNR 和 SSIM 等指标上表现出色，但是在 Top-1V 和 Top-1R 指标上明显落后于本章所提方法。这也进一步证明了本章在引言中提到的问题，即图像的视觉质量和其在下游识别任务中所需的识别质量存在本质上的差异，同时也说明了研究识别驱动图像复原方法的重要性。同时，通过对比图像分类和目标检测的结果也可以发现，不同图像退化对于图像的视觉质量和语义质量的影响是存在显著差异的。例如，各类图像复原方法一般在图像去噪任务上可以取得相对

中国知网　https://www.cnki.net

较高的 PSNR 值，然而复原图像在图像分类和目标检测任务上的性能却都较低；而在图像去雾任务中，情况则相反，各类图像去雾方法的 PSNR 指标相对较低，但是复原图像在图像分类和目标检测任务中的性能却普遍较高。本章推测这主要是由于不同的退化类型对于图像的不同频带有着不同的影响。

在另一方面，上述的实验结果也证明了本章方法在面向多种下游视觉识别任务时所具有的优秀泛化能力。例如，在表 4.1和表 4.4中，“针对多类型退化图像复原方法”一栏中的“本章方法”，指的是同一个复原网络模型。即本章所提方法在经过单次训练之后，能够同时服务于多种下游视觉识别任务，展示其较强的综合应用性。本章所提方法便是旨在针对下游视觉识别任务未知的实际应用场景。而事实上，如果在下游识别任务和模型已知的前提下，可以将本章中特征提取器替换为该特定的下游识别网络，使得训练的图像复原网络可以更加专一地服务于该特定的下游识别任务。这种针对性设计可以有效提升复原网络针对该特定下游识别系统的兼容性，并提升该识别系统的整体性能。然而，这种训练方法却容易使得复原网络过拟合到该特定识别系统的模式上，进而导致复原网络对其他下游视觉识别任务适配性和泛化性的下降。关于这一问题将在下一章中进行重点分析讨论。综上所述，在实际应用中，需要考虑图像复原网络在提升特定识别任务性能和跨识别任务泛化能力之间的平衡。

4.4.4　消融实验

本节通过一系列消融实验来证明本章设计的网络模块、训练策略和损失函数的有效性。本章所有的消融实验都选择在 CUB[171] 数据集上进行，通过复原图像在预训练 VGG16 分类器中的 Top-1V 指标来表明性能。

（1）内在语义增强模块的有效性分析

为了消除退化信息对图像语义特征的影响，本章提出了内在语义增强模块。该模块由退化归一化补偿模块和傅里叶引导调制模块组成。为了验证这两个模块的有效性，本节设置了多个模型变体，如表 4.7所示。其中，“模型 2”表示将退化归一化补偿模块使用一个与其有相同参数量的卷积模块替代；类似地，“模型 3”表示将傅里叶引导调制模块使用一个与其有相同参数量的卷积模块替代。而“模型 1”则表示同时替换退化归一化补偿模块和傅里叶引导调制模块。

可以看出，在预训练的 VGG16 分类器上，在图像去雾和图像去噪任务中，“模型 2”和“模型 3”的 Top-1V 准确率相比于“模型 1”分别提升了 3.39%/1.76% 和 5.24%/3.48%。在同时引入两个模块的情况下，本章所提方法在图像去雾和图像去噪的复原图像分类准确率上分别达到了 72.11% 和 32.00%。这表明了退化归一化补偿模块和傅里叶引导调制模块具有互补性，二者对本章所提方法均起到关键作用，共同促成了优秀的识别性能。

中国知网　https://www.cnki.net

表 4.7　内在语义增强模块在 Top-1V 准确率上的消融实验

方法	退化归一化补偿模块	傅里叶引导调制模块	图像去雾	图像去噪
模型 1	×	×	61.18	25.17
模型 2	×	√	64.57	26.93
模型 3	√	×	66.42	28.65
本章方法	√	√	**72.11**	**32.00**

（2）先验赋予优化策略有效性分析

为了有效提升图像复原网络对下游识别任务的适配性，本章提出了先验赋予优化策略，在两个训练阶段中分别单独优化语义感知解码器和内在语义增强模块的参数。表 4.8展示了有关先验赋予优化策略的消融实验结果，其中“模型 4”表示直接将内在语义增强模块和语义感知解码器级联，而后端到端的训练。可以看到，不采用先验赋予优化策略的方案在分类任务上出现明显的性能下降。这证明了本章所提的先验赋予优化策略能够帮助图像复原网络更好地从语义理解的角度进行图像修复，提升复原图像在下游高层视觉系统中的识别准确率。

表 4.8　先验赋予优化策略在 Top-1V 准确率上的消融实验

方法	图像去雾	图像去噪	图像去雨
模型 4	67.55	25.14	73.23
本章方法	**72.11**	**32.00**	**74.68**

（3）语义最大化约束有效性分析

为了在修复特征的过程中更好地增强特征的语义信息，本章提出了一个语义最大化约束，其实现方式是对经过最大池化后的两个特征计算余弦相似度。之前的方法通常采用 L1 损失或者均方误差损失作为约束语义恢复的损失函数。本节对语义最大化约束和以上提到两种可能的其他方案进行对比。如表 4.9所示，本章所提的语义最大化约束在面向 CUB 数据集分类的图像去雾和图像去噪任务中的分类准确率分别比 L1 约束高出 3.15%/2.47%，同时也要比使用均方误差约束方式的方案高出 3.28%/2.24%。与 L1 或者均方误差直接平等地对待特征中每个像素不同，本章所提的语义最大化约束能够挖掘两个特征之间最具价值的语义对应关系，并有效保持特征的语义一致性。

表 4.9　语义最大化约束在 Top-1V 准确率上的消融实验

约束方式	图像去雾	图像去噪	图像去雨
L1	68.96	29.53	73.59
均方误差	68.83	29.76	73.88
语义最大约束	**72.11**	**32.00**	**74.68**

（4）语义感知解码器预训练方式有效性分析

本章在 4.3.3节讨论了预训练语义感知解码器的三种可能的方式。表 4.10展示了这三种预训练方式在 CUB 数据集图像去雾任务中复原图像的分类性能，以

中国知网　https://www.cnki.net

及三种预训练方式对应的语义感知解码器的参数量。其中，“方式 1”代表只使用清晰图像语义特征预训练语义感知解码器的方式，对应于图 4.8（a）中的方案；“方式 2”代表使用清晰图像语义特征和退化图像语义特征共同训练语义感知解码器，训练目标是重建这些语义特征对应的图像，对应于图 4.8（b）中的方案。可以看出，相比于本章采用的方法，“方式 1”在使用与本章方法相同结构和参数量的语义感知解码器的情况下，其性能出现明显下降。另一方面，“方式 2”和本章方法的性能相近，但是其需要给语义感知解码器设置更大的参数量，增加了训练负担和部署难度。

表 4.10　语义感知解码器预训练方式消融实验

预训练方式	语义感知解码器参数量	Top-1V
方式 1	0.90M	64.36
方式 2	1.43M	72.18
本章方法	0.90M	72.11

4.5　本章小结

本章提出了一个面向视觉识别任务的多退化统一图像复原方法。针对现有图像复原模型在下游识别任务中适配性不佳的问题，本章从网络结构、损失函数、训练策略等多角度出发，设计了一个可以同时处理多种退化类型的面向识别任务的图像复原方法。具体来说，考虑到不同图像退化对于语义层面的不同影响，本章提出了一个内在语义增强模块，以自适应的方式动态地处理输入退化特征，并针对性地设计了语义最大化损失函数来约束其训练。同时，本章进一步提出了先验赋予优化策略，以引导内在语义增强模块从语义理解的角度对输入的退化特征进行修复增强。在多个图像复原场景和视觉识别任务上的实验结果证明了本章方法的有效性。本章部分内容在 2023 年发表于计算机视觉会议 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)。

中国知网　https://www.cnki.net

第 5 章　基于视觉感知与语义优化协同的图像复原方法

5.1　引言

在第 4 章中，本文提出了面向视觉识别任务的多退化统一图像复原方法，通过对网络结构和训练策略的精心设计，显著提升了复原图像在下游识别任务的性能。本章在第 4 章的基础上更进一步，将视野从特定网络设计拓展至更加通用的图像复原网络训练范式。鉴于已有的图像复原网络在传统训练框架下已经在视觉质量恢复方面取得了巨大成功，本章旨在设计一种识别驱动的图像复原网络训练范式，以有效约束图像复原过程中语义信息的恢复。该训练范式可以直接无缝对接并应用于到现有的各类图像复原模型中，从而有效提升复原图像在下游识别系统中的适配性。

在 4.1节中，对传统图像复原方法无法有效适配于下游识别模型的问题进行了阐述，并指出这主要是由于图像视觉质量与语义质量之间存在本质差异。为了解决这个问题，已有识别任务驱动的图像复原方法通常利用预训练视觉识别模型提供富含语义的特征空间，并通过计算复原图像与清晰图像在该特征空间中的像素级距离（例如均方误差）来约束网络的训练。然而，这类方法存在两个关键问题。第一个问题是图像复原网络对下游未见过的识别系统的泛化能力较差。由于该类方法通常将图像复原网络与特定的预训练识别模型进行耦合，并通过最小化识别损失或特征距离来引导图像复原过程。然而，由于所选择的识别模型或任务具有特定的高层语义模式，导致图像复原网络可能会过拟合到该特定的模型或者任务上。换而言之，通过该类方法训练得到的图像复原网络成为了选定识别模型或任务的“定制化”预处理模块，难以有效泛化到其他未见过的识别系统中，如图 5.1（a）所示。第二个问题在于不合理的语义损失函数计算方式。现有的研究[90,194]通常采用像素级约束来评估语义空间中语义特征的相似性，如图 5.1（c）所示。然而，这种优化方式将语义特征空间中每个像素视为同等重要，难以捕捉特征中不同区域对语义表达的贡献差异，无法精准评估复原图像与清晰图像之间的语义相似性[89]。因此，所恢复的语义信息往往是不充分的，难以有效提升复原图像在后续识别系统中的性能。

为了解决上述问题，本章提出了一个新颖的基于视觉感知与语义优化协同的图像复原方法，旨在提升图像复原模型在各类下游识别系统上的泛化性与有效性。具体而言，本章通过联合优化语义恢复与图像重建目标函数来训练图像复原模型，其中，语义恢复作为主要优化目标以增强复原图像对于下游识别任务的适配性，而图像重建目标则作为正则项约束优化过程。为了使图像复原网络具备更好地泛化能力，本章设计了一种动态梯度校正策略，如图 5.1（b）所示。当语

中国知网　https://www.cnki.net

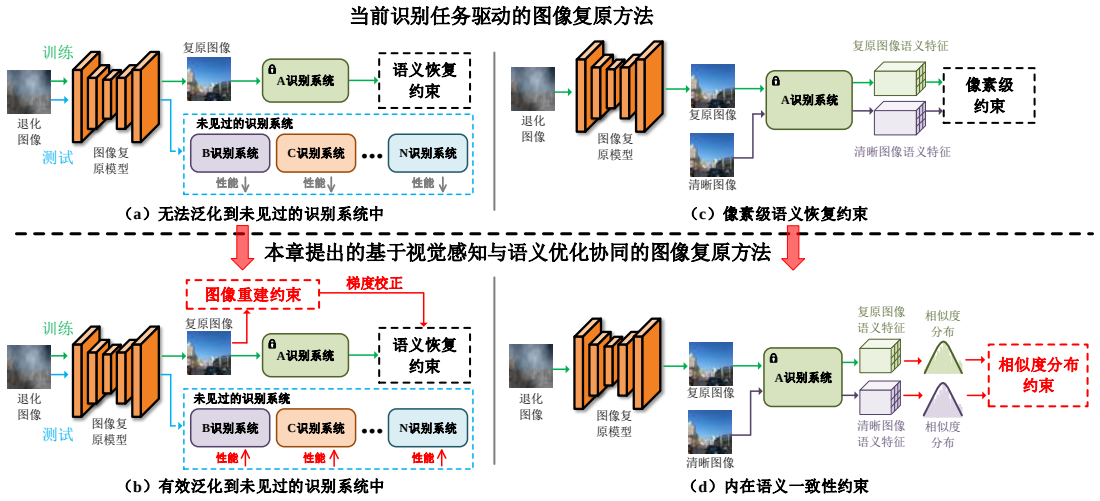


图 5.1　已有识别任务驱动图像复原方法的与本章提出的方法比较

义恢复梯度与图像重建梯度在优化空间中发生冲突时，将对语义恢复的梯度进行校正；反之，则保持不变。该策略使图像复原网络可以充分探索通用低层视觉和特定高层视觉之间共同的优化空间，从而避免图像复原网络在选定的高层识别模型或任务上出现过拟合，进而提升其针对下游未知识别系统的泛化能力。同时，为了进一步保留复原图像中的语义信息，本章设计了一个内在语义一致性约束，用以衡量复原图像与清晰图像在语义特征空间中的相似性，如图 5.1（d）所示。该约束能够充分挖掘高层语义的统计特性，并匹配其复原图像与清晰图像间的相似度分布以实现更准确地高层语义恢复。此外，本章还提出了一种清晰图像增强策略，以增强语义恢复的鲁棒性。值得注意的是，本章提出的框架无需依赖特定识别任务的语义标注数据进行训练。它与现有的图像复原方法相互独立，可以直接嵌入到现有的图像复原模型中，从而在不增加推理阶段计算开销的情况下，有效提升复原图像在各类下游识别任务的性能。

本章所提出的主要内容和贡献可以总结如下：（1）本章提出了一种新颖的基于视觉感知与语义优化协同的图像复原方法。该方法兼具通用性和有效性，能够显著提升现有图像复原方法在多种下游高层识别任务中的泛化能力和性能。（2）设计了一个动态梯度校正策略，通过动态的方式调整语义恢复损失函数的梯度，从而显著提升复原网络针对未见过的下游识别系统的泛化能力。（3）提出了一种内在语义一致性约束，用于挖掘复原图像和清晰图像之间的语义关联，以实现更精准的语义恢复。同时，提出了一种清晰图像增强策略，以提升语义恢复的鲁棒性。（4）将本章设计的框架应用于现有的图像复原网络中，并在包括图像分类和目标检测在内的多种视觉识别任务上进行性能评估。实验结果表明，在不同退化条件下，本章方法在识别任务中具有明显优势，同时，本章的方法不会额外增加图像复原模型推理过程的计算开销。

本章的后续安排如下：　5.2节介绍本章所提的基于视觉感知与语义优化协同

中国知网　https://www.cnki.net

的图像复原方法，包括动态梯度校正策略、内在语义一致性约束以及清晰图像增强策略； 5.3节将本章所提的训练范式应用于多个现有的图像复原模型中，并在图像分类和目标检测两个视觉识别任务上验证本章所提方法的有效性；最后，5.4节对本章所提方法进行总结。

5.2　视觉感知与语义优化协同的网络训练框架

在本节中，首先对本章所提的基于视觉感知与语义优化协同的图像复原方法进行整体介绍。而后，具体介绍该框架内的动态梯度校正策略，内在语义一致性约束和清晰图像增强策略。

5.2.1　整体框架描述

在本章中，训练集可以表示为 $D = \{(x_i, y_i)\}_{i=1}^{N}$，其中 x_i 代表第 i 张退化图像，y_i 代表 x_i 对应的清晰图像，N 代表数据集 D 中所有样本的数量。给定一个参数为 θ 的图像复原模型 f_{IR}，本章的目标是训练 f_{IR} 使其复原的图像能够有效提升在各种下游识别任务上的性能。

图 5.2中展示了本章所提方法的整体框架。整个训练流程可以分为三个部分。首先计算重建损失函数 $\mathcal{L}_{rec}$。具体而言，对于给定的退化-清晰图像对 (x_i, y_i)，将 x_i 输入到图像复原网络 f_{IR} 中，获得对应的复原图像 y_i^r，并计算 y_i^r 与 y_i 之间的重建损失 $\mathcal{L}_{rec}$，其计算方式如公式 5.1所示。而后，计算语义恢复约束 $\mathcal{L}_{sem}$。具体来说，首先对清晰图像 y_i 使用数据增强策略，得到增强后的清晰图像 $\hat{y}_i$（如图 5.2紫色框所示）。随后，将复原图像 y_i^r 与增强清晰图像 $\hat{y}_i$ 输入到参数固定的预训练识别模型中，并计算用于语义恢复的语义恢复约束 $\mathcal{L}_{sem}$（如图 5.2中蓝色框所示）。最后，基于重建损失函数 $\mathcal{L}_{rec}$ 和语义恢复约束 $\mathcal{L}_{sem}$ 对图像复原网络 f_{IR} 进行联合优化，并使用 5.2.2节中提出的动态梯度校正策略约束优化过程。算法 5.1完整地展示了整个训练流程。

可以看到，本章所提方法的整体优化目标由两个损失函数组成：其一是语义恢复损失函数 $\mathcal{L}_{sem}(\theta)$，该损失函数通过参数固定的预训练识别模型计算得到；其二是重建损失函数 $\mathcal{L}_{rec}(\theta)$。在训练过程中，语义恢复损失的梯度 $\nabla\mathcal{L}_{sem}(\theta)$ 会被动态校正，以提升在下游识别任务中的性能和泛化能力，具体操作将在 5.2.2中进行详细描述。对于语义恢复损失函数 $\mathcal{L}_{sem}(\theta)$ 的计算，本章采用与第 4 章相似的方式，引入了一个预训练识别模型 f_{ext}。该模型在大规模数据集上进行了预训练，旨在提供语义丰富的特征表示空间。为了更好地实现语义的恢复，本章设计了一个内在语义一致性约束，通过匹配复原图像和清晰图像的语义统计分布来探索它们之间的语义关系，具体计算方式在 5.2.3中进行详细描述。此外，本

中国知网　https://www.cnki.net

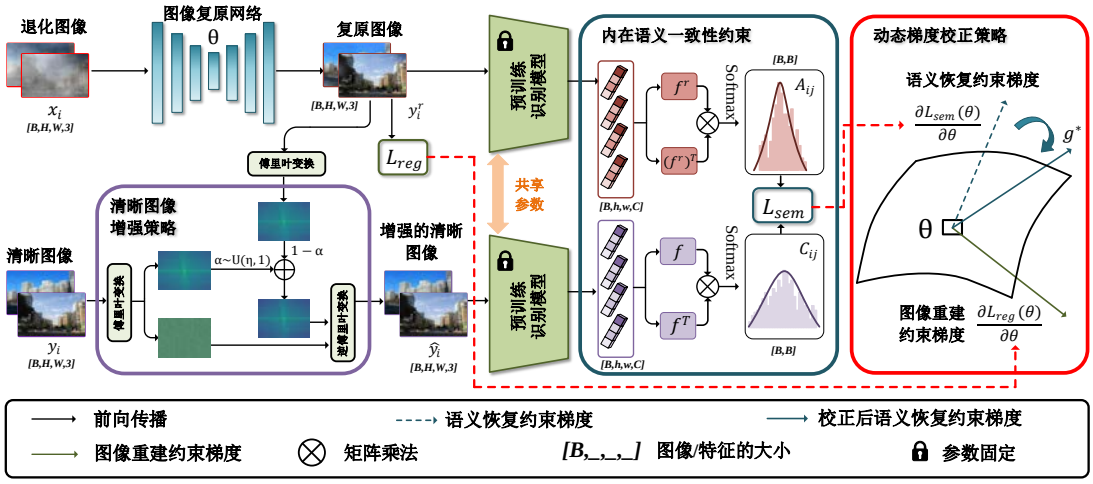


图 5.2　基于视觉感知与语义优化协同的图像复原方法

章引入了一种基于傅里叶变换的清晰图像增强策略。在计算语义恢复损失函数 $\mathcal{L}_{sem}(\theta)$ 时，不直接使用原始的清晰图像 y_i，而是采用其增强版本 $\hat{y}_i$。其中，$\hat{y}_i$ 是通过对 y_i 的幅度谱进行扰动，同时保持其相位谱不变的方式获得的。相关细节在 5.2.4中进行详细描述。

5.2.2　动态梯度校正策略

本节首先阐述提出动态梯度校正策略的动机及整体概述，而后展示详细的数学推导过程。最后，进一步讨论该策略与其他训练策略之间的对比分析。

（1）动态梯度校正策略提出的动机

正如在 5.1节中所述，现有的识别驱动图像复原方法可能会导致图像复原网络过拟合到选定的预训练识别模型的特定模式中，从而导致泛化能力不足。相比之下，只使用图像重建约束的图像复原方法由于不依赖任何预训练的识别模型，因此在面对多样的识别系统时具有较好的泛化能力。具体而言，图像重建约束要求复原图像与清晰图像在像素空间保持一致，这意味这该约束具有较强的通用性。同时，图像重建约束可以一定程度上使复原图像的语义信息向清晰图像靠拢，进而使其能够适应于各种下游的视觉识别任务。然而，图像重建约束无法直接针对图像的语义进行优化，因此限制了其在下游视觉识别任务中的性能[90]。与之相对的，基于特定视觉识别模型计算的语义约束能够有效拉近复原图像和清晰图像在该模型特征空间中的语义距离，但却无法保证对于其他未见过的识别模型也能实现相似的效果，即在面对未见过的下游识别系统时，其泛化能力较差。这两种损失函数展示出的互补性是动态梯度校正策略提出的动机。本章将图像重建约束作为正则项引入，用于对语义恢复约束进行校正，在实现语义信息恢复的同时提升图像复原网络针对下游识别任务的泛化能力。

（2）动态梯度校正策略整体概述

中国知网　https://www.cnki.net

给定一张退化图像 x_i，将其输入到参数为 θ 图像复原网络 f_{IR} 中可以得到复原图像 y_i^r，该过程可以表示为 $y_i^r = f_{IR}(x_i)$。由于本章的目标是复原图像以提升其在下游识别任务中的性能，而非单纯追求人眼视觉质量，因此本章通过一个预训练的识别模型 f_{ext} 来计算语义恢复约束 $\mathcal{L}_{sem}(\theta)$，以确保复原图像的语义完整性。$\mathcal{L}_{sem}(\theta)$ 的具体计算方式将在 5.2.3节中详细叙述。

考虑到只使用 $\mathcal{L}_{sem}(\theta)$ 训练可能会使图像复原网络过拟合到选定的预训练识别模型 f_{ext} 上，因此本章引入了图像重建损失函数 $\mathcal{L}_{rec}(\theta)$ 作为正则项，其计算方式可以表示为：

$$\mathcal{L}_{rec}(\theta) = \|y_i^r - y_i\|_1, \tag{5.1}$$

其中，$\|\cdot\|_1$ 代表 L1 范数，y_i 为 x_i 对应的清晰图像。

然而，在使用 $\mathcal{L}_{sem}$ 和 $\mathcal{L}_{rec}$ 进行联合优化时，存在一个关键问题：由于凸性差异[195]，这两个目标在联合优化过程中可能会相互冲突，进而导致图像复原网络在下游识别任务中的性能未能达到最优且泛化能力有限。为了更好地平衡这两种约束，本节提出了一种动态梯度校正策略以校正 $\mathcal{L}_{sem}(\theta)$ 的梯度。

事实上，对于任何下游识别模型而言，由图像复原模型从退化输入 x_i 中复原得到的理想增强图像 y_i^{r*} 应该与清晰图像 y_i 完全一样，即两者在像素空间完全一致。此时，理想复原图像 y_i^{r*} 与清晰图像 y_i 在任何下游识别模型中的语义表示也必然相同。因此，可以推断出 $\mathcal{L}_{sem}(\theta)$ 的临界点（Critical Point）应被 $\mathcal{L}_{rec}(\theta)$ 的临界空间（Critical Space）所涵盖。换言之，当图像复原网络的模型参数 θ 的一次优化能同时降低 $\mathcal{L}_{sem}(\theta)$ 和 $\mathcal{L}_{rec}(\theta)$，则此次优化是有利的，其不但提升了语义恢复的效果，同时保证了在下游识别任务上的泛化性，如图 5.3（a）所示。另一方面，如果这两项约束的优化方向相互冲突，说明此时 $\mathcal{L}_{sem}(\theta)$ 向着过度拟合选定识别模型的方向优化，此时应对语义恢复 $\mathcal{L}_{sem}(\theta)$ 的梯度进行校正，以保证泛化性能，如图 5.3（b）所示。由于图像重建损失函数 $\mathcal{L}_{rec}(\theta)$ 的计算并不依赖于预训练识别模型 f_{ext}，可以将其作为约束语义恢复 $\mathcal{L}_{sem}(\theta)$ 的正则项。因此，在第 t 步时网络参数 θ 的优化可以表示为：

$$\begin{aligned} &\theta^{t+1} = \arg\min_{\theta} \mathcal{L}_{sem}(\theta), \\ &s.t. \quad \mathcal{L}_{rec}(\theta) \leqslant \mathcal{L}_{rec}(\theta^t). \end{aligned} \tag{5.2}$$

为了便于计算，将上述公式 5.2中的约束条件 $\mathcal{L}_{rec}(\theta) \leqslant \mathcal{L}_{rec}(\theta^t)$ 替换为 $\left\langle \nabla\mathcal{L}_{sem}(\theta^t), \nabla\mathcal{L}_{rec}(\theta^t) \right\rangle \geqslant 0$，其中，$\nabla$ 代表对参数 θ 求导 $\frac{\partial}{\partial\theta}$，而 $\langle\cdot\rangle$ 代表内积操作。也就是说，使用 $\nabla\mathcal{L}_{sem}(\theta)$ 和 $\nabla\mathcal{L}_{rec}(\theta)$ 之间的对齐程度作为约束，从而确保图像复原模型对各种下游识别任务具有较好的泛化能力。当此约束被满足时，$\nabla\mathcal{L}_{sem}(\theta^t)$ 能够有效提升在下游识别任务上的性能；反之，则需要对 $\nabla\mathcal{L}_{sem}$ 的方向进行校正。本章采用文献[196]中使用的校正方法，寻找与原始梯度 $\nabla\mathcal{L}_{sem}(\theta^t)$

中国知网　https://www.cnki.net

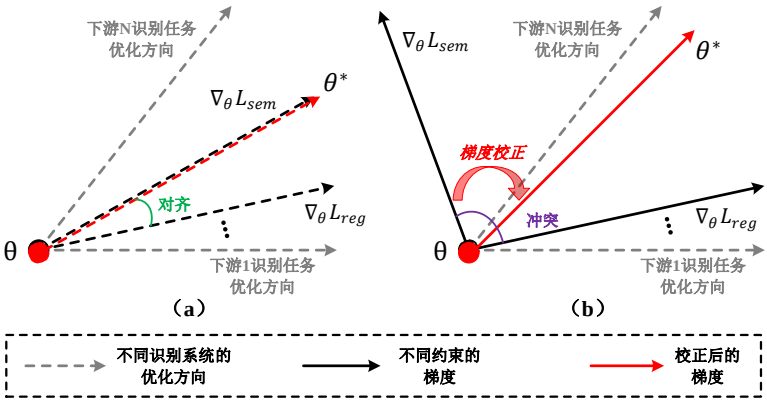


图 5.3　动态梯度校正策略

距离最近且满足约束条件的候选解。这里将校正后的梯度 $\nabla\mathcal{L}^c_{sem}(\theta)$ 记作 g^*，其可以表示为：

$$\begin{aligned} g^* &= \arg\min_g \frac{1}{2}\|g - \nabla\mathcal{L}_{sem}(\theta^t)\|_2^2, \\ s.t. \quad &\left\langle g, \nabla\mathcal{L}_{rec}(\theta^t)\right\rangle \geqslant 0. \end{aligned} \tag{5.3}$$

公式 5.3中的优化问题可以通过拉格朗日乘子法（Lagrange Multiplier）来求解。为了简便起见，将内积记作 $Q = \left\langle \nabla\mathcal{L}_{sem}(\theta^t), \nabla\mathcal{L}_{rec}(\theta^t)\right\rangle$。根据 Karush-Kuhn-Tucker 条件推广，最终校正后的梯度 g^* 可以表示为：

$$g^* = \nabla\mathcal{L}_{sem}(\theta^t) - \mathbb{I}(Q < 0) \cdot \frac{Q}{\|\nabla\mathcal{L}_{rec}(\theta^t)\|_2^2} \cdot \nabla\mathcal{L}_{rec}(\theta^t), \tag{5.4}$$

其中，$\mathbb{I}(\cdot)$ 代表指示函数，当括号内条件满足时输入 1，否则输出 0。下面详细给出从公式 5.3到 5.4的详细推导过程。

（3）动态梯度校正算法的详细推导

针对公式 5.3中的优化问题,可以采用拉格朗日乘子法进行求解。基于 Karush-Kuhn-Tucker 条件的推广，拉格朗日函数可以表示为：

$$\mathcal{L}(g, \lambda) = \frac{1}{2}\|g - \nabla\mathcal{L}_{sem}(\theta^t)\|_2^2 + (-\lambda\left\langle g, \nabla\mathcal{L}_{rec}(\theta^t)\right\rangle). \tag{5.5}$$

首先将 $\mathcal{L}(g, \lambda)$ 关于 g 的导数置 0，即 $\frac{\partial\mathcal{L}(g,\lambda)}{\partial g} = 0$，该过程可以表示为：

$$\frac{\partial}{\partial g}\left[\frac{1}{2}\|g - \nabla\mathcal{L}_{sem}(\theta^t)\|_2^2\right] - \frac{\partial}{\partial g}(\lambda\left\langle g, \nabla\mathcal{L}_{rec}(\theta^t)\right\rangle) = 0. \tag{5.6}$$

通过求解公式 5.6，可以求得最优 g 的表示形式为：

$$g = \nabla\mathcal{L}_{sem}(\theta^t) + \lambda\nabla\mathcal{L}_{rec}(\theta^t). \tag{5.7}$$

随后，将公式 5.7中得到的 g 代入到公式 5.5中，得到 $\mathcal{L}^*(\lambda)$，其形式可以表示为：

$$\mathcal{L}^*(\lambda) = -\lambda\left\langle \nabla\mathcal{L}_{sem}(\theta^t), \nabla\mathcal{L}_{rec}(\theta^t)\right\rangle - \frac{1}{2}\lambda^2\|\nabla\mathcal{L}_{rec}(\theta^t)\|_2^2. \tag{5.8}$$

中国知网　https://www.cnki.net

进一步，将 $\mathcal{L}^*(\lambda)$ 关于 λ 的导数置 0，即：

$$\frac{\partial \mathcal{L}^*(\lambda)}{\partial \lambda} = 0. \tag{5.9}$$

通过求解公式 5.9，可以得到 λ 的形式为：

$$\lambda = -\mathbb{I}(\left\langle \nabla \mathcal{L}_{sem}(\theta^t), \nabla \mathcal{L}_{rec}(\theta^t) \right\rangle < 0) \cdot \frac{\left\langle \nabla \mathcal{L}_{sem}(\theta^t), \nabla \mathcal{L}_{rec}(\theta^t) \right\rangle}{\|\nabla \mathcal{L}_{rec}(\theta^t)\|_2^2}. \tag{5.10}$$

而后，将公式 5.10中的 λ 代入到公式 5.7中，并将 $Q = \left\langle \nabla \mathcal{L}_{sem}(\theta^t), \nabla \mathcal{L}_{rec}(\theta^t) \right\rangle$ 代入，便可以得到公式 5.4中最终语义恢复约束的修正梯度 g^*。

综上所述，最终的优化目标可以表示为：

$$\mathcal{L}_{total}(\theta^t) = \mathcal{L}^*_{sem}(\theta^t) + \mathcal{L}_{rec}(\theta^t), \tag{5.11}$$

其中，$\mathcal{L}_{total}(\theta^t)$ 代表最终的优化目标，$\mathcal{L}^*_{sem}(\theta^t)$ 代表带有梯度校正的语义约束。

（4）讨论

图 5.4展示了不同方法中各种训练策略的优化轨迹。本章的目标是引导图像复原模型 θ_i 的优化朝向内在语义恢复，即从 θ_i 优化至 θ_o，从而使图像复原模型能够适应各种各样的未知下游识别任务。策略 1（从 θ_i 优化至 θ_r）展示了只使用重建损失函数的传统图像复原方法。这类方法主要关注于视觉质量的提升，而忽视了语义质量的增强，因此无法有效提升在下游高层识别任务中的性能。策略 2（从 θ_i 优化至 θ_p）代表现有的识别任务驱动的图像复原方法。这些方法仅使用语义损失函数 $\mathcal{L}_{sem}$ 而考虑重建损失函数 $\mathcal{L}_{rec}$。这类方法往往容易过拟合到所选择的识别模型的模式上，导致其对未见过的识别系统泛化能力较差。策略 3（从 θ_i 优化至 θ_b）代表使用 $\mathcal{L}_{sem}$ 和 $\mathcal{L}_{rec}$ 来联合训练图像复原模型，但没有添加约束机制。尽管这种训练方式尝试兼顾视觉质量与语义质量，但是由于两种损失函数在优化空间中潜在的冲突，导致难以实现两种约束的有效集成。策略 4（从 θ_i 优化至 θ_o）代表本章提出的动态梯度校正策略。该策略通过动态校正的方式有效协调了图像重建与语义恢复两种约束的优化关系，同时鼓励图像复原模型探索低层视觉感知和高层语义理解所共有的优化空间，有效恢复图像的内在语义信息，从而在各种下游视觉识别任务中获得更优的性能和更强的泛化能力。

事实上，动态梯度校正策略与持续学习（Continual Learning）[196-197] 领域中的思想有共同之处。在持续学习中，研究者们探索并优化不同任务间梯度的关系，旨在使模型学习解决新问题的同时，保留已获取的知识，从而实现持续学习的目标。从探索并优化不同任务间梯度关系的思路上，本章所提的动态梯度校正策略与持续学习有相似之处。然而，本章研究聚焦于低层图像复原与高层识别任务之间的关系，并拓展了持续学习中关于梯度关系的探索。具体而言，本章所提

中国知网　https://www.cnki.net

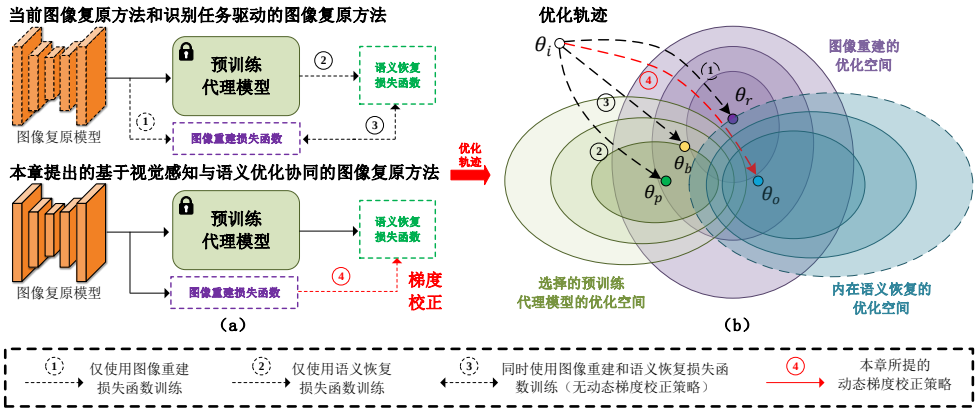


图 5.4　不同训练策略对应的优化轨迹

的动态梯度校正策略利用图像重建约束的梯度对语义恢复约束的梯度进行校正，从而挖掘探索低层视觉与高层视觉所共享的优化空间。通过这种方式，本章所提出的方法不仅能够在恢复图像时保持其高质量的视觉效果，同时也能在下游高层识别任务上展现出更优的性能和更强的泛化能力。

5.2.3　内在语义一致性约束

为了更好地提升复原图像的语义属性，需要一种度量指标来精确衡量图像之间的语义差异。现有的许多研究通过基于像素级的损失函数（如均方误差损失）来计算复原图像与清晰图像在语义特征空间中的距离。然而，这类像素级约束忽视了图像固有的语义相关性，因此无法有效地反映图像之间的语义关系。

近期许多研究表明[198-200]，通过统计分布可以有效表征图像的内在语义。因此，本章计划借助基于统计分布的约束来更精确地衡量图像间的语义关系。本节提出了一种内在语义一致性约束，用于挖掘复原图像和清晰图像在小批量样本中的语义统计差异。具体而言，利用清晰图像之间的语义相似性作为真实标签，对复原图像的语义相似性进行监督，从而在复原图像和清晰图像之间保持语义一致性，其计算过程如图 5.2蓝色框所示。

对于一个小批量的输入退化图像 $x \in \mathbb{R}^{B\times H\times W\times 3}$，将其输入到图像复原模型 f_{IR} 中，可以得到复原图像 $y^r \in \mathbb{R}^{B\times H\times W\times 3}$，其中，$B$ 表示小批量样本的数量，H 和 W 表示图像的高度和宽度，3 表示图像的 R，G，B 三个通道维度。之后，将得到的复原图像 y^r 输入到预训练的识别模型 f_{ext} 中提取语义特征，即 $f^r = f_{ext}(y^r)$，其中 $f^r \in \mathbb{R}^{B\times h\times w\times C}$，其中，$h$ 和 w 表示语义特征的高度和宽度，C 为语义特征的通道数。随后，通过 Softmax 操作将语义相似性转换为预测分布 A：

$$A_{ij} = \frac{\exp(\left\langle f_i^r, f_j^r \right\rangle / \tau)}{\sum_{m=1}^{B} \exp(\left\langle f_i^r, f_m^r \right\rangle / \tau)}, \quad i, j = 1, ..., B \tag{5.12}$$

其中，f_i^r，f_j^r 和 f_m^r 代表小批量语义特征 f^r 中的单张图像的语义特征，τ 为软实例

中国知网　https://www.cnki.net

温度超参数，根据经验，在本章实验中设置为 0.5。$A \in \mathbb{R}^{B\times B}$ 代表小批量样本中每张图像与其他图像之间的语义相似度。识别模型 f_{ext} 是在大规模数据集上预训练的识别模型，在本章的实验中，选择在 ImageNet[168] 上预训练的 VGG16[134] 作为该提供语义空间的识别模型。

对于对应的增强后清晰图像 $\hat{y}$（即 y 的增强版本），采用相同的处理方式。首先，使用预训练识别模型获得 $\hat{y}$ 对应的语义特征，即 $f = f_{ext}(\hat{y})$。而后，计算目标分布 C，该过程可以表示为：

$$C_{ij} = \frac{\exp(\langle f_i, f_j \rangle / \tau)}{\sum_{m=1}^{B} \exp(\langle f_i, f_m \rangle / \tau)}, \quad i, j = 1, ..., B \tag{5.13}$$

其中，f_i，f_j 和 f_m 代表小批量语义特征 f 中的单张图像语义特征。

随后，采用 KL 散度（Kullback-Leibler Divergence）度量来衡量两个分布之间的差异，并构建相应的内在语义一致性约束损失函数，该过程可以表示为：

$$\mathcal{L}_{sem} = \mathcal{D}_{KL}(A||C), \tag{5.14}$$

其中，$\mathcal{D}_{KL}$ 表示 KL 散度。

需要注意的是，语义统计分布是通过在小批量样本中计算两两图像语义特征之间的内积获得的。该操作的目的是在小批量样本内部获得图像之间的成对相似性分布，用以表示每个样本选择其邻近样本的概率，从而构建一种更加全局的语义关系。已有相关研究证明，这种建模方式能够有效刻画特征空间的几何结构，并进一步表征图像中所蕴含的内在语义[201-202]。与常用的特征空间逐像素级的约束相比，本章所提出的内在语义一致性约束能够更好地约束图像中语义信息的恢复。另一方面，本章采用的预训练识别模型 f_{ext} 与第 4 章相同，均选用了在 ImageNet[168] 上预训练的 VGG16[134] 网络。无论是本章还是第 4 章，方法设计的目标便是希望训练出来的图像复原网络具有较强的泛化性，能够有效适配多种下游视觉识别系统。而这就要求预训练识别模型 f_{ext} 提供的语义空间要尽可能地具有通用性，以避免出现 5.1节中提到的复原网络过拟合到特定模型或任务模式上的问题。Palacio 等人[203] 发现，利用 VGG 网络作为分类器约束训练出来的自编码器具有较强通用性和泛化性，可以有效适配到其他的网络架构中。这证明了相较于其他网络架构，VGG 网络可以提供更为通用的语义监督信号。受此启发，本章以及第 4 章都采用预训练的 VGG16 网络来提供语义空间，以增强图像复原网络的泛化性，使其能够有效适配于不同的下游识别任务。

5.2.4　清晰图像增强策略

为了实现更优的语义恢复效果，本章进一步在内在语义一致性约束中引入了一种清晰图像增强策略，以提升语义增强的鲁棒性，如图 5.2紫色框所示。对

中国知网　https://www.cnki.net

算法 5.1　基于视觉感知与语义优化协同的图像复原方法

Require: 初始化图像复原网络 f_{IR} 及其参数 θ，训练数据集 $D = \{(x_i, y_i)\}_{i=1}^{N}$，
预训练识别模型 f_{ext}，第 t 步迭代时的学习率 ϵ_t;
Ensure: 图像复原网络 f_{IR} 训练后的参数 θ^*;
for 第 t 步迭代时每小批量样本 $(x, y) \subseteq D$ **do**
　步骤 1：得到复原图像 y^r
　将退化图像 x 输入到图像复原模型 f_{IR} 中，输出复原图像 y^r，
　即 $y^r = f_{IR}(x)$;
　步骤 2：获得增强清晰图像 $\hat{y}$
　利用傅里叶变换，使用复原图像 y^r 的幅度谱对清晰图像 y 的幅度谱
　进行增强，详见公式 5.15;
　通过傅里叶逆变换，得到增强后的清晰图像 $\hat{y}$;
　步骤 3：计算重建损失函数 $\mathcal{L}_{rec}(\theta)$
　利用复原图像 y^r 与清晰图像 y，计算重建损失函数 $\mathcal{L}_{rec}(\theta)$，详见公式 5.1;
　步骤 4：计算语义恢复损失函数 $\mathcal{L}_{sem}(\theta)$
　将复原图像 y^r 和增强清晰图像 $\hat{y}$ 分别输入到预训练识别模型 f_{ext} 中，
　获得对应语义特征 f^r 和 f，即 $f^r = f_{ext}(y^r)$ 和 $f = f_{ext}(\hat{y})$;
　根据获得的复原图像语义特征 f^r 和增强清晰图像语义特征 f，计算
　内在语义一致性约束 $\mathcal{L}_{sem}(\theta)$，详见公式 5.12，5.13和 5.14;
　步骤 5：基于动态梯度校正策略优化网络参数 θ
　计算校正后的语义恢复约束的梯度 g^*，详见公式 5.4;
　优化更新图像复原网络参数：$\theta^{t+1} = \theta^t - \epsilon_t(g^* + \nabla\mathcal{L}_{rec}(\theta^t))$;
end for
输出：训练好的图像复原网络参数 θ^*;

于给定的退化图像 x_i，将其送入图像复原模型 f_{IR} 中获得复原图像 y_i^r。在将 y_i^r 送入到预训练识别模型 f_{IR} 之前，首先将 y_i^r 对应的清晰图像 y_i 施加傅里叶变换，将其从空间域转换到频率域 $\mathcal{F}(y_i)$，并进一步得到对应的幅度谱 $\mathcal{A}(y_i)$ 和相位谱 $\mathcal{P}(y_i)$。傅里叶变换的相关计算过程已经在 4.3.2中进行过介绍，在此不再赘述。使用相同的方式，也可以得到复原图像 y_i^r 对应的幅度谱 $\mathcal{A}(y_i^r)$ 和相位谱 $\mathcal{P}(y_i^r)$。而后，使用 $\mathcal{A}(y_i^r)$ 对 $\mathcal{A}(y_i)$ 进行扰动，从而获得增强后的幅度谱 $\mathcal{A}(\hat{y}_i)$，该过程可以表示为：

$$\mathcal{A}(\hat{y}_i)(u, v) = \alpha\mathcal{A}(y_i)(u, v) + (1 - \alpha)\mathcal{A}(y_i^r)(u, v), \tag{5.15}$$

其中，$\alpha \sim U(\eta, 1)$ 代表从均匀分布 $U(\eta, 1)$ 中采样得到的权重参数，用于增加随机性。参数 η 决定了增强的程度。在本章实验中，η 设置为 0.8。随后，利用增强的幅度谱 $\mathcal{A}(\hat{y}_i)$ 和原始的相位谱 $\mathcal{P}(y_i)$ 重新计算增强后的频域表示 $\mathcal{F}(\hat{y}_i)$，并通过逆傅里叶变换得到增强后的清晰图像 $\hat{y}_i$。

清晰图像增强策略的动机在于，图像的幅度谱主要承载低层统计信息，例如图像的风格、退化等信息，而图像的相位谱则保留了图像的高层语义信息[180,204]。这一点也在 4.3.2节中进行了相关的讨论。受到文献[205]中利用幅度谱干扰进行鲁棒语义表征学习的启发，本章选择对清晰图像的幅度谱使用线性插值进行混合。需要注意的是，相位谱信息在此过程中保持不变，因为其所蕴含的语义信息对于后续的识别任务至关重要。从直观上看，通过随机幅度谱的扰动，可以鼓励图像复原模型从相位信息中学习稳健的特征。而由于相位谱中蕴含丰富的语义，

中国知网　https://www.cnki.net

该策略进一步促使图像复原模型探索鲁棒的语义恢复。另一方面，该策略提高了真实标签的多样性，使其不再是“硬”标签（”Hard” Labels），从而进一步探索清晰图像语义分布 C 可能的“软”替代形式。这不仅提升了图像复原模型针对语义恢复的泛化能力，同时增强了对噪声的鲁棒性。

5.3　实验分析

5.3.1　数据集和评价指标

本章所提方法作为一个通用性的图像复原网络训练框架，可以直接无缝套用到现有的图像复原模型中。由于本章拟解决的问题与第 4 章相同，所以本章的实验设置也基本与第 4 章相同。为了验证所提训练框架的有效性，本章在图像去雾、图像去噪和图像去雨三个图像复原方法中测试不同方法的性能。本章同样选择图像分类和目标检测作为验证性能的下游视觉识别任务。同时，数据集的设置也与第 4 章类似。针对图像去雾任务，选择 RESIDE[112] 作为训练数据集；针对图像去噪任务，使用 BSD400[182] 和 WED[183] 作为训练数据集；针对图像去雨任务，选择 Rain100L[181] 作为训练数据集。在验证复原图像在下游高层识别任务性能时，针对图像分类任务，选择 CUB[171] 数据集作为测试分类性能的数据集；针对目标检测任务，选择 CrowdHuman[184] 数据集用来验证目标检测性能。每个数据集的详细信息已在 4.4.1中进行了介绍，这里不再赘述。

本章使用的评价指标也与第 4 章基本相同。针对视觉质量的评价指标，采用峰值信噪比（PSNR）和结构相似性指数（SSIM）。在测试识别任务性能时，针对图像分类任务，除了已经介绍过的 Top-1 准确率（Top-1 Accuracy）指标之外，还引入了 Top-5 准确率（Top-5 Accuracy）。该指标用于衡量模型在预测时是否能将正确类别包含在其前 5 个预测结果中。相比于 Top-1 准确率预测完全正确的严格要求，Top-5 准确率更加宽容。其计算过程为，对每张图像执行分类预测，并选取图像分类模型预测的前 5 个概率最高的类别，构成 Top-5 预测结果。如果该图像的真实标签出现在 Top-5 预测结果中，则认为分类正确。假设测试集总样本为 N，Top-5 分类正确的样本数为 M，则 Top-5 准确率可以表示为：

$$\text{Top-5 准确率} = \frac{M}{N} \times 100\%. \tag{5.16}$$

针对目标检测任务，采用在第 4 章介绍过的平均精度（Average Precision，AP），交并比（Jaccard Index，JI）以及漏检率（Miss Rate，MR）作为评价指标。这些指标已经在第 4 章中进行了介绍，在此不再赘述。

中国知网　https://www.cnki.net

5.3.2　实验设置

本章将所提出的训练框架套用到现有的图像复原方法中，并训练对应的图像复原模型。训练采用 Adam 优化器，其参数 β_1，β_2 和 γ 分别设置为 0.9，0.999 和 0.5。训练的总轮数设置为 200，以保证每个图像复原模型都可以得到充分的优化。初始学习率设置为 2×10^{-4}，并且随着训练轮数的增加逐渐递减，以确保训练过程的稳定与模型的最优收敛值。每个训练迭代时输入图像的批量大小设置为 20，每张图像都被裁剪为 128×128 的图像块。本章所有实验都是在一张 NVIDIA 3090Ti GPU 上进行的。

5.3.3　性能比较

（1）图像分类任务上性能提升

对比的基准方法。本章展示了利用所提出的面向高层视觉任务图像复原方法与传统的图像复原方法在图像分类任务上的性能对比，以验证本章所提方法的有效性。与第 4 章相似，本章使用 CUB[171] 数据集作为分类测试数据集，并按照 ImageNet-C[173] 中的方法合成退化图像。本章仍然使用在清晰 CUB 训练集上预训练的 VGG16[134] 和 ResNet50[135] 作为下游的识别模型。需要注意的是，本章在训练过程中用于计算语义恢复约束的预训练模型 f_{ext} 是在 ImageNet 上预训练的 VGG16，而在这里用于评测识别性能的是基于 CUB 数据集预训练的 VGG16。这意味着，后者对于传统的图像复原方法还是本章所提的方法，都属于未见过的下游识别系统。利用其测试的性能可以充分反映不同图像复原方法对于下游视觉识别任务的适配性和泛化性。具体的训练和测试流程已经在 4.4.3节中进行了详细介绍，这里不在赘述。

在图像去雾任务上，本章选择 DehazeNet[123]，AODNet[47]，EPRN[185]，FDGAN[186]，FFANet[7]，DL[187]，AirNet[71]，FSDGN[97]，HINet[206]，MPRNet[26] 和 Restormer[15] 作为用于对比的基准图像去雾方法。同时，为了验证本章所提的基于视觉感知与语义优化协同的图像复原方法有效性，本章选择 FSDGN[97]，HINet[206]，MPRNet[26] 和 Restormer[15] 作为基准模型，使用本章所提的训练范式进行重新训练。在图像去噪任务上，本章选择 CBM3D[188]，DnCNN[189]，IR-CNN[24]，FFDNet[9]，AirNet[71]，BRDNet[190]，DL[187]，HINet[206]，MPRNet[26] 和 Restormer[15] 作为用于对比的图像去噪方法。同时，选择 HINet[206]，MPRNet[26] 和 Restormer[15] 作为基准模型，使用本章所提的方法重新训练。针对图像去雨任务，本章选择 DIDMDN[58]，UMRL[191]，SIRR[192]，AirNet[71]，DL[187]，MSPFN[193]，MPRNet[26] 和 Restormer[15] 作为用于对比的基准图像去雨方法。同时，选择 MSPFN[193]，MPRNet[26] 和 Restormer[15] 作为基准模型，使用本章所提的方法重新训练。

中国知网　https://www.cnki.net

表 5.1　不同方法在 CUB[171] 数据集图像去雾后分类性能定量比较

	方法	分类性能				视觉性能	
		Top-1V	Top-5V	Top-1R	Top-5R	PSNR	SSIM
	有雾图像	25.7	49.2	52.0	75.2	12.91	0.6377
	清晰图像	81.0	94.8	86.4	96.1	-	-
传统图像复原方法	DehazeNet[123]	6.7	18.3	17.2	34.7	14.29	0.5225
	AODNet[47]	24.0	47.1	42.1	66.8	13.28	0.6415
	EPRN[185]	12.1	26.8	25.9	43.1	14.39	0.6864
	FDGAN[186]	62.0	84.3	74.2	90.3	16.76	0.7545
	FFANet[7]	62.3	84.3	74.6	90.4	16.82	0.7658
	DL[187]	65.6	85.8	76.0	91.0	16.23	0.7567
	AirNet[71]	68.2	87.5	76.8	91.2	16.97	0.7692
	FSDGN[97]	70.4	88.2	80.3	92.9	18.47	0.7667
	HINet[206]	67.5	86.1	77.0	91.6	16.97	0.7193
	MPRNet[26]	70.4	89.0	78.6	91.7	19.23	0.8134
	Restormer[15]	72.5	89.3	82.9	94.0	19.68	0.8186
本章方法	FSDGN-I	**72.5**	**90.2**	**81.5**	**93.6**	18.16	0.7946
	HINet-I	**69.9**	**88.4**	**79.7**	**92.9**	16.98	0.7095
	MPRNet-I	**73.4**	**90.4**	**82.0**	**93.9**	19.00	0.8121
	Restormer-I	**74.2**	**90.6**	**83.9**	**94.1**	19.72	0.8192

表 5.2　不同方法在 CUB[171] 数据集图像去噪后分类性能定量比较

	方法	分类性能				视觉性能	
		Top-1V	Top-5V	Top-1R	Top-5R	PSNR	SSIM
	带噪图像	0.6	3.9	2.6	10.7	13.40	0.1105
	清晰图像	81.0	94.8	86.4	96.1	-	-
传统图像复原方法	CBM3D[188]	20.2	45.6	25.4	49.3	22.67	0.5237
	DnCNN[189]	24.5	47.0	38.9	61.5	23.01	0.5474
	IRCNN[24]	27.0	52.9	43.4	64.5	25.52	0.7121
	FFDNet[9]	22.7	47.4	37.5	61.5	25.16	0.6982
	AirNet[71]	27.8	55.9	45.7	71.1	26.42	0.7653
	BRDNet[190]	25.1	48.0	42.0	63.8	26.28	0.7522
	DL[187]	25.1	48.1	42.1	63.9	26.33	0.7635
	HINet[206]	33.4	60.1	51.6	74.0	25.93	0.6737
	MPRNet[26]	27.3	55.6	44.5	70.9	26.90	0.7819
	Restormer[15]	29.2	50.8	47.5	71.1	27.46	0.7972
本章方法	HINet-I	**35.6**	**61.1**	**53.9**	**74.7**	25.98	0.7408
	MPRNet-I	**38.9**	**64.4**	**56.5**	**77.2**	26.17	0.7455
	Restormer-I	**36.7**	**61.3**	**55.2**	**75.1**	27.41	0.7970

定量结果比较。表 5.1，表 5.2和表 5.3分别表示了在图像去雾、图像去噪和图像去雨三个任务中复原的图像在 CUB 数据集上的分类定量性能。其中，Top-1V 和 Top-5V 分别代表在使用 CUB 数据集预训练的 VGG16 模型上的 Top-1 准确率和 Top-5 准确率；Top-1R 和 Top-5R 分别代表在使用 CUB 数据集预训练的 ResNet50 模型上的 Top-1 准确率和 Top-5 准确率。其中，后缀“-I”表示采用本

中国知网　https://www.cnki.net

表 5.3　不同方法在 CUB[171] 数据集图像去雨后分类性能定量比较

	方法	分类性能				视觉性能	
		Top-1V	Top-5V	Top-1R	Top-5R	PSNR	SSIM
	有雨图像	57.9	79.8	69.0	86.0	18.46	0.7183
	清晰图像	81.0	94.8	86.4	96.1	-	-
传统图像复原方法	DIDMDN[58]	50.3	74.5	62.4	82.9	18.63	0.6845
	UMRL[191]	55.9	76.2	68.6	85.3	20.80	0.7197
	SIRR[192]	73.3	90.4	81.2	93.7	27.56	0.8655
	AirNet[71]	73.1	90.7	81.7	93.6	27.45	0.8693
	DL[187]	70.3	88.4	78.1	91.5	26.62	0.8496
	MSPFN[193]	73.5	90.5	81.3	93.7	27.68	0.8664
	MPRNet[26]	74.5	91.3	82.1	94.2	28.50	0.8851
	Restormer[15]	74.6	90.9	82.8	93.9	29.98	0.8894
本章方法	MSPFN-I	**73.7**	**90.8**	**81.8**	**93.7**	28.35	0.8741
	MPRNet-I	**75.0**	**91.4**	**82.4**	**94.3**	29.13	0.8892
	Restormer-I	**75.2**	**91.2**	**82.9**	**93.9**	29.94	0.8892

章框架训练的图像复原方法。比如，“MPRNet-I”代表使用 MPRNet 作为基模型，采用本章所提的训练框架进行训练。为了更加清晰的对比，表中使用加粗标注的数据表示本章所提训练框架的图像复原网络在下游识别任务上的识别性能，而下划线标注的数据表示使用传统图像复原训练框架的相同图像复原网络的识别性能。需要特别强调两点：一是无论对于表格中的传统图像复原方法还是本章方法，表中所使用的两个分类模型，即在 CUB 数据集上预训练的 VGG16 和 ResNet50，都属于未见过的下游识别系统，在其上测试的性能可以充分反映图像复原方法针对下游视觉识别任务的适配性和泛化性；二是在本章表中的评测指标中，有关识别的评测指标（例如 Top-1 准确率和 Top-5 准确率）要比视觉评测指标（例如 PSNR 和 SSIM）更加重要。

可以看出，本章提出的方法在 CUB 测试集上，在三种退化场景下的两个分类识别系统中的分类性能都要优于对应的图像复原方法。例如，在图像去雾场景中，使用本章所提训练框架的 Restormer-I 相比于传统图像复原方法 Restormer 在 Top-1V，Top-5V，Top-1R 和 Top-5R 上分别提升了 1.7%，1.3%，1.0% 和 0.1% 的提升。在相对更加困难的图像去噪任务上，与采用传统图像复原训练流程的 MPRNet 相比，MPRNet-I 在 Top-1V，Top-5V，Top-1R 和 Top-5R 指标上分别获得了 11.6%，8.8%，12.0% 和 6.3% 的提升。即使是在识别性能影响相对较小的图像去雨场景中，使用本章方法训练的模型也在分类表现中领先于对应的传统图像复原方法。这充分证明了本章所提训练框架可以有效提升图像复原模型针对下游识别任务的适配性和泛化性。可以看到，传统的图像复原方法虽然在 PSNR 和 SSIM 等视觉指标上表现优异，但是在识别准确率方面却显著低于本章所提方法。这是因为传统图像复原方法主要侧重于从视觉质量的角度对退化图像进行

中国知网　https://www.cnki.net

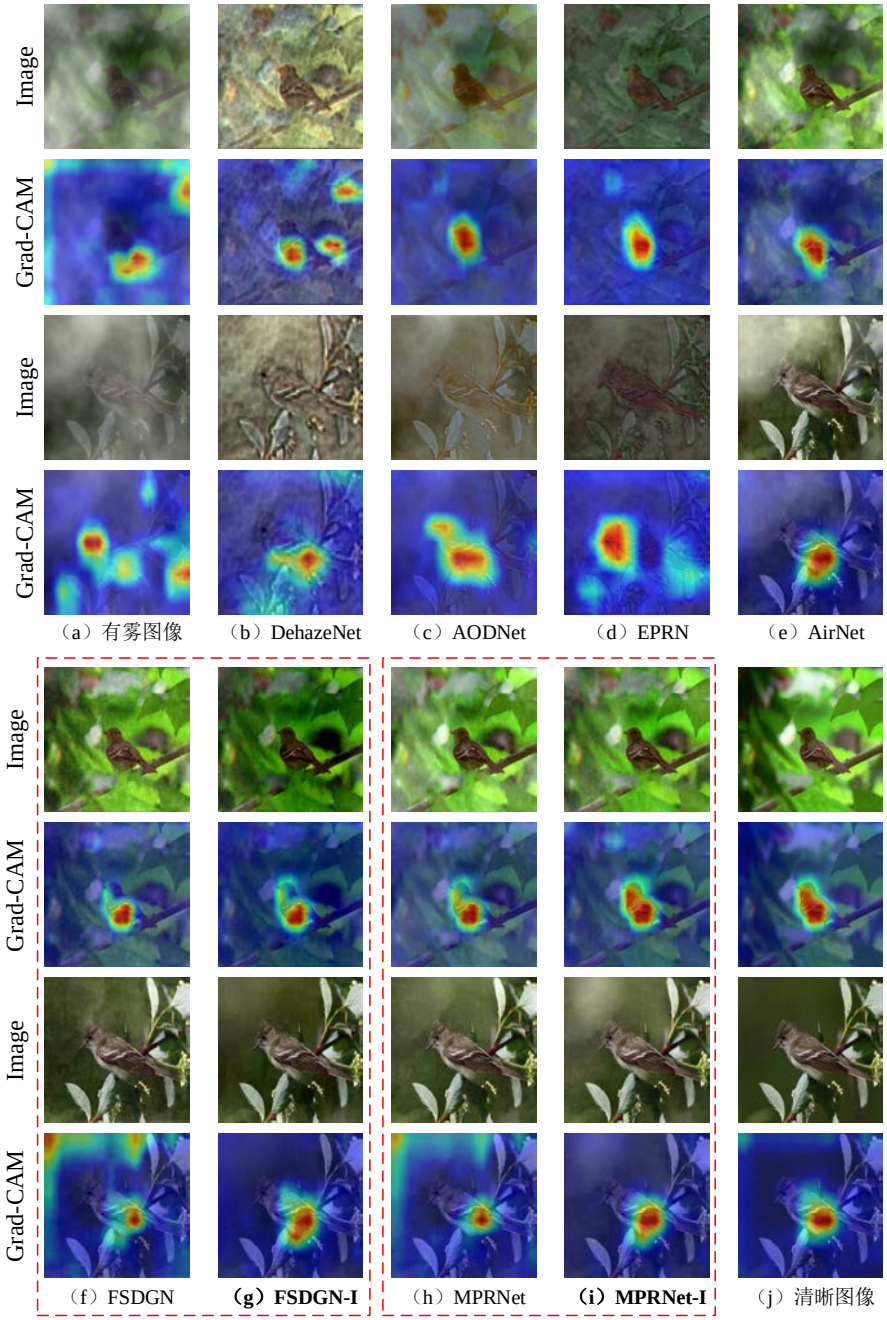


图 5.5　不同方法在 CUB[171] 数据集上图像去雾定性比较

增强，而忽略了该过程中图像内部高层语义信息的恢复。

值得注意的是，为了直观对比，表 5.1，表 5.2和表 5.3中分别展示了未经修复的退化图像在识别性能和视觉性能上的表现。从性能结果中也可以看出不同退化类型对于图像语义质量和视觉质量影响的不同。例如，通过对比表 5.1中有雾图像和表 5.2中带噪图像的识别指标和视觉指标可以发现，有雾图像的 PSNR 值低于带噪图像，但是其分类准确率却大幅领先于带噪图像。这一现象与 4.4.3节所推测的一致，即不同退化成分对于图像的不同频带的影响是差异化的。

定性结果比较。图 5.5和图 5.6分别展示了传统图像复原方法和本章所提的基

中国知网　https://www.cnki.net

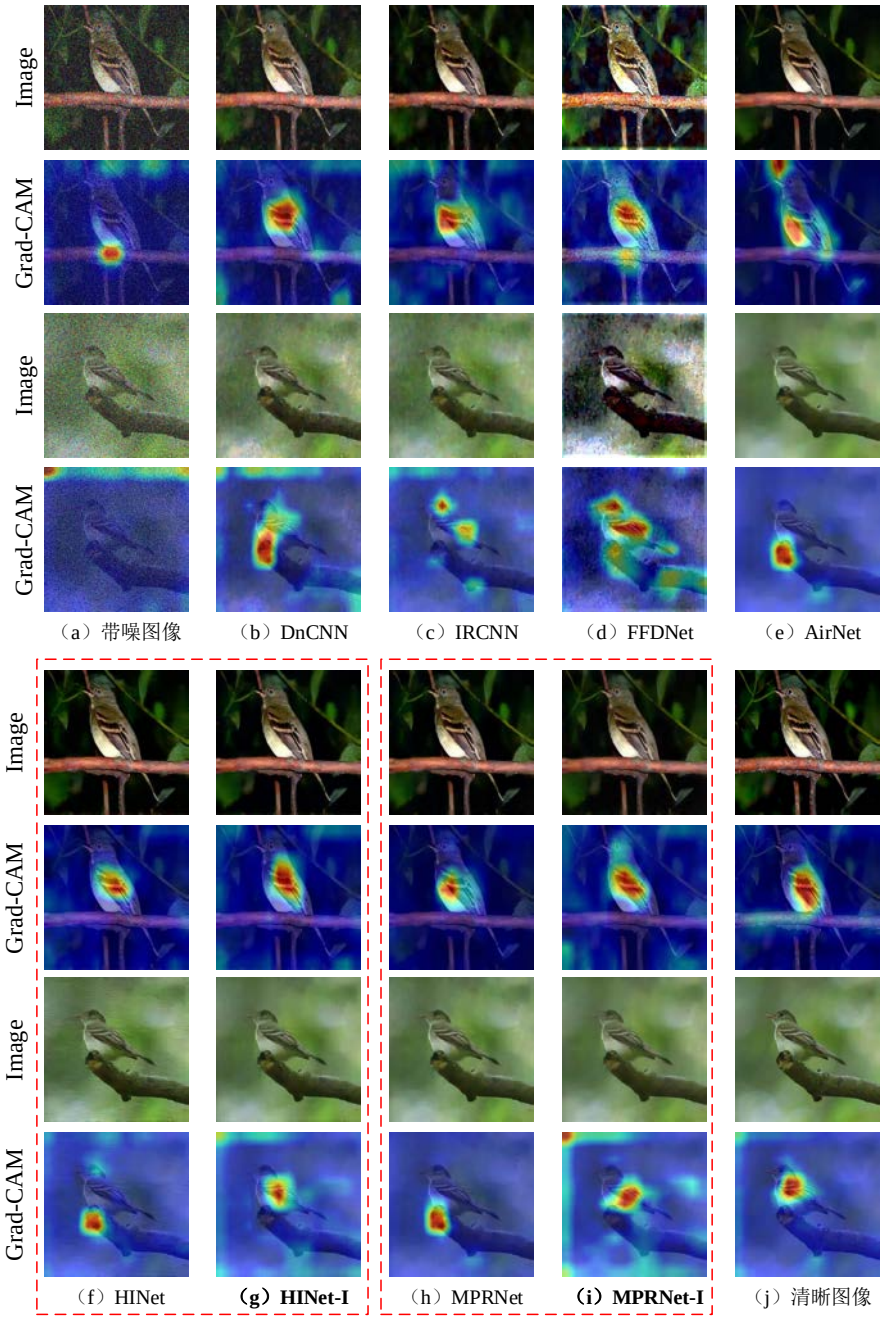


图 5.6　不同方法在 CUB[171] 数据集上图像去噪定性比较

于视觉感知与语义优化协同的图像复原方法在图像去雾和图像去噪任务上的定性结果，并附有对应的梯度加权类激活热图（Gradient-weighted Class Activation Mapping，Grad-CAM）[207]。Grad-CAM 图利用目标类别对于特征图的梯度信息生成热力图，可以直观地呈现出图像中不同区域对于最终分类预测结果的贡献分布。其中，本章所提方法使用加粗标注，并与对应的传统图像复原方法用红色线框进行标注以方便对比。可以将清晰图像的 Grad-CAM 作为参考标准，当复原图像的 Grad-CAM 在激活区域和激活强度上与清晰图像的 Grad-CAM 保持一致时，意味着复原图像的内在语义得到了更准确地恢复。可以看出，本章所提方法复原

中国知网　https://www.cnki.net

表 5.4　不同方法在 CrowdHuman[184] 数据集图像去雾后检测性能定量比较

	方法	检测性能			视觉性能	
		AP	JI	MR	PSNR	SSIM
传统图像复原方法	DehazeNet[123]	46.77	41.39	85.53	13.13	0.4935
	AODNet[47]	61.08	53.18	75.79	12.13	0.5638
	EPRN[185]	55.45	47.69	81.04	13.26	0.5784
	AirNet[71]	78.24	65.87	64.03	19.00	0.8427
	FSDGN[97]	79.14	67.42	63.13	21.10	0.8518
	MPRNet[26]	78.64	66.52	63.60	19.27	0.8569
本章方法	FSDGN-I	**79.60**	**68.07**	**62.53**	20.83	0.8621
	MPRNet-I	**79.72**	**68.08**	**62.53**	21.28	0.8699

表 5.5　不同方法在 CrowdHuman[184] 数据集图像去噪后检测性能定量比较

	方法	检测性能			视觉性能	
		AP	JI	MR	PSNR	SSIM
传统图像复原方法	DnCNN[189]	56.48	48.89	78.62	22.59	0.5529
	IRCNN[24]	59.08	50.76	78.12	24.10	0.6739
	FFDNet[9]	57.88	50.63	78.27	23.94	0.6773
	AirNet[71]	59.36	51.95	77.08	24.66	0.7126
	HINet[206]	60.52	53.04	76.36	23.94	0.6297
	MPRNet[26]	58.77	51.49	77.15	24.86	0.7218
本章方法	HINet-I	**61.10**	**53.47**	**75.98**	23.82	0.6285
	MPRNet-I	**59.95**	**52.86**	**76.01**	24.53	0.7010

图像的 Grad-CAM 图在激活区域和激活强度上与清晰图像的 Grad-CAM 更为接近。例如，在图 5.5中，FSDGN 和 MPRNet 复原图像的 Grad-CAM 图显示，下游分类模型的预测过程被背景中的信息所干扰；而通过本章方法训练的 FSDGN-I 和 MPRNet-I 复原的图像则可以使下游分类模型更加精确地捕捉图像中的关键特征。这表明，相比与传统的图像复原方法，本章所提的方法能够更有效地鼓励图像复原网络恢复图像的内在语义，使其更好地适应于下游的视觉识别任务。

（2）目标检测任务上性能提升

对比的基准方法。本章进一步在目标检测任务上验证本章方法的有效性。与第 4 章类似，本章使用 CrowdHuman 数据集[184]作为测试数据集，并按照与 ImageNet-C[173]相同的方式合成退化图像。本章同样使用在清晰 CrowdHuman 数据集上预训练的 RetinaNet[163]作为下游目标检测模型。针对图像去雾任务，选择 DehazeNet[123]，AODNet[47]，EPRN[185]，AirNet[71]，FSDGN[97]和 MPRNet[26]作为用于对比的基准图像去雾方法。其中，将 FSDGN[97]和 MPRNet[26]两个模型使用本章所提的训练方法进行训练以验证有效性。针对图像去噪任务，选择 DnCNN[189]，IRCNN[24]，FFDNet[9]，AirNet[71]，HINet[206]和 MPRNet[26]作为用于对比的基准图像去噪方法。同时，选择 HINet[206]和 MPRNet[26]使用本章所提框架重新训练。针对图像去雨任务，选择 DIDMDN[58]，UMRL[191]，SIRR[192]，

中国知网　https://www.cnki.net

表 5.6　不同方法在 CrowdHuman[184] 数据集图像去雨后检测性能定量比较

	方法	检测性能			视觉性能	
		AP	JI	MR	PSNR	SSIM
传统图像复原方法	DIDMDN[58]	74.44	63.10	67.89	22.72	0.7865
	UMRL[191]	76.36	64.49	66.51	23.16	0.8089
	SIRR[192]	78.05	66.26	64.47	26.21	0.8651
	AirNet[71]	77.76	66.29	64.53	26.61	0.8792
	MSPFN[193]	78.21	66.54	63.99	26.44	0.8720
	MPRNet[26]	78.69	67.29	63.30	27.83	0.8978
本章方法	MSPFN-I	**78.87**	**67.32**	**63.27**	27.79	0.8952
	MPRNet-I	**79.11**	**67.45**	**63.01**	28.40	0.8997

AirNet[71]，MSPFN[193]和 MPRNet[26]作为用于对比的基准图像去雨方法。同时，选择 MSPFN[193]和 MPRNet[26]使用本章所提方法重新训练。

定量结果比较。表 5.4，表 5.5和表 5.6分别表示了在图像去雾，图像去噪和图像去雨三个任务中复原的图像在 CrowdHuman 数据集上的检测定量性能。其中，后缀“-I”表示采用本章框架训练的图像复原网络。加粗标注的数值为使用本章方法训练的图像复原网络在检测任务中的检测性能，使用下划线标注的数值表示对应的传统图像复原网络在检测任务中的检测性能。可以看到，使用本章方法训练的图像复原网络在检测性能上都要优于各自对应的传统图像复原训练方法。这进一步验证了本章所提框架在提升图像复原模型于各种下游识别任务中的性能和泛化能力的有效性。

（3）与已有识别驱动的图像复原方法对比

本节进一步将所提出的方法与现有的识别驱动的图像复原方法进行比较。具体而言，选择在 CUB 数据集针对图像分类任务，将本节方法与 DDP[90]和 URIE[95]进行对比。其中，URIE 将图像复原网络与特定下游视觉识别任务模型级联，并使用识别损失函数训练图像复原网络。在这个过程中，引入了特定的语义标签。对于 DDP 方法，为了保证比较的公平性，使用一个预训练的解码器将复原后的特征重新映射回图像。表 5.7展示了各种方法的对比的定量结果。其中，“Top-1/5V”表示在 VGG16 分类器下 Top-1 准确率和 Top-5 准确率；“Top-1/5R”表示在 ResNet50 分类器下 Top-1 准确率和 Top-5 准确率。加粗标注的数值表示最优的结果。对于本章方法，本节选用 MPRNet 作为基模型，并使用本章所提方法进行训练。可以看出，在图像去雾与图像去噪两种场景下，本章提出的方法在分类性能上均优于其他基准方法，进一步验证了本章方法的有效性。

5.3.4　消融实验

本节通过一系列消融实验来证明本章设计的有效性。具体来说，本节选用 MPRNet 作为基模型，并在 CUB[171]数据集进行消融实验，通过测试不同方法复

中国知网　https://www.cnki.net

表 5.7　不同方法在 CUB[171] 数据集图像去雾与图像去噪后分类性能定量比较

方法	图像去雾		图像去噪	
	Top-1/5V	Top-1/5R	Top-1/5V	Top-1/5R
DDP[90]	41.3/56.6	45.7/60.8	21.1/44.2	36.2/60.3
URIE[95]	66.3/86.9	77.6/90.3	35.6/60.7	53.6/74.6
本章方法	**73.4/90.4**	**82.0/93.9**	**38.9/64.4**	**56.5/77.2**

原图像的分类指标来表明性能。

（1）动态梯度校正策略的有效性分析

本章所提的训练框架使用语义恢复和图像重建两个损失函数来约束图像复原网络的训练，而两个优化目标通过动态梯度校正策略集成到一起。在本节中，通过在图像去噪场景下的分类任务，来验证该策略的有效性。表 5.8展示了不同训练方法在图像去噪分类任务上的性能。其中，“模型 1”表示只使用图像重建损失函数 $\mathcal{L}_{rec}$ 训练图像复原网络，该训练范式与传统的图像复原方法的训练范式相似；“模型 2”表示只使用语义恢复损失函数 $\mathcal{L}_{sem}$ 训练图像复原网络，该训练范式与已有的识别驱动的图像复原方法相似。“模型 3”表示同时使用图像重建损失函数 $\mathcal{L}_{rec}$ 和 $\mathcal{L}_{sem}$ 训练图像复原网络，但是并没有引入动态梯度校正策略，只是单纯将两个损失函数相加作为最终的损失函数。需要再次强调的是，表 5.8中使用的在 CUB 数据集上预训练的 VGG16 和 ResNet50 分类网络都属于未见过的下游识别系统。

可以看出，“模型 2”和“模型 3”在分类准确率上要比“模型 1”高。这是由于“模型 2”和“模型 3”的训练过程中都引入了语义恢复的约束 $\mathcal{L}_{sem}$，使它们相比于只使用图像重建约束的训练方式能更好地恢复图像语义并提升下游识别任务的性能。需要注意的是，同时使用图像重建约束 $\mathcal{L}_{rec}$ 和语义恢复约束 $\mathcal{L}_{sem}$ 进行训练的“模型 3”其性能要比只使用语义恢复约束 $\mathcal{L}_{sem}$ 进行训练的“模型 2”效果稍好。这是由于图像重建损失函数 $\mathcal{L}_{rec}$ 能够作为正则项提升图像复原模型对于下游识别任务的泛化能力。在本章所提出的动态梯度校正策略的作用下，本章方法在 Top-1V 和 Top-1R 指标上分别比“模型 3”提高了 3.7% 和 3.6%。这证明了本章所提的动态梯度校正策略不仅能够提升图像复原模型的泛化能力，同时也能显著提高其复原的图像在各种下游视觉识别系统上的性能。

表 5.8　动态梯度校正策略消融实验

方法	$\mathcal{L}_{rec}$	$\mathcal{L}_{sem}$	动态梯度校正策略	Top-1V	Top-1R
模型 1	√	×	×	27.3	44.5
模型 2	×	√	×	34.7	52.0
模型 3	√	√	×	35.2	52.9
本章方法	√	√	√	**38.9**	**56.5**

（2）内在语义一致性约束的有效性分析

中国知网　https://www.cnki.net

表 5.9　内在语义一致性约束消融实验

约束方式	Top-1V	Top-5V	Top-1R	Top-5R
L1	32.5	59.7	49.7	72.9
均方误差	33.1	59.9	50.0	73.1
本章方法	**38.9**	**64.4**	**56.5**	**77.2**

为了实现高效的语义恢复，本章设计了一个内在语义一致性约束，该约束通过相似性分布来探索复原图像和清晰图像之间的语义关系。以往的方法通常选择在高维语义特征空间中使用 L1 或者均方误差计算复原图像与清晰图像的特征距离，并将其作为语义恢复约束，但这并非是最佳的选择。本节将内在语义一致性约束与这两种语义约束计算方式进行比较。如表 5.9所示，在图像去噪分类任务中，相较于 L1 约束，内在语义一致性约束在 Top-1V，Top-5V，Top-1R 和 Top-5R 指标上分别提升了 6.4%，4.7%，6.8% 和 4.3%。同时，相比于均方误差约束计算方式，内在语义一致性约束在 Top-1V，Top-5V，Top-1R 和 Top-5R 指标上分别提升了 5.8%，4.5%，6.5% 和 4.1%。这证明了本章所提的内在语义一致性约束对于语义恢复的有效性。

（3）清晰图像增强策略的有效性分析

本节进一步对基于傅里叶变换的清晰图像增强策略进行了消融实验分析。如图 5.7所示，当不采用清晰图像增强策略时，对应的识别性能在 Top-1V，Top-5V，Top-1R 和 Top-5R 指标上性能分别下降了 2.8%，2.7%，2.3% 和 2.1%。显然，清晰图像增强策略有利于实现更鲁棒的语义恢复。

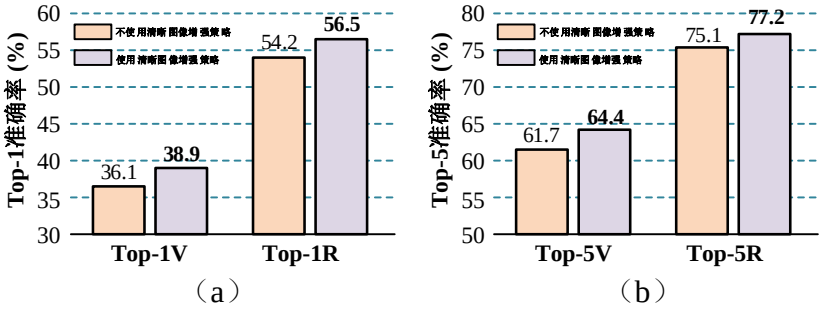


图 5.7　清晰图像增强策略消融实验

（4）超参数选择分析

与传统的图像复原方法相比，本章提出的基于视觉感知与语义优化协同的图像复原方法引入了两个超参数：τ 与 η。其中，公式 5.12与公式 5.13中的参数 τ 控制着内在语义一致性约束中相似度尺度，而公式 5.15中的参数 η 控制着清晰图像增强的程度。本节对 τ 在 CUB 数据集图像去噪分类任务中的敏感性进行了分析。图 5.8（a）展示了不同 τ 值下 VGG16 分类器的 Top-1 准确率结果，可以看到 $\tau = 0.5$ 为最佳选择。对于公式 5.15中的 η，如图 5.8（b）所示，$\eta = 0.8$ 的性能表现优于其他候选值。一方面，如果 η 取值过大，则清晰图像增强程度较小，

中国知网　https://www.cnki.net

图像复原模型难以获得足够的鲁棒性；另一方面，如果 η 取值过小，则清晰图像中所蕴含的判别性特征可能会被破坏，从而无法为语义恢复提供正确的指导。

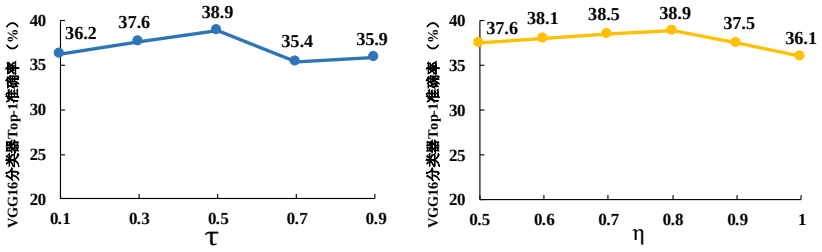


图 5.8　参数 τ 和参数 η 选择消融实验

（5）底层视觉感知与高层语义理解之间的权衡

从分类和检测的性能对比可以看出，由于高层语义理解优化和低层视觉感知优化之间存在权衡关系[195]，因此有时难以实现同时提升复原图像的高层识别性能（例如分类准确率）和低层视觉性能（例如 PSNR）。本章追求的理想场景是提升复原图像识别性能的同时，可以保持视觉性能不变甚至略有提升，如表 5.2中展示的 HINet 所达到的效果。另一方面，由于本章的首要目标是提升图像复原模型在下游视觉识别任务上的适配性和泛化性，因此，某些图像复原模型在使用本章所提方法后，只要在下游识别任务的性能上有所提升，即使视觉指标稍有下降，仍然是可以接受的。例如，表 5.2中的 MPRNet 的本章方法变体 MPRNet-I，其 PSNR 仅略有下降，而其分类识别性能则在 Top-1V 和 Top-1R 指标上分别获得 11.6% 和 12.0% 的提升。

5.4　本章小结

本章提出了一个基于视觉感知与语义优化协同的图像复原方法。针对现有识别驱动图像复原方法在下游识别任务上泛化性差的问题，本章设计了一个动态梯度校正策略，通过利用图像重建约束作为正则项对语义恢复约束的梯度进行校正。同时，针对现有语义恢复约束计算方式不合理的问题，本章提出了一个内在语义一致性约束，通过匹配图像间语义相似度分布的方式有效约束语义信息的增强。本章还提出了一种基于傅里叶变换的清晰图像增强策略，通过对清晰图像幅度谱进行适度扰动，增强图像复原网络对语义恢复的鲁棒性。本章提出了训练范式可以无缝应用于现有的图像复原模型，有效提升其针对下游识别任务的适配性和泛化性。在多个图像复原场景和视觉识别任务上的实验结果证明了本章方法的有效性。本章部分内容在 2024 年发表于多媒体期刊 IEEE Transactions on Multimedia。

中国知网　https://www.cnki.net

第 6 章　总结与展望

6.1　研究内容总结

图像复原技术作为计算机视觉领域的重要研究方向，旨在从输入的退化图像中恢复出清晰的高质量图像。随着深度学习技术兴起，图像复原技术也获得了飞速的发展，无论是对于学术界还是工业界都有着重要的研究意义。随着计算机视觉技术的快速发展，人们对于图像复原技术的要求已经从满足视觉感知扩展到同时兼顾语义理解。如何在图像复原过程进一步提升复原图像的视觉效果，并增强图像复原网络对下游高层视觉识别任务的适配性，成为了图像复原技术研究的重点。为了进一步推动图像复原技术的发展，本文针对视觉感知与语义理解这两个方面，探索了图像复原的设计方法。本文取得的研究成果如下：

（1）针对现有的基于深度学习的图像复原网络信息表征建模能力不足的问题，提出了基于扩散模型先验信息的图像复原方法。具体而言，首先探索了预训练扩散模型语义隐空间的特性，并发现了退化图像在该空间的表征随着时间步变化呈现出渐进式的变化：当时间步较小时，特征主要编码图像的底层内容，当时间步较大时，特征越来越多地捕捉图像的退化特性。根据以上观察，设计了一个基于扩散模型隐空间特征引导的图像复原网络，并集成有两个针对性设计的模块，内容融合模块和退化感知增强模块。时间步较小时，扩散模型语义隐空间特征主要表征图像的底层内容，内容融合模块利用此时的特征来引导图像内容信息的恢复；时间步较大时，扩散模型语义隐空间特征主要表征图像的退化特性，退化感知增强模块利用该特征作为引导帮助图像退化成分的去除。在多个图像复原任务上的实验结果表明，本文所提的方法能够有效提升图像复原的能力，在更全面地去除退化成分的同时，提升图像纹理细节的恢复效果。

（2）针对多视角图像复原中跨视角信息协同利用不充分的问题，提出了基于多视角空间关系探索的图像复原方法，并以双目图像复原为切入点进行研究。具体而言，提出了一个基于 Transformer 架构的双目图像复原网络，利用 Transformer 强大的捕获长距离空间依赖关系的能力建模双目视角间的对应关系，并通过由粗到细的方式对双目图像间的信息进行交互探索。提出了双目对齐模块，沿着水平极线的方向学习双目图像间的对应关系，并对双目视角的信息进行对齐；而后，提出了双目融合模块，在水平极线约束下对双目视角对应区域进行局部探索，以实现跨视角信息的精准融合。在多个图像复原任务和公开数据集上的实验结果表明，本文所提的方法能够有效探索和建模双目图像之间的关系，并显著提升双目图像复原的效果。

（3）针对面向视觉识别任务的图像复原方法中语义引导机制不完善的问题，

中国知网　https://www.cnki.net

提出了面向视觉识别任务的多退化统一图像复原方法。考虑到不同退化类型对于语义层面的差异化影响，提出了内在语义增强模块。具体来说，首先使用退化归一化补偿模块将不同退化语义特征映射到统一的特征空间，而后根据输入语义特征的统计特性对其进行动态调整。同时，提出了一个先验赋予优化策略，将整个训练过程分为两个目标清晰的子阶段。在第一个阶段中，利用退化图像和清晰图像预训练语义感知解码器，赋予其对不同输入语义信息的感知能力；在第二个阶段中，将语义感知解码器与内在语义增强模块级联，并固定语义感知解码器的参数，单独训练内在语义增强模块，引导其向着清晰图像语义特征的方向不断增强退化语义特征。该方法可以未知退化类型和下游识别任务的条件下，从退化输入中复原出有效适配下各种下游识别任务的图像。在多个图像复原任务和多种视觉识别任务上的实验结果证明，本文所提的方法可以有效提升复原图像在下游视觉识别任务上的性能。

（4）针对现有识别驱动的图像复原方法中泛化性不足的问题，提出了一个基于视觉感知与语义优化协同的图像复原方法。使用语义恢复约束和图像重建约束训练图像复原网络，同时利用图像重建约束对语义恢复约束的梯度进行校正，以保证对未见过下游识别系统的泛化性。同时，针对现有语义约束设计不合理的问题，提出了内在语义一致性约束，通过匹配复原图像与清晰图像间语义相似度分布的方式，有效约束语义信息的恢复。提出了清晰图像增强策略，通过对清晰图像的幅度谱进行适度扰动对其进行增强，并提升图像复原过程中语义恢复的鲁棒性。本文提出的训练范式可以无缝应用于现有的图像复原模型中。在多个图像复原任务和多种视觉识别任务上的实验结果表明，本文所提的基于视觉感知与语义优化协同的图像复原方法可以有效提升现有图像复原模型对于各种下游识别任务的适配性和泛化性。

6.2　未来展望

随着深度学习技术的快速发展，图像复原技术也取得了显著进展。通过设计深度神经网络，并采用端到端的训练方式学习退化图像到清晰图像映射关系的训练范式也成为主流。尽管如此，随着计算机视觉技术的快速发展，许多新兴技术也为进一步拓展图像复原技术框架提供了灵感。本章结合当前深度学习领域的前沿技术，对图像复原技术的未来发展进行展望。

（1）基于生成式模型的图像复原方法探索。随着扩散模型在生成领域的发展，其在图像、视频生成领域取得了巨大成功并逐渐占据主导地位。在这一过程中，涌现出大量具备优秀生成能力的预训练扩散模型，这为图像复原领域的发展带来的新的契机。这些扩散模型在大规模的图像或视频数据集中进行了预训练，其

中国知网　https://www.cnki.net

模型中蕴含了丰富且高质量的视觉先验信息。在第 2 章中，本文提出了一种基于预训练扩散模型视觉先验的图像复原方法，探索了扩散模型语义隐空间的特性，并利用该特性引导图像复原过程。如何从其他角度进一步挖掘现有扩散模型的视觉先验，并进一步探索将视觉先验与图像复原任务集成到一起的方法，从而不断提升复原图像的清晰度与逼真度，并进一步提升图像复原模型在复杂场景和任务中的泛化性，是未来图像复原方法的重要研究方向之一。

（2）基于多模态信息融合图像复原方法探索。近年来，大语言模型（Large Language Model，LLM）的兴起推动以语言为中心的多模态处理技术迅速发展。大语言模型在多模态理解和复杂任务推理方面的优秀能力也为图像复原技术的进一步发展带来了新的思路。例如，通过用户输入的指令，大语言模型可以分析当前任务的具体需求，并进一步输出指导信号，以引导图像复原过程。或是利用多模态大模型对图像进行语义分析，并输出指导信号以确保图像复原过程中结构信息的保真。如何充分利用大语言模型提供的多模态信息来引导图像复原过程，以提升图像复原效果，同时探究如何更有效地对齐语言与视觉两个模态之间特征，确保多模态信息可以得到有效融合以支持图像复原过程，是图像复原领域可以进一步深入探索的问题。

（3）视觉感知与语义理解图像复原的进一步统一。随着计算机视觉技术的快速发展，对于图像复原技术的要求也从满足人类视觉观感扩展到同时兼顾下游计算机视觉识别系统。本文分别探索了针对人类视觉观感和下游计算机视觉识别任务的图像复原方法。在第 5 章中，本文说明视觉感知优化与语义理解优化之间存在权衡关系。在未来的应用中，视觉感知与语义理解的提升需要进一步统一，从而增强当前复原图像在多样化场景中的通用性。因此，研究如何设计更加合理的训练范式和损失函数，在训练过程中对图像复原模型进行合理的约束和优化，使得图像复原方法可以同时提升复原图像的视觉质量与语义质量，是图像复原方法未来需要深入研究的方向之一。

（4）面向更复杂多样实际应用场景的图像复原方法探索。本文着重探索了面向自然场景的图像复原方法，并研究了多视角和多退化统一场景下的方法设计思路。然而，现实应用中存在更多复杂或者特殊的应用场景。现实场景中可能会出现多种退化同时存在的情况，例如雨天拍摄的图像可能会同时存在雨和雾两种退化。因此，研究如何有效建模复杂场景下图像中同时存在的多种退化，通过合理的方式对不同退化进行区分和去除，从而恢复出高质量的清晰图像，是未来图像复原方法的研究方向之一。同时，除了常见的自然图像，医学图像和遥感图像等领域也对图像复原技术提出了特殊要求。例如，可以将本章第 2 章中使用的在自然图像上预训练的扩散模型在医学或遥感图像上进行微调，使扩散模型学习这些特殊领域图像的视觉先验，并设计合理的方式来利用这些新学到的先验

中国知网　https://www.cnki.net

引导医学图像或遥感图像的复原过程。研究如何有效结合医学和遥感图像独特的领域知识，合理设计图像复原网络和训练方式，从而精准地恢复出清晰图像，对于图像复原技术在实际场景中的进一步落地和拓展有着重要意义。

中国知网　https://www.cnki.net

参考文献

[1] HU Y, YANG J, CHEN L, et al. Planning-Oriented Autonomous Driving[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 17853-17862.

[2] JIN X, LAN C, ZENG W, et al. Style Normalization and Restitution for Generalizable Person Re-Identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 3143-3152.

[3] LEE H J, KIM J U, LEE S, et al. Structure Boundary Preserving Segmentation for Medical Image with Ambiguous Boundary[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 4817-4826.

[4] HO J, JAIN A, ABBEEL P. Denoising Diffusion Probabilistic Models[C]//Advances in Neural Information Processing Systems (NeurIPS). 2020: 6840-6851.

[5] WANG Y, XIAO B, BI X, et al. MCF: Mutual Correction Framework for Semi-Supervised Medical Image Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 15651-15660.

[6] WANG Z, ZHANG Z, ZHANG X, et al. DR2: Diffusion-Based Robust Degradation Remover for Blind Face Restoration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 1704-1713.

[7] QIN X, WANG Z, BAI Y, et al. FFA-Net: Feature Fusion Attention Network for Single Image Dehazing[C]//Proceedings of the AAAI Conference on Artificial Intelligence (AAAI). 2020: 11908-11915.

[8] FU X, LIANG B, HUANG Y, et al. Lightweight Pyramid Networks for Image Deraining[J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 31(6): 1794-1807.

[9] ZHANG K, ZUO W, ZHANG L. FFDNet: Toward a Fast and Flexible Solution for CNN-Based Image Denoising[J]. IEEE Transactions on Image Processing, 2018, 27(9): 4608-4622.

[10] LIM B, SON S, KIM H, et al. Enhanced Deep Residual Networks for Single Image Super-Resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). 2017: 136-144.

[11] KUPYN O, BUDZAN V, MYKHAILYCH M, et al. DeblurGAN: Blind Motion Deblurring Using Conditional Adversarial Networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 8183-8192.

[12] WU W, WENG J, ZHANG P, et al. URetinex-Net: Retinex-Based Deep Unfolding Network for Low-Light Image Enhancement[C]//Proceedings of the IEEE/CVF Conference on

中国知网 https://www.cnki.net

Computer Vision and Pattern Recognition (CVPR). 2022: 5901-5910.

[13] HE K, SUN J, TANG X. Single Image Haze Removal Using Dark Channel Prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 33(12): 2341-2353.

[14] DONG C, LOY C C, HE K, et al. Image Super-Resolution Using Deep Convolutional Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 38(2): 295-307.

[15] ZAMIR S W, ARORA A, KHAN S, et al. Restormer: Efficient Transformer for High-Resolution Image Restoration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 5728-5739.

[16] BERMAN D, AVIDAN S, et al. Non-Local Image Dehazing[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 1674-1682.

[17] ZHU Q, MAI J, SHAO L. A Fast Single Image Haze Removal Algorithm Using Color Attenuation Prior[J]. IEEE Transactions on Image Processing, 2015, 24(11): 3522-3533.

[18] FATTAL R. Single Image Dehazing[J]. ACM Transactions on Graphics, 2008, 27(3): 1-9.

[19] LAND E H. The Retinex Theory of Color Vision[J]. Scientific American, 1977, 237(6): 108-129.

[20] RAHMAN Z U, JOBSON D J, WOODELL G A. Multi-Scale Retinex for Color Image Enhancement[C]//Proceedings of the IEEE International Conference on Image Processing (ICIP). 1996: 1003-1006.

[21] FU X, ZENG D, HUANG Y, et al. A Weighted Variational Model for Simultaneous Reflectance and Illumination Estimation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 2782-2790.

[22] GUO X, LI Y, LING H. LIME: Low-Light Image Enhancement via Illumination Map Estimation[J]. IEEE Transactions on Image Processing, 2016, 26(2): 982-993.

[23] LI M, LIU J, YANG W, et al. Structure-Revealing Low-Light Image Enhancement via Robust Retinex Model[J]. IEEE Transactions on Image Processing, 2018, 27(6): 2828-2841.

[24] ZHANG K, ZUO W, GU S, et al. Learning Deep CNN Denoiser Prior for Image Restoration [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 3929-3938.

[25] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]//Medical Image Computing and Computer-Assisted Intervention (MICCAI). 2015: 234-241.

[26] ZAMIR S W, ARORA A, KHAN S, et al. Multi-Stage Progressive Image Restoration[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition

中国知网 https://www.cnki.net

(CVPR). 2021: 14821-14831.

[27] ZHANG Y, LI K, LI K, et al. Image Super-Resolution Using Very Deep Residual Channel Attention Networks[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 286-301.

[28] VASWANI A. Attention Is All You Need[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 6000-6010.

[29] CHEN H, WANG Y, GUO T, et al. Pre-Trained Image Processing Transformer[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 12299-12310.

[30] WANG Z, CUN X, BAO J, et al. Uformer: A General U-Shaped Transformer for Image Restoration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 17683-17693.

[31] LEDIG C, THEIS L, HUSZÁR F, et al. Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 4681-4690.

[32] ZHANG Y, TIAN Y, KONG Y, et al. Residual Dense Network for Image Super-Resolution [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 2472-2481.

[33] 孟海腾, 赵小乐, 李天瑞. 基于非对称信息蒸馏网络的轻量级图像超分辨重建[J]. 计算机应用, 2025, 45(02): 601-609.

[34] YANG Z, XIA J, LI S, et al. A Dynamic Kernel Prior Model for Unsupervised Blind Image Super-Resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 26046-26056.

[35] WANG Y, YANG W, CHEN X, et al. SINSR: Diffusion-Based Image Super-Resolution in a Single Step[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 25796-25805.

[36] ABDELHAMED A, BRUBAKER M A, BROWN M S. Noise Flow: Noise Modeling with Conditional Normalizing Flows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 3165-3173.

[37] BROOKS T, MILDENHALL B, XUE T, et al. Unprocessing Images for Learned Raw Denoising[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 11036-11045.

[38] CHANG K C, WANG R, LIN H J, et al. Learning Camera-Aware Noise Models[C]// Proceedings of the European Conference on Computer Vision (ECCV). 2020: 343-358.

[39] GUO S, YAN Z, ZHANG K, et al. Toward Convolutional Blind Denoising of Real Pho-

中国知网 https://www.cnki.net

tographs[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 1712-1722.

[40] MILDENHALL B, BARRON J T, CHEN J, et al. Burst Denoising with Kernel Prediction Networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 2502-2510.

[41] 周先春, 吕梦楠, 芮旸, 等. 基于注意力机制的双卷积图像去噪网络[J]. 电子测量与仪器学报, 2025, 39(02): 60-71.

[42] KIM C, KIM T H, BAIK S. LAN: Learning to Adapt Noise for Image Denoising[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 25193-25202.

[43] CHEN W T, DING J J, KUO S Y. PMS-Net: Robust Haze Removal Based on Patch Map for Single Images[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 11681-11689.

[44] 石冬阳, 黄胜, 刘焕淋, 等. 具有透射率先验与亮度感知的图像去雾算法[J]. 红外与激光工程, 2024, 53(07): 279-292.

[45] FATTAL R. Dehazing Using Color-Lines[J]. ACM Transactions on Graphics, 2014, 34(1): 1-14.

[46] LI B, GOU Y, LIU J Z, et al. Zero-Shot Image Dehazing[J]. IEEE Transactions on Image Processing, 2020, 29: 8457-8466.

[47] LI B, PENG X, WANG Z, et al. AOD-Net: All-in-One Dehazing Network[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2017: 4770-4778.

[48] LIU X, MA Y, SHI Z, et al. GridDehazeNet: Attention-Based Multi-Scale Network for Image Dehazing[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 7314-7323.

[49] ZHANG H, PATEL V M. Densely Connected Pyramid Dehazing Network[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 3194-3203.

[50] 王燕, 卢鹏屹, 他雪. 结合特征融合注意力的规范化卷积图像去雾网络[J]. 计算机工程与应用, 2025, 61(08): 226-238.

[51] WANG Z, ZHAO H, PENG J, et al. ODCR: Orthogonal Decoupling Contrastive Regularization for Unpaired Image Dehazing[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 25479-25489.

[52] FU X, HUANG J, ZENG D, et al. Removing Rain from Single Images via a Deep Detail Network[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 3855-3863.

中国知网 https://www.cnki.net

[53] LI X, WU J, LIN Z, et al. Recurrent Squeeze-and-Excitation Context Aggregation Net for Single Image Deraining[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 254-269.

[54] LUO Y, XU Y, JI H. Removing Rain from a Single Image via Discriminative Sparse Coding [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2015: 3397-3405.

[55] QIAN R, TAN R T, YANG W, et al. Attentive Generative Adversarial Network for Raindrop Removal from a Single Image[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 2482-2491.

[56] REN D, ZUO W, HU Q, et al. Progressive Image Deraining Networks: A Better and Simpler Baseline[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 3937-3946.

[57] YANG W, TAN R T, FENG J, et al. Deep Joint Rain Detection and Removal from a Single Image[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 1357-1366.

[58] ZHANG H, PATEL V M. Density-Aware Single Image De-Raining Using a Multi-Stream Dense Network[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 695-704.

[59] 宋建辉, 胡强强, 刘晓阳, 等. 基于注意力机制及多尺度特征融合的图像去雨[J]. 沈阳理工大学学报, 2024, 43(06): 28-33.

[60] CHEN X, PAN J, DONG J. Bidirectional Multi-Scale Implicit Neural Representations for Image Deraining[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 25627-25636.

[61] GAO N, JIANG X, ZHANG X, et al. Efficient Frequency-Domain Image Deraining with Contrastive Regularization[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2024: 240-257.

[62] CHAKRABARTI A. A Neural Approach to Blind Motion Deblurring[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2016: 221-235.

[63] 王晨卿, 荆涛, 刘云鹏, 等. 基于多尺度条件生成对抗网络的图像去模糊[J]. 计算机工程与设计, 2022, 43(04): 1074-1082.

[64] CHO S J, JI S W, HONG J P, et al. Rethinking Coarse-to-Fine Approach in Single Image Deblurring[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 4641-4650.

[65] GAO H, TAO X, SHEN X, et al. Dynamic Scene Deblurring with Parameter Selective Sharing and Nested Skip Connections[C]//Proceedings of the IEEE/CVF Conference on Computer

中国知网 https://www.cnki.net

Vision and Pattern Recognition (CVPR). 2019: 3848-3856.

[66] KUPYN O, MARTYNIUK T, WU J, et al. DeblurGAN-v2: Deblurring (Orders-of-Magnitude) Faster and Better[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 8878-8887.

[67] REN W, ZHANG J, PAN J, et al. Deblurring Dynamic Scenes via Spatially Varying Recurrent Neural Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(8): 3974-3987.

[68] 陈姿含, 张红云, 苗夺谦, 等. 深度融合频域和空间域特征的多粒度动态场景图像去模糊网络[J]. 模式识别与人工智能, 2024, 37(06): 557-569.

[69] CHEN L, TIAN X, XIONG S, et al. Unsupervised Blind Image Deblurring Based on Self-Enhancement[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 25691-25700.

[70] LI R, TAN R T, CHEONG L F. All in One Bad Weather Removal Using Architectural Search [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 3175-3185.

[71] LI B, LIU X, HU P, et al. All-in-One Image Restoration for Unknown Corruption[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 17452-17462.

[72] VALANARASU J M J, YASARLA R, PATEL V M. TransWeather: Transformer-Based Restoration of Images Degraded by Adverse Weather Conditions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 2353-2363.

[73] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative Adversarial Networks [J]. Communications of the ACM, 2020, 63(11): 139-144.

[74] WANG X, YU K, WU S, et al. ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks[C]//Proceedings of the European Conference on Computer Vision Workshops (ECCVW). 2018: 63-79.

[75] LUO Z, GUSTAFSSON F K, ZHAO Z, et al. Image Restoration with Mean-Reverting Stochastic Differential Equations[A]. 2023: arXiv preprint arXiv:2301.11699.

[76] SOHL-DICKSTEIN J, WEISS E, MAHESWARANATHAN N, et al. Deep Unsupervised Learning Using Nonequilibrium Thermodynamics[C]//International Conference on Machine Learning (ICML). 2015: 2256-2265.

[77] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-Resolution Image Synthesis with Latent Diffusion Models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 10684-10695.

中国知网 https://www.cnki.net

[78] ESSER P, KULAL S, BLATTMANN A, et al. Scaling Rectified Flow Transformers for High-Resolution Image Synthesis[C]//International Conference on Machine Learning (ICML). 2024: 12606-12633.

[79] GUO Y, YANG C, RAO A, et al. AnimateDiff: Animate Your Personalized Text-to-Image Diffusion Models without Specific Tuning[A]. 2023: arXiv preprint arXiv:2307.04725.

[80] BLATTMANN A, DOCKHORN T, KULAL S, et al. Stable Video Diffusion: Scaling Latent Video Diffusion Models to Large Datasets[A]. 2023: arXiv preprint arXiv:2311.15127.

[81] SAHARIA C, HO J, CHAN W, et al. Image Super-Resolution via Iterative Refinement[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(4): 4713-4726.

[82] YUE Z, WANG J, LOY C C. ResShift: Efficient Diffusion Model for Image Super-Resolution by Residual Shifting[C]//Advances in Neural Information Processing Systems (NeurIPS). 2024: 13294-13307.

[83] CHUNG H, KIM J, MCCANN M T, et al. Diffusion Posterior Sampling for General Noisy Inverse Problems[A]. 2022: arXiv preprint arXiv:2209.14687.

[84] CHUNG H, YE J C, MILANFAR P, et al. Prompt-Tuning Latent Diffusion Models for Inverse Problems[A]. 2023: arXiv preprint arXiv:2310.01110.

[85] ZHOU S, ZHANG J, ZUO W, et al. DAVANet: Stereo Deblurring with View Aggregation [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 10996-11005.

[86] WANG Y, YING X, WANG L, et al. Symmetric Parallax Attention for Stereo Image Super-Resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 766-775.

[87] ZHANG K, LUO W, REN W, et al. Beyond Monocular Deraining: Stereo Image Deraining via Semantic Understanding[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2020: 71-89.

[88] WANG Y, YANG J, WANG L, et al. Light Field Image Super-Resolution Using Deformable Convolution[J]. IEEE Transactions on Image Processing, 2020, 30: 1057-1071.

[89] YANG Z, DONG W, LI X, et al. Self-Feature Distillation with Uncertainty Modeling for Degraded Image Recognition[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2022: 552-569.

[90] WANG Y, CAO Y, ZHA Z J, et al. Deep Degradation Prior for Low-Quality Image Classification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 11049-11058.

[91] KIM I, HAN S, BAEK J W, et al. Quality-Agnostic Image Recognition via Invertible Decoder [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition

中国知网 https://www.cnki.net

(CVPR). 2021: 12257-12266.

[92] LEE S, SON T, KWAK S. FIFO: Learning Fog-Invariant Features for Foggy Scene Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 18911-18921.

[93] LIU D, WEN B, LIU X, et al. When Image Denoising Meets High-Level Vision Tasks: A Deep Learning Approach[A]. 2017: arXiv preprint arXiv:1706.04284.

[94] SHARMA V, DIBA A, NEVEN D, et al. Classification-Driven Dynamic Image Enhancement [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 4033-4041.

[95] SON T, KANG J, KIM N, et al. URIE: Universal Image Enhancement for Visual Recognition in the Wild[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2020: 749-765.

[96] WANG W, XU Z, HUANG H, et al. Self-Aligned Concave Curve: Illumination Enhancement for Unsupervised Adaptation[C]//Proceedings of the 30th ACM International Conference on Multimedia (ACMMM). 2022: 2617-2626.

[97] YU H, ZHENG N, ZHOU M, et al. Frequency and Spatial Dual Guidance for Image Dehazing [C]//Proceedings of the European Conference on Computer Vision (ECCV). 2022: 181-198.

[98] BROOKS T, HOLYNSKI A, EFROS A A. InstructPix2Pix: Learning to Follow Image Editing Instructions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 18392-18402.

[99] HERTZ A, MOKADY R, TENENBAUM J, et al. Prompt-to-Prompt Image Editing with Cross Attention Control[A]. 2022: arXiv preprint arXiv:2208.01626.

[100] GAL R, ALALUF Y, ATZMON Y, et al. An Image Is Worth One Word: Personalizing Text-to-Image Generation Using Textual Inversion[A]. 2022: arXiv preprint arXiv:2208.01618.

[101] LIU Z, FENG R, ZHU K, et al. Cones: Concept Neurons in Diffusion Models for Customized Generation[A]. 2023: arXiv preprint arXiv:2303.05125.

[102] RUIZ N, LI Y, JAMPANI V, et al. DreamBooth: Fine Tuning Text-to-Image Diffusion Models for Subject-Driven Generation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 22500-22510.

[103] JEONG J, KWON M, UH Y. Training-Free Content Injection Using h-Space in Diffusion Models[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). 2024: 5151-5161.

[104] KWON M, JEONG J, UH Y. Diffusion Models Already Have a Semantic Latent Space[A]. 2022: arXiv preprint arXiv:2210.10960.

[105] PARK Y H, KWON M, CHOI J, et al. Understanding the Latent Space of Diffusion Models

中国知网 https://www.cnki.net

Through the Lens of Riemannian Geometry[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023: 24129-24142.

[106] XIA B, ZHANG Y, WANG S, et al. DiffIR: Efficient Diffusion Model for Image Restoration [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2023: 13095-13105.

[107] YI X, XU H, ZHANG H, et al. Diff-Retinex: Rethinking Low-Light Image Enhancement with a Generative Diffusion Model[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2023: 12302-12311.

[108] VAN DER MAATEN L, HINTON G. Visualizing Data Using t-SNE.[J]. Journal of Machine Learning Research, 2008, 9(11): 2579-2605.

[109] CHOI J, LEE J, SHIN C, et al. Perception Prioritized Training of Diffusion Models[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 11472-11481.

[110] WANG J, YUE Z, ZHOU S, et al. Exploiting Diffusion Prior for Real-World Image Super-Resolution[J]. International Journal of Computer Vision, 2024, 132(12): 5929-5949.

[111] WANG X, YU K, DONG C, et al. Recovering Realistic Texture in Image Super-Resolution by Deep Spatial Feature Transform[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 606-615.

[112] LI B, REN W, FU D, et al. Benchmarking Single-Image Dehazing and Beyond[J]. IEEE Transactions on Image Processing, 2018, 28(1): 492-505.

[113] ANCUTI C O, ANCUTI C, SBERT M, et al. Dense-Haze: A Benchmark for Image Dehazing with Dense-Haze and Haze-Free Images[C]//Proceedings of the IEEE International Conference on Image Processing (ICIP). 2019: 1014-1018.

[114] ANCUTI C O, ANCUTI C, TIMOFTE R. NH-HAZE: An Image Dehazing Benchmark with Non-Homogeneous Hazy and Haze-Free Images[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). 2020: 444-445.

[115] WEI C, WANG W, YANG W, et al. Deep Retinex Decomposition for Low-Light Enhancement [A]. 2018: arXiv preprint arXiv:1808.04560.

[116] YANG W, WANG W, HUANG H, et al. Sparse Gradient Regularized Deep Retinex Network for Robust Low-Light Image Enhancement[J]. IEEE Transactions on Image Processing, 2021, 30: 2072-2086.

[117] WANG Z, BOVIK A C, SHEIKH H R, et al. Image Quality Assessment: From Error Visibility to Structural Similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612.

[118] ZHANG R, ISOLA P, EFROS A A, et al. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric[C]//Proceedings of the IEEE/CVF Conference on Computer Vision

中国知网 https://www.cnki.net

and Pattern Recognition (CVPR). 2018: 586-595.

[119] HEUSEL M, RAMSAUER H, UNTERTHINER T, et al. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 6629-6640.

[120] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the Inception Architecture for Computer Vision[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 2818-2826.

[121] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet Classification with Deep Convolutional Neural Networks[C]//Advances in Neural Information Processing Systems (NeurIPS). 2012: 84-90.

[122] DHARIWAL P, NICHOL A. Diffusion Models Beat GANs on Image Synthesis[C]//Advances in Neural Information Processing Systems (NeurIPS). 2021: 8780-8794.

[123] CAI B, XU X, JIA K, et al. DehazeNet: An End-to-End System for Single Image Haze Removal[J]. IEEE Transactions on Image Processing, 2016, 25(11): 5187-5198.

[124] DONG H, PAN J, XIANG L, et al. Multi-Scale Boosted Dehazing Network with Dense Feature Fusion[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 2157-2167.

[125] WU H, QU Y, LIN S, et al. Contrastive Learning for Compact Single Image Dehazing [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 10551-10560.

[126] LIANG J, CAO J, SUN G, et al. SwinIR: Image Restoration Using Swin Transformer[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 1833-1844.

[127] GUO C L, YAN Q, ANWAR S, et al. Image Dehazing Transformer with Transmission-Aware 3D Position Embedding[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 5812-5820.

[128] GUO C, LI C, GUO J, et al. Zero-Reference Deep Curve Estimation for Low-Light Image Enhancement[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 1780-1789.

[129] JIANG Y, GONG X, LIU D, et al. EnlightenGAN: Deep Light Enhancement Without Paired Supervision[J]. IEEE Transactions on Image Processing, 2021, 30: 2340-2349.

[130] ÖZDENIZCI O, LEGENSTEIN R. Restoring Vision in Adverse Weather Conditions with Patch-Based Denoising Diffusion Models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(8): 10346-10357.

[131] FEI B, LYU Z, PAN L, et al. Generative Diffusion Prior for Unified Image Restoration and

中国知网 https://www.cnki.net

Enhancement[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 9935-9946.

[132] FU X, HUANG J, DING X, et al. Clearing the Skies: A Deep Network Architecture for Single-Image Rain Removal[J]. IEEE Transactions on Image Processing, 2017, 26(6): 2944-2956.

[133] CHEN Z, ZHANG Y, LIU D, et al. Hierarchical Integration Diffusion Model for Realistic Image Deblurring[C]//Advances in Neural Information Processing Systems (NeurIPS). 2024: 29114-29125.

[134] SIMONYAN K, ZISSERMAN A. Very Deep Convolutional Networks for Large-Scale Image Recognition[A]. 2014: arXiv preprint arXiv:1409.1556.

[135] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778.

[136] CHEN C, QING C, XU X, et al. Cross Parallax Attention Network for Stereo Image Super-Resolution[J]. IEEE Transactions on Multimedia, 2021, 24: 202-216.

[137] NA J Y, YOON K J. Stereo Vision Aided Image Dehazing Using Deep Neural Network[C]// Proceedings of the 1st Workshop and Challenge on Comprehensive Video Understanding in the Wild. 2018: 15-19.

[138] SONG W, CHOI S, JEONG S, et al. Stereoscopic Image Super-Resolution with Stereo Consistent Feature[C]//Proceedings of the AAAI Conference on Artificial Intelligence (AAAI). 2020: 12031-12038.

[139] WANG L, GUO Y, WANG Y, et al. Parallax Attention for Unsupervised Stereo Correspondence Learning[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 44(4): 2108-2125.

[140] WANG L, WANG Y, LIANG Z, et al. Learning Parallax Attention for Stereo Image Super-Resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 12250-12259.

[141] XU Q, WANG L, WANG Y, et al. Deep Bilateral Learning for Stereo Image Super-Resolution [J]. IEEE Signal Processing Letters, 2021, 28: 613-617.

[142] YAN B, MA C, BARE B, et al. Disparity-Aware Domain Adaptation in Stereo Image Restoration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 13179-13187.

[143] YAO M, XIONG Z, WANG L, et al. Spectral-Depth Imaging with Deep Learning Based Reconstruction[J]. Optics Express, 2019, 27(26): 38312-38325.

[144] YING X, WANG Y, WANG L, et al. A Stereo Attention Module for Stereo Image Super-

中国知网 https://www.cnki.net

Resolution[J]. IEEE Signal Processing Letters, 2020, 27: 496-500.

[145] DAI Q, LI J, YI Q, et al. Feedback Network for Mutually Boosted Stereo Image Super-Resolution and Disparity Estimation[C]//Proceedings of the 29th ACM International Conference on Multimedia (ACMMM). 2021: 1985-1993.

[146] JEON D S, BAEK S H, CHOI I, et al. Enhancing the Spatial Resolution of Stereo Images Using a Parallax Prior[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 1721-1730.

[147] HUANG J, FU X, XIAO Z, et al. Low-Light Stereo Image Enhancement[J]. IEEE Transactions on Multimedia, 2022, 25: 2978-2992.

[148] DOSOVITSKIY A. An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale[A]. 2020: arXiv preprint arXiv:2010.11929.

[149] LEI BA J, KIROS J R, HINTON G E. Layer Normalization[A]. 2016.

[150] HENDRYCKS D, GIMPEL K. Gaussian Error Linear Units (GELUs)[A]. 2016: arXiv preprint arXiv:1606.08415.

[151] LI Z, LIU X, DRENKOW N, et al. Revisiting Stereo Depth Estimation from a Sequence-to-Sequence Perspective with Transformers[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 6197-6206.

[152] SCHARSTEIN D, HIRSCHMÜLLER H, KITAJIMA Y, et al. High-Resolution Stereo Datasets with Subpixel-Accurate Ground Truth[C]//Pattern Recognition. 2014: 31-42.

[153] WANG Y, WANG L, YANG J, et al. Flickr1024: A Large-Scale Dataset for Stereo Image Super-Resolution[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW). 2019: 3852-3857.

[154] GEIGER A, LENZ P, URTASUN R. Are We Ready for Autonomous Driving? The KITTI Vision Benchmark Suite[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2012: 3354-3361.

[155] MENZE M, GEIGER A. Object Scene Flow for Autonomous Vehicles[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 3061-3070.

[156] KIM J, LEE J K, LEE K M. Accurate Image Super-Resolution Using Very Deep Convolutional Networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 1646-1654.

[157] ZHANG K, GOOL L V, TIMOFTE R. Deep Unfolding Network for Image Super-Resolution [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 3217-3226.

[158] ZHANG J, PAN J, REN J, et al. Dynamic Scene Deblurring Using Spatially Variant Re-

中国知网 https://www.cnki.net

current Neural Networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 2521-2529.

[159] TAO X, GAO H, SHEN X, et al. Scale-Recurrent Network for Deep Image Deblurring [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 8174-8182.

[160] HU X, FU C W, ZHU L, et al. Depth-Attentional Features for Single-Image Rain Removal [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 8022-8031.

[161] LI R, CHEONG L F, TAN R T. Heavy Rain Image Restoration: Integrating Physics Model and Conditional Adversarial Learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 1633-1642.

[162] HE K, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2017: 2961-2969.

[163] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal Loss for Dense Object Detection[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2017: 2980-2988.

[164] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[C]//Advances in Neural Information Processing Systems (NeurIPS). 2015: 91-99.

[165] TAN M, PANG R, LE Q V. EfficientDet: Scalable and Efficient Object Detection[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 10781-10790.

[166] CHEN L C, ZHU Y, PAPANDREOU G, et al. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 801-818.

[167] LONG J, SHELHAMER E, DARRELL T. Fully Convolutional Networks for Semantic Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 3431-3440.

[168] RUSSAKOVSKY O, DENG J, SU H, et al. ImageNet Large Scale Visual Recognition Challenge[J]. International Journal of Computer Vision, 2015, 115: 211-252.

[169] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft COCO: Common Objects in Context [C]//Proceedings of the European Conference on Computer Vision (ECCV). 2014: 740-755.

[170] DONG C, LOY C C, HE K, et al. Learning a Deep Convolutional Network for Image Super-Resolution[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2014: 184-199.

中国知网 https://www.cnki.net

[171] WAH C, BRANSON S, WELINDER P, et al. The Caltech-UCSD Birds-200-2011 Dataset [Z]. 2011.

[172] PEI Y, HUANG Y, ZOU Q, et al. Does Haze Removal Help CNN-Based Image Classification? [C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 682-697.

[173] HENDRYCKS D, DIETTERICH T. Benchmarking Neural Network Robustness to Common Corruptions and Perturbations[A]. 2019: arXiv preprint arXiv:1903.12261.

[174] LOH Y P, CHAN C S. Getting to Know Low-Light Images with the Exclusively Dark Dataset [J]. Computer Vision and Image Understanding, 2019, 178: 30-42.

[175] YANG W, YUAN Y, REN W, et al. Advancing Image Understanding in Poor Visibility Environments: A Collective Benchmark Study[J]. IEEE Transactions on Image Processing, 2020, 29: 5737-5752.

[176] GIRSHICK R. Fast R-CNN[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2015: 1440-1448.

[177] LI C, LI L, JIANG H, et al. YOLOv6: A Single-Stage Object Detection Framework for Industrial Applications[A]. 2022: arXiv preprint arXiv:2209.02976.

[178] HUANG J, LIU Y, FU X, et al. Exposure Normalization and Compensation for Multiple-Exposure Correction[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 6043-6052.

[179] PAN X, LUO P, SHI J, et al. Two at Once: Enhancing Learning and Generalization Capacities via IBN-Net[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 464-479.

[180] XU Q, ZHANG R, ZHANG Y, et al. A Fourier-Based Framework for Domain Generalization [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 14383-14392.

[181] YANG W, TAN R T, FENG J, et al. Joint Rain Detection and Removal from a Single Image with Contextualized Deep Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 42(6): 1377-1393.

[182] MARTIN D, FOWLKES C, TAL D, et al. A Database of Human Segmented Natural Images and Its Application to Evaluating Segmentation Algorithms and Measuring Ecological Statistics[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2001: 416-423.

[183] MA K, DUANMU Z, WU Q, et al. Waterloo Exploration Database: New Challenges for Image Quality Assessment Models[J]. IEEE Transactions on Image Processing, 2016, 26(2): 1004-1016.

[184] SHAO S, ZHAO Z, LI B, et al. CrowdHuman: A Benchmark for Detecting Human in a Crowd

中国知网 https://www.cnki.net

[A]. 2018: arXiv preprint arXiv:1805.00123.

[185] QU Y, CHEN Y, HUANG J, et al. Enhanced Pix2Pix Dehazing Network[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 8160-8168.

[186] DONG Y, LIU Y, ZHANG H, et al. FD-GAN: Generative Adversarial Networks with Fusion-Discriminator for Single Image Dehazing[C]//Proceedings of the AAAI Conference on Artificial Intelligence (AAAI). 2020: 10729-10736.

[187] FAN Q, CHEN D, YUAN L, et al. A General Decoupled Learning Framework for Parameterized Image Operators[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 43(1): 33-47.

[188] DABOV K, FOI A, KATKOVNIK V, et al. Color Image Denoising via Sparse 3D Collaborative Filtering with Grouping Constraint in Luminance-Chrominance Space[C]//Proceedings of the IEEE International Conference on Image Processing (ICIP). 2007: I - 313-I - 316.

[189] ZHANG K, ZUO W, CHEN Y, et al. Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising[J]. IEEE Transactions on Image Processing, 2017, 26(7): 3142-3155.

[190] TIAN C, XU Y, ZUO W. Image Denoising Using Deep CNN with Batch Renormalization [J]. Neural Networks, 2020, 121: 461-473.

[191] YASARLA R, PATEL V M. Uncertainty Guided Multi-Scale Residual Learning-Using a Cycle Spinning CNN for Single Image De-Raining[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 8405-8414.

[192] WEI W, MENG D, ZHAO Q, et al. Semi-Supervised Transfer Learning for Image Rain Removal[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 3877-3886.

[193] JIANG K, WANG Z, YI P, et al. Multi-Scale Progressive Fusion Network for Single Image Deraining[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 8346-8355.

[194] LIU Z, WANG H J, ZHOU T, et al. Exploring Simple and Transferable Recognition-Aware Image Processing[A]. 2019: arXiv preprint arXiv:1910.09185.

[195] LIU D, ZHANG H, XIONG Z. On the Classification-Distortion-Perception Tradeoff[C]// Advances in Neural Information Processing Systems (NeurIPS). 2019: 1206-1215.

[196] CHAUDHRY A, RANZATO M, ROHRBACH M, et al. Efficient Lifelong Learning with A-GEM[A]. 2018: arXiv preprint arXiv:1812.00420.

[197] LOPEZ-PAZ D, RANZATO M. Gradient Episodic Memory for Continual Learning[C]// Advances in Neural Information Processing Systems (NeurIPS). 2017: 6470-6479.

中国知网 https://www.cnki.net

[198] LI C L, CHANG W C, CHENG Y, et al. MMD GAN: Towards Deeper Understanding of Moment Matching Network[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 2200-2210.

[199] TUNG F, MORI G. Similarity-Preserving Knowledge Distillation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 1365-1374.

[200] HINTON G, VINYALS O, DEAN J. Distilling the Knowledge in a Neural Network[A]. 2015: arXiv preprint arXiv:1503.02531.

[201] PASSALIS N, TEFAS A. Learning Deep Representations with Probabilistic Knowledge Transfer[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 268-284.

[202] PASSALIS N, TZELEPI M, TEFAS A. Probabilistic Knowledge Transfer for Lightweight Deep Representation Learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(5): 2030-2039.

[203] PALACIO S, FOLZ J, HEES J, et al. What Do Deep Networks Like to See?[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2018: 3108-3117.

[204] HANSEN B C, HESS R F. Structural Sparseness and Spatial Phase Alignment in Natural Scenes[J]. Journal of the Optical Society of America A, 2007, 24(7): 1873-1885.

[205] HU C, DU Y, WANG R, et al. Phase Matching for Out-of-Distribution Generalization[A]. 2023: arXiv preprint arXiv:2307.12622.

[206] CHEN L, LU X, ZHANG J, et al. HINet: Half Instance Normalization Network for Image Restoration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 182-192.

[207] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2017: 618-626.

中国知网 https://www.cnki.net