博 士 学 位 论 文

面向道路交通场景的低质图像增强及目标检测方法研究

Research on Low Quality Image Enhancement and Object Detection Methods for Road Traffic Scenes

一 级 学 科　　控制科学与工程

二 级 学 科　　模式识别与智能系统

作 者 姓 名　　李明鸿

指 导 教 师　　赵于前教授

2025 年 6 月

中国知网 https://www.cnki.net

中图分类号 TP391　　学校代码 10533
UDC 004　　学位类别 学术学位

博士学位论文

面向道路交通场景的低质图像增强及目标检测方法研究

Research on Low Quality Image Enhancement and Object Detection Methods for Road Traffic Scenes

作 者 姓 名	李明鸿
一 级 学 科	控制科学与工程
二 级 学 科	模式识别与智能系统
研 究 方 向	计算机视觉
二级培养单位	自动化学院
指 导 教 师	赵于前教授
副指导教师	

论文答辩日期 2025.6.22　　答辩委员会主席_____

中 南 大 学
2025 年 06 月

中国知网 https://www.cnki.net

面向道路交通场景的低质图像增强及目标检测方法研究

摘要：图像作为道路交通场景信息的重要载体，不仅为后台监控人员提供直观的环境理解与决策支持，也是智能驾驶系统实现视觉感知与分析的重要基础。然而，受限于采集设备性能、成像环境复杂性以及传输带宽等因素，实际获取的图像经常存在分辨率低、模糊、噪声干扰等质量问题。这些低质量图像不仅影响人眼的直观判读效率，更严重制约了后续如目标检测等视觉任务的可靠性。此外，道路交通场景中普遍存在诸如远距离道路坑洞等特征不显著的异常目标，难以被现有方法有效感知，进一步加剧了车辆行驶的安全风险。针对上述挑战，本文围绕道路交通场景中的低质量图像增强与目标检测性能提升的关键问题开展研究，提出了一系列有效的方法。论文的主要创新性工作包括：

（1）针对现有图像增强方法通常采用静态方式融合多尺度特征，导致模型适应性较弱的问题，本文提出一种基于空间域多尺度特征选择的低质图像增强方法。该方法设计了一个多尺度特征选择模块，并将其作为整体网络的基础构建单元。该模块通过多路并行与渐进连接策略，生成丰富且细粒度的多尺度特征。同时，引入宽激活残差学习机制以增强特征的非线性表达能力。为实现不同尺度特征的自适应融合，进一步提出尺度选择模块，用作多尺度特征选择模块中相邻支路间的连接桥梁。在尺度选择模块中，设计了一个综合通道注意力机制，通过考虑通道间的局部和全局依赖关系来计算准确的特征选择权重。实验表明，相较于其他方法，所提出的方法在能以最少的模型参数实现最佳性能。

（2）针对大多图像增强方法仅利用单一空间域信息进行学习，导致特征表达能力受限的问题，本文提出一种基于空间域和频率域混合的低质图像增强方法。为充分挖掘并整合两种域特征，该方法构建了一个混合域增强模块，作为整体网络的基础构建单元。该模块包含两条并行分支，分别负责空间域增强与频率域增强。空间域增强支路结合多路宽激活残差学习与空洞卷积技术，有效扩大感受野范围，提升对多尺度特征的建模能力；频率域增强支路则通过离散小波变换将输入特征分解为多种频率分量，并融合其互补信息，从而增强网络对

中国知网 https://www.cnki.net

高频细节的感知能力。实验结果表明，所提出的方法通过有效联合空间域与频率域信息，显著提升了模型性能。

（3）针对低质图像细节纹理丢失导致目标检测准确率低的问题，本文提出了一种基于双阶段增强的道路交通目标检测方法。在第一阶段，构建了一个超轻量级的任务分解增强网络，旨在检测器前执行图像级增强。在该网络中，为降低复合降质因素下图像重构的难度，将整个图像增强任务分为图像复原和分辨率增强两个子任务并依次执行。为探索共同且准确特征表示，两个任务分支采用递归方式连接，并在它们之间应用共享特征提取器。在第二阶段，设计了一个由高分辨率图像先验驱动的辅助特征增强头模块，无需增加推理开销，即可有效细化检测器中的任务相关特征。此外，该模块引入特征交互机制，通过交叉注意力融合低层增强特征与高层检测特征，有助于网络捕捉更完整的目标信息。实验结果表明，所提出的方法仅引入极少的参数就实现了显著优于对比方法的检测性能。

（4）针对远距离道路异常因视觉特征不显著而导致检测困难的问题，本文提出一种联合跨阶段特征交互和语义增强的远距离道路异常检测方法。为提升模型对异常目标与背景细微差异的感知能力，设计了一个跨阶段特征感知颈部模块，利用相邻阶段的信息加强每一阶段的骨干特征表示，为最终解码提供更全面的信息支持。该模块通过引入双向特征交互机制，在相邻两个阶段之间采用提出的多尺度交叉注意调制模块，深入挖掘输入特征间的多尺度长程依赖关系，从而实现阶段间目标线索的有效聚合。此外，构建了一个语义超分辨率头模块，借助高分辨率语义标签对初步预测图进行引导，提升分辨率表现，有效增强小尺寸异常目标的检测能力。实验结果表明，所提方法在参数量和计算复杂度较低的条件下，检测精度明显优于对比方法。

图39幅，表32个，参考文献156篇

关键词：卷积神经网络；低质图像增强；目标检测；多尺度特征提取；注意力机制

分类号：TP391

中国知网 https://www.cnki.net

Research on Low Quality Image Enhancement and Object Detection Methods for Road Traffic Scenes

Abstract: As an important carrier of information in road traffic scenes, images not only provide intuitive environmental understanding and decision support for backstage monitoring personnel but also serve as an important foundation for visual perception and analysis in intelligent driving systems. However, due to limitations in imaging equipment performance, the complexity of imaging environments, and bandwidth constraints, the acquired images often suffer from issues such as low resolution, blurriness, and noise interference. These low-quality images not only impair human visual interpretation but also seriously constrain the reliability of subsequent visual tasks such as object detection. In addition, road traffic scenes commonly contain anomalous objects with weak visual features, such as distant road potholes, which are difficult to effectively perceive by existing methods, thus increasing the safety risks of vehicle driving. To address these challenges, this thesis focuses on the key issues of low-quality image enhancement and object detection performance improvement in road traffic scenes, and proposes a series of effective methods. The main innovations of this thesis are as follows:

(1) To address the limitation that existing image enhancement methods usually use static strategies to fuse multi-scale features, which leads to weak model adaptability, a low-quality image enhancement method based on spatial-domain multi-scale feature selection is proposed. A multi-scale feature selection block (MFSB) is designed as the basic building unit of the overall network. The MFSB generates rich and fine-grained multi-scale features through multiple parallel branches and progressive connection strategies. In addition, a wide-activation residual learning mechanism is introduced to enhance the nonlinear representational capability of features. To enable adaptive fusion of features at different scales, a scale selection module (SSM) is further proposed, serving as a bridge between adjacent branches within the

中国知网 https://www.cnki.net

MFSB. In the SSM, a comprehensive channel attention mechanism is designed to compute accurate feature selection weights by considering the local and global inter-channel dependencies. Experimental results show that, compared with other methods, the proposed method achieves superior performance with minimal model parameters.

(2) Most image enhancement methods rely solely on single spatial domain information for learning, leading to limited feature expression ability. To address this problem, this thesis proposes a low-quality image enhancement method based on the combination of spatial and frequency domains. To fully exploit and integrate the two domain features, a hybrid-domain enhancement module (HDEM) is designed as the basic building unit of the overall network. The HDEM comprises two parallel branches that are responsible for spatial-domain and frequency-domain enhancement, respectively. The spatial-domain enhancement branch combines multi-branch wide-activation residual learning with dilated convolution to effectively enlarge the receptive field and improve the modeling of multi-scale features. The frequency domain enhancement branch decomposes the features into multiple frequency components through a discrete wavelet transform and fuses their complementary information, thereby enhancing the network's ability to perceive high-frequency details. Experimental results demonstrate that the proposed method significantly improves model performance by effectively integrating spatial and frequency domain information.

(3) Aiming at the problem of low accuracy of object detection caused by the loss of details and textures in low-quality images, a two-stage enhancement-based method for road traffic object detection is proposed. In the first stage, an ultra-lightweight task disentanglement enhancement network (TDEN) is constructed to perform image-level enhancement before the detector. In the TDEN, to reduce the difficulty of image reconstruction under complex degradation conditions, the entire enhancement task is divided into two sequential subtasks: image restoration and resolution enhancement. To explore common and accurate feature representations, two task branches are recursively connected, and a shared feature extractor is used between them. In the second stage, an

中国知网 https://www.cnki.net

auxiliary feature enhancement head (AFEH) driven by high-resolution image priors is designed to effectively refine task-related features in the detector without increasing inference overhead. Moreover, the AFEH incorporates a feature interaction mechanism that combines low-level enhanced features with high-level detection features through cross-attention fusion, which helps the network capture more complete object information. Experimental results show that the proposed method achieves significantly better detection performance than the compared methods by introducing only very few parameters.

(4) A joint cross-stage feature interaction and semantic enhancement method for road anomaly detection is proposed to address the detection difficulties caused by the insignificant visual features of distant road anomalies. To improve the model's ability to perceive subtle differences between anomalous objects and the background, a cross-stage feature perception neck (CSFPN) is designed. The CSFPN enhances the backbone feature representations at each stage by leveraging information from adjacent stages, providing more comprehensive information support for final decoding. A bi-directional feature interaction mechanism is introduced between adjacent stages, where a proposed multi-scale cross-attention modulation module is employed to capture long-range dependencies across multiple scales, thus facilitating the effective aggregation of object cues across stages. In addition, a semantic super-resolution head module is built to guide the refinement of the initial prediction map using high-resolution semantic labels, thereby improving spatial resolution and enhancing the detection of small-scale anomalies. Experimental results demonstrate that the proposed method achieves significantly higher detection accuracy than comparative methods while maintaining low parameter count and computational complexity.

Keywords: Convolutional Neural Network; Low-Quality Image Enhancement; Object Detection; Multi-scale Feature Extraction; Attention Mechanism
Classification: TP391

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 基于深度学习的低质图像增强方法.....3
1.2.2 低质图像目标检测.....6
1.2.3 道路异常检测方法.....8
1.3 本课题研究面临的挑战.....12
1.4 论文研究内容及创新点.....13
1.5 论文结构和安排.....15
第 2 章 基于空间域多尺度特征选择的低质图像增强.....17
2.1 引言.....17
2.2 基于空间域多尺度特征选择的低质图像增强方法.....19
2.2.1 多尺度特征选择网络总体结构.....19
2.2.2 基于多尺度特征选择的空间域增强模块.....20
2.2.3 基于综合通道注意力机制的尺度选择模块.....23
2.3 实验结果与分析.....26
2.3.1 数据集.....26
2.3.2 实验设置.....27
2.3.3 评价指标.....28
2.3.4 消融实验.....29
2.3.5 与其他方法的比较.....31
2.3.6 模型参数、计算复杂度与运行时间分析.....32
2.4 在道路交通场景中的应用.....33
2.4.1 提升道路交通场景下低质图像的人眼视觉感知.....33
2.4.2 提升道路交通场景下低质图像目标检测准确率.....36
2.5 本章小结.....37
第 3 章 基于空间域和频率域混合的低质图像增强.....39
3.1 引言.....39
3.2 基于空间域和频率域混合的低质图像增强方法.....40
3.2.1 混合域增强网络总体结构.....40
3.2.2 空间域和频率域混合增强的特征提取模块.....41
3.2.3 基于多路空洞宽激活残差的空间域增强模块.....42
3.2.4 基于离散小波变换的频率域增强模块.....44
3.3 实验结果与分析.....45

中国知网 https://www.cnki.net

3.3.1 实验设置.....45
3.3.2 消融实验.....45
3.3.3 与其他方法的比较.....47
3.3.4 模型参数、计算复杂度与运行时间分析.....49
3.4 在道路交通场景中的应用.....49
3.4.1 提升道路交通场景下低质图像的人眼视觉感知.....49
3.4.2 提升道路交通场景下低质图像目标检测准确率.....52
3.5 本章小结.....53
第 4 章 基于双阶段增强的低质图像道路交通目标检测.....55
4.1 引言.....55
4.2 基于双阶段增强的低质图像道路交通目标检测方法.....57
4.2.1 基于双阶段增强的低质图像道路交通目标检测框架.....57
4.2.2 基于任务分解策略的图像增强网络.....58
4.2.3 高分辨率先验引导的特征增强模块.....60
4.2.4 损失函数和训练策略.....63
4.3 实验结果与分析.....65
4.3.1 数据集.....65
4.3.2 实验设置.....66
4.3.3 评价指标.....67
4.3.4 消融实验.....68
4.3.5 与其他方法的比较.....71
4.3.6 泛化性分析.....76
4.3.7 特征分布可视化.....76
4.3.8 模型参数和运行时间分析.....78
4.4 本章小结.....79
第 5 章 联合跨阶段特征交互和语义增强的远距离道路异常检测.....80
5.1 引言.....80
5.2 联合跨阶段特征交互和语义增强的远距离道路异常检测方法 82
5.2.1 联合跨阶段特征交互和语义超分辨率网络总体框架.....82
5.2.2 高层语义和低层空间特征跨阶段融合感知颈部模块.....84
5.2.3 基于多尺度交叉注意力的双向特征交互模块.....84
5.2.4 基于混合域增强的语义超分辨率增强头模块.....87
5.2.5 损失函数.....88
5.3 实验结果与分析.....89
5.3.1 数据集.....89
5.3.2 实验设置.....89
5.3.3 评价指标.....90
5.3.4 消融实验.....91

中国知网 https://www.cnki.net

5.3.5 与其他方法的比较.....94
5.3.6 模型参数、计算复杂度与运行时间分析 97
5.4 本章小结.....98
第 6 章 总结与展望 99
6.1 总结.....99
6.2 展望.....100
参考文献.....102

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景及意义

近年来，人工智能技术已深度融入社会服务、产业数字化转型及国防现代化等多个领域，推动全球生产力模式和治理体系发生系统性变革。作为第四次工业革命的核心引擎，人工智能不仅被美国、欧盟等主要经济体视为国家战略竞争的重点领域，也成为我国实现科技自主创新、提升国际竞争力的重要突破口。从政策导向来看，早在 2017 年，国务院所颁发的《新一代人工智能发展规划》明确了“三步走”发展目标，提出到 2030 年建成世界主要人工智能创新中心[1]。到 2024 年，中国信通院颁布的《人工智能发展报告（2024 年）》更是指出，当前人工智能正处于迈向通用智能时代的初始阶段，该技术浪潮将推动更大范围的行业转型升级，助力行业迈向智能化新阶段[2]。在此背景下，图像智能解析技术作为人工智能必不可少计算机视觉领域中的攻坚方向，凭借其在非结构化数据处理上的独特优势，得到了国家的重点支持。

随着城市化进程的不断推进，城市道路交通网络日益庞大且复杂，交通管理与道路安全问题也随之愈发突出。为了有效缓解交通拥堵、降低事故发生率，并提升交通系统的智能化水平，基于计算机视觉技术的自动化感知与分析已逐渐成为智慧交通领域的重要研究方向。在实际道路交通场景中，图像不仅是视觉信息传递的重要载体，更直接服务于人类驾驶员、交通管理人员及应急响应人员等，帮助其快速、准确地感知道路环境、识别目标物体并评估潜在风险，从而辅助决策并提升交通安全性。与此同时，图像作为计算机视觉感知系统的核心输入，其质量也直接决定了后续视觉任务的准确性与鲁棒性。尤其在目标检测等关键应用中，高清晰度、高质量的图像能够显著提升算法的稳定性和实用性，进一步保障智能驾驶系统的高效运行。

然而，在道路交通场景下，受前端摄像设备的硬件性能、复杂多变的成像环境，以及网络传输带宽等因素限制，实际获取的图像往往存在分辨率低、模糊、噪声干扰等退化问题。在本章中，这类图像统称为低质图像，如图 1-1 所示。低质图像不仅影响了人眼对画面内容的直观判读，降低了相关工作人员的工作效率，同时还会影响图像特征提取和分析，从而对后续视觉任务造成较大挑战，给实际的应用带来困难。例如，在自动驾驶过程中，车辆摄像头捕捉的图像不仅需要输入给智驾系统进行视觉感知分析，有时还需要实时传输到云端以提供给后台安全员观看，以判断是否需要进行人工接管，如图 1-2 所示。然而，在图像采集、转换、传输和显示的过程中因为各种因素影响，导致获取的图像呈现低质特点。

中国知网 https://www.cnki.net

这些低质图像由于自身纹理特征丢失严重，不仅会影响智驾系统中图像感知相关任务如道路交通目标检测的准确性，从而降低车辆行驶的安全性，还会使后台安全员人工聚焦的成本提高，增加他们提取场景真实信息的难度，使得决策延迟加剧和交互滞后，甚至会导致信息误判，从而进一步加大车辆行驶安全风险。

除了图像质量受限所带来的感知困难，道路交通场景中还普遍存在另一类视觉感知难题：远距离的道路异常检测。例如，道路异常中的坑洞往往因其自身与周围环境在色彩、亮度或纹理上差异较小，极易被视觉系统忽略或误判。如果道路坑洞还处于距离摄像头较远的位置，其所占据的像素信息将进一步降低。这类道路异常往往存在明显的特征不显著问题，且更容易受如光照不足、阴影等环境因素的影响。这不仅增加了视觉检测算法的识别难度，也容易导致自动驾驶车辆在行驶过程中出现感知延迟，从而降低后续路径规划的安全性，还会因此造成行车颠簸，影响乘坐舒适性。

综上所述，如何增强低质图像的质量并提高低质图像中道路交通目标的检测能力，以及如何精准定位远距离道路异常，已成为道路交通场景下智慧系统亟需解决的重要问题。本文将面向道路交通场景的低质图像增强及目标检测方法作为课题并展开深入研究，以进一步推动图像智能解析技术在实际道路交通场景中的应用，提升交通系统感知智能化。



图 1-1 低质图像示例



(a) 萝卜快跑自动驾驶车辆 (b) 自动驾驶后台安全员

图 1-2 自动驾驶和后台安全员示例

中国知网 https://www.cnki.net

1.2 国内外研究现状

1.2.1 基于深度学习的低质图像增强方法

针对如何有效改善低质图像的质量问题，图像超分辨率（Super-Resolution，SR）重建是最常用的一种增强技术。图像 SR 作为图像智能解析领域的重要方向，长期以来受到众多研究学者的关注[3-5]。图像 SR 技术的目标是通过从低分辨率（Low-Resolution，LR）图像中恢复细节信息，从而生成高分辨率（High-Resolution，HR）图像[6,7]。从给定 LR 图像中重构出原始 HR 图像是一个非常有挑战性的问题。这主要源于一个事实：一幅 LR 图像对应无数种可能的 HR 图像，使得图像 SR 成为一个典型的病态问题。

在 SR 任务中，LR 图像通常由如下降质模型生成：

$$\boldsymbol{I}_{\mathrm{LR}} = \left(\boldsymbol{I}_{\mathrm{HR}} * \boldsymbol{\kappa}\right)\downarrow_{s} + \boldsymbol{\eta} \tag{1-1}$$

式中，$\boldsymbol{I}_{\mathrm{HR}}$ 和 $\boldsymbol{I}_{\mathrm{LR}}$ 分别表示输入的 HR 图像和对应输出的 LR 图像；$\boldsymbol{\kappa}$ 为模糊核；$*$ 表示卷积运算；$\downarrow_{s}$ 是指下采样率为 s 的下采样操作；$\boldsymbol{\eta}$ 是加性噪声。

随着深度学习的快速发展，图像 SR 领域涌现了许多基于深度学习的方法[8-11]，并取得了令人瞩目的成功。最早基于卷积神经网络（Convolutional Neural Network，CNN）的图像 SR 方法是由 Dong 等人[12]提出的 SRCNN（Super-Resolution CNN，SRCNN）。该方法能较好地诠释了网络中每一步的物理意义，从而为后续基于 CNN 的 SR 方法提供基础理论支撑。然而，SRCNN 仅采用简单的三层网络结构，限制了其学习复杂特征的能力。针对这一问题，Kim 等人[13]提出了一种 20 层深的网络结构，命名为 VDSR（Very Deep convolutional network for image Super-Resolution，VDSR）。该网络通过引入全局跳跃连接方式，使其可以关注高频残差特征的学习，从而改善 SR 图像重建的能力。VDSR 的成功反映了更深的网络可以实现更优的模型性能。为此，Tai 等人[14]通过将门单元（Gate Unit）与记忆模块（Memory Block）相结合，并通过将结合后的模块进行多次堆叠，建立了一个名为 MemNet（Memory Network for image super-resolution）的网络，其有 80 层深。更有甚者，Lim 等人[15]通过堆叠大量残差单元开发了一个名为 EDSR（Enhanced Deep residual network for single image SR）的超大规模网络，参数数量甚至达到了百万（Million，M）级别。得益于残差单元中有效的跳跃传输机制和所构建的大规模网络，EDSR 在 2017 年的 NTIRE（New Trends in Image Restoration and Enhancement）SR 挑战赛中一举夺冠。从此，大规模 SR 网络的设计成为了大量研究工作人员热衷追求的方向。值得注意的是，虽然大尺寸 SR 模型能带来不错的性能提升，但也由于过于复杂的网络结构，在训练过程中容易出现梯度消失或梯度爆炸问题。为了解决这些问题，Zhang 等人[16]提出的 RDN

中国知网 https://www.cnki.net

（Residual Dense Network）通过结合稠密连接策略[17]和局部特征融合方式，形成一种连续记忆机制，得到了优异 SR 结果。

为进一步改善 SR 模型性能，一些研究工作者受高层视觉任务启发，引入各种注意力机制到 SR 任务中[18-23]，并得到了较好的成果。例如，Zhang 等人[18]提出的 RCAN（Residual Channel Attention Network）通过结合残差中的残差思想和通道注意力机制来构建基础特征提取模块，不仅增强了特征的判别能力，还使信息传递更有效，从而有助于恢复 SR 任务所关注的高频信息。考虑到 RCAN 中的通道注意力机制只是简单地采用全局平均池化（Global Average Pooling，GAP）来对特征进行一阶信息统计，并不能有效表征每个特征通道的重要性，Dai 等人[24]提出一种二阶注意力网络（Second-order Attention Network，SAN）。该网络通过采用协方差矩阵来描述通道之间的相关性，从而使得模型更有判别性地关注每个特征通道，从而提升 SR 重建结果。除了应用通道注意力，Chen 等人[25]还引入空间注意力来捕捉不同分辨率特征的长距离依赖关系，搭建了一种多注意力增强网络（Multi-Attention Augmented Network，MAAN）。通过有效结合通道注意力和空间注意力，MAAN 获得明显高于 SAN 的 SR 性能。虽然上述大多数方法在 SR 性能方面取得了长足进步，但同样带来了计算负担和参数的急剧增加，因此难以在低预算移动设备中部署。

最近，在 SR 领域，研究学者们对设计节省计算资源的高效轻量级网络的兴趣逐渐增加[26]。Dong 等人[27]提出的 FSRCNN（Fast Super Resolution using Convolutional Neural Network）采用紧凑沙漏形结构并通过应用反卷积层对 LR 特征进行上采样来得到 SR 图像。Lai 等人[28]提出的 LapSRN（Laplacian pyramid Super-Resolution Network）通过金字塔式的上采样策略，渐进提升图像分辨率，从而实现优秀 SR 性能。Ahn 等人[29]通过引入组卷积来代替常规卷积，建立了一个名为 CARN-M（CAscading Residual Network-Mobile）的网络用于移动设备。与 CARN-M 采用组卷积降低参数的策略类似，Hao 等人[30]提出的轻量级蓝图残差网络（Lightweight Blueprint Residual Network，LBRN）通过利用蓝图分离卷积和残差的残差策略来学习高频信息，从而以较低的模型参数实现较好的图像重建性能。与前面通过卷积优化技术来达到降低网络参数目的不同，Tai 等人[31]通过引入递归学习开发了一种深度递归残差网络（Deep Recursive Residual Network，DRRN）实现了高效特征学习。该网络的核心在于所构建的递归模块包含几个共享权重的残差单元，使其在增加网络深度的同时能避免引入过多参数，从而在模型性能与参数之间实现较好的平衡。Jiang 等人[32]提出的 IMRN（Information Multi-slicing Residual Network）采用渐进式全局稀疏优化策略来裁剪网络，使其维持模型性能的同时降低了计算复杂性。最近，Park 等人[33]提出的 DRSAN

中国知网 https://www.cnki.net

（Dynamic Residual Self-Attention Network）引入一种自适应残差连接方法，其利用各种残差特征组合来应对不同输入统计数据，给模型带来更多灵活性，提升了图像重建质量。

在高层视觉任务中已经证实了多尺度特征学习能有效改善 CNN 模型性能[34,35]。受此启发，一些研究者也开始将高层视觉任务中的多尺度学习策略如多支路结构等引入到 SR 领域中，企图以较少的模型参数实现较高的 SR 性能。例如，Li 等人[36]开发的 MSRN（Multi-Scale Residual Network）采用3×3 和5×5 卷积的双分支结构，结合双向交互策略，实现有效的多尺度特征提取，改善了 SR 重建结果。另一方面，Hui 等人[37]引入信息蒸馏概念构建了一种名为 IDN（Information Distillation Network）的 SR 网络。该网络通过将中间特征切分成两部分，一部分用于进一步提炼，另一部分则被保留并通过跳跃连接方式输送到模块后端继续处理，从而实现多尺度特征的利用。考虑到 IDN 只简单地进行一次信息蒸馏步骤难以充分学习多尺度特征的问题，Hui 等人[38]进一步开发了 IMDN（Information Multi-Distillation Network）。该网络主要是采用了一个新的信息多重蒸馏块（Information Multi-Distillation Block，IMDB），通过多次采用特征切分操作来逐步提取分层特征，以实现更好的特征表示能力。然而，无论是 IDN 还是 IMDN，它们所采用的特征通道切分方式会带来一些结构设计上的不灵活。为了解决这个问题，Liu 等人[39]提出的 RFDN（Residual Feature Distillation Network）采用了另一种更轻量化的残差特征蒸馏块来实现特征细化。该模块主要使用1×1 卷积层取代特征切片操作实现更灵活的特征蒸馏。此外，还引入了更细粒度的残差学习，并将其与单个3×3 卷积结合起来，更有效地探索多尺度特征。与前面基于信息蒸馏的方法不同，李等人[40]提出的双阶段特征补偿的信息蒸馏网络（Two-stage Feature-compensated Information Distillation Network，TFIDN）额外引入特征补偿机制，使得不同级别的特征能进行合并，从而有效促进网络内信息的流动，提高信息利用率。Zhu 等人[41]提出的 EMASRN（Expectation-Maximization Attention mechanism for Super-Resolution Network）所采用的多尺度特征提取模块通过集成 Res2Net[42]（Residual 2nd order Network）的分支交叉连接思想，捕捉到更丰富的多尺度特征，进一步增强了模型特征的表达能力。

虽然上述轻量级 SR 方法探索了不同多尺度特征提取策略，但大多数方法往往采用像素加或者通道拼接的方式来对多尺度特征进行融合，这类线性且静态的融合方式等同地处理每种尺度特征，导致模型的适应能力偏弱。此外，大多数方法仅专注于空间域特征的强化，这种单一域信息学习的方式，会造成网络在捕捉图像特征时不够全面，从而限制模型特征表达能力的进一步提升。针对以上两个问题，本文在第二章和第三章中分别提出相应的解决方法。

中国知网 https://www.cnki.net

1.2.2 低质图像目标检测

随着深度学习技术发展，CNN 已被广泛应用于目标检测任务[43-46]中。最近，基于 CNN 的目标检测方法在经典基准数据集上取得了显著结果。这些检测方法主要分为两类：以 R-CNN 系列为代表的双阶段检测算法[47-49]和以 YOLO 系列为代表的单阶段检测算法[50]。例如，Girshick 等人[51]首次将深度学习应用到目标检测领域，提出了一种名为 R-CNN（Region-based Convolutional Neural Network）的算法。该算法先通过选择性搜索算法生成大量候选区域，并利用 CNN 在这些区域上进行特征提取。然后，采用 SVM 分类器对提取的特征进行判别后用线性回归模型调整边界框。考虑到 R-CNN 存在大量计算冗余的问题，Girshick 等人[52]进一步提出了 Fast R-CNN 算法，通过将图像输入到 CNN 中进行特征提取，然后基于所提取的特征生成候选区域，从而避免了特征重复计算。为进一步提升 Fast R-CNN 的速度，Ren 等人[53]提出了 Faster RCNN，其主要引入了区域提议网络（Region Proposal Network，RPN）来代替传统的选择性搜索算法以优化候选区域的生成方式。通过应用 RPN，Faster RCNN 实现了端到端检测，不仅大大提升了检测速度，还保持较高准确率。以上 RCNN 系列算法都采用的是双阶段检测策略：需要先生成候选框再进行目标的检测和定位。因此，这类算法的精度虽高，但由于检测过程繁琐且计算量较大，导致推理速度相对较慢。考虑到这个问题，Redmon 等人[54]开创性地提出单阶段检测算法 YOLO（You Only Look Once）。该算法主要将图像划分成多个网格单元，然后各单元直接预测目标的类别、置信度以及边界框位置，实现了检测速度的飞跃。虽然，YOLO 初步展示了单阶段算法在实时性上的优势，但在精度方面仍存在一定的限制，特别是在面对小目标时容易出现误检和漏检。基于此，Redmon 等人在 YOLO 的基础上通过更换特征提取能力更强的骨干网络、引入批量归一化（Batch Norm，BN）[55]、使用高分辨率分类器、采用锚点框以及多尺度预测策略来进一步提高检测精度，从而衍生出了 YOLOv2[56]和 YOLOv3[57]算法。随着技术不断深入探索和优化，学者们相继提出了 YOLOv4[58]、YOLOv5[59]、YOLOv6[60]以及 YOLOv7[61]等算法，为 YOLO 目标检测框架注入了许多创新元素。虽然现有目标检测模型在经典数据集上已经实现了较高的检测精度，但它们大多是在高质量图像数据集上进行训练和优化的，在实际道路交通场景应用中可能难以处理因各种降质因素影响而产生的低质图像。若在低质图像上直接进行检测，这些模型的检测精度容易因高质量和低质量图像之间的特征域差距过大而出现明显下降。为解决这个问题，研究学者们提出了一些有效的方法，主要分为三类，包括重训练方法、独立增强方法和联合增强和目标检测方法。

（1）重训练方法

中国知网 https://www.cnki.net

重训练方法是指利用低质图像训练集对目标检测模型进行重新训练的方法。尽管这种方法在低质图像目标检测中最为直观和简便，但实际效果往往难以达到预期。究其原因，低质图像在采集过程中丢失了大量细节信息和小尺度结构特征，而这些降质图像直接输入到检测器后，难以提取有用的任务相关特征，从而影响模型的收敛效果和检测精度。

（2）独立增强法

独立增强方法是指低质图像先经过一个预处理的网络进行图像增强后进一步输入到目标检测器中进行检测。值得注意的是，预处理部分和目标检测部分是单独进行的，且它们都由预训练好的模型执行。已经有一些研究表明，在识别模型之前应用 SR 模型进行图像增强可以在一定程度上提高识别性能[62-64]。然而，目前大多方法采用像素损失来对预增强模型进行优化训练，使得增强后的 SR 图像与 HR 图像在像素层面上尽可能接近，从而实现视觉上的图像质量改良。因此，这些 SR 方法主要是针对人类视觉系统而非机器感知所设计的。这就容易导致下游检测任务可能无法总是从独立增强后的图像中获益，一定程度限制了模型检测性能的提升[65]。

（3）联合增强和目标检测方法

在联合增强和目标检测方法中，增强网络和检测器是在低质图像上共同训练和联合优化的。最近，研究工作者开发了一些联合增强和目标检测方法。例如，Haris 等人[66]通过将图像 SR 与目标检测任务进行结合，提出了一种名为 TDSR（Task-Driven Super Resolution，TDSR）的方法。该方法主要将 SR 子网络和特定检测器简单级联，并利用目标检测损失和像素损失来进行端到端训练，使 SR 子网络能更好地服务于目标检测任务，从而提升在 LR 图像上的检测准确率。与 TDSR 类似，Wang 等人[67]提出的 FDSR（Feature-Driven Super Resolution for object detection）虽然也将 SR 子网络作为目标检测器的预增强部分，但不同的是，FDSR 是直接使用从现有检测器骨干网络提取的特征域先验来指导 SR 网络进行图像重建。通过这种方式，能够使所得到的增强图像更符合目标检测任务的要求，为后续检测器提供更有益的特征信息。然而，无论是 TDSR 还是 FDSR 都采用相同的大规模 SR 网络 DBPN（Deep Back-Projection Network）[68]作为预处理子网络，导致整体框架的计算负担大和推理速度慢。因此，Talebi 等人[69]提出一种用于计算机视觉任务的可学习图像缩放器（Learned image Resizer for Computing Vision Task，LRCVT）来解决这个问题。LRCVT 具备轻量级的网络结构且同样可以与视觉模型进行联合训练。与传统的双线性插值（Bilinear）、双三次插值（Bicubic）等图像缩放方法不同，LRCVT 能根据具体的计算机视觉任务和数据来调整图像缩放方式以提升模型性能。不同于前面的联合增强和目标检测方法，Liu 等人[70]

中国知网 https://www.cnki.net

提出了一种图像增强引导目标检测（Image Enhancement Guided Object Detection，IEGOD）方法，其主要应用外部图像增强分支来完善检测器的骨干特征。由于该外部图像增强分支仅在训练阶段参与，而在推理阶段丢弃。因此，IEGOD 并没有引入额外的计算负担和参数。与 IEGOD 类似的研究工作还有 Cui 等人[71]提出的 AERIS（Auto Encoding Resolution In the Self-supervision）和 Zhang 等人[72]提出的 SuperYOLO（Super-resolution assisted YOLO）。它们分别在检测器的颈部网络和骨干网络处引入 SR 解码器，并以多任务学习方式增强检测特征的表示能力，从而提高 LR 图像目标检测精度。虽然 IEGOD、AERIS 和 SuperYOLO 避免了引入大量计算负担，但仍会遭遇到像重训练方法一样的挑战：难以从低质图像中提取准确的特定任务特征。

上述方法虽然能一定程度提升低质图像目标检测的准确率，但往往难以在模型检测性能和计算复杂度之间取得较好地平衡。而本文在第四章研究的一种高效低质图像目标检测方法，能较好地解决这个问题。所提方法能以较低的参数和计算量实现更好的检测精度，从而推动目标检测技术在道路交通场景下的进步与应用拓展。

1.2.3 道路异常检测方法

目前，大多数自动驾驶感知系统的检测重点主要集中在行人、交通标志及车辆等显著目标上，往往对路面异常的关注不足[73]。事实上，路面状况是影响车辆全生命周期性能的关键因素。从行驶平顺性、操控稳定性到燃油经济性、轮胎磨损程度，细微的路面缺陷都可能引发连锁反应。而道路坑洞作为最频发的路面异常，不仅会加剧驾乘颠簸感，更可能因车辆高速碾轧导致轮胎瞬间鼓包爆裂，进而诱发严重交通事故，造成难以估量的生命财产损失。因此，深入研究道路坑洞检测技术，系统梳理其研究现状，对攻克道路异常检测难题、保障车辆行驶安全、提升智能驾驶系统可靠性具有重要的现实意义。

目前，道路坑洞检测方法主要可分为三类：基于经典二维图像处理的方法、基于三维点云建模与分割的方法以及基于数据驱动的深度学习方法[74]。第一类方法主要依靠传统图像处理算法对道路的 RGB 或深度图像进行分割[75]。然而，这类方法对环境因素，尤其是光照变化和天气条件十分敏感[76]。此外，由于坑洞本身具有形状不规则的特点，基于几何假设的分割方法在实际场景中往往难以适用，导致鲁棒性较差。为了解决上述问题，部分研究工作采用了基于三维点云的建模与分割方法[77]。该类方法通常将采集到的道路三维点云建模为二次曲面，并通过分析建模曲面与实际点云之间的残差，完成对道路表面异常区域的分割[78]。尽管此类方法在理论上可以有效应对坑洞的复杂形态，但对三维成像设备

中国知网 https://www.cnki.net

及计算资源的依赖较大，检测成本也相对较高。随着深度学习技术的发展，依托 CNN 强大的特征表示能力，基于数据驱动的方法已逐渐成为道路坑洞检测的主流选择。在该方向的早期研究中，受通用目标检测算法的启发，不少学者尝试将经典的双阶段方法（如 R-CNN 和 Faster R-CNN）以及单阶段方法（如 YOLO）应用到道路坑洞检测任务中，并取得了良好的检测效果[79,80]。例如，文献[81]中，Yebes 等人采用不同骨干网络的 Faster R-CNN 对道路坑洞进行检测，其所得实验结果表明，使用 ResNet101[82]作为骨干网络能够获得最佳检测性能。需要指出的是，以上方法只能在目标层面对坑洞进行定位，即通过矩形框粗略标注坑洞的位置，无法实现像素级分割。针对这一问题，基于语义分割的检测方法则提供了另一种有效的解决方案，能够对坑洞的具体形态和边界进行更精确的描述。

第一个将 CNN 应用到像素级预测的语义分割方法是由 Long 等人[83]提出的全卷积网络（Fully Convolutional Network，FCN）。该网络通过将卷积层代替分类网络中的全连接层，使其不需要受到传统固定输入图像维度的束缚，更好地对任意分辨率图像进行分割。然而，FCN 仅是简单地进行卷积堆叠，缺乏利用全局语义线索。为了解决这个问题，Zhao 等人[84]提出一种金字塔场景解析网络（Pyramid Scene Parsing Network，PSPNet）。该方法的核心在于提出一种金字塔池化模块（Pyramid Pooling Module，PPM）来有效捕捉不同尺度的上下文信息，以提升网络对全局语义的理解，进而改善分割性能。虽然 PSPNet 通过在不同尺度上执行池化操作获得了丰富的语义知识，但也因此丢失了与目标相关的详细信息。为了解决这个问题，Chen 等人[85]提出的 DeepLab-v3+通过结合空洞卷积与多尺度特征融合策略，设计出的空洞空间金字塔池化（Atrous Spatial Pyramid Pooling，ASPP）模块能进一步提升网络对不同尺度目标的感知能力。为了进一步提升模型的分割精度，Xie 等人[86]提出的 SegFormer（Segmentation with transFormers）以其轻量级且无需位置编码的分层 Transformer 编码器设计，能同时生成高分辨率精细特征和低分辨率粗特征，表现出极具竞争力的像素预测能力。与通用目标检测方法类似，通用语义分割方法如 FCN 和 DeepLab-v3+等同样被一些研究学者应用到道路坑洞检测中[87,88]。

由于坑洞这类道路异常在纹理、颜色等方面常常与其周围背景具有较高的相似性，呈现出低对比度的视觉特征，这一特性与伪装目标的视觉属性高度相似。因此，近年来兴起的伪装目标检测（Camouflaged Object Detection，COD）方法[89-92]，其核心思想同样适用于道路坑洞检测任务。值得注意的是，COD 虽然名称上为检测方法，但其本质上与语义分割方法一样，都是执行像素级预测任务。早期 COD 方法主要依靠手工设计的特征进行目标定位，常见特征包括三维凸度特征[93]、颜色特征[94]、边缘特征[95]和纹理特征[96]，用于辅助从复杂背景中分离

中国知网 https://www.cnki.net

伪装目标。然而，由于手工特征在表达能力和适应性方面的局限性，这类方法的检测精度始终难以满足实际应用需求。随着大数据时代的到来，基于CNN的COD方法相继问世，并取得了显著性能提升。

众所周知，深度学习通常需要大型数据集来训练模型。为了解决现有 COD 数据集在规模上的局限性，Fan 等人[97]构建了最大的 COD 数据集名为 COD10K，并同时提出了一种简单但有效的搜索识别网络（Search Identification Network，SINet）。为了进一步提升模型性能，Mei 等人[98]创建了定位和聚焦网络（Positioning and Focus Network，PFNet）。该网络主要包含两个关键模块，分别为定位模块和聚焦模块，前者负责从全局角度定位目标，后者则是用于执行识别过程。通过有效搭配这两个模块，PFNet 的检测精度得到了一定提升。随后，Zhou 等人[99]设计了一种特征聚合和传播网络（Feature Aggregation and Propagation Network，FAPNet）用于 COD 任务。该网络通过有效融合跨层特征并自适应地向解码器传输有价值的上下文信息以此实现检测准确率的提高。与 FAPNet 采用的并行跨级特征融合方式不同，Chen 等人[100]提出的 C2FNet-V2（Context-aware Cross-level Fusion Network Version 2）构建了一个注意力诱导的跨层融合模块，旨在从上到下逐步融合相邻阶段的特征。受人类寻找伪装目标过程中重点观察目标与背景之间边界的启发，Zhu 等人[101]提出一种边界指导的分离注意力网络（Boundary-Guided Separated Attention Network，BSANet）。该网络通过额外构建一个边缘检测器以有效利用边缘信息指导骨干特征细化，以此增强目标与背景之间差异，进而准确定位伪装目标。考虑到重叠角和隐含边界等情况容易带来较大不确定性，Lyu 等[102]引入贝叶斯神经网络，通过利用概率衍生的不确定性，提升了对隐藏物体的精确检测能力。虽然上述方法在 COD 领域取得了长足进步，但由于过分追求应用大规模骨干网络或设计复杂的解码器，大多数方法遭遇模型规模和计算成本急剧增加的问题。

为避免给解码步骤引入过多计算负担，学者通常采用一些策略来将编码器的输出特征转换到一个更紧凑的格式，再输入到解码器中进行解码。一种最直接的策略就是用1×1卷积调整特征通道维度，从而实现特征转换。虽然这种策略引入的参数数量较少，但其只能进行全通道特征聚合，而无法实现局部特征提取功能。为解决这个问题，一些 COD 算法，包括 MRR-Net（Matching-Recognition-Refinement Network）[103]、FSPNet（Feature Shrinkage Pyramid Network）[104]和 DGNet（Deep Gradient Network）[105]，采用3×3卷积而不是1×1卷积来实现特征变换。此外，为进一步丰富各阶段骨干特征的上下文信息，一些研究采用多尺度模块来调整通道维度。例如，SINet-V2（Search Identification Network Version 2）[106]、FEDER（FEature Decomposition and Edge Reconstruction）[107]和 C2FNet-V2[100]

中国知网 https://www.cnki.net

都采用了纹理增强模块（Texture Enhanced Module，TEM）[108]来扩大感受野。Liu 等人[109]提出的 MSCAF-Net（Multi-Scale Context-Aware Feature Network）使用基于人类视觉系统特征设计的增强感受野（Enhanced Receptive Field，ERF）模块来捕捉不同尺度特征。鉴于尺度变化给 COD 任务带来的一大挑战，FAPNet[99]在完成特征转换功能的同时，使用多尺度特征聚合模块来描述目标尺度变化。然而，上述方法都是对每个阶段的骨干特征进行单独处理，没有考虑骨干特征之间的相关性。因此，这些方法可能不足以在特征转换过程中探索出每个阶段骨干特征的综合表示线索。

为进一步提升模型检测性能，一些研究工作引入了 Transformer 到 COD 任务中。Transformer 最早由 Vaswani 等人[110]提出，并应用于自然语言处理领域。Transformer 的核心设计是多头自注意模块，旨在学习输入句子中不同单词之间的长距离依赖关系以获得全局信息。后来，各种 Transformer 变种被引入到计算机视觉领域，并用于各种视觉任务中，如目标检测[111-113]、图像分类[114-116]、图像分割[117-119]。值得一提的是，Dosovitskiy 等人[120]提出的视觉 Transformer（Vision Transformer，ViT）是 Transformer 在计算机视觉领域应用的一项开创性工作。虽然 ViT 在图像分类任务上实现明显的性能提升，但其不适合处理 HR 图像。因为随着图像尺寸增大，ViT 计算需求会呈指数级增长。为解决这个问题，学者提出了几种解决方案，包括 Swin Transformer[121]、金字塔视觉 Transformer（Pyramid Vision Transformer，PVT）[122]和尺度调制 Transformer（Scale-aware Modulation Transformer，SMT）[123]。Swin Transformers[121]通过同时采用移位窗口自注意策略和分层结构来达到降低计算复杂度的目的。PVT[122]通过应用空间缩减注意层，进一步降低了 CNN 的计算复杂度，并在图像分类任务中取得了优异的结果。与前两种 Transformer 相比，SMT[123]是一种结合了 CNN 和 Transformer 的混合网络。得益于这种混合结构，SMT 避免了计算大空间尺寸特征自注意力所带来的沉重计算负担。考虑到 Transformer 在目标分类任务应用的有效性，FSPNet[104]采用 ViT 作为 COD 框架的骨干网络，并提出一种非局部令牌（Token）增强模块。该模块借助非局部机制，促使相邻 Token 相互作用，同时挖掘 Token 内部基于图结构的高阶关系，以此强化 Transformer 的局部表征能力。Xing 等人[124]采用 PVT 作为提取全局特征表征的骨干部分，并开发了一种搜索—放大—识别三阶段网络（Search-Amplify-Recognize Network，SARNet），以更好地检测隐藏在背景中的物体。

总的来说，由于传统的检测方法并不能提供足够检测精度，本文在第五章提出的道路异常检测方法主要基于深度学习技术。考虑到通用目标检测方法如 Faster RCNN 等，仅能支持矩形框对道路异常进行粗略定位，而无法描绘异常目

中国知网 https://www.cnki.net

标的具体轮廓，因此，本文第五章方法是基于像素级定位开发的。此外，在道路异常像素级预测任务中，无论是基于通用语义分割的方法还是 COD 方法，它们大多都缺乏有效的跨阶段特征关联手段，导致浅层定位信息与深层语义线索无法有效互补，限制了网络对远距离道路异常的感知能力。针对这一问题，本文第五章提出的跨阶段特征交互颈部模块能作为一种有效的解决方案。

1.3 本课题研究面临的挑战

基于上述文献分析，现阶段围绕道路交通场景下低质图像增强及目标检测方法研究仍面临以下挑战：

（1）多尺度特征静态融合不充分导致模型适应能力弱

目前低质图像增强方法通常采用多支路结构提取不同感受野下的多尺度特征，旨在通过扩大特征感知范围来增强图像重建的信息完备性。然而，这些方法在对多尺度特征进行融合时，普遍采用像素相加或通道拼接等静态线性方式，这不仅降低了特征表达的灵活性，还容易导致模型缺乏足够的适应性和限制了网络在复杂场景中对纹理细节重建的能力。

（2）单一域信息不全面导致模型特征表达能力受限

大多图像在频率维度上具有显著不平衡性：大部分能量集中在低频区域（如平滑的背景），而高频成分（如锐利边缘和细腻纹理）占比较少。当图像经历降质后，所得到的低质图像中高频信息含量会进一步降低，给图像增强带来不小挑战。此外，目前主流图像增强方法主要依赖于 CNN 或 Transformer 架构，其通常采用空间域特征提取模块（如残差单元和自注意力模块）来学习局部纹理和全局信息。虽然，这类方法能有效学习图像的整体结构，但其仅从空间维度上分析像素关系，而忽略了对高频细节重建更为关键的频率域特征探索，从而限制了模型的特征表达能力。

（3）道路交通场景下低质量图像细节纹理丢失导致目标检测精度低

在道路交通实际应用场景中，图像从采集到数据传输的各个环节，不可避免会受到环境噪声、设备性能局限、传输带宽限制等多种降质因素影响。这些因素使得最终获取的图像呈现出分辨率低、画面模糊、细节纹理大量丢失等特征。若直接将基于高质量图像数据集训练的传统目标检测模型应用于低质量图像检测，会由于低质图像与高质量图像之间存在显著的域差异，模型难以适应低质图像的特征分布，从而导致检测精度大幅下降。

（4）道路交通场景下远距离道路异常视觉特征不显著导致检测难度大

在道路交通场景中，道路异常由于自身材质或受环境因素影响与周围背景颜色相近，呈现低对比度特性。在这些异常中，特别是远距离的道路异常在图像中

中国知网 https://www.cnki.net

占据像素信息较少，往往缺乏足够的细节纹理和存在明显视觉特征不显著的问题，使其更容易隐藏在背景之中，大大增加了检测难度。

1.4 论文研究内容及创新点

针对目前道路交通场景下低质图像增强及目标检测方法研究中所存在的问题，本文提出了对应的解决方案。本文的总体技术路线如图 1-3 所示，主要研究内容及创新点如下：

（1）基于空间域多尺度特征选择的低质图像增强方法

针对多尺度特征静态融合导致模型适应能力弱的问题，提出一种基于空间域多尺度特征选择的低质图像增强方法。该方法主要提出一种多尺度特征选择模块，用作总体网络的基础构建单元。该模块主要通过搭建一种多路并行且渐进连接的结构来实现细粒度多尺度特征的提取。同时，该方法还提出一种新颖的尺度选择模块，并将其作为多尺度特征选择模块中相邻支路的连接桥梁，以动态地融合携带不同感受野信息的两个分支特征，实现特征的高效表达。该方法通过对多尺度特征的高效探索和自适应融合，使网络能灵活地学习到更丰富的上下文信息，进而高效增强图像质量。

（2）基于空间域和频率域混合的低质图像增强方法

针对单一域信息不全面导致模型特征表达能力受限的问题，提出一种基于空间域和频率域混合的低质图像增强方法。该方法主要提出一种混合域增强模块，其通过构建两个不同支路来同时整合空间域和频率域信息，形成更综合且强大的特征表达。对于空间域支路，通过采用 3 个携带不同空洞率的宽激活残差单元，以有效探索不同感受野下的信息，增强空间域特征。对于频率域支路，引入离散小波变换对特征进行频率分解并融合，以利用不同频率分量之间的依赖关系，提升特征对边缘等高频细节的敏感度。通过将混合域增强模块进行堆叠，可以得到最终混合域增强网络。实验证明，相比其他的方法，所提出的方法能实现更高的模型性能。

（3）基于双阶段增强的低质图像道路交通目标检测方法

针对道路交通场景下低质量图像因丢失细节纹理等重要信息导致目标检测精度低的问题，提出一种基于双阶段增强的低质图像道路交通目标检测方法。在第一阶段，构建了一个任务分解增强网络用以在检测器前对低质图像进行图像层增强。为降低多降质因素下图像增强的难度，该网络将总的图像增强任务分解成图像复原和分辨率增强两个子任务，并由两个分支来执行。为了有效利用两个子任务的相关性，采用递归方式来连接这两个分支，以提升增强图像的质量。值得指出的是，为了自适应增强不同尺寸目标特征而不引入较多计算负担，任务分解

中国知网 https://www.cnki.net

增强网络的核心特征提取器采用了第二章提出的多尺度特征选择模块。在第二阶段，提出一个辅助特征增强头以实现特征层面的增强。该模块主要通过跨注意力机制将低层增强特征与高层检测特征进行融合以弥补检测特征丢失的空间信息。其次，辅助特征增强头模块受 HR 图像特征先验驱动，有效细化了检测特征，提升了目标检测准确率。实验结果表明，与其他方法相比，所提出的方法能在模型性能、参数和计算负担之间取得较好的平衡。

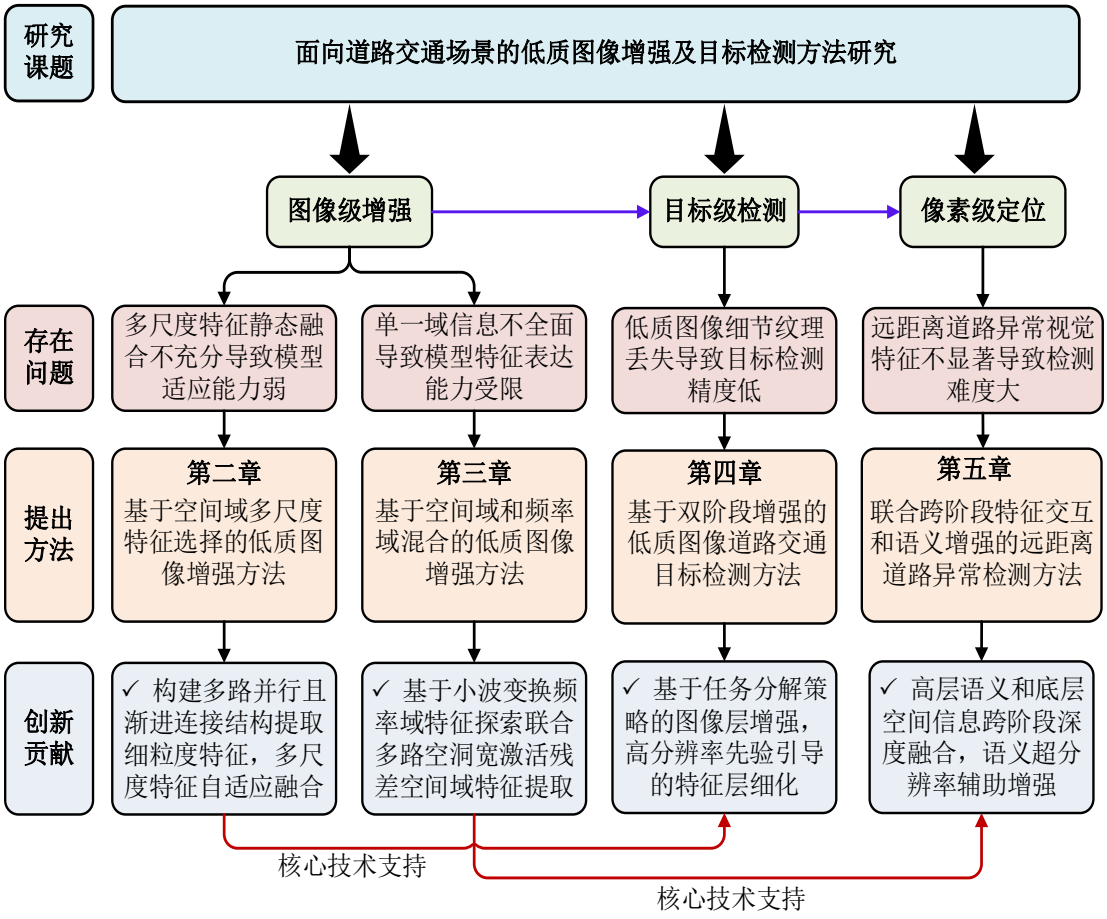


图 1-3 本文总体技术路线

（4）联合跨阶段特征交互和语义增强的远距离道路异常检测方法

针对远距离道路异常因视觉特征不显著导致检测难度大的问题，提出联合跨阶段特征交互和语义增强的远距离道路异常检测方法。首先，提出一个跨阶段特征交互颈部模块，通过采用双向特征交互机制来整合高层语义和低层空间信息，实现每个骨干特征的高效转换，从而有效捕捉异常与周围背景之间细微的差异并提升对小尺寸异常的感知能力。其次，为将两个相邻阶段特征进行深度融合，在双向特征交互机制中引入了一个多尺度注意力调制模块，用以探索两个输入特征之间的多尺度长距离依赖关系。最后，构建一个语义 SR 头模块，利用 HR 语义

中国知网 https://www.cnki.net

先验作为指导，用以提高初步预测图的分辨率，进一步提升小尺寸道路异常检测准确率。值得注意的是，为了更好地细化目标分割边缘，语义 SR 头模块主要由第三章提出的核心混合域增强模块构成。相比其他方法，所提方法能以最低的参数实现最好的模型性能。

1.5 论文结构和安排

本文共分为六章，各章节安排如下：

第一章为绪论。首先介绍了道路交通场景下低质图像增强及目标检测方法的背景和意义。然后，围绕低质图像质量增强和目标检测关键技术对国内外研究现状进行了介绍和分析。最后，列出了本课题研究面临的挑战、论文主要研究内容以及创新点。

第二章提出了一种基于空间域多尺度特征选择的低质图像增强方法。首先，提出了一种设计良好的多尺度特征选择模块，并将其多次堆叠构成总体网络；然后，为实现细粒度多尺度特征的学习，多尺度特征选择模块主要采用多路渐进连接的方式来构建；其次，开发了一种尺度选择模块，通过综合通道注意力机制来自适应挑选并融合包含不同尺度信息的两个相邻分支特征；最后，通过实验证明了所提方法的优越性。

第三章提出了一种基于空间域和频率域混合的低质图像增强方法。该章节主要设计了一种混合域增强模块，并将其作为总体网络的基础构建模块。该模块综合利用了空间域和频率域的信息，有效增强了特征表达能力。其中，针对空间域特征增强，采用携带不同空洞率的多路宽激活残差单元来从不同感受野范围中提取丰富的上下文信息。针对频率域特征增强，通过使用离散小波变换实现多频分解，并进行高—低频信息融合，有效提升了模型对高频细节重建的能力。实验结果充分验证了所提方法的有效性。

第四章提出了一种基于双阶段增强的低质图像道路交通目标检测方法。首先，提出了一种任务分解增强子网络，其主要通过将总体增强任务分解成图像复原和分辨率增强两个子任务并渐进地执行，来达到降低多降质条件下图像重建难度的目的。其中，在两个子任务分支之间构建共享特征提取器以有效利用它们之间的依赖关系。所提到的共享特征提取器主要由第二章方法核心部件多尺度特征选择模块来构建；其次，提出一个辅助特征增强头，采用跨注意力机制来有效融合增强网络中的增强特征和检测器中的检测特征，并辅以 HR 图像特征先验引导，从而提升模型检测精度；最后，经实验证明，所提出的方法仅引入较低的参数和计算复杂度就能实现最优的检测性能。

第五章提出了一种联合跨阶段特征交互和语义增强的远距离道路异常检测

中国知网 https://www.cnki.net

方法。首先，该方法提出了一种跨阶段特征感知颈部模块，通过利用相邻两个阶段骨干特征的互补性，实现高效的特征转换。其次，为了有效融合不同阶段特征，提出一种双向特征融合模块。该模块利用多尺度跨阶段注意力机制来探索两个输入特征之间的相关性，从而进行多方位深度融合；再次，为了有效利用 HR 语义信息作为指导的同时，不引入太大的计算量和参数量，提出一个主要由第三章方法核心部件混合域增强模块组成的语义 SR 头模块来对初步预测图进一步 SR 增强，以提升最终检测准确率；最后，经实验证明，相较于其他方法，所提出的方法在模型性能、参数、计算复杂度以及推理时间之间实现更好的平衡。

第六章为总结与展望。通过回顾全文的研究工作，对本文提出的 4 个方法进行总结，认真思考所提方法中存在的局限性，最后对本研究的改进做出设想。

中国知网 https://www.cnki.net

第 2 章 基于空间域多尺度特征选择的低质图像增强

2.1 引言

图像作为人类感知世界与传递信息的重要媒介，在道路交通场景中的作用尤为关键。无论是后台监控人员进行实时路况监测，还是自动驾驶系统依赖图像感知完成导航与决策，图像的清晰度和精确性都是保障这些应用高效运行的基础。然而，受限于实际采集环境中的多种干扰因素，获取的图像常常存在分辨率低等质量问题。这不仅严重影响人眼的视觉体验，也难以满足复杂目标检测等后续任务对图像质量的高要求。为应对上述挑战，图像 SR 技术为提升图像质量提供了一种可行的解决思路。

图像 SR 方法主要分为传统方法和基于深度学习的方法两类。由于前者是基于手工设计的先验或者模型，导致其图像重建效果和鲁棒性都较差，难以被广泛应用。随着大数据时代的到来，后者逐渐成为了主流。起初，研究者们仅设计一些简单的网络来执行 SR 重建任务，如 SRCNN[12]、FSRCN[27]和 ESPCN[125]，但这些网络的性能容易受它们本身固有浅层结构的限制。为了实现更好的 SR 性能，研究人员探索了更深、更广的网络设计，并取得了实质性的改进。然而，更深的网络架构容易遭遇梯度消失和爆炸问题，导致模型训练不稳定。为解决这些问题，众多 SR 方法引入残差学习[82]的思想，以改善梯度传播使模型训练更容易。残差学习的引入不仅促进更加复杂的网络设计，也显著提升了重建图像的质量。但在设计网络结构时，如何在提升输出结果质量的同时兼顾参数量和计算开销，对在资源有限的设备上应用 SR 技术尤为重要。为此，一些研究者开始致力于构建轻量级 SR 网络以应对性能与效率之间的平衡挑战。然而，大多数轻量级 SR 方法在设计多支路结构时，对于多尺度特征的探索并不充分，且往往采用静态方式如像素加操作或普通卷积来对所提取的多尺度特征进行融合，导致模型的适应性较弱，并不能很好地处理复杂场景如道路交通环境下的 LR 图像。

为解决上述问题，本章提出了一种轻量级多尺度特征选择网络（Multi-scale Feature Selection Network，MFSN）以高效执行图像增强任务。首先，为改善网络上下文感知能力，本章在 2.2.2 小节提出了一种精心设计的多尺度特征选择模块（Multi-scale Feature Selection Block，MFSB）。在 MFSB 中，输入特征经过 4 条并行且渐进连接的宽激活残差支路来产生细粒度的多尺度特征，以增强模型对不同尺寸目标特征的表达能力。其次，为有效融合相邻两个包含不同尺度信息的分支特征，本章在 2.2.3 小节提出了一个尺度选择模块（Scale Selection Module，SSM）。与大多数方法采用1×1 或3×3 卷积来线性融合多尺度特征不同，MFSN

中国知网 https://www.cnki.net

所采用的动态融合模块 SSM 能自适应选择不同尺度特征进行灵活组合，有效改善了模型的适应能力。最后，通过依次堆叠多个 MFSB，可以得到完整网络 MFSN，网络总体结构将会在本章 2.2.1 小节进行展示。

图 2-1 展示了各方法的峰值信噪比（Peak Signal-to-Noise Ratio，PSNR）值、参数数量和每秒浮点运算次数（FLoating point Operations Per second，FLOPs）的比较。其中，所有方法的 PSNR 值是在 4 倍上采样情况下对 Manga109[126]数据集进行计算得到；FLOPs 是假设输出的 SR 结果分辨率为1280×720 时计算得到；红色圆圈表示本章提出的方法 MFSN；圆圈越大表明网络耗费的参数越多。从图 2-1 中可以看到，在所有比较方法中，MFSN 以最低的 FLOPs 和模型参数量得到最高的 PSNR 值，充分展示了其高效性。

总的来说，本章主要创新点和贡献如下：

1） 提出一种有效的多尺度学习模块 MFSB，通过使用 4 个并行分支并采用渐进连接的策略，能使网络从粗到细的感受野层面逐步捕捉和融合多尺度信息，从而形成强大的特征表示能力。

2） 在 MFSB 中构建一个新颖的 SSM，通过动态组合可变的感受野，有效聚合来自两个相邻分支的多尺度特征。此外，SSM 中还集成了一个综合通道注意力机制（Comprehensive Channel Attention Mechanism，CCAM），通过综合利用全局和局部跨通道交互来学习准确的选择权重。

3） 经实验表明，相较于其他轻量级方法，由多个 MFSB 堆叠构建的 MFSN 能以最少的网络参数实现最好的模型性能。

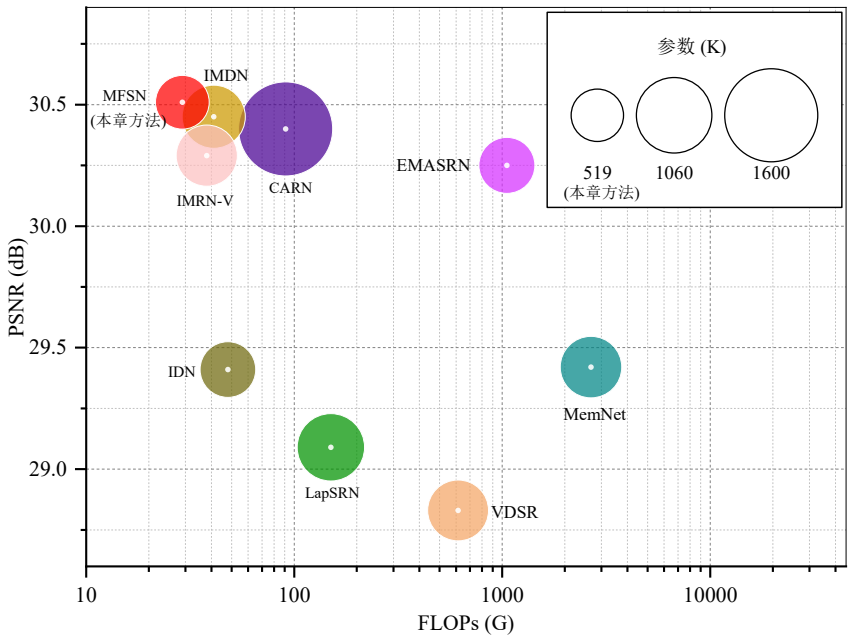


图 2-1 4 倍上采样情况下各方法在 Manga109 测试集上的 PSNR、参数和 FLOPs 比较

中国知网 https://www.cnki.net

2.2 基于空间域多尺度特征选择的低质图像增强方法

2.2.1 多尺度特征选择网络总体结构

现有大多基于深度学习的图像 SR 网络通常采用模块堆叠的架构：先设计具有某种功能的模块，然后通过多次堆叠该模块构成整体网络。这种堆叠架构具有以下几点好处：首先，通过堆叠模块，网络可以从输入 LR 图像中逐步提取到不同层次的特征（从简单边缘纹理特征到复杂语义特征），使其学习到丰富的细节信息，从而重建出清晰的 SR 图像。其次，堆叠结构灵活且可扩展能力强，其可以根据实际需求如提高精度或者速度，以进行模块的增加或者删减。此外，新的模块也便于插入到网络中，以实现某种特定功能，从而适应不同任务需求。最后，这种堆叠结构具有规整的特性，非常便于研究人员对网络的理解从而进行高效复现和改进。基于以上优势，本小节所提出的网络 MFSN 也采用模块堆叠的方式来构建，其主要核心是 MFSB。图 2-2 展示了 MFSN 详细的整体网络结构，其主要由三个阶段依次执行，分别为初始特征提取阶段、非线性特征映射阶段和图像重建阶段。

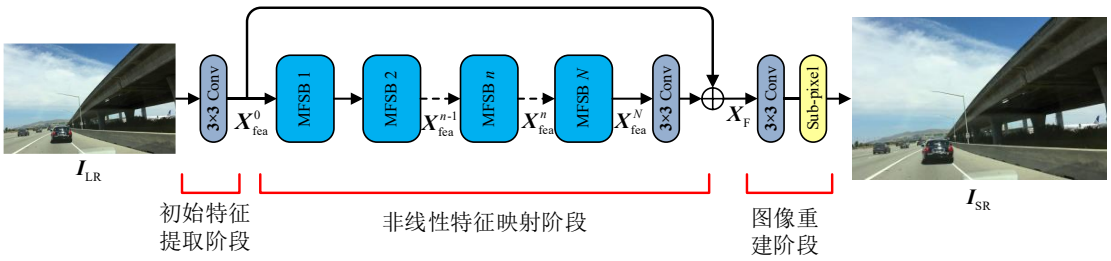


图 2-2 MFSN 的结构

初始特征提取阶段主要采用一个简单的3×3 卷积层从输入的 LR RGB 图像 $\boldsymbol{I}_{\mathrm{LR}} \in \mathbb{R}^{H\times W\times 3}$ 中提取初始特征 $\boldsymbol{X}^0_{\mathrm{fea}}$，其中的 H 和 W 分别为图像的高度和宽度。初始特征提取阶段的核心作用是将图像从像素域转换至特征域，为后续 LR 图像到 HR 图像的非线性映射学习提供更便于处理的特征表示。

特征非线性映射阶段是整个 MFSN 的核心部分，主要负责提取分层特征，并完成特征的逐步提炼。从图 2-2 中可见，MFSN 采用了 N 个 MFSB 对 $\boldsymbol{X}^0_{\mathrm{fea}}$ 进行逐步特征细化。假定 $\boldsymbol{X}^n_{\mathrm{fea}}$ 为第 n 个 MFSB 的输出特征，则其可以通过以下公式得到：

$$\boldsymbol{X}^n_{\mathrm{fea}} = \mathcal{F}^n_{\mathrm{MFSB}}\left(\boldsymbol{X}^{n-1}_{\mathrm{fea}}\right) = \mathcal{F}^n_{\mathrm{MFSB}}\left(\mathcal{F}^{n-1}_{\mathrm{MFSB}}\left(\cdots\right)\mathcal{F}^1_{\mathrm{MFSB}}\left(\boldsymbol{X}^0_{\mathrm{fea}}\right)\right) \tag{2-1}$$

式中，$\mathcal{F}^n_{\mathrm{MFSB}}(\cdot)$ 表示第 n 个 MFSB 函数。在非线性特征映射阶段结尾部分，初始特征 $\boldsymbol{X}^0_{\mathrm{fea}}$ 经跳跃连接传输后与经 N 个 MFSB 提炼后的残差特征进行逐像素相加，

中国知网　https://www.cnki.net

进而产生最终细化特征 $\boldsymbol{X}_{\mathrm{F}}$。这个过程可以由如下公式表示：

$$\boldsymbol{X}_{\mathrm{F}}=\mathcal{F}_{\mathrm{Res}}\left(\boldsymbol{X}_{\mathrm{fea}}^{N}\right)+\boldsymbol{X}_{\mathrm{fea}}^{0} \tag{2-2}$$

式中，$\boldsymbol{X}_{\mathrm{fea}}^{N}$ 表示第 N 个 MFSB 的输出特征；$\mathcal{F}_{\mathrm{Res}}(\cdot)$ 是表示一个3×3 卷积函数，主要负责从 $\boldsymbol{X}_{\mathrm{fea}}^{N}$ 中提取精炼后的残差特征。

图像重建阶段负责将特征域转换回图像域，为实现这一目的，采用上采样模块将 $\boldsymbol{X}_{\mathrm{F}}$ 映射到 HR 空间，以得到最终 SR 图像 $\boldsymbol{I}_{\mathrm{SR}}\in\mathbb{R}^{sH\times sW\times 3}$，其中 s 为上采样倍数。这个过程可以由以下式子表示：

$$\boldsymbol{I}_{\mathrm{SR}}=\mathcal{F}_{\mathrm{U}}\left(\boldsymbol{X}_{\mathrm{F}}\right) \tag{2-3}$$

其中，$\mathcal{F}_{\mathrm{U}}(\cdot)$ 定义为子像素卷积函数，其由一个卷积核为3×3 的卷积层和像素洗牌层[125]来实现。

根据文献[15]所提到的采用 L2 损失函数训练模型容易使重建图像过于平滑，对锐利边缘的恢复并不友好。因此，本章在 MFSN 模型训练过程中，采用的是 L1 损失函数。假定 $\boldsymbol{I}_{\mathrm{HR}}^{j}$ 和 $\boldsymbol{I}_{\mathrm{LR}}^{j}$ 分别表示第 j 个 HR 图像和对应的 LR 图像，则 MFSN 的目标损失函数 $\mathcal{L}_{\mathrm{MFSN}}$ 可以由如下公式表示：

$$\mathcal{L}_{\mathrm{MFSN}}=\frac{1}{\mathcal{B}}\sum_{j=1}^{\mathcal{B}}\left\|\mathcal{F}_{\mathrm{MFSN}}(\boldsymbol{I}_{\mathrm{LR}}^{j})-\boldsymbol{I}_{\mathrm{HR}}^{j}\right\|_{1} \tag{2-4}$$

其中，$\mathcal{F}_{\mathrm{MFSN}}(\cdot)$ 为 MFSN 函数；$\mathcal{B}$ 和 $\|\cdot\|_{1}$ 分别为批次大小（Batch Size）和 L1 范数。

2.2.2 基于多尺度特征选择的空间域增强模块

在图像 SR 任务中，不同尺度特征包含不同层次的细节信息，如小尺度特征侧重于表征图像中的局部细节，而大尺度特征更关注图像的整体结构。通过学习不同尺度的特征，能使网络更综合地关注图像中不同层次的信息，从而更好地恢复图像细节纹理。因此，在图像 SR 领域，设计有效的多尺度特征提取模块是提升模型性能常用的一种手段。现有大多 SR 方法仅采用简单的多支路结构辅以不同核大小的卷积以实现多尺度特征的提取。这种多支路结构虽然能一定程度提升网络对不同尺寸特征的感知能力，但其中每条支路仅能单独处理一种尺度信息，而缺乏细粒度多尺度特征探索能力。

为解决以上问题，在本小节中，提出了一个新颖的多尺度特征学习模块名为 MFSB，其具体结构展示在图 2-3 中。其中，“Slice”和“Concat”分别表示特征通道切分和特征通道级联操作；⊕ 表示像素加操作；“1×1 Conv”和“3×3 Conv”分别为1×1 和3×3 卷积层。MFSB 主要由 2 个1×1 卷积层和 4 条并行支路构成，其中 3 条支路采用了宽激活残差单元。不同于传统多支路结构各支路之间相互独立而缺乏信息交互，MFSB 采用渐进连接方式整合不同支路中不同尺度的特征，

中国知网 https://www.cnki.net

以便捕捉丰富且细粒度的信息。MFSB 的总体结构可由以下公式表示：

$$\boldsymbol{X}_{\mathrm{fea}}^{n}=\mathcal{F}_{\mathrm{R}}\left(\mathcal{F}_{\mathrm{B}}\left(\mathcal{F}_{\mathrm{E}}\left(\boldsymbol{X}_{\mathrm{fea}}^{n-1}\right)\right)\right)+\boldsymbol{X}_{\mathrm{fea}}^{n-1} \tag{2-5}$$

其中，$\boldsymbol{X}_{\mathrm{fea}}^{n-1}$和$\boldsymbol{X}_{\mathrm{fea}}^{n}$分别为第$n$个 MFSB 的输入和输出特征；$\mathcal{F}_{\mathrm{E}}(\cdot)$和$\mathcal{F}_{\mathrm{R}}(\cdot)$分别为特征扩展和收缩函数，其缩放功能由 1 个1×1卷积层实现；$\mathcal{F}_{\mathrm{B}}(\cdot)$表示多尺度特征提取主体函数，主要由 3 个宽激活残差单元和 2 个 SSM 组成。文献[127]有提到过，在激活层前扩张特征的通道维度，有利于改善网络的非线性能力。因此，在 MFSB 的头部和尾部，分别采用$\mathcal{F}_{\mathrm{E}}(\cdot)$和$\mathcal{F}_{\mathrm{R}}(\cdot)$来实现特征的扩张和收缩。此外，大多数方法提出的多支路结构通常将输入特征复制多份再分别传输到每一条支路中。这意味着每条支路在对同样输入进行特征提取时，会存在大量冗余计算，从而增加模型训练和推理时间成本。此外，这种方式还会引入大量不必要的参数进行卷积运算，阻碍了网络的进一步轻量化。考虑到这些问题，在 MFSB 中，采用了特征切分—细化—级联策略。首先，对经 MFSB 头部1×1卷积层扩张后的特征，沿其通道维度等分切割。然后，将切分后的每组子特征分别输入到不同支路以进一步处理。最后，在多支路特征输入到 MFSB 尾部1×1卷积层进行融合前，将这些特征沿通道维度级联，以保证最终特征信息的完整。通过使用特征切分—细化—级联策略，MFSB 能提取丰富多尺度特征的同时，有效降低模型的参数量和计算复杂度。

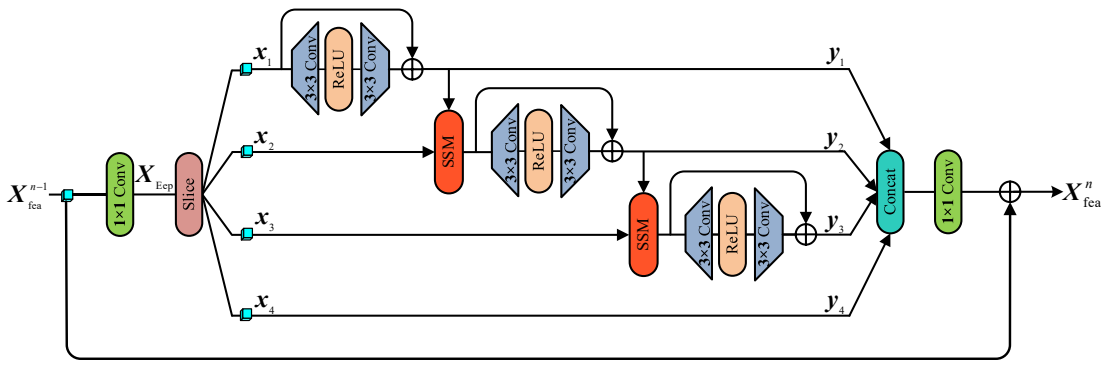


图 2-3 MFSB 的结构

假设$\boldsymbol{X}_{\mathrm{fea}}^{n-1}$的通道维度为$V_{\mathrm{O}}$，并定义扩张后的特征为$\boldsymbol{X}_{\mathrm{Exp}}$。通过应用头部1×1卷积层可以将$\boldsymbol{X}_{\mathrm{fea}}^{n-1}$的通道维度从$V_{\mathrm{O}}$扩大到$V_{\mathrm{Exp}}$。与该操作相反，尾部1×1卷积层则是将级联后特征的通道维度从V_{Exp}缩小回V_{O}。如图 2-3 所示，在头部1×1卷积层后，$\boldsymbol{X}_{\mathrm{Exp}}$被切分成 4 组子特征$\boldsymbol{x}_1$、$\boldsymbol{x}_2$、$\boldsymbol{x}_3$和$\boldsymbol{x}_4$，再分别传递到 4 条支路中。另一方面，尾部1×1卷积层的输入特征则由 4 组包含不同尺度信息的特征$\boldsymbol{y}_1$、$\boldsymbol{y}_2$、$\boldsymbol{y}_3$和$\boldsymbol{y}_4$通过级联操作后得到。因此，头部1×1卷积层可以隐式地学习如何将每条支路所需的特征进行打包，而尾部1×1卷积层则可以通过通道层面的特征聚集将

中国知网 https://www.cnki.net

来自不同支路的多尺度信息进行融合和压缩。$\boldsymbol{y}_i$ 表示 MFSB 中的第 i 条支路的输出特征，其可以由以下公式表示：

$$\boldsymbol{y}_i=\begin{cases}\mathcal{F}_{\mathrm{WDSR}}^{i}\left(\boldsymbol{x}_i\right) & i=1\\ \mathcal{F}_{\mathrm{WDSR}}^{i}\left(\mathcal{F}_{\mathrm{SSM}}\left(\boldsymbol{x}_i,\boldsymbol{y}_{i-1}\right)\right) & 2\le i<\rho\\ \boldsymbol{x}_i & i=\rho\end{cases} \tag{2-6}$$

其中 ρ 表示 MFSB 包含的支路数量，在本章中，ρ 默认设置为 4；$\mathcal{F}_{\mathrm{WDSR}}^{i}\left(\cdot\right)$ 表示第 i 条支路上的宽激活残差单元函数，主要负责特征提炼；$\mathcal{F}_{\mathrm{SSM}}\left(\cdot\right)$ 表示尺度特征挑选函数，主要用于对不同尺度特征进行自适应组合；$\boldsymbol{x}_i$ 表示 MFSB 中第 i 条支路的输入特征。由于 $\boldsymbol{x}_i$ 是由 $\boldsymbol{X}_{\mathrm{Exp}}$ 通过等分切割而产生的，因此 $\boldsymbol{x}_i$（$1\le i\le\rho$）具有相同的特征维度，都为 $H\times W\times V_{\mathrm{Exp}}/\rho$。

传统多支路结构通常引入大核卷积如5×5和7×7卷积来得到大的感受野范围，导致计算负担和参数量急剧增加。此外，这种结构中的各支路单独处理一种尺度信息且支路之间互不干扰，网络仅能在固定的感受野范围上进行感知，从而缺乏足够的模型适应能力。因此，为了更高效地学习多尺度信息，本小节设计了 4 条并行且渐进连接的支路，并将其作为 MFSB 的主体部分。不同于传统多支路结构，MFSB 仅由直连操作和大量小核卷积如1×1和3×3卷积构成，从而保证网络具有足够低的参数量和计算复杂度。在 MFSB 的主体部分，为改善特征的非线性表达能力，每条支路采用一个宽激活残差单元 $\mathcal{F}_{\mathrm{WDSR}}^{i}\left(\cdot\right)$ 来执行特征细化。该单元由 2 个3×3卷积、1 个 ReLU 激活层以及 1 个跳跃连接构成。为进一步降低网络参数的同时增加尺度信息，在第四条路（图 2-3 中从上往下数）中并没有采用宽激活残差单元，而是使用直连操作来处理。另一方面，在 MFSB 中采用渐进连接方式聚集不同支路特征来扩大感受野范围，而不是采用大核卷积。这种策略能使网络从粗到细感受野层面产生细粒度多尺度特征。如图 2-3 所示，若只是将每组特征 $\boldsymbol{x}_i$ 分别输入到每个 $\mathcal{F}_{\mathrm{WDSR}}^{i}\left(\cdot\right)$ 进行处理，得到的输出特征虽然具有比输入更大的感受野，但每条支路仅仅只包含一种尺度信息。因此，为产生更丰富的多尺度特征，在应用 $\mathcal{F}_{\mathrm{WDSR}}^{i}\left(\cdot\right)$ 对特征细化前，先采用精心设计的 SSM 来将上条支路的输出特征 $\boldsymbol{y}_{i-1}$ 和当前支路的输入特征 $\boldsymbol{x}_i$ 进行融合。通过使用这种方式，每个 $\mathcal{F}_{\mathrm{WDSR}}^{i}\left(\cdot\right)$ 能隐式地接收所有输入特征 $\{x_m, m\le i\}$ 的信息，从而得到具有细粒度感受野的组合特征。

图2-4展示了传统多支路结构和本小节所提出的多支路结构的感受野范围比较。其中，“DC”表示直连操作；黑色和蓝色箭头分别表示特征流和感受野流；“Fuse”表示融合操作或者模块，如像素加操作或者本章提出的 SSM；“1×1 Conv”、“3×3 Conv”、“5×5 Conv”和“7×7 Conv”分别表示1×1、3×3、5×5和7×7卷积层。为了方便展示，图 2-4 中右侧的每条支路采用3×3卷积来代

中国知网 https://www.cnki.net

替原来的宽激活残差单元。从图 2-4 的左侧部分可以发现，传统多支路结构采用 1 个直连操作和 3 个携带不同卷积核的卷积层对输入特征分别进行处理。由于每条支路是相互独立的，因此这种结构仅能得到具有1×1 、 3×3 、 5×5 和 7×7 的 4 种固定大小感受野的输出特征。相反，在图 2-4 的右侧，本章所提出的多支路结构通过使用“Fuse”模块来渐进连接相邻且包含有不同感受野特征的两条支路（除第一条支路外），所得到的输出特征会因此具有多种感受野，呈现出细粒度特性。得益于这种组合效应，特征提取过程中容易产生大量等同尺度的信息（如图 2-4 中红色箭头所示），从而为网络提供丰富的特征表示。值得注意的是，通过使用这种渐进连接策略，所提出的多支路结构仅使用 3 个3×3 卷积就可以达到传统多支路结构采用 1 个7×7 卷积所能实现的感受野。值得一提的是，前者所消耗的参数远小于后者，且前者所产生的感受野更具细粒度。因此，有理由也有必要在 MFSB 中引入渐进连接策略来高效学习多尺度特征表示。

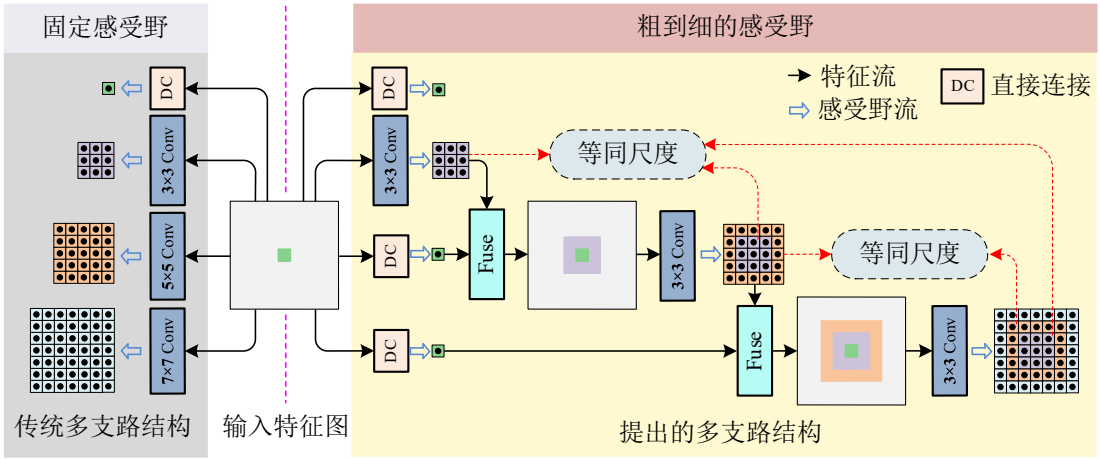


图 2-4 不同多支路结构的感受野表示

2.2.3 基于综合通道注意力机制的尺度选择模块

在多尺度特征提取后，一个关键处理步骤在于如何有效融合它们。有效的多尺度特征融合方式，一方面能帮助网络综合利用不同层次的信息来全面描述图像内容，提升特征的表达能力。另一方面，能增强模型对多样化输入的适应性，使其在处理复杂场景图像时表现更为稳健。然而，目前大多数 SR 方法采用静态且线性的方式如像素加或通道级联操作来融合多尺度特征[128]。正如文献[129]中所报告的，这类多尺度特征线性融合方法简单粗暴，其所提供的网络适应能力非常有限。

在生物学中，视觉皮层神经元有一种能够根据刺激调节感受野的能力[129]。受该机制的启发，通过类比可以发现，在 CNN 领域中，输入的多尺度特征可以

中国知网 https://www.cnki.net

视作是外部刺激，而特征融合函数则视作可以根据受到的刺激来动态调整感受野的视觉皮层神经元。基于这个原理，在 MFSB 中，引入了一个非线性的动态特征聚合模块 SSM，它能通过利用综合通道注意力机制来自适应学习不同的选择权重，进而有效融合来自不同分支的多尺度信息。图 2-5 展示了 SSM 的具体结构。其中，“GAP”表示全局平均池化操作；“R”为矩阵重塑操作；“⊗”为通道层面的乘法操作。如图 2-5 所示，SSM 主要通过三个步骤来实现，分别为多尺度特征聚合、综合通道注意力学习和多尺度特征挑选。

（1）多尺度特征聚合

作为 MFSB 中连接两条相邻支路的桥梁，SSM 自然接收到两组携带不同尺度信息的特征 $\tilde{\boldsymbol{M}} \in \mathbb{R}^{H\times W\times C}$ 和 $\hat{\boldsymbol{M}} \in \mathbb{R}^{H\times W\times C}$，其中，$C$ 表示特征的通道数量。为方便后续统计 $\tilde{\boldsymbol{M}}$ 和 $\hat{\boldsymbol{M}}$ 之间的相关性，采用像素层面的加操作来对它们进行初步融合，得到特征 $\boldsymbol{M}_{\text{sum}} \in \mathbb{R}^{H\times W\times C}$，这个过程可以由以下公式表示：

$$\boldsymbol{M}_{\text{sum}} = \tilde{\boldsymbol{M}} + \hat{\boldsymbol{M}} \tag{2-7}$$

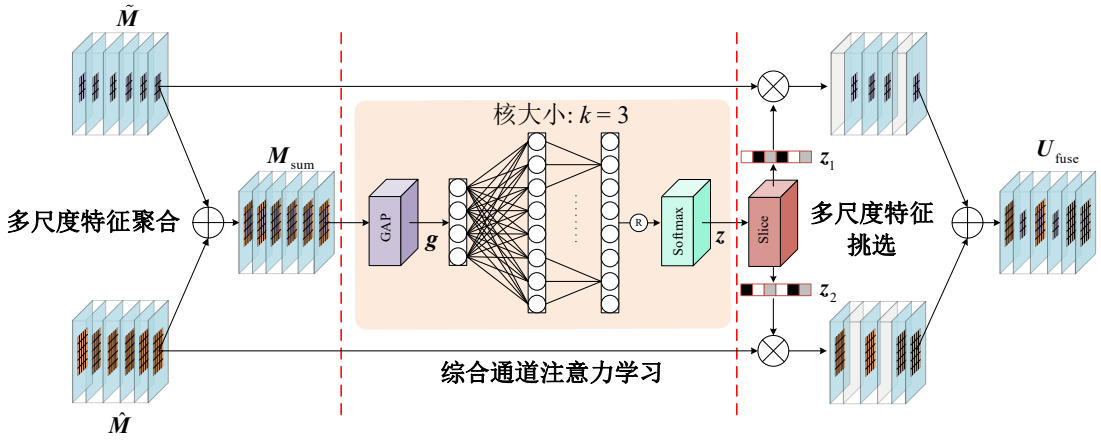


图 2-5 SSM 的结构

（2）综合通道注意力学习

为使不同尺度信息可以得到自适应的选择，关键步骤在于引入注意力机制来产生控制两条不同支路信息流的权重。通过动态加权的方式，能显式保留或者抑制不同支路特征的通道信息，以达到尺度选择的目的。然而，传统注意力模块如通道注意力（Channel Attention，CA）[130]只考虑特征通道之间的全局依赖，而忽略局部跨通道的交互，这使得后续所生成的选择权重并不足够准确。因此，本小节设计了一种新的注意力机制 CCAM，通过结合1×1 和 1D（Dimension）卷积来提取全局和局部注意力，以捕捉不同尺度特征之间更综合的通道信息。具体来说，首先，对 $\boldsymbol{M}_{\text{sum}}$ 进行 GAP 操作，以获得通道层面的初始权重 $\boldsymbol{g} \in \mathbb{R}^{1\times 1\times C}$。$\boldsymbol{g}$ 中

中国知网 https://www.cnki.net

的第c个通道特征由以下公式表示：

$$\boldsymbol{g}_c = \mathcal{F}_{\mathrm{GAP}}\left(\boldsymbol{M}_{\mathrm{sum}}^{c}\right)=\frac{1}{H\times W}\sum_{h=1}^{H}\sum_{w=1}^{W}\boldsymbol{M}_{\mathrm{sum}}^{c}\left(h,w\right) \tag{2-8}$$

其中$\mathcal{F}_{\mathrm{GAP}}\left(\cdot\right)$表示 GAP 函数；$\boldsymbol{M}_{\mathrm{sum}}^{c}\left(h,w\right)$为$\boldsymbol{M}_{\mathrm{sum}}$第 c 个通道特征图中坐标位置为$\left(h,w\right)$所对应的像素值。然后，为生成两个支路所对应的挑选权重，采用以下公式计算注意力信号$\boldsymbol{z}\in\mathbb{R}^{1\times1\times2C}$：

$$\boldsymbol{z}=\mathcal{F}_{\mathrm{CCAM}}\left(\boldsymbol{M}_{\mathrm{sum}}\right)=\mathcal{F}_{\sigma}\left(\mathcal{F}_{\mathrm{r}}\left(\mathcal{F}_{\mathrm{LA}}\left(\mathcal{F}_{\mathrm{relu}}\left(\mathcal{F}_{\mathrm{GA}}\left(\boldsymbol{g}\right)\right)\right)\right)\right) \tag{2-9}$$

其中，$\mathcal{F}_{\mathrm{CCAM}}\left(\cdot\right)$为综合通道注意力函数；$\mathcal{F}_{\mathrm{GA}}\left(\cdot\right)$和$\mathcal{F}_{\mathrm{LA}}\left(\cdot\right)$分别表示1×1卷积和卷积核大小为$k$的 1D 卷积函数，主要用于提取全局和局部注意力；$\mathcal{F}_{\mathrm{relu}}\left(\cdot\right)$和$\mathcal{F}_{\mathrm{r}}\left(\cdot\right)$分别为 ReLU 激活函数和矩阵重塑操作；$\mathcal{F}_{\sigma}\left(\cdot\right)$表示 Softmax 函数，用于对输出注意力信号归一化，使其在 0-1 范围内取值。

为避免引入额外超参数和特征通道维度降低所带来的副作用，在 CCAM 中仅利用一个1×1卷积层从全局的方式去捕捉通道间的依赖关系。通过使用这种方式，$F_{\mathrm{GA}}\left(\cdot\right)$输出的每个注意力元素能将$\boldsymbol{g}$的所有通道信息考虑在内。值得注意的是，1×1卷积受限于其结构并不能提供局部的通道信息，而 1D 卷积则可以通过卷积核在注意力信号上滑动的方式，学习到k个相邻通道之间的局部信息。此外，考虑到重复地应用1×1卷积层，难以为注意力计算提供新的知识，对于最终注意力值的预测益处非常有限。因此，为了更准确地计算注意力值，选择引入 1D 卷积来学习特征通道之间的局部交互。

（3）多尺度特征挑选

为得到最终选择权重，将经 CCAM 学习到的注意力信号$\boldsymbol{z}$切分成$\boldsymbol{z}_1\in\mathbb{R}^{1\times1\times C}$和$\boldsymbol{z}_2\in\mathbb{R}^{1\times1\times C}$并将其分别作用于$\tilde{\boldsymbol{M}}$和$\hat{\boldsymbol{M}}$以实现特征缩放。通过将两个缩放后的特征进行逐像素相加，得到最终融合特征$\boldsymbol{U}_{\mathrm{fuse}}\in\mathbb{R}^{1\times1\times C}$：

$$\boldsymbol{U}_{\mathrm{fuse}}=\boldsymbol{z}_1\otimes\tilde{\boldsymbol{M}}+\boldsymbol{z}_2\otimes\hat{\boldsymbol{M}} \tag{2-10}$$

式中，⊗表示通道层面的乘法操作。

与简单的线性特征融合策略相比，所提出的 SSM 能通过注意力机制自适应地选择不同尺度特征进行融合，从而获得更好的特征表达能力。尺度特征选择机制主要是挑选特征的感受野，其实现过程如图 2-5 所示。其中，黑色、白色和灰色的格子分别定义为选择权重值为 1.0、0.0 和 0.5。假定输入特征$\tilde{\boldsymbol{M}}$和$\hat{\boldsymbol{M}}$分别包含 1 个3×3和 1 个5×5感受野。从图 2-5 中可以发现，多尺度特征聚合步骤本质上是一种线性融合过程，融合后的特征$\boldsymbol{M}_{\mathrm{sum}}$中所有通道都具有固定且相同的感受野组合，包括 1 个3×3和 1 个5×5。这种现象表明了线性融合策略，仅能对不同尺度特征进行简单组合，难以根据不同输入特征的特性做出有效的适应。不

中国知网 https://www.cnki.net

同于线性融合方式，SSM 在完成 CCAM 步骤后，每条支路中不同通道的3×3 或者5×5 感受野能通过加权的方式被选择性地保留下来。最终，通过融合从两个分支中选取的尺度特征，$\boldsymbol{U}_{\text{fuse}}$ 中每个通道都能获得合适的感受野组合，显然提供了一种更灵活的特征描述方式。基于对感受野大小的自适应选择，MFSB 可捕捉重要但容易被忽略的特征，这有利于模型更好地恢复图像的全局结构和局部细节。

2.3 实验结果与分析

2.3.1 数据集

（1）训练集

DIV2K 数据集[131]是一个专为 SR 任务构建的公开高质量数据集，其全称为 Diverse 2K Resolution High Quality Images。DIV2K 由 1000 幅 2K 分辨率的图像组成，其中包括用作训练集的 800 幅图像、作为验证集的 100 幅图像以及作为测试集的 100 幅图像。这些图像涵盖了各种场景，包括人物和建筑等，具有丰富的细节和多样的纹理。本章采用 DIV2K 训练集来训练所提出的 MFSN。

（2）测试集

本章对不同模型性能的评估采用 5 个公开的基准图像数据集 Set5[132]、Set14[133]、BSD100[134]、Urban100[135]和 Manga109[126]作为测试集。Set5 数据集是一个经典的用于快速实验和测试的图像 SR 测试集，其仅有 5 张图像；Set14 数据集包含 14 幅图像，内容涵盖人物和动物等，图像具有一定的复杂性和多样性；BSD100 数据集源于伯克利分割数据集（Berkeley Segmentation Dataset），包含 100 幅具有丰富的自然纹理和细节的图像；Urban100 数据集是专门针对城市场景的图像 SR 测试集，由 100 幅 2K 高分辨率的各种城市景观图像构成，包括建筑物和街道等。通过以该数据集作为测试集，能有效衡量模型对城市环境中复杂结构和纹理特征的处理能力；Manga109 是一个包含 109 幅高质量图像的数据集，其所包含的图像的线条和色彩具有较高对比度，因此对图像增强算法的性能有一定的要求。

为验证本章所提出的方法 MFSN 在实际道路交通场景中应用的有效性，本章选用自动驾驶数据集 BDD100K（Berkeley Deep Drive 100K）[137]作为算法主观结果展示的图像来源。BDD100K 是由加州大学伯克利分校 AI 实验室于 2018 年发布的数据集，旨在推动自动驾驶和计算机视觉领域的研究。BDD100K 包含 10 万张图像，涵盖了不同天气情况（如晴天、阴天、雨天等）、场景（如城市街道和高速公路等）和时间段（如白天和夜晚等）。图像内容非常丰富且部分场景较为复杂，其中物体尺度变化范围较大，非常考验图像 SR 算法的重建能力。图 2-6 展示了 BDD100K 数据集中的一部分示例图像。

中国知网 https://www.cnki.net

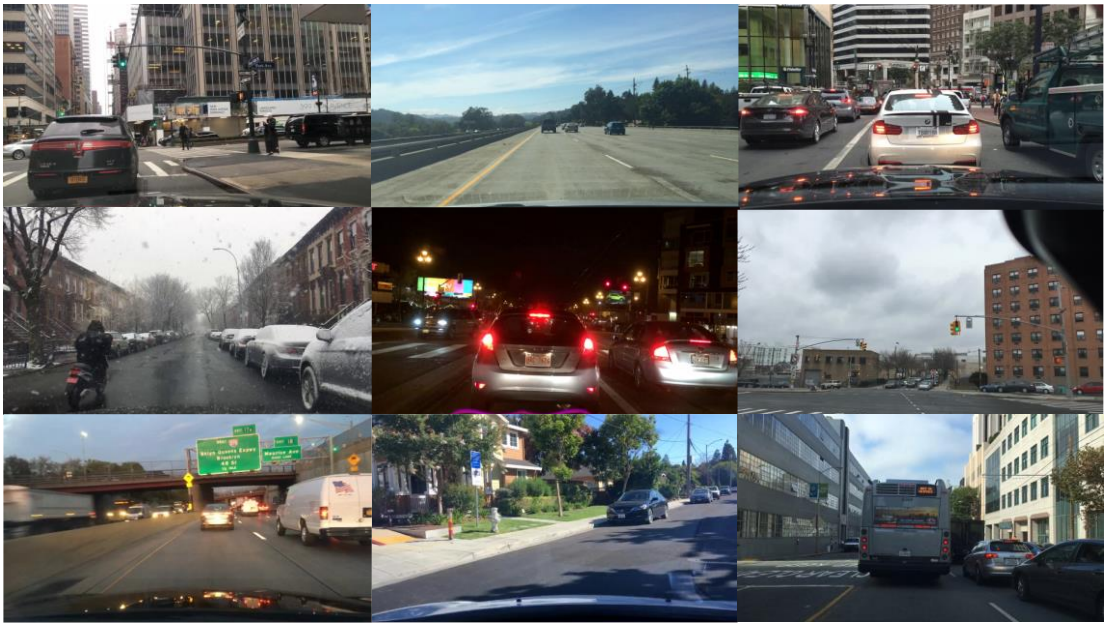


图 2-6 BDD100K 数据集部分示例图

2.3.2 实验设置

（1）实验环境和数据预处理

为保证实验公平，本章所有实验都基于 Pytorch 框架，所有训练和测试的结果都是在 Ubuntu 18.04 的操作系统上和搭载 32G 内存、NVIDIA GTX 1080Ti GPU 的硬件环境上得到的。对于数据集的处理，由于以上提到的数据集图像都为原始 HR 图像，因此，为生成尺度因子分别为 3 和 4 的 LR 图像，本章采用 Bicubic 操作对上述 HR 图像进行下采样。在训练过程中，选取 16 幅图像作为一个批次，且对其中每幅图像随机裁剪以得到 48×48 大小的 LR 彩色图像。此外，采用如随机旋转和翻转等操作对训练图像进行数据增强以提升模型泛化能力。在测试阶段，不同模型直接采用经不同尺度因子下采样得到的 LR 图像作为输入进行测试。

（2）MFSN 超参数设置

在训练本章所提出的 MFSN 时，MFSB 堆叠数 N 设置为 14；为避免引入大量网络参数和计算复杂度，在每个 MFSB 中，输入特征通道维度 V_{O} 选为 32 而不是常用的 64；MFSB 中通道扩展维度 V_{Exp} 和支路数量 ρ 分别设为 48 和 4；宽激活残差单元中的扩展因子固定为 4；CCAM 中的 1D 卷积核大小 k 选为 3。

（3）模型训练细节

采用 ADAM 作为优化器并将其中关键参数设定为 $\beta_1=0.9$、$\beta_2=0.999$ 和 $\varepsilon=10^{-8}$ 以进行模型训练。网络所有参数初始化采用的是 Pytorch 默认初始化方式。由于 MFSN 加入了权重归一化（Weight Normalization，WN）[136]，训练模

中国知网 https://www.cnki.net

型需要采用一个较高的学习率，因此，本章将学习率设置为10^{-3}。训练期间总的轮次（Epoch）数设为 500，且每经过 200 个轮次，将学习率降低为原来的一半。

2.3.3 评价指标

在客观评价方面，与大多数 SR 方法一致，采用 PSNR 和结构相似性指数（Structural Similarity Index Measure，SSIM）来对不同模型输出的 SR 图像在亮度通道上的质量进行评估。

（1）PSNR 指标

PSNR 最初定义为信号最大可能功率与影响其精度的破坏性噪声功率的比值，其单位为分贝（dB）。当 PSNR 作为评估图像像素误差的客观指标时，其是基于真实图像和复原图像之间的均方误差（Mean Square Error，MSE）进行计算，可由如下公式计算得到：

$$\mathrm{PSNR}=10\times\log_{10}\left(\frac{\left(2^{t}-1\right)^{2}}{\mathrm{MSE}}\right) \tag{2-11}$$

式中，t表示每个采样值的比特数，如果对于 8 位图像，则$2^{t}-1$的值为 255；假设$\boldsymbol{I}_{\mathrm{SR}}$和$\boldsymbol{I}_{\mathrm{HR}}$分别为 SR 图像和原始 HR 图像，则 MSE 可由如下公式计算得到：

$$\mathrm{MSE}=\frac{1}{H\times W}\sum_{h=1}^{H}\sum_{w=1}^{W}\left(\boldsymbol{I}_{\mathrm{SR}}\left(h,w\right)-\boldsymbol{I}_{\mathrm{HR}}\left(h,w\right)\right)^{2} \tag{2-12}$$

式中，$\boldsymbol{I}_{\mathrm{SR}}\left(h,w\right)$和$\boldsymbol{I}_{\mathrm{HR}}\left(h,w\right)$分别为 SR 和 HR 图像在$\left(h,w\right)$位置上的像素值。总的来说，PSNR 值越高表明图像 SR 算法所重建图像的质量越高，与真实 HR 图像越接近。

（2）SSIM 指标

SSIM 是一种考虑了人类视觉系统特性的图像质量评价指标，主要从图像亮度、对比度以及结构三个方面来评估图像结构信息质量，从而衡量 SR 和 HR 图像的相似性。图像均值为图像所有像素值的平均值，反映了图像的平均亮度水平，因此图像亮度对比函数可由如下公式表示：

$$\mathcal{F}_{\mathrm{Luminance}}\left(\boldsymbol{I}_{\mathrm{SR}},\boldsymbol{I}_{\mathrm{HR}}\right)=\frac{\left(2\mu_{\mathrm{SR}}\mu_{\mathrm{HR}}+C_{1}\right)}{\left(\mu_{\mathrm{SR}}^{2}+\mu_{\mathrm{HR}}^{2}+C_{1}\right)} \tag{2-13}$$

式中，μ_{SR}和μ_{HR}分别是$\boldsymbol{I}_{\mathrm{SR}}$和$\boldsymbol{I}_{\mathrm{HR}}$的均值；$C_{1}$作为常数，通常定义为$C_{1}=K_{1}L$，主要用来避免出现分母为 0 的情况。其中，$K_{1}$是一个远小于 1 的常数；$L$表示图像像素值范围（例如 8 位图像时，$L=255$）。

标准差是用来衡量数据离散程度的统计量。在图像中，标准差描述的是各个

中国知网 https://www.cnki.net

像素值相对于整个图像均值的偏离程度。当图像标准差大的时候，表明图像中存在范围的像素值变化，反映的是图像对比度高，图像质量也就越好。因此，$\boldsymbol{I}_{\mathrm{SR}}$ 和 $\boldsymbol{I}_{\mathrm{HR}}$ 的对比度函数可以由以下公式表示：

$$\mathcal{F}_{\mathrm{Contrast}}\left(\boldsymbol{I}_{\mathrm{SR}},\boldsymbol{I}_{\mathrm{HR}}\right)=\frac{\left(2\sigma_{\mathrm{SR\text{-}HR}}+C_2\right)}{\left(\sigma_{\mathrm{SR}}^2+\sigma_{\mathrm{HR}}^2+C_2\right)} \tag{2-14}$$

式中 $\sigma_{\mathrm{SR\text{-}HR}}$ 是 $\boldsymbol{I}_{\mathrm{SR}}$ 和 $\boldsymbol{I}_{\mathrm{HR}}$ 之间的协方差，用来衡量它们之间的相关性；σ_{SR} 和 σ_{HR} 分别是 $\boldsymbol{I}_{\mathrm{SR}}$ 和 $\boldsymbol{I}_{\mathrm{HR}}$ 的标准差；C_2 为常数，定义为 $C_2=\left(K_2L\right)^2$，K_2 为远小于 1 的常数。

在得到图像的均值和标准差后，通过对图像进行归一化，能够突出图像的结构信息，同时去除图像亮度和对比度等因素的干扰。因此，$\boldsymbol{I}_{\mathrm{SR}}$ 和 $\boldsymbol{I}_{\mathrm{HR}}$ 的结构化信息可以分别由 $\left(\boldsymbol{I}_{\mathrm{SR}}-\mu_{\mathrm{SR}}\right)/\sigma_{\mathrm{SR}}$ 和 $\left(\boldsymbol{I}_{\mathrm{HR}}-\mu_{\mathrm{HR}}\right)/\sigma_{\mathrm{HR}}$ 表示。两幅图像的结构信息的相似度通常是通过计算它们之间结构信息的协方差来衡量。因此，图像结构相似度可由如下公式计算得到：

$$\mathcal{F}_{\mathrm{Structure}}\left(\boldsymbol{I}_{\mathrm{SR}},\boldsymbol{I}_{\mathrm{HR}}\right)=\frac{\left(\sigma_{\mathrm{SR\text{-}HR}}+C_3\right)}{\left(\sigma_{\mathrm{SR}}\sigma_{\mathrm{HR}}+C_3\right)} \tag{2-15}$$

式中，C_3 为常数，通常定义为 $C_3=C_2/2$。

通过综合图像亮度、对比度和结构信息，最终的 SSIM 可由以下公式计算：

$$\begin{aligned}\mathrm{SSIM}&=\mathcal{F}_{\mathrm{Luminance}}\left(\boldsymbol{I}_{\mathrm{SR}},\boldsymbol{I}_{\mathrm{HR}}\right)\mathcal{F}_{\mathrm{Contrast}}\left(\boldsymbol{I}_{\mathrm{SR}},\boldsymbol{I}_{\mathrm{HR}}\right)\mathcal{F}_{\mathrm{Structure}}\left(\boldsymbol{I}_{\mathrm{SR}},\boldsymbol{I}_{\mathrm{HR}}\right)\\&=\frac{\left(2\mu_{\mathrm{SR}}\mu_{\mathrm{HR}}+C_1\right)\left(2\sigma_{\mathrm{SR\text{-}HR}}+C_2\right)}{\left(\mu_{\mathrm{SR}}^2+\mu_{\mathrm{HR}}^2+C_1\right)\left(\sigma_{\mathrm{SR}}^2+\sigma_{\mathrm{HR}}^2+C_2\right)}\end{aligned} \tag{2-16}$$

SSIM 值在 $[0,1]$ 范围内，值越大表明复原图像与真实 HR 图像的相似度越高，图像 SR 算法的性能越好。

2.3.4 消融实验

在 MFSN 中，MFSB 模块作为核心构建单元，对整体模型的重建性能起着决定性作用，其超参数的设置以及所采用的多尺度特征融合策略都对最终效果有显著影响。因此，本小节在 4 倍上采样的情况下以 Set5 作为测试集进行了一系列实验，系统地验证了不同超参数配置和特征融合策略对模型性能的影响。所有网络的基本输入特征维度都设为 32。

（1）支路数 ρ 的影响

为研究不同支路数 ρ 对 MFSN 性能的影响，分别以 4 种具有不同支路数量结构的 MFSB 构建不同变种的 MFSN 来进行一系列实验。所得到的实验结果展示在表 2-1 中。其中，V_{Exp} 为扩展特征的通道数。为公平比较，随着 ρ 的改变，V_{Exp} 也会随之调整，以确保具有不同支路数的 MFSB 所构成网络的参数量相近。值

中国知网 https://www.cnki.net

得注意的是，所有情况下 MFSB 的最后一条支路都没有引入宽激活残差单元，而是只采用直连操作。当 ρ 为 2 时，因为仅有一条宽激活残差支路，所以并没有引入 SSM。至于在 $\rho=3$、$\rho=4$ 和 $\rho=5$ 的情况下，在 MFSB 中会分别设置 1 个、2 个和 3 个 SSM。从表 2-1 中可以得到以下结论：

1） 随着支路数的增加，网络所重建 SR 图像的 PSNR 值也逐步提升，说明了更多支路数给网络在特征提取过程中带来更大且更丰富的感受野，提升了模型特征表达能力。

2） 在 $\rho=4$ 的网络基础上额外添加一个分支后，网络引入 63 K 参数的同时并不能得到更高 PSNR 值。这原因可能在于当 $\rho=5$ 时，MFSN 的感受野范围过大，导致网络引入一些无效的信息或噪声，阻碍有用特征的表达，限制了模型性能的进一步提升。总的来说，当 $\rho=4$ 时，MFSN 能用最少的参数获得最佳模型性能。因此，有理由将支路数 ρ 设定为 4。

表 2-1 支路数 ρ 对模型性能的影响

支路数 ρ	2	3	4	5
V_{Exp}	46	48	48	55
参数（K）	604	598	519	582
PSNR（dB）	32.07	32.21	32.22	32.22

（2）1D 卷积核大小 k 的影响

1D 卷积核大小 k 决定了 CCAM 中用于提取局部跨通道交互依赖所需的相邻通道数。在保持 MFSB 其他超参数不变的情况下，本小节通过改变 k 来研究其对总体模型性能的影响，所有实验结果展示在表 2-2 中。

从表 2-2 中可以发现，当 k 从 3 逐渐增加到 9 时，PSNR 值从也从 32.22 dB 逐渐下降到 32.19 dB。值得注意的是，由于 1D 卷积核自身特性，其消耗的参数几乎可以忽略。得到以上结果可能归因于，当 k 设置为 3 时，特征通道间的局部相关性达到最大，有利于 CCAM 更好地实现跨通道的全面交互，改进不同尺度特征的选择能力，从而提升模型性能。因此，在本章中，统一将 1D 卷积核 k 固定为 3。

表 2-2 1D 卷积核 k 对模型性能的影响

核大小 k	3	5	7	9
参数（K）	519	519	520	520
PSNR（dB）	32.22	32.20	32.20	32.19

（3）不同多尺度特征融合策略的影响

多尺度特征融合作为 MFSB 实现特征有效表达的关键一环，研究其对模型性能的影响至关重要。表 2-3 展示了 MFSB 采用不同多尺度特征融合策略后所得

中国知网 https://www.cnki.net

到的实验结果。其中，基准网络主要有 14 个宽激活残差单元串联构成且没有使用多支路特征提取结构；网络“Sum”、“Concat”、“SSM（CA）”和“SSM”均主要由 14 个 MFSB 构建，值得注意的是，不同网络中的 MFSB 应用了不同的多尺度特征融合策略。网络“Sum”和“Concat”分别在 MFSB 中采用像素加和通道级联操作来实现特征融合。网络“SSM（CA）”表示在所采用的 MFSB 中的 SSM 是由传统 CA 驱动而不是所提出的 CCAM；网络“SSM”为完整版本的 MFSN。

从表 2-3 中可以得到如下结论：

1） 相较于基准网络，另外 4 种网络获得与其一样甚至比其更高的 PSNR 值，但这些网络的参数量只有基准网络的一半以下。以上结果表明了多支路结构搭配渐进连接策略，能通过探索细粒度多尺度特征高效改善模型的性能。

2） 与网络“Sum”和“Concat”相比，网络“SSM（CA）”在参数量相近的情况下获得了更高的 PSNR 值。结果表明 SSM（CA）所采用的注意力驱动的非线性动态融合策略比传统的静态线性融合策略更适合用来聚合多尺度特征。

3） 与网络“SSM（CA）”相比，网络“SSM”只增加了 1K 参数就能获得 0.04 dB 的性能增益。结果说明所提出的 CCAM 通过结合全局和局部跨通道交互，以更全面的角度捕捉通道之间的非线性关系，从而学习到更精准的选择权重，实现了有效的多尺度特征融合。

表 2-3 不同多尺度特征融合策略对模型性能的影响

融合策略	基准网络	Sum	Concat	SSM（CA）	SSM
参数（K）	1061	510	519	518	519
PSNR（dB）	32.11	32.11	32.12	32.18	32.22

2.3.5 与其他方法的比较

为验证本章所提方法 MFSN 的有效性，将 MFSN 与 8 个轻量级 SR 方法进行比较。比较方法包括 VDSR[13]、LapSRN[28]、MemNet[14]、IDN[37]、CARN[29]、IMDN[38]、IMRN-V[32]和 EMASRN[41]。为了公平地进行比较，本章将相关比较方法进行了重新训练。表 2-4 和表 2-5 分别展示了不同 SR 方法在采样率为 3 和 4 情况下对 5 个广泛采用的公开基准测试集 Set5[132]、Set14[133]、BSD100[134]、Urban100[135]和 Manga109[126]的定量比较结果。其中，PSNR 和 SSIM 用作评估指标；MFSN$^+$是指采用几何性自集成（Geometric Self-ensemble）策略进一步提高模型性能的 MFSN。

中国知网 https://www.cnki.net

表 2-4 采样率为 3 的情况下不同方法的平均 PSNR（dB）/ SSIM 定量比较

方法	Set5[132]	Set14[133]	BSD100[134]	Urban100[135]	Manga109[126]
VDSR[13]	33.66 / 0.9213	29.77 / 0.9213	28.82 / 0.7976	27.14 / 0.8279	32.01 / 0.9310
LapSRN[28]	33.82 / 0.9227	29.87 / 0.8320	28.82 / 0.7980	27.07 / 0.8280	32.21 / 0.9350
MemNet[14]	34.09 / 0.9248	30.01 / 0.8350	28.96 / 0.8001	27.56 / 0.8376	32.51 / 0.9369
IDN[37]	34.11 / 0.9253	29.99/ 0.8354	28.95 / 0.8013	27.42 / 0.8359	32.71 / 0.9381
CARN[29]	34.29 / 0.9255	30.29 / 0.8407	29.06 / 0.8034	28.06 / 0.8493	33.49 / 0.9440
IMDN[38]	34.36 / 0.9270	30.32 / 0.8417	29.09 / 0.8046	28.17 / 0.8519	33.61 / 0.9445
IMRN-V[32]	34.35 / 0.9268	30.23 / 0.8398	29.04 / 0.8037	28.04 / 0.8495	33.40 / 0.9430
EMASRN[41]	34.27 / 0.9260	30.24 / 0.8396	29.02 / 0.8029	27.96 / 0.8479	33.27 / 0.9425
MFSN	34.36 / 0.9272	30.32 / 0.8419	29.07 / 0.8048	28.17 / 0.8526	33.59 / 0.9447
MFSN$^+$	**34.47 / 0.9280**	**30.40 / 0.8429**	**29.13 / 0.8057**	**28.33 / 0.8552**	**33.88 / 0.9463**

表 2-5 采样率为 4 的情况下不同方法的平均 PSNR（dB）/ SSIM 定量比较

方法	Set5[132]	Set14[133]	BSD100[134]	Urban100[135]	Manga109[126]
VDSR[13]	31.35 / 0.8838	28.01 / 0.7674	27.29 / 0.7251	25.15 / 0.7524	28.83 / 0.8809
LapSRN[28]	31.54 / 0.8850	28.19 / 0.7720	27.32 / 0.7270	25.21 / 0.7560	29.09 / 0.8900
MemNet[14]	31.74 / 0.8893	28.26 / 0.7723	27.40 / 0.7281	25.50 / 0.7630	29.42 / 0.8942
IDN[37]	31.82 / 0.8903	28.25 / 0.7730	27.41 / 0.7297	25.41 / 0.7632	29.41 / 0.8942
CARN[29]	32.13 / 0.8937	28.60 / 0.7806	27.58 / 0.7349	26.07 / 0.7837	30.40 / 0.9082
IMDN[38]	32.21 / 0.8948	28.58 / 0.7811	27.56 / 0.7353	26.01 / 0.7838	30.45 / 0.9075
IMRN-V[32]	32.11 / 0.8939	28.52 / 0.7800	27.53 / 0.7344	25.98 / 0.7825	30.29 / 0.9054
EMASRN[41]	32.12 / 0.8934	28.54 / 0.7793	27.51 / 0.7330	25.91 / 0.7788	30.25 / 0.9051
MFSN	32.22 / 0.8950	28.56 / 0.7811	27.55 / 0.7356	26.05 / 0.7846	30.51 / 0.9088
MFSN$^+$	**32.35 / 0.8967**	**28.65 / 0.7829**	**27.61 / 0.7369**	**26.20 / 0.7882**	**30.80 / 0.9117**

从表 2-4 和表 2-5 中可以观察到，相比大多数 SR 方法，本章方法 MFSN 在所有测试集上能实现更好的结果。例如，在 4 倍上采样情况下，相较于 EMASRN，MFSN 在 Set5、Set14、BSD100、Urban100 和 Manga109 测试集上分别获得 0.10 dB、0.02 dB、0.04 dB、0.14 dB 和 0.26 dB 的 PSNR 值提升，而 SSIM 的提升值分别为 0.0016、0.0018、0.0026、0.0058 和 0.0037。得到以上结果的原因在于，MFSN 的核心模块 MFSB 通过采用有效的多路并行且渐进融合策略，从粗到细感受野层面上提取到丰富且细粒度的多尺度特征，并结合动态多尺度特征选择机制，重建出高质量 SR 图像。虽然 MFSN 在某些情况下轻微低于 IDN[37]和 IMDN[38]，但其具有明显更小的模型参数量和更低的计算复杂度（参数量和 FLOPs 详见表 2-6）。

2.3.6 模型参数、计算复杂度与运行时间分析

表 2-6 展示了在 4 倍上采样的情况下本章所提方法 MFSN 与其他 8 种轻量级 SR 方法的参数数量、FLOPs 和运行时间的比较结果。表 2-6 中所公布的 FLOPs

中国知网 https://www.cnki.net

和模型参数是在假定HR图像的空间分辨率为1280×720情况下，通过使用Python工具包 thop 计算所得。模型运行时间是在 BSD100[134]测试集上通过使用 1 张NVIDA GTX 1080Ti GPU 测量得到。

从表 2-6 中可以看到，VDSR[13]和 MemNet[14]虽然参数不多，但其 FLOPs 明显较高，主要是因为它们预先采用 Bicubic 操作对 LR 图像进行上采样再输入到网络中，导致模型计算复杂度急剧增加。此外，LapSRN[28]采用的渐进上采样的策略和 EMASRN[41]的递归学习方式，也致使它们的 FLOPs 较高。相较于 IDN[37]、CARN[29]、IMDN[38]和 IMRN-V[32]，虽然本章方法 MFSN 的运行速度相对较慢，但其网络参数量和 FLOPs 是最低的。得到该结果主要是因为 MFSN 所采用的多分支结构和渐进连接策略。

表 2-6 不同方法的参数量、FLOPs、运行时间和 PSNR 值比较

方法	参数（K）	FLOPs（G）	运行时间（s）
VDSR[13]	665	614	0.03
LapSRN[28]	813	150	0.01
MemNet[14]	677	2670	14.17
IDN[37]	553	48	0.01
CARN[29]	1592	91	0.01
IMDN[38]	715	41	0.01
IMRN-V[32]	669	38	0.02
EMASRN[41]	559	1054	0.09
MFSN（本章方法）	519	29	0.03

2.4 在道路交通场景中的应用

2.4.1 提升道路交通场景下低质图像的人眼视觉感知

在道路交通场景中，图像 SR 技术能提升前端摄像设备捕捉并传输过来的图像的分辨率，为负责远程监控等工作人员提供更清晰的图像信息，帮助他们更好地掌握现场情况并及时做出相应决策，从而提高远程监管的效率和准确性。因此，为评估所提出的 MFSN 的鲁棒性以及其在道路交通场景中应用的可行性，对自动驾驶数据集 BDD100K 中的图像进行了可视化结果对比实验。所对比的 SR 方法包括基于插值的方法 Bicubic 和基于 CNN 的方法。前者是经典且最简单常用的 SR 方法之一。后者包括 FSRCNN[27]、VDSR[13]、LapSRN[28]、IDN[37]、CARN[29]、IMDN[38]、IMRN-V[32]和 EMASRN[41]。图 2-7~图 2-10 展示了不同方法在 BDD100K 数据集图像上的主观结果比较。其中，图 2-7 和图 2-8 是在 3 倍上采样情况下的主观结果比较图，而图 2-9 和图 2-10 则是在 4 倍上采样率情况下的主观结果比较图。

中国知网 https://www.cnki.net



(a) Bicubic　　(b) FSRCNN　　(c) VDSR



(d) LapSRN　　(e) CARN　　(f) IMDN



(g) IMRN-V　　(h) EMASRN　　(i) 本章方法 MFSN

图 2-7 不同方法在 3 倍上采样下对 BDD100K 中 daa9d119-235d81ea 号图像的主观效果



(a) Bicubic　　(b) FSRCNN　　(c) VDSR



(d) LapSRN　　(e) CARN　　(f) IMDN



(g) IMRN-V　　(h) EMASRN　　(i) 本章方法 MFSN

图 2-8 不同方法在 3 倍上采样下对 BDD100K 中 ea9b012a-bc17ed08 号图像的主观效果

中国知网 https://www.cnki.net



(a) Bicubic (b) FSRCNN (c) VDSR



(d) LapSRN (e) CARN (f) IMDN

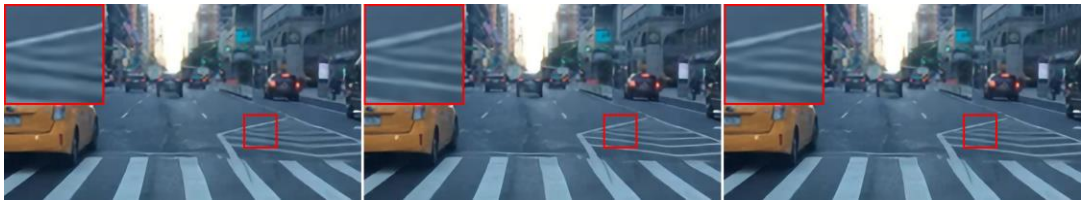


(g) IMRN-V (h) EMASRN (i) 本章方法 MFSN

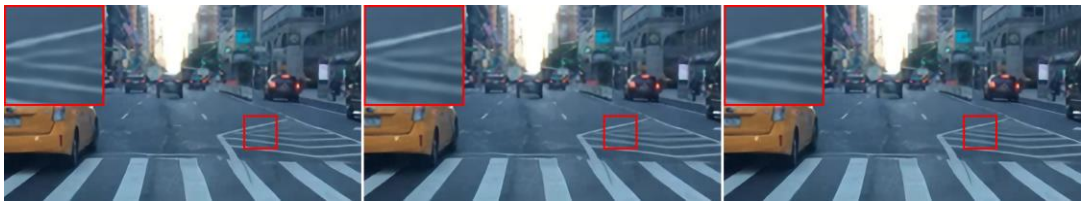
图 2-9 不同方法在 4 倍上采样下对 BDD100K 中 d0bf7531-7a0be3ce 号图像的主观效果



(a) Bicubic (b) FSRCNN (c) VDSR



(d) LapSRN (e) CARN (f) IMDN



(g) IMRN-V (h) EMASRN (i) 本章方法 MFSN

图 2-10 不同方法在 4 倍上采样下对 BDD100K 中 ec1d6e09-d20e93b4 号图像的主观效果

中国知网 https://www.cnki.net

从图 2-7~图 2-10 中可见，在所有比较方法中，本章方法 MFSN 能实现最好的视觉效果。例如，在图 2-7 和图 2-8 中，相较于其他方法，MFSN 不仅能更准确地重建出近处车辆（如图 2-7 所示）原本的纹理，对于远处仅占据较少量像素信息的车辆（如图 2-8 所示）也能实现准确复原。又例如图 2-9 中的斑马线和图 2-10 中的道路标线，MFSN 能产生最直和最清晰的边缘细节，而其他方法重构的图像存在不同程度的错误纹理和明显伪影。以上结果反映了本章方法 MFSN 具有较高的泛化能力。总的来说，MFSN 在交通道路场景中能有效增强图像的质量，从而帮助人们更好地识别复杂交通环境。因此，本章所提方法具有一定的实际应用价值。

2.4.2 提升道路交通场景下低质图像目标检测准确率

在道路交通场景中，图像增强对目标检测任务至关重要。低质图像会严重削弱目标特征，致使目标检测算法出现漏检、误检等问题。例如远处的车辆和行人轮廓模糊，检测算法难以准确识别。通过图像增强，可显著提升图像清晰度，突出目标关键特征，为目标检测算法提供更优质的输入图像，从而有效提高检测准确率和召回率。因此，本小节有必要进一步评估所提方法对于提升道路交通场景低质图像目标检测准确率的有效性。图 2-11 展示了经典的目标检测器 CenterNet[138]对 LR 图像、EMASRN 重建图像以及本章方法 MFSN 重建图像的检测结果对比。

从图 2-11 中可以看到，在这些方法中，未经过增强的 LR 图像的检测准确率是最低的。这主要是因为 LR 图像中的纹理细节丢失严重，目标信息不充分，使得后续目标检测器难以提取到准确的判别特征，从而出现明显的漏检现象。在对 LR 图像使用 SR 方法进行增强后，可以明显看到，相比子图 2-11 (a)，子图 2-11 (b)和(c)显然具有更高的检测准确率。其中，本章方法 MFSN 的检测结果最好，无论是近处的行人还是远处的小目标车辆都能识别出更多。尽管 MFSN 增强后的图像与 EMASRN 在视觉效果上差异较小，但其检测精度更高。这一现象的本质原因在于，检测算法对图像目标的边缘、纹理等关键特征具有极高敏感性，而不同增强方法对这些关键特征的强化机制存在本质差异。深入分析表明，EMASRN 采用静态多尺度特征融合方式，而 MFSN 则通过动态特征选择机制挖掘丰富细粒度的多尺度特征，能够在目标尺寸差异显著、纹理复杂的道路交通场景中，更精准地增强目标关键特征如行人的轮廓纹理、车辆轮毂的辐条结构等。这些人眼难以察觉的局部细节，恰恰是检测模型区分目标与背景的核心决策依据。尽管在目标检测前引入预增强步骤可能伴随新的问题与误差风险，但 MFSN 凭借精心设计的轻量级架构，能够在图像增强效果、对检测性能的提升以及计算

中国知网 https://www.cnki.net

资源消耗之间实现良好平衡。以上实验结果也表明，在道路交通场景中，针对低质量图像进行 SR 增强，可有效改进目标检测的性能。这一预处理策略的有效性，验证了在计算机视觉实际应用中通过图像增强优化检测流程的必要性与可行性。



(a) LR 图像直接检测　　(b) EMASRN　　(c) 本章方法 MFSN

图 2-11 CenterNet 检测器对 LR 图像和不同 SR 图像的检测效果比较

2.5 本章小结

本章提出了一种新颖的名为 MFSN 的轻量级网络用于低质图像增强。该网络主要由高效的多尺度特征学习模块 MFSB 堆叠构成。MFSB 通过采用多条并行且渐进连接支路去提取细粒度多尺度特征，从而实现特征表达能力的有效增强。在 MFSB 中，采用精心设计 SSM 以非线性的方式动态聚集来相邻两条支路的信息，解决了传统方法多尺度特征静态融合不充分导致模型适应能力弱的问题。作为 SSM 的核心，CCAM 通过探索综合的通道信息来准确学习对应不同尺度特征

中国知网　https://www.cnki.net

的选择权重，帮助 SSM 更好地整合多尺度信息。实验结果表明，相较于其他轻量级 SR 模型，MFSN 能在模型准确度和效率之间实现较好的平衡。此外，MFSN 在道路交通场景中也能实现有效的图像增强，从而为人眼视觉感知体验和后续目标检测准确率的提升做出一定的贡献。

中国知网 https://www.cnki.net

第 3 章 基于空间域和频率域混合的低质图像增强

3.1 引言

上一章提出了一种新的低质图像增强方法 MFSN，其通过充分探索空间域的多尺度特征并结合设计的动态融合机制，解决了多尺度特征融合不充分导致的模型适应能力弱的问题。然而，与大多数方法一样，MFSN 仅专注于空间域特征的增强而忽略了其他域特征的探索，导致在训练过程中网络所学习的信息来源单一，缺乏对图像的全面感知，限制了模型性能的进一步提升。

为应对上述挑战，本章提出了一种混合域增强网络（Hybrid Domain Enhancement Network，HDEN）。HDEN 的核心组件是混合域增强模块（Hybrid Domain Enhancement Module，HDEM），其可以从空间和频率域中提取多源特征以实现稳健而全面的特征表示。具体来说，HDEM 主要由两个并行排列的模块组成，分别为频域增强模块（Frequency Domain Enhancement Block，FDEB）和空间域增强模块（Spatial Domain Enhancement Block，SDEB）。为充分利用频域特征复原高质量图像，FDEB 采用离散小波变换（Discrete Wavelet Transform，DWT）[139]将特征从空间域转换为频率域，并对分解得到的多频分量进行融合，以有效学习图像中的精细结构和纹理细节。与上一章提出的 MFSB 类似，SDEB 同样采用多条包含宽激活残差单元的并行支路从空间域提取多尺度特征。由于 HDEM 已经额外引入频率域特征的学习，为避免模型运行时间成本过大，SDEB 并没有采用上一章所提出的渐进连接方式来构建多支路结构，而是选择在不同分支的宽激活残差单元中使用不同空洞率的空洞卷积，以此得到不同的感受野范围。通过堆叠多个 HDEM，可以得到总体网络 HDEN。

图 3-1 展示了各方法 PSNR 值、参数和 FLOPs 的比较结果。其中，PSNR 值是 4 倍上采样情况下模型对 Manga109[126]测试集计算得到的平均值；蓝色和红色圆圈分别表示第二章方法 MFSN 和本章方法 HDEN；圆圈越大表明模型所耗费的参数越多。从图 3-1 中可以看到，与 MFSN 相比，虽然 HDEN 的计算复杂度更高一些，但其模型性能更好。在所有比较的 SR 方法中，HDEN 通过协同空间域和频率域特征细化，能得到最高的 PSNR 值。

总的来说，本章的主要创新点和贡献如下：

1） 提出一种空间域特征学习模块 SDEB，通过在不同并行分支上应用具有不同空洞率的宽激活残差单元，实现有效的多尺度特征提取，从而增强模型的上下文感知和空间特征学习能力。

2） 开发一种频率域特征学习模块 FDEB，通过利用 DWT 将空间域特征转换

中国知网 https://www.cnki.net

到频率域，以探索不同频率信息的相关性，进而改善图像纹理和细节。

3） 通过集成 SDEB 和 FDEB，可以得到一种混合域特征学习模块 HDEM。该模块可同时利用空间域和频率域特征信息，以实现稳健而全面的特征表示，从而提升模型性能。

4） 相比其他方法，通过堆叠多个 HDEM 构建的网络 HDEN，在 5 个广泛使用的基准测试集上都实现了最优性能。

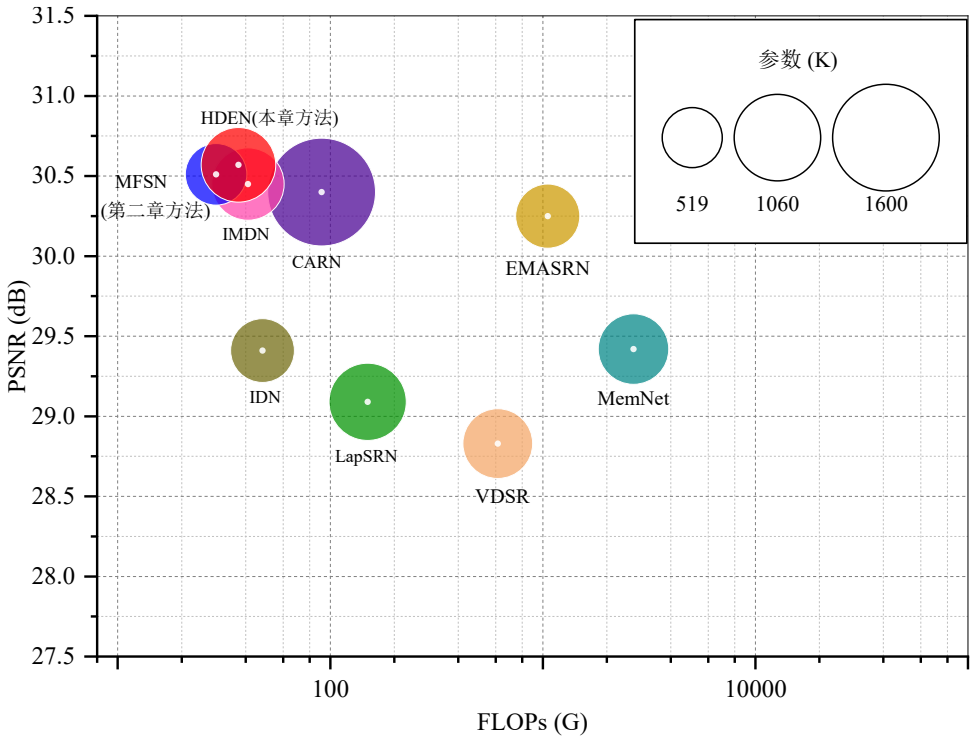


图 3-1 4 倍上采样情况下各方法在 Manga109 测试集上的 PSNR、参数和 FLOPs 比较

3.2 基于空间域和频率域混合的低质图像增强方法

3.2.1 混合域增强网络总体结构

HDEN 的总体网络结构展示在图 3-2 中。与第二章方法 MFSN 大体一致，HDEN 的总体网络结构同样由 3 个阶段构成，分别为初始特征提取、非线性特征映射以及图像重建阶段。不同之处在于，HDEN 中的非线性特征映射阶段主要采用 HDEM 作为基础构建模块。HDEN 总体网络的具体信息参考 2.2.1 节，在本节将不过多赘述。

在训练阶段，与第二章方法 MFSN 一致，HDEN 同样采用 L1 损失函数来训练模型，以实现更好的图像重建结果。HDEN 的目标优化函数 $\mathcal{L}_{\mathrm{HDEN}}$ 可以由以下公式表示：

中国知网　https://www.cnki.net

$$\mathcal{L}_{\mathrm{HDEN}}=\frac{1}{\mathcal{B}}\sum_{j=1}^{\mathcal{B}}\left\|\mathcal{F}_{\mathrm{HDEN}}\left(\boldsymbol{I}_{\mathrm{LR}}^{j}\right)-\boldsymbol{I}_{\mathrm{HR}}^{j}\right\|_{1} \tag{3-1}$$

其中，$\mathcal{F}_{\mathrm{HDEN}}(\cdot)$表示 HDEN 函数。

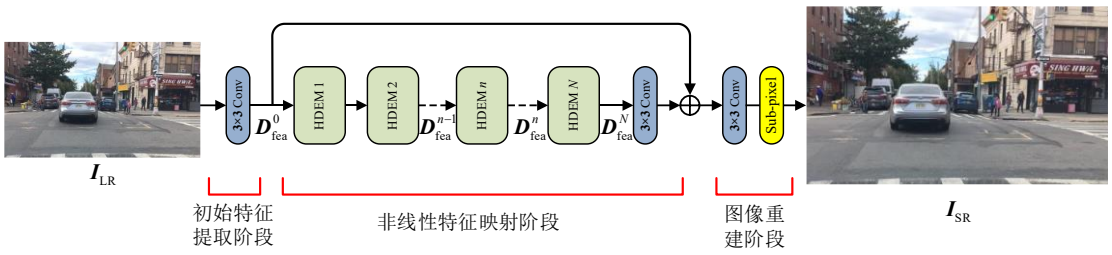


图 3-2 HDEN 的结构

3.2.2 空间域和频率域混合增强的特征提取模块

在 SR 任务中，LR 图像通常包含大量冗余的低频分量（如平滑的背景等）和少量的高频分量（如纹理和边缘等细节）。以往大多数 SR 方法仅专注于空间域特征的探索，虽然能提升模型对图像整体结构信息的感知，但对高频部分细节却无法很好建模。为了解决上述问题，本小节提出一种名为 HDEM 的特征提取模块，通过有效整合空间域和频率域特征改善图像整体重建效果。HDEM 的具体结构展示在图 3-3 中，其总体形式可以由如下公式表示：

$$\boldsymbol{D}_{\mathrm{fea}}^{n}=\mathcal{F}_{\mathrm{fuse}}\left(\mathcal{F}_{\mathrm{Concat}}\left(\mathcal{F}_{\mathrm{FDEB}}\left(\boldsymbol{D}_{\mathrm{fea}}^{n-1}\right),\mathcal{F}_{\mathrm{SDEB}}\left(\boldsymbol{D}_{\mathrm{fea}}^{n-1}\right)\right)\right)+\boldsymbol{D}_{\mathrm{fea}}^{n-1} \tag{3-2}$$

式中，$\boldsymbol{D}_{\mathrm{fea}}^{n-1}$和$\boldsymbol{D}_{\mathrm{fea}}^{n}$分别定义为第$n$个 HDEM 的输入和输出特征；$\mathcal{F}_{\mathrm{fuse}}(\cdot)$是特征融合函数，由1×1卷积层实现；$\mathcal{F}_{\mathrm{Concat}}(\cdot)$表示通道层面的级联操作；$\mathcal{F}_{\mathrm{FDEB}}(\cdot)$和$\mathcal{F}_{\mathrm{SDEB}}(\cdot)$分别为 FDEB 和 SDEB 特征增强函数。

如图 3-3 所示，HDEM 主要包括两个并行分支，分别由 SDEB 和 FDEB 负责特征的提取。具体来说，SDEB 的设计目的是通过多支路结构搭配空洞卷积来挖掘多尺度信息，以有效增强空间域特征，详细结构将在 3.2.3 节展示。同时，为了引入频率域信息来进一步提高模型特征表示能力，采用 FDEB 作为 HDEM 的另一个分支。该分支侧重于学习与频率相关的知识，以助力网络更好地恢复图像的高频细节，其结构将在 3.2.4 节中详细介绍。

与经典主要由 1 个跳跃连接、2 个卷积层和 1 个 ReLU 层组成的残差单元相比，所提出的 HDEM 具有以下 3 个方面优势：

1） 引入的 SDEB 通过具有不同空洞因子的多路径宽激活残差单元，在空间域实现了更大和更多样化的感受野探索，有效增强了模块的多尺度特征表征能力。

中国知网　https://www.cnki.net

2） 额外引入的频率域模块 FDEB，通过利用 DWT 提供的多频分解功能，使网络更好地探索高频细节线索，为模块的表达提供不同的视角。

3） HDEM 通过将 SDEB 与 FDEB 无缝结合，实现了空间域与频率域信息的整合，使其具备更强且更全面的精细图像结构捕捉能力。这种对混合域特征的探索特性，使其明显有别于仅专注于空间域特征学习的残差单元。

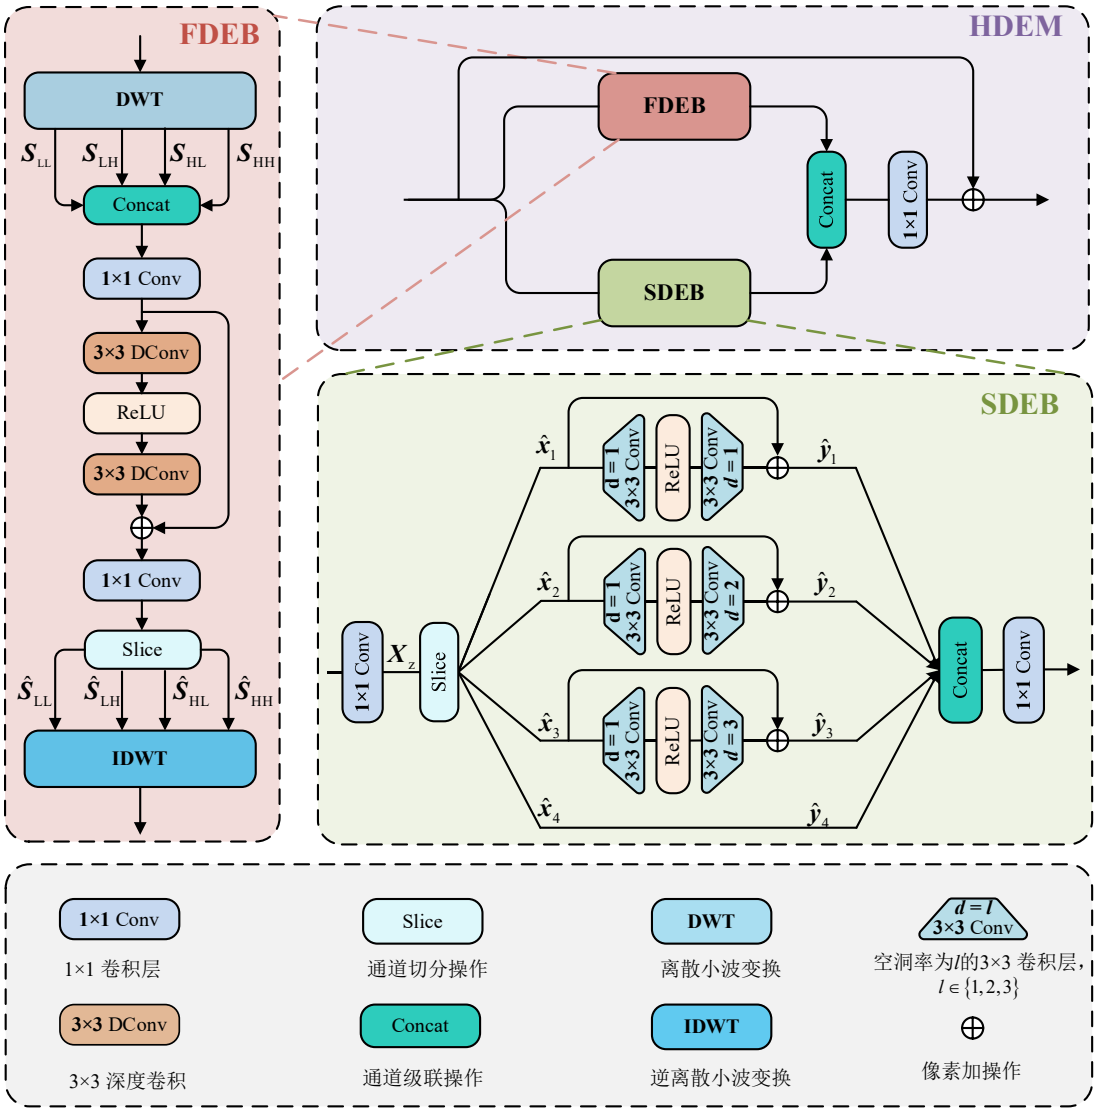


图 3-3 HDEM 的结构

3.2.3 基于多路空洞宽激活残差的空间域增强模块

多尺度表示是网络对图像特征进行有效建模的关键能力，而精心设计的多尺度结构可以显著提高模型性能。多尺度特征学习的一个关键在于如何探索更大且更丰富的感受野。为了捕捉更多的上下文信息，大多数传统多分支模块通常采用

中国知网　https://www.cnki.net

大核卷积如5×5和7×7卷积来获得更大的感受野。然而，这种策略通常会带来沉重的计算负担，并大大增加参数数量。虽然第二章提出的 MFSB 模块采用的多路并行且渐进连接策略能较好的解决以上问题，但也因此带来运行时间的增加。考虑到总体网络运行时间成本有限，SDEB 并没有采用这种策略，而是转为探索另一种高效多分支结构。为此，本小节提出了一种新的多尺度特征学习模块称为SDEB，其详细结构如图 3-3 所示。SDEB 的总体形式可以由如下公式表示：

$$\boldsymbol{X}_{\mathrm{p}}=\mathcal{F}_{\mathrm{R}}\left(\mathcal{F}_{\mathrm{H}}\left(\mathcal{F}_{\mathrm{E}}\left(\boldsymbol{X}_{\mathrm{c}}\right)\right)\right) \tag{3-3}$$

式中，$\boldsymbol{X}_{\mathrm{c}}$ 和 $\boldsymbol{X}_{\mathrm{p}}$ 分别为 SDEB 的输入和输出特征；$\mathcal{F}_{\mathrm{E}}(\cdot)$ 和 $\mathcal{F}_{\mathrm{R}}(\cdot)$ 分别表示特征扩张和特征缩减函数，它们都由1×1卷积实现；$\mathcal{F}_{\mathrm{H}}(\cdot)$ 表示多路特征提取函数。

与第二章提出的 MFSB 模块出发点一致，为了提升特征非线性表达能力，SDEB 在开头和结尾分别采用 $\mathcal{F}_{\mathrm{E}}(\cdot)$ 和 $\mathcal{F}_{\mathrm{R}}(\cdot)$ 来对特征进行扩展和缩小。假设 $\boldsymbol{X}_{\mathrm{c}}$ 的通道维度为 M_{O}，当 SDEB 的头部1×1卷积层作用于 $\boldsymbol{X}_{\mathrm{c}}$ 时，特征通道维度可以从 M_{O} 扩展到 M_{E}。而 SDEB 的尾部1×1卷积层则负责将细化后特征的通道维度从 M_{E} 缩减回原来的 M_{O}。如图 3-3 所示，经过头部1×1卷积层后，扩展后的特征被等分切割为 4 组子特征。这些子特征通过不同分支分别处理，得到的输出特征在送入尾部1×1卷积层前沿着通道维度进行级联。通过这种方式，头部1×1卷积层能自适应为后续分支打包相应特征，减少冗余计算。与此同时，尾部1×1卷积层则负责有效地合并和压缩所有分支处理后的特征，以去除冗余的信息，提升特征学习效率。

定义 $\mathcal{F}_{\mathrm{E}}(\boldsymbol{X}_{\mathrm{c}})$ 为 $\boldsymbol{X}_{\mathrm{z}}$，则SDEB的主体多尺度特征提取部分可由如下公式表示：

$$\mathcal{F}_{\mathrm{H}}\left(\boldsymbol{X}_{\mathrm{z}}\right)=\mathcal{F}_{\mathrm{Concat}}\left(\mathcal{F}_{\mathrm{w}}^{1}\left(\hat{\boldsymbol{x}}_{1}\right),\mathcal{F}_{\mathrm{w}}^{2}\left(\hat{\boldsymbol{x}}_{2}\right),\mathcal{F}_{\mathrm{w}}^{3}\left(\hat{\boldsymbol{x}}_{3}\right),\mathcal{F}_{\mathrm{direct}}\left(\hat{\boldsymbol{x}}_{4}\right)\right) \tag{3-4}$$

式中，$\hat{\boldsymbol{x}}_{i}$ 表示特征 $\boldsymbol{X}_{\mathrm{z}}$ 沿通道维度等同分割出来的第 i 组子特征，其中 $i\in\{1,2,3,4\}$；$\mathcal{F}_{\mathrm{w}}^{i}(\cdot)$ 定义为第 i 个宽激活残差支路函数，其中 $i\in\{1,2,3\}$；$\mathcal{F}_{\mathrm{direct}}(\cdot)$ 为直接连接操作。

为了有效学习不同尺度的信息，SDEB 构建了 4 个不同分支。第一分支主要使用普通的宽激活残差单元[127]。不同于第一分支，第二和第三分支分别整合了空洞率为 2 和 3 的3×3的卷积层。这些空洞卷积能使网络得到与5×5和7×7卷积等同大小的感受野，且明显消耗更少的参数。因此，在不同分支利用不同空洞率的空洞卷积是提取多尺度特征的高效方法。然而，直接应用空洞卷积会导致感受野中出现明显盲点问题[140]。为了在第二和第三分支中缓解这一问题，使用标准卷积而不是空洞卷积来进行特征扩展。最后，为了在不增加参数的情况下引入额外的尺度信息，第四分支采用了直接连接操作。总的来说，通过使用这种新策略，SDEB 能以较低的参数和计算复杂实现有效的多尺度特征提取。

中国知网 https://www.cnki.net

3.2.4 基于离散小波变换的频率域增强模块

对于 SR 任务而言，恢复边缘和纹理等结构信息是衡量模型性能的关键指标。现有许多 SR 方法主要侧重于加强空间域特征提取能力，而往往忽视了高频细节学习的重要性。为了解决这一问题，本小节提出一种名为 FDEB 的频率域特征学习模块，并将其作为 HDEM 其中一条支路，来提高网络对高频信息的关注力度。FDEB 先是利用 DWT 将特征从空间域转换到频率域，再将不同频率分量进行融合。这样的方式能使网络在捕捉特征细节信息的同时，抑制噪声的影响，从而更好地恢复图像精细结构。图 3-3 展示了 FDEB 的详细结构。给定一个特征图 $\boldsymbol{X}_{\mathrm{a}} \in \mathbb{R}^{H \times W \times C}$，其中 H、W 和 C 分别表示 $\boldsymbol{X}_{\mathrm{a}}$ 的高度、宽度和通道数，FDEB 通过应用 DWT 可以将 $\boldsymbol{X}_{\mathrm{a}}$ 分解成 4 个频率分量。这个分解过程可以由如下公式表示：

$$\left[\boldsymbol{S}_{\mathrm{LH}}, \boldsymbol{S}_{\mathrm{HL}}, \boldsymbol{S}_{\mathrm{HH}}, \boldsymbol{S}_{\mathrm{LL}}\right] = \mathcal{D}\left(\boldsymbol{X}_{\mathrm{a}}\right) \tag{3-5}$$

其中 $\mathcal{D}(\cdot)$ 是 DWT 函数；$\boldsymbol{S}_{\mathrm{LH}}$、$\boldsymbol{S}_{\mathrm{HL}}$、$\boldsymbol{S}_{\mathrm{HH}}$ 以及 $\boldsymbol{S}_{\mathrm{LL}}$ 分别表示由 DWT 分解得到的特征维度都为 $H/2 \times W/2 \times C$ 的低—高频、高—低频、高—高频以及低—低频子带。值得注意的是，$\boldsymbol{S}_{\mathrm{LH}}$、$\boldsymbol{S}_{\mathrm{HL}}$、$\boldsymbol{S}_{\mathrm{HH}}$ 都为高频子带，而 $\boldsymbol{S}_{\mathrm{LL}}$ 为低频子带。

在应用 DWT 后，将 4 个频率子带沿通道维度级联起来。为了有效探索不同频率分量之间的相互关系，采用 1 个1×1 卷积层融合和压缩级联后的频率特征，并利用包含 2 个3×3 深度卷积层和 1 个 ReLU 层的残差单元进一步从融合后的特征中提炼频率知识。通过使用上述方式，FDEB 能高效利用频率子带之间的互补性增强图像结构细节。这主要原因在于，在这 4 个频率分量中，低频分量 $\boldsymbol{S}_{\mathrm{LL}}$ 可提供特征图中大致的轮廓信息，而 3 个高频分量 $\boldsymbol{S}_{\mathrm{LH}}$、$\boldsymbol{S}_{\mathrm{HL}}$ 和 $\boldsymbol{S}_{\mathrm{HH}}$ 则分别提供水平、垂直和对角线上的结构细节。通过对这些频率特征级联后再进行卷积运算，网络就能以这些分量之间的空间结构相关性为指导，使卷积权重专注于精细细节的学习。值得一提的是，不同频率分量融合过程中使用深度卷积可以一定程度减少网络参数的引入和避免计算开销过大，保持了 FDEB 的轻量级特性。

在完成频率域特征提炼后，需要进一步将特征从频率域转换回空间域。因此，为方便执行随后的反离散小波变换（Inverse Discrete Wavelet Transform，IDWT），首先使用第二个1×1 卷积层来扩展提炼后特征的通道维度。然后，采用特征切分操作，将扩展后的特征沿通道维度等分切割为 4 个重建子带：$\hat{\boldsymbol{S}}_{\mathrm{LH}}$、$\hat{\boldsymbol{S}}_{\mathrm{HL}}$、$\hat{\boldsymbol{S}}_{\mathrm{HH}}$ 和 $\hat{\boldsymbol{S}}_{\mathrm{LL}}$。最后，对这些重建频率子带应用 IDWT，从而得到 FDEB 的输出特征 $\boldsymbol{X}_{\mathrm{b}}$。该过程可以由如下公式表示：

$$\boldsymbol{X}_{\mathrm{b}} = \mathcal{R}\left(\hat{\boldsymbol{S}}_{\mathrm{LH}}, \hat{\boldsymbol{S}}_{\mathrm{HL}}, \hat{\boldsymbol{S}}_{\mathrm{HH}}, \hat{\boldsymbol{S}}_{\mathrm{LL}}\right) \tag{3-6}$$

式中，$\mathcal{R}(\cdot)$ 表示 IDWT 函数。值得一提的是，因为 Haar 小波的计算高效性，FDEB 将其作为 DWT 和 IDWT 的小波基。

中国知网 https://www.cnki.net

为了方便理解 DWT 的原理，图 3-4 展示 2D DWT 和 IDWT 的工作过程。其中，↑2 和↓2 分别表示 2 倍上采样和下采样操作。从图 3-4 中可以看到，给定一个 1D 输入数据 $\boldsymbol{W}_{\mathrm{x}}$，1D DWT 通过对输入数据依次沿行和列应用低通滤波器 $\boldsymbol{h}=[1/\sqrt{2},1/\sqrt{2}]$ 和高通滤波器 $\boldsymbol{p}=[1/\sqrt{2},-1/\sqrt{2}]$，可以将其分解成 4 个频率分量，包括 $\boldsymbol{W}_{\mathrm{LL}}$、$\boldsymbol{W}_{\mathrm{LH}}$、$\boldsymbol{W}_{\mathrm{HL}}$ 和 $\boldsymbol{W}_{\mathrm{HH}}$，从而完成 DWT 过程。对于 DWT 的逆过程，得益于 Haar 小波的正交特性，IDWT 可以通过先对两个被上采样后的频率分量进行逆滤波操作，再计算其总和来重构出原始 1D 数据 $\boldsymbol{W}_{\mathrm{x}}$。

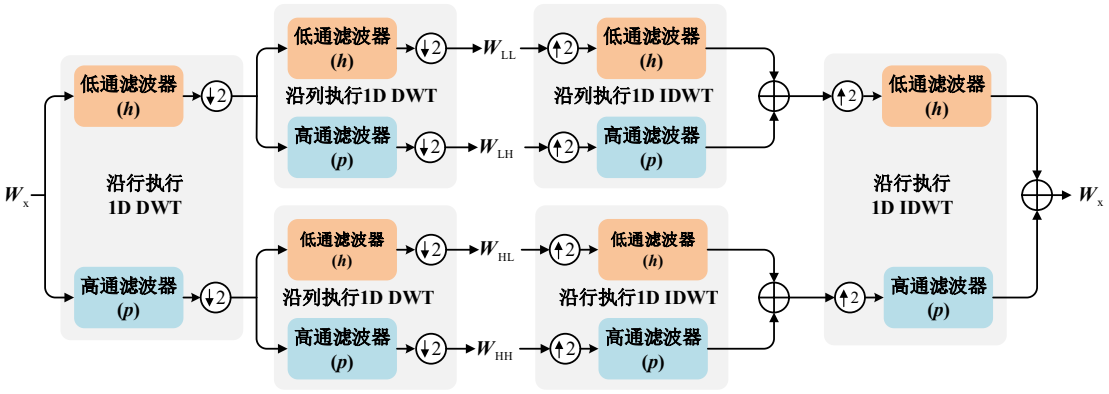


图 3-4 2D DWT 和 IDWT 的过程图

3.3 实验结果与分析

3.3.1 实验设置

本章的实验环境、数据预处理方式、所使用的评价指标、训练集和测试集与第二章方法 MFSN 一致。HDEN 由 16 个 HDEM 模块构建（即 N 设置为 16）。为了减少网络的参数量，HDEM 的基本输入特征通道维度与 MFSN 的设置一样，都为 32。SDEB 中的通道维度 M_{E}、宽激活残差单元的扩展因子 e 和分支数量 ρ 分别设置为 48、4 和 4。FDEB 中的小波变换采用的是 1 级分解。在训练阶段，使用 ADAM 作为优化器，并将其中关键参数设定为 $\beta_1=0.9$、$\beta_2=0.999$ 和 $\varepsilon=10^{-8}$。为了加速模型收敛，在网络中采用了 WN[136]。整个模型总共训练了 1000 个轮次，初始学习率设置为 10^{-3}，每 200 个轮次将当前的学习率减半。此外，本章还采用了热启动策略来微调最终的 HDEN 模型。

3.3.2 消融实验

作为 HDEN 的基础构建模块，HDEM 中每个组件以及所涉及的超参数都是影响模型性能的重要因素。因此，本小节以 Set5 作为测试集，通过增删组件以及改变超参数进行一系列消融实验，以此来评估它们对 HDEN 性能的影响。本

中国知网　https://www.cnki.net

小节所有实验结果都是在设定尺度因子为 4 和所有网络的基本输入特征通道维度为 32 的情况下得到的。此外，为节省训练时间，在消融实验中没有采用热启动策略。

（1）SDEB 和 FDEB 的有效性

为研究本章方法 HDEN 中 SDEB 和 FDEB 对模型性能的影响，本小节进行了一系列实验，所得实验结果汇总于表 3-1。其中，基准网络主要由 16 个宽激活残差单元构建；$\mathcal{N}_a$ 是指用 SDEB 代替基准网络中的宽激活残差单元后得到的变种网络。通过进一步将 FDEB 加入到网络 $\mathcal{N}_a$ 中，可以得到网络 $\mathcal{N}_b$，即完整版 HDEN。通过观察表 3-1，可以得出以下结论：

1） 虽然网络 $\mathcal{N}_a$ 的 PSNR 值与基准网络一样，但参数数量却减少了一半以上。这主要归功于 SDEB 通过结合多路宽激活残差单元与空洞卷积，实现了高效的多尺度特征表达。

2） 通过将 FDEB 进一步集成到网络 $\mathcal{N}_a$ 中，生成的网络 $\mathcal{N}_b$ 显然获得更高的 PSNR 值。这一结果表明联合空间域和频率域可以显著增强网络特征表达能力，从而提高模型的整体性能。

表 3-1 SDEB 和 FDEB 的有效性

方法	SDEB	FDEB	参数（K）	PSNR（dB）
基准网络	×	×	1209	32.15
$\mathcal{N}_a$	✓	×	579	32.15
$\mathcal{N}_b$	✓	✓	761	32.20

（2）SDEB 中分支数量 ρ 的影响

表 3-2 列出了不同 ρ 下 HDEN 的 PSNR 值。其中，M_E 是指 SDEB 中第一个 1×1 卷积层的输出特征通道数。为了确保比较的公平性，随着 ρ 改变，同时调整 M_E 以保持所有模型参数数量相近。当 ρ 设为 2 时，SDEB 只包含两个分支，分别由一个直连操作和一个普通宽激活残差单元构成。当 ρ 为 3 时，相比 $\rho=2$，新增第三条支路同样由宽激活残差单元实现，但不同的是，在该单元中负责特征通道缩减的标准卷积被替换成空洞率为 2 的空洞卷积。以此类推，当 $\rho=4$ 和 $\rho=5$ 时，新增的第四条支路和第五条支路中的相应位置分别采用了空洞率为 3 和 4 的空洞卷积。

表 3-2 不同分支数 ρ 对模型性能的影响

支路数 ρ	2	3	4	5
M_E	46	48	48	55
参数（K）	687	671	579	645
PSNR（dB）	32.11	32.14	32.15	32.16

中国知网 https://www.cnki.net

从表 3-2 中可见，随着 ρ 的增加，PSNR 值也在逐渐增大。得到该结果的主要原因在于网络采用更多的分支来探索更大且更丰富的感受野，从而实现更好的多尺度特征提取能力。然而，与 $\rho=4$ 相比，当 $\rho=5$ 时，SR 结果 PSNR 值的提升微乎其微，且模型引入更多的参数。因此经过权衡后，在本章中，将 ρ 统一设置为 4。

（3）SDEB 中 M_E 的影响

在 SDEB 中，M_E 表示 SDEB 的第一个1×1卷积层输出特征的通道数。在保持 SDEB 的输入特征维度为 32 的情况下，通过改变 M_E 来评估该参数对模型性能的影响，所得实验结果展示表 3-3 中。

从表 3-3 中可以看到，当 M_E 从 40 增加到 52 时，SR 结果的 PSNR 值逐步提升，而参数数量也在一直增加。特别是 M_E 从 48 增加到 52 时，没有观察到明显的性能提升。因此，选择 $M_E=48$ 是合理的，且在这个情况下，模型能在性能和参数之间实现更好的平衡。

表 3-3 SDEB 中 M_E 的影响

M_E	40	44	48	52
参数（K）	412	495	579	670
PSNR（dB）	32.08	32.11	32.15	32.16

（4）扩展因子 e 的影响

表 3-4 展示了 SDEB 中宽激活残差单元的扩展因子对模型性能影响的实验结果。从中可以看出，当扩展因子从 2 变为 5 时，PSNR 值有所提高。然而，当扩展因子超过 4 时，模型性能并没有得到提升。考虑到更大的扩展因子会引入更多的网络参数和计算负担，因此，本章最终将 e 设为 4。

表 3-4 SDEB 中宽激活残差单元扩展因子 e 的影响

扩展因子 e	2	3	4	5
参数（K）	328	454	579	705
PSNR（dB）	32.03	32.04	32.15	32.15

3.3.3 与其他方法的比较

为了评估本章所提方法 HDEN 的性能，将其与 9 个轻量级 SR 模型进行了比较，包括 VDSR[13]、LapSRN[28]、MemNet[14]、IDN[37]、CARN[29]、IMDN[38]、IMRN-V[32]、EMASRN[41]和第二章方法 MFSN。为了公平地进行比较，本章将相关比较方法进行了重新训练。表 3-5 和表 3-6 分别列出了采样因子为 3 和 4 的情况下不同 SR 方法在 5 个基准测试集 Set5[132]、Set14[133]、BSD100[134]、Urban100[135]和 Manga109[126]上的 PSNR 和 SSIM 值比较结果。与 MFSN 一样，本章同样采用

中国知网 https://www.cnki.net

了几何性自集成策略来进一步提高 HDEN 的性能，增强后的 HDEN 称为 HDEN$^+$。

表 3-5 采样率为 3 的情况下不同方法的平均 PSNR（dB）/ SSIM 定量比较

方法	Set5[132]	Set14[133]	BSD100[134]	Urban100[135]	Manga109[126]
VDSR[13]	33.66 / 0.9213	29.77 / 0.9213	28.82 / 0.7976	27.14 / 0.8279	32.01 / 0.9310
LapSRN[28]	33.82 / 0.9227	29.87 / 0.8320	28.82 / 0.7980	27.07 / 0.8280	32.21 / 0.9350
MemNet[14]	34.09 / 0.9248	30.01 / 0.8350	28.96 / 0.8001	27.56 / 0.8376	32.51 / 0.9369
IDN[37]	34.11 / 0.9253	29.99/ 0.8354	28.95 / 0.8013	27.42 / 0.8359	32.71 / 0.9381
CARN[29]	34.29 / 0.9255	30.29 / 0.8407	29.06 / 0.8034	28.06 / 0.8493	33.49 / 0.9440
IMDN[38]	34.36 / 0.9270	30.32 / 0.8417	29.09 / 0.8046	28.17 / 0.8519	33.61 / 0.9445
IMRN-V[32]	34.35 / 0.9268	30.23 / 0.8398	29.04 / 0.8037	28.04 / 0.8495	33.40 / 0.9430
EMASRN[41]	34.27 / 0.9260	30.24 / 0.8396	29.02 / 0.8029	27.96 / 0.8479	33.27 / 0.9425
MFSN	34.36 / 0.9272	30.32 / 0.8419	29.07 / 0.8048	28.17 / 0.8526	33.59 / 0.9447
HDEN	34.42 / 0.9273	30.36 / 0.8425	29.11 / 0.8055	28.20 / 0.8537	33.67 / 0.9452
HDEN$^+$	**34.51 / 0.9279**	**30.45 / 0.8441**	**29.16 / 0.8065**	**28.34 / 0.8557**	**33.93 / 0.9466**

表 3-6 采样率为 4 的情况下不同方法的平均 PSNR（dB）/ SSIM 定量比较

方法	Set5[132]	Set14[133]	BSD100[134]	Urban100[135]	Manga109[126]
VDSR[13]	31.35 / 0.8838	28.01 / 0.7674	27.29 / 0.7251	25.15 / 0.7524	28.83 / 0.8809
LapSRN[28]	31.54 / 0.8850	28.19 / 0.7720	27.32 / 0.7270	25.21 / 0.7560	29.09 / 0.8900
MemNet[14]	31.74 / 0.8893	28.26 / 0.7723	27.40 / 0.7281	25.50 / 0.7630	29.42 / 0.8942
IDN[37]	31.82 / 0.8903	28.25 / 0.7730	27.41 / 0.7297	25.41 / 0.7632	29.41 / 0.8942
CARN[29]	32.13 / 0.8937	28.60 / 0.7806	27.58 / 0.7349	26.07 / 0.7837	30.40 / 0.9082
IMDN[38]	32.21 / 0.8948	28.58 / 0.7811	27.56 / 0.7353	26.01 / 0.7838	30.45 / 0.9075
IMRN-V[32]	32.11 / 0.8939	28.52 / 0.7800	27.53 / 0.7344	25.98 / 0.7825	30.29 / 0.9054
EMASRN[41]	32.12 / 0.8934	28.54 / 0.7793	27.51 / 0.7330	25.91 / 0.7788	30.25 / 0.9051
MFSN	32.22 / 0.8950	28.56 / 0.7811	27.55 / 0.7356	26.05 / 0.7846	30.51 / 0.9088
HDEN	32.28 / 0.8954	28.64 / 0.7828	27.59 / 0.7369	26.08 / 0.7867	30.57 / 0.9096
HDEN$^+$	**32.34 / 0.8966**	**28.72 / 0.7843**	**27.64 / 0.7382**	**26.21 / 0.7896**	**30.82 / 0.9120**

从表 3-5 和表 3-6 中可以看到，与其他轻量级图像 SR 方法相比，本章方法 HDEN 在所有测试集上都获得了最高的 PSNR 和 SSIM 值。值得一提的是，HDEN 明显优于最近 SR 方法 EMASRN，特别是采样率为 4 的情况下。例如，HDEN 在 Set5[132]、Set14[133]、BSD100[134]、Urban100[135]和 Manga109[126]上的 PSNR 值分别提高了 0.16 dB、0.10 dB、0.08 dB、0.17 dB 和 0.32 dB。而 SSIM 的提升值分别为 0.0020、0.0035、0.0039、0.0079 和 0.0045。这些结果都凸显了本章方法 HDEN 的优越性。值得一提的是，虽然第二章方法 MFSN 采用的多路并行渐进融合策略实现了细粒度的多尺度特征提取，但 HDEN 通过引入频率域的强化特征，并联合空间域特征细化，实现了更全面的特征表达，从而获得更高的 PSNR 和 SSIM 值。

中国知网 https://www.cnki.net

3.3.4 模型参数、计算复杂度与运行时间分析

在本小节中，为了评估各种方法的网络规模和计算复杂度，将参数数量、FLOPs 和运行时间作为关键评估指标。所有指标的计算方式都与第二章方法 MFSN 一致。表 3-7 展示了在 4 倍上采样的情况下，不同轻量级模型的参数、FLOPs、运行时间以及 PSNR 值的比较结果。其中，PSNR 值是各 SR 方法在 Manga109 测试集[126]上计算所得。

从表 3-7 中可知，在所有比较的轻量级方法中，本章方法 HDEN 的参数、FLOPs 以及推理时间虽然不是最优的，但并不是最差的。与第二章方法 MFSN 相比，HDEN 虽然耗费的参数和 FLOPs 更多，但其 PSNR 值也更高。主要原因在于 HDEN 所采用的 DWT 虽然能使网络学习到额外的频率域信息，从而提升模型性能，但也因此增加了模型计算负担。因此，为避免进一步增加运行时间成本，在设计空间域特征增强模块 SDEB 时，并没有沿用第二章方法 MFSN 所提的多路并行且渐进连接策略，以保证 HDEN 在模型参数、计算复杂度以及性能之间实现较好的平衡。

表 3-7 不同 SR 方法的参数量、FLOPs、运行时间和 PSNR 值比较

方法	参数（K）	FLOPs（G）	运行时间（s）	PSNR（dB）
VDSR[13]	665	614	0.03	28.83
LapSRN[28]	813	150	0.01	29.09
MemNet[14]	677	2670	14.17	29.42
IDN[37]	553	48	0.01	29.41
CARN[29]	1592	91	0.01	30.40
IMDN[38]	715	41	0.01	30.45
IMRN-V[32]	669	38	0.02	30.29
EMASRN[41]	559	1054	0.09	30.25
MFSN（第二章方法）	519	29	0.03	30.51
HDEN（本章方法）	761	37	0.06	30.57

3.4 在道路交通场景中的应用

3.4.1 提升道路交通场景下低质图像的人眼视觉感知

与第二章一样，本章也采用自动驾驶数据集 BDD100K[137]的图像来对所提方法 HDEN 的鲁棒性和在道路交通场景中的应用可行性进行评估。所对比的 SR 方法包括 Bicubic、LapSRN[28]、CARN[29]、IMDN[38]、IMRN-V[32]、EMASRN[41]、和第二章方法 MFSN。图 3-5~图 3-8 展示了不同轻量级 SR 方法在 BDD100K[137]数据集图像上的主观结果比较。其中，图 3-5 和图 3-6 是在放大倍数为 3 情况下的结果比较图，而图 3-7 和图 3-8 则是在放大倍数为 4 情况下的结果比较图。

中国知网 https://www.cnki.net

从图 3-5~图 3-8 中可以得出以下结论：

1） 相比其他 SR 方法，第二章方法 MFSN 和本章方法 HDEN 所得到的主观效果明显更好。就主观效果来看，HDEN 所重建的 SR 图像在所有方法中是最优的。

2） 与其他 SR 方法的主观效果相比，HDEN 能更好地抑制伪影的产生和恢复更清晰的边缘。例如，在图 3-5 中，HDEN 能更好地恢复交通指示牌上单词的细节信息，使其能更好地被人类识别和理解，而其他方法输出的图像存在或多或少的伪影。又例如，在图 3-6 和图 3-7 中，HDEN 所重建的道路标线和斑马线的边缘更加锐利。这些主观结果反映了由于 HDEM 模块的使用，所提出的网络能通过对空间域和频率域多源信息的融合来学习更全面的特征表示。这种跨域信息互补能力使 HDEN 能够有效捕捉和重建更完整的图像结构和更精细的高频细节，从而获得更高质量的 HR 图像输出。



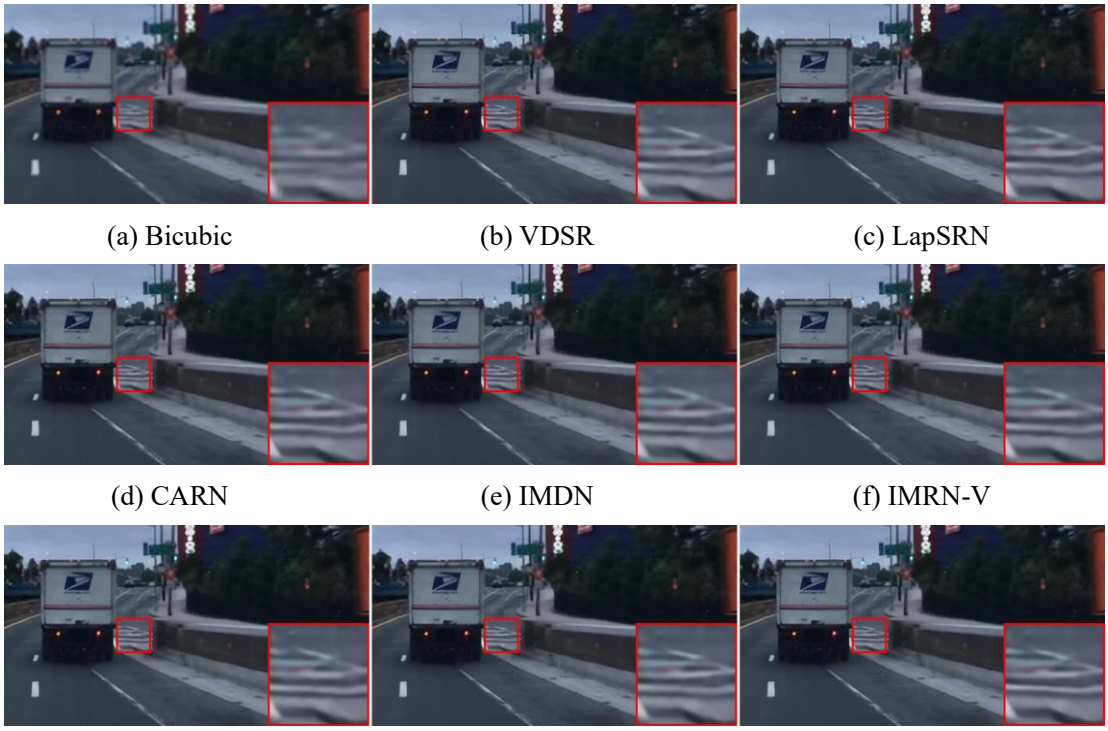
(a) Bicubic　(b) VDSR　(c) LapSRN

(d) CARN　(e) IMDN　(f) IMRN-V

(g) EMASRN　(h) 第二章方法 MFSN　(i) 本章方法 HDEN

图 3-5 不同方法在 3 倍上采样下对 BDD100K 中 ff88670c-e2a4a167 号图像的主观效果

中国知网 https://www.cnki.net

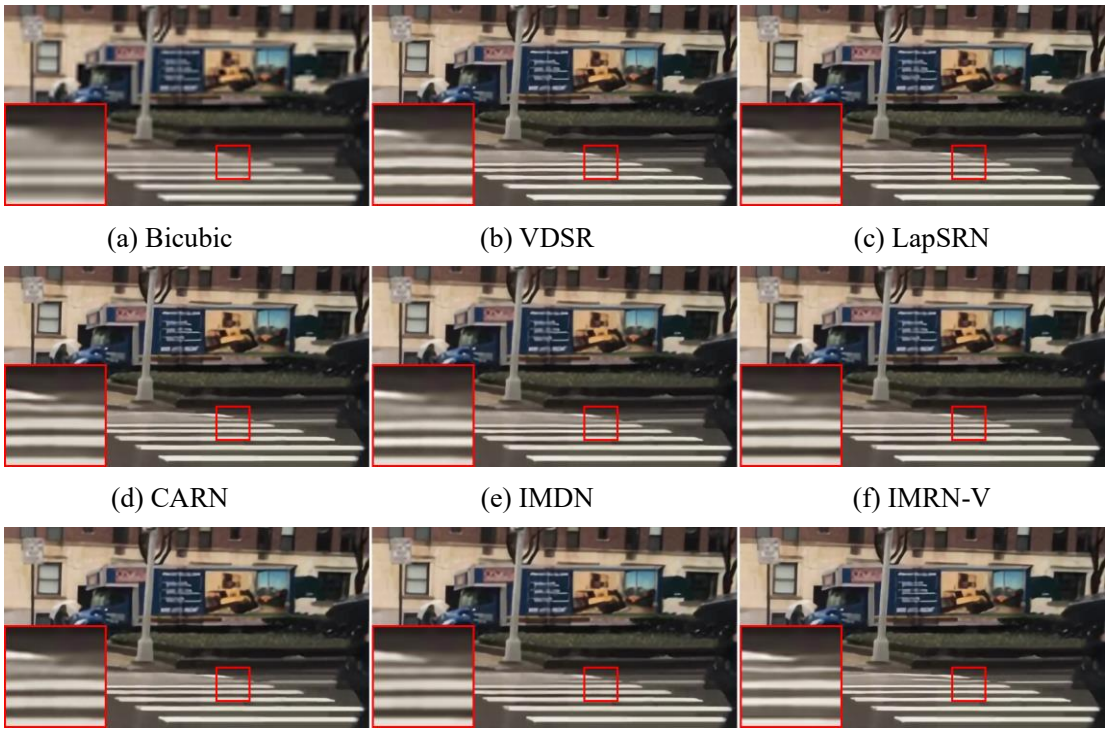


(a) Bicubic (b) VDSR (c) LapSRN

(d) CARN (e) IMDN (f) IMRN-V

(g) EMASRN (h) 第二章方法 MFSN (i) 本章方法 HDEN

图 3-6 不同方法在 3 倍上采样下对 BDD100K 中 f984582b-228d1880 号图像的主观效果



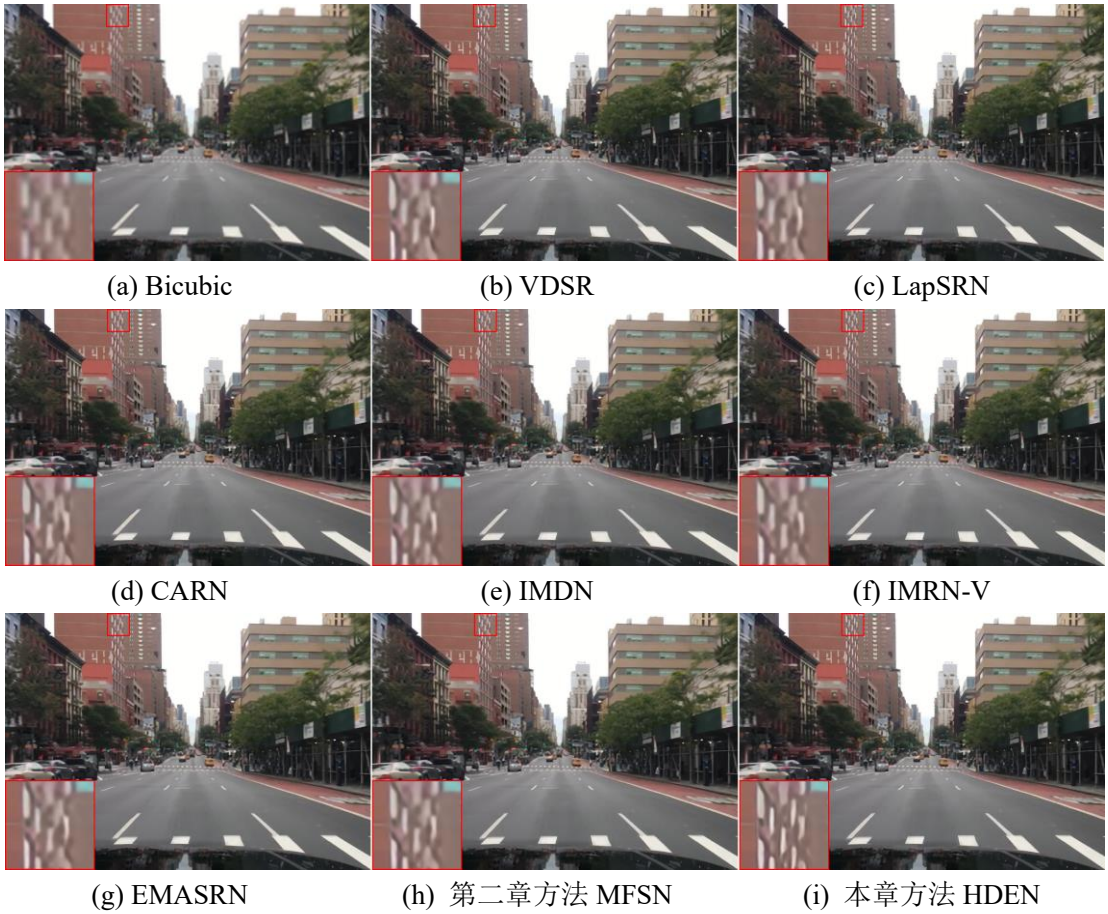
(a) Bicubic (b) VDSR (c) LapSRN

(d) CARN (e) IMDN (f) IMRN-V

(g) EMASRN (h) 第二章方法 MFSN (i) 本章方法 HDEN

图 3-7 不同方法在 4 倍上采样下对 BDD100K 中 df85e86a-aee49961 号图像的主观效果

中国知网 https://www.cnki.net



(a) Bicubic　(b) VDSR　(c) LapSRN

(d) CARN　(e) IMDN　(f) IMRN-V

(g) EMASRN　(h) 第二章方法 MFSN　(i) 本章方法 HDEN

图 3-8 不同方法在 4 倍上采样下对 BDD100K 中 f48e5666-d04e3e57 号图像的主观效果

3.4.2 提升道路交通场景下低质图像目标检测准确率

与第二章一样，本小节也采用自动驾驶数据集 BDD100K 的图像评估所提方法 HDEN 对于提升道路交通场景中低质图像目标检测准确率的有效性和必要性。图 3-10 展示了经典目标检测器 CenterNet[138]对 LR 图像、第二章方法 MFSN 重建图像以及本章方法 HDEN 重建图像的检测结果对比。

从图 3-9 中可以看到，LR 图像直接输入到检测器中进行检测，所得到的检测准确率是最低的。这也再次证明了第二章所提到的结论：目标检测器难以从纹理细节丢失严重的 LR 图像中提取到准确的判别特征。在对 LR 图像使用 SR 方法进行增强后，可以明显看到，相比子图 3-9 (a)，子图 3-9 (b)和(c)的检测效果明显更好。例如，图 3-9 中第一行子图远处的车辆，检测器在 LR 图像上仅能检测出 1 辆车，而第二章 MFSN 方法和第三章方法 HDEN 显然能识别和定位出更多的目标。又例如第二行子图远处的行人，在 LR 图像上甚至识别不出 1 个，而在基于 SR 图像的检测结果中能识别出 6 个行人。这些结果反映了 MFSN 和 HDEN 都能有效提升 LR 图像的目标检测准确率。在这些结果中，HDEN 方法在多数情况下优于 MFSN，进一步揭示了特征增强机制的深层差异。原因可能在于，HDEN

中国知网　https://www.cnki.net

通过引入基于 DWT 的频率域增强模块，针对性强化目标的高频边缘信息，并将频率域的边缘特征与空间域的纹理特征进行融合，形成“结构—细节”多层次特征表示。相比之下，MFSN 仅在空间域进行特征增强，对远距离目标的边缘恢复能力存在局限性。总的来说，相比于 LR 图像直接检测，无论是 MFSN 和 HDEN，都能以较少的计算资源消耗实现显著的检测性能提升，都说明了低质图像增强对计算机视觉目标检测任务是有必要且有效的。



(a) LR 图像直接检测　　(b) 第二章方法 MFSN　　(c) 本章方法 HDEN

图 3-9 CenterNet 检测器对 LR 图像和不同 SR 图像的检测效果比较

3.5 本章小结

本章提出了一种名为 HDEN 的轻量级图像增强网络，其主要混合域特征提取模块 HDEM 堆叠构成。与以往大多方法仅关注空间域特征的学习不同，HDEM 综合利用了空间域和频率域的多源信息，使网络实现了更全面的特征表示。在

中国知网　https://www.cnki.net

HDEM 中，负责空间域特征增强的 SDEB 采用多个不同宽激活残差单元构成的并行支路结构来有效捕捉多尺度特征。为了减少网络参数的同时，有效扩展感受野范围，在宽激活残差单元中使用了不同空洞因子的空洞卷积来代替标准卷积。对于频率域特征增强方面，FDEB 使用 DWT 将特征从空间域转换到频率域，并利用频率分量之间的相关性，促进网络对边缘等高频细节的关注。这种双域增强策略可确保网络提取更丰富细致的特征信息，解决了单一域特征表达能力受限的问题。最后，实验结果表明，HDEN 在保持适度参数数量的同时实现了卓越的性能，为交通道路场景人类视觉感知体验和目标检测准确率的提升提供一种有效的图像增强方案。

中国知网 https://www.cnki.net

第 4 章 基于双阶段增强的低质图像道路交通目标检测

4.1 引言

本文在第二章和第三章分别针对大多低质图像增强方法存在多尺度特征静态融合不充分和单一域特征信息不全面导致的模型适应性弱和表达能力受限的问题，给出了对应解决方案。这两章提出的方法 MFSN 和 HDEN 除了能有效提升人类视觉感知体验，对于提高道路交通场景中低质图像目标检测精度也有一定的帮助。然而，无论是 MFSN 还是 HDEN 都是采用像素损失来优化模型，以使所重建图像与 HR 图像在像素层面上尽可能相近。因此，这类 SR 方法主要是面向人类感知系统，而不是机器视觉。此外，SR 模型与检测器的训练过程是分别独立进行的，在推理阶段也只是简单地将经 SR 网络增强后的图像输入到检测器中进行检测。基于以上两个原因，前两章所提出的方法在重建图像时可能难以有效恢复有利于后续检测任务的判别特征，从而限制了其对道路交通场景低质图像目标检测精度的进一步提升。

解决道路交通场景下低质图像目标检测准确率低的问题，除了上述这类先 SR 再检测的方法（统称为独立增强方法），还有一种更简单直接的重训练方法：在低质图像数据集上重新训练目标检测模型。由于低质图像丢失大量细节和纹理结构等重要信息，检测器在直接提取判别特征进行检测方面面临重大挑战。考虑到这个问题，一些学者开发了一种联合增强和目标检测方法 FDSR[67]，通过级联 SR 模型和特定检测器来构建联合框架。与独立增强方法将图像增强和检测分开处理的方式不同，FDSR 通过使用任务损失来联合训练图像 SR 网络和目标检测器，以此提升目标检测精度。然而，FDSR 采用大尺寸 SR 网络 DBPN[68]来进行预增强，这给整个低质图像目标检测框架带来繁重的计算负担并大大降低了模型运行速度，显然并不适用于实际应用场景。为了克服这个挑战，一些研究人员开发了另一种联合增强和目标检测方法 AERIS[71]。该方法虽然没有直接级联图像 SR 和检测模型，但其采用的多任务学习策略，可以在检测器中同时执行 SR 重建和目标检测任务。然而，与重训练方法类似，AERIS 也存在难以从有用信息大量丢失的低质图像中学习准确判别特征的问题。

为了解决以上问题，本章提出一种新颖的双阶段增强方法 TELOD（Two-stage Enhancement method for Low-quality Object Detection），以切实有效地提高低质图像道路交通目标检测精度。在 TELOD 中，第一阶段和第二阶段分别用于图像层和特征层增强。

在第一阶段，提出了一个仅有 0.01 M 参数的超轻量级任务分解增强网络

中国知网 https://www.cnki.net

（Task Disentanglement Enhancement Network，TDEN），来对具有各种退化类型和任意比例因子的低质图像进行图像域增强。为了降低复杂降质带来的图像重建挑战，TDEN 将总的图像增强任务分解为图像复原和分辨率增强两个子任务，并采用图像复原分支（Image Restoration Branch，IRB）和分辨率增强分支（Resolution Enhancement Branch，REB）来依次执行。在 TDEN 中，特别在 IRB 和 REB 之间使用一个共享特征提取器，以从两个子任务的相关性中学习域不变的潜在特征表示。值得一提的是，在道路交通场景图像中，通常存在不同类型的目标，它们具有不同的形状和纹理特征且尺寸大小差异显著。为了更灵活地从这复杂场景中提取特征的同时不引入过多计算负担，共享特征提取器的核心采用的是第二章提出的 MFSB 模块而不是第三章提出的 HDEM 模块。为了得到便于检测的 SR 结果，TDEN 在训练阶段不仅采用了像素损失，还额外引入目标检测任务损失进行联合优化。

在第二阶段，检测器中引入辅助特征增强头（Auxiliary Feature Enhancement Head，AFEH）进行特征域增强，以进一步缩小从 SR 图像与对应 HR 图像中提取的检测特征之间的域间隙。为了更好地增强对检测有益的特征内在视觉结构，额外采用一个预训练特征提取器从 HR 图像中提取先验信息，以用作指导 AFEH 学习的标签特征。在 AFEH 中，为进一步改善检测特征，构建了一个特征交互模块（Feature Interaction Module，FIM），通过交叉注意力的方式将 TDEN 中的低层增强特征和检测器的高层检测特征整合在一起。通过利用低层增强特征提供的空间线索，可以帮助高层检测特征恢复更详细的结构信息，从而提高目标检测精度。值得注意的是，AFEH 犹如火箭助推器，只在训练期间使用，在推理期间移除，避免了额外计算成本和参数的引入。

总的来说，本章的主要创新点和贡献如下：

1） 提出一种名为 TDEN 的超轻量级且面向检测的 SR 子网络，用以处理具有不同退化类型和任意比例因子的低质图像。为了降低复合降质因素带来的图像重建挑战，TDEN 内建了一个带有共享特征提取器的双分支结构以执行任务分解增强策略。在共享特征提取器中，采用第二章方法的核心模块 MFSB 来高效增强不同尺寸不同类型目标的特征。

2） 通过引入 HR 图像先验作为指导，提出了一种 AFEH 实现特征层增强，以进一步增强检测特征。为了探索更多有利于检测的综合线索，设计了 FIM 并将其集成到 AFEH 中，以促进增强和检测阶段之间的特征互动。值得注意的是，AFEH 并不会给整体框架引入额外参数和推理成本。

3） 通过将 TDEN 和 AFEH 集成到一个通用检测器中，可以得到一种有效的双阶段增强检测框架 TELOD。与其他方法相比，TELOD 仅引入较低的

中国知网 https://www.cnki.net

参数和计算复杂度就能实现最优的低质图像目标检测性能。

4.2 基于双阶段增强的低质图像道路交通目标检测方法

4.2.1 基于双阶段增强的低质图像道路交通目标检测框架

针对实际道路交通场景下低质图像由于细节、纹理等重要特征信息的丢失，导致目标检测准确率低的问题，本章提出了一种新型基于双阶段增强的低质图像道路交通目标检测方法 TELOD，其总体结构如图 4-1 所示。TELOD 主要包含三个部分，分别为 TDEN、通用检测器和 AFEH。其中，TDEN 和 AFEH 分别在第一和第二阶段负责图像层和特征层的增强，而检测器可以是任意检测器，如 CenterNet[138]和 YOLOv7[61]等。在本章中，无特殊说明，都默认采用 CenterNet 作为基础检测器。

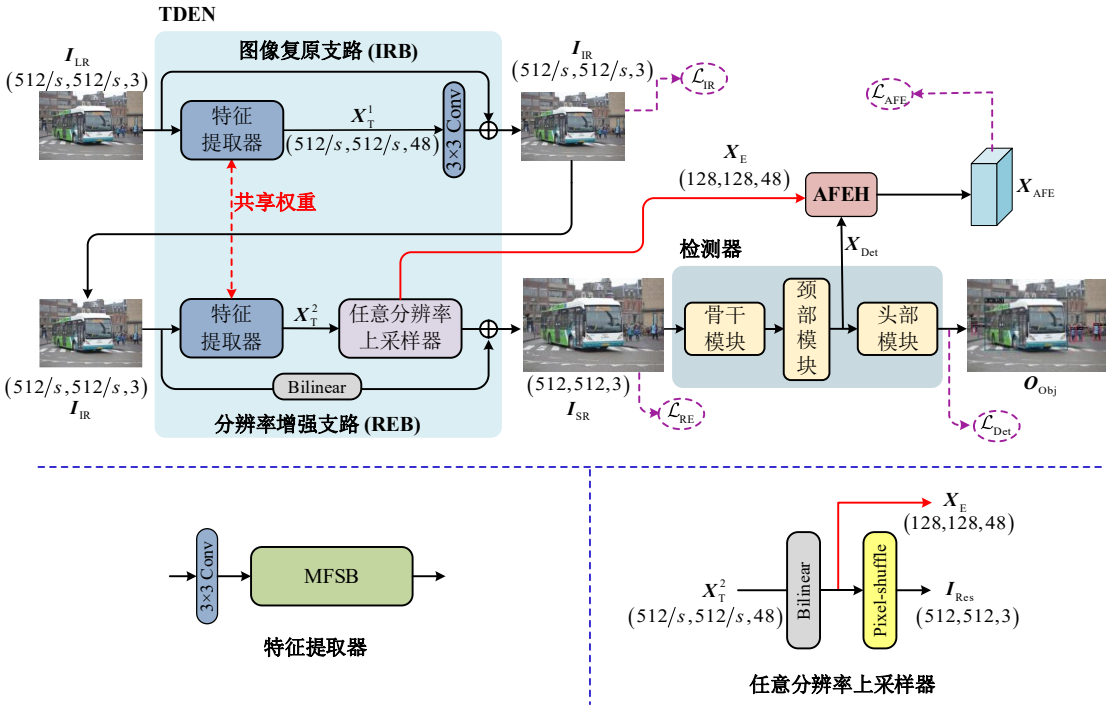


图 4-1 TELOD 总体网络结构

一般来说，基于视觉的任务（如目标检测）需要依赖图像的结构和纹理信息来提取特定特征[67]。然而，低质图像缺乏许多重要的细节和纹理，导致目标可用特征线索减少，从而给后续检测任务带来较大挑战。特别是在道路交通场景中，降质因素并不唯一，低质图像可能存在多种降质如噪声和模糊混合的情况，这会进一步加剧目标检测的难度。因此，为避免检测器直接从低质图像中提取到无效特征，在第一阶段，设计了一个 TDEN 来对低质图像预先进行增强。值得一提的是，TDEN 通过采用任务分解增强策略，可以处理包含不同混合降质的低质图

中国知网　https://www.cnki.net

像，且仅消耗约 0.01 M 参数。此外，引入的任意分辨率上采样器也支持 TDEN 对任意比例因子的低质图像进行分辨率增强。TDEN 的详细结构将展示在 4.2.2 节中。在完成第一阶段图像层增强后，为进一步改进从增强图像中提取到的检测特征，在检测器颈部处应用 AFEH 来进行特征层增强。AFEH 能通过引入 HR 图像特征先验作为指导，并辅以 FIM 促进增强网络和检测器之间信息的交互，以有效完善检测特征的表达能力。需要注意的是，AFEH 只参与模型训练的过程，在测试期间会被弃用，因此并不会引入额外的参数和计算负担。AFEH 的详细结构将展示在 4.2.3 节中。

事实上，TELOD 的两个阶段增强都旨在缩小从 LR 图像和 HR 图像中提取到的检测特征之间的域差距，而非直接缩小 LR 图像与 HR 图像在像素层面上的差异。首先，第一阶段的 TDEN 旨在提升 LR 图像的检测精度，而不是生成在视觉上尽可能接近 HR 图像的 SR 图像。换言之，TDEN 重建的图像更关注机器视觉的感知效果，而非人类视觉系统。因此，从 TDEN 输出的 SR 图像中提取到的检测特征，更接近于从 HR 图像中提取的检测特征。其次，第二阶段的增强是在第一阶段的基础上进一步执行的，其核心目标是通过引入 AFEH 模块对检测特征进行强化，从而进一步缩小 SR 图像和 HR 图像在检测特征层面上的差异。总的来说，通过依次执行两个阶段增强，TELOD 能够实现对低质图像的高效检测。

4.2.2 基于任务分解策略的图像增强网络

对受多种降质因素如模糊、噪声以及不同比例因子下采样影响的低质图像进行增强，通常需要同步处理图像复原和分辨率增强问题。显然，这种联合增强问题比单独增强问题更具挑战性[141]。因此，为了降低复合降质情况下图像增强的难度，本小节提出一种名为 TDEN 的超轻量级的图像增强子网络，将整个图像增强任务分解成图像复原和分辨率增强两个子任务，并按顺序执行。TDEN 的具体结构如图 4-1 所示，其中 IRB 和 REB 分别负责图像复原和分辨率增强子任务；“Bilinear”是指 Bilinear 插值操作；“Pixel-shuffle”表示像素洗牌操作；“MFSB”为第二章方法 MFSN 的核心构建模块。如图 4-1 所示，在 TDEN 中，首先执行的是图像复原，而不是分辨率增强子任务，主要是为了避免放大低质图像中的有害信息（如模糊和噪声）和引入昂贵的计算成本。值得注意的是，IRB 和 REB 并没有进行简单级联，而是以递归的方式进行连接，并共享同一个配备有 3×3 卷积层和 MFSB 的特征提取器，以有效探索它们之间的依赖关系。在共享特征提取器中，采用的是第二章提出的 MFSB 而不是第三章提出的 HDEM 模块。主要是考虑到交通道路场景包含多种类型目标如汽车、自行车、行人、交通标志等，且通常存在复杂的背景如道路、建筑物、树木和广告牌等。通过使用 MFSB 细

中国知网 https://www.cnki.net

粒度多尺度特征提取和动态融合能力，能有效增强不同尺度下目标的特征，同时减少背景的干扰。此外，相比 HDEM，MFSB 具有更低的计算负担和参数，更适合作为预增强网络的核心模块。为了解决任意比例因子下的 LR 图像上采样问题，在 TDEN 的尾部构建一个任意分辨率上采样器，以此重构最终的 SR 图像。

图 4-2 进一步展示了简单级联和递归连接方式之间的区别。在子图 4-2 (b)中，以 3 次迭代的情况为例说明递归连接方式的工作原理，其中 $\boldsymbol{I}_{\mathrm{IR}}^{t}$（$t \in \{1,2,3\}$）表示第 t 个中间复原图像。从子图 4-2 (a)中可以看到，LR 图像 $\boldsymbol{I}_{\mathrm{LR}} \in \mathbb{R}^{512/s \times 512/s \times 3}$（$s$ 为采样率）输入到 IRB 进行处理，得到中间复原图像 $\boldsymbol{I}_{\mathrm{IR}} \in \mathbb{R}^{512/s \times 512/s \times 3}$ 后进一步输入到 REB 中，产生 SR 图像 $\boldsymbol{I}_{\mathrm{SR}} \in \mathbb{R}^{512 \times 512 \times 3}$。其中，IRB 和 REB 在结构上是互相独立的，且它们的特征提取器分别仅从 $\boldsymbol{I}_{\mathrm{LR}}$ 和 $\boldsymbol{I}_{\mathrm{IR}}$ 中提取特征。与简单的级联方式不同，子图 4-2 (b)所展示的递归连接方式，通过采用共享特征提取器，可以把 IRB 和 REB 更紧密地联系在一起。与简单级联相比，递归学习结构主要有两方面好处：第一，递归连接允许网络利用 IRB 和 REB 之间的任务相关性促进图像的有效增强。此外，共享特征提取器能从输入 LR 图像和中间复原图像中学习共同而准确的潜在特征表示，从而改善模型的泛化能力。这是因为共享权重的循环利用类似于多次使用数据来学习网络的参数。从本质上讲，这种方法等同于采用不同退化图像（$\boldsymbol{I}_{\mathrm{LR}}$ 和中间多层复原图像 $\left\{\boldsymbol{I}_{\mathrm{IR}}^{t}\right\}$ 可以认为是不同退化类型下的图像）进行数据增强；第二，递归连接可以进一步节省预增强子网络的参数数量，保证其超轻量化特性。

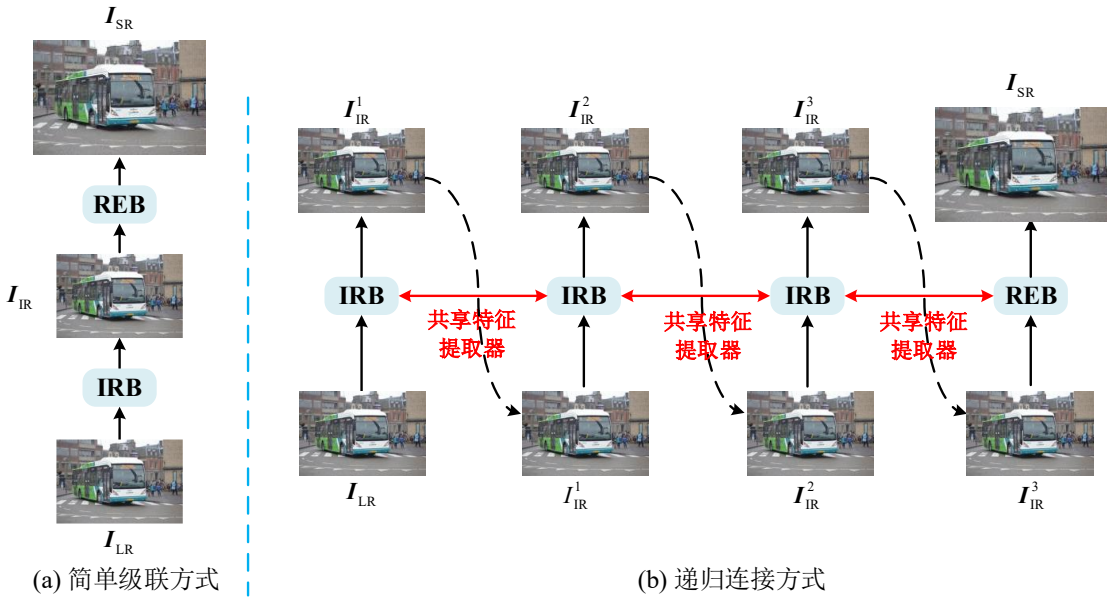


图 4-2 TDEN 不同连接方式示意图

由于 IRB 和 REB 分别负责的是图像复原和分辨率增强子任务，所以它们的

中国知网 https://www.cnki.net

最终任务目的并不一样。考虑到这个问题，在 IRB 和 REB 进行最后图像重建时，分别创建 1 个3×3 卷积层和 1 个任意分辨率上采样器。具体来说。IRB 的任务目标是恢复干净的图像，而不是改变图像的分辨率。因此，在 IRB 的尾部仅需采用 1 个简单3×3 卷积将特征 $\boldsymbol{X}_{\mathrm{T}}^{1} \in \mathbb{R}^{512/s \times 512/s \times 48}$ 的通道数量从 48 降低到 3 即可。而 REB 的任务目标是增强图像细节并提高图像分辨率，且由于采样率 s 并不是固定值，因此 REB 无法采用传统 SR 方法常用的固定比例上采样器如反卷积层来进行 SR 图像重构。为了解决这个问题，本小节提出一种任意分辨率上采样器，其主要由 Bilinear 层和像素洗牌（Pixel-Shuffle）层[125]组成。如图 4-1 所示，在 REB 中，用 Bilinear 对任意分辨率特征 $\boldsymbol{X}_{\mathrm{T}}^{2} \in \mathbb{R}^{512/s \times 512/s \times 48}$ 进行插值，可以得到固定分辨率的特征 $\boldsymbol{X}_{\mathrm{E}} \in \mathbb{R}^{128 \times 128 \times 48}$，而像素洗牌层则是用于进一步将 $\boldsymbol{X}_{\mathrm{E}}$ 上采样为残差图像 $\boldsymbol{I}_{\mathrm{Res}} \in \mathbb{R}^{512 \times 512 \times 3}$。此外，$\boldsymbol{I}_{\mathrm{IR}}$ 经 Bilinear 层处理后通过跳跃连接与 $\boldsymbol{I}_{\mathrm{Res}}$ 相加，形成最终的 $\boldsymbol{I}_{\mathrm{SR}}$。值得注意的是，无论是 Bilinear 层还是像素洗牌层，都不需要引入额外的参数。

4.2.3 高分辨率先验引导的特征增强模块

为了进一步缩小 SR 图像和 HR 图像检测特征之间的域差距，在检测器中引入 AFEH，以辅助学习的方式改进特定任务特征的表达能力。在 AFEH 中，有两个关键设计：第一，引入 HR 图像先验知识助力检测特征进一步细化。HR 图像可以提供检测器所依赖丰富的结构和纹理信息。为有效利用这些先验信息，额外采用一个预训练好的特征提取器如 VGG16[142]来提取 HR 图像中的先验特征。通过使用 HR 先验信息作为指导，检测器可以有效改进检测任务所关注的特征；第二，探索更全面的信息帮助检测器学习稳健的特征表示。一方面，由于 TDEN 是通过联合像素损失和检测损失训练得到，所以从 TDEN 中所提取的底层增强特征包含丰富且对检测友好的空间信息。另一方面，重建的 SR 图像经过检测器的骨干网络时，连续的池化（Pooling）操作，使得用于最终检测的高层特征的空间信息丢失严重。基于以上两点考虑，创新性地在 AFEH 中构建 FIM，通过采用跨注意力方式引入底层增强特征，以辅助高层检测特征恢复更详细的空间信息，从而进一步提升模型检测精度。

图 4-3 展示了 AFEH 的具体结构。其中，“特征分割”和“特征级联”分别表示通道切分和级联操作。从图 4-3 中可以看到，AFEH 主要由 1 个 Bilinear 层、1 个3×3 卷积层、1 个 FIM、2 个带层归一化（Layer Normalization，LN）[143]的残差单元和 1 个1×1 卷积层构成。AFEH 接收 2 个输入特征，包括来自 TDEN 的增强特征 $\boldsymbol{X}_{\mathrm{E}}$ 和来自检测器颈部输出的检测特征 $\boldsymbol{X}_{\mathrm{Det}}$。为了方便后续整合这两个特征，依次采用 Bilinear 层和3×3 卷积层对 $\boldsymbol{X}_{\mathrm{Det}}$ 进行空间和通道维度的调整，以

中国知网 https://www.cnki.net

保证调整后的特征 $\boldsymbol{X}_{\mathrm{G}}$ 与 $\boldsymbol{X}_{\mathrm{E}}$ 具有相同的维度。通过将 $\boldsymbol{X}_{\mathrm{G}}$ 和 $\boldsymbol{X}_{\mathrm{E}}$ 一起输入到 FIM，可以得到融合特征 $\boldsymbol{X}_{\mathrm{B}}$。其中，FIM 由多头转置交叉注意力（Multi-head Transposed Cross-attention，MTCA）和门控深度卷积前馈网络（Gated-Dconv Feed-forward Network，GDFN）[144]组成。$\boldsymbol{X}_{\mathrm{B}}$ 可由以下公式表示：

$$\boldsymbol{X}_{\mathrm{B}}=\mathcal{F}_{\mathrm{FIM}}\left(\boldsymbol{X}_{\mathrm{G}},\boldsymbol{X}_{E}\right)=\mathcal{F}_{\mathrm{GDFN}}\left(\mathcal{F}_{\mathrm{MTCA}}\left(\boldsymbol{X}_{\mathrm{G}},\boldsymbol{X}_{\mathrm{E}}\right)\right) \tag{4-1}$$

其中，$\mathcal{F}_{\mathrm{FIM}}(\cdot)$、$\mathcal{F}_{\mathrm{MTCA}}(\cdot)$ 和 $\mathcal{F}_{\mathrm{GDFN}}(\cdot)$ 分别定义为 FIM、MTCA 和 GDFN 函数。在 FIM 之后，采用两个带有 LN 的残差单元进一步细化 $\boldsymbol{X}_{\mathrm{B}}$，并采用跳跃连接将 $\boldsymbol{X}_{\mathrm{G}}$ 传输到尾部与最终细化特征进行逐像素相加，以促进 AFEH 内信息的流动。最后，使用1×1卷积层调整特征通道维度，以获得 AFEH 的输出特征 $\boldsymbol{X}_{\mathrm{AFE}}$。

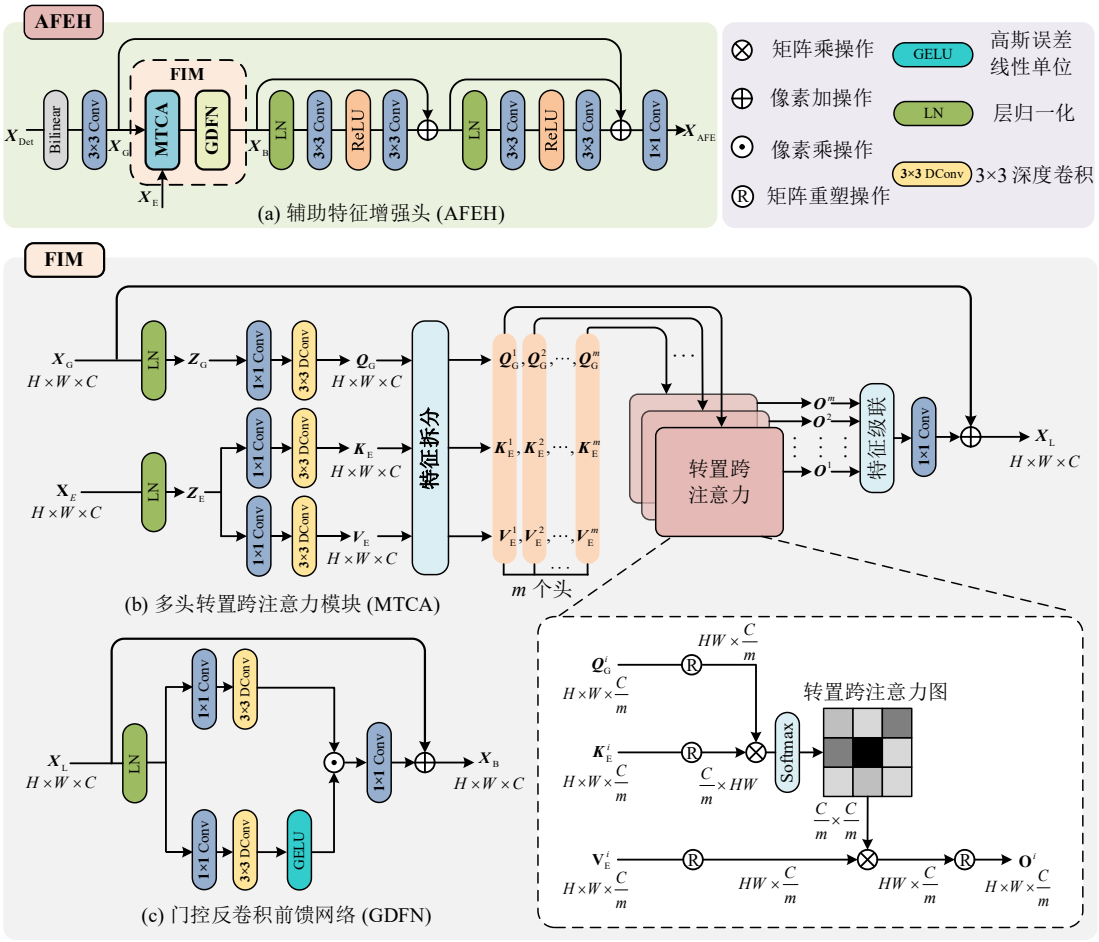


图 4-3 AFEH 的结构

为深入整合增强和检测特征，MTCA 引入了 Transformers 思想。需要注意的是，与用于计算自注意力的传统 Transformers[120,145]不同，所提出的 MTCA 是基于交叉注意力机制的。具体来说，首先将检测特征投影到查询（Query，Q）上，同时将增强特征分别投影到键（Key）和值（Value）上。投影操作是通过 1 个1×1

中国知网 https://www.cnki.net

卷积和 1 个3×3 深度卷积来实现，分别用于执行通道上下文像素聚合和局部上下文通道聚合。然后，通过计算查询和键之间的跨通道交叉协方差，可以生成转置交叉注意力图。该图隐含了增强特征和检测特征之间的全局上下文相关性。通过进一步将该图应用于值，可以分别强调和抑制增强特征中检测相关和检测无关的信息。最后，将加权后增强特征与输入检测特征相加，得到具有更强判别能力的融合特征。

如图 4-3 所示。MTCA 以 $\boldsymbol{X}_{\mathrm{G}} \in \mathbb{R}^{H \times W \times C}$ 和 $\boldsymbol{X}_{\mathrm{E}} \in \mathbb{R}^{H \times W \times C}$ 作为输入，通过执行 LN 可以生成特征 $\boldsymbol{Z}_{\mathrm{G}} \in \mathbb{R}^{H \times W \times C}$ 和 $\boldsymbol{Z}_{\mathrm{E}} \in \mathbb{R}^{H \times W \times C}$，其中 H、W 和 C 分别为特征图的高度、宽度和通道数。然后，用 $\mathcal{F}_{\mathrm{d}}^{\mathrm{Q}}\left(\mathcal{F}_{\mathrm{p}}^{\mathrm{Q}}\left(\cdot\right)\right)$ 对 $\boldsymbol{Z}_{\mathrm{G}}$ 投影，得到 $\boldsymbol{Q}_{\mathrm{G}} \in \mathbb{R}^{H \times W \times C}$。同时，利用 $\mathcal{F}_{\mathrm{d}}^{\mathrm{K}}\left(\mathcal{F}_{\mathrm{p}}^{\mathrm{K}}\left(\cdot\right)\right)$ 和 $\mathcal{F}_{\mathrm{d}}^{\mathrm{V}}\left(\mathcal{F}_{\mathrm{p}}^{\mathrm{V}}\left(\cdot\right)\right)$ 对 $\boldsymbol{Z}_{\mathrm{E}}$ 投影，可以分别得到 $\boldsymbol{K}_{\mathrm{E}} \in \mathbb{R}^{H \times W \times C}$ 和 $\boldsymbol{V}_{\mathrm{E}} \in \mathbb{R}^{H \times W \times C}$。其中，$\mathcal{F}_{\mathrm{p}}^{(\cdot)}\left(\cdot\right)$ 和 $\mathcal{F}_{\mathrm{d}}^{(\cdot)}\left(\cdot\right)$ 分别表示1×1 卷积和3×3 深度卷积。为了捕捉不同层次的特征，与传统的多头（Head）自注意力机制一样，MTCA 也将特征划分为多个头来并行学习不同特征空间下的注意力图。为此，分别沿通道维度对 $\boldsymbol{Q}_{\mathrm{G}}$、$\boldsymbol{K}_{\mathrm{E}}$ 和 $\boldsymbol{V}_{\mathrm{E}}$ 进行特征切割操作，生成 m 个头特征（如图 4-3 中橙色标记区域所示），然后在这些头特征上并行执行转置交叉注意力，以获得一系列加权特征 $\left\{\boldsymbol{O}^{i} \in \mathbb{R}^{H \times W \times C/m}\right\}$，$i=1,2,\cdots,m$。在本章中，$m$ 统一设为 8。通过对 $\left\{\boldsymbol{O}^{i} \in \mathbb{R}^{H \times W \times C/m}\right\}$ 进行通道拼接，然后采用1×1 卷积执行特征转换，所得特征再与 $\boldsymbol{X}_{\mathrm{G}}$ 逐像素相加，可以得到 MTCA 的输出 $\boldsymbol{X}_{\mathrm{L}} \in \mathbb{R}^{H \times W \times C}$。MTCA 的计算过程可由以下公式表示：

$$\boldsymbol{X}_{\mathrm{L}} = \mathcal{F}_{\mathrm{MTCA}}\left(\boldsymbol{X}_{\mathrm{G}}, \boldsymbol{X}_{\mathrm{E}}\right) = \mathcal{F}_{\mathrm{p}}\left(\mathcal{F}_{\mathrm{Concat}}\left(\boldsymbol{O}^{1}, \boldsymbol{O}^{2}, \ldots, \boldsymbol{O}^{m}\right)\right) + \boldsymbol{X}_{\mathrm{G}} \tag{4-2-a}$$

$$\boldsymbol{O}^{i} = \mathcal{F}_{\mathrm{Attention}}\left(\boldsymbol{Q}_{\mathrm{G}}^{i}, \boldsymbol{K}_{\mathrm{E}}^{i}, \boldsymbol{V}_{\mathrm{E}}^{i}\right) = \mathcal{F}_{\mathrm{r}}\left(\boldsymbol{V}_{\mathrm{E}}^{i}\right) \cdot \mathcal{F}_{\sigma}\left(\mathcal{F}_{\mathrm{r}}\left(\boldsymbol{K}_{\mathrm{E}}^{i}\right) \cdot \mathcal{F}_{\mathrm{r}}\left(\boldsymbol{Q}_{\mathrm{G}}^{i}\right) / \omega\right) \tag{4-2-b}$$

式中，$\mathcal{F}_{\mathrm{MTCA}}\left(\cdot\right)$ 为 MTCA 函数；$\mathcal{F}_{\mathrm{Concat}}\left(\cdot\right)$ 表示通道级联操作；$\mathcal{F}_{\mathrm{Attention}}\left(\cdot\right)$ 表示转置跨注意力函数；$\boldsymbol{Q}_{\mathrm{G}}^{i} \in \mathbb{R}^{H \times W \times C/m}$、$\boldsymbol{K}_{\mathrm{E}}^{i} \in \mathbb{R}^{H \times W \times C/m}$ 和 $\boldsymbol{V}_{\mathrm{E}}^{i} \in \mathbb{R}^{H \times W \times C/m}$ 分别是 $\boldsymbol{Q}_{\mathrm{G}}$、$\boldsymbol{K}_{\mathrm{E}}$ 和 $\boldsymbol{V}_{\mathrm{E}}$ 的第 i 个头特征；$\mathcal{F}_{\mathrm{r}}\left(\cdot\right)$ 定义为矩阵重塑操作；$\mathcal{F}_{\sigma}\left(\cdot\right)$ 表示 Softmax 函数；ω 是一个可学习参数，用于控制 $\mathcal{F}_{\mathrm{r}}\left(\boldsymbol{K}_{\mathrm{E}}^{i}\right)$ 和 $\mathcal{F}_{\mathrm{r}}\left(\boldsymbol{Q}_{\mathrm{G}}^{i}\right)$ 的内积大小。

在经过注意力计算步骤之后，传统的 Transformer 通常会使用携带 2 个1×1 卷积层的前馈网络（Feed-forward Network）[110,120]来进一步变换特征。然而，仅仅使用1×1 卷积并不能提供足够的变换能力。为了进一步提高交互特征 $\boldsymbol{X}_{\mathrm{L}}$ 的表示能力，采用 GDFN[144]而不是传统的前馈网络来控制通过 FIM 的信息流，以达到抑制无用特征并提高信息传输效率的目的。GDFN 可由以下公式表示：

$$\boldsymbol{X}_{\mathrm{B}} = \mathcal{F}_{\mathrm{p}}^{1}\left(\mathcal{F}_{\mathrm{g}}\left(\boldsymbol{X}_{\mathrm{L}}\right)\right) + \boldsymbol{X}_{\mathrm{L}} \tag{4-3-a}$$

$$\mathcal{F}_{\mathrm{g}}\left(\boldsymbol{X}_{\mathrm{L}}\right) = \mathcal{F}_{\mathrm{d}}^{2}\left(\mathcal{F}_{\mathrm{p}}^{2}\left(\mathcal{F}_{\mathrm{LN}}\left(\boldsymbol{X}_{\mathrm{L}}\right)\right)\right) \odot \mathcal{F}_{\delta}\left(\mathcal{F}_{\mathrm{d}}^{3}\left(\mathcal{F}_{\mathrm{p}}^{3}\left(\mathcal{F}_{\mathrm{LN}}\left(\boldsymbol{X}_{\mathrm{L}}\right)\right)\right)\right) \tag{4-3-b}$$

其中 $\boldsymbol{X}_{\mathrm{B}}$ 和 $F_{\mathrm{g}}\left(\cdot\right)$ 分别定义为 FIM 的输出特征和门控（Gating）函数；$F_{\mathrm{LN}}\left(\cdot\right)$ 表示

中国知网 https://www.cnki.net

LN 层[143]；$\odot$ 和 $\mathcal{F}_{\delta}(\cdot)$ 分别表示像素层面的乘法操作和高斯误差线性单元（Gaussian Error Linear Unit，GELU）[146]。

4.2.4 损失函数和训练策略

在模型训练过程中，采用图像域和特征域双阶段增强策略来训练本章提出的 TELOD 算法。具体来说，在第一阶段，将 TDEN 和检测器进行级联，并以端到端的方式进行训练。为了保证 TDEN 中 IRB 和 REB 能分别执行各自任务，引入了任务分解损失（Task Disentanglement Loss，TDL）来监督这两个分支的训练。除了 TDL 之外，检测损失也用于 TDEN 的训练，以保留图像中有利于检测任务的判别特征。为了减少训练时间并加速模型收敛，使用在 HR 图像数据集上训练后的检测模型权重来对检测器进行初始化。

（1）第一阶段损失函数

第一阶段的损失函数 $\mathcal{L}_{\mathrm{S1}}$ 可由如下公式表示：

$$\mathcal{L}_{\mathrm{S1}} = \mathcal{L}_{\mathrm{TD}} + \mathcal{L}_{\mathrm{Det}} \tag{4-4-a}$$

$$\mathcal{L}_{\mathrm{TD}} = \mathcal{L}_{\mathrm{IR}} + \mathcal{L}_{\mathrm{RE}} \tag{4-4-b}$$

式中，$\mathcal{L}_{\mathrm{TD}}$ 是 TDL 损失函数，其包含分别用来监督 IRB 和 REB 训练的图像复原损失函数 $\mathcal{L}_{\mathrm{IR}}$ 和分辨率增强损失函数 $\mathcal{L}_{\mathrm{RE}}$；$\mathcal{L}_{\mathrm{Det}}$ 表示检测损失函数。

虽然 TELOD 能适用于不同检测器，但本章主要以 CenterNet 作为基础检测器来进行说明，因此 $\mathcal{L}_{\mathrm{Det}}$ 表示的是 CenterNet 所采用的检测损失函数，其可由以下公式表示：

$$\mathcal{L}_{\mathrm{Det}} = \lambda_{\mathrm{heat}}\mathcal{L}_{\mathrm{heat}} + \lambda_{\mathrm{off}}\mathcal{L}_{\mathrm{off}} + \lambda_{\mathrm{size}}\mathcal{L}_{\mathrm{size}} \tag{4-5}$$

式中，$\mathcal{L}_{\mathrm{heat}}$、$\mathcal{L}_{\mathrm{off}}$ 和 $\mathcal{L}_{\mathrm{size}}$ 分别表示中心点热力图损失、中心点偏移损失和目标尺寸损失；λ_{heat}、λ_{off} 和 λ_{size} 分别为这三个损失的权重系数。在本章中，这三个系数分别设置为 1、1 和 0.1。

中心点热力图损失 $\mathcal{L}_{\mathrm{heat}}$ 作为 CenterNet 损失函数的核心部分，主要用于预测目标的中心坐标。对于每个目标类别，网络输出一个对应的热力图，其中每个像素值代表以该位置为目标中心点的概率。$\mathcal{L}_{\mathrm{heat}}$ 采用的是高斯焦点损失（Gaussian Focal Loss），可以由以下公式表达：

$$\mathcal{L}_{\mathrm{heat}} = -\frac{1}{N_{\mathrm{obj}}}\sum_{xyc=1}^{N_{\mathrm{obj}}}\begin{cases}\left(1-\tilde{Y}_{xyc}\right)^{\gamma}\log\left(\tilde{Y}_{xyc}\right) & \text{若}\ \bar{Y}_{xyc}=1\\ \left(1-\bar{Y}_{xyc}\right)^{\tau}\left(\tilde{Y}_{xyc}\right)^{\gamma}\log\left(1-\tilde{Y}_{xyc}\right) & \text{否者}\end{cases} \tag{4-6}$$

式中，$\tilde{Y}_{xyc}$ 和 $\bar{Y}_{xyc}$ 分别为网络预测值和真实标签；γ 和 τ 分别为焦点损失的超参数，

中国知网 https://www.cnki.net

用于平衡正负样本和难易样本的权重，其默认为 2 和 4；N_{obj} 为图像中目标数量。

由于网络在特征提取过程中采用的降采样步骤会导致中心点坐标精度的损失，因此需要引入中心点偏移损失 $\mathcal{L}_{\text{off}}$ 来修正目标中心点位置的偏差。$\mathcal{L}_{\text{off}}$ 主要采用 L1 损失，其可以由如下公式表示：

$$\mathcal{L}_{\text{off}}=\frac{1}{N_{\text{obj}}}\sum_{\bar{p}}\left\|\hat{O}_{\tilde{p}}-\left(\frac{\bar{p}}{R}-\tilde{p}\right)\right\|_1 \tag{4-7}$$

式中，$\bar{p}$ 和 $\tilde{p}$ 分别为图像中目标真实的中心点坐标和预测的中心点坐标。R 为输出的下采样步幅。$\hat{O}_{\tilde{p}}$ 为网络预测的偏移量，仅对正样本进行损失计算。$\|\cdot\|_1$ 表示 L1 范数

尺寸损失函数 $\mathcal{L}_{\text{size}}$ 主要用来预测目标的宽和高，用于还原目标的真实边界框。由于已经存在预测的中心点坐标，因此只需要再对目标宽高尺寸信息进行估计，则可以实现目标的定位。$\mathcal{L}_{\text{size}}$ 主要采用 L1 损失来实现，可以通过以下公式表示：

$$\mathcal{L}_{\text{size}}=\frac{1}{N_{\text{obj}}}\sum_{i=1}^{N_{\text{obj}}}\left\|\hat{S}_{pi}-\bar{S}_i\right\|_1 \tag{4-8}$$

式中，$\hat{S}_{pi}$ 为网络预测目标的宽和高；$\bar{S}_i$ 为目标真实的宽和高。

通过定义第 j 个 HR 图像和对应的 LR 图像为 $\boldsymbol{I}_{\text{HR}}^{j}$ 和 $\boldsymbol{I}_{\text{LR}}^{j}$。$\mathcal{L}_{\text{IR}}$ 和 $\mathcal{L}_{\text{RE}}$ 分别由以下公式计算得到：

$$\mathcal{L}_{\text{IR}}=\frac{1}{\mathcal{B}}\sum_{j=1}^{\mathcal{B}}\left\|\mathcal{F}_{\text{IRB}}(\boldsymbol{I}_{\text{LR}}^{j})-\mathcal{F}_{\text{Bic}}\left(\boldsymbol{I}_{\text{HR}}^{j}\right)\right\|_1 \tag{4-9-a}$$

$$\mathcal{L}_{\text{RE}}=\frac{1}{\mathcal{B}}\sum_{j=1}^{\mathcal{B}}\left\|\mathcal{F}_{\text{REB}}(\boldsymbol{I}_{\text{IR}}^{j})-\boldsymbol{I}_{\text{HR}}^{j}\right\|_1 \tag{4-9-b}$$

其中，$\mathcal{B}$ 定义为批次大小；$\boldsymbol{I}_{\text{IR}}^{j}$ 为第 j 个由 IRB 得到的中间复原图像；$\mathcal{F}_{\text{IRB}}(\cdot)$ 和 $\mathcal{F}_{\text{REB}}(\cdot)$ 分别表示 IRB 和 REB 函数；$\mathcal{F}_{\text{Bic}}(\cdot)$ 表示 Bicubic 操作，主要用来对 $\boldsymbol{I}_{\text{HR}}^{j}$ 插值，以此得到空间尺寸与 $\boldsymbol{I}_{\text{LR}}^{j}$ 一致的标签图像。

（2）第二阶段损失函数

在第二阶段，仍然将 TDEN 和检测器进行级联，并用第一阶段训练得到的预训练模型权重对级联后的网络进行初始化。此外，在训练过程中，会激活 AFEH 并冻结 TDEN 的权重。第二阶段的损失函数 $\mathcal{L}_{\text{S2}}$ 可由如下公式表示：

$$\mathcal{L}_{\text{S2}}=\mathcal{L}_{\text{AFE}}+\mathcal{L}_{\text{Det}} \tag{4-10}$$

式中，L_{AFE} 是辅助特征增强损失函数，由以下式子表示：

中国知网 https://www.cnki.net

$$\mathcal{L}_{\mathrm{AFE}}=\frac{1}{\mathcal{B}}\sum_{j=1}^{\mathcal{B}}\left\|\boldsymbol{X}_{\mathrm{AFE}}-\mathcal{F}_{\mathrm{Extractor}}\left(\boldsymbol{I}_{\mathrm{HR}}^{j}\right)\right\|_{1} \tag{4-11}$$

其中，$\boldsymbol{X}_{\mathrm{AFE}}$ 是 AFEH 的输出特征；$\mathcal{F}_{\mathrm{Extractor}}(\cdot)$ 定义为额外预训练特征提取器 VGG16 函数，用来提取 HR 图像先验并将其作为 $\boldsymbol{X}_{\mathrm{AFE}}$ 的标签，以辅助训练检测器。需要注意的是，AFEH 只在训练阶段使用，在测试阶段丢弃，因此，不会引入额外的参数和推理成本。

表 4-1 总结了本章提出的 TELOD 算法的实现过程。在第一阶段，首先将 $\boldsymbol{I}_{\mathrm{LR}}$ 输入到 TDEN 处理后，产生中间复原图像 $\boldsymbol{I}_{\mathrm{IR}}$ 和最终 SR 图像 $\boldsymbol{I}_{\mathrm{SR}}$，并将它们分别用于计算 $\mathcal{L}_{\mathrm{IR}}$ 和 $\mathcal{L}_{\mathrm{RE}}$。然后，将 $\boldsymbol{I}_{\mathrm{SR}}$ 传递给检测器，得到检测器输出 $\boldsymbol{O}_{\mathrm{Obj}}$，用于计算 $\mathcal{L}_{\mathrm{Det}}$。与第一阶段相比，第二阶段的训练过程主要有两个区别：第一，TDEN 和检测器分别额外输出中间特征 $\boldsymbol{X}_{\mathrm{E}}$ 和 $\boldsymbol{X}_{\mathrm{Det}}$，并将它们用作 AFEH 的输入，生成用于计算 $\mathcal{L}_{\mathrm{AFE}}$ 的特征 $\boldsymbol{X}_{\mathrm{AFE}}$；第二，由于 TDEN 处于冻结状态，所以 $\mathcal{L}_{\mathrm{IR}}$ 和 $\mathcal{L}_{\mathrm{RE}}$ 并不参与第二阶段 TELOD 的优化过程。

表 4-1 TELOD 算法流程

本章算法：TELOD
（1）第一阶段增强：
输入：$\boldsymbol{I}_{\mathrm{LR}}$、检测器函数 $\mathcal{F}_{\mathrm{Det}}(\cdot)$。
输出：$\boldsymbol{I}_{\mathrm{IR}}$、$\boldsymbol{I}_{\mathrm{SR}}$ 和检测器输出 $\boldsymbol{O}_{\mathrm{Obj}}$。
使用在 HR 图像数据集上训练得到的模型权重对检测器进行初始化；
TDEN 处理：$\boldsymbol{I}_{\mathrm{IR}}=\mathcal{F}_{\mathrm{IRB}}\left(\boldsymbol{I}_{\mathrm{LR}}\right)$、$\boldsymbol{I}_{\mathrm{SR}}=\mathcal{F}_{\mathrm{REB}}\left(\boldsymbol{I}_{\mathrm{IR}}\right)$；
检测器处理：$\boldsymbol{O}_{\mathrm{Obj}}=\mathcal{F}_{\mathrm{Det}}\left(\boldsymbol{I}_{\mathrm{SR}}\right)$。
（2）第二阶段增强：
输入：$\boldsymbol{I}_{\mathrm{LR}}$、检测器函数 $\mathcal{F}_{\mathrm{Det}}(\cdot)$ 和 AFEH 函数 $\mathcal{F}_{\mathrm{AFEH}}(\cdot)$。
输出：AFEH 输出 $\boldsymbol{X}_{\mathrm{AFE}}$ 和检测器输出 $\boldsymbol{O}_{\mathrm{Obj}}$。
用第一阶段预训练的相应模型权重初始化 TDEN 和检测器；
冻结 TDEN 权重；激活 AFEH；
TDEN 处理：$\boldsymbol{I}_{\mathrm{IR}}=\mathcal{F}_{\mathrm{IRB}}\left(\boldsymbol{I}_{\mathrm{LR}}\right)$、$\left(\boldsymbol{X}_{\mathrm{E}},\boldsymbol{I}_{\mathrm{SR}}\right)=\mathcal{F}_{\mathrm{REB}}\left(\boldsymbol{I}_{\mathrm{IR}}\right)$；
检测器处理：$\left(\boldsymbol{X}_{\mathrm{Det}},\boldsymbol{O}_{\mathrm{Obj}}\right)=\mathcal{F}_{\mathrm{Det}}\left(\boldsymbol{I}_{\mathrm{SR}}\right)$；
AFEH 处理：$\mathbf{X}_{\mathrm{AFE}}=\mathcal{F}_{\mathrm{AFEH}}\left(\mathbf{X}_{\mathrm{E}},\mathbf{X}_{\mathrm{Det}}\right)$。

4.3 实验结果与分析

4.3.1 数据集

（1）PSCAL VOC 数据集[147]（简称 VOC 数据集）

VOC 数据集是目标检测领域中一个具有重要影响力的标准数据集，始于 2005 年，是由欧盟资助的网络组织 PASCAL（Pattern Analysis Statical Modeling and Computational Learning）举办的 VOC（Visual Object Classes）挑战赛。该比赛旨

中国知网 https://www.cnki.net

在推动视觉对象的目标分类（Object Classification）、目标检测（Object Detection）和目标分割（Object Segmentation）等任务的相关研究。

VOC 数据集包含 20 类日常目标，如人、自行车、小车、公交车等。在 VOC 中，应用最广泛的是 VOC 2007 和 VOC 2012。这两个数据集都由三部分组成，分别为训练集（Train）、验证集（Val）和测试集（Test）。此外，还存在一种特殊集 Trainval，其由数据集 Train 和 Val 合并而得到。在很多前面相关工作中，为了使网络训练更加稳定且泛化性更好，会将 VOC 2007 Trainval 和 VOC 2012 Trainval 进一步合并以形成更大的训练集（称为 VOC Trainval）用于模型训练。因此，本章也将延续这种方式进行实验的训练和测试。表 4-2 汇总了这些数据集的具体信息。

表 4-2 PSCAL VOC 数据集具体信息汇总

数据集	Train 图像数	Val 图像数	Test 图像数	Trainval 图像数
VOC 2007	2501	2510	4952	5011
VOC 2012	5717	5823	11530	11540

（2）MS COCO 数据集[148]（简称 COCO 数据集）

MS COCO 数据集是于 2014 年由微软公司出资标注产生的，全称为 Microsoft Common Objects in Context。COCO 是一个大规模且用于目标检测、语义分割以及实例分割等任务的数据集。COCO 不仅计算机高层视觉学术领域中最受研究人员关注的比赛之一，在工业界其也得到了广泛的应用和认可。

COCO 具有比 VOC 更多的目标类别，共有 80 类，不仅包含了 VOC 中道路交通场景常见的目标类别，还额外增加交通标志相关的目标类别如交通信号灯、停车标志、停车收费表等。本章实验也采用了 COCO 数据集对模型性能进行评估。具体来说，采用 COCO 2017 Train 和 COCO 2017 Val 数据集分别进行训练和测试。表 4-3 汇总了 COCO 数据集的具体图像数。

表 4-3 COCO 数据集具体信息汇总

数据集	Train 图像数	Val 图像数	Test 图像数
COCO 2017	118287	5000	40670

4.3.2 实验设置

（1）数据预处理

在训练过程中，与 AERIS[71]一致，将 COCO 和 VOC 训练集图像统一调整为512×512 的固定空间大小，并将其作为 HR 图像。为了得到低质图像，采用公式（1-1）提供的降质模型来对以上数据集中的 HR 图像进行降质。具体来说，公式（1-1）中的模糊核 κ 是从各向同性和各向异性高斯核中随机选择的；采样

中国知网 https://www.cnki.net

率 s 和加性高斯噪声 η 分别从均匀分布 $U(1.0,4.0)$ 和 $U(0,25/255)$ 中随机挑选。由于采样率并不固定，因此生成的低质图像的空间分辨率是处于 128×128 到 512×512 之间。低质图像经 SR 模型重建后得到的图像空间分辨率最终恢复到 512×512。为便于区分 HR 图像数据集和降质后的图像数据集，本章将降质后的 VOC 和 COCO 数据集分别称为 VOC-L 和 COCO-L。

（2）模型参数配置

为验证 TELOD 的有效性，除特殊说明外，本章将 CenterNet[138]设置为基础检测器，同时将 ResNet18[82]作为检测器的骨干网络。TDEN 中的递归迭代数设为 1。此外，选择预训练好的 VGG16[142]作为附加的 HR 图像特征提取器，并根据经验选择 VGG16 中第三个特征提取块的输出作为 AFEH 输出特征的标签。

（3）模型训练细节

在训练过程中，优化器采用 SGD，其中动量（Momentum）和权重衰减（Weight Decay）参数分别设置为 0.9 和 0.0001。训练轮次总数和学习率分别设为 80 和 0.005。学习率将在模型训练到 40 和 70 个轮次时降低为原来的十分之一。TELOD 的每个阶段都采用相同学习策略进行训练。整个 TELOD 框架通过使用 MMDetection 工具箱[149]构建。在数据增强方面，采用随机裁剪和随机翻转的方法，以提升模型泛化能力。为了确保实验公正，所有模型都是采用 PyTorch 框架并在 4 个 NVIDIA GTX 1080Ti GPU 上进行分布式训练，其中每个 GPU 的批次大小设置为 16。

4.3.3 评价指标

（1）PASCAL VOC 的评价指标

VOC 2007 的评价指标采用的是平均精度（mean Average Precision，mAP）。计算 mAP 需要先计算交并比（Intersection over Union，IoU），其可以由以下公式表示：

$$\mathrm{IoU}=\frac{\Omega_{\mathrm{g}}\cap\Omega_{\mathrm{p}}}{\Omega_{g}\cup\Omega_{\mathrm{p}}} \tag{4-12}$$

式中，Ω_{g} 和 Ω_{p} 分别表示标签框和预测框的面积。通过使用 IoU 来衡量标签框和预测框的重叠程度，并与预设阈值进行比较，如果大于阈值则预测框为检测正确，否则检测失败。根据 IoU 值并结合表 4-4 中的混淆矩阵，可以进一步计算关键指标精度（Precision）和召回率（Recall）。表 4-4 中，TP 是指预测结果为正类，且与实际标签结果一致，称为真阳性；FP 是指预测结果为正类，但实际上标签结果为负类，称为假阳性；FN 是指预测结果为负类，实际上目标为正类，称为假阴性；TN 是指模型预测结果与实际结果都为负类，称为真阴性。精度可以由以

中国知网 https://www.cnki.net

下公式计算得到：

$$\text{Precision}=\frac{\text{TP}}{\text{TP+FP}} \tag{4-13}$$

召回率可以由以下公式计算得到：

$$\text{Recall}=\frac{\text{TP}}{\text{TP+FN}} \tag{4-14}$$

根据精度和召回率，mAP 可以由以下公式计算得到：

$$\text{mAP}=\frac{1}{N_{\text{cls}}}\sum_{a=1}^{N_{\text{cls}}}\text{AP}_a \tag{4-15}$$

其中，N_{cls} 表示模型所能检测的类别数，例如在 VOC 数据集中的类别数是 20 类，则 N_{cls} 为 20；AP_a 表示检测第 a 个类别的平均精度（Average Precision，AP），其通过计算不同阈值的 P-R（Precision-Recall）曲线下的面积获得。AP_a 可由如下公式计算得到：

$$\text{AP}_a=\int_0^1 P_a\ (r)\ dr \tag{4-16}$$

其中，P_a 和 r 分别表示第 a 个类别的精确率和召回率。本章进行实验时，统一设定阈值为 0.5 来计算 mAP，简称为 mAP_{50}。

（1）MS COCO 的评价指标

COCO 数据集具体包括 6 个指标，分别为 $\text{mAP}_{50:95}$、mAP_{50}、mAP_{75}、mAP_{s}、mAP_{m} 和 mAP_{l}。$\text{mAP}_{50:95}$ 是在 10 个不同 IoU 阈值下计算 AP 值并取平均得到（这些阈值以 0.05 为间隔，从 0.5 递增至 0.95）；mAP_{50} 和 mAP_{75} 分别指 IoU 阈值设置为 0.5 和 0.75 下得到的 AP 值。值得一提的是，IoU 阈值设定的越高，表明预测框和标签框的重叠度要求越高，标准更加严格；mAP_{s}、mAP_{m} 和 mAP_{l} 分别表示检测小、中和大目标下的 mAP 值，主要用来衡量模型对不同尺寸目标的检测性能。通常，小目标和大目标分别定义为包含像素数量小于 32^2 和大于 96^2 的目标。中目标的像素数量则在 32^2~96^2 之间。

表 4-4 混淆矩阵

预测情况 / 实际情况	正类	负类
正类	TP	FN
负类	FP	TN

4.3.4 消融实验

本小节为验证 TELOD 中不同部件、TDEN 的不同变种和超参数对模型性能的影响，统一采用以 ResNet18[82]为骨干网络的 CenterNet[138]作为基础检测器来进

中国知网 https://www.cnki.net

行一系列实验。所有实验结果都是通过 VOC Trainval-L 数据集训练得到的模型在 VOC 2017 Test-L 数据集上测试得到。

（1）TELOD 中不同组件对检测性能的影响

表 4-5 展示了 TDEN、AFEH w/o FIM 和 FIM 对检测性能影响的实验结果。其中，基准网络表示 CenterNet[138]；“w/”和“w/o”分别是英文“with”和“without”的缩写；“AFEH w/ FIM”和“AFEH w/o FIM”分别表示 AFEH 中有和没有引入 FIM；$\mathbb{N}_1$ 表示在基准网络上添加 TDEN 后得到的变种网络；网络 $\mathbb{N}_2$ 表示仅采用第二阶段特征层增强而得到的变种网络。值得注意的是，由于没有采用 TDEN，因此网络 $\mathbb{N}_2$ 引入的是“AFEH w/o FIM”而不是“AFEH w/ FIM”；网络 $\mathbb{N}_3$ 是指在基准网络上同时引入第一阶段的 TDEN 和第二阶段的“AFEH w/o FIM”后产生的变种网络；网络 $\mathbb{N}_4$ 为完整的 TELOD。

从表 4-5 中可以得出以下结论：

1） 将 TDEN 应用到基准网络后，在 VOC 2007 Test-L 测试集上的 mAP_{50} 值提高了 4.1%。这主要得益于 TDEN 所使用的任务分解增强策略，有效改善了低质图像的各种细节和纹理内容，从而使检测器能够提取出更准确的判别特征。

2） 在网络 $\mathbb{N}_1$ 的基础上额外引入不含 FIM 的 AFEH，mAP_{50} 值增加了 0.5%。这是因为“AFEH w/o FIM”采用了 HR 图像提供的精确结构先验作为指导，提高了检测特征的表示能力。

3） 将 FIM 引入 AFEH 后，网络 $\mathbb{N}_4$ 的检测性能实现了进一步提升，表明 TDEN 的底层增强特征可以提供有用的空间线索，从而协助高层检测特征恢复更全面的信息。

4） TDEN 和“AFEH w/ FIM”的组合使模型的检测性能达到最佳，反映了 TELOD 中的这两个组件是能互相补充的。

5） 虽然网络 $\mathbb{N}_2$ 的性能优于基准网络，但与完整的 TELOD 相比，其 mAP_{50} 值仍有明显的差距，表明仅执行第二阶段增强并不能很好地缩小从 LR 和 HR 图像中提取的检测特征之间的域间隙。

表 4-5 TELOD 不同组件对检测性能的影响

方法	TDEN	AFEH w/o FIM	AFEH w/ FIM	mAP_{50}（%）
基准网络	×	×	×	53.8
$\mathbb{N}_1$	✓	×	×	57.9
$\mathbb{N}_2$	×	✓	×	55.7
$\mathbb{N}_3$	✓	✓	×	58.4
$\mathbb{N}_4$	✓	×	✓	58.6

（2）TDEN 不同变种对检测性能的影响

中国知网 https://www.cnki.net

表 4-6 列出了 TDEN 不同变种对检测性能影响的实验结果。其中，基准网络与表 4-5 中的基准网络等同；网络$\mathbb{N}_5$和$\mathbb{N}_6$分别为将 IRB 和 REB 作为 SR 子网络添加到基准网络后产生的变种网络；网络$\mathbb{N}_7$和$\mathbb{N}_8$分别指采用级联和递归方式连接 IRB 和 REB，并进一步添加到基准网络后产生的变种网络；所列参数值表示当前网络与基准网络相比所额外增加的参数。从表 4-6 中可以得出以下结论：

1） 在基准网络上单独应用 IRB 或 REB 可以提高低质图像的目标检测性能。此外，与网络$\mathbb{N}_5$相比，网络$\mathbb{N}_6$在 VOC 2007 Test-L 测试集上能实现 0.5% 的 mAP 值提升。主要原因在于后者使用原始而不是经 Bicubic 下采样后的 HR 图像作为标签来监督预增强子网络的训练。相比于原始 HR 图像，插值后图像的信息并不完整，仅能为网络权重学习提供次优指导。

2） 与网络$\mathbb{N}_5$和$\mathbb{N}_6$相比，网络$\mathbb{N}_7$和$\mathbb{N}_8$的 mAP 值明显更高。该结果说明采用任务分解增强策略能有效降低多降质因素带来的重建挑战，从而提升模型检测性能。

3） 相较于网络$\mathbb{N}_7$，网络$\mathbb{N}_8$能减少近一半参数的同时实现更高的 mAP 值。主要原因在于递归连接结构可以通过探索 IRB 和 REB 之间的任务相关性，学习更精确的特征表示，从而实现更高的检测精度。

表 4-6 TDEN 不同变种的性能比较

方法	IRB	REB	级联方式	递归方式	参数（K）	mAP_{50}（%）
基准网络	×	×	×	×	-	53.8
$\mathbb{N}_5$	✓	×	×	×	10	55.9
$\mathbb{N}_6$	×	✓	×	×	10	56.4
$\mathbb{N}_7$	✓	✓	✓	×	18	57.6
$\mathbb{N}_8$	✓	✓	×	✓	10	57.9

（3）TDEN 中迭代数对模型检测性能的影响

由于 TDEN 采用递归学习结构，因此研究迭代数如何对检测性能产生影响是至关重要的。为此，表 4-7 展示了不同迭代数下模型在 VOC 2007 Test-L 测试集上的实验结果。从表 4-7 中可观察得到，随着迭代数增加，mAP 值逐渐减少。原因可能在于更多的迭代会使 TDEN 在训练过程中更关注于图像像素层面上的提升，而忽略了对检测所需的结构化特征学习。因此，TDEN 的迭代数设为 1。

表 4-7 TDEN 中不同迭代数 μ 对性能的影响

迭代数 μ	1	2	3
参数（K）	10	11	12
mAP_{50}（%）	57.9	57.6	57.3

中国知网 https://www.cnki.net

4.3.5 与其他方法的比较

（1）客观评价

本节实验采用以 ResNet18[82]为骨干网络的 CenterNet[138]作为基础检测器。表 4-8 和表 4-9 分别展示了不同方法在 VOC 2007 Test-L 和 COCO 2017 Val-L 数据集上的客观结果比较。为了全面地验证本章所提方法的有效性，与三类方法进行比较，分别为重训练方法、独立增强方法和联合增强和目标检测方法。重训练方法是将检测器在 LR 图像数据集上进行重新训练的方法；独立增强方法是预先使用 SR 模型对 LR 图像进行增强，然后输入到经 HR 图像训练得到的检测器中进行检测的方法。值得注意的是，SR 模型和检测器的训练过程是互相独立的。所采用的 SR 方法包含以下 4 种：CARN[29]、DRSAN[33]、第二章方法 MFSN 和第三章方法 HDEN。由于这些原始 SR 模型只能对 LR 图像按固定整数倍数进行分辨率放大，因此采用 TDEN 中的任意分辨率上采样器取代它们原始网络中的上采样器来实现任意尺度上采样；联合增强和目标检测方法是将增强网络和检测器进行协同优化，这类方法包括 IEGOD[70]、SuperYOLO[72]和 AERIS[71]。SuperYOLO 最初是为多模态遥感图像目标检测所设计的，为使其适应 RGB 图像的检测，删除了原有网络头部的多模态融合模块。此外，为保证使用相同的基础检测器，将 CenterNet 代替 IEGOD 和 SuperYOLO 框架中原有的 YOLOv3[57]和 YOLOv5[59]。为公平地进行比较，独立增强方法和联合增强和目标检测方法都在相同的降质数据集上进行重新训练。

表 4-8 不同方法在 VOC 2007 Test-L 数据集上的检测性能比较

方法	mAP_{50}（%）	参数（M）
基准方法		
HR-LR	39.5	14.43
LR-LR	53.8	14.43
独立增强方法		
CARN[29]	42.2	15.28
DRSAN[33]	42.5	14.70
MFSN（第二章方法）	43.4	14.95
HDEN（第三章方法）	43.5	15.19
联合增强和目标检测方法		
AERIS[71]	57.5	14.59
IEGOD[70]	55.2	14.43
SuperYOLO[72]	55.4	14.43
TELOD（本章方法）	**58.6**	14.44

表 4-8 和表 4-9 中的基准方法包括 HR-LR 和 LR-LR。其中，HR-LR 表示检测器在 HR 图像上进行训练，但却在 LR 图像上进行测试。LR-LR 是指检测网络

中国知网 https://www.cnki.net

在 LR 图像上进行训练，在推理阶段同样在 LR 图像上进行测试，其是一种基于重训练的方法。从表 4-8 和表 4-9 中可以得出以下 5 个结论：

表 4-9 不同方法在 COCO 2017 Val-L 数据集上的检测性能比较

方法	$mAP_{50:95}$（%）	mAP_s（%）	mAP_m（%）	mAP_l（%）
基准方法				
HR-LR	14.7	1.4	10.8	38.7
LR-LR	15.9	1.4	11.9	40.3
独立增强方法				
CARN[29]	15.3	2.2	14.1	35.2
DRSAN[33]	15.9	2.1	14.8	36.5
MFSN（第二章方法）	15.8	2.0	14.5	36.1
HDEN（第三章方法）	15.9	2.1	14.7	36.8
联合增强和目标检测方法				
AERIS[71]	18.3	2.6	16.2	43.3
IEGOD[70]	17.7	1.8	13.8	43.7
SuperYOLO[72]	17.8	1.7	13.6	44.0
TELOD（本章方法）	**21.4**	**3.0**	**20.9**	**46.0**

1） 在所有比较方法中，HR-LR 在 VOC 2007 Test-L 上的 mAP_{50} 和在 COCO 2017 Val-L 上的 $AP_{50:95}$ 都是最低的。原因在于，HR 和 LR 图像之间的特征域差距较大，导致在 HR 图像域训练的检测器，在测试时无法很好适应 LR 图像域。

2） LR-LR 通过在 LR 图像上重新训练后，确实能得到优于 HR-LR 的检测精度。然而，LR-LR 的性能提升仍不够明显，尤其在 COCO 2017 Val-L 上。这结果表明了 LR-LR 仍然不能有效地从丢失了许多细节和小结构的 LR 图像中提取准确特征。

3） 从 DRSAN[33]、第二章方法 MFSN 以及第三章方法 HDEN 这类独立增强方法与 HR-LR 的对比实验结果可以看到，通过在检测器前预先对 LR 图像进行增强，可以在一定程度上提高模型的检测精度。这也再次证明了第二章和第三章中提到的 SR 方法有助于提升目标检测模型在 LR 图像上检测能力的观点。

4） 相较于独立增强方法，联合增强和目标检测方法得到了更高的 mAP 值和 AP 值。这表明了通过将 SR 网络和检测器进行联合优化并利用适当的损失函数约束，可以较好地学习 LR 图像中用于检测任务的判别特征。

5） TELOD 在所有测试集以及所有指标上都取得了最优结果，特别是在 COCO 2017 Val-L 数据集上。例如，相比第二优的方法 AERIS[71]，TELOD 在 $mAP_{50:95}$、mAP_m 和 mAP_l 上分别得到了 3.1%、4.7%和 2.7%的提升。

中国知网 https://www.cnki.net

得到以上结果主要归功于 TELOD 分别采用 TDEN 和 AFEH 进行图像层和特征层增强，从而更好地检测不同大小的目标。

（2）主观评价

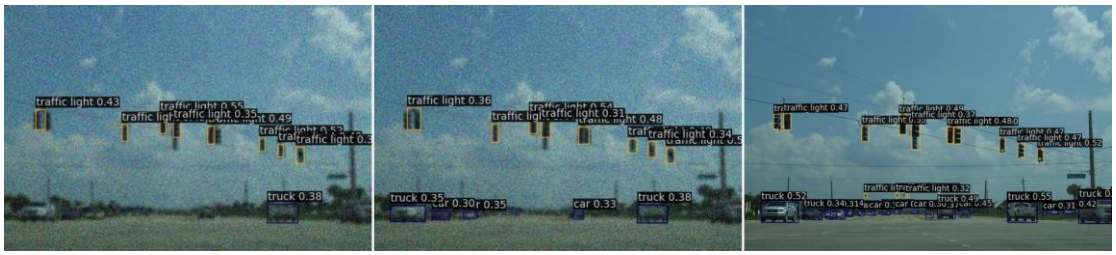
为了更直观地对比不同方法的检测性能，图 4-4 展示了本章所提方法 TELOD 和其他方法在 COCO 2017 Val-L 数据集图像上的检测结果。其中，HR-HR 是指检测网络在 HR 图像上训练，并同样在 HR 图像上测试的方法。HR-HR 的可视化目标检测结果可作为评估方法性能的理论上限参考。所有方法都是采用 CenterNet 作为检测器。为了方便展示，所有比较图中不同方法的底图都为其采用的模型所输入的图像。从图 4-4 中可以看到：



(a) HR-LR　　(b) LR-LR　　(c) DRSAN



(d) MFSN（第二章方法）　　(e) HDEN（第三章方法）　　(f) AERIS



(j) IEGOD　　(k) TELOD（本章方法）　　(l) HR-HR

图 4-4 不同方法对 COCO 2017 Val-L 数据集中 000000166391 号图像的检测结果

1） HR-LR 的检测准确率最低，这主要是因为在 HR 图像域数据上训练的检测模型无法很好适应 LR 图像。

2） 虽然 LR-LR 和独立增强方法得到比 HR-LR 更好的检测结果，但它们仍存在较高的漏检率。

3） 在所比较的方法中，本章所提方法 TELOD 能准确地检测出更多目标，

中国知网　https://www.cnki.net

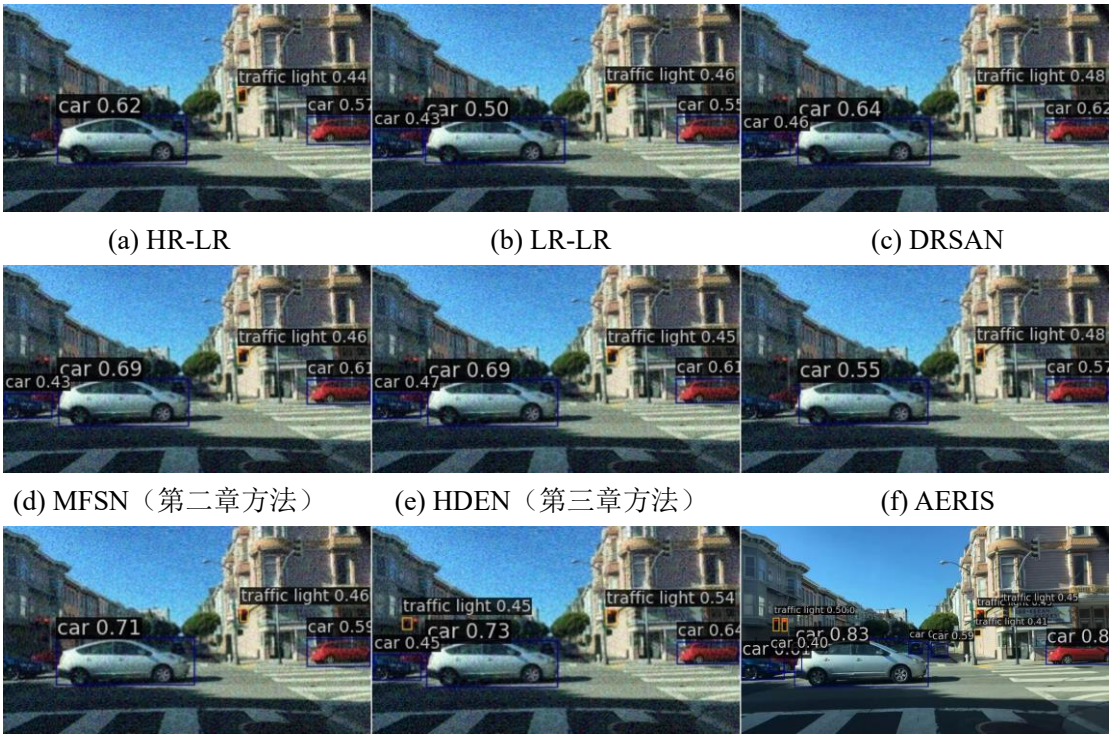
也更接近 HR-HR 所展示的目标检测性能上限。值得注意的是，即使对于具有较高检测难度的小目标，TELOD 仍能表现的更好。如图 4-4 所示，TELOD 明显能检测出更多远处的小车。

为更好地评估 TELOD 对道路交通场景中受多种降质因素影响的低质图像的检测性能，采用公式（1-1）降质模型对自动驾驶数据集 BDD100K[137]中图像进行降质，得到降质数据集 BDD100K-L。图 4-5~图 4-8 展示了 TELOD 和其他方法在 BDD100K-L 图像上的检测结果。从图 4-5~图 4-8 中可以得出以下结论：

1） 从图 4-5 和图 4-6 中可以看到，在所有比较方法中，本章所提出的 TELOD 能更准确地检测出更多交通信号灯。原因在于 TELOD 通过 TDEN 对低质图像进行预增强，有效改善了小目标交通信号灯的细节特征，从而使检测器更容易检测得到。

2） 如图 4-7 所示，在噪声和模糊较为严重的情况下，HR-LR 甚至都难以检测出一个目标，其他比较方法最多仅检测出两辆小车，而 TELOD 却能检测出四辆，表明其具有一定的鲁棒性和有效性。

3） 在所有示例中，TELOD 都能实现最优的检测结果。究其原因，是 TELOD 采用了图像域和特征域双阶段增强策略，有效地从 LR 图像中学习到更为准确的结构化特征，从而提升了模型的检测能力。



(a) HR-LR　(b) LR-LR　(c) DRSAN

(d) MFSN（第二章方法）　(e) HDEN（第三章方法）　(f) AERIS

(j) IEGOD　(k) TELOD（本章方法）　(l) HR-HR

图 4-5 不同方法对 BDD100K-L 数据集中 b95c237a-00000000 号图像的检测结果

中国知网 https://www.cnki.net



(a) HR-LR　　(b) LR-LR　　(c) DRSAN



(d) MFSN（第二章方法）　　(e) HDEN（第三章方法）　　(f) AERIS



(j) IEGOD　　(k) TELOD（本章方法）　　(l) HR-HR

图 4-6 不同方法对 BDD100K-L 数据集中 de594ebf-74f3b97b 号图像的检测结果



(a) HR-LR　　(b) LR-LR　　(c) DRSAN



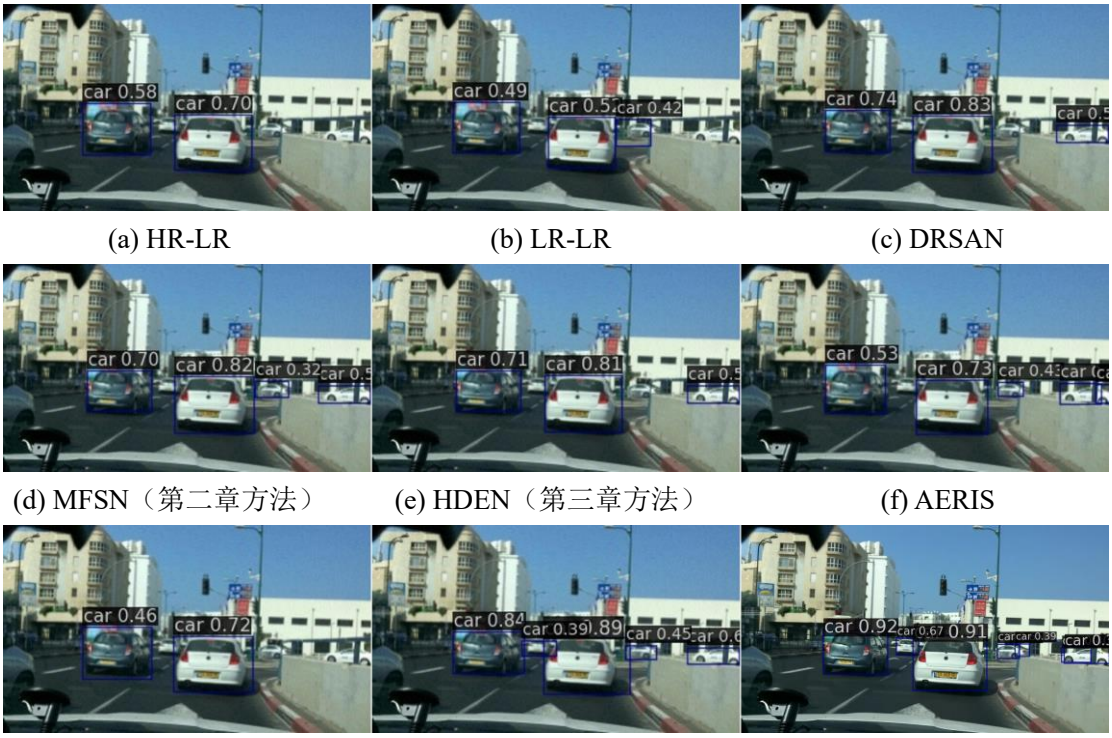
(d) MFSN（第二章方法）　　(e) HDEN（第三章方法）　　(f) AERIS



(j) IEGOD　　(k) TELOD（本章方法）　　(l) HR-HR

图 4-7 不同方法对 BDD100K-L 数据集中 c7fe7144-00000000 号图像的检测结果

中国知网　https://www.cnki.net



(a) HR-LR　(b) LR-LR　(c) DRSAN

(d) MFSN（第二章方法）　(e) HDEN（第三章方法）　(f) AERIS

(j) IEGOD　(k) TELOD（本章方法）　(l) HR-HR

图 4-8 不同方法对 BDD100K-L 数据集中 dd96add1-21cfd102 003701 号图像的检测结果

4.3.6 泛化性分析

为了验证本章所提方法 TELOD 的泛化性，将 TELOD 应用到最近提出的检测器 YOLOv7-tiny[61]上。具体来说，分别使用 YOLOv7-tiny 替换原有的 CenterNet 建立新的 TELOD 和其他比较算法框架。所有调整后的基准方法与联合增强和目标检测方法都进行了重新训练。表 4-10 和表 4-11 分别列出不同比较方法和 TELOD 中的不同组件在 COCO 2017 Val-L 数据集上的实验结果。从表 4-10 中可以观察到，尽管采用 YOLOv7-tiny 作为新的基础检测器，相较于其他方法，TELOD 在所有评价指标上仍能达到最佳。例如，相比第二优的方法 AERIS[71]，TELOD 在评价指标 $mAP_{50:95}$、mAP_{50} 和 mAP_{75} 上分别得到 2%、2%和 2.3%的提升。这结果表明了 TELOD 能适用于其他检测器，具有一定的泛化能力。从表 4-11 中可以看出，在 LR-LR 基础上，应用 TDEN 后可获得 1.5%的 $mAP_{50:95}$ 值的提升。如果额外采用 AFEH，模型性能还能进一步提高。这些结果表明 TDEN 和 AFEH 在其他检测器上也能有较好的表现。

4.3.7 特征分布可视化

为了方便说明本章方法 TELOD 的两个阶段增强如何缩小检测特征域差距，

中国知网 https://www.cnki.net

图 4-9 展示了通过 t 分布随机邻域嵌入（t-distributed stochastic neighbor embedding，t-SNE）算法[150]获得的不同检测器颈部特征可视化分布。其中，蓝色和橙色点分别代表检测器从源域样本和目标域样本中学习到的源域和目标域特征，而蓝色和红色十字分别表示源域和目标域特征均值；YOLOv7-tiny (H)表示在 COCO 2017 Train 数据集上训练得到的模型。在本小节实验中，采用 YOLOv7-tiny[61]作为基础检测器，并分别从 COCO 2017 Val-L 和 COCO 2017 Val 数据集中随机选择 2000 张图像作为源域样本和目标域样本。在图 4-9 (a)中，蓝色和橙色特征分布是通过将源域样本和目标域样本分别输入到 YOLOv7-tiny (H)进行特征提取后将颈部特征用 t-SNE 可视化得到的。同理可得，在图 4-9 (b)中，蓝色和橙色特征分布分别来自 TELOD 的第一阶段模型和 YOLOv7-tiny (H)的颈部特征；在图 4-9 (c)中，蓝色和橙色特征分布分别来自 TELOD 的第二阶段模型和 YOLOv7-tiny (H)的颈部特征。

表 4-10 不同方法在 COCO 2017 Val-L 测试集上性能比较

方法	YOLOv7-tiny[61]		
	$mAP_{50:95}$（%）	mAP_{50}（%）	mAP_{75}（%）
基准方法			
HR-LR	17.4	28.2	17.7
LR-LR	20.6	33.8	21.2
联合增强和目标检测方法			
AERIS[71]	21.2	34.7	21.9
IEGOD[70]	20.9	34.3	21.7
SuperYOLO[72]	20.9	34.2	21.5
TELOD	**23.2**	**36.7**	**24.2**

表 4-11 TDEN 和 AFEH 对模型性能的影响

方法	TDEN	AFEH	YOLOv7-tiny[61]		
			$mAP_{50:95}$（%）	mAP_{50}（%）	mAP_{75}（%）
LR-LR	×	×	20.6	33.8	21.2
TELOD	✓	×	22.1	35.3	23.1
	✓	✓	**23.2**	**36.7**	**24.2**

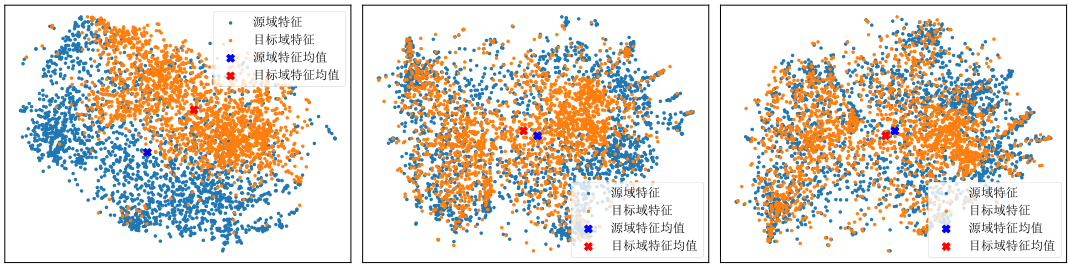
从图 4-9 中可以得到以下 2 个结论：

1） 在图 4-9 (a)中，源域和目标域特征各聚在一边，域特征均值相距甚远，表明从 LR 和 HR 图像中提取到的检测特征从一开始就存在较大域差距。

2） 从图 4-9 (b)中可以看出，TELOD 采用第一阶段增强后，相比图 4-9 (a)，蓝色和橙色特征分布更加接近，且逐步融合在一起。此外，两个域特征均值也更加接近。在图 4-9 (c)中，当 TELOD 采用第二阶段增强后，蓝色和橙色特征分布进一步靠近，并且蓝色交叉点和红色交叉点几乎要重

中国知网 https://www.cnki.net

叠在一起。上述结果表明，TELOD 的双阶段增强策略可以有效缩小从 LR 图像和 HR 图像中提取的检测特征之间的域差距，从而提高 LR 图像的检测精度。



(a) YOLOv7-tiny (H)　　(b) TELOD 的第一阶段　　(c) TELOD 的第二阶段

图 4-9 通过 t-SNE 算法获得的检测器颈部特征分布可视化

4.3.8 模型参数和运行时间分析

表 4-12 展示了不同模型参数、运行时间和 mAP_{50} 值的比较结果。在本小节中，采用以 ResNet18[82]为骨干网络的 CenterNet[138]作为基础检测器。表 4-12 中的平均运行时间是使用单个 NVIDIA GTX 1080 Ti GPU 在 VOC 2007 Test-L 数据集上计算得到的。

表 4-12 不同方法参数、运行时间和性能比较

方法	参数（M）	运行时间（s）	mAP_{50}（%）
基准方法			
HR-LR	14.43	0.006	39.5
LR-LR	14.43	0.006	53.8
独立增强方法			
CARN[29]	15.28	0.029	42.2
DRSAN[33]	14.70	0.029	42.5
第二章方法 MFSN	14.95	0.051	43.4
第三章方法 HDEN	15.19	0.097	43.5
联合增强和目标检测方法			
AERIS[71]	14.59	0.007	57.5
IEGOD[70]	14.43	0.006	55.2
SuperYOLO[72]	14.43	0.006	55.4
本章方法 TELOD	14.44	0.011	**58.6**

从表 4-12 中可以观察得到，本章提出的 TELOD 所消耗的参数和所需运行时间远小于独立增强方法。这主要是因为 TELOD 采用了由递归学习结构组成的超轻量级增强网络 TDEN 来高效提升低质图像的质量。其次，虽然 IEGOD[70]和

中国知网 https://www.cnki.net

SuperYOLO[72]仅在训练过程中使用 SR 模块而无需引入额外计算成本和参数，但 TELOD 只引入较少的计算复杂度和参数，就实现了明显更高的检测精度。相比其他方法，TELOD 在模型检测性能、参数和运行时间之间实现了更好的平衡。

4.4 本章小结

为了提高道路交通场景下目标检测模型在具有不同退化类型和任意比例因子的低质图像上的检测精度，本章提出了一种名为 TELOD 的双阶段增强的道路交通目标检测方法。在第一阶段，设计了 TDEN 并将其作为 SR 子网络，旨在检测器前执行图像层增强。为降低复合降质因素带来的图像重建挑战，TDEN 将整个增强任务分解为图像复原和分辨率增强子任务，并使用 IRB 和 REB 去分别执行。此外，在两个任务分支之间设置一个共享特征提取器，以便从原始 LR 和中间复原图像中学习域不变知识。为了对不同尺度的目标特征进行有效增强，采用了第二章方法的核心模块 MFSB 来构建共享特征提取器。在第二阶段，在检测器颈部位置，构建一个辅助头 AFEH，并利用 HR 图像先验指导进行特征层面的增强，进一步缩小从 SR 和 HR 图像中提取到的检测特征之间的域差距，而无需引入额外推理成本。在 AFEH 中，FIM 采用交叉注意力的方式有效整合底层增强特征和高层检测特征，以帮助检测器更好地学习特定任务的特征。实验表明，与其他方法相比，TELOD 仅引入较少的参数和计算复杂度就能实现最佳的检测精度。

中国知网 https://www.cnki.net

第 5 章 联合跨阶段特征交互和语义增强的远距离道路异常检测

5.1 引言

在第四章中，本文提出了一种基于双阶段增强的低质图像道路交通目标检测方法。该方法首先通过引入任务分解增强网络，有效提升了图像质量；随后设计了辅助特征增强头，在特征层面对检测特征进行进一步优化。实验结果表明，该方法在复杂交通环境下展现出良好的鲁棒性和适应性，能够显著提升低质图像目标检测性能。

然而，在实际道路交通场景中，车辆所面临的环境复杂性不仅体现在视觉信息降质导致的目标检测准确率下降问题上，还常常伴随着远距离道路异常的干扰。例如，在不同光照、天气、材质及观察视角条件下，道路异常往往呈现出与周围完好路面极为相似的外观特征。特别是远距离的道路异常，其占据的像素信息更少，细节纹理丢失严重。这些因素都会让道路异常的视觉特征更加不显著，导致传统检测模型容易出现漏检或误判问题，进而对道路车辆行驶安全构成潜在威胁。此外，不同于上一章所关注的基于矩形框的目标定位，道路异常具有不规则轮廓，传统检测框架难以准确描述其真实形态，从而影响检测的精度和实用性。针对上述问题，本章进一步研究并提出了一种面向远距离道路异常的检测方法，旨在提升模型在复杂道路环境下对远距离道路异常的检测准确性和轮廓描述能力。值得注意的是，本章方法本质上是像素级检测方法，虽然归类为目标检测，但也可称为目标分割。

为有效提升模型在复杂场景下对远距离道路异常的感知能力，本章提出了一种联合跨阶段特征交互和语义超分辨率的网络（Joint Cross-stage Feature Interaction and sematic SR Network，JCFI-SRNet）。该网络首先采用混合了 Transformer 和 CNN 结构的 SMT[123]作为骨干网络来从输入图像中提取全局和局部上下文特征。然后，设计了一个跨阶段特征感知颈（Cross-Stage Feature Perception Neck，CSFPN）模块，通过利用相邻阶段的信息作为指导来增强每个阶段的特征，使网络更好地感知不同尺寸的异常目标，特别是小尺寸异常。具体来说，为了使每个阶段特征得到更全面的表征，提出了一种双向特征交互模块（Bi-directional Feature Interaction Module，BFIM）作为 CSFPN 的关键组件。该模块通过在相邻两个阶段特征之间构建一种双向连接结构，有效促进了高层语义和底层空间的信息互补。为了深入执行特征的双向交互，在 BFIM 中设计了一个跨阶段特征细化模块（Cross-Stage feature Refinement Block，CSRB），对两个输

中国知网 https://www.cnki.net

入特征进行深度融合。在 CSRB 中，提出了一种多尺度跨注意调制块（Multi-scale Cross-attention Modulation Block，MCMB）来代替普通卷积，以利用相邻阶段特征之间的多尺度长距离依赖关系实现特征的充分交互。其次，使用1×1卷积层构建预测头，对转换特征进行解码，以得到初步预测图。最后，受图像 SR 重建技术可以有效增强特征细节信息的启发，设计了一个由 HR 语义真值指导的语义 SR 增强头（Semantic Super-Resolution enhancement Head，SSRH）。由于第三章提出的混合域增强模块 HDEM 能通过综合利用频率域和空间域信息增强网络的高频细节特征，因此，SSRH 也主要采用 HDEM 来搭建。通过使用 SSRH 对初步预测图进行 2 倍 SR 增强，能进一步改善小尺寸异常的检测能力，从而提升模型性能。

图 5-1 展示了各方法在道路异常检测测试集（Road Anomaly Detection-Test，RAD-Test）上的 F1 分数（F1-score）值、参数量和 FLOPs 的比较。其中，FLOPs 是假定输入图像分辨率为384×384时计算得到；红色圆圈表示本章提出的方法 JCFI-SRNet；圆圈越大表明模型所耗费的参数越多。从图 5-1 中可以看到，相较于其他方法，JCFI-SRNet 在模型性能、FLOPs 和参数量上都实现了最优，充分展示了其高效性。

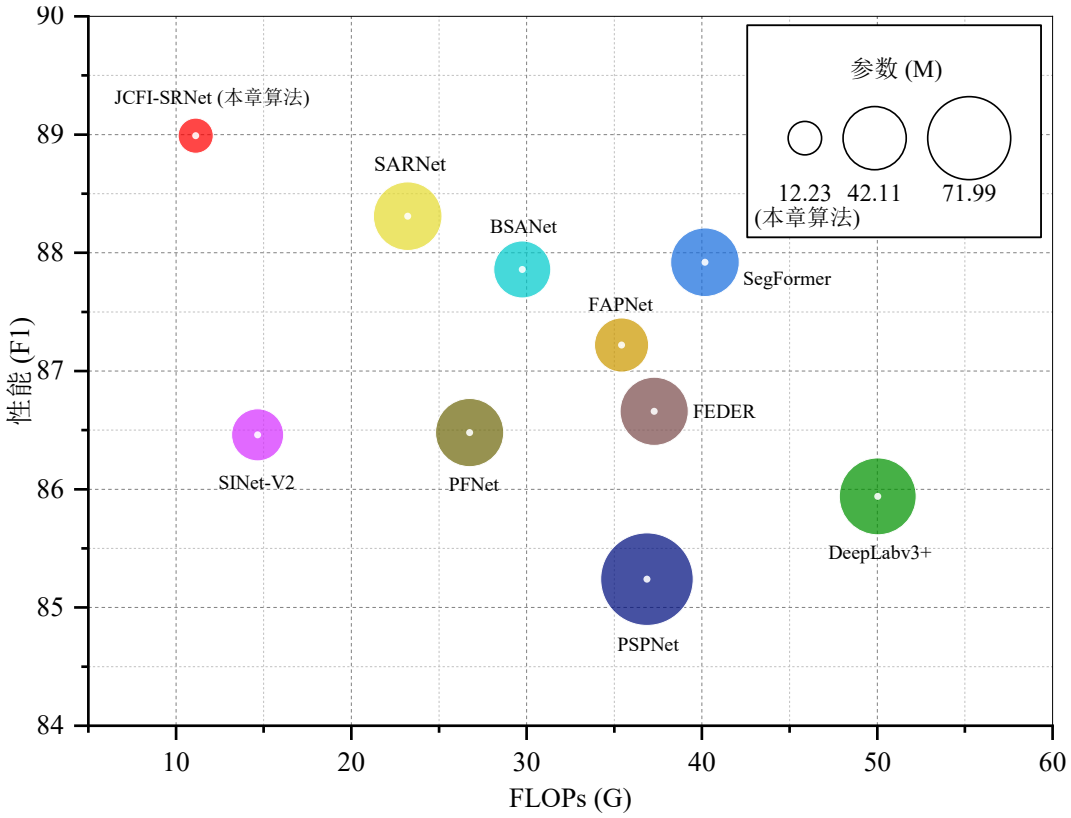


图 5-1 不同比较方法在 RAD-Test 数据集上的 F1 值、参数量和 FLOPs 的比较

中国知网 https://www.cnki.net

总的来说，本章的主要创新点和贡献概述如下：

1） 提出了一种有效的特征转换模块 CSFPN，通过整合相邻阶段特征的空间或语义信息来改进每个阶段的骨干特征，从而高效地实现特征转换，为最终的特征解码步骤提供综合信息表示。

2） 在两个相邻阶段特征之间建立 BFIM，以有效进行双向信息交互。此外，BFIM 中还集成了一种新颖的注意力调制模块 MCMB，以充分探索两个输入特征之间的多尺度远距离依赖关系，从而实现不同阶段特征的深度融合。

3） 提出一种有效的 SSRH，用以对初始预测图执行进一步语义 SR 增强。此外，通过辅以边缘细节更完整 HR 语义掩膜指导，可以使网络学习到更为丰富完整的特征表示，以有效解决道路异常特征不显著造成的目标分割边缘不清晰问题。

4） 提出一种名为 JCFI-SRNet 的新型道路异常检测框架。通过大量实验表明，与所比较的算法相比，JCFI-SRNet 能以最少的参数和计算复杂度实现最佳的模型检测准确率。

5.2 联合跨阶段特征交互和语义增强的远距离道路异常检测方法

5.2.1 联合跨阶段特征交互和语义超分辨率网络总体框架

在交通场景中，道路异常会以各种不规则形状而存在，往往具有与周围完好路面相似的颜色和同样的材质，这种低对比度特性使其难以被有效检测。在这些异常中，距离摄像头越远的目标，其包含的像素信息越少，越难以被有效感知。因此，为了精准检测这些远距离道路异常，应用大规模骨干网络或者构建复杂的解码器都是潜在的解决方案。然而，这些方式都很容易导致模型计算成本高和推理时间长，难以在实际应用中部署。

针对以上问题，本小节设计了一种新颖且高效的框架名为 JCFI-SRNet，其具体结构如图 5-2 所示。JCFI-SRNet 主要由 4 个部分组成，分别为特征提取骨干网、CSFPN、初始预测模块和 SSRH。首先，采用 SMT[123]作为骨干网络，从输入图像中提取 4 个阶段的基本特征。选择 SMT 主要有以下 2 个原因：一方面，与其他骨干网络不同，SMT 可以通过有效结合 CNN 和 Transformer 的优势来学习局部和全局信息。这种混合架构设计使 SMT 适用于检测等密集型预测相关任务。另一方面，SMT 在实现出色特征提取功能的同时，还能防止引入大量计算负担和模型参数。然后，为了避免后续构建复杂的解码器，选择在编码器和解码器之间构建高效的特征转换模块。为此，设计了 CSFPN 来利用相邻阶段的特征作为指导，更全面地增强从骨干网中获得的 4 个阶段基础特征。通过这种方式，

中国知网 https://www.cnki.net

能有效捕捉道路异常与背景之间的细微差异，以提升低对比度异常的检测准确率。值得注意的是，CSFPN 只消耗 0.7 M 参数，表明其尽管移植到其他网络中也不会引入过多的参数。其次，采用初始预测模块来简单地融合 4 个经 CSFPN 细化后的特征，形成初步预测图。最后，利用 SSRH 对初步预测图进行语义 SR 重构，以生成更高分辨率的最终预测图。

如图 5-2 所示，输入图像为 $\boldsymbol{X}_{\text{img}} \in \mathbb{R}^{H\times W\times 3}$，其先经过 SMT 提取骨干特征 $\{\boldsymbol{F}_i\}(1\le i\le 4)$。然后，利用 CSFPN 调整 $\{\boldsymbol{F}_i\}$ 通道维度的同时进行特征增强，进而得到细化特征 $\{\tilde{\boldsymbol{F}}_i\}(1\le i\le 4)$。随后，预测头使用 Bilinear 将 $\{\tilde{\boldsymbol{F}}_i\}(2\le i\le 4)$ 上采样到与 $\tilde{\boldsymbol{F}}_1$ 相同的空间维度，并使用像素加法运算将 4 个细化特征融合在一起。为了生成初步预测图 $\boldsymbol{X}_{\text{map}} \in \mathbb{R}^{H\times W\times 1}$，采用1×1 卷积将融合特征的通道维度降为 1，并通过 Bilinear 操作将其插值到与输入图像一样的空间大小。最后，采用 SSRH 来对 $\boldsymbol{X}_{\text{map}}$ 进行 2 倍语义 SR 增强，得到最终预测图 $\boldsymbol{X}_{\text{map}}^{\text{SR}} \in \mathbb{R}^{2H\times 2W\times 1}$。JCFI-SRNet 的总体过程可以由如下公式描述：

$$\boldsymbol{X}_{\text{map}} = \mathcal{F}_{\text{C-head}}\left(\mathcal{F}_{\text{CSFPN}}\left(\mathcal{F}_{\text{backbone}}\left(\boldsymbol{X}_{\text{img}}\right)\right)\right) \tag{5-1-a}$$

$$\boldsymbol{X}_{\text{map}}^{\text{SR}} = \mathcal{F}_{\text{SSRH}}\left(\boldsymbol{X}_{\text{map}}\right) \tag{5-1-b}$$

其中，$\mathcal{F}_{\text{backbone}}(\cdot)$、$\mathcal{F}_{\text{CSFPN}}(\cdot)$、$\mathcal{F}_{\text{C-head}}(\cdot)$和 $\mathcal{F}_{\text{SSRH}}(\cdot)$分别为骨干网络、CSFPN、初始预测模块和 SSRH 函数。

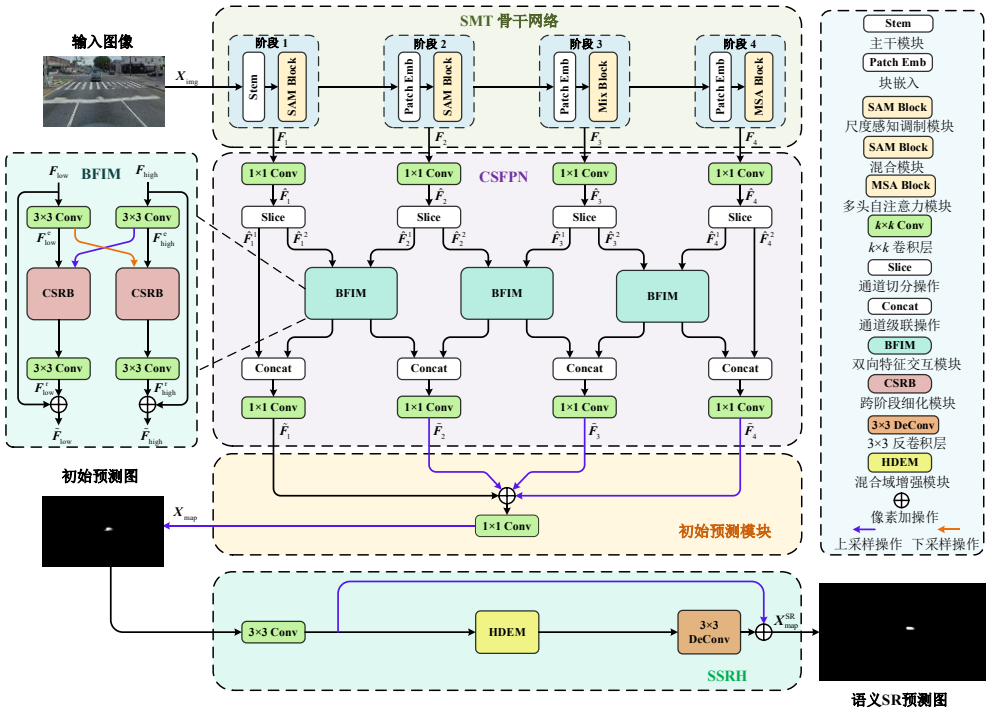


图 5-2 JCFI-SRNet 的总体结构

中国知网　https://www.cnki.net

5.2.2 高层语义和低层空间特征跨阶段融合感知颈部模块

为了减轻后续解码的计算负担，传统方法通常对从主干提取的各阶段特征执行简单的1×1或3×3卷积，以实现特征变换。为进一步增强骨干特征的上下文信息，一些研究工作者采用不同的多尺度模块（如 TEM[108]和 ERF[109]）来取代普通的卷积层实现特征转换，一定程度提升了模型性能。然而，上述方法在特征转换过程中并没有考虑骨干特征之间的相关性，从而限制了特征表示能力的进一步提高。因此，本小节设计了一种新型 CSFPN 来有效解决上述问题。如图 5-2 所示，首先通过1×1卷积层将每个阶段骨干特征 $\boldsymbol{F}_i$ 的通道维度调整为 96，进而得到特征 $\hat{\boldsymbol{F}}_i$。在每一阶段，其相邻阶段的特征与该阶段特征相关性最强，并且蕴含着更为丰富的语义或空间信息。因此，CSFPN 的目的是通过有效整合每个阶段及其相邻阶段的特征线索，以提高网络的综合表示能力。为实现这一目标的同时，避免引入繁重的计算负担，首先采用特征切分操作沿通道维度将 $\hat{\boldsymbol{F}}_i$ 等分切割成两组子特征，分别为 $\hat{\boldsymbol{F}}_i^1$ 和 $\hat{\boldsymbol{F}}_i^2$。然后，将相邻阶段的两组子特征 $\hat{\boldsymbol{F}}_i^2$ 和 $\hat{\boldsymbol{F}}_{i+1}^1$ 一起送入第 i 个 BFIM 中执行特征交互步骤，其中 $1 \le i \le 3$。由于网络结构的限制，$\hat{\boldsymbol{F}}_1^1$ 和 $\hat{\boldsymbol{F}}_4^2$ 并没有相邻阶段特征与其融合，因此采用直接连接的操作来处理。最后，将每个阶段分开处理的两组子特征沿通道维度进行级联，并通过1×1卷积层融合，得到最终细化特征 $\tilde{\boldsymbol{F}}_i$。

总的来说，得益于特征切片、特征交互以及特征级联等精心设计的步骤，CSFPN 可以通过引入低阶段的纹理细节和高阶段的丰富语义作为特征指导，使其仅以较低的参数量（0.7 M）就能全面改进各个阶段的骨干特征。通过使用这种跨阶段特征交互策略，能有效利用相邻阶段特征之间的相关性来完善每个阶段的骨干特征，为最终检测提供更为全面的判别线索，这与传统的孤立处理每个阶段信息的特征变换策略有很大不同。总的来说，经过 CSFPN 细化后的特征，具有更综合的表达能力，能充分捕捉到细微的特征差异，从而更好地定位到隐藏在背景中的异常目标。

5.2.3 基于多尺度交叉注意力的双向特征交互模块

如前所述，CSFPN 的目的是通过利用相邻阶段特征中更丰富的空间或语义信息来改进每个当前阶段特征，而提出的 BFIM 在其中发挥了关键作用，其具体结构展示在图 5-2 中。从中可以看出，BFIM 主要包含两个分支，每个分支都具有相同结构，都是由 2 个3×3 卷积、1 个 CSRB 和 1 个跳跃连接组成。每个 BFIM 将两个相邻阶段的特征作为输入，其中低层特征用 $\boldsymbol{F}_{\text{low}}$ 表示，高层特征用 $\boldsymbol{F}_{\text{high}}$ 表示。然后，使用 2 个3×3 卷积层从 $\boldsymbol{F}_{\text{low}}$ 和 $\boldsymbol{F}_{\text{high}}$ 中提取特征，分别得到特征 $\boldsymbol{F}_{\text{low}}^{\text{e}}$ 和 $\boldsymbol{F}_{\text{high}}^{\text{e}}$。接下来，为使 $\boldsymbol{F}_{\text{low}}^{\text{e}}$ 和 $\boldsymbol{F}_{\text{high}}^{\text{e}}$ 能互相进行信息补充，在两个分支之间建立了双

中国知网　https://www.cnki.net

向连接，并分别在每个分支上插入一个融合模块。每个融合模块具有 2 个特征输入，一个为融合模块所在分支的特征，另一个则是作为外部指导的相邻分支特征。由于 2 个输入特征分别处于不同阶段，因此它们的特征维度并不相同。为此，对融合模块中作为外部指导的特征采用 Bilinear 操作进行插值，以确保其在信息聚合前与当前输入特征具有相同的空间维度。为有效整合 $\boldsymbol{F}_{\text{low}}^{\text{e}}$ 和 $\boldsymbol{F}_{\text{high}}^{\text{e}}$，文献[151]提出的仿射变换可以作为一种可能的解决方案。假设 $\boldsymbol{P}_{\text{cur}} \in \mathbb{R}^{h\times w\times c}$ 和 $\boldsymbol{G}_{\text{ext}} \in \mathbb{R}^{h\times w\times c}$ 为当前阶段特征及其相邻阶段特征（也定义为外部指导特征），其中 h、w 和 c 分别表示特征的高度、宽度和通道数，通过仿射变换，可以得到变换后的特征 $\boldsymbol{Y}_{\text{cur}}$：

$$\boldsymbol{Y}_{\text{cur}} = \boldsymbol{a} \odot \boldsymbol{P}_{\text{cur}} + \boldsymbol{b} \tag{5-2}$$

其中，$\boldsymbol{a}$ 和 $\boldsymbol{b}$ 分别表示缩放和平移参数，每个参数都可从相邻阶段特征 $\boldsymbol{G}_{\text{ext}}$ 中学习得到的，且它们的特征维度与 $\boldsymbol{P}_{\text{cur}}$ 相同；$\odot$ 表示像素层面的相乘操作。需要注意的是，在文献[151]中，仿射变换的 $\boldsymbol{a}$ 和 $\boldsymbol{b}$ 是通过采用 2 个独立的卷积层对外部指导特征进行卷积而得到。由于传统卷积层的结构限制，其所能关注的感受野非常有限，无法探索特征内部的长距离依赖关系。因此，采用这种方式学习到的缩放和平移参数并不足够准确，进而限制仿射变换的有效性。

为了解决上述问题，在传统仿射变换中创新性地引入 Transformer 机制后可以得到 CSRB，其具体结构展示在图 5-3 中。从图 5-3 中可以看到，CSRB 主要由 MCMB 和 GDFN[144]构成。前者旨在深入探索 $\boldsymbol{P}_{\text{cur}}$ 与 $\boldsymbol{G}_{\text{ext}}$ 之间的长范围依赖关系来调制 $\boldsymbol{P}_{\text{cur}}$。后者则用于进一步促进 MCMB 输出的调制信息在网络中流动。具体来说，与传统 Transformer 方法[144]一样，先对 MCMB 的 2 个输入特征进行 LN[143]，再采用1×1卷积聚合通道特征。不同于第四章提出的 MTCA 只建立两个不同单尺度特征之间的长程依赖关系，MCMB 额外引入了一种多尺度特征生成块（Multi-scale Feature Generation Block，MFGB）从多个不同感受野层面提取丰富的局部信息。在 MFGB 中，建立了 3 个并行的深度空洞卷积（空洞因子分别为 1、3 和 5）以扩大感受野范围，同时避免引入过多参数。为了得到查询 $\boldsymbol{Q}_{\text{cur}} \in \mathbb{R}^{h\times w\times c}$ 和键 $\boldsymbol{K}_{\text{ext}} \in \mathbb{R}^{h\times w\times c}$，分别采用1×1卷积来融合第一和第二个 MFGB 输出的多尺度特征（如图 5-3 所示，从上到下计数）。为了在后续的注意力加权过程中更准确、有目的性地聚焦到每个尺度特征，第三个 MFGB 的输出特征直接用作 3 个值（分别为 $\boldsymbol{V}_1 \in \mathbb{R}^{h\times w\times c}$、$\boldsymbol{V}_2 \in \mathbb{R}^{h\times w\times c}$ 和 $\boldsymbol{V}_3 \in \mathbb{R}^{h\times w\times c}$），而不是使用1×1卷积来进一步合并。

与大多数 Transformer 类似[110]，在 MCMB 中也采用了多头注意力机制，以并行学习不同的注意力图谱。具体来说，首先对 $\boldsymbol{Q}_{\text{cur}}$、$\boldsymbol{K}_{\text{ext}}$、$\boldsymbol{V}_1$、$\boldsymbol{V}_2$ 和 $\boldsymbol{V}_3$ 进行矩阵重塑，并将它们划分为 m 个头。在本章中，将 m 设为 8。为了方便描述注意力计算的过程，下面主要以 $\boldsymbol{Q}_{\text{cur}}$ 为例进行说明。通过多头划分操作后，可以将 $\boldsymbol{Q}_{\text{cur}}$

中国知网 https://www.cnki.net

转换为$[\bar{\boldsymbol{Q}}_1,\ldots,\bar{\boldsymbol{Q}}_m]$的形式，其中$\bar{\boldsymbol{Q}}_i \in \mathbb{R}^{h\times w\times c/m}$表示$\boldsymbol{Q}_{\text{cur}}$的第 i 个头特征，$1\le i\le m$。$\boldsymbol{K}_{\text{ext}}$、$\boldsymbol{V}_1$、$\boldsymbol{V}_2$和$\boldsymbol{V}_3$的多头切分操作与$\boldsymbol{Q}_{\text{cur}}$一致。此外，为避免引入巨大的计算负担和占用大量的显存，在计算全局注意力图时，MCMB 选择计算特征通道上交叉协方差的方式而不是传统 Transformer 所采用跨空间维度的矩阵乘方式。第 i 个头的注意力图$\bar{\boldsymbol{A}}_i$可以由以下公式表示：

$$\bar{\boldsymbol{A}}_i = \mathcal{F}_{\sigma}\left(\bar{\boldsymbol{K}}_i \cdot \bar{\boldsymbol{Q}}_i / w_i\right) \tag{5-3}$$

其中，$\mathcal{F}_{\sigma}(\cdot)$表示用于产生注意力权重的 Softmax 函数；$w_i$表示可学习的温度参数，用于动态缩放矩阵乘法；$\bar{\boldsymbol{K}}_i \in \mathbb{R}^{c/m\times hw}$表示$\boldsymbol{K}_{\text{ext}}$的第 i 个头特征。得到注意力图$\bar{\boldsymbol{A}}_i$后，需要将其分别作用在对应不同尺度的值上以实现特征加权。该过程可以由以下公式计算得到：

$$\bar{\boldsymbol{M}}_i^1 = \bar{\boldsymbol{V}}_i^1 \cdot \bar{\boldsymbol{A}}_i; \bar{\boldsymbol{M}}_i^2 = \bar{\boldsymbol{V}}_i^2 \cdot \bar{\boldsymbol{A}}_i; \bar{\boldsymbol{M}}_i^3 = \bar{\boldsymbol{V}}_i^3 \cdot \bar{\boldsymbol{A}}_i \tag{5-4}$$

式中，$\bar{\boldsymbol{V}}_i^1 \in \mathbb{R}^{hw\times c/m}$、$\bar{\boldsymbol{V}}_i^2 \in \mathbb{R}^{hw\times c/m}$和$\bar{\boldsymbol{V}}_i^3 \in \mathbb{R}^{hw\times c/m}$分别是$\boldsymbol{V}_1$、$\boldsymbol{V}_2$和$\boldsymbol{V}_3$的第 i 个头特征；$\bar{\boldsymbol{M}}_i^1$、$\bar{\boldsymbol{M}}_i^2$和$\bar{\boldsymbol{M}}_i^3$分别表示对应三种不同尺度的第 i 个头的加权特征。

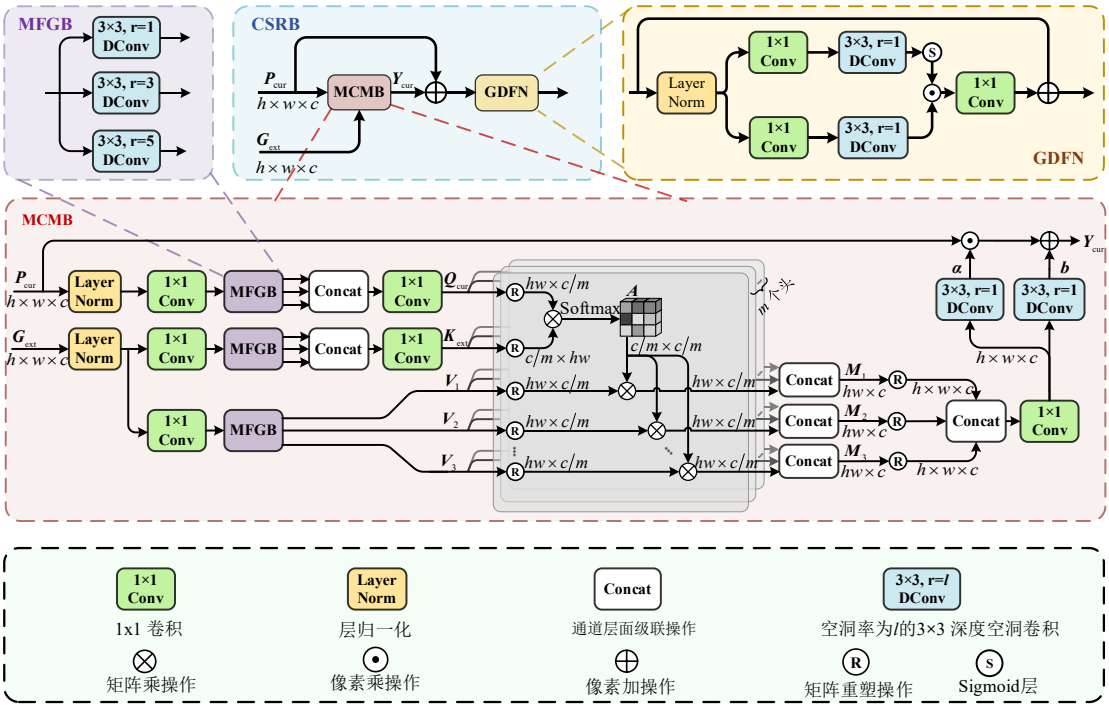


图 5-3 CSRB 的结构

在完成对每个头的注意力计算后，将 m 个头的加权特征沿通道维度级联起来，可以生成$\boldsymbol{M}_1 = [\bar{\boldsymbol{M}}_1^1,\ldots,\bar{\boldsymbol{M}}_m^1]$、$\boldsymbol{M}_2 = [\bar{\boldsymbol{M}}_1^2,\ldots,\bar{\boldsymbol{M}}_m^2]$和$\boldsymbol{M}_3 = [\bar{\boldsymbol{M}}_1^3,\ldots,\bar{\boldsymbol{M}}_m^3]$，其中，$\boldsymbol{M}_1$、$\boldsymbol{M}_2$和$\boldsymbol{M}_3$的特征维度都为$hw\times c$。最后，缩放参数$\boldsymbol{a}$和平移参数$\boldsymbol{b}$可以通过以下公式产生:

中国知网　https://www.cnki.net

$$\boldsymbol{a}=\mathcal{F}_{\text{dconv3}}\left(\mathcal{F}_{\text{conv1}}\left(\mathcal{F}_{\text{Concat}}\left(\mathcal{F}_{\text{r}}\left(\boldsymbol{M}_{1}\right),\mathcal{F}_{\text{r}}\left(\boldsymbol{M}_{2}\right),\mathcal{F}_{\text{r}}\left(\boldsymbol{M}_{3}\right)\right)\right)\right) \tag{5-5-a}$$

$$\boldsymbol{b}=\mathcal{F}_{\text{dconv3}}\left(\mathcal{F}_{\text{conv1}}\left(\mathcal{F}_{\text{Concat}}\left(\mathcal{F}_{\text{r}}\left(\boldsymbol{M}_{1}\right),\mathcal{F}_{\text{r}}\left(\boldsymbol{M}_{2}\right),\mathcal{F}_{\text{r}}\left(\boldsymbol{M}_{3}\right)\right)\right)\right) \tag{5-5-b}$$

式中，函数 $\mathcal{F}_{\text{r}}(\cdot)$ 为矩阵重塑操作，用于将特征的维度从 $hw\times c$ 重塑为 $h\times w\times c$；$\mathcal{F}_{\text{Concat}}(\cdot)$ 表示特征级联操作；$\mathcal{F}_{\text{conv1}}(\cdot)$ 和 $\mathcal{F}_{\text{dconv3}}(\cdot)$ 分别为1×1 卷积层和3×3 深度卷积层。

通过应用CSRB进行特征交互后，采用2个3×3 卷积层进一步提取细化特征，得到特征 $\boldsymbol{F}_{\text{low}}^{\text{r}}$ 和 $\boldsymbol{F}_{\text{high}}^{\text{r}}$，并将其分别与经跳跃连接传输过来的 $\boldsymbol{F}_{\text{low}}$ 和 $\boldsymbol{F}_{\text{high}}$ 相加，形成最终的增强特征 $\tilde{\boldsymbol{F}}_{\text{low}}$ 和 $\tilde{\boldsymbol{F}}_{\text{high}}$，它们可由如下公式表示:

$$\tilde{\boldsymbol{F}}_{\text{low}}=\boldsymbol{F}_{\text{low}}+\mathcal{F}_{\text{conv3br}}\left(\mathcal{F}_{\text{CSRB}}\left(\mathcal{F}_{\text{conv3br}}\left(\boldsymbol{F}_{\text{low}}\right),\mathcal{F}_{\text{conv3br}}\left(\mathcal{F}_{\text{up}}\left(\boldsymbol{F}_{\text{high}}\right)\right)\right)\right) \tag{5-6-a}$$

$$\tilde{\boldsymbol{F}}_{\text{high}}=\boldsymbol{F}_{\text{high}}+\mathcal{F}_{\text{conv3br}}\left(\mathcal{F}_{\text{CSRB}}\left(\mathcal{F}_{\text{conv3br}}\left(\boldsymbol{F}_{\text{high}}\right),\mathcal{F}_{\text{conv3br}}\left(\mathcal{F}_{\text{down}}\left(\boldsymbol{F}_{\text{low}}\right)\right)\right)\right) \tag{5-6-b}$$

其中 $\mathcal{F}_{\text{CSRB}}(\cdot)$ 表示 CSRB 函数；$\mathcal{F}_{\text{conv3br}}(\cdot)$ 表示由3×3 卷积、BN 层和 ReLU 组成的模块；$\mathcal{F}_{\text{down}}(\cdot)$ 和 $\mathcal{F}_{\text{up}}(\cdot)$ 分别表示下采样和上采样操作，均由 Bilinear 实现。

需要强调的是 BFIM 的核心是探索用于最终检测的综合目标线索。换言之，通过考虑相邻阶段特征之间的区别性和互补性，BFIM 可以利用高级特征提供的丰富语义信息来帮助过滤低级特征中的噪声。同时，BFIM 还能从低级特征中提取更精细的空间细节，并将其补充到高级特征中。通过采用这种双向特征交互策略，每个阶段特征都能获得更全面的上下文信息。

5.2.4 基于混合域增强的语义超分辨率增强头模块

在道路交通场景中，远距离的道路异常因其分辨率不足，在正常路面中占比较低，导致其细节特征极其不明显。为了克服这个挑战，图像 SR 技术是一种潜在的解决方案。与第四章提出的 TELOD 在检测器前应用图像 SR 网络提升 LR 图像质量来改进模型检测精度的方式不同，本小节设计的 SSRH 旨在对模型产生的初步预测图进行语义 SR 增强，以此进一步提升远距离道路异常的检测准确率。通过采用 SSRH，模型可以使用更高分辨率的真值标签作为指导，使网络更准确地学习 HR 特征表示，进而提升模型检测精度。值得注意的是，由于初始预测图的空间维度与输入图像一致，都为384×384，在这样大的空间分辨率如果进行复杂的特征细化操作，会引入繁重的计算负担。此外，初步预测图中目标特征比较简单，且通常图中大部分内容为背景并不存在目标信息。基于以上两个原因，SSRH 并不需要采用复杂的网络结构来进行非线性特征映射。

SSRH 的具体结构展示在图 5-2 中的最下面，主要有简单的三部分构成，包括 1 个用于提取初步特征的3×3 卷积、1 个用于特征细化的 HDEM、1 个用于上

中国知网　https://www.cnki.net

采样的反卷积层。值得一提的是，这里用于特征细化的模块采用的是第三章提出的核心模块 HDEM 而不是第二章提出的 MFSB。主要原因在于本章方法是进行像素级检测，需要准确描绘目标的边缘轮廓。因此，HDEM 这种结合了空间域和频率域学习的模块对边缘细节的感知能力更强，从而更适合用于道路异常检测任务。SSRH 的实现过程可以由如下公式表示：

$$\boldsymbol{X}_{\text{map}}^{\text{SR}} = \mathcal{F}_{\text{deconv3}}\left(\mathcal{F}_{\text{HDEM}}\left(\mathcal{F}_{\text{conv3}}\left(\boldsymbol{X}_{\text{map}}\right)\right)\right) + \mathcal{F}_{\text{up}}\left(\boldsymbol{X}_{\text{map}}\right) \tag{5-7}$$

式中，$\mathcal{F}_{\text{conv3}}(\cdot)$和$\mathcal{F}_{\text{deconv3}}(\cdot)$分别表示3×3 的卷积和反卷积函数；$\mathcal{F}_{\text{HDEM}}(\cdot)$为第二章提出的 HDEM 函数。

5.2.5 损失函数

在 JCFI-SRNet 的训练过程中，主要采用初始预测损失$\mathcal{L}_{\text{C-head}}$和语义 SR 损失$\mathcal{L}_{\text{SSRH}}$来对初始预测图和最终预测图进行监督。这两个损失函数都由加权二元交叉熵（Binary Cross Entropy，BCE）损失$\mathcal{L}_{\text{BCE}}^{\text{W}}$和加权 IoU 损失函数$\mathcal{L}_{\text{IoU}}^{\text{W}}$组成。JCFI-SRNet 的总损失函数定义为：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{C-head}} + \mathcal{L}_{\text{SSRH}} \tag{5-8-a}$$

$$\mathcal{L}_{\text{C-head}} = \lambda_{\text{c1}}\mathcal{L}_{\text{BCE}}^{\text{W}}\left(\boldsymbol{X}_{\text{map}}, \boldsymbol{G}_{\text{map}}\right) + \lambda_{\text{c2}}\mathcal{L}_{\text{IoU}}^{\text{W}}\left(\boldsymbol{X}_{\text{map}}, \boldsymbol{G}_{\text{map}}\right) \tag{5-8-b}$$

$$\mathcal{L}_{\text{SSRH}} = \lambda_{\text{s1}}\mathcal{L}_{\text{BCE}}^{\text{W}}\left(\boldsymbol{X}_{\text{map}}^{\text{SR}}, \boldsymbol{G}_{\text{map}}^{\text{SR}}\right) + \lambda_{\text{s2}}\mathcal{L}_{\text{IoU}}^{\text{W}}\left(\boldsymbol{X}_{\text{map}}^{\text{SR}}, \boldsymbol{G}_{\text{map}}^{\text{SR}}\right) \tag{5-8-c}$$

其中，$\boldsymbol{G}_{\text{map}} \in \mathbb{R}^{H\times W\times 1}$和$\boldsymbol{G}_{\text{map}}^{\text{SR}} \in \mathbb{R}^{2H\times 2W\times 1}$分别为初步掩码标签和高分辨率掩码标签，它们都由真值掩码图经过 Bilinear 操作插值得到；λ_{c1}、λ_{c2}、λ_{s1}和λ_{s2}都为损失函数的权重系数，都默认设置为 1。

（1）加权 BCE 损失函数

BCE 损失是分类任务中常用的损失函数，用于衡量预测值和真实标签的概率分布差距。加权 BCE 损失是在 BCE 损失的基础上进行改进的。它通过给不同类别赋予特定权重，来调节各类别的重要程度，能够有效应对前景与背景样本不均衡的问题。$\mathcal{L}_{\text{BCE}}^{\text{W}}$可以由以下公式表示：

$$\mathcal{L}_{\text{BCE}}^{\text{W}} = -\frac{1}{N_{\text{pn}}}\sum_{i=1}^{N_{\text{pn}}}\psi_i\cdot\bar{y}_i\cdot\tilde{y}_i\cdot\log\left(\tilde{y}_i\right) + \left(1-\psi_i\right)\cdot\left(1-\bar{y}_i\right)\cdot\log\left(1-\tilde{y}_i\right) \tag{5-9}$$

式中，$\tilde{y}_i$为网络预测的第 i 个像素属于前景的概率，值范围为$[0,1]$；$\bar{y}_i$为第 i 个像素的真实概率，其值若为 0 则为背景，为 1 则是前景；ψ_i表示第 i 个像素的权重；N_{pn}为图像像素总数。

（2）加权 IoU 损失函数

IoU 的定义详见公式（4-12），不同的是，在第四章的 IoU 是按矩形框面积

中国知网 https://www.cnki.net

计算 IoU，而在本章是按不规则的分割区域来计算。根据公式（4-12）得到 IoU 值后，$\mathcal{L}_{\mathrm{IoU}}^{\mathrm{W}}$ 可以由如下公式表示：

$$\mathcal{L}_{\mathrm{IoU}}^{\mathrm{W}} = 1 - w_{\mathrm{IoU}}\mathrm{IoU} \tag{5-10}$$

式中，w_{IoU} 为 IoU 值的权重系数。与加权 BCE 损失函数类似，都是通过加权的方式来解决样本不平衡问题。

5.3 实验结果与分析

5.3.1 数据集

（1）UDTIRI 数据集

UDTIRI[73]（Urban Digital Twins Intelligent Road Inspections）是由同济大学提出的用于路面异常检测的数据集，共有 1000 幅图像。UDTIRI 数据集分为训练集、验证集和测试集，其具体信息展示表 5-1 中。UDTIRI 数据集中图像包含不同尺度目标，且它们是在不同光照和天气条件下的真实场景中拍摄得到，能反映实际道路环境的多样性。由于官方没有公布 UDTIRI 测试集的真值图，因此本章将验证集作为测试集的一部分。

表 5-1 UDTIRI 数据集具体信息汇总

数据集	Train 图像数	Val 图像数	Test 图像数
图像数量	600	100	300
目标数量	885	151	426

（2）RDD2022 数据集

RDD2022[152]全称为 Road Damage Dataset 2022，其包含六个国家的道路图像数据，分别为中国、日本、捷克、挪威、美国和印度。该数据集涵盖了这 6 个国家实际路况图片，反映了不同地区的道路状况和特点，便于推动计算机视觉在道路交通领域的应用。RDD2022 共有 47420 张道路图像组成，包含了不同类型的道路异常，图像带有超过 55000 个道路损害实例标注。

由于 RDD2022 数据集只提供有矩形框的标注，为将其用于像素级预测任务，从中筛选了 230 幅包含了道路异常的图像，并采用 Labelme 软件进行像素级标注。其中，150 幅图像与 UDRITI-Train 联合组成新的训练集 RAD-Train（Road Anomaly Detection-Train）用于模型的训练，80 幅图像与 UDRITI-Val 组成新的测试集 RAD-Test 用于模型的测试。

5.3.2 实验设置

本章所有训练和测试的结果都是在 Ubuntu 18.04 的操作系统上和搭载 32G

中国知网 https://www.cnki.net

内存、NVIDIA GTX 1080Ti GPU 的硬件环境上得到。所有模型都采用 PyTorch 深度学习框架进行搭建和训练。在训练和测试阶段，所有方法都先应用 Bilinear 操作将所有输入图像调整为384×384 的大小再输入到网络中。在训练数据处理方面，本章采用随机翻转、旋转和裁剪等数据增强策略来提升模型的泛化能力。在训练过程中，使用 ADAM 作为优化器，并将其中关键参数设定为 $\beta_1 = 0.9$、$\beta_2 = 0.999$ 和 $\varepsilon = 10^{-8}$。初始学习率设置为 5×10^{-5}，训练期间每 50 个轮次学习率降低为原来的1/10。批量大小和总训练轮次分别设置为 12 和 100。本章所提的 JCFI-SRNet 的骨干网络采用 SMT 预训练模型来初始化。在对骨干网络每个阶段特征进行转换时，设置 $\hat{\boldsymbol{F}}_i$ 的通道维度为 96。

5.3.3 评价指标

本章采用4个评价指标来衡量模型的性能，包括结构度量（Structure-measure，S_α）[153]、F 度量（F-measure，F_β）[154]、平均绝对误差（Mean Absolute Error，MAE）[155]和 E 度量（E-measure，E_ϕ）[156]。假定模型输出的预测图为 $\hat{\boldsymbol{P}}$ 和对应的真值图为 $\hat{\boldsymbol{G}}$，接下来对各个评价指标计算方式进行详细说明。

（1）结构度量 S_α

S_α 指标主要用来评估网络预测图和二值真值图之间的结构相似度，其由以下公式表示：

$$S_\alpha = \alpha \times S_o + (1-\alpha) \times S_r \tag{5-11}$$

式中，S_o 和 S_r 分别为面向目标和区域的感知相似度度量；α 是一个用于平衡区域和目标的感知相似度的参数，默认设置为 0.5；S_α 值越高，表示模型预测图与真值图的结构相似度越高，模型性能越好。

（2）F 度量 F_β

F_β 是 Precision 和 Recall（定义详见公式（4-13）和公式（4-14））的加权调和平均值，综合考虑了模型的精度和召回率，可由以下公式表示：

$$F_\beta = \frac{(1+\beta^2) \times \text{Precision} \times \text{Recall}}{\beta^2 \times \text{Precision} + \text{Recall}} \tag{5-12}$$

式中 β 是用来平衡 Precision 和 Recall 的参数，β^2 默认设置为 0.3；通过不同的 Precision-Recall 对，可以得到不同类型的 F_β 得分，包括最大值 F-度量（$F_\beta^{\max}$）、平均 F 度量（F_β^{m}）、自适应 F-度量（F_β^{a}）以及加权 F-度量（F_β^{w}）。在本章采用的是 F_β^{w} 来综合评估模型的性能。。

（3）平均绝对误差 MAE

MAE 主要通过逐像素计算模型输出预测图和真值图之间的绝对误差的平均

中国知网 https://www.cnki.net

值，以此衡量模型预测图的质量，其可由以下公式表示：

$$\mathrm{MAE}=\frac{1}{W\times H}\sum_{i=1}^{W}\sum_{j=1}^{H}\left|\hat{\boldsymbol{P}}(i,j)-\hat{\boldsymbol{G}}(i,j)\right| \tag{5-13}$$

式中，$\hat{\boldsymbol{P}}(i,j)$和$\hat{\boldsymbol{G}}(i,j)$分别表示预测图和真值图中坐标为$(i,j)$上的像素值。MAE 值越小，表明预测图与真值图之间的误差越小，模型性能越好。

（4）E 度量E_ϕ

E_ϕ通过同时考虑像素层面的全局和局部对齐性来衡量预测图和真值图之间的形态及位置的一致性，其可由如下公式表示：

$$E_\phi=\frac{1}{W\times H}\sum_{i=1}^{W}\sum_{j=1}^{H}\phi_{\mathrm{FM}}\left(\hat{\boldsymbol{P}}(i,j),\hat{\boldsymbol{G}}(i,j)\right) \tag{5-14}$$

式中，$\phi_{\mathrm{FM}}(\cdot)$表示增强的对齐矩阵。$E_\phi$值在 0 和 1 之间，越接近 1 表明预测图越接近真值图，模型的性能越好。E_ϕ同样也提供了三种类型指标值，包括最大 E-measure（$E_\phi^{\max}$）、平均 E-measure（E_ϕ^{m}）和自适应 E-measure（E_ϕ^{a}）。在本章中，采用E_ϕ^{m}来对模型性能进行评估。

5.3.4 消融实验

本小节将进行一系列消融实验，以评估本章所提出的 JCFI-SRNet 中不同组件和超参数设置对模型性能的影响。所有实验结果均由模型在 RAD-Test 数据集上计算所得。采用的评价指标为S_α、F_β^{w}、MAE 和E_ϕ^{m}，指标旁边的↑/↓表示数字越大或越小越好。

（1）JCFI-SRNet 中不同组件的有效性

表 5-2 展示了 CSFPN w/o CSRB、CSRB 以及 SSRH 对模型性能影响的结果。其中，CSFPN w/o CSRB 和 CSFPN w/ CSRB 分别表示 CSFPN 有和没有采用 CSRB 模块。基准网络由 1 个 SMT 主干网、4 个1×1 卷积层以及 1 个初始预测模块构成。当使用不含 CSRB 的 CSFPN 代替基准网络中 4 个1×1 卷积层来对四阶段骨干特征进行特征转换后，可以得到网络$\mathbb{Z}_a$；$\mathbb{Z}_{\mathrm{b}}$是在网络$\mathbb{Z}_a$的基础上，通过引入 CSRB 代替原有的3×3 积来实现特征交互功能后产生的变种网络；网络$\mathbb{Z}_{\mathrm{c}}$是完整版本的 JCFI-SRNet。

从表 5-2 中可以得出以下 3 个结论：

1） 与基准网络相比，网络$\mathbb{Z}_a$实现了显著的改进。例如，在指标S_α和F_β^{w}上，网络$\mathbb{Z}_a$分别得到了 0.012 和 0.017 的提升。原因在于基准网络在编码和解码步骤之间仅是采用简单的1×1 卷积进行通道特征聚合，没有实现有效的特征转换。不同于基准网络，网络$\mathbb{Z}_a$所采用的 CSFPN w/o CSRB 可以通过利用相邻阶段特征的互补性来改进各阶段骨干特征，为后续解码

中国知网 https://www.cnki.net

步骤提供更综合的目标线索，从而增强模型的表达能力。

2） 相比网络$\mathbb{Z}_a$，网络$\mathbb{Z}_b$通过进一步引入 CSRB，使性能得到了提升。这得益于 CSRB 通过设计的 MCMB 从多尺度层面探索 2 个不同阶段特征之间的长程依赖关系，实现了特征信息的深度整合，提升了模型感知能力。

3） 通过进一步接入 SSRH，网络$\mathbb{Z}_c$在 3 个指标上都实现了一定提升。这说明了 SSRH 所采用的语义 SR 策略，可以帮助网络更好地识别特征不显著的道路异常，从而有效改善模型检测性能。

表 5-2 JCFI-SRNet 中不同组件对模型性能的影响

方法		基准网络	$\mathbb{Z}_a$	$\mathbb{Z}_b$	$\mathbb{Z}_c$
CSFPN w/o CSRB		×	✓	×	×
CSFPN w/ CSRB		×	×	✓	✓
SSRH		×	×	×	✓
RAD-Test	$S_\alpha\uparrow$	0.790	0.802	0.805	**0.808**
	$F_\beta^{\mathrm{w}}\uparrow$	0.620	0.637	0.649	**0.661**
	MAE↓	0.012	0.012	**0.011**	**0.011**
	$E_\phi^{\mathrm{m}}\uparrow$	0.862	0.870	0.873	**0.879**
参数（M）		**11.60**	12.14	12.21	12.23

（2）CSFPN 的有效性

为验证 CSFPN 的有效性，将其与其他 4 种特征转换策略进行了比较，所得实验结果展示在表 5-3 中。其中，网络“1×1 Conv”与表 5-2 中的基准网络为同一个；“3×3 Conv”、“TEM”和“ERF”分别指采用3×3 卷积、TEM[108]和 ERF[109]代替网络“1×1 Conv”中的1×1 卷积来执行特征转换功能而产生的变种网络；“CSFPN”是指 JCFI-SRNet 去掉 SSRH 后得到的变种网络，其与表 5-2 中的网络$\mathbb{Z}_b$为同一个。

从表 5-3 中可以得出以下 3 个结论：

1） 虽然网络“1×1 Conv”消耗的参数最少，但由于1×1 卷积层本身的特性所致，其仅能执行通道层面的信息聚集，而缺乏局部特征提取能力。因此，网络“1×1 Conv”的性能最差。

2） 与网络“1×1 Conv”相比，虽然网络“3×3 Conv”、“TEM”和“ERF”分别采用不同局部特征提取方式来增强特征表示能力，提高了模型检测精度。但是，它们对每个阶段骨干特征的特征转换过程都是采用单独处理的策略，没有考虑不同阶段特征之间的相关性，从而限制了模型对低对比度道路异常以及形状各异特别是小尺寸异常的检测能力。

3） 与其他网络不同，网络“CSFPN”通过采用跨阶段特征融合策略，探索了一种更全面的空间和语义特征表示方法，使其在 4 个评价指标上都得到最优结果。值得注意的是，网络“CSFPN”在实现高性能的同时，其

中国知网 https://www.cnki.net

参数量仍低于所有网络（除网络“1×1 Conv”外），这主要是因为 CSFPN 采用了特征切片策略以及引入了大量的1×1 卷积和深度卷积，有效改善分割精度的同时，避免了大量网络参数的引入。

表 5-3 不同特征转换策略对模型性能的影响

特征转换策略		1×1 Conv	3×3 Conv	TEM[108]	ERF[109]	CSFPN
RAD-Test	$S_\alpha\uparrow$	0.790	0.800	0.795	0.802	**0.805**
	$F_\beta^{\mathrm{w}}\uparrow$	0.620	0.627	0.633	0.635	**0.649**
	MAE↓	0.012	0.012	0.012	0.012	**0.011**
	$E_\phi^{\mathrm{m}}\uparrow$	0.862	0.865	0.855	0.864	**0.873**
参数（M）		**11.60**	12.34	15.41	15.31	12.21

（3）CSRB 的有效性

为了评估所提出的 CSRB 的有效性，将其与另外两种特征调制模块进行比较，包括空间特征变换（Spatial Feature Transform，SFT）模块[151]和标准 Transformer 的多头交叉注意模块（Multi-head Cross-Attention Block，MCAB）[110]，所得到的比较实验结果展示在表 5-4 中。其中，“MCAB”是指采用常规多头注意力 MCAB 替换 CSRB 中的 MCMB 后得到的变种网络。为了公平地进行比较，本小节实验中的 MCAB 是采用与本章所提出的 MCMB 一样的注意力图计算策略：沿着特征的通道维度而不是空间维度进行计算。“SFT”是指用 SFT 代替 CSRB 而构建的变体网络。SFT 主要由一个残差单元和两个深度3×3 卷积层构成，后者分别用于学习缩放和平移参数，即公式（5-2）中的 $\boldsymbol{a}$ 和 $\boldsymbol{b}$。网络“CSRB”等同于表 5-2 中的网络 $\mathbb{Z}_{\mathrm{b}}$。为避免不同模块之间的组合效应影响实验结果，以上网络都没有引入 SSRH 模块。

从表 5-4 中可以看出，相比于网络“MCAB”和“SFT”，网络“CSRB”在参数略有增加的情况下得到更好的性能。这说明了利用两个输入特征之间的多尺度远距离依赖关系来调制特征比简单地进行交叉注意和以局部的方式调制特征更加有效。

表 5-4 不同特征调制模块对模型性能的影响。

方法		MCAB[110]	SFT[151]	CSRB
RAD-Test	$S_\alpha\uparrow$	0.803	0.802	**0.805**
	$F_\beta^{\mathrm{w}}\uparrow$	0.643	0.643	**0.649**
	MAE↓	**0.011**	0.012	**0.011**
	$E_\phi^{\mathrm{m}}\uparrow$	**0.873**	0.871	**0.873**
参数（M）		12.07	**11.89**	12.21

（4）特征 $\hat{\boldsymbol{F}}_i$ 通道维度的影响

表 5-5 展示了特征 $\hat{\boldsymbol{F}}_i$ 的不同通道维度对模型性能影响的结果。从表 5-5 中可以观察得到，当通道维度从 32 增加到 128 时，模型在 RAD-Test 数据集上的性能

中国知网 https://www.cnki.net

逐渐提高。然而，当通道维度大于 96 时，模型性能提升幅度较小。此外，由于特征通道维度不断增大，导致模型参数量也在不断增大。通过综合考虑模型性能和参数量的平衡问题，本章将特征 $\hat{\boldsymbol{F}}_i$ 的通道维度设为 96。

表 5-5 特征 $\hat{\boldsymbol{F}}_i$ 不同通道维度对模型性能的影响

$\hat{\boldsymbol{F}}_i$ 的通道维度		32	64	96	128
RAD-Test	$S_\alpha \uparrow$	0.783	0.797	0.805	0.805
	$F_\beta^{\mathrm{w}} \uparrow$	0.600	0.624	0.649	0.650
	MAE↓	0.012	0.012	0.011	0.012
	$E_\phi^{\mathrm{m}} \uparrow$	0.852	0.863	0.873	0.876
	参数（M）	11.62	11.85	12.21	12.69

5.3.5 与其他方法的比较

（1）客观评价

为评估本章所提方法 JCFI-SRNet 的有效性，将其与 3 种经典语义分割方法和 6 种 COD 方法进行定量比较。其中，语义分割方法包括 PSPNet[84]、DeepLab-v3+[85]和 SegFormer[86]；COD 方法包括 PFNet[98]、SINet-v2[106]、FAPNet[99]、BSANet[101]、FEDER[107]和 SARNet[124]。表 5-6 列出了不同方法在 RAD-Test 上的检测结果。

从表 5-6 中可以看出：

表 5-6 不同方法采用评价指标 S_α、F_β^{w}、MAE 和 E_ϕ^{m} 进行检测性能比较

方法	$S_\alpha \uparrow$	$F_\beta^{\mathrm{w}} \uparrow$	MAE↓	$E_\phi^{\mathrm{m}} \uparrow$
PSPNet[84]	0.737	0.512	0.025	0.804
DeepLab-v3+[85]	0.772	0.596	0.014	0.843
SegFormer[86]	0.788	0.622	0.012	0.872
PFNet[98]	0.768	0.573	0.013	0.855
SINet-v2[106]	0.775	0.589	0.012	0.833
FAPNet[99]	0.781	0.631	0.012	0.867
BSANet[101]	0.781	0.601	0.012	0.842
FEDER[107]	0.781	0.611	0.012	0.861
SARNet[124]	0.780	0.634	**0.011**	0.864
JCFI-SRNet（本章方法）	**0.808**	**0.661**	**0.011**	**0.879**

1） 本章方法 JCFI-SRNet 在所有评价指标上都得到最优的结果，且所消耗的参数量和计算量也是最少的（详细参数和 FLOPs 见表 5-7）。例如，与 SARNet 相比，JCFI-SRNet 在 S_α、F_β^{w}、E_ϕ^{m} 上分别提高了 0.028、0.027 和 0.015。得到上述结果主要归功于精心设计的 CSFPN 和 SSRH。其中，CSFPN 采用跨阶段特征交互策略，帮助每个阶段特征学习更全面的上下文知识，从而更好地捕捉道路异常的细微特征差异。另一方面，SSRH 通过对初步预测图进行语义 SR，增强了模型对小尺寸道路异常的检测能

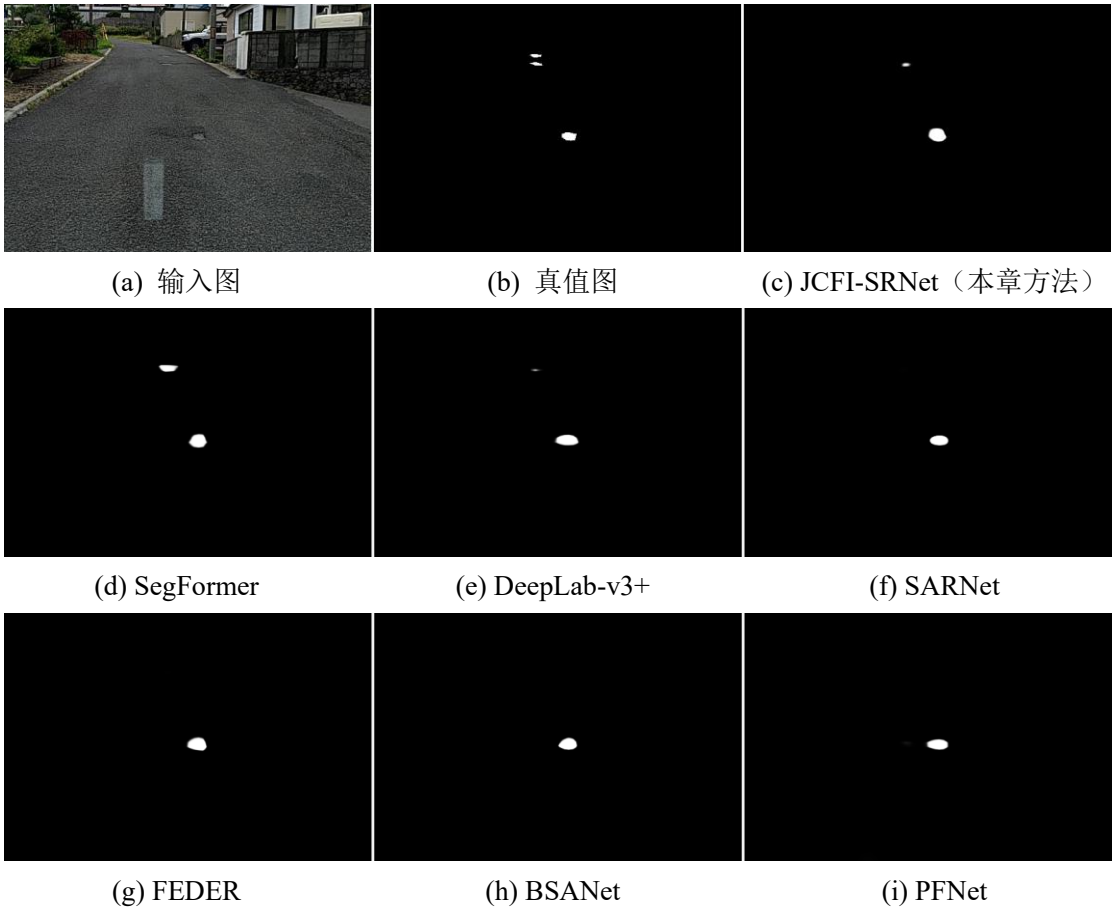
中国知网 https://www.cnki.net

力，进一步提升了检测准确性。

2） 在大多数情况下，COD 方法比语义分割方法表现更优，说明在检测道路异常任务上，COD 方法更适用。在道路交通场景中，由于道路异常自身属性限制，且容易受光照、天气等环境因素影响，导致其与周围背景存在较高的相似度。从本质上来说，道路异常与伪装目标的特性是相近的。因此，得到上述结果的原因可能在于 COD 方法是针对伪装特性场景进行设计和优化的，其能通过有效提取目标与背景之间的差异，从而更好地对特定隐蔽目标进行精确定位和识别。而语义分割方法更侧重于对图像整体语义的理解，具备更强的通用性。

（2）主观评价

为了验证本章方法 JCFI-SRNet 的有效性，将其与 6 种方法在 RAD-Test 数据集图像中进行定性比较。比较的方法包括 DeepLab-v3+[85]、SegFormer[86]、PFNet[98]、BSANet[101]、FEDER[107]和 SARNet[124]。所得可视化结果展示在图 5-4~图 5-7 中。



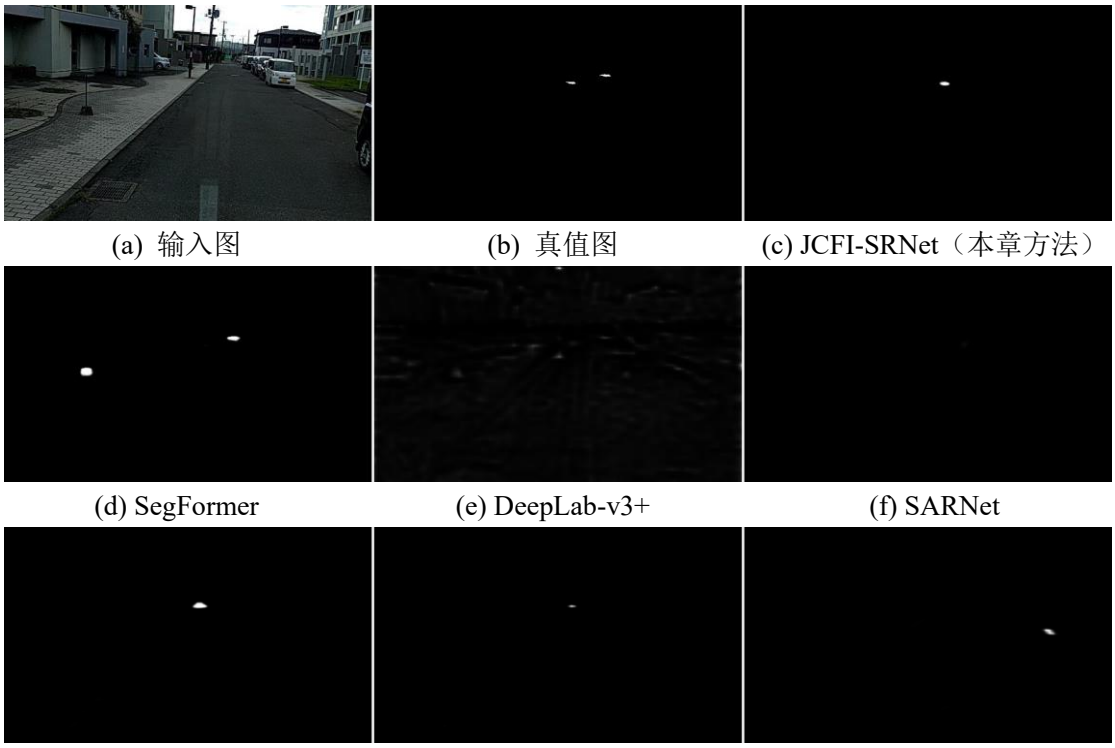
(a) 输入图　(b) 真值图　(c) JCFI-SRNet（本章方法）

(d) SegFormer　(e) DeepLab-v3+　(f) SARNet

(g) FEDER　(h) BSANet　(i) PFNet

图 5-4 不同方法对 RAD-Test 数据集中 Japan_000363 号图像的检测结果比较

中国知网 https://www.cnki.net

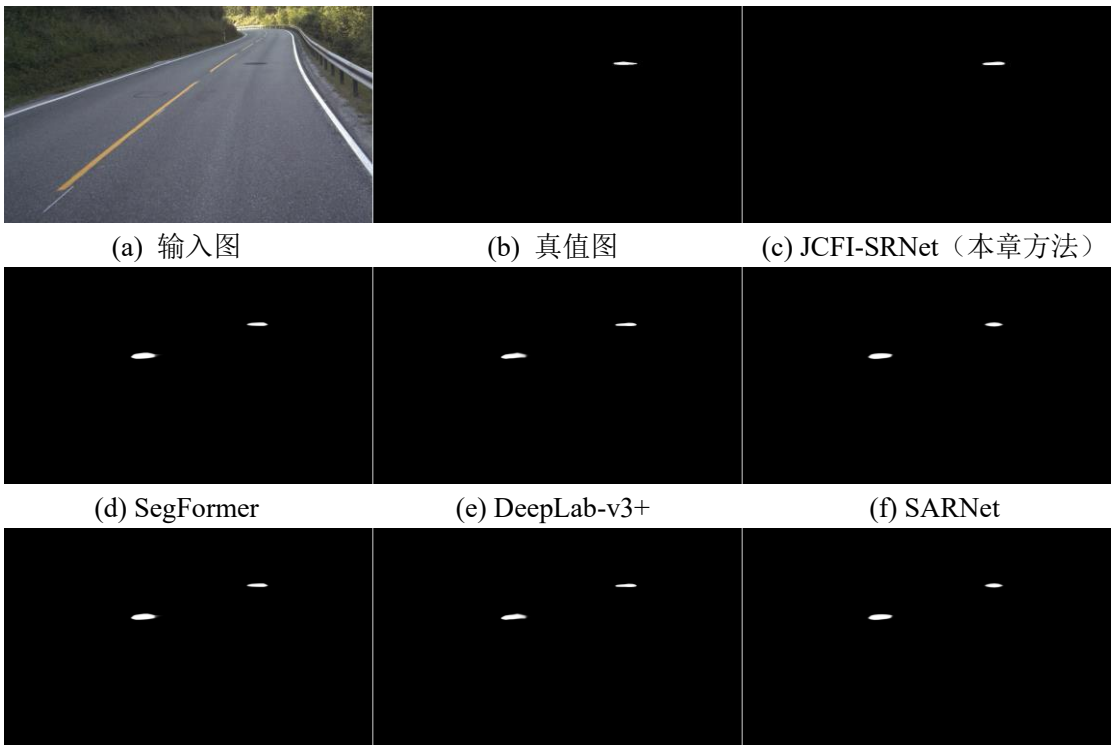


(a) 输入图　(b) 真值图　(c) JCFI-SRNet（本章方法）

(d) SegFormer　(e) DeepLab-v3+　(f) SARNet

(g) FEDER　(h) BSANet　(i) PFNet

图 5-5 不同方法对 RAD-Test 数据集中 Japan_000933 号图像的检测结果比较



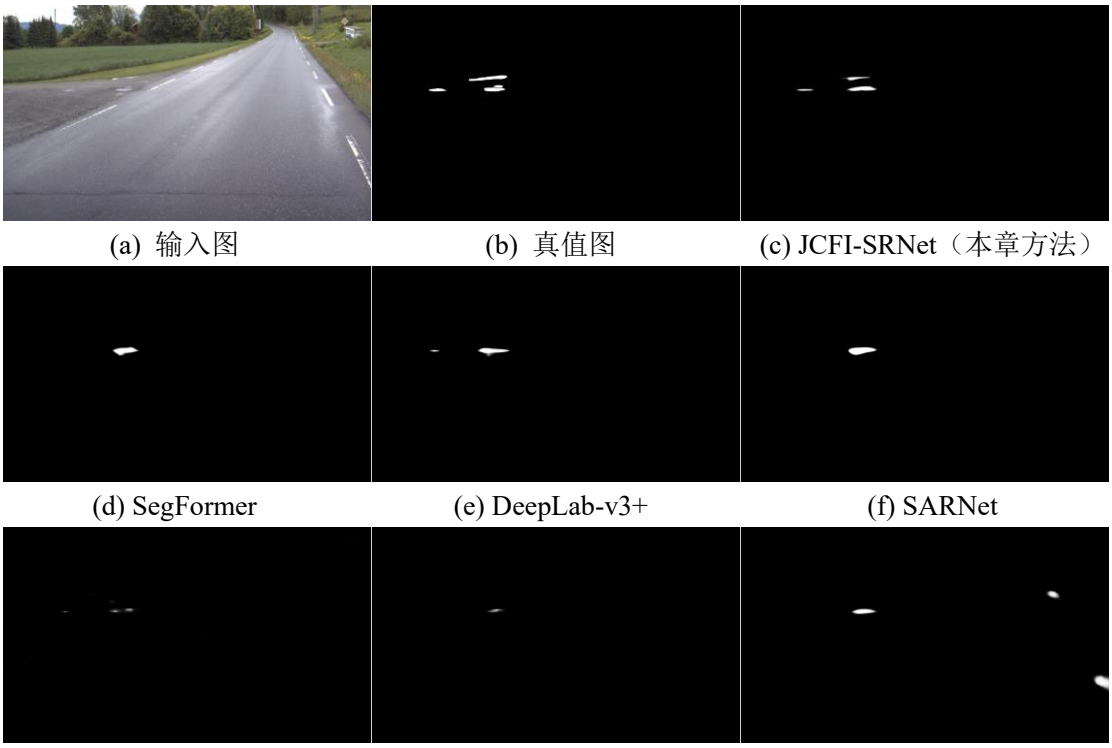
(a) 输入图　(b) 真值图　(c) JCFI-SRNet（本章方法）

(d) SegFormer　(e) DeepLab-v3+　(f) SARNet

(g) FEDER　(h) BSANet　(i) PFNet

图 5-6 不同方法对 RAD-Test 数据集中 Norway_003608 号图像的检测结果比较

中国知网　https://www.cnki.net



(a) 输入图　(b) 真值图　(c) JCFI-SRNet（本章方法）

(d) SegFormer　(e) DeepLab-v3+　(f) SARNet

(g) FEDER　(h) BSANet　(i) PFNet

图 5-7 不同方法对 RAD-Test 数据集中 Norway_007400 号图像的检测结果比较

从图 5-4~图 5-7 中可以看出，与其他方法相比，本章所提方法 JCFI-SRNet 在所有比较样例上均得到更好的检测结果，这充分说明了其在检测远距离道路异常任务上的有效性。例如，从图 5-4 和图 5-5 中可见，JCFI-SRNet 能更准确地检测出小尺寸的道路异常。此外，JCFI-SRNet 对远距离的道路异常也能实现更精准的定位。如图 5-6 和图 5-7 所示，JCFI-SRNet 的分割结果明显出现更少的假阳区域和更低的漏检率，与真值图更为接近。得到以上结果主要得益于本章所设计的 CSFPN 和 SSRH。CSFPN 通过利用跨阶段特征交互策略提供网络更综合的感知能力，使其能从这低对比度路面上也能捕捉到细微异常。而 SSRH 则通过语义 SR 增强的方式，有效增强小尺寸异常的特征，从而提升了检测率。

5.3.6 模型参数、计算复杂度与运行时间分析

表 5-7 展示了不同方法详细的模型参数、FLOPs、运行时间以及 F1 得分。运行时间是每个模型在 NVIDIA GTX 1080Ti GPU 上循环运行 100 次并计算平均值得到的结果。从表 5-7 中可以看出，本章方法 JCFI-SRNet 具有最少的参数量和 FLOPs 值。这主要是因为 JCFI-SRNet 引入特征切分策略以及采用大量1×1 和 3×3 卷积层和深度卷积层，避免了引入大量参数和计算复杂度。而其他方法大多是由于采用大尺寸骨干网络或者构建复杂解码器而导致模型产生高的 FLOPs 和

中国知网　https://www.cnki.net

参数量。在所比较的方法中，虽然 JCFI-SRNet 的运行速度并不是最快的，但其 F1 得分是最高的。总体而言，本章所提出的 JCFI-SRNet 在保持适当运行速度的同时，能以最低的 FLOPs 和参数量实现最优异的模型性能。

表 5-7 不同方法的参数、FLOPs 和运行时间比较

方法	参数（M）↓	FLOPs（G）↓	运行时间（s）↓	F_β^w ↑
PSPNet[84]	85.94	36.86	0.023	0.512
DeepLab-v3+[85]	59.34	50.03	0.019	0.596
SegFormer[86]	47.22	40.17	0.037	0.622
PFNet[98]	46.50	26.75	0.018	0.573
SINet-v2[106]	26.98	14.65	**0.013**	0.589
FAPNet[99]	29.52	35.41	0.023	0.631
BSANet[101]	32.58	29.75	0.028	0.601
FEDER[107]	46.34	37.28	0.043	0.611
SARNet[124]	46.96	23.21	0.038	0.634
JCFI-SRNet（本章方法）	**12.23**	**11.12**	0.031	**0.661**

5.4 本章小结

针对交通场景中远距离道路异常特征不显著导致检测困难的问题，本章提出了一种名为 JCFI-SRNet 的新颖检测框架。为了更好地表征编码信息中各种尺寸的目标特征，特别是小尺寸目标，CSFPN 通过利用各阶段骨干特征与其相邻阶段特征之间的相关性，来实现有效的特征转换，从而为后续解码特征提供更全面的异常线索。BFIM 作为 CSFPN 的核心，旨在通过应用设计的 CSRB 和双向连接结构，实现相邻两个阶段特征之间的信息互补。为深度整合当前输入特征和外部指导特征，在 CSRB 中引入了 MCMB，以充分探索它们之间的多尺度长距离依赖关系。为进一步解决远距离道路异常因像素信息缺乏而难以有效识别的问题，提出了一个 SSRH 来对初步预测图进行 SR 重构。该模块主要由第三章方法核心模块 HDEM 构成，通过利用 HR 语义信息作为先验指导，使模型学习到更准确的特征信息。实验表明，与经典语义分割方法和 COD 方法相比，本章方法 JCFI-SRNet 在模型性能、参数、FLOPs 和运行速度之间实现了最佳平衡。

中国知网 https://www.cnki.net

第 6 章 总结与展望

6.1 总结

本文主要以深度学习技术为基础，在道路交通场景下，围绕低质图像增强与目标检测方法进行了深入系统地研究。针对低质图像增强技术所面临的两个主要问题分别提出了不同的解决方案，即基于空间域多尺度特征选择的低质图像增强方法和基于空间域和频率域混合的低质图像增强方法。此外，针对图像低质量和目标低对比度所带来的检测难题，本文探索了两种有效的目标检测方法，即基于双阶段增强的低质图像道路交通目标检测方法和联合跨阶段特征交互和语义增强的远距离道路异常检测方法。具体来说，本文的主要研究内容和取得的重点研究成果如下：

（1）基于空间域多尺度特征选择的低质图像增强方法

针对低质图像增强方法通常采用像素加等静态方式融合多尺度特征导致模型适应能力弱的问题，提出一种基于 MFSN 的低质图像增强方法。作为 MSFN 的核心构建模块，MFSB 主要采用多支路并行且渐进连接的结构设计来从粗到细的感受野层面上提取不同尺度的特征。此外，在 MFSB 中相邻两条支路的连接处，采用精心设计的 SSM 来动态选择不同尺度特征进行组合，以实现多尺度特征的高效表达。在 SSM 中，构建了 CCAM 来综合考虑局部和全局的通道关系，以生成准确的通道权重，从而实现有效特征挑选。大量客观与主观结果表明，该方法能以较少的参数实现较好的图像重建结果。

（2）基于空间域和频率域混合的低质图像增强方法

针对大多低质图像增强方法仅依赖单一空间域的信息来学习致使模型特征表达能力受限的问题，提出了基于 HDEN 的低质图像增强方法。为了综合利用空间域和频率域信息，提出一种混合域增强模块 HDEM。该模块主要由两个并行分支和一个1×1卷积构成。其中，两个并行分支分别由 SDEB 和 FDEB 组成，用于实现空间域和频率域的特征增强。而1×1卷积则用于双域增强特征的进一步融合。为了有效利用不同感受野范围来捕捉更丰富的上下文信息，SDEB 采用 3 种不同空洞率下的宽激活残差单元来实现多尺度特征提取功能。为了增加尺度信息的同时避免引入参数和计算量，额外构建了一条直连支路。对于 FDEB，先是采用 DWT 对特征进行多频分解，然后将所有频率分量进行级联并使用深度可分离卷积来提取频率之间的依赖关系，进而实现频率域的特征增强。经过大量实验表明，相较于其他方法，该方法在所有测试集上都能取得更优的结果。

（3）基于双阶段增强的低质图像道路交通目标检测方法

中国知网 https://www.cnki.net

针对道路交通场景下低质图像细节丢失、纹理模糊导致目标检测准确率低的问题，提出基于双阶段增强的低质图像道路交通目标检测方法。所提出的检测框架 TELOD 主要包含图像增强和特征增强两个阶段。对于图像增强阶段，为缓解多降质因素导致的图像重建难度大问题，提出了一个 TDEN，通过采用任务分解增强策略，有效改善了低质图像的质量。TDEN 主要由 IRB 和 REB 构成，通过将它们的特征提取器进行权重共享，能有效利用图像复原和分辨率增强两个子任务之间的相关性，同时避免引入额外参数。在共享特征提取器中，采用了第二章提出的 MFSB 作为核心部件，有效增强了不同尺寸目标的特征。在特征增强阶段，提出一个 AFEH，其以跨注意力的方式引入 TDEN 中的增强特征来对检测特征的空间信息进行补充。同时，AFEH 采用 HR 图像特征先验作为指导，进一步缩小 SR 与 HR 图像上的特征域差距。值得注意的是，AFEH 仅在训练阶段使用，而在推理阶段丢弃，不会额外增加模型的计算负担和参数。总体而言，第四章提出的 TELOD 能针对低质图像进行高效的检测，相比其他的方法，也具有明显的优越性。

（4）联合跨阶段特征交互和语义增强的远距离道路异常检测方法

针对远距离道路异常在图像中像素占比少和特征不显著导致检测难度大的问题，提出联合跨阶段特征交互和语义增强的远距离道路异常检测方法。首先，为了得到优越的基础编码特征，采用结合了 CNN 和 Transformer 优势的 SMT 作为骨干网络来提取图像局部和全局信息。然后，设计了 CSFPN 用于将基础骨干特征转换成更紧凑和更具表达能力的增强特征。CSFPN 主要采用 BFIM 来将每个阶段的骨干特征进行细化。BFIM 能有效地将更高阶段特征的语义信息以及更低阶段的空间信息整合到当前阶段特征中，以实现更全面的特征表达。其中，为了在 BFIM 中深度融合当前和相邻阶段特征，提出 CSRB，其主要由 MCMB 和 GDFN 组成。MCMB 主要通过从多尺度层面来应用跨注意力机制去学习两个输入特征之间的长距离依赖关系，并以仿射变换的方式实现特征融合。GDFN 则是用于对融合后的特征做进一步的特征变换。最后，引入一个 SSRH 并辅以 HR 语义标签作为指导，对初步预测图执行分辨率增强，以有效提升小尺寸道路异常的检测准确率。在 SSRH 中，核心的特征提取模块采用的是第三章提出的 HDEM，以有效增强网络对目标边界的感知能力。总的来说，相较于其他方法，该方法无论是在参数和计算开销还是性能上，都具有较大的优势。

6.2 展望

本文围绕道路交通场景下低质图像增强及目标检测方法进行了深入研究，所提出的 4 种方法能较好地解决了该研究领域内的一些重要挑战。然而，当前研究

中国知网 https://www.cnki.net

仍存在一些考虑不到位或者被忽视的问题，在后续的研究工作中，需要针对这些问题进行深入探索和完善。

在后续的工作中，将从以下方面进行深入讨论和研究：

（1）本文提出的多尺度特征选择网络通过利用精心设计的多路渐进结构来捕捉丰富且细粒度的多尺度信息，使其实现高效且灵活的特征表达。但该方法在图像全局信息的利用上，仍有提升空间。后续将尝试引入 Transformer 思想到 MFSB 中去有效挖掘图像的全局多尺度特征。同时，研究如何高效地结合局部和全局的多尺度特征，使网络能以更全面的视角，充分利用图像的上下文信息，从而对大比例因子下的 LR 图像也能实现出色的图像 SR 重建。

（2）本文提出的混合域增强网络通过频率域和空间域联合学习的方式，能有效提升网络的特征表达能力。为更进一步探索频率域和空间域之间的联系，在接下来的研究中，将尝试开发一些有效策略例如异域特征的自适应融合，使网络可以根据不同 LR 图像特性，给空间域和频率域信息动态分配融合权重，高效整合出最适宜描述当前 LR 图像的特征信息，以进一步提高模型特征表达能力。

（3）本文提出的 TELOD 通过结合图像域和特征域增强，使其仅引入少量的参数就能获得明显优于比其他方法的性能。目前，TELOD 框架仅应用在目标检测任务上，且所考虑的多降质因素仅包含噪声、模糊和下采样。因此，在接下来的研究工作中，将尝试将该框架应用到其他的计算机视觉任务，如语义分割、目标跟踪等。此外，还会考虑真实场景中常出现的暗光、雨天和雾天等极端恶劣条件对目标检测性能的影响。通过针对性地调整网络结构和设计损失函数，使模型能够同时适应不同视觉任务和处理多类型恶劣条件下的降质图像，推进所提算法在实际场景中的应用，提升算法的实际应用价值。

（4）本文提出的 JCFI-SRNet 得益于所设计的 CSFPN 和 SSRH，使其能以较低的参数实现较高的检测精度，在可接受的低计算成本下获得了高于同类型检测算法的性能。因此，在未来的研究工作中，考虑引入权重裁剪、量化、重参数化以及知识蒸馏等技术完成对 JCFI-SRNet 结构进一步轻量化的同时保持甚至提升模型整体精度，以便将 JCFI-SRNet 部署到边缘设备中。

中国知网 https://www.cnki.net

参考文献

[1] 中华人民共和国国务院. 新一代人工智能发展规划 [R/OL]. (2017-07-08)[2025-03-18]. https://www.gov.cn/zhengce/content/2017-07/20/content_5211996.htm.

[2] 中国信通院. 人工智能发展报告(2024 年) [R/OL]. (2024-12)[2025-03-18]. https://www.caict.ac.cn/kxyj/qwfb/bps/202412/t20241210_647283.htm.

[3] Harris L J. Diffraction and resolving power [J]. Journal of the Optical Society of America (JOSA), 1964, 54(7): 931-936.

[4] 李佳星, 赵勇先, 王京华. 基于深度学习的单幅图像超分辨率重建算法综述 [J]. 自动化学报, 2021, 47(10): 2341-2363.

[5] 孙超文, 陈晓. 基于多尺度特征融合反投影网络的图像超分辨率重建 [J]. 自动化学报, 2021, 47(7): 1689-1700.

[6] 唐艳秋, 潘泓, 朱亚平, 等. 图像超分辨率重建研究综述 [J]. 电子学报, 2020, 48(7): 1407-1420.

[7] 吴靖, 叶晓晶, 黄峰, 等. 基于深度学习的单帧图像超分辨率重建综述 [J]. 电子学报, 2022, 50(9): 2265-2294.

[8] Li M, Zhao Y, Zhang F, et al. Multi-scale feature selection network for lightweight image super-resolution [J]. Neural Networks, 2024, 169: 352-364.

[9] 张芳, 赵东旭, 肖志涛, 等. 单幅图像超分辨率重建技术研究进展 [J]. 自动化学报, 2022, 48(11): 2634-2654.

[10] 周登文, 刘子涵, 刘玉铠. 基于像素对比学习的图像超分辨率算法 [J]. 自动化学报, 2024, 50(1): 181-193.

[11] 唐述, 曾琬凌, 杨书丽, 等. 基于 Transformer 的块内块间双聚合的单图像超分辨率重建网络 [J]. 计算机学报, 2024, 47(12): 2783-2802.

[12] Dong C, Loy C C, He. K, et al. Image super-resolution using deep convolutional networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2016, 38(2): 295-307.

[13] Kim J, Lee J, Lee K M. Accurate image super-resolution using very deep convolutional networks [C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016: 1646-1654.

[14] Tai Y, Yang J, Liu X, et al. Memnet: A persistent memory network for image

中国知网 https://www.cnki.net

restoration [C]. International Conference on Computer Vision (ICCV), Venice, Italy, 2017: 4549-4557.

[15] Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution [C]. Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Honolulu, HI, USA, 2017: 1132-1140.

[16] Zhang Y, Tian Y, Kong Y, et al. Residual dense network for image super-resolution [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Salt Lake City, UT, USA, 2018: 2472-2481.

[17] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 2017: 2261-2269.

[18] Zhang Y, Li K, Li K, et al. Image super-resolution using very deep residual channel attention networks [C]. European Conference on Computer Vision (ECCV), Munich, Germany, 2018: 294-310.

[19] Mei Y, Fan Y, Zhou Y, et al. Image super-resolution with cross-scale non-local attention and exhaustive self-exemplars mining [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Seattle, WA, USA, 2020: 5689-5698.

[20] Zhang X, Zeng H, Guo S, et al. Efficient long-range attention network for image super-resolution [C]. European Conference on Computer Vision (ECCV), Tel Aviv, Israel, 2022: 649-667.

[21] Zhou Y, Li Z, Guo C-L, et al. SRFormer: Permuted Self-Attention for Single Image Super-Resolution [C]. International Conference on Computer Vision (ICCV), Paris, France, 2023: 12734-12745.

[22] Zhao L, Gao J, Deng D, et al. SSIR: Spatial shuffle multi-head self-attention for Single Image Super-Resolution [J]. Pattern Recognition, 2024, 148: 110195.

[23] Chen X, Wang X, Zhou J, et al. Activating more pixels in image super-resolution transformer [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, BC, Canada, 2023: 22367-22377.

[24] Dai T, Cai J, Zhang Y, et al. Second-Order Attention Network for Single Image Super-Resolution [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Long Beach, CA, USA, 2019: 11065-11074.

[25] Chen R, Zhang H, Liu J. Multi-attention augmented network for single image super-resolution [J]. Pattern Recognition, 2022, 122: 108349.

中国知网 https://www.cnki.net

[26] Kong F, Li M, Liu S, et al. Residual local feature network for efficient super-resolution [DB/OL]. (2022-05-16)[2025-03-18] https://arxiv.org/abs/2205.07514.

[27] Dong C, Loy C C, Tang X. Accelerating the super-resolution convolutional neural network [C]. European Conference on Computer Vision (ECCV), Amsterdam, The Netherlands, 2016: 391-407.

[28] Lai W S, Huang J B, Ahuja N, et al. Deep laplacian pyramid networks for fast and accurate super-resolution [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 2017: 5835-5843.

[29] Ahn N, Kang B, Sohn K A. Fast, accurate, and lightweight super-resolution with cascading residual network [C]. European Conference on Computer Vision (ECCV), Munich, Germany, 2018: 256-272.

[30] Hao F, Wu J, Liang W, et al. Lightweight blueprint residual network for single image super-resolution [J]. Expert Systems with Applications, 2024, 250:123954.

[31] Tai Y, Yang J, Liu X. Image super-resolution via deep recursive residual network [C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 2017: 2790-2798.

[32] Jiang X, Wang N, Xin J, et al. Learning lightweight super-resolution networks with weight pruning [J]. Neural Networks, 2021, 144: 21-32.

[33] Park K, Soh J W, Cho N I. A dynamic residual self-attention network for lightweight single image super-resolution [J]. IEEE Transactions on Multimedia, 2023, 25: 907-918.

[34] Szegedy C, Liu W, Jia Y, et al. Going deeper with Convolutions [C]. Computer Vision and Pattern Recognition (CVPR), Boston, MA, USA, 2015: 1-9.

[35] Szegedy C, Ioffe S, Vanhoucke V, et al. Inception-v4, inception-ResNet and the impact of residual connections on learning [C]. AAAI Conference on Artificial Intelligence, San Francisco, California, USA, 2017: 4278-4284.

[36] Li J, Fang F, Mei K, et al. Multi-scale residual network for image super-resolution [C]. European Conference on Computer Vision (ECCV), Munich, Germany, 2018: 527-542.

[37] Hui Z, Wang X, Gao X, et al. Fast and accurate single image super-resolution via information distillation network [C]. Computer Vision and Pattern Recognition (CVPR), Salt Lake City, UT, USA, 2018: 723-731.

中国知网 https://www.cnki.net

[38] Hui Z, Gao X, Yunchu Y, et al. Lightweight image super-resolution with information multi-distillation network [C]. ACM international conference on multimedia (ACM MM), Nice, France, 2019: 2024-2032.

[39] Liu J, Tang J, Wu G, et al. Residual feature distillation network for lightweight image super-resolution [C]. European Conference on Computer Vision Workshops (ECCVW), Glasgow, UK, 2020: 41-55.

[40] 李明鸿, 常侃, 李恒鑫, 等. 双阶段信息蒸馏的轻量级图像超分辨率网络 [J]. 中国图象图形学报, 2021, 26(5): 0991-1005.

[41] Zhu X, Guo K, Ren S, et al. Lightweight image super-resolution with expectation-maximization attention mechanism [J]. IEEE Transactions on Circuits and Systems for Video Technology (TCSVT), 2022, 32(3): 1273-1284.

[42] Gao S-H, Cheng M-M, Zhao K, et al. Res2Net: A new multi-scale backbone architecture [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2021, 43(2): 652-662.

[43] 蒋弘毅, 王永娟, 康锦煜. 目标检测模型及其优化方法综述 [J]. 自动化学报, 2021, 47(6): 1232-1255.

[44] 琚长瑞, 秦晓燕, 袁广林. 尺度敏感损失与特征融合的快速小目标检测方法 [J]. 电子学报, 2022, 50(9): 2119-2126.

[45] 柳长源, 张玉亮, 毕晓君. 基于多阶段提议稀疏区域卷积网络的城市交通目标检测 [J]. 电子学报, 2023, 51(1): 26-31.

[46] Li M, Zhao Y, Gui G, et al. Object detection on low-resolution images with two-stage enhancement [J]. Knowledge-Based Systems, 2024, 299: 111985.

[47] He K, Gkioxari G, Dollár P, et al. Mask r-cnn [C]. International Conference on Computer Vision (ICCV), Venice, Italy, 2017: 2980-2988.

[48] Cai Z, Vasconcelos N. Cascade R-CNN: High quality object detection and instance segmentation [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2019, 43(5): 1483-1498.

[49] Pang J, Chen K, Shi J, et al. Libra r-cnn: Towards balanced learning for object detection [C]. Computer Vision and Pattern Recognition (CVPR). Long Beach, CA, USA, 2019: 821-830.

[50] Jocher G, Chaurasia A, Stoken A, et al. YOLOv8 by ultralytics [DB/OL]. (2023-01-10)[2025-03-18]. https://github.com/ultralytics/ultralytics.

[51] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation [C]. Conference on Computer

中国知网 https://www.cnki.net

Vision and Pattern Recognition (CVPR), Columbus, OH, USA, 2014: 580-587.

[52] Girshick R. Fast r-cnn [C]. IEEE International Conference on Computer Vision (ICCV), Santiago, Chile, 2015: 1440-1448.

[53] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2017, 39(6): 1137-1149.

[54] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016: 779-788.

[55] Ioffe S. Batch normalization: Accelerating deep network training by reducing internal covariate shift [DB/OL]. (2015-02-11)[2025-03-18]. https://arxiv.org/abs/1502.03167.

[56] Redmon J, Farhadi A. YOLO9000: better, faster, stronger [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 2017: 6517-6525.

[57] Redmon J, Farhadi A, Yolov3: An incremental improvement [DB/OL]. (2018-04-08)[2025-03-18]. https://arxiv.org/abs/1804.02767.

[58] Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal speed and accuracy of object detection [DB/OL]. (2020-04-23)[2025-03-18]. https://arxiv.org/abs/2004.10934.

[59] Jocher G, Chaurasia A, Stoken A, et al. ultralytics/yolov5: v6.2. [DB/OL]. (2022-08-17)[2025-03-18]. https://github.com/ultralytics/yolov5.

[60] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications [DB/OL]. (2022-07-07)[2025-03-18]. https://arxiv.org/abs/2209.02976.

[61] Wang C -Y, Bochkovskiy A, Liao H -Y M, et al. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, BC, Canada, 2023: 7464-7475.

[62] Dai D, Wang Y, Chen Y, et al. Is image super-resolution helpful for other vision tasks? [C]. Winter Conference on Applications of Computer Vision (WACV), Lake Placid, NY, USA, 2016: 1-9.

[63] Gondal M W, Schölkopf B, Hirsch M. The unreasonable effectiveness of texture transfer for single image super-resolution [C]. European Conference on

中国知网 https://www.cnki.net

Computer Vision Workshops (ECCVW), Munich, Germany, 2019: 80-97.

[64] Wen J, Cheng S, Xu P, et al. When super-resolution meets camouflaged object detection: A comparison study [DB/OL]. (2023-08-08)[2025-03-18]. https://arxiv.org/abs/2308.04370.

[65] Yan T, Li H, Sun B, et al. Discriminative feature mining and enhancement network for low-resolution fine-grained image recognition [J]. IEEE Transactions on Circuits and Systems for Video Technology (TCSVT), 2022, 32(8): 5319-5330.

[66] Haris M, Shakhnarovich G, Ukita N. Task-driven super resolution: object detection in low-resolution images [C]. Neural Information Processing: 28th International Conference (ICONIP), Sanur, Bali, Indonesia, 2021: 387-395.

[67] Wang B, Lu T, Zhang Y. Feature-driven super-resolution for object detection [C]. Conference on Control, Robotics and Cybernetics (CRC), Wuhan, China, 2020: 211-215.

[68] Haris M, Shakhnarovich G, Ukita N. Deep back-projection networks for super-resolution [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Salt Lake City, UT, USA, 2018: 1664-1673.

[69] Talebi H, Milanfar P. Learning to resize images for computer vision tasks [C]. International Conference on Computer Vision (ICCV), Montreal, QC, Canada, 2021, 487-496.

[70] Liu H, Jin F, Zeng H, et al. Image enhancement guided object detection [J]. IEEE Transactions on Neural Networks and Learning Systems (TNNLS), 2024, 35(10): 14164-14177.

[71] Cui Z, Zhu Y, Gu L, et al. Exploring resolution and degradation clues as self-supervised signal for low quality object detection [C]. European Conference on Computer Vision (ECCV), Tel Aviv, Israel, 2022: 473-491.

[72] Zhang J, Lei J, Xie W, et al. SuperYOLO: super resolution assisted object detection in multimodal remote sensing imagery [J]. IEEE Transactions on Geoscience and Remote Sensing (TGRS), 2023, 61: 1-15.

[73] Guo S, Li J, Feng Y, et al. UDTIRI: An Online Open-Source Intelligent Road Inspection Benchmark Suite [J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25, 8: 9920-9931.

[74] Ma N, Fan J, Wang W, et al. Computer vision for road imaging and pothole detection: a state-of-the-art review of systems and algorithms [J].

中国知网 https://www.cnki.net

Transportation Safety and Environment, 2022, 4(4): tdac026.

[75] Koch C, Georgieva K, Kasireddy V, et al. A review on computer vision based defect detection and condition assessment of concrete and asphalt civil infrastructure [J]. Advanced Engineering Informatics, 2015, 29(2): 196-210.

[76] Jahanshahi M R, Jazizadeh F, Masri S F, et al. Unsupervised approach for autonomous pavement-defect detection and quantification using an inexpensive depth sensor [J]. Journal of Computing in Civil Engineering, 2013, 27(6): 743-754.

[77] Li Y, Papachristou C, Weyer D. Road pothole detection system based on stereo vision [C]. NAECON 2018-IEEE National Aerospace and Electronics Conference, Dayton, OH, USA, 2018: 292-297.

[78] Fan R, Liu M. Road damage detection based on unsupervised disparity map segmentation [J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 21(11): 4906-4911.

[79] Gupta S, Sharma P, Sharma D, et al. Detection and localization of potholes in thermal images using deep neural networks [J]. Multimedia tools and applications, 2020, 79: 26265-26284.

[80] Javed A, Mahmud M S, Alam M T, et al. Pothole detection system using region-based convolutional neural network [C]. 2021 IEEE 4th International Conference on Computer and Communication Engineering Technology (CCET), Beijing, China, 2021: 6-11.

[81] Yebes J J, Montero D, Arriola I. Learning to automatically catch potholes in worldwide road scene images [J]. IEEE Intelligent Transportation Systems Magazine, 2020, 13(3): 192-205.

[82] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016: 770-778.

[83] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation [C]. Proceedings of the IEEE conference on Computer Vision and Pattern Recognition (CVPR), Boston, MA, USA, 2015: 3431-3440.

[84] Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 2017: 2881-2890.

[85] Chen L C, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable

中国知网 https://www.cnki.net

convolution for semantic image segmentation [C]. Proceedings of the European Conference on Computer Vision (ECCV), Munich, Germany, 2018: 801-818.

[86] Xie E, Wang W, Yu Z, et al. SegFormer: Simple and efficient design for semantic segmentation with transformers [J]. Advances in Neural Information Processing Systems (NIPS), virtual, 2021, 34: 12077-12090.

[87] Chun C, Ryu S K. Road surface damage detection using fully convolutional neural networks and semi-supervised learning [J]. Sensors, 2019, 19(24): 5501.

[88] Masihullah S, Garg R, Mukherjee P, et al. Attention Based Coupled Framework for Road and Pothole Segmentation [C]. 2020 25th International Conference on Pattern Recognition (ICPR), Milan, Italy, 2021: 5812-5819.

[89] 葛斌, 陈宁洁, 夏晨星, 等. 基于全局上下文交互融合的伪装目标检测网 [J]. 控制与决策, 2024, 39(10): 3347-3356.

[90] 赖杰, 彭锐晖, 孙殿星, 等. 融合注意力机制与多检测层结构的伪装目标检测 [J]. 中国图象图形学报, 2024, 29(01): 134-146.

[91] 刘文犀, 张家榜, 李悦洲, 等. 基于边界特征融合和前景引导的伪装目标检测 [J]. 电子学报, 2024, 52(07): 2279-2290.

[92] Li M, Zhao Y, Gui G, et al. CSFIN: A lightweight network for camouflaged object detection via cross-stage feature interaction [J]. Expert Systems with Applications, 2025, 269: 126451.

[93] Pan Y, Chen Y, Fu Q, et al. Study on the camouflaged target detection method based on 3D convexity [J]. Modern Applied Science, 2011, 5(4): 152.

[94] Huerta I, Rowe D, Mozerov M, et al. Improving background subtraction based on a casuistry of colour-motion segmentation problems [C]. Iberian conference on pattern recognition and image analysis, Girona, Spain, 2007: 475-482.

[95] Siricharoen P, Aramvith S, Chalidabhongse T H, et al. Robust outdoor human segmentation based on color-based statistical approach and edge combination [C]. Green Circuits and Systems, Shanghai, China, 2010: 463-468.

[96] Kavitha C, Rao B P, Govardhan A. An efficient content based image retrieval using color and texture of image sub blocks [J]. International Journal of Engineering Science and Technology (IJEST), 2011, 3(2): 1060-1068.

[97] Fan D -P, Ji G -P, Sun G, et al. Camouflaged object detection [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Seattle, WA, USA, 2020: 2774-2784.

[98] Mei H, Ji G -P, Wei Z, et al. Camouflaged object segmentation with distraction

中国知网 https://www.cnki.net

mining [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Virtual, 2021: 8772-8781.

[99] Zhou, T, Zhou, Y, Gong, C, et al. Feature aggregation and propagation network for camouflaged object detection [J]. IEEE Transactions on Image Processing (TIP), 2022, 31: 7036-7047.

[100] Chen G, Liu S-J, Sun Y-J, et al. Camouflaged object detection via context-aware cross-level fusion [J]. IEEE Transactions on Circuits and Systems for Video Technology (TCSVT), 2022, 32(10): 6981-6993.

[101] Zhu H, Li P, Xie H, et al. I can find you! boundary-guided separated attention network for camouflaged object detection [C]. AAAI Conference on Artificial Intelligence, Virtual, 2022, 36(3): 3608-3616.

[102] Lyu, Y, Zhang H, Li Y. UEDG: Uncertainty edge dual guided camouflage object detection [J]. IEEE Transactions on Multimedia (TMM), 2024, 26: 4050-4060.

[103] Yan X, Sun M, Han Y, et al. Camouflaged object segmentation based on matching-recognition-refinement network [J]. IEEE Transactions on Neural Networks and Learning Systems (TNNLS), 2023, 35(11): 15993-16007.

[104] Huang Z, Dai H, Xiang T -Z, et al. (2023). Feature shrinkage pyramid for camouflaged object detection with transformers [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, BC, Canada, 2023: 5557-5566.

[105] Ji G-P, Fan D-P, Chou Y -C, et al. (2023). Deep gradient learning for efficient camouflaged object detection [J]. Machine Intelligence. Research, 2023, 20(1): 92-108.

[106] Fan D-P, Ji G-P, Cheng M-M. et al. Concealed Object Detection [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2022, 44(10): 6024-6042.

[107] He C, Li K, Zhang Y et al. Camouflaged object detection with feature decomposition and edge reconstruction [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, BC, Canada, 2023: 22046-22055.

[108] Wu Z, Su L, Huang Q. Cascaded partial decoder for fast and accurate salient object detection [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Long Beach, CA, USA, 2019: 3907-3916.

中国知网 https://www.cnki.net

[109] Liu Y, Li H, Cheng J, et al. MSCAF-net: A general framework for camouflaged object detection via learning multi-scale context-aware features [J]. IEEE Transactions on Circuits and Systems for Video Technology (TCSVT), 2023, 33(9): 4934-4947.

[110] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [C]. Conference on Neural Information Processing Systems (NIPS), Long Beach, CA, USA, 2017: 5998-6008.

[111] Helvig K, Abeloos B, Trouvé-Peloux P. CAFF-DINO: Multi-spectral Object Detection Transformers with Cross-attention Features Fusion [C]. Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Seattle, WA, USA, 2024: 3037-3046.

[112] Moon J, Jeon M, Jeong S, et al. RoMP-transformer: Rotational bounding box with multi-level feature pyramid transformer for object detection [J]. Pattern Recognition, 2024, 147: 110067.

[113] Yuan M, Shi X, Wang N, et al. Improving RGB-infrared object detection with cascade alignment-guided transformer [J]. Information Fusion, 2024, 105: 102246.

[114] Li J, Zhang Z, Song R, et al. SCFormer: Spectral coordinate transformer for cross-domain few-shot hyperspectral image classification [J]. IEEE Transactions on Image Processing (TIP), 2024, 33: 840-855.

[115] Xu R, Dong X M, Li W, et al. DBCTNet: Double branch convolution-transformer network for hyperspectral image classification [J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-15.

[116] Li Y, Yang X, Tang D, et al. RDTN: Residual Densely Transformer Network for hyperspectral image classification [J]. Expert Systems with Applications, 2024, 250: 123939.

[117] Li X, Ding H, Yuan H, et al. Transformer-Based Visual Segmentation: A Survey [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2024, 46(12): 10138-10163.

[118] Li L, Liu Q, Shi X, et al. UCFilTransNet: Cross-Filtering Transformer-based network for CT image segmentation [J]. Expert Systems with Applications, 2024, 238: 121717.

[119] Zhang N, Yu L, Zhang D, et al. Ct-net: Asymmetric compound branch transformer for medical image segmentation [J]. Neural Networks, 2024, 170:

中国知网 https://www.cnki.net

298-311.

[120] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale [DB/OL]. (2020-10-22)[2025-03-18]. https://arxiv.org/abs/2010.11929.

[121] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows [C]. International Conference on Computer Vision (ICCV), Montreal, QC, Canada, 2021: 9992-10002.

[122] Wang W, Xie E, Li X, et al. Pvt v2: Improved baselines with pyramid vision transformer [J]. Computational Visual Media, 2022, 8(3): 415-424.

[123] Lin W, Wu Z, Chen J, et al. Scale-aware modulation meet transformer [C]. International Conference on Computer Vision (ICCV), Paris, France, 2023: 5992-6003.

[124] Xing H, Gao S, Wang Y, et al. Go closer to see better: Camouflaged object detection via object area amplification and figure-ground conversion [J]. IEEE Transactions on Circuits and Systems for Video Technology (TCSVT), 2023, 33(10): 5444-5457.

[125] Shi W, Caballero J, Huszar F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016: 1874-1883.

[126] Matsui Y, Ito K, Aramaki Y, et al. Sketch-based manga retrieval using manga109 dataset [J]. Multimedia Tools and Applications, 2017, 76(20): 21811-21838.

[127] Yu J, Fan Y, Yang J, et al. Wide activation for efficient and accurate image super-resolution [DB/OL]. (2018-08-27)[2025-03-18]. https://arxiv.org/abs/1808.08718.

[128] Yang W, Wang W, Zhang X, et al. Lightweight feature fusion network for single image super-resolution [J]. IEEE Signal Processing Letters, 2019, 26(4): 538-542.

[129] Li X, Wang W, Hu X, et al. Selective kernel networks [C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Long Beach, CA, USA, 2019: 510-519.

[130] Hu J, Shen L, Sun G. Squeeze-and-excitation networks [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Salt Lake City, UT, USA,

中国知网 https://www.cnki.net

2018: 7132-7141.

[131] Agustsson E, Timofte R. NTIRE 2017 challenge on single image super-resolution: Dataset and study [C]. Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Honolulu, HI, USA, 2017: 1122-1131.

[132] Bevilacqua M, Roumy A, Guillemot C, et al. Low-complexity single-image super-resolution based on nonnegative neighbor embedding [C]. British Machine Vision Conference (BMVC), Surrey, UK, 2012: 1-10.

[133] Zeyde R, Elad M, Protter M. On single image scale-up using sparse-representations [C]. International Conference on Curves and Surfaces, Avignon, France, 2010: 711-730.

[134] Timofte R, Smet V D, Gool L V. A+: Adjusted anchored neighborhood regression for fast super-resolution [C]. Asian Conference on Computer Vision. (ACCV), Singapore, 2014: 111-126.

[135] Huang J, Ahuja A S N. Single image super-resolution from transformed self-exemplars [C]. Computer Vision and Pattern Recognition (CVPR), Boston, USA, 2015: 5197-5206.

[136] Salimans T, Kingma D P. Weight normalization: A simple reparameterization to accelerate training of deep neural networks [C]. Neural Information Processing Systems (NIPS), Barcelona, Spain, 2016, 901-909.

[137] Yu F, Chen H, Wang X, et al. Bdd100k: A diverse driving dataset for heterogeneous multitask learning [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Seattle, WA, USA, 2020, 2633-2642.

[138] Zhou X, Wang D, Krähenbühl P. Objects as points [DB/OL]. (2019-04-16) [2025-03.18]. https://arxiv.org/abs/1904.07850.

[139] Mallat S. A theory for multiresolution signal decomposition: the wavelet representation [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 1989, 11(7): 674-693.

[140] Zhang Z, Wang X, Jung C. DCSR: dilated convolutions for single image super-resolution [J]. IEEE Transactions on Image Processing. (TIP), 2019, 28(4): 1625-1635.

[141] Xi S, Wei J, Zhang W. Pixel-guided dual-branch attention network for joint image deblurring and super-resolution [C]. Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Virtual, 2021: 532-540.

中国知网 https://www.cnki.net

[142] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [DB/OL]. (2014-09-04)[2025-03-18]. https://arxiv.org/abs/1409.1556.

[143] Lei Ba J, Kiros J R, Hinton G E. Layer normalization [DB/OL]. (2016-07-21)[2025-03-18]. https://arxiv.org/abs/1607.06450.

[144] Zamir S W, Arora A, Khan S, et al. Restormer: Efficient transformer for high-resolution image restoration [C]. Conference on Computer Vision and Pattern Recognition (CVPR), New Orleans, LA, USA, 2022: 5728-5739.

[145] Ali A, Touvron H, Caron M, et al. Xcit: Cross-covariance image transformers [C]. Advances in Neural Information Processing Systems (NIPS), Virtual, 2021, 1531: 20014-20027.

[146] Hendrycks D, Gimpel K. Gaussian error linear units (gelus) [DB/OL]. (2016-06-27)[2025-03-18]. https://arxiv.org/abs/1606.08415.

[147] Everingham M, Van Gool L, Williams C K I, et al. The pascal visual object classes (voc) challenge [J]. International journal of computer vision (IJCV), 2010, 88: 303-338.

[148] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context [C]. Conference on European Conference on Computer Vision (ECCV), Zurich, Switzerland, 2014: 740-755.

[149] Chen K, Wang J, Pang J, et al. MMDetection: Open mmlab detection toolbox and benchmark [DB/OL]. (2019-06-17)[2025-03-18]. https://arxiv.org/abs/1906.07155.

[150] Van der Maaten L, Hinton G. Visualizing data using t-SNE [J]. Journal of machine learning research, 2008, 9(86): 2579-2605.

[151] Wang X, Yu K, Dong C, et al. Recovering realistic texture in image super-resolution by deep spatial feature transform [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Salt Lake City, UT, USA, 2018: 606-615.

[152] Arya D, Maeda H, Ghosh S K, et al. RDD2022: A multi‐national image dataset for automatic road damage detection [DB/OL]. (202209-18)[2025-03-18]. https://arxiv.org/abs/2209.08538.

[153] Fan D P, Cheng M M, Liu Y, et al. Structure-measure: A new way to evaluate foreground maps [C]. International Conference on Computer Vision (ICCV), Venice, Italy, 2017: 4548-4557.

中国知网 https://www.cnki.net

[154] Margolin R, Zelnik-Manor L, Tal A. How to evaluate foreground maps? [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Columbus, OH, USA, 2014: 248-255.

[155] Perazzi F, Krähenbühl P, Pritch Y, et al. Saliency filters: Contrast based filtering for salient region detection [C]. Conference on Computer Vision and Pattern Recognition (CVPR), Providence, RI, USA, 2012: 733-740.

[156] Fan D P, Gong C, Cao Y, et al. Enhanced-alignment measure for binary foreground map evaluation [DB/OL]. (201805-26)[2025-03-18]. https://arxiv.org/abs/1805.10421.

中国知网 https://www.cnki.net