中图法分类号:TP183　　**文献标识码**: A　　**文章编号**: 1006-8961(2024)10-3033-14

论文引用格式:Hua X, Shu T, Li M X, Shi Y and Hong H Y. 2024. Nonlocal feature representation-embedded blurred image restoration. Journal of Image and Graphics, 29(10):3033-3046(华夏, 舒婷, 李明欣, 时愈, 洪汉玉. 2024. 融合非局部特征表示的模糊图像复原. 中国图象图形学报, 29(10):3033-3046)[DOI:10.11834/jig.230735]

融合非局部特征表示的模糊图像复原

华夏,舒婷,李明欣,时愈,洪汉玉*

武汉工程大学电气信息学院,武汉　430205

摘　要:**目的**　基于深度学习的端到端单图像去模糊方法已取得了优秀成果。但大多数网络中的构建块仅专注于提取局部特征,而在建模远距离像素依赖关系方面表现出局限性。为解决这一问题,提出了一种为网络引入局部特征和非局部特征的方法。**方法**　采用现有的优秀构建块提取局部特征,将大窗口的Transformer块划分为更小的不重叠图像块,对每个图像块仅采样一个最大值点参与自注意力运算,在不占用过多计算资源的情况下提取非局部特征。最后将两个模块结合应用,在块内耦合局部信息和非局部信息,从而有效捕捉更丰富的特征信息。**结果**　实验表明,相比于仅能提取局部信息的模块,提出的模块在峰值信噪比(peak signal-to-noise ratio, PSNR)指标上的提升不少于1.3 dB。此外,设计两个局部与非局部特征耦合的图像复原网络,分别运用在单图像去运动模糊和去散焦模糊任务上,与Uformer(a general U-shaped Transformer for image restoration)相比,在去运动模糊测试集GoPro(deep multi-scale convolutional neural network for dynamic scene deblurring)和HIDE(human-aware motion deblurring)上的平均PSNR分别提高了0.29 dB和0.25 dB,且模型的浮点数更低。在去散焦模糊测试集DPD(defocus deblurring using dual-pixel data)上,平均PSNR提高了0.42 dB。**结论**　本文方法在块内成功引入非局部信息,使得模型能够同时捕捉局部特征和非局部特征,获得更多的特征表示,提升了去模糊网络的性能。同时,恢复图像也具有更清楚的边缘,更接近真实图像。

关键词:运动模糊;散焦模糊;自注意力;非局部特征;融合网络

Nonlocal feature representation-embedded blurred image restoration

Hua Xia, Shu Ting, Li Mingxin, Shi Yu, Hong Hanyu*

School of Electrical and Information Engineering, Wuhan Institute of Technology, Wuhan　430205, China

Abstract: **Objective** Image deblurring is a classic low-level computer vision problem that aims to restore a sharp image from a blurry image. In recent years, convolutional neural networks (CNNs) have boosted the advancement of computer vision considerably, and various CNN-based deblurring methods have been developed with remarkable results. Although convolution operation is powerful in capturing local information, the CNNs show a limitation in modeling long-range dependencies. By employing self-attention mechanisms, vision Transformers have shown a high ability to model long-range pixel relationships. However, most Transformer models designed for computer vision tasks involving high-resolution images use a local window self-attention mechanism. This is contradictory to the goal of employing Transformer structures to capture true long-range pixel dependencies. We review some deblurring models that are sufficient for processing high-resolution images; most CNN-based and vision Transformer-based approaches can only extract spatial local features. Some studies

收稿日期:2023-10-23;**修回日期**:2023-12-19;**预印本日期**:2023-12-26

*通信作者:洪汉玉　hhyhong@wit.edu.cn

基金项目:国家自然科学基金项目(61801337,62471345,62171329)

Supported by:National Natural Science Foundation of China (61801337,62471345,62171329)

obtain the information with larger receptive field by directly increasing the window size, but this method not only has excessive computational overhead but also lacks flexibility in the process of feature extraction. To solve the above problems, we propose a method that can incorporate local and nonlocal information for the network. **Method** We employ the local feature representation (LFR) modules and nonlocal feature representation (NLFR) modules to extract enriched information. For the extraction of local information, most of the existing building blocks have this capability, and we can treat these blocks directly as LFR modules. In addition to obtaining local information, we also designed a generic NLFR module that can be easily combined with the LFR module for extracting nonlocal information. The NLFR module consists of a nonlocal feature extraction (NLFE) block and an interblock transmission (IBT) mechanism. The NLFE block applies a nonlocal self-attention mechanism, which avoids the interference of local information and texture details, captures purer nonlocal information, and considerably reduces the computational complexity. To reduce the effect of accumulating more local information in the NLFE block as the network depth increases, we introduce an IBT mechanism for successive NLFE blocks, which provides a direct data flow for the transfer of nonlocal information. This design has two advantages: 1) The NLFR module ignores local texture details in features when extracting information to ensure that information does not interfere with each other. 2) Instead of computing the self-similarity of all pixels within the receptive field, the NLFR module adaptively samples the salient pixels, considerably reducing computational complexity. We selected LeFF and ResBlock as the LFR module combined with the NLFR module and designed two models named NLCNet_L and NLCNet_R to deal with motion blur removal and defocus blur removal, respectively, based on the single-stage UNet as the model architecture. **Result** We verify the gains of each component of the NLFR module in the network; the network consisting of the NLFR module combined with the LFR module obtains peak signal-to-noise ratio (PSNR) gains of 0.89 dB compared with using only the LFR as the building block. Applying the IBT module over this, the performance is further improved by 0.09 dB on PSNR. For fair comparisons, we build a baseline model only using ResBlock as the building block with similar computational overhead and number of parameters to the proposed network. Results demonstrate that NLFR-combined ResBlock is more effective in constructing a deblurred network than directly using ResBlock as the building block. In scalability experiments, the experiment shows that the combination of NLFR modules with existing building blocks can remarkably improve the deblurring performance, including convolutional residual blocks and a Transformer block. In particular, two networks designed with NLFR-combination LeFF block and ResBlock as the building blocks achieve excellent results in single-image motion deblurring and dual-pixel defocus deblurring compared with other methods. In accordance with a popular training method, NLCNet_L was trained on the GoPro dataset with 3 000 epochs and tested on the GoPro test set. Our method achieves the best results on the GoPro test set with the lowest computational complexity. Compared with the previous method Uformer, our method improves PSNR by 0.29 dB. We trained NLCNet_R on the DPD dataset for 200 epochs for two-pixel defocus deblurring experiments. In the combined scene category, we achieved excellent performance in all four metrics. Compared with the previous method Uformer, our method improves the PSNR in indoor and outdoor scenes by 1.37 dB and 0.94 dB, respectively. **Conclusion** We propose a generic NLFR module to represent the extraction of real nonlocal information from images, which can be coupled with local information within the block to improve the expressive ability of the model. Through rational design, the network composed of NLFR modules achieves excellent performance with low computational consumption, and the visual effect of the recovered image, especially the edge contours, is clearer and more complete.

Key words: motion blur; defocus blur; self-attention; non-local features; fusion network

0 引 言

在拍摄过程中,如果受到成像设备或外部环境等干扰,会导致拍摄的图像清晰度下降和质量降低,造成图像模糊。图像去模糊研究的目标则是从给定的模糊图像中恢复出清晰的图像。对于物体检测、语义分割等高级计算机视觉任务,图像去模糊也是非常重要的预处理步骤。近年来,随着卷积神经网络(convolutional neural network, CNN)的兴起(He等,2016; Krizhevsky等,2017),计算机视觉研究取得了巨大的进展。研究者们相继开发了许多基于CNN的优秀去模糊方法(Nah等,2017; Zamir等,2021)。

基于CNN的方法依靠卷积运算往往具备捕捉图像局部特征的能力，但在建模远程依赖关系上表现不佳。近几年，基于Transformer的深度学习方法（Vaswani等，2017）被引入到计算机视觉任务中并取得了能与基于CNN的方法相媲美的结果（Dosovitskiy等，2020）。通过自注意力机制，视觉Transformer天然具有建模更长距离依赖关系的特性。然而，涉及高分辨率图像的视觉任务中设计的视觉Transformer模型大多数都采用了局部窗口自注意机制（Liu等，2021）以降低计算复杂度。尽管这种方法取得了一定的成效，但由于窗口尺寸设置过小，如7或8（Liang等，2021；Wang等，2022），严重限制了自注意力操作的感受野，依然难以捕捉真正的远距离依赖关系，与利用Transformer结构解决计算机视觉问题的初始动机相悖。

基于以上分析，本文回顾了一些能够处理高分辨率图像的去模糊模型。无论是基于CNN或是基于Transformer的方法大多都只能提取局部特征，而无法利用远距离像素之间的交互信息来帮助恢复图像。一些研究者之前也尝试过直接增大自注意力局部窗口尺寸来获得更大的接受野（Chen等，2021b），但这种方法不仅造成了过大的计算开销而且在特征提取过程中缺乏灵活性，即对窗口内的所有内容一视同仁反而又忽略了图像中存在的局部特征（Li等，2021；Yuan等，2021）。与只关注局部信息的模型相比，直接增加窗口大小的方法所带来的性能提升非常有限。

在本文中，分别采用局部特征表示（local feature representation，LFR）模块和非局部特征表示（non-local feature representation，NLFR）模块来提取图像中丰富的信息。在提取的局部特征中融合非局部特征，能够有效地平衡局部信息和非局部信息在网络中的作用，从而在提升图像复原能力的同时，也增强了模型的泛化能力。该结构通过在局部特征中引入非局部特征的方式，既保留了局部信息的细节特征，也融合了非局部信息的上下文信息。由于大多数现有的构建块都具有对局部信息的提取能力，因此可以直接将这些块视为LFR模块。于是设计了一个通用的NLFR模块来提取非局部信息，能灵活地与LFR模块结合使用。NLFR模块由非局部特征提取（non-local feature extraction，NLFE）块和块间传输（inter-block transmission，IBT）机制两部分组成，在NLFE块中采用非局部自注意机制不仅能够避免图像中局部信息和纹理细节的干扰，捕获更纯粹的非局部信息，同时也显著降低了计算复杂度。IBT机制是为了避免随着网络深度的增加而在NLFE块中积累越来越多的局部信息，在连续的NLFE块间提供了一个直接的数据流以传递非局部信息。通过将NLFR模块与现有的代表性LFR模块（包括卷积残差块和Transformer块）相结合，证明了所提出方法的有效性和可扩展性。

实验结果表明，结合了NLFR模块的构建块组成的网络比原始网络具有更好的去模糊性能。其中，以局部增强的前馈网络（local enhanced feedforward，LeFF）块（Yuan等，2021）和ResBlock（Nah等，2017）结合NLFR模块作为构建块设计的两个网络，与其他方法相比在单图像去运动模糊和双像素去散焦模糊方面都取得了出色的结果。

本文主要贡献如下：1）考虑到大多数现有的去模糊模型构建块只擅长提取局部特征，难以捕获远程像素依赖关系，提出了一个NLFR模块能有效地提取非局部信息。2）NLFR模块可以与现有的能提取局部信息的构建块相结合，耦合块内的局部和非局部信息以增强模型的表示能力。3）实验表明，NLFR模块显著提高了模型的去模糊性能。使用与NLFR结合的LeFF和ResBlock作为构建块设计的两个网络，在去运动模糊和去散焦模糊任务上都取得了优异的复原效果。

1 相关工作

1.1 基于统计先验的去模糊方法

传统的盲去模糊方法是从模糊图像中联合估计模糊核和清晰图像，但这个问题是高度不适定的，自然的解决办法是利用限制和约束来排除不可行解。许多有效的自然图像先验已经被开发出来，如$L0$先验（Xu等，2013）、稀疏性先验（Krishnan等，2011）、暗通道先验（Pan等，2016）等。然而，由于真实图像中的模糊核通常较为复杂，统计先验建模方法在对图像清晰特征进行建模时存在一定的局限性，估计的模糊核通常不准确，导致恢复结果并不理想。此外，基于先验的建模方法需要解决一个优化问题，如果设计的先验很复杂，往往会导致求解去模糊模型非常困难。并且复杂的计算过程又需要更长的程序运

行时间,很难满足实时去除模糊的需求。

1.2 基于CNN的去模糊方法

早期的深度学习方法利用卷积网络强大的学习能力作为数学建模方法的替代方案来辅助估计图像中的非均匀运动模糊核。Sun等人(2015)基于卷积神经网络预测运动模糊概率分布,然后通过马尔可夫随机场模型估计图像中的非均匀模糊。Gong等人(2017)提出了一种利用全卷积神经网络估计运动流来恢复模糊图像的方法,该方法能够处理现实世界中的模糊图像,但该方法仅限于具有线性模糊核的模糊图像。Schuler等人(2016)通过对多个卷积神经网络进行从粗到精的叠加来模拟迭代优化过程以实现图像去模糊。

随着卷积神经网络的发展,Nah等人(2017)提出了一种不需要估计模糊核直接端到端去模糊的方法。这类基于CNN的端到端去模糊方法的性能增益主要来自两个关键因素:合理的模型架构和高效残差块的设计。对于模型架构,许多图像去模糊研究都做出了尝试,试图检验其合理性。例如,Nah等人(2017)采用由粗到精的策略提出了一种多尺度网络框架,通过叠加ResBlocks逐步恢复出3层大小不同的图像。Zhang等人(2019)采用一种多图像块模型来解决非均匀运动模糊的问题。Cho等人(2021)提出了一种高效的多输入多输出的去模糊结构。Zamir等人(2021)提出了一种多阶段的图像恢复架构,将整个恢复过程分解为更易于管理的步骤。目前基于编码器—解码器(encoder-decoder)结构的U型网络是图像去模糊任务的常用方案,这种UNet结构具有分层提取不同尺度信息的能力,有利于恢复具有不同大小的模糊图像。

基于CNN的去模糊方法性能优异的另一个关键因素是其高效残差块的设计。Nah等人(2017)在原始残差块的基础上去掉了残差块输出前的归一化层(layer normalization,LN)和激活函数,命名为ResBlock。Chen等人(2021a)在残差块中引入了半实例归一化层,设计了名为HIN Block的残差块,将归一化层重新引入到图像恢复任务中。陈紫柠等人(2022)在多尺度生成对抗网络中也改进了残差块的结构。Chen等人(2022)在NAFNet中的实验也表明在给定相同的模型框架下,改变残差块中的非线性激活函数,或者有无LN,都对性能有不可忽视的影响。

1.3 视觉Transformer

近年来,Transformer已经在自然语言处理(natural language processing,NLP)任务中取得了丰硕的成果。Dosovitskiy等人(2020)的开创性实验将Transformer结构应用于图像分类任务中,并取得了具有竞争力的性能,证明了其在计算机视觉中的可行性。随后,研究者们相继提出了各种有效的优化策略以减轻Transformer带来高额计算复杂度的问题。Liu等人(2021)通过在图像的窗口和移位窗口内应用自注意力,显著降低了自注意力的计算复杂度。CSwin(cross-shaped windows)(Dong等,2022)在水平和垂直条形窗口中并行计算自注意力,在不引入额外计算成本的情况下扩大了自注意力的覆盖范围。Wang等人(2021)在PVT(pyramid vision Transformer)中提出空间缩减注意力(spatial-reduction attention,SRA),实现了多尺度和高分辨率特征的灵活学习方法,也减少了计算资源的消耗。

1.4 基于Transformer的去模糊方法

最近,基于Transformer的模型已经很好地应用到了图像去模糊任务中。IPT(image processing Transformer)(Chen等,2021b)在大型数据集上预训练了一个具有多头和多尾的参数共享模型,这样的设计能使其应对不同的恢复任务。Uformer(Wang等,2022)和Swin IR(image restoration using swin Transformer)(Liang等,2021)中图像恢复的关键技术都源自于Swin Transformer(Liu等,2021),其中Uformer设计了一个适合图像去模糊的U型Transformer通用恢复模型。Stripformer(Tsai等,2022a)利用条内和条间的注意力,以较低的计算复杂度获得了更好的去模糊效果。不同于将图像划分为局部窗口的策略,Restormer(Zamir等,2022)通过跨通道计算自注意力,能有效地探索远程上下文信息。由于UNet架构在图像去模糊任务中的契合性,上述基于Transformer结构的模型通常也都遵循了这种设计。

2 方 法

在本节中将详细描述提出的NLFR模块,以及与3个LFR模块结合的具体示例。使用的网络总体架构为单级UNet,如图1所示。

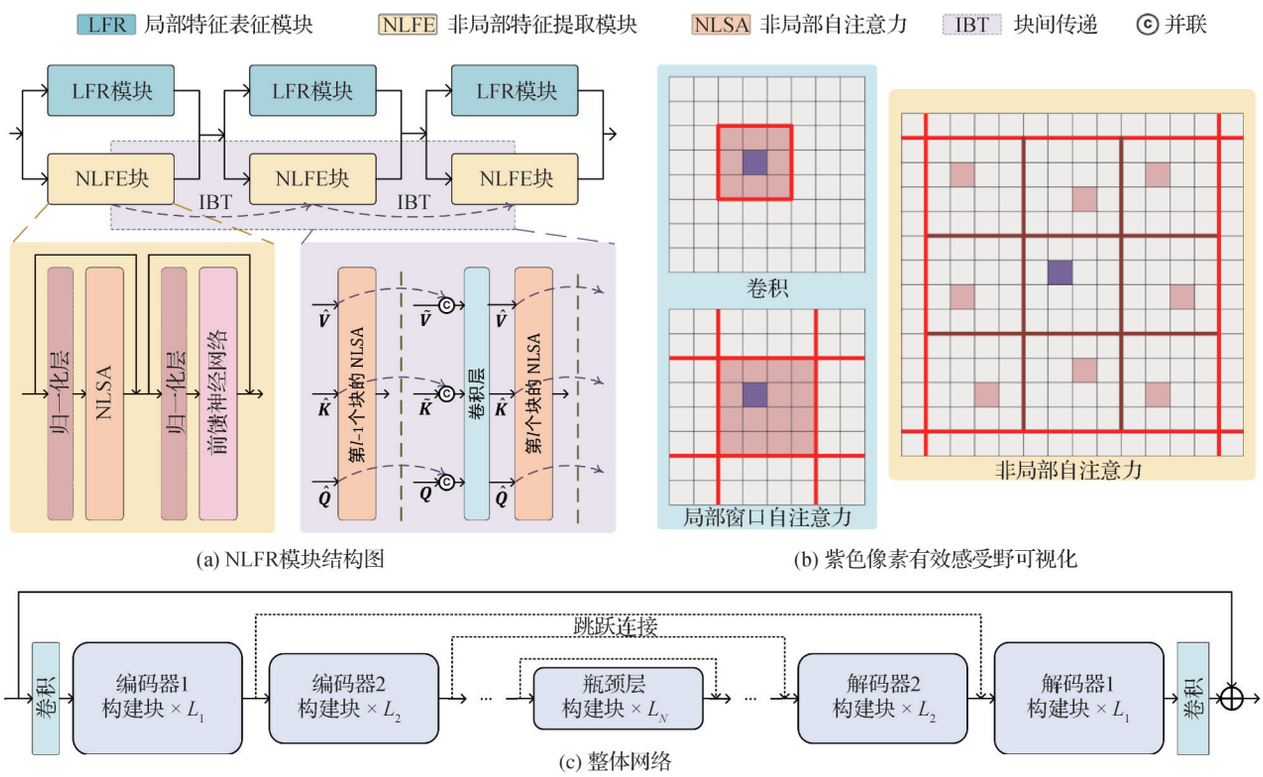


图 1　整体网络以及组成结构

Fig. 1　Overall network and component structures ((a) structure of the NLFR module; (b) visualization of the effective receptive filed of the purple pixel; (c) overall network)

2.1　非局部特征表示模块

以往基于 CNN 或基于局部窗口的 Transformer 模型大多只能提取局部特征，难以建模远距离像素之间的交互关系。为了解决这个问题，本文提出一个通用的非局部特征表示（non-local feature representation，NLFR）模块来提取非局部信息，可以灵活地与大多数能提取局部信息的构建块结合，将两种类型信息耦合在一个块内以增强构建块的表达能力（图 1(a)），该模块具有较大的感受野（图 1(b)）。NLFR 模块由非局部特征提取（non-local feature extraction，NLFE）块和块间传输（inter-block transmission，IBT）机制组成，其中 NLFE 块基于大窗口 Transformer 设计并引入非局部自注意力机制以提取非局部信息。具体来说，给定一个已经窗口化的输入特征 X，NLFE 块首先通过 1 × 1 卷积将其映射成 3 个序列：查询（query，$\boldsymbol{Q}$）、键（key，$\boldsymbol{K}$）和值（value，$\boldsymbol{V}$）。$\boldsymbol{Q}=\boldsymbol{W}^{Q}\boldsymbol{X}$，$\boldsymbol{K}=W^{K}X$，$\boldsymbol{V}=W^{V}X$，其中，$W^{(\cdot)}$ 指卷积操作。随后，为了避免局部信息的干扰以捕获纯粹的非局部信息，非局部自注意机制隐式地将 $\boldsymbol{K}$ 和 $\boldsymbol{V}$ 序列划分为更小的不重叠图像块。每个图像块中只有一个最大的像素点被采样并参与自注意力计算操作，如图 2 所示。

这种方法不仅限制了图像块内部的局部信息交互，而且由于只计算被采样点之间的交互性，计算复杂度也大大降低。采样后的序列 $\tilde{\boldsymbol{K}}$ 和 $\tilde{\boldsymbol{V}}$ 可以表示为

$$\tilde{\boldsymbol{K}}=S_{P\times P}(\boldsymbol{K}) \tag{1}$$

$$\tilde{\boldsymbol{V}}=S_{P\times P}(\boldsymbol{V}) \tag{2}$$

式中，$S_{P\times P}(\cdot)$ 表示在大小为 P 的图像块内采样值最大的像素点。

NLFR 块中的前馈网络遵循经典设计，由两个 1 × 1 卷积和中间的一个激活函数 GELU（Gaussian error linear unit）组成。前一个卷积将通道数提升为 α 倍，然后第 2 个卷积将通道减小到原始维数，其中，α 通常设置为 4。此外，如果与之结合的 LFR 模块包含归一化层，也会在 NLFE 块中添加相同的归一化层来对齐特征值。

2.2　块内传递机制

为了缓解 NLFE 块中局部信息随着网络深度的增加而积累的问题，提出了 IBT 机制。对于连续 NLFE 块，IBT 机制可以为它们提供直接传输非局部

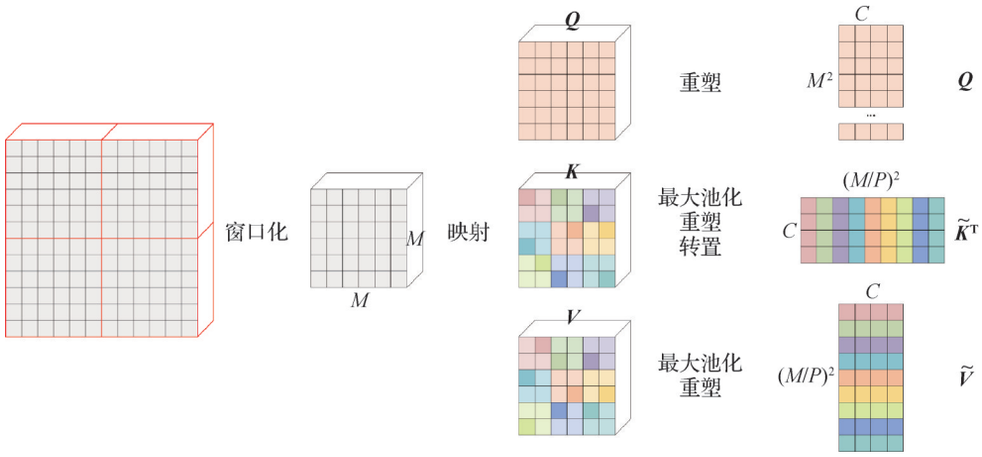


图2　$\tilde{K}, \tilde{V}$序列生成流程

Fig. 2　Process of $\tilde{K}, \tilde{V}$ sequence generation

特征的额外信息流。具体地，来自第l个NLFE块的注意力层的$\hat{Q}_l$、$\hat{K}_l$、$\hat{V}_l$或Q_l、$\tilde{K}_l$、$\tilde{V}_l$被转移到第$l+1$个NLFE块，在那里分别与生成的Q_{l+1}、$\tilde{K}_{l+1}$、$\tilde{V}_{l+1}$特征融合。融合时首先将两者在通道维度并联，然后再传递给共享参数的卷积层，包括一个1×1卷积和一个3×3深度卷积。在特征融合结束之后，产生的$\hat{Q}_{l+1}$、$\hat{K}_{l+1}$、$\hat{V}_{l+1}$执行第$l+1$个块的自注意力操作也将继续传递给下一个NLFE块，具体为

$$\hat{Q}_{l+1}=\begin{cases}F(Q_l,Q_{l+1}) & l=1\\ F(\hat{Q}_l,Q_{l+1}) & l>1\end{cases} \tag{3}$$

$$\hat{K}_{l+1}=\begin{cases}F(\tilde{K}_l,\tilde{K}_{l+1}) & l=1\\ F(\hat{K}_l,\tilde{K}_{l+1}) & l>1\end{cases} \tag{4}$$

$$\hat{V}_{l+1}=\begin{cases}F(\tilde{V}_l,\tilde{V}_{l+1}) & l=1\\ F(\hat{V}_l,\tilde{V}_{l+1}) & l>1\end{cases} \tag{5}$$

式中，$\hat{Q}_{l+1}$、$\hat{K}_{l+1}$、$\hat{V}_{l+1}$为第$l+1$层融合之后产生的特征，$F(\cdot)$为特征融合机制。

IBT机制的优点在于：1）为连续的NLFR模块提供直接的信息流，有效地增强了块间的连通性；2）IBT的参数共享设计在不影响性能的前提下节省了计算资源。

2.3　与局部特征表示模块结合

NLFR模块与LFR模块结合时，首先以NLFE块替换掉LFR模块中原有的残差连接，然后在连续的NLFE块上应用IBT机制。

1）与ResBlock结合。Nah等人（2017）提出了一种适应去模糊任务的基本构建块ResBlock，由两个卷积层和中间的ReLU（rectified linear unit）组成。自此以后，ResBlock及其变体经常应用在不同的去模糊模型中。因此，首先选择ResBlock作为LFR模块与NLFR模块结合来搭建模型。

2）与LeWin Transformer Block结合。最近，有研究者开发出以Transformer块为构建块来提取局部特征的模型，并取得了显著的成果。本文尝试将经典的局部窗口LeWin Transformer块作为LFR模块与NLFR模块相结合来搭建网络，对于这种具有两个子块的块，只与第1个子块结合以避免过度的内存消耗。

3）与LeFF块结合。LeFF块（Yuan等，2021）原本是作为Transformer块的前馈网络层被提出，目的是结合CNN提取局部信息的特征。虽然目前没有在去模糊模型中应用独立的LeFF块，但包含该块的Transformer模型已在去模糊任务中获得了出色的表现，此外，LeFF块还具有低计算资源的特性。所以本文将其视为一个单独的块并与NLFR模块相结合来搭建网络模型。

2.4　网络整体结构

网络整体结构是一个单阶段N层的UNet，包括$N-1$个对称的编码器—解码器和一个在最底部的瓶颈层，同一层的编码器解码器之间都有一个跳跃连接。详细的图像恢复过程如下：

1）给定模糊图像$\boldsymbol{B}\in\mathbf{R}^{H\times W\times3}$，使用$3\times3$卷积和激活函数提取其浅层特征$\boldsymbol{F}_0\in\mathbf{R}^{H\times W\times C}$，其中$H$和$W$代表特征的尺寸，$C$是通道数。

2）浅层特征依次通过编码器、瓶颈层和解码器，从中逐渐提取更深的特征。瓶颈层和每个编码器、

解码器都包含多个基本构建块，并且块的数量随着级别的增加而增加，以降低计算消耗和占用内存。

3）在同层编码器和解码器之间的跳跃连接能将编码器的粗级特征与解码器的精细特征连接起来。

4）不同层次的编解码器和瓶颈层通过上采样和下采样连接，每次下采样操作都扩大了通道数并采用像素变换压缩空间维度，上采样操作则通过转置卷积实现。

5）最后一个解码器后，将输出特征恢复到原始大小，然后进行卷积，将通道数减少到3，得到$\boldsymbol{I} \in \mathbf{R}^{H \times W \times 3}$。

6）将$\boldsymbol{I}$与原始模糊图像$\boldsymbol{B}$相加，得到恢复图像$\boldsymbol{I}_r$。遵循Cho等人（2021）的方法，本文的损失函数L也使用内容损失L_{cont}和频域损失L_{freq}来训练模型，具体为

$$L = L_{\text{cont}} + \lambda L_{\text{freq}} \tag{6}$$

$$L_{\text{cont}} = \left\| \boldsymbol{I}_r - \boldsymbol{I}_s \right\|_1 \tag{7}$$

$$L_{\text{freq}} = \left\| F\left(\boldsymbol{I}_r\right) - F\left(\boldsymbol{I}_s\right) \right\|_1 \tag{8}$$

式中，$\boldsymbol{I}_s$为清晰图像，$F(\cdot)$为快速傅里叶变换，λ为权重因子，设为0.1。

3 实　验

在本节中，为证明所提出方法的优越性，分别在去运动模糊和去散焦模糊任务中进行实验。

3.1 基本设置

3.1.1 数据集

用GoPro数据集（Nah等，2017）训练模型以进行去运动模糊的实验。GoPro数据集包括3 214对模糊和清晰图像，其中2 103对作为训练数据集，剩下的1 111对作为测试数据集。为了展示模型的泛化能力，本文将在GoPro上训练的权重直接应用到HIDE（human-aware motion deblurring）数据集（Shen等，2019）上进行测试。HIDE数据集是专门为人类感知运动去模糊数据集设计的，其中包含2 025对图像，仅供测试。去散焦模糊实验在DPD（defocus deblurring using dual-pixel data）（Abuolaim和Brown，2020）数据集上进行。DPD数据集由2 000幅尺寸为6 720×4 480像素的图像组成，其中500幅为散焦模糊图像，1 000幅为双像素子孔径视图，500幅为对应的全焦图像。

3.1.2 实验细节

目前主流的训练方法是在图像块上训练模型，因此会在GoPro训练集的原始图像上随机裁剪出尺寸为256×256像素的图像块上训练模型。在DPD数据集上，训练样本会被裁剪为具有60%重叠区域的512×512像素的图像块，并且锐度能量最低的30%图像块会被直接丢弃（Wang等，2022）。采用的数据增广包括随机旋转和水平翻转。测试也将采用通用的策略，首先会根据模型的下采样次数将测试图像填充到合适的尺寸，例如8的倍数或16的倍数等，然后在推理时将恢复的填充图像裁剪到原始大小。采用常用的峰值信噪比（peak signal-to-noise ratio，PSNR）和结构相似性（structural similarity，SSIM）指标来评估去模糊性能，并采用标准偏差（standard deviation，STD，记做σ）来验证复原图像质量的稳定性，其中σ_{P}表示PSNR的标准偏差，σ_{S}表示SSIM的标准偏差。此外，针对去散焦模糊额外采用两个评价指标，即平均绝对误差（mean absolute error，MAE）和学习感知图像补丁相似度（learned perceptual image patch similarity，LPIPS）。

在所有实验中，除非另有说明，否则都使用以下参数训练。采用Adam优化器训练模型，初始学习率设置为1E−4，逐渐降低至1E−7。如果模型中存在归一化层则应适当提高学习率（Chen等，2022），因此将初始学习率设为2E−4，逐渐降低至1E−6。窗口尺寸W默认为64，采样块尺寸P默认为8，以ResBlock为默认的LFR模块。

3.2 消融实验

在本小节中，实验中所用到的模型均在GoPro数据集上训练1 000轮。为了保持实验的简明性，模型架构定为3层的UNet，从编码器到瓶颈层再到解码器，其中堆叠的构建块数量分别为2，4，16。根据第1层中通道数（16或32）将模型分为UNet^{T}和UNet^{B}两种变体。

3.2.1 特征图可视化

对于NLFR模块与LFR模块相结合后的模型，可视化输入的模糊图像在两者处的特征图如图3所示。LFR模块处的特征图显示了图像的细节纹理，而在NLFR模块中，原始图像的纹理被有效抑制，只显示图像的轮廓。

3.2.2 有效性验证

在UNet^{B}模型上验证网络中各个部件所带来的

增益效果，结果如表1所示。由NLFR模块和LFR模块结合组成的网络与仅使用LFR模块组成的网络相比，可获得0.89 dB PSNR的增益。在此基础上应用IBT机制，PSNR进一步提高了0.09 dB。为了进一步更公平地比较，仅使用ResBlock作为构建块搭建一个基线模型，通过调整第1层通道数和各层堆叠的构建块数量，将其计算开销和参数量提升到与本文网络的相当水平。结果表明，与直接使用ResBlock作为构建块相比，NLFR模块结合ResBlock在构建去模糊网络上会更加高效。

3.2.3　窗口大小和采样斑块大小

为分析NLFR块中窗口尺寸和采样块尺寸这两个重要参数对去模糊效果的影响，在UNet^{T}模型上同时调整这两个参数进行实验。不同窗口大小和采样尺寸对应的PSNR结果如表2所示。可以看出，当采样块尺寸固定时，增大窗口尺寸可以显著改善去模糊效果，但同时也增加了计算成本。而在计算复杂度相当的情况下，在较大的窗口上选择合适的采样率比在较小的窗口上不使用采样获得了更好的结果。这意味着合理引入局部最大池化不仅可以减少计算复杂度，也在一定程度上促进了去模糊过程。



(a) 模糊图像　(b) LFR处　(c) NLFR处

图3　模糊图像在网络中的特征图可视化

Fig. 3　The feature map visualization of blur images in the network ((a) blur images; (b) at LFR; (c) at NLFR)

表1　NLFR模块中各部件的有效性分析

Table 1　Effectiveness analysis of the components in the NLFR module

UNet^{B}	LFR	NLFE	IBT	PSNR/dB	σ_p	SSIM	σ_s	参数量/M	模型复杂度/GFLOPs
√	√			31.19	2.853	0.945	0.033	**5.52**	**34.89**
√	√	√		32.08	2.727	0.953	0.026	9.13	60.58
√	√	√	√	**32.17**	**2.710**	**0.954**	**0.025**	9.76	63.78
基线：以ResBlock为构建块组成的UNet				31.63	2.790	0.949	0.030	9.77	66.38

注：加粗字体表示各列最优结果；“√”表示采用了该子网络。

表2　不同窗口尺寸(W)和采样块尺寸(P)的性能比较

Table 2　Performance comparison of different window sizes (W) and sampling patch sizes (P)

	PNSR/dB				
	P = 16	P = 8	P = 4	P = 2	不使用采样
W = 64	31.22	**31.30**	31.29	–	–
W = 32	31.21	31.23	31.24	31.31	–
W = 16	–	31.13	31.09	31.14	31.10

注：加粗字体表示最优结果；“–”表示无数据 。

3.2.4　可扩展性实验

为了验证NLFR模块的通用性，在UNet^{T}模型上使用不同的构建块作为LFR模块进行了实验。表3表明，与原始构建块网络相比，由NLFR结合块构建的网络都能获得显著的提升，其中LeFF作为LFR模块获得了1.58 dB PSNR的最高增幅。

表3　不同LFR模块与NLFR模块结合的性能对比

Table 3　Performance comparison of NLFR modules combined with different LFR modules

LFR	NLFR	PSNR/dB	σ_p	SSIM	σ_s
ResBlock	未采用	29.99	3.039	0.931	0.041
	采用	31.30(+1.31)	2.786	0.945	0.031
LeWin Transformer块	未采用	30.01	3.001	0.933	0.038
	采用	31.33(+1.32)	2.785	0.947	0.031
LeFF块	未采用	29.84	3.126	0.928	0.044
	采用	**31.42(+1.58)**	**2.728**	**0.948**	**0.029**

注：加粗字体表示各列最优结果，“()”内表示增幅。

3.2.5　NLFR模块的视觉效果

为了进一步验证所提出的NLFR的有效性，对有无NLFR模块网络的恢复图像视觉进行比较，结果如图4所示。从图4可以看到，包含NLFR模块的网络恢复的图像具有更好的视觉效果，特别是轮廓更加清晰完整。



(a) 模糊图像　(b) 清晰图像　(c) 使用NLFR　(d) 不使用NLFR

图4　有无NLFR模块的视觉效果对比

Fig. 4　Comparison of visual effects with and without NLFR module

((a) blur images; (b) sharp images; (c) w/ NLFR; (d) w/o NLFR)

3.2.6　K-V序列的采样策略

为了分析哪种采样策略提取的信息更有利于图像去模糊过程，本文通过实验将NLFR块中使用的最大池化与PVT中的平均池化和卷积进行比较。结果如表4所示，最大池化操作的性能优于其他方法，并且与卷积运算相比，池化操作也不需要引入额外的训练参数。

表4　NLFR模块中采样策略分析

Table 4　Analysis of sampling strategies in the NLFR module

方法	PSNR/dB	σ_p	SSIM	σ_s	参数量/M
最大池化	**31.30**	**2.786**	**0.945**	**0.030**	**2.46**
平均池化	31.04	2.855	0.943	0.032	**2.46**
卷积	31.02	2.867	0.943	0.032	2.63

注：加粗字体表示各列最优结果。

3.3　以NLFR组合块构建网络的图像去模糊结果

本文将NLFR模块分别与LeFF块和ResBlock结合作为构建块设计了两个网络模型，其中与LeFF块结合的网络命名为NLCNet_L，应用在去运动模糊任务上；与ResBlock结合的网络命名为NLCNet_R，应用在去散焦模糊任务上。

按照主流的训练方法，NLCNet_L在GoPro数据集上进行3 000轮的训练，并在GoPro测试集和HIDE数据集上进行测试，对图像尺寸为256×256像素的情况计算了模型复杂度，结果如表5和表6所示。从表5可知，本文方法在GoPro测试集上以最低的计算复杂度取得了最好结果。相较Wang等人(2022)的方法，本文方法将PSNR提高了0.29 dB。表6显示，本文方法在HIDE数据集上也取得了有竞争力的结果。恢复图像的视觉比较如图5和图6所示。可以看出，与其他方法相比，本文方法恢复的图像更加精准，视觉上更接近于真实图像。

在DPD数据集上训练NLCNet_R模型200轮以

表5　GoPro测试集上的单幅图像运动去模糊性能对比

Table 5　Performance comparison of single image motion deblurring on GoPro test set

方法	PSNR/dB	σ_p	SSIM	σ_s	模型复杂度/GFLOPs
Nah等人(2017)	29.08	2.909	0.914	0.038	–
Zhang等人(2019)	31.20	2.558	0.940	0.028	678.56
Zhang等人(2020)	31.10	2.768	0.942	0.032	759.85
Tsai等人(2022b)	32.54	2.703	0.957	0.024	264.00
Zamir等人(2021)	32.66	2.655	0.959	0.023	777.01
Cho等人(2021)	32.45	2.671	0.957	0.026	154.41
Tu等人(2022)	32.86	**2.356**	0.961	0.020	169.50
Wang等人(2022)	32.97	2.470	**0.967**	**0.019**	89.46
本文	**33.26**	2.525	0.963	**0.019**	**75.85**

注：加粗、下划线字体分别表示各列最优、次优结果；“–”表示无数据。

表6　HIDE测试集上的单幅图像运动去模糊性能对比

Table 6　Performance comparison of single image motion deblurring on HIDE test set

方法	PSNR/dB	σ_p	SSIM	σ_s	模型复杂度/GFLOPs
Zhang等人(2020)	28.94	3.307	0.915	0.049	759.85
Zhang等人(2019)	29.09	**2.809**	0.924	0.040	678.56
Cho等人(2021)	29.99	2.892	0.930	0.034	154.41
Tsai等人(2022b)	30.16	3.334	0.930	0.042	264.00
Purohit等人(2021)	30.29	–	0.931	–	2 401.00
Zamir等人(2021)	30.96	3.135	0.939	**0.030**	777.01
Wang等人(2022)	30.83	2.886	**0.952**	**0.029**	89.46
本文	**31.08**	3.063	0.940	**0.029**	**75.85**

注：加粗、下划线字体分别表示各列最优、次优结果；“–”表示无数据。



图5　NCLNet_L模型在GoPro测试集上与其他方法的恢复图像视觉效果对比

Fig. 5　NCLNet_L model visualization of restored images on GoPro test set vs. other methods

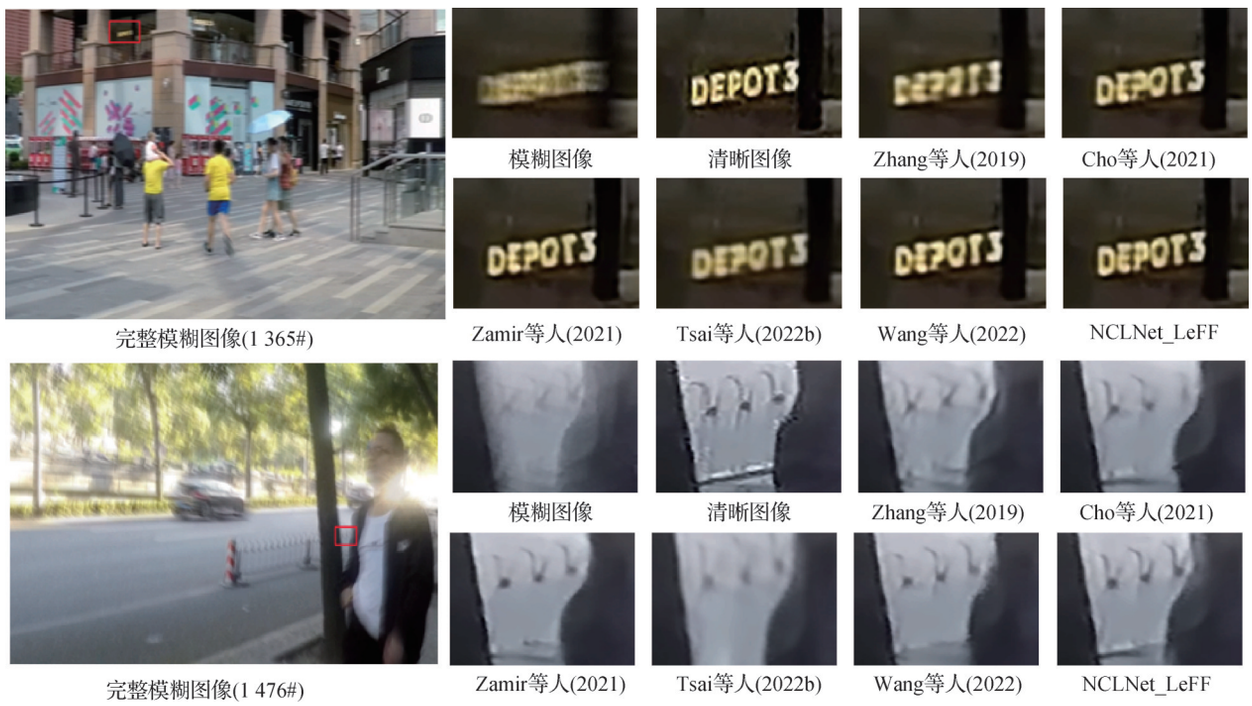


图 6　NCLNet_L 模型在 HIDE 测试集上与其他方法的恢复图像视觉效果对比

Fig. 6　NCLNet_L model visualization of restored images on HIDE test set vs. other methods

进行双像素去散焦模糊实验。在表 7 的综合场景类别中，模型在 4 个指标上都取得了最优表现。与 Wang 等人（2022）的方法相比，本文方法在室内和室外场景下的 PSNR 分别提高了 1.37 dB 和 0.94 dB。从图 7 可以看出，本文方法相比于其他方法更清晰地恢复出了图像的轮廓。

表 7　DPD 数据集上的双像素散焦去模糊性能对比

Table 7　Performance comparison of dual-pixel defocus deblurring on the DPD dataset

方法	室内场景				室外场景				综合场景					
	PSNR/dB	SSIM	MAE	LPIPS	PSNR/dB	SSIM	MAE	LPIPS	PSNR/dB	σ_p	SSIM	σ_s	MAE	LPIPS
Abuolaim 和 Brown（2020）	27.48	0.849	0.029	0.189	22.90	0.726	0.052	0.255	25.13	–	0.786	–	0.041	0.233
Abuolaim 等人（2021）	28.10	0.843	0.027	0.210	22.82	0.704	0.053	0.298	25.39	–	0.772	–	0.040	0.255
Liang 等人（2022）	28.60	0.872	0.026	–	24.30	0.772	**0.045**	–	26.40	4.218	0.821	0.110	0.036	–
Lee 等人（2021）	28.66	0.868	0.025	0.172	23.46	0.743	0.049	0.240	25.99	4.190	0.804	0.111	0.037	0.207
Zamir 等人（2023）	28.96	0.881	0.024	0.154	23.59	0.753	0.049	0.205	26.20	4.461	0.816	0.115	0.037	0.180
Ruan 等人（2022）	29.06	0.873	0.024	**0.121**	23.73	0.752	0.048	0.184	26.33	4.221	0.811	0.109	0.037	0.154
Wang 等人(2022）	28.23	0.860	0.026	0.199	23.10	0.728	0.051	0.285	25.65	**4.116**	0.795	**0.106**	0.039	0.243
本文	**29.60**	**0.898**	**0.023**	0.127	**24.04**	**0.780**	0.047	**0.177**	**26.75**	4.408	**0.837**	0.110	**0.035**	**0.153**

注：加粗字体表示各列最优结果，“–”表示无数据 。

4　结　论

以往大多数能够处理高分辨率图像的去模糊模型仅能充分提取局部特征，而不能对远距离视觉像素依赖的特征进行建模。为了解决这个问题，本文提出了一个通用的 NLFR 模块来表征从图像中提取真正的非局部信息，这些信息可以与网络中的局部

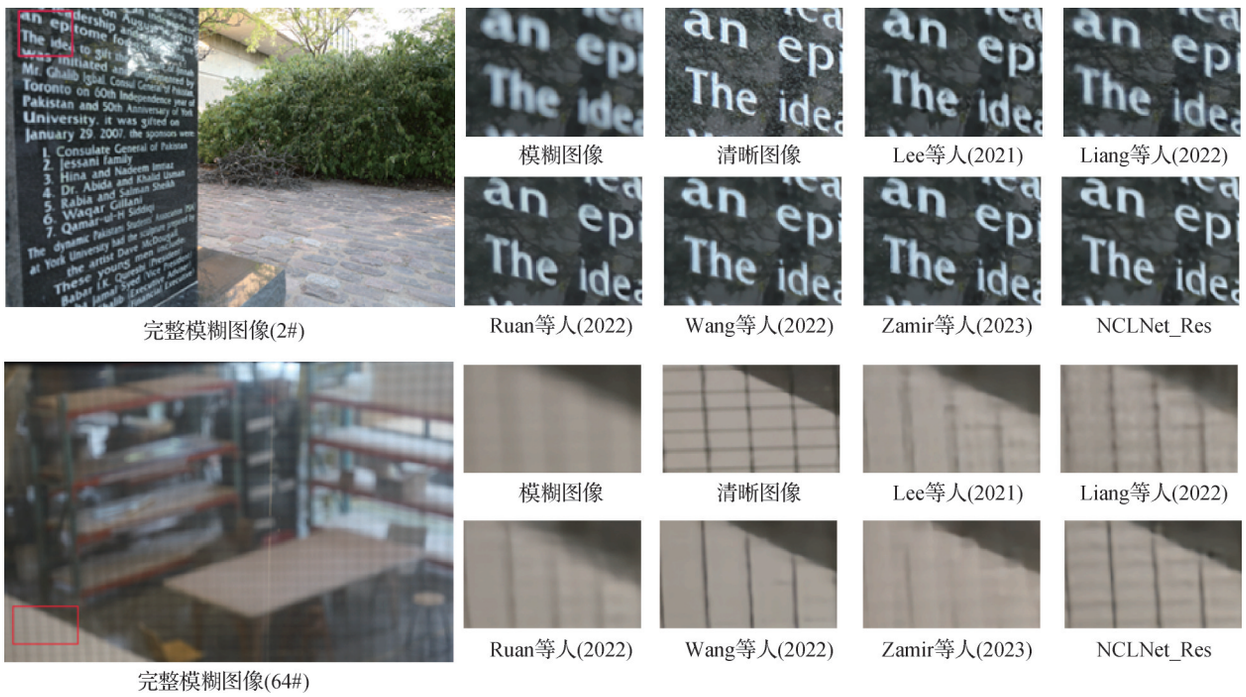


图7　NCLNet_R模型与其他优秀方法的恢复图像视觉效果对比

Fig. 7　Visual comparison of restored images of NCLNet_R model with other excellent methods

信息耦合，从而提高模型的表达能力。通过合理的设计，由NLFR模块组成的网络能在较低计算资源的情况下获得非常优秀的性能表现，且恢复图像的视觉效果尤其是边缘轮廓更加清晰完整。

本文提出的模型可以通过调整窗口尺寸和采样块尺寸来获得最佳的模型性能，但是人为固定的采样尺寸难以统一契合所有分辨率的图像。未来可以尝试利用注意力模型生成的注意力掩码来动态采样全局相似度强的特征点，从而提升模型的泛化性。

参考文献(References)

Abuolaim A and Brown M S. 2020. Defocus deblurring using dual-pixel data//Proceedings of the 16th European Conference on Computer Vision-ECCV 2020. Glasgow, UK: Springer: 111-126 [DOI: 10.1007/978-3-030-58607-2_7]

Abuolaim A, Delbracio M, Kelly D, Brown M S and Milanfar P. 2021. Learning to reduce defocus blur by realistically modeling dual-pixel data//Proceedings of 2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, Canada: IEEE: 2269-2278 [DOI: 10.1109/ICCV48922.2021.00229]

Chen H T, Wang Y H, Guo T Y, Xu C, Deng Y P, Liu Z H, Ma S W, Xu C J, Xu C and Gao W. 2021b. Pre-trained image processing Transformer//Proceedings of 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, USA: IEEE: 12294-12305 [DOI: 10.1109/CVPR46437.2021.01212]

Chen L Y, Chu X J, Zhang X Y and Sun J. 2022. Simple baselines for image restoration//Proceedings of the 17th European Conference Computer Vision — ECCV 2022. Tel Aviv, Israel: Springer: 17-33 [DOI: 10.1007/978-3-031-20071-7_2]

Chen L Y, Lu X, Zhang J, Chu X J and Chen C P. 2021a. HINet: half instance normalization network for image restoration//Proceedings of 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Nashville, USA: IEEE: 182-192 [DOI: 10.1109/CVPRW53098.2021.00027]

Chen Z N, Zhang H Y, Zeng N Y and Li H. 2022. Attention mechanism embedded multi-scale restoration method for blurred image. Journal of Image and Graphics, 27(5): 1682-1696 (陈紫柠, 张宏怡, 曾念寅, 李寒. 2022. 融合注意力机制的模糊图像多尺度复原. 中国图象图形学报, 27(5): 1682-1696) [DOI: 10.11834/jig.210249]

Cho S J, Ji S W, Hong J P, Jung S W and Ko S J. 2021. Rethinking coarse-to-fine approach in single image deblurring//Proceedings of 2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, Canada: IEEE: 4621-4630 [DOI: 10.1109/ICCV48922.2021.00460]

Dong X Y, Bao J, M Chen D D, Zhang W M, Yu N H, Yuan L, Chen D and Guo B N. 2022. CSWin Transformer: a general vision Transformer backbone with cross-shaped windows//Proceedings of 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, USA: IEEE: 12114-12124 [DOI: 10.1109/CVPR52688.2022.01181]

Dosovitskiy A, Beyer L, Kolesnikov A, Weissenborn D, Zhai X H, Unterthiner T, Dehghani M, Minderer M, Heigold G and Gelly S. 2020. An image is worth 16 × 16 words: Transformers for image recognition at scale [EB/OL]. [2023-10-23]. https://arxiv.org/pdf/2010.11929.pdf

Gong D, Yang J, Liu L Q, Zhang Y N, Reid I, Shen C H, Van Den Hengel A and Shi Q F. 2017. From motion blur to motion flow: a deep learning solution for removing heterogeneous motion blur//Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, USA: IEEE: 3806-3815 [DOI: 10.1109/CVPR.2017.405]

He K M, Zhang X Y, Ren S Q and Sun J. 2016. Deep residual learning for image recognition//Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, USA: IEEE: 770-778 [DOI: 10.1109/CVPR.2016.90]

Krishnan D, Tay T and Fergus R. 2011. Blind deconvolution using a normalized sparsity measure//Proceedings of 2011 CVPR. Colorado Springs, USA: IEEE: 233-240 [DOI: 10.1109/CVPR. 2011. 5995521]

Krizhevsky A, Sutskever I and Hinton G E. 2017. ImageNet classification with deep convolutional neural networks. Communications of the ACM, 60(6): 84-90 [DOI: 10.1145/3065386]

Lee J, Son H, Rim J, Cho S and Lee S. 2021. Iterative filter adaptive network for single image defocus deblurring//Proceedings of 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, USA: IEEE: 2034-2042 [DOI: 10.1109/CVPR46437.2021.00207]

Li Y W, Zhang K, Cao J Z, Timofte R and Van Gool L. 2021. LocalVit: bringing locality to vision Transformers [EB/OL]. [2023-10-23]. https://arxiv.org/pdf/2104.05707.pdf

Liang J Y, Cao J Z, Sun G L, Zhang K, Van Gool L and Timofte R. 2021. SwinIR: image restoration using swin Transformer//Proceedings of 2021 IEEE/CVF International Conference on Computer Vision Workshops (ICCVW). Montreal, Canada: IEEE: 1833-1844 [DOI: 10.1109/ICCVW54120.2021.00210]

Liang P W, Jiang J J, Liu X M and Ma J Y. 2022. BaMBNet: a blur-aware multi-branch network for dual-pixel defocus deblurring. IEEE/CAA Journal of Automatica Sinica, 9(5): 878-892 [DOI: 10.1109/JAS.2022.105563]

Liu Z, Lin Y T, Cao Y, Hu H, Wei Y X, Zhang Z, Lin S and Guo B N. 2021. Swin Transformer: hierarchical vision Transformer using shifted windows//Proceedings of 2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, Canada: IEEE: 9992-10002 [DOI: 10.1109/ICCV48922.2021.00986]

Nah S, Kim T H and Lee K M. 2017. Deep multi-scale convolutional neural network for dynamic scene deblurring//Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, USA: IEEE: 257-265 [DOI: 10.1109/CVPR. 2017.35]

Pan J S, Sun D Q, Pfister H and Yang M H. 2016. Blind image deblurring using dark channel prior//Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, USA: IEEE: 1628-1636 [DOI: 10.1109/CVPR.2016.180]

Purohit K, Suin M, Rajagopalan A N and Boddeti V N. 2021. Spatially-adaptive image restoration using distortion-guided networks//Proceedings of 2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, Canada: IEEE: 2289-2299 [DOI: 10.1109/ICCV48922.2021.00231]

Ruan L Y, Chen B, Li J Z and Lam M. 2022. Learning to deblur using light field generated and real defocus images//Proceedings of 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, USA: IEEE: 16283-16292 [DOI: 10.1109/CVPR52688.2022.01582]

Schuler C J, Hirsch M, Harmeling S and Schölkopf B. 2016. Learning to deblur. IEEE Transactions on Pattern Analysis and Machine Intelligence, 38(7): 1439-1451 [DOI: 10.1109/TPAMI.2015.2481418]

Shen Z Y, Wang W G, Lu X K, Shen J B, Ling H B, Xu T F and Shao L. 2019. Human-aware motion deblurring//Proceedings of 2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea: IEEE: 5571-5580 [DOI: 10.1109/ICCV. 2019. 00567]

Sun J, Cao W F, Xu Z B and Ponce J. 2015. Learning a convolutional neural network for non-uniform motion blur removal//Proceedings of 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Boston, USA: IEEE: 769-777 [DOI: 10.1109/CVPR.2015.7298677]

Tsai F J, Peng Y T, Lin Y Y, Tsai C C and Lin C W. 2022a. Stripformer: strip Transformer for fast image deblurring//Proceedings of the 17th European Conference on Computer Vision — ECCV 2022. Tel Aviv, Israel: Springer: 146-162 [DOI: 10.1007/978-3-031-19800-7_9]

Tsai F J, Peng Y T, Tsai C C, Lin Y Y and Lin C W. 2022b. BANet: a blur-aware attention network for dynamic scene deblurring. IEEE Transactions on Image Processing, 31: 6789-6799 [DOI: 10.1109/TIP.2022.3216216]

Tu Z Z, Talebi H, Zhang H, Yang F, Milanfar P, Bovik A and Li Y X. 2022. MAXIM: multi-axis MLP for image processing//Proceedings of 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, USA: IEEE: 5759-5770 [DOI: 10.1109/CVPR52688.2022.00568]

Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez A N, Kaiser Ł and Polosukhin I. 2017. Attention is all you need//Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach, USA: Curran Associates Inc.: 6000-6010 [DOI: 10.5555/3295222.3295349]

Wang W H, Xie E Z, Li X, Fan D P, Song K T, Liang D, Lu T, Luo P and Shao L. 2021. Pyramid vision Transformer: a versatile backbone for dense prediction without convolutions//Proceedings of

2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, Canada: IEEE: 548-558 [DOI: 10.1109/ICCV48922.2021.00061]

Wang Z D, Cun X D, Bao J M, Zhou W G, Liu J Z and Li H Q. 2022. Uformer: a general U-shaped Transformer for image restoration// Proceedings of 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, USA: IEEE: 17662-17672 [DOI: 10.1109/CVPR52688.2022.01716]

Xu L, Zheng S C and Jia J Y. 2013. Unnatural L_0 sparse representation for natural image deblurring//Proceedings of 2013 IEEE Conference on Computer Vision and Pattern Recognition. Portland, USA: IEEE: 1107-1114 [DOI: 10.1109/CVPR.2013.147]

Yuan K, Guo S P, Liu Z W, Zhou A J, Yu F W and Wu W. 2021. Incorporating convolution designs into visual Transformers//Proceedings of 2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, Canada: IEEE: 559-568 [DOI: 10.1109/ICCV48922.2021.00062]

Zamir S W, Arora A, Khan S, Hayat M, Khan F S and Yang M H. 2022. Restormer: efficient Transformer for high-resolution image restoration//Proceedings of 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, USA: IEEE: 5718-5729 [DOI: 10.1109/CVPR52688.2022.00564]

Zamir S W, Arora A, Khan S, Hayat M, Khan F S, Yang M H and Shao L. 2021. Multi-stage progressive image restoration//Proceedings of 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, USA: IEEE: 14816-14826 [DOI: 10.1109/CVPR46437.2021.01458]

Zamir S W, Arora A, Khan S, Hayat M, Khan F S, Yang M H and Shao L. 2023. Learning enriched features for fast image restoration and enhancement. IEEE Transactions on Pattern Analysis and Machine Intelligence, 45(2): 1934-1948 [DOI: 10.1109/TPAMI.2022.3167175]

Zhang H G, Dai Y C, Li H D and Koniusz P. 2019. Deep stacked hierarchical multi-patch network for image deblurring//Proceedings of 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, USA: IEEE: 5971-5979 [DOI: 10.1109/CVPR.2019.00613]

Zhang K H, Luo W H, Zhong Y R, Ma L, Stenger B, Liu W and Li H D. 2020. Deblurring by realistic blurring//Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, USA: IEEE: 2734-2743 [DOI: 10.1109/CVPR42600.2020.00281]

作者简介

华夏,男,副教授,主要研究方向为深度学习算法和图像处理。E-mail: hedahuaxia@wit.edu.cn

洪汉玉,通信作者,男,教授,主要研究方向为模式识别和计算机视觉。E-mail: hhyhong@wit.edu.cn

舒婷,女,硕士研究生,主要研究方向为图像处理。E-mail: sttt1130@163.com

李明欣,男,硕士研究生,主要研究方向为深度学习算法和图像处理。E-mail: limingxin0005@gmail.com

时愈,女,副教授,主要研究方向为图像复原。E-mail: shiyu0125@wit.edu.cn