Journal of Computer Applications
计算机应用, 2024, 44(5): 1644 - 1654
ISSN 1001-9081
CODEN JYIIDU
2024-05-10
http://www.joca.cn

文章编号:1001-9081(2024)05-1644-11
DOI:10.11772/j.issn.1001-9081.2023060796

基于Transformer的视觉目标跟踪方法综述

孙子文[1],钱立志[1],杨传栋[1],高一博[1],陆庆阳[2],袁广林[2*]
(1. 陆军炮兵防空兵学院 高过载弹药制导控制与信息感知实验室,合肥 230031;
2. 陆军炮兵防空兵学院 信息工程系,合肥 23003)
(*通信作者电子邮箱1183212999@qq.com)

摘　要:视觉目标跟踪是计算机视觉中的重要任务之一,为实现高性能的目标跟踪,近年来提出了大量的目标跟踪方法,其中基于Transformer的目标跟踪方法由于具有全局建模和联系上下文的能力,是目前视觉目标跟踪领域研究的热点。首先,根据网络结构的不同对基于Transformer的视觉目标跟踪方法进行分类,概述相关原理和模型改进的关键技术,总结不同网络结构的优缺点;其次,对这类方法在公开数据集上的实验结果进行对比,分析网络结构对性能的影响,其中MixViT-L(ConvMAE)在LaSOT和TrackingNet上跟踪成功率分别达到了73.3%和86.1%,说明基于纯Transformer两段式架构的目标跟踪方法具有更优的性能和更广的发展前景;最后,对方法当前存在的网络结构复杂、参数量大、训练要求高和边缘设备使用难度大等不足进行总结,并对今后的研究重点进行展望,通过与模型压缩、自监督学习以及Transformer可解释性分析相结合,可为基于Transformer的视觉目标跟踪提出更多可行的解决方案。

关键词:计算机视觉;目标跟踪;混合网络结构;深度学习;孪生网络;Transformer
中图分类号:TP391.4　　**文献标志码**:A

Survey of visual object tracking methods based on Transformer

SUN Ziwen[1], QIAN Lizhi[1], YANG Chuandong[1], GAO Yibo[1], LU Qingyang[2], YUAN Guanglin[2*]
(1. *Laboratory of Guidance Control and Information Perception Technology of High Overload Projectiles, Army Academy of Artillery and Air Defense, Hefei Anhui* 230031, *China*;
2. *Department of Information Engineering, Army Academy of Artillery and Air Defense, Hefei Anhui* 230031, *China*)

Abstract: Visual object tracking is one of the important tasks in computer vision, in order to achieve high-performance object tracking, a large number of object tracking methods have been proposed in recent years. Among them, Transformer-based object tracking methods become a hot topic in the field of visual object tracking due to their ability to perform global modeling and capture contextual information. Firstly, existing Transformer-based visual object tracking methods were classified based on their network structures, an overview of the underlying principles and key techniques for model improvement were expounded, and the advantages and disadvantages of different network structures were also summarized. Then, the experimental results of the Transformer-based visual object tracking methods on public datasets were compared to analyze the impact of network structure on performance. in which MixViT-L (ConvMAE) achieved tracking success rates of 73.3% and 86.1% on LaSOT and TrackingNet, respectively, proving that the object tracking methods based on pure Transformer two-stage architecture have better performance and broader development prospects. Finally, the limitations of these methods, such as complex network structure, large number of parameters, high training requirements, and difficulty in deploying on edge devices, were summarized, and the future research focus was outlooked, by combining model compression, self-supervised learning, and Transformer interpretability analysis, more kinds of feasible solutions for Transformer-based visual target tracking could be presented.

Key words: computer vision; object tracking; hybrid network structure; deep learning; Siamese network; Transformer

0　引言

随着近30年人工智能技术的发展,计算机视觉目标跟踪技术已经发展成为该领域重要的研究方向。目标跟踪的任务是在给定初始帧序列的条件下预测目标在视频序列中下一帧的位置。目标跟踪广泛应用于计算机视觉领域,如公共安防视频监控[1]、智能机器人视觉[2]、无人自动驾驶[3]以及人机智能交互[4]等。目前根据跟踪目标数量的不同可以分成单目标跟踪与多目标跟踪,本文主要是对单目标跟踪进行研究。近些年,虽然目标跟踪的发展取得了重大进步,并引起工业界以及学术界的广泛关注和大量研究[5-6],但仍然面临很多挑战,如目标遮挡、快速移动、严重形变、目标干扰以

收稿日期:2023-06-21;**修回日期**:2023-09-04;**录用日期**:2023-09-11。　**基金项目**:军队型号项目(LZX20190112)。
作者简介:孙子文(1996—),男,安徽蒙城人,博士研究生,主要研究方向:计算机视觉;　钱立志(1963—),男,安徽枞阳人,教授,博士,主要研究方向:智能弹药打击;　杨传栋(1994—),男,山东泰安人,博士研究生,主要研究方向:计算机视觉;　高一博(1998—),男,安徽太和人,硕士,主要研究方向:机器学习、硬件可编程语言;　陆庆阳(1994—),男,安徽合肥人,硕士研究生,主要研究方向:自然语言处理、目标跟踪;　袁广林(1976—),河南周口人,副教授,博士,主要研究方向:计算机视觉、机器学习。

及目标清晰度变化等。因此，如何设计一个高精度、高可靠性的实时目标跟踪方法非常具有挑战性。

为了应对目标跟踪面临的诸多挑战，大量的目标跟踪方法被提出。早期的目标跟踪方法与经典的机器学习方法相结合，采用支持向量机[7-8]、稀疏重建[9]、集成学习[10]等方法。2010年，Bolme等[11]首次提出基于相关滤波的目标跟踪方法MOSSE（Minimum Output Sum Square Error），相较于早期目标跟踪方法，相关滤波跟踪方法利用在目标周围循环移位采样的方式大量扩充目标训练样本，增大了样本训练时的多样性，有效提升了跟踪鲁棒性和精确度。另外在进行卷积计算时采用快速傅里叶变换（Fast Fourier Transform，FFT）在频域内进行加速，在降低计算量的同时提高了效率，因此跟踪精度和速度都有大幅提高。随后，不断有研究者在特征选择和模型优化方面进行改进，代表的算法有CSK（Circulant Structure Kernel）[12]、KCF（Kernelized Correlation Filters）[13]、DSST（Discriminative Scale Space Tracking）[14]、SAMF（Socially Aware Mobility Framework）[15]和CSR-DCF（Channel and Spatial Reliability-aware DCF）[16]等。之后随着计算机硬件运算能力的加强，深度学习方法迅速发展，基于深度学习目标跟踪方法通过卷积神经网络（Convolutional Nueral Network，CNN）设计更加复杂的网络结构，提取更具有表达能力的深度特征。为了充分利用相关滤波与深度学习的优势，两者相结合的方法不断被提出，代表算法DeepSRDCF（Deep Spatially Regularized Discriminative Correlation Filter）[17]、HCF（Hierarchical Convolutional Features）[18]、BACF（Background Aware Correlation Filter）[19]、C-COT（Continuous Convolution Operators for visual Tracking）[20]、ECO（Efficient Convolution Operators）[21]以及UPDT（Unified Particle Decision Tree）[22]等方法。基于深度学习与相关滤波相结合的目标跟踪方法成为计算机视觉目标跟踪领域的主流方法。

Transformer在2017年首次被Vaswani等[23]应用于机器文本翻译任务。Transformer主要是由编码器和解码器两部分构成，其中的编、解码器都由注意力模块的多重叠加状态所构成。Transformer通常以一个序列作为输入，扫描序列中的每个元素，并行计算序列中任意元素相对其他所有元素的相关性，高效地提取上下文信息，并学习它们的依赖关系。这个特性使Transformer能够在本质上擅长捕获输入序列中的全局信息。Transformer凭借着并行化处理能力和良好的性能，迅速取代了长短期记忆（Long Short-Term Memory，LSTM）模型，很快在自然语言处理（Natural Language Processing，NLP）任务中占据主导地位，成为自然语言建模的主流架构。2018年谷歌提出的BERT（Bidirectional Encoder Representations from Transformers）[24]和Radford等提出的GPT（Generative Pre-trained Transformer）系列[25]都依靠大规模预训练模型在NLP任务中取得了巨大的成功。近年来，Transformer在图像分类[26-27]、目标检测[28]、语义分割[29]、目标跟踪[30]等视觉任务中显示出了巨大的潜力。随着在计算机视觉领域的不断探索和发展，从2020年开始，Transformer被广泛地引入计算机视觉领域。DETR（DEtection TRansformer）[28]使用Transformer实现目标检测的端到端过程，采用全局一步的框架，将目标检测问题转化为一个集合预测问题。它通过自注意力机制，同时对整个图像和预测目标类别、位置的集合进行建模，达到了当时最先进的性能。2021年ViT（Visual Transformer）[26]被提出，输入图像被划分为较小的补丁，然后被展平和线性嵌入以获得一系列的嵌入向量。这些嵌入向量随后被输入标准的Transformer架构中，包括多个自注意力层和前馈神经网络。随着Transformer架构在目标跟踪领域上的成功应用，一系列以ViT为基础模型的算法[31-33]被提出。经过不断地发展，基于Transformer的目标跟踪方法在目标跟踪领域取得了顶尖的性能结果。

目前，基于Transformer的目标跟踪方法数量迅速增加，迫切需要对现有研究进行整体的概括。本文重点对基于Transformer目标跟踪方法的最新研究进展进行全面概述和总结，按网络结构将基于Transformer目标跟踪方法主要分为3个大类，分别为：CNN+Transformer三段式混合结构、纯Transformer三段式结构以及纯Transformer两段式结构，并在每一类别中分别对相关方法提出的背景、解决的问题、采用的方法以及存在的不足等方面进行梳理和概述。其次，对基于Transformer目标跟踪方法在各大数据集上的结果进行统计和性能比较，分析每种类型方法性能差异化的原因，从更深层次探讨模型对跟踪结果所起到的作用。最后，对下一步的研究方向进行展望。

1　基于Transformer的目标跟踪方法

1.1　研究现状

基于Transformer架构的目标跟踪方法是为了解决基于孪生网络[34]目标跟踪方法中的相关操作问题而提出的。孪生网络通常是指2个并行的相同或者相似网络，在1990年之后，基于孪生网络的有关方法陆续应用在模板匹配、相似度量等任务。孪生网络因具有结构简单、运行效果好和速度较快等特点，很快被广泛应用在计算机视觉领域。2016年提出的SINT[35]和SiamFC[36]首次将孪生网络引入到目标跟踪中，将复杂的目标跟踪问题转化为模板与候选图像的简单匹配问题，将特征相关性与Siamese框架相结合。SiamFC一经提出，就凭借较高的跟踪精度和速度引起业界强烈的反响。

孪生网络与Transformer之间存在以下两种联系：一是孪生网络和Transformer都可以用于处理文本对或序列对的任务，如文本匹配、问答、机器翻译等；二是它们都是基于神经网络的模型，通过学习输入序列之间的关系进行任务预测。它们的区别是：

1）孪生网络通常使用CNN或循环神经网络（Recurrent Neural Network，RNN）作为基础模型，而Transformer则使用自注意力机制。

2）孪生网络一般采用共享参数的方式将两个输入序列分别通过相同的网络结构进行编码，然后再进行后续的任务处理；而Transformer则使用多头自注意力机制对输入序列进行编码。

3）Transformer在编码输入序列时，不依赖于序列的顺序，而是通过自注意力机制学习序列中不同位置的依赖关系；而孪生网络则依赖于序列的顺序信息。

3）Transformer在编码输入序列时，可以并行计算，提高了

训练和推理的速度；而孪生网络则需要串行地处理两个输入序列。

基于孪生网络的目标跟踪方法普遍忽略了两个问题：一是基于相关操作的网络没有充分利用全局上下文，易陷入局部最优；二是通过相关操作，语义信息会部分丢失，导致对目标框的预测不精准。由于Transformer中的自注意力机制可以进行全局建模并能够获得丰富的上下文信息，因此很快被应用在基于孪生网络的目标跟踪中。基于Transformer的目标跟踪方法自2021年首次提出，在此基础上改进的算法层出不穷，凭借高效的性能指标很快霸榜各大目标跟踪数据集。

1.2 基于Transformer目标跟踪方法的分类

如图1所示，基于Transformer的目标跟踪方法按照网络结构共划分为3大类。

1）CNN+Transformer三段式混合结构，代表方法有：DTT（Discriminative Tracker with Transformers）[37]、TrTr（Visual Tracking with Transformer）[38]、TransT系列（Transformer Tracking）[39-41]、TrDiMP[42]、STARK（Spatio-Temporal trAnsfoRmer for visual tracKing）[43]、E. T. Track（Exemplar Transformer Tracker）[44]、SparseTT（visual Tracking with Sparse Transformers）[45]、CSWinTT（Cyclic Shifting Window Transformer Tracker）[46]、ToMP（Transforming Model Prediction for tracking）[47]和AiATrack（Attention in Attention for transformer visual Tracking）[48]等方法。

2）纯Transformer三段式结构，代表方法有：DualTFR（Dual-branch TransFormeR）[49]、SwinTrack（Swin-Transformer Tracker）[50]和SFTransT（Spatial-Frequency Transformer Tracking）[51]等。

3）纯Transformer两段式结构，代表方法有：TATrack（online Tracker with a Target-Aware backbone）[52]、MixFormer（Mixing Features across windows and dimensions）[53]、MixViT[54]、SimTrack（Simplified Tracking architecture）[55]、OSTrack（One-Stream Tracking）[56]、ProContEXT（tracking framework with Progressive Context Encoding Transformer Tracker）[57]、VideoTrack（Video Transformer Tracking）[58]、GRM（Generalized Relation Modeling method）[59]、DropTrack[60]、SeqTrack（Sequence to Sequence Tracking）[61]、ARTrack（AutoRegressive visual Tracking）[62]等方法。

图1同时根据时间线梳理了基于Transformer的目标跟踪方法的发展过程，简要概括了每种方法所对应的创新点。根据图1中展示的发展规律可以直观看出，CNN+Transformer三段式混合结构是Transformer刚被应用在目标跟踪领域时的初始结构，目前的潮流都集中在纯Transformer两段式结构中。

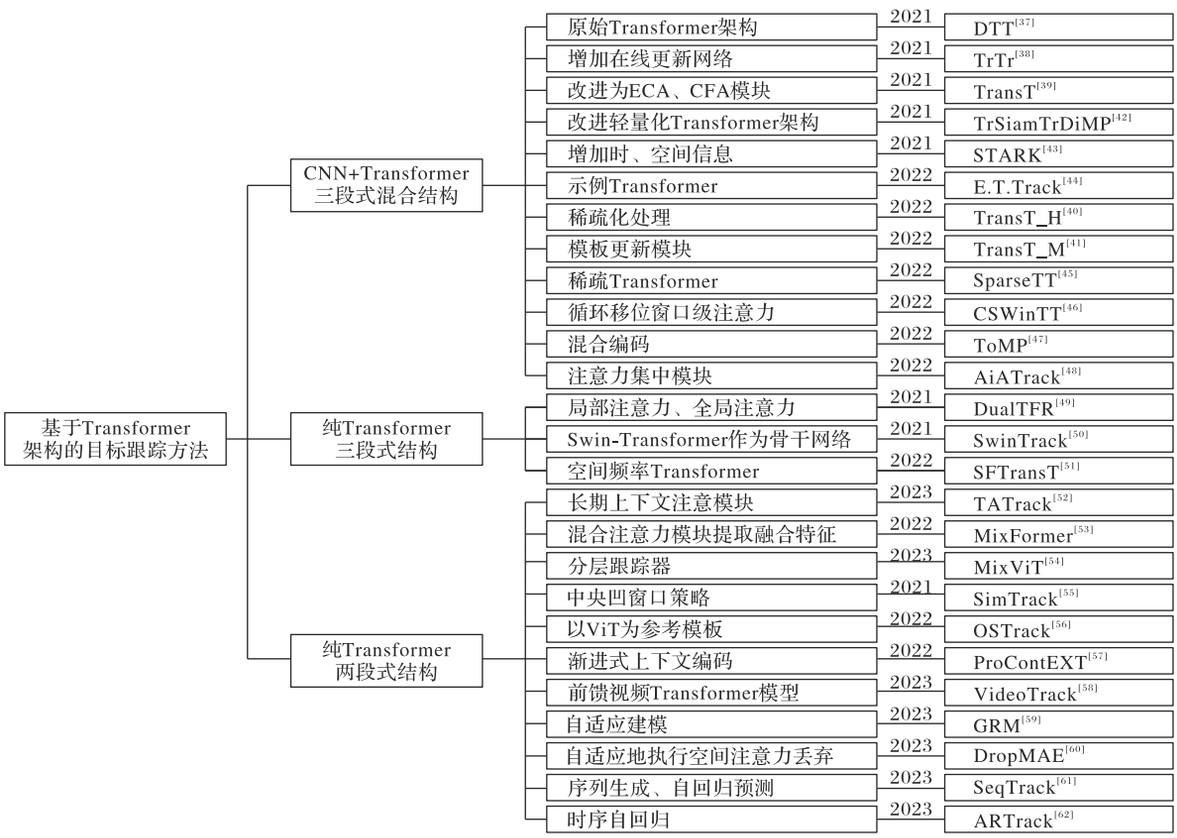


图1 基于Transformer目标跟踪方法的发展和分类

Fig. 1 Development and classification of Transformer based object tracking methods

1.2.1 CNN+Transformer三段式混合结构

如图2所示，基于CNN+Transformer三段式混合结构的目标跟踪方法主要包括3个部分：1）提取深度特征的CNN主干网络，通常使用ResNet50或ResNet101[63]；2）基于Transformer的深度特征融合模块，主要目的是融合第1）部分提取到的模板与搜索区域的深度特征；3）由分类以及回归预测头组成，起到精确定位目标位置的作用。

1）模型性能改进。

孪生网络中的相关操作是一个局部线性匹配过程,会丢失语义信息并易陷入局部最优,因此相关操作可能是高性能跟踪方法的设计瓶颈。为了突破这个瓶颈,提高目标跟踪性能,2021年卢湖川团队提出TransT方法[39]。该方法在特征融合部分增加了一个基于自注意力的自我上下文增强(Ego-Context Augment, ECA)模块和一个基于交叉注意力的交叉特征增强(Cross-Feature Augment, CFA)模块,在多个数据集实验中取得了优异的效果。Blatter等[44]在2022年提出使用示例Transformer进行有效目标跟踪的E. T. Track。E. T. Track设计了一个利用单个示例级注意力层实现实时可视化的Transformer模块,与传统的注意力模块相比,提出的示例注意力能够捕获关于目标更明确的信息,取得了不错的实验效果。由于现有基于Transformer的目标跟踪方法通过像素级提取特征,在计算注意力时会破坏目标的完整性。Song等[46]在2022年提出一个带有多尺度循环移位窗口注意力Transformer的方法CSWinTT,将注意力机制从像素级别提升至窗口级别。为了解决现有跟踪方法不能在目标模型中集成任何先验知识的问题,Mayer等[47]于2022年提出的ToMP设计了2种新的编码方式,分别嵌入了前景和背景信息,并通过实验结果验证了目标跟踪结果性能的提升。为了解决注意力机制中的独立相关性计算可能会受到外界干扰产生模糊的注意力权重的问题,Gao等[48]在2022年提出了应用于目标跟踪的注意力集中模块AiATrack,通过在所有相关向量之间寻求共识增强了适当的相关性并抑制错误的相关性。实验表明,AiATrack跟踪器在6个跟踪数据集上实现了先进的性能,同时以实时速度运行。

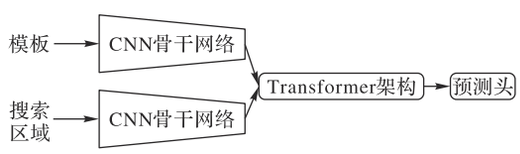


图2　CNN+Transformer三段式混合结构

Fig. 2　Three-stage hybrid structure of CNN+Transformer

2)模板更新改进。

Yu等[37]于2021年提出了一种基于Transformer的跟踪器DTT,它能够利用丰富的场景信息,在端到端学习中生成判别特征。DTT同时采用移动平均法每10帧更新一次的方式作为在线更新模板的策略,性能达到了理想的效果。为了获取视频连续帧之间丰富的时序关系,Wang等2021年将改进的Transformer集成到两个流行的跟踪框架Siamese和DiMP中,得到TrSiam和TrDiMP目标跟踪方法[42]。整个跟踪模型每5帧将当前收集到的模板特征添加到模板集T中,T中最多可以存放20个模板,一旦超过这个值就会自动删除存放时间最久的模板。Zhao等[38]提出了TrTr,包含基于Transformer的离线模型和用于分类的在线更新模型两部分。基于Transformer的离线模型通过计算模板和搜索区域图像特征间的自注意力和交叉注意力获取全局和丰富的上下文相关性,最终跟踪结果更准确稳定。由于目前大多数的目标追踪方法都仅使用了视频图像中的空间信息,忽略视频帧之间存在的时间信息,没能充分利用视频图像中的时、空间信息,导致目标追踪的效果不好。2021年卢湖川团队提出了一种基于Transformer利用时、空间信息的目标跟踪方法STARK[43],当达到更新间隔且置信度分数高于设定的阈值时模型才会更新动态模板。新的模板是从原始图像中裁剪出的,用于代替上一个动态模板。2022年卢湖川团队等在TransT的基础上又进一步提出了多模板输入的TransT-M[41],通过采用多个模板的方式记录目标的外观变化,并设计了一个在线模板更新机制应对目标的外观变化对目标跟踪的影响。TransT-M方法相较于TransT在跟踪鲁棒性和精确度上都有所提升。

3)跟踪速度改进。

TransT中Transformer的串行性导致计算量较大,跟踪速度缓慢。2022年卢湖川团队为了提高TransT的跟踪速度设计了一种基于分层交叉注意力机制的目标跟踪模型TransT_H[40],分别通过使用分层连接深化网络,使用交叉注意力机制提升效率,提出了一种特征稀疏(Feature Sparse, FS)模块,在不降低性能的情况下大幅降低了计算量。为了解决自注意力机制在搜索区域内缺乏与目标相关信息的关注,容易被背景干扰的问题,Fu等[45]在2022年提出了使用稀疏Transformer进行目标跟踪的SparseTT。SparseTT通过一个目标聚焦网络集中搜索区域中感兴趣的目标,并突出最相关信息的特征,可以更好地估计目标的状态,具有处理目标变形、局部遮挡、尺度变化的能力,能实现更精确的跟踪。

1.2.2　纯Transformer三段式结构

基于CNN+Transformer三段式混合架构的目标跟踪方法大部分都是通过CNN提取深度特征,并且拥有全局注意力特性的Transformer只在最后一层融合特征。为了让Transformer也能够作用于目标跟踪早期的特征提取阶段,提出了如图3所示的基于纯Transformer三段式结构的目标跟踪方法。它与CNN+Transformer三段式混合结构的不同在于提取模板和搜索区域深度特征时并没有采用CNN作为主干网络,而是采用了Transformer作为主干网络,其他部分都保持相似的结构。

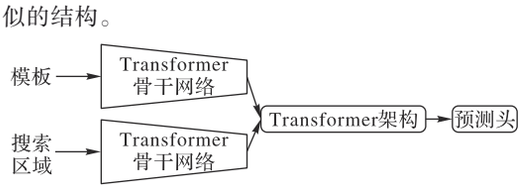


图3　纯Transformer三段式架构

Fig. 3　Three-stage architecture of pure Transformer

基于CNN+Transformer三段式混合结构的跟踪方法依赖CNN作为主干网络提取深度特征,忽略了Transformer可以模拟不同区域之间的结构依赖关系,也可以应用于特征提取环节。Xie等[49]在2021年首次提出了利用纯Transformer网络提取并融合特征的DualTFR方法,通过局部注意力模块和全局注意力模块分别提取模板图像和搜索区域图像的深度特征。与局部注意力模块不同的是,全局注意力模块计算同一图像的所有标记之间的注意力,从而可以捕获长期依赖关系。Liu等[30]在2021年提出了以Swin-Transformer作为主干网络提取深度特征的SwinTrack[50],与ResNet[63]相比,Swin-Transformer可以提供更紧凑的特征表示和更丰富的语义信息,以帮助后续网络更好地定位目标对象。Tang等[51]在

2022年提出一种学习空间频率的Transformer进行视觉目标跟踪的方法SFTransT。SFTransT同时对高斯空间先验和高频强调注意力进行建模，采用基于跨尺度融合的Swin Transformer作为主干网络，并使用多头交叉注意力模块增强搜索和模板特征之间的交互关系。

1.2.3 纯Transformer两段式结构

基于Transformer的目标跟踪方法基本上都是采用“三段式”的结构：首先使用CNN或者Transformer主干网络进行特征提取；其次通过Transformer中的注意力机制进行特征层面的融合；最后通过预测头预测目标的类型和位置。这种“三段式”结构方法存在处理过程复杂、需要迭代计算且参数量巨大等不足，性能虽好但是效率较低。为了解决上述问题，基于纯Transformer两段式架构的目标跟踪方法被提出，如图4所示。



图4 纯Transformer两段式架构

Fig. 4 Two-stage architecture of pure Transformer

由于之前基于Transformer的目标跟踪方法将特征提取和特征融合分为2个阶段，导致特征提取过程无法感知目标。特征提取网络通常是由分类网络在离线预训练得出的，与目标跟踪中的任意性违背，导致网络前景和背景判别能力有限，与此同时跟踪中的性能与效率之间的矛盾越来越大。为解决这类问题，Chen等[53]在2022年首次提出纯Transformer两段式的目标跟踪MixFormer，并在2023年对模型进行改进，实例化了2种类型的混合跟踪器：分层跟踪器MixCvT和非分层跟踪器MixViT[54]。整个网络框架一部分是模板和搜索图像经过基于混合注意力模块（Mixed Attention Module，MAM）的主干网络进行特征提取和融合，另一部分是通过预测头输出结果，整体结构更加紧凑简洁。为解决现有跟踪方法需要先验知识进行架构选择的问题，Chen等[55]在2022年提出了一种简化的跟踪架构SimTrack，为了减少视觉Transformer（Vision Transformer，ViT）中降采样造成的信息损失，进一步提出了一种中央凹窗口（Foveal Window，FW）策略，这有助于Transformer主干网络在重要的样本图像区域捕获更多的细节。Ye等[56]借鉴ViT模型结构在2022年提出了简洁高效的单流单阶段跟踪框架OSTrack，利用早期获得的相似度得分先验，提出了一种网络内早期候选估计提出模块，减少了推理时间。OSTrack在原始图像对阶段就进行信息交互，提取了面向目标的特征，避免判别信息的丢失。为了解释连续帧之间目标外观的变化，Lan等[57]2022年使用渐进式上下文编码Transformer跟踪器ProContEXT改进了跟踪框架，该跟踪器连贯地利用空间和时间上下文预测目标运动轨迹，利用上下文感知自我注意力模块编码空间和时间上下文，细化和更新多尺度静态和动态模板，以逐步执行精确跟踪。为了提升目标跟踪的效率和工业部署，Xie等[58]2023年首次提出VideoTrack，它通过一个简洁的前馈视频Transformer模型将时间上下文编码为空间特征，将2维成对匹配问题提升到连续视频帧的时空领域，使视频Transformer应用于视觉跟踪。为了使跟踪器能够应对目标外观变化、快速运动以及相似目标干扰的情况，He等[52]通过在Transformer中嵌入一个长期上下文注意（Long-term Context Attention，LCA）模块，构建了一个带有目标自注意主干网络的强大在线跟踪器，称为TATrack。TATrack采用了一个基于交替叠加的LCA和转移窗口注意（Shift Window Attention，SWA）模块的目标感知主干网络。此外，TATrack还提出了一种基于历史信息分类置信度的动态在线更新算法，无需增加计算负担。由于现有的在线跟踪器总是让模板在所有编码器层中与搜索区域内的所有部分进行交互，当提取的特征表示没有足够的区别时，可能导致目标背景混淆。针对该问题，Gao等[59]2023年提出了一种基于自适应标记划分的广义关系建模方法。该方法利用基于注意力关系建模的广义公式用于Transformer目标跟踪，它通过选择合适的搜索区域的向量与模板向量交互，实现了更灵活的关系建模。为了解决基于掩码自动编码器（Masked AutoEncoder，MAE）的目标跟踪严重依赖空间线索，而忽略了帧重建时间关系的问题，Wu等[60]2023年在DropTrack提出了DropMAE，在帧重构中自适应地执行空间注意力丢弃操作，以促进视频中的时间对应关系学习。Chen等[61]2023年提出了一种新的序列到序列学习框架的视觉跟踪，称为SeqTrack。它将视觉跟踪转换为一个序列生成问题，以自回归的方式预测目标的边界框。SeqTrack只采用了一个简单的编、解码器Transformer架构，编码器使用双向Transformer提取目标特征，而解码器使用因果Transformer自动回归生成一系列边界框值。Wei等[62]2023年提出一个视觉目标跟踪的自回归框架ARTrack，将跟踪问题视为一个坐标序列解释任务，逐步估计物体的轨迹，其中当前的估计受到先前状态的影响，并进而影响到子序列。这种时序自回归方法对轨迹的顺序演化建模，以在帧之间持续跟踪目标。ARTrack由于消除了定制的定位头和后处理步骤，结构简单，在当前主流公开数据集上取得了最先进的性能。

1.3 Transformer相对于CNN的优势

与CNN相比，Transformer在以下方面具有明显优势：

1）更少的先验偏置。由于CNN大多数模型使用监督性学习，但是基于CNN的目标跟踪方法对海量数据的适配能力并不突出，随着数据的增加会趋于稳定。而基于Transformer的目标跟踪方法对大数据的适配能力更强，通过实验可以发现随着数据量的增加，模型的表现会越来越好。

2）参数动态性。CNN在学习参数的过程中，大多数的参数是静态参数，在学习完之后就固定不动了，而Transformer中的每个参数都是动态的，具有更强的可学习性。

3）联系上下文和全局建模能力。CNN存在局部感受野较局限的问题，为了获得全局信息，需要多层堆叠，但是随着层数增加，CNN获取的信息量会减少，导致提取的特征注意力集中在某些区域。Transformer拥有自注意力机制，更关注特征之间的相互关系，能有效获得全局信息，并且通过多头注意力机制可以将它映射到多个空间，使模型表达能力变强。

4）多模态融合能力。Transformer可以通过线性映射对输入的图像进行初始编码，然后反馈传输到Transformer中，而不需要像CNN一样，始终保持$H \times W \times C$的特征图结构。

数据只要信息能够编码,都可以被Transformer轻松利用。

5)多任务能力。因为Transformer中的注意力机制可以对不同的任务进行不同的学习,一般简单的用法就是在编码时加一个任务编号,因此一个Transformer可以执行很多任务。

1.4　基于Transformer的目标跟踪方法分析

随着基于注意力机制的Transformer在计算机视觉领域的大量应用,基于Transformer的目标跟踪方法被大量提出,并在不断地改进中取得非常亮眼的跟踪效果。

基于CNN+Transformer三段式混合结构的目标跟踪方法的优点是:由于Transformer具有更少的先验偏置和更强的可学习性,当训练数据越多时,性能提升越明显。利用Transformer中的编、解码器进行特征融合时,能够充分利用上下文信息,获取全局的有效信息,跟踪精度和成功率相比孪生网络跟踪器明显提高。不足之处是:CNN提取深度特征缺乏全局建模能力,方法模型复杂,需要用大量数据集进行训练。

基于纯Transformer三段式结构的目标跟踪方法的优点是:通过使用Transformer作为主干网络提取特征,充分利用Transformer全局建模能力,相较于CNN能够提取到更强表达能力的深度特征,与基于CNN+Transformer三段式混合结构的目标跟踪方法相比,跟踪效果提升明显。不足之处是:方法模型较为复杂,计算和参数量巨大,需要用大量数据集进行训练。

基于纯Transformer两段式结构的目标跟踪方法的优点是:通过一个模块联合特征提取和特征融合,使特征提取在提取过程能够感知目标,使提取到的特征包含更多目标信息,能提升跟踪器对前景和背景的判别能力。与此同时还能解决跟踪中性能与效率之间的矛盾,通过简化模型结构,降低计算和参数量,跟踪器整体更加高效。

2　实验数据分析

如表1所示,本文将基于Transformer的目标跟踪方法在常用的LaSOT[64]、TrackingNet[65]、GOT-10k[66]、OTB2015[67]、NFS[68]、UAV123[69]以及VOT2020[70]数据集上进行性能、速度以及参数量等方面的比较,以便对算法进行分析。

在OTB、NFS、UAV123、LaSOT和TrackingNet等数据集中,常用的方法评价指标主要包括两种:一种是在特定阈值(一般设为20像素)情况下,用于度量预测框与真值框中心点之间欧氏距离的目标中心定位精度(Precision, P),当计算的精度小于20像素时,判定为跟踪正确。另一种是计算预测框与真值框之间的重叠度,与特定阈值进行比较,从而算出跟踪的成功率。根据不同的阈值,可以绘制出不同的成功率曲线,并通过计算曲线下面积(Area Under Curve, AUC)作为评估结果。

VOT竞赛数据集的评价指标包括鲁棒性(Robustness, Rob)、精度(Accuracy, Acc)以及综合指标期望平均重叠度(Expected Average Overlap, EAO)。与其他数据集评估方法有所不同,在VOT竞赛数据集中跟踪失败时,会重新将跟踪器复位到正确的位置,记录重新初始化的次数并作为评估方法鲁棒性(Rob)的依据。VOT竞赛数据集中的精度(Acc)是指跟踪器的预测框与真值框之间的重合度,反映预测框与真值框之间的定位误差。EAO是跟踪方法鲁棒性和精度的整合,反映跟踪器的综合性能。

GOT-10k的评价指标包括平均重叠度(Average Overlap, AO)和平均成功率($SR_{0.5}$、$SR_{0.75}$)。其中:AO指目标的真值框和预测框之间重叠的平均值;SR是计算重叠度超过阈值(例如0.5、0.75)的成功跟踪帧所占的百分比。AO与其他常规数据集中的AUC效果等价,也与VOT竞赛中的EAO相近似。

FPS/Params:目标跟踪方法的跟踪速度通常由速度性能评价指标FPS(Frame Per Second)表示,表示跟踪器每秒跟踪视频中的图片帧数,FPS越大表示跟踪方法的跟踪速度越快,跟踪速度性能越好。参数量(Parameters,Params)用于评价目标跟踪方法中网络与模型的复杂度,是网络与模型中各个权值参数总量,由于参数量较大,单位为MB。

2.1　基于Transformer+CNN三段式混合架构的目标跟踪方法

表1的第一部分展示的是基于Transformer+CNN三段式混合架构的目标跟踪方法在常用数据集上的评估结果以及方法跟踪速度的汇总比较。ToMP通过设计2种新的编码方式,充分利用深度特征与前景和背景信息,实验结果显示ToMP-101的跟踪成功率比ToMP-50在LaSOT、TrackingNet、OTB2015数据集上分别提高0.9、0.3和0个百分点,整体跟踪性能表现优秀。AiATrack提出了应用于目标跟踪的注意力集中模块,跟踪结果在基于Transformer+CNN三段式混合架构的目标跟踪方法中处于领先的地位,在LaSOT和TrackingNet数据集上的跟踪成功率分别比ToMP-101高0.5和1.2个百分点,但是在OTB2015上比ToMP-101低0.5个百分点,FPS指标为38,能够达到实时跟踪的要求。

2.2　基于纯Transformer三段式架构的目标跟踪方法

表1的第二部分展示的是基于纯Transformer三段式架构的目标跟踪方法在常用数据集上的评估结果以及方法跟踪速度的汇总比较。受Swin-Transformer启发,SwinTrack以Swin-Transformer作为主干网络提取深度特征,SwinTrack-B-384指搜索区域图像的尺寸为384×384。实验结果显示,与SwinTrack-B相比,SwinTrack-B-384在LaSOT和TrackingNet数据集上的跟踪成功率分别提高了0.6和1.5个百分点,FPS减少了7.2,达到45。与SwinTrack-B-384相比,SFTransT在LaSOT和TrackingNet数据集上的跟踪成功率分别低了1.2和1.1个百分点,跟踪速度FPS降到27.3,但是参数量降低了71.69 MB,仅为29.61 MB。

2.3　基于纯Transformer两段式架构的目标跟踪方法

表1的第三部分展示的是基于纯Transformer两段式架构的目标跟踪方法在常用数据集上的评估结果以及方法跟踪速度的汇总比较。MixFormer和MixFormer-L分别指主干网络由CVT-21(Convolutions to Vision Transformers)和CVT24-W进行初始化,而CVT-21和CVT24-W主干网络的区别比较大:在第一阶段作用时,CVT-21由1个多头注意力模块组成且维数是64,而CVT24-W由3个多头注意力模块组成且维数是192;在第二阶段作用时,CVT-21由3个多头注意力模块组成且维数是192,而CVT24-W由12个多头注意力模块组成且维数是768;在第三阶段作用时,CVT-21由6个多头注意力模块组成且维数是384,而CVT24-W由16个多头

注意力模块组成且维数是1 024。实验结果显示，MixFormer-L的参数量是MixFormer的近4倍，与ProContEXT性能和跟踪速度相当的情况下，MixFormer-L的参数量是ProContEXT的近2倍。2023年通过分层处理的方式提出的MixViT-L（ConvMAE）在LaSOT和TrackingNet上的跟踪成功率比MixFormer-L分别提高了3.2和2.2个百分点，跟踪速度FPS仅下降了15，提升效果明显。SeqTrack根据编码器使用ViT-B与ViT-L以及输入的尺寸256×256与384×384的不同，分成了4个版本。ARTrack与它类似，主干网络选择ViT-B与ViT-L以及搜索区域选择256×256与384×384分成3个版本。从实验结果可以看出，ARTrack-L_{384}比SeqTrack-L384在LaSOT、TrackingNet、GOT-10k中的跟踪成功率分别高出0.6、0.1和3.7个百分点，同时FPS增加了21。综上可知，MixViT-L（ConvMAE）是目前性能最高的算法。目前，基于两阶段纯Transformer的目标跟踪方法展现出非常大的跟踪性能优势，同时还具有非常快的跟踪速度，是未来研究和发展的方向。

表1 基于Transformer的目标跟踪方法在常用数据集中的结果对比

Tab. 1 Comparison of results of Transformer based object tracking methods in common datasets

方法	出处	LaSOT		TrackingNet		GOT-10k			OTB2015	NFS	UAV123	VOT2020			FPS	Params/MB
		AUC/%	P/%	AUC/%	P/%	AO	$SR_{0.5}$	$SR_{0.75}$	AUC/%	AUC/%	AUC/%	EAO	Acc/%	Rob		
DTT[37]	ICCV21	53.8		74	68.8	63.4	74.9	51.4		60.8					54.5	
TrTr-offline[38]	CVPR21	46.3		69.3					69.1	55.2	59.4				50	33.9
TrTr-online[38]		55.1		71					71.5	63.1	65.2				35.3	21
TransT[39]	ICCV21	64.9	69	81.4	80.3	72.3	82.4	68.2	69.4	65.7	69.1				50	35.5
TrSiam[42]	ICCV21	62.4	60	78.1	72.7	67.3	78.7	58.6	70.8	65.8	67.4				35.6	52
TrDiMP[42]		63.9	61.4	78.4	73.1	68.8	80.5	59.7	71.1	66.5	67.5				26.3	55.2
STARK-ST50[43]	ICCV21	66.6	70.8	81.3		68.0	77.7	62.3		66.2	68.2	0.308	0.478	0.799	41.8	23.5
STARK-ST101[43]		67.1	77.0	82.0		68.8	78.1	64.1				0.303	0.481	0.775	31.7	42.4
E. T. Track[44]	CVPR22	59.1		75.0	70.6				67.8	59.0	62.3	0.267	0.432	0.741	47.2	
HCAT[40]	CVPR22	59.1	60.7	76.6	72.9	65.3	76.8	57	68.1	63.6	63.6	0.276	0.455	0.747	195	
TransT_H[40]		66.2	70.7	82.2	80.4	72.4	82.0	68.5								
TransT-M[41]	CVPR22	65.4	69.6	82.5	80.0	74.7	85.5	71.3	68.9	66.2	70.9	0.550	0.742	0.869	42.7	23.1
SparseTT[45]	IJCAI22	66.0	70.1	81.7	79.5	69.3	79.1	63.8	70.4		70.4				40.1	58.3
CSWinTT[46]	ICCV22	66.2	70.9	81.9	79.5	69.4	78.9	65.4			70.5	0.304	0.480	0.787	12	
ToMP-50[47]	CVPR22	67.6	72.2	81.2	78.6				70.1	66.9	69	0.297	0.453	0.789		
ToMP-101[47]		68.5	73.5	81.5	78.9				70.1	66.7	66.9	0.309	0.453	0.814		
AiATrack[48]	ECCV22	69.0	73.8	82.7	80.4	69.6	80.0	63.2	69.6	67.9	70.6	0.530	0.764	0.827	38	23.6
DualTFR[49]	ICCV21	63.5	66.5	80.1		73.5	84.8	69.9			68.2	0.528	0.755	0.836		44.1
SwinTrack-B[50]	CVPR21	69.6	74.1	82.5	80.4	69.4	78	64.3							52.2	91.4
SwinTrack-B-384[50]		70.2	75.3	84.0	83.2										45	101.3
SFTransT[51]	CoRR22	69.0	73.9	82.9	81.3	72.7	84.3	66.9	70.3	66.0	71.3				27.3	29.61
Sim-L/14[55]	ECCV21	70.5	76.2	83.4	87.4	69.8	78.8	66.0			71.2					103.1
OSTrack-256[56]	ECCV22	69.1	75.2	83.1	82.0	71.0	80.4	68.2		64.7	66.5				105.4	
OSTrack-384[56]		71.1	77.6	83.9	83.2	73.7	83.2	70.8		68.3	70.7				58.1	
ProContEXT[57]	CoRR22			84.6	83.8	74.6	84.7	72.9							26.4	118.5
VideoTrack[58]	CVPR23	70.2	76.4	83.8	83.1	72.9	81.9	69.8			69.7				81.4	
TATrack-L[52]	IAAI23	71.1	76.1	85.0	84.5	79.2	88.6	78.3							6.6	112.8
GRM[59]	CVPR23	69.9	75.8	84.0	83.3	73.4	82.9	70.4		65.6	70.2				45	
GRM-L320[59]		71.4	77.9	84.4	84.0											
DropTrack[60]	CVPR23	71.8	78.1	84.1	83.0	75.9	86.8	72.0	69.6							
MixFormer[53]	CVPR22	67.9	73.9	82.6	81.2	73.2	83.2	70.2			68.7	0.527	0.746	0.833	29	53.3
MixFormer-L[53]		70.1	76.3	83.9	83.1	75.6	85.7	72.8			69.5	0.555	0.762	0.855	25	215.7
MixViT-L (ConvMAE)[54]	CVPR23	73.3	80.3	86.1	86.0	75.4	84.0	75.4	70.7		70.0	0.567	0.747	0.870	10	286.9
SeqTrack-B256[61]	CVPR23	69.9	76.3	83.3	82.2	74.7	84.7	71.8		67.6	69.2	0.520			40	89
SeqTrack-B384[61]		71.5	77.8	83.9	83.6	74.5	84.3	71.4		66.7	68.6	0.522			15	89
SeqTrack-L256[61]		72.1	79.0	85.0	84.9	74.5	83.2	72.0		66.9	69.7	0.555			15	309
SeqTrack-L384[61]		72.5	79.3	85.5	85.8	74.8	81.9	72.2		66.2	68.5	0.561			5	309
$ARTrack_{256}$[62]	CVPR23	70.4	76.6	84.2	83.5	73.5	82.2	70.9		64.3	67.7					
$ARTrack_{384}$[62]		72.6	79.1	85.1	84.8	75.5	84.3	74.3		66.8	70.5					
ARTrack-L_{384}[62]		73.1	80.3	85.6	86.0	78.5	87.4	77.8		67.9	71.2				26	

3 总结与展望

本文将基于Transformer目标跟踪方法按网络结构主要分为CNN+Transformer三段式混合结构、纯Transformer三段式结构以及纯Transformer两段式结构3大类，并对每一类方法的发展脉络进行梳理，在每一类别中分别对相关方法被提出的背景、要解决的问题、所采用的方法以及尚存在的不足等方面进行总结，分析了Transformer相较于CNN所具有的

优势以及每一类别的优缺点。此外，对基于Transformer目标跟踪方法在各类数据集上的结果进行统计和性能分析。虽然Transformer在计算机视觉目标跟踪领域上展现了先进的性能，但也面临网络结构复杂、参数量巨大、训练要求高、移动端使用难度大等不足，可以考虑与模型压缩、自监督学习以及Transformer可解释性分析等技术结合，与其他领域的技术相互促进、共同发展。以下是对基于Transformer目标跟踪方法的3点展望。

1）由于Transformer本质上不对先验知识进行编码处理，它们通常在训练前需要大量的训练数据找出潜在的特定规则。例如，由于池化操作或多尺度处理等模块的存在，CNN具有内置的平移不变性、权重共享和部分尺度不变性。然而，一个Transformer网络需要通过大量训练示例找出图像中特定的属性；类似地，视频帧之间的关系需要Transformer网络通过自注意机制查看一个大型视频序列数据库自动发现。这导致训练时间和计算量大幅增加。例如，SwinTrack[50]模型需要数亿个图像示例才能在ImageNet数据集[71]上获得良好的性能。凭借数据以高效的方式学习Transformer网络将是未来研究的一个热点问题。目前，大规模的Transformer网络在目标跟踪方法中训练时具有较高的功率和计算需求，阻碍了它在边缘设备或资源有限环境中的部署，大多数基于Transformer的目标跟踪方法模型计算成本很高，需要大量计算资源。未来的一个研究方向是应用CNN中的模型压缩技术对Transformer深度特征的提取和融合等过程进行压缩，降低资源成本。例如微软亚洲研究院提出集成了大量前沿剪枝算法的高精度压缩Transformer模型NNI（Neural Network Intelligence）[72]，既能降低模型参数量和计算量，又能保持模型较高精度，获得了较好的模型剪枝效果。随后，微软研究院提出了基于Transformer预训练模型的通用压缩方法深度自注意力知识蒸馏（Compressing Deep Self-Attention via Knowledge Distillation，MiniLM）[73]，谷歌提出了Evolved Transformer[74]，韩松研究团队提出了利用长短距离注意力结构的Lite Transformer[75]等模型压缩方法。通过压缩和加速嵌入式系统上的Transformer模型结构，使模型更易部署在一些如智能手机、监控系统等实时移动端设备中。

2）自监督学习的方式可以在无标注数据上对模型进行表征学习，基于Transformer的自监督学习可以解决模型对数据的依赖性，从而有望实现更强大的性能。自监督Transformer预训练已经使自然语言处理领域标准化，并在各种应用中取得了巨大的成功。卷积孪生网络作为计算机视觉中的自监督范式，2021年Caron等[76]采用对比学习进行自监督预训练，除了将自监督的方法应用于Transformer效果特别好之外，还有2个优点：一是自监督的ViT特征包含关于图像语义分割的明确信息；二是这些特征也是优秀的k最近邻（k-Nearest Neighbors，k-NN）分类器，算法在ImageNet上的精度指标达到78.3%，位居第一。研究还强调了动量编码器、多目标训练以及使用小补丁与ViT结合的重要性。DINO（DETR with Improved deNoising anchOr boxes）[76]使用图像的不同视角或裁剪等数据增强方法构建训练样本对，并设计了一种新颖的对比损失函数鼓励模型学习出更具判别性的特征表示。DINO对ViT进行了改进和调整，以适应自监督训练，同时保持了Transformer在图像领域的优势。2021年Zhen等提出以ViT作为主干架构的自监督学习算法MoBY（MoCo v2 and BYOL）[77]，性能优于DINO。2021年Atito等[78]提出了一种使用未标注的数据进行训练的自监督视觉Transformer模型（Self-supervised Vision Transformer，SiT），将预训练模型用作初始化以进行下游任务的微调，性能优秀。基于自监督学习的Transformer模型具有利用未标注数据、迁移学习、模型鲁棒性高和能保护数据隐私等优点，成为一种强大的学习范式，在计算机视觉和自然语言处理等领域初步取得了成果，因此用于自监督学习的Transformer值得进一步研究。

3）由于Transformer具有强大的性能，因此如何解释它们进行决策是非常关键的，能够提高该类方法在精密机器上使用的可靠性。当给定分类决策可视化图像中的相关区域时。面临的主要挑战是当计算每一层注意力时，注意力都会在随后的一层中以复杂的方式混合，这导致无法准确计算输入编码向量对最终预测结果的相对贡献量。最近的一些研究者聚焦于Transformer的可解释性，并取得了不错的结果。Chefer等[79]为了可视化Transformer的图像部分，提出了一种计算Transformer网络相关性的方法。该方法基于深度泰勒分解原理分配局部相关性，然后通过注意力层传播相关性分数。这种传播涉及注意力层和残差连接，为现有方法提出了新的方向。目前的研究热点是将之前应用在CNN中的成熟可解释性方法应用在视觉Transformer领域，提出基于梯度的、基于特征的（Grad-CAM（Gradient-weighted Class Activation Mapping）[80]、ViT-CX（Vision Transformer for Image Classification with Extra Large Training Set）[81]）和基于扰动的（Value Zeroing[82]）等视觉Transformer可解释性方法，这些借助CNN的可解释性方法对Transformer展开可解释性研究都取得了丰硕的成果，这也将是未来一项研究重点。

参考文献（References）

[1] 黄凯奇，陈晓棠，康运锋，等. 智能视频监控技术综述[J]. 计算机学报，2015，38(6)：1093-1118.（HUANG K Q，CHEN X T，KANG Y F，et al. Intelligent visual surveillance：a review[J]. Chinese Journal of Computers，2015，38(6)：1093-1118.）

[2] 钱夔，宋爱国. 一种改进型机器人仿生认知神经网络[J]. 电子学报，2015，43(6)：1084-1089.（QIAN K，SONG A G. An improved bionic cognitive neural network for robot[J]. Acta Electronica Sinica，2015，43(6)：1084-1089.）

[3] 刘彩虹，张磊，黄华. 交通路口监控视频跨视域多目标跟踪的可视化[J]. 计算机学报，2018，41(1)：221-235.（LIU C H，ZHANG L，HUANG H. Visualization of cross-view multi-object tracking for surveillance videos in crossroad[J]. Chinese Journal of Computers，2018，41(1)：221-235.）

[4] 梁永强，王崴，瞿珏，等. 基于眼动特征的人机交互行为意图预测模型[J]. 电子学报，2018，46(12)：2993-3001.（LIANG Y Q，WANG W，QU Y，et al. Human-computer interaction behavior and intention prediction model based on eye movement characteristics[J]. Acta Electronica Sinica，2018，46(12)：2993-3001.）

[5] 葛宝义，左宪章，胡永江. 视觉目标跟踪方法研究综述[J]. 中国图象图形学报，2018，23(8)：1091-1107.（GE B Y，ZUO X Z，HU Y J. Review of visual object tracking technology[J]. Journal of Image and Graphics，2018，23(8)：1091-1107.）

[6] 孟琭，杨旭. 目标跟踪算法综述[J]. 自动化学报，2019，45(7)：1244-1260.（MENG L，YANG X. A survey of object tracking algorithms[J]. Acta Automatica Sinica，2019，45(7)：1244-1260.）

[7] AVIDAN S. Support vector tracking[J]. IEEE Transactions on

Pattern Analysis and Machine Intelligence, 2004, 26(8): 1064-1072.

[8] NING J, YANG J, JIANG S, et al. Object tracking via dual linear structured SVM and explicit feature map[C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016 :4266-4274.

[9] ZHANG T, GHANEM B, LIU S, et al. Robust visual tracking via multi task sparse learning [C]// Proceedings of the 2012 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2012: 2042-2049.

[10] BABENKO B, YANG M-H, BELONGIE S. Visual tracking with online multiple instance learning[C]// Proceedings of the 2009 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2009: 983-990.

[11] BOLME D S, BEVERIDGE J R, DRAPER B A, et al. Visual object tracking using adaptive correlation filters[C]// Proceeding of the 2010 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2010: 2544-2550.

[12] HENRIQUES J F, CASEIRO R, MARTINS P, et al. Exploiting the circulant structure of tracking-by-detection with kernels[C]// Proceedings of the 12th European Conference on Computer Vision. Berlin: Springer, 2012: 702-715.

[13] HENRIQUES J F, CASEIRO R, MARTINS P, et al. High-speed tracking with kernelized correlation filters[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(3): 583-596.

[14] DANELLJAN M HÄGER G, KHAN F, et al. Accurate scale estimation for robust visual tracking [C]// Proceedings of the British Machine Vision Conference 2014. Durham: British Machine Vision Association, 2014: 1-11.

[15] LI Y, ZHU J. A scale adaptive kernel correlation filter tracker with feature integration[C]// Proceedings of the 2014 European Conference on Computer Vision Workshops. Cham: Springer, 2015: 254-265.

[16] LUKEŽIČ A, VOJÍŘ T, ČEHOVIN ZAJC L, et al. Discriminative correlation filter tracker with channel and spatial reliability[J]. International Journal of Computer Vision, 2018, 126: 671-688.

[17] DANELLJAN M, HÄGER G, KHAN F S, et al. Convolutional features for correlation filter based visual tracking [C]// Proceedings of the 2015 IEEE International Conference on Computer Vision Workshop. Piscataway: IEEE,2015:621-629.

[18] MA C, HUANG J-B, YANG X, et al. Hierarchical convolutional features for visual tracking[C]// Proceedings of the 2015 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2015: 3074-3082.

[19] GALOOGAHI H K, FAGG A, LUCEY S. Learning background-sware correlation filters for visual tracking[C]// Proceedings of the 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE,2017:1144-1152.

[20] DANELLJAN M, ROBINSON A, KHAN F S, et al. Beyond correlation filters: learning continuous convolution operators for visual tracking[C]// Proceedings of the 14th European Conference on Computer Vision. Cham: Springer, 2016: 472-488.

[21] DANELLJAN M, BHAT G, FAHAD S K, et al. ECO: efficient convolution operators for tracking[C]// Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE,2017: 6931-6939.

[22] BHAT G, JOHNANDER J, DANELLJAN M, et al. Unveiling the power of deep tracking[C]// Proceedings of the 15th European Conference on Computer Vision. Piscataway: IEEE, 2018: 493-509.

[23] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]// Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc., 2017: 6000-6010.

[24] DEVLIN J, CHANG M-W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding[C]// Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Stroudsberg: ACL, 2019: 4171-4186.

[25] TONG C, PENG H, DAI Q, et al. Improving natural language understanding by reverse mapping Bytepair encoding [C]// Proceedings of the 23rd Conference on Computational Natural Language Learning. Stroudsberg: ACL, 2019:163-173.

[26] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16×16 words: Transformers for image recognition at scale [C/OL]// Proceedings of the 9th International Conference on Learning Representations. [S. l.]: ICLR, 2020 [2023-05-30]. https://arxiv. org/2010. 11929. pdf.

[27] CHEN C-F R, FAN Q, PANADA R. CrossViT: cross-attention multi-scale vision transformer for image classification [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 347-356.

[28] CARION N, MASSA F, G SYNNAEVE, et al. End-to-end object detection with Transformers[C]// Proceeding of the 16th European Conference on Computer Vision. Cham: Springer, 2020:213-229.

[29] STRUDEL R, GARCIA R, LAPTEV I, et al. Segmenter: Transformer for semantic segmentation[C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021:7242-7252.

[30] LIU Z, LIN Y, CAO Y, et al. Swin Transformer: hierarchical vision Transformer using shifted windows[C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021:9992-10002.

[31] TOUVRON H, CORD M, DOUZE M, et al. Training data-efficient image Transformers & distillation through attention[C]// Proceedings of the 38th International Conference on Machine Learning. New York: PMLR, 2021:10347-10357.

[32] ZHOU D, KANG B, JIN X, et al. DeepViT: towards deeper vision Transformer[EB/OL]. [2023-05-30]. https://arxiv. org/pdf/2103. 11886v4. pdf.

[33] LI Y, ZHANG K, CAO J, et al. LocalViT: bringing locality to vision Transformers[EB/OL]. [2023-05-30]. https://arxiv. org/pdf//2103. 11886/2104. 05707. pdf.

[34] CHOPRA S, HADSELL R, LeCUN Y. Learning a similarity metric discriminatively, with application to face verification[C]// Proceedings of the 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2005:539-546.

[35] TAO R, GAVVES E, SMEULDERS A W M. Siamese instance search for tracking[C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 1420-1429.

[36] BERTINETTO L, VALMADRE J, HENRIQUES J F, et al. Fully-convolutional siamese networks for object tracking [C]// Proceeding of the 14th European Conference on Computer Vision. Cham: Springer, 2016: 850-865.

[37] YU B, TANG M, ZHENG L, et al. High-performance discriminative tracking with Transformers[C]// Proceedings of the

2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 9836-9845.

[38] ZHAO M, OKADA K, INABA M. TrTr: visual tracking with Transformer [EB/OL]. [2023-05-30]. https://arxiv. org/pdf/2105. 03817. pdf.

[39] CHEN X, YAN B, ZHU J, et al. Transformer tracking [C]// Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 8122-8131.

[40] CHEN X, KANG B, WANG D, et al. Efficient visual tracking via hierarchical cross-attention Transformer [C]// Proceedings of the 17th European Conference on Computer Vision. Cham: Springer 2022: 461-477.

[41] CHEN X, YAN B, ZHU J, et al. High-performance Transformer tracking [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(7): 8507-8523.

[42] WANG N, ZHOU W, WANG J, et al. Transformer meets tracker: exploiting temporal context for robust visual tracking [C]// Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2021: 1571-1580.

[43] YAN B, PENG H, FU J, et al. Learning spatio-temporal Transformer for visual tracking [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 10428-10437.

[44] BLATTER P, KANAKIS M, DANELLJAN M, et al. Efficient visual tracking with exemplar Transformers [C]// Proceedings of the 2023 IEEE/CVF Winter Conference on Applications of Computer Vision. Piscataway: IEEE, 2023: 1571-1581.

[45] FU Z, FU Z, LIU Q, et al. SparseTT: visual tracking with sparse Transformers [C]// Proceedings of 31st the International Joint Conference on Artificial Intelligence. California: IJCAI, 2022: 905-912.

[46] SONG Z, YU J, CHEN Y-P, et al. Transformer tracking with cyclic shifting window attention [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022:8781-8790.

[47] MAYER C, DANELLJAN M, BHAT G , et al. Transforming model prediction for tracking [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 8721-8730.

[48] GAO S, ZHOU C, MA C, et al. AiATrack: attention in attention for Transformer visual tracking [C]// Proceedings of the 17th European Conference on Computer Vision. Cham: Springer, 2022:146-164.

[49] XIE F, WANG C, WANG G, et al. Learning tracking representations via dual-branch fully Transformer networks [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision Workshops. Piscataway: IEEE, 2021: 2688-2697.

[50] LIN L, FAN H, XU Y, et al. SwinTrack: a simple and strong baseline for Transformer tracking [EB/OL]. [2023-05-30]. https://arxiv. org/pdf/2112. 00995. pdf.

[51] TANG C, WANG X, BAI Y, et al. Learning spatial-frequency Transformer for visual object tracking [EB/OL]. [2023-05-30]. https://arxiv. org/pdf/2208. 08829v1. pdf.

[52] HE K, ZHANG C, XIE S, et al. Target-aware tracking with long-term context attention [C]// Proceedings of the Thirty-Seventh AAAI Conference on Artificial Intelligence and Thirty-Fifth Conference on Innovative Applications of Artificial Intelligence and Thirteenth Symposium on Educational Advances in Artificial Intelligence. Palo Alto: AAAI Press, 2023: 773-780.

[53] CHEN Q, WU Q, WANG J, et al. MixFormer: mixing features across windows and dimensions [C]// Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2022: 5239-5249.

[54] CUI T, JIANG C, WU G, et al. MixFormer: end-to-end tracking with iterative mixed attention [EB/OL]. [2023-05-30]. https://arxiv. org/pdf/2302. 02814v2. pdf.

[55] CHEN B, LI P, BAI L, et al. Backbone is all you need: a simplified architecture for visual object tracking [C]// Proceedings of the 17th European Conference on Computer Vision. Cham: Springer, 2022: 375-392.

[56] YE B, CHANG H, MA B, et al. Joint feature learning and relation modeling for tracking: a one-stream framework [C]// Proceedings of the 17th European Conference on Computer Vision. Cham: Springer, 2022: 341-357.

[57] LAN J-P, CHENG Z-Q, HE J-Y, et al. ProContEXT: exploring progressive context Transformer for tracking [EB/OL]. [2023-05-30]. https://arxiv. org/pdf/2210. 15511v1. pdf.

[58] XIE F, CHU L, LI J, et al. VideoTrack: learning to track objects via video Transformer [C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 22826-22835.

[59] GAO S, ZHOU C, ZHANG J. Generalized relation modeling for Transformer tracking [C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 18686-18695.

[60] WU Q, YANG T, LIU Z, et al. DropMAE: masked autoencoders with spatial-attention dropout for tracking tasks [C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 14561-14571.

[61] CHEN X, PENG H, WANG D, et al. SeqTrack: sequence to sequence learning for visual object tracking [C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023:14572-14581.

[62] WEI X, BAI Y, ZHENG Y, et al. Autoregressive visual tracking [C]// Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 9697-9706.

[63] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 770-778.

[64] FAN H, LING L, YANG F, et al. LaSOT: a high quality benchmark for large scale single object tracking [C]// Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2019: 5369-5378.

[65] MÜLLER M, BIBI A, GIANCOLA S, et al. TrackingNet: a large scale dataset and benchmark for object tracking in the wild [C]// Proceedings of the 15th European Conference on Computer Vision. Cham: Springer, 2018:310-327.

[66] HUANG L, ZHAO X, HUANG K. GOT-10k: a large high diversity benchmark for generic object tracking in the wild [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 43(5):1562-1577.

[67] WU Y, LIM J, YANG M-H. Object tracking benchmark [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9):1834-1848.

[68] GALOOGHI H K, FAGG A, HUANG C, et al. Need for speed: a

benchmark for higher frame rate object tracking[C]// Proceedings of the 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 1134-1143.

[69] MUELLER M, SMITH N, GHANEM B. A benchmark and simulator for UAV tracking[C]// Proceedings of the 14th European Conference on Computer Vision. Cham: Springer, 2016: 445-461.

[70] KRISTAN M, LEONARDIS A, MATAS J, et al. The eighth visual object tracking VOT2020 Challenge results [C]// Proceedings of the 16th European Conference on Computer Vision. Cham: Springer, 2020: 547-601.

[71] KRIZHEVSKY A, SUTSKEVER I, HINTON G. ImageNet classification with deep convolutional neural networks [C]// Proceedings of the 25th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2012: 1097-1105.

[72] XIA M, ZHONG Z, CHEN D. Structured pruning learns compact and accurate models[C]// Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Stroudsberg: ACL, 2022: 1513-1528.

[73] WANG W, WEI F, LI D, et al. MiniLM: deep self-attention distillation for task-agnostic compression of pre-trained Transformers [C]// Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2020: 5776-5788.

[74] SO D R, LE Q V, LIANG C. The evolved Transformer[C]// Proceedings of the 36th International Conference on Machine Learning. New York: JMLR, 2019:5877-5886.

[75] WU Z, LIU Z, LIN J, et al. Lite Transformer with long-short range attention [C/OL]// Proceedings of the 8th International Conference on Learning Representations. [S. l.]: ICLR, 2020 [2023-05-30]. https://arxiv.org/pdf/2004.11886v1.pdf.

[76] CARON M, TOUVRON H, MISRA I, et al. Emerging properties in self-supervised vision Transformers [C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 9630-9640.

[77] XIE Z, LIN Y, YAO Z, et al. Self-supervised learning with Swin Transformers [EB/OL]. [2023-05-30]. http://arxiv.org/pdf/2105.04553v2.pdf.

[78] ATITO S, AWAIS M, KITTLER J. SiT: self-supervised vision Transformer [EB/OL]. [2023-05-30]. https://arxiv.org/pdf/2104.03602v3.pdf.

[79] CHEFER H, GUR S, WOLF L. Transformer interpretability beyond attention visualization[C]// Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognitio. Piscataway: IEEE, 2021: 782-791.

[80] SU H, YE Y, CHEN Z, et al. Re-attention Transformer for weakly supervised object localization[C]// Proceedings of the 33rd British Machine Vision Conference. Durham: BMVA Press, 2022:70.

[81] XIE W, LI X-H, CAO C C, et al. ViT-CX: causal explanation of vision Transformers [C]// Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence. California: IJCAI, 2023: 1569-1577.

[82] MOHEBBI H, ZUIDEMA W, CHRUPAŁA G, et al. Quantifying context mixing in Transformers [C]// Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistic. Stroudsberg: ACL, 2023: 3378-3400.

This work is partially supported by Military Model Project (LZX20190112).

SUN Ziwen, born in 1996, Ph. D. candidate. His research interests include computer vision.

QIAN Lizhi, born in 1963, Ph. D., professor. His research interests include intelligent ammunition strike.

YANG Chuandong, born in 1994, Ph. D. candidate. His research interests include computer vision.

GAO Yibo, born in 1998, M. S. His research interests include machine learning, hardware programmable languages.

LU Qingyang, born in 1994, M. S. candidate. His research interests include natural language processing, object tracking.

YUAN Guanglin, born in 1976, Ph. D., associate professor. His research interests include computer vision, machine learning.