武漢工程大学

Wuhan Institute of Technology

硕士学位论文

基于深度学习的光伏板缺陷检测与识别方法研究

学科专业：　新一代电子信息技术（含量子技术等）

研 究 生：　程柏霖

指导教师：　洪汉玉 教授

培养单位：　电气信息学院

二 ○ 二 五 年 五 月

中国知网 https://www.cnki.net

分类号：TP391 **学校代号：10490**

学　号：22203010032 **密　　级：公开**

武汉工程大学硕士学位论文

基于深度学习的光伏板缺陷检测与识别方法研究

作者姓名：程柏霖　　指导教师姓名、职称：洪汉玉教授

申请学位类别：电子信息硕士　学科专业名称：新一代电子信息技术（含量子技术等）

研究方向：图像处理

论文提交日期：2025 年 4 月 2 日　论文答辩日期：2025 年 5 月 27 日

学位授予单位：武汉工程大学　　学位授予日期：2025 年 6 月 20 日

答辩委员会主席：　桑农　

中国知网　https://www.cnki.net

Research on deep learning-based defect detection and identification method for photovoltaic panels

A Thesis Submitted for the Degree of Master

Major： New-Generation Electronic Information Technology

Candidate：Cheng Bolin

Supervisor：Prof. Hong Hanyu

Wuhan Institute of Technology

Wuhan, Hubei 430073, P. R. China

中国知网 https://www.cnki.net

摘 要

光伏发电作为实现我国碳中和的重要途径，在推动全球能源结构转型进程中发挥着至关重要的作用。在光伏电站生产和运营过程中，及时、准确地检测光伏面板的缺陷，是保障光伏发电系统高效运行的重要环节。利用无人机拍摄光伏组件图像，正逐渐成为光伏巡检过程中主流且高效的数据采集手段。由于安装方式的差异以及复杂地形等因素的影响，所采集到的光伏板图像存在倾斜、错位等位置偏差问题。同时，光伏缺陷也呈现出弱小且细微的表现形式，单一图像无法表达出缺陷的完整信息。论文以光伏巡检为研究背景，针对上述存在的问题，开展以下研究：

（1）在光伏缺陷样本缺失的情况下，本文提出一种基于区域特征与点特征的光伏板缺陷检测算法。该算法利用先验知识，构建一个用于存储缺陷区域特征与点特征的特征向量，并使用 SVM 对其进行缺陷分类。对比实验结果表明，与其他基于先验知识的无监督算法相比，该算法在热斑与遮盖缺陷的识别与分类方面展现出更高的准确性与鲁棒性。

（2）红外图像在缺陷特征表达上不完整，将红外图像与可见光图像进行融合可以增强缺陷特征的可辨识性。为此，本文提出一种基于改进跨模态图像生成与配准的无监督错位红外与可见光图像融合网络(UMF-CMGR)的图像配准融合算法，能够有效应对因拍摄视场不同导致的光伏板图像错位、畸变问题。该算法利用可变形卷积的动态采样，提高模型对光伏板边缘的提取能力，并引入 SE 注意力机制，突出重要特征信息。与仅依赖红外图像进行检测的实验结果相比，在融合红外图像与可见光图像特征信息后，基于区域特征与点特征的光伏板缺陷检测算法的检测效果进一步得到了提升，验证了融合结果的有效性。

（3）为了实现端到端的光伏板缺陷检测，本文提出一种基于多源融合的改

中国知网 https://www.cnki.net

进 YOLOv8 缺陷检测识别网络。通过设计 Bottleneck-Hybrid 结构，与原 C2f 模块中的 Bottleneck 模块并行计算，提升了特征提取效率。引入融合 Mamba 隐式状态更新机制与线性注意力机制的创新注意力模块 MLLA，以增强上下文建模能力。与现有的目标检测网络相比，改进后的 YOLOv8 在光伏板缺陷检测与识别方面表现更加优越。为实现图像配准、融合与检测的一体化处理，将改进的 UMF-CMGR 网络与改进的 YOLOv8 网络进行串联。实验对比结果表明，串联后的融合检测网络比原检测网络准确度更高，验证了串联结构的合理性。

关键词：光伏板缺陷检测与识别；图像配准融合；深度学习；可变形卷积；注意力机制

中国知网 https://www.cnki.net

Abstract

Photovoltaic (PV) power generation, as an important way to achieve carbon neutrality in China, plays a crucial role in promoting the process of global energy structure transformation. In the production and operation of PV power stations, timely and accurate detection of defects in PV panels is an important part of ensuring the efficient operation of PV power generation systems. The use of drones to capture images of PV modules is gradually becoming a mainstream and efficient means of data collection during PV inspections. Due to the differences in installation methods and the influence of factors such as complex terrain, the collected images of PV panels suffer from positional deviations such as tilting and misalignment. At the same time, PV defects are also weak and subtle, and a single image cannot express the complete information of the defects. The thesis takes PV inspection as the research background, and carries out the following research in view of the above existing problems:

(1) In the absence of PV defect samples, this thesis proposes an algorithm for detecting defects in PV panels based on region features and point features. The algorithm uses a priori knowledge to construct a feature vector for storing defective region features and point features, and uses SVM to classify the defects. Comparative experimental results show that the algorithm exhibits higher accuracy and robustness in identifying and classifying hot spot and masking defects compared to other unsupervised algorithms based on a priori knowledge.

(2) Infrared images are incomplete in defect feature representation, and fusion of infrared images with visible light images can enhance the recognisability of defect features. To this end, this thesis proposes an image alignment fusion algorithm based on an unsupervised misaligned infrared and visible image fusion network (UMF-CMGR) with improved cross-modal image generation and alignment, which can effectively deal with the problem of photovoltaic panel image misalignment and aberration due to the

中国知网 https://www.cnki.net

difference in the shooting field of view. The algorithm utilises dynamic sampling with deformable convolution to improve the model's ability to extract the edges of PV panels, and introduces the SE attention mechanism to highlight important feature information. Compared with the experimental results relying only on infrared images for detection, the detection effect of the PV panel defect detection algorithm based on regional and point features is further improved after fusing the feature information of infrared and visible images, which verifies the effectiveness of the fusion results.

(3) In order to achieve end-to-end PV panel defect detection, this thesis proposes an improved YOLOv8 defect detection and identification network based on multi-source fusion. The feature extraction efficiency is improved by designing the Bottleneck-Hybrid structure, which is computed in parallel with the Bottleneck module in the original C2f module. An innovative attention module MLLA, which fuses Mamba's implicit state update mechanism with linear attention mechanism, is introduced to enhance the context modelling capability. Compared with existing target detection networks, the improved YOLOv8 performs better in PV panel defect detection and recognition. To achieve the integrated processing of image alignment, fusion and detection, the improved UMF-CMGR network is connected in series with the improved YOLOv8 network. The experimental comparison results show that the fusion detection network after the series connection is more accurate than the original detection network, which verifies the reasonableness of the series connection structure.

Keywords: Photovoltaic panel defect detection and identification; Image registration fusion; Deep learning; Deformable convolution; Attention mechanism

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 课题研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 基于先验知识的无监督光伏缺陷检测研究现状.....2
1.2.2 基于深度学习的光伏缺陷检测研究现状.....6
1.3 本文主要研究内容.....7
1.4 本文组织安排.....8
第 2 章 光伏板缺陷检测相关理论基础.....9
2.1 引言.....9
2.2 光伏板缺陷成因及特性.....9
2.3 目标检测网络对光伏板检测任务的应用分析.....12
2.3.1 两阶段目标检测网络.....13
2.3.2 一阶段目标检测网络.....15
2.4 本章小结.....16
第 3 章 基于区域特征与点特征的缺陷检测与识别算法.....17
3.1 引言.....17
3.2 算法整体流程.....17
3.3 图像预处理.....18
3.3.1 滤波.....18
3.3.2 图片分割.....19
3.3.3 形态学处理.....21
3.4 缺陷区域特征与点特征的检测与识别.....22
3.4.1 缺陷特征提取.....23
3.4.2 构建特征向量.....24
3.4.3 光伏板缺陷检测与识别.....25
3.4.4 实验对比分析.....28
3.5 本章小结.....30
第 4 章 基于改进的 UMF-CMGR 网络的图像配准融合算法.....31
4.1 引言.....31
4.2 基于关键点检测的图像配准算法.....31
4.3 基于跨模态图像生成与配准的融合网络.....35
4.4 基于改进的 UMF-CMGR 网络的光伏板图像融合.....38
4.4.1 改进的特征提取网络.....38
4.4.2 引入 SE 注意力机制.....40

中国知网 https://www.cnki.net

4.4.3 光伏板图像配准融合实验.....41
4.4.4 配准融合有效性实验.....45
4.5 本章小结.....47
第 5 章 基于多源融合的改进 YOLOv8 缺陷检测识别网络.....49
5.1 引言.....49
5.2 改进的 YOLOv8 模型介绍.....49
5.2.1 YOLOv8 的优势与局限性.....49
5.2.2 改进的 C2f 结构.....50
5.2.3 引入 MLLA 注意力机制.....53
5.3 配准融合网络串联 YOLOv8-MDCNv3 网络.....56
5.4 模型改进实验.....58
5.4.1 消融实验.....58
5.4.2 实验对比分析.....58
5.4.3 配准融合网络串联 YOLOv8-MDCNv3 实验.....60
5.4.4 实验结果展示.....61
5.5 本章小结.....62
第 6 章 总结与展望.....63
6.1 本文总结.....63
6.2 研究展望.....64
参考文献.....65

中国知网 https://www.cnki.net

第1章 绪论

1.1 课题研究背景及意义

随着全球能源形势的日益严峻，化石燃料的持续消耗和能源价格的波动，它们加剧了能源供应的不稳定性。在这一大环境下，各领域对可再生能源的需求不断增长。作为能源转型的重要发展方向，新能源和新型电力系统凭借高效、清洁、绿色低碳的优势，逐步得到大众的广泛认可。并且，光伏、风能等可再生能源技术不断进步，使得电站发电效率得到提高的同时也降低了发电成本。如图 1-1 所示，据国家能源局官网发布的 2024 年底全国电力工业统计数据显示来看，全国累计发电装机容量约 33.5 亿千瓦，太阳能发电装机容量约 8.9 亿千瓦，风电装机容量约 5.2 亿千瓦，以光伏发电和风电为主的新能源电力系统装机容量占比持续增长[1]，达到了 42%。光伏发电和风电成为了仅次于煤电发电的电源类型，这一变化对推动电力行业由煤电向低碳发电转型发挥了重要作用。其中，光伏发电因其转换效率高、储量大、清洁安全等优点[2]，成为能源绿色低碳转型的重要组成部分。

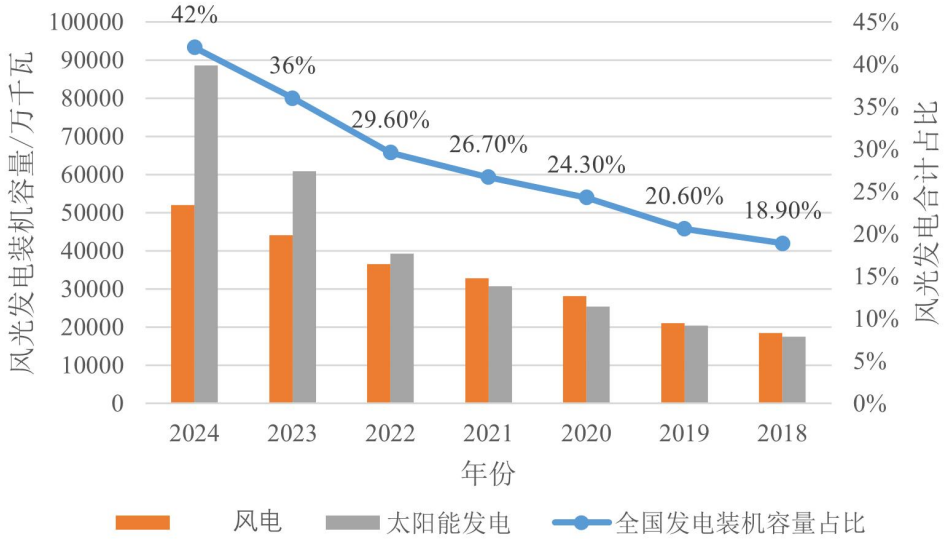


图 1-1 中国风光发电装机容量占比

然而，在实际生活中，光伏板的发电效率受到缺陷，例如热斑[3]、二极管过热[4]、覆盖物[5]（如鸟粪、树枝等）的影响较大，这些问题也是缺陷检测过程中的主要检测目标。目前的光伏缺陷检测方法主要

中国知网 https://www.cnki.net

还是依赖于人工检查和现场巡检，但大型光伏电站通常规模庞大、组件数量众多，因此传统的人工检测方法会带来许多问题，例如劳动强度过大、效率不高、主观因素影响检测结果[6]等。并且，训练一个好的光伏板缺陷检测模型往往依赖大量的数据集，但由于不同地区、不同厂商的光伏组件在制造工艺、使用环境、老化程度等方面存在差异，导致单一数据集训练的模型在其他场景下泛化能力较差。光伏缺陷数据的采集成本较高采集速度较慢，这也导致训练数据的不足，这些都是影响光伏板缺陷检测效率的主要原因[7]。因此，在没有大规模数据集的情况下，提出一种光伏板缺陷检测算法很有必要。

需要指出的是，光伏板通常安装在户外，受当地环境、天气、光伏板安装角度的影响，采集到的光伏板红外图像可能会存在过曝、信噪比较低、畸变等问题[8]，这些会导致缺陷检测算法的鲁棒性降低。光伏巡检过程中，仅仅对红外图像或对可见光图像进行检测，缺陷特征并不完整，例如在红外图像上呈现出阴影的区域，既可能是因为存在遮盖导致的，也可能是因为光伏板内部出现断路，发电不正常导致的，单一图像的缺陷检测很难对其进行缺陷成因的分析。

1.2 国内外研究现状

1.2.1 基于先验知识的无监督光伏缺陷检测研究现状

基于先验知识的无监督光伏缺陷检测技术中，图像检测方法是一种低成本，适用范围较广的方法。基于先验知识的图像检测方法主要是对单个图像进行检测并分类，这些技术主要针对光伏板表面的机械损伤和内部接触不良等问题。

因光伏板内部出现的接触不良、局部短路、旁路二极管损坏等问题，使用红外热成像仪检测光伏板表面的温度分布，可以快速识别光伏板内部出现的问题[9]。在拍摄过程中采用无人机搭载红外成像设备（红外相机、红外热像仪等）巡检可实现远距离检测，不影响光伏板的正常运行。拍摄完成之后，通过一系列算法可快速识别、区分这些缺陷，这使得热成像检测法更适合于大规模的光伏电站的快速检修。这种方法正是根据红外图像可以很好的反映光伏板表面温度分布而

中国知网 https://www.cnki.net

提出的，当光伏板因为内部问题出现故障，故障区域温度通常高于正常部位[10]。因此，可以通过对光伏板红外图像分析以判断是否出现故障，图 1-2 所示为拍摄的光伏阵列红外图片，图中光伏板高亮部位即为故障部位。

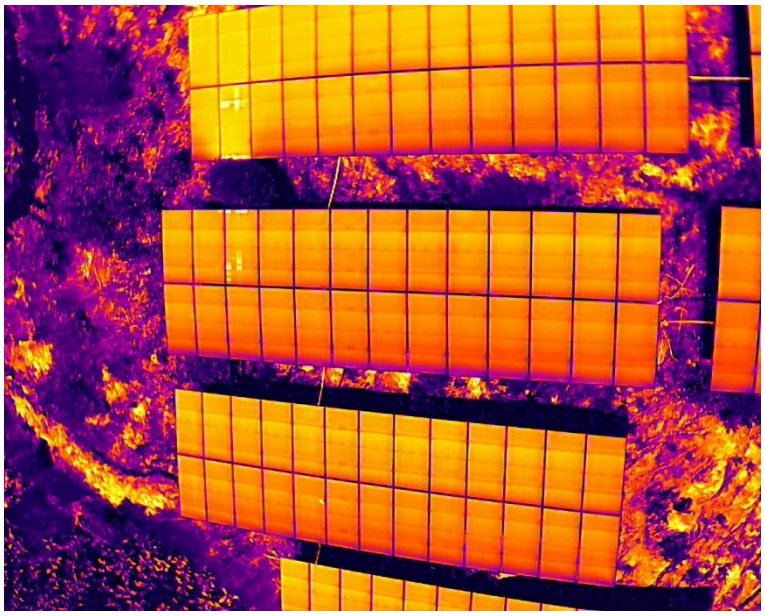


图 1-2 光伏阵列红外图

王培珍等人[11]提出一种根据红外图像来检测光伏板工作状态的方法。该方法在图像预处理部分就考虑了因为天气、风速等噪声的影响，对采集到的红外图像进行滤波以排除噪声的干扰，之后采用二维阈值法进行阈值化，区分光伏板和背景区域。缺陷检测阶段采用特征提取方法，根据缺陷区域与整体区域的灰度平均值之差，判断是否存在温度异常。该方法采用模糊推理方法进行状态缺陷识别，可快速扫描光伏阵列，适合现场检测。

Ali 等人[12]提出了一种基于彩色图像描述符和机器学习算法的光伏板早期热点检测新框架。该方法首先将获取的光伏板热像图像划分为不重叠的区域，然后计算这些区域的彩色图像描述符。使用颜色描述符作为特征来训练不同的机器学习算法，将光伏板分为三类(即正常，热点和缺陷)。该方法采用基于 k-最近邻的红绿尺度不变特征变换(rgSIFT)描述符优于所有其他图像描述符和机器学习组合，准确率达到 98.7%。

王亚丽等人[13]构建了一套光伏板缺陷检测系统，根据光伏板的缺陷特征，通过改进的边缘检测算法和 K-L 变换算法，可实现对四种缺

中国知网　https://www.cnki.net

陷的提取以及分类。该系统在光伏板缺陷检测任务中工作安全系数高、检测速度快、检测精度高等优势。

马浩等人[14]通过改进 Adaboost 算法进行光伏阵列检测，并采用温度直方图分析和滑动窗口技术提高热斑检测精度。缺陷定位过程中采用 Harris 特征点检测和图像配准技术，实现热斑的精准定位。该方法具有较高的缺陷识别精度，可以实现热斑的精准定位，能够满足大型光伏巡检任务要求。

Henry 等人[15]将图像转换为 HSV 颜色空间，以分离色度信息和强度信息。接下来在 HSV 色彩空间中进行颜色阈值提取感兴趣的区域，从热图像中计算出最高温度值 Tmax、最低温度值 Tmin 和平均温度值 Tavg。分别计算高温阈值 Thigh 或低温阈值 flow。当温度值低于 Tmax 和 Tmin 时，增加计数值。若占模块面积值的 0.2%以上，则认为该模块异常。

可以看出，以上对于光伏板红外图像检测的缺陷大都是热斑，而无法检测更多类型的缺陷，或者说没有进一步细分缺陷。这样的缺陷检测虽然可以帮助巡检人员获悉缺陷的大致位置，但无法根据缺陷的类型作出维修策略，依然需要人工复查，这样将会降低光伏板电力巡检的效率。此外，基于先验知识的无监督算法对于光伏板红外图像进行缺陷检测过程中，主要通过图像中的热度信息进行检测，图像质量的好坏将会直接影响检测准确率。对于小型热斑，若图像较模糊，则会在检测过程中因为图像预滤波等操作忽略掉这些缺陷。

通过工业相机拍摄的光伏板可见光图像，如图 1-3 所示，经由人工或算法分析光伏板表面是否存在可见缺陷。这种方法可检测到光伏板表面出现的机械损伤[16]（划痕、裂纹、遮盖等）和组件安装的异常（倾斜、间距不均等）。对光伏板可见光图像进行检测的优势在于设备成本低，适用于工厂日常巡检，缺点也很明显，无法检测到内部存在的缺陷，且受到环境光照的影响较大。

中国知网 https://www.cnki.net



图 1-3 光伏阵列可见光图

Hsu-Nan Yen 等人[17]针对光伏板栅线的缺陷设计了一个检测系统。因为主栅线和副栅线的垂直关系，通过垂直投影和水平投影来确定主栅线的位置，之后根据确定的主栅线的走向，在垂直方向上确定副栅线位置。如果过程中发现灰度值为零的部分则代表检测到了栅线缺陷。

虎民飞等人[18]基于改进的 PID 算法提出了一套光伏板清洗视觉伺服控制系统。该系统不仅能够利用实时视频图像精确定位到光伏板表面的缺陷，还能在识别到缺陷时对其进行清洗。

Li X 等人[19]提出了一种无人机巡检的大规模光伏系统检测方法。主要用于蜗牛纹和灰尘遮挡的检测，该方法利用无人机搭载的可见光摄像头拍摄光伏板图像，将拍摄到的图像实时传回地面控制站，拍摄过程中无人机会按照预设的轨迹自动巡检，无需巡检人员控制无人机。拍摄到的光伏板图像主要通过通道分离、滤波、缺陷边缘提取、特征匹配等算法进行检测，研究在多地大型场站进行实地测试。在飞行高度 2 米的情况下依旧能满足对蜗牛纹和灰尘遮挡的检测需求。

综上所述，对光伏板可见光图像进行检测的方法中，主要针对的是光伏板表面的栅线、遮挡、物理损坏等缺陷。基于先验知识的无监督光伏板缺陷检测方法对于此类缺陷有一定的检测精度，且能够快速部署到巡检系统中，实时性较高。但对于光伏板内部出现的问题无法进一步进行检测。

中国知网　https://www.cnki.net

1.2.2 基于深度学习的光伏缺陷检测研究现状

随着对深度学习的不断研究与实验，人类在深度学习领域取得了很多成果，对于基于深度学习的图像检测算法在准确度、识别率等方面也得到了很大程度的提升。因此，许多学者提出了基于深度学习的光伏缺陷检测方法。

陈克松等人[20]提出了一种在卷积神经网络中通过加入改进门控单元的优化方法。该方法首先建立了光伏板的数学模型，之后对其出现的不同缺陷进行分析、仿真等一系列实验。采用卷积神经网络对光伏板数据时序性特征进行分析，利用生成对抗网络进行数据增强，引入半监督学习减少了对标签样本的依赖性。实验证明，该方法在缺陷分类的准确性和精度都比较高。

沈灵鑫等人[21]则提出了一种基于融合边缘特征的 DeepLabv3+语义分割网络和 Transformer 的 PVT-v2 结构与改进后的 YOLOX 结合的方法。该方法不仅能够优化光伏板数据边缘断续腐蚀问题，而且能够达到较高的检测精度。

Cao Y 等人[22]提出了一种 YOLOv5-GBC 模型。该研究采用注意力机制和双向特征金字塔网络来提高检测准确度，并采用 GhostConv 和 Gaussian 对模型进行轻量化，提高模型的推理速度。提出的 YOLOv5-GBC 模型对比原模型准确性和推理速度上都有一定提升。

J. Jerome Vasanth 等人[23]主要针对光伏板表面的缺陷，如裂纹、脱层、烧伤痕迹等。采用无人机搭载高分辨率数字相机收集光伏板高清图像，利用卷积神经网络从预处理之后的图像提取特征，应用 J48 决策树算法进行特征选择，使用不同的分类算法来分类和识别不同缺陷。实验过程中，分析和讨论使用不同特征和分类器组合的性能，找到了最优的检测策略，实现光伏板故障检测。

Wang X 等人[24]提出了一种基于红外检测的智能检测技术。该研究主要利用 U-Net 神经网络和分类器相结合的方式进行检测，通过无人机拍摄的光伏板红外热成像，利用 U-Net 神经网络在光伏板图像中分割故障区域形成掩码图。根据轮廓面积、轮廓周长、长宽比、轮廓面积与其外接矩形面积比值缺陷四种关键特征并结合决策树、支持向量机和 K 近邻来检测缺陷。实验研究表明，经过训练的 U-Net 神经

中国知网 https://www.cnki.net

网络图像分割率达到了 95.2%。

综上所述，随着深度学习算法在光伏板巡检过程中的应用，检测效率大大提升，且对于缺陷能够更加细致的分类对于光伏板巡检来说这是一种进步。缺陷更为细致的分类能够让巡检人员根据具体缺陷类型进行维修策略的调整，提高检修效率，且深度学习算法的应用也能让算法应对更多的数据类型，无需检修人员手动调整算法，普适性较高。但很多深度学习方法依旧只能针对可见光图像或者红外图像某一类图像进行检测，无法做到结合两种图像的特点一起检测。

1.3　本文主要研究内容

本文将从以下几个方面展开研究：

（1）提出一种基于区域特征与点特征的光伏板缺陷检测算法。该方法通过滑窗提取光伏板缺陷的区域特征与点特征，之后将这些特征信息归一化后存储到一个新的特征向量，完成特征向量的构建，选择 SVM 分类器进行缺陷分类。该算法在红外图像上能够有效识别出光伏板异常区域，并将其分类，但因为固定光伏板的螺丝钉发热导致的误检仍然不能解决。

（2）针对采集到的光伏板图像出现的畸变、倾斜等问题，以及光伏板缺陷在红外图像上的特征信息不完整等问题，在缺少有效的融合目标图像的情况下，提出一种基于改进的 UMF-CMGR 网络的图像配准融合算法。该算法通过无监督的形式实现了光伏板图像的配准与融合，解决光伏板图像中出现的畸变、倾斜等问题，并且融合结果也结合了可见光图像的特征信息，弱化了螺丝钉发热的特征，一定程度上降低了误检的情况。因为改进的 UMF-CMGR 网络的图像配准融合算法是无监督的，所以无法保证该算法的融合结果是否有利于后续的光伏板缺陷检测与识别。因此，使用基于区域特征与点特征的光伏板缺陷检测算法对配准融合之后的结果进行检测，验证配准融合结果的有效性。

（3）提出一种基于多源融合的改进 YOLOv8 网络对光伏板缺陷实现端到端检测和分类。通过加入新的 DCNv3 模块和 MLLA 注意力机制，提高模型对缺陷的精测精度和识别准确率，为了实现端到端的

中国知网　https://www.cnki.net

融合检测，将改进的 UMF-CMGR 网络与改进的 YOLOv8 网络进行串联，得到新的损失函数，进一步反向监督配准融合的结果。串联网络能够提高配准融合的质量同时也提高对光伏板缺陷的检测精度。

1.4 本文组织安排

第一章：绪论。本章首先对光伏板缺陷检测研究背景及意义进行分析，提出光伏板缺陷检测与识别的必要性和迫切性；接着介绍了基于先验知识的无监督光伏缺陷检测的国内外研究现状；之后介绍深度学习在光伏板缺陷检测算法上的国内外研究现状。

第二章：光伏板缺陷检测相关理论基础。本章首先介绍了光伏板缺陷的成因以及特性；接着分析了目标检测网络对光伏板检测任务的应用，分析两阶段检测网络模型 R-CNN 到一阶段检测网络模型 YOLO、SSD 对于光伏板缺陷检测任务的适用性。

第三章：基于区域特征与点特征的光伏板缺陷检测算法。本章首先阐述了整个算法的整体设计；其次对算法的关键技术进行介绍与实验分析，通过实验结果图体现每一个步骤的必要性；最后经过实验结果对缺陷检测的准确率分析，总结算法的优势与不足之处。

第四章：基于改进的 UMF-CMGR 网络的图像配准融合算法。本章首先提出一种基于关键点检测的图像配准算法，说明图像配准网络的必要性；其次介绍了一种基于跨模态图像生成与配准的无监督错位红外与可见光图像融合网络；之后对该网络进行改进，用实验验证了配准融合结果的有效性。

第五章：基于多源融合的改进 YOLOv8 缺陷检测与识别。本章首先指出了 YOLOv8 的局限性；然后针对光伏板缺陷的尺度变化特点，引入了改进的 C2f 结构；根据缺陷的形状不规则性引入了 MLLA 注意力机制；之后将改进的 UMF-CMGR 网络与改进的 YOLOv8 串联，实现端到端融合检测；最后，将改进的模型与不同系列的其他模型进行对比实验与数据对比分析，验证改进模型的有效性。将串联前与串联后的网络进行对比分析，实验表明，串联网络的精确度更高。

第六章：总结与展望。总结本文的的一系列研究与成果，并对本文工作中的不足与未来光伏板缺陷检测的下一步研究做出展望。

中国知网 https://www.cnki.net

第2章 光伏板缺陷检测相关理论基础

2.1 引言

光伏缺陷检测是近年来光伏巡检任务的重点。光伏板缺陷因其成因及特性的不同，所形成的缺陷也不相同。目前，常规的光伏板缺陷检测主要根据缺陷的各种特性进行检测，无法自动检测多地区、多形态的光伏板缺陷。卷积神经网络在目标检测任务中的发展将有效提高光伏板缺陷检测任务的准确率、普适性。将光伏板缺陷作为异常目标采用目标检测网络进行检测将提高光伏板检测任务的效率和准确率。

2.2 光伏板缺陷成因及特性

依据其成因机制的差异，光伏板缺陷主要可分为以下几类：热斑缺陷、多热斑缺陷、旁路二极管失效以及遮盖类缺陷。

热斑缺陷[25]指的是光伏组件中某些区域温度异常升高的现象。这些区域通常是由于电流无法正常流过，导致电流在局部区域堆积并形成高温区域。热斑形成的主要原因是材料老化、焊点故障、组件破损导致的局部过热，在红外图像上通常显示为高亮且区域形状不规则，而在可见光图像上没有明显的表现。

多热斑缺陷[26]则是比热斑更为严重的缺陷，它在红外图像上表现为多出亮斑且各处亮斑形状都不规则，可见光图像上无明显表现。它的出现往往提醒检修人员应该尽快更换光伏组件，否则多热斑的出现极有可能导致光伏板烧毁，形成火灾。

光伏组件通常采用旁路二极管保护光伏电池免受热斑效应的影响[27]。当光伏组件的某些单元由于遮挡或故障不能正常发电时，旁路二极管会为光伏板提供低阻抗路径让电流绕过故障单元，防止该单元反向偏置过热。二极管缺陷[28]指的就是旁路二极管出现的故障，形成的原因可能是二极管的 PN 结由于过电流或过电压击穿，导致二极管出现短路，或者因为二极管老化导致开路，二极管会进入反向偏置状态，形成二极管缺陷。二极管缺陷通常在红外图像上表现为高亮，形状较规整且覆盖范围一般较大，可见光图像上没有明显的表现。

中国知网　https://www.cnki.net

遮盖[29]指的是因为环境的影响，沙尘、鸟粪、树枝等覆盖物造成的阴影区域。覆盖物因为阻挡了光伏板对于阳光的吸收，会降低光伏板的发电效率，遮盖缺陷在可见光图像上能够清晰看到覆盖物的形状，在红外图像上表现为阴影暗斑。图 2-1 展示了光伏板热斑、多热斑、二极管缺陷在红外图上的表现形式，遮盖在可见光图像上的表现形式。

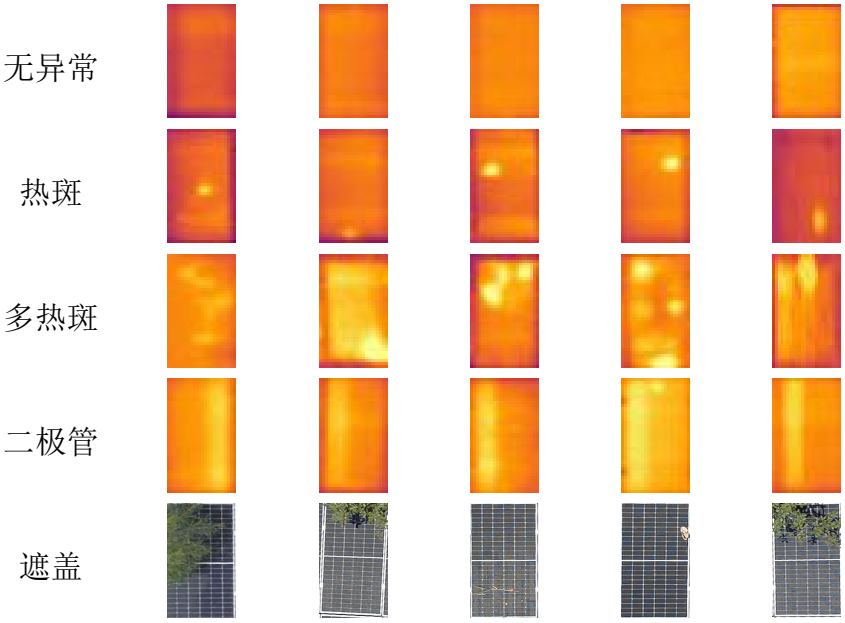
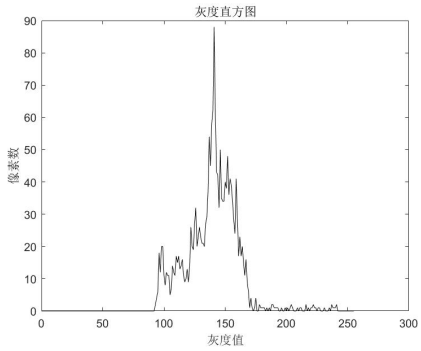
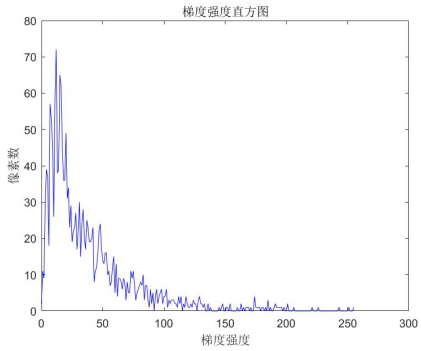


图 2-1 光伏板缺陷表现形式

光伏板缺陷在图像上因其纹理、形状、颜色、梯度等特征明显，常规的光伏板缺陷检测方法更多采用的是灰度阈值[30]、边缘检测[31]、形态学处理[32]等方法，基于人工规则去设置光伏板缺陷特征进行检测。图 2-2 为热斑、多热斑、二极管三种缺陷的灰度直方图梯度强度直方图。在未出现缺陷的部分，无论是灰度还是梯度强度都不高，而出现热斑、多热斑、二极管缺陷部分，灰度强度和梯度强度都较高，而热斑的高灰度和高强度梯度像素数要低于多热斑、二极管缺陷。

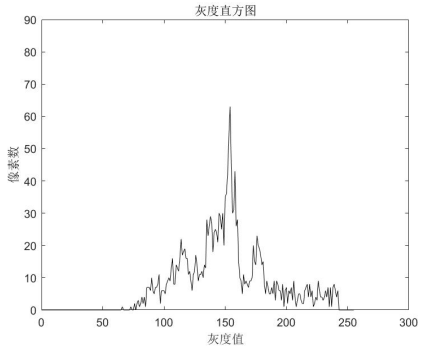


(a) 热斑灰度直方图

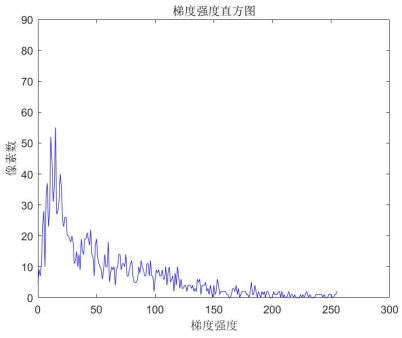


(b) 热斑梯度直方图

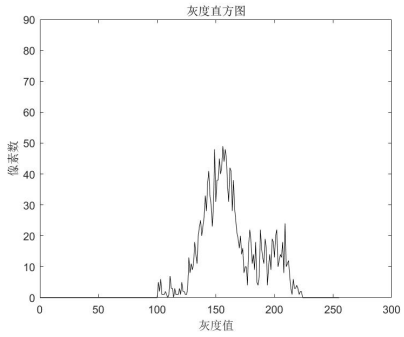
中国知网 https://www.cnki.net



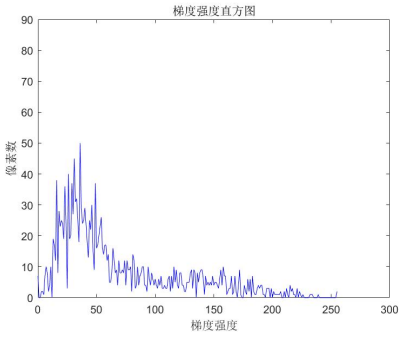
(c) 多热斑灰度直方图



(d) 多热斑梯度直方图



(e) 二极管灰度直方图



(f) 二极管梯度直方图

图 2-2 红外图像上缺陷特征图

图 2-3 是热斑、多热斑、二极管的梯度强度图。梯度强度图是通过对图像计算梯度后，得到每个像素处的梯度大小的图像。可以看出，在出现缺陷的边缘区域，梯度强度都较高，而热斑的梯度强度区域面积较小，多热斑、二极管缺陷的梯度强度区域面积较大。



(a) 热斑



(b) 多热斑



(c) 二极管

图 2-3 缺陷梯度强度图

对于遮盖缺陷的检测[33]，当检测到不规则轮廓时，常常认定为存在遮盖缺陷。图 2-4 为遮盖缺陷用多种边缘检测算法的结果图，除去光伏板自身的栅线，当出现遮盖时，会出现多个不规则边缘，对可见光图片常规检测时出现这样的不规则边缘便会认定为出现遮盖。



(a) 原图



(b) Canny 边缘检测

图 2-4 边缘检测结果图

中国知网　https://www.cnki.net

常规的光伏板缺陷检测方法很大部分都是根据缺陷在图像上的各种特征，手动设置阈值进行检测。这样的好处就是不依赖大量的数据集，算法简单易部署，但不足之处也很明显，手动设置的阈值只能适用于自身的光伏板图像，受图像质量影响较大。因此，越来越多的检测算法开始使用深度学习模型去完成光伏板缺陷检测任务，将光伏板作为识别目标，将光伏板缺陷作为异常目标去检测的基于目标识别网络的算法也越来越多。

2.3 目标检测网络对光伏板检测任务的应用分析

目标检测任务的核心目的是识别图像中的物体,并在图像或视频资料中确定其位置，通常涉及目标的定位和分类两个基本步骤。随着技术研究的深入,基于深度学习的目标检测算法主要分为两类：两阶段算法和一阶段算法[34]。目标检测网络以光伏板为目标去做识别，不仅支持检测单块完整的光伏板，还支持多尺寸、角度、遮挡情况下的光伏板识别，对于光伏板缺陷识别等后续任务有一定帮助。

其中，大多数两阶段目标检测算法都是基于卷积神经网络 CNN，CNN 源于 20 世纪 60 年代 Wiesel 进行的猫视觉皮层实验[35]。他们发现视觉皮层的神经元对特定的边缘方向或移动方向敏感，这启发了局部感知字段和层次结构处理的思想。1980 年，日本学者福岛邦彦提出了一种“神经认知机”，它是 CNN 的雏形，其结构受到视觉系统的启发，包含多个交替的卷积和池化层。1990 年代，Yann LeCun 及其合作者通过引入反向传播算法来训练卷积神经网络，成功开发了 LeNet-5，这是第一个实际成功的 CNN，用于手写数字识别，这标志着 CNN 在视觉任务中的潜力初步显现。进入 21 世纪后，CNN 的发展和普及主要得益于两个因素：一是硬件计算能力的显著提升，特别是 GPU 的使用；二是大量标注数据集的可用性，如 ImageNet。2012 年，Alex Krizhevsky 设计的 AlexNet[36]在 ImageNet 竞赛中大放异彩，随后的几年中，更深更复杂的网络如 VGG[37], GoogleNet[38], ResNet[39] 相继出现，它们通过更深的网络结构和新颖的技术（如残差学习）不断推动着性能的边界。

卷积神经网络（CNN）的设计主要基于它的层级结构，CNN 结

中国知网 https://www.cnki.net

构主要分为卷积层[40]、池化层[41]、全连接层[42]等多种类型的层。对输入的数据，每一层会执行特定的运算来提取和转换数据的信息。在这些层中，卷积层和池化层发挥了重要作用，它们通过局部连接以处理输入进来的数据，从而显著减少了网络的复杂度和所需的计算资源，其结构如图 2-5 所示。

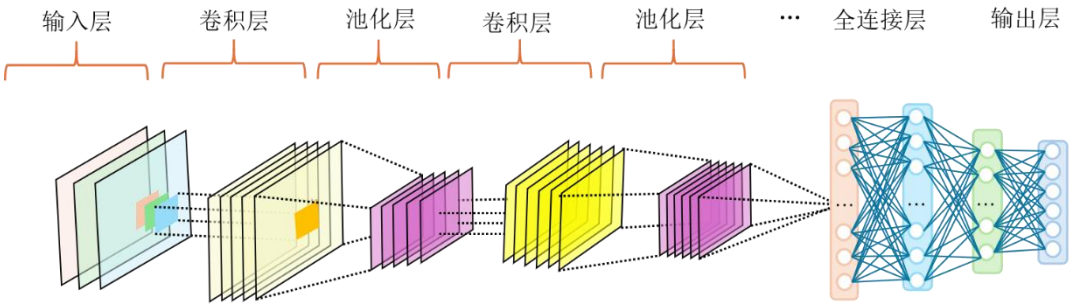


图 2-5　卷积神经网络

2.3.1　两阶段目标检测网络

常见的两阶段目标检测算法主要有 R-CNN、Fast R-CNN、Faster R-CNN 等[43]。它们能够更细致地处理每个候选区域，通过分阶段处理优化检测的准确性，因此，它们能够获得更高的检测精度。因为需要两个阶段的计算，尤其是在第一阶段，算法需要生成大量的候选区域，所以检测速度相对较慢。

（1）R-CNN 是卷积神经网络中一种最为常见的两阶段目标检测算法，由 Ross Girshick[44]等人于 2014 年提出。R-CNN 的核心思想是将目标检测问题视为一种图像分类问题。首先，R-CNN 会在输入图像中使用选择性搜索算法快速生成大约 2000 个候选区域，这些区域可能包含某些对象；其次，生成的候选区域大小会被统一为输入 CNN 模型的尺寸，常设为 227×227 像素；随后，每个处理后的区域被输入预训练的卷积神经网络当中，以此提取得到这些输入区域的特征，这些特征将会被用作支持向量机（SVM）的输入，用于区分不同的类别。

R-CNN 结构如图 2-6 所示。R-CNN 的提出显著提高了目标检测的精度，但也有几个明显的局限性：它的运算速度较慢，因为需要对每个候选区域独立运行深度卷积网络，面对大规模且高质量光伏板数

中国知网　https://www.cnki.net

据集时，这在处理大量区域时尤为耗时。

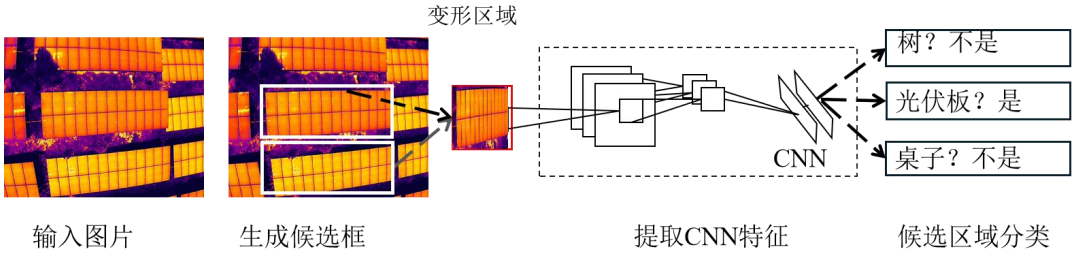


图 2-6 R-CNN 目标检测算法

（2）Fast R-CNN 是一种在 R-CNN 基础上改进的目标检测算法，由 Ross Girshick 在 2015 年提出。它主要目的是解决原始 R-CNN 在速度和训练效率上的局限性，通过一系列创新极大地提高了处理速度和训练的便捷性。首先，与 R-CNN 不同的是，Fast R-CNN 仅对整个输入图像进行一次卷积运算，并生成整幅图像的特征图；然后，直接在特征图上而非原始图上生成候选区域。其结构如图 2-7 所示。

尽管速度有很大提升，Fast R-CNN 的性能还是受到选择性搜索算法的速度限制。因为这一步骤并未完全集成到神经网络中，仍需作为一个独立步骤去进行外部处理。因此，在完成光伏板缺陷检测任务中不论是光伏板识别还是光伏板缺陷检测，Fast R-CNN 的训练速度仍然较慢。

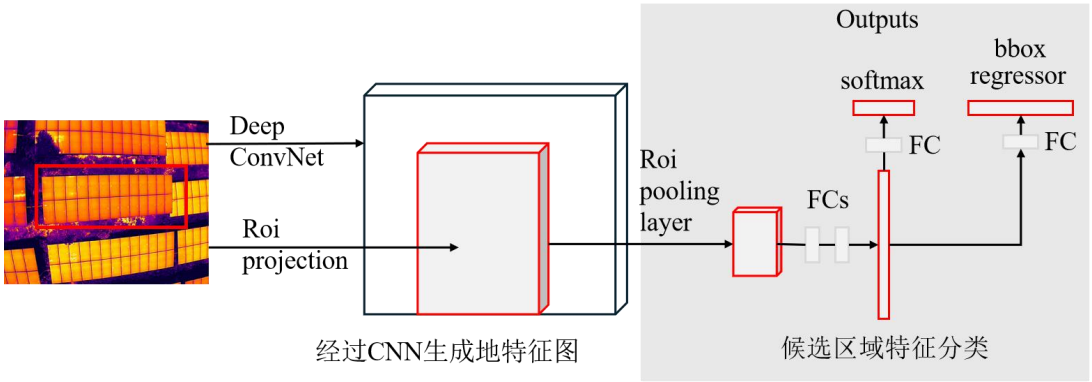


图 2-7 Fast R-CNN 目标检测算法

（3）Faster R-CNN 是一种高效的目标检测算法，由 Shaoqing Ren 等人在 2015 年提出。这个算法的出现是为了解决 Fast R-CNN 中依赖于选择性搜索算法来生成候选区域较为缓慢的问题[45]。Faster R-CNN 的工作原理包括两个主要部分：区域提议网络（RPN）和 Fast R-CNN 检测器，其结构如图 2-8 所示。

中国知网 https://www.cnki.net

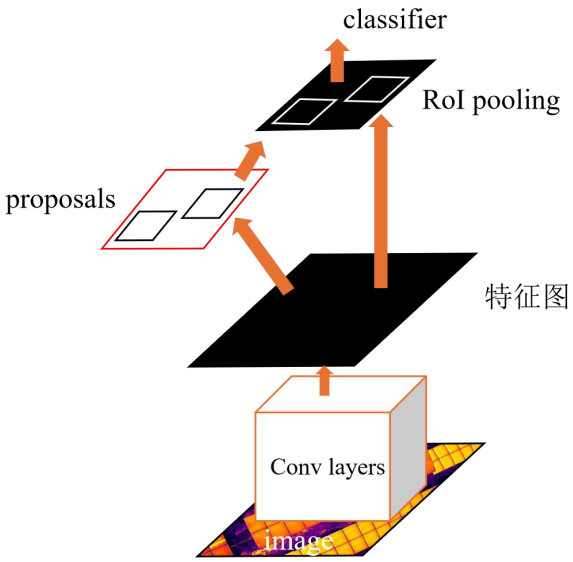


图 2-8 Faster R-CNN 目标检测算法

两阶段目标检测网络因为其内存消耗较高，对于拍摄的高清光伏板图像计算量较大，推理速度较慢，并且，两阶段目标检测网络对于 ROI 质量要求比较高。但由于光伏板常常排列紧密，两阶段网络生成的候选框会出现大量重叠，这就会导致后续检测任务难度升高，甚至造成漏检、误检的情况发生。因此，两阶段目标检测网络暂时还不适用于光伏板缺陷检测任务。

2.3.2 一阶段目标检测网络

代表性算法主要有 YOLO 系列、SSD 等。相较于两阶段目标检测算法，一阶段目标检测算法速度更快，因为整个检测过程只需要一个阶段，减少了计算量，所以检测速度得到了较大提升。

（1）YOLO 由 Joseph Redmon 等人在 2016 年提出[46]。该方法将目标检测视作单一的回归问题，显著提升检测的速度和效率。YOLO 的核心理念是将整个图像划分为一个 S×S 的网格，并对每个网格单元直接预测得到边界框。每个边界框的预测包括边界框的位置、尺寸（相对于整个图像）和一个置信度得分，这个得分表示边界框中含有物体的概率以及预测边界框的准确性。同时，每个网格单元还需要预测那些中心点落在该单元内的物体的类别概率。YOLO 通过对整个图像的一次性检测，减少了重复的特征提取，因为它处理速度非常快，这使得它非常适合如视频监控和自动驾驶等实时处理应用。

中国知网　https://www.cnki.net

（2）SSD 是一种高效的一阶段目标检测算法，由 Wei Liu 等人在 2016 年提出。SSD 在设计上与 YOLO 不同，它通过在尺度大小不固定的特征图上进行检测，能够有效地处理各种大小的物体，从而提高了检测的准确性和速度。SSD 的工作原理是在单个深度卷积网络中直接预测物体的边界框和类别[47]。这个网络首先使用一个标准的基础架构（如 VGG 或 ResNet）来提取图像的特征，然后在此基础上添加了几个特征层进行检测。每个特征层都可以使用一系列预定义大小和比例的锚框来预测边界框的位置和形状,其结构如图 2-9 所示。

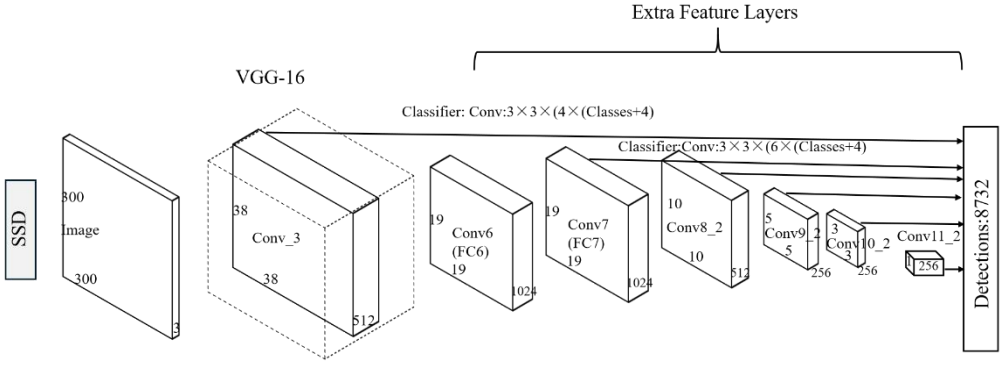


图 2-9 SSD 网络结构

一阶段目标检测网络因其设计简洁，效率更高且适合实时检测。对于光伏板检测任务来说，对数据集的要求相比于两阶段目标检测网络来说更低，适合大规模粗标注数据集，且能保持一定精度的同时实现高效检测。因此，一阶段检测网络更适用于光伏板缺陷检测任务。

2.4 本章小结

在本章主要介绍了光伏板缺陷种类以及形成原因进行了详细介绍，对光伏板各种缺陷的特征进行分析，对之后的缺陷识别以及分类做出铺垫。其次，探讨了目前主流的目标检测网络中一阶段检测网络和两阶段检测网络对于光伏板缺陷检测任务的优势与劣势。

中国知网 https://www.cnki.net

第3章 基于区域特征与点特征的缺陷检测与识别算法

3.1 引言

光伏板质量直接影响光伏发电系统的效率和性能。光伏板缺陷在无大量样本的情况下，检测难度大、检测精度低。常规的光伏板缺陷检测算法往往只根据缺陷的某一特征（例如梯度、亮度等）进行检测，对不同尺度、不同类型的缺陷往往检测效果不佳。因此，本文提出一种基于区域特征与点特征的光伏板缺陷检测与识别算法。该算法构建了一个新的特征向量用以存储光伏板缺陷的区域特征和点特征，运用分类器实现光伏板缺陷的分类。在没有大量样本标注的情况下，该算法适用于不同尺度和不同类型的光伏板缺陷检测与识别。

3.2 算法整体流程

根据无人机拍摄的光伏板图像特征，本文提出了一种基于区域特征与点特征的光伏板缺陷检测算法，该算法主要流程如下：

（1）对于无人机拍摄的含有缺陷的光伏板图像，首先需进行系统性的图像预处理操作，对光伏板图像进行预处理包括滤波、对比度增强、去噪，增强缺陷区域的显著性。

（2）对预处理后的图片进行分割，对图片进行颜色阈值分割、边缘检测分离光伏板和背景。又由于拍摄角度的不同，光伏板图像可能存在透视变形。通过使用霍夫线检测和投影变换，能够将光伏板校正到正视视角，方便后续的特征提取。

（3）缺陷特征提取，基于区域特征与点特征的光伏板缺陷检测算法，对预处理过后的图片，提取 ROI 区域特征与点特征，获取缺陷的区域特征和点特征，将高维信息转化为向量值。

（4）构建特征向量，提出一个新的特征向量 *Ipv*，里面用多个字段存储提取到的特征信息。即使时不同尺度的缺陷也能够进行存储，存储之前需要对数据进行归一化，再将归一化后的缺陷特征数据存储到特征向量中，完成特征向量 *Ipv* 的构建。

（5）分类器分类，采用 SVM 分类器对构建好的特征向量进行

中国知网　https://www.cnki.net

分类，避免了人工分类中手动设置阈值的缺点，最后，生成预测结果。图 3-1 为基于区域特征与点特征的光伏板缺陷检测算法的流程图。

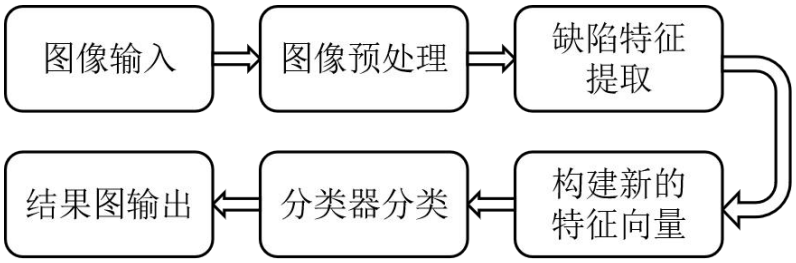
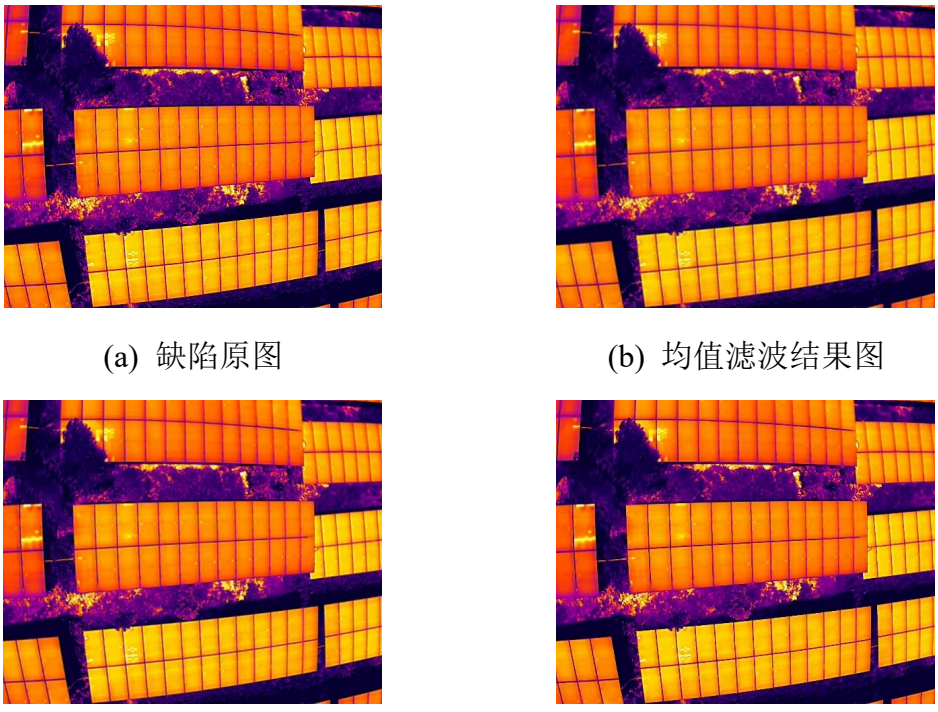


图 3-1 基于区域特征与点特征的光伏板缺陷检测算法算法流程图

3.3 图像预处理

3.3.1 滤波

由于采集设备或环境影响，由无人机拍摄到的光伏板图像存在一定的噪声干扰，图像滤波处理能一定程度上减小噪声干扰。常见的滤波有均值滤波、高斯滤波、双边滤波等。如图 3-2(a)所示为原图，分别对输入图像用均值滤波[48]、高斯滤波[49]、双边滤波[50]进行处理，滤波结果分别如图 3-2(b)、图 3-2(c)、图 3-2(d)所示：



(a) 缺陷原图　(b) 均值滤波结果图

(c) 高斯滤波结果图　(d) 双边滤波结果图

图 3-2 滤波实验结果

中国知网 https://www.cnki.net

由图 3-2 可以看出，虽然均值滤波和高斯滤波也能有效去除噪声，但它们在图像边缘造成了不必要的模糊，不利于后续的分割处理。双边滤波通过加权平均的方式，其中权重取决于像素值的差异。双边滤波使得颜色或强度变化大的边缘部分不会过度平滑，从而更好地保持图像的结构特征，避免了边缘和细节的模糊，有助于后续将整块光伏板从图片中分割出来。因此，后续采用双边滤波处理采集到的图片。

3.3.2 图片分割

（1）光伏板红外图像特征

如果板上某些部分因效率不高或损坏而导致热量集中，这些部分在红外图像中可能会显示为更暖(即亮度更高)的颜色，而这些更暖的部分即是缺陷出现的地方。如图 3-3 所示，图中的缺陷部分已经用红色圆圈标记。

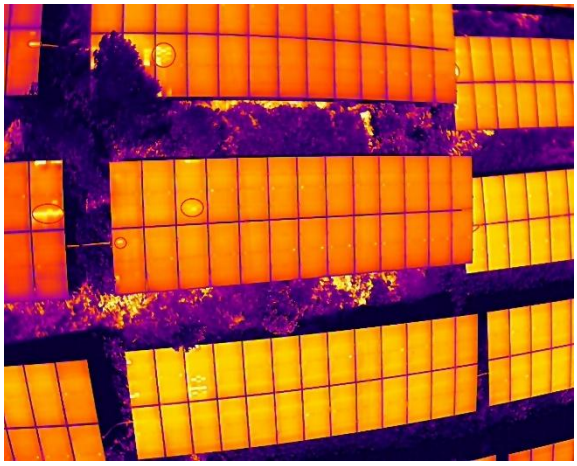


图 3-3 光伏图像缺陷示意图

（2）颜色阈值分割

根据红外图像的光伏板图像特征，将红外图像转换为 HSV 图像。这样做的目的是为了利用 HSV 空间在色调、饱和度和亮度上的分离特性[51]，使得对颜色的分割和分析更加方便和直观。虽然红外图像本质上是伪彩色图像，但它们通常以 RGB 格式表现出来。这意味着技术上可以将这种以 RGB 形式表现的红外图像转换到 HSV 颜色空间。

HSV 颜色空间是一种常用的颜色表示方法，HSV 代表了色调、饱和度、和亮度，尤其在图像处理和计算机视觉中十分流行。假设 RGB 值的范围是 0 到 255，首先，将 RGB 值规范化到 0 到 1 的范围。

中国知网　https://www.cnki.net

其公式如（3-1）所示：

$$R' = R/255, G' = G/255, B' = B/255 \tag{3-1}$$

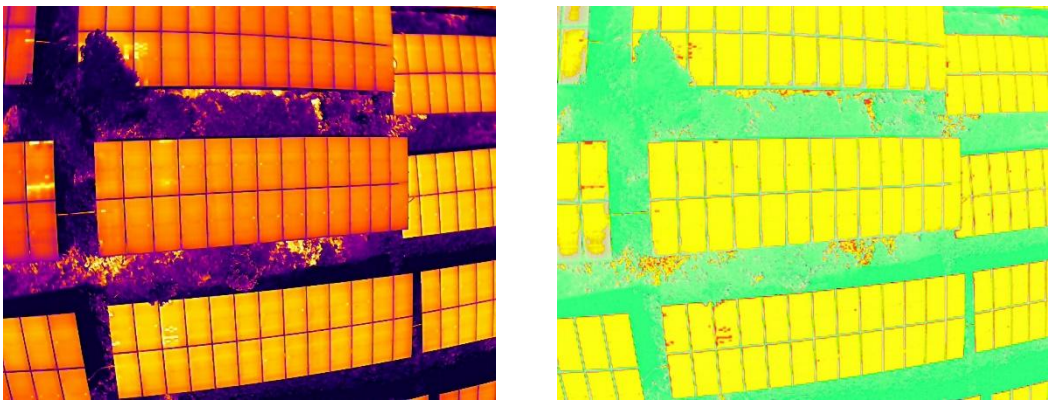
根据 RGB 颜色空间转换成 HSV 颜色空间的公式（3-2）所示，其中亮度 V 为规范化后计算得到的 RGB 值最大值。与此同时，假设其中 $Max = max(R,G,B), Min = min(R,G,B)$。其转换公式如下：

$$S = Max - Min$$

$$V = Max$$

$$H = \begin{cases} 0\left(\text{if } Min = Max\right) \\ 60 \cdot \dfrac{G-R}{Max-Min} + 60\left(\text{if } Min = B\right) \\ 60 \cdot \dfrac{B-G}{Max-Min} + 180\left(\text{if } Min = R\right) \\ 60 \cdot \dfrac{R-B}{Max-Min} + 300\left(\text{if } Min = G\right) \end{cases} \tag{3-2}$$

将图像从 RGB 转换为 HSV 图像，计算机随之存储的 HSV 转换图像。得到的结果光伏板主体区域显示为黄色，背景部分显示为绿色，转换后结果如图 3-4(b)所示。



(a) RGB 原图　　(b) HSV 转换图

图 3-4 HSV 转换结果图像

从图 3-4(b)中可以看出，转换后的结果图中光伏板与背景区域实现分离，并且在缺陷部分呈现红色，保留了缺陷特征，并不影响后续的缺陷检测。

（3）图像校正与主体分割

从图 3-4(a)中可以看出，由于相机拍摄角度与光伏板安装姿态问题，光伏板图像中会出现一定的歪斜，需要对图像进行一定的校正，

中国知网 https://www.cnki.net

减小光伏板歪斜对后续的分割带来的影响。霍夫线检测（Hough Line Transform）是一种用于从图像中提取线条的技术，广泛应用于图像分析和计算机视觉中，适用于环境中存在多种干扰但需要精确检测直线的场景。

霍夫线检测[52,53]的基本思想是将图像空间中的特征点映射到参数空间来实现，并在参数空间中寻找满足直线方程的参数集合。每一条直线都可以由两个参数描述，通常使用极坐标中的ρ（距离原点的垂直距离）和θ（从 x 轴到线的角度）来表示。将每个边缘点映射到参数空间。对于图像中的每一个点(x,y)，按照霍夫变换[54]公式（3-3）考虑所有可能的θ值，并计算对应的ρ:

$$\rho = x\cos(\theta) + y\sin(\theta) \tag{3-3}$$

线检测完成后，根据得到的θ值，将图片旋转θ以此校正图像。得到的矫正图像通过颜色阈值分割和 Canny 边缘检测算法的结合，将光伏板的主体区域从图像中分割出来，这样做的目的是将光伏板与背景区域分割，减小背景区域对后续缺陷检测算法的影响,分割结果如图 3-5 所示。

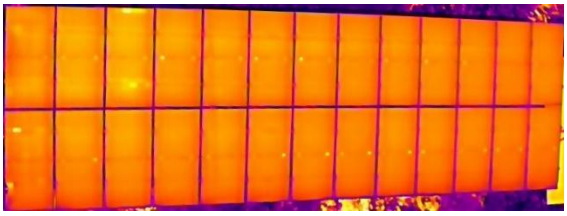


图 3-5 图像校正分割结果

从图3-5结果图中可以看出，算法将一块完整的光伏板从图3.2(d)中分割了出来，并且对于光伏板出现的歪斜进行了校正，但由于拍摄过程中出现的透视畸变问题仍无法解决。

3.3.3 形态学处理

形态学操作主要包括膨胀、腐蚀、开运算和闭运算[55]，形态学操作通常应用于二值图像，但也可以扩展到灰度或彩色图像。膨胀和腐蚀是两种操作相反的方法[56]，膨胀操作如公式（3-4）所示。其中，B是结构元素，通常为一个小的矩阵。

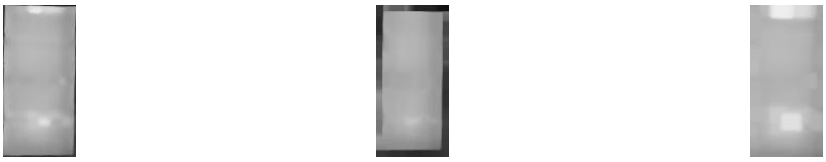
中国知网　https://www.cnki.net

$$(I \oplus B)(x,y) = \max_{(m,n)\in B} I(x-m, y-n) \tag{3-4}$$

膨胀操作会扩大图像中的白色区域，用于填充图像缺失的部分。在执行膨胀时，将结构元素与图像进行卷积，如果结构元素覆盖的区域内至少有一个像素值为 1，则输出图像中对应位置的中心像素被赋值为 1。腐蚀操作与膨胀相反，如公式（3-5）所示，腐蚀用于缩小图像中的白色区域。在进行腐蚀操作时，只有当结构元素与图像的对应部分完全对应时，输出图像的中心像素点才为 1。

$$(I \ominus B)(x,y) = \min_{(m,n)\in B} I(x+m, y+n) \tag{3-5}$$

在实验过程中，本文选取了光伏板中带有缺陷部分的某一块电池片，如图 3-6(a)所示。缺陷部分连通域并不是像素值一致，很难检测到缺陷所有位置，所以需要先对缺陷部分进行形态学操作，以便后续检测。将含有缺陷的电池片进行二值化，分别对其进行腐蚀、膨胀，结果分别如图 3-6(b)、3-6(c)所示。



(a) 含缺陷电池片　　(b) 腐蚀操作结果　　(c) 膨胀操作结果

图 3-6 形态学操作结果

由实验结果可以看出，膨胀操作通过增加图像中前景物体的大小来增强特定特征，这使得图像中的小面积缺陷变得更加明显和容易识别。相对地，腐蚀操作通过缩小图像中的前景物体来弱化特征。在处理带有缺陷的光伏板图像时，腐蚀弱化了光伏板带有的小噪声和细微缺陷，但因为细微缺陷也会影响到整块光伏板的发电效率，所以本文不能放弃对细微缺陷的检测。因此，在后续本文只对图像进行膨胀操作，不进行腐蚀操作。

3.4 缺陷区域特征与点特征的检测与识别

目前已有的的光伏板检测算法大多利用红外图像中缺陷的亮度或梯度进行检测与分类，且很多阈值都是手动设置，普适性较低。鉴于此，本文提出了一种基于区域特征与点特征的光伏板缺陷检测算法。

中国知网 https://www.cnki.net

该算法在无数据标注样本的情况下，可以结合区域特征（例如区域亮度、区域对比度等）与点特征（例如梯度强度、边缘平均梯度等），使得算法不仅能够检测到缺陷位置，而且能够判断出缺陷类型。

3.4.1 缺陷特征提取

本算法检测和识别的光伏板缺陷主要针对光伏板表面出现的阴影遮盖和电气工艺中焊接不正确或局部过热形成的热斑进行检测[57]。阴影遮盖在红外图像上多表征为边缘不规则，内部较暗(即缺陷内部像素平均值较低)；热癍缺陷在红外图像上多表现为边缘不规则，呈斑点状，面积较小，内部高亮(即缺陷内部像素平均值较高)；两种缺陷的边缘部分梯度强度均大于正常区域的梯度强度。

（1）区域特征提取

对于每个光伏板图像，将图像分块成固定大小（如 32×32）的小块区域，逐块提取区域的特征。本文将对 ROI 区域计算其区域亮度均值、区域亮度标准差、热斑对比度、阴影对比度四个值，以下将给出它们的计算公式：

区域亮度均值是用于判断该区域的整体发光、发热强度，若存在热斑区域则通常亮度较高，阴影区域亮度较低，如公式（3-6）所示，其中，N 是 ROI 区域内的像素总数。

$$L_{\text{mean}} = \frac{1}{N} \sum_{(x,y)\in \text{ROI}} I(x,y) \tag{3-6}$$

区域亮度标准差是用于衡量区域的亮度分布是否均匀，用于识别非均匀亮度分布区域，进一步减小漏检概率，如公式（3-7）所示。

$$L_{\text{std}} = \sqrt{\frac{1}{N} \sum_{(x,y)\in \text{ROI}} (I(x,y) - L_{\text{mean}})^2} \tag{3-7}$$

热斑对比度用于判断此区域是否存在热斑缺陷，与整张光伏板图像归一化对比，值越大，越可能判定为热斑，如公式（3-8）所示，其中，μ、σ是全图亮度均值与标准差，当 $C_{hot}>k$（k 取 1.0-1.5）时，则为潜在热斑。

中国知网　https://www.cnki.net

$$C_{hot}=\frac{L_{mean}-\mu}{\sigma} \tag{3-8}$$

阴影对比度是用于判断此区域是否存在阴影遮盖，如公式（3-9）所示，若 C_{shadow}>1.0 则可能为阴影区域。

$$C_{\text{shadow}}=\frac{\mu-L_{\text{mean}}}{\sigma} \tag{3-9}$$

（2）点特征提取

对于光伏板图像的点特征提取主要计算特征点的梯度幅值、区域边缘平均梯度等。这些特征能够在区域特征的基础上进一步区分缺陷的大小、类型，减少因为背景干扰带来的误检，以下将给出它们的计算公式。

梯度幅值用于判断是否存在缺陷，当有缺陷时，缺陷边缘梯度往往较高，如公式（3-10）所示。

$$G_x=\frac{\partial I}{\partial x},\quad G_y=\frac{\partial I}{\partial y},\quad G(x,y)=\sqrt{G_x^2+G_y^2} \tag{3-10}$$

区域边缘平均梯度是用于判断区域边界是否清晰，光伏板边缘与背景的差异较大，边界较为尖锐，而热斑、阴影的边界则往往模糊。该值能够辅助判断检测到的梯度较大区域是光伏板边界还是缺陷区域，如公式（3-11）所示，其中 M 是边界像素数量，可利用该值获取轮边界。

$$G_{\text{edge}}=\frac{1}{M}\sum_{(x,y)\in\text{boundary}}G(x,y) \tag{3-11}$$

3.4.2 构建特征向量

缺陷特征提取后，算法只是提取到了缺陷原始语义特征，这些特征只是图像中局部或像素的统计与结构现象，还不能被机器很好的“理解”。因此，本文需要将缺陷特征提取得到的感知信息转为数值向量，对每个候选区域构建一个特征向量 *Ipv*。该向量会存储以下字段：区域亮度均值 L_{mean}、区域亮度标准差 L_{std}、全图亮度均值μ、全

中国知网 https://www.cnki.net

图亮度标准差σ、与全图亮度均值的差值 L_g、区域最大亮度 L_{max}（用于定位热斑中心）、热斑对比度 C_{hot}、阴影对比度 C_{shadow}、梯度幅值 G、区域边缘平均梯度 G_{edge}、区域面积 S、边界像素数量 M（可用于获取边界的轮廓），如图 3-7 为特征向量 Ipv 的结构。

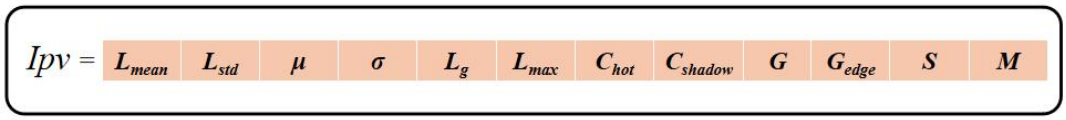


图 3-7 特征向量 Ipv 结构

由于特征向量 Ipv 中每个特征值的数值范围差异较大，例如亮度的范围是[0-255]，而梯度比例是[0-1]，区域面积范围不定。因此，为了不让某个特征主导分类边界，采用公式（3-12）进一步对特征尺度进行归一化操作，得到最终的特征向量 Ipv。其中，μ是该特征在所有样本中的均值，σ是该特征的标准差。

$$x' = \frac{x - \mu}{\sigma} \tag{3-12}$$

特征向量 Ipv 的构建使得图像从多像素甚至百万像素数直接变成了一个多维向量。构建 Ipv 特征向量既提取得到了高维表达的关键信息，压缩了图像的冗余数据，加速计算过程，而且把难以直接识别的光伏板图像特征转变成了有意义的统计数据和结构指标。对于不同尺度的缺陷，多维的特征向量也能够保存不同尺度的缺陷特征，便于后续算法对缺陷的识别与分类，增强算法对不同尺度的检测能力。

3.4.3 光伏板缺陷检测与识别

计算出特征向量 Ipv 后，本文就可根据其中包含的字段进行检测与分类。例如当梯度幅值较大，区域边缘平均梯度不高（排除光伏板边缘影响）区域内的亮度异常等字段的表现，则将该 ROI 区域判定为可能存在缺陷；之后根据热斑对比度和阴影对比度等字段进行热斑和阴影的分类；最后根据区域面积、边界像素数量等字段找出缺陷的位置以及范围，以此完成缺陷的检测和分类。

对于获得的特征向量 Ipv，传统的人工阈值判断由于特征之间的复杂关系难以进行手动建模。在对于比较各个特征值时，若根据经验

中国知网　https://www.cnki.net

手动设置阈值，可能只适用于部分图像数据集，而换一批数据集则可能导致误检、漏检等情况的发生。人工规则也难以量化结果置信度和在最终的检测结果图上难以完成可视化边界处理。

分类器则能够自动拟合这种复杂的边界关系，建立映射模型，学习样本间的统计规律。这使得分类器具备了跨样本、跨场景的适应能力，并且，分类器能够对置信度筛选，输出概率和得分，有助于后续可视化处理。因此，对于光伏板缺陷分类，本文后续将采用分类器去进行实验。

（1）SVM 分类器

支持向量机（SVM）是一种基于统计学习理论的监督学习算法，广泛应用于分类与回归任务中。SVM 的核心思想是通过在特征空间中构建一个最优的超平面，以最大化不同类别样本之间的间隔，从而实现高精度的分类判别。在二分类问题中，SVM 寻找最靠近边界的那一部分样本点作为“支持向量”，它们对最终超平面的构成起决定性作用，因而 SVM 模型具有较好的可解释性与鲁棒性。

通过提前构建的光伏板特征向量，SVM 可以构建出一条高效、清晰、具有泛化能力的分类边界，从而实现高准确率的光伏板缺陷识别。图 3-8 为 SVM 的示意图。

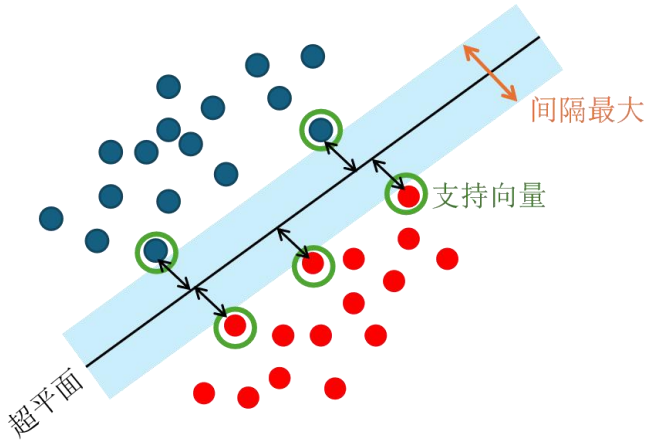


图 3-8 SVM 示意图

（2）随机森林

随机森林（Random Forest）是一种集成学习方法，属于基于决策树（Decision Tree）的 Bagging 集成策略。其核心思想是通过构建多个决策树，并将它们的预测结果进行集成（投票或平均），从而实现

中国知网 https://www.cnki.net

更强的分类、回归或特征选择能力。相较于单棵决策树容易过拟合的问题，随机森林通过引入“随机性”有效提高了模型的泛化能力与鲁棒性。它的两个关键机制包括：一是在训练每棵树时，使用 Bootstrap 方法（有放回抽样）从原始训练集采样生成新的子集；二是在每个树节点的划分过程中，从特征集中随机选择一个子集来决定最佳划分特征。

在光伏板缺陷检测任务中，随机森林适用于基于光伏板特征向量的分类场景。随机森林能提供每个特征对分类任务的重要性评估，这对于后续的特征优化与模型可解释性分析具有极大帮助，图 3-9 为随机森林的示意图。

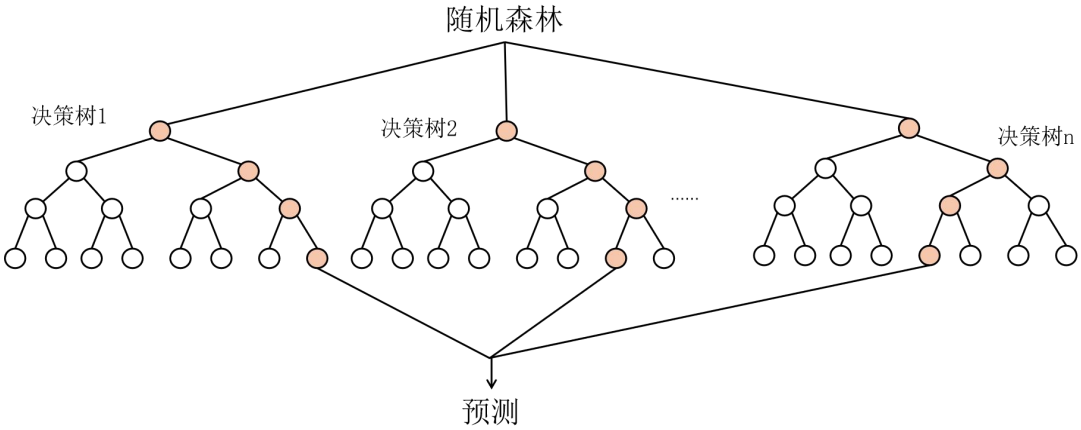


图 3-9 随机森林示意图

本文从光伏板数据集中挑选出 400 张图像，其中 100 张为无缺陷的光伏板图像，300 张为存在缺陷的光伏板图像，将其中 200 张有缺陷的数据集作为训练集，50 张用以验证，50 张划分为测试集。采用滑窗法提取缺陷特征，为了避免窗口太小导致计算开销过大和窗口太大导致不能完全提取缺陷特征，本文分别设置窗口大小为 64×64、96×96 和 128×128 分别采用 SVM 进行测试，采用推理速度表示算法对单个样本进行推理所需的时间。

表 3-1 不同窗口大小实验结果

窗口大小	准确率（%）	误检率（%）	推理速度（ms）
64×64	76.01	10.9	11
96×96	75.63	9.2	8
128×128	72.25	11.6	6

中国知网　https://www.cnki.net

由表 3-1 所示，虽然使用 64×64 的窗口使得准确率略高于使用 96×96 的准确率，但推理速度明显升高，而使用 128×128 窗口大小的算法准确率较低，因此，本文后续采用 96×96 的窗口大小，步长为 48 进行分类。

表 3-2 为采用随机森林和 SVM 对光伏板图像的预测结果，并且本文选取了部分预测结果进行对比分析。

表 3-2 预测实验结果

方法	准确率（%）	误检率（%）	热斑（个）	阴影（个）
SVM	75.63	9.2	1230	41
随机森林	72.66	11.3	1130	50

可以看到，对比 SVM 和随机森林的预测结果，SVM 的准确率要高于随机森林的准确率，造成这一结果的原因是光伏板的边界较为明显，SVM 相较于随机森林能够更好地适应复杂边界问题，因此误检率会低于随机森林。并且，随着特征维度的增加，随机森林的特征处理能力会随之下降，造成准确率的下降。因此，后续本文将采用 SVM 分类器进行光伏板缺陷检测任务，图 3-10 为使用 SVM 进行缺陷检测的部分实验结果图，其中，红色圈出的是热斑，蓝色圈出的是阴影。

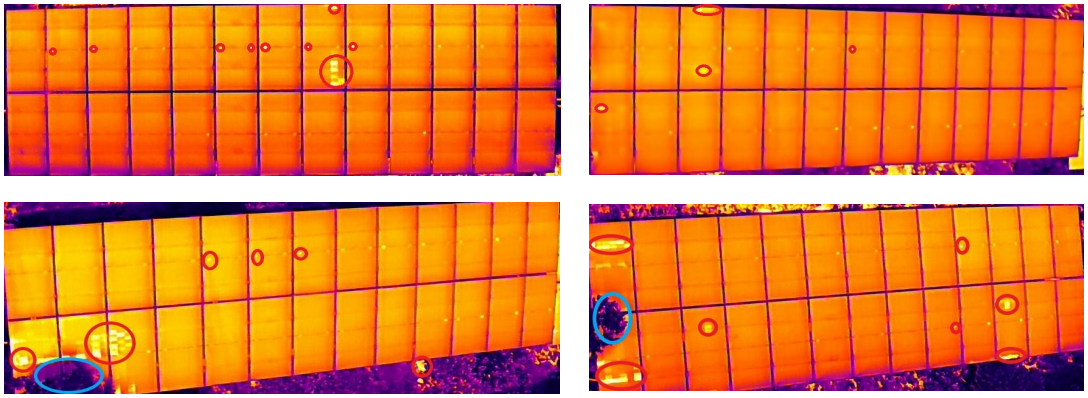


图 3-10 部分实验结果图

3.4.4 实验对比分析

通过以上几个关键步骤，本章设计的基于区域特征与点特征的光伏板缺陷检测与识别算法能够有效识别缺陷的位置和种类，能够在图片中标记出缺陷的位置。

中国知网 https://www.cnki.net

为了验证算法能够很好地完成光伏板检测与识别任务，本文从拍摄到的数据中抽取了 200 张图片，与其他方法进行对比。Henry[15]通过计算红外图像中的最高温度值和最低温度值进行异常检测，手动设置一个阈值，将区域温度与阈值相比较，温度异常且区域面积占比0.2%及以上时则判定为缺陷。Ali[12]则采用计算 ROI 区域的彩色图像颜色描述符为特征进行检测分类，将他们的算法和本章提出的算法进行对比分析，对比实验结果如下表 3-3 所示。

表 3-3 对比实验结果

方法	准确率（%）	误检率（%）	热斑（个）	阴影（个）
Henry[15]	66.59	13.9	1035	35
Ali[12]	67.55	12.3	1109	38
Ours	75.63	9.2	1230	41

对检测完成的 200 张图片结果进行统计得出，本实验对于光伏板缺陷检测的平均准确率为 75%左右，部分光伏板图像的检测结果较为准确，能把图像的缺陷都检测出来，而有的图像则检测准确率偏低，存在错检、漏检等情况。如图 3-11 所示的检测结果来看，实际图像中有规律排列的亮斑是由于固定光伏板的螺丝钉长期受阳光照射发热导致的，因此不能算作缺陷。并且，红外图的分辨率一般不高，这也会导致缺陷的特征弱化，导致缺陷的特征提取不准确，使得算法检测过程中发生误检，导致误检情况的发生。

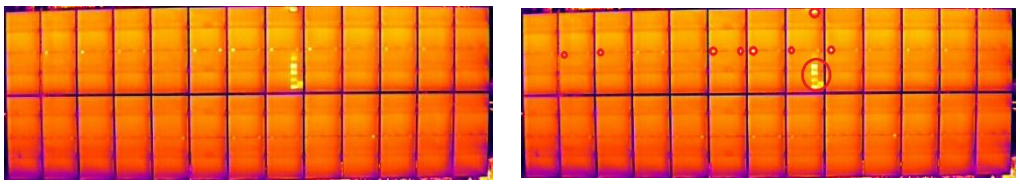


图 3-11 错检结果图

漏检主要由于缺陷梯度强度不高或范围太小，在滤波过程中直接将缺陷过滤掉导致漏检情况的发生。而误检情况则多由光伏板固定部位发热或背景区域的干扰导致。两种情况对于检测结果的准确性都有较大的影响，常常出现漏检、误检等情况的发生。

中国知网　https://www.cnki.net

3.5 本章小结

本章主要提出了一种基于区域特征与点特征的光伏板缺陷检测算法，该算法解决了前期数据量缺失和样本不足的问题。首先输入红外图像后，将图像进行一系列预处理操作，提取缺陷的区域特征与点特征，提出一种新的特征向量用于存储高维缺陷信息转化成的机器可理解的特征值，最后用分类器进行缺陷分类。实验结束后将本章提出的算法与其他算法进行了对比分析，验证了本章提出的算法的准确度和普适性，并且对于多尺度的缺陷，算法也能很好地检测与分类。

中国知网 https://www.cnki.net

第4章 基于改进的UMF-CMGR网络的图像配准融合算法

4.1 引言

仅用红外图像不足以完全表征出缺陷的所有特征信息，需要结合可见光图像的特征，通过融合的特征信息进行缺陷检测。此外，由于采集光伏板红外图像和可见光图像时，相机位置不同会造成光伏板图像尺度变换和位置不一致。为了避免因为视场不同给后续检测带来的影响和红外图像的信息不完整的缺点，提出一种改进的 UMF-CMGR 网络的图像配准融合算法，对光伏板红外与可见光图像配准并融合，增强算法对多源图像缺陷特征的检测能力。

4.2 基于关键点检测的图像配准算法

通过红外相机和可见光相机同步拍摄光伏板图像时，因为两类相机的成像方式、焦距、视场角不同的原因，拍摄到的光伏板图像往往存在畸变或位置不相同的情况。因为歪斜等原因，算法无法排除光伏板背景区域带来的影响，对于融合图像来说，错位情况的发生也会影响最终的融合结果。

为了说明图像配准网络的必要性，本文提出一种基于关键点检测的光伏板图像配准方法，有以下几个关键步骤：

（1）Harris 角点检测[58]，基于图像局部窗口的差异函数的自相关矩阵来测定角点。Harris 角点检测的核心思想是寻找图像中灰度变化明显的地方。当窗口在图像的角点处移动时，无论窗口移动方向如何，窗内的像素灰度值都会发生显著变化。

对于每一个像素点，构造一个结构张量（也称为自相关矩阵），该矩阵是梯度的外积，经过高斯函数 G 加权，其结构张量 M 如公式（4-1）所示。

$$M = G*\begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \tag{4-1}$$

用结构张量 M 计算每个像素点的角点响应函数 R,公式如（4-2）所示。

中国知网　https://www.cnki.net

$$R=\det(M)-k\cdot\left(\operatorname{trace}(M)\right)^2 \tag{4-2}$$

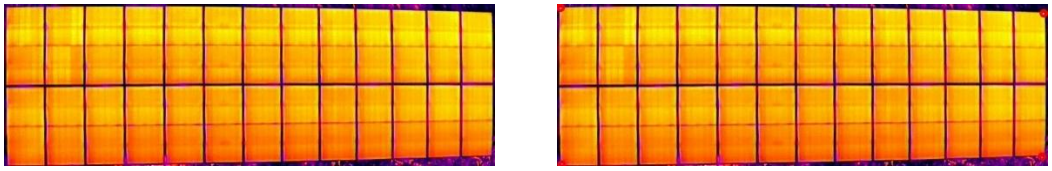
其中：

$\det(M)=\lambda_1\lambda_2,\operatorname{trace}(M)=\lambda_1+\lambda_2$；

λ_1和λ_2 ——M的特征值；

k—— 经验常数（通常取 0.04 到 0.06 之间）。

R 值较高的点被认为是角点，具体地，可以设置一个阈值 T，当 $R>T$ 时，该点被认为是角点。此外，通常还会应用非极大值抑制来确保检测到的角点是局部最大值，这有助于减少邻近点的多次检测。对光伏板的角点检测结果如图 4-1 所示。



(a) (b)

图 4-1 角点检测结果

其中 4-1(a)为原图，4-1(b)为角点检测结果，图中红色圈出部位即为光伏板最接近图像几何顶点的角点，而四个角点区域内的部分即为光伏板主体部位。

（2）透视映射[59]也称为透视变换，用于模拟或纠正由于观察角度造成的图像畸变。这种变换能够将图像中的一个平面区域映射到另一个平面上，同时保留透视效果，即远处的物体看起来比近处的物体小。透视映射可以根据四对对应点（即图像中一个平面上的四个点与目标平面上的四个点）之间的关系来定义。这种映射可以用一个 3×3 的变换矩阵来描述，该矩阵能够将一个平面上的点通过透视投影变换到另一个平面上。透视变换可以通过公式（4-3）表示。

$$\begin{bmatrix}x'\\y'\\w'\end{bmatrix}=\begin{bmatrix}h_{11}&h_{12}&h_{13}\\h_{21}&h_{22}&h_{23}\\h_{31}&h_{32}&h_{33}\end{bmatrix}\begin{bmatrix}x\\y\\1\end{bmatrix} \tag{4-3}$$

其中：

(x,y)—— 原始图像中的点；

(x',y')—— 变换后的图像中的点；

中国知网 https://www.cnki.net

h_{ij} —— 变换参数；

w' —— 齐次坐标系中的缩放因子。

为了从上述齐次坐标得到实际坐标，本文需要进行归一化，归一化公式如公式（4-4）所示。

$$x' = \frac{x'}{w'}, y' = \frac{y'}{w'} \tag{4-4}$$

透视变换矩阵通常通过匹配四个点在原始图像和目标图像中的位置来计算。这些点的选择应该准确，并且它们不应共线，以避免退化情况，即无法求解透视变换矩阵。

从图 4-1(b)结果所示来看,图像存在因为相机拍摄出现的透视畸变，这种畸变是由拍摄角度对于被摄物体的相对位置造成的。当拍摄时不是正对物体中心，或者当使用广角镜头从近处拍摄较大物体时，最常见。本小节采用 Harris 角点检测算法检测出光伏板的四个角点，通过预设一个矩形框的四个顶点，将两组点互相对应，通过透视映射解决算法解决出现的透视畸变现象，其流程如图 4-2 所示。

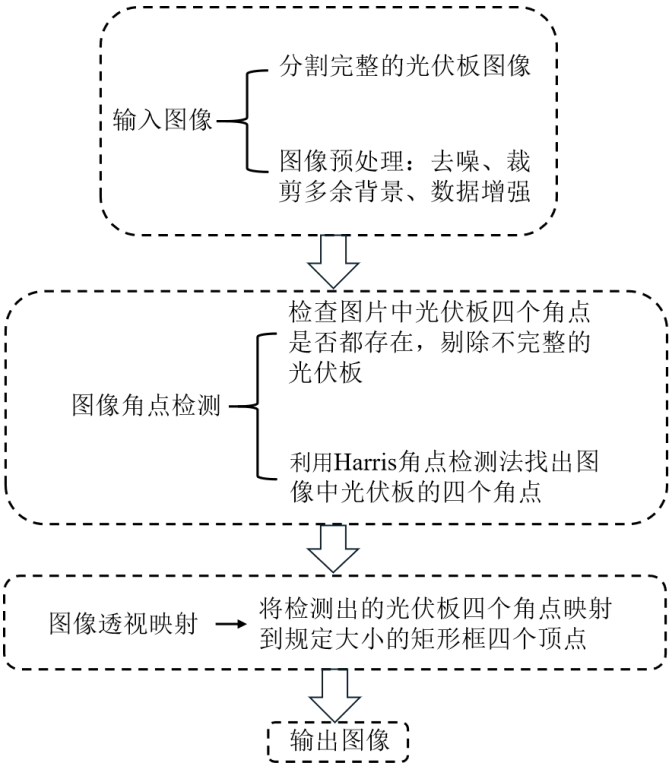
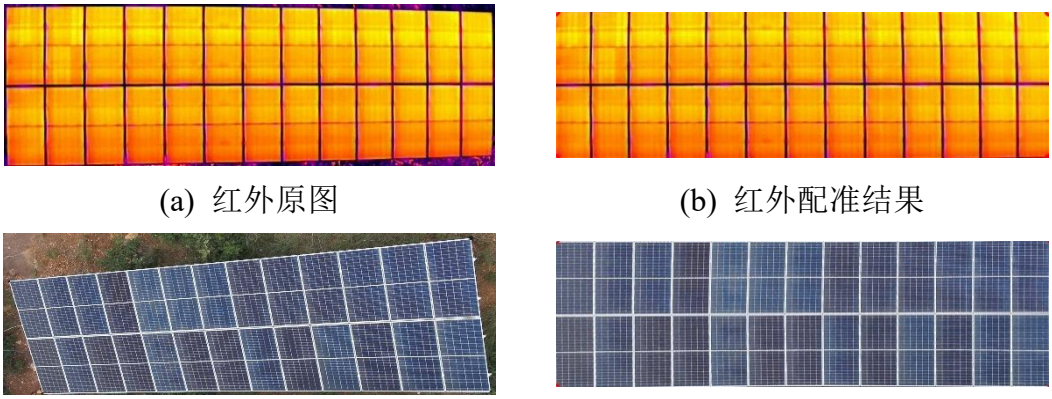


图 4-2 基于关键点检测的对齐流程

通过以上流程，可以一定程度上将光伏板红外图像和可见光图像中出现的透视畸变问题解决，并将图像中多余的背景去除，配准结果

中国知网　https://www.cnki.net

如图 4-3 所示为较好实现光伏板图像的配准。



(a) 红外原图　(b) 红外配准结果

(c) 可见光原图　(d) 可见光配准结果

图 4-3 配准结果

然而，光伏板因其角点重复模式较多，背景区域影响较大，使用基于关键点检测的图像配准方法进行配准会因为重复的角点特征或光伏板缺少最边缘角点，导致语义对齐出现一系列错位、变形等原因，图 4-4 展示了配准失败的结果。

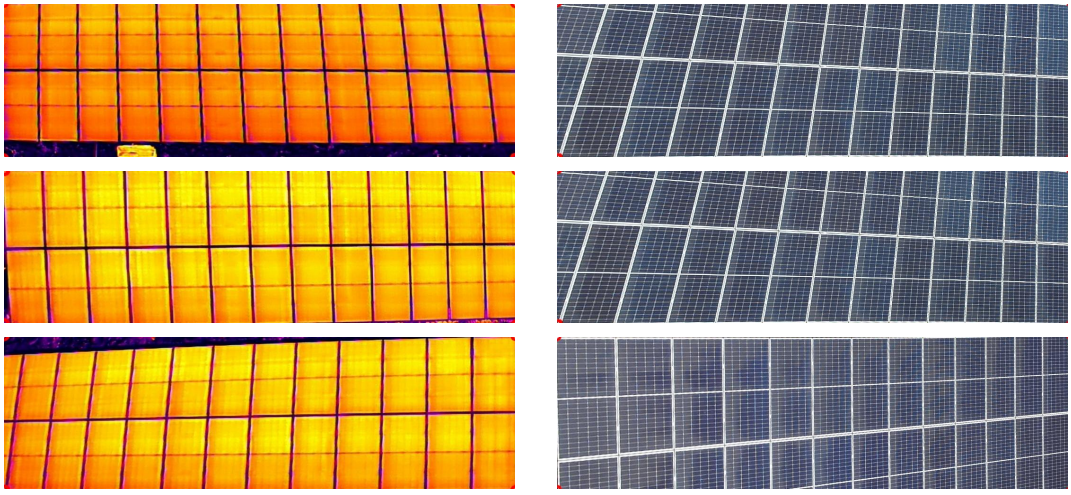


图 4-4 配准失败结果

由图 4-4 所示，只采用基于关键点检测的方法进行配准，会出现大量的错误配准结果，这无论是对后续的图像融合还是光伏板缺陷检测，都会带来较大影响。并且，角点检测通常根据经验设定系数，这只能针对同一批次的光伏板，面对多批次光伏板，基于关键点检测的配准很难得到一个好的配准结果。因此，需要一个根据光伏板特征，实现端到端配准的网络，无需人工干预也能有较好的配准融合结果。

又因为光伏板图像在拍摄过程中很难得到一个融合目标图像，因此，本文提出一种改进的 UMF-CMGR 网络的图像配准融合算法，避

中国知网 https://www.cnki.net

免了因为没有目标融合图像而难以训练光伏板红外与可见光图像融合网络的问题。

4.3　基于跨模态图像生成与配准的融合网络

UMF-CMGR[60]是一种基于跨模态图像生成与配准的无监督错位红外与可见光图像融合网络。该网络通过可见光图像生成伪红外图像，用于减少模态差异，通过自动学习图像之间的空间对应关系完成配准，不需要人工配准的配准标准图（Ground Truth），通过网络自动学习融合规则，不依赖外部标注。

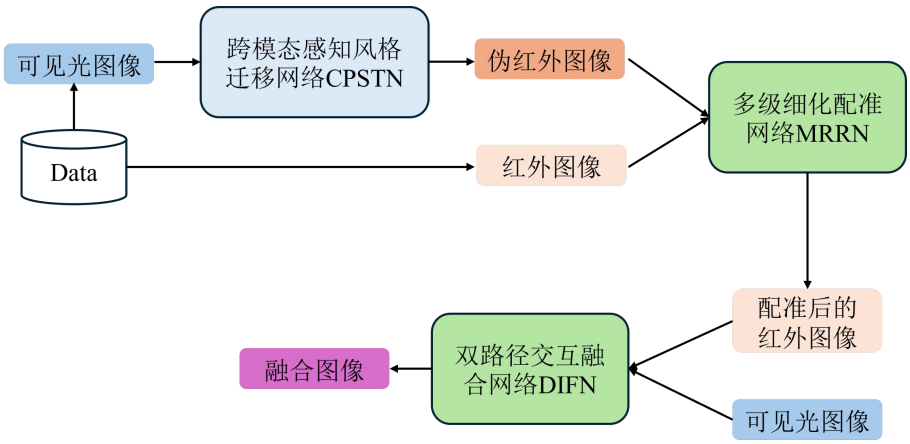


图 4-5 UMF-CMGR 网络结构示意图[60]

图 4-5 为 UMF-CMGR 的网络结构图，具体的网络结构见参考文献[60]。UMF-CMGR 实现无监督融合的核心主要由三个网络完成：跨模态感知风格迁移网络（CPSTN），多级细化配准网络（MRRN）和双路径交互融合网络（DIFN），下面将主要介绍三个主要模块。

跨模态感知风格迁移网络（CPSTN）：CPSTN 的任务是将可见光图像转化为伪红外图像。这个过程不仅是图像的转换，减少红外和可见光图像之间的模态差异，同时保留了红外图像的几何结构特征，从而有助于后续处理。由图 4-5 所示，CPSTN 采用了类似 UNet 的生成器结构，其底部由 9 个 ResNet 块组成，能够在不同的尺度上提取图像特征。

CPSTN 通过无监督的方式，利用生成器将可见光图像映射到伪红外图像，期间红外图像用于指导训练，不直接参与监督损失，为了使生成的伪红外图像更接近真实的红外图像，采用了感知风格损失来

中国知网　https://www.cnki.net

控制图像的，感知风格损失由感知损失和风格损失组成，感知损失如公式（4-5）所示，风格损失如公式（4-6）所示，其中，ψ_j是 VGG-19 的第 j 层特征提取函数。

$$\begin{aligned}\mathcal{L}_{pcp}^{\psi_j} &= \| \psi_j(I_{vis}) - \psi_j\left(G_B\left(G_A(I_{vis})\right)\right)\|^2 \\ &+ \| \psi_j(I_{ir}) - \psi_j\left(G_A\left(G_B(I_{ir})\right)\right)\|^2,\end{aligned} \tag{4-5}$$

$$\begin{aligned}\mathcal{L}_{sty}^{\psi_j} &= \omega_j \| \mathcal{G}_{\psi_j}(I_{vis}) - \mathcal{G}_{\psi_j}\left(G_B\left(G_A(I_{vis})\right)\right)\|^2 \\ &+ \omega_j \| \mathcal{G}_{\psi_j}(I_{ir}) - \mathcal{G}_{\psi_j}\left(G_A\left(G_B(I_{ir})\right)\right)\|^2,\end{aligned} \tag{4-6}$$

最终的感知风格损失如公式（4-7）所示，其中λ_p通常设置为 1.0，λ_s一般设置为 100。

$$\mathcal{L}_{pst} = \lambda_p \mathcal{L}_{pcp} + \lambda_s \mathcal{L}_{sty} \tag{4-7}$$

并且，在训练 CPSTN 过程中，两个循环路径之间采用跨路径正则化损失函数，加强对偶路径间的边缘结构一致性，包含内容一致损失和边缘结构损失如公式（4-8）所示。

$$\begin{aligned}\mathcal{L}_{con} &= \| I_{\tilde{ir}} - I_{\hat{ir}} \|_1 + \| I_{\tilde{vis}} - I_{\hat{vis}} \|_1, \\ \mathcal{L}_{edge} &= \| \nabla I_{\tilde{ir}} - \nabla I_{\hat{ir}} \|_{char} + \| \nabla I_{\tilde{vis}} - \nabla I_{\hat{vis}} \|_{char}\end{aligned} \tag{4-8}$$

最终的正则化损失如公式（4-9）所示，其中，λ_c和λ_e设置为 8。

$$\mathcal{L}_{cross} = \lambda_c \mathcal{L}_{con} + \lambda_e \mathcal{L}_{edge} \tag{4-9}$$

多级细化配准网络（MRRN）：MRRN 的目标是通过计算变形场将伪红外图像和真实红外图像进行对齐，从而进行图像配准。该过程需要精确地捕捉和估计图像的空间变形，并使得配准后的图像在几何结构上尽可能一致。由图 4-5 所示，MRRN 通过多级特征提取和变形场预测，从粗到细逐步优化变形场。该网络包含了一个共享的多级特征提取模块（SM-FE），以及两个粗到细的变形场估计模块（C2F-DFE）。

MRRN 在特征空间中采用双向相似性损失来约束红外图像与伪红外图像的配准，如公式（4-10）所示，用平滑损失防止过渡型变，如公式（4-11）所示。

$$\mathcal{L}_{sim}^{bi} = \| \psi_j(I_{ir}^{reg}) - \psi_j(I_{\tilde{ir}}) \| + \lambda_{rev} \| \psi_j(\phi \circ I_{\tilde{ir}}) - \psi_j(I_{ir}) \|_1 \tag{4-10}$$

$$\mathcal{L}_{\text{smooth}} = \| \nabla \phi \|_1 \tag{4-11}$$

中国知网 https://www.cnki.net

最终的配准损失如公式（4-12）所示，由双向相似性损失和平滑损失组成，其中λ_{sm}一般设置为 10。

$$\mathcal{L}_{\text{reg}} = \mathcal{L}_{sim} + \lambda_{sm}\mathcal{L}_{smooth} \tag{4-12}$$

双路径交互融合网络（DIFN）：DIFN 的任务是将配准后的红外图像和可见光图像进行融合，得到一幅最终的融合图像。DIFN 采用了双路径结构，一条路径处理红外图像，另一条路径处理可见光图像。通过交互融合模块（IFM），选择性地融合红外图像和可见光图像的特征，因为其特有的跨通道注意力机制，DIFN 会自动分配每一路输入的重要性。

DIFN 引入了多尺度结构相似性损失，如公式（4-13）所示，用以衡量融合图像和多源图像（红外图像和可见光图像）之间的结构相似性，强制融合图像在结构层面上同时接近两个源图像，能够避免融合图像的模糊、重影。

$$\mathcal{L}_{ssim}^{ms} = (1 - SSIM(I_{fus}, I_{ir}^{reg})) + (1 - SSIM(I_{fus}, I_{vis})) \tag{4-13}$$

引入梯度联合损失，如公式（4-14）所示，取红外和可见光图像的最大值作为参考，让融合图像的梯度尽可能保留最强的细节。

$$\mathcal{L}_{JGrad} = \| max\left(\nabla I_{ir}^{reg}, \nabla I_{vis}\right), \nabla I_{fus} \|_1 \tag{4-14}$$

引入显著性可视引导损失，如公式（4-15）所示，用以保留关键目标、热源区域，提高目标感知能力，减少目标模糊或遗漏。

$$\begin{aligned} &\omega_{ir} = S_{f_{ir}} / \left(S_{f_{ir}} - S_{f_{vis}}\right), \omega_{vis} = 1 - \omega_{ir}, \\ &\mathcal{L}_{svs} = \| \left(\omega_{ir} \otimes I_{ir}^{reg} + \omega_{vis} \otimes I_{vis}\right), I_{fus} \|_1, \end{aligned} \tag{4-15}$$

最终的融合损失由以上几个损失函数组成，如公式（4-16）所示。

$$\mathcal{L}_{fus} = \lambda_{ssim}\mathcal{L}_{ssim}^{ms} + \lambda_{JG}\mathcal{L}_{JGrad} + \lambda_{svs}\mathcal{L}_{svs}, \tag{4-16}$$

以上损失函数中包含了多个多项加权系数，它们的选择首先根据参考文献[60]中获得这些系数的初始值，之后根据数据集的训练效果，逐步调整，最终筛选出在验证集性能最佳的一组参数。通过以上网络结构和损失函数设计的协同作用，使得 UMF-CMGR 无需依赖对标签进行训练，完成对多源图像的无监督配准与融合。

中国知网　https://www.cnki.net

4.4 基于改进的 UMF-CMGR 网络的光伏板图像融合

4.4.1 改进的特征提取网络

C2F-DFE 是 MRRN 中提出的一种模块机制，作用是改进图像或视频理解任务中的特征提取过程，C2F-DFE 的核心思想包括先抓取全局粗略结构，在逐渐细化到局部关键细节，结构图如图 4-6 所示，其中，M_C 是粗略变形场估计模块，主要利用低分辨率特征快速估计初始的变形场，而 M_R 是精细变形场估计模块，在上一步粗略估计的基础上，进一步细化变形场，提高配准精度。

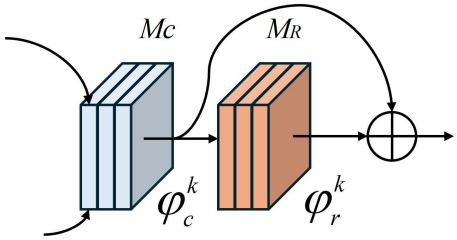


图 4-6 C2F-DFE 结构

C2F-DFE 滤波器权重会根据输入内容动态生成卷积核，使得不同输入可以激活不同的特征响应，注重通道和权重的动态演化，而可变形卷积 DCN[61]注重空间位置的适应性，二者结合可以实现空间与通道的联合适配。

可变形卷积网络是一种在传统卷积神经网络基础上进行改进的网络结构。传统的卷积操作具有固定的感受野和结构，这意味着它们在处理图像中非线性空间变形时可能不够灵活。可变形卷积通过引入额外的偏移量来调整卷积核的位置，使得卷积核能够自适应地对齐输入特征的重要部分，从而更有效地捕获局部特征和复杂的空间变形。可变性卷积操作如图 4-7 所示。

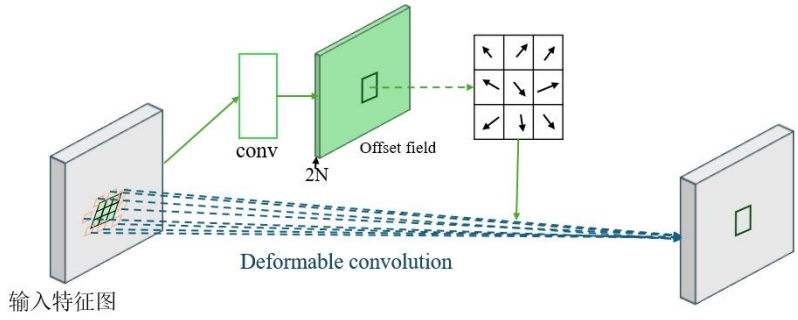


图 4-7 3×3 可变形卷积示意图

中国知网 https://www.cnki.net

在进行卷积操作时，除了学习卷积权重外，还需要学习一个偏移量字段。这个偏移量字段由网络自动学习，用于调整每个卷积核位置的偏移。偏移量通常由一个额外的卷积层生成，这个层专门用于预测每个卷积操作位置的偏移量。对于标准卷积中的每个位置 p_0 和卷积核大小 $K\times K$，偏移量 Δp 由公式(4-17)得出。

$$\Delta p = \mathrm{Conv}(F) \tag{4-17}$$

其中：

F —— 输入特征图；

Conv —— 用于学习偏移量的卷积操作。

对于一个 $K\times K$ 的卷积核，这个卷积层的输出将会有 $2K^2$ 个通道，对应于每个卷积点的 x 和 y 方向上的偏移量。

在标准的卷积操作中，输出特征图的每个位置 $y(p_0)$ 是通过在输入特征图 F 上以 p_0 为中心进行卷积来计算的,如公式（4-18）所示。

$$y(p_0) = \sum_{p_n \in R} w(p_n) \cdot F(p_0 + p_n) \tag{4-18}$$

其中：

R —— 卷积核的空间范围（例如 $R=\{-1,0,1\}^2$ 对于 3×3 卷积核）；

$w(p_n)$ —— 卷积核权重；

p_n —— 卷积核内的相对位置。

本文将 DCN 加入到 C2F-DFE 的精细变形场估计模块 M_R，替换 M_R 中的普通卷积层，图 4-8 为替换之后的网络结构示意图。

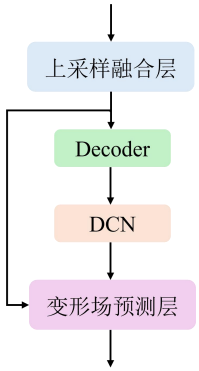


图 4-8 改进的精细变形场估计模块示意图

加入 DCN 模块增强了网络跨模态特征对齐能力和特征表达能力，使得模型能够更灵活地关注边缘和纹理信息。DCN 的引入可以充分保留光伏板图片的细节信息，提高模型对配准边界的对齐精度。

中国知网　https://www.cnki.net

4.4.2 引入 SE 注意力机制

UMF-CMGR 网络中的 DIFN 结构主要由两部分组成，细节注入模块用以提取图像中的特征，特征交互融合模块 IFM 进行融合，IFM 的结构示意图如图 4-9 所示。

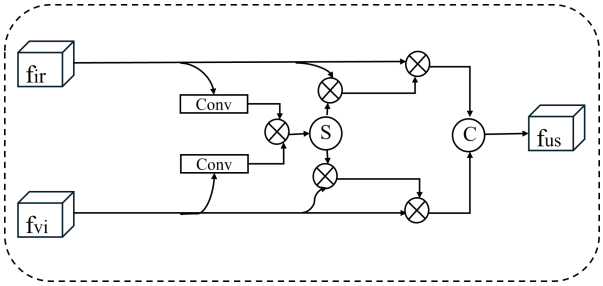


图 4-9 IFM 的结构示意图

本文在 IFM 模块中输入特征之后加入 SE 注意力机制[62]，用以进一步调整各自通道的重要性，SE 注意力机制的核心思想是自适应学习通道权重，抑制不重要的通道，SE 结构图如图 4-10 所示。

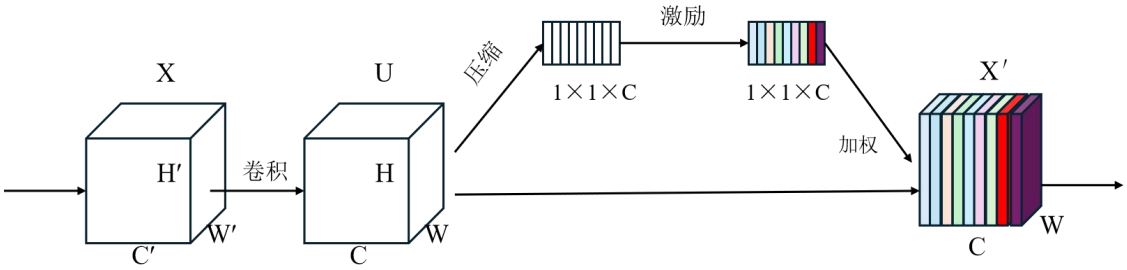


图 4-10 SE 注意力示意图

SE 注意力机制由三部分计算组成：

首先，通道全局信息压缩，SE 注意力通过全局平均池化获取每个通道的全局特征，假设输入特征图(H*W*C)，SE 会将该特征图压缩成一个维度为(1*1*C)的向量，如公式(4-19)所示。

$$z_c = \frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} F_c(i,j) \tag{4-19}$$

其中：

H —— 高度；

W —— 宽度；

z_c —— c 通道的压缩权重。

之后，通道权重学习，SE 注意力通过两个全连接层(FC)、ReLU、

中国知网 https://www.cnki.net

Sigmoid 计算每个通道的权重，第一个 FC 层会减少计算量，提高泛化能力，第二个 FC 层用于恢复通道数，ReLU 激活函数用来增加非线性能力，Sigmoid 函数用于归一化，使最后的权重在[0,1]之间，这些权重反映的是每个通道的重要性，权重计算如公式（4-20）所示。

$$s=\sigma\left(W_2\cdot\delta\left(W_1\cdot z\right)\right) \tag{4-20}$$

其中：

W_1 —— $W_1\in \mathrm{R}^{\frac{C}{r}\times C}$，降维，全连接层 1；

$\delta(\cdot)$ —— ReLU 激活函数;

W_2 —— $W_2\in \mathrm{R}^{C\times\frac{C}{r}}$，升维，全连接层 2；

$\sigma(\cdot)$ —— Sigmoid 函数;

r —— 压缩率。

最后，通道加权，将学习得到的权重应用到原始特征图上，从而对特征图进行重新标定，增强了重要通道，计算公式如（4-21）所示。

$$F_c'=s_c\times F_c \tag{4-21}$$

图 4-11 为改进之后的 IFM 模块示意图。

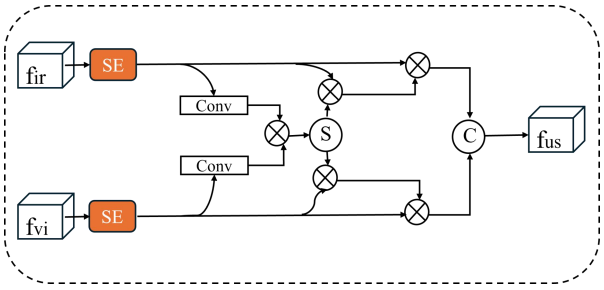


图 4-11 改进的 IFM 结构示意图

SE 注意力通过通道加权机制，抑制非必要特征通道，使得改进后的 DIFN 结构能够更容易捕捉光伏板图像的重要特征，调整融合过程，提高网络最终的融合质量。

4.4.3 光伏板图像配准融合实验

本实验是在基于 Linux 平台，搭建了 Pytorch 的深度学习框架，使用的 Python 版本是 Python3.8，并搭配 Pytorch1.10.0，CUDA11.1 使用，训练过程的具体环境配置如表 4-1 所示，此后的实验都将在本节的实验环境中进行实验。

中国知网　https://www.cnki.net

表 4-1 模型搭建环境配置

名称	配置详情
处理器（CPU）	Intel(R)Core(TM) i7-13700F
显卡（GPU）	NVIDIA GeForce RTX 3090 24G
内存大小	2T

目前，全球最大的光伏电池缺陷异常检测数据集 PVELAD 包含 36543 张具有各种内部缺陷和异构背景的近红外图像，并无给出对应的可见光图像。其他数据集图片数量较少且拍摄清晰度不高，也并未给出对应的可见光图片，对于缺陷具体分类有一定的影响。

因此，本文收集了全国各地包括云南（山陵地区）、湖北（平原地区）具有明显地形差异的两地光伏场站图片共计 5564 张图片，剔除其中拍摄模糊且拍摄不全的光伏板图片，本文的数据集总共包含 5200 张可用图片，其中包含 2600 张红外图片，2600 张可见光图片。

融合完成后，因为改进的 UMF-CMGR 网络带有的协同匹配和引导修正机制，对于一些存在形变的区域可以提供一些精细的修正，去除了大部分背景区域的干扰，但还是无法完全去除光伏板背景区域. 因此，本文采用第三章提到的预处理方法，将融合之后的光伏板图像进行旋转校正，对融合结果进行边缘检测，这样可以确定光伏板区域结果图如图 4-12 所示。

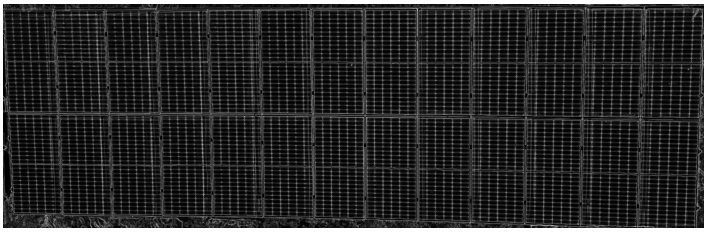


图 4-12 融合结果边缘检测

可以看到，仍然存在部分背景区域，这对后续缺陷检测会有一定影响，但对比融合前，背景区域已经明显变少。此外，一个正常的光伏板图像应该是无畸变、旋转的图像，根据光伏板连接处“十字”较为明显的特征，将十字进行模板匹配，将检测到的十字整齐排列，把十字里面的内容进行透视映射，这样能最大程度因为输出的结果图尺寸相同，用以去除光伏板背景区域的影响。图 4-13 为对融合结果进

中国知网 https://www.cnki.net

行模板匹配的裁剪示意图。

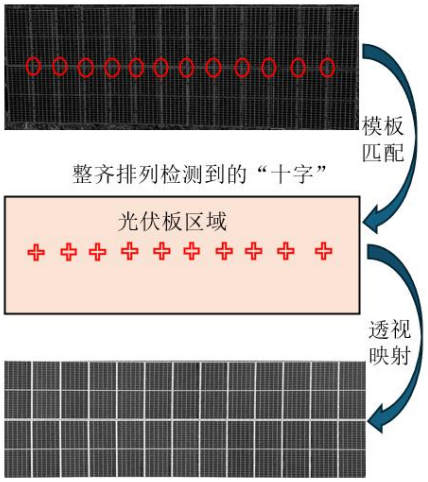
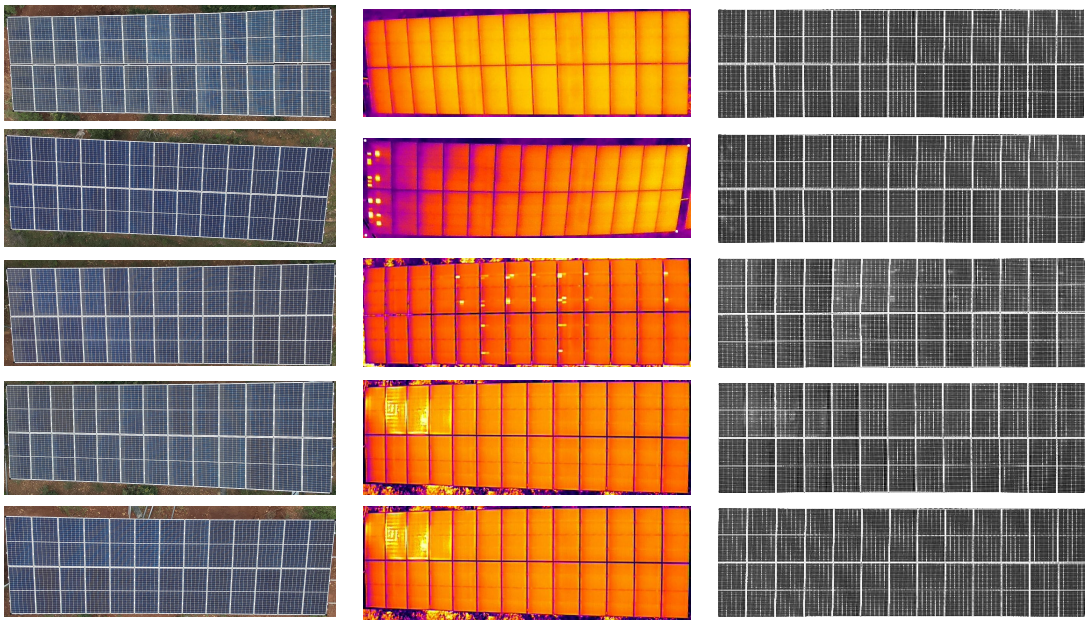


图 4-13 模板匹配裁剪示意图

模板匹配的如公式（4-22）所示。

$$SSD(x,y)=\sum(I(x+i,y+j)-T(i,j))^2 \tag{4-22}$$

将裁剪之后的图像作为改进的 UMF-CMGR 网络的图像配准融合的输出。训练完成后，图 4-14 展示改进之后的网络对光伏板图像的融合结果。可以看到，融合之后的图像不仅保留了可见光图像的细节纹理信息，而且保留了红外图像的温度信息。对于存在的缺陷也保留了缺陷的亮度信息，其次对于拍摄产生的歪斜，图像融合结果向本文展示了改进之后的模型对光伏板图像的融合有较好的完成度。



(a) 可见光图　　(b) 红外图　　(c) 融合结果图

图 4-14 融合结果可视化

中国知网　https://www.cnki.net

（2）融合结果数据分析

为了验证实验融合结果的有效性，本文还设计了一系列指标对图像融合质量的评估，其中包括：

图像熵 *EN*,用于评估图像的信息丰富度，图像的熵越高，说明图像保留的源图像信息越多，计算公式如（4-23）所示, 其中 p 是每个像素值的出现概率。

$$EN = -\sum\left(p\log_2 p\right) \tag{4-23}$$

标准差 *SD*，用于衡量图像像素值相对于平均值的偏差。计算公式如（4-24）所示，其中 x_i 是像素值，μ 是像素值的平均数。

$$SD = \sqrt{\frac{1}{N}\sum(x_i - \mu)^2} \tag{4-24}$$

信息共享度 *ISD*，用于衡量两个图像之间共享的信息量，互信息越高，表示融合图像和源图像的共享信息越多。计算公式如（4-25）所示, 其中 *P(x,y)*是联合概率分布，$p(x)$和 $p(y)$是边缘概率分布。

$$ISD(X,Y) = \sum_{x\in X}\sum_{y\in Y} p(x,y)\log\frac{p(x,y)}{p(x)p(y)} \tag{4-25}$$

图像误差平方 *IES*,衡量两幅图像的差异，如公式（4-26）所示。

$$IES = \frac{1}{N}\sum(I_1 - I_2)^2 \tag{4-26}$$

视觉信息保真度 *VIF*，用于衡量图像相对于输入图像的视觉质量。计算公式如（4-27）所示,其中 s 是不同的尺度，x 表示图像的局部子带系数,C_{sx} 代表原始输入图像在尺度 s 下的小波子带系数, V_{sx} 代表输入可见光图像的子带系数，F_{sx} 是代表融合后的图像在尺度 s 下的小波子带系数，σ_{sx}^2 代表图像噪声的方差。

$$VIF = \frac{\sum_{s\in S}\sum_{x\in X_s} I\left(C_{sx};F_{sx}\mid\sigma_{sx}^2\right)}{\sum_{s\in S}\sum_{x\in X_s} I\left(C_{sx};V_{sx}\mid\sigma_{sx}^2\right)} \tag{4-27}$$

视觉相似度指数 *SSIM*，用于评估图像的相似性，综合亮度、对比度和结构三个值。计算公式如（4-28）所示，其中，μ_x，μ_y 为均值，σ_x,σ_y 为方差，σ_{xy} 为协方差，C_1,C_2 为稳定性常数。

中国知网 https://www.cnki.net

$$SSIM=\frac{\left(2\mu_x\mu_y+C_1\right)\left(2\sigma_{xy}+C_2\right)}{\left(\mu_x^2+\mu_y^2+C_1\right)\left(\sigma_x^2+\sigma_y^2+C_2\right)} \tag{4-28}$$

以上所有评判指标都是基于融合后图像和源图像（可见光和红外图像）的平均求和来得到一个总的指标，这样更能验证算法对于源图像的信息保留能力。

以下是对光伏板图像数据集的融合质量评估，对原 UMF-CMGR 网络、引入可变形卷积的 UMF-CMGR-DCN 网络、改进之后的 UMF-CMGR 网络，分别计算了 EN、SD、ISD、IES、VIF、SSIM，配准融合结果如表 4-2 所示。

表 4-2 光伏板融合结果评估

方法	EN	SD	ISD	IES	VIF	SSIM
UMF-CMGR	6.659	49.398	2.119	1.384	0.764	0.475
UMF-CMGR -DCN	6.755	50.231	2.196	1.413	0.795	0.496
UMF-CMGR-DCN-SE	6.863	51.616	2.285	1.465	0.833	0.522

从表 4-3 结果中可以看出，引入 DCN 后在各项指标上均有所提升，在引入 SE 注意力机制后，改进的 UMF-CMGR 网络对比原网络，EN 提升了 3.1%，SD 提升了 4.5%，ISD 提升了 7.8%，IES 提升了 5.9%，VIF 提升了 9%，SSIM 提升了 9.9%。本文提出的改进的 UMF-CMGR 网络结构在各个指标方面对比原网络都有较好的表现，并且，对于在没有目标图像的情况下，改进的 UMF-CMGR 网络也能很好地完成光伏板红外和可见光图像配准融合任务。

4.4.4 配准融合有效性实验

由于改进的 UMF-CMGR 网络是一个无监督网络，无法证明融合之后的图像是保留了缺陷的主要特征还是弱化了一部分缺陷的特征。因此，本文使用第三章算法对融合后的图像进行缺陷检测，验证配准融合之后的光伏板图像是否有利于缺陷检测与识别任务。为了进一步对比融合图像的效果，本文采用了一种通道替换的图片融合方式，将 RGB 图片的 B 通道（B 通道的可用信息较少）替换成红外图像，之后通过加权融合形成 RGI 图像，用以对比改进的 UMF-CMGR 网络

中国知网　https://www.cnki.net

的配准融合结果。

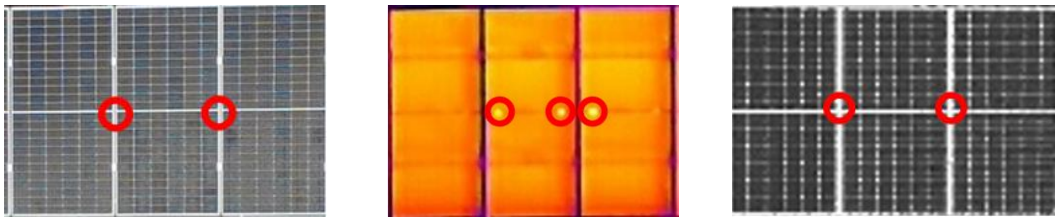
为了与第三章算法只在红外图像上检测的结果作比较，本文选取了 200 对可见光和红外图像，使用通道替换融合的方式生成了 200 张 RGI 图像，另外，使用改进的 UMF-CMGR 网络对 200 对源图像进行配准融合，最后，用第三章算法分别对 200 张红外图像、200 张生成的 RGI 图像，200 张配准融合图像进行检测，表 4-3 是使用第三章算法检测的实验结果。

表 4-3 验证实验结果

检测图像	准确率（%）	误检率（%）	热斑（个）	阴影（个）
IR	75.23	9.5	650	23
RGI	76.01	9.3	632	23
配准融合图像	79.4	7.9	611	20

可以看到，对于第三章提出的基于区域特征与点特征的光伏板缺陷检测算法，当使用通道替换的方式进行融合，算法准确率和误检率变化都不多，而使用改进的 UMF-CMGR 网络的配准融合结果进行缺陷检测时，缺陷的检测准确率要比只使用红外图像进行检测提升了 4.17%，误检率降低了 1.6%。这也证明，该配准融合结果对于光伏板缺陷检测与识别任务是有效的。

由于可见光图像特征的加入，弥补了红外图像分辨率不高导致缺陷特征弱化的影响。用于固定光伏板的螺丝钉部位在可见光图像主要位于可见光主栅线部位，特征较强，在配准融合之后也降低了因为光伏板的螺丝钉发热的误检，如图 4-15 所示。



(a) 可见光螺丝钉特征　(b) 红外螺丝钉特征　(c) 融合后螺丝钉特征

图 4-15 光伏板螺丝钉特征

由图 4-15 所示，因固定位置螺丝钉发热导致在红外图像上引起的发热，当与可见光图像进行配准融合之后，能够有效弱化螺丝钉发

中国知网 https://www.cnki.net

热引起的误检，而其不处于光伏板主栅线部位的缺陷则影响不大，配准融合之后的结果能很好地保留缺陷的特征。

4.5　本章小结

本章主要提出了一种光伏板红外与可见光配准融合方法。首先，使用改进的 UMF-CMGR 网络结构生成的配准融合光伏板图像不仅保留了红外图像的热量信息，而且结合了可见光图像的纹理和细节信息；其次，为了验证配准融合图像的有效性，使用第三章算法对配准融合之后的图像进行缺陷检测。实验表明，改进的 UMF-CMGR 网络生成的光伏板配准融合结果对光伏板缺陷检测是有效的。

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net

第5章 基于多源融合的改进YOLOv8缺陷检测识别网络

5.1 引言

使用基于区域特征与点特征的光伏板缺陷检测算法对配准融合之后的图像进行检测时，无法实现端到端的缺陷检测。将配准融合网络与目标检测网络联合设计，不仅实现了图像融合与缺陷检测的一体化处理，还能进一步提升整体网络的性能。由于 YOLO 系列的检测精度和效率在众多目标检测网络中较为突出，因此，本文选取 YOLOv8 进行改进，引入可变形卷积 DCNv3 和注意力机制提升模型对缺陷目标的识别能力。最后，联合改进的 UMF-CMGR 网络与改进的 YOLOv8 网络，实现端到端的融合检测。

5.2 改进的 YOLOv8 模型介绍

5.2.1 YOLOv8 的优势与局限性

YOLOv8 使用的主干网络是 CSPDarknet53[63,64]，这是一种改进版的 Darknet 架构。它引入了交叉阶段部分(CSP)网络，目的是在不显著增加计算成本的情况下，增强网络的学习能力和特征提取能力。CSP 结构通过减少梯度的重复计算和参数数量来优化训练过程。

此外，YOLOv8 保留了 YOLO 系列的特征检测头[65]，它直接在特征图上生成预测。这包括边界框的坐标、对象存在的置信度以及类别的概率。YOLOv8 引入了无锚点检测技术[66]，这意味着它可以直接预测物体的中心点和边界，消除了需要预定义锚点框的复杂性。YOLOv8 在主干网络（Backbone）和颈部（Neck）中引入了 C2f 结构，它改进了 CSP 结构，提高特征提取能力的同时也通过分组卷积和跳跃连接减少了计算量，使其更适合于小目标检测任务。图 5-1 给出了 YOLOv8 的网络结构图。

中国知网　https://www.cnki.net

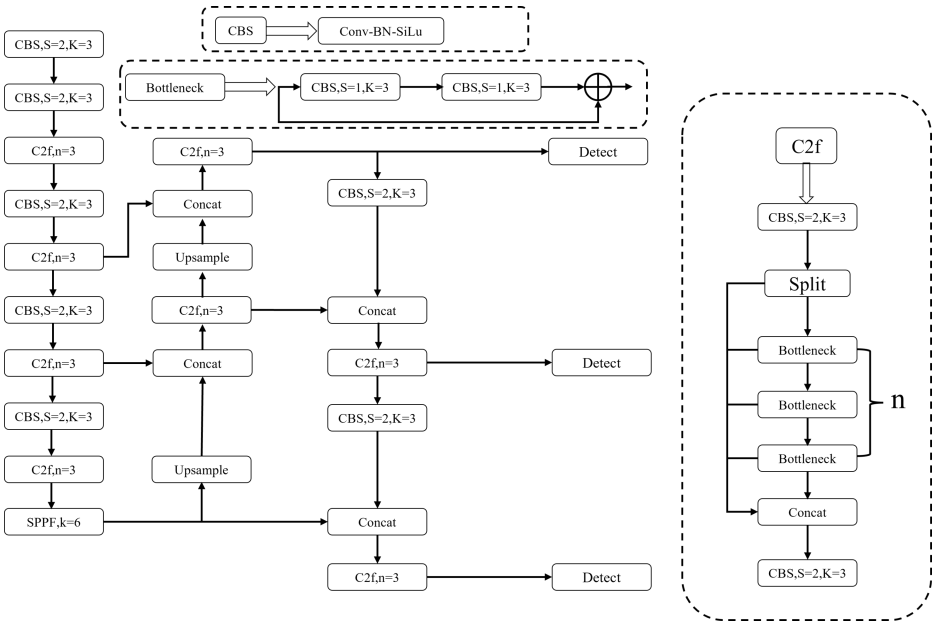


图 5-1 YOLOv8 网络结构

虽然 YOLOv8 在处理速度和准确性上表现出色，但在处理小目标检测时，YOLOv8 还是存在一定的局限性，例如：

（1）特征提取与空间信息丢失，在进行特征提取时，YOLOv8 的卷积层会对输入图像进行多次下采样。这个过程中，图像的分辨率逐渐降低，可能导致小目标的特征信息丢失。尤其是在目标尺寸非常小或与背景特征相似时，这些目标可能会在特征图中消失不见。

（2）锚框适配性问题，在 YOLOv8 中，预设的锚框大小和比例可能不适合所有尺寸的目标。对于小目标，如果预设锚框太大，就很难精确匹配目标的实际边界，这可能导致小目标的识别不准确。

（3）高误检率和漏检问题，针对小目标，YOLOv8 可能存在较高的误检率和漏检率。这是因为模型在辨识小目标与背景噪声或其他非目标物体时，可能会出现判断错误。

5.2.2 改进的 C2f 结构

为了提高 YOLOv8 对小目标的检测能力，引入可变形卷积 DCNv3。将 C2f 结构中的 Bottleneck 与引入的 Bottleneck-Hybrid 结构并行计算组成最终的 C2f_DCNv3 结构。DCNv3 可能会使模型训练过程变得不稳定，保留原有的 Bottleneck 能起到一定的正则化作用，因此并行计算不仅可以保留原有结构的稳定性，而且增加了 DCNv3 的

中国知网 https://www.cnki.net

动态适应性，使得每个分支负责为目标的不同类别进行特征提取。通过 DCNv3 的引入，特征提取阶段会通过可变形卷积来动态调整卷积核的采样位置，以更精准地捕捉小目标的局部特征。DCNv3 加入后，特征融合路径的加权机制会根据不同目标的特性动态调整，使得网络能够在训练过程中自适应地选择最优的特征进行加权融合，增强网络在处理复杂目标的准确度，C2f_DCNv3 的网络结构如图 5-2 所示。

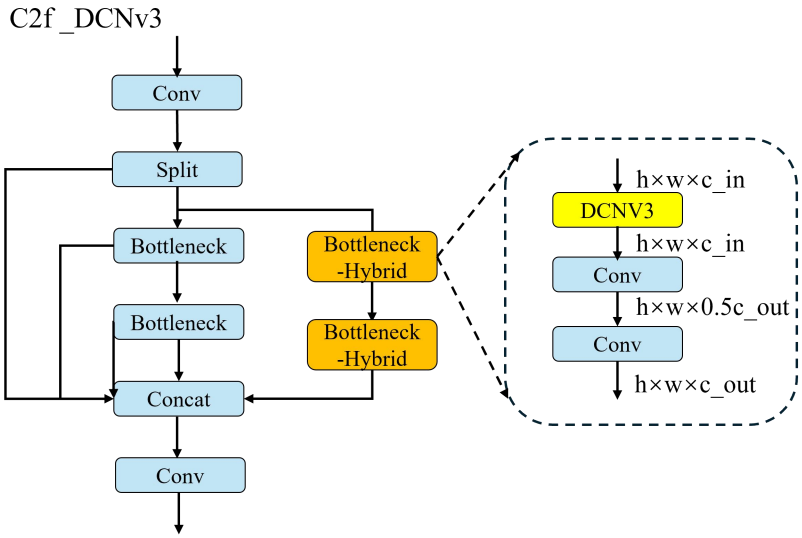


图 5-2 C2f_DCNv3 结构

在传统的卷积神经网络中，卷积操作是基于一个固定的网格（通常为 3×3 或 5×5）进行采样的。这种操作假设目标或物体的形状和位置是规则的且相对一致的。然而在实际的目标检测任务中，光伏板缺陷例如热斑等小缺陷形状往往不规则，且因为形态变化和目标与背景的区分度较低的情况，传统的卷积神经网络往往存在局限性。

在标准卷积中，每个像素位置的卷积核都是在固定的规则网格（例如 3×3 或 5×5）上进行采样的。而 DCNv3 通过学习额外的偏移量（offsets），使得每个采样点都能根据输入图像的特征动态调整其位置，例如，在一个 3×3 的卷积中，传统卷积的 9 个采样点始终位于网格的固定位置，如图 5-3 所示。

(-1, -1)	(0, -1)	(1, -1)
(-1, 0)	(0, 0)	(1, 0)
(-1, 1)	(0, 1)	(1, 1)

图 5-3 传统卷积核采样方式

中国知网 https://www.cnki.net

而 DCNv3 在这些位置的基础上引入了偏移量Δ(x, y)，每个位置 P 的采样点变为如图 5-4 所示的采样位置。

(-1+Δx1, -1+Δy1)	(0+Δx2, -1+Δy2)	(1+Δx3, -1+Δy3)
(-1+Δx4, 0+Δy4)	(0+Δx5, 0+Δy5)	(1+Δx6, 0+Δy6)
(-1+Δx7, 1+Δy7)	(0+Δx8, 1+Δy8)	(1+Δx9, 1+Δy9)

图 5-4 DCNv3 卷积核采样方式

假设输入特征图为 X，卷积核为 W，最终输出特征为 Y。则传统的卷积计算公式如公式（5-1）所示。

$$Y(p)=\sum_{k=1}^{K}W_k\cdot X(p+p_k) \tag{5-1}$$

其中：

p —— 标准卷积核的采样位置；

k —— 卷积核的大小（例如 3×3 卷积，$k=9$）；

p_k —— 卷积核的固定采样位置(例如 3×3 卷积的 p_k 可能为 $(-1,-1),(0,-1),(1,-1),...,(1,1)$)；

W_k —— 卷积核的权重；

$X(p+p_k)$ —— 从输入特征图中采样的位置。

DCNv3 引入了动态偏移量Δp_k，使得每个卷积核的采样位置变为可变形的，其卷积计算公式如公式（5-2）所示。

$$Y(p)=\sum_{k=1}^{K}W_k\cdot X(p+p_k+\Delta p_k) \tag{5-2}$$

其中：

Δp_k —— 每个采样点的偏移量，由一个额外的卷积层学习得到，并对每个像素点 p 进行预测；

$p+p_k+\Delta p_k$ —— 新的卷积采样位置。

由于 $p_k+\Delta p_k$ 可能不是整数坐标，因此 DCNv3 采用双线性插值来计算 $X(p+p_k+\Delta p_k)$的值。

DCNv3 在标准卷积的基础上，引入了一个额外的卷积分支，用于学习偏移量Δp_k，由公式（5-3）计算得出。

中国知网 https://www.cnki.net

$$\Delta p_k = f\left(X; W_{\text{offset}}\right) \tag{5-3}$$

其中：

$f(X)$ —— 标准的 3×3 卷积操作；

W_{offset} —— 学习偏移量的卷积核权重。

偏移量Δp_k的通道数为 k×2（例如 3×3 卷积，对应 9×2=18 个偏移量），这些偏移量控制着卷积核每个采样点的移动，使其适应不同形状的目标。

DCNv3 的计算流程如图 5-5 所示。

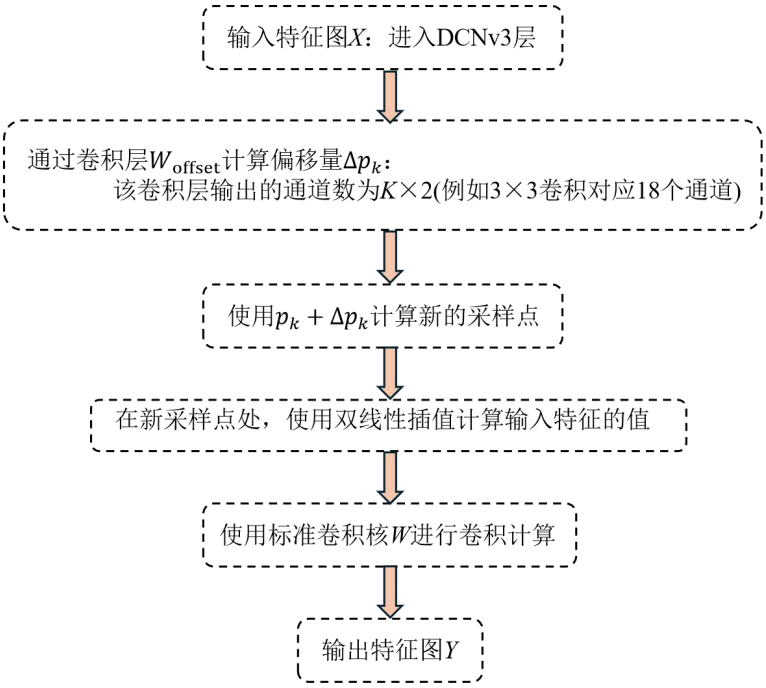


图 5-5 DCNv3 的计算流程

在加入 C2f_DCNv3 结构的 YOLOv8 检测过程中，DCNv3 的引入将传统的卷积操作替换为可变形卷积，DCNv3 在每个卷积核的位置引入学习到的偏移量。这些偏移量是由网络自动学习得到，它们控制卷积核采样位置的变化。针对某个缺陷，DCNv3 可以通过学习到的偏移量将卷积核的采样位置移向缺陷的中心部分，而不是仅仅依赖固定的卷积网格，从而更准确地捕捉缺陷的细节。

5.2.3 引入 MLLA 注意力机制

注意力机制可以让模型自动关注输入数据中的关键部分，而忽略

中国知网　https://www.cnki.net

不重要的信息。这种机制能够更精准地建模长距离依赖关系、复杂结构以及多模态数据。光伏板缺陷受背景纹理影响而导致的难以检测问题，使用注意力机制可以使模型只关注缺陷部位，抑制背景纹理特征，提高模型的泛化能力和鲁棒性，从而提高光伏板缺陷的检测精度。

MLLA[67]（Mamba-Like Linear Attention）是一种结合了 Mamba（基于 S4 序列建模）和线性注意力（Linear Attention）的创新注意力机制。它能够提供一种高效、可扩展的注意力计算方式，以降低计算复杂度，同时保持良好的序列建模能力。传统的 Transformer 注意力计算复杂度较高，对于长序列成本过高，会带来明显的显存消耗，且传统的 Transformer 注意力需要全局信息进行计算，存在一定的瓶颈，而线性注意力则是将 Softmax 操作替换为线性核函数优化了计算复杂度，Mamba 则通过连续时间演化方程进行长序列建模，避免了 Transformer 的全局计算瓶颈。MLLA 结构如图 5-6 所示。

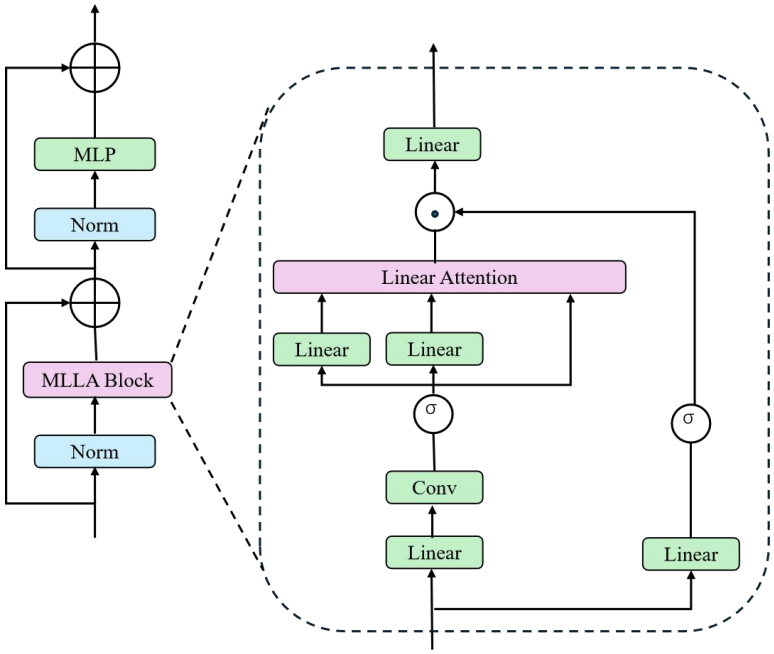


图 5-6 MLLA 注意力结构

MLLA 注意力机制的计算步骤如下：

首先，状态更新，MLLA 继承了 Mamba 的隐式状态更新机制，Mamba 是一种基于隐式状态空间模型的高效序列建模方法，通过增量式更新来实现在输入新数据时仅更新相关状态，而不需要重新计算整个序列的注意力分布。每个时间步 t 更新隐藏状态，如公式（5-4）所示。

中国知网 https://www.cnki.net

$$h_t = Ah_{t-1} + Bx_t \tag{5-4}$$

其中：

h_t —— 当前时间步的隐藏状态；

A —— 状态更新矩阵，控制信息从前一个时间步流向当前时间步；

B —— 输入变换矩阵，用于将输入 x_t 映射到隐藏状态空间；

x_t —— 输入序列的当前时间步特征。

这一步是 Mamba 的核心，它允许模型在时间步 t 之前保留隐藏状态 h_{t-1}，从而减少对全局计算的依赖，使用隐式状态空间模型（SSM）进行序列建模，能够有效整合长期依赖信息。

接着，线性注意力计算，用于替代传统的 Transformer 注意力计算，传统 Transformer 注意力计算复杂度为 O(N^2)，线性注意力则将时间复杂度降为 O(N)，如公式（5-5）所示。

$$Y_t = \phi(Q_t) \cdot (\phi(K_t)^T V_t) \tag{5-5}$$

其中：

$\phi(Q)$和$\phi(K)$ —— 线性变换，V 通过状态更新后的特征提取得到。

这一步是 MLLA 计算的核心步骤，能够显著降低计算复杂度，并且减少存储需求，提高推理效率。

最后，归一化与非线性变换，MLLA 采用了类似 RMSNorm 或 LayerNorm 进行归一化，如公式（5-6）所示。

$$Output = \sigma(W_1 x) \cdot \mathrm{ReLU}(W_2 x) \tag{5-6}$$

其中：

W_1 和 W_2 —— 可学习参数；

σ —— Sigmoid 门控机制；

ReLU —— 激活函数负责增强模型的非线性表达能力。

这一步的作用是为了提高训练的稳定性，避免梯度消失或梯度爆炸。

通过引入 MLLA 注意力机制，不仅可以使计算复杂度降低至 O(N)，而且因为 Mamba 的隐式状态更新机制避免了 Transformer 的 全

中国知网 https://www.cnki.net

局注意力计算瓶颈，从而能建模超长序列由于，又因为 MLLA 在多个层次上并行计算状态更新，使得 MLLA 注意力机制相比 Mamba 在层次化特征提取和语义建模方面更强，更适合应用到光伏缺陷检测算法当中。

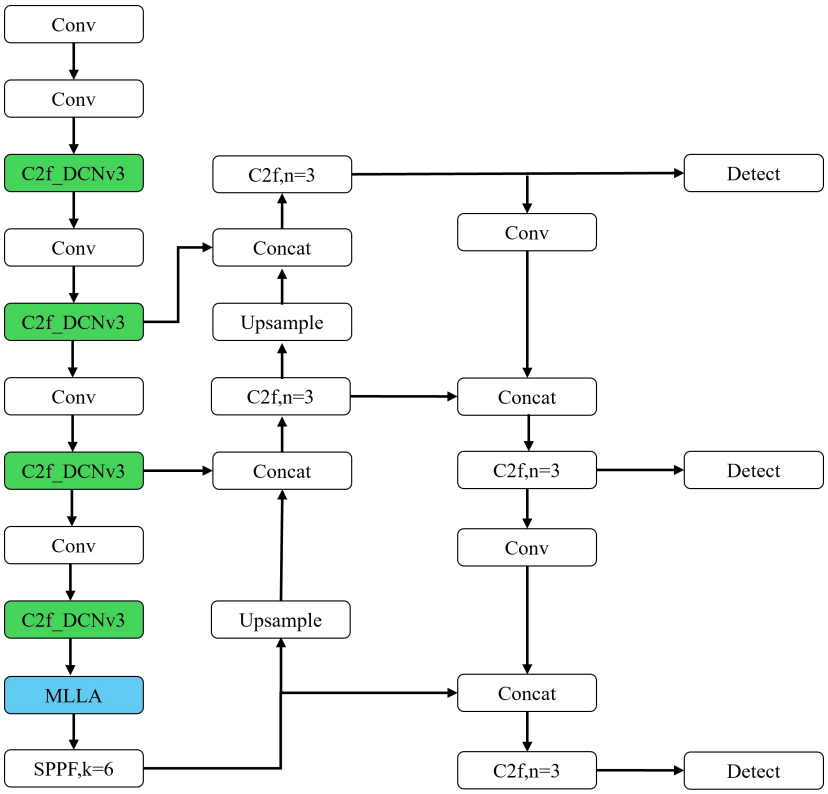


图 5-7 YOLOv8-MDCNv3 结构图

图 5-7 为最终改进的 YOLOv8-MDCNv3 结构图。将改进的 C2f_DCNv3 结构替换原网络中的 C2f 结构，增强网络对缺陷特征的提取能力，在 SPPF 结构前添加 MLLA 注意力机制，增强网络对缺陷特征的敏感性，最后组合成最终的 YOLOv8-MDCNv3 检测网络。

5.3 配准融合网络串联 YOLOv8-MDCNv3 网络

由于缺乏目标图像，第四章在可见光与红外图像的信息特征融合中，采用的是无监督网络方法进行图像配准与融合。但目前，已有很多网络是对不同模态的图像进行融合然后接入检测网络，实现融合检测一体化。例如 MFNet 网络[68]，通过双通道主干提取网络，使用两个共享或非共享的 CNN 主干分别提取 IR 和 RGB 图像的特征，使用拼接、加权平均、注意力机制等方法进行特征融合，最后接入检测网

中国知网 https://www.cnki.net

络进行缺陷检测。

基于融合检测网络的思想，本文将配准融合网络和检测网络串联，提出一种 IMPUC-IMPYOLOv8(Improved UMF-CMGR + Improved YOLOv8)，将改进的 UMF-CMGR 网络的输出，直接接入检测网络进行缺陷检测，串联成为最终的多模态融合检测网络，而因为有了改进的 YOLOv8-MDCNv3 网络的加入，使 YOLOv8 中的分类损失、边框损失、置信度损失加入到了损失计算当中，最终总损失函数如公式（5-7）所示。

$$L_{total} = \lambda_1 * L_{UMF-CMGR} + \lambda_2 * [L_{box} + L_{cls} + L_{obj}] \tag{5-7}$$

其中：

$L_{UMF-CMGR}$ —— UMF-CMGR 网络损失函数；

L_{box}，L_{cls}，L_{obj}—— YOLOv8 的边框损失、分类损失、置信度损失。

串联之后的网络结构图如图 5-8 所示。

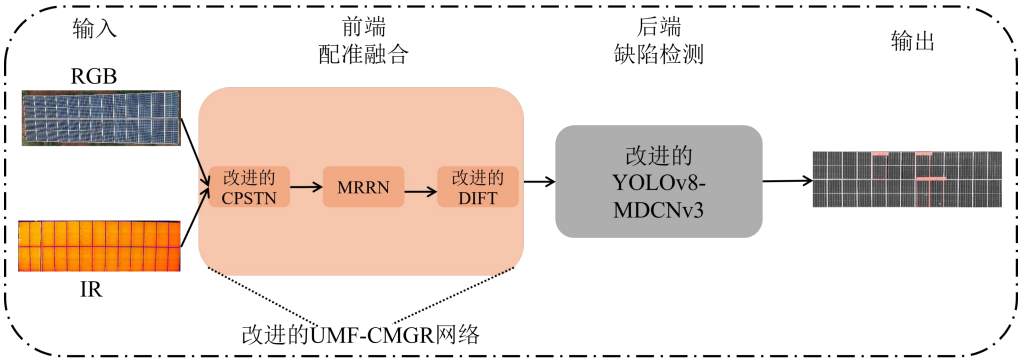


图 5-8 IMPUC-IMPYOLOv8 网络结构示意图

串联网络 IMPUC-IMPYOLOv8 通过前端配准融合技术，有效缓解了光伏板图像采集过程中由于位移、旋转及尺度差异等因素引发的图像不对齐问题。这一处理机制在消除图像间干扰因素的同时，显著提升了后端缺陷检测网络的输入质量，为更精准的缺陷识别奠定了坚实基础。更为重要的是，检测网络中的损失函数被引入至训练流程中，进一步优化了配准融合结果，从而实现了可见光图像与红外图像特征的深度协同。该机制不仅增强了网络对多模态信息的整合能力，也显著提升了其对光伏板缺陷特征的提取效率与准确性。

中国知网　https://www.cnki.net

5.4 模型改进实验

5.4.1 消融实验

本文将进行消融实验来验证分别引入 C2f_DCNv3 结构和 MLLA 注意力机制之后的模型效果。本次消融实验将继续沿用 4.4.3 章节的实验环境进行实验，并继续采用同样的光伏板数据集。

消融实验结果如表 5-1 所示，可以看出，通过引入 C2f_DCNv3 结构的 YOLOv8 模型对比原模型在召回率、平均精度都有一定程度的提升。之后，通过引入 MLLA 注意力机制使得模型在各指标上再次得到提升，改进后的 YOLOv8-MDCNv3 模型相比于 YOLOv8 模型召回率提升了 3.4%，平均精度提升了 3%，FPS 提升了 9.6 帧，IoU 提升了 0.14。消融实验的结果表明了本文引入的 C2f_DCNv3 结构和 MLLA 注意力机制都是有效的。

表 5-1 消融实验结果

C2f_DCNv3	MLLA	召回率	平均精度均值	每秒帧率	IoU
×	×	0.89	0.799	70.2	0.72
√	×	0.895	0.801	72.3	0.75
×	√	0.902	0.805	75.6	0.79
√	√	0.92	0.823	79.8	0.86

5.4.2 实验对比分析

在光伏板缺陷检测过程中，改进的 YOLOv8-MDCNv3 模型在降低漏检率的同时提高了检测准确性，对比 YOLOv8 的检测性能有明显提升。同时，为了验证模型的准确度，将改进后的 YOLOv8-MDCNv3 模型与 YOLOv5、YOLOv8、YOLOv11 同系列模型进行对比实验，此外，本文还将数据集采用单阶段检测算法 CenterNet[69]模型和端到端目标检测算法 DETR[70]模型进行对比实验，如图 5-9 所示为 YOLOv8-MDCNv3 与其他模型的分类损失曲线对比图，可以看出，改进后 YOLOv8-MDCNv3 模型的分类损失对比原模

中国知网 https://www.cnki.net

型 YOLOv8 更低，说明对比原模型来说，改进后 YOLOv8-MDCNv3 模型对光伏板数据的拟合程度更好，这有助于提高模型的预测准确率。对比同系列的 YOLOv5、YOLOv11 来说，虽然它们的损失曲线下降更快，但损失值都高于改进后的 YOLOv8-MDCNv3 模型。

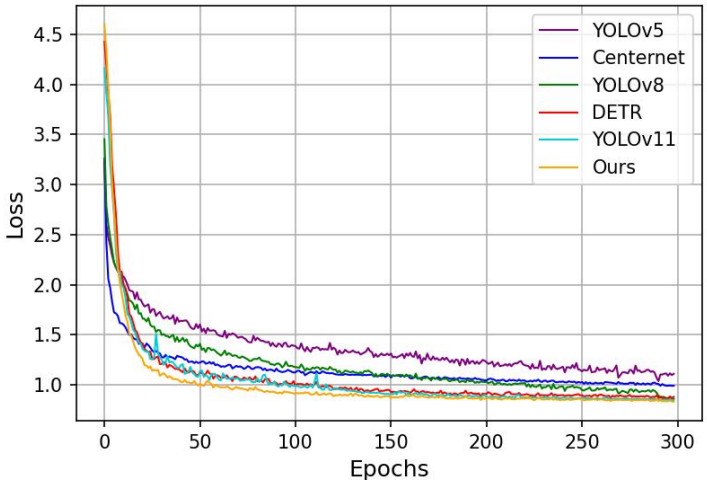


图 5-9 分类损失对比曲线

对比单阶段检测算法 CenterNet 模型来说，CenterNet 模型因为省去了 Anchor-Free 机制，导致它计算复杂度更低，分类损失曲线下降更快，但也导致了它在分类损失上略高于改进后的 YOLOv8-MDCNv3 模型。对比端到端目标检测算法 DETR 模型来说，DETR 模型采用 Transformer 代替传统 CNN 架构，提高了模型的预测精确度，但训练时间也大幅增加，而改进后的 YOLOv8-MDCNv3 模型弥补了原 YOLOv8 网络与 DETR 模型在预测精确度上的差距。六种模型的对比结果如表 5-2 所示。

表 5-2 对比结果

算法	召回率	平均精度均值	每秒帧率	IoU
YOLOv5	0.883	0.786	68.3	0.66
YOLOv8	0.89	0.799	70.2	0.72
YOLOv11	0.895	0.803	73.6	0.69
DETR[70]	0.93	0.853	60.2	0.79
CenterNet[69]	0.901	0.806	75.5	0.73
YOLOv8-MDCNv3	0.92	0.823	79.8	0.86

改进后的 YOLOv8-MDCNv3 模型相比于同系列模型都有明显提

中国知网　https://www.cnki.net

升，并且召回率、平均精度、每秒帧率、IoU 都高于单阶段检测算法 CenterNet，虽然在平均精度均值和召回率上相较于 DETR 略有差距，但在每秒帧率和 IoU 都高于 DETR。这是因为 DETR 牺牲了训练时间，DETR 模型中由于 Transformer 需要学习全局关系导致它的收敛速度较慢，且 Transformer 计算复杂度较高，存在训练时间长、检测时效性低的问题。因此，综合比较，本章提出的算法虽然略差于 DETR 检测算法，但是实时性会更好，检测速度会更快，能更好地满足光伏板缺陷检测任务。

本文通过一系列对比实验和数据分析验证改进后的 YOLOv8-MDCNv3 检测效果，从对比结果可以看出，改进后的 YOLOv8-MDCNv3 模型不仅比原模型效果更好，对比其他系列模型仍然表现出了较好的检测性能。

5.4.3 配准融合网络串联 YOLOv8-MDCNv3 实验

为了验证配准融合网络串联改进的 YOLOv8 网络的有效性，本文先将光伏板图像送入改进的 UMF-CMGR 网络进行配准融合，再将融合结果送入改进的 YOLOv8-MDCNv3 模型，未实现端到端融合检测。之后，为了验证串联网络的有效性，将光伏板红外与可见光图像直接送入 IMPUC+IMPYOLOv8 网络直接进行配准融合加检测，实现端到端融合检测，实验对比结果如表 5-3 所示。

表 5-3 融合检测对比结果

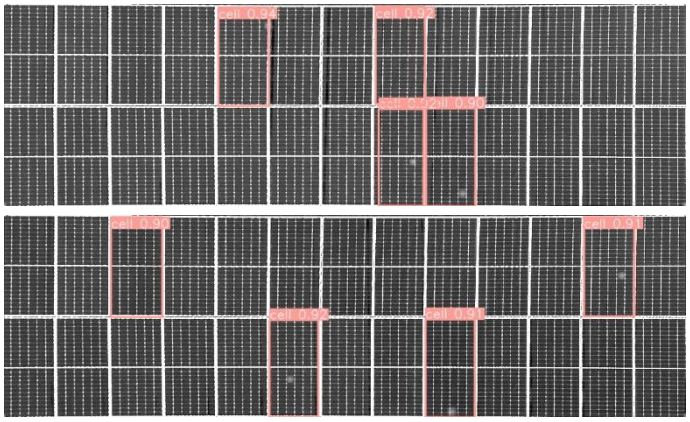
算法	召回率	平均精度
YOLOv8-MDCNv3	0.92	0.823
IMPUC+IMPYOLOv8	0.94	0.855

由对比结果可以看出，通过将配准融合网络与 YOLOv8-MDCNv3 网络串联使用，检测的召回率与平均精度得到了进一步提升。这一性能的改进主要归因于在训练过程中将优化后的 UMF-CMGR 网络与改进型 YOLOv8-MDCNv3 网络的损失函数进行联合建模，从而实现了配准融合模块与目标检测模块的协同优化。该联合优化机制不仅加强了两个子网络之间的信息互补性，也显著提升了整体检测框架的鲁棒性与精度表现。

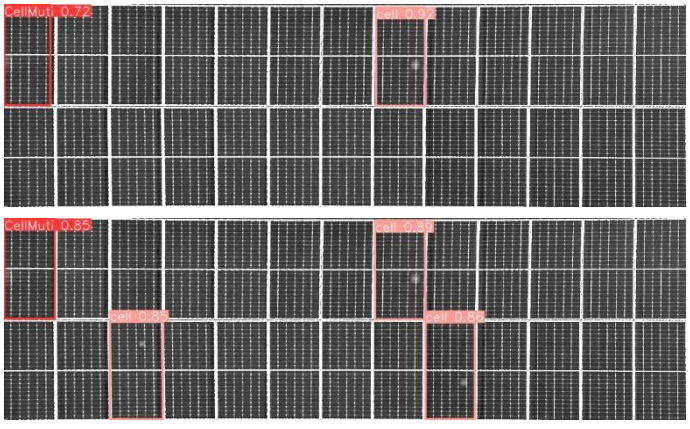
中国知网 https://www.cnki.net

5.4.4 实验结果展示

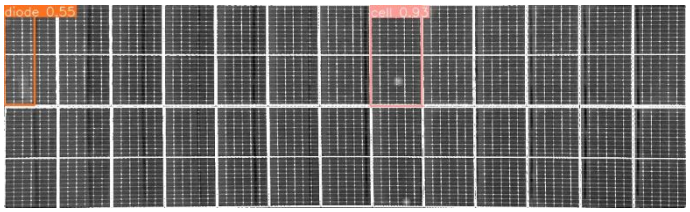
改进后的 YOLOv8-MDCNv3 模型联合改进的 UMF-CMGR 网络对光伏板三种缺陷的检测结果如图 5-10 所示，联合模型对于热斑的检测置信度能够稳定在 90%左右，对于阴影的检测置信度能够稳定在 85%左右。多热斑的检测置信度只能稳定在 85%左右，这是因为多热斑缺陷和热斑缺陷的相似性，导致对于多热斑的检测置信度略低于热斑的检测置信度。对于二极管缺陷来说，因为较难检测和数据量不够的原因，所以检测置信度略低。



(a) 热斑

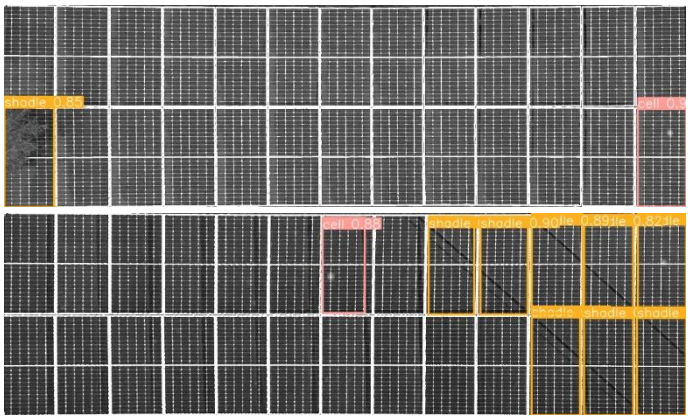


(b) 多热斑



(c) 二极管

中国知网　https://www.cnki.net



(d) 阴影

图 5-10 实验结果

5.5 本章小结

本章主要主要提出了一种多源融合的改进 YOLOv8 模型进行光伏板缺陷检测任务。首先，详细介绍了所引入的结构性改进模块及其集成的注意力机制，阐述其在特征提取与语义增强方面的优势。随后，将图像配准融合网络与改进后的检测网络进行串联，构建了一个端到端的一体化融合检测架构。在实验部分，本文首先采用改进后的检测模型对经配准融合处理的图像数据进行缺陷检测与分类，以评估其基础性能。为全面验证所提出改进策略的有效性，将改进后的模型与原 YOLOv8 模型、同系列的变体模型以及其他主流目标检测算法进行了对比实验。通过定量指标与结果分析，证明了所提出的 YOLOv8-MDCNv3 模型在光伏板缺陷检测任务中具有更高的检测精度与鲁棒性。最后，结合配准融合模块与检测网络，构建联合模型以实现端到端的融合检测流程，并通过实验证明该串联网络结构在实际应用中的可行性与有效性。

中国知网 https://www.cnki.net

第6章 总结与展望

6.1 本文总结

本文通过分析光伏板存在的各类缺陷，对光伏板缺陷的研究现状和深度学习在光伏板缺陷检测的应用研究，在面对无数据集标注的情况下，提出一种基于区域特征与点特征的光伏板缺陷检测算法，在收集大量数据后，通过改进的 UMF-CMGR 网络实现端到端的配准融合，之后提出了一种改进的 YOLOv8 的光伏板缺陷检测模型，与改进的 UMF-CMGR 网络进行串联，实现光伏板端到端的配准融合检测。主要研究内容如下：

（1）本文首先对光伏板缺陷检测的国内外研究现状进行分析，根据数据得出光伏板缺陷检测目前存在的需要解决的问题，如数据集缺失问题、检测效率不高问题等都急需解决。之后对光伏板成因及特性进行分析，说明深度学习算法对光伏板缺陷检测与识别任务的作用。具体研究了从两阶段目标检测网络到单阶段目标检测网络以光伏板作为目标，以缺陷作为异常目标进行识别的适用性。

（2）为解决没有数据集标注而导致无法训练深度学习模型的问题，本文提出了一种基于区域特征与点特征的光伏板缺陷检测算法。介绍了该算法的一些关键技术，例如，缺陷区域特征和点特征提取，构建新的特征向量，分类器分类等，并对实验结果进行分析。在没有数据集标注的情况下，该算法对比其他基于先验知识的无监督算法的缺陷检测准确度更高。

（3）为了解决红外图像上，光伏板缺陷的特征不完整的问题，需要结合可见光图像，综合两种图像的特征信息。由于在光伏板图像采集过程中，红外相机与可见光相机存在拍摄角度、位置等方面的差异，导致所获取的图像常出现空间错位、几何畸变等问题。此外，在目标图像缺失的情况下，融合方法难以保证配准精度及融合质量。为此，本文提出一种改进型 UMF-CMGR 图像配准融合网络，有效缓解因图像偏差造成的融合质量下降问题。该方法在应对图像错位与结构不完整方面表现出更强的鲁棒性。

中国知网　https://www.cnki.net

（4）为了完成光伏板缺陷检测与识别任务，本文提出了一种改进的 YOLOv8-MDCNv3 网络模型。主要是针对光伏板缺陷的尺度变化特性，利用 DCNv3 动态调整缺陷的采样位置，构建了一种新型的 Bottleneck-Hybrid 结构与原 Bottleneck 结构并行计算，提高模型的小目标捕捉能力。通过加入 MLLA 注意力机制来提高模型对不同尺度缺陷的敏感性。为了实现端到端的光伏板缺陷检测与识别，将改进的 UMF-CMGR 与 YOLOv8-MDCNv3 网络联合。通过对比实验证明了改进后的 YOLOv8-MDCNv3 网络模型的有效性，并且联合网络对光伏板缺陷检测与识别任务的准确度有进一步的提升。

6.2 研究展望

本文针对光伏板缺陷检测任务进行研究实验，提出一种改进的 UMF-CMGR 与改进的 YOLOv8 模型串联算法，在光伏板缺陷检测任务中取得了初步进展，但是在数据集获取、缺陷划分、检测种类、实际生产应用方面仍然存在诸多不足，还需要进一步研究改善：

（1）数据集的获取以及数据集的质量提升是深度学习研究的一大难题，数据集的不平衡性导致模型对于热斑的检测效果较好，对于数据量较少的二极管缺陷和多热斑缺陷来说，检测效果不佳。本文使用的数据集仍然存在数据采集较为困难且拍摄质量不高等问题。例如在强光反射、阴影遮挡、雨雪天气等复杂环境下，由于数据集较难获取，后期考虑优化数据采集方式以及提升拍摄质量，重新对本文算法进行训练，提高模型在实际应用中的稳定性。

（2）由于缺陷分类不明确，且某些缺陷因为数量较少等问题导致数据集标注过程中存在分类不均问题，导致很多缺陷例如微裂纹、虚焊等缺陷都无法满足数据集数量需求，这也导致模型无法识别并细分这些缺陷。后期考虑采集更多的不同缺陷样本并制定一个更为详细的标准对缺陷进行划分，提高数据集的质量。

（3）本文提出的光伏板缺陷检测算法仍具有一定的不足，后续考虑与其他学科的交叉融合，分析不同材料光伏板缺陷在图像特征上的差异，从而开发出更具针对性的检测算法，考虑不同气象条件对光伏板缺陷表现的影响，构建更全面的缺陷检测模型。

中国知网 https://www.cnki.net

参考文献

[1] Das U K, Tey K S, Seyedmahmoudian M, et al. Forecasting of photovoltaic power generation and model optimization: A review[J]. Renewable and Sustainable Energy Reviews, 2018, 81: 912-928.

[2] 熊福军, 黄升华. 新形势下储能技术在光伏和风力发电系统中的应用[J]. 光源与照明, 2025, (01): 150-152.

[3] Sun T, Xing H, Cao S, et al. A novel detection method for hot spots of photovoltaic (PV) panels using improved anchors and prediction heads of YOLOv5 network[J]. Energy Reports, 2022, 8: 1219-1229.

[4] Akram M W, Li G, Jin Y, et al. Failures of Photovoltaic modules and their Detection: A Review[J]. Applied Energy, 2022, 313: 118822.

[5] Gupta V, Gruss M S , Cammarano D , et al. Optimizing corn agrivoltaic farming through farm-scale experimentation and modeling[J]. Cell Reports Sustainability, 2024, 1(7): 100148-100148.

[6] 麻瑞. 基于视觉感知的光伏板表面异物检测方法研究与应用[D]. 西安建筑科技大学, 2024.

[7] 牛小育, 刘长良, 刘卫亮, 等. 基于深度学习的光伏红外图像热斑检测方法[J]. 太阳能学报, 2024, 45(11): 272-281.

[8] 巩书麟. 基于双光图像配准与融合的光伏热斑识别方法研究与实现[D]. 东北电力大学, 2024.

[9] 管宽岐. 基于深度学习的航拍光伏板红外图像热斑检测[D]. 沈阳农业大学, 2023.

[10] Guo L , Wang Y , Guo M , et al. YOLO-IRS: Infrared Ship Detection Algorithm Based on Self-Attention Mechanism and KAN in Complex Marine Background[J]. Remote Sensing, 2024, 17(1): 20-20.

[11] 王培珍, 郑诗程. 基于红外图像的太阳能光伏阵列故障分析[J]. 太阳能学报, 2010, 31(2): 197-202.

[12] Ali M U, Saleem S, Masood H, et al. Early hotspot detection in

中国知网 https://www.cnki.net

photovoltaic modules using color image descriptors: An infrared thermography study[J]. International Journal of Energy Research, 2022, 46(2): 774-785.

[13] 王亚丽, 孙坚, 徐红伟. 基于红外成像太阳能板缺陷检测方法研究[J]. 测控技术, 2015, 34(7): 59-61, 66.

[14] 马浩. 基于红外热成像及可见光图像的光伏电站热斑检测及定位技术研究[D]. 江苏: 南京邮电大学, 2019.

[15] Henry C, Poudel S, Lee S W, et al. Automatic detection system of deteriorated PV modules using drone with thermal camera[J]. Applied Sciences, 2020, 10(11): 3802.

[16] Papargyri L , Theristis M , Kubicek B , et al. Modelling and experimental investigations of microcracks in crystalline silicon photovoltaics: A review[J]. Renewable Energy, 2020, 1452387-2408.

[17] Yen H N, Sie Y J. Machine vision system for surface defect inspection of printed silicon solar cells[C]//The 1st IEEE Global Conference on Consumer Electronics 2012. IEEE, 2012: 422-424.

[18] 虎民飞, 孟一飞, 王葭. 基于视觉伺服控制的光伏板清洗系统设计[J]. 自动化与仪表, 2020, 35(1): 33-37.

[19] Li X, Yang Q, Chen Z, et al. Visible defects detection based on UAV-based inspection in large-scale photovoltaic systems[J]. IET Renewable Power Generation, 2017, 11(10): 1234-1244.

[20] 陈克松. 基于深度学习的光伏组件故障诊断方法[D]. 甘肃: 兰州理工大学, 2022.

[21] 沈灵鑫. 基于深度学习的光伏板故障检测算法研究[D]. 山西: 太原科技大学, 2023.

[22] Cao Y, Pang D, Yan Y, et al. A photovoltaic surface defect detection method for building based on deep learning[J]. Journal ofBuilding Engineering, 2023, 70: 106375.

[23] Jerome Vasanth J, Naveen Venkatesh S, Sugumaran V, et al. Enhancing Photovoltaic Module Fault Diagnosis with Unmanned Aerial Vehicles and Deep Learning-Based Image Analysis[J].

中国知网 https://www.cnki.net

International Journal of Photoenergy, 2023, 2023(1): 8665729.

[24] Wang X, Yang W, Qin B, et al. Intelligent monitoring of photovoltaic panels based on infrared detection[J]. Energy Reports, 2022, 8: 5005-5015.

[25] Molenbroek E, Waddington D W, Emery K A. Hot spot susceptibility and testing of PV modules[C]//Photovoltaic Specialists Conference. Las Vegas, 1991, 1: 547-552.

[26] Wang A, Xuan Y. Close examination of localized hot spots within photovoltaic modules[J]. Energy Conversion and Management, 2021, 234: 113959.

[27] Ko S W, Ju Y C, Hwang H M, et al. Electric and thermal characteristics of photovoltaic modules under partial shading and with a damaged bypass diode[J]. Energy, 2017, 128: 232-243.

[28] Vieira R G, de Araújo F M U, Dhimish M, et al. A comprehensive review on bypass diode application on photovoltaic modules[J]. Energies, 2020, 13(10): 2472.

[29] Syafiq A, Balakrishnan V, Ali M S, et al. Application of transparent self-cleaning coating for photovoltaic panel: a review[J]. Current Opinion in Chemical Engineering, 2022, 36: 100801.

[30] 赵强, 刘胜杰, 韩东成, 等. 基于改进 K 均值聚类的光伏板缺陷检测方法[J]. Infrared Technology, 2024, 46(4): 475-482.

[31] Monicka S G, Manimegalai D, Karthikeyan M. Detection of microcracks in silicon solar cells using Otsu-Canny edge detection algorithm[J]. Renewable Energy Focus, 2022, 43: 183-190.

[32] Junchao W, Chang Z. Defect detection on solar cells using mathematical morphology and fuzzy logic techniques[J]. Journal of Optics, 2024, 53(1): 249-259.

[33] Hijjawi U, Lakshminarayana S, Xu T, et al. A review of automated solar photovoltaic defect detection systems: Approaches, challenges, and future orientations[J]. Solar Energy, 2023, 266: 112186.

[34] 余海坤. 资源受限下目标检测网络轻量化方法研究[D]. 西安工

中国知网 https://www.cnki.net

业大学, 2023.

[35] Alzubaidi L, Zhang J, Humaidi A J, et al. Review of deep learning: concepts, CNN architectures, challenges, applications, future directions[J]. Journal of big Data, 2021, 8: 1-74.

[36] Alom M Z, Taha T M, Yakopcic C, et al. The history began from alexnet: A comprehensive survey on deep learning approaches[J]. arXiv preprint arXiv:1803.01164, 2018.

[37] Tammina S. Transfer learning using vgg-16 with deep convolutional neural network for classifying images[J]. International Journal of Scientific and Research Publications (IJSRP), 2019, 9(10): 143-150.

[38] Al-Qizwini M, Barjasteh I, Al-Qassab H, et al. Deep learning algorithm for autonomous driving using googlenet[C]//2017 IEEE intelligent vehicles symposium (IV). IEEE, 2017: 89-96.

[39] Koonce B. ResNet 50[M]//Convolutional neural networks with swift for tensorflow: image recognition and dataset categorization. Berkeley, CA: Apress, 2021: 63-72.

[40] 辛鹏, 许悦雷, 唐红, 等. 全卷积网络多层特征融合的飞机快速检测[J]. Acta Optica Sinica, 2018, 38(3): 315003--1.

[41] 刘淼, 王晶, 董桂官, 等. 基于改进池化层的弱标记声音事件检测[J]. 信号处理, 2021, 37(10): 1907-1913.

[42] Basha S H S, Dubey S R, Pulabaigari V, et al. Impact of fully connected layers on performance of convolutional neural networks for image classification[J]. Neurocomputing, 2020, 378: 112-119.

[43] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.

[44] 王婉婷, 姜国龙, 褚云飞, 等. 从 RCNN 到 YOLO 系列的物体检测系统综述[J]. 齐鲁工业大学学报, 2021, 35(05): 9-16.

[45] 龚圣斌, 王少杰, 侯亮, 等. 基于 Faster-RCNN 算法的轻量化改进及其在沙滩废弃物检测中的应用[J]. 厦门大学学报(自然科学

中国知网 https://www.cnki.net

版), 2022, 61(02): 253-261.

[46] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv: 2209.02976, 2022.

[47] 印志本, 刘锋, 栾世伟. 改进 SSD 算法在骏枣黑斑病识别模型研究[J]. 农业与技术, 2022, 42(22): 15-18.

[48] Justusson B I. Median filtering: Statistical properties[J]. Two-dimensional digital signal prcessing II: transforms and median filters, 2006: 161-196.

[49] 闫冬, 卢晓东. 一种改进的高斯滤波方法[J]. 地理空间信息, 2018, 16(05): 113-114+122+10.

[50] Tomasi C, Manduchi R. Bilateral filtering for gray and color images[C]//Sixth international conference on computer vision (IEEE Cat. No. 98CH36271). IEEE, 1998: 839-846.

[51] 刘永波, 雷波, 胡亮, 等. 机器视觉在 HSV 颜色空间下稻瘟病病程分级判定研究[J]. 农学学报, 2020, 10(10): 83-90.

[52] Aggarwal N, Karl W C. Line detection in images through regularized Hough transform[J]. IEEE transactions on image processing, 2006, 15(3): 582-591.

[53] 栾帅, 尹红娟. 基于霍夫变换的足球场标志线检测[J]. 计算机与数字工程, 2017, 45(01): 152-155.

[54] 陈信强, 陈建慧, 刘恕浩, 等. 基于语义分割和霍夫变换的可见光图像海天线检测方法[J]. 中国航海, 2024, 47(04): 36-43.

[55] Nguyen H G ,Hua H T Y ,Nguyen C L , et al. Image Enhancement Using Bidimensional Empirical Mode Decomposition and Morphological Operations for Brain Tumor Detection and Classification. [J].Asian Pacific journal of cancer prevention : APJCP, 2024, 25(9): 3327-3336.

[56] 王文善, 张维忠, 李强. 基于 OpenCL 的腐蚀膨胀算法的并行优化[J]. 青岛大学学报(工程技术版), 2023, 38(04): 22-26.

[57] Gallardo-Saavedra S , Hernández-Callejo L , Alonso-García C D M ,

中国知网 https://www.cnki.net

et al. Infrared Thermography for the Detection and Characterization of Photovoltaic Defects: Comparison between Illumination and Dark Conditions[J]. Sensors, 2020, 20(16): 4395-.

[58] Sánchez J, Monzón N, Salgado De La Nuez A. An analysis and implementation of the harris corner detector[J]. Image Processing On Line, 2018..

[59] Oliveira M, Santos V, Sappa A D. Multimodal inverse perspective mapping[J]. Information Fusion, 2015, 24: 108-121.

[60] Wang D, Liu J, Fan X, et al. Unsupervised misaligned infrared and visible image fusion via cross-modality image generation and registration[J]. arXiv preprint arXiv:2205.11876, 2022.

[61] Zhang X, Song Y, Song T, et al. LDConv: Linear deformable convolution for improving convolutional neural networks[J]. Image and Vision Computing, 2024, 149: 105190.

[62] Lv H, Chen J, Pan T, et al. Attention mechanism in intelligent fault diagnosis of machinery: A review of technique and application[J]. Measurement, 2022, 199: 111594.

[63] Sohan M, Sai Ram T, Reddy R, et al. A review on yolov8 andits advancements[C]//International Conference on Data Intelligence and Cognitive Informatics. Springer, Singapore, 2024: 529-545.

[64] Lou H, Duan X, Guo J, et al. DC-YOLOv8: Small-size object detection algorithm based on camera sensor[J]. Electronics, 2023, 12(10): 2323.

[65] Li Y, Fan Q, Huang H, et al. A modified YOLOv8 detection network for UAV aerial image recognition[J]. Drones, 2023, 7(5): 304.

[66] Yi H, Liu B, Zhao B, et al. Small object detection algorithm based on improved YOLOv8 for remote sensing[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023, 17: 1734-1747.

[67] Han D, Wang Z, Xia Z, et al. Demystify mamba in vision: A linear attention perspective[J]. arXiv preprint arXiv:2405.16605, 2024.

中国知网 https://www.cnki.net

[68] Zhu G, Qin Z, Ding Y, et al. MFNet: Real-time motion focus network for video frame interpolation[J]. IEEE Transactions on Multimedia, 2023, 26: 3251-3262.

[69] Zhuangzhuang T, Hengwei Z, Kun W, et al. Application of an improved CenterNet in remote sensing images object detection[J]. National Remote Sensing Bulletin, 2024, 27(12): 2706-2715.

[70] Dai Z, Cai B, Lin Y, et al. Up-detr: Unsupervised pre-training for object detection with transformers[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 1601-1610.

中国知网 https://www.cnki.net