武漢工程大学

Wuhan Institute of Technology

硕士学位论文

基于高速成像的车辆运动参数在线测量系统

学科专业：　信号与信息处理

研 究 生：　高耀

指导教师：　洪汉玉 教授

培养单位：　电气信息学院

二 〇 二 五 年 六 月

中国知网　https://www.cnki.net

分类号：TP391　　学校代号：10490

学　号：22203010009　　密　　级：公开

武汉工程大学硕士学位论文

基于高速成像的车辆运动参数在线测量系统

作者姓名：高耀　　指导教师姓名、职称：洪汉玉教授

申请学位类别：工学硕士　　学科专业名称：信号与信息处理

研究方向：图像处理与智能系统

论文提交日期：2025 年 6 月 5 日　论文答辩日期：2025 年 5 月 27 日

学位授予单位：武汉工程大学　　学位授予日期：2025 年 6 月 20 日

答辩委员会主席：桑农

中国知网　https://www.cnki.net

Online measurement system for vehicle motion parameters based on high-speed imaging

A Thesis Submitted for the Degree of Master

Major: Signal and Information Processing

Candidate: Gao Yao

Supervisor: Prof.Hong hanyu

Wuhan Institute of Technology

Wuhan, Hubei 430205, P. R. China

中国知网 https://www.cnki.net

摘 要

车辆运动参数的测量是交通计量和交通管理的核心任务之一，传统的基于地感线圈和毫米波雷达的测量方法虽然在某些特定场景下有效，但却存在着覆盖范围有限、部署困难较大、精度不足等问题。为了解决这些问题，本文提出了一种基于高速成像的车辆运动参数在线测量系统，该系统结合了高速成像和图像处理技术，对车辆的轨迹、轨迹曲率、速度、加速度、航向角和转向角这六个关键运动参数进行准确的测量。

本文先介绍了系统的整体框架，并分别详细阐述了图像采集与成像模型、坐标系变换与标定方法、车辆运动状态模型的原理，然后分别从硬件方面和软件方面介绍了系统的组成结构。

在相机标定方面，本文提出了基于最小生成树（Minimum Spanning Tree, MST）聚类优化的消失点相机自标定技术，适用于大视野的交通监控相机标定，能够准确的将图像坐标系下的车辆运动位置转换为世界坐标系中的车辆运动位置。

在运动参数测量方面，本文提出了一种基于平滑优化的扩展卡尔曼滤波（Extended Kalman Filter, EKF）的车辆跟踪和运动参数测量方法。该方法通过引入后向平滑和插值机制对传统的扩展卡尔曼滤波器进行了优化，然后利用多特征加权融合策略提升了匈牙利算法的匹配精度，最终实现了准确的车辆跟踪和车辆运动参数的测量。同时该方法利用参数补偿机制对测量的运动参数进行补偿，提高了车辆运动参数测量的准确性。

在实验部分，本文通过使用不同条件下的视频数据对系统在车辆运动参数测量中的有效性进行实验验证。实验结果表明，更高的帧率能帮助系统捕捉车辆的转弯、加速等复杂行为，降低因运动模糊问题造成的误差，从而提高系统的测量精度。

本文提出的基于高速成像的车辆运动参数在线测量系统，凭借精确的相机标定、高帧率的图像采集和准确的运动参数测量方法，实现了高精度的车辆运动参数测量。同时该系统展现出了强大的鲁棒性，为智能交通计量领域提供了有力的技术支持，对促进智慧交通技术的发展也具有重要意义。

中国知网 https://www.cnki.net

关键字：运动参数测量；智慧交通；高速成像；相机自标定；扩展卡尔曼滤波

中国知网 https://www.cnki.net

Abstract

Measurement of vehicle motion parameters is one of the core tasks of traffic measurement and traffic management. Traditional measurement methods based on ground sensing coils and millimeter-wave radar, although effective in some specific scenarios, suffer from limited coverage, greater difficulties in deployment, and insufficient accuracy. To address these issues, this thesis presents an online system for measuring vehicle motion parameters, utilizing high-speed imaging technology. The system combines high-speed imaging and image processing technologies to accurately measure six key motion parameters, namely trajectory, trajectory curvature, velocity, acceleration, heading angle and steering angle of the vehicle.

This thesis begins by outlining the system's overall framework, followed by a detailed explanation of the image acquisition principles, imaging model, coordinate system transformation and calibration method, as well as the vehicle motion state model. It then discusses the system's structure from both hardware and software perspectives.

For camera calibration, this thesis proposes a vanishing point camera self-calibration technique based on Minimum Spanning Tree (MST) clustering optimization. This method is suitable for large-field-of-view traffic monitoring cameras and accurately converts vehicle motion positions from the image coordinate system to the world coordinate system.

For motion parameter measurement, this thesis presents a vehicle tracking and motion parameter estimation approach utilizing a smoothing Extended Kalman Filter (EKF). The method optimizes the traditional extended Kalman filter by introducing backward smoothing

中国知网 https://www.cnki.net

and interpolation mechanisms, while improving the Hungarian algorithm's matching accuracy through a multi-feature weighted fusion strategy, which ultimately achieves accurate vehicle tracking and vehicle motion parameter measurement. Meanwhile, a parameter compensation mechanism is applied to adjust the measured motion parameters, enhancing the accuracy of the vehicle motion measurement.

In the experimental part, this thesis experimentally verifies the effectiveness of the system in vehicle motion parameter measurement by using video data under different conditions. The experimental results show that a higher frame rate can help the system capture the complex behaviors of the vehicle such as turning and accelerating, reduce the errors caused by motion blurring problems, and thus improve the measurement accuracy of the system.

The online measurement system of vehicle motion parameters based on high-speed imaging proposed in this thesis achieves high-precision measurement of vehicle motion parameters by virtue of accurate camera calibration, high-frame-rate image acquisition and accurate method for motion parameter measurement. Meanwhile, this system exhibits exceptional robustness, offering substantial technical support for intelligent transportation metrology, and plays a crucial role in advancing the development of intelligent transportation technology.

Keywords: Motion Parameter Measurement; Intelligent Transportation; High-Speed Imaging; Camera Self-Calibration; Extended Kalman Filter

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 相机标定技术研究现状.....3
1.2.2 车辆运动参数测量技术研究现状.....6
1.3 本文主要研究内容.....8
1.4 论文组织结构.....9
第 2 章 基于高速成像的车辆运动参数在线测量系统.....11
2.1 引言.....11
2.2 系统测量原理.....11
2.2.1 图像采集与成像模型.....11
2.2.2 车辆运动状态模型.....17
2.3 系统硬件结构设计.....19
2.4 系统软件结构设计.....22
2.5 本章小结.....24
第 3 章 交通监控相机自标定方法研究.....25
3.1 引言.....25
3.2 传统相机标定方法.....25
3.3 交通监控相机自标定方法.....29
3.4 基于 MST 聚类优化的消失点相机自标定.....31
3.4.1 线段提取与方向表示.....33
3.4.2 霍夫空间投影与候选点生成.....35
3.4.3 基于最小生成树的消失点聚类与优化.....37
3.4.4 相机内外参数求解.....40
3.5 相机标定算法性能验证.....43
3.6 本章小结.....46
第 4 章 基于平滑 EKF 的车辆跟踪和运动参数测量方法.....47
4.1 引言.....47
4.2 扩展卡尔曼滤波的研究和优化.....47
4.2.1 扩展卡尔曼滤波的基础原理.....47
4.2.2 后向平滑的扩展卡尔曼滤波.....49
4.3 车辆关联匹配与跟踪实现.....52
4.3.1 二分图匹配和匈牙利算法.....52
4.3.2 多特征加权融合.....54

中国知网 https://www.cnki.net

4.3.3 车辆匹配跟踪策略.....56
4.4 车辆运动参数测量与补偿策略.....59
4.4.1 车辆运动参数测量.....59
4.4.2 运动参数的校验与补偿.....62
4.5 本章小结.....65
第 5 章 运动参数测量与实验结果分析.....67
5.1 引言.....67
5.2 实验环境和测试设置.....67
5.2.1 实验准备.....67
5.2.2 实验数据采集.....68
5.3 基于相机标定的参数测量与分析.....69
5.3.1 车辆轨迹及轨迹曲率测量分析.....69
5.3.2 速度与加速度测量分析.....70
5.3.3 航向角与转向角测量分析.....72
5.4 高速成像对测量结果的影响.....73
5.4.1 帧率对测量精度的影响.....73
5.4.2 系统处理性能分析和评价.....77
5.5 本章小结.....78
第 6 章 总结与展望.....79
6.1 本文总结.....79
6.2 工作展望.....80
参考文献.....81

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景与意义

随着城市化进程的不断加快和交通流量不断增长，交通拥堵现象变得越来越严重，这给城市交通管理带来了前所未有的严峻考验[1,2]。传统的车辆运动参数测量技术大多数都是使用毫米波雷达、地磁感应线圈及视频监控等手段，这些技术虽然在主干道监控领域已相对成熟，但在中小型道路的监控广度与数据精确度上却表现出明显的局限性，所以亟需更为高效且精确的测量技术来填补这一空白。

如何准确地测量车辆的运动参数，已经成为影响智能交通系统（Intelligent Traffic System, ITS）发展的重要问题[3]。随着图像处理技术视觉技术的突飞猛进[4]，对动态车辆的检测和运动参数的测量也产生了新的技术理念。借助高帧率的摄像设备与尖端的计算机视觉算法，在不干扰正常交通秩序的前提下，高精度测量车辆的运动参数。机器视觉技术还能灵活应对多样化的道路和光照变化，展现出强大的广泛的适用性，为智能交通管理领域带来了全新的解决方案[5,6]。图 1-1 为智能交通监控系统示意图。

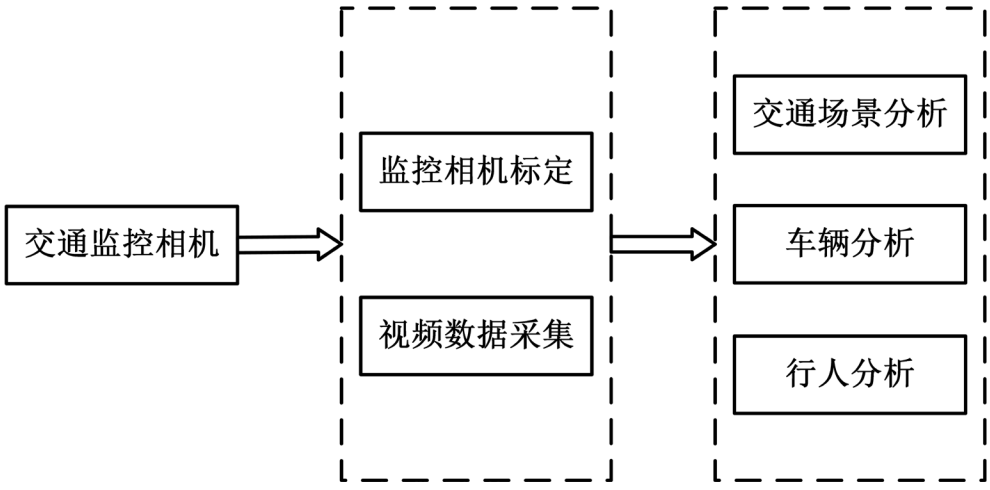


图 1-1 智能交通监控系统示意图

中国知网 https://www.cnki.net

车辆运动参数的精确测量技术已经被视为智慧交通体系中不可或缺的一部分。对车辆运动参数进行准确地测量，不仅能提升交通管理的效能，还能为城市道路的合理规划及交通计量领域的发展提供坚实的科学支撑。因此，开发一套高效且精确的车辆运动参数测量系统，不仅能够弥补传统交通监控技术的不足，还能够促进智慧交通、国防监控等多个领域的技术发展，其应用领域十分广泛[7]。

本研究致力于构建一套基于高速成像的车辆运动参数在线测量系统，旨在突破传统传感器技术的局限性，为交通管理、交通计量及动态目标监控领域提供技术支撑，并且可以在下列领域中实现具体应用：

（1）城市交通智能化管理。交通运输的发展对城市交通监控的需求日益增加，目前城市通常采用地感线圈、毫米波雷达等地面传感器来实现交通监控，这些方法存在布设困难、精度不足的问题。基于高速成像的车辆运动参数在线测量系统将交通监控相机和机器视觉技术进行结合，能够实现对交通流的精细监测，为智能交通管理与计量提供强有力的数据支撑，助力城市交通监控体系的智能化升级。

（2）城市道路布局规划。城市道路的布局规划对于一个城市的发展以及人们生活的便利性有着极大地影响。本研究课题可以对城市任意路段的车辆行驶轨迹、车速变化等关键数据进行精确测量。该测量结果可以为城市道路规划管理人员提供详细的数据支持，助力他们优化道路网络布局，从而全面提升城市交通系统的综合运行效能。

（3）国防应用的目标监测。在国防领域中，本研究课题内容可实现对战场动态中目标车辆的智能预警与实时运动参数测量，可以为军事决策提供重要的数据支持。

1.2 国内外研究现状

随着交通计量领域的不断发展，对车辆运动行为的捕获和车辆运动参数的量化变得越来越重要。相机标定技术作为车辆运动参数精准测量的基石，其主要作用是实现二维图像中车辆位置与三维世界中车辆位置的坐标转换，是保障车辆运动参数测量准确性和可靠性的基础[8,9]。

中国知网 https://www.cnki.net

从车辆的运动参数测量技术发展来看，从早期的利用地感线圈、毫米波雷达等传感器进行测量，到今天的以视频图像为基础的非接触式测量，这些测量技术在测量精度上有了明显的提高，而且在测量范围和适应性上都表现出了很强的潜力。提升车辆运动参数检测的准确性和可靠性，能够为智能交通系统的发展提供更为坚实的数据支持[10,11]。

在上述背景下，深入研究相机标定技术与车辆运动参数测量技术的最新进展，不仅能为本课题研究奠定坚实的理论基础，更能明晰当前各项技术发展的瓶颈所在，以下将介绍本课题研究内容的研究现状。

1.2.1 相机标定技术研究现状

相机标定是机器视觉和图像测量应用中必不可少的关键步骤。通过完成相机标定步骤能够获得相机成像几何模型的内外参数，利用改参数就可以计算出三维空间中点与二维图像中点的对应关系。一般来说，常用的相机标定方法有传统相机标定法[12]、基于主动视觉相机标定法[13]和相机自标定法[14]。

传统相机标定法[15,16]适用于各种相机模型，通常具有较高的精度，但标定过程中需要使用标定物通过相机采集两幅以上的标定物图像，需要建立标定物上已知坐标点与二维图像点之间的对应关系，并采用特定算法求解相机模型的内外参数。常见的传统标定方法包括直接线性法[17]、Tsai 两步法[18]、张氏标定法[19]等方法。

基于主动视觉的相机标定法则是利用已知的相机运动信息来进行标定。Tardif 等[20]人通过让相机绕特定轴进行两次旋转，再通过闭式方程组求解相机内参数。Dron[21]让相机按照规定方向做平面运动，再通过最小二乘法求解相机内参数。吴福朝和李华等[22]人通过获取相机的 N 组正交平移运动来线性求解相机的内参数，该方法不依赖标定物，算法简便且具有较高的鲁棒性，但其缺点是成本较高且设备昂贵。

本文在相机标定方面重点研究相机自标定算法。早期的相机自标定方法主要是基于几何约束模型[23]进行标定的，这些方法的核心在于通过

中国知网 https://www.cnki.net

道路特征的几何关系计算相机的内外参数，使用比较广泛的是基于消失点的相机自标定方法[24]。在 1992 年 Mayban 和 Faugeras[25]提出了一种相机的自标定算法，这种方法不需要在相机视野中放置规格已知的标定物，仅仅是利用二次曲线或曲面进行相机参数的求解。但这种算法的鲁棒性较差，且对相机的运动约束条件较高，这导致该方法在实际应用中并不实用。1981 年 Fischler 和 Bolles[26]提出了 RANSAC 算法，该方法降低了标定过程中噪声对标定结果的影响，RANSAC 算法被广泛应用于优化参数估计阶段。2007 年段成钢[27]利用自然场景中三组两两正交的平行线所获得的消失点作为约束条件，对摄像机参数进行优化标定。2009 年 Lepetit 等[28]提出的 EPnP 算法显著提高了 PnP 问题的求解效率，在保留计算精度的同时减少了计算时间，该方法是相机外参估计的重要工具。2014 年 Zheng 等[29]提出了一种简单实用的路侧相机动态标定方法，利用多个视频帧观测到的消失点进行相机标定，并通过最小二乘法来优化相机标定精度。2016 年 Zhai 等[30]提出基于全局图像上下文的消失点检测方法，改进了复杂场景中的初始估计精度，该标定方法特别适用于非曼哈顿世界场景的相机自标定。

从车道信息和运动轨迹约束方面进行相机自标定工作也引起了国内外研究人员的广泛关注。张润初等[31]提出了一种基于参考图像与路面信息的的道路监控摄像机标定方法，利用车道标线宽度、间距以及垂直线段来估计摄像机参数，包括焦距、俯角等关键信息。2009 年 Juan 等[32]提出了一种新的单摄像机交通监控标定算法，从道路车道线自动获取标定图案，实现了快速标定。2013 年 Zhang 和 Tan 等[33]提出了一种利用交通场景中移动物体进行相机标定的方法，该方法通过分析车辆运动轨迹来计算相机参数，适用于各种交通监控场景中的相机标定。2014 年 Wan[34]利用道路中的标记点作为已知的三维参考点进行相机的自动标定，这种方法减少了对人工干预的依赖，提高了标定的效率和准确性。2015 年 Dubska 和 Herout[35]提出了一种全自动的路边相机标定方法，该方法利用特征点轨迹分析实现全自动路边相机标定，进一步提高了相机自标定的效率和精度。

中国知网 https://www.cnki.net

随着计算能力的提升，优化算法在相机自动标定中的应用逐渐增多，增强了传统方法的鲁棒性和精度。2013 年 Dawson 和 Birchfield[36]利用能量最小化框架结合马尔科夫链蒙特卡洛（MCMC）优化道路模型，以求实现交通摄像头自动标定，显著提高了参数估计的准确性。2017 年 Fuhr[37]提出了一种新的静态相机自标定方法，利用非线性优化函数改进初始估计，提高标定精度，特别适用于监控应用，增强了静态相机标定的适用性。结合多源信息方面，2010 年 Kanhere 等[24]提出过约束标定方法，将所有可用的测量值纳入计算，从而减少了误差，克服了单消失点方案的模糊性问题。2017 年 Bhardwaj 等[12]利用 3D 地图和车辆轨迹信息，提出了 AutoCalib 方法，实现了大规模的相机自动标定，简化了交通监控系统中大规模相机部署的标定流程。

随着深度学习技术在场景理解和特征表达中展现了显著的优势，国内外研究人员也开始探索基于深度学习的相机自动标定技术，以进一步提升传统相机标定方法的标定效率和标定精度。2016 年 Borji[38]首次将卷积神经网络（CNN）引入消失点检测任务，大幅提升了消失点检测的鲁棒性，这是深度学习技术在相机标定中最早的应用。2015 年 Yang[39]发布的大规模汽车数据集，包含车辆的精细分类和验证信息，为基于检测和跟踪的相机自动标定方法提供了训练和验证数据支持。2018 年 Chang 等[40]提出 DeepVP 消失点检测框架，该框架通过大规模街景数据训练，显著提高了实际场景中的相机标定精度。2023 年 Zhang 等[41]利用深度卷积神经网络从多车辆轨迹中估计正交消失点，再使用这些消失点解算相机的内外参数，不仅求解出相机的高度，还实现了完全自动化的相机标定。2022 年 SonHongPhan[42]提出了结合霍夫变换和边缘检测的全自动相机标定方法，该方法展现出了较高的可靠性。

综合来看，现有的相机标定方法虽然在鲁棒性和精度计算方面表现良好，但是大多数方法仍存在复杂场景适应性不足、计算效率与精度难以兼顾以及自动化程度有限的问题，未来的研究重点应该放在提高标定算法的场景适应性以及推动无人工干预的自适应标定技术的发展上。

中国知网 https://www.cnki.net

1.2.2 车辆运动参数测量技术研究现状

相机标定参数可以用于车辆速度估计[43,44]，车辆定位[45]和车道偏离预警[46]，对车辆运动参数进行准确测量，以提高交通监控系统的控制和安全性。

早期的车辆运动参数测量技术大多是基于经典物理模型和几何关系展开的，这些方法仅通过简单的优化技术对车辆的运动状态进行推算，在结构简单和计算量较小的条件下能够实现一定的测量精度，但在复杂环境中仍然存在局限性[47,48]。

目前常用的车辆运动参数测量方法是基于惯性传感器与物理模型的方法。2019 年杨澜等[49]提出了基于惯性传感器的车辆运动参数测量方法，能够实时计算姿态参数，还提出来一种姿态融合估计结构，实现了车辆姿态观测信息的实时最优关联在一定程度上提升了复杂场景的测量鲁棒性。2020 年 Kichun Jo 等[50]采用多传感器融合的方法，结合道路坡度信息和动力学模型，提出了一种道路坡度辅助的位置估计算法，该算法能够补偿受到道路坡度影响的车辆运动模型，改进了复杂路况中的车辆位置的估算精度。2023 年袁见等[51]通过构建四种基于机器学习的车道级车流实时溯源模型，解决了车道中车流的运动溯源问题，并且利用几何约束方法和交通波分析对车辆的运动参数进行了测量。2024 年 Zhao 等[52]将对约束最优控制方法与驾驶行为模式进行结合，在尊重车辆动力学和运动约束的同时，输出 2D 轨迹并且以最小化重构轨迹相对于测量轨迹的误差，实现了二维轨迹的高精度重建。

毫米波雷达和视觉传感器在车辆运动测量领域的应用逐渐增多，成为多传感器融合测量的重要组成部分。2022 年王俊骅等[53]提出一种基于毫米波雷达的全域车辆轨迹跟踪技术方法，能够实现设备内部及跨设备对车辆轨迹的持续跟踪，还提升了动态场景中遮挡问题的处理能力。2021 年 Li 等[54]提出了一种新的基于学习的框架，从通过单目视觉估计车辆姿态并重建运动参数，提取有意义的中间几何表示来估计自我中心车辆方向，减少了标定误差对测量的影响。2021 年 Wang 等[55]提出了一种基于

中国知网 https://www.cnki.net

深度学习的运动参数测量算法，通过将深度学习和模板匹配进行结合，实现了相关物体的快速跟踪技术的优化。

深度学习技术有助于提高了复杂环境下的运动参数测量精度和效率。2021 年黄士琛等[56]构建了基于数据增强的 LSTM-AE-Attention 深度学习模型，利用深度卷积神经网络重建车辆轨迹并检测异常轨迹，实现了车辆轨迹数据的平滑和异常车辆轨迹纠正。2022 年 Liu 等[57]提出了一种面向周边车辆交互轨迹预测的驾驶风险图-集成深度学习（DRM-DL）方法，综合考虑了运动不确定性、轨迹意图不确定性以及车道线和道路边界之间的交互影响，显著增强了复杂环境下的轨迹预测能力。2023 年 Wojke 等[58]提出了 DeepSORT 算法，该算法深度学习技术对 SORT 跟踪算法进行了改进，通过融合外观信息来提高 SORT 的性能。2023 年 Tian 等[59]提出浅层特征融合技术，开发了一种基于检测跟踪的车辆监控和计数的创新架构，通过优化多目标车辆跟踪方法的实时性和精度，解决了常见的目标遮挡、重复标号的问题。

为了提高运动参数的测量精度与鲁棒性，近年来的研究更加注重参数自适应方法的开发和传感器精度的提升。2020 年 Ansaripour 等[60]结合超宽带无线电技术和视觉信息，提出了一个基于 UWB 的姿态估计系统，该系统使用低通滤波器和参考选择的方法减少了非视距传输在测量中的影响，实现了对车辆姿态的精准测量。2022 年 Chen 等[61]提出了一种新的微观视角下的参数测量框架，该框架利用多传感器融合方法对估计轨迹进行集成，同时以最小化误差为目标对上下游分离得到的估计轨迹进行融合，提升了车辆轨迹数据的完整性和可靠性。2024 年 Song 等[62]开发了参数自适应控制框架，建立线性二次型调节器（LQR）和三个鲁棒控制器的同时，以模块化的方式解决轨迹跟踪和运动控制，显著提高了自动驾驶车辆的轨迹跟踪与运动控制性能。2017 年 Sochor 等[43]提出了一种基于 3D 模型边界框对齐的交通监控相机标定法，该方法将检测到的车辆与 3D 模型进行对齐匹配并自动推断相机的参数，实现了对车辆运动速度的准确测量。

随着道路数据的大规模增加，车辆运动参数的测量技术正逐步向实

中国知网 https://www.cnki.net

用化和系统化的方向发展。2023 年 Su 等[63]提出了一个通用的重建车辆轨迹的框架，该框架通过路侧感知数据重建全部实验数据的连续轨迹，为交通管理提供了有力的支持。2023 年袁见等[51]结合交通流特征提出了一种车流溯源方法，该方法构建了四种基于机器学习的车流实时溯源模型，解决了大范围车辆流量溯源问题。2016 年 Bewley 等[64]针对复杂城市道路场景中的在线多目标跟踪方法的难点，提出了一种实用的多目标跟踪方法，该方法做到了在线和实时地关联目标，提升了测量的适应性和实时性。2019 年，Sochor 等[44]人提供了一个用于单目相机视觉测速的综合数据集，该数据集包含精丰富的速度测量数据和相机标定信息，为研究和评估自动相机标定和速度测量方法提供了宝贵的资源。

综合来看，这些研究为智能交通和智能驾驶技术提供了技术支撑，同时推动了车辆运动参数测量技术的发展与应用。车辆运动参数测量技术车辆运动参数测量技术正从单一模型向多传感器融合[65,66]、深度学习[55,67]。和自适应控制融合[68]的方向发展，显著提升了复杂场景下的精度、鲁棒性和实时性。未来，技术的实用化、系统化以及数据集的完善将是研究重点，这些工作将为交通监控和交通计量提供更可靠支持。

1.3 本文主要研究内容

通过对现有相机标定技术和车辆运动参数测量技术的研究，发现目前这两项技术存在瓶颈。具体来说是

（1）相机标定准确性和稳定性问题。传统相机标定方法比较依赖标定物，而且对人工干预的依赖性比较强，同时现有的标定方法较为耗时，无法满足交通监控场景中对实时性和自动化标定的需求。

（2）车辆运动参数测量技术存在多传感器融合的复杂性和技术实用化问题。虽然传感器融合（如视觉、激光雷达、毫米波雷达等）能够提高测量精度，但在实时性、计算效率和数据同步方面仍存在显著的挑战[69,70]。同时在动态交通场景中，复杂背景以及车辆行为的快速变化会显著降低运动参数测量的稳定性和可靠性。

针对相机标定的准确性和稳定性问题以及车辆运动参数测量技术在

中国知网 https://www.cnki.net

复杂交通环境中的局限性问题，本研究提出了一系列改进与优化方案，研究内容主要包括以下四个方面：

（1）测量系统设计研究：本文设计了一套适用于动态交通场景的车辆运动参数在线测量系统。采用高帧率成像技术，提升了动态场景中对快速运动目标的捕获能力，确保数据采集的完整性和精确性。然后利用相机自标定参数对图像坐标中的车辆位置与三维世界坐标中的车辆位置进行转换，实现准确的车辆运动参数测量。

（2）大视野交通监控相机标定技术研究：为了适应大视野监控场景的复杂需求，本研究通过最小生成树（Minimum Spanning Tree, MST）算法提升消失点寻找的准确性，解决了大视野场景下的相机自标定精度不稳定的问题。同时该方法减少了人工干预，提高了标定的鲁棒性和自适应性，为后续将图像坐标系下的车辆运动转换到世界坐标系下的车辆运动打下了基础。

（3）车辆运动跟踪和参数测量方法的研究：为解决在动态场景中的性能瓶颈以及运动参数测量误差问题，本文对扩展卡尔曼滤波器（Extended Kalman Filter, EKF）进行后向平滑插值优化，再配合多特征加权融合技术，实现了准确的车辆跟踪。最后通过连续时间内车辆轨迹数据的分析，对车辆轨迹、轨迹曲率、速度、加速度、航向角和转向角这六种参数进行高精度的测量和补偿。

（4）实验验证分析：为验证本文所提车辆运动参数测量系统和车辆运动参数测量方法的性能，本文利用真实车辆运动数据，对车辆运动参数进行测量，同时对不同光照条件和帧率条件下的系统性能进行验证，重点测试系统车辆运动参数测量的精度和系统的测量效率。

以上研究内容是为了解决目前相机标定技术与车辆运动参数测量技术在交通场景中的技术瓶颈，旨在为智能交通和交通计量行业的发展提供高效、可靠的技术支持。

1.4 论文组织结构

在分析了现有的技术之后，本文将研究重点放在交通监控相机自标

中国知网 https://www.cnki.net

定方法研究以及车辆跟踪和运动参数测量方法上，本文具体结构安排如下：

第一章：绪论。本章首先介绍本论文研究背景，分析车辆运动参数测量技术在智能交通和交通计量领域的关键作用，总结了研究意义。其次介绍相机标定技术和车辆运动参数测量技术的国内外研究现状，针对现存的不足，介绍本文的研究目的和主要工作，最后明确了本文的章节安排。

第二章：基于高速成像的车辆运动参数在线测量系统。本章设计了一套车辆运动参数测量系统，分析了其测量原理和功能。还介绍了系统硬件设计、核心硬件的选型、系统软件结构设计和数据处理流程，搭建出了一套完整的系统，为后续实验提供支撑。

第三章：交通监控相机自标定方法研究。针对大视野交通监控场景中相机标定的挑战，本章基于线段提取与方向聚类方法，利用最小生成树优化了三方向消失点的提取，实现了稳定的相机自标定，重点解决大视野下的交通监控相机自标定结果不稳定的难题。

第四章：基于平滑 EKF 的车辆跟踪和运动参数测量方法。本章详细探讨了基于平滑优化的扩展卡尔曼滤波器原理与车辆运动参数测量新方法，该方法通过引入后向平滑和插值机制对传统的扩展卡尔曼滤波器进行了优化，然后利用多特征加权融合策略提升了匈牙利算法的匹配精度，最终实现了准确的车辆跟踪和车辆运动参数测量。同时利用参数补偿机制对测量的运动参数进行补偿，提高了车辆运动参数测量的准确度。

第五章：运动参数测量与实验结果分析。本章对基于高速成像的车辆运动参数测量系统进行实验验证，并进行实验结果分析，还对系统的处理性能进行了总结。

第六章：总结与展望。总结了本文在系统设计、相机自标定技术改进和车辆运动参数测量方法优化这三个方面的实际贡献，并对系统未来的改进优化提出了建议。

中国知网 https://www.cnki.net

第 2 章 基于高速成像的车辆运动参数在线测量系统

2.1 引言

随着智能交通系统（ITS）的快速发展，基于视觉的车辆运动参数测量技术得到了广泛应用。相比于传统的雷达、激光和地感线圈等测量技术，视觉测量技术具有非接触、低成本和高精度的优点。研究开发基于高速成像的车辆运动参数在线测量系统，对于促进交通计量领域的进步和智慧交通的发展具有重要意义。

本章将对系统的总体设计框架与测量原理进行详细介绍，还对系统的硬件组成和软件模块设计进行了介绍，这些内容为后续章节的算法设计与性能验证打下了基础。

2.2 系统测量原理

2.2.1 图像采集与成像模型

本研究设计的基于高速成像的车辆运动参数测量系统，工作流程涵盖了图像采集、相机标定、车辆运动参数计算等环节。以下将详细说明系统的测量原理，图 2-1 是采集装置示意图。

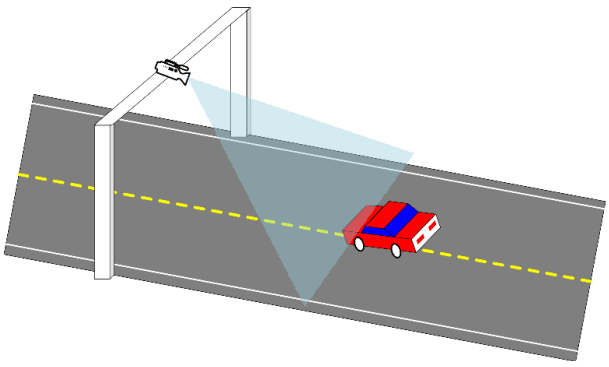


图 2-1 采集装置示意图

如图 2-1 所示，本系统将高速相机固定在龙门架上，倾斜拍摄道路场

中国知网 https://www.cnki.net

景。通过相机的高帧率采集视频，捕捉车辆运动过程中的关键帧。

车辆的运动视频采集是基于工业高速相机的针孔成像模型，该模型一共涉及四个坐标系：世界坐标系、相机坐标系、图像坐标系和像素坐标系。各个坐标系的基本概念如图 2-2 所示：

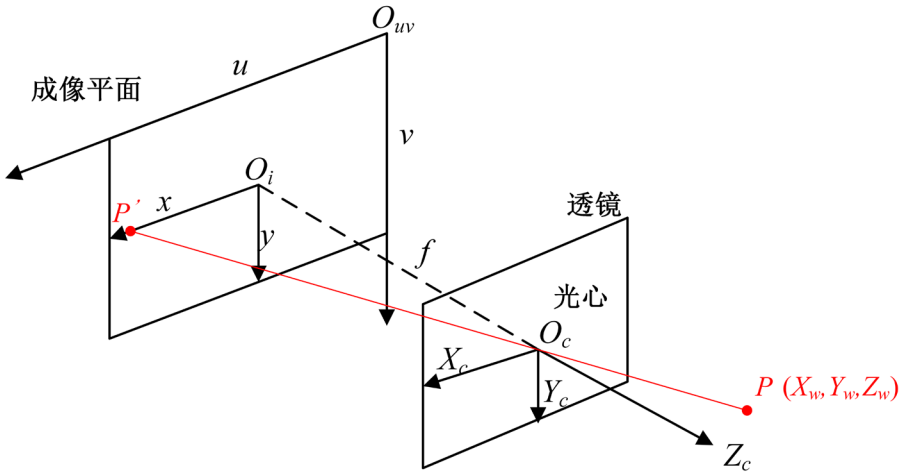


图 2-2 相机小孔成像模型

世界坐标系：用三维直角坐标系 O_w-$X_wY_wZ_w$ 表示，以(X_w, Y_w, Z_w)表示坐标系中点的位置，在这个坐标系中，原点 O_w 可以是任意参考点，X_w、Y_w 和 Z_w 是某点在世界坐标系中的三个坐标轴上的投影。

相机坐标系：用三维直角坐标系 O_c-$X_cY_cZ_c$ 表示，以(X_c, Y_c, Z_c)表示坐标系中点的位置。在这个坐标系中，原点 O_c 通常位于相机的光学中心，X_c 和 Y_c 轴分别定义了相机平面的水平和垂直方向，Z_c 轴指向相机的前方。

图像坐标系：用二维坐标系 O_i-xy 表示，以(x, y)表示坐标系中点的位置。在这个坐标系中，原点 O_i 通常位于图像的中心位置，x 轴向右，y 轴向下。

像素坐标系：用二维坐标系 O_p-uv 表示，以(u, v)表示坐标系中点的位置。在这个坐标系中，原点 O_p 通常位于图像的左上角，u 轴向右，v 轴向下。在这个坐标系中，像素坐标系中的每个单位代表一个像素的大小。

四个坐标系位置如图 2-3 所示：

中国知网 https://www.cnki.net

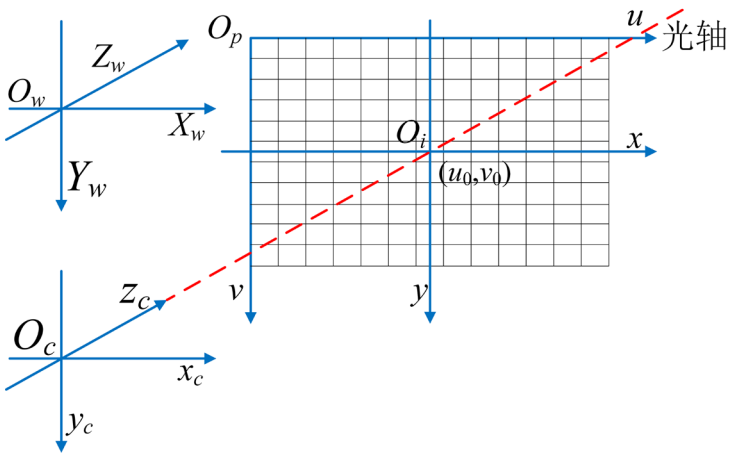


图 2-3 四大坐标系位置示意图

相机标定就是通过建立二维图像平面与三维世界空间之间的映射关系来求解相机参数的过程。这一过程可以分为刚体变化、透视投影和平移变换三个转换步骤[71]，具体可表示为图 2-4。

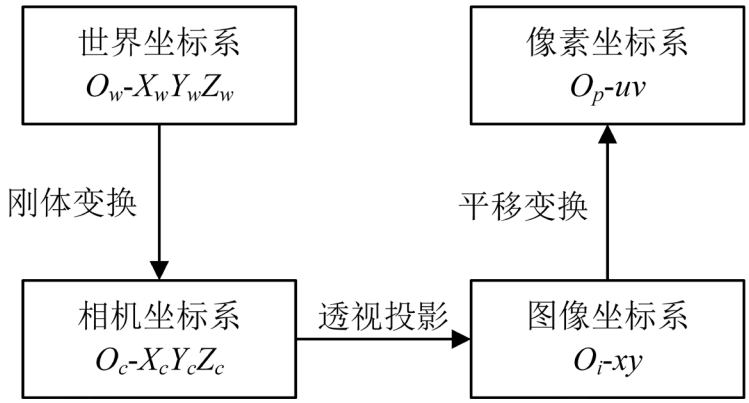


图 2-4 坐标系转换过程

（1）刚体变换：世界坐标系转相机坐标系

刚体变换（Rigid Transformation）是指将物体从一个坐标系移动到另一个坐标系。它主要包括旋转和平移两种移动方式，旋转是绕着某个轴的转动，用旋转矩阵 **R** 来表示。平移是沿着某个方向移动一定距离，用平移向量 **T** 来表示。如下图所示，世界坐标系先分别绕 X_w，Y_w，Z_w 轴旋转不同的角度，再进行平移，即可以转换到相机坐标系。

中国知网 https://www.cnki.net

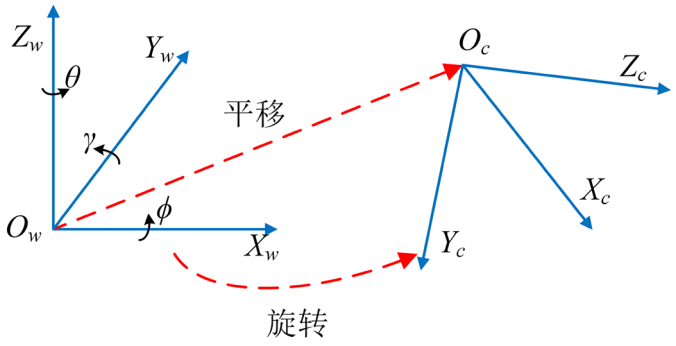


图 2-5 刚体变换示意图

旋转矩阵 **R** 表示为：

$$\mathbf{R}=\begin{bmatrix} r_{00} & r_{01} & r_{02} \\ r_{10} & r_{11} & r_{12} \\ r_{20} & r_{21} & r_{22} \end{bmatrix} \tag{2-1}$$

平移向量 **T** 表示为：

$$\mathbf{T}=\begin{bmatrix} t_x \\ t_y \\ t_z \end{bmatrix} \tag{2-2}$$

将旋转矩阵 **R** 和平移向量 **T** 组合起来，就可以得到从世界坐标系到相机坐标系的刚体变换矩阵。

如果世界坐标系中的点用(X_w, Y_w, Z_w)表示，相机坐标系的点用(X_c, Y_c, Z_c)表示，那么由世界坐标系点与相机坐标系点之间的刚体变换的过程可以表示为：

$$\begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix}=\begin{bmatrix} r_{00} & r_{01} & r_{02} & t_x \\ r_{10} & r_{11} & r_{12} & t_y \\ r_{20} & r_{21} & r_{22} & t_z \\ 0 & 0 & 0 & 1 \end{bmatrix}\begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}=\begin{bmatrix} \mathbf{R} & \mathbf{T} \\ \vec{0} & 1 \end{bmatrix}\begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \tag{2-3}$$

（2）透视投影：相机坐标系转图像坐标系

透视投影变换模拟了人眼观察世界的方式，即近处的物体看起来更大，远处的物体看起来更小。这种投影方式使得物体在图像中的大小与其距离相机的远近有关。

中国知网 https://www.cnki.net

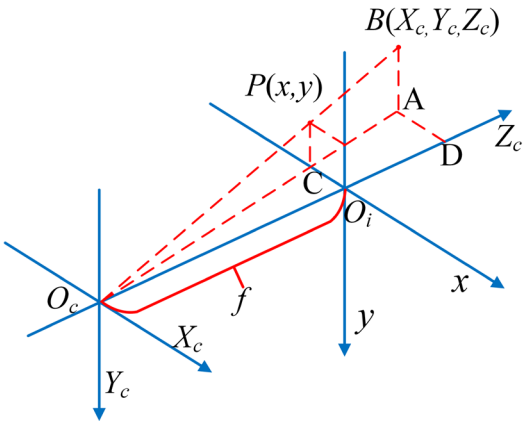


图 2-6 透视投影示意图

如图 2-6 所示将，相机坐标系中的 B 点(X_c, Y_c, Z_c)透视投影到图像坐标系中的 P 点(x, y)。点 A 为点 B 在相机坐标系 X_c-Z_c 平面上的投影，点 D 为点 B 在 Z_c 轴上的垂足，点 C 是直线 AO_c 在成像平面上的交点，O_cO_i 为相机焦距 f。

投影过程可以使用相似三角形的关系来求解，通常涉及到除以 Z_c 坐标，这模拟了透视效果：

$$x=\frac{Xc}{Zc}\cdot f,\qquad y=\frac{Yc}{Zc}\cdot f \tag{2-4}$$

转换为齐次坐标就可以得到相机坐标系与图像坐标系的转换关系：

$$\begin{bmatrix}X_c\\Y_c\\Z_c\\1\end{bmatrix}=\begin{bmatrix}\frac{Z_c}{f}&0&0\\0&\frac{Z_c}{f}&0\\0&0&Z_c\\0&0&1\end{bmatrix}\begin{bmatrix}x\\y\\1\end{bmatrix} \tag{2-5}$$

这种投影方式在二维图像上模拟了三维空间的透视效果。

（3）平移变换：图像坐标系转像素坐标系

平移变换（Translation Transformation）是将图像坐标系中的点转换到像素坐标系中的过程，该过程是按照像素的物理尺寸对图像坐标进行缩放和平移来完成的。图像坐标系的原点通常位于图像中心，而像素坐标系的原点则位于图像的左上角。平移变换的转换公式是：

中国知网 https://www.cnki.net

$$u = x \cdot s_x + c_x, \qquad v = y \cdot s_y + c_y \tag{2-6}$$

其中 s_x 和 s_y 是图像的缩放因子，c_x 和 c_y 是坐标系原点的偏移量。

将像素坐标系的原点 O_p 平移到图像的中心，就变化为图像坐标系的原点 O_i。

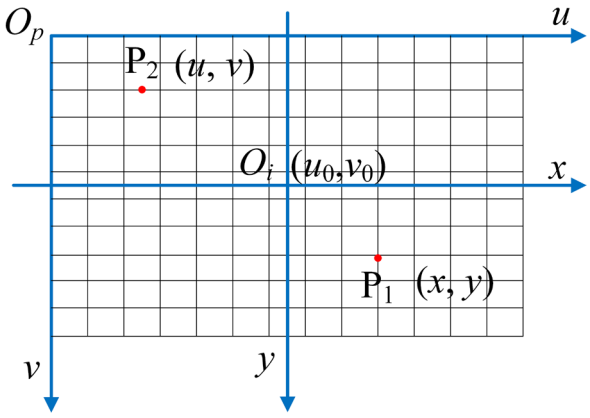


图 2-7 平移变换示意图

在图 2-7 中，假设图像中心的像素坐标是(u_0, v_0)，相机的 CMOS 传感器的每个像素的物理尺寸是 $d_x * d_y$，那么图像坐标系的坐标(x,y)与像素坐标系下的坐标(u, v)之间的关系可以表示为：

$$\begin{cases} x = udx - u_0 dx \\ y = vdy - v_0 dy \end{cases} \tag{2-7}$$

写成矩阵的形式是：

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} dx & 0 \\ 0 & dy \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} \begin{bmatrix} -u_0 dx \\ -v_0 dy \end{bmatrix} \tag{2-8}$$

改写为齐次坐标的形式是（齐次坐标系能够明显的区分点与向量，并且便于计算机做图形处理时进行仿射变换的坐标系）：

$$\begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} dx & 0 & 0 \\ 0 & dy & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} u \\ v \\ 0 \end{bmatrix} + \begin{bmatrix} -u_0 dx \\ -v_0 dy \\ 1 \end{bmatrix} = \begin{bmatrix} dx & 0 & -u_0 dx \\ 0 & dy & -v_0 dy \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} \tag{2-9}$$

该变换可以在图像上准确地找到像素位置，这一变化在图像处理和图像分析中是非常重要的。结合四个变换的公式，可以得到某点从像素坐标系到世界坐标系的变换关系：

中国知网 https://www.cnki.net

$$\begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} = \begin{bmatrix} \mathbf{R} & \mathbf{T} \\ \bar{0} & 1 \end{bmatrix} \begin{bmatrix} \frac{Z_c dx}{f} & 0 & \frac{-Z_c u_0 dx}{f} \\ 0 & \frac{Z_c dy}{f} & \frac{-Z_c v_0 dx}{f} \\ 0 & 0 & Z_c \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} \tag{2-10}$$

外参由旋转矩阵 **R** 和平移矩阵 **T** 组成，其物理含义就是相机相对于世界坐标系的旋转和平移变换关系。内参主要包括焦距 f 和像元尺寸，是相机的固有参数，Z_c 表示物体离光学中心的距离。

2.2.2 车辆运动状态模型

车辆运动状态模型的作用是描述车辆在道路上的位姿变化和车辆运动特性的。为满足车辆跟踪和车辆运动参数测量的准确度要求，本文采用单车模型（Bicycle Model）作为车辆运动学的描述框架。

单车模型是一种经典的车辆运动学模型，该模型能够准确表达车辆的运动特性，尤其适用于平面内的车辆运动状态估计，所以该模型在车辆轨迹跟踪、路径规划和状态预测等领域具有广泛应用。

假设车辆运动状态由以下变量描述：点 A、B、C 表示不同时刻车辆重心的位置；ψ 是航向角，表示车辆的航向，即车辆在全局坐标系中的角度；δ 是车辆的转向角；V 是车辆的线速度；L 是车辆的轴距，即前后轮轴之间的距离，L_r 是车辆后轴到重心的距离，L_f 是前轴到重心的距离，且 $L=L_r+L_f$。

单车运动模型原理图如图 2-8 所示。

中国知网 https://www.cnki.net

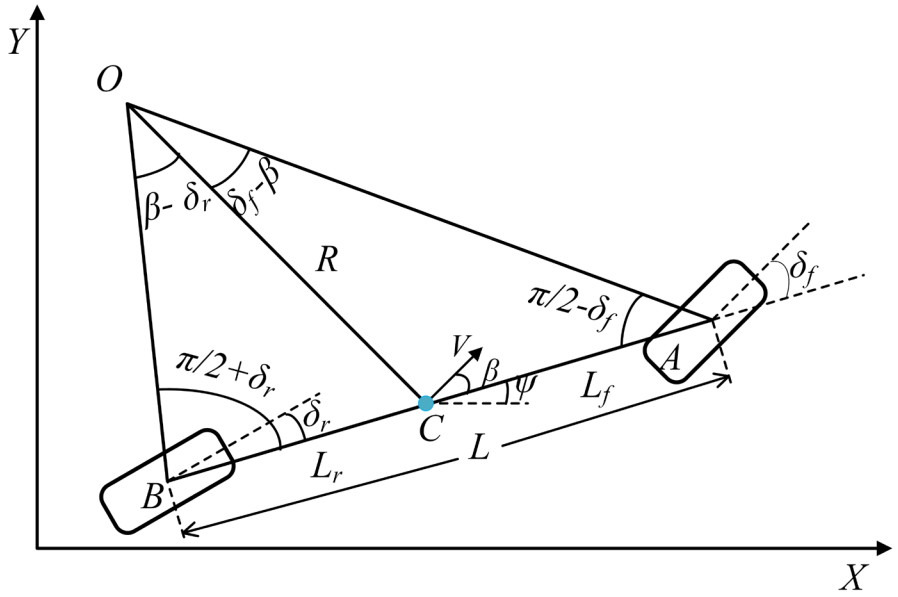


图 2-8 单车模型示意图

单车模型使用一组非线性微分方程来描述车辆状态的变化，公式如下：

$$\begin{aligned} x &= V \cdot \cos(\psi + \beta), \\ y &= V \cdot \sin(\psi + \beta), \\ \psi &= \frac{V}{L_f + L_r} \cdot \tan(\delta_r), \\ \beta &= \arctan\left(\frac{L_r}{L_f + L_r} \cdot \tan(\delta_f) \right) \end{aligned} \tag{2-11}$$

其中，x 和 y 分别表示车辆在平面坐标系中的速度和角速度；ψ 和 β 是航向角和转向角，用于描述车辆重心的运动方向与车辆的转向。

车辆运动参数的测量是本系统的核心功能，主要包括车辆运动轨迹和轨迹曲率、车辆速度和加速度以及航向角和转向角这六种核心运动参数的测量。

（1）运动轨迹和轨迹曲率。车辆轨迹是描述车辆运动过程中质心位置变化的路径，通常用一系列离散的坐标点表示。车辆轨迹可以反映车辆的实际运动路径，将车辆轨迹与其他车辆运动参数相结合，有助于还原车辆行驶路径并分析车辆的异常行为。轨迹曲率的定义为车辆行驶路径在

中国知网 https://www.cnki.net

某一点上的方向变化率，描述的是车辆质心路径的弯曲程度。轨迹曲率是进行车辆轨迹分析的重要参数，通过曲率的变化趋势并结合车辆航向角等参数综合分析，可帮助判断车辆的急转弯、偏航或越线等异常行为。

（2）速度和加速度。速度是描述车辆在单位时间内运动距离的标量，车辆质心在世界坐标系中运动的速率，单位常为米每秒（m/s）。加速度是描述车辆速度变化率的量，车辆质心速度的变化率，本系统主要测量车辆纵向加速度（车辆前后方向）。

（3）航向角和转向角。车辆航向角通常指车辆质心速度与地面坐标系 X 轴的夹角，用于描述物体在全球坐标系中的方向，常用于导航和路径规划中确定车辆的绝对方向，坐标系是地面坐标。车辆转向角是以车辆自身坐标系为准，车辆自身在水平面内的旋转角度，用于描述车辆相对其纵轴（自身坐标系 x 轴）的旋转，常用于动态稳定控制中。车辆转向角通常是局部的，描述车辆在水平面内的旋转运动。

2.3 系统硬件结构设计

（1）相机选型

当前工业相机传感器主要分为 CCD 和 CMOS 这两种，CCD 传感器具有高集成性、低噪声性和高光敏性的特点，但其较低的帧率和较高的功耗限制了其在高速、实时测量场景中的应用。比起传统的 CCD 传感器，CMOS 传感器的多通道并行读取、低功耗、可靠性强等特点更高速运动目标的捕捉需求。此外，CMOS 传感器支持高动态范围（HDR）功能，能够在强光或阴影等复杂光照条件下提供更优质的图像质量。因此本文选用 CMOS 传感器的工业相机作为图像采集设备。

为了满足高速运动目标的捕捉需求，选用千眼狼 5F08 系列高速摄像机。该相机由富煌君达高科自主研发，专门为工业图像处理应用而设计，相机采用高端 CMOS 图像传感器，具备高帧率特性，同时具有体积小、功耗低的优势。

中国知网 https://www.cnki.net

相机实物图如图 2-9 所示。



图 2-9 相机实物图

相机主要性能参数如表 2-1 所示。

表 2-1 相机性能参数表

性能名称	参数	
型号	千眼狼 5F08 系列	
传感器类型	CMOS	
性能名称	参数	
像元尺寸	3.9μm×3.9μm	
分辨率	4096×2048	
帧率	分辨率	帧率
	4096×2048	500FPS
	4096×1024	1000FPS
	4096×64	14500FPS
内存	16GB	
相机尺寸	329mm×160mm×193mm	
数据接口	USB3.0	

根据车辆运动参数的准确测量需求，该相机能够保证对视场中的快速运动车辆进行连续采样，便于捕捉车辆的连续运动特征，有助于提高车辆运动参数测量精度。

中国知网 https://www.cnki.net

（2）镜头选型

镜头在机器视觉系统中扮演着十分重要的角色，镜头的核心功能是将目标物体的图像精准聚焦到相机的光敏元件上，所有的图像信息都需要通过镜头采集，因此镜头的品质好坏直接决定了视觉系统性能的优劣。本系统的镜头选择主要考虑两个因素：

一是选择适合 7 米高龙门架拍摄的广角镜头，确保覆盖双车道以上的拍摄视野，同时保证焦距可调，便于调整视场。

二是选择大光圈、高分辨率的工业镜头，保证图像亮度和边缘清晰度，减少光学畸变。

综合考虑以上两种因素，本系统选择适马（SIGMA）17-50mm F2.8 EX DC OS HSM 镜头，该镜头是一款专为数码单反相机设计的大光圈标准变焦镜头。

相机镜头实物图如图 2-10 所示。



图 2-10 镜头实物图

该镜头核心性能参数表如表 2-2 所示。

表 2-2 镜头性能参数表

性能名称	参数
型号	17-50mm F2.8 EX DC OS HSM
镜头焦距	17-50mm

中国知网 https://www.cnki.net

表 2-2 镜头性能参数表（续）

性能名称	参数
相机接口	F 卡口
最小光圈	F22
最短对焦距离	28cm
芯片尺寸	APS-C（23.5mm×15.6mm）
重量	565g
视场角	79.7°（17mm 端）至 31.7°（50mm 端）
放大倍率	1:5

此适马镜头的最小焦距为 17mm，最大光圈为 F2.8，镜头在整个变焦范围内提供的最小对焦距离为 28cm，最大放大倍率是 1:5，可见镜头能够提供了不错的低光表现和浅景深效果。同时镜头具有出色的周边亮度，即使在最大光圈下也能提供高对比度的图像。值得一提的是，镜头内置了适马独创的 OS（光学稳定器），在提供卓越稳定性的同时，还有助于减少相机抖动带来的模糊。

2.4 系统软件结构设计

系统的软件设计是车辆运动参数测量系统的核心部分，系统软件总体架构图如图 2-11 所示。

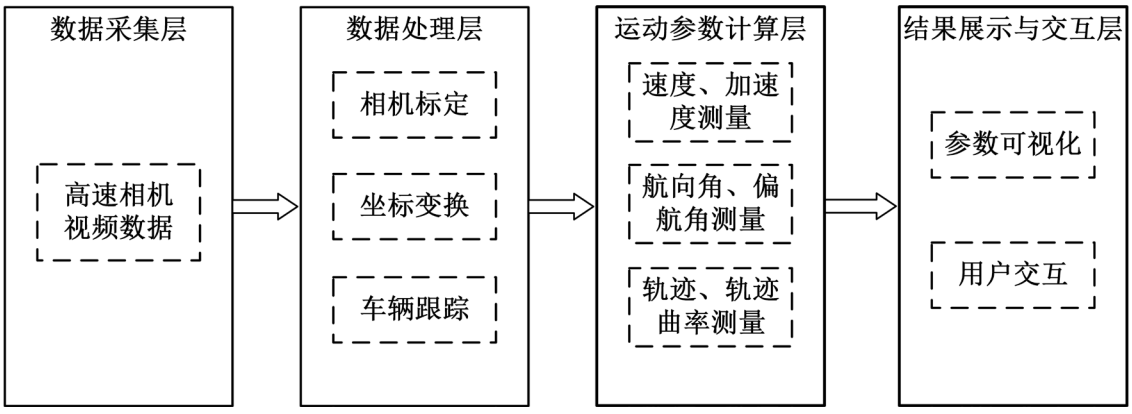


图 2-11 系统软件总体架构图

中国知网 https://www.cnki.net

基于高速成像的车辆运动参数在线测量系统设计目标是实现一套功能完善并且容易维护的软件。所以软件采用模块化设计方法，分为多个功能模块，各模块之间职责明确、接口清晰。以下详细介绍系统总体架构和各模块功能。

系统软件总体架构分为四个主要层次，从底层的数据采集到高层的可视化与交互，分别为数据采集层、数据处理层、运动参数计算层、结果展示与交互层。

（1）数据采集层的功能是通过高速相机采集视频数据，并进行数据管理。实现方式是使用多线程技术保证高速数据流的实时采集，将采集的数据以帧为单位存储，支持后续处理模块调用。

（2）数据处理层的功能包括：相机标定、坐标变换和车辆跟踪。相机标定是通过基于消失点的自适应标定算法获取相机内外参数，为坐标变换做准备；坐标变换是像素坐标系转换为世界坐标系，为后续参数计算做准备；车辆跟踪是实现车辆目标的精准跟踪，保障参数计算准确性。

（3）运动参数计算层的功能是根据视频数据中车辆位置变化，对车辆运动参数进行计算与补偿，包括轨迹、轨迹曲率、速度、加速度、航向角和偏航角这六种核心运动参数。

（4）结果展示与交互层的功能是利用数据处理模块的数据，绘制车辆轨迹和各个运动参数变化曲线，显示车辆运动状态信息，提供运动参数的可视化展示。

系统软件处理流程从底层数据采集到高层可视化交互，层层递进，确保高效、精准地完成车辆运动参数测量任务，本文系统软件处理流程图如图 2-12 所示：

中国知网 https://www.cnki.net

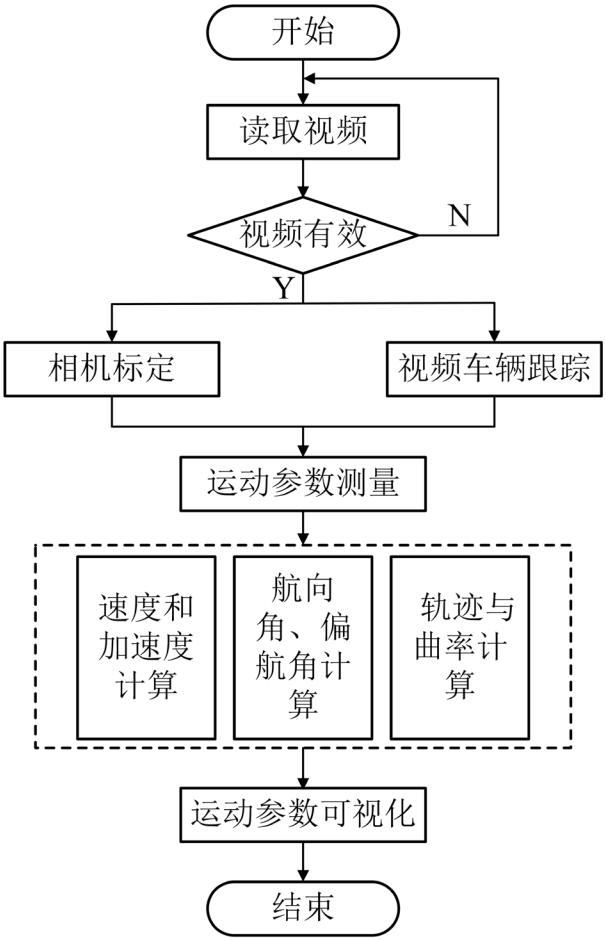


图 2-12 系统软件处理流程图

2.5 本章小结

本章从系统的测量原理出发，详细介绍了图像采集与成像模型、坐标系变化与标定方法和车辆运动状态模型这三部分内容，明确了本系统的测量内容和测量原理。然后对硬件选型和软件实现进行了全面的梳理，明确了系统的功能模块和各个技术模块实现细节，为后续的实验验证和性能评估奠定了坚实基础。

中国知网 https://www.cnki.net

第 3 章 交通监控相机自标定方法研究

3.1 引言

计算机视觉的核心任务是从二维图像中提取三维空间中物体的几何信息，方便进一步实现物体的重建与定位。将二维图像与三维世界中物体的实际信息相互联系起来，找到它们的成像几何关系并建立起一个成像模型，那么该模型的参数就是相机参数。

在图像测量和机器视觉领域，摄像机标定是至关重要的一环，标定结果的稳定性直接影响到最终测量结果的准确性。因此，本文做好相机标定工作是做好后续车辆运动参数准确测量的前提，提高标定结果准确性和稳定性是本文工作的重点所在。

3.2 传统相机标定方法

传统相机标定方法依赖于结构已知且精度较高的标定物或控制场，传统方法的典型代表有 Tsai 两步标定法[72]、直接线性变换法（Direct Linear Transformation）[73]、张氏标定法[19]。这些相机标定方法主要是通过空间点与影像点的对应关系建立相机内参数的约束[74]，并借助优化算法求解这些参数。

（1）Tsai 两步法首先通过线性计算得到相机参数的初始值，随后考虑畸变因素的影响，通过非线性优化获取最终的相机参数。Tsai 两步法速度较快，但仅考虑径向畸变，当相机畸变严重时，该方法不适用。

第一步利用径向排列约束（RAC），求解超定线性方程组，求出相机的外部参数，包括 r_1-r_9，s_x，t_x，t_y。由像素坐标系和世界坐标系之间的关系，添加畸变系数后得到如下公式：

$$\begin{aligned} x_c &= r_1 x_w + r_2 y_w + r_3 z_w + t_x \\ y_c &= r_4 x_w + r_5 y_w + r_6 z_w + t_y \\ z_c &= r_7 x_w + r_8 y_w + r_9 z_w + t_z \end{aligned} \tag{3-1}$$

中国知网 https://www.cnki.net

由于方向一致，即方向平行：

$$\frac{x_d}{y_d}=\frac{x_c}{y_c}=\frac{r_1x_w+r_2y_w+r_3z_w+t_x}{r_4x_w+r_5y_w+r_6z_w+t_x} \tag{3-2}$$

第二步是求解相机的内部参数，可以分为两种情况。一是使用超定线性方程求解没有透镜畸变的相机内部参数；二是使用三变量的优化搜索求解存在透镜畸变的相机内部参数。所求参数是焦距 f，平移量 t_z 和透镜畸变系数 k。

超定方程组可以通过将畸变系数 k 设置为零得到：

$$\begin{gathered}[y_i-d_y(x_{fi}-u_0)]\cdot\begin{bmatrix}f\\t_z\end{bmatrix}=w_id_y(y_{fi}-v_0)\\ y_i=r_4x_{wi}+r_5y_{fi}+r_6\cdot 0+t_y\\ w_i=r_7x_{wi}+r_8y_{fi}+r_9\cdot 0\end{gathered} \tag{3-3}$$

得到相机焦距 f 和平移量 t_z 作为初始值，然后利用优化算法进行迭代更新，得到更精确的相机内部参数焦距 f、移量 t_z 和畸变系数 k。

（2）直接线性变换法是通过建立像素坐标系中点坐标与世界坐标系中点坐标之间的线性关系，然后求解参数的标定算法。由于该方法不需要相机内外方位元素的初值就可以进行计算，因此该方法在近景摄影测量中被广泛使用。张永军[75]最早在 2002 年提出可以利用共线方程和二维 DLT 参数的对应关系分解相机外方位元素初值，最后再利用光束法平差完成相机的标定，该算法二维 DLT 可表示为：

$$\begin{gathered}x=\frac{h_1X+h_2Y+h_3}{h_7X+h_8Y+1}\\ y=\frac{h_4X+h_5Y+h_6}{h_7X+h_8Y+1}\end{gathered} \tag{3-4}$$

其中，(x,y)为相应的像坐标，当像片点数超过 4 个时，即可求解二维 DLT 参数。与摄影测量中的共线方程对比，若设定平面格网的 Z 坐标为零，则可进一步推导：

$$f=\sqrt{\frac{-(h_1-h_7x_0)(h_2-h_8x_0)-(h_4-h_7y_0)(h_5-h_8y_0)}{h_7h_8}} \tag{3-5}$$

当求得主点(x_0, y_0)后，即可通过公式(3-5)求出相机的焦距 f。相机的

中国知网 https://www.cnki.net

主点一定在主纵线上，所以主点(x_0, y_0)满足方程：

$$\begin{aligned} F_h = &(h_1h_8 - h_2h_7)(h_1h_7 - h_7^2x_0 + h_2h_8 + h_8^2x_0) \\ &+ (h_4h_8 - h_5h_7)(h_4h_7 - h_7^2y_0 + h_5h_8 + h_8^2y_0) = 0 \end{aligned} \tag{3-6}$$

其矩阵形式为：

$$(L_x \quad L_y)\begin{pmatrix} x_0 \\ y_0 \end{pmatrix} = L_c \tag{3-7}$$

因此，只要有多于两张的图片，就可以通过解方程组利用多条主纵线求得主点(x_0, y_0)。之后再利用 DLT 相机的内外方位元素初值后，就可以使用光束法平差进行相机标定。

（3）张氏标定法使用棋盘格作为标定板进行标定，采集标定板不同位姿图片，然后利用角点检测算法得到棋盘格中角点的像素坐标，计算得到角点在世界坐标系下的物理坐标，最后利用坐标转换关系进行相机标定。该方法操作简单，而且精度较高，可以满足大部分场合。

无畸变原单点的成像模型可以用下式表示。

$$Z\begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = \begin{pmatrix} \dfrac{f}{dX} & -\dfrac{f\cot\theta}{dX} & u_0 \\ 0 & \dfrac{f}{dX\sin\theta} & v_0 \\ 0 & 0 & 1 \end{pmatrix}(R_1 \quad R_2 \quad T)\begin{pmatrix} U \\ V \\ 1 \end{pmatrix} \tag{3-8}$$

其中，R_1 和 R_2 为旋转矩阵 **R** 的前两列。

将内参矩阵和外参矩阵的积记为 H，其三列为(H_1, H_2, H_3)，那么有：

$$\begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = \frac{1}{Z}H\begin{pmatrix} U \\ V \\ 1 \end{pmatrix} = \frac{1}{Z}\begin{bmatrix} H_{11} & H_{12} & H_{13} \\ H_{12} & H_{22} & H_{32} \\ H_{31} & H_{32} & H_{33} \end{bmatrix}\begin{pmatrix} U \\ V \\ 1 \end{pmatrix} \tag{3-9}$$

利用上式，消除尺度因子 Z，可以得到：

$$\begin{aligned} u &= \frac{H_{11}U + H_{12}V + H_{13}}{H_{31}U + H_{32}V + H_{33}} \\ v &= \frac{H_{21}U + H_{22}V + H_{23}}{H_{31}U + H_{32}V + H_{33}} \end{aligned} \tag{3-10}$$

中国知网 https://www.cnki.net

利用角点检测算法，可以检测出每个角点的像素坐标(u, v)，同时标定板的世界坐标系和标定板上每一个格子的大小是已知的，据此就可以计算得到标定板角点的世界坐标(U, V)。从而可以计算出内参矩阵和外参矩阵的积。

已知了矩阵H=A$(R_1\ R_2\ T)$，接下来需要求解相机的内参矩阵 A。再利用R_1和R_2作为旋转矩阵 **R** 的两列，存在单位正交的关系，即：

$$\begin{aligned} R_1^{\mathrm{T}} R_2 &= 0 \\ R_1^{\mathrm{T}} R_1 &= R_2^{\mathrm{T}} R_2 = 1 \end{aligned} \tag{3-11}$$

由H和R_1，R_2的关系，可知：

$$\begin{aligned} R_1 &= A^{-1} H_1 \\ R_2 &= A^{-1} H_2 \end{aligned} \tag{3-12}$$

代入可得：

$$\begin{aligned} H_1^{\mathrm{T}} A^{-\mathrm{T}} A^{-1} H_2 &= 0 \\ H_1^{\mathrm{T}} A^{-\mathrm{T}} A^{-1} H_1 &= H_2^{\mathrm{T}} A^{-\mathrm{T}} A^{-1} H_2 = 1 \end{aligned} \tag{3-13}$$

记$A^{-\mathrm{T}}A^{-1}=B$，显而易见，B是一个对称矩阵。可以先求解出矩阵B，通过矩阵B再求解相机的内参矩阵A为：

$$A = \begin{pmatrix} \dfrac{f}{dX} & -\dfrac{f\cot\theta}{dX} & u_0 & 0 \\ 0 & \dfrac{f}{dX\sin\theta} & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix} = \begin{pmatrix} \alpha & \gamma & u_0 \\ 0 & \beta & u_0 \\ 0 & 0 & 1 \end{pmatrix} \tag{3-14}$$

在关系：$A(R_1\ R_2\ T)=H$中，已经求解得到了矩阵H、矩阵A。通过公式：$(R_1\ R_2\ T)=A^{-1}H$，即可求得每一张图片对应的外参矩阵$(R_1\ R_2\ T)$。

在该方法中世界坐标系的原点位于棋盘格上，棋盘格上任意点的物理坐标满足 $W = 0$，这就使得旋转矩阵的第三列R_3在坐标转化中并没有作用。但是R_3满足旋转矩阵的正交性，列与列之间单位正交，因此可以通过向量R_1, R_2的叉乘计算得到R_3。至此相机标定已经完成，相机的内参矩阵和外参矩阵也已经被求出。

中国知网 https://www.cnki.net

3.3 交通监控相机自标定方法

由于交通监控相机一般用于各种道路监控，所以对交通监控相机的标定无法像传统的相机标定那样灵活的使用标定物进行标定。因此，许多学者提出了针对交通监控相机的自适应标定方法。这些自标定方法无需任何的标定物，仅仅是通过多视图中对应点的关系直接进行标定，或者利用单幅图像中消失点的关系来获取相机的相关参数。常用的自标定方法为基于 Kruppa 的自标定方法[76]、基于光束自标定法[77]和基于消失点的自标定方法[78]。

（1）基于 Kruppa 的自标定法的核心在于利用二次曲线构建相机内参矩阵的约束方程并进行求解。图像序列长度会影响标定算法的稳定性，无法保证射影空间中的无穷远平面。基于 Kruppa 方程的自标定方法标定步骤一般分为：1、多视图采集；2、计算基础矩阵；3、求解 Kruppa 方程。

具体计算为，在两个视图中，任意一对匹配点(x_1, x_2)满足：

$$\begin{gathered} x_2^{\mathrm{T}} F x_1 = 0 \\ x_1 = \left[u_1, v_1, 1\right]^{\mathrm{T}}, x_2 = \left[u_2, v_2, 1\right]^{\mathrm{T}} \end{gathered} \tag{3-15}$$

其中，F 为基础矩阵，x_1 和 x_2 是图像点的齐次坐标。基础矩阵又可以通过内参矩阵 K_1、K_2 和外参（旋转 R、平移 t）表示为：

$$\begin{gathered} F = K_2^{-\mathrm{T}} [t]_{\times} R K_1^{-1} \\ [t]_{\times} = \begin{bmatrix} 0 & -t_z & t_y \\ t_z & 0 & -t_x \\ t_y & t_x & 0 \end{bmatrix} \end{gathered} \tag{3-16}$$

其中$[t]_{\times}$是 t 的反对称矩阵形式，用于表示平移的叉乘运算。利用极点与基础矩阵的关系可以得到 Kruppa 方程：

$$v_i^{\mathrm{T}} K^{-\mathrm{T}} K^{-1} v_i = 0 \quad (i = 1,2) \tag{3-17}$$

其中 v_i 是基础矩阵对应的极点（或极线）。

在实际应用场景中，多组视图对应点生成多个约束方程，将 K 表示为：

中国知网 https://www.cnki.net

$$K=\begin{bmatrix} f & 0 & c_x \\ 0 & f & c_y \\ 0 & 0 & 1 \end{bmatrix} \tag{3-18}$$

根据多视图构建的方程组，可逐步求解出内参参数：焦距f、主点位置(c_x, c_y)。

基于 Kruppa 的自标定法的优点是不需要额外的标定物，同时理论支持充分，适合高精度场景。其局限性在于对对应点的精度要求较高，并且需要多个视角，适合移动摄像机的场景。

（2）光束自标定法是一种通过优化多视图点的重投影误差来估计相机参数的方法。该方法的核心思想是最小化图像空间中的误差，从而精确求解相机参数。光束自标定法标定步骤一般分为：特征点提取与匹配、初始参数估计和全局优化。

对投影模型进行定义之后，三维点 **X** 在相机坐标系中的投影为：

$$\begin{aligned} \mathbf{x} &= K[R\,|\,t]\mathbf{X} \\ \mathbf{X} &= \left[X, Y, Z, 1\right]^{\mathrm{T}} \end{aligned} \tag{3-19}$$

其中 K 是内参矩阵，$[R\,|\,t]$是相机的旋转和平移矩阵，x 是图像坐标中的点（齐次坐标形式）。然后通过比较三维点的投影 $\hat{\mathbf{x}}_i$ 与图像点的实际位置 $\mathbf{x}_i$，计算误差：

$$e_i = \left\| \mathbf{x}_i - \hat{\mathbf{x}}_i \right\|^2 \tag{3-20}$$

对于所有视图的点集，构建全局误差函数：

$$\min_{\{K,R,t,X\}} \sum_i \sum_j \left\| \mathbf{x}_{ij} - \hat{\mathbf{x}}_{ij} \right\|^2 \tag{3-21}$$

其中 i 表示相机编号，j 表示点编号。最后使用非线性优化方法迭代求解。初始值可通过基础矩阵 F 或直接几何法估计，每次迭代调整内参 K，外参（R, t）和三维点 **X**，以减少重投影误差。

（3）基于消失点的自标定法利用单幅图像中的直线特征，通过消失点之间的几何关系推导相机参数。该类方法中的一个代表方法是 VWH 标定方法，该方法利用图像上的一个消失点信息以及标志物宽度和相机高度进行相机标定。对于消失点，可以定义为在空间中存在一组平行线，平

中国知网 https://www.cnki.net

行线在图像无穷远处最终相交于一点，该点定义为消失点。

基于消失点的自标定法标定步骤一般分为：1、提取直线特征；2、求解消失点；3、计算相机参数。

空间中一组平行线方向向量为 $\mathbf{d}=[d_x, d_y, d_z]^{\mathrm{T}}$，在图像中的消失点为：

$$\mathbf{v}=\mathrm{K}\mathbf{d} \tag{3-22}$$

其中 $\mathbf{v}=[u,v,1]^{\mathrm{T}}$ 是消失点在图像中的齐次坐标。消失点的方向向量在图像中存在正交性，故而消失点满足如下性质：

$$\mathbf{v}_i^{\mathrm{T}}K^{-\mathrm{T}}K^{-1}\mathbf{v}_i=0 \tag{3-23}$$

若检测到两组正交平行线的消失点 $\mathbf{v}_x$ 和 $\mathbf{v}_y$，可以通过以下公式求解焦距 f：

$$f=\sqrt{-\frac{\mathbf{v}_x^{\mathrm{T}}\mathbf{v}_y}{\mathbf{v}_x^{\mathrm{T}}\mathbf{v}_x+\mathbf{v}_y^{\mathrm{T}}\mathbf{v}_y}} \tag{3-24}$$

如果主点位置已知，那么就可以得到相机的内参矩阵 K。

$$\mathrm{K}=\begin{bmatrix} f & 0 & c_x \\ 0 & f & c_y \\ 0 & 0 & 1 \end{bmatrix} \tag{3-25}$$

然后假设消失点 $\mathbf{v}_x$ 和 $\mathbf{v}_y$ 在图像平面上的坐标分别为(v_{x1}, v_{x2})和(v_{y1}, v_{y2})，则外参矩阵 **R** 和平移向量 **T** 可以通过以下公式求解：

$$\begin{aligned} \mathbf{R}&=\begin{bmatrix}\mathbf{r}_1 & \mathbf{r}_2 & \mathbf{r}_3\end{bmatrix} \\ \mathbf{T}&=\mathrm{K}^{-1}\begin{bmatrix} v_{x1} \\ v_{x2} \\ 1 \end{bmatrix} \end{aligned} \tag{3-26}$$

其中 $\mathbf{r}_1$ 和 $\mathbf{r}_2$ 是通过消失点位置求得的两个正交向量，$\mathbf{r}_3=\mathbf{r}_1\times\mathbf{r}_2$。至此，相机的内参矩阵 K、外参矩阵 **R** 和平移向量 **T** 均已求出，基于消失点的相机标定就完成了。

3.4 基于 MST 聚类优化的消失点相机自标定

本研究设计的基于高速成像的车辆运动参数测量系统，专门针对公路上的交通监测场景。由于该系统无法使用依赖标定物的传统相机标定

中国知网 https://www.cnki.net

法，因此本文提出了一种无需先验信息的基于最小生成树（Minimum Spanning Tree, MST）聚类优化[79]的消失点相机自标定。该方法核心是使用 MST 聚类从图像中寻找出三个消失点，然后利用三个消失点的位置求解相机参数。世界坐标系中的三个消失点示意图如图 3-1 所示。

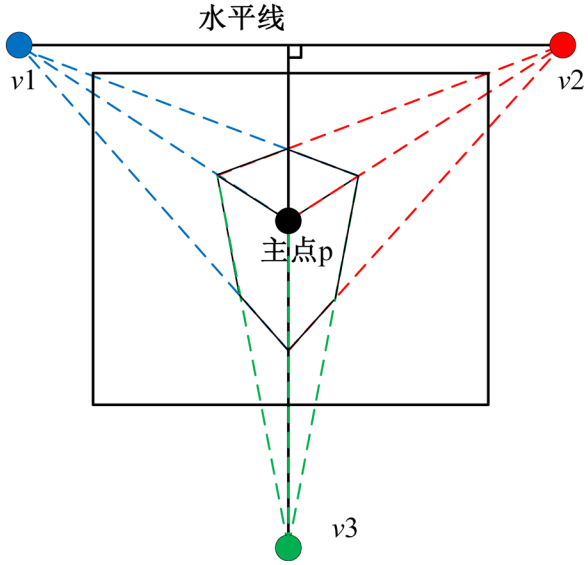


图 3-1 三消失点示意图

基于消失点的自标定法的优点是其适合复杂场景和快速标定的需求，仅需单幅图像，简单高效，不需要多视图，只要求图像中存在足够多的直线特征就可以进行标定。

本文所提方法包含以下四个关键步骤：

（1）线段提取与方向表示。通过边缘检测和概率霍夫变换提取显著线段，并剔除冗余线段以提高效率；

（2）霍夫空间投影与候选点生成。通过霍夫空间的累积特性生成初步候选点集合，剔除噪声候选点；

（3）基于最小生成树的消失点聚类与优化。利用最小生成树算法对候选点进行聚类分组，通过代价函数优化最终确定主要消失点；

（4）计算相机参数。利用优化聚类后求得的消失点坐标解算相机内外参数，实现相机自标定。

中国知网 https://www.cnki.net

3.4.1 线段提取与方向表示

本研究所提出的标定方法通过边缘检测、霍夫直线变换以及方向筛选这三个步骤提取出图像中显著的线段，并对这些线段的方向进行有效表示和筛选。通过这一过程，能够生成并保留指向潜在消失点的候选线段，减少了冗余计算。

（1）边缘检测。

使用 Canny 算法提取图像的边缘，生成二值边缘图。然后对边缘图进行高斯模糊降噪，减少干扰点。

首先对图像 $I(x,y)$进行高斯滤波，减少高频噪声干扰。滤波后的图像：

$$I_G(x,y) = I(x,y) * G(x,y) \tag{3-27}$$

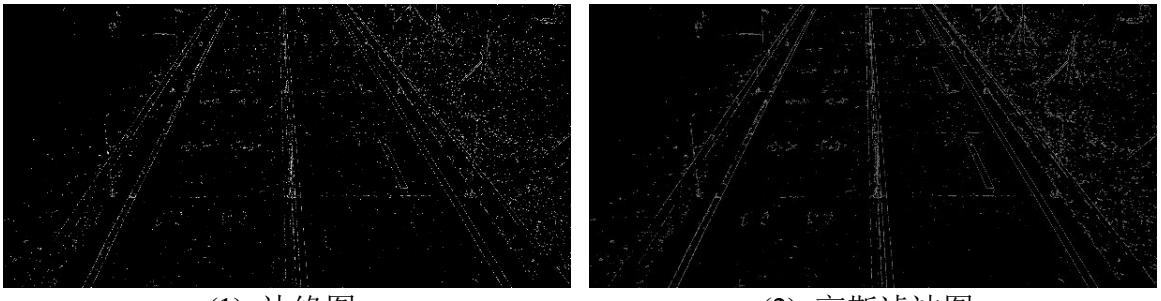
其中 $G(x,y)$为高斯核函数。然后使用 Sobel 算子对图像的梯度和梯度幅值方向进行计算：

$$G_x = \frac{\partial I_G}{\partial x}, \quad G_y = \frac{\partial I_G}{\partial y} \tag{3-28}$$

梯度幅值和方向计算为：

$$G = \sqrt{G_x^2 + G_y^2}, \quad \theta = \arctan\left(\frac{G_y}{G_x}\right) \tag{3-29}$$

通过高低阈值连接边缘，生成二值边缘图，预处理结果图如图 3-2 所示：



(1) 边缘图　　(2) 高斯滤波图

图 3-2 图像预处理图

（2）霍夫直线变换。

从二值边缘图中提取线段，通过概率霍夫变换（Probabilistic Hough

中国知网 https://www.cnki.net

Transform，PHT）有效检测直线端点，并表示为方向参数。每条线段以起点、终点和方向参数（斜率 θ、截距 ρ）表示。在霍夫空间中，用极坐标参数化直线：

$$\rho = x\cos\theta + y\sin\theta \tag{3-30}$$

其中 ρ 表示线段到原点的垂直距离，θ 表示法线与 x-轴的夹角。对图像中每个边缘点(x, y)，计算所有可能的(ρ, θ)，并记录其方向参数：

$$L_i = \{(x_1, y_1), (x_2, y_2), \theta_i, \rho_i\} \tag{3-31}$$

最后对无效线段进行剔除，包括短线段和强度低的线段。设动态长度阈值 T_L，仅保留长度$\|L_i\| \geq T_L$ 的线段：

$$\| L_i \| = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2} \tag{3-32}$$

（3）方向筛选。

计算剩余线段的方向分布特性。目的是保留指向消失点的线段，过滤掉无关或冗余的线段。首先是计算方向分布的集中度，使用分布峰值作为主要方向的指标：

$$C(\theta) = \max_{\theta} H(\theta) \tag{3-33}$$

若方向集中度低，说明线段分布较为离散，可适当增加投票阈值或调整剔除规则。仅保留与主要方向（即直方图峰值 θ_{peak} 附近）一致的线段：

$$|\theta_i - \theta_{\text{peak}}| \leq T_{\text{dir}} \tag{3-34}$$

根据线段方向与潜在消失点方向的一致性进行筛选，计算一致性评分，根据一致性评分 $S(L_i)$值来保留评分较高的线段：

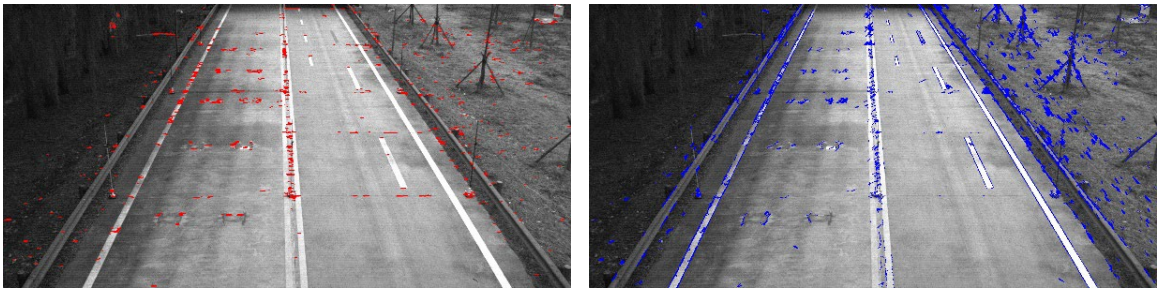
$$S(L_i) = \cos(\theta_i - \theta_{\text{vanish}}) \tag{3-35}$$

经过上述（1）~（3）步骤即可以提取出图像中有效的特征线段。

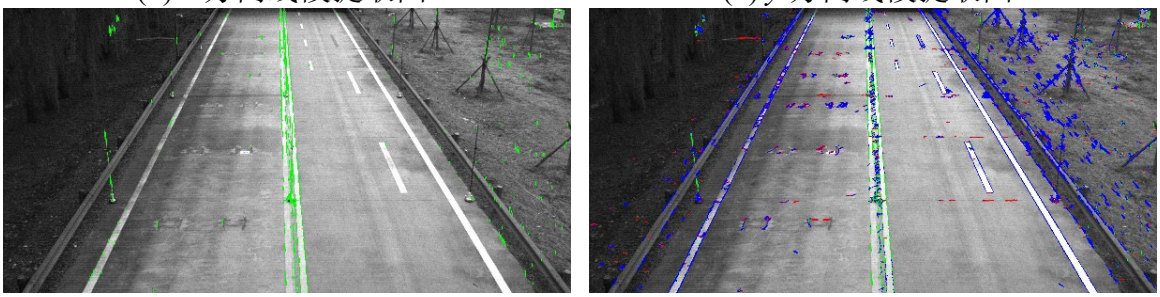
本节通过边缘检测、霍夫直线变换和方向筛选三个步骤，可以高效提取图像中的显著线段，并对其方向特性进行有效建模。该措施提高了线段提取的鲁棒性与计算效率，为后续消失点检测奠定了基础。

显著线段提取结果图如图 3-3 所示。

中国知网 https://www.cnki.net



(1) x 方向线段提取图　　(2) y 方向线段提取图



(3) z 方向线段提取图　　(4) 线段提取整体图

图 3-3 显著线段提取图

3.4.2 霍夫空间投影与候选点生成

为了高效地识别图像中的潜在消失点，本节从线段交点的计算、霍夫空间的投影和累积投票，到候选点的筛选，逐步生成最终的候选点集合。

（1）线段延长与交点计算。

对筛选后的线段进行延长，计算其可能的交点集合。再将每个交点映射到图像坐标系，对每条线段 L 以直线方程的形式表示：

$$y = k_i x + b_i \tag{3-36}$$

其中 k_i=tanθ_i 为线段的斜率；b_i 为截距；c_i 为 x-轴截距。对任意两条线段 L_i 和 L_j，计算它们的交点：

$$x_{int} = \frac{b_j - b_i}{k_i - k_j}, \quad y_{int} = k_i x_{int} + b_i \tag{3-37}$$

将计算出的交点集合(x_{int}, y_{int})映射到图像坐标系，记录为候选点。

（2）霍夫空间投票。

在图像空间中的候选点，也就是笛卡尔坐标系的点，投影到霍夫空间中后，该点会变为霍夫空间中的一条直线。霍夫空间单点投影示意图如图

中国知网 https://www.cnki.net

3-4 所示。

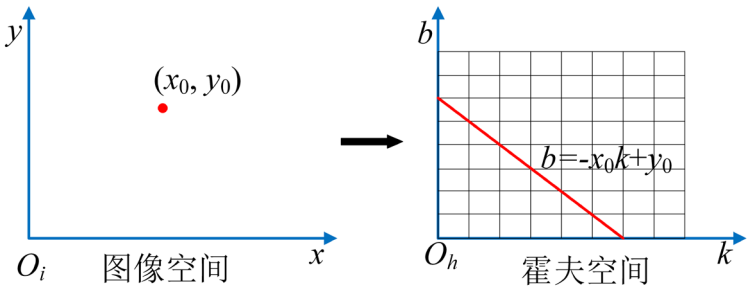


图 3-4 霍夫空间单点投影示意图

在笛卡尔坐标系中共线的点，其在霍夫空间中对应的直线会相交于一点。相交点也只有一种可能的取值，该相交点就是霍夫空间中的投票结果。霍夫空间多点投影示意图如图 3-5 所示。

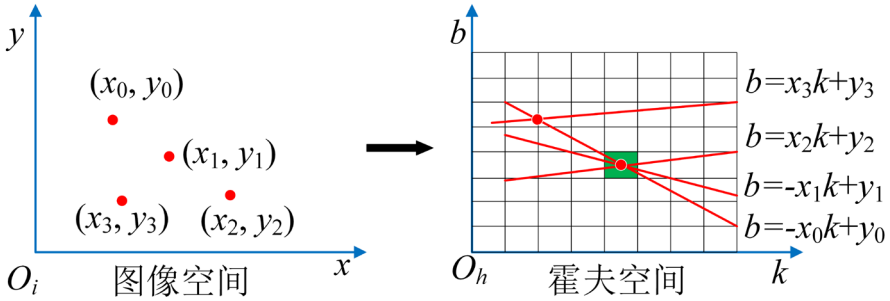


图 3-5 霍夫空间多点投影示意图

转换为霍夫空间下的极坐标表示，极坐标表示示意图如图 3-6 所示。

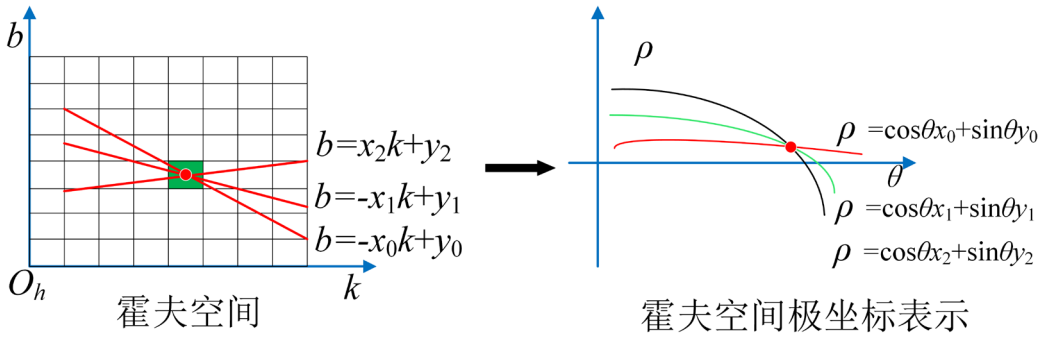


图 3-6 霍夫空间极坐标表示

根据线段的投票权重（如长度、方向一致性）对霍夫空间进行加权累积。紧接着在霍夫空间中计算每个区域的累积密度，选取密度最高的若干区域作为初步候选点：

中国知网 https://www.cnki.net

$$D(\rho,\theta)=\sum_i W_i\cdot\delta(\rho_i,\theta_i) \tag{3-38}$$

其中 $\delta(\rho_i, \theta_i)$为指示函数，用于判断交点(ρ_i, θ_i)是否属于该区域。

（3）候选点筛选。

对每个候选点，统计其对应的累计投票值 $D(\rho, \theta)$。若累计值低于阈值 T_{vote}，则剔除。对候选点方向进行一致性评估，计算其方向得分：

$$S(\rho,\theta)=\frac{\sum_i W_i\cdot\cos(\theta_i-\theta)}{\sum_i W_i} \tag{3-39}$$

若得分低于阈值 T_{score}，则剔除。若候选点彼此间欧几里得距离小于阈值 $T_{distance}$，则将其合并为一个点，位置取加权中心：

$$(x,y)=\frac{\sum_i W_i\cdot(x_i,y_i)}{\sum_i W_i} \tag{3-40}$$

本节通过线段延长与交点计算，结合霍夫空间投票与候选点筛选，从大量初始交点中高效生成消失点候选集合，为后续的聚类优化与主要消失点识别奠定了基础。

3.4.3 基于最小生成树的消失点聚类与优化

（1）构建图模型。候选点集合被视为无向图的节点，每对候选点之间通过边权值衡量其关联性。边权值综合考虑空间接近性和方向一致性。

设候选点集合为$\{P_1, P_2, \ldots, P_n\}$，每个候选点 P_i 用其坐标和方向表示：

$$P_i=(x_i,y_i,\theta_i) \tag{3-41}$$

任意两节点 P_i 和 P_j 之间的边权值 w_{ij} 定义为：

$$\begin{aligned} w_{ij}&=\alpha\cdot d_{ij}+\beta\cdot\Delta\theta_{ij}\\ d_{ij}&=\sqrt{(x_i-x_j)^2+(y_i-y_j)^2}\end{aligned} \tag{3-42}$$

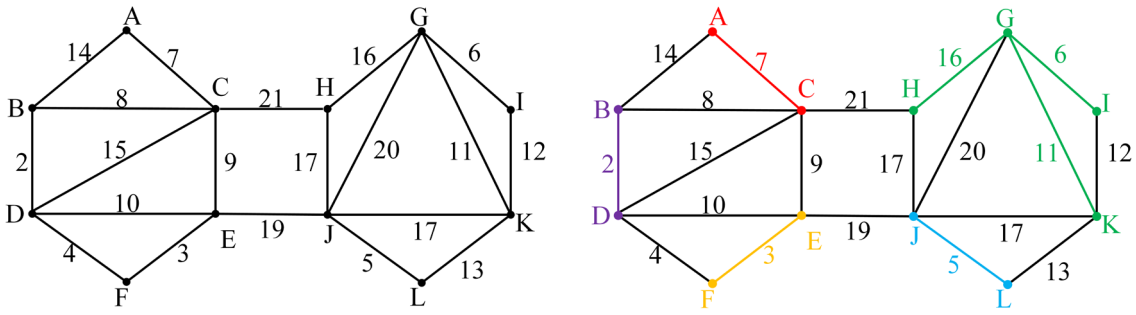
其中，d_{ij} 为欧几里得距离，用于衡量候选点的空间接近性；$\Delta\theta_{ij}$ 为方向夹角，用于衡量候选点方向的一致性；α、β 是控制距离和方向的权重系数。

通过上述定义，将候选点集合构建为无向图 $G=(V, E)$，其中，$V=\{P_1,$

中国知网 https://www.cnki.net

$P_2, \ldots, P_n\}$：候选点集合作为图的节点；E 是节点之间的边，权值为 w_{ij}。

（2）生成最小生成树（Minimum Spanning Tree，MST）并分组。无向连通图每条边权值相加，相加和最小的树就是最小生成树 MST。



(1) 原始数据图　　(2) 聚类优化图

图 3-7 MST 聚类优化示意图

图 3-7 是 MST 聚类优化原理示意图，MST 的目标是选择权值最小的边集合，使所有节点互连且无环：

$$T = \arg\min_{T \subseteq G} \sum_{(i,j) \in T} w_{ij} \tag{3-43}$$

引入距离阈值 τ 剔除生成树中的长边，从而分割为若干连通子图：

$$E_{\text{filtered}} = \{(i,j) \in T \mid w_{ij} \le \tau\} \tag{3-44}$$

其中，τ 根据候选点集合的全局统计特性动态设定：

$$\tau = \mu + \lambda \cdot \sigma \tag{3-45}$$

其中，μ 和 σ 分别为边权值的均值和标准差；λ 为调节系数。

每个连通子图对应一个候选点簇，子图中的候选点具有较高的空间接近性和方向一致性。

（3）消失点优化与剔除。对每个分组计算簇中心，作为初步的消失点。使用代价函数最小化误差，对消失点位置进行优化：

$$\text{Cost}(V) = \sum_i \frac{\text{alignment}(\text{line}_i, V)}{S_L} \tag{3-46}$$

其中，S_L 是线条的数量。再对每个候选点簇 $C_k=\{P_{k1}, P_{k2}, \ldots\}$，计算其几何中心作为初步消失点：

中国知网 https://www.cnki.net

$$P_k = \left(\frac{\sum_{P \in C_k} x}{|C_k|}, \frac{\sum_{P \in C_k} y}{|C_k|}, \frac{\sum_{P \in C_k} \theta}{|C_k|} \right) P \tag{3-47}$$

最后定义代价函数 $E(P_k)$，衡量线段与簇中心 Pk 的方向一致性：

$$E(P_k) = \sum_{L \in \mathcal{L}} W_L \cdot \mathrm{Error}(P_k, L)$$

$$\mathrm{Error}(P_k, L) = \cos^{-1}\left(\frac{(x_k - x_L) \cdot dx_L + (y_k - y_L) \cdot dy_L}{\sqrt{(x_k - x_L)^2 + (y_k - y_L)^2}} \right) \tag{3-48}$$

其中，L 是与消失点相关的线段集合；W_L 是线段权重；Error(P_k,L)是线段 L 的误差函数；dx 和 dy 为线段方向向量。使用 MST 聚类优化后的消失点提取图如图 3-8 所示。

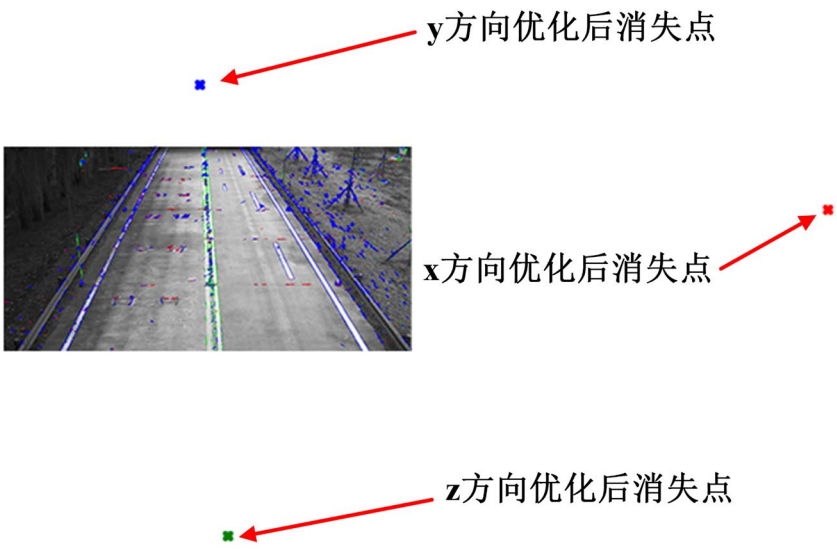


图 3-8 消失点生成示意图

本节上述方法通过改进的 MST 方法实现高效的聚类与优化，结合空间接近性和方向一致性，剔除弱关联点和噪声。同时引入动态阈值控制簇的划分，适应不同场景。最后定义代价函数结合线段方向一致性，实现对消失点的精准聚类优化。

中国知网 https://www.cnki.net

3.4.4 相机内外参数求解

（1）内参计算

在基于消失点的相机自标定方法中，一般认定主点是图像的中心点，倾斜度为零(y=0)，且比例因子为 1，即 $\alpha u=\alpha v=f$，因此相机内参矩阵可以简化为：

$$\mathbf{K}=\begin{bmatrix} f & 0 & u_0 \\ 0 & f & v_0 \\ 0 & 0 & 1 \end{bmatrix} \tag{3-49}$$

当图像大小已知时，主点位置(u_0, v_0)也就唯一确定了。根据公式(3-49)，仅需要计算出相机的焦距f，就可以确定相机的内参矩阵 **K**。

通过单应性，将三个方向相互正交的消失点投影到图像平面上：

$$\begin{bmatrix} \lambda_1 u_1 & \lambda_2 u_2 & \lambda_3 u_3 \\ \lambda_1 v_1 & \lambda_2 v_2 & \lambda_3 v_3 \\ \lambda_1 & \lambda_2 & \lambda_3 \end{bmatrix} = P_{3\times 4}\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix} \tag{3-50}$$

三个消失点可以用比例来表示为：

$$V_1=\lambda_1\begin{bmatrix} u_1 \\ v_1 \\ 1 \end{bmatrix}, V_2=\lambda_2\begin{bmatrix} u_2 \\ v_2 \\ 1 \end{bmatrix}, V_3=\lambda_3\begin{bmatrix} u_3 \\ v_3 \\ 1 \end{bmatrix} \tag{3-51}$$

利用投影矩阵的分解，可得：

$$\begin{bmatrix} V_1 & V_2 & V_3 \end{bmatrix}=\mathbf{K}\begin{bmatrix} \mathbf{R} \mid \mathbf{T} \end{bmatrix}\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix} \tag{3-52}$$

根据齐次坐标的几何特性，无穷远点与平移向量的点积结果为零，可以对上式进行化简：

$$\begin{bmatrix} V_1 & V_2 & V_3 \end{bmatrix}=\mathbf{KR} \tag{3-53}$$

利用相机矩阵 K，旋转矩阵 R 可以写成：

中国知网 https://www.cnki.net

$$\mathbf{R}=\begin{bmatrix} \dfrac{\lambda_1(u_1-u_0)}{f} & \dfrac{\lambda_2(u_2-u_0)}{f} & \dfrac{\lambda_3(u_3-u_0)}{f} \\ \dfrac{\lambda_1(v_1-v_0)}{f} & \dfrac{\lambda_2(v_2-v_0)}{f} & \dfrac{\lambda_3(v_3-v_0)}{f} \\ \lambda_1 & \lambda_2 & \lambda_3 \end{bmatrix} \tag{3-54}$$

利用旋转矩阵的正交性，并将其应用于前两列，就得到：

$$\lambda_1\lambda_2\left(\frac{(V_1-O_i)\cdot(V_2-O_i)}{f^2}+1\right)=0 \tag{3-55}$$

那么焦距可以计算如下

$$f=\sqrt{|(O_i-V_1)\cdot(V_2-O_i)|} \tag{3-56}$$

（2）外参计算

外部参数包括旋转矩阵 R 和平移向量 t，一旦确定了尺度因子 λ_i，就可以根据如下公式直接计算旋转矩阵：

$$\begin{bmatrix} u_1 & u_2 & u_3 \\ v_1 & v_2 & v_3 \\ 1 & 1 & 1 \end{bmatrix}\begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix}=\mathbf{KR} \tag{3-57}$$

考虑到旋转矩阵存在正交性的特征，将公式(3-57)两边同时乘以 $(\mathbf{KR})^{\mathrm{T}}$，就可以得到：

$$\begin{bmatrix} u_1 & u_2 & u_3 \\ v_1 & v_2 & v_3 \\ 1 & 1 & 1 \end{bmatrix}\begin{bmatrix} \lambda_1^2 & 0 & 0 \\ 0 & \lambda_2^2 & 0 \\ 0 & 0 & \lambda_3^2 \end{bmatrix}\begin{bmatrix} u_1 & v_1 & 1 \\ u_2 & v_2 & 1 \\ u_3 & v_3 & 1 \end{bmatrix}=\mathbf{K}\mathbf{K}^{\mathrm{T}} \tag{3-58}$$

这里定义 **Q** 矩阵为：

$$\mathbf{Q}=\mathbf{K}\mathbf{K}^{\mathrm{T}}=\begin{bmatrix} f^2+u_0^2 & u_0v_0 & u_0 \\ u_0v_0 & f^2+u_0^2 & v_0 \\ u_0 & v_0 & 1 \end{bmatrix} \tag{3-59}$$

通过重新联立上述公式，就可以得到：

中国知网 https://www.cnki.net

$$\begin{bmatrix} u_1 & u_2 & u_3 \\ v_1 & v_2 & v_3 \\ u_1^2 & u_2^2 & u_3^2 \\ v_1^2 & v_2^2 & v_3^2 \\ u_1v_1 & u_2v_2 & u_3v_3 \end{bmatrix} \begin{bmatrix} \lambda_1^2 \\ \lambda_2^2 \\ \lambda_3^2 \end{bmatrix} = \begin{bmatrix} u_0 \\ v_0 \\ f^2+u_0^2 \\ f^2+v_0^2 \\ u_0v_0 \end{bmatrix} \tag{3-60}$$

通过对上述方程组进行奇异值分解，就可以计算出尺度因子，从而能够确定旋转矩阵 **R**。

此外，当世界坐标系场景中 XYZ 三个方向都存在消失点时，这三个消失点可以构成一个三角形，通过该三角形的正交中心就可以确定主点坐标(u_0, v_0)。投影矩阵的最后一列是平移向量，表示从相机坐标系原点指向世界世界坐标系原点的向量，世界坐标系的投影则通过等式(3-50)获得。

将世界场景中的一点，投影到图像平面上有：

$$\begin{bmatrix} \lambda_i u_i \\ \lambda_i v_i \\ \lambda_i \end{bmatrix} = \mathbf{K}[\mathbf{R} \mid \mathbf{T}] \begin{bmatrix} x_i \\ y_i \\ z_i \\ 1 \end{bmatrix} \tag{3-61}$$

然后，得到以下方程组：

$$\begin{aligned} \lambda_i u_i &= r_1 P_{wi} + u_0 r_3 P_{wi} + t_1 + u_0 t_3 \\ \lambda_i v_i &= r_2 P_{wi} + v_0 r_3 P_{wi} + t_2 + v_0 t_3 \\ \lambda_i &= r_3 P_{wi} + t_3 \end{aligned} \tag{3-62}$$

变换后得到

$$\begin{aligned} r_3 P_w u_i + t_3 u_i &= f r_1 P_w + u_0 r_3 P_w + f t_1 + u_0 t_3 \\ r_3 P_w v_i + t_3 v_i &= f r_2 P_w + v_0 r_3 P_w + f t_1 + v_0 t_3 \end{aligned} \tag{3-63}$$

重新书写如下

$$\begin{bmatrix} f & 0 & u_0 - u_i \\ 0 & f & v_0 - v_i \end{bmatrix} \begin{bmatrix} t_1 \\ t_2 \\ t_3 \end{bmatrix} = \begin{bmatrix} r_3 P_w (u_i - u_0) - f(r_1 P_w) \\ r_3 P_w (v_i - v_0) - f(r_2 P_w) \end{bmatrix} \tag{3-64}$$

至此，综合已获得的参数进行求解，即可以获得相机外参矩阵 **R** 和平移向量 **T**。

中国知网 https://www.cnki.net

3.5 相机标定算法性能验证

根据本研究拍摄数据，利用基于 MST 聚类优化的消失点相机自标定方法多次实验获取实验数据的三个消失点坐标分别为 $VP_0(2011, -552)$、$VP_1(1947, 10465)$、$VP_2(13038, 349)$。然后进行相机标定，获取相机的内外参数。

经过内外参数计算得到相机标定参数如表 3-1 所示。

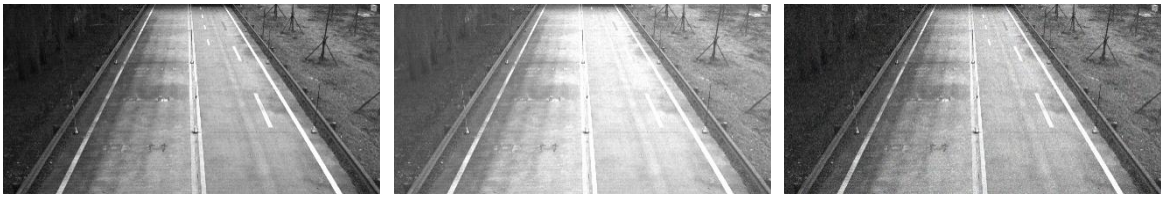
表 3-1 相机标定参数表

参数类型	符号	数值
焦距	f	4310
主点坐标	(u_0, v_0)	(2048, 1024)
内参矩阵	K	$\begin{bmatrix} 4310 & 0 & 2048 \\ 0 & 4310 & 1024 \\ 0 & 0 & 1 \end{bmatrix}$
外参矩阵	R	$\begin{bmatrix} 0.071 & 0.996 & -0.045 \\ -0.280 & -0.023 & 0.960 \\ 0.957 & 0.082 & 0.276 \end{bmatrix}$
平移向量	T	$\begin{bmatrix} 6.095 & -2.140 & 7.500 \end{bmatrix}$
旋转欧拉角	Euler	$\begin{bmatrix} 14.5 & -43.2 & -15.6 \end{bmatrix}$

为了验证该自标定算法的准确性以及算法的鲁棒性，本研究采用正常图像、高光照条件图像、噪声图像进行三组标定结果验证，并与光束自标定法和基于一个消失点的 VWH 自标定算法进行对比实验，从像素焦距计算误差、旋转矩阵误差、重投影误差和相机标定时间来进行对比。

每组验证实验包括 50 张同条件图像，每组实验数据示意图如图 3-9 所示。

中国知网 https://www.cnki.net



(1) 道路原始图　(2) 强光照条件道路图　(3) 噪声条件道路图

图 3-9 对比试验数据图

焦距误差用于比较估计的焦距 f_{est} 与真实焦距 f_{true} 的偏差。f_{true} 是根据相机物理焦距和传感器参数计算的真实焦距。本相机像素焦距真值计算为 4352 pixels。

旋转矩阵误差用来衡量估计的旋转矩阵 R_{est} 与真实旋转矩阵 R_{true} 的角度偏差。

$$\theta_{error} = \arccos(\frac{trace(R_{true}^{T} R_{est}) - 1}{2}) \tag{3-65}$$

其中，R_{est} 是标定算法得到的旋转矩阵，R_{true} 是真实旋转矩阵，$trace$ 是矩阵的迹（对角线元素之和）。

重投影误差是真实投影点与估计投影点的像素偏差。对于一个 3D 点 $P = [X, Y, Z]^T$，使用标定得到的内外参数将其投影到图像平面，得到投影点坐标 $p_{proj}=[x_{proj}, y_{proj}]^T$。真实观测点坐标为 $p_{true}=[x_{true}, y_{true}]^T$，重投影误差的公式为：

$$\text{Error} = \sqrt{(x_{proj} - x_{true})^2 + (y_{proj} - y_{true})^2} \tag{3-66}$$

利用三种算法对三组实验数据分别计算误差并取平均值，误差对比实验结果图如图 3-10 所示。

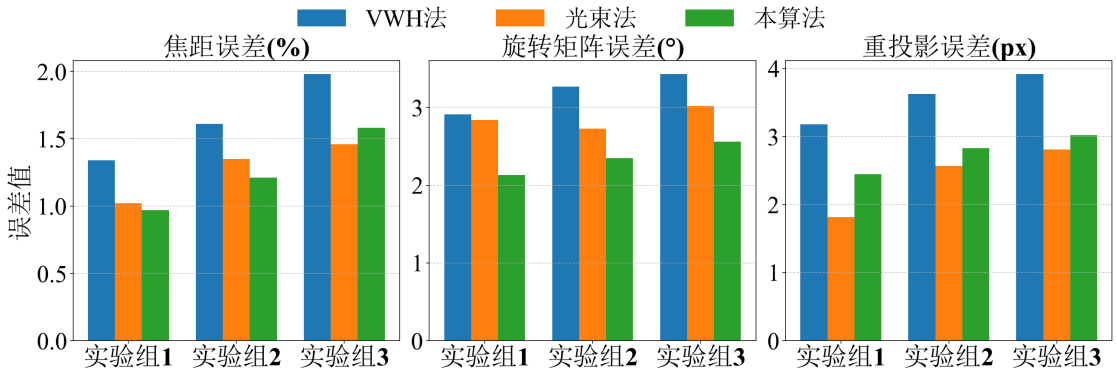


图 3-10 误差对比试验结果图

中国知网 https://www.cnki.net

焦距误差是衡量相机标定精度的重要指标之一。本算法的焦距误差在 0.9%～1.6%之间，整体误差最低且波动范围最小，比另外两种方法更稳定，说明算法的焦距估计的稳定性和精度均优于其他两种方法。

旋转矩阵误差反映了算法在估计相机姿态时的准确性。本算法在实验中表现优异，旋转矩阵误差在 2.1°～2.6°之间，在三组实验中均为最低，这表明本算法在旋转矩阵估计方面具有较好的鲁棒性。

重投影误差是衡量算法精确度的综合指标，该误差值可以反映相机参数的估计拟合程度和实际数据的大小。该算法在实验中显示出较低的重投影误差，这说明此算法在相机标定的精度上优势明显，可以更好的表达出坐标转换关系。

对于算法处理时间，主要影响因素是对消失点的寻找和对场景的处理，场景复杂度由图像中的线段数量表示。通过计算不同场景下的算法运行平均时间来分析算法的效率，时间对比结果图如图 3-11 所示。

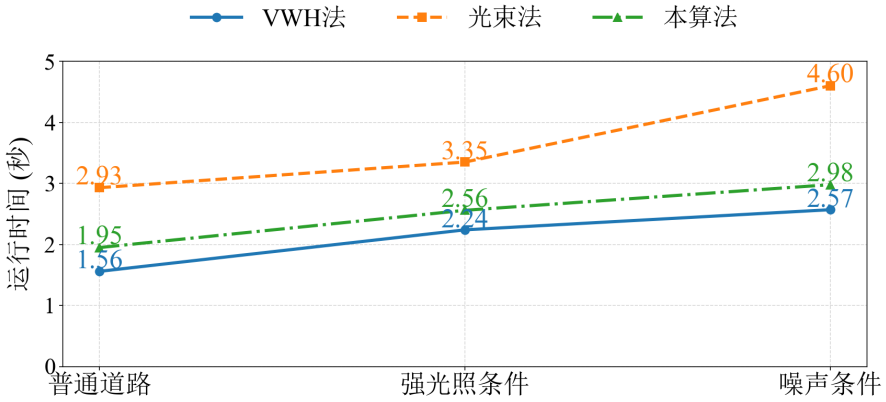


图 3-11 时间对比试验数据图

VWH 自标定算法的计算复杂度低，故标定速度最快；光束自标定法需要迭代优化，标定时间最长；而本文算法通过高效算法实现，标定时间可控，介于两者之间。

但在强光照条件和噪声条件下，各算法运行时间均显著增加。VWH 法在所有场景下运行最快，适合实时应用。光束法的运行时间最长，因复杂的计算导致性能下降，且易受到环境因素影响。本算法在实验中表现稳定，鲁棒性较好。

中国知网 https://www.cnki.net

综合来看，本文所提的基于 MST 聚类优化的消失点相机自标定方法在准确性和鲁棒性方面具有显著优势，尤其在高光照和噪声等复杂条件下表现稳定。其通过多消失点信息和聚类优化，克服了光束自标定法对特征点依赖和 VWH 算法精度不足的局限性。虽然标定时间略长于 VWH 算法，但远低于光束自标定法，且精度提升明显。

3.6 本章小结

本章围绕交通监控相机标定技术展开了详细研究，首先介绍了传统相机标定方法和自适应交通监控相机标定方法，分析了传统相机标定方法的优势并指出其在交通场景中适用性不足的问题。之后提出基于 MST 聚类优化的消失点相机自标定方法，通过霍夫空间投影和最小生成树（MST）聚类算法，实现了高效且精确的三方向消失点检测与相机标定，解决了传统方法对场景变化的敏感性。

综上，本文所提出的相机自标定方法能够在大视野的交通监控场景中完成准确地相机标定，为后续的车辆运动参数测量奠定了坚实的基础。

中国知网 https://www.cnki.net

第 4 章 基于平滑 EKF 的车辆跟踪和运动参数测量方法

4.1 引言

对车辆行为和测控性能的精确评估，成为推动智能交通行业发展的核心任务之一。本研究提出了基于平滑扩展卡尔曼滤波器的车辆跟踪和运动参数测量方法，实现了动态场景下的车辆运动参数的准确测量。

本章将详细介绍平滑扩展卡尔曼滤波器的原理和运动参数计算的关键算法，并补偿和优化复杂场景下的测量误差。这些研究不仅为车辆的运动参数评估和量化提供了技术支持，同时也为智能交通系统的安全性提升打下了理论基础。

4.2 扩展卡尔曼滤波的研究和优化

4.2.1 扩展卡尔曼滤波的基础原理

扩展卡尔曼滤波器（Extended Kalman Filter, EKF）[80]是一种用于非线性动态系统状态估计的滤波器。它通过对非线性系统进行局部线性化，结合系统的预测与观测信息，实现对车辆运动状态的精确估计[81]。

EKF 是卡尔曼滤波器（Kalman Filter, KF）的非线性扩展版本，适用于系统状态方程和观测方程非线性的问题。对于非线性动态系统，一般由状态转移方程和观测方程表示，状态转移方程和观测方程表示为：

$$\begin{aligned} x_k &= f(x_{k-1}, u_{k-1}) + w_{k-1} \\ z_k &= h(x_k) + v_k \end{aligned} \tag{4-1}$$

其中，x_k 为系统在 k 时刻的状态向量；u_{k-1} 为控制向量，代表加速度，角加速度等；$f(\cdot)$和 $h(\cdot)$分别为状态转移函数和观测函数；w_{k-1} 和 v_k 分别为过程噪声和观测噪声，假设其满足零均值高斯分布，即：

$$w_{k-1} \sim \mathcal{N}(0, Q_k), \quad v_k \sim \mathcal{N}(0, R_k) \tag{4-2}$$

其中，过程噪声协方差矩阵 Q_k 和观测噪声协方差矩阵 R_k 用来衡量模

中国知网 https://www.cnki.net

型的准确度，值越小该模型就越准确。

EKF 的状态估计分为预测和更新两个阶段，在预测阶段可以根据状态转移方程预测当前状态：

$$\hat{x}_{k|k-1} = f(\hat{x}_{k-1|k-1}, u_{k-1}) \tag{4-3}$$

误差协方差预测：

$$\begin{aligned} P_{k|k-1} &= F_k P_{k-1|k-1} F_k^{\mathrm{T}} + Q_k \\ F_k &= \frac{\partial f}{\partial \mathbf{x}}\Big|_{\hat{x}_{k-1|k-1}, u_{k-1}} \end{aligned} \tag{4-4}$$

其中，F_k 是状态转移函数的雅可比矩阵。在更新阶段可以根据观测方程修正预测状态，卡尔曼增益计算可以由下式：

$$\begin{aligned} K_k &= P_{k|k-1} H_k^{\mathrm{T}} \left(H_k P_{k|k-1} H_k^{\mathrm{T}} + R_k \right)^{-1} \\ H_k &= \frac{\partial h}{\partial \mathbf{x}}\Big|_{\hat{\mathbf{x}}_{k|k-1}} \end{aligned} \tag{4-5}$$

其中，H_k 是观测函数的雅可比矩阵。更新阶段的状态更新表示为：

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \left(z_k - h(\hat{x}_{k|k-1}) \right) \tag{4-6}$$

误差协方差更新可以表示为：

$$P_{k|k} = \left(I - K_k H_k \right) P_{k|k-1} \tag{4-7}$$

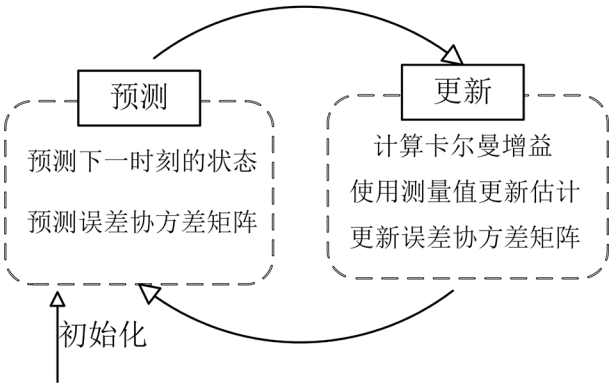


图 4-1 原始 EKF 流程图

以上是 EKF 的标准流程，上述过程可以在动态系统中递归执行，实现对目标状态的实时估计，配合匹配算法实现车辆的跟踪。原始 EKF 的更新预测实验图如图 4-2 所示。

中国知网 https://www.cnki.net

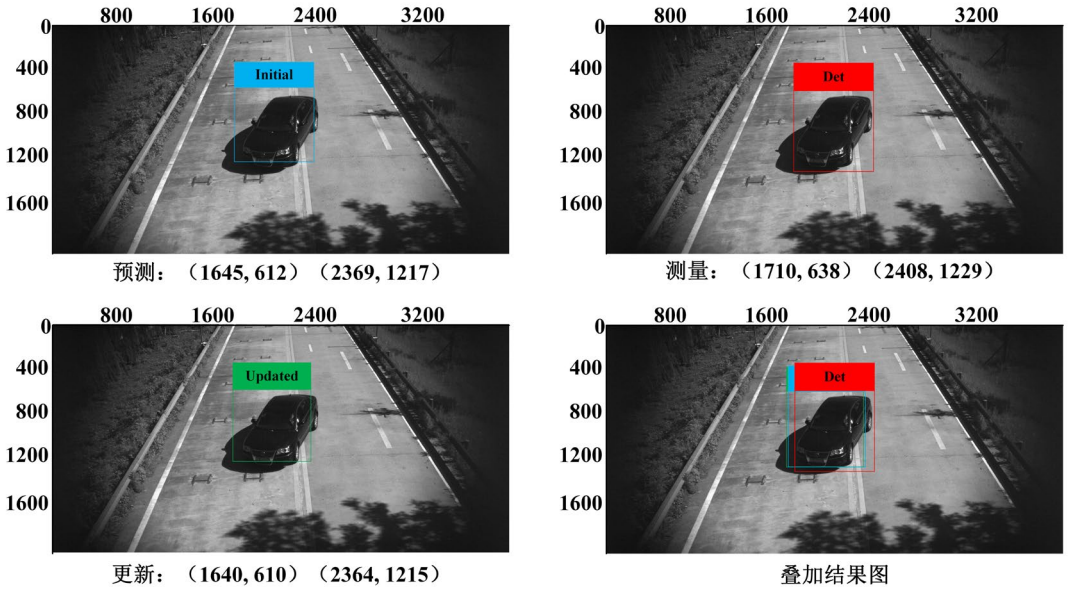


图 4-2 原始 EKF 预测更新图

上图展示了卡尔曼滤波器预测更新过程，红色边界框代表测量值，是检测模型检测值，比较可靠。蓝色边界框代表初始状态的预测值，绿色边界框代表更新后的状态更新值。

在本实验条件下，检测噪声较大，所以常规扩展卡尔曼滤波器更新后的状态坐标与初始状态坐标非常接近，与测量状态坐标相差比较大。这种现象说明该滤波器收到噪声影响太大，并没有发挥很好的更新-预测作用。

4.2.2 后向平滑的扩展卡尔曼滤波

传统 EKF 算法在实际应用中存在下述问题：（1）对历史轨迹的处理较弱；（2）缺乏对观测数据的全局优化；（3）单一的匹配策略可能导致跟踪错误。针对上述问题，本文在传统框架中引入平滑与插值操作优化了 EKF 的预测和更新机制，提升了轨迹测量的准确度和稳定性。

（1）EKF 预测与更新改进。

优化后的 EKF 仍遵循预测-更新的基本流程，但针对状态方程和观测方程的非线性问题，改进了状态估计的过程。

对于预测阶段，本方法在状态预测过程中，除了根据上一时刻的状态

中国知网 https://www.cnki.net

和控制量预测当前状态，还加入对噪声协方差的动态调整机制，以适应复杂场景的变化：

$$P_{k|k-1} = F_k P_{k-1|k-1} F_k^{\mathrm{T}} + \lambda Q_k, \tag{4-8}$$

其中，λ 为动态调整因子，与场景的复杂程度相关，可通过历史轨迹的变化率进行自适应计算。

对于更新阶段，更新阶段重点优化了卡尔曼增益的计算，增加了对噪声的权重调整：

$$K_k = \frac{\left(P_{k|k-1} H_k^{\mathrm{T}}\right)}{\left(H_k P_{k|k-1} H_k^{\mathrm{T}} + \beta R_k\right)} \tag{4-9}$$

其中，β 为噪声权重因子，可根据观测噪声的实时特性动态调整。

（2）平滑和插值机制。

传统 EKF 对目标状态的估计仅仅是基于单一时间点的递归更新，并没有充分利用全局的历史轨迹信息。为了提升轨迹测量的准确性，本研究在 EKF 基础上引入了 RTS 平滑器（Rauch-Tung-Striebel Smoother），替代固定窗口的平滑算法。

RTS 平滑器是一种基于后向递归的优化方法，能够充分利用未来时间点的信息修正历史状态，从而提高轨迹的平滑性和准确性。

RTS 平滑器可以分为三步，平滑增益计算、状态修正和协方差修正。平滑增益计算是在每一时刻 k，根据状态预测协方差计算平滑增益 G_k：

$$G_k = P_k F_k^{\mathrm{T}} P_{k+1}^{-1} \tag{4-10}$$

其中，P_k 表示时刻 k 的后验协方差；F_k 表示状态转移矩阵；P_{k+1} 表示时刻 k+1 的先验协方差。

状态修正是利用平滑增益将未来信息反馈到当前状态：

$$\hat{x}_{k|N} = \hat{x}_k + G_k\left(\hat{x}_{k+1|N} - \hat{x}_{k+1|k}\right) \tag{4-11}$$

其中，$\hat{x}_{k|N}$ 是时刻 k 的平滑状态估计；$\hat{x}_{k+1|N}$ 是时刻 k+1 的平滑状态估计；$\hat{x}_{k+1|k}$ 时刻 k+1 的预测状态估计。

协方差修正是对协方差矩阵进行平滑修正，修正方法可表示为：

$$P_{k|N} = P_k + G_k\left(P_{k+1|N} - P_{k+1}\right)G_k^{\mathrm{T}} \tag{4-12}$$

插值机制用于在目标短暂丢失时，补偿其轨迹缺失段。

中国知网 https://www.cnki.net

假设目标在时间 t_{start} 和 t_{end} 有观测数据，缺失段的插值轨迹 $\hat{x}_t$ 可表示为：

$$\hat{x}_t = \frac{t - t_{\text{start}}}{t_{\text{end}} - t_{\text{start}}} \hat{x}_{t_{\text{end}}} + \frac{t_{\text{end}} - t}{t_{\text{end}} - t_{\text{start}}} \hat{x}_{t_{\text{start}}}, \quad t \in [t_{\text{start}}, t_{\text{end}}] \tag{4-13}$$

插值后的轨迹可用作下一步的预测输入，从而实现轨迹的连续性。

优化后的 EKF 在目标状态预测和更新时不仅能够更好地适应复杂场景，还通过平滑和插值实现了轨迹全局优化，从而提高了对动态目标的跟踪精度。

优化后的 EKF 流程图如图 4-3 所示。

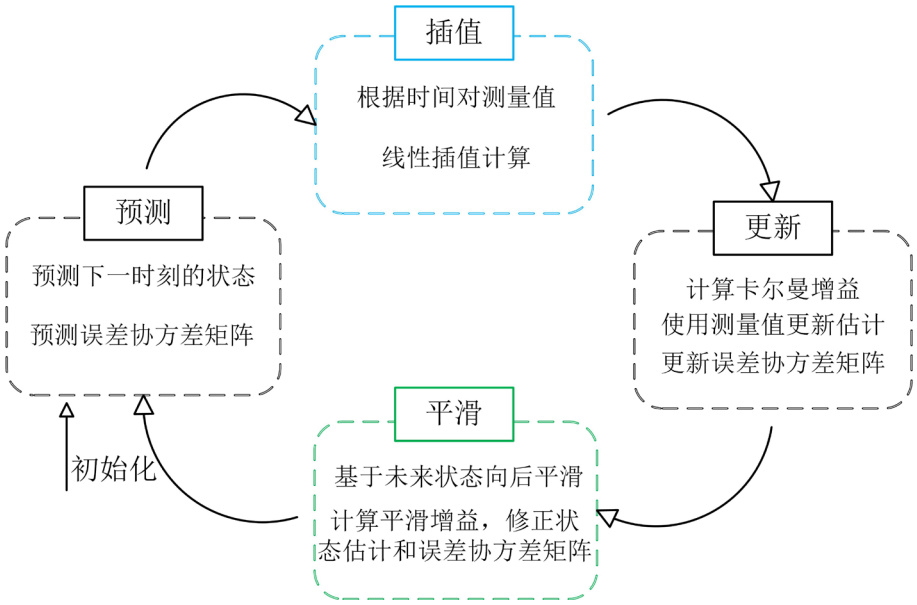


图 4-3 优化 EKF 流程图

以上是后向平滑 EKF 的标准流程，平滑和插值技术能够更好的利用历史信息，使得预测和更新更可靠。

优化后的 EKF 实验图如图 4-4 所示。

中国知网 https://www.cnki.net

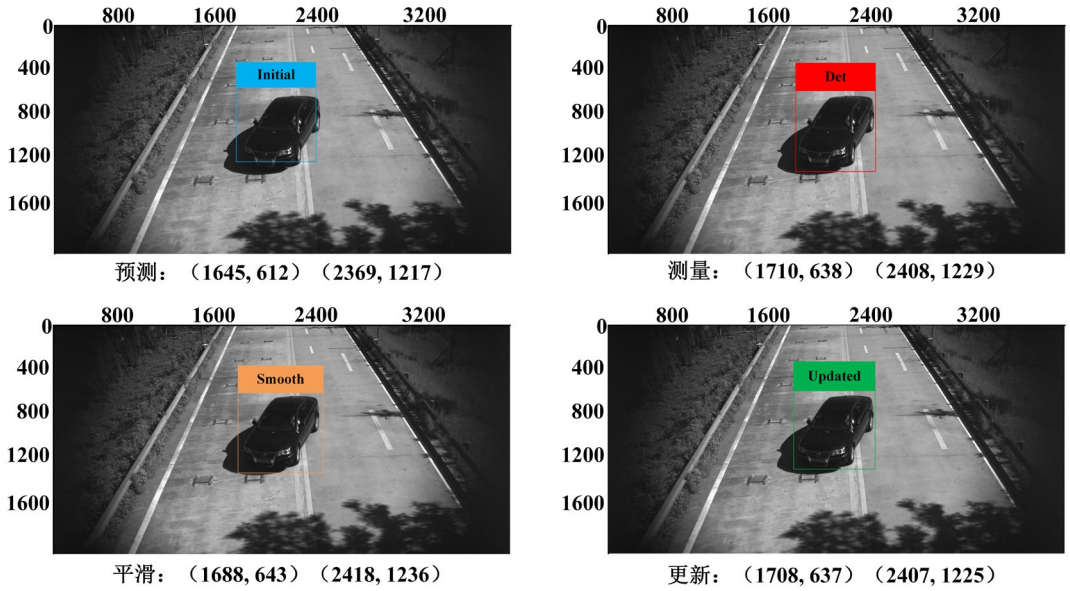


图 4-4 平滑优化 EKF 实验结果图

图 4-4 展示了后向平滑扩展卡尔曼滤波器的处理过程，蓝色边界框代表初始状态的预测值（像素坐标(1645, 612)(2369, 1217)），红色边界框代表测量状态的测量值（像素坐标(1710, 638)(2408, 1229)），该值比较可靠，橙色边界框代表平滑后的状态值（像素坐标(1688, 643)(2418, 1236)），绿色边界框代表更新后的状态更新值（像素坐标(1708, 637)(2407, 1225)）。

与扩展卡尔曼滤波器类似，该滤波器处理的初始状态和测量状态相差较大，但通过平滑步骤进行全局优化后，状态有所改进，最终更新状态和测量状态相近，说明本研究的功能克服了噪声等外部影响，效果领先传统扩展卡尔曼滤波器。

4.3 车辆关联匹配与跟踪实现

4.3.1 二分图匹配和匈牙利算法

在车辆关联匹配与跟踪的任务中，车辆的检测结果需要与已有的车辆轨迹进行关联，从而实现跨帧的车辆连续跟踪。由于检测误差、缺帧和环境噪声等因素的影响，车辆关联匹配的实现通常存在很大的困难。

中国知网 https://www.cnki.net

SORT 算法是一种针对多目标跟踪的简单而高效的算法。该算法利用卡尔曼滤波器对由深度传感器捕获的观测数据进行基于运动的多目标跟踪分析。其核心在于巧妙地结合了卡尔曼滤波器和匈牙利算法，以实现实时的多目标跟踪。

二分图匹配与匈牙利算法被广泛应用于解决车辆关联匹配的问题。

（1）二分图的定义是将一个完整的图划分为两组子图，每一组子图内的节点直接不相互连接，两组子图之间的节点相互连接。

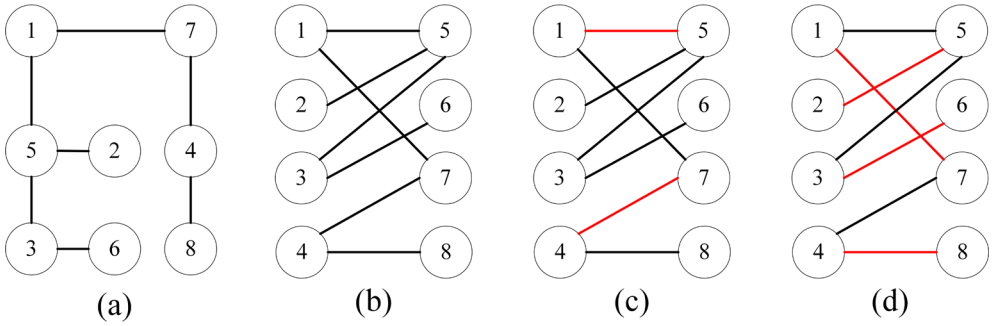


图 4-5 二分匹配图

上图(a)是一个二分图，将其分为两组，如图(b)所示。在二分图中，匹配就是指某条边的一个集合，上图(c)和图(d)中红色的边就是图(b)的一个匹配。图 4-5 的(d)中展示了一个最大匹配，最大匹配就是包含匹配边数最多的那个匹配。完美匹配的定义是指在某个匹配中，所有的顶点都被匹配。图 4-5(d)也是一个完美匹配。

（2）匈牙利算法常被用来解决二分图的最大匹配问题，尤其适用于带权二分图的最优匹配。算法的主要思想是通过构造辅助图和调整路径，不断优化匹配方案，直到找到最优解。为了理解该算法，首先需要介绍交替路和增广路的概念。

一个二分图中，如果有一条路径是从一个未匹配的顶点出发，沿非匹配边和匹配边交替行进的，那么该路径是交替路。

增广路则是从一个未匹配的顶点开始，沿非匹配边和匹配边交替行，且最终到达另一个未匹配的点的路径。如图 4-6 所示，图(b)就是图(a)中的一条增广路，增广路是一种特殊的交替路。

中国知网 https://www.cnki.net

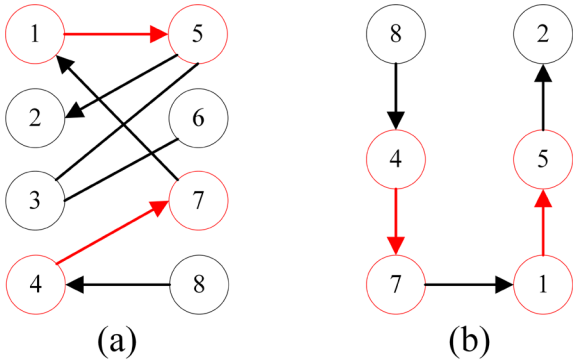


图 4-6 交替路和增广路示意图

增广路的一个显著特性是其包含的非匹配边比匹配边多一条。由于路径中的匹配节点与其他匹配边无关，所以可以采用交换匹配边和非匹配边的的方法来优化匹配，同时这种交换不会破坏匹配的合法性。交换完成后，匹配边的数量将比非匹配边多出一条。

匈牙利算法的核心就是在寻找增广路的过程中，不断通过交换匹配边与非匹配边，逐步提升匹配中顶点和边的数量，直到无法再找到增广路为止，最终实现了最大匹配。

4.3.2 多特征加权融合

在车辆跟踪任务中，车辆检测框与跟踪器之间准确的关联匹配是做到准确跟踪的基础。

传统的车辆跟踪方法通常是采用匈牙利算法，通过构建代价矩阵，并依据代价最小化的原则，完成检测框与跟踪器的最优匹配。然而，传统的匈牙利算法仅考虑单一特征，难以应对复杂场景中目标的相似性问题。

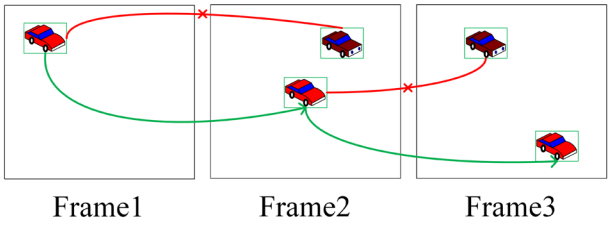


图 4-7 车辆匹配跟踪示意图

为此，本文结合多特征融合策略，优化了匈牙利算法的匹配过程。为

中国知网 https://www.cnki.net

提高匹配的鲁棒性，需要构建多特征融合的代价矩阵，即构建基于位置特征、运动特征和外观特征的代价矩阵。

位置特征关联是利用目标在图像坐标系中的位置和预测轨迹，计算交并比（IoU）匹配代价，该代价用来表示检测框与跟踪框的空间匹配度：

$$C_{pos}=1-\mathrm{IoU}(B_i,B_j)=1-\frac{B_i\cap B_j}{B_i\cup B_j} \tag{4-14}$$

其中，$B_i=[x^i_{\min},y^i_{\min},x^i_{\max},y^i_{\max}]$表示当前帧第 i 个检测框的坐标。$B_j=[x^j_{\min},y^j_{\min},x^j_{\max},y^j_{\max}]$表示第 j 条预测轨迹的边界框。

运动特征关联是通过扩展卡尔曼滤波（EKF）预测车辆的速度矢量余弦相似度关联。基于车辆的运动连续性，定义速度矢量的方向一致性：

$$C_{mot}=1-\frac{\mathbf{v}_i\cdot\mathbf{v}_j}{\|\mathbf{v}_i\|\ \|\mathbf{v}_j\|} \tag{4-15}$$

其中，$\mathbf{v}_i=[\dot{x}_i,\dot{y}_i]^T$ 表示检测框 i 的速度矢量，由相邻帧位移差分计算。$\mathbf{v}_j=[\dot{x}_j,\dot{y}_j]^T$ 表示轨迹 j 的预测速度矢量，由 EKF 状态量提取。

外观特征关联是提取目标的颜色直方图特征，利用余弦相似度计算外观匹配代价：

$$C_{app}=1-\frac{\mathbf{f}_i\cdot\mathbf{f}_j}{\|\mathbf{f}_i\|\ \|\mathbf{f}_j\|} \tag{4-16}$$

其中，$\mathbf{f}_i$ 和 $\mathbf{f}_j$ 分别为跟踪器和检测框的外观特征向量。

为消除多特征量纲差异，采用 Min-Max 归一化处理。对于位置特征，$C_{pos}\in[0,1]$；对于运动特征，速度余弦相似度 $C_{mot}\in[-1,1]$；对于外观特征，特征向量余弦距离 $C_{app}\in[0,2]$；所以需要对运动特征和外观特征进行归一化，映射至[0, 1]。

$$\begin{aligned}C'_{mot}&=\frac{C_{mot}+1}{2}\\ C'_{app}&=\frac{C_{app}}{2}\end{aligned} \tag{4-17}$$

最终关联得分通过加权融合上述特征得分：

$$C(i,j)=\alpha C_{pos}+\beta C'_{mot}+\gamma C'_{app} \tag{4-18}$$

其中，α，β 和 γ 为权重因子，满足 $\alpha+\beta+\gamma=1$。实验测得最优权重比为

中国知网 https://www.cnki.net

0.5:0.3:0.2。

4.3.3 车辆匹配跟踪策略

（1）车辆匹配跟踪策略

车辆匹配跟踪策略是车辆跟踪系统中的关键环节，其主要目的是将当前帧检测到的车辆与已有的轨迹进行准确匹配。本文采用多特征加权融合的代价矩阵，并通过匈牙利算法求解最优匹配策略，从而实现车辆的准确跟踪。

匈牙利算法在车辆跟踪中可以形象化表述为：构建初始的代价矩阵 C，其中 C_{ij} 表示检测目标 d_i 和轨迹 t_j 之间的匹配代价。在代价矩阵上进行若干次行列操作，以确保矩阵中存在零值，且每个零值都代表一个潜在的匹配。然后在矩阵中找到一个完美匹配，并迭代优化，直到匹配代价达到最优，即此时的匹配为最优。

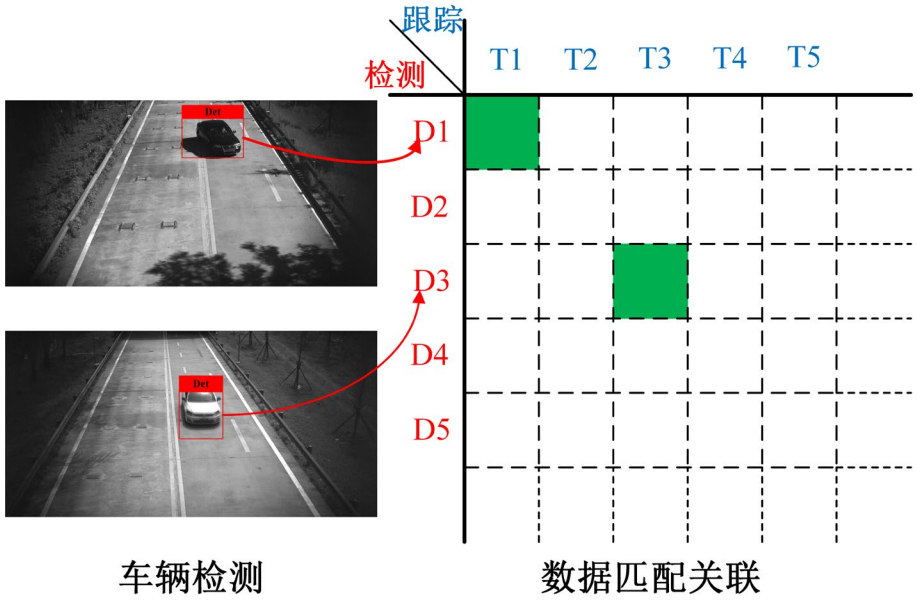


图 4-8 车辆检测和匹配关联图

为了利用多特征加权提高匹配准确度，本文研究使用新的车辆匹配策略，该策略包含粗匹配、精匹配和新轨迹初始化三个阶段。

粗匹配阶段以运动特征为主，输入当前帧检测框 D_t、预测轨迹 $T_{t|t-1}$，

中国知网 https://www.cnki.net

如果速度余弦相似度 $C_{mot}<\tau_1=0.9$，那么输出高置信度匹配对集合 M_1。

精匹配阶段以特征融合为主，输入未匹配检测框 D_t'和未匹配轨迹 T_t'，如果综合代价 $C(i,j)<\tau_2=0.7$，那么输出次级匹配对集合 M_2。

$$D_t^{'}=\frac{D_t}{M_1},\quad T_t^{'}=\frac{T_{t|t-1}}{M_1} \tag{4-19}$$

新轨迹初始化是对剩余未匹配检测框 D_t''进行处理，若连续 5 帧未被关联，则初始化为新轨迹。

根据线性分配的结果，本方法维护两个列表，分别用于存储未匹配的检测和未匹配的跟踪。未匹配的检测指的是当汽车首次被检测到时，未与任何现有轨迹相匹配；未匹配的跟踪则指的是当汽车离开某一帧时，之前建立的轨迹将不再进行检测。

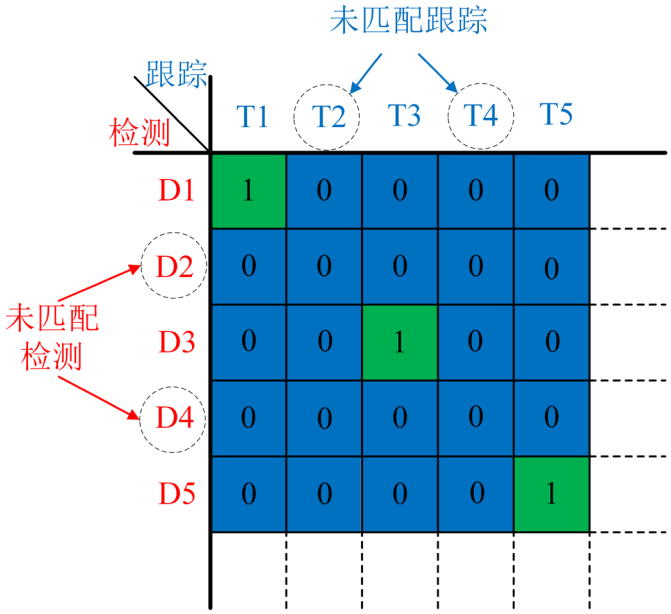


图 4-9 车辆匹配跟踪原理图

该跟踪器的轨迹管理机制如下所示。

表 4-1 跟踪器管理机制表

操作	触发条件	处理逻辑
跟踪确认	连续匹配成功 3 帧	加入匹配跟踪列表
轨迹初始化	连续 5 帧未匹配	初始化为新轨迹
跟踪恢复	丢失后 3 帧内重新匹配	EKF 平滑插值补全轨迹

中国知网 https://www.cnki.net

（2）跟踪性能验证

为了验证本文提出的基于平滑 EKF 的车辆跟踪算法的性能，本文采用测试视频进行车辆跟踪测试，并与 SORT 算法进行车辆跟踪对比。在使用跟踪算法进行车辆跟踪时，跟踪器会为测试数据中的每个检测到的车辆绘制检测框和轨迹，当同一车辆行驶时，轨迹出现中断的话就说明跟踪失败。



(a) SORT 算法跟踪数据 1　　(b) SORT 算法跟踪数据 2

图 4-10 SORT 算法车辆跟踪失败图

如图 4-10 所示，对于同一车辆，SORT 算法在进行跟踪时候出现了跟踪失败的问题，即在同一个车辆的时候判断为非同一目标车辆，这主要是由于阴影环境影响和运动突变场景问题，以及由于检测器性能不完善而导致跟踪失败的情况。



(a) 本文算法跟踪数据 1　　(b) 本文算法跟踪数据 2

图 4-11 本文算法车辆持续跟踪图

如图 4-11 所示，本文算法在相同测试视频下，对车辆能够做到持续跟踪，不存在未匹配问题。从车辆检测开始到车辆检测结束，始终保持跟踪同一目标车辆，这表明本文跟踪算法通过 EKF 平滑插值与多特征融合，有效解决了 SORT 在遮挡和运动突变场景下的跟踪失败和目标变换问题。在复杂交通场景中的跟踪保持能力显著优于 SORT。

为了进一步验证本研究所提算法对车辆跟踪的性能，本研究在 KITTI

中国知网 https://www.cnki.net

Tracking 基准数据集上（包含 21 个复杂交通场景序列）进行测试，并与 SORT、DeepSORT 和 FairMOT 算法进行对比。实验评估指标包括多目标跟踪精度（MOTA）、ID 保持（IDF1）、总 ID 切换数（ID Switch）、总误报数（FP）和总漏报数（FN）。

表 4-2 实验结果对比表（KITTI 验证集）

算法	MOTA(%)	IDF1(%)	ID Switch	FP	FN
SORT	57.4	62.1	1243	2856	3891
DeepSORT	64.8	68.7	892	2412	3205
FairMOT	72.3	74.5	537	1987	2764
本算法	62.7	65.3	963	2435	3340

表 4-2 中展示了实验结果，本算法在验证集上的表现但整体性能还算可以，在各项指标上均优于 SORT，表明本算法在跟踪准确性、目标身份跟踪稳定性以及目标检测准确性等方面相比 SORT 有明显进步，对 SORT 算法进行了有效的改进和优化。

在验证集上，本算法能够取得一定的跟踪效果，MOTA 达到 62.7%，IDF1 为 65.3%，在实验中可以作为一种有效的跟踪算法选择。

4.4 车辆运动参数测量与补偿策略

4.4.1 车辆运动参数测量

车辆运动参数的测量是通过对连续时间内车辆轨迹数据的分析，计算得出车辆运动的轨迹、轨迹曲率、速度、加速度、航向角和转向角这六种关键运动参数。

在此基础上，本研究还提出了一种运动参数校验与补偿方法，确保了测量结果在噪声干扰和数据丢失情况下的准确性。

（1）运动轨迹测量与轨迹曲率测量。运动轨迹是指车辆的空间行驶路径，直接反映其行驶方向和路线。利用目标跟踪算法，在连续帧中跟踪同一车辆目标，记录其物理坐标点序列(x_k, y_k)。

通过轨迹数据分析可获取行驶路径长度、变向点和停滞区域等特征，

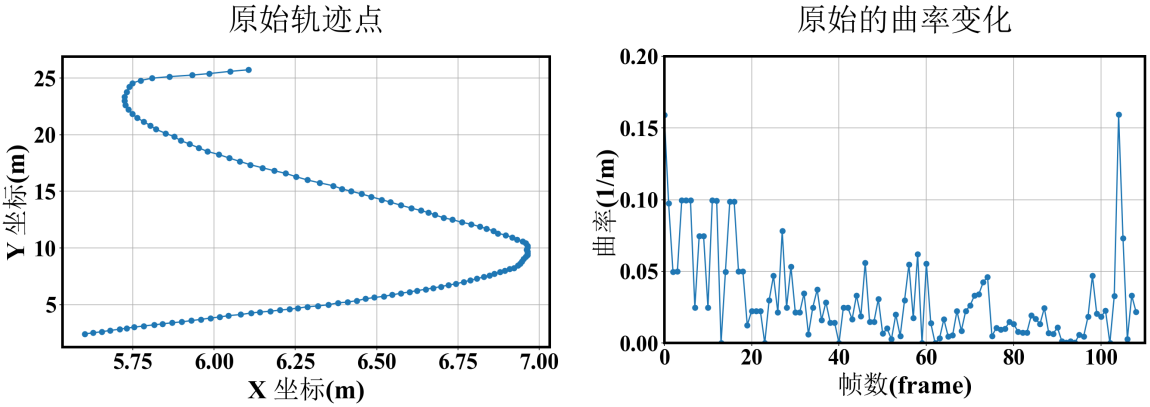
中国知网 https://www.cnki.net

为后续的偏航测量和交通流分析提供支持。

轨迹曲率测量是根据多帧位置点拟合轨迹曲线，用于反映车辆轨迹的平滑性及弯道特性，在曲率变化显著时，可辅助判断急转弯行为。利用曲率公式计算曲率：

$$\kappa(k)=\frac{|x_k'y_k''-y_k'x_k''|}{\left((x_k')^2+(y_k')^2\right)^{3/2}} \tag{4-20}$$

其中 x_k', y_k'和 x_k'', y_k''分别为一阶和二阶导数。



(a) 轨迹变化图　　(b) 轨迹曲率变化图

图 4-12 轨迹和轨迹曲率测量

（2）速度和加速度测量。速度测量是反映车辆行驶动态的基础参数，通过分析车辆在连续图像帧中的位置变化进行计算。计算车辆在时间间隔 Δt 内的瞬时速度：

$$v(k)=\frac{\sqrt{(x_k-x_{k-1})^2+(y_k-y_{k-1})^2}}{\Delta t} \tag{4-21}$$

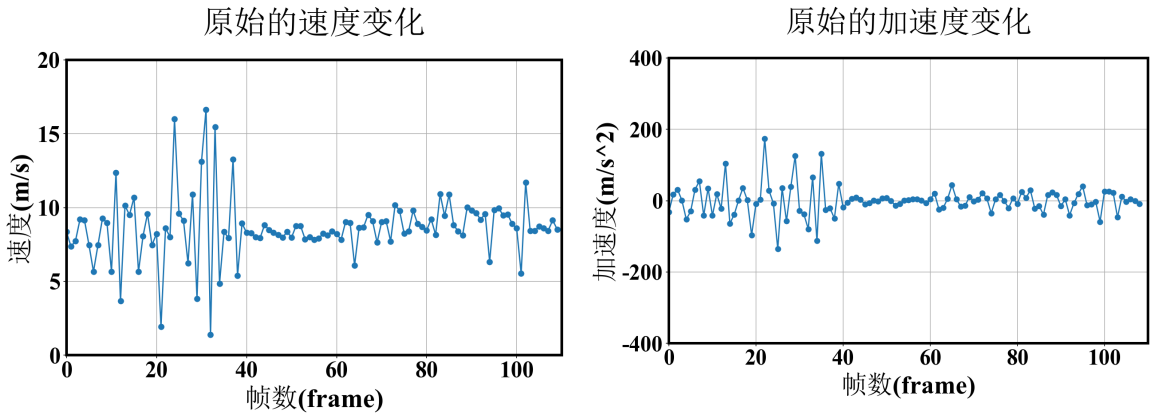
其中 Δt 为时间间隔，(x_k, y_k)为第 k 帧车辆重心的像素坐标，(x_{k-1}, y_{k-1})为第 k-1 帧车辆重心的像素坐标。速度测量结果为瞬时速度，可用于轨迹预测和航向计算；

加速度测量是速度随时间的变化率，用于描述车辆动态特性。基于连续帧速度数据，第 k 帧加速度 $a(k)$计算公式为：

$$a(k)=\frac{v(k)-v(k-1)}{\Delta t} \tag{4-22}$$

加速度测量可捕捉车辆在加速、减速以及紧急变向时的状态变化，实现更全面的车辆运动描述。

中国知网 https://www.cnki.net



(a) 速度变化图　　(b) 加速度变化图

图 4-13 速度和加速度测量

（3）航向角和转向角测量。航向角的测量是基于速度矢量计算，航向角测量结果可用于判断车辆行驶方向，第 k 帧航向角 $\psi(k)$的表达式为：

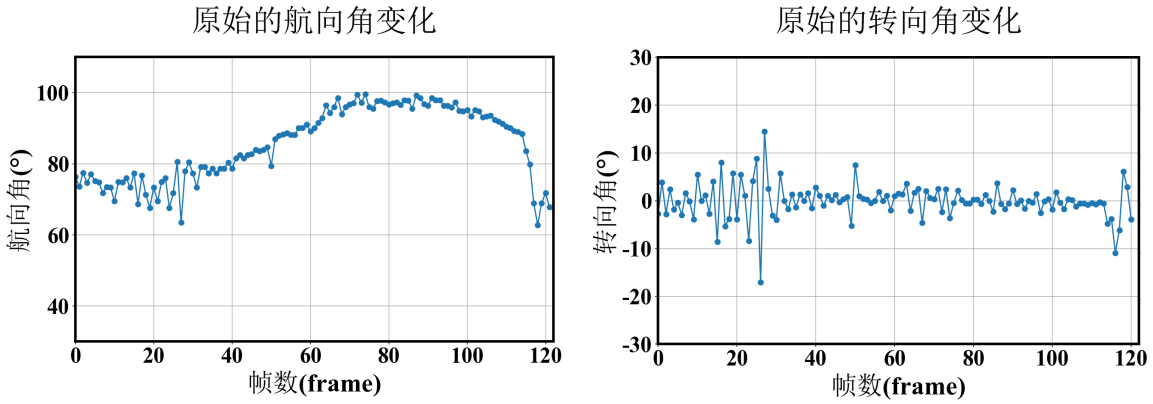
$$\psi(k)=\arctan\left(\frac{y_k-y_{k-1}}{x_k-x_{k-1}}\right) \tag{4-23}$$

航向角的变化趋势可用于分析车辆的转向行为，与轨迹曲率测量结合，有助于准确还原车辆行驶路径。

转向角反映车辆方向的变化，是分析车辆轨迹的重要参数。转向角是车辆行驶方向与上一时刻方向之间的夹角，用公式表示为：

$$\delta(k)=\psi(k)-\psi(k-1) \tag{4-24}$$

转向行为可以根据转向角大小与变化趋势进行分类，根据转向角 δ 的大小和变化趋势，可判断车辆的转向行为。



(a) 航向角变化图　　(b) 转向角变化图

图 4-14 航向角和转向角测量

中国知网 https://www.cnki.net

结合转向角和轨迹偏移分析，可以识别异常转向行为，例如急转弯或越线行驶。

通过上述车辆运动参数计算和补偿方法，本系统能够准确的测量车辆的运动参数并对其进行校验和补偿，为交通流分析、智能交通系统优化和交通计量提供强有力的数据支持。

4.4.2 运动参数的校验与补偿

车辆的运动参数可能受到多种因素的影响，例如噪声干扰、数据缺失和多传感器误差等。为了提高车辆运动参数测量的准确性，本文对所测的车辆运动参数进行校验和补偿，最终得到准确的车辆运动状态。

（1）轨迹和轨迹曲率计算补偿。为提高轨迹的连贯性和可靠性，采用移动平均滤波对轨迹数据进行局部平滑处理。

$$\begin{cases} x_{smooth}(k)=\dfrac{1}{w}\displaystyle\sum_{i=k-\left\lfloor\frac{w}{2}\right\rfloor}^{k+\left\lfloor\frac{w}{2}\right\rfloor}x(i) \\ y_{smooth}(k)=\dfrac{1}{w}\displaystyle\sum_{i=k-\left\lfloor\frac{w}{2}\right\rfloor}^{k+\left\lfloor\frac{w}{2}\right\rfloor}y(i) \end{cases} \tag{4-25}$$

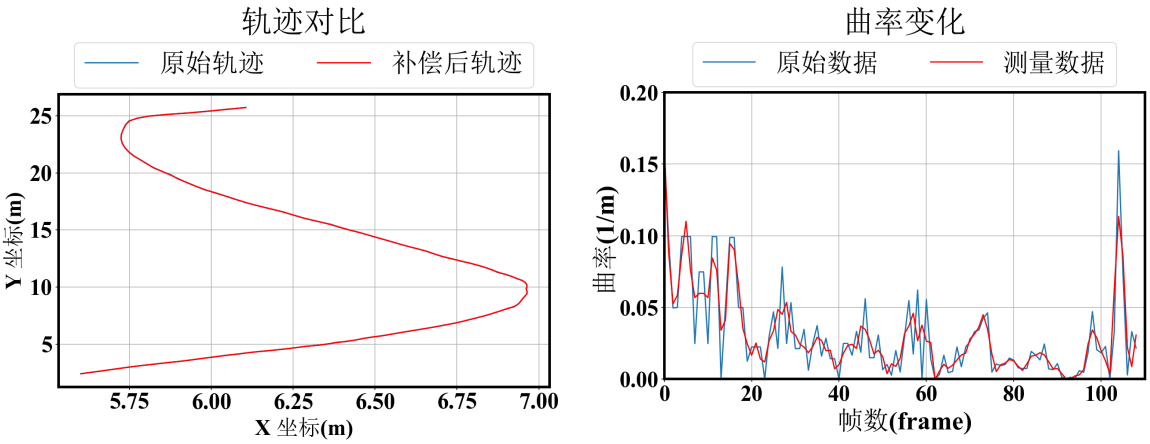
同时采用基于车辆的物理转向极限（最小转弯半径）来限制曲率值，防止出现不合理的急转弯。

$$\kappa_{\text{limited}}(k)=\begin{cases} 0.3, & \kappa(k)>0.3 \\ \kappa(k), & |\kappa(k)|\le 0.3 \\ -0.3, & \kappa(k)<-0.3 \end{cases} \tag{4-26}$$

其中，w 为滑动窗口大小，本文中 w 取值为 5，这样每一帧的平滑坐标都是其邻近帧坐标的平均值，有效减少噪声，提高轨迹的连贯性。

轨迹和轨迹曲率测量的原始数据和平滑数据如图 4-15 所示。

中国知网 https://www.cnki.net



(a) 轨迹变化图　　(b) 轨迹曲率变化图

图 4-15 轨迹和轨迹曲率测量

（2）速度与加速度补偿。针对运动参数中存在的噪声干扰，可利用历史状态和观测值对当前速度、加速度进行预测与校验，若偏差超出阈值，则以 EKF 的结果为准进行校正，同时从物理可行性方面对速度和加速度这两种参数进行限制。

对于速度，预测值 v_k^{pred} 和测量值 v_k^{meas} 的差值应满足以下条件：

$$|v_k^{\text{meas}} - v_k^{pred}| < \epsilon_v \tag{4-27}$$

若测量值超出阈值 ϵ_v，则认为测量值可能异常，直接采用预测值补偿。

$$v(k) = \begin{cases} v_k^{pred}, & \left|v_k^{meas} - v_k^{pred}\right| \geq \epsilon_v \\ v_k^{meas}, & \left|v_k^{meas} - v_k^{pred}\right| < \epsilon_v \end{cases} \tag{4-28}$$

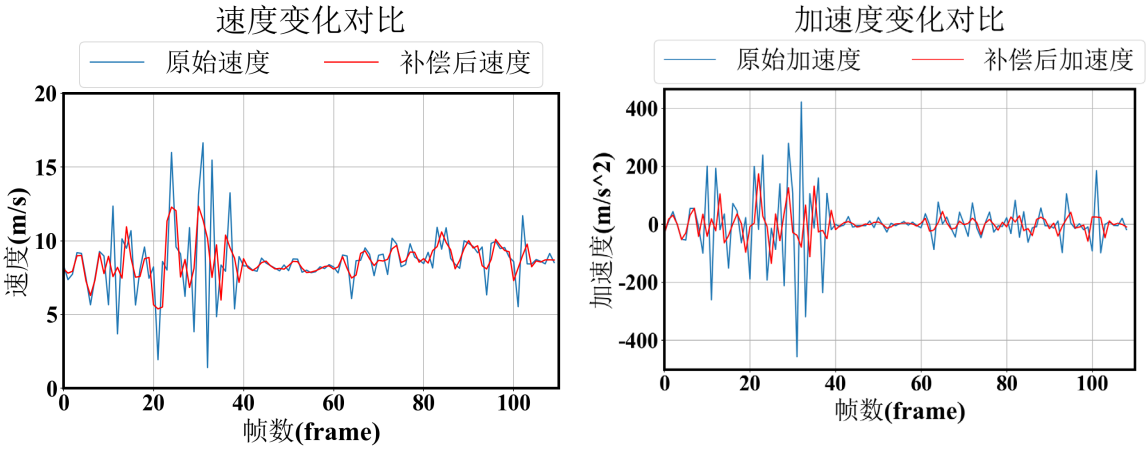
此外，基于车辆物理特性，限制速度的合理范围：

$$v_k^{limited} = \begin{cases} v_{\max}, & v(k) > v_{\max} \\ v(k), & 0 \leq v(k) \leq v_{\max} \\ 0, & v(k) < 0 \end{cases} \tag{4-29}$$

对于加速度，根据速度变化率预测加速度，对测量值进行平滑优化。

图 4-16 是速度和加速度测量与补偿实验结果对比图。

中国知网 https://www.cnki.net



(a) 速度变化图　　(b) 加速度变化图

图 4-16 速度和加速度对比

（3）航向角和转向角补偿。针对航向角和转向角可能存在的角度抖动或非物理性跳变，使用基于动力学模型的约束校验法和基于前后状态连续性的校验法，分别从物理可行性和时序平滑性角度进行补偿。

航向角变化率约束：基于单车模型，航向角变化率由车速 $v(k)$和转向角 $\delta(k)$决定：

$$\psi(k)=\frac{v(k)tan\delta(k)}{L} \tag{4-30}$$

如果航向角变化量超出限制，则修正为理论上限：

$$\psi(k)=\psi(k-1)+\text{sign}(\Delta\psi)\cdot\frac{v(k)tan\delta_{max}}{L}\cdot\Delta t \tag{4-31}$$

其中，sign 函数用于提取一个数的符号，L 为车辆轴距 L，$\delta_{\max}$ 为最大转向角，Δt 为样间隔。

根据前两时刻状态预测当前值，设定偏差阈值，若实际值与预测值偏差超过阈值，则修正为预测值。

$$\psi_{pred}(k)=2\psi(k-1)-\psi(k-2) \tag{4-32}$$

转向角变化率约束：转向角瞬时变化率不得超过机械极限：

$$\left|\delta(k)-\delta(k-1)\right|\le\delta_{max}\cdot\Delta t \tag{4-33}$$

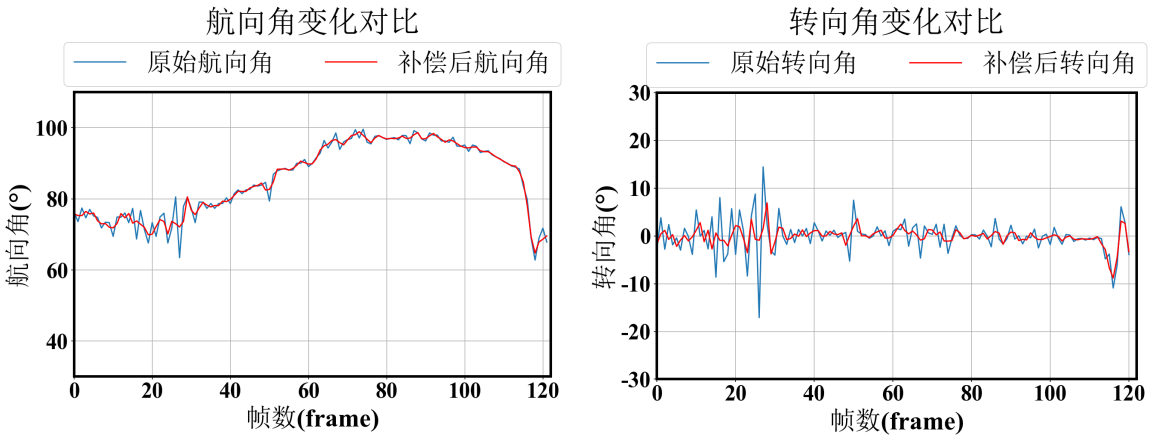
若超出限制，则修正为边界值：

$$\delta(k)=\text{clamp}(\delta(k),\delta(k-1)\pm\delta_{max}\cdot\Delta t) \tag{4-34}$$

其中，clamp 函数用于将某个值限制在指定的范围内。

图 4-17 是航向角和转向角测量与补偿实验结果对比图。

中国知网 https://www.cnki.net



(a) 航向角变化图　　(b) 转向角变化图

图 4-17 航向角和转向角测量

4.5 本章小结

本章主要介绍了基于平滑 EKF 的车辆跟踪和运动参数测量方法，详细探讨了扩展卡尔曼滤波的原理，并在其基础上进行优化，利用历史信息对原始滤波器进行平滑和插值优化。同时引入了基于车辆位置、运动和外观特征的加权融合策略，优化了匈牙利算法的匹配精度，解决了动态交通场景中的车辆跟踪问题。然后在车辆准确跟踪的基础上，通过连续时间内车辆轨迹数据的分析，对车辆的轨迹、轨迹曲率速度、加速度、航向角和转向角这六种参数进行测量。考虑到车辆的运动参数可能受到多种因素的影响，所以本研究对所测的运动参数进行校验和补偿，最终得到准确的车辆运动参数。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 5 章 运动参数测量与实验结果分析

5.1 引言

本章旨在通过实验验证基于高速成像的车辆运动参数测量系统的有效性与准确性。实验的核心任务是：

一、研究通过相机标定和坐标变换，有效地将图像坐标系下的车辆运动转换到世界坐标系下的车辆运动，从而实现准确的运动参数测量；

二、分析系统在不同帧率下的性能，评估高速成像对测量结果的影响。

实验过程中，本文验证了系统在车辆轨迹、轨迹曲率、速度、加速度、航向角和转向角这六种参数的测量精度，评估了高速成像技术对这些参数测量结果的优化作用。

5.2 实验环境和测试设置

5.2.1 实验准备

本实验系统主要硬件环境如表 5-1 所示。

表 5-1 实验软硬件环境配置表

环境	配置	环境	配置
系统	Windows11，64 位	编译器	Pycharm 2022
处理器	Intel(R) Core(TM) i5-13500HX	语言	Python 3.9
显卡	NVIDIA GeForce RTX 4060	模型	PyTorch 2.1.2
内存	16GB	架构	CUDA 12.4

实验所用的测试视频均拍摄于北京交通部试验场内部，实验道路为国家道路与桥梁工程检测设备计量站的 500 米长直线试验路段，均为相机俯视视角，相机安装图和实验道路图如下所示。

中国知网 https://www.cnki.net



(a) 相机安装示意图　　(b) 实验道路图

图 5-1 实验环境图

5.2.2 实验数据采集

实验视频的采集采用了多种帧率设置，包括 30fps、50fps 和 100fps，以测试不同帧率下系统的性能，测试包括 3 辆不同类型的车辆，行驶速度从 10km/h 到 70km/h 不等，模拟道路行驶下的直线和 S 线车辆运动行驶场景。



(a) 车辆直线运动图　　(b) 车辆 S 线运动图

图 5-2 实验信息图

视频采集表如下所示。

表 5-2 视频采集参数表

视频文件	帧率帧率/fps	车辆运动	分辨率
视频 1	30	直线	4096*2048
视频 2	50	直线	

中国知网 https://www.cnki.net

表 5-2 视频采集参数表（续）

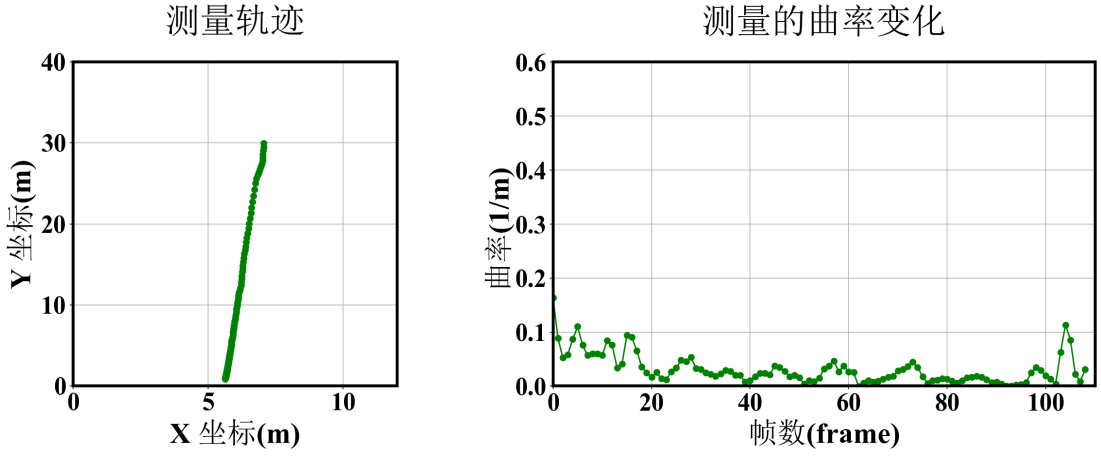
视频文件	帧率帧率/fps	车辆运动	分辨率
视频 3	100	直线	4096*2048
视频 4	30	S 线	
视频 5	50	S 线	
视频 6	100	S 线	

5.3 基于相机标定的参数测量与分析

运动参数的测量前提是车辆图像位置获取与准确的坐标系转换。首先，在每帧图像中检测车辆，并提取其位置中心点坐标，然后进行空间坐标转换。利用相机标定参数，进行坐标转换，将车辆运动图像坐标系下的车辆位置转换为世界坐标系中的位置，从而确保了参数测量的准确性。

5.3.1 车辆轨迹及轨迹曲率测量分析

车辆运动轨迹和轨迹曲率能够帮助更好地理解车辆的行驶路径和转向行为，下图展示了直线和 S 线运动下的车辆轨迹和轨迹曲率测量结果。



(a) 直线运动轨迹测量　　(b) 直线运动轨迹曲率测量

图 5-3 直线运动下轨迹和轨迹曲率测量图

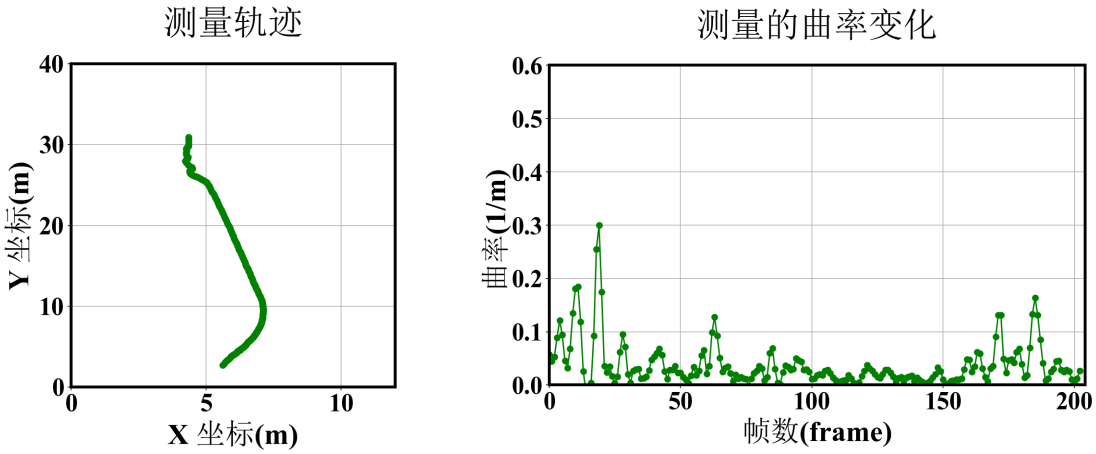
如图 5-3 的车辆轨迹测量结果所示，在直线运动中，车辆的轨迹呈现

中国知网 https://www.cnki.net

为一条直线，此测量结果表明系统能够精确地捕捉到车辆的运动轨迹，并通过坐标系转换和图像数据的处理，将车辆的实际运动轨迹进行了准确的重建。

如图 5-3 的车辆轨迹曲率测量结果所示，在直线运动中，轨迹曲率理论值为零，表示车辆沿直线路径行驶。系统的测量结果也显示直线运动时的的轨迹曲率测量值接近为零，表明此系统对轨迹曲率测量十分准确。

图 5-4 展示了系统对在 S 线运动下车辆的运动轨迹测量和曲率测量结果。



(a) S 线运动轨迹测量　　(b) S 线运动轨迹曲率测量

图 5-4 S 线运动下轨迹和轨迹曲率测量图

如图 5-4 的车辆轨迹测量结果所示，在车辆 S 线运动过程中，车辆的整体运动轨迹呈现出明显的弯曲形状。此测量结果表明系统能够准确地测量车辆在 S 线上的行驶路径。

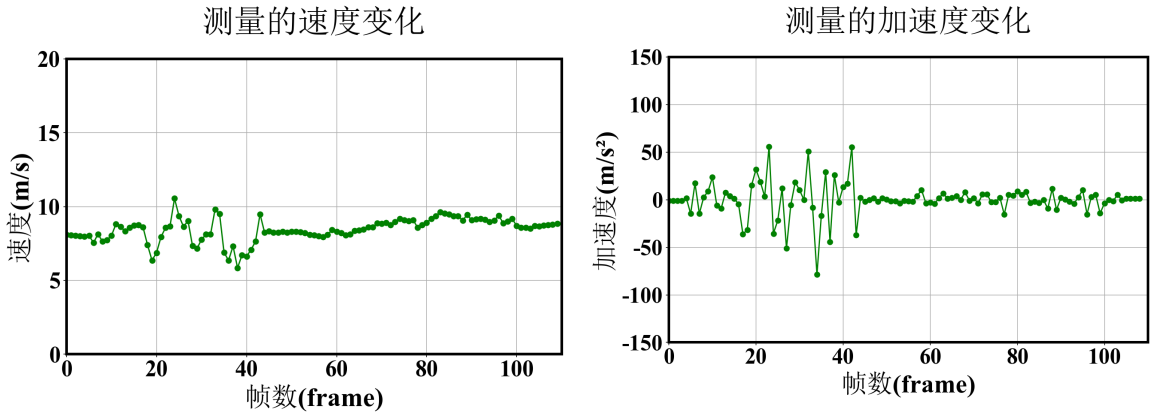
如图 5-4 的车辆轨迹曲率测量结果所示，在车辆 S 线运动中，车辆的轨迹曲率变化较为明显，轨迹曲率会随着车辆的转弯而产生变化，特别是在急转弯时，轨迹曲率变化较大。此测量结果表明此系统能够准确地测量车辆的轨迹曲率。

5.3.2 速度与加速度测量分析

速度和加速度的测量是通过连续视频帧之间的车辆位置变化来进行

中国知网 https://www.cnki.net

计算的，图 5-5 和图 5-6 分别展示了车辆直线和 S 线运动过程中速度和加速度的测量结果。

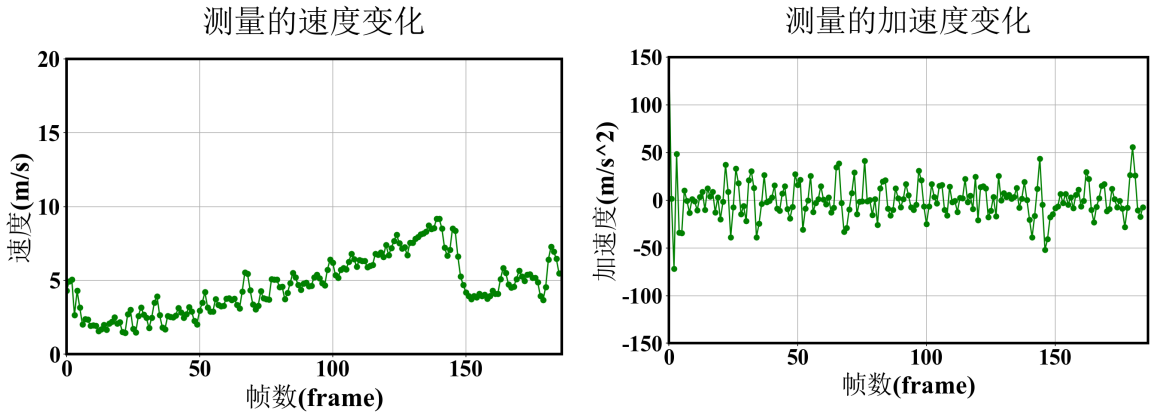


(a) 直线运动速度测量　　(b) 直线运动加速度测量

图 5-5 直线运动下速度和加速度测量图

图 5-5 的速度和加速度测量结果显示，在直线运动过程中车辆整体速度较为稳定，这表明系统能够准确测量车辆的瞬时速度。

同时系统所测得的加速度在零值上下浮动，这是由于车辆沿直线运动时一直保持匀速运动。该结果表明系统能够准确测量加速度。



(a) S 线运动速度测量　　(b) S 线运动加速度测量

图 5-6 S 线运动下速度和加速度测量图

如图 5-6 的速度测量结果所示，在 S 线运动中，车辆速度存在一定的波动，尤其是在转弯时速度波动更加明显。该测量结果表明系统能够精确捕捉车辆的速度变化，能够给出准确的速度测量结果。

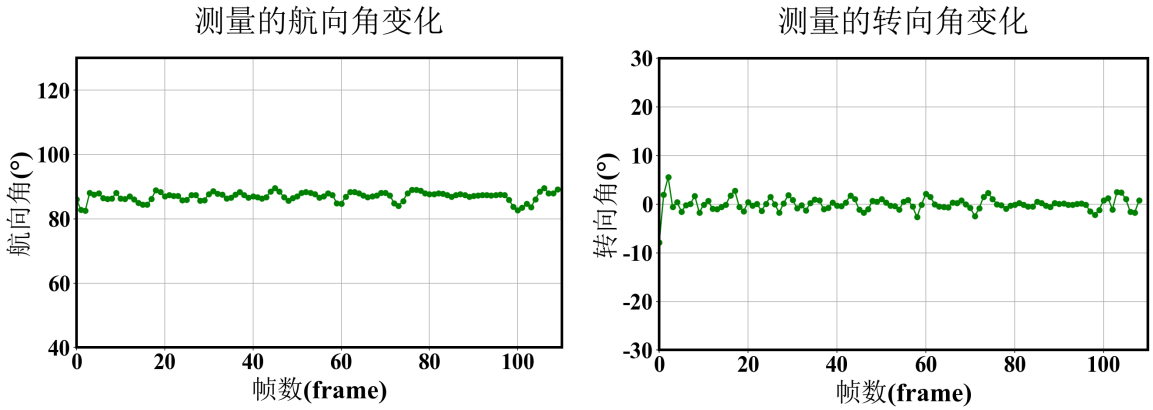
图 5-6 的加速度测量结果所示，S 线运动中的加速度变化比较复杂，

中国知网 https://www.cnki.net

加速度呈现较大的变化，这主要是由于车辆在 S 线运动中速度持续变化所导致的。该测量结果表明此系统能够准确测量车辆的加速度，特别是在车辆加速或转弯时，能够及时捕捉到加速度的变化。

5.3.3 航向角与转向角测量分析

航向角与偏航角的变化曲线显示了车辆行驶过程中方向的变化。图 5-7 和图 5-8 展示了车辆在直线和 S 线运动中航向角和转向角的变化。



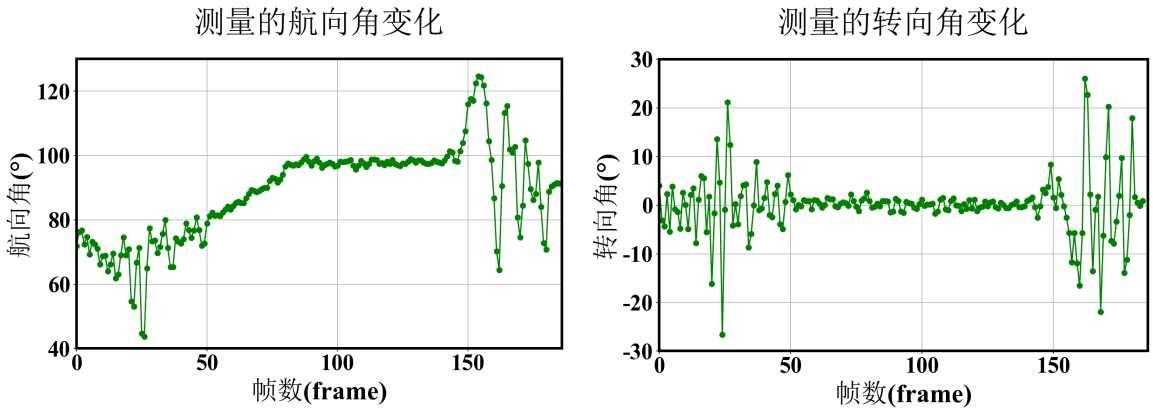
(a) 直线航向角测量　　(b) 直线运动转向角测量

图 5-7 直线运动下航向角和转向角测量图

如图 5-7 的航向角测量结果所示，在直线运动中，由于车辆行驶方向不发生改变，航向角的测量值非常接近一个固定值。系统所测的车辆直线运动航向角范围在 80°到 90°之间，误差较小，表明系统能够稳定测量车辆的航向角。

如图 5-7 的转向角测量结果所示，车辆的转向角测量结果始终在零值附近波动，表示车辆没有发生明显的转向运动。这表明系统能够准确测量出车辆直线运动时的车辆转向角。

中国知网 https://www.cnki.net



(a) S 线运动航向角测量　　(b) S 线运动转向角测量

图 5-8 S 线运动下航向角和转向角测量图

如图 5-8 的航向角测量结果所示，在车辆 S 线运动过程中，航向角会随着车辆转弯而发生变化，尤其在急转弯时，航向角的变化更加剧烈。测量结果表明该系统能够准确捕捉车辆航向角的变化。

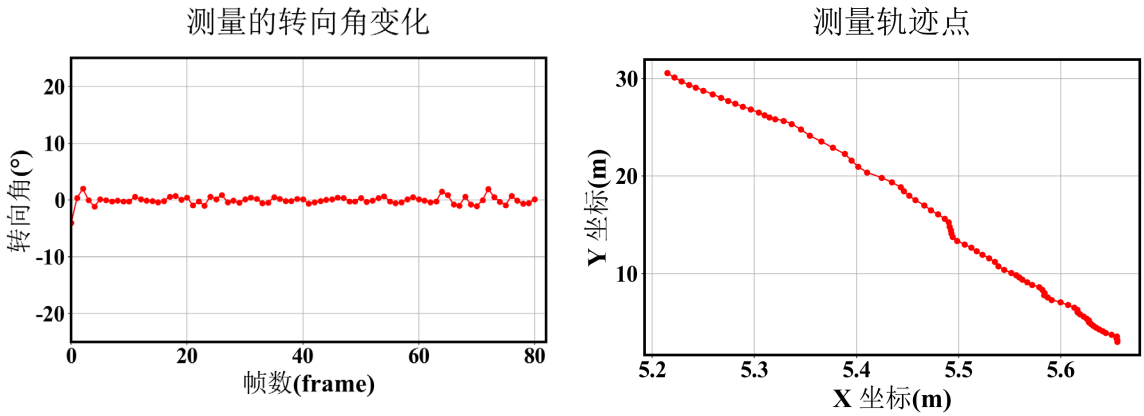
如图 5-8 的转向角测量结果所示，S 线运动中的转向角测量结果表现出较为明显的波动，尤其是在急转弯时，车辆的转向角变化会非常显著，与事实相符。测量结果表明系统能够准确捕捉转向角的变化。

5.4 高速成像对测量结果的影响

5.4.1 帧率对测量精度的影响

为了验证高速成像技术对车辆运动参数测量结果的影响，本研究分别拍摄车辆直线运动和车辆 S 线运动下的 30fps、50fps 和 100fps 的车辆运动视频进行实验测试。通过分析不同帧率下的车辆直线运动和车辆 S 线运动下的转向角和轨迹点测量结果，来验证高速成像对车辆运动参数测量结果的影响。

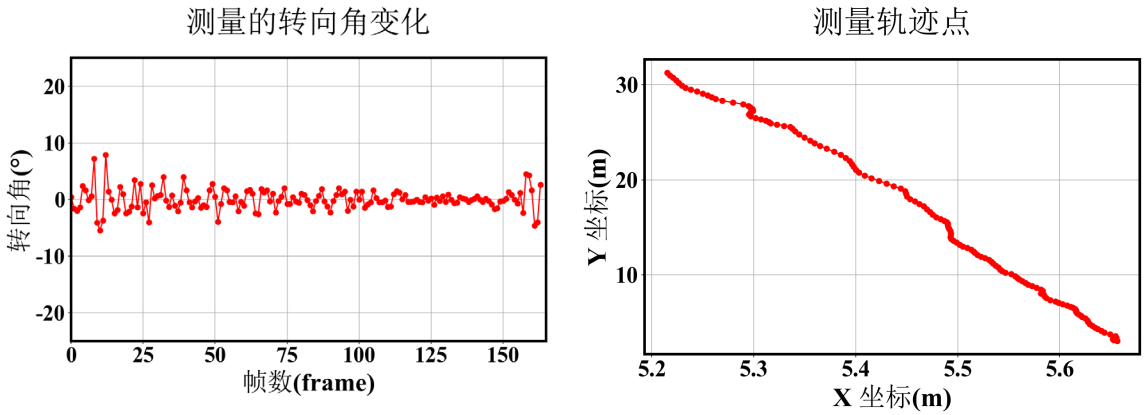
中国知网 https://www.cnki.net



(a) 直线运动 30fps 下转向角测量　　(b) 直线运动 30fps 下轨迹点测量

图 5-9 直线运动下 30fps 下测量图

图 5-9 展示了 30fps 视频条件下直线运动的车辆转向角和轨迹点测量结果。通过实验结果可以看出，在 30fps 的条件下，转向角的变化较为粗糙，并且存在较为明显的测量误差。车辆的轨迹点分布也较为离散，轨迹曲线波动较大，点与点之间的间隔明显，数据连续性较差。

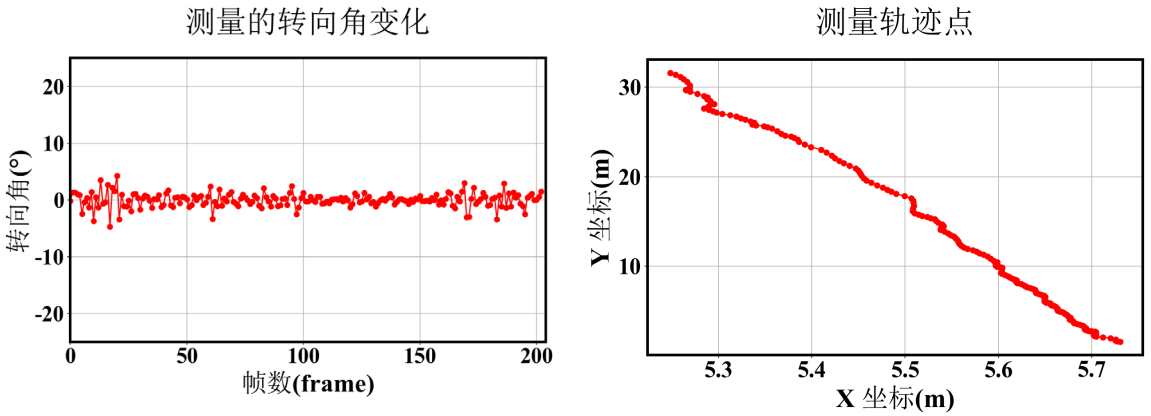


(a) 直线运动 50fps 下转向角测量　　(b) 直线运动 50fps 下轨迹点测量

图 5-10 直线运动下 50fps 下测量图

图 5-10 展示了 50fps 视频条件下直线运动的车辆转向角和轨迹点测量结果。通过实验结果可以看出，在 50fps 条件下，转向角的测量曲线更加平滑，变化趋势更加明显。轨迹点分布稍显密集，曲线波动有所减小，但仍存在一定程度的离散性，数据点之间的过渡不够平滑。

中国知网 https://www.cnki.net

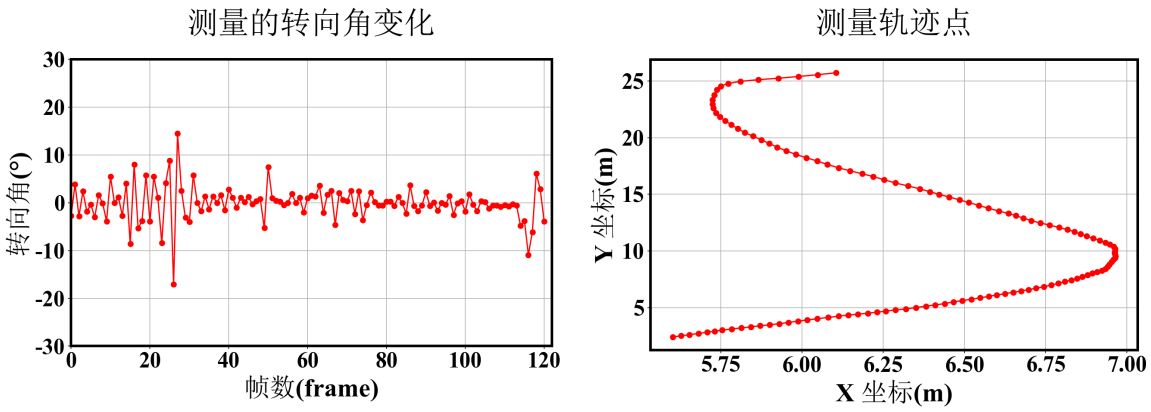


(a) 直线运动 100fps 下转向角测量　　(b) 直线运动 100fps 下轨迹点测量

图 5-11 直线运动下 100fps 下测量图

图 5-11 展示了 100fps 视频条件下直线运动下的车辆转向角和轨迹点测量结果。通过实验结果可以看出，在 100fps 的条件下，转向角的测量结果更加细致，变化趋势更加明显。轨迹点分布最为密集，曲线波动最小，数据点几乎连成一条平滑曲线，测量稳定性显著提升。

总结来看，在直线运动中，随着帧率从 30fps 增加到 100fps，系统能够更精确的捕捉车辆的运动细节，减少由于采样不足导致的误差，使轨迹曲线更贴近车辆的真实运动路径。



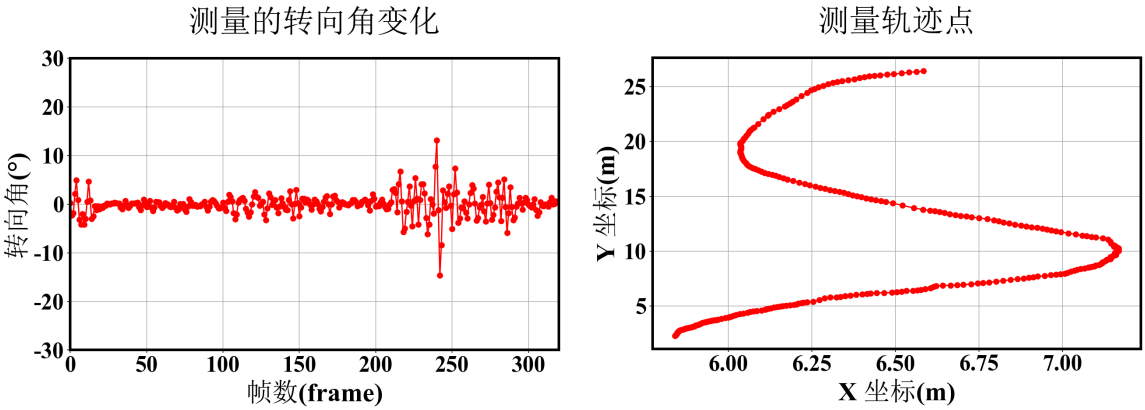
(a) S 线运动 30fps 下转向角测量　　(b) S 线运动 30fps 下轨迹点测量

图 5-12 S 线运动下 30fps 下测量图

图 5-12 展示了 30fps 视频条件下 S 线运动的车辆转向角和轨迹点测量结果。在车辆转弯时，车辆的转向角会发生明显的变化。但在 30fps 条

中国知网 https://www.cnki.net

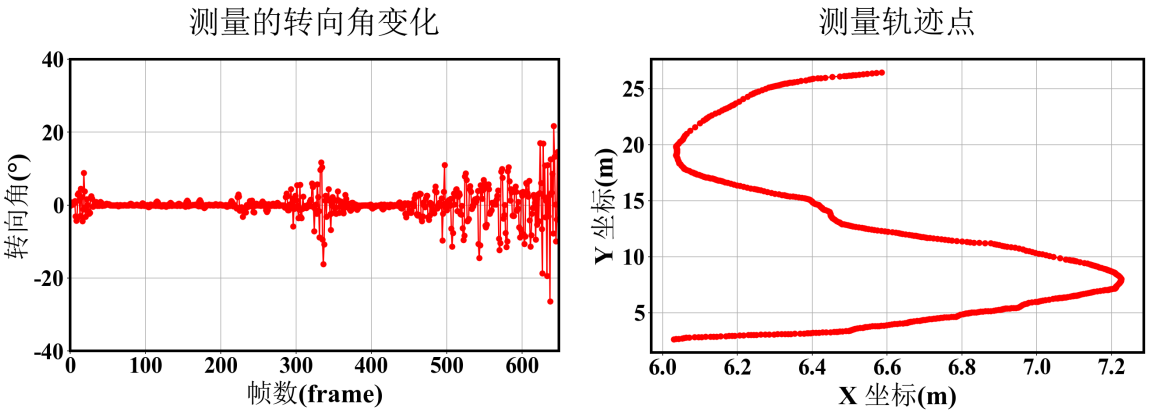
件下，转向角的变化表现得较为粗糙，尤其在急转弯的时候，测量的误差较大。所测的车辆的轨迹点也较为稀疏，轨迹的平滑性较差，并且出现了明显的断裂。



(a) S 线运动 50fps 下转向角测量　　(b) S 线运动 50fps 下轨迹点测量

图 5-13 S 线运动下 50fps 下测量图

图 5-13 展示了 50fps 视频条件下 S 线运动的车辆转向角和轨迹点测量结果。实验结果表明，在 50fps 条件下，系统能够准确捕捉到车辆转弯的细节，车辆转向角的波动也更加细致。所测量的轨迹点分布也更加紧密，能够比较准确地反映出车辆的行驶路径。



(a) S 线运动 100fps 转向角测量　　(b) S 线运动 100fps 轨迹点测量

图 5-14 S 线运动下 100fps 测量图

图 5-14 展示了 100fps 视频条件下，车辆转向角和轨迹点在 S 线运动时的测量结果。实验结果显示，在 100fps 条件下，该系统得到了最丰富

中国知网 https://www.cnki.net

的车辆位置数据，从而测出了车辆转向角度变化的最精确趋势。轨迹点的测量精度也有了明显的提高，可以更加准确的反映车辆在 S 线运动中的行驶路线。

总结在 S 线运动中，较高的帧率对车辆曲线运动下转向角的测量精度和稳定性提升效果显著，可以帮助系统更精细地捕捉车辆的转向行为，从而让测量转向角的结果变得更为细致。在 100fps 时，测量数据波动最小、精度最高，能有效还原车辆曲线运动时的转向情况。

通过对不同帧率下的车辆运动参数测量结果进行分析，可以得出以下结论：高速成像对于提高车辆运动参数测量精度具有重要作用，特别是在转向角和轨迹点的测量中，更高的帧率可以提高数据的丰富性，从而提高测量精度。

5.4.2 系统处理性能分析和评价

为了确保车辆运动参数测量的准确性，系统的处理性能尤为关键。系统的处理流程主要包括视频采集、相机标定、车辆检测与跟踪、标定坐标转换和运动参数计算这几个关键步骤，每个步骤都需要消耗一定的时间。

为了评估系统的处理性能和计算效率，本文通过对不同条件下实验录像的采集，计算出系统的处理时间，并对其进行比较分析。表 5-3 中显示了不同帧率条件下数据处理的时间，用来对系统的表现进行评估。

表 5-3 不同帧率下的系统处理时间与延迟

帧率	视频时长/s	标定时间/s	检测与跟踪时间/s	运动参数计算时间/s	总处理时间/s
30FPS	10	2.76	16.02	1.65	20.43
50FPS	10	2.58	27.59	2.18	32.35
100FPS	10	2.65	51.14	3.32	57.11

标定时间只依赖于初始帧的几何信息，与帧率无关。运动参数计算时间随帧率增加小幅提升，这与帧间数据关联的计算量增加有关。但随着视频帧率的提高，检测与跟踪时间随帧率线性增加，该模块的计算量与系统

中国知网 https://www.cnki.net

需要处理的帧数成正比，系统的总处理时间的增长主要由检测与跟踪时间主导，表明该模块是系统性能的瓶颈。

表 5-4 不同光照条件下的系统处理时间与延迟

光照条件	视频总帧数	标定时间/s	检测与跟踪时间/s	运动参数计算时间/s	总处理时间/s
正常光照	500	2.58	27.59	2.18	32.35
强光照	500	2.96	29.37	2.09	34.42
弱光照	500	3.17	31.56	2.34	37.07

表 5-4 展示了在不同光照条件下，系统对 50fps 视频处理时间的变化。类似光照条件的外部环境对系统的处理时间有一定影响。当光照较弱或光照较强时，可能是因为图像质量下降以及图像特征丢失，导致算法鲁棒性受到挑战，车辆检测的难度会增加，从而导致车辆检测和跟踪时间增加。

综上所述，系统在不同光照条件下的处理时间变化幅度较小（7%-14%），表明光照条件对系统效率的影响有限，系统在强光照和弱光照条件下的性能可控，总体稳定性较好。所以此系统能够适用于动态交通场景中的车辆跟踪和运动参数测量，并确保测量结果的准确性。

5.5 本章小结

本章通过实验展示了基于高速成像的车辆运动参数测量系统对车辆的轨迹、轨迹曲率、速度、加速度、航向角和转向角这些参数的准确测量。不管是在直线运动还是 S 线运动中，系统都能够准确地捕捉车辆的运动变化，系统表现出较高的鲁棒性。通过对比不同帧率视频的测量结果发现，高帧率的情况下，车辆的运动信息更加丰富，采集到的轨迹点更多，不会存在运动模糊和数据丢失的情况，因此在高帧率下，系统能够提供更加精确的运动参数数据，系统的运动参数测量精度也得到了显著提高。

本章通过实验证了以高速成像为基础的车辆运动参数测量系统的可靠性，同时也验证了车辆运动参数测量中高速成像的优点，证明了系统的可行性。

中国知网 https://www.cnki.net

第 6 章 总结与展望

6.1 本文总结

随着智能交通系统的发展，准确的车辆运动参数测量在交通流管理和交通计量中越来越重要。本文针对目前车辆运动参数测量技术存在的系统化和实用性问题，提出了基于高速成像的车辆运动参数在线测量系统，实现了对车辆的轨迹、轨迹曲率、速度、加速度、航向角和转向角的准确测量。

本文的主要创新成果和贡献体现在以下几个方面：

（1）鲁棒性的系统设计：本研究设计一套基于高速成像的车辆运动参数在线测量系统，通过高速相机采集车辆行驶数据然后分析测量。实验结果表明，该系统具备鲁棒性，能够在复杂场景下能够实现对车辆运动参数的准确测量。

（2）相机标定技术优化：针对传统标定方法在大视野监控场景中的局限性，提出了一种基于 MST 聚类优化的消失点相机自标定方法。通过 MST 聚类计算优化了消失点提取的精度，突破了传统方法消失点提取准确率低的问题，优化了标定精度，提升了系统在动态交通环境中的适应性和精度。

（3）车辆跟踪与运动参数测量及补偿的研究：本研究在传统 EKF 的基础上，充分利用历史信息对 EKF 进行后向平滑和插值优化，并结合多特征加权融合技术，提出了一种高效的车辆跟踪方法。在准确跟踪的基础上，实现车辆运动轨迹点的准确检测，利用相机标定参数，成功地将图像坐标系下的轨迹点转换到世界坐标系下的轨迹点，精确测量了车辆运动参数，并对这些参数进行补偿，提高了运动参数测量的准确性和稳定性。

（4）高帧率成像对测量精度的提升：本文通过实验验证了高帧率采集对测量精度的积极影响，尤其在车辆转弯、加速和刹车等复杂运动状态下，高帧率系统能够有效减少运动模糊，提高了测量结果的准确性。

中国知网 https://www.cnki.net

通过上述创新，本研究为交通计量领域的进步和智能交通行业的发展提供了可靠的技术支持，还为未来的交通管理和自动驾驶决策提供了可行的解决方案。

6.2 工作展望

本文研究基于高速成像的车辆运动参数测量方法，实现了一套软硬件完善的车辆运动参数测量系统，但由于深度学习的发展和多传感器融合方面的进步，本研究仍存在诸多问题有待深入研究。

（1）算法优化与实时性提升。随着交通环境和车辆行为的不断复杂化，本研究所提算法存在计算开销较大、实时性不足的问题。未来可以通过引入更高效的算法，进一步优化计算效率，提升实时性，以满足交通流管理和智能交通系统的要求。

（2）多传感器融合与数据同步。本研究仅使用一个高速相机实现了较为准确的车辆运动参数测量，但在实际交通环境中，激光雷达、毫米波雷达等传感器可以提供更多的感知信息。未来的研究可以从多传感器融合的方向入手，解决传感器间的数据同步问题，提升整体系统的精度和鲁棒性。

（3）深度学习与智能化应用。结合深度学习技术，进一步提升车辆检测、目标跟踪和运动参数估计的精度与鲁棒性。未来还可以利用深度学习去帮助系统更好地理解复杂的交通场景，为智能交通系统提供更可靠的数据支持。

综上所述，未来的研究可以从算法优化、传感器融合和智能化技术应用的方面入手，通过不断提升系统的性能，可以实现对日益复杂的交通流的稳定管理，最终推动智慧交通技术的发展与应用。

中国知网 https://www.cnki.net

参考文献

[1] Li L, Wen D, Yao D. A survey of traffic control with vehicular communications[J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15(1): 425–432.

[2] Yang B, Sun S, Li J, Lin X, Tian Y. Traffic flow prediction using LSTM with feature enhancement[J]. Neurocomputing, 2019, 332: 320–327.

[3] Liu Y, Tian B, Chen S, Zhu F, Wang K. A survey of vision-based vehicle detection and tracking techniques in ITS[C]//Proceedings of 2013 IEEE International Conference on Vehicular Electronics and Safety. Dongguan, China:IEEE,2013: 72–77.

[4] 洪汉玉，荆根强，章秀华. 现代图像图形处理与分析[R]. 武汉工程大学,2021.

[5] Lv Y, Duan Y, Kang W, Li Z, Wang F-Y. Traffic flow prediction with big data: a deep learning approach[J]. IEEE Transactions on Intelligent Transportation Systems, 2014: 1–9.

[6] Wu Y-J, Chen F, Lu C-T, Yang S. Urban traffic flow prediction using a spatio-temporal random effects model[J]. Journal of Intelligent Transportation Systems, 2016, 20(3): 282–293.

[7] Nur Fadila J, Haliza Abdul Wahab N, Alshammari A, Aqarni A, Al-Dhaqm A, Aziz N. Comprehensive review of smart urban traffic management in the context of the fourth industrial revolution[J]. IEEE Access, 2024, 12: 196866–196886.

[8] 田凯. 基于单目相机的车辆3D检测和鸟瞰视角下的跟踪算法研究[D]. 桂林:桂林电子科技大学,2023.

[9] 刘雨鑫. 基于视频流的车辆检测与跟踪系统研究[D]. 桂林:桂林电子科技大学,2023.

[10] Zhang Y, Liu K, Wang T. End-to-end Visual Object Tracking with Motion

中国知网 https://www.cnki.net

Saliency Guidance[C]//2020 39th Chinese Control Conference (CCC). Shenyang, China:IEEE,2020: 6566–6571.

[11] 张博研. 遥感图像的车辆目标检测与运动参数估计[D]. 西安:西安电子科技大学,2013.

[12] Bhardwaj R, Tummala G K, Ramalingam G, Ramjee R, Sinha P. AutoCalib: automatic traffic camera calibration at scale[J]. ACM Transactions on Sensor Networks, 2018, 14(3-4): 1-27.

[13] Hartley R I. Kruppa's equations derived from the fundamental matrix[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1997, 19(2): 133–135.

[14] Sang De Ma. A self-calibration technique for active vision systems[J]. IEEE Transactions on Robotics and Automation, 1996, 12(1): 114–120.

[15] Peng E, Li L. Camera calibration using one-dimensional information and its applications in both controlled and uncontrolled environments[J]. Pattern Recognition, 2010, 43(3): 1188–1198.

[16] He X, Zhang H, Hur N, Kim J, Wu Q, Kim T. Estimation of internal and external parameters for camera calibration using 1D pattern[C]//2006 IEEE International Conference on Video and Signal Based Surveillance. Sydney, Australia:IEEE, 2006: 93–93.

[17] Du F, Brady M. Self-calibration of the intrinsic parameters of cameras for active vision systems[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition. New York, NY, USA:IEEE Comput. Soc. Press,1993: 477–482.

[18] Chang H, Tsai F. Vanishing point extraction and refinement for robust camera calibration[J]. Sensors, 2018, 18(1): 63.

[19] Zhengyou Zhang. Flexible camera calibration by viewing a plane from unknown orientations[C]//Proceedings of the Seventh IEEE International Conference on Computer Vision. Kerkyra, Greece:IEEE,1999: 666–673 卷 1.

中国知网 https://www.cnki.net

[20] Tardif J-P. Non-iterative approach for fast and accurate vanishing point detection[C]//2009 IEEE 12th International Conference on Computer Vision. Kyoto:IEEE,2009: 1250–1257.

[21] Dron L. The multiscale veto model: a two-stage analog network for edge detection and image reconstruction[J]. International Journal of Computer Vision, 1993, 11(1): 45–61.

[22] 李华, 吴福朝, 胡占义. 一种新的线性摄像机自标定方法[J]. 计算机学报, 2000(11): 1121–1129.

[23] 李世杰. 基于基础矩阵的相机自标定方法研究[D]. 大连:大连理工大学, 2018.

[24] Kanhere N K, Birchfield S T. A taxonomy and analysis of camera calibration methods for traffic monitoring applications[J]. IEEE Transactions on Intelligent Transportation Systems, 2010, 11(2): 441–452.

[25] Maybank S J, Faugeras O D. A theory of self-calibration of a moving camera[J]. International Journal of Computer Vision, 1992, 8(2): 123–151.

[26] Fischler M A, Bolles R C. Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography[J]. Communications of the ACM, 1981, 24(6): 381-395.

[27] 段成钢, 李秀智. 一种基于三消隐点的摄像机自标定算法[J]. 计测技术, 2007(04): 20–21, 25.

[28] Lepetit V, Moreno-Noguer F, Fua P. EPnP: an accurate O(n) solution to the PnP problem[J]. International Journal of Computer Vision, 2009, 81(2): 155–166.

[29] Zheng Y, He Z, Yang W-G, Zhang X F. An efficient and practical calibration method for roadside camera using two vanishing points[C]// Proceedings 2014 IEEE International Conference on Security, Pattern Analysis, and Cybernetics (SPAC). Wuhan, China:IEEE,2014: 65–69.

[30] Zhai M, Workman S, Jacobs N. Detecting vanishing points using global image context in a non-ManhattanWorld[C]//2016 IEEE Conference on

中国知网 https://www.cnki.net

Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA:IEEE,2016: 5657–5665.

[31] 张润初, 杜倩云, 俞祝良等. 一种利用参考图象与路面信息的道路监控摄像机标定方法[J]. 公路交通科技, 2014, 31(11): 137–141.

[32] Diaz, Juan Carlos Tocino, Quentin Houben et al. A Camera Auto-calibration Algorithm for Realtime Road Traffic Analysis[C]//Proceedings of the Fourth International Conference on Computer Vision Theory and Applications. Lisboa, Portugal:SciTePress - Science and and Technology Publications,2009: 626–631.

[33] Zhang Z, Tan T, Huang K, Wang Y. Practical camera calibration from moving objects for traffic scene surveillance[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2013, 23(3): 518–533.

[34] Wan Y, Huang Y, Buckles B. Camera calibration and vehicle tracking: highway traffic video analytics[J]. Transportation Research Part C Emerging Technologies, 2014, 44: 202–213.

[35] Dubska M, Herout A, Juranek R, Sochor J. Fully automatic roadside camera calibration for traffic surveillance[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 16(3): 1162–1171.

[36] Dawson D N, Birchfield S T. An Energy Minimization Approach to Automatic Traffic Camera Calibration[J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(3): 1095–1108.

[37] Fuhr G, Jung C R. Camera Self-Calibration Based on Nonlinear Optimization and Applications in Surveillance Systems[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2017, 27(5): 1132–1142.

[38] Borji A. Vanishing point detection with convolutional neural networks[A]. arXiv preprint arXiv:,1609.00967, 2016.

[39] Yang L, Luo P, Loy C C, Tang X. A large-scale car dataset for fine-grained categorization and verification[C]//2015 IEEE Conference on Computer

中国知网 https://www.cnki.net

Vision and Pattern Recognition (CVPR). Boston, MA, USA:IEEE,2015: 3973–3981.

[40] Chang C-K, Zhao J, Itti L. DeepVP: deep learning for vanishing point detection on 1 million street view images[C]//2018 IEEE International Conference on Robotics and Automation (ICRA). Brisbane, QLD: IEEE, 2018: 4496–4503.

[41] Zhang W, Song H, Liu L. Automatic calibration for monocular cameras in highway scenes via vehicle vanishing point detection[J]. Journal of Transportation Engineering, Part A: Systems, 2023, 149(7): 4023050.

[42] Phan S H, Pham L H, Tran D N-N, Jeon J W. Automatic Method of Camera Calibration for The Traffic Surveillance[C]//2022 IEEE International Conference on Consumer Electronics-Asia (ICCE-Asia). Yeosu, Korea, Republic of:IEEE,2022: 1–4.

[43] Sochor J, Juránek R, Herout A. Traffic surveillance camera calibration by 3D model bounding box alignment for accurate vehicle speed measurement[J]. Computer Vision and Image Understanding, 2017, 161: 87–98.

[44] Sochor J, Juránek R, Špaňhel J, Maršík L, Široký A, Herout A, Zemčík P. Comprehensive data set for automatic single camera visual speed measurement[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 20(5): 1633–1643.

[45] Howard A. Real-time stereo visual odometry for autonomous ground vehicles[C]//2008 IEEE/RSJ International Conference on Intelligent Robots and Systems. Nice:IEEE,2008: 3946–3952.

[46] Hold S, Nunn C, Kummert A, Muller-Schneiders S. Efficient and robust extrinsic camera calibration procedure for lane departure warning[C]// 2009 IEEE Intelligent Vehicles Symposium. Xi’an, China:IEEE,2009: 382–387.

[47] 武非凡, 宋焕生, 戴喆, 王伟. 交通监控场景下的相机标定与车辆速

中国知网 https://www.cnki.net

度测量[J]. 计算机应用研究, 2020, 37(8): 2417–2421.

[48] Rozsa Z, Golarits M, Sziranyi T. Immediate Vehicle Movement Estimation and 3D Reconstruction for Mono Cameras by Utilizing Epipolar Geometry and Direction Prior[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(12): 23548–23558.

[49] 杨澜, 郝茹茹, 王润民等. 一种车辆运动姿态参数的实时测量方法[J]. 中国科技论文, 2016, 11(19): 2155–2158.

[50] Jo K, Lee M, Sunwoo M. Road Slope Aided Vehicle Position Estimation System Based on Sensor Fusion of GPS and Automotive Onboard Sensors[J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 17(1): 250–263.

[51] 袁见, 刘福强, 安琨等. 基于交通波特征的车道级车流溯源方法[J]. 交通运输系统工程与信息, 2024, 24(01): 159–167.

[52] Zhao J, Ma R, Wang M. A behaviourally underpinned approach for two-dimensional vehicular trajectory reconstruction with constrained optimal control[J]. Transportation Research Part C: Emerging Technologies, 2024, 159: 104489.

[53] 王俊骅, 宋昊, 景强等. 基于毫米波雷达组群的全域车辆轨迹检测技术方法[J]. 中国公路学报, 2022, 35(12): 181–192.

[54] Li S, Yan Z, Li H, Cheng K-T. Exploring Intermediate Representation for Monocular Vehicle Pose Estimation[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA:IEEE,2021: 1873–1883.

[55] Wang S, Wang H, Zhou Y, Liu J, Dai P, Du X, Abdel Wahab M. Automatic laser profile recognition and fast tracking for structured light measurement using deep learning and template matching[J]. Measurement, 2021, 169: 108362.

[56] 黄士琛, 邵春福, 李娟等. 基于深度学习的车辆轨迹重建与异常轨迹识别[J]. 交通运输系统工程与信息, 2021, 21(3): 47–54.

中国知网 https://www.cnki.net

[57] Liu X, Wang Y, Jiang K, Zhou Z, Nam K, Yin C. Interactive Trajectory Prediction Using a Driving Risk Map-Integrated Deep Learning Method for Surrounding Vehicles on Highways[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(10): 19076–19087.

[58] Wojke N, Bewley A, Paulus D. Simple Online and Realtime Tracking with a Deep Association Metric [C]//2017 IEEE International Conference on Image Processing (ICIP). Beijing: IEEE, 2017: 3621-3625.

[59] Zhonglin T, Wahab M N A, Akbar M F, Mohamed A S A, Noor M H M, Rosdi B A. SFFSORT Multi-Object Tracking by Shallow Feature Fusion for Vehicle Counting[J]. IEEE Access, 2023, 11: 76827–76841.

[60] Ansaripour A, Heydariaan M, Gnawali O, Kim K. ViPER: Vehicle Pose Estimation using Ultra-WideBand Radios[C]//2020 16th International Conference on Distributed Computing in Sensor Systems (DCOSS). Marina del Rey, CA, USA:IEEE,2020: 120–127.

[61] Chen X, Yin J, Tang K, Tian Y, Sun J. Vehicle Trajectory Reconstruction at Signalized Intersections Under Connected and Automated Vehicle Environment[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(10): 17986–18000.

[62] Song J, Sun Y, Dong Q, Ji X. A parameter adaptive trajectory tracking and motion control framework for autonomous vehicle[A]. arXiv preprint arXiv:2411.17745, 2024.

[63] Su G, Zeng Z, Song A, Zhao C, Shen F, Yuan L, Li X. A General Framework for Reconstructing Full-Sample Continuous Vehicle Trajectories Using Roadside Sensing Data[J]. Applied Sciences, 2023, 13(5): 3141.

[64] Bewley A, Ge Z, Ott L, Ramos F, Upcroft B. Simple Online and Realtime Tracking[C]//2016 IEEE International Conference on Image Processing (ICIP). Phoenix, Arizona, USA: IEEE, 2016: 3464-3468.

[65] 苟铃滔，宋焕生，张朝阳等. 融合时空特征的隧道场景跨相机车辆

中国知网 https://www.cnki.net

实时跟踪方法[J]. 计算机工程与应用, 2023, 59(24): 88–97.

[66] 陈瑞东, 秦会斌. 多特征融合与卡尔曼预测的车辆跟踪算法[J]. 电子测量技术, 2023, 46(7): 32–38.

[67] 宋秀兰, 董兆航, 单杭冠等. 基于时空融合的多头注意力车辆轨迹预测[J]. 浙江大学学报(工学版), 2023, 57(8): 1636–1643.

[68] Jiao Y, Jie Z, Chen S, Chen J, Ma L, Jiang Y-G. MSMDFusion: Fusing LiDAR and Camera at Multiple Scales with Multi-Depth Seeds for 3D Object Detection [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, Canada: IEEE, 2023: 10205088.

[69] Alam A, Jaffery Z, Sharma H. A cost-effective computer vision-based vehicle detection system[J]. Concurrent Engineering, 2022, 30: 1063293X2110691.

[70] Saikia H, Weinkauf T. Global Feature Tracking and Similarity Estimation in Time-Dependent Scalar Fields[J]. Computer Graphics Forum, 2017, 36(3): 1–11.

[71] 张文涛. 高速公路场景下相机自动标定及Frenet坐标系自动建立[D]. 西安:长安大学,2023.

[72] Tsai R. A versatile camera calibration technique for high-accuracy 3D machine vision metrology using off-the-shelf TV cameras and lenses[J]. IEEE Journal on Robotics and Automation, 1987, 3(4): 323–344.

[73] Hallert B. The method of least squares applied to multicollimator camera calibration[J], Photogrammetric Engineering, 2017, 836-840.

[74] Pollefeys M, Koch R, Gool L V. Self-calibration and metric reconstruction in spite of varying and unknown intrinsic camera parameters[J] . International Journal of Computer Vision, 1997, 22(1): 1-10.

[75] 张永军, 张祖勋, 张剑清. 利用二维 dlt 及光束法平差进行数字摄像机标定[J]. 武汉大学学报(信息科学版), 2002(6): 566–571.

[76] Hartley R I. Projective reconstruction and invariants from multiple

中国知网 https://www.cnki.net

images[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1994, 16(10): 1036–1041.

[77] Gong Y, Meng D, Seibel E J. Bound constrained bundle adjustment for reliable 3D reconstruction[J]. Optics Express, 2015, 23(8): 10771.

[78] Triggs B. Autocalibration and the absolute quadric[C]//Proceedings of IEEE Computer Society Conference on Computer Vision and Pattern Recognition. San Juan, Puerto Rico:IEEE Comput. Soc,1997: 609–614.

[79] 林钰莹, 侯新民. 基于局部密度峰和标签传播的最小生成树聚类[J]. 计算机系统应用, 2024, 33(8): 18–29.

[80] Geneva P, Maley J, Huang G. An efficient schmidt-EKF for 3D visual-inertial SLAM[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Long Beach, CA, USA:IEEE,2019: 12097–12107.

[81] Wang Y, Papageorgiou M. Real-time freeway traffic state estimation based on extended kalman filter: a general approach[J]. Transportation Research Part B: Methodological, 2005, 39(2): 141–167.

中国知网 https://www.cnki.net