武漢工程大學

Wuhan Institute of Technology

硕士学位论文

面向光伏板巡检系统的光伏组串精准检测与定位方法研究

类别/领域：控制工程

研 究 生： 李博璘

指导教师： 洪汉玉 教授

培养单位： 电气信息学院

二 〇 二 五 年 四 月

中国知网 https://www.cnki.net

分类号：TP751　　学校代号：10490

学　号：22203010108　　密　　级：公开

武汉工程大学硕士学位论文

面向光伏板巡检系统的光伏组串精准检测与定位方法研究

作者姓名：李博璘　　指导教师姓名、职称：洪汉玉 教授

申请学位类别：电子信息硕士　　专业学位类别名称：控制工程

研究方向：电力巡检

论文提交日期：2025 年 4 月 2 日 论文答辩日期：2025 年 5 月 27 日

学位授予单位：武汉工程大学　　学位授予日期：2025 年 6 月 20 日

答辩委员会主席：　桑农　

中国知网　https://www.cnki.net

Research on Precise Detection and Localization Methods for PV Arrays in Photovoltaic Panel Inspection Systems

A Thesis Submitted for the Degree of Master

Major: Control Engineering

Candidate: Lee Bolin

Supervisor: Prof. Hong Han Yu

Wuhan Institute of Technology

Wuhan, Hubei 430073, P. R. China

中国知网 https://www.cnki.net

摘 要

近几十年来，随着经济的发展和碳排放水平的上升，大力推动节能工作，助力实现碳达峰中和成为现在政府重点关注的话题，光伏发电因其清洁、可持续的特性成为能源转型的重要方向。大规模光伏电站多分布于偏远地区，因长期放置在外面临各种气候变化，容易发生故障，对此定期的对光伏板故障区域进行检测保障电力输送的可靠稳定至关重要。基于图像的光伏板巡检已经成为光伏发电的重要工作之一，由于光伏组串重复模式较多，规格不一，用传统模板匹配或者模型训练的方式容易造成误检测。为此本文以此为背景针对无人机光伏巡检展开了光伏组串识别与定位研究，主要工作包括：

（1）介绍了光伏巡检的研究背景及意义，分析了当前目标识别技术的发展现状以及光伏电站巡检的挑战。随后针对光伏巡检数据采集问题，详细阐述了光伏组串的红外成像特性，并研究了无人机轨迹导航优化方法，同时针对红外图像噪声多、对比度低的问题，系统分析了均值滤波、中值滤波、高斯滤波及双边滤波的效果与特点，随后提出基于选择增强的 HSV 颜色空间优化方法，显著提升光伏组串与背景的辐射差异。

（2）在光伏组串检测与分割方面，本文研究了传统图像处理方法在光伏图像上的适用性，并基于灰度曲线的自适应 B 样条最小二乘拟合法对组串进行检测分割。此外，本文通过自主标记的样本增强后，采用 YOLOv8 深度学习模型对光伏组串进行检测，并对比分析了不同方法的性能以及优缺点。

（3）针对静态单张红外图像的光伏组串检测，本文首先提出了一种基于改进霍夫变换的旋转校正方法，通过改进的统计概率霍夫直线检测算法提取光伏栅线，结合共线性概率分析实现倾斜校正。随后利用选择增强的 HSV 颜色空间对图像处理并自适应分割，然后通过角点检测的光伏组件变换矫正与高斯核密度估计的 K-means 聚类，优化了聚类数与初始聚类中心选择，使准确率相比传统 K-means 算法和其他算法有着明显提高。

（4）针对巡检过程中单张图片拍摄时间过长的问题，本文基于视频运动信息，

中国知网 https://www.cnki.net

实验对比不同抽帧策略，分析了传统方案在光伏视频巡检中的不足并以此提出优化的光伏组串动态帧提取，通过对冗余帧筛选后利用光伏组串中心偏移量最小化确定最佳帧。并用改进的光流法，通过引入惯性补偿因子与权重函数实现运动轨迹方向的判定，进一步优化光伏板相对位置实现设备定位。

关键词：光伏巡检；无人机；光伏检测；K-means 聚类；光伏定位

中国知网 https://www.cnki.net

Abstract

In recent decades, with economic development and the rise in carbon emissions, promoting energy conservation and achieving carbon peaking and neutrality have become key priorities for governments. Due to its clean and sustainable characteristics, photovoltaic (PV) power generation has emerged as a crucial direction in energy transition. Large-scale PV power stations are typically located in remote areas, where they are exposed to various climatic changes, making them susceptible to failures. Therefore, regular inspection of faulty PV panel areas is essential to ensure stable and reliable power transmission. Image-based PV panel inspection has become a vital aspect of PV power generation. However, due to the high repetition patterns and varying specifications of PV arrays, traditional template matching or model training approaches often result in misdetections. Against this backdrop, this study focuses on UAV-based PV inspection, specifically investigating PV array recognition and localization. The primary contributions of this research include:

(1) It introduces the research background and significance of PV inspection, analyzes the current development status of target recognition technology and the challenges of PV power plant inspection. Subsequently, for the problem of PV inspection data acquisition, the infrared imaging characteristics of PV strings are elaborated in detail, and the optimization method of UAV trajectory navigation is studied. At the same time, for the problem of infrared image with much noise and low contrast, the effects and characteristics of mean filtering, median filtering, Gaussian filtering, and bilateral filtering are analyzed in a systematic way, and the HSV color space optimization method based on selective enhancement is then proposed, which can significantly improve the PV string's radiation difference with the background.

(2) In terms of PV string detection and segmentation, this paper investigates the applicability of traditional image processing methods on PV images, and detects and

中国知网 https://www.cnki.net

segments the strings based on adaptive B-spline least squares fitting of gray curves. In addition, this paper adopts YOLOv8 deep learning model to detect PV strings after enhanced by self-labeled samples, and compares and analyzes the performance as well as the advantages and disadvantages of different methods.

(3) For PV string detection of static single infrared images, this paper firstly proposes a rotation correction method based on improved Hough transform, which extracts PV gridlines by improved statistical probabilistic Hough straight line detection algorithm, and combines with covariance probability analysis to realize tilt correction. Subsequently, the image is processed and adaptively segmented using a selection of enhanced HSV color space, and then K-means clustering with Gaussian kernel density estimation through PV module transform correction for corner point detection optimizes the number of clusters and the initial clustering center selection, which results in a significant improvement in accuracy compared to the traditional K-means algorithm and other algorithms.

(4) For the inspection process of single picture shooting time is too long, this paper based on the video motion information, experimental comparison of different frame extraction strategy, analysis of the traditional scheme in the photovoltaic video inspection deficiencies and thus put forward optimized photovoltaic string dynamic frame extraction, through the use of redundant frames filtered by the photovoltaic string after the center of the string to minimize the offset to determine the best frame. And with the improved optical flow method, by introducing the inertia compensation factor and weight function to achieve the determination of the direction of the motion trajectory, and further optimize the relative position of the PV panels to achieve equipment positioning.

Keywords: Photovoltaic inspection; UAV; Photovoltaic detection; K-means clustering; Photovoltaic positioning

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 目标识别技术研究现状.....2
1.2.2 光伏电站无人机巡检研究现状.....5
1.3 研究内容与章节安排.....6
第 2 章 光伏巡检中数据采集与巡检方法.....9
2.1 光伏组串红外成像.....9
2.1.1 光伏组串工作原理.....9
2.1.2 红外成像原理.....9
2.1.3 光伏红外图像特性分析.....10
2.2 光伏巡检项目概况.....11
2.2.1 研究区域概况.....11
2.2.2 无人机与相机介绍.....12
2.3 无人机轨迹导航与设计.....14
2.3.1 无人机位置偏差测定.....14
2.3.2 路径跟随策略.....15
2.3.3 边界转向机制.....16
2.4 本章小结.....17
第 3 章 基于红外图像光伏组串检测分割研究.....19
3.1 光伏组串预处理研究.....19
3.1.1 光伏图像滤波去噪研究.....19
3.1.2 光伏图像增强研究.....24
3.1.3 光伏图像矫正研究.....29
3.2 传统的光伏组串检测分割方法.....31
3.3 基于 YOLOv8 模型的光伏组串检测算法.....35
3.3.1 光伏数据集的采集获取.....35
3.3.2 光伏数据集增强与标注.....36
3.3.3 YOLOv8 模型概述.....37
3.3.4 实验环境与训练参数设置.....39
3.4 实验结果及分析.....39
3.4.1 评价指标.....39
3.4.2 实验结果分析.....40
3.5 本章小结.....42

中国知网 https://www.cnki.net

第 4 章 基于静态单张的红外光伏组串检测方法 43
4.1 基于改进霍夫提线算法的光伏组串旋转处理 43
4.2 K-means 算法描述 47
4.3 改进的 K-means 光伏分割 48
4.3.1 图像去噪处理 49
4.3.2 基于选择增强的图象色彩空间的光伏组串处理 50
4.3.3 基于自适应阈值分割的光伏组串处理 54
4.3.4 基于角点检测的光伏组件变换矫正 55
4.3.5 初始聚类中心及 K 值的确定 56
4.4 实验结果与分析 60
4.5 本章小结 62
第 5 章 基于视频运动信息的光伏组串检测定位 63
5.1 无人机关键帧提取分析 63
5.1.1 基于镜头边界的关键帧提取 64
5.1.2 基于运动信息的关键帧提取 64
5.1.3 基于聚类的关键帧提取 65
5.1.4 基于无人机速度与视频帧率的动态设置抽帧方案 65
5.1.5 评价指标与实验分析 66
5.2 优化的光伏组串动态关键帧提取 69
5.2.1 冗余帧筛选方法 69
5.2.2 基于光伏组串中心偏移量的最佳帧判定 71
5.3 改进的光流法与光伏组串设备定位 74
5.4 本章小结 79
第 6 章 总结与展望 81
6.1 工作总结 81
6.2 研究展望 82
参考文献 83

中国知网 https://www.cnki.net

第 1 章绪论

1.1 研究背景与意义

随着社会的发展，人们对能源的需求日益增加，传统化石能源储量正迅速减少，节能减排与新能源开发成为当前解决能源危机和环境污染的关键途径，而光伏发电作为一种重要的清洁可再生能源，正在成为全球新能源领域的重要研究方向。坚持研发节能新技术、提升光伏发电效率，以及加快光伏电站的智能化管理，已经成为促进绿色科技创新和实现可持续发展的重要任务，同时也是必然趋势[1]。

在中国“双碳”战略目标的引领下，光伏发电行业迎来了快速发展的黄金期。根据中研普华研究院发布的《2024-2029 年中国光伏发电行业市场全景调研与发展前景预测报告》显示，2024 年上半年，全国新增光伏装机容量已达 1.02 亿千瓦，同比增长了 31%[2]。光伏行业在国家清洁能源转型中的重要地位正在不断增强，我国已然成为光伏装机全球最多的国家[3]。截至 2024 年 6 月底，全国光伏发电的总装机容量已经达到了 7.13 亿千瓦，相较于去年增长了 52%。由图 1-1 可知，光伏发电在中国能源结构中的比例正在稳步上升，且有望在未来进一步扩大。光伏发电正逐步成为中国能源供应的重要组成部分，为我国实现碳达峰、碳中和目标做出了积极贡献[4,5]。

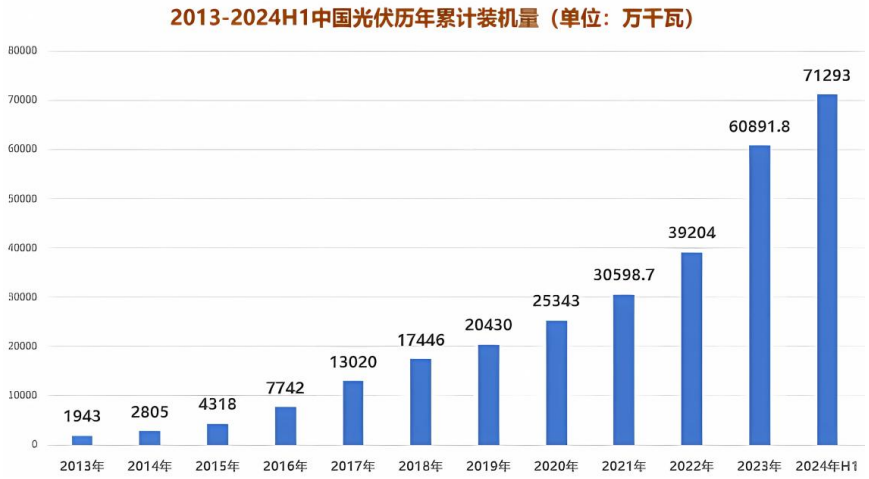


图 1-1 中国光伏理念累计装机量

中国知网 https://www.cnki.net

光伏电站是实现新能源利用的关键设施，但其光伏组件与配套设备长期处于自然环境中，易受气候变化与污染沉积等影响，致使设备故障频发，发电性能也随之减退。传统的光伏巡检以人力为主[6]，但其巡检效率低、问题定位不准、运维成本高等问题日益凸显[7]，尤其是在大规模光伏电站和复杂地形区域。因此通过无人机技术手段来优化光伏巡检方式，提升巡检效率，对保障光伏电站稳定运行具有重要作用[8]，已成为当前绿色能源技术创新的重点方向。

在节能减排和绿色科技创新的趋势下，无人机光伏巡检技术的研究和应用显得尤为重要。结合无人机巡检、红外成像监测等技术，可以大幅提升设备运维效率。无人机光伏巡检技术的引入，不仅有助于降低传统运维的人工成本和安全风险，还能推动光伏电站向智能化、绿色化发展，为全球节能减排目标的实现以及应对气候变化产生积极的推动作用，对光伏基础设施运营和安全建设具有重要意义[9]。

1.2 国内外研究现状

无人机光伏巡检是一种将无人机技术应用于新能源领域的创新方式，其光伏巡检系统通常由无人机和地面站两部分组成，能够实现光伏电站高效巡检。早在 2014 年就有研究将此类技术应用于配电网的巡检任务[10]，并取得了良好的效果。在后来的无人机光伏巡检领域中，相关研究也取得了多方面的成果。在无人机路径规划算法方面展开的研究[11-14]，以及在光伏组件故障识别与缺陷分析领域[15-18]的深入探索，使得无人机光伏巡检日趋成熟。

1.2.1 目标识别技术研究现状

目标识别技术主要涵盖图像识别相关方法，根据当前技术的发展趋势，可以将目标识别大致划分为两大研究路线：传统图像处理方法和深度学习的处理方法[19]。这两种技术路径在发展历程和应用场景上各具特色。

中国知网 https://www.cnki.net

在传统图像处理领域，目标识别技术的研究历史悠久，传统图像处理方法主要依赖手动设计特征和经典机器学习算法，分析目标的几何形状、颜色、纹理等信息来完成目标检测和分类任务。艾明伟通过结合边缘跟踪技术与小区域剔除的方法，对传统的 Canny 算子进行了优化改进，使其在车辆检测任务中具备了更高的鲁棒性，改进后的方法能够有效提高目标车辆的分割精度，即使在复杂背景下也能保持较好的性能表现[20]。Juan Andrade 等研究者提出了一种创新的云天空分割方法，利用云形成条件对阈值进行自适应调整，实现更加准确的云层与天空区域的分离[21]。目标识别通常理解为目标检测，传统的目标检测通过 SIFT[22]、HOG[23]等特征算子对图像提取特征，随后运用支持向量机 SVM 以及 Adaboost 等机器学习算法进行分类检测，常见的有 VJ 检测器[24,25]与 DPM[26-30]。实际运用中，叶俊杰等人提出了一种结合边缘特征圆形检测与 HOG-SVM 分类器的变电站电力屏柜锁孔图像快速检测方法。通过对实时采集的图像进行预处理，有效降低计算复杂度；在此基础上利用边缘特征构建判定条件，实现对圆形的高效检测[31]。孙可等人提出了一种基于 HSI 空间转换和自适应融合改进的 DPM，用于高效车辆目标检测[32]。王雪娇等人提出了一种融合改进的可变形卷积网络（DCN）和可变形部件模型（DPM）的人体动作识别系统，通过优化部件滤波器、兴趣点采样及融合设计显著提升了识别精度和速度[33]。

随着深度学习技术与人工智能技术的快速发展，卷积神经网络（CNN）和深度神经网络（DNN）已经成为计算机视觉领域的重要基础结构，并在各类视觉任务中被广泛应用，已成为计算机视觉常用结构[34]。图 1-2 为深度学习目标检测的历史发展图。基于深度学习的目标检测大致上由输入层、隐藏层、输出层对图像特征进行提取，相比一般传统算法来说其有着更深的层次结构，能够从数据中提取更为抽象和高层次的特征，更好地表征目标对象的特性。深度神经网络通过对算法的预调节和充分训练，能够有效减少分类错误，提高模型的预测精度，实现对目标物体的精准识别，尤其是在面对高维数据和多样化目标时，能够更全面地捕捉数据的潜在规律和特征。

中国知网 https://www.cnki.net

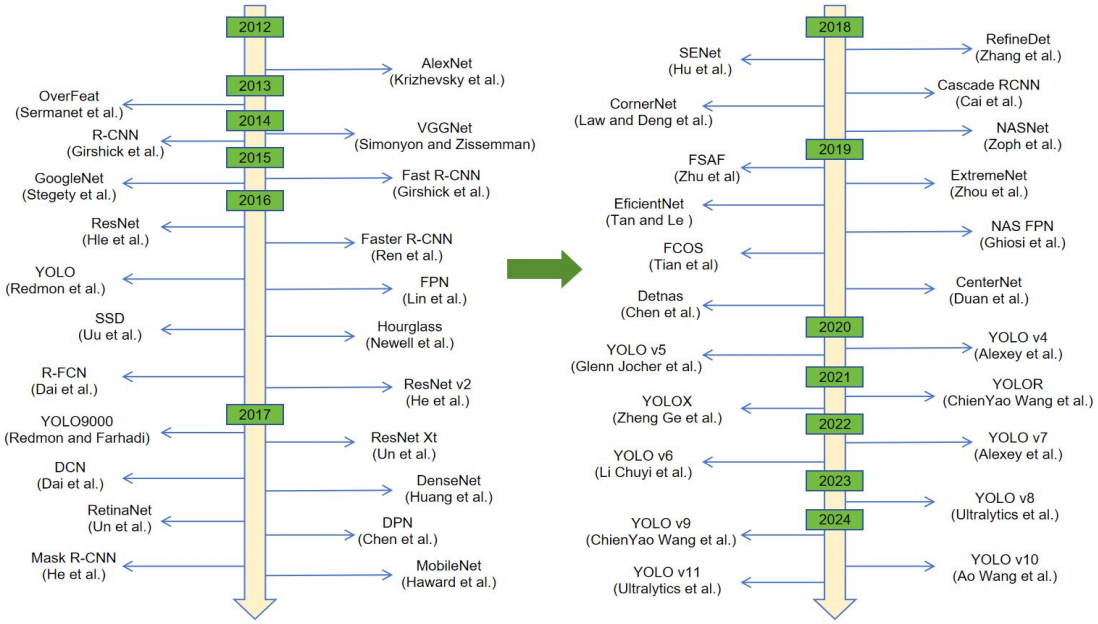


图 1-2 深度学习目标检测的历史发展

当前，目标检测领域的主流方法可以分为两大类：单阶段目标检测（One-stage）和双阶段目标检测（Two-stage）。

常见的双阶段目标检测有 R-CNN、Fast R-CNN、Faster R-CNN 等，通过先生成候选框，再利用卷积神经网络对其进行分类和位置优化，具有高精度和准确定位的优势，但检测速度相对较慢。

常见的单阶段目标检测有 YOLO 系列与 SSD 等，对于双阶段的目标检测来说单阶段目标检测速度更快，计算效率更高。单阶段方法省去了候选框生成的步骤，直接在输入图像上完成目标分类和定位任务，极大地简化了检测流程。此外其模型结构通常更紧凑，计算资源占用较少，基于深度学习的目标检测基本流程如下图所示。

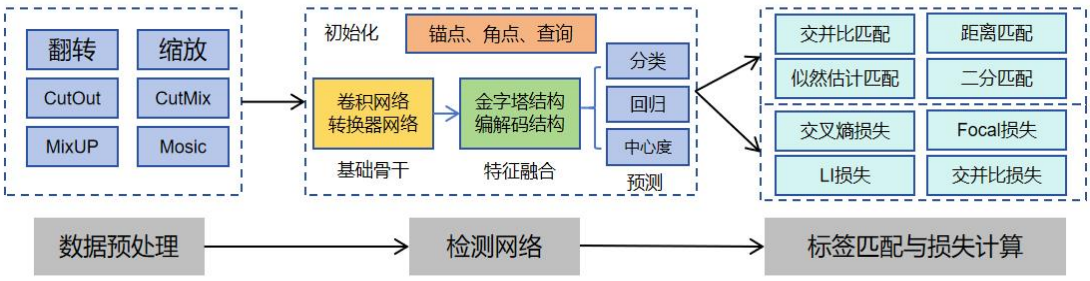


图 1-3 基于深度学习目标检测的训练过程

中国知网 https://www.cnki.net

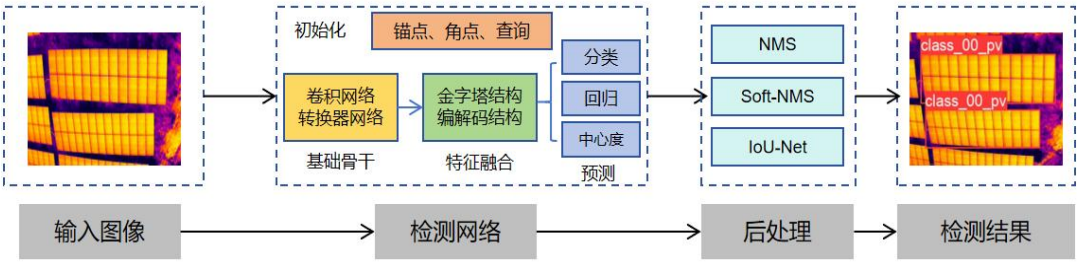


图 1-4 基于深度学习目标检测的测试过程

目前 YOLO 检测发展迅速，已广泛用于目标检测领域，YOLOv1[35]开创了单阶段目标检测的先驱，邓力等人提出一种结合改进损失函数的 YOLO 目标检测算法，通过设计综合考虑目标中心点距离、重叠面积和长宽比的改进损失函数，并引入基于动态非单调聚焦机制的 WIoU 函数，提升了红外火焰图像检测的准确率[36]。王兴家等人提出了一种基于改进 YOLOv8n-seg 的群猪实例分割模型，通过引入 GhostConv 至 C2f 模块中降低计算复杂度，结合空间分组增强、内卷和多维协作注意力机制提升特征提取能力，并采用 WIoU 损失函数加速收敛和提高整体性能[37]，在 2024 年 Ultralytics 在其活动 YOLOVision 中正式发布了最新的 YOLOv11[38]，YOLOv11 采用改进的主干和颈部架构，增强了特征提取能力，以实现更精确的目标检测和复杂任务性能。

1.2.2 光伏电站无人机巡检研究现状

目前无人机技术的快速发展，旋翼无人机因其飞行速度快、稳定性高、载重能力强以及经济性等特点，已在大规模巡检中得到广泛应用。在光伏电站巡检中，四旋翼无人机具备更高的稳定性和更强的设备搭载能力，在绝大部分的应用场景中能够取代传统人工巡检方式，大幅提高效率并显著缩短巡检时间。

近年来，无人机在光伏巡检领域取得了诸多成果，夏德喜[39]设计了一套无人机光伏组件故障识别系统，有效提升了巡检效率并缩短了工作周期，邢发男[40]针对无人机电网巡检中的单 MEC 和多 MEC-WPT 场景，提出了基于深度强化学习的改进 DDPG 算法 IAESDDPG 和 IPERDDPG，通过任务卸载与充电调度协同优化，显著提高了任务处理效率、系统能

中国知网 https://www.cnki.net

耗和剩余能量，且在仿真中优于传统基线算法。姚瑛等人[41]提出了一种结合注意力机制目标检测算法与无人机技术的光伏板巡检方案，利用高分辨率图像采集与智能检测，有效提升了巡检效率与缺陷检测准确性。吴张宇等人[42]针对大规模光伏电站巡检问题，提出基于 K-means 聚类与精英蚁群算法（ACO）的无人机路径规划方法，通过区域划分与优化路径设计，减少巡检路径长度和能耗，提高巡检效率。

在光伏故障检测领域，2021 年，栾艳军[43]提出了一种将改进的 Otsu_Iteration_Canny 算法与航拍红外图像相结合的光伏阵列故障检测方法。作者通过优化 Otsu_Iteration_Canny 算法，更高效地处理航拍红外图像中的信息，实现对光伏组件故障区域与周围环境的精准分割。2022 年，李鑫林[44]提出了一种结合生成对抗网络与图像重构技术的热斑故障检测方法。作者通过利用生成对抗网络（GAN）生成高质量的重构图像，实现了对光伏红外图像中热斑故障的精准检测，同时引入自注意力机制来捕捉光伏红外图像中特征点之间的关联性，进一步优化模型的特征表达能力和对热斑区域的识别精度。2023 年，焦思韬[45]提出了一种改进的 SSD 检测算法，通过使用嵌入 ECA 注意力机制的 ResNet50 模块替代 VGG-16，并引入 FocalLoss 损失函数，有效提升了光伏板表面缺陷检测的速度与精度。2024 年，兰金江[46]结合 Unet 模型与传统图像处理算法，提出了一种改进的光伏缺陷检测方法，通过优化模型结构与传统算法相结合，有效提升了光伏缺陷检测的准确率。

1.3 研究内容与章节安排

本文基于无人机光伏巡检，围绕大型光伏电站巡检展开研究，主要研究了基于巡检图像光伏组串检测与定位的相关技术与方法。本文主要研究内容如下：

（1）针对红外图像中背景干扰和对比度不明显等问题，本文对比分析多种传统图像处理方法，实现了图像去噪、增强和校正等预处理，为后续的光伏组串检测提供了良好的基础。

（2）针对光伏系统中光伏区域识别问题，本文对比了深度学习算法

中国知网 https://www.cnki.net

和传统图像处理方法在光伏组串识别中的表现与特点，分析了在该行业背景下，深度神经网络与传统方法的优缺点。

（3）针对静态红外图像的光伏组串检测，本文通过改进的提线算法以实现倾斜校正，接着利用增强的 HSV 颜色空间对图像处理并自适应分割，然后基于角点检测进行光伏组件变换矫正，采用高斯核密度估计的 K-means 聚类，优化聚类数与初始聚类中心选择，提高检测准确率。

（4）针对动态视频，本文对各种抽帧策略进行了对比与实验，分析了诸多方法存在的问题，并以此提出了优化的冗余帧筛选和最佳帧判定方法，能够在巡检视频中选取最能代表光伏组串的最佳帧，并有效去除冗余数据。随后又通过改进的光流算法，实现了在最佳帧上的光伏组串的设备定位。

论文组织架构图如下所示：

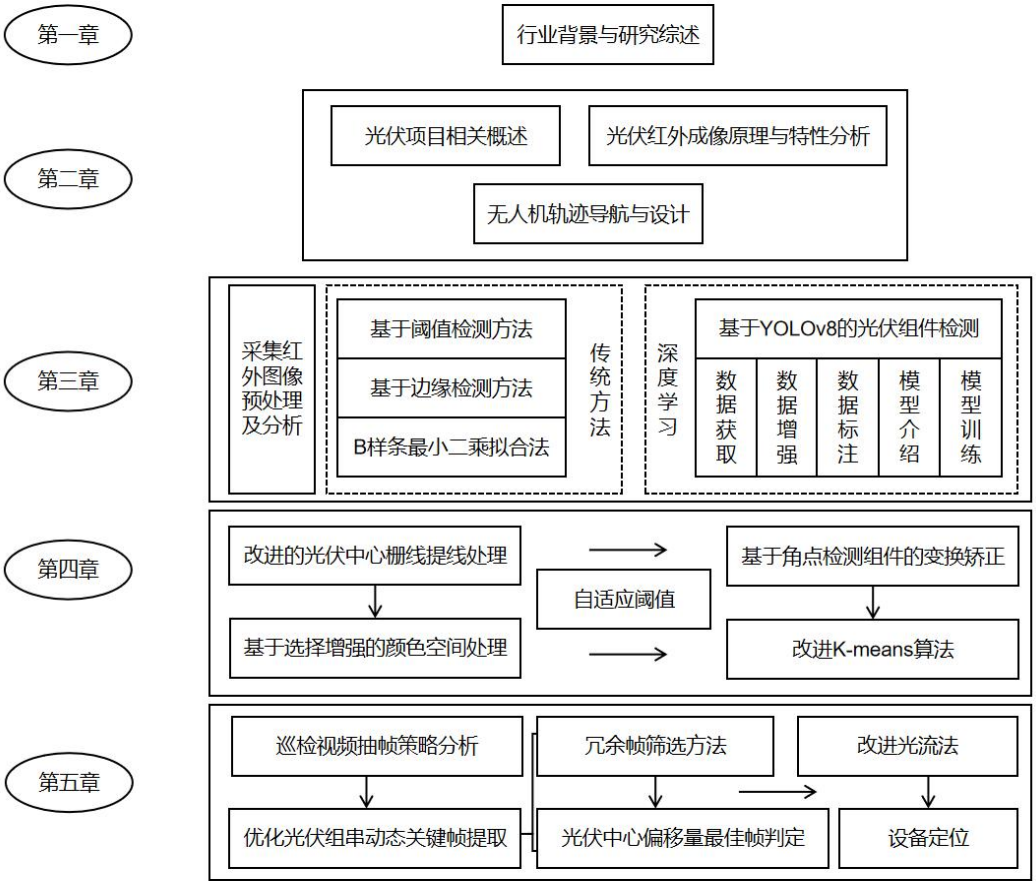


图 1-5 论文结构框架图

中国知网 https://www.cnki.net

论文章节安排如下：

第一章，绪论。本章主要介绍了光伏巡检的研究背景及意义，分析了目前目标识别技术以及光伏电站巡检现状，最后总结了本文的主要研究内容与文章的组织架构。

第二章，光伏巡检中数据采集与巡检方法。本章详细介绍了光伏组串工作原理以及光伏红外成像特性，并对项目概况以及无人机的轨迹导航设计做出相应的描述。

第三章，基于红外图像光伏组串检测分割研究。本章中对于采集的光伏组串红外图像，研究不同方法的图像去噪、增强和校正处理效果并做出总结。详细介绍了一些传统图像检测与分割方法运用在光伏图像上的效果，并基于灰度曲线的自适应 B 样条最小二乘拟合法在传统方法领域对光伏组串进行检测分割，同时运用 YOLOv8 深度学习模型对光伏组串进行检测，并对其结果进行分析对比。

第四章，基于静态单张的红外光伏组串检测方法。本章中利用基于改进霍夫提线算法的光伏组串旋转处理对光伏组串图首先进行预处理。随后利用选择增强的颜色空间对图像处理并自适应分割，并通过角点检测的光伏组件变换矫正与改进的 K-means 实现对光伏组串以及组串各个部件进行检测，并将结果与其他方法进行对比分析。

第五章，基于视频运动信息的光伏组串检测定位。本章对多种抽帧策略进行了比较和实验，借此提出本章中的优化方法，通过冗余帧筛选减少多余数据，利用光伏组串中心偏移量最小化方法选定最佳帧，最终结合改进的光流法与无人机的巡检航线实现精确定位和设备编号匹配。

第六章，总结与展望。对全文的工作内容进行总结，对本文不足之处进行了展望。

中国知网 https://www.cnki.net

第 2 章光伏巡检中数据采集与巡检方法

2.1 光伏组串红外成像

2.1.1 光伏组串工作原理

光伏组串工作原理基于光伏组件中光伏电池对光能的转化作用[47]。光伏电池由富含自由电子的 N 型半导体与富含正电荷空穴的 P 型半导体组合构成，当太阳光子照射到电池表面时，其能量被 N 型区的电子吸收，进而激发电子跃迁，形成电子-空穴对。在 PN 结内建电场的导向作用下，电子朝着 N 型区域移动聚集，同时空穴被驱使向 P 型区域汇聚，进而使得电池的两端产生电势差。当电路闭合时，电子在电路中流动形成电流，PN 结中载流子数量越多，通过太阳能所产生的电流也就越大[48-50]。在实际运用中为了提升输出电压，通常将多个光伏电池串联组成光伏组件，光伏组件进一步串联形成光伏组串。光伏电池中 PN 结原理示意图如下所示：

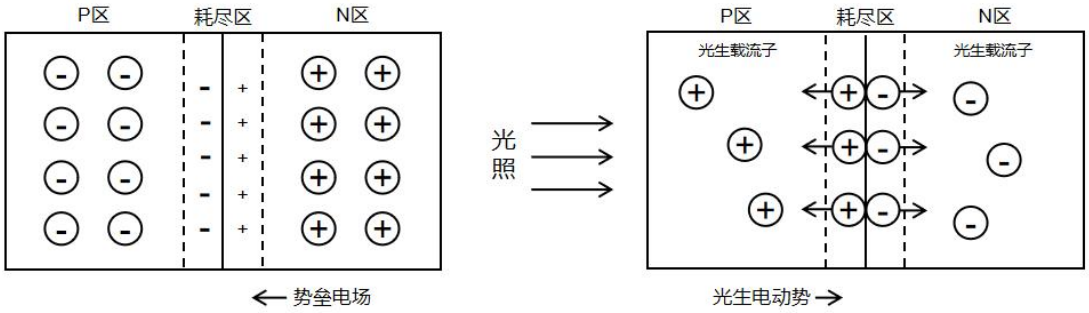


图 2-1 PN 结原理图

2.1.2 红外成像原理

红外辐射是一种电磁波，波长介于 0.76 微米至 1000 微米之间[51]。在自然界中，所有物体都会发出强度与频率各异、长短不一的红外辐射。然而，红外探测器的灵敏度和工作范围通常有限，能够捕捉的红外辐射仅局限于特定频谱范围内的红外辐射信号。图 2-2 为电磁波频谱图，其中

中国知网 https://www.cnki.net

红外根据波长不同可划分为近红外、短波、中波、长波红外和远红外五个波段。

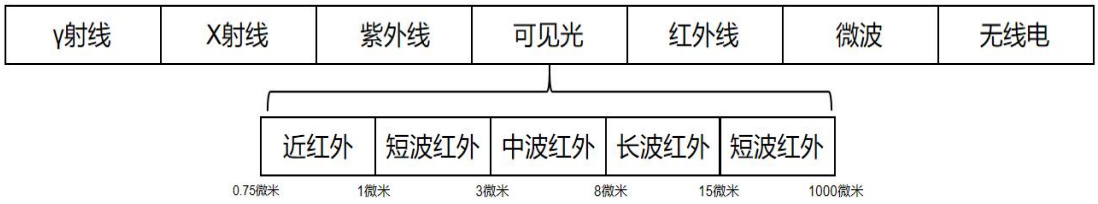


图 2-2 光电磁波频谱

物体的红外特性可以由红外热成像仪转换其相应的红外图像，红外热成像仪一般由四个部分组成，即红外光学系统、红外探测器、图像信号处理以及显示器，由图 2-3 所示。光伏组串巡检通过红外热成像仪形成光伏组串红外图的步骤如下所示：首先红外光学系统聚焦并捕获光伏组串表面发出的红外辐射；接着红外探测器将辐射信号转为电信号，随后图像信号处理单元对其放大、去噪和校准处理，将其映射为光伏组串的温度分布图；最后通过显示器将温度分布以伪彩色或灰度图像形式直观呈现。

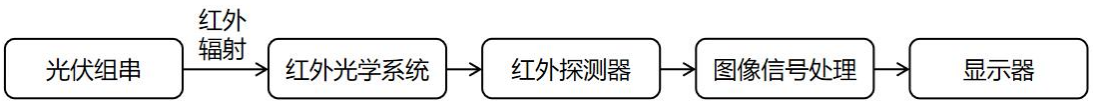


图 2-3 光伏红外图像转化过程

2.1.3 光伏红外图像特性分析

红外图像通过捕捉物体的热辐射特性，在光伏组串检测中展现出显著优势，通过红外图像的特性能够在复杂环境中清晰展现光伏组件区域与背景环境的差异，提供高对比度和清晰的目标信息。与可见光图像相比，红外图像不依赖光照条件进行成像，在弱光或无光环境下仍能捕捉到高质量的图片信息，能够清晰展现光伏组串的细节，而可见光图像在低光条件下则容易出现模糊或信息缺失，不利于进一步的处理。同时红外图像能够直观反映光伏组件表面的温度分布，在检测上一定程度能够减小背景环境的干扰。

中国知网 https://www.cnki.net

2.2 光伏巡检项目概况

2.2.1 研究区域概况

本文依托于云南雄里坡复合型光伏发电项目，其位置位于云南省祥云县普淜镇，地处普淜镇么底扎村附近坡地上，场址中心距离祥云县县城约 36 公里，地理坐标介于东经 100°48′16″至 100°49′37″、北纬 25°14′15″至 25°15′41″之间，海拔高程 1717 米至 2050 米。该地区地形以坡地为主，靠近普淜镇，交通较为便利，区域太阳能资源丰富。

本文研究区域为雄里坡复合型光伏项目所在地，如图所示，雄里坡复合型光伏项目总装机容量为 100MW，直流侧实际安装容量达 119.50848MWp。光伏发电系统由 32 个 3.73464MWp 的单晶硅光伏发电分系统组成。预计 25 年运行期内，项目累计上网电量达 408670 万 kWh，平均每年上网电量约为 16347 万 kWh，满负荷年均利用时长 1368 小时。

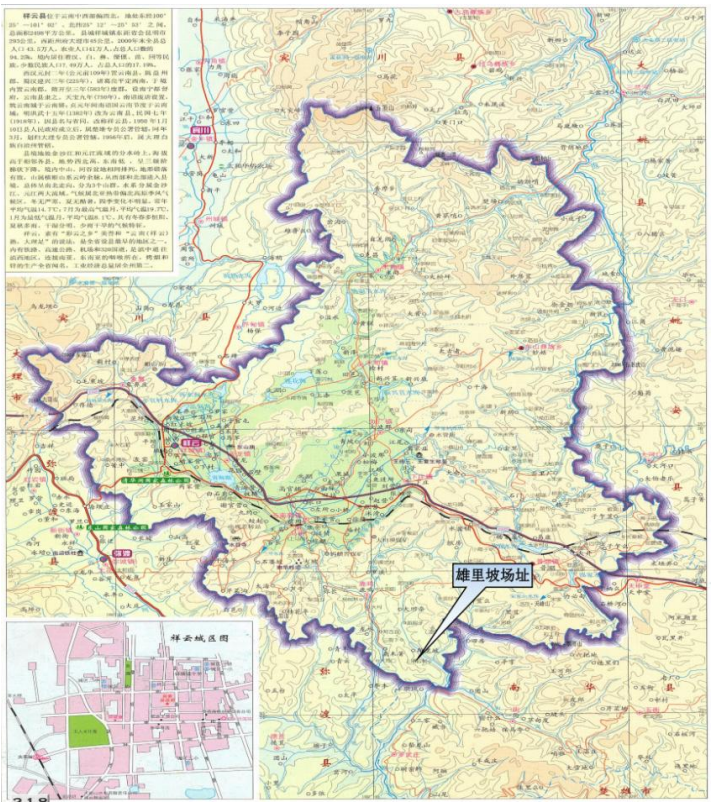


图 2-4 光伏场站地理位置

中国知网 https://www.cnki.net

2.2.2 无人机与相机介绍

随着无人机技术的迅猛发展，其在光伏组串巡检领域的应用日益广泛。无人机能够凭借其卓越的灵活性和适应性，不受地势环境的干扰，有效地应对光伏电站的复杂地形，借助高空视角实现对大面积区域的高效覆盖，显著提升巡检效率。与传统的人工巡检方式相比，无人机在采集光伏组串数据方面展现出更快的速度和更全面的覆盖范围。它能够搭载高分辨率相机，精准记录组串的运行状态和环境信息，为后续深入的数据分析提供必要条件。此外无人机操作便捷，具备灵活调度能力，可根据实际需求实现定点飞行或自动化巡检，满足不同场景下的作业要求。其系统构成如下图所示：

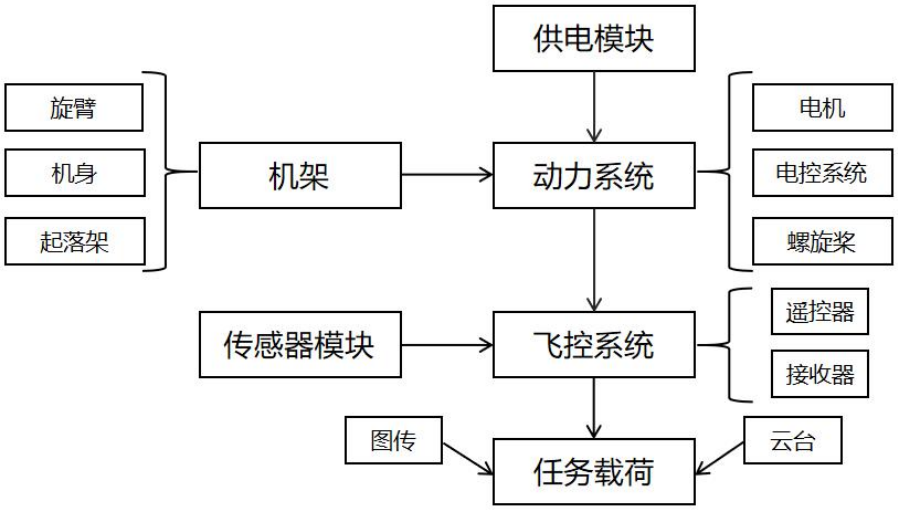


图 2-5 无人机系统构成

无人机主要由供电模块、动力系统、传感器飞控系统、任务载荷等构成，在本章中无人机数据采集采用大疆经纬 M300 无人机搭配禅思 H20T，如图 2-6 所示。与上一代 M200 无人机相比，大疆 M300 在多个性能指标上实现了显著提升，其图传距离达到了 15 公里，数据传输更加稳定且覆盖范围更广，能够满足更大规模区域的巡检需求。

中国知网 https://www.cnki.net



(a) 大疆经纬 M300 无人机



(b) 禅思 H20T 相机

图 2-6 采集无人机及相机型号

此外 M300 拥有 55 分钟的超长飞行时间和 50 公里的续航能力，大幅延长了单次作业时间，提高了巡检效率。在悬停精度方面，M300 的悬停误差可控制在 1.5 米以内，即便在复杂环境中也能保证稳定飞行。在巡检路径方面，得益于高精度 GPS 定位技术，M300 能够在巡检过程中准确遵循设定的飞行路径，从而避免偏移和遗漏区域。无人机以及相机具体参数如表 2-1 与表 2-2 所示。

表 2-1 M300 无人机参数

参数	指标
机身重量	3600g
最大载重	2700g
最大俯仰角	30°
最大飞行速度	23m/s
GPS 下悬停精度	垂直：0.5m，水平：1.5m
飞行时间	55min
续航里程	50km

表 2-2 H20T 相机参数

参数	指标
相机尺寸	167×135×161mm
相机重量	828±5g
DFOV	40.6°
分辨率	640×512
帧率	30fps
焦距	13.5mm
捕捉波长	8~14 微米

中国知网 https://www.cnki.net

2.3 无人机轨迹导航与设计

光伏电站巡检中，针对组件排列复杂、环境多变以及无人机路径与光伏组串实际位置可能偏移的问题，需对无人机的飞行控制进行如下设计：实时测定无人机与目标路径的距离和方向；动态调整飞行轨迹以确保沿组串中心线精准巡检；设计边界转向机制，在抵达区域边缘时候调整航向，平滑进入下一巡检区域。

2.3.1 无人机位置偏差测定

无人机导航的首要任务是计算其与光伏组串中心线的横向偏差量以及光伏组串的排列方向。通过图像处理算法（第四章中有详细介绍），提取光伏组串的中心栅线直线斜率 k，并结合视频帧中心点与直线的纵向像素偏移量，可以得到光伏组串在视频帧中的倾斜角：

$$\theta_3 = \arctan(k) \tag{2-1}$$

在无人机的导航坐标系中，光伏组串的排列方向可以表示为：

$$\theta = \theta_1 + \theta_2 + \theta_3 \tag{2-2}$$

其中，θ_1 为无人机的偏航角，θ_2 为云台的偏航角，其关系如图 2-7 所示可由无人机实时获取接下来，无人机与光伏组串中心线的偏移量 d_{err} 可以通过以下公式计算：

$$d_{\text{err}} = \frac{d}{h_i} \cdot H \cdot \tan\left(\frac{F}{2}\right) \cdot \cos(\theta_3) \tag{2-3}$$

式中，H 是无人机的飞行高度，h_i 是视频帧图像的高度，F 是摄像头的视场角。通过上述计算，无人机可以实时获取偏移量信息，为飞行路径调整提供依据。

中国知网 https://www.cnki.net

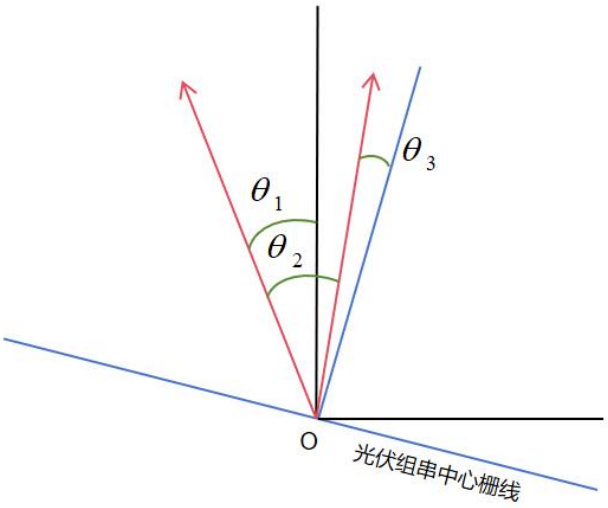


图 2-7 偏航角与倾斜角之间的关系

2.3.2 路径跟随策略

在光伏组串巡检任务中，无人机需要保持飞行路径与组串中心线一致，同时确保组串在视频帧中的上下边缘平行于图像的水平方向。为了实现这一目标，本文采用“视线导引法”[52]，原理如图 2-8 所示该方法通过选择虚拟预瞄点指导无人机飞行。

假设在光伏组串中心线上的投影距离为δ，则无人机的飞行方向始终指向预瞄点。无人机的云台角调整量可表示为:

$$\Delta\theta_2 = \theta_3 \tag{2-4}$$

为了调整无人机的飞行速度，基于视线导引法的速度控制公式为：

$$v_x = v_0 \cos\left(\theta + \frac{\pi}{2} - \arctan\left(\frac{d_{\text{err}}}{\delta}\right)\right) \tag{2-5}$$

$$v_y = v_0 \sin\left(\theta + \frac{\pi}{2} - \arctan\left(\frac{d_{\text{err}}}{\delta}\right)\right) \tag{2-6}$$

其中，v_0为无人机的巡航速度，d_{err}是偏移量，δ是预瞄距离。通过这种方式，无人机能够动态调整速度方向，确保持续跟踪光伏组串的中心线。

中国知网 https://www.cnki.net

为了验证上述控制策略的稳定性，定义李雅普诺夫函数 W：

$$W = \frac{d_{\text{err}}^2}{2} \tag{2-7}$$

根据图 2-8 的关系，可知其导数W'：

$$\begin{aligned} W' &= d_{\text{err}}(-v_0 \cos\varphi) = \\ & d_{\text{err}}[-v_0 \cos(\pi/2 - \arctan(d_{\text{err}}/\delta))]. \end{aligned} \tag{2-8}$$

根据奇偶性，可知其导数$W' < 0$可以证明该控制策略能够将偏移量 d_{err} 收敛至 0，确保无人机沿组串中心线平稳飞行。

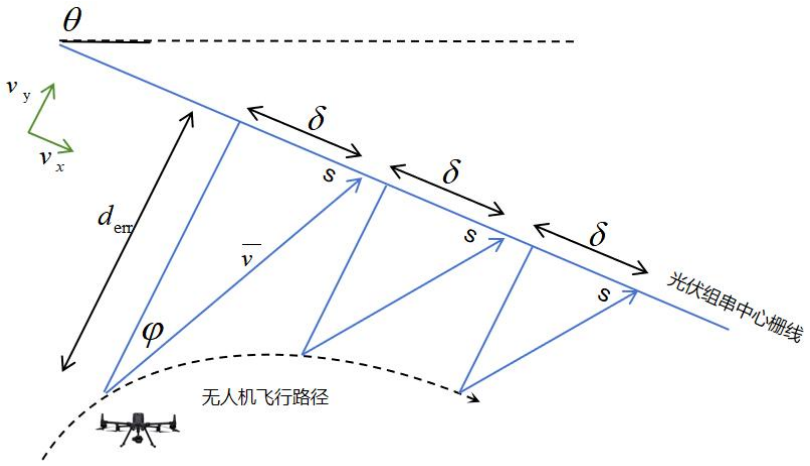


图 2-8 无人机路径过程

2.3.3 边界转向机制

当无人机到达任务区域的边界时，需要执行转弯操作以飞向下一个区域继续巡检任务，区域边界的判定通过无人机的实时位置和视频帧中的光伏组串检测结果来实现。当视频帧中未检测到光伏组串，则根据以下公式进行辅助判定[53]：

$$\sum \frac{x_{i,j}}{n_{\text{pix}}} \geq T_{\text{PV}} \tag{2-9}$$

其中，$x_{i,j}$为二值图像中光伏组串的像素值，n_{pix}为视频帧的总像素数，T_{PV}为 0.2 的阈值。

当边界判定条件满足时，无人机将执行转弯操作，其转弯策略综合

中国知网 https://www.cnki.net

考虑了无人机当前位置信息与任务区域边界信息，提出了两种典型的转弯策略：无人机转弯后仍然位于当前任务区域的边界内；无人机转弯后越过区域边界，进而进入新的巡检区域。转弯过程中，无人机根据实时调整的飞行路径和航向角确保其顺利完成过渡，从而继续后续的巡检任务。

2.4 本章小结

本章围绕光伏巡检中的数据采集展开，主要介绍了光伏组串红外成像的原理与应用、光伏巡检项目的概况以及无人机巡检方法。首先阐述了光伏组串的工作原理，解析了光伏电池如何通过 PN 结实现光能到电能的转换，并介绍了红外成像技术如何利用红外热成像仪获取光伏组件的温度分布。相比传统可见光图像，红外成像在弱光或无光环境下有着较强的环境适应性和高对比度。其次介绍了云南雄里坡复合型光伏发电项目的基本情况，包括地理位置、装机容量和发电能力并探讨了无人机在光伏巡检中的应用优势。最后通过对无人机轨迹导航的设计，为后续图像采集奠定基础。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 3 章 基于红外图像光伏组串检测分割研究

在无人机采集影像数据的过程中，由于外界环境和设备自身的影响，影像中常常夹杂了噪声和其他干扰，这不仅降低了图像质量，也妨碍了有效信息的解析，相比于可见光图像，在红外图像中这些问题如低对比度、低信噪比和模糊的边缘更为显著。为了提升图像的处理质量和光伏检测的准确性，对图像进行降噪和预处理以减小噪声影响[54]消除干扰。本章中列举了几项传统的滤波降噪方法，并将其结果进行对比，同时利用深度学习的图形检测算法与分割算法，分析其可行性。

3.1 光伏组串预处理研究

3.1.1 光伏图像滤波去噪研究

（1）均值滤波

均值滤波是一种常用的线性滤波方法，常常用于图像平滑处理中，其核心思想是将每个像素的值替换为其邻域内所有像素值的平均值，实现去噪和平滑效果。均值滤波通过定义一个固定大小的滤波窗口对窗口内的像素值求均值并更新中心像素值。均值滤波简单高效，能够有效去除随机噪声，但也会导致图像边缘和细节的模糊，适合处理较简单的噪声场景，其公式如下所示：

$$g(x,y)=\frac{1}{m\cdot n}\sum_{(i,j)\in \mathrm{Kernel}} f(x+i,y+j) \tag{3-1}$$

式中 $g(x,y)$ 为滤波后的像素值，$f(x+i,y+j)$ 为领域类的像素值，$m\cdot n$ 为滤波窗口大小。

（2）中值滤波

中值滤波常用于去除图像中的椒盐噪声，其核心思想是取像素邻域内的中值替换中心像素，对脉冲信号和随机干扰处理效果较好[55]。具体操作是将滤波窗口覆盖的像素值按大小排序，取其中的中值作为新的像

中国知网 https://www.cnki.net

素值，从而有效去除极端值的影响，同时较好地保留图像的边缘和细节。与均值滤波不同，中值滤波能在保护边缘的同时不模糊图像，在处理含有高强度噪声的图像时效果尤为显著。虽然中值滤波在在去噪和保留图像特征方面表现更优，但其计算涉及排序操作，相对均值滤波计算复杂度略高。



图 3-1 中值滤波示意图

（3）高斯滤波

高斯滤波是一种基于高斯分布的线性平滑滤波方法，在图像处理领域中常用于去噪和平滑处理，同时能够很好地保留图像的整体结构。其核心思想是利用高斯函数生成一个加权滤波核，使图像中每个像素的值根据其邻域像素的加权平均值进行更新，遍历整幅图像[56]，权重由高斯分布决定，距离中心越近的像素权重越大，高斯函数如图所示：

$$G(x,y)=\frac{1}{2\pi\sigma^2}\exp\left[-\frac{(x-x_0)^2+(y-y_0)^2}{2\sigma^2}\right] \tag{3-2}$$

式中σ为标准差，x,y为像素到窗口中心的水平和垂直距离，(x_0,y_0)为窗口中心像素坐标。

标准差σ用来控制高斯分布的宽度，当标准差较小时，高斯核的权重集中在中心像素附近，滤波作用范围小，平滑效果较弱，能够较好地保留图像的边缘和细节，适用于噪声较少且需要保留纹理的场景；而当标准差较大时，高斯核的权重分布范围更广，生成模板中的权重之间相差相比较小[57]，对图像的平滑作用更强，能有效去除噪声，但也会使图像的边缘和细节模糊。

中国知网 https://www.cnki.net

（4）双边滤波

高斯滤波在高频细节处理上存在一定的缺陷，高频细节的处理不当容易引起边缘的模糊，为了解决这一问题，人们提出了双边滤波算法。双边滤波在处理时同时结合了图像的空间邻域关系和灰度值的相似性，通过加权平均的方法，在保留边缘的同时又能平滑图像，其公式如下[58]：

$$I_{\text{out}}(p)=\frac{1}{W_p}\sum_{q\in\text{kernel}}G_s(p,q)\cdot G_r(I(p),I(q))\cdot I(q) \tag{3-3}$$

其中$I(p)$为像素p的值，W_p为归一化因子，用于保证权重和为 1，$G_s(p,q)$为空间权重，$G_r(p,q)$为像素值权重，空间权重和像素值权重的的公式分别为：

$$G_s(x,y)=\exp\left(-\frac{x^2+y^2}{2\sigma_s^2}\right) \tag{3-4}$$

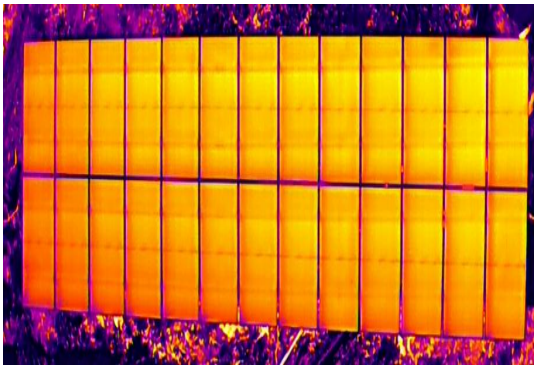
$$G_r(I,J)=\exp\left(-\frac{(I-J)^2}{2\sigma_r^2}\right) \tag{3-5}$$

式子中σ_s、σ_r分别表示控制空间范围内的影响程度和控制像素值差异的影响程度。

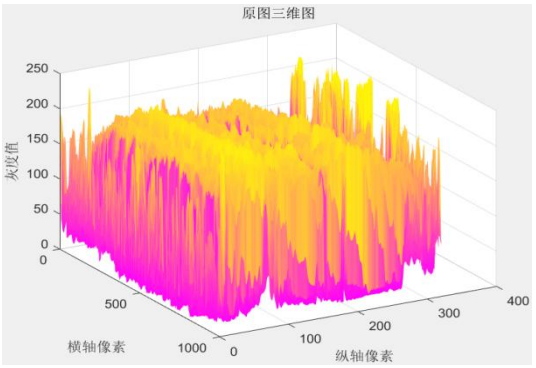
双边滤波与传统线性滤波不同，双边滤波结合了空间距离和像素值相似性两个权重，对每个像素进行加权平滑。空间权重基于像素之间的几何距离，距离越近权重越大；而像素值权重则基于像素值的相似性，值越相近权重越大。空间标准差控制滤波，范围像素值标准差控制平滑强度。双边滤波可以理解为不同的两个高斯滤波构成，通过这种双重加权机制，双边滤波在平滑图像的同时，不会模糊边缘区域，适用于去除噪声、平滑图像以及保留边缘细节的高质量图像处理[59]。

红外光伏组串各个滤波方法效果如图 3-2 所示：

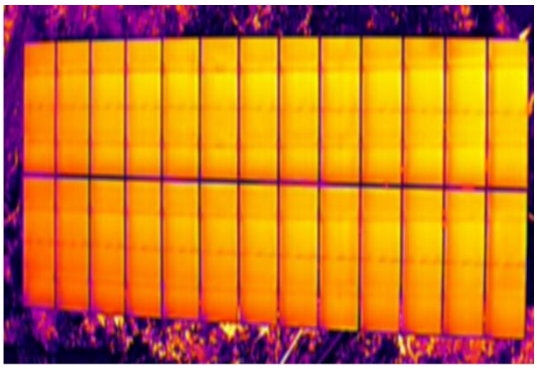
中国知网 https://www.cnki.net



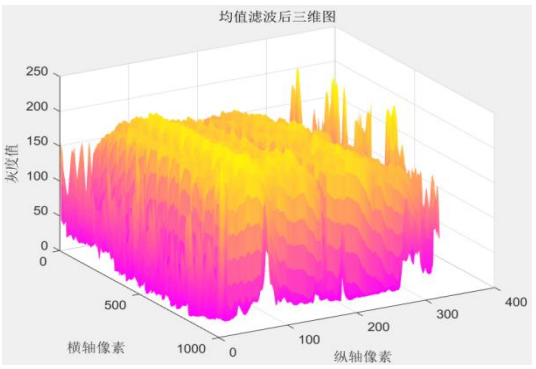
(a) 原图



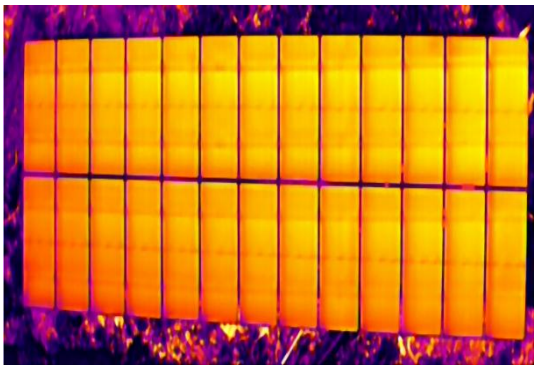
(b) 原图三维图



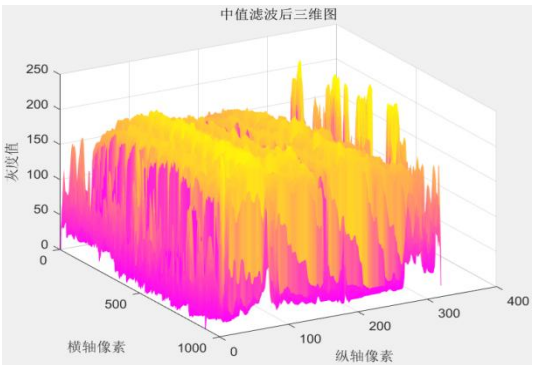
(c) 均值滤波



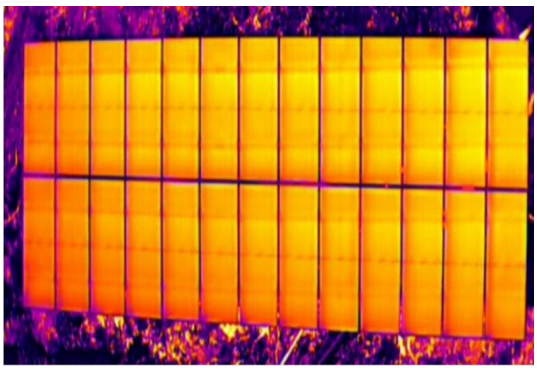
(d) 均值滤波三维图



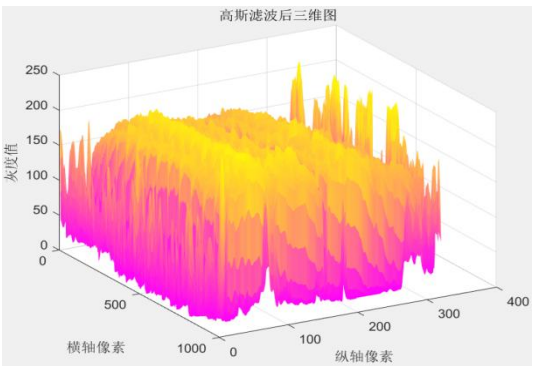
(e) 中值滤波



(f) 中值滤波三维图

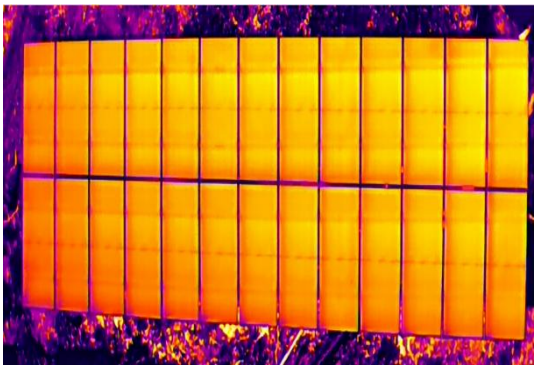


(g) 高斯滤波

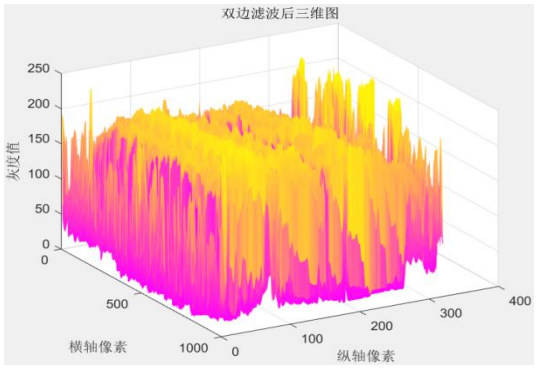


(h) 高斯滤波三维图

中国知网 https://www.cnki.net



(i) 双边滤波



(j) 双边滤波三维图

图 3-2 光伏红外图像降噪滤波效果图

图中展示了光伏红外图像经过不同滤波后的结果图及其三视图，从实验结果可以看出各个滤波方法在一定程度上都能改善图像的质量，减小图像的噪声。从定量角度分析，评价降噪效果的常用标准包括峰值信噪比（Peak Signal-to-Noise Ratio，PSNR）、均方误差（Mean Square Error，MES）以及结构相似性指数（Structure Similarity Index Measure，SSIM）。其中，PSNR 值越高表示图像保真度越好；MES 值越小则表明噪声降低效果越显著；SSIM 越大，说明图像结构的一致性越高，降噪算法的效果越优良。通常以这三项指标综合评估不同算法的去噪性能。

表 3-1 不同算法滤波去噪指标

	PSNR	**MES**	**SSIM**
均值滤波	24.2865	1.9236	0.9714
中值滤波	24.3973	1.7052	0.9762
高斯滤波	24.7345	1.5067	0.9795
双边滤波	24.8390	1.0645	0.9817

观察上表可知，双边滤波在所有测试指标中表现最为优异。具体而言相较于其他滤波，PSNR 最高，MES 最低，SSIM 值接近 1。双边滤波在去除光伏电池表面红外图像噪声时，相较其他方法效果更加出色。该方法能够有效消除脉冲信号和异常点引起的干扰噪声，同时尽可能保留红外图像的细节信息，为后续的缺陷识别与判断提供了更加精准可靠的基础。综合四种滤波方法的三维效果图与测试指标对比结果，在第四章节采用双边滤波图像去噪处理方式。

中国知网 https://www.cnki.net

3.1.2 光伏图像增强研究

光伏图像增强的研究具有重要意义，其主要作用是通过提高图像质量、突出关键信息和改善细节层次，为后续的缺陷检测和分析提供更准确的输入。常见的图像增强分为空间域和频域率两大类[60]，包括直方图均衡化[61]、伽马变换、Retinex[62,63]、导向滤波[64]等方法。红外光伏图像因成像设备分辨率低、灰度范围有限、噪声干扰大等问题，通常需要进行增强处理。通过图像增强，可以显著提高图像的对比度和清晰度，使光伏组件相比于背景环境更加突出，降低后续的处理与分析的复杂度[65]，便于快速检测和定位，从而提升光伏检测的效率和精度。

（1）直方图均衡

直方图均衡化是一种常用的图像增强技术，它能调整图像像素的灰度分布，提升图像的整体对比度。其基本原理是计算图像的累积分布函数，然后将原始灰度值映射到新的灰度范围，使灰度分布更均匀化，让灰度有相似出现频率使得图像对比度增加[66]，其公式如下：

$$s_i = T(r_i) = \sum_{k=0}^{i} p(r_k) = \sum_{k=0}^{i} \frac{n_k}{n}, i \in [0,255] \tag{3-6}$$

式中，s_i 表示表示直方图均衡化后，第 i 个灰度级对应的新灰度值。$T(r_i)$ 表示表示灰度值 r_i 经过均衡化的映射函数。$p(r_k)$ 表示灰度级 r_k 的概率分布，n 表示图像的总像素数。

通过均衡化，将原本集中于某些灰度范围的像素分布调整为全灰度范围均匀分布，从而提高对比度，主要适用于对比度较低或灰度分布不均匀的图像，能够显著改善视觉效果。

（2）伽马变换

伽马变换是一种常用的图像增强方法，根据人眼对暗部变换敏感，而对强光变换影响较小设计出来[67]，通过非线性变换像素值，调整图像亮度与对比度。伽马变换可以放大或压缩图像中亮部或暗部的细节，适用于显示设备的亮度校正和特定图像增强任务，伽马变换表达式如下[68]：

$$s = c \cdot r^{\gamma} \tag{3-7}$$

中国知网 https://www.cnki.net

其中，r 表示输入像素的归一化灰度值，s 表示伽马变换后的输出灰度值，c 常数系数，用于调整整体亮度，通常设置为 1，γ 伽马值，决定变换的非线性特性。

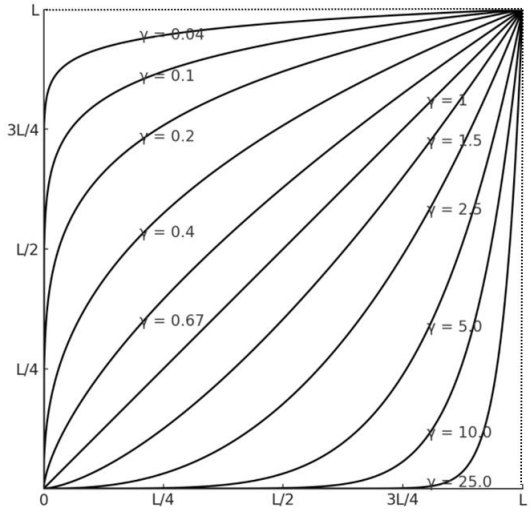


图 3-3 伽马变换函数

由图可知，伽马变换通过调整伽马值 γ 对图像的亮度和对比度进行非线性调节：当 γ<1 时，增强图像暗部的亮度，压缩亮部的细节，使阴影和低亮度区域的细节更加清晰；当 γ>1 时，压缩暗部亮度，增强亮部细节，提升亮部的对比度[69]，使过亮的图像更加自然；当 γ=1 时，图像保持不变，输出与输入一致。

（3）Retinex 算法

由 E.Land 在光的三原色理论基础上提出，通过模拟人眼对颜色恒常性的感知特性，将图像分解为照明分量和反射分量，分别进行处理以增强图像的对比度和细节表现，增强图像的清晰度和对比度。其核心思想认为物体的颜色由其反射光的能力决定，而光照变化不应显著影响物体的颜色表现。Retinex 算法通过对数变换将像素亮度建模为光照和反射的叠加，结合高斯滤波估计光照分量，再通过动态范围压缩突出反射分量，从而生成增强后的图像。

由 Retinex 理论可知，一幅图像可以看作是入射分量和反射分量的乘积。研究者基于该理论进行了众多研究，其中包括单尺度 Retinex 算法，该方法适用于简单场景，对增强效果的平衡能力有限；多尺度 Retinex 算

中国知网 https://www.cnki.net

法，适用于对比度提升和细节增强要求较高的场景，效果显著但参数较多；带色彩恢复的多尺度 Retinex 算法[70]，适用于需要保持色彩自然且增强效果强的场景，是当前 Retinex 算法的改进版本中较为常用的方法。

（4）基于选择增强的光伏图像算法

选择增强因子本质上是一种图像增强技术，通过调整图像亮度或特定区域的属性，提升目标区域与背景的对比度，其流程图如下：

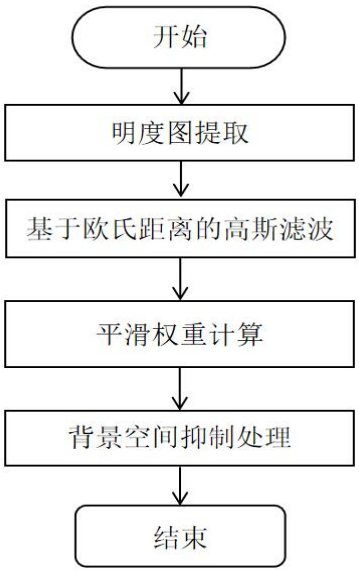
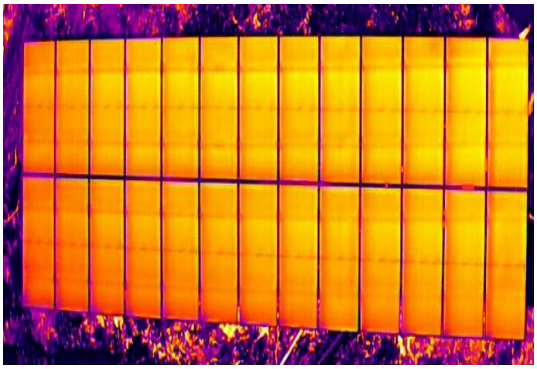


图 3-4 选择增强流程图

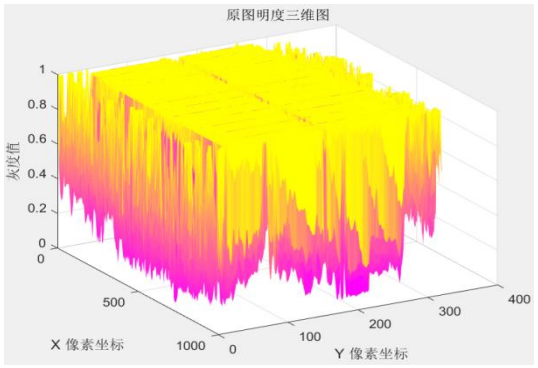
选择增强是通过选择增强因子调整，有效突出光伏板区域与背景的差异，从而提高光伏板与背景的对比度。具体来说，选择增强因子首先通过提取图像的明度分量来分析光伏板与背景的亮度分布，利用高斯滤波估计光照分量并计算反射分量突出光伏板的特征。随后对光伏板区域的亮度进行非线性增强，结合动态调整的增强因子，提升光伏板区域的亮度和边缘特征，同时对背景区域进行抑制处理，降低背景的亮度和噪声干扰。

红外光伏组串各个方法增强效果如图 3-5 所示：

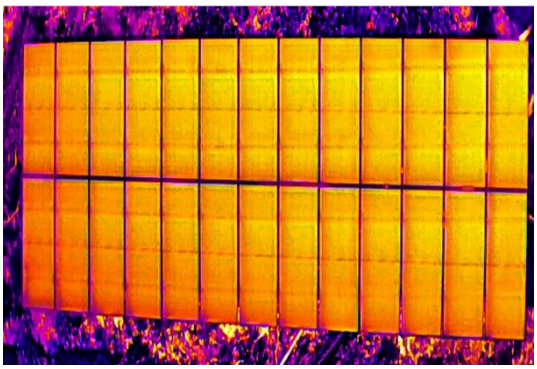
中国知网 https://www.cnki.net



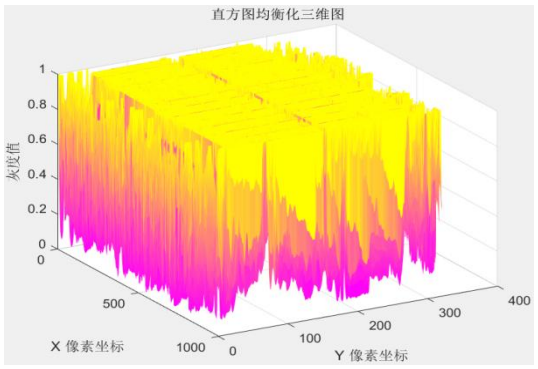
(a) 原图



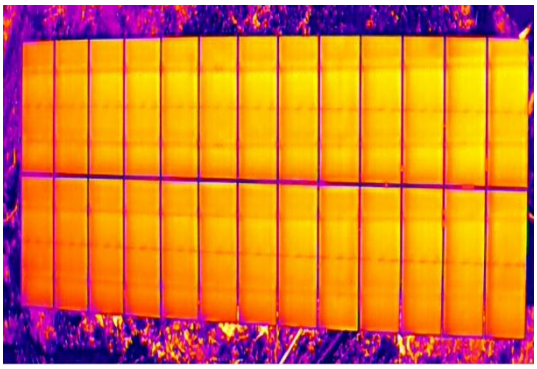
(b) 原图明度三维图



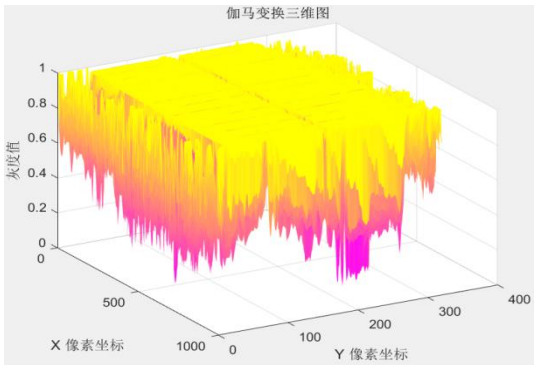
(c) 直方图均衡化



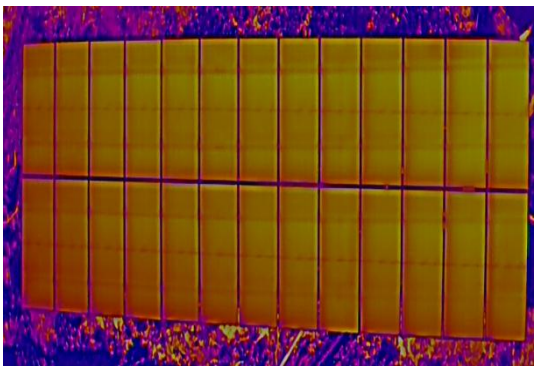
(d) 直方图均衡化三维图



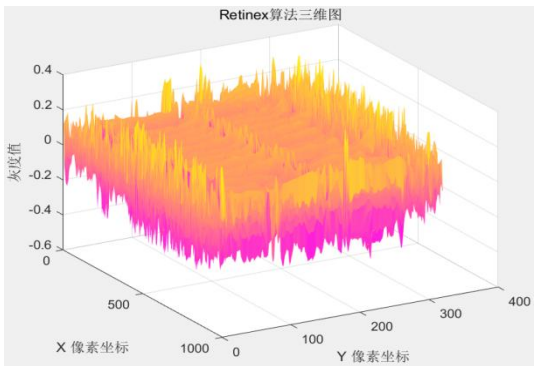
(e) 伽马变换



(f) 伽马变换三维图

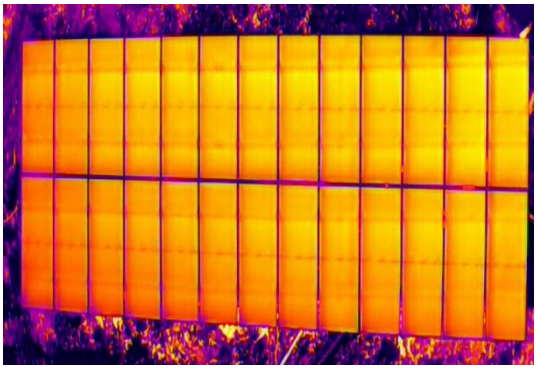


(g) Retinex 算法

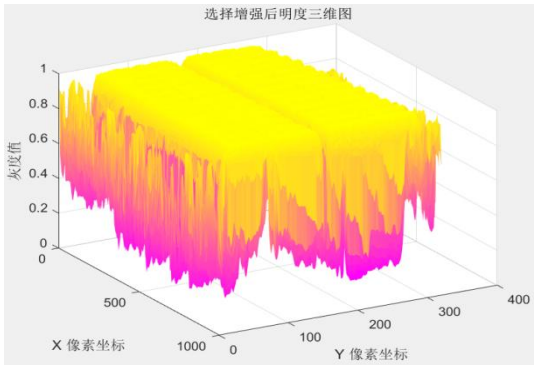


(h) Retinex 算法三维图

中国知网 https://www.cnki.net



(i) 选择增强



(j) 选择增强三维图

图 3-5 光伏红外图像降增强效果图

从图中可以直观看出，不同增强方法对图像的表现存在显著差异。直方图均衡化、伽马变换、Retinex 算法和选择增强均在一定程度上抑制了背景区域的干扰，增强了光伏组件区域的灰度特征。然而，这些方法的增强效果各有不同：

直方图均衡化在对比度提升方面具有一定的效果，但容易使图像整体灰度分布失衡；伽马变换能够有效改善对比度和饱和度，使图像更具视觉清晰度；Retinex 算法虽然提升了局部区域的对比度，但引入了较多噪声，使图像细节变得模糊，三维表现中呈现明显的毛刺；而选择增强方法在抑制背景噪声的同时，显著提升了目标区域的清晰度和对比度，其增强效果在主观视觉上优于其他方法。

表 3-2 不同增强算法指标

	PSNR	MES	SSIM
直方图均衡化	19.9446	3.6812	0.9381
伽马滤波	26.4279	0.4127	0.9762
Retinex	13.5892	8.6412	0.6149
选择增强	28.8931	0.3353	0.9892

通过对比四种图像增强方法的性能指标可以看出，选择增强在 PSNR、MES 和 SSIM 指标上均表现最佳，具有显著的降噪能力和细节增强效果，同时有效抑制了背景噪声，突出了光伏组件区域的清晰度和对比度，是所有方法中效果最优的一种；伽马滤波在各项指标上次于选择增强，能够提升对比度和饱和度，同时较好地保留图像细节，适合对比

中国知网 https://www.cnki.net

度需求较高的场景；直方图均衡化虽然在提升图像整体对比度方面有所作用，但存在信息丢失和噪声增强的问题，效果相对一般；Retinex 算法则由于引入较多噪声，导致图像结构不清晰和细节模糊，整体表现最差。综合来看，选择增强方法在光伏电池红外图像处理中具有最优的增强效果，可为后续的故障检测和分析提供高质量的图像基础，本文第四章在此基础上做出改进。

3.1.3 光伏图像矫正研究

在光伏图像的矫正研究中，常用的图像几何变换包括刚性变换、仿射变换和透视变换，这些变换能够有效解决因拍摄角度、透视关系等因素引起的图像失真问题，提升后续图像处理的准确性。

（1）刚性变换

刚性变换是一种保持图像几何形状和大小不变的变换方式，主要包括平移、旋转两种操作。刚性变换的本质是对图像坐标系的线性操作，对于图像领域有着极其重要的理论与实用价值[71]公式如下：

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} t_x \\ t_y \end{bmatrix} \tag{3-8}$$

其中，(x, y) 是原图像坐标，(x', y') 是变换后的坐标，θ 为旋转角度，t_x 和 t_y 分别表示平移量。刚性变换可以用于调整图像的角度或位置，但不会改变图像的形状和比例。

（2）仿射变换

仿射变换是一种更灵活的线性变换，除了平移和旋转，还允许图像进行缩放和剪切操作，通过对一次函数的非奇异线性变换结合平移构成[72]。仿射变换的公式为：

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} t_x \\ t_y \end{bmatrix} \tag{3-9}$$

其中，前一个矩阵决定图像的旋转、缩放和剪切，平移向量控制图像的位置变化。仿射变换可以保持图像直线之间的平行关系，是许多几

中国知网 https://www.cnki.net

何校正任务的常用工具。

（3）透视变换

透视变换是一种非线性变换，用于处理因视角变化而导致的图像透视失真问题。透视变换可以将图像从一个平面投影到另一个平面，对于发生畸变的光伏组串，本文图像矫正使用到改进的透视变换相关技术[73]，透视变换公式为：

$$\begin{bmatrix} x' \\ y' \\ w \end{bmatrix} = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \tag{3-10}$$

通过归一化得到：

$$x' = \frac{h_{11}x + h_{12}y + h_{13}}{h_{31}x + h_{32}y + h_{33}}, \quad y' = \frac{h_{21}x + h_{22}y + h_{23}}{h_{31}x + h_{32}y + h_{33}} \tag{3-11}$$

在实际图像采集过程中，由于无人机航线设置、拍摄角度及相机倾斜等问题，采集的红外图像不可避免地存在不理想之处。本文后续采用透射变换对光伏组串进行了校正处理。透视变换可以校正图像的透视失真，使倾斜的光伏板图像被拉直至正视角，从而方便后续的进一步分割和分析。

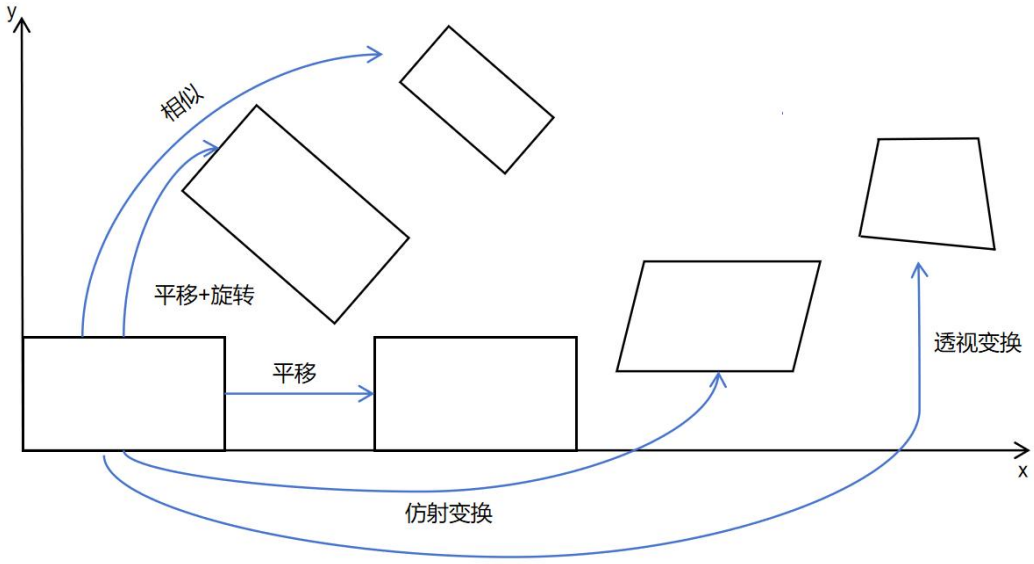


图 3-6 图像基本变换示意图

中国知网 https://www.cnki.net

3.2 传统的光伏组串检测分割方法

图像检测与分割是图像处理的一个重要技术，由于不同应用领域的需求各异，图像检测与分割算法需要根据具体场景灵活选择才能实现最优效果。为了满足多样化的分割需求，众多算法被相继提出，目前已有成千上万的相关研究文献，这些文献从理论到实践为图像分割提供了丰富的技术支持，本节中对几个检测与分割方法逐一介绍。

（1）基于阈值的光伏组串检测分割方法

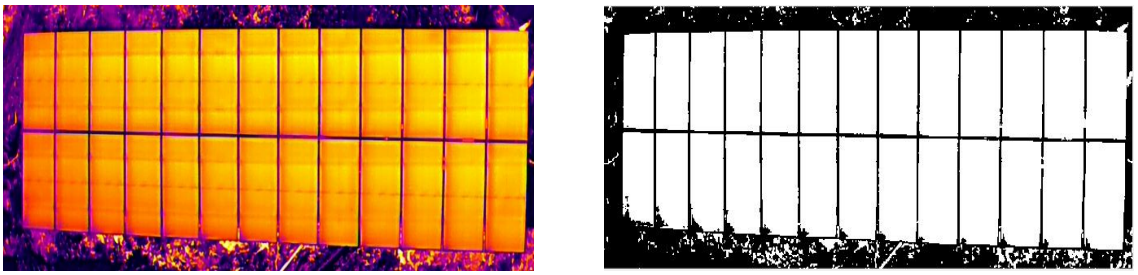
基于阈值的分割方法是一种经典的图像分割方法，因其简单高效，操作方便而被广泛运用，其原理基于图像参数值范围，利用图像灰度值或颜色值的分布特性确认一个及多个像素的参数值作为分割值，通过设设定阈值，将图像分为目标区与背景区。常见的阈值光伏组串分割有直方图峰谷法[74]、迭代阈值法与 Otsu 等方法，此小节中详细介绍 Otsu 方法。

Otsu 方法基于最小二乘理论构造的一种自适应图像阈值分割方法，该方法通过最大化类间方差来自动选择最佳的全局阈值。其目标是找到一个阈值 T，使得图像被分割为两类，使得两类之间差异最大，此时阈值确定为该图像的分割阈值[75-77]，对应类间方差公式为：

$$\sigma_B^2 = w_1(T)w_2(T)[\mu_1(T) - \mu_2(T)]^2 \tag{3-12}$$

其中，T 是分割阈值，$w_1(T)$，$w_2(T)$ 分别为阈值两侧像素的比例，$\mu_1(T)$，$\mu_2(T)$ 分别为分别为前景和背景的平均灰度值。

通过遍历所有可能的灰度值，使得σ_B^2最大阈值作为最终的检测分割阈值，其分割结果如下所示：



(a) 原图　　(b) Otsu 分割结果

图 3-7 红外光伏及 Otsu 分割图

中国知网 https://www.cnki.net

（2）基于边缘检测的光伏组串检测分割方法

边缘检测算法是一种常用的图像分割算法，通过检测图像中灰度或颜色显著变化的边缘区域，将目标与背景区分开。边缘通常对应于物体的边界，通过提取边界信息，结合形态学操作对检测结果进行优化实现目标区域的准确检测。

一阶算子与二阶算子是图像边缘检测中常用的方法，它们分别基于图像灰度值的一、二阶导数来提取边缘特征。常见的一阶算子包括 Sobel、Prewitt 和 Roberts 算子，主要通过计算灰度值的梯度来检测边缘，但存在对噪声敏感、边缘定位精度较低以及边界不连续等问题。二阶算子如拉普拉斯算子、LoG 算子和 Canny 算子通过检测二阶导数的零交叉点来准确定位边缘，同时结合高斯滤波等预处理可以有效抑制噪声，捕捉一阶算子难以检测的弱边缘。相比一阶算子，二阶算子对各方向边缘的检测能力更强，能更好地保持边缘的连续性。



(a) 一阶 sobel 算子边缘检测　　(b) 二阶 canny 边缘检测

图 3-8 基于边缘检测的光伏组串

（3）基于灰度曲线的自适应 B 样条最小二乘拟合法的组串检测

B 样条曲线拟合是一种常用的数学方法，它将曲线表示为一系列分段的 B 样条曲线，通过分段多项式的组合来逼近数据点，使得拟合曲线在每个区间内更加平滑。因其更好的局部控制性，B 样条曲线在许多领域得到了广泛应用[78]。

B 样条曲线方程定义为:

$$P(t)=\sum_{i=0}^{n}P_iN_{i,k}(t) \tag{3-13}$$

其中 P_i 为控制顶点，$N_{i,k}(t)$ 为 k 阶 B 样条基函数。

中国知网 https://www.cnki.net

假设有一个数据集 X 含有 n 个样本，坐标为[a，b]：

$$X=\{(t_1,y_1),(t_2,y_2),(t_3,y_3),\cdots(t_n,y_n)\} \tag{3-14}$$

$$a=max\{t_i\},b=max\{y_i\},i=1,2,\cdots,n \tag{3-15}$$

将区间 $[a，b]$分为Δ等分点，取个$M+1$样本节点为:

$$\Delta:a=x_0<x_1<\cdots<x_M=b \tag{3-16}$$

根据节点序列τ_k表示曲线，其中k为 B 样条阶数，m 为控制点个数，令$m=M+k$满足以下条件：

$$\tau_0\le\cdots\le\tau_k=a\le\tau_{k+1}<\cdots<\tau_{k+M}\le b=\tau_{k+M+1}\le\cdots\le\tau_{m+k+1} \tag{3-17}$$

基于公式(4-3)B 样条曲线方程定义，以 k 次 B 样条线性组合的函数样条方程$s(t)=\sum^{m}a_lB_l(t)$（为线性系数、为样条基函数、l为 0 到 m 的自然数），自适应节点的 B 样条函数最小二乘拟合问题[79]就是通过引入目标函数$f(t)$，使得：

$$\|f-s^*\|=\min\|f-s\| \tag{3-18}$$

其优化目标函数为：

$$J(\alpha)=\|f-s\|=\sum_{i=1}^{n}\left(\sum_{l=0}^{m}a_lB_l(t_i)-y_i\right)^2 \tag{3-19}$$

$$J(\alpha^*)=\min J(a) \tag{3-20}$$

求得最优 B 样条曲线拟合函数$s^*(t)$。

红外图像中通常会受到噪声和不规则毛刺的干扰，这些干扰导致灰度直方图中包含大量局部起伏，使得直接分割会比较困难。为减小直方图干扰影响，采用 B 样条拟合平滑直方图数据，找到与样本之间的最小偏差的样条曲线，并依此样条曲线寻找最高波峰以及波谷对应的灰度值，从而确定分割阈值范围，流程方法如图所示：

中国知网 https://www.cnki.net

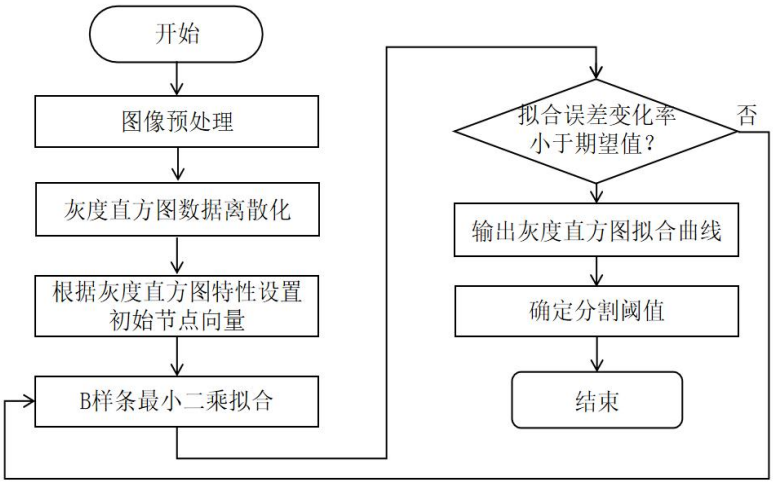
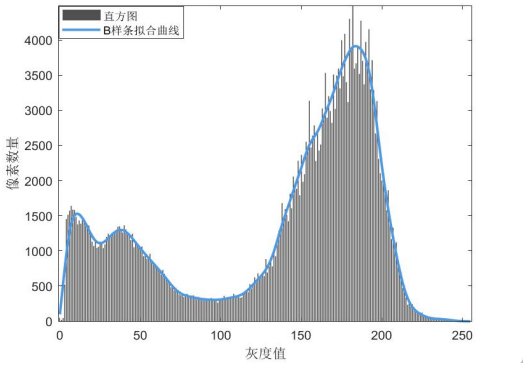
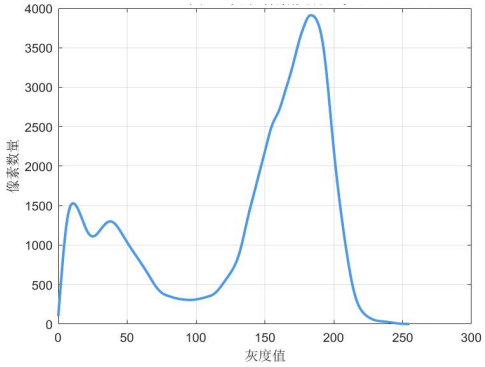


图 3-9 B 样条拟合确定阈值分割流程

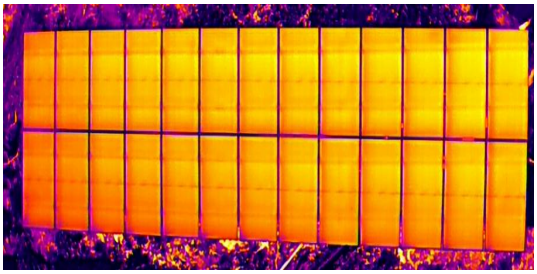
实验结果如下所示：



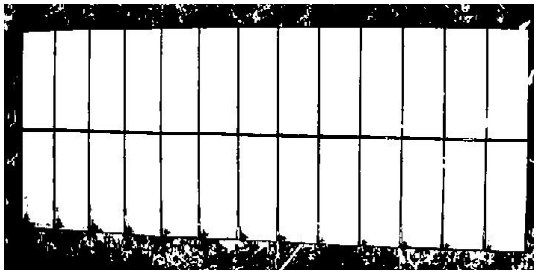
(a) 灰度直方图以及拟合曲线



(b) B 样条拟合曲线



(c) 原图



(d) 自适应 B 样条最小二乘拟合法

图 3-10 B 样条拟合曲线及结果图

自适应 B 样条拟合方法是一种非线性优化求解问题，其核心在于确定数据点的节点以及控制顶点的位置[80]，需要通过全局优化算法进行计算。这类方法通常能够实现较好的拟合效果，尤其在处理复杂数据时表现出较强的适应性，但其固有的不足之处也不可避免。该方法处理复杂

中国知网 https://www.cnki.net

数据时可能需要耗费较长的运算时间。此外由于优化过程的非线性和复杂性，全局最优解通常难以完全保证，可能会陷入局部最优解，从而影响最终拟合的准确性和可靠性[81,82]。

3.3 基于 YOLOv8 模型的光伏组串检测算法

YOLO 模型的光伏组串检测算法是一种利用深度神经网络进行目标检测的高效方法。Ultralytics 公司在 2023 年提出了该算法的第八代版本[83]，YOLOv8 继承了其快速、精确的检测特点，并通过引入改进的网络结构和优化算法，进一步提升了小目标检测的能力。

在光伏板检测任务中，YOLOv8 能够通过卷积神经网络提取图像特征，将光伏板区域与背景进行有效区分，同时结合多尺度检测机制，对光伏组串中不同尺度的组件进行精准识别。相较于传统检测算法，YOLOv8 模型不仅能够实现实时检测，还能兼顾检测精度和速度的平衡。此外 YOLOv8 结合了 Anchor-free 机制以及改进的损失函数，在处理光伏板检测中可能存在的复杂背景和遮挡问题方面略有优势。

在实际应用中，针对光伏阵列图像的特性，YOLOv8 可以通过大量标注数据进行模型训练，自动学习光伏组串的边界、形状及纹理信息，实现对光伏板区域的高效检测与分类。本节中尝试利用 YOLOv8 网络模型对光伏组件进行检测研究，研究其在红外图像中对光伏板目标的检测性能和实际应用效果。

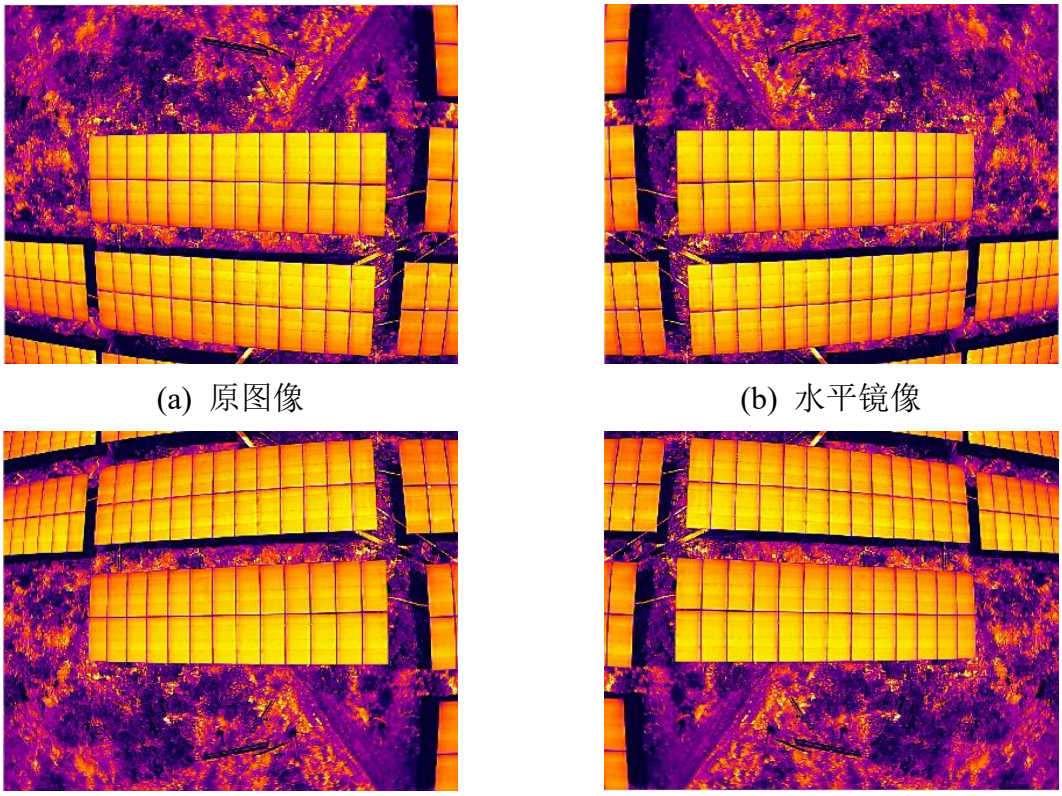
3.3.1 光伏数据集的采集获取

本文使用无人机 M300RTK 搭载禅思 H20T 镜头在天气晴朗时从云南省祥云县雄里坡光伏电站采集到像素 640×512 像素的红外光伏图片 783 张，剔除掉大面积反光、模糊、重影后最终得到 472 张质量表现较好的红外光伏图像。

中国知网 https://www.cnki.net

3.3.2 光伏数据集增强与标注

由于采集的数据有限，为避免模型训练过拟合，同时提升泛化能力，对数据集进行数据增强处理。数据增强是一种通过对已有样本进行变换生成更多训练数据的技术，能够显著增加样本数量、提升数据多样性，减轻样本不均衡对训练的影响。常用的数据增强方法主要包括几何变换、颜色空间变换以及其他处理方式。几何变换是目标检测任务中最常用的手段，操作包括随机旋转、缩放、翻转、通道分离等操作[84]。本研究对标注好的光伏图像数据进行了镜像、旋转、亮度变换和模糊处理等增强操作，使训练集样本数量从 472 张扩充到 857 张。



(a) 原图像　(b) 水平镜像

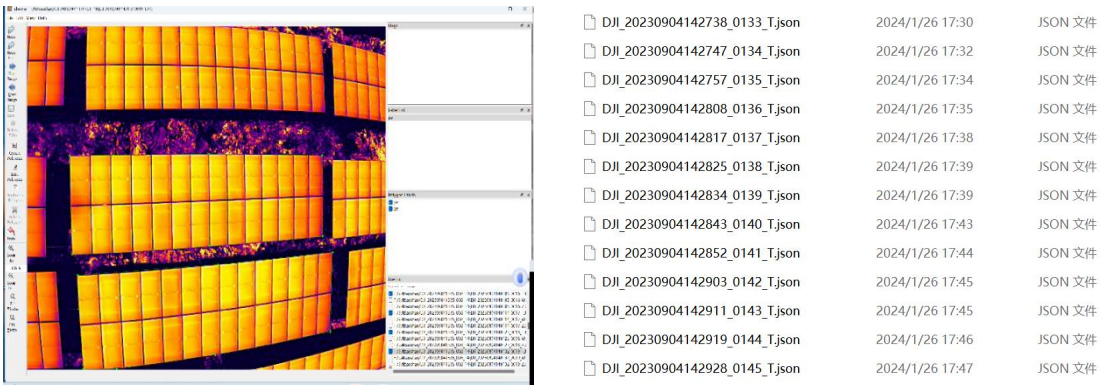
(c) 垂直镜像　(d) 180°旋转

图 3-11 红外图像数据增强

本文采用的标注软件为 Labelme，标注结果以 JSON 格式保存，文件中包含每个目标的类别信息、目标轮廓的多边形坐标信息以及其他附加属性。在光伏数据的标注过程中，本文使用多边形标注方式对光伏组件进行标注，在众多光伏组串中标注完整的光伏组串，以确保检测的精确

中国知网 https://www.cnki.net

性和完整性。



(a) Labelme 标注软件　　(b) 部分标注图片

图 3-12 图像标注软件及结果

3.3.3 YOLOv8 模型概述

YOLOv8 的结构主要由输入层、骨干网络、颈部网络和头部网络四部分构成。输入层将待检测的光伏板红外图像输入到网络中，为后续处理提供基础数据。骨干网络则承担了特征提取的核心任务，通过一系列卷积和激活操作提取图像中的关键信息，形成高质量的特征表示。特征被传递到颈部网络后，颈部网络通过多层次特征融合与池化操作，将不同尺度的特征有效结合进一步提升对小目标的检测能力。最后经过特征处理后的信息传递到头部网络，在头部网络中完成目标分类和边界框的预测，进而输出检测结果。

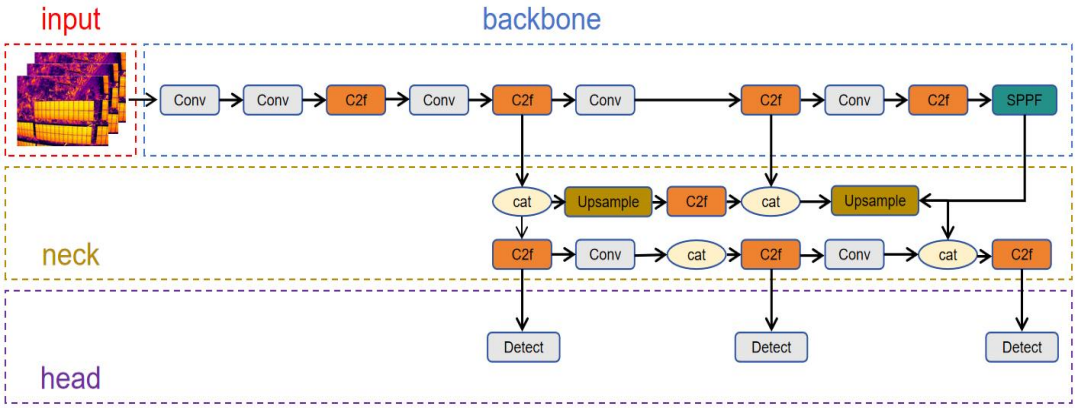


图 3-13 YOLOv8 网络结构图

中国知网 https://www.cnki.net

（1）骨干网络（backbone）：

YOLOv8 的骨干网络由多个 Conv 模块、C2f 模块和 SPPF 模块组成。Conv 模块由卷积层（Conv2d）、批处理归一化（BN）层和 SiLU 激活函数组成，用于对图像进行初步特征提取，提取边缘信息和低级特征。C2f 模块采用 CSP 结构，将输入特征分为两个分支，其中一个分支连接若干 BottleNeck 模块进行深层特征提取，另一个分支直接传递后与第一个分支进行 Concat 融合，增强特征表达能力并降低计算复杂度。SPPF 模块通过三个相同卷积核大小的池化层，融合局部和全局特征，同时扩大感受野并减少计算量，进一步提升特征提取的效率。

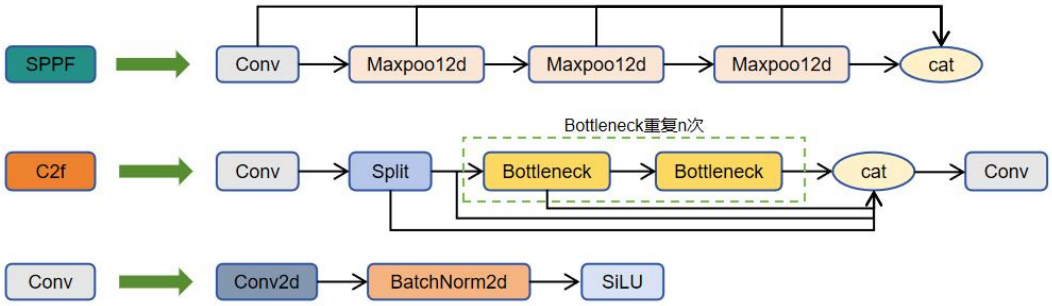


图 3-14 YOLOv8 网络模块结构图

（2）颈部网络（neck）：

颈部网络结合了 PANet 结构的特性，通过 Upsample 模块对特征图进行上采样，恢复高分辨率的特征图，同时结合 Concat 操作，将来自骨干网络不同尺度的特征与上采样后的特征进行融合，实现深层语义信息和浅层细节信息的互补。融合后的特征经过 C2f 模块进一步处理，提升特征的表达能力和鲁棒性。颈部网络能够有效整合多层特征，使模型有着出色的鲁棒性与泛化能力。

（3）头部网络（head）：

头部网络通过 Detect 模块对不同尺度的特征图进行处理，直接输出目标类别和位置坐标信息。与传统 YOLO 版本不同，YOLOv8 引入了 Anchor-Free 机制，摒弃了锚框设计，简化了网络结构并降低了参数复杂度，提高了目标检测的精度和稳定性。

中国知网 https://www.cnki.net

3.3.4 实验环境与训练参数设置

本文模型训练时所使用的显存 16G 的 NVIDIA RTX4080 显卡，具体实验环境如下表所示:

表 3-3 实验环境配置

设备	配置
系统类型	64 位操作系统，基于 x64 处理器
操作系统	Windows 11
处理器	Intel 酷睿 i7-11700k
显卡	英伟达 GeForce RTX4080 16G
算法开发语言及学习框架	Python3.8/Pytorch1.5

其中 CUDA 版本为 11.8，训练时数据集的 Batch size 设置为 16，总共进行了 100 个 epochs 的训练，初始学习率为 0.01，动量参数为 0.9，训练时将输入图像调整为统一的尺寸大小，并进行标准化处理。同时，使用随机翻转策略来增强模型的泛化能力，当随机概率超过 0.5 时，对输入图像进行水平翻转。

3.4 实验结果及分析

3.4.1 评价指标

实验采用精确度（P）、召回率（R）、误检率（FDR）、准确率（AR）、交并比（IoU）作为评估检测性能的指标。

P 表示正确检测出的光伏组串样本占所有检测出的样本的比率：

$$P = \frac{TP}{TP + FP} \tag{3-21}$$

R 表示正确检测出光伏组串样本部分与总光伏样本之间的比率：

$$R = \frac{TP}{TP + FN} \tag{3-22}$$

FDR 表示错误检测出光伏组串样本部分与总背景样本之间的比率：

中国知网 https://www.cnki.net

$$FDR = \frac{FP}{FP + TN} \tag{3-23}$$

AR 表示正确检测出光伏组串样本与总样本之间的比率：

$$AR = \frac{TP + TN}{TN + TP + FN + FP} \tag{3-24}$$

IoU 是一种衡量预测框与真实框重叠程度的指标，用于判断检测是否准确：

$$IoU = \frac{TP}{TP + FP + FN} \tag{3-25}$$

式中，*TP* 表示预测与实际样本都为正例，*TN* 表示预测与实际样本都为反例，*FP* 表示预测正例，实际反例，*FN* 表示预测反例，实际正例[85,86]。

3.4.2 实验结果分析

本章实验使用 3.3.2 小节里面 857 张光伏组串数据集对 YOLOv8 模型进行训练，模型在训练时的 loss 曲线如图所示，随着 epoch 的增加，loss 值逐渐减小，直至 80 次左右开始收敛并趋于稳定。

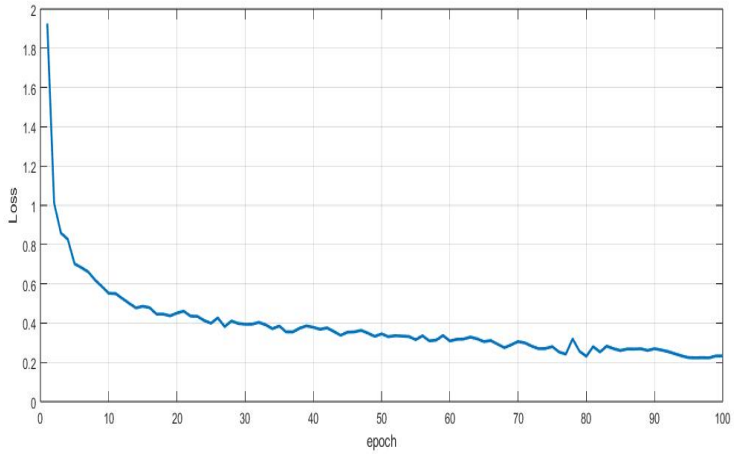


图 3-15 模型 loss 曲线

使用 3.4.1 所述的评价指标对自适应 B 样条拟合法的组串分割与 YOLOv8 模型方法结果进行分析对比，将结果图中每个像素点的分类结果与软件标注的类别进行比对，并对 100 张测试样本的结果进行统计，

中国知网 https://www.cnki.net

计算相应的评价指标，如下表所示：

表 3-4 算法结果对比

算法	精确度 P	召回率 R	误检率 FDR	准确率 AR	交并比 IoU
B 样条	88.56%	85.52%	9.83%	86.72%	81.64%
YOLOv8	95.64%	91.82%	0.94%	95.16%	93.53%

从表中可以看出相比于自适应 B 样条拟合算法，YOLOv8 在各项评价指标都优于前者。

光伏组件红外检测图如下所示，class_00_pv 为光伏板目标检测框，图 3-17 是自适应 B 样条拟合算法对同一组图的拟合效果以及分割结果。

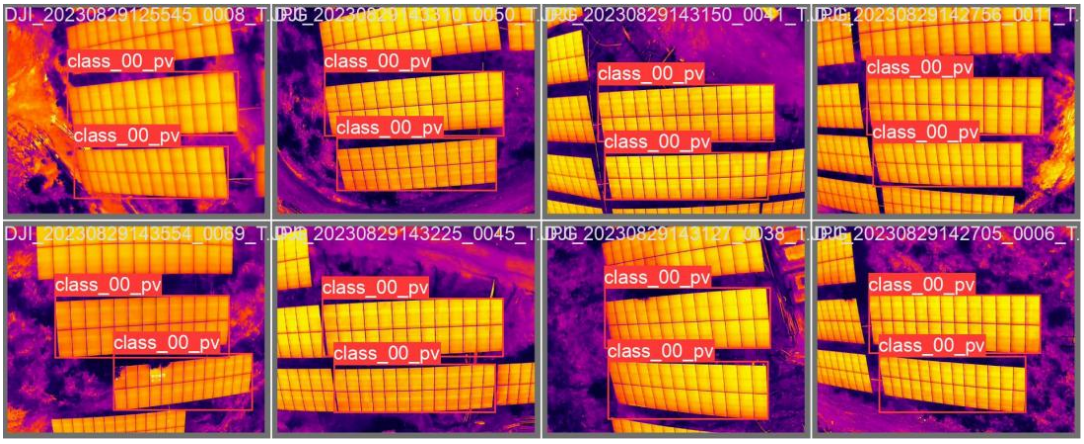


图 3-16 YOLOv8 光伏组串检测结果

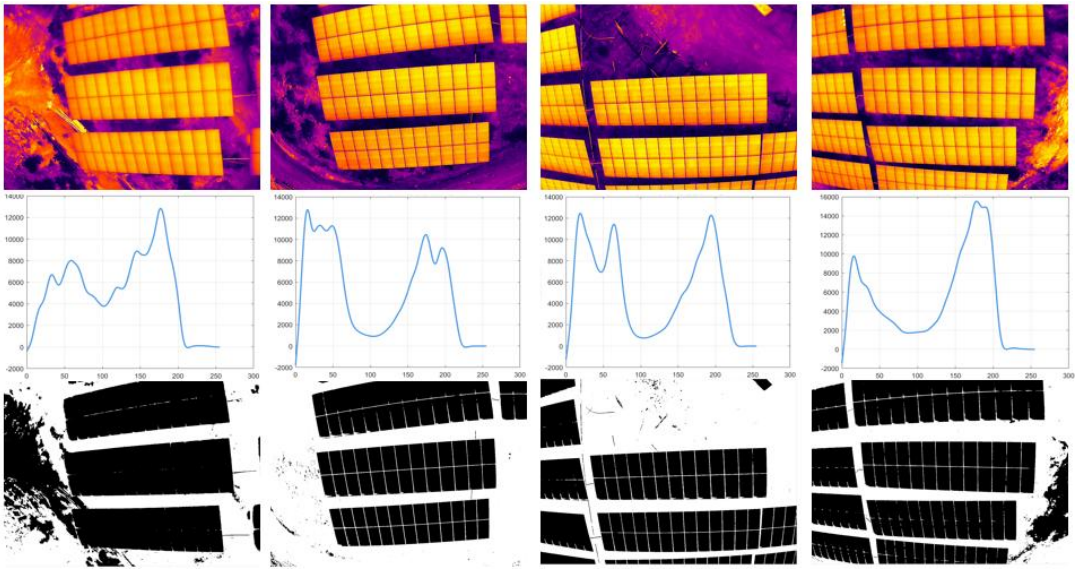


图 3-17 B 样条光伏组串分割结果

中国知网 https://www.cnki.net

从图中可以看出，对于图中完整且规则的光伏组串，YOLOv8 能够较为准确地识别目标，表现出较高的检测能力。然而在光伏巡检过程中，由于无人机飞行姿态的变化、角度偏差以及图像畸变等原因，对于形状不规则、边界模糊或并非标准矩形的光伏组串，YOLOv8 的检测表现会受到一定影响。此外，检测结果中包含较多的背景信息，进一步增加了识别的难度。自适应 B 样条拟合分割方法同样面临类似问题，尤其是在复杂背景中，例如背景区域的树木或土壤，其比热容较小，红外特征与光伏组串的热辐射特征较为接近，自适应 B 样条拟合方法容易将这些噪声部分误判为光伏组串目标。与此同时，在光伏组件排列密集的区域，自适应 B 样条方法在区分同一个光伏板的光伏组件时表现出一定的局限性。本章提出的自适应 B 样条最小二乘拟合分割法与 YOLOv8 模型对光伏组串检测具有一定的检测能力，但仍需进一步提高光伏组串检测精度。

3.5 本章小结

本章基于光伏巡检中红外光伏组串图，对各种去噪、增强和校正的处理效果进行了分析并做出总结，比较了传统学习和深度学习在光伏组串识别的特点。传统方法在目标特征单一、背景变化较为简单的情况下通常能取得较好的检测效果，且具有操作简便的优势。然而，当背景环境变得复杂时，其表现往往显著下降鲁棒性较低。基于 YOLOv8 的深度学习模型通过神经网络学习了光伏组串更加深层次的特征，相比传统算法有着较强的鲁棒性和泛化能力，但是面对视角偏差以及畸变的影响难以剔除部分光伏组串背景。根据本张章节的描述，通过对现有方法的分析与总结，明确了光伏组串检测中存在的主要问题和技术难点，为第四章光伏组串检测识别做了铺垫。

中国知网 https://www.cnki.net

第 4 章 基于静态单张的红外光伏组串检测方法

本章设计了基于静态单张的红外光伏组件传统检测算法，首先针对于 YOLOv8 中光伏组串检测出现不完整和畸变的问题设计了基于霍夫直线检测算法的光伏组串旋转、矫正变换方案，其次，基于红外图像光伏组串与环境背景的辐射特性差异，提出一种基于色彩空间模型改进的自适应阈值分割方法，并使用改进的聚类分割对其进一步处理。

相比于 YOLOv8 等基于深度学习的分割与检测算法，传统算法在计算资源需求、模型解释性以及对小数据集和实时性场景的适应性方面具有显著优势。此外传统方法对标注数据的依赖较低，在数据稀缺或无监督的情况下依然可以获得较为稳定的性能，在低分辨率或高噪声图像处理中的鲁棒性较强。

4.1 基于改进霍夫提线算法的光伏组串旋转处理

图 4-1 中为无人机单张拍摄的光伏巡检红外图像，从图像中可知，正常工作状态下的光伏组件其表面温度场较为均匀，相比于背景区域，表现出较为单一的颜色，同时组串中每个光伏组件的边缘连接特征明显，基于光伏中间连接处色调对比明显的先验知识，设计了一种基于霍夫直线的检测方案对光伏组串进行预处理。

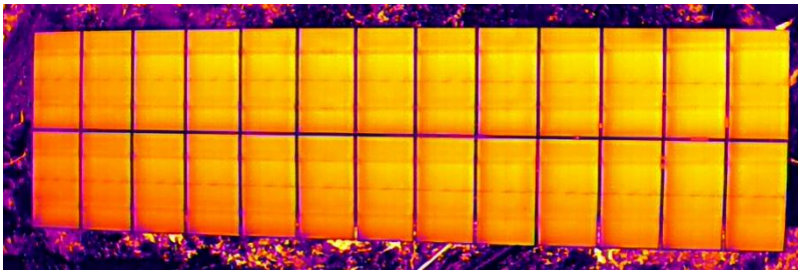


图 4-1 静态红外光伏组串巡检图

霍夫直线检测算法是一种经典的图像处理技术，广泛应用于各种领域，并且有许多改进和变种。霍夫直线检测算法最初用于直线检测，现在已扩展到多种形状的检测，通过将图像中的直线从笛卡尔坐标系转化

中国知网 https://www.cnki.net

为极坐标系的思想，以解决直线检测中的不连续性问题。该算法将每个图像中的像素点映射到极坐标空间中的一系列参数ρ和θ形成一个二维的参数空间。在此空间中，直线通过其与原点的最短距离和与横轴的夹角来表示，每个像素点对其对应的极坐标参数进行投票，最终在霍夫空间中形成一系列峰值，从而形成图像中的直线，其表达式为：

$$\rho = x\cos\theta + y\sin\theta \tag{4-1}$$

其中ρ为直线距离原点的垂直距离，θ是直线与横坐标轴的夹角，x和y分别为笛卡尔坐标系下的坐标，对光伏组串的霍夫直线检测算法如图4-2所示。

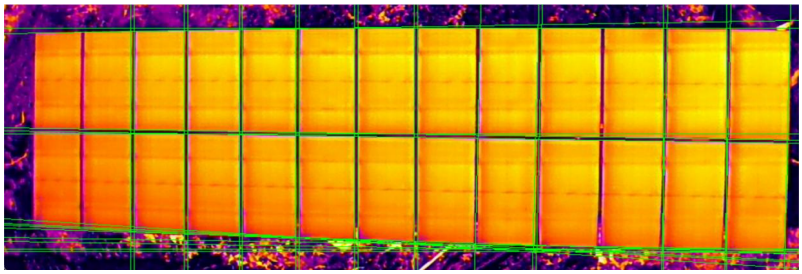


图 4-2 统计概率霍夫直线检测算法

传统的霍夫直线变换依赖于投票机制统计峰值，从图像空间到参数空间的转换中时间较长，在光伏电站的巡检中难以满足对众多光伏组串检测的实时性。对此，本文通过对光伏组串中间处栅线边缘的轮廓点进行取样，通过统计概率霍夫检测算法计算直线信息，具体方法如下:

（1）在目标区域内，首先使用 Canny 算子进行边缘检测，提取光伏板栅线边缘的二值化边缘点集合。为增强边缘连通性、填补裂缝及空洞，对边缘点集合进行 Sobel 滤波器滤波及形态学膨胀操作优化边缘。随后从 Otsu 阈值法二值化膨胀后的边缘点集合中随机抽取点，并为每个抽取点建立局部参数空间累加器。

（2）在每个兴趣点的局部感兴趣区域内，对邻域像素点进行霍夫变换，累加其对应的直线参数到局部参数空间。通过累加值与设定阈值的比较，判定局部区域内直线特征。

（3）从参数空间中提取符合条件的直线段，计算其长度，大于阈值则判断为直线。

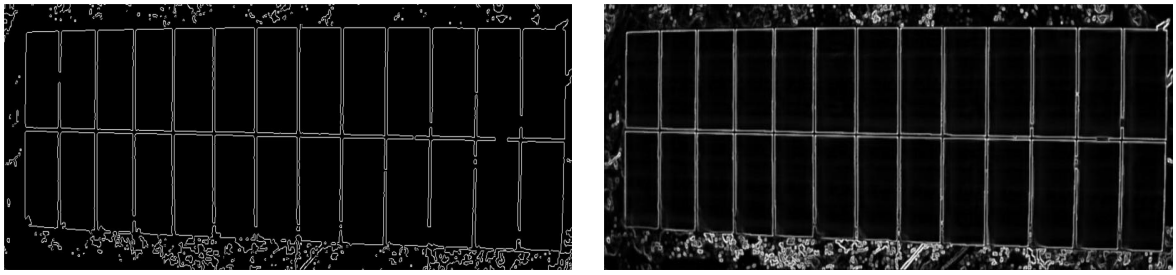
中国知网 https://www.cnki.net

（4）光伏组串同一边缘包含多个近似线段，本文采用共线性概率公式评估两线段是否共线，公式如下所示;

$$p=(1-\frac{2\left|\arctan k_1-\arctan k_2\right|}{\pi})(1-\frac{\left|b_1-b_2\right|}{b_{nor}}) \tag{4-2}$$

式中k_1和k_2为两条线段的斜率，两条线段斜率非常接近时，该项的值趋近于 1，b_1和b_2为两条线段的截距若截距差接近 0，表示两条线段位置接近共线，b_{nor}是归一化参数，用于标准化两截距之差 p 是两条线段的共线性概率 $p\to 1$ 表示两条线段高度共线，在本文中，阈值取为 0.95，即 $p\geq p_{thr}$（p_{thr}=0.95）时，两线段共线。

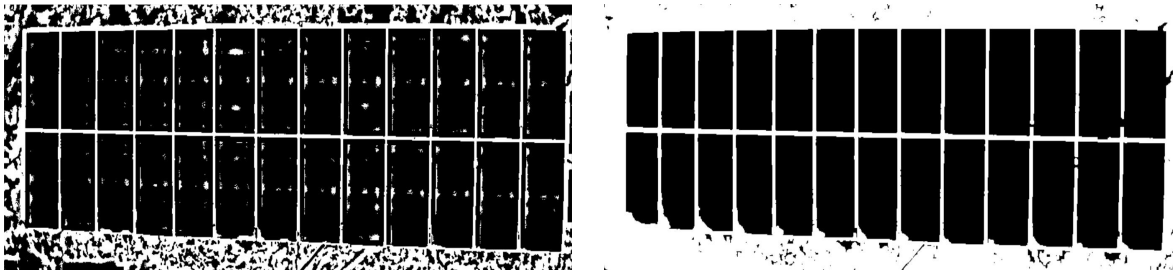
（5）根据线段之间的共线性关系对直线进行分组，以区分光伏组串不同边缘的线段集合。对每组线段坐标点，采用最小二乘法拟合直线，提取光伏栅线边缘的全局特征，并取最中心的检测结果在图中显示。



(a) 传统滤波 Canny 算子光伏边缘检测　　(b) 改进 Sobel 滤波器处理的光伏图像

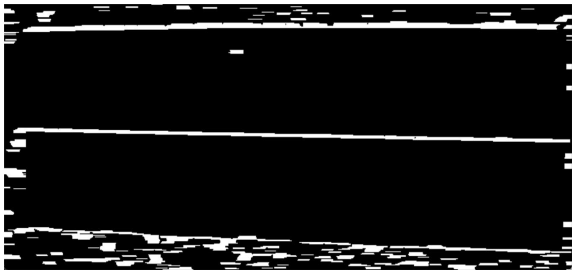
图 4-3 光伏边缘处理过程

由图可知，改进的 Sobel 滤波无论是在光伏组串中间连通的光伏栅线还是在各个光伏组件的四周边缘，相较于传统的滤波 Canny 算子光伏图像边缘检测都有着明显改善，保证了光伏栅线的连续性，为进一步的提线奠定了良好基础, 各个提线分步骤如下图所示。

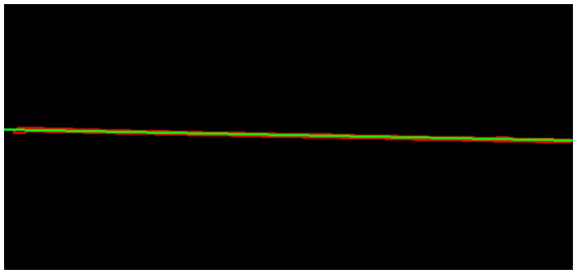


(a) 光伏图像 Otsu 阈值法二值化　　(b) 膨胀后的光伏图像

中国知网 https://www.cnki.net



(c) 改进的霍夫直线提取



(d) 中心栅线区域直线提取检测结果

图 4-4 光伏组串中心栅线提线过程

计算提取出来的直线线段与水平线之间的角度：0.891903°，将原图进行该角度的旋转以消除图片倾斜。

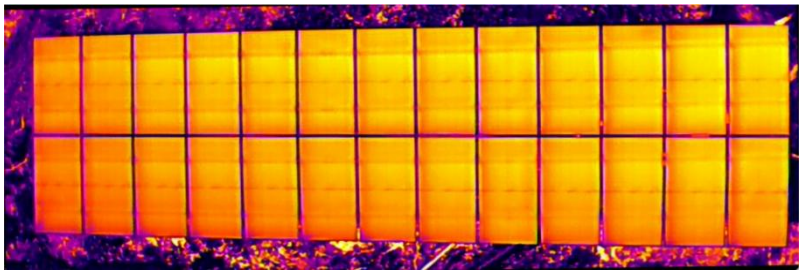
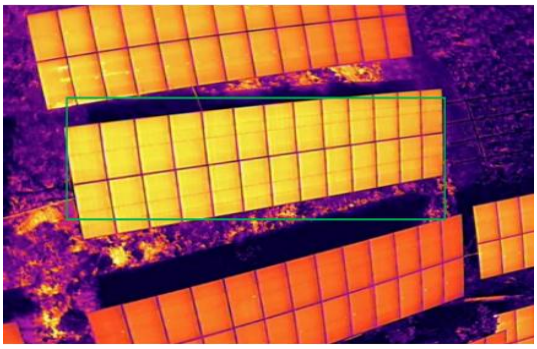
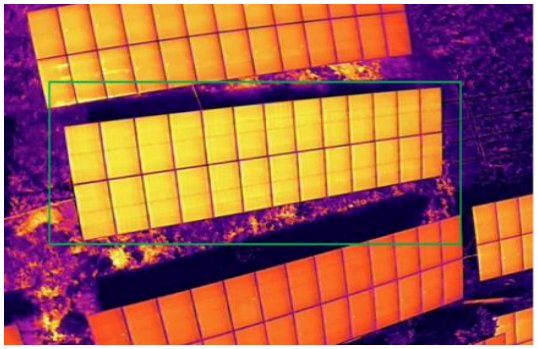


图 4-5 旋转后的光伏图像

光伏组串轮廓中提取直线信息可以作为理论飞行路径，未经旋转校正时，直接提取的最小外接矩形常因覆盖不全导致边界信息丢失；而扩大外接矩形范围又易引入其他组串及环境干扰信息，增加处理难度。相比之下经旋转校正后光伏组串姿态更加规整，外接矩形与组串边界契合度高，能够更精确地框定目标区域且无需额外扩大矩形范围，同时减少了噪声干扰，使框选更高效、准确。

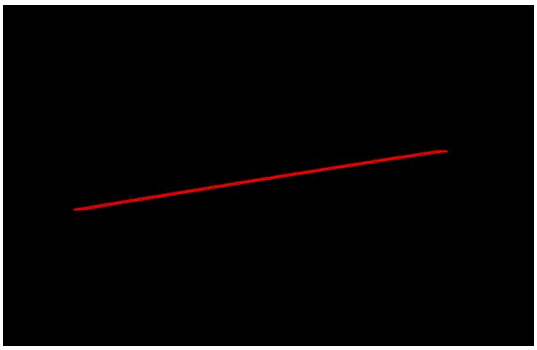


(a) 未旋转且外接矩形未扩展

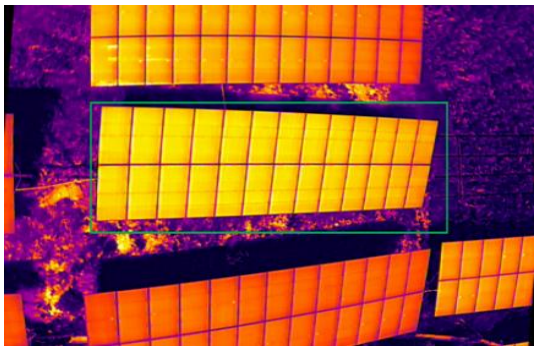


(b) 未旋转并扩展外部矩形

中国知网 https://www.cnki.net



(c) 改进提线方法



(d) 旋转而不扩展外部矩形

图 4-6 旋转与未旋转光伏组串对比图

4.2 K-means 算法描述

K-means 聚类是一种经典的无监督学习算法，其主要目的是将数据集中的样本划分为多个类别，使同类样本相似性高，而不同类别样本相似性低[87]。该算法通过将数据点分为 k 个簇，计算每个簇的中心点，并不断优化以最小化簇内样本与其中心点之间的距离，通过计算样本数据与各类别均值之间的距离来进行聚类划分，其流程图如下所示。

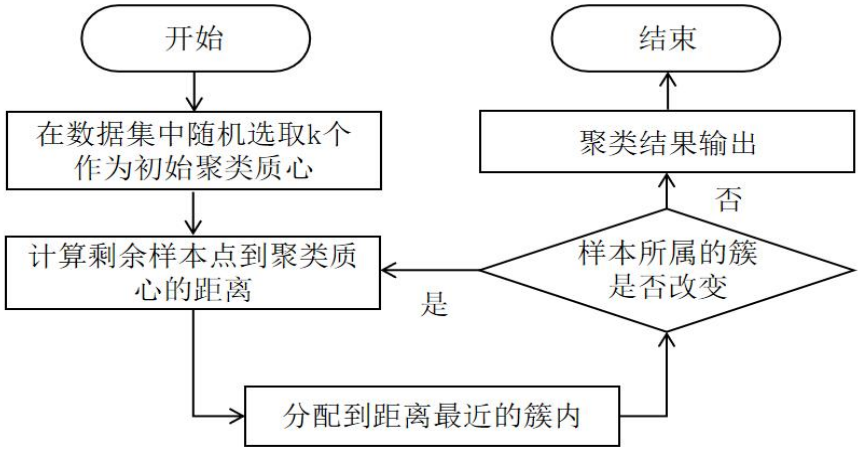


图 4-7 K-means 算法流程图

K-means 中常见的距离度量方式有曼哈顿距离、切比雪夫距离、闵可夫斯基距离、马氏距离等，本文用欧氏距离来度量样本和聚类中心点，欧氏距离公式如下：

中国知网 https://www.cnki.net

$$d\left(X_i,C_j\right)=\sqrt{\sum_{t=1}^{m}\left(X_{it}-C_{jt}\right)^2} \tag{4-3}$$

式中，X_i表示第 i 个样本数据，C_j表示第 j 个聚类中心点，X_{it}表示第 i 个样本数据的第 t 个属性，C_{jt}表示 j 个聚类中心点的第 t 个属性。

在传统 K-means 算法中，初始聚类中心是随机选取的，而初始聚类中心的选择对最终分割结果有直接影响。如果两个初始聚类中心之间的欧式距离过大或过小，可能无法实现分割目标，即组串内部样本特征值的紧凑性与组串间样本特征值的离散性[88]。对于光伏组串的分割问题，面对背景红外辐射度与光伏组串辐射度相似的大量数据点，直接使用 K-means 分割会导致错误较多，而且这一过程可能耗费大量时间，降低了算法的效率，从而影响实际应用效果。

4.3 改进的 K-means 光伏分割

传统的 K-means 算法虽然简单易用,具有较好的聚类效果，但仍存在一些不足，体现在聚类数的确定和初始聚类中心的选择方面。以此，本文提出一种改进 K-means 算法，首先利用选择增强的 HSV 颜色空间放大光伏组串与环境背景的辐射特性差异并对红外巡检图像进行初次分割，在分割之后利用角点检测对光伏组串进行拉伸放射变换，减小镜头畸变影响，最后在优化后的光伏组件上利用改进的 K 均值聚类对光伏组串进行进一步的识别提取，该方法检测准确率高，且对复杂多样的组串规格有较好的适应性。具体流程如下：

中国知网 https://www.cnki.net

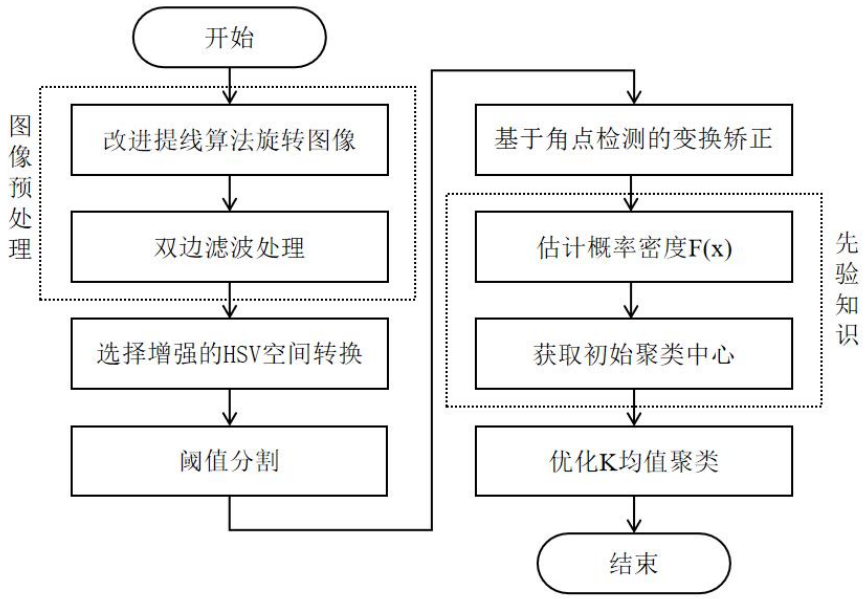


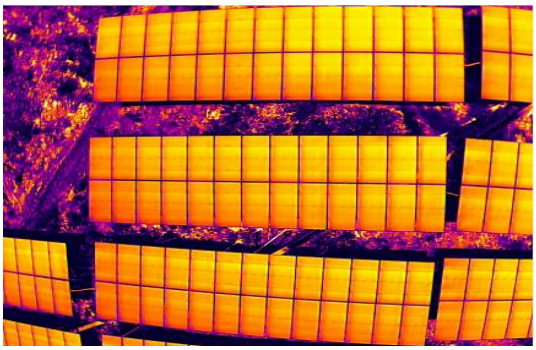
图 4-8 光伏组串检测算法流程图

4.3.1 图像去噪处理

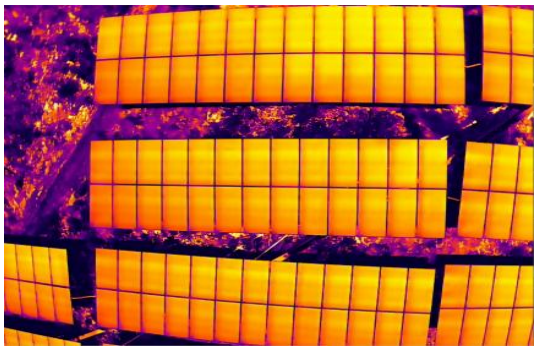
光伏区域多处于山间丘陵等地带，其环境相对复杂，干扰因素较多。为了更好的减小光伏板的环境影响，确定光伏板所在位置，在采集的图像中采用双边滤波的方法，从整体的角度降低外部环境的干扰，使光伏板内灰度值变化差异小有效信息得到保留，改善光伏板识别问题，从而达到保边去噪的目的[89]。

在图像的平坦区域，由于相邻像素的特征差异较小，因此值域的权重接近 1，这时空间高斯权重变为主导，相当于对这一区域进行标准的高斯滤波，实现平滑处理。相反，在边缘区域由于相邻像素的差异性较大，空间权重的影响减小，而尺度权重变得更加显著。红外图像在采集和传输过程中，受到传感器性能、环境条件以及设备的影响，红外图像一般具有细节模糊、对比度较低和噪声较大的问题[90]，而双边滤波中两种权重的共同作用使得光伏边缘细节得以保留。

中国知网 https://www.cnki.net



(a) 红外图



(b) 双边滤波过后红外图

图 4-9 滤波前与滤波后对比

由图 4-9 以及第三章 3.1.1 中实验分析可知，滤波之后的红外光伏图像相较于原图边缘更加明显，光伏组串更加平滑完整，相对于背景也更容易区分。

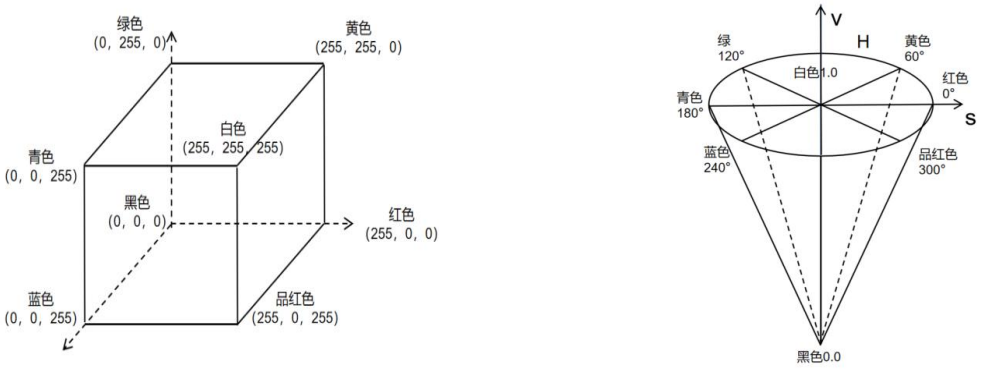
4.3.2 基于选择增强的图象色彩空间的光伏组串处理

RGB 颜色通道是目前最为基础且广泛使用的颜色模式之一。由于该模式基于红色、绿色和蓝色三种主要颜色，因此也被称为三基色通道模式。其核心原理是通过线性组合这三种基本颜色分量生成其他颜色，从而使得任何一种颜色都与这三种分量密切相关[91]。在图像处理中，RGB 颜色通道因其简单和普适性而得到了广泛应用，但对于红外光伏组串而言，光伏组串反射的红外光波属性与部分周围环境反射的红外光波相似，而 RGB 空间在非控制条件下对光照的改变敏感，三种基本颜色分量会被光照变化严重影响，使得在光伏组串图像检测上产生较大误差。

HSV（Hue, Saturation, Value）颜色空间比 RGB 更贴近人类对颜色的感知方式，更容易将色调与亮度信息分离。相比于普遍的 RGB 通道，HSV 通道在图像处理中的表现更优，它能够更准确地反映人眼对环境色彩的理解，在颜色对比和追踪方面表现突出。HSV 颜色通道由三部分组成：色相（H）、饱和度（S）和明度（V）。色相（H）用于描述颜色的倾向，范围为 0°到 360°；饱和度（S）表示颜色的纯净程度，范围为 0.0 到 1.0，值越高表明颜色越浓；明度（V）专门表示亮度，与 RGB 中每个分量都受亮度影响不同，HSV 用独立分量表示亮度，范围为 0 到 1，纯黑色时

中国知网 https://www.cnki.net

亮度为 0，纯白色时亮度为 1。HSV 色彩空间能够直观地表达颜色的鲜明程度、色调和明暗关系，且色彩表现方式更接近人眼感知，常被用于对指定颜色物体的图像分割任务中。



(a) RGB 颜色模型　　(b) HSV 颜色模型

图 4-10 颜色空间模型

图像的 RGB 色彩空间转换为 HSV 色彩空间[92]具有直观、分离亮度和颜色信息、稳定的色彩感知以及方便的色彩选择和分析等优势，使得在光伏组串处理和颜色调整方面更加灵活和方便[93]。图为 RGB 和 HSV 颜色空间模型，HSV 颜色通道为 RGB 颜色通道映射而来，两者的映射变换公式为：

$$H=\begin{cases}60^\circ\times\dfrac{G-B}{\Delta}+0^\circ & Max=\mathrm{R}\\ 60^\circ\times\dfrac{B-R}{\Delta}+240^\circ & Max=\mathrm{G}\\ 60^\circ\times\dfrac{R-G}{\Delta}+240^\circ & Max=\mathrm{B}\\ 0^\circ & \Delta=0\end{cases} \tag{4-4}$$

$$S=\begin{cases}0 & Max=0\\ \dfrac{\Delta}{Max} & Max\neq 0\end{cases} \tag{4-5}$$

$$V=Max(\mathrm{R},\ \mathrm{G},\ \mathrm{B}) \tag{4-6}$$

式中 Max 等于 R，G，B 中的最大者，Δ 为最大者和最小者之差，R、G、B 为 RGB 颜色空间的三基色通道的分量值。HSV 通过光伏反射和周

中国知网 https://www.cnki.net

围环境漫反射亮度和饱和度上尚有差异的特点通过表 4-1 的分割阈值对光伏图像进行初次分割。

表 4-1 HSV 颜色通道分割阈值

	黑	灰	白	红	橙	黄	绿	青	蓝	紫
HMIN	0	0	0	0/156	11	26	35	78	100	125
HMAX	180	180	180	10/180	25	34	77	99	124	155
SMIN	0	0	0	43	43	43	43	43	43	43
SMAX	255	43	30	255	255	255	255	255	255	255
VMIN	0	46	221	46	46	46	46	46	46	46
VMAX	46	220	255	255	255	255	255	255	255	255

将图像转化为 HSV 后，光伏组串大部分信息都存在于黄色光亮的通道中，光伏黄色区域对应的 HSV 阈值范围为 H：26~34，S：43~255，V：46~255。

在 HSV 的基础上，为进一步提高检测效率，本文提出一种基于选择增强的图像检测算法，选择对光伏板区域进行增强处理，使得检测结果更加精准，增加检测效率。首先，从颜色空间中提取明度 V 分量，由于明度图中各个像素点之间存在一定的关联性，为了更好地保持明度图中像素之间的关系，在计算高斯权重时引入欧氏距离[94]，公式如下：

$$G(p,q)=exp[-\frac{D(p,q)}{2\sigma^2}] \tag{4-7}$$

其中，$D(p,q)$ 表示明度图中两个像素点之间的欧氏距离，p,q 为两个不同的像素点，σ 是标准差，通常设为 3。为了增强图像平滑度，使用高斯滤波器对像素点在 x、y 方向的梯度进行处理，x、y 的平滑权重为：

$$\begin{cases} \omega_{x,p}=\dfrac{T_{x,p}}{\left|\left(\partial_x V\right)_p\right|+\varepsilon} \\ \omega_{y,p}=\dfrac{T_{y,p}}{\left|\left(\partial_y V\right)_p\right|+\varepsilon} \end{cases} \tag{4-8}$$

中国知网 https://www.cnki.net

$$\begin{cases} T_{x,p}=\sum\limits_{q\in\Omega_p}\dfrac{G(p,q)}{\left|\sum\limits_{q\in\Omega_p}G(p,q)E_{xq}\right|+\varepsilon},\ E_{xq}=\left(\partial_x V\right)_q \\ T_{y,p}=\sum\limits_{q\in\Omega_p}\dfrac{G(p,q)}{\left|\sum\limits_{q\in\Omega_p}G(p,q)E_{yq}\right|+\varepsilon},\ E_{yq}=\left(\partial_y V\right)_q \end{cases} \tag{4-9}$$

式中，E_{xq}、E_{yq}为点 q 在 x 和 y 上的导数，$G(p,q)$为 p 与 q 两点欧氏距离的高斯权重 $T_{x,p}$，$T_{y,p}$为 x、y 上的边缘平滑权重，ε 为缓和系数，$G(p,q)E_{xq}$、$G(p,q)E_{yq}$为高斯处理后点 q 在 x、y 方向上的导数。在知晓某像素点的平滑权重后，结合边缘平滑权重，得到增强因子与明度图的差异，调整增强因子使其与明度图相似，并在边缘区域保持原状，采用公式：

$$\sum_p\left\{\left(V_p-L_p\right)^2+\lambda\left[\omega_{x,p}\left(\partial_x L\right)_p{}^2+\omega_{y,p}\left(\partial_y L\right)_p{}^2\right]\right\}=0$$
$$F_{xp}=\left(\partial_x L\right)_p, F_{yp}=\left(\partial_y L\right)_p \tag{4-10}$$

式中 λ 为权重系数，取值为 0.6，L 为选择增强因子，F_{xp}，F_{yp}为选择增强因子中像素点 p 在 x、y 上的导数。为了避免增强过程中导致图像变色，需要抑制图像的色相（H 值）的变化，以保持图像色彩的自然性，计算公式为：

$$H_i'=(1-\alpha)H_i+\alpha\cdot L_i \tag{4-11}$$

$$L'=L\cdot\alpha \tag{4-12}$$

其中，α 为抑制因子，通常设为 0.85，i 为组串中的像素点；H_i 为图中 i 点的 H 值，L_i 为增强因子中 i 的数值，L' 为抑制处理后的选择增强因子。

通过对光伏图像的选择增强，使得光伏组串与背景区域区别更为显著，提高了对比度，减少背景环境的干扰，增强了后续光伏组串检测的精准性和效率，同时光伏组串的选择增强平滑了光伏缺陷部分和正常部分的色域亮度，使得后续组件聚类结果更加准确。

中国知网 https://www.cnki.net

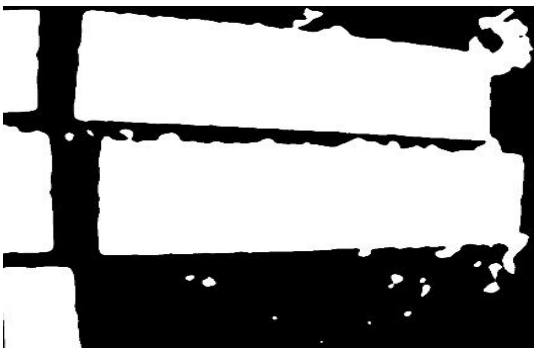
4.3.3 基于自适应阈值分割的光伏组串处理

在对 HSV 色彩空间进行选择增强后，传统的色调通道阈值的选取对于环境复杂多样的光伏组串来说效果并不佳，而模板匹配在面对光伏组串规格不一时又难以将光伏组串分割完整。针对此现象本文采用一种基于局部统计特性的自适应阈值分割方法，该方法通过计算窗口内像素的均值与标准差来确定二值化阈值，像素值大于阈值的视为前景像素，小于或等于阈值的则视为背景像素。最后，通过应用二值化操作，将图像分割为前景和背景区域。阈值法的数学表达如式所示[95]：

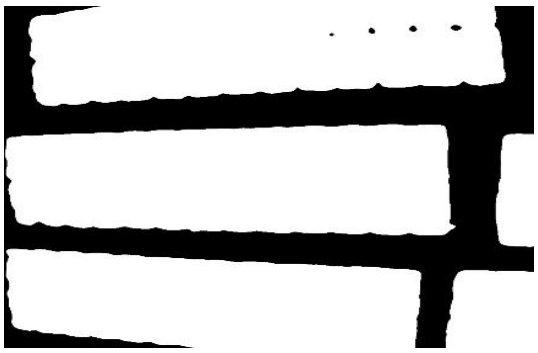
$$g(x,y)=\begin{cases}255, f(x,y)\geq T\\ 0, \quad f(x,y)\leq T\end{cases} \tag{4-13}$$

其中 $f(x,y)$代表输入的图像，T 代表所设计的阈值，$g(x,y)$代表输出的图像。

在阈值分割之后通过形态学腐蚀膨胀平滑图像去掉光伏组串及周边干扰。先通过腐蚀将光伏组串内连接栅线经行掩盖腐蚀，避免在阈值分割中出现分割不完整的现象，随后再经过膨胀对光伏板边缘及连接线经行填充，使之形成完整的组串，此时将阈值中黄色高亮通道进行阈值分割，并以最小外接矩形的形式在原图呈现，如图所示：

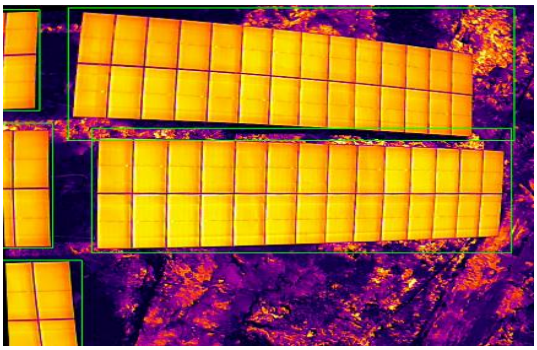


(a) 分割图 1

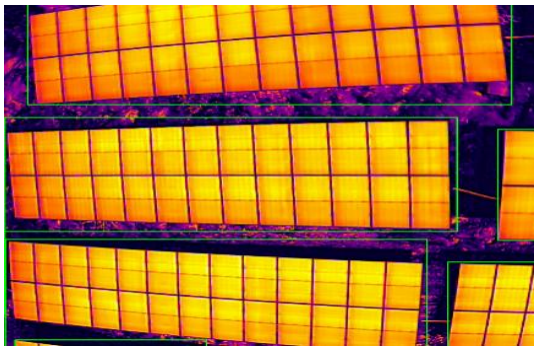


(b) 分割图 2

中国知网 https://www.cnki.net



(c) 对应原图框定结果 1



(d) 对应原图框定结果 2

图 4-11 分割效果图与结果框定

4.3.4 基于角点检测的光伏组件变换矫正

光伏巡检系统中，光伏巡检红外图像受到相机拍摄角度、镜头畸变、无人机轨迹偏移等多方面因素的影响，导致拍摄的光伏板图像可能存在视角扭曲和几何变形，难以直接进行后续的分析与处理。从光伏板在初次分割后，其角点特征相较于复杂的背景更加明显这一点出发，可以通过基于角点检测的方法，提取光伏板关键点信息，结合透视变换技术对光伏组件图像进行仿射变换矫正，从而消除图像的几何畸变，恢复光伏板的标准矩形形态，为后续操作奠定基础。

Shi-Tomasi 角点检测在 Harris 角点检测的基础上改进而来，主要优点集中在角点质量评估标准的改进和排除噪声影响的鲁棒性，在光伏角点检测上精度更高，Shi-Tomasi 角点检测通过计算图像局部梯度的协方差矩阵 M：

$$M = \begin{bmatrix} \sum I_x^2 & \sum I_x I_y \\ \sum I_x I_y & \sum I_y^2 \end{bmatrix} \tag{4-14}$$

进一步计算角点响应值 R：

$$R = \det(M) - \alpha \cdot (trace(M))^2 \tag{4-15}$$

其中α为经验系数，用于调整响应值的敏感性，通常取值为 0.04。当 R 大于阈值时，当前位置被认为是角点，为了确定图像的四个关键角点（对

中国知网 https://www.cnki.net

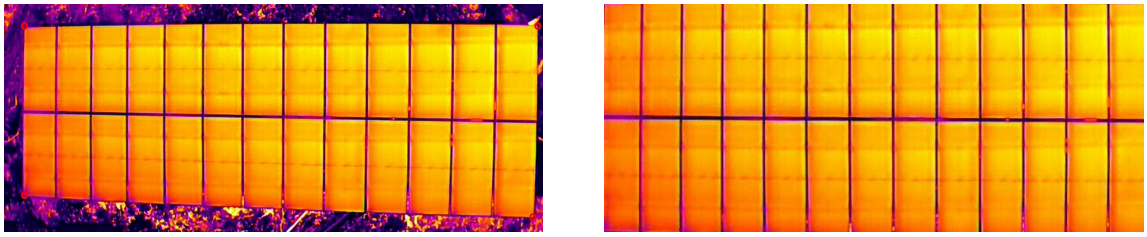
应于目标视角光伏组串的四个顶点左上、左下、右上、右下），需要从检测到的所有角点中找到离原图四个顶点最近的点。通过计算欧几里得距离：

$$d(p_i,q_j)=\sqrt{(x_i-x_j)^2+(y_i-y_j)^2} \tag{4-16}$$

逐一比较各角点与图像四角的距离，并选择最近的点作为关键角点。随后，结合关键角点和目标图像顶点计算透视变换矩阵 H，变换公式为：

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = H \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \tag{4-17}$$

解出参数后，对原图经行透视变换矫正，通过透视变换矫正，可以有效地消除光伏组件图像因拍摄角度、无人机轨迹偏移或镜头畸变造成的几何扭曲，使光伏板图像恢复为标准矩形形态。



(a) 光伏角点检测　　(b) 变换矫正

图 4-12 基于角点检测的光伏组件变换矫正

4.3.5 初始聚类中心及 K 值的确定

传统 K-means 算法随机选取 k 个样本作为初始聚类中心，通过迭代更新聚类中心，直至中心点稳定，但初始聚类中心的随机性对聚类结果影响较大[96]。针对随机选取的中心点问题，本文采用了基于灰度概率密度函数确认中心点的方法，在计算后的灰度概率密度函数中，通过寻找函数的极值点来提取灰度特征点，灰度特征点反映了灰度分布中的显著变化区域，从而作为划分簇的重要依据。

灰度概率密度函数定义为灰度值出现的概率，可以通过统计图像中各灰度值的分布获得。公式如下：

中国知网 https://www.cnki.net

$$f(x)=\frac{N_x}{N_{\text{sum}}},\quad x\in[0,255] \tag{4-18}$$

式中 N_x 为灰度值 x 的像素数量，N_{sum} 为图像中所有像素的总数。灰度概率密度函数满足归一化的条件为：

$$\sum_{x=0}^{255}f(x)=1 \tag{4-19}$$

通过概率密度函数 $f(x)$，可以反映图像中灰度值的全局分布特性，进一步为聚类分析提供先验知识。但由于缺乏适当的函数，无法直接使用通过数据统计得到的灰度概率密度，本文通过采用 Parzen 窗[97]对其进行估算，使其变得可用。在灰度值范围[0,255]内，样本灰度值分布可以通过灰度概率密度函数 $f(x)$表示，可以通过积分公式求得样本灰度值落在某一灰度区间 D 中的概率 P：

$$P=\int_D f(x)dx=\int_{D_{\min}}^{D_{\max}}f(x)dx \tag{4-20}$$

灰度区域 D 的宽度 h 足够小时，认定为小区间的概率近似，区间内概率密度函数 $f(x)$的值基本恒定，此时 P 可以表示为：

$$P\approx\int_D f(x)dx\approx f(x)\cdot h \tag{4-21}$$

公式表示在小区间 D 内，概率等于概率密度 $f(x)$与区间宽度 h 的乘积。

离散样本假设有 N 个样本点，其中落在灰度区间 D 内的样本数为 k，则区域 D 的灰度概率 P 可由样本数比例表示：

$$P=k/N \tag{4-22}$$

式中，k 是灰度区间内的样本数量，N 是样本总数。

概率密度估计的效果受核函数 $K(x)$的影响[98]，为了平滑估计样本的灰度概率分布，本文采用高斯核函数 $K(x)$，高斯核函数的表达式为：

$$K\left(\frac{x-x_i}{h}\right)=\frac{1}{\sqrt{2\pi}}\exp\left(-\frac{(x-x_i)^2}{2h^2}\right) \tag{4-23}$$

其中 x 为当前灰度值，x_i 为样本数据点，h 为平滑参数。基于核函数的定义，利用所有样本点对灰度概率密度进行估计：

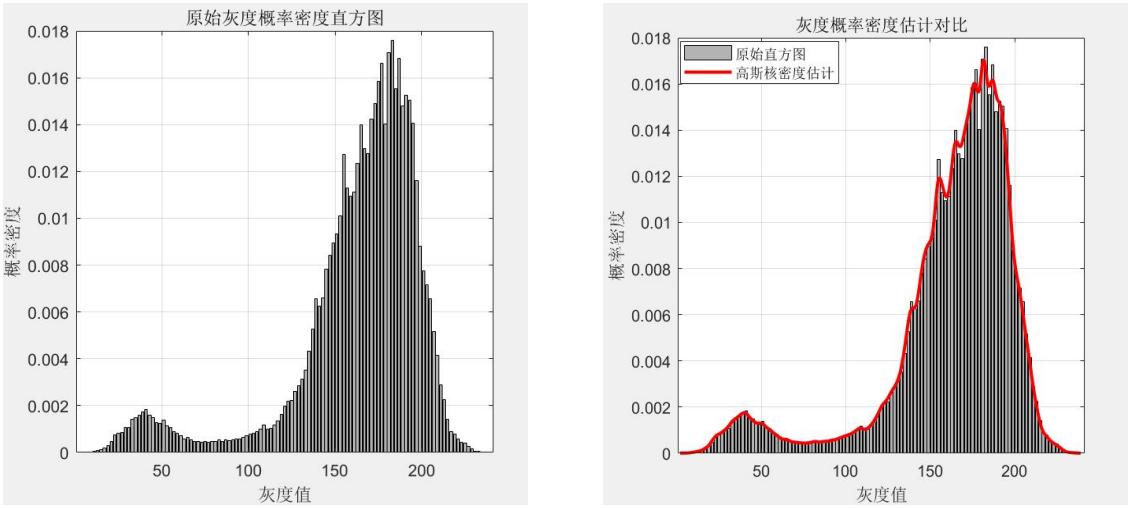
中国知网 https://www.cnki.net

$$k=\sum_{i=1}^{N}K\left(\frac{x-x_i}{h}\right) \tag{4-24}$$

通过上式，计算任意灰度值 x 处的核密度函数值，同时结合核函数和所有样本点，灰度概率密度函数 $F(x)$可以表示为：

$$F(x)=\frac{1}{N\cdot h}\sum_{i=1}^{N}K\left(\frac{x-x_i}{h}\right) \tag{4-25}$$

公式通过对每个样本点的概率贡献求和，得到任意灰度值 x 处的平滑概率密度，最终得到的灰度概率密度函数 $F(x)$，对于矫正后的光伏组串高斯核函数估计灰度概率密度图如下所示：



(a) 原始灰度概率密度直方图　　(b) 高斯核密度估计对比

图 4-13 高斯核密度估计对比前后图

由图可知，通过高斯核函数对样本点贡献进行加权求和，反映图像灰度分布的平滑趋势，减少了噪声对结果的影响，实现平滑的概率密度估计。

聚类算法中聚类数 k 的确定十分重要，聚类效果受到 k 值影响[99]，常用的 k 值确定有轮廓系数法、肘部法、Gap Statistic 法等。在之前光伏组串通过增强矫正后，光伏各个组件以及变得清晰可见，为了快速聚焦于组件与栅线，提高检测效率，将 k 值设置为 2，当 k=2 时，算法的聚类复杂度较低，结果易于解释，能够快速分割出关键区域。

在 k 值确定后，根据聚类数 k，将特征点范围等分为 k 个区域，每个

中国知网 https://www.cnki.net

区域宽度为 t，计算公式如下：

$$t=\frac{\theta_{\max}-\theta_{\min}}{k} \tag{4-26}$$

其中$\theta_{\max}$、$\theta_{\min}$分别是最大和最小的特征点灰度值。

在特征点集合中，比较任意两个特征点的灰度值差异θ_i、θ_j，如果两个特征点的灰度值变化幅度小于设定的阈值 t，则认为这两个特征点属于同一个类别：

$$|\theta_i-\theta_j|<t,\quad \theta_i,\theta_j\in[\theta_{\min},\theta_{\max}] \tag{4-27}$$

将满足条件的特征点分为 k 类，记为V，其中$i=1,2,\ldots,k$。每个类簇包含在同一区域内的灰度特征点。在每个类簇V中，选取灰度概率密度最大的特征点作为该类的初始聚类中心如图所示，公式如下：

$$\max(f(x_i))\rightarrow x_i,\quad x_i\in V_i,i=1,2,\ldots,k \tag{4-28}$$

$f(x_i)$表示特征点x_i的概率密度值，x_i是类簇V中概率密度值最大的特征点。

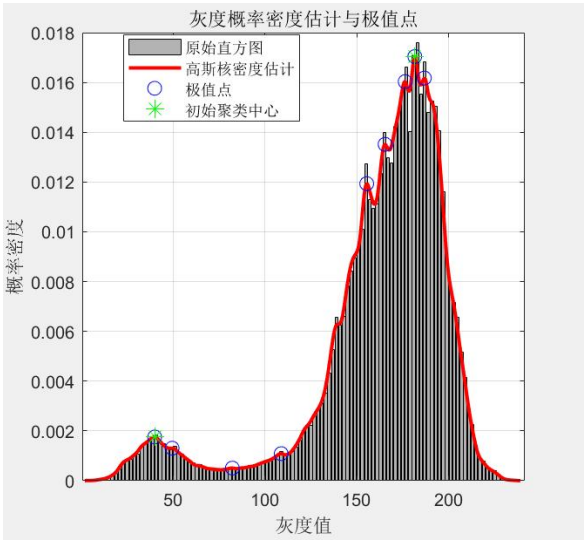
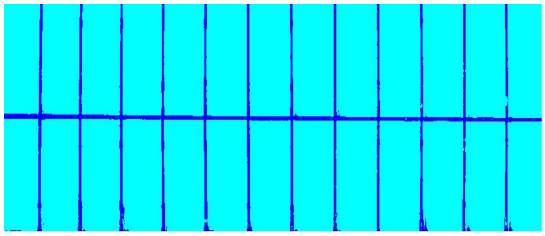


图 4-14 光伏组串检测算法流程图

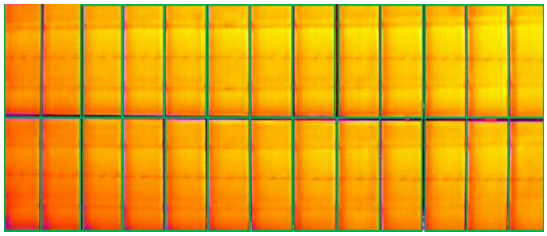
初始聚类中心以及 k 值确定后，采用最小欧几里得距离原则[100]，将样本点分配到距离最近的聚类中心所在的簇中，并通过计算每个簇内样本点的均值更新聚类中心，随后算法迭代进行，直到新旧聚类中心的变化量小于设定阈值或达到收敛条件，样本数据与相应聚类集之间的误差

中国知网 https://www.cnki.net

平方和（SSE）达到最小值，至此聚类中心稳定，聚类结果用最小外接矩形框在原图中表示。



(a) 聚类结果

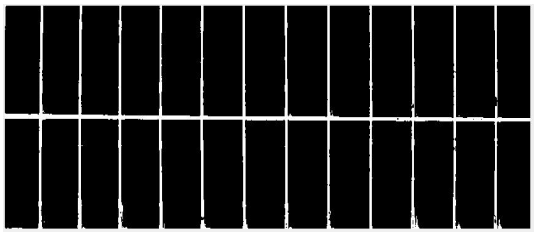


(b) 结果框定

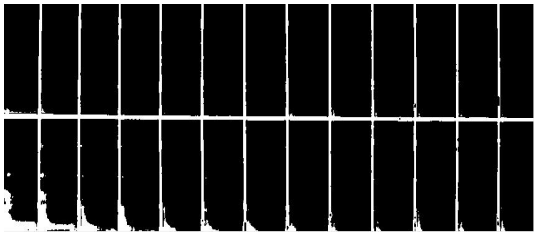
图 4-15 聚类结果与框定

4.4 实验结果与分析

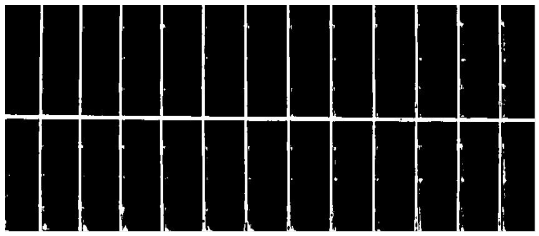
为验证本方法的可行性，本文将改进的光伏检测分割与传统 k 均值聚类算法、自适应节点的 B 样条函数最小二乘拟合、改进的 Otsu 方法做对比，对比图如下所示：



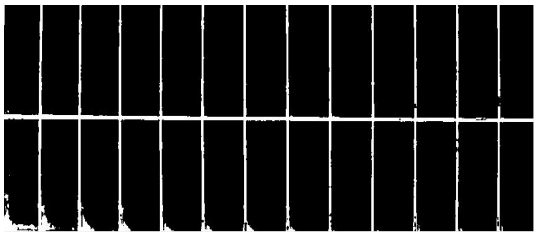
(a) 本文所用方法



(b) 传统 k 均值聚类算法



(c) 改进的 Otsu 方法



(d) 自适应 B 样条函数最小二乘拟合

图 4-16 结果对比图

由图可知传统 k 均值聚类算法（图 b）由于初始聚类中心随机，分割结果不稳定，光伏板与背景区分效果较差，且边缘模糊，容易受到噪声干扰；改进的 Otsu 方法（图 c）在分割结果中存在大量噪声点，光伏板区域出现碎片化现象，分割边缘不平滑，整体分割精度受到较大影响；

中国知网 https://www.cnki.net

自适应 B 样条函数最小二乘拟合方法（图 d）的分割效果相比传统的 k 均值聚类方法有所改进，但是还是存在一定的误差，难以准确识别光伏板区域。而本文所提出的方法的分割效果最佳，光伏板区域与背景区域分离清晰，轮廓完整，边缘检测准确，且噪声点少，表现出较高的分割精度和鲁棒性。

相比于传统的聚类，本文从信息熵（Information Entropy，IE）、戴维森堡丁指数（Davies-Bouldin index，DBI）以及轮廓系数（Silhouette Coefficient，SC）等指标来进行定量衡量，其中信息熵主要用于衡量聚类结果的信息不确定性。IE 越大，表明类别分布越均匀，聚类的不确定性越高；DBI 是衡量类内相似性（紧密度）与类间分离度（分散性）的比值，DBI 越小，表明聚类越紧凑，不同聚类分隔度越高，聚类质量越好；SC 为衡量个体数据点在聚类中的紧密程度和类间分离度，SC 值越高数据点更接近于自己的簇中心，聚类效果越好。相比于传统的 K-means 算法，本文改进的聚类效果效果明显，如表 4-2 所示其 IE 和 DBI 的值分别降低 2.9%与 2.1%，SC 系数增加 0.2%。

表 4-2 传统聚类与改进聚类各个评价指标

algorithm	IE	DBI	SC
K-means	3.5792	0.4724	0.8239
Improved K-means	3.4754	0.4625	0.8256

为了比较传统 K-means 和改进 K-means 的计算速度，本研究进行了 100 次迭代的对比实验。图中虚线表示传统 K-means 的迭代次数，灰色实线表示其平均值，蓝色实线则表示改进 K-means 的迭代次数。从图中可见，传统 K-means 因为随机初始化簇中心，导致迭代次数波动较大，计算速度较慢。而改进的 K-means 通过更合理的初始簇中心选择，使得迭代次数稳定,如图 4-17 所示。

中国知网 https://www.cnki.net

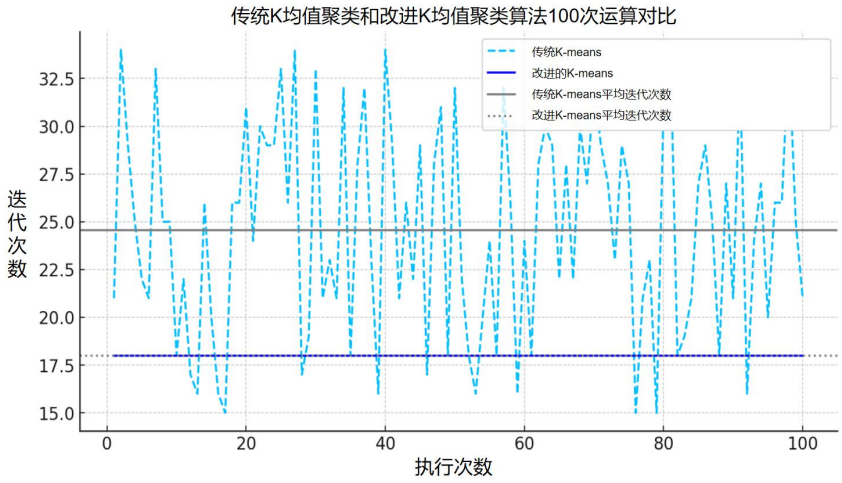


图 4-17 传统聚类与本文改进迭代速度对比

4.5 本章小结

本章主要介绍了基于静态单张的红外光伏组串检测方法，针对传统检测算法在处理过程中存在的不足，提出了一系列改进方案。首先利用基于改进霍夫直线检测算法对光伏组串图像进行旋转矫正，有效解决了光伏组件在拍摄过程中产生的倾斜问题，随后利用基于选择增强的 HSV 颜色空间的处理方法，进一步增强光伏组串与背景的辐射特性差异从而提高检测精度；通过高斯核概率密度估计方法确定初始聚类中心，将 K 值固定为 2，从而优化传统 K-means 聚类算法。实验结果表明本文方法在光伏组串检测分割中具有明显优势，能够有效抑制噪声、提高边缘检测精度，且对复杂背景具有较强的适应性。分割结果优于传统 K-means 算法、改进的 Otsu 方法及自适应 B 样条函数最小二乘拟合方法。

中国知网 https://www.cnki.net

第 5 章 基于视频运动信息的光伏组串检测定位

无人机在对单张光伏板图片进行拍摄时，通常需要经历减速、停止、加速的周期性过程，这种方式虽然能够保证每张图片的清晰度，但在大规模光伏场站的巡检中，因拍摄过程中频繁的动态调整导致整体巡检时间较长，效率十分低下，难以满足光伏场站的实际运维需求。针对这一问题，本章提出了一种基于视频运动信息的光伏组串检测与定位方法。通过对无人机飞行路径的合理规划，将无人机设置为低速匀速飞行状态，以连续录像的方式对光伏组串进行采集，从而避免频繁的动态调整带来的效率损失。

经过多次实验大疆 M300 无人机在满电情况下对光伏组串单张图采集一轮采集的图像约为 100~120 张左右即巡检 100~120 块光伏组串，此时，无人机就得返回充电或是更换电池，若采用匀速视频的采集方式，单次采集的光伏板块约为 400 多块，相比于单张巡检，视频巡检速度约为 4 倍。但是视频巡检过程中也会引发新的问题：

（1）同一个光伏组串可能在视频中出现多帧的情况，如何确定最佳帧使其与相应光伏组串对应？

（2）无人机在飞行过程中虽然轨迹是已知的，但是但飞行过程中不可避免地涉及转弯等非直线运动，如何确定每一个光伏组串对应光伏分布图的哪个设备？

为解决此问题，本章设计最优帧提取，用于筛选最能代表光伏组串的关键帧，以及根据改进的光流法进行设备定位。

5.1 无人机关键帧提取分析

在光伏巡检过程中，通常会生成大量的视频数据，其中包含许多冗余信息。如何高效地浏览这些视频数据，将其转化为浓缩的关键帧图像，是提升巡检效率的重要研究方向。关键帧是对视频内容的核心代表，提取关键帧可以将视频数据转化为更简洁的形式，便于快速理解和分析视

中国知网 https://www.cnki.net

频中的光伏内容。这项技术在光伏设备的目标检测中尤为关键。

5.1.1 基于镜头边界的关键帧提取

基于镜头边界的关键帧提取算法是视频检索领域中最早发展并应用的一种方法[101]，一般只抽取首帧、末帧、尾帧三帧，该方法存在明显的局限性，当视频内容发生剧烈变化或场景呈现高度复杂性时，仅仅依靠镜头的首帧和尾帧往往难以全面反映视频中的信息变化。由于这种方法在处理复杂场景时表现出较大的局限性，难以满足当前日益增长的多样化应用需求，尤其是在现代社会对视频内容理解和分析精度提出更高要求的背景下，其适用性显得愈发不足。

5.1.2 基于运动信息的关键帧提取

基于运动信息的关键帧提取被许多学者用于视频分析与处理领域，该方法通过物体运动特征进行关键帧提取[102,103]，首先在视频镜头中分析物体运动特性并计算光流量，选光流移动量最小的帧作关键帧。光流法可量化视频帧运动量，精确提取反映运动特征的关键帧，其运动量的计算公式如下所示：

$$M(k)=\sum|L_x(i,j,k)|+|L_y(i,j,k)| \tag{5-1}$$

其中 $M(k)$ 表示第 k 帧率的运动量，$L_x(i,j,k)$，$L_y(i,j,k)$ 分别表示第 k 帧中像素点 (i,j) 在 x 和 y 的光流分量。通过对视频中每一帧的运动量进行计算，可以选取运动量最小的帧作为关键帧，具体公式如下：

$$M(k_t)=\min[M(k)] \tag{5-2}$$

基于光流的关键帧提取方法具有较强的理论基础，能够有效捕捉视频帧中运动量的变化，但是这种方法也存在一定的局限性。由于其计算过程复杂，涉及大量光流运算，计算成本相对昂贵且面对众多光伏组串时传统光流方向难以判断。此外，该方法还对视频中物体运动的局部特征较为敏感，当视频中存在复杂运动或多目标交互的场景时，导致结果

中国知网 https://www.cnki.net

准确率降低。

5.1.3 基于聚类的关键帧提取

聚类是一种在分类问题研究中常见的统计方法，同时也是数据挖掘中广泛应用的技术之一。其核心思想是按数据相似性将数据集分为若干簇，使同簇数据相似度高，不同簇数据差异明显。在基于聚类的关键帧提取算法中，首先对视频帧特征分析并按规则分簇，再从每簇中选最能代表其特征的帧作关键帧。

方法的实现步骤主要包括以下几点：首先初始化一个或多个聚类中心，通常从视频帧中随机选取一个帧作为初始中心。其次逐帧计算每一帧与当前聚类中心的相似度，根据相似性将其归类到已有簇或作为新簇的中心。如果某一帧的相似性超出设定的阈值，则将其作为新簇的中心点。最后从每个聚类中选择距离聚类中心最近的帧，作为该簇的代表性关键帧，在本文中，聚类的方法选择与第四章相同，同为 K-means 聚类，即对每一帧提取颜色直方图作为特征后使用 K-means 聚类方法将所有帧特征分成若干簇，并从每个簇中选取最能代表该簇的关键帧。

聚类过程能够有效避免关键帧的重复提取，同时通过聚类分析可以总结出视频帧的全局特征，能够有效避免漏帧现象，基本确保提取到足够数量的关键帧。许多实验结果显示，基于聚类的关键帧提取算法在帧数较多、时长较长的视频场景时，相对比其他方法略有优势。

5.1.4 基于无人机速度与视频帧率的动态设置抽帧方案

基于无人机速度与视频帧率的动态设置抽帧方案即根据无人机速度与视频帧率，对拍摄的视频抽帧进行调整。要实现动态设置抽帧方案并让目标出现在抽帧图片中，需要综合考虑无人机飞行速度、拍摄帧率、抽帧频率，通过分析无人机的飞行参数和目标的分布规律，设计合理的抽帧间隔，使得抽取的图像尽量的确保目标位于图像的中心区域，具体分析和实现方法如下：

中国知网 https://www.cnki.net

假设无人机以恒定速度 v 行驶，目标之间的距离为 d，无人机到达下一个目标所需时间即为：

$$t_d = \frac{d}{v} \tag{5-3}$$

根据相机拍摄帧数 f，一段时间 t_d 内拍摄的总帧数 M 为：

$$M = f \cdot t_d \tag{5-4}$$

在这些帧中，目标帧对应于目标中心即关键帧，其帧编号为：

$$n_c = f \cdot t_d = \frac{f \cdot d}{v} \tag{5-5}$$

假设目标之间的时间间隔为 td ，则抽帧间隔帧数满足：

$$k = \frac{f \cdot t_d}{n} \tag{5-6}$$

以雄里坡光伏电站为例，雄里坡光伏电站采用 550W 光伏组串，长度约为 2.2 米，加上光伏板之间的间隔长度约为 2.5 米，无人机初始速度设置为 0.5 米每秒，相机帧率设置为 30fps，第一帧以光伏板中间关键帧开始，根据公式无人机到达下次目标所需时间为 5s，总帧数为 150 帧，则设置 150 帧为关键帧，每隔 150 帧抽一帧。

5.1.5 评价指标与实验分析

当前，大多数关键帧提取方法的评价标准仍以主观感受为主，缺乏统一的客观评价指标，本文采用了准确率(P)和查全率(R)两个评价指标，准确率表示提取出的关键帧中被正确判定为关键帧的比例，查全率表示视频中所有应提取的关键帧中实际被提取的比例。由于查准率和查全率存在一定的权衡关系，因此本文进一步通过两者的调和均值（F 值）来综合衡量算法性能。准确率、查全率和调和均值的计算公式分别如下：

$$P = \frac{X}{X + Y} \tag{5-7}$$

中国知网 https://www.cnki.net

$$R=\frac{X}{X+C} \tag{5-8}$$

$$F=\frac{2\cdot R\cdot P}{R+P} \tag{5-9}$$

式中 X 表示正确帧的数目、Y 表示错误帧的数目、C 表示漏判关键帧数目。F 的值为 0 到 1 之间，F 值越高表示性能越好。

为验证几种算法的可行性，对几种算法进行实验，选取的视频数据为云南省祥云县雄里坡光伏电站巡检的部分视频，实验算法在 Windows、VS2017 和 Opencv3.4 环境下实现，下图展示了视频在不同算法下的关键帧，其中红色框表示错误选取的帧，蓝色框表示冗余帧:



图 5-1 基于运动信息抽帧方案



图 5-2 基于聚类抽帧方案



图 5-3 基于无人机速度与视频帧率的动态设置抽帧方案

上述图片展示了不同算法对同一小段巡检视频进行抽帧的结果记录。这些结果通过对同一段视频应用不同的抽帧算法得到，为验证这些算法在实际巡检任务中的性能优劣，本文针对多个不同时间段的同一路线的巡检视频，采用不同算法进行了多次实验。在每次实验中，记录各

中国知网 https://www.cnki.net

算法的抽帧效果及相关指标数据，并对实验结果进行统计和分析。为了更客观地评价算法性能，本文对所有实验结果取平均值，以减少单次实验中可能存在的随机性误差和偶然因素的影响，实验数据如下表所示：

表 5-1 同一巡检视频不同巡检时间不同算法结果统计

巡检时间	算法	关键帧	准确率 P	查全率 R	评价系数
上午（天气较好）	运动信息	10	78%	54%	63.8%
	聚类	11	81%	72%	77.1%
	动态设置	10	82%	75%	78.3%
中午（有风）	运动信息	10	74%	57%	64.4%
	聚类	12	80%	77%	78.5%
	动态设置	10	71%	66%	68.4%
下午（天气较好）	运动信息	9	75%	58%	65.4%
	聚类	11	80%	72%	75.8%
	动态设置	10	83%	71%	76.5%

通过表格分析可以看出，在已知光伏板长度和光伏组串间距离的情况下，且无明显环境干扰时，自主动态设置抽帧方案的性能相比之下最为优越。该方案在准确率（P）和查全率（R）方面均表现突出，与基于聚类和运动信息的抽帧方法相比，其综合评价系数（F 值）较高，能够较为准确的获取光伏板区域的关键帧，但是相比于最佳定位还有一定差距。

然而随着环境因素的变化，自主动态设置方案的性能明显下降。由于环境干扰的存在导致无人机的运动轨迹和相机拍摄帧序的不稳定，目标帧的检测准确率降低，同时因为部分光伏板区间跨度较大，自主动态设置的错误帧率相较于其他两种算法更为明显，影响了关键帧提取的整体效率。

针对上述问题，本文提出了一种冗余帧筛选方法以优化数据存储和提高效率减小多余工作量，并在保留的帧中基于光伏组串中心偏移量选取最佳帧图像。

中国知网 https://www.cnki.net

5.2 优化的光伏组串动态关键帧提取

在无人机光伏巡检过程中，由于无人机的动态飞行模式，相同的光伏板可能出现在多个连续帧或是多个关键帧中。在数据处理阶段，需要确定一帧最优影像。本文设计的动态关键帧筛选方法先进行冗余帧筛选，因初步冗余帧筛选保留的帧中含有最佳帧以及其他帧，随后进行光伏组串中心偏移最小化的最佳帧判定以确定最佳帧。需要说明的是，因实验中红外光伏数据采集时相机设置问题，效果较差，本章中用可见光视频巡检演示，在第四章中 HSV 选择增强与自适应分割中，光伏可见光区域对应的 HSV 阈值范围为 H：90~120，S：0~255，V：0~255。

5.2.1 冗余帧筛选方法

冗余帧筛选旨在面对大篇幅的巡检视频时减少视频数据冗余，提高存储与处理效率，同时确保巡检视频中的每个光伏板仅保留最具代表性的画面，具体方法如下：

当光伏板的边缘完全进入视频画面时，定义该时刻的帧编号为：

$$F_{\text{start}} = i \tag{5-10}$$

随着无人机的持续前进，光伏板逐渐向画面中心靠拢，并在时间 t_{key} 内达到画面正中央。此时，光伏板的中心点与图像中心点重合，这一时刻的帧编号时间点可由以下公式计算：

$$t_{\text{key}} = \frac{l}{2v} \tag{5-11}$$

其中，l 表示光伏板长度，v 表示无人机速度，f 表示为相机帧率那么中心点帧编号大致为：

$$F_{\text{key}} = F_{\text{start}} + f \cdot \frac{l}{2v} \tag{5-12}$$

该帧被认为是最具代表性的帧，能够最大程度保证光伏板的完整性和对齐性。在此之后光伏板继续向后移动。为了防止画面冗余，设定为

中国知网 https://www.cnki.net

当光伏板中心越过图像中心半个长度后，删除去其后一帧及所有后续帧。删除操作的起始帧编号则为：

$$F_{\text{delete}} = F_{\text{key}} + 1 \tag{5-13}$$

从此帧开始，直到检测到新的光伏板进入画面前的所有帧均被移除，考虑到光伏板之间存在间隔 d，需要精确计算下一块光伏板进入画面的时间点。下一块光伏板的边缘进入视频的时间点与其对应帧率粗略计算为：

$$t_{\text{next}} = \frac{l + d}{v} \tag{5-14}$$

$$F_{\text{next}} = F_{\text{start}} + f \cdot \frac{l + d}{v} \tag{5-15}$$

在 F_{next} 帧后，将循环保留关键帧与冗余帧删除流程，其中，循环次数 n 为此时光伏板所在行数具体光伏板个数，而在垂直方向上，由于光伏组串宽度相比长度较小，设光伏组串高度为 h，间隔为 d_1，则时间间隔 t_1 为：

$$t_1 = \frac{h + d_1}{v} \tag{5-16}$$

最终，水平方向的光伏板按照关键帧选取和冗余帧删除策略进行处理，并循环 n 次，而在垂直方向上，确保每 t_1 时间内的所有帧均被保留具体流程图如下所示：

中国知网 https://www.cnki.net

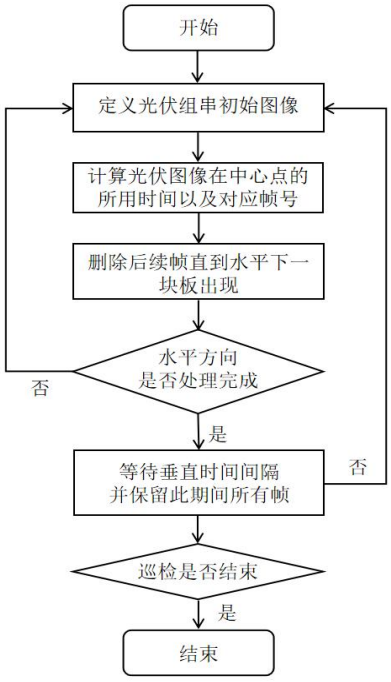


图 5-4 视频冗余帧筛选流程图

视频保留的初始帧与结束帧如图所示：



(a) 保留的起始帧　　(b) 保留的结束帧

图 5-5 聚冗余帧删除后保留的起始帧与结束帧

5.2.2 基于光伏组串中心偏移量的最佳帧判定

在冗余帧去除后保留着关键帧以及其他关键帧，为了从其中找到最佳帧，本文设计了光伏组串中心偏移量最小化的最佳帧判定方法，通过分析本文第四章中光伏板在影像中的空间位置，计算光伏组串中心与影像中心的偏移量，并选取偏移最小的帧作为最佳帧。该方法能够在快速

中国知网 https://www.cnki.net

巡检的过程中减少光伏板定位误差，提高巡检数据的空间一致性。

最佳帧的判定主要包括以下步骤：

Step1：光伏板检测与单目标选取：

在影像中检测光伏板目标，并选取最靠近影像中心的光伏板检测框。在巡检影像中，光伏板的位置通过本章第四节方法进行识别。设影像 I 中的光伏板检测框集合为：

$$B=\{B_1,B_2,...,B_N\} \tag{5-17}$$

其中，每个光伏板检测框 B_i 由其左上角坐标和右下角坐标确定，则检测框的中心坐标可表示为：

$$C_i=\left(\frac{x_{i1}+x_{i2}}{2},\frac{y_{i1}+y_{i2}}{2}\right) \tag{5-18}$$

在所有检测出的光伏板中，选取最靠近影像中心的光伏板检测框作为最终计算对象：

$$B^*=\arg\min_{B_i}||C_i-C_{frame}|| \tag{5-19}$$

表示选定的光伏板检测框，为影像中心点，为了度量光伏板的空间分布情况，需要计算其相对影像中心的偏移量。影像中心 C_{frame} 由影像尺寸确定：

$$C_{frame}=\left(\frac{W}{2},\frac{H}{2}\right) \tag{5-20}$$

其中 W，H 分别为影像的宽度和高度，而欧几里得距离用于衡量光伏板检测框中心点与影像中心的距离：

$$d_i=\sqrt{(x_i-W/2)^2+(y_i-H/2)^2} \tag{5-21}$$

最终选取偏移量最小的光伏板检测框 B^* 作为光伏组串的代表检测框，并以其中心点作为光伏组串中心。

Step2：光伏组串中心与偏移量计算：

选定的光伏板检测框的中心坐标即为光伏组串的中心：

$$C_{group}=C_{B^*}=(x_{group},y_{group}) \tag{5-22}$$

中国知网 https://www.cnki.net

式中，C_{group} 代表光伏板中心点的像素坐标，同时，为了衡量光伏板在影像中的对齐程度，计算其与影像中心的偏移向量：

$$V=(V_x,V_y)=C_{group}-C_{frame} \tag{5-23}$$

$$V_x=x_{group}-\frac{W}{2},\quad V_y=y_{group}-\frac{H}{2} \tag{5-24}$$

其中 V_x、V_y 表示光伏板在水平与垂直方向的偏移量。

Step3：最佳帧筛选：

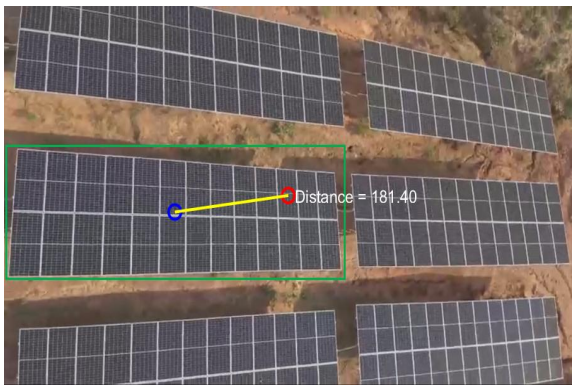
在所有包含目标光伏板的影像帧序列中，需要找到最优的一帧，使其光伏组串中心最接近影像中心。为此，定义整体偏移量 D 作为衡量标准，其计算公式为：

$$D=\sqrt{V_x^2+V_y^2} \tag{5-25}$$

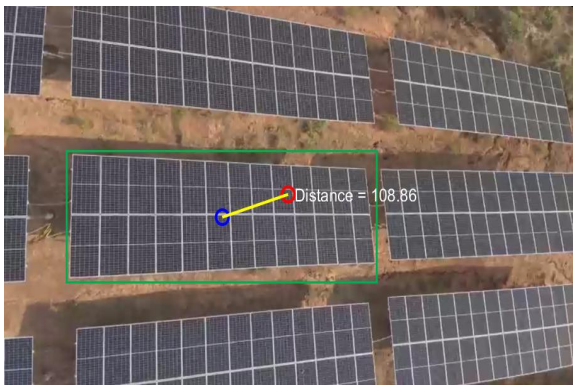
其中，D 越小，光伏板在该帧中越居中，该帧更适合作为最佳帧。在所有候选帧 F 中，计算每一帧的偏移量 $D(F)$并逐一对比，选择偏移量最小帧图为该光伏板最佳帧：

$$F^*=\arg\min_F D(F) \tag{5-26}$$

F^* 为最佳帧，$D(F)$表示第 F 帧的偏移量，如图所示：

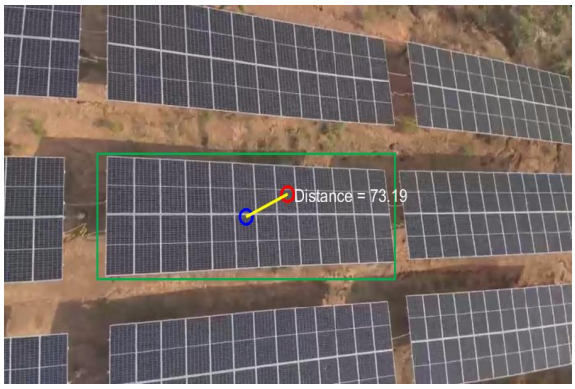


(a) 帧率图 1 以及偏移量



(b) 帧率图 2 以及偏移量

中国知网 https://www.cnki.net



(c) 帧率图 3 以及偏移量



(d) 帧率图 4 以及偏移量

图 5-6 分割效果图与结果框定

如图所示，红色表示影像图像中心，蓝色表示光伏组串中心，分别对帧率图 1、图 2、图 3 和图 4 中的同一个光伏组串中心进行检测并计算其与影像中心的偏移量。对比发现图 4 中的光伏组串中心与影像中心之间的即偏移量最小，能够提供更精准的设备定位，在这一帧中光伏板最接近影像中心。根据本文提出的“基于光伏组串中心偏移量最小化的最佳帧判定方法”将图 4 视为最佳帧并保存。

根据 5.1 小节的评价指标，对优化后的光伏组串动态关键帧进行实验，相比与前面 5.1 章节的分析，本节中提出的方法无论在准确率、查全率和调和均值中都接近于百分之百，且外界环境对实验结果几乎没有干扰，有着较强的稳定性。

5.3 改进的光流法与光伏组串设备定位

最佳帧确定后，面对最佳帧图片如何与光伏场站的设备编号对应起来实现光伏场站的设备定位难以解决，由于光伏组串较多，无人机采用往复式巡检方式可能使光伏板的相对位置关系变得不清晰，导致结果的混乱和误差的累积，为了避免这一现象，本文提出了一种改进光流法。

利用本章中 5.2.1 筛选冗余帧后保留的关键帧序列进行改进的光流法对光伏的运动轨迹进行判断，根据运动轨迹明确光伏板的前后关系。

光伏板的角点特征集中在组件边界、板间连接处等具有较强梯度变化的区域。为保证特征点的稳定性与分布均匀性，本文使用基于图像梯

中国知网 https://www.cnki.net

度的特征点检测方法，对光伏板区域进行特征提取，在每一帧图像中，利用第四章 Shi-Tomasi 角点检测方法提取光伏板区域的特征点，并通过设置最小距离约束，避免过密的特征点分布。

基于前面提取的特征点，利用改进的光流法，通过视频中的动态变化有效提取光伏组件巡检过程中的运动目标，光流场的基本方程可表示为：

$$\frac{\partial F_{j,t}}{\partial x}\cdot a_{xy}+\frac{\partial F_{j,t}}{\partial y}\cdot b_{xy}+\frac{\partial F_{j,t}}{\partial t}=0 \tag{5-27}$$

其中，$F_{j,t}$为j个特征点的灰度值，a_{xy}，b_{xy}为特征点在x、y方向的光流速度分量，$\partial F_{j,t}/\partial x$，$\partial F_{j,t}/\partial y$分别为灰度值在$x$与$y$方向的偏导数，$\partial F_{j,t}/\partial t$为灰度值时间的偏导数。

为进一步提高光伏板目标轨迹分析的精确度，本文引入拉格朗日乘子对基本方程进行约束优化，定义优化后的约束方程为：

$$\int\left[\begin{array}{l}\left(\frac{\partial F_{j,t}}{\partial x}\cdot a_{xy}+\frac{\partial F_{j,t}}{\partial y}\cdot b_{xy}+\frac{\partial F_{j,t}}{\partial t}\right)^2+\\ \alpha\left(\left(\frac{\partial a_{xy}}{\partial x}\right)^2+\left(\frac{\partial a_{xy}}{\partial y}\right)^2+\left(\frac{\partial b_{xy}}{\partial x}\right)^2+\left(\frac{\partial b_{xy}}{\partial y}\right)^2\right)\end{array}\right]dxdy=0 \tag{5-28}$$

式中α为拉格朗日乘子[104]，用于平衡光流场误差项与光流平滑项之间的关系，平滑项中的偏导数项$\partial a_{xy}/\partial x$、$\partial b_{xy}/\partial y$表示运动矢量在空间上的连续性。

为增强光伏板区域特征点对光流计算的贡献，本文在原始光流约束方程的基础上引入权函数，对目标区域赋予更高的权重，从而减少背景噪声的影响。改进后的光流约束方程如下

$$\int\left[\begin{array}{l}w_j(x,y)\left(\frac{\partial F_{j,t}}{\partial x}\cdot a_{xy}+\frac{\partial F_{j,t}}{\partial y}\cdot b_{xy}+\frac{\partial F_{j,t}}{\partial t}\right)^2+\\ \alpha\left(\left(\frac{\partial a_{xy}}{\partial x}\right)^2+\left(\frac{\partial a_{xy}}{\partial y}\right)^2+\left(\frac{\partial b_{xy}}{\partial x}\right)^2+\left(\frac{\partial b_{xy}}{\partial y}\right)^2\right)\end{array}\right]dxdy=0 \tag{5-29}$$

其中，$w_j(x,y)$为特征点权函数，a_{xy}、b_{xy}为特征点在x，y方向的光流速度分量，$\partial F_{i,t}/\partial x,\partial F_{i,t}/\partial y,\partial F_{i,t}/\partial t$表示图像的灰度梯度。

中国知网 https://www.cnki.net

权函数$w_j(x,y)$的作用在于为运动区域的特征点赋予较高权重，减少背景干扰区域对光流计算的影响计算公式为：

$$w_j(x,y)=\begin{cases}1,若\dfrac{\partial^2 F_{j,t}}{\partial x^2}+\dfrac{\partial^2 F_{j,t}}{\partial y^2}>T\\ 0,若\dfrac{\partial^2 F_{j,t}}{\partial x^2}+\dfrac{\partial^2 F_{j,t}}{\partial y^2}\le T\end{cases} \tag{5-30}$$

其中T为灰度梯度阈值，用于区分目标区域与背景区域。

为进一步提高光伏板运动轨迹的平滑性与稳定性，本文在光流速度矢量更新过程中引入了惯性补偿项。惯性项的作用在于利用当前和上一帧的光流矢量信息，平滑目标点的运动轨迹，惯性补偿后的光流速度矢量更新公式为：

$$a_{xy}^{j,h+1}=a_{xy}^{j,h}-\frac{\partial F_{j,t}}{\partial x}\left[\frac{\partial F_{j,t}}{\partial x}a_{xy}^{j,h}+\frac{\partial F_{j,t}}{\partial y}b_{xy}^{j,h}+\frac{\partial F_{j,t}}{\partial t}\right]+\rho(h)\left(a_{xy}^{j,h}-a_{xy}^{j,h-1}\right) \tag{5-31}$$

$$b_{xy}^{j,h+1}=b_{xy}^{j,h}-\frac{\partial F_{j,t}}{\partial y}\left[\frac{\partial F_{j,t}}{\partial x}a_{xy}^{j,h}+\frac{\partial F_{j,t}}{\partial y}b_{xy}^{j,h}+\frac{\partial F_{j,t}}{\partial t}\right]+\rho(h)\left(b_{xy}^{j,h}-b_{xy}^{j,h-1}\right) \tag{5-32}$$

式子中：$\rho(h)$为惯性补偿因子[105]，控制补偿幅度，$a_{xy}^{j,h}$、$b_{xy}^{j,h}$为第j个特征点在h次迭代时的光流速度分量。

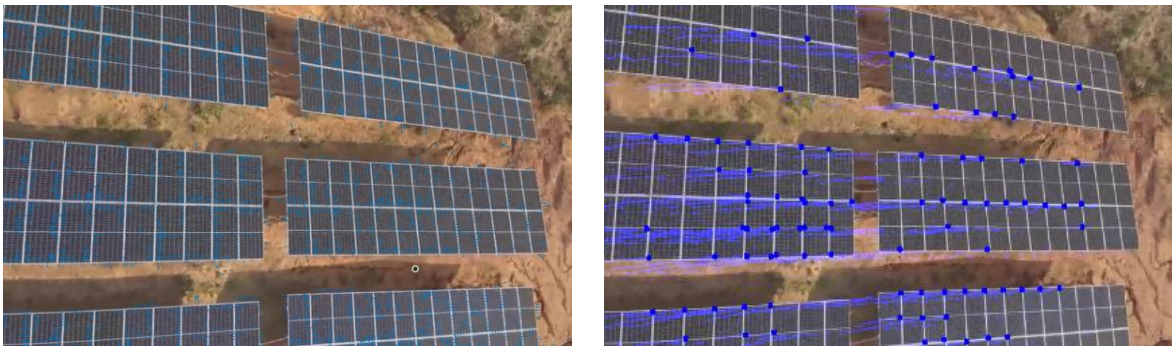
通过更新后的光流矢量，可以提取每个特征点的运动速度和方向：

$$v(x,y)=\sqrt{\left(a_{xy}^{j,h+1}\right)^2+\left(b_{xy}^{j,h+1}\right)^2} \tag{5-33}$$

$$\lambda(x,y)=\arctan\frac{b_{xy}^{j,h+1}}{a_{xy}^{j,h+1}} \tag{5-34}$$

式中$v(x,y)$、$\lambda(x,y)$分别为特征点的运动速度和运动方向角，同时为了确保光流计算的精确性，保留运动速度大于阈值的特征点，以减小噪声对光流计算结果的干扰，其结果如图 5-7 所示。

中国知网 https://www.cnki.net



(a) 普通光流　　(b) 改进后光流法

图 5-7 改进前与改进后对比图

由图可知，传统光流法在处理复杂环境下的光伏板巡检时，受外界环境因素影响较大，导致特征点的运动方向杂乱无章。由于传统光流法仅基于局部梯度信息计算运动矢量，其对噪声和干扰的鲁棒性不足，特征点运动方向的准确性大幅下降，使得两帧之间的相对运动关系难以判断，难以进行设备定位。

改进后的光流法在引入权重函数和特征点筛选机制后，能够有效排除受环境干扰较大的特征点，仅保留运动信息可靠的光流点，使得运动方向更加集中明确，能够有效的判断两帧直接的先后顺序与光伏板的相对位置，同时进一步优化光伏板相对位置计算，增强定位的鲁棒性，光伏场站设备图以及实验结果如下图所示：



(a) 实验光伏场站广角实拍图　　(b) 光伏场站设备编号图

图 5-8 实验光伏场站设备图

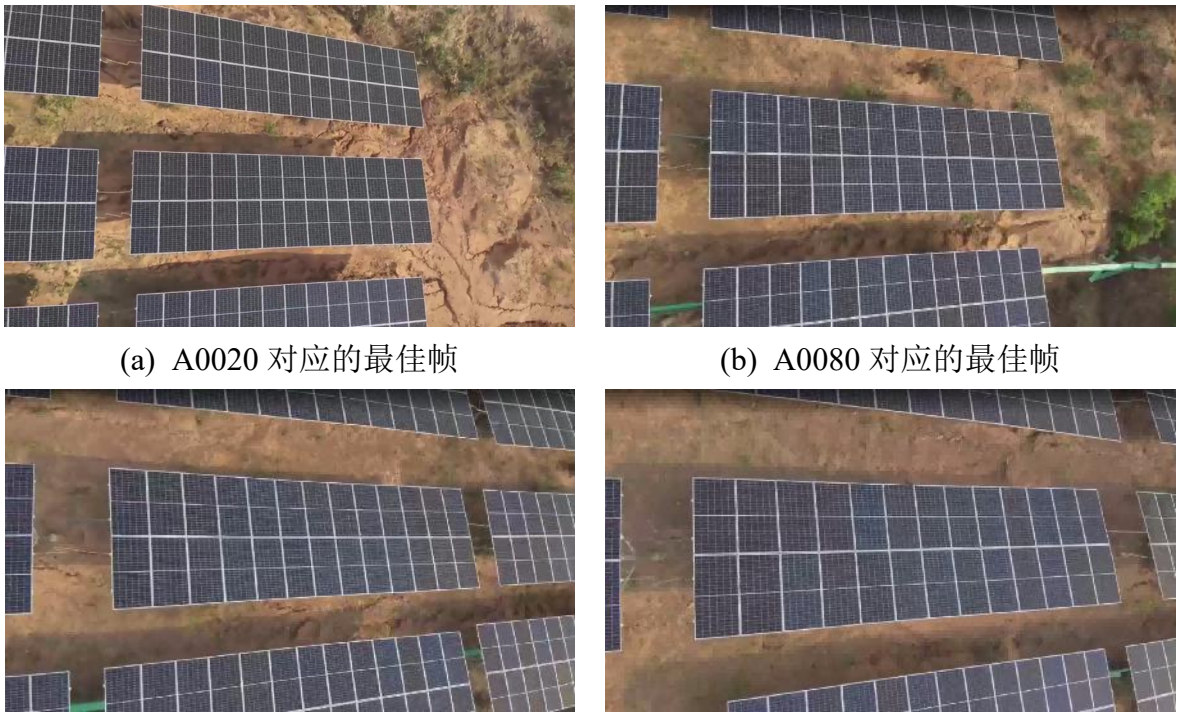
对于相似的两张图已知无人机轨迹规划后依据本文的改进光流法可将巡检视频最佳帧结果与其设备编号定位。

中国知网 https://www.cnki.net



(a) 某区域设备编号图　　(b) 无人机巡检方向

图 5-9 部分光伏场站设备编号与轨迹规划图



(a) A0020 对应的最佳帧　　(b) A0080 对应的最佳帧

(c) A0079 对应的最佳帧　　(d) A0078 对应的最佳帧

图 5-10 根据本文方法判断的相似帧分别对应的设备编号

根据本章中提供的方法，通过对视频进行最佳帧判定与改进的光流法进行设备定位后，原先单张巡检所需要的时间大大降低，极大的提高了巡检效率，同时通过本章中的方法，能够将视频巡检处理为第四章中的静态单张巡检，为后续进一步对光伏组串进行检验奠定基础。

中国知网 https://www.cnki.net

5.4 本章小结

本章提出了一种基于视频运动信息的光伏组串检测与定位方法，以提升无人机巡检的效率和精准度。传统的单帧拍摄方式因频繁动态调整导致巡检时间较长，而本方法通过无人机低速匀速飞行对光伏组串进行录像视频巡检并进行处理，提高处理效率。本章介绍了基于镜头边界、运动信息、聚类分析及无人机速度与视频帧率动态调整的抽帧方法，并通过实验验证了传统方法在视频巡检中的不足。针对此问题，本章提出了优化后的光伏组串动态关键帧选取，通过冗余帧删除筛选的方法保留光伏组串的连续关键帧，并对其计算光伏组串中心与影像中心的偏移量，选取偏移最小的帧作为最佳帧，最后通过改进的光流法，实现光伏板的设备定位。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第 6 章 总结与展望

6.1 工作总结

本文围绕光伏组串精准检测与定位方法展开深入研究，通过无人机巡检结合图像处理技术，能够有效提升光伏板故障检测的效率与准确性，为光伏电站的稳定运行提供有力保障，本文主要工作如下：

（1）针对光伏巡检数据采集问题，详细阐述了光伏组串的红外成像特性与无人机轨迹导航优化方法，对光伏组串红外图像进行了多种图像处理的实验与分析，提出了一种基于选择增强的 HSV 颜色空间优化方法，显著提升了光伏组串与背景的辐射差异，增强了图像的对比度并为后续图像处理奠定基础。

（2）在光伏组串检测与分割方面，本文研究了现有的部分传统图像检测与分割方法，详细介绍了基于灰度曲线的自适应 B 样条最小二乘拟合法。同时通过自主标记的样本增强，运用 YOLOv8 深度学习模型对光伏组串进行检测，对比分析不同方法的性能及优缺点。实验结果表明 YOLOv8 模型在检测精度和速度上均优于传统方法，但面对复杂背景和视角偏差时仍存在一定局限性。

（3）针对静态单张红外图像的光伏组串检测，本文提出了一种改进的 K-means 聚类检测方法。首先通过改进的统计概率霍夫直线检测算法提取光伏栅线，并结合共线性概率分析实现倾斜校正。随后利用选择增强的颜色空间对图像处理并自适应分割，通过角点检测的光伏组件变换矫正与高斯核密度估计的 K-means 聚类，优化了初始聚类中心选择，使准确率相比传统 K-means 算法和其他算法有明显提高。

（4）在基于视频运动信息的光伏组串检测定位方面，本文通过对比不同抽帧策略，提出了优化的光伏组串动态最优帧提取。通过冗余帧筛选减少多余数据，利用光伏组串中心偏移量最小化方法选定最佳帧，并最终结合改进的光流法实现设备定位。改进的光流法通过引入特征点筛选、权重函数和惯性补偿，使轨迹分析更稳定、精度更高，显著提高了

中国知网 https://www.cnki.net

光伏巡检的速度与准确度。

6.2 研究展望

本尽管本文在光伏组串检测与定位方法的研究中取得了一定成果，提升了检测的准确性和效率，但仍存在一些有待进一步改进和完善的地方：

（1）本文受限于有限资源，在具体实验中红外光伏组串较为单一，在视频巡检方面也因为相机的设置问题导致红外图像效果差只能用可见光图像代替，目前的研究在这些复杂环境下的适应性还有待进一步提高。未来可以通过开展更多的实地测试和实验，收集不同环境下的数据，并针对这些数据进行模型训练和算法优化，以增强光伏组串检测与定位方法在复杂环境下的鲁棒性。

（2）本文的研究主要集中在光伏组串的检测与定位方法上，但在实际运行过程中，还需要进一步实现智能化和自动化的巡检流程。后续可以结合无人机的自主飞行技术与最优路径算法，构建一个完整的智能化光伏巡检平台，实现路径规划、数据采集、光伏板检测的系统构建。

（3）深度学习是现在的主流趋势，后续可以通过进一步优化模型结构以及增加训练数据的多样性来提升模型的鲁棒性和泛化能力。

中国知网 https://www.cnki.net

参考文献

[1] 周得永. 基于电致发光太阳能电池板缺陷检测系统设计[D]. 扬州大学, 2022.

[2] 中研普华. 2024 年中国光伏发电行业发展现状、竞争格局及未来发展趋势与前景分析[EB]. 中研网. https://www.chinairn.com/hyzx/20240914/154831553.shtml. 2024.

[3] 前瞻产业研究院. 2022 年中国及 31 省市光伏行业政策汇总及解读[EB]. https://www.qianzhan.com/analyst/detail/220/220715-0f0918ba.html. 2022.

[4] 国务院新闻办公室. 中国应对气候变化的政策与行动[EB]. https://www.mee.gov.cn/zcwj/gwywj/202110/t20211027_958030.html. 2021.

[5] 国务院. 国务院关于印发 2030 年前碳达峰行动方案的通知[EB]. https://www.mee.gov.cn/zcwj/gwywj/202110/t20211026_957879.html. 2021.

[6] 侯林杰. 光伏巡检无人车路径规划算法研究[D]. 吉林大学, 2024.

[7] 王浩, 闫号, 叶海瑞, 等. 基于无人机的光伏电站智能巡检[J]. 红外技术, 2022, 44(5): 537-542.

[8] 赖菲, 陈亚鹏, 单正涛, 等. 深度学习算法在光伏电站无人机智能运维中应用[J]. 热力发电, 2019, 48(9): 139-144.

[9] 丁祎. 面向无人机光伏巡检的图像配准和目标检测算法研究[D]. 吉林大学, 2024.

[10] 郑维刚. 基于无人机红外影像技术的配电网巡检系统研究[D]. 沈阳农业大学, 2014.

[11] 陈亚东. 基于深度强化学习的无人机路径规划算法研究[D]. 齐鲁工业大学, 2024.

[12] 刘阳. 紫外光协作无人机任务分配和路径规划算法研究[D]. 西安理工大学, 2024.

[13] 刘昕. 复杂环境下无人机路径规划研究[D]. 电子科技大学, 2024.

中国知网 https://www.cnki.net

[14] 席志鹏. 无人机自主飞行若干关键问题研究[D]. 浙江大学, 2019.
[15] 曹玉康. 基于深度学习的光伏组件缺陷检测与分割方法研究[D]. 山东建筑大学, 2024.
[16] 雷叶. 基于深度学习的红外图像中光伏板热斑缺陷检测方法[D]. 兰州理工大学, 2024.
[17] 赵全钊. 基于 YOLO 的光伏板热成像故障检测算法研究[D]. 长安大学, 2024.
[18] 洪晓璇. 基于深度学习的多晶硅光伏电池电致发光图像缺陷检测[D]. 华中科技大学, 2023.
[19] 齐风扬. 基于无人机巡检的光伏区域视觉识别与定位方法研究[D]. 浙江大学, 2021.
[20] 艾明伟. 一种改进的 Canny 算子的图像分割在车辆检测中的应用[D]. 吉林大学, 2014.
[21] Andrade J, Katoch S, Turaga P, et al. Formation-aware cloud segmentation of ground-based images with applications to PV systems[C]//2019 10th International Conference on Information, Intelligence, Systems and Applications (IISA). IEEE, 2019: 1-7.
[22] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International journal of computer vision, 2004, 60: 91-110.
[23] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05). IEEE, 2005, 1: 886-893.
[24] Viola P, Jones M. Rapid object detection using a boosted cascade of simple features[C]//Proceedings of the 2001 IEEE computer society conference on computer vision and pattern recognition. CVPR 2001. IEEE, 2001, 1: I-I.
[25] Viola P, Jones M J. Robust real-time face detection[J]. International journal of computer vision, 2004, 57: 137-154.
[26] Felzenszwalb P, McAllester D, Ramanan D. A discriminatively trained,

中国知网 https://www.cnki.net

multiscale, deformable part model[C]//2008 IEEE conference on computer vision and pattern recognition. IEEE, 2008: 1-8.

[27] Felzenszwalb P F, Girshick R B, McAllester D. Cascade object detection with deformable part models[C]//2010 IEEE Computer society conference on computer vision and pattern recognition. IEEE, 2010: 2241-2248.

[28] Felzenszwalb P F, Girshick R B, McAllester D, et al. Object detection with discriminatively trained part-based models[J]. IEEE transactions on pattern analysis and machine intelligence, 2009, 32(9): 1627-1645.

[29] Girshick R, Felzenszwalb P, McAllester D. Object detection with grammar models[J]. Advances in neural information processing systems, 2011, 24.

[30] Girshick R B. From rigid templates to grammars: Object detection with structured models[M]. The University of Chicago, 2012.

[31] 叶俊杰, 高丙团, 陈昊, 等. 基于 HOG-SVM 分类器的电力屏柜锁孔快速检测方法[J]. 计算机应用与软件, 2023, 40(01): 134-138+188.

[32] 孙可, 张琦, 李航, 等. 基于改进可变形部件模型的车辆检测[J]. 沈阳师范大学学报(自然科学版), 2020, 38(06): 532-536.

[33] 王雪娇, 智敏. 基于可变形卷积神经网络的人体动作识别[J]. 计算机工程与科学, 2021, 43(01): 105-111.

[34] 齐风扬. 基于无人机巡检的光伏区域视觉识别与定位方法研究[D]. 浙江大学, 2021.

[35] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.

[36] 邓力, 谢爽爽, 刘全义, 等. 基于改进 YOLO 模型的飞机货舱红外图像火灾检测[J]. 航空科学技术, 2024, 35(11): 112-118.

[37] 王兴家, 郑纪业, 盛清凯, 等. 基于改进 YOLOv8n-seg 的群猪分割方法研究[J/OL]. 中国农业科技导报, 1-11[2025-03-04].

中国知网 https://www.cnki.net

[38] Khanam R, Hussain M. Yolov11: An overview of the key architectural enhancements. arxiv 2024[J]. arxiv preprint arxiv:2410.17725.

[39] 夏德喜, 刘浩满. 无人机自动化巡检技术在光伏电站中的应用[J]. 太阳能, 2023, (12): 74-81.

[40] 邢发男. 面向电网巡检的无人机任务卸载策略研究[D]. 南京信息工程大学, 2024.

[41] 姚瑛, 顾冰, 方正楠. 一种基于注意力机制目标检测的无人机的光伏板巡检方法[J/OL]. 电气传动, 1-8[2025-03-04].

[42] 吴张宇, 吴池莉, 于慧铭, 等. 面向大规模光伏电站的无人机巡检路径规划策略[J]. 综合智慧能源, 2024, 46(11): 46-53.

[43] 栾艳军. 光伏组件航拍红外图像的故障智能识别[D]. 河北大学, 2021.

[44] 李鑫林. 基于生成式对抗网络的光伏板热斑检测研究[D]. 东北电力大学, 2022.

[45] 焦思韬, 王可庆, 周奇, 等. 基于改进 SSD 算法的光伏板缺陷检测研究[J]. 软件, 2023, 44(12): 47-52.

[46] 兰金江, 曾学仁, 方亮, 等. 基于无人机巡检的光伏缺陷检测与定位[J]. 科技创新与应用, 2024, 14(18): 14-19.

[47] Guo R, You L, Zhou Y, et al. Non-volatile memory based on the ferroelectric photovoltaic effect[J]. Nature communications, 2013, 4(1): 1990.

[48] 周昶. 光伏电池阵列模拟电源的研究与设计[D]. 复旦大学, 2010.

[49] Da Rocha N M M, Brighenti L L, Passos J C, et al. Photovoltaic Cell Cooling as a Facilitator for MPPT[J]. IEEE Latin America Transactions, 2019, 17(10): 1569-1577.

[50] Kret J, Parola S, Martinez F, et al. Modeling and characterization of an MBE-grown concentrator PN GaSb solar cells using a pseudo-3D Model[J]. IEEE Journal of Photovoltaics, 2021, 11(4): 1032-1039.

[51] He Y, Deng B, Wang H, et al. Infrared machine vision and infrared

中国知网 https://www.cnki.net

thermography with deep learning: A review[J]. Infrared physics & technology, 2021, 116: 103754.

[52] Ye L, Cao Y, Skogestad S. Global self-optimizing control for uncertain constrained process systems[J]. IFAC-PapersOnLine, 2017, 50(1): 4672-4677.

[53] 席志鹏, 楼卓, 李晓霞, 等. 集中式光伏电站巡检无人机视觉定位与导航[J]. 浙江大学学报(工学版), 2019, 53(05): 880-888.

[54] 陈冉. 基于图像处理的太阳能电池无损检测技术研究[D]. 西安科技大学, 2019.

[55] 刘智嘉, 夏寅辉, 杨德振, 等. 基于中值滤波器的红外图像噪声处理的改进方法[J]. 激光与红外, 2019, 49(03): 376-380.

[56] 左志强, 唐新明, 李国元, 等. GF-7 星载激光测高仪全波形自适应高斯滤波[J]. 红外与激光工程, 2020, 49(11): 132-142.

[57] 毛峡, 石天朋. 光伏热斑图像有效区域分割算法研究[J]. 太阳能学报, 2018, 39(5): 1270-1276.

[58] 杨九章, 刘炜剑, 程阳. 基于对比度金字塔与双边滤波的非对称红外与可见光图像融合[J]. 红外技术, 2021. 43(9): 840-844.

[59] 许慧琴. 基于结构感知的自然图像保边平滑研究[D]. 兰州交通大学, 2022.

[60] 王奎, 黄福珍. 基于光照补偿的 HSV 空间多尺度 Retinex 图像增强[J]. 激光与光电子学进展, 2022, 59(10): 102-113.

[61] Tan S F, Isa N A M. Exposure based multi-histogram equalization contrast enhancement for non-uniform illumination images[J]. IEEE Access, 2019, 7: 70842-70861.

[62] Xu J, Hou Y, Ren D, et al. Star: A structure and texture aware retinex model[J]. IEEE Transactions on Image Processing, 2020, 29: 5022-5037.

[63] Jang J H, Bae Y, Ra J B. Contrast-enhanced fusion of multisensor images using subband-decomposed multiscale retinex[J]. IEEE Transactions on Image Processing, 2012, 21(8): 3479-3490.

中国知网 https://www.cnki.net

[64] Chen H, Zhao H, Han D, et al. Accurate and robust crack detection using steerable evidence filtering in electroluminescence images of solar cells[J]. Optics and Lasers in Engineering, 2019, 118: 22-33.

[65] Li X, Yang Q, Chen Z, et al. Visible defects detection based on UAV‐based inspection in large‐scale photovoltaic systems[J]. IET Renewable Power Generation, 2017, 11(10): 1234-1244.

[66] 丁畅, 董丽丽, 许文海. “直方图”均衡化图像增强技术研究综述[J]. 计算机工程与应用, 2017, 53(23): 12-17.

[67] 隋远峰. 图像信号处理器（ISP）-卷积神经网络（VGG16）联合优化及关键模块设计[D]. 大连理工大学, 2021.

[68] 李良福, 冯建云, 宋睿. 基于图像重生成的桥梁裂缝检测方法研究[J]. 光电子·激光, 2019, 30(12): 1298-1308.

[69] 朱铮涛, 萧达安. 基于非线性调整的伽马校正图像增强算法[J]. 计算机工程与设计, 2018, 39(9): 2822-2826+2866.

[70] 卢官明, 唐贵进, 崔子冠. 数字图像与视频处理[M].机械工业出版社, 2018.

[71] Fernández A, Usamentiaga R, de Arquer P, et al. Robust detection, classification and localization of defects in large photovoltaic plants based on unmanned aerial vehicles and infrared thermography[J]. Applied Sciences, 2020, 10(17): 5948.

[72] 应捷, 陈文, 杨海马, 等. 基于仿射变换与模板匹配的车位识别与计数算法研究[J]. 计算机应用研究, 2022, 39(3): 919-924.

[73] 杨磊, 高德东, 孟广双, 等. 光伏组件故障诊断方法研究[J]. 机械设计与制造, 2021, 370(12): 82-87.

[74] 柳扬, 陈美珍, 徐胜彬, 等. 基于热成像与灰度转换技术的光伏阵列缺陷检测方法[J]. 电子测量技术, 2021, 44(11): 96-102.

[75] Chen P, Zou T, Chen J Y, et al. The application of improved pso algorithm in pmmw image ostu threshold segmentation[J]. Applied Mechanics and Materials, 2015, 721: 779-782.

中国知网 https://www.cnki.net

[76] 刘昆, 刘卫东. 基于加权融合特征与 Ostu 分割的红外弱小目标检测算法[J]. 计算机工程, 2017, 43(07): 253-260.

[77] 宋森森, 贾振红, 杨杰, 等. 结合 Ostu 阈值法的最小生成树图像分割算法[J]. 计算机工程与应用, 2019, 55(09): 178-183.

[78] Liu L, Feng R. Least Squares Fitting with B-Spline by Genetic Algorithm[J]. 2014.

[79] 蒋琳, 苏建徽, 施永, 等. 基于红外热图像处理的光伏阵列热斑检测方法[J]. 太阳能学报, 2020, 41(08): 180-184.

[80] 曹娟, 欧阳永昇, 陈中贵, 等. 非均匀 B 样条曲面的自适应节点设置方法[J]. 计算机辅助设计与图形学学报, 2015, 27(01): 60-67.

[81] Hussain M Z, Khalid M, Irshad M, et al. Spline Functions and Genetic Algorithm for Reverse Engineering of Symmetric 3D Models[C]//2019 23rd International Conference in Information Visualization – Part II. IEEE, 2019: 134-140.

[82] 蒋琳, 苏建徽, 陈薇, 等. 基于灰度直方图自适应 B 样条曲线拟合的光伏组件热斑检测方法[J]. 太阳能学报, 2024, 45(06): 310-315.

[83] 王燕妮, 张婧菲. 改进 YOLOv8 的无人机小目标检测算法[J/OL]. 探测与控制学报, 1-10[2025-03-04].

[84] 刘涛. 硅基光伏电池缺陷电脉冲红外热成像检测技术研究[D]. 哈尔滨商业大学, 2022.

[85] 李红娣, 袁非牛. 采用金字塔纹理和边缘特征的图像烟雾检测[J]. 中国图象图形学报, 2015, 20(06): 772-780.

[86] 陶志勇, 杜福廷, 任晓奎, 等. 基于 T-VGG 的太阳电池片缺陷检测[J]. 太阳能学报, 2022, 43(07): 145-151.

[87] 刘正国. 基于深度学习的麦穗和稻穗检测识别研究[D]. 南京信息工程大学, 2024.

[88] 杨君保. 基于改进 K-means 算法的大跨屋盖结构表面风荷载分区研究[D]. 石家庄铁道大学, 2023.

[89] 李茂月, 刘泽隆, 赵伟翔, 等. 面结构光在机检测的叶片反光抑制技

中国知网 https://www.cnki.net

术[J]. 中国光学, 2022, 15(03): 464-475.

[90] 姜斌, 石峰, 崔东旭, 等. 改进的 K 均值聚类红外目标检测方法[J]. 应用光学, 2012, 33(04): 766-769.

[91] 洪梦霞, 梁少华. 基于 RGB 颜色空间的彩色图像分割[J]. 电脑知识与技术, 2020, 16(34): 225-227.

[92] ZhangShuji. Image and processing analysis[M]. Beijing: Tsinghua University Press. 1999, 19-21.

[93] Pathak S P, Patil S A. Evaluation of effect of pre-processing techniques in solar panel fault detection[J]. IEEE Access, 2023, 11: 72848-72860.

[94] Zhang Q, Nie Y, Zheng W S. Dual illumination estimation for robust exposure correction[C]//Computer graphics forum. 2019, 38(7): 243-252.

[95] Zhao L, Wang Y, Liu J. Detection and analysis of photovoltaic panels based on UAV and HSV space[J]. Infrared Technology, 2020, 42(10): 978-982.

[96] 廖纪勇, 吴晟, 刘爱莲. 基于相异性度量选取初始聚类中心改进的 K-means 聚类算法[J]. 控制与决策, 2021, 36(12): 3083-3090.

[97] Veraverbeke N, Janssen P, Swanepoel J W H. Efficiency behaviour of kernel-smoothed kernel distribution function estimators[J]. South African Statistical Journal, 2020, 54(1): 15-23.

[98] Han B, Comaniciu D, Zhu Y, et al. Sequential kernel density approximation and its application to real-time visual tracking[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2008, 30(7): 1186-1197.

[99] 曹志广, 陈玮, 马如豹. K 均值和最大加权熵在彩色图像分割中的应用[J]. 计算机工程与应用, 2012, 48(21): 174-177.

[100] 王惠琴, 侯文斌, 彭清斌, 等. 基于 K 均值聚类的 SPPM 分步分类检测算法[J]. 通信学报, 2022, 43(01): 161-171.

[101] Cernekova Z, Pitas I, Nikou C. Information theory-based shot cut/fade

中国知网 https://www.cnki.net

detection and video summarization[J]. IEEE Transactions on circuits and systems for video technology, 2005, 16(1): 82-91.

[102] 刘洁. 基于光流法的运动目标检测和跟踪算法研究[D]. 中国矿业大学, 2015.

[103] Lai J L, Yi Y. Key frame extraction based on visual attention model[J]. Journal of Visual Communication and Image Representation, 2012, 23(1): 114-125.

[104] 陈希有, 郭源博, 齐琛, 等. 论拉格朗日方程与基尔霍夫定律相互演绎[J]. 中国电机工程学报, 2022, 42(05): 2036-2045.

[105] 铁富珍. 基于改进光流法的视频监控中人群异常行为检测算法[J]. 现代电子技术, 2024, 47(07): 45-48.

中国知网 https://www.cnki.net